生成式 AI 与随机热力学：自由能的故事

Generative AI and Stochastic Thermodynamics: A Tale of Free Energies

Max Welling, Sirui Lu, Lars Holdijk

First Edition · Cambridge University Press · 2026

数译 翻译及重排

Model: AI 辅助翻译

Updated: 18 Oct 2026

数译
mathtranslations.org

译者说明

本译本以剑桥大学出版社 2026 年第一版 *Generative AI and Stochastic Thermodynamics: A Tale of Free Energies*（Max Welling、Sirui Lu、Lars Holdijk 著）为底本翻译. 翻译遵循“数学含义优先于句式”的原则，保留原书的定义、假设、量词、逻辑依赖、记号与公式结构. 彩色配图直接采用原书图版；适合用节点与箭头表达的关系图（如交换图）以 `tikz-cd` 重绘. 人名与人名派生术语保留原文拼写（如 Langevin、Schrödinger、Hamilton），不做音译.

排版流程：

1. 以原书为最高依据完成翻译；
2. 按本模板完成 LaTeX 排版与交叉引用；
3. 编译通过后进行中文术语、数学结构、编译排版三轮检查.

排版细则：行间公式统一使用 `align`、`aligned` 或 `align*` 环境；有序列表一律使用 `enumerate`；中文双引号前引号写作 “，后引号写作”；句末使用英文句点 “.”，其余标点使用中文标点.

数译
18 Oct 2026

目录

译者说明 i

前言 1

致谢 2

为什么需要机器学习的随机热力学？ 3

第 1 章 数学预备知识 7

1.1 引言 . . . 7
1.2 概率 . . . 7
1.2.1 概率质量函数与概率密度函数 . . . 7
1.2.2 条件分布与 Bayes 法则 . . . 9
1.2.3 熵 . . . 11
1.2.4 分布之间的比较 . . . 11
1.3 期望的近似计算 . . . 13
1.3.1 Monte Carlo 近似 . . . 13
1.3.2 采样方法 . . . 15
1.4 对称性 . . . 16
1.5 凸优化要点 . . . 18
1.5.1 原问题 . . . 18
1.5.2 对偶问题 . . . 19
1.5.3 弱对偶与强对偶 . . . 19
1.5.4 Karush–Kuhn–Tucker 条件 . . . 20
1.5.5 由最大熵原理导出正则系综 . . . 21
1.6 Lagrangian 视角与 Eulerian 视角 . . . 23

第 2 章 神经网络预备 25

2.1 引言 . . . 25
2.2 多层感知机 . . . 25
2.3 卷积神经网络 . . . 27
2.4 现代 CNN 架构 . . . 30
2.5 Transformer . . . 31
2.6 反向传播规则的 Lagrangian 推导 . . . 33

第 3 章 物理预备 35

3.1 引言 . . . 35
3.2 统计力学基础 . . . 35
3.2.1 能量与 Hamiltonian . . . 36
3.2.2 微正则系综：能量恒定的系统 . . . 37
3.2.3 正则系综：温度恒定的系统 . . . 40
3.2.4 从配分函数到热力学量 . . . 41

3.2.5 其他宏观量 . . . 43
3.3 热力学基础 . . . 45
3.3.1 热力学第一定律 . . . 45
3.3.2 热力学第二定律 . . . 47

第 4 章 隐变量模型与图模型 51
4.1 引言 . . . 51
4.2 隐变量模型 . . . 51
4.3 图模型 . . . 52
4.4 变分期望最大化算法 . . . 55
4.4.1 VE 步 . . . 56
4.4.2 VM 步 . . . 58
4.5 变分贝叶斯 . . . 60

第 5 章 概率机器学习的热力学 64
5.1 引言 . . . 64
5.2 联系热力学与 ML 中的自由能 . . . 64

第 6 章 置信传播 68
6.1 置信传播及其扩展 . . . 68
6.2 一个马尔可夫链例子 . . . 72

第 7 章 变分自编码器 74
7.1 引言 . . . 74
7.2 机器学习中的自由能 . . . 74
7.3 变分期望最大化 . . . 75
7.4 层次化 VAE . . . 76

第 8 章 归一化流 78
8.1 引言 . . . 78
8.2 变换概率分布 . . . 78
8.2.1 隐变量模型中的 Jacobian . . . 80
8.3 归一化流 . . . 81
8.4 训练 . . . 82
8.5 可逆变换 . . . 84
8.6 ELBO 的分解 . . . 85
8.7 热力学解释 . . . 85

第 9 章 马尔可夫过程与时间反演 87
9.1 引言 . . . 87
9.2 五个马尔可夫核 . . . 87
9.2.1 对偶核 . . . 92
9.3 时间反演 . . . 93
9.3.1 Hamilton 系统的时间反演 . . . 93

9.3.2 马尔可夫过程的时间反演 94

第 10 章 随机热力学 **97**
10.1 引言 97
10.2 随机热力学 97
10.3 随机过程 97
10.3.1 记号 97
10.3.2 Hamilton 系统 98
10.3.3 离散时间马尔可夫过程 98
10.4 热力学量 100
10.5 随机热力学第一定律 101
10.5.1 Hamilton 系统 101
10.5.2 离散时间马尔可夫过程 103
10.6 第二定律：热力学与统计不可逆性 104
10.6.1 Clausius 表述与熵产生 104
10.6.2 Kelvin 表述与耗散功 106

第 11 章 马尔可夫链蒙特卡洛 **108**
11.1 引言 108
11.2 马尔可夫链蒙特卡洛 108
11.3 为 MCMC 设计马尔可夫核 109
11.3.1 平稳分布 109
11.3.2 遍历性 112
11.4 MCMC 核的例子 114
11.4.1 Gibbs 采样 115
11.4.2 Hamiltonian Monte Carlo 115
11.4.3 Langevin 蒙特卡洛 118

第 12 章 序贯重要性采样 **120**
12.1 引言 120
12.2 IS 与 SNIS 的方差 120
12.3 序贯重要性采样 122
12.3.1 沿时间正向延拓提议分布 123
12.3.2 沿时间反向延拓目标分布 123
12.3.3 利用 SIS 框架估计期望 123
12.3.4 优化序贯重要性采样 126

第 13 章 变分扩散模型 **130**
13.1 引言 130
13.2 作为图模型的扩散模型 130
13.3 自由能（证据下界）界 132
13.3.1 后向核与流平衡方程 132
13.3.2 条件分布的 ELBO 134

13.4 训练解码器模型 . . . 134
13.5 方差缩减技术 . . . 136
13.6 实现细节 . . . 137

第 14 章 Schrödinger 桥 139
14.1 引言 . . . 139
14.2 Schrödinger 桥 . . . 139
14.3 训练扩散 Schrödinger 桥 . . . 143
14.4 与最优传输的关系 . . . 144
14.5 与最大 Caliber 的关系 . . . 145

第 15 章 最优控制 147
15.1 引言 . . . 147
15.2 基于模型的强化学习 . . . 147
15.3 最优控制 . . . 148
15.4 Kullback–Leibler 控制 . . . 149
15.4.1 与推断的关系 . . . 151
15.4.2 学习策略 . . . 152
15.4.3 与 Schrödinger 桥的关系 . . . 153

第 16 章 生成流网络 154
16.1 引言 . . . 154
16.2 生成流网络 . . . 154
16.3 与序贯重要性采样的关系 . . . 156
16.4 与变分推断的关系 . . . 157
16.5 与 AIS 的关系 . . . 158
16.6 与其他概念的关系 . . . 158

第 17 章 涨落定理 159
17.1 引言 . . . 159
17.2 涨落定理背后的数学 . . . 159
17.3 三种熵产生分解 . . . 161
17.3.1 证明 . . . 162
17.3.2 熵产生的显式表达式 . . . 163
17.4 三个涨落定理的推导 . . . 164
17.5 Crooks 涨落定理与 Jarzynski 等式 . . . 165

第 18 章 自由能估计 168
18.1 引言 . . . 168
18.2 自由能估计 . . . 168
18.2.1 自由能微扰 . . . 168
18.2.2 热力学积分 . . . 169
18.3 非平衡功测量 . . . 170
18.3.1 Jarzynski 估计量 . . . 171

18.4 双向估计量：Crooks 与 Bennett 172
18.4.1 Bennett 接受率方法 173

第 19 章 伴随自由能估计与涨落定理 175
19.1 用于自由能估计的伴随模拟 175
19.2 伴随 Jarzynski 等式 179
19.3 反绝热驱动 181

第 20 章 混合随机流与满射流 182
20.1 随机归一化流 182
20.2 满射流 184

第 21 章 从 Fokker–Planck 方程看随机热力学 191
21.1 连续性方程 191
21.2 能量变化与第一定律 193
21.3 熵产生与第二定律 195
21.4 Fokker–Planck 方程作为梯度流 197
21.5 广义 Fokker–Planck 方程 198
21.6 对应的随机微分方程 200
21.7 第二定律（再说一次） 200
21.8 自由能变化与过剩功 201

第 22 章 最优传输与 Schrödinger 桥 203
22.1 最优传输与 Wasserstein 距离 203
22.2 最小耗散功 205
22.3 反绝热驱动 207
22.4 Jordan–Kinderlehrer–Otto 格式 208
22.5 Schrödinger 桥 210
22.6 更一般的作用量 212
22.7 与最优控制的关系 213
22.8 回到扩散模型 215

第 23 章 连续归一化流与流匹配 217
23.1 连续归一化流 217
23.2 流匹配 220

第 24 章 自由能才是你所需要的一切 229

术语索引 248

前言

我们都有过这样的经历：问题的答案是在骑车、洗澡、走回家、在卫生间 “放松”、或者早上醒来时冒出来的. 重要的是，它不是在你对着纸上的方程、有意识地拼命求解时出现的. 事实上，我敢说，我最关键的进展都是在休息、“跳出问题” 时取得的. 希腊哲学家思考问题时绕着圈子散步，而我们大多数人却整天盯着电脑屏幕. 写这篇前言的目的，是让你更清楚地意识到你那富有创造力的心智藏在何处，以及如何富有成效地与它互动.

我们的基本论点是：与流行的看法相反，创造性思维并不是由有意识的思考完成的. 它更像是一种交互：你的意识准备好 “种子”，把它们种进你心智的无意识部分，后者会在 “看不见的地方” 反复咀嚼问题，然后在相当随机的时刻把有希望的求解路径送回你的意识. 这个过程不断迭代，直到意识判断问题已经解得足够好、已经无从下手、或者干脆无聊透顶，于是转向下一个问题. 当你得知至少有一部分思考发生在你心智（或者肠胃?）中一个似乎难以触及、且与你所认为的 “自我” 之间接口十分有限的部分时，或许会有些不安. 但不可否认，它就在那里，并在创造性思维的过程中扮演着角色.

要成为一名富有创造力的思考者，就应该学会把这场游戏玩得更好. 为此，我们应当思考：用什么语言来表征知识，才能最有效地与我们的无意识心智沟通. 换言之，我们应当在意识与无意识心智之间使用什么样的 “接口”?

把一条复杂方程或问题的所有细节都死记硬背下来，大概不是个好主意. 相反，我们应当提炼出抽象的思想，用一幅图来捕捉它的精髓. 这可以是一部带有色彩和种种华丽细节的电影，也可以是一种更 “平淡” 的表征，只要管用就好.

关于所呈现内容的反思. 原因似乎在于：你试图从讲座中捕捉的那个抽象思想，与你已经存储的某个相似思想发生了冲突. 而这反过来可能意味着，你要么误解了这个思想、需要更新它，要么正在呈现的东西本身就有问题. 类似地，你可以很容易地察觉到某个思想只是你已知内容的一个小扰动（你会感到愉快的乏味），或者某个思想是全新的（你会感到好奇并略带挫败）. 新手不断受到挑战、常常感到应接不暇；而更有经验的研究者 90% 的时间都游刃有余，因为 “新” 思想其实早已在他们的数据库里，几乎不需要更新.

不知何故，我们的无意识心智还能把已有的抽象思想操弄成新的思想. 这正是我们通常所说的创造性思维. 你可以通过把一个问题播撒进心智来刺激它. 这是一种有意识的努力，通常包括细致的数学推导，以及为你试图理解的事物构建一幅直观的图景或隐喻. 如果你在这个过程中投入足够的时间和精力，然后走回家吃午饭，你会发现自己仍在以一种模糊得多的方式思考它：你回顾并创造关于该问题的视觉表征. 接着你把心思完全从问题上移开；当你走回工作岗位时，解的若干部分会突然浮现到意识中. 不知何故，你的无意识心智接管了问题，并继续在它上面工作. 精髓在于：你创造了视觉表征，作为无意识心智得以加工的积木.

无论这个过程的细节究竟如何（我不是心理学家），我猜想任何好的解释都应当同时包含直观的部分（包括例子、隐喻和可视化）和精确的数学部分（每个方程与推导都得到恰当解释）. 这，便是我们为自己设定的挑战. 而你的任务，是坚持去理解正在传达的抽象思想.

致谢

本书的源头可以追溯到 2023 年 10 月，当时我（MW）与妻子 Marga 一起在我最钟爱的国家意大利旅行. 每天早晨，我们住在意大利乡村某个随机的 Airbnb，我一边享用卡布奇诺，一边写上几页书. 因此，第一个要感谢的人是 Marga，感谢她容忍我在这趟旅行中把一半时间都花在写作上.

2024 年 1 月至 2 月，我以 Merkin 杰出教授的身份在帕萨迪纳访学两个月，写作得以继续. 我特别感谢 Pietro Perona，没有他，这次访学便无从谈起.

到 2024 年 3 月完成的那部分书稿，构成了我在南非穆伊曾贝格的非洲数学科学研究所（AIMS）所做一系列讲座的基础. 我感谢 AIMS 的组织者，特别是 Ulrich Paquet 和 Claire David，感谢他们对这次访问的慷慨支持. 然而最重要的是，我想感谢 AIMS 那些聪慧的学生，他们参加了我们的讲座系列，并在我们共同尝试梳理构成本书基础的种种关系时满怀热情地投入其中. 没有他们富有洞见的问题，这本书真的不会问世.

在写作过程中，作者们受益于与 Sandeep Suresh Cranganore 的讨论，内容涉及在（共）动参考系中功、热与熵的定义.

本书由 Ulrich Paquet 和 Miranda Cheng 试读，我感谢他们宝贵的反馈.

为什么需要机器学习的随机热力学？

在概率机器学习、图模型或生成式人工智能（AI）中，我们使用概率来表达对世界中那些未被我们显式建模的众多自由度的不确定性. 世界实在太过复杂、太过混沌，无法把它们全部追踪. 于是，我们引入粗粒化的、随机的（随机变量意义上的 “随机”）变量，并设计概率模型来描述它们.

在物理中情况与此类似. 要描述一个由大量分子构成的系统，追踪其组成原子与电子的全部自由度是完全不可能的. 于是物理学家发展出热力学与统计物理等理论，通过概率分布来近似地描述这些系统. 在这个框架下，我们可以计算期望（平均）量及其涨落，而无需追踪每一个原子.

在机器学习（ML）中，我们清楚地知道概率更像是信念：它们表达的是我们关于世界处于某一特定状态的信念，并赋予某一概率. 这些概率并没有什么 “实在的” 或本体论的东西；相反，它们反映的是我们知识的缺失.

类似地，在物理中，熵也没有什么物理实体. 它是一种计算工具，告诉我们在对世界的描述中缺失了多少信息. 不过，不知道粒子精确的位置与速度，会带来真实的后果：我们因此无法做功. 这就是为什么我们从能量中减去熵，并把结果称为 “自由能”，因为它是仍然可用于做功的能量.

Maxwell 妖的思想实验绝妙地阐明了这一概念：小妖利用它对粒子位置与速度的了解，在恰当时刻打开一扇小门，通过一个滑块把所有粒子赶到盒子的一侧. 一旦所有粒子都集中到一侧，小妖关上门、松开滑块——滑块会因两侧的压差而运动——从而做功. 可见，知识的缺失会真实地影响我们能从系统中提取多少能量.

变分推断在 ML 中最早的应用，或许是 Peterson 与 Anderson（1987）. 据我们所知，自由能的概念最早由 Hinton 及其合作者（Hinton and Zemel, 1993; Hinton and van Camp, 1993）在 Bayes 学习与最小描述长度的背景下引入. 结构化变分逼近则由 Jordan 实验室的一系列论文发展出来（Jaakkola and Jordan, 1996; Saul et al., 1996; Ghahramani and Jordan, 1997; Jaakkola and Jordan, 1997; Jordan et al., 1999）. 另一篇里程碑式的论文是 Neal 与 Hinton（1998），其中研究了自由能与期望最大化原理之间的关系. 如今，人们通常把变分推断的自由能形式称为 ELBO（证据下界，Evidence Lower Bound；Blei et al., 2017），这个术语最早由 Braun 与 McAuliffe（2010）提出. ELBO 在变分自编码器（Kingma and Welling, 2014; Rezende et al., 2014）以及其后的层次化变体（例如现代扩散模型；Sohl-Dickstein et al., 2015; Ho et al., 2020; Song et al., 2021; Kingma et al., 2021; Huang et al., 2021）的发展中扮演了关键角色.

本书将更深入地挖掘热力学与生成式 AI 之间的这一关系. 不过，热力学与统计力学描述的是处于平衡态的物理系统，而生成式 AI 真正描述的却是远离平衡态的系统（而且它就运行在你的电脑里）. 例如，我们会发现，一次学习步与在物理系统中做功非常相似. 类似地，推断最好与一个趋向平衡态的物理系统相比较.

两者之间最美妙的联系，或许出现在现代扩散模型中（Sohl-Dickstein et al., 2015; Ho et al., 2020; Song et al., 2021）：一个数据样本被施以热力学第二定律，逐步解构为噪声. 生成式 AI 如今把这个过程反转过来，学会把噪声重新变回结构. 这就像谚语所说的 “把煎蛋重新打散”!

把结构变成噪声、并在此过程中增加总熵的过程，在物理世界中无处不在. 鸡蛋掉

到地上、你的身体在你死后回归“尘土”、宇宙最终衰变为低能光子，都是如此. 热力学第二定律说总熵永不减少，但这并不意味着我们不能在局部减少熵. 而学习所发生的，恰恰就是这种局部熵减：当我们通过反转加噪过程来学习生成模型时，它在发生；当生命利用来自太阳的能量在地球上生长时，它在发生；当演化产生出漫游地球的新物种时，它也在发生.

本书旨在弥合 ML（Bishop, 2006）与非平衡热力学（Zwanzig, 2001）（或称随机热力学：Sekimoto, 2010; Van den Broeck and Esposito, 2013; Peliti and Pigolotti, 2021; Shiraishi, 2021）之间的鸿沟. 我们希望同时帮助 ML 与自然科学两个领域的学生和研究者：

- 在这两门看似如此不同的学科之间建立联系；
- 理解 ELBO 是一种自由能；
- 理解变分期望最大化算法可以从功、热与熵最大化的角度加以解释；
- 理解变分自编码器及其层次化表亲——扩散模型——实际上是在学习远离平衡态的物理系统；
- 理解在这些模型中，无论通过变分方法还是马尔可夫链蒙特卡洛方法进行的推断，都与物理系统弛豫到平衡态非常相似.

事实上，我们甚至会展示：最优控制与强化学习也可以被看作一个由自由能描述的受控物理系统.

我们甚至愿意说，这些理论之间并没有真正的区别. 概率 ML、图模型、生成式 AI——无论你如何称呼这些方法，包括它们的学习算法与受控版本——都可以用与非平衡热力学相同的数学来描述，并且事实上可以富有成效地被视为一类运行在你电脑里的物理系统.

本书由三个部分组成. 第一部分引入一些数学工具，例如概率、对称性与凸优化. 我们还提供一份自包含的深度学习入门. 最后，我们讨论统计物理与热力学的基础.

第二部分是本书的核心，我们用离散时间演化来描述远离平衡态的演化系统. 我们引入本书最核心的概念：变分自由能. 这个自由能泛函既在物理中用于描述远离平衡态的热力学系统，也在 ML 中作为带隐变量的概率模型的学习目标. 在本书中我们论证：这两种自由能密切相关，这意味着我们可以把推断看作一个弛豫到最低自由能态的物理系统，而把学习看作对物理系统做功.

本书的这一部分尝试把 ML 中的许多概念与物理中的概念联系起来. 例如，我们把统计学中的（变分）期望最大化算法解释为：在变分后验分布上最小化自由能（产生热），以及在模型参数上最小化自由能（做功）. 我们说明，在物理与 ML 中都有应用的置信传播，不过是又一种最小化变分自由能的算法. 我们讨论变分自编码器（VAE）、归一化流（NF）与扩散模型等生成模型，以及它们与自由能和热力学概念之间的关系.

在第二部分中，我们还相当全面地概述了从物理学家视角看到的随机热力学概念，包括著名的涨落定理——它描述了远离平衡态系统中功、热、熵等热力学量之间的精确关系. 为了深入理解这些涨落定理，我们加入了一章关于时间反演对称性的内容，时间

反演对称性的破缺与熵产生相关. 我们还加入了一章关于自由能估计方法的内容，因为这类方法在制药与化学工业中非常流行，例如用于计算药物与蛋白质结合的优劣.

事实证明，涨落定理与马尔可夫链采样文献中的思想——例如 “退火重要性采样” 以及其他序贯蒙特卡洛方法——密切相关. 马尔可夫链蒙特卡洛（MCMC）采样代表了另一族执行推断与（Bayes）学习的方法. 马尔可夫链是收敛到所关心目标分布的系统，遵循与物理系统弛豫到平衡态相同的数学. 本书设有关于 MCMC 与序贯重要性采样的章节.

迄今为止最成功的一类生成模型是扩散模型，它们也是促使我们写作本书的灵感来源，因为它们几乎完美地对应于非平衡热力学的数学. 我们更进一步，还详细展示了诸如随机归一化流与 SurVAE 流之类的混合方法，在物理中对应于伴随自由能方法.

最后，在第二部分中，我们讨论随机（非平衡）热力学系统与 Schrödinger 桥、生成流网络、最优控制等概念之间的关系.

第三部分用 Fokker–Planck 方程引入随机热力学的连续时间表述. 物理系统的反绝热驱动与最优传输理论之间存在着优美的联系，我们在这一部分尝试加以解释. 而这又把我们带回到以基于流的方法为形式的 ML.

在第四部分，我们以 “自由能才是你所需要的一切” 一章作为结尾，强调本书的所有概念都由万能的自由能黏合在一起.

本书基于 2024 年 3 月至 4 月我在南非穆伊曾贝格非洲数学科学研究所讲授的课程. 它绝不是对非平衡热力学与机器学习这两个领域之间所有联系的完备论述. 我们主要局限于离散时间系统，只在最后几章讨论基于 Fokker–Planck 方程的连续时间描述. 我们完全避开了基于 Langevin 方程与路径积分方程的随机微分方程描述. 主要原因是它们的数学会变得相当艰深，我们认为对于初次接触该主题而言并无必要. 此外，离散时间表述是最容易直接与 ML 文献相衔接的. 我们确实打算再写一本书（或本书的后续版次），把这一更宽泛的理论体系纳入进来.

我们衷心希望本书能帮助来自 ML 与自然科学两个群体的学生与研究者，弥合这两个领域之间的鸿沟，并受益于对方领域已取得的进展.

Part I

预备知识 Preliminaries

Chapter 1

数学预备知识

1.1 引言

在本章中，我们将讨论一些数学概念，这些概念对于阅读本书第二部分和第三部分是有用的预备知识. 具体而言，我们将讨论概率论的各个方面，包括 Bayes 法则（Bayes' rule）等基本概念，以及熵等信息论概念. 我们将向你介绍物理中的对称性概念，例如时间反演对称性这一基本概念. 接下来，我们将全面介绍 凸优化（convex optimization），你将在其中学习 Lagrange 乘子如何帮助你施加约束. 最后，我们简要谈谈 Eulerian 视角与 Lagrangian 视角之间的区别，它描述了固定参考系与共动参考系之间的差异.

1.2 概率

1.2.1 概率质量函数与概率密度函数

随机变量 X 的概率分布有两种形式：概率质量函数（probability mass function）（PMF）与 概率密度函数（probability density function）（PDF）. 前者定义在离散状态 $x = i,\ i = 1, \ldots, N$ 上，后者定义在连续空间 $x \in \mathbb{R}$ 上. PMF 由一组非负且总和为 1 的数定义：

$$p(X = x) \geq 0 \quad \text{对所有} x, \qquad \sum_x p(X = x) = 1. \tag{1}$$

PDF 由于存在体积元，是一个更复杂的对象. 它由一个非负且积分为 1 的函数组成：

$$p(X = x) \geq 0 \quad \text{对所有} x, \qquad \int \mathrm{d}x\, p(X = x) = 1. \tag{2}$$

注意，对于 PMF，所有 $p(x)$ 必须小于或等于 1；否则它们无法像式 (1) 要求的那样求和为 1. 然而，由于式 (2) 中体积元 $\mathrm{d}x$ 的存在，这一约束不一定适用于 PDF. 事实上，只要在整个定义域上的积分等于 1，PDF 的 $p(x)$ 完全可以大于 1. 稍后讨论 Gaussian 分布时，我们将看到一个这样的例子.

为简便起见，我们常常用下标记号将 $p(X = x)$ 写作 $p_X(x)$. 但如果上下文清楚，我们将在后续章节中完全省略对随机变量的指明.

PMF 常由分类分布（categorical distribution）描述，它为每个离散状态 x 赋予概率：

$$p(x = i) = \pi_i, \qquad \pi_i \geq 0 \text{ 对所有} i, \qquad \sum_i \pi_i = 1. \tag{3}$$

这里我们将 π_i 视为模型的参数. 为施加非负性约束，我们可以用指数形式来参数化分类分布：

$$\pi_i = \frac{1}{Z}\exp(-\varepsilon_i), \qquad Z = \sum_i \exp(-\varepsilon_i), \tag{4}$$

其中 ε_i 可解释为状态 i 的能量，Z 为归一化常数.

PDF 有许多例子，但最常用的之一是 Gaussian 分布（正态分布）(Gaussian distribution). 我们将均值为 μ、标准差为 σ 的 Gaussian 分布记为 $G(\mu,\sigma)$，其概率密度函数为：

$$p(x) = \frac{1}{\sqrt{2\pi}\sigma}\exp\left(-\frac{1}{2\sigma^2}(x-\mu)^2\right). \tag{5}$$

该分布如图 1 所示. 可以验证：

$$\mathbb{E}_p[x] = \mu, \qquad \mathbb{E}_p[(x-\mu)^2] = \sigma^2, \tag{6}$$

$$Z = \int \mathrm{d}x\, \exp\left(-\frac{1}{2\sigma^2}(x-\mu)^2\right) = \sqrt{2\pi}\,\sigma, \tag{7}$$

其中 $\mathbb{E}_p[\cdot]$ 表示关于分布 p 的期望，定义为对任意函数 $f(x)$：

$$\mathbb{E}_p[f(x)] = \int \mathrm{d}x\, p(x)\, f(x). \tag{8}$$

在 $\sigma \to 0^+$ 的极限下，Gaussian 分布 $G(\mu,\sigma)$ 趋向于 Dirac δ 函数：

$$\lim_{\sigma\to 0^+} G(\mu,\sigma) = \delta(x-\mu), \tag{9}$$

它具有以下性质：

$$\int \mathrm{d}x\, \delta(x-\mu)\, f(x) = f(\mu). \tag{10}$$

$\delta(x-\mu)$ 的值在 $x=\mu$ 处趋向无穷、在其余位置为零，但其积分仍然良定义且等于 1. 这证实了我们从式 (2) 得出的早先论断：对于 PDF，$p(x)$ 的值确实可以超过 1!

Gaussian 分布式 (5) 的高维推广称为 多元 Gaussian 分布（multivariate Gaussian distribution），由下式给出：

$$p(\mathbf{x}) = \frac{1}{(2\pi)^{d/2}\,|\det(\Sigma)|^{1/2}}\exp\left(-\frac{1}{2}(\mathbf{x}-\boldsymbol{\mu})^\top\Sigma^{-1}(\mathbf{x}-\boldsymbol{\mu})\right), \tag{11}$$

其中 $\boldsymbol{\mu}$ 为均值向量，Σ 为协方差矩阵. 多元 Gaussian 分布的矩为：

$$\mathbb{E}_p[\mathbf{x}] = \boldsymbol{\mu}, \qquad \mathbb{E}_p[(\mathbf{x}-\boldsymbol{\mu})(\mathbf{x}-\boldsymbol{\mu})^\top] = \Sigma, \tag{12}$$

$$Z = \int \mathrm{d}\mathbf{x}\, \exp\left(-\frac{1}{2}(\mathbf{x}-\boldsymbol{\mu})^\top\Sigma^{-1}(\mathbf{x}-\boldsymbol{\mu})\right) = (2\pi)^{d/2}|\det(\Sigma)|^{1/2}. \tag{13}$$

上述例子属于一个具有良好性质的更大的分布族，即 指数族（exponential family）（Wainwright and Jordan, 2007）. 它可以定义为：

$$p(x) = \frac{1}{Z} \exp\left(- \sum_k \theta_k f_k(x) \right), \tag{14}$$

其中 θ_k 是参数，f_k 是特征或充分统计量（随机变量 x 的函数）. 函数 $F(\boldsymbol{\theta}) = -\log Z(\boldsymbol{\theta})$ 在指数族中扮演特殊角色，因为它生成分布的中心化矩（或累积量）：

$$\nabla_{\theta_k} F(\boldsymbol{\theta}) = \mathbb{E}_p[f_k], \tag{15}$$

$$\nabla_{\theta_l} \nabla_{\theta_k} F(\boldsymbol{\theta}) = \mathbb{E}_p[f_k f_l] - \mathbb{E}_p[f_k]\, \mathbb{E}_p[f_l] = -\operatorname{Cov}[f_k, f_l], \tag{16}$$

等等. 许多其他常见分布，如 Bernoulli 分布和 Poisson 分布，也属于指数族. 例如，对二值随机变量建模的 Bernoulli 分布可写为：

$$p(x) = \mu^x (1-\mu)^{1-x} = \exp\left(x \log \frac{\mu}{1-\mu} + \log(1-\mu) \right), \tag{17}$$

其中 μ 为成功概率（即 $x = 1$）. 将式 (17) 与式 (14) 比较，可以识别出 $f(x) = x$、$\theta = -\log \frac{\mu}{1-\mu}$ 以及 $\log Z(\theta) = \log(1 + e^{-\theta})$.

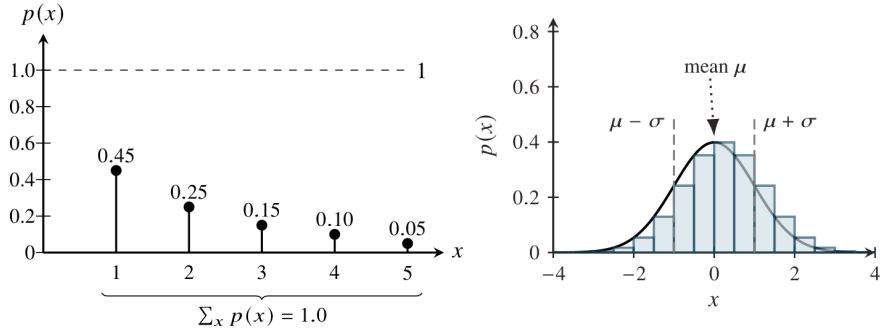


Figure 1.1 (a) A probability mass function assigns probabilities to discrete values that must

图 1: (a) 概率质量函数为离散值赋予概率，且其总和必须为 1. 每条带圆点的竖线表示特定结果的概率，并标出了具体概率值. (b) 标准差 $\sigma = 1$ 的 Gaussian 概率密度函数. $\mu - \sigma$ 与 $\mu + \sigma$ 处的垂直虚线标出了包含约 68% 概率质量的区间，直方图条形展示了来自 Gaussian 分布的离散样本如何逼近连续概率密度函数.

1.2.2 条件分布与 Bayes 法则

聚焦于 PDF，两个事件同时发生的概率可定义为一个非负的二元函数，且在所有变量上的积分为 1：

$$p(x, y) \geq 0 \text{ 对所有} x, \text{对所有} y, \qquad \iint \mathrm{d}x\, \mathrm{d}y\, p(x, y) = 1. \tag{18}$$

这称为 x 与 y 的 *联合分布*（joint distribution）. 前面讨论的 Gaussian 分布的高维推广就是一个例子，其中不同维度代表不同变量. 我们可以通过对所有其他变量积分来得到单变量 PDF：

$$p(x) = \int \mathrm{d}y\, p(x, y). \tag{19}$$

当由联合分布导出时，$p(x)$ 称为 $p(x, y)$ 的 *边缘分布*（marginal distribution）. 边缘分布仍然满足约束 $\int \mathrm{d}x\, p(x) = 1$.

我们也可以不对 y 做边缘化，而是考虑 y 的值被固定的情形. 我们称之为 x 关于 y 的 *条件分布*（conditional distribution），由下式获得：

$$p(x|y) = \frac{p(x, y)}{p(y)}. \tag{20}$$

条件分布也是一个合法的 PDF，因此对所有 x 满足 $\int \mathrm{d}x\, p(x|y) = 1$.

Bayes 法则 我们可以将 x 关于 y 的条件分布与 y 关于 x 的条件分布联系起来：

$$p(y|x) = \frac{p(x|y)\, p(y)}{p(x)}, \tag{21}$$

这就是 Bayes 定理或 Bayes 法则（以 Thomas Bayes 命名）. Bayes 法则是（细致）平衡方程的一个例子，我们将在本书后续章节中以各种形式遇到它. 如果将其写为：

$$p(y|x)\, p(x) = p(x|y)\, p(y), \tag{22}$$

它表明任意两点 x 与 y 之间的总概率流是相同的，因此边缘概率 p_X 与 p_Y 将保持不变. 条件分布 $p(y|x)$ 与 $p(x|y)$ 充当这些流的转移概率. 我们可以说，Bayes 法则表达了由 p_X 和 p_Y 描述的系统处于相对平衡状态.

Bayes 定理在机器学习中起着关键作用，它被用来在给定新证据时更新我们的信念. 在这一语境下，我们将 $p(y)$ 称为 *先验概率*（prior probability），它反映了我们在未观测到任何数据之前对系统的原始信念. 相应地，$p(y|x)$ 称为 *后验分布*（posterior distribution），代表我们在观测到 x 之后对系统的信念. Bayes 定理中的分母：

$$p(x) = \int \mathrm{d}y\, p(x|y)\, p(y), \tag{23}$$

称为 *证据*（evidence）. 由于需要对 y 的整个空间进行边缘化，这在计算上可能非常昂贵.

（条件）独立性条件 如果观测一个变量不会影响观测另一个变量的概率，则称两个随机变量 x 与 y 是独立的. 例如，考虑抛两枚均匀硬币. 观测到第一枚硬币正面朝上不会影响第二枚硬币正面朝上的概率，因此我们可以认为这两个事件彼此独立. 更形式化地，我们称两个变量 x 与 y 独立（记为 $x \perp y$）当且仅当它们的联合概率分布可分解：

$$p(x, y) = p(x)\, p(y), \tag{24}$$

这同时蕴含 $p(x|y) = p(x)$、$p(y|x) = p(y)$，以及 $\mathbb{E}[xy] = \mathbb{E}[x]\mathbb{E}[y]$. 此外，如果给定第三个随机变量 z 时 x 与 y 独立，则称 x 与 y 关于 z 条件独立（写作 $x \perp y \,|\, z$）：

$$p(x, y|z) = p(x|z)\, p(y|z). \tag{25}$$

例如，考虑抛两枚均匀硬币. 如果我们被告知至少有一枚硬币正面朝上，则两枚硬币的结果在此信息下变为条件依赖. 例如，知道第一枚硬币是反面现在使得第二枚硬币必然是正面（以满足条件）. 在这一情形下，两枚硬币的抛掷是边缘独立的，但在关于合并结果的信息下是条件依赖的.

1.2.3 熵

除了累积量之外，我们在本书中要考虑的概率分布的一个重要性质是它的 熵（entropy）. 在信息论意义上，熵定义了分布所编码的惊奇度或不确定性的平均度量. 形式上，它定义为：

$$S[p] = -\int \mathrm{d}\mathbf{x}\, p(\mathbf{x}) \log p(\mathbf{x}), \tag{26}$$

其中 $S[p](\mathbf{x}) = -\log p(\mathbf{x})$ 称为单个值 $\mathbf{x}$ 的 惊奇度（意外度）（surprisal）. 根据上下文，对数的底可以不同. 例如，在信息论中常使用底 2，此时熵的单位为比特（bit）. 然而在本书的其余部分中，我们将使用底 e，并以奈特（nat）为单位（Winter, 2021）. 1 奈特等于 $\log_2 e \approx 1.44$ 比特.

对于两个独立变量的联合分布，熵等于其边缘熵之和：

$$S[p_{X,Y}] = S[p_X] + S[p_Y]. \tag{27}$$

对于支撑在整个实轴上的连续分布，前面介绍的 Gaussian 分布是一个典型例子. 其熵可计算为：

$$\begin{aligned} S[p] &= \mathbb{E}_p[-\log p(x)] && (28)\\ &= \mathbb{E}_p\left[-\log \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)\right] && (29)\\ &= \log(\sqrt{2\pi}\sigma) + \frac{1}{2\sigma^2}\mathbb{E}_p[(x-\mu)^2] && (30)\\ &= \log(\sqrt{2\pi}\sigma) + \frac{1}{2}. && (31) \end{aligned}$$

这表明 Gaussian 分布的熵仅取决于标准差，而不取决于分布的均值.

1.2.4 分布之间的比较

Kullback–Leibler 散度（Kullback–Leibler divergence）（KL 散度）是两个概率分布之间差异的一种非对称度量. 给定两个不同的分布 $p(x)$ 与 $q(x)$，KL 散度定义为：

$$D_{\mathrm{KL}}[p\|q] = \int \mathrm{d}x\, p(x) \log \frac{p(x)}{q(x)}. \tag{32}$$

直观上，KL 散度表示用概率分布 q 来描述由 p 描述的系统时所损失的信息量. 这种信息损失解释在将 KL 散度表示为下式时变得清晰：

$$D_{\mathrm{KL}}[p\|q] = \int \mathrm{d}x\, p(x)\big(\log p(x) - \log q(x)\big) \tag{33}$$

$$= -S[p] + S[p\|q], \tag{34}$$

其中 $S[p\|q] = -\int \mathrm{d}x\, p(x) \log q(x)$ 称为 交叉熵（cross-entropy）. 在这一解释下，KL 散度也称为 相对熵（relative entropy）. 使用 KL 散度时需要注意，它仅在 q 与 p 具有相同支撑集时才被良定义；即对所有 $p(x) \neq 0$ 的 x，有 $q(x) \neq 0$.

作为例子，考虑两个单变量 Gaussian 分布 $p(x) = G(\mu_1, \sigma_1)$ 与 $q(x) = G(\mu_2, \sigma_2)$. 它们之间的 KL 散度为：

$$D_{\mathrm{KL}}[p\|q] = \log \frac{\sigma_2}{\sigma_1} + \frac{\sigma_1^2 + (\mu_1 - \mu_2)^2}{2\sigma_2^2} - \frac{1}{2}. \tag{35}$$

如前所述，KL 散度是非对称的，即 $D_{\mathrm{KL}}[p\|q] \neq D_{\mathrm{KL}}[q\|p]$，因此不是真正的度量. 这种非对称性在机器学习中关于使用哪个方向的散度具有重要意义，如图 2 所示.

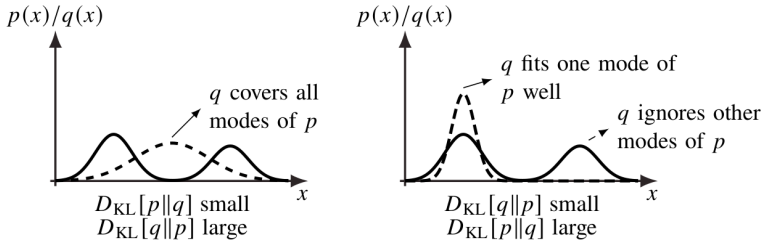


Figure 1.2 Asymmetry of the KL divergence. Let p be the true (bimodal) distribution and q be

图 2: KL 散度的非对称性. 设 p 为真实（双峰）分布，q 为逼近分布. 最小化 “前向” KL 散度 $D_{\mathrm{KL}}[p\|q]$ 鼓励 q 在 p 非零处也非零，从而得到宽覆盖、包络所有模态的逼近（左图）. 最小化 “反向” KL 散度 $D_{\mathrm{KL}}[q\|p]$ 则惩罚 q 在 p 为零处非零，从而得到聚焦、寻求单一模态的逼近，可能忽略 p 的某些模态（右图）.

此外，它不一定满足三角不等式. 然而它是非负的，且当且仅当 $p = q$ 几乎处处成立时 $D_{\mathrm{KL}}[p\|q] = 0$，因此可以被视为一种散度（由此得名）.

关于两个（或更多）随机变量 x 与 y 的 KL 散度有一个有用的分解：

$$D_{\mathrm{KL}}[p_{X,Y}\|q_{X,Y}] = D_{\mathrm{KL}}[p_X\|q_X] + \mathbb{E}_{p_X}\left[D_{\mathrm{KL}}[p_{Y|X}\|q_{Y|X}]\right]. \tag{36}$$

可以将其视为 KL 散度的 “Bayes 法则”.

虽然本书其余部分将主要考虑 KL 散度，但还有各种其他散度和方法可用于度量分布之间的差异. 其中最著名的有 χ^2 散度、互信息（mutual information），以及 Wasserstein 距离（Wasserstein distance）（Cover and Thomas, 2006）.

1.3 期望的近似计算

如我们所见，许多关于概率的问题归结为求解期望形式的积分：

$$\mathbb{E}_p[f(\mathbf{x})] = \int \mathrm{d}\mathbf{x}\, p(\mathbf{x})\, f(\mathbf{x}). \tag{37}$$

高效地实现这一点将是本书的中心主题，因此值得花一些时间来了解其基础. 如前所述，在 Gaussian 分布的情况下这通常可以方便地完成，但一般情况并非如此. 因此需要近似.

1.3.1 Monte Carlo 近似

Monte Carlo *方法*（Monte Carlo methods）被广泛用于通过从目标分布中抽取样本来估计概率和期望. 在常规采样中，我们从目标分布 $p(\mathbf{x})$ 中抽取 N 个独立同分布（i.i.d.）样本：

$$\mathbf{x}_n \sim p(\mathbf{x}), \qquad n = 1, \ldots, N, \tag{38}$$

其中记号 $\mathbf{x}_n \sim p(\mathbf{x})$ 表示每个样本 $\mathbf{x}_n$ 都是从分布 $p(\mathbf{x})$ 中随机抽取的. 给定这些样本，函数 $f(\mathbf{x})$ 的期望值 (8) 可以由 Monte Carlo 估计逼近：

$$\mathbb{E}_p[f(\mathbf{x})] \simeq \langle f \rangle = \frac{1}{N} \sum_{n=1}^{N} f(\mathbf{x}_n). \tag{39}$$

大数定律保证，当 N 增大时，Monte Carlo 估计 $\langle f \rangle$ 收敛于真实期望 $\mathbb{E}_p[f(\mathbf{x})]$. 这一性质称为 *一致性*（consistency）. Monte Carlo 估计 $\langle f \rangle$ 也是 $\mathbb{E}_p[f(\mathbf{x})]$ 的 *无偏估计量*（unbiased estimator）：

$$\mathbb{E}[\langle f \rangle] = \frac{1}{N} \sum_{n=1}^{N} \mathbb{E}_p[f(\mathbf{x}_n)] = \mathbb{E}_p[f(\mathbf{x})], \tag{40}$$

此处我们使用了期望的线性性以及每个样本都从同一分布 $p(\mathbf{x})$ 抽取这一事实.

估计量方差 Monte Carlo 估计的期望误差可以通过其方差来量化，定义为：

$$V[f] = \mathbb{E}\big[(f - \mathbb{E}[f])^2\big]. \tag{41}$$

利用此定义，并注意样本是独立的（因此当 $n \neq m$ 时 $\mathrm{Cov}(f(\mathbf{x}_n), f(\mathbf{x}_m)) = 0$），我们可以推导 $\langle f \rangle$ 的方差：

$$
\begin{aligned}
V[\langle f \rangle] &= \mathbb{E}\big[(\langle f \rangle - \mathbb{E}_p[f(\mathbf{x})])^2\big] && (42)\\
&= V\left[\frac{1}{N}\sum_{n=1}^{N} f(\mathbf{x}_n)\right] && (43)\\
&= \frac{1}{N^2}\sum_{n=1}^{N}\sum_{m=1}^{N} \mathrm{Cov}\big(f(\mathbf{x}_n), f(\mathbf{x}_m)\big) && (44)\\
&= \frac{1}{N^2}\sum_{n=1}^{N} V\big(f(\mathbf{x}_n)\big) && (45)\\
&= \frac{1}{N} V_p(f(\mathbf{x})). && (46)
\end{aligned}
$$

这一推导的关键洞见是：Monte Carlo 估计的方差以 $1/N$ 的速率下降，其中 N 为样本数. 这意味着增加样本数可以减小估计的期望误差，误差的标准差以 $\mathcal{O}(1/\sqrt{N})$ 的速率减小.

重要性采样 如前所述，进行 Monte Carlo 近似需要从目标分布 $p(\mathbf{x})$ 中抽取 i.i.d. 样本. 在下一节以及本书的其他各处，我们将探索实现这一点的不同方法，但需要注意，在许多情况下，在给定的计算预算内这仍然是不可行的. 在这种情形下，*重要性采样*（importance sampling）（IS）提供了一种有用的替代方案.

重要性采样利用了这样一个恒等式：我们可以通过比率 $w(\mathbf{x}) = p(\mathbf{x})/q(\mathbf{x})$ 将两个分布 $p(\mathbf{x})$ 与 $q(\mathbf{x})$ 联系起来. 这使我们能够将目标分布 $p(\mathbf{x})$ 的期望用另一个分布 $q(\mathbf{x})$ 改写为：

$$
\mathbb{E}_p[f(\mathbf{x})] = \int \mathrm{d}\mathbf{x}\, p(\mathbf{x})\, f(\mathbf{x}) = \int \mathrm{d}\mathbf{x}\, q(\mathbf{x})\, \frac{p(\mathbf{x})}{q(\mathbf{x})}\, f(\mathbf{x}) = \mathbb{E}_q[w(\mathbf{x})\, f(\mathbf{x})]. \tag{47}
$$

如果我们定义备选分布（通常称为 *提议分布*（proposal distribution））$q(\mathbf{x})$ 使得我们可以方便地从中采样，就可以使用权重 $w(\mathbf{x})$ 获得目标分布 $p(\mathbf{x})$ 期望的无偏且一致的估计：

$$
\mathbb{E}_p[f(\mathbf{x})] \simeq \langle f \rangle_{\mathrm{IS}} = \frac{1}{N}\sum_{n=1}^{N} w(\mathbf{x}_n)\, f(\mathbf{x}_n), \qquad \text{其中} \mathbf{x}_n \sim q(\mathbf{x}). \tag{48}
$$

无偏性与一致性同样可以通过期望的线性性以及样本为 i.i.d. 的事实来证明，如 Monte Carlo 估计所做的那样.

自归一化重要性采样 然而，虽然重要性采样使我们无需直接从分布中采样就能获得期望的无偏估计，但它要求我们能够对所有 $\mathbf{x}$ 计算比率 $p(\mathbf{x})/q(\mathbf{x})$. 这通常是不可能的，因为目标分布 $p(\mathbf{x})$ 的归一化常数 Z_p 是未知的. 如果令 $p(\mathbf{x}) = \frac{1}{Z_p}\tilde{p}(\mathbf{x})$，则可以将重要性

采样估计重写为：

$$\mathbb{E}_p[f(\mathbf{x})] = \int \mathrm{d}\mathbf{x}\, \frac{1}{Z_p}\tilde{p}(\mathbf{x})\, f(\mathbf{x}) \tag{49}$$

$$= \frac{1}{Z_p}\int \mathrm{d}\mathbf{x}\, q(\mathbf{x})\, \frac{\tilde{p}(\mathbf{x})}{q(\mathbf{x})}\, f(\mathbf{x}) = \frac{1}{Z_p}\mathbb{E}_q[\tilde{w}(\mathbf{x})\, f(\mathbf{x})], \tag{50}$$

其中 $\tilde{w}(\mathbf{x}) = \tilde{p}(\mathbf{x})/q(\mathbf{x})$ 为未归一化权重. 幸运的是，如果现在在提议分布 $q(\mathbf{x})$ 上取未归一化权重的期望，我们得到：

$$\mathbb{E}_q[\tilde{w}(\mathbf{x})] = \int \mathrm{d}\mathbf{x}\, q(\mathbf{x})\, \tilde{w}(\mathbf{x}) = \int \mathrm{d}\mathbf{x}\, q(\mathbf{x})\, \frac{\tilde{p}(\mathbf{x})}{q(\mathbf{x})} = \int \mathrm{d}\mathbf{x}\, \tilde{p}(\mathbf{x}) = Z_p. \tag{51}$$

因此，我们可以将这些结合起来构造 *自归一化重要性采样*（self-normalized importance sampling）（SNIS）估计量：

$$\mathbb{E}_p[f(\mathbf{x})] \simeq \langle f\rangle_{\mathrm{SNIS}} = \frac{\frac{1}{N}\sum_{n=1}^{N}\tilde{w}(\mathbf{x}_n)\, f(\mathbf{x}_n)}{\frac{1}{N}\sum_{n=1}^{N}\tilde{w}(\mathbf{x}_n)}. \tag{52}$$

虽然这是一个非常有用的结果，但需要注意 SNIS 估计不再是无偏的（即 $\mathbb{E}_q[\langle f\rangle_{\mathrm{SNIS}}] \neq \mathbb{E}_p[f(\mathbf{x})]$），因为两个期望的比率不等于比率的期望. 然而，它既是渐近无偏的又是一致的：当 $N \to \infty$ 时，偏差消失（$\mathbb{E}_q[\langle f\rangle_{\mathrm{SNIS}}] \to \mathbb{E}_p[f(\mathbf{x})]$），且 $\langle f\rangle_{\mathrm{SNIS}} \to \mathbb{E}_p[f(\mathbf{x})]$.

我们将在本书各处进一步讨论重要性采样. 例如，我们将看到它在 VAE 一章（第 7 章）定义 ELBO 时起着核心作用；在第 12 章中，我们将把它进一步扩展为定义在扩展分布空间上的形式，作为退火重要性采样框架的一部分. 该章也是我们将更详细讨论 IS 和 SNIS 估计量方差的地方.

1.3.2 采样方法

在上一节中，我们看到获得期望 $\mathbb{E}_p[f(\mathbf{x})]$ 的 Monte Carlo 估计需要从分布 $p(\mathbf{x})$ 中抽取 N 个独立同分布样本. 然而，这本身就是一个不平凡的问题；本书的若干章节都致力于探讨试图实现这一点的方法；例如，第 11 章使用 *马尔可夫链蒙特卡洛*（Markov chain Monte Carlo）方法. 我们在此强调两种通用方法：一种基于使用确定性变换将简单分布变换为目标分布，另一种基于从提议分布中接受或拒绝样本.

可逆变换方法 当分布 $p(\mathbf{x})$ 通过某个确定性变换 $\mathbf{x} = g(\mathbf{z})$ 与某个较简单的分布 $q(\mathbf{z})$ 相联系时，我们可以利用这一关系来定义 $p(\mathbf{x})$ 的采样方法：从 $q(\mathbf{z})$ 中采样，然后用 g 将样本变换为 $\mathbf{x}$. 值得注意的是，在这种情况下 $p(\mathbf{x})$ 与 $q(\mathbf{z})$ 之间的精确关系由 *变量替换公式*（change of variables formula）给出：

$$p(\mathbf{x}) = q\big(g^{-1}(\mathbf{x})\big)\left|\det\frac{\partial g^{-1}(\mathbf{x})}{\partial \mathbf{x}}\right|. \tag{53}$$

Jacobi 行列式 $\left|\frac{\partial g^{-1}(\mathbf{x})}{\partial \mathbf{x}}\right|$ 表示从较简单分布 $q(\mathbf{z})$ 来的无穷小体积元 $\mathrm{d}\mathbf{z}$ 在通过 g 变换为来自 $p(\mathbf{x})$ 的样本时被缩放的比例. 这一公式将在归一化流一章（第 8 章）中详细出现.

例 1.3.1 (Box–Muller 变换)**：** 这方面的一个经典例子是 Box–Muller 变换，它通过以下变换将一对独立的均匀随机变量 $\mathbf{u} = (u_1, u_2)$ 变换为一对独立的标准正态随机变量 $\mathbf{x} = (x_1, x_2)$：

$$x_1 = \sqrt{-2\log u_1}\cos(2\pi u_2), \qquad x_2 = \sqrt{-2\log u_1}\sin(2\pi u_2). \tag{54}$$

◇

例 1.3.2 (逆 CDF 方法)**：** 形式上，PDF 由其累积分布函数 $F(x) = \int_{-\infty}^{x} \mathrm{d}x'\, p(x')$ 表征. 如果此 CDF 可逆，我们可以用它来定义 $p(x)$ 的采样方法：抽取均匀随机数 $u \sim \mathrm{Unif}(0,1)$，并令 $x = F^{-1}(u)$. 这一简单方法仅限于具有可逆 CDF 的分布，且对于高维分布会变得复杂. ◇

接受–拒绝采样 第二种方法不依赖于可逆确定性变换的存在，即接受–拒绝采样. 给定目标分布 $p(\mathbf{x})$，接受–拒绝采样使用提议分布 $q(\mathbf{x})$ 进行采样，但并不对样本 $\mathbf{x}$ 进行变换，而是以正比于 $p(\mathbf{x})/(Mq(\mathbf{x}))$ 的概率接受它们，其中 M 是使得对所有 $\mathbf{x}$ 有 $p(\mathbf{x}) \le Mq(\mathbf{x})$ 的常数. 被接受的样本集合随后将按照 $p(\mathbf{x})$ 分布. 该方法的效率由提议分布 $q(\mathbf{x})$ 与常数 M 的选择决定. 提议分布 $q(\mathbf{x})$ 越接近目标分布 $p(\mathbf{x})$，采样就越高效. 对于高维分布，接受–拒绝采样通常不切实际，因为接受率通常非常低.

1.4 对称性

对称性在整个物理学中扮演着非常重要的角色. 它们通过观察者之间的 Lorentz 变换统一了电场与磁场；它们通过使所有物理定律在任意可逆坐标变换下协变，成为广义相对论的根基，并导致了引力与加速度作为同一枚硬币两面的统一. 它们还将基本粒子组织成通过对称变换相互关联的族.

在本书中，我们将特别遇到一个非常基本的对称性：时间反演对称性（time-reversal symmetry）. 这一思想是：如果我们在时间中向前或向后播放“电影”，物理定律应当保持不变. 如果你观察一堆分子四处跳跃，你无法判断电影是在正常播放还是在倒放. 这与日常生活形成鲜明对比——你永远不会看到煎蛋自己恢复成生蛋. 我们说，对于不处于平衡态的热力学系统，时间反演对称性在宏观尺度上被破缺. 时间反演对称性在平衡态中得以恢复.

时间反演对称性(或其破缺)的重要性在于:诸如产热和熵产生(entropy production)之类的概念——这两者都是在微观层面没有真正类比的宏观概念——可以直接与之联系起来. 粗略地说，正向动力学与反向动力学之间不对称的总量决定了系统中熵产生的量. 这一点在 Crooks 与 Jarzynski 的著名涨落定理（fluctuation theorem）中得到了更精确的表述（Jarzynski, 2011; Seifert, 2012）. 在本节中，我们将提供一些关于对称性数学的背景知识.

假设我们有一个向量场 $\mathbf{v}(\mathbf{x})$，想了解如果将该向量场旋转会发生什么. 为描述旋转后的向量场，我们加一个撇号：$\mathbf{v}'(\mathbf{x})$. 我们现在问：新向量场与旧向量场之间有何关系? 经过一番思考，我们得到：

$$\mathbf{v}'(\mathbf{x}) = R\,\mathbf{v}(r^{-1}\mathbf{x}), \tag{55}$$

其中我们使用旋转群的表示 r 来旋转位置 $\mathbf{x}$，使用表示 R 来旋转切向量 $\mathbf{v}$. 一般而言它们可以不同，但在本例子中你可以假设它们相同. 换句话说，该方程表明：为了得到位置 $\mathbf{x}$ 处的新向量 $\mathbf{v}'$，你需要将 $\mathbf{x}$ 转回旋转前的位置 $r^{-1}\mathbf{x}$，然后将该向量旋转一个量 R. 类似的规则适用于矩阵和高阶张量：

$$M'(\mathbf{x}) = R\, M(r^{-1}\mathbf{x})\, R^{\top} \quad \Rightarrow \quad M'_{i,j}(\mathbf{x}) = \sum_{i',j'} R_{i,i'} R_{j,j'} M_{i',j'}(r^{-1}\mathbf{x}), \tag{56}$$

$$T'(\mathbf{x}) = \underbrace{R \otimes R \otimes \cdots \otimes R}_{d\text{ 个}}\, T(r^{-1}\mathbf{x}) \quad \Rightarrow \quad T'_{i_1,i_2,\ldots,i_d}(\mathbf{x}) = \sum_{i'_1,i'_2,\ldots,i'_d} R_{i_1,i'_1} R_{i_2,i'_2} \cdots R_{i_d,i'_d}\, T_{i'_1,i'_2,\ldots,i'_d}(r^{-1}\mathbf{x}). \tag{57}$$

这些变换通常具有群的结构. 群由一些元素组成，这些元素可以复合成新的群元素：两次旋转的序列仍是另一次旋转. 群变换的其他性质包括：存在恒等变换、每个群元素都有逆变换，以及群变换满足结合律.

它们作用于向量空间的具体形式取决于空间的维度. 这种形式称为 *表示*（representation）. 表示需要尊重群结构，即如果 $M(g)$ 是群元素 g 的一个表示，则 $M(g)\cdot M(h) = M(g\circ h)$. 我们称此为 *同态*（homomorphism）.

时间反演的群结构确实非常简单；它是一个对合. 也就是说，施加时间反演 Ω 两次会回到起点：

$$\Omega^2 = \mathbb{1}. \tag{58}$$

物理变量在某些 “对称变换” 下变换. 对于对合，有两类这样的变量：偶宇称变量与奇宇称变量，后者在时间反演下改变符号. 对于时间区间 $[0,\tau_f]$ 上的轨迹 $(\mathbf{x}(\tau),\mathbf{p}(\tau))$，时间反演轨迹（以波浪号表示）定义为：

$$\tilde{\mathbf{x}}(\tau) = \Omega\, \mathbf{x}(\tilde{\tau}) = \mathbf{x}(\tau_f - \tau), \tag{59}$$

$$\tilde{\mathbf{p}}(\tau) = \Omega\, \mathbf{p}(\tilde{\tau}) = -\mathbf{p}(\tau_f - \tau). \tag{60}$$

在两种情形下，我们确实都有施加时间反演两次会恢复原始变量.

对称性现在是指在群变换下不变的 “某种东西”. 圆在圆的旋转下不变. 我们关心不变的概率分布和不变的物理定律. 在微观层面，所有物理定律被认为在联合电荷–宇称–时间反演变换下不变. 在本书中我们考虑宇称和时间反演. 例如，Hamilton 方程在时间反演下是不变的，其含义是：一条从 $\mathbf{x}(0),\mathbf{p}(0)$ 出发、结束于状态 $\mathbf{x}(\tau_f),\mathbf{p}(\tau_f)$ 的轨迹，在 Hamilton 运动方程下，有一条对偶路径从 $\mathbf{x}(\tau_f),-\mathbf{p}(\tau_f)$ 出发，并在同一组方程下演化回初始状态（动量翻转）$\mathbf{x}(0),-\mathbf{p}(0)$；见图 3.

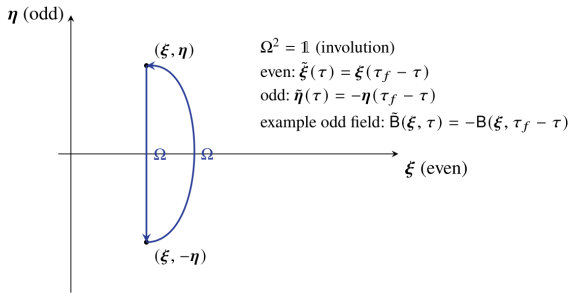


Figure 1.3 Time reversal parity in phase space. Positions (even variables) remain unchanged

图 3: 相空间中的时间反演宇称. 位置（偶变量）在时间反演下保持不变，而动量（奇变量）翻转符号：$\Omega : (\boldsymbol{\xi}, \boldsymbol{\eta}) \mapsto (\boldsymbol{\xi}, -\boldsymbol{\eta})$. 算子 Ω 是一个对合：$\Omega^2 = \mathbb{1}$.

在热力学中，情况更为复杂. 随机的 Brown 运动一般不可逆，因为由于碰撞，我们正在丢失关于系统的信息. 这意味着通常的随机运动方程不具有时间反演对称性. 我们丢失信息的程度由系统中熵的增加来度量. 当系统处于平衡态时，时间反演对称性得以恢复，不再产生更多熵（我们已经丢失了所有与平均能量、温度、压强等宏观变量相容的、可丢失的信息）.

1.5 凸优化要点

1.5.1 原问题

约束优化问题可以形式化地表示为：

$$\begin{aligned} &\min_{\mathbf{x}} && f_0(\mathbf{x}) \\ &\text{subject to:} && f_i(\mathbf{x}) \le 0, \quad \text{对所有} i, \\ &&& h_j(\mathbf{x}) = 0, \quad \text{对所有} j. \end{aligned} \tag{61}$$

这里，我们有一个想要最小化的目标函数 $f_0(\mathbf{x})$，约束为不等式约束 $f_i(\mathbf{x}) \le 0$ 和等式约束 $h_j(\mathbf{x}) = 0$. 目标是找到在满足所有约束的同时使目标函数最小的最优解 $\mathbf{x}^*$.

为获得对该问题的直观理解，可以考虑一个类比：一个球在由目标函数 $f_0(\mathbf{x})$ 定义的曲面上滚下. 球的运动受到墙壁（由不等式约束 $f_i(\mathbf{x}) \le 0$ 表示）和轨道（由等式约束 $h_j(\mathbf{x}) = 0$ 表示）的约束. 最优解 $\mathbf{x}^*$ 对应于球静止下来的位置，在该位置它满足所有约束并使其势能最小.

在凸优化中，式 (61) 称为 原问题（primal problem）. 我们现在写出该问题的原 Lagrangian，它将在后续推导中用到：

$$L_P(\mathbf{x}, \boldsymbol{\lambda}, \boldsymbol{\nu}) = f_0(\mathbf{x}) + \sum_i \lambda_i f_i(\mathbf{x}) + \sum_j \nu_j h_j(\mathbf{x}), \tag{62}$$

其中 $\boldsymbol{\lambda} = (\lambda_1, \lambda_2, \dots)$ 和 $\boldsymbol{\nu} = (\nu_1, \nu_2, \dots)$ 分别是与不等式和等式约束相关的 Lagrange 乘子. Lagrange 乘子可以解释为违反约束的 “价格” 或 “代价”. 在球的类比中，λ_i 表示墙壁在球与墙壁接触时对球施加的反作用力，ν_j 表示轨道对球施加的力以使其保持在轨道上. 下面我们假设对所有 i 有 $\lambda_i \ge 0$.

1.5.2 对偶问题

原问题 (61) 可以变换为另一种形式，称为 对偶问题（dual problem）. 从原 Lagrangian 出发，我们可以定义对偶函数：

$$L_D(\boldsymbol{\lambda}, \boldsymbol{\nu}) = \inf_{\mathbf{x}} L_P(\mathbf{x}, \boldsymbol{\lambda}, \boldsymbol{\nu}). \tag{63}$$

这里 inf 表示 下确界（infimum），即一个集合的最大下界. 对于优化问题，当我们不能保证最小值确实在可行集内达到时，常用 inf 代替 min. 类似地，sup 表示 上确界（supremum），即一个集合的最小上界. 在此语境下，它表示对于固定的 $\boldsymbol{\lambda}$ 和 $\boldsymbol{\nu}$，原 Lagrangian L_P 在所有可能的 $\mathbf{x}$ 值上的最低值. 对于其参数的某些值，此目标实际上可以变成 $-\infty$. 我们将那些使 $L_D(\boldsymbol{\lambda}, \boldsymbol{\nu}) > -\infty$ 的参数 $\boldsymbol{\lambda} \geq 0$、$\boldsymbol{\nu}$ 称为 对偶可行（dual feasible）.

需要注意的是，对偶 Lagrangian (63) 是 $\boldsymbol{\lambda}, \boldsymbol{\nu}$ 的凹函数，因为它是一族关于 $\boldsymbol{\lambda}, \boldsymbol{\nu}$ 的线性函数的逐点下确界. 因此，即使原问题 (61) 不是凸的，对偶问题也总是凹的（Boyd and Vandenberghe, 2004）!

不难证明：

$$L_D(\boldsymbol{\lambda}, \boldsymbol{\nu}) \leq p^*, \tag{64}$$

其中 p^* 是原最优值. 这是因为对任何原可行点 $\mathbf{x}$，我们有 $f_i(\mathbf{x}) \leq 0$ 和 $h_j(\mathbf{x}) = 0$. 由于 $\lambda_i \geq 0$，求和 $\sum_i \lambda_i f_i(\mathbf{x}) + \sum_j \nu_j h_j(\mathbf{x}) \leq 0$. 因此，对任何可行的 $\mathbf{x}$，$L_P(\mathbf{x}, \boldsymbol{\lambda}, \boldsymbol{\nu}) \leq f_0(\mathbf{x})$. 在左边对所有 $\mathbf{x}$ 取下确界，在右边对可行 $\mathbf{x}$ 取最小值，得到 $L_D(\boldsymbol{\lambda}, \boldsymbol{\nu}) \leq p^*$. 因此，对偶问题总是为原问题提供一个下界，如式 (64) 所示. 最紧的下界可以通过求解对偶问题找到：

$$\begin{array}{ll} \max_{\boldsymbol{\lambda}, \boldsymbol{\nu}} & L_D(\boldsymbol{\lambda}, \boldsymbol{\nu}) \\ \text{subject to:} & \lambda_i \geq 0 \quad \text{对所有} i, \end{array} \tag{65}$$

因此这是一个凸优化问题.

1.5.3 弱对偶与强对偶

如果用 d^* 表示对偶最优值，则总有：

$$d^* = L_D(\boldsymbol{\lambda}^*, \boldsymbol{\nu}^*) \leq p^*, \tag{66}$$

其中 $\boldsymbol{\lambda}^*$ 和 $\boldsymbol{\nu}^*$ 是对偶问题的最优解. 这一性质称为 弱对偶（weak duality）. 原最优值与对偶最优值之差 $p^* - d^*$ 称为 对偶间隙（duality gap）. 当 $p^* = d^*$ 时成立 强对偶（strong duality）；即对偶间隙为零时. 强对偶特别有用，尤其是当我们能用对偶解 $(\boldsymbol{\lambda}^*, \boldsymbol{\nu}^*)$ 来表示原解 $\mathbf{x}^*$ 时. 在这种情况下，我们可以简单地求解对偶问题 (65)，并将答案转换到原问题域，同时知道该解必然是最优的. 通常，对偶问题更容易求解.

那么强对偶何时成立呢？抛开一些数学细节，答案是：当原问题 (61) 是凸的且等式约束是仿射的时（Boyd and Vandenberghe, 2004）. 这意味着 $f_0(\mathbf{x})$ 和 $\{f_i(\mathbf{x})\}$ 是凸函数，且 $h_j(\mathbf{x}) = A_j \cdot \mathbf{x} - b_j$.

原问题 (61) 可以写成：

$$p^* = \inf_{\mathbf{x}} \sup_{\boldsymbol{\lambda}\geq 0,\boldsymbol{\nu}} L_P(\mathbf{x},\boldsymbol{\lambda},\boldsymbol{\nu}). \tag{67}$$

这可以通过注意以下事实来理解：当 $\mathbf{x}$ 可行时 $\sup_{\boldsymbol{\lambda}\geq 0,\boldsymbol{\nu}} L_P(\mathbf{x},\boldsymbol{\lambda},\boldsymbol{\nu}) = f_0(\mathbf{x})$，否则为无穷大. 要看到这一点，首先注意：通过违反某个约束，你可以找到一组 $\boldsymbol{\lambda},\boldsymbol{\nu}$ 使 Lagrangian (294) 为无穷大. 此外，当所有约束都满足时，我们所能做的最好就是将附加项最大化到零，这总是可能的. 例如，我们可以简单地将所有 $\boldsymbol{\lambda},\boldsymbol{\nu}$ 设为零，即使当约束本身消失时这并非必要.

对偶问题根据定义由下式给出：

$$d^* = \sup_{\boldsymbol{\lambda}\geq 0,\boldsymbol{\nu}} \inf_{\mathbf{x}} L_P(\mathbf{x},\boldsymbol{\lambda},\boldsymbol{\nu}). \tag{68}$$

因此，如果强对偶成立，“sup” 与 “inf” 可以交换，从而最优解是一个鞍点. 重要的是要认识到，对于任意函数，最大化与最小化的顺序是有影响的（但对于凸–凹函数则不然，因为 minimax 定理（minimax theorem）保证了这一点）. 想象一个 “V 形” 山谷斜穿过坐标系. 如果我们先在一个方向上最大化（固定另一个方向），然后对结果取最小，我们最终得到边缘上的最低点. 如果颠倒顺序，我们最终得到山谷中的最高点.

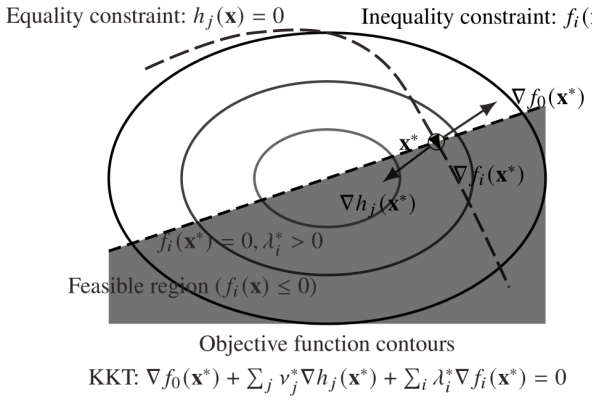


Figure 1.4 Geometric interpretation of constrained optimization and KKT conditions. The

图 4: 约束优化与 KKT 条件的几何解释. 最优点 $\mathbf{x}^*$ 位于长虚线等值线 $h_j(\mathbf{x}) = 0$（等式约束）与虚线不等式约束边界 $f_i(\mathbf{x}) = 0$ 的交点处. $\mathbf{x}^*$ 处的梯度向量展示了平稳性条件：$\nabla f_0(\mathbf{x}^*)$ 垂直于目标等值线，而约束的梯度则阻止进入不可行区域. 它们的加权和平衡为零，阴影楔形区域标出了可行集.

1.5.4 Karush–Kuhn–Tucker 条件

Karush–Kuhn–Tucker 条件（Karush–Kuhn–Tucker conditions）（KKT 条件）是一组对零对偶间隙问题成立的必要条件. 事实证明，这些条件对于凸优化问题也是充分的

（Boyd and Vandenberghe, 2004）. KKT 条件如图 4 所示，由下式给出：

$$\nabla f_0(\mathbf{x}^*) + \sum_i \lambda_i^* \nabla f_i(\mathbf{x}^*) + \sum_j \nu_j^* \nabla h_j(\mathbf{x}^*) = 0, \tag{69}$$

$$f_i(\mathbf{x}^*) \leq 0, \tag{70}$$

$$h_j(\mathbf{x}^*) = 0, \tag{71}$$

$$\lambda_i^* \geq 0, \tag{72}$$

$$\lambda_i^* f_i(\mathbf{x}^*) = 0. \tag{73}$$

第一个条件 (69) 称为 *平稳性条件*（stationarity condition），可以从式 (67) 容易地推导出来，该式表明 $p^* = \inf_{\mathbf{x}} L_P(\mathbf{x}, \boldsymbol{\lambda}^*, \boldsymbol{\nu}^*)$. 这意味着 Lagrangian 关于 $\mathbf{x}$ 的所有导数在最优点 $\mathbf{x}^*$ 处必须为零. 这一条件有一个漂亮的 “力的平衡” 解释. 想象一个球在由 $f_0(\mathbf{x})$ 定义的曲面上滚下（即你正在做梯度下降来寻找最小值）. 球被墙壁挡住，墙壁就是约束曲面. 如果曲面和约束都是凸的，那么在球不再移动的点处，我们就达到了最优解. 在该点，作用在球上的力必须平衡. 第一项表示球由于重力对墙壁施加的力（球仍在斜坡上）. 第二项表示墙壁在相反方向上的反作用力. λ_i^* 表示反作用力的大小，如果曲面坡度越大，它就需要越大. 我们说这个约束是 *活跃的*（active）. 其他不施加力的约束是 *非活跃的*（inactive），且 $\lambda_i^* = 0$.

最后的 KKT 条件 (73) 称为 *互补松弛*（complementary slackness），它表明：要么 $f_i(\mathbf{x}^*) = 0$（约束被饱和因而活跃），此时 λ_i^* 可以取非零值；要么约束非活跃（$f_i(\mathbf{x}^*) < 0$），此时 λ_i^* 必须为零.

互补松弛 (73) 可推导如下：

$$f_0(\mathbf{x}^*) = L_D(\boldsymbol{\lambda}^*, \boldsymbol{\nu}^*) \tag{74}$$

$$= \inf_{\mathbf{x}} \left(f_0(\mathbf{x}) + \sum_i \lambda_i^* f_i(\mathbf{x}) + \sum_j \nu_j^* h_j(\mathbf{x}) \right) \tag{75}$$

$$\leq f_0(\mathbf{x}^*) + \sum_i \lambda_i^* f_i(\mathbf{x}^*) + \sum_j \nu_j^* h_j(\mathbf{x}^*) \tag{76}$$

$$\leq f_0(\mathbf{x}^*). \tag{77}$$

这里，式 (74) 来自强对偶，式 (75) 是对偶 Lagrangian 的定义，式 (76) 成立是因为下确界总是小于或等于任意点 $\mathbf{x}^*$ 处的值，式 (77) 来自 $\mathbf{x}^*$ 的可行性——式 (70) 和式 (71)——以及 λ_i^* 的非负性式 (72). 由于该推导中的第一个表达式与最后一个表达式相等，所有不等式必须取等号，这意味着每一项 $\lambda_i^* f_i(\mathbf{x}^*)$ 必须为零，从而得到互补松弛条件.

通过求解 KKT 条件，我们可以找到最优的原解与对偶解，分别为 $\mathbf{x}^*$ 和 $(\boldsymbol{\lambda}^*, \boldsymbol{\nu}^*)$.

1.5.5 由最大熵原理导出正则系综

E. T. Jaynes 为物理系统和信息系统提出的一个原理是：在缺乏信息（以熵度量）的情况下，对于某个有给定观测值的问题，最佳解是与观测值一致、但在其余自由度上最大化熵的解（Jaynes, 1957a,b）. 在某种意义上，系统对它不知道的事物尽可能少地做假设. 这在 Bayes 统计中有时被称为 Occam *剃刀*（Occam's razor）（Jaynes, 2003）.

对于 正则系综（canonical ensemble），我们假设系统的平均能量已知且等于某个值 E. 最大熵原理（maximum entropy principle）（MaxEnt）问题可以表述为：

$$\rho^{\mathrm{eq}} = \arg\max_{\rho} L_P(\rho, \beta, \lambda) \tag{78}$$

$$= \arg\max_{\rho} \left[S[\rho] - \beta \left(\int \mathrm{d}\zeta\, \rho(\zeta)\mathcal{H}(\zeta) - E \right) - \lambda \left(\int \mathrm{d}\zeta\, \rho(\zeta) - 1 \right) \right], \tag{79}$$

其中 $\rho(\zeta)$ 是关于微观态 ζ 的概率分布，$S[\rho]$ 是熵泛函，$\mathcal{H}(\zeta)$ 是系统的 Hamiltonian. 这里我们有两个由 Lagrange 乘子 β 和 λ 施加的约束，确保系统的平均能量等于 E 且概率分布是归一化的. 对原 Lagrangian L_P 关于 ρ 取（泛函）导数并令其为零，得到 KKT 条件中的平稳性条件：

$$\frac{\delta L_P}{\delta \rho} = -\log \rho(\zeta) - 1 - \beta\mathcal{H}(\zeta) - \lambda = 0, \tag{80}$$

其解为：

$$\rho^{\mathrm{eq}}(\zeta) = \exp(-\beta\mathcal{H}(\zeta) - \lambda - 1) = \frac{1}{Z}\exp(-\beta\mathcal{H}(\zeta)), \qquad \lambda = \log Z - 1. \tag{81}$$

Lagrange 乘子 λ 可以容易地用归一化常数 Z 解出. 另一个 Lagrange 乘子 β 被识别为逆温度 $1/(k_B T)$，其中 k_B 是 Boltzmann 常数，T 是热浴的温度. 注意，我们本可以添加一个单独的不等式约束来强制 $\rho \geq 0$，但由于解的指数形式，这一约束自动满足. 下面我们令 $k_B = 1$.

下一步是将 KKT 条件 (80) 的解 (452) 代回原 Lagrangian (78)，得到对偶 Lagrangian：

$$L_D(\beta, \lambda) = \beta E + \lambda + \int \mathrm{d}\zeta\, \exp(-\beta\mathcal{H}(\zeta) - \lambda - 1). \tag{82}$$

定义 $\tilde{\lambda} = \lambda + 1$ 并求解 $\tilde{\lambda}$ 以归一化分布，我们得到：

$$\tilde{\lambda}^* = \log Z(\beta) = \log \int \mathrm{d}\zeta\, \exp(-\beta\mathcal{H}(\zeta)), \tag{83}$$

由此得到：

$$L_D(\beta, \lambda^*) = \beta E + \log Z(\beta) = \beta(E - F(\beta)) = S(\beta), \tag{84}$$

其中我们使用了平衡自由能的定义 $F = -T\log Z$，以及由 $F = E - TS$ 给出的熵的定义. 我们注意到这是平衡态的熵，因为它仅是 β 的函数而不是 ρ 的函数. 这是一个漂亮的结果！（非平衡）最大熵问题 (78) 的对偶 Lagrangian (82)，是平衡态 Boltzmann 分布熵的表达式，我们现在可以对 β 最大化它. 由于我们知道对偶 Lagrangian 总是凹的，这应该是一个可处理的优化问题. 计算 L_D 关于 β 的导数，得到：

$$\frac{\partial L_D}{\partial \beta} = E - \mathbb{E}_{\rho^{\mathrm{eq}}(\beta)}[\mathcal{H}]. \tag{85}$$

我们可以对 L_D 执行迭代梯度上升更新，直到达到最大值. 得到的 β^* 是对应于平均能量 E 的系统逆温度.

由于原问题 (78) 是凸的，我们有强对偶，这意味着原最优值与对偶最优值相等；即 $p^* = d^*$. 这确保了我们的解确实是全局最优.

总而言之，Jaynes 的最大熵原理通过 Lagrange 乘子法巧妙地为我们提供了正则系综 (452)（即 Boltzmann 分布）的推导，其中逆温度 β 被解释为施加平均能量约束的 Lagrange 乘子.

1.6 Lagrangian 视角与 Eulerian 视角

在随机热力学和机器学习中，我们经常需要追踪概率分布如何随时间演化. 执行此类计算有两种互补的视角：Eulerian 视角（Eulerian view），即我们从空间中的固定参考系观察系统；以及 Lagrangian 视角（Lagrangian view），即我们跟随单个粒子（或样本）运动.

在固定的 Eulerian 参考系中，我们在相空间中定义时空坐标 $(\boldsymbol{\zeta}, \tau) = (\boldsymbol{\xi}, \boldsymbol{\eta}, \tau)$，并将场定义为这些固定坐标的函数；也就是说，我们可能有一个 Hamiltonian $\mathcal{H}(\boldsymbol{\zeta}, \tau)$. 一般而言，我们将为这类函数写 $\mathbf{h}(\boldsymbol{\zeta}, \tau)$，它们可以是标量、向量（“场”），甚至是矩阵和高阶张量. 粒子密度由密度场 $\rho(\boldsymbol{\zeta}, \tau)$ 描述，它满足以下连续性方程：

$$\partial_\tau \rho(\boldsymbol{\zeta}, \tau) = -\nabla_{\boldsymbol{\zeta}} \cdot \big(\rho(\boldsymbol{\zeta}, \tau)\mathbf{v}(\boldsymbol{\zeta}, \tau)\big) = -\operatorname{div}\big(\rho(\boldsymbol{\zeta}, \tau)\mathbf{v}(\boldsymbol{\zeta}, \tau)\big), \tag{86}$$

其中 $\mathbf{v}$ 为某个向量场. 这正是沿向量场 $\mathbf{v}$ 对某个密度进行 推前（确定性）变换（push-forward transformation）的连续形式表达.

当我们计算平均值时，计算：

$$\int \mathrm{d}\boldsymbol{\zeta}\, \rho(\boldsymbol{\zeta}, \tau)\, \mathbf{h}(\boldsymbol{\zeta}, \tau). \tag{87}$$

在上面我们注意到 $\rho(\boldsymbol{\zeta}, \tau)$ 是一个与 $\rho(\boldsymbol{\zeta}, 0)$ 不同的（变换后的）分布. 如果该密度在对所有 $\boldsymbol{\zeta}_0$ 的确定性（推前）变换 $\boldsymbol{\zeta}_0 \mapsto \boldsymbol{\zeta}_\tau = g(\boldsymbol{\zeta}_0, \tau)$ 下变换，则我们有以下关系：

$$\rho(\boldsymbol{\zeta}_\tau, \tau) = \rho(\boldsymbol{\zeta}(\boldsymbol{\zeta}_0, \tau), \tau) = \rho(\boldsymbol{\zeta}_0, 0) \left| \det \frac{\partial \boldsymbol{\zeta}(\boldsymbol{\zeta}_0, \tau)}{\partial \boldsymbol{\zeta}_0} \right|^{-1}. \tag{88}$$

注意测度将保持不变：

$$\rho(\boldsymbol{\zeta}_\tau, \tau)\, \mathrm{d}\boldsymbol{\zeta}_\tau = \rho(\boldsymbol{\zeta}_0, 0)\, \mathrm{d}\boldsymbol{\zeta}_0. \tag{89}$$

当我们计算平均值时，可以这样做：

$$\int \mathrm{d}\boldsymbol{\zeta}\, \rho(\boldsymbol{\zeta}, \tau)\, \mathbf{h}(\boldsymbol{\zeta}, \tau) \tag{90}$$

$$= \int \mathrm{d}\boldsymbol{\zeta}_\tau\, \rho(\boldsymbol{\zeta}_\tau, \tau)\, \mathbf{h}(\boldsymbol{\zeta}_\tau, \tau) \quad (\boldsymbol{\zeta} \text{ 为哑积分变量}) \tag{91}$$

$$= \int \mathrm{d}\boldsymbol{\zeta}_0\, \rho(\boldsymbol{\zeta}_0, 0)\, \mathbf{h}(\boldsymbol{\zeta}(\boldsymbol{\zeta}_0, \tau), \tau) \quad (\text{测度不变性}) \tag{92}$$

$$= \iint \mathrm{d}\boldsymbol{\zeta}_0\, \mathrm{d}\boldsymbol{\zeta}_\tau\, \rho(\boldsymbol{\zeta}_0, 0)\, \delta(\boldsymbol{\zeta}_\tau - \boldsymbol{\zeta}(\boldsymbol{\zeta}_0, \tau))\, \mathbf{h}(\boldsymbol{\zeta}_\tau, \tau), \tag{93}$$

其中我们可以定义：

$$\rho(\boldsymbol{\zeta}_\tau, \boldsymbol{\zeta}_0) = \rho(\boldsymbol{\zeta}_\tau|\boldsymbol{\zeta}_0)\,\rho(\boldsymbol{\zeta}_0) = \rho(\boldsymbol{\zeta}_0, 0)\,\delta(\boldsymbol{\zeta}_\tau - \boldsymbol{\zeta}(\boldsymbol{\zeta}_0, \tau)). \tag{94}$$

在前两行中，我们将 $\boldsymbol{\zeta}_0$ 视为需要对其积分的随机变量. 此外，密度 $\rho(\boldsymbol{\zeta}, \tau)$ 和函数 $\mathbf{h}(\boldsymbol{\zeta}, \tau)$ 都被视为 τ 的函数. 我们称此为 Eulerian 视角，因为随机变量是固定的. 然而在第三行中，我们考虑固定测度 $\rho(\boldsymbol{\zeta}_0, 0)\,\mathrm{d}\boldsymbol{\zeta}_0$，即我们从中采样系综点的初始测度. 现在函数 $\mathbf{h}(\boldsymbol{\zeta}_\tau, \tau)$ 以两种方式依赖于时间：首先是显式地，但也通过 $\boldsymbol{\zeta}_\tau = g(\boldsymbol{\zeta}_0, \tau)$ 隐式地依赖. 我们称此为 Lagrangian 视角. 这一结果也在 VAE 的 重参数化技巧（reparameterization trick）中被利用.

让我们计算上述表达式的时间导数：

$$\frac{\mathrm{d}}{\mathrm{d}\tau}\int \mathrm{d}\boldsymbol{\zeta}\,\rho(\boldsymbol{\zeta}, \tau)\,\mathbf{h}(\boldsymbol{\zeta}, \tau) \tag{95}$$

$$= \frac{\mathrm{d}}{\mathrm{d}\tau}\int \mathrm{d}\boldsymbol{\zeta}_\tau\,\rho(\boldsymbol{\zeta}_\tau, \tau)\,\mathbf{h}(\boldsymbol{\zeta}_\tau, \tau) = \int \mathrm{d}\boldsymbol{\zeta}_\tau\,\partial_\tau\rho(\boldsymbol{\zeta}_\tau, \tau)\,\mathbf{h}(\boldsymbol{\zeta}_\tau, \tau) + \rho(\boldsymbol{\zeta}_\tau, \tau)\,\partial_\tau\mathbf{h}(\boldsymbol{\zeta}_\tau, \tau) \tag{96}$$

$$= \int \mathrm{d}\boldsymbol{\zeta}_\tau\,\nabla_{\zeta_\tau}\cdot(-\rho(\boldsymbol{\zeta}_\tau, \tau)\mathbf{v}(\boldsymbol{\zeta}_\tau, \tau))\,\mathbf{h}(\boldsymbol{\zeta}_\tau, \tau) + \rho(\boldsymbol{\zeta}_\tau, \tau)\,\partial_\tau\mathbf{h}(\boldsymbol{\zeta}_\tau, \tau) \tag{97}$$

$$= \int \mathrm{d}\boldsymbol{\zeta}_\tau\,\rho(\boldsymbol{\zeta}_\tau, \tau)\left(\mathbf{v}(\boldsymbol{\zeta}_\tau, \tau)\cdot\nabla_{\zeta_\tau}\mathbf{h}(\boldsymbol{\zeta}_\tau, \tau) + \partial_\tau\mathbf{h}(\boldsymbol{\zeta}_\tau, \tau)\right) \tag{98}$$

$$= \int \mathrm{d}\boldsymbol{\zeta}_0\,\rho(\boldsymbol{\zeta}_0, 0)\left(\mathbf{v}(\boldsymbol{\zeta}_\tau, \tau)\cdot\nabla_{\zeta_\tau}\mathbf{h}(\boldsymbol{\zeta}_\tau, \tau) + \partial_\tau\mathbf{h}(\boldsymbol{\zeta}_\tau, \tau)\right);\quad \boldsymbol{\zeta}_\tau = \boldsymbol{\zeta}(\boldsymbol{\zeta}_0, \tau) \tag{99}$$

$$= \int \mathrm{d}\boldsymbol{\zeta}_0\,\rho(\boldsymbol{\zeta}_0, 0)\,\frac{\mathrm{d}}{\mathrm{d}\tau}\mathbf{h}(\boldsymbol{\zeta}_\tau, \tau);\quad \boldsymbol{\zeta}_\tau = \boldsymbol{\zeta}(\boldsymbol{\zeta}_0, \tau) \tag{100}$$

$$= \frac{\mathrm{d}}{\mathrm{d}\tau}\int \mathrm{d}\boldsymbol{\zeta}_0\,\rho(\boldsymbol{\zeta}_0, 0)\,\mathbf{h}(\boldsymbol{\zeta}_\tau, \tau);\quad \boldsymbol{\zeta}_\tau = \boldsymbol{\zeta}(\boldsymbol{\zeta}_0, \tau). \tag{101}$$

第一行与最后一行的等式与上述关于计算平均值的 Eulerian 视角和 Lagrangian 视角的结果一致. 在第一行中，我们需要取两个偏导数，因为 ρ 和 $\mathbf{h}$ 都依赖于 τ. 然而 $\boldsymbol{\zeta}_0$ 只是一个积分变量，不依赖于 τ. 在最后一行中，我们取 Lagrangian 视角下的时间导数，其中 ρ 现在是固定的（初始分布），而 $\mathbf{h}$ 以两种方式依赖于 τ：显式地以及通过 $\boldsymbol{\zeta}_\tau$ 隐式地. $\mathbf{h}$ 的全导数有时称为 “物质” 或 “共动” 导数. 我们注意到，为了连接这两种视角，我们需要连续性方程和分部积分.

Chapter 2

神经网络预备

2.1 引言

在本章中，我们将简要概述最相关的神经网络（NN）架构. 从某种意义上说，这是背景阅读材料，旨在确保你跟上深度学习的最新进展. 在本书的其余部分，我们经常提到要训练一个神经网络，但不会展开该网络的细节. 例如，当我们训练扩散模型时，需要使用一个 *分数网络*（score network），而你可以选择本章描述的架构之一来实现这一目的. 例子包括多层感知机、卷积神经网络、残差网络或 Transformer. 本章的最后一节提供了反向传播的另一种视角，反向传播是从数据中训练这些模型的主力算法. 关于神经网络的完整讨论，我们推荐 Goodfellow et al. (2016)、Murphy (2012) 和 Bishop (2006) 的标准教科书.

2.2 多层感知机

多层感知机（multilayer perceptron）（MLP）是深度神经网络架构最早的形式之一，也是一种特定类型的前馈神经网络. 在前馈神经网络中，通过堆叠多个简单函数所产生的复杂性被用来解决复杂任务. 顾名思义，MLP 的简单构建块函数称为感知机：

$$f_\ell(x_{\ell-1};\theta_\ell) = \phi(W_\ell x_{\ell-1} + b_\ell), \tag{102}$$

其中 $\theta_\ell = (W_\ell, b_\ell)$ 是第 ℓ 层的参数集合，$\phi : \mathbb{R}^{d_\ell} \to \mathbb{R}^{d_\ell}$ 是逐元素应用的非线性激活函数，$W_\ell \in \mathbb{R}^{d_\ell \times d_{\ell-1}}$ 是权重矩阵，$b_\ell \in \mathbb{R}^{d_\ell}$ 是偏置向量. 这里，$x_{\ell-1} \in \mathbb{R}^{d_{\ell-1}}$ 是第 ℓ 层的输入，即前一层的输出，$d_{\ell-1}$ 和 d_ℓ 分别是该层的输入和输出维度. 如图 5 所示，单个 MLP 层内的所有节点（每一层中的特征）都通过权重 W_ℓ 连接到下一层的所有节点. 正因如此，MLP 有时也称为全连接神经网络.

使用非线性激活函数 ϕ 为模型引入了非线性，使得堆叠层可以增加表达能力，而不是退化为单个线性映射. 如果没有激活函数，无论网络多深，它本质上都是一个线性模型. 一些最常用的激活函数如下.

Sigmoid sigmoid（或 logistic）函数定义为：

$$\phi(x) = \frac{1}{1+\exp(-x)}. \tag{103}$$

sigmoid 函数将输入压缩到 0 与 1 之间的值，这对于二分类问题很有用，并且可以解释为概率. 历史上，sigmoid 函数因其平滑性和可微性而广受欢迎. 然而，它在深度网络中存在 *梯度消失问题*（vanishing gradient problem），因为 sigmoid 函数在输入值很大和很小时分别饱和于 1 和 0. 其导数 $\phi'(x) = \phi(x)(1-\phi(x))$ 在输入为大的正值或负值时变得非常小，从而减慢学习速度.

线性修正单元 线性修正单元（rectified linear unit）（ReLU）是现代神经网络中最流行的激活函数之一. 它最早由 Fukushima (1969) 提出，但在 2010 年代得到推广（Glorot et al., 2011）. ReLU 函数是一种非饱和激活函数，定义为：

$$\phi(x) = \mathrm{ReLU}(x) = \max(0, x). \tag{104}$$

ReLU 的导数在 $x > 0$ 时为 1，在 $x \leq 0$ 时为 0，从而允许梯度对于正激活在网络中高效流动. ReLU 的变体，如 leaky ReLU（Maas et al., 2013），已被提出来解决诸如 "dying ReLU" 之类的问题——即神经元如果持续输出零，可能永久失活.

Softmax softmax 函数常用于 MLP 的输出层，以解决多分类问题或对多个离散结果的概率建模. 它将输入向量 $x \in \mathbb{R}^K$ 映射到 K 个类上的概率分布：

$$\mathrm{Softmax}(x)_k = \frac{\exp(x_k)}{\sum_{k'=1}^{K} \exp(x_{k'})}, \qquad \text{对} k = 1, \ldots, K. \tag{105}$$

softmax 函数确保输出总和为 1，并可解释为概率. 它通过对输入分数取指数并以指数分数之和进行归一化来实现这一点. 在监督学习中，softmax 输出常与交叉熵损失函数结合使用来训练网络. 在概率模型中，softmax 函数用于参数化分类分布. 例如，给定输入 x_0 的类别 k 的概率建模为：

$$p(y = k \mid x_0) = \mathrm{Softmax}(f(x_0))_k = \frac{\exp(f_k(x_0))}{\sum_{k'=1}^{K} \exp(f_{k'}(x_0))}, \tag{106}$$

其中 $f(x_0) = [f_1(x_0), \ldots, f_K(x_0)]^\top$ 是网络在激活前的输出（通常称为 对数几率（logits）（logits））.

虽然已经证明具有一个隐藏层的 MLP 是 通用函数逼近器（universal function approximator）（Hornik et al., 1989），即在给定足够宽度的情况下可以在紧集上以任意精度逼近任何连续函数，但这一理论结果并不意味着实际效率. 在实践中，具有适当架构、考虑数据特定模态和结构的更深网络在参数效率上更高，并且泛化能力更好. 我们接下来将讨论此类模型的主要例子——卷积神经网络.

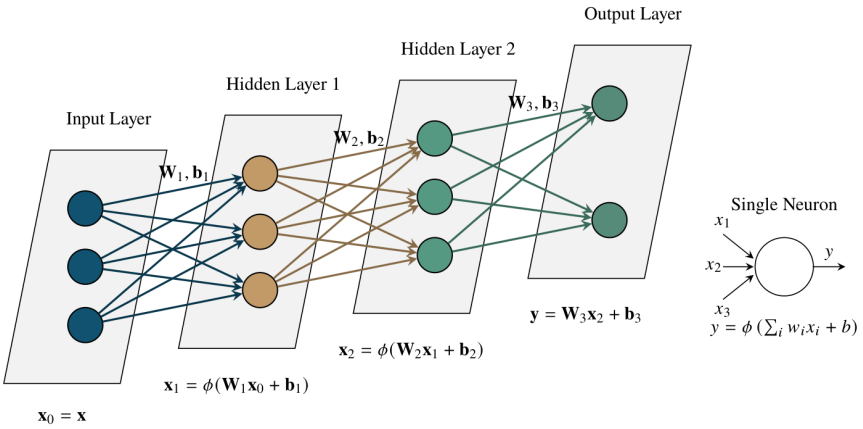


Figure 2.1 Multilayer perceptron with two hidden layers. Each layer is represented as a slanted

图 5: 具有两个隐藏层的多层感知机. 每一层表示为一个斜矩形，神经元显示为彩色圆圈. 层与层之间的连接（由箭头表示）形成权重矩阵 W_1、W_2 和 W_3. 每一层还包含偏置向量 b_1、b_2 和 b_3. 每一层的数学运算如图所示. 插图放大显示了单个神经元中输入如何通过激活函数 ϕ 组合和处理.

2.3 卷积神经网络

在前面讨论 MLP 时，我们没有对提供给模型的数据 x 的类型做任何假设. 然而，在神经网络的大多数应用中，数据具有特定的结构，描述了单个样本中不同特征之间的关系. 最明显的例子是图像数据，其中图像表示为像素值的二维数组. 这些像素值与邻近像素值之间存在良好定义的结构关系（彼此相关）.

卷积神经网络（convolutional neural network）（CNN）通过应用 *卷积层*（convolutional layer）来利用数据中的这种结构（LeCun et al., 1998；如图 6 所示）. 与全连接层中输出层的每个节点都连接到前一层的每个节点不同，卷积层对于每个输出仅考虑前一层的一个小补丁（称为 *感受野*（receptive field））. 这一性质称为 *局部性*（locality），它使 CNN 能够捕获局部模式并构建输入数据的层次化表示.

CNN 可以被视为高级的特征提取器. 如图 6 所示，卷积操作将滤波器在输入的补丁上滑动. 在每个位置，计算滤波器与输入相应区域之间的内积，并将结果存储在输出中. 数学上，对于二维输入 $x \in \mathbb{R}^{H\times W\times C_{\text{in}}}$ 和滤波器 $w \in \mathbb{R}^{k\times k\times C_{\text{in}}\times C_{\text{out}}}$，离散卷积操作可表示为：

$$f_\ell(x;\theta_\ell)_{i,j,c} = (\operatorname{Conv} x)_{i,j,c} = (x * w)_{i,j,c} = \sum_{a=0}^{k-1}\sum_{b=0}^{k-1}\sum_{c'=1}^{C_{\text{in}}} x_{i+a,j+b,c'}\, w_{a,b,c',c} + b_c, \tag{107}$$

其中 H 和 W 是输入的高度和宽度，C_{in} 和 C_{out} 分别是输入和输出通道数. 这里，参数 $\theta_\ell = \{w, b\}$ 是可学习参数（滤波器权重和偏置），k 决定感受野的大小. 索引 i 和 j 表示输出特征图中的空间位置，而 a 和 b 索引输入中 (i, j) 周围的局部邻域. 索引 c 表示输出通道，c' 表示输入通道.

该过程检测输入中的特定模式或特征. 例如，某个特定滤波器可能充当边缘检测器，检测输入中的边缘. 与全连接层相比，它还减少了参数数量. 使用多个滤波器使网络能够在每一层检测各种特征，构建输入数据的层次化表示.

卷积层的另一个有用性质是 *参数共享*（parameter sharing）. 同一个滤波器 w 应用于输入中的每个像素补丁，形成值为 $f_\ell(x;\theta_\ell)_{i,j,c}$ 的特征图. 该特征图定义了滤波器对每个像素补丁的响应. 通过在整个输入上应用同一个滤波器（而不是像全连接层那样为每个输入变量设置单独的权重），CNN 实现了 *平移等变性*（translation equivariance）：当输入平移一小段距离时，输出特征图将等价地平移.

等变性与对称性 数学上，如果函数 f 满足 $f(T(x)) = T(f(x))$，则称 f 关于变换 T 是等变的. 在 CNN 中，平移等变性意味着如果输入图像被平移，输出特征图将平移相同的距离. 这一性质在图像处理任务中特别有用，因为它允许网络识别模式而不管它们在图像中的位置. 更多对称性，如旋转或反射对称性，也可以被纳入神经网络架构以提高其性能和泛化能力. 例子包括 *群等变* CNN（group equivariant CNNs）（Cohen and Welling, 2016）和球面 CNN（Cohen et al., 2018），它们分别将等变性扩展到其他类型的变换和球面数据.

与 MLP 相比，CNN 对于图像等结构化数据的效率显著更高. 对于一张大小为 $n \times n$、具有 c 个通道的图像，MLP 每个神经元需要 $\mathcal{O}(n^2c)$ 个参数，而具有 $k \times k$ 滤波器的 CNN 每个滤波器仅需要 $\mathcal{O}(k^2c)$ 个参数，与图像大小无关. 这种参数减少使 CNN 特别适用于大型输入.

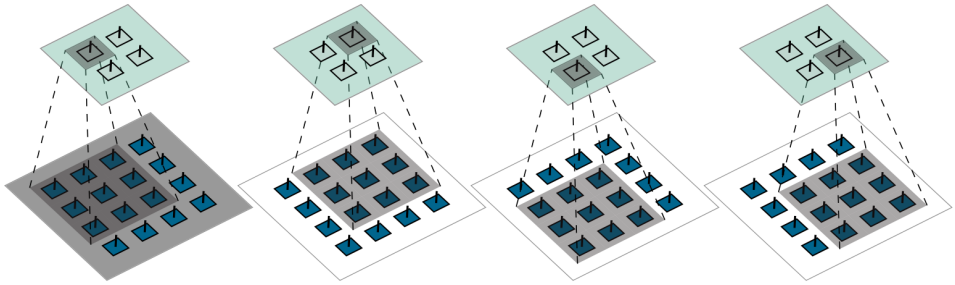


Figure 2.2 Convolutional operation (no padding, unit strides). Bottom grid: input; top grid:

图 6: 卷积操作（无填充，单位步幅）. 底部网格：输入；顶部网格：输出特征图. 阴影的 3×3 方块：不同位置的 3×3 局部感受野. 每个位置示出了对应的输出. 展示了局部性（输出依赖于局部输入）和参数共享（同一滤波器跨位置应用）. 每个向量都有一个索引（出射箭头），表示不同的输入或输出通道.

除了卷积层之外，现代 CNN 还包含许多对其功能重要的其他层，我们现在描述.

池化层 除了填充问题之外，卷积层保留输入的维度，因此需要额外的层来降低模型输出的维度. *池化层*（pooling layer）是最常用的方法，它通过再次取输入的补丁来工作，但不是应用保持维度的函数，而是应用简单的聚合函数，如取最大值（*最大池化*

(max-pooling)) 或平均值（平均池化（average-pooling））(Scherer et al., 2010)．对于步幅为 s 的 $K \times K$ 区域上的最大池化：

$$\text{Pool}(x)_{i,j,c} = \max_{0 \le a,b \le K-1} x_{si+a,sj+b,c}, \tag{108}$$

其中 i, j 是输出的空间索引，c 是通道索引，K 是池化窗口大小，s 是步幅（通常等于 K）．池化层有助于降低特征图的空间维度．它们还引入了一定程度的平移不变性 (translation invariance)，因为输入的微小偏移不会显著影响池化输出．

Dropout Dropout（Dropout）(Srivastava et al., 2014) 是一种正则化技术，在训练期间随机将一部分输入单元置零，以帮助防止过拟合并提高模型的泛化能力：

$$\text{Dropout}(x) = x \odot r, \qquad \text{其中} r_i \sim \text{Bern}(p). \tag{109}$$

这里，$\odot$ 表示逐元素乘法，p 是保持单元活跃的概率．在推理时，dropout 被关闭，剩余单元的输出乘以 p 以维持与训练期间相同的期望输出．

归一化层 归一化层用于通过归一化激活来稳定和加速神经网络的训练．两种广泛使用的技术是批归一化和层归一化．

批归一化 给定一个小批量输入 $\{x_n\}_{n=1}^N$，批归一化（batch normalization）(Ioffe and Szegedy, 2015) 对每个特征维度 c 归一化如下：

$$\text{BatchNorm}(x_n)_c = \gamma_c \frac{x_{n,c} - \mu_c}{\sqrt{\sigma_c^2 + \epsilon}} + \beta_c, \tag{110}$$

$$\mu_c = \frac{1}{N} \sum_{n=1}^{N} x_{n,c}, \qquad \sigma_c^2 = \frac{1}{N} \sum_{n=1}^{N} (x_{n,c} - \mu_c)^2, \tag{111}$$

其中 γ_c, β_c 是每个特征维度 c 的可学习参数，ϵ 是防止除零的小常数．

层归一化 层归一化（layer normalization）(Ba et al., 2016) 对每个单独样本内的特征归一化激活，而不是跨批量归一化．对于输入 $x \in \mathbb{R}^d$，层归一化计算：

$$\text{LayerNorm}(x)_i = \gamma_i \frac{x_i - \mu}{\sqrt{\sigma^2 + \epsilon}} + \beta_i, \tag{112}$$

$$\mu = \frac{1}{d} \sum_{i=1}^{d} x_i, \qquad \sigma^2 = \frac{1}{d} \sum_{i=1}^{d} (x_i - \mu)^2, \tag{113}$$

其中 γ_i, β_i 是每个特征维度 i 的可学习参数，ϵ 是小常数．

批归一化更常用于计算机视觉任务，在这些任务中大且一致的批量大小很常见，并且图像的空间维度可以从批统计中受益．通过利用跨批量的统计，批归一化可以正则化模型并提高泛化能力．另一方面，层归一化在自然语言处理（NLP）任务中更有用，特别是在 Transformer 等模型中 (Vaswani et al., 2017)，其中序列具有可变长度且批量大小可能较小．在 NLP 中，模型通常一次处理一个序列，这使得批归一化效果较差．层归一化通过跨特征维度归一化来帮助稳定此类设置中的激活．

2.4 现代 CNN 架构

在基本 CNN 结构的基础上，已经开发出若干高级架构来解决特定挑战并提高各种任务的性能. 我们不会在此提供完整综述，而将讨论两种特别有影响力的架构：ResNet 和 U-Net.

ResNet 残差网络（Residual network）（ResNet）（He et al., 2016）引入了 跳跃连接（skip connection），允许梯度直接通过层流动，使得训练非常深的网络更容易. 关键思想是学习关于层输入的残差函数：

$$x_{\ell+1} = x_\ell + \mathcal{F}(x_\ell; \theta_\ell), \tag{114}$$

其中 $\mathcal{F}$ 是待学习的残差映射，通常由多个卷积层和非线性组成，x_ℓ 是第 ℓ 层的输入. 函数 $\mathcal{F}$ 和输入 x_ℓ 必须具有相同的维度，加法才有意义. ResNet 中的跳跃连接为梯度回流到早期层提供了一条 “捷径”，缓解了在非常深的网络中可能出现的梯度消失问题. 这个看似非常简单的思想使训练极深网络（例如具有数百层）变得更加可行. ResNet 已广泛应用于各种计算机视觉任务，也被用于一些扩散模型，展示了其多功能性和有效性.

U-Net U-Net（U-Net）（Ronneberger et al., 2015）是一种流行的 CNN 架构，已在扩散模型中得到广泛应用（如第 13 章所讨论）. U-Net 架构由捕获上下文的编码器路径和实现精确定位的对称解码器路径组成，两者之间有跳跃连接. 编码器路径通常由卷积、批归一化、ReLU 激活和最大池化下采样的重复应用组成. 每个下采样步骤使特征通道数翻倍. 数学上，对于编码器中的第 ℓ 层：

$$x_{\ell+1} = \mathrm{MaxPool}\big(\mathrm{ReLU}(\mathrm{BatchNorm}(\mathrm{Conv}(x_\ell)))\big), \tag{115}$$

$$\mathrm{ReLU}(y) = \max(0, y), \tag{116}$$

$$\mathrm{MaxPool}(x) = \max_{\text{over } 2\times 2 \text{ window}}(x). \tag{117}$$

解码器路径由上采样、与相应编码器层输出的拼接以及进一步的卷积组成. 对于解码器中的第 ℓ 层：

$$x_{\ell+1} = \mathrm{ReLU}\big(\mathrm{BatchNorm}(\mathrm{Conv}(\mathrm{Concat}(\mathrm{Upsample}(x_\ell), \mathrm{Skip}(x_\ell))))\big), \tag{118}$$

其中 $\mathrm{Upsample}(x)$ 通常是转置卷积或插值，$\mathrm{Skip}(x_\ell)$ 是相应的编码器层输出. U-Net 中的跳跃连接在保留细粒度空间信息方面起着关键作用. 数学上，它们可以表示为：

$$x_\ell^{\text{decoder}} = \big[\mathrm{Upsample}(x_{\ell-1}^{\text{decoder}}), x_{N-\ell}^{\text{encoder}}\big], \tag{119}$$

其中 N 是总层数，$[\cdot,\cdot]$ 表示沿通道维度拼接. 这些跳跃连接允许网络将解码器路径的高级特征与编码器路径的低级特征结合起来，实现精确定位. 在扩散模型的背景下，该架构允许模型在去噪过程中有效组合不同尺度和噪声水平的信息.

2.5 Transformer

Transformer（Transformer）（Vaswani et al., 2017）是一种近年来获得显著关注的神经网络架构，特别是在 NLP 中，以及最近在视觉任务和扩散模型中，如视觉 Transformer（ViT）（Dosovitskiy et al., 2021）和扩散 Transformer（DiT）（Peebles and Xie, 2023）.

Transformer 架构的核心是 *自注意力机制*（self-attention mechanism）. 对于输入序列 $X = [x_1, \ldots, x_n]^\top \in \mathbb{R}^{n \times d}$，其中 n 是序列长度，d 是特征维度，自注意力计算为：

$$\text{Attention}(Q, K, V) = \text{Softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right) V, \tag{120}$$

其中 $Q = XW^Q$、$K = XW^K$ 和 $V = XW^V$ 分别是查询、键和值矩阵，其中 $W^Q, W^K \in \mathbb{R}^{d \times d_k}$ 且 $W^V \in \mathbb{R}^{d \times d_v}$. 这里，$d_k$ 是键和查询的维度，d_v 是值的维度. 自注意力背后的直觉是，它允许模型在处理每个元素时权衡输入不同部分的重要性. 点积 $QK^\top$ 度量查询与键之间的相似性，决定每个值对输出的贡献程度.

多头注意力（Multi-head attention）通过并行应用多个注意力操作来扩展这一点：

$$\text{MultiHead}(X) = \text{Concat}(\text{head}_1, \ldots, \text{head}_h)\, W^O, \tag{121}$$

$$\text{head}_i = \text{Attention}(XW_i^Q, XW_i^K, XW_i^V), \tag{122}$$

其中 $W^O \in \mathbb{R}^{hd_v \times d}$，$h$ 是注意力头的数量.

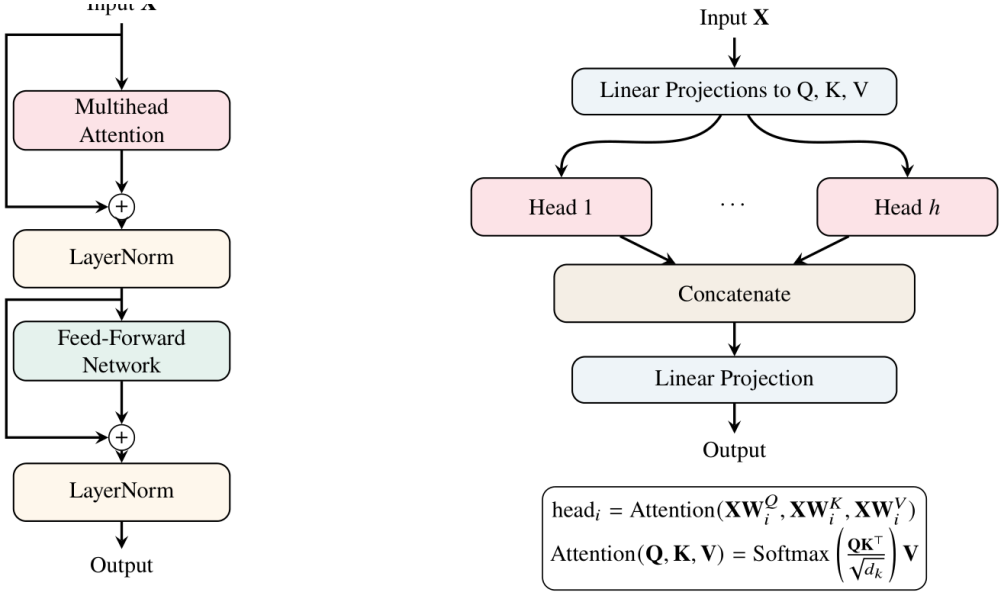
一个完整的 Transformer 块由多头注意力和一个带残差连接的前馈网络（FFN）组成：

$$Z = \text{LayerNorm}(X + \text{MultiHead}(X)), \tag{123}$$

$$\text{FFN}(Z) = \text{ReLU}(ZW_1 + b_1)W_2 + b_2, \tag{124}$$

$$\text{Output} = \text{LayerNorm}(Z + \text{FFN}(Z)), \tag{125}$$

其中 $W_1 \in \mathbb{R}^{d \times d_{\text{FFN}}}$、$W_2 \in \mathbb{R}^{d_{\text{FFN}} \times d}$、$b_1 \in \mathbb{R}^{d_{\text{FFN}}}$ 和 $b_2 \in \mathbb{R}^d$ 是前馈网络的参数. 这里，d_{FFN} 是前馈网络内层的维度. Transformer 块的结构和多头注意力机制如图 7 所示.



ıre 2.3 The transformer architecture. (a) A single transformer encoder block. Transformer

图 7: Transformer 架构. (a) 单个 Transformer 编码器块. Transformer 模型通常通过堆叠 N 个这样的块来构建. 每个块由一个多头注意力层和一个前馈网络组成. 每个子层的输出通过残差连接与其输入相加，然后将结果通过层归一化. (b) 多头注意力机制. 输入被线性投影，为多个并行的 "头" 创建查询 Q_i、键 K_i 和值 V_i. 每个头计算缩放点积注意力. 输出然后被拼接并通过最终的线性投影.

为了纳入位置信息，Transformer 使用 *位置编码*（positional encoding）. 对于位置 pos 和 d_{model} 维嵌入的维度 i:

$$\text{PE}(pos, 2i) = \sin\left(\frac{pos}{10000^{2i/d_{\text{model}}}}\right), \tag{126}$$

$$\text{PE}(pos, 2i+1) = \cos\left(\frac{pos}{10000^{2i/d_{\text{model}}}}\right). \tag{127}$$

视觉 Transformer 视觉 Transformer 使 Transformer 架构适应图像任务. 关键思想是将图像视为补丁的序列. 给定图像 $X \in \mathbb{R}^{H\times W\times C}$，它被划分为 N 个补丁 $x_p \in \mathbb{R}^{P^2C}$，其中 (P, P) 是每个补丁的分辨率. 这些补丁然后被线性嵌入并由标准 Transformer 编码器处理:

$$z_0 = [x_{\text{class}};\, x_1E;\, x_2E;\, \ldots;\, x_NE] + E_{\text{pos}}, \tag{128}$$

$$z_\ell = \text{TransformerEncoder}(z_{\ell-1}), \qquad \ell = 1, \ldots, L, \tag{129}$$

其中 $x_{\text{class}} \in \mathbb{R}^D$ 是可学习的分类 token，$E \in \mathbb{R}^{P^2C\times D}$ 是补丁嵌入投影，$E_{\text{pos}} \in \mathbb{R}^{(N+1)\times D}$ 是可学习的位置嵌入. 这里，D 是 Transformer 隐藏层的维度.

Transformer 已被适配以处理扩散模型中的图像数据. 例如，扩散 Transformer（DiT）（Peebles and Xie, 2023）在潜在补丁上操作.

2.6 反向传播规则的 Lagrangian 推导

有了神经网络，问题只解决了一半：我们仍然需要训练它们. 赢得 “硬件彩票” 的算法是 *反向传播*（backpropagation）. 虽然通常的推导基于微积分的链式法则，但还有另一种更优雅的推导，基于凸优化，由 Yann LeCun 在其 1987 年的博士论文（LeCun, 1987）及后续论文（LeCun, 1988）中提出.

考虑一个具有 L 层的前馈神经网络. 我们可以将优化问题表述为约束优化问题：

$$\begin{array}{ll}\min_{\{\theta_\ell, x_\ell\}} & C(x_L, y) \\ \text{subject to:} & x_\ell = f_\ell(x_{\ell-1}; \theta_\ell), \quad \text{对} \ell = 1, \ldots, L.\end{array} \tag{130}$$

这里，$C(x_L, y)$ 是比较网络输出 x_L 与目标 y 的损失函数，$\theta_\ell \in \mathbb{R}^{d_\ell \times d_{\ell-1}}$ 是第 ℓ 层的权重，$x_\ell \in \mathbb{R}^{d_\ell}$ 是第 ℓ 层的激活，$f_\ell : \mathbb{R}^{d_{\ell-1}} \times \mathbb{R}^{d_\ell \times d_{\ell-1}} \to \mathbb{R}^{d_\ell}$ 是逐层变换（例如，一个仿射变换后接一个非线性激活函数）.

我们为每层约束引入 Lagrange 乘子 $\lambda_\ell \in \mathbb{R}^{d_\ell}$，形成 Lagrangian：

$$L[\{\theta_\ell, x_\ell, \lambda_\ell\}] = C(x_L, y) + \sum_{\ell=1}^{L} \lambda_\ell^\top (x_\ell - f_\ell(x_{\ell-1}; \theta_\ell)). \tag{131}$$

应用 KKT 条件（如第 1.5 节所讨论），我们令 Lagrangian 的导数为零：

$$\frac{\partial L}{\partial x_L} = \frac{\partial C(x_L, y)}{\partial x_L} + \lambda_L = 0, \tag{132}$$

$$\frac{\partial L}{\partial x_\ell} = \lambda_\ell^\top - \lambda_{\ell+1}^\top \frac{\partial f_{\ell+1}}{\partial x_\ell} = 0, \qquad \text{对} \ell = 1, \ldots, L-1, \tag{133}$$

$$\frac{\partial L}{\partial \theta_\ell} = -\lambda_\ell^\top \frac{\partial f_\ell}{\partial \theta_\ell} = 0, \qquad \text{对} \ell = 1, \ldots, L. \tag{134}$$

由式 (132)，我们识别出 $\lambda_L = -\frac{\partial C(x_L, y)}{\partial x_L}$，这给出了反向传播的起点. 重排式 (133) 并对两边取转置，我们推导出 Lagrange 乘子的递归关系：

$$\lambda_\ell^\top = \lambda_{\ell+1}^\top \frac{\partial f_{\ell+1}}{\partial x_\ell} \tag{135}$$

$$= \lambda_{\ell+2}^\top \frac{\partial f_{\ell+2}}{\partial x_{\ell+1}} \frac{\partial f_{\ell+1}}{\partial x_\ell} = \cdots = \lambda_L^\top \frac{\partial f_L}{\partial x_{L-1}} \cdots \frac{\partial f_{\ell+1}}{\partial x_\ell}. \tag{136}$$

这就是反向传播步骤，其中 Lagrange 乘子（即误差信号）通过层变换的 Jacobian 的连续矩阵乘法，从最后一层反向传播通过网络.

最后，式 (134) 表明 $\{\theta_\ell\}$ 是 L 的驻点，这等价于在满足约束的同时找到输出损失函数 $C(x_L, y)$ 的最小值. 做到这一点的最直接方法是使用梯度下降算法更新权重. 为此，我们可以使用式 (134) 推导损失关于参数的梯度：

$$\frac{\partial L}{\partial \theta_\ell} = -\lambda_\ell^\top \frac{\partial f_\ell}{\partial \theta_\ell} = -\lambda_L^\top \frac{\partial f_L}{\partial x_{L-1}} \cdots \frac{\partial f_{\ell+1}}{\partial x_\ell} \frac{\partial f_\ell}{\partial \theta_\ell}. \tag{137}$$

完整的反向传播算法如算法 1 所示. 然后我们使用梯度下降算法更新权重:

$$\theta_\ell \leftarrow \theta_\ell - \eta \frac{\partial C}{\partial \theta_\ell}, \tag{138}$$

其中 η 是学习率. 对于深度学习问题, 学习率 η 通常被选择为自适应的(例如使用 Adam 优化器, Kingma and Ba, 2014), 并且梯度在从训练集中采样的一批数据上估计 (称为随机梯度下降) .

Algorithm 1 反向传播算法

1: 前向传播: 对 $\ell = 1, \ldots, L$ 计算 $x_\ell = f_\ell(x_{\ell-1}; \theta_\ell)$
2: 计算输出梯度: $\lambda_L = -\frac{\partial C(x_L, y)}{\partial x_L}$
3: 使用式 (137) 计算 $\frac{\partial C}{\partial \theta_L}$
4: **for** $\ell = L-1, \ldots, 1$ **do**
5: 使用式 (135) 由 $\lambda_{\ell+1}$ 计算 λ_ℓ
6: 使用式 (137) 计算 $\frac{\partial C}{\partial \theta_\ell}$
7: **end for**

Chapter 3

物理预备

3.1 引言

在本章中，我们旨在简要概述统计物理与热力学. 两者都是物理学中的主要领域，已有无数著作论述（Landau and Lifshitz, 1980; Huang, 1987）. 试图在此处对这些主题进行接近完整的覆盖将是徒劳且不必要的. 相反，我们将聚焦于最相关的主题，以突出这些领域的物理与本书其余部分将要讨论的生成式 AI 方法之间的相似性. 具体而言，我们将讨论重要概念，例如通过 Hamiltonian *动力学* (Hamiltonian dynamics) 驱动物理系统演化的 Hamiltonian. 我们讨论各种热力学系综，这些系综最早由 J. Willard Gibbs (1902) 形式化，例如 *微正则系综* (microcanonical ensemble)（NVE 系综）、*正则系综* (canonical ensemble) (NVT 系综) 和 *巨正则系综* (grand canonical ensemble) (μVT 系综）. 我们讨论基本热力学量，如温度、熵、自由能、功和热，并简要讨论 *热力学第一定律* (First law of thermodynamics) 和 *热力学第二定律* (Second law of thermodynamics). 我们在本章结尾解决一个悖论，即为什么系统产生的热必须与热浴熵的增加成正比——这一结果在本书第二部分和第三部分中被多次使用.

3.2 统计力学基础

统计物理是物理学的一个分支，处理大量粒子的系综，其集体行为过于复杂，无法从第一原理建模. 它将微观物理定律（经典或量子）与我们可以测量的系统宏观观测量联系起来. 顾名思义，实现这一点所用的语言是统计学的语言.

统计物理背后的核心思想是：即使我们可以完全定义一个物理系统的微观态（包含描述其所含粒子所需的所有可能自由度：位置、动量、质量、自旋等），由于系统总是处于不断运动中，这也几乎没有什么用处. 因此，当我们想要推断一个材料或物体的任何可测量宏观观测量（如能量 E 或体积 V）时，考虑单个微观态只会给出瞬时的、转瞬即逝的指示. 相反，我们需要知道系统可能处于的所有状态，以及它在每个状态中停留的时间.

为此，统计力学旨在用微观态上的概率分布 $\rho(\boldsymbol{\zeta})$ 来描述系统，其中 $\boldsymbol{\zeta} = (\boldsymbol{\xi}, \boldsymbol{\eta})$ 表示相空间中系统的状态，$\boldsymbol{\xi}$ 表示位置，$\boldsymbol{\eta}$ 表示动量. 略过关于时间平均与系综平均的一些基本讨论，我们认为该概率表示在给定微观态中花费的时间比例. 给定 $\rho(\boldsymbol{\zeta})$ 和定义每个微观态的宏观性质的函数 $\mathcal{O}(\boldsymbol{\zeta})$，宏观观测量可定义为该分布下的期望：

$$\mathcal{O}[\rho] = \int \mathrm{d}\boldsymbol{\zeta}\, \rho(\boldsymbol{\zeta})\, \mathcal{O}(\boldsymbol{\zeta}). \tag{139}$$

定义概率分布 $\rho(\boldsymbol{\zeta})$ 是统计物理中核心感兴趣的问题，它也可以被视为一个统计推断问题！根据 E. T. Jaynes (1957a,b) 开创的信息论解释，该概率分布代表我们关于系统微观态的主观知识或信念，基于可获得的宏观信息.

这些分布的主要形式——Boltzmann 分布——已在第 1 章中作为给定平均能量下的最大熵分布导出. 在以下各节中，我们将通过一种再次推导它的方法来阐明为什么它描述了一个与固定温度热浴接触的系统.

为此，我们首先需要讨论对应于孤立系统（而非与热浴接触的系统）的更具限制性但更基本的概率分布 $\rho(\boldsymbol{\zeta})$. 但在此之前，我们介绍本章其余部分主要关注的宏观观测量——内能（internal energy）$\mathcal{U}$——及其对应的微观函数，即 Hamiltonian $\mathcal{H}$.

3.2.1 能量与 Hamiltonian

给定微观态 $\boldsymbol{\zeta} = (\boldsymbol{\xi}, \boldsymbol{\eta}) = \{\boldsymbol{\xi}_1, \ldots, \boldsymbol{\xi}_N, \boldsymbol{\eta}_1, \ldots, \boldsymbol{\eta}_N\}$，其中 $(\boldsymbol{\xi}_i, \boldsymbol{\eta}_i)$ 表示粒子 i 的三维坐标和动量，我们认为系统的动力学由 Hamiltonian $\mathcal{H}(\boldsymbol{\zeta})$ 通过以下方程控制：

$$\frac{\mathrm{d}\boldsymbol{\xi}}{\mathrm{d}\tau} = \frac{\partial \mathcal{H}}{\partial \boldsymbol{\eta}}, \qquad \frac{\mathrm{d}\boldsymbol{\eta}}{\mathrm{d}\tau} = -\frac{\partial \mathcal{H}}{\partial \boldsymbol{\xi}}. \tag{140}$$

我们可以将 Hamiltonian 视为一个计算系统在微观位形 $\boldsymbol{\zeta}$ 中总能量的函数，同时编码位置和动量如何随时间演化. 它通常取以下形式：

$$\mathcal{H}(\boldsymbol{\zeta}) = \sum_{i=1}^{N} \frac{1}{2m} \|\boldsymbol{\eta}_i\|^2 + V(\boldsymbol{\xi}), \tag{141}$$

其中 m 是粒子质量，$V(\boldsymbol{\xi})$ 是势能函数. 第一项表示粒子的动能，第二项表示粒子间相互作用和外力引起的势能. 大多数物理理论被表述为局域理论，因此粒子间的相互作用通常是局域的. 例如，分子通过 Lennard–Jones 势相互作用（r^{-6} 尾项建模吸引性的 van der Waals 相互作用），该势随距离衰减：

$$V(\boldsymbol{\xi}) = \sum_{i<j} 4V_0 \left[\left(\frac{\sigma}{|\boldsymbol{\xi}_i - \boldsymbol{\xi}_j|} \right)^{12} - \left(\frac{\sigma}{|\boldsymbol{\xi}_i - \boldsymbol{\xi}_j|} \right)^{6} \right], \tag{142}$$

其中 V_0 是势阱深度，σ 是粒子间势为零的距离. 大多数物理系统还表现出对称性，例如式 (142) 在粒子交换下的不变性.

对系统可能处于的所有微观态取平均，Hamiltonian 给出系统的平均能量，称为内能：

$$\mathcal{U}[\rho] = \int \mathrm{d}\boldsymbol{\zeta}\, \rho(\boldsymbol{\zeta})\, \mathcal{H}(\boldsymbol{\zeta}). \tag{143}$$

相空间体积守恒 Hamiltonian 动力学的一个重要性质是它保持相空间中的体积. 考虑时间 $\tau = 0$ 时相空间中的一个小体积元 $\mathrm{d}V_0$，它在时间 τ 演化为新的体积元 $\mathrm{d}V_\tau$（见图 8）. 这些体积元之间的关系由 Jacobi 行列式给出：

$$\mathrm{d}V_\tau = \left| \frac{\partial(\boldsymbol{\xi}_\tau, \boldsymbol{\eta}_\tau)}{\partial(\boldsymbol{\xi}_0, \boldsymbol{\eta}_0)} \right| \mathrm{d}V_0, \tag{144}$$

其中 $\frac{\partial(\boldsymbol{\xi}_\tau, \boldsymbol{\eta}_\tau)}{\partial(\boldsymbol{\xi}_0, \boldsymbol{\eta}_0)}$ 是从 $(\boldsymbol{\xi}_0, \boldsymbol{\eta}_0)$ 到 $(\boldsymbol{\xi}_\tau, \boldsymbol{\eta}_\tau)$ 变换的 Jacobi 矩阵. Jacobi 行列式的绝对值给出体积之比.

为证明 Jacobi 行列式等于 1，注意 Hamiltonian 向量场 $(\dot{\boldsymbol{\xi}}, \dot{\boldsymbol{\eta}})$ 的散度由 Hamilton 方程和混合偏导数相等而消失. 这一结果，加上 $\boldsymbol{J}_0 = 1$，意味着体积守恒——即经典力学中的 Liouville 定理（Liouville's theorem）(Landau and Lifshitz, 1976). 数学上，这意味着 Hamiltonian 向量场 $(\dot{\boldsymbol{\xi}}, \dot{\boldsymbol{\eta}})$ 的散度为零：

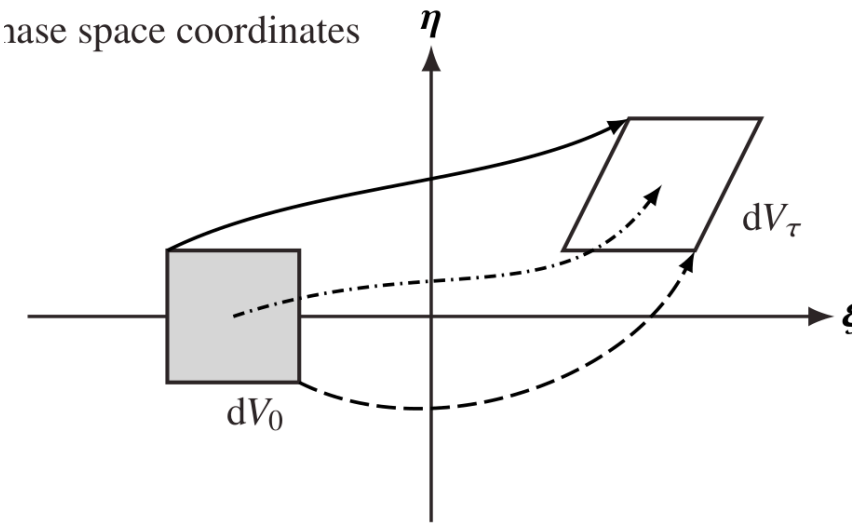
$$\frac{\partial \dot{\boldsymbol{\xi}}}{\partial \boldsymbol{\xi}} + \frac{\partial \dot{\boldsymbol{\eta}}}{\partial \boldsymbol{\eta}} = \frac{\partial^2 \mathcal{H}}{\partial \boldsymbol{\xi} \partial \boldsymbol{\eta}} - \frac{\partial^2 \mathcal{H}}{\partial \boldsymbol{\eta} \partial \boldsymbol{\xi}} = 0. \tag{145}$$

利用这一性质以及 $\tau = 0$ 时 Jacobi 矩阵为单位矩阵的事实，可以证明 Jacobi 行列式对所有 τ 保持等于 1.

$$\frac{\mathrm{d}}{\mathrm{d}\tau} \left| \frac{\partial(\boldsymbol{\xi}_\tau, \boldsymbol{\eta}_\tau)}{\partial(\boldsymbol{\xi}_0, \boldsymbol{\eta}_0)} \right| = \left(\frac{\partial \boldsymbol{\xi}_\tau}{\partial \boldsymbol{\xi}_\tau} + \frac{\partial \boldsymbol{\eta}_\tau}{\partial \boldsymbol{\eta}_\tau} \right) \left| \frac{\partial(\boldsymbol{\xi}_\tau, \boldsymbol{\eta}_\tau)}{\partial(\boldsymbol{\xi}_0, \boldsymbol{\eta}_0)} \right| = 0$$

$$\Rightarrow \left| \frac{\partial(\boldsymbol{\xi}_\tau, \boldsymbol{\eta}_\tau)}{\partial(\boldsymbol{\xi}_0, \boldsymbol{\eta}_0)} \right| = \text{const} = \left| \frac{\partial(\boldsymbol{\xi}_0, \boldsymbol{\eta}_0)}{\partial(\boldsymbol{\xi}_0, \boldsymbol{\eta}_0)} \right| = 1.$$

olume of a phase space element remains constant: $\mathrm{d}V_\tau$



rvation of phase space volume in Hamiltonian dynamics. The

图 8: Hamiltonian 动力学中相空间体积的守恒. 阴影矩形 $\mathrm{d}V_0$ 被剪切为等面积的交叉阴影平行四边形 $\mathrm{d}V_\tau$. 三条曲线（实线、长虚线和短虚线）是相空间中点的轨迹.

3.2.2 微正则系综：能量恒定的系统

我们首先考虑具有恒定内能 $\mathcal{U}$（宏观观测量）的系统；即式 (446) 中的内能具有零方差. 这样的系统称为 *孤立系统*（isolated system），表示与任何其他系统没有能量交换，否则可能导致能量涨落. 宇宙是最直接的例子，处于恒定能量下.

尽管是孤立的，系统并不是静态的. 描述系统的微观位形总是在变化，因为粒子四处运动并相互碰撞. 然而，在这些涨落中，粒子之间仅在彼此之间交换能量，系统某一

部分的任何能量增加都是另一部分能量损失的结果. 换言之，对于任何变化 $\boldsymbol{\zeta} \to \boldsymbol{\zeta}'$，我们有 $\mathcal{H}(\boldsymbol{\zeta}) = \mathcal{H}(\boldsymbol{\zeta}') = E$. 因此，给定某一时刻观测到的宏观能量值 E，系统在每个满足 $\mathcal{H}(\boldsymbol{\zeta}) = E$ 的微观态 $\boldsymbol{\zeta}$ 中具有非零概率. 然而，为了确定概率质量在这些微观态上的分布方式，我们需要做最后一个基本假设：

在孤立系统中，所有可及微观态是等概率的.

这导出了孤立系统的概率分布：

$$\rho(\boldsymbol{\zeta}) = \begin{cases} \frac{1}{\Omega(E)}, & \text{若} \mathcal{H}(\boldsymbol{\zeta}) = E, \\ 0, & \text{否则}. \end{cases} \tag{146}$$

其中 $\Omega(E)$ 是能量为 E 的状态数. 这称为微正则系综. 或者，微正则系综也可以使用 Jaynes 的最大熵原理（见第 1.5.5 节）推导，仅对概率分布的归一化有一个约束. 结果将是相同的.

熵 在第 1.2.3 节中，我们将熵讨论为概率分布的一个性质. 既然我们已将系统定义为状态上的概率分布，我们也可以在此应用这一定义. 正如我们将在平衡热力学一节中看到的，熵将被证明是物理学中最基本的概念之一.

对于微正则系综，熵由下式给出：

$$S[\rho] = -k_B \int \mathrm{d}\boldsymbol{\zeta}\, \rho(\boldsymbol{\zeta}) \log \rho(\boldsymbol{\zeta}) \tag{147}$$

$$= -k_B \int \mathrm{d}\boldsymbol{\zeta}\, \frac{\delta(\mathcal{H}(\boldsymbol{\zeta}) - E)}{\Omega(E)} \log \frac{1}{\Omega(E)} \tag{148}$$

$$= k_B \log \Omega(E), \tag{149}$$

其中我们引入了 Dirac δ 函数 $\delta(\mathcal{H}(\boldsymbol{\zeta}) - E)$ 来仅选择能量为 E 的状态. 该熵是宏观观测量能量 E 的函数. 如果你想知道这种依赖关系隐藏在方程左边的哪里，请记住 ρ 实际上是以 E 为条件的，如前所述.

值得注意的是，我们观察到物理熵与信息熵是等价的，仅相差一个附加常数 k_B，我们已将其悄悄引入熵的定义中. 这个常数称为 Boltzmann 常数（Boltzmann constant），将在整个统计力学中不断出现. 其值约为 $1.380649 \times 10^{-23}\,\mathrm{J/K}$. 虽然它具有物理重要性，但在本书的其余部分中，为简单起见，我们通常将其值设为 1.

这清楚地表明，物理意义上的熵不过是与系统给定宏观观测相对应的微观态数的对数. 用信息论的术语来说，物理熵因此描述了由于用宏观观测量而非实际微观态来描述系统而导致的缺失信息量——即我们的不确定性. 物理与信息之间的深刻联系近几十年来一直是备受关注的主题. 这一思想被 John Wheeler 的名言 “it from bit” 所著名地概括.

根据 E. T. Jaynes (1957a)，物理中的熵不仅是物理系统的一个性质，还代表我们对系统微观态或其微观自由度的无知. 因此，有些争议地，我们可以将熵视为一个主观量，它取决于我们关于系统的知识. 这种熵和建模的主观观点也为 Bayes 推断所共享，其中概率代表我们关于系统的信念程度，而非给定事件的客观频率.

温度 超越熵的哲学性质，我们现在看一个同样重要的由它导出的概念：温度. 温度作为一个概念，与熵等概念不同，因为我们都对温度的含义有直观理解. 我们甚至可以感受到它：在 Muizenberg 海滩的夏日，我们可以感到炎热. 我们在那种情况下描述的温度是高的. 相反，在冬天，坐在牛津一间保温不佳的图书馆里，我们感到寒冷. 我们在那时描述的温度是低的.

思考温度的最简单方式是将其视为（两倍的）存储在粒子随机热运动中的每自由度平均能量. 为推导这一点，我们使用 能量均分定理（equipartition theorem），该定理指出系统的动能被均等地分配到其所有自由度中. 回忆一下，对于单原子理想气体，内能为 $E = \frac{3}{2}Nk_BT$. 为简单起见令 $k_B = 1$，我们看到每自由度的平均动能为 $\varepsilon = \frac{1}{2}T$，或 $T = 2\varepsilon$，如上所述. 上述内容可以通过假设具有标准形式的 Hamiltonian 并计算平衡（Boltzmann）分布下的平均动能来容易地推导：

$$\mathcal{H}(\boldsymbol{\xi}, \boldsymbol{\eta}) = \sum_{i=1}^{N} \frac{1}{2m} \|\boldsymbol{\eta}_i\|^2 + V(\boldsymbol{\xi}) \tag{150}$$

$$E[E_{\text{kin}}] = \int \mathrm{d}\boldsymbol{\xi}\mathrm{d}\boldsymbol{\eta}\, \frac{1}{Z} \exp(-\beta \mathcal{H}(\boldsymbol{\xi}, \boldsymbol{\eta})) \sum_{i=1}^{N} \frac{1}{2m} \|\boldsymbol{\eta}_i\|^2 = \frac{3}{2} N k_B T. \tag{151}$$

还有一个温度的热力学定义：

$$\frac{1}{T} = \frac{\partial S(E)}{\partial E}. \tag{152}$$

换言之，温度定义为熵随能量变化的速率，在特定能量处求值（如图 9 所示）. 为使其严格，我们需要在取偏导数时保持其他一些量不变，如粒子数 N 和体积 V. 由于能量以焦耳为单位定义，熵以 J/K 为单位（由于包含了 Boltzmann 常数），我们因此发现温度以开尔文为便利单位度量.

我们观察到，由于 T 正比于系统中每自由度的动能，而 S 计数描述所有这些隐藏自由度所需的比特数，它们的乘积代表这些比特中所表示的总能量. 在 Helmholtz 自由能的定义中（见第 3.2.4 节），我们需要从总（平均）能量中减去该量，以得到可自由使用的能量量.

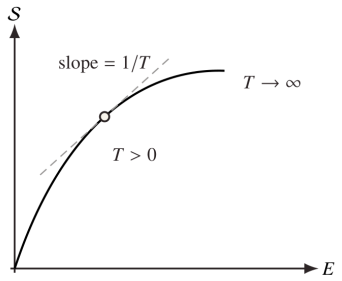


Figure 3.2 Entropy–energy relationship and temperature. The curve $\mathcal{S}(E)$ is shown together

图 9: 熵–能量关系与温度. 曲线 $S(E)$ 与切线一起显示，切线说明斜率的倒数 $1/T$ 设定了熵随能量增长的速率. 当 E 增加时，切线变平，对应于越来越高的温度.

3.2.3 正则系综：温度恒定的系统

到目前为止，虽然关于熵和温度的讨论是普遍的，但我们仅考虑了处于恒定内能下的孤立系统. 然而，这对于一个系统来说实际上是一个非常有限的定义. 任何系统（也许除了宇宙）本身都将是更大系统的一部分，并不可避免地与该系统相互作用. 通过这些相互作用，所关注的系统可能被推入不再具有相同 $\mathcal{H}(\boldsymbol{\zeta})$ 值的微观位形. 系统可能的微观态 $\boldsymbol{\zeta}$ 上的概率分布现在可以到达更广泛的可能位形集合，不再全部具有相同的 $\mathcal{H}(\boldsymbol{\zeta})$ 值. 关键是，式 (446) 中的内能现在不再具有零方差.

在统计力学中形式化建模的方式是：将所关注的系统视为一个具有恒定内能 E_{tot} 的大得多的孤立系统的一部分（如图 10 所示）. 该孤立系统中不属于所关注系统的其余自由度 $\boldsymbol{\zeta}_{\mathrm{bath}}$ 称为 热浴（热库）(heat bath)，它是一个处于热平衡、具有恒定温度的大系统，所关注的系统可以与其交换能量. 通过与该热浴交换能量，$\mathcal{H}(\boldsymbol{\zeta})$ 现在可以涨落，而总系统的能量保持不变：$E_{\mathrm{tot}} = \mathcal{H}(\boldsymbol{\zeta}, \boldsymbol{\zeta}_{\mathrm{bath}}) = \mathcal{H}(\boldsymbol{\zeta}) + \mathcal{H}_{\mathrm{bath}}(\boldsymbol{\zeta}_{\mathrm{bath}})$. 关键是，我们假设热浴比所关注的系统大几个数量级，使得 $\mathcal{H}_{\mathrm{bath}}(\boldsymbol{\zeta}_{\mathrm{bath}})$ 的涨落可以忽略. 因此，我们可以假设热浴的温度 T_{bath} 对于所关注系统的所有可能位形都是恒定的.

为推导这样一个系统的概率分布 $\rho(\boldsymbol{\zeta})$，我们将组合系统（所关注的系统加热浴）视为具有总能量 E_{tot} 的孤立系统. 组合系统的概率分布为：

$$\rho_{\mathrm{tot}}(\boldsymbol{\zeta}, \boldsymbol{\zeta}_{\mathrm{bath}}) = \begin{cases} \frac{1}{\Omega_{\mathrm{tot}}(E_{\mathrm{tot}})}, & \text{若} \mathcal{H}(\boldsymbol{\zeta}) + \mathcal{H}_{\mathrm{bath}}(\boldsymbol{\zeta}_{\mathrm{bath}}) = E_{\mathrm{tot}}, \\ 0, & \text{否则.} \end{cases} \tag{153}$$

其中 $\boldsymbol{\zeta}_{\mathrm{bath}}$ 表示热浴的微观态.

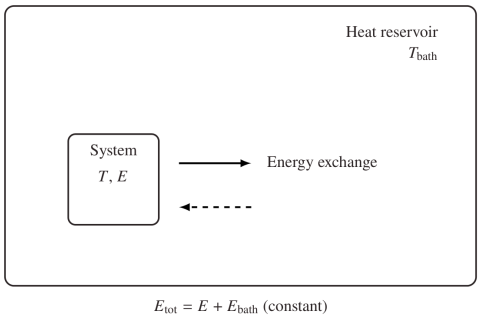


Figure 3.3 System–reservoir coupling. The reservoir remains much larger than the system so

图 10: 系统–热浴耦合. 热浴始终比系统大得多，使得交换能量时 E_{bath} 保持不变，同时保持组合能量 E_{tot} 恒定. 对向箭头表示热交换.

对热浴状态进行边缘化，我们得到：

$$\rho(\boldsymbol{\zeta}) = \int \mathrm{d}\boldsymbol{\zeta}_{\mathrm{bath}}\, \rho_{\mathrm{tot}}(\boldsymbol{\zeta}, \boldsymbol{\zeta}_{\mathrm{bath}}) \tag{154}$$

$$= \frac{1}{\Omega_{\mathrm{tot}}(E_{\mathrm{tot}})} \int \mathrm{d}\boldsymbol{\zeta}_{\mathrm{bath}}\, \delta(E_{\mathrm{tot}} - \mathcal{H}(\boldsymbol{\zeta}) - \mathcal{H}_{\mathrm{bath}}(\boldsymbol{\zeta}_{\mathrm{bath}})) \tag{155}$$

$$= \frac{\Omega_{\mathrm{bath}}(E_{\mathrm{tot}} - \mathcal{H}(\boldsymbol{\zeta}))}{\Omega_{\mathrm{tot}}(E_{\mathrm{tot}})}, \tag{156}$$

其中 $\Omega_{\text{bath}}(E_{\text{bath}})$ 是能量为 $E_{\text{bath}} = E_{\text{tot}} - \mathcal{H}(\boldsymbol{\zeta})$ 的热浴微观态数.

为继续推进，我们观察到对于固定能级 $\mathcal{H}(\boldsymbol{\zeta}) = E$，我们可以再次假设该能级内状态的能量均分，并使用式 (149) 中孤立系统熵的定义来改写 Ω_{bath}：

$$\Omega_{\text{bath}}(E_{\text{tot}} - \mathcal{H}(\boldsymbol{\zeta})) = \exp\left(\frac{S_{\text{bath}}(E_{\text{tot}} - \mathcal{H}(\boldsymbol{\zeta}))}{k_B}\right). \tag{157}$$

现在我们做一个关键假设：热浴比所关注的系统大得多. 这使我们能够在 E_{tot} 附近对 S_{bath} 进行 Taylor 展开：

$$S_{\text{bath}}(E_{\text{tot}} - \mathcal{H}(\boldsymbol{\zeta})) = S_{\text{bath}}(E_{\text{tot}}) - \left.\frac{\partial S_{\text{bath}}}{\partial E}\right|_{E_{\text{tot}}} \mathcal{H}(\boldsymbol{\zeta}) + \mathcal{O}\left(\frac{\mathcal{H}(\boldsymbol{\zeta})^2}{E_{\text{tot}}^2}\right) \tag{158}$$

$$\approx S_{\text{bath}}(E_{\text{tot}}) - \frac{\mathcal{H}(\boldsymbol{\zeta})}{T_{\text{bath}}}, \tag{159}$$

其中在第一行我们将熵展开到 $\mathcal{H}(\boldsymbol{\zeta})$ 的一阶. 高阶项 $\mathcal{O}(\mathcal{H}(\boldsymbol{\zeta})^2/E_{\text{tot}}^2)$ 可以忽略，因为热浴比系统大得多，所以 $\mathcal{H}(\boldsymbol{\zeta})/E_{\text{tot}} \ll 1$. 这是统计力学中处理大系统时的常见近似. 在第二行中，我们使用了式 (152) 中温度的定义.

将此代回我们的 $\rho(\boldsymbol{\zeta})$ 表达式：

$$\rho(\boldsymbol{\zeta}) = \frac{1}{\Omega_{\text{tot}}(E_{\text{tot}})} \exp\left(\frac{S_{\text{bath}}(E_{\text{tot}})}{k_B}\right) \exp\left(-\frac{\mathcal{H}(\boldsymbol{\zeta})}{k_B T_{\text{bath}}}\right) \tag{160}$$

$$= \frac{1}{Z} \exp\left(-\frac{\mathcal{H}(\boldsymbol{\zeta})}{k_B T_{\text{bath}}}\right) = \rho^{\text{eq}}(\boldsymbol{\zeta}), \tag{161}$$

其中我们将第一个指数项吸收到归一化常数 Z 中，因为 $S_{\text{bath}}(E_{\text{tot}})$ 是常数且不依赖于 $\boldsymbol{\zeta}$. 因此，我们将所有独立于 $\boldsymbol{\zeta}$ 的项包含在归一化常数 Z 中，Z 称为 *配分函数* (partition function)：

$$Z = \int \mathrm{d}\boldsymbol{\zeta} \, \exp\left(-\frac{\mathcal{H}(\boldsymbol{\zeta})}{k_B T_{\text{bath}}}\right). \tag{162}$$

这就是著名的 Boltzmann 分布，即正则系综，我们在第 1.5.5 节中已经找到. 参数 $\beta = 1/(k_B T_{\text{bath}})$ 称为 *逆温度* (inverse temperature)，它也为第 1.5.5 节中引入的 Lagrange 乘子提供了物理解释，即作为热浴的逆温度. 归一化常数 Z 称为配分函数，在统计力学中起着核心作用，我们将很快看到. 它编码了概率如何在不同能级之间分布.

注意，我们已经去掉了对组合系统总能量 E_{tot} 的依赖. 唯一剩余的影响是热浴的温度 T_{bath}，在热平衡时它等于所关注系统的温度 T.

3.2.4 从配分函数到热力学量

配分函数 Z 在统计力学中起着核心作用. 它编码了关于系统的所有热力学信息，并作为各种热力学量的生成函数. 注意，这里 Z 隐含地是温度 T 的函数，或等价地是逆温度 $\beta = 1/(k_B T)$ 的函数. 我们现在以 Z 为基础推导三个对我们最重要的热力学量的表达式：内能、熵和自由能.

内能 在式 (446) 中，我们将系统的内能定义为 Hamiltonian 在系统所有可能状态上的期望. 我们可以类似地用配分函数表达此定义：

$$E = -\frac{\partial}{\partial\beta}\log Z = \frac{1}{Z}\int \mathrm{d}\boldsymbol{\zeta}\, \exp(-\beta\mathcal{H}(\boldsymbol{\zeta}))\,\mathcal{H}(\boldsymbol{\zeta}) = \int \mathrm{d}\boldsymbol{\zeta}\, \rho^{\mathrm{eq}}(\boldsymbol{\zeta})\,\mathcal{H}(\boldsymbol{\zeta}). \tag{163}$$

熵 熵也可以用配分函数表达：

$$\begin{aligned}
S &= k_B \frac{\partial}{\partial T}(T\log Z) && (164)\\
&= k_B \log Z + k_B T \frac{\partial \log Z}{\partial T} && (165)\\
&= k_B \log Z + k_B \beta \frac{\partial \log Z}{\partial \beta}\cdot\frac{\partial \beta}{\partial T}\cdot T && (166)\\
&= k_B \log Z + k_B \beta (-E)\cdot\left(-\frac{1}{k_B T^2}\right)\cdot T && (167)\\
&= k_B \log Z + \frac{E}{T} && (168)\\
&= -k_B \int \mathrm{d}\boldsymbol{\zeta}\, \rho^{\mathrm{eq}}(\boldsymbol{\zeta}) \log \rho^{\mathrm{eq}}(\boldsymbol{\zeta}). && (169)
\end{aligned}$$

在第一行中，我们对 T 求 $T\log Z$ 的导数时应用了乘积法则. 在第二行中，我们引入了逆温度 $\beta = 1/(k_B T)$ 并使用了链式法则，其中 $\frac{\partial\beta}{\partial T} = -1/(k_B T^2)$ 且 $\frac{\partial \log Z}{\partial \beta} = -E$. 将这些代入表达式，我们得到用内能 E 和配分函数 Z 表示的熵. 最后，我们识别出 $\rho^{\mathrm{eq}}(\boldsymbol{\zeta}) = \frac{1}{Z}\exp(-\beta\mathcal{H}(\boldsymbol{\zeta}))$，并恢复了熟悉的熵积分形式.

自由能 最后，我们考虑 Helmholtz 自由能 F，它定义为内能减去温度与熵的乘积：

$$F = E - TS. \tag{170}$$

我们可以再次用配分函数表达：

$$\begin{aligned}
F = E - TS &= -\frac{\partial}{\partial\beta}\log Z - T k_B \frac{\partial}{\partial T}(T\log Z) && (171)\\
&= k_B T^2 \frac{\partial}{\partial\beta}\log Z - k_B T \frac{\partial}{\partial T}(T\log Z) && (172)\\
&= -k_B T \log Z. && (173)
\end{aligned}$$

这里需要注意的是，用配分函数表达的所有三个量仅在 ρ 是 Boltzmann 分布时有效；即在平衡态 ρ^{eq}. 对于其他非平衡分布，只有这些量的原始定义——式 (163)、式 (169) 和式 (170)——成立，而我们确实可以定义 变分自由能（variational free energy）：

$$F[\rho] = U[\rho] - TS[\rho] \geq F. \tag{174}$$

自由能的概念与大多数生成式 AI 方法密切相关，你将在本书其余部分中看到这一点.

平衡态下自由能的最小值 可以证明，自由能 $\mathcal{F}[\rho]$ 在平衡态达到其最小值；即当 $\rho = \rho^{\mathrm{eq}}$ 时. 我们可以使用 Kullback–Leibler 散度的非负性证明如下. 考虑一个温度为 T 的系统，其概率分布 $\rho(\boldsymbol{\zeta})$ 可能不同于平衡 Boltzmann 分布 $\rho^{\mathrm{eq}}(\boldsymbol{\zeta})$. 该分布与平衡分布之间的自由能差为：

$$
\begin{aligned}
F[\rho] - F &= U[\rho] - TS[\rho] - (-k_B T \log Z) && (175)\\
&= \int \mathrm{d}\boldsymbol{\zeta}\, \rho(\boldsymbol{\zeta})\mathcal{H}(\boldsymbol{\zeta}) + k_B T \int \mathrm{d}\boldsymbol{\zeta}\, \rho(\boldsymbol{\zeta}) \log \rho(\boldsymbol{\zeta}) + k_B T \log Z && (176)\\
&= k_B T \int \mathrm{d}\boldsymbol{\zeta}\, \rho(\boldsymbol{\zeta}) \left(\frac{\mathcal{H}(\boldsymbol{\zeta})}{k_B T} + \log \rho(\boldsymbol{\zeta}) + \log Z \right) && (177)\\
&= k_B T \int \mathrm{d}\boldsymbol{\zeta}\, \rho(\boldsymbol{\zeta}) \log \frac{\rho(\boldsymbol{\zeta})}{\rho^{\mathrm{eq}}(\boldsymbol{\zeta})} && (178)\\
&= k_B T\, D_{\mathrm{KL}}[\rho \| \rho^{\mathrm{eq}}] \geq 0. && (179)
\end{aligned}
$$

因此，当 $\rho = \rho^{\mathrm{eq}}$ 时，自由能最小；即在平衡态. 这意味着对于温度恒定的系统，任何自发变化平均而言将始终朝着（变分）自由能减小的方向进行，系统将继续演化，直到达到（变分）自由能最小的状态. 它还为平衡态提供了一个变分原理：平衡态就是使变分自由能最小的状态.

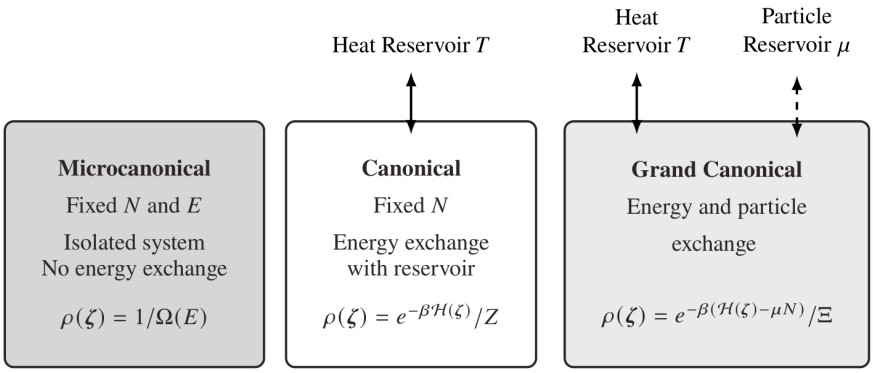


Figure 3.4 Comparison of microcanonical, canonical, and grand canonical ensembles: isolated

图 11: 微正则系综、正则系综和巨正则系综的比较：孤立系统（固定 E, N）、有热交换的系统（固定 T）和有热与粒子交换的系统. 每个系综的概率分布、系统特征和热浴相互作用如图所示.

3.2.5 其他宏观量

在进入下一个主题之前，我们需要简要说明本章对温度和内能的关注. 内能显然不是系统唯一值得研究的宏观观测量. 事实上，如果你翻阅其他关于统计力学的讲义和书籍，你会发现虽然能量常被视为宠儿，但它几乎从不与其他宏观量（如体积和粒子数）隔离开来考虑. 原因主要在于它们在经典热力学最初被处理的方式，之后才通过统计物理给予更形式化的处理.

我们在此选择刻意仅聚焦于一个宏观量来讨论宏观观测量以及它们如何定义微正则系综和正则系综. 这里选择能量纯粹是为了方便，因为它与热力学的思想最一致，但任何其他宏观量或其组合都可以被选择（见图 11）.

例如，我们可以不只是使用能量，而是认为我们的系统不仅能与第 3.2.3 节中的热浴交换能量，还能交换粒子本身. 如果我们遵循与之前相同的推理，我们现在将发现概率分布由下式给出：

$$\rho(\boldsymbol{\zeta}) = \frac{1}{\Xi} \exp(-\beta(\mathcal{H}(\boldsymbol{\zeta}) - \mu N(\boldsymbol{\zeta}))) \,, \tag{180}$$

其中 $\Xi = \int \mathrm{d}\boldsymbol{\zeta} \, \exp(-\beta(\mathcal{H}(\boldsymbol{\zeta}) - \mu N(\boldsymbol{\zeta})))$ 是巨正则系综的配分函数，$N(\boldsymbol{\zeta})$ 计数位形 $\boldsymbol{\zeta}$ 中的粒子数. *化学势*（化学势）μ 对粒子数的作用类似于温度 T 对能量的作用. 事实上，它也是通过对熵求导来定义的，但这次是关于粒子数：

$$\mu = -T \left(\frac{\partial S}{\partial N} \right)_{E,V} , \tag{181}$$

其中下标 E 和 V 表示偏导数在能量和体积恒定下取.

μ 和 T 等量称为 *热力学力*（thermodynamic forces）. 这些是 *强度量*（intensive variables）——它们不随系统规模缩放，与它们所控制的系统与热浴之间交换的对应 *广延量*（extensive quantities）（粒子数 N 和能量 E）不同. 化学势 μ 驱动粒子流入或流出系统，类似于温度 T 驱动能量流.

遵循与正则系综相同的推理，我们可以使用此 ρ 的定义等价地定义内能、（内部）粒子数、熵和自由能. 在这种情况下的自由能称为 *巨势*（巨势），与巨正则系综相对应. 另一个经常讨论的系综是等温–等压系综，它还允许系统与热浴交换体积（保持压强恒定），并使用 Gibbs 自由能.

如你在巨正则系综的情况中所见（但其他系综也是如此），ρ 总是取相同的指数形式：

$$\rho(\boldsymbol{\zeta}) = \frac{1}{Z} \exp(-\beta \Phi(\boldsymbol{\zeta})), \tag{182}$$

$$\Phi(\boldsymbol{\zeta}) = \mathcal{H}(\boldsymbol{\zeta}) - \mu N(\boldsymbol{\zeta}) + \cdots \,, \tag{183}$$

其中广义 Hamiltonian $\Phi(\boldsymbol{\zeta})$ 是表征系统的广延量（能量、粒子数、体积等）的函数. 值得注意的是，我们按惯例总是在这里包含逆温度 β，但我们同样可以使用化学势 μ 或任何其他热力学力. 这突出表明，我们可以抽象掉特定的宏观势，转而考虑具有对应热力学力 β 的广义 Hamiltonian Φ.

经典热力学中的宏观势 宏观观测量在经典热力学中也起着重要作用，但如你所见，我们也将尝试抽象掉这里的细节. 最显著的是，这将体现在功的定义中. 我们不考虑单个宏观观测量及其执行功的不同机制，而是考虑一个更一般的定义，其中功简单地被视为系统广义 Hamiltonian 的任何变化.

3.3 热力学基础

在讨论了统计力学基础之后，我们现在讨论经典热力学的基础（Feynman et al., 1963; Kittel and Kroemer, 1980; Callen, 1985）. 在上一节中，我们看到在最小假设下（我们所做的唯一假设是：对于孤立系统，所有可及微观态等概率），我们可以推导微正则系综和正则系综. 在这样做时，我们然而将这些系统视为处于平衡态——它们所描述的分布和宏观性质都不随时间变化.

然而，有各种方式可以与系统交互以使其宏观观测量发生变化. 例如：

1. 我们可以升高热浴的温度，或将系统与处于不同温度的另一个热浴接触.
2. 我们可以对系统施加电流.
3. 我们可以改变容纳系统的盒子的体积.
4. 我们可以向系统添加额外粒子.

无论我们选择哪种方式与系统交互，最初基于给定温度和 Hamiltonian 定义的描述系统的分布都不再正确. 系统不再相对于原始温度和 Hamiltonian 处于平衡态，但最终将收敛到另一个平衡分布.

热力学是描述平衡态和平衡态附近小扰动的系统的理论. 特别是，热力学稳定性要求自由能相对于小扰动处于最小值，确保系统在小扰动后回到平衡态. 物理学还有其他分支，如动力学理论、输运理论和过渡态理论，它们也研究系统的更大变化或非平衡系统.

下面我们将进一步解释一些与经典热力学相关的核心概念，而在第 10 章中我们将研究 *随机热力学*（stochastic thermodynamics），这一理论也描述了存在热浴时的非平衡系统，且在单个轨迹的层面上.

3.3.1 热力学第一定律

热力学第一定律描述了我们可以改变系统宏观观测量的可能方式. 它指出：

$$\Delta U = Q + W, \tag{184}$$

其中 ΔU 指感兴趣的宏观观测量的变化（在我们的情况下为内能），Q 是添加到系统的热，W 是对系统做的功.

第一定律的无穷小版本写为：

$$\mathrm{d}U = \cancel{\mathrm{d}}Q + \cancel{\mathrm{d}}W. \tag{185}$$

注意，我们在 $\cancel{\mathrm{d}}Q$ 和 $\cancel{\mathrm{d}}W$ 上加上横线，因为它们是 *非恰当微分*（inexact differentials），表示热和功是路径依赖的量，而 $\mathrm{d}U$ 是恰当微分，意味着内能是一个 *态函数*（state function）. 然而，在本书中，我们有时会戴上物理学家的帽子，使用 δ 来进行无穷小变化的计算.

热和功直观上代表什么？我们可以将热视为存储在构成粒子随机涨落中的动能，我们与热浴（或环境）交换这种动能. 因为我们没有关于这些粒子运动的位置和动量的信

息，我们无法直接从中提取能量. 但注意，这再次取决于我们设备的精度：如果有更精确的测量设备可以非常精确地 “耦合” 到每个粒子，原则上我们可以从系统中提取更多能量. 这正是 Maxwell 妖（见第 52 页）所实现的，因为它可以访问人们通常没有的信息. 功是存储在一个或很少几个 “可及” 宏观自由度中的能量部分. 例如，我们可以通过让气体对可动隔板施加压强来提取功，因为我们可以制造一个设备，利用该压强来逆着引力场提升一个质量. 因此我们得出结论，与熵一样，热与功之间的划分是 “主观的”，因为它取决于人们制造设备以提取存储在粒子运动中的能量的能力.

为进一步阐明热与功之间的区别，考虑内能的定义及其变化：

$$U = \int \mathrm{d}\boldsymbol{\zeta}\, \rho(\boldsymbol{\zeta})\mathcal{H}(\boldsymbol{\zeta}), \tag{186}$$

$$\Delta U = \int \mathrm{d}\boldsymbol{\zeta}\, \Delta\rho(\boldsymbol{\zeta})\mathcal{H}(\boldsymbol{\zeta}) + \int \mathrm{d}\boldsymbol{\zeta}\, \rho(\boldsymbol{\zeta})\Delta\mathcal{H}(\boldsymbol{\zeta}). \tag{187}$$

第一项对应于热（保持 $\mathcal{H}$ 固定时 ρ 的变化），而第二项对应于功（保持 ρ 固定时 $\mathcal{H}$ 的变化）. 该方程对于非平衡系统也成立，此时 ρ 可能因为弛豫到平衡态而变化.

现在让我们看一个由 Boltzmann 分布描述的平衡系统，我们对其施加小的温度 T 变化：

$$\rho(\boldsymbol{\zeta}) = \frac{1}{Z}\exp(-\beta\mathcal{H}(\boldsymbol{\zeta})), \tag{188}$$

$$\Delta\rho(\boldsymbol{\zeta}) = -\rho(\boldsymbol{\zeta})\big(\mathcal{H}(\boldsymbol{\zeta})\Delta\beta + \beta\Delta\log Z\big). \tag{189}$$

将此代入我们 ΔU 表达式的第一项，并观察到 $\Delta\log Z = -\Delta\beta\,\mathbb{E}_\rho[\mathcal{H}]$，我们得到：

$$\begin{aligned}
\Delta U &= -\Delta\beta\,\mathbb{E}_\rho[\mathcal{H}^2] - \mathbb{E}_\rho[\mathcal{H}]\Delta\log Z && (190)\\
&= -\Delta\beta\,\mathbb{E}_\rho[\mathcal{H}^2] - \mathbb{E}_\rho[\mathcal{H}]\cdot(-\Delta\beta\,\mathbb{E}_\rho[\mathcal{H}]) && (191)\\
&= -\Delta\beta\big(\mathbb{E}_\rho[\mathcal{H}^2] - \mathbb{E}_\rho[\mathcal{H}]^2\big) = -\Delta\beta\, V_\rho[\mathcal{H}] && (192)\\
&= T^2\Delta\beta\, V_\rho[\mathcal{H}] = T\Delta S. && (193)
\end{aligned}$$

项 $V_\rho[\mathcal{H}] = \mathbb{E}_\rho[\mathcal{H}^2] - \mathbb{E}_\rho[\mathcal{H}]^2$ 是 Hamiltonian 的方差，与 热容（heat capacity）相关，定容系统的热容定义为 $C_V = (\partial U/\partial T)_V$. 热容度量将系统温度升高一单位需要多少能量. 它可以从配分函数推导如下：

$$C_V = \frac{\partial U}{\partial T} = k_B\beta^2 V_\rho[\mathcal{H}] = \beta^2 V_\rho[\mathcal{H}]. \tag{194}$$

或者，你有时会看到第一定律被表述为：

$$\mathrm{d}U = T\,\mathrm{d}S - p\,\mathrm{d}V, \tag{195}$$

其中 p 是压强，V 是体积. 这种形式历史上源于理想气体和机械系统的研究，其中功通过对抗压强的体积变化来执行. 然而，第一定律可以推广到任意强度量与广延量的共轭

对，这对于我们的 ML 背景将更相关. 在这种形式中，温度 T 和压强 p 是强度量（它们不依赖于系统规模），而熵 S 和体积 V 是对应的广延量（它们随系统规模缩放）.

推导通过代入熵和能量的定义进行. 对于平衡分布 $\rho = \frac{1}{Z}e^{-\beta\mathcal{H}}$，我们有：

$$\begin{aligned} \mathrm{d}U &= T\,\mathrm{d}S - p\,\mathrm{d}V && (196)\\ &= -k_B T \int \mathrm{d}\boldsymbol{\zeta}\,[\mathrm{d}\rho(\boldsymbol{\zeta})\log\rho(\boldsymbol{\zeta}) + \mathrm{d}\rho(\boldsymbol{\zeta})] + \int \mathrm{d}\boldsymbol{\zeta}\,\rho(\boldsymbol{\zeta})\frac{\partial\mathcal{H}(\boldsymbol{\zeta},V)}{\partial V}\mathrm{d}V && (197)\\ &= \int \mathrm{d}\boldsymbol{\zeta}\,\mathrm{d}\rho(\boldsymbol{\zeta})\mathcal{H}(\boldsymbol{\zeta},V) + \int \mathrm{d}\boldsymbol{\zeta}\,\rho(\boldsymbol{\zeta})\frac{\partial\mathcal{H}(\boldsymbol{\zeta},V)}{\partial V}\mathrm{d}V, && (198)\end{aligned}$$

其中我们使用了归一化条件 $\int \mathrm{d}\boldsymbol{\zeta}\,\mathrm{d}\rho(\boldsymbol{\zeta}) = 0$，以及压强 p 的定义，即 Hamiltonian 体积导数的负期望值：

$$p \equiv -\int \mathrm{d}\boldsymbol{\zeta}\,\rho(\boldsymbol{\zeta})\frac{\partial\mathcal{H}(\boldsymbol{\zeta},V)}{\partial V}. \tag{199}$$

3.3.2 热力学第二定律

如前所述，无论我们对系统执行哪种类型的交互以改变内能（无论是温度变化还是 Hamiltonian 变化），原始分布都不再正确. 系统不再处于平衡态，最终将转变为另一个平衡分布. 热力学第一定律帮助我们理解这些变化对其他宏观观测量的影响，但它没有告诉我们为什么系统实际上会改变分布. 这就是第二定律所描述的：

$$\Delta S_{\mathrm{tot}} \geq 0. \tag{200}$$

这是自然界的一个基本原理：在任何自然过程中，孤立系统的总熵总是增加或保持不变. 这种熵的增加可以解释为系统无序（随机性）的增加，或按 Jaynes 的精神解释为我们的不确定性或缺失信息的增加.

考虑一个从高度有序状态（低熵）开始的系统. 随着它演化，系统将自然地向更可能的状态演化，这些状态通常更无序（高熵），我们关于精确微观态的不确定性通常增加.

这实际上陈述的是：当我们固定任何宏观观测量时，其他宏观观测量将过渡到使系统熵最大的值. 例如，当我们定义 Boltzmann 分布时，我们使用了热浴的温度 T_{bath}，但没有说明系统本身的温度. 我们现在可以通过固定热浴的温度 T_{bath} 来定义该温度. 将总系统的熵视为两个子系统熵之和：

$$S_{\mathrm{tot}} = S_{\mathrm{sys}} + S_{\mathrm{bath}}. \tag{201}$$

根据第二定律，系统将稳定在使 S_{tot} 最大的状态，此时我们有 $\mathrm{d}S_{\mathrm{tot}}/\mathrm{d}E = 0$. 使用温度的定义 (152)，并由能量守恒 $\mathrm{d}E = -\mathrm{d}E_{\mathrm{bath}}$，我们发现：

$$0 = \frac{\mathrm{d}S_{\mathrm{tot}}}{\mathrm{d}E} = \frac{\mathrm{d}S_{\mathrm{sys}}}{\mathrm{d}E} + \frac{\mathrm{d}S_{\mathrm{bath}}}{\mathrm{d}E} = \frac{\mathrm{d}S_{\mathrm{sys}}}{\mathrm{d}E} - \frac{\mathrm{d}S_{\mathrm{bath}}}{\mathrm{d}E_{\mathrm{bath}}} \tag{202}$$

$$\Rightarrow \frac{1}{T_{\mathrm{sys}}} = \frac{1}{T_{\mathrm{bath}}}. \tag{203}$$

系统的这种状态也称为 热平衡（thermal equilibrium）. 该结果表明，在热平衡时，系统的温度等于热浴的温度，这是第二定律的直接推论. 这意味着你的咖啡杯过一段时间后将与室温达到相同的温度.

一个表面上违反热力学第二定律的例子是 Maxwell 妖（Maxwell's demon）. 这个思想实验涉及一个充满气体分子的房间，中间有隔板. 一个小妖被放在盒子里，控制一个门，只让最快的分子通过而阻挡较慢的分子. 这将导致盒子一侧气体温度升高，另一侧温度随时间降低，与热力学第二定律相矛盾. 对这一悖论的解决，正如 Landauer 和 Bennett 所指出的（Landauer, 1961; Bennett, 1982），是小妖必须获取、存储和擦除信息才能运作，而这一过程总是使熵增加至少等于被观测系统中熵减少的量. 信息与热力学之间的协同至今仍是一个迷人的活跃研究课题（Parrondo et al., 2015）.

我们将在随机热力学一章（第 10 章）中进一步扩展热力学第二定律. 在那里我们将讨论第二定律的两种替代表述：Clausius 表述和 Kelvin 表述.

为什么 $\not{\mathrm{d}}Q = T\,\mathrm{d}S_{\mathrm{bath}}$？ 在本书中，我们将多次使用这个方程来声称系统中产生的热 $\not{\mathrm{d}}Q$（例如通过弛豫到平衡态）将成比例地增加热浴的熵 S_{bath}. 事实上，这将被证明是推导热力学第二定律的关键. 然而，这一陈述并不完全显而易见. 由于我们考虑的是热浴，热浴的温度 T 将被假设为恒定. 既然我们没有改变热浴的 Hamiltonian，且热浴被假设处于平衡态，平衡分布以及熵怎么可能变化呢？回忆一下，Boltzmann 分布完全由 Hamiltonian 和温度决定. 此外，直观上，如果我们以热的形式向热浴添加能量，我们期望温度——毕竟它与热涨落的平均动能相关——会升高，而不是严格保持恒定. 那么让我们看看发生了什么.

假设在我们向热浴转移无穷小量的热 $\not{\mathrm{d}}Q$ 后，温度从 T 变为 $T' = T + \mathrm{d}T$. 如果取 $k_B = 1$，则 $\beta = 1/T$ 是逆温度；它将变为：

$$\beta' = \beta - \beta^2 \mathrm{d}T. \tag{204}$$

我们可以对热浴的 Boltzmann 分布的对数进行 Taylor 展开，到 $\mathrm{d}T$ 的一阶：

$$\log \rho'_{\mathrm{bath}}(\boldsymbol{\zeta}, T') = \log \rho_{\mathrm{bath}}(\boldsymbol{\zeta}, T) + \frac{\partial \log \rho_{\mathrm{bath}}}{\partial T}\mathrm{d}T + \mathcal{O}(\mathrm{d}T^2) \tag{205}$$

$$= \log \rho_{\mathrm{bath}}(\boldsymbol{\zeta}, T) + \beta^2(\mathcal{H}_{\mathrm{bath}}(\boldsymbol{\zeta}) - \mathbb{E}_{\rho_{\mathrm{bath}}}[\mathcal{H}_{\mathrm{bath}}])\mathrm{d}T, \tag{206}$$

其中我们使用了 $\frac{\partial \log \rho_{\mathrm{bath}}}{\partial T} = \beta^2(\mathcal{H}_{\mathrm{bath}} - \mathbb{E}_{\rho_{\mathrm{bath}}}[\mathcal{H}_{\mathrm{bath}}])$，且 $\mathbb{E}_{\rho_{\mathrm{bath}}}[\cdot]$ 表示温度 T 下关于 ρ_{bath} 的期望值.

类似地，我们可以展开热浴的内能：

$$U_{\mathrm{bath}}(T') = U_{\mathrm{bath}}(T) + \frac{\partial U_{\mathrm{bath}}}{\partial T}\mathrm{d}T + \mathcal{O}(\mathrm{d}T^2) = U_{\mathrm{bath}}(T) + \beta^2 V_{\rho_{\mathrm{bath}}}[\mathcal{H}_{\mathrm{bath}}]\mathrm{d}T, \tag{207}$$

其中 $V_{\rho_{\mathrm{bath}}}[\mathcal{H}_{\mathrm{bath}}] = \mathbb{E}_{\rho_{\mathrm{bath}}}[(\mathcal{H}_{\mathrm{bath}} - \mathbb{E}_{\rho_{\mathrm{bath}}}[\mathcal{H}_{\mathrm{bath}}])^2]$ 是热浴中 Hamiltonian 的方差.

热浴的熵可以类似地展开：

$$S_{\mathrm{bath}}(T') = S_{\mathrm{bath}}(T) + \frac{\partial S_{\mathrm{bath}}}{\partial T}\mathrm{d}T + \mathcal{O}(\mathrm{d}T^2) = S_{\mathrm{bath}}(T) + \beta^3 V_{\rho_{\mathrm{bath}}}[\mathcal{H}_{\mathrm{bath}}]\mathrm{d}T. \tag{208}$$

从这个 Taylor 展开的练习中，我们立即读出：

$$\mathrm{d}U_{\mathrm{bath}}(T) = T\,\mathrm{d}S_{\mathrm{bath}}(T). \tag{209}$$

由于热浴内能的变化等于转移的热量 $\cancel{\mathrm{d}}Q = \mathrm{d}U_{\mathrm{bath}}$，我们得到期望的结果：

$$\cancel{\mathrm{d}}Q = T\,\mathrm{d}S_{\mathrm{bath}}(T). \tag{210}$$

从式 (207)，我们还可以推导温度变化的表达式：

$$\mathrm{d}T = \frac{\beta^2 \cancel{\mathrm{d}}Q}{V_{\rho_{\mathrm{bath}}}[\mathcal{H}_{\mathrm{bath}}]}. \tag{211}$$

该方程告诉我们，温度的变化正比于 T^2 乘以转移热量除以热浴 Hamiltonian 的方差. 由于热浴由非常大量的粒子 N 组成，热浴的 Hamiltonian $\mathcal{H}_{\mathrm{bath}}$ 实际上是 N 个随机涨落项的和. 当然，原子之间也有许多相互作用项，但这不会影响下面的论证. N 个独立随机变量之和的方差按 $\mathcal{O}(N)$ 增长. 例如，如果 X 是 N 次独立抛硬币的和，每次正面概率为 p，则 $V[X] = Np(1-p)$. 因此，当 $N \to \infty$ 时，方差 $V_{\rho_{\mathrm{bath}}}[\mathcal{H}_{\mathrm{bath}}]$ 无界增长，温度变化 $\mathrm{d}T$ 趋近于零：

$$\mathrm{d}T \approx \frac{\beta^2 \cancel{\mathrm{d}}Q}{\mathcal{O}(N)} \to 0. \tag{212}$$

这解释了为什么我们可以假设热浴的温度实际上保持恒定，即使有能量转移到其中.

这一表面悖论的解决是：转移的热产生了无穷小的温度升高，这是增加热浴可及微观态数所需的，而这些微观态正是热浴熵升高的原因. 然而，即使我们让热力学极限 $N \to \infty$ 中的 $\mathrm{d}T \to 0$，热与热浴熵之间的导出关系仍然成立.

Part

II

离散时间随机动力学 Discrete-Time Stochastic Dynamics

Chapter 4

隐变量模型与图模型

4.1 引言

在本书中你会发现，我们将通过将生成式 AI 模型的核心原理与统计物理和热力学领域中的概念联系起来，来讨论这些模型. 本章探讨的这种联系的一个关键方面，是两个领域中 可观测变量（observable variables）与 隐变量（latent variables）的使用之间的相似性，以及抽象掉信息引入不确定性的方式.

在物理中，可观测变量描述我们可以用传感器测量的宏观量（如温度和压强）. 相反，未观测的隐变量描述系统的微观态，我们无法直接测量但可以推断它们. 也就是说，当我们对微观态与宏观态之间的映射有完整知识时，我们可以推断它们. 推断于是采取后验概率的形式，描述在给定我们可获得的观测的情况下系统处于某状态的可能性.

在生成式 AI 中，我们类似地有可以用传感器测量的观测变量（如图像、音频、文本等），以及我们没有直接知识的隐变量（世界中我们未追踪但产生了观测图像、音频、文本等的众多自由度）. 学习这些观测变量与隐变量之间的映射是生成式机器学习的核心. 描述这一点的一般语言是 隐变量模型（latent variable model）及其以 图模型（graphical model）形式的结构化扩展.

本章介绍图模型领域：隐变量与观测变量之间的结构化概率模型. 例子包括有向模型（如隐 Markov 模型）和无向模型（如 Markov 随机场）. 在本章中，我们研究可以有效训练这些模型的学习算法，称为 变分期望最大化（variational expectation maximization）（VEM）算法. 其目标称为 证据下界（evidence lower bound）（ELBO），它恰好与物理中的自由能有非常强的联系. 我们在本章结尾将此框架应用于 Bayes 学习，其中模型参数也被视为随机变量.

4.2 隐变量模型

隐变量模型（latent variable model）（LVM）定义如下：

$$p_X(x) = \sum_z p_{X,Z}(x,z) = \sum_z p_{X|Z}(x|z)\, p_Z(z), \tag{213}$$

其中 $p_X(x)$ 是观测变量 x 的边缘（似然）分布，$p_{X,Z}$ 是观测变量与隐变量的联合分布，$p_{X|Z}(x|z)$ 是给定隐变量时观测变量的条件分布（称为 似然（likelihood））, $p_Z(z)$ 是隐变量的先验分布. 虽然定义简单，但由于边缘分布 p_X 是通过对 z 边缘化（对 z 的混合）给出的，该模型类非常有表达力!

为简单起见，本章中我们假设隐变量是离散的，但同样的推理可以应用于连续变量

的情形. 在这种情况下，我们可以将式 (213) 改写为：

$$p(x) = \int p(x|z)\, p(z)\, \mathrm{d}z, \tag{214}$$

其中我们现在对隐变量 z 的所有可能值积分. 注意，为简洁起见，我们在此省略了下标 X 和 Z，在本章及本书的其余部分中也将这样做.

使用 Bayes 法则，我们还可以推导给定观测变量时隐变量的分布：

$$p(z|x) = \frac{p(x|z)\, p(z)}{p(x)}, \tag{215}$$

这称为隐变量的后验分布. 我们可以将此模型解释为因子分析，其中变化的因子由 z 给出，后验将告诉我们哪些因子解释了观测 x 中的大部分信号.

回到统计物理，我们可以看到隐变量的后验分布通常是我们感兴趣的分布. 例如，在正则系综中，逆温度 β 下微观态上的后验分布就是 Boltzmann 分布.

例 4.2.1 (Gaussian 例子)**：** 作为例子，考虑一个模型，其中先验 p_Z 由 Gaussian 密度给出，条件分布也是 Gaussian：

$$p(z) = \mathcal{N}(0, I), \qquad p(x|z) = \mathcal{N}(Wz, \Sigma). \tag{216}$$

你现在可以计算联合分布：

$$p(x, z) = \mathcal{N}(0, C), \tag{217}$$

$$C = \begin{pmatrix} \Sigma^{-1} & -\Sigma^{-1}W \\ -W^\top\Sigma^{-1} & I + W^\top\Sigma^{-1}W \end{pmatrix}. \tag{218}$$

从该联合分布，我们可以通过 “配平方” 推导后验分布：

$$p(z|x) = \mathcal{N}(\mu, \Lambda), \tag{219}$$

$$\Lambda = I + W^\top\Sigma^{-1}W, \tag{220}$$

$$\mu = \Lambda^{-1}W^\top\Sigma^{-1}x. \tag{221}$$

作为练习，我们鼓励你从式 (216) 和式 (218) 推导式 (220) 和式 (221). ◇

4.3 图模型

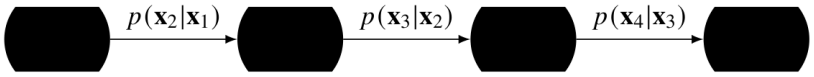
我们现在可以开始对这些模型施加结构. 处理结构化（隐变量）模型的领域称为 图模型（graphical model）(Koller and Friedman, 2009). 在图模型（GM）中，节点表示随机变量，边表示这些变量之间的概率依赖关系. 图的结构编码了模型所做的条件独立性假设.

作为我们在本书中会频繁遇到的例子，考虑由结构化分布给出的 Markov 模型（Markov model）（MM）：

$$p(x_0, x_1, \ldots, x_{t_f}) = p_0(x_0) \prod_{t=1}^{t_f} p_t(x_t|x_{t-1}), \tag{222}$$

其中每个条件分布 $p_t(x_t|x_{t-1})$ 在每个时间步可以不同. 图 12 展示了一个简单的 Markov 链，它是 Markov 模型的一种.

每个图模型对随机变量之间的（条件）独立性做出某些假设. 在上述 Markov 模型中，假设是对所有 t 有 $x_t \perp x_0, \ldots, x_{t-2} \,|\, x_{t-1}$. 换言之：给定 x_{t-1} 的值，变量 x_t 在统计上独立于 x_t 过去的所有变量.



1.1 Graphical model of a Markov chain representing the probability distributio
$_2, \mathbf{x}_3, \mathbf{x}_4) = p(\mathbf{x}_1) \prod_{t=2}^{4} p(\mathbf{x}_t|\mathbf{x}_{t-1})$. Rounded nodes represent observed variable
indicate the sequential dependency between variables in a simple linear progres
ucture has the Markov property that each variable depends only on the immedi
ng variable.

can now start to impose structure on these models. The field that dea
red (latent variable) models is called graphical models (Koller and Fri
In a graphical model (GM), nodes represent random variables, and
nt the probabilistic dependencies between these variables. The structur
ncodes the conditional independence assumptions made by the model.
give an example that we will encounter frequently in this book, let us c
v models (MM) given by the structured distribution

$$p(\mathbf{x}_0, \mathbf{x}_1, \ldots, \mathbf{x}_{t_f}) = p_0(\mathbf{x}_0) \prod_{t=1}^{t_f} p_t(\mathbf{x}_t|\mathbf{x}_{t-1}),$$

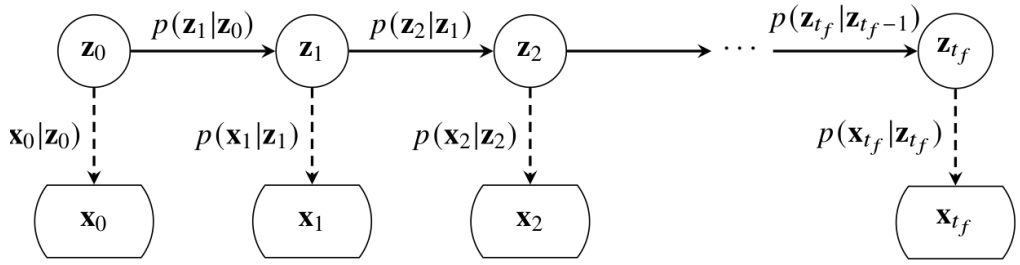
each conditional distribution $p_t(\mathbf{x}_t|\mathbf{x}_{t-1})$ can be different for every tin
4.1 illustrates a simple Markov chain, which is a type of MM.

图 12: Markov 链的图模型，表示概率分布 $p(x_1, x_2, x_3, x_4) = p(x_1) \prod_{t=2}^{4} p(x_t|x_{t-1})$. 圆形节点表示观测变量. 箭头表示简单线性推进中变量之间的序列依赖关系. 该结构具有 Markov 性质，即每个变量仅依赖于紧邻的前一个变量.

隐 Markov 模型 带有隐变量的 Markov 模型的一个例子是 隐 Markov 模型（hidden Markov model）（Rabiner, 1989）：

$$p(x_0, \ldots, x_{t_f}, z_0, \ldots, z_{t_f}) = p_0(z_0) \prod_{t=1}^{t_f} p_t(z_t|z_{t-1}) \prod_{t=0}^{t_f} p(x_t|z_t), \tag{223}$$

其中 z_t 是隐变量，x_t 是时间步 t 的观测变量. 你可以为每个变量画一个节点，为每个条件分布画一个箭头，这可视化了模型的结构（如图 13 所示），从中你可以读出所有的条件独立性关系.



1.2 Graphical model representation of a homogeneous hidden Markov model (HMM

图 13: 齐次隐 Markov 模型（HMM）的图模型表示. 模型结构由概率分布 $p(x_0,\ldots,x_{t_f},z_0,\ldots,z_{t_f}) = p_0(z_0)\prod_{t=1}^{t_f} p(z_t|z_{t-1})\prod_{t=0}^{t_f} p(x_t|z_t)$ 定义. 实线箭头连接隐状态（实心圆）并编码转移概率，而虚线箭头通过发射分布将每个隐状态链接到其对应的观测变量.

Markov 随机场 最后一个对我们非常有用的例子是 Markov 随机场（Markov random field）(Kindermann and Snell, 1980). Markov 随机场（MRF）是根据变量子集（包括观测和未观测变量）上的势函数定义的. 这些势通常在某个空间中是局域定义的；即它们指定哪些变量在该空间中是邻居. 如果我们引入 聚类（cluster）$\mathcal{G}_\alpha$ 作为由 α 索引的聚类，$\mathbf{x}_\alpha = \{x_{\alpha(1)}, x_{\alpha(2)}, \ldots, x_{\alpha(n_\alpha)}\}$ 作为参与该聚类的变量子集，我们可以定义以下概率分布：

$$p(x_1, x_2, \ldots, x_N) = \frac{1}{Z}\exp\left(-\sum_\alpha \Psi_\alpha(\mathbf{x}_\alpha)\right), \tag{224}$$

其中 $\Psi_\alpha(\mathbf{x}_\alpha)$ 是定义在聚类上的势函数，Z 是归一化常数. 等价地，我们也可以使用定义 $p(x_1, x_2, \ldots, x_N) = \prod_\alpha \Phi_\alpha(\mathbf{x}_\alpha)/Z$. 我们称其为无向图模型，因为我们没有条件概率分布，而是一种带结构化势的 Boltzmann 分布. 我们注意到，当我们使用隐变量 z 和观测变量 x 的混合时，完全相同的定义也适用. MRF 的一个例子如图 14 所示.

模型所隐含的条件独立性关系如下. 首先，在变量 x_i 与出现在某个势的同一自变量中的所有变量之间画一条（无向）边. 将此集合称为变量 i 的 Markov 毯（Markov blanket）（MB）$\mathcal{M}(i)$. 我们现在有条件独立性：$x_i \perp x_{-\{i\cup\mathcal{M}(i)\}} \,|\, x_{\mathcal{M}(i)}$. 换言之：如果我们以 MB 中的变量为条件，$x_i$ 独立于 MRF 中 MB 之外的所有其他变量；即 MB 将 x_i 与其余变量的统计依赖关系屏蔽开. 一个节点的 MB 也是使 x_i 独立于所有其他节点所需的最小节点集合.

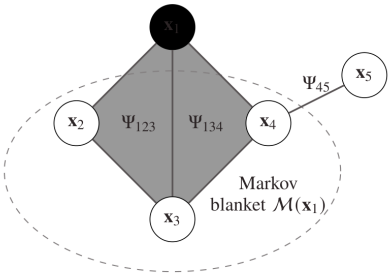


Figure 4.3 Markov random field (MRF) model representing the factorization of the probability

图 14: Markov 随机场（MRF）模型，表示概率分布分解为最大团上势的乘积 $p(x) \propto \exp(-\Psi_{123}(x_1, x_2, x_3) - \Psi_{134}(x_1, x_3, x_4) - \Psi_{45}(x_4, x_5))$. x_1 的 Markov 毯为 $\mathcal{M}(x_1) = \{x_2, x_3, x_4\}$. Markov 毯将 x_1 与 x_5 的影响屏蔽开，产生条件独立性关系 $x_1 \perp x_5 \,|\, \mathcal{M}(x_1)$.

4.4 变分期望最大化算法

一旦我们定义了图模型，就需要从数据中学习它. 一个数据集由 N 个数据案例组成，其中每个数据案例为图模型中的所有观测变量赋值. 我们想要最大化的边缘对数似然为：

$$\mathcal{L}(\theta, p) = \sum_{n=1}^{N} \log p(x_n) = \sum_{n=1}^{N} \log \sum_{z_n} p(x_n, z_n). \tag{225}$$

我们可以利用 KL 散度的非负性推导对数似然的下界，并为每个数据案例 n 引入变分分布 $q_n(z_n)$：

$$\begin{aligned}
\mathcal{L}(\theta, p) &= \sum_{n=1}^{N} \sum_{z_n} q_n(z_n) \log \frac{p(x_n)\, q_n(z_n)}{q_n(z_n)} && (226)\\
&= \sum_{n=1}^{N} \sum_{z_n} q_n(z_n) \log \frac{p(x_n|z_n)\, p(z_n)\, q_n(z_n)}{p(z_n|x_n)\, q_n(z_n)} && (227)\\
&= \sum_{n=1}^{N} \sum_{z_n} q_n(z_n) \big(\log p(x_n, z_n) - \log q_n(z_n)\big) + \sum_{n=1}^{N} D_{\mathrm{KL}}[q_n(z_n) \| p(z_n|x_n)] && (228)\\
&\geq -\sum_{n=1}^{N} F[q_n, p] \equiv -F[q_1, \ldots, q_N, p]. && (229)
\end{aligned}$$

这里，从第一行到第二行的过渡成立，因为 $p(x_n) = \frac{p(x_n|z_n)p(z_n)}{p(z_n|x_n)}$ 对 z_n 的每个值都成立. 我们为每个数据案例引入了自由能（也等价于负 ELBO）：

$$F[q_n, p] = \sum_{z_n} q_n(z_n) \big(\log q_n(z_n) - \log p(x_n, z_n)\big). \tag{230}$$

如果我们定义熵 $S[q_n] = -\sum_{z_n} q_n(z_n) \log q_n(z_n)$ 和数据案例特定的 Hamiltonian $\mathcal{H}_n(z_n, x_n) \equiv -\log p(x_n, z_n)$，我们可以写 $F[q_n, p] = \mathbb{E}_{q_n}[\mathcal{H}_n] - S[q_n]$. 这恰好与 $\beta = 1$（或

等价地，在 $k_BT = 1$ 的单位制中）的非平衡 Helmholtz 自由能具有完全相同的 $U - TS$ 结构，这解释了 “（变分）自由能” 这一术语. 热力学联系将在下一章进一步展开.

我们得出结论，作为要最大化的自然目标的对数似然，以负 F 为下界，这可以解释为 N 个数据案例的系统总自由能的负值.

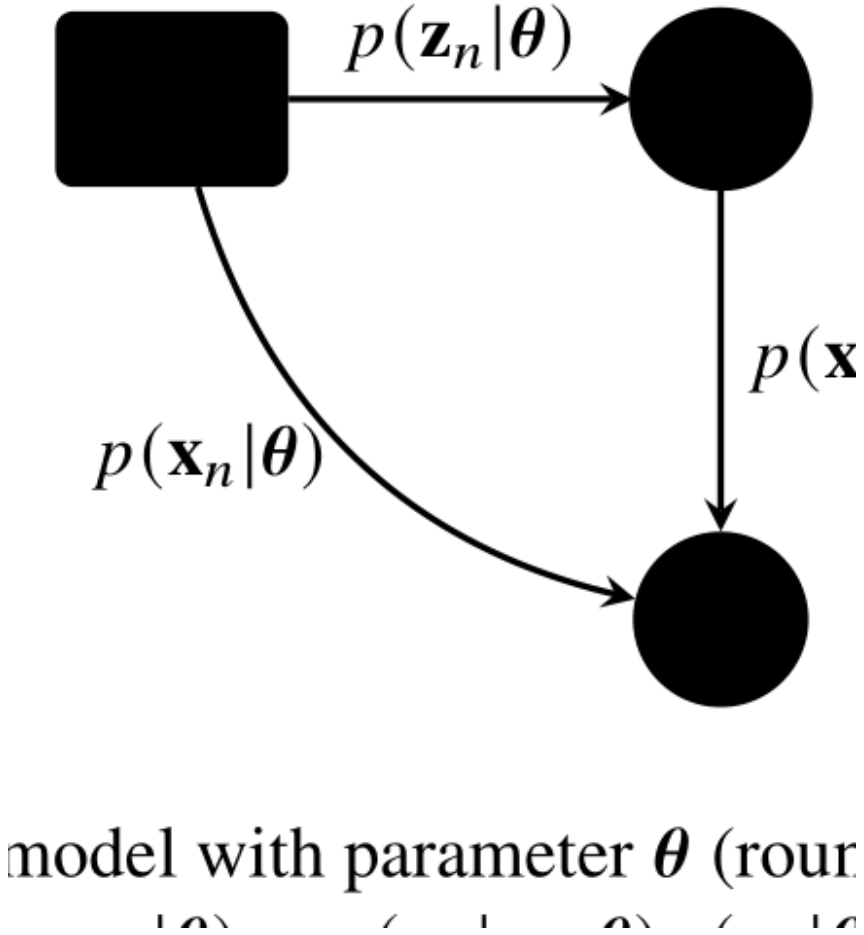


图 15: 带参数 θ（圆角矩形）的隐变量模型，表示概率分布 $p(x_n, z_n|\theta) = p(x_n|z_n, \theta)p(z_n|\theta)$. 从 θ 到 x_n 的箭头表示观测变量 x_n（圆圈）依赖于参数 θ，而从隐变量 z_n（双圈）到 x_n 的箭头表示条件概率 $p(x_n|z_n, \theta)$.

4.4.1 VE 步

为最大化 $\mathcal{L}$，我们现在迭代两个步骤. 首先，我们在分布集合 $\{q_n\}$ 上最小化 F. 你可以选择进行部分最小化：例如，仅在 $\{q_n\}$ 的子集上最小化，或仅最小化几步. 我们称此为推断算法的 VE 步（VE-step），并为将来参考注明这类似于将一个非平衡的物理系统弛豫到平衡态.

假设我们已经用数据案例特定的参数 ϕ_n 参数化了推断分布 $q_n(z_n|\phi_n)$. 然后我们可

以对 F 关于 ϕ_n 求导得到：

$$\nabla_{\phi_n} F = \sum_{z_n} \nabla_{\phi_n} q_n(z_n|\phi_n) \log q_n(z_n|\phi_n) - \log p(x_n, z_n) \tag{231}$$

$$+ \sum_{z_n} q_n(z_n|\phi_n) \nabla_{\phi_n} \log q_n(z_n|\phi_n) \tag{232}$$

$$= \sum_{z_n} q_n(z_n|\phi_n) \nabla_{\phi_n} \log q_n(z_n|\phi_n) \big(\log q_n(z_n|\phi_n) - \log p(x_n, z_n) + 1\big) \tag{233}$$

$$= \sum_{z_n} q_n(z_n|\phi_n) \nabla_{\phi_n} \log q_n(z_n|\phi_n) \big(\log q_n(z_n|\phi_n) - \log p(x_n, z_n)\big) \tag{234}$$

$$\approx \frac{1}{M} \sum_{m=1}^{M} \nabla_{\phi_n} \log q_n(\tilde{z}_{nm}|\phi_n) \big(\log q_n(\tilde{z}_{nm}|\phi_n) - \log p(x_n, \tilde{z}_{nm})\big), \tag{235}$$

其中在最后一行我们用从 q_n 中抽取的 Monte Carlo 样本代替求和，中间我们使用了以下技巧：

$$\nabla_{\phi_n} q_n(z_n|\phi_n) = q_n(z_n|\phi_n) \nabla_{\phi_n} \log q_n(z_n|\phi_n), \tag{236}$$

$$\sum_{z_n} q_n(z_n) \nabla_{\phi_n} \log q_n(z_n) = \sum_{z_n} \nabla_{\phi_n} q_n(z_n) = \nabla_{\phi_n} \sum_{z_n} q_n(z_n) = \nabla_{\phi_n} 1 = 0. \tag{237}$$

这称为 REINFORCE 估计量（REINFORCE estimator）（Williams, 1992）. 不幸的是，如果你通过从 q_n 采样来使用 Monte Carlo 估计计算梯度，它的方差非常高.

重参数化技巧 对于某些分布，有一个非常好的技巧可以降低该估计量的方差，称为 *重参数化技巧*（reparameterization trick）（Kingma and Welling, 2014）. 其工作原理如下（关于它如何变换计算图以实现高效梯度计算的说明见图 16）. 假设我们想计算关于 θ 的以下形式积分的导数：

$$\nabla_\theta \int \mathrm{d}z \, q(z|\theta) \, f(z), \tag{238}$$

并想象执行变量替换 $z = g(\epsilon, \theta)$ 使得：

$$\int \mathrm{d}z \, q(z|\theta) = \int \mathrm{d}\epsilon \, p(\epsilon), \tag{239}$$

$$\int \mathrm{d}z \, q(z|\theta) \, f(z) = \int \mathrm{d}\epsilon \, p(\epsilon) \, f(g(\epsilon, \theta)), \tag{240}$$

$$\nabla_\theta \int \mathrm{d}z \, q(z|\theta) \, f(z) = \int \mathrm{d}\epsilon \, p(\epsilon) \, \frac{\partial f}{\partial g}(g(\epsilon, \theta)) \nabla_\theta g(\epsilon, \theta), \tag{241}$$

其中 $p(\epsilon)$ 是易于采样的标准分布. 关键思想是将随机性的来源从分布 $q(z|\theta)$ 移动到具有固定分布 $p(\epsilon)$ 的辅助变量 ϵ.

例如，考虑 Gaussian 分布：

$$\int \mathrm{d}z\, \mathcal{N}(z|\mu,\sigma)\, f(z) = \int \mathrm{d}\epsilon\, \mathcal{N}(\epsilon|0,1)\, f(\mu+\sigma\cdot\epsilon), \tag{242}$$

$$z = g(\epsilon,\mu,\sigma) = \mu+\sigma\cdot\epsilon. \tag{243}$$

在一维中，这总是可以实现的，但在更高维中，可能难以识别该变换. 我们现在可以改写：

$$\nabla_\theta \int \mathrm{d}z\, q(z|\theta)\, f(z) = \int \mathrm{d}\epsilon\, p(\epsilon|0,1)\, \frac{\partial f}{\partial g}(g(\epsilon,\theta))\nabla_\theta g(\epsilon,\theta) \tag{244}$$

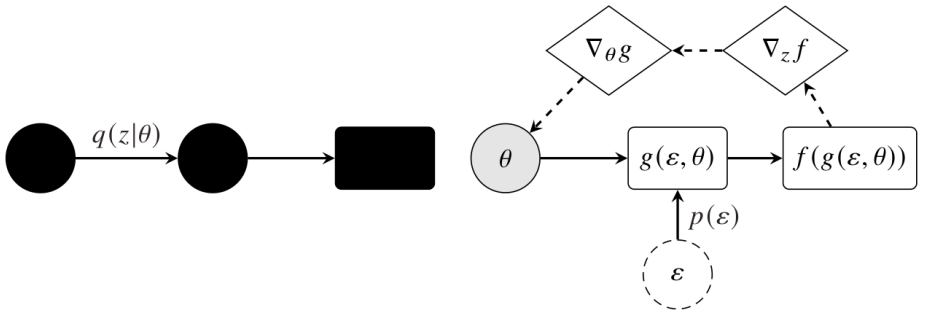
$$\approx \frac{1}{M}\sum_{m=1}^{M} \frac{\partial f}{\partial g}(g(\epsilon_m,\theta))\nabla_\theta g(\epsilon_m,\theta), \qquad \epsilon_m \sim \mathcal{N}(0,1). \tag{245}$$

该估计量具有好得多的方差性质！

$$\nabla_\theta \int \mathrm{d}z\, q(z|\theta) f(z) = \int \mathrm{d}\varepsilon\, G(\varepsilon|0,1) \frac{\partial f}{\partial g}(g(\varepsilon,\theta))\nabla_\theta g(\varepsilon,\theta)$$

$$\approx \frac{1}{S}\sum_{s=1}^{S} \frac{\partial f}{\partial g}(g(\varepsilon_s,\theta))\nabla_\theta g(\varepsilon_s,\theta), \quad \varepsilon_s \sim G(0,1). \qquad (4.2\epsilon$$

This estimator has much better variance properties!



(a) Original form: $\mathbb{E}_{z\sim q(z|\theta)}[f(z)]$ (b) Reparameterized form: $\mathbb{E}_{\varepsilon\sim p(\varepsilon)}[f(g(\varepsilon,\theta))]$

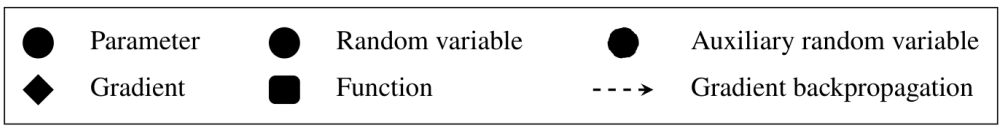


Figure 4.5 Illustration of the reparameterization trick. (a) Original form: expectation over

图 16: 重参数化技巧说明. (a) 原始形式：关于 $q(z|\theta)$ 的期望 $\mathbb{E}_{z\sim q(z|\theta)}[f(z)]$. (b) 重参数化形式：随机性移动到辅助变量 $\epsilon\sim p(\epsilon)$. 梯度从 $f(g(\epsilon,\theta))$ 反向传播到 θ，实现直接优化. 梯度计算为 $\nabla_\theta f(g(\epsilon,\theta)) = \frac{\partial f}{\partial g}\cdot\nabla_\theta g(\epsilon,\theta)$.

4.4.2 VM 步

在（部分）VE 步结束后，我们现在切换到在 θ 上最小化 F. 这里，θ 是我们由参数 θ 参数化的图模型. 在 VM 步中我们保持 q_n 固定并更新这些参数. 我们可以对 F 关

于 θ 求梯度并发现：

$$-\nabla_\theta F = \sum_{n=1}^{N} \sum_{z_n} q_n(z_n) \nabla_\theta \log p(x_n, z_n|\theta) \tag{246}$$

$$\approx \frac{1}{N} \sum_{n=1}^{N} \nabla_\theta \log p(x_n, \tilde{z}_{nm}|\theta), \qquad \tilde{z}_{nm} \sim q_n \tag{247}$$

$$\Rightarrow \theta^{k+1} = \theta^k - \eta_k \nabla_{\theta^k} F[q_1, q_2, \ldots, q_N, \theta^k]. \tag{248}$$

我们可以以任意顺序迭代 VE 步和 VM 步直到收敛，如图 17 所示. 值得注意的是，我们可以将 $\mathcal{H}_n(z_n, x_n) = -\log p(z_n, x_n|\theta)$ 视为系统 n 的 Hamiltonian. 事实上，通过这一识别，我们可以写：

$$F = \sum_n \mathbb{E}_{q_n}[\mathcal{H}_n] - S[q_n] = \mathbb{E}_q[\mathcal{H}] - S[q], \tag{249}$$

$$q = \bigotimes_n q_n, \qquad \mathcal{H} = \sum_n \mathcal{H}_n, \qquad S[q] = \sum_n S[q_n]. \tag{250}$$

正如我们将在接下来的章节中看到的，M 步与对物理系统做 “功” 相关.

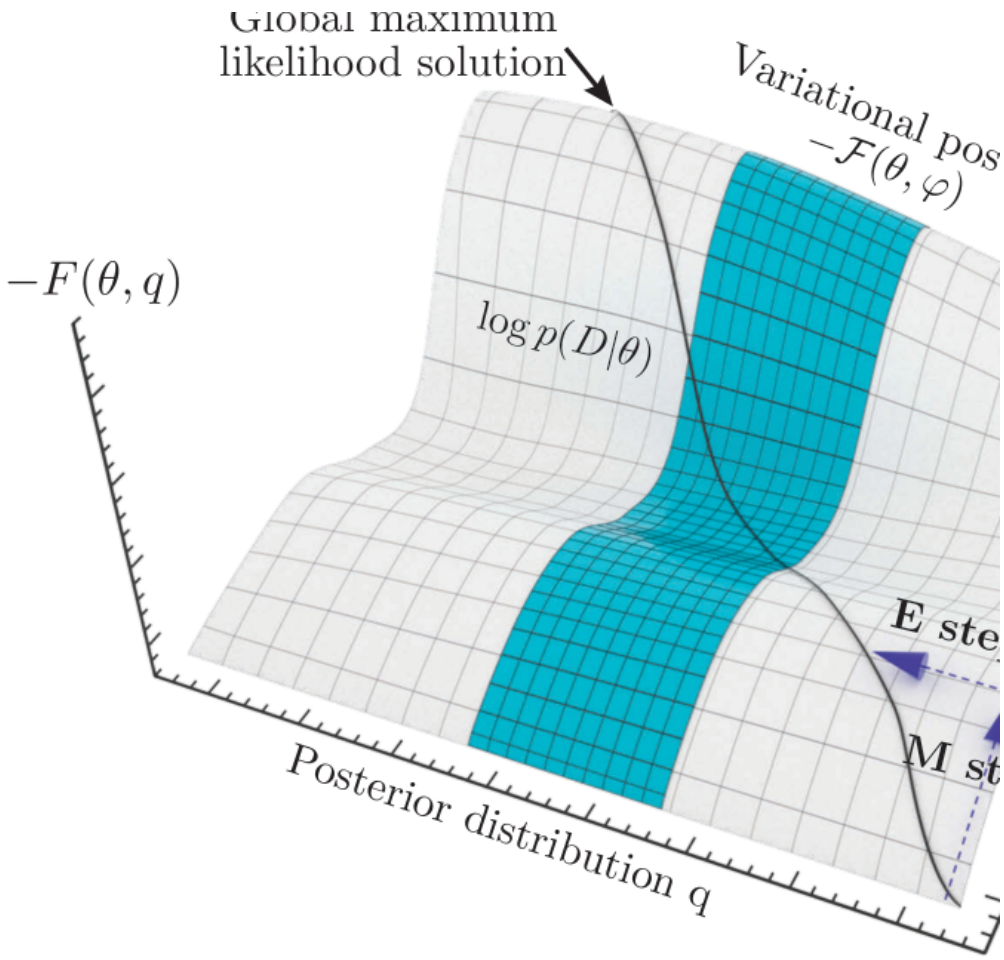
一个重要的考虑是，我们为每个数据点有单独的变分分布 q_n. 这意味着我们可以为每个 q_n 优化单独的参数 ϕ_n. 这是一组非常灵活的变分分布. 然而，它的缺点是对于新的（测试）数据案例，人们将不得不引入新的分布 q_n 和参数 ϕ_n 并执行优化. 这很慢! 在 *变分自编码器*（variational autoencoder）（Kingma and Welling, 2014; Rezende et al., 2014）中，正如我们将在第 7 章中看到的，我们引入一个 “摊销的” 变分分布，它是一个由神经网络给出的从 x 到 z 的（随机）函数 $q(z|x)$. 对于任何新数据案例，我们可以简单地执行该函数 $q(z_n|x_n)$ 来找到（变分）后验. 这快得多（如果执行神经网络的时间比对 q_n 的迭代推断更短）.

如果真实后验 $p(z_n|x_n)$ 可以被 $q_n(z_n)$ 完美逼近，那么最优分布 q_n^* 由该后验给出：$q_n^*(z_n) = p(z_n|x_n)$. 作为练习，我们鼓励你证明：当且仅当对所有 n 有 $q_n^*(z_n) = p(z_n|x_n)$ 时，式 (229) 中的界饱和（等式成立）.

平均场近似 为保持可处理性，有时引入一族对 q_n 来说不够灵活、无法完全逼近后验的分布是有用的. 在这种情况下，总会存在间隙：$\mathcal{L} \geq -F$. 然而，在收敛时，我们确实找到在此约束下的最佳可能逼近. 例如，我们可以使用 Gaussian 分布族并调整其均值和方差来逼近真实后验. 或者，我们可以使用解耦的分布集合：

$$q_n(z_n) = \prod_i q_{n,i}(z_{n,i}). \tag{251}$$

我们称此为 *平均场近似*（mean-field approximation）（Parisi, 1988）.



ization of the expectation-maximization algori

图 17: 期望最大化算法可视化 [灵感来自并重新创建自 Dayan et al. (1995) 的图 2]. 曲面对象表示负自由能 $-F(\theta, q)$ 作为模型参数 θ 和后验分布 p 的函数. 对数似然函数 $\log p(D|\theta)$ 显示为曲面上的一条曲线. 蓝色阴影区域表示变分后验 $-F(\theta, \phi)$，它与式 (229) 中的 ELBO 直接相关. 全局最大似然解在峰值处标出. EM 算法通过交替更新后验分布（E 步）和优化模型参数（M 步）来迭代最大化似然. 算法的 VE 步和 VM 步分别图示为沿 ϕ 轴和 θ 轴的移动.

4.5 变分贝叶斯

到目前为止，我们将隐变量视为与参数不同：隐变量是随机变量，它们标记有数据案例 z_n. 这意味着对于每个数据案例，它们可以取不同的值. 参数被视为确定性数字. 然而，没有什么能阻止我们将参数也视为随机变量！我们只需要在它们上面指定概率分

布. 我们注意到参数不是为单个数据案例指定的，而是在模型层面. 因此参数不按数据案例索引.

当我们将参数视为随机变量时，我们进入了 Bayes 统计（Bayesian statistics）的领域（Jaynes, 2003; Gelman et al., 2013）. 在 Bayes 统计中，我们指定一个先验分布 $p(\theta)$，反映我们认为合理值的信念. 这是主观的!（这种主观性是为什么有些人更喜欢频率派方法，他们认为科学应该是客观的.）Bayes 派学者不是在参数 θ 上优化似然，而是对给定他们迄今所见的所有证据的参数后验感兴趣.

令 D_N 为 N 个数据案例的数据集. 则:

$$p(\theta|D_N) = \frac{p(D_N|\theta)\,p(\theta)}{p(D_N)} \propto p(\theta)\prod_{n=1}^{N} p(x_n|\theta), \tag{252}$$

$$p(D_N) = \int \mathrm{d}\theta\, p(D_N|\theta)\,p(\theta). \tag{253}$$

边缘似然 $p(D_N)$ 是归一化常数（参见配分函数!），在模型选择中起着重要作用. 例如，如果我们有多个模型 M 可供选择，我们有:

$$p(M|D_N) = \frac{p(D_N|M)\,p(M)}{p(D_N)} \quad \text{(模型选择)}, \tag{254}$$

$$p(D_N) = \sum_{M} p(D_N|M)\,p(M) \quad \text{(证据)}, \tag{255}$$

$$p(D_N|M) = \int \mathrm{d}\theta\, p(D_N|\theta, M)\,p(\theta|M) \quad \text{(模型证据)}. \tag{256}$$

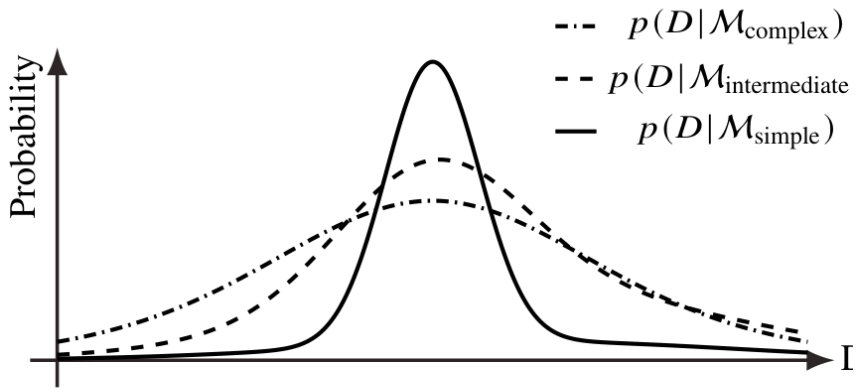
后验概率最高的模型是我们偏爱的模型（见图 18）.

$$)_N) = \frac{p(D_N|\mathcal{M})p(\mathcal{M})}{p(D_N)} \qquad \text{(model s}$$

$$)_N) = \sum_{\mathcal{M}} p(D_N|\mathcal{M})p(\mathcal{M}) \qquad \text{(evidenc}$$

$$\mathcal{M}) = \int \mathrm{d}\boldsymbol{\theta}\; p(D_N|\boldsymbol{\theta},\mathcal{M})p(\boldsymbol{\theta}|\mathcal{M}) \qquad \text{(model e}$$

ith the highest posterior probability is the one we fa



odel complexity and marginal likelihood in Bayesian mod

图 18: Bayes 模型选择中的模型复杂度与边缘似然. 简单模型具有更高的峰值概率但覆盖范围更窄，而复杂模型具有更低的峰值概率但覆盖范围更宽. 符号 $\mathcal{M}$ 表示模型类.

学习现在被替换为对 θ 以及可能还有 $\{z_n\}$ 的推断（见图 15）. 为执行此推断，我们可以使用 Markov 链 Monte Carlo 算法从后验中采样，这是我们将在第 11 章中探讨的主题. 现在，我们想展示这再次可以表述为在更大空间上的自由能最小化问题（如图 19 所示）.

引入变分推断分布 $q(z_1, \ldots, z_N, \theta)$. 为简单起见，我们将其写为 $q(Z, \theta)$. 我们现在可以推导界，为简洁起见写 $X \equiv D_N$：

$$-F = \log p(D_N) = \log \int \mathrm{d}\theta\, \mathrm{d}Z\, p(\theta, Z, X) \tag{257}$$

$$= \log \int \mathrm{d}\theta\, \mathrm{d}Z\, q(\theta, Z)\, \frac{p(\theta, Z, X)}{q(\theta, Z)} \tag{258}$$

$$\geq \int \mathrm{d}\theta\, \mathrm{d}Z\, q(\theta, Z) \log \frac{p(\theta, Z, X)}{q(\theta, Z)} = -F[q], \tag{259}$$

其中我们在第三行应用了 Jensen 不等式（Jensen's inequality），并使用了 $p(X, Z, \theta) = p(X|Z, \theta)p(Z|\theta)p(\theta)$.

在变分贝叶斯（variational Bayesian）（VB）推断中（Hinton and van Camp, 1993），我们做了一个关键的简化假设：$q(Z, \theta) = q(\theta) \prod_n q_n(z_n)$. 虽然假设给定参数时隐变量独

立是合理的——即 $q(Z,\theta)=\prod_n q_n(z_n|\theta)q(\theta)$——但 $q(Z,\theta)=q(\theta)\prod_n q_n(z_n)$ 做出了更激进的假设，即 Z 和 θ 完全独立. 这一般不成立，因为改变模型会影响隐变量. 然而，出于计算原因，这个假设是方便的，利用该假设我们可以再次定义变分 EM（VEM）"学习" 方案. 特别是，我们可以简化自由能和对应的界：

$$F_{\mathrm{VB}}[q]=\int \mathrm{d}\theta\, q(\theta)\log q(\theta)-\log p(\theta) \tag{260}$$

$$+\sum_n\sum_{z_n} q_n(z_n)\big(\log q_n(z_n)-\log p(x_n,z_n|\theta)\big), \tag{261}$$

其中 $p(x_n,z_n,\theta)=p(x_n|z_n,\theta)p(z_n|\theta)p(\theta)$. 因此，自由能分解为涉及 $q_n(z_n)$ 和 $q(\theta)$ 的项. 变分贝叶斯 EM（Beal, 2003）更新现在由下式给出：

$$\text{VBE 步：}\quad q_n^{k+1}(z_n)=\frac{1}{Z_n}\exp\left(\int \mathrm{d}\theta\, q^k(\theta)\log[p(x_n|z_n,\theta)\,p(z_n|\theta)\,p(\theta)]\right), \tag{262}$$

$$\text{VBM 步：}\quad q^{k+1}(\theta)=\frac{1}{Z(\theta)}p(\theta)\exp\left(\sum_n\sum_{z_n} q_n^{k+1}(z_n)\log p(x_n,z_n|\theta)\right). \tag{263}$$

虽然这看起来复杂，但我们所做的唯一改变是将参数提升为随机变量，并在自由能框架内一致地对待它们. 学习已完全被推断所取代. 我们创建了一个超系统，由许多较小的系统组成（每个数据案例一个），在这些系统中我们在给定单个观测约束 x_n 的情况下对 z_n 最大化熵. 此外，我们构建了一个更大的系统，通过由参数 θ 介导的相互作用将所有这些较小的系统耦合在一起. 这个更大的系统也在试图最大化熵，但受整个数据集的约束. 我们可以想象所有这些系统在最大化熵（或最小化自由能）的动力学下演化，同时确保数据提供的约束得到遵守. 这就是 Bayes 机器学习的随机热力学视角！

---

is constrained by the entire dataset. We can imagine all these systems evolving under dynamics that maximize entropy (or minimize free energy) while making sure the constraints provided by the data are respected. This is the stochastic thermodynamics view of Bayesian machine learning!

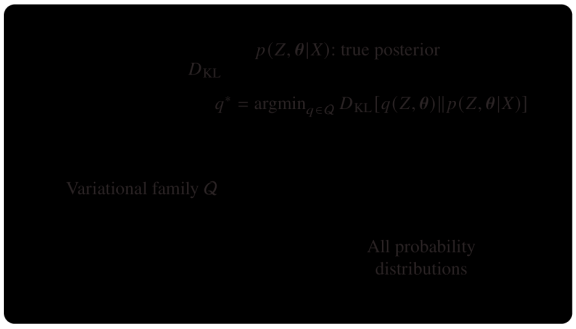


Figure 4.8 Illustration of variational inference: the true posterior is approximated by a

图 19: 变分推断说明：真实后验由变分族 $\mathcal{Q}$ 中的分布逼近. 浅灰色背景区域表示所有候选概率分布的空间，而五边形表示变分族 $\mathcal{Q}$. 标记的点 q^* 是使到真实后验 $p(Z,\theta|X)$（黑点）的 KL 散度最小的最优变分分布. 箭头表示被最小化的 KL 散度.

Chapter 5

概率机器学习的热力学

5.1 引言

在这一简短的章节中，我们将更详细地解释物理中的自由能与机器学习中的“自由能”（即 ELBO）之间的深刻联系. 从某种意义上说，这一思想处于本书的核心！我们还将联系两个领域中自由能的变化. 当物理中的自由能变化时，要么是因为系统弛豫到平衡态，我们将其与熵变和产热联系起来；要么是因为我们改变了 Hamiltonian，例如因为我们想要控制系统——我们将其与做功联系起来. 在 ML 中，这些过程可以映射到推断和学习.

5.2 联系热力学与 ML 中的自由能

（非平衡）热力学中变分自由能的表达式由下式给出：

$$F_{\mathrm{TD}}[q] = U[q] - TS[q] = \mathbb{E}_q[\mathcal{H}] + T\mathbb{E}_q[\log q], \tag{264}$$

这是期望能量项 $U[q]$ 减去温度乘以熵. 在 ML 中，我们还推导了隐变量模型 p 对于数据点 x 的变分自由能：

$$F_{\mathrm{ML}}[q] = \mathbb{E}_q[-\log p] + \mathbb{E}_q[\log q], \tag{265}$$

其中 $p(x, z)$ 表示 x 和 z 上的联合分布，$q(z|x)$ 是变分分布.

比较热力学自由能与 ML 自由能，我们看到如果将 Hamiltonian $\mathcal{H}$ 与负对数联合概率 $-\log p(x, z)$ 等同起来并设温度 $T = 1$，则存在直接的类比. 在 ML 语境中，没有显式的热浴，因此惯例是使用无量纲量，其中温度被吸收到能量的定义中. 我们在余下的讨论中采用此约定（$T = 1$，或逆温度 $\beta = 1$）. 这意味着 ML 中与自由能、热和功类似的量以信息单位（奈特或比特）而非能量单位（焦耳）度量. 一些研究者考虑在 ML 模型中重新引入类温度参数，如 Higgins et al. (2017) 所讨论的.

在热力学中，自由能 F 有几种变化方式，我们现在将这些与 ML 中的变分期望最大化（VEM）更新联系起来. 首先，让我们研究系统内部（期望）能量扰动的贡献：

$$\Delta U(x) = \sum_z \Delta\big(q(z|x)\mathcal{H}(z, x)\big) \tag{266}$$

$$= \sum_z \mathcal{H}(z, x)\Delta q(z|x) + \sum_z q(z|x)\Delta\mathcal{H}(z, x), \tag{267}$$

其中我们可以识别出：

$$\text{热：} \quad \Delta Q(x) = \sum_z \mathcal{H}(z, x)\Delta q(z|x), \quad \text{满足} \sum_z \Delta q(z|x) = 0, \tag{268}$$

$$\text{功：} \quad \Delta W(x) = \sum_z q(z|x) \Delta \mathcal{H}(z, x). \tag{269}$$

换言之：当分布 $q(z|x)$ 在 Hamiltonian 恒定下变化时（例如在扰动后弛豫），系统产生“热”；当分布固定但 Hamiltonian 改变时（例如被控制以实现某个目标），系统做功. 目前，我们将这些作为定义.

当我们使用概率模型中 Hamiltonian 的定义时，可以将热和功与推断和学习联系起来. 令 θ 和 ϕ 分别表示联合分布 $p(x, z|\theta)$ 和近似后验分布 $q(z|x, \phi)$ 的参数. 参数 θ 通常表示我们想要学习的模型参数，而 ϕ 表示我们用于推断的近似后验的参数. 因此：

$$\text{热：} \quad \Delta Q(x) = -\sum_z \log p(x, z|\theta) \frac{\partial q(z|x, \phi)}{\partial \phi} \Delta \phi, \tag{270}$$

$$\text{功：} \quad \Delta W(x) = -\sum_z q(z|x, \phi) \frac{\partial \log p(x, z|\theta)}{\partial \theta} \Delta \theta. \tag{271}$$

这种联系使我们能够将 VEM 算法中的 E 步（推断）识别为将自由能弛豫到基态并在此过程中产生热和熵. 此外，M 步（学习）可以识别为对系统做功以提高其性能：

$$\text{E 步：} \quad \Delta F(x) = \Delta Q(x) - \Delta S(x) \quad \text{对所有} x, \tag{272}$$

$$\text{M 步：} \quad \Delta F = \sum_n \Delta W(x_n). \tag{273}$$

我们还观察到，当 q 最小化自由能时达到平衡分布，我们称之为 Boltzmann 分布. 为看到这一点，我们令自由能的变分为零：

$$\Delta F(x) = 0 \quad \Rightarrow \quad \Delta Q(x) - \Delta S(x) = 0 \quad \Rightarrow \quad \Delta Q(x) = \Delta S(x). \tag{274}$$

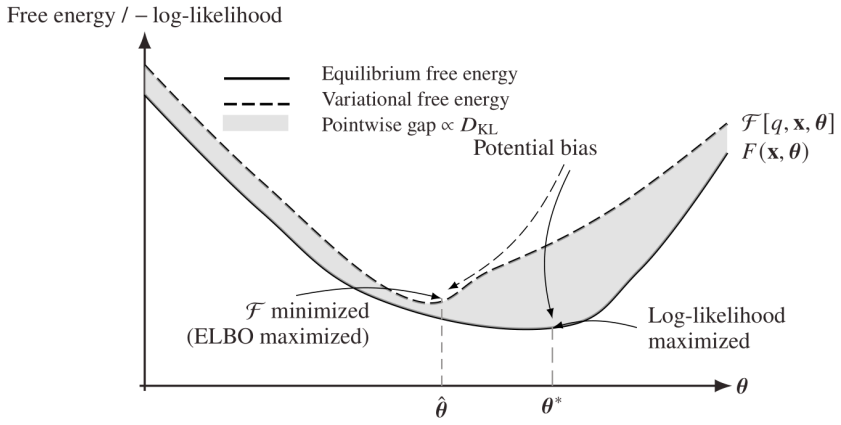


Figure 5.1 Comparison of variational and equilibrium free energies in machine learning. The

图 20: 机器学习中变分自由能与平衡自由能的比较. 黑色实线显示平衡自由能 $F(x,\theta)$（负对数似然），而黑色虚线表示变分自由能 $\mathcal{F}[q,x,\theta]$（负 ELBO）. 灰色阴影区域表示变分自由能与平衡自由能之间的逐点差异，它等于近似后验与真实后验之间的 KL 散度. 注意不同的最小值：$\hat{\theta}$ 最大化 ELBO，而 θ^* 最大化对数似然，显示了变分方法中的潜在偏差. 这种偏差源于变分推断中的逼近，可能导致次优的参数估计. 逐点差异（灰色区域）量化了变分逼近的质量.

在归一化约束 $\sum_z q(z|x)=1$ 下关于 $q(z|x)$ 最小化自由能，我们得到：

$$0=\sum_z q(z|x)\mathcal{H}(z,x)+\sum_z q(z|x)\log q(z|x)-\lambda\left(\sum_z q(z|x)-1\right)\frac{\delta}{\delta q(z|x)} \tag{275}$$

$$=\mathcal{H}(z,x)+(\log q(z|x)+1)-\lambda. \tag{276}$$

求解 $q(z|x)$，我们发现：

$$q(z|x)=\frac{1}{Z(x)}\exp(-\mathcal{H}(z,x))=\frac{1}{p(x)}p(x,z)=p(z|x), \tag{277}$$

其中 $Z(x)=\sum_z\exp(-\mathcal{H}(z,x))=p(x)$. 平衡自由能于是为：

$$F(x)=-\log Z(x)=-\log p(x). \tag{278}$$

有了上述关系，我们通过非常明确地建立随机热力学中非平衡自由能定义与机器学习中证据下界定义之间的类比来结束本节. 在物理中，我们有：

$$D_{\mathrm{KL}}[q\|p_B]=\mathbb{E}_q[\mathcal{H}(z,\theta)]-S[q]+\log Z(\theta), \tag{279}$$

其中 $p_B(z)=\frac{1}{Z(\theta)}e^{-\beta\mathcal{H}(z,\theta)}$ 是 Boltzmann 分布. 由于 $D_{\mathrm{KL}}[q\|p_B]\geq 0$，我们有：

$$F(\theta)\equiv-\beta^{-1}\log Z(\theta)\leq\mathbb{E}_q[\mathcal{H}(z,\theta)]-\beta^{-1}S[q]\equiv\mathcal{F}[q,\theta]. \tag{280}$$

类似地，在 ML 的情况下（如图 20 所示），我们显式地以某些观测为条件并写为：

$$D_{\mathrm{KL}}[q_{Z|X}\|p_{Z|X}] = \sum_z q(z|x)[-\log p(x,z|\theta)] - S[q_{Z|X}] + \log p(x|\theta). \tag{281}$$

由于 $D_{\mathrm{KL}}[q_{Z|X}\|p_{Z|X}] \geq 0$，我们有：

$$F(x,\theta) \equiv -\log p(x|\theta) \leq \mathbb{E}_q[-\log p(x,z|\theta)] - S[q_{Z|X}] \equiv \mathcal{F}[q,x,\theta]. \tag{282}$$

这些推导揭示了热力学量与机器学习中不同概率分布上的负对数概率之间迷人的对应关系. 我们应该识别 $q(z) \leftrightarrow q(z|x)$，这意味着每个观测 x 有不同的自由能. 每个这些系统的 Hamiltonian 必须识别为 $\mathcal{H}(z,x,\theta) = -\log p(x,z|\theta)$，平衡自由能识别为 $F(x,\theta) = -\log p(x|\theta)$. 此外，我们可以将近似后验的熵定义为 $S[q_{Z|X}] = -\sum_z q(z|x)\log q(z|x)$（如果我们有变分参数 ϕ，则为 $S[q^{\phi}_{Z|X}] = -\sum_z q(z|x,\phi)\log q(z|x,\phi)$）.

Chapter 6

置信传播

6.1 置信传播及其扩展

我们已经看到，概率推断可以视为在变分分布 Q 上最小化自由能. 我们也已经看到，Bayes 推断——它把对隐变量的推断与对模型参数的推断结合起来——是概率推断的一种形式. 因此，概率推断是一个非常一般的问题. 遗憾的是，除了最简单的情形，这个问题都很难求解. 这导致人们去寻找在一个受限制的变分分布集合上最小化自由能的近似方法，从而得到自由能的一个上界以及一个近似分布 Q.

让我们简要回顾平均场近似，其中我们取 $Q(\mathbf{z}) = \prod_k q_k(z_k)$. 此时变分自由能取如下形式：

$$\mathcal{F}[Q] = -\sum_{\mathbf{z}} \left[\prod_k q_k(z_k)\right] \log P(\mathbf{x}, \mathbf{z}) + \sum_k \sum_{z_k} q_k(z_k) \log q_k(z_k). \tag{283}$$

现在，假设模型 P 可以写成若干项之积，每一项依赖于隐变量的一个子集：

$$-\log P(\mathbf{x}, \mathbf{z}) = \sum_{\alpha} \Psi_\alpha(\mathbf{z}_\alpha; \mathbf{x}), \tag{284}$$

其中 α 索引 $\mathbf{z}$ 的一个可能相互重叠的变量子集 $\mathcal{V}_\alpha$，而 $\mathcal{V}_\alpha \subseteq \{1, \ldots, K\}$，$K$ 为变量总数. 这一分解假设现在给出：

$$\mathcal{F}[Q] = \sum_{\alpha} \sum_{\mathbf{z}_\alpha} \left[\prod_{k \in \mathcal{V}_\alpha} q_k(z_k)\right] \Psi_\alpha(\mathbf{z}_\alpha; \mathbf{x}) + \sum_k \sum_{z_k} q_k(z_k) \log q_k(z_k), \tag{285}$$

由此得到平均场更新：

$$q_k(z_k) \leftarrow \frac{1}{Z_k} \exp\left(- \sum_{\alpha : k \in \mathcal{V}_\alpha} \sum_{\mathbf{z}_\alpha \setminus z_k} \left[\prod_{j \in \mathcal{V}_\alpha \setminus k} q_j(z_j)\right] \Psi_\alpha(\mathbf{z}_\alpha; \mathbf{x}) \right). \tag{286}$$

这里，$\mathbf{z}_\alpha \setminus z_k$ 表示 $\mathbf{z}_\alpha$ 中除去 z_k 后的变量集合，$\mathcal{V}_\alpha \setminus k$ 表示相应的指标集合. 用文字表述：q_k 的新估计正比于所有包含变量 z_k 的能量因子之期望的负指数和.

平均场虽然易于处理，但由于它假设所有变量相互独立，精度并不高. 事实证明，存在一种好得多的近似方法，称为*置信传播*（belief propagation, BP）. 在 BP 中，我们做两个近似：第一，用累积展开（见下文）来近似熵项；第二，在一组相互一致的边缘密度 $\{q_\alpha, q_k\}$ 上进行优化. 所谓“相互一致”，指的是：

$$\sum_{\mathbf{z}_\alpha \setminus z_k} q_\alpha(\mathbf{z}_\alpha) = q_k(z_k), \qquad \text{对所有} \alpha,\ k \in \mathcal{V}_\alpha. \tag{287}$$

之所以说这是近似，是因为并不能保证任意一组一致的边缘都与某个全局分布 $q(\mathbf{z})$ 相容；换言之，可能根本不存在一个以这些“边缘分布”为真实边缘的全局分布.

我们这里处理的情形，是一个更为一般的框架——簇变分方法（Morita, 1990）或广义置信传播（Yedidia et al., 2005）——的特例. 在这些更一般的方法中，我们可以定义任意子集及其所有交集、交集的交集所构成的变量簇，然后要求它们全部一致. 本章中，我们处理稍简单的情形，称为因子图 BP.

首先写出熵的近似，即熟知的 Bethe 熵：

$$\mathcal{S}[Q] \approx \sum_{\alpha} \mathcal{S}_{\alpha}[q_{\alpha}] - \sum_{k} (N_k - 1)\, \mathcal{S}_k[q_k], \tag{288}$$

其中

$$\mathcal{S}_{\alpha}[q_{\alpha}] = -\sum_{\mathbf{z}_{\alpha}} q_{\alpha}(\mathbf{z}_{\alpha}) \log q_{\alpha}(\mathbf{z}_{\alpha}), \tag{289}$$

$$\mathcal{S}_k[q_k] = -\sum_{z_k} q_k(z_k) \log q_k(z_k). \tag{290}$$

这里 N_k 是变量 z_k 参与的簇 α 的个数. 可以用重复计数论证来理解这一点. 熵是广延量：两个不相交（独立）子集的并的熵应当可加. 然而，有些簇相互重叠，因此我们应当减去因某些变量被多个簇包含而造成的重复计数. 例如，若各簇互不相交，则每个变量在每个簇中恰好参与一次，无需修正（即对所有 k 有 $N_k = 1$）. 若一个变量位于两个簇中，则需减去它被重复计算的那一份贡献（即 $N_k = 2$），依此类推.

我们还注意到，在由相互重叠的簇构成的树上，这一熵近似是精确的. 最直观的方式是画出因子图：它是一个二部图，一侧为簇 α，另一侧为变量节点 k. 若某变量参与某个簇 Ψ_{α}，则把该因子节点与该变量节点相连. 若此因子图无环，精确概率分布可以写为

$$Q(\mathbf{z}) = \prod_{\alpha} q_{\alpha}(\mathbf{z}_{\alpha}) \prod_{k} q_k(z_k)^{1 - N_k}, \tag{291}$$

由此得到 (288) 中的熵. Bethe 熵近似的动机在于：它在树上是精确的，并且通过修正变量的重复计数，对有环图也给出合理的近似. 方程 (288) 只是一个近似.

若我们有精确的边缘，则能量可以精确计算，因为它已分解到各因子上. 此时，我们可以写出自由能的如下近似：

$$\mathcal{F}_{\mathrm{BP}}[\{q_{\alpha}, q_k\}] = \sum_{\alpha} \sum_{\mathbf{z}_{\alpha}} q_{\alpha}(\mathbf{z}_{\alpha}) \Psi_{\alpha}(\mathbf{z}_{\alpha}; \mathbf{x}) - \sum_{\alpha} \mathcal{S}_{\alpha}[q_{\alpha}] + \sum_{k} (N_k - 1)\, \mathcal{S}_k[q_k] \tag{292}$$

约束为

$$\sum_{\mathbf{z}_{\alpha} \setminus z_k} q_{\alpha}(\mathbf{z}_{\alpha}) = q_k(z_k), \qquad \text{对所有} \alpha,\ k \in \mathcal{V}_{\alpha}. \tag{293}$$

我们现在的任务是：在一致性约束下对 $\{q_{\alpha}, q_k\}$ 最小化 $\mathcal{F}_{\mathrm{BP}}$，从而找到该自由能的“基态”.

由第 1 章我们知道如何处理等式约束：Lagrange 乘子！对每一个约束，引入一个 Lagrange 乘子 $\lambda_{\alpha,k}$，写出 Lagrangian：

$$\mathcal{L}[\{q_\alpha, q_k, \lambda_{\alpha,k}\}] = \mathcal{F}_{\mathrm{BP}}[\{q_\alpha, q_k\}] + \sum_\alpha \sum_{k\in\mathcal{V}_\alpha} \sum_{z_k} \lambda_{\alpha,k}(z_k) \left[\sum_{\mathbf{z}_\alpha \setminus z_k} q_\alpha(\mathbf{z}_\alpha) - q_k(z_k) \right]. \tag{294}$$

我们还应为 q_α 与 q_k 归一化、非负的约束加上乘子. 可以证明，非负性约束在构造中自动满足，而归一化可以事后容易地实现. 因此为简洁起见，我们略去这些乘子.

对 q_α 与 q_k 求导，得到

$$\frac{\partial \mathcal{L}}{\partial q_\alpha(\mathbf{z}_\alpha)} = \Psi_\alpha(\mathbf{z}_\alpha; \mathbf{x}) + \log q_\alpha(\mathbf{z}_\alpha) + \sum_{k\in\mathcal{V}_\alpha} \lambda_{\alpha,k}(z_k) + c_1, \tag{295}$$

$$\frac{\partial \mathcal{L}}{\partial q_k(z_k)} = (1 - N_k) \log q_k(z_k) - \sum_{\alpha: k\in\mathcal{V}_\alpha} \lambda_{\alpha,k}(z_k) + c_2, \tag{296}$$

其中 c_1, c_2 为将被吸收到归一化中的常数. 记号 $\alpha : k \in \mathcal{V}_\alpha$ 表示变量节点 k 属于其论域的簇 α. 解出 q，得到

$$q_\alpha(\mathbf{z}_\alpha) = \frac{1}{Z_\alpha} \exp\left(-\Psi_\alpha(\mathbf{z}_\alpha; \mathbf{x}) - \sum_{k\in\mathcal{V}_\alpha} \lambda_{\alpha,k}(z_k) \right), \tag{297}$$

$$q_k(z_k) = \frac{1}{Z_k} \exp\left(-\frac{1}{N_k - 1} \sum_{\alpha: k\in\mathcal{V}_\alpha} \lambda_{\alpha,k}(z_k) \right). \tag{298}$$

现在把消息定义为：

$$n_{k\to\alpha}(z_k) \equiv \exp\big(-\lambda_{\alpha,k}(z_k)\big) \equiv \prod_{\beta: k\in\mathcal{V}_\beta\setminus\alpha} m_{\beta\to k}(z_k). \tag{299}$$

由此可以推出：

$$\begin{aligned} q_\alpha(\mathbf{z}_\alpha) &= \frac{1}{Z_\alpha} \exp\big(-\Psi_\alpha(\mathbf{z}_\alpha; \mathbf{x})\big) \prod_{k\in\mathcal{V}_\alpha} n_{k\to\alpha}(z_k) \\ &= \frac{1}{Z_\alpha} \exp\big(-\Psi_\alpha(\mathbf{z}_\alpha; \mathbf{x})\big) \prod_{k\in\mathcal{V}_\alpha} \prod_{\beta: k\in\mathcal{V}_\beta\setminus\alpha} m_{\beta\to k}(z_k), \end{aligned} \tag{300}$$

$$q_k(z_k) = \frac{1}{Z_k} \prod_{\alpha: k\in\mathcal{V}_\alpha} \big[n_{k\to\alpha}(z_k)\big]^{\frac{1}{N_k - 1}} = \frac{1}{Z_k} \prod_{\alpha: k\in\mathcal{V}_\alpha} m_{\alpha\to k}(z_k). \tag{301}$$

用这些定义来看，因子上的近似边缘等于传入消息 $n_{k\to\alpha}$ 之积再乘以落在该因子节点上的任意因子. 变量节点的边缘则简单地由传入消息 $m_{\alpha\to k}$ 之积给出. 图 21 在一个简单因子图上示意了这一消息传递格式.

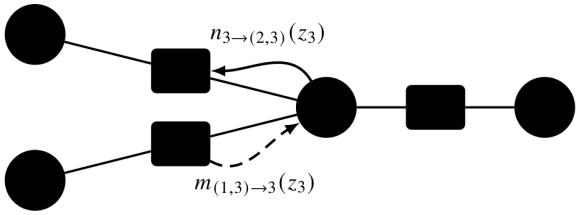


Figure 6.1 Belief propagation on a factor graph. Circular nodes represent variables (z_i), and

图 21: 因子图上的置信传播. 圆形节点表示变量 (z_i)，圆角矩形表示因子 (Ψ_α). 长虚线箭头表示从因子到变量的消息 $m_{\alpha\to k}(z_k)$，实线箭头表示从变量到因子的消息 $n_{k\to\alpha}(z_k)$. 消息被迭代地传递，直至收敛.

(294) 中的 Lagrange 乘子，可以通过保证边缘上的局部一致性方程 (293) 成立来求解. 既然我们已经把 Lagrange 乘子重新参数化为消息，我们就改为求解消息：

$$\frac{1}{Z_\alpha}\sum_{\mathbf{z}_\alpha\setminus z_k}\exp\bigl(-\Psi_\alpha(\mathbf{z}_\alpha;\mathbf{x})\bigr)\prod_{j\in\mathcal{V}_\alpha}\prod_{\beta:j\in\mathcal{V}_\beta\setminus\alpha}m_{\beta\to j}(z_j)=\frac{1}{Z_k}\prod_{\gamma:k\in\mathcal{V}_\gamma}m_{\gamma\to k}(z_k), \tag{302}$$

消去两边同时出现的项后，得到消息的不动点更新：

$$\begin{aligned}m^{\text{new}}_{\alpha\to k}(z_k)&\propto\sum_{\mathbf{z}_\alpha\setminus z_k}\exp\bigl(-\Psi_\alpha(\mathbf{z}_\alpha;\mathbf{x})\bigr)\prod_{j\in\mathcal{V}_\alpha\setminus k}n_{j\to\alpha}(z_j)\\&=\sum_{\mathbf{z}_\alpha\setminus z_k}\exp\bigl(-\Psi_\alpha(\mathbf{z}_\alpha;\mathbf{x})\bigr)\prod_{j\in\mathcal{V}_\alpha\setminus k}\prod_{\beta:j\in\mathcal{V}_\beta\setminus\alpha}m_{\beta\to j}(z_j).\end{aligned} \tag{303}$$

我们迭代这些不动点方程，直至收敛. 在树结构（因子）图上，这一过程保证收敛，并且若随后用 (300) 与 (301) 计算边缘 q_α 与 q_k，则保证得到精确结果. 这一点可以由以下事实推出：在该情形下，自由能中的能量项与熵项都没有被近似. 奇妙之处在于，即使（因子）图有环时我们仍然迭代这些方程，它们往往仍然收敛到一个不动点，而近似边缘往往也是相当好的近似.

有几个实用技巧可以改善收敛性并避免数值误差. 第一，注意到我们在更新中略去了任何归一化常数. 原因在于它们对最终的边缘估计不起作用——反正边缘会被单独归一化（而且它们只以乘法方式影响这些估计）. 不过，良好的实践是把消息的最大值保持在一定范围内，以防止数值溢出.

第二，人们可能发现，对有环的因子图，消息更新方程实际上并不收敛. 此时，可以通过如下更新消息来施加（几何）阻尼：

$$m'_{\alpha\to k}(z_k)=\sum_{\mathbf{z}_\alpha\setminus z_k}\exp\bigl(-\Psi_\alpha(\mathbf{z}_\alpha;\mathbf{x})\bigr)\prod_{j\in\mathcal{V}_\alpha\setminus k}\prod_{\beta:j\in\mathcal{V}_\beta\setminus\alpha}m_{\beta\to j}(z_j), \tag{304}$$

$$m^{\text{new}}_{\alpha\to k}(z_k)=\bigl[m_{\alpha\to k}(z_k)\bigr]^{1-\eta}\bigl[m'_{\alpha\to k}(z_k)\bigr]^{\eta},\qquad \eta\in(0,1], \tag{305}$$

其中 η 为阻尼因子. 最后，需要初始化消息；通常把它们初始化为全 1 即可.

Yedidia 等人（2005）证明，即使在（因子）图有环的情形下，上述“环路置信传播”（LBP）的不动点也对应于（近似的）Bethe 自由能的驻点. 该文并未证明这些驻点是该自由能的全局极小. Heskes（2002）随后证明，LBP 的稳定不动点是 Bethe 自由能的局部极小.

LBP 对纠错译码社区产生了巨大影响，因为一些最好的码——如 Turbo 码与低密度奇偶校验（LDPC）码——正是基于它. 此外，作为一种近似推断算法，LBP 及其在 Bayes 推断上的推广——期望传播（Minka, 2001）——至今仍是性能最好的近似推断算法之一.

6.2 一个马尔可夫链例子

现在把 BP 应用于马尔可夫链，这与本书的主题相关，并将在第 15 章中使用.

一个带观测的马尔可夫链的联合分布为（其图模型表示见 图 22）：

$$\begin{aligned} P(\mathbf{x},\mathbf{z}) &= p_0(z_0)p_0(x_0|z_0)\prod_{t=1}^{t_f} p(z_t|z_{t-1})p(x_t|z_t) \\ &= \prod_{t=1}^{t_f} \exp\bigl(-\Psi_{t-1,t}(z_{t-1},z_t;x_t)\bigr), \end{aligned} \tag{306}$$

其中

$$\Psi_{0,1}(z_0,z_1;x_0,x_1) = -\log\bigl(p_0(z_0)p_0(x_0|z_0)p(z_1|z_0)p(x_1|z_1)\bigr), \tag{307}$$

$$\Psi_{t-1,t}(z_{t-1},z_t;x_t) = -\log\bigl(p(z_t|z_{t-1})p(x_t|z_t)\bigr), \qquad \text{对} t>1. \tag{308}$$

由于链式结构，每个变量 z_t 恰好参与两个因子（端点除外），因此对内部节点有 $N_k = 2$. n 消息与 m 消息之间的关系由 (299) 简化为

$$n_{t\to(t-1,t)}(z_t) = m_{(t,t+1)\to t}(z_t), \tag{309}$$

$$n_{t\to(t,t+1)}(z_t) = m_{(t-1,t)\to t}(z_t), \tag{310}$$

此时簇 α 总是形如 $(t,t+1)$.

我们把所有消息初始化为全 1，并从左、右两个方向执行 (303)：

$$m^{\text{new}}_{(0,1)\to 1}(z_1) = \sum_{z_0} \exp\bigl(-\Psi_{0,1}(z_0,z_1;x_0,x_1)\bigr), \tag{311}$$

$$m^{\text{new}}_{(t,t+1)\to t+1}(z_{t+1}) = \sum_{z_t} \exp\bigl(-\Psi_{t,t+1}(z_t,z_{t+1};x_{t+1})\bigr)\, m_{(t-1,t)\to t}(z_t), \tag{312}$$

$$m^{\text{new}}_{(t_f-1,t_f)\to t_f-1}(z_{t_f-1}) = \sum_{z_{t_f}} \exp\bigl(-\Psi_{t_f-1,t_f}(z_{t_f-1},z_{t_f};x_{t_f})\bigr), \tag{313}$$

$$m^{\text{new}}_{(t-1,t)\to t-1}(z_{t-1}) = \sum_{z_t} \exp\bigl(-\Psi_{t-1,t}(z_{t-1},z_t;x_t)\bigr)\, m_{(t,t+1)\to t}(z_t). \tag{314}$$

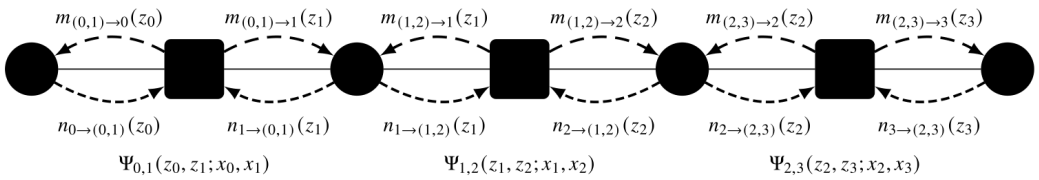


Figure 6.2 Belief propagation on a Markov chain. Circular nodes represent hidden states (z_t), and rounded rectangles represent factors ($\Psi_{t-1,t}$). Long-dashed curves indicate forward

图 22: 马尔可夫链上的置信传播. 圆形节点表示隐状态 (z_t), 圆角矩形表示因子 $(\Psi_{t-1,t})$. 长虚线曲线表示从因子到变量的前向消息 $(m_{(t-1,t)\to t}(z_t))$，短虚线曲线表示从变量到因子的后向消息 $(n_{t\to(t-1,t)}(z_t))$.

最后，边缘计算为：

$$q_{t,t+1}(z_t, z_{t+1}) = \frac{1}{Z_{t,t+1}} \exp\big(-\Psi_{t,t+1}(z_t, z_{t+1}; x_{t+1})\big)\, m_{(t-1,t)\to t}(z_t)\, m_{(t+1,t+2)\to t+1}(z_{t+1}), \tag{315}$$

$$q_t(z_t) = \frac{1}{Z_t}\, m_{(t-1,t)\to t}(z_t)\, m_{(t,t+1)\to t}(z_t). \tag{316}$$

我们注意到，对于状态空间 z_t 很大的系统，即使在链上运行 LBP 所需的求和也将是难以承受的，因此需要额外的近似.

Chapter 7

变分自编码器

7.1 引言

现在，我们可以把前几章学到的图模型知识、以及基于证据下界（ELBO）目标的 VEM 学习算法，应用到一个具体的模型架构上：变分自编码器（variational autoencoder, VAE）. VAE 有一个显式的编码器神经网络（NN），用于在给定观测时推断隐变量上的分布；还有一个生成式解码器模型，用于把来自隐变量先验分布的随机样本变换为生成的数据样本. VAE 的核心思想是：我们可以通过学习一个模型（编码器）来预测推断的结果，从而加速推断. 这一核心原理称为“摊销推断”（amortized inference）.

7.2 机器学习中的自由能

如前一章所讨论的，概率 ML 中使用的基本量是证据下界（evidence lower bound, ELBO）（Blei et al., 2017）. 为了表述它，我们引入观测变量 $\mathbf{x}$ 与未观测（即隐）变量 $\mathbf{z}$. 我们有时也称隐变量为隐藏变量，但与深度神经网络中作为观测变量之确定性函数的隐藏变量不同，这里我们假设隐藏变量本质上是随机的.

我们在这些变量上构造两个概率分布：

$$p(\mathbf{x}, \mathbf{z}) = p(\mathbf{x}|\mathbf{z})\, p(\mathbf{z}), \tag{317}$$

$$q(\mathbf{z}, \mathbf{x}) = q(\mathbf{z}|\mathbf{x})\, q(\mathbf{x}). \tag{318}$$

出于稍后会清楚的原因，我们把 q 称为前向模型、编码器或推断模型，把 p 称为后向模型、解码器或生成模型. $q(\mathbf{x})$ 通常是数据分布，而 $p(\mathbf{z})$ 是隐变量上的先验. 若已知 $q(\mathbf{z}|\mathbf{x})$，我们就可以对生成数据的隐因子执行（近似）推断. 若已知 $p(\mathbf{x}|\mathbf{z})$，我们就可以（近似地）从数据分布中采样.

使这两个模型之间的差异变小是合理的. 由于我们真正关心的只是数据分布，一个目标就是最小化

$$D_{\mathrm{KL}}[q_X \| p_X] = \sum_{\mathbf{x}} q(\mathbf{x}) \big(\log q(\mathbf{x}) - \log p(\mathbf{x})\big), \tag{319}$$

$$p(\mathbf{x}) = \sum_{\mathbf{z}} p(\mathbf{x}|\mathbf{z})\, p(\mathbf{z}), \tag{320}$$

其中 $q(\mathbf{x})$ 是数据分布.[1] 若 $p(\mathbf{x})$ 依赖于某些参数 $\boldsymbol{\theta}$——即 $p(\mathbf{x}|\boldsymbol{\theta})$——则最小化目标变为

$$\mathcal{L}(\boldsymbol{\theta}, \mathbf{x}) = -\sum_{\mathbf{x}} q(\mathbf{x}) \log p(\mathbf{x}|\boldsymbol{\theta}) \approx -\sum_{n} \log p(\mathbf{x}_n|\boldsymbol{\theta}), \tag{321}$$

[1] 形式上，我们应总是写成 $q_X(\mathbf{x})$ 等，以标明分布及其自变量. 不过，当我们显式写出自变量时（如 $q(\mathbf{x})$），常略去下标以免混淆. 同样，当我们写出 KL 散度等泛函时，不应写出自变量，于是我们加上下标.

这称为极大似然原理（Bishop, 2006）.

由于 $p(\mathbf{x})$ 涉及对隐变量的难以处理的积分，这一优化通常非常困难. 我们转而使用联合分布之间 KL 散度的如下分解：

$$D_{\mathrm{KL}}[q_{Z,X}\|p_{X,Z}] = D_{\mathrm{KL}}[q_X\|p_X] + \mathbb{E}_{q_X}\big[D_{\mathrm{KL}}[q_{Z|X}\|p_{Z|X}]\big], \tag{322}$$

$$D_{\mathrm{KL}}[q_X\|p_X] = D_{\mathrm{KL}}[q_{Z,X}\|p_{X,Z}] - \mathbb{E}_{q_X}\big[D_{\mathrm{KL}}[q_{Z|X}\|p_{Z|X}]\big], \tag{323}$$

$$\Rightarrow \quad D_{\mathrm{KL}}[q_X\|p_X] \leq D_{\mathrm{KL}}[q_{Z,X}\|p_{X,Z}]. \tag{324}$$

由此得到不等式

$$\sum_{\mathbf{x}} q(\mathbf{x}) \log p(\mathbf{x}) \geq \sum_{\mathbf{x}} q(\mathbf{x}) \sum_{\mathbf{z}} q(\mathbf{z}|\mathbf{x}) \big(\log p(\mathbf{x},\mathbf{z}) - \log q(\mathbf{z}|\mathbf{x})\big), \tag{325}$$

$$\mathbb{E}_{q_X}[-\log p(\mathbf{x})] \leq \mathbb{E}_{q_X}\Big[\mathbb{E}_{q_{Z|X}}\big[-\log p(\mathbf{x},\mathbf{z}) + \log q(\mathbf{z}|\mathbf{x})\big]\Big], \tag{326}$$

在此过程中，我们可以识别出自由能 F、期望能量 $\mathcal{H}$、熵 $\mathcal{S}$ 以及变分自由能 $\mathcal{F}$. 事实上，由于该界对任意 $q(\mathbf{x})$ 都成立，我们可以把它取为关于某一特定 $\mathbf{x}$ 的 δ 函数，这意味着该界对每个 $\mathbf{x}$ 都条件成立：

$$F(\mathbf{x}) = -\log p(\mathbf{x}), \tag{327}$$

$$\leq \mathbb{E}_{q_{Z|X}}[\mathcal{H}(\mathbf{x},\mathbf{z})] - \mathcal{S}(\mathbf{x}) \equiv \mathcal{F}(\mathbf{x}), \tag{328}$$

$$\mathcal{H}(\mathbf{x},\mathbf{z}) = -\log p(\mathbf{x},\mathbf{z}), \tag{329}$$

$$\mathcal{S}(\mathbf{x}) = -\sum_{\mathbf{z}} q(\mathbf{z}|\mathbf{x}) \log q(\mathbf{z}|\mathbf{x}). \tag{330}$$

由此可以清楚地看到，它与物理之间存在密切联系，这正是本书将要探讨的.

7.3 变分期望最大化

学习一个参数化模型 $p(\mathbf{x}|\boldsymbol{\theta})$，现在可以通过迭代以下两步来进行，我们在前几章中称之为变分期望最大化（variational expectation-maximization, VEM）算法（Neal and Hinton, 1998）. 首先，假设我们还给变分后验 $q_{Z|X,\boldsymbol{\varphi}}$ 配备了某些参数 $\boldsymbol{\varphi}$. 然后，我们迭代：

$$\text{E-Step:} \quad \boldsymbol{\varphi}^{t+1} = \arg\min_{\boldsymbol{\varphi}} D_{\mathrm{KL}}[q_{Z,X|\boldsymbol{\varphi}}\|p_{X,Z|\boldsymbol{\theta}^t}], \tag{331}$$

$$\text{M-Step:} \quad \boldsymbol{\theta}^{t+1} = \arg\min_{\boldsymbol{\theta}} D_{\mathrm{KL}}[q_{Z,X|\boldsymbol{\varphi}^{t+1}}\|p_{X,Z|\boldsymbol{\theta}}]. \tag{332}$$

如第 4 章那样，我们本可以为数据集中观测到的每个 $\mathbf{x}_n$ 分离出参数 $\boldsymbol{\varphi}_n$. 然而，执行摊销推断要高效得多；也就是说，我们在由 q_X 生成的所有数据样本之间共享编码器 $q_{Z|X,\boldsymbol{\varphi}}$ 的参数. 这一算法就是变分自编码器的基础（Kingma and Welling, 2014; Rezende et al., 2014）.

优化所需的梯度可以容易地计算出来，但关于 q 的标准梯度（常使用 “REINFORCE” 估计量计算；见 Williams, 1992）方差很大；见 (4.19). 如第 4 章那样，我们可以应用重

参数化技巧来减小方差. 其关键思想仍是把随机变量 $\mathbf{z}$ 表达为输入 $\mathbf{x}$ 与一个辅助噪声变量 $\boldsymbol{\epsilon}$ 的确定性函数. 对于均值为 $\boldsymbol{\mu}(\mathbf{x})$、标准差为 $\boldsymbol{\sigma}(\mathbf{x})$ 的 Gaussian 分布 $q(\mathbf{z}|\mathbf{x})$，有

$$\mathbf{z} = \boldsymbol{\mu}(\mathbf{x}) + \boldsymbol{\sigma}(\mathbf{x}) \cdot \boldsymbol{\epsilon}, \qquad \boldsymbol{\epsilon} \sim G(\mathbf{0}, \mathbf{I}). \tag{333}$$

这使我们能够使用 Monte Carlo 采样来估计每个数据样本 $\mathbf{x}$ 的变分自由能（即负 ELBO）：

$$\mathcal{F}(\mathbf{x}) = \mathbb{E}_{\boldsymbol{\epsilon}\sim G(\mathbf{0},\mathbf{I})}\big[-\log p(\mathbf{x}, \mathbf{z}(\boldsymbol{\epsilon})) + \log q(\mathbf{z}(\boldsymbol{\epsilon})|\mathbf{x})\big] \tag{334}$$

$$\approx \frac{1}{S}\sum_{s=1}^{S}\big[-\log p(\mathbf{x}, \mathbf{z}_s) + \log q(\mathbf{z}_s|\mathbf{x})\big], \qquad \mathbf{z}_s = \boldsymbol{\mu}(\mathbf{x}) + \boldsymbol{\sigma}(\mathbf{x}) \cdot \boldsymbol{\epsilon}_s, \tag{335}$$

其中 S 个样本取自 $\boldsymbol{\epsilon}_s \sim G(\mathbf{0}, \mathbf{I})$.

由于 $G(\boldsymbol{\epsilon}; \mathbf{0}, \mathbf{I})$ 不像 $G(\mathbf{z}; \boldsymbol{\mu}(\mathbf{x}), \boldsymbol{\sigma}(\mathbf{x}))$ 那样依赖于任何参数，样本也就不依赖于这些参数. 这使得我们可以安全地把关于参数的导数穿过求和，并直接作用于期望内部的各项. 变分自编码器（VAE）学习算法现在包括：采样一个数据样本 $\mathbf{x}_n$，从标准正态分布中抽取一个或多个样本 $\boldsymbol{\epsilon}_{sn}$，然后对 (334) 中重参数化后的自由能表达式执行梯度更新.

7.4 层次化 VAE

在标准 VAE 架构中，我们用一个 NN 把输入 $\mathbf{x}$ 映射到分布 $q_{Z|X}$，方法是预测一个正态分布的均值与（协）方差：

$$q_{\boldsymbol{\varphi}}(\mathbf{z}|\mathbf{x}) = G(\mathbf{z}; \boldsymbol{\mu}(\mathbf{x}), \boldsymbol{\sigma}(\mathbf{x})), \tag{336}$$

$$\boldsymbol{\mu}(\mathbf{x}), \boldsymbol{\sigma}(\mathbf{x}) = \mathrm{NN}_{\boldsymbol{\varphi}}(\mathbf{x}). \tag{337}$$

然而，引入多层随机变量（见 图 23）并构建层次化模型，在不同抽象层级上学习特征，要强大得多. 我们定义：

$$\mathbf{z}_{0:t_f} = \{\mathbf{z}_0, \mathbf{z}_1, \ldots, \mathbf{z}_{t_f}\}, \tag{338}$$

其中我们用 $\mathbf{z}_0$ 表示可以对数据样本 $\mathbf{x}$ 进行条件化的随机变量. 我们把编码器与解码器都定义为马尔可夫链. 解码器（生成模型）由以下过程给出：从先验 $p(\mathbf{z}_{t_f})$ 中采样，然后在以 $\mathbf{z}_t$ 为条件下依次采样 $\mathbf{z}_{t-1}$，最后在以 $\mathbf{z}_1$ 为条件下采样 $\mathbf{z}_0 = \mathbf{x}$：

$$p(\mathbf{z}_{0:t_f}) = p(\mathbf{z}_{t_f}) \prod_{t=1}^{t_f} p_t(\mathbf{z}_{t-1}|\mathbf{z}_t). \tag{339}$$

编码器（推断模型）可以有两种分解方式（Kingma et al., 2016）：

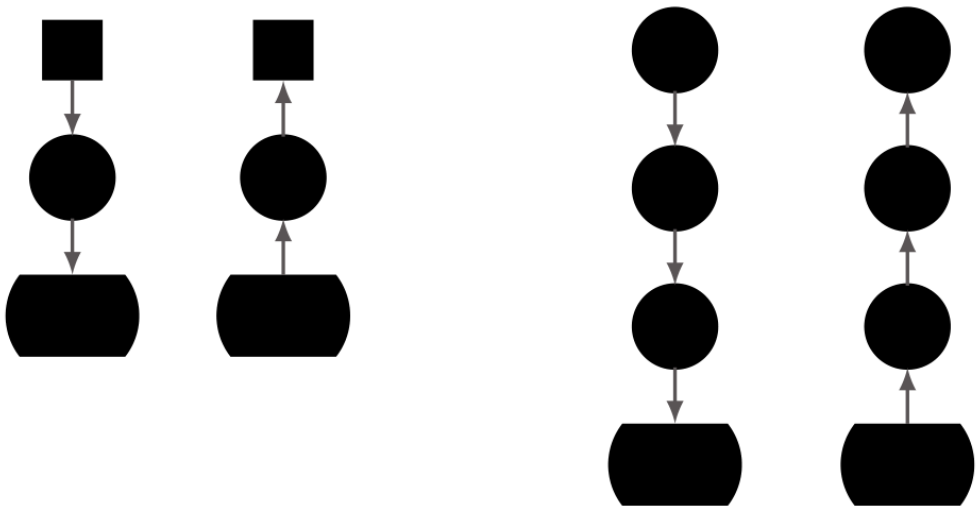
$$\text{自上而下：} \quad q(\mathbf{z}_{1:t_f}|\mathbf{z}_0 = \mathbf{x}) = q(\mathbf{z}_{t_f}|\mathbf{z}_0 = \mathbf{x}) \prod_{t=1}^{t_f-1} q_t(\mathbf{z}_t|\mathbf{z}_{t+1}, \mathbf{z}_0 = \mathbf{x}), \tag{340}$$

$$\text{自下而上：} \quad q(\mathbf{z}_{1:t_f}|\mathbf{z}_0 = \mathbf{x}) = \prod_{t=1}^{t_f} q_t(\mathbf{z}_t|\mathbf{z}_{t-1}, \mathbf{z}_0 = \mathbf{x}). \tag{341}$$

在自上而下的分解中，后验从最高层隐变量开始，并把每个较低层以其上层与数据 $\mathbf{x}$ 为条件；而自下而上的分解则从数据出发构建隐表示，把 $\mathbf{x}$ 沿层次向上传播.

如 图 23 所示，我们还可以在生成与推断过程中引入标签 $\mathbf{y}$. 在推断模型中，若 $\mathbf{y}$ 作为数据的一部分被观测到，我们通常以它为条件（若未被观测到，则生成它们）. 在生成过程中，我们可以选择从某个先验分布中随机抽取一个标签（即生成它们），或者若我们想生成某一特定类别 $\mathbf{y}$ 的样本，则以它们为条件.

我们注意到，界 (328) 仍然成立，因为它不依赖于隐变量的数目或其结构. 这一层次化 VAE 同时也构成了扩散模型的基础（Sohl-Dickstein et al., 2015; Ho et al., 2020），我们将在第 13 章中讨论.



(a) Class-conditional VAEs (b) Hierarchical VAEs

urchical extensions of variational autoencoders (VAEs). (a) Class-

图 23: 变分自编码器（VAE）的层次化扩展. (a) 类别条件 VAE 引入一个类别变量 y（方形），它影响隐变量 $\mathbf{z}$（双圈圆形），后者再生成观测数据 $\mathbf{x}$（圆角矩形）. 左列展示生成模型（箭头向下），右列展示推断模型（箭头向上）. (b) 层次化 VAE 堆叠多层隐变量 $(\mathbf{z}_1, \mathbf{z}_2, \mathbf{z}_3)$，在生成（左列）与推断（右列）模型中均构成马尔可夫链. 生成过程自上而下流动，推断过程自下而上流动. 这种层次结构允许更复杂、更具表达力的隐表示，捕捉数据中不同的抽象层级.

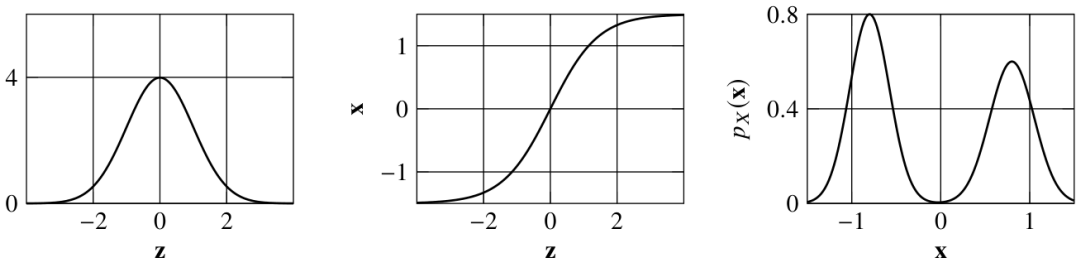
Chapter 8

归一化流

8.1 引言

在前几章中，我们讨论了把隐变量 $\mathbf{z}$ 映射到观测变量 $\mathbf{x}$ 的隐变量模型，其映射使用（一系列）随机变换 $p_{X|Z}(\mathbf{x}|\mathbf{z})$. 通过把映射取为随机的，诸如已讨论的变分自编码器（Kingma and Welling, 2014, 2019）之类的方法可以容易地改变隐空间的维数：增加维数通过混入噪声随机变量来实现，而降低维数则通过诸如池化之类的压缩映射来实现. 概率框架使这一切易于处理. 然而，反过来看，当使用随机映射时，对数似然是难以处理的，因此用极大似然估计（MLE）来优化它只能通过一个界（ELBO）来实现.

本章中，我们将讨论*归一化流*（normalizing flow），这是一种生成模型，与 VAE 不同，它使用确定性映射. 这使得精确的对数似然计算与优化成为可能. 但正如我们将看到的，它的缺点是映射必须是双射，这使模型更为复杂. 图 24 示意了这一变换过程，展示了一个简单的 Gaussian 分布如何通过一个可逆非线性函数被映射为一个复杂的多峰分布.



8.1 Visualization of a normalizing flow transformation. Left: A standard Gaussian prior

图 24: 归一化流变换的可视化. 左：标准 Gaussian 先验 $p_Z(\mathbf{z}) = G(0, 1)$. 中：把 $\mathbf{z}$ 映射到 $\mathbf{x}$ 的非线性可逆变换 g. 右：由此得到的变换后分布 $p_X(\mathbf{x})$，尽管先验是单峰的，它却呈现出双峰结构，表明归一化流可以建模复杂分布.

8.2 变换概率分布

在讨论归一化流之前，我们先回顾一些关于概率分布变换的一般规则. 概率分布的一个关键性质是它是归一化的，即总概率质量为 1；因此，当我们变换分布时，需要保证质量守恒：

$$p_X(\mathbf{x})\,\mathrm{d}\mathbf{x} = p_Z(\mathbf{z})\,\mathrm{d}\mathbf{z}. \tag{342}$$

在可逆确定性变换 $\mathbf{z} = \mathbf{z}(\mathbf{x})$ 的特殊情形下，我们可以用变换的 Jacobian 把这一守

恒律改写为：

$$p_X(\mathbf{x}) = p_Z(\mathbf{z}(\mathbf{x}))\left|\det \mathbf{J}_{\mathbf{z}}(\mathbf{x})\right|, \tag{343}$$

这里我们重载了符号 $\mathbf{z}$，使它既是 $\mathbb{R}^d$ 中的变量，也是函数 $\mathbf{z}:\mathbb{R}^d \to \mathbb{R}^d$. 方程 (343) 称为变量替换公式. 需要强调的是，函数 $\mathbf{z}(\mathbf{x})$ 必须可逆，上式才成立；即 $\mathbf{x} = \mathbf{x}(\mathbf{z}) = \mathbf{z}^{-1}(\mathbf{z})$.

最后一个因子是变换的 Jacobian 矩阵 $\mathbf{J}$ 的行列式的绝对值：

$$\mathbf{J}_{\mathbf{z}}(\mathbf{x}) = \left(\frac{\partial \mathbf{z}(\mathbf{x})}{\partial \mathbf{x}}\right) = \begin{pmatrix} \frac{\partial z_1(\mathbf{x})}{\partial x_1} & \cdots & \frac{\partial z_1(\mathbf{x})}{\partial x_d} \\ \vdots & \ddots & \vdots \\ \frac{\partial z_d(\mathbf{x})}{\partial x_1} & \cdots & \frac{\partial z_d(\mathbf{x})}{\partial x_d} \end{pmatrix}. \tag{344}$$

Jacobian 与变换空间中体积的局部膨胀或收缩相关（见 图 25）. 当映射 $\mathbf{z}(\mathbf{x})$ 局部压缩时，Jacobian 行列式的绝对值小于 1；反之，若映射局部膨胀，则它大于 1.

例 8.2.1 (线性变换)**：** 为了建立直觉，考虑一个标准正态分布 $p_Z(z) = G(z;0,1)$，对其施加线性变换 $x = az + b$. 该变换可逆，其逆为 $z = (x-b)/a$.

我们可以通过变量替换公式推导出所得分布的显式形式. 作为单变量变换，Jacobian 就是变换的导数，即 $\mathbf{J}_{\mathbf{z}} = \frac{\partial z}{\partial x} = \frac{1}{a}$. 代入变量替换公式，得到

$$p_X(x) = G\left(\frac{x-b}{a};0,1\right)\frac{1}{|a|} = G(x;b,a). \tag{345}$$

这仍是一个均值为 b、方差为 a^2 的正态分布.

这展示了 Jacobian 行列式在变量替换公式中的作用：它重新归一化分布，以保证总概率质量守恒. 根据 a 的取值，分布的方差将收缩或膨胀，从而影响分布的体积. 若 $|a| > 1$，这是一个压缩映射，$|\det(\mathbf{J})| < 1$；否则，该映射使体积膨胀. 另一方面，参数 b 只平移分布的均值，因此不改变体积，这由它不出现在 Jacobian 行列式中可见一斑.$\diamond$

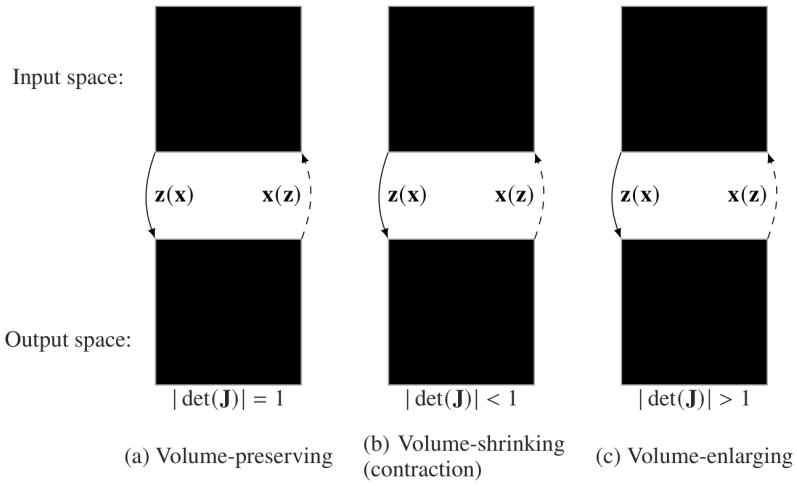


Figure 8.2 Invertible transformations between input space $\mathbf{x}$ and output space $\mathbf{z}$ in normalizing

图 25: 归一化流中输入空间 $\mathbf{x}$ 与输出空间 $\mathbf{z}$ 之间的可逆变换. (a) 保体积变换, Jacobian 行列式等于 1. (b) 缩体积变换(压缩), Jacobian 行列式小于 1. (c) 胀体积变换, Jacobian 行列式大于 1.

8.2.1 隐变量模型中的 Jacobian

我们可以把这一点与隐变量模型和 ELBO 联系起来，方法是追问：在随机设定下，Jacobian 的类比表达式是什么.

为此，考虑第 4 章中引入的隐变量模型的一般定义：

$$p_X(\mathbf{x}) = \sum_{\mathbf{z}} p_{X|Z}(\mathbf{x}|\mathbf{z})\, p_Z(\mathbf{z}) \tag{346}$$

如我们在 ELBO 的推导中所见，可以将其改写为

$$p_X(\mathbf{x}) = \sum_{\mathbf{z}} q_{Z|X}(\mathbf{z}|\mathbf{x})\, \frac{p_{X|Z}(\mathbf{x}|\mathbf{z})\, p_Z(\mathbf{z})}{q_{Z|X}(\mathbf{z}|\mathbf{x})}, \tag{347}$$

其中引入了变分分布 $q_{Z|X}(\mathbf{z}|\mathbf{x})$. 由于 $z(\mathbf{x})$ 是一个确定性变换，我们可以把变分分布 $q_{Z|X}(\mathbf{z}|\mathbf{x})$ 写为 δ 函数

$$q_{Z|X}(\mathbf{z}|\mathbf{x}) = \delta(\mathbf{z} - \mathbf{z}(\mathbf{x})).$$

代入上式，得到：

$$\begin{aligned} p_X(\mathbf{x}) &= \sum_{\mathbf{z}} \delta(\mathbf{z} - \mathbf{z}(\mathbf{x}))\, \frac{p_{X|Z}(\mathbf{x}|\mathbf{z})\, p_Z(\mathbf{z})}{q_{Z|X}(\mathbf{z}|\mathbf{x})} \\ &= p_Z(\mathbf{z}(\mathbf{x}))\, \frac{p_{X|Z}(\mathbf{x}|\mathbf{z}(\mathbf{x}))}{q_{Z|X}(\mathbf{z}(\mathbf{x})|\mathbf{x})}. \end{aligned} \tag{348}$$

将其与 (343) 中的变量替换公式比较，可见 Jacobian 项由下式给出：

$$\left|\det(\mathbf{J}_{\mathbf{z}}(\mathbf{x}))\right| = \frac{p_{X|Z}(\mathbf{x}|\mathbf{z}(\mathbf{x}))}{q_{Z|X}(\mathbf{z}(\mathbf{x})|\mathbf{x})}. \tag{349}$$

8.3 归一化流

在掌握了可逆变换下概率分布变换所需的背景知识后，我们现在可以用它来构建生成模型. 为此，先考虑单个变换的情形.

我们现在用许多层这样的变换构建一个层次化模型（如 图 26 所示），称为归一化流（Rezende and Mohamed, 2015）. 与 VAE 不同，归一化流使用确定性的双射变换（如 图 28(b) 所示）. 定义 $\mathbf{z}_2 = \mathbf{z}_2(\mathbf{z}_1) = \mathbf{z}_2(\mathbf{z}_1(\mathbf{x}))$，有

$$\log p_{Z_1}(\mathbf{z}_1) = \log p_{Z_2}(\mathbf{z}_2(\mathbf{z}_1)) + \log \left|\det\left(\frac{\partial \mathbf{z}_2(\mathbf{z}_1)}{\partial \mathbf{z}_1}\right)\right|. \tag{350}$$

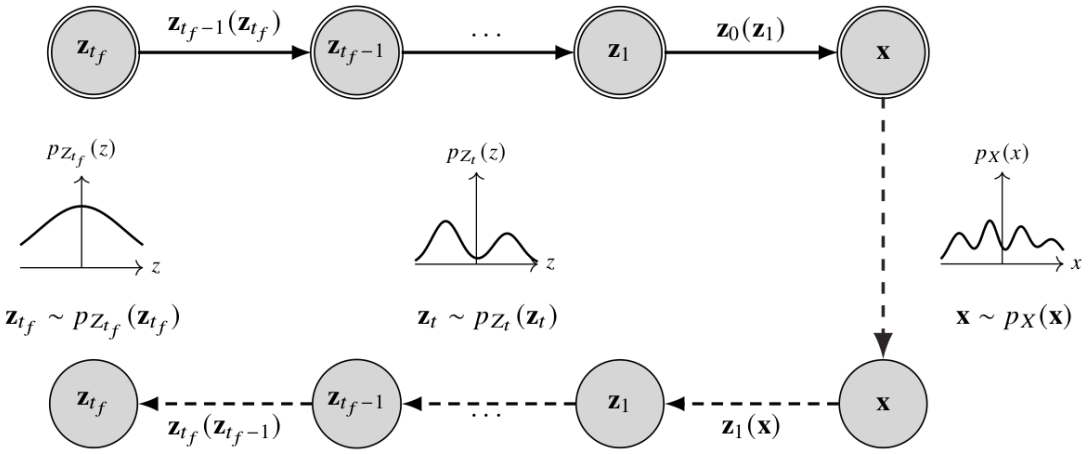
因此，可以写出：

$$\begin{aligned}\log p_X(\mathbf{x}) &= \log p_{Z_1}(\mathbf{z}_1(\mathbf{x})) + \log \left|\det\left(\frac{\partial \mathbf{z}_1(\mathbf{x})}{\partial \mathbf{x}}\right)\right| \\ &= \log p_{Z_2}(\mathbf{z}_2(\mathbf{z}_1(\mathbf{x}))) + \log \left|\det\left(\frac{\partial \mathbf{z}_2(\mathbf{z}_1(\mathbf{x}))}{\partial \mathbf{z}_1}\right)\right| + \log \left|\det\left(\frac{\partial \mathbf{z}_1(\mathbf{x})}{\partial \mathbf{x}}\right)\right|. \end{aligned} \tag{351}$$

若把这一点推广到多层变换，得到

$$\begin{aligned}\log p_X(\mathbf{x}) = &\log p_{Z_{t_f}}\left(\mathbf{z}_{t_f} \circ \mathbf{z}_{t_f-1} \circ \cdots \circ \mathbf{z}_1(\mathbf{x})\right) \\ &+ \sum_{t=1}^{t_f} \log \left|\det\left(\frac{\partial \mathbf{z}_t(\mathbf{z}_{t-1})}{\partial \mathbf{z}_{t-1}}\right)\right|\Bigg|_{\mathbf{z}_{t-1}=\mathbf{z}_{t-1}\circ\cdots\circ\mathbf{z}_1(\mathbf{x})}. \end{aligned} \tag{352}$$

$$+\sum_{t=1}^{} \log \left| \det \left(\frac{\partial \mathbf{z}_t}{\partial \mathbf{z}_{t-1}} \right) \right|_{\mathbf{z}_{t-1}=\mathbf{z}_{t-1}^{\boldsymbol{\theta}_{t-1}} \circ \cdots \circ \mathbf{z}_1^{\boldsymbol{\theta}_1}(\mathbf{x}_n)} \right|.$$



3.3 Normalizing flow composed of multiple invertible layers. The top row (solic

图 26: 由多个可逆层组成的归一化流. 上排（实线箭头）展示了从简单 Gaussian 分布 $p_{Z_{t_f}}(\mathbf{z}_{t_f})$ 经一系列可逆变换到复杂多峰分布 $p_X(\mathbf{x})$ 的前向变换. 下排（虚线箭头）展示了从观测数据分布 $\mathbf{x}$ 反向回到简单分布 $\mathbf{z}_{t_f}$ 的逆变换. 小图展示了流中概率密度从初始简单分布逐步演化为更复杂分布的过程.

8.4 训练

为了把它变成一个可训练的生成模型，我们对变换进行参数化，选择一个简单分布 $p_{Z_{t_f}}$（例如标准正态），并在数据集上最大化对数似然. 为方便起见，我们把参数化的变换记为 $\mathbf{z}_t^{\boldsymbol{\theta}_t}(\mathbf{z}_{t-1})$，其中 $\boldsymbol{\theta}_t$ 是第 t 个变换的参数. 我们还把复合变换定义为 $\mathbf{z}(\mathbf{x};\boldsymbol{\theta}) = \mathbf{z}_{t_f}^{\boldsymbol{\theta}_{t_f}} \circ \mathbf{z}_{t_f-1}^{\boldsymbol{\theta}_{t_f-1}} \circ \cdots \circ \mathbf{z}_1^{\boldsymbol{\theta}_1}(\mathbf{x})$，其中 $\boldsymbol{\theta} = \{\boldsymbol{\theta}_1, \ldots, \boldsymbol{\theta}_{t_f}\}$.

归一化流可以用两种方式训练：(1) 逼近给定数据集的分布；(2) 逼近目标密度，例如 Boltzmann 分布 $\pi_X(\mathbf{x}) = e^{-\mathcal{H}(\mathbf{x})}/Z$，其中 $\mathcal{H}(\mathbf{x})$ 是 Hamiltonian，Z 是配分函数（Boltzmann 生成器通常用于从物理或分子系统的 Boltzmann 分布中采样）.

当可以获得目标分布 $\pi(\mathbf{x})$ 的样本 $\{\mathbf{x}_s\}_{s=1}^S$ 时（例如来自 MCMC、分子动力学，或在有数据集可用的生成建模中），我们可以通过最小化前向 KL 散度来训练 NF：

$$D_{\mathrm{KL}}[\pi_X \| p_X] = \mathbb{E}_\pi[\log \pi(\mathbf{x}) - \log p_X(\mathbf{x})] \tag{353}$$

$$\approx -\frac{1}{S}\sum_{s=1}^{S} \log p_X(\mathbf{x}_s) + \text{常数}, \tag{354}$$

其中常数项包含 $\mathbb{E}_\pi[\log \pi(\mathbf{x})]$，它与参数 $\boldsymbol{\theta}$ 无关. 当我们可以直接获得目标分布的样本、并希望学习一个能生成类似样本的模型时，这种模式特别有用.

这等价于最大化对数似然：

$$\mathcal{L}(\boldsymbol{\theta}) = \frac{1}{S}\sum_{s=1}^{S} \log p_X(\mathbf{x}_s) \tag{355}$$

$$= \frac{1}{S}\sum_{s=1}^{S}\left[\log p_{Z_{t_f}}(\mathbf{z}(\mathbf{x}_s;\boldsymbol{\theta})) + \sum_{t=1}^{t_f}\log\left|\det\left(\frac{\partial \mathbf{z}_t^{\boldsymbol{\theta}_t}(\mathbf{z}_{t-1})}{\partial \mathbf{z}_{t-1}}\right)\right|\Bigg|_{\mathbf{z}_{t-1}=\mathbf{z}_{t-1}^{\boldsymbol{\theta}_{t-1}}\circ\cdots\circ\mathbf{z}_1^{\boldsymbol{\theta}_1}(\mathbf{x}_s)}\right], \tag{356}$$

其中 $\mathbf{z}_{t-1}(\mathbf{x}_s)$ 表示在 $\mathbf{x}_s$ 处计算的第 $(t-1)$ 个变换的输出.

对数似然关于参数的梯度可计算为：

$$\nabla_{\boldsymbol{\theta}}\mathcal{L}(\boldsymbol{\theta}) = \frac{1}{S}\sum_{s=1}^{S}\left[\nabla_{\boldsymbol{\theta}}\log p_{Z_{t_f}}(\mathbf{z}(\mathbf{x}_s;\boldsymbol{\theta})) + \sum_{t=1}^{t_f}\nabla_{\boldsymbol{\theta}}\log|\det(\mathbf{J}_t(\mathbf{x}_s;\boldsymbol{\theta}))|\right], \tag{357}$$

其中 $\mathbf{J}_t(\mathbf{x}_s;\boldsymbol{\theta})$ 是在 $\mathbf{x}_s$ 处计算的第 t 个变换的 Jacobian. 该梯度可用于随机梯度下降算法来优化参数 $\boldsymbol{\theta}$. 由于变换的双射性，训练后，我们可以通过从 $p_{Z_{t_f}}$ 中采样并施加复合变换的逆来从 p_X 生成新样本.

为了把 NF 训练为 Boltzmann 生成器（Noé et al., 2019）以从目标分布 $\pi_X(\mathbf{x})$ 中采样，我们最小化 $p_X(\mathbf{x})$ 与 $\pi_X(\mathbf{x})$ 之间的反向 KL 散度：

$$D_{\mathrm{KL}}[p_X\|\pi_X] = \mathbb{E}_{p_X}[\log p_X(\mathbf{x}) - \log\pi_X(\mathbf{x})] \tag{358}$$

$$= \mathbb{E}_{p_X}[\log p_X(\mathbf{x}) + \mathcal{H}(\mathbf{x})] + \log Z \tag{359}$$

$$= -\mathcal{S}[p_X] + \mathbb{E}_{p_X}[\mathcal{H}(\mathbf{x})] + \log Z, \tag{360}$$

其中 $\mathcal{S}[p_X] = -\mathbb{E}_{p_X}[\log p_X(\mathbf{x})]$ 是 p_X 的熵. 当我们有目标分布的解析形式（直到一个归一化常数）、但不易从其中获得样本时，这种方法特别有用. $\log Z$ 项是常数，我们再次看到优化目标是以自由能形式出现的.

该目标也可以用隐变量 $\mathbf{z}_{t_f}$ 来表述. 由变量替换公式，有：

$$D_{\mathrm{KL}}[p_X\|\pi_X] = -\mathbb{E}_{p_{Z_{t_f}}}\left[\log|\det(\mathbf{J}(\mathbf{z}_{t_f};\boldsymbol{\theta}))|\right] + \mathbb{E}_{p_{Z_{t_f}}}\left[\mathcal{H}\big(\mathbf{x}(\mathbf{z}_{t_f};\boldsymbol{\theta})\big)\right] + \log Z - \mathcal{S}[p_{Z_{t_f}}], \tag{361}$$

其中 $\mathbf{J}(\mathbf{z}_{t_f};\boldsymbol{\theta})$ 是在 $\mathbf{z}_{t_f}$ 处的复合变换 Jacobian，$\mathbf{x}(\mathbf{z}_{t_f};\boldsymbol{\theta})$ 是复合变换的逆.

关于 NF 参数的梯度可以用变量替换公式和 NF 的 Jacobian 来计算：

$$\nabla_{\boldsymbol{\theta}} D_{\mathrm{KL}}[p_X\|\pi_X] = -\mathbb{E}_{p_{Z_{t_f}}}\left[\nabla_{\boldsymbol{\theta}}\log|\det(\mathbf{J}(\mathbf{z}_{t_f};\boldsymbol{\theta}))|\right] + \mathbb{E}_{p_{Z_{t_f}}}\left[\nabla_{\boldsymbol{\theta}}\mathcal{H}\big(\mathbf{x}(\mathbf{z}_{t_f};\boldsymbol{\theta})\big)\right]. \tag{362}$$

注意 $\log Z$ 项关于参数是常数，因此在梯度计算中消失. 为计算这些梯度，可以使用以下步骤：

$$\nabla_{\boldsymbol{\theta}}\log|\det(\mathbf{J}(\mathbf{z}_{t_f};\boldsymbol{\theta}))| = \mathrm{tr}\big(\mathbf{J}(\mathbf{z}_{t_f};\boldsymbol{\theta})^{-1}\nabla_{\boldsymbol{\theta}}\mathbf{J}(\mathbf{z}_{t_f};\boldsymbol{\theta})\big), \tag{363}$$

$$\nabla_{\boldsymbol{\theta}}\mathcal{H}(\mathbf{x}(\mathbf{z}_{t_f};\boldsymbol{\theta})) = \nabla_{\mathbf{x}}\mathcal{H}(\mathbf{x}(\mathbf{z}_{t_f};\boldsymbol{\theta}))\cdot\nabla_{\boldsymbol{\theta}}\mathbf{x}(\mathbf{z}_{t_f};\boldsymbol{\theta}), \tag{364}$$

其中 $\mathrm{tr}(\cdot)$ 表示矩阵的迹. 项 $\nabla_{\boldsymbol{\theta}}\mathbf{J}(\mathbf{z}_{t_f};\boldsymbol{\theta})$ 可以用自动微分技术（即反向传播；见第 2.6 节）计算.

也可以在混合模式下运行：我们用 MCMC 从目标密度生成样本，再在这些样本上训练 NF，以加速 MCMC 采样器. 当目标分布是多峰的或具有复杂结构时，这有时很有用.

一旦训练完成，作为 Boltzmann 生成器的 NF 可用于各种任务，例如在隐空间 $\mathbf{z}_{t_f}$ 上运行 MCMC 以更快地从目标分布采样，或用重要性采样估计期望或配分函数. 这些方法已在从生化分子构型到格点场论和规范理论等复杂系统的采样中获得应用（Albergo et al., 2021; Abbott et al., 2023）. 我们将在第 11 章和第 12 章中解释这些.

8.5 可逆变换

有了对数似然的显式表达式是方便的，但我们仍需选择可逆变换. 可逆性要求严重限制了这些映射的选择. 下面给出几个双射变换的例子，其中一些在 图 27 中示意.

我们首先把变量集 $\mathbf{x}$ 和 $\mathbf{z}$ 分成两个（随机）子集，每一层使用不同的分割：

$$\mathbf{x} = \{\mathbf{x}_A, \mathbf{x}_B\}, \qquad \mathbf{z} = \{\mathbf{z}_A, \mathbf{z}_B\}. \tag{365}$$

耦合流变换（见 图 27）及其逆由下式给出（Dinh et al., 2017）：

$$\mathbf{z}_A = \mathbf{x}_A, \qquad \mathbf{z}_B = \exp\big(\mathbf{f}(\mathbf{x}_A)\big) \odot \mathbf{x}_B + \mathbf{g}(\mathbf{x}_A), \tag{366}$$

$$\mathbf{x}_A = \mathbf{z}_A, \qquad \mathbf{x}_B = \exp\big(-\mathbf{f}(\mathbf{z}_A)\big) \odot \big(\mathbf{z}_B - \mathbf{g}(\mathbf{z}_A)\big), \tag{367}$$

其中 $\odot$ 表示逐元素乘法，$\mathbf{f}, \mathbf{g}$ 是函数（通常是神经网络，如 Dinh et al. (2017) 中的卷积神经网络），它们基于 $\mathbf{x}_A$ 输出缩放与平移参数. 该变换产生一个易于计算的三角 Jacobian.

这一主题的一个变体是残差流变换（Dinh et al., 2014; Gomez et al., 2017）：

$$\mathbf{z}_A = \mathbf{x}_A + \mathbf{f}(\mathbf{x}_B), \qquad \mathbf{z}_B = \mathbf{x}_B + \mathbf{g}(\mathbf{z}_A) = \mathbf{x}_B + \mathbf{g}(\mathbf{x}_A + \mathbf{f}(\mathbf{x}_B)), \tag{368}$$

$$\mathbf{x}_B = \mathbf{z}_B - \mathbf{g}(\mathbf{z}_A), \qquad \mathbf{x}_A = \mathbf{z}_A - \mathbf{f}(\mathbf{x}_B) = \mathbf{z}_A - \mathbf{f}(\mathbf{z}_B - \mathbf{g}(\mathbf{z}_A)). \tag{369}$$

最后，提及自回归流变换（及其逆）（Papamakarios et al., 2017）：

$$\mathbf{z}_1 = \mathbf{f}_1(\mathbf{x}_1), \tag{370}$$

$$\mathbf{z}_2 = \mathbf{f}_2(\mathbf{x}_2|\mathbf{z}_1), \tag{371}$$

$$\vdots$$

$$\mathbf{z}_{t_f} = \mathbf{f}_{t_f}(\mathbf{x}_{t_f}|\mathbf{z}_1, \ldots, \mathbf{z}_{t_f-1}), \tag{372}$$

$$\mathbf{x}_1 = \mathbf{f}_1^{-1}(\mathbf{z}_1), \tag{373}$$

$$\mathbf{x}_2 = \mathbf{f}_2^{-1}(\mathbf{z}_2|\mathbf{x}_1) = \mathbf{f}_2^{-1}(\mathbf{z}_2|\mathbf{f}_1^{-1}(\mathbf{z}_1)), \tag{374}$$

$$\vdots$$

$$\mathbf{x}_{t_f} = \mathbf{f}_{t_f}^{-1}\big(\mathbf{z}_{t_f}|\mathbf{f}_1^{-1}(\mathbf{z}_1), \mathbf{f}_2^{-1}(\mathbf{z}_2|\mathbf{f}_1^{-1}(\mathbf{z}_1)), \ldots\big), \tag{375}$$

其中每个变量的变换只依赖于先前的变量. 文献中还提出了许多更巧妙的可逆变换，但我们留给读者去发现.

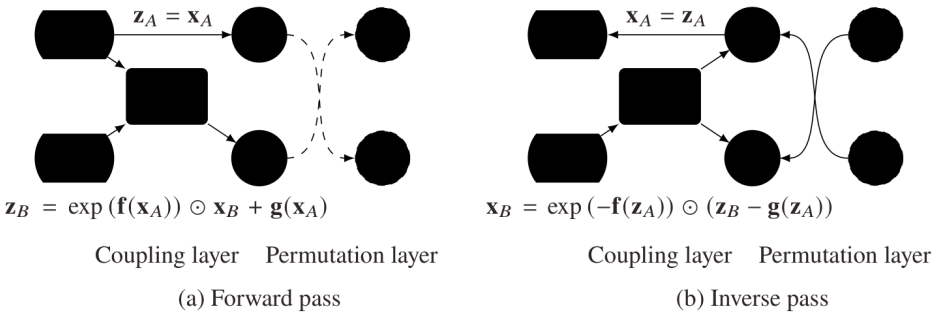


Figure 8.4 Coupling and permutation layers in normalizing flows. (a) Forward pass: The

图 27: 归一化流中的耦合层与置换层. (a) 前向传播：耦合层基于 $\mathbf{x}_A$ 施加 $\mathbf{f}$ 和 $\mathbf{g}$ 来变换 $\mathbf{x}_B$；置换层交换 $\mathbf{z}_A$ 和 $\mathbf{z}_B$. (b) 反向传播：用 $\mathbf{f}$ 和 $\mathbf{g}$ 逆序执行. 这使得在 $\mathbf{x}$ 与 $\mathbf{z}$ 空间之间可以进行具有易处理 Jacobian 的可逆变换.

8.6 ELBO 的分解

ELBO 可以有三种不同的分解方式：

$$\log p_X(\mathbf{x}) \geq \mathbb{E}_{q_{Z|X}}\left[\log p_{X|Z}(\mathbf{x}|\mathbf{z}) + \log p_Z(\mathbf{z})\right] + \mathcal{S}[q_{Z|X}] \tag{376}$$

$$= \mathbb{E}_{q_{Z|X}}[\log p_{X|Z}(\mathbf{x}|\mathbf{z})] - D_{\mathrm{KL}}[q_{Z|X} \| p_Z] \tag{377}$$

$$= \mathbb{E}_{q_{Z|X}}[\log p_Z(\mathbf{z})] + \mathbb{E}_{q_{Z|X}}\left[\log \frac{p_{X|Z}(\mathbf{x}|\mathbf{z})}{q_{Z|X}(\mathbf{z}|\mathbf{x})}\right], \tag{378}$$

其中第一行是通常的（负）自由能分解. 第二行是“率–失真”分解，第一项代表 $\mathbf{x}$ 的（重构误差）失真，第二项代表“率”，即相对于先验 p_Z（假设收发双方已知）对隐码 $\mathbf{z}$ 进行编码所需的比特数. 第三行在 NF 语境下是最自然的：第一项是变换后输入在先验下的概率，第二项代表 Jacobian “缩放因子”.

8.7 热力学解释

归一化流平滑且可逆地把状态 $\mathbf{x}$ 映射到状态 $\mathbf{z}$，如 图 26 所示. 我们之所以需要使用概率，唯一的原因是对值 $\mathbf{x}$ 存在初始不确定性，而这种不确定性被传播到 $\mathbf{z}$. 用数学术语说，这称为概率密度 p_X 的推前映射：在可逆映射 $\mathbf{z}(\mathbf{x})$ 下，$\mathbf{x}$ 的概率密度被变换为 $\mathbf{z}$ 的概率密度（见 图 28(b)）. 与 VAE 的随机映射（图 28(a)）不同，映射本身中不加入额外的噪声（随机性、随机性）.

可逆性要求使这些架构的设计具有挑战性. 此外，由于映射是平滑的，p_X 中的多峰比单峰的 p_Z 更难建模；你会发现 p_X 的各峰之间有细小的概率桥相连. 一个解决方案是使用随机归一化流（Wu et al., 2020）和 SurVAE 流（Nielsen et al., 2020），它们把

VAE 中典型的随机与变维映射（图 28(a)）与 NF 的确定性步骤（图 28(b)）结合起来. 这些将在第 20 章中讨论. 与随机映射相比，确定性 NF 的最大优势在于：你可以访问精确的对数概率，而不是一个界.

由于归一化流是一个确定性可逆映射，根据定义不丢失任何信息（我们可以沿时间反向运行方程以恢复精确历史），熵增为零. 这类似于说：在微观层面，Hamilton 方程是确定性且可逆的，因此不产生熵. 当我们开始积分掉自由度时（当有许多这样被丢弃的自由度时，我们称之为 “热浴”），熵才进入画面. NF 的类似概念是：某些维度对输入的粗粒化信号建模，而其他维度对噪声变量建模. 存储 “噪声” 比特的剩余维度是逆变换所必需的；然而，对于分类等任务，人们可能只依赖粗粒化概念. 就泛化性能而言，丢弃噪声维度甚至可能是有益的. 如果我们忘记或删除这些噪声维度，可以把这解释为丢失了对细节的追踪，而只保留对粗粒化量的追踪. 我们可以把这些噪声维度看作一种 “热浴”. 通过丢弃（即积分掉）噪声比特，我们无法再逆转变换，这些变换变得实际上不可逆. 我们现在可以引入一个熵来描述系统中由此产生的不确定性. 该熵计数总系统中与低维系统的某一状态相容的状态数. 这随后类似于用诸如 Brown 运动之类的不可逆随机动力学来描述信号维度.

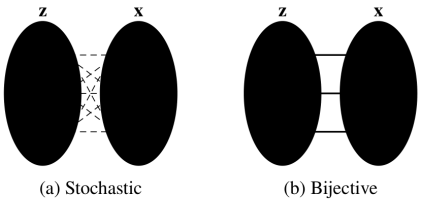


Figure 8.5 Transformations in generative models: (a) Stochastic: Variational autoencoders

图 28: 生成模型中的变换. (a) 随机：变分自编码器（VAE）使用概率映射（虚线箭头）在带图案的隐区域 $\mathbf{z}$ 与带图案的观测区域 $\mathbf{x}$ 之间映射. (b) 双射：归一化流使用一对一的确定性映射（实线箭头）.

CHAPTER 9

马尔可夫过程与时间反演

9.1 引言

本章中，我们介绍研究随机热力学中如此突出的非平衡随机过程的一个关键组件：马尔可夫过程（Markov process, MP）. 马尔可夫过程是一种无记忆过程，其下一状态只依赖于前一状态，而不依赖于更早的状态. 在本书余下部分，我们将需要五个不同但相关的马尔可夫过程. 有物理的前向过程及其时间反演（非物理的“后向”）过程. “伴随”过程对第 11 章研究的马尔可夫链蒙特卡洛方法非常重要，在第 17 章推导涨落定理时同样重要. 最后，我们还会加入时间反演过程与对偶过程，它们都与涨落定理相关.

本章中，我们还将更深入地探讨时间反演对称性，以及如何用它来联系这些不同的过程.

9.2 五个马尔可夫核

在本书后续章节中，我们会遇到许多复杂的记号问题. 因此在使用它们之前，我们先用本节来解释. 此处定义的五个核对于理解第 10 章和第 17 章是必要的.

假设我们有一条路径的联合密度 $\rho_{0:t_f}(\boldsymbol{\zeta}_0, \ldots, \boldsymbol{\zeta}_{t_f})$，或时刻 t 相空间中一个状态的边缘密度 $\rho_t(\boldsymbol{\zeta}_t)$. 为方便起见，下面我们记 $\rho \equiv \rho_{0:t_f}$. 此外，回忆相空间变量 $\boldsymbol{\zeta}$ 由位形变量 $\boldsymbol{\xi}$ 与动量变量 $\boldsymbol{\eta}$ 组成.

全书我们都将考虑马尔可夫过程. 这是一种近似，因为若被积分掉的状态比我们所考虑的状态更快地达到平衡，那么就会存在记忆效应：下一状态不仅依赖于当前状态加上不可预测的噪声，还可预测地依赖于更长的状态历史. 因此，马尔可夫假设与噪声的引入，正是对底层确定性过程快速混沌动力学所导致的微观自由度不可预测性的建模.

为了用数学描述马尔可夫过程，我们使用过渡核把密度从一个时间步推进到下一个时间步. 我们用 $F_t(\boldsymbol{\zeta}_t|\boldsymbol{\zeta}_{t-1})$ 来表示它们. 这个物理过渡核依赖于控制参数 $\boldsymbol{\lambda}_t$：

$$F_t(\boldsymbol{\zeta}_t|\boldsymbol{\zeta}_{t-1}) \equiv F(\boldsymbol{\zeta}_t|\boldsymbol{\zeta}_{t-1}, \boldsymbol{\lambda}_t). \tag{379}$$

使用这些过渡核，一条完整路径的联合概率密度 $\rho = \rho_{0:t_f}$ 由如下马尔可夫过程给出：

$$\rho(\boldsymbol{\zeta}_0, \boldsymbol{\zeta}_1, \ldots, \boldsymbol{\zeta}_{t_f}) = \rho_0(\boldsymbol{\zeta}_0) \prod_{t=1}^{t_f} F_t(\boldsymbol{\zeta}_t|\boldsymbol{\zeta}_{t-1}), \tag{380}$$

其中 ρ_0 是任意初始分布. 由于过程远离平衡，边缘分布 ρ_t 将依赖于直到该时刻的全部控制参数历史：

$$\rho_t(\boldsymbol{\zeta}_t) = \rho_t(\boldsymbol{\zeta}_t|\boldsymbol{\lambda}_0, \ldots, \boldsymbol{\lambda}_t). \tag{381}$$

接下来我们想定义时间反演后的密度. 尽管在微观层面自然界是时间反演对称的，但当我们用粗粒化变量上的概率密度来描述世界时，情况并非必然如此. 随机热力学中的许多关键概念都与这些不可逆过程相关. 例如，产生的热量与熵的多少直接与动力学的不可逆性相关. 甚至更根本地，我们感知到时间向前流逝、并把因与果赋予总是按一定顺序发生的过程，这一事实与我们所经验的过程不可逆相关. 因此，一般而言，(380) 中马尔可夫过程的前向与后向过渡核不必相同. 例如，扩散过程的后向核应当 "反扩散"（或 "去噪"）一个概率分布，即把一个分散的分布演化为一个集中的分布. 把摊开的煎蛋卷重新变回鸡蛋这种感觉上非物理的事实，正是演化定律时间反演不对称的信号.

给定 (380) 中的前向过程，我们可以把同一联合分布重新参数化为一个后向过程：它从 ρ_{t_f} 出发，用另一个过渡核 B 向后转移：

$$\rho(\boldsymbol{\zeta}_{0:t_f}) = \rho_{t_f}(\boldsymbol{\zeta}_{t_f}) \prod_{t=1}^{t_f} B_t(\boldsymbol{\zeta}_{t-1}|\boldsymbol{\zeta}_t), \tag{382}$$

其中 $B_t(\boldsymbol{\zeta}_{t-1}|\boldsymbol{\zeta}_t)$ 是后向过渡概率密度. 注意，非物理的时间反演过程（例如把煎蛋卷变回鸡蛋）在这个后向过程下是可能的. 我们注意到，(382) 不过是把 (380) 按时间反演方向重写.

前向与后向过程通过如下 "平衡方程" 相联系：

$$F_t(\boldsymbol{\zeta}_t|\boldsymbol{\zeta}_{t-1})\rho_{t-1}(\boldsymbol{\zeta}_{t-1}) = B_t(\boldsymbol{\zeta}_{t-1}|\boldsymbol{\zeta}_t)\rho_t(\boldsymbol{\zeta}_t) \tag{383}$$

$$\Rightarrow \quad B_t(\boldsymbol{\zeta}_{t-1}|\boldsymbol{\zeta}_t) = \frac{F_t(\boldsymbol{\zeta}_t|\boldsymbol{\zeta}_{t-1})\rho_{t-1}(\boldsymbol{\zeta}_{t-1})}{\rho_t(\boldsymbol{\zeta}_t)}, \tag{384}$$

$$\rho_t(\boldsymbol{\zeta}_t) = \int \mathrm{d}\boldsymbol{\zeta}_{t-1}\, F_t(\boldsymbol{\zeta}_t|\boldsymbol{\zeta}_{t-1})\rho_{t-1}(\boldsymbol{\zeta}_{t-1}), \tag{385}$$

$$\rho_{t-1}(\boldsymbol{\zeta}_{t-1}) = \int \mathrm{d}\boldsymbol{\zeta}_t\, B_t(\boldsymbol{\zeta}_{t-1}|\boldsymbol{\zeta}_t)\rho_t(\boldsymbol{\zeta}_t). \tag{386}$$

这表达了 B 反演一个远离平衡的概率流这一事实（ρ_{t-1} 与 ρ_t 是非平衡边缘分布）. B_t 的定义依赖于密度 ρ_t 与 ρ_{t-1}（的比值）（因而依赖于 $\boldsymbol{\lambda}_0, \ldots, \boldsymbol{\lambda}_t$），它并不代表一条物理演化定律.（我们用 t 而非 $t-1$ 来标记 B_t，原因是它依赖于直到 $\boldsymbol{\lambda}_t$ 在内的所有参数.）

除了由 B 支配的非物理时间反演过程外，在后续章节中我们还会遇到若干其他 "反向" 马尔可夫链. 第一个是一个反向核，称为伴随核（adjoint kernel）. 既然每个不可约（遍历或混合）马尔可夫链都有唯一的平稳分布，我们总可以写出

$$\pi_t(\boldsymbol{\zeta}_{t-1})F_t(\boldsymbol{\zeta}_t|\boldsymbol{\zeta}_{t-1}) = \pi_t(\boldsymbol{\zeta}_t)A_t(\boldsymbol{\zeta}_{t-1}|\boldsymbol{\zeta}_t), \tag{387}$$

其中 π_t 表示过渡核 F_t 的平稳（或稳态）分布，因而（只）依赖于 $\boldsymbol{\lambda}_t$. 事实上，当且仅当 π_t 是 F_t 的平稳分布时，(387) 中的广义平衡方程（GB）成立，这等价于说 π_t 在施加 F_t 下不变：

$$\int \mathrm{d}\boldsymbol{\zeta}_{t-1}\, \pi_t(\boldsymbol{\zeta}_{t-1})F_t(\boldsymbol{\zeta}_t|\boldsymbol{\zeta}_{t-1}) = \pi_t(\boldsymbol{\zeta}_t). \tag{388}$$

因此，应当把 GB 方程 (387) 视为 A_t 的定义：

$$A_t(\boldsymbol{\zeta}_{t-1}|\boldsymbol{\zeta}_t) \equiv \frac{\pi_t(\boldsymbol{\zeta}_{t-1})F_t(\boldsymbol{\zeta}_t|\boldsymbol{\zeta}_{t-1})}{\pi_t(\boldsymbol{\zeta}_t)}, \tag{389}$$

其中 A_t 的下标 t 再次表示该核只依赖于 $\boldsymbol{\lambda}_t$. 可以验证，当 π_t 确实是 F_t 的不变（平稳）分布时，A_t 是非负且归一化的. 容易验证，这个伴随核同样保持平稳分布 π_t：

$$\int \mathrm{d}\boldsymbol{\zeta}_t\, A_t(\boldsymbol{\zeta}_{t-1}|\boldsymbol{\zeta}_t)\pi_t(\boldsymbol{\zeta}_t) = \pi_t(\boldsymbol{\zeta}_{t-1}) \int \mathrm{d}\boldsymbol{\zeta}_t\, F_t(\boldsymbol{\zeta}_t|\boldsymbol{\zeta}_{t-1}) = \pi_t(\boldsymbol{\zeta}_{t-1}), \tag{390}$$

其中我们使用了前向核的归一化.

与“反扩散”（或 ML 术语中的“去噪”）的 B 不同，核 A 是一个扩散过程. 它与 F 的不同之处在于：在平稳态下，它反转了任何剩余概率流的方向.

为说明这一区别，我们考虑如下模型（改编自 Spinney and Ford, 2012b; Lee et al., 2013）. 考虑一个由 L 个状态与两个速度构成的圆环，给出维数为 $2L$ 的完整状态空间：

$$(\boldsymbol{\xi}, \boldsymbol{\eta}) = \{(0,-1),(0,+1),\ldots,(L-1,-1),(L-1,+1)\}. \tag{391}$$

我们对前向过渡核假设如下取值，它对动量翻转与依赖于动量的空间跳跃建模：

$$F(\boldsymbol{\xi}_i,+1|\boldsymbol{\xi}_i,-1) = a, \qquad (\text{动量从 } -1 \text{ 翻到 } +1), \tag{392}$$
$$F(\boldsymbol{\xi}_i,-1|\boldsymbol{\xi}_i,+1) = b, \qquad (\text{动量从 } +1 \text{ 翻到 } -1), \tag{393}$$
$$F(\boldsymbol{\xi}_{i+1},+1|\boldsymbol{\xi}_i,+1) = c, \qquad (\text{动量为 } +1 \text{ 时向右跳}), \tag{394}$$
$$F(\boldsymbol{\xi}_{i-1},-1|\boldsymbol{\xi}_i,-1) = d, \qquad (\text{动量为 } -1 \text{ 时向左跳}), \tag{395}$$
$$F(\boldsymbol{\xi}_i,+1|\boldsymbol{\xi}_i,+1) = 1-b-c, \qquad (\text{自环}), \tag{396}$$
$$F(\boldsymbol{\xi}_i,-1|\boldsymbol{\xi}_i,-1) = 1-a-d, \qquad (\text{自环}), \tag{397}$$

所有其他转移等于 0. 该过程在 图 29(a) 中示意.

由平移对称性，平稳分布在空间指标 i 上必须均匀. 令 $\pi_+ = \sum_i \pi(\boldsymbol{\xi}_i,+1)$ 与 $\pi_- = \sum_i \pi(\boldsymbol{\xi}_i,-1)$ 表示两个速度扇区的总平稳权重；在平稳态下，符号翻转通量必须平衡：

$$\pi_+ b = \pi_- a.$$

再结合 $\pi_+ + \pi_- = 1$，得到 $\pi_+ = \frac{a}{a+b}$ 与 $\pi_- = \frac{b}{a+b}$. 因此

$$\pi(\boldsymbol{\xi}_i,+1) = \frac{1}{L}\frac{a}{a+b}, \tag{398}$$
$$\pi(\boldsymbol{\xi}_i,-1) = \frac{1}{L}\frac{b}{a+b}. \tag{399}$$

我们还观察到，该分布在时间反演下不对称，因为它在变换 $\boldsymbol{\eta} = +1 \leftrightarrow \boldsymbol{\eta} = -1$ 下不对称.

现在来研究这个例子中伴随核 A_t 是什么样子. 用 (389) 中 A_t 的定义，我们得到

$$A(\boldsymbol{\xi}_i, +1|\boldsymbol{\xi}_i, -1) = a, \tag{400}$$
$$A(\boldsymbol{\xi}_i, -1|\boldsymbol{\xi}_i, +1) = b, \tag{401}$$
$$A(\boldsymbol{\xi}_{i-1}, +1|\boldsymbol{\xi}_i, +1) = c, \tag{402}$$
$$A(\boldsymbol{\xi}_{i+1}, -1|\boldsymbol{\xi}_i, -1) = d, \tag{403}$$
$$A(\boldsymbol{\xi}_i, +1|\boldsymbol{\xi}_i, +1) = 1 - b - c, \tag{404}$$
$$A(\boldsymbol{\xi}_i, -1|\boldsymbol{\xi}_i, -1) = 1 - a - d. \tag{405}$$

如 图 29(b) 所示，我们发现该核只反转了等动量移动的概率流方向：空间移动现在与速度方向相反！可以由 (388) 验证，与 F_t 一样，核 A_t 也使 π_t 不变.

接下来引入反向核 R_t，定义为

$$R_t(\boldsymbol{\zeta}_{t-1}|\boldsymbol{\zeta}_t) \equiv F_t(\hat{\boldsymbol{\zeta}}_{t-1}|\hat{\boldsymbol{\zeta}}_t). \tag{406}$$

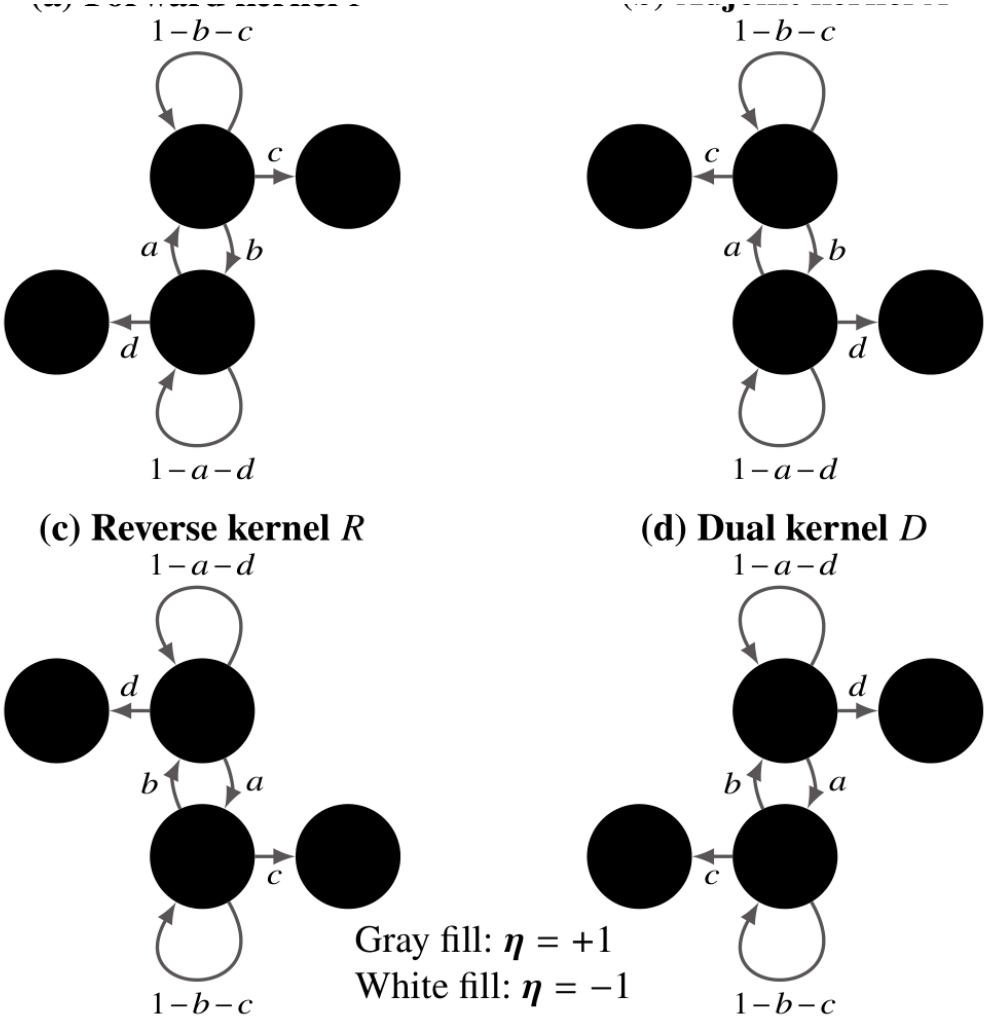
带帽量定义为 $\hat{\boldsymbol{\zeta}}_t = (\hat{\boldsymbol{\xi}}_t, \hat{\boldsymbol{\eta}}_t) = (\boldsymbol{\xi}_t, -\boldsymbol{\eta}_t)$；即它们反转动量（及任何其他奇变量）的方向. 在我们的例子中，核 R_t 如下所示（见 图 29(c)）：

$$R(\boldsymbol{\xi}_i, +1|\boldsymbol{\xi}_i, -1) = b, \tag{407}$$
$$R(\boldsymbol{\xi}_i, -1|\boldsymbol{\xi}_i, +1) = a, \tag{408}$$
$$R(\boldsymbol{\xi}_{i-1}, +1|\boldsymbol{\xi}_i, +1) = d, \tag{409}$$
$$R(\boldsymbol{\xi}_{i+1}, -1|\boldsymbol{\xi}_i, -1) = c, \tag{410}$$
$$R(\boldsymbol{\xi}_i, +1|\boldsymbol{\xi}_i, +1) = 1 - a - d, \tag{411}$$
$$R(\boldsymbol{\xi}_i, -1|\boldsymbol{\xi}_i, -1) = 1 - b - c. \tag{412}$$

重要的是，核 R_t 并不使 π_t 不变. 相反，它的不变分布为

$$\pi_R(\boldsymbol{\xi}_i, +1) = \frac{b}{L(a+b)}, \tag{413}$$
$$\pi_R(\boldsymbol{\xi}_i, -1) = \frac{a}{L(a+b)}, \tag{414}$$

其中 a 与 b 的角色互换了.



›mparison of the four Markov kernels for the circular state space mc

图 29: 圆环状态空间模型中四个马尔可夫核的比较. 状态按 $\boldsymbol{\eta} = +1$（灰填）在上排、$\boldsymbol{\eta} = -1$（白填）在下排排列. (a) 前向核 F：动量一致的空间转移所对应的物理演化. (b) 伴随核 A：在保持平稳分布 π_t 的同时反转概率流方向. (c) 反向核 R：由 F 中的动量反转得到，交换 $a \leftrightarrow b$ 与 $c \leftrightarrow d$. (d) 对偶核 D：结合动量反转与伴随变换，得到前向空间流但转移率被交换.

若我们希望 R_t 也保持原来的 π_t，就必须使它与 A_t 一致. 由 (389) 给出的 A_t 定义，这构成对 F_t 的约束：

$$\begin{aligned} R_t(\boldsymbol{\zeta}_{t-1}|\boldsymbol{\zeta}_t)\pi_t(\boldsymbol{\zeta}_t) &= A_t(\boldsymbol{\zeta}_{t-1}|\boldsymbol{\zeta}_t)\pi_t(\boldsymbol{\zeta}_t) \\ &= F_t(\hat{\boldsymbol{\zeta}}_{t-1}|\hat{\boldsymbol{\zeta}}_t)\pi_t(\boldsymbol{\zeta}_t) \\ &= F_t(\boldsymbol{\zeta}_t|\boldsymbol{\zeta}_{t-1})\pi_t(\boldsymbol{\zeta}_{t-1}). \end{aligned} \tag{415}$$

在例子中 across A_t 与 R_t 使对应项相等，得到 $a = b$ 且 $c = d$.

这一约束在物理中传统上称为细致平衡（detailed balance, DB），意思是任意两个 $\boldsymbol{\xi}$ 状态之间的概率流相等，因此平衡时没有净概率流. 注意，我们并不要求相空间中任

意两个状态之间的概率流相等，因为一旦速度固定，由于确定性转移，那是不可能的. 相反，我们希望正、负速度的流相互抵消.

在更近的论文中（例如 Spinney and Ford, 2012b; Lee et al., 2013），研究者指出，上述 DB 条件实际上可以拆分为两个陈述：(1) 平稳分布在 $\boldsymbol{\zeta} \to \hat{\boldsymbol{\zeta}}$ 下的时间反演对称性（TRS）（例子中即 $a = b$）；(2) 由以下条件给出的 DB：

$$F_t(\hat{\boldsymbol{\zeta}}_{t-1}|\hat{\boldsymbol{\zeta}}_t)\pi_t(\hat{\boldsymbol{\zeta}}_t) = F_t(\boldsymbol{\zeta}_t|\boldsymbol{\zeta}_{t-1})\pi_t(\boldsymbol{\zeta}_{t-1}), \tag{416}$$

在我们的例子中这只要求 $ac = bd$. 我们注意到，这种版本的 DB 由 (416) 的构造出发，导致概率流的平衡，因而使净概率流消失. 然而，它并不使 R_t 具有与 F_t 相同的不变分布. 反过来，π 的时间反演对称性（TRS）确实使 R_t 具有与 F_t 相同的平稳分布，但并不导致概率流的平衡. 我们现在证明 TRS 导致正确的不变分布：

$$\begin{aligned}
\int \mathrm{d}\boldsymbol{\zeta}_t\, R_t(\boldsymbol{\zeta}_{t-1}|\boldsymbol{\zeta}_t)\pi_t(\boldsymbol{\zeta}_t) &= \int \mathrm{d}\boldsymbol{\zeta}_t\, F_t(\hat{\boldsymbol{\zeta}}_{t-1}|\hat{\boldsymbol{\zeta}}_t)\pi_t(\boldsymbol{\zeta}_t) \\
&= \int \mathrm{d}\hat{\boldsymbol{\zeta}}_t\, F_t(\hat{\boldsymbol{\zeta}}_{t-1}|\hat{\boldsymbol{\zeta}}_t)\pi_t(\hat{\boldsymbol{\zeta}}_t) \\
&\qquad \text{（利用 } \pi_t \text{ 的 TRS 与 } \boldsymbol{\zeta} \to \hat{\boldsymbol{\zeta}} \text{ 的 Jacobian} = 1\text{）} \\
&= \pi_t(\hat{\boldsymbol{\zeta}}_{t-1}) = \pi_t(\boldsymbol{\zeta}_{t-1}) \qquad \text{（再次利用 } \pi_t \text{ 的 TRS）.}
\end{aligned} \tag{417}$$

9.2.1 对偶核

最后，我们现在可以定义 A_t 的反向版本，称之为对偶核（dual kernel）D_t，由在 A_t 中翻转动量来定义：

$$\begin{aligned}
D_t(\boldsymbol{\zeta}_t|\boldsymbol{\zeta}_{t-1}) &\equiv A_t(\hat{\boldsymbol{\zeta}}_t|\hat{\boldsymbol{\zeta}}_{t-1}) \\
&= \frac{F_t(\hat{\boldsymbol{\zeta}}_{t-1}|\hat{\boldsymbol{\zeta}}_t)\pi_t(\hat{\boldsymbol{\zeta}}_t)}{\pi_t(\hat{\boldsymbol{\zeta}}_{t-1})} \\
&= \frac{R_t(\boldsymbol{\zeta}_{t-1}|\boldsymbol{\zeta}_t)\pi_t(\hat{\boldsymbol{\zeta}}_t)}{\pi_t(\hat{\boldsymbol{\zeta}}_{t-1})}.
\end{aligned} \tag{418}$$

在我们的例子中，这给出 图 29(d) 所示的转移：

$$D(\boldsymbol{\xi}_i, +1|\boldsymbol{\xi}_i, -1) = b, \tag{419}$$
$$D(\boldsymbol{\xi}_i, -1|\boldsymbol{\xi}_i, +1) = a, \tag{420}$$
$$D(\boldsymbol{\xi}_{i+1}, +1|\boldsymbol{\xi}_i, +1) = d, \tag{421}$$
$$D(\boldsymbol{\xi}_{i-1}, -1|\boldsymbol{\xi}_i, -1) = c, \tag{422}$$
$$D(\boldsymbol{\xi}_i, +1|\boldsymbol{\xi}_i, +1) = 1 - a - d, \tag{423}$$
$$D(\boldsymbol{\xi}_i, -1|\boldsymbol{\xi}_i, -1) = 1 - b - c. \tag{424}$$

可以再次证明，核 D_t 与 R_t 保持 $\hat{\pi}(\boldsymbol{\zeta}) = \pi(\hat{\boldsymbol{\zeta}})$，而不一定保持 π_t. 然而，在平稳分布是时间反演对称（即 $\pi_t = \hat{\pi}_t$）的假设下，四个核 F, A, R, D 都保持 π_t 不变.

总结一下，我们总共定义了五个核：B, F, A, R, D. 这些核之间的关系如下：

1. F_t：前向核（物理演化），保持 π_t.

2. B_t：后向核（反扩散，(384)），依赖于 (ρ_{t-1}, ρ_t).

3. A_t：伴随核（概率流反转，(389)），保持 π_t.

4. R_t：反向核（动量反转，$R_t(\boldsymbol{\zeta}_{t-1}|\boldsymbol{\zeta}_t) = F_t(\hat{\boldsymbol{\zeta}}_{t-1}|\hat{\boldsymbol{\zeta}}_t)$），保持 $\hat{\pi}_t(\boldsymbol{\zeta}) = \pi_t(\hat{\boldsymbol{\zeta}})$.

5. D_t：对偶核（伴随 + 动量反转，(418)），保持 $\hat{\pi}_t$.

在这个列表中，核 B 是唯一去噪而非扩散的. 其余四个成对出现：$F \leftrightarrow A$ 使 π 不变，$R \leftrightarrow D$ 使 $\hat{\pi}$ 不变. 我们注意到 $B \to A$ 当 $\rho \to \pi$；即在平衡态.

为避免本书后续出现歧义，我们将一致地把 F_t 称为前向过程，把 B_t 称为后向（变分或推断）过程. 每当我们讨论动力学的物理时间反演——包括动量翻转与反转控制协议——时，就称之为时间反演过程，并用 R_t 表示其核. 这一术语将贯穿全书，包括我们对扩散模型、随机热力学与 Monte Carlo 方法的讨论.

这些核在我们研究第 10 章和第 17 章的涨落定理时会派上用场.

9.3 时间反演

时间反演对称性在热力学中扮演基础角色. 众所周知，从日常生活中我们对世界的经验并不是时间反演对称的（煎蛋卷自发变回鸡蛋，远比鸡蛋变成煎蛋卷不可能!）. 我们对时间单向性的感知正源于此. 微观时间反演不变的理论如何能导致不可逆过程，以及时间方向的概念，是一个极为深刻的问题. Boltzmann 本人曾就此与 Loschmidt 和 Zermelo 争论（Boltzmann, 1877, 1896; Brush, 1976; Lebowitz, 1993）. 这后来被称为 Loschmidt 佯谬（Loschmidt, 1876）.

因此，TRS 在宏观尺度上被破缺. 远离平衡时，反转时间方向会把扩散变成去噪，并翻转动量（或速度）的符号. 但即使是平稳分布在时间反演下也会变换，因为稳态中存在净概率流（或通量），它会反转方向. 只有在真正的平衡态、稳态中不再有剩余通量时，分布才真正时间反演对称.

9.3.1 Hamilton 系统的时间反演

我们现在先看微观层面 Hamilton 动力学的 TRS. 若状态的反转序列仍是演化方程的解，则称一条物理定律是时间反演对称的. 这一性质在微观层面适用于广泛的物理理论，包括经典力学与量子力学[2].

对于 Hamilton 系统，Hamilton 量本身在时间反演下保持不变，演化方程（Hamilton 动力学）亦然，因而代表前向与后向时间方向上同一条物理定律. 然而，位置与动量需区别对待. 位置在时间反演下保持不变，而动量必须翻转符号，即 $\boldsymbol{\eta}_\tau \to -\boldsymbol{\eta}_\tau$. 这是因为位置在时间反演下是偶变量（偶宇称），而动量是奇变量（奇宇称）. 这一结果是直观的：若我们不翻转符号，时间上向后运动就等于沿速度向量的反方向运动. 然而，若翻转速度或动量向量的符号，运动又重新成为物理的，沿速度向量方向前进. 我们还假设时间平移不变性，这意味着我们可以相对于任意固定时刻 τ 翻转时间方向.

[2]被认为在基本层面普遍成立的对称性是 CPT，即电荷–宇称–时间反演.

下面我们用波浪号表示时间反演：相对于最终时刻 τ_f 的时间反演为 $\tilde{\tau} = \tau_f - \tau$. 由于这是一个对合，由此可知量在时间反演下只能以两种方式变换：要么不变（偶），例如 $\tilde{\boldsymbol{\xi}}(\tau) = \boldsymbol{\xi}(\tilde{\tau})$；要么翻转符号（奇），例如 $\tilde{\boldsymbol{\eta}}(\tau) = -\boldsymbol{\eta}(\tilde{\tau})$. 如前所述，我们可以统一写成 $\tilde{\boldsymbol{\zeta}}(\tau) = \hat{\boldsymbol{\zeta}}(\tilde{\tau})$，其中帽号表示应翻转任何奇变量的符号. 奇量的另一个例子是磁场：$\tilde{\mathbf{B}}(\boldsymbol{\xi}, \tau) = -\mathbf{B}(\boldsymbol{\xi}, \tilde{\tau})$.

由这些变换规则，我们得到 $\tilde{\boldsymbol{\xi}}(\tilde{\tau}) = \boldsymbol{\xi}(\tau)$ 与 $\tilde{\boldsymbol{\eta}}(\tilde{\tau}) = -\boldsymbol{\eta}(\tau)$，合起来即 $\tilde{\boldsymbol{\zeta}}(\tilde{\tau}) = \hat{\boldsymbol{\zeta}}(\tau)$；再结合 $\partial_{\tilde{\tau}} = -\partial_\tau$ 以及 Hamilton 量在动量上为偶（即 $\mathcal{H}(\boldsymbol{\xi}, -\boldsymbol{\eta}) = \mathcal{H}(\boldsymbol{\xi}, \boldsymbol{\eta})$），我们可以导出 Hamilton 方程在时间反演下的不变性：

$$-\partial_{\tilde{\tau}}\tilde{\boldsymbol{\xi}}(\tilde{\tau}) = \frac{\partial \mathcal{H}(\tilde{\boldsymbol{\xi}}, -\tilde{\boldsymbol{\eta}})}{\partial(-\tilde{\boldsymbol{\eta}})}(\tilde{\tau}) \;\Rightarrow\; \partial_{\tilde{\tau}}\tilde{\boldsymbol{\xi}}(\tilde{\tau}) = \frac{\partial \mathcal{H}(\tilde{\boldsymbol{\xi}}, \tilde{\boldsymbol{\eta}})}{\partial \tilde{\boldsymbol{\eta}}}(\tilde{\tau}), \tag{425}$$

$$-\partial_{\tilde{\tau}}(-\tilde{\boldsymbol{\eta}}(\tilde{\tau})) = -\frac{\partial \mathcal{H}(\tilde{\boldsymbol{\xi}}, -\tilde{\boldsymbol{\eta}})}{\partial \tilde{\boldsymbol{\xi}}}(\tilde{\tau}) \;\Rightarrow\; \partial_{\tilde{\tau}}\tilde{\boldsymbol{\eta}}(\tilde{\tau}) = -\frac{\partial \mathcal{H}(\tilde{\boldsymbol{\xi}}, \tilde{\boldsymbol{\eta}})}{\partial \tilde{\boldsymbol{\xi}}}(\tilde{\tau}). \tag{426}$$

这表达了这样一个事实：若我们使用初始条件 $\tilde{\boldsymbol{\xi}}(0) = \boldsymbol{\xi}(\tau_f)$ 与 $\tilde{\boldsymbol{\eta}}(0) = -\boldsymbol{\eta}(\tau_f)$，则对每条前向路径都存在一条对应的后向路径. 若这些初始条件上的分布相等，我们就会观察到与后向路径一样多的前向路径. 显然，事实并非如此，因为我们清楚地看到时间上前向演化与后向演化的世界之间的差别. 图 30 示意了这一点.

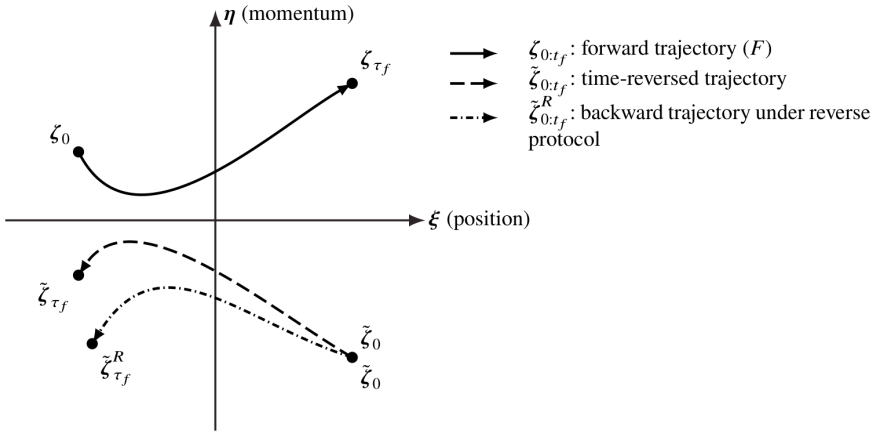


Figure 9.2 Trajectories in phase space. The solid curve $\zeta_{0:t_f}$ illustrates a forward path, the

图 30: 相空间中的轨迹. 实线 $\boldsymbol{\zeta}_{0:t_f}$ 展示一条前向路径，虚线 $\tilde{\boldsymbol{\zeta}}_{0:t_f}$ 展示其精确的时间反演，点划线 $\tilde{\boldsymbol{\zeta}}^R_{0:t_f}$ 表示由物理反向协议（例如核 R_t）生成的典型后向轨迹. 尽管 $\tilde{\boldsymbol{\zeta}}_{0:t_f}$ 与 $\tilde{\boldsymbol{\zeta}}^R_{0:t_f}$ 从同一状态出发，后者通常沿反向动力学中概率更大的路径行进.

9.3.2 马尔可夫过程的时间反演

现在来看由随机马尔可夫链描述的粗粒化系统的 TRS. 下面我们把上一节导出的方程与时间反演变换联系起来. 首先引入记号：我们再次用波浪号表示时间反演，用帽号

表示奇变量的符号翻转：

$$\begin{aligned}\tilde{\rho}(\boldsymbol{\zeta}_0,\dots,\boldsymbol{\zeta}_{t_f}) &= \rho(\tilde{\boldsymbol{\zeta}}_0,\dots,\tilde{\boldsymbol{\zeta}}_{t_f}) = \rho(\hat{\boldsymbol{\zeta}}_0,\dots,\hat{\boldsymbol{\zeta}}_{t_f}) = \rho(\hat{\boldsymbol{\zeta}}_{t_f},\dots,\hat{\boldsymbol{\zeta}}_0)\\ &= \rho(\boldsymbol{\xi}_{t_f},-\boldsymbol{\eta}_{t_f},\dots,\boldsymbol{\xi}_0,-\boldsymbol{\eta}_0), \qquad (427)\\ \tilde{\rho}_t(\boldsymbol{\zeta}_t) &= \rho_{\tilde{t}}(\tilde{\boldsymbol{\zeta}}_t) = \rho_{\tilde{t}}(\hat{\boldsymbol{\zeta}}_{\tilde{t}}) = \rho_{t_f-t}(\hat{\boldsymbol{\zeta}}_{t_f-t}) = \rho_{t_f-t}(\boldsymbol{\xi}_{t_f-t},-\boldsymbol{\eta}_{t_f-t}). \qquad (428)\end{aligned}$$

我们使用的记号由此从密度级联到相空间变量，再到时间与动量反演.

现在，考虑过程由时变参数 $\boldsymbol{\lambda}_0,\dots,\boldsymbol{\lambda}_{t_f}$ 控制的情形. 密度 $\rho_{0:t_f}$ 因而依赖于这些参数. 与动量一样，这些参数中的某些，如自旋或磁场，在时间反演下可能为奇变换. 然而下面我们不需要这一点. 对于反向协议，我们用 $\hat{\boldsymbol{\lambda}}_t$ 表示沿反向时间表在时刻 t 的宇称翻转控制参数；通常 $\tilde{\boldsymbol{\lambda}}_t \equiv \tilde{\boldsymbol{\lambda}}_{t_f-t+1}$.

参数与初始分布 ($\boldsymbol{\lambda}_0$) 以及转移 $F(\boldsymbol{\zeta}_t|\boldsymbol{\zeta}_{t-1},\boldsymbol{\lambda}_t)$ 相关联. 这意味着我们也可以把它们赋予边缘平稳分布 $\pi(\boldsymbol{\zeta}_t|\boldsymbol{\lambda}_t)$. 由于马尔可夫链会遗忘过去，若我们在固定参数值 $\boldsymbol{\lambda}_t$ 下运行链足够长时间，平稳分布只依赖于该参数. 但我们注意，一般而言，不处于稳态的边缘分布依赖于所有参数的完整历史. 总结一下，我们有

$$\begin{aligned}F_t(\boldsymbol{\zeta}_t|\boldsymbol{\zeta}_{t-1}) &\equiv F(\boldsymbol{\zeta}_t|\boldsymbol{\zeta}_{t-1},\boldsymbol{\lambda}_t), \qquad (429)\\ \pi_t(\boldsymbol{\zeta}_t) &\equiv \pi(\boldsymbol{\zeta}_t|\boldsymbol{\lambda}_t), \qquad (430)\\ \rho_t(\boldsymbol{\zeta}_t) &= \rho(\boldsymbol{\zeta}_t|\boldsymbol{\lambda}_0,\dots,\boldsymbol{\lambda}_t). \qquad (431)\end{aligned}$$

在时间反演下，我们现在从最终（边缘）分布 $\rho_{t_f}(\hat{\boldsymbol{\zeta}}_{t_f})$ 出发，并反向施加控制协议. 我们不会用 B_{t_f} 向后转移，那确实会通过反扩散把电影倒放. 相反，我们将使用时间反演的前向过程，对任意时刻 t 定义为 $F(\hat{\boldsymbol{\zeta}}_{t-1}|\hat{\boldsymbol{\zeta}}_t,\hat{\boldsymbol{\lambda}}_{t_f})$. 这就是前向核 F_{t_f}，但所有参数都被反转（且带帽）. 更一般地，与前一节的定义一致，我们定义

$$\begin{aligned}R_t(\boldsymbol{\zeta}_{t-1}|\boldsymbol{\zeta}_t) &\equiv F(\hat{\boldsymbol{\zeta}}_{t-1}|\hat{\boldsymbol{\zeta}}_t,\hat{\boldsymbol{\lambda}}_t), \qquad (432)\\ \hat{\pi}(\boldsymbol{\zeta}_t) &\equiv \pi(\boldsymbol{\zeta}_t|\hat{\boldsymbol{\lambda}}_t). \qquad (433)\end{aligned}$$

这里以及 (432) 中的帽号只表示宇称翻转. 我们选择用指标 t 而非 $t-1$ 来标记核 R_t，因为它依赖于 $\boldsymbol{\lambda}_t$（而不依赖于 $\boldsymbol{\lambda}_{t-1}$）. 这使其与稳态分布 $\hat{\pi}_t$ 一致.

我们说一个物理过程是时间反演对称的，若前向与时间反演概率相等. 换言之，我们想断言：以时间反演方向观察该过程的概率，与原过程相等. 任何产生熵的过程都不会满足这一条件，因为热力学第二定律. 然而，在达到平稳态之后，即使在宏观上这也可能成立. 我们可以在任意时刻 t 施加这一要求，但必须记住我们使用带相同参数 $\boldsymbol{\lambda}_t$ 的 F_t；即 π_t 是用相同参数 $\boldsymbol{\lambda}_t$ 多次施加 F_t 得到的平稳分布. 于是我们有如下 TRS 条件：

$$\pi_t(\boldsymbol{\zeta}_{t-1})F_t(\boldsymbol{\zeta}_t|\boldsymbol{\zeta}_{t-1}) = \pi_t(\hat{\boldsymbol{\zeta}}_t)F_t(\hat{\boldsymbol{\zeta}}_{t-1}|\hat{\boldsymbol{\zeta}}_t). \qquad (434)$$

这说明没有净概率流，但它并不意味着 π_t 在动量 $\boldsymbol{\eta}$ 上对称. 我们需要单独强制 $\pi(\boldsymbol{\zeta}) = \pi(\hat{\boldsymbol{\zeta}})$.

现在把时间反演算符施加到 (387) 上，得到一个有趣的关系. 从

$$\pi_{\tilde{t}}(\hat{\boldsymbol{\zeta}}_{\tilde{t}-1})F_{\tilde{t}}(\hat{\boldsymbol{\zeta}}_{\tilde{t}}|\hat{\boldsymbol{\zeta}}_{\tilde{t}-1}) = \pi_{\tilde{t}}(\hat{\boldsymbol{\zeta}}_{\tilde{t}})A_{\tilde{t}}(\hat{\boldsymbol{\zeta}}_{\tilde{t}-1}|\hat{\boldsymbol{\zeta}}_{\tilde{t}}) \qquad (435)$$

出发，这非常乱！为整理它，我们注意到 $\tilde{t}-1=t_f-(t-1)=(t_f-t)+1=\tilde{t}+1$. 我们还注意到方程对任意 $\tilde{t}$ 成立，因此可以任意平移时间，并把处处的 $\tilde{t}$ 替换为 $t-1$:

$$\pi_{t-1}(\hat{\boldsymbol{\zeta}}_t)F_{t-1}(\hat{\boldsymbol{\zeta}}_{t-1}|\hat{\boldsymbol{\zeta}}_t)=\pi_{t-1}(\hat{\boldsymbol{\zeta}}_{t-1})A_{t-1}(\hat{\boldsymbol{\zeta}}_t|\hat{\boldsymbol{\zeta}}_{t-1}), \tag{436}$$

$$\pi_{t-1}(\hat{\boldsymbol{\zeta}}_t)R_{t-1}(\boldsymbol{\zeta}_{t-1}|\boldsymbol{\zeta}_t)=\pi_{t-1}(\hat{\boldsymbol{\zeta}}_{t-1})D_{t-1}(\boldsymbol{\zeta}_t|\boldsymbol{\zeta}_{t-1}), \tag{437}$$

这与我们在 (418) 中 D_t 的定义相等. 因此，我们通过时间反演，由 F_t 与 A_t 之间的关系导出了 D_t 与 R_t 之间的关系.

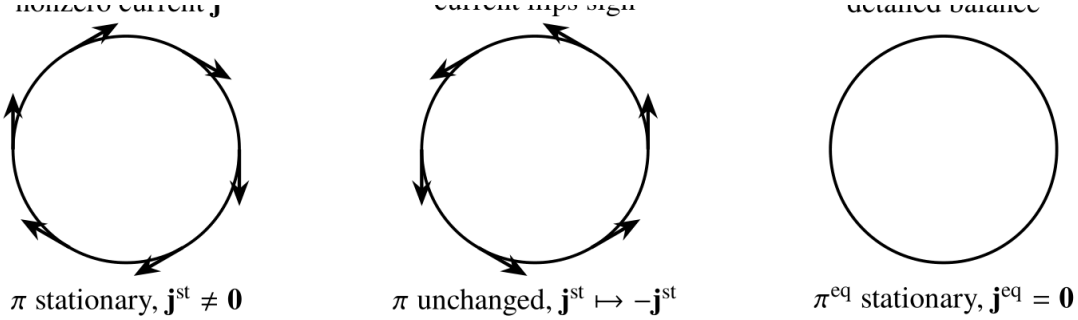


Figure 9.3 Probability currents under time reversal. In a nonequilibrium steady state (NESS)

图 31: 时间反演下的概率流. 在非平衡稳态（NESS）中，平稳分布 π^{st} 与绕环的非零流 $\mathbf{j}^{\mathrm{st}}$ 共存（面板 a，箭头顺时针）. 时间反演下，分布 π 不变，而流翻转符号（面板 b，箭头逆时针）. 平衡时，细致平衡强制净流为零（面板 c，无箭头的圆）.

Chapter 10

随机热力学

10.1 引言

我们已经到达本书的核心. 本章将概述随机热力学 (stochastic thermodynamics) 这一领域. 你将学习非平衡热力学; 因此这纯粹是一章物理. 我们将引入新的基于轨迹的量, 例如单条轨迹的熵、功或热. 我们展示热、功、系统熵、热浴熵与能量在轨迹水平上如何紧密相关, 以及热力学第二定律如何作为平均结果出现、但在轨迹水平上 (以极低概率) 可以被违反. 这些结果与不可逆性 (例如时间反演对称性的破缺) 和涨落定理等概念深刻相关. 本章讨论的概念将构成本书后续内容的基础.

10.2 随机热力学

随机热力学是一个把第 3 章所涵盖的经典热力学扩展到涨落起重要作用的小系统的框架. 它植根于 Sekimoto (2010)、Jarzynski (1997, 2011)、Crooks (1998, 1999, 2000) 和 Seifert (2012) 等人的开创性工作, 仅举几例. 它们为在单条轨迹与涨落水平上理解热力学奠定了基础. 本章将引入随机热力学中与机器学习特别相关的基本概念与工具.

10.3 随机过程

随机过程是按时间索引的随机变量集合, 处于随机热力学与机器学习两者的核心. 随机过程是描述受随机涨落影响的系统演化的数学模型. 在随机热力学中, 它们表示受随机涨落影响的物理系统的演化, 并产生各种非平衡现象. 类似地, 在机器学习中, 随机过程被用于建模各种系统的动力学, 例如生成模型中隐变量的演化, 或第 11 章引入的 MCMC 算法中的采样过程.

与两个领域都相关的随机过程例子包括离散时间与连续时间马尔可夫过程 (例如将在第 11 章讨论的 Langevin 与 Hamiltonian Monte Carlo 动力学), 以及由主方程描述的离散状态系统的动力学. 这些过程建模了从流体中粒子运动到生成图像的扩散模型中隐变量演化的广泛范围的系统. 为了为探索随机热力学与机器学习之间的联系奠定基础, 我们将从讨论两个关键例子开始: Hamilton 系统与离散时间马尔可夫过程. 完整的连续时间处理需要随机微积分, 将留待另一本书.

10.3.1 记号

为在整个讨论中保持清晰与一致, 我们将对物理量与变量采用特定记号. 希腊字母用于表示这些实体, 其中 $\boldsymbol{\zeta}_t = (\boldsymbol{\xi}_t, \boldsymbol{\eta}_t)$ 表示时刻 t 物理动力学的相空间变量, $\boldsymbol{\xi}_t$ 是位置变量, $\boldsymbol{\eta}_t$ 是时刻 t 的动量变量. $\boldsymbol{\zeta}_t$ 是动力学过程从 $t = 0$ 到 $t = t_f$ 的轨迹上时刻 t 的相空间变量: $\boldsymbol{\zeta}_{0:t_f} = (\boldsymbol{\zeta}_0, \ldots, \boldsymbol{\zeta}_{t_f})$. 此外, $\rho_t(\boldsymbol{\zeta}_t)$ 表示时刻 t 相空间中的 (边缘) 概率密

度函数. 注意 ρ_t 在演化，因而随时间变化；换言之，它（通常）不处于平衡态. 整条路径上的联合密度记为 $\rho(\boldsymbol{\zeta}_{0:t_f}) = \rho(\boldsymbol{\zeta}_0, \ldots, \boldsymbol{\zeta}_{t_f})$. 我们还将采用第 9 章的记号，帽号（如 $\hat{\boldsymbol{\zeta}}_t = (\boldsymbol{\xi}_t, -\boldsymbol{\eta}_t)$）表示奇变量（如动量）的反转，波浪号表示路径或协议上的完整时间反演操作.

10.3.2 Hamilton 系统

在物理中，许多系统的动力学由 Hamiltonian $\mathcal{H}(\boldsymbol{\zeta})$ 支配，其中 $\boldsymbol{\zeta} = (\boldsymbol{\xi}, \boldsymbol{\eta})$ 表示相空间中的系统状态，$\boldsymbol{\xi}$ 表示位置，$\boldsymbol{\eta}$ 表示动量. Hamilton 量可被视为系统的能量函数，它决定位置与动量如何随时间演化. Hamilton 量的一种常见形式为

$$\mathcal{H}(\boldsymbol{\zeta}) = \mathcal{H}(\boldsymbol{\xi}, \boldsymbol{\eta}) = \frac{1}{2m}\|\boldsymbol{\eta}\|^2 + V(\boldsymbol{\xi}), \tag{438}$$

其中 m 是粒子质量，$V(\boldsymbol{\xi})$ 是势能函数. Hamilton 量的第一项表示粒子的动能，第二项表示粒子间相互作用与外力所产生的势能.

运动方程由 Hamilton 方程给出：

$$\partial_\tau \boldsymbol{\xi}(\tau) = \frac{\partial \mathcal{H}(\boldsymbol{\xi}, \boldsymbol{\eta})}{\partial \boldsymbol{\eta}}(\tau), \qquad \boldsymbol{\xi}(0) = \boldsymbol{\xi}_0, \tag{439}$$

$$\partial_\tau \boldsymbol{\eta}(\tau) = -\frac{\partial \mathcal{H}(\boldsymbol{\xi}, \boldsymbol{\eta})}{\partial \boldsymbol{\xi}}(\tau), \qquad \boldsymbol{\eta}(0) = \boldsymbol{\eta}_0, \tag{440}$$

其中 τ 表示物理时间.

Hamilton 演化是确定性的，这意味着给定粒子的初始位置与动量，系统的未来状态可以被精确确定. 然而，Hamilton 系统在随机热力学中仍极有意义，因为它们可以对系统–热浴的联合动力学建模，通过积分掉热浴变量而把随机性引入系统（Jarzynski, 2000）.

注意，多粒子的 Hamilton 动力学是高度混沌的，这意味着即使我们以高（但有限）精度知道整个系统的初始状态，由于粒子轨迹对初始条件的敏感性，我们将不可避免地失去对其精确值的追踪. 对于热浴，当我们积分掉其自由度后，所考虑的系统粒子会接收到热浴中粒子的随机撞击，使动力学成为随机的. 这是我们作为宏观观测者会丢失关于系统变量 $\boldsymbol{\zeta}_t$ 详细状态信息的另一个原因. 正是这种丢失关于系统详细状态信息的过程导致了热力学第二定律，即熵（量化我们正在丢失多少信息）平均而言总是增加.

10.3.3 离散时间马尔可夫过程

离散时间马尔可夫过程是一个随机变量序列 $\{\boldsymbol{\zeta}_t\}_{t=0}^{t_f}$，其中 t 表示离散时间步，$\boldsymbol{\zeta}_t$ 取值于状态空间.[3] 重要的是要认识到，“时间” t 不是物理时间，而是离散计数指标. 为区分二者，我们用 τ 表示物理时间. 每个时间指标 t 对应于某个物理时间 $\tau(t)$，时间演化映射为 $\tau(t) \to \tau(t+1) = \tau(t) + \delta\tau$. 图 32 示意了把连续物理时间离散化为离散马尔可夫步的过程.

[3]对于离散状态空间，本章中所有对 $\boldsymbol{\zeta}$ 的积分都应理解为求和.

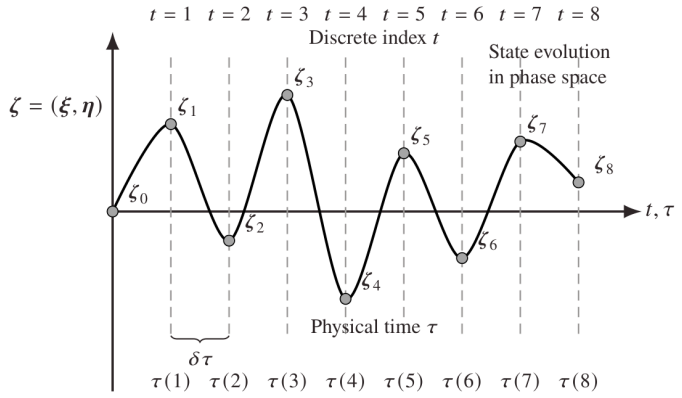


Figure 10.1 Discretization of continuous-time evolution into a Markov process, where each

图 32: 把连续时间演化离散化为马尔可夫过程，其中每次转移只依赖于当前状态. 光滑实线展示系统状态 $\boldsymbol{\zeta}_t$ 在相空间中的演化，圆形标记指示每个离散时间步的状态. 状态按规则物理时间间隔 $\delta\tau$ 离散化，上方显示离散指标 t，下方显示相应物理时间 $\tau(t)$.

（随机）马尔可夫过程的定义性质是：未来状态 $\boldsymbol{\zeta}_{t+1}$ 的概率分布只依赖于当前状态 $\boldsymbol{\zeta}_t$，而不依赖于一旦我们知道 $\boldsymbol{\zeta}_t$ 之后过程的历史（即过去的所有信息都被概括在当前状态 $\boldsymbol{\zeta}_t$ 中）. 这一性质称为马尔可夫性，使我们可以用状态之间的转移概率来描述系统的演化，由条件（前向）转移概率分布 $F_t(\boldsymbol{\zeta}_t|\boldsymbol{\zeta}_{t-1})$ 给出. 这个物理过渡核依赖于控制参数 $\boldsymbol{\lambda}_t$. 然而，这会在记号中产生大量冗余，因为我们将识别

$$F_t(\boldsymbol{\zeta}_t|\boldsymbol{\zeta}_{t-1}) = F(\boldsymbol{\zeta}_t|\boldsymbol{\zeta}_{t-1}, \boldsymbol{\lambda}_t). \tag{441}$$

为热力学一致性，我们稍后将假设：对任意固定控制参数 $\boldsymbol{\lambda}_t$，该核是遍历的，并具有唯一的平稳分布 π_t，对应于 Hamiltonian $\mathcal{H}_t$ 的 Boltzmann 分布.

我们可以按如下过程根据马尔可夫链模拟路径：

$$\boldsymbol{\zeta}_0 \sim \rho_0(\cdot), \tag{442}$$

$$\boldsymbol{\zeta}_1 \sim F_1(\cdot|\boldsymbol{\zeta}_0), \tag{443}$$

$$\vdots$$

$$\boldsymbol{\zeta}_{t_f} \sim F_{t_f}(\cdot|\boldsymbol{\zeta}_{t_f-1}). \tag{444}$$

状态空间中一条路径 $(\boldsymbol{\zeta}_0, \ldots, \boldsymbol{\zeta}_{t_f})$ 的联合概率密度为

$$\rho_{0:t_f}(\boldsymbol{\zeta}_0, \boldsymbol{\zeta}_1, \ldots, \boldsymbol{\zeta}_{t_f}) = \rho_0(\boldsymbol{\zeta}_0) \prod_{t=1}^{t_f} F_t(\boldsymbol{\zeta}_t|\boldsymbol{\zeta}_{t-1}), \tag{445}$$

其中 $\rho_0(\boldsymbol{\zeta}_0)$ 是状态 $\boldsymbol{\zeta}_0$ 的初始概率密度. 下面我们常略去下标 “0”，简记 t_f.

若 Hamiltonian 与时间无关（即我们不通过外部控制对系统做功），则转移概率也与时间无关. 然而，即使假设转移概率是时间齐次的，边缘概率密度 $\rho_t(\boldsymbol{\zeta}_t)$ 仍可依赖于 t.

如上所述，过渡核 F_t 也可以是时变的，例如当过程由外部智能体通过参数 $\{\boldsymbol{\lambda}_0, \ldots, \boldsymbol{\lambda}_{t_f}\}$ 控制时.

马尔可夫过程是我们研究粗粒化变量上概率分布时的一种近似. 通常，下一状态（密度）依赖于过去所有状态. 在那种情形下，我们说过程有 “记忆”. 然而，若快过程（如碰撞）与慢过程（分子中原子的运动）之间的时间尺度差异很大，则马尔可夫假设通常非常好. 在那种情形下，随机（Brown）噪声为建模复杂系统提供了非常好的近似.

10.4 热力学量

记号

下面，我们用方括号 $[\cdot]$ 表示一个量是概率分布的泛函，而圆括号 $(\cdot)$ 表示该量是某个具体实现或微观态的函数. 对于单时间量，$\mathcal{A}[\rho]$ 表示概率分布 $\rho(\boldsymbol{\zeta})$ 的泛函，而 $\mathcal{A}(\boldsymbol{\zeta})$ 或 $\mathcal{A}[\rho](\boldsymbol{\zeta})$ 表示具体微观态 $\boldsymbol{\zeta}$ 的函数. 类似地，对于依赖轨迹的量，$\mathcal{A}[\rho_{0:t_f}]$ 表示轨迹概率分布 $\rho(\boldsymbol{\zeta}_{0:t_f})$ 的泛函，而 $\mathcal{A}(\boldsymbol{\zeta}_{0:t_f})$ 或 $\mathcal{A}[\rho_{0:t_f}](\boldsymbol{\zeta}_{0:t_f})$ 表示具体轨迹实现 $\boldsymbol{\zeta}_{0:t_f}$ 的函数. 当上下文清楚时，我们可以略去方括号，直接写 $\mathcal{A}$ 来表示在相关概率分布上的平均量，并用 $\mathbb{E}[\mathcal{A}(\boldsymbol{\zeta})] = \mathbb{E}_\rho[\mathcal{A}(\boldsymbol{\zeta})]$ 或 $\mathbb{E}[\mathcal{A}(\boldsymbol{\zeta}_{0:t_f})] = \mathbb{E}_\rho[\mathcal{A}(\boldsymbol{\zeta}_{0:t_f})]$.

内能

内能 $\mathcal{U}[\rho]$ 定义为 Hamiltonian $\mathcal{H}(\boldsymbol{\zeta})$ 关于概率密度 $\rho(\boldsymbol{\zeta})$ 的期望值：

$$\mathcal{U}[\rho] = \int \mathrm{d}\boldsymbol{\zeta}\, \rho(\boldsymbol{\zeta})\mathcal{H}(\boldsymbol{\zeta}) = \mathbb{E}_\rho[\mathcal{H}(\boldsymbol{\zeta})]. \tag{446}$$

这里 $\mathcal{H}(\boldsymbol{\zeta})$ 是具体微观态 $\boldsymbol{\zeta}$ 下系统的内能，有时也称为随机内能.

熵

熵是连接热力学与信息论世界的基本概念. 它量化系统中不确定性或惊讶（意外）的程度，以比特为单位度量隐藏或不可访问的信息量. 取 Boltzmann 常数 $k_B = 1$，事件 $\boldsymbol{\zeta}$ 的随机熵定义为

$$\mathcal{S}[\rho](\boldsymbol{\zeta}) = -\log \rho(\boldsymbol{\zeta}), \tag{447}$$

它度量若事件 $\boldsymbol{\zeta}$ 发生我们有多惊讶. 概率分布 $\rho(\boldsymbol{\zeta})$ 的熵则由随机熵的统计平均给出：

$$\mathcal{S}[\rho] = -\int \mathrm{d}\boldsymbol{\zeta}\, \rho(\boldsymbol{\zeta}) \log \rho(\boldsymbol{\zeta}) = \mathbb{E}_\rho[-\log \rho(\boldsymbol{\zeta})]. \tag{448}$$

原则上，世界只处于一个状态，但由于我们无法显式建模所有自由度，我们在（随机）变量上引入概率分布. 熵是我们对系统实际微观态遗忘了多少的度量.

除了某一时刻分布的熵 $\mathcal{S}[\rho_t]$ 与状态的熵 $\mathcal{S}[\rho_t](\boldsymbol{\zeta}_t)$，我们还可以定义轨迹 $\boldsymbol{\zeta}_{0:t_f} = (\boldsymbol{\zeta}_0, \ldots, \boldsymbol{\zeta}_{t_f})$ 的（随机）熵：

$$\mathcal{S}[\rho_{0:t_f}] = -\int \mathrm{d}\boldsymbol{\zeta}_{0:t_f}\, \rho(\boldsymbol{\zeta}_{0:t_f}) \log \rho(\boldsymbol{\zeta}_{0:t_f}) = \mathbb{E}_{\rho_{0:t_f}}[-\log \rho(\boldsymbol{\zeta}_{0:t_f})], \tag{449}$$

其中 $\rho(\boldsymbol{\zeta}_{0:t_f})$ 是轨迹的概率密度（离散时间马尔可夫轨迹由 (445) 给出）.

自由能

自由能是结合能量与熵概念的热力学量. 随机自由能 $\mathcal{F}(\boldsymbol{\zeta})$ 定义为

$$\mathcal{F}(\boldsymbol{\zeta}) = \mathcal{H}(\boldsymbol{\zeta}) - T\mathcal{S}(\boldsymbol{\zeta}) = \mathcal{H}(\boldsymbol{\zeta}) + T\log\rho(\boldsymbol{\zeta}), \tag{450}$$

其中 T 是热浴温度. 平均自由能泛函 $\mathcal{F}[\rho]$ 则由随机自由能在概率密度 $\rho(\boldsymbol{\zeta})$ 上取平均得到:

$$\mathcal{F}[\rho] = \mathbb{E}_\rho[\mathcal{F}(\boldsymbol{\zeta})] = \mathcal{U}[\rho] - T\mathcal{S}[\rho], \tag{451}$$

其中 $\mathcal{U}[\rho] = \mathbb{E}_\rho[\mathcal{H}(\boldsymbol{\zeta})]$ 是内能，$\mathcal{S}[\rho] = -\mathbb{E}_\rho[\log\rho(\boldsymbol{\zeta})]$ 是熵.

自由能泛函 $\mathcal{F}[\rho]$ 由平衡概率密度 $\rho^{\mathrm{eq}}(\boldsymbol{\zeta})$ 最小化，后者可由在归一化约束下求解变分问题 $\delta\mathcal{F}/\delta\rho = 0$ 得到:

$$\rho^{\mathrm{eq}}(\boldsymbol{\zeta}) = \frac{1}{Z}e^{-\beta\mathcal{H}(\boldsymbol{\zeta})}, \qquad Z = \int \mathrm{d}\boldsymbol{\zeta}\, e^{-\beta\mathcal{H}(\boldsymbol{\zeta})}, \tag{452}$$

其中 $\beta = 1/T$ 是逆温度，Z 是配分函数. 平衡时，自由能化为熟悉的表达式 $\mathcal{F}^{\mathrm{eq}} = F = -T\log Z$. 然而，$\mathcal{U}[\rho]$、$\mathcal{S}[\rho]$ 与 $\mathcal{F}[\rho]$ 所有这些量不仅对平衡系统、也对非平衡系统定义. 因此，非平衡自由能是平衡系统通常自由能定义的自然推广.

10.5 随机热力学第一定律

热力学第一定律指出，系统内能的变化 $\Delta\mathcal{U}$ 等于对系统做的功 $\mathcal{W}$ 与系统吸收的热 $\mathcal{Q}$ 之和:

$$\Delta\mathcal{U} = \mathcal{W} + \mathcal{Q}. \tag{453}$$

在随机热力学设定下，第一定律被推广到对单条轨迹成立:

$$\Delta\mathcal{U}(\boldsymbol{\zeta}_{0:t_f}) = \mathcal{W}(\boldsymbol{\zeta}_{0:t_f}) + \mathcal{Q}(\boldsymbol{\zeta}_{0:t_f}). \tag{454}$$

这一扩展使我们能在单条涨落与稀有事件的水平上分析系统的（非平衡）热力学性质.

10.5.1 Hamilton 系统

在 Hamilton 系统中，随机功 $\mathcal{W}(\boldsymbol{\zeta}_{0:t_f})$ 解释了由于外部参数 $\lambda(\tau)$ 的显式时间依赖而导致的 Hamiltonian 变化. 对于连续时间 Hamilton 系统，随机功由 Hamiltonian 关于（物理）时间的偏导数的积分给出:

$$\mathcal{W}(\boldsymbol{\zeta}_{0\to\tau_f}) = \int \delta\mathcal{W} = \int_0^{\tau_f} \mathrm{d}\tau\, \frac{\partial\mathcal{H}(\boldsymbol{\zeta},\tau;\lambda)}{\partial\lambda}\frac{\mathrm{d}\lambda}{\mathrm{d}\tau}, \tag{455}$$

其中 λ 是协议的功参数，$\frac{\mathrm{d}\lambda}{\mathrm{d}\tau}$ 是 λ 的（物理）时间导数.

对于离散时间过程，随机功与热可视为连续时间版本 (455) 的离散化. 考虑一个初始处于状态 $\boldsymbol{\zeta}_0$、时刻 $t = 0$ 的系统，其 Hamiltonian 为 $\mathcal{H}_0(\boldsymbol{\zeta}_0)$. 我们可以把时间演化分为两步，这可视为底层连续动力学的 Trotter–Suzuki 或算符分裂:

1. 通过把 Hamiltonian 更新为 $\mathcal{H}_1$，使系统离开平衡. 这一步需要对系统做功 $\delta\mathcal{W}_1 = \mathcal{H}_1(\boldsymbol{\zeta}_0) - \mathcal{H}_0(\boldsymbol{\zeta}_0)$.

2. 让系统在恒定 Hamiltonian $\mathcal{H}_1$ 下从 $\boldsymbol{\zeta}_0$ 弛豫到 $\boldsymbol{\zeta}_1$. 在此步中，系统从热浴吸收热 $\delta\mathcal{Q}_1 = \mathcal{H}_1(\boldsymbol{\zeta}_1) - \mathcal{H}_1(\boldsymbol{\zeta}_0)$.

把这两步过程重复 t_f 步，我们得到对系统做的总功 $\mathcal{W}(\boldsymbol{\zeta}_{0:t_f})$ 与系统吸收的总热 $\mathcal{Q}(\boldsymbol{\zeta}_{0:t_f})$：

$$\mathcal{W}(\boldsymbol{\zeta}_{0:t_f}) = \sum_{t=1}^{t_f} \delta\mathcal{W}_t = \sum_{t=1}^{t_f} \big[\mathcal{H}_t(\boldsymbol{\zeta}_{t-1}) - \mathcal{H}_{t-1}(\boldsymbol{\zeta}_{t-1})\big], \tag{456}$$

$$\mathcal{Q}(\boldsymbol{\zeta}_{0:t_f}) = \sum_{t=1}^{t_f} \delta\mathcal{Q}_t = \sum_{t=1}^{t_f} \big[\mathcal{H}_t(\boldsymbol{\zeta}_t) - \mathcal{H}_t(\boldsymbol{\zeta}_{t-1})\big]. \tag{457}$$

由 (456) 与 (457) 可见，随机功与热是路径依赖函数. 然而，它们的和给出内能的总变化 $\Delta\mathcal{U}(\boldsymbol{\zeta}_{0:t_f})$：

$$\Delta\mathcal{U}(\boldsymbol{\zeta}_{0:t_f}) = \mathcal{Q}(\boldsymbol{\zeta}_{0:t_f}) + \mathcal{W}(\boldsymbol{\zeta}_{0:t_f}) = \mathcal{H}_{t_f}(\boldsymbol{\zeta}_{t_f}) - \mathcal{H}_0(\boldsymbol{\zeta}_0), \tag{458}$$

它只依赖于系统的初始与最终状态，使其成为状态函数.

(458) 是离散时间 Hamilton 系统热力学第一定律的随机版本，对每条单独轨迹 $\boldsymbol{\zeta}_{0:t_f}$ 成立. 传统第一定律 (453) 由随机第一定律 (458) 在所有可能轨迹上取平均而恢复：

$$\mathbb{E}_\rho[\Delta\mathcal{U}(\boldsymbol{\zeta}_{0:t_f})] = \mathbb{E}_\rho[\mathcal{Q}(\boldsymbol{\zeta}_{0:t_f})] + \mathbb{E}_\rho[\mathcal{W}(\boldsymbol{\zeta}_{0:t_f})]. \tag{459}$$

时间反演过程 为进一步深入理解系统的热力学性质，考虑上述过程的时间反演是有益的. 如第 9 章与记号小节所述，我们用帽号翻转奇变量，用波浪号表示时间反演，因此将考虑 $\tilde{\boldsymbol{\zeta}}_t$、$\tilde{\mathcal{H}}_t$、$\tilde{\mathcal{Q}}_t$ 和 $\tilde{\mathcal{W}}_t$ 等时间反演量. 在时间反演过程中，我们从 $\tilde{t} = \tilde{0}$ 出发，系统在 Hamiltonian $\tilde{\mathcal{H}}_0 = \mathcal{H}_{t_f}$ 下处于状态 $\tilde{\boldsymbol{\zeta}}_0 = \hat{\boldsymbol{\zeta}}_{t_f}$（这里假设 Hamiltonian $\mathcal{H}$ 在奇动量翻转为偶），然后施加反转协议. 时间反演过程中的第一项贡献是热，它等于前向过程弛豫步骤 2 中释放的热的负值：

$$\begin{aligned}
\delta\tilde{\mathcal{Q}}_1 &= \tilde{\mathcal{H}}_0(\tilde{\boldsymbol{\zeta}}_1) - \tilde{\mathcal{H}}_0(\tilde{\boldsymbol{\zeta}}_0) \\
&= \mathcal{H}_{t_f}(\hat{\boldsymbol{\zeta}}_{t_f-1}) - \mathcal{H}_{t_f}(\hat{\boldsymbol{\zeta}}_{t_f}) \\
&= \mathcal{H}_{t_f}(\boldsymbol{\zeta}_{t_f-1}) - \mathcal{H}_{t_f}(\boldsymbol{\zeta}_{t_f}) \qquad (\text{假设 } \mathcal{H}_{t_f}(\hat{\boldsymbol{\zeta}}) = \mathcal{H}_{t_f}(\boldsymbol{\zeta})) \\
&= -\big[\mathcal{H}_{t_f}(\boldsymbol{\zeta}_{t_f}) - \mathcal{H}_{t_f}(\boldsymbol{\zeta}_{t_f-1})\big] \\
&= -\delta\mathcal{Q}_{t_f}.
\end{aligned} \tag{460}$$

第二项贡献是在时刻 $\tilde{t} = \tilde{1}$ 把 Hamiltonian 从 $\tilde{\mathcal{H}}_0 = \mathcal{H}_{t_f}$ 更新为 $\tilde{\mathcal{H}}_1 = \mathcal{H}_{t_f-1}$ 对系

统做的功，它等于前向过程在时刻 $t=t_f$ 对系统做的功的负值：

$$\begin{aligned}\delta\tilde{\mathcal{W}}_1 &= \tilde{\mathcal{H}}_1(\tilde{\boldsymbol{\zeta}}_1) - \tilde{\mathcal{H}}_0(\tilde{\boldsymbol{\zeta}}_1) \\ &= \mathcal{H}_{t_f-1}(\hat{\boldsymbol{\zeta}}_{t_f-1}) - \mathcal{H}_{t_f}(\hat{\boldsymbol{\zeta}}_{t_f-1}) \\ &= \mathcal{H}_{t_f-1}(\boldsymbol{\zeta}_{t_f-1}) - \mathcal{H}_{t_f}(\boldsymbol{\zeta}_{t_f-1}) \qquad (\text{假设 } \mathcal{H}(\hat{\boldsymbol{\zeta}})=\mathcal{H}(\boldsymbol{\zeta})) \\ &= -\big[\mathcal{H}_{t_f}(\boldsymbol{\zeta}_{t_f-1}) - \mathcal{H}_{t_f-1}(\boldsymbol{\zeta}_{t_f-1})\big] \\ &= -\delta\mathcal{W}_{t_f}. \end{aligned} \tag{461}$$

把这一过程重复 t_f 步直到 $\tilde{t}=\tilde{t}_f$，我们得到时间反演过程中的总随机功与热，它们分别等于前向过程中总随机功与热的负值：

$$\tilde{\mathcal{Q}}(\boldsymbol{\zeta}_{0:t_f}) = \sum_{t=1}^{t_f} \delta\tilde{\mathcal{Q}}_t = -\mathcal{Q}(\boldsymbol{\zeta}_{0:t_f}), \tag{462}$$

$$\tilde{\mathcal{W}}(\boldsymbol{\zeta}_{0:t_f}) = \sum_{t=1}^{t_f} \delta\tilde{\mathcal{W}}_t = -\mathcal{W}(\boldsymbol{\zeta}_{0:t_f}). \tag{463}$$

随机功与热的这一性质对第 17 章推导涨落定理将至关重要.

10.5.2 离散时间马尔可夫过程

现在考虑随机热力学如何应用于由前向过渡核 $F_t(\boldsymbol{\zeta}_t|\boldsymbol{\zeta}_{t-1})$ 给出的离散时间马尔可夫过程. 我们假设该核在每个时间步 t 使分布 $\pi_t(\boldsymbol{\zeta}_t)$ 不变：

$$\pi_t(\boldsymbol{\zeta}_t) = \int \mathrm{d}\boldsymbol{\zeta}_{t-1}\, F_t(\boldsymbol{\zeta}_t|\boldsymbol{\zeta}_{t-1})\pi_t(\boldsymbol{\zeta}_{t-1}). \tag{464}$$

为把该过程与热力学联系起来，我们选择不变分布为对应于时变 Hamiltonian $\mathcal{H}_t(\boldsymbol{\zeta}_t)$ 的 Boltzmann 分布：

$$\pi_t(\boldsymbol{\zeta}_t) = \frac{1}{Z_t} e^{-\beta\mathcal{H}_t(\boldsymbol{\zeta}_t)} = e^{\beta\mathcal{F}[\pi_t]-\beta\mathcal{H}_t(\boldsymbol{\zeta}_t)}, \tag{465}$$

其中 β 是逆温度，Z_t 是配分函数，$\mathcal{F}[\pi_t]=-T\log Z_t$ 是分布 π_t 的平衡自由能.

细致平衡假设 为使下面的热力学分析一致，特别是在处理动量变量时，我们必须假设系统关于奇变量满足细致平衡条件（见第 9 章）：

$$F_t(\boldsymbol{\zeta}_t|\boldsymbol{\zeta}_{t-1})\pi_t(\boldsymbol{\zeta}_{t-1}) = F_t(\hat{\boldsymbol{\zeta}}_{t-1}|\hat{\boldsymbol{\zeta}}_t)\pi_t(\hat{\boldsymbol{\zeta}}_t), \tag{466}$$

其中 $\hat{\boldsymbol{\zeta}}=(\boldsymbol{\xi},-\boldsymbol{\eta})$ 表示动量反转后的状态. 此外，我们假设平稳分布在动量反转下对称（即 $\pi_t(\boldsymbol{\zeta})=\pi_t(\hat{\boldsymbol{\zeta}})$），这意味着平衡分布具有零平均动量.

由这些假设、π_t 的定义 (465) 以及随机热的表达式 (457)，我们可以推导马尔可夫过程中随机热的如下关系. 利用细致平衡条件，

$$\frac{F_t(\boldsymbol{\zeta}_t|\boldsymbol{\zeta}_{t-1})}{F_t(\hat{\boldsymbol{\zeta}}_{t-1}|\hat{\boldsymbol{\zeta}}_t)} = \frac{\pi_t(\boldsymbol{\zeta}_t)}{\pi_t(\boldsymbol{\zeta}_{t-1})} = \frac{F_t(\boldsymbol{\zeta}_t|\boldsymbol{\zeta}_{t-1})}{R_t(\boldsymbol{\zeta}_{t-1}|\boldsymbol{\zeta}_t)}, \tag{467}$$

随机热可以用过渡核表示为：

$$\begin{aligned}\mathcal{Q}(\boldsymbol{\zeta}_{0:t_f}) &= -T\sum_{t=1}^{t_f}\log\frac{\pi_t(\boldsymbol{\zeta}_t)}{\pi_t(\boldsymbol{\zeta}_{t-1})}\\ &= -T\sum_{t=1}^{t_f}\log\frac{F_t(\boldsymbol{\zeta}_t|\boldsymbol{\zeta}_{t-1})}{R_t(\boldsymbol{\zeta}_{t-1}|\boldsymbol{\zeta}_t)},\end{aligned} \tag{468}$$

其中反向核定义为 $R_t(\boldsymbol{\zeta}_{t-1}|\boldsymbol{\zeta}_t) = F_t(\hat{\boldsymbol{\zeta}}_{t-1}|\hat{\boldsymbol{\zeta}}_t)$，如第 9 章所述.

利用 (456)，随机功也可表示为

$$\mathcal{W}(\boldsymbol{\zeta}_{0:t_f}) = \mathcal{F}[\pi_{t_f}] - \mathcal{F}[\pi_0] - \beta^{-1}\sum_{t=1}^{t_f}\log\frac{\pi_t(\boldsymbol{\zeta}_{t-1})}{\pi_{t-1}(\boldsymbol{\zeta}_{t-1})}. \tag{469}$$

与随机第一定律 (458) 一致，内能的总变化因而为

$$\Delta\mathcal{U}(\boldsymbol{\zeta}_{0:t_f}) = \mathcal{Q}(\boldsymbol{\zeta}_{0:t_f}) + \mathcal{W}(\boldsymbol{\zeta}_{0:t_f}) = -\beta^{-1}\left[\log\frac{Z_{t_f}}{Z_0} + \log\frac{\pi_{t_f}(\boldsymbol{\zeta}_{t_f})}{\pi_0(\boldsymbol{\zeta}_0)}\right], \tag{470}$$

它再次只依赖于系统的初始与最终状态及其相应的平衡分布.

10.6 第二定律：热力学与统计不可逆性

随机热力学中的不可逆性可以用两种方式量化：热力学不可逆性，由熵产生或耗散功度量；以及统计不可逆性，通过比较以时间反演顺序观察事件的概率来评估. 这两种不可逆性形式之间的相互作用是量化随机热力学第二定律的核心主题. 热力学第二定律可以用两种等价形式陈述：Clausius 表述与 Kelvin 表述. 这两种表述分别与熵产生和耗散功的概念相关.

10.6.1 Clausius 表述与熵产生

第二定律的 Clausius 表述断言：热不能自发地从较冷物体流向较热物体. 这一表述与不可逆过程中熵产生的概念密切相关. 为了让热从冷流向热，系统别处必须有一个补偿性的熵增，这通常通过与外部热储交换热来实现.

为在随机热力学的语境下量化这一思想，我们沿轨迹 $\boldsymbol{\zeta}_{0:t_f}$ 引入随机总熵产生 $\Sigma(\boldsymbol{\zeta}_{0:t_f})$，定义为系统熵变化与环境熵变化之和：

$$\Sigma(\boldsymbol{\zeta}_{0:t_f}) = \Delta\mathcal{S}_{\mathrm{sys}}(\boldsymbol{\zeta}_{0:t_f}) + \Delta\mathcal{S}_{\mathrm{bath}}(\boldsymbol{\zeta}_{0:t_f}), \tag{471}$$

其中 $\Delta\mathcal{S}_{\mathrm{sys}}(\boldsymbol{\zeta}_{0:t_f})$ 与 $\Delta\mathcal{S}_{\mathrm{bath}}(\boldsymbol{\zeta}_{0:t_f})$ 是随机系统与环境熵的变化：

$$\Delta\mathcal{S}_{\mathrm{sys}}(\boldsymbol{\zeta}_{0:t_f}) = -\log\rho_{t_f}(\boldsymbol{\zeta}_{t_f}) + \log\rho_0(\boldsymbol{\zeta}_0), \tag{472}$$

$$\Delta\mathcal{S}_{\mathrm{bath}}(\boldsymbol{\zeta}_{0:t_f}) = \beta\mathcal{Q}_{\mathrm{bath}}(\boldsymbol{\zeta}_{0:t_f}) = -\beta\mathcal{Q}(\boldsymbol{\zeta}_{0:t_f}). \tag{473}$$

这里 $\mathcal{Q}_{\mathrm{bath}}(\boldsymbol{\zeta}_{0:t_f})$ 与 $\mathcal{Q}(\boldsymbol{\zeta}_{0:t_f})$ 是沿轨迹耗散到环境与被系统吸收的随机热 (457)，$\beta = 1/T$ 是环境的逆温度. 这一关系假设热浴远大于系统，使得热交换引起的热浴温度

变化可忽略，且即使系统本身远离平衡，热浴也在每次交换后迅速弛豫回平衡态. 由于热代表 “无用能量”，热浴的自由能不会改变. 因此，由热项表示的内能任何变化都必须由热浴熵的等量变化来补偿.

对于前向路径概率为 $\rho(\boldsymbol{\zeta}_{0:t_f})$ (445)、时间反演过程由 R_t 构建并从 ρ_{t_f} 出发的离散时间马尔可夫过程，我们可以用 (472)、(473) 与 (468) 把 $\Sigma(\boldsymbol{\zeta}_{0:t_f})$ 表示为前向与时间反演路径概率的函数：

$$\begin{aligned}\Sigma(\boldsymbol{\zeta}_{0:t_f}) &= \Delta\mathcal{S}_{\text{sys}}(\boldsymbol{\zeta}_{0:t_f}) + \Delta\mathcal{S}_{\text{bath}}(\boldsymbol{\zeta}_{0:t_f}) \\ &= \big[-\log\rho_{t_f}(\boldsymbol{\zeta}_{t_f}) + \log\rho_0(\boldsymbol{\zeta}_0)\big] + \sum_{t=1}^{t_f}\log\frac{F_t(\boldsymbol{\zeta}_t|\boldsymbol{\zeta}_{t-1})}{R_t(\boldsymbol{\zeta}_{t-1}|\boldsymbol{\zeta}_t)} \\ &= \log\frac{\rho_0(\boldsymbol{\zeta}_0)\prod_{t=1}^{t_f}F_t(\boldsymbol{\zeta}_t|\boldsymbol{\zeta}_{t-1})}{\rho_{t_f}(\boldsymbol{\zeta}_{t_f})\prod_{t=1}^{t_f}R_t(\boldsymbol{\zeta}_{t-1}|\boldsymbol{\zeta}_t)} \\ &= \log\frac{\rho(\boldsymbol{\zeta}_{0:t_f})}{\rho_R(\boldsymbol{\zeta}_{0:t_f})},\end{aligned} \tag{474}$$

其中我们对前向路径概率 $\rho(\boldsymbol{\zeta}_{0:t_f})$ 使用了马尔可夫性，并定义时间反演路径概率 $\rho_R(\boldsymbol{\zeta}_{0:t_f}) = \rho_{t_f}(\boldsymbol{\zeta}_{t_f})\prod_{t=1}^{t_f}R_t(\boldsymbol{\zeta}_{t-1}|\boldsymbol{\zeta}_t)$.

随机熵产生 (474) 可以从过程的统计不可逆性角度给出清晰解释. 它量化了观察到某条前向轨迹的概率与观察到相应时间反演轨迹的概率之间的差异. 若过程可逆，前向与时间反演路径概率相等，随机熵产生为零. 然而，对于不可逆过程，前向路径通常远比时间反演路径可能，导致正的随机熵产生.

容易把 (474) 中的时间反演路径概率 ρ_R 与第 9 章 (382) 中的混淆. 后者是使反向路径等可能的后向过程概率. 然而请注意，反向路径在 (382) 下等可能，但在 (474) 下并不等可能!

把随机熵产生在所有前向轨迹上取平均，平均总熵产生 $\mathbb{E}_\rho[\Sigma]$ 表示为前向与后向路径概率分布之间的 Kullback–Leibler 散度：[4]

$$\mathbb{E}_\rho[\Sigma(\boldsymbol{\zeta}_{0:t_f})] = \int \mathrm{d}\boldsymbol{\zeta}_{0:t_f}\,\rho(\boldsymbol{\zeta}_{0:t_f})\log\frac{\rho(\boldsymbol{\zeta}_{0:t_f})}{\rho_R(\boldsymbol{\zeta}_{0:t_f})} = D_{\text{KL}}[\rho\|\rho_R] \geq 0. \tag{475}$$

$\mathbb{E}_\rho[\Sigma]$ 的非负性由 KL 散度的非负性给出，从而得到第二定律：[5]

$$\mathbb{E}_\rho[\Sigma(\boldsymbol{\zeta}_{0:t_f})] = \mathbb{E}_\rho[\Delta\mathcal{S}_{\text{sys}}] + \mathbb{E}_\rho[\Delta\mathcal{S}_{\text{bath}}] \geq 0. \tag{476}$$

当然，第二定律不仅适用于离散时间马尔可夫过程，也适用于广泛的物理系统.

在无外部功的情形下（即 Hamiltonian 保持恒定且每个 F_t 都相同 $F_t = F$），我们可以使用具有相同平稳分布 π 的 DB 条件 (466)，

$$F(\boldsymbol{\zeta}_t|\boldsymbol{\zeta}_{t-1})\pi(\boldsymbol{\zeta}_{t-1}) = R(\boldsymbol{\zeta}_{t-1}|\boldsymbol{\zeta}_t)\pi(\boldsymbol{\zeta}_t), \tag{477}$$

[4]这要求路径测度 ρ 与 ρ_R 相互绝对连续，从而使比值有良定义.

[5]为完成推导，我们需要证明后向路径概率密度 $\rho_R(\boldsymbol{\zeta}_{0:t_f})$ 是一个合法的概率分布（即非负且归一化）. 非负性由定义给出，归一化可用过渡核的性质直接积分验证.

来简化熵产生的一般表达式 (474). 由此我们有

$$\begin{aligned}\Sigma(\boldsymbol{\zeta}_{0:t_f}) &= \log \frac{\rho(\boldsymbol{\zeta}_{0:t_f})}{\rho_R(\boldsymbol{\zeta}_{0:t_f})} \\ &= \log \frac{\rho_0(\boldsymbol{\zeta}_0)\prod_{t=1}^{t_f} F(\boldsymbol{\zeta}_t|\boldsymbol{\zeta}_{t-1})}{\rho_{t_f}(\boldsymbol{\zeta}_{t_f})\prod_{t=1}^{t_f} R(\boldsymbol{\zeta}_{t-1}|\boldsymbol{\zeta}_t)}.\end{aligned} \tag{478}$$

对平稳分布使用 (477)，可以把熵产生改写为

$$\begin{aligned}\Sigma(\boldsymbol{\zeta}_{0:t_f}) &= \log \frac{\rho_0(\boldsymbol{\zeta}_0)}{\rho_{t_f}(\boldsymbol{\zeta}_{t_f})} + \sum_{t=1}^{t_f} \log \frac{\pi(\boldsymbol{\zeta}_t)}{\pi(\boldsymbol{\zeta}_{t-1})} \\ &= \log \frac{\rho_0(\boldsymbol{\zeta}_0)}{\pi(\boldsymbol{\zeta}_0)} + \log \frac{\pi(\boldsymbol{\zeta}_{t_f})}{\rho_{t_f}(\boldsymbol{\zeta}_{t_f})}.\end{aligned} \tag{479}$$

把所有轨迹取平均，得到

$$\begin{aligned}\mathbb{E}_\rho[\Sigma(\boldsymbol{\zeta}_{0:t_f})] &= \int \mathrm{d}\boldsymbol{\zeta}_0\, \rho_0(\boldsymbol{\zeta}_0) \log \frac{\rho_0(\boldsymbol{\zeta}_0)}{\pi(\boldsymbol{\zeta}_0)} + \int \mathrm{d}\boldsymbol{\zeta}_{t_f}\, \rho_{t_f}(\boldsymbol{\zeta}_{t_f}) \log \frac{\pi(\boldsymbol{\zeta}_{t_f})}{\rho_{t_f}(\boldsymbol{\zeta}_{t_f})} \\ &= D_{\mathrm{KL}}[\rho_0\|\pi] - D_{\mathrm{KL}}[\rho_{t_f}\|\pi].\end{aligned} \tag{480}$$

由于系统在时刻 t_{t_f} 尚未收敛到平稳分布，我们为总熵产生得到一个 “退款”，等于上述最后一项，它总是小于第一项，因为 ρ_{t_f} 比 ρ_0 更接近平稳. 事实上，当系统向平衡弛豫时，ρ_{t_f} 趋近于 π. 当过程运行足够长时间以达到平衡时，我们有

$$\lim_{t_f\to\infty} D_{\mathrm{KL}}[\rho_{t_f}\|\pi] = 0, \tag{481}$$

$$\lim_{t_f\to\infty} \mathbb{E}_\rho[\Sigma(\boldsymbol{\zeta}_{0:t_f})] = D_{\mathrm{KL}}[\rho_0\|\pi]. \tag{482}$$

即，总熵产生由初始分布与最终平衡分布之间的 KL 散度给出.

这还告诉我们，熵产生提供了系统初始状态与平衡状态之间 “距离” 的定量度量，且该距离随系统向平衡演化而单调减小. 事实上，Langevin 动力学将沿该目标的最速下降路径行进，每一步都保证使目标减小，因而也保证增加系统与环境的总熵.

10.6.2 Kelvin 表述与耗散功

第二定律的 Kelvin 表述断言：不可能构造一台循环工作的热机，它只从单一热储吸热并做出等量功，而不产生任何其他效果. 这一表述与随机热力学中耗散功的概念直接相关.

随机耗散功 $\mathcal{W}_{\mathrm{diss}}(\boldsymbol{\zeta}_{0:t_f})$ 对一个热力学过程定义，量化由于过程不可逆性而需要额外做的功. 它定义为对系统做的随机功 (456) 与随机自由能变化 $\Delta\mathcal{F} = \mathcal{F}(\boldsymbol{\zeta}_{t_f}) - \mathcal{F}(\boldsymbol{\zeta}_0)$ (450) 之差：

$$\mathcal{W}_{\mathrm{diss}}(\boldsymbol{\zeta}_{0:t_f}) = \mathcal{W}(\boldsymbol{\zeta}_{0:t_f}) - \Delta\mathcal{F}(\boldsymbol{\zeta}_{0:t_f}). \tag{483}$$

注意，虽然随机功是路径依赖量，但自由能的变化只依赖于系统的初始与最终状态. 耗散功是过程低效性的度量，因为它代表总功中无法回收为有用功输出的那一部分.

为推导耗散功与熵产生之间的联系，我们从随机热力学第一定律 (454) 与随机自由能的定义 (450) 出发. 对一条具体轨迹 $\boldsymbol{\zeta}_{0:t_f}$，

$$\Delta\mathcal{U}(\boldsymbol{\zeta}_{0:t_f}) = \mathcal{Q}(\boldsymbol{\zeta}_{0:t_f}) + \mathcal{W}(\boldsymbol{\zeta}_{0:t_f}), \tag{484}$$

$$\Delta\mathcal{F}(\boldsymbol{\zeta}_{0:t_f}) = \mathcal{F}(\boldsymbol{\zeta}_{t_f}) - \mathcal{F}(\boldsymbol{\zeta}_0) = \Delta\mathcal{U}(\boldsymbol{\zeta}_{0:t_f}) - T\Delta\mathcal{S}_{\mathrm{sys}}(\boldsymbol{\zeta}_{0:t_f}). \tag{485}$$

把第一定律代入自由能差：

$$\Delta\mathcal{F}(\boldsymbol{\zeta}_{0:t_f}) = \mathcal{Q}(\boldsymbol{\zeta}_{0:t_f}) + \mathcal{W}(\boldsymbol{\zeta}_{0:t_f}) - T\Delta\mathcal{S}_{\mathrm{sys}}(\boldsymbol{\zeta}_{0:t_f}). \tag{486}$$

重新整理各项，并使用随机环境熵变化的定义 (473)，

$$T\Delta\mathcal{S}_{\mathrm{sys}}(\boldsymbol{\zeta}_{0:t_f}) + T\Delta\mathcal{S}_{\mathrm{bath}}(\boldsymbol{\zeta}_{0:t_f}) = \mathcal{W}(\boldsymbol{\zeta}_{0:t_f}) - \Delta\mathcal{F}(\boldsymbol{\zeta}_{0:t_f}). \tag{487}$$

使用随机总熵产生的定义 (471) 与随机耗散功 (483)，我们得到

$$T\Sigma(\boldsymbol{\zeta}_{0:t_f}) = \mathcal{W}_{\mathrm{diss}}(\boldsymbol{\zeta}_{0:t_f}). \tag{488}$$

把所有轨迹取平均，得到 Kelvin 形式的热力学第二定律：

$$T\mathbb{E}_\rho[\Sigma] = \mathbb{E}_\rho[\mathcal{W}_{\mathrm{diss}}] \geq 0. \tag{489}$$

平均耗散功 $\mathbb{E}_\rho[\mathcal{W}_{\mathrm{diss}}]$ 的非负性是第二定律 (476) 的直接推论，且它仅对可逆过程为零. 然而，对于单条轨迹，随机耗散功 $\mathcal{W}_{\mathrm{diss}}(\boldsymbol{\zeta}_{0:t_f})$ 可以为负，但概率很低，这一现象由涨落定理量化.

Chapter 11

马尔可夫链蒙特卡洛

11.1 引言

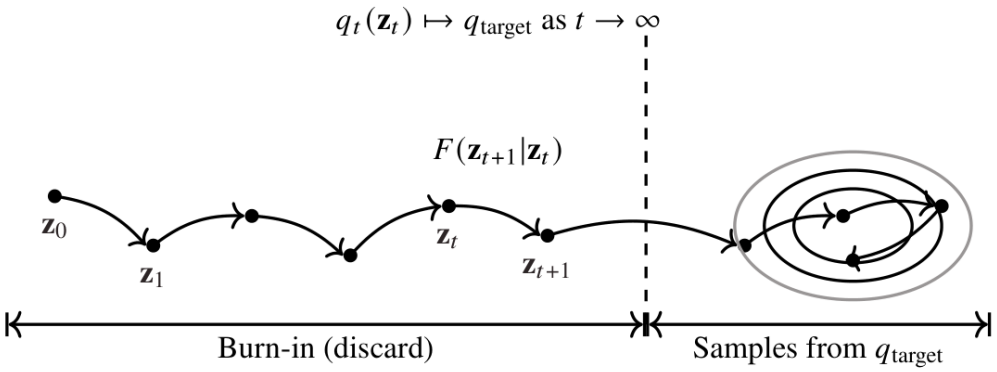
继第 4 章对马尔可夫过程与核的讨论、以及第 9 章围绕其可逆性的特殊挑战之后，我们现在考虑它们的一个具体应用领域：*马尔可夫链蒙特卡洛*（Markov chain Monte Carlo, MCMC）. 除变分推断之外，MCMC 是进行后验推断最流行的方法之一. 它通过从感兴趣的分布中采集样本来实现这一点. MCMC 基于一条马尔可夫链，其过渡核被设计成使平衡分布即为目标分布. 本章将讨论如何设计这样的核，并给出几个例子，包括 Metropolis–Hastings、Gibbs 采样、Hamiltonian Monte Carlo 与 Langevin 采样. 这些核分为两类：满足细致平衡的核与不满足细致平衡的核，这与我们在第 9 章中讨论的核类似.

11.2 马尔可夫链蒙特卡洛

MCMC 的目标是设计一个迭代过程，从不归一化的概率分布 $q_{\text{target}}(\mathbf{z})$（或密度）生成样本. MCMC 通过设计一个马尔可夫核 $F(\mathbf{z}'|\mathbf{z})$ 来实现这一点：通过迭代地应用该过渡核，

$$\begin{aligned}
&\mathbf{z}_0 \sim q_0(\mathbf{z}_0),\\
&\mathbf{z}_1 \sim F(\mathbf{z}_1|\mathbf{z}_0),\\
&\quad\vdots\\
&\mathbf{z}_t \sim F(\mathbf{z}_t|\mathbf{z}_{t-1}),\\
&\quad\vdots
\end{aligned} \tag{490}$$

当连续应用核的次数趋于无穷时，边缘分布 $q_t(\mathbf{z}_t) = \int \mathrm{d}\mathbf{z}_{0:t-1}\, q_0(\mathbf{z}_0) \prod_{j=1}^{t} F(\mathbf{z}_j|\mathbf{z}_{j-1})$（其中积分遍历所有先前状态 $\mathbf{z}_0, \ldots, \mathbf{z}_{t-1}$）收敛到目标分布 $q_\infty = q_{\text{target}}$，且不依赖于初始分布 q_0. 这一过程我们称为*祖先采样*（ancestral sampling），如 图 33 所示.



1 The process of a Markov chain Monte Carlo algorithm. The chain starts

图 33: 马尔可夫链蒙特卡洛算法的过程. 链从初始状态 $\mathbf{z}_0$ 出发，通过一系列过渡 $F(\mathbf{z}_{t+1}|\mathbf{z}_t)$ 演化. Burn-in 期表示被丢弃的初始样本. 当 $t \to \infty$ 时，样本分布收敛到目标分布 q_{target}.

形式化地，这陈述了当 $t \to \infty$ 时，不依赖于初始分布，q_t 与 q_{target} 之间的总变差距离趋于零:

$$\lim_{t\to\infty} \|q_t - q_{\text{target}}\|_{\text{TV}} = 0, \tag{491}$$

这正是 MCMC 所期望的收敛性质.

设计这样一个过渡核并非易事，但幸运的是存在一组充分条件，使我们能验证某个核确实达到这一目标. 这是下一节的主题.

11.3 为 MCMC 设计马尔可夫核

要设计一个核使得我们具有 (491) 中的收敛性质，该核必须:

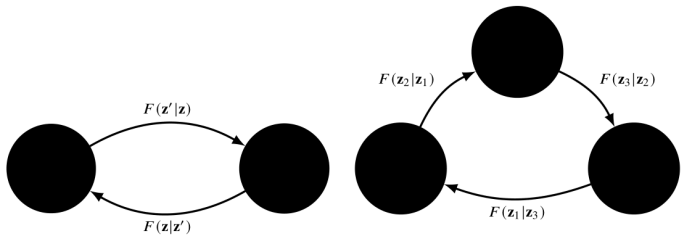
(i) 以目标分布为其平稳分布之一，即通过使目标分布在该核下不变，或通过满足关于它的细致平衡;

(ii) 是遍历的（ergodic），即该核具有唯一的平稳分布，且在反复应用该核后链收敛到该分布.

结合这两个性质，我们可以看到该核将具有正确的平稳分布，该平稳分布将是唯一的，且链将收敛到该平稳分布. 什么是一个核的平稳分布、以及一条链成为遍历链意味着什么，将在下面详细讨论.

11.3.1 平稳分布

我们考虑的第一个判据是: 过渡核 F 需要以目标分布 q_{target} 作为其平稳分布. 给定一个特定的 q_{target}，许多核可以达到这一目标，它们分为两类: 满足细致平衡的核，以及不满足细致平衡但使目标分布不变的核（两种情形的示意见 图 34）.



(a) Detailed Balance (b) Invariance Condition

Figure 11.2 Comparison of detailed balance and invariance conditions in MCMC. (a) Detailed balance requires symmetric transitions between states at equilibrium, shown with bidirectional arrows between two states. (b) The invariance condition allows for cyclic flows of probabilities that maintain the overall stationary distribution, illustrated here with a three-state system where probability can flow in a directed cycle while preserving q_{target}.

can achieve this goal, falling into two classes: those satisfying detailed balance and those leaving the target distribution invariant without satisfying detailed balance (see Figure 11.2 for an illustration of both cases).

图 34: MCMC 中细致平衡与不变性条件的比较. (a) 细致平衡要求平衡时状态间的对称转移，以两状态间的双向箭头表示. (b) 不变性条件允许概率的循环流动以维持整体平稳分布，此处以三状态系统示意，概率可沿有向环流动而保持 q_{target}.

不变性条件 概率分布 q_{target} 被称为在核 F 下不变的（invariant），若

$$q_{\text{target}}(\mathbf{z}') = \int \mathrm{d}\mathbf{z}\, F(\mathbf{z}'|\mathbf{z}) q_{\text{target}}(\mathbf{z}) \qquad \text{对所有}\mathbf{z}'. \tag{492}$$

等价地，我们可以说 q_{target} 是 F 的平稳（steady-state）分布.

理解平稳性/不变性的一种方式是想象一组任意体积元（例如各种小立方体）. (492) 陈述：在每一时间步，核 F 从每个立方体移出的概率与移入该立方体的概率相等. 换言之，立方体中的概率水平保持不变. 若对所有体积元都成立，我们就满足了上述条件.

然而值得注意的是，虽然流出一个立方体与流入该立方体的总概率相等，但两个特定立方体之间交换的概率并不要求平衡. 这允许概率从一侧进入、从另一侧离开，从而产生概率在其中循环流动的确定性流.

另一种理解方式是把它视为概率分布的一种对称性. 若 q_{target} 具有某种对称性，则存在一个向量场把概率输运到等概率轮廓上. 由定义，这使分布保持不变.

伴随核 我们此前在第 9 章的物理语境中讨论过不变分布的概念. 在那里我们见到了不变性条件的另一种刻画：

$$\text{存在} A: \quad F(\mathbf{z}'|\mathbf{z}) q_{\text{target}}(\mathbf{z}) = A(\mathbf{z}|\mathbf{z}') q_{\text{target}}(\mathbf{z}') \qquad \text{对所有}\mathbf{z}, \mathbf{z}', \tag{493}$$

这陈述存在一个正的、适当归一化的伴随过渡核 A，满足 $A(\mathbf{z}|\mathbf{z}') \geq 0$ 对所有 $\mathbf{z}, \mathbf{z}'$ 成立，且 $\int \mathrm{d}\mathbf{z}\, A(\mathbf{z}|\mathbf{z}') = 1$ 对所有 $\mathbf{z}'$ 成立，使得 (493) 成立.

容易验证这样的 A 的存在直接导出不变性：

$$\int \mathrm{d}\mathbf{z}\, F(\mathbf{z}'|\mathbf{z}) q_{\text{target}}(\mathbf{z}) = \int \mathrm{d}\mathbf{z}\, A(\mathbf{z}|\mathbf{z}') q_{\text{target}}(\mathbf{z}') = q_{\text{target}}(\mathbf{z}'). \tag{494}$$

这也突出了伴随核 A 与前向核 F 具有相同的平稳分布.

反向蕴涵则稍出人意料，它通过构造一个满足 (493) 的伴随核来证明，即

$$A(\mathbf{z}|\mathbf{z}') = \frac{F(\mathbf{z}'|\mathbf{z}) q_{\text{target}}(\mathbf{z})}{q_{\text{target}}(\mathbf{z}')}. \tag{495}$$

然而，这并不保证 A 是非负且适当归一化的. 对于非负性，我们回忆 F 与 q_{target} 都是非负的，因此 A 也必为非负. 为证明归一化，我们使用平稳性：

$$\int \mathrm{d}\mathbf{z}\, A(\mathbf{z}|\mathbf{z}') = \int \mathrm{d}\mathbf{z}\, \frac{F(\mathbf{z}'|\mathbf{z}) q_{\text{target}}(\mathbf{z})}{q_{\text{target}}(\mathbf{z}')} = \frac{q_{\text{target}}(\mathbf{z}')}{q_{\text{target}}(\mathbf{z}')} = 1, \tag{496}$$

这就证明了 (492)（即 q_{target} 在 F 下不变）与 (493)（即 A 的存在）实际上等价.

把伴随核 A 作用于平稳分布 q_{target} 将相对于前向方向反转概率流（例如，概率会从右侧流入立方体、从左侧流出）. 对于确定性动力学，把 A 作用于稳态分布 q_{target} 意味着我们在时间上反向播放 F 的模拟. 因此，我们把一个需要伴随核 A 来反转概率流的核 F 称为“不可逆的”，这或许是有点出人意料的. “非自可逆的”这一术语本会更具描述性.

“自可逆”或“自伴随”的核，通常被称为“可逆”核，将在下文中讨论.

细致平衡条件 我们可以对核 F 施加的关于目标分布 q_{target} 的一个更严格条件是细致平衡（detailed balance, DB）：

$$F(\mathbf{z}'|\mathbf{z}) q_{\text{target}}(\mathbf{z}) = F(\mathbf{z}|\mathbf{z}') q_{\text{target}}(\mathbf{z}') \qquad \text{对所有} \mathbf{z}, \mathbf{z}'. \tag{497}$$

把它与 (493) 比较，我们可以直接看到它与基于伴随核定义的不变性条件的相似性. 核 F 满足 DB 当且仅当它是“自伴随”的，即 $A = F$.

回到一组任意体积元的类比，我们现在可以看到 DB 意味着概率不能从一端流入立方体、从另一端流出. 相反，对于任意体积元的每一个表面元，通过该表面元流入立方体的概率流必须等于通过同一表面元流出立方体的概率流. 因此，对每一对点 $\mathbf{z}, \mathbf{z}'$，概率流都是平衡的.

这里需要注意，在物理学中 DB 的定义有所不同. 在存在动量时，我们把反向核定义为 $R(\zeta'|\zeta) = F(\hat{\zeta}'|\hat{\zeta})$，其中 $\zeta = (\boldsymbol{\xi}, \boldsymbol{\eta})$，$\hat{\zeta} = (\boldsymbol{\xi}, -\boldsymbol{\eta})$. 我们此时说当 $A = R$ 时 DB 成立. 然而这已经涉及了动量的反转，因而会包含在圆循环的概率流. 在 MCMC 对 DB 的定义中，若核作用于奇变量，我们反而需要在步末显式地确保奇变量的这一反转，作为核的一部分来满足 DB.

例如，下面我们将讨论 Hamiltonian Monte Carlo，在 MCMC 定义中我们需要在每一步后反转动量以获得 DB. 然而在物理学定义中，这一点对于称其为 DB 并不是必要的.

细致平衡蕴涵不变性 使用基于伴随核的不变性条件定义，证明 DB 蕴涵不变性是直截了当的；但如果使用 (492) 中的不变性定义，证明 DB 蕴涵不变性同样不难：

$$\int \mathrm{d}\mathbf{z}\, F(\mathbf{z}'|\mathbf{z}) q_{\text{target}}(\mathbf{z}) = \int \mathrm{d}\mathbf{z}\, F(\mathbf{z}|\mathbf{z}') q_{\text{target}}(\mathbf{z}') = q_{\text{target}}(\mathbf{z}'), \qquad \text{对所有} \mathbf{z}' \tag{498}$$

（因为 $\int \mathrm{d}\mathbf{z}\, F(\mathbf{z}|\mathbf{z}') = 1$）.

Metropolis–Hastings 考虑到 DB 是比不变性更严格的条件，它的相关性问题便随之而来. 毕竟，我们只需要核具有正确的平稳分布，它就能成为 MCMC 中可用的有效核（此外它还需遍历，如我们接下来将讨论的）. 答案是：对任意提议核 F，存在一个简单技巧，即使用 Metropolis–Hastings（Metropolis et al., 1953; Hastings, 1970）规则接受或拒绝提议的样本，来构造一个满足 DB 的新核.

给定一个过渡核 F 作为我们的提议分布，MH 接受概率为

$$p_{\text{accept}}(\mathbf{z}'|\mathbf{z}) = \min\left[1, \frac{q_{\text{target}}(\mathbf{z}')}{q_{\text{target}}(\mathbf{z})} \cdot \frac{F(\mathbf{z}|\mathbf{z}')}{F(\mathbf{z}'|\mathbf{z})}\right]. \tag{499}$$

我们可以证明，先用 F 提议、再以 p_{accept} 接受的组合将产生细致平衡条件 (497). 具体地，通过分别考虑 $\mathbf{z}' = \mathbf{z}$ 与 $\mathbf{z}' \neq \mathbf{z}$ 的情形，我们发现在接受与拒绝两种情形下都有

$$q_{\text{target}}(\mathbf{z}) F(\mathbf{z}'|\mathbf{z}) p_{\text{accept}}(\mathbf{z}'|\mathbf{z}) = q_{\text{target}}(\mathbf{z}') F(\mathbf{z}|\mathbf{z}') p_{\text{accept}}(\mathbf{z}|\mathbf{z}'). \tag{500}$$

通过这一技巧，在 MCMC 中细致平衡条件 (497)——加上遍历性，如我们接下来将讨论的——常被用作构造收敛到所需目标分布的有效马尔可夫链的一个方便（且充分）的条件.

许多流行的 MCMC 算法，例如著名的 Metropolis–Hastings 算法（Metropolis et al., 1953; Hastings, 1970），都基于细致平衡条件.

11.3.2 遍历性

简而言之，用核 F 构造的马尔可夫链被称为*遍历链*（ergodic chain），若它是不可约（irreducible）、非周期（aperiodic）且正 Harris 常返（positive Harris recurrent）的. 我们稍后将详细讨论这些判据，但完整的讨论请参见该主题的专门教材（Robert and Casella, 1999; Brooks, 1998）. 若三者都满足，我们即可保证链将在 $t \to \infty$ 时收敛到唯一的平稳分布，且不依赖于初始分布. 如前所述，为使该平稳分布为正确的 q_{target}，该核还必须满足不变性条件 (492). 现在来讨论各判据.

(i) **正 Harris 常返**：正 Harris 常返意味着链将以概率 1 回到任意状态，且平均时间有限. 这确保链不会被困在一组被排除的状态中. 正常返确保该核具有平稳分布.

(ii) **不可约**：任意状态都可从任意其他状态到达. 这在离散空间中最容易想象，它本质上意味着：如果我们画出可达状态的图，任意两状态之间都应有一条路径. 这确保了对正常返核保证存在的平稳分布是唯一的.

(iii) **非周期**：链不包含任何固定环. 这确保在任意时刻 t 不存在一组链无法到达的被排除状态. 没有这一判据，总变差距离可能只对固定的时间步区间收敛到 0. 结合正 Harris 常返与不可约性，这不仅确保唯一平稳分布的存在，还确保链实际收敛到它.[6]

虽然这三个判据看起来抽象且难以满足，但在大多数情形下，它们可以通过使用包含某种形式随机扰动且具有充分支撑的核来满足. 我们将在本章后面关于著名 MCMC 算法的一节中看到一些例子.

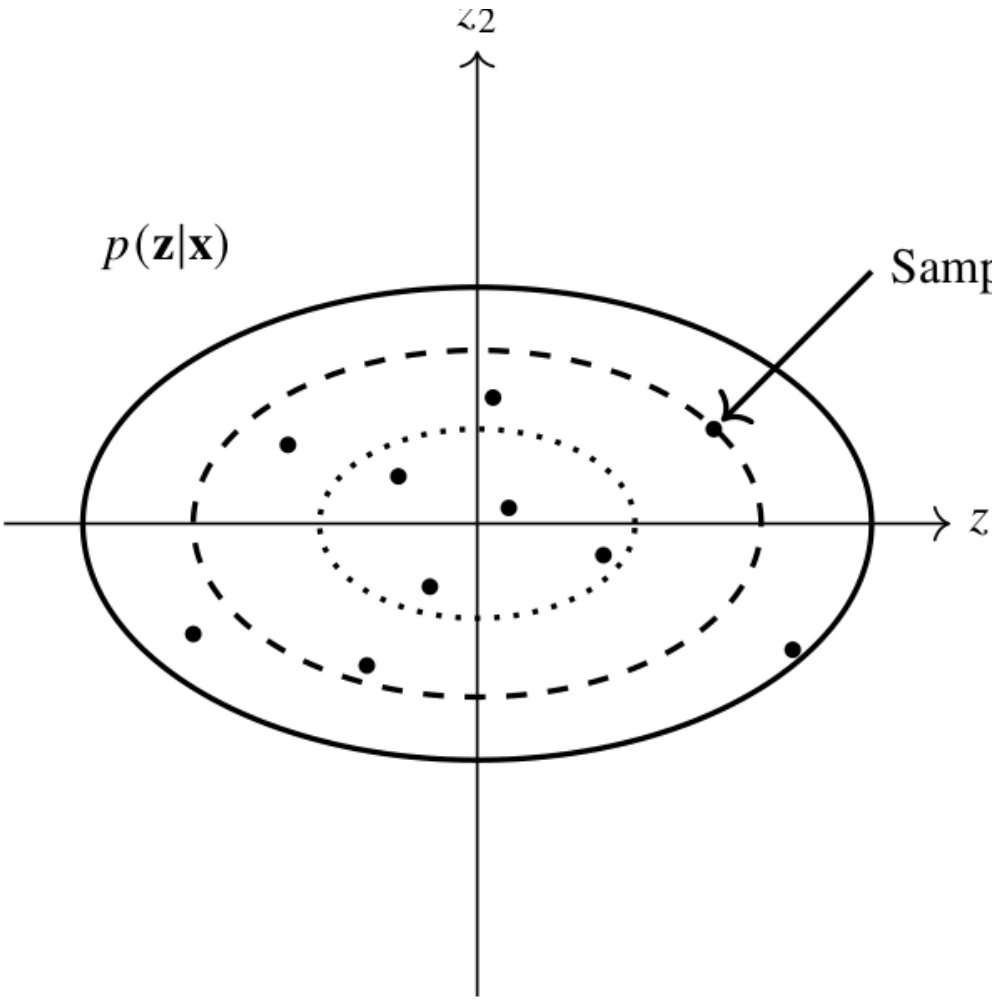
把这一点与通过 MH 接受–拒绝步确保任意核具有正确平稳分布的技巧相结合，我们现在拥有了构造马尔可夫核的完整配方：该核在连续应用后将收敛到我们期望的目标分布. 在这种情形下，我们有一个关于目标分布满足 DB 的核，且由于遍历性保证收敛到目标分布，我们把目标分布称为该核的*平衡分布*（equilibrium distribution）.

混合时间 与遍历性的概念一致，你常会在书与论文中听到“*混合时间*（mixing time）”这一概念. 该概念指链在总变差距离意义下收敛到与目标分布可接受的接近程度所需的时间（或步数）. 你也会听到它被称为“*预热期*（burn-in period）”.

不同的马尔可夫核具有不同的混合时间. 例如，虽然 DB 是满足不变性的方便条件，但它往往混合缓慢. 在实践中，与只满足不变性的不可逆核相比，这导致更长的预热期. DB 可以比作通过扩散把牛奶混入茶中，而我们真正想要的是用茶匙搅拌使牛奶在茶中对流，这由不可逆 MCMC 核实现. 毕竟，搅拌牛奶远比等待扩散来分布牛奶要快!

图 35 给出了 MCMC 如何从后验分布采样的简单二维示意：链探索 $p(\mathbf{z}|\mathbf{x})$ 的水平集，产生一团样本云，可用于近似后验下的期望.

[6]值得注意的是，MCMC 还常考虑第二个收敛判据，即*遍历定理*（ergodic theorem）. 遍历定理陈述：若我们对链生成的样本取时间平均，该平均将收敛到目标分布下的期望值. 这正是我们在第 3 章讨论如何为动力系统定义相空间上的概率分布时简要提及的性质. 令人困惑的是，尽管非周期性是马尔可夫链遍历性的必要条件，但为使遍历定理成立，链并不需要是非周期的.



ampling with MCMC. The ellipses repres

图 35: 用 MCMC 进行后验采样. 椭圆表示后验分布 $p(\mathbf{z}|\mathbf{x})$ 的轮廓. 实心圆表示用 MCMC 从该分布中抽取的样本. 箭头高亮特定样本 $\mathbf{z}_s$. 样本用于近似期望 $\mathbb{E}_{p(\mathbf{z}|\mathbf{x})}[f(\mathbf{z})] \approx \frac{1}{S}\sum_{s=1}^{S} f(\mathbf{z}_s)$，其中 $\mathbf{z}_s \sim p(\mathbf{z}|\mathbf{x})$.

11.4 MCMC 核的例子

在讨论了为 MCMC 设计有效马尔可夫核的要求之后，我们现在讨论一些著名的例子. 我们将讨论的核包括 Gibbs 采样、Hamiltonian Monte Carlo 与 Langevin 动力学. 如你所见，虽然我们此前把马尔可夫核 F 描述为执行 MCMC 过程中的单一步骤，但为满足成为有效 MCMC 核的要求，大多数实用核——包括我们讨论的所有这些——都需要多个内部步骤.

11.4.1 Gibbs 采样

Gibbs 采样是多元随机变量 MCMC 方法的一个有用例子. 令状态向量 $\mathbf{z}$ 由 n 个分量组成，即 $\mathbf{z} = (\mathbf{z}^1, \mathbf{z}^2, \ldots, \mathbf{z}^n)$. 在 Gibbs 采样中，我们顺序地更新每个分量 $\mathbf{z}^i$，条件是所有其他分量的当前值 $\mathbf{z}^{-i} = (\mathbf{z}^1, \ldots, \mathbf{z}^{i-1}, \mathbf{z}^{i+1}, \ldots, \mathbf{z}^n)$. 顺序可以是随机的或固定的. 这里我们考虑从 $\mathbf{z}_t$ 到 $\mathbf{z}_{t+1}$ 的固定顺序：

$$\mathbf{z}_{t+1}^1 \sim q_{\text{target}}(\mathbf{z}^1 | \mathbf{z}_t^{2:n}), \tag{501}$$

$$\mathbf{z}_{t+1}^2 \sim q_{\text{target}}(\mathbf{z}^2 | \mathbf{z}_{t+1}^1, \mathbf{z}_t^{3:n}), \tag{502}$$

$$\vdots$$

$$\mathbf{z}_{t+1}^n \sim q_{\text{target}}(\mathbf{z}^n | \mathbf{z}_{t+1}^{1:n-1}). \tag{503}$$

这里 $q_{\text{target}}(\mathbf{z}^i | \mathbf{z}^{-i})$ 表示在给定所有其他分量时第 i 个分量的条件分布. 该过程循环遍历所有分量，并把过渡核 $F(\mathbf{z}_{t+1} | \mathbf{z}_t)$ 定义为各条件分布的乘积.

Gibbs 采样的基本原理是：从一元条件分布采样通常比从完整联合分布采样更容易. Gibbs 采样对于从图模型中采样特别有用，它只需要固定所关注节点的 Markov 毯内节点的值.

可逆性 可以证明，Gibbs 采样方案的每个单独条件更新步本身都满足关于目标分布 q_{target} 的细致平衡条件 (497). 然而，所有这些单独步骤组合成单个马尔可夫核 F 后却不满足. 这一点很容易看出：Gibbs 采样算法依赖于变量被更新的顺序. 这使得相应的马尔可夫链核 F 不可逆；你可以验证，若前向与后向路径使用相同的顺序，细致平衡条件 (497) 并不满足.

然而，通过反转被条件化变量的顺序，

$$\mathbf{z}_t^n \sim q_{\text{target}}(\mathbf{z}^n | \mathbf{z}_{t+1}^{1:n-1}), \tag{504}$$

$$\mathbf{z}_t^{n-1} \sim q_{\text{target}}(\mathbf{z}^{n-1} | \mathbf{z}_{t+1}^{1:n-2}, \mathbf{z}_t^n), \tag{505}$$

$$\vdots$$

$$\mathbf{z}_t^1 \sim q_{\text{target}}(\mathbf{z}^1 | \mathbf{z}_t^{2:n}), \tag{506}$$

可以构造出反向过渡核 $A(\mathbf{z}_t | \mathbf{z}_{t+1})$，且不变性条件 (493) 成立. 因此，$F$ 与 A 都使目标分布 q_{target} 保持不变.

值得注意的是，若条件更新使用随机顺序（例如随机扫描 Gibbs 采样（Tierney, 1994)），Gibbs 采样方案确实变得可逆.

11.4.2 Hamiltonian Monte Carlo

一个非常重要的 MCMC 方法是Hamiltonian Monte Carlo（Hamiltonian Monte Carlo, HMC）（Neal, 2011）. 它使用 Hamiltonian 动力学来提议新样本. HMC 背后的思想是引入辅助动量变量 $\mathbf{p}$ 并定义一个 Hamiltonian：

$$\mathcal{H}(\mathbf{z}, \mathbf{p}) = \frac{1}{2}\|\mathbf{p}\|^2 + \mathcal{V}(\mathbf{z}), \tag{507}$$

$$\mathcal{V}(\mathbf{z}) = -\log q_{\text{target}}(\mathbf{z}). \tag{508}$$

这些动量变量通常从各向同性 Gaussian 分布初始化：

$$p(\mathbf{p}) \propto e^{-\frac{1}{2}\|\mathbf{p}\|^2}. \tag{509}$$

HMC 随后通过用 Hamilton 方程模拟该物理系统的演化，在系统的组合相空间 $\mathbf{x} = (\mathbf{z}, \mathbf{p})$ 上构造一个过渡核 $F(\mathbf{x}'|\mathbf{x})$：

$$\frac{\mathrm{d}\mathbf{z}}{\mathrm{d}\tau} = \frac{\partial \mathcal{H}}{\partial \mathbf{p}} = \mathbf{p}, \tag{510}$$

$$\frac{\mathrm{d}\mathbf{p}}{\mathrm{d}\tau} = -\frac{\partial \mathcal{H}}{\partial \mathbf{z}} = -\frac{\partial \mathcal{V}(\mathbf{z})}{\partial \mathbf{z}} = \frac{\partial \log q_{\text{target}}(\mathbf{z})}{\partial \mathbf{z}}, \tag{511}$$

从当前样本 $\mathbf{x}$ 出发，在固定时长内运行以生成新样本 $\mathbf{x}'$. 这里 τ 是 Hamiltonian 动力学的虚拟时间参数. 关于 Hamiltonian 动力学的进一步讨论见第 3 章.

正如我们将在后续章节中确认的，这个 HMC 核（包括稍后将讨论的动量重采样步）具有 Boltzmann 分布

$$p(\mathbf{z}, \mathbf{p}) \propto \exp(-\mathcal{H}(\mathbf{z}, \mathbf{p})) \tag{512}$$

作为平稳分布. 然而请注意，我们只对样本 $\{\mathbf{z}_n\}$ 感兴趣；动量变量 $\{\mathbf{p}_n\}$ 只是作为辅助变量被加入以定义 Hamiltonian 动力学. 幸运的是，由于 $p(\mathbf{p})$ 独立于 $\mathbf{z}$，动量变量与位置变量相互独立，因此 Boltzmann 分布在原始变量 $\mathbf{z}$ 上的边缘分布对应于我们的目标分布：

$$\int \mathrm{d}\mathbf{p}\, \exp(-\mathcal{H}(\mathbf{z}, \mathbf{p})) = \int \mathrm{d}\mathbf{p}\, \exp\left(-\frac{1}{2}\|\mathbf{p}\|^2\right) \exp(-\mathcal{V}(\mathbf{z})) \propto \exp(-\mathcal{V}(\mathbf{z})) = q_{\text{target}}(\mathbf{z}). \tag{513}$$

因此我们唯一要做的就是忽略样本 $\{\mathbf{p}_n\}$，因为样本 $\{\mathbf{z}_n\}$ 按定义按该边缘分布分布.

然而为证明这是正确的，我们仍需证明 HMC 具有 Boltzmann 分布 $p(\mathbf{z}, \mathbf{p}) \propto \exp(-\mathcal{H}(\mathbf{z}, \mathbf{p}))$ 作为其唯一平稳分布并收敛到它.

通过动量翻转实现可逆性 人们可以问：由 Hamilton 运动方程定义的过渡核 F 的选择是否满足关于联合分布 $p(\mathbf{z}, \mathbf{p})$ 的 DB? 与 Gibbs 采样器类似，结果表明并非如此；它满足的是不变性条件. 这可以通过考虑 Hamiltonian 动力学是体积与能量保持的来证明. 能量守恒可以通过对 Hamiltonian 关于时间求导来容易地证明：

$$\frac{\mathrm{d}\mathcal{H}}{\mathrm{d}\tau} = \frac{\partial \mathcal{H}}{\partial \mathbf{z}}\frac{\mathrm{d}\mathbf{z}}{\mathrm{d}\tau} + \frac{\partial \mathcal{H}}{\partial \mathbf{p}}\frac{\mathrm{d}\mathbf{p}}{\mathrm{d}\tau} = \frac{\partial \mathcal{H}}{\partial \mathbf{z}}\frac{\partial \mathcal{H}}{\partial \mathbf{p}} + \frac{\partial \mathcal{H}}{\partial \mathbf{p}}\left(-\frac{\partial \mathcal{H}}{\partial \mathbf{z}}\right) = 0. \tag{514}$$

关于体积保持，我们参考第 3 章的讨论.

要看到能量与体积保持如何导出 Boltzmann 分布成为 HMC 的平稳分布，我们首先考虑：由 Hamiltonian 动力学定义的马尔可夫核可以写成 delta 函数的形式，

$$F(\mathbf{x}'|\mathbf{x}) = \delta(\mathbf{x}' - \Phi(\mathbf{x})), \tag{515}$$

其中 $\Phi(\mathbf{x})$ 定义了从 $\mathbf{x}$ 出发在固定时间内运行 Hamiltonian 动力学的解. 若我们把它代入不变性条件 (492) 的定义，并结合 Boltzmann 分布 (512)，我们得到

$$\int \mathrm{d}\mathbf{x}\, p(\mathbf{x})F(\mathbf{x}'|\mathbf{x}) = \int \mathrm{d}\mathbf{x}\, \frac{1}{Z}\exp(-\mathcal{H}(\mathbf{x}))\delta(\mathbf{x}' - \Phi(\mathbf{x})) = \frac{1}{Z}\exp(-\mathcal{H}(\Phi^{-1}(\mathbf{x}'))) \cdot |\det \mathbf{J}_{\Phi^{-1}}(\mathbf{x}')| \tag{516}$$

其中我们使用了变量替换公式 (53)，以逆变换 $\Phi^{-1}(\mathbf{x}')$ 重写积分. 现在若考虑 Hamiltonian 动力学是体积保持的，

$$\exp(-\mathcal{H}(\Phi^{-1}(\mathbf{x}'))) \cdot |\det \mathbf{J}_{\Phi^{-1}}(\mathbf{x}')| = \exp(-\mathcal{H}(\Phi^{-1}(\mathbf{x}'))), \tag{517}$$

以及能量保持的，

$$\exp(-\mathcal{H}(\Phi^{-1}(\mathbf{x}'))) = \exp(-\mathcal{H}(\mathbf{x}')), \tag{518}$$

我们确实发现不变性条件被满足：

$$\int \mathrm{d}\mathbf{x}\, p(\mathbf{x})F(\mathbf{x}'|\mathbf{x}) = p(\mathbf{x}'). \tag{519}$$

在这种情形下，伴随核 A 可以通过沿相反方向（以 $\mathbf{p}$ 的反方向）遍历路径来构造. 若动力学不保持能量与体积，伴随核还需考虑两点之间的 Jacobian 与能量差.

恢复 DB 条件的一种朴素方法是简单地在每条轨迹末尾添加一个翻转动量的步. 这是因为，有了额外的动量翻转，F 成为一个对合（involution），因而可用于从 $\mathbf{x} \to \mathbf{x}'$ 再返回. 然而，虽然这会形式上恢复 DB，但它仍有一个遗留问题：它只是在两点之间来回移动，因此永远无法满足遍历性.[7]

一般地，可以证明确定性动力学只有当它是对合 (involution) 时才能满足 DB (Neklyudov et al., 2020)：即满足 $f(f(x)) = x$ 的映射.

通过动量重采样实现遍历性 虽然能量守恒是一个有助于通过不变性条件证明 HMC 具有正确平稳分布的有用性质，但不幸的是它使最简形式的 HMC 无法满足遍历性. 给定能量为 $E_0 = \mathcal{H}(\mathbf{z}_0, \mathbf{p}_0)$ 的初始 $\mathbf{z}_0$ 与 $\mathbf{p}_0$，该马尔可夫核将只访问能量为 E_0 的状态. 这使得该马尔可夫核非遍历，因此它不会收敛到联合分布 $p(\mathbf{z}, \mathbf{p})$，而该联合分布以我们的目标分布 $q_{\text{target}}(\mathbf{z})$ 为其边缘.

如前简要提及，我们常通过引入随机步来解决非遍历性. 在 HMC 的情形下，这通过在 HMC 核的开头添加一个从各向同性 Gaussian 分布重新初始化动量的步来实现. 这将把系统置于一个新的能量水平上，供下一次 HMC 核迭代遍历. 这被称为*动量重采样*（momentum resampling），它确保该核是遍历的.

关键的是，我们可以证明：这个动量重采样步还将确保 HMC 核满足关于 $p(\mathbf{z}, \mathbf{p})$ 的 DB，若我们还在核的末尾包含动量翻转步，从而使它完全适用于 MCMC：既具有正确的平稳分布，又收敛到该分布.

这个同时具有动量翻转与动量重采样步的版本，正是机器学习/MCMC 社区通常所称的 HMC.

[7] 我们提醒读者注意 §11.3.1 末尾的评论：物理学家确实称 HMC 为可逆的，并说它满足 DB，这是由于他们对 DB 的不同定义.

离散化 最后，我们对 HMC 核（或任何其他基于确定性连续时间动力学的 MCMC 核）的实际实现做一说明. 为实际实现 HMC 核，我们需要离散化 (511) 中给出的动力学.

这通常通过使用一个可逆且辛（symplectic）的积分器来完成，例如蛙跳（leapfrog）或 Verlet 积分，用于模拟这些方程，以一系列步骤更新位置与动量：

$$\mathbf{p}_{\tau+\frac{1}{2}\delta\tau} = \mathbf{p}_\tau - \frac{1}{2}\frac{\partial \mathcal{V}(\mathbf{z}_\tau)}{\partial \mathbf{z}}\delta\tau, \tag{520}$$

$$\mathbf{z}_{\tau+\delta\tau} = \mathbf{z}_\tau + \mathbf{p}_{\tau+\frac{1}{2}\delta\tau}\delta\tau, \tag{521}$$

$$\mathbf{p}_{\tau+\delta\tau} = \mathbf{p}_{\tau+\frac{1}{2}\delta\tau} - \frac{1}{2}\frac{\partial \mathcal{V}(\mathbf{z}_{\tau+\delta\tau})}{\partial \mathbf{z}}\delta\tau. \tag{522}$$

我们的马尔可夫核 $F(\mathbf{x}'|\mathbf{x})$ 现在对应于固定的积分时间 $T = N\delta\tau$，其中 N 与 $\delta\tau$ 都是待调参数. 然而，这使得近似 Hamiltonian 动力学不再严格保持能量，因此该核不再具有正确的平稳分布. 幸运的是，我们仍有可信的 MH 接受步来恢复 DB. 我们可以证明，当使用一个精确保持相空间体积的可逆辛积分器时，HMC 提议的接受概率为：

$$p_{\text{accept}}(\mathbf{x}_{\tau+N\delta\tau}|\mathbf{x}_\tau) = \min\left[1, \exp\big(\mathcal{H}(\mathbf{z}_\tau, \mathbf{p}_\tau) - \mathcal{H}(\mathbf{z}_{\tau+N\delta\tau}, \mathbf{p}_{\tau+N\delta\tau})\big)\right]. \tag{523}$$

时间步长 $\delta\tau$ 通常选择得足够小，以确保能量仍近似守恒（$\Delta\mathcal{H} \approx 0$），从而使接受率接近 1.

对于非体积保持的积分器，接受率还需包含一个对应于相空间体积变化的 Jacobian 因子. Hamiltonian 动力学还保持相空间中的体积，如我们在第 3 章中所示.

11.4.3 Langevin 蒙特卡洛

最后，我们提及基于Langevin *动力学*（Langevin dynamics）的 Langevin 蒙特卡洛（LMC）采样器：

$$\mathrm{d}\mathbf{z} = \eta\frac{\partial \log q_{\text{target}}(\mathbf{z})}{\partial \mathbf{z}}\mathrm{d}\tau + \sqrt{2\eta}\,\mathrm{d}W_\tau, \tag{524}$$

其中 $\mathrm{d}W_\tau$ 是 Wiener 过程，η 是控制系统迁移率的参数.

如果我们通过在固定时长内运行这些连续时间 Langevin 动力学来构造马尔可夫核 $F(\mathbf{z}'|\mathbf{z})$，我们可以证明它满足关于目标分布 $q_{\text{target}}(\mathbf{z})$ 的细致平衡条件，并且它是遍历的. 这些证明更为复杂，需要通过 Fokker–Planck 方程展示平稳性，这将在第 21 章中讨论.

离散化 与 HMC 类似，为在实践中实现 LMC 核，我们需要离散化 (524) 中的动力学. 一种方法是使用 Euler–Maruyama 方法，一种简单且广泛使用的求解随机微分方程的数值方法. Euler–Maruyama 更新为：

$$\mathbf{z}_{\tau+\delta\tau} = \mathbf{z}_\tau + \eta\frac{\partial \log q_{\text{target}}(\mathbf{z}_\tau)}{\partial \mathbf{z}}\delta\tau + \sqrt{2\eta\delta\tau}\,\boldsymbol{\epsilon}_\tau, \qquad \boldsymbol{\epsilon}_\tau \sim G(\mathbf{0}, \mathbf{I}). \tag{525}$$

同样，与 HMC 类似，离散化后动力学不再严格可逆，因此不再使目标分布 $q_{\text{target}}(\mathbf{z})$ 保持不变. 为在步长 $\delta\tau$ 不是无穷小时解释这些误差，我们需要额外的 Metropolis–Hastings 校正步. 对于离散化动力学的单步，提议分布是 Gaussian，接受概率为

$$p_{\text{accept}}(\mathbf{z}_{\tau+\delta\tau}|\mathbf{z}_\tau) = \min\left[1, \frac{q_{\text{target}}(\mathbf{z}_{\tau+\delta\tau})G(\mathbf{z}_\tau; \boldsymbol{\mu}', 2\eta\delta\tau\,\mathbf{I})}{q_{\text{target}}(\mathbf{z}_\tau)G(\mathbf{z}_{\tau+\delta\tau}; \boldsymbol{\mu}, 2\eta\delta\tau\,\mathbf{I})}\right], \tag{526}$$

$$\boldsymbol{\mu} = \mathbf{z}_\tau + \eta\frac{\partial \log q_{\text{target}}(\mathbf{z}_\tau)}{\partial \mathbf{z}}\delta\tau, \tag{527}$$

$$\boldsymbol{\mu}' = \mathbf{z}_{\tau+\delta\tau} + \eta\frac{\partial \log q_{\text{target}}(\mathbf{z}_{\tau+\delta\tau})}{\partial \mathbf{z}}\delta\tau. \tag{528}$$

这个带有 MH 校正的 Langevin 蒙特卡洛版本通常被称为Metropolis 校正 Langevin 算法（Metropolis-adjusted Langevin algorithm, MALA）. 当步长 $\delta\tau$ 减小时，接受概率趋近于 1，该算法退化为未校正的连续时间 Langevin 动力学.

你可以证明，Langevin MCMC 采样器是 HMC 的一个极限情形，我们在蛙跳积分器的前两行中识别：

$$\boldsymbol{\epsilon}_\tau = \mathbf{p}_\tau \sim G(\mathbf{0}, \mathbf{I}), \tag{529}$$

$$\eta = \frac{1}{2}\delta\tau. \tag{530}$$

然而，与 HMC（在蛙跳积分期间对 $\mathbf{p}$ 使用确定性更新）不同，Langevin 动力学通过噪声项 $\sqrt{2\eta\delta\tau}\,\boldsymbol{\epsilon}_\tau$ 在每一步引入随机性.

在物理学中，Langevin 蒙特卡洛方法被广泛用于从复杂的高维分布中采样，从分子（Frenkel and Smit, 2001）一直到格点规范理论这样复杂的问题. 在机器学习中，Langevin 采样器被用于从后验分布中生成样本（Salimans et al., 2015）以及从基于能量的模型（EBM）中生成样本，也被用于训练它们（Du and Mordatch, 2019; Song and Kingma, 2021; Carbone et al., 2023）. Log-梯度项还与扩散模型的 score-matching 目标有密切联系，我们将在后续章节中讨论.

Chapter 12

序贯重要性采样

12.1 引言

在上一章中，我们考察了 MCMC 方法族，它们通过构造一条收敛到目标分布的马尔可夫链来从目标分布中采样. 这使得 MCMC 方法成为从复杂分布中采样的极其强大的工具. 然而，MCMC 方法并非没有局限. 最重要的是，当目标分布是多峰的、且各峰之间由低概率区域隔开时，它们的收敛时间可能是指数级长的；而且关键在于，虽然它们甚至可以从未归一化分布中采样，但其生成的样本却不能用来逼近该未归一化密度的归一化常数.

与 MCMC 不同，重要性采样虽然不提供来自目标分布的精确样本，但如预备章节所述，它提供了一个强大的工具来逼近任意目标分布下函数的期望，包括多峰分布. 而且关键在于，IS 可以以自归一化重要性采样的形式来逼近未归一化目标分布的归一化常数.

然而不幸的是，IS 并非万能解药. 为了使 IS 提供有效且高效的估计程序，提议分布 $q(\mathbf{x})$ 必须满足某些要求. 首先，它必须在目标分布 $p_{\text{target}}(\mathbf{x})$ 有定义的所有地方都有支撑，也就是说，$q(\mathbf{x})$ 在 $p_{\text{target}}(\mathbf{x})$ 非零之处也必须非零. 其次，提议分布应选择得与目标密度尽可能相似，以减小重要性权重的方差，这一点可由 (535) 推知. 然而在高维空间中，重要性采样往往因维数灾难而失败：大多数样本的权重可忽略不计，只有少数样本主导估计. 这使得随着维数增加，设计有效的提议分布变得具有挑战性.

这正是序贯重要性采样的用武之地. 与 MCMC 类似，SIS 不是直接从提议分布中采样，而是用马尔可夫核迭代地更新一组样本. 然而与 MCMC 不同的是，所使用的马尔可夫核通常是时间依赖的，这使得我们可以计算出非平凡的重要性权重. 一类特别重要的 SIS 方法是退火重要性采样（AIS）(Neal, 2001)，它与随机热力学（ST）中的概念密切相关.

我们将在本章首先简要讨论 IS 和 SNIS 估计量的方差，然后转入讨论序贯重要性采样框架.

12.2 IS 与 SNIS 的方差

简要回顾一下，重要性采样和自归一化重要性采样是两种用于估计目标分布下函数期望的方法. 给定目标是估计函数 $f(\mathbf{x})$ 在目标分布 $p_{\text{target}}(\mathbf{x}) = \frac{1}{Z_p}\gamma(\mathbf{x})$ 下的期望，IS 和

SNIS 估计量分别为

$$\mathbb{E}_{p_{\text{target}}}[f(\mathbf{x})] \simeq \langle f \rangle_{\text{IS}} = \frac{1}{N}\sum_{n=1}^{N} w(\mathbf{x}_n) f(\mathbf{x}_n), \tag{531}$$

$$\mathbb{E}_{p_{\text{target}}}[f(\mathbf{x})] \simeq \langle f \rangle_{\text{SNIS}} = \frac{\frac{1}{N}\sum_{n=1}^{N} \tilde{w}(\mathbf{x}_n) f(\mathbf{x}_n)}{\frac{1}{N}\sum_{n=1}^{N} \tilde{w}(\mathbf{x}_n)}, \tag{532}$$

其中归一化重要性权重和未归一化重要性权重定义为

$$w(\mathbf{x}_n) = \frac{p_{\text{target}}(\mathbf{x}_n)}{q(\mathbf{x}_n)}, \qquad \tilde{w}(\mathbf{x}_n) = \frac{\gamma(\mathbf{x}_n)}{q(\mathbf{x}_n)}. \tag{533}$$

有趣的是，对于任意未归一化目标密度 $\gamma(\mathbf{x})$，我们可以用未归一化重要性权重来估计归一化常数 Z_p：

$$\mathbb{E}_q[\tilde{w}(\mathbf{x})] = Z_p. \tag{534}$$

现在我们来考察这两个估计量的方差. IS 估计量的方差为

$$\begin{aligned}
\mathbb{V}[\langle f \rangle_{\text{IS}}] &= \mathbb{V}\left[\frac{1}{N}\sum_{n=1}^{N} w(\mathbf{x}_n) f(\mathbf{x}_n)\right] \\
&= \frac{1}{N^2}\sum_{n=1}^{N} \mathbb{V}[w(\mathbf{x}_n) f(\mathbf{x}_n)] \\
&= \frac{1}{N}\mathbb{V}[w(\mathbf{x}) f(\mathbf{x})] \\
&= \frac{1}{N}\left(\mathbb{E}_q[w(\mathbf{x})^2 f(\mathbf{x})^2] - \mathbb{E}_{p_{\text{target}}}[f(\mathbf{x})]^2\right),
\end{aligned} \tag{535}$$

其中包含 $f(\mathbf{x})$ 真实期望值的常数项通常可以忽略，因为它与样本无关. 类似地，我们可以推导 SNIS 估计量的渐近方差为

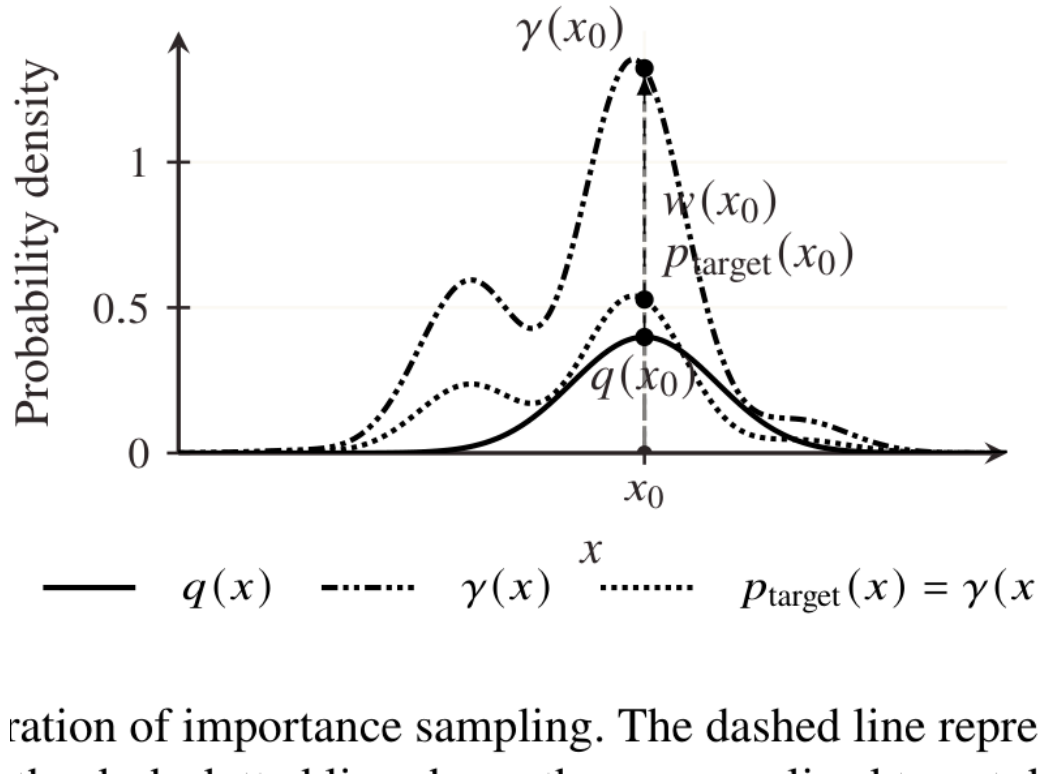
$$\mathbb{V}[\langle f \rangle_{\text{SNIS}}] \approx \frac{1}{N}\mathbb{E}_q[w(\mathbf{x})^2 (f(\mathbf{x}) - \mathbb{E}_{p_{\text{target}}}[f(\mathbf{x})])^2], \tag{536}$$

值得注意的是，虽然它与 IS 估计量具有相同的领头阶 $1/N$，但由于围绕均值中心化，它通常比 IS 估计量的方差更小.

对本章余下部分更为根本的是，在估计归一化常数 Z_p 的情形中（即 $f(\mathbf{x}) = 1$），归一化常数估计量 $\hat{Z}_p = \frac{1}{N}\sum_{n=1}^{N} \tilde{w}(\mathbf{x}_n)$ 的方差为

$$\mathbb{V}[\hat{Z}_p] = \frac{1}{N}\mathbb{V}[\tilde{w}(\mathbf{x})] = \frac{1}{N}\left(\mathbb{E}_q[\tilde{w}(\mathbf{x})^2] - Z_p^2\right), \tag{537}$$

这表明我们可以通过选择与未归一化目标密度 $\gamma(\mathbf{x})$ 尽可能相似的提议分布 $q(\mathbf{x})$ 来最小化归一化常数估计量的方差，从而最小化重要性权重平方的期望（见 图 36）.



ration of importance sampling. The dashed line repre

图 36: 重要性采样示意. 虚线表示提议分布 $q(x)$，点划线表示未归一化目标密度 $\gamma(x)$，点线表示归一化目标密度 $p_{\text{target}}(x) = \gamma(x)/Z_p$. 在某一点 x_0 处，重要性权重为 $w(x_0) = \gamma(x_0)/q(x_0)$；垂直辅助线标示了该比值中使用的值. 这些权重用于校正从 $q(x)$ 而非目标分布采样所带来的偏差. 重要性采样的有效性取决于 $q(x)$ 对 $p_{\text{target}}(x)$ 的逼近程度，最优情形是两者成比例.

选择与目标密度尽可能相似的提议分布、从而通过最小化权重 $\tilde{w}(\mathbf{x})$ 的方差来最小化 Z_p 的 IS 估计方差的这一思想非常强大. 正如我们接下来要讨论的，SIS 不仅克服了重要性采样在维度扩展性方面的挑战，还引入了一个框架，其中存在多种调节权重以最小化方差的途径.

12.3 序贯重要性采样

为了绕开 IS 的问题，序贯重要性采样引入了一列中间分布 $\{\pi_t\}$，它们从一个易于处理的分布 π_0 桥接到目标分布 $\pi_{t_f} = p_{\text{target}}$. 通常选择

$$\pi_t(\mathbf{x}) = \frac{\gamma_0(\mathbf{x})^{1-\beta_t}\gamma(\mathbf{x})^{\beta_t}}{Z_t}, \tag{538}$$

其中 $0 = \beta_0 < \beta_1 < \cdots < \beta_{t_f} = 1$ 是退火调度，Z_t 是中间分布 π_t 的归一化常数. 也可以考虑其他参数化方式，而参数化的选择对估计量的方差起着至关重要的作用.

12.3.1 沿时间正向延拓提议分布

此外，SIS 定义了一列时间依赖的转移核 F_t. 理论上，它们可以是任意有效的马尔可夫核，不需要具有特定的平稳分布或满足遍历性，但在实践中我们通常选择它们使相应的中间分布 π_t 保持不变，即满足以下条件：

$$F_t(\mathbf{x}_t|\mathbf{x}_{t-1})\pi_t(\mathbf{x}_{t-1}) = A_t(\mathbf{x}_{t-1}|\mathbf{x}_t)\pi_t(\mathbf{x}_t), \tag{539}$$

其中 A_t 是对应于 F_t 的伴随核，它也使同一平稳分布 π_t 保持不变，记号遵循第 9 章所建立的约定.

通过采样 $\mathbf{x}_0 \sim \pi_0$ 并依次施加转移核序列 F_t，SIS 构造了一个扩展的联合提议分布

$$Q(\mathbf{x}_{0:t_f}) = \pi_0(\mathbf{x}_0)\prod_{t=1}^{t_f} F_t(\mathbf{x}_t|\mathbf{x}_{t-1}). \tag{540}$$

第 t 步的边缘分布为

$$\begin{aligned} q_t(\mathbf{x}_t) &= \int d\mathbf{x}_{0:t-1}\, d\mathbf{x}_{t+1:t_f}\, Q(\mathbf{x}_{0:t_f}) \\ &= \int d\mathbf{x}_{0:t-1}\, \pi_0(\mathbf{x}_0)\prod_{j=1}^{t} F_j(\mathbf{x}_j|\mathbf{x}_{j-1}). \end{aligned} \tag{541}$$

由于转移核 F_t 在每一步都在变化，系统只有有限的时间来混合. 因此，在每一步采样之后，第 t 个样本的边缘分布 q_t 并不等于第 t 个核的平衡分布 π_t；也就是说，$q_t \neq \pi_t$. 用热力学的语言来说，我们称系统远离平衡态，并且不是在绝热演化（见 图 37）.[8]

12.3.2 沿时间反向延拓目标分布

我们现在引入第二个扩展联合分布，但这次是从目标分布反向运行：

$$P(\mathbf{x}_{0:t_f}) = \frac{1}{Z_p}\gamma(\mathbf{x}_{t_f})\prod_{t=1}^{t_f} K_t(\mathbf{x}_{t-1}|\mathbf{x}_t), \tag{542}$$

其中 K_t 是有效的马尔可夫转移核，满足 $\int d\mathbf{x}_{t-1}K_t(\mathbf{x}_{t-1}|\mathbf{x}_t) = 1$. 由构造可知，最后一步 t_f 的边缘分布就是目标分布：

$$p_{t_f}(\mathbf{x}_{t_f}) = \int d\mathbf{x}_{0:t_f-1}\, P(\mathbf{x}_{0:t_f}) = \frac{\gamma(\mathbf{x}_{t_f})}{Z_p} = p_{\text{target}}(\mathbf{x}_{t_f}). \tag{543}$$

12.3.3 利用 SIS 框架估计期望

对于任意选择的前向核和后向核（它们之间不需要有任何关系），我们可以设计一个程序来计算函数 $h(\mathbf{x})$ 的近似平均. 首先，我们令 $\mathbf{x} = \mathbf{x}_{t_f}$，并将随机变量空间延拓为

[8]注意，引入扩展联合分布的方法在文献中通常被称为 序贯蒙特卡洛（SMC）方法（Del Moral et al., 2006），而非序贯或退火重要性采样. 我们将 SMC 保留给更特定的情形，即引入额外步骤（如 MCMC 步或重加权）以强制使 $q_t \approx \pi_t$.

$\{\mathbf{x}_0, \ldots, \mathbf{x}_{t_f}\}$. 然后我们从前向链（由构造可知是易于处理的）中采样，并计算由后向与前向联合分布之比给出的未归一化重要性权重，类似于 (533)：

$$w(\mathbf{x}_{0:t_f}) = \frac{P(\mathbf{x}_{0:t_f})}{Q(\mathbf{x}_{0:t_f})} = \frac{\gamma(\mathbf{x}_{t_f}) \prod_{t=1}^{t_f} K_t(\mathbf{x}_{t-1}|\mathbf{x}_t)}{\pi_0(\mathbf{x}_0) \prod_{t=1}^{t_f} F_t(\mathbf{x}_t|\mathbf{x}_{t-1})}. \tag{544}$$

注意，此前我们用 $\tilde{w}$ 表示未归一化重要性权重，用 w 表示归一化重要性权重. 由于本章余下部分以及本书大部分内容将主要处理未归一化概率分布，为简单起见，从今以后我们用 w 表示未归一化重要性权重.

函数 $h(\mathbf{x})$ 在目标分布下的期望可以用与 IS 相同的方式估计，即使用重要性权重：

$$\mathbb{E}_p[h] \simeq \frac{\sum_{n=1}^N w_n h(\mathbf{x}_{t_f}^n)}{\sum_{n=1}^N w_n}, \qquad w_n \equiv w(\mathbf{x}_0^n, \ldots, \mathbf{x}_{t_f}^n), \quad \mathbf{x}_0^n, \ldots, \mathbf{x}_{t_f}^n \sim Q. \tag{545}$$

此外，如果我们选择 $h = Z_p$（即一个常数），则得到

$$\hat{Z}_p \simeq \frac{1}{N} \sum_{n=1}^N w(\mathbf{x}_0^n, \ldots, \mathbf{x}_{t_f}^n) = \frac{1}{N} \sum_{n=1}^N w_n. \tag{546}$$

我们注意到，可以通过简单地使函数 h 独立于那些维度，将仅在 $\mathbf{x}_{t_f}$ 上定义的函数 h 延拓到整个序列上.

非常有趣的是，这些结果在理论上对任意选择的 Q 和 P 都成立（见 节 17.2 中的讨论）. 然而，如果不明智地选择它们，我们的估计将面临非常大的方差. 下面我们讨论一些选择，并将它们与 ST 和 ML 联系起来，强调方差缩减的启发式方法.

退火重要性采样 我们现在考虑 SIS 的一个特例：退火重要性采样（annealed importance sampling）（AIS）. 在 AIS 中，后向核 K_t 通常被选为前向核 F_t 关于中间分布 π_t 的伴随：

$$K_t(\mathbf{x}_{t-1}|\mathbf{x}_t) = A_t(\mathbf{x}_{t-1}|\mathbf{x}_t) \tag{547}$$

$$= \frac{\pi_t(\mathbf{x}_{t-1}) F_t(\mathbf{x}_t|\mathbf{x}_{t-1})}{\pi_t(\mathbf{x}_t)}. \tag{548}$$

注意，这个核必然存在；但如果我们选择 F_t 使 π_t 不变，那么我们也明确知道 A_t 同样具有相应的平稳分布 π_t. 这在下一步中将很有用. 事实上，在这样选择后向核的情

况下，AIS 中的重要性权重简化为

$$
\begin{aligned}
w(\mathbf{x}_{0:t_f}) &= \frac{\gamma(\mathbf{x}_{t_f}) \prod_{t=1}^{t_f} K_t(\mathbf{x}_{t-1}|\mathbf{x}_t)}{\pi_0(\mathbf{x}_0) \prod_{t=1}^{t_f} F_t(\mathbf{x}_t|\mathbf{x}_{t-1})} \\
&= \frac{\gamma(\mathbf{x}_{t_f}) \prod_{t=1}^{t_f} A_t(\mathbf{x}_{t-1}|\mathbf{x}_t)}{\pi_0(\mathbf{x}_0) \prod_{t=1}^{t_f} F_t(\mathbf{x}_t|\mathbf{x}_{t-1})} \\
&= \frac{\gamma(\mathbf{x}_{t_f}) \prod_{t=1}^{t_f} \frac{\pi_t(\mathbf{x}_{t-1}) F_t(\mathbf{x}_t|\mathbf{x}_{t-1})}{\pi_t(\mathbf{x}_t)}}{\pi_0(\mathbf{x}_0) \prod_{t=1}^{t_f} F_t(\mathbf{x}_t|\mathbf{x}_{t-1})} \\
&= Z_0 \frac{\gamma(\mathbf{x}_{t_f})}{\gamma_0(\mathbf{x}_0)} \prod_{t=1}^{t_f} \frac{\gamma_t(\mathbf{x}_{t-1})}{\gamma_t(\mathbf{x}_t)} \\
&= Z_0 \frac{\gamma(\mathbf{x}_{t_f})}{\gamma_{t_f}(\mathbf{x}_{t_f})} \prod_{t=1}^{t_f} \frac{\gamma_t(\mathbf{x}_{t-1})}{\gamma_{t-1}(\mathbf{x}_{t-1})} \\
&= Z_0 \prod_{t=1}^{t_f} \frac{\gamma_t(\mathbf{x}_{t-1})}{\gamma_{t-1}(\mathbf{x}_{t-1})},
\end{aligned} \tag{549}
$$

我们认出这就是退火重要性权重，其中 Z_0 是初始分布 π_0 的配分函数.

与随机热力学的联系 如果我们写 $\gamma_t(\mathbf{x}_t) = \exp(-\beta \mathcal{H}_t(\mathbf{x}_t))$，[9] 则权重可以用退火过程中所做的功来表示：

$$
\begin{aligned}
w(\mathbf{x}_{0:t_f}) &= Z_0 \exp\left(-\beta \sum_{t=1}^{t_f} [\mathcal{H}_t(\mathbf{x}_{t-1}) - \mathcal{H}_{t-1}(\mathbf{x}_{t-1})] \right) \\
&= Z_0 \exp(-\beta \mathcal{W}[\mathbf{x}_0, \ldots, \mathbf{x}_{t_f}]),
\end{aligned} \tag{550}
$$

其中，如果我们暂时假设细致平衡，指数中的表达式 $\mathcal{W}[\mathbf{x}_0, \ldots, \mathbf{x}_{t_f}]$ 表示在这一系列步骤中所做的功. 如果我们现在利用 (546) 并将其重新表述为功的形式，我们就得到在 ST（第 10 章）中被称为 Jarzynski 等式（Jarzynski equality）的结果，用于估计自由能：

$$
\frac{Z_p}{Z_0} = \mathbb{E}_Q \left[\exp(-\beta \mathcal{W}[\mathbf{x}_0, \ldots, \mathbf{x}_{t_f}]) \right], \tag{551}
$$

其中平均是对从前向过程 Q 中采样的序列取的. 注意，与 Jarzynski 等式的这种联系仅在细致平衡成立且我们按 (547) 选择后向核的情况下才成立. 在没有细致平衡的情况下，这与第 17 章讨论的非绝热熵产生的涨落定理相关.

[9] 注意，这里的逆温度 β 与为 AIS 定义的温度调度 β_t 不同. 此处 β 由热浴决定，而上面的序列只是为了定义一列边缘分布. 我们已将所有时间依赖性吸收到 Hamiltonian $\mathcal{H}_t$ 中.

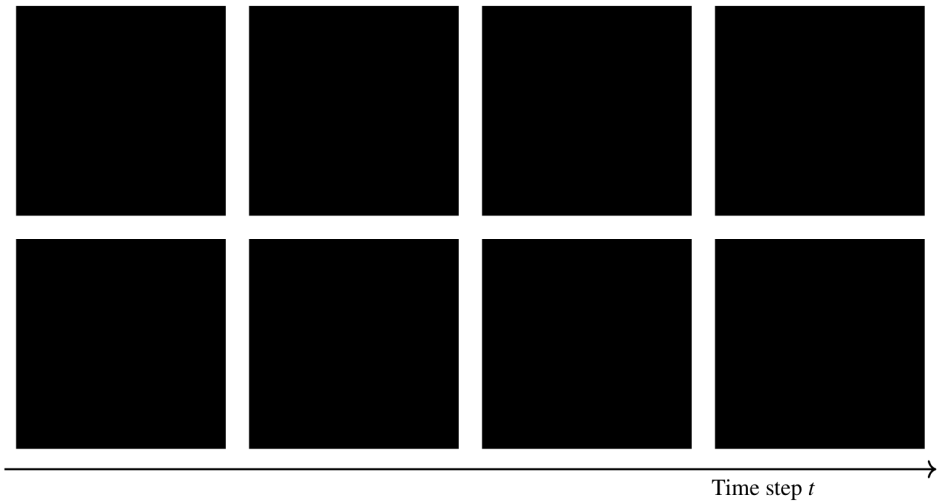


Figure 12.2 Evolution of probability distributions and transition kernels in sequential

图 37: 序贯重要性采样中概率分布与转移核的演化. 每个面板代表一个时间步. 顶行: 平衡分布 π_t（实线等值线），满足第 9 章平衡条件的前向核 F_t（实线顺时针箭头）与伴随核 A_t（实线逆时针箭头）. 底行: 前向过程的瞬时平衡分布 π_t（实线曲线）和边缘分布 q_t（虚线曲线），参见 (541). “滞后” 箭头表明在有限时间内 $q_t \neq \pi_t$；也就是说，系统被驱离平衡，在下一个核施加之前无法完全弛豫. 从左到右逐渐增大的偏差表明这种非平衡滞后通常随演化推进而增长.

12.3.4 优化序贯重要性采样

我们在 AIS 中对 K_t 所做的选择 (547) 在最小化重要性权重方差方面并不是最优的.

为了找到最优核，让我们计算重要性权重的方差. 类似于 (535)，重要性权重的方差可以利用总方差定律（Cover and Thomas, 2006）分解为

$$\begin{aligned}
\mathbb{V}_Q[w(\mathbf{x}_{0:t_f})] &= \mathbb{E}_Q[w(\mathbf{x}_{0:t_f})^2] - \mathbb{E}_Q[w(\mathbf{x}_{0:t_f})]^2 \\
&= \mathbb{E}_{q_{t_f}}[\mathbb{E}_{Q(\cdot|\mathbf{x}_{t_f})}[w(\mathbf{x}_{0:t_f})^2]] - \mathbb{E}_{q_{t_f}}[\mathbb{E}_{Q(\cdot|\mathbf{x}_{t_f})}[w(\mathbf{x}_{0:t_f})]]^2 \\
&= \mathbb{E}_{q_{t_f}}[\mathbb{E}_{Q(\cdot|\mathbf{x}_{t_f})}[w(\mathbf{x}_{0:t_f})^2] - \mathbb{E}_{Q(\cdot|\mathbf{x}_{t_f})}[w(\mathbf{x}_{0:t_f})]^2] \\
&\quad + \mathbb{E}_{q_{t_f}}[\mathbb{E}_{Q(\cdot|\mathbf{x}_{t_f})}[w(\mathbf{x}_{0:t_f})]^2] - \mathbb{E}_{q_{t_f}}[\mathbb{E}_{Q(\cdot|\mathbf{x}_{t_f})}[w(\mathbf{x}_{0:t_f})]]^2 \\
&= \mathbb{E}_{q_{t_f}}[\mathbb{V}_{Q(\cdot|\mathbf{x}_{t_f})}[w(\mathbf{x}_{0:t_f})]] + \mathbb{V}_{q_{t_f}}[\mathbb{E}_{Q(\cdot|\mathbf{x}_{t_f})}[w(\mathbf{x}_{0:t_f})]] \\
&= \mathbb{E}_{q_{t_f}}[\mathbb{V}_{Q(\cdot|\mathbf{x}_{t_f})}[w(\mathbf{x}_{0:t_f})]] + \mathbb{V}_{q_{t_f}}[w_{\mathrm{mar}}(\mathbf{x}_{t_f})], \qquad (552)
\end{aligned}$$

其中 $w_{\mathrm{mar}}(\mathbf{x}_{t_f}) = \gamma(\mathbf{x}_{t_f})/q_{t_f}(\mathbf{x}_{t_f})$ 是最后一步的边缘重要性权重，第一项可以通过对每一步 $t = 1, \ldots, t_f$ 递归应用总方差定律，分解为在边缘分布上取平均的每一步重要性权重的期望方差.

一个高度相关的计算可以利用 KL 散度来进行. 首先，回顾前面章节，我们可以用

后向核 B 来反演前向模型，B 定义为

$$B_t(\mathbf{x}_{t-1}|\mathbf{x}_t) = \frac{F_t(\mathbf{x}_t|\mathbf{x}_{t-1})q_{t-1}(\mathbf{x}_{t-1})}{q_t(\mathbf{x}_t)} \tag{553}$$

$$\Rightarrow \quad Q(\mathbf{x}_{0:t_f}) = q_{t_f}(\mathbf{x}_{t_f}) \prod_{t=1}^{t_f} B_t(\mathbf{x}_{t-1}|\mathbf{x}_t). \tag{554}$$

然后，前向与后向联合分布之间的 KL 散度可以用链式法则分解如下：

$$\begin{aligned} D_{\mathrm{KL}}[Q\|P] &= \mathbb{E}_Q\left[\log \frac{Q(\mathbf{x}_{0:t_f})}{P(\mathbf{x}_{0:t_f})}\right] \\ &= \mathbb{E}_Q\left[\log \frac{q_{t_f}(\mathbf{x}_{t_f})}{p_{t_f}(\mathbf{x}_{t_f})} + \log \frac{Q(\mathbf{x}_{0:t_f-1}|\mathbf{x}_{t_f})}{P(\mathbf{x}_{0:t_f-1}|\mathbf{x}_{t_f})}\right] \\ &= D_{\mathrm{KL}}[q_{t_f}\|p_{t_f}] + \mathbb{E}_{q_{t_f}}[D_{\mathrm{KL}}[Q(\cdot|\mathbf{x}_{t_f})\|P(\cdot|\mathbf{x}_{t_f})]] \\ &= D_{\mathrm{KL}}[q_{t_f}\|\pi_{t_f}] + \sum_{t=1}^{t_f} \mathbb{E}_{q_t}[D_{\mathrm{KL}}[B_t(\cdot|\mathbf{x}_t)\|K_t(\cdot|\mathbf{x}_t)]]. \end{aligned} \tag{555}$$

该分解中的第一项表示最后一步的边缘分布 q_{t_f} 与目标分布 π_{t_f} 之间的 KL 散度，而第二项是在各步上反演 F 的核与后向转移核 K 之间的期望 KL 散度，对边缘分布取平均.

对于固定的前向过程 Q，当后向核被选为给出前向过程逆的核 B 时，KL 散度和重要性权重的方差同时被最小化（Doucet et al., 2022）：

$$K_t^*(\mathbf{x}_{t-1}|\mathbf{x}_t) = B_t(\mathbf{x}_{t-1}|\mathbf{x}_t). \tag{556}$$

在这个最优点处，我们有

$$D_{\mathrm{KL}}[Q\|P] = D_{\mathrm{KL}}[q_{t_f}\|\pi_{t_f}], \tag{557}$$

$$\mathbb{V}_Q[w(\mathbf{x}_{0:t_f})] = \mathbb{V}_{q_{t_f}}[w_{\mathrm{mar}}(\mathbf{x}_{t_f})]. \tag{558}$$

我们看到它与 (547) 相比有两点不同：第一，我们用 q 而非 π；第二，我们使用两个相邻状态之间的轨迹平衡方程，而非目标分布在某个时刻 t 的平稳性条件. 这个方程反演了过程 $F_t : q_{t-1} \rightleftharpoons q_t$. 如果我们把 $F_t : q_{t-1} \rightleftharpoons q_t$ 看作将 q_{t-1} 变换为 q_t 的映射，那么 $K_t^* = B_t$ 实现了该过程的逆（就像把 “电影” 倒放一样）；也就是说，$K_t^* : q_t \rightleftharpoons q_{t-1}$. 回顾 π_t 与 q_t 之间的区别（见 图 37）：分布 π_t 是时刻 t 的固定目标分布，也是 F_t 的平稳分布，而 q_t 是前向过程 Q 在时刻 t 的边缘分布.

在这种 K_t^* 的最优选择下，重要性权重简化为最后一步目标密度与边缘密度之比：

$$w(\mathbf{x}_{0:t_f}) = \frac{\gamma(\mathbf{x}_{t_f}) \prod_{t=1}^{t_f} B_t(\mathbf{x}_{t-1}|\mathbf{x}_t)}{\pi_0(\mathbf{x}_0) \prod_{t=1}^{t_f} F_t(\mathbf{x}_t|\mathbf{x}_{t-1})} = \frac{\gamma(\mathbf{x}_{t_f})}{p_{t_f}(\mathbf{x}_{t_f})}. \tag{559}$$

虽然 q_{t_f} 不易处理，但如果我们能获得 K_t^*，那么用前向和后向核表示的权重表达式是易处理的. 一种方法是学习一个能近似反演 F_t 的良好 K_t^* 模型，然后利用该表达式计算重要性权重.

(559) 相对于 (549) 中 AIS 权重的优势在于它只涉及最后一步的边缘密度. 然而, AIS 的优势在于引导前向过程 Q, 使得最终边缘 $q_{t_f} \approx \pi_{t_f} = p_{\text{target}}$. 因此, (559) 中权重的低方差依赖于 q_{t_f} 接近 $\pi_{t_f} = p_{\text{target}}$.

我们所需要的是两全其美: 如果我们能设计一个前向模型, 使其在时刻 t_f 具有正确的边缘分布 P, 同时选择后向核为 (556), 这将产生几乎恒等于 1 的重要性权重, 从而导致非常低的方差. 让我们像以前一样, 用 AIS 插值分布序列 $\{\pi_t\}$ 来引导我们到达 P. 这个序列确定前向转移核 F_t 和伴随核 A_t, 两者都使分布 π_t 保持不变. 现在, 如 (556) 中那样, 让我们选择最优核 K_t^* 将分布 P 延拓到完整序列. 我们可以将 (556) 重写为

$$K_t^*(\mathbf{x}_{t-1}|\mathbf{x}_t) = \frac{\pi_t(\mathbf{x}_{t-1})F_t(\mathbf{x}_t|\mathbf{x}_{t-1})}{\pi_t(\mathbf{x}_t)} \cdot \frac{q_t(\mathbf{x}_t)q_{t-1}(\mathbf{x}_{t-1})}{q_t(\mathbf{x}_t)q_{t-1}(\mathbf{x}_{t-1})}, \tag{560}$$

其中 A_t 是第 9 章中关于 π_t 对应于 F_t 的伴随核. 当 $q_t \approx \pi_t$ 且 $\pi_t \approx q_{t-1}$ 时, 即当边缘分布接近平衡分布——系统绝热演化的 regime——时, 这个表达式与 AIS 后向核 (547) 之间的差异很小. 重要性权重仍由 (559) 给出, 但现在我们可以期望 $q_{t_f} \approx \pi_{t_f} = p_{\text{target}}$, 从而实现更高效的采样.

虽然后向核 K 的选择可以帮助减小重要性权重的方差, 但边缘分布 q_t 最终由前向过程 Q 决定. 同时优化 Q 和 K 可以带来更高效的采样.

学习最优前向与后向核 我们可以通过以下推导容易地得到 $F_p = -\log Z_p$ 的一个界 (Doucet et al., 2022; Salimans et al., 2015; Ho et al., 2020; Thin et al., 2021). 为了学习最优后向核 K_t^*, 我们可以构造一个变分目标, 最小化前向与后向联合分布之间的 KL 散度. 这给出了 $\log Z_p$ 的一个下界:

$$\begin{aligned}
& D_{\text{KL}}[Q\|P] \geq 0 \\
\Rightarrow \quad & \sum_{\mathbf{x}_{0:t_f}} Q(\mathbf{x}_{0:t_f}) \log \frac{Q(\mathbf{x}_{0:t_f})}{P(\mathbf{x}_{0:t_f})} \geq 0 \\
\Rightarrow \quad & -\sum_{\mathbf{x}_{0:t_f}} Q(\mathbf{x}_{0:t_f}) \log \left(Z_p \frac{P(\mathbf{x}_{0:t_f})}{Q(\mathbf{x}_{0:t_f})} \right) + \log Z_p \geq 0 \\
\Rightarrow \quad & -\log Z_p = F_p \leq -\sum_{\mathbf{x}_{0:t_f}} Q(\mathbf{x}_{0:t_f}) \log w(\mathbf{x}_{0:t_f}) = \mathcal{F}.
\end{aligned} \tag{561}$$

当然, 我们认出这个目标就是我们此前见过的证据下界 (ELBO). 对于 AIS 下所做的前向与后向核选择, 我们得到

$$\begin{aligned}
\mathcal{F} &= -\sum_{t=1}^{t_f} \mathbb{E}_{q_{t-1}}[\log(\gamma_t) - \log(\gamma_{t-1})] - \log Z_0 \\
&= \beta \sum_{t=1}^{t_f} \left(\mathbb{E}_{q_{t-1}}[\mathcal{H}_t] - \mathbb{E}_{q_{t-1}}[\mathcal{H}_{t-1}] \right) = \beta \mathbb{E}_Q[\mathcal{W}],
\end{aligned} \tag{562}$$

它可以在中间分布序列 $\{\gamma_t\}$ 或相应的 Hamiltonian 序列 $\{\mathcal{H}_t\}$ 上最小化. $\log Z_0$ 项是常数, 可以忽略, 因为 π_0 是固定的. 边缘分布 q_t 可以通过对所有 t 以 π_t 为其平稳分布

的 MCMC 采样器从 Q 中采样获得. 具有分数函数 $\nabla \log \pi_t$ 的未校正 Langevin 采样器可用于此目的.

然而，AIS 对后向核的选择并不总是最优的. ELBO 目标促使我们同时优化前向过程 Q 和后向过程 P，使界尽可能紧，并服从最后一步边缘分布匹配目标分布的约束；即 $p_{t_f}(\mathbf{x}_{t_f}) = p_{\text{target}}(\mathbf{x}_{t_f}) = \gamma(\mathbf{x}_{t_f})/Z_p$. 我们可能还希望约束初始分布 $\pi_0(\mathbf{x}_0)$ 至少是易于处理的，以便我们能高效地从中采样.

对 $p_{t_f} = p_{\text{target}}$ 的约束最方便的实现方式是沿后向方向构造 P：

$$P(\mathbf{x}_{0:t_f}) = p_{\text{target}}(\mathbf{x}_{t_f}) \prod_{t=1}^{t_f} K_t(\mathbf{x}_{t-1}|\mathbf{x}_t). \tag{563}$$

学习最优核的优化问题可以表述为

$$\begin{aligned} \min_{Q,K} D_{\text{KL}}[Q\|P], \quad \text{服从：} \quad Q(\mathbf{x}_{0:t_f}) &= \pi_0(\mathbf{x}_0) \prod_{t=1}^{t_f} F_t(\mathbf{x}_t|\mathbf{x}_{t-1}), \\ P(\mathbf{x}_{0:t_f}) &= \pi_{t_f}(\mathbf{x}_{t_f}) \prod_{t=1}^{t_f} K_t(\mathbf{x}_{t-1}|\mathbf{x}_t), \\ \pi_0(\mathbf{x}_0) = \pi_0(\mathbf{x}_0), \quad \pi_{t_f}(\mathbf{x}_{t_f}) &= p_{\text{target}}(\mathbf{x}_{t_f}), \end{aligned} \tag{564}$$

其中我们注意到，由于参数化方式，我们自动有 $q_0 = \pi_0$ 和 $p_{t_f} = p_{\text{target}}$ 固定在我们想要的分布上.

如 Doucet et al.（2022）提出的一种方法是使用中间分布序列 $\{\pi_t\}$（其中 $\pi_{t_f} = p_{\text{target}}$），并定义使 π_t 不变的 MCMC 核 F_t. 然后将前向转移核设为 $\{F_t\}$，后向核序列 $\{K_t\}$ 和中间分布序列 $\{\pi_t\}$ 同时更新以最小化 ELBO 目标.

Chapter 13

变分扩散模型

13.1 引言

在本章中，我们将把前面章节中学到的关于图模型、变分自编码器和自由能的知识应用到一个被称为 *扩散模型*（diffusion model）的特定架构上（Sohl-Dickstein et al., 2015）. 扩散模型可以说是目前最流行、最成功的图像和视频生成模型. 它们与随机热力学密切相关，正如关于该主题的第一篇论文的标题所示：《使用非平衡热力学的深度无监督学习》（Deep Unsupervised Learning using Nonequilibrium Thermodynamics）. 扩散模型与 VAE 的关系在于它们优化同一个目标函数（Kingma et al., 2021），但不同之处在于它们具有许多随机层（而 VAE 只有单一随机层），且编码器被固定为一个 Ornstein–Uhlenbeck 过程（而在 VAE 中编码器是学习得到的）. 在本章中，我们通过最小化变分自由能来推导扩散模型的标准学习算法.

13.2 作为图模型的扩散模型

一个 DM 可以被理解为一个具有深度隐变量 $z_{t_f} \sim p_{t_f}(z_{t_f})$ 的图模型，该隐变量通过许多层（时间依赖的）马尔可夫转移[10] $p_{t-1|t}(z_{t-1}|z_t)$ 被缓慢变换，以生成类似数据的样本（例如图像）. 在下文中，我们称 $x = z_0$ 为数据层，即我们有观测数据的层. 所有其他层都是隐层，因此不可观测. 用 GM 的语言来说，生成模型分布（或用 VAE 的行话说，解码器）由下式给出：

$$P(z_{t_f:0}) \equiv P(z_{t_f}, \ldots, z_0) = p_{t_f}(z_{t_f}) \prod_{t=1}^{t_f} p_{t-1|t}(z_{t-1}|z_t), \tag{565}$$

其中我们写 $z_{t_f:0}$ 来表示所有隐变量和观测变量（包括数据层）的集合. 这个过程与热力学第二定律相悖：它从噪声 z_{t_f} 中创造出结构（或数据），如 图 38 所示：

$$x = z_0 \leftarrow z_1 \leftarrow \cdots \leftarrow z_{t_f-1} \leftarrow z_{t_f}. \tag{566}$$

这就是谚语中所说的 “把煎蛋重新打散”，不过是反过来——熵在减少而非增加. 就像演化一样，学习以增加其环境的熵为代价来减少熵，从而创造出结构的局部区域（例如，你的身体就是通过亿万年演化制造出来的这种低熵结构的绝佳范例）.

上述生成过程是一个后向过程. 我们现在引入一个推断分布 q，它是以物理学自然

[10] 为避免混淆并标示每个转移概率可以在函数上不同，我们用其所表示的转移来显式标记概率分布；例如，$p_{t-1|t}$ 是从 z_t 到 z_{t-1} 的分布，即给定 z_t 下关于 z_{t-1} 的条件分布.

演化的方式增加熵的前向过程. 它由下式给出:

$$q(z_0, \ldots, z_{t_f}) = q_0(z_0) \prod_{t=1}^{t_f} q_{t|t-1}(z_t|z_{t-1}), \tag{567}$$

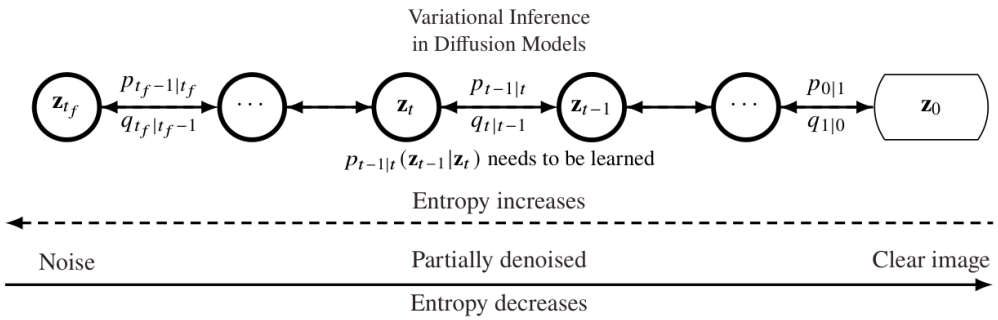
它将数据映射到隐空间:

$$x = z_0 \to z_1 \to \cdots \to z_{t_f-1} \to z_{t_f}. \tag{568}$$

在一般情况下，前向过程中也有时间依赖的转移. 然而，有些论文通过使用相同的转移核来简化这一点. 供将来参考，我们注意到

$$q(z_1, \ldots, z_{t_f}|z_0) = \frac{q(z_{0:t_f})}{q_0(z_0)} = \prod_{t=1}^{t_f} q_{t|t-1}(z_t|z_{t-1}). \tag{569}$$

$$q(\mathbf{z}_1, \ldots, \mathbf{z}_{t_f}|\mathbf{z}_0) = \frac{\mathbf{z}(\mathbf{z}_{0:t_f})}{q_0(\mathbf{z}_0)} = \prod_{t=1}^{} \prod q_{t|t-1}(\mathbf{z}_t|\mathbf{z}_{t-1}). \quad ($$



re 13.1 The Markov chain of forward and backward diffusion processes for generatin

图 38: 前向与后向扩散过程的马尔可夫链，通过缓慢地添加或移除噪声来生成样本. 前向过程 $q_{t|t-1}$ 增加熵（虚线箭头），而生成过程 $p_{t-1|t}$ 减少熵（实线箭头）以创造结构. 标注突出显示 $p_{t-1|t}(z_{t-1}|z_t)$ 是未知的、必须被学习. 隐节点以双边框圆圈表示，而观测节点 z_0 以圆角矩形表示.

直观地说，就像在 VAE 中一样，我们希望前向和后向过程互为逆过程. 然而，有一个重要的区别: 在 VAE 中，我们只有一个隐层，因此映射 $q(z|x)$ 更像是 x 在隐空间中的随机嵌入. 这意味着 z 和 x 之间仍然存在大量相关性，暗示隐空间中的不同区域编码了特定的类别. 在扩散模型中，x 和 z 之间的相关性被完全去除了，原则上任意 z 都可以生成任意 x. z 中的所有结构都被去除了，汽车图像的编码可以紧挨着鸭子图像的编码. 虽然与 VAE 不同，但这两类模型都能成功生成高质量数据，因为为此目的，你只需要所有 z 最终都收敛到一个好的图像（或其他类似数据的对象）. 当然，DM 可以以信息为条件来引导它们生成具有特定属性的数据，例如红色汽车（Dhariwal and Nichol, 2021）. 条件信息将引导生成过程从先验分布的任意样本走向输入空间中某个期望区域，例如红色汽车图像所在的区域.

13.3 自由能（证据下界）界

DM 的标准自由能界或 ELBO 由下式给出：

$$\begin{aligned}\mathcal{F} &= -\mathbb{E}_q\left[\log \frac{P(z_{t_f},\ldots,z_0)}{Q(z_1,\ldots,z_{t_f}|z_0)}\right] \\ &= -\mathbb{E}_q\left[\log p_{t_f}(z_{t_f}) + \sum_{t=1}^{t_f} \log \frac{p_{t-1|t}(z_{t-1}|z_t)}{q_{t|t-1}(z_t|z_{t-1})}\right] \\ &\geq F = \mathbb{E}[-\log p_0(z_0)]. \end{aligned} \tag{570}$$

从这个自由能界，我们可以立即推导出一个学习算法. 即，我们通过运行前向过程 q 来采样隐变量样本，然后执行梯度更新：

1. 采样一个数据样本：$z_0 \sim q_0(z_0)$.
2. 采样隐状态：$z_{s,1},\ldots,z_{s,t_f} \sim \prod_{t=1}^{t_f} q_{t|t-1}(z_t|z_{t-1})$.
3. 执行学习更新：

$$\theta'_{t-1|t} = \theta_{t-1|t} + \eta \frac{1}{S}\sum_{s=1}^{S} \nabla_{\theta_{t-1|t}} \log p_{t-1|t}(z_{s,t-1}|z_{s,t};\theta_{t-1|t}), \quad t=1,\ldots,t_f, \tag{571}$$

$$\theta'_{t_f} = \theta_{t_f} + \eta \frac{1}{S}\sum_{s=1}^{S} \nabla_{\theta_{t_f}} \log p_{t_f}(z_{s,t_f}|\theta_{t_f}). \tag{572}$$

在第 2 步中抽取 S 个样本，并在第 3 步中对它们取平均以获得梯度估计. 注意，我们假设 q 是固定的，因此不需要更新该分布的参数. 虽然上述学习算法可以工作，但它仍然需要在许多层上采样所有隐状态，因此方差会很高. 好消息是，如果我们选择所有分布都是正态分布，我们实际上可以以闭式计算许多平均.

13.3.1 后向核与流平衡方程

在这样做之前，让我们首先通过为前向过程定义一个后向核来稍微重写 ELBO：

$$q_{t|t-1}(z_t|z_{t-1}) = \frac{q_{t-1|t}(z_{t-1}|z_t)q_t(z_t)}{q_{t-1}(z_{t-1})}. \tag{573}$$

这个方程并不表达细致平衡，因为边缘分布 $q_t(z_t)$ 和 $q_{t-1}(z_{t-1})$ 是不同的. 相反，它表达的是将前向过程沿时间反向运行的核. 为了更好地理解这一点，考虑以下针对整条路径 $(s, z_0, \ldots, z_{t_f})$ 的转移核，其中 s 是一个额外的源状态，只能取一个值 $s=1$：

$$T(Z', s'|Z, s) = q_0(z'_0|s)\left[\prod_{t=1}^{t_f} q_{t|t-1}(z'_t|z'_{t-1})\right] T(s'|z'_{t_f}), \tag{574}$$

$$T(s|z_{t_f}) = \delta_{s,1}, \quad q_0(z_0|s) = q_0(z_0). \tag{575}$$

这个转移矩阵受到高度约束：对于每一层，在祖先更新时，下一个状态仅依赖于前一层的前一个状态. 此外，最后一个状态确定性地转移到源状态 $s = 1$，而第一个状态然后根据先验 q_0 将源状态分配回 z_0.

如果我们采样 $z_0 \sim q_0$ 并使用前向转移核采样所有后续的 $z_1, \ldots, z_{t_f}$，我们就在一步中精确地从联合分布 $q^{\text{st}}(z_{0:t_f}) = q(z_0, \ldots, z_{t_f})$ 中采样（即马尔可夫链不需要收敛或 “预热”）. 概率绕圈流动，如 图 39 所示，所有概率都是不变的. 这给了我们一个平稳分布 $q^{\text{st}}(z_{0:t_f})$，因此也有边缘分布 $q_t^{\text{eq}}(z_t)$，它们在不同时刻可以不同. 这些就是 (573) 中的边缘分布. 该方程中的后向核 $q_{t|t-1}(z_t|z_{t-1})$ 应被理解为：如果我们将时间反向运行，它生成转移，而流动沿相反方向移动. 当达到平稳分布时，后向核显然也使该分布不变.

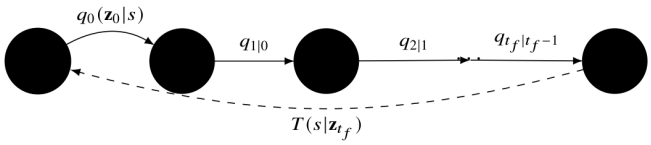


Figure 13.2 Circular flow of probability in the stationary distribution. The process starts from a

图 39: 平稳分布中概率的循环流动. 过程从源状态 s 出发，经过所有隐状态 $z_0, z_1, \ldots, z_{t_f}$，然后返回 s，形成一个闭环. 概率在系统中以正向转移（实线箭头，$q_{t|t-1}$）和返回转移（虚线箭头，$T(s|z_{t_f})$）相互平衡地循环流动，维持平稳分布.

建立了这一解释后，我们现在继续重写自由能（负 ELBO）：

$$\begin{aligned}
\mathcal{F} &= -\mathbb{E}_q\left[\log p_{t_f}(z_{t_f}) + \sum_{t=1}^{t_f} \log \frac{p_{t-1|t}(z_{t-1}|z_t)}{q_{t|t-1}(z_t|z_{t-1})}\right] \\
&= -\mathbb{E}_q\left[\log p_{t_f}(z_{t_f}) + \sum_{t=1}^{t_f} \log \frac{p_{t-1|t}(z_{t-1}|z_t) q_{t-1}(z_{t-1})}{q_{t-1|t}(z_{t-1}|z_t) q_t(z_t)}\right] \\
&= -\mathbb{E}_q\left[\log \frac{p_{t_f}(z_{t_f})}{q_{t_f}(z_{t_f})} + \sum_{t=1}^{t_f} \log \frac{p_{t-1|t}(z_{t-1}|z_t)}{q_{t-1|t}(z_{t-1}|z_t)} + \log q_0(z_0)\right] \\
&= D_{\text{KL}}[q_{t_f} \| p_{t_f}] + \sum_{t=1}^{t_f} \mathbb{E}_{q_t}[D_{\text{KL}}[q_{t-1|t} \| p_{t-1|t}]] + \mathcal{S}[q_0]. \qquad (576)
\end{aligned}$$

这是一个很好的结果：它说我们需要使生成过程的先验 p_{t_f} 等于聚合后验 q_{t_f}.[11] 此外，我们希望生成过程的每个转移 $p_{t-1|t}$ 都等于前向过程 $q_{t-1|t}$ 的逆. 数据分布的熵项 $\mathcal{S}[q_0] = \mathbb{E}_{q_0}[-\log q_0(z_0)]$ 可以从学习中忽略，因为它不依赖于参数.

虽然这个结果很优雅，但它并不实用，因为我们无法访问像 $q_{t-1|t}$ 这样的分布或边缘分布 q_t. 原因是它们是对数据分布取平均的，因此是对所有数据的复杂混合（回顾 q_0

[11] 聚合后验是对所有数据取平均的边缘分布 q_{t_f}. 这是不可处理的，因为 q_0 是一个复杂的分布. 可处理的分布是 $q_{t_f|0}$，它以一个数据点为条件.

是数据分布，非常复杂）. 可处理的分布是对特定数据样本而言的条件分布 $q_{t|0}(z_t|z_0)$.[12] 下面，我们将例如考察选择高斯分布来定义前向过程的情形，在这种情况下，当以一个数据样本为条件时，我们可以计算所有必要的分布. 幸运的是，我们也可以为这种情形推导 ELBO!

13.3.2 条件分布的 ELBO

我们像之前一样开始推导，但当我们插入平衡方程时，我们以 z_0 为条件，转而使用

$$q_{t-1|t,0}(z_{t-1}|z_t, z_0) = \frac{q_{t|t-1}(z_t|z_{t-1})q_{t-1|0}(z_{t-1}|z_0)}{q_{t|0}(z_t|z_0)}, \tag{577}$$

其中我们注意到 $q_{t|t-1,0}(z_t|z_{t-1}, z_0) = q_{t|t-1}(z_t|z_{t-1})$，这是由于马尔可夫性.

这是一个不同流动的后向核，即一个必须经过单一状态 $z_0 = x$ 的流动. 我们可以像上面一样构造循环流动，但需要将转移核 $q_0(z_0|s)$ 替换为 $\delta(z_0 - x)$. 使用这个流平衡方程，我们可以进行非常类似的推导，在一个伸缩求和中应用流平衡方程后许多项相互抵消，得到

$$\begin{aligned}\mathcal{F} &= -\mathbb{E}_q\left[\log \frac{p_{t_f}(z_{t_f})}{q_{t_f|0}(z_{t_f}|z_0)} + \sum_{t=2}^{t_f} \log \frac{p_{t-1|t}(z_{t-1}|z_t)}{q_{t-1|t,0}(z_{t-1}|z_t, z_0)} + \log p_{0|1}(z_0|z_1)\right] \\ &= \mathbb{E}_{q_0}\left[D_{\mathrm{KL}}[q_{t_f|0}\|p_{t_f}]\right] + \sum_{t=2}^{t_f} \mathbb{E}_{q_{t|0}}\left[D_{\mathrm{KL}}[q_{t-1|t,0}\|p_{t-1|t}]\right] - \mathbb{E}_{q_{1|0}}[\log p_{0|1}].\end{aligned} \tag{578}$$

同样，这个分解表明 $\mathcal{F}$ 可以使用条件分布 $q_{t|0}$ 和 $q_{t-1|t,0}$ 来计算，当以特定数据点 z_0 为条件时它们是可处理的. 有趣的是，我们可以为无条件分布和条件分布都定义自由能界.

13.4 训练解码器模型

为了训练解码器模型 p，我们按如下步骤进行. 我们从 q_0 中采样数据样本. 然后，假设我们已经有了所有条件分布（如 $q_{t_f|0}$ 和 $q_{t-1|t,0}$）的解析表达式，我们显式地最小化所有项. 两个高斯分布之间的 KL 散度为

$$q = G(\mu_q, \sigma_q), \qquad p = G(\mu_p, \sigma_p), \tag{579}$$

$$D_{\mathrm{KL}}[q\|p] = \log \frac{\sigma_p}{\sigma_q} + \frac{\sigma_q^2 + (\mu_p - \mu_q)^2}{2\sigma_p^2} - \frac{1}{2}, \tag{580}$$

其中 μ_q 和 σ_q 是给定且固定的（见下文）. 一旦知道 μ_p，我们就可以通过最小化 KL 散度来解出 σ_p：

$$\sigma_p^2 = \sigma_q^2 + (\mu_p - \mu_q)^2. \tag{581}$$

为了解出 μ_p，我们将其参数化为一个试图预测 μ_q 的神经网络.

[12] 注意，我们使用记号 $q_{t|0}$ 来表示我们感兴趣的是以数据样本 $z_0 = x$ 为条件的分布 $q(z_t|z_0)$.

在下面的讨论中，我们将遵循 Ho et al.（2020）. 第一步是选择一个前向过程. 一个好的选择是 “方差保持” 过程（实际上它并不保持方差，但至少不会爆炸或内爆）：

$$z_t = \sqrt{1-\beta_t}\, z_{t-1} + \sqrt{\beta_t}\, \epsilon_t, \qquad \epsilon_t \sim G(0, I). \tag{582}$$

接下来，我们需要出现在 ELBO 中的必要量 $q_{t|0}$ 和 $q_{t-1|t,0}$ 的显式表达式. 对于高斯分布，这些可以以闭式获得. 定义 $\alpha_t \equiv 1-\beta_t$ 和 $\bar{\alpha}_t \equiv \prod_{s=1}^{t} \alpha_s$，我们得到：

$$q_{t|0}(z_t|z_0) = G\big(\sqrt{\bar{\alpha}_t}\, z_0,\, (1-\bar{\alpha}_t)I\big) \tag{583}$$

$$\Rightarrow \quad z_t(z_0, \epsilon) = \sqrt{\bar{\alpha}_t}\, z_0 + \sqrt{1-\bar{\alpha}_t}\, \epsilon, \quad \epsilon \sim G(0, I), \tag{584}$$

$$q_{t-1|t,0}(z_{t-1}|z_t, z_0) = G\left(\frac{\sqrt{\bar{\alpha}_{t-1}}\beta_t}{1-\bar{\alpha}_t} z_0 + \frac{\sqrt{\bar{\alpha}_t}(1-\bar{\alpha}_{t-1})}{1-\bar{\alpha}_t} z_t,\, \frac{(1-\bar{\alpha}_{t-1})\beta_t}{1-\bar{\alpha}_t} I\right) \tag{585}$$

$$\Rightarrow \quad z_{t-1}(z_t, z_0, \epsilon) = \frac{\sqrt{\bar{\alpha}_{t-1}}\beta_t}{1-\bar{\alpha}_t} z_0 + \frac{\sqrt{\bar{\alpha}_t}(1-\bar{\alpha}_{t-1})}{1-\bar{\alpha}_t} z_t + \sqrt{\frac{(1-\bar{\alpha}_{t-1})\beta_t}{1-\bar{\alpha}_t}}\, \epsilon,$$

$$\epsilon \sim G(0, I). \tag{586}$$

这些方程推导起来不太容易，但我们会在下面给你一个直观的感受. 让我们看看在上述过程下时刻 t 处分布的均值和方差：

$$\begin{aligned}
\mathbb{E}[z_t] &= \sqrt{1-\beta_t}\, \mathbb{E}[z_{t-1}] + \sqrt{\beta_t}\, \mathbb{E}[\epsilon_t] \\
&= \prod_{s=1}^{t} \sqrt{1-\beta_s}\, \mathbb{E}[z_0] \quad (\mathbb{E}[\epsilon_t] = 0 \text{ 对所有} t) \\
&= \sqrt{\bar{\alpha}_t}\, z_0,
\end{aligned} \tag{587}$$

这确实是条件分布 $q_{t|0}$ 的均值. 对于方差：

$$\begin{aligned}
\mathbb{E}[z_t z_t^\top] &= \mathbb{E}\Big[(\sqrt{1-\beta_t}\, z_{t-1} + \sqrt{\beta_t}\, \epsilon_t)(\sqrt{1-\beta_t}\, z_{t-1} + \sqrt{\beta_t}\, \epsilon_t)^\top\Big] \\
&= (1-\beta_t)\mathbb{E}[z_{t-1} z_{t-1}^\top] + \beta_t I, \quad (\mathbb{E}[z_{t-1}\epsilon_t^\top] = \mathbb{E}[z_{t-1}]\mathbb{E}[\epsilon_t^\top] = 0) \\
&= (1-\beta_t)(1-\beta_{t-1})\mathbb{E}[z_{t-2} z_{t-2}^\top] + (\beta_t + (1-\beta_t)\beta_{t-1}) I \\
&= \bar{\alpha}_t\, z_0 z_0^\top + \sum_{s=1}^{t} \left[\prod_{r=1}^{s-1}(1-\beta_{t-r+1})\right] \beta_{t-s+1} I.
\end{aligned} \tag{588}$$

这看起来更复杂了！然而，我们可以把第二项解释为一个抛硬币的过程，计算在 t 次试验后我们看到 “正面朝上” 的概率. 但是，我们是以相反的顺序做实验的，从时刻 t 开始第一次实验，然后往回做到时刻 0. 在时刻 t 的 “第一次” 试验中找到正面朝上的概率是 β_t. 之后会发生什么我们不再关心. 在第二次试验中首次看到正面朝上的概率是 $(1-\beta_t)\beta_{t-1}$（失败的概率是 $1-\beta_t$），以此类推. 我们知道，在这 t 次试验中成功看到正面朝上的总概率等于 1 减去在 t 次试验中从未看到正面朝上而彻底失败的概率. 那个概率由 $\prod_{s=1}^{t}(1-\beta_s)$ 给出. 换句话说，(588) 右边的复杂求和由 $1 - \prod_{s=1}^{t}(1-\beta_s) = 1-\bar{\alpha}_t$ 给出. 还要注意，我们真正关心的是方差而非协方差——利用 (587)，

$$\begin{aligned}
\mathbb{V}[z_t] &= \mathbb{E}[z_t z_t^\top] - \mathbb{E}[z_t] \cdot \mathbb{E}[z_t^\top] \\
&= (1-\bar{\alpha}_t) I,
\end{aligned} \tag{589}$$

这确实与 (583) 一致.

为了推导 $q_{t-1|t,0}$ 的均值和方差方程，我们需要回顾 Bayes 法则，(21)：

$$\begin{aligned} q_{t-1|t,0}(z_{t-1}|z_t, z_0) &= \frac{q_{t|t-1,0}(z_t|z_{t-1}, z_0)\, q_{t-1|0}(z_{t-1}|z_0)}{q_{t|0}(z_t|z_0)} \\ &\propto q_{t|t-1}(z_t|z_{t-1})\, q_{t-1|0}(z_{t-1}|z_0), \end{aligned} \tag{590}$$

其中我们使用了 $q_{t|t-1,0}(z_t|z_{t-1}, z_0) = q_{t|t-1}(z_t|z_{t-1})$，因为转移是马尔可夫的且独立于 z_0. 我们对其中每一个都有表达式：

$$q_{t-1|0}(z_{t-1}|z_0) = G\left(\sqrt{\bar{\alpha}_{t-1}}\, z_0,\, (1-\bar{\alpha}_{t-1})I\right), \tag{591}$$

$$q_{t|t-1}(z_t|z_{t-1}) = G\left(\sqrt{1-\beta_t}\, z_{t-1},\, \beta_t I\right). \tag{592}$$

由于一切都是高斯的，我们可以显式地写出 (590) 的对数，并观察到它是 z_{t-1} 的二次函数. 现在，我们将该二次函数改写为 log–高斯形式 $-\frac{1}{2}(z_{t-1}-\mu)^2/\sigma^2 + c$，其中常数不依赖于 z_{t-1}. 由于我们知道最终结果必须是高斯分布，所有常数最终都将决定归一化常数，因此你可以忽略它们并在之后归一化你的高斯分布. 如果你这样做，你就会得到 (585) 中的结果.

13.5 方差缩减技术

就像在 VAE 中一样，我们现在将使用一些技巧来减小估计的方差. 我们优化的目标有很多项，但让我们聚焦于目标中最复杂的一项，即 (578)：

$$\mathbb{E}_{q_{t|0}}[D_{\mathrm{KL}}[q_{t-1|t,0}\|p_{t-1|t}]] = \frac{1}{2(\sigma^p_{t-1|t})^2}\mathbb{E}_{q_{t,0}}\left[\|\mu(z_t;\theta_t) - \mu_{t-1|t,0}(z_t, z_0)\|^2\right] + \text{const}, \tag{593}$$

其中 $\mu(z_t;\theta_t)$ 是我们试图学习的后向解码器模型 p 的均值，它仅依赖于状态 z_t. 均值 $\mu_{t-1|t,0}(z_t, z_0)$ 是前向编码器模型的均值，它没有自由参数，并且我们有其显式表达式.

第一个技巧仍然是 “重参数化技巧”，基于 (584). 这意味着我们将期望中的随机变量 z_t 替换为 $\epsilon \sim G(0, I)$，并在所有地方写 $z_t(z_0, \epsilon_t)$：

$$\mathbb{E}_{z_0\sim q_0, \epsilon_t\sim G_\epsilon}[D_{\mathrm{KL}}[q_{t-1|t,0}\|p_{t-1|t}]] = \frac{1}{2\sigma^2_{t-1|t}}\mathbb{E}_{z_0\sim q_0, \epsilon_t\sim G_\epsilon}\left[\|\mu(z_t(z_0,\epsilon_t);\theta_t) - \mu_{t-1|t,0}(z_t(z_0,\epsilon_t), z_0)\|^2\right] + \text{const}, \tag{594}$$

$$z_t(z_0, \epsilon) = \sqrt{\bar{\alpha}_t}\, z_0 + \sqrt{1-\bar{\alpha}_t}\, \epsilon, \quad \epsilon \sim G(0, I). \tag{595}$$

我们采样一个数据样本 z_0 和一个来自标准高斯分布的随机噪声向量 ϵ_t，将它们代入 z_t 的表达式，然后代入神经网络 μ^{θ_t} 和由 (585) 给出的 q 的均值表达式：

$$\mu_{t-1|t,0}(z_t(z_0,\epsilon_t), z_0) = \frac{\sqrt{\bar{\alpha}_{t-1}}\beta_t}{1-\bar{\alpha}_t} z_0 + \frac{\sqrt{\bar{\alpha}_t}(1-\bar{\alpha}_{t-1})}{1-\bar{\alpha}_t} z_t(z_0,\epsilon_t). \tag{596}$$

第二个技巧是构建一个模型来预测零均值变量，而不是预测具有大均值的变量. 特别是，如果你检查上面的均值表达式，你会发现神经网络 μ^{θ_t} 可以访问 z_t 的值，因此没

有必要预测它. 在上面的表达式中，我们可以再次使用 (595) 将 z_0 写为 z_t 和 ϵ_t 的形式，经过一些简化后得到：

$$\mu_{t-1|t,0}(z_t(z_0,\epsilon_t),z_0)=\frac{1}{\sqrt{\bar{\alpha}_t}}\left(z_t(z_0,\epsilon_t)-\frac{\beta_t}{\sqrt{1-\bar{\alpha}_t}}\epsilon_t\right). \tag{597}$$

现在我们观察到，如果我们将神经网络参数化为

$$\mu(z_t,\epsilon_t;\theta_t)=\frac{1}{\sqrt{\bar{\alpha}_t}}\left(z_t-\frac{\beta_t}{\sqrt{1-\bar{\alpha}_t}}\epsilon(z_t;\theta_t)\right), \tag{598}$$

那么将两者相减后，我们得到目标函数：

$$\mathcal{L}_t=\frac{\beta_t^2}{2\sigma_{t-1|t}^2\bar{\alpha}_t(1-\bar{\alpha}_t)}\mathbb{E}_{z_0\sim q_0,\epsilon_t\sim G_\epsilon}\left[\|\epsilon(z_t(z_0,\epsilon_t);\theta_t)-\epsilon_t\|^2\right]. \tag{599}$$

乍一看，这令人困惑：我们怎么可能希望预测一个完全随机的数 ϵ_t 呢？然而，注意神经网络 ϵ^{θ_t} 本身通过其对 z_t 的依赖而依赖于同一个随机数. 例如，假设我们有一个数据样本，并且正在采样大量噪声向量. 神经网络将接收 $\{z_n,\epsilon_n\}$ 对，并被要求从 z 预测 ϵ. 由于噪声对称地分布在 z_0 周围，很容易学习一个从 z 到 ϵ 的映射，从而回到 z_0. 这个映射基本上就是向量 $z\to z_0-z$. 可以把它想象成去噪：我们收到 z_0 的带噪版本，并被要求预测干净的源 z_0. 这就是为什么这有时也被称为去噪分数匹配（Vincent, 2011）.

13.6 实现细节

有一些我们略过但对成功实现很重要的细节. 例如，有些人认为你可以直接忽略权重因子

$$w_t=\frac{\beta_t^2}{2\sigma_{t-1|t}^2\bar{\alpha}_t(1-\bar{\alpha}_t)}, \tag{600}$$

因为这些权重鼓励算法花费大量注意力在数据层附近把细节做对. 然而，虽然这可能是改进对数似然的最佳方式，但这对我们来说通常不太重要，因为我们可以轻松地训练单独的模型来生成合理的高分辨率细节. 将所有权重 w_t 设为 1 会将更多的重点放在关注更粗粒度结构的更深层上.

像潜在扩散（Tzen and Raginsky, 2019; Rombach et al., 2022）这样的方法试图将这一原则更进一步，通过为另一个模型（例如 VAE）的先验 p_{t_f} 训练扩散模型. 然后使用生成对抗网络来改进 VAE 的解码器模型以生成高分辨率细节.

此外，通常不训练先验 p_{t_f}，而是将其设为前向过程的平衡分布. 然而，该过程在 t_f 步后不一定达到平衡，因此这是一种近似. 你可以像我们在这里描述的那样训练先验，但那样在生成时可能很难从中采样. 学习先验的一种方法是对从 $q_{t_f|0}$ 中抽取的样本拟合一个高斯模型.

另一种选择是将编码前向模型与后向解码器模型一起训练，以尝试强制 q_{t_f} 成为一个期望的（易于采样的）分布. 这就是所谓的 Schrödinger 桥问题（De Bortoli et al., 2021），我们将在第 14 章讨论.

最后，模型 $p_{0|1}$ 可以通过从 $q_{1|0}$ 中采样 z_1 并最大化

$$L_0 = \sum_s \log p_{0|1}(z_0^s = x^s | z_1^s), \quad z_1^s \sim q_{1|0}(z_1 | z_0 = x^s), \tag{601}$$

来训练，例如通过梯度下降.

Chapter 14

Schrödinger 桥

14.1 引言

在第 12 章中，我们介绍了序贯蒙特卡洛采样，其中我们的任务是从一个易于采样的初始分布出发，然后学习引导采样过程，使其在有限步数内从正确的目标分布中采样. 退火重要性采样就是一个众所周知的例子.

在第 13 章中，我们最小化了一个前向联合分布 $Q(\mathbf{x}, \mathbf{z})$ 与一个生成分布 $P(\mathbf{x}, \mathbf{z})$ 之间的 KL 散度，该生成分布是联合定义在观测变量（即数据）$\mathbf{x}$ 和（多层）隐变量 $\mathbf{z}$ 上的. 我们假设可以从数据分布 $q_0(\mathbf{x})$ 中获得样本 $\{\mathbf{x}_s\}_{s=1}^S$，并设计了前向过程使其具有标准正态分布 $q_{t_f}(\mathbf{x}_{t_f})$ 作为平稳分布.

在第 15 章中，我们将研究受控过程，它们从某个初始分布（通常是在单个状态处的 delta 峰）出发，并具有与末时刻边缘目标密度的对数概率（KL 控制）或概率本身（GFlowNet，见第 16 章）成比例的终端奖励. 那里的任务是找到将分布引导向目标分布的控制. 所有这些问题都有一个共同的目标：在端点处边缘约束下最小化前向与后向过程之间的 KL 散度.

在本章中，我们将描述 Schrödinger 桥（Schrödinger bridge）（SB）问题的一般表述，并提供求解它们的算法. 我们还将把它与最优传输和最大 caliber 问题联系起来.

14.2 Schrödinger 桥

Schrödinger 桥问题（Schrödinger, 1931; Chetrite et al., 2021）由以下数学目标描述：

$$\min_Q D_{\mathrm{KL}}[Q\|P] \quad \text{s.t.} \quad q_0(\mathbf{x}_0) = \mu(\mathbf{x}_0),\ q_{t_f}(\mathbf{x}_{t_f}) = \nu(\mathbf{x}_{t_f}), \tag{602}$$

其中 P 是参考分布，Q 是我们优化的分布，μ 是初始分布，ν 是目标分布. 当选择 P 为均匀分布时，这变成了一个在路径上的最大熵问题，服从起点 μ 和终点 ν 处的边缘约束. 这有时被称为 最大 caliber（maximum caliber）（MaxCal）问题（Jaynes, 1980），我们将在 节 14.5 中简要解释. Schrödinger 桥问题的几何解释如 图 40 所示.

in Section 14.5. The geometric interpretation of the Schrödinger bridge problem is illustrated in Figure 14.1.

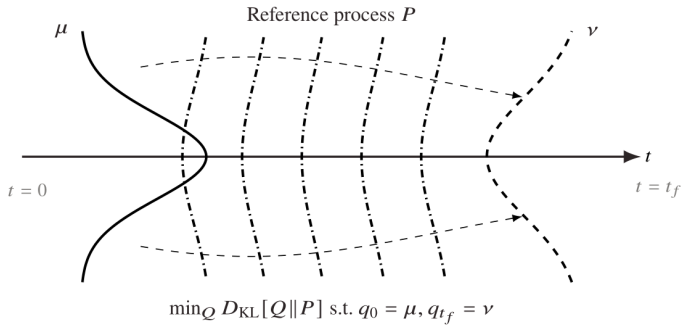


Figure 14.1 Visualization of the Schrödinger bridge problem. The solid curve (μ) represents

图 40: Schrödinger 桥问题可视化. 实线曲线 μ 表示 $t = 0$ 处的初始分布，虚线曲线 ν 表示 $t = t_f$ 处的目标分布. 点划线曲线显示参考过程 P 的中间分布. 虚线箭头表示初始与目标分布之间可能的传输路径. Schrödinger 桥问题旨在找到 μ 与 ν 之间最可能的演化，最小化桥 Q 与参考过程 P 之间的 KL 散度，服从边缘约束 $q_0 = \mu$ 和 $q_{t_f} = \nu$.

为了求解 SB 问题，我们将添加 Lagrange 乘子项来强制 $q_0 = \mu$ 和 $q_{t_f} = \nu$:

$$\begin{aligned}\mathcal{L}[Q, \gamma, \lambda] &= D_{\mathrm{KL}}[Q\|P] + \sum_{\mathbf{x}_0} \gamma(\mathbf{x}_0)(q_0(\mathbf{x}_0) - \mu(\mathbf{x}_0)) + \sum_{\mathbf{x}_{t_f}} \lambda(\mathbf{x}_{t_f})(q_{t_f}(\mathbf{x}_{t_f}) - \nu(\mathbf{x}_{t_f})) \\ &= D_{\mathrm{KL}}[Q\|P] + \sum_{\mathbf{x}_{0:t_f}} \gamma(\mathbf{x}_0) Q(\mathbf{x}_{0:t_f}) - \sum_{\mathbf{x}_0} \gamma(\mathbf{x}_0)\mu(\mathbf{x}_0) \\ &\quad + \sum_{\mathbf{x}_{0:t_f}} \lambda(\mathbf{x}_{t_f}) Q(\mathbf{x}_{0:t_f}) - \sum_{\mathbf{x}_{t_f}} \lambda(\mathbf{x}_{t_f})\nu(\mathbf{x}_{t_f}). \end{aligned} \tag{603}$$

注意，我们将对 $Q(\mathbf{x}_{0:t_f})$ 的求和延拓到整个路径空间，以包含时刻 0 和 t_f 处的 Lagrange 乘子 $\gamma(\mathbf{x}_0)$ 和 $\lambda(\mathbf{x}_{t_f})$. 此外，可以添加约束以保持 Q 为正且归一化，但这在下面会自动实现.

通过对 Lagrangian $\mathcal{L}$ 关于 Q 取泛函导数并令其为零，我们得到最优解 Q^*:

$$\begin{aligned}\frac{\delta \mathcal{L}}{\delta Q(\mathbf{x}_{0:t_f})} &= \log Q(\mathbf{x}_{0:t_f}) - \log P(\mathbf{x}_{0:t_f}) + \gamma(\mathbf{x}_0) + \lambda(\mathbf{x}_{t_f}) + 1 = 0 \\ \Rightarrow \quad Q^*(\mathbf{x}_{0:t_f}) &= \Gamma(\mathbf{x}_{0:t_f}) = \frac{1}{Z_\Gamma} P(\mathbf{x}_{0:t_f}) e^{-\gamma(\mathbf{x}_0) - \lambda(\mathbf{x}_{t_f})}. \end{aligned} \tag{604}$$

这个解可以解释为参考分布 P 的一个重加权版本，其中重加权因子通过 Lagrange 乘子依赖于初始和最终状态.

让我们首先尝试找到 Lagrange 乘子 $\lambda(\mathbf{x}_{t_f})$ 的表达式，它强制正确的约束 $q_{t_f} = \nu$. 这可以通过对 (604) 关于 $\mathbf{x}_0, \ldots, \mathbf{x}_{t_f - 1}$ 积分并将结果与期望的最终边缘 $\nu(\mathbf{x}_{t_f})$ 匹配来

完成：

$$
\begin{aligned}
q_{t_f}(\mathbf{x}_{t_f}) &= \sum_{\mathbf{x}_{0:t_f-1}} \frac{1}{Z_\Gamma} P(\mathbf{x}_{0:t_f}) e^{-\gamma(\mathbf{x}_0)-\lambda(\mathbf{x}_{t_f})} \\
&= \frac{1}{Z_\Gamma} e^{-\lambda(\mathbf{x}_{t_f})} \tilde{p}_{t_f}(\mathbf{x}_{t_f}|\gamma) \\
&= \nu(\mathbf{x}_{t_f}), \qquad (605) \\
\tilde{p}_{t_f}(\mathbf{x}_{t_f}|\gamma) &= \sum_{\mathbf{x}_{0:t_f-1}} P(\mathbf{x}_{0:t_f}) e^{-\gamma(\mathbf{x}_0)}, \qquad (606) \\
\Rightarrow \quad e^{-\lambda(\mathbf{x}_{t_f})} &= \frac{Z_\Gamma \nu(\mathbf{x}_{t_f})}{\tilde{p}_{t_f}(\mathbf{x}_{t_f}|\gamma)}. \qquad (607)
\end{aligned}
$$

将此结果代回 Q^*（见 (604)），我们得到最优解 Γ 的一个不动点方程：

$$
\Gamma(\mathbf{x}_{0:t_f}) = \frac{P(\mathbf{x}_{0:t_f}) e^{-\gamma(\mathbf{x}_0)} \nu(\mathbf{x}_{t_f})}{\sum_{\mathbf{x}_{0:t_f-1}} P(\mathbf{x}_{0:t_f}) e^{-\gamma(\mathbf{x}_0)}} = \Gamma(\mathbf{x}_{0:t_f-1}|\mathbf{x}_{t_f}) \nu(\mathbf{x}_{t_f}). \qquad (608)
$$

这个方程有一个直观的解释：Lagrange 乘子 $\lambda(\mathbf{x}_{t_f})$ 有效地将联合分布除以时刻 t_f 处的边缘分布，然后将其替换为期望的边缘 $\nu(\mathbf{x}_{t_f})$. 因此，如果这个方程成立（两边有相同的 Γ），它肯定解决了关于 $\mathbf{x}_{t_f}$ 的约束：该方程然后表明 $\Gamma(\mathbf{x}_{t_f}) = \nu(\mathbf{x}_{t_f})$. 如果它不成立，我们可以简单地将其视为对 Γ 的一次更新，之后它就会成立.

我们可以对另一个 Lagrange 乘子 $\gamma(\mathbf{x}_0)$ 重复同样的推导，得到如下形式的不动点方程：

$$
\Gamma(\mathbf{x}_{0:t_f}) = \frac{P(\mathbf{x}_{0:t_f}) e^{-\lambda(\mathbf{x}_{t_f})} \mu(\mathbf{x}_0)}{\sum_{\mathbf{x}_{1:t_f}} P(\mathbf{x}_{0:t_f}) e^{-\lambda(\mathbf{x}_{t_f})}} = \Gamma(\mathbf{x}_{1:t_f}|\mathbf{x}_0) \mu(\mathbf{x}_0). \qquad (609)
$$

我们完成了吗？不幸的是，在像 (609) 这样的更新之后，不能保证 (608) 仍然成立. 好消息是，我们可以不断更新这两个方程直到收敛（在某些条件下收敛是有保证的），到达一个两个条件都满足的不动点. 这个迭代过程被称为 *迭代比例拟合*（iterative proportional fitting）（IPF），可以形式化地写为

$$
\begin{aligned}
&Q_0 = P_{\text{init}}, \\
&Q_1 = \arg\min_Q D_{\text{KL}}[Q \| Q_0] \quad \text{s.t.} \quad q_0^1 = \mu, \\
&Q_2 = \arg\min_Q D_{\text{KL}}[Q \| Q_1] \quad \text{s.t.} \quad q_{t_f}^2 = \nu, \\
&\quad \cdots \qquad (610)
\end{aligned}
$$

每个子问题都可以用与之前相同的方法求解，参考分布是上一次迭代的解：

$$
Q_{k+1}(\mathbf{x}_{0:t_f}) = \begin{cases} Q_k(\mathbf{x}_{1:t_f}|\mathbf{x}_0)\mu(\mathbf{x}_0), & \text{若} k \text{ 为奇数}, \\ Q_k(\mathbf{x}_{0:t_f-1}|\mathbf{x}_{t_f})\nu(\mathbf{x}_{t_f}), & \text{若} k \text{ 为偶数}. \end{cases} \qquad (611)
$$

计算这些条件分布可能代价高昂，因为它涉及对许多变量的求和. 然而，如果分布结构为链（或树），且状态数 $\mathbf{x}$ 不太大，则可以使用置信传播高效求解（见第 6 章）. IPF 的交替投影结构如 图 41 所示.

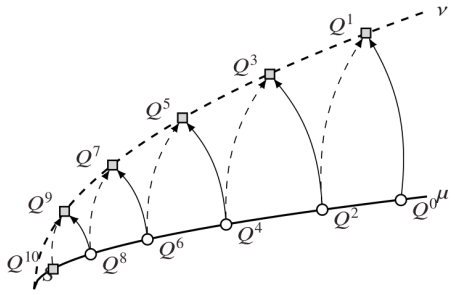


Figure 14.2 Iterative proportional fitting procedure for solving the Schrödinger bridge

图 41: 求解 Schrödinger 桥问题的迭代比例拟合过程. 虚线曲线表示初始分布 μ，实线曲线表示目标分布 ν. 迭代 Q^i 显示了偶数次迭代（圆圈，在 μ 流形上）和奇数次迭代（方块，在 ν 流形上）之间的交替投影，收敛到 Schrödinger 桥解 Q. 实线箭头表示投影到 ν 约束；虚线箭头表示投影到 μ 约束.

在前面的讨论中，我们假设 $q_0(\mathbf{x}_0) = \sum_{\mathbf{x}_{1:t_f}} Q(\mathbf{x}_{0:t_f}) = \mu(\mathbf{x}_0)$，这阻止了我们一次性（不迭代地）求解问题. 如果我们将初始分布固定为单个点——即 $p_0(\mathbf{x}_0) = \delta(\mathbf{x}_0 - \mathbf{y}_0)$——那么求解 $\mathbf{x}_{t_f}$ 处的边缘分布不会改变 $\mathbf{x}_0$ 处的分布. 这可以通过执行置信传播（见第 6 章）看到，从最后一个边缘分布 $\nu(\mathbf{x}_{t_f})$ 开始并反向传播到 $t = 0$. 在积分出所有变量 $\{\mathbf{x}_1, \ldots, \mathbf{x}_{t_f}\}$ 之后，这将给出

$$q_0^*(\mathbf{x}_0) = \frac{\delta(\mathbf{x}_0 - \mathbf{y}_0) m_{1\to 0}(\mathbf{x}_0)}{\sum_{\mathbf{x}_0'} \delta(\mathbf{x}_0' - \mathbf{y}_0) m_{1\to 0}(\mathbf{x}_0')} = \delta(\mathbf{x}_0 - \mathbf{y}_0), \tag{612}$$

其中 $m_{t\to t-1}(\mathbf{x}_t)$ 是第 6 章中定义的消息. 因此我们得出结论，如果选择 $\mu = \delta_{\mathbf{y}_0}$，Schrödinger 桥问题在一次迭代后即告解决. 这在第 15 章讨论最优控制问题及其与 SB 的关系时将很重要（Y. Chen et al., 2020）.

在选择 $\mu = \delta_{\mathbf{y}_0}$ 的上述约束下，我们可以通过移除 $q_0 = \mu$ 的约束、将 P 参数化为前向马尔可夫链 $P = p_0 \prod_t p_{t|t-1}$、选择 $p_0 = \delta_{\mathbf{y}_0}$、然后将 (607) 中 λ 的解代入 Lagrangian (603) 来重写 SB 问题，得到

$$\begin{aligned}
\mathcal{L} &= D_{\mathrm{KL}}[Q\|P] + \mathbb{E}_Q[\lambda(\mathbf{x}_{t_f})] - \sum_{\mathbf{x}_{t_f}} \lambda(\mathbf{x}_{t_f})\nu(\mathbf{x}_{t_f}) \\
&= D_{\mathrm{KL}}[Q\|P] + \mathbb{E}_Q\left[\log \frac{p_{t_f}}{\nu}\right] + D_{\mathrm{KL}}[\nu\|p_{t_f}] \\
&= D_{\mathrm{KL}}[Q\|P] + \mathbb{E}_Q\left[\log \frac{P(\mathbf{x}_{t_f})}{\nu(\mathbf{x}_{t_f})}\right] + D_{\mathrm{KL}}[\nu\|P_{t_f}] \\
&= D_{\mathrm{KL}}\left[Q(\mathbf{x}_{0:t_f})\|P(\mathbf{x}_{0:t_f-1}|\mathbf{x}_{t_f})\nu(\mathbf{x}_{t_f})\right] + D_{\mathrm{KL}}[\nu\|P_{t_f}].
\end{aligned} \tag{613}$$

由于我们保持 P（参考分布）和 ν（目标分布）固定，最后一项 $D_{\mathrm{KL}}[\nu\|p_{t_f}]$ 是常数，对优化不重要. 我们可以将项 $\mathbb{E}_Q[\log(P(\mathbf{x}_{t_f})/\nu(\mathbf{x}_{t_f}))]$ 解释为最优控制问题的终端成本项，用于求解策略 Q，该策略被正则化以保持接近 P. 这被称为 Kullback–Leibler 控制（Kullback–Leibler control），可以用自由能在热力学意义上解释. 这是 节 15.4 的主题.

14.3 训练扩散 Schrödinger 桥

以下内容基于 De Bortoli et al.（2021）.

为了高效实现 IPF，我们可以将联合分布表示为马尔可夫链. 对于偶数次（$k = 2n$）和奇数次（$k = 2n + 1$）迭代，分布具有前向和后向过程的形式：

$$Q^{2n}(\mathbf{x}_{0:t_f}) = q_0^n(\mathbf{x}_0) \prod_{t=1}^{t_f} q_{t|t-1}^n(\mathbf{x}_t|\mathbf{x}_{t-1}), \tag{614}$$

$$Q^{2n+1}(\mathbf{x}_{0:t_f}) = q_{t_f}^n(\mathbf{x}_{t_f}) \prod_{t=1}^{t_f} q_{t-1|t}^n(\mathbf{x}_{t-1}|\mathbf{x}_t), \tag{615}$$

其中 $q_{t|t-1}^n$ 和 $q_{t-1|t}^n$ 表示 IPF 第 n 次迭代时从时刻 $t-1$ 到 t 和从时刻 t 到 $t-1$ 的转移核.

为了使其对高维系统更实用，我们选择转移核为具有可学习漂移函数的高斯分布：

$$q_{t|t-1}^n(\mathbf{x}_t|\mathbf{x}_{t-1}) = G(\mathbf{x}_t; \mathbf{x}_{t-1} + \mathbf{a}_{t-1}^n(\mathbf{x}_{t-1}), \sigma_t^2 I), \tag{616}$$

$$q_{t-1|t}^n(\mathbf{x}_{t-1}|\mathbf{x}_t) = G(\mathbf{x}_{t-1}; \mathbf{x}_t + \mathbf{b}_t^n(\mathbf{x}_t), \sigma_t^2 I), \tag{617}$$

其中 $\mathbf{a}_{t-1}^n$ 和 $\mathbf{b}_t^n$ 是第 n 次迭代时的前向和后向漂移函数，σ_t^2 是可以固定或学习的方差参数.

通过最小化连续 IPF 迭代之间的 KL 散度并取小步长极限 $\sigma_t^2 \to 0$（类似于第 13 章中的 ELBO 分解），漂移函数的学习目标变成了一个回归问题：

$$\hat{\mathbf{b}}_t^k = \operatorname*{argmin}_{\hat{\mathbf{b}}} \mathbb{E}_{p_{t-1,t}^k} \left[\|\hat{\mathbf{b}}(\mathbf{x}_t) - (\mathbf{x}_t + \hat{\mathbf{a}}_{t-1}^k(\mathbf{x}_{t-1}) - \hat{\mathbf{a}}_{t-1}^k(\mathbf{x}_t))\|^2 \right], \tag{618}$$

$$\hat{\mathbf{a}}_{t-1}^{k+1} = \operatorname*{argmin}_{\hat{\mathbf{a}}} \mathbb{E}_{q_{t-1,t}^k} \left[\|\hat{\mathbf{a}}(\mathbf{x}_{t-1}) - (\mathbf{x}_{t-1} + \hat{\mathbf{b}}_t^k(\mathbf{x}_t) - \hat{\mathbf{b}}_t^k(\mathbf{x}_{t-1}))\|^2 \right], \tag{619}$$

其中 $\hat{\mathbf{b}}_t^k(\mathbf{x}) = \mathbf{x} + \sigma_t \mathbf{b}_t^k(\mathbf{x})$ 和 $\hat{\mathbf{a}}_{t-1}^k(\mathbf{x}) = \mathbf{x} + \sigma_t \mathbf{a}_{t-1}^k(\mathbf{x})$ 是包含恒等映射的增广漂移函数，$p_{t-1,t}^k$、$q_{t-1,t}^k$ 是步骤 $t-1$ 和 t 处的联合密度. 扩散 Schrödinger 桥（DSB）算法然后在学习后向漂移函数 $\hat{\mathbf{b}}_t^k$ 和前向漂移函数 $\hat{\mathbf{a}}_{t-1}^{k+1}$ 之间交替. 为了学习 $\hat{\mathbf{b}}_t^k$，我们从当前前向过程出发、从 μ 开始采样路径. 为了学习 $\hat{\mathbf{a}}_{t-1}^{k+1}$，我们从当前后向过程出发、从先验 ν 开始采样路径.

DSB 可以应用于机器学习中的两个重要场景. 对于生成建模，我们设 $\mu = p_{\mathrm{data}}$（数据分布），$\nu = p_{\mathrm{prior}}$（通常是标准正态分布）. 模型训练完成后，我们可以通过以下方式生成新样本：(i) 采样 $\mathbf{x}_{t_f} \sim \nu$；(ii) 对 $t = t_f, t_f - 1, \ldots, 1$，使用学习到的后向漂移函数依次采样 $\mathbf{x}_{t-1} \sim q_{t-1|t}(\cdot|\mathbf{x}_t)$.

这与变分扩散模型（第 13 章）非常相似，但在这里我们同时学习前向和后向转移，而不是单一前向过程. 此外，SB 确保模型在有限时间内匹配两个端点处的期望分布，与基于 Ornstein–Uhlenbeck 过程的 DM 不同，后者需要无限时间才能收敛到先验.

DSB 也可以应用于从未归一化密度采样. 我们可以将 μ 设为易于采样的分布（例如 $G(0, I)$），并将 ν 取为目标分布，指定到归一化常数为止；即 $\nu(\mathbf{x}_{t_f}) \propto \pi(\mathbf{x}_{t_f})$. 训练然后需要一些额外的组件（见 Bernton et al., 2019; Vargas et al., 2022; Heng et al., 2023）. 例如，可以将未归一化密度 $\pi(\mathbf{x}_{t_f})$ 作为终端成本或奖励纳入目标函数，这与第 15 章和第 22 章讨论的最优控制视角相联系. 退火重要性采样和序贯蒙特卡洛方法也可以在 IPF 迭代中使用（Bernton et al., 2019）.

14.4 与最优传输的关系

最优传输（optimal transport）（Chewi et al., 2024）是另一个研究如何最高效地将概率质量从分布 $\mu = q_0$ 移动到另一个分布 $\nu = q_{t_f}$ 的框架. 由于这个问题不是唯一的，我们定义一个成本函数 $\mathcal{C}(\mathbf{x}, \mathbf{y})$ 来度量将一单位概率质量从 $\mathbf{x}$ 移动到 $\mathbf{y}$ 的成本. 然后我们将问题定义为

$$\inf_{Q} \mathbb{E}_Q[\mathcal{C}(\mathbf{x}, \mathbf{y})] \quad \text{s.t.} \quad q_X = \mu,\ q_Y = \nu. \tag{620}$$

这里，Q 是 $\mathbf{x}, \mathbf{y}$ 上的联合概率分布，具有指定的边缘分布 μ, ν. OT 问题的这种表述被称为 Kantorovich 表述（Kantorovich, 1942）. 它允许 $\mathbf{x}$ 和 $\mathbf{y}$ 之间的随机映射，由联合分布 $Q(\mathbf{x}, \mathbf{y}) = q(\mathbf{x})q(\mathbf{y}|\mathbf{x})$ 表示.

该问题的一个更受限的版本是 Monge 表述（Monge, 1781）——它先于 Kantorovich 表述——其中我们只允许确定性映射：$q(\mathbf{y}|\mathbf{x}) = \delta(\mathbf{y} - f(\mathbf{x}))$. 在 Monge 表述中，目标是找到一个确定性映射 f，最小化期望传输成本 $\mathbb{E}_{q_X}[\mathcal{C}(\mathbf{x}, f(\mathbf{x}))]$，服从初始分布 μ 在映射 f 下的推前分布等于目标分布 ν 的约束：

$$\inf_{f} \mathbb{E}_{q_X}[\mathcal{C}(\mathbf{x}, f(\mathbf{x}))] \quad \text{s.t.} \quad q_X = \mu,\ f_{\#}[q_X] = \nu, \tag{621}$$

其中 $f_{\#}[q_X]$ 表示分布 q_X 在确定性映射 f 下的 推前（pushforward）. 推前定义为分布 q_X 在映射 f 下的变换，遵循密度在确定性映射下的变换规则：

$$f_{\#}[q_X](\mathbf{y}) = q_X(f^{-1}(\mathbf{y})) \left| \det \left(\frac{\partial f^{-1}(\mathbf{y})}{\partial \mathbf{y}} \right) \right|. \tag{622}$$

Monge 问题的经典解释——将土从挖掘处运送到建筑工地——如 图 42 所示.

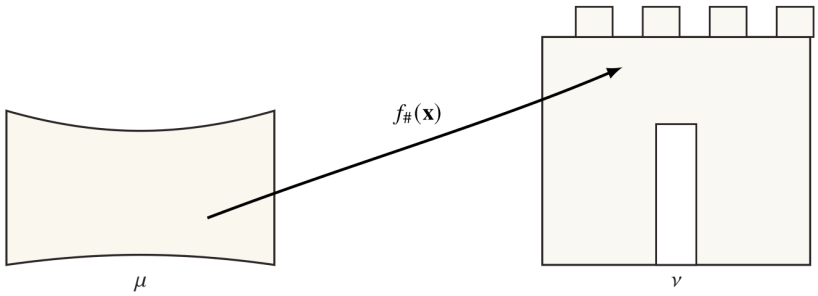


Figure 14.3 Monge formulation of optimal transport. The problem involves finding an optimal

图 42: 最优传输的 Monge 表述. 问题涉及找到一个最优映射 $f_\#(\mathbf{x})$，将质量从源分布 μ（左侧挖掘的坑）传输到目标分布 ν（右侧围墙结构）. 箭头指示传输映射. 该映射必须最小化期望传输成本 $\mathbb{E}_\mu[\mathcal{C}(\mathbf{x}, f(\mathbf{x}))]$，同时确保 μ 在 f 下的推前分布等于 ν.

为了与 SB 重新联系起来，我们在 OT 问题的 Kantorovich 表述 (620) 中添加一个熵正则化项：

$$\inf_Q\{\mathbb{E}_Q[\mathcal{C}(\mathbf{x},\mathbf{y})] - T\mathcal{S}[Q]\} \quad \text{s.t.} \quad q_X = \mu,\ q_Y = \nu. \tag{623}$$

如果我们现在令 $\mathcal{C}(\mathbf{x},\mathbf{y}) = -\log P(\mathbf{x},\mathbf{y}) = \mathcal{H}(\mathbf{x},\mathbf{y})$，我们就回到了一个具有温度 T 的自由能，或者等价地表述为 Q 与 P 之间的 KL 散度的 ELBO，服从边缘约束：

$$\inf_Q D_{\mathrm{KL}}[Q\|P] = \inf_Q \mathcal{F}[Q], \quad \mathcal{F}[Q] = \mathbb{E}_Q[\mathcal{H}] - T\mathcal{S}[Q], \quad \text{s.t.} \quad q_X = \mu,\ q_Y = \nu. \tag{624}$$

这建立了 SB 与 OT 之间的清晰联系：Monge 问题可以看作 Kantorovich 问题的确定性极限，而后者又是熵正则化 Kantorovich 问题的零温度极限，后者等价于一个二元 SB 问题（Léonard, 2014; Y. Chen et al., 2016）.

在机器学习中也观察到了随机映射与确定性映射之间类似的关系，其中扩散模型（第 13 章）具有随机转移，而归一化流（第 8 章）具有确定性变换.

14.5 与最大 Caliber 的关系

MaxCal 原理由 E. T. Jaynes（1980）提出，是最大熵原理向路径空间的直接推广. 其表述涉及在路径泛函上的某些期望约束下最大化熵（或更一般地，最小化到参考分布 P 的 KL 散度）（见 图 43）：

$$\min_Q D_{\mathrm{KL}}[Q\|P] \quad \text{s.t.} \quad \mathbb{E}_Q[A_k(\mathbf{x}_{0:t_f})] = \sum_{\mathbf{x}_{0:t_f}} Q(\mathbf{x}_{0:t_f}) A_k(\mathbf{x}_{0:t_f}) = a_k, \quad k = 1,\ldots,K, \tag{625}$$

其中 $A_k(\mathbf{x}_{0:t_f})$ 是路径泛函，a_k 是它们的指定期望值.



(a) High caliber: many admissible paths

(b) Low caliber: concentrated paths

Figure 14.4 Illustration of the maximum caliber principle comparing high and low entropy path

图 43: 最大 caliber 原理示意，比较高熵和低熵路径系综. (a) 高 caliber 构型，显示固定起点和终点状态之间的多样路径（实线曲线），对应高路径熵 $\mathcal{S}[Q]$. (b) 低 caliber 构型，路径更集中（虚线曲线），表示更低的路径熵. 两种构型必须满足相同的路径泛函约束 A_k，但在熵上不同.

注意，SB 问题现在可以通过选择特定的路径泛函来强制期望的边缘约束，从而被视为 MaxCal 形式体系的一个特例：

$$A_{\mathbf{y}_0}(\mathbf{x}_{0:t_f}) = \delta(\mathbf{x}_0 - \mathbf{y}_0) \times \mathbf{1}(\mathbf{x}_{1:t_f})$$
$$\Rightarrow \quad \sum_{\mathbf{x}_{0:t_f}} Q(\mathbf{x}_{0:t_f}) A_{\mathbf{y}_0}(\mathbf{x}_{0:t_f}) = \mu(\mathbf{y}_0), \tag{626}$$

$$A_{\mathbf{y}_{t_f}}(\mathbf{x}_{0:t_f}) = \mathbf{1}(\mathbf{x}_0, \ldots, \mathbf{x}_{t_f-1}) \times \delta(\mathbf{x}_{t_f} - \mathbf{y}_{t_f})$$
$$\Rightarrow \quad \sum_{\mathbf{x}_{0:t_f}} Q(\mathbf{x}_{0:t_f}) A_{\mathbf{y}_{t_f}}(\mathbf{x}_{0:t_f}) = \nu(\mathbf{y}_{t_f}), \tag{627}$$

其中 $\mathbf{1}(\cdot)$ 是对其自变量的所有值都等于 1 的函数.

然而，MaxCal 比 SB 问题更一般，因为我们可以对整条路径施加任意约束. 例如，我们可能想要控制某些转移率或自相关函数. 求解 MaxCal 问题也通过使用 Lagrange 乘子来强制期望约束，这与我们在第 1 章中对 MaxEnt 问题所做的非常相似，但现在将状态 $\mathbf{x}$ 替换为路径 $\mathbf{x}_{0:t_f}$. 因此，MaxCal 可以被视为非平衡热力学的一种最大熵表述!

Chapter 15

最优控制

15.1 引言

我们可以把扩散模型看作一个受控随机过程，它利用学习到的分数函数将扩散过程引导向数据分布. 因此，随机控制可以用变分自由能最小化来表述，这也许就不足为奇了. 在本章中，我们将研究 KL 控制，在其中我们可以通过最小化自由能泛函来执行推断（我们将用置信传播来完成）以求解控制问题. 我们在本章最后将其与 Schrödinger 桥联系起来.

15.2 基于模型的强化学习

在 基于模型的强化学习（model-based reinforcement learning）（RL）中，我们希望将系统的动力学驱离其自然动力学，以避免成本或获取奖励（Bellman, 1957）. 这个过程通常涉及定义一个动力学模型，描述世界在控制信号影响下如何演化. 为实现这一点，我们定义一列外部控制 $\mathbf{u}_t$，并考虑给定控制下状态的条件分布：

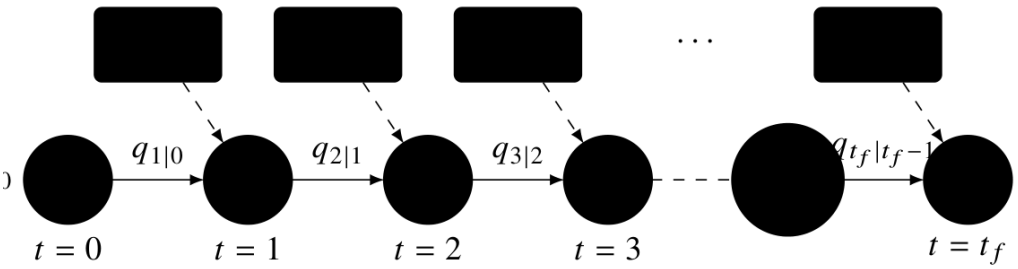
$$P(\mathbf{x}|\mathbf{u}) = p_0(\mathbf{x}_0)\prod_{t=1}^{t_f} p_{t|t-1}(\mathbf{x}_t|\mathbf{x}_{t-1}, \mathbf{u}_{t-1}), \tag{628}$$

其中 $\mathbf{x} = \mathbf{x}_{0:t_f}$ 和 $\mathbf{u} = \mathbf{u}_{0:t_f-1}$ 分别是状态序列和控制序列. 这里为简单起见，我们引入简写记号 $\mathbf{x}$ 和 $\mathbf{u}$ 来表示 $\mathbf{x}_{0:t_f}$ 和 $\mathbf{u}_{0:t_f-1}$，这样就不需要每次都写全. 图模型表示如 图 44 所示.

或者，我们可以通过引入随机策略 $\pi_t(\mathbf{u}_{t-1}|\mathbf{x}_{t-1})$ 来考虑 $\mathbf{x}$ 和 $\mathbf{u}$ 上的联合分布：

$$P(\mathbf{x}, \mathbf{u}) = p_0(\mathbf{x}_0)\prod_{t=1}^{t_f} p_{t|t-1}(\mathbf{x}_t|\mathbf{x}_{t-1}, \mathbf{u}_{t-1})\pi_t(\mathbf{u}_{t-1}|\mathbf{x}_{t-1}). \tag{629}$$

在 π_t 为 delta 峰（即确定性策略）的极限下，这两种表述变得等价.



Graphical model for model-based reinforcement learning. Circular nodes d

图 44: 基于模型的强化学习的图模型. 圆形节点表示状态轨迹 $\mathbf{x}_t$，矩形节点表示控制 $\mathbf{u}_t$，标注箭头编码了 (628) 中的受控转移密度 $p_{t|t-1}(\mathbf{x}_t|\mathbf{x}_{t-1}, \mathbf{u}_{t-1})$.

为了完成 RL 问题的表述，我们添加一个奖励（或成本）函数. 智能体的目标是在每个时间步 t 计算最佳动作，使总期望奖励最大化. 这需要执行推断（或边缘化，如我们将看到的）来计算最优动作.

我们将把这个问题表述为一个变分推断问题，其中最优策略是最大化 ELBO 或最小化变分自由能的那个. 要在实践中真正求解这个推断问题，需要假设非常小的状态空间或诉诸近似. 在（基于模型的）RL 中，人们会转而随机模拟遵循特定策略时获得的奖励，然后优化策略.

15.3 最优控制

在最优控制中，我们区分规划和学习（Bellman, 1957; Stengel, 1986）. 在前一种情形中，我们有一个世界动力学模型，智能体通过优化其动作来最大化奖励（或最小化成本）. 因此每一步都涉及一些昂贵的优化过程. 在现实生活中，例如当面临危险时，快速反应往往能救命，因此演化常常试图用对外部刺激的快速反射式动作来替代缓慢的优化或推断过程，这并不奇怪. Daniel Kahneman 用他的系统 1 和系统 2 思维模式来描述这种二分法，以区分这些快速和慢速的信息处理模式（Kahneman, 2011）.

为了模拟这一点，我们可以用一个学习到的策略 $\pi_t(\mathbf{u}_t|\mathbf{x}_t)$ 来替代逐时刻的显式优化，该策略可以立即执行，跳过规划操作. 例如，$\pi_t(\mathbf{u}_t|\mathbf{x}_t;\theta)$ 或 $\mathbf{u}_t = f(\mathbf{x}_t;\theta)$ 可以是参数化函数，如神经网络. 这个策略函数是一种 摊销推断的形式，通过观察大量样本，智能体试图预测最佳动作，作为最优规划的良好近似. 这种摊销与变分自编码器（VAE）非常相似，其中每个数据样本的推断被一个直接将输入映射到隐因子分布的函数所替代. 在本章中，我们将考察规划，即在每一步我们都优化最佳动作.

为了数学地表述控制问题，我们定义一个成本函数（或负奖励函数）$C(\mathbf{x}, \mathbf{u})$，它依赖于控制序列和状态序列. 当处理随机策略或演化动力学时，将平均成本作为优化目标更有意义：

$$\mathbb{E}_Q[C] = \sum_{\mathbf{x},\mathbf{u}} Q(\mathbf{x}, \mathbf{u}) C(\mathbf{x}, \mathbf{u}). \tag{630}$$

我们可以将这个平均成本视为自由能的 Hamiltonian，并添加一个熵项，偏好高熵路径而非低熵路径：

$$\mathcal{F}[Q] = \mathbb{E}_Q[C] - T\mathcal{S}[Q] = \sum_{\mathbf{x},\mathbf{u}} Q(\mathbf{x},\mathbf{u})\left(C(\mathbf{x},\mathbf{u}) + T\log Q(\mathbf{x},\mathbf{u})\right), \tag{631}$$

其中 T 是控制熵与成本之间权衡的温度参数. 通过定义逆温度 $\beta = 1/T$ 的 “Boltzmann 分布”

$$Q^*(\mathbf{x},\mathbf{u}) = \frac{1}{Z_{Q^*}} \exp(-\beta C(\mathbf{x},\mathbf{u})), \tag{632}$$

并利用 KL 散度的非负性 $D_{\mathrm{KL}}[Q\|Q^*] \geq 0$，我们可以推导以下关系：

$$F_{Q^*} \equiv -T\log Z_{Q^*} \leq \mathcal{F}[Q] = \mathbb{E}_Q[C] - T\mathcal{S}[Q]. \tag{633}$$

从这个熵正则化控制的简单表述中，我们得出结论：熵正则化控制等价于找到一个最优控制策略（或动作序列），使受控动力学 Q 尽可能接近 Boltzmann 分布 Q^*. 换句话说，我们需要在 Q 上最小化（松弛）(631) 中的自由能.

有趣的是，规划现在等价于在最优分布 Q^* 中执行（近似）推断（Levine, 2018）. 正如我们将在 节 15.4.3 中看到的，当仅考虑终端奖励时，存在与 Schrödinger 桥的联系，后者可以用迭代比例拟合求解——这个过程将某个联合分布的边缘 q_{t_f} 替换为指定的边缘 ν. 当边缘是集中在单个状态上的 delta 峰时，我们回到条件化，但在 IPF 中，我们可以对整个边缘进行 “条件化”.

15.4 Kullback–Leibler 控制

以下讨论基于 Kappen et al.（2012）. KL 控制框架此前由 Todorov（2007, 2008, 2009）以及 Toussaint and Storkey（2006）提出并研究. 为了与我们之前的记号保持一致，我们用 Q 表示我们从中采样轨迹的受控前向过程，而 P 表示我们的参考过程（注意这与 Kappen et al., 2012 中使用的记号不同）.

在 KL 控制中，我们引入一个固定的参考过程 P，通常表示世界的未受控 “自然” 动力学. 这个参考过程可以表示为一个前向过程：

$$P(\mathbf{x}_{0:t_f}) = p_0(\mathbf{x}_0)\prod_{t=1}^{t_f} p_{t|t-1}(\mathbf{x}_t|\mathbf{x}_{t-1}). \tag{634}$$

或者，它可以参数化为后向过程，如生成流网络中所做的那样（见第 16 章）：

$$P(\mathbf{x}_{0:t_f}) = p_{t_f}(\mathbf{x}_{t_f})\prod_{t=1}^{t_f} p_{t-1|t}(\mathbf{x}_{t-1}|\mathbf{x}_t). \tag{635}$$

人们总是可以用其中一个来表示另一个. 前向 (634) 和后向 (635) 表述之间的关系由平衡方程给出，

$$p_{t|t-1}(\mathbf{x}_t|\mathbf{x}_{t-1})p_{t-1}(\mathbf{x}_{t-1}) = p_{t-1|t}(\mathbf{x}_{t-1}|\mathbf{x}_t)p_t(\mathbf{x}_t), \tag{636}$$

其中 $p_t(\mathbf{x}_t)$ 是参考过程在时间步 t 的边缘分布：

$$p_t(\mathbf{x}_t) = \sum_{\mathbf{x}_{0:t-1}, \mathbf{x}_{t+1:t_f}} P(\mathbf{x}_{0:t_f}). \tag{637}$$

有了这些定义，KL 正则化控制问题表述为

$$\mathcal{F}[Q, P] = \mathbb{E}_Q[C] + D_{\mathrm{KL}}[Q \| P], \tag{638}$$

其中我们在 Q 上优化. 目标中的 KL 项鼓励受控动力学 Q 保持接近参考动力学 P，而期望成本项 $\mathbb{E}_Q[C]$ 驱动 Q 朝着最小化成本函数的方向发展. 这个表述推广了我们之前讨论的熵正则化情形，可以通过选择 P 为均匀分布来恢复. 我们本可以再次插入一个温度，但为了保持记号简单，我们假设 $\beta = 1/T$ 已被吸收到成本函数 $\mathcal{C}$ 的定义中.

通过再次定义引导 Boltzmann 分布，

$$Q^*(\mathbf{x}|\mathbf{u}) = \frac{1}{Z_{Q^*}} P(\mathbf{x}) \exp(-C(\mathbf{x}, \mathbf{u})), \tag{639}$$

我们仍然从不等式 $D_{\mathrm{KL}}[Q \| Q^*] \geq 0$ 出发，可以推导以下界：

$$F_{Q^*} \equiv -\log Z_{Q^*} \leq \mathcal{F}[Q, P] = \mathbb{E}_Q[C] + D_{\mathrm{KL}}[Q \| P], \tag{640}$$

其中目标现在是找到在平均上最小化成本 $\mathbb{E}_Q[C]$ 同时被正则化为保持接近未受控参考路径 P 的路径. 这个表述再次允许自由能解释，建立了与统计推断的直接联系. 如上所述，我们可以将 Q^* 视为一种广义后验分布，它已经纳入了奖励信号.

通常，我们定义一个同时包含路径成本项和终端成本项的成本函数：

$$C(\mathbf{x}, \mathbf{u}) = C_{t_f}(\mathbf{x}_{t_f}) + \sum_{t=1}^{t_f} C_t(\mathbf{x}_t, \mathbf{x}_{t-1}, \mathbf{u}_{t-1}). \tag{641}$$

额外的 KL 项允许我们定义一个 Hamiltonian，

$$\mathcal{H}(\mathbf{x}, \mathbf{u}) = C_{t_f}(\mathbf{x}_{t_f}) + \sum_{t=1}^{t_f} \big(C_t(\mathbf{x}_t, \mathbf{x}_{t-1}, \mathbf{u}_{t-1}) - \log p_{t|t-1}(\mathbf{x}_t|\mathbf{x}_{t-1}) \big) - \log p_0(\mathbf{x}_0), \tag{642}$$

它现在将成本项与参考过程 P 的负对数概率结合起来. 这些负对数概率可以解释为额外的成本，惩罚偏离系统自然动力学的行为. 添加一个熵项后，自由能可以写为

$$\mathcal{F} = \mathbb{E}_Q[\mathcal{H}] - \mathcal{S}[Q] = \mathbb{E}_Q\left[C_{t_f}(\mathbf{x}_{t_f}) + \sum_{t=1}^{t_f} \left(C_t(\mathbf{x}_t, \mathbf{x}_{t-1}, \mathbf{u}_{t-1}) + \log \frac{q_{t|t-1}(\mathbf{x}_t|\mathbf{x}_{t-1}, \mathbf{u}_{t-1})}{p_{t|t-1}(\mathbf{x}_t|\mathbf{x}_{t-1})} \right) + \log \frac{q_0(\mathbf{x}_0)}{p_0(\mathbf{x}_0)} \right]. \tag{643}$$

从上面，我们可以用两种方式解释这个问题. 首先，我们可以将其视为标准的最优控制形式，试图最小化成本 $\mathbb{E}_Q[C]$，其中成本现在也涉及 Q 和 P. 或者，我们可以将其视为一个统计推断问题，我们希望通过将 Q 匹配到引导 Boltzmann 分布 Q^* 来最小化 Q 上的自由能，我们将在下一节进一步解释.

15.4.1 与推断的关系

KL 控制问题与统计推断相联系. 为了找到最优动作 $\mathbf{u}_t$，我们需要在 Q 上最小化 (640) 中的自由能. 这个优化产生每个时间步的最优转移 $q^*_{t|t-1}(\mathbf{x}_t|\mathbf{x}_{t-1}, \mathbf{u}_{t-1})$. 然而，我们已经解决了这个问题！即，(639) 中的 Boltzmann 分布就是自由能最小化问题的最优解. 因此，在我们的控制足够灵活以实现 $Q = Q^*$ 的假设下，我们只需要（通过推断）计算 $q^*_{t|t-1}(\mathbf{x}_t|\mathbf{x}_{t-1}, \mathbf{u}_{t-1})$，就能知道我们的最优动作 $\mathbf{u}_{t-1}$ 应该是什么.

注意，$Q = Q^*$ 是控制问题在热力学意义上的平衡分布. 在平衡态，受控动力学 $Q = Q^*$ 将等于未受控动力学 P，但被控制成本 “引导”，其中高成本路径被降权，反之亦然. 上面定义的两个程序将产生相同的答案.

我们如何计算 $q^*_{t|t-1}(\mathbf{x}_t|\mathbf{x}_{t-1}, \mathbf{u}_{t-1})$? 为了找到它，我们观察到我们的任务是从联合分布计算条件分布:

$$q^*_{t|t-1}(\mathbf{x}_t|\mathbf{x}_{t-1}, \mathbf{u}_{t-1}) = \frac{q^*_t(\mathbf{x}_t, \mathbf{x}_{t-1}|\mathbf{u}_{t-1})}{\sum_{\mathbf{x}_t} q^*_t(\mathbf{x}_t, \mathbf{x}_{t-1}|\mathbf{u}_{t-1})} \propto \sum_{\mathbf{x}\setminus\{\mathbf{x}_t,\mathbf{x}_{t-1}\}} Q^*(\mathbf{x}|\mathbf{u}), \tag{644}$$

$$Q^*(\mathbf{x}|\mathbf{u}) = \frac{1}{Z_{Q^*}} P(\mathbf{x}) \exp(-C(\mathbf{x}, \mathbf{u})). \tag{645}$$

这是一个标准的边缘化问题，可以用动态规划（Bellman, 1957）（又名 “置信传播”）求解，如下（见第 6 章）.

首先，观察到 Q^* 可以写成成对势的乘积:

$$\begin{aligned} Q^*(\mathbf{x}|\mathbf{u}) &\propto p_0(\mathbf{x}_0) e^{-C_{t_f}(x_{t_f})} \prod_{t=1}^{t_f} p_{t|t-1}(\mathbf{x}_t|\mathbf{x}_{t-1}) \exp(-C_t(\mathbf{x}_t, \mathbf{x}_{t-1}, \mathbf{u}_{t-1})) \\ &= \Phi_0(\mathbf{x}_0) \prod_{t=1}^{t_f} \Phi_{t,t-1}(\mathbf{x}_t, \mathbf{x}_{t-1}, \mathbf{u}_{t-1}). \end{aligned} \tag{646}$$

接下来，将 (639) 和 (646) 对除 $\mathbf{x}_t$ 和 $\mathbf{x}_{t-1}$ 以外的所有变量边缘化:

$$\begin{aligned} q^*_t(\mathbf{x}_t, \mathbf{x}_{t-1}|\mathbf{u}_{t-1}) &= \sum_{\mathbf{x}_{0:t-2}, \mathbf{x}_{t+1:t_f}} Q^*(\mathbf{x}|\mathbf{u}) \\ &\propto \Phi_0(\mathbf{x}_0) \Phi_{t,t-1}(\mathbf{x}_t, \mathbf{x}_{t-1}, \mathbf{u}_{t-1}) \left(\sum_{\mathbf{x}_{0:t-2}} \prod_{s=1}^{t-1} \Phi_{s,s-1}(\mathbf{x}_s, \mathbf{x}_{s-1}, \mathbf{u}_{s-1}) \right) \\ &\quad \times \left(\sum_{\mathbf{x}_{t+1:t_f}} \prod_{s=t+1}^{t_f} \Phi_{s,s-1}(\mathbf{x}_s, \mathbf{x}_{s-1}, \mathbf{u}_{s-1}) \right) \\ &= \Phi_{t,t-1}(\mathbf{x}_t, \mathbf{x}_{t-1}, \mathbf{u}_{t-1}) \, m_{t-1\to t}(\mathbf{x}_{t-1}, \mathbf{u}_{t-1}) \, m_{t+1\to t}(\mathbf{x}_t, \mathbf{u}_t), \end{aligned} \tag{647}$$

其中在最后一步我们识别出前向和后向消息为

$$m_{t-1\to t}(\mathbf{x}_{t-1}, \mathbf{u}_{t-1}) = \sum_{\mathbf{x}_{0:t-2}} \Phi_0(\mathbf{x}_0) \prod_{s=1}^{t-1} \Phi_{s,s-1}(\mathbf{x}_s, \mathbf{x}_{s-1}, \mathbf{u}_{s-1}), \tag{648}$$

$$m_{t+1\to t}(\mathbf{x}_t, \mathbf{u}_t) = \sum_{\mathbf{x}_{t+1:t_f}} \prod_{s=t+1}^{t_f} \Phi_{s,s-1}(\mathbf{x}_s, \mathbf{x}_{s-1}, \mathbf{u}_{s-1}). \tag{649}$$

如果我们将后向消息初始化为 $m_{t_f+1\to t_f}(\mathbf{x}_{t_f},\mathbf{u}_{t_f})=1$，那么，理解消息隐式地依赖于所有未来控制后，后向消息可以迭代地计算为

$$m_{t+1\to t}(\mathbf{x}_t,\mathbf{u}_t)=\sum_{\mathbf{x}_{t+1}}\Phi_{t+1,t}(\mathbf{x}_{t+1},\mathbf{x}_t,\mathbf{u}_t)\,m_{t+2\to t+1}(\mathbf{x}_{t+1},\mathbf{u}_{t+1}). \tag{650}$$

现在，为了获得最优策略的条件概率，我们从 (647) 对 $\mathbf{x}_t$ 归一化：

$$\begin{aligned} q^*_{t|t-1}(\mathbf{x}_t|\mathbf{x}_{t-1},\mathbf{u}_{t-1}) &= \frac{q^*_t(\mathbf{x}_t,\mathbf{x}_{t-1}|\mathbf{u}_{t-1})}{\sum_{\mathbf{x}_t} q^*_t(\mathbf{x}_t,\mathbf{x}_{t-1}|\mathbf{u}_{t-1})} \\ &= \frac{\Phi_{t,t-1}(\mathbf{x}_t,\mathbf{x}_{t-1},\mathbf{u}_{t-1})\,m_{t+1\to t}(\mathbf{x}_t,\mathbf{u}_t)}{\sum_{\mathbf{x}_t}\Phi_{t,t-1}(\mathbf{x}_t,\mathbf{x}_{t-1},\mathbf{u}_{t-1})\,m_{t+1\to t}(\mathbf{x}_t,\mathbf{u}_t)}. \end{aligned} \tag{651}$$

有趣的是，前向消息 $m_{t-1\to t}(\mathbf{x}_{t-1},\mathbf{u}_{t-1})$ 在分子和分母中抵消了，这意味着我们只需要计算后向消息来确定最优策略. 直观地说，这来自前向模型 Q^* 的图结构，其中变量 $\mathbf{x}_t$ 在给定 $\mathbf{x}_{t-1}$ 的条件下独立于所有变量 $\{\mathbf{x}_0,\dots,\mathbf{x}_{t-2}\}$. 换句话说，变量 $\mathbf{x}_{t-1}$ 总结了关于过去的所有信息，因此来自过去的影响在知道 $\mathbf{x}_{t-1}$ 后被阻断. 因此，我们此时的动作不依赖于我们在过去收集（或错过）的奖励. 然而，我们现在的动作显然会影响我们期望在未来获得的奖励.

15.4.2 学习策略

如前所述，本章的方法是在每个时间步通过计算 $q^*_{t|t-1}(\mathbf{x}_t|\mathbf{x}_{t-1},\mathbf{u}_{t-1})$ 来找到动作上的最优分布，从中我们计算实现该转移的最优动作 $\mathbf{u}^*_{t-1}$. 然而，这在计算上非常昂贵，尤其是在高维状态和动作空间中或处理长规划视界时.

另一种方法是通过学习一个策略 $\mathbf{u}^*_t=f(\mathbf{x}_t;\theta)$ 来摊销这个过程，该策略近似最优动作分布. 这个策略可以表示为一个函数逼近器，如神经网络，将状态映射到动作或（动作上的概率分布）. 通过离线训练这个策略，我们可以快速执行动作，而无需在每一步执行昂贵的优化.

在实践中，学习策略涉及在从与环境交互或使用模型模拟中收集的数据上训练函数逼近器. 目标是最小化一个损失函数，度量策略动作与从规划导出的最优动作之间的差异，例如

$$\min_\theta \mathbb{E}_{\mathbf{x}_t}\left[\|\mathbf{u}^*_t(\mathbf{x}_t)-f(\mathbf{x}_t;\theta)\|^2\right]. \tag{652}$$

这种方法在实时决策至关重要的应用中特别有用.

KL 控制框架在传统控制问题之外找到了令人惊讶的应用，包括 AI 对齐. 一个特别值得注意的例子是基于人类反馈的强化学习（Christiano et al., 2017; Ouyang et al., 2022），其中语言模型使用人类偏好数据进行微调. 最近的工作表明，RLHF 可以在 KL 控制框架内优雅地表述（Korbak et al., 2022; Yang et al., 2024）. 在 RLHF 中，参考过程 P 表示预训练语言模型在序列上的分布，而成本函数 C 从基于人类偏好训练的奖励模型导出. 对齐的策略仍然取我们 (639) 中引导 Boltzmann 分布的形式. 这提供了一个重要的洞见：RLHF 主要是对原始分布进行重加权，而非引入真正的新知识，因为它只能降权不期望的行为、升权预训练分布中已存在的期望行为.

我们还应该提及无模型强化学习方法，如 Q-learning（Watkins and Dayan, 1992）和值迭代，它们不依赖环境的显式模型来学习值函数或动作-值函数. 这些方法超出了本书的范围，但关于它们如何与自由能和 ELBO 相关联的有趣视角，见 Levine（2018）.

15.4.3 与 Schrödinger 桥的关系

KL 控制框架与 Schrödinger 桥有有趣的联系,在第 14 章中讨论过. 回顾 Schrödinger 桥的 Lagrangian，(613)：

$$\mathcal{L} = D_{\mathrm{KL}}[Q\|P] + \mathbb{E}_Q\left[\log \frac{p_{t_f}(\mathbf{x}_{t_f})}{\nu(\mathbf{x}_{t_f})}\right] + \text{const}, \tag{653}$$

其中我们假设 $q_0 = \delta_{\mathbf{y}_0}$，即在 $\mathbf{x}_0 = \mathbf{y}_0$ 处的 delta 峰. 将此与 (638) 比较，我们立即看到，通过以下识别：

$$C(\mathbf{x}) = \mathbf{1}(\mathbf{x}_0, \ldots, \mathbf{x}_{t_f-1}) \log \frac{p_{t_f}(\mathbf{x}_{t_f})}{\nu(\mathbf{x}_{t_f})}, \tag{654}$$

KL 控制目标直接映射到 Schrödinger 桥 Lagrangian. 在两个框架中，我们都在寻找一个接近参考过程 P 的过程 Q. 关键区别在于，在 Schrödinger 桥中，我们匹配一个指定的终端分布 ν，而在 KL 控制中，我们最小化一个可以依赖于整条轨迹的成本函数.

Chapter 16

生成流网络

16.1 引言

在本书的大部分内容中，我们一直在讨论马尔可夫链，它们是可以描绘为链图的图模型. 扩散模型和序贯重要性采样方法就是很好的例子，而且它们非常成功. 在第 4 章中，我们还介绍了可以描绘为有向无环图（DAG）的图模型，并在第 6 章中解释了如何在它们上执行推断和学习. 在本章中，我们将介绍 生成流网络（generative flow network）（GFlowNet），这是一类定义在 DAG 上的机器学习模型，由 Bengio et al.（2021, 2023）提出. GFlowNet 结合了强化学习、图模型概率建模和生成式 AI 的思想. 当我们想要按奖励函数比例采样解决方案路径时，它们特别有用. 在本章中，我们还将 GFlowNet 与本书中描述的其他各种方法联系起来，如变分推断、退火重要性采样（AIS）和（熵正则化）控制.

16.2 生成流网络

我们可以将 GFlowNet(Bengio et al., 2021, 2023)形式化地定义为一个元组 $(\mathcal{X}, \mathcal{A}, F, B, R)$，其中：

- $\mathcal{X}$ 是状态集合，包括一个初始源状态 $\mathbf{x}_0$ 和一组终端状态 $\mathcal{X}_f$，以及一个最终汇状态 $\mathbf{x}_s$.
- $\mathcal{A}$ 是定义状态间转移的动作集合.
- $F(\mathbf{x}'|\mathbf{x})$ 是前向策略，指定从状态 $\mathbf{x}$ 转移到状态 $\mathbf{x}'$ 的概率.
- $B(\mathbf{x}|\mathbf{x}')$ 是后向策略，指定从状态 $\mathbf{x}'$ 转移到状态 $\mathbf{x}$ 的概率.
- $R(\mathbf{x})$ 是定义在终端状态 $\mathbf{x} \in \mathcal{X}_f$ 上的非负奖励函数.

这如 图 45 所示. 如果我们把它看作一个图模型，那么在根节点处我们有一个关于单个可能源状态 $\mathbf{x}_0$ 的先验分布，即 $q_0(\mathbf{x}_0) = 1$. 然后我们使用转移概率 $F(\mathbf{x}'|\mathbf{x}_0)$（每个转移概率都可以不同）将这个概率质量扩散到下一个可能状态 $\mathbf{x}_1, \mathbf{x}_2, \mathbf{x}_3$ 等等. 最后，我们以概率 1 转移到单个最终 “汇” 状态 $\mathbf{x}_s$. 终端状态（汇状态之前的最后一个状态）的边缘概率等于 $q_f(\mathbf{x}_f) \equiv \pi(\mathbf{x}_f) = R(\mathbf{x}_f)/Z_R$，其中 $Z_R = \sum_{\mathbf{x}' \in \mathcal{X}_f} R(\mathbf{x}')$. 可以在每个状态退出的推广也很容易处理；例如见 Bengio et al.（2023）.

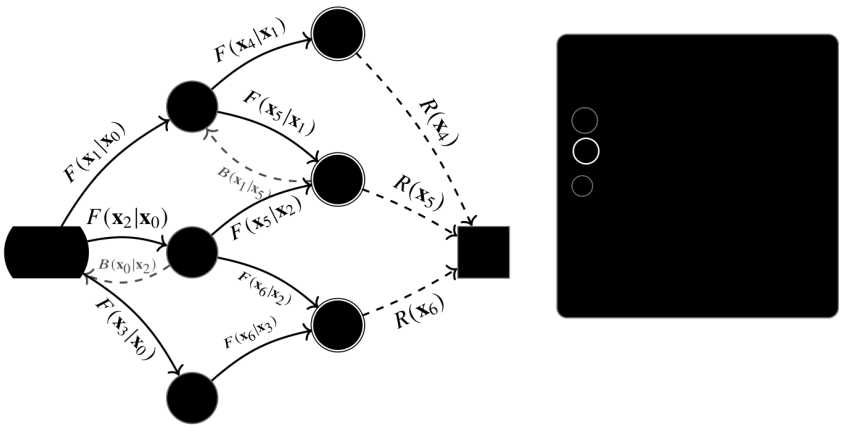


Figure 16.1 Generative flow network (GFlowNet). The network shows the flow of probabilities

图 45: 生成流网络（GFlowNet）. 网络显示了概率从初始状态 $\mathbf{x}_0$ 通过各种中间和终端状态流向汇状态 $\mathbf{x}_s$ 的过程. 前向流 $F(\mathbf{x}'|\mathbf{x})$（实线箭头）表示状态间的转移，而后向流 $B(\mathbf{x}|\mathbf{x}')$（虚线箭头，仅部分画出）表示反向转移. 终端状态（双圈）收集奖励 $R(\mathbf{x})$（指向汇的虚线箭头）.

如果通过适当设计转移 F，我们可以强制最终边缘概率与 $R(\mathbf{x}_f)$ 成正比，那么我们就可以使用 GFlowNet 按 $R(\mathbf{x}_f)$ 的比例采样状态. 在这个意义上，这与强化学习非常相似，其中我们学习一个以与 $R(\mathbf{x})$ 成正比的概率传递奖励的策略. 然而注意，在 RL 中我们学习一个最大化期望奖励的策略，而在这里我们学习一个按奖励比例采样状态的策略.

实现这一目标的关键是将概率解释为守恒量的流，类似于粒子或概率质量流过网络. 最初的 GFlowNet 论文使用未归一化的 “流” 而非概率. 然而，这两种表述是等价的. 例如，我们可以称 Z_R 为在源处注入的奖励总量，它然后在网络上重新分布并在汇节点处再次被收集. 我们可以识别

$$\Gamma(\mathbf{x} \to \mathbf{x}') = Z_R \, q(\mathbf{x}) \, F(\mathbf{x}'|\mathbf{x}) \tag{655}$$

为从节点 $\mathbf{x}$ 流向 $\mathbf{x}'$ 的总奖励，其中 $\Gamma(\mathbf{x} \to \mathbf{x}')$ 表示流，$F(\mathbf{x}'|\mathbf{x})$ 表示转移概率（无量纲）. 我们可以认为

$$\Gamma(\mathbf{x}) = Z_R \, q(\mathbf{x}) \tag{656}$$

为驻留在节点 $\mathbf{x}$ 上的奖励总量. 当奖励流到达终端节点时，我们可以 “测量” 从终端节点流向汇节点的奖励量. 到达汇节点的奖励总量等于 Z_R，即在源节点处注入的奖励总量.

现在可以写出一些简单的奖励守恒定律，表示流入任意节点的奖励总量必须等于流出的奖励总量：

$$\sum_{\mathbf{x} \in \text{Parents}(\mathbf{x}')} \Gamma(\mathbf{x} \to \mathbf{x}') + \mathbb{I}_{\mathbf{x}'=\mathbf{x}_0} Z_R = \sum_{\mathbf{x}'' \in \text{Children}(\mathbf{x}')} \Gamma(\mathbf{x}' \to \mathbf{x}''), \quad \text{对所有} \mathbf{x}' \in \mathcal{X}. \tag{657}$$

将两边除以 Z_R 并使用 $\Gamma(\mathbf{x} \to \mathbf{x}') = Z_R q(\mathbf{x}) F(\mathbf{x}'|\mathbf{x})$，我们得到概率形式的流守恒方程：

$$\sum_{\mathbf{x} \in \text{Parents}(\mathbf{x}')} q(\mathbf{x}) F(\mathbf{x}'|\mathbf{x}) + \mathbb{1}_{\mathbf{x}'=\mathbf{x}_0} = \sum_{\mathbf{x}'' \in \text{Children}(\mathbf{x}')} q(\mathbf{x}') F(\mathbf{x}''|\mathbf{x}'), \quad \text{对所有} \mathbf{x}' \in \mathcal{X}. \tag{658}$$

这里，$\mathbb{1}_{\mathbf{x}=\mathbf{y}}$ 是指示函数，当 $\mathbf{x} = \mathbf{y}$ 时为 1，否则为 0. 量 $Z_R > 0$ 是在 $\mathbf{x}_0$ 处注入的源流. 当 $\mathbf{x}' = \mathbf{x}_0$ 时我们需要额外的指示项，因为 $\mathbf{x}_0$ 在图中没有父节点. 集合 Parents($\mathbf{x}$) 表示可以转移到 $\mathbf{x}$ 的状态集合，类似地，Children($\mathbf{x}$) 表示 $\mathbf{x}$ 可以转移到的状态集合. 最后，我们注意到

$$\Gamma(\mathbf{x}_f \to \mathbf{x}_s) = Z_R \, q_f(\mathbf{x}_f) F(\mathbf{x}_s|\mathbf{x}_f) = Z_R \, \pi(\mathbf{x}_f) \equiv R(\mathbf{x}_f), \tag{659}$$

其中 $F(\mathbf{x}_s|\mathbf{x}_f) = 1$，因为只有一种转移可能.

这个条件确保流在整个网络中守恒，除了在收集奖励的终端状态处（以及在注入奖励的初始状态处）. 用物理术语来说，我们可以把它想象成一个物理系统，在源和汇位置（链的起点和终点）连接了一个 “粒子浴”（奖励浴）. 奖励在源处注入，然后流过链并在汇处被吸收. （人们可以将源和汇连接起来，此时奖励在系统中循环流动.）

16.3 与序贯重要性采样的关系

GFlowNet 可用于学习前向策略，以从与奖励函数成正比的分布中采样，这可以看作序贯重要性采样方法的推广，如第 12 章所讨论的. 为了将 GFlowNet 与第 12 章的序贯重要性采样方法联系起来，我们现在限制在 DAG 为链图的特殊情形，即状态按顺序排列为 $\mathbf{x}_0, \mathbf{x}_1, \ldots, \mathbf{x}_{t_f}$. 在链中，每个状态 $\mathbf{x}_t$ 恰好有一个父状态 $\mathbf{x}_{t-1}$（除 $\mathbf{x}_0$ 外）和一个子状态 $\mathbf{x}_{t+1}$（除 $\mathbf{x}_{t_f}$ 外）.

对于链情形，我们使用时间索引记号定义前向和后向模型：

$$Q(\mathbf{x}_{0:t_f}) = q_0(\mathbf{x}_0) \prod_{t=1}^{t_f} F_t(\mathbf{x}_t|\mathbf{x}_{t-1}), \tag{660}$$

$$P(\mathbf{x}_{0:t_f}) = \pi(\mathbf{x}_{t_f}) \prod_{t=1}^{t_f} B_t(\mathbf{x}_{t-1}|\mathbf{x}_t). \tag{661}$$

注意我们固定 $q_{t_f} = \pi = R/Z_R$.

在 GFlowNet 中，前向和后向流在每个时间步之间的流平衡方程为

$$q_{t-1}(\mathbf{x}_{t-1}) F_t(\mathbf{x}_t|\mathbf{x}_{t-1}) = q_t(\mathbf{x}_t) B_t(\mathbf{x}_{t-1}|\mathbf{x}_t), \tag{662}$$

它们使用局部一致性目标来强制实现. 这是 (658) 中一般流守恒定律在连续时间步上的链图版本.

Bengio 等人提出的一个这样的目标有时被称为 “细致平衡” 损失：

$$L_{\text{DB}}(\mathbf{x}_{t-1}, \mathbf{x}_t) = \log^2 \frac{q_{t-1}(\mathbf{x}_{t-1}) F_t(\mathbf{x}_t|\mathbf{x}_{t-1})}{q_t(\mathbf{x}_t) B_t(\mathbf{x}_{t-1}|\mathbf{x}_t)}. \tag{663}$$

我们想强调，在本书的语境中，这个方程并不强制细致平衡，因为边缘分布 q_t 和 q_{t-1} 指代不同的节点. 细致平衡是一个平衡条件，而这里我们只是写下前向流 F 和后向（时间反演）流 B 之间的关系. 我们在本书中讨论马尔可夫链时已经多次遇到这个微妙之处.

通常，在 GFlowNet 文献中，后向核 B_t 保持固定（例如在 $\mathbf{x}_t$ 的父节点上均匀分布），尽管它们也可以被学习. 人们可以把这看作是通过定义一列中间奖励样函数来将奖励函数 R 沿时间向后延拓，引导学习过程朝向期望的终端奖励函数，类似于 AIS 中中间分布的思想以及扩散模型的运作方式. GFlowNet 然后学习一个前向策略，反向地遵循由延拓奖励函数定义的后向过程.

除了学习前向转移 F_t 之外，边缘分布 q_t 也必须被学习，因为它们通过 (658) 中的流匹配条件与前向转移绑定. 然后可以使用祖先采样（通过 F_t 前向采样）或重要性采样来从目标分布采样，类似于第 12 章中描述的方法.

一些替代目标已被引入，使用 ϕ-散度强制这些流平衡方程（其中 ϕ 有一些偏好选择）(Malkin et al., 2023, 2022)，以及通过匹配子轨迹（Madan et al., 2023）而非整条轨迹或链中时间步的序贯对. 除此之外，该框架非常好地映射到第 12 章的退火重要性采样讨论，并且是 MCMC 启发方法如何应用于强化学习问题的一个例子.

16.4 与变分推断的关系

虽然 (663) 强制每个时间步上流之间的局部一致性，但一个在整条轨迹上强制轨迹平衡的不同目标已被证明表现更好，并且与变分推断和 ELBO 表述有更密切的联系 (Malkin et al., 2022, 2023). 这个目标基于以下轨迹平衡约束：

$$Z_R\, q_0(\mathbf{x}_0) \prod_{t=1}^{t_f} F_t(\mathbf{x}_t|\mathbf{x}_{t-1}) = R(\mathbf{x}_{t_f}) \prod_{t=1}^{t_f} B_t(\mathbf{x}_{t-1}|\mathbf{x}_t), \tag{664}$$

其中 Z_R 是与源注入相关的可学习归一化常数.

回顾 $q_0(\mathbf{x}_0) = 1$，我们可以定义轨迹平衡残差 $r(\mathbf{x}_{0:t_f})$ 为

$$r(\mathbf{x}_{0:t_f}) = \log Z_R + \sum_{t=1}^{t_f} \log F_t(\mathbf{x}_t|\mathbf{x}_{t-1}) - \log R(\mathbf{x}_{t_f}) - \sum_{t=1}^{t_f} \log B_t(\mathbf{x}_{t-1}|\mathbf{x}_t). \tag{665}$$

轨迹平衡目标然后是均方残差

$$\mathcal{L}_{\mathrm{TB}}(\mathbf{x}_{0:t_f}) = r(\mathbf{x}_{0:t_f})^2. \tag{666}$$

可以证明，如果对所有轨迹 $\mathbf{x}_{0:t_f}$ 都有 $r(\mathbf{x}_{0:t_f}) = 0$，则相应的马尔可夫流 Q 对所有终端状态 $\mathbf{x}_{t_f}$ 满足 $Q(\mathbf{x}_{t_f}) \propto R(\mathbf{x}_{t_f})$，且 F_t 按奖励比例采样.

我们现在将此与 KL/ELBO 目标联系起来. 令 $\hat{P}(\mathbf{x}_{0:t_f}) = R(\mathbf{x}_{t_f}) \prod_{t=1}^{t_f} B_t(\mathbf{x}_{t-1}|\mathbf{x}_t)$ 为未归一化后向路径密度，$Z_R = \sum_{\mathbf{x}\in\mathcal{X}_f} R(\mathbf{x})$. 则 $P(\mathbf{x}_{0:t_f}) = \hat{P}(\mathbf{x}_{0:t_f})/Z_R$，且

$$\mathbb{E}_Q\left[\log \frac{Q(\mathbf{x}_{0:t_f})}{\hat{P}(\mathbf{x}_{0:t_f})}\right] = \mathbb{E}_Q[r(\mathbf{x}_{0:t_f})] - \log Z_R = D_{\mathrm{KL}}[Q\|P] - \log Z_R. \tag{667}$$

假设 B_t 固定，我们可以为基于残差的目标计算一个方便的梯度：

$$\nabla_\theta \mathbb{E}_Q[r(\mathbf{x}_{0:t_f})] = \mathbb{E}_Q\left[(1 + r(\mathbf{x}_{0:t_f})) \sum_{t=1}^{t_f} \nabla_\theta \log F_t(\mathbf{x}_t|\mathbf{x}_{t-1})\right], \tag{668}$$

其中 θ 是 F_t（以及可能的 Z_R）的参数.

16.5 与 AIS 的关系

GFlowNet 与第 12 章讨论的 AIS 有概念上的相似性. 与 AIS 类似，GFlowNet 在一列状态或步骤上运作，从初始状态 $\mathbf{x}_0$ 逐步移动到终端状态 $\mathbf{x}_f$. 两个框架都旨在计算直接采样具有挑战性的目标分布的性质. 两种方法都平衡前向和反向转移，以减小重要性权重的方差或确保终端流与期望的奖励分布对齐.

AIS 是一种重要性采样方法，具有精心设计的中间分布来估计配分函数或期望值. 在 AIS 中，采样轨迹基于目标与中间分布之比累积重要性权重. 相比之下，GFlowNet 将问题框架化为一个流守恒网络，学习策略以按奖励比例采样路径. 换句话说，GFlowNet 本质上为整条路径构建了一个生成模型.

16.6 与其他概念的关系

GFlowNet 还与熵正则化强化学习相联系，如 Bengio et al.（2021）; Tiapkin et al.（2023）所示.

在熵正则化 RL 中，智能体寻求的策略 π 不仅最大化期望奖励，还最大化奖励与策略熵的组合：

$$\max_\pi \mathbb{E}_{\pi\sim\tau}[R(\tau)] + T\mathcal{S}[\pi], \tag{669}$$

其中 $\mathcal{S}[\pi]$ 是策略的熵，它鼓励所采取动作的探索和多样性. GFlowNet 可以被视为求解类似的问题.

Chapter 17

涨落定理

17.1 引言

涨落定理（fluctuation theorem）（FT）是一组将热力学第二定律推广到涨落普遍存在的小系统的等式. 它们联系了在非平衡过程中观察到产生熵轨迹和消耗熵轨迹的概率. FT 在轨迹层面运作，是非平衡过程中为数不多的精确等式之一. 标准的热力学不等式（如第二定律）作为 FT 对平均量的近似而成立. 因此，FT 代表了非平衡热力学中一个非常深刻和核心的理论，可用于例如估计分布的自由能（或 ML 中的证据）以及分布之间的自由能差（例如计算药物与蛋白质结合的亲和力）. 下一章将完全致力于自由能估计.

17.2 涨落定理背后的数学

以下阐述基于 Esposito and Van den Broeck（2010）的深刻论文.

考虑一个按概率分布 $P(\chi)$ 分布的随机变量 χ. 我们说 χ 服从 积分涨落定理（integral fluctuation theorem）（IFT），如果

$$\mathbb{E}_P[e^{-\chi}] = \int d\chi\, P(\chi) e^{-\chi} = 1. \tag{670}$$

由 Jensen 不等式，这蕴含 $\mathbb{E}[\chi] \geq 0$. (670) 等价于陈述：非负函数 $P(\chi)e^{-\chi}$ 实际上积分为 1，因此是一个归一化的概率密度函数. 这进而也意味着函数 $Q(\chi) = P(-\chi)e^{\chi}$ 是一个 PDF. 我们为什么选择后者将在后面变得清楚. 这一认识导出了以下 细致涨落定理（detailed fluctuation theorem）（DFT）：

$$\frac{P(\chi)}{Q(-\chi)} = e^{\chi} \quad \text{对所有}\chi. \tag{671}$$

这意味着积分 FT 蕴含细致 FT. 通过积分很容易看出 DFT 也蕴含 IFT，因此实际上这两个陈述是等价的.

此外，我们还可以如下写出广义 IFT：对任意函数 f，我们有

$$\begin{aligned}\mathbb{E}_P[f(\chi)e^{-\chi}] &= \int d\chi\, P(\chi) f(\chi) e^{-\chi} \\ &= \int d\chi\, Q(-\chi) f(\chi) = \mathbb{E}_Q[f(-\chi)].\end{aligned} \tag{672}$$

我们现在在热力学路径上选择以下耗散函数：

$$\Sigma(\zeta_{0:t_f}) = \log \frac{\rho(\zeta_{0:t_f})}{\omega(\zeta_{0:t_f})}, \tag{673}$$

其中 ρ 和 ω 是路径上的两个 PDF. 我们假设这些分布相互绝对连续（具有相同的支撑），使得对数比有良好定义. 我们想推导耗散函数取某一值 χ 的 FT；即我们定义

$$P(\chi) = \int d\zeta_{0:t_f}\, \rho(\zeta_{0:t_f})\, \delta(\Sigma(\zeta_{0:t_f}) - \chi). \tag{674}$$

由 (673) 中耗散函数的定义，我们立即验证 IFT：

$$\begin{aligned}\int d\chi\, P(\chi) e^{-\chi} &= \int d\chi \int d\zeta_{0:t_f}\, \rho(\zeta_{0:t_f}) \delta(\Sigma(\zeta_{0:t_f}) - \chi) e^{-\chi} \\ &= \int d\chi \int d\zeta_{0:t_f}\, \omega(\zeta_{0:t_f}) e^{\Sigma(\zeta_{0:t_f})} \delta(\Sigma(\zeta_{0:t_f}) - \chi) e^{-\chi} \\ &= \int d\zeta_{0:t_f}\, \omega(\zeta_{0:t_f}) = 1,\end{aligned} \tag{675}$$

其中我们使用了 delta 函数的性质 $\int d\chi\, \delta(a-\chi) f(\chi) = f(a)$ 以及 ω 是归一化 PDF 的事实.

我们现在知道 IFT 也必须成立，因此（在 (670) 中将 χ 换为 $-\chi$ 并使用 (674) 和 (673)）

$$\begin{aligned}Q(\chi) = P(-\chi) e^{\chi} &= \int d\zeta_{0:t_f}\, \rho(\zeta_{0:t_f}) \delta(\Sigma(\zeta_{0:t_f}) + \chi) e^{\chi} \\ &= \int d\zeta_{0:t_f}\, \omega(\zeta_{0:t_f}) e^{\Sigma(\zeta_{0:t_f})} \delta(\Sigma(\zeta_{0:t_f}) + \chi) e^{\chi} \\ &= \int d\zeta_{0:t_f}\, \omega(\zeta_{0:t_f}) \delta(\Sigma(\zeta_{0:t_f}) + \chi).\end{aligned} \tag{676}$$

我们强调，到目前为止我们所做的不过是定义数学对象并将它们相互联系起来. 在某种层面上，这些只是没有物理意义的数学重言式. 但在接下来的步骤中，我们做出选择，开始将其与物理学联系起来. 特别是，我们将通过一个物理变换将分布 ω 与分布 ρ 联系起来：$\omega = \rho'$. 例如，我们可以反转路径的顺序、反转动量、反转控制协议，或对 ρ 施加任意操作，将一个密度变换为另一个密度. 然后我们写：

$$\omega(\zeta_{0:t_f}) = \rho'(\zeta_{0:t_f}). \tag{677}$$

通过两次施加变换，我们可以推导耗散函数如何变换：

$$\begin{aligned}\Sigma'(\zeta_{0:t_f}) &= \log \frac{\rho'(\zeta_{0:t_f})}{\rho''(\zeta_{0:t_f})} \\ &= \log \frac{\rho'(\zeta_{0:t_f})}{\rho(\zeta_{0:t_f})}.\end{aligned} \tag{678}$$

如果我们现在假设该操作是一个对合（involution）；即 $\rho'' = \omega' = \rho$，我们得到

$$\Sigma'(\zeta_{0:t_f}) = \log \frac{\rho'(\zeta_{0:t_f})}{\rho(\zeta_{0:t_f})} = -\Sigma(\zeta_{0:t_f}). \tag{679}$$

由 (676) 我们现在可以进一步简化 FT 中 P 的定义：

$$P(\chi) = \int d\zeta_{0:t_f}\, \rho'(\zeta_{0:t_f})\delta(\Sigma'(\zeta_{0:t_f}) - \chi). \tag{680}$$

注意，P 现在具有与 (674) 相同的形式，但 $\rho \to \rho'$ 且 $\Sigma \to \Sigma'$. 如果这些代表系统上的物理变换，那么 FT (670) 和 (671) 现在具有有趣的物理意义. 在接下来的章节中，我们将使用三个特定变换来应用这个一般框架：时间反演（给出 ρ_R）、伴随变换（给出 ρ_A）和对偶变换（给出 ρ_D）.

17.3 三种熵产生分解

如 Esposito and Van den Broeck（2010）所引入，非平衡过程中的总熵产生可以分解为绝热和非绝热贡献，每一种都满足自己的细致涨落定理. 含奇变量的情形更为微妙，在文献中被 Spinney and Ford（2012a,b）作为单独情形处理. 为了避免这些复杂性和相关的边界项，我们在本节全程假设平稳分布在动量上是对称的；即 $\hat{\pi} = \pi$，$\pi(\hat{\zeta}) = \pi(\zeta)$.

考虑一个具有路径概率密度的前向过程：

$$\rho(\zeta_{0:t_f}) = \rho_0(\zeta_0) \prod_{t=1}^{t_f} F_t(\zeta_t|\zeta_{t-1}), \tag{681}$$

其中 $F_t(\zeta_t|\zeta_{t-1})$ 是前向转移核，$\rho_0(\zeta_0)$ 是初始分布. 遵循第 9 章的记号，任何具有转移核 F_t 且具有唯一平稳分布 π_t 的马尔可夫链满足以下平衡方程：

$$F_t(\zeta_t|\zeta_{t-1})\pi_t(\zeta_{t-1}) = A_t(\zeta_{t-1}|\zeta_t)\pi_t(\zeta_t), \tag{682}$$

其中 A_t 是使同一平稳分布不变的伴随核.

我们还定义时间反演核 R_t 为

$$R_t(\zeta_{t-1}|\zeta_t) = F_t(\hat{\zeta}_{t-1}|\hat{\zeta}_t), \tag{683}$$

其中 $\hat{\zeta}_t = (\xi_t, -\eta_t)$ 表示动量反转后的 ζ_t.

类似地，我们可以定义对偶核 D_t 为

$$D_t(\zeta_t|\zeta_{t-1}) = A_t(\hat{\zeta}_t|\hat{\zeta}_{t-1}). \tag{684}$$

使用这些核，我们定义几个随机过程：(i) 具有路径概率的时间反演过程：

$$\rho_R(\zeta_{0:t_f}) = \rho_{t_f}(\zeta_{t_f}) \prod_{t=1}^{t_f} R_t(\zeta_{t-1}|\zeta_t). \tag{685}$$

(ii) 具有路径概率的伴随过程：

$$\rho_A(\zeta_{0:t_f}) = \rho_{t_f}(\zeta_{t_f}) \prod_{t=1}^{t_f} A_t(\zeta_{t-1}|\zeta_t). \tag{686}$$

(iii) 具有路径概率的对偶过程：

$$\rho_D(\zeta_{0:t_f}) = \rho_0(\zeta_0)\prod_{t=1}^{t_f} D_t(\zeta_t|\zeta_{t-1}). \tag{687}$$

这些过程使我们能够定义三个依赖于轨迹的熵产生：

$$\Sigma_{\rm tot}(\zeta_{0:t_f}) = \log\frac{\rho(\zeta_{0:t_f})}{\rho_R(\zeta_{0:t_f})}, \tag{688}$$

$$\Sigma_{\rm na}(\zeta_{0:t_f}) = \log\frac{\rho(\zeta_{0:t_f})}{\rho_A(\zeta_{0:t_f})}, \tag{689}$$

$$\Sigma_{\rm a}(\zeta_{0:t_f}) = \log\frac{\rho(\zeta_{0:t_f})}{\rho_D(\zeta_{0:t_f})}. \tag{690}$$

在我们关于平稳分布在动量上对称的假设下，我们可以证明这三个熵产生的关系如下：

$$\Sigma_{\rm tot}(\zeta_{0:t_f}) = \Sigma_{\rm na}(\zeta_{0:t_f}) + \Sigma_{\rm a}(\zeta_{0:t_f}). \tag{691}$$

然而，如果我们不假设平稳分布的时间反演对称性，我们会多出一个项，它即使在平均上也不一定是正的（Spinney and Ford, 2012b）.

非绝热熵产生 $\Sigma_{\rm na}$ 与系统向其瞬时平稳态的弛豫相关. 它量化了由于系统远离平稳态而产生的熵产生. 当系统演化足够缓慢、在整个过程中保持在瞬时平稳态时（热力学意义上的准静态或绝热过程），这一贡献消失. 如果我们选择初始和最终状态相对于参数 λ_0 和 λ_{t_f} 处于平衡态——即 $\rho_0 = \pi_0$ 且 $\rho_{t_f} = \pi_{t_f}$——那么 $\Sigma_{\rm na}$ 对应于耗散功：$\Sigma_{\rm na} = \beta(W - \Delta F)$.

绝热熵产生 $\Sigma_{\rm a}$ 与非平衡稳态中概率流的维持相关. 它量化了即使系统处于非平衡稳态、由于细致平衡破缺而持续存在的熵产生. 这一贡献对满足细致平衡的系统（例如平衡态系统）消失，但对由非保守力驱动的系统即使在达到稳态时也保持非零. 注意 $\Sigma_{\rm a}$ 与管家热 $Q_{\rm hk}$ 的关系为 $\Sigma_{\rm a} = -\beta Q_{\rm hk}$.

17.3.1 证明

为了推导熵分解 (691)，我们代入熵产生的定义：

$$\Sigma_{\rm na} + \Sigma_{\rm a} = \log\frac{\rho}{\rho_A} + \log\frac{\rho}{\rho_D} = \log\frac{\rho^2}{\rho_A\rho_D}. \tag{692}$$

为了继续，我们需要计算乘积 $\rho_A(\zeta_{0:t_f})\rho_D(\zeta_{0:t_f})$. 使用 (686) 和 (687) 中的定义，我们发现：

$$\rho_A(\zeta_{0:t_f})\rho_D(\zeta_{0:t_f}) = \rho_0(\zeta_0)\rho_{t_f}(\zeta_{t_f})\prod_{t=1}^{t_f} A_t(\zeta_{t-1}|\zeta_t)D_t(\zeta_t|\zeta_{t-1}). \tag{693}$$

使用 A_t 和 D_t 的定义，我们可以证明：

$$A_t(\zeta_{t-1}|\zeta_t)D_t(\zeta_t|\zeta_{t-1}) = \frac{A_t(\zeta_{t-1}|\zeta_t)\pi_t(\zeta_{t-1})}{\pi_t(\zeta_t)}\cdot\frac{D_t(\zeta_t|\zeta_{t-1})\hat{\pi}_t(\zeta_t)}{\hat{\pi}_t(\zeta_{t-1})}, \tag{694}$$

如果我们假设 $\hat{\pi}_t = \pi_t$. 这然后导致

$$\rho_A(\zeta_{0:t_f})\rho_D(\zeta_{0:t_f}) = \rho(\zeta_{0:t_f})\rho_R(\zeta_{0:t_f}). \tag{695}$$

因此

$$\Sigma_{\mathrm{na}} + \Sigma_{\mathrm{a}} = \log \frac{\rho^2}{\rho_A \rho_D} = \log \frac{\rho^2}{\rho \rho_R} = \log \frac{\rho}{\rho_R} = \Sigma_{\mathrm{tot}}. \tag{696}$$

这证明了 (691) 中的分解.

17.3.2 熵产生的显式表达式

我们可以用转移核和平稳分布推导每个熵产生的显式表达式.

对于总熵产生，从 (681) 和 (685) 中的定义出发：

$$\begin{aligned}
\Sigma_{\mathrm{tot}}(\zeta_{0:t_f}) &= \log \frac{\rho_0(\zeta_0)\prod_t F_t(\zeta_t|\zeta_{t-1})}{\rho_{t_f}(\zeta_{t_f})\prod_t R_t(\zeta_{t-1}|\zeta_t)} \\
&= \log \frac{\rho_0(\zeta_0)}{\rho_{t_f}(\zeta_{t_f})} + \sum_{t=1}^{t_f} \log \frac{F_t(\zeta_t|\zeta_{t-1})}{R_t(\zeta_{t-1}|\zeta_t)} \\
&= \log \frac{\rho_0(\zeta_0)}{\rho_{t_f}(\zeta_{t_f})} + \sum_{t=1}^{t_f} \log \frac{F_t(\zeta_t|\zeta_{t-1})}{R_t(\hat{\zeta}_{t-1}|\hat{\zeta}_t)},
\end{aligned} \tag{697}$$

其中在最后一步我们使用了 (683) 中 R_t 的定义.

对于绝热熵产生，使用 (681)、(687)、(684) 中 D_t 的定义以及 (682)：

$$\begin{aligned}
\Sigma_{\mathrm{a}}(\zeta_{0:t_f}) &= \sum_{t=1}^{t_f} \log \frac{D_t(\zeta_t|\zeta_{t-1})}{F_t(\zeta_t|\zeta_{t-1})} \\
&= \sum_{t=1}^{t_f} \log \frac{A_t(\hat{\zeta}_t|\hat{\zeta}_{t-1})}{F_t(\zeta_t|\zeta_{t-1})} \\
&= \sum_{t=1}^{t_f} \log \frac{A_t(\hat{\zeta}_t|\hat{\zeta}_{t-1})\hat{\pi}_{t-1}(\hat{\zeta}_{t-1})}{F_t(\zeta_t|\zeta_{t-1})\pi_t(\zeta_t)} \\
&= \sum_{t=1}^{t_f} \log \frac{A_t(\hat{\zeta}_t|\hat{\zeta}_{t-1})\pi_{t-1}(\zeta_{t-1})}{R_t(\hat{\zeta}_{t-1}|\hat{\zeta}_t)\pi_t(\zeta_t)},
\end{aligned} \tag{698}$$

其中在最后一行我们再次假设 $\hat{\pi} = \pi$. 观察到如果细致平衡成立，Σ_{a} 消失. 因此 Σ_{a} 仅依赖于每个时间步细致平衡的破缺.

对于非绝热熵产生，由 (681) 和 (686)，我们得到

$$\begin{aligned}
\Sigma_{\mathrm{na}}(\zeta_{0:t_f}) &= \log \frac{\rho_0(\zeta_0)}{\rho_{t_f}(\zeta_{t_f})} + \sum_{t=1}^{t_f} \log \frac{F_t(\zeta_t|\zeta_{t-1})}{A_t(\zeta_{t-1}|\zeta_t)} \\
&= \log \frac{\rho_0(\zeta_0)}{\rho_{t_f}(\zeta_{t_f})} + \sum_{t=1}^{t_f} \log \frac{\pi_t(\zeta_t)}{\pi_{t-1}(\zeta_{t-1})}.
\end{aligned} \tag{699}$$

观察到，正如预期的那样，

$$\Sigma_{\mathrm{tot}} = \Sigma_{\mathrm{na}} + \Sigma_{\mathrm{a}}. \tag{700}$$

因此，Σ_{na} 将边界项与沿轨迹的平稳分布变化结合起来，而 Σ_{a} 捕捉细致平衡破缺.

17.4 三个涨落定理的推导

对于每个熵产生，我们可以推导一个细致涨落定理. 让我们定义观察每个熵产生特定值的概率分布：

$$P_{\mathrm{tot}}(\chi) = \int d\zeta_{0:t_f}\, \rho(\zeta_{0:t_f})\delta(\Sigma_{\mathrm{tot}}(\zeta_{0:t_f}) - \chi), \tag{701}$$

$$P_{\mathrm{na}}(\chi) = \int d\zeta_{0:t_f}\, \rho(\zeta_{0:t_f})\delta(\Sigma_{\mathrm{na}}(\zeta_{0:t_f}) - \chi), \tag{702}$$

$$P_{\mathrm{a}}(\chi) = \int d\zeta_{0:t_f}\, \rho(\zeta_{0:t_f})\delta(\Sigma_{\mathrm{a}}(\zeta_{0:t_f}) - \chi). \tag{703}$$

以及在各自共轭过程下的相应分布：

$$\tilde{P}_{\mathrm{tot}}(\chi) = \int d\zeta_{0:t_f}\, \rho_R(\zeta_{0:t_f})\delta(\tilde{\Sigma}_{\mathrm{tot}}(\zeta_{0:t_f}) - \chi), \tag{704}$$

$$\tilde{P}_{\mathrm{na}}(\chi) = \int d\zeta_{0:t_f}\, \rho_A(\zeta_{0:t_f})\delta(\tilde{\Sigma}_{\mathrm{na}}(\zeta_{0:t_f}) - \chi), \tag{705}$$

$$\tilde{P}_{\mathrm{a}}(\chi) = \int d\zeta_{0:t_f}\, \rho_D(\zeta_{0:t_f})\delta(\tilde{\Sigma}_{\mathrm{a}}(\zeta_{0:t_f}) - \chi). \tag{706}$$

对于总熵产生，遵循 节 17.2 的方法，我们可以写：

$$\begin{aligned} P_{\mathrm{tot}}(\chi) &= \int d\zeta_{0:t_f}\, \rho(\zeta_{0:t_f})\delta(\Sigma_{\mathrm{tot}}(\zeta_{0:t_f}) - \chi) \\ &= \int d\zeta_{0:t_f}\, \rho_R(\zeta_{0:t_f}) e^{\Sigma_{\mathrm{tot}}(\zeta_{0:t_f})}\delta(\Sigma_{\mathrm{tot}}(\zeta_{0:t_f}) - \chi) \\ &= e^{\chi} \int d\zeta_{0:t_f}\, \rho_R(\zeta_{0:t_f})\delta(\Sigma_{\mathrm{tot}}(\zeta_{0:t_f}) - \chi). \end{aligned} \tag{707}$$

对于时间反演过程，我们需要证明熵产生变号. 在时间反演变换 $\rho \to \rho_R$ 下，轨迹 $(\zeta_0, \ldots, \zeta_{t_f})$ 映射到 $(\hat{\zeta}_{t_f}, \ldots, \hat{\zeta}_0)$. 该变换下的熵产生变为：

$$\tilde{\Sigma}_{\mathrm{tot}}(\zeta_{0:t_f}) = \Sigma_{\mathrm{tot}}(\hat{\zeta}_{t_f}, \ldots, \hat{\zeta}_0) = -\Sigma_{\mathrm{tot}}(\zeta_{0:t_f}), \tag{708}$$

其中我们使用了 $\hat{\pi} = \pi$ 以及两次施加变换返回原始状态的事实. 这导出

$$P_{\mathrm{tot}}(\chi) = e^{\chi} \int d\zeta_{0:t_f}\, \rho_R(\zeta_{0:t_f})\delta(\tilde{\Sigma}_{\mathrm{tot}}(\zeta_{0:t_f}) + \chi) = e^{\chi}\tilde{P}_R(-\chi). \tag{709}$$

因此，我们得到总熵产生的 DFT：

$$\frac{P_{\mathrm{tot}}(\chi)}{\tilde{P}_R(-\chi)} = e^{\chi}. \tag{710}$$

绝热和非绝热熵产生的推导遵循类似模式. 我们有:

$$\tilde{\Sigma}_{\mathrm{na}}(\zeta_{0:t_f}) = -\Sigma_{\mathrm{na}}(\zeta_{0:t_f}), \tag{711}$$

$$\tilde{\Sigma}_{\mathrm{a}}(\zeta_{0:t_f}) = -\Sigma_{\mathrm{a}}(\zeta_{0:t_f}). \tag{712}$$

这导出另外两个细致涨落定理:

$$\frac{P_{\mathrm{na}}(\chi)}{\tilde{P}_A(-\chi)} = e^{\chi}, \tag{713}$$

$$\frac{P_{\mathrm{a}}(\chi)}{\tilde{P}_D(-\chi)} = e^{\chi}. \tag{714}$$

由于每个熵产生都满足自己的细致涨落定理——(710)、(713) 和 (714)——积分涨落定理通过积分得出. 这意味着相应的平均熵产生是非负的:

$$\mathbb{E}_\rho[\Sigma_{\mathrm{tot}}] \geq 0, \tag{715}$$

$$\mathbb{E}_\rho[\Sigma_{\mathrm{na}}] \geq 0, \tag{716}$$

$$\mathbb{E}_\rho[\Sigma_{\mathrm{a}}] \geq 0. \tag{717}$$

这些不等式代表三个不同的（广义）热力学第二定律. 对于趋近平衡态的系统，绝热贡献消失 $\langle \Sigma_{\mathrm{a}} \rangle = 0$，只有非绝热项贡献于总熵产生. 相反，对于处于非平衡稳态的系统，非绝热贡献消失 $\langle \Sigma_{\mathrm{na}} \rangle = 0$，只有绝热项贡献于总熵产生.

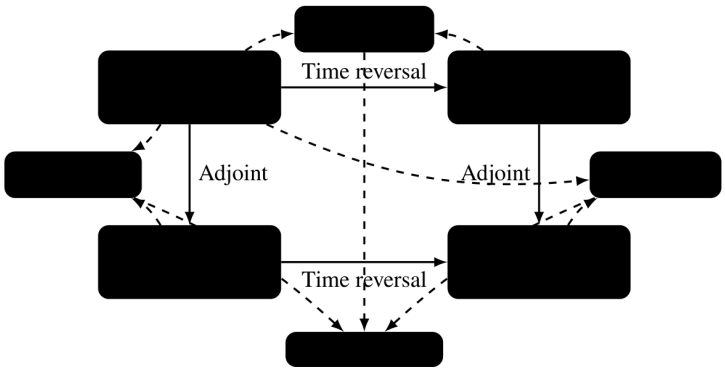


Figure 17.1 Relationship between the forward process and its conjugate processes

图 46: 前向过程与其共轭过程（时间反演、伴随、时间反演伴随）之间的关系，以及三种熵产生及其分解. 每种熵产生关于其共轭过程满足自己的细致涨落定理.

17.5 Crooks 涨落定理与 Jarzynski 等式

Crooks 涨落定理（Crooks fluctuation theorem）（Crooks, 1999）是前几节推导的 FT 的一个特例. 我们需要两个假设:

(1) 我们假设平衡态下细致平衡成立；即我们识别 $A_t = R_t$ 且 $D_t = F_t$（见第 9 章）. 这使得绝热熵产生贡献消失，因为 Σ_{a} 度量细致平衡的破缺.

(2) 我们假设马尔可夫链的初始状态和最终状态分别是 λ_0 和 λ_{t_f} 的平衡分布：

$$\rho_0(\zeta_0) = \pi_0(\zeta_0) = \frac{1}{Z_0} e^{-\beta \mathcal{H}_0(\zeta_0)}, \tag{718}$$

$$\rho_{t_f}(\zeta_{t_f}) = \pi_{t_f}(\zeta_{t_f}) = \frac{1}{Z_{t_f}} e^{-\beta \mathcal{H}_{t_f}(\zeta_{t_f})}, \tag{719}$$

其中 $\mathcal{H}_0(\zeta_0)$ 和 $\mathcal{H}_{t_f}(\zeta_{t_f})$ 是初始和最终 Hamiltonian，$\beta = 1/(k_B T)$ 是逆温度. 初始和最终平衡自由能由下式给出：

$$\mathcal{F}[\pi_0] = -\frac{1}{\beta} \log Z_0, \tag{720}$$

$$\mathcal{F}[\pi_{t_f}] = -\frac{1}{\beta} \log Z_{t_f}. \tag{721}$$

在这些假设下，系统的随机熵变可以表示为：

$$\begin{aligned} \Delta \mathcal{S}_{\mathrm{sys}}(\zeta_{0:t_f}) &= -\log \frac{\pi_{t_f}(\zeta_{t_f})}{\pi_0(\zeta_0)} \\ &= \beta[\mathcal{H}_{t_f}(\zeta_{t_f}) - \mathcal{H}_0(\zeta_0) - \mathcal{F}[\pi_{t_f}] + \mathcal{F}[\pi_0]] \\ &= \beta[\Delta \mathcal{U}(\zeta_{0:t_f}) - \Delta F], \end{aligned} \tag{722}$$

其中 $\Delta \mathcal{U}(\zeta_{0:t_f}) = \mathcal{H}_{t_f}(\zeta_{t_f}) - \mathcal{H}_0(\zeta_0)$ 是沿轨迹的内能变化，$\Delta F = F_{t_f} - F_0 = \mathcal{F}[\pi_{t_f}] - \mathcal{F}[\pi_0]$ 是平衡自由能差.

第 10 章的随机第一定律 (458) 蕴含 $\mathcal{W}(\zeta_{0:t_f}) = \Delta \mathcal{U}(\zeta_{0:t_f}) - \mathcal{Q}(\zeta_{0:t_f})$，假设环境的熵变由系统中的热产生给出 $\Delta \mathcal{S}_{\mathrm{bath}}(\zeta_{0:t_f}) = -\beta \mathcal{Q}(\zeta_{0:t_f})$，我们可以将总熵产生表示为：

$$\begin{aligned} \Sigma_{\mathrm{tot}}(\zeta_{0:t_f}) &= \Delta \mathcal{S}_{\mathrm{sys}}(\zeta_{0:t_f}) + \Delta \mathcal{S}_{\mathrm{bath}}(\zeta_{0:t_f}) \\ &= \beta[\Delta \mathcal{U}(\zeta_{0:t_f}) - \Delta F] - \beta \mathcal{Q}(\zeta_{0:t_f}) \\ &= \beta[\mathcal{W}(\zeta_{0:t_f}) - \Delta F], \end{aligned} \tag{723}$$

其中在最后一步我们使用了第一定律 $\Delta \mathcal{U} = \mathcal{W} + \mathcal{Q}$，即 $\Delta \mathcal{U} - \mathcal{Q} = \mathcal{W}$.

使用 (688)，这给出

$$\frac{\rho(\zeta_{0:t_f})}{\rho_R(\zeta_{0:t_f})} = e^{\Sigma_{\mathrm{tot}}(\zeta_{0:t_f})} = e^{\beta[\mathcal{W}(\zeta_{0:t_f}) - \Delta F]}, \tag{724}$$

由此 Crooks 细致 FT 从上述各节的一般理论得出：

$$\frac{\mathcal{P}(\chi)}{\mathcal{P}_R(-\chi)} = e^{\chi} \quad \Rightarrow \quad \frac{\mathcal{P}(\mathcal{W})}{\mathcal{P}_R(-\mathcal{W})} = e^{\beta[\mathcal{W} - \Delta F]}. \tag{725}$$

$\mathcal{P}(\mathcal{W}) = \mathcal{P}_R(-\mathcal{W})$ 的交叉点出现在 $\mathcal{W} = \Delta F$ 处，这提供了一种从非平衡测量估计自由能差的实用方法，我们将在第 18 章更详细地讨论这个主题.

Jarzynski 等式（Jarzynski equality）（Jarzynski, 1997）现在可以通过对 (724) 推导的方程两边在 ρ 上积分来平凡地导出：

$$\frac{\rho_R(\zeta_{0:t_f})}{\rho(\zeta_{0:t_f})} = e^{-\Sigma_{\text{tot}}(\zeta_{0:t_f})} = e^{-\beta[\mathcal{W}(\zeta_{0:t_f})-\Delta F]}, \tag{726}$$

$$\begin{aligned} 1 &= \mathbb{E}_\rho[e^{-\beta[\mathcal{W}(\zeta_{0:t_f})-\Delta F]}] \\ \Rightarrow \quad \mathbb{E}_\rho[e^{-\beta\mathcal{W}(\zeta_{0:t_f})}] &= e^{-\beta\Delta F}. \end{aligned} \tag{727}$$

这是积分涨落定理的一个实例. 它建立了非平衡过程中对系统所做的功与初始和最终状态之间平衡自由能差之间的显著联系. 关于通过验证 Jarzynski 等式的直接证明，见第 18 章.

对 (727) 应用 Jensen 不等式导出热力学第二定律的 Kelvin 表述：

$$\mathbb{E}_\rho[\mathcal{W}(\zeta_{0:t_f})] \geq \Delta F. \tag{728}$$

Chapter 18

自由能估计

18.1 引言

估计自由能差是物理学、机器学习，特别是生物化学背景下的一个核心问题（Chipot and Pohorille, 2007）. 平衡态之间的自由能差对于研究动力学系统（如真空中的小分子或膜蛋白）非常有意义. 例如，药物亲和力可以表示为配体-受体复合物结合态与未结合态之间的自由能差（Kollman et al., 2000），蛋白质的构象变化可以通过沿反应坐标的自由能景观来表征（Dellago et al., 2002）.

在本章中，我们将回顾一些流行的自由能估计方法，如 *自由能微扰*（free energy perturbation）和 *热力学积分*（thermodynamic integration）. 我们还推导基于涨落定理的方法，如 Jarzynski 和 Crooks FT. 最后，我们将推导最优 Bennett 接受率方法作为最小方差估计量.

18.2 自由能估计

在机器学习中，概率模型的归一化常数（边缘似然或模型证据）在数学上等价于物理学中的配分函数. 它的对数对应于负自由能，第 12 章讨论的退火重要性采样等方法就是我们在此讨论的物理自由能估计方法的直接应用.

令 π_A 和 π_B 为由各自 Hamiltonian $\mathcal{H}_A$ 和 $\mathcal{H}_B$ 定义的两个平衡分布. 系统在平衡态 A 的自由能由下式给出：

$$F_A = -\beta^{-1} \log Z_A, \tag{729}$$

其中 $Z_A = \int d\zeta \, e^{-\beta \mathcal{H}_A(\zeta)}$ 是配分函数，$\beta = 1/(k_B T)$ 是逆温度. 平衡态 A 和 B 之间的自由能差为

$$\Delta F_{AB} = F_B - F_A = -\beta^{-1} \log \frac{Z_B}{Z_A}. \tag{730}$$

计算困难在于 Z_A 和 Z_B 涉及高维积分，对于真实系统无法解析计算. 分子动力学（MD）模拟是生物化学中最常见的采样方法，其中有趣的自由能差通常定义在易于采样的平衡态和更有趣但更难采样的状态之间（Karplus and McCammon, 2002）. 例如，研究配体门控离子通道时，开放状态被认为是其天然状态，比关闭状态更容易采样.

18.2.1 自由能微扰

Zwanzig 方程，也称为 *自由能微扰理论*（free energy perturbation theory）（Zwanzig, 1954），将自由能差与参考平衡分布 π_A 上的系综平均联系起来：

$$\Delta F_{AB} = -\beta^{-1} \log \mathbb{E}_{\pi_A}\left[e^{-\beta [\mathcal{H}_B(\zeta) - \mathcal{H}_A(\zeta)]} \right]. \tag{731}$$

这可以用重要性采样容易地理解和推导. 配分函数之比可以写为关于分布 π_A 的期望值:

$$\frac{Z_B}{Z_A} = \frac{\int d\zeta\, e^{-\beta\mathcal{H}_B(\zeta)}}{\int d\zeta\, e^{-\beta\mathcal{H}_A(\zeta)}} = \frac{\int d\zeta\, e^{-\beta\mathcal{H}_A(\zeta)} e^{-\beta[\mathcal{H}_B(\zeta)-\mathcal{H}_A(\zeta)]}}{\int d\zeta\, e^{-\beta\mathcal{H}_A(\zeta)}}$$
$$= \int d\zeta\, \frac{e^{-\beta\mathcal{H}_A(\zeta)}}{Z_A} e^{-\beta[\mathcal{H}_B(\zeta)-\mathcal{H}_A(\zeta)]} = \mathbb{E}_{\pi_A}\left[e^{-\beta[\mathcal{H}_B(\zeta)-\mathcal{H}_A(\zeta)]}\right]. \tag{732}$$

对 (732) 两边取 $-\beta^{-1}\log$ 得到 Zwanzig 方程 (731).

与任何重要性采样估计量一样, 该估计量的效率关键取决于分布 π_A 和 π_B 之间的重叠. 如果重叠很小, 意味着 π_A 下的典型构型在 π_B 下非常罕见, 估计量可能具有高方差, 需要不切实际的大量样本才能收敛. 因此, 引入一系列中间状态来弥合 A 和 B 之间的差距通常是有益的.

18.2.2 热力学积分

直接重要性采样的替代方法是构造连接两个状态的可逆路径. 热力学积分 (Kirkwood, 1935; Frenkel and Smit, 2001) 提供了这种估计自由能差的方法, 基于构造平衡态之间的路径.

我们引入一个连续参数 $\lambda \in [0,1]$ 来平滑地插值两个 Hamiltonian 之间. 我们定义一个路径依赖的 Hamiltonian $\mathcal{H}(\zeta;\lambda)$, 它在工作参数 λ 从 $\lambda=0$ 变到 $\lambda=1$ 时在 $\mathcal{H}_A$ 和 $\mathcal{H}_B$ 之间插值. 例如, 经常使用线性插值: $\mathcal{H}(\zeta;\lambda) = (1-\lambda)\mathcal{H}_A(\zeta) + \lambda\mathcal{H}_B(\zeta)$.

自由能 F_λ 现在是 λ 的函数. 它关于 λ 的导数可以计算如下:

$$F_\lambda = -\beta^{-1}\log Z_\lambda, \quad Z_\lambda = \int d\zeta\, e^{-\beta\mathcal{H}(\zeta;\lambda)}, \tag{733}$$

$$\frac{dF_\lambda}{d\lambda} = -\beta^{-1}\frac{1}{Z_\lambda}\frac{dZ_\lambda}{d\lambda} = -\beta^{-1}\frac{1}{Z_\lambda}\int d\zeta\, e^{-\beta\mathcal{H}(\zeta;\lambda)}\left(-\beta\frac{\partial\mathcal{H}}{\partial\lambda}\right) = \int d\zeta\, \pi_\lambda(\zeta)\frac{\partial\mathcal{H}}{\partial\lambda} = \mathbb{E}_{\pi_\lambda}\left[\frac{\partial\mathcal{H}}{\partial\lambda}\right]. \tag{734}$$

将此导数从 $\lambda=0$ 积分到 $\lambda=1$ 给出总自由能差:

$$\Delta F_{AB} = F_B - F_A = \int_0^1 d\lambda\, \frac{dF_\lambda}{d\lambda} = \int_0^1 d\lambda\, \mathbb{E}_{\pi_\lambda}\left[\frac{\partial\mathcal{H}}{\partial\lambda}\right]. \tag{735}$$

这表明自由能差可以通过计算准静态 (无限缓慢) 或可逆过程中所做总功的系综平均来计算, 其中系统在每个瞬间 λ 都保持在平衡态 π_λ. 在实践中, 我们无法执行无限缓慢的过程. 相反, 我们将 λ 离散化为 t_f 步: 由 λ_t ($t=0,\ldots,t_f$) 定义的有限数量的中间状态, 其中 $\lambda_0=0$ 且 $\lambda_{t_f}=1$. 对于每个中间状态 λ_t, 运行平衡模拟 (例如 MD 或 MCMC) 来计算系综平均 $\mathbb{E}_{\pi_{\lambda_t}}[\partial\mathcal{H}/\partial\lambda]$. 然后通过对这些平均进行数值积分获得总自由能差, 例如使用梯形法则:

$$\Delta F_{AB} \approx \sum_{t=1}^{t_f}\frac{1}{2}\left(\mathbb{E}_{\pi_{\lambda_t}}\left[\frac{\partial\mathcal{H}}{\partial\lambda}\right] + \mathbb{E}_{\pi_{\lambda_{t-1}}}\left[\frac{\partial\mathcal{H}}{\partial\lambda}\right]\right)(\lambda_t - \lambda_{t-1}), \tag{736}$$

其中 $\tau(t) = t\Delta\tau$ 且 $\lambda_t = \lambda(\tau(t))$.

该方法与接下来讨论的非平衡功测量不同, 后者涉及单个有限时间切换过程.

18.3 非平衡功测量

在准静态过程中测量功的方法（其中 $\mathbb{E}_\rho[\mathcal{W}] = \Delta F$）通常不切实际，因为所需的过程极其缓慢. 涨落定理提供了强大的工具来分析和改进从非平衡功测量中估计自由能差，后者在计算上更易实现.

在本节中，我们解释如何使用随机动力学模拟非平衡过程，并重新推导 Jarzynski 等式，它将非平衡功与平衡自由能差联系起来.

考虑一个由时间依赖 Hamiltonian $\mathcal{H}_t(\zeta)$ 描述的系统，其中下标 t 表示离散时间步，Hamiltonian 按照预定协议 $\{\lambda_0, \ldots, \lambda_{t_f}\}$ 变化. 系统按照该协议在一系列 Hamiltonian $\{\mathcal{H}_0, \ldots, \mathcal{H}_{t_f}\}$ 下演化. 在逆温度 $\beta = 1/(k_B T)$ 下，每个 Hamiltonian $\mathcal{H}_t$ 对应的平衡分布由 Boltzmann 分布给出：

$$\pi_t(\zeta) = \frac{e^{-\beta \mathcal{H}_t(\zeta)}}{Z_t}, \quad Z_t = \int d\zeta \, e^{-\beta \mathcal{H}_t(\zeta)}, \tag{737}$$

其中 Z_t 是配分函数，$F_t = -\beta^{-1} \log Z_t$ 是时间步 t 的平衡自由能.

为了模拟系统的演化，我们采用 Monte Carlo 动力学. 如第 11 章所讨论的，Monte Carlo 算法使用前向转移概率核 $F_t(\zeta_t|\zeta_{t-1})$，它使分布 π_t 不变：

$$\int d\zeta_{t-1} \, F_t(\zeta_t|\zeta_{t-1}) \pi_t(\zeta_{t-1}) = \pi_t(\zeta_t). \tag{738}$$

该核 F_t 表示完整的 MCMC 转移，包括任何提议和接受-拒绝步骤. 平稳性条件确保如果外部驱动参数在第 t 步保持恒定，系统最终将弛豫到平衡分布 π_t（假设遍历性）.

回顾第 9 章，我们还可以定义反向核 $R_t(\zeta_{t-1}|\zeta_t) = F_t(\hat{\zeta}_{t-1}|\hat{\zeta}_t)$，其中 $\hat{\zeta}_t = (\xi_t, -\eta_t)$ 表示动量反转的状态. 该反向核定义了涨落定理背景下的时间反演过程.

在非平衡切换模拟中，我们在每个时间步遵循两步程序：(1) Hamiltonian 从 $\mathcal{H}_{t-1}$ 更新到 $\mathcal{H}_t$. (2) 使用核 $F_t(\cdot|\cdot)$ 执行 Monte Carlo 移动，该核被构造为使 π_t 不变，将系统从状态 ζ_{t-1} 移动到 ζ_t.

我们从 $t = 0$ 时系统处于平衡态开始，初始微态 ζ_0 从平衡分布 $\pi_0(\zeta_0)$ 采样. 然后系统按照该协议演化 t_f 个离散步. 此过程生成一条轨迹 $\zeta_{0:t_f} = \{\zeta_0, \zeta_1, \ldots, \zeta_{t_f}\}$：

$$\zeta_0 \xrightarrow{\mathcal{H}_1} \zeta_1 \xrightarrow{\mathcal{H}_2} \zeta_2 \cdots \xrightarrow{\mathcal{H}_{t_f}} \zeta_{t_f}. \tag{739}$$

遵循第 10 章所示的 Markov 性质，生成此轨迹的概率密度 $\rho(\zeta_{0:t_f})$ 由下式给出：

$$\rho(\zeta_{0:t_f}) = \pi_0(\zeta_0) \prod_{t=1}^{t_f} F_t(\zeta_t|\zeta_{t-1}). \tag{740}$$

对系统所做的随机功的量从每个时间步 Hamiltonian 更新（步骤 1）引起的能量变化计算，在系统弛豫（步骤 2）之前：

$$\mathcal{W}(\zeta_{0:t_f}) = \sum_{t=1}^{t_f} \delta \mathcal{W}_t \equiv \sum_{t=1}^{t_f} \left[\mathcal{H}_t(\zeta_{t-1}) - \mathcal{H}_{t-1}(\zeta_{t-1}) \right]. \tag{741}$$

18.3.1 Jarzynski 估计量

现在，让我们通过显式计算指数功项在轨迹系综上的期望，来验证该随机动力学的 Jarzynski 等式 (727)：

$$\begin{aligned}\mathbb{E}_\rho[e^{-\beta\mathcal{W}(\zeta_{0:t_f})}] &= \int d\zeta_{0:t_f}\,\rho(\zeta_{0:t_f})e^{-\beta\mathcal{W}(\zeta_{0:t_f})} \\ &= \int d\zeta_{0:t_f}\,\pi_0(\zeta_0)\prod_{t=1}^{t_f}F_t(\zeta_t|\zeta_{t-1})\exp\left(-\beta\sum_{t=1}^{t_f}[\mathcal{H}_t(\zeta_{t-1})-\mathcal{H}_{t-1}(\zeta_{t-1})]\right) \\ &= \int d\zeta_{0:t_f}\,\frac{e^{-\beta\mathcal{H}_0(\zeta_0)}}{Z_0}\prod_{t=1}^{t_f}\left(F_t(\zeta_t|\zeta_{t-1})e^{-\beta[\mathcal{H}_t(\zeta_{t-1})-\mathcal{H}_{t-1}(\zeta_{t-1})]}\right). \end{aligned} \tag{742}$$

聚焦于关于 ζ_0 的最内层积分，我们可以简化：

$$\begin{aligned}\int d\zeta_0\,\frac{e^{-\beta\mathcal{H}_0(\zeta_0)}}{Z_0}F_1(\zeta_1|\zeta_0)e^{-\beta[\mathcal{H}_1(\zeta_0)-\mathcal{H}_0(\zeta_0)]} &= \frac{1}{Z_0}\int d\zeta_0\,F_1(\zeta_1|\zeta_0)e^{-\beta\mathcal{H}_1(\zeta_0)} \\ &= \frac{Z_1}{Z_0}\int d\zeta_0\,F_1(\zeta_1|\zeta_0)\pi_1(\zeta_0)\quad\text{(使用 (737))} \\ &= \frac{Z_1}{Z_0}\pi_1(\zeta_1)\quad\text{(使用不变性 (738))}. \end{aligned} \tag{743}$$

有趣的是，我们只使用了每个 π_t 在相应核 F_t 下的不变性. 这个证明不需要细致平衡. 将此结果代回，关于 ζ_0 的积分完成，表达式现在以 $\frac{Z_1}{Z_0}\pi_1(\zeta_1)$ 开始. 我们可以对关于 $\zeta_1,\zeta_2,\ldots,\zeta_{t_f-1}$ 的积分重复此过程. 积分到 ζ_{t_f-1} 后，我们剩下：

$$\mathbb{E}_\rho[e^{-\beta\mathcal{W}(\zeta_{0:t_f})}] = \frac{Z_1}{Z_0}\frac{Z_2}{Z_1}\cdots\frac{Z_{t_f}}{Z_{t_f-1}}\int d\zeta_{t_f}\,\pi_{t_f}(\zeta_{t_f}) = \frac{Z_{t_f}}{Z_0} = e^{-\beta\Delta F}. \tag{744}$$

这个 Jarzynski 等式（Jarzynski, 1997, 2011）允许从非平衡功测量估计 ΔF. 给定从过程的 S 个独立实现中采样的 S 个独立功值 $\{\mathcal{W}_1,\mathcal{W}_2,\ldots,\mathcal{W}_S\}$，自由能差可以估计为：

$$\langle\Delta F\rangle \approx -\frac{1}{\beta}\log\left(\frac{1}{S}\sum_{s=1}^{S}e^{-\beta\mathcal{W}_s}\right). \tag{745}$$

该估计量的效率取决于耗散功，定义为 $\mathcal{W}_{\text{diss}} = \mathcal{W} - \Delta F$. 为了理解方差，我们需要分析 $e^{-\beta\mathcal{W}}$ 的方差以及传播到自由能估计的方差. 首先，对于指数功：

$$\begin{aligned}\mathrm{V}[e^{-\beta\mathcal{W}}] = \mathbb{E}_\rho[e^{-2\beta\mathcal{W}}] - \mathbb{E}_\rho[e^{-\beta\mathcal{W}}]^2 &= \mathbb{E}_\rho[e^{-2\beta\mathcal{W}}] - e^{-2\beta\Delta F}\quad\text{(使用 Jarzynski 等式)} \\ &= e^{-2\beta\Delta F}\left(\mathbb{E}_\rho[e^{-2\beta(\mathcal{W}-\Delta F)}]-1\right) = e^{-2\beta\Delta F}\left(\mathbb{E}_\rho[e^{-2\beta\mathcal{W}_{\text{diss}}}]-1\right). \end{aligned} \tag{746}$$

因此指数估计量的相对误差为

$$\frac{\sqrt{\mathrm{V}[e^{-\beta\mathcal{W}}]}}{\mathbb{E}_\rho[e^{-\beta\mathcal{W}}]} = \sqrt{\mathbb{E}_\rho[e^{-2\beta\mathcal{W}_{\text{diss}}}]-1}. \tag{747}$$

对于自由能估计本身，我们需要考虑 $\langle \Delta F \rangle$ 的方差. 使用对数变换的误差传播公式，对于大 S 我们得到

$$\mathrm{V}[\langle \Delta F \rangle] \approx \frac{1}{\beta^2 S} \frac{\mathrm{V}[e^{-\beta \mathcal{W}}]}{(\mathbb{E}[e^{-\beta \mathcal{W}}])^2} = \frac{\mathbb{E}_\rho[e^{-2\beta \mathcal{W}_{\mathrm{diss}}}] - 1}{\beta^2 S}. \tag{748}$$

为了将此方差转化为实际的样本量要求，我们使用对于 S 个独立样本，样本均值的标准误为 $\mathrm{SE}[\langle X \rangle] = \sqrt{\mathrm{V}[X]}/\sqrt{S}$. 为了实现估计的期望标准误 ϵ，我们需要样本数 S 使得 $\sqrt{\mathrm{V}[\langle \Delta F \rangle]} < \epsilon$. 这意味着

$$S > \frac{1}{\beta^2 \epsilon^2} \left(\mathbb{E}_\rho[e^{-2\beta \mathcal{W}_{\mathrm{diss}}}] - 1 \right). \tag{749}$$

因为平均值由 $\mathcal{W}$ 很小的稀有事件主导（即 $\mathcal{W}_{\mathrm{diss}}$ 大且为负），对于平均耗散功很大的高度不可逆过程，该估计量可能效率低下.

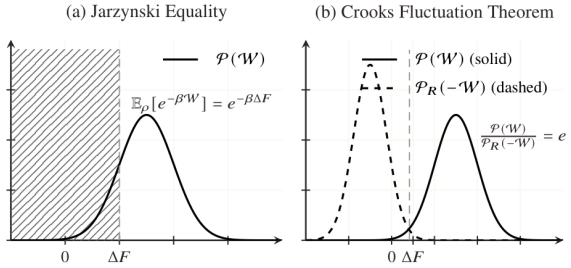


Figure 18.1 Jarzynski's equality and the Crooks fluctuation theorem. (a) The work distribution

图 47: Jarzynski 等式与 Crooks 涨落定理. (a) 前向过程的功分布 $\mathcal{P}(\mathcal{W})$（实线），ΔF 由垂直虚线参考线标出. 阴影区域表示 $\mathcal{W} \leq \Delta F$，对应于所做功小于自由能差的稀有涨落. Jarzynski 等式将 $e^{-\beta \mathcal{W}}$ 的平均值与 $e^{-\beta \Delta F}$ 联系起来，分布的尾部起着关键作用. (b) 前向 $\mathcal{P}(\mathcal{W})$（实线）和反向 $\mathcal{P}_R(-\mathcal{W})$（虚线）过程的功分布. Crooks 涨落定理将这些概率之比与 $e^{\beta(\mathcal{W}-\Delta F)}$ 联系起来，交叉点指示 $\mathcal{W} = \Delta F$. 反向过程通常在 ΔF 以下的功值处具有更高的概率，与热力学中时间之箭的方向一致.

18.4 双向估计量：Crooks 与 Bennett

Jarzynski 估计量的效率可以分析（Gore et al., 2003），并且通常通过结合前向过程（A 到 B）和反向过程（B 到 A）的数据来改进（Geiger and Dellago, 2010）. 我们现在引入反向过程，并展示它如何实现更高效的估计量.

反向过程定义如下. 从最终平衡分布 $\pi_{t_f}(\zeta_{t_f})$ 开始，系统在时间反演协议下演化，Hamiltonian 按相反顺序施加：$\{\mathcal{H}_{t_f}, \mathcal{H}_{t_f-1}, \ldots, \mathcal{H}_0\}$. 转移核也根据第 9 章的定义反向：$R_t(\zeta_{t-1}|\zeta_t) = F_t(\hat{\zeta}_{t-1}|\hat{\zeta}_t)$，其中 $\hat{\zeta}_t = (\xi_t, -\eta_t)$ 表示动量反转的状态. 反向过程的路径概率密度为：

$$\rho_R(\zeta_{0:t_f}) = \pi_{t_f}(\zeta_{t_f}) \prod_{t=1}^{t_f} R_t(\zeta_{t-1}|\zeta_t). \tag{750}$$

对于每条前向轨迹 $\zeta_{0:t_f} = (\zeta_0, \zeta_1, \ldots, \zeta_{t_f})$，我们可以通过两个操作构造其共轭反向轨迹：(1) 反转状态的时间顺序，(2) 反转所有动量. 这给出 $\tilde{\zeta}_{0:t_f} = (\hat{\zeta}_{t_f}, \hat{\zeta}_{t_f-1}, \ldots, \hat{\zeta}_0)$. 这条共轭轨迹代表轨迹层面的精确时间反演——它是如果我们将前向轨迹在时间上倒推并反转动量时观察到的特定路径. 这与从 π_{t_f} 采样的新初始条件运行反向协议生成的典型轨迹不同.

反向协议的功泛函 $\tilde{\mathcal{W}}$（按定义施加于共轭路径 $\tilde{\zeta}_{0:t_f}$）产生前向功的负值（见第 10 章）：

$$\tilde{\mathcal{W}}(\tilde{\zeta}_{0:t_f}) = -\mathcal{W}(\zeta_{0:t_f}). \tag{751}$$

此功关系对特定的共轭轨迹成立. 然而，在实践中我们从前向和反向协议生成独立轨迹. 这些采样不同的分布：前向轨迹遵循 $\rho(\zeta_{0:t_f})$，具有功分布 $\mathcal{P}(\mathcal{W})$；反向轨迹遵循 $\rho_R(\zeta_{0:t_f})$，具有功分布 $\mathcal{P}_R(\tilde{\mathcal{W}})$. 这些分布不是简单的镜像.

在下文中，我们假设已收集 S_F 个前向功值 $\{\mathcal{W}_i\}_{i=1}^{S_F}$ 和 S_R 个反向功值 $\{\tilde{\mathcal{W}}_j\}_{j=1}^{S_R}$.

如第 17 章所强调，Crooks 涨落定理将这些分布联系起来：

$$\frac{\mathcal{P}(\mathcal{W})}{\mathcal{P}_R(-\mathcal{W})} = e^{\beta(\mathcal{W}-\Delta F)} \quad \Rightarrow \quad \frac{\mathcal{P}(\mathcal{W})}{\mathcal{P}_R(\tilde{\mathcal{W}})} = e^{\beta(\mathcal{W}-\Delta F)}. \tag{752}$$

这提供了两种简单的估计 ΔF 的方法. 首先，ΔF 可以从前向和反向功分布交叉处的功值 $\mathcal{W}^*$ 确定：$\mathcal{P}(\mathcal{W}^*) = \mathcal{P}_R(-\mathcal{W}^*)$，得到 $\Delta F = \mathcal{W}^*$（见 图 47(b)）. 其次，将 $\log \frac{\mathcal{P}(\mathcal{W})}{\mathcal{P}_R(-\mathcal{W})}$ 对 $\mathcal{W}$ 作图应得到一条斜率为 β、截距为 $-\beta\Delta F$ 的直线. 在实践中，我们构造前向和反向功分布的直方图或核密度估计，找到交叉点或对对数比拟合直线. 然而，这两种方法在分布重叠很少的区域都存在统计量差的问题，限制了它们的实用性.

18.4.1 Bennett 接受率方法

以前向无偏方式组合前向和反向数据的统计最优方法是 Bennett 接受率（Bennett acceptance ratio）（BAR）方法（Bennett, 1976; Shirts et al., 2003）. 有两种互补的推导：(i) 遵循 Shirts et al.（2003）的最大似然推导，以及 (ii) Bennett（1976）原始的方差最优加权视角. 在本书中我们遵循前者.

为了通过最大似然推导 BAR，我们将问题重新表述为用 logistic 回归求解的二分类问题. 我们引入以下变量：

$$Y = \{F, R\}, \tag{753}$$

$$X = \begin{cases} \mathcal{W} & \text{若} Y = F, \\ -\mathcal{W} & \text{若} Y = R, \end{cases} \tag{754}$$

$$\theta = \Delta F. \tag{755}$$

然后我们可以写出条件分布 $P(Y|X,\theta)$ 的概率分布，并尝试通过调整参数 $\theta = \Delta F$ 在样本 $\{Y_s, X_s\}$（$s = 1 : N$）上最大化它. 换句话说，我们想找到使预测观察到的功值 X 来自前向还是反向模拟链的分类概率最大似然的 ΔF 值.

下一步是识别

$$p(X|Y=F)=\mathcal{P}(\mathcal{W}), \tag{756}$$

$$p(X|Y=R)=\mathcal{P}_R(-\mathcal{W}) \tag{757}$$

这样我们可以使用 Crooks 涨落定理联系这两个量：

$$\frac{p(X|Y=F)}{p(X|Y=R)}=e^{\beta(\mathcal{W}-\Delta F)}. \tag{758}$$

然后我们可以使用 Bayes 法则写出

$$\frac{P(Y=F|X)}{P(Y=R|X)}=\frac{P(Y=F|X)}{1-P(Y=F|X)}, \tag{759}$$

因为 $\sum_Y P(Y|X)=1$. 由 (756) 和 (757) 我们还可以写

$$\frac{P(Y=F|X)}{P(Y=R|X)}=\frac{p(X|Y=F)P(Y=F)}{p(X|Y=R)P(Y=R)}=e^{\beta(\mathcal{W}-\Delta F)+c}, \tag{760}$$

其中 $c=\log\frac{p(F)}{p(R)}$ 是对数先验几率. 因为我们收集 S_F 个前向和 S_R 个反向样本，合理的选择是经验先验 $p(F)=\frac{S_F}{S_F+S_R}$，给出 $c=\log\frac{S_F}{S_R}$.

定义这些概率后，我们可以解出 $P(Y=F|X)$ 为

$$p(Y=F|X)=\sigma(\beta(\mathcal{W}-\Delta F)+c), \tag{761}$$

$$p(Y=R|X)=1-p(Y=F|X)=1-\sigma(\beta(\mathcal{W}-\Delta F)+c)=\sigma(-\beta(\mathcal{W}-\Delta F)-c), \tag{762}$$

其中 $\sigma(x)=\frac{1}{1+e^{-x}}$ 是 sigmoid 函数，我们使用了 $1-\sigma(x)=\sigma(-x)$.

定义这些概率后，我们现在可以写出 logistic 回归分类问题的对数似然：

$$\begin{aligned}\mathcal{L}(\Delta F)&=\sum_{s=1}^{S_F+S_R}\log p(Y_s|X_s,\Delta F)\\&=\sum_{s=1}^{S_F}\log p(Y_s=F|X_s,\Delta F)+\sum_{s=1}^{S_R}\log p(Y_s=R|X_s,\Delta F)\\&=\sum_{s=1}^{S_F}\log\sigma(\beta(\mathcal{W}_s-\Delta F)+c)+\sum_{s=1}^{S_R}\log\sigma(\beta(\tilde{\mathcal{W}}_s+\Delta F)-c).\end{aligned} \tag{763}$$

对 ΔF 取对数似然的导数并设为零（使用 $\frac{d}{dx}\log\sigma(x)=\sigma(-x)$），我们得到以下方程：

$$\sum_{s=1}^{S_F}\sigma(-\beta(\mathcal{W}_s-\Delta F)-c)=\sum_{s=1}^{S_R}\sigma(-\beta(\tilde{\mathcal{W}}_s+\Delta F)-c) \tag{764}$$

$$\Leftrightarrow\quad\sum_{s=1}^{S_F}\frac{1}{1+e^{\beta(\tilde{\mathcal{W}}_s-\Delta F)+c}}=\sum_{s=1}^{S_R}\frac{1}{1+e^{-\beta(\mathcal{W}_s-\Delta F)-c}}, \tag{765}$$

这被称为 BAR 自洽方程，可以数值求解以找到自由能差 ΔF.

BAR 方法是最优的，因为它在所有以前向无偏方式组合前向和反向功值的估计量中，最小化自由能估计的渐近方差.

Chapter 19

伴随自由能估计与涨落定理

在前面的章节中，我们介绍了构建深度层次化生成模型的两类有力工具：归一化流（第 8 章）与变分自编码器（第 7 章）. 两种方法在生成建模、重要性采样与自由能估计方面都被证明行之有效. 然而，它们各有优劣. 归一化流擅长计算精确的对数似然，但这一优势以变换必须可逆为代价，从而限制了设计灵活性. 此外，可逆结构天然具有光滑性，这使得建模多峰分布颇具挑战：细小的 “概率桥” 不可避免地连接了各个模态. 另一方面，VAE 与扩散模型不受此限，能够自然地处理多峰分布，但它们依赖于优化变分自由能或 ELBO 来逼近对数似然. 此外，这些模型使用时间依赖的序贯随机变换，意味着系统仅有有限的时间达到平衡，从热力学角度看可能导致高度耗散的过程与低效的自由能估计.

权衡之下，一个自然的问题浮现出来：我们能否结合确定性方法与随机方法各自的长处？本章通过借鉴物理与机器学习两个领域的进展来探讨这一可能性. 在物理中，Vaikuntanathan 与 Jarzynski（2008, 2011）引入了**伴随自由能估计**方法，它把一列双射变换与随机变换交错排布，引导系统沿配置空间中一条更高效的路径前进. 与此同时，在机器学习中，研究者把随机映射与可逆映射结合起来，为生成建模与重要性采样构建更高效的模型（Wu et al., 2020; Nielsen et al., 2020），这将在第 20 章介绍.

然而，随机热力学与机器学习中的这些方法之间存在一个关键区别. 在随机热力学（ST）中，时间反演过程（其转移核为 R_t）是固定的：系统按照与正向过程相同的物理定律向后演化. 在机器学习中，反向过程通常是变分的，自由能界（或 ELBO）必须经过优化，才能使反向过程尽可能地逼近正向过程的逆. 对于可逆映射，反向过程是确定性的，它就是正向变换的逆.

本章推导伴随自由能估计方法，并将其与**反绝热驱动**联系起来.

19.1 用于自由能估计的伴随模拟

如第 17 章所述，我们的目标是计算两个平衡态之间的自由能差

$$\Delta F = \mathcal{F}[\pi_{t_f}] - \mathcal{F}[\pi_0]. \tag{766}$$

模拟从初始平衡分布出发：$\zeta_0 \sim \pi_0(\cdot)$，最终收敛到末态平衡分布 $\pi_{t_f}(\zeta_{t_f})$. 这两个平衡态由一列满足平稳性条件 (9.10) 的 Markov 转移 $F_t(\zeta_t|\zeta_{t-1})$ 连接：

$$\int d\zeta_{t-1}\, F_t(\zeta_t|\zeta_{t-1})\, \pi_t(\zeta_{t-1}) = \pi_t(\zeta_t), \tag{767}$$

$$\iff \quad F_t(\zeta_t|\zeta_{t-1})\pi_t(\zeta_{t-1}) = R_t(\zeta_{t-1}|\zeta_t)\pi_t(\zeta_t). \tag{768}$$

本章我们假定更强的细致平衡条件，即

$$F_t(\zeta_t|\zeta_{t-1})\pi_t(\zeta_{t-1}) = R_t(\zeta_{t-1}|\zeta_t)\pi_t(\zeta_t), \tag{769}$$

其中 $R_t(\zeta_{t-1}|\zeta_t) = F_t(\hat{\zeta}_{t-1}|\hat{\zeta}_t)$. 我们进一步定义 Boltzmann 分布为

$$\pi_t(\zeta_t) = \frac{\exp[-\beta \mathcal{H}_t(\zeta_t)]}{Z_t}, \tag{770}$$

其中 $\mathcal{H}_t$ 是每个时间步 t 的 Hamiltonian，β 是逆温，Z_t 是配分函数.

伴随轨迹

伴随模拟（Vaikuntanathan and Jarzynski, 2008, 2011）的动机，是克服第 17 章讨论过的传统非平衡功测量在自由能估计中的局限. 当耗散很大时，由于功的方差随耗散指数增长，这些方法常常收敛缓慢. 伴随模拟通过引入一族双射（即一一且映上）映射函数 $\zeta'_t = \zeta'_t(\zeta_t)$ 来引导轨迹沿一条更绝热的路径前进，从而缓解这一问题.

伴随轨迹按如下方式生成：

$$\begin{aligned}
&\zeta_0 \sim \pi_0(\cdot), \\
&\zeta'_0 = \zeta'_0(\zeta_0), \quad \zeta_1 \sim F_1(\cdot|\zeta'_0), \\
&\zeta'_1 = \zeta'_1(\zeta_1), \quad \zeta_2 \sim F_2(\cdot|\zeta'_1), \\
&\quad \vdots \\
&\zeta'_{t_f-1} = \zeta'_{t_f-1}(\zeta_{t_f-1}), \quad \zeta_{t_f} \sim F_{t_f}(\cdot|\zeta'_{t_f-1}).
\end{aligned} \tag{771}$$

这里我们重载了符号 ζ'_t，既表示映射函数 $\zeta'_t(\zeta_t)$，也表示映射后得到的微观态 ζ'_t. 注意该过程在 ζ_{t_f} 上不再施加最后的映射步骤. 图 48 同时展示了正向过程与时间反演过程.

$$\zeta_0 \overset{\zeta'_0(\cdot)}{\dashrightarrow} \zeta'_0 \xrightarrow{F_1} \zeta_1 \overset{\zeta'_1(\cdot)}{\dashrightarrow} \zeta'_1 \xrightarrow{F_2} \cdots \overset{\zeta'_{t_f-1}(\cdot)}{\dashrightarrow} \zeta'_{t_f-1} \xrightarrow{F_{t_f}} \zeta_{t_f}$$

$$\tilde{\zeta}_{t_f} \overset{(\zeta'_{t_f-1})^{-1}}{\dashrightarrow} \tilde{\zeta}'_{t_f-1} \xrightarrow{R_{t_f}} \tilde{\zeta}_{t_f-1} \overset{(\zeta'_{t_f-2})^{-1}}{\dashrightarrow} \tilde{\zeta}'_{t_f-2} \xrightarrow{R_{t_f-1}} \cdots \overset{(\zeta'_0)^{-1}}{\dashrightarrow} \tilde{\zeta}'_0 \xrightarrow{R_1} \tilde{\zeta}_0$$

图 48: 伴随模拟示意：上行是正向过程，下行是时间反演过程. 正向过程（上行）从 ζ_0 出发，经一系列虚线双射映射 $\zeta'_t(\cdot)$（虚线箭头）与实线随机转移 F_t（实线箭头）演化到 ζ_{t_f}. 时间反演过程（下行）从对应正向路径的末态出发，通过转移 R_t 与逆映射 $(\zeta'_t)^{-1}$ 演化. 该方法通过减小每一步中系统状态与瞬时平衡态之间的滞后，提高采样效率.

生成状态序列 $\{\zeta_0, \zeta'_0, \ldots, \zeta'_{t_f-1}, \zeta_{t_f}\}$ 的概率为

$$\rho(\zeta_0, \zeta'_0, \ldots, \zeta_{t_f}) = \pi_0(\zeta_0) \prod_{t=1}^{t_f} F_t(\zeta_t|\zeta'_{t-1})\, \delta\big(\zeta'_t - \zeta'_{t-1}(\zeta_{t-1})\big)\,. \tag{772}$$

由于每个 ζ'_t 由 ζ_t 唯一确定，我们可以积分掉带撇变量，写出生成不带撇状态序列 $\zeta_{0:t_f} = \{\zeta_0, \ldots, \zeta_{t_f}\}$ 的概率：

$$\rho(\zeta_{0:t_f}) = \pi_0(\zeta_0) \prod_{t=1}^{t_f} F_t(\zeta_t|\zeta'_{t-1}(\zeta_{t-1})). \tag{773}$$

功、热与内能的修正

为理解伴随模拟如何改变热力学量，我们从第 10 章中无伴随情形下功、热与内能变化的标准定义出发：

$$\mathcal{W}(\zeta_{0:t_f}) = \sum_{t=1}^{t_f} \delta\mathcal{W}_t = \sum_{t=1}^{t_f} \big[\mathcal{H}_t(\zeta_{t-1}) - \mathcal{H}_{t-1}(\zeta_{t-1})\big], \tag{774}$$

$$\mathcal{Q}(\zeta_{0:t_f}) = \sum_{t=1}^{t_f} \delta\mathcal{Q}_t = \sum_{t=1}^{t_f} \big[\mathcal{H}_t(\zeta_t) - \mathcal{H}_t(\zeta_{t-1})\big], \tag{775}$$

$$\Delta\mathcal{U}(\zeta_{0:t_f}) = \mathcal{W}(\zeta_{0:t_f}) + \mathcal{Q}(\zeta_{0:t_f}) = \mathcal{H}_{t_f}(\zeta_{t_f}) - \mathcal{H}_0(\zeta_0), \tag{776}$$

Jarzynski 等式与 Crooks 涨落定理对此成立.

在伴随情形下，我们希望推导这些定理的修正版本，使之适用于更精确的自由能估计与重要性采样. Vaikuntanathan 与 Jarzynski（2008, 2011）处理了这一挑战，引入了修正的功定义，并证明了修正的 Jarzynski 等式与 Crooks 涨落定理成立. 另一条思路是从标准功定义出发，考虑随机映射的确定性极限. 类似的思路曾帮助我们理解：当随机映射变得越来越确定时，归一化流如何可以看作 VAE 的极限，如第 8 章所述：

$$F'_t(\zeta'_t|\zeta_t) = \mathcal{G}\big(\zeta'_t \,\big|\, \zeta'_t(\zeta_t), \sigma^2\mathbf{I}\big)\,, \tag{777}$$

$$\lim_{\sigma\to 0^+} F'_t(\zeta'_t|\zeta_t) = \delta(\zeta'_t - \zeta'_t(\zeta_t))\,, \tag{778}$$

其中 $\mathcal{G}(\zeta'_t|\zeta'_t(\zeta_t), \sigma^2\mathbf{I})$ 表示随机变量 ζ'_t 的 Gauss 分布，其中心为 $\zeta'_t(\zeta_t)$，协方差为 $\sigma\mathbf{I}$.

一个自然的问题是：我们能否从标准定义出发、取随机映射的确定性极限，从而推导出伴随情形下的修正功与涨落定理?

让我们用伴随序列表示标准的功与热：

$$\mathcal{W}'_{t+1} = [\mathcal{H}'_t(\zeta'_t) - \mathcal{H}_t(\zeta_t)] + [\mathcal{H}_{t+1}(\zeta'_t) - \mathcal{H}'_t(\zeta'_t)], \tag{779}$$

$$\mathcal{Q}'_{t+1} = [\mathcal{H}'_t(\zeta'_t) - \mathcal{H}'_t(\zeta_t)] + [\mathcal{H}_{t+1}(\zeta_{t+1}) - \mathcal{H}_{t+1}(\zeta'_t)]. \tag{780}$$

由于 Hamiltonian 可以用平衡分布与配分函数表示，我们显式比较前向核与反向核 (19.3)：

$$\frac{R'_t(\zeta_t|\zeta'_t)}{F'_t(\zeta'_t|\zeta_t)} = \frac{\pi'_t(\zeta_t)}{\pi'_t(\zeta'_t)} = \exp\big[-\beta\big(\mathcal{H}'_t(\zeta_t) - \mathcal{H}'_t(\zeta'_t)\big)\big]\,. \tag{781}$$

利用平稳性条件 (19.4)，取确定性极限 (19.10)、(19.11)，可以算出这些比值：

$$\begin{aligned}\frac{\pi'_t(\zeta_t)}{\pi'_t(\zeta_t)} &= \frac{\pi'_t(\zeta_t)}{\int d\zeta'_t\, F'_t(\zeta'_t|\zeta_t)\,\pi'_t(\zeta_t)} \\ &= \frac{\pi'_t(\zeta_t)}{\int d\zeta'_t\, \delta(\zeta'_t-\zeta'_t(\zeta_t))\,\pi'_t(\zeta_t)} \\ &= \frac{\pi'_t(\zeta_t)}{\int d\zeta'_t\, \left|\det\left(\frac{\partial\zeta'_t(\zeta_t)}{\partial\zeta_t}\right)\right|^{-1}\delta(\zeta'_t-\zeta'_t(\zeta_t))\,\pi'_t(\zeta_t)} \\ &= \frac{\left|\det\left(\frac{\partial\zeta'_t(\zeta_t)}{\partial\zeta_t}\right)\right|\pi'_t(\zeta_t)}{\pi'_t(\zeta_t)} \\ &= \left|\det\left(\frac{\partial\zeta'_t(\zeta_t)}{\partial\zeta_t}\right)\right|, \end{aligned} \tag{782}$$

这正是概率密度在随机变量的确定性可逆（双射）变换下的变换法则. 对上式取对数，我们得到对随机功的贡献：

$$\mathcal{H}'_t(\zeta'_t)-\mathcal{H}'_t(\zeta_t) = T\log\frac{R'_t(\zeta_t|\zeta'_t)}{F'_t(\zeta'_t|\zeta_t)} = T\log\left|\det\left(\frac{\partial\zeta'_t}{\partial\zeta_t}\right)\right|. \tag{783}$$

最终，我们得到与 Vaikuntanathan 与 Jarzynski（2011）相同的修正功定义：

$$\mathcal{W}'(\zeta_{0:t_f}) = \sum_{t=1}^{t_f}\delta\mathcal{W}'_t \equiv \sum_{t=1}^{t_f}\left[\mathcal{H}_t(\zeta'_{t-1})-\mathcal{H}_{t-1}(\zeta_{t-1})-T\log\left|\det\left(\frac{\partial\zeta'_{t-1}}{\partial\zeta_{t-1}}\right)\right|\right] \tag{784}$$

$$\equiv \Delta\mathcal{U}(\zeta_{0:t_f})-\mathcal{Q}'(\zeta_{0:t_f}), \tag{785}$$

其中

$$\Delta\mathcal{U}(\zeta_{0:t_f}) \equiv \mathcal{H}_{t_f}(\zeta_{t_f})-\mathcal{H}_0(\zeta_0), \tag{786}$$

$$\begin{aligned}\mathcal{Q}'(\zeta_{0:t_f}) &= \sum_{t=1}^{t_f}\left[\mathcal{H}_t(\zeta_t)-\mathcal{H}_t(\zeta'_{t-1})\right]+T\sum_{t=1}^{t_f}\log\left|\det\left(\frac{\partial\zeta'_{t-1}}{\partial\zeta_{t-1}}\right)\right| \\ &\equiv \mathcal{Q}(\zeta_{0:t_f})+T\sum_{t=1}^{t_f}\log\left|\det\left(\frac{\partial\zeta'_{t-1}}{\partial\zeta_{t-1}}\right)\right|. \end{aligned} \tag{787}$$

这里 $\Delta\mathcal{U}$ 是总能量变化，$\mathcal{Q}'$ 是随机更新过程中与热库交换的热量，并附带一个 Jacobi 行列式项，用于计入映射引起的体积变化（注意：与 Vaikuntanathan and Jarzynski (2011) 相比，我们选择把这些 Jacobi 项吸收到热的定义中）. 同时注意，$\mathcal{Q}$ 的定义相对 (19.8) 中的原始定义已略有修改.

利用细致平衡条件 (19.3) 与 Boltzmann 分布定义 (19.4)，我们可以建立两个关键关系. 第一，随机步骤的前向与反向转移概率之比，与交换的热量相关：

$$\prod_{t=1}^{t_f}\frac{F_t(\zeta_t|\zeta'_{t-1})}{R_t(\zeta'_{t-1}|\zeta_t)} = \prod_{t=1}^{t_f}\frac{\pi_t(\zeta_t)}{\pi_t(\zeta'_{t-1})} = e^{-\beta\mathcal{Q}(\zeta_{0:t_f})}. \tag{788}$$

第二，初态与末态平衡分布之比，与内能变化及自由能相关：

$$\frac{\pi_0(\zeta_0)}{\pi_{t_f}(\zeta_{t_f})} = \frac{Z_{t_f}}{Z_0} e^{-\beta(\mathcal{H}_0(\zeta_0)-\mathcal{H}_{t_f}(\zeta_{t_f}))} = e^{\beta(\Delta\mathcal{U}(\zeta_{0:t_f})-\Delta F)}. \tag{789}$$

由此立即推出：在修正功定义下，Jarzynski 等式与 Crooks 涨落定理对伴随情形成立. 对于 Crooks 涨落定理

$$\frac{\mathcal{P}(\mathcal{W}')}{\mathcal{P}_R(-\mathcal{W}')} = e^{\beta[\mathcal{W}'-\Delta F]}, \tag{790}$$

我们还需要进一步明确时间反演过程.

让我们计算伴随情形下的前向–反向路径概率比（它也应给出总熵产生），并取确定性极限：

$$\begin{aligned}
&\lim_{\sigma\to 0^+} \frac{\rho(\zeta_0, \zeta_0', \ldots, \zeta_{t_f})}{\rho_R(\zeta_0, \zeta_0', \ldots, \zeta_{t_f})} \\
&= \lim_{\sigma\to 0^+} \frac{\pi_0(\zeta_0)\prod_{t=1}^{t_f} F_t(\zeta_t|\zeta_{t-1}')F_{t-1}'(\zeta_{t-1}'|\zeta_{t-1})}{\pi_{t_f}(\zeta_{t_f})\prod_{t=1}^{t_f} R_t(\zeta_{t-1}'|\zeta_t)R_{t-1}'(\zeta_{t-1}|\zeta_{t-1}')} \\
&= \frac{\pi_0(\zeta_0)}{\pi_{t_f}(\zeta_{t_f})} \prod_{t=1}^{t_f} \frac{F_t(\zeta_t|\zeta_{t-1}')}{R_t(\zeta_{t-1}'|\zeta_t)} \cdot \lim_{\sigma\to 0^+} \prod_{t=0}^{t_f-1} \frac{F_t'(\zeta_t'|\zeta_t)}{R_t'(\zeta_t|\zeta_t')} \\
&= \frac{\pi_0(\zeta_0)}{\pi_{t_f}(\zeta_{t_f})} \prod_{t=1}^{t_f} \frac{F_t(\zeta_t|\zeta_{t-1}')}{R_t(\zeta_{t-1}'|\zeta_t)} \left|\det \frac{\partial \zeta_{0:t_f-1}'}{\partial \zeta_{0:t_f-1}}\right|^{-1} \\
&= \exp\big[\beta\big(\Delta\mathcal{U}(\zeta_{0:t_f}) - \Delta F - \mathcal{Q}'(\zeta_{0:t_f})\big)\big] \\
&= \exp\big[\beta\big(\mathcal{W}'(\zeta_{0:t_f}) - \Delta F\big)\big]\,.
\end{aligned} \tag{791}$$

我们得到了 (17.28) 中轨迹概率比在伴随模拟情形下的推广. 注意，这一伴随 Crooks 涨落定理的连续时间版本最近由 Zhong et al.（2024）与 Vargas et al.（2024）研究.

然后，我们就可以利用第 18.3 节中学到的所有技巧，把推广的 Crooks 涨落定理应用回自由能估计问题.

19.2 伴随 Jarzynski 等式

我们通过在伴随轨迹系综上计算指数负功 $\exp(-\beta\mathcal{W}'(\zeta_{0:t_f}))$ 的平均，来验证伴随情形下的 Jarzynski 等式. 我们从其定义出发，递归地积分掉变量 $\zeta_0, \zeta_1, \ldots, \zeta_{t_f-1}$ 来证明该等式：

$$\mathbb{E}_\rho\Big[e^{-\beta\mathcal{W}'(\zeta_{0:t_f})}\Big] = \int d\zeta_{0:t_f}\, e^{-\beta\mathcal{W}'(\zeta_{0:t_f})}\rho(\zeta_{0:t_f}) \tag{792}$$

$$= \frac{1}{Z_0}\int d\zeta_0\cdots d\zeta_{t_f}\, e^{-\beta\mathcal{H}_0(\zeta_0)}\left(\prod_{t=1}^{t_f} F_t(\zeta_t|\zeta_{t-1}')\right) e^{-\beta\sum_{t=1}^{t_f}\delta\mathcal{W}_t'}. \tag{793}$$

为计算该式，我们从 ζ_0 开始逐步向前积分. 先对 ζ_0 积分：

$$\begin{aligned}
&\int d\zeta_0\, e^{-\beta\mathcal{H}_0(\zeta_0)} F_1(\zeta_1|\zeta_0') e^{-\beta\delta\mathcal{W}_1'} \\
&= \int d\zeta_0\, e^{-\beta\mathcal{H}_0(\zeta_0)} F_1(\zeta_1|\zeta_0') e^{-\beta[\mathcal{H}_1(\zeta_0')-\mathcal{H}_0(\zeta_0)-T\log|\det(\partial\zeta_0'/\partial\zeta_0)|]} \\
&= \int d\zeta_0\, F_1(\zeta_1|\zeta_0') e^{-\beta\mathcal{H}_1(\zeta_0')} \left|\det\left(\frac{\partial\zeta_0'}{\partial\zeta_0}\right)\right| \\
&= \int d\zeta_0'\, F_1(\zeta_1|\zeta_0') e^{-\beta\mathcal{H}_1(\zeta_0')} \quad (\text{变量替换：}\ \zeta_0' = \zeta_0'(\zeta_0))\ .
\end{aligned} \tag{794}$$

利用平稳性条件 (19.4)，其中 $\pi_1(\zeta_0') = e^{-\beta\mathcal{H}_1(\zeta_0')}/Z_1$，该积分变为：

$$\int d\zeta_0'\, F_1(\zeta_1|\zeta_0') Z_1 \pi_1(\zeta_0') = Z_1 \int d\zeta_0'\, F_1(\zeta_1|\zeta_0')\pi_1(\zeta_0') = Z_1\pi_1(\zeta_1) = e^{-\beta\mathcal{H}_1(\zeta_1)}. \tag{795}$$

积分掉 ζ_0 后，原式简化为：

$$\mathbb{E}_\rho[e^{-\beta\mathcal{W}'}] = \frac{1}{Z_0}\int d\zeta_1\cdots d\zeta_{t_f}\, e^{-\beta\mathcal{H}_1(\zeta_1)} \left(\prod_{t=2}^{t_f} F_t(\zeta_t|\zeta_{t-1}')\right) e^{-\beta\sum_{t=2}^{t_f}\delta\mathcal{W}_t'}. \tag{796}$$

对 $\zeta_1, \zeta_2, \ldots, \zeta_{t_f-2}$ 重复这一过程. 在每一步 k，对 ζ_{k-1} 的积分都得到 $e^{-\beta\mathcal{H}_k(\zeta_k)}$. 积分到 ζ_{t_f-2} 后，剩下：

$$\mathbb{E}_\rho[e^{-\beta\mathcal{W}'}] = \frac{1}{Z_0}\int d\zeta_{t_f-1} d\zeta_{t_f}\, e^{-\beta\mathcal{H}_{t_f-1}(\zeta_{t_f-1})} F_{t_f}(\zeta_{t_f}|\zeta_{t_f-1}') e^{-\beta\delta\mathcal{W}_{t_f}'}. \tag{797}$$

接着对 ζ_{t_f-1} 积分：

$$\begin{aligned}
&\int d\zeta_{t_f-1}\, e^{-\beta\mathcal{H}_{t_f-1}(\zeta_{t_f-1})} F_{t_f}(\zeta_{t_f}|\zeta_{t_f-1}') e^{-\beta\delta\mathcal{W}_{t_f}'} \\
&= \int d\zeta_{t_f-1}\, F_{t_f}(\zeta_{t_f}|\zeta_{t_f-1}') e^{-\beta\mathcal{H}_{t_f}(\zeta_{t_f-1}')} \left|\det\left(\frac{\partial\zeta_{t_f-1}'}{\partial\zeta_{t_f-1}}\right)\right| \\
&= \int d\zeta_{t_f-1}'\, F_{t_f}(\zeta_{t_f}|\zeta_{t_f-1}') e^{-\beta\mathcal{H}_{t_f}(\zeta_{t_f-1}')}.
\end{aligned} \tag{798}$$

代回原式，并利用最后一步的平稳性条件：

$$\begin{aligned}
\mathbb{E}_\rho[e^{-\beta\mathcal{W}'}] &= \frac{1}{Z_0}\int d\zeta_{t_f} \left[\int d\zeta_{t_f-1}'\, F_{t_f}(\zeta_{t_f}|\zeta_{t_f-1}') e^{-\beta\mathcal{H}_{t_f}(\zeta_{t_f-1}')}\right] \\
&= \frac{1}{Z_0}\int d\zeta_{t_f} \left[Z_{t_f}\int d\zeta_{t_f-1}'\, F_{t_f}(\zeta_{t_f}|\zeta_{t_f-1}')\pi_{t_f}(\zeta_{t_f-1}')\right] \\
&= \frac{Z_{t_f}}{Z_0}\int d\zeta_{t_f}\, \pi_{t_f}(\zeta_{t_f}) = \frac{Z_{t_f}}{Z_0} = e^{-\beta\Delta F}.
\end{aligned} \tag{799}$$

因此，我们得到伴随版本的 Jarzynski 等式：

$$\mathbb{E}_\rho\left[e^{-\beta\mathcal{W}'(\zeta_{0:t_f})}\right] = e^{-\beta\Delta F}. \tag{800}$$

该恒等式对任意双射映射函数族 $\{\zeta_t'(\zeta_t)\}$ 都成立. 当每个 $\zeta_t'(\zeta_t)$ 都是恒等映射时，我们回到 (17.61) 中的原始 Jarzynski 等式.

19.3 反绝热驱动

利用 (19.33) 估计 ΔF 的效率，关键取决于映射函数族 $\{\zeta'_t(\zeta_t)\}$ 的选择. 提升收敛速度的关键，在于减小每一步中系统状态与瞬时 Hamiltonian 平衡态之间的滞后. 这里的 “滞后” 指的是系统当前分布 $\rho_t(\zeta_t)$ 与瞬时 Hamiltonian 的平衡分布 $\pi_t(\zeta_t)$ 之间的差距.

如果我们能找到完美映射 $\{\zeta'^{*}_{t-1}(\zeta_{t-1})\}$ 彻底消除滞后，它们就会把上一步的平衡分布变换到下一步的平衡分布：

$$\pi_t(\zeta'_{t-1}) = \frac{\pi_{t-1}(\zeta_{t-1})}{\left|\det\!\left(\frac{\partial \zeta'^{*}_{t-1}(\zeta_{t-1})}{\partial \zeta_{t-1}}\right)\right|}, \tag{801}$$

其中分母用于变量替换. 对这样一个完美映射，相应的功增量 $\delta\mathcal{W}'_t$ 变成确定的：

$$\begin{aligned}
\delta\mathcal{W}'_t &= \mathcal{H}_t(\zeta'_{t-1}) - \mathcal{H}_{t-1}(\zeta_{t-1}) - T\log\left|\det\!\left(\frac{\partial \zeta'^{*}_{t-1}(\zeta_{t-1})}{\partial \zeta_{t-1}}\right)\right| \\
&= -T\log\big(Z_t \pi_t(\zeta'_{t-1})\big) + T\log(Z_{t-1}\pi_{t-1}(\zeta_{t-1})) - T\log\left|\det\!\left(\frac{\partial \zeta'^{*}_{t-1}(\zeta_{t-1})}{\partial \zeta_{t-1}}\right)\right| \\
&= -T\log\frac{Z_t}{Z_{t-1}} - T\log\left(\frac{\pi_t(\zeta'_{t-1})}{\pi_{t-1}(\zeta_{t-1})}\left|\det\!\left(\frac{\partial \zeta'^{*}_{t-1}(\zeta_{t-1})}{\partial \zeta_{t-1}}\right)\right|\right) \\
&= \mathcal{F}[\pi_t] - \mathcal{F}[\pi_{t-1}],
\end{aligned} \tag{802}$$

最后一步使用了 (19.34). 对所有步求和，任意轨迹上的总修正功都恰好等于自由能差：

$$\mathcal{W}'(\zeta_{0:t_f}) = \sum_{t=1}^{t_f}\big(\mathcal{F}[\pi_t] - \mathcal{F}[\pi_{t-1}]\big) = \mathcal{F}[\pi_{t_f}] - \mathcal{F}[\pi_0] = \Delta F. \tag{803}$$

这意味着：有了完美映射，每条轨迹都给出精确的自由能差，与初始微观态或具体路径无关. 于是我们得到 ΔF 的零方差估计. 直观上，完美映射引导系统沿一条每一步都保持平衡的路径前进，消除了耗散，使所做的功恰好等于自由能差.

这类完美映射在文献中也称为**反绝热驱动**或**绝热捷径**（Li et al., 2017）. 我们将在第 22 章用 Fokker–Planck 方程解释其连续时间版本.

虽然完美映射在复杂系统中通常不现实，但能大幅减小滞后的映射仍可显著改善收敛. 为寻找更好的映射，我们可以把它建模为一个学习问题：最小化目标平衡分布 π_t 与 “由上一步平衡分布 π_{t-1} 经映射推前得到的分布” 之间的 KL 散度：

$$\min_{\zeta'_{t-1}} \mathrm{KL}\big[\pi_t \,\|\, (\zeta'_{t-1})_{\#}\pi_{t-1}\big], \tag{804}$$

其中 $(\zeta'_{t-1})_{\#}\pi_{t-1}$ 是 π_{t-1} 经映射 ζ'_{t-1} 推前得到的分布. 这等价于训练一个归一化流，把 π_{t-1} 的样本变换为 π_t 的样本. 平衡分布 $\pi_t(\zeta)$ 的样本可以通过反复应用相应的 Markov 核 F_t 生成. 这与 Arbel et al.（2021）的思路相关.

Chapter 20

混合随机流与满射流

我们已经见过只有一层随机映射、但可以在输入与输出之间灵活改变维度数的 VAE. 我们用 ELBO 界来训练它们. 我们也研究过归一化流中的确定性变换，那里有数据模型概率的精确表达式，但难以在层间改变维度，且映射必须可逆. 本章把二者组合进同一个架构，称为**随机归一化流**（Wu et al., 2020）或**满射 VAE**（SurVAE; Nielsen et al., 2020）. 我们为这一更一般的模型族提供统一框架，并讨论若干有代表性的例子：张量切片与增广、舍入与排序. 我们着重强调这些思想在现代 ML 与随机热力学中的美妙汇合，因为上一章的伴随自由能估计方法，正是本章所描述的 “可逆与不可逆过程交替” 的一个实例.

20.1 随机归一化流

归一化流（第 8 章）从一个基分布出发，通过一列双射变换构建. 层次化 VAE（或扩散模型，第 13 章）也可以写成对基分布施加一列随机变换. 在第 8.1 节，我们提到归一化流所用的变量替换公式可以与 Bayes 法则相对应：

$$p_{X|Z}(\mathbf{x}|\mathbf{z}) = p_Z(\mathbf{z})\,|\det J|\,, \tag{805}$$

$$\implies \quad p_X(\mathbf{x}) = p_Z(\mathbf{z}(\mathbf{x}))\,|\det J|\,, \tag{806}$$

若我们使用随机变换 $p_{X|Z}(\mathbf{x}|\mathbf{z}) = \mathcal{G}(\mathbf{x}|\mathbf{x}(\mathbf{z}), \sigma^2\mathbf{I})$，并取确定性极限 $\sigma \to 0^+$.

在第 19.2 节，我们看到如何通过结合随机与确定性变换、并附加 Jacobi 行列式修正，来改善自由能估计. 这些观察自然引出一个问题：我们能否系统地把 VAE 与 NF 组合进同一个框架，同时学习随机与确定性变换？这正是随机流模型背后的思想（Wu et al., 2020; Nielsen et al., 2020）.

混合层的一般框架

考虑一个一般框架：模型中每一层由一个前向变换（输入 $\mathbf{z}$、输出 $\mathbf{x}$）与一个反向变换（输入 $\mathbf{x}$、输出 $\mathbf{z}$）定义. 两者都可以是随机的或确定性的. 我们把随机前向变换记作 $p_{X|Z}(\mathbf{x}|\mathbf{z})$；确定性前向变换可以写成 $p_{X|Z}(\mathbf{x}|\mathbf{z}) = \delta(\mathbf{x} - \mathbf{x}(\mathbf{z}))$，或简记为 $\mathbf{x} = \mathbf{x}(\mathbf{z})$，其中 $\mathbf{x}$ 既可指随机变量也可指函数. 确定性逆变换简记为 $\mathbf{z} = \mathbf{z}(\mathbf{x})$. 真正的随机逆变换应由 Bayes 法则给出：

$$p_{Z|X}(\mathbf{z}|\mathbf{x}) = \frac{p_{X|Z}(\mathbf{x}|\mathbf{z})p_Z(\mathbf{z})}{p_X(\mathbf{x})}, \tag{807}$$

但它通常难以处理. 取而代之，我们使用一个可学习的变分逼近 $q_{Z|X}(\mathbf{z}|\mathbf{x})$，这与随机热力学中使用的逆变换不同.

有了这个变分逼近，我们就可以推导似然的界. 对确定性层与随机层，都可以写出 ELBO（证据下界）或自由能界. 我们把对数似然分解为三项：基分布贡献、似然贡献 $\mathcal{V}(\mathbf{x},\mathbf{z})$ 与变分间隙 $\mathcal{E}(\mathbf{x},\mathbf{z})$：

$$\begin{aligned}\log p_X(\mathbf{x}) &= \mathbb{E}_{q_{Z|X}}[\log p_Z(\mathbf{z})] + \mathbb{E}_{q_{Z|X}}\left[\log \frac{p_{X|Z}(\mathbf{x}|\mathbf{z})}{q_{Z|X}(\mathbf{z}|\mathbf{x})}\right] \\ &\quad + D_{\mathrm{KL}}\big[q_{Z|X}(\mathbf{z}|\mathbf{x}) \,\|\, p_{Z|X}(\mathbf{z}|\mathbf{x})\big] \qquad (808)\\ &\simeq \log p_Z(\mathbf{z}) + \mathcal{V}(\mathbf{x},\mathbf{z}) + \mathcal{E}(\mathbf{x},\mathbf{z}), \quad \mathbf{z}\sim q_{Z|X}(\mathbf{z}|\mathbf{x}), \qquad (809)\end{aligned}$$

这是从 $q_{Z|X}(\mathbf{z}|\mathbf{x})$ 中抽取单个 Monte Carlo 样本后的结果；$\simeq$ 表示对期望的单样本 Monte Carlo 估计. $\mathcal{V}$ 与 $\mathcal{E}$ 的具体形式取决于该层是双射还是随机映射，下面详述. 稍后在第 20.3 节，我们把该框架推广到满射层.

对双射变换，似然评估是精确的（$\mathcal{E}=0$）；对随机映射，界有有限间隙：

$$\text{双射：}\quad \mathcal{V}(\mathbf{x},\mathbf{z}) = \log\left|\det\left(\frac{\partial \mathbf{z}(\mathbf{x})}{\partial \mathbf{x}}\right)\right|, \quad \mathcal{E}(\mathbf{x},\mathbf{z})=0; \tag{810}$$

$$\text{随机映射：}\quad \mathcal{V}(\mathbf{x},\mathbf{z}) = \log\frac{p_{X|Z}(\mathbf{x}|\mathbf{z})}{q_{Z|X}(\mathbf{z}|\mathbf{x})}, \quad \mathcal{E}(\mathbf{x},\mathbf{z}) = \log\frac{q_{Z|X}(\mathbf{z}|\mathbf{x})}{p_{Z|X}(\mathbf{z}|\mathbf{x})}. \tag{811}$$

混合层的堆叠

现在我们把这些确定性层与随机层堆叠起来，构成深度模型 $\{\mathbf{z}_{t_f}, \mathbf{z}_{t_f-1}, \dots, \mathbf{z}_1, \mathbf{x}\}$，其负对数似然被下式界住：

$$-\log p_X(\mathbf{x}) \le \mathcal{F}[\mathbf{x}] = -\log p_Z(\mathbf{z}_{t_f}) - \sum_{t=1}^{t_f} \mathcal{V}_t(\mathbf{z}_{t-1},\mathbf{z}_t), \tag{812}$$

其中

$$\text{双射：}\quad \mathcal{V}_t = \log\left|\det\left(\frac{\partial \mathbf{z}_t(\mathbf{z}_{t-1})}{\partial \mathbf{z}_{t-1}}\right)\right|; \tag{813}$$

$$\text{随机映射：}\quad \mathcal{V}_t = \log\frac{p_{t-1|t}(\mathbf{z}_{t-1}|\mathbf{z}_t)}{q_{t|t-1}(\mathbf{z}_t|\mathbf{z}_{t-1})}, \tag{814}$$

而 $p_Z(\mathbf{z}_{t_f})$ 是基分布.

与第 13 章类似，若要把模型用于生成，我们可以用反向（生成）模型 $p_{t-1|t}$ 从基分布 $\mathbf{z}_{t_f}$ 出发生成样本. 为得到更好的生成模型，我们优化 ELBO 或自由能界 (20.7).

在重要性采样中的应用

除生成建模外，这些混合流还能改进重要性采样方案，结合确定性与随机变换的长处. 考虑连接易处理分布 π_0 与目标分布 $\pi_{t_f} = p_{\text{target}}$ 的中间分布

$$\pi_t(\mathbf{z}_t) = \gamma_t(\mathbf{z}_t)/Z_t = \pi_0(\mathbf{z}_t)^{1-\beta_t}\gamma(\mathbf{z})^{\beta_t}. \tag{815}$$

注意现在是 $\mathbf{z}_0$ 从较简单的分布中采样，而不是 $\mathbf{z}_{t_f}$，这与变分扩散模型的约定不同. 重要性权重为

$$w(\mathbf{z}_{0:t_f}) = Z_p \frac{P(\mathbf{z}_{0:t_f})}{Q(\mathbf{z}_{0:t_f})} = \frac{\gamma(\mathbf{z}_{t_f})}{\pi_0(\mathbf{z}_0)} \prod_{t=1}^{t_f} \exp(\mathcal{V}_t). \tag{816}$$

于是期望可用下式估计：

$$\mathbb{E}_{\mathbf{z}_{t_f} \sim \pi_{t_f}}[f(\mathbf{z}_{t_f})] \approx \frac{\sum_{s=1}^{S} w(\mathbf{z}_0^s, \ldots, \mathbf{z}_{t_f}^s) f(\mathbf{z}_{t_f}^s)}{\sum_{s=1}^{S} w(\mathbf{z}_0^s, \ldots, \mathbf{z}_{t_f}^s)}, \tag{817}$$

其中路径从正向路径分布 $Q(\mathbf{z}_{0:t_f})$ 中采样. 为减小估计量的方差——例如估计配分函数时的方差 $\mathbb{V}[w(\mathbf{z}_{0:t_f})]$——我们再次优化同一个 ELBO.

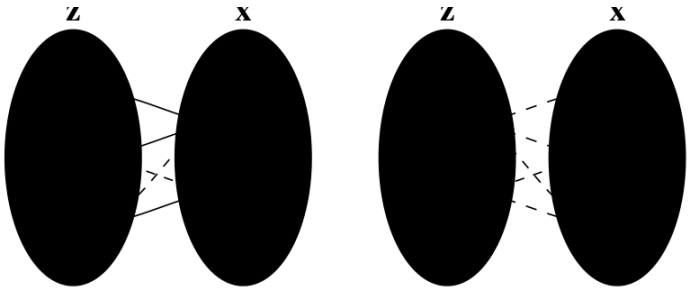
该估计量的精度取决于 Q 对 P 的逼近程度. 如第 12 章所见，估计量的方差最终由末态分布滞后于平衡分布的程度决定. 若能学习到双射变换以减小这一滞后，估计量方差便可下降. 当确定性变换是完美的时候，估计量方差变为零.

若对随机变换使用退火重要性采样，并采用确定性与随机变换相互交错的结构——很像伴随模拟的设定——那么重要性采样恒等式就退化为伴随 Jarzynski 等式 (19.33). 更一般地，对前向 Q 的其他选择，我们使用积分涨落定理的伴随推广作为重要性采样恒等式，类似于第 17 章与第 19.2 节.

20.2 满射流

虽然双射层与随机层提供了很大的灵活性，但生成建模中某些自然的操作本质上是满射（多对一）的. 例如降维、量化、强制置换不变性，都涉及多个输入映射到同一输出的变换. 满射流把我们的框架扩展到这些操作，同时保持似然界的可处理性. SurVAE 流（Nielsen et al., 2020）的关键创新，在于证明这些满射变换可以与双射变换、随机变换完全复合，从而支持更丰富的模型架构.

核心思想是引入这样一类满射变换：在一个方向上是确定性的，在反方向上是随机的. 图 49 展示了生成方向 (a) 与推断方向 (b) 下的满射映射，实线箭头表示确定性方向，虚线箭头表示随机方向.



(a) Surjective (Gen.) (b) Surjective (Inf.)

ve transformations in hybrid models. (a) Surjective (G

图 49: 混合模型中的满射变换. (a) 满射（生成方向）：多对一映射，多个 $\mathbf{z}$ 映射到同一个 $\mathbf{x}$. 实线箭头表示确定性前向方向；虚线箭头表示可能的随机反向路径. (b) 满射（推断方向）：一对多映射，是 (a) 的逆，一个 $\mathbf{x}$ 可以随机映射到多个 $\mathbf{z}$. 输入空间 $\mathbf{z}$ 用阴影背景表示，输出空间 $\mathbf{x}$ 留白.

设 $\mathcal{X}$ 与 $\mathcal{Z}$ 为两个空间. 一个满射 $f : \mathcal{Z} \to \mathcal{X}$ 满足：对所有 $\mathbf{x} \in \mathcal{X}$，存在 $\mathbf{z} \in \mathcal{Z}$ 使 $\mathbf{x} = f(\mathbf{z})$. 满射不一定可逆，但存在右逆 $g : \mathcal{X} \to \mathcal{Z}$，使对所有 $\mathbf{x} \in \mathcal{X}$ 有 $f \circ g(\mathbf{x}) = \mathbf{x}$.

我们区分生成满射（满射 $\mathcal{Z} \to \mathcal{X}$）与推断满射（满射 $\mathcal{X} \to \mathcal{Z}$）. 对生成满射 $f : \mathcal{Z} \to \mathcal{X}$，我们定义：

$$\text{前向（确定性）：} \quad p(\mathbf{x}|\mathbf{z}) = \delta(\mathbf{x} - f(\mathbf{z})); \tag{818}$$

$$\text{逆向（随机）：} \quad q(\mathbf{z}|\mathbf{x})，\text{支集在} \mathcal{B}(\mathbf{x}) = \{\mathbf{z} \,|\, \mathbf{x} = f(\mathbf{z})\} \text{ 上.} \tag{819}$$

这里 $\delta(\cdot)$ 是 Dirac δ 函数，$\mathcal{B}(\mathbf{x})$ 是 $\mathbf{x}$ 的原像——即在 f 下映射到 $\mathbf{x}$ 的所有 $\mathbf{z}$ 的集合. 对推断满射 $g : \mathcal{X} \to \mathcal{Z}$，我们有：

$$\text{前向（随机）：} \quad p(\mathbf{x}|\mathbf{z})，\text{支集在} \mathcal{B}(\mathbf{z}) = \{\mathbf{x} \,|\, \mathbf{z} = g(\mathbf{x})\} \text{ 上;} \tag{820}$$

$$\text{逆向（确定性）：} \quad q(\mathbf{z}|\mathbf{x}) = \delta(\mathbf{z} - g(\mathbf{x})). \tag{821}$$

连续满射的似然贡献项为

$$\mathcal{V}(\mathbf{x}, \mathbf{z}) = \mathbb{E}_{q(\mathbf{z}|\mathbf{x})}\left[\log \frac{p(\mathbf{x}|\mathbf{z})}{q(\mathbf{z}|\mathbf{x})}\right], \tag{822}$$

其中

$$\begin{cases} p(\mathbf{x}|\mathbf{z}) \to \delta(\mathbf{x} - f(\mathbf{z})), & \text{对生成满射,} \\ q(\mathbf{z}|\mathbf{x}) \to \delta(\mathbf{z} - g(\mathbf{x})), & \text{对推断满射,} \end{cases} \tag{823}$$

稍后我们会看到，在满射变换情形下，δ 函数的对数若取恰当极限便可以被良定义.

对推断满射，ELBO 界是紧的：$\mathcal{E}(\mathbf{x}, \mathbf{z}) = 0$. 这是因为

$$p(\mathbf{z}|\mathbf{x}) \propto p(\mathbf{x}|\mathbf{z})p(\mathbf{z}) = \delta(\mathbf{x} \in \mathcal{B}(\mathbf{z}))p(\mathbf{x}|\mathbf{z})p(\mathbf{z}), \tag{824}$$

而对任一特定 $\mathbf{x}$，只有唯一的 $\mathbf{z}$ 与之相容，这意味着（归一化后）$p(\mathbf{z}|\mathbf{x}) = \delta(\mathbf{z} - g(\mathbf{x})) = q(\mathbf{z}|\mathbf{x})$. 对生成满射，界不紧，即 $\mathbb{E}_q[\mathcal{E}] > 0$.

一个完全可复合的 SurVAE 流由一列变换构成，包括双射、满射与随机变换. 双射器在多峰数据或具有拓扑障碍的分布上常常吃力. 满射变换可用于连续数据（Nielsen et al., 2020）与离散数据，甚至多峰数据（Hoogeboom et al., 2021）的生成建模，也可用于从复杂离散分布采样（Jaini et al., 2021）.

下面举几个例子说明 SurVAE 流的应用.

张量切片与增广

最简单的满射之一是通过丢弃（切片）或添加（增广）变量来改变空间维度. 这两种操作互为逆运算，构成许多高级生成模型的基础.

考虑一个生成方向的张量切片满射 f：输入 $\mathbf{z} = (\mathbf{z}_a, \mathbf{z}_b) \in \mathbb{R}^{d_z}$，返回其分量的一个子集 $\mathbf{x} = f(\mathbf{z}) = \mathbf{z}_a$. 我们定义随机前向与逆向变换为：

$$\text{前向（确定性）：} \quad p(\mathbf{x}|\mathbf{z}) = \lim_{\sigma \to 0^+} \mathcal{G}(\mathbf{x}|\mathbf{z}_a, \sigma^2 \mathbf{I}); \tag{825}$$

$$\text{逆向（随机）：} \quad q(\mathbf{z}|\mathbf{x}) = \lim_{\sigma \to 0^+} \mathcal{G}(\mathbf{z}_a|\mathbf{x}, \sigma^2 \mathbf{I})\, q(\mathbf{z}_b|\mathbf{x}). \tag{826}$$

似然贡献项推导如下：

$$\begin{aligned}
\mathcal{V}(\mathbf{x}, \mathbf{z}) &= \lim_{\sigma \to 0^+} \mathbb{E}_{q(\mathbf{z}|\mathbf{x})} \left[\log \frac{p(\mathbf{x}|\mathbf{z})}{q(\mathbf{z}|\mathbf{x})} \right] \\
&= \lim_{\sigma \to 0^+} \mathbb{E}_{q(\mathbf{z}|\mathbf{x})} \left[\log \frac{\mathcal{G}(\mathbf{x}|\mathbf{z}_a, \sigma^2 \mathbf{I})}{\mathcal{G}(\mathbf{z}_a|\mathbf{x}, \sigma^2 \mathbf{I})\, q(\mathbf{z}_b|\mathbf{x})} \right] \\
&= \lim_{\sigma \to 0^+} \mathbb{E}_{q(\mathbf{z}|\mathbf{x})} \left[\log \frac{\mathcal{G}(\mathbf{x}|\mathbf{z}_a, \sigma^2 \mathbf{I})}{\mathcal{G}(\mathbf{z}_a|\mathbf{x}, \sigma^2 \mathbf{I})} - \log q(\mathbf{z}_b|\mathbf{x}) \right] \\
&= \mathbb{E}_{q(\mathbf{z}_b|\mathbf{x})}[-\log q(\mathbf{z}_b|\mathbf{x})].
\end{aligned} \tag{827}$$

最后一步中，当 $\sigma \to 0^+$ 时 Gauss 分布变成 δ 函数，其比值趋于 1，只剩下含 $q(\mathbf{z}_b|\mathbf{x})$ 的项. 这一变换通过丢弃 $\mathbf{z}_b$ 分量显然损失了信息.

张量切片的逆操作是增广，这是一个通过附加随机变量来提升维度的推断满射. 考虑映射 $g : \mathcal{X} \to \mathcal{Z}$，其中 $\mathbf{x} \in \mathbb{R}^d$ 是原始数据，$\mathbf{z} = g(\mathbf{x}) = (\mathbf{x}, \mathbf{u}) \in \mathbb{R}^{d+k}$ 是增广后的数据，$\mathbf{u} \in \mathbb{R}^k$ 是附加的随机变量. 随机前向与确定性逆向变换为：

$$\text{前向（随机）：} \quad p(\mathbf{z}|\mathbf{x}) = p(\mathbf{u}|\mathbf{x})\, \delta(\mathbf{z}_{1:d} - \mathbf{x}); \tag{828}$$

$$\text{逆向（确定性）：} \quad q(\mathbf{x}|\mathbf{z}) = \delta(\mathbf{x} - \mathbf{z}_{1:d}), \tag{829}$$

其中 $\mathbf{z}_{1:d}$ 表示 $\mathbf{z}$ 的前 d 个分量. 似然贡献项与张量切片类似，为 $\mathcal{V}(\mathbf{x}, \mathbf{z}) = \mathbb{E}_{p(\mathbf{u}|\mathbf{x})}[\log p(\mathbf{u}|\mathbf{x})]$. 由于这是一个推断满射，ELBO 界是紧的（$\mathcal{E}(\mathbf{x}, \mathbf{z}) = 0$），因为真实后验 $p(\mathbf{x}|\mathbf{z})$ 等于变分逼近 $q(\mathbf{x}|\mathbf{z}) = \delta(\mathbf{x} - \mathbf{z}_{1:d})$.

增广与张量切片合起来在 SurVAE 流中对提升模型表达力特别有用. 例如在多尺度架构中，增广可以在不同尺度引入额外隐变量，使模型能捕捉数据的层次结构. 通过增广隐空间，模型可以学习更复杂的依赖关系，表示更宽范围的分布. 增广归一化流

(Huang et al., 2020) 与 VFlow (J. Chen et al., 2020) 正是这样做的：它们的前向变换先用额外维度增广数据空间，再接一个双射变换；这等价于一个双射复合一个丢弃增广维度的生成切片满射.

热力学解释. 从热力学角度看，张量切片操作可以解释为一个粗粒化过程：关于 $\mathbf{z}_b$ 的信息被丢弃. 这与 Kawai et al. (2007) 和 Gomez-Marin et al. (2008) 讨论的粗粒化类似. 在随机热力学中（第 10 章），记 ρ 为前向路径概率，ρ_R 为时间反演路径概率. 它们之间的 KL 散度与平均总熵产生 $\mathbb{E}[\Sigma]$ 相关：

$$D_{\mathrm{KL}}[\rho\|\rho_R] = \mathbb{E}[\Sigma]. \tag{830}$$

在张量切片情境下，我们可以把这一概念同时用于完整系统与粗粒化（切片）系统：

$$\begin{aligned}\mathbb{E}[\Sigma^{\mathrm{full}}] &= D_{\mathrm{KL}}[\rho_{Z_a,Z_b}\|\rho_{RZ_a,Z_b}] \\ &= D_{\mathrm{KL}}[\rho_{Z_a}\|\rho_{RZ_a}] + \mathbb{E}_{\rho_{Z_a}}[D_{\mathrm{KL}}[\rho_{Z_b|Z_a}\|\rho_{RZ_b|Z_a}]] \\ &\geq D_{\mathrm{KL}}[\rho_{Z_a}\|\rho_{RZ_a}] = \mathbb{E}[\Sigma^{\mathrm{observed}}].\end{aligned} \tag{831}$$

这里 ρ_{Z_a,Z_b} 与 ρ_{RZ_a,Z_b} 分别是完整系统在前向与时间反演过程中的联合分布；ρ_{Z_a} 与 ρ_{RZ_a} 是观测（切片）变量的边缘分布.

该不等式基于我们在粗粒化系统中观测到的量，给出了完整系统耗散的一个下界. 差值 $\mathbb{E}[\Sigma^{\mathrm{full}}] - \mathbb{E}[\Sigma^{\mathrm{observed}}]$ 表示因丢弃信息而 "隐藏起来" 的熵产生. 物理上，这意味着粗粒化（张量切片）会让观测到的系统耗散或熵产生看似减小. 但这种减小是由于我们观测（切片）有限所致，并非系统熵真正下降.

在物理系统中，时间反演路径是按相同物理定律做时间反演得到的. 在 SurVAE 流中，随机逆向 $q(\mathbf{z}|\mathbf{x})$ 未必这样定义. 虽然很想把 SurVAE 流中界松弛项 $\mathcal{E}(\mathbf{x},\mathbf{z}) = \log\frac{q(\mathbf{z}|\mathbf{x})}{p(\mathbf{z}|\mathbf{x})}$ 解释为隐藏的额外功，但由于两种语境下反向过程定义方式不同，这一解释并不严格准确.

舍入

除连续维度变化外，满射还自然地建模由有限分辨率引起的离散化操作. 舍入满射把输入向量的每个元素舍入到最近整数. 设 f 是一个舍入满射，输入 $\mathbf{z} \in \mathbb{R}^{d_z}$，返回舍入后的 $\mathbf{x} := \lfloor \mathbf{z} \rceil$，其中 $\lfloor\cdot\rceil$ 表示逐元素 floor 函数. 我们定义：

$$\text{前向（确定性）：}\quad p(\mathbf{x}|\mathbf{z}) = \mathbb{1}(\mathbf{z} \in \mathcal{B}(\mathbf{x})),\quad \mathcal{B}(\mathbf{x}) = \{\mathbf{x} + \mathbf{u} \,|\, \mathbf{u} \in [0,1)^d\}; \tag{832}$$

$$\text{逆向（随机）：}\quad q(\mathbf{z}|\mathbf{x}) = r(\mathbf{z}|\mathbf{x})\mathbb{1}(\mathbf{z} \in \mathcal{B}(\mathbf{x})). \tag{833}$$

这里 $\mathbb{1}(\cdot)$ 是指示函数，$\mathcal{B}(\mathbf{x})$ 表示舍入到 $\mathbf{x}$ 的所有可能 $\mathbf{z}$ 构成的单位立方体. 在物理中，这类操作源自测量设备精度有限，例如相机中的像素化.

舍入操作的似然贡献项推导如下：

$$\begin{aligned}\mathcal{V}(\mathbf{x},\mathbf{z}) &= \mathbb{E}_{q(\mathbf{z}|\mathbf{x})}\left[\log\frac{p(\mathbf{x}|\mathbf{z})}{q(\mathbf{z}|\mathbf{x})}\right] \\ &= \mathbb{E}_{q(\mathbf{z}|\mathbf{x})}\left[\log\frac{\mathbb{1}(\mathbf{z} \in \mathcal{B}(\mathbf{x}))}{r(\mathbf{z}|\mathbf{x})\mathbb{1}(\mathbf{z} \in \mathcal{B}(\mathbf{x}))}\right] \\ &= \mathbb{E}_{q(\mathbf{z}|\mathbf{x})}[-\log r(\mathbf{z}|\mathbf{x})].\end{aligned} \tag{834}$$

对从 $q(\mathbf{z}|\mathbf{x})$ 采样的 $\mathbf{z}$，指示函数 $\mathbb{1}(\mathbf{z} \in \mathcal{B}(\mathbf{x}))$ 恒为 1，因此在最终表达式中消失. 结果表明，似然贡献就是逆向分布 $q(\mathbf{z}|\mathbf{x})$ 的微分熵.

均匀去量化（Uria et al., 2014）与变分去量化（Ho et al., 2019）都可以看作舍入满射的逆操作（见图 50）. 均匀去量化对应一个生成方向的舍入满射，其随机逆向 $q(\mathbf{z}|\mathbf{x})$ 为均匀分布；变分去量化则为 $q(\mathbf{z}|\mathbf{x})$ 使用更灵活的基于流的分布. 数学上可写为：

$$f(\mathbf{z}) = \lfloor \mathbf{z} \rfloor \quad \text{（舍入）}, \tag{835}$$

$$g(\mathbf{x}) = \mathbf{x} + \mathbf{u}, \quad \mathbf{u} \sim q(\mathbf{u}|\mathbf{x}) \quad \text{（去量化）}. \tag{836}$$

这些技术通过引入一个连续隐变量并将其舍入得到离散观测，从而能用连续分布建模离散数据. 去量化分布 $q(\mathbf{u}|\mathbf{x})$ 的选择决定了模型的表达力：分布越灵活，对真实离散分布的逼近越好.

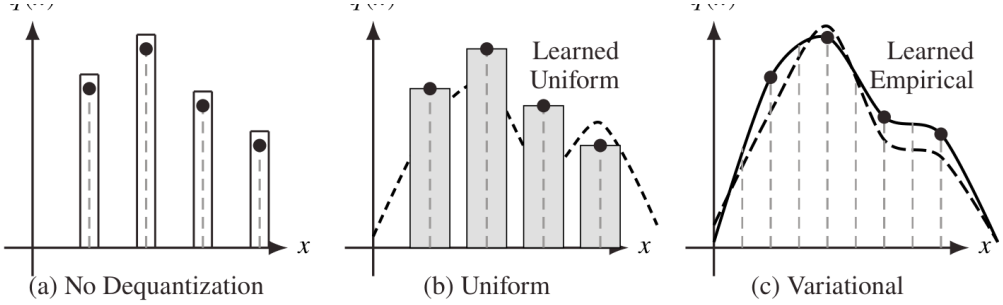


Figure 20.2 Comparison of dequantization methods. (a) Without dequantization the data

图 50: 去量化方法比较. (a) 不去量化时数据仍是尖峰测度，难以做连续拟合. (b) 均匀去量化给每个样本垫上对称噪声带，得到一个光滑的替代密度. (c) 变分去量化学习一个基于流的 $q(\mathbf{x})$（虚线），它更贴近经验尖峰，同时保持连续.

排序满射

当我们想建模置换不变分布或顺序统计量上的分布时，会遇到更精巧的满射. 排序满射把输入向量的元素按升序排列. 设 $\mathbf{x} \in \mathbb{R}^d$ 为输入向量，$\mathbf{z} = \mathrm{sort}(\mathbf{x})$ 为排序后的输出. 这是一个多对一映射，因为给定向量 $\mathbf{x}$ 的任意置换都得到同一个排序后向量 $\mathbf{z}$. 记 S_d 为 d 个元素的全体置换构成的集合.

我们把这个推断满射表示为：

$$\text{前向（随机）：} \quad p(\mathbf{x}|\mathbf{z}) = \sum_{\pi \in S_d} p(\mathbf{x}|\mathbf{z}, \pi)\, p(\pi|\mathbf{z}) \tag{837}$$

$$= \sum_{\pi \in S_d} \delta(\mathbf{x} - \pi^{-1}(\mathbf{z}))\, p(\pi|\mathbf{z}); \tag{838}$$

$$\text{逆向（确定性）：} \quad q(\mathbf{z}|\mathbf{x}) = \delta(\mathbf{z} - \mathrm{sort}(\mathbf{x})), \tag{839}$$

其中 π^{-1} 是 π 的逆置换，$p(\pi|\mathbf{z})$ 是一个以排序后向量 $\mathbf{z}$ 为条件、定义在置换上的可学习分类分布. 前向过程通过选取一个置换 π、把其逆作用于排序后向量 $\mathbf{z}$，生成未排序向量 $\mathbf{x}$.

排序满射的似然贡献项推导如下：

$$
\begin{aligned}
\mathcal{V}(\mathbf{x}, \mathbf{z}) &= \mathbb{E}_{q(\mathbf{z}|\mathbf{x})}\left[\log \frac{p(\mathbf{x}|\mathbf{z})}{q(\mathbf{z}|\mathbf{x})}\right] \\
&= \mathbb{E}_{q(\mathbf{z}|\mathbf{x})}\left[\log \frac{\sum_{\pi \in S_d} \delta(\mathbf{x} - \pi^{-1}(\mathbf{z}))\, p(\pi|\mathbf{z})}{\delta(\mathbf{z} - \operatorname{sort}(\mathbf{x}))}\right] \\
&= \log \frac{\sum_{\pi \in S_d} \delta(\mathbf{x} - \pi^{-1}(\operatorname{sort}(\mathbf{x})))\, p(\pi|\operatorname{sort}(\mathbf{x}))}{\delta(\operatorname{sort}(\mathbf{x}) - \operatorname{sort}(\mathbf{x}))} \\
&= \log \left[\delta(\mathbf{x} - \operatorname{sort}^{-1}(\operatorname{sort}(\mathbf{x})))\, p(\operatorname{sort}|\operatorname{sort}(\mathbf{x}))\right] \\
&= \log p(\operatorname{sort}|\operatorname{sort}(\mathbf{x})); \qquad (840)
\end{aligned}
$$

对每个 $\mathbf{x}$ 及其对应的 $\mathbf{z}$，只有把 $\mathbf{x}$ 排到 $\mathbf{z}$ 的那个置换 π 对求和有贡献. 这里 sort^{-1} 表示把排序后向量映射回原始顺序的逆置换.

排序满射可用于建模涉及顺序统计量的分布，例如一组随机变量中第 k 小值的分布. 更多文献中提出的满射变换（Nielsen et al., 2020）留给读者自行探索.

Part III

连续时间概率动力学 Continuous-Time Probabilistic Dynamics

Chapter 21

从 Fokker–Planck 方程看随机热力学

本书大部分章节都采用离散表述来描述物理系统的时间演化，时间是一个按单位步长前进的指标 $t = 0, 1, 2, \ldots$. 然而，物理（至少在经典层面）是连续的；因此我们需要引入按无穷小步长前进的物理时间 $\tau = \tau_0, \tau_0 + \Delta\tau, \ldots$，并把对时间的求和换成积分，相应调整其他表达式. 本章我们用 τ 表示物理时间，以保持记号一致.

在含 Brown 运动的随机系统中，对随机路径积分实际上相当微妙，需要 Itô 随机分析. 这一高级话题将留待后续卷册. 尽管如此，本书中的许多结果都可以通过引入 Fokker–Planck 方程而优雅地导出；该方程最早由 Fokker（1914）、Planck（1917）与 Kolmogorov（1931）的开创性工作建立. 我们忍不住要让你尝一尝这一优雅替代框架的味道，它能帮助你理解随机热力学这一丰富领域.

本章回顾第二部分讨论过的许多热力学关系，例如把能量、功、热与（系统和热库的）熵联系起来的热力学第一、第二定律. 我们还会把 Fokker–Planck 方程推导为变分自由能的梯度流，并把它推广到含动量与非保守旋转分量的情形，从而得到 Klein–Kramers 方程. 然后我们再次推导第二定律，最后推导一个相当一般的方程，描述把一个分布变换为另一个分布所需的过剩功.

21.1 连续性方程

本章我们追求一般性，使用相空间变量 $\zeta = (\xi, \eta)$；同时指出，在过阻尼极限下 $\zeta = \xi$，许多结果会大大简化. 下一章我们将聚焦这一过阻尼极限，在配置空间而非完整相空间中工作，从而自然地与机器学习应用衔接.

我们从推导连续性方程开始. 这是一条非常直观、普适而自然的定律：质量不会凭空消失，也不会被瞬间传送. 若我们有一团质量，并让它在某个速度场下流动，所有质量仍都在那里，只是被移动了位置. 换言之，任何地方都不产生新质量，任何地方也不消灭质量. 把这一直觉说得更具体些：考虑空间中任意体积 $\mathcal{V}$. 由质量守恒的定义，$\mathcal{V}$ 内质量的增加量必定等于流入的质量减去流出的质量.

设 ζ 为相空间变量，$\rho(\zeta, \tau)$ 为 ζ 处在时刻 τ 的概率密度. 设 $\mathcal{B}(\mathcal{V})$ 为体积 $\mathcal{V}$ 的边界，$\hat{\mathbf{n}}$ 为指向外侧的单位法向量. 那么面积分 $\oiint_{\mathcal{B}(\mathcal{V})} \rho \mathbf{v} \cdot \hat{\mathbf{n}}\, d\mathcal{B}$ 表示通过表面向外流出的概率流，其中 $\mathbf{v}(\zeta, \tau)$ 是速度场.

应用质量守恒，我们有

$$\iiint_{\mathcal{V}} \partial_\tau \rho(\zeta,\tau)\, dV = -\oiint_{\mathcal{B}(\mathcal{V})} \rho(\zeta,\tau)\mathbf{v}(\zeta,\tau)\cdot\hat{\mathbf{n}}(\zeta)\, dB \tag{841}$$

$$= -\iiint_{\mathcal{V}} \operatorname{div}\big(\rho(\zeta,\tau)\mathbf{v}(\zeta,\tau)\big)\, dV, \tag{842}$$

其中我们用 Gauss 定理把面积分转化为体积分. 注意到该恒等式必须对任意体积 $\mathcal{V}$ 都成立，于是只能是被积函数恒为零：

$$\partial_\tau \rho(\zeta,\tau) + \nabla\cdot\big(\rho(\zeta,\tau)\mathbf{v}(\zeta,\tau)\big) = 0. \tag{843}$$

这就是**连续性方程**，它是一个非常普适的结果. 只要概率质量不能被产生、消灭或瞬间传送（在物理中通常成立），它就对任何沿（可能含时的）向量场 $\mathbf{v}$ 输运的概率密度成立（见图 51）.

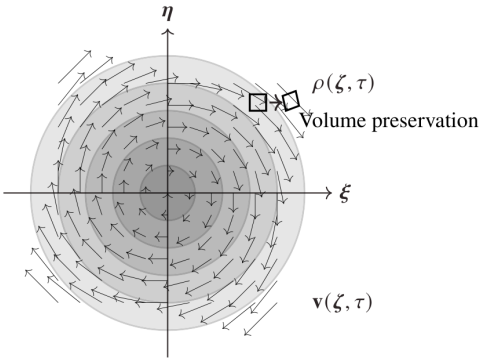


Figure 21.1 Visualization of the continuity equation in phase space. The concentric contours

图 51: 相空间中连续性方程的示意. 同心等高线表示概率密度 $\rho(\zeta,\tau)$，颜色越深表示中心附近密度越高. 箭头表示速度场 $\mathbf{v}(\zeta,\tau)$，箭头强度正比于场强. 右上角小图（正方形变为平行四边形）展示体积元在流作用下的形变，印证 (21.2) 所表达的概率质量守恒.

我们换一种稍许不同的方式推导，并把它与前面章节中的概念联系起来. 设我们从密度 $\rho(\zeta,\tau)$ 出发，在确定性动力学下把它“推前”：

$$\zeta \mapsto \zeta' = \zeta + \dot{\zeta}\, d\tau, \tag{844}$$

$$\dot{\zeta}' = \dot{\zeta} = \zeta + \mathbf{v}(\zeta,\tau) d\tau. \tag{845}$$

这一演化可看作一个坐标变换. 相应地，密度按

$$\rho(\zeta,\tau) = \rho(\zeta',\tau')\det\left(\frac{\partial \zeta'}{\partial \zeta}\right) \tag{846}$$

变换. 展开到 $d\tau$ 的一阶：

$$\rho(\zeta,\tau) \approx \big(\rho(\zeta,\tau) + \partial_\tau\rho(\zeta,\tau)d\tau + \mathbf{v}(\zeta,\tau)\cdot\nabla\rho(\zeta,\tau)d\tau\big)\big(\mathbf{I} + \nabla\cdot\mathbf{v}(\zeta,\tau)d\tau\big) \tag{847}$$

$$\implies \rho(\zeta,\tau)+\partial_\tau\rho(\zeta,\tau)d\tau+\mathbf{v}\cdot\nabla\rho\,d\tau+\rho(\zeta,\tau)\nabla\cdot\mathbf{v}(\zeta,\tau)d\tau\approx\rho(\zeta,\tau) \tag{848}$$

$$\implies \partial_\tau\rho(\zeta,\tau)+\mathbf{v}(\zeta,\tau)\cdot\nabla\rho(\zeta,\tau)+\rho(\zeta,\tau)\nabla\cdot\mathbf{v}(\zeta,\tau)=0 \tag{849}$$

$$\implies \partial_\tau\rho(\zeta,\tau)+\nabla\cdot\big(\rho(\zeta,\tau)\mathbf{v}(\zeta,\tau)\big)=0. \tag{850}$$

可见连续性方程不过是密度变换法则的直接结果.

有了连续性方程，我们可以问：密度 ρ 何时平稳？这与 MCMC 算法中的平稳性条件类似（见第 11 章）. 要达到平稳，需要 ρ 不随时间变化：

$$\partial_\tau\rho(\zeta,\tau)=0 \quad\implies\quad \operatorname{div}\big(\rho(\zeta,\tau)\mathbf{v}(\zeta,\tau)\big)=0. \tag{851}$$

换言之，我们要找一个向量场，使得在任一固定点 ζ 处，密度 $\rho(\zeta,\tau)$ 不随时间变化. 这样的向量场保证流入空间任一区域的概率等于流出该区域的概率，从而该区域内总概率不变——即平稳. 若要更强的细致平衡条件，则要求每个体积的每个面元上流入与流出都相等. 在过阻尼情形 $\zeta=\xi$，细致平衡意味着 $\mathbf{v}$ 处处为零.

这未必是平庸解，因为正如我们将看到的，$\mathbf{v}$ 可以由漂移项与扩散项构成. 特别地，当存在漂移与扩散项时，细致平衡条件退化为

$$\nabla\mathcal{H}(\zeta)=-\beta\nabla\log\rho(\zeta), \tag{852}$$

其中 $\mathcal{H}$ 是 Hamiltonian；这当然等价于说 ρ^{eq} 应是 Boltzmann 分布：

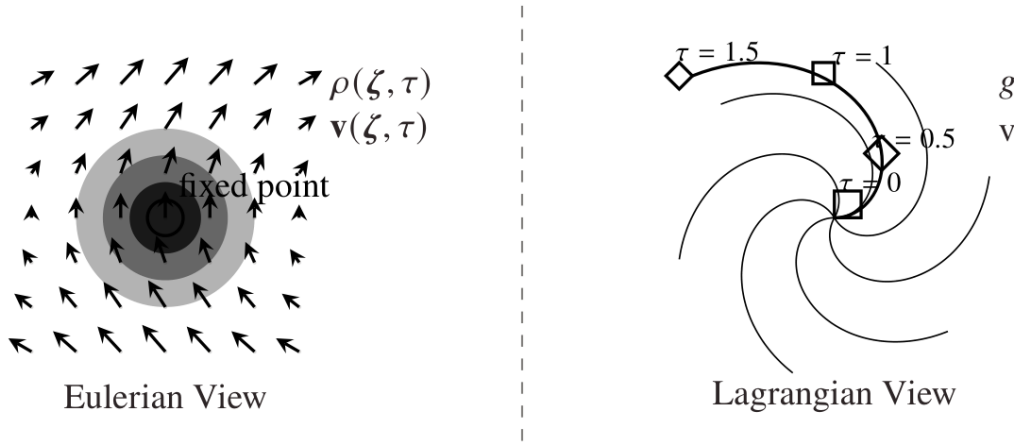
$$\rho^{\mathrm{eq}}(\zeta)=\frac{1}{Z}\exp(-\beta\mathcal{H}(\zeta)). \tag{853}$$

21.2 能量变化与第一定律

前面章节中，我们把热力学系统的内能定义为

$$U[\rho](\tau)=\int d\zeta\,\rho(\zeta,\tau)\mathcal{H}(\zeta,\tau), \tag{854}$$

其中 $\mathcal{H}$ 是系统的 Hamiltonian. 现在计算能量随时间的变化率. 在这些计算中，必须认识到我们采用 Euler 形式：ζ 是一个固定的随机变量，我们对它积分；密度 ρ 与 Hamiltonian $\mathcal{H}$（或任何其他函数）显式地随时间变化. 重要的是，变量 ζ 本身不依赖于时间.



igure 21.2 Comparison of Eulerian and Lagrangian perspectives in phase

图 52: 相空间动力学中 Euler 视角与 Lagrangian 视角的比较. 左：固定点视角，展示密度场 $\rho(\zeta,\tau)$（阴影等高线）与速度场 $\mathbf{v}(\zeta,\tau)$（箭头），并标出一个固定参考点（圆）. 右：随粒子视角，展示体积元（正方形）沿轨迹 $g(\zeta_0,\tau)$（实线）如何形变；时间标签 $\tau = 0, 0.5, 1.5$ 标出路径上的位置；背景流线表示流场.

或者, 我们可以采用 Lagrangian 视角, 类似于第 7 章 VAE 中的重参数化技巧. 在这一视角下, 随机变量 $\zeta_\tau = g(\zeta_0,\tau)$ 成为时间的显式函数, 而测度 $\rho(\zeta_\tau,\tau)d\zeta_\tau = \rho(\zeta_0,0)d\zeta_0$ 保持不变、与时间无关. 图 52 给出了两种视角的示意. 注意这两种视角等价, 可以通过变量替换 $\zeta_0 \leftrightarrow \zeta_\tau$ 互相转换.

能量变化率为

$$\frac{d}{d\tau}U[\rho](\tau) = \partial_\tau U[\rho](\tau) \tag{855}$$

$$= \int d\zeta\, (\partial_\tau \rho(\zeta,\tau))\mathcal{H}(\zeta,\tau) + \int d\zeta\, \rho(\zeta,\tau)\partial_\tau \mathcal{H}(\zeta,\tau) \tag{856}$$

$$= \int d\zeta\, \big(- \operatorname{div}(\rho(\zeta,\tau)\mathbf{v}(\zeta,\tau))\big)\mathcal{H}(\zeta,\tau) + \int d\zeta\, \rho(\zeta,\tau)\partial_\tau \mathcal{H}(\zeta,\tau), \tag{857}$$

最后一行用了连续性方程. 分部积分后继续：

$$\frac{d}{d\tau}U[\rho](\tau) = \int d\zeta\, \rho(\zeta,\tau)\mathbf{v}(\zeta,\tau)\cdot\nabla\mathcal{H}(\zeta,\tau) + \int d\zeta\, \rho(\zeta,\tau)\partial_\tau \mathcal{H}(\zeta,\tau) \tag{858}$$

$$= \int d\zeta\, \rho(\zeta,\tau)\big(\partial_\tau \mathcal{H}(\zeta,\tau) + \mathbf{v}(\zeta,\tau)\cdot\nabla\mathcal{H}(\zeta,\tau)\big) \tag{859}$$

$$= \int d\zeta\, \rho(\zeta,\tau) D_\tau \mathcal{H}(\zeta,\tau), \tag{860}$$

其中我们定义了**物质导数**（随体导数）

$$D_\tau = \partial_\tau + \mathbf{v}(\zeta,\tau)\cdot\nabla. \tag{861}$$

它描述随速度场运动时 $\mathcal{H}$ 如何变化. 这一推导中，我们使用了连续性方程并分部积分，假设密度 ρ 在积分区域边界上为零.

由该式我们可以识别出热与功的变化：

$$\partial_\tau U[\rho](\tau) = \partial_\tau \mathcal{Q}(\tau) + \partial_\tau \mathcal{W}(\tau), \tag{862}$$

$$\partial_\tau \mathcal{W}(\tau) = \int d\zeta\, \rho(\zeta,\tau)\partial_\tau \mathcal{H}(\zeta,\tau), \tag{863}$$

$$\partial_\tau \mathcal{Q}(\tau) = \int d\zeta\, \rho(\zeta,\tau)\mathbf{v}(\zeta,\tau)\cdot\nabla\mathcal{H}(\zeta,\tau). \tag{864}$$

这里 $\partial_\tau \mathcal{W}(\tau)$ 是对系统做功的功率，$\partial_\tau \mathcal{Q}(\tau)$ 是流入系统的热流率. 这就是**热力学第一定律**.

21.3 熵产生与第二定律

现在看连续性方程如何改变系统的熵. 任意时刻 τ 的熵定义为

$$\mathcal{S}[\rho](\tau) = -\int d\zeta\, \rho(\zeta,\tau)\log\rho(\zeta,\tau). \tag{865}$$

于是熵产生率为

$$\frac{d}{d\tau}\mathcal{S}[\rho](\tau) = \partial_\tau \mathcal{S}[\rho](\tau) \tag{866}$$

$$= -\int d\zeta\, (\partial_\tau\rho(\zeta,\tau))\log\rho(\zeta,\tau) - \int d\zeta\, \rho(\zeta,\tau)\partial_\tau \log\rho(\zeta,\tau) \tag{867}$$

$$= \int d\zeta\, \nabla\cdot\big(\rho(\zeta,\tau)\mathbf{v}(\zeta,\tau)\big)\log\rho(\zeta,\tau) - \int d\zeta\, \partial_\tau\rho(\zeta,\tau). \tag{868}$$

第二个等号处我们用连续性方程 (21.2) 替换了 $\partial_\tau\rho$. 分部积分并假设 $\rho(\zeta,\tau)$ 在边界上为零，该式简化为

$$\frac{d}{d\tau}\mathcal{S}[\rho](\tau) = -\int d\zeta\, \rho(\zeta,\tau)\mathbf{v}(\zeta,\tau)\cdot\nabla\log\rho(\zeta,\tau) - \partial_\tau\int d\zeta\, \rho(\zeta,\tau) \tag{869}$$

$$= -\int d\zeta\, \mathbf{v}(\zeta,\tau)\cdot\nabla\rho(\zeta,\tau) - 0 \tag{870}$$

$$= \int d\zeta\, \rho(\zeta,\tau)\mathrm{div}(\mathbf{v}(\zeta,\tau)). \tag{871}$$

最后一行是再次分部积分的结果. 这意味着：若相空间中没有压缩（即 $\mathrm{div}(\mathbf{v}) = 0$），就没有熵产生. 下面会看到，Hamilton 流没有压缩（保体积），因此不产生熵. 我们还从上述推导中观察到：向量场 $\mathbf{v}$ 在负分数函数 $-\nabla\log\rho$ 方向上的分量负责产生熵.

Hamilton 流不可压缩

下面用 Hamilton 方程生成向量场. 对相空间变量 $\zeta = (\xi,\eta)$，Hamilton 方程给出

$$v_\xi(\zeta,\tau) = \nabla_\eta\mathcal{H}(\zeta,\tau), \tag{872}$$

$$v_\eta(\zeta,\tau) = -\nabla_\xi\mathcal{H}(\zeta,\tau). \tag{873}$$

用辛矩阵 $\mathbf{J}$ 可紧凑地写为

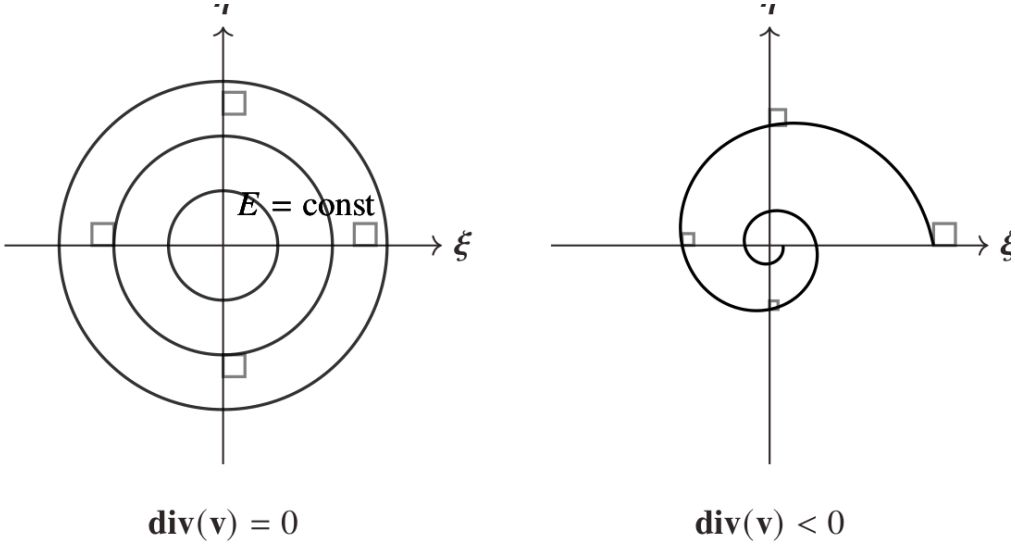
$$\mathbf{v}(\zeta,\tau)=\mathbf{J}\nabla_{\zeta}\mathcal{H}(\zeta,\tau),\quad \mathbf{J}=\begin{pmatrix}0 & \mathbf{I}\\ -\mathbf{I} & 0\end{pmatrix}, \tag{874}$$

其中 $\mathbf{I}$ 是单位矩阵，∇_{ζ} 表示对所有相空间变量 $\zeta=(\xi,\eta)$ 求梯度.

散度为

$$\begin{aligned}\operatorname{div}(\mathbf{v}(\zeta,\tau)) &= \nabla\cdot\mathbf{v}(\zeta,\tau)=\nabla_{\xi}\cdot v_{\xi}(\zeta,\tau)+\nabla_{\eta}\cdot v_{\eta}(\zeta,\tau) &(875)\\ &= \nabla_{\xi}\cdot\nabla_{\eta}\mathcal{H}(\zeta,\tau)-\nabla_{\eta}\cdot\nabla_{\xi}\mathcal{H}(\zeta,\tau)=0, &(876)\end{aligned}$$

因为混合偏导对称. 可见 Hamilton 流不可压缩、不产生熵（见图 53）. 这是一个合理的结果：我们描述的是系统的全部自由度，而非粗粒化后的有效自由度. 这意味着演化过程中，描述系统所需的比特数保持不变（即 $6N$ 个实数），从而观测者关于系统的信息没有损失. 事实上，信息守恒是一条关于物理定律的基本假设，它与 “物理定律时间反演对称” 这一事实紧密相关. 换言之，在任意时刻，我们都拥有足够的信息来精确地把系统轨迹逆向追溯回去. 这只有在时间演化中信息不丢失时才可能.



1.3 Comparison of phase space flows. Left: Hamiltonian flow preserves ph

图 53: 相空间流的比较. 左：Hamilton 流保持相空间体积 $\operatorname{div}(\mathbf{v})=0$，沿同心等能线放置的正方形大小不变. 右：耗散流收缩相空间体积 $\operatorname{div}(\mathbf{v})<0$，沿向内螺旋轨迹的正方形不断缩小.

耗散

现在看一个例子：在 Hamilton 方程上加一个耗散项：

$$\begin{aligned}v_{\xi}(\zeta,\tau) &= \nabla_{\eta}\mathcal{H}(\zeta,\tau), &(877)\\ v_{\eta}(\zeta,\tau) &= -\nabla_{\xi}\mathcal{H}(\zeta,\tau)-\gamma\eta,\quad \gamma>0. &(878)\end{aligned}$$

这里 γ 是阻尼常数，决定耗散强度. 这一形式的方程由 Kramers（1940）在其关于力场中 Brown 运动的开创性工作中深入研究. 此时散度为

$$\begin{aligned}\operatorname{div}(\mathbf{v}(\zeta,\tau)) &= \nabla_\xi \cdot v_\xi(\zeta,\tau) + \nabla_\eta \cdot v_\eta(\zeta,\tau) && (879)\\ &= \nabla_\xi \cdot \nabla_\eta \mathcal{H}(\zeta,\tau) - \nabla_\eta \cdot \nabla_\xi \mathcal{H}(\zeta,\tau) - 3N\gamma && (880)\\ &= -3N\gamma < 0. && (881)\end{aligned}$$

负散度意味着相空间在演化下收缩（见图 53）. 我们按第 21.4 节的方式计算熵产生：

$$\frac{d}{d\tau}\mathcal{S}[\rho](\tau) = \int d\zeta\, \rho(\zeta,\tau)\operatorname{div}(\mathbf{v}(\zeta,\tau)) = -3N\gamma. \tag{882}$$

于是系统的熵减小了！这说得通：我们正把能量从系统中抽走，在没有产生熵的随机碰撞的情况下，所有 N 个粒子最终都会停在动能为零、势能 $\mathcal{V}(\xi)$ 最小的状态. 那是一个一句话就能描述的极简单状态，复杂度很低，即熵很低.

这是否违反了“熵必须总是增加”的热力学第二定律？不，因为摩擦项代表与外部环境（热库）的相互作用：热库吸收能量，从而增加自身熵. 两个系统（系统与环境）合起来的总熵应当增加或不变，与第二定律一致.

21.4 Fokker–Planck 方程作为梯度流

下面推导著名的 Fokker–Planck（FP）方程，也称漂移–扩散方程或 Smoluchowski 方程. 它支配着过阻尼极限下气体与流体的动力学（Risken, 1996）. 我们通过寻找一条能“以最快速度”最小化自由能的速度场来推导它，这种路径称为**梯度流**（Jordan et al., 1998）. 我们还会直接把它与 Benamou 与 Brenier 的一项开创性数学结果联系起来：该结果把 FP 方程与最优传输理论联系起来（Benamou and Brenier, 2000）.

先定义一个泛函 $\mathcal{F} : \rho \to \mathbb{R}$，把密度映射为实数（例如能量或自由能）. 我们最关心的是自由能泛函：

$$\mathcal{F}[\rho] = \int d\zeta\, \rho(\zeta,\tau)\big(\mathcal{H}(\zeta,\tau) + T\log\rho(\zeta,\tau)\big) + \lambda\left(\int d\zeta\, \rho(\zeta,\tau) - 1\right), \tag{883}$$

其中 $\mathcal{H}$ 是 Hamilton 函数，第二项是分布 ρ 的熵（我们取 Boltzmann 常数 $k_B = 1$）. 最后一项是 Lagrange 乘子项，用于强制 ρ 归一化：$\int d\zeta\, \rho(\zeta,\tau) = 1$. 我们强调这只是一种选择；事实上，经典密度泛函理论用远为一般、复杂的项来代替上述熵项（Evans, 1979; Dijkman et al., 2025）.

先对 ρ 取 $\mathcal{F}$ 的泛函导数：

$$\frac{\delta\mathcal{F}}{\delta\rho(\zeta,\tau)} = \mathcal{H}(\zeta,\tau) + T\log\rho(\zeta,\tau) + T + \lambda. \tag{884}$$

令此导数为零并解出 ρ，立即得到时刻 τ 的 Boltzmann 分布：

$$\rho^{\mathrm{eq}}(\zeta,\tau) = \frac{1}{Z}\exp(-\beta\mathcal{H}(\zeta,\tau)). \tag{885}$$

我们强调：虽然这是每个时刻 τ 的平衡分布，但一般而言 $\rho(\zeta,\tau)$ 并不在平衡态，因此不等于 $\rho^{\mathrm{eq}}(\zeta,\tau)$（这正是“非平衡热力学”一名的由来）.

若我们改变密度 $\rho(\zeta,\tau)$，$\mathcal{F}$ 如何变化?

$$\partial_\tau \mathcal{F} = \int d\zeta\, \frac{\delta \mathcal{F}}{\delta \rho(\zeta,\tau)} \partial_\tau \rho(\zeta,\tau) \tag{886}$$

$$= -\int d\zeta\, \frac{\delta \mathcal{F}}{\delta \rho(\zeta,\tau)} \nabla \cdot \big(\rho(\zeta,\tau)\mathbf{v}(\zeta,\tau)\big) \tag{887}$$

$$= \int d\zeta\, \rho(\zeta,\tau) \nabla\left(\frac{\delta \mathcal{F}}{\delta \rho(\zeta,\tau)}\right) \cdot \mathbf{v}(\zeta,\tau). \tag{888}$$

这里分部积分并假设边界项为零. 可见 $\mathcal{F}$ 的变化正比于 $\nabla(\delta\mathcal{F}/\delta\rho)$ 与 $\mathbf{v}$ 的内积. 显然，最快下降自由能的方式是在每个时刻 τ 选择向量场

$$\mathbf{v}(\zeta,\tau) \propto -\nabla\left(\frac{\delta \mathcal{F}}{\delta \rho(\zeta,\tau)}\right). \tag{889}$$

这样选择后，FP 方程为

$$\partial_\tau \rho(\zeta,\tau) = \gamma \nabla \cdot \left(\rho(\zeta,\tau) \nabla\left(\frac{\delta \mathcal{F}}{\delta \rho(\zeta,\tau)}\right)\right), \tag{890}$$

其中比例常数 γ 称为“迁移率”. 可以通过重新标度时间把它吸收掉（即改变迁移率常数等价于加快或减慢时间），因此下面取 $\gamma = 1$.

在这一选择下，$\mathcal{F}$ 的变化也可算出，且恒非正：

$$\partial_\tau \mathcal{F} = -\int d\zeta\, \rho(\zeta,\tau) \left\| \nabla\left(\frac{\delta \mathcal{F}}{\delta \rho(\zeta,\tau)}\right)\right\|^2 \le 0. \tag{891}$$

对 (21.27) 的特例，连续性方程化为

$$\partial_\tau \rho(\zeta,\tau) = \nabla \cdot \big(\rho(\zeta,\tau)(\nabla \mathcal{H}(\zeta,\tau) + T\nabla \log \rho(\zeta,\tau))\big) \tag{892}$$

$$= \nabla \cdot \big(\rho(\zeta,\tau)\nabla \mathcal{H}(\zeta,\tau)\big) + T\nabla^2 \rho(\zeta,\tau). \tag{893}$$

把 FP 方程识别为梯度流，为理解热力学系统中概率分布的演化提供了一个有力框架. 下一节我们将在这一表述下重新审视热力学第二定律.

21.5 广义 Fokker–Planck 方程

上一节把 FP 方程推导为自由能的梯度流，但这并不是保证自由能下降的最一般 FP 方程. 例如，我们可以把速度换成下式，仍保证每一步自由能下降：

$$\mathbf{v}' = \mathbf{M}\mathbf{v} = (\mathbf{D} + \mathbf{A})\mathbf{v}, \quad \mathbf{D}^{\top} = \mathbf{D},\ \mathbf{A}^{\top} = -\mathbf{A}, \tag{894}$$

其中 $\mathbf{M}$ 是任意矩阵，分解为对称（扩散）矩阵 $\mathbf{D}$ 与反对称矩阵 $\mathbf{A}$. 由于任意对称半正定矩阵可写为 $\mathbf{D} = \mathbf{G}^{\top}\mathbf{G}$，且对任意反对称矩阵有 $\operatorname{tr}(\mathbf{S}\mathbf{A}) = 0$（$\mathbf{S}$ 为任意对称矩阵，

tr(·) 为矩阵迹），我们有

$$\partial_\tau \mathcal{F} = \int d\zeta\, \rho(\zeta,\tau) \nabla\!\left(\frac{\delta \mathcal{F}}{\delta \rho(\zeta,\tau)}\right) \cdot \mathbf{v}(\zeta,\tau) \tag{895}$$

$$= -\int d\zeta\, \rho(\zeta,\tau) \nabla^{\top}\!\left(\frac{\delta \mathcal{F}}{\delta \rho(\zeta,\tau)}\right) (\mathbf{D}+\mathbf{A}) \nabla\!\left(\frac{\delta \mathcal{F}}{\delta \rho(\zeta,\tau)}\right) \tag{896}$$

$$= -\int d\zeta\, \rho(\zeta,\tau) \left[\mathbf{G}\nabla\!\left(\frac{\delta \mathcal{F}}{\delta \rho(\zeta,\tau)}\right)\right]^{\top} \left[\mathbf{G}\nabla\!\left(\frac{\delta \mathcal{F}}{\delta \rho(\zeta,\tau)}\right)\right] \le 0. \tag{897}$$

把这一更一般形式的 FP 方程应用于 (21.27) 的自由能，从连续性方程出发得到

$$\partial_\tau \rho(\zeta,\tau) = \nabla \cdot \big(\rho(\zeta,\tau)(\mathbf{D}+\mathbf{A})(\nabla \mathcal{H}(\zeta,\tau) + T\nabla \log \rho(\zeta,\tau))\big) \tag{898}$$

$$= \nabla \cdot \big(\rho(\zeta,\tau)(\mathbf{D}+\mathbf{A})\nabla \mathcal{H}(\zeta,\tau)\big) + T\Delta_{\mathbf{D}} \rho(\zeta,\tau), \tag{899}$$

其中 $\Delta_{\mathbf{D}} = \nabla^{\top}\mathbf{D}\nabla$ 是广义 Laplace 算子.

下面对 $\mathcal{H}$、$\mathbf{D}$、$\mathbf{A}$ 作具体选择：

$$\mathcal{H}(\zeta,\tau) = \frac{\eta^2}{2m} + \mathcal{V}(\xi,\tau), \tag{900}$$

$$\mathbf{A} = \mathbf{J} \equiv \begin{pmatrix} 0 & \mathbf{I} \\ -\mathbf{I} & 0 \end{pmatrix}, \tag{901}$$

$$\mathbf{D} = \begin{pmatrix} 0 & 0 \\ 0 & \gamma \mathbf{I} \end{pmatrix}, \tag{902}$$

代入得到

$$\partial_\tau \rho(\zeta,\tau) = \frac{\gamma}{m} \nabla_\eta \cdot (\rho(\zeta,\tau)\eta) - \frac{\eta}{m} \cdot \nabla_\xi \rho(\zeta,\tau) + \nabla_\eta \cdot (\rho(\zeta,\tau) \nabla_\xi \mathcal{V}(\xi,\tau)) \tag{903}$$

$$+ \gamma T \nabla_\eta^2 \rho(\zeta,\tau). \tag{904}$$

一旦我们作识别

$$T \to k_B T, \tag{905}$$

$$\gamma = m\mu, \tag{906}$$

这就是著名的 **Klein–Kramers 方程**，其中 k_B 是 Boltzmann 常数，μ 是摩擦（阻力）系数.

对 $\mathbf{A}$ 与 $\mathbf{D}$ 的其他选择会导出不同的著名近似. 例如取 $\mathbf{A} = 0$ 与

$$\mathbf{D} = \begin{pmatrix} \gamma \mathbf{I} & 0 \\ 0 & 0 \end{pmatrix}, \tag{907}$$

得到过阻尼 Langevin 方程：

$$\partial_\tau \rho(\zeta,\tau) = \gamma \nabla_\xi \cdot \big(\rho(\zeta,\tau) \nabla_\xi \mathcal{V}(\xi,\tau)\big) + \gamma T \Delta_\xi \rho(\zeta,\tau). \tag{908}$$

注意我们取 $\mathbf{M} = \mathbf{D} + \mathbf{A}$ 为常数（与空间和时间无关）. 当然可以让它们成为空间与时间的函数，但那会在 FP 方程中产生更多项，为可读性起见我们在此略去；更一般的构造见 Ma et al.（2015）.

21.6 对应的随机微分方程

每个 FP 方程都对应一个随机微分方程 (SDE), 可用于通过采样高效地模拟 $\rho(\zeta,\tau)$. 上节所讨论 FP 方程对应的最一般 SDE 为（不加证明）:

$$d\zeta(\tau) = -\mathbf{M}\nabla\mathcal{H}(\zeta,\tau)\,d\tau + d\epsilon(\tau), \tag{909}$$

$$d\epsilon(\tau) \sim \mathcal{N}(0, 2\beta^{-1}\mathbf{D}\,d\tau), \tag{910}$$

其中 $d\epsilon$ 从协方差为 $\Xi = 2\beta^{-1}\mathbf{D}\,d\tau$ 的正态分布中采样.

对 Langevin 情形，它退化为

$$d\xi(\tau) = \frac{\eta}{m}d\tau, \tag{911}$$

$$d\eta(\tau) = -(\nabla_\xi\mathcal{V}(\xi,\tau) + \mu\eta)d\tau + \sqrt{2\gamma T}\,d\bar{\omega}(\tau), \quad d\bar{\omega}(\tau) \sim \mathcal{N}(0, d\tau). \tag{912}$$

这里两式中的第一项都是 Hamilton 运动方程; 动量方程还多出摩擦项与噪声项. Hamilton 方程对应更新中的反对称部分，守恒能量; 摩擦项与噪声项改变能量，但彼此平衡: 摩擦项把能量从系统传给热库，噪声项把能量从热库传入系统.

最后，对 Brown 运动有更简单的 SDE:

$$d\xi(\tau) = -\gamma\nabla_\xi\mathcal{V}(\xi,\tau)d\tau + \sqrt{2\gamma T}\,d\bar{\omega}(\tau). \tag{913}$$

这些 SDE 已被用于 MCMC 采样. 为此需选择 $\beta\mathcal{V}(\xi) = -\log p_{\text{target}}(\xi)$（相差一个常数），并可引入辅助动量变量以改善混合效率.

21.7 第二定律（再说一次）

在速度场取 (21.31) 的选择下，我们重新审视热产生率 (21.15) 与熵产生率 (21.18):

$$\partial_\tau\mathcal{Q}(\tau) = \int d\zeta\,\rho(\zeta,\tau)\mathbf{v}(\zeta,\tau)\cdot\nabla\mathcal{H}(\zeta,\tau), \tag{914}$$

$$\partial_\tau\mathcal{S}(\tau) = -\int d\zeta\,\rho(\zeta,\tau)\mathbf{v}(\zeta,\tau)\cdot\nabla\log\rho(\zeta,\tau), \tag{915}$$

$$\implies \partial_\tau\mathcal{Q}(\tau) - T\partial_\tau\mathcal{S}(\tau) = \int d\zeta\,\rho(\zeta,\tau)\mathbf{v}(\zeta,\tau)\cdot(\nabla\mathcal{H}(\zeta,\tau) + T\nabla\log\rho(\zeta,\tau)) \tag{916}$$

$$= -\int d\zeta\,\rho(\zeta,\tau)\|\nabla\mathcal{H}(\zeta,\tau) + T\nabla\log\rho(\zeta,\tau)\|_{\mathbf{D}}^2 \le 0, \tag{917}$$

其中 $\|\mathbf{v}\|_{\mathbf{D}}^2 \equiv \mathbf{v}^\top\mathbf{D}\mathbf{v}$. 若假设热库恒温且处于平衡态，则 $T\partial_\tau\mathcal{S}_{\text{bath}}(\tau) = -\partial_\tau\mathcal{Q}(\tau)$，于是

$$T\partial_\tau\Sigma(\tau) = T\partial_\tau\mathcal{S}(\tau) + T\partial_\tau\mathcal{S}_{\text{bath}}(\tau) = T\partial_\tau\mathcal{S}(\tau) - \partial_\tau\mathcal{Q}(\tau) \ge 0, \tag{918}$$

其中 $\Sigma(\tau)$ 是到时刻 τ 系统与环境的总熵产生. 我们再次得到第二定律.

我们可以把熵产生与当前密度和平衡密度之间 KL 散度的变化联系起来. 回顾: 漂移与扩散不随时间变化的 Fokker–Planck 方程为

$$\partial_\tau\rho(\zeta,\tau) = -\nabla\cdot\big(\rho(\zeta,\tau)\mathbf{v}(\zeta,\tau)\big), \tag{919}$$

$$\mathbf{v}(\zeta,\tau) = -\mathbf{M}\nabla\big[\mathcal{H}(\zeta) + T\log\rho(\zeta,\tau)\big]. \tag{920}$$

平衡分布 $\rho^{\mathrm{eq}}(\zeta)$ 满足 $\nabla[\mathcal{H}(\zeta)+T\log\rho^{\mathrm{eq}}(\zeta)]=0$，即正则分布：

$$\rho^{\mathrm{eq}}(\zeta)=\frac{\exp[-\beta\mathcal{H}(\zeta)]}{Z},\quad Z=\int d\zeta'\exp[-\beta\mathcal{H}(\zeta')]. \tag{921}$$

我们可以用 $\rho(\zeta,\tau)$ 与 $\rho^{\mathrm{eq}}(\zeta)$ 之间 KL 散度的时间导数来表示熵产生率 $\sigma(\tau)=\partial_\tau\Sigma(\tau)$：

$$\partial_\tau D_{\mathrm{KL}}[\rho(\tau)\|\rho^{\mathrm{eq}}]=\int d\zeta\,(\partial_\tau\rho(\zeta,\tau))\log\frac{\rho(\zeta,\tau)}{\rho^{\mathrm{eq}}(\zeta)}-\partial_\tau\int d\zeta\,\rho^{\mathrm{eq}}(\zeta) \tag{922}$$

$$=-\int d\zeta\,\nabla\cdot\big(\rho(\zeta,\tau)\mathbf{v}(\zeta,\tau)\big)\log\frac{\rho(\zeta,\tau)}{\rho^{\mathrm{eq}}(\zeta)} \tag{923}$$

$$=\int d\zeta\,\rho(\zeta,\tau)\mathbf{v}(\zeta,\tau)\cdot\nabla\log\frac{\rho(\zeta,\tau)}{\rho^{\mathrm{eq}}(\zeta)}. \tag{924}$$

利用

$$\log\frac{\rho(\zeta,\tau)}{\rho^{\mathrm{eq}}(\zeta)}=\log\rho(\zeta,\tau)+\beta\mathcal{H}(\zeta)+\log Z, \tag{925}$$

并注意 $\nabla\log\rho^{\mathrm{eq}}(\zeta)=-\beta\nabla\mathcal{H}(\zeta)$，得到

$$\partial_\tau D_{\mathrm{KL}}[\rho(\tau)\|\rho^{\mathrm{eq}}]=\int d\zeta\,\rho(\zeta,\tau)\mathbf{v}(\zeta,\tau)\cdot(\nabla\log\rho(\zeta,\tau)+\beta\nabla\mathcal{H}(\zeta)) \tag{926}$$

$$=-\beta\int d\zeta\,\rho(\zeta,\tau)\|\nabla\mathcal{H}(\zeta)+T\nabla\log\rho(\zeta,\tau)\|_{\mathbf{D}}^2 \tag{927}$$

$$=-\partial_\tau\Sigma(\tau). \tag{928}$$

因此熵产生率与 KL 散度的下降有关：

$$\sigma(\tau)=-\partial_\tau D_{\mathrm{KL}}[\rho(\tau)\|\rho^{\mathrm{eq}}]\geq 0. \tag{929}$$

这表明 $\rho(\tau)$ 与 ρ^{eq} 之间的 KL 散度随时间减小，与热力学第二定律一致.

21.8 自由能变化与过剩功

综合前面各节的结果，我们推导

$$\partial_\tau\mathcal{F}(\tau)=\partial_\tau\mathcal{U}(\tau)-T\partial_\tau\mathcal{S}(\tau) \tag{930}$$

$$=\partial_\tau\mathcal{W}(\tau)+\partial_\tau\mathcal{Q}(\tau)-T\partial_\tau\mathcal{S}(\tau) \tag{931}$$

$$=\partial_\tau\mathcal{W}(\tau)-T\partial_\tau\Sigma(\tau), \tag{932}$$

其中 $\partial_\tau\mathcal{W}(\tau)$ 是对系统做功的功率，$\partial_\tau\Sigma(\tau)$ 是总熵产生率. 由上式我们识别出耗散功的功率：

$$\partial_\tau\mathcal{W}_{\mathrm{diss}}(\tau)\equiv\partial_\tau\mathcal{W}(\tau)-\partial_\tau\mathcal{F}(\tau)=T\partial_\tau\Sigma(\tau)\geq 0, \tag{933}$$

它等于总熵产生率（乘以 T）.

从 $\tau=0$ 积分到 $\tau=\tau_f$，得到总耗散功：

$$\mathcal{W}_{\rm diss}\equiv\mathcal{W}-\Delta\mathcal{F}=T\Sigma=\int_0^{\tau_f}d\tau\int d\zeta\,\rho(\zeta,\tau)\|\nabla\mathcal{H}(\zeta,\tau)+T\nabla\log\rho(\zeta,\tau)\|_{\mathbf{D}}^2\geq 0,\quad(934)$$

其中 $\mathcal{W}_{\rm diss}$、$\mathcal{W}$ 与 Σ 依赖于路径，而 $\Delta\mathcal{F}=\mathcal{F}_{\tau_f}-\mathcal{F}_0$ 是态函数，与所选路径无关.

我们常常关心：当系统完全弛豫时，$\tau=0$ 到 $\tau=\infty$ 之间耗散功的总量. 这称为**过剩功** $\mathcal{W}_{\rm exc}$. 假设我们可以控制系统直到 $\tau=\tau_f$，之后系统不受外部影响地自行弛豫：

$$\mathcal{H}(\zeta,\tau)=\mathcal{H}_\infty(\zeta)+\mathcal{H}_\lambda(\zeta;\lambda(\tau)),\quad \tau\in[0,\tau_f),\qquad(935)$$

$$\mathcal{H}(\zeta,\tau)=\mathcal{H}_\infty(\zeta),\quad \tau\in[\tau_f,\infty).\qquad(936)$$

这意味着 (21.62) 仍成立，但积分上限改为 ∞，并使用上述 Hamiltonian. 我们也可把它改写为

$$\mathcal{W}_{\rm exc}=\mathcal{W}_{\rm diss}-(F_\infty-F_{\tau_f}),\qquad(937)$$

其中最后一段 $\tau\geq\tau_f$ 中功 $\mathcal{W}=0$，因为 $\partial_\tau\mathcal{H}_\infty(\zeta)=0$. 注意 $\mathcal{F}_\infty=F_\infty=-T\log Z_\infty$. 此外，

$$\beta D_{\rm KL}[\rho_{\tau_f}\|\rho_\infty]=-\beta\mathcal{S}[\rho_{\tau_f}]+\mathbb{E}_{\rho_{\tau_f}}[\mathcal{H}_\infty]+\beta\log Z_\infty=F_{\tau_f}-F_\infty.\qquad(938)$$

综合起来，我们得到如下有用恒等式：

$$\mathcal{W}_{\rm exc}=\int_0^{\tau_f}d\tau\int d\zeta\,\rho(\zeta,\tau)\|\nabla\mathcal{H}(\zeta,\tau)+T\nabla\log\rho(\zeta,\tau)\|_{\mathbf{D}}^2+\beta D_{\rm KL}[\rho_{\tau_f}\|\rho_\infty]\geq 0.\qquad(939)$$

上式对任意受控 Hamiltonian $\mathcal{H}_\lambda$ 都成立. 现在我们可以提出一个重要问题：给定控制时间 τ_f，从分布 ρ_0 出发、希望到达分布 ρ_∞，最优控制序列 $\lambda(\tau)$ 是什么，能最小化总耗散能量（即 $\mathcal{W}_{\rm exc}$）？我们将在下一章“解决”这个问题.

Chapter 22

最优传输与 Schrödinger 桥

本章我们把记号从相空间换到配置空间：$\zeta \to \xi$，从完整 Hamiltonian 换到势能函数：$\mathcal{H} \to \mathcal{V}$. 这对应于在过阻尼（Brown 运动）极限下工作，即第 21 章末尾引入的情形. 这样简化有两个原因：其一，有些结果在完整相空间中尚未知晓或推导困难得多；其二，配置空间表述为与机器学习应用衔接提供了自然桥梁——在 ML 中我们通常处理可观测量上的分布，而非完整相空间轨迹.

本章我们更细致地考察**最优传输**与 **Wasserstein 距离**，以及它们与 “把一个分布变换为另一个分布所需的最小（过剩）功” 的关系. 我们研究**反绝热驱动**——一种最小化传输分布所需功的最优控制形式，最优传输解是其中一个例子. 我们用 Fokker–Planck 方程这套新语言重新审视 Schrödinger 桥、最优控制与扩散模型. 顺便解释用于数值求解 FP 方程的 JKO 格式，并讨论更一般的作用量，用于导出与物理相关的微分方程.

22.1 最优传输与 Wasserstein 距离

Benamou 与 Brenier 在一篇奠基性论文中，把最优传输（OT）问题重新表述为一个 Lagrange 问题，并把它与流体力学联系起来（Benamou and Brenier, 2000）. 我们先给出 Monge 提出的标准 OT 问题（见图 54）.

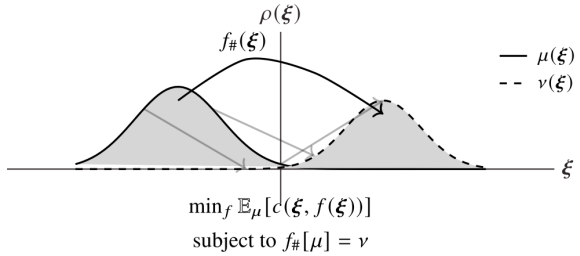


Figure 22.1 Monge formulation of optimal transport showing the transformation of source

图 54: 最优传输的 Monge 表述. 源分布 $\mu(\xi)$（左峰）通过最优传输映射 $f_\#(\xi)$（带箭头的实线，连接两个峰）变换为目标分布 $\nu(\xi)$（右峰）. 淡箭头表示质量从源位置流向目标位置. 推前测度约束 $f_\#[\mu] = \nu$ 保证质量守恒.

假设有一个映射 f 传输概率质量：$\xi' = f(\xi)$. 我们定义移动概率质量的代价为

$$\mathcal{C}[f, \rho_0, \rho_{\tau_f}] = \int d\xi\, \rho_0(\xi) c(\xi, f(\xi)), \quad \text{s.t. } \rho_{\tau_f} = f_\#[\rho_0], \tag{940}$$

其中 $c(\xi,\xi')$ 是衡量从 ξ 移动质量到 ξ' 所需 “努力” 的代价函数，$f_{\#}[\rho_0]$ 是 ρ_0 在映射 f 下的推前测度. 推前测度定义为

$$\rho_{\tau_f}(\xi') = \int d\xi\, \delta(\xi' - f(\xi))\rho_0(\xi). \tag{941}$$

换言之，映射 f 需把 ρ_0 变换为 ρ_{τ_f}. 变换代价由 $c(\xi,\xi')$ 给出，其中在我们的情形下 $\xi' = f(\xi)$. 下面我们只考虑 2-Wasserstein 距离，即对代价 c 使用 L_2 距离.

给定代价后，我们要问：在所有满足 ρ_0 与 ρ_{τ_f} 之间迁移约束的映射中，哪一个使代价最小？对所有可能映射 f 取下确界，我们就把这个最小代价称为分布 ρ_0 与 ρ_{τ_f} 之间的距离：

$$W_2[\rho_0,\rho_{\tau_f}] = \left(\inf_{f:\, f_{\#}[\rho_0]=\rho_{\tau_f}} \int \|\xi - f(\xi)\|^2 \rho_0(\xi) d\xi \right)^{1/2}. \tag{942}$$

在 Monge 表述中，可能不存在满足约束的映射（例如质量需要被分割时）. Kantorovich 对问题的松弛通过考虑乘积空间上的概率测度，保证了解的存在性：

$$\mathcal{D}_{\mathrm{MK}}[\rho_0,\rho_{\tau_f}] = \inf_{\gamma\in\Gamma(\rho_0,\rho_{\tau_f})} \int d\xi_0\, d\xi_{\tau_f}\, c(\xi_0,\xi_{\tau_f})\, \gamma(\xi_0,\xi_{\tau_f}), \tag{943}$$

其中我们对所有具有指定边缘分布 ρ_0 与 ρ_{τ_f} 的联合分布 $\gamma(\xi_0,\xi_{\tau_f})$ 取平均.

Benamou 与 Brenier 证明与其 Kantorovich OT 表述等价的方案是：在 ρ_0 与 ρ_{τ_f} 之间引入一个 Markov 过程，在连续极限下由带速度场 $\mathbf{v}$ 的连续性方程描述. 我们的任务是寻找时间上的密度与速度场，满足连续性方程与 ρ_0、ρ_{τ_f} 上的约束，并最小化总期望动能（或控制代价）[1]：

$$\mathcal{D}_{\mathrm{OT}}[\rho_0,\rho_{\tau_f}] = \inf_{\rho,\mathbf{v}} \tau_f \int_0^{\tau_f} d\tau \int d\xi\, \rho(\xi,\tau)\|\mathbf{v}(\xi,\tau)\|^2, \tag{944}$$

$$\text{s.t. } \partial_\tau \rho(\xi,\tau) = -\mathrm{div}(\rho(\xi,\tau)\mathbf{v}(\xi,\tau)), \tag{945}$$

$$\text{s.t. } \rho(\xi,0) = \rho_0, \quad \rho(\xi,\tau_f) = \rho_{\tau_f}. \tag{946}$$

[1] 也可以通过变换 $s = \tau/\tau_f$ 把同一距离写成更标准的形式. 注意到测度变换为 $d\tau = \tau_f ds$，且 $\mathbf{v}(\xi,\tau) = \tau_f^{-1}\mathbf{v}'(\xi,s)$，则 $\tau_f \int_0^{\tau_f} d\tau \int d\xi\, \rho\|\mathbf{v}\|^2 \to \int_0^1 ds \int d\xi\, \rho\|\mathbf{v}'\|^2$.

首先注意到：连续性方程保证 $\tau = 0$ 处适当归一化且非负的密度，在所有 $\tau > 0$ 处仍归一化且非负，因此不必把它作为单独约束加入. 下面构造 Lagrangian，把连续性方程作为约束加入目标（为后面方便，用 $2\phi(\xi,\tau)$ 代替 $\phi(\xi,\tau)$ 作为 Lagrange 乘子）. 为保持方程可读，下面推导中省略 $\tau = 0$ 与 $\tau = \tau_f$ 处边界条件的约束：

$$\begin{aligned}
\mathcal{L}_{\mathrm{BB}}[\rho,\mathbf{v},\phi] = \inf_{\rho,\mathbf{v}} \sup_{\phi}\ & \tau_f \int_0^{\tau_f} d\tau \int d\xi \Big[\rho(\xi,\tau)\|\mathbf{v}(\xi,\tau)\|^2 \\
& + 2\phi(\xi,\tau)\big(\partial_\tau\rho(\xi,\tau) + \mathrm{div}(\rho(\xi,\tau)\mathbf{v}(\xi,\tau))\big)\Big] \qquad (947) \\
= \inf_{\rho,\mathbf{v}} \sup_{\phi}\ & \tau_f \int_0^{\tau_f} d\tau \int d\xi \Big[\rho(\xi,\tau)\|\mathbf{v}(\xi,\tau)\|^2 - 2\rho(\xi,\tau)\partial_\tau\phi(\xi,\tau) \\
& - 2\rho(\xi,\tau)\mathbf{v}(\xi,\tau)\cdot\nabla\phi(\xi,\tau)\Big] + \int d\xi\, 2\rho(\xi,\tau_f)\phi(\xi,\tau_f) - 2\rho(\xi,0)\phi(\xi,0). \qquad (948)
\end{aligned}$$

这里分部积分并整理了项. 现在要求 Lagrangian 在 $\mathbf{v}$ 与 ρ 变分下取平稳点（满足边界条件）：

$$\frac{\delta \mathcal{L}_{\mathrm{BB}}}{\delta \mathbf{v}(\xi,\tau)} = 2\rho(\xi,\tau)\mathbf{v}(\xi,\tau) - 2\rho(\xi,\tau)\nabla\phi(\xi,\tau) = 0 \tag{949}$$

$$\implies \mathbf{v}(\xi,\tau) = \nabla\phi(\xi,\tau), \quad \text{若} \rho(\xi,\tau) > 0. \tag{950}$$

$$\frac{\delta \mathcal{L}_{\mathrm{BB}}}{\delta \rho(\xi,\tau)} = \|\mathbf{v}(\xi,\tau)\|^2 - 2\partial_\tau\phi(\xi,\tau) - 2\mathbf{v}(\xi,\tau)\cdot\nabla\phi(\xi,\tau) \tag{951}$$

$$= -\|\nabla\phi(\xi,\tau)\|^2 - 2\partial_\tau\phi(\xi,\tau) = 0 \tag{952}$$

$$\implies \partial_\tau\phi(\xi,\tau) = -\frac{1}{2}\|\nabla\phi(\xi,\tau)\|^2. \tag{953}$$

把这些方程代回 Lagrangian，得到对偶 Lagrangian：

$$\mathcal{D}[\phi,\rho_0,\rho_{\tau_f}] = 2\int d\xi\, \rho_{\tau_f}(\xi)\phi(\xi,\tau_f) - 2\int d\xi\, \rho_0(\xi)\phi(\xi,0). \tag{954}$$

对偶优化问题在满足 Hamilton–Jacobi–Bellman（HJB）方程 (22.10) 的条件下最大化该目标.

考察 OT 解中各条路径的行为是有启发性的. 路径满足常微分方程

$$\frac{d\xi(\tau)}{d\tau} = \mathbf{v}(\xi(\tau),\tau) = \nabla\phi(\xi(\tau),\tau), \tag{955}$$

这意味着加速度为

$$\frac{d^2\xi(\tau)}{d\tau^2} = \frac{d}{d\tau}\mathbf{v}(\xi(\tau),\tau) = \partial_\tau\mathbf{v}(\xi(\tau),\tau) + (\mathbf{v}(\xi(\tau),\tau)\cdot\nabla)\mathbf{v}(\xi(\tau),\tau) \tag{956}$$

$$= \nabla\partial_\tau\phi(\xi(\tau),\tau) + \frac{1}{2}\|\nabla\phi(\xi(\tau),\tau)\|^2 = 0, \tag{957}$$

最后一步用了 (22.10). 这表明沿 OT 解的粒子沿直线以恒定速度运动. 这条确定性直线结构在第 23 章讨论 OT flow matching 这一具体 ML 模型时会很重要.

Wasserstein 距离 W_2 是定义在性质足够好的概率分布空间上的真距离. 表示 OT 解的概率空间中的路径 $\rho(\xi,\tau)$，是两个分布之间在 Wasserstein 度量下的最短路径（测地线）. Wasserstein 距离还满足三角不等式：

$$W_2[\rho_1,\rho_3] \le W_2[\rho_1,\rho_2] + W_2[\rho_2,\rho_3]. \tag{958}$$

此外，OT 问题是凸优化问题，因此对偶问题与原问题等价、无对偶间隙.

22.2 最小耗散功

Benamou–Brenier 的最优传输表述与随机热力学中 “最小耗散功” 概念自然衔接. 回顾第 21 章 (21.62)：0 到 τ_f 之间的总耗散功为

$$\mathcal{W}_{\mathrm{diss}} = \int_0^{\tau_f} d\tau \int d\xi\, \rho(\xi,\tau)\|\nabla\mathcal{V}(\xi,\tau) + \beta\nabla\log\rho(\xi,\tau)\|^2. \tag{959}$$

把它与最优传输的 Benamou–Brenier 表述 (22.5) 对比，我们看到若作识别

$$\nabla\phi(\xi,\tau) = -\mathcal{V}(\xi,\tau) - \beta^{-1}\log\rho(\xi,\tau) = -\mathcal{V}_\infty(\xi) - \mathcal{V}_\lambda(\xi;\lambda(\tau)) - \beta^{-1}\log\rho(\xi,\tau), \quad (960)$$

其中 $\lambda(\tau)$ 是 (21.67) 中引入的时间依赖控制参数，那么最小化 $\mathcal{W}_{\text{diss}}$ 恰好对应 OT 问题. 事实上，若假设 $\mathcal{V}_\lambda$ 足够强，能在有限时间 τ_f 内把 ρ_0 变换为 ρ_{τ_f}，那么只要遵守正确的动力学方程，最小可能的耗散功就由求解 OT 问题得到的 $\rho^*(\xi,\tau)$ 与 $\phi^*(\xi,\tau)$ 给出. 为求出实际的控制 Hamiltonian，我们解

$$\mathcal{V}_\lambda^*(\xi,\tau) = -\phi^*(\xi,\tau) - \mathcal{V}_\infty(\xi) - \beta^{-1}\log\rho^*(\xi,\tau). \quad (961)$$

理解这一点：控制 λ^* 需要先抵消 $\mathcal{V}_\infty$ 与 $T\log\rho^*$ 项，再加回最优势能 ϕ^*. 抵消渗透力项 $T\log\rho^*$ 实际上就是给流 “去噪”（或反扩散）. 这说得通，因为扩散是不可逆动力学与热产生的主要元凶. 为佐证这一解释，回顾上节：求解 OT 问题的粒子沿直线确定性运动，从而把本来含噪的轨迹 “去噪” 了（见图 55）. 因此，要给流去噪，必须对系统做功，从而产生自己的热.

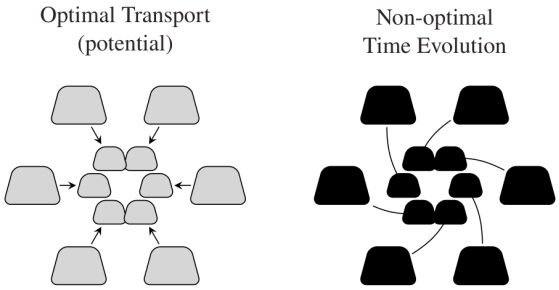


Figure 22.2 Comparison of optimal and nonoptimal transport. Left: Optimal transport

图 55: 最优与非最优传输的比较. 左：最优传输（梯度流）沿直接径向路径（直箭头）把质量从外梯形搬到内梯形，耗散最小. 右：非最优时间演化沿弯曲路径（弯箭头），耗散更大. 梯形形状表示外层（源）与内层（目标）位置处的概率质量.

因此，若要在有限时间内把分布从 ρ_0 变换为 ρ_{τ_f}，熵产生有一个绝对下界，即由两分布之间的 Wasserstein 距离给出（Aurell et al., 2012; Dechant and Sakurai, 2019; Nakazato and Ito, 2021）：

$$\Sigma_{\tau_f} \geq \frac{W_2^2[\rho_0,\rho_{\tau_f}]}{2\beta^{-1}\tau_f}. \quad (962)$$

该不等式可解释为热力学速度极限（Aurell et al., 2012）：给定熵产生预算，把 ρ_0 搬到 ρ_{τ_f} 至少需要一定时间：

$$\tau_f \geq \frac{W_2^2[\rho_0,\rho_{\tau_f}]}{2\beta^{-1}\Sigma_{\tau_f}}. \quad (963)$$

该界对任意初末分布都是紧的、可达的（Aurell et al., 2012; Nakazato and Ito, 2021）. 此外，这一原理可用于导出信息擦除 Landauer 界的有限时间修正（Landauer, 1961; Proesmans et al., 2020），即在有限时间过程中擦除一比特经典信息的热力学代价下界.

到目前为止，我们假设控制器足够强，能到达目标分布. 但情况并非总是如此. 假设分布在 τ_f 时刻到达 ρ_{τ_f}，但它自然倾向于弛豫到 ρ_∞. 从势能分解可以清楚看到：我们只需等待系统弛豫到平衡. 若想在整个轨迹（受控段 $\tau \in [0, \tau_f]$ 与不受控段 $\tau > \tau_f$）上最小化耗散功，我们回忆表达式是过剩功——见 (21.67)——现在要在所有 ρ_{τ_f} 上最小化它的值：

$$\mathcal{W}_{\mathrm{exc}} \geq \inf_{\rho_{\tau_f}} \frac{W_2^2[\rho_0, \rho_{\tau_f}]}{2\tau_f} + \beta D_{\mathrm{KL}}[\rho_{\tau_f} \| \rho_\infty]. \tag{964}$$

22.3 反绝热驱动

上一节中，我们同时求解密度流 $\rho^*(\xi, \tau)$ 与速度/控制向量 $\mathbf{v}^*(\xi, \tau)$ 来最小化总熵产生. 我们发现控制势能需要抵消自然势能与扩散所产生的流. 本节讨论一种相关方法，称为**反绝热驱动**：我们自己选择密度序列 $\rho^\#(\xi, \tau)$，再求解使系统沿这条预定路径走的控制势能. 每个密度通过 Boltzmann 分布由一个势能参数化（这总是可行的）：

$$\rho^\#(\xi, \tau) = \frac{1}{Z^\#(\tau)} \exp(-\beta \mathcal{V}^\#(\xi, \tau)). \tag{965}$$

假设系统按自然势能与受控势能之和演化：

$$\partial_\tau \rho(\xi, \tau) = \mathrm{div}\big(\rho(\xi, \tau)(\nabla \mathcal{V}_\infty(\xi) + \nabla \mathcal{V}_\lambda(\xi, \tau))\big) + \beta^{-1} \nabla^2 \rho(\xi, \tau), \tag{966}$$

并要求 $\rho = \rho^\#$. 这导致

$$\begin{aligned} \partial_\tau F^\#(\tau) &= \partial_\tau \mathcal{V}^\#(\xi, \tau) - \nabla \mathcal{V}^\#(\xi, \tau) \cdot (\nabla \mathcal{V}_\infty(\xi) + \nabla \mathcal{V}_\lambda(\xi, \tau) - \nabla \mathcal{V}^\#(\xi, \tau)) \\ &\quad + \nabla^2 \mathcal{V}_\infty(\xi) + \nabla^2 \mathcal{V}_\lambda(\xi, \tau) - \nabla^2 \mathcal{V}^\#(\xi, \tau) \qquad (967) \\ &= \partial_\tau \mathcal{V}^\#(\xi, \tau) - \nabla \mathcal{V}^\#(\xi, \tau) \cdot \nabla \phi(\xi, \tau) + \beta^{-1} \nabla^2 \phi(\xi, \tau), \qquad (968) \end{aligned}$$

其中我们回忆 $F^\# = -T \log Z^\#$，并定义

$$\phi(\xi, \tau) = \mathcal{V}_\infty(\xi) + \mathcal{V}_\lambda(\xi, \tau) - \mathcal{V}^\#(\xi, \tau). \tag{969}$$

若从上式解出 ϕ，便可由关系

$$\mathcal{V}_\lambda^*(\xi, \tau) = \phi^*(\xi, \tau) - \mathcal{V}_\infty(\xi) + \mathcal{V}^\#(\xi, \tau) \tag{970}$$

提取控制势能.

这与上节的思路显然非常相似. 不同之处在于：我们不是同时求解 ϕ 与 ρ 的 OT 问题，而是在此固定密度路径 $\rho^\#$、只求解 ϕ. 不过，求解 (22.23) 似乎比求解 OT 问题更难，因为 $F^\#(\tau)$ 没有显式表达式，难以计算.

但从 (22.23) 可以看到：一旦我们有了 ϕ 的表达式（例如通过求解 OT 问题，那也同时决定了 $\mathcal{V}^{\#}$），就有了一种计算自由能差的新方式. 只要确保 $\mathcal{V}^{\#}(\xi,0)$ 与 $\mathcal{V}^{\#}(\xi,\tau_f)$ 对应期望的初末 Boltzmann 分布，就可以计算

$$\Delta F^{\#} = \int_0^{\tau_f} d\tau \int d\xi\, \partial_\tau \mathcal{V}^{\#}(\xi,\tau) - \nabla \mathcal{V}^{\#}(\xi,\tau)\cdot\nabla\phi(\xi,\tau) + \beta^{-1}\nabla^2\phi(\xi,\tau). \tag{971}$$

这是一个相当特殊的结果：左边不依赖于 ξ，而右边却依赖！这意味着该等式对 ξ 的每个取值都成立，事实上对每条轨迹 $\xi(\tau)=\psi(\xi_0,\tau)$ 都成立. 为看清这一点，我们写

$$\int_0^{\tau_f} d\tau \int d\xi_0\, \rho_0(\xi_0)\big[\partial_\tau \mathcal{V}^{\#}(\xi(\xi_0,\tau),\tau) - \nabla \mathcal{V}^{\#}(\xi(\xi_0,\tau),\tau)\cdot\nabla\phi(\xi(\xi_0,\tau),\tau) + \beta^{-1}\nabla^2\phi(\xi(\xi_0,\tau),\tau)\big] \tag{972}$$

$$= \int_0^{\tau_f} d\tau \int d\xi\, \rho(\xi,\tau)\big[\partial_\tau \mathcal{V}^{\#}(\xi,\tau) - \nabla \mathcal{V}^{\#}(\xi,\tau)\cdot\nabla\phi(\xi,\tau) + \beta^{-1}\nabla^2\phi(\xi,\tau)\big] \tag{973}$$

$$= \int_0^{\tau_f} d\tau \int d\xi\, \rho(\xi,\tau)\partial_\tau F^{\#}(\tau) = \int_0^{\tau_f} d\tau\, \partial_\tau F^{\#}(\tau) = \Delta F^{\#}, \tag{974}$$

第一行是把方括号内表达式沿路径积分的 Lagrangian 形式，第二行换到 Eulerian 视角，第三行用了 (22.25). (22.26) 的结果对任意初态 ρ_0 与轨迹 $\psi(\xi_0,\tau)$ 都成立，因而对任意路径或路径上的分布都成立. 这又意味着：由采样路径随机性带来的涨落都被抵消了，因而 $\Delta F^{\#}$ 估计量的方差为零.

此外，由于 $\mathcal{V}^{\#}$ 在时间反演下不变，而 ϕ 在时间反演下变号（因其梯度是速度），被积函数也在时间反演下变号. 这促使人们把右端定义为功的新表达式，由此可导出新的涨落定理，进而得到通过 Jarzynski 型等式估计自由能差的新方法（Zhong et al., 2024; Vargas et al., 2024）.

22.4 Jordan–Kinderlehrer–Otto 格式

在第 21.5 节，我们看到 Fokker–Planck 方程可由自由能泛函导数的负梯度导出，即自由能的梯度流. 直观上，这意味着我们在概率分布空间中、关于自由能做梯度下降. 在那里的推导中，我们假设连续性方程对某个速度场成立. 本节我们再深入一层：只假设概率测度之间的距离用 Wasserstein 度量来衡量，就推出 FP 方程是自由能泛函的梯度流. 由此得到的算法通过对时间离散化，数值地 “求解” FP 方程，称为 Jordan–Kinderlehrer–Otto（JKO）格式（Jordan et al., 1998）. 它是邻近梯度法或最小移动格式的一个实例.

该方法通常写作如下迭代优化格式：

$$\rho_{\tau+\Delta\tau} = \arg\min_{\rho}\ \mathcal{F}[\rho] + \frac{1}{2\Delta\tau} W_2^2[\rho_\tau,\rho], \tag{975}$$

其中 $\Delta\tau>0$ 是时间步长参数. 不过为建立几何直观，我们用 Lagrange 乘子把该问题表为另一种形式. 几何上，我们在当前密度 ρ_τ 周围定义一个半径为 ϵ 的小球. 要定义半

径，就需要概率测度上的度量，我们选 Wasserstein 度量. 然后在球面上搜索自由能最小的密度：

$$\rho_{\tau+\Delta\tau} = \arg\min_{\rho} \ \mathcal{F}[\rho] + \mu\left(W_2^2[\rho_\tau, \rho] - \epsilon^2\right), \tag{976}$$

其中我们把 Wasserstein 度量视为距离平方. Lagrange 乘子 μ 用于保证 ρ 在球面上，代表一个抵消自由能下降力的力.

刻画解的方程由目标函数的泛函导数给出：

$$\frac{\delta\mathcal{F}[\rho^*]}{\delta\rho} + \mu\frac{\delta W_2^2[\rho_\tau, \rho^*]}{\delta\rho} = 0. \tag{977}$$

由 OT 问题的对偶形式 (22.11)，我们得到

$$\frac{\delta W_2^2[\rho_\tau, \rho]}{\delta\rho}(\xi) = 2\phi(\xi, \tau), \tag{978}$$

$$\Longrightarrow \ \frac{\delta\mathcal{F}[\rho^*]}{\delta\rho}(\xi) = -2\mu\phi^*(\xi, \tau), \tag{979}$$

$$\Longrightarrow \ \nabla\frac{\delta\mathcal{F}[\rho^*]}{\delta\rho}(\xi) = -2\mu\nabla\phi^*(\xi, \tau) = -2\mu\mathbf{v}^*(\xi, \tau). \tag{980}$$

由于 OT 问题的 Benamou–Brenier 表述涉及带速度 $\mathbf{v}^*$ 的连续性方程，我们已经证明：上述约束优化问题的解确实是一个 FP 型方程，其速度场为

$$\mathbf{v}^*(\xi, \tau) = -\frac{1}{2\mu}\nabla\frac{\delta\mathcal{F}[\rho^*]}{\delta\rho}(\xi). \tag{981}$$

这与第 21.5 节的 (21.31) 一致.

最后把 μ 与 ϵ 联系起来. 给定 ρ_τ 与某个 $\mathbf{v}^*$，用连续性方程演化极短时间 $\Delta\tau$ 得到 $\rho^{\text{new}}_{\tau+\Delta\tau}$，此时平方 Wasserstein 距离为

$$W_2^2[\rho_\tau, \rho_{\tau+\Delta\tau}] = \Delta\tau\int_0^{\Delta\tau} d\tau \int d\xi\, \rho^*(\xi, \tau)\|\mathbf{v}^*(\xi, \tau)\|^2 \tag{982}$$

$$\approx \Delta\tau\int d\xi\, \rho^*(\xi, \tau)\frac{1}{4\mu^2}\left\|\nabla\frac{\delta\mathcal{F}[\rho^*]}{\delta\rho}(\xi, \tau)\right\|^2. \tag{983}$$

令其等于 ϵ^2，解出 μ：

$$\epsilon = \sqrt{\Delta\tau}\|\cdots\|, \quad \Longrightarrow \ \mu = \frac{1}{2}\sqrt{\frac{\Delta\tau}{|\cdots|}}. \tag{984}$$

JKO 格式不仅证明了 FP 方程是自由能在 Wasserstein 度量下的梯度流，而且本身就是一种稳定的数值方法，通过迭代求解一系列 OT 问题来求解 FP 方程.

22.5 Schrödinger 桥

Schrödinger 桥（SB）问题与 OT 问题只有一点差别：我们假设扩散动力学，而不仅仅是连续性方程：

$$\mathcal{D}_{\mathrm{SB}}[\rho_0,\rho_{\tau_f}] = \inf_{\rho,\mathbf{v}} \int_0^{\tau_f} d\tau \int d\xi\, \rho(\xi,\tau)\|\mathbf{v}(\xi,\tau)\|^2, \tag{985}$$

$$\text{s.t. } \partial_\tau \rho(\xi,\tau) = -\mathrm{div}(\rho(\xi,\tau)\mathbf{v}(\xi,\tau)) + \nu\nabla^2\rho(\xi,\tau), \tag{986}$$

$$\text{s.t. } \rho(\xi,0) = \rho_0, \quad \rho(\xi,\tau_f) = \rho_{\tau_f}. \tag{987}$$

这里 ν 是扩散常数. 按前几节方式构造 Lagrangian，推导 HJB 方程：

$$\begin{aligned}\mathcal{L}_{\mathrm{SB}}(\rho,\mathbf{v},\phi) = \inf_{\rho,\mathbf{v}}\sup_{\phi} \int_0^{\tau_f} d\tau \int d\xi \Big[&\rho(\xi,\tau)\|\mathbf{v}(\xi,\tau)\|^2 \\ &+ 2\phi(\xi,\tau)\big(\partial_\tau\rho(\xi,\tau) + \mathrm{div}(\rho(\xi,\tau)[\mathbf{v}(\xi,\tau) - \nu\nabla\log\rho(\xi,\tau)])\big)\Big] \qquad (988)\\ = \inf_{\rho,\mathbf{v}}\sup_{\phi} \int_0^{\tau_f} d\tau \int d\xi \Big[&\rho(\xi,\tau)\|\mathbf{v}(\xi,\tau)\|^2 - 2\rho(\xi,\tau)\partial_\tau\phi(\xi,\tau) \\ &- 2\rho(\xi,\tau)[\mathbf{v}(\xi,\tau) - \nu\nabla\log\rho(\xi,\tau)]\cdot\nabla\phi(\xi,\tau)\Big] \\ &+ \int d\xi\, 2\rho(\xi,\tau_f)\phi(\xi,\tau_f) - 2\rho(\xi,0)\phi(\xi,0). \qquad (989)\end{aligned}$$

对 $\mathbf{v}$ 变分得到与 OT 问题完全相同的方程：$\mathbf{v}(\xi,\tau) = \nabla\phi(\xi,\tau)$. 代入 Lagrangian 并对 ρ 变分，得到

$$\partial_\tau\phi(\xi,\tau) = -\frac{1}{2}\|\nabla\phi(\xi,\tau)\|^2 - \nu\nabla^2\phi(\xi,\tau). \tag{990}$$

注意对偶 Lagrangian 与 OT 优化问题具有相同的简单形式——只含两个边界项——但现在需服从上面这个 HJB 方程，后者对 ϕ 多了一个扩散样的项. 因此 SB 问题可解释为一个随机最优控制问题，其动力学由带扩散的 Fokker–Planck 方程支配.

OT 与 SB 的关系

从 SB 问题出发，作变换

$$\mathbf{w}(\xi,\tau) = \mathbf{v}(\xi,\tau) - \nu\nabla\log\rho(\xi,\tau), \tag{991}$$

其中 $\mathbf{w} = \nabla\psi$. 这把扩散动力学转化为连续性方程：

$$\partial_\tau\rho(\xi,\tau) = -\mathrm{div}(\rho(\xi,\tau)\mathbf{w}(\xi,\tau)), \tag{992}$$

而距离（作用量）变为

$$\mathcal{D}_{\mathrm{SB}}[\rho_0,\rho_{\tau_f}] = \inf_{\rho,\mathbf{w}} \int_0^{\tau_f} d\tau \int d\xi\, \rho(\xi,\tau)\left[\|\mathbf{w}(\xi,\tau)\|^2 + \nu^2\|\nabla\log\rho(\xi,\tau)\|^2 + 2\nu\mathbf{w}(\xi,\tau)\cdot\nabla\log\rho(\xi,\tau)\right]. \tag{993}$$

最后一项可用 (21.18) 改写为边界项：

$$\int_0^{\tau_f} d\tau \int d\xi\, \rho(\xi,\tau)\, 2\nu \mathbf{w}(\xi,\tau)\cdot\nabla\log\rho(\xi,\tau) = -2\nu\int_0^{\tau_f} d\tau\, \partial_\tau \mathcal{S}[\rho] = -2\nu\big(\mathcal{S}[\rho_{\tau_f}] - \mathcal{S}[\rho_0]\big), \tag{994}$$

由于边界上的边缘约束，该项为常数. 由此得到重要结论：OT 与 SB 问题之差是作用量中多出的一项，我们把它识别为 Fisher 信息，即渗透力 $\nabla\log\rho$ 对应的能量. 综合起来，SB 问题的等价表述，即 **Yasue 问题**（Léger, 2019）为：

$$\mathcal{D}_{\mathrm{Y}}[\rho_0,\rho_{\tau_f}] = \inf_{\rho,\mathbf{w}}\int_0^{\tau_f} d\tau \int d\xi\, \rho(\xi,\tau)\big[\|\mathbf{w}(\xi,\tau)\|^2 + \nu^2\|\nabla\log\rho(\xi,\tau)\|^2\big], \tag{995}$$

$$\text{s.t. } \partial_\tau\rho(\xi,\tau) = -\mathrm{div}(\rho(\xi,\tau)\mathbf{w}(\xi,\tau)), \tag{996}$$

$$\text{s.t. } \rho(\xi,0)=\rho_0,\quad \rho(\xi,\tau_f)=\rho_{\tau_f}, \tag{997}$$

相应的 HJB 方程（利用通常的关系 $\mathbf{w}=\nabla\psi$，其中 ψ 是 $\mathbf{w}$ 变分平稳性给出的 Lagrange 乘子）为

$$\partial_\tau\phi(\xi,\tau) = -\frac{1}{2}\|\nabla\phi(\xi,\tau)\|^2 - \frac{1}{2}\nu^2\|\nabla\log\rho(\xi,\tau)\|^2 - \frac{1}{2}\nu^2\nabla^2\log\rho(\xi,\tau). \tag{998}$$

两个 Lagrange 乘子之间的关系为

$$\phi(\xi,\tau) = \psi(\xi,\tau) - \nu\log\rho(\xi,\tau). \tag{999}$$

时间反演

前面章节中，我们看到时间反演对称性扮演着根本角色. 正是前向与反向过程之间的不对称性告诉我们一个过程产生了多少熵. 那么各种 OT 与 SB 问题在时间反演下如何表现?

先看 OT 问题：

$$\partial_\tau\rho(\xi,\tau) = -\nabla\cdot(\rho(\xi,\tau)\nabla\phi(\xi,\tau)), \tag{1000}$$

$$\partial_\tau\phi(\xi,\tau) = -\frac{1}{2}\|\nabla\phi(\xi,\tau)\|^2. \tag{1001}$$

作变换 $\tau\to\tilde\tau=\tau_f-\tau$：

$$\partial_{\tau_f-\tilde\tau}\rho(\xi,\tau_f-\tilde\tau) = -\nabla\cdot(\rho(\xi,\tau_f-\tilde\tau)\nabla\phi(\xi,\tau_f-\tilde\tau)), \tag{1002}$$

$$\partial_{\tau_f-\tilde\tau}\phi(\xi,\tau_f-\tilde\tau) = -\frac{1}{2}\|\nabla\phi(\xi,\tau_f-\tilde\tau)\|^2. \tag{1003}$$

利用 $\partial_{\tau_f-\tilde\tau}=-\partial_{\tilde\tau}$，并记 $\rho(\xi,\tau_f-\tilde\tau)=\tilde\rho(\tilde\xi,\tilde\tau)$，其中 $\tilde\xi=(\xi,-\eta)$. 由于尚不知 ϕ 的变换规则，记 $\phi(\xi,\tau_f-\tilde\tau)=\alpha\tilde\phi(\tilde\xi,\tilde\tau)$：

$$-\partial_{\tilde\tau}\tilde\rho(\tilde\xi,\tilde\tau) = -\alpha\nabla\cdot(\tilde\rho(\tilde\xi,\tilde\tau)\nabla\tilde\phi(\tilde\xi,\tilde\tau)), \tag{1004}$$

$$-\alpha\partial_{\tilde\tau}\tilde\phi(\tilde\xi,\tilde\tau) = -\frac{1}{2}\alpha^2\|\nabla\tilde\phi(\tilde\xi,\tilde\tau)\|^2. \tag{1005}$$

要让变换后变量中的演化方程保持原方程形式，读出 $\alpha = 1$，且

$$\tilde{\phi}(\tilde{\xi}, \tilde{\tau}) = -\phi(\tilde{\xi}, \tilde{\tau}). \tag{1006}$$

对 SB 问题，情况稍复杂. 但 SB 问题的 Yasue 表述显式地时间对称. 按同样推理，我们可以直接令

$$\tilde{\psi}(\tilde{\xi}, \tilde{\tau}) = -\psi(\tilde{\xi}, \tilde{\tau}) \tag{1007}$$

$$\implies \tilde{\phi}(\tilde{\xi}, \tilde{\tau}) - \nu \log \tilde{\rho}(\tilde{\xi}, \tilde{\tau}) = -\psi(\tilde{\xi}, \tilde{\tau}) + \nu \log \rho(\tilde{\xi}, \tilde{\tau}) \tag{1008}$$

$$\implies \tilde{\phi}(\tilde{\xi}, \tilde{\tau}) = -\phi(\tilde{\xi}, \tilde{\tau}) + 2\nu \log \rho(\tilde{\xi}, \tilde{\tau}). \tag{1009}$$

这个看似奇怪的时间反演变换规则，正是保持传播律在时间反演下不变所必需的.

22.6 更一般的作用量

物理学家发现，几乎所有基本物理定律都可从变分原理导出（Goldstein, 1950; Landau and Lifshitz, 1976），这与我们在 OT 与 SB 问题中所用的非常相似. 在变分问题中，系统的初末态被约束，通过对作用量泛函取极值来确定解路径；作用量是 Lagrangian 沿路径的积分（见图 56）：

$$A[\xi] = \int_{\tau_0}^{\tau_f} L(\xi(\tau), \dot{\xi}(\tau), \tau)\, d\tau, \tag{1010}$$

其中 $\xi(\tau)$ 是位置坐标，$\dot{\xi}(\tau) = \partial_\tau \xi(\tau)$.

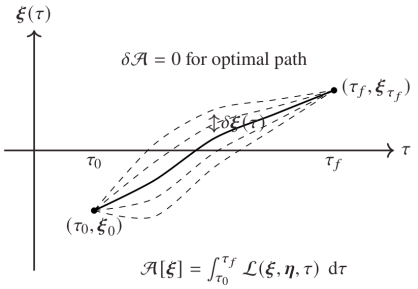


Figure 22.3 The principle of least action states that the physical path $\boldsymbol{\xi}(\tau)$ (solid curve)

图 56: 最小作用量原理：在固定端点 (τ_0, ξ_0) 与 (τ_f, ξ_{τ_f})（实心圆）之间，物理路径 $\xi(\tau)$（实线）是使作用量泛函 $A[\xi]$ 取极值的路径. 任何绕该最优路径的变分 $\delta\xi(\tau)$（满足 $\delta\xi(\tau_0) = \delta\xi(\tau_f) = 0$）都使 $\delta A = 0$（一阶）. 虚线表示满足端点约束的可能路径变分.

考虑路径的无穷小变分 $\xi(\tau) \to \xi(\tau) + \delta\xi(\tau)$，变分满足边界条件 $\delta\xi(\tau_0) = 0$、$\delta\xi(\tau_f) = 0$. 相应的速度变分为 $\delta\dot{\xi}(\tau) = \partial_\tau \delta\xi(\tau)$. 作用量的变分（对 $\delta\xi$、$\delta\dot{\xi}$ 展开到一阶）为

$$\delta A = A[\xi + \delta\xi] - A[\xi] = \int_{\tau_0}^{\tau_f} d\tau \left\{ L(\xi + \delta\xi, \dot{\xi} + \delta\dot{\xi}, \tau) - L(\xi, \dot{\xi}, \tau) \right\} \tag{1011}$$

$$= \int_{\tau_0}^{\tau_f} d\tau \, \frac{\partial L}{\partial \xi} \cdot \delta\xi(\tau) + \frac{\partial L}{\partial \dot{\xi}} \cdot \delta\dot{\xi}(\tau). \tag{1012}$$

由于 $\delta\dot{\xi}(\tau) = \partial_\tau \delta\xi(\tau)$，分部积分第二项：

$$\int_{\tau_0}^{\tau_f} d\tau \, \frac{\partial L}{\partial \dot{\xi}} \cdot \delta\dot{\xi}(\tau) = \frac{\partial L}{\partial \dot{\xi}} \cdot \delta\xi(\tau)\Big|_{\tau_0}^{\tau_f} - \int_{\tau_0}^{\tau_f} d\tau \, \partial_\tau \frac{\partial L}{\partial \dot{\xi}} \cdot \delta\xi(\tau). \tag{1013}$$

由边界条件 $\delta\xi(\tau_0) = \delta\xi(\tau_f) = 0$，边界项消失. 于是由任意变分 $\delta\xi(\tau)$ 下 $\delta A = 0$，得到 Euler–Lagrange 方程：

$$\delta A = \int_{\tau_0}^{\tau_f} d\tau \left(\frac{\partial L}{\partial \xi} - \partial_\tau \frac{\partial L}{\partial \dot{\xi}} \right) \cdot \delta\xi(\tau) = 0 \quad \Longrightarrow \quad \frac{\partial L}{\partial \xi} - \partial_\tau \frac{\partial L}{\partial \dot{\xi}} = 0. \tag{1014}$$

在确定性经典系统中，Lagrangian 为动能减势能：$L(\xi, \dot{\xi}, \tau) = \frac{1}{2}\|\dot{\xi}(\tau)\|^2 - \mathcal{V}(\xi)$. 把它代入 Euler–Lagrange 方程 (22.60)，得到 Newton 力学给出的解：

$$\partial_\tau \frac{\partial L}{\partial \dot{\xi}}(\xi(\tau)) + \frac{\partial \mathcal{V}}{\partial \xi}(\xi(\tau)) = 0 \quad \Longrightarrow \quad \frac{d^2\xi(\tau)}{d\tau^2} = -\nabla \mathcal{V}(\xi(\tau)). \tag{1015}$$

注意这一最小作用量设定与通常的 Newton 定律因果表述略有不同：那里给出初始位置与速度，未来随之而定；而在变分表述中，我们得到未来的部分信息（初末位置），初始速度场反而需要推导.

这一变分原理也适用于概率密度（甚至量子力学波函数；Feynman et al., 2010）. 指定初末概率密度（不指定速度场），便可写下一个作用量（如 OT 或 SB 问题中的），通过找作用量的鞍点（即极值路径）来确定最优路径. 我们在 OT 与 SB 问题中做的正是这件事，只是作用量相对简单.

更一般地，我们可以考虑更灵活的作用量泛函：

$$A[\rho_0, \rho_{\tau_f}] = \inf_{\rho, \mathbf{v}} \int_0^{\tau_f} d\tau \int d\xi \, \rho(\xi, \tau) \left[\frac{1}{2}\|\mathbf{v}(\xi, \tau)\|^2 - \mathcal{V}(\xi, \tau) \right], \tag{1016}$$

$$\text{s.t. } \partial_\tau \rho(\xi, \tau) = -\mathrm{div}(\rho(\xi, \tau)\mathbf{v}(\xi, \tau)) + \nu \nabla^2 \rho(\xi, \tau), \tag{1017}$$

$$\text{s.t. } \rho(\xi, 0) = \rho_0, \quad \rho(\xi, \tau_f) = \rho_{\tau_f}. \tag{1018}$$

第一项是动能密度，第二项是负势能密度. 再次用 Lagrange 乘子加入 FP 方程，推导 HJB 方程：

$$\partial_\tau \phi(\xi, \tau) = -\frac{1}{2}\|\nabla \phi(\xi, \tau)\|^2 - \mathcal{V}(\xi, \tau) - \nu \nabla^2 \phi(\xi, \tau) \tag{1019}$$

$$\Longrightarrow \; \partial_\tau \mathbf{v}(\xi, \tau) + \frac{1}{2}\mathbf{v}(\xi, \tau) \cdot \nabla \mathbf{v}(\xi, \tau) = -\nabla \mathcal{V}(\xi, \tau) - \nu \nabla^2 \mathbf{v}(\xi, \tau), \tag{1020}$$

其中 $\mathbf{f} = -\nabla \mathcal{V}$ 可识别为力场. 该方程说明速度场的随体导数正比于力场加一个额外扩散项. 这是 Newton 定律的流体力学推广！

22.7 与最优控制的关系

可以把上节定义的作用量看作受控系统为达到特定目标而付出的代价. 在 SB 问题中，目标是通过控制流场 $\mathbf{v}$，到达末态分布 $\rho(\xi, \tau_f) = \rho_{\tau_f}(\xi)$. 这里我们考虑更一般的 τ_f

时刻终端代价. 假设在时刻 τ 我们处于确定状态 $\xi_\tau = \mathbf{y}_\tau$，即 $\rho(\xi,\tau) = \delta(\xi - \mathbf{y}_\tau)$. 那么“代价至终点”（cost-to-go）是从此刻起最优行动下能达到的最小代价，定义为：

$$J(\mathbf{y}_\tau,\tau) = \inf_{\rho,\mathbf{v}} \int_\tau^{\tau_f} d\tau' \int d\xi\, \rho(\xi,\tau') \left[\frac{1}{2}\|\mathbf{v}(\xi,\tau')\|^2 - \mathcal{V}(\xi,\tau')\right] + \mathcal{K}_{\tau_f}, \tag{1021}$$

$$\text{s.t. } \partial_{\tau'}\rho(\xi,\tau') = -\mathrm{div}(\rho(\xi,\tau')\mathbf{v}(\xi,\tau')) + \nu\nabla^2\rho(\xi,\tau'), \tag{1022}$$

$$\text{s.t. } \rho(\xi,\tau) = \delta(\xi - \mathbf{y}_\tau). \tag{1023}$$

这里 $\mathcal{K}_{\tau_f}$ 是 τ_f 时刻的终端代价. 项 $\mathcal{V}$ 解释为在时刻 τ 处于状态 ξ 的奖励；由于前面有负号，系统沿路径最大化该函数以积累尽可能多的奖励.

为求最优解，我们在服从 FP 方程与当前状态约束 $\rho(\xi,\tau)$ 的条件下，对 ρ 与 $\mathbf{v}$ 同时最小化该代价. 我们已知这会导出 HJB 方程，但换个角度解释. 如前把约束作为 Lagrange 乘子加入并求解，可把代价改写为（形式上即对偶）：

$$J(\mathbf{y}_\tau,\tau) = \int d\xi\, \rho(\xi,\tau_f)\phi(\xi,\tau_f) - \int d\xi\, \rho(\xi,\tau)\phi(\xi,\tau) + \mathcal{K}_{\tau_f}[\rho_{\tau_f}] = \mathcal{K}'_{\tau_f}[\rho_{\tau_f}] - \phi(\mathbf{y}_\tau,\tau), \tag{1024}$$

其中 $\mathcal{K}'_{\tau_f}$ 收集首末两项，在 $\tau \neq \tau_f$ 时与 $\mathbf{y}_\tau$ 无关，是常数. 第二式用了 (22.67). 换言之，cost-to-go 正比于 Lagrange 乘子的负值.

控制问题的 HJB 方程是 $\partial_\tau J(\mathbf{y}_\tau,\tau)$ 的表达式. 由于我们把 cost-to-go 与负势能 ϕ 作了识别，答案应等于 (22.63). 我们按最优控制理论中推导 HJB 方程的典型方式来推. 观察：从时刻 τ 到终点 τ_f 的总代价，等于从 τ 到 $\tau + \Delta\tau$ 的代价加上 $\tau + \Delta\tau$ 时刻剩余的代价：

$$J(\mathbf{y}_\tau,\tau) = J(\mathbf{y}_\tau,\tau+\Delta\tau) + \Delta\tau \int d\xi\, \rho(\xi,\tau) \left[\frac{1}{2}\|\mathbf{v}(\xi,\tau)\|^2 - \mathcal{V}(\xi,\tau)\right] \tag{1025}$$

$$= J(\mathbf{y}_\tau,\tau) - \Delta\tau \int d\xi\, (\rho(\xi,\tau)\partial_\tau\phi(\xi,\tau) + \rho(\xi,\tau)\partial_\tau\phi(\xi,\tau)) \tag{1026}$$

$$+ \Delta\tau \int d\xi\, \rho(\xi,\tau) \left[\frac{1}{2}\|\nabla\phi(\xi,\tau)\|^2 - \mathcal{V}(\xi,\tau)\right], \tag{1027}$$

第二式用了 (22.68) 与 $\Delta\tau$ 的 Taylor 展开. 由此推出

$$\int d\xi\, \rho(\xi,\tau)\partial_\tau\phi(\xi,\tau) = \int d\xi\, \rho(\xi,\tau) \left[-\frac{1}{2}\|\nabla\phi(\xi,\tau)\|^2 - \mathcal{V}(\xi,\tau) - \nu\nabla^2\phi(\xi,\tau)\right], \tag{1028}$$

与 (22.63) 一致. 利用 $\rho(\xi,\tau) = \delta(\xi - \mathbf{y}_\tau)$ 与 (22.68)，得到最优控制理论中对随机 Brown 动力学与二次控制的常见 HJB 方程：

$$\frac{\partial J(\mathbf{y}_\tau,\tau)}{\partial\tau} = \frac{1}{2}\|\nabla J(\mathbf{y}_\tau,\tau)\|^2 + \mathcal{V}(\mathbf{y}_\tau,\tau) - \nu\nabla^2 J(\mathbf{y}_\tau,\tau), \tag{1029}$$

s.t. $J(\mathbf{y}_{\tau_f},\tau_f) = \mathcal{K}_{\tau_f}(\mathbf{y}_{\tau_f})$. 该方程也称为 Riccati 方程；由于 $\tau = \tau_f$ 处的边界条件，它必须反向时间求解.

综上：把 SB 问题（带随机动力学）扩展一个奖励项 $\mathcal{V}$ 与初态分布 $\delta(\xi - \mathbf{y}_\tau)$，恰好等价于一个最优控制（OC）问题. HJB 方程作为 ODE 计算 cost-to-go. 这再次把 OC 与 SB、OT 问题美妙地联系起来.

22.8 回到扩散模型

回顾训练扩散模型时，我们定义了前向与反向过程（见第 13 章）. 前向过程通常采用简单的 Ornstein–Uhlenbeck 过程，从数据分布出发，收敛到标准正态分布这一不动点. 该过程最早由 Uhlenbeck 与 Ornstein（1930）在 Brown 运动的开创性工作中分析，为随机动力学建模提供了数学上易处理的框架. 反向过程被训练来反转前向过程，把先验标准正态分布变回数据分布.

本章我们从 Fokker–Planck 方程视角看待随机过程（离散时间视角见第 13 章）. 于是前向过程形式为

$$\partial_\tau \rho(\xi,\tau) = -\mathrm{div}(\rho(\xi,\tau)\mathbf{v}(\xi,\tau)) + \nu\nabla^2\rho(\xi,\tau), \quad \text{s.t. } \rho(\xi,0)=\rho_{\text{data}}. \tag{1030}$$

时间反演过程可直接施加时间反演变换得到. 具体地，用 $\tilde\tau = \tau_f - \tau$、$\tilde\zeta = (\xi,-\eta)$、$\tilde\rho(\tilde\zeta,\tilde\tau)=\rho(\xi,\tau)$、$\tilde{\mathbf{v}}(\tilde\zeta,\tilde\tau)=-\mathbf{v}(\xi,\tau)$，时间反演方程变为

$$\partial_{\tilde\tau}\tilde\rho(\tilde\xi,\tilde\tau) = -\mathrm{div}(\tilde\rho(\tilde\xi,\tilde\tau)\tilde{\mathbf{v}}(\tilde\xi,\tilde\tau)) - \nu\nabla^2\tilde\rho(\tilde\xi,\tilde\tau), \quad \text{s.t. } \tilde\rho(\tilde\xi,0)=\rho_{\text{prior}}. \tag{1031}$$

从这些变换中读出：扩散项获得负号. 这减小系统熵，从噪声过渡到结构（即去噪），与第 13 章讨论一致.

为得到扩散项为正的方程，我们把扩散项移入散度内部：

$$\partial_{\tilde\tau}\tilde\rho(\tilde\xi,\tilde\tau) = -\mathrm{div}\left[\tilde\rho(\tilde\xi,\tilde\tau)\left(\tilde{\mathbf{v}}(\tilde\xi,\tilde\tau) + 2\nu\nabla\log\tilde\rho(\tilde\xi,\tilde\tau)\right)\right] + \nu\nabla^2\tilde\rho(\tilde\xi,\tilde\tau). \tag{1032}$$

这提示有效反向漂移速度场为（Anderson, 1982; Nelson, 1967）

$$\mathbf{v}^*(\xi,\tau) = \tilde{\mathbf{v}}(\tilde\xi,\tilde\tau) + 2\nu\nabla\log\tilde\rho(\tilde\xi,\tilde\tau) \tag{1033}$$

$$= -\mathbf{v}(\xi,\tau) + 2\nu\nabla\log\rho(\xi,\tau). \tag{1034}$$

因此反向时间动力学由一个漂移项支配，它同时含前向漂移的负值与一个正比于对数密度梯度的额外项，即**分数函数**：

$$\mathbf{s}(\xi,\tau) := \nabla\log\rho(\xi,\tau). \tag{1035}$$

但实际中边缘分布 $\rho(\xi,\tau)$ 未知. 我们转而依赖样本路径来训练一个能反演该动力学的速度场. 思路是用神经网络 $\mathbf{s}_\theta(\xi,\tau)$ 参数化分数函数 [2]. [2] 为简单与符合扩散模型惯例，常取过阻尼情形 $\zeta=\xi$，但一般表述仍成立. 为学习参数 θ，我们构造 score matching 目标，最小化网络输出与真实分数函数之差：

$$\mathcal{L}(\theta) = \mathbb{E}_{\tau\sim\mathrm{Unif}[0,\tau_f]}\,\lambda(\tau)\,\mathbb{E}_{\rho(\xi,\tau)}\|\mathbf{s}_\theta(\xi,\tau)-\mathbf{s}(\xi,\tau)\|^2, \tag{1036}$$

其中 $\lambda(\tau)$ 是时间依赖权重函数. 由于真实分数函数 $\mathbf{s}(\xi,\tau)$ 未知，该目标直接计算有难度（讨论见 Song and Ermon, 2019）. 进一步简化用去噪 score matching 目标（Vincent, 2011; Song et al., 2021）：若在多个噪声水平下用 Gauss 噪声扰动数据分布，分数函数可通过最小化

$$\mathcal{L}(\theta) = \mathbb{E}_{\tau\sim\mathrm{Unif}[0,\tau_f]}\,\lambda(\tau)\,\mathbb{E}_{\rho(\xi(0))}\mathbb{E}_{\rho(\xi(\tau)|\xi(0))}\frac{1}{2}\left\|\mathbf{s}_\theta(\xi(\tau),\tau) - \nabla_{\xi(\tau)}\log\rho(\xi(\tau)|\xi(0))\right\|^2 \tag{1037}$$

来估计，其中 $\rho(\xi(\tau)|\xi(0))$ 是前向过程的转移核. 当前向过程取 Ornstein–Uhlenbeck（即速度场 $\mathbf{v}(\xi,\tau)$ 对 ξ 仿射）时，转移核 $\rho(\xi(\tau)|\xi(0))$ 是 Gauss 分布，有闭式解，可用于训练. 当分数网络训练完美后，反向过程几乎处处精确反转前向扩散.

(22.72) 与 (22.74) 的 Fokker–Planck 方程对应如下 SDE：

$$d\xi = \mathbf{v}(\xi,\tau)d\tau + \sqrt{2\nu}\, d\mathbf{w}_\tau, \tag{1038}$$

$$d\xi = [-\mathbf{v}(\xi,\tau) + 2\nu\nabla \log \rho(\xi,\tau)]d\tau + \sqrt{2\nu}\, d\tilde{\mathbf{w}}_\tau, \tag{1039}$$

其中 $d\mathbf{w}_\tau$ 与 $d\tilde{\mathbf{w}}_\tau$ 分别是标准 Wiener 过程与反向时间 Wiener 过程. Wiener 过程概念建立在 Norbert Wiener（1930）奠定的数学基础上，他把 Brown 运动纳入严格数学框架. 训练好神经网络 $\mathbf{s}_\theta(\xi,\tau)$ 逼近分数函数后，可用近似反向 SDE，从 $\tau = \tau_f$ 的先验分布 ρ_{prior} 出发，反向时间积分到 $\tau = 0$ 来生成新样本：

$$d\xi = [-\mathbf{v}(\xi,\tau) + 2\nu\mathbf{s}_\theta(\xi,\tau)]d\tau + \sqrt{2\nu}\, d\tilde{\mathbf{w}}_\tau. \tag{1040}$$

本书未详细讨论 SDE 与 Brown 运动，关于 score matching 及其在基于 SDE 的扩散模型中应用的更详细讨论，读者可参阅 Song and Ermon（2019）; Song et al.（2021）; Kingma et al.（2021）; Gardiner（2009）. Gardiner（2009）对物理与计算背景下的随机方法有特别全面的处理.

下一章我们应用本章学到的一课：不必用扩散来演化，而可以求解最优传输问题（见第 22.2 节）. 这样做的好处是先验分布与数据分布之间的路径更简单（直线路径），因而更易学习. 此外，Ornstein–Uhlenbeck 过程要经过无穷多步才到达不动点（我们的先验），而求解 OT 问题保证我们在有限步内完成数据分布与先验之间的映射. 这一点很重要：生成样本时，我们假设从先验采初样时已经到达该不动点.

生成式 AI 文献中已有若干工作探索 OT 问题的数值解. Sinkhorn 自编码器（Patrini et al., 2020）是著名一例：它通过基于匹配两分布样本构造目标，同时训练编码器与解码器，实现从数据分布到选定先验的单步确定性映射（即推前）. 更近的用连续确定性映射（即连续归一化流，CNF）作为生成模型的尝试包括流匹配（FM；Lipman et al., 2023）及其衍生——条件流匹配（CFM）与最优传输条件流匹配（OT-CFM；Tong et al., 2023）. 我们将在第 23 章详细讨论这些方法. 所有这些模型都是学习从先验到数据分布的推前映射.

Chapter 23

连续归一化流与流匹配

承接上一章通过随机过程与 Fokker–Planck 方程视角讨论扩散模型，本章转向由确定性（而非随机）映射定义的生成模型. 我们讨论流匹配的各种形式，如条件流匹配与变分流匹配，以及最优传输理论如何提供一个速度场来求解流匹配问题. 最后，我们用一个物理系统的视角来解释：该系统需要投入最小功，才能把分布从先验变换为数据分布.

23.1 连续归一化流

确定性映射的优势是给出精确似然、无需变分界，但对模型架构施加更强约束. 这类模型由第 21 章引入的连续性方程支配：

$$\partial_\tau p(\mathbf{x},\tau) = -\mathrm{div}(p(\mathbf{x},\tau)\mathbf{v}(\mathbf{x},\tau)), \tag{1041}$$

$$\text{s.t. } p(\mathbf{x},\tau=0) = p_{\text{data}}. \tag{1042}$$

要从先验分布 p_{prior} 生成样本到数据分布 p_{data}，我们需要时间反演过程. 令 $\tilde{\tau} = \tau_f - \tau$ 为反向时间变量. 时间反演密度 $\tilde{p}(\mathbf{x},\tilde{\tau}) = p(\mathbf{x},\tau_f - \tilde{\tau})$ 按

$$\partial_{\tilde{\tau}}\tilde{p}(\mathbf{x},\tilde{\tau}) = -\mathrm{div}(\tilde{p}(\mathbf{x},\tilde{\tau})\tilde{\mathbf{v}}(\mathbf{x},\tilde{\tau})), \tag{1043}$$

$$\text{s.t. } \tilde{p}(\mathbf{x},\tilde{\tau}=0) = p_{\text{prior}}, \tag{1044}$$

演化，时间反演关系为

$$\tilde{p}(\mathbf{x},\tilde{\tau}) = p(\mathbf{x},\tau) = p(\mathbf{x},\tau_f - \tilde{\tau}), \tag{1045}$$

$$\tilde{\mathbf{v}}(\mathbf{x},\tilde{\tau}) = -\mathbf{v}(\mathbf{x},\tau) = -\mathbf{v}(\mathbf{x},\tau_f - \tilde{\tau}). \tag{1046}$$

给定任意选定的 p_{prior}，主要目标是找到确定性的时间反演速度场 $\tilde{\mathbf{v}}(\mathbf{x},\tilde{\tau}) = -\mathbf{v}(\mathbf{x},\tau)$，它在 $\tilde{\tau}=0$（对应 $\tau=\tau_f$）把 p_{prior} 映射到 $\tilde{\tau}=\tau_f$（对应 $\tau=0$）的 p_{data}.[13] 但我们既不能直接访问 $\mathbf{v}(\mathbf{x},\tau)$，也不能访问其时间反演 $-\mathbf{v}(\mathbf{x},\tau)$，因而必须从数据中学习它们.

图 23.1：原书配图位置，待补

图 57: 连续时间流的三个视角. 上图：复杂数据密度 $p_{\text{data}}(\mathbf{x})$；中图：驱动轨迹的速度场 $\mathbf{v}(\mathbf{x},\tau)$；下图：简化后的先验 $p_{\text{prior}}(\mathbf{x})$. 沿 τ 正向积分该场把数据形变为先验；反向积分该场则恢复数据用于生成.

[13] 注意这与大多数其他问题定义相反：那里只是要找 $\mathbf{v}(\mathbf{x},\tau)$ 把 p_{prior} 映射到 p_{data}.

学习速度场的第一种思路是把第 8 章的离散归一化流推广到连续时间. 该方法称为**连续归一化流**（CNF；R. Chen et al., 2018; Grathwohl et al., 2018）. CNF 不直接定义离散 NF 核心的那列参数化双射变换 $\mathbf{x}_t^\theta(\mathbf{x}_{t-1})$，而是考虑常微分方程

$$d\mathbf{x} = \mathbf{v}(\mathbf{x}, \tau)\, d\tau, \tag{1047}$$

并定义 $\mathbf{x}(\mathbf{x}_0, \tau)$ 为该 ODE 在初值 $\mathbf{x}(\mathbf{x}_0, 0) = \mathbf{x}_0$ 下的解. 换言之，$\mathbf{x}(\mathbf{x}_0, \tau)$ 就是样本 $\mathbf{x}_0$ 沿 $\mathbf{v}$ 从时刻 0 输运到时刻 τ. 图 23.1 展示了 CNF 如何通过一列连续变换把复杂数据分布变换为简单先验.

沿流的密度变化

我们现在考察沿单条轨迹（Lagrangian 视角）时概率密度 $p(\mathbf{x}, \tau)$ 如何演化. 为此考虑 $\log p(\mathbf{x}, \tau)$ 对时间的全导数：

$$\frac{d}{d\tau} \log p(\mathbf{x}, \tau) = \partial_\tau \log p(\mathbf{x}, \tau) + \frac{d\mathbf{x}}{d\tau} \cdot \nabla_{\mathbf{x}} \log p(\mathbf{x}, \tau) \tag{1048}$$

$$= \partial_\tau \log p(\mathbf{x}, \tau) + \mathbf{v}(\mathbf{x}, \tau) \cdot \nabla_{\mathbf{x}} \log p(\mathbf{x}, \tau), \tag{1049}$$

其中按 (23.7) 的 ODE 代入了 $d\mathbf{x}/d\tau = \mathbf{v}(\mathbf{x}, \tau)$.

再用连续性方程 $\partial_\tau p(\mathbf{x}, \tau) = -\mathrm{div}(p(\mathbf{x}, \tau)\mathbf{v}(\mathbf{x}, \tau))$，按乘积法则 $\mathrm{div}(f\mathbf{g}) = f\,\mathrm{div}(\mathbf{g}) + \mathbf{g} \cdot \nabla f$ 展开散度：

$$\frac{1}{p(\mathbf{x}, \tau)} \partial_\tau p(\mathbf{x}, \tau) = -\frac{1}{p(\mathbf{x}, \tau)} \mathrm{div}(p(\mathbf{x}, \tau)\mathbf{v}(\mathbf{x}, \tau)), \tag{1050}$$

$$\Longrightarrow \ \partial_\tau \log p(\mathbf{x}, \tau) = -\frac{1}{p(\mathbf{x}, \tau)} \mathrm{div}(p(\mathbf{x}, \tau)\mathbf{v}(\mathbf{x}, \tau)), \tag{1051}$$

$$\Longrightarrow \ \partial_\tau \log p(\mathbf{x}, \tau) + \mathbf{v}(\mathbf{x}, \tau) \cdot \nabla_{\mathbf{x}} \log p(\mathbf{x}, \tau) = -\mathrm{div}(\mathbf{v}(\mathbf{x}, \tau)). \tag{1052}$$

代入 (23.8)，得到

$$\frac{d}{d\tau} \log p(\mathbf{x}, \tau) = -\mathrm{div}(\mathbf{v}(\mathbf{x}, \tau)), \tag{1053}$$

表明沿轨迹的对数密度变化率由向量场 $\mathbf{v}$ 的负散度给出. 这说明密度变化来自相空间中流的压缩与膨胀，如图 58 所示.

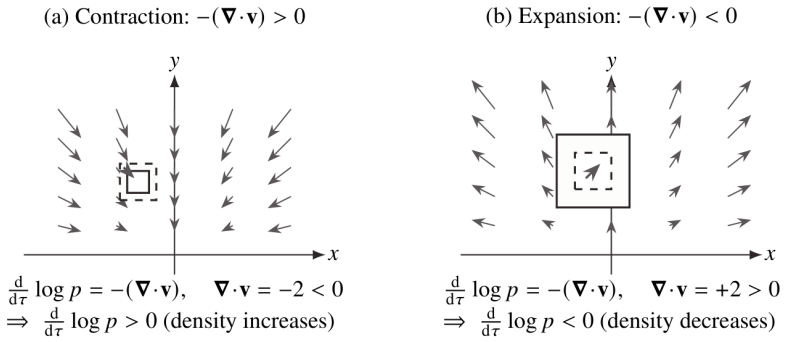


Figure 23.2 Local volume effect of divergence on log-density along characteristics.

图 58: 散度沿特征线对对数密度的局部体积效应. (a) 压缩流 $\mathbf{v} = -(x, y)$，$\nabla \cdot \mathbf{v} = -2$，故 $-(\nabla \cdot \mathbf{v}) > 0$，$d \log p / d\tau > 0$（密度增大）. (b) 膨胀流 $\mathbf{v} = (x, y)$，$\nabla \cdot \mathbf{v} = +2$，故 $-(\nabla \cdot \mathbf{v}) < 0$，$d \log p / d\tau < 0$（密度减小）.

连续时间下的变量替换

这一结果让我们推出离散归一化流中变量替换公式的连续时间版本. 为此把 (23.12) 两边从 τ_0 积分到 τ_1：

$$\int_{\tau_0}^{\tau_1} \frac{d \log p(\mathbf{x}, \tau)}{d\tau} d\tau = -\int_{\tau_0}^{\tau_1} \operatorname{div}(\mathbf{v}(\mathbf{x}, \tau))\, d\tau, \tag{1054}$$

对初值 $\mathbf{x}(\mathbf{x}_0, \tau_0) = \mathbf{x}_0$，

$$\log \frac{p(\mathbf{x}(\mathbf{x}_0, \tau_1), \tau_1)}{p(\mathbf{x}(\mathbf{x}_0, \tau_0), \tau_0)} = -\int_{\tau_0}^{\tau_1} \operatorname{div}(\mathbf{v}(\mathbf{x}(\mathbf{x}_0, \tau), \tau))\, d\tau. \tag{1055}$$

两边取指数：

$$\frac{p(\mathbf{x}(\mathbf{x}_0, \tau_1), \tau_1)}{p(\mathbf{x}(\mathbf{x}_0, \tau_0), \tau_0)} = \exp\left(-\int_{\tau_0}^{\tau_1} \operatorname{div}(\mathbf{v}(\mathbf{x}(\mathbf{x}_0, \tau), \tau))\, d\tau \right). \tag{1056}$$

这就用流 $\mathbf{x}$ 定义了 τ_1 时刻的推前密度 $p_{\tau_1} := \mathbf{x}(\cdot, \tau_1)_{\#}[p_{\tau_0}]$（$[\cdot]_{\#}$ 表示映射对测度的推前）. 对照归一化流定义与 (8.2) 中概率密度的变换法则，可见：在连续时间下考虑变换 $\mathbf{x}$，显著简化了 Jacobi 行列式的计算. 多层归一化流对每层可逆性的约束很强；而在 CNF 中，对适定的 ODE，ODE 本身构造上可逆.

训练 CNF

我们用神经网络参数化速度场 $\mathbf{v}$，并用与第 8 章训练归一化流相同的前向/反向 KL 方法来训练. 目标是学习速度场 $\mathbf{v}_\theta$，使 $\tau = \tau_0$ 时 $p_{\tau_0} = p_{\text{data}}$ 对应的推前密度

$$p_{\tau_f} := \mathbf{x}(\cdot, \tau_f)_{\#}[p_{\tau_0}] \tag{1057}$$

在 $\tau = \tau_f$ 匹配先验分布 p_{prior}（见图 23.1）. 所得模型即 CNF. 为从数据分布生成新样本，我们用时间反演关系得到速度场 $\tilde{\mathbf{v}}_\theta = -\mathbf{v}_\theta$，它在 $\tilde{\tau} = 0$ 把 p_{prior} 输运到 $\tilde{\tau} = \tau_f$ 的 p_{data}.

但该方法在训练时需要模拟前向 ODE 来评估推前密度，由于数值积分误差累积以及通过 ODE 求解器反向传播所需的内存，计算开销很大（R. Chen et al., 2018）. 近期工作因而探索无模拟（simulation-free）的 CNF 训练方法. 这类方法中最主要的一族称为**流匹配**，下面讨论.

23.2 流匹配

为避免训练时 ODE 模拟的计算开销，流匹配采取另一条路：直接用易处理的条件流对速度场做回归. 关键洞见是：我们可以构造条件流，使其边缘行为匹配期望速度场，而无需直接访问该速度场. 这种无模拟方法相对 CNF 大幅降低了计算与内存成本. 流匹配最早由 Lipman et al.（2023）提出. 本章我们紧密跟随 Tong et al.（2023）的表述，它给出了若干相关方法的统一视角.

本节我们使用与流匹配文献中相反的时间方向，但与本书其他章节一致. 若用带波浪号的变量，公式就与文献一致. 全程使用 $\tilde{\tau} = \tau_f - \tau$ 作为反向时间.

重申：我们的目标是学习反向时间速度场 $\tilde{\mathbf{v}}$，它把 $\tilde{p}(\mathbf{x}, \tilde{\tau} = 0) = p_{\text{prior}}$ 输运到 $\tilde{p}(\mathbf{x}, \tilde{\tau} = \tau_f) = p_{\text{data}}$. 从监督学习视角看，一个自然做法是直接用流匹配损失

$$\mathcal{L}_{\text{FM}} := \mathbb{E}_{\tilde{\tau} \sim \text{Unif}[0, \tau_f],\ \mathbf{x} \sim \tilde{p}(\mathbf{x}, \tilde{\tau})} \big\| \tilde{\mathbf{v}}_\theta(\mathbf{x}, \tilde{\tau}) - \tilde{\mathbf{v}}(\mathbf{x}, \tilde{\tau}) \big\|^2 \tag{1058}$$

把参数化向量场 $\tilde{\mathbf{v}}_\theta$ 回归到真实向量场 $\tilde{\mathbf{v}}$. 若能访问 $\tilde{p}(\mathbf{x}, \tilde{\tau})$ 与 $\tilde{\mathbf{v}}(\mathbf{x}, \tilde{\tau})$，这就是一种无模拟方法，训练时无需模拟 (23.7) 的 ODE. 但该目标假设我们已经知道想学习的那个量 $\tilde{\mathbf{v}}(\mathbf{x}, \tilde{\tau})$. 流匹配的关键洞见是：用易处理的条件流构造替代目标，使其边缘行为匹配期望速度场，而无需直接访问它.

条件流匹配

关键观察是：引入条件变量后，我们可以构造易处理的条件流，使其边缘匹配期望分布. 为此引入条件隐变量 $\mathbf{z}$，由我们选定的分布 $q(\mathbf{z})$ 支配；它与条件密度 $\tilde{p}(\mathbf{x}, \tilde{\tau} | \mathbf{z})$ 共同定义边缘

$$\tilde{p}(\mathbf{x}, \tilde{\tau}) = \int d\mathbf{z}\, \tilde{p}(\mathbf{x}, \tilde{\tau} | \mathbf{z})\, q(\mathbf{z}). \tag{1059}$$

若认为 $\tilde{\mathbf{v}}(\mathbf{x}, \tilde{\tau} | \mathbf{z})$ 是生成条件密度 $\tilde{p}(\mathbf{x}, \tilde{\tau} | \mathbf{z})$ 的条件向量场，即它对每个 $\mathbf{z}$ 分别求解条件连续性方程

$$\partial_{\tilde{\tau}} \tilde{p}(\mathbf{x}, \tilde{\tau} | \mathbf{z}) = -\text{div}(\tilde{p}(\mathbf{x}, \tilde{\tau} | \mathbf{z}) \tilde{\mathbf{v}}(\mathbf{x}, \tilde{\tau} | \mathbf{z})), \tag{1060}$$

那么由下式定义的边缘速度场

$$\tilde{\mathbf{v}}(\mathbf{x}, \tilde{\tau}) := \frac{1}{\tilde{p}(\mathbf{x}, \tilde{\tau})} \mathbb{E}_q(\mathbf{z}) \big[\tilde{\mathbf{v}}(\mathbf{x}, \tilde{\tau} | \mathbf{z}) \tilde{p}(\mathbf{x}, \tilde{\tau} | \mathbf{z}) \big] \tag{1061}$$

将生成边缘密度 $\tilde{p}(\mathbf{x},\tilde{\tau})$. 为验证，对 (23.17) 取时间导数：

$$\partial_{\tilde{\tau}}\tilde{p}(\mathbf{x},\tilde{\tau}) = \int d\mathbf{z}\, \partial_{\tilde{\tau}}\tilde{p}(\mathbf{x},\tilde{\tau}|\mathbf{z})\, q(\mathbf{z}). \tag{1062}$$

结合条件连续性方程 (23.18)，把积分移入散度内部：

$$\partial_{\tilde{\tau}}\tilde{p}(\mathbf{x},\tilde{\tau}) = -\int d\mathbf{z}\, \mathrm{div}(\tilde{p}(\mathbf{x},\tilde{\tau}|\mathbf{z})\tilde{\mathbf{v}}(\mathbf{x},\tilde{\tau}|\mathbf{z}))q(\mathbf{z}) \tag{1063}$$

$$= -\mathrm{div}\left(\int d\mathbf{z}\, \tilde{p}(\mathbf{x},\tilde{\tau}|\mathbf{z})\tilde{\mathbf{v}}(\mathbf{x},\tilde{\tau}|\mathbf{z})q(\mathbf{z})\right) \tag{1064}$$

$$= -\mathrm{div}(\tilde{p}(\mathbf{x},\tilde{\tau})\tilde{\mathbf{v}}(\mathbf{x},\tilde{\tau})), \tag{1065}$$

最后一步用了 (23.19). 于是得到连接边缘 $\tilde{p}$ 与边缘速度场 $\tilde{\mathbf{v}}$ 的连续性方程.

条件流匹配损失

不幸的是，(23.19) 中用于定义边缘速度场的边缘密度 $\tilde{p}(\mathbf{x},\tilde{\tau})$ 仍是一个难处理的积分. 因而无法直接评估 (23.16) 的原始流匹配目标. 但我们可以基于条件流构造一个逐样本的替代目标，使其梯度相同. 定义第二个辅助条件流匹配损失

$$\mathcal{L}_{\mathrm{CFM}} := \mathbb{E}_{\tilde{\tau}\sim\mathrm{Unif}[0,\tau_f],\ \mathbf{x}\sim\tilde{p}(\mathbf{x},\tilde{\tau}|\mathbf{z}),\ \mathbf{z}\sim q(\mathbf{z})} \left\|\tilde{\mathbf{v}}_\theta(\mathbf{x},\tilde{\tau}) - \tilde{\mathbf{v}}(\mathbf{x},\tilde{\tau}|\mathbf{z})\right\|^2, \tag{1066}$$

关键在于：学到的速度场 $\tilde{\mathbf{v}}_\theta(\mathbf{x},\tilde{\tau})$ 并不以 $\mathbf{z}$ 为条件，尽管我们回归的对象是条件场 $\tilde{\mathbf{v}}(\mathbf{x},\tilde{\tau}|\mathbf{z})$.

一个惊人结果是两个损失的梯度等价：

$$\nabla_\theta\mathcal{L}_{\mathrm{CFM}} = \nabla_\theta\mathcal{L}_{\mathrm{FM}}. \tag{1067}$$

这可把梯度拆成三项来证明：

$$\nabla_\theta\mathcal{L}_{\mathrm{CFM}} = \nabla_\theta\mathbb{E}_{\tilde{\tau},\mathbf{x},\mathbf{z}}\left[\|\tilde{\mathbf{v}}_\theta(\mathbf{x},\tilde{\tau})\|^2 - 2\tilde{\mathbf{v}}_\theta(\mathbf{x},\tilde{\tau})^\top\tilde{\mathbf{v}}(\mathbf{x},\tilde{\tau}|\mathbf{z}) + \|\tilde{\mathbf{v}}(\mathbf{x},\tilde{\tau}|\mathbf{z})\|^2\right]. \tag{1068}$$

关键观察是：在每一项中，我们都可以对 $\mathbf{z}$ 取边缘，证明对 $\mathbf{z}$ 的依赖抵消. 证明留作练习，细节见 Tong et al.（2023）.

因此，只要有易处理的条件向量场 $\tilde{\mathbf{v}}(\mathbf{x},\tilde{\tau}|\mathbf{z})$，就足以把参数化向量场 $\tilde{\mathbf{v}}_\theta(\mathbf{x},\tilde{\tau})$ 回归到边缘向量场 $\tilde{\mathbf{v}}(\mathbf{x},\tilde{\tau})$，即使该边缘速度场本身难以处理. 条件化表述通过采样少量 $(\tilde{\tau},\mathbf{z},\mathbf{x})$ 三元组做梯度更新，实现随机（小批量）学习. 虽然这是近似的，但深度学习中的随机梯度下降告诉我们，这种小批量训练是大规模成功训练模型的关键.

变分流匹配

另一种学习向量场 $\tilde{\mathbf{v}}_\theta$ 的思路，是把流匹配重写为条件轨迹端点标签上的变分推断问题，由 Eijkelboom et al.（2024）提出. 这一变分视角提供了另一种参数化，自然地把流匹配与基于分数的模型联系起来. 为此，把 (23.19) 中的边缘速度场改写为

$$\tilde{\mathbf{v}}(\mathbf{x},\tilde{\tau}) = \int d\mathbf{z}\, q(\mathbf{z})\tilde{\mathbf{v}}(\mathbf{x},\tilde{\tau}|\mathbf{z})\frac{\tilde{p}(\mathbf{x},\tilde{\tau}|\mathbf{z})}{\tilde{p}(\mathbf{x},\tilde{\tau})} \tag{1069}$$

$$= \int d\mathbf{z}\, \tilde{\mathbf{v}}(\mathbf{x},\tilde{\tau}|\mathbf{z})\tilde{p}(\mathbf{z}|\mathbf{x},\tilde{\tau}) = \mathbb{E}_{\tilde{p}(\mathbf{z}|\mathbf{x},\tilde{\tau})}[\tilde{\mathbf{v}}(\mathbf{x},\tilde{\tau}|\mathbf{z})], \tag{1070}$$

其中 $\tilde{p}(\mathbf{z}|\mathbf{x},\tilde{\tau})$ 是给定当前状态下条件变量的后验.

不直接参数化边缘 $\tilde{\mathbf{v}}_\theta$，我们等价地引入 $\mathbf{z}$ 的变分逼近 $q^\theta(\mathbf{z}|\mathbf{x},\tilde{\tau})$，并把预测器绑定到变分期望：

$$\tilde{\mathbf{v}}_\theta(\mathbf{x},\tilde{\tau}) := \int \tilde{\mathbf{v}}(\mathbf{x},\tilde{\tau}|\mathbf{z})\, q^\theta(\mathbf{z}|\mathbf{x},\tilde{\tau})\, d\mathbf{z} = \mathbb{E}_{q^\theta(\mathbf{z}|\mathbf{x},\tilde{\tau})}[\tilde{\mathbf{v}}(\mathbf{x},\tilde{\tau}|\mathbf{z})]. \tag{1071}$$

训练通过对 $\tilde{\tau}$、$\mathbf{x}$ 期望下的 KL 散度最小化进行：

$$\mathcal{L}_{\mathrm{VFM}}(\theta) := \mathbb{E}_{\tilde{\tau}\sim\mathrm{Unif}[0,\tau_f],\ \mathbf{x}\sim\tilde{p}(\mathbf{x},\tilde{\tau}|\mathbf{z}),\ \mathbf{z}\sim q(\mathbf{z})} D_{\mathrm{KL}}[\tilde{p}(\mathbf{z}|\mathbf{x},\tilde{\tau}) \,\|\, q^\theta(\mathbf{z}|\mathbf{x},\tilde{\tau})] \tag{1072}$$

$$= -\mathbb{E}_{\tilde{\tau},\mathbf{x},\mathbf{z}}[\log q^\theta(\mathbf{z}|\mathbf{x},\tilde{\tau})] + \mathrm{const}, \tag{1073}$$

与 CFM 损失类似，它用样本 $(\tilde{\tau},\mathbf{z},\mathbf{x})$（$\mathbf{z}\sim q(\mathbf{z})$，$\mathbf{x}\sim\tilde{p}(\mathbf{x},\tilde{\tau}|\mathbf{z})$）给出无模拟目标. 这一变分视角的关键好处是：学到的变分逼近自然地基于条件分布的分数参数化边缘分布的分数. 为看清这一点，注意

$$\nabla_{\mathbf{x}} \log \tilde{p}(\mathbf{x},\tilde{\tau}) = \frac{1}{\tilde{p}(\mathbf{x},\tilde{\tau})} \nabla_{\mathbf{x}} \tilde{p}(\mathbf{x},\tilde{\tau}) \tag{1074}$$

$$= \frac{1}{\tilde{p}(\mathbf{x},\tilde{\tau})} \nabla_{\mathbf{x}} \int d\mathbf{z}\, \tilde{p}(\mathbf{x},\tilde{\tau}|\mathbf{z}) q(\mathbf{z}) \tag{1075}$$

$$= \int d\mathbf{z}\, \frac{\tilde{p}(\mathbf{x},\tilde{\tau}|\mathbf{z})q(\mathbf{z})}{\tilde{p}(\mathbf{x},\tilde{\tau})} \cdot \frac{\nabla_{\mathbf{x}}\tilde{p}(\mathbf{x},\tilde{\tau}|\mathbf{z})}{\tilde{p}(\mathbf{x},\tilde{\tau}|\mathbf{z})} \tag{1076}$$

$$= \int d\mathbf{z}\, \tilde{p}(\mathbf{z}|\mathbf{x},\tilde{\tau}) \nabla_{\mathbf{x}} \log \tilde{p}(\mathbf{x},\tilde{\tau}|\mathbf{z}) \tag{1077}$$

$$\approx \mathbb{E}_{q^\theta(\mathbf{z}|\mathbf{x},\tilde{\tau})}[\nabla_{\mathbf{x}} \log \tilde{p}(\mathbf{x},\tilde{\tau}|\mathbf{z})], \tag{1078}$$

其中先对 $\mathbf{z}$ 取边缘，再用变分逼近近似真实后验. 于是变分流匹配（VFM）在基于确定性流的生成模型与基于分数估计的随机生成模型（如扩散模型）之间提供了直观桥梁. 这一视角还引出了可处理类别数据的推广（Eijkelboom et al., 2024）.

条件概率路径

建立 CFM 与 VFM 框架后，我们考察三种具体的条件概率路径选择，展示这些方法在实践中的表现. 不同选择导致不同的边缘概率路径 $\tilde{p}(\mathbf{x},\tilde{\tau})$ 与相应的边缘向量场 $\tilde{\mathbf{v}}(\mathbf{x},\tilde{\tau})$，各具不同性质. 图 59 展示了这三种条件概率路径的差异.

Different choices lead to different marginal probability paths $\tilde{p}(\mathbf{x}, \tilde{\tau})$ and corresponding marginal vector fields $\tilde{\mathbf{v}}(\mathbf{x}, \tilde{\tau})$, each with distinct properties. Figure 23.3 illustrates the differences between these three approaches to conditional probability paths.

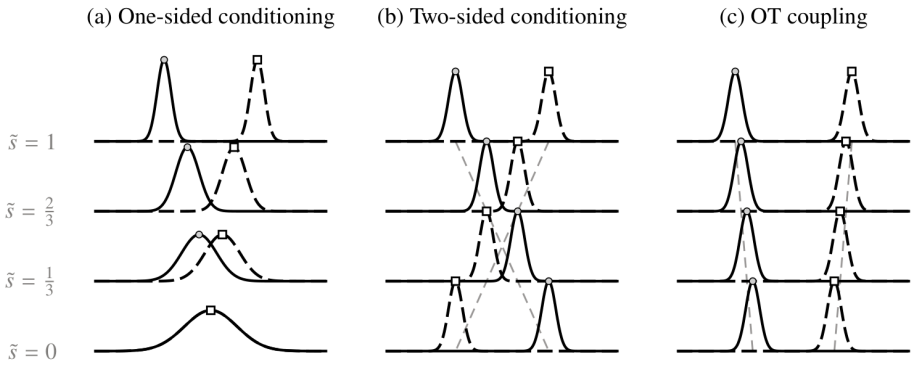


Figure 23.3 Comparison of flow matching approaches showing the evolution of probability

图 59: 流匹配方法比较，展示概率分布的演化. 时间向上增加，刻度标签为重新标度的时间 $\tilde{s} = \tilde{\tau}/\tau_f$. 带圆点标记的实线表示源/先验密度，带方块标记的虚线表示目标/数据密度. (a) 单边条件（Gaussian CFM）把两个峰合并为一个. (b) 独立耦合的双边条件展示直线交叉轨迹. (c) OT 耦合给出平行、不交叉、移动最小的路径，反映最优传输位移插值. 点虚线标出代表性传输路径. 图改编自 Tong et al.（2023）.

以上讨论对任意 $q(\mathbf{z})$、$\tilde{p}(\mathbf{x}, \tilde{\tau}|\mathbf{z})$、$\tilde{\mathbf{v}}(\mathbf{x}, \tilde{\tau}|\mathbf{z})$ 选择都成立，只要 $\tilde{\mathbf{v}}(\mathbf{x}, \tilde{\tau}|\mathbf{z})$ 生成 $\tilde{p}(\mathbf{x}, \tilde{\tau}|\mathbf{z})$. 为简化记号，下面用重标度时间 $\tilde{s} \in [0, 1]$，其中 $\tilde{s} = \tilde{\tau}/\tau_f$. 这使条件路径更易参数化，时间导数按 $d\tilde{\tau} = \tau_f d\tilde{s}$ 变换.

Gaussian CFM. 在 Gaussian CFM 中，我们特取条件变量为数据点：$\mathbf{z} = \mathbf{x}_1 \sim p_{\text{data}}$. 于是条件分布为 $q(\mathbf{z}) = p_{\text{data}}(\mathbf{z})$. 我们考虑如下形式的条件概率路径：

$$\tilde{p}(\mathbf{x}, \tilde{\tau}|\mathbf{z}) = \mathcal{G}(\mathbf{x}|\sigma\mathbf{x}_1, (\tilde{s}\sigma - \tilde{s} + 1)^2\mathbf{I}), \tag{1079}$$

其中 $\sigma \in (0, 1)$ 是超参数. 相应条件速度场为

$$\tilde{\mathbf{v}}(\mathbf{x}, \tilde{\tau}|\mathbf{z}) = \frac{1}{\sigma} \cdot \frac{\sigma\mathbf{x}_1 - (1 - \tilde{s})\mathbf{x}}{1 - (1 - \sigma)\tilde{s}}. \tag{1080}$$

我们可以通过验证 $\partial_{\tilde{\tau}}\tilde{p}(\mathbf{x}, \tilde{\tau}|\mathbf{z})$ 与 $-\text{div}(\tilde{p}(\mathbf{x}, \tilde{\tau}|\mathbf{z})\tilde{\mathbf{v}}(\mathbf{x}, \tilde{\tau}|\mathbf{z}))$ 相等，从而满足 (23.18) 的条件连续性方程，来确认这是合法的条件密度与速度场选择. 不过这相当繁琐，验证留作读者练习.

该设定把条件密度在 $\tilde{\tau} = 0$ 处的边缘限制为单位方差的标准 Gauss 分布 $\tilde{p}(\mathbf{x}, 0) = \mathcal{G}(\mathbf{0}, \mathbf{I})$，我们随后选它作为先验密度 $p_{\text{prior}}(\mathbf{x})$. 这允许像扩散模型那样高效地从先验采样. 但注意：与扩散模型不同，这是显式选择的先验分布，并非硬性要求.

该方法最早由 Lipman et al.（2023）提出，是用流匹配做生成建模的开创性工作. 若纯粹对学习生成新样本感兴趣，用简单 Gauss 先验就够了. 但若对其他辅助任务感兴

趣，例如条件生成或在生成轨迹上带最优性目标的生成，则需要不同的条件概率路径. 下面两种方法放松了 Gauss 先验约束，最终通向热力学最优路径.

独立耦合 CFM. 为摆脱 Gauss 先验约束，我们推广为让条件变量 $\mathbf{z}$ 表示一对点：$\mathbf{z} = (\mathbf{x}_0, \mathbf{x}_1)$，其中 $\mathbf{x}_0$ 是源点、$\mathbf{x}_1$ 是目标点. 我们稍后再考虑一般联合分布 $q(\mathbf{x}_0, \mathbf{x}_1)$，先考虑 $q(\mathbf{z}) = q(\mathbf{x}_0, \mathbf{x}_1) = p_{\text{prior}}(\mathbf{x}_0)p_{\text{data}}(\mathbf{x}_1)$，即先验与数据分布之间的独立耦合.

条件分布与速度场定义为

$$\tilde{p}(\mathbf{x}, \tilde{\tau}|\mathbf{x}_0, \mathbf{x}_1) = \mathcal{G}(\mathbf{x}|\tilde{s}\mathbf{x}_1 + (1-\tilde{s})\mathbf{x}_0,\, \sigma^2\mathbf{I}), \tag{1081}$$

$$\tilde{\mathbf{v}}(\mathbf{x}, \tilde{\tau}|\mathbf{x}_0, \mathbf{x}_1) = \frac{1}{\sigma\tilde{s}}(\mathbf{x}_1 - \mathbf{x}_0), \tag{1082}$$

回忆 $\tilde{s} = \tilde{\tau}/\tau_f$. 该路径在源点 $\mathbf{x}_0$ 与目标点 $\mathbf{x}_1$ 之间线性插值并叠加 Gauss 噪声，每条条件轨迹上速度恒定.

$\tilde{\tau}$ 时刻的边缘为

$$\tilde{p}(\mathbf{x}, \tilde{\tau}) = \iint d\mathbf{x}_0 d\mathbf{x}_1\, \tilde{p}(\mathbf{x}, \tilde{\tau}|\mathbf{x}_0, \mathbf{x}_1) q(\mathbf{x}_0, \mathbf{x}_1) \tag{1083}$$

$$= \iint d\mathbf{x}_0 d\mathbf{x}_1\, \mathcal{G}(\mathbf{x}|\tilde{s}\mathbf{x}_1 + (1-\tilde{s})\mathbf{x}_0, \sigma^2\mathbf{I})\, p_{\text{prior}}(\mathbf{x}_0)p_{\text{data}}(\mathbf{x}_1). \tag{1084}$$

在 $\tilde{\tau} = 0$ 处求值，它对应先验分布与 Gauss 的卷积（$(f * g)(\mathbf{x}) = \int f(\mathbf{x} - \mathbf{y})g(\mathbf{y})\, d\mathbf{y}$ 表示卷积）：

$$\tilde{p}(\mathbf{x}, 0) = \iint d\mathbf{x}_0 d\mathbf{x}_1\, \mathcal{G}(\mathbf{x}|\mathbf{x}_0, \sigma^2\mathbf{I})\, p_{\text{prior}}(\mathbf{x}_0)p_{\text{data}}(\mathbf{x}_1) \tag{1085}$$

$$= \int d\mathbf{x}_0\, \mathcal{G}(\mathbf{x}|\mathbf{x}_0, \sigma^2\mathbf{I})\, p_{\text{prior}}(\mathbf{x}_0) = (p_{\text{prior}} * \mathcal{G}(\mathbf{0}, \sigma^2\mathbf{I}))(\mathbf{x}). \tag{1086}$$

类似地，$\tilde{\tau} = \tau_f \Leftrightarrow \tilde{s} = 1$ 时，$\tilde{p}(\mathbf{x}, \tau_f) = (p_{\text{data}} * \mathcal{G}(\mathbf{0}, \sigma^2\mathbf{I}))(\mathbf{x})$. 当 $\sigma \to 0$，边缘速度场 $\tilde{\mathbf{v}}(\mathbf{x}, \tilde{\tau})$ 于是把先验分布的样本映射到目标分布. 这是一个关键限制：与 Gaussian CFM 不同，除端点外，我们无法把边缘路径 $\tilde{p}(\mathbf{x}, \tilde{\tau})$ 写成闭式. 对任意非端点时刻 $\tilde{\tau}$，我们仍需对源样本与目标样本做难处理的积分.

重要的是：尽管条件概率路径是 Gauss 的，先验本身不必是 Gauss. 对 $\mathbf{x}_0$ 的条件化允许把流匹配推广到任意源分布与目标分布.

我们还需验证 (23.32)、(23.33) 是满足条件连续性方程的合法条件密度与速度场对. 幸运的是，若定义

$$\xi(\tilde{s}) = \tilde{s}\mathbf{x}_1 + (1-\tilde{s})\mathbf{x}_0, \quad \frac{d\xi}{d\tilde{s}} = \frac{1}{\sigma}(\mathbf{x}_1 - \mathbf{x}_0), \tag{1087}$$

且

$$\partial_{\tilde{\tau}}\tilde{p}(\mathbf{x}, \tilde{\tau}|\mathbf{x}_0, \mathbf{x}_1) = \frac{1}{\sigma^2}(\mathbf{x} - \xi(\tilde{s}))^\top(\mathbf{x}_1 - \mathbf{x}_0), \tag{1088}$$

注意 $\tilde{\mathbf{v}}$ 在空间中为常数（只依赖 $\mathbf{x}_0, \mathbf{x}_1$，不依赖 $\mathbf{x}$），故 $\operatorname{div}(\tilde{\mathbf{v}}) = 0$，于是

$$\operatorname{div}(\tilde{p}(\mathbf{x}, \tilde{\tau}|\mathbf{x}_0, \mathbf{x}_1)\tilde{\mathbf{v}}(\mathbf{x}, \tilde{\tau}|\mathbf{x}_0, \mathbf{x}_1)) = \nabla\tilde{p}(\mathbf{x}, \tilde{\tau}|\mathbf{x}_0, \mathbf{x}_1) \cdot \tilde{\mathbf{v}}(\mathbf{x}, \tilde{\tau}|\mathbf{x}_0, \mathbf{x}_1) \tag{1089}$$

$$= -\frac{1}{\sigma^2}(\mathbf{x} - \xi(\tilde{s}))^\top(\mathbf{x}_1 - \mathbf{x}_0), \tag{1090}$$

确认 (23.18) 成立.

最优传输 CFM. 独立耦合平等对待所有源–目标对，但我们可以做得更好：优先配对相近的点，最小化传输代价. 这就是最优传输耦合. 我们进一步把独立耦合 CFM 推广到不可分解的联合分布 $q(\mathbf{z}) = q(\mathbf{x}_0, \mathbf{x}_1)$. 一个特别有趣的选择是

$$q(\mathbf{z}) := \gamma(\mathbf{x}_0, \mathbf{x}_1) = p_{\text{prior}}(\mathbf{x}_0)\gamma(\mathbf{x}_1|\mathbf{x}_0), \tag{1091}$$

其中 γ 是求解最优传输问题（最小化 p_{prior} 与 p_{data} 间期望传输代价）的确定性可逆 Monge 映射.

有趣的是：即使条件密度路径 $\tilde{p}(\mathbf{x}, \tilde{\tau}|\mathbf{z})$ 不变，改变耦合 $q(\mathbf{z})$ 也会改变边缘密度路径 $\tilde{p}(\mathbf{x}, \tilde{\tau})$. 用 OT 耦合 $\gamma(\mathbf{x}_0, \mathbf{x}_1)$ 与 (23.32) 的条件密度，$\tilde{\tau}$ 时刻的边缘为

$$\begin{aligned}
\tilde{p}(\mathbf{x}, \tilde{\tau}) &= \iint d\mathbf{x}_0 d\mathbf{x}_1 \, \mathcal{G}(\mathbf{x}|\tilde{s}\mathbf{x}_1 + (1-\tilde{s})\mathbf{x}_0, \sigma^2\mathbf{I})\gamma(\mathbf{x}_0, \mathbf{x}_1) && (1092)\\
&= \iint d\mathbf{x}_0 d\mathbf{x}_1 \, \mathcal{G}(\mathbf{x}|\tilde{s}\mathbf{x}_1 + (1-\tilde{s})\mathbf{x}_0, \sigma^2\mathbf{I})p_{\text{prior}}(\mathbf{x}_0)\gamma(\mathbf{x}_1|\mathbf{x}_0) && (1093)\\
&= \iint d\mathbf{x}_0 d\mathbf{x}_1 \, \mathcal{G}(\mathbf{x}|\tilde{s}\mathbf{x}_1 + (1-\tilde{s})\mathbf{x}_0, \sigma^2\mathbf{I})p_{\text{prior}}(\mathbf{x}_0)\delta(\mathbf{x}_1 - T_\gamma(\mathbf{x}_0)) && (1094)\\
&= \int d\mathbf{x}_0 \, \mathcal{G}(\mathbf{x}|\tilde{s}T_\gamma(\mathbf{x}_0) + (1-\tilde{s})\mathbf{x}_0, \sigma^2\mathbf{I})p_{\text{prior}}(\mathbf{x}_0), && (1095)
\end{aligned}$$

其中 $T_\gamma : \mathbf{x}_0 \mapsto \mathbf{x}_1$ 是 Monge 映射（确定性最优传输映射）.

对独立耦合，我们能在 $\tilde{\tau} = 0$ 与 $\tilde{\tau} = \tau_f$ 把边缘密度路径写成简单卷积；在中间时刻 $\tilde{\tau}$ 仍受限于必须对源样本与目标样本取边缘. 现在用 OT 耦合后，(23.39) 给出任意时刻 $\tilde{\tau}$ 下边缘密度路径的卷积表达式：

$$\tilde{p}(\mathbf{x}, \tilde{\tau}) = ([\mu_{\tilde{s}}]_{\#} p_{\text{prior}} * \mathcal{G}(\mathbf{0}, \sigma^2\mathbf{I}))(\mathbf{x}), \tag{1096}$$

其中 $\mu_{\tilde{s}}(\mathbf{x}) = \mu(\mathbf{x}, \tilde{s}) = \tilde{s}T_\gamma(\mathbf{x}) + (1-\tilde{s})\mathbf{x}$ 是位移插值，$[\mu_{\tilde{s}}]_{\#}$ 表示经映射 $\mu_{\tilde{s}}$ 的推前. 当 $\sigma \to 0$, 它收敛为 $[\mu_{\tilde{s}}]_{\#} p_{\text{prior}}(\mathbf{x})$, 即 McCann 插值（Gangbo and McCann, 1996; McCann, 1997）.

到目前为止我们假设 Monge 映射已给出. 但求解 OT 解本身就是一个不平凡问题. 有趣的是，Benamou 与 Brenier（2000）证明 Monge 映射可通过求解一个变分流体力学问题得到，这在第 22 章已讨论. 这就在流匹配与求解 OT 问题之间建立了联系，下面讨论.

下面我们证明：若假设 (23.32)、(23.33) 对边缘密度与速度场成立，且进一步假设映射 $T_\gamma(\cdot)$ 可逆，则它最小化定义 Benamou–Brenier 动力学流体力学 OT 描述的动能泛函.

求解动力学 OT 问题. 要证明这一点需考虑两件事. 第一，必须证明：对条件密度 (23.32)、条件速度场 (23.33) 与耦合 $\gamma(\mathbf{x}_0, \mathbf{x}_1)$，相应的边缘密度路径 $\tilde{p}(\mathbf{x}, \tilde{\tau})$ 与边缘速度场 $\tilde{\mathbf{v}}(\mathbf{x}, \tilde{\tau})$ 满足连续性方程，这是它们成为动力学 OT 问题解的要求. 证明思路：在第 23.3.3 节中，我们已对独立耦合情形证明了条件密度路径 $\tilde{p}(\mathbf{x}, \tilde{\tau}|\mathbf{x}_0, \mathbf{x}_1)$ 与条件速度场 $\tilde{\mathbf{v}}(\mathbf{x}, \tilde{\tau}|\mathbf{x}_0, \mathbf{x}_1)$ 满足条件连续性方程. 由于我们条件化在 $\mathbf{z} = \{\mathbf{x}_0, \mathbf{x}_1\}$ 上，OT 耦合情形的推导相同. 再用 (23.22)，即可推出边缘密度路径 $\tilde{p}$ 与边缘速度场 $\tilde{\mathbf{v}}$ 也满足连续性方程.

第二件事稍复杂：必须证明边缘密度路径 $\tilde{p}$ 与相应速度场 $\tilde{\mathbf{v}}$ 在 OT 解定义的路径上也最小化动能：

$$\tilde{\mathbf{v}}(\mathbf{x},\tilde{\tau}) = \arg\min_{\tilde{\mathbf{v}}'(\mathbf{x},\tilde{\tau}):\ \partial_{\tilde{\tau}}\tilde{p}=-\mathrm{div}(\tilde{p}\tilde{\mathbf{v}}')} \int_0^{\tau_f} d\tilde{\tau} \int d\mathbf{x}\, \tilde{p}(\mathbf{x},\tilde{\tau})\|\tilde{\mathbf{v}}'(\mathbf{x},\tilde{\tau})\|^2. \tag{1097}$$

为此先推导 OT 耦合对应的边缘速度场 $\tilde{\mathbf{v}}(\mathbf{x},\tilde{\tau})$. 注意用 Monge 映射 T_γ 后，条件速度场 $\tilde{\mathbf{v}}(\mathbf{x},\tilde{\tau}|\mathbf{x}_0,\mathbf{x}_1)$ 只依赖 $\mathbf{x}_0$，可简化写为

$$\tilde{\mathbf{v}}(\mathbf{x},\tilde{\tau}|\mathbf{x}_0,\mathbf{x}_1) = \frac{1}{\sigma}(\mathbf{x}_1-\mathbf{x}_0) = \frac{1}{\sigma}(T_\gamma(\mathbf{x}_0)-\mathbf{x}_0) = \hat{\mathbf{v}}(\mathbf{x}_0), \tag{1098}$$

其中引入记号 $\hat{\mathbf{v}}(\mathbf{x}_0) := (T_\gamma(\mathbf{x}_0)-\mathbf{x}_0)/\tau_f$. 类似地，

$$\tilde{p}(\mathbf{x},\tilde{\tau}|\mathbf{x}_0,\mathbf{x}_1) = \tilde{p}(\mathbf{x},\tilde{\tau}|\mathbf{x}_0,T_\gamma(\mathbf{x}_0)) = \tilde{p}(\mathbf{x},\tilde{\tau}|\mathbf{x}_0). \tag{1099}$$

由 (23.19) 中边缘速度场的定义，把期望改写为

$$\mathbb{E}_{q(\mathbf{x}_0,\mathbf{x}_1)}[\tilde{\mathbf{v}}(\mathbf{x},\tilde{\tau}|\mathbf{x}_0,\mathbf{x}_1)\tilde{p}(\mathbf{x},\tilde{\tau}|\mathbf{x}_0,\mathbf{x}_1)] = \iint d\mathbf{x}_0 d\mathbf{x}_1\, \tilde{\mathbf{v}}(\mathbf{x},\tilde{\tau}|\mathbf{x}_0,\mathbf{x}_1)\tilde{p}(\mathbf{x},\tilde{\tau}|\mathbf{x}_0,\mathbf{x}_1)\gamma(\mathbf{x}_0,\mathbf{x}_1) \tag{1100}$$

$$= \iint d\mathbf{x}_0 d\mathbf{x}_1\, \hat{\mathbf{v}}(\mathbf{x}_0)\tilde{p}(\mathbf{x},\tilde{\tau}|\mathbf{x}_0)\gamma(\mathbf{x}_1|\mathbf{x}_0)p_{\text{prior}}(\mathbf{x}_0) \tag{1101}$$

$$= \int d\mathbf{x}_0\, \hat{\mathbf{v}}(\mathbf{x}_0)\tilde{p}(\mathbf{x},\tilde{\tau}|\mathbf{x}_0)p_{\text{prior}}(\mathbf{x}_0) \tag{1102}$$

$$= \int d\mathbf{x}_0\, \hat{\mathbf{v}}(\mathbf{x}_0)\mathcal{G}(\mathbf{x}|\xi(\mathbf{x}_0,\tilde{\tau}),\sigma^2\mathbf{I})p_{\text{prior}}(\mathbf{x}_0). \tag{1103}$$

代入 (23.19) 的边缘速度场定义：

$$\tilde{\mathbf{v}}(\mathbf{x},\tilde{\tau}) = \frac{1}{\tilde{p}(\mathbf{x},\tilde{\tau})}\mathbb{E}_q[\tilde{\mathbf{v}}\tilde{p}] \tag{1104}$$

$$= \frac{1}{\tilde{p}(\mathbf{x},\tilde{\tau})}\int d\mathbf{x}_0\, \hat{\mathbf{v}}(\mathbf{x}_0)\mathcal{G}(\mathbf{x}|\xi(\mathbf{x}_0,\tilde{\tau}),\sigma^2\mathbf{I})p_{\text{prior}}(\mathbf{x}_0) \tag{1105}$$

$$= \int d\mathbf{x}_0\, \hat{\mathbf{v}}(\mathbf{x}_0)\tilde{p}(\mathbf{x}_0|\mathbf{x},\tilde{\tau}), \tag{1106}$$

其中 $\tilde{p}(\mathbf{x}_0|\mathbf{x},\tilde{\tau})$ 是给定当前状态下源点的后验. 当 $\sigma\to 0$，后验集中：$\tilde{p}(\mathbf{x}_0|\mathbf{x},\tilde{\tau}) \to \delta(\mathbf{x}_0-\mu^{-1}(\mathbf{x},\tilde{\tau}))$. 于是

$$\tilde{\mathbf{v}}(\mathbf{x},\tilde{\tau}) = \int d\mathbf{x}_0\, \hat{\mathbf{v}}(\mathbf{x}_0)\delta(\mathbf{x}_0-\mu^{-1}(\mathbf{x},\tilde{\tau})) \tag{1107}$$

$$= \hat{\mathbf{v}}(\mu^{-1}(\mathbf{x},\tilde{\tau})) \tag{1108}$$

$$= \frac{1}{\sigma}\left(T_\gamma(\mu^{-1}(\mathbf{x},\tilde{\tau})) - \mu^{-1}(\mathbf{x},\tilde{\tau})\right), \tag{1109}$$

对应于沿初末分布之间的直线、以恒定速度移动样本. 这正是最小化动能的速度场，因而我们可以得出结论：有了可逆映射 $T_\gamma(\cdot)$ 与 (23.32)、(23.33) 定义的条件密度与速度场，CFM 学到的速度场 $\tilde{\mathbf{v}}_\theta(\mathbf{x},\tilde{\tau})$ 求解的是 Benamou–Brenier 动力学 OT 问题.

在推导中，我们似乎除可逆性外完全没用 Monge 映射 $T_\gamma(\cdot)$ 的性质. 证明看起来只依赖把所有初始分布的点以恒定速度沿直线映射到末分布. 但要找到这样一个可逆映射（即直线不交叉）绝非易事，事实上它就求解了 OT 问题. 求解静态 OT 问题以得到该映射计算代价高昂，时间复杂度关于样本数呈 $O(n^3)$，内存 $O(n^2)$（Villani, 2003, 2008）.

实践中我们有一批数据点. 寻找该映射的一种实用算法是：也从先验中采等量的点，按 Sinkhorn 算法配对. 具体算法见 Peyré 与 Cuturi（2019）. 然后用直线连接这些配对点，假设它们速度恒定. 再用这些直线，通过最小化 (23.23) 的损失来学习边缘速度场 $\tilde{\mathbf{v}}_\theta(\mathbf{x}, \tilde{\tau})$. 这就给出了一个把先验中任意点映射到数据分布的实用流程.

实践中，对所有数据点求解 OT 匹配（例如用 Sinkhorn 算法）可能慢得不可接受. 通常配合小批量方法，只对批内样本求解匹配问题. 实验表明即使小批量也能取得好性能.

最小耗散功条件流匹配. 虽然理论上有趣，但“为什么”我们要学习一个求解 Benamou–Brenier 动力学 OT 问题的速度场 $\tilde{\mathbf{v}}_\theta$，答案并不显然. 严格地说，只为生成新样本 $\mathbf{x}$，任何以 p_{prior} 为初始分布的条件密度与速度场对都够用. OT–CFM 解提供的直线积分线确有一些数值好处，例如所需积分步数更少，但并不直接提升样本质量.

只有当我们开始考虑那些不仅关心终端边缘、也关心所走路径的任务时，在采样流程中使用最优传输路径的好处才显现出来. 这绝非巧合，正是随机热力学领域的同一类考虑. 在此语境下，CFM 中使用最优传输路径可与上一章关于功耗散最小化与反绝热驱动的讨论漂亮地呼应起来.

学习求解 Benamou–Brenier 动力学 OT 问题的速度场 $\tilde{\mathbf{v}}_\theta$ 时，用 OT-CFM 采样的轨迹耗散功最小. 因而它是使系统总熵增加最少的解，也就使我们关于系统丢失的信息最少. 一个引人入胜的洞见是：热产生最小的解，也是给出最佳（例如方差最低）估计量的解，例如估计自由能差时（Geiger and Dellago, 2010）. 这从 Jarzynski 等式很容易理解：路径上功的涨落正是计算自由能差时方差的来源.

条件速度场、密度与耦合的其他组合并不提供这一保证. 这些方法学到的速度场仍描述反绝热驱动协议，但耗散更多功. 与反绝热驱动类似的控制协议曾用于受控 Monte Carlo 扩散采样器（Vargas et al., 2024），以改善采样性能、降低计算边缘对数似然（即自由能）时的方差. 随机热力学的原理也曾被 Ikeda et al.（2025）用于改善扩散采样器性能.

Part

IV

结语 Epilogue

Chapter 24

自由能才是你所需要的一切

恭喜你走到了结尾！希望你抓住了本书的主旨：在非平衡热力学（或其子领域**随机热力学**）与概率机器学习（及其如今被称为**生成式 AI** 的子领域）之间，存在着非凡的联系. 用来生成 “狗狗在雪中玩耍” 美丽视频的数学，与描述固体、液体、气体等非平衡热力学系统的数学，是同一套.

这一联系的核心，是变分自由能——在 ML 中也称为（负的）证据下界. 在物理中，变分自由能是平衡自由能的推广，用于描述非平衡系统. 该变分自由能为平衡自由能提供上界. 事实上，物理系统可以理解为始终沿自由能最速下降方向下降. 在概率（生成）ML 中，我们做推断或学习时同样最小化自由能. 由此我们发现了物理量（功、热、熵产生）与统计/ML 中 EM 算法之间的深刻联系.

我们想特别强调熵在两套理论中的角色. 在物理中，熵可被视为系统的本体论属性. 但我们想论证（与许多人一道，最著名的是 E. T. Jaynes）：熵应被解读为关于系统的 “丢失信息” 或 “知识缺失”. 这与概率和熵在 AI 中的角色完全吻合：它们是处理关于系统细节信息缺失的数学工具. 熵量化了我们丢失了多少可访问的信息. 一个拥有更先进测量工具、能追踪单个粒子的外星文明，其世界描述中的熵或许能降到接近零！

但这一联系还要更深. 基于扩散的生成式 AI 模型可视为：在编码器方向上朝平衡演化，同时在外力控制下于生成、解码器方向远离平衡. 我们相信这两个领域的数学超越了这些具体应用，可以富有成效地把生成式 AI 视为非平衡热力学的一种形式. 在最深层次上，二者都可视为信息处理系统，即 J. A. Wheeler 那句名言所说的 “it from bit”. 在这个意义上，我们相信 2024 年颁给 Hopfield 与 Hinton 的诺贝尔物理学奖再恰当不过.



Figure 24.1 A conceptual overview of how free energy unifies different areas of probabilistic

图 60: 自由能统一概率机器学习不同领域的概念总览

待最小化的自由能目标表达式为

$$D_{\mathrm{KL}}[Q\|P] + F[P, \mathbf{x}] = \mathcal{F}(Q, P, \mathbf{x}) = \mathbb{E}_Q[-\log(P(\mathbf{x}|\mathbf{z})P(\mathbf{z}))] - \mathcal{S}[Q],$$

其中 Q、P 为 Markov 链：

$$Q(\mathbf{z}_{0:t_f}) = Q_0(\mathbf{z}_0)\prod_{t=1}^{t_f} F_{t|t-1}(\mathbf{z}_t|\mathbf{z}_{t-1}), \quad P(\mathbf{z}_{0:t_f}) = P_{t_f}(\mathbf{z}_{t_f})\prod_{t=1}^{t_f} B_{t-1|t}(\mathbf{z}_{t-1}|\mathbf{z}_t).$$

可用该框架描述的各类 ML 方法为：(1) 变分推断与 MCMC：优化变分分布、设计高效采样器；(2) 最优控制与 GFlowNets：把控制问题映射为概率推断与流平衡；(3) Schrödinger 桥与最优传输：在边缘约束下最小化前向与反向过程之间的 KL 散度；(4) 扩散模型与归一化流：通过分数匹配与变量替换学习生成模型.

除扩散模型外，本书还把 ML 社区中许多不同工具与非平衡热力学概念联系起来，涵盖 Schrödinger 桥、最大 caliber 方法、最优传输理论、Markov 链 Monte Carlo 采样方法、变分学习、归一化流、基于流的模型、最优控制理论、强化学习与 GFlowNet. 它们在核心处都可用一个编码器 Markov 链 Q 与一个解码器 Markov 链 P 来描述. 前者 Q 沿自然的、物理的前向方向运行，熵增；P 沿反向的、受控的方向运行，通过去噪动力学降低熵、从噪声中创造结构.

所有这些方法间的差异，可归结为我们对这些分布所做的某些选择. 例如：我们是假设能写出分布 Q_0 的表达式，还是只假设能访问数据？我们是从 $t = t_f$ 出发反向迭代

参数化解码器（生成模型），还是像策略那样按同一方向参数化（最优控制方法）？我们把动力学视为随机（扩散）还是确定性（流）？我们是通过从数据学习、还是从奖励函数学习（强化）来优化力以引导生成模型？统一所有这些方法的，是这两条互为近似逆的 Markov 链，以及贯穿其下的自由能目标概念. 本书确实是一部 “自由能的传说”.

随机热力学理论的一个标志性结果是涨落定理：即使在非平衡态，热力学量沿样本路径的指数平均也满足精确关系. 例如，著名的 Jarzynski 等式把总（负）功沿样本路径的指数平均与两分布间（负）自由能差的指数联系起来（Jarzynski, 1997）. 该等式事实上等价于 Radford Neal 在 MCMC 采样背景下发展的退火重要性采样所用的等式. Crooks 涨落定理更一般，它把熵产生的期望概率与底层物理过程的不可逆性联系起来（Crooks, 1999）. 这涉及科学家（如 Gibbs、Boltzmann）之间非常深刻的哲学讨论——即所谓 Loschmidt 佯谬：为什么我们观察到世界演化方向上的不对称——我们从不会看到一个鸡蛋自己复原. 若底层物理定律实际上是时间反演对称的，为什么在粗粒化层次上，我们会看到由不断增大的熵所定义的时间方向？虽然涨落定理似乎给出了答案，Loschmidt 认为问题并未真正解决. 不知为何，导致我们所喜欢（或能够）测量的那类变量熵增的初态概率，远大于导致熵减方向演化的初态概率. 有人论证这种不对称必定已编码在大爆炸时刻宇宙的初态中. 但若有更深理论能对宇宙中信息处理观察者的角色建模，我们也不会惊讶.

与时间反演相关的是本书讨论的第二个基本概念：“平衡方程”. 细致平衡是其中最简单的一种，它陈述任意两态之间的概率流相等（Metropolis et al., 1953）. 它可用于推导涨落定理，也是设计 MCMC 算法的关键. 这些方程的一种推广只要求分布的不变性（或平稳性），其中前向与反向核可以不同，但共享同一不变分布. 这把涨落定理推广到该情形，也导出了比基于细致平衡的 MCMC 混合更快的不可逆 MCMC 方法. 不可逆核甚至可用于完全确定性系统，最终是连续性方程的一种反映——概率应当守恒. 术语上很容易混淆：基于不可逆核的时间反演 Markov 链仍遵循熵增的物理动力学，并与前向动力学有相同平衡分布. 这就像在镜子里看动力学，所有速度都反向. 而由反向转移 B 生成的时间反演动力学 P（见图 24.1）是非物理的，倾向于降低熵. 它对系统执行去噪，而这只有在外（学习到的）力控制下才可能发生.

我们承认本书未覆盖一些相当重要的理论. 特别地，你可能注意到我们完全回避了随机微积分. 这是 “随机微分方程” 背后的理论，例如 Brown 运动与 Langevin 方程，需要 Itô 微积分. 它描述经历碰撞所导致随机动力学的粒子在 $\Delta\tau \to 0$ 时如何取极限. 我们正在写另一本书（或本书的新版本），用这套语言描述随机热力学. 那将涉及随机单条样本路径的连续时间描述与路径积分理论. 本书中，我们用离散时间增量描述随机热力学——避开了 $\Delta\tau \to 0$ 这些讨厌的极限——既在概率密度层面，也在单条样本路径层面. 此外，在最后几章我们还覆盖了时间演化概率密度描述的（平均场）连续时间极限（但不覆盖单条样本路径）. 与单条样本路径不同，概率密度可假设始终光滑，因而 $\Delta\tau \to 0$ 的极限是标准的.

这勾勒出一幅有趣图景：我们可用四种不同数学框架描述随机热力学：离散时间下的概率分布层面（Markov 链）、连续时间下的概率分布层面（Fokker–Planck 偏微分方程）、离散时间下的单条样本路径层面（如 MCMC 类采样算法），以及连续时间下的单条样本路径层面（随机微分方程与 Brown 运动）. 此外还有路径积分表述，它为连续时间下的单条样本路径分配概率.

离散时间与连续时间框架各有局限：离散时间动力学通过把时间切成有限增量隐含近似，但能描述任意（非 Gauss）动力学；连续时间动力学通常限于 Gauss 噪声（如 Brown 运动）. 当我们思考 ML 中热力学系统的概率或单样本时，概率层面与路径层面描述之间存在有趣的平行. 例如，VAE 中的重参数化技巧可视为从概率分布到样本路径的转移. 注意这也与 Eulerian 视角（思考时间演化的概率分布 $\rho(\zeta, t)$）和 Lagrangian 视角（思考演化的单条样本路径、把其概率描述为 $\rho(\zeta(t))$）之间的区分有关.

本书所有方法都假设 “无记忆” 动力学，这由碰撞发生的时间尺度远短于分子动力学时间尺度这一事实所隐含. 但这是一个并非在所有情形下都成立的近似. 事实上，当 “时间尺度分离” 不发生时，需要给所研究系统的动力学加上记忆. 有记忆的推广（例如对 Langevin 方程）确实存在，但本书未处理. 在 ML 中，积分掉自由度时出现记忆的原因众所周知：当对影响多个下游变量的变量取边缘时，这些下游变量变得相关.

物理定律在其基本（经典）层次上是二阶的. 这意味着我们有位置与动量，粒子遵循 Hamilton 运动方程. 全书我们用记号 $\zeta = (\xi, \eta)$ 表示要在完整相空间中发展理论. 但有时我们假设过阻尼动力学，即速度变化的时间尺度远短于位置变化的时间尺度. 此时可令 $\dot{\eta} = 0$，得到位置变量上常见的漂移–扩散 SDE. 随机热力学文献中许多结果都在该过阻尼极限下导出（更复杂的欠阻尼系统见 SI 部分）.

你可能注意到在物理章节中我们总在谈热浴及其温度，但讨论 ML 时这些显著缺席. 确实，在随机热力学中我们额外假设隐自由度耦合到一个无限大热浴，与之交换能量. 这并非系统部分信息被积分（或边缘）掉时最一般的问题——例如当那个非常大的热浴不存在时. ML 表述在这个意义上稍更一般，但我们发现变分自由能、功、热与熵这些概念仍然有意义地适用.

我们相信自己只看到了冰山一角. 2024 年该领域已获两项诺贝尔奖，加之其数学上的优雅以及在药物研发与可持续发展中的重要应用，我们预计该领域将快速成长. 两个植根于或许更基础的信息处理理论的非常不同的领域，已开始相互滋养：基于物理原理开发新的 ML 方法，新的 ML 工具又被用来加速物理科学. 希望我们让你尝到了这个优雅新领域的味道，也希望这已足够诱人，激起了你的兴趣.

[1] R. Abbott, M. S. Albergo, A. Botev, D. Boyda, K. Cranmer, D. C. Hackett, G. Kanwar, A. G. D. G. Matthews, S. Racanière, A. Razavi, D. J. Rezende, F. Romero-López, P. E. Shanahan, and J. M. Urban, Normalizing flows for lattice gauge theory in arbitrary space-time dimension, ArXiv preprint 2305.02402, 2023.

[2] M. S. Albergo, D. Boyda, D. C. Hackett, G. Kanwar, K. Cranmer, S. Racanière, D. J. Rezende, and P. E. Shanahan, Introduction to normalizing flows for lattice field theory, ArXiv preprint 2101.08176, 2021.

[3] B. D. Anderson, Reverse-time diffusion equation models, Stochastic Processes and their Applications 12(3):313–326, 1982.

[4] M. Arbel, A. G. de G. Matthews, and A. Doucet, Annealed flow transport Monte Carlo, in Proc. of ICML, PMLR vol. 139, pp. 318–330, 2021.

[5] E. Aurell, K. Gawędzki, C. Mejía-Monasterio, R. Mohayaee, and P. Muratore-Ginanneschi, Refined second law of thermodynamics for fast random processes, J. Stat. Phys. 147(3):487–505, 2012.

[6] J. L. Ba, J. R. Kiros, and G. E. Hinton, Layer normalization, ArXiv preprint 1607.06450, 2016.

[7] M. J. Beal, Variational Algorithms for Approximate Bayesian Inference, PhD thesis, University College London, 2003.

[8] R. E. Bellman, Dynamic Programming, Princeton University Press, 1957.

[9] J.-D. Benamou and Y. Brenier, A computational fluid mechanics solution to the Monge–Kantorovich mass transfer problem, Numer. Math. 84:375–393, 2000.

[10] E. Bengio, M. Jain, M. Korablyov, D. Precup, and Y. Bengio, Flow network based generative models for non-iterative diverse candidate generation, in Adv. Neural Inf. Process. Syst., vol. 34, 2021.

[11] Y. Bengio, S. Lahlou, T. Deleu, E. J. Hu, M. Tiwari, and E. Bengio, GFlowNet Foundations, ArXiv preprint 2111.09266, 2023.

[12] C. H. Bennett, Efficient estimation of free energy differences from Monte Carlo data, J. Computat. Phys. 22(2):245–268, 1976.

[13] C. H. Bennett, The thermodynamics of computation – A review, Int. J. Theor. Phys. 21(12):905–940, 1982.

[14] E. Bernton, J. Heng, A. Doucet, and P. E. Jacob, Schrödinger bridge samplers, ArXiv preprint 1912.13170, 2019.

[15] C. M. Bishop, Pattern Recognition and Machine Learning, Springer, 2006.

[16] D. M. Blei, A. Kucukelbir, and J. D. McAulife, Variational inference: A review for statisticians, J. Amer. Stat. Assoc. 112(518):859–877, 2017.

[17] L. Boltzmann, Über die Beziehung zwischen dem zweiten Hauptsatze der mechanischen Wärmetheorie und der Wahrscheinlichkeitsrechnung respective den Sätzen über das Wärmegleichgewicht, Wiener Berichte 2:373–435, 1877.

[18] L. Boltzmann, Entgegnung auf die wärmetheoretischen Betrachtungen des Hrn. E. Zermelo, Ann. der Phys. 293(4):773–784, 1896.

[19] S. Boyd and L. Vandenberghe, Convex Optimization, Cambridge University Press, 2004.

[20] M. Braun and J. McAulife, Variational inference for large-scale models of discrete choice, J. Amer. Stat. Assoc. 105(489):324–335, 2010.

[21] S. Brooks, Markov chain Monte Carlo method and its application, J. R. Stat. Soc. D 47(1):69–100, 1998.

[22] S. G. Brush, The Kind of Motion We Call Heat: A History of the Kinetic Theory of Gases in the 19th Century, vol. 1–2, North-Holland, 1976.

[23] H. B. Callen, Thermodynamics and an Introduction to Thermostatistics, 2nd ed., Wiley, 1985.

[24] D. Carbone, M. Hua, S. Coste, and E. Vanden-Eijnden, Efficient training of energy-based models using Jarzynski's equality, in Adv. Neural Inf. Process. Syst., vol. 36, 2023.

[25] J. Chen, C. Lu, B. Chenli, J. Zhu, and T. Tian, VFlow: More expressive generative flows with variational data augmentation, in Proc. 37th ICML, 2020.

[26] R. T. Q. Chen, Y. Rubanova, J. Bettencourt, and D. K. Duvenaud, Neural ordinary differential equations, in Adv. Neural Inf. Process. Syst., vol. 31, 2018.

[27] T. Chen, B. Xu, C. Zhang, and C. Guestrin, Training deep nets with sublinear memory cost, ArXiv preprint 1604.06174, 2016.

[28] T. Q. Chen, J. Behrmann, D. Duvenaud, and J.-H. Jacobsen, Residual flows for invertible generative modeling, in Adv. Neural Inf. Process. Syst. 32, 2019.

[29] Y. Chen, T. T. Georgiou, and M. Pavon, On the relation between optimal transport and Schrödinger bridges: A stochastic control viewpoint, J. Optim. Theory Appl. 169(2):671–691, 2016.

[30] Y. Chen, T. T. Georgiou, and A. Tannenbaum, Stochastic control and nonequilibrium thermodynamics: Fundamental limits, IEEE Trans. Automat. Contr. 65(7):2979–2991, 2020.

[31] R. Chetrite, P. Muratore-Ginanneschi, and K. Schwieger, E. Schrödinger's 1931 paper "On the reversal of the laws of nature", Eur. Phys. J. H 46(1):28–57, 2021.

[32] S. Chewi, J. Niles-Weed, and P. Rigollet, Statistical optimal transport, ArXiv preprint 2407.18163, 2024.

[33] C. Chipot and A. Pohorille, Free Energy Calculations: Theory and Applications in Chemistry and Biology, Springer, 2007.

[34] P. F. Christiano, J. Leike, T. Brown, M. Martic, S. Legg, and D. Amodei, Deep reinforcement learning from human preferences, in Adv. Neural Inf. Process. Syst., vol. 30, 2017.

[35] T. S. Cohen and M. Welling, Group equivariant convolutional networks, in Proc. 33rd ICML, PMLR vol. 48, 2016.

[36] T. S. Cohen, M. Geiger, J. Köhler, and M. Welling, Spherical CNNs, in Proc. ICLR, 2018.

[37] T. Cover and J. Thomas, Elements of Information Theory, Wiley–Interscience, 2006.

[38] G. E. Crooks, Nonequilibrium measurements of free energy differences for microscopically reversible Markovian systems, J. Stat. Phys. 90(5):1481–1487, 1998.

[39] G. E. Crooks, Entropy production fluctuation theorem and the nonequilibrium work relation for free energy differences, Phys. Rev. E 60(3):2721–2726, 1999.

[40] G. E. Crooks, Path-ensemble averages in systems driven far from equilibrium, Phys. Rev. E 61(3):2361–2366, 2000.

[41] P. Dayan, G. E. Hinton, R. M. Neal, and R. S. Zemel, The Helmholtz machine, Neural Comput. 7(5):889–904, 1995.

[42] V. De Bortoli, J. Thornton, J. Heng, and A. Doucet, Diffusion Schrödinger bridge with applications to score-based generative modeling, in Adv. Neural Inf. Process. Syst. 34, 2021.

[43] A. Dechant and Y. Sakurai, Thermodynamic interpretation of Wasserstein distance, ArXiv preprint 1912.08405, 2019.

[44] P. Del Moral, A. Doucet, and A. Jasra, Sequential Monte Carlo samplers, J. Roy. Stat. Soc. Ser. B 68(3):411–436, 2006.

[45] C. Dellago, P. G. Bolhuis, and P. L. Geissler, Transition path sampling and the calculation of rate constants, Advances in Chemical Physics 123:1–78, 2002.

[46] P. Dhariwal and A. Q. Nichol, Diffusion models beat GANs on image synthesis, in Adv. Neural Inf. Process. Syst., vol. 34, 2021.

[47] J. Dijkman, M. Dijkstra, R. van Roij, M. Welling, J.-W. van de Meent, and B. Ensing, Learning neural free-energy functionals with pair-correlation matching, Phys. Rev. Lett. 134(5):056103, 2025.

[48] L. Dinh, D. Sohl-Dickstein, and Y. Bengio, NICE: Non-linear independent components estimation, ArXiv preprint 1410.8516, 2014.

[49] L. Dinh, J. Sohl-Dickstein, and S. Bengio, Density estimation using real NVP, in Proc. ICLR, 2017.

[50] A. Dosovitskiy et al., An image is worth 16×16 words: Transformers for image recognition at scale, in Proc. ICLR, 2021.

[51] A. Doucet, W. S. Grathwohl, A. G. D. G. Matthews, and H. Strathmann, Score-based diffusion meets annealed importance sampling, in Adv. Neural Inf. Process. Syst., 2022.

[52] Y. Du and I. Mordatch, Implicit generation and modeling with energy-based models, in Adv. Neural Inf. Process. Syst., vol. 32, 2019.

[53] F. Eijkelboom, G. Bartosh, C. A. Naesseth, M. Welling, and J.-W. van de Meent, Variational flow matching for graph generation, in Adv. Neural Inf. Process. Syst. 37:11735–11764, 2024.

[54] M. Esposito and C. Van den Broeck, Three detailed fluctuation theorems, Phys. Rev. Lett. 104(9):090601, 2010.

[55] R. Evans, The nature of the liquid–vapour interface and other topics in the statistical mechanics of non-uniform, classical fluids, Advances in Physics 28(2):143–200, 1979.

[56] R. P. Feynman, R. B. Leighton, and M. Sands, The Feynman Lectures on Physics, Vol. I: Mainly Mechanics, Radiation, and Heat, Addison-Wesley, 1963.

[57] R. P. Feynman, A. R. Hibbs, and D. F. Styer, Quantum Mechanics and Path Integrals, Emended edition, Dover, 2010.

[58] A. D. Fokker, Die mittlere Energie rotierender elektrischer Dipole im Strahlungsfeld, Ann. der Phys. 348(5):810–820, 1914.

[59] D. Frenkel and B. Smit, Understanding Molecular Simulation: From Algorithms to Applications, 2nd ed., Academic Press, 2001.

[60] K. Fukushima, Visual feature extraction by a multilayered network of analog threshold elements, IEEE Trans. Syst. Sci. Cybern. SSC-5(4):322–333, 1969.

[61] W. Gangbo and R. J. McCann, The geometry of optimal transportation, Acta Mathematica 177(2):113–161, 1996.

[62] C. W. Gardiner, Stochastic Methods: A Handbook for the Natural and Social Sciences, Springer, 2009.

[63] P. Geiger and C. Dellago, Optimum protocol for fast-switching free-energy calculations, Phys. Rev. E 81(2):021127, 2010.

[64] A. Gelman, J. B. Carlin, H. S. Stern, D. B. Dunson, A. Vehtari, and D. B. Rubin, Bayesian Data Analysis, 3rd ed., Chapman and Hall/CRC, 2013.

[65] Z. Ghahramani and M. I. Jordan, Factorial hidden Markov models, Machine Learning 29(2-3):245–273, 1997.

[66] J. W. Gibbs, Elementary Principles in Statistical Mechanics, Charles Scribner's Sons, 1902.

[67] X. Glorot, A. Bordes, and Y. Bengio, Deep sparse rectifier neural networks, in Proc. 14th AISTATS, PMLR vol. 15, 2011.

[68] H. Goldstein, Classical Mechanics, Addison-Wesley, 1950.

[69] A. N. Gomez, M. Ren, R. Urtasun, and R. B. Grosse, The reversible residual network: Backpropagation without storing activations, in Proc. 31st NeurIPS, 2017.

[70] A. Gomez-Marin, J. M. R. Parrondo, and C. Van den Broeck, Lower bounds on dissipation upon coarse graining, Phys. Rev. E 78(1):011107, 2008.

[71] I. Goodfellow, Y. Bengio, and A. Courville, Deep Learning, MIT Press, 2016.

[72] J. Gore, F. Ritort, and C. Bustamante, Bias and error in estimates of equilibrium free-energy differences from nonequilibrium measurements, Proc. Natl. Acad. Sci. USA 100(22):12564–12569, 2003.

[73] W. Grathwohl, R. T. Q. Chen, J. Bettencourt, I. Sutskever, and D. Duvenaud, FFJORD: Free-form continuous dynamics for scalable reversible generative models, in Proc. ICLR, 2018.

[74] J. Hadamard, An Essay on the Psychology of Invention in the Mathematical Field, Princeton University Press, 1945.

[75] W. K. Hastings, Monte Carlo sampling methods using Markov chains and their applications, Biometrika 57(1):97–109, 1970.

[76] K. He, X. Zhang, S. Ren, and J. Sun, Deep residual learning for image recognition, in Proc. IEEE CVPR, pp. 770–778, 2016.

[77] J. Heng, V. De Bortoli, and A. Doucet, Diffusion Schrödinger bridges for Bayesian computation, ArXiv preprint 2308.14106, 2023.

[78] T. Heskes, Stable fixed points of loopy belief propagation are local minima of the Bethe free energy, in Adv. Neural Inf. Process. Syst., vol. 15, 2002.

[79] I. Higgins et al., Beta-VAE: Learning basic visual concepts with a constrained variational framework, in Proc. ICLR, 2017.

[80] G. E. Hinton and D. van Camp, Keeping the neural networks simple by minimizing the description length of the weights, in Proc. 6th Annu. Conf. on Computational Learning Theory, 1993.

[81] G. E. Hinton and R. Zemel, Autoencoders, minimum description length and Helmholtz free energy, in Adv. Neural Inf. Process. Syst., vol. 6, 1993.

[82] J. Ho, X. Chen, A. Srinivas, Y. Duan, and P. Abbeel, Flow++: Improving flow-based generative models with variational dequantization and architecture design, in Proc. 36th ICML, 2019.

[83] J. Ho, A. Jain, and P. Abbeel, Denoising diffusion probabilistic models, in Adv. Neural Inf. Process. Syst., vol. 33, 2020.

[84] E. Hoogeboom, D. Nielsen, P. Jaini, P. Forré, and M. Welling, Argmax flows and multinomial diffusion: Learning categorical distributions, in Adv. Neural Inf. Process. Syst. vol. 34, 2021.

[85] K. Hornik, M. Stinchcombe, and H. White, Multilayer feedforward networks are universal approximators, Neural Networks 2(5):359–366, 1989.

[86] C.-W. Huang, L. Dinh, and A. Courville, Augmented normalizing flows: Bridging the gap between generative flows and latent variable models, ArXiv preprint 2002.07101, 2020.

[87] C.-W. Huang, J. H. Lim, and A. C. Courville, A variational perspective on diffusion-based generative models and score matching, in Adv. Neural Inf. Process. Syst., vol. 34, 2021.

[88] K. Huang, Statistical Mechanics, 2nd ed., Wiley, 1987.

[89] K. Ikeda, T. Uda, D. Okanohara, and S. Ito, Speed–accuracy relations for diffusion models: Wisdom from nonequilibrium thermodynamics and optimal transport, Phys. Rev. X 15(3):031031, 2025.

[90] S. Ioffe and C. Szegedy, Batch normalization: Accelerating deep network training by reducing internal covariate shift, in Proc. 32nd ICML, PMLR vol. 37, 2015.

[91] T. S. Jaakkola and M. I. Jordan, Recursive algorithms for approximating probabilities in graphical models, in Adv. Neural Inf. Process. Syst., vol. 9, 1996.

[92] T. S. Jaakkola and M. I. Jordan, A variational approach to Bayesian logistic regression models and their extensions, in 6th Int. Workshop on AI and Statistics, 1997.

[93] P. Jaini, D. Nielsen, and M. Welling, Sampling in combinatorial spaces with SurVAE flow augmented MCMC, in Proc. 24th AISTATS, PMLR vol. 130, 2021.

[94] C. Jarzynski, Nonequilibrium equality for free energy differences, Phys. Rev. Lett. 78(14):2690–2693, 1997.

[95] C. Jarzynski, Hamiltonian derivation of a detailed fluctuation theorem, J. Stat. Phys. 98(1/2):77–102, 2000.

[96] C. Jarzynski, Equalities and inequalities: Irreversibility and the second law of thermodynamics at the nanoscale, Annu. Rev. Condens. Matter Phys. 2(1):329–351, 2011.

[97] E. T. Jaynes, Information theory and statistical mechanics, Phys. Rev. 106(4):620–630, 1957.

[98] E. T. Jaynes, Information theory and statistical mechanics. II, Phys. Rev. 108(2):171–190, 1957.

[99] E. T. Jaynes, The minimum entropy production principle, Annu. Rev. Phys. Chem. 31(1):579–601, 1980.

[100] E. T. Jaynes, Probability Theory: The Logic of Science, Cambridge University Press, 2003.

[101] M. I. Jordan, Z. Ghahramani, T. S. Jaakkola, and L. K. Saul, An introduction to variational methods for graphical models, Machine Learning 37(2):183–233, 1999.

[102] R. Jordan, D. Kinderlehrer, and F. Otto, The variational formulation of the Fokker–Planck equation, SIAM J. Math. Anal. 29(1):1–17, 1998.

[103] D. Kahneman, Thinking, Fast and Slow, Farrar, Straus and Giroux, 2011.

[104] L. Kantorovich, On the translocation of masses, Doklady Akademii Nauk SSSR 37(7-8):199–201, 1942.

[105] H. J. Kappen, V. Gómez, and M. Opper, Optimal control as a graphical model inference problem, Machine Learning 87(2):159–182, 2012.

[106] M. Karplus and J. A. McCammon, Molecular dynamics simulations of biomolecules, Nature Structural Biology 9(9):646–652, 2002.

[107] R. Kawai, J. M. R. Parrondo, and C. Van den Broeck, Dissipation: The phase-space perspective, Phys. Rev. Lett. 98(8):080602, 2007.

[108] R. Kindermann and J. L. Snell, Markov Random Fields and Their Applications, American Mathematical Society, 1980.

[109] D. Kingma, T. Salimans, B. Poole, and J. Ho, Variational diffusion models, in Adv. Neural Inf. Process. Syst., vol. 34, 2021.

[110] D. P. Kingma and J. Ba, Adam: A method for stochastic optimization, ArXiv preprint 1412.6980, 2014.

[111] D. P. Kingma and M. Welling, Auto-encoding variational Bayes, in Proc. ICLR, 2014.

[112] D. P. Kingma and M. Welling, An introduction to variational autoencoders, Found. Trends Mach. Learn. 12(4):307–392, 2019.

[113] D. P. Kingma, T. Salimans, R. Jozefowicz, X. Chen, I. Sutskever, and M. Welling, Improved variational inference with inverse autoregressive flow, in Adv. Neural Inf. Process. Syst., vol. 29, 2016.

[114] J. G. Kirkwood, Statistical mechanics of fluid mixtures, J. Chem. Phys. 3(5):300–313, 1935.

[115] C. Kittel and H. Kroemer, Thermal Physics, 2nd ed., W. H. Freeman, 1980.

[116] D. Koller and N. Friedman, Probabilistic Graphical Models: Principles and Techniques, MIT Press, 2009.

[117] P. A. Kollman et al., Calculating structures and free energies of complex molecules: Combining molecular mechanics and continuum models, Accounts of Chem. Res. 33(12):889–897, 2000.

[118] A. N. Kolmogorov, Über die analytischen Methoden in der Wahrscheinlichkeitsrechnung, Math. Ann. 104(1):415–458, 1931.

[119] T. Korbak, E. Perez, and C. Buckley, RL with KL penalties is better viewed as Bayesian inference, in Findings of EMNLP 2022, 2022.

[120] H. A. Kramers, Brownian motion in a field of force and the diffusion model of chemical reactions, Physica 7(4):284–304, 1940.

[121] L. D. Landau and E. M. Lifshitz, Mechanics, 3rd ed., Butterworth–Heinemann, 1976.

[122] L. D. Landau and E. M. Lifshitz, Statistical Physics, 3rd ed., Butterworth–Heinemann, 1980.

[123] R. Landauer, Irreversibility and heat generation in the computing process, IBM J. Research and Development 5(3):183–191, 1961.

[124] J. L. Lebowitz, Boltzmann's entropy and time's arrow, Phys. Today 46(9):32–38, 1993.

[125] Y. LeCun, Modèles Connexionnistes de l'Apprentissage, PhD thesis, Université Pierre et Marie Curie, Paris, 1987.

[126] Y. LeCun, A theoretical framework for back-propagation, in Proc. Connectionist Models Summer School, 1988.

[127] Y. LeCun, L. Bottou, Y. Bengio, and P. Hafner, Gradient-based learning applied to document recognition, Proc. IEEE 86(11):2278–2324, 1998.

[128] H. K. Lee, C. Kwon, and H. Park, Fluctuation theorems and entropy production with odd-parity variables, Phys. Rev. Lett. 110(5):050602, 2013.

[129] F. Léger, A geometric perspective on regularized optimal transport, J. Dyn. Diff. Equat. 31(4):1777–1791, 2019.

[130] C. Léonard, A survey of the Schrödinger problem and some of its connections with optimal transport, DCDS 34(4):1533–1574, 2014.

[131] S. Levine, Reinforcement learning and control as probabilistic inference: Tutorial and review, ArXiv preprint 1805.00909, 2018.

[132] G. Li, H. T. Quan, and Z. C. Tu, Shortcuts to isothermality and nonequilibrium work relations, Phys. Rev. E 96(1):012144, 2017.

[133] Y. Lipman, R. T. Q. Chen, H. Ben-Hamu, M. Nickel, and M. Le, Flow matching for generative modeling, in Proc. ICLR, 2023.

[134] J. Loschmidt, Über den Zustand des Wärmegleichgewichtes eines Systems von Körpern mit Rücksicht auf die Schwerkraft, Sitzungsberichte der Akademie der Wissenschaften in Wien 73:128–142, 1876.

[135] Y.-A. Ma, T. Chen, and E. Fox, A complete recipe for stochastic gradient MCMC, in Adv. Neural Inf. Process. Syst., vol. 28, 2015.

[136] A. L. Maas, A. Y. Hannun, and A. Y. Ng, Rectifier nonlinearities improve neural network acoustic models, in Proc. 30th ICML, 2013.

[137] K. Madan et al., Learning GFlowNets from partial episodes for improved convergence and stability, in Proc. ICML, PMLR, 2023.

[138] N. Malkin, M. Jain, E. Bengio, C. Sun, and Y. Bengio, Trajectory balance: Improved credit assignment in GFlowNets, in Adv. Neural Inf. Process. Syst. 35:5955–5967, 2022.

[139] N. Malkin, S. Lahlou, T. Deleu, X. Ji, E. J. Hu, K. E. Everett, D. Zhang, and Y. Bengio, GFlowNets and variational inference, in Proc. ICLR, 2023.

[140] R. J. McCann, A convexity principle for interacting gases, Adv. Math. 128(1):153–179, 1997.

[141] N. Metropolis, A. W. Rosenbluth, M. N. Rosenbluth, A. H. Teller, and E. Teller, Equation of state calculations by fast computing machines, J. Chem. Phys. 21(6):1087–1092, 1953.

[142] T. P. Minka, Expectation propagation for approximate Bayesian inference, in Proc. 17th Conf. on Uncertainty in AI, 2001.

[143] G. Monge, Mémoire sur la Théorie des Déblais et des Remblais, De l'Imprimerie Royale, Paris, 1781.

[144] T. Morita, Cluster variation method and Moebius inversion formula, J. Stat. Phys. 59(3):819–825, 1990.

[145] K. P. Murphy, Machine Learning: A Probabilistic Perspective, MIT Press, 2012.

[146] M. Nakazato and S. Ito, Geometrical aspects of entropy production in stochastic thermodynamics based on Wasserstein distance, Phys. Rev. Research 3(4):043093, 2021.

[147] R. M. Neal, Annealed importance sampling, Statistics and Computing 11(2):125–139, 2001.

[148] R. M. Neal, MCMC using Hamiltonian dynamics, Chapter 5 in Handbook of Markov Chain Monte Carlo, Chapman and Hall/CRC, 2011.

[149] R. M. Neal and G. E. Hinton, A view of the EM algorithm that justifies incremental, sparse, and other variants, in Learning in Graphical Models, Springer, 1998.

[150] K. Neklyudov, M. Welling, E. Egorov, and D. Vetrov, Involutive MCMC: A unifying framework, in ICML, PMLR, 2020.

[151] E. Nelson, Dynamical Theories of Brownian Motion, Princeton University Press, 1967.

[152] D. Nielsen, P. Jaini, E. Hoogeboom, O. Winther, and M. Welling, SurVAE flows: Surjections to bridge the gap between VAEs and flows, in Adv. Neural Inf. Process. Syst., vol. 33, 2020.

[153] F. Noé, S. Olsson, J. Köhler, and H. Wu, Boltzmann generators: Sampling equilibrium states of many-body systems with deep learning, Science 365(6457):eaaw1147, 2019.

[154] L. Ouyang et al., Training language models to follow instructions with human feedback, in Adv. Neural Inf. Process. Syst., vol. 35, 2022.

[155] G. Papamakarios, T. Pavlakou, and I. Murray, Masked autoregressive flow for density estimation, in Adv. Neural Inf. Process. Syst., vol. 30, 2017.

[156] G. Parisi, Statistical Field Theory, Addison-Wesley, 1988.

[157] J. M. R. Parrondo, J. M. Horowitz, and T. Sagawa, Thermodynamics of information, Nat. Phys. 11(2):131–139, 2015.

[158] G. Patrini, R. van den Berg, P. Forré, M. Carioni, S. Bhargav, M. Welling, T. Genewein, and F. Nielsen, Sinkhorn autoencoders, in Proc. 35th UAI, PMLR, 2020.

[159] W. Peebles and S. Xie, Scalable diffusion models with transformers, in IEEE/CVF ICCV, 2023.

[160] L. Peliti and S. Pigolotti, Stochastic Thermodynamics: An Introduction, Princeton University Press, 2021.

[161] C. Peterson and J. R. Anderson, A mean field theory learning algorithm for neural networks, Complex Systems 1:995–1019, 1987.

[162] G. Peyré and M. Cuturi, Computational optimal transport: With applications to data science, Found. Trends Mach. Learn. 11(5-6):355–607, 2019.

[163] M. Planck, Über einen Satz der statistischen Dynamik und seine Erweiterung in der Quantentheorie, Sitzungsberichte der Preussischen Akademie der Wissenschaften, pp. 324–341, 1917.

[164] K. Proesmans, J. Ehrich, and J. Bechhoefer, Finite-time Landauer principle, Phys. Rev. Lett. 125(10):100602, 2020.

[165] L. R. Rabiner, A tutorial on hidden Markov models and selected applications in speech recognition, Proc. IEEE 77(2):257–286, 1989.

[166] D. J. Rezende and S. Mohamed, Variational inference with normalizing flows, in Proc. ICML, PMLR vol. 37, 2015.

[167] D. J. Rezende, S. Mohamed, and D. Wierstra, Stochastic backpropagation and approximate inference in deep generative models, in Proc. ICML, 2014.

[168] H. Risken, The Fokker–Planck Equation: Methods of Solution and Applications, Springer, 1996.

[169] C. P. Robert and G. Casella, Monte Carlo Statistical Methods, Springer, 1999.

[170] R. Rombach, A. Blattmann, D. Lorenz, P. Esser, and B. Ommer, High-resolution image synthesis with latent diffusion models, in Proc. IEEE/CVF CVPR, 2022.

[171] O. Ronneberger, P. Fischer, and T. Brox, U-Net: Convolutional networks for biomedical image segmentation, in MICCAI 2015, Springer, 2015.

[172] T. Salimans, D. P. Kingma, and M. Welling, Markov chain Monte Carlo and variational inference: Bridging the gap, in Proc. ICML, 2015.

[173] L. K. Saul, T. Jaakkola, and M. I. Jordan, Mean field theory for sigmoid belief networks, J. Artif. Intell. Res. 4:61–76, 1996.

[174] D. Scherer, A. Müller, and S. Behnke, Evaluation of pooling operations in convolutional architectures for object recognition, in Artif. Neural Networks – ICANN, Springer, 2010.

[175] E. Schrödinger, Über die Umkehrung der Naturgesetze, Sitzungsberichte der Preussischen Akademie der Wissenschaften, Physikalisch-mathematische Klasse 8(9):144–153, 1931.

[176] U. Seifert, Stochastic thermodynamics, fluctuation theorems and molecular machines, Rep. Prog. Phys. 75(12):126001, 2012.

[177] K. Sekimoto, Stochastic Energetics, Springer, 2010.

[178] N. Shiraishi, Stochastic Thermodynamics: From Basic to Advanced, SpringerBriefs in Physics, Springer, 2021.

[179] M. R. Shirts, E. Bair, G. Hooker, and V. S. Pande, Equilibrium free energies from nonequilibrium measurements using maximum-likelihood methods, Phys. Rev. Lett. 91(14):140601, 2003.

[180] J. Sohl-Dickstein, E. A. Weiss, N. Maheswaranathan, and S. Ganguli, Deep unsupervised learning using nonequilibrium thermodynamics, in Proc. ICML, 2015.

[181] Y. Song and S. Ermon, Generative modeling by estimating gradients of the data distribution, in Adv. Neural Inf. Process. Syst. 32, 2019.

[182] Y. Song and D. P. Kingma, How to train your energy-based models, ArXiv preprint 2101.03288, 2021.

[183] Y. Song, J. Sohl-Dickstein, D. P. Kingma, A. Kumar, S. Ermon, and B. Poole, Score-based generative modeling through stochastic differential equations, in Proc. ICLR, 2021.

[184] R. E. Spinney and I. J. Ford, Entropy production in full phase space for continuous stochastic dynamics, Phys. Rev. E 85(5):051113, 2012.

[185] R. E. Spinney and I. J. Ford, Nonequilibrium thermodynamics of stochastic systems with odd and even variables, Phys. Rev. Lett. 108(17):170603, 2012.

[186] N. Srivastava, G. Hinton, A. Krizhevsky, I. Sutskever, and R. Salakhutdinov, Dropout: A simple way to prevent neural networks from overfitting, J. Mach. Learn. Res. 15:1929–1958, 2014.

[187] R. F. Stengel, Stochastic Optimal Control: Theory and Application, Wiley, 1986.

[188] A. Thin, N. Kotelevskii, A. Doucet, A. Durmus, E. Moulines, and M. Panov, Monte Carlo variational auto-encoders, in Proc. ICML, PMLR vol. 139, 2021.

[189] D. Tiapkin, N. Morozov, A. Naumov, and D. Vetrov, Generative flow networks as entropy-regularized RL, ArXiv preprint 2310.12934, 2023.

[190] L. Tierney, Markov chains for exploring posterior distributions, Ann. Stat. 22(4):1701–1762, 1994.

[191] E. Todorov, Linearly-solvable Markov decision problems, in Adv. Neural Inf. Process. Syst., vol. 19, 2007.

[192] E. Todorov, General duality between optimal control and estimation, in 47th IEEE Conf. on Decision and Control, 2008.

[193] E. Todorov, Efficient computation of optimal actions, Proc. Natl. Acad. Sci. 106(28):11478–11483, 2009.

[194] A. Tong, N. Malkin, G. Huguet, Y. Zhang, J. Rector-Brooks, K. Fatras, G. Wolf, and Y. Bengio, Improving and generalizing flow-based generative models with minibatch optimal transport, ArXiv preprint 2302.00482, 2023.

[195] M. Toussaint and A. Storkey, Probabilistic inference for solving discrete and continuous state Markov decision processes, in ICML '06, 2006.

[196] B. Tzen and M. Raginsky, Theoretical guarantees for sampling and inference in generative models with latent diffusions, in Proc. 32nd COLT, PMLR, 2019.

[197] G. E. Uhlenbeck and L. S. Ornstein, On the theory of the Brownian motion, Phys. Rev. 36(5):823–841, 1930.

[198] B. Uria, I. Murray, and H. Larochelle, A deep and tractable density estimator, in Proc. 31st ICML, PMLR, 2014.

[199] S. Vaikuntanathan and C. Jarzynski, Escorted free energy simulations: Improving convergence by reducing dissipation, Phys. Rev. Lett. 100(19):190601, 2008.

[200] S. Vaikuntanathan and C. Jarzynski, Escorted free energy simulations, J. Chem. Phys. 134(5):054107, 2011.

[201] C. Van den Broeck and M. Esposito, Ensemble and trajectory thermodynamics: A brief introduction, Physica A 418:6–16, 2013.

[202] F. Vargas, A. Ovsianas, D. Fernandes, M. Girolami, N. D. Lawrence, and N. Nüsken, Bayesian learning via neural Schrödinger–Föllmer flows, Stat Comput 33(1):3, 2022.

[203] F. Vargas, S. Padhy, D. Blessing, and N. Nüsken, Transport meets variational inference: Controlled Monte Carlo diffusions, in Proc. ICLR, 2024.

[204] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin, Attention is all you need, in Adv. Neural Inf. Process. Syst., vol. 30, 2017.

[205] C. Villani, Topics in Optimal Transportation, American Mathematical Society, 2003.

[206] C. Villani, Optimal Transport: Old and New, Springer, 2008.

[207] P. Vincent, A connection between score matching and denoising autoencoders, Neural Comput. 23(7):1661–1674, 2011.

[208] M. J. Wainwright and M. I. Jordan, Graphical models, exponential families, and variational inference, Found. Trends Mach. Learn. 1(1–2):1–305, 2007.

[209] C. J. C. H. Watkins and P. Dayan, Q-learning, Mach. Learn. 8(3):279–292, 1992.

[210] N. Wiener, Generalized harmonic analysis, Acta Mathematica 55(1):117–258, 1930.

[211] R. J. Williams, Simple statistical gradient-following algorithms for connectionist reinforcement learning, Machine Learning 8:229–256, 1992.

[212] A. Winter, A genuinely natural information measure, ArXiv preprint 2103.16662, 2021.

[213] H. Wu, J. Köhler, and F. Noé, Stochastic normalizing flows, in Adv. Neural Inf. Process. Syst. 33, 2020.

[214] J. Q. Yang, S. Salamatian, Z. Sun, A. T. Suresh, and A. Beirami, Asymptotics of language model alignment, in 2024 IEEE ISIT, 2024.

[215] J. Yedidia, W. Freeman, and Y. Weiss, Constructing free-energy approximations and generalized belief propagation algorithms, IEEE Trans. Inf. Theory 51(7):2282–2312, 2005.

[216] A. Zhong, B. Kuznets-Speck, and M. R. DeWeese, Time-asymmetric fluctuation theorem and efficient free-energy estimation, Phys. Rev. E 110(3):034121, 2024.

[217] R. Zwanzig, Nonequilibrium Statistical Mechanics, Oxford University Press, 2001.

[218] R. W. Zwanzig, High-temperature equation of state by a perturbation method. I. Nonpolar gases, J. Chem. Phys. 22(8):1420–1426, 1954.

术语索引

中文术语	英文术语	页码
Bayes 法则	Bayes' rule	7
凸优化	convex optimization	7
概率质量函数	probability mass function	7
概率密度函数	probability density function	7
Gaussian 分布（正态分布）	Gaussian distribution	8
多元 Gaussian 分布	multivariate Gaussian distribution	8
指数族	exponential family	9
联合分布	joint distribution	10
边缘分布	marginal distribution	10
条件分布	conditional distribution	10
先验概率	prior probability	10
后验分布	posterior distribution	10
证据	evidence	10
熵	entropy	11
惊奇度（意外度）	surprisal	11
Kullback–Leibler 散度	Kullback–Leibler divergence	11
交叉熵	cross-entropy	12
相对熵	relative entropy	12
互信息	mutual information	12
Wasserstein 距离	Wasserstein distance	12
Monte Carlo 方法	Monte Carlo methods	13
一致性	consistency	13
无偏估计量	unbiased estimator	13
重要性采样	importance sampling	14
提议分布	proposal distribution	14
自归一化重要性采样	self-normalized importance sampling	15
马尔可夫链蒙特卡洛	Markov chain Monte Carlo	15

中文术语	英文术语	页码
变量替换公式	change of variables formula	15
时间反演对称性	time-reversal symmetry	16
熵产生	entropy production	16
涨落定理	fluctuation theorem	16
表示	representation	17
同态	homomorphism	17
原问题	primal problem	18
对偶问题	dual problem	19
下确界	infimum	19
上确界	supremum	19
对偶可行	dual feasible	19
弱对偶	weak duality	19
对偶间隙	duality gap	19
强对偶	strong duality	19
minimax 定理	minimax theorem	20
Karush–Kuhn–Tucker 条件	Karush–Kuhn–Tucker conditions	20
平稳性条件	stationarity condition	21
活跃的	active	21
非活跃的	inactive	21
互补松弛	complementary slackness	21
Occam 剃刀	Occam's razor	21
正则系综	canonical ensemble	22
最大熵原理	maximum entropy principle	22
Eulerian 视角	Eulerian view	23
Lagrangian 视角	Lagrangian view	23
推前（确定性）变换	push-forward transformation	23
重参数化技巧	reparameterization trick	24
分数网络	score network	25
多层感知机	multilayer perceptron	25

中文术语	英文术语	页码
梯度消失问题	vanishing gradient problem	25
线性修正单元	rectified linear unit	26
对数几率（logits）	logits	26
通用函数逼近器	universal function approximator	26
卷积神经网络	convolutional neural network	27
卷积层	convolutional layer	27
感受野	receptive field	27
局部性	locality	27
参数共享	parameter sharing	28
平移等变性	translation equivariance	28
群等变 CNN	group equivariant CNNs	28
池化层	pooling layer	28
最大池化	max-pooling	28
平均池化	average-pooling	29
平移不变性	translation invariance	29
Dropout	Dropout	29
批归一化	batch normalization	29
层归一化	layer normalization	29
残差网络	Residual network	30
跳跃连接	skip connection	30
U-Net	U-Net	30
Transformer	Transformer	31
自注意力机制	self-attention mechanism	31
多头注意力	Multi-head attention	31
位置编码	positional encoding	32
反向传播	backpropagation	33
Hamiltonian 动力学	Hamiltonian dynamics	35
微正则系综	microcanonical ensemble	35
正则系综	canonical ensemble	35
巨正则系综	grand canonical ensemble	35

中文术语	英文术语	页码
热力学第一定律	First law of thermodynamics	35
热力学第二定律	Second law of thermodynamics	35
内能	internal energy	36
Liouville 定理	Liouville's theorem	37
孤立系统	isolated system	37
Boltzmann 常数	Boltzmann constant	38
能量均分定理	equipartition theorem	39
热浴（热库）	heat bath	40
配分函数	partition function	41
逆温度	inverse temperature	41
变分自由能	variational free energy	42
化学势	化学势	44
热力学力	thermodynamic forces	44
强度量	intensive variables	44
广延量	extensive quantities	44
巨势	巨势	44
随机热力学	stochastic thermodynamics	45
非恰当微分	inexact differentials	45
态函数	state function	45
热容	heat capacity	46
热平衡	thermal equilibrium	48
Maxwell 妖	Maxwell's demon	48
可观测变量	observable variables	51
隐变量	latent variables	51
隐变量模型	latent variable model	51
图模型	graphical model	51
变分期望最大化	variational expectation maximization	51
证据下界	evidence lower bound	51
隐变量模型	latent variable model	51
似然	likelihood	51

中文术语	英文术语	页码
图模型	graphical model	52
Markov 模型	Markov model	53
隐 Markov 模型	hidden Markov model	53
Markov 随机场	Markov random field	54
聚类	cluster	54
Markov 毯	Markov blanket	54
VE 步	VE-step	56
REINFORCE 估计量	REINFORCE estimator	57
重参数化技巧	reparameterization trick	57
变分自编码器	variational autoencoder	59
平均场近似	mean-field approximation	59
Bayes 统计	Bayesian statistics	61
Jensen 不等式	Jensen's inequality	62
变分贝叶斯	variational Bayesian	62
置信传播	belief propagation, BP	68
归一化流	normalizing flow	78
马尔可夫过程	Markov process, MP	87
伴随核	adjoint kernel	88
细致平衡	detailed balance, DB	91
对偶核	dual kernel	92
祖先采样	ancestral sampling	108
遍历的	ergodic	109
不变的	invariant	110
遍历链	ergodic chain	112
平衡分布	equilibrium distribution	113
混合时间	mixing time	113
预热期	burn-in period	113
遍历定理	ergodic theorem	113
Hamiltonian Monte Carlo	Hamiltonian Monte Carlo, HMC	115

中文术语	英文术语	页码
对合	involution	117
动量重采样	momentum resampling	117
Langevin 动力学	Langevin dynamics	118
Metropolis 校正 Langevin 算法	Metropolis-adjusted Langevin algorithm, MALA	119
退火重要性采样	annealed importance sampling	124
Jarzynski 等式	Jarzynski equality	125
扩散模型	diffusion model	130
Schrödinger 桥	Schrödinger bridge	139
最大 caliber	maximum caliber	139
迭代比例拟合	iterative proportional fitting	141
Kullback–Leibler 控制	Kullback–Leibler control	143
最优传输	optimal transport	144
基于模型的强化学习	model-based reinforcement learning	147
生成流网络	generative flow network	154
涨落定理	fluctuation theorem	159
积分涨落定理	integral fluctuation theorem	159
细致涨落定理	detailed fluctuation theorem	159
Crooks 涨落定理	Crooks fluctuation theorem	165
Jarzynski 等式	Jarzynski equality	166
自由能微扰	free energy perturbation	168
热力学积分	thermodynamic integration	168
自由能微扰理论	free energy perturbation theory	168
Bennett 接受率	Bennett acceptance ratio	173