扩散模型原理

从起源到前沿

The Principles of Diffusion Models

From Origins to Advances

Chieh-Hsin Lai, Yang Song, Dongjun Kim, Yuki Mitsufuji, Stefano Ermon

arXiv:2510.21890v1 [cs.LG], 24 Oct 2025

数译
mathtranslations.org

AI 协作翻译组 翻译及重排

Model: Doubao Seedream / 协作多智能体

Updated: 12 Oct 2026

译者说明

本译本依据 Lai、Song、Kim、Mitsufuji 与 Ermon 的 arXiv 预印本 *The Principles of Diffusion Models: From Origins to Advances*（arXiv:2510.21890v1, 24 Oct 2025）翻译。原书系统梳理深度生成模型的变分视角（VAE→DDPM）、分数视角（EBM→NCSN）、Score SDE 框架、流视角（NF→Flow Matching）、统一视角与最优传输，并讲解采样（引导、快速求解器）与快速生成器（蒸馏、一致性模型等）。

翻译与排版约定：

1. 以原书为最高依据，逐节翻译正文、定理、证明、算法与附录；
2. 公式保留 LaTeX 记号，按原书章. 节. 序号编号；
3. 彩色配图直接采用原书裁剪图；节点箭头类关系图（网络流图、交换图）以 TikZ/tikz-cd 重绘；
4. 人名与人名衍生方法保留原文拼写（如 Langevin、Gaussian、Bayesian），不音译；
5. 模型、数据集、优化器名保留原文（如 DDPM、NCSN、DDIM、DPM-Solver、VAE）；
6. 行间公式统一使用 `align`/`aligned`/`align*`；有序列表用 `enumerate`；
7. 中文双引号写作 TeX 引号：“xxx”。

AI 协作翻译组
12 Oct 2026

目录

译者说明 i

第 1 章 深度生成建模 10
1.1 什么是深度生成建模? . . . 10
1.1.1 数学设置 . . . 10
1.1.2 分布建模的挑战 . . . 13
1.2 重要的深度生成模型 . . . 14
1.3 建模方法分类学 . . . 16
1.4 小结 . . . 17

第 2 章 变分视角：从 VAE 到 DDPM 20
2.1 变分自编码器 . . . 20
2.1.1 概率编码器与解码器 . . . 20
2.1.2 通过证据下界（ELBO）训练 . . . 21
2.1.3 Gaussian VAE . . . 23
2.1.4 标准 VAE 的缺陷 . . . 23
2.1.5 （可选）从标准 VAE 到层次化 VAE . . . 24
2.2 变分视角：DDPM . . . 26
2.2.1 前向过程（固定编码器） . . . 27
2.2.2 反向去噪过程（可学习解码器） . . . 28
2.2.3 反向转移核 $p_\phi(\mathbf{x}_{i-1} \mid \mathbf{x}_i)$ 的建模 . . . 30
2.2.4 预测与损失的实用选择 . . . 31
2.2.5 DDPM 的 ELBO . . . 32
2.2.6 采样 . . . 33
2.3 小结 . . . 35

第 3 章 基于分数的视角：从 EBM 到 NCSN 36
3.1 基于能量的模型 . . . 36
3.1.1 用能量函数建模概率分布 . . . 36
3.1.2 动机：什么是分数? . . . 37
3.1.3 通过分数匹配训练 EBM . . . 38
3.1.4 带分数函数的 Langevin 采样 . . . 39
3.2 从基于能量的模型到基于分数的生成模型 . . . 41
3.2.1 用分数匹配训练 . . . 42
3.2.2 用 Langevin 动力学采样 . . . 43
3.2.3 序章：基于分数的生成模型 . . . 43
3.3 去噪分数匹配 . . . 43
3.3.1 动机 . . . 43
3.3.2 训练 . . . 44
3.3.3 采样 . . . 46
3.3.4 为什么 DSM 是去噪：Tweedie 公式 . . . 47

3.3.5 （可选）为什么 DSM 是去噪：SURE . . . 48
3.3.6 （可选）广义分数匹配 . . . 50
3.4 去噪分数匹配的多噪声级（NCSN） . . . 51
3.4.1 动机 . . . 51
3.4.2 训练 . . . 53
3.4.3 采样 . . . 54
3.5 小结：NCSN 与 DDPM 的比较视角 . . . 55
3.6 结语 . . . 55

第 4 章 今日扩散模型：Score SDE 框架 57
4.1 Score SDE：其原理 . . . 57
4.1.1 动机：从离散过程到连续时间过程 . . . 57
4.1.2 前向时间 SDE：从数据到噪声 . . . 59
4.1.3 用于生成的反向时间随机过程 . . . 61
4.1.4 用于生成的确定性过程（概率流 ODE） . . . 63
4.1.5 前向/反向时间 SDE 与 PF-ODE 中匹配边缘分布 . . . 64
4.1.6 可计算示例：Gaussian 动力学的演化 . . . 66
4.2 Score SDE：其训练与采样 . . . 70
4.2.1 训练 . . . 70
4.2.2 采样与推断 . . . 70
4.3 SDE 的具体实例 . . . 73
4.3.1 VE SDE . . . 73
4.3.2 VP SDE . . . 74
4.3.3 （可选）扰动核 $p_t(\mathbf{x}_t \mid \mathbf{x}_0)$ 如何推导? . . . 75
4.4 （可选）反思基于分数与变分扩散模型中的前向核 . . . 76
4.4.1 一般仿射前向过程 $p_t(\mathbf{x}_t \mid \mathbf{x}_0)$ . . . 77
4.4.2 与 Score SDE 的联系 . . . 77
4.4.3 与变分扩散模型的联系 . . . 79
4.5 （可选）经边缘化与 Bayes 规则的 Fokker–Planck 方程与反向时间 SDE 80
4.5.1 从转移核的边缘化导出 Fokker–Planck 方程 . . . 80
4.5.2 反向时间 SDE 为何取此形式? . . . 82
4.6 结语 . . . 84

第 5 章 流视角：从归一化流到流匹配 85
5.1 基于流的模型：归一化流与神经常微分方程 . . . 85
5.1.1 归一化流 . . . 85
5.1.2 神经常微分方程 . . . 88
5.2 流匹配框架 . . . 90
5.2.1 从基于分数的方法中得到的启示 . . . 91
5.2.2 流匹配框架 . . . 93
5.2.3 扩散模型、一般 FM 与 NODE 的对比 . . . 96
5.2.4 （可选）底层规则 . . . 97

5.3 在分布之间构造概率路径与速度 . . . 98
5.3.1 一个关键特例：Gauss–Gauss 桥中的边缘 $p_t(\mathbf{x}_t)$ 与速度 $\mathbf{v}_t(\mathbf{x}_t)$ . . . 99
5.3.2 $\mathbf{v}_t(\cdot \mid \mathbf{z})$ 与 $p_t(\cdot \mid \mathbf{z})$ 的条件概率路径先构造 . . . 100
5.3.3 $\mathbf{v}_t(\cdot \mid \mathbf{z})$ 与 $p_t(\cdot \mid \mathbf{z})$ 的条件流先构造 . . . 103
5.3.4 概率路径先与流先构造的对比 . . . 105
5.4 （可选）标准仿射流的性质 . . . 106
5.4.1 Rectifying Flows：从含噪猜测到结构化配对 . . . 106
5.4.2 Reflow：迭代拉直流 . . . 107
5.4.3 Reflow 的性质 . . . 108
5.5 本章小结 . . . 109

第 6 章 扩散模型的统一与系统视角 111
6.1 条件技巧：扩散模型的秘诀 . . . 111
6.2 阐明扩散模型训练损失的路线图 . . . 112
6.2.1 扩散模型中四种常见参数化 . . . 113
6.2.2 解构扩散模型的训练目标 . . . 114
6.3 扩散模型中的等价性 . . . 116
6.3.1 四种预测类型等价 . . . 116
6.3.2 不同参数化下的 PF-ODE . . . 117
6.3.3 所有仿射流等价 . . . 118
6.3.4 （可选）参数化与标准流的概念分析 . . . 120
6.4 一切之下：Fokker–Planck 方程 . . . 123
6.4.1 基于流方法与 Score SDE 的联系 . . . 124
6.5 本章小结 . . . 125

第 7 章 （可选）扩散模型与最优传输 128
7.1 分布到分布迁移的序幕 . . . 128
7.2 问题设定的分类 . . . 129
7.2.1 最优传输（OT） . . . 129
7.2.2 熵正则化最优传输（EOT） . . . 132
7.2.3 Schrödinger 桥（SB） . . . 133
7.2.4 全局推前与局部动力学：DGM 的 OT 类比 . . . 137
7.3 各最优传输表述之间的关系 . . . 137
7.3.1 SB 与 EOT（对偶）等价 . . . 138
7.3.2 当 $\varepsilon \to 0$ 时 EOT_ε 退化为 OT . . . 139
7.3.3 当 $\varepsilon \to 0$ 时 SB_ε 退化为 OT . . . 140
7.4 扩散模型的 SDE 是 SB 问题的最优解吗? . . . 141
7.4.1 扩散模型作为 Schrödinger 桥的特例 . . . 141
7.4.2 扩散模型作为 Schrödinger 半桥 . . . 142
7.5 扩散模型的 ODE 是 OT 问题的最优映射吗? . . . 143
7.5.1 PF-ODE 流一般不是最优传输 . . . 143
7.5.2 典范线性流与 Reflow 能否给出 OT 映射? . . . 146

第 8 章　引导与可控生成　150
8.1　序幕 . . . 150
8.2　分类器引导 . . . 154
8.2.1　分类器引导的基础 . . . 154
8.2.2　用 CG 推理 . . . 155
8.2.3　优点与局限 . . . 155
8.3　无分类器引导 . . . 155
8.3.1　无分类器引导的基础 . . . 155
8.3.2　CFG 的训练与采样 . . . 156
8.4　（可选）免训练引导 . . . 158
8.4.1　免训练引导的概念框架 . . . 158
8.4.2　免训练逆问题求解方法示例 . . . 159
8.5　从强化学习到面向模型对齐的直接偏好优化 . . . 161
8.5.1　动机：绕开 RLHF 的陷阱 . . . 161
8.5.2　RLHF：Bradley–Terry 视角 . . . 162
8.5.3　DPO 框架 . . . 163
8.5.4　Diffusion-DPO . . . 164
8.6　小结 . . . 167

第 9 章　快速采样的精巧求解器　169
9.1　序幕 . . . 169
9.1.1　扩散模型的高阶求解器 . . . 169
9.1.2　文献中设计求解器的统一框架 . . . 170
9.1.3　PF–ODE 数值求解器的几条路线 . . . 170
9.2　DDIM . . . 171
9.2.1　把 DDIM 解释为 ODE 求解器 . . . 171
9.2.2　不同参数化下 DDIM 的直觉 . . . 171
9.2.3　（可选）DDIM 的变分视角 . . . 172
9.2.4　DDIM 即条件流匹配 . . . 172
9.3　DEIS . . . 172
9.3.1　多项式外推 . . . 173
9.3.2　DEIS：PF–ODE 积分的 Lagrange 多项式逼近 . . . 173
9.3.3　DDIM = AB-DEIS-0 . . . 174
9.4　DPM-Solver . . . 174
9.4.1　DPM-Solver 的洞见：用对数 SNR 作时间重参数化 . . . 174
9.4.2　用 Taylor 展开估计积分 . . . 174
9.4.3　DPM-Solver-n 的实现 . . . 175
9.4.4　DDIM = DPM-Solver-1 . . . 176
9.4.5　DPM-Solver-2 与经典 Heun 更新的讨论 . . . 176
9.5　DPM-Solver++ . . . 178
9.5.1　从 DPM-Solver 到面向引导的 DPM-Solver++ . . . 178

9.5.2 DPM-Solver++ 的方法 . . . 178
9.5.3 DPM-Solver++：Taylor 展开的单步格式 . . . 179
9.5.4 DPM-Solver++：回收历史的多步格式 . . . 179
9.6 PF–ODE 求解器族及其数值对应 . . . 180
9.6.1 PF–ODE 求解器族与经典对应 . . . 181
9.6.2 关于 DEIS 与 DPM-Solver++ 的讨论 . . . 181
9.7 （可选）DPM-Solver-v3 . . . 182
9.7.1 洞见一：调整式 (9.9.4.470) 中的线性项 . . . 182
9.7.2 洞见二：在模型参数化中引入自由变量以进一步减小离散化误差 . 183
9.7.3 综合两个洞见 . . . 184
9.7.4 高阶 DPM-Solver-v3 . . . 184
9.7.5 DPM-Solver-v3 的更多解读 . . . 185
9.7.6 DPM-Solver-v3 与其他方法的联系 . . . 186
9.8 （可选）ParaDiGMS . . . 186
9.8.1 从时间步进走向时间并行求解器 . . . 186
9.8.2 ParaDiGMS 的方法 . . . 186
9.8.3 与时间步进求解器的关系 . . . 188
9.9 本章结语 . . . 189

第 10 章 面向快速采样的蒸馏方法 192
10.1 序幕 . . . 192
10.1.1 分布级蒸馏 . . . 193
10.1.2 流映射级蒸馏 . . . 193
10.2 基于分布的蒸馏 . . . 195
10.2.1 以 VSD 为代表的表述 . . . 195
10.2.2 VSD 的训练流程 . . . 196
10.2.3 补充讨论：散度选择与 VSD 的应用 . . . 197
10.3 Progressive Distillation . . . 198
10.3.1 PD 中的蒸馏操作 . . . 199
10.3.2 PD 的完整训练流程与采样 . . . 200
10.3.3 补充讨论：局部半群匹配与推广求解器的可能性 . . . 201
10.3.4 带引导的 PD . . . 202
10.4 本章小结 . . . 202

第 11 章 从零学习快速生成器 204
11.1 序幕 . . . 204
11.2 特殊流映射：离散时间 Consistency Model . . . 207
11.2.1 学习一致性函数的离散时间逼近 . . . 209
11.2.2 Consistency Model 的采样 . . . 212
11.3 特殊流映射：连续时间 Consistency Model . . . 213
11.3.1 连续时间 Consistency Model . . . 213
11.3.2 训练连续时间 Consistency Model . . . 214

11.3.3 （可选）连续时间一致性训练的实用考量 . . . 215
11.4 一般流映射：Consistency Trajectory Model . . . 219
11.4.1 用于灵活转移学习的 CTM 参数化 . . . 219
11.4.2 CTM 中的一致性损失 . . . 221
11.4.3 CTM 中的辅助损失 . . . 223
11.4.4 CTM 的灵活采样 . . . 224
11.5 一般流映射：Mean Flow . . . 226
11.5.1 Mean Flow 的建模与训练 . . . 226
11.5.2 Mean Flow 的采样 . . . 227
11.5.3 CTM 与 MF 的等价性 . . . 228
11.6 本章小结 . . . 230

附录 A 微分方程速成 231
A.1 常微分方程基础 . . . 231
A.1.1 常微分方程的直观 . . . 231
A.1.2 常微分方程解的存在性与唯一性 . . . 232
A.1.3 指数积分因子 . . . 234
A.1.4 常微分方程的数值求解器 . . . 235
A.2 随机微分方程基础 . . . 237
A.2.1 从 ODE 到 SDE：直观引入 . . . 238
A.2.2 对方程 (A.2.3) 的进一步说明 . . . 239
A.2.3 SDE 的数值求解器 . . . 239

附录 B 密度演化：从换元公式到 Fokker–Planck 方程 240
B.1 换元公式：从确定性映射到随机流 . . . 240
B.1.1 确定性映射的换元公式 . . . 241
B.1.2 连续时间极限：连续性方程 . . . 243
B.1.3 随机过程：Fokker–Planck 方程 . . . 244
B.2 连续性方程的直观 . . . 245
B.2.1 连续性方程的物理解释 . . . 245
B.2.2 由守恒定律推导连续性方程 . . . 245

附录 C 扩散模型幕后：Itô 演算与 Girsanov 定理 247
C.1 Itô 公式：随机过程的链式法则 . . . 247
C.1.1 动机：为何需要特殊的链式法则? . . . 247
C.1.2 由 Taylor 展开推导一维 Itô 公式 . . . 248
C.1.3 Itô 公式：SDE 的链式法则 . . . 249
C.1.4 Itô 公式的应用：Fokker–Planck 方程推导 . . . 249
C.1.5 Itô 公式的应用：线性 SDE 的闭式解 . . . 250
C.2 测度的换元：扩散模型中的 Girsanov 定理 . . . 251
C.2.1 Girsanov 定理作为似然训练与分数匹配之间的桥梁 . . . 252

附录 D 补充材料与证明 254

D.1 变分视角 . . . 254
D.1.1 定理 2.2.1：边缘 KL 最小化与条件 KL 最小化的等价性 . . . 254
D.1.2 定理 2.2.3：扩散模型的 ELBO . . . 254
D.2 分数视角 . . . 255
D.2.1 命题 3.2.1：经分部积分的可处理分数匹配 . . . 255
D.2.2 定理 3.3.1：SM 与 DSM 最小化的等价性 . . . 256
D.2.3 引理 3.3.2：Tweedie 公式 . . . 256
D.2.4 Stein 恒等式与代理 SURE 目标 . . . 257
D.2.5 定理 4.1.1：经 Fokker–Planck 的边缘对齐 . . . 258
D.2.6 命题 4.2.1：SM 与 DSM 的最小化解 . . . 259
D.2.7 Gauss 的闭式分数函数 . . . 259
D.3 流视角 . . . 260
D.3.1 引理 5.1.1：瞬时换元 . . . 260
D.3.2 定理 5.2.2：质量守恒准则 . . . 260
D.4 理论补充：扩散模型的统一系统视角 . . . 261
D.4.1 命题 6.3.1：参数化的等价性 . . . 261
D.5 理论补充：学习快速扩散生成器 . . . 261
D.5.1 知识蒸馏损失作为一般框架方程 (10.1.4) 的一个实例 . . . 261
D.5.2 命题 10.2.1 的参数–流解释 . . . 262
D.5.3 定理 11.2.1：CM 在 $O(\Delta s)$ 精度上等于 CT . . . 262
D.5.4 命题 11.3.1：CT 梯度的连续时间极限 . . . 263
D.6 （可选）Elucidating Diffusion Model（EDM） . . . 263
D.6.1 神经网络 x_ϕ 设计的准则 . . . 263
D.6.2 一个常见 EDM 特例：$\alpha_t = 1$、$\sigma_t = t$ . . . 264

参考文献 **266**

术语索引 **278**

致谢

作者们衷心感谢首尔市立大学（University of Seoul）与韩国高等研究院（KIAS）的 Dohyun Kwon 教授。他慷慨地投入时间与精力参与本书工作，仔细审阅了第 7 章的部分内容，帮助核对命题与证明的正确性，并在多次富有价值的讨论中厘清了若干表述。除技术性建议之外，他周到的反馈与乐于分享见解的态度，贯穿了本专著写作的始终，成为我们重要的鼓励来源。我们由衷感谢他的支持与学者风范，正是这些使最终稿更加充实。

序言与路线图

扩散模型（diffusion models）已迅速成为生成建模（generative modeling）中的核心范式，相关工作横跨机器学习、计算机视觉、自然语言处理等诸多领域。这些文献分散在不同学术圈中，各自强调不同维度的进展：理论基础层面关注建模原理、训练目标、采样器设计及其背后的数学思想；实现进展层面覆盖工程实践与架构选择；实际应用层面将模型适配到特定领域或任务；系统层面的优化则着眼于计算、显存与部署效率。

本专著致力于为扩散模型提供一个有原理可循的基础，聚焦以下中心主题：

- 我们给出锚定扩散模型研究的基本概念与形式化表述，使读者具备理解更广泛文献所需的核心认识。我们并不穷举所有变体或领域特定应用，而是建立一个稳定的概念基础，以便读者由此去理解后续种种发展。
- 与直接学习从噪声到数据映射的经典生成模型不同，扩散模型把生成视为一个随时间逐步演进的变换过程，将粗粒度结构逐步精化为细粒度细节。这一核心思想通过三种主要视角发展而来，即变分视角、分数视角与流视角，它们提供了理解与实现扩散建模的互补途径。我们聚焦这些形式化表述的核心原理与基础，旨在追溯其关键思想的起源，厘清不同表述之间的关系，并建立一种将直觉洞见与严格数学表述相连接的连贯理解。
- 在上述基础之上，我们考察扩散模型如何被进一步发展，以更高效地生成样本、对生成过程施加更强控制，并启发那些独立成型、但以扩散原理为根基的生成建模新形态。

本专著面向这样的研究者、研究生与工程实践者：他们已具备深度学习的基础认识（例如知道神经网络是什么、训练是如何进行的），更具体地说，对深度生成建模有基本了解，并希望超越表面熟悉，深入把握扩散模型。读完本书后，读者将对扩散建模的基础建立原理性的理解，能够在一个连贯框架内解读不同形式化表述，并具备既有把握地应用现有模型、又能探索新研究方向的背景。

本专著的路线图. 本书系统介绍扩散模型的基础，并将其追溯到背后的核心原理。

建议阅读路径. 我们建议读者按本书给出的顺序阅读，以建立完整认识。标注为“可选”的小节，已熟悉基础的读者可以略过。例如，熟悉深度生成模型（deep generative model, DGM）的读者可以跳过第 1 章的概述。类似地，若已具备变分自编码器（变分自编码器（Variational Autoencoder, VAE），见 §1.2）、基于能量的模型（energy-based model, EBM，见 §3.1）或归一化流（normalizing flow, NF，见 §1.2）的先验知识，也可跳过相应的介绍性小节。其他可选部分提供关于高级或专题内容的更深入洞见，可按需查阅。

全书由四个主要部分构成。

Part A 与 Part B：扩散模型的基础. 本部分通过回顾塑造了本领域的三种基础视角，追溯扩散模型的起源。图 0.1 给出了时间线概览，图 0.2 给出了 Part B 的整体结构。

Part A：深度生成建模导论.

我们在第 1 章从深度生成建模的基本目标出发。给定一组数据样本，目标是构造一个模型，使其能够产生看似来自同一底层数据分布（该分布通常未知）的新样本。许多方法通过学习数据如何分布来达成这一目标，显式地借助概率模型，或隐式地借助一个学到的变换。随后我们说明：这类模型如何用神经网络表示数据分布、如何从样本中学习、以及如何生成新样本。本章最后给出主要生成框架的分类学，突出各自的中心思想与关键区别。

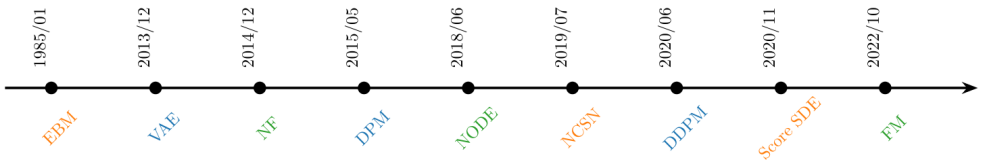


Figure 1: Timeline of diffusion model perspectives. Each group shares the same color.

图 0.1：扩散模型各视角的时间线。同组视角共用同一颜色。第 2 章：变分自编码器（VAE，Kingma 与 Welling, 2013）→ 扩散概率模型（DPM，Sohl-Dickstein 等, 2015）→ 去噪扩散概率模型（DDPM，Ho 等, 2020）。第 3、4 章：基于能量的模型（EBM，Ackley 等, 1985）→ 噪声条件分数网络（NCSN，Song 与 Ermon, 2019）→ 分数 SDE（Score SDE，Song 等, 2020c）。第 5 章：归一化流（NF，Rezende 与 Mohamed, 2015）→ 神经常微分方程（NODE，Chen 等, 2018）→ 流匹配（Flow Matching, FM，Lipman 等, 2022）。

Part B：扩散模型的核心视角.

在勾勒深度生成建模的一般目标与机制之后，我们转向扩散模型本身：这是一类把生成实现为从噪声到数据之渐进变换的方法。我们考察三个相互关联的框架，每一个都由一个逐渐加噪的前向过程和一个由一系列逐步去噪模型近似的反向时间过程所刻画：

- **变分视角（第 2 章）**：起源于变分自编码器（VAE, Kingma 与 Welling, 2013），把扩散刻画为通过变分目标学习一个去噪过程，由此导出去噪扩散概率模型（denoising diffusion probabilistic model, DDPM；Sohl-Dickstein 等, 2015；Ho 等, 2020）。

- **分数视角（第 3 章）**：植根于基于能量的模型（EBM，Ackley 等, 1985），并发展为噪声条件分数网络（NCSN，Song 与 Ermon, 2019）。它学习分数函数——即对数数据密度的梯度，用以指导如何逐步从样本中去除噪声。在连续时间下，第 4 章引入 Score SDE 框架，把这一去噪过程描述为随机微分方程（Stochastic Differential Equation, SDE），其确定性对应物则为常微分方程（Ordinary Differential Equation, ODE）。这一视角将扩散建模与经典微分方程理论相连接，为分析与算法设计提供了清晰的数学基础。

- **流视角（第 5 章）**：建立在归一化流（Rezende 与 Mohamed, 2015）之上，并由流匹配（Lipman 等, 2022）推广。该视角把生成建模为一个连续变换，将样本从一

个简单先验运输到数据分布。这一演化由一个速度场（velocity field）通过 ODE 支配，显式地定义概率质量如何随时间移动。这种流形式化自然地超越 “先验 → 数据” 式的生成，推广到更一般的 “分布到分布” 翻译问题——即学习连接任意一对源分布与目标分布的流。

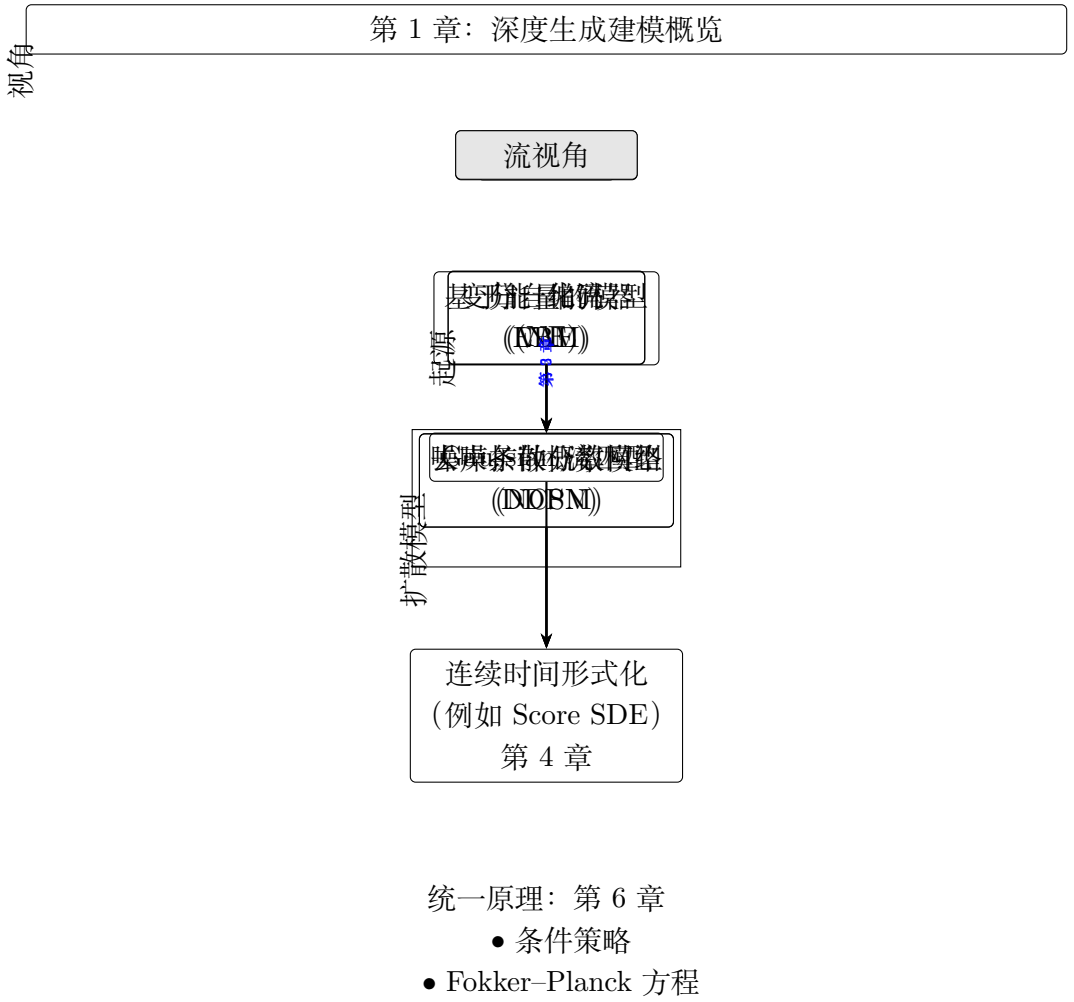


图 0.2: Part B：关于扩散模型的统一而有原理可循的视角。本图将经典生成建模方法——变分自编码器、基于能量的模型、归一化流——与其对应的扩散模型形式化连接起来。每条纵向路径展示一条概念谱系，最终汇集到连续时间形式化。三种视角（变分、分数、流）提供了彼此不同但在数学上等价的解读。

尽管这三种视角初看之下彼此不同，第 6 章将表明它们在深层是相通的。每一种都使用某种条件策略（conditioning strategy），把学习目标转化为一个可处理的回归问题。在更深的层次上，它们都在描述概率分布从先验走向数据这同一个时间演化，这一演化由 Fokker–Planck 方程支配——该方程可视为密度的连续时间变量替换公式，从而保证随机形式化与确定性形式化之间的一致性。

由于扩散模型可视为把一个分布运输到另一个分布的方法，第 7 章发展了它与经典最优传输（optimal transport）以及 Schrödinger 桥（Schrödinger bridge）之间的联系；

后者可解释为带熵正则的最优传输。我们回顾静态与动态两种形式化，并解释它们与连续性方程和 Fokker–Planck 视角之间的关系。对于聚焦于实用方面的读者，本章是可选的；但对于希望深入研究这些联系的读者，它提供了严格的数学背景以及指向经典文献的线索。

Part C 与 Part D：控制并加速扩散采样. 在统一了基础原理之后，我们转向利用扩散模型高效生成的实践层面。从扩散模型中采样对应于求解一个微分方程。然而这一过程通常在计算上十分昂贵。Part C 与 Part D 聚焦于通过改进采样与学习到的加速技术，提升生成质量、可控性与效率。

Part C：从扩散模型中采样.

扩散模型的生成过程呈现出独特的 "由粗到细" 的精化：噪声被逐步去除，样本的结构与细节也随之越来越连贯。这一性质伴随着权衡。正面地看，它允许细粒度控制：通过在学到的、依赖时间的速度场上加入一个引导项，我们可以操纵 ODE 流，使其反映用户意图，从而让采样可控。负面地看，所需的迭代积分使得采样相较于一次性生成器更慢。本部分聚焦于在不重新训练的前提下改进推理阶段的生成过程。

- **引导生成（第 8 章）**：分类器引导（classifier guidance）与无分类器引导（classifier-free guidance）等技术，使生成过程可以按用户给定的目标或属性进行条件化。在此基础上，我们进一步讨论如何利用偏好数据集（preference dataset）使扩散模型与这类偏好对齐。
- **用数值求解器快速生成（第 9 章）**：使用更先进的数值求解器可以在更少步数内近似反向过程，从而显著加速采样，同时保持生成质量。

Part D：学习快速生成模型.

除改进已有采样算法之外，我们还研究如何直接学习快速生成器，使其近似整个扩散过程。

- **基于蒸馏的方法（第 10 章）**：该思路训练一个学生模型，使其模仿一个预先训练好、但采样缓慢的扩散模型（教师模型）的行为。目标不是缩小教师模型的规模，而是用远少于原来的积分步数（往往只有几步甚至一步）复现其采样轨迹或输出分布。
- **从零学习（第 11 章）**：由于扩散模型中的采样可视为求解一个 ODE，该思路直接从零开始学习解映射（即流映射 flow map），而不依赖教师模型。学到的映射既可以直接把噪声映射到数据，也可以更一般地沿解轨迹做任意时刻到任意时刻的跳跃。

附录. 为使本书内容对所有读者都易于进入，附录提供若干基础概念的背景。附录 A 提供一个关于微分方程的速成教程——这些方程已经成为扩散模型的通用语言。尽管扩散模型的视角与起源各异，其核心洞见在于变量替换公式（change-of-variables formula）。这一基础自然延伸到更深刻的概念，如 Fokker–Planck 方程与连续性方程，它们描述概率密度如何在由函数定义的映射下（离散时间）或由微分方程定义的映射下（连续时间）变换与演化。附录 B 提供一个温和的导引，把这些基础思想桥接到更高级的概念。附录 C 给出两个强大却常被忽视的工具：Itô 公式与 Girsanov 定理，它们为 Fokker–Planck 方程与反向时间采样过程提供严格支撑。最后，附录 D 汇集了主章节中若干命题与定理的证明。

本书覆盖什么、不覆盖什么. 我们追求持久的价值。从自上而下的视角看，本书从一条原理出发：构造连续时间动力学，把一个简单先验运输到数据分布，同时保证每一时刻的边缘分布与由一个预先规定的 “从数据到噪声” 的前向过程所诱导的边缘分布相匹配。从这条原理出发，我们发展出用于采样的随机流与确定性流，展示如何操纵轨迹（引导），并解释如何加速轨迹（数值求解器）。随后我们研究受扩散启发的快速生成器，包括蒸馏方法与流映射模型。借助这些工具，读者可以把新论文放入一个共同模板，理解方法为何有效，并设计出改进的模型。

我们并不试图穷尽式综述扩散模型文献；也不罗列架构、训练实践、超参数，不跨方法比较实验结果，不覆盖数据集与排行榜，不描述领域或模态特定的应用，不讨论系统级部署，不给出大规模训练的配方，也不涉及硬件工程。这些主题演变极快，更适合由专题综述、开源仓库与实现指南来覆盖。

符号表

数与数组.

a	标量.
$\mathbf{a}$	列向量（例如 $\mathbf{a} \in \mathbb{R}^D$）.
$\mathbf{A}$	矩阵（例如 $\mathbf{A} \in \mathbb{R}^{m \times n}$）.
$\mathbf{A}^\top$	$\mathbf{A}$ 的转置.
$\mathrm{Tr}(\mathbf{A})$	$\mathbf{A}$ 的迹.
$\mathbf{I}_D$	$D \times D$ 的单位矩阵.
$\mathbf{I}$	单位矩阵；维数由上下文决定.
$\mathrm{diag}(\mathbf{a})$	对角元由 $\mathbf{a}$ 给出的对角矩阵.
ϕ, θ	可学习的神经网络参数.
$\phi^\times, \theta^\times$	训练后的参数（推理时固定）.
ϕ^*, θ^*	优化问题的最优参数.

微积分.

$\dfrac{\partial \mathbf{y}}{\partial \mathbf{x}}$	$\mathbf{y}$ 关于 $\mathbf{x}$ 的偏导数（按分量）.
$\dfrac{d\mathbf{y}}{d\mathbf{x}}$ 或 $D\mathbf{y}(\mathbf{x})$	$\mathbf{y}$ 关于 $\mathbf{x}$ 的全（Fréchet）导数.
$\nabla_{\mathbf{x}} y$	标量 $y : \mathbb{R}^D \to \mathbb{R}$ 的梯度；$\mathbb{R}^D$ 中的列向量.
$\dfrac{\partial \mathbf{F}}{\partial \mathbf{x}}$ 或 $\nabla_{\mathbf{x}} \mathbf{F}$	$\mathbf{F} : \mathbb{R}^n \to \mathbb{R}^m$ 的 Jacobian；形状 $m \times n$.
$\nabla \cdot \mathbf{y}$	向量场 $\mathbf{y} : \mathbb{R}^D \to \mathbb{R}^D$ 的散度；为标量.
$\nabla^2_{\mathbf{x}} f(\mathbf{x})$ 或 $\mathbf{H}(f)(\mathbf{x})$	$f : \mathbb{R}^D \to \mathbb{R}$ 的 Hessian；形状 $D \times D$.
$\int f(\mathbf{x})\, d\mathbf{x}$	f 在 $\mathbf{x}$ 定义域上的积分.

概率与信息论.

$p(\mathbf{a})$	连续向量 $\mathbf{a}$ 上的密度 / 分布.
p_{data}	数据分布.
p_{prior}	先验分布（例如标准正态）.
p_{src}	源分布.
p_{tgt}	目标分布.
$\mathbf{a} \sim p$	随机向量 $\mathbf{a}$ 服从分布 p.
$\mathbb{E}_{\mathbf{x} \sim p}[f(\mathbf{x})]$	在 $p(\mathbf{x})$ 下 $f(\mathbf{x})$ 的期望.
$\mathbb{E}[f(\mathbf{x}) \mid \mathbf{z}]$，或 $\mathbb{E}_{\mathbf{x} \sim p(\cdot \mid \mathbf{z})}[f(\mathbf{x})]$	在给定 $\mathbf{z}$ 下 $f(\mathbf{x})$ 的条件期望，其中 $\mathbf{x}$ 服从 $p(\cdot \mid \mathbf{z})$.
$\mathrm{Var}(f(\mathbf{x}))$	在 $p(\mathbf{x})$ 下的方差.
$\mathrm{Cov}(f(\mathbf{x}), g(\mathbf{x}))$	在 $p(\mathbf{x})$ 下的协方差.
$\mathcal{D}_{\mathrm{KL}}(p \Vert q)$	由 q 到 p 的 Kullback–Leibler 散度.
$\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$	标准正态样本.
$\mathcal{N}(\mathbf{x}; \boldsymbol{\mu}, \boldsymbol{\Sigma})$	关于 $\mathbf{x}$ 的 Gaussian 分布，均值 $\boldsymbol{\mu}$，协方差 $\boldsymbol{\Sigma}$.

记号澄清. 我们对随机向量与其实现值使用同一个符号。这一约定在深度学习与生成建模中常见，可保持记号紧凑而不冗杂，具体含义由上下文决定。

例如在 $p(\mathbf{x})$ 这样的表达式中，符号 $\mathbf{x}$ 只是哑变量，整个表达式表示作为其输入函数的分布或密度。因此 $p(\mathbf{x})$ 指的是函数形式，而不是在某个特定样本上的取值。当我们想表达在某一给定点处的取值时，会显式说明（例如 "在给定点 $\mathbf{x}$ 处计算 p"）。

条件表达式按上下文解读。对于 $p(\mathbf{x} \mid \mathbf{y})$，固定 $\mathbf{y}$ 后它是 $\mathbf{x}$ 的密度；固定 $\mathbf{x}$ 后它是 $\mathbf{y}$ 的函数。

对于条件期望，$\mathbb{E}[f(\mathbf{x}) \mid \mathbf{z}]$ 是 $\mathbf{z}$ 的函数，给出在给定 $\mathbf{z}$ 时 $f(\mathbf{x})$ 的期望值。当条件作用在某一具体实现值上时，写作 $\mathbb{E}[f(\mathbf{x}) \mid \mathbf{Z} = \mathbf{z}]$。等价地，它可以写成关于条件分布的积分：

$$\mathbb{E}_{\mathbf{x}\sim p(\cdot\mid\mathbf{z})}[f(\mathbf{x})] = \int f(\mathbf{x})\, p(\mathbf{x} \mid \mathbf{z})\, d\mathbf{x}.$$

这一区分澄清了 $\mathbf{z}$ 究竟是被视为定义一个函数的变量 $\mathbf{z} \mapsto \mathbb{E}[f(\mathbf{x}) \mid \mathbf{z}]$，还是被视为在其上计算该函数的固定取值。

Part A　深度生成建模导论

Chapter 1

深度生成建模

"What I cannot create, I do not understand."
— Richard P. Feynman

深度生成模型（Deep Generative Model, DGM）是一类神经网络，它在高维数据（例如图像、文本、音频）上学习一个概率分布，从而能够生成与数据集相似的新样本。我们用 p_ϕ 表示模型分布，用 p_{data} 表示数据分布。给定一个有限数据集，我们通过最小化一个衡量 p_ϕ 与 p_{data} 之间距离的损失来拟合 ϕ。训练完成后，生成即运行模型的采样过程，抽取 $\mathbf{x} \sim p_\phi$ （密度 $p_\phi(\mathbf{x})$ 是否可直接计算，取决于模型类别）。模型质量由生成样本及其汇总统计与 p_{data} 的匹配程度来判断，并辅以任务特定或感知类指标。

本章建立这些思想背后的数学与概念基础。我们在 §1.1 形式化问题，在 §1.2 给出代表性模型类，并在 §1.3 给出一个实用的分类学。

1.1 什么是深度生成建模？

DGM 以大量来自真实世界的样本（如图像、文本）为输入，这些样本来自一个未知而复杂的分布 p_{data}；它输出一个训练好的神经网络，用以参数化一个近似分布 p_ϕ。其目标有二：

1. **逼真生成**：产生新颖、逼真、与真实数据难以区分的样本.
2. **可控生成**：对生成过程进行细粒度、可解释的控制.

本小节介绍 DGM 背后的基本概念与动机，为后续深入探索其数学框架与实际应用做准备。

1.1.1 数学设置

假设我们能访问一个有限样本集，这些样本独立同分布（i.i.d.）地从某个底层复杂数据分布 $p_{\text{data}}(\mathbf{x})$ 中抽取[1]。

DGM 的目标. DGM 的首要目标是从有限数据集出发，学习一个可处理的概率分布。这些数据点是观测，假定来自一个未知而复杂的真实分布 $p_{\text{data}}(\mathbf{x})$。由于 $p_{\text{data}}(\mathbf{x})$ 的形式未知，我们无法直接从中抽取新样本。核心挑战因此在于：构造一个模型，使其对该分布的近似足够好，从而能够生成新的、逼真的样本。

[1]这是机器学习中常见的假设。为简便起见，我们用符号 p 同时表示概率分布及其概率密度 / 质量函数，具体含义由上下文决定。

为此，DGM 用一个深度神经网络参数化模型分布 $p_\phi(\mathbf{x})$，其中 ϕ 是网络中可训练的参数。训练目标是寻找最优参数 ϕ^*，使其最小化模型分布 $p_\phi(\mathbf{x})$ 与真实数据分布 $p_{\text{data}}(\mathbf{x})$ 之间的散度。在概念上，

$$p_{\phi^*}(\mathbf{x}) \approx p_{\text{data}}(\mathbf{x}).$$

当统计模型 $p_{\phi^*}(\mathbf{x})$ 紧密逼近数据分布 $p_{\text{data}}(\mathbf{x})$ 时，它即可作为代理，用于生成新样本并计算概率值。模型 $p_\phi(\mathbf{x})$ 通常被称为**生成模型**。

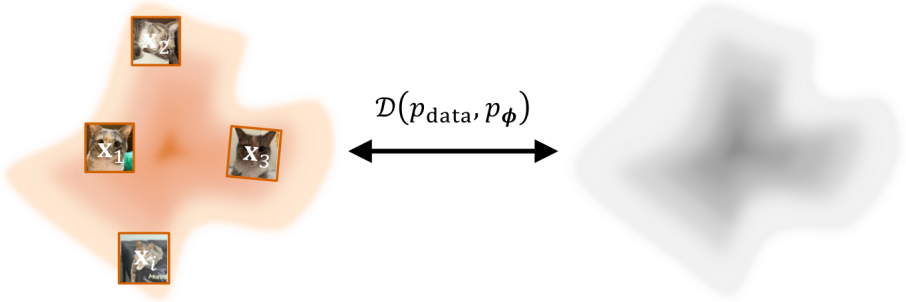


Figure 1.1: Illustration of the target in DGM. Training a DGM is essentially minimizing the discrepancy between the model distribution $p_{\boldsymbol{\phi}}$ and the unknown data distribution p_{data}. Since p_{data} is not directly accessible, this discrepancy must be estimated efficiently using a finite set of independent and identically distributed (i.i.d.) samples, $\mathbf{x}_i$, drawn from it.

Capability of DGM Once a proxy of the data distribution $p_\phi(\mathbf{x})$ is avail

图 1.3: DGM 目标的示意图。训练一个 DGM，本质上是最小化模型分布 p_ϕ 与未知数据分布 p_{data} 之间的差异。由于 p_{data} 不可直接访问，这一差异必须利用从它抽取的有限 i.i.d. 样本 $\mathbf{x}_i$ 来高效估计。

DGM 的能力. 一旦获得数据分布的代理 $p_\phi(\mathbf{x})$，我们即可借助采样方法（例如从 $p_\phi(\mathbf{x})$ 做 Monte Carlo 采样）生成任意多个新数据点。此外，给定任意样本 $\mathbf{x}'$，还可通过计算 $p_\phi(\mathbf{x}')$ 得到其概率（或似然）。

DGM 的训练. 我们通过最小化差异 $\mathcal{D}(p_{\text{data}}, p_\phi)$ 来学习模型族 $\{p_\phi\}$ 的参数 ϕ：

$$\phi^* \in \arg\min_{\phi} \ \mathcal{D}(p_{\text{data}}, p_\phi). \tag{1.1.1.1}$$

由于 p_{data} 未知，$\mathcal{D}$ 的实用选择必须能够用来自 p_{data} 的 i.i.d. 样本高效估计。在容量足够时，p_{ϕ^*} 可以紧密逼近 p_{data}。

前向 KL 与最大似然估计（MLE）. 一个标准选择是（前向）Kullback–Leibler 散度[2]：

$$\begin{aligned}\mathcal{D}_{\text{KL}}(p_{\text{data}} \| p_\phi) &:= \int p_{\text{data}}(\mathbf{x}) \log \frac{p_{\text{data}}(\mathbf{x})}{p_\phi(\mathbf{x})}\, d\mathbf{x} \\ &= \mathbb{E}_{\mathbf{x}\sim p_{\text{data}}}\big[\log p_{\text{data}}(\mathbf{x}) - \log p_\phi(\mathbf{x})\big].\end{aligned}$$

[2]所有积分均在 Lebesgue 意义下，在计数测度下退化为求和。

它是非对称的，即

$$\mathcal{D}_{\mathrm{KL}}(p_{\mathrm{data}}\|p_\phi) \neq \mathcal{D}_{\mathrm{KL}}(p_\phi\|p_{\mathrm{data}}).$$

重要的是，最小化 $\mathcal{D}_{\mathrm{KL}}(p_{\mathrm{data}}\|p_\phi)$ 会鼓励“覆盖所有模态”（mode covering）：若存在正测度集合 A，满足 $p_{\mathrm{data}}(A) > 0$，但对 $\mathbf{x} \in A$ 有 $p_\phi(\mathbf{x}) = 0$，则被积函数在 A 上含有 $\log \frac{p_{\mathrm{data}}(\mathbf{x})}{0} = +\infty$，从而 $\mathcal{D}_{\mathrm{KL}} = +\infty$。因此最小化前向 KL 会迫使模型在数据有支撑的所有位置都赋予概率。

尽管数据密度 $p_{\mathrm{data}}(\mathbf{x})$ 无法显式求值，前向 KL 散度可分解为

$$\begin{aligned}\mathcal{D}_{\mathrm{KL}}(p_{\mathrm{data}}\|p_\phi) &= \mathbb{E}_{\mathbf{x}\sim p_{\mathrm{data}}}\Big[\log \frac{p_{\mathrm{data}}(\mathbf{x})}{p_\phi(\mathbf{x})}\Big] \\ &= -\mathbb{E}_{\mathbf{x}\sim p_{\mathrm{data}}}\big[\log p_\phi(\mathbf{x})\big] + H(p_{\mathrm{data}}),\end{aligned}$$

其中 $H(p_{\mathrm{data}}) := -\mathbb{E}_{\mathbf{x}\sim p_{\mathrm{data}}}\big[\log p_{\mathrm{data}}(\mathbf{x})\big]$ 是数据分布的熵，关于 ϕ 为常数。这一观察给出如下等价关系：

引理 1.1.1 (最小化 KL $\Leftrightarrow$ MLE)**：**

$$\min_\phi \ \mathcal{D}_{\mathrm{KL}}(p_{\mathrm{data}}\|p_\phi) \quad\Longleftrightarrow\quad \max_\phi \ \mathbb{E}_{\mathbf{x}\sim p_{\mathrm{data}}}\big[\log p_\phi(\mathbf{x})\big]. \tag{1.1.1.2}$$

换言之，最小化前向 KL 散度等价于做最大似然估计（MLE）。

在实践中，我们用 i.i.d. 样本 $\{\mathbf{x}^{(i)}\}_{i=1}^N \sim p_{\mathrm{data}}$ 上的 Monte Carlo 估计替代总体期望，得到经验 MLE 目标：

$$\widehat{L}_{\mathrm{MLE}}(\phi) := -\frac{1}{N}\sum_{i=1}^N \log p_\phi\big(\mathbf{x}^{(i)}\big),$$

在小批量上用随机梯度优化；无需对 $p_{\mathrm{data}}(\mathbf{x})$ 求值。

Fisher 散度. Fisher 散度是（基于分数的）扩散建模中的另一重要概念（见第 3 章）。对两个分布 p 与 q，其定义为

$$\mathcal{D}_{\mathrm{F}}(p\|q) := \mathbb{E}_{\mathbf{x}\sim p}\Big[\big\|\nabla_{\mathbf{x}}\log p(\mathbf{x}) - \nabla_{\mathbf{x}}\log q(\mathbf{x})\big\|_2^2\Big]. \tag{1.1.1.3}$$

它衡量两个分数函数 $\nabla_{\mathbf{x}}\log p(\mathbf{x})$ 与 $\nabla_{\mathbf{x}}\log q(\mathbf{x})$ 之间的差异，二者都是指向更高概率区域的向量场。简言之，$\mathcal{D}_{\mathrm{F}}(p\|q) \geq 0$，等号当且仅当 $p = q$ 几乎处处成立。

它对归一化常数不变，因为分数只依赖于对数密度的梯度；它构成**分数匹配**（score matching，式 (3.1.3) 与 (3.2.1)）的基础：这一方法学习对数密度的梯度以用于生成（基于分数的模型）。在这一设置下，数据分布 $p = p_{\mathrm{data}}$ 作为目标，而模型 $q = p_\phi$ 被训练为使其分数场与数据的分数场对齐。

超越 KL. 尽管 KL 散度是衡量概率分布之间差异最常用的工具，但它并非唯一选择。不同散度捕捉不同的几何或统计差异概念，进而影响学习算法的优化动态。一族广泛的散度是 f-散度（Csiszár, 1963）：

$$\mathcal{D}_f(p\|q) = \int q(\mathbf{x})\, f\left(\frac{p(\mathbf{x})}{q(\mathbf{x})}\right)\, d\mathbf{x}, \qquad f(1) = 0, \tag{1.1.1.4}$$

其中 $f:\mathbb{R}_+\to\mathbb{R}$ 是凸函数。通过改变 f，可得到许多著名散度：

$$
\begin{aligned}
f(u)=u\log u \;&\Rightarrow\; \mathcal{D}_f=\mathcal{D}_{\mathrm{KL}}(p\|q)\quad\text{（前向 KL）},\\
f(u)=\tfrac{1}{2}\Big[u\log u-(u+1)\log\tfrac{1+u}{2}\Big] \;&\Rightarrow\; \mathcal{D}_f=\mathcal{D}_{\mathrm{JS}}(p\|q)\quad\text{（Jensen–Shannon）},\\
f(u)=\tfrac{1}{2}|u-1| \;&\Rightarrow\; \mathcal{D}_f=\mathcal{D}_{\mathrm{TV}}(p,q)\quad\text{（全变差）}.
\end{aligned}
$$

显式形式为

$$
\begin{aligned}
\mathcal{D}_{\mathrm{JS}}(p\|q)&=\tfrac{1}{2}\mathcal{D}_{\mathrm{KL}}\big(p\|\tfrac{p+q}{2}\big)+\tfrac{1}{2}\mathcal{D}_{\mathrm{KL}}\big(q\|\tfrac{p+q}{2}\big),\\
\mathcal{D}_{\mathrm{TV}}(p,q)&=\tfrac{1}{2}\int_{\mathbb{R}^D}|p-q|\,d\mathbf{x}=\sup_{A\subset\mathbb{R}^D}|p(A)-q(A)|.
\end{aligned}
$$

直观上，JS 散度提供了一种平滑而对称的度量，平衡两个分布并避免 KL 的无界惩罚（我们稍后会看到，它有助于解释生成对抗网络（GAN）框架）；而全变差距离捕捉两分布之间可能出现的最大概率差。

另一种视角来自最优传输（见第 7 章），其代表是 Wasserstein 距离。它衡量把概率质量从一个分布运输到另一个分布所需的最小代价。与比较密度比的 f-散度不同，Wasserstein 距离依赖于样本空间的几何，即使 p 与 q 的支撑不重叠也仍有意义。

每一种散度都体现了分布间“接近”的不同概念，因而诱导出不同的学习行为。在本专著后续章节中，当这些散度在生成建模语境中自然出现时，我们还会再讨论它们。

1.1.2 分布建模的挑战

为对复杂数据分布建模，我们可以用一个参数为 ϕ 的神经网络参数化概率密度 p_{data}，得到模型 p_ϕ。要使 p_ϕ 成为合法的概率密度，它必须满足两条基本性质：

1. **非负性**：对定义域内所有 $\mathbf{x}$，$p_\phi(\mathbf{x})\ge 0$.
2. **归一性**：在整个定义域上的积分等于 1，即 $\int p_\phi(\mathbf{x})\,d\mathbf{x}=1$.

一个网络对输入 $\mathbf{x}$ 自然地输出一个实标量 $E_\phi(\mathbf{x})\in\mathbb{R}$。要把这一输出解释为合法密度，必须经过变换以满足条件 (i) 与 (ii)。一个实用做法是把 $E_\phi:\mathbb{R}^D\to\mathbb{R}$ 视为定义了一个**未归一化密度**，再显式施加这些性质。

第一步：保证非负性. 我们可以通过对网络原始输出 $E_\phi(\mathbf{x})$ 施加一个正值函数（例如 $|E_\phi(\mathbf{x})|$、$E_\phi^2(\mathbf{x})$）来保证模型输出恒非负。一个标准而方便的选择是指数函数。这给出一个恒为正的未归一化密度 $\tilde{p}_\phi(\mathbf{x})$：

$$\tilde{p}_\phi(\mathbf{x})=\exp(E_\phi(\mathbf{x})).$$

第二步：施加归一性. 函数 $\tilde{p}_\phi(\mathbf{x})$ 为正，但积分不为 1。要得到合法概率密度，必须将其除以它在整个空间上的积分。这给出模型的最终形式：

$$p_\phi(\mathbf{x})=\frac{\tilde{p}_\phi(\mathbf{x})}{\int\tilde{p}_\phi(\mathbf{x}')\,d\mathbf{x}'}=\frac{\exp(E_\phi(\mathbf{x}))}{\int\exp(E_\phi(\mathbf{x}'))\,d\mathbf{x}'}.$$

上式分母称为归一化常数或配分函数（partition function），记作 $Z(\phi)$：

$$Z(\phi) := \int \exp(E_\phi(\mathbf{x}'))\, d\mathbf{x}'.$$

尽管这一构造给出了合法的 $p_\phi(\mathbf{x})$，却引入了一个重大计算挑战：对大多数高维问题，计算归一化常数 $Z(\phi)$ 所需的积分是不可处理的。这种不可处理性是一个核心问题，它推动了许多不同深度生成模型族的发展。

在后续小节中，我们介绍几种重要的 DGM 方法。每一种都为规避或降低计算这一归一化常数的代价而设计。

1.2 重要的深度生成模型

生成建模的一个中心挑战，是学习能够捕捉高维数据丰富而复杂结构的表达型概率模型。多年来，研究者发展出多种建模策略，每一种都在可处理性、表达能力与训练效率之间做出不同权衡。本小节探索几种塑造了本领域最具影响力的策略，并在图 1.4 中比较它们的计算图。

基于能量的模型（**Energy-Based Model, EBM**）. EBM（Ackley 等, 1985；LeCun 等, 2006）通过一个能量函数 $E_\phi(\mathbf{x})$ 定义概率分布：能量越低，对应的数据点越可能出现。某数据点的概率定义为

$$p_\phi(\mathbf{x}) := \frac{1}{Z(\phi)} \exp(-E_\phi(\mathbf{x})), \qquad Z(\phi) = \int \exp(-E_\phi(\mathbf{x}))\, d\mathbf{x},$$

其中 $Z(\phi)$ 是配分函数。训练 EBM 通常需要最大化数据的对数似然。然而，这要求有方法应对配分函数不可处理所带来的计算挑战。在下一章中，我们将看到扩散模型如何提供一种替代途径：它从对数密度的梯度生成数据，而该梯度不依赖归一化常数，从而规避了计算配分函数的需要。

自回归模型（AR）. 深度自回归（autoregressive, AR）模型（Frey 等, 1995；Larochelle 与 Murray, 2011；Uria 等, 2016）利用概率链式法则，将联合数据分布 p_{data} 分解为一系列条件概率的乘积：

$$p_{\text{data}}(\mathbf{x}) = \prod_{i=1}^{D} p_\phi(x_i \mid x_{<i}),$$

其中 $\mathbf{x} = (x_1, \ldots, x_D)$，$x_{<i} = (x_1, \ldots, x_{i-1})$。每个条件 $p_\phi(x_i \mid x_{<i})$ 由一个神经网络（例如 Transformer）参数化，可灵活建模复杂依赖。由于每个因子按构造都是归一化的（例如对离散变量用 softmax，对连续变量用参数化的 Gaussian），全局归一化是平凡的。训练通过最大化精确似然进行，等价于最小化负对数似然。

尽管 AR 模型在密度估计与精确似然上表现优异，其序列性限制了采样速度，固定顺序也可能限制灵活性。尽管如此，它们仍是基于似然的生成模型的基础类别，也是现代研究中的关键方法。

变分自编码器 **(Variational Autoencoder, VAE)．** VAE（Kingma 与 Welling, 2013）在经典自编码器中引入 隐变量（latent variable）$\mathbf{z}$，用以捕捉数据 $\mathbf{x}$ 中的隐藏结构。VAE 不直接学习 $\mathbf{x}$ 与 $\mathbf{z}$ 之间的映射，而是采用概率视角：同时学习一个 编码器（encoder）$q_\theta(\mathbf{z} \mid \mathbf{x})$，用以逼近在给定数据下隐变量的未知分布；以及一个 解码器（decoder）$p_\phi(\mathbf{x} \mid \mathbf{z})$，用以从这些隐变量重建数据。为使训练可行，VAE 最大化一个对真实对数似然的可处理代理，称为证据下界（Evidence Lower Bound, ELBO）：

$$L_{\mathrm{ELBO}}(\theta, \phi; \mathbf{x}) = \mathbb{E}_{q_\theta(\mathbf{z}|\mathbf{x})}\big[\log p_\phi(\mathbf{x} \mid \mathbf{z})\big] - \mathcal{D}_{\mathrm{KL}}\big(q_\theta(\mathbf{z} \mid \mathbf{x}) \| p_{\mathrm{prior}}(\mathbf{z})\big).$$

其中第一项鼓励对数据的准确重建，第二项则通过让隐变量接近一个简单先验分布 $p_{\mathrm{prior}}(\mathbf{z})$（通常为 Gaussian）来正则化隐变量。

VAE 提供了一种把神经网络与隐变量模型相结合的有原理可循的方法，至今仍是最常用的基于似然的方法之一。但它也面临实际挑战，例如样本锐度有限与训练病态（例如编码器倾向于忽略隐变量）。尽管存在这些局限，VAE 为后续进展（包括扩散模型）奠定了重要基础。

归一化流 **(Normalizing Flow, NF)．** 经典的流模型，例如归一化流（Rezende 与 Mohamed, 2015）与神经常微分方程（NODE，Chen 等, 2018），旨在通过一个可逆算子，学习从简单隐分布 $\mathbf{z}$ 到复杂数据分布 $\mathbf{x}$ 的双射 f_ϕ。这要么通过一系列双射变换实现（在 NF 中），要么通过把变换建模为常微分方程实现（在 NODE 中）。这些模型利用 “密度的变量替换公式”，使 MLE 训练成为可能：

$$\log p_\phi(\mathbf{x}) = \log p(\mathbf{z}) + \log \left| \det \frac{\partial f_\phi^{-1}(\mathbf{x})}{\partial \mathbf{x}} \right|,$$

其中 f_ϕ 表示把 $\mathbf{z}$ 映射到 $\mathbf{x}$ 的可逆变换。NF 用可逆变换显式建模归一化密度，并具有可处理的 Jacobian 行列式。归一化常数通过变量替换公式被解析吸收，使似然计算既精确又可处理。

尽管概念优雅，经典流模型在实践中常有局限。例如，NF 为保证双射性往往施加限制性的架构约束；而 NODE 由于求解 ODE 的计算开销，可能面临训练低效。两种方法在扩展到高维数据时都有挑战。在后续章节中，我们将探索扩散模型如何与这些经典流方法相联系并在其基础上发展。

生成对抗网络（GAN）． GAN（Goodfellow 等, 2014）由两个相互竞争的神经网络构成：一个生成器 G_ϕ 与一个判别器 D_ζ。生成器从随机噪声 $\mathbf{z} \sim p_{\mathrm{prior}}$ 出发，试图产生逼真样本 $G_\phi(\mathbf{z})$；判别器则试图区分真实样本 $\mathbf{x}$ 与生成样本 $G_\phi(\mathbf{z})$。GAN 的目标函数可写为

$$\min_{G_\phi} \max_{D_\zeta} \underbrace{\mathbb{E}_{\mathbf{x} \sim p_{\mathrm{data}}(\mathbf{x})}[\log D_\zeta(\mathbf{x})]}_{\text{real}} + \underbrace{\mathbb{E}_{\mathbf{z} \sim p_{\mathrm{prior}}(\mathbf{z})}[\log(1 - D_\zeta(G_\phi(\mathbf{z})))]}_{\text{fake}}.$$

GAN 不定义显式密度函数，因此完全绕开了似然估计。它不计算归一化常数，而是聚焦于生成与数据分布高度相似的样本。

从散度视角看，判别器隐式地衡量真实数据分布 p_{data} 与生成器分布 p_{G_ϕ} 之间的差异，其中 p_{G_ϕ} 表示由噪声 $\mathbf{z} \sim p_{\text{prior}}$ 得到的生成样本 $G_\phi(\mathbf{z})$ 的分布。对固定生成器 G_ϕ，最优判别器为 $\frac{p_{\text{data}}(\mathbf{x})}{p_{\text{data}}(\mathbf{x})+p_{G_\phi}(\mathbf{x})}$，此时生成器的最小化退化为

$$\min_{G_\phi} \; 2\,\mathcal{D}_{\text{JS}}\big(p_{\text{data}} \| p_{G_\phi}\big) - \log 4.$$

其中 $\mathcal{D}_{\text{JS}}$ 表示 Jensen–Shannon 散度，定义为

$$\mathcal{D}_{\text{JS}}(p\|q) := \tfrac{1}{2}\mathcal{D}_{\text{KL}}\big(p\|\tfrac{p+q}{2}\big) + \tfrac{1}{2}\mathcal{D}_{\text{KL}}\big(q\|\tfrac{p+q}{2}\big)\,.$$

这表明 GAN 隐式地最小化 $\mathcal{D}_{\text{JS}}(p_{\text{data}}\|p_{G_\phi})$。更广义地，f-GAN（Nowozin 等, 2016）等扩展表明，对抗训练可以最小化一族 f-散度，从而把 GAN 与其他生成模型一同置于“散度最小化” 这一统一框架下。

尽管 GAN 能够生成高质量数据，其 min-max 训练过程以不稳定著称，往往需要精心设计架构与工程技巧才能取得令人满意的性能。然而，GAN 后来作为辅助组件被复兴，用以增强其他生成模型，尤其是扩散模型。

1.3 建模方法分类学

如前所述，DGM 横跨一系列建模策略。一个根本区别在于：这些模型如何参数化底层数据分布——即它们是显式指定 $p_\phi(\mathbf{x})$，还是仅隐式指定；这与训练目标本身无关。

- **显式模型**：这类模型通过可处理或近似可处理的密度 / 质量函数，直接参数化概率分布 $p_\phi(\mathbf{x})$。例子包括 AR、NF、VAE 与 DM，它们要么精确地定义 $p_\phi(\mathbf{x})$，要么通过一个可处理的界定义它。
- **隐式模型**：这类模型仅通过一个采样过程指定分布，通常形如 $\mathbf{x} = G_\phi(\mathbf{z})$，其中 $\mathbf{z} \sim p_{\text{prior}}$ 为噪声变量。此时 $p_\phi(\mathbf{x})$ 没有闭式表达，甚至可能根本没有定义。

表 1 对这两类对立方法给出简明总结。

表 1: 显式与隐式生成模型的比较

	显式		**隐式**
	精确似然	**近似似然**	
似然目标	MLE	ELBO	对抗（Adversarial）
可处理性	可处理	界 / 近似	不直接建模 / 不可处理
代表模型	NF、AR	VAE、DM	GAN

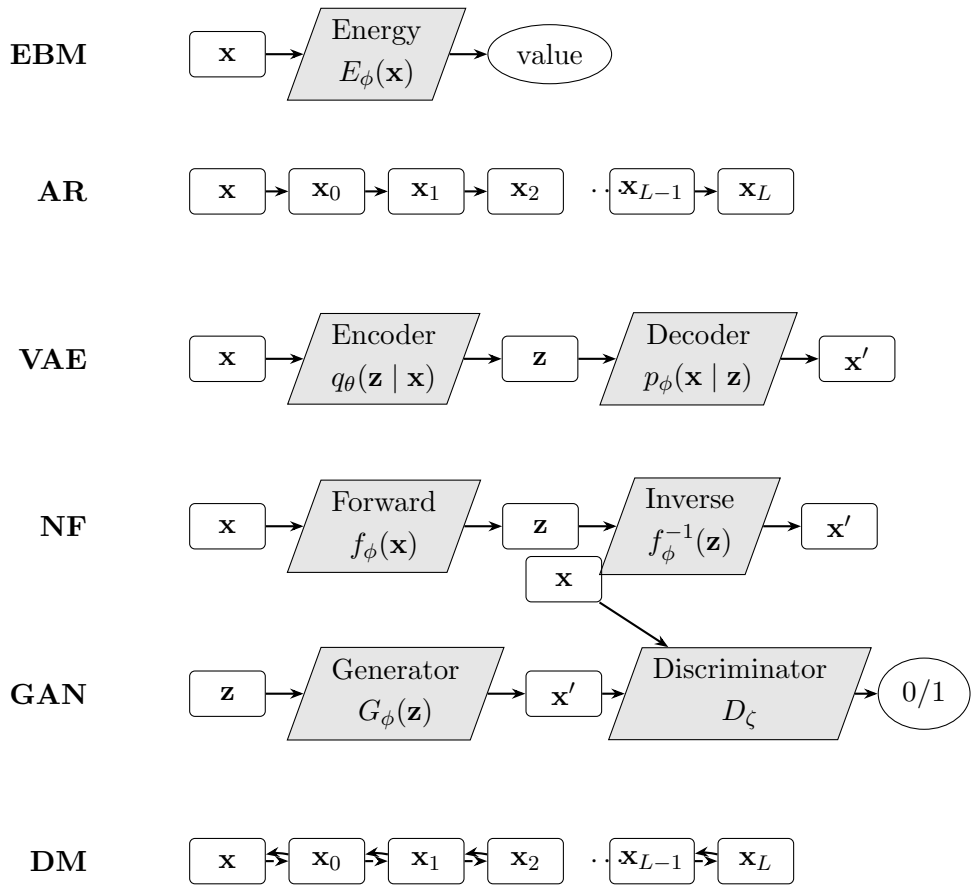


图 1.4: 主要深度生成模型的计算图。从上到下：EBM 将输入 $\mathbf{x}$ 映射为标量能量；AR 以因果依赖从左向右生成序列 $\{\mathbf{x}_\ell\}$；VAE 把 $\mathbf{x}$ 编码为隐变量 $\mathbf{z}$，再解码为重建 $\mathbf{x}'$；NF 在 $\mathbf{x}$ 与 $\mathbf{z}$ 之间施加可逆映射 f_ϕ，并用 f_ϕ^{-1} 产生 $\mathbf{x}'$；GAN 把噪声 $\mathbf{z}$ 变换为样本 $\mathbf{x}'$，并由判别器 D_ζ 与真实 $\mathbf{x}$ 比较；DM 通过多步去噪链 $\{\mathbf{x}_\ell\}$ 迭代精化一个含噪样本。方框表示变量，梯形表示可学习网络，椭圆表示标量；箭头表示计算流向。

与扩散模型的联系. 综合起来，这些经典 DGM 家族展示了建模复杂分布的互补策略。除各自独立的重要性之外，它们还为理解扩散模型提供了指引原则。扩散方法从其中若干视角继承了思想：通过变分训练目标与 VAE 相联系；通过学习对数密度梯度（与能量函数紧密相关）的分数匹配方法与 EBM 相联系；通过连续时间变换与 NF 相联系。

为给后续章节讨论的扩散方法奠定基础，我们聚焦于三个中心范式：VAE（§1.2）、EBM（§3.1）与 NF（§1.2）。这一探索将为后续章节中现代基于扩散的生成建模的核心原理打下基础。

1.4 小结

本章建立了深度生成建模的基础概念。我们首先定义首要目标：学习一个可处理的模型分布 p_{model}（由 ϕ 参数化），使其逼近未知而复杂的数据分布 p_{data}。一个核心挑战是归一化常数（即配分函数 $Z(\phi)$）的计算不可处理，而要定义合法概率密度就必须得到它。

为绕开这一问题，人们发展了多种深度生成模型族，各自采用不同策略。我们综述了若干重要方法：基于能量的模型（EBM）、自回归模型（AR）、变分自编码器（VAE）、归一化流（NF）与生成对抗网络（GAN）。这些模型可大致分为两类：显式模型定义可处理密度；隐式模型仅通过采样过程定义分布。

尽管这些经典框架各自都很重要，但其中三者尤其构成本专著所聚焦的扩散模型的概念起源：VAE、EBM 与 NF。在后续章节中，我们将追踪扩散模型从这三个基础范式出发的演化：

1. Part B 将从变分视角（第 2 章）开始，展示 VAE 的（层次化隐变量结构）如何自然地导向去噪扩散概率模型（DDPM）的形式化；

2. 随后，我们将考察分数视角（第 3 章），它起源于 EBM 与分数匹配，并发展为噪声条件分数网络（NCSN）以及更一般的 Score SDE 框架（第 4 章）；

3. 最后，我们将研究流视角（第 5 章），它建立在归一化流的原理之上，把生成刻画为一个连续变换，并由流匹配（Flow Matching）概念加以推广。

通过理解这些起源，我们将建立一个连贯框架，用以解读扩散模型的各种形式化表述，并揭示统一它们的深层原理。

Part B　扩散模型的起源与基础

Chapter 2

变分视角：从 VAE 到 DDPM

本章我们透过变分透镜看待扩散模型。我们从变分自编码器（VAE）出发：它用隐变量表示数据，并通过最大化对数似然的一个可处理下界来训练。在这一设置下，一个学到的编码器把观测映射到隐变量，一个学到的解码器再把隐变量映射回观测，从而闭合建模回路。

在这一模式之上，层次化变体（层次化 VAE）堆叠多层隐变量，以在多个尺度上捕捉结构。沿用这一模板，去噪扩散概率模型（DDPM）遵循同一框架：不再联合训练编码器与解码器，而是把编码器固定为一个前向加噪过程，它逐步把数据映射为噪声；训练则学习一个解码器，使其在连续的去噪步骤中逆转这一路径。在这一视角下，VAE、层次化 VAE 与扩散模型都在优化一个由变分界定义的似然代理，从而为这里介绍的方法提供了共同基础。

2.1 变分自编码器

神经网络如何学会生成逼真数据？一个自然出发点是自编码器（autoencoder）：它由两个网络构成——一个确定性编码器，把输入压缩为低维隐码；以及一个确定性解码器，从该码重建输入。训练最小化原始输入与其重建之间的误差。这一设置虽能实现精确重建，但隐空间是无结构的：随机采样隐码通常产生无意义的输出，限制了模型在生成上的用途。

变分自编码器（VAE，Kingma 与 Welling, 2013）通过在隐空间上施加概率结构来解决这一问题。这把模型从一个简单的重建工具转变为一个真正的生成模型，能够产生新颖而逼真的数据。

2.1.1 概率编码器与解码器

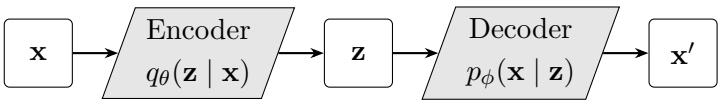


图 2.5: VAE 示意图。它由一个随机编码器 $q_\theta(\mathbf{z} \mid \mathbf{x})$（把数据 $\mathbf{x}$ 映射到隐变量 $\mathbf{z}$）与一个解码器 $p_\phi(\mathbf{x} \mid \mathbf{z})$（从隐变量重建数据）构成。

解码器（生成器）的构造. 在 VAE 中，我们区分两类变量：观测变量 $\mathbf{x}$，对应于我们看到的数据（例如图像）；以及隐变量 $\mathbf{z}$，它捕捉数据中隐藏的变化因子（例如物体形状、颜色或风格）。模型假设每个观测 $\mathbf{x}$ 都由一个从简单先验分布中采样的隐变量生成，该先验通常为标准 Gaussian：$\mathbf{z} \sim p_{\text{prior}} := \mathcal{N}(\mathbf{0}, \mathbf{I})$。

为把 $\mathbf{z}$ 映射回数据空间，我们定义一个解码器（生成器）分布 $p_\phi(\mathbf{x} \mid \mathbf{z})$。在实践中，解码器保持简单，常用分解 Gaussian（见 §2.1.3）或类似分布，以便学习聚焦于抽取有用的隐特征，而非记忆数据。直观上，逐像素直接生成极其困难；隐变量提供了一种紧凑表示，由此解码出精确像素布局要容易得多。新样本的产生方式是：先采样 $\mathbf{z} \sim p_{\text{prior}}$，再解码 $\mathbf{x} \sim p_\phi(\mathbf{x} \mid \mathbf{z})$。

由此，VAE 通过边缘似然定义了一个隐变量生成模型：

$$p_\phi(\mathbf{x}) = \int p_\phi(\mathbf{x} \mid \mathbf{z})\, p(\mathbf{z})\, d\mathbf{z}.$$

理想情况下，解码器参数 ϕ 应通过最大化这一边缘似然来学习，正如最大似然估计（见式 (1.1.1.2)）。然而，对表达型非线性解码器，关于 $\mathbf{z}$ 的积分不可处理，直接 MLE 在计算上不可行，这促使 VAE 采用变分方法。

编码器（推断网络）的构造. 为把不可处理的生成器与真实数据相连接，考虑反向问题：给定观测 $\mathbf{x}$，哪些隐码 $\mathbf{z}$ 可能产生它？由 Bayes 公式，后验为

$$p_\phi(\mathbf{z} \mid \mathbf{x}) = \frac{p_\phi(\mathbf{x} \mid \mathbf{z})\, p(\mathbf{z})}{p_\phi(\mathbf{x})}.$$

困难在于分母涉及边缘似然 $p_\phi(\mathbf{x})$，需要对所有隐变量积分，对非线性解码器不可处理。因此，由 $\mathbf{x}$ 精确推断 $\mathbf{z}$ 在计算上不可行。

VAE 中的 “变分” 一步正是用一个可处理的近似替换不可处理的后验。我们引入一个由神经网络参数化的编码器（或推断网络）$q_\theta(\mathbf{z} \mid \mathbf{x})$，其作用是充当可学习的代理：

$$q_\theta(\mathbf{z} \mid \mathbf{x}) \approx p_\phi(\mathbf{z} \mid \mathbf{x}).$$

在实践中，编码器把每个观测数据点 $\mathbf{x}$ 映射到隐码上的一个分布，从而提供一条从 $\mathbf{x}$ 回到 $\mathbf{z}$ 的可行、可训练路径。

2.1.2 通过证据下界（ELBO）训练

我们现在定义一个可计算的训练目标。虽然无法直接优化 $\log p_\phi(\mathbf{x})$，但可以最大化它的一个下界——证据下界（ELBO）：

定理 2.1.1 (证据下界（ELBO）)**：** *对任意数据点 $\mathbf{x}$，对数似然满足*

$$\log p_\phi(\mathbf{x}) \geq L_{\text{ELBO}}(\theta, \phi; \mathbf{x}),$$

其中 ELBO 为

$$L_{\text{ELBO}} = \underbrace{\mathbb{E}_{\mathbf{z} \sim q_\theta(\mathbf{z}|\mathbf{x})}\big[\log p_\phi(\mathbf{x} \mid \mathbf{z})\big]}_{\text{重建项}} - \underbrace{\mathcal{D}_{\text{KL}}\big(q_\theta(\mathbf{z} \mid \mathbf{x}) \| p(\mathbf{z})\big)}_{\text{隐变量正则}}. \tag{2.2.1.5}$$

证明： ELBO 来自 Jensen 不等式：

$$\begin{aligned}\log p_\phi(\mathbf{x}) &= \log \int p_\phi(\mathbf{x}, \mathbf{z})\, d\mathbf{z} = \log \int q_\theta(\mathbf{z} \mid \mathbf{x}) \frac{p_\phi(\mathbf{x}, \mathbf{z})}{q_\theta(\mathbf{z} \mid \mathbf{x})}\, d\mathbf{z} \\ &= \log \mathbb{E}_{\mathbf{z} \sim q_\theta(\mathbf{z}|\mathbf{x})}\left[\frac{p_\phi(\mathbf{x}, \mathbf{z})}{q_\theta(\mathbf{z} \mid \mathbf{x})}\right] \geq \mathbb{E}_{\mathbf{z} \sim q_\theta(\mathbf{z}|\mathbf{x})}\left[\log \frac{p_\phi(\mathbf{x}, \mathbf{z})}{q_\theta(\mathbf{z} \mid \mathbf{x})}\right].\end{aligned}$$

展开即得式 (2.2.1.5)。 □

ELBO 目标自然分解为两部分：

- **重建项**：鼓励从隐码 $\mathbf{z}$ 准确恢复 $\mathbf{x}$。在 Gaussian 编码器与解码器假设下，该项恰好退化为自编码器中熟悉的重建损失（见 §2.1.3）。然而与自编码器一样，仅优化该项有记忆训练数据的风险，这促使引入额外正则。
- **隐变量 KL**：鼓励编码器分布 $q_\theta(\mathbf{z} \mid \mathbf{x})$ 保持接近一个简单的 Gaussian 先验 $p_{\text{prior}}(\mathbf{z})$。这一正则把隐空间塑形为平滑而连续的结构，保证从先验采样出的样本可以被可靠解码，从而实现有意义的生成。

这一权衡既保证重建忠实，又保证采样连贯。

信息论视角：ELBO 作为散度界. ELBO 目标有一个自然的信息论解释。回顾最大似然训练等价于最小化 KL 散度 $\mathcal{D}_{\text{KL}}(p_{\text{data}}(\mathbf{x}) \| p_\phi(\mathbf{x}))$，它衡量模型分布对数据分布的逼近程度。由于该项一般不可处理，变分框架引入一种联合比较。

具体地，考虑两个联合分布：

- **生成联合** $p_\phi(\mathbf{x}, \mathbf{z}) = p(\mathbf{z})\, p_\phi(\mathbf{x} \mid \mathbf{z})$，描述模型如何生成数据；
- **推断联合** $q_\theta(\mathbf{x}, \mathbf{z}) = p_{\text{data}}(\mathbf{x})\, q_\theta(\mathbf{z} \mid \mathbf{x})$，把真实数据与其推断出的隐变量耦合。

比较这两个分布给出不等式

$$\mathcal{D}_{\text{KL}}\big(p_{\text{data}}(\mathbf{x}) \| p_\phi(\mathbf{x})\big) \le \mathcal{D}_{\text{KL}}\big(q_\theta(\mathbf{x}, \mathbf{z}) \| p_\phi(\mathbf{x}, \mathbf{z})\big), \tag{2.2.1.6}$$

有时称为 KL 散度的链式法则。直观上，仅比较边缘 $(\mathbf{x})$ 可能掩盖失配，而当考虑完整的隐–数据联合时这些失配就会暴露出来。

形式上，可把联合 KL 展开为

$$\begin{aligned}
\underbrace{\mathcal{D}_{\text{KL}}\big(q_\theta(\mathbf{x}, \mathbf{z}) \| p_\phi(\mathbf{x}, \mathbf{z})\big)}_{\text{总误差界}} &= \mathbb{E}_{q_\theta(\mathbf{x}, \mathbf{z})}\left[\log \frac{p_{\text{data}}(\mathbf{x})\, q_\theta(\mathbf{z} \mid \mathbf{x})}{p_\phi(\mathbf{x})\, p_\phi(\mathbf{z} \mid \mathbf{x})}\right] \\
&= \mathbb{E}_{p_{\text{data}}(\mathbf{x})}\left[\log \frac{p_{\text{data}}(\mathbf{x})}{p_\phi(\mathbf{x})} + \mathcal{D}_{\text{KL}}\big(q_\theta(\mathbf{z} \mid \mathbf{x}) \| p_\phi(\mathbf{z} \mid \mathbf{x})\big)\right] \\
&= \underbrace{\mathcal{D}_{\text{KL}}(p_{\text{data}} \| p_\phi)}_{\text{真实建模误差}} + \underbrace{\mathbb{E}_{p_{\text{data}}(\mathbf{x})} \mathcal{D}_{\text{KL}}\big(q_\theta(\mathbf{z} \mid \mathbf{x}) \| p_\phi(\mathbf{z} \mid \mathbf{x})\big)}_{\text{推断误差}},
\end{aligned}$$

其中第一项是真实建模误差，第二项是推断误差，即近似后验与真实后验之间的差距。后者恒非负，这解释了式 (2.2.1.6)。

最后注意

$$\log p_\phi(\mathbf{x}) - L_{\text{ELBO}}(\theta, \phi; \mathbf{x}) = \mathcal{D}_{\text{KL}}\big(q_\theta(\mathbf{z} \mid \mathbf{x}) \| p_\phi(\mathbf{z} \mid \mathbf{x})\big).$$

因此推断误差恰好是对数似然与 ELBO 之间的差距。最大化 ELBO 因而等价于直接减小推断误差，保证训练最小化总界中有意义的一部分。

2.1.3 Gaussian VAE

VAE 的一种标准形式对编码器与解码器均采用 Gaussian 分布。

编码器部分. 编码器 $q_\theta(\mathbf{z} \mid \mathbf{x})$ 通常建模为 Gaussian：

$$q_\theta(\mathbf{z} \mid \mathbf{x}) := \mathcal{N}\big(\mathbf{z}; \boldsymbol{\mu}_\theta(\mathbf{x}), \mathrm{diag}(\boldsymbol{\sigma}_\theta^2(\mathbf{x}))\big),$$

其中 $\boldsymbol{\mu}_\theta : \mathbb{R}^D \to \mathbb{R}^d$ 与 $\boldsymbol{\sigma}_\theta : \mathbb{R}^D \to \mathbb{R}^d_+$ 是编码器网络的确定性输出。

解码器部分. 解码器通常建模为固定方差的 Gaussian：

$$p_\phi(\mathbf{x} \mid \mathbf{z}) := \mathcal{N}\big(\mathbf{x}; \boldsymbol{\mu}_\phi(\mathbf{z}), \sigma^2 \mathbf{I}\big),$$

其中 $\boldsymbol{\mu}_\phi : \mathbb{R}^d \to \mathbb{R}^D$ 是一个神经网络，$\sigma > 0$ 是控制方差的小常数。

在这一假设下，ELBO 中的重建项简化为

$$\mathbb{E}_{q_\theta(\mathbf{z}|\mathbf{x})}\big[\log p_\phi(\mathbf{x} \mid \mathbf{z})\big] = -\frac{1}{2\sigma^2}\mathbb{E}_{q_\theta(\mathbf{z}|\mathbf{x})}\big[\|\mathbf{x} - \boldsymbol{\mu}_\phi(\mathbf{z})\|^2\big] + C,$$

其中 C 是与 θ、ϕ 无关的常数。ELBO 目标因而退化为

$$\min_{\theta,\phi} \ \mathbb{E}_{q_\theta(\mathbf{z}|\mathbf{x})}\Big[\tfrac{1}{2\sigma^2}\|\mathbf{x} - \boldsymbol{\mu}_\phi(\mathbf{z})\|^2\Big] + \mathcal{D}_{\mathrm{KL}}\big(q_\theta(\mathbf{z} \mid \mathbf{x}) \| p_{\mathrm{prior}}(\mathbf{z})\big),$$

由于 Gaussian 假设，KL 项有闭式解。训练 VAE 因而退化为最小化一个正则化的重建损失。

2.1.4 标准 VAE 的缺陷

尽管 VAE 框架在理论上很有吸引力，它却有一个关键缺陷：常常产生模糊的输出。

VAE 中模糊的生成. 为理解这一现象，考虑一个固定的 Gaussian 编码器 $q_{\mathrm{enc}}(\mathbf{z} \mid \mathbf{x})$，以及如下形式的解码器

$$p_{\mathrm{dec}}(\mathbf{x} \mid \mathbf{z}) = \mathcal{N}(\mathbf{x}; \boldsymbol{\mu}(\mathbf{z}), \sigma^2 \mathbf{I}),$$

其中 $\boldsymbol{\mu}(\mathbf{z})$ 表示解码器网络。对任意编码器，优化 ELBO（相差一个加性常数）退化为最小化期望重建误差：

$$\arg\min_{\boldsymbol{\mu}} \ \mathbb{E}_{p_{\mathrm{data}}(\mathbf{x})q_{\mathrm{enc}}(\mathbf{z}|\mathbf{x})}\big[\|\mathbf{x} - \boldsymbol{\mu}(\mathbf{z})\|^2\big].$$

这是关于 $\boldsymbol{\mu}(\mathbf{z})$ 的标准最小二乘问题，其解由条件均值以闭式给出：

$$\boldsymbol{\mu}^*(\mathbf{z}) = \mathbb{E}_{q_{\mathrm{enc}}(\mathbf{x}|\mathbf{z})}[\mathbf{x}],$$

其中 $q_{\mathrm{enc}}(\mathbf{x} \mid \mathbf{z})$ 是由编码器诱导的“给定隐变量时输入上的后验”，通过 Bayes 公式定义：

$$q_{\mathrm{enc}}(\mathbf{x} \mid \mathbf{z}) = \frac{q_{\mathrm{enc}}(\mathbf{z} \mid \mathbf{x})\, p_{\mathrm{data}}(\mathbf{x})}{p_{\mathrm{prior}}(\mathbf{z})}.$$

由 Bayes 公式，最优生成器的等价形式为

$$\boldsymbol{\mu}^*(\mathbf{z}) = \frac{\mathbb{E}_{p_{\text{data}}(\mathbf{x})}\big[q_{\text{enc}}(\mathbf{z} \mid \mathbf{x}) \cdot \mathbf{x}\big]}{\mathbb{E}_{p_{\text{data}}(\mathbf{x})}\big[q_{\text{enc}}(\mathbf{z} \mid \mathbf{x})\big]}.$$

现在假设两个不同输入 $\mathbf{x} \neq \mathbf{x}'$ 被映射到隐空间中相互重叠的区域，即 $q_{\text{enc}}(\cdot \mid \mathbf{x})$ 与 $q_{\text{enc}}(\cdot \mid \mathbf{x}')$ 的支撑相交。也就是说，$\boldsymbol{\mu}^*(\mathbf{z})$ 是在多个可能无关的输入上取平均，这导致模糊而无区分度的输出。这种在相互冲突模态上取平均的效应，是 VAE 生成样本特征性模糊的根本原因。

2.1.5 （可选）从标准 VAE 到层次化 VAE

为对复杂数据建模，层次化变分自编码器（HVAE，Vahdat 与 Kautz, 2020）通过引入隐变量层次来增强 VAE。这种深度、分层的结构使模型能在多个抽象层级上捕捉数据特征，显著提升表达能力，并反映真实世界数据的组合性本质。

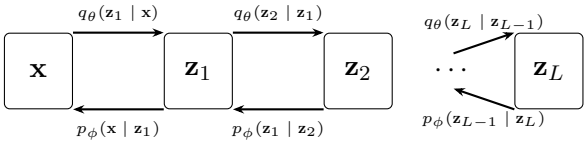


图 2.6: HVAE 的计算图。它具有层次结构，跨多个隐变量层堆叠可训练的编码器与解码器。

HVAE 的建模. 与使用单一隐码 $\mathbf{z}$ 的标准 VAE 不同，层次化 VAE（HVAE）引入多层隐变量，按自顶向下的层次排列。每一层隐变量条件化下一层，形成一条条件先验链，在越来越细的抽象层级上捕捉结构。这给出联合分布的如下自顶向下分解：

$$p_\phi(\mathbf{x}, \mathbf{z}_{1:L}) = p_\phi(\mathbf{x} \mid \mathbf{z}_1) \prod_{i=2}^{L} p_\phi(\mathbf{z}_{i-1} \mid \mathbf{z}_i)\, p(\mathbf{z}_L).$$

这一结构定义了边缘数据分布

$$p_{\text{HVAE}}(\mathbf{x}) := \int p_\phi(\mathbf{x}, \mathbf{z}_{1:L})\, d\mathbf{z}_{1:L}.$$

生成按渐进方式进行：从顶层隐变量 $\mathbf{z}_L$ 开始，依次向下解码每一层隐变量直到 $\mathbf{z}_1$，最后生成观测 $\mathbf{x}$。

在编码部分，HVAE 使用一个结构化、可学习的变分编码器 $q_\theta(\mathbf{z}_{1:L} \mid \mathbf{x})$，它镜像生成层次。一种常见选择是自底向上的 Markov 分解：

$$q_\theta(\mathbf{z}_{1:L} \mid \mathbf{x}) = q_\theta(\mathbf{z}_1 \mid \mathbf{x}) \prod_{i=2}^{L} q_\theta(\mathbf{z}_i \mid \mathbf{z}_{i-1}).$$

HVAE 的 ELBO. 与式 (2.2.1.5) 类似，ELBO 通过 Jensen 不等式导出：

$$\begin{aligned}\log p_{\mathrm{HVAE}}(\mathbf{x}) &= \log \int p_\phi(\mathbf{x}, \mathbf{z}_{1:L})\, d\mathbf{z}_{1:L} = \log \int \frac{p_\phi(\mathbf{x}, \mathbf{z}_{1:L})}{q_\theta(\mathbf{z}_{1:L} \mid \mathbf{x})}\, q_\theta(\mathbf{z}_{1:L} \mid \mathbf{x})\, d\mathbf{z}_{1:L} \\ &= \log \mathbb{E}_{q_\theta(\mathbf{z}_{1:L}|\mathbf{x})}\left[\frac{p_\phi(\mathbf{x}, \mathbf{z}_{1:L})}{q_\theta(\mathbf{z}_{1:L} \mid \mathbf{x})}\right] \geq \mathbb{E}_{q_\theta(\mathbf{z}_{1:L}|\mathbf{x})}\left[\log \frac{p_\phi(\mathbf{x}, \mathbf{z}_{1:L})}{q_\theta(\mathbf{z}_{1:L} \mid \mathbf{x})}\right] =: L_{\mathrm{ELBO}}(\phi).\end{aligned} \tag{2.2.1.7}$$

代入分解形式得到

$$L_{\mathrm{ELBO}} = \mathbb{E}_{q_\theta(\mathbf{z}_{1:L}|\mathbf{x})}\left[\log \frac{p(\mathbf{z}_L)\prod_{i=2}^{L} p_\phi(\mathbf{z}_{i-1} \mid \mathbf{z}_i)\, p_\phi(\mathbf{x} \mid \mathbf{z}_1)}{q_\theta(\mathbf{z}_1 \mid \mathbf{x})\prod_{i=2}^{L} q_\theta(\mathbf{z}_i \mid \mathbf{z}_{i-1})}\right].$$

这一层次化 ELBO 分解为可解释的若干项，包括一个重建项，以及每个生成条件与其对应变分近似之间的 KL 散度。

从浅层网络到深层网络的跃迁革新了机器学习，类似思想也革新了生成模型。HVAE 展示了用深度、堆叠层构造数据的威力。这种分层层次的概念是现代生成建模的基石，它在基于分数的方法（§3.4）与归一化流（§1.2）中再次出现。核心洞见简单而有力：

注 2.1.1 (分层堆叠使数据渐进生成)**：** *堆叠各层使模型能够渐进地生成数据：从粗细节开始，在每一步加入更细的细节。这一过程使捕捉高维数据的复杂结构变得容易得多。*◇

为何在扁平 VAE 中加深网络并不够. 标准扁平 VAE 有两条根本局限，仅靠把编码器与解码器加深并不能解决。

第一条局限是变分族。在标准 VAE 中，

$$q_\theta(\mathbf{z} \mid \mathbf{x}) = \mathcal{N}\big(\mathbf{z}; \boldsymbol{\mu}_\theta(\mathbf{x}), \mathrm{diag}(\boldsymbol{\sigma}_\theta^2(\mathbf{x}))\big),$$

因此对每个固定 $\mathbf{x}$，编码器后验只是一个对角协方差的 Gaussian。网络更深可提升 $\boldsymbol{\mu}_\theta$ 与 $\boldsymbol{\sigma}_\theta$ 的精度，但并不扩展变分族；即使使用满协方差，它仍是一个单峰椭球。当 $p_\phi(\mathbf{z} \mid \mathbf{x})$ 是多峰时，这一变分族无法匹配它，从而使 ELBO 变松、推断变弱。解决这一问题需要更丰富的后验类，而不只是更深的网络。

第二条局限是，若解码器表达能力过强，模型可能遭遇后验崩塌（posterior collapse）。为看清原因，回顾 VAE 的目标

$$\begin{aligned}&\mathbb{E}_{p_{\mathrm{data}}(\mathbf{x})}\big[L_{\mathrm{ELBO}}(\mathbf{x})\big] \\ &= \mathbb{E}_{p_{\mathrm{data}}(\mathbf{x})q_\theta(\mathbf{z}|\mathbf{x})}\big[\log p_\phi(\mathbf{x} \mid \mathbf{z})\big] - \mathbb{E}_{p_{\mathrm{data}}(\mathbf{x})}\mathcal{D}_{\mathrm{KL}}\big(q_\theta(\mathbf{z} \mid \mathbf{x}) \| p(\mathbf{z})\big) \\ &= \mathbb{E}_{p_{\mathrm{data}}(\mathbf{x})q_\theta(\mathbf{z}|\mathbf{x})}\big[\log p_\phi(\mathbf{x} \mid \mathbf{z})\big] - I_q(\mathbf{x}; \mathbf{z}) - \mathcal{D}_{\mathrm{KL}}\big(q_\theta(\mathbf{z}) \| p(\mathbf{z})\big),\end{aligned}$$

其中互信息 $I_q(\mathbf{x}; \mathbf{z})$ 定义为

$$I_q(\mathbf{x}; \mathbf{z}) = \mathbb{E}_{q(\mathbf{x},\mathbf{z})}\left[\log \frac{q_\theta(\mathbf{z} \mid \mathbf{x})}{q(\mathbf{z})}\right] = \mathbb{E}_{p_{\mathrm{data}}(\mathbf{x})}\mathcal{D}_{\mathrm{KL}}\big(q_\theta(\mathbf{z} \mid \mathbf{x}) \| q(\mathbf{z})\big),$$

聚合后验 $q_\theta(\mathbf{z}) = \int p_{\mathrm{data}}(\mathbf{x})\, q_\theta(\mathbf{z} \mid \mathbf{x})\, d\mathbf{x}$。

若解码器类能在不使用 $\mathbf{z}$ 的情况下很好地建模数据（即它包含某个 $p_\phi(\mathbf{x} \mid \mathbf{z}) = r(\mathbf{x})$ 接近 p_{data}），则 ELBO 的最大化者会取 $q_\theta(\mathbf{z} \mid \mathbf{x}) = p(\mathbf{z})$，于是 $I_q(\mathbf{x}; \mathbf{z}) = 0$ 且 $q_\theta(\mathbf{z}) = p(\mathbf{z})$。这种 “忽略 $\mathbf{z}$” 的解并不会因加深网络而消失：(1) 学到的码变得与 $\mathbf{x}$ 独立（因而不携带对下游任务有用的、依赖数据的结构）；(2) 在 $\mathbf{z}$ 上做条件化或移动对生成样本无影响，可控生成失败。

层次带来的改变. HVAE 引入多个隐层级，

$$p_\phi(\mathbf{x}, \mathbf{z}_{1:L}) = p_\phi(\mathbf{x} \mid \mathbf{z}_1) \prod_{i=2}^{L} p_\phi(\mathbf{z}_{i-1} \mid \mathbf{z}_i)\, p(\mathbf{z}_L),$$

其 ELBO 为

$$\begin{aligned} L_{\text{ELBO}}(\mathbf{x}) = {} & \mathbb{E}_q\big[\log p_\phi(\mathbf{x} \mid \mathbf{z}_1)\big] - \mathbb{E}_q\big[\mathcal{D}_{\text{KL}}\big(q_\theta(\mathbf{z}_1 \mid \mathbf{x}) \| p_\phi(\mathbf{z}_1 \mid \mathbf{z}_2)\big)\big] \\ & - \sum_{i=2}^{L-1} \mathbb{E}_q\big[\mathcal{D}_{\text{KL}}\big(q_\theta(\mathbf{z}_i \mid \mathbf{z}_{i-1}) \| p_\phi(\mathbf{z}_i \mid \mathbf{z}_{i+1})\big)\big] - \mathbb{E}_q\big[\mathcal{D}_{\text{KL}}\big(q_\theta(\mathbf{z}_L \mid \mathbf{z}_{L-1}) \| p(\mathbf{z}_L)\big)\big]. \end{aligned}$$

这里记 $\mathbb{E}_q := \mathbb{E}_{p_{\text{data}}(\mathbf{x}) q_\theta(\mathbf{z}_{1:L} \mid \mathbf{x})}$。每个推断条件都与其自顶向下的生成对应物对齐：$q_\theta(\mathbf{z}_1 \mid \mathbf{x})$ 对齐 $p_\phi(\mathbf{z}_1 \mid \mathbf{z}_2)$，中间层对齐 $p_\phi(\mathbf{z}_i \mid \mathbf{z}_{i+1})$，顶层对齐先验 $p(\mathbf{z}_L)$。这把信息惩罚分散到各个层级，并通过这些相邻 KL 项局部化学习信号。这些性质来自层次隐变量图，而不是简单地在扁平 VAE 中加深网络。

后续内容. 尽管 HVAE 通过多层隐变量扩展了 VAE 框架以增强表达能力，其训练却带来独特挑战。由于编码器与解码器必须联合优化，学习变得不稳定：低层与解码器已经能重建 $\mathbf{x}$，留给高层隐变量的有效信号很少。此外，到达更深变量的梯度信息往往是间接而微弱的，使它们难以有意义地贡献。另一个困难在于平衡模型容量：表达能力过强的条件项可能主导重建任务，抑制高层隐变量的效用。

有趣的是，这种深度、分层层次的核心思想在变分扩散模型中找到了更强大的化身，这是 §2.2 的主题。扩散模型继承了 HVAE 的渐进结构，却巧妙地绕开了其核心弱点。通过固定编码过程、只专注于学习生成反向，它们解锁了新的稳定性与建模灵活性，使生成输出质量大幅跃升。

注 2.1.2 (记号约定)**：** *为简便起见，我们偏离 VAE 中用 q 表示编码器、p 表示生成器的常见约定。为避免歧义，我们把分布都记作 p，并通过适当的下标或上标在上下文中明确其角色。* ◇

2.2 变分视角：DDPM

去噪扩散概率模型（DDPM，Sohl-Dickstein 等, 2015；Ho 等, 2020）是扩散建模的基石。在概念上，它们与 VAE、HVAE 一样在变分框架内运作。然而 DDPM 引入了一个巧妙转折，解决了前代方法面临的一些挑战。

其核心，DDPM 涉及两个不同的随机过程：

- **前向过程（固定编码器）**：该过程通过转移核 $p(\mathbf{x}_i \mid \mathbf{x}_{i-1})$ 在多步中注入 Gaussian 噪声，逐步腐蚀数据。数据最终演化为各向同性 Gaussian 分布，实际上变成纯噪声。这意味着编码器是固定的、不学的。

- **反向去噪过程（可学习解码器）**：这里由一个神经网络学习通过参数化分布 $p_\phi(\mathbf{x}_{i-1} \mid \mathbf{x}_i)$ 逆转噪声腐蚀。从纯噪声开始，该过程迭代去噪以生成逼真样本。关键在于，每一步单独的去噪任务都比 VAE 常做的 “从零生成完整样本” 更可控。

通过固定编码器、把学习集中在渐进生成轨迹上，DDPM 取得了显著的稳定性与表达能力。

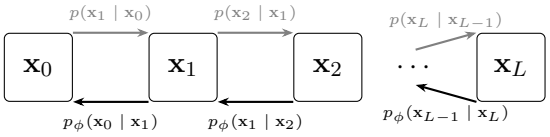
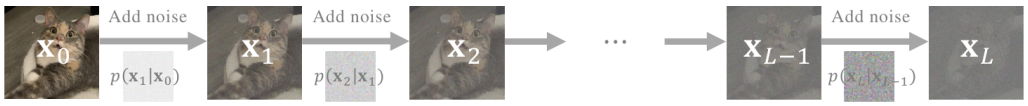


图 2.7: DDPM 示意图。它由一个固定前向过程（灰色，逐步向数据加入 Gaussian 噪声）与一个学到的反向过程（逐步去噪以生成新样本）构成。

本小节聚焦于 DDPM，更广泛的讨论推迟到 §4.1，那里我们给出更一般、更灵活的框架。

2.2.1 前向过程（固定编码器）

在 DDPM 中，前向过程是一个固定、不可训练的操作，充当编码器。它通过在多步中加噪逐步腐蚀原始数据，最终把它变换为一个简单的先验分布 $p_{\text{prior}} := \mathcal{N}(\mathbf{0}, \mathbf{I})$。这一变换即图 2.7 中的前向链，或图 2.8 中的示意。



igure 2.4: Illustration of the DDPM forward process, wherein Gaussian noise is incrementally dded to corrupt a data sample into pure noise.

图 2.8: DDPM 前向过程示意图：逐步加入 Gaussian 噪声，把数据样本腐蚀为纯噪声。

我们把这一步步腐蚀形式化如下。

固定 Gaussian 转移. 前向过程中每一步都由一个固定 Gaussian 转移核支配[3]：

$$p(\mathbf{x}_i \mid \mathbf{x}_{i-1}) := \mathcal{N}\big(\mathbf{x}_i; \sqrt{1-\beta_i^2}\,\mathbf{x}_{i-1}, \beta_i^2 \mathbf{I}\big).$$

[3]这一形式虽看似不同，在数学上与原始 DDPM 转移核等价。

过程从 $\mathbf{x}_0$ 开始，$\mathbf{x}_0$ 表示从真实数据分布 p_{data} 抽取的样本。序列 $\{\beta_i\}_{i=1}^L$ 表示预先给定、单调递增的噪声调度，每个 $\beta_i \in (0,1)$ 控制第 i 步注入 Gaussian 噪声的方差。为方便，定义 $\alpha_i := \sqrt{1-\beta_i^2}$。这一定义与如下直观迭代更新精确等价：

$$\mathbf{x}_i = \alpha_i \mathbf{x}_{i-1} + \beta_i \boldsymbol{\epsilon}_i, \qquad \boldsymbol{\epsilon}_i \sim \mathcal{N}(\mathbf{0}, \mathbf{I}) \text{ 独立同分布.}$$

即在每一步 i，我们用 α_i 缩放前一状态 $\mathbf{x}_{i-1}$，再加入由 β_i 缩放的受控 Gaussian 噪声。

扰动核与先验分布. 递归应用转移核，可得在给定原始数据 $\mathbf{x}_0$ 时第 i 步含噪样本分布的闭式：

$$p_i(\mathbf{x}_i \mid \mathbf{x}_0) = \mathcal{N}\big(\mathbf{x}_i; \bar{\alpha}_i \mathbf{x}_0, (1-\bar{\alpha}_i^2)\mathbf{I}\big),$$

其中

$$\bar{\alpha}_i := \prod_{k=1}^{i} \sqrt{1-\beta_k^2} = \prod_{k=1}^{i} \alpha_k.$$

这意味着我们可以直接由 $\mathbf{x}_0$ 采样 $\mathbf{x}_i$[4]：

$$\mathbf{x}_i = \bar{\alpha}_i \mathbf{x}_0 + \sqrt{1-\bar{\alpha}_i^2}\,\boldsymbol{\epsilon}, \qquad \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}). \tag{2.2.2.8}$$

设噪声调度 $\{\beta_i\}_{i=1}^L$ 为递增序列，则前向过程的边缘分布收敛：

$$p_L(\mathbf{x}_L \mid \mathbf{x}_0) \longrightarrow \mathcal{N}(\mathbf{0}, \mathbf{I}) \quad \text{当} L \to \infty,$$

这促使我们选取先验分布为 $p_{\text{prior}} := \mathcal{N}(\mathbf{0}, \mathbf{I})$，而无需依赖数据 $\mathbf{x}_0$。

2.2.2 反向去噪过程（可学习解码器）

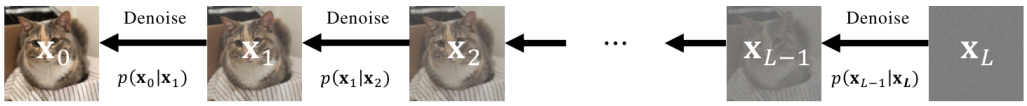
DDPM 的本质，在于逆转由前向扩散过程施加的受控腐蚀。从纯而无结构的噪声 $\mathbf{x}_L \sim p_{\text{prior}}$ 出发，目标是逐步对这种随机性去噪，直到一个连贯而有意义的数据样本出现。这一反向生成通过一条 Markov 链进行，如图 2.9 所示。

根本挑战，也是指引 DDPM 发展的中心问题，于是变为：

问题 2.2.1 (反向转移核是否可计算？)**：** 我们能否精确计算，或至少有效近似这些反向转移核 $p(\mathbf{x}_{i-1} \mid \mathbf{x}_i)$，尤其是在考虑 $\mathbf{x}_i \sim p_i(\mathbf{x}_i)$ 的复杂分布时？

我们不立即像原始 DDPM 论文那样进入 ELBO 那套数学上复杂的推导（详细讨论见 §2.2.5），而是从更直观的视角逼近训练目标：利用条件概率获得一个可处理的形式。

[4]对固定指标 t，我们在本处及后续常使用 Gaussian 扰动形式 $p_t(\mathbf{x}_t \mid \mathbf{x}_0) = \mathcal{N}\big(\mathbf{x}_t; \alpha_t \mathbf{x}_0, \sigma_t^2 \mathbf{I}\big)$，并等价地写成分布意义下的等式 $\mathbf{x}_t \overset{d}{=} \alpha_t \mathbf{x}_0 + \sigma_t \boldsymbol{\epsilon}$，即 $\text{Law}(\mathbf{x}_t) = \text{Law}(\alpha_t \mathbf{x}_0 + \sigma_t \boldsymbol{\epsilon})$，其中 $\mathbf{x}_0 \sim p_{\text{data}}$，$\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 与 $\mathbf{x}_0$ 独立，α_t, σ_t 为确定性标量。记号 "$\overset{d}{=}$" 表示两随机变量有相同概率密度（即律），因而对任意检验函数 ϕ 有相同期望：$\mathbb{E}[\phi(\mathbf{x}_t)] = \mathbb{E}[\phi(\alpha_t \mathbf{x}_0 + \sigma_t \boldsymbol{\epsilon})]$。为简洁起见，我们写作 $\mathbf{x}_t = \alpha_t \mathbf{x}_0 + \sigma_t \boldsymbol{\epsilon}$，按上下文理解为分布等式或样本实现；这一记法将贯穿全书。



igure 2.5: Illustration of DDPM reverse (denoising) process. Starting from noise $\mathbf{x}_L \sim p_{\text{prior}}$, he model sequentially samples $\mathbf{x}_{i-1} \sim p(\mathbf{x}_{i-1}|\mathbf{x}_i)$ for $i = L, \dots, 1$ to obtain a newly generated lata $\mathbf{x}$. The oracle transition $p(\mathbf{x}_{i-1}|\mathbf{x}_i)$ is unknown; thus, we aim to approximate it.

图 2.9: DDPM 反向（去噪）过程示意图。从噪声 $\mathbf{x}_L \sim p_{\text{prior}}$ 出发，模型依次采样 $\mathbf{x}_{i-1} \sim p(\mathbf{x}_{i-1} \mid \mathbf{x}_i)$，$i = L, \dots, 1$，得到新生成的数据 $\mathbf{x}$。oracle 转移 $p(\mathbf{x}_{i-1} \mid \mathbf{x}_i)$ 未知，我们的目标是近似它。

概述：建模与训练目标. 为使生成过程可行，我们的目标是近似未知的真实反向转移核 $p(\mathbf{x}_{i-1} \mid \mathbf{x}_i)$。做法是引入一个可学习的参数化模型 $p_\phi(\mathbf{x}_{i-1} \mid \mathbf{x}_i)$，训练它最小化期望 KL 散度：

$$\mathbb{E}_{p_i(\mathbf{x}_i)}\big[\mathcal{D}_{\text{KL}}\big(p(\mathbf{x}_{i-1} \mid \mathbf{x}_i) \| p_\phi(\mathbf{x}_{i-1} \mid \mathbf{x}_i)\big)\big]. \tag{2.2.2.9}$$

然而直接计算目标分布 $p(\mathbf{x}_{i-1} \mid \mathbf{x}_i)$ 颇具挑战。由 Bayes 定理，我们需要计算

$$p(\mathbf{x}_{i-1} \mid \mathbf{x}_i) = p(\mathbf{x}_i \mid \mathbf{x}_{i-1}) \frac{p_{i-1}(\mathbf{x}_{i-1})}{p_i(\mathbf{x}_i)} \underbrace{\qquad}_{\text{不可处理}}.$$

边缘 $p_i(\mathbf{x}_i)$ 与 $p_{i-1}(\mathbf{x}_{i-1})$ 是对未知数据分布 p_{data} 的期望：

$$p_i(\mathbf{x}_i) = \int p_i(\mathbf{x}_i \mid \mathbf{x}_0)\, p_{\text{data}}(\mathbf{x}_0)\, d\mathbf{x}_0,$$

$p_{i-1}(\mathbf{x}_{i-1})$ 类似。由于 p_{data} 未知，这些积分没有闭式求值；至多只能从样本近似，因此在实践中拿不到精确密度。

用条件化克服不可处理性. DDPM 的一个核心洞见解决了这一不可处理性：我们把反向转移条件在干净数据样本 $\mathbf{x}$ 上。这一微妙而有力的一步把不可处理的核变为数学上可处理的：

$$p(\mathbf{x}_{i-1} \mid \mathbf{x}_i, \mathbf{x}) = \frac{p(\mathbf{x}_i \mid \mathbf{x}_{i-1})\, p(\mathbf{x}_{i-1} \mid \mathbf{x})}{p(\mathbf{x}_i \mid \mathbf{x})}.$$

这种可处理性来自前向过程的两条关键性质：其 Markov 性，即 $p(\mathbf{x}_i \mid \mathbf{x}_{i-1}, \mathbf{x}) = p(\mathbf{x}_i \mid \mathbf{x}_{i-1})$；以及所有涉及分布的 Gaussian 性。因此 $p(\mathbf{x}_{i-1} \mid \mathbf{x}_i, \mathbf{x})$ 本身是 Gaussian，并有闭式（见式 (2.2.2.13)）。关键在于，这一优雅的条件化策略使我们能推出一个可处理目标，它与式 (2.2.2.9) 中看似不可处理的边缘 KL 在功能上等价。

定理 2.2.1 (边缘 KL 与条件 KL 最小化的等价性)**：** 下列等式成立：

$$\mathbb{E}_{p_i(\mathbf{x}_i)}\big[\mathcal{D}_{\text{KL}}\big(p(\mathbf{x}_{i-1} \mid \mathbf{x}_i) \| p_\phi(\mathbf{x}_{i-1} \mid \mathbf{x}_i)\big)\big] = \mathbb{E}_{p_{\text{data}}(\mathbf{x})}\mathbb{E}_{p(\mathbf{x}_i|\mathbf{x})}\big[\mathcal{D}_{\text{KL}}\big(p(\mathbf{x}_{i-1} \mid \mathbf{x}_i, \mathbf{x}) \| p_\phi(\mathbf{x}_{i-1} \mid \mathbf{x}_i)\big)\big] + C, \tag{2.2.2.10}$$

其中 C 是与 ϕ 无关的常数。此外，式 (2.2.2.10) 的最小化者满足

$$p^*(\mathbf{x}_{i-1} \mid \mathbf{x}_i) = \mathbb{E}_{p(\mathbf{x}|\mathbf{x}_i)}\big[p(\mathbf{x}_{i-1} \mid \mathbf{x}_i, \mathbf{x})\big] = p(\mathbf{x}_{i-1} \mid \mathbf{x}_i), \qquad \mathbf{x}_i \sim p_i.$$

证明： 证明通过展开 KL 散度的定义、应用概率链式法则，并利用对数恒等式将其分解为“期望条件 KL”与“边缘 KL”之和。完整推导见附录 D.1.1。 □

这种替代视角——通过条件化获得可处理目标——构成了 DDPM 的基础，并揭示了它与其他有影响力的扩散模型之间深刻的共性，这一点将在第 3 章与第 5 章中进一步探讨。它揭示了一种强大等价性：最小化边缘分布间的 KL 散度，在数学上与最小化特定条件分布间的 KL 散度完全相同。后一形式极为有用，因为关键条件分布 $p(\mathbf{x}_{i-1} \mid \mathbf{x}_i, \mathbf{x})$ 有方便的闭式：

引理 2.2.1 (反向条件转移核)**：** $p(\mathbf{x}_{i-1} \mid \mathbf{x}_i, \mathbf{x})$ 是 Gaussian，有闭式

$$p(\mathbf{x}_{i-1} \mid \mathbf{x}_i, \mathbf{x}) = \mathcal{N}\big(\mathbf{x}_{i-1}; \boldsymbol{\mu}(\mathbf{x}_i, \mathbf{x}, i), \sigma^2(i)\mathbf{I}\big), \tag{2.2.2.11}$$

其中

$$\boldsymbol{\mu}(\mathbf{x}_i, \mathbf{x}, i) := \frac{\bar{\alpha}_{i-1}\beta_i^2}{1-\bar{\alpha}_i^2}\,\mathbf{x} + \frac{(1-\bar{\alpha}_{i-1}^2)\alpha_i}{1-\bar{\alpha}_i^2}\,\mathbf{x}_i, \tag{2.2.2.12}$$

$$\sigma^2(i) := \frac{1-\bar{\alpha}_{i-1}^2}{1-\bar{\alpha}_i^2}\,\beta_i^2. \tag{2.2.2.13}$$

稍后在引理 4.4.2 中，我们会给出一个更一般的公式，它超越式 (2.2.2.8) 所述 DDPM 加噪过程。

2.2.3 反向转移核 $p_\phi(\mathbf{x}_{i-1} \mid \mathbf{x}_i)$ 的建模

利用定理 2.2.1 中的梯度级等价性，以及引理 2.2.1 中反向条件 $p(\mathbf{x}_{i-1} \mid \mathbf{x}_i, \mathbf{x})$ 的 Gaussian 形式，DDPM 假设每个反向转移 $p_\phi(\mathbf{x}_{i-1} \mid \mathbf{x}_i)$ 都是 Gaussian，参数化为

$$p_\phi(\mathbf{x}_{i-1} \mid \mathbf{x}_i) := \mathcal{N}\big(\mathbf{x}_{i-1}; \boldsymbol{\mu}_\phi(\mathbf{x}_i, i), \sigma^2(i)\mathbf{I}\big), \tag{2.2.2.14}$$

其中 $\boldsymbol{\mu}_\phi(\cdot, i) : \mathbb{R}^D \to \mathbb{R}^D$ 是可学习的均值函数，$\sigma^2(i) > 0$ 按式 (2.2.2.13) 固定。

我们把在所有时间步 i 上平均、并条件于数据 $\mathbf{x}_0 \sim p_{\text{data}}$ 的 KL 散度记作：

$$L_{\text{diffusion}}(\mathbf{x}_0; \phi) := \sum_{i=1}^{L} \mathbb{E}_{p(\mathbf{x}_i|\mathbf{x}_0)}\big[\mathcal{D}_{\text{KL}}\big(p(\mathbf{x}_{i-1} \mid \mathbf{x}_i, \mathbf{x}_0) \| p_\phi(\mathbf{x}_{i-1} \mid \mathbf{x}_i)\big)\big]. \tag{2.2.2.15}$$

由于两分布均为 Gaussian，且参数化如式 (2.2.2.14)，目标有闭式并可简化为

$$L_{\text{diffusion}}(\mathbf{x}_0; \phi) = \sum_{i=1}^{L} \frac{1}{2\sigma^2(i)} \big\|\boldsymbol{\mu}_\phi(\mathbf{x}_i, i) - \boldsymbol{\mu}(\mathbf{x}_i, \mathbf{x}_0, i)\big\|_2^2 + C, \tag{2.2.2.16}$$

其中 C 是与 ϕ 无关的常数。在数据分布上平均并略去不影响优化的常数 C，得到最终 DDPM 训练目标

$$L_{\text{DDPM}}(\phi) := \sum_{i=1}^{L} \frac{1}{2\sigma^2(i)} \mathbb{E}_{\mathbf{x}_0}\mathbb{E}_{p(\mathbf{x}_i|\mathbf{x}_0)}\big[\|\boldsymbol{\mu}_\phi(\mathbf{x}_i, i) - \boldsymbol{\mu}(\mathbf{x}_i, \mathbf{x}_0, i)\|_2^2\big], \tag{2.2.2.17}$$

其中 $\mathbf{x}_0 \sim p_{\text{data}}$。

2.2.4 预测与损失的实用选择

ϵ-预测. 在典型 DDPM 实现中，训练并不直接使用基于式 (2.2.2.17) 中均值预测参数化的原始损失，而是采用一种等价的重参数化，称为 ϵ-预测（噪声预测）形式。

回顾 DDPM 前向过程中，噪声级 i 处的含噪样本 $\mathbf{x}_i \sim p(\mathbf{x}_i \mid \mathbf{x})$ 由

$$\mathbf{x}_i = \bar{\alpha}_i \mathbf{x}_0 + \sqrt{1-\bar{\alpha}_i^2}\,\boldsymbol{\epsilon}, \qquad \mathbf{x}_0 \sim p_{\text{data}}, \quad \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}) \tag{2.2.2.18}$$

生成。利用这一表达式，式 (2.2.2.13) 中的反向均值 $\boldsymbol{\mu}(\mathbf{x}_i, \mathbf{x}_0, i)$ 可重写为

$$\boldsymbol{\mu}(\mathbf{x}_i, \mathbf{x}_0, i) = \frac{1}{\alpha_i}\left(\mathbf{x}_i - \frac{1-\alpha_i^2}{\sqrt{1-\bar{\alpha}_i^2}}\,\boldsymbol{\epsilon}\right).$$

这启发我们用一个直接预测噪声的神经网络 $\boldsymbol{\epsilon}_\phi(\mathbf{x}_i, i)$ 来参数化模型均值 $\boldsymbol{\mu}_\phi$：

$$\boldsymbol{\mu}_\phi(\mathbf{x}_i, i) = \frac{1}{\alpha_i}\left(\mathbf{x}_i - \underbrace{\frac{1-\alpha_i^2}{\sqrt{1-\bar{\alpha}_i^2}}\,\boldsymbol{\epsilon}_\phi(\mathbf{x}_i, i)}_{\epsilon\text{-预测}}\right).$$

代入原始损失后，得到预测噪声与真实噪声之间的平方 ℓ_2 误差：

$$\|\boldsymbol{\mu}_\phi(\mathbf{x}_i, i) - \boldsymbol{\mu}(\mathbf{x}_i, \mathbf{x}_0, i)\|_2^2 \propto \|\boldsymbol{\epsilon}_\phi(\mathbf{x}_i, i) - \boldsymbol{\epsilon}\|_2^2,$$

相差一个依赖于 i 的权重因子。直观上，模型扮演 “噪声侦探” 的角色，估计前向过程在每一步加入的随机噪声。从腐蚀样本中减去这一估计，使其更接近干净原始样本；逐步重复即从纯噪声重建数据。

ϵ-预测下的简化损失. 在实践中，这一表达式进一步简化为略去权重项，得到广泛使用的 DDPM 训练损失：

$$L_{\text{simple}}(\phi) := \mathbb{E}_i \mathbb{E}_{\mathbf{x}\sim p_{\text{data}}(\mathbf{x})} \mathbb{E}_{\boldsymbol{\epsilon}\sim\mathcal{N}(\mathbf{0},\mathbf{I})}\left[\|\boldsymbol{\epsilon}_\phi(\mathbf{x}_i, i) - \boldsymbol{\epsilon}\|_2^2\right], \tag{2.2.2.19}$$

其中 $\mathbf{x}_i = \bar{\alpha}_i \mathbf{x}_0 + \sqrt{1-\bar{\alpha}_i^2}\,\boldsymbol{\epsilon}$，$\mathbf{x}_0 \sim p_{\text{data}}$。由于目标噪声在每个时间步 t 上都是单位方差，式 (2.2.2.19) 中的 ℓ_2 损失在所有 t 上保持一致尺度，避免了目标消失或爆炸，也无需显式的损失加权。

重要的是，L_{DDPM} 与 L_{simple} 共享同一最优解 $\boldsymbol{\epsilon}^*$，这是因为式 (2.2.2.19) 本质上退化为最小二乘问题（命题 4.2.1 或命题 6.3.1 中类似）：

$$\boldsymbol{\epsilon}^*(\mathbf{x}_i, i) = \mathbb{E}[\boldsymbol{\epsilon} \mid \mathbf{x}_i], \qquad \mathbf{x}_i \sim p_i.$$

直观上，ϵ-预测网络 $\boldsymbol{\epsilon}_\phi(\mathbf{x}_i, i)$ 估计前向过程为产生 $\mathbf{x}_i$ 所加入的噪声。在最优处，这一估计与真实噪声的条件期望重合——即使 $\mathbf{x}_i$ 并不唯一决定原始干净样本。

另一种等价参数化：x-预测. 式 (2.2.2.13) 启发了另一种等价参数化，称为 $\mathbf{x}$-预测（干净预测）：训练一个神经网络 $\mathbf{x}_\phi(\mathbf{x}_i, i)$，在噪声级 i 处从给定含噪输入 $\mathbf{x}_i \sim p_i(\mathbf{x}_i)$ 预测一个干净（去噪）样本。把反向均值表达式中的真值干净样本 $\mathbf{x}$ 替换为 $\mathbf{x}_\phi(\mathbf{x}_i, i)$，得到如下模型：

$$\boldsymbol{\mu}_\phi(\mathbf{x}_i, i) = \frac{\bar{\alpha}_{i-1}\beta_i^2}{1-\bar{\alpha}_i^2}\,\mathbf{x}_\phi(\mathbf{x}_i, i) + \frac{(1-\bar{\alpha}_{i-1}^2)\alpha_i}{1-\bar{\alpha}_i^2}\,\mathbf{x}_i.$$

与 ϵ-预测类似，训练目标可写为

$$\|\boldsymbol{\mu}_\phi(\mathbf{x}_i, i) - \boldsymbol{\mu}(\mathbf{x}_i, \mathbf{x}_0, i)\|_2^2 \propto \|\mathbf{x}_\phi(\mathbf{x}_i, i) - \mathbf{x}_0\|_2^2, \qquad \mathbf{x}_0 \sim p_{\text{data}},$$

即模型被训练为从其含噪版本 $\mathbf{x}_i$ 预测原始数据样本 $\mathbf{x}$。这一等价性把式 (2.2.2.17) 中的均值匹配损失退化为

$$\mathbb{E}_i \mathbb{E}_{\mathbf{x}_0 \sim p_{\text{data}}} \mathbb{E}_{\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})} \left[\omega_i \, \|\mathbf{x}_\phi(\mathbf{x}_i, i) - \mathbf{x}_0\|_2^2 \right],$$

其中 ω_i 为某权重函数。由于这是最小二乘问题，最优解为（命题 4.2.1 或命题 6.3.1）

$$\mathbf{x}^*(\mathbf{x}_i, i) = \mathbb{E}[\mathbf{x}_0 \mid \mathbf{x}_i], \qquad \mathbf{x}_i \sim p_i, \tag{2.2.2.20}$$

即模型应预测在时间步 i 给定含噪观测 $\mathbf{x}_i$ 时期望的干净数据。

$\mathbf{x}$-预测与 ϵ-预测在数学上等价，并通过前向过程相联系：

$$\mathbf{x}_i = \bar{\alpha}_i \, \mathbf{x}_\phi(\mathbf{x}_i, i) + \sqrt{1-\bar{\alpha}_i^2}\, \boldsymbol{\epsilon}_\phi(\mathbf{x}_i, i). \tag{2.2.2.21}$$

也就是说，既可以预测干净样本 $\mathbf{x}_\phi(\mathbf{x}_i, i)$，也可以预测噪声 $\boldsymbol{\epsilon}_\phi(\mathbf{x}_i, i)$，使二者组合在前向加噪过程下重现 $\mathbf{x}_i$。

2.2.5 DDPM 的 ELBO

在反向转移如式 (2.2.2.14) 定义后，DDPM 中的联合生成分布定义为

$$p_\phi(\mathbf{x}_0, \mathbf{x}_{1:L}) := p_\phi(\mathbf{x}_0 \mid \mathbf{x}_1)\, p_\phi(\mathbf{x}_1 \mid \mathbf{x}_2) \cdots p_\phi(\mathbf{x}_{L-1} \mid \mathbf{x}_L)\, p_{\text{prior}}(\mathbf{x}_L),$$

数据的边缘生成模型为

$$p_\phi(\mathbf{x}_0) := \int p_\phi(\mathbf{x}_0, \mathbf{x}_{1:L})\, d\mathbf{x}_{1:L}.$$

事实上，式 (2.2.2.15) 所定义的 DDPM 训练可严格地建立在最大似然估计（式 (1.1.1.2)）之上。具体地，其目标构成一个 ELBO，类似 §2.1.3 中 VAE 与 HVAE 的情形，作为对数密度的下界：

定理 2.2.2 (DDPM 的 ELBO)**：**

$$-\log p_\phi(\mathbf{x}_0) \le -L_{\text{ELBO}}(\mathbf{x}_0; \phi) := L_{\text{prior}}(\mathbf{x}_0) + L_{\text{recon.}}(\mathbf{x}_0; \phi) + L_{\text{diffusion}}(\mathbf{x}_0; \phi) \tag{2.2.2.22}$$

各损失分量定义为：

$$
\begin{aligned}
L_{\text{prior}}(\mathbf{x}_0) &:= \mathcal{D}_{\text{KL}}\big(p(\mathbf{x}_L \mid \mathbf{x}_0) \| p_{\text{prior}}(\mathbf{x}_L)\big), \\
L_{\text{recon.}}(\mathbf{x}_0;\phi) &:= \mathbb{E}_{p(\mathbf{x}_1|\mathbf{x}_0)}\big[-\log p_\phi(\mathbf{x}_0 \mid \mathbf{x}_1)\big], \\
L_{\text{diffusion}}(\mathbf{x}_0;\phi) &= \sum_{i=1}^{L} \mathbb{E}_{p(\mathbf{x}_i|\mathbf{x}_0)}\big[\mathcal{D}_{\text{KL}}\big(p(\mathbf{x}_{i-1} \mid \mathbf{x}_i, \mathbf{x}_0) \| p_\phi(\mathbf{x}_{i-1} \mid \mathbf{x}_i)\big)\big].
\end{aligned}
$$

证明： 推导如 HVAE/VAE ELBO（式 (2.2.1.7)）那样应用 Jensen 不等式，并进一步化简。详细证明见附录 D.1.2。 □

ELBO L_{ELBO} 由三项构成：

- L_{prior} 可通过选择噪声调度 $\{\beta_i\}$ 使其 $p(\cdot \mid \mathbf{x}_0) \approx p_{\text{prior}}(\cdot)$，从而忽略不计；
- $L_{\text{recon.}}$ 可用 Monte Carlo 估计近似与优化；实用实现见（Ho 等, 2020；Kingma 等, 2021）；
- $L_{\text{diffusion}}$（对照式 (2.2.2.15)）在所有步 i 上把反向条件 $p_\phi(\mathbf{x}_{i-1} \mid \mathbf{x}_i)$ 匹配到 $p(\mathbf{x}_{i-1} \mid \mathbf{x}_i)$。

ELBO 目标 L_{ELBO} 也可以通过 “带隐变量 $\mathbf{z} = \mathbf{x}_{1:L}$ 的数据处理不等式” 视角解读，如式 (2.2.1.6) 所示：

$$
\mathcal{D}_{\text{KL}}\big(p_{\text{data}}(\mathbf{x}_0) \| p_\phi(\mathbf{x}_0)\big) \le \mathcal{D}_{\text{KL}}\big(p(\mathbf{x}_0, \mathbf{x}_{1:L}) \| p_\phi(\mathbf{x}_0, \mathbf{x}_{1:L})\big),
$$

其中 $p(\mathbf{x}_0, \mathbf{x}_{1:L}) := p_{\text{data}}(\mathbf{x}_0)\, p(\mathbf{x}_1 \mid \mathbf{x}_0)\, p(\mathbf{x}_2 \mid \mathbf{x}_1) \cdots p(\mathbf{x}_L \mid \mathbf{x}_{L-1})$ 表示沿前向过程的联合分布。

注 2.2.1 (扩散的变分视角契合 HVAE 模板)**：** “编码器” 是固定前向加噪链，隐变量 $\mathbf{x}_{1:T}$ 与数据同维。训练最大化同一 ELBO。没有学到的编码器，也没有逐层 KL 项；目标反而分解为从大噪声到小噪声（由粗到细）的、条件良好的去噪子问题，从而实现稳定优化与高样本质量，同时在时间/噪声上保持由粗到细的层次。 ◇

2.2.6 采样

训练好 ϵ-预测模型 $\boldsymbol{\epsilon}_{\phi^\times}(\mathbf{x}_i, i)$[5] 后，采样按图 2.9 顺序进行，使用参数化转移 $p_{\phi^\times}(\mathbf{x}_{i-1} \mid \mathbf{x}_i)$。

更具体地，从随机种子 $\mathbf{x}_L \sim p_{\text{prior}} = \mathcal{N}(\mathbf{0}, \mathbf{I})$ 开始，对 $i = L, L-1, \ldots, 1$ 递归地按如下更新规则从 $p_{\phi^\times}(\mathbf{x}_{i-1} \mid \mathbf{x}_i)$ 采样：

$$
\mathbf{x}_{i-1} \leftarrow \underbrace{\frac{1}{\alpha_i}\left(\mathbf{x}_i - \frac{1-\alpha_i^2}{\sqrt{1-\bar{\alpha}_i^2}}\,\boldsymbol{\epsilon}_{\phi^\times}(\mathbf{x}_i, i)\right)}_{\boldsymbol{\mu}_{\phi^\times}(\mathbf{x}_i, i)} + \sigma(i)\,\boldsymbol{\epsilon}_i, \qquad \boldsymbol{\epsilon}_i \sim \mathcal{N}(\mathbf{0}, \mathbf{I}). \tag{2.2.2.23}
$$

这一 “去噪” 过程持续进行，直到得到 $\mathbf{x}_0$ 作为最终干净生成样本。

[5]我们用符号 “×” 表示模型已经训练并被冻结。

DDPM 采样的另一种解读. 由式 (2.2.2.21)，对应于噪声估计 $\boldsymbol{\epsilon}_{\phi^\times}(\mathbf{x}_i, i)$ 的干净样本预测为

$$\mathbf{x}_{\phi^\times}(\mathbf{x}_i, i) = \frac{\mathbf{x}_i - \sqrt{1-\bar{\alpha}_i^2}\,\boldsymbol{\epsilon}_{\phi^\times}(\mathbf{x}_i, i)}{\bar{\alpha}_i}.$$

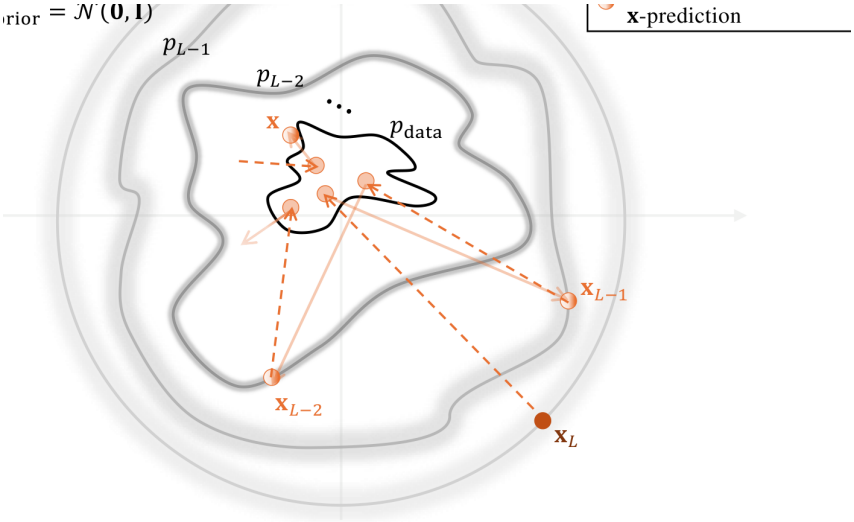
把它代入式 (2.2.2.23) 的 DDPM 采样规则，得到等价更新：

$$\mathbf{x}_{i-1} \leftarrow \big(\mathbf{x}_i \text{ 与干净预测}\mathbf{x}_{\phi^\times} \text{ 的插值}\big) + \sigma(i)\boldsymbol{\epsilon}_i,$$

即每一步都以预测干净样本为中心，并加入由 $\sigma(i)$ 缩放的 Gaussian 噪声。

这表明 DDPM 采样可视为一个迭代去噪过程，在两步之间交替：

1. 从当前含噪输入 $\mathbf{x}_i$ 估计干净数据 $\mathbf{x}_{\phi^\times}(\mathbf{x}_i, i)$；
2. 用这一干净估计按更新规则采样一个噪声更小的隐变量 $\mathbf{x}_{i-1}$。



ure 2.6: Illustration of DDPM sampling with clean prediction: estimate $\mathbf{x}_{\phi^\times}(\mathbf{x}_i, i)$ fi then update to $\mathbf{x}_{i-1}$.

图 2.10: 带干净预测的 DDPM 采样示意图：从 $\mathbf{x}_i$ 估计 $\mathbf{x}_{\phi^\times}(\mathbf{x}_i, i)$，再更新到 $\mathbf{x}_{i-1}$。

然而，即使 $\mathbf{x}_{\phi^\times}$ 被训练为最优去噪器（即条件期望最小化者，见式 (2.2.2.20)），它也只能预测给定 $\mathbf{x}_i$ 时干净样本的平均。这一局限导致模糊预测，尤其在高噪声级：从严重腐蚀的输入中恢复细节结构变得困难。

从这一视角看，扩散采样通常从高噪声走向低噪声，渐进精化对干净信号的估计。早期步骤设定全局结构，后期步骤加入细细节；随着噪声被去除，样本变得更逼真。

DDPM 采样速度慢. DDPM（即扩散模型）采样本质上很慢[6]，这源于其反向过程的序列性，并受以下因素制约：

[6]DDPM 通常需要 1,000 步去噪。

定理 2.2.1 表明，表达型 $p_\phi(\mathbf{x}_{i-1} \mid \mathbf{x}_i)$ 理论上可以匹配真实反向分布 $p(\mathbf{x}_{i-1} \mid \mathbf{x}_i)$。然而在实践中，$p_\phi(\mathbf{x}_{i-1} \mid \mathbf{x}_i)$ 通常建模为 Gaussian 以近似 $p(\mathbf{x}_{i-1} \mid \mathbf{x}_i)$，限制了其表达能力。

对小的前向噪声尺度 β_i，真实反向分布近似 Gaussian，可精确近似。反之，大 β_i 诱导多峰或强非 Gaussian 性，单一 Gaussian 无法捕捉。为保持精度，DDPM 采用许多小 β_i 步，形成序列链，每一步都依赖前一步并需要一次神经网络评估 $\boldsymbol{\epsilon}_{\phi^\times}(\mathbf{x}_i, i)$。这导致 $O(L)$ 次序列前向，无法并行化，从而拖慢生成。

在第 4 章中，我们将展示对这一固有采样瓶颈的一种更有原理可循的解读——把它视为微分方程问题，这促使我们采用连续时间数值策略来加速生成。

2.3 小结

本章我们透过变分透镜追溯了扩散模型的起源。我们从变分自编码器（VAE）出发：这是一个基础生成模型，通过证据下界（ELBO）在数据与结构化隐空间之间学习概率映射。我们看到层次化 VAE（HVAE）如何通过堆叠隐层扩展这一思想，引入了 “渐进、由粗到细生成” 这一强有力的概念。然而这些模型在训练稳定性与样本质量上仍面临挑战。

随后我们把去噪扩散概率模型（DDPM）刻画为这一变分框架内的关键演化。通过把编码器固定为渐进加噪过程、只学习反向去噪步骤，DDPM 巧妙地绕开了 HVAE 的训练不稳定。关键在于，我们证明 DDPM 也是通过最大化对数似然的变分界来训练的，其训练目标分解为一系列简单去噪任务。这种可处理性由一种强大的条件化策略实现：把不可处理的边缘目标转化为可处理的条件目标，这是扩散模型中反复出现的主题。

尽管这一变分框架为 DDPM 提供了完整而强大的基础，它并非理解它们的唯一方式。另一种同样基础的视角来自基于能量建模的原理。在下一章中，我们将探索这种基于分数的视角：

1. 我们将把焦点从学习去噪转移概率 $p_\phi(\mathbf{x}_{i-1} \mid \mathbf{x}_i)$，转向直接学习数据对数密度的梯度，即分数函数；

2. 我们将看到，这种起源于 EBM 的方法如何导出噪声条件分数网络（NCSN），并揭示 DDPM 中学到的噪声预测（ϵ-预测）与分数函数本身之间深刻的数学等价性。

这一替代视角不仅提供新洞见，也将成为后续发展的、统一的连续时间扩散模型框架的另一块基石。

Chapter 3

基于分数的视角：从 EBM 到 NCSN

在前几章中，我们追溯了扩散模型的变分起源，并展示了它们如何在 VAE 的框架中自然出现。现在我们转向第二个同等基础的视角：基于能量的模型（Energy-Based Model, EBM）（Ackley 等, 1985；LeCun 等, 2006）。EBM 用一个能量曲面来表示分布：数据处能量低，其余位置能量高。采样通常依赖 Langevin 动力学（Langevin dynamics），它沿着该能量曲面的梯度方向把样本推向高密度区域。这个梯度场被称为 分数（score），它指向概率更高的方向.

核心观察是：只要知道分数就足以进行生成——它把样本推向高概率区域，而无需计算不可处理的归一化常数。基于分数的扩散模型（score-based diffusion model）正是建立在这一思想之上：它不只考虑干净数据分布，而是考虑一列被 Gaussian 噪声扰动过的分布，这些分布的分数更容易逼近。学习这些分数便得到一族向量场，引导带噪样本一步一步去噪回到数据，从而把生成转化为渐进式去噪.

3.1 基于能量的模型

对于已经熟悉 EBM 的读者，本节既是简明回顾，也是通往扩散的基于分数视角的桥梁.

3.1.1 用能量函数建模概率分布

设 $\mathbf{x} \in \mathbb{R}^D$ 表示一个数据点。EBM 通过一个由 ϕ 参数化的能量函数 $E_\phi(\mathbf{x})$ 定义概率密度，它给更可能的构型赋予更低的能量。所得分布为

$$p_\phi(\mathbf{x}) := \frac{\exp(-E_\phi(\mathbf{x}))}{Z_\phi}, \qquad Z_\phi := \int_{\mathbb{R}^D} \exp(-E_\phi(\mathbf{x}))\,\mathrm{d}\mathbf{x}, \tag{3.3.1.24}$$

其中 Z_ϕ 称为 配分函数（partition function），用于保证归一化：

$$\int_{\mathbb{R}^D} p_\phi(\mathbf{x})\,\mathrm{d}\mathbf{x} = 1. \tag{3.3.1.25}$$

在这一视角下，能量更低的点对应更高的概率，就像小球滚入山谷。配分函数 Z_ϕ 保证所有概率之和为 1，因此只有能量的相对值才有意义：例如，给所有能量加上同一个常数，分子分母同乘一个因子，分布不变.

此外，由于 Z_ϕ 强制概率之和为 1，数学上必然有：在某一区域内降低其能量，会增大该区域的概率，同时其补集的概率相应减小. 因此 EBM 服从严格的全局权衡：把

$$\int_{\mathbb{R}^D} p_\phi(\mathbf{x})\,\mathrm{d}\mathbf{x} = 1.$$

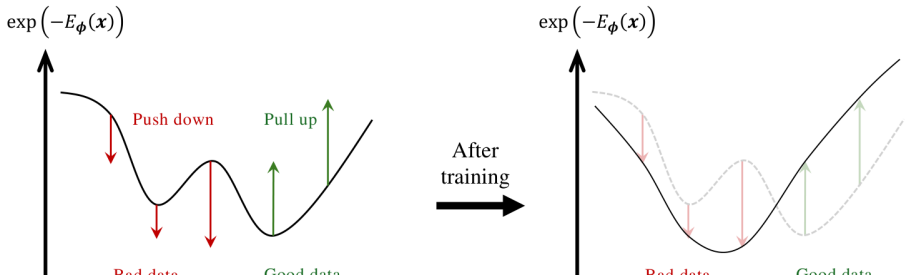


图 3.11: EBM 训练示意。模型在 “坏” 数据点处降低密度（抬高能量，红色箭头），在 “好” 数据点处抬高密度（降低能量，绿色箭头）.

一个山谷挖得更深，必然使其他山谷变浅，概率质量在整个空间上重新分配，而非独立地赋给每个区域.

EBM 中最大似然训练的困难. 原则上，EBM 可以通过最大似然训练，它自然地在拟合数据与全局正则化之间取得平衡（见式 (3.3.1.26)）：

$$\begin{aligned}\mathcal{L}_{\mathrm{MLE}}(\phi) &= \mathbb{E}_{p_{\mathrm{data}}(\mathbf{x})}\left[\log \frac{\exp(-E_\phi(\mathbf{x}))}{Z_\phi}\right] \\ &= \underbrace{-\mathbb{E}_{p_{\mathrm{data}}}[E_\phi(\mathbf{x})]}_{\text{降低数据能量}} \underbrace{-\log \int \exp(-E_\phi(\mathbf{x}))\,\mathrm{d}\mathbf{x}}_{\text{全局正则化}},\end{aligned} \tag{3.3.1.26}$$

其中 $Z_\phi = \int \exp(-E_\phi(\mathbf{x}))\,\mathrm{d}\mathbf{x}$。第一项降低真实数据的能量，第二项通过配分函数强制归一化.

然而在高维情形下，计算 $\log Z_\phi$ 及其梯度是不可处理的，因为它需要在模型分布下取期望。这促使人们寻找替代目标：要么近似这一项，例如 对比散度（contrastive divergence）（Hinton, 2002）；要么完全绕开它，即 分数匹配（score matching）.

下文结构如下：在第 3.1.2 节引入分数函数的概念；在第 3.1.3 节给出绕开配分函数的可处理训练目标——分数匹配；在第 3.1.4 节讨论如何用分数函数配合 Langevin 动力学进行实用采样.

3.1.2 动机：什么是分数？

对于 $\mathbb{R}^D$ 上的密度 $p(\mathbf{x})$，分数函数（score function）即对数密度的梯度：

$$\mathbf{s}(\mathbf{x}) := \nabla_{\mathbf{x}} \log p(\mathbf{x}), \qquad \mathbf{s} : \mathbb{R}^D \to \mathbb{R}^D. \tag{3.3.1.27}$$

直观上，分数构成一个向量场，指向概率更高的区域，从而给出数据最可能出现位置的局部指引（见图 3.12）.

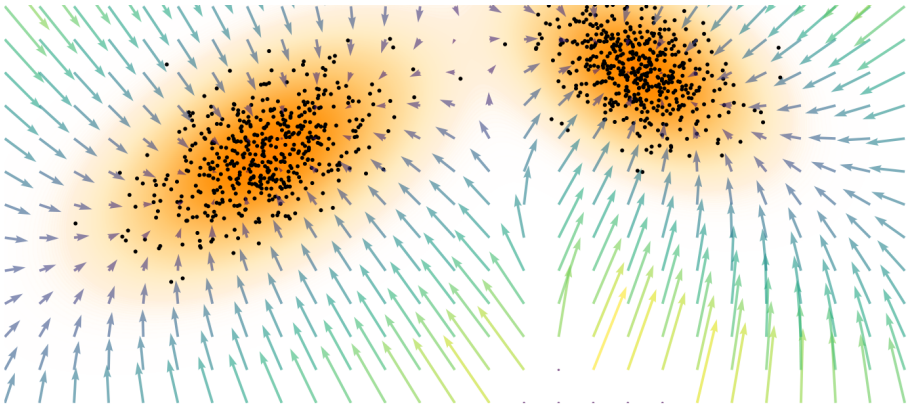


Figure 3.2: Illustration of score vector fields. Score vector fields $\nabla_{\mathbf{x}} \log p(\mathbf{x})$ indicate directions of increasing density.

Why Model Scores Instead of Densities? Modeling the score offers both theoretical and practical benefits:

图 3.12: 分数向量场示意。分数向量场 $\nabla_{\mathbf{x}} \log p(\mathbf{x})$ 指示密度增大的方向.

为什么建模分数而不是密度？ 建模分数在理论与实践上都有优势：

1. **摆脱归一化常数**。许多分布只由一个未归一化的密度 $\tilde{p}(\mathbf{x})$ 定义，例如 EBM 中的 $\exp(-E_\phi(\mathbf{x}))$：

$$p(\mathbf{x}) = \frac{\tilde{p}(\mathbf{x})}{Z}, \qquad Z = \int \tilde{p}(\mathbf{x})\, \mathrm{d}\mathbf{x}. \tag{3.3.1.28}$$

   虽然计算 Z 不可处理，但分数只依赖于 $\tilde{p}$：

$$\nabla_{\mathbf{x}} \log p(\mathbf{x}) = \nabla_{\mathbf{x}} \log \tilde{p}(\mathbf{x}) - \underbrace{\nabla_{\mathbf{x}} \log Z}_{=0} = \nabla_{\mathbf{x}} \log \tilde{p}(\mathbf{x}), \tag{3.3.1.29}$$

   因为 Z 关于 $\mathbf{x}$ 是常数。这就完全绕开了配分函数.

2. **完全的表示能力**。分数函数完全刻画了底层分布。由于它是对数密度的梯度，密度（差一个常数）可以通过路径积分恢复：

$$\log p(\mathbf{x}) = \log p(\mathbf{x}_0) + \int_0^1 \mathbf{s}(\mathbf{x}_0 + t(\mathbf{x} - \mathbf{x}_0))^\top (\mathbf{x} - \mathbf{x}_0)\, \mathrm{d}t, \tag{3.3.1.30}$$

   其中 $\mathbf{x}_0$ 是参考点，$\log p(\mathbf{x}_0)$ 由归一化固定。因此，建模分数与建模 $p(\mathbf{x})$ 具有相同的表达能力，但通常对生成建模更易处理.

3.1.3 通过分数匹配训练 EBM

在 EBM 中，密度定义为 $p_\phi(\mathbf{x}) = \frac{\exp(-E_\phi(\mathbf{x}))}{Z_\phi}$。最大似然训练需要计算 Z_ϕ，一般不可处理。关键观察是：模型分数 p_ϕ 简化为 $-\nabla_{\mathbf{x}} E_\phi(\mathbf{x})$，与 Z_ϕ 无关（见式 (3.3.1.29)）.

分数匹配（Hyvärinen–Dayan）（score matching）（Hyvärinen 与 Dayan, 2005）利用了分数只依赖能量函数这一事实。它不再拟合归一化概率，而是让模型分数与（未知的）数据分数对齐：

$$\mathcal{L}_{\mathrm{SM}}(\phi) = \tfrac{1}{2}\mathbb{E}_{p_{\mathrm{data}}(\mathbf{x})}\left\|\nabla_{\mathbf{x}} \log p_\phi(\mathbf{x}) - \nabla_{\mathbf{x}} \log p_{\mathrm{data}}(\mathbf{x})\right\|_2^2. \tag{3.3.1.31}$$

虽然数据分数无法直接获得，但通过分部积分可得到一个只涉及能量及其导数的等价表达式（详见命题 3.2.1）：

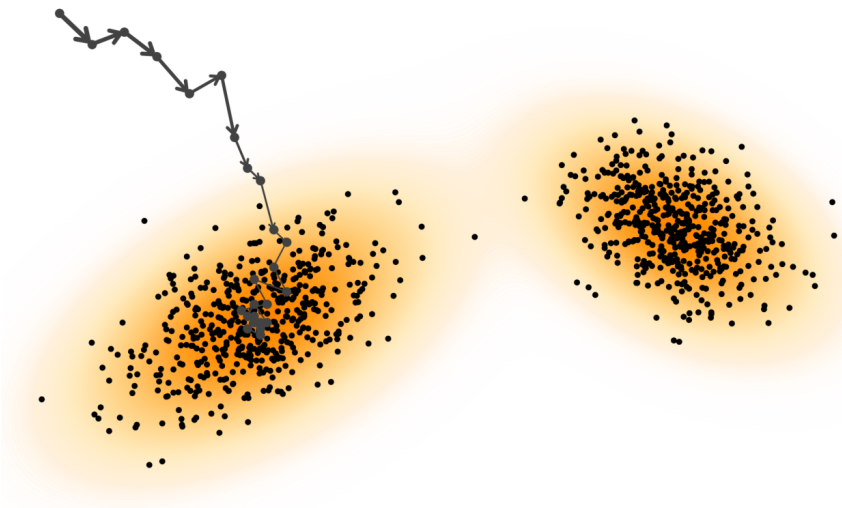
$$\mathcal{L}_{\mathrm{SM}}(\phi) = \mathbb{E}_{p_{\mathrm{data}}(\mathbf{x})}\left[\mathrm{Tr}\left(\nabla_{\mathbf{x}}^2 E_\phi(\mathbf{x})\right) + \tfrac{1}{2}\|\nabla_{\mathbf{x}} E_\phi(\mathbf{x})\|_2^2\right] + C, \tag{3.3.1.32}$$

其中 $\nabla_{\mathbf{x}}^2 E_\phi(\mathbf{x})$ 是 E_ϕ 的 Hessian，C 是与 ϕ 无关的常数.

这一公式很吸引人，因为它消除了配分函数，也避免了训练时从模型采样。它的主要缺点是需要二阶导数，在高维下计算代价过高。本章后面会再讨论解决这一局限的方法.

3.1.4 带分数函数的 Langevin 采样

由能量函数 $E_\phi(\mathbf{x})$ 定义的 EBM，可以用 Langevin 动力学采样。我们先给出离散时间 Langevin 更新，再取其连续时间极限作为随机微分方程（SDE），最后讨论 Langevin 动力学为何能高效探索复杂能量曲面.



ure 3.3: Illustration of Langevin sampling. Langevin sampling using the score function $\log p_\phi(\mathbf{x})$ to guide trajectories toward high-density regions via the update in Equa-

图 3.13: Langevin 采样示意。利用分数函数 $\nabla_{\mathbf{x}} \log p_\phi(\mathbf{x})$，按式 (3.3.1.35) 的更新（箭头所示）把轨迹推向高密度区域.

离散时间 Langevin 动力学. 离散时间 Langevin 更新为

$$\mathbf{x}_{n+1} = \mathbf{x}_n - \eta\, \nabla_{\mathbf{x}} E_\phi(\mathbf{x}_n) + \sqrt{2\eta}\, \boldsymbol{\epsilon}_n, \qquad n = 0, 1, 2, \ldots, \tag{3.3.1.33}$$

其中 $\mathbf{x}_0$ 由某个分布初始化（通常是 Gaussian），$\eta > 0$ 是步长，$\boldsymbol{\epsilon}_n \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 是 Gaussian 噪声。噪声通过加入随机性，使样本能够跳出局部极小.

由于分数函数可写为

$$\nabla_{\mathbf{x}} \log p_\phi(\mathbf{x}) = -\nabla_{\mathbf{x}} E_\phi(\mathbf{x}), \tag{3.3.1.34}$$

更新可等价写成

$$\mathbf{x}_{n+1} = \mathbf{x}_n + \eta \nabla_{\mathbf{x}} \log p_\phi(\mathbf{x}_n) + \sqrt{2\eta}\, \boldsymbol{\epsilon}_n, \tag{3.3.1.35}$$

其中分数函数把样本推向高密度区域。这一形式对扩散模型至关重要，后面会详细展开.

连续时间 Langevin 动力学. 当步长 $\eta \to 0$ 时，离散 Langevin 更新自然收敛到一个连续时间过程，即 Langevin 随机微分方程（Langevin SDE）：

$$\mathrm{d}\mathbf{x}(t) = \nabla_{\mathbf{x}} \log p_\phi(\mathbf{x}(t))\, \mathrm{d}t + \sqrt{2}\, \mathrm{d}\mathbf{w}(t), \tag{3.3.1.36}$$

其中 $\mathbf{w}(t)$ 是标准 Brown 运动（也称 Wiener 过程[7]）。需要理解的是，式 (3.3.1.33) 的离散更新规则正是该连续 SDE 的 Euler–Maruyama 离散化.

在标准正则性假设下（例如 $p_\phi \propto e^{-E_\phi}$，且 E_ϕ 具有 confining、足够光滑的势），$\mathbf{x}(t)$ 的分布（指数快地）收敛到 p_ϕ；因此我们可以通过模拟（求解）式 (3.3.1.36) 的 SDE 来采样.

为什么使用 Langevin 采样？ 理解 Langevin 采样的一个自然视角来自物理学：能量函数 $E_\phi(\mathbf{x})$ 定义了一个势场，塑造粒子的行为。根据 Newton 动力学，粒子在该能量所导出的力场下的运动由常微分方程（ODE）描述：

$$\mathrm{d}\mathbf{x}(t) = -\nabla_{\mathbf{x}} E_\phi(\mathbf{x}(t))\, \mathrm{d}t, \tag{3.3.1.37}$$

它确定性地把粒子沿下坡推到能量函数的某个局部极小。然而这种确定性动力学可能陷入局部极小，无法探索完整的数据分布.

为克服这一局限，Langevin 动力学引入随机扰动，得到 SDE：

$$\mathrm{d}\mathbf{x}(t) = -\nabla_{\mathbf{x}} E_\phi(\mathbf{x}(t))\, \mathrm{d}t + \underbrace{\sqrt{2}\, \mathrm{d}\mathbf{w}(t)}_{\text{注入噪声}}, \tag{3.3.1.38}$$

其中 $\mathbf{w}(t)$ 是标准 Brown 运动。噪声项使粒子能够越过势垒逃出局部极小，使轨迹成为一个随机过程，其平稳分布收敛到 Boltzmann 分布

$$p_\phi(\mathbf{x}) \propto e^{-E_\phi(\mathbf{x})}. \tag{3.3.1.39}$$

从这一视角看，EBM 就是学习一个力场，把样本推向高概率区域。Langevin 采样对 EBM 尤其有用，因为它提供了一种从模型分布 $p_\phi(\mathbf{x})$ 生成样本的实用方法，而无需显式计算配分函数。通过迭代地应用 Langevin 更新，便能得到逼近目标分布的样本.

[7]Brown 增量满足 $\mathbf{w}(t+\eta) - \mathbf{w}(t) \sim \mathcal{N}(\mathbf{0}, \eta\mathbf{I})$。Euler–Maruyama 因此使用步长噪声 $\sqrt{2}[\mathbf{w}(t+\eta) - \mathbf{w}(t)] = \sqrt{2\eta}\, \boldsymbol{\epsilon}_n$，其中 $\boldsymbol{\epsilon}_n \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$，这正是 $\sqrt{\eta}$ 因子的来源；平方根缩放由此而来。关于 Brown 运动与 SDE 的详细介绍参见附录 A.

Langevin 采样的固有困难. Langevin 动力学是广泛使用的基于 MCMC 的采样器，但它在高维空间中面临严重局限。其效率对步长 η、噪声尺度以及逼近目标分布所需迭代次数的选择高度敏感.

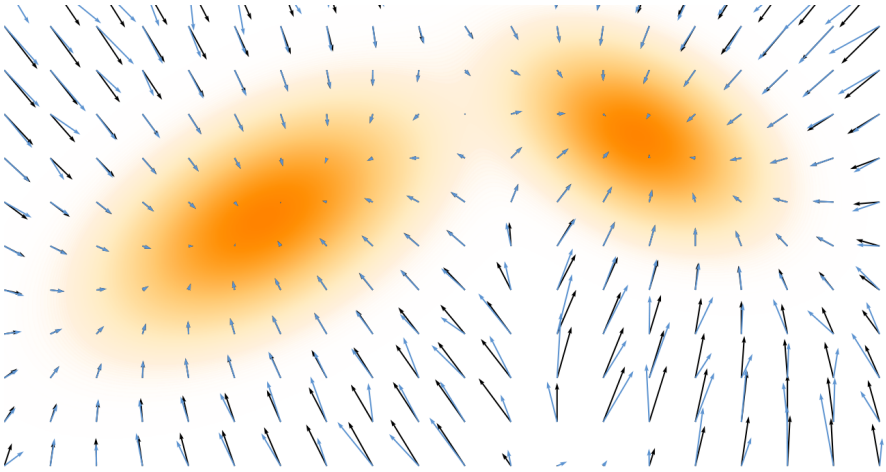
这种低效率的核心在于糟糕的 “混合时间”：在具有多个孤立模式的复杂数据分布中，Langevin 采样往往需要极长时间才能在高概率区域之间转移。随维度增大，这一问题显著恶化，导致收敛慢到不可接受.

可以把采样想象为探索一片辽阔而崎岖的地形，上面有许多遥远的山谷，每个山谷对应一个不同的数据模式。Langevin 动力学依赖局部随机更新，难以在这些山谷之间高效穿行。结果它常常无法捕捉分布的全部多样性.

这种低效率提示我们需要更有结构、更有引导性的采样方法，使其比纯随机探索更有效地在复杂数据流形上导航.

3.2 从基于能量的模型到基于分数的生成模型

EBM 表明：生成只依赖分数——它指向高概率区域——而不依赖完整的归一化密度。分数匹配虽然绕开了配分函数，但通过能量训练仍需要昂贵的二阶导数。关键想法是：既然用 Langevin 动力学采样只需要分数，我们可以直接用神经网络学习它。这一从建模能量到建模分数的转变，构成了基于分数的生成模型的基础.



ure 3.4: Illustration of Score Matching. The neural network score $\mathbf{s}_\phi(\mathbf{x})$ is trained to tch the ground truth score $\mathbf{s}(\mathbf{x})$ using a MSE loss. Both are represented as vector fields.

.1 Training with Score Matching

图 3.14: 分数匹配示意。神经网络分数 $s_\phi(\mathbf{x})$ 通过 MSE 损失训练，使之逼近真值分数 $\mathbf{s}(\mathbf{x})$，二者都以向量场表示.

3.2.1 用分数匹配训练

分数匹配. 为了从 p_{data} 的样本逼近分数函数 $\mathbf{s}(\mathbf{x}) = \nabla_{\mathbf{x}} \log p_{\text{data}}(\mathbf{x})$，我们直接把它近似为一个由神经网络参数化的向量场 $\mathbf{s}_\phi(\mathbf{x})$（见图 3.14）：

$$\mathbf{s}_\phi(\mathbf{x}) \approx \mathbf{s}(\mathbf{x}). \tag{3.3.2.40}$$

分数匹配通过最小化真值分数与估计分数之间的均方误差（MSE）来拟合该向量场：

$$\mathcal{L}_{\text{SM}}(\phi) := \frac{1}{2}\mathbb{E}_{\mathbf{x}\sim p_{\text{data}}}\left[\|\mathbf{s}_\phi(\mathbf{x}) - \mathbf{s}(\mathbf{x})\|_2^2\right]. \tag{3.3.2.41}$$

可处理的分数匹配. 乍一看这一目标不可行，因为作为回归目标的真值分数 $\mathbf{s}(\mathbf{x})$ 未知。幸运的是，Hyvärinen 与 Dayan（2005）证明：分部积分给出一个等价目标，它只依赖模型 $\mathbf{s}_\phi$ 与数据样本，而无需访问真值分数。我们把这一关键结果陈述为如下命题：

命题 3.2.1 (Hyvärinen 的可处理 SM 形式)**：** *可将下式写成*

$$\mathcal{L}_{\text{SM}}(\phi) = \widetilde{\mathcal{L}}_{\text{SM}}(\phi) + C, \tag{3.3.2.42}$$

其中

$$\widetilde{\mathcal{L}}_{\text{SM}}(\phi) := \mathbb{E}_{\mathbf{x}\sim p_{\text{data}}(\mathbf{x})}\left[\text{Tr}\left(\nabla_{\mathbf{x}}\mathbf{s}_\phi(\mathbf{x})\right) + \tfrac{1}{2}\|\mathbf{s}_\phi(\mathbf{x})\|_2^2\right], \tag{3.3.2.43}$$

C 是与 ϕ 无关的常数。最小化解 $\mathbf{s}^*$ 为 $\mathbf{s}^*(\cdot) = \nabla_{\mathbf{x}} \log p(\cdot)$.

命题证明： 将 $\mathcal{L}_{\text{SM}}$ 中的 MSE 展开并分部积分即得。证明见附录 D.2.1. □

利用式 (3.3.2.43) 的等价目标，我们仅从观测到的 p_{data} 样本训练分数模型 $\mathbf{s}_\phi(\mathbf{x})$，从而不再需要真值分数函数.

式 (3.3.2.43) 的直观. 替代目标 $\widetilde{\mathcal{L}}_{\text{SM}}(\phi)$ 可直接从两项理解。范数项 $\frac{1}{2}\|\mathbf{s}_\phi(\mathbf{x})\|^2$ 在 p_{data} 大的区域抑制分数，使这些点成为驻点。散度项 $\text{Tr}(\nabla_{\mathbf{x}}\mathbf{s}_\phi(\mathbf{x}))$ 偏好负值，因此这些驻点起到吸引汇的作用。二者共同把高密度区域塑造成分数场的稳定收缩点。下面详细解释.

由幅值项产生驻点. 由于 $\widetilde{\mathcal{L}}_{\text{SM}}(\phi)$ 中的期望取在 p_{data} 下，$p_{\text{data}}(\mathbf{x})$ 大的区域（高数据密度）对损失贡献最大。幅值项 $\frac{1}{2}\|\mathbf{s}_\phi(\mathbf{x})\|^2$ 因此驱动 $\mathbf{s}_\phi(\mathbf{x}) \to 0$，恰好发生在这些高概率区域，即这些位置成为驻点.

当场（近似）为梯度时的凹性. 散度项 $\text{Tr}(\nabla_{\mathbf{x}}\mathbf{s}_\phi(\mathbf{x}))$ 鼓励向量场在高数据密度区域具有负散度。负散度意味着附近向量收敛而非散开，因此该区域的驻点起到汇的作用：附近轨迹被向内拉。为精确化，假设 $\mathbf{s}_\phi = \nabla_{\mathbf{x}} u$，其中 $u : \mathbb{R}^D \to \mathbb{R}$ 是标量函数——这在匹配对数密度时是自然的。则 $\nabla_{\mathbf{x}}\mathbf{s}_\phi = \nabla_{\mathbf{x}}^2 u$（Hessian），$\nabla \cdot \mathbf{s}_\phi(\mathbf{x}) = \text{Tr}(\nabla_{\mathbf{x}}^2 u(\mathbf{x}))$（散度）.

在驻点 $\mathbf{x}_\star$，$\mathbf{s}_\phi(\mathbf{x}_\star) = \nabla_{\mathbf{x}} u(\mathbf{x}_\star) = \mathbf{0}$，二阶 Taylor 展开给出

$$u(\mathbf{x}) = u(\mathbf{x}_\star) + \tfrac{1}{2}(\mathbf{x} - \mathbf{x}_\star)^\top \nabla_{\mathbf{x}}^2 u(\mathbf{x}_\star)(\mathbf{x} - \mathbf{x}_\star) + o(\|\mathbf{x} - \mathbf{x}_\star\|^2). \tag{3.3.2.44}$$

若 Hessian $\nabla_{\mathbf{x}}^2 u(\mathbf{x}_\star)$ 负定，则 u 在 $\mathbf{x}_\star$ 局部凹，对数密度在该处取得严格局部极大[8]。由于 Hessian 的所有特征值均为负，迹也为负：$\mathrm{Tr}(\nabla_{\mathbf{x}}^2 u(\mathbf{x}_\star)) < 0$。于是学到的向量场具有负散度，驻点是汇：小扰动被收缩回 $\mathbf{x}_\star$.

3.2.2 用 Langevin 动力学采样

一旦通过最小化式 (3.3.2.43) 训练好，分数模型 $\mathbf{s}_{\phi^\times}(\mathbf{x})$ 便可在 Langevin 动力学中替代 oracle 分数进行采样：

$$\mathbf{x}_{n+1} = \mathbf{x}_n + \eta\, \mathbf{s}_{\phi^\times}(\mathbf{x}_n) + \sqrt{2\eta}\, \boldsymbol{\epsilon}_n, \qquad \boldsymbol{\epsilon}_n \sim \mathcal{N}(\mathbf{0}, \mathbf{I}), \tag{3.3.2.45}$$

$n = 0, 1, 2, \ldots$，从 $\mathbf{x}_0$ 初始化。与 EBM 情形的式 (3.3.1.36) 一样，这一递归正是连续时间 Langevin SDE 的 Euler–Maruyama 离散化：

$$\mathrm{d}\mathbf{x}(t) = \mathbf{s}_{\phi^\times}(\mathbf{x}(t))\, \mathrm{d}t + \sqrt{2}\, \mathrm{d}\mathbf{w}(t), \tag{3.3.2.46}$$

初始化为 $\mathbf{x}(0)$。因此在小步长极限下，离散形式与连续形式一致。实践中，既可运行离散采样器，也可直接模拟 SDE.

3.2.3 序章：基于分数的生成模型

本章余下部分，我们考察分数函数在现代扩散模型中的基础作用。分数函数最初是为了让 EBM 高效训练而引入的，如今已演变为新一代生成模型的核心组件。在此基础上，我们探讨分数函数如何影响 基于分数的扩散模型（score-based diffusion model）的理论表述与实际实现，为通过随机过程进行数据生成提供一个有原则的框架.

3.3 去噪分数匹配

3.3.1 动机

虽然式 (3.3.2.43) 的替代目标更易处理，但它仍需计算 Jacobian 的迹 $\mathrm{Tr}(\nabla_{\mathbf{x}} \mathbf{s}_\phi(\mathbf{x}))$，最坏情形复杂度为 $\mathcal{O}(D^2)$。这种复杂度限制了它在高维数据上的可扩展性.

为解决这一问题，*切片分数匹配*（sliced score matching）（Song 等, 2020b）用基于随机投影的随机估计替代迹项。我们简述其思想.

切片分数匹配与 Hutchinson 估计. 切片分数匹配用沿随机 “切片” 的方向导数平均来替代分数匹配中的迹。设 $\mathbf{u} \in \mathbb{R}^D$ 为各向同性随机向量（例如 Rademacher 或标准 Gaussian），满足 $\mathbb{E}[\mathbf{u}] = \mathbf{0}$、$\mathbb{E}[\mathbf{u}\mathbf{u}^\top] = \mathbf{I}$。由 Hutchinson 恒等式

$$\mathrm{Tr}(\mathbf{A}) = \mathbb{E}_{\mathbf{u}}[\mathbf{u}^\top \mathbf{A} \mathbf{u}], \qquad \mathbb{E}_{\mathbf{u}}[(\mathbf{u}^\top \mathbf{s}_\phi(\mathbf{x}))^2] = \|\mathbf{s}_\phi(\mathbf{x})\|_2^2, \tag{3.3.3.47}$$

得到精确形式

$$\widetilde{\mathcal{L}}_{\mathrm{SM}}(\phi) = \mathbb{E}_{\mathbf{x},\mathbf{u}}\left[\mathbf{u}^\top (\nabla_{\mathbf{x}} \mathbf{s}_\phi(\mathbf{x}))\mathbf{u} + \tfrac{1}{2}(\mathbf{u}^\top \mathbf{s}_\phi(\mathbf{x}))^2\right]. \tag{3.3.3.48}$$

[8]我们注意：严格凹性（从而对数密度的严格局部极大）要求整个 Hessian $\nabla_{\mathbf{x}}^2 u$ 负定，而不仅是迹为负。负迹只保证特征值之和为负，某些特征值仍可能为正，从而得到鞍点而非极大值。

该目标可用自动微分高效求值，使用 Jacobian-向量积（JVP/VJP）运算，而无需显式构造大的 Jacobian 或 Hessian。对 K 个随机探针取平均得到方差为 $\mathcal{O}(1/K)$ 的无偏估计；方向项 $\mathbf{u}^\top(\nabla_{\mathbf{x}}\mathbf{s}_\phi)\mathbf{u}$ 可用 JVP/VJP 高效计算。直观上，这意味着我们只在随机方向上检查模型行为：投影分数被推向上数据密度更高的区域，从而在期望意义上使数据点成为驻点.

从切片分数匹配到去噪分数匹配. 切片分数匹配绕开了 Jacobian，但仍依赖原始数据分布。这使它很脆弱：对于位于低维流形上的图像数据，分数 $\nabla_{\mathbf{x}} \log p_{\text{data}}(\mathbf{x})$ 可能无定义或不稳定，且该方法只在观测点约束向量场，对其邻域控制很弱。它还受探针诱导方差与反复 JVP/VJP 开销之苦.

我们这里聚焦的更鲁棒的替代方案是 *去噪分数匹配*（Denoising Score Matching, DSM）（Vincent, 2011），它提供了有原则且可扩展的解决方案.

3.3.2 训练

回顾式 (3.3.2.41) 中的 SM 损失：

$$\mathcal{L}_{\text{SM}}(\phi) = \frac{1}{2}\mathbb{E}_{\mathbf{x}\sim p_{\text{data}}(\mathbf{x})}\left[\|\mathbf{s}_\phi(\mathbf{x}) - \nabla_{\mathbf{x}} \log p_{\text{data}}(\mathbf{x})\|_2^2\right], \tag{3.3.3.49}$$

其中困难来自不可处理项 $\nabla_{\mathbf{x}} \log p_{\text{data}}(\mathbf{x})$.

Vincent(2011)通过条件化解决. 为克服 $\nabla_{\mathbf{x}} \log p_{\text{data}}(\mathbf{x})$ 的不可处理性，Vincent(2011) 提出：通过已知条件分布 $p_\sigma(\tilde{\mathbf{x}} \mid \mathbf{x})$（尺度 σ）向数据 $\mathbf{x} \sim p_{\text{data}}$ 注入噪声。训练神经网络 $\mathbf{s}_\phi(\tilde{\mathbf{x}}; \sigma)$ 去逼近边缘扰动分布

$$p_\sigma(\tilde{\mathbf{x}}) = \int p_\sigma(\tilde{\mathbf{x}} \mid \mathbf{x}) p_{\text{data}}(\mathbf{x})\, \mathrm{d}\mathbf{x} \tag{3.3.3.50}$$

的分数，最小化损失

$$\mathcal{L}_{\text{SM}}(\phi; \sigma) := \frac{1}{2}\mathbb{E}_{\tilde{\mathbf{x}}\sim p_\sigma}\left[\|\mathbf{s}_\phi(\tilde{\mathbf{x}}; \sigma) - \nabla_{\tilde{\mathbf{x}}} \log p_\sigma(\tilde{\mathbf{x}})\|_2^2\right]. \tag{3.3.3.51}$$

虽然 $\nabla_{\tilde{\mathbf{x}}} \log p_\sigma(\tilde{\mathbf{x}})$ 一般不可处理，但 Vincent（2011）证明：对 $\mathbf{x} \sim p_{\text{data}}$ 进行条件化，可得到一个等价且可处理的目标——DSM 损失（DSM loss）：

$$\mathcal{L}_{\text{DSM}}(\phi; \sigma) := \frac{1}{2}\mathbb{E}_{\mathbf{x}\sim p_{\text{data}}, \tilde{\mathbf{x}}\sim p_\sigma(\cdot|\mathbf{x})}\left[\|\mathbf{s}_\phi(\tilde{\mathbf{x}}; \sigma) - \nabla_{\tilde{\mathbf{x}}} \log p_\sigma(\tilde{\mathbf{x}} \mid \mathbf{x})\|_2^2\right]. \tag{3.3.3.52}$$

式 (3.3.3.52) 的最优最小化解 $\mathbf{s}^*$ 满足

$$\mathbf{s}^*(\tilde{\mathbf{x}}; \sigma) = \nabla_{\tilde{\mathbf{x}}} \log p_\sigma(\tilde{\mathbf{x}}), \tag{3.3.3.53}$$

它对式 (3.3.3.51) 也是最优的.

例如，当 $p_\sigma(\tilde{\mathbf{x}} \mid \mathbf{x})$ 是方差为 σ^2 的 Gaussian 噪声时，

$$p_\sigma(\tilde{\mathbf{x}} \mid \mathbf{x}) = \mathcal{N}(\tilde{\mathbf{x}}; \mathbf{x}, \sigma^2\mathbf{I}), \tag{3.3.3.54}$$

其梯度 $\nabla_{\tilde{\mathbf{x}}} \log p_\sigma(\tilde{\mathbf{x}} \mid \mathbf{x})$ 有闭式（见式 (3.3.3.61)），使回归目标显式且计算上可处理.

此外，当 $\sigma \to 0$ 时，$p_\sigma(\tilde{\mathbf{x}}) \approx p_{\text{data}}(\mathbf{x})$，且

$$\mathbf{s}^*(\tilde{\mathbf{x}}; \sigma) = \nabla_{\tilde{\mathbf{x}}} \log p_\sigma(\tilde{\mathbf{x}}) \approx \nabla_{\mathbf{x}} \log p_{\text{data}}(\mathbf{x}), \tag{3.3.3.55}$$

表明学到的分数逼近原始数据分数，可用于生成.

我们把 $\mathcal{L}_{\text{SM}}$ 与 $\mathcal{L}_{\text{DSM}}$ 之间的梯度等价性形式化为如下定理：

定理 3.3.1 ($\mathcal{L}_{\text{SM}}$ 与 $\mathcal{L}_{\text{DSM}}$ 的等价性)**：** 对任意固定噪声尺度 $\sigma > 0$，下式成立：

$$\mathcal{L}_{\text{SM}}(\phi; \sigma) = \mathcal{L}_{\text{DSM}}(\phi; \sigma) + C, \tag{3.3.3.56}$$

其中 C 是与参数 ϕ 无关的常数。进一步，两个损失的最小化解 $\mathbf{s}^*(\cdot; \sigma)$ 满足

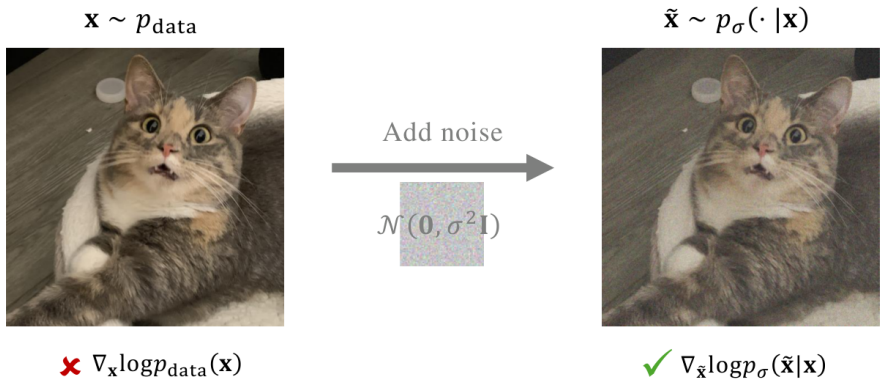
$$\mathbf{s}^*(\tilde{\mathbf{x}}; \sigma) = \nabla_{\tilde{\mathbf{x}}} \log p_\sigma(\tilde{\mathbf{x}}), \qquad \text{对几乎所有} \tilde{\mathbf{x}}. \tag{3.3.3.57}$$

定理证明： 等价性来自直接计算：展开 $\mathcal{L}_{\text{SM}}$ 与 $\mathcal{L}_{\text{DSM}}$ 中的 MSE，所有依赖 ϕ 的项相消，只剩与 ϕ 无关的常数差. 最小化解的推导与命题 3.2.1 的论证相同，见附录 D.2.1. □

本定理与 DDPM 中的定理 2.2.1 一样，揭示了一个关键的共享原理：

注 3.3.1 (条件化技巧)**：** 条件化技巧同样出现在 DDPM 扩散模型的变分视角中（见 DDPM 中的等价定理）：对数据点 $\mathbf{x}$ 进行条件化，把一个不可处理损失转化为可用于 Monte Carlo 估计的可处理损失。类似思想也出现在基于流的视角中（例如 Flow Matching，Lipman 等, 2022），我们将在第 5.2 节看到. ◇

特例：加性 Gaussian 噪声. 现在考虑常见情形：给每个数据点加方差为 σ^2 的 Gaussian 噪声 $\mathcal{N}(\mathbf{0}, \sigma^2\mathbf{I})$，即 $\mathbf{x} \sim p_{\text{data}}$：



ure 3.5: Illustration of DSM via the conditioning technique. By perturbing the d

图 3.15: 通过条件化技术进行 DSM 示意。用小加性 Gaussian 噪声 $\mathcal{N}(\mathbf{0}, \sigma^2\mathbf{I})$ 扰动数据分布 p_{data} 后，所得条件分布 $p_\sigma(\tilde{\mathbf{x}} \mid \mathbf{x}) = \mathcal{N}(\tilde{\mathbf{x}}; \mathbf{x}, \sigma^2\mathbf{I})$ 具有闭式分数函数.

$$\tilde{\mathbf{x}} = \mathbf{x} + \sigma\,\boldsymbol{\epsilon}, \qquad \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}), \tag{3.3.3.58}$$

于是带噪数据 $\tilde{\mathbf{x}}$ 服从

$$p_\sigma(\tilde{\mathbf{x}} \mid \mathbf{x}) = \mathcal{N}(\tilde{\mathbf{x}}; \mathbf{x}, \sigma^2 \mathbf{I}). \tag{3.3.3.59}$$

此设定下，条件分数解析给出：

$$\nabla_{\tilde{\mathbf{x}}} \log p_\sigma(\tilde{\mathbf{x}} \mid \mathbf{x}) = \frac{\mathbf{x} - \tilde{\mathbf{x}}}{\sigma^2}. \tag{3.3.3.60}$$

因此 DSM 损失简化为：

$$\begin{aligned} \mathcal{L}_{\mathrm{DSM}}(\phi; \sigma) &= \frac{1}{2} \mathbb{E}_{\mathbf{x}, \tilde{\mathbf{x}} \mid \mathbf{x}} \left[\left\| \mathbf{s}_\phi(\tilde{\mathbf{x}}; \sigma) - \frac{\mathbf{x} - \tilde{\mathbf{x}}}{\sigma^2} \right\|_2^2 \right] \\ &= \frac{1}{2} \mathbb{E}_{\mathbf{x}, \boldsymbol{\epsilon}} \left[\left\| \mathbf{s}_\phi(\mathbf{x} + \sigma \boldsymbol{\epsilon}; \sigma) + \frac{\boldsymbol{\epsilon}}{\sigma} \right\|_2^2 \right], \end{aligned} \tag{3.3.3.61}$$

其中 $\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$。这一目标构成了（基于分数的）扩散模型的核心.

当噪声水平 σ 小时，Gaussian 平滑后的边缘 $p_\sigma = p_{\mathrm{data}} * \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I})$，其高密度区域与分数几乎重合：$\nabla_{\tilde{\mathbf{x}}} \log p_\sigma(\tilde{\mathbf{x}}) \approx \nabla_{\mathbf{x}} \log p_{\mathrm{data}}(\mathbf{x})$。因此，沿带噪分数方向 $\nabla_{\tilde{\mathbf{x}}} \log p_\sigma$ 走一小步，便把带噪样本推向干净分布几乎相同的高似然区域，这与第 3.2.1 节总结的分数匹配直觉一致. 反之，当 σ 大时，平滑 “过度简化” 了曲面：p_σ 抹掉局部模式，其分数主要把样本拉向全局质量中心（可类比向均值收缩），产生过于平滑的粗去噪。实践中，DSM 通常假设注入噪声小而温和.

为更好理解该目标为何自然对应 “去噪” 过程，我们在第 3.3.4 与 3.3.5 节展开.

3.3.3 采样

一旦在噪声水平 σ 训练好分数模型 $\mathbf{s}_{\phi^\times}(\tilde{\mathbf{x}}; \sigma)$，我们便用 Langevin 动力学生成样本：用学到的模型替换真值分数。更新规则为：

$$\tilde{\mathbf{x}}_{n+1} = \tilde{\mathbf{x}}_n + \eta \underbrace{\mathbf{s}_{\phi^\times}(\tilde{\mathbf{x}}_n; \sigma)}_{\approx \nabla_{\tilde{\mathbf{x}}} \log p_\sigma(\tilde{\mathbf{x}}_n)} + \sqrt{2\eta}\, \boldsymbol{\epsilon}_n, \qquad \boldsymbol{\epsilon}_n \sim \mathcal{N}(\mathbf{0}, \mathbf{I}), \tag{3.3.3.62}$$

$n = 0, 1, 2, \ldots$，从初值 $\tilde{\mathbf{x}}_0$ 开始。若 σ 足够小，则足够多步后 $\tilde{\mathbf{x}}_n$ 逼近 p_{data} 的样本.

注入噪声的优势. 我们还注意到：与式 (3.3.2.41) 的原始分数匹配相比，注入 Gaussian 噪声形成 p_σ（例如式 (3.3.3.61)）带来两个关键优势（Song 与 Ermon, 2019）：

- **良定义的梯度.** 噪声把数据从低维流形上推开，得到在 $\mathbb{R}^D$ 上具有全支撑的分布 p_σ。因此分数函数 $\nabla_{\tilde{\mathbf{x}}} \log p_\sigma(\tilde{\mathbf{x}})$ 在处处良定义.
- **改进的覆盖.** 噪声平滑了模式之间的稀疏区域，提升训练信号质量，并使 Langevin 动力学更有效地穿越低密度区域.

3.3.4 为什么 DSM 是去噪：Tweedie 公式

我们从 Tweedie 公式（Tweedie's formula）（Efron, 2011）开始，它为仅从带噪观测去噪提供了有原则的基础。具体地，它表明：给定来自未知 $\mathbf{x} \sim p_{\text{data}}$ 的单个 Gaussian 污染观测 $\tilde{\mathbf{x}} \sim \mathcal{N}(\cdot; \alpha\mathbf{x}, \sigma^2\mathbf{I})$，一个去噪估计（所有合理干净信号在 $\tilde{\mathbf{x}}$ 下的平均）可以通过把 $\tilde{\mathbf{x}}$ 沿其带噪边缘 p_σ（定义如下）的分数 $\nabla_{\tilde{\mathbf{x}}} \log p_\sigma(\tilde{\mathbf{x}})$ 方向推进一步、步长 σ^2 得到：

$$p_\sigma(\tilde{\mathbf{x}}) := \int \mathcal{N}(\tilde{\mathbf{x}}; \alpha\mathbf{x}_0, \sigma^2\mathbf{I})\, p_{\text{data}}(\mathbf{x})\, \mathrm{d}\mathbf{x}. \tag{3.3.3.63}$$

下面正式陈述该命题.

引理 3.3.1 (Tweedie 公式)**：** 设 $\mathbf{x} \sim p_{\text{data}}$，且在给定 $\mathbf{x}$ 条件下 $\tilde{\mathbf{x}} \sim \mathcal{N}(\cdot; \alpha\mathbf{x}, \sigma^2\mathbf{I})$，$\alpha \neq 0$。则 Tweedie 公式为

$$\alpha\, \mathbb{E}_{\mathbf{x}\sim p(\mathbf{x}|\tilde{\mathbf{x}})}[\mathbf{x} \mid \tilde{\mathbf{x}}] = \tilde{\mathbf{x}} + \sigma^2 \nabla_{\tilde{\mathbf{x}}} \log p_\sigma(\tilde{\mathbf{x}}), \tag{3.3.3.64}$$

其中期望取在给定 $\tilde{\mathbf{x}}$ 时 $\mathbf{x}$ 的后验分布 $p(\mathbf{x} \mid \tilde{\mathbf{x}})$ 上.

引理证明： 证明通过计算边缘 $p(\tilde{\mathbf{x}}) = \int p(\tilde{\mathbf{x}} \mid \mathbf{x}) p_{\text{data}}(\mathbf{x})\, \mathrm{d}\mathbf{x}$ 的分数完成。在积分号下求导并使用 Gaussian 条件密度的形式，直接得到一个表达式，它整理后便是联系分数与后验均值的恒等式。细节见附录 D.2.3. □

Tweedie 公式在扩散模型中起核心作用，其中多层噪声如同 DDPM 那样被引入。它使得能够通过分数函数从带噪观测估计干净样本，从而在分数预测与去噪器之间建立基本联系：

$$\underbrace{\mathbb{E}[\mathbf{x} \mid \tilde{\mathbf{x}}]}_{\text{从}\tilde{\mathbf{x}}\text{ 估计出的去噪器}} = \frac{1}{\alpha}\big(\tilde{\mathbf{x}} + \sigma^2 \nabla_{\tilde{\mathbf{x}}} \log p_\sigma(\tilde{\mathbf{x}})\big). \tag{3.3.3.65}$$

特别地，在带噪对数似然上以特定步长 σ^2 走一步梯度上升，便得到去噪估计（条件平均干净信号）。这使得 DSM 训练与去噪紧密相关：若从 DSM 训练得 $\mathbf{s}_\phi(\tilde{\mathbf{x}}) \approx \nabla_{\tilde{\mathbf{x}}} \log p_\sigma(\tilde{\mathbf{x}})$，则

$$\frac{1}{\alpha}\big(\tilde{\mathbf{x}} + \sigma^2 \mathbf{s}_\phi(\tilde{\mathbf{x}})\big) \tag{3.3.3.66}$$

就是去噪器.

（可选）高阶 Tweedie 公式. 经典 Tweedie 公式通过梯度 $\nabla_{\tilde{\mathbf{x}}} \log p(\tilde{\mathbf{x}})$ 表示后验均值 $\mathbb{E}[\mathbf{x}_0 \mid \tilde{\mathbf{x}}]$。高阶推广（Meng 等, 2021a）通过 $\log p(\tilde{\mathbf{x}})$ 的高阶导数表示后验协方差与更高阶累积量.

带对数归一化子 $\lambda(\tilde{\mathbf{x}})$ 的指数族设定. 设给定隐自然参数 $\boldsymbol{\eta} \in \mathbb{R}^D$ 时 $\tilde{\mathbf{x}}$ 的条件律属于自然指数族：

$$q_\sigma(\tilde{\mathbf{x}} \mid \boldsymbol{\eta}) = \exp\big(\boldsymbol{\eta}^\top \tilde{\mathbf{x}} - \psi(\boldsymbol{\eta})\big)\, q_0(\tilde{\mathbf{x}}). \tag{3.3.3.67}$$

这里 $q_0(\tilde{\mathbf{x}})$ 是基测度，即不依赖 $\boldsymbol{\eta}$ 的部分；对于方差 $\sigma^2\mathbf{I}$ 的加性 Gaussian 噪声，它等于 $(2\pi\sigma^2)^{-D/2}\exp(-\|\tilde{\mathbf{x}}\|^2/(2\sigma^2))$。设 $p(\boldsymbol{\eta})$ 是隐自然参数的预定义分布，可视为干净数据分布的重参数化（对 Gaussian 位置模型，$\boldsymbol{\eta}=\mathbf{x}/\sigma^2$）。观测到的带噪边缘为

$$p_\sigma(\tilde{\mathbf{x}}) = \int q_\sigma(\tilde{\mathbf{x}} \mid \boldsymbol{\eta})\, p(\boldsymbol{\eta})\, \mathrm{d}\boldsymbol{\eta}. \tag{3.3.3.68}$$

定义 $\tilde{\mathbf{x}}$ 处的对数配分函数（对数归一化子）

$$\lambda(\tilde{\mathbf{x}}) := \log p_\sigma(\tilde{\mathbf{x}}) - \log q_0(\tilde{\mathbf{x}}). \tag{3.3.3.69}$$

则给定 $\tilde{\mathbf{x}}$ 时 $\boldsymbol{\eta}$ 的后验为

$$p(\boldsymbol{\eta} \mid \tilde{\mathbf{x}}) \propto \exp\big(\boldsymbol{\eta}^\top\tilde{\mathbf{x}} - \psi(\boldsymbol{\eta}) - \lambda(\tilde{\mathbf{x}})\big)\, p(\boldsymbol{\eta}), \tag{3.3.3.70}$$

这表明：作为 $\tilde{\mathbf{x}}$ 的函数，后验具有指数族形式，自然参数为 $\tilde{\mathbf{x}}$，充分统计量为 $\boldsymbol{\eta}$，对数配分函数为 $\lambda(\tilde{\mathbf{x}})$.

λ 的导数给出后验累积量. 两条简单规则在起作用。第一，归一化：对任意 $\tilde{\mathbf{x}}$，

$$\int \exp\big(\boldsymbol{\eta}^\top\tilde{\mathbf{x}} - \psi(\boldsymbol{\eta}) - \lambda(\tilde{\mathbf{x}})\big)\, p(\boldsymbol{\eta})\, \mathrm{d}\boldsymbol{\eta} = 1. \tag{3.3.3.71}$$

对该恒等式关于 $\tilde{\mathbf{x}}$ 求导，会从指数中带下 $\boldsymbol{\eta}$ 的幂次以及 $\lambda(\tilde{\mathbf{x}})$ 的导数；令结果为零，便得到 λ 的导数与 $\boldsymbol{\eta}$ 的后验矩之间的等式。第二，指数族的标准性质：对数配分函数是充分统计量的累积量生成函数。因此

$$\nabla_{\tilde{\mathbf{x}}}\lambda(\tilde{\mathbf{x}}) = \mathbb{E}[\boldsymbol{\eta} \mid \tilde{\mathbf{x}}], \qquad \nabla^2_{\tilde{\mathbf{x}}}\lambda(\tilde{\mathbf{x}}) = \mathrm{Cov}[\boldsymbol{\eta} \mid \tilde{\mathbf{x}}], \qquad \nabla^{(k)}_{\tilde{\mathbf{x}}}\lambda(\tilde{\mathbf{x}}) = \kappa_k(\boldsymbol{\eta} \mid \tilde{\mathbf{x}}) \quad (k \geq 3), \tag{3.3.3.72}$$

其中 κ_k 是给定 $\tilde{\mathbf{x}}$ 时随机向量 $\boldsymbol{\eta}$ 的 k 阶条件累积量，由标准矩–累积量关系得到.

这些就是高阶 Tweedie 公式。特化到 $\boldsymbol{\eta}=\mathbf{x}/\sigma^2$ 的 Gaussian 位置模型，便得到用 $\log p_\sigma(\tilde{\mathbf{x}})$ 导数表示的常见形式：

$$\mathbb{E}[\mathbf{x} \mid \tilde{\mathbf{x}}] = \tilde{\mathbf{x}} + \sigma^2\nabla_{\tilde{\mathbf{x}}}\log p_\sigma(\tilde{\mathbf{x}}), \qquad \mathrm{Cov}[\mathbf{x} \mid \tilde{\mathbf{x}}] = \sigma^2\mathbf{I} + \sigma^4\nabla^2_{\tilde{\mathbf{x}}}\log p_\sigma(\tilde{\mathbf{x}}), \tag{3.3.3.73}$$

更高阶累积量随 $\log p_\sigma(\tilde{\mathbf{x}})$ 的高阶导数缩放.

已有若干研究探索训练神经网络估计高阶分数（Meng 等, 2021a；Lu 等, 2022a；Lai 等, 2023a）。相比之下，我们的目的是澄清它们与统计量的关系，方法细节请参阅这些工作.

3.3.5 （可选）为什么 DSM 是去噪：SURE

SURE（Stein 无偏风险估计）. 高层地看，Stein 无偏风险估计（SURE）是一种无需知道干净信号即可估计去噪器 $\mathbf{D}$ 的均方误差（MSE）的技术。换言之，SURE 提供了一种在只有带噪数据时选择或训练去噪器的方法.

为清晰起见，考虑加性 Gaussian 噪声设定：

$$\tilde{\mathbf{x}} = \mathbf{x} + \sigma\,\boldsymbol{\epsilon}, \qquad \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}), \tag{3.3.3.74}$$

其中 $\mathbf{x} \in \mathbb{R}^D$ 是未知干净信号，$\tilde{\mathbf{x}}$ 是观测到的带噪版本。去噪器是任意（弱可微）映射 $\mathbf{D} : \mathbb{R}^D \to \mathbb{R}^D$，它给出 $\mathbf{x}$ 的估计 $\mathbf{D}(\tilde{\mathbf{x}})$.

自然的度量是条件 MSE：

$$R(\mathbf{D}; \mathbf{x}) := \mathbb{E}_{\tilde{\mathbf{x}}|\mathbf{x}}\left[\|\mathbf{D}(\tilde{\mathbf{x}}) - \mathbf{x}\|_2^2 \mid \mathbf{x}\right]. \tag{3.3.3.75}$$

该量依赖未知的真值 $\mathbf{x}$，因此无法直接计算。然而 Stein 恒等式（见附录 D.2.4）给出如下可观测的替代量：

$$\mathrm{SURE}(\mathbf{D}; \tilde{\mathbf{x}}) = \|\mathbf{D}(\tilde{\mathbf{x}}) - \tilde{\mathbf{x}}\|_2^2 + 2\sigma^2 \nabla_{\tilde{\mathbf{x}}} \cdot \mathbf{D}(\tilde{\mathbf{x}}) - D\sigma^2, \tag{3.3.3.76}$$

其中 $\nabla_{\tilde{\mathbf{x}}} \cdot \mathbf{D}(\tilde{\mathbf{x}})$ 表示 $\mathbf{D}$ 的散度。我们强调 $\mathrm{SURE}(\mathbf{D}; \tilde{\mathbf{x}})$ 只需要带噪观测 $\tilde{\mathbf{x}}$，不需要干净 $\mathbf{x}$.

直观上，SURE 由两部分互补组成。项 $\|\mathbf{D}(\tilde{\mathbf{x}}) - \tilde{\mathbf{x}}\|^2$ 度量去噪器输出与带噪输入相差多远；单独看它低估了真实误差，因为 $\tilde{\mathbf{x}}$ 已被污染。散度项作为校正：它刻画去噪器对输入小扰动的敏感度，从而计入噪声引入的方差.

重要的是，对任意固定但未知的 $\mathbf{x}$，

$$\mathbb{E}_{\tilde{\mathbf{x}}|\mathbf{x}}\left[\,\mathrm{SURE}(\mathbf{D}; \mathbf{x} + \sigma\boldsymbol{\epsilon}) \mid \mathbf{x}\right] = R(\mathbf{D}; \mathbf{x}), \tag{3.3.3.77}$$

其中期望取在 Gaussian 噪声 $\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 上。因此最小化 SURE（期望意义或经验意义）等价于最小化真实 MSE，而只依赖带噪数据。实践中，对 $\mathbf{x} \sim p_{\mathrm{data}}$ 与污染噪声 $\boldsymbol{\epsilon}$ 同时平均 SURE，便得到全局 MSE 风险的无偏估计.

与 Tweedie 公式和 Bayes 最优的联系. 设 $p_\sigma(\tilde{\mathbf{x}}) = (p_{\mathrm{data}} * \mathcal{N}(\mathbf{0}, \sigma^2\mathbf{I}))(\tilde{\mathbf{x}})$ 表示本节考虑的带噪边缘.

SURE 是对噪声（在给定 $\mathbf{x}$ 条件下）的 MSE 无偏估计：

$$\mathbb{E}_{\tilde{\mathbf{x}}|\mathbf{x}}[\mathrm{SURE}(\mathbf{D}; \tilde{\mathbf{x}})] = \mathbb{E}_{\tilde{\mathbf{x}}|\mathbf{x}}[\|\mathbf{D}(\tilde{\mathbf{x}}) - \mathbf{x}\|^2]. \tag{3.3.3.78}$$

因此最小化期望 SURE 等于最小化 Bayes 风险 $\mathbb{E}_{(\mathbf{x},\tilde{\mathbf{x}})}[\|\mathbf{D}(\tilde{\mathbf{x}}) - \mathbf{x}\|^2] = \mathbb{E}_{\tilde{\mathbf{x}}}[\mathbb{E}_{\mathbf{x}|\tilde{\mathbf{x}}}[\|\mathbf{D}(\tilde{\mathbf{x}}) - \mathbf{x}\|^2]]$（由全期望公式/tower 性质）。该分解给出逐点优化：对几乎每个 $\tilde{\mathbf{x}}$，

$$\mathbf{D}^*(\tilde{\mathbf{x}}) = \arg\min_{\mathbf{z}} \mathbb{E}_{\mathbf{x}|\tilde{\mathbf{x}}}[\|\mathbf{z} - \mathbf{x}\|^2] = \mathbb{E}[\mathbf{x} \mid \tilde{\mathbf{x}}]. \tag{3.3.3.79}$$

因此 SURE 最优去噪器与第 3.3.4 节的 Bayes 估计器一致，由 Tweedie 恒等式：

$$\mathbf{D}^*(\tilde{\mathbf{x}}) = \mathbb{E}[\mathbf{x} \mid \tilde{\mathbf{x}}] = \tilde{\mathbf{x}} + \sigma^2 \nabla_{\tilde{\mathbf{x}}} \log p_\sigma(\tilde{\mathbf{x}}). \tag{3.3.3.80}$$

SURE 与分数匹配的关系. 式 (3.3.3.80) 的恒等式启发我们通过分数场参数化去噪器 $\mathbf{D}$:

$$\mathbf{D}(\tilde{\mathbf{x}}) = \tilde{\mathbf{x}} + \sigma^2 \mathbf{s}_\phi(\tilde{\mathbf{x}}; \sigma), \tag{3.3.3.81}$$

其中 $\mathbf{s}_\phi(\cdot;\sigma)$ 用于逼近带噪分数 $\nabla_{\tilde{\mathbf{x}}} \log p_\sigma(\cdot)$。把 $\mathbf{D}(\tilde{\mathbf{x}}) = \tilde{\mathbf{x}} + \sigma^2 \mathbf{s}_\phi(\tilde{\mathbf{x}};\sigma)$ 代入式 (3.3.3.76), 得

$$\frac{1}{2\sigma^4} \mathrm{SURE}(\mathbf{D}; \tilde{\mathbf{x}}) = \mathrm{Tr}(\nabla_{\tilde{\mathbf{x}}} s_\phi(\tilde{\mathbf{x}};\sigma)) + \tfrac{1}{2}\|\mathbf{s}_\phi(\tilde{\mathbf{x}};\sigma)\|_2^2 + \mathrm{const}(\sigma). \tag{3.3.3.82}$$

因此，对 $\tilde{\mathbf{x}} \sim p_\sigma$ 取期望后，最小化 SURE（差一个加性常数）等价于在噪声水平 σ 下最小化 Hyvärinen 替代分数匹配目标，期望取在 p_σ 下（见式 (3.3.2.43)）。于是两个目标具有相同的最小化解，即式 (3.3.3.80) 的去噪器.

3.3.6 （可选）广义分数匹配

动机. 经典分数匹配、去噪分数匹配及其高阶变体都以

$$\frac{\mathcal{L}p(\mathbf{x})}{p(\mathbf{x})} \tag{3.3.3.83}$$

为目标，其中 $\mathcal{L}$ 是作用于密度的线性算子。在经典情形 $\mathcal{L} = \nabla_{\mathbf{x}}$，这给出

$$\nabla_{\mathbf{x}} \log p(\mathbf{x}) = \frac{\nabla_{\mathbf{x}} p(\mathbf{x})}{p(\mathbf{x})}. \tag{3.3.3.84}$$

$\frac{\mathcal{L}p}{p}$ 的结构使得分部积分可消除归一化常数，得到只依赖 p 的样本与学到的场 $\mathbf{s}_\phi$ 的可处理目标。这一观点引出广义分数匹配框架.

广义 Fisher 散度. 设 p 为数据分布，q 为任意模型分布。对 $\mathbf{x}$ 的标量函数上的线性算子 $\mathcal{L}$，定义广义 Fisher 散度

$$\mathcal{D}_{\mathcal{L}}(p\|q) := \int p(\mathbf{x}) \left\| \frac{\mathcal{L}p(\mathbf{x})}{p(\mathbf{x})} - \frac{\mathcal{L}q(\mathbf{x})}{q(\mathbf{x})} \right\|_2^2 \mathrm{d}\tilde{\mathbf{x}}. \tag{3.3.3.85}$$

若 $\mathcal{L}$ 是完备的，即

$$\frac{\mathcal{L}p_1}{p_1} = \frac{\mathcal{L}p_2}{p_2} \text{ a.e.} \quad \Longrightarrow \quad p_1 = p_2 \text{ a.e.}, \tag{3.3.3.86}$$

则 $\mathcal{D}_{\mathcal{L}}(p\|q) = 0$ 唯一识别 $q = p$。对 $\mathcal{L} = \nabla_{\tilde{\mathbf{x}}}$，这恢复了经典 Fisher 散度（见式 (1.1.1.3)）.

分数参数化. 实践中我们不建模归一化密度 q。而是直接参数化向量场 $\mathbf{s}_\phi(\mathbf{x})$ 来逼近广义分数 $\frac{\mathcal{L}p(\mathbf{x})}{p(\mathbf{x})}$。考虑

$$\mathcal{D}_{\mathcal{L}}(p\|\mathbf{s}_\phi) := \mathbb{E}_{\mathbf{x}\sim p}\left[\left\| \mathbf{s}_\phi(\mathbf{x}) - \frac{\mathcal{L}p(\mathbf{x})}{p(\mathbf{x})} \right\|_2^2 \right]. \tag{3.3.3.87}$$

虽然 $\frac{\mathcal{L}p(\mathbf{x})}{p(\mathbf{x})}$ 未知，但 “分部积分” 使损失只依赖 $\mathbf{s}_\phi$。设 $\mathcal{L}^\dagger$ 是 $\mathcal{L}$ 的伴随，定义为

$$\int (\mathcal{L}f)^\top g = \int f(\mathcal{L}^\dagger g) \qquad \text{对所有检验函数} f, g, \tag{3.3.3.88}$$

当边界项消失时，它形式上把 $\mathcal{L}$“移过” 积分号。展开平方并应用该恒等式，得到可处理目标

$$\mathcal{L}_{\mathrm{GSM}}(\phi) = \mathbb{E}_{\mathbf{x}\sim p}\left[\tfrac{1}{2}\|\mathbf{s}_\phi(\mathbf{x})\|_2^2 - (\mathcal{L}^\dagger \mathbf{s}_\phi)(\mathbf{x})\right] + \text{const}, \tag{3.3.3.89}$$

其中常数与 ϕ 无关。我们只通过期望使用 p，因此广义分数匹配损失允许从训练数据得到经验估计，与经典分数匹配完全一样.

对 $\mathcal{L} = \nabla$，有 $\mathcal{L}^\dagger = -\nabla\cdot$，这恢复了式 (3.3.2.43) 中 Hyvärinen 的分数匹配目标 $\mathbb{E}_p[\frac{1}{2}\|\mathbf{s}_\phi\|^2 + \nabla\cdot\mathbf{s}_\phi]$.

算子示例.

- **经典分数匹配.** 取 $\mathcal{L} = \nabla_{\mathbf{x}}$。则广义分数退化为经典分数函数

$$\frac{\mathcal{L}p(\mathbf{x})}{p(\mathbf{x})} = \nabla_{\mathbf{x}} \log p(\mathbf{x}). \tag{3.3.3.90}$$

- **去噪分数匹配.** 对加性 Gaussian 噪声，定义算子

$$(\mathcal{L}f)(\tilde{\mathbf{x}}) = \tilde{\mathbf{x}}\, f(\tilde{\mathbf{x}}) + \sigma^2 \nabla_{\tilde{\mathbf{x}}} f(\tilde{\mathbf{x}}). \tag{3.3.3.91}$$

  则

$$\frac{\mathcal{L}p_\sigma(\tilde{\mathbf{x}})}{p_\sigma(\tilde{\mathbf{x}})} = \tilde{\mathbf{x}} + \sigma^2 \nabla_{\tilde{\mathbf{x}}} \log p_\sigma(\tilde{\mathbf{x}}) = \mathbb{E}[\mathbf{x}_0 \mid \tilde{\mathbf{x}}], \tag{3.3.3.92}$$

  其中 $p_\sigma(\tilde{\mathbf{x}}) := \int \mathcal{N}(\tilde{\mathbf{x}}; \alpha\mathbf{x}_0, \sigma^2\mathbf{I}) p_{\mathrm{data}}(\mathbf{x})\,\mathrm{d}\mathbf{x}$，$\tilde{\mathbf{x}} = \mathbf{x} + \sigma\boldsymbol{\epsilon}$。这正是 Tweedie 恒等式。用该算子最小化 $\mathcal{L}_{\mathrm{GSM}}$ 训练 $\mathbf{s}_\phi$ 去逼近去噪器，恢复了去噪分数匹配目标.

- **高阶目标.** 在 $\mathcal{L}$ 内堆叠导数会暴露 $\nabla^2 \log p$ 与更高阶导数，它们对应后验协方差与高阶累积量.

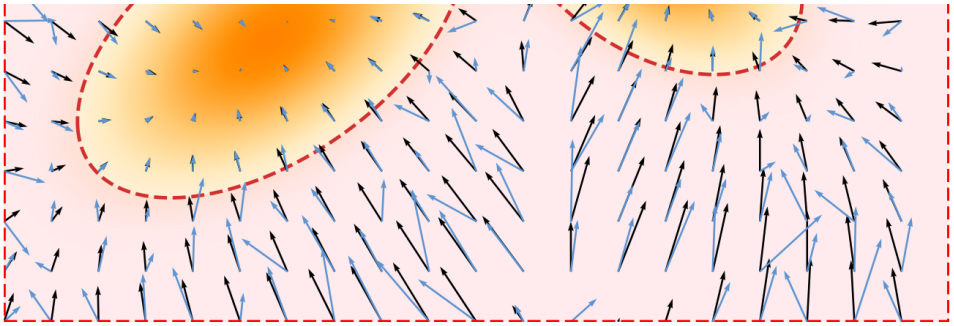
推广与用例. 广义分数匹配超越连续变量，扩展到离散设定，包括语言建模 (Meng 等, 2022；Lou 等, 2024)。它还启发了产生去噪风格目标的分数启发式训练。这一算子视角统一了一系列目标，允许从数据经验估计，并通过合适选择 $\mathcal{L}$ 给出设计损失函数的一般原理.

3.4 去噪分数匹配的多噪声级（NCSN）

3.4.1 动机

给数据分布加单一固定方差的 Gaussian 噪声虽能在一定程度上平滑它，但只在一个噪声水平训练基于分数的模型会引入关键局限。在低注入噪声水平，Langevin 动力学

因低密度区域梯度消失而难以在多峰分布中穿越模式。反之，在高噪声水平，采样虽更容易，但模型只捕捉粗结构，产生缺乏细节的模糊样本。此外，Langevin 动力学在高维空间收敛缓慢甚至失败。由于它依赖对数密度梯度作引导，糟糕的初始化——尤其在平台区或鞍点附近——会阻碍探索，或使采样器困在单一模式.



ure 3.6: Illustration of SM inaccuracy (revisiting Figure 3.4). the red region indica
-density areas with potentially inaccurate score estimates due to limited sample cover
le high-density regions tend to yield more accurate estimates.

To address these challenges, Song and Ermon (2019) propose inject
ussian noise at multiple levels into the data distribution and jointly train
ıoise-conditional score network (NCSN) to estimate score functions acr
ange of noise scales. During generation, Langevin dynamics is applied
ıoise-annealed fashion: beginning with high-noise levels to enable coa
eleration, and gradually refining toward low-noise levels to recover f

图 3.16: 分数匹配不准示意（回到图 3.14）。红色区域表示低密度区域，因样本覆盖有限而可能给出不准的分数估计；高密度区域则倾向给出更准确的估计.

为应对这些挑战，Song 与 Ermon（2019）提出：向数据分布注入多个水平的 Gaussian 噪声，并联合训练一个 *噪声条件分数网络*（Noise-Conditional Score Network, NCSN），使其在一系列噪声尺度上估计分数函数。生成时，Langevin 动力学以噪声退火方式施加：从高噪声水平开始以实现粗探索，逐步细化到低噪声水平以恢复细节.

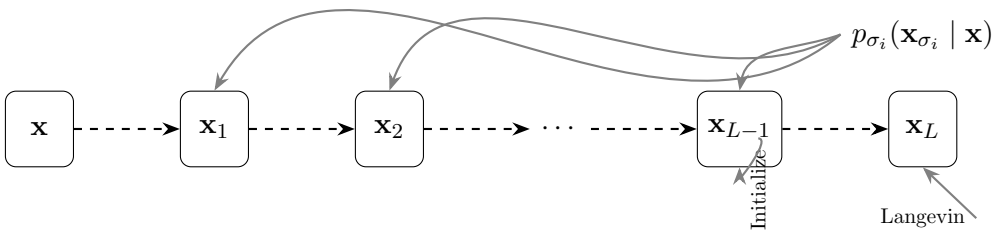


图 3.17: NCSN 示意。前向过程用多层加性 Gaussian 噪声 $p_\sigma(\mathbf{x}_\sigma \mid \mathbf{x})$ 扰动数据；生成时在每个噪声级施加 Langevin 采样，并以上一级结果初始化下一级（更低方差）的采样.

3.4.2 训练

为克服单噪声级训练基于分数模型的局限，Song 与 Ermon（2019）提出向数据分布加多个水平的 Gaussian 噪声。具体地，选取 L 个噪声水平 $\{\sigma_i\}_{i=1}^{L}$，满足

$$0 < \sigma_1 < \sigma_2 < \cdots < \sigma_L, \tag{3.3.4.93}$$

其中 σ_1 足够小以保留数据的大部分细节，σ_L 足够大以充分平滑分布，便于训练.

每个带噪样本由扰动干净数据点 $\mathbf{x} \sim p_{\text{data}}$ 构造：$\mathbf{x}_\sigma = \mathbf{x} + \sigma\,\boldsymbol{\epsilon}$，$\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$。这定义了

扰动核：

$$p_\sigma(\mathbf{x}_\sigma \mid \mathbf{x}) := \mathcal{N}(\mathbf{x}_\sigma; \mathbf{x}, \sigma^2 \mathbf{I}), \tag{3.3.4.94}$$

它诱导出

边缘分布：

$$p_\sigma(\mathbf{x}_\sigma) = \int p_\sigma(\mathbf{x}_\sigma \mid \mathbf{x})\, p_{\text{data}}(\mathbf{x})\, \mathrm{d}\mathbf{x}, \tag{3.3.4.95}$$

即在每个噪声水平 σ 下的 Gaussian 平滑数据分布.

NCSN 的训练目标. 目标是训练噪声条件分数网络 $\mathbf{s}_\phi(\mathbf{x}, \sigma)$，使其对所有 $\sigma \in \{\sigma_i\}_{i=1}^{L}$ 估计分数函数 $\nabla_{\mathbf{x}} \log p_\sigma(\mathbf{x})$。这通过最小化所有噪声级上的 DSM 目标实现：

$$\mathcal{L}_{\text{NCSN}}(\phi) := \sum_{i=1}^{L} \lambda(\sigma_i)\, \mathcal{L}_{\text{DSM}}(\phi; \sigma_i), \tag{3.3.4.96}$$

其中

$$\mathcal{L}_{\text{DSM}}(\phi; \sigma) = \frac{1}{2} \mathbb{E}_{\mathbf{x} \sim p_{\text{data}}(\mathbf{x}),\, \tilde{\mathbf{x}} \sim p_\sigma(\tilde{\mathbf{x}} \mid \mathbf{x})} \left[\left\| \mathbf{s}_\phi(\tilde{\mathbf{x}}, \sigma) - \left(\frac{\mathbf{x} - \tilde{\mathbf{x}}}{\sigma^2} \right) \right\|_2^2 \right], \tag{3.3.4.97}$$

$\lambda(\sigma_i) > 0$ 是各尺度的加权函数.

最小化该目标得到分数模型 $\mathbf{s}^*(\mathbf{x}, \sigma)$，它在每个噪声级恢复真值分数：

$$\mathbf{s}^*(\cdot, \sigma) = \nabla_{\mathbf{x}} \log p_\sigma(\cdot), \qquad \text{对所有} \sigma \in \{\sigma_i\}_{i=1}^{L}, \tag{3.3.4.98}$$

因为它本质上就是 DSM 最小化（见定理 3.3.1）.

与 DDPM 损失的关系. 设 $\mathbf{x}_\sigma = \mathbf{x} + \sigma\boldsymbol{\epsilon}$，$\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$，$p_\sigma$ 为边缘分布。由 Tweedie 公式，

$$\nabla_{\mathbf{x}_\sigma} \log p_\sigma(\mathbf{x}_\sigma) = -\frac{1}{\sigma} \mathbb{E}[\boldsymbol{\epsilon} \mid \mathbf{x}_\sigma]. \tag{3.3.4.99}$$

因此 NCSN 最优点是真值分数 $\mathbf{s}^*(\mathbf{x}_\sigma,\sigma)=\nabla_{\mathbf{x}_\sigma}\log p_\sigma(\mathbf{x}_\sigma)$，而 DDPM 损失式 (2.2.2.17) 下的 Bayes 最优噪声预测器为 $\boldsymbol{\epsilon}^*(\mathbf{x}_\sigma,\sigma)=\mathbb{E}[\boldsymbol{\epsilon}\mid\mathbf{x}_\sigma]$。二者完全等价：

$$\mathbf{s}^*(\mathbf{x}_\sigma,\sigma)=-\frac{1}{\sigma}\boldsymbol{\epsilon}^*(\mathbf{x}_\sigma,\sigma),\qquad \boldsymbol{\epsilon}^*(\mathbf{x}_\sigma,\sigma)=-\sigma\,\mathbf{s}^*(\mathbf{x}_\sigma,\sigma). \tag{3.3.4.100}$$

在 DDPM 扰动式 (2.2.2.8)（离散指标 i）$\mathbf{x}_i=\bar\alpha_i\mathbf{x}_0+\sqrt{1-\bar\alpha_i^2}$ 中，同样的关系给出

$$\mathbf{s}^*(\mathbf{x}_i,i)=-\frac{1}{\sigma_i}\mathbb{E}[\boldsymbol{\epsilon}\mid\mathbf{x}_i], \tag{3.3.4.101}$$

因此最小化 DDPM 损失学习 $\boldsymbol{\epsilon}$ 的条件去噪器，它正是噪声水平 i 处真值分数的一个缩放重参数化.

我们将在第 6 章系统比较并总结这些参数化的等价性.

3.4.3 采样

有了在多个噪声水平可用的训练好的分数网络

$$\mathbf{s}_{\phi^\times}(\cdot,\sigma_1),\ \mathbf{s}_{\phi^\times}(\cdot,\sigma_2),\ \ldots,\ \mathbf{s}_{\phi^\times}(\cdot,\sigma_{L-1}),\ \mathbf{s}_{\phi^\times}(\cdot,\sigma_L),$$

则称为 退火 Langevin 动力学（annealed Langevin dynamics）的采样过程（Song 与 Ermon, 2019）通过从高噪声水平 σ_L 渐进去噪到低噪声水平 $\sigma_1\approx 0$ 来生成数据.

从 Gaussian 噪声 $\mathbf{x}^{\sigma_L}\sim\mathcal{N}(\mathbf{0},\mathbf{I})$ 开始，算法在每个噪声级 σ_ℓ 施加 Langevin 动力学，以近似从扰动分布 $p_{\sigma_\ell}(\mathbf{x})$ 采样。σ_ℓ 级的输出用于为下一个更低噪声级 $\sigma_{\ell-1}$ 提供更好的初始化.

在每一级，Langevin 动力学迭代更新：

$$\tilde{\mathbf{x}}_{n+1}=\tilde{\mathbf{x}}_n+\eta_\ell\,\mathbf{s}_{\phi^\times}(\tilde{\mathbf{x}}_n,\sigma_\ell)+\sqrt{2\eta_\ell}\,\boldsymbol{\epsilon}_n,\qquad \boldsymbol{\epsilon}_n\sim\mathcal{N}(\mathbf{0},\mathbf{I}), \tag{3.3.4.102}$$

从 $\tilde{\mathbf{x}}_0=\mathbf{x}^{\sigma_\ell}$ 开始。步长通常按噪声尺度缩放：

$$\eta_\ell=\delta\cdot\frac{\sigma_\ell^2}{\sigma_1^2},\qquad \text{对某固定}\delta>0. \tag{3.3.4.103}$$

这种噪声退火细化一直进行到最低噪声级 σ_1，得到最终样本 $\mathbf{x}^{\sigma_1}$。通过渐进地把上一级输出作为下一级更好的初始化，这一策略能更有效地探索并改善复杂数据分布的覆盖. 算法 1 总结了该过程.

NCSN 采样速度慢. NCSN 用跨噪声尺度 $\{\sigma_i\}_{i=1}^L$ 的退火 MCMC（通常是 Langevin 动力学）生成样本。对每个尺度 σ_i，它执行 K 次形如 “用分数 $\mathbf{s}_\phi(\tilde{\mathbf{x}}_n,\sigma_i)$ 加小随机扰动更新 $\tilde{\mathbf{x}}_n$” 的迭代，每次都需要一次分数网络前向传播。两个因素决定了需要很大的 $L\times K$：

1. **局部精度与稳定性：**学到的分数只在小扰动下可靠，要求每噪声级小步长、多迭代，以避免偏差或不稳定；
2. **高维下混合慢：**局部 MCMC 移动低效地探索多峰高维目标，需要很多迭代才能到达典型数据区域.

由于更新严格串行（每次迭代依赖上一次），且每次都需要昂贵的网络评估，总代价是 $\mathcal{O}(LK)$ 次串行网络前向，使采样计算缓慢.

Algorithm 1 退火 Langevin 动力学

Require: 训练好的分数 $s_{\phi^\times}(\cdot, \sigma_\ell)$，步长 η_ℓ，各噪声级 $\ell = L, \dots, 2$ 的 Langevin 迭代预算 N_ℓ

采样 $\mathbf{x}^{\sigma_L} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$
for $\ell = L, \dots, 2$ **do**
  $\tilde{\mathbf{x}}_0 \leftarrow \mathbf{x}^{\sigma_\ell}$ ▷ 从上一噪声级输出初始化 Langevin
  for $n = 0$ to $N_\ell - 1$ **do**
    $\boldsymbol{\epsilon}_n \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$
    $\tilde{\mathbf{x}}_{n+1} \leftarrow \tilde{\mathbf{x}}_n + \eta_\ell \, \mathbf{s}_{\phi^\times}(\tilde{\mathbf{x}}_n, \sigma_\ell) + \sqrt{2\eta_\ell}\, \boldsymbol{\epsilon}_n$
  end for
  $\mathbf{x}^{\sigma_{\ell-1}} \leftarrow \tilde{\mathbf{x}}_{N_\ell}$ ▷ 输出用作下一噪声级的初始化
end for
return $\mathbf{x}^{\sigma_1}$

3.5 小结：NCSN 与 DDPM 的比较视角

比较. 我们先比较图 3.17 中 NCSN 与 DDPM 的图模型，关键异同总结于表 2.

表 2: NCSN 与 DDPM 比较

	NCSN	**DDPM**
$\mathbf{x}_{i+1} \mid \mathbf{x}_i$	推导为 $\mathbf{x}_{i+1} = \mathbf{x}_i + \sqrt{\sigma_{i+1}^2 - \sigma_i^2}\, \boldsymbol{\epsilon}$	定义为 $\mathbf{x}_{i+1} = \sqrt{1-\bar{\beta}_i}\, \mathbf{x}_i + \sqrt{\bar{\beta}_i}\, \boldsymbol{\epsilon}$
$\mathbf{x}_i \mid \mathbf{x}$	定义为 $\mathbf{x}_i = \mathbf{x} + \sigma_i^2\, \boldsymbol{\epsilon}$	推导为 $\mathbf{x}_i = \bar{\alpha}_i \mathbf{x} + \sqrt{1-\bar{\alpha}_i^2}\, \boldsymbol{\epsilon}$
p_{prior}	$\mathcal{N}(\mathbf{0}, \sigma_L^2 \mathbf{I})$	$\mathcal{N}(\mathbf{0}, \mathbf{I})$
Loss	$\mathbb{E}_i \mathbb{E}_{p_{\text{data}}(\mathbf{x})} \mathbb{E}_{\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})} \left[\left\| \mathbf{s}_\phi(\mathbf{x}_i, \sigma_i) + \frac{\boldsymbol{\epsilon}}{\sigma_i} \right\|^2 \right]$	$\mathbb{E}_i \mathbb{E}_{p_{\text{data}}(\mathbf{x})} \mathbb{E}_{\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})} \left[\left\| \boldsymbol{\epsilon}_\phi(\mathbf{x}_i, i) - \boldsymbol{\epsilon} \right\|^2 \right]$
Sampling	每层施加 Langevin；用输出初始化下一层	沿 Markov 链以 $p_{\phi^\times}(\mathbf{x}_{i-1} \mid \mathbf{x}_i)$ 遍历

共享瓶颈. 尽管表述不同，NCSN 与 DDPM 都依赖稠密时间离散化。这导致一个关键局限：采样常常需要成百上千次迭代，使生成缓慢且计算密集.

问题 3.5.1 (问题 3.5.1)**：** 我们如何加速扩散模型的采样?

我们将在第 9 章与第 10 章回到这一挑战.

3.6 结语

本章勾勒了通往扩散模型的第二条主要路径，它源于基于能量模型（EBM）的基于分数视角。我们从识别 EBM 的核心困难——不可处理的配分函数——出发，并引入分数函数 $\nabla_{\mathbf{x}} \log p(\mathbf{x})$ 作为绕开这一困难的有力工具.

我们的旅程从经典分数匹配走到其更可扩展、更鲁棒的变体——去噪分数匹配（DSM）。通过 DSM，我们看到用噪声扰动数据如何使训练目标变得可处理，再次利

用条件化策略构造简单的回归目标。进一步，我们通过 Tweedie 公式建立了分数估计与去噪行为之间的深刻联系：分数给出从带噪观测估计干净信号所需的精确方向.

这一原理随后从单一噪声级推广到连续统，得到噪声条件分数网络（NCSN）：它学习一个以多个噪声尺度为条件的单一分数模型，并通过退火 Langevin 动力学生成样本。到探索结束时，我们发现 NCSN 与变分视角的 DDPM 尽管起源不同，却结构惊人相似，并共享同一瓶颈：缓慢的串行采样.

这种汇合绝非巧合；它暗示更深层的统一数学结构。这些离散时间模型的局限促使我们寻求更一般的框架。下一章我们将迈出关键一步：

1. 我们将进入连续时间视角，表明 DDPM 与 NCSN 都可以被优雅地统一为同一个由随机微分方程（SDE）描述的强大过程的不同离散化；

2. 这一 Score SDE 框架将形式上连接变分视角与基于分数视角，把生成问题重述为求解微分方程的问题.

这一统一视角不仅将提供深刻的理论清晰性，还将解锁一类新的先进数值方法，以应对采样缓慢这一根本挑战.

Chapter 4

今日扩散模型：Score SDE 框架

There is only one precise way of presenting the laws, and that is by means of differential equations. They have the advantage of being fundamental and, so far as we know, precise. — *Richard P. Feynman*

到目前为止，我们从两个视角研究了扩散模型：变分视角与基于分数的视角，后者自然地从 EBM 表述中涌现。现在我们迈出下一步，进入 连续时间框架（continuous-time framework）。其核心是 Score SDE（Score SDE），即把 DDPM 与 NCSN 统一为单一表述的连续极限。这一视角之所以有力，是因为它用一个干净、有原则的、扎根于微分方程（DE）的描述来扩展离散更新。在这一视角下，生成归结为在时间上求解一个 DE。这使我们能直接应用数值分析工具：例如，基本 Euler 法可模拟动力学，更先进的求解器提升稳定性与效率。在连续时间下工作，我们还获得更丰富的数学结构与统一的基础，用于理解、分析和改进扩散模型。本专著将进一步发展这一视角.

4.1 Score SDE：其原理

多噪声尺度的使用是 NCSN 与 DDPM 框架成功的关键要素。本节介绍 Score SDE（Song 等, 2020c）的基础，它通过考虑连续的噪声层级把这一思想提升。前向与反向扩散过程的连续时间极限早已被 Sohl-Dickstein 等（2015）注意到，但 Song 等（2020c）通过把数据演化表述为随机/常微分方程（其中噪声水平随时间平滑增大）使这一视角成为核心。这一连续时间表述不仅统一了先前的离散时间模型，还通过把生成建模作为求解微分方程的问题，为其提供了有原则且灵活的基础.

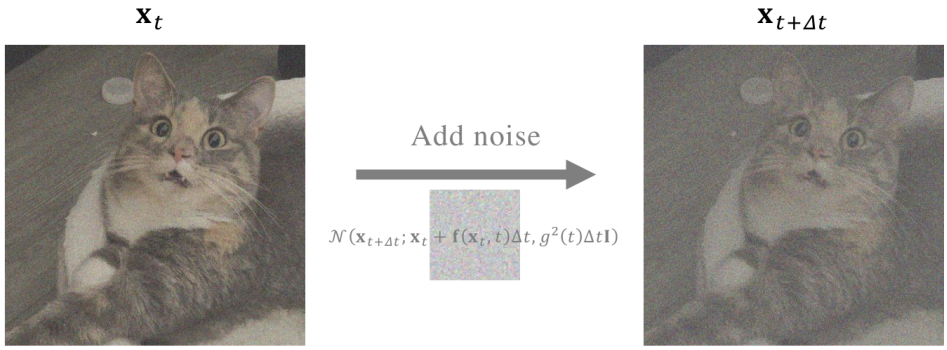
4.1.1 动机：从离散过程到连续时间过程

我们回顾 NCSN 与 DDPM 的前向加噪方案。NCSN 使用递增噪声级序列 $\{\sigma_i\}_{i=1}^{L}$。每个干净样本 $\mathbf{x} \sim p_{\text{data}}$ 被扰动为

$$\mathbf{x}_{\sigma_i} = \mathbf{x} + \sigma_i \boldsymbol{\epsilon}_i, \qquad \boldsymbol{\epsilon}_i \sim \mathcal{N}(\mathbf{0}, \mathbf{I}). \tag{4.4.1.104}$$

DDPM 则按方差调度 $\{\beta_i\}_{i=1}^{L}$ 增量加噪：

$$\mathbf{x}_i = \sqrt{1-\beta_i^2}\,\mathbf{x}_{i-1} + \beta_i \boldsymbol{\epsilon}_i, \qquad \boldsymbol{\epsilon}_i \sim \mathcal{N}(\mathbf{0}, \mathbf{I}). \tag{4.4.1.105}$$



ure 4.1: Illustration of the discrete-time noise-adding step. It adds noise from t to $t+\Delta t$ h mean drift $\mathbf{f}(\mathbf{x}_t, t)$ and diffusion coefficient $g(t)$.

图 4.18: 离散时间加噪步示意。它从 t 到 $t+\Delta t$ 加噪，均值漂移为 $\mathbf{f}(\mathbf{x}_t, t)$，扩散系数为 $g(t)$.

我们在离散时间网格上统一看待它们，从 $\mathbf{x}_t$ 到 $\mathbf{x}_{t+\Delta t}$ 的顺序更新形式为[9]：

$$\begin{aligned}
\text{NCSN:} \quad & \mathbf{x}_{t+\Delta t} = \mathbf{x}_t + \sqrt{\sigma_{t+\Delta t}^2 - \sigma_t^2}\,\boldsymbol{\epsilon}_t \approx \mathbf{x}_t + \sqrt{\frac{\mathrm{d}\sigma_t^2}{\mathrm{d}t}\Delta t}\,\boldsymbol{\epsilon}_t, \\
\text{DDPM:} \quad & \mathbf{x}_{t+\Delta t} = \sqrt{1-\beta_t}\,\mathbf{x}_t + \sqrt{\beta_t}\,\boldsymbol{\epsilon}_t \approx \mathbf{x}_t - \tfrac{1}{2}\beta_t\mathbf{x}_t\Delta t + \sqrt{\beta_t \Delta t}\,\boldsymbol{\epsilon}_t,
\end{aligned}$$

其中 $\boldsymbol{\epsilon}_t \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$。有趣的是，两个加噪过程遵循共同的结构模式：

$$\mathbf{x}_{t+\Delta t} \approx \mathbf{x}_t + \mathbf{f}(\mathbf{x}_t, t)\Delta t + g(t)\sqrt{\Delta t}\,\boldsymbol{\epsilon}_t, \tag{4.4.1.106}$$

其中 $\mathbf{f} : \mathbb{R}^D \times \mathbb{R} \to \mathbb{R}^D$、$g : \mathbb{R} \to \mathbb{R}$ 由下式给出：

$$\begin{aligned}
\text{NCSN:} \quad & \mathbf{f}(\mathbf{x}, t) = \mathbf{0}, \qquad & g(t) = \sqrt{\frac{\mathrm{d}\sigma^2(t)}{\mathrm{d}t}}, \\
\text{DDPM:} \quad & \mathbf{f}(\mathbf{x}, t) = -\tfrac{1}{2}\beta(t)\mathbf{x}, \qquad & g(t) = \sqrt{\beta(t)}.
\end{aligned}$$

该表述对应如下 Gaussian 转移[10]：

$$p(\mathbf{x}_{t+\Delta t} \mid \mathbf{x}_t) := \mathcal{N}\big(\mathbf{x}_{t+\Delta t}; \mathbf{x}_t + \mathbf{f}(\mathbf{x}_t, t)\Delta t,\, g^2(t)\Delta t\,\mathbf{I}\big), \tag{4.4.1.107}$$

其中按记号的轻微滥用，我们把 $\mathbf{x}_t$ 视为固定样本、$\mathbf{x}_{t+\Delta t}$ 视为随机变量.

当 $\Delta t \to 0$（概念上可理解为准备无限多层噪声），离散时间过程收敛到一个沿时间前向演化的连续时间 SDE：

$$\mathrm{d}\mathbf{x}(t) = \mathbf{f}(\mathbf{x}(t), t)\,\mathrm{d}t + g(t)\,\mathrm{d}\mathbf{w}(t), \tag{4.4.1.108}$$

其中 $\mathbf{w}(t)$ 是标准 Wiener 过程（Brown 运动）.

[9]为方便起见，我们交替使用 $\mathbf{x}(t)$ 与 $\mathbf{x}_t$（对其他时变变量类似）表示时刻 t 的样本。

[10]式 (4.4.1.107) 的前向核在 $\Delta t \to 0$ 时收敛到相应 Itô SDE 的解。严格证明依赖高级结果，我们留待文献。

注 4.1.1 (Wiener 过程)**：** 这里不必给出完整形式定义：Wiener 过程是一个连续时间随机过程 $\mathbf{w}(t)$，它从零开始，具有独立增量，且对任意 $s < t$，增量 $\mathbf{w}(t) - \mathbf{w}(s)$ 服从均值为零、方差为 $t - s$ 的正态分布。它表示随时间累积的独立 Gaussian 涨落，虽几乎处处连续，却处处不可微。在无穷小时间区间 $[t, t + \mathrm{d}t]$ 上，Wiener 过程的增量定义为

$$\mathrm{d}\mathbf{w}(t) := \mathbf{w}(t + \mathrm{d}t) - \mathbf{w}(t), \tag{4.4.1.109}$$

它被建模为零均值、方差 $\mathrm{d}t$ 的 Gaussian 随机变量：

$$\mathrm{d}\mathbf{w}(t) \sim \mathcal{N}(\mathbf{0}, \mathrm{d}t\, \mathbf{I}). \tag{4.4.1.110}$$

SDE 基础的简要介绍见附录 A.2，更深入讨论见附录 C。我们可概念性地把离散与连续表述的联系理解为：

- $\mathbf{x}(t + \Delta t) - \mathbf{x}(t) \approx \mathrm{d}\mathbf{x}(t)$；
- $\Delta t \approx \mathrm{d}t$；
- $\sqrt{\Delta t}\, \boldsymbol{\epsilon}_t \sim \mathcal{N}(\mathbf{0}, \Delta t\, \mathbf{I}) \approx \mathrm{d}\mathbf{w}(t)$.

◇

一旦指定漂移 $\mathbf{f}(\mathbf{x}, t)$ 与扩散系数 $g(t)$，前向时间 SDE 自动诱导出一个反向时间 SDE，把末端噪声分布运回数据分布。反向动力学只涉及一个未知项，而且出人意料地就是每个连续时间水平上的 分数函数（score function）。这把分数识别为训练目标：一旦学到分数，采样就归结为用学到的分数数值积分反向时间 SDE.

第 4.2 节给出实际实现，我们先在第 4.1.2 与 4.1.3 节考察前向与反向过程的理论基础.

4.1.2 前向时间 SDE：从数据到噪声

有了这一表述，先前基于离散时间的方法（如 NCSN，Song 与 Ermon, 2019；DDPM，Sohl-Dickstein 等, 2015；Ho 等, 2020）都可在连续时间框架下统一，通过在区间 $[0, T]$ 上由前向 SDE 控制的随机过程 $\mathbf{x}(t)$：

$$\mathrm{d}\mathbf{x}(t) = \mathbf{f}(\mathbf{x}(t), t)\, \mathrm{d}t + g(t)\, \mathrm{d}\mathbf{w}(t), \qquad \mathbf{x}(0) \sim p_{\mathrm{data}}. \tag{4.4.1.111}$$

这里 $\mathbf{f}(\cdot, t) : \mathbb{R}^D \to \mathbb{R}^D$ 是漂移，$g(t) \in \mathbb{R}$ 是标量扩散系数，$\mathbf{w}(t)$ 为标准 Wiener 过程。我们称之为 前向 SDE（forward SDE），它描述干净数据如何随时间被逐渐扰动为噪声.

一旦指定漂移 $\mathbf{f}$ 与扩散系数 g，前向过程便完全确定，描述数据变量如何通过注入 Gaussian 噪声被逐步污染。特别地，它诱导出两族时变密度：

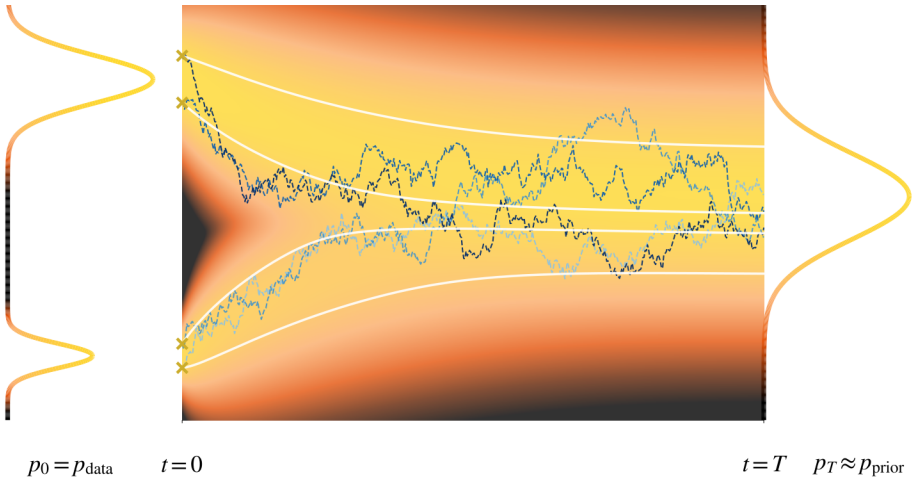


Figure 4.2: (1D) Visualization of the forward process in a diffusion model. The process starts from initial points sampled (denoted as "×") from a complex bimodal data distribution ($p_0 = p_{\text{data}}$) and evolves toward a simple, unimodal Gaussian prior ($p_T \approx p_{\text{prior}}$). The

图 4.19: （1D）扩散模型前向过程可视化。过程从复杂双峰数据分布（$p_0 = p_{\text{data}}$）采样的初始点（记为 ×）出发，演化为简单单峰 Gaussian 先验（$p_T \approx p_{\text{prior}}$）。背景热图展示随时间平滑的边缘概率密度 p_t。样本轨迹（蓝色路径）由随机前向 SDE 过程给出；白色路径为其确定性对应 PF-ODE。注意 PF-ODE 是密度的确定性传输映射，一般不是从单点出发的样本路径均值.

扰动核. 条件律 $p_t(\mathbf{x}_t \mid \mathbf{x}_0)$ 描述干净数据样本 $\mathbf{x}_0 \sim p_{\text{data}}$ 如何在时刻 t 演化为其带噪对应 $\mathbf{x}_t$。一般地，式 (4.4.1.111) 中的漂移项 $\mathbf{f}(\mathbf{x}, t)$ 可以是 $\mathbf{x}$ 的任意函数，但一个常见且解析方便的选择是假设它是仿射的：

$$\mathbf{f}(\mathbf{x}, t) = f(t)\mathbf{x}, \tag{4.4.1.112}$$

其中 $f(t)$ 是 t 的标量函数，通常取非正。在这种结构下，过程在每个时刻都保持 Gaussian，条件分布有闭式解，通过求解相应均值–方差 ODE 得到（Särkkä 与 Solin, 2019；亦见第 4.3.3 节）。特别地，

$$p_t(\mathbf{x}_t \mid \mathbf{x}_0) = \mathcal{N}\big(\mathbf{x}_t; \mathbf{m}(t), P(t)\mathbf{I}_D\big), \tag{4.4.1.113}$$

其中

$$\mathbf{m}(t) = \exp\Big(\int_0^t f(u)\,\mathrm{d}u\Big)\mathbf{x}_0, \qquad P(t) = \int_0^t \exp\Big(2\int_s^t f(u)\,\mathrm{d}u\Big) g^2(s)\,\mathrm{d}s, \tag{4.4.1.114}$$

初始条件 $\mathbf{m}(0) = \mathbf{x}_0$、$P(0) = 0$.

这一闭式形式使我们能给定 $\mathbf{x}_0$ 直接采样 $\mathbf{x}_t$，而无需数值积分 SDE，因此称为 免模拟（simulation-free）。NCSN 与 DDPM 都属于这种仿射漂移设定.

下文我们针对任意漂移 $\mathbf{f}(\mathbf{x}, t)$ 发展一般理论，但在需要闭式分析时再回到仿射漂移.

边缘密度. 时间边缘密度 $p_t(\mathbf{x}_t)$ 通过在扰动核上积分得到：

$$p_t(\mathbf{x}_t) := \int p_t(\mathbf{x}_t \mid \mathbf{x}_0)\, p_{\text{data}}(\mathbf{x}_0)\, \mathrm{d}\mathbf{x}_0, \qquad p_0 = p_{\text{data}}. \tag{4.4.1.115}$$

通过合适选择系数 $f(t)$ 与 $g(t)$，前向过程逐渐加噪，直到初始状态的影响被有效遗忘。当 T 很大时，条件分布 $p_T(\mathbf{x}_T \mid \mathbf{x}_0)$ 不再依赖 $\mathbf{x}_0$，因为其均值演化为

$$\mathbf{m}(T) = \exp\Big(\int_0^T f(u)\, \mathrm{d}u\Big)\mathbf{x}_0 \longrightarrow \mathbf{0}, \qquad \text{当} T \to \infty, \tag{4.4.1.116}$$

只要 $f(u)$ 非正使指数因子衰减。同时方差增长并稳定到选定的先验分布。于是边缘

$$p_T(\mathbf{x}_T) = \int p_T(\mathbf{x}_T \mid \mathbf{x}_0)\, p_{\text{data}}(\mathbf{x}_0)\, \mathrm{d}\mathbf{x}_0 \tag{4.4.1.117}$$

起初是数据样本上的复杂混合，收敛到简单先验 p_{prior}（通常是 Gaussian）。在这一极限下，

$$p_T(\mathbf{x}_T) \approx p_{\text{prior}}(\mathbf{x}_T), \qquad p_T(\mathbf{x}_T \mid \mathbf{x}_0) \approx p_{\text{prior}}(\mathbf{x}_T), \tag{4.4.1.118}$$

因此前向过程把任意数据分布映射为可处理的先验，为反向与生成提供了便利起点.

4.1.3 用于生成的反向时间随机过程

4.1.3 Reverse-Time Stochastic Process for Generation

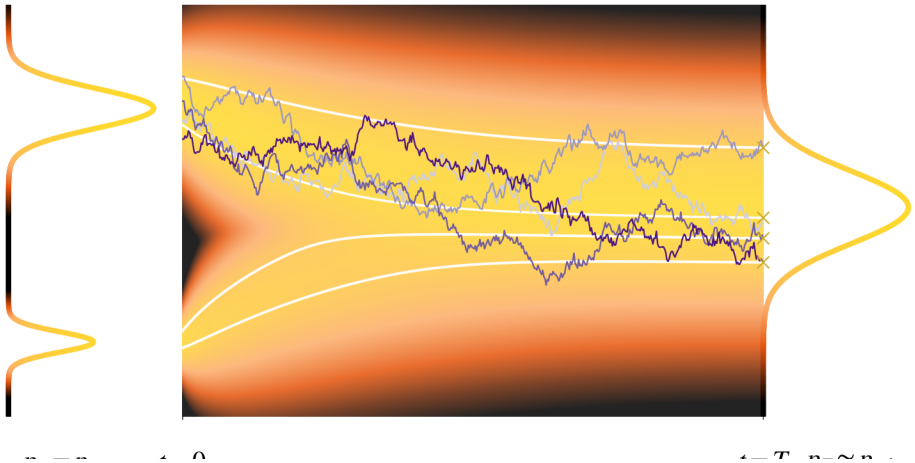


图 4.20: 用于数据生成的反向时间随机过程可视化。它从 $t = T$ 时刻由简单先验分布（p_{prior}）采样的样本（记为 ×）出发，用反向 SDE 在时间上向后演化。所得轨迹终止于 $t = 0$，集体构成目标双峰数据分布（$p_0 = p_{\text{data}}$）。背景热图展示概率密度如何从简单 Gaussian 逐渐转化为复杂目标分布.

直观上，从噪声生成数据可通过 “反转” 前向过程实现：从先验分布采样的随机点出发，在时间上向后演化得到生成样本。对确定性系统（即 ODE），这一思想自然成立：

不涉及随机性，反转时间只是沿前向过程同一路径反向追踪轨迹[11]。相反，SDE 在每一步都纳入随机性，单点可沿多条合理随机轨迹演化。因此反转这类过程更为微妙[12]。

尽管单个随机轨迹不可逆，但值得注意的是，这些轨迹上的分布可以反转。这一点由 Anderson（1982）的基础结果形式化：式 (4.4.1.111) 前向过程的时间反转过程 $\{\bar{\mathbf{x}}(t)\}_{t\in[0,T]}$[13]本身由一个良定义的 SDE 控制。该反向时间过程从 T 演化到 0，其动力学为：

$$\begin{aligned} \mathrm{d}\bar{\mathbf{x}}(t) &= \big[\mathbf{f}(\bar{\mathbf{x}}(t),t) - g^2(t)\nabla_{\mathbf{x}}\log p_t(\bar{\mathbf{x}}(t))\big]\mathrm{d}t + g(t)\,\mathrm{d}\bar{\mathbf{w}}(t), \\ \bar{\mathbf{x}}(T) &\sim p_{\text{prior}} \approx p_T. \end{aligned} \tag{4.4.1.119}$$

这里 $\bar{\mathbf{w}}(t)$ 是反向时间的标准 Wiener 过程，定义为 $\bar{\mathbf{w}}(t) := \mathbf{w}(T-t) - \mathbf{w}(T)$.

为建立对式 (4.4.1.119) 的直观，我们在第 4.1.6 节给出一个 Gaussian 数据分布加线性–Gaussian 动力学的具体例子。这一设定解析上可处理：只用基本微积分与线性代数就能推导时间反转公式，而不必调用 Anderson（1982）的完整一般理论.

注意，随机性的存在（$g \neq 0$）引入了额外校正项 $-g^2(t)\nabla_{\mathbf{x}}\log p_t(\bar{\mathbf{x}}(t))$，它解释扩散效应，并确保反向动力学正确复现前向 SDE 所诱导的边缘分布演化（见第 4.1.5 节）.

概念上，反向过程为什么有效？ 第 4.5.2 节通过把反向时间 SDE 连接到 DDPM 变分框架，给出它的直观推导（可选但富有启发性）。这里我们补充反向动力学如何从噪声恢复结构化数据的直观.

乍看之下，反向时间过程中出现 Brown 噪声似乎自相矛盾。若前向扩散把数据散布为越来越嘈杂的构型，不清楚反转这一过程——尤其那个通过 $\bar{\mathbf{w}}(t)$ 引入额外随机性的过程——如何能产生集中在数据流形附近的干净结构化样本。关键在于，反向时间 SDE 并不注入任意随机性。扩散项 $g(t)\mathrm{d}\bar{\mathbf{w}}(t)$ 总是与分数驱动漂移 $-g^2(t)\nabla_{\mathbf{x}}\log p_t(\bar{\mathbf{x}}(t))$ 耦合在一起。二者相互平衡：分数把轨迹引向高密度区域，而噪声引入受控的随机性，允许探索而不淹没动力学.

为更清楚地看到这一点，回到式 (3.3.1.36) 的 Langevin 直觉。当 $f(t)\equiv 0$，式 (4.4.1.119) 写为

$$\mathrm{d}\bar{\mathbf{x}}(t) = -g^2(t)\nabla_{\mathbf{x}}\log p_t(\bar{\mathbf{x}}(t))\,\mathrm{d}t + g(t)\,\mathrm{d}\bar{\mathbf{w}}(t). \tag{4.4.1.120}$$

把时间前向重参数化为 $s := T - t$（故 $\mathrm{d}t = -\mathrm{d}s$），并在律中重命名 Brown 运动使 $\mathrm{d}\bar{\mathbf{w}}(t) = -\mathrm{d}\mathbf{w}_s$。令 $\bar{\mathbf{x}}_s := \bar{\mathbf{x}}(T-s)$、$\pi_s := p_{T-s}$，则

$$\begin{aligned} \mathrm{d}\bar{\mathbf{x}}_s &= g^2(T-s)\nabla\log\pi_s(\bar{\mathbf{x}}_s)\,\mathrm{d}s + g(T-s)\,\mathrm{d}\mathbf{w}_s \\ &= 2\tau(s)\nabla\log\pi_s(\bar{\mathbf{x}}_s)\,\mathrm{d}s + \sqrt{2\tau(s)}\,\mathrm{d}\mathbf{w}_s, \qquad \tau(s) := \tfrac{1}{2}g^2(T-s). \end{aligned} \tag{4.4.1.121}$$

这具有时变温度 $\tau(s)$ 的 Langevin 形式，目标是演化密度 π_s。由 Tweedie 公式（式 (3.3.3.64)），分数方向 $\nabla\log\pi_s$ 指向每个时间切片上的条件干净信号，因此漂移不断“拉回”去噪结构.

[11]技术上，这对应于用时间翻转替换 $t \leftrightarrow T-t$ 求解 ODE。

[12]朴素地翻转时间得不到正确的反向过程。

[13]我们用 “bar” 记号区分反向过程 $\{\bar{\mathbf{x}}(t)\}_{t\in[0,T]}$ 与前向过程 $\{\mathbf{x}(t)\}_{t\in[0,T]}$，后者由前向时间 SDE 定义。

关键在于，$g(t)$ 在反向轨迹上是 退火（annealing）。早期（$s \approx 0$，即 $t \approx T$）$g(T-s)$ 通常较大，注入噪声更强，过程广泛探索。随 s 增大，$g(T-s)$ 减小，随机项减弱，分数项主导，把样本拉入 π_s 的高密度区域；到 $s = T$（即 $t = 0$），轨迹集中在数据流形附近.

反向时间 SDE 能力概览. 时变分数函数

$$\mathbf{s}(\mathbf{x}, t) := \nabla_{\mathbf{x}} \log p_t(\mathbf{x}) \tag{4.4.1.122}$$

自然出现在式 (4.4.1.119) 中。一旦指定前向系数 $f(t)$ 与 $g(t)$，分数就是反向动力学中唯一剩余未知项。这凸显其核心作用：有了分数，反向过程即被确定，采样归结为用学到的分数数值积分式 (4.4.1.119).

由于 oracle 分数一般没有闭式表达，我们采用第 3 章的方法：训练神经网络 $\mathbf{s}_\phi(\mathbf{x}, t)$ 通过分数匹配逼近它（细节见第 4.2 节）。把式 (4.4.1.119) 中的 $\mathbf{s}(\mathbf{x}, t)$ 替换为 $\mathbf{s}_\phi(\mathbf{x}, t)$ 便完全指定了反向动力学.

生成对应于从 $t = T$ 反向求解反向时间 SDE，初值 $\mathbf{x}_T \sim p_{\text{prior}}$，到 $t = 0$。重要的是，Anderson（1982）证明前向与反向过程的边缘密度重合，保证当 $p_{\text{prior}} \approx p_T$ 时，$t = 0$ 处的样本近似服从 p_{data}。我们将在第 4.2 节进一步探讨.

4.1.4 用于生成的确定性过程（概率流 ODE）

虽然式 (4.4.1.119) 的 SDE 引入随机性并可能增加生成样本多样性，但一个问题浮现：

问题 4.1.1 (问题 4.1.1)**：** 是否有必要用式 (4.4.1.119) 的 SDE 来采样?

受 Maoutsa 等（2020）启发，Song 等（2020c）还引入了一个确定性过程——一个 ODE——它演化出与前向 SDE 相同的边缘分布。该过程 $\{\tilde{\mathbf{x}}(t)\}_{t\in[0,T]}$[14]称为 概率流 ODE（Probability Flow ODE, PF-ODE），由下式给出：

$$\frac{\mathrm{d}}{\mathrm{d}t}\tilde{\mathbf{x}}(t) = \mathbf{f}(\tilde{\mathbf{x}}(t), t) - \tfrac{1}{2} g^2(t) \nabla_{\mathbf{x}} \log p_t(\tilde{\mathbf{x}}(t)). \tag{4.4.1.123}$$

与 SDE 情形类似，可以用学到的逼近替换真值分数，并从 $t = T$ 到 $t = 0$ 积分反向时间 ODE 以生成样本。具体地，生成样本（$t = 0$ 时 PF-ODE 的解）形式为

$$\tilde{\mathbf{x}}(T) + \int_T^0 \Big[\mathbf{f}(\tilde{\mathbf{x}}(\tau), \tau) - \tfrac{1}{2} g^2(\tau) \nabla_{\mathbf{x}} \log p_\tau(\tilde{\mathbf{x}}(\tau))\Big] \mathrm{d}\tau, \tag{4.4.1.124}$$

其中初值 $\tilde{\mathbf{x}}(T) \sim p_{\text{prior}}$。由于该积分无闭式，实际生成依赖数值求解器（例如 Euler 法，见式 (4.4.2.174)）.

与反向时间 SDE 相比，PF-ODE 有两个关键优势：

- ODE 可在任一方向积分，从 $t = 0$ 到 $t = T$ 或从 $t = T$ 到 $t = 0$，只要在选定端点指定相应初值即可。这种双向性与 SDE 形成对比，SDE 一般只允许前向时间积分；

[14]我们用 tilde 区分与前向/反向时间 SDE 相关的过程。后文为简洁省略这一记号区分。

- 它受益于为 ODE 开发的广泛成熟、开箱即用的数值求解器.

我们强调：PF-ODE 不是简单地去掉式 (4.4.1.119) 中的扩散项得到的；值得注意的是，其漂移项中的因子 $\frac{1}{2}$ 有原则性来源。高层地，式 (4.4.1.123) 通过选择 ODE 的漂移使其演化保持与式 (4.4.1.111) 前向 SDE 相同的边缘密度而得到。保证这种边缘对齐的底层原理（即 Fokker–Planck 方程，Øksendal, 2003）将在下一节详细展开.

4.1.5 前向/反向时间 SDE 与 PF-ODE 中匹配边缘分布

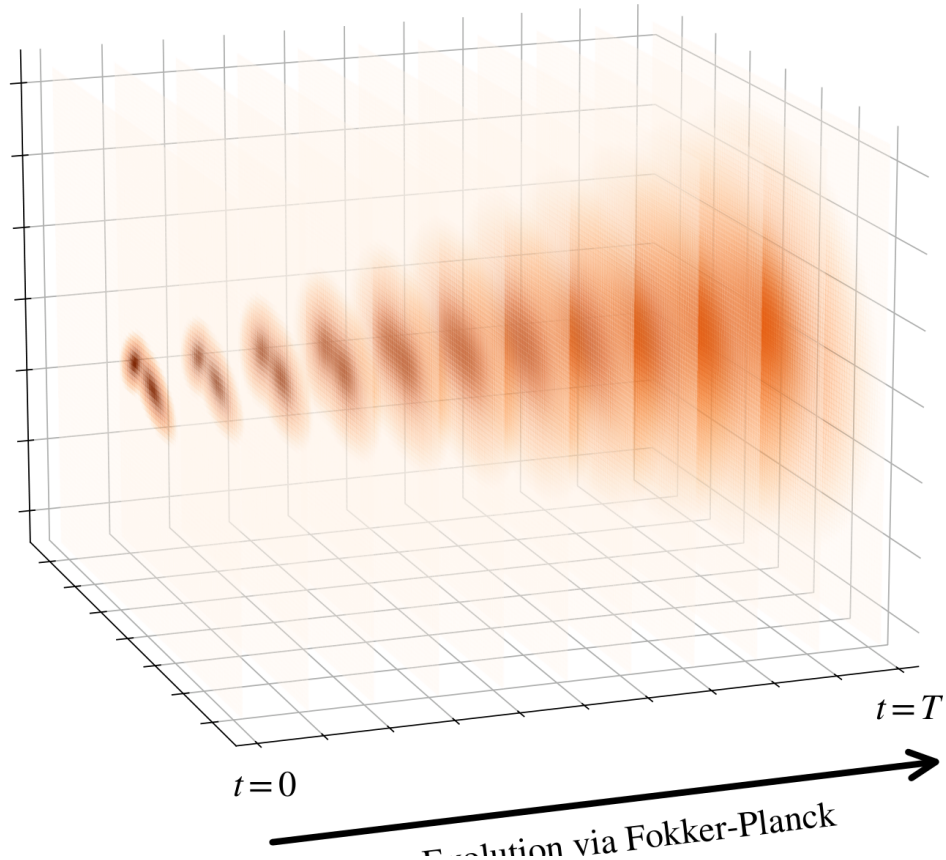


图 4.21: （2D）边缘密度 p_t 的时间演化。前向 SDE 取 $\mathbf{f} \equiv \mathbf{0}$、$g(t) = \sqrt{2t}$，区间 $[0, T]$。它从 $p_0 = p_{\text{data}}$（双峰 Gaussian 混合）出发，终止于 $p_T \approx p_{\text{prior}} := \mathcal{N}(\mathbf{0}, T^2\mathbf{I})$。$p_t$ 的时空演化遵循 Fokker–Planck 方程.

Fokker–Planck 方程保证边缘密度对齐. 扩散模型中的一个核心概念是：不同过程可以导出相同的边缘分布序列（本节稍后说明）。目标是构造一个过程，通过在时间上对

齐边缘（尤其在 $t=0$），把 p_{prior} 转化为 p_{data}。只要该过程可处理且允许高效采样，过程的精确形式是次要的。这自然引出一个基本问题：

问题 4.1.2 (问题 4.1.2)**：** 我们如何确保不同过程产生相同的边缘分布?

回到我们的设定：一旦指定前向 SDE，它便定义了从 p_{data} 到 p_{prior} 的边缘密度演化。反向时间 SDE 与 PF-ODE 随后被构造为使其轨迹产生的边缘分布与前向过程精确匹配。这一对应的关键在于 Fokker–Planck 方程，它支配扩散过程中边缘密度如何演化。以下定理（Anderson, 1982；Song 等, 2020c）建立了这一联系的基础：

定理 4.1.1 (Fokker–Planck 方程保证边缘对齐)**：** 设 $\{\mathbf{x}(t)\}_{t\in[0,T]}$ 按前向 SDE 演化

$$\mathrm{d}\mathbf{x}(t) = \mathbf{f}(\mathbf{x}(t),t)\,\mathrm{d}t + g(t)\,\mathrm{d}\mathbf{w}(t), \tag{4.4.1.125}$$

初值 $\mathbf{x}(0)\sim p_0 = p_{\text{data}}$。则其边缘密度 p_t 满足 Fokker–Planck 方程

$$\begin{aligned}\partial_t p_t(\mathbf{x}) &= -\nabla_{\mathbf{x}}\cdot[\mathbf{f}(\mathbf{x},t)p_t(\mathbf{x})] + \tfrac{1}{2}g^2(t)\Delta_{\mathbf{x}}p_t(\mathbf{x}) \\ &= -\nabla_{\mathbf{x}}\cdot[\tilde{\mathbf{f}}(\mathbf{x},t)p_t(\mathbf{x})],\end{aligned} \tag{4.4.1.126}$$

其中 $\Delta_{\mathbf{x}}$ 是 Laplace 算子，且

$$\mathbf{v}(\mathbf{x},t) = \mathbf{f}(\mathbf{x},t) - \tfrac{1}{2}g^2(t)\nabla_{\mathbf{x}}\log p_t(\mathbf{x}). \tag{4.4.1.127}$$

则 PF-ODE 与反向时间 SDE 都产生同一族 $\{p_t\}_{t\in[0,T]}$，后者沿反向时间演化：

1. **PF-ODE** $\{\tilde{\mathbf{x}}(t)\}_{t\in[0,T]}$：

$$\frac{\mathrm{d}\tilde{\mathbf{x}}(t)}{\mathrm{d}t} = \mathbf{v}(\tilde{\mathbf{x}}(t),t), \tag{4.4.1.128}$$

若从 $\tilde{\mathbf{x}}(0)\sim p_0$ 出发沿 t 前向运行；等价地，若从 $\tilde{\mathbf{x}}(T)\sim p_T$ 出发沿 t 反向运行，则其边缘为 $\tilde{\mathbf{x}}(t)\sim p_t$，对所有 $t\in[0,T]$.

2. **反向时间 SDE** $\{\bar{\mathbf{x}}(t)\}_{t\in[0,T]}$：

$$\mathrm{d}\bar{\mathbf{x}}(t) = [\mathbf{f}(\bar{\mathbf{x}}(t),t) - g^2(t)\nabla_{\mathbf{x}}\log p_t(\bar{\mathbf{x}}(t))]\mathrm{d}t + g(t)\,\mathrm{d}\bar{\mathbf{w}}(t), \tag{4.4.1.129}$$

其中 $\bar{\mathbf{x}}(0)\sim p_T$，$\bar{\mathbf{w}}(t)$ 是反向时间标准 Wiener 过程，其边缘为 $\bar{\mathbf{x}}(t)\sim p_{T-t}$.

定理证明： 证明见附录 D.2.5；第 4.5.2 节用概率边缘化技术给出 Fokker–Planck 方程的进一步直观. □

固定边缘的多个条件分布. 要理解 PF-ODE 如何在时间上向前传输 p_{data}（或等价地反向传输 p_{prior}），考虑 流映射 (flow map) $\Psi_{s\to t}:\mathbb{R}^D\to\mathbb{R}^D$，其中 $\Psi_{s\to t}(\mathbf{x}_s)$ 表示 PF-ODE 在时刻 s 由 $\mathbf{x}_s$ 初始化、在时刻 t 的解，对任意 $s,t\in[0,T]$。换言之，该映射取初态 $\mathbf{x}_s$ 并直接跳到其 t 时刻的状态：

$$\Psi_{s\to t}(\mathbf{x}_s) := \mathbf{x}_s + \int_s^t \mathbf{v}(\mathbf{x}_\tau,\tau)\,\mathrm{d}\tau, \tag{4.4.1.130}$$

其中速度场

$$\mathbf{v}(\mathbf{x},\tau) := \mathbf{f}(\mathbf{x},\tau) - \tfrac{1}{2}g^2(\tau)\nabla_{\mathbf{x}} \log p_\tau(\mathbf{x}). \tag{4.4.1.131}$$

这里积分捕获沿 PF-ODE 轨迹 $\mathbf{x}_\tau$ 累积的净位移。在对 $\mathbf{v}$ 的 mild 光滑性假设下，流映射 $\Psi_{s\to t} : \mathbb{R}^D \to \mathbb{R}^D$ 是光滑双射[15]。

对任意 $t \in [0,T]$，前推密度定义为

$$p_t^{\mathrm{fwd}}(\mathbf{x}_t) := \int \delta(\mathbf{x}_t - \Psi_{t\to 0}(\mathbf{x}_0))\, p_{\mathrm{data}}(\mathbf{x}_0)\, \mathrm{d}\mathbf{x}_0, \tag{4.4.1.132}$$

记为 $\Psi_{t\to 0}\#p_{\mathrm{data}}$，表示 $\Psi_{t\to 0}$ 下时刻 t 的分布。定理 4.1.1 保证 $p_t^{\mathrm{fwd}} = p_t$，其中 p_t 是前向 SDE 的边缘密度，等价于确定性 PF-ODE 与随机核：

$$p_t(\mathbf{x}_t) = \int p_t(\mathbf{x}_t \mid \mathbf{x}_0)\, p_{\mathrm{data}}(\mathbf{x}_0)\, \mathrm{d}\mathbf{x}_0 = \int \delta(\mathbf{x}_t - \Psi_{t\to 0}(\mathbf{x}_0))\, p_{\mathrm{data}}(\mathbf{x}_0)\, \mathrm{d}\mathbf{x}_0. \tag{4.4.1.133}$$

这意味着无穷多个条件 $Q_t(\mathbf{x}_t \mid \mathbf{x}_0)$ 给出同一个 $p_t(\mathbf{x}_t)$，例如：

- 随机（免模拟）：$Q_t(\mathbf{x}_t \mid \mathbf{x}_0) = p_t(\mathbf{x}_t \mid \mathbf{x}_0)$；
- 确定性（需求解 ODE）：$Q_t(\mathbf{x}_t \mid \mathbf{x}_0) = \delta(\mathbf{x}_t - \Psi_{t\to 0}(\mathbf{x}_0))$；
- 混合：$Q_t(\mathbf{x}_t \mid \mathbf{x}_0) = \lambda p_t(\mathbf{x}_t \mid \mathbf{x}_0) + (1-\lambda)\delta(\mathbf{x}_t - \Psi_{t\to 0}(\mathbf{x}_0))$，$\lambda \in [0,1]$.

$Q_t(\mathbf{x}_t \mid \mathbf{x}_0)$ 的这种非唯一性源于边缘约束不能唯一确定条件分布这一事实。这一概念在第 5.2 节与第 9.3 节重现。特别地，存在整整一族与同一边缘 p_t 相容的反向时间 SDE.

注 4.1.2 (观察 4.1.1：匹配指定边缘密度)**：** 多个过程可产生同一边缘密度序列；真正重要的是满足 Fokker–Planck 方程。这一根本洞见为我们设计从 p_{prior} 过渡到 p_{data}（或反向）的生成过程提供了非凡的灵活性. ◇

Fokker–Planck 方程位于扩散模型的核心，扎根于概率密度的变量替换基本公式（系统讨论见附录 B）。它远非次要技术细节，而是贯穿我们发展过程的原理，尤其在第 5.2 节.

4.1.6 可计算示例：Gaussian 动力学的演化

当 p_{data} 是正态分布（或 Gaussian 混合）时，分数函数有闭式表达。这使它成为建立扩散过程直觉的理想设定：我们只用基本微积分就能显式推导反向时间 SDE 与 PF-ODE，而不必诉诸高级数学工具。本节我们说明这些方程在这种可处理情形下如何表现.

[15]剧透：PF-ODE 流映射 $\Psi_{s\to t}$ 正是归一化流（NF）的双射，把 p_s 携带到 p_t（详见第 5.1.1 节）。区别在于：PF-ODE 固定由 SDE 的 Fokker–Planck 动力学决定的唯一向量场；而 NF（或连续时间 NF）参数化该场，但依赖同一变量替换原理。

带 Gaussian 的反向时间 SDE 精确计算. 当 p_{data} 是 Gaussian 时，式 (4.4.1.119) 可直接推导，不必依赖 Anderson（1982）的一般理论与证明。为说明核心思想，我们考虑一维情形；高维推广同理.

从前向 SDE 开始

$$\mathrm{d}x(t) = f(t)x(t)\,\mathrm{d}t + g(t)\,\mathrm{d}w_t, \tag{4.4.1.134}$$

走一步小 Euler 步长 $\Delta t > 0$：

$$x_{t+\Delta t} = a\,x_t + r\,\epsilon, \tag{4.4.1.135}$$

其中 $a := 1 + f(t)\Delta t$、$r := g(t)\sqrt{\Delta t}$、$\epsilon \sim \mathcal{N}(0,1)$。等价地，前向单步转移核为 Gaussian：

$$x_{t+\Delta t} \mid x_t \sim \mathcal{N}(ax_t, r^2). \tag{4.4.1.136}$$

由于假设 p_{data} 是 Gaussian，时刻 t 的当前边缘也是 Gaussian，形式为

$$x_t \sim \mathcal{N}(m_t, s_t^2), \tag{4.4.1.137}$$

其中 m_t、s_t 为标量。因此条件化归结为两个 Gaussian 相乘再归一化，代数保持初等.

由 Bayes 规则，条件密度（差一个常数）是先验与转移核的乘积：

$$\begin{aligned} p(x_t \mid x_{t+\Delta t}) &\propto p(x_{t+\Delta t} \mid x_t)\, p_t(\mathbf{x}_t) \\ &\propto \exp\Big(-\frac{(x_t - m_t)^2}{2s_t^2}\Big) \exp\Big(-\frac{(x_{t+\Delta t} - ax_t)^2}{2r^2}\Big). \end{aligned} \tag{4.4.1.138}$$

指数是 x_t 的二次式。展开两个平方并合并项，精确显示哪些系数重要：

$$-2\log p(x_t \mid x_{t+\Delta t}) = Ax_t^2 - 2Bx_t + \text{const}, \tag{4.4.1.139}$$

其中

$$A := \frac{1}{s_t^2} + \frac{a^2}{r^2}, \qquad B := \frac{m_t}{s_t^2} + \frac{ax_{t+\Delta t}}{r^2}. \tag{4.4.1.140}$$

这里 A 是精度之和（先验精度加上经 a 传递的转移核精度），B 是相应精度加权目标和。有了这些，配方给出一行后验：

$$Ax_t^2 - 2Bx_t = A\Big(x_t - \frac{B}{A}\Big)^2 - \frac{B^2}{A}, \tag{4.4.1.141}$$

于是条件分布是 Gaussian，方差 $1/A$、均值 B/A：

$$\mathrm{Var}(x_t \mid x_{t+\Delta t}) = \frac{1}{\frac{1}{s_t^2} + \frac{a^2}{r^2}}, \qquad \mathbb{E}[x_t \mid x_{t+\Delta t}] = \frac{\frac{m_t}{s_t^2} + \frac{ax_{t+\Delta t}}{r^2}}{\frac{1}{s_t^2} + \frac{a^2}{r^2}}. \tag{4.4.1.142}$$

这些闭式已描述任意小 Δt 的反向转移。为读出反向时间 SDE，现在对小 Δt 展开.

取 $a = 1 + f(t)\Delta t$、$r^2 = g^2(t)\Delta t$。当 $\Delta t \to 0$，贡献 $\frac{a^2}{r^2} \sim \frac{1}{g^2(t)\Delta t}$ 主导精度，故方差变为

$$\mathrm{Var}(x_t \mid x_{t+\Delta t}) = \Big(\frac{1}{s_t^2} + \frac{a^2}{r^2}\Big)^{-1} = g^2(t)\Delta t + \mathcal{O}(\Delta t^2), \tag{4.4.1.143}$$

这告诉我们反向步与前向步具有相同扩散尺度 $g(t)$。对均值，把比 B/A 展开到一阶：

$$\mathbb{E}[x_t \mid x_{t+\Delta t}] = x_{t+\Delta t} + \Delta t\Big[-\Big(f(t) + \frac{g^2(t)}{s_t^2}\Big)x_{t+\Delta t} + \frac{g^2(t)}{s_t^2} m_t\Big] + \mathcal{O}(\Delta t^2). \tag{4.4.1.144}$$

把均值与方差合起来，得到单步反向转移核：

$$x_t \mid x_{t+\Delta t} \sim \mathcal{N}\Big(x_{t+\Delta t} + \Delta t\Big[-\Big(f + \frac{g^2}{s_t^2}\Big)x_{t+\Delta t} + \frac{g^2}{s_t^2} m_t\Big],\, g^2\Delta t\Big) + \mathcal{O}(\Delta t^2). \tag{4.4.1.145}$$

这被识别为 Euler–Maruyama 更新，从 $t + \Delta t$ 向后跑到 t：

$$x_t - x_{t+\Delta t} = \Delta t\Big[-\Big(f + \frac{g^2}{s_t^2}\Big)x_{t+\Delta t} + \frac{g^2}{s_t^2} m_t\Big] + g\sqrt{\Delta t}\,\epsilon + \mathcal{O}(\Delta t^2). \tag{4.4.1.146}$$

令 $\Delta t \to 0$，得到原时钟上的 SDE（时间沿路径递减）：

$$\mathrm{d}x(t) = \Big[-\Big(f(t) + \frac{g^2(t)}{s_t^2}\Big)x(t) + \frac{g^2(t)}{s_t^2} m_t\Big]\mathrm{d}t + g(t)\,\mathrm{d}\bar{w}_t. \tag{4.4.1.147}$$

该漂移可用分数写出，因为对 Gaussian 边缘 $p_t = \mathcal{N}(m_t, s_t^2)$，

$$\partial_x \log p_t(x) = -\frac{x - m_t}{s_t^2} \quad \Longrightarrow \quad -\Big(f + \frac{g^2}{s_t^2}\Big)x + \frac{g^2}{s_t^2} m_t = -fx + g^2 \partial_x \log p_t(x). \tag{4.4.1.148}$$

为表示常规的沿 t 前向反向时间参数化，定义反转过程 $\bar{x}(t) := x(T - t)$（使我们现在沿 t 前向演化）。时间翻转把漂移变为

$$\mathrm{d}\bar{x}(t) = \big[f(t)\bar{x}(t) - g^2(t)\partial_x \log p_t(\bar{x}(t))\big]\mathrm{d}t + g(t)\,\mathrm{d}\bar{w}_t, \tag{4.4.1.149}$$

其中 $\bar{x}(T) \sim p_{\text{prior}} \approx p_T$。这正是常规反向时间 SDE。向量形式下，它与一般式 (4.4.1.119) 一致，只是用 $\nabla_{\mathbf{x}} \log p_t$ 代替一维导数.

带 Gaussian 的 PF-ODE 精确计算. 当数据分布假设为 Gaussian，我们也能直接推导 PF-ODE 公式，避免 Fokker–Planck 方程这类重型工具。最终我们将看到，PF-ODE 的边缘密度与前向 SDE 及反向时间 SDE 的边缘密度重合，为第 4.1.5 节讨论的 Fokker–Planck 理论提供构造性验证.

设在时刻 t，$x_t \sim \mathcal{N}(m_t, s_t^2)$。一步小确定性步长 Δt 可写为光滑映射

$$x_{t+\Delta t} = \Phi_{t,\Delta t}(x_t) = x_t + \Delta t\, v_t(x_t) + \mathcal{O}(\Delta t^2), \tag{4.4.1.150}$$

这只是 Δt 中的一阶 Taylor 展开。我们的目标是看 v_t 必须取什么形式，才能保证每当输入是 Gaussian 时输出仍为 Gaussian.

为此，把 v_t 在当前均值 m_t 附近展开：

$$v_t(x) = v_t(m_t) + v_t'(m_t)(x - m_t) + \tfrac{1}{2}v_t''(m_t)(x - m_t)^2 + \cdots . \tag{4.4.1.151}$$

令 $y := x_t - m_t$，故 $y \sim \mathcal{N}(0, s_t^2)$。接着把输出减去其均值（$\Delta t$ 一阶）：

$$z := x_{t+\Delta t} - \mathbb{E}[x_{t+\Delta t}] = y + \Delta t\Big(v_t'(m_t)y + \tfrac{1}{2}v_t''(m_t)(y^2 - s_t^2)\Big) + \mathcal{O}(\Delta t^2). \tag{4.4.1.152}$$

此时回忆：Gaussian 偏度为零，即其三阶中心矩为零。因此计算 $\mathbb{E}[z^3]$ 到一阶，用 $\mathbb{E}[y] = 0$、$\mathbb{E}[y^2] = s_t^2$、$\mathbb{E}[y^3] = 0$、$\mathbb{E}[y^4] = 3s_t^4$，得

$$\mathbb{E}[z^3] = 3\Delta t \cdot \tfrac{1}{2}v_t''(m_t)(\mathbb{E}[y^4] - s_t^2\mathbb{E}[y^2]) + \mathcal{O}(\Delta t^2) = 3\Delta t\, v_t''(m_t)s_t^4 + \mathcal{O}(\Delta t^2). \tag{4.4.1.153}$$

为使输出对所有小 Δt 都保持 Gaussian，该量必须在 Δt 一阶消失，这迫使 $v_t''(m_t) = 0$。对更高阶导数重复同一论证，排除更高次幂。因此 v_t 必须是线性加平移：

$$v_t(x) = a_t x + b_t. \tag{4.4.1.154}$$

代回步长：

$$x_{t+\Delta t} = (1 + \alpha_t\Delta t)x_t + \beta_t\Delta t + \mathcal{O}(\Delta t^2), \qquad \alpha_t := a_t,\ \beta_t := b_t. \tag{4.4.1.155}$$

现在把 $x_t \sim \mathcal{N}(m_t, s_t^2)$ 推入该映射，跟踪均值与方差到一阶：

$$\mathbb{E}[x_{t+\Delta t}] = m_t + \Delta t(\alpha_t m_t + \beta_t) + \mathcal{O}(\Delta t^2), \tag{4.4.1.156}$$

$$\mathrm{Var}(x_{t+\Delta t}) = s_t^2 + \Delta t(2\alpha_t s_t^2) + \mathcal{O}(\Delta t^2). \tag{4.4.1.157}$$

另一方面，前向 SDE $\mathrm{d}x = f(t)x\,\mathrm{d}t + g(t)\,\mathrm{d}w_t$ 有初等矩公式（式 (4.4.3.191)）：

$$m_t' = f(t)m_t, \qquad (s_t^2)' = 2f(t)s_t^2 + g^2(t). \tag{4.4.1.158}$$

匹配 Δt 的系数，得

$$\alpha_t = f(t) + \frac{g^2(t)}{2s_t^2}, \qquad \beta_t = -\frac{g^2(t)}{2s_t^2}m_t. \tag{4.4.1.159}$$

在这些选择下，步长变为

$$x_{t+\Delta t} = x_t + \Delta t\Big[\Big(f(t) + \frac{g^2(t)}{2s_t^2}\Big)x_t - \frac{g^2(t)}{2s_t^2}m_t\Big] + \mathcal{O}(\Delta t^2). \tag{4.4.1.160}$$

由于对 Gaussian $p_t = \mathcal{N}(m_t, s_t^2)$ 有 $\partial_x \log p_t(x) = -(x - m_t)/s_t^2$，可把括号重写为 $f(t)x_t - \frac{1}{2}g^2(t)\partial_x \log p_t(x_t)$。因此

$$x_{t+\Delta t} = x_t + \Delta t\Big[f(t)x_t - \tfrac{1}{2}g^2(t)\partial_x \log p_t(x_t)\Big] + \mathcal{O}(\Delta t^2). \tag{4.4.1.161}$$

最后，除以 Δt 并令 $\Delta t \to 0$，得到 PF-ODE

$$x'(t) = f(t)x(t) - \tfrac{1}{2}g^2(t)\partial_x \log p_t(x(t)). \tag{4.4.1.162}$$

为看出为何该 ODE 与前向 SDE（及反向时间 SDE）具有相同边缘：注意上述漂移是线性加平移。于是 $x(t)$ 仿射依赖 $x(0)$，而仿射映射把 Gaussian 映到 Gaussian。此外，沿该 ODE 的均值 m_t 与方差 s_t^2 恰好满足与前向 SDE 相同的两个标量 ODE（由我们的匹配），初值相同。因此 $p_t = \mathcal{N}(m_t, s_t^2)$ 在每个时刻 t 对两种演化都相同.

4.2 Score SDE：其训练与采样

4.2.1 训练

秉承第 3 章的思路，我们用时间条件神经网络逼近 oracle 分数 $\nabla_{\mathbf{x}} \log p_t(\mathbf{x})$：

$$\mathbf{s}_\phi = \mathbf{s}_\phi(\mathbf{x}, t), \tag{4.4.2.163}$$

跨所有 $t \in [0, T]$，通过最小化式 (3.3.2.41) 的分数匹配目标：

$$\mathcal{L}_{\mathrm{SM}}(\phi; \omega(\cdot)) := \frac{1}{2}\mathbb{E}_{t\sim p_{\mathrm{time}}}\mathbb{E}_{\mathbf{x}_t\sim p_t}\left[\omega(t)\|\mathbf{s}_\phi(\mathbf{x}_t, t) - \nabla_{\mathbf{x}} \log p_t(\mathbf{x}_t)\|_2^2\right], \tag{4.4.2.164}$$

其中 p_{time} 是某个时间分布（例如 $[0, T]$ 上均匀分布），$\omega(\cdot)$ 是时间加权函数.

为避免依赖不可处理的 oracle 分数 $\nabla_{\mathbf{x}} \log p_t(\mathbf{x})$，我们采用式 (3.3.3.52) 的 DSM 损失。在数据点 $\mathbf{x}_0$ 条件下，该方法允许使用解析可处理的分数 $\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t \mid \mathbf{x}_0)$（经式 (D.D.2.574)，具体示例见第 4.3 节）。具体地，我们使用如下损失函数：

$$\mathcal{L}_{\mathrm{DSM}}(\phi; \omega(\cdot)) := \frac{1}{2}\mathbb{E}_t\mathbb{E}_{\mathbf{x}_0}\mathbb{E}_{p_t(\mathbf{x}_t|\mathbf{x}_0)}\left[\omega(t)\|\mathbf{s}_\phi(\mathbf{x}_t, t) - \nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t \mid \mathbf{x}_0)\|_2^2\right], \tag{4.4.2.165}$$

其中 $\mathbf{x}_0 \sim p_{\mathrm{data}}$。式 (4.4.2.165) 可理解为式 (3.3.4.96) 的连续时间对应：离散情形的求和被积分替换.

与定理 3.3.1 的结果类似，式 (4.4.2.165) 的最小化解唯一确定为：

命题 4.2.1 (DSM 的最小化解)**：** *最小化解 $\mathbf{s}^*$ 满足*

$$\mathbf{s}^*(\mathbf{x}_t, t) = \mathbb{E}_{\mathbf{x}_0\sim p(\mathbf{x}_0|\mathbf{x}_t)}[\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t \mid \mathbf{x}_0)] = \nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t), \tag{4.4.2.166}$$

对几乎所有 $\mathbf{x}_t \sim p_t$ 与 $t \in [0, T]$.

命题证明： DSM 目标可理解为最小二乘问题：在每个时刻 t，最优分数函数由对数条件密度梯度的条件期望给出，而由 Bayes 规则，它等价于对数边缘密度的梯度。详细证明见附录 D.2.6. □

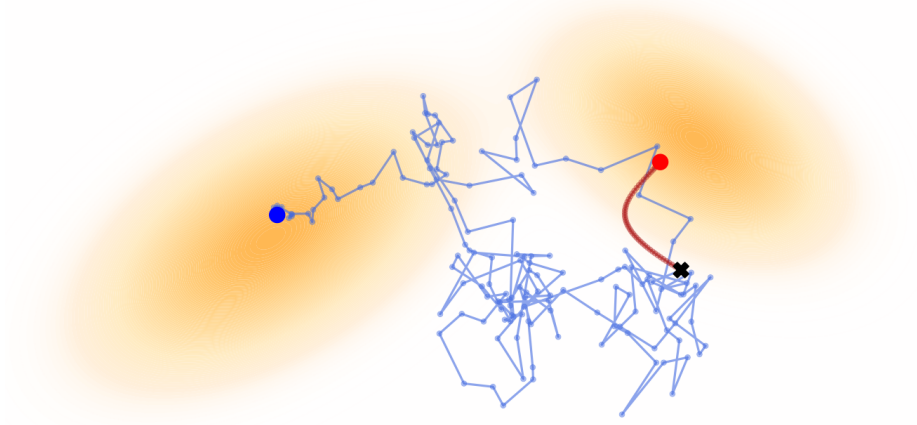
4.2.2 采样与推断

训练后

$$\mathbf{s}_{\phi^\times} := \mathbf{s}_{\phi^\times}(\mathbf{x}, t) \approx \nabla_{\mathbf{x}} \log p_t(\mathbf{x}), \tag{4.4.2.167}$$

我们用学到的代理 $\mathbf{s}_{\phi^\times}(\mathbf{x}, t)$ 替换反向时间 SDE(式 (4.4.1.119))与 PF-ODE(式 (4.4.1.123))中不可处理的 oracle 分数。这一代替允许通过 SDE 或 ODE 进行可处理推断。为清晰起见，我们把所得过程分别记为 $\mathbf{x}_{\phi^\times}^{\mathrm{SDE}}(t)$ 与 $\mathbf{x}_{\phi^\times}^{\mathrm{ODE}}(t)$，但后文省略这一区分[16].

[16]这是为本小节后简化记号。



ure 4.5: (2D) Illustration of sampling from the Score SDE. Sampling is by solving the erse-time SDE (blue; via Equation (4.2.4)) and the PF-ODE (red; via Equation (4.2.6)) the same forward SDE setup as in Figure 4.4. Starting from a random point $\mathbf{x}_T \sim p_{\text{prior}}$

图 4.22: （2D）从 Score SDE 采样示意。采样通过求解反向时间 SDE（蓝色，经式 (4.4.2.169)）与 PF-ODE（红色，经式 (4.4.2.174)）进行，前向 SDE 设定与图 4.21 相同。从随机点 $\mathbf{x}_T \sim p_{\text{prior}}$（深色 ×）出发，两条轨迹都终止于 $t = 0$ 附近 p_{data} 的支撑.

经验反向时间 SDE. 把训练好的分数模型 $\mathbf{s}_{\phi^\times}$ 代入式 (4.4.1.119) 替换真值分数，得到参数化的用于生成的反向时间 SDE：

$$\mathrm{d}\mathbf{x}^{\mathrm{SDE}}_{\phi^\times}(t) = \Big[\mathbf{f}\big(\mathbf{x}^{\mathrm{SDE}}_{\phi^\times}(t), t\big) - g^2(t)\mathbf{s}_{\phi^\times}\big(\mathbf{x}^{\mathrm{SDE}}_{\phi^\times}(t), t\big)\Big]\mathrm{d}t + g(t)\,\mathrm{d}\bar{\mathbf{w}}(t). \tag{4.4.2.168}$$

为生成样本，我们先从先验分布 p_{prior} 抽取初值 $\mathbf{x}_T$，然后从 $t = T$ 到 $t = 0$ 数值求解式 (4.4.2.168)。标准数值求解器是 Euler–Maruyama 法，给出离散更新规则：

$$\mathbf{x}_{t-\Delta t} \leftarrow \mathbf{x}_t - \Big[\mathbf{f}(\mathbf{x}_t, t) - g^2(t)\mathbf{s}_{\phi^\times}(\mathbf{x}_t, t)\Big]\Delta t + g(t)\sqrt{\Delta t}\,\boldsymbol{\epsilon}, \tag{4.4.2.169}$$

其中 $\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$，$\Delta t > 0$ 是步长.

迭代该更新规则得到最终样本 $\mathbf{x}^{\mathrm{SDE}}_{\phi^\times}(0)$。若分数模型准确，这些生成样本的分布（记为 $p^{\mathrm{SDE}}_{\phi^\times}(\cdot; 0)$）提供对真实数据分布的逼近[17]：

$$p^{\mathrm{SDE}}_{\phi^\times}(\cdot; 0) \approx p_{\text{data}}(\cdot). \tag{4.4.2.170}$$

事实上，式 (2.2.2.23) 中给出的 DDPM 采样正是这一 Euler–Maruyama 格式的特例，应用于 $\mathbf{f}$ 与 g 的特定选择（见第 4.3 节）.

[17]理论上，估计精度取决于 p_T 与 p_{prior} 的偏差（通常可忽略）、模型训练误差与数值离散化误差（De Bortoli, 2022）。我们此处不追求形式界。

经验 PF-ODE. PF-ODE 定义了连接 p_{prior} 与 p_{data} 的连续流，可用于采样、编码与精确似然评估。下一节进一步说明每种操作.

I. 用 PF-ODE 采样. 把式 (4.4.1.123) 中的 oracle 分数替换为 $\mathbf{s}_{\phi^\times}$，得到经验 PF-ODE：

$$\frac{\mathrm{d}}{\mathrm{d}t}\mathbf{x}_{\phi^\times}^{\mathrm{ODE}}(t) = \mathbf{f}\big(\mathbf{x}_{\phi^\times}^{\mathrm{ODE}}(t), t\big) - \tfrac{1}{2}g^2(t)\mathbf{s}_{\phi^\times}\big(\mathbf{x}_{\phi^\times}^{\mathrm{ODE}}(t), t\big). \tag{4.4.2.171}$$

为生成样本，我们先从先验分布 p_{prior} 抽取初始样本 $\mathbf{x}_T$，然后从 $t = T$ 到 $t = 0$ 数值求解式 (4.4.2.171)。该过程等价于逼近积分：

$$\mathbf{x}_{\phi^\times}^{\mathrm{ODE}}(0) = \mathbf{x}_T + \int_T^0 \Big[\mathbf{f}\big(\mathbf{x}_{\phi^\times}^{\mathrm{ODE}}(\tau), \tau\big) - \tfrac{1}{2}g^2(\tau)\mathbf{s}_{\phi^\times}\big(\mathbf{x}_{\phi^\times}^{\mathrm{ODE}}(\tau), \tau\big)\Big]\mathrm{d}\tau. \tag{4.4.2.172}$$

求解该积分得到最终样本 $\mathbf{x}_{\phi^\times}^{\mathrm{ODE}}(0)$。由该确定性过程生成的样本分布（记为 $p_{\phi^\times}^{\mathrm{ODE}}(\cdot;0)$）提供对数据分布的逼近，$p_{\phi^\times}^{\mathrm{ODE}}(\cdot;0) \approx p_{\text{data}}$.

设 $\Delta t > 0$ 为离散化步长。标准数值积分方法是 Euler 法，它估计

$$\mathbf{f}(\mathbf{x}_\tau, \tau) - \tfrac{1}{2}g^2(\tau)\mathbf{s}_{\phi^\times}(\mathbf{x}_\tau, \tau) \approx \mathbf{f}(\mathbf{x}_t, t) - \tfrac{1}{2}g^2(t)\mathbf{s}_{\phi^\times}(\mathbf{x}_t, t), \qquad \tau \in [t - \Delta t, t], \tag{4.4.2.173}$$

得到如下更新规则：

$$\mathbf{x}_{t-\Delta t} \leftarrow \mathbf{x}_t - \Big[\mathbf{f}(\mathbf{x}_t, t) - \tfrac{1}{2}g^2(t)\mathbf{s}_{\phi^\times}(\mathbf{x}_t, t)\Big]\Delta t. \tag{4.4.2.174}$$

这一联系使我们能用如下核心洞见重述生成过程：

注 4.2.1 (洞见 4.2.1：生成 $\Leftrightarrow$ ODE/SDE 求解)**：** 从扩散模型采样，本质上等价于求解相应的概率流 ODE 或反向时间 SDE. ◇

这一等价清晰解释了问题 3.5.1 中提出的扩散模型采样缓慢：生成计算密集，因为这些微分方程的数值求解器本质上是迭代的，常需多步才能精确逼近解轨迹[18]。然而 PF-ODE 表述也有优势：它允许我们利用加速数值求解器的大量文献。探索这些技术以加速扩散模型采样是第 9 章的主要焦点.

II. 用 PF-ODE 反转. 如前所述，与 SDE 情形不同，我们可从两个方向求解同一个式 (4.4.2.171)：前向（从 0 到 T）或反向（从 T 到 0）。前向求解时，ODE 流映射把数据在所有 $t \in [0, T]$ 上映射到其（带噪）隐表示，起到编码器作用。这一概念为可控生成的强大应用打开了大门，例如图像翻译与编辑等（Mokady 等, 2023；Su 等, 2022）.

III. 经 PF-ODE 的精确对数似然计算. 我们把式 (4.4.2.171) 中的动力学重新解释为神经常微分方程（Chen 等, 2018）变体（见第 5.1.2 节）：它只参数化分数函数而非完整速度场。这一 PF-ODE 表述使我们能通过变量替换公式实现精确对数似然计算.

把式 (5.5.0.235) 的恒等式应用于式 (4.4.2.171) 的 PF-ODE，定义速度场

$$\mathbf{v}_{\phi^\times}(\mathbf{x}, t) := \mathbf{f}(\mathbf{x}, t) - \tfrac{1}{2}g^2(t)\mathbf{s}_{\phi^\times}(\mathbf{x}, t), \tag{4.4.2.175}$$

[18]例如，DDPM 与 Score SDE 生成通常使用 1000 次函数评估。

其中 $\mathbf{s}_{\phi^\times}$ 是学到的分数。沿 PF-ODE 轨迹 $\{\mathbf{x}^{\mathrm{ODE}}_{\phi^\times}(t)\}_{t\in[0,T]}$，对数密度 $p^{\mathrm{ODE}}_{\phi^\times}(\cdot;t)$ 的时间演化满足

$$\frac{\mathrm{d}}{\mathrm{d}t}\log p^{\mathrm{ODE}}_{\phi^\times}\big(\mathbf{x}^{\mathrm{ODE}}_{\phi^\times}(t),t\big)=-\nabla\cdot\mathbf{v}_{\phi^\times}\big(\mathbf{x}^{\mathrm{ODE}}_{\phi^\times}(t),t\big), \tag{4.4.2.176}$$

其中 $\nabla\cdot\mathbf{v}$ 表示 $\mathbf{x}$ 中的散度.

为评估数据点 $\mathbf{x}_0\sim p_{\mathrm{data}}$ 的似然，我们从 $t=0$ 到 $t=T$ 积分如下增广 ODE 系统：

$$\frac{\mathrm{d}}{\mathrm{d}t}\begin{bmatrix}\mathbf{x}(t)\\ \delta(t)\end{bmatrix}=\begin{bmatrix}\mathbf{v}_{\phi^\times}(\mathbf{x}(t),t)\\ \nabla\cdot\mathbf{v}_{\phi^\times}(\mathbf{x}(t),t)\end{bmatrix},\qquad\begin{bmatrix}\mathbf{x}(0)\\ \delta(0)\end{bmatrix}=\begin{bmatrix}\mathbf{x}_0\\ 0\end{bmatrix}, \tag{4.4.2.177}$$

其中 $\delta(t)$ 累积随时间的对数密度变化。把系统求解到 $t=T$，得到末端状态

$$\begin{bmatrix}\mathbf{x}(T)\\ \delta(T)\end{bmatrix}. \tag{4.4.2.178}$$

原始样本 $\mathbf{x}_0$ 在模型下的对数似然可评估为

$$\log p^{\mathrm{ODE}}_{\phi^\times}(\mathbf{x}_0;0)=\log p_{\mathrm{prior}}(\mathbf{x}(T))+\delta(T), \tag{4.4.2.179}$$

其中 $p_{\mathrm{prior}}(\mathbf{x}(T))$ 表示在 $\mathbf{x}(T)$ 处求值的闭式先验密度.

4.3 SDE 的具体实例

Song 等（2020c）根据演化中方差的行为，把前向 SDE 中的漂移项 $\mathbf{f}(\mathbf{x},t)$ 与扩散项 $g(t)$ 分为三类。这里我们聚焦两种常用类型：*方差爆炸* SDE（Variance Explosion SDE, VE SDE）与 *方差保持* SDE（Variance Preserving SDE, VP SDE）。虽然可以设计自定义噪声调度器，但其设计会显著影响实证性能。表 3 总结了这两种 SDE 实例.

表 3: 前向 SDE 总结

	VE SDE	**VP SDE**
$\mathbf{f}(\mathbf{x},t)$	$\mathbf{0}$	$-\frac{1}{2}\beta(t)\mathbf{x}$
$g(t)$	$\sqrt{\frac{\mathrm{d}\sigma^2(t)}{\mathrm{d}t}}$	$\sqrt{\beta(t)}$
SDE	$\mathrm{d}\mathbf{x}(t)=g(t)\,\mathrm{d}\mathbf{w}(t)$	$\mathrm{d}\mathbf{x}(t)=-\frac{1}{2}\beta(t)\mathbf{x}(t)\,\mathrm{d}t+\sqrt{\beta(t)}\,\mathrm{d}\mathbf{w}(t)$
$p_t(\mathbf{x}_t\mid\mathbf{x}_0)$	$\mathcal{N}\big(\mathbf{x}_t;\mathbf{x}_0,(\sigma^2(t)-\sigma^2(0))\mathbf{I}\big)$	$\mathcal{N}\big(\mathbf{x}_t;\mathbf{x}_0e^{-\frac{1}{2}\int_0^t\beta(\tau)\mathrm{d}\tau},\mathbf{I}-\mathbf{I}e^{-\int_0^t\beta(\tau)\mathrm{d}\tau}\big)$
p_{prior}	$\mathcal{N}(\mathbf{0},\sigma^2(T)\mathbf{I})$	$\mathcal{N}(\mathbf{0},\mathbf{I})$

4.3.1 VE SDE

VE SDE 有以下组件：

- **漂移项：** 零漂移 $\mathbf{f}=\mathbf{0}$；

- **扩散项：** $g(t)=\sqrt{\frac{\mathrm{d}\sigma^2(t)}{\mathrm{d}t}}$，对某函数 $\sigma(t)$.

前向 SDE 取如下形式：

$$\mathrm{d}\mathbf{x}(t)=\sqrt{\frac{\mathrm{d}\sigma^2(t)}{\mathrm{d}t}}\,\mathrm{d}\mathbf{w}(t). \tag{4.4.3.180}$$

类似地，第 4.3.3 节的结果给出 VE SDE 的扰动核，并提示选择合适的先验分布：

- **扰动核：**

$$p_t(\mathbf{x}_t\mid\mathbf{x}_0)=\mathcal{N}\big(\mathbf{x}_t;\mathbf{x}_0,(\sigma^2(t)-\sigma^2(0))\mathbf{I}\big). \tag{4.4.3.181}$$

- **先验分布：** 假设 $\sigma(t)$ 在 $t\in[0,T]$ 上递增，且 $\sigma^2(T)\gg\sigma^2(0)$。先验分布为

$$p_{\text{prior}}:=\mathcal{N}(\mathbf{0},\sigma^2(T)\mathbf{I}). \tag{4.4.3.182}$$

VE SDE 的典型实例是 NCSN，设计如下：

$$\sigma(t):=\sigma_{\min}\Big(\frac{\sigma_{\max}}{\sigma_{\min}}\Big)^t,\qquad t\in(0,1], \tag{4.4.3.183}$$

其中 $\sigma_{\min}$、$\sigma_{\max}$ 是预先指定的常数。即方差序列设计为几何序列。这样，NCSN 被视为 VE SDE 的离散化，如第 4.1.2 节所述.

4.3.2 VP SDE

设 $\beta:[0,T]\to\mathbb{R}_{\geq 0}$ 是 t 的非负函数。VP SDE 由以下组件定义：

- **漂移项：** 线性漂移 $\mathbf{f}(\mathbf{x},t)=-\frac{1}{2}\beta(t)\mathbf{x}$；
- **扩散项：** $g(t)=\sqrt{\beta(t)}$.

因此前向 SDE 表达为

$$\mathrm{d}\mathbf{x}(t)=-\tfrac{1}{2}\beta(t)\mathbf{x}(t)\,\mathrm{d}t+\sqrt{\beta(t)}\,\mathrm{d}\mathbf{w}(t). \tag{4.4.3.184}$$

用第 4.3.3 节的结果，可推导 VP SDE 的扰动核并选择合适的先验分布：

- **扰动核：**

$$p_t(\mathbf{x}_t\mid\mathbf{x}_0)=\mathcal{N}\big(\mathbf{x}_t;\mathbf{x}_0e^{-\frac{1}{2}\int_0^t\beta(\tau)\mathrm{d}\tau},\,\mathbf{I}-\mathbf{I}e^{-\int_0^t\beta(\tau)\mathrm{d}\tau}\big). \tag{4.4.3.185}$$

- **先验分布：** $p_{\text{prior}}:=\mathcal{N}(\mathbf{0},\mathbf{I})$.

我们注意：由于扰动核是具有已知均值与协方差的 Gaussian，可用式 (D.D.2.575) 计算其分数函数.

VP SDE 的经典实例是 DDPM，其噪声调度 $\beta(t)$ 定义为

$$\beta(t):=\beta_{\min}+t(\beta_{\max}-\beta_{\min}),\qquad t\in[0,1]. \tag{4.4.3.186}$$

这里 $\beta_{\min}$、$\beta_{\max}$ 是预定义常数。这样，DDPM 可解释为 VP SDE 的离散化，如第 4.1.2 节所述.

4.3.3 （可选）扰动核 $p_t(\mathbf{x}_t \mid \mathbf{x}_0)$ 如何推导？

若前向 SDE 式 (4.4.1.111) 中的漂移项关于 $\mathbf{x}$ 线性，形式为

$$\mathbf{f}(\mathbf{x}, t) = f(t)\mathbf{x}, \tag{4.4.3.187}$$

其中 $f(t) \in \mathbb{R}$ 是某个标量值时变函数，则式 (4.4.1.111) 变为线性 SDE：

$$\mathrm{d}\mathbf{x}(t) = f(t)\mathbf{x}(t)\,\mathrm{d}t + g(t)\,\mathrm{d}\mathbf{w}(t). \tag{4.4.3.188}$$

即使初始分布 p_{data} 非 Gaussian，漂移的线性性也保证条件过程保持 Gaussian。特别地，对 $t > 0$，转移核取形式

$$p_t(\mathbf{x}_t \mid \mathbf{x}_0) = \mathcal{N}\big(\mathbf{x}_t; \mathbf{m}(t), P(t)\mathbf{I}_D\big), \tag{4.4.3.189}$$

其中 $\mathbf{x}_0 \sim p_{\text{data}}$，$\mathbf{m}(t) \in \mathbb{R}^D$、$P(t) \in \mathbb{R}_{\geq 0}$ 表示给定 $\mathbf{x}_0$ 时的条件均值与（标量）方差，定义为

$$\mathbf{m}(t) = \mathbb{E}[\mathbf{x}_t \mid \mathbf{x}(0) = \mathbf{x}_0], \qquad P(t)\mathbf{I}_D = \mathrm{Cov}[\mathbf{x}_t \mid \mathbf{x}(0) = \mathbf{x}_0]. \tag{4.4.3.190}$$

这些一阶、二阶矩按以下 ODE 演化（Särkkä 与 Solin, 2019）：

$$\begin{aligned} \frac{\mathrm{d}\mathbf{m}(t)}{\mathrm{d}t} &= f(t)\mathbf{m}(t), \\ \frac{\mathrm{d}P(t)}{\mathrm{d}t} &= 2f(t)P(t) + g^2(t), \end{aligned} \tag{4.4.3.191}$$

只要初始均值 $\mathbf{m}(0)$ 与方差 $P(0)$ 有限.

由于两个 ODE 都是线性的，它们通过积分因子法有闭式解。给定初值条件 $\mathbf{x}_0$，均值与方差演化为

$$\mathbf{m}(t) = \mathcal{E}(0 \to t)\mathbf{x}_0, \qquad P(t) = \int_0^t \mathcal{E}^2(s \to t) g(s)^2\,\mathrm{d}s, \tag{4.4.3.192}$$

其中 $\mathbf{m}(0) = \mathbf{x}_0$、$P(0) = 0$。$\mathcal{E}(s \to t)$ 表示指数积分因子

$$\mathcal{E}(s \to t) := \exp\Big(\int_s^t f(u)\,\mathrm{d}u\Big), \tag{4.4.3.193}$$

它捕获从时刻 s 到 t 漂移的累积效应。因此转移核 $p_t(\mathbf{x}_t \mid \mathbf{x}_0)$ 也有闭式表达.

我们把 $p_t(\mathbf{x}_t \mid \mathbf{x}_0)$ 的条件协方差为各向同性（即 $\mathrm{Cov}[\mathbf{x}_t \mid \mathbf{x}_0] = P(t)\mathbf{I}_D$，在 D 维 Wiener 过程与独立坐标扩散 $g(t)\mathbf{I}_D$ 下）这一论断的证明，以及式 (4.4.3.191) 的推导，留待附录 C.1.5，因为它依赖 Itô 微积分.

例 4.3.1 (VE SDE 的转移核)： VE SDE 的特例：$\mathbf{f} \equiv \mathbf{0}$、$g(t) = \sqrt{\frac{\mathrm{d}\sigma^2(t)}{\mathrm{d}t}}$，SDE 解的均值与协方差演化如下.

均值.

$$\frac{\mathrm{d}\mathbf{m}(t)}{\mathrm{d}t} = \mathbf{0}, \qquad \text{with } \mathbf{m}(0) = \mathbf{x}_0 \quad \Longrightarrow \quad \mathbf{m}(t) = \mathbf{x}_0. \tag{4.4.3.194}$$

方差.

$$\frac{\mathrm{d}P(t)}{\mathrm{d}t} = \frac{\mathrm{d}\sigma^2(t)}{\mathrm{d}t}, \qquad \text{with } P(0) = 0 \quad \Longrightarrow \quad P(t) = \sigma^2(t) - \sigma^2(0). \tag{4.4.3.195}$$

因此

$$p_t(\mathbf{x}_t \mid \mathbf{x}_0) = \mathcal{N}\big(\mathbf{x}_t; \mathbf{x}_0, (\sigma^2(t) - \sigma^2(0))\mathbf{I}_D\big). \tag{4.4.3.196}$$

◇

例 4.3.2 (VP SDE 的转移核)**：** VP SDE 情形，漂移 $\mathbf{f}(\mathbf{x}, t) = -\frac{1}{2}\beta(t)\mathbf{x}$，扩散 $g(t) = \sqrt{\beta(t)}$:

均值 $\mathbf{m}(t)$.

$$\frac{\mathrm{d}\mathbf{m}}{\mathrm{d}t} = -\tfrac{1}{2}\beta(t)\mathbf{m}(t), \qquad B(t) := \int_0^t \beta(s)\,\mathrm{d}s, \qquad \mathbf{m}(t) = e^{-\frac{1}{2}B(t)}\mathbf{x}_0. \tag{4.4.3.197}$$

方差 $P(t)$. 方差满足

$$\frac{\mathrm{d}P}{\mathrm{d}t} = -\beta(t)P(t) + \beta(t). \tag{4.4.3.198}$$

用积分因子 $e^{B(t)}$（$B(t) = \int_0^t \beta(s)\mathrm{d}s$），得

$$\frac{\mathrm{d}}{\mathrm{d}t}\big[P(t)e^{B(t)}\big] = \beta(t)e^{B(t)}. \tag{4.4.3.199}$$

两边积分给出

$$P(t) = 1 - e^{-B(t)}. \tag{4.4.3.200}$$

于是协方差各向同性，

$$\mathbf{P}(t) = P(t)\mathbf{I}_D = (1 - e^{-B(t)})\mathbf{I}_D. \tag{4.4.3.201}$$

最终闭式转移核.

$$p_t(\mathbf{x}_t \mid \mathbf{x}_0) = \mathcal{N}\big(\mathbf{x}_t; \underbrace{e^{-\frac{1}{2}B(t)}\mathbf{x}_0}_{\mathbf{m}(t)}, \underbrace{(1 - e^{-B(t)})\mathbf{I}_D}_{P(t)\mathbf{I}_D}\big), \qquad B(t) = \int_0^t \beta(s)\,\mathrm{d}s. \tag{4.4.3.202}$$

◇

4.4 （可选）反思基于分数与变分扩散模型中的前向核

DDPM 与 Score SDE 通常通过前向转移核 $p(\mathbf{x}_t \mid \mathbf{x}_{t-\Delta t})$ 引入：DDPM 中离散定义，Score SDE 中连续时间 SDE。然而实践中最关键的是损失函数（式 (2.2.2.17) 与式 (4.4.2.165)）中累积的转移核 $p_t(\mathbf{x}_t \mid \mathbf{x}_0)$。两个框架最终都依赖该核，要么通过递归计算（DDPM），要么通过求解 ODE（见第 4.3.3 节 Score SDE）.

本节我们先（连续时间地）定义 $p_t(\mathbf{x}_t \mid \mathbf{x}_0)$，它提供更干净、更直接的视角。总体上，虽然 $p(\mathbf{x}_t \mid \mathbf{x}_{t-\Delta t})$ 与 $p_t(\mathbf{x}_t \mid \mathbf{x}_0)$ 理论等价，但定义后者常得到更干净、更可解释的表述。特别地，$p_t(\mathbf{x}_t \mid \mathbf{x}_0)$ 直接给出 $t \to T$ 时关于先验的洞察，并与实际损失设计自然对齐.

4.4.1 A General Affine Forward Process $p_t(\mathbf{x}_t|\mathbf{x}_0)$

We begin with defining a general forward perturbation kernel:

$$p_t(\mathbf{x}_t|\mathbf{x}_0) := \mathcal{N}(\mathbf{x}_t; \alpha_t \mathbf{x}_0, \sigma_t^2 \mathbf{I}), \tag{4.4.1}$$

where $\mathbf{x}_0 \sim p_{\text{data}}$, and α_t, σ_t are nonnegative scalar functions of $t \in [0, T]$ satisfying:

图 4.23: 引理 4.4.1 示意。通过连续时间 SDE 增量加噪（$\Delta t \to 0$）与式 (4.4.4.203) 的直接扰动在数学上等价.

4.4.1 一般仿射前向过程 $p_t(\mathbf{x}_t \mid \mathbf{x}_0)$

我们先定义一般前向扰动核：

$$p_t(\mathbf{x}_t \mid \mathbf{x}_0) := \mathcal{N}(\mathbf{x}_t; \alpha_t \mathbf{x}_0, \sigma_t^2 \mathbf{I}), \tag{4.4.4.203}$$

其中 $\mathbf{x}_0 \sim p_{\text{data}}$，$\alpha_t$、$\sigma_t$ 是 $t \in [0, T]$ 的非负标量函数，满足：

1. 对所有 $t \in (0, 1]$，$\alpha_t > 0$、$\sigma_t > 0$（允许 $\sigma_0 = 0$）；
2. 通常 $\alpha_0 = 1$、$\sigma_0 = 0$.

即 $\mathbf{x}_t \sim p_t(\mathbf{x}_t \mid \mathbf{x}_0)$ 可采样为

$$\mathbf{x}_t = \alpha_t \mathbf{x}_0 + \sigma_t \boldsymbol{\epsilon}, \qquad \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}). \tag{4.4.4.204}$$

该框架涵盖若干熟知实例，包括 VE（如 NCSN）、VP（如 DDPM）以及 Flow Matching（FM）前向核（Lipman 等, 2022；Liu, 2022），后者在 $\mathbf{x}_0$ 与 $\boldsymbol{\epsilon}$ 之间线性插值（见第 5.2 节）。

- **VE（NCSN）核：** $\alpha_t \equiv 1$，$\sigma_T \gg 1$；
- **VP（DDPM）核：** $\alpha_t := \sqrt{1 - \sigma_t^2}$，使 $\alpha_t^2 + \sigma_t^2 = 1$；
- **FM 核：** $\alpha_t = 1 - t$，$\sigma_t = t$.

4.4.2 与 Score SDE 的联系

对 Score SDE，以线性形式指定 $p_t(\mathbf{x}_t \mid \mathbf{x}_0)$ 自然诱导出具有仿射系数的 SDE，提供了一个比从漂移与扩散项出发再求解矩 ODE（见第 4.3.3 节）更直观的替代.

给定式 (4.4.4.203) 的前向扰动核，相应前向 SDE 取式 (4.4.3.184) 中关于 $\mathbf{x}$ 线性的形式：

$$\mathrm{d}\mathbf{x}(t) = \underbrace{f(t)\mathbf{x}(t)}_{\mathbf{f}(\mathbf{x}(t), t)} \mathrm{d}t + g(t)\, \mathrm{d}\mathbf{w}(t), \tag{4.4.4.205}$$

其中 $f, g : [0, T] \to \mathbb{R}$ 是实值时间函数。系数 $f(t)$ 与 $g(t)$ 可解析地用 α_t、σ_t 表达，如下引理总结.

引理 4.4.1 (前向扰动核 $\Leftrightarrow$ 线性 SDE)**：** 定义 $\lambda_t := \log \frac{\alpha_t}{\sigma_t}$，$t \in (0, T]$。给定前向扰动核

$$\mathbf{x}_t = \alpha_t \mathbf{x}_0 + \sigma_t \boldsymbol{\epsilon}, \qquad \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}), \tag{4.4.4.206}$$

线性 SDE

$$\mathrm{d}\mathbf{x}(t) = f(t)\mathbf{x}(t)\,\mathrm{d}t + g(t)\,\mathrm{d}\mathbf{w}(t) \tag{4.4.4.207}$$

的系数为

$$f(t) = \frac{\mathrm{d}}{\mathrm{d}t}\log \alpha_t, \qquad g^2(t) = \frac{\mathrm{d}\sigma_t^2}{\mathrm{d}t} - 2\frac{\mathrm{d}}{\mathrm{d}t}\log \alpha_t\, \sigma_t^2 = -2\sigma_t^2 \frac{\mathrm{d}}{\mathrm{d}t}\lambda_t, \tag{4.4.4.208}$$

对所有 $t \in (0, T]$ 具有条件转移 $p_t(\mathbf{x}_t \mid \mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t; \alpha_t \mathbf{x}_0, \sigma_t^2 \mathbf{I})$。反之，若线性 SDE 具有条件转移 $\mathcal{N}(\mathbf{x}_t; \alpha_t \mathbf{x}_0, \sigma_t^2 \mathbf{I})$ 且对所有 $t \in (0, T]$ $\alpha_t > 0$、$\sigma_t > 0$，则其系数在 $t \in (0, T]$ 满足式 (4.4.4.208).

引理证明： 由第 4.3.3 节, 证明通过匹配均值与协方差 ODE $\mathbf{m}'(t) = f(t)\mathbf{m}(t)$、$\mathbf{P}'(t) = 2f(t)\mathbf{P}(t) + g^2(t)\mathbf{I}$，其中 $\mathbf{m}(t) = \alpha_t \mathbf{x}_0$、$\mathbf{P}(t) = \sigma_t^2 \mathbf{I}$ 在 $(0, T]$ 上. □

注 4.4.1 (终端 Gaussian 先验的渐近遗忘)**：** 为在终端时刻精确匹配 Gaussian 先验，过程必须完全遗忘 $\mathbf{x}_0$ 并达到目标方差；这要求 $\alpha_T = 0$，且 σ_T^2 等于先验方差.

在 SDE 表述中，有

$$\alpha_t = \exp\Big(\int_0^t f(u)\,\mathrm{d}u \Big). \tag{4.4.4.209}$$

因此在有限 T 强制 $\alpha_T = 0$ 迫使

$$\int_0^T f(u)\,\mathrm{d}u = -\infty, \tag{4.4.4.210}$$

意味着漂移必须在 $t \to T$ 时无限快收缩。同时扩散必须发散，以维持指定方差，这反映为

$$g^2(t) = \sigma_t^{2\prime} - 2\frac{\alpha_t'}{\alpha_t}\sigma_t^2 \to \infty, \qquad \text{当} t \to T. \tag{4.4.4.211}$$

若 f 与 g 在 $[0, T]$ 上有界，则必然 $\alpha_T > 0$，对 $\mathbf{x}_0$ 的残余依赖仍存在。此时 Gaussian 先验只渐近达到：要么在 $t \to T$ 极限下（不精确达到），要么经适当时间重参数化后在无限视界 $T \to \infty$ 处精确达到. ◇

由上述引理，通过具有系数 $f(t)$、$g(t)$ 的线性 SDE 指定增量加噪，与用参数 α_t、σ_t 定义扰动核在数学上等价。在扩散模型文献中，这两个视角可互换使用。因此我们结论：

注 4.4.2 (观察 4.4.1)**：** 定义 $p_t(\mathbf{x}_t \mid \mathbf{x}_0)$ 等价于指定线性 SDE 系数 $f(t)$ 与 $g(t)$. ◇

4.4.3 与变分扩散模型的联系

我们回顾 DDPM 中一个核心恒等式（由 Bayes 规则推导）：

$$p(\mathbf{x}_{t-\Delta t} \mid \mathbf{x}_t, \mathbf{x}) = p(\mathbf{x}_t \mid \mathbf{x}_{t-\Delta t}) \cdot \frac{p_{t-\Delta t}(\mathbf{x}_{t-\Delta t} \mid \mathbf{x})}{p_t(\mathbf{x}_t \mid \mathbf{x})}, \tag{4.4.4.212}$$

对任意 $\mathbf{x}$（通常 $\mathbf{x} \sim p_{\text{data}}$）。这一反向条件 $p(\mathbf{x}_{t-\Delta t} \mid \mathbf{x}_t, \mathbf{x})$ 是建模的核心，使可处理训练目标与高效采样成为可能.

虽然 DDPM 通常先定义增量核 $p(\mathbf{x}_t \mid \mathbf{x}_{t-\Delta t})$，累积转移 $p_t(\mathbf{x}_t \mid \mathbf{x}_0)$ 常提供更可解释、更实用的表述，尤其在与先验和损失设计相关时.

推导转移核. 我们把它推广到连续时间设定。设 $0 \le t < s \le T$ 为两个（连续）时刻。给定扰动核 $p_t(\mathbf{x}_t \mid \mathbf{x}_0)$，可用式 (4.4.4.212)[19]对任意 $\mathbf{x}$ 计算反向条件 $p(\mathbf{x}_t \mid \mathbf{x}_s, \mathbf{x})$，以前向核 $p(\mathbf{x}_s \mid \mathbf{x}_t)$ 为中间量。以下引理总结这一推导，推广了引理 2.2.1，而不假设 $\alpha_t^2 + \sigma_t^2 = 1$.

引理 4.4.2 (反向条件转移核)**：** 设 $0 \le t < s \le T$。反向条件转移核为

$$p(\mathbf{x}_t \mid \mathbf{x}_s, \mathbf{x}) = \mathcal{N}\big(\mathbf{x}_t; \boldsymbol{\mu}(\mathbf{x}_s, \mathbf{x}; s, t), \sigma^2(s,t)\mathbf{I}\big), \tag{4.4.4.213}$$

其中

$$\begin{aligned} \boldsymbol{\mu}(\mathbf{x}_s, \mathbf{x}; s, t) &:= \frac{\alpha_{s|t}\sigma_{t|s}^2}{\sigma_s^2}\mathbf{x}_s + \frac{\alpha_t \sigma_{s|t}^2}{\sigma_s^2}\mathbf{x}, \\ \sigma^2(s,t) &:= \sigma_{s|t}^2 \frac{\sigma_t^2}{\sigma_s^2}. \end{aligned} \tag{4.4.4.214}$$

这里 $\alpha_{s|t}$、$\sigma_{s|t}$ 定义为

$$\alpha_{s|t} := \frac{\alpha_s}{\alpha_t}, \qquad \sigma_{s|t}^2 := \sigma_s^2 - \alpha_{s|t}^2 \sigma_t^2. \tag{4.4.4.215}$$

引理证明： 我们先计算前向转移核：

$$p(\mathbf{x}_s \mid \mathbf{x}_t) = \mathcal{N}\big(\mathbf{x}_s; \alpha_{s|t}\mathbf{x}_t, \sigma_{s|t}^2\mathbf{I}\big). \tag{4.4.4.216}$$

反向核由 Bayes 规则给出；由于所有涉及分布都是 Gaussian，结果可由直接计算推导。细节见 Kingma 等（2021）附录 A. □

虽然 $p(\mathbf{x}_{t+\Delta t} \mid \mathbf{x}_t)$ 与 $p_t(\mathbf{x}_t \mid \mathbf{x}_0)$ 理论等价，但 $p_t(\mathbf{x}_t \mid \mathbf{x}_0)$ 常起更核心作用。式 (4.4.4.216) 的逐步转移主要用于得到闭式反向核。近期工作（Kingma 等, 2021）因此偏好直接指定 $p_t(\mathbf{x}_t \mid \mathbf{x}_0)$，因其清晰且可解释.

反向过程建模、训练与采样. 式 (2.2.2.22) 的训练目标（ELBO）与第 2.1 节引入的建模框架在广义工作下仍适用。为清晰起见，我们遵循 Kingma 等（2021）采用 $\mathbf{x}$-预测表述，记为 $\mathbf{x}_\phi(\mathbf{x}_s, s)$。然而等价的 $\boldsymbol{\epsilon}$-预测视角（记为 $\boldsymbol{\epsilon}_\phi(\mathbf{x}_s, s)$）也有效，由式 (2.2.2.21) 的关系

$$\mathbf{x}_s = \alpha_s \mathbf{x}_\phi(\mathbf{x}_s, s) + \sigma_s \boldsymbol{\epsilon}_\phi(\mathbf{x}_s, s), \qquad \text{对任意给定} \mathbf{x}_s \sim q_s. \tag{4.4.4.217}$$

[19]该恒等式通过把 s 视为一般更早时间自然推广到连续时间。

建模与扩散损失 $\mathcal{L}_{\text{diffusion}}$. 与 DDPM 类似，式 (4.4.4.214) 中的条件分布 $p(\mathbf{x}_t \mid \mathbf{x}_s, \mathbf{x})$ 启发我们用可学习预测器 $\mathbf{x}_\phi(\mathbf{x}_s, s)$ 替换干净信号 $\mathbf{x}$，得到参数化反向模型：

$$p_\phi(\mathbf{x}_t \mid \mathbf{x}_s) := \mathcal{N}\big(\mathbf{x}_t; \boldsymbol{\mu}_\phi(\mathbf{x}_s, s, t), \sigma^2(s,t)\mathbf{I}\big), \tag{4.4.4.218}$$

其中均值参数化为

$$\boldsymbol{\mu}_\phi(\mathbf{x}_s, s, t) = \frac{\alpha_{s|t}\sigma_{t|s}^2}{\sigma_s^2}\mathbf{x}_s + \frac{\alpha_t \sigma_{s|t}^2}{\sigma_s^2}\mathbf{x}_\phi(\mathbf{x}_s, s). \tag{4.4.4.219}$$

给定式 (4.4.4.203) 的前向核，$\mathcal{L}_{\text{diffusion}}(\mathbf{x}; \phi)$ 中的 KL 散度退化为加权回归损失：

$$\begin{aligned}\mathcal{D}_{\text{KL}}(p(\mathbf{x}_t \mid \mathbf{x}_s, \mathbf{x}_0) \| p_\phi(\mathbf{x}_t \mid \mathbf{x}_s)) &= \frac{1}{2\sigma^2(s,t)} \|\boldsymbol{\mu}(\mathbf{x}_s, \mathbf{x}_0; s, t) - \boldsymbol{\mu}_\phi(\mathbf{x}_s, s, t)\|_2^2 \\ &= \tfrac{1}{2}\big(\text{SNR}(t) - \text{SNR}(s)\big)\|\mathbf{x}_0 - \mathbf{x}_\phi(\mathbf{x}_s, s)\|_2^2,\end{aligned} \tag{4.4.4.220}$$

其中 $\mathbf{x}_s = \alpha_s \mathbf{x}_0 + \sigma_s \boldsymbol{\epsilon}$，$\mathbf{x}_0 \sim p_{\text{data}}$，$\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$，$\text{SNR}(s) := \alpha_s^2/\sigma_s^2$ 表示时刻 s 的信噪比.

注 4.4.3 (连续时间极限)**：** 在 Kingma 等（2021）中，作者研究式上式在 $t \to s$ 时的连续时间极限，得到

$$\mathcal{L}_{\text{VDM}}^{\infty}(\mathbf{x}_0) = -\frac{1}{2}\mathbb{E}_{s, \boldsymbol{\epsilon}\sim\mathcal{N}(\mathbf{0},\mathbf{I})}\,\text{SNR}'(s)\|\mathbf{x}_0 - \mathbf{x}_\phi(\mathbf{x}_s, s)\|_2^2. \tag{4.4.4.221}$$

该设定还引入可学习噪声调度；虽然它推广到连续数据之外，但此类扩展超出当前讨论范围. ◇

采样. 采样与 DDPM 类似，使用式 (4.4.4.218) 的参数化核：

$$\mathbf{x}_t = \underbrace{\frac{\alpha_{s|t}\sigma_{t|s}^2}{\sigma_s^2}\mathbf{x}_s + \frac{\alpha_t\sigma_{s|t}^2}{\sigma_s^2}\mathbf{x}_{\phi^\times}(\mathbf{x}_s, s)}_{\boldsymbol{\mu}_{\phi^\times}(\mathbf{x}_s, t, s)} + \sigma_{s|t}\frac{\sigma_t}{\sigma_s}\boldsymbol{\epsilon}_s, \qquad \boldsymbol{\epsilon}_s \sim \mathcal{N}(\mathbf{0}, \mathbf{I}). \tag{4.4.4.222}$$

4.5 （可选）经边缘化与 Bayes 规则的 Fokker–Planck 方程与反向时间 SDE

本节从概率论视角给出 Fokker–Planck 方程与反向时间 SDE 结构的直观理解。通过利用边缘化技巧与 Bayes 规则等基本工具，我们阐明随机过程的统计表述与对应微分方程之间的联系.

我们强调：这里给出的 “推导” 不是数学严格证明，而是旨在传达底层联系的启发式论证.

4.5.1 从转移核的边缘化导出 Fokker–Planck 方程

给定式 (4.4.1.107) 的前向转移概率

$$p(\mathbf{x}_{t+\Delta t} \mid \mathbf{x}_t) = \mathcal{N}\big(\mathbf{x}_{t+\Delta t}; \mathbf{x}_t + \mathbf{f}(\mathbf{x}_t, t)\Delta t,\, g^2(t)\Delta t\,\mathbf{I}\big), \tag{4.4.5.223}$$

以及边缘分布

$$p_t(\mathbf{x}_t), \qquad p_{t+\Delta t}(\mathbf{x}_{t+\Delta t}), \tag{4.4.5.224}$$

我们旨在导出支配边缘分布 p_t 时间演化的 Fokker–Planck 方程.

变量替换. 由 Markov 性质，时刻 $t+\Delta t$ 的边缘分布可表示为对先前状态 $\mathbf{x}_t$ 的积分（即 Chapman–Kolmogorov 方程）：

$$p_{t+\Delta t}(\mathbf{x}) = \int \mathcal{N}\big(\mathbf{x}; \mathbf{y} + \mathbf{f}(\mathbf{y}, t)\Delta t,\, g^2(t)\Delta t\, \mathbf{I}\big)\, p_t(\mathbf{y})\, \mathrm{d}\mathbf{y}. \tag{4.4.5.225}$$

引入新变量

$$\mathbf{u} := \mathbf{y} + \mathbf{f}(\mathbf{y}, t)\Delta t, \tag{4.4.5.226}$$

于是 Gaussian 中心在 $\mathbf{u}$。对小 Δt，该映射可逆：

$$\mathbf{y} = \mathbf{u} - \mathbf{f}(\mathbf{u}, t)\Delta t + \mathcal{O}(\Delta t^2), \qquad \left|\det \frac{\partial \mathbf{y}}{\partial \mathbf{u}}\right| = 1 - (\nabla_{\mathbf{u}} \cdot \mathbf{f})(\mathbf{u}, t)\Delta t + \mathcal{O}(\Delta t^2). \tag{4.4.5.227}$$

因此变量替换公式给出：

$$p_{t+\Delta t}(\mathbf{x}) = \int \mathcal{N}\big(\mathbf{x}; \mathbf{u}, g^2(t)\Delta t\, \mathbf{I}\big) \cdot \Big[p_t(\mathbf{u}) - \Delta t\, \mathbf{f}(\mathbf{u}, t) \cdot \nabla_{\mathbf{u}} p_t(\mathbf{u}) - \Delta t (\nabla_{\mathbf{u}} \cdot \mathbf{f})(\mathbf{u}, t) p_t(\mathbf{u})\Big]\, \mathrm{d}\mathbf{u} + \mathcal{O}(\Delta t^2).$$

Taylor 展开. 对任意光滑函数 $\phi : \mathbb{R}^D \to \mathbb{R}$ 与尺度 $\sigma > 0$，若 $\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$，则有如下逼近（称为 Taylor–Gaussian 平滑公式）：

$$\int \mathcal{N}(\mathbf{x}; \mathbf{u}, \sigma^2 \mathbf{I}) \phi(\mathbf{u})\, \mathrm{d}\mathbf{u} = \mathbb{E}[\phi(\mathbf{x} + \sigma \mathbf{z})] = \phi(\mathbf{x}) + \frac{\sigma^2}{2} \Delta_{\mathbf{x}} \phi(\mathbf{x}) + \mathcal{O}(\sigma^4). \tag{4.4.5.228}$$

这是因为

$$\phi(\mathbf{x} + \sigma \mathbf{z}) = \phi(\mathbf{x}) + \sigma \nabla_{\mathbf{x}} \phi(\mathbf{x}) \cdot \mathbf{z} + \frac{\sigma^2}{2} \mathbf{z}^\top \nabla_{\mathbf{x}}^2 \phi(\mathbf{x}) \mathbf{z} + \mathcal{O}(\sigma^3), \tag{4.4.5.229}$$

且 $\mathbb{E}[\mathbf{z}] = \mathbf{0}$、$\mathbb{E}[\mathbf{z}\mathbf{z}^\top] = \mathbf{I}$.

代入 $\phi = p_t$、$\phi = \mathbf{f} \cdot \nabla_{\mathbf{u}} p_t$、$\phi = (\nabla_{\mathbf{u}} \cdot \mathbf{f}) p_t$，并取 $\sigma^2 = g^2(t)\Delta t$，得

$$\begin{aligned} p_{t+\Delta t}(\mathbf{x}) - p_t(\mathbf{x}) &= -\Delta t\, \mathbf{f}(\mathbf{x}, t) \cdot \nabla_{\mathbf{x}} p_t(\mathbf{x}) - \Delta t (\nabla_{\mathbf{x}} \cdot \mathbf{f})(\mathbf{x}, t) p_t(\mathbf{x}) \\ &\quad + \frac{g^2(t)}{2} \Delta t\, \Delta_{\mathbf{x}} p_t(\mathbf{x}) + \mathcal{O}(\Delta t^2) \\ &= -\Delta t\, \nabla_{\mathbf{x}} \cdot [\mathbf{f}(\mathbf{x}, t) p_t(\mathbf{x})] + \frac{g^2(t)}{2} \Delta t\, \Delta_{\mathbf{x}} p_t(\mathbf{x}) + \mathcal{O}(\Delta t^2). \end{aligned}$$

除以 Δt 并令 $\Delta t \to 0$，得到 Fokker–Planck 方程.

在附录 C.1.4 中，我们给出基于 Itô 的推导，补充上述离散时间视角.

4.5.2 反向时间 SDE 为何取此形式？

反向时间 SDE 的严格推导技术性强，需要深入研究 Fokker–Planck 方程的性质。然而反向时间 SDE 的形式可通过 Bayes 规则直观理解。这里我们给出启发式推导，说明式 (4.4.1.119) 为何取其形式、为何出现分数函数[20].

用 Bayes 规则做反转. 我们的目标是通过先考虑离散时间情形确定反向时间转移核：

$$p(\mathbf{x}_t \mid \mathbf{x}_{t+\Delta t}), \tag{4.4.5.230}$$

再取 $\Delta t \to 0$ 得到连续时间表述。用 Bayes 定理表达：

$$\begin{aligned} p(\mathbf{x}_t \mid \mathbf{x}_{t+\Delta t}) &= p(\mathbf{x}_{t+\Delta t} \mid \mathbf{x}_t) \frac{p_t(\mathbf{x}_t)}{p_{t+\Delta t}(\mathbf{x}_{t+\Delta t})} \\ &= p(\mathbf{x}_{t+\Delta t} \mid \mathbf{x}_t) \exp\big(\log p_t(\mathbf{x}_t) - \log p_{t+\Delta t}(\mathbf{x}_{t+\Delta t})\big). \end{aligned} \tag{4.4.5.231}$$

前向转移核假设如式 (4.4.1.107)：

$$p(\mathbf{x}_{t+\Delta t} \mid \mathbf{x}_t) = \mathcal{N}\big(\mathbf{x}_{t+\Delta t}; \mathbf{x}_t + \mathbf{f}(\mathbf{x}_t, t)\Delta t,\, g^2(t)\Delta t\, \mathbf{I}\big). \tag{4.4.5.232}$$

Taylor 展开. 为处理指数项，我们应用一阶 Taylor 展开。关键洞见是在空间与时间上都绕点 $(\mathbf{x}_t, t)$ 展开：

$$\log p_{t+\Delta t}(\mathbf{x}_{t+\Delta t}) = \log p_t(\mathbf{x}_t) + \nabla_{\mathbf{x}} \log p_t(\mathbf{x}_t) \cdot (\mathbf{x}_{t+\Delta t} - \mathbf{x}_t) + \frac{\partial \log p_t(\mathbf{x}_t)}{\partial t}\Delta t + \mathcal{O}(\|\mathbf{h}\|_2^2), \tag{4.4.5.233}$$

其中 $\mathbf{h} := (\mathbf{x}_{t+\Delta t} - \mathbf{x}_t, \Delta t)$。因此：

$$\log p_t(\mathbf{x}_t) - \log p_{t+\Delta t}(\mathbf{x}_{t+\Delta t}) = -\nabla_{\mathbf{x}} \log p_t(\mathbf{x}_t) \cdot (\mathbf{x}_{t+\Delta t} - \mathbf{x}_t) - \frac{\partial \log p_t(\mathbf{x}_t)}{\partial t}\Delta t + \mathcal{O}(\|\mathbf{h}\|_2^2). \tag{4.4.5.234}$$

对具有有限漂移与扩散的前向过程，$\mathbb{E}[\|\mathbf{x}_{t+\Delta t} - \mathbf{x}_t\|_2^2] = \mathcal{O}(\Delta t)$，这保证余项在期望上是 $\mathcal{O}((\Delta t)^2)$.

代入反向转移. 把式 (4.4.1.107) 与上式代入：

$$\begin{aligned} p(\mathbf{x}_t \mid \mathbf{x}_{t+\Delta t}) = \frac{1}{(2\pi g^2(t)\Delta t)^{D/2}} \exp\Big(- \frac{\|\mathbf{x}_{t+\Delta t} - \mathbf{x}_t - \mathbf{f}(\mathbf{x}_t, t)\Delta t\|_2^2}{2g^2(t)\Delta t} \Big) \\ \cdot \exp\Big(- \nabla_{\mathbf{x}} \log p_t(\mathbf{x}_t) \cdot (\mathbf{x}_{t+\Delta t} - \mathbf{x}_t) - \frac{\partial \log p_t(\mathbf{x}_t)}{\partial t}\Delta t + \mathcal{O}((\Delta t)^2) \Big). \end{aligned}$$

[20]本推导受该博文方法启发。

代数操作. 关键步骤是在指数中配方。有：

$$
\begin{aligned}
&-\frac{\|\mathbf{x}_{t+\Delta t}-\mathbf{x}_t-\mathbf{f}(\mathbf{x}_t,t)\Delta t\|_2^2}{2g^2(t)\Delta t}-\nabla_{\mathbf{x}}\log p_t(\mathbf{x}_t)\cdot(\mathbf{x}_{t+\Delta t}-\mathbf{x}_t)\\
&=-\frac{\big[\|\mathbf{x}_{t+\Delta t}-\mathbf{x}_t-\mathbf{f}(\mathbf{x}_t,t)\Delta t\|_2^2+2g^2(t)\Delta t\,\nabla_{\mathbf{x}}\log p_t(\mathbf{x}_t)\cdot(\mathbf{x}_{t+\Delta t}-\mathbf{x}_t)\big]}{2g^2(t)\Delta t}.
\end{aligned}
$$

令 $\boldsymbol{\delta}:=\mathbf{x}_{t+\Delta t}-\mathbf{x}_t$、$\boldsymbol{\mu}:=\mathbf{f}(\mathbf{x}_t,t)\Delta t$。则：

$$
\begin{aligned}
&\|\boldsymbol{\delta}-\boldsymbol{\mu}\|_2^2+2g^2(t)\Delta t\,\nabla_{\mathbf{x}}\log p_t(\mathbf{x}_t)\cdot\boldsymbol{\delta}\\
&=\|\boldsymbol{\delta}\|_2^2-2\boldsymbol{\delta}\cdot\boldsymbol{\mu}+\|\boldsymbol{\mu}\|_2^2+2g^2(t)\Delta t\,\nabla_{\mathbf{x}}\log p_t(\mathbf{x}_t)\cdot\boldsymbol{\delta}\\
&=\|\boldsymbol{\delta}\|_2^2-2\boldsymbol{\delta}\cdot[\boldsymbol{\mu}-g^2(t)\Delta t\,\nabla_{\mathbf{x}}\log p_t(\mathbf{x}_t)]+\|\boldsymbol{\mu}\|_2^2\\
&=\|\boldsymbol{\delta}-[\boldsymbol{\mu}-g^2(t)\Delta t\,\nabla_{\mathbf{x}}\log p_t(\mathbf{x}_t)]\|_2^2-\|g^2(t)\Delta t\,\nabla_{\mathbf{x}}\log p_t(\mathbf{x}_t)\|_2^2.
\end{aligned}
$$

代回：

$$
\|\boldsymbol{\delta}-[\mathbf{f}(\mathbf{x}_t,t)\Delta t-g^2(t)\Delta t\,\nabla_{\mathbf{x}}\log p_t(\mathbf{x}_t)]\|_2^2=\|\mathbf{x}_{t+\Delta t}-\mathbf{x}_t-[\mathbf{f}(\mathbf{x}_t,t)-g^2(t)\nabla_{\mathbf{x}}\log p_t(\mathbf{x}_t)]\Delta t\|_2^2.
$$

因此

$$
\begin{aligned}
p(\mathbf{x}_t\mid\mathbf{x}_{t+\Delta t})=&\frac{1}{(2\pi g^2(t)\Delta t)^{D/2}}\\
&\cdot\exp\Big(-\frac{\|\mathbf{x}_{t+\Delta t}-\mathbf{x}_t-[\mathbf{f}(\mathbf{x}_t,t)-g^2(t)\nabla_{\mathbf{x}}\log p_t(\mathbf{x}_t)]\Delta t\|_2^2}{2g^2(t)\Delta t}\Big)\\
&\cdot\exp(\mathcal{O}(\Delta t))\\
=&\,\mathcal{N}\big(\mathbf{x}_t;\mathbf{x}_{t+\Delta t}-[\mathbf{f}(\mathbf{x}_t,t)-g^2(t)\nabla_{\mathbf{x}}\log p_t(\mathbf{x}_t)]\Delta t,\,g^2(t)\Delta t\,\mathbf{I}\big)\\
&\cdot(1+\mathcal{O}(\Delta t)).
\end{aligned}
$$

配方得到的附加项 $\|g^2(t)\Delta t\,\nabla_{\mathbf{x}}\log p_t(\mathbf{x}_t)\|_2^2$ 是 $\mathcal{O}((\Delta t)^2)$，可吸收到误差项。类似地，时间导数项 $\frac{\partial\log p_t(\mathbf{x}_t)}{\partial t}\Delta t$ 是 $\mathcal{O}(\Delta t)$，在连续极限下消失.

取 $\Delta t\to 0$ 极限. 当 $\Delta t\approx 0$，在光滑性假设下有如下逼近：

$$
\begin{aligned}
\mathbf{f}(\mathbf{x}_t,t)&\approx\mathbf{f}(\mathbf{x}_{t+\Delta t},t+\Delta t),\\
g(t)&\approx g(t+\Delta t),\\
\nabla_{\mathbf{x}}\log p_t(\mathbf{x}_t)&\approx\nabla_{\mathbf{x}}\log p_{t+\Delta t}(\mathbf{x}_{t+\Delta t})=\mathbf{s}(\mathbf{x}_{t+\Delta t},t+\Delta t).
\end{aligned}
$$

用这些逼近与一些整理，得：

$$
p(\mathbf{x}_t\mid\mathbf{x}_{t+\Delta t})\approx\frac{1}{(2\pi g^2(t)\Delta t)^{D/2}}\exp\left(-\frac{\Big\|\mathbf{x}_t-\Big(\mathbf{x}_{t+\Delta t}-[\mathbf{f}(\mathbf{x}_{t+\Delta t},t+\Delta t)-g^2(t+\Delta t)\mathbf{s}(\mathbf{x}_{t+\Delta t},t+\Delta t)]\Delta t\Big)\Big\|_2^2}{2g^2(t+\Delta t)\Delta t}\right).
$$

这意味着 $p(\mathbf{x}_t\mid\mathbf{x}_{t+\Delta t})$ 近似一个正态分布：

- 均值：$\mathbf{x}_{t+\Delta t} - [\mathbf{f}(\mathbf{x}_{t+\Delta t}, t+\Delta t) - g^2(t+\Delta t)\mathbf{s}(\mathbf{x}_{t+\Delta t}, t+\Delta t)]\Delta t$；
- 协方差：$g^2(t+\Delta t)\Delta t\,\mathbf{I}$.

取 $\Delta t \to 0$ 极限，我们 “推导” 出式 (4.4.1.119) 给出的反向时间连续 SDE.

4.6 结语

本章标志我们旅程中的关键时刻：把变分视角与基于分数视角的离散时间扩散过程统一为单一优雅的连续时间框架。我们证明 DDPM 与 NCSN 都可理解为具有不同漂移/波动系数的随机微分方程（SDE）的离散化.

这一框架的基石是相应反向时间 SDE 的存在，它形式上定义了一个反转噪声污染的生成过程。关键在于，该反向过程的漂移依赖一个未知量：每个时刻边缘数据分布的分数函数 $\nabla_{\mathbf{x}} \log p_t(\mathbf{x})$。这一洞见巩固了分数函数在生成建模中的核心地位.

进一步，我们引入纯确定性对应——概率流常微分方程（PF-ODE），其解轨迹演化出与 SDE 相同的边缘密度 $\{p_t\}$。这种非凡一致性由底层 Fokker–Planck 方程保证。其深刻含义是：复杂的生成任务本质上等价于求解微分方程。训练归结为学习定义方程向量场的分数函数，而采样成为数值积分问题.

PF-ODE（纯确定性流）的引入为通往扩散模型的第三也是最终视角架起了桥梁。这一学习由速度场控制的确定性变换的概念，是近期一大类生成模型的核心原理。下一章我们将：

1. 探索这一流视角，从其在归一化流与神经常微分方程中的起源出发；
2. 展示这一视角如何通向现代 Flow Matching 框架，它直接学习速度场以在分布间传输样本.

最终，我们将看到：从随机原理导出的确定性 PF-ODE，如何能够从这一完全不同的、基于流的起源被构造与推广，从而完成我们对扩散建模的统一图景.

Chapter 5

流视角：从归一化流到流匹配

万物皆流。

—*Heraclitus*

换元公式（change-of-variables formula）是概率论的基石之一（Tabak 与 Vanden-Eijnden, 2010；Turner, 2013），在现代生成建模中焕发了新的生命力。Score SDE 通过 Fokker–Planck 方程（第 4 4.1.5 节）为数据分布与先验分布之间架起了一座微分方程的桥梁；而这种连续演化，本质上正是同一基本原理的动态形式.

密度的换元公式. 给定一个可逆变换 $\mathbf{f}$，当 $\mathbf{z} \sim p_{\text{prior}}$ 时，$\mathbf{x} = \mathbf{f}(\mathbf{z})$ 的密度为：

$$p(\mathbf{x}) = p_{\text{prior}}(\mathbf{z}) \left| \det \frac{\partial \mathbf{f}^{-1}(\mathbf{x})}{\partial \mathbf{x}} \right|, \qquad \text{其中} \mathbf{z} = \mathbf{f}^{-1}(\mathbf{x}). \tag{5.5.0.235}$$

这一看似简单的公式在 $\mathbf{f}$ 易于处理时，可以实现密度与样本之间精确、双向的传输，构成了我们将在 5.1.1 节中介绍的归一化流（Normalizing Flow, NF）的基石. 但是，如果我们透过连续时间变换的视角重新审视这一思想呢?

本章将围绕这一核心原理，探索扩散模型的一个全新视角：流匹配（Flow Matching, FM，见 5.2 节）. 它自然地从（连续）归一化流中生长出来，使我们更深刻地理解扩散作为一种强大的密度传输过程.

为帮助读者牢固掌握本章内容，我们在附录 B 中给出了换元公式各种形式的直观、自包含的综述，从最简单的情形逐步推进到连续性方程，最后到 Fokker–Planck 方程.

5.1 基于流的模型：归一化流与神经常微分方程

本节介绍基于流的模型，包括归一化流（NF，Rezende 与 Mohamed, 2015）和神经常微分方程（Neural ODE,NODE，Chen 等, 2018）.

NF 通过一系列可逆变换将数据映射到简单的基底分布上，从而实现灵活且易处理的概率密度估计. NODE 把这一框架推广到连续时间，变换由一个 ODE 控制. 通过把变换视作连续时间动力学，NODE 为 NF 范式提供了平滑、可扩展的推广.

5.1.1 归一化流

归一化流（Rezende 与 Mohamed, 2015）通过一个可逆映射

$$\mathbf{f}_\phi : \mathbb{R}^D \to \mathbb{R}^D,$$

将简单先验 $p_{\text{prior}}(\mathbf{z})$（例如标准 Gauss 分布 $\mathcal{N}(\mathbf{0}, \mathbf{I})$）变换为复杂的数据分布 $p_{\text{data}}(\mathbf{x})$，其中 $\mathbf{x} = \mathbf{f}_\phi(\mathbf{z})$，$\mathbf{z} \sim p_{\text{prior}}$. 这里 $\mathbf{x}$ 与 $\mathbf{z}$ 维数相同. 利用换元公式 (5.5.0.235)，模型似然

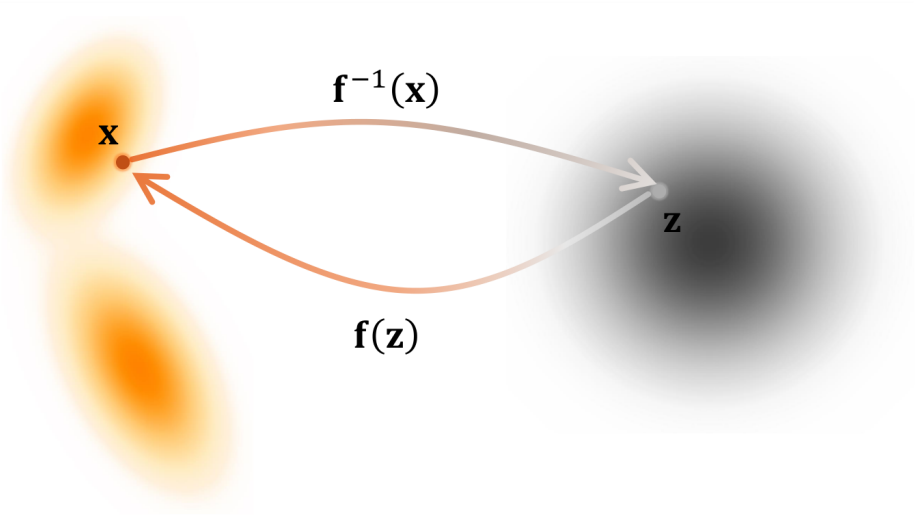


图 5.24: 可逆映射下 NF 样本移动示意图. 它由一系列可逆函数 $\mathbf{f}: \mathbf{z} \mapsto \mathbf{x}$ 组成，将隐变量 $\mathbf{z}$ 变换为数据 $\mathbf{x}$；并伴有逆映射 $\mathbf{f}^{-1}: \mathbf{x} \mapsto \mathbf{z}$ 用于重构数据. NF 类似于编码器–解码器结构，但编码器是一个平滑可逆映射，解码器恰为其逆. 相应的密度变化可由换元公式 (5.5.0.235) 计算.

为[21]

$$\log p_\phi(\mathbf{x}) = \log p_{\text{prior}}(\mathbf{z}) + \log \left| \det \frac{\partial \mathbf{f}_\phi^{-1}(\mathbf{x})}{\partial \mathbf{x}} \right|. \tag{5.5.1.236}$$

训练目标. 参数 ϕ 通过最大化数据上的似然来学习：

$$\mathcal{L}_{\text{NF}}(\phi) = \mathbb{E}_{\mathbf{x}\sim p_{\text{data}}} \left[\log p_\phi(\mathbf{x}) \right]. \tag{5.5.1.237}$$

一般而言，计算 (5.5.1.236) 中的 Jacobi 行列式代价高昂，复杂度为 $\mathcal{O}(D^3)$.

构造可逆变换. 单个复杂可逆网络因其 Jacobi 行列式而代价高昂；反之，简单变换（如线性）虽然高效却缺乏表达能力.

为取得平衡，NF 采用 K 个可训练可逆映射堆叠 $\{\mathbf{f}_k\}_{k=0}^{L-1}$，每个映射的 Jacobi 都易于计算：

$$\mathbf{f}_\phi = \mathbf{f}_{L-1} \circ \mathbf{f}_{L-2} \circ \cdots \circ \mathbf{f}_0.$$

每个 $\mathbf{f}_k$ 由神经网络参数化，为记号简洁我们省略对 ϕ 的显式依赖.

样本经以下变换：

$$\mathbf{x}_{k+1} = \mathbf{f}_k(\mathbf{x}_k), \qquad k = 0, \ldots, L-1, \tag{5.5.1.238}$$

[21]若进一步要求映射是凸势函数的梯度，即 $\mathbf{f}_\phi = \nabla \psi_\phi$ 且 ψ_ϕ 凸，则 (5.5.0.235) 退化为 (7.7.2.293) 节中的 Monge–Ampère 关系. 该 PDE 刻画了在二次代价下一个分布到另一个分布的最优变换，详见第 7 章与（Huang 等, 2021）.

其中 $\mathbf{z}=\mathbf{x}_0\sim p_{\text{prior}}$，$\mathbf{x}=\mathbf{x}_L$ 对应数据. 由此得到的（对数）密度为

$$p_\phi(\mathbf{x})=p_{\text{prior}}(\mathbf{x}_0)\prod_{k=0}^{L-1}\left|\det\frac{\partial\mathbf{f}_k}{\partial\mathbf{x}_k}\right|^{-1},\quad \text{或等价地，}\quad \log p_\phi(\mathbf{x})=\log p_{\text{prior}}(\mathbf{x}_0)+\sum_{k=0}^{L-1}\log\left|\det\frac{\partial\mathbf{f}_k}{\partial\mathbf{x}_k}\right|^{-1}. \tag{5.5.1.239}$$

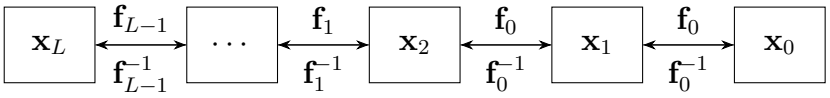


图 5.25: NF 结构示意图. NF 由可逆映射栈 $\mathbf{f}_\phi=\mathbf{f}_{L-1}\circ\mathbf{f}_{L-2}\circ\cdots\circ\mathbf{f}_0$ 构成. 该映射将隐样本 $\mathbf{x}_0\sim p_{\text{prior}}$ 变换为数据样本 $\mathbf{x}_L\sim p_{\text{data}}$.

可逆流示例. 已有大量文献聚焦于设计能高效计算 Jacobi 的单层流结构. 下面介绍两类代表性构造：平面流（Planar Flow，Rezende 与 Mohamed, 2015）与残差流（Residual Flow，Chen 等, 2019；Behrmann 等, 2019），后者直接启发了 5.1.2 节.

平面流：它施加一个简单变换

$$\mathbf{f}(\mathbf{z})=\mathbf{z}+\mathbf{u}\,h(\mathbf{w}^\top\mathbf{z}+b),$$

其中 $\mathbf{u},\mathbf{w}\in\mathbb{R}^D$，$b\in\mathbb{R}$，$h(\cdot)$ 为激活函数. Jacobi 行列式为

$$\left|1+\mathbf{u}^\top h'(\mathbf{w}^\top\mathbf{z}+b)\mathbf{w}\right|.$$

残差流：定义变换 $\mathbf{f}$ 为

$$\mathbf{f}(\mathbf{z})=\mathbf{z}+\mathbf{v}(\mathbf{z}), \tag{5.5.1.240}$$

其中 $\mathbf{v}$ 是压缩的（Lipschitz 常数 <1）. 这由 Banach 不动点定理保证可逆性.

Jacobi 的对数行列式可展开为迹级数：

$$\begin{aligned}\log\left|\det\frac{\partial\mathbf{f}(\mathbf{z})}{\partial\mathbf{z}}\right|&=\log\left(\det\frac{\partial\mathbf{f}(\mathbf{z})}{\partial\mathbf{z}}\right)\\&=\operatorname{Tr}\left(\log\left(\frac{\partial\mathbf{f}(\mathbf{z})}{\partial\mathbf{z}}\right)\right)\\&=\operatorname{Tr}\left(\log\left(\mathbf{I}+\frac{\partial\mathbf{v}(\mathbf{z})}{\partial\mathbf{z}}\right)\right)\\&=\sum_{k=1}^{\infty}\frac{(-1)^{k+1}}{k}\operatorname{Tr}\left(\left(\frac{\partial\mathbf{v}(\mathbf{z})}{\partial\mathbf{z}}\right)^k\right),\end{aligned} \tag{5.5.1.241}$$

利用迹估计子（Hutchinson, 1989）可高效计算.

采样与推断. NF 的采样十分直接：抽取 $\mathbf{x}_0\sim p_{\text{prior}}$，计算 $\mathbf{x}=\mathbf{f}_\phi(\mathbf{x}_0)$. 精确似然由 (5.5.1.239) 给出.

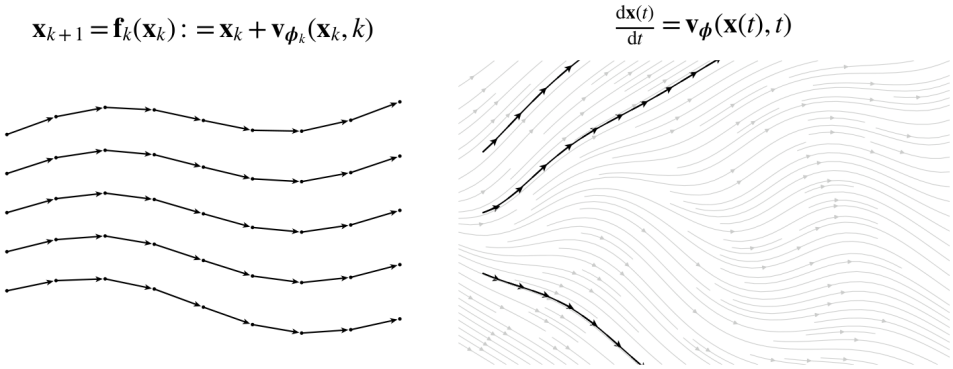


Figure 5.3: Discrete- vs. continuous-time normalizing flows. (Left) A discrete NF transports samples by a finite sequence of invertible maps $\mathbf{x}_{k+1} = \mathbf{f}_k(\mathbf{x}_k)$, yielding stepwise, non-crossing trajectories (dots with arrows). (Right) A continuous NF (Neural ODE) evolves states along integral curves of $\frac{d\mathbf{x}(t)}{dt} = \mathbf{v}_\phi(\mathbf{x}(t), t)$, where black paths with tangent arrows are shown over the gray vector field.

图 5.26: 离散时间与连续时间归一化流对比. 左: 离散 NF 通过有限可逆映射序列 $\mathbf{x}_{k+1} = \mathbf{f}_k(\mathbf{x}_k)$ 传输样本，得到阶梯式、不相交的轨迹（带箭头的点）. 右: 连续 NF (Neural ODE) 沿 $\dfrac{d\mathbf{x}(t)}{dt} = \mathbf{v}_\phi(\mathbf{x}(t), t)$ 的积分曲线演化状态，灰色向量场上叠加了带切向箭头的黑色路径.

5.1.2 神经常微分方程

从离散 NF 到连续 NF (Neural ODE). NF 通常被写成 L 个离散可逆变换的序列. 透过 (5.5.1.238) 与 (5.5.1.240) 式中 "残差流" 形式的视角，每层可写成:

$$\mathbf{x}_{k+1} = \mathbf{f}_k(\mathbf{x}_k) := \mathbf{x}_k + \mathbf{v}_{\phi_k}(\mathbf{x}_k, k),$$

其中 $\mathbf{v}_{\phi_k}(\cdot, k)$ 是与层相关的速度场，由神经网络参数化. 直观上，该速度场是一个学习到的向量值函数，在输入空间中以小而平滑的步长 "推动" 数据点. 每次变换沿速度所指方向移动点，逐步把简单先验分布形变为复杂目标分布.

事实上，这一表述正是以下连续时间 ODE 在可学习参数 ϕ 下的 Euler 离散化:

$$\frac{d\mathbf{x}(t)}{dt} = \mathbf{v}_\phi(\mathbf{x}(t), t).$$

在层数趋于无穷、步长趋于零 ($\Delta t \to 0$) 的极限下，离散 NF 收敛为连续模型，即神经 *ODE* (NODE, Chen 等, 2018)，又称连续归一化流 (Continuous Normalizing Flow, CNF) .

Neural ODE 的形式化设定. Neural ODE 通过下式定义连续变换:

$$\frac{d\mathbf{x}(t)}{dt} = \mathbf{v}_\phi(\mathbf{x}(t), t), \qquad t \in [0, T] \tag{5.5.1.242}$$

其中:

- $\mathbf{x}(t) \in \mathbb{R}^D$ 是 t 时刻的状态；有时简记为 $\mathbf{x}_t$；
- $\mathbf{v}_\phi(\mathbf{x}(t), t)$ 是由 ϕ 参数化的神经网络.

NODE 的目标. 从初值 $\mathbf{x}(0) \sim p_{\text{prior}}$ 出发，ODE 使状态随时间连续演化，诱导出一族边缘分布 $p_\phi(\mathbf{x}_t, t)$（类似于 PF-ODE[22]！）.

目标是学习神经向量场 $\mathbf{v}_\phi$，直观上它代表一个速度，在数据空间中沿连续轨迹传输点. 通过学习该速度，$t = 0$ 处的终端分布与目标分布 $p_{\text{data}}(\cdot)$ 匹配. 这一连续变换在统一框架下融合了离散归一化流与 Neural ODE.

连续时间换元公式. 与 (5.5.0.235) 或 (5.5.1.239) 类似，Chen 等（2018）推导了换元公式的连续时间版本. 对于按 (5.5.1.242) 演化的过程 $\mathbf{x}(t)$，其时间依赖密度 $p_\phi(\mathbf{x}(t), t)$ 满足所谓瞬时换元公式：

$$\frac{\mathrm{d}}{\mathrm{d}t} \log p_\phi(\mathbf{x}(t), t) = -\nabla_{\mathbf{x}} \cdot \mathbf{v}_\phi(\mathbf{x}(t), t).$$

因此，给定先验 $p_{\text{prior}}(\mathbf{x}(T), T)$，Neural ODE 诱导的终端状态 $\mathbf{x}(T)$ 的对数密度为

$$\log p_\phi(\mathbf{x}(T), T) = \log p_{\text{prior}}(\mathbf{x}(0), 0) - \int_0^T \nabla_{\mathbf{x}} \cdot \mathbf{v}_\phi(\mathbf{x}(t), t)\, \mathrm{d}t. \tag{5.5.1.243}$$

该表达式允许通过数值求解 ODE 来精确计算似然，进而对模型进行极大似然训练. 我们稍后将详细回到这一点.

虽然初看似乎陌生，但这一瞬时换元公式其实是 Fokker–Planck 方程的一个特例——其确定性形式即连续性方程（见附录 B）. 它也可视为 (5.5.1.239) 在连续时间下的极限. 我们把这一结果及其推导总结为以下引理：

引理 5.1.1 (瞬时换元公式)**：** 设 $\mathbf{z}(t)$ 是具有时间依赖密度 $p(\mathbf{z}(t), t)$ 的连续随机过程，并按 ODE

$$\frac{\mathrm{d}\mathbf{z}(t)}{\mathrm{d}t} = \mathbf{F}(\mathbf{z}(t), t)$$

演化. 假设 $\mathbf{F}$ 关于 $\mathbf{z}$ 一致 Lipschitz、关于 t 连续，则对数密度的时间导数满足：

$$\frac{\partial \log p(\mathbf{z}(t), t)}{\partial t} = -\nabla_{\mathbf{z}} \cdot \mathbf{F}(\mathbf{z}(t), t). \tag{5.5.1.244}$$

引理证明： 我们在附录 D.3 中给出两种等价推导. □

与离散时间公式的联系. NODE 似然 (5.5.1.243)

$$\log p_\phi(\mathbf{x}(T), T) = \log p_{\text{prior}}(\mathbf{x}(0), 0) - \int_0^T \nabla_{\mathbf{x}} \cdot \mathbf{v}_\phi(\mathbf{x}(t), t)\, \mathrm{d}t,$$

[22]我们采用翻转时间约定，$t = 0$ 表示先验（源），$t = 1$ 表示数据（目标）分布. 先验可互换地写作 $p_\phi(\mathbf{x}(0), 0)$、$p_{\text{prior}}(\mathbf{x}(0), 0)$ 或简记为 $p_{\text{prior}}(\mathbf{z})$.

可视为离散 NF (5.5.1.239) 的连续时间对应：

$$\log p_\phi(\mathbf{x}_L) = \log p_{\text{prior}}(\mathbf{x}_0) - \sum_{k=0}^{L-1} \log \left| \det \frac{\partial \mathbf{f}_k}{\partial \mathbf{x}_k} \right|.$$

积分对应求和，迹算子替代对数行列式，如 (5.5.1.241) 所述. 这些对应关系将在引理证明中进一步展开.

训练 NODE. 基于 (5.5.1.243)，NODE 学习参数化速度场 $\mathbf{v}_\phi$，使终端分布

$$p_\phi(\cdot, T) \approx p_{\text{data}},$$

其中轨迹由隐变量 $\mathbf{x}(0) \sim p_{\text{prior}}$ 经 ODE 流演化而来. 训练遵循 (3.3.1.26) 式的 MLE 框架：

$$\mathcal{L}_{\text{NODE}}(\phi) := \mathbb{E}_{\mathbf{x} \sim p_{\text{data}}} \left[\log p_\phi(\mathbf{x}, T) \right].$$

精确对数似然计算. 为给数据点 $\mathbf{x}$ 计算 $\log p_\phi(\mathbf{x}, T)$，我们对换元公式 (5.5.1.243) 积分：

$$\log p_\phi(\mathbf{x}, T) = \log p_{\text{prior}}(\mathbf{z}(0)) - \int_0^T \nabla_{\mathbf{z}} \cdot \mathbf{v}_\phi(\mathbf{z}(t), t) \, \mathrm{d}t. \tag{5.5.1.245}$$

这里 $\mathbf{z}(t)$ 从 $t = T$ 反向求解 ODE：

$$\frac{\mathrm{d}\mathbf{z}}{\mathrm{d}t} = \mathbf{v}_\phi(\mathbf{z}(t), t),$$

初值 $\mathbf{z}(T) = \mathbf{x}$. 对于标准分布，先验项 $\log p_{\text{prior}}(\mathbf{z}(0))$ 是易处理的. 这使得 Neural ODE 中基于似然的训练与评估成为可能.

基于梯度的优化. 最大化 $\mathcal{L}_{\text{NODE}}$ 需要通过 ODE 求解器反向传播. 伴随灵敏度法（Pontryagin, 2018；Chen 等, 2018）以 $\mathcal{O}(1)$ 内存复杂度计算梯度，但由于每步都要数值积分，NODE 训练依然昂贵.

NODE 推断. 用训练好的模型 $\mathbf{v}_{\phi^\times}$ 采样时，抽取 $\mathbf{x}(0) \sim p_{\text{prior}}$，前向积分（用数值求解器）：

$$\mathbf{x}(T) = \mathbf{x}(0) + \int_0^T \mathbf{v}_{\phi^\times}(\mathbf{x}(t), t) \, \mathrm{d}t.$$

终端状态 $\mathbf{x}(T)$ 近似为 p_{data} 的样本.

此外，对任意向量场 $\mathbf{F}$，有恒等式：

$$\operatorname{Tr}\left(\frac{\partial \mathbf{F}}{\partial \mathbf{z}(t)} \right) = \nabla_{\mathbf{z}} \cdot \mathbf{F}.$$

因此散度可通过随机迹估计子（如 Hutchinson 估计子，Hutchinson, 1989）高效估计，使高维场景下的精确似然计算更易处理.

5.2 流匹配框架

Score SDE（第 4 章）与 NODE（5.1.2 节）为生成建模提供了另一种视角：学习一个连续时间流（随机或确定性），将简单 Gauss 先验样本 $\boldsymbol{\epsilon} \sim p_{\text{prior}}$ 传输为类似数据的样本.

流匹配（Flow Matching, FM，Lipman 等, 2022；Lipman 等, 2024；Tong 等, 2024）在此基础上推广：学习在两个任意固定端点分布之间的流——源分布 p_{src} 与目标分布 p_{tgt}，两者都假定易于采样. 生成任务成为其特例：p_{src} 是 Gauss 先验，p_{tgt} 是数据分布.

本节我们采用 FM 视角[23]，强调其核心原理：学习一个时间依赖向量场 $\mathbf{v}_t(\mathbf{x}_t)$，使其关联 ODE 流匹配预先给定的概率路径 $\{p_t\}_{t\in[0,1]}$，并满足边界条件

$$p_0 = p_{\text{src}}, \qquad p_1 = p_{\text{tgt}}.$$

当 p_{src} 为 Gauss 时，我们称之为 *Gauss* 流匹配. 与经典扩散模型相比，FM 仅需从端点采样，即可为一大类传输问题提供高效、免模拟的训练.

5.2.1 从基于分数的方法中得到的启示

我们重访 Score SDE 框架（第 4 章），使用一种略有不同但等价的表述，以提取启发 FM 的关键洞见. 这一分析揭示扩散模型如何隐式学习概率流，并启发更直接的表述.

第一步：定义条件路径及其边缘密度. 扩散模型指定一族连续时间密度 $\{p_t\}_{t\in[0,1]}$，它把 $t = 1$ 处用作源的简单先验 p_{prior}（如 Gauss）传输到 $t = 0$ 处的目标数据分布 p_{data}：

$$p_1(\mathbf{x}_1) = p_{\text{prior}}(\mathbf{x}_1), \qquad p_0(\mathbf{x}_0) = p_{\text{data}}(\mathbf{x}_0).$$

该路径由前向条件分布隐式定义：

$$p_t(\mathbf{x}_t \mid \mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t; \alpha_t \mathbf{x}_0, \sigma_t^2 \mathbf{I}), \qquad \mathbf{x}_0 \sim p_{\text{data}} \tag{5.5.2.246}$$

诱导出边缘密度

$$p_t(\mathbf{x}_t) := \int p_t(\mathbf{x}_t \mid \mathbf{x}_0) p_{\text{data}}(\mathbf{x}_0)\, \mathrm{d}\mathbf{x}_0.$$

条件 Gauss 的递增方差 σ_t^2 驱动 p_t 向 Gauss 先验演化.

第二步：速度场. 边缘密度 p_t 的时间演化由速度场 $\mathbf{v}_t : \mathbb{R}^D \to \mathbb{R}^D$ 控制，由 Fokker–Planck 方程导出：

$$\mathbf{v}_t(\mathbf{x}) := f(t)\mathbf{x} - \tfrac{1}{2} g^2(t) \nabla_{\mathbf{x}} \log p_t(\mathbf{x}), \tag{5.5.2.247}$$

[23]若干相关方法共享同一核心思想——用连续时间流在端点分布间传输——只是形式略有不同. 包括 FM（Lipman 等, 2022；Lipman 等, 2024；Neklyudov 等, 2023）、Rectified Flow（RF，Liu, 2022；Heitz 等, 2023）与 Stochastic Interpolants（Albergo 等, 2023；Albergo 与 Vanden-Eijnden, 2023；Ma 等, 2024）. 这里我们采用 FM 术语作为统一表述.

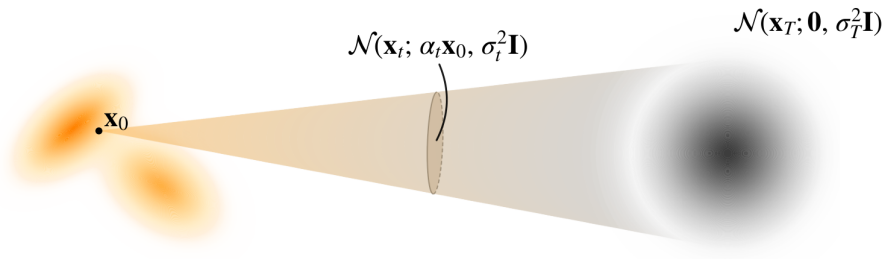


Figure 5.4: Illustration of the conditional transition distribution. $p_t(\mathbf{x}_t|\mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t; \alpha_t \mathbf{x}_0, \sigma_t^2 \mathbf{I})$, defines a (Gaussian) conditional probability path from a data sample $\mathbf{x}_0 \sim p_{\text{data}}$ (left) towards the Gaussian prior p_{prior} (right).

图 5.27: 条件转移分布示意图. $p_t(\mathbf{x}_t \mid \mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t; \alpha_t \mathbf{x}_0, \sigma_t^2 \mathbf{I})$ 定义了一条从数据样本 $\mathbf{x}_0 \sim p_{\text{data}}$（左）指向 Gauss 先验 p_{prior}（右）的（Gauss）条件概率路径.

它通过 PF-ODE 定义确定性粒子流：

$$\frac{\mathrm{d}\mathbf{x}(t)}{\mathrm{d}t} = \underbrace{f(t)\mathbf{x}(t) - \tfrac{1}{2} g^2(t) \nabla_{\mathbf{x}} \log p_t(\mathbf{x}(t))}_{\mathbf{v}_t(\mathbf{x}(t))}.$$

该 ODE 将初值随机变量 $\mathbf{x}(0) \sim p_{\text{data}}$ 沿时间前向传输，或将 $\mathbf{x}(1) \sim p_{\text{prior}}$ 反向传输，使 $\mathbf{x}(t)$ 的边缘密度在每个 $t \in [0,1]$ 都匹配 p_t（见下文 “底层规则”）.

标量函数 $f(t)$ 与 $g(t)$ 由前向 SDE 的系数决定，等价地由条件路径中的 Gauss 核参数 α_t、σ_t 决定（见 4.4.1 引理）.

第三步：通过条件策略学习. 目标是用神经网络 $\mathbf{s}_\phi(\mathbf{x}_t, t)$ 逼近 oracle 速度场 $\mathbf{v}_t(\mathbf{x}_t)$，训练目标为期望平方误差：

$$\mathcal{L}_{\text{SM}}(\phi) = \mathbb{E}_{t \sim \mathcal{U}[0,1], \mathbf{x}_t \sim p_t} \left[\| \mathbf{s}_\phi(\mathbf{x}_t, t) - \nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t) \|^2 \right].$$

由于边缘分数 $\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t)$ 不可得，我们利用易处理的条件分布定义条件速度：

$$\mathbf{v}_t(\mathbf{x}_t \mid \mathbf{x}_0) := f(t)\mathbf{x}_t - \tfrac{1}{2} g^2(t) \nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t \mid \mathbf{x}_0).$$

由全期望公式，边缘分数可恢复为

$$\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t) = \mathbb{E}_{\mathbf{x}_0 \sim p(\cdot|\mathbf{x}_t)} \left[\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t \mid \mathbf{x}_0) \right]. \tag{5.5.2.248}$$

这就证明了以下代理训练目标：

$$\mathcal{L}_{\text{SM}}(\phi) = \underbrace{\mathbb{E}_{t, \mathbf{x}_0 \sim p_{\text{data}}, \mathbf{x}_t \sim p_t(\cdot|\mathbf{x}_0)} \left[\| \mathbf{s}_\phi(\mathbf{x}_t, t) - \nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t \mid \mathbf{x}_0) \|^2 \right]}_{\mathcal{L}_{\text{DSM}}(\phi)} + C,$$

其中 C 与 ϕ 无关. 极小元 $\mathbf{s}^*(\mathbf{x}_t, t)$ 满足

$$\mathbf{s}^*(\mathbf{x}_t, t) = \mathbb{E}_{\mathbf{x}_0 \sim p(\cdot|\mathbf{x}_t)} \left[\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t \mid \mathbf{x}_0) \right] = \nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t),$$

其中第二个等号来自 (5.5.2.248)，从而验证了条件训练目标.

底层规则：Fokker–Planck 方程. 边缘密度 p_t 按 Fokker–Planck 方程演化：

$$\frac{\partial p_t(\mathbf{x})}{\partial t} + \nabla \cdot \left(\underbrace{\left(f(t)\mathbf{x} - \tfrac{1}{2} g^2(t) \nabla_{\mathbf{x}} \log p_t(\mathbf{x}) \right)}_{\mathbf{v}_t(\mathbf{x})} p_t(\mathbf{x}) \right) = 0.$$

该 PDE 保证 PF-ODE 给出的密度与前向 SDE 的边缘分布一致. 为此，回顾 (4.4.1.130) 式定义的 PF-ODE 流映射 $\Psi_{s\to t}(\mathbf{x}_s)$，它把 s 时刻的初态直接携带到 t 时刻的状态. 从 $t=1$ 开始反向运行 PF-ODE，初值 $\mathbf{x}_1 \sim p_{\text{prior}}$，通过推前公式得到时间依赖密度：

$$p_t^{\text{rev}}(\mathbf{x}) = \int \delta\left(\mathbf{x} - \Psi_{1\to t}(\mathbf{x}_1)\right) p_{\text{prior}}(\mathbf{x}_1)\, \mathrm{d}\mathbf{x}_1. \tag{5.5.2.249}$$

Fokker–Planck 方程保证诱导的密度路径与同一演化密度重合：

$$p_t^{\text{rev}} = p_t. \tag{5.5.2.250}$$

特别地，这意味着 $p_0^{\text{rev}} = p_0 = p_{\text{data}}$，即在 $t=0$ 处恢复数据分布. 由于 ODE 解映射双向可逆，我们也可类似地从 $\mathbf{x}_0 \sim p_{\text{data}}$ 出发前向求解 ODE，进行平行分析.

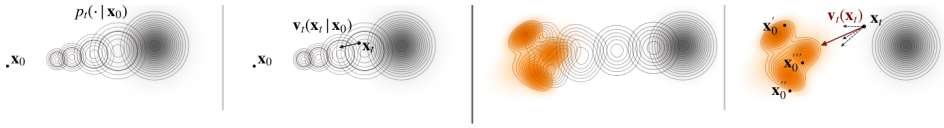


Figure 5.5: Illustration of conditional versus marginal perspectives in diffusion. (This figure is motivated by Lipman *et al.* (2024).) (1) Conditional Gaussian path $p_t(\cdot|\mathbf{x}_0)$, showing expanding densities from a fixed $\mathbf{x}_0$ toward the prior. (2) Conditional velocity $\mathbf{v}_t(\mathbf{x}_t|\mathbf{x}_0) = f(t)\mathbf{x}_t - \frac{1}{2}g^2(t)\nabla_{\mathbf{x}_t}\log p_t(\mathbf{x}_t|\mathbf{x}_0)$. (3) Marginal density p_t, transporting the data distribution p_{data} (orange) into the prior p_{prior} (gray). (4) Marginal velocity $\mathbf{v}_t(\mathbf{x}_t) = f(t)\mathbf{x}_t - \frac{1}{2}g^2(t)\nabla_{\mathbf{x}_t}\log p_t(\mathbf{x}_t)$, obtained by averaging conditional directions from $\mathbf{x}_t$ to multiple

图 5.28: 扩散中条件视角与边缘视角对比.（本图受 Lipman 等（2024）启发.）(1) 条件 Gauss 路径 $p_t(\cdot \mid \mathbf{x}_0)$，从固定 $\mathbf{x}_0$ 向先验展开密度；(2) 条件速度 $\mathbf{v}_t(\mathbf{x}_t \mid \mathbf{x}_0) = f(t)\mathbf{x}_t - \frac{1}{2}g^2(t)\nabla_{\mathbf{x}_t}\log p_t(\mathbf{x}_t \mid \mathbf{x}_0)$；(3) 边缘密度 p_t，把数据分布 p_{data}（橙）传输到先验 p_{prior}（灰）；(4) 边缘速度 $\mathbf{v}_t(\mathbf{x}_t) = f(t)\mathbf{x}_t - \frac{1}{2}g^2(t)\nabla_{\mathbf{x}_t}\log p_t(\mathbf{x}_t)$，由 $\mathbf{x}_t$ 到多个可能来源（虚线）的条件方向平均得到红色箭头. 在 FM 单边条件 $\mathbf{z} = \mathbf{x}_0$ 下，同样的示意适用于 $\mathbf{v}_t(\mathbf{x}_t \mid \mathbf{x}_0)$ 与 $\mathbf{v}_t(\mathbf{x}_t)$，无需把它们显式写成分数 $\nabla_{\mathbf{x}_t}\log p_t(\mathbf{x}_t \mid \mathbf{x}_0)$ 或 $\nabla_{\mathbf{x}_t}\log p_t(\mathbf{x}_t)$.

5.2.2 流匹配框架

5.2.1 节的分析表明，扩散模型之所以成功，是因为学习了一个速度场（具体而言是分数），它在满足边界条件的同时在分布之间传输. (5.5.2.246) 式中具有递增方差 σ_t^2 的 Gauss 条件路径把一个端点锚定在 Gauss 先验上，同时允许条件密度在整个空间上定义，从而可进行基于分数的梯度计算.

本小节介绍 FM 框架，它建立在这一洞见之上（图 5.28 中同一示意也适用于 FM），并将其推广为在两个任意分布 p_{src} 与 p_{tgt} 之间传输样本的连续流.

第一步：定义条件路径及其边缘密度. 考虑 $\mathbb{R}^D$ 上任意源分布与目标分布 p_{src}、p_{tgt}. 我们设定[24]

$$p_0(\mathbf{x}) = p_{\text{src}}(\mathbf{x}), \qquad p_1(\mathbf{x}) = p_{\text{tgt}}(\mathbf{x}). \tag{5.5.2.251}$$

FM 隐式定义一族在两端点之间插值的连续中间密度 $\{p_t\}_{t\in[0,1]}$. 每个边缘 p_t 通过一个隐变量 $\mathbf{z}$（来自已知分布 $\pi(\mathbf{z})$）与条件分布 $p_t(\mathbf{x}_t \mid \mathbf{z})$ 表示：

$$p_t(\mathbf{x}_t) = \int p_t(\mathbf{x}_t \mid \mathbf{z})\pi(\mathbf{z})\,\mathrm{d}\mathbf{z}, \tag{5.5.2.252}$$

其中 $(\pi(\mathbf{z}), \{p_t(\cdot \mid \mathbf{z})\})$ 的选择需满足 (5.5.2.251) 的边界条件.

我们注意，一般而言边缘密度 p_t 不易处理，因为需要对 $\pi(\mathbf{z})$ 积分，且 $\pi(\mathbf{z})$ 与条件分布 $p_t(\mathbf{x}_t \mid \mathbf{z})$ 都可能很复杂. 尽管如此，对隐变量 $\mathbf{z}z$ 进行条件化使 FM 能建模比 5.2.1 节更广的插值路径. $\mathbf{z}$ 的常见选择包括：

- **双边条件：** $\mathbf{z} = (\mathbf{x}_0, \mathbf{x}_1) \sim p_{\text{src}}(\mathbf{x}_0)p_{\text{tgt}}(\mathbf{x}_1)$，其中 π 耦合源与目标分布. 这使 FM 能在任意分布之间定义传输.
- **单边条件：** $\mathbf{z} = \mathbf{x}_0$ 或 $\mathbf{z} = \mathbf{x}_1$. 当源分布选为 Gauss 时，尤其恢复类扩散设置.

在所有情形中，条件分布 $p_t(\mathbf{x}_t \mid \mathbf{z})$ 都应具有易处理的闭式表达式. 我们在全章采用这一假设，并在 5.3.2 节给出具体构造，图 5.29 给出示意.

第二步：速度场. 在标准扩散模型或 Gauss FM 中，中间密度 $\{p_t\}_{t\in[0,1]}$ 以一端为标准 Gauss 构造. 此时速度场 $\mathbf{v}_t$ 唯一确定，且有与分数相关的闭式表达式（见 (5.5.2.247)）.

与之相对，一般 FM 在一般源分布 p_{src} 与目标分布 p_{tgt} 之间插值，速度场不再唯一确定（稍后解释）.

目标是找到速度场 $\mathbf{v}_t(\mathbf{x})$，使诱导的 ODE（实现样本级变换）

$$\frac{\mathrm{d}\mathbf{x}(t)}{\mathrm{d}t} = \mathbf{v}_t(\mathbf{x}(t)), \qquad t \in [0,1],$$

所产生的 $\mathbf{x}(t)$ 边缘分布在每个时刻 t 都与 p_t 匹配，无论从 $\mathbf{x}(0) \sim p_{\text{src}}$ 前向积分还是从 $\mathbf{x}(1) \sim p_{\text{tgt}}$ 反向积分（更形式化的讨论见 5.2.4 节）.

该要求由连续性方程[25]刻画：

$$\frac{\partial p_t(\mathbf{x})}{\partial t} + \nabla \cdot (\mathbf{v}_t(\mathbf{x})p_t(\mathbf{x})) = 0. \tag{5.5.2.253}$$

任何满足 (5.5.2.253) 的速度场 $\mathbf{v}_t$ 都保证 ODE 流严格按预定 p_t 传输样本（详见 5.2.4 节）. 因此，求解该 ODE 即可在匹配所有中间分布的同时实现 $p_{\text{src}} \to p_{\text{tgt}}$ 的传输.

[24]为与 FM 文献的标准记号对齐，我们相比早前章节反转了时间轴：$t = 0$ 对应源分布，$t = 1$ 对应目标.

[25]Fokker–Planck 方程的确定性对应，不含扩散项.

直观上，许多不同流可以诱导相同的边缘演化. 这是因为 (5.5.2.253) 是标量方程，而 $\mathbf{v}_t$ 是 $\mathbb{R}^D$ 中的向量场，故方程有无穷多解. 例如，若 $\mathbf{v}_t$ 是解，则对任意无散度向量场 $\tilde{\mathbf{v}}_t$（即 $\nabla \cdot \tilde{\mathbf{v}}_t = 0$），$\mathbf{v}_t + \frac{1}{p_t}\tilde{\mathbf{v}}_t$ 也是解. 因此 FM 寻求满足 (5.5.2.253) 的某个特定速度场 $\mathbf{v}_t$，使样本沿路径 $\{p_t\}$ 连续传输. 但对任意分布，p_t 与 $\mathbf{v}_t$ 一般没有闭式. 作为具体示例， 5.3.1 节讨论 Gauss–Gauss 桥，那里两个量都可显式计算.

第三步：通过条件策略学习. FM 训练目标是用神经网络 $\mathbf{v}_\phi$ 逼近 oracle 速度场 $\mathbf{v}_t$，最小化期望平方误差：

$$\mathcal{L}_{\mathrm{FM}}(\phi) = \mathbb{E}_{t,\mathbf{x}_t\sim p_t}\left[\|\mathbf{v}_\phi(\mathbf{x}_t,t) - \mathbf{v}_t(\mathbf{x}_t)\|^2\right].$$

我们把这种参数化称为 **v-prediction**（速度预测），旨在直接学习 ODE 漂移项.

与 5.2.1 节一样，oracle 速度 $\mathbf{v}_t(\mathbf{x})$ 一般不可处理. 为此引入隐变量 $\mathbf{z}\sim\pi(\mathbf{z})$，构造条件速度场 $\mathbf{v}_t(\mathbf{x}\mid\mathbf{z})$. 这使我们能通过全期望公式[26]重写损失：

$$\mathcal{L}_{\mathrm{FM}}(\phi) = \underbrace{\mathbb{E}_{t,\mathbf{z}\sim\pi(\mathbf{z}),\mathbf{x}_t\sim p_t(\cdot|\mathbf{z})}\left[\|\mathbf{v}_\phi(\mathbf{x}_t,t) - \mathbf{v}_t(\mathbf{x}_t\mid\mathbf{z})\|^2\right]}_{\mathcal{L}_{\mathrm{CFM}}(\phi)} + C, \tag{5.5.2.254}$$

其中 C 与 ϕ 无关. 主项 $\mathcal{L}_{\mathrm{CFM}}$ 称为条件流匹配（Conditional Flow Matching, CFM）.

也就是说，最小化 $\mathcal{L}_{\mathrm{FM}}(\phi)$ 等价于最小化 $\mathcal{L}_{\mathrm{CFM}}(\phi)$，后者形式更易处理. 为使 $\mathcal{L}_{\mathrm{CFM}}(\phi)$ 可进行易处理、免模拟的训练，必须满足两个要求：

(i) 从条件概率路径 $p_t(\cdot\mid\mathbf{z})$ 采样应直接可行（免模拟）；

(ii) 用作回归目标的条件速度 $\mathbf{v}_t(\mathbf{x}_t\mid\mathbf{z})$ 必须有简单的闭式表达式.

我们将在 5.3.2 节给出满足这些条件的显式构造. 这一条件视角使训练可行：模型不再学习不可处理的无条件速度场 $\mathbf{v}_t(\cdot)$，而是学习易处理的条件场 $\mathbf{v}_t(\cdot\mid\mathbf{z})$，与去噪分数匹配直接类比.

尽管与给定 p_t 相容的可能无条件速度场有无穷多个，但通过对条件速度场做边缘化，即可恢复其中之一：

$$\mathbf{v}_t(\mathbf{x}_t) := \mathbb{E}_{\mathbf{z}\sim p(\cdot|\mathbf{x}_t)}\left[\mathbf{v}_t(\mathbf{x}_t\mid\mathbf{z})\right], \tag{5.5.2.255}$$

其中期望对 $p(\mathbf{z}\mid\mathbf{x}_t)$ 取. 可以证明， (5.5.2.254) 式中 CFM 目标的极小元 $\mathbf{v}^*$ 恢复该边缘速度：

$$\mathbf{v}^*(\mathbf{x}_t,t) = \mathbf{v}_t(\mathbf{x}_t). \tag{5.5.2.256}$$

因此，学习匹配条件速度场 $\mathbf{v}_t(\cdot\mid\mathbf{z})$ 足以恢复有效的无条件速度场.

我们把上述讨论总结为：

[26]这与 (6.6.1.266) 式的分部积分论证相同. 类似地， (5.5.2.256) 式也在分数匹配框架内用相同方法推导.

定理 5.2.1 ($\mathcal{L}_{\mathrm{FM}}$ 与 $\mathcal{L}_{\mathrm{CFM}}$ 的等价性)**：** 下式成立：

$$\mathcal{L}_{\mathrm{FM}}(\phi) = \mathcal{L}_{\mathrm{CFM}}(\phi) + C,$$

其中 C 是与参数 ϕ 无关的常数. 此外，两个损失的极小元 $\mathbf{v}^*$ 满足

$$\mathbf{v}^*(\mathbf{x}_t, t) = \mathbf{v}_t(\mathbf{x}_t), \qquad \text{对几乎所有} \mathbf{x}_t \sim p_t,$$

其中 $\mathbf{v}_t(\mathbf{x}_t)$ 由 (5.5.2.255) 定义.

定理证明： 极小元的论证与推导与 4.2.1 命题中分数匹配情形完全相同. □

这是条件技巧第三次给出易处理训练目标. 值得注意的是，变分、基于分数与基于流的方法都反映了同一底层原理.

注 5.2.1： 取 $\pi = p_{\mathrm{data}}$，应用 Bayes 法则：

$$p(\mathbf{x}_0 \mid \mathbf{x}_t) = \frac{p_t(\mathbf{x}_t \mid \mathbf{x}_0) p_{\mathrm{data}}(\mathbf{x}_0)}{p_t(\mathbf{x}_t)},$$

在基于分数的模型中也出现 (5.5.2.255) 的类似分解：

$$\begin{aligned}\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t) &= \mathbb{E}_{\mathbf{x}_0 \sim p(\cdot \mid \mathbf{x}_t)} \left[\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t \mid \mathbf{x}_0) \right] \\ &= \mathbb{E}_{\mathbf{x}_0 \sim p_{\mathrm{data}}} \left[\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t \mid \mathbf{x}_0) \cdot \frac{p_t(\mathbf{x}_t \mid \mathbf{x}_0)}{p_t(\mathbf{x}_t)} \right],\end{aligned}$$

与 (5.5.2.255) 的边缘化策略对应. ◇

与 5.2.1 节一样，必须显式指定条件密度 $p_t(\mathbf{x}_t \mid \mathbf{z})$ 与条件速度场 $\mathbf{v}_t(\mathbf{x}_t \mid \mathbf{z})$（那里为 $p_t(\mathbf{x}_t \mid \mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t; \alpha_t \mathbf{x}_0, \sigma_t^2 \mathbf{I})$、$\mathbf{v}_t(\mathbf{x}_t \mid \mathbf{x}_0) = f(t)\mathbf{x}_t - \frac{1}{2} g^2(t) \nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t \mid \mathbf{x}_0)$）. 一般 CFM 框架也需要这两个分量. 但在一般情形下，我们尚未构造条件密度 $p_t(\mathbf{x}_t \mid \mathbf{z})$ 或条件速度场 $\mathbf{v}_t(\mathbf{x}_t \mid \mathbf{z})$. 下一节将介绍这些分量的几种常见实例.

5.2.3 扩散模型、一般 FM 与 NODE 的对比

扩散模型与一般 FM 的对比. 5.2.1 节的洞见引出了保留同一底层原理的扩展 FM 框架. 为凸显相似性，我们在表 4 中总结.

我们注意，由于 Gauss FM 与标准扩散模型本质等价（详见第 6 章），除非显式说明，下文不再区分二者.

与 NODE 的联系. FM 可视为 5.1.2 节 NODE 的免模拟替代. CNF 在极大似然训练中需要求解 ODE，计算代价高昂；FM 通过简单回归损失直接回归预设速度场，绕过了这一步. 关键洞见是：当源–目标密度路径固定时，训练中的精确模拟不再必要.

表 4: 扩散模型（或 Gauss FM）与一般 FM 框架对比. 这里一般 FM 指双边条件设置，$\mathbf{x}_0 \sim p_{\text{src}}$ 与 $\mathbf{x}_1 \sim p_{\text{tgt}}$ 独立采样.

方面	**扩散模型**	**一般 FM**
源分布 p_{src}	Gauss 先验	任意
目标分布 p_{tgt}	数据分布	任意
隐变量分布 $\pi(\mathbf{z})$	p_{data}	见 5.3.2 节
条件分布 $p_t(\mathbf{x}_t \mid \mathbf{z})$	$\mathcal{N}(\mathbf{x}_t; \alpha_t \mathbf{x}_0, \sigma_t^2 \mathbf{I})$	见 5.3.2 节
边缘分布 $p_t(\mathbf{x}_t)$	$\int p_t(\mathbf{x}_t \mid \mathbf{x}_0) p_{\text{data}}(\mathbf{x}_0)\, \mathrm{d}\mathbf{x}_0$	$\int p_t(\mathbf{x}_t \mid \mathbf{z}) \pi(\mathbf{z})\, \mathrm{d}\mathbf{z}$
条件速度 $\mathbf{v}_t(\mathbf{x} \mid \mathbf{z})$	$f(t)\mathbf{x} - \frac{1}{2} g^2(t) \nabla \log p_t(\mathbf{x} \mid \mathbf{x}_0)$	见 5.3.2 节
边缘速度 $\mathbf{v}_t(\mathbf{x})$	$f(t)\mathbf{x} - \frac{1}{2} g^2(t) \nabla \log p_t(\mathbf{x})$	见 (5.5.2.255)
学习目标	$\mathcal{L}_{\text{SM}} = \mathcal{L}_{\text{DSM}} + C$	$\mathcal{L}_{\text{FM}} = \mathcal{L}_{\text{CFM}} + C$
底层规则	Fokker–Planck / 连续性方程	连续性方程

5.2.4 （可选）底层规则

连续性方程：质量守恒准则. 与 5.2.1 节中 PF-ODE 与 Fokker–Planck 分析类似，我们给出一个准则，用于验证 ODE 流诱导的密度路径是否与预定路径 $\{p_t\}_{t\in[0,1]}$ 对齐.

考虑在时间依赖速度场 $\mathbf{v}_t$ 下描述粒子 ODE 的方程：

$$\frac{\mathrm{d}\mathbf{x}(t)}{\mathrm{d}t} = \mathbf{v}_t(\mathbf{x}(t)).$$

如 (5.5.2.249)，该 ODE 对任意 $s, t \in [0,1]$ 定义流映射 $\Psi_{s\to t}(\mathbf{x}_0)$，特别地把 0 时刻的初值点 $\mathbf{x}_0 \sim p_{\text{src}}$ 传输到 t 时刻的状态. t 时刻的诱导分布由推前给出：

$$p_t^{\text{fwd}}(\mathbf{x}) = \int \delta\left(\mathbf{x} - \Psi_{0\to t}(\mathbf{x}_0)\right) p_{\text{src}}(\mathbf{x}_0)\, \mathrm{d}\mathbf{x}_0 =: \Psi_{0\to t} \# p_{\text{src}}, \tag{5.5.2.257}$$

即 $\mathbf{x}_0 \sim p_{\text{src}}$ 时 $\Psi_{0\to t}(\mathbf{x}_0) \sim p_t^{\text{fwd}}$. 类似地，可从 $\mathbf{x}_1 \sim p_{\text{tgt}}$ 反向传输回 p_{src}，即 $\Psi_{1\to 0}(\mathbf{x}_1)$.

假设给定预定密度路径 $\{p_t\}_{t\in[0,1]}$，并构造速度场 $\{\mathbf{v}_t\}_{t\in[0,1]}$ 定义粒子流. 这自然引出问题：

问题 5.2.1 (问题 5.2.1)**：** 在什么条件下，流诱导密度 p_t^{fwd} 对所有 $t \in [0,1]$ 都精确匹配目标密度 p_t?

一旦两个密度演化对齐，即可通过求解 ODE 在 p_{src} 与 p_{tgt} 之间灵活传输样本.

如 (5.5.2.250)，验证对齐的一个原则性方法是通过连续性方程，它刻画了时间演化密度中的质量守恒：

定理 5.2.2 (质量守恒准则)**：** 流诱导密度 p_t^{fwd} 对所有 $t \in [0,1]$ 等于预定路径 p_t，即

$$p_t^{\text{fwd}} = p_t, \qquad \text{对所有} t \in [0,1],$$

当且仅当 $(p_t, \mathbf{v}_t)$ 满足连续性方程：

$$\partial_t p_t(\mathbf{x}) + \nabla_{\mathbf{x}} \cdot (p_t(\mathbf{x}) \mathbf{v}_t(\mathbf{x})) = 0, \qquad \text{对所有} t \in [0,1] \text{ 与} \mathbf{x}.$$

定理证明： 概念性推导见附录 D.3.2，更严格的处理见（Villani 等, 2008）（“质量守恒公式”）. □

从条件路径到边缘路径. 如 5.2.2 节所述，我们先定义条件概率路径 $p_t(\cdot \mid \mathbf{z})$ 及相应条件速度场 $\mathbf{v}_t(\cdot \mid \mathbf{z})$，再构造边缘速度场：

$$\mathbf{v}_t(\mathbf{x}) = \int \mathbf{v}_t(\mathbf{x} \mid \mathbf{z}) \frac{p_t(\mathbf{x} \mid \mathbf{z})\pi(\mathbf{z})}{p_t(\mathbf{x})} \, \mathrm{d}\mathbf{z},$$

即 (5.5.2.255) . 然而仍需保证所得边缘速度 $\mathbf{v}_t$ 诱导的 ODE 流的密度路径与预定 p_t 对齐. 幸运的是，这一验证可完全在条件层面完成：若每个条件速度场 $\mathbf{v}_t(\cdot \mid \mathbf{z})$ 都诱导匹配 $p_t(\cdot \mid \mathbf{z})$ 的条件密度路径，则所得边缘速度场 $\mathbf{v}_t(\cdot)$ 也诱导从 $p_0(\cdot)$ 出发、与 $p_t(\cdot)$ 对齐的边缘密度路径. 形式化地陈述如下：

命题 5.2.1 (边缘速度场生成给定边缘密度)**：** *若条件速度场 $\mathbf{v}_t(\cdot \mid \mathbf{z})$ 诱导出与 $p_t(\cdot \mid \mathbf{z})$ (从 $p_0(\cdot \mid \mathbf{z})$ 出发) 匹配的条件密度路径，则 (5.5.2.255) 定义的边缘速度场 $\mathbf{v}_t(\cdot)$ 诱导出从 $p_0(\cdot)$ 出发、与 $p_t(\cdot)$ 对齐的边缘密度路径.*

命题证明： 本结果通过验证 $(p_t, \mathbf{v}_t)$ 满足连续性方程得到. 我们反向组织论证，以说明为什么边缘化速度场取 (5.5.2.255) 的形式. 由于条件速度场 $\mathbf{v}_t(\cdot \mid \mathbf{z})$ 诱导出与条件密度 $p_t(\cdot \mid \mathbf{z})$ ($\mathbf{z} \sim \pi$) 匹配的密度路径，连续性方程对每个条件对成立：

$$\frac{\mathrm{d}}{\mathrm{d}t} p_t(\mathbf{x} \mid \mathbf{z}) = -\nabla_{\mathbf{x}} \cdot \left(\mathbf{v}_t(\mathbf{x} \mid \mathbf{z}) p_t(\mathbf{x} \mid \mathbf{z}) \right). \tag{5.5.2.258}$$

我们希望找到速度场 $\mathbf{v}_t(\cdot)$，使其诱导密度与边缘密度 p_t 对齐，即满足

$$\frac{\mathrm{d}}{\mathrm{d}t} p_t(\mathbf{x}) = -\nabla_{\mathbf{x}} \cdot \left(\mathbf{v}_t(\mathbf{x}) p_t(\mathbf{x}) \right). \tag{5.5.2.259}$$

从 (5.5.2.252) 的 p_t 定义出发：

$$\begin{aligned}
\frac{\mathrm{d}}{\mathrm{d}t} p_t(\mathbf{x}) &= \int \frac{\mathrm{d}}{\mathrm{d}t} p_t(\mathbf{x}_t \mid \mathbf{z}) \pi(\mathbf{z}) \, \mathrm{d}\mathbf{z} \\
&= -\int \nabla_{\mathbf{x}} \cdot \left(\mathbf{v}_t(\mathbf{x} \mid \mathbf{z}) p_t(\mathbf{x} \mid \mathbf{z}) \right) \pi(\mathbf{z}) \, \mathrm{d}\mathbf{z} \\
&= -\nabla_{\mathbf{x}} \cdot \left(\int \mathbf{v}_t(\mathbf{x} \mid \mathbf{z}) p_t(\mathbf{x} \mid \mathbf{z}) \pi(\mathbf{z}) \, \mathrm{d}\mathbf{z} \right),
\end{aligned}$$

其中第二个等号应用了 (5.5.2.258) . 将其与 (5.5.2.259) 右侧对比可知，在相差一个无散度项的意义下：

$$\mathbf{v}_t(\mathbf{x}) p_t(\mathbf{x}) = \int \mathbf{v}_t(\mathbf{x} \mid \mathbf{z}) p_t(\mathbf{x} \mid \mathbf{z}) \pi(\mathbf{z}) \, \mathrm{d}\mathbf{z}.$$

因此可定义

$$\mathbf{v}_t(\mathbf{x}) := \int \mathbf{v}_t(\mathbf{x} \mid \mathbf{z}) \frac{p_t(\mathbf{x} \mid \mathbf{z})}{p_t(\mathbf{x})} \pi(\mathbf{z}) \, \mathrm{d}\mathbf{z},$$

这正是 (5.5.2.255) 的形式. 该定理的证明本质上是上述论证的反向. □

这一联系使我们能把构造潜在不可处理的边缘速度场，简化为构造更简单、按构造即可工作的条件场 $\mathbf{v}_t(\cdot \mid \mathbf{z})$.

5.3 在分布之间构造概率路径与速度

流匹配的精髓在于把源分布逐步变换为目标. 要引导这一变换，需要两个关键元素：概率路径 p_t（在每个时刻 t 提供演化分布的快照）与速度场 $\mathbf{v}_t$（描述单个粒子如何沿路径移动）. 二者并不独立：它们通过连续性方程相连，保证粒子动力学与分布演化一致. 因此学习任务归结为寻找一个能忠实驱动过程的速度场 $\mathbf{v}_t$. 困难在于：对一般复杂分布，真实边缘速度 $\mathbf{v}_t$ 未知，留下一个无法直接访问的不可处理目标.

条件流匹配的核心思想是：通过构造一个人工但易处理的过程，来解决真实边缘速度的不可处理性. 为此引入条件变量 $\mathbf{z}$，并设计条件速度 $\mathbf{v}_t(\mathbf{x}_t \mid \mathbf{z})$ 和/或条件路径 $p_t(\mathbf{x}_t \mid \mathbf{z})$，使其被刻意选择为简单形式.

由于这些条件对象有闭式解，它们充当了模型可回归的代理目标. 这给出有效的训练损失 $\mathcal{L}_{\text{CFM}}$，只要满足两个实际条件：(i) 能从 $p_t(\cdot \mid \mathbf{z})$ 高效采样；(ii) 相应速度 $\mathbf{v}_t(\cdot \mid \mathbf{z})$ 有闭式表达式.

如何设计一个行为良好的条件过程？作为启发，我们转向唯一被完全理解的情形：Gauss 到 Gauss 的桥（5.3.1 节）. 该例子凸显了两种自然设计策略：在每个时刻 t 采用 Gauss 概率路径，或预设一个仿射速度场；两者都解析易处理.

受此启发，我们用两种互补视角（另见附录 B.1.2）推广到一般端点分布，用于构造条件路径与速度：

- **先条件概率路径（Euler 视角）：** 先给定条件概率路径 $p_t(\cdot \mid \mathbf{z})$，再推导相应条件速度场.
- **先条件流（Lagrange 视角）：** 从条件流 $\Psi_{0\to t}(\cdot \mid \mathbf{z})$（通常仿射）出发，沿轨迹对时间求导得到条件速度场.

5.3.2 节详述第一种方法，展示其与 5.2.1 节扩散模型构造的紧密类比；5.3.3 节给出第二种. 两种视角共同提供了定义 $p_t(\mathbf{x}_t \mid \mathbf{z})$ 与 $\mathbf{v}_t(\mathbf{x}_t \mid \mathbf{z})$ 的实用框架，使任意源–目标分布之间都能进行免模拟训练与流构造.

5.3.1 一个关键特例：Gauss–Gauss 桥中的边缘 $p_t(\mathbf{x}_t)$ 与速度 $\mathbf{v}_t(\mathbf{x}_t)$

我们从 Gauss 端点情形开始，此时可解析计算边缘密度 $p_t(\mathbf{x}_t)$ 与速度场 $\mathbf{v}_t(\mathbf{x}_t)$. 这作为一般条件密度 $p_t(\mathbf{x}_t \mid \mathbf{z}_t)$ 与速度场 $\mathbf{v}_t(\mathbf{x}_t \mid \mathbf{z}_t)$ 构造的模板.

当源分布 p_{src} 与目标分布 p_{tgt} 都是 Gauss 时，速度场 $\mathbf{v}_t(\cdot)$ 有闭式表达式. 考虑插值边缘密度路径：

$$p_t(\mathbf{x}_t) = \mathcal{N}\left(\mathbf{x}_t; \boldsymbol{\mu}(t), \sigma^2(t)\mathbf{I}\right), \tag{5.5.3.260}$$

其中均值 $\boldsymbol{\mu}(t)$ 随时间变化，方差 $\sigma^2(t) > 0$. 两个端点为

$$p_{\text{src}} = p_0 = \mathcal{N}\left(\mathbf{x}; \boldsymbol{\mu}(0), \sigma^2(0)\mathbf{I}\right), \qquad p_{\text{tgt}} = p_1 = \mathcal{N}\left(\mathbf{x}; \boldsymbol{\mu}(1), \sigma^2(1)\mathbf{I}\right),$$

从而路径 $\{p_t\}_{t\in[0,1]}$ 连接这两个分布.

给定路径 $\{p_t\}_{t\in[0,1]}$，确实存在许多速度场能诱导 ODE 流 $\Psi_{0\to t}(\mathbf{x})$，使 $\mathbf{x}\sim p_0 \Rightarrow \Psi_{0\to t}(\mathbf{x})\sim p_t$. 对该 Gauss 路径，一个特别简单的实现为[27]：

$$\Psi_{0\to t}(\mathbf{x}) := \boldsymbol{\mu}(t) + \sigma(t)\left(\frac{\mathbf{x}-\boldsymbol{\mu}(0)}{\sigma(0)}\right). \tag{5.5.3.261}$$

对定义的 Gauss 路径 p_t（对所有 t 都是 Gauss），诱导 (5.5.3.261) ODE 流的速度场 $\mathbf{v}_t(\cdot)$ 唯一且解析刻画如下（Lipman 等, 2022）：

命题 5.3.1 (Gauss 密度路径的闭式速度场)**：** 设 p_t 为 (5.5.3.260) 中的 Gauss 路径. 则生成 (5.5.3.261) ODE 流的速度场 $\mathbf{v}_t(\cdot)$ 对该 $\Psi_{0\to t}$ 唯一，并有闭式表达式：

$$\mathbf{v}_t(\mathbf{x}) = \frac{\sigma'(t)}{\sigma(t)}(\mathbf{x}-\boldsymbol{\mu}(t)) + \boldsymbol{\mu}'(t).$$

命题证明： 考虑初值为 $\mathbf{y}$ 的 ODE：

$$\frac{\mathrm{d}}{\mathrm{d}t}\Psi_{0\to t}(\mathbf{y}) = \mathbf{v}_t(\Psi_{0\to t}(\mathbf{y})).$$

由于 $\Psi_{0\to t}$ 可逆（$\sigma(t)>0$），可设 $\mathbf{x}=\Psi_{0\to t}(\mathbf{y})$、$\mathbf{y}=\Psi^{-1}_{0\to t}(\mathbf{x})=\Psi_{t\to 0}(\mathbf{x})$，得到

$$\Psi'_{0\to t}(\Psi^{-1}_{0\to t}(\mathbf{x})) = \mathbf{v}_t(\mathbf{x}).$$

对 (5.5.3.261) 关于 t 求导：

$$\Psi'_{0\to t}(\mathbf{x}) = \boldsymbol{\mu}'(t) + \sigma'(t)\left(\frac{\mathbf{x}-\boldsymbol{\mu}(0)}{\sigma(0)}\right).$$

解出 $\mathbf{y}=\Psi^{-1}_{0\to t}(\mathbf{x})$：

$$\mathbf{y} = \boldsymbol{\mu}(0) + \sigma(0)\left(\frac{\mathbf{x}-\boldsymbol{\mu}(t)}{\sigma(t)}\right).$$

代入 $\Psi'_{0\to t}(\mathbf{x})$ 得

$$\mathbf{v}_t(\mathbf{x}) = \frac{\sigma'(t)}{\sigma(t)}(\mathbf{x}-\boldsymbol{\mu}(t)) + \boldsymbol{\mu}'(t),$$

即所证. □

我们注意，对固定流映射 $\Psi_{0\to t}$（流先视角），速度唯一确定为

$$\mathbf{v}_t = \partial_t\Psi_{0\to t}\circ\Psi^{-1}_{0\to t}.$$

在此构造下，$(p_t,\mathbf{v}_t)$ 自动满足连续性方程. 反之，对给定密度路径 $t\mapsto p_t$ 而不固定 $\Psi_{0\to t}$（概率路径先视角），速度场并不唯一.

这一区分精确刻画了流先视角与概率路径先视角之间的差异.

当条件于隐变量 $\mathbf{z}$ 时，这一闭式刻画依然成立. 下面我们把这一洞见推广到一般边缘情形，构造条件 Gauss 路径 $p_t(\cdot\mid\mathbf{z})$ 并推导相应条件速度场 $\mathbf{v}_t(\cdot\mid\mathbf{z})$.

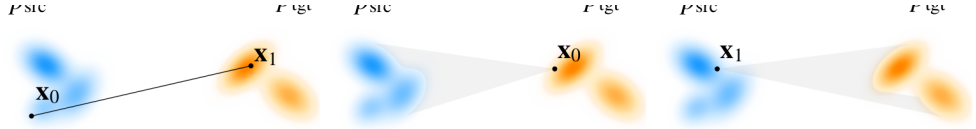


Figure 5.6: Illustrations of two common types of conditioning probability paths. It includes: (1) *two-sided*, conditioned on $\mathbf{x}_0 \sim p_{\text{tgt}}$ and $\mathbf{x}_1 \sim p_{\text{src}}$ with general endpoint distributions; (2) *one-sided*, conditioned at either $\mathbf{x}_0 \sim p_{\text{tgt}}$ or $\mathbf{x}_1 \sim p_{\text{src}}$.

图 5.29: 两种常见条件概率路径示意. (1) 双边：条件于 $\mathbf{x}_0 \sim p_{\text{tgt}}$ 与 $\mathbf{x}_1 \sim p_{\text{src}}$，端点分布任意；(2) 单边：条件于 $\mathbf{x}_0 \sim p_{\text{tgt}}$ 或 $\mathbf{x}_1 \sim p_{\text{src}}$.

5.3.2 $\mathbf{v}_t(\cdot \mid \mathbf{z})$ 与 $p_t(\cdot \mid \mathbf{z})$ 的条件概率路径先构造

我们先构造条件密度路径 $p_t(\cdot \mid \mathbf{z})$，再（通过 5.3.1 ）推导相应条件速度场 $\mathbf{v}_t(\cdot \mid \mathbf{z})$. 根据 $\mathbf{z}$ 的选择，有两种自然情形：(i) 双边条件 $\mathbf{z} = (\mathbf{x}_0, \mathbf{x}_1)$；(ii) 单边条件 $\mathbf{z} = \mathbf{x}_0$ 或 $\mathbf{x}_1$. 任一情形下构造都必须匹配边界分布：

$$p_{\text{src}}(\mathbf{x}_0) = \int p_0(\mathbf{x}_0 \mid \mathbf{z})\pi(\mathbf{z})\,\mathrm{d}\mathbf{z}, \qquad p_{\text{tgt}}(\mathbf{x}_1) = \int p_1(\mathbf{x}_1 \mid \mathbf{z})\pi(\mathbf{z})\,\mathrm{d}\mathbf{z}.$$

一旦指定具体构造，验证这些约束是直接的，这里不再强调验证步骤.

I. 双边 $\mathbf{z} = (\mathbf{x}_0, \mathbf{x}_1)$ ——“束状”路径. $\pi(\mathbf{z})$ 的选择. 考虑 $\mathbb{R}^D$ 上一般分布 p_{src} 与 p_{tgt}. 令 $\mathbf{z} = (\mathbf{x}_0, \mathbf{x}_1)$，$\mathbf{x}_0 \sim p_{\text{src}}$、$\mathbf{x}_1 \sim p_{\text{tgt}}$ 独立，即

$$\pi(\mathbf{z}) = p_{\text{src}}(\mathbf{x}_0)p_{\text{tgt}}(\mathbf{x}_1).$$

条件路径 $p_t(\cdot \mid \mathbf{z})$ 的选择. 用固定方差 $\sigma > 0$ 的线性插值定义条件路径：

$$p_t(\mathbf{x}_t \mid \mathbf{z} = (\mathbf{x}_0, \mathbf{x}_1)) = \mathcal{N}(\mathbf{x}_t; a_t\mathbf{x}_0 + b_t\mathbf{x}_1, \sigma^2\mathbf{I}),$$

其中 a_t、b_t 为时间依赖函数，满足 $a_0 = 1, b_0 = 0$ 与 $a_1 = 0, b_1 = 1$. （Lipman 等, 2022; Liu, 2022）建议取 $a_t = 1 - t$、$b_t = t$. 在确定性情形 $\sigma = 0$ 下：

$$p_t(\mathbf{x}_t \mid \mathbf{z}) = \delta\left(\mathbf{x}_t - [a_t\mathbf{x}_0 + b_t\mathbf{x}_1]\right),$$

即从 $\mathbf{x}_0$ 到 $\mathbf{x}_1$ 的确定性插值路径.

导出的条件速度 $\mathbf{v}_t(\cdot \mid \mathbf{z})$. 由 5.3.1，条件速度为

$$\mathbf{v}_t(\mathbf{x} \mid \mathbf{z}) = a_t'\mathbf{x}_0 + b_t'\mathbf{x}_1.$$

CFM 损失. 当 $\sigma = 0$，即 $\mathbf{x}_t = a_t\mathbf{x}_0 + b_t\mathbf{x}_1$ 时，CFM 损失化为

$$\mathcal{L}_{\text{CFM}} = \mathbb{E}_{t,\mathbf{x}_0\sim p_{\text{src}},\mathbf{x}_1\sim p_{\text{tgt}}} \left\|\mathbf{v}_\phi(\mathbf{x}_t, t) - (a_t'\mathbf{x}_0 + b_t'\mathbf{x}_1)\right\|^2.$$

[27]在（Lipman 等, 2022）中作者考虑 $\Psi_{0\to t}(\mathbf{x}) = \boldsymbol{\mu}(t) + \sigma(t)\mathbf{x}$，需要对 $\boldsymbol{\mu}(t)$ 与 $\sigma(t)$ 加约束以保证边界条件. 我们采用等价的归一化形式，避免此类约束.

由 (5.5.2.255) 与 (5.5.2.256)，最优速度场为

$$\mathbf{v}^*(\mathbf{x}_t, t) = \mathbb{E}\left[\mathbf{x}_t' \mid \mathbf{x}_t\right] = \mathbb{E}\left[a_t'\mathbf{x}_0 + b_t'\mathbf{x}_1 \mid \mathbf{x}_t\right].$$

这里期望对 $p(\mathbf{x}_0, \mathbf{x}_1 \mid \mathbf{x}_t)$ 取，即在时刻 t 能产生观测插值 $\mathbf{x}_t = a_t\mathbf{x}_0 + b_t\mathbf{x}_1$ 的源–目标对 $(\mathbf{x}_0, \mathbf{x}_1)$ 上的条件分布.

II. 单边 $\mathbf{z} = \mathbf{x}_0$ 或 $\mathbf{x}_1$ ——"聚光状" 路径. 我们以单边设置说明条件概率路径先构造，考虑标准生成设置 $p_{\text{src}} = \mathcal{N}(\mathbf{0}, \mathbf{I})$、$p_{\text{tgt}} = p_{\text{data}}$. 关键地，该 Gauss 源不是额外假设，而是下面定义的条件路径的直接推论. 更一般端点的处理见 5.3.3 节.

$\pi(\mathbf{z})$ 的选择. 取 $\mathbf{z} = \mathbf{x}_1$，$\pi(\mathbf{z}) = p_{\text{data}}(\mathbf{x}_1)$（$\mathbf{z} = \mathbf{x}_0 \sim p_{\text{prior}}$ 情形类似）.

条件路径 $p_t(\cdot \mid \mathbf{z})$ 的选择. 对固定 $\mathbf{x}_1 \sim p_{\text{data}}$，定义

$$p_t(\mathbf{x}_t \mid \mathbf{z} = \mathbf{x}_1) = \mathcal{N}(\mathbf{x}_t; b_t\mathbf{x}_1, a_t^2\mathbf{I}),$$

其中 $a_0 = 1, b_0 = 0$，$a_1 = 0, b_1 = 1$（通常理解为极限）. 在边界处：

$$p_0(\cdot \mid \mathbf{z} = \mathbf{x}_1) = \mathcal{N}(\cdot; \mathbf{0}, \mathbf{I}), \qquad p_1(\cdot \mid \mathbf{z} = \mathbf{x}_1) = \delta(\cdot - \mathbf{x}_1).$$

对 $\mathbf{x}_1$ 边缘化，得到 $\{p_t\}_{t\in[0,1]}$，其中 $p_0 = \mathcal{N}(\mathbf{0}, \mathbf{I})$（与 p_{data} 无关），$p_1 = p_{\text{data}}$.

导出的条件速度 $\mathbf{v}_t(\cdot \mid \mathbf{z})$. 对 $t \in (0, 1)$、$b_t > 0$，把 5.3.1 应用于条件 Gauss 路径得

$$\mathbf{v}_t(\mathbf{x} \mid \mathbf{x}_1) = b_t'\mathbf{x}_1 + \frac{a_t'}{a_t}(\mathbf{x} - b_t\mathbf{x}_1).$$

单边 *CFM* 目标. 取 $t \sim \mathcal{U}(0, 1)$（或任意固定采样分布）、$\mathbf{x}_1 \sim p_{\text{data}}$，CFM 损失为

$$\mathcal{L}_{\text{CFM}} = \mathbb{E}_{t,\mathbf{x}_1}\mathbb{E}_{\mathbf{x}_t\sim p_t(\cdot|\mathbf{x}_1)}\left\|\mathbf{v}_\phi(\mathbf{x}_t, t) - \left[b_t'\mathbf{x}_1 + \frac{a_t'}{a_t}(\mathbf{x}_t - b_t\mathbf{x}_1)\right]\right\|_2^2. \tag{5.5.3.262}$$

由 MSE 最优性，唯一极小元是边缘速度场

$$\mathbf{v}^*(\mathbf{x}, t) = \mathbb{E}\left[\mathbf{v}_t(\mathbf{x} \mid \mathbf{x}_1) \mid \mathbf{x}_t = \mathbf{x}\right] = \mathbb{E}\left[a_t'\mathbf{x}_0 + b_t'\mathbf{x}_1 \mid \mathbf{x}_t = \mathbf{x}\right].$$

与双边目标的等价性. 对配对样本 $(\mathbf{x}_0, \mathbf{x}_1)$、$\mathbf{x}_t = a_t\mathbf{x}_0 + b_t\mathbf{x}_1$，

$$\mathbf{v}_t(\mathbf{x}_t \mid \mathbf{x}_1) = b_t'\mathbf{x}_1 + \frac{a_t'}{a_t}(\mathbf{x}_t - b_t\mathbf{x}_1) = a_t'\mathbf{x}_0 + b_t'\mathbf{x}_1.$$

因此单边损失回归的是给定 $\mathbf{x}_t$ 下双边目标的条件期望：

$$\mathbf{v}^*(\mathbf{x}, t) = \mathbb{E}\left[a_t'\mathbf{x}_0 + b_t'\mathbf{x}_1 \mid \mathbf{x}_t = \mathbf{x}\right],$$

故单边与双边 CFM 目标共享同一极小元.

Gauss FM = 扩散模型. 我们采用 FM 约定，$t = 0$ 表示源/先验，$t = 1$ 表示目标/数据：

$$p_{\text{src}} = p_{\text{prior}}, \qquad p_{\text{tgt}} = p_{\text{data}}.$$

与之相反，扩散模型通常从数据到噪声索引时间（即 $t=0$ 为数据，$t=1$ 为先验）. 这里我们统一采用 FM 约定以避免混淆. 若进一步 $p_{\text{src}}=\mathcal{N}(\mathbf{0},\mathbf{I})$，则对固定条件 $\mathbf{x}_1\sim p_{\text{data}}$，条件路径 $p_t(\cdot\mid\mathbf{x}_1)$ 自然选为 Gauss，而目标分布 p_{tgt} 本身不必是 Gauss. 部分文献把这种设置称为 *Gauss FM*.

取 $a_t=1-t$、$b_t=t$（等价地 $a_t=\sigma_t$、$b_t=\alpha_t$）并在扩散模型的记号下重记 $a_t:=\sigma_t$、$b_t:=\alpha_t$，即恢复熟悉的 FM/RF 调度（Lipman 等, 2022；Liu, 2022）.

在 Gauss FM 设置下，束状与聚状条件路径都导出与标准扩散损失相似的训练目标. 我们将在第 6 章阐明：Gauss FM 事实上可等价解释为在线性调度 $a_t=1-t$、$b_t=t$ 下训练预测速度的扩散模型. 这一视角凸显流匹配与扩散并非根本不同，而是两种可相互转换的等价表述. 实践中 Gauss FM 目标格外吸引人：损失函数 $\left(\mathbb{E}_{t,\mathbf{x}_t}\left[\|\mathbf{v}_\phi(\mathbf{x}_t,t)-(\mathbf{x}_1-\mathbf{x}_0)\|_2^2\right]\right)$ 简单，且已被证明在大规模上取得有竞争力的性能（Esser 等, 2024）.

表 5: FM 约定 $\mathbf{x}_t=a_t\mathbf{x}_0+b_t\mathbf{x}_1$ 下不同插值子总结，$\mathbf{x}_0\sim p_{\text{src}}=p_{\text{prior}}$，$\mathbf{x}_1\sim p_{\text{tgt}}=p_{\text{data}}$. VE/VP 通过 $a_t:=\sigma_t$、$b_t:=\alpha_t$ 从其扩散约定（数据 → 噪声）转换而来.

	VE	**VP**	**FM/RF**	**Trig.**（Albergo 等, 2023）
a_t（先验系数）	a_t	$\sqrt{1-b_t^2}$	$1-t$	$\cos\left(\frac{\pi}{2}t\right)$
b_t（数据系数）	1	b_t	t	$\sin\left(\frac{\pi}{2}t\right)$
a_0	0	0	1	1
b_0	1	1	0	0
a_1	a_1	1	0	0
b_1	1	0	1	1
p_{prior}	$\mathcal{N}(\mathbf{0},a_1^2\mathbf{I})$	$\mathcal{N}(\mathbf{0},\mathbf{I})$	$\mathcal{N}(\mathbf{0},\mathbf{I})$	$\mathcal{N}(\mathbf{0},\mathbf{I})$

注 5.3.1： 值得强调，一些早期工作（Liu, 2022；Lipman 等, 2022）建议：采用标准仿射流 $a_t=1-t$、$b_t=t$ 会得到“直线”ODE 轨迹，从而加速采样. 然而这一说法一般并不成立. 该表述中的速度场由条件期望给出：

$$\mathbf{v}(\mathbf{x},t)=\mathbb{E}\left[\mathbf{x}_1-\mathbf{x}_0\mid\mathbf{X}_t=\mathbf{x}\right],$$

它依赖于 t，因此并不总与朴素方向 $\mathbf{x}_1-\mathbf{x}_0$ 对齐. 实践中，时间加权函数与参数化的选择强烈影响训练动力学，并能改进实证性能，但此类改进不能归因于调度器（$a_t=1-t$、$b_t=t$）所声称的“直线性”. ◇

5.3.3 $\mathbf{v}_t(\cdot\mid\mathbf{z})$ 与 $p_t(\cdot\mid\mathbf{z})$ 的条件流先构造

我们处理一般情形：端点 p_{src}（$t=0$）与 p_{tgt}（$t=1$）任意. 目标是直接在轨迹空间中设计一个条件流，把样本从 p_{src} 传输到 p_{tgt}，并给出闭式 $\mathbf{v}_t(\mathbf{x}_t\mid\mathbf{z})$ 作为回归目标.

动机. 我们可以不先设计条件密度路径，而是直接指定条件流映射 $\Psi_{0\to t}(\cdot;\mathbf{z})$，使样本沿轨迹移动. 这有两个实际优势：(i) 立即通过沿轨迹对时间求导给出训练的回归目标；

(ii) 在具有几何结构的空间（Riemann 流形、Lie 群或约束子流形）上，从几何直接构造条件流映射 $\Psi_{0\to t}$（例如测地线、指数映射、预度量）通常是自然的（Lipman 等, 2024），从而得到解析、免模拟的目标速度.

条件仿射流(联系 5.3.1). 固定条件变量 $\mathbf{z}\sim\pi$(例如单边“聚光”训练中 $\mathbf{z}=\mathbf{x}_1\sim p_{\mathrm{tgt}}$)，并通过时间依赖条件仿射流把前向 $\mathbf{x}_0\sim p_{\mathrm{src}}$ 推前：

$$\Psi_{0\to t}(\mathbf{x}_0;\mathbf{z}):=\boldsymbol{\mu}_t(\mathbf{z})+\mathbf{A}_t(\mathbf{z})\mathbf{x}_0,\qquad t\in[0,1],$$

其中 $\boldsymbol{\mu}_t(\mathbf{z})\in\mathbb{R}^D$, $\mathbf{A}_t(\mathbf{z})\in\mathbb{R}^{D\times D}$ 在 $t\in(0,1)$ 可逆. 边界 $\mathbf{A}_0(\mathbf{z})=\mathbf{I}$、$\boldsymbol{\mu}_0(\mathbf{z})=\mathbf{0}$ 在 $t=0$ 处恢复 p_{src}. 标准做法是把 $t\to 1$ 的边界理解为极限（终端映射可把质量集中到低维集或点上[28]）.

诱导的条件路径 $p_t(\cdot\mid\mathbf{z})$. 该构造定义

$$p_t(\cdot\mid\mathbf{z})=(\Psi_{0\to t}(\cdot;\mathbf{z}))_{\#}p_{\mathrm{src}},\qquad p_t(\cdot)=\int p_t(\cdot\mid\mathbf{z})\pi(\mathbf{z})\,\mathrm{d}\mathbf{z}.$$

对 $\mathcal{L}_{\mathrm{CFM}}$ 而言，关键是如何从中采样：先抽 $\mathbf{z}\sim\pi$，再抽 $\mathbf{x}_0\sim p_{\mathrm{src}}$，最后令

$$\mathbf{x}_t=\boldsymbol{\mu}_t(\mathbf{z})+\mathbf{A}_t(\mathbf{z})\mathbf{x}_0.$$

我们注意，当 $\Psi_{0\to t}$ 关于 $\mathbf{x}_0$ 仿射时，$p_t(\cdot\mid\mathbf{z})$ 是 Gauss 当且仅当 p_{src} 是 Gauss. 特别地，对任意（非 Gauss）p_{src}，仿射流一般产生非 Gauss 的 $p_t(\cdot\mid\mathbf{z})$.

导出的条件速度 $\mathbf{v}_t(\cdot\mid\mathbf{z})$. 条件速度 $\mathbf{v}_t(\cdot\mid\mathbf{z})$ 通过对条件流映射 $\Psi_{0\to t}$ 关于 t 求导得到. 遵循 5.3.1 的推导，考虑由流映射 $\Psi_{0\to t}(\mathbf{y};\mathbf{z})$（初值 $\mathbf{y}$）定义的条件 ODE，目标是识别相应条件速度场 $\mathbf{v}_t(\cdot\mid\mathbf{z})$：

$$\frac{\mathrm{d}}{\mathrm{d}t}\Psi_{0\to t}(\mathbf{y};\mathbf{z})=\mathbf{v}_t\left(\underbrace{\Psi_{0\to t}(\mathbf{y};\mathbf{z})}_{\mathbf{x}}\middle|\mathbf{z}\right).$$

由于 $\Psi_{0\to t}(\cdot;\mathbf{z})$ 在 $t\in(0,1)$ 可逆，可把 $\mathbf{y}$ 用当前状态 $\mathbf{x}:=\Psi_{0\to t}(\mathbf{y};\mathbf{z})$ 表示为 $\mathbf{y}=\Psi_{0\to t}^{-1}(\mathbf{x};\mathbf{z})=\Psi_{t\to 0}(\mathbf{x};\mathbf{z})$. 代入 ODE 得条件速度场构造：

$$\mathbf{v}_t(\mathbf{x}\mid\mathbf{z}):=\frac{\mathrm{d}}{\mathrm{d}t}\Psi_{0\to t}\left(\Psi_{t\to 0}(\mathbf{x};\mathbf{z});\mathbf{z}\right),$$

这显式说明导数必须沿 t 时刻到达空间点 $\mathbf{x}$ 的轨迹取.

由于 $\mathbf{x}_t=\boldsymbol{\mu}_t(\mathbf{z})+\mathbf{A}_t(\mathbf{z})\mathbf{x}_0$、$\mathbf{A}_t(\mathbf{z})$ 在 $(0,1)$ 可逆，有 $\mathbf{x}_0=\mathbf{A}_t(\mathbf{z})^{-1}(\mathbf{x}-\boldsymbol{\mu}_t(\mathbf{z}))$，给出

$$\mathbf{v}_t(\mathbf{x}\mid\mathbf{z})=\boldsymbol{\mu}_t'(\mathbf{z})+\mathbf{A}_t'(\mathbf{z})\mathbf{A}_t(\mathbf{z})^{-1}(\mathbf{x}-\boldsymbol{\mu}_t(\mathbf{z})).$$

[28]允许 $\mathbf{A}_1(\mathbf{z})$ 奇异（例如 $\mathbf{0}$）与 $(0,1)$ 上可逆性相容，并使路径在 $t=1$ 处收缩到预定端点.

单边条件（$\mathbf{z}=\mathbf{x}_1$）. 取 $\boldsymbol{\mu}_t(\mathbf{z})=b_t\mathbf{z}$、$\mathbf{A}_t(\mathbf{z})=a_t\mathbf{I}$，并取 $a_0=1, a_1=0$、$b_0=0, b_1=1$（$t\in(0,1)$ 时 $a_t>0$），得

$$\mathbf{x}_t=a_t\mathbf{x}_0+b_t\mathbf{x}_1,\qquad \mathbf{v}_t(\mathbf{x}\mid\mathbf{x}_1)=b_t'\mathbf{x}_1+\frac{a_t'}{a_t}(\mathbf{x}-b_t\mathbf{x}_1).$$

在配对样本 $(\mathbf{x}_0,\mathbf{x}_1)$（$\mathbf{x}_t=a_t\mathbf{x}_0+b_t\mathbf{x}_1$）下，这简化为通常的 CFM 目标：

$$\mathbf{v}_t(\mathbf{x}_t\mid\mathbf{x}_1)=a_t'\mathbf{x}_0+b_t'\mathbf{x}_1.$$

双边条件（$\mathbf{z}=(\mathbf{x}_0,\mathbf{x}_1)$）. 同一模板取 $\boldsymbol{\mu}_t(\mathbf{x}_0,\mathbf{x}_1)=b_t\mathbf{x}_1$、$\mathbf{A}_t(\mathbf{x}_0,\mathbf{x}_1)=a_t\mathbf{I}$，使条件路径确定性：

$$\mathbf{x}_t=a_t\mathbf{x}_0+b_t\mathbf{x}_1,\qquad p_t(\cdot\mid\mathbf{x}_0,\mathbf{x}_1)=\delta\left(\cdot-(a_t\mathbf{x}_0+b_t\mathbf{x}_1)\right),$$

条件速度为

$$\mathbf{v}_t(\mathbf{x}_t\mid\mathbf{x}_0,\mathbf{x}_1)=a_t'\mathbf{x}_0+b_t'\mathbf{x}_1,$$

即标准双边 CFM 目标.

非条件 Gauss 路径作为特例. 若 $\boldsymbol{\mu}_t$ 与 $\mathbf{z}$ 无关（记为 $\boldsymbol{\mu}(t)$）、$\mathbf{A}_t=\frac{\sigma(t)}{\sigma(0)}\mathbf{I}$，则

$$\Psi_{0\to t}(\mathbf{x}_0)=\boldsymbol{\mu}(t)+\sigma(t)\frac{\mathbf{x}_0-\boldsymbol{\mu}(0)}{\sigma(0)},\qquad \mathbf{v}_t(\mathbf{x})=\boldsymbol{\mu}'(t)+\frac{\sigma'(t)}{\sigma(t)}(\mathbf{x}-\boldsymbol{\mu}(t)),$$

这恢复了 5.3.1 中的 Gauss 密度路径与闭式速度.

5.3.4 概率路径先与流先构造的对比

两种构造都旨在通过条件动力学连接源分布 p_{src} 与目标分布 p_{tgt}. 概率路径先（Euler）视角先给出条件密度路径 $p_t(\cdot\mid\mathbf{z})$（常选自 Gauss 或仿射族），使相应速度 $\mathbf{v}_t(\cdot\mid\mathbf{z})$ 可解析求解. 流先（Lagrange）视角则直接指定条件流映射 $\Psi_{0\to t}(\cdot\mid\mathbf{z})$，并沿粒子轨迹对时间求导得到速度. 在正则性下二者给出等价传输，但在可辨识性、计算便利性与端点约束实施方式上有所不同. 下表总结对比. 要点：当条件路径容许闭式速度时，路径先自然；当对轨迹有强结构先验时，流先自然.

5.4 （可选）标准仿射流的性质

给定两个端点分布 $p_0=p_{\text{src}}$ 与 $p_1=p_{\text{tgt}}$，流匹配（FM，Lipman 等, 2022）与 Rectified Flow（RF，Liu、Gong 等, 2022）中一个自然且广泛使用的条件路径选择是线性插值

$$a_t=1-t,\qquad b_t=t,$$

得到插值

$$\mathbf{x}_t=(1-t)\mathbf{x}_0+t\mathbf{x}_1,\qquad \mathbf{x}_0\sim p_{\text{src}},\ \mathbf{x}_1\sim p_{\text{tgt}}.$$

在此选择下，训练目标简化为

$$\mathbb{E}_{t\sim\mathcal{U}[0,1]}\mathbb{E}_{\mathbf{x}_0,\mathbf{x}_1}\left[\|\mathbf{v}_\phi(\mathbf{x}_t,t)-(\mathbf{x}_1-\mathbf{x}_0)\|_2^2\right].$$

该线性流具有若干吸引人的性质. 特别地，它容许一种迭代精化格式，称为 *Reflow*，在保持边缘的同时逐步拉直分布间的路径.

表 6: 概率路径先与流先构造对比.

维度	条件概率路径先	条件流先
给定	条件密度路径 $p_t(\cdot \mid \mathbf{z})$.	条件流映射 $\Psi_{0\to t}(\cdot \mid \mathbf{z})$（轨迹，对每个固定 $\mathbf{z}$）.
求速度	对每个 $\mathbf{z}$，找 $\mathbf{v}_t(\cdot \mid \mathbf{z})$ 满足 $\partial_t p_t(\cdot \mid \mathbf{z}) + \nabla \cdot (p_t(\cdot \mid \mathbf{z})\mathbf{v}_t(\cdot \mid \mathbf{z})) = 0$；不唯一：若 $\nabla \cdot (p_t \mathbf{w}_t) = 0$，则 $\mathbf{v}_t + \mathbf{w}_t$ 给出同一 p_t.	沿（每个 $\mathbf{z}$ 的）路径：$\mathbf{v}_t(\Psi_{0\to t}(\cdot \mid \mathbf{z})) = \frac{\mathrm{d}}{\mathrm{d}t}\Psi_{0\to t}(\cdot \mid \mathbf{z})$. $\Psi_{0\to t}$ 可逆时可解 $\mathbf{v}_t(\mathbf{x} \mid \mathbf{z}) = \frac{\mathrm{d}}{\mathrm{d}t}\Psi_{0\to t}(\Psi_{0\to t}^{-1}(\mathbf{x}) \mid \mathbf{z})$.
$\mathbf{v}_t(\cdot \mid \mathbf{z})$ 闭式	当 $p_t(\cdot \mid \mathbf{z})$ 为 Gauss/指数族时方便；否则求 $\mathbf{v}_t(\cdot \mid \mathbf{z})$ 非平凡.	当 $\Psi_{0\to t}(\cdot \mid \mathbf{z})$ 具有结构（仿射/低秩）时方便；避免密度求值.
$\mathbf{v}_t(\cdot \mid \mathbf{z})$ 唯一性	对每个 $\mathbf{z}$，$\mathbf{v}_t(\cdot \mid \mathbf{z})$ 在未加选择规则（如势流 / 最小动能）时欠定.	给定 $\Psi_{0\to t}(\cdot \mid \mathbf{z})$，$p_t(\cdot \mid \mathbf{z}) = (\Psi_{0\to t}(\cdot \mid \mathbf{z}))_{\#}p_0$ 与 $\mathbf{v}_t(\cdot \mid \mathbf{z})$ 都确定；不可逆映射仍定义 $\mathbf{v}_t(\cdot \mid \mathbf{z})$ 沿轨迹，可逆映射使之唯一.
可实现性	必须验证所构造 $\mathbf{v}_t(\cdot \mid \mathbf{z})$ 在指定支撑上求解连续性方程.	按构造成立：$p_t(\cdot \mid \mathbf{z}) = (\Psi_{0\to t}(\cdot \mid \mathbf{z}))_{\#}p_0(\cdot \mid \mathbf{z})$.
匹配 $(p_{\mathrm{src}}, p_{\mathrm{tgt}})$	混合条件：$p_{\mathrm{src}} = \int p_0(\cdot \mid \mathbf{z})\pi(\mathbf{z})\,\mathrm{d}\mathbf{z}$，$p_{\mathrm{tgt}} = \int p_1(\cdot \mid \mathbf{z})\pi(\mathbf{z})\,\mathrm{d}\mathbf{z}$. 在 Gauss–仿射条件路径下，系数与 $\mathbf{z}$ 独立时，p_{src} 被迫为 Gauss. 对一般固定端点 p_{src}（可能非 Gauss），$p_t(\cdot \mid \mathbf{z})$ 的选择一般不钉住 p_{src}.	设 $\Psi_{0\to 0} = \mathrm{Id}$，并选择边界条件以命中任意 p_{tgt}.
偏好场景	扩散式构造；通过条件 Gauss $p_t(\cdot \mid \mathbf{z})$ 得到解析目标.	对映射 $\Psi_{0\to t}(\cdot \mid \mathbf{z})$ 有强结构先验；边界控制容易；容纳奇异/低维端点；天然适合基于映射的正则化/传输代价.

5.4.1 Rectifying Flows：从含噪猜测到结构化配对

经相干路径从噪声到数据. 考虑 p_{src} 为先验、p_{tgt} 为真实数据的生成任务. 我们希望一条连续路径把噪声传输到数据. 朴素策略是独立采样 $\mathbf{z}_0 \sim p_{\mathrm{src}}$、$\mathbf{x}_1 \sim p_{\mathrm{tgt}}$，插值（例如 $\mathbf{x}_t = (1-t)\mathbf{x}_0 + t\mathbf{x}_1$），并拟合一个速度场到该直线. 这造成不相干配对：各次迭代端点之间无关，轨迹起伏、方差爆炸、收敛变慢、样本质量下降.

为何独立配对不够好. 独立采样的条件流匹配使用

$$\pi(\mathbf{z}) = p_{\mathrm{src}}(\mathbf{x}_0)p_{\mathrm{tgt}}(\mathbf{x}_1),$$

或单边变体. 此类配对便于采样，却诱导出锯齿状、高方差路径，速度场难以建模.

通过相关配对整流流. 我们不依赖任意配对，而是用预训练扩散模型 $\mathbf{v}_{\phi^\times}(\cdot, t)$ 作为 PF-ODE 的漂移，确定性地传输每个源点. 从 $\mathbf{z}(0) = \mathbf{z}_0 \sim p_{\text{src}}$ 起积分

$$\frac{\mathrm{d}\mathbf{z}(t)}{\mathrm{d}t} = \mathbf{v}_{\phi^\times}(\mathbf{z}(t), t), \qquad t \in [0, 1],$$

得到 $\hat{\mathbf{z}}_1 := \mathbf{z}(1)$，它被定位在预训练模型学到的数据空间附近. 所得对 $(\mathbf{z}_0, \hat{\mathbf{z}}_1)$ 形成相关配对：它沿结构化、模型引导路径而非任意插值. 这一思想自然推广到形如 $\mathbf{x}_t = a_t\mathbf{x}_0 + b_t\mathbf{x}_1$ 的仿射参考路径，其中 $\mathbf{x}_0 \sim p_{\text{src}}$、$\mathbf{x}_1 \sim p_{\text{tgt}}$.

Algorithm 2 Rectify 操作

Require: 参考路径 $\{\mathbf{x}_t\}_{t\in[0,1]}$（例如 $\mathbf{x}_t = a_t\mathbf{x}_0 + b_t\mathbf{x}_1$）

1: **预训练扩散模型.** 在所选路径上最小化以下目标拟合 $\mathbf{v}_{\phi^\times}$：

$$\phi^\times \in \arg\min_{\phi} \mathbb{E}_{t,\mathbf{x}_0,\mathbf{x}_1}\left[\left\|\mathbf{v}_\phi(\mathbf{x}_t, t) - \frac{\mathrm{d}\mathbf{x}_t}{\mathrm{d}t}\right\|_2^2\right].$$

2: **整流.** 采样 $\mathbf{z}_0 \sim p_{\text{src}}$ 并积分

$$\frac{\mathrm{d}\mathbf{z}(t)}{\mathrm{d}t} = \mathbf{v}_{\phi^\times}(\mathbf{z}(t), t), \qquad \mathbf{z}(0) = \mathbf{z}_0,\ t \in [0, 1],$$

得到 $\hat{\mathbf{z}}_1 = \mathbf{z}(1)$ 与轨迹 $\{\mathbf{z}(t)\}_{t\in[0,1]}$.

Ensure: 相关（相干）对 $(\mathbf{z}_0, \hat{\mathbf{z}}_1)$ 或完整轨迹.

为何有效：保边缘结构. 记 $\Phi_{0\to t}$ 为由预训练扩散 $\mathbf{v}_{\phi^\times}$ 生成的上述 ODE 的流映射；则 $\mathbf{z}(t) = \Phi_{0\to t}(\mathbf{z}_0)$、$\hat{\mathbf{z}}_1 = \Phi_{0\to 1}(\mathbf{z}_0)$. Rectify 过程把每个源点与其流端点配对，给出确定性联合

$$\pi_{\text{Rectify}}(\mathbf{z}_0, \mathbf{z}_1) = p_{\text{src}}(\mathbf{z}_0)\delta\left(\mathbf{z}_1 - \Phi_{0\to 1}(\mathbf{z}_0)\right).$$

两个直接推论：

- **源边缘保持：** $\int \pi_{\text{Rectify}}(\mathbf{z}_0, \mathbf{z}_1)\,\mathrm{d}\mathbf{z}_1 = p_{\text{src}}(\mathbf{z}_0)$.
- **沿流推前：** $(\Phi_{0\to t})_{\#}p_{\text{src}} = \text{Law}(\mathbf{z}(t))$，即 t 时刻分布是 p_{src} 在 $\Phi_{0\to t}$ 下的推前.

若 $\mathbf{v}_{\phi^\times}$ 匹配给定参考路径 $\mathbf{x}_t$ 的 oracle 漂移，则所有中间边缘重合：

$$\text{Law}(\mathbf{z}(t)) = \text{Law}(\mathbf{x}_t), \qquad \text{对所有} t \in [0, 1], \quad \text{且} \quad (\Phi_{0\to 1})_{\#}p_{\text{src}} = p_{\text{tgt}}.$$

小结. Rectification 用平滑、教师引导的轨迹取代含噪独立配对，降低方差、便于优化、改善样本. 该思想覆盖标准线性路径 $\mathbf{x}_t = (1-t)\mathbf{x}_0 + t\mathbf{x}_1$ 与一般仿射形式 $\mathbf{x}_t = a_t\mathbf{x}_0 + b_t\mathbf{x}_1$.

对标准路径，反复应用 Rectify（“*Reflow*”）可在不增加传输代价的情况下进一步拉直轨迹，使训练更易.

5.4.2 Reflow：迭代拉直流

为何需要 Reflow？ 独立配对常在 p_{src} 与 p_{tgt} 之间引入不规则、蜿蜒的 ODE 轨迹，增加离散化误差与模拟方差. 这引出一个自然问题：

问题 5.4.1 (问题 5.4.1)**：** 我们能否学到一种配对，使诱导的传输路径更接近两分布之间的直线，同时仍保持正确的边缘？

这启发了 *Reflow*：反复应用 Rectify 更新配对，使后续流更易积分.

核心思想：通过 Rectify 递归拉直. 从乘积耦合上的标准线性插值开始：

$$\pi^{(0)} := p_{\text{src}}(\mathbf{x}_0)p_{\text{tgt}}(\mathbf{x}_1), \qquad \mathbf{x}_t = t\mathbf{x}_0 + (1-t)\mathbf{x}_1.$$

应用 Rectify 把独立配对替换为相关配对 $(\mathbf{z}_0, \hat{\mathbf{z}}_1)$，实证表明它在学习场下诱导出曲率更低的轨迹. 迭代此更新逐步降低路径曲率（不强制字面直线），改善数值稳定性与对齐.

Reflow 过程. 每次迭代执行两步：

- **重拟合流：**用当前配对的样本训练新速度场：

$$\phi_{k+1} = \arg\min_{\phi} \mathcal{L}\left(\phi \mid \pi^{(k)}\right), \quad \text{其中} \quad \mathcal{L}\left(\phi \mid \pi^{(k)}\right) := \mathbb{E}_{t,(\mathbf{z}_0^{(k)},\hat{\mathbf{z}}_1^{(k)})\sim\pi^{(k)}}\left[\left\|\mathbf{v}_\phi(\mathbf{z}_t,t) - (\hat{\mathbf{z}}_1^{(k)} - \mathbf{z}_0^{(k)})\right\|^2\right] \tag{5.5.4.263}$$

  且 $\mathbf{z}_t = t\mathbf{z}_0^{(k)} + (1-t)\hat{\mathbf{z}}_1^{(k)}$.

- **生成新配对：**从新源样本 $\mathbf{z}_0^{(k+1)} \sim p_{\text{src}}$ 求解学到的 ODE：

$$\hat{\mathbf{z}}_1^{(k+1)} \leftarrow \mathbf{z}_0^{(k+1)} + \int_0^1 \mathbf{v}_{\phi_{k+1}}(\mathbf{z}(t),t)\,\mathrm{d}t,$$

  并定义更新后配对：

$$\pi^{(k+1)}(\mathbf{z}_0,\mathbf{z}_1) := p_{\text{src}}(\mathbf{z}_0)\delta\left(\mathbf{z}_1 - \hat{\mathbf{z}}_1^{(k+1)}\right).$$

换言之，Reflow 可视为反复应用 Rectify 算子，产生逐步精化的配对序列：

$$\pi^{(k+1)} = \text{Rectify}\left(\pi^{(k)}\right), \tag{5.5.4.264}$$

使流与配对共同演化，得到逐步稳定的传输路径.

5.4.3 Reflow 的性质

两个关键理论性质决定了 Reflow 的用处：它降低传输代价，并拉直轨迹.

I. Reflow 从不增加传输代价. 设 $c(\mathbf{y})$ 为凸代价函数（例如 $\|\mathbf{y}\|_2^p$，$p \geq 1$）. 每步 Rectify 形成新配对 $(\mathbf{z}_0, \hat{\mathbf{z}}_1)$，其代价不差于原配对：

命题 5.4.1 (Rectify 可降低传输代价)**：** 假设速度场理想 $\mathbf{v}^* = \mathbf{v}_{\phi^\times}$，则

$$\mathbb{E}\left[c(\hat{\mathbf{z}}_1 - \mathbf{z}_0)\right] \leq \mathbb{E}\left[c(\mathbf{x}_1 - \mathbf{x}_0)\right].$$

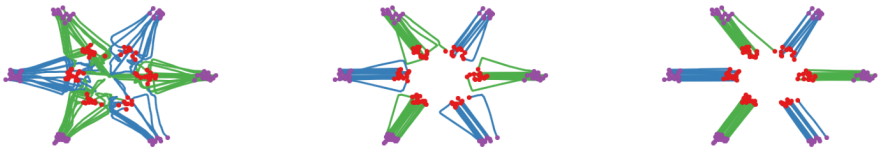
命题证明： 由 Jensen 不等式即得. 完整推导见（Liu、Gong 等, 2022）. □

递归应用此结果可知 Reflow 过程不增加传输代价.

II. Reflow 拉直路径. 迭代 Reflow 越久，学到的轨迹可能越直. 为此定义路径 $\mathbf{Y} = \{\mathbf{y}_t\}_{t\in[0,1]}$ 的平直泛函：

$$\mathcal{S}(\mathbf{Y}) := \int_0^1 \mathbb{E}\left[\left\|\mathbf{y}_1 - \mathbf{y}_0 - \frac{\mathrm{d}\mathbf{y}_t}{\mathrm{d}t}\right\|_2^2\right] \mathrm{d}t.$$

若 $\mathcal{S}(\mathbf{Y}) = 0$，则 $\mathbf{Y}$ 恰为直线.



(a) 1-rectified flow (b) 2-rectified flow (c) 3-rectified flow

Figure 5.7: Illustration of `Reflow` from Liu, Gong, *et al.* (2022). Paths become progressively straighter with `Rectify` procedure.

图 5.30: Reflow 示意（取自 Liu、Gong 等, 2022）. 路径随 Rectify 过程逐步拉直.

命题 5.4.2 (Reflow 拉直随机路径)**：** 对整流后路径 $\mathbf{Z}^{(k)}$，有

$$\min_{k\in\{0,\ldots,K\}} \mathcal{S}(\mathbf{Z}^{(k)}) \leq \frac{\mathbb{E}\left[\|\mathbf{x}_1 - \mathbf{x}_0\|^2\right]}{K}.$$

命题证明： 见 Liu（2022）定理 3.7. □

带线性插值核的 FM/RF 表述，连同 `Reflow` 过程，提供了更简单的训练目标与一种精化随机配对的实用方法. 理论细节见（Liu、Gong 等, 2022；Liu, 2022）.

III. 与最优传输的联系. 最后我们注意，直线配对在最优传输（OT）意义下并不必然最优. 这涉及 7.1 节将引入的术语；不熟悉 OT 的读者请参考该节.

二次代价最优传输的标志是粒子沿直线运动：$\mathbf{x}_0$ 处的粒子通过 $\mathbf{x}_t = (1-t)\mathbf{x}_0 + t\mathbf{T}(\mathbf{x}_0)$ 移动到 $\mathbf{T}(\mathbf{x}_0)$，其中 $\mathbf{T}$ 是最优传输映射. 但并非每个生成此类直线路径的映射 $\mathbf{S}$（即 $\mathbf{x}_t = (1-t)\mathbf{x}_0 + t\mathbf{S}(\mathbf{x}_0)$）都是最优的. $\mathbf{S}$ 给出最优流当且仅当它最小化 Monge 代价 $\mathbb{E}[\|\mathbf{x}_0 - \mathbf{S}(\mathbf{x}_0)\|^2]$. 因此，直线路径是必要而非充分条件；最优性还取决于正确的端点映射 $\mathbf{T}$.

例 5.4.1 (直线配对未必最优)**：** 设 $p_{\text{src}} = p_{\text{tgt}} = \mathcal{N}(\mathbf{0}, \mathbf{I})$. 对代价 $c(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\|^p$ $(p > 0)$，c-最优配对是恒等配对 π^*，其中 π^* 是 $(\mathbf{x}, \mathbf{x})$ 在 $\mathbf{x} \sim p_{\text{src}}$ 下的律.

现考虑由 $(\mathbf{x}, \mathbf{A}\mathbf{x})$ 的律定义的配对 $\pi_{\mathbf{A}}$，其中 $\mathbf{x} \sim p_{\text{src}}$，$\mathbf{A}$ 为满足 $\mathbf{A}^\top \mathbf{A} = \mathbf{I}$、$\det(\mathbf{A}) = 1$、$\mathbf{A} \neq \mathbf{I}$、$-1$ 不是特征值的旋转矩阵. 则 $\pi_{\mathbf{A}}$ 是 p_{src} 与 p_{tgt} 的有效配对，对应于 $\mathbf{x}$ 与 $\mathbf{A}\mathbf{x}$ 之间的直线路径，但对任意二次可微、严格凸且 Hessian 可逆的代价 c，它都不是 c-最优. 次优性来自旋转变换. 如 (7.7.5.375) 所讨论，即使去掉旋转，也未必得到最优配对. ◇

我们将在 7.5 节继续探讨与 OT 的联系.

5.5 本章小结

本章阐明了扩散模型的第三个也是最后一个基础视角，它根植于确定性流的原理. 我们的探索从归一化流（NF）开始：它利用换元公式，学习简单先验与数据分布之间精确、可逆的映射. 随后我们看到这一概念演化为连续时间过程——Neural ODE，由学习到的速度场控制变换. 然而该方法有一个显著缺点：训练循环中需要代价高昂的 ODE 模拟.

现代流匹配（FM）框架作为优雅而高效的解决方案出现. 通过预先定义概率路径 $\{p_t\}_t$ 与相应速度场（满足连续性方程），FM 为 ODE 流建立了清晰目标. 关键地，正如变分与基于分数视角中所见，FM 也使用了强大的条件技巧：它把匹配不可处理边缘速度场的问题，转化为对已知条件速度的简单易处理回归，使训练完全免模拟. 这一视角把扩散模型本身重述为 “学习把 Gauss 先验传输到数据分布的确定性流” 这一特例.

随着流视角的引入，我们对扩散建模三大概念支柱的考察告一段落. 贯穿这段旅程，一个显著模式浮现：各框架尽管起源不同（VAE、EBM 或 NF），都收敛到一个连续时间生成过程，并依赖条件策略以实现易处理学习.

下一章我们将把这些平行的线索综合进一个统一框架：

1. 形式化证明变分、基于分数与基于流视角不仅是类比，而且在基本层面上数学等价；

2. 说明 Fokker–Planck 方程如何作为普适定律支配三种视角下的密度演化，揭示它们只是描述同一核心生成原理的不同镜头.

这一统一视角将为现代扩散范式提供完整而系统的理解.

Chapter 6

扩散模型的统一与系统视角

数学就是把不同的东西叫同一个名字的艺术.

—*Henri Poincaré*

本章给出一个系统视角，把变分、基于分数与基于流的视角联系在同一幅连贯图景中. 尽管出发点各异，这些方法在现代扩散方法所依赖的核心机制上殊途同归. 在第 2 3 4 5 章的基础上，我们观察到一个共同配方：定义一个前向损坏过程，它描出一族边缘路径；再学习一个时间依赖向量场，沿该路径把简单先验传输到数据分布.

贯穿所有视角的关键要素是 6.1 节介绍的条件技巧：它把不可处理的边缘目标转化为易处理的条件目标，从而实现稳定高效的训练.

6.2 节以系统方式分析训练目标，识别其基本组分，厘清损失函数在变分、基于分数与基于流视角下如何形成.

6.3 节表明，任何形如 $\mathbf{x}_t = \alpha_t \mathbf{x}_0 + \sigma_t \boldsymbol{\epsilon}$ 的仿射噪声注入都可等价变换为标准线性调度 $\mathbf{x}_t = (1-t)\mathbf{x}_0 + t\boldsymbol{\epsilon}$. 此外，噪声预测、干净数据预测、分数预测与速度预测等常见参数化在梯度层面彼此可互换. 因此噪声调度器与参数化的选择都遵循同一建模原理.

最后，6.4 节把讨论汇合到一起，识别支配规则：Fokker–Planck 方程. 无论是视作变分格式（离散时间去噪）、基于分数方法（SDE 表述），还是基于流的方法（ODE 表述），每种方法都构造一个生成器，其边缘遵循同一密度演化. Fokker–Planck 方程因此成为三种视角共同遵守的普适约束，差异仅出现在参数化与训练目标上.

6.1 条件技巧：扩散模型的秘诀

至此，我们从三个看似不同的起源考察了扩散模型：变分、基于分数与基于流视角. 三者最初由不同目标驱动，导出各自的训练目标（固定 t）：

- **变分视角：** 学习参数化密度 $p_\phi(\mathbf{x}_{t-\Delta t} \mid \mathbf{x}_t)$ 以逼近 oracle 反向转移 $p(\mathbf{x}_{t-\Delta t} \mid \mathbf{x}_t)$，最小化：
$$\mathcal{J}_{\mathrm{KL}}(\phi) := \mathbb{E}_{p_t(\mathbf{x}_t)}\left[\mathcal{D}_{\mathrm{KL}}\left(p(\mathbf{x}_{t-\Delta t} \mid \mathbf{x}_t) \| p_\phi(\mathbf{x}_{t-\Delta t} \mid \mathbf{x}_t)\right)\right];$$
- **基于分数视角：** 学习分数模型 $\mathbf{s}_\phi(\mathbf{x}_t, t)$ 以逼近边缘分数 $\nabla_{\mathbf{x}} \log p_t(\mathbf{x}_t)$：
$$\mathcal{J}_{\mathrm{SM}}(\phi) := \mathbb{E}_{p_t(\mathbf{x}_t)}\left[\left\|\mathbf{s}_\phi(\mathbf{x}_t, t) - \nabla_{\mathbf{x}} \log p_t(\mathbf{x}_t)\right\|_2^2\right];$$
- **基于流视角：**学习速度模型 $\mathbf{v}_\phi(\mathbf{x}_t, t)$ 以匹配 oracle 速度 $\mathbf{v}_t(\mathbf{x}_t)$（例如由 (5.5.2.255) 定义），最小化：
$$\mathcal{J}_{\mathrm{FM}}(\phi) := \mathbb{E}_{p_t(\mathbf{x}_t)}\left[\left\|\mathbf{v}_\phi(\mathbf{x}_t, t) - \mathbf{v}_t(\mathbf{x}_t)\right\|_2^2\right].$$

初看这些目标似乎完全不可处理，因为它们都需要访问 oracle 量，而这些量在一般情形下根本不可知. 但精彩之处在于：每种方法都独立地想到了同一解决方案——对数据 $\mathbf{x}_0$ 进行条件化. 该技巧把每个不可处理的训练目标转化为易处理目标.

这一优雅的 “条件技巧” 把目标重写为对已知 Gauss 条件 $p_t(\mathbf{x}_t \mid \mathbf{x}_0)$ 的期望，从而得到梯度等价的闭式回归目标与易处理训练目标：

- **变分视角**（(6.6.1.265) 式）：

$$\mathcal{J}_{\mathrm{KL}}(\phi) = \underbrace{\mathbb{E}_{\mathbf{x}_0}\mathbb{E}_{p_t(\mathbf{x}_t|\mathbf{x}_0)}\left[\mathcal{D}_{\mathrm{KL}}\left(p(\mathbf{x}_{t-\Delta t} \mid \mathbf{x}_t, \mathbf{x}_0) \| p_\phi(\mathbf{x}_{t-\Delta t} \mid \mathbf{x}_t)\right)\right]}_{\mathcal{J}_{\mathrm{CKL}}(\phi)} + C; \tag{6.6.1.265}$$

- **基于分数视角**（(6.6.1.266) 式）：

$$\mathcal{J}_{\mathrm{SM}}(\phi) = \underbrace{\mathbb{E}_{\mathbf{x}_0}\mathbb{E}_{p_t(\mathbf{x}_t|\mathbf{x}_0)}\left[\left\|\mathbf{s}_\phi(\mathbf{x}_t, t) - \nabla_{\mathbf{x}_t}\log p_t(\mathbf{x}_t \mid \mathbf{x}_0)\right\|_2^2\right]}_{\mathcal{J}_{\mathrm{DSM}}(\phi)} + C; \tag{6.6.1.266}$$

- **基于流视角**（(5.5.2.254) 式）：

$$\mathcal{J}_{\mathrm{FM}}(\phi) = \underbrace{\mathbb{E}_{\mathbf{x}_0}\mathbb{E}_{p_t(\mathbf{x}_t|\mathbf{x}_0)}\left[\left\|\mathbf{v}_\phi(\mathbf{x}_t, t) - \mathbf{v}_t(\mathbf{x}_t \mid \mathbf{x}_0)\right\|^2\right]}_{\mathcal{J}_{\mathrm{CFM}}(\phi)} + C.$$

为建立统一视角，我们接下来系统重访条件 KL、分数与速度目标. 关键在于：这些目标不仅易处理，而且在相差一个常数垂直平移的意义上等价于其原始形式. 条件版本（$\mathcal{J}_{\mathrm{CKL}}$、$\mathcal{J}_{\mathrm{DSM}}$、$\mathcal{J}_{\mathrm{CFM}}$）与原始版本（$\mathcal{J}_{\mathrm{KL}}$、$\mathcal{J}_{\mathrm{SM}}$、$\mathcal{J}_{\mathrm{FM}}$）仅差这一平移，梯度不变，因而保留了优化地形. 结果是极小元仍唯一对应真实 oracle 目标，因为每个都归结为最小二乘回归问题，其解恢复相应条件期望：

$$\begin{aligned}
p^*(\mathbf{x}_{t-\Delta t} \mid \mathbf{x}_t) &= \mathbb{E}_{\mathbf{x}_0 \sim p(\cdot|\mathbf{x}_t)}\left[p(\mathbf{x}_{t-\Delta t} \mid \mathbf{x}_t, \mathbf{x}_0)\right] &&= p(\mathbf{x}_{t-\Delta t} \mid \mathbf{x}_t), \\
\mathbf{s}^*(\mathbf{x}_t, t) &= \mathbb{E}_{\mathbf{x}_0 \sim p(\cdot|\mathbf{x}_t)}\left[\nabla_{\mathbf{x}_t}\log p_t(\mathbf{x}_t \mid \mathbf{x}_0)\right] &&= \nabla_{\mathbf{x}_t}\log p_t(\mathbf{x}_t), \\
\mathbf{v}^*(\mathbf{x}_t, t) &= \mathbb{E}_{\mathbf{x}_0 \sim p(\cdot|\mathbf{x}_t)}\left[\mathbf{v}_t(\mathbf{x}_t \mid \mathbf{x}_0)\right] &&= \mathbf{v}_t(\mathbf{x}_t).
\end{aligned} \tag{6.6.1.267}$$

这并非巧合：通过使训练易处理，这些条件形式揭示了深刻的统一性. 变分扩散、基于分数的 SDE 与流匹配只是同一原理的不同侧面. 三个视角，一个洞见，优雅相连.

我们将在本章余下部分继续探讨它们的等价性.

6.2 阐明扩散模型训练损失的路线图

本节建立扩散模型训练损失的系统视图. 在 6.2.1 中，我们把标准三个目标扩展为四种参数化，展示它们如何从不同建模视角产生. 在 6.2.2 中，把这些结果提炼为一个通用框架，解构扩散目标的结构，为 6.3 的等价性结果铺垫.

6.2.1 扩散模型中四种常见参数化

本节默认前向扰动核为

$$p_t(\mathbf{x}_t \mid \mathbf{x}_0) = \mathcal{N}\left(\mathbf{x}_t; \alpha_t \mathbf{x}_0, \sigma_t^2 \mathbf{I}\right), \tag{6.6.2.268}$$

其中 $\mathbf{x}_0 \sim p_{\text{data}}$，如 (6.6.2.268) 式所定义（除非另述）.

设 $\omega : [0, T] \to \mathbb{R}_{>0}$ 为正时间加权函数. 四种标准参数化（噪声 $\boldsymbol{\epsilon}_\phi$、干净 $\mathbf{x}_\phi$、分数 $\mathbf{s}_\phi$、速度 $\mathbf{v}_\phi$）及其各自极小元 $\boldsymbol{\epsilon}^*$、$\mathbf{x}^*$、$\mathbf{s}^*$、$\mathbf{v}^*$ 总结如下，以便对照并方便后续讨论.

变分视角. 基于 DDPM 中的 KL 散度（见 2.2.5 与 4.3 节），该方法归结为预测产生 $\mathbf{x}_t$ 的期望噪声，或 $\mathbf{x}_t$ 所来自的期望干净信号.

1. **$\boldsymbol{\epsilon}$-预测（噪声预测）**（Ho 等, 2020）:

$$\boldsymbol{\epsilon}_\phi(\mathbf{x}_t, t) \approx \mathbb{E}[\boldsymbol{\epsilon} \mid \mathbf{x}_t] = \boldsymbol{\epsilon}^*(\mathbf{x}_t, t) \tag{6.6.2.269}$$

   训练目标

$$\mathcal{L}_{\text{noise}}(\phi) := \mathbb{E}_t \left[\omega(t) \mathbb{E}_{\mathbf{x}_0, \boldsymbol{\epsilon}} \left\| \boldsymbol{\epsilon}_\phi(\mathbf{x}_t, t) - \boldsymbol{\epsilon} \right\|_2^2 \right].$$

   这里 $\boldsymbol{\epsilon}^*$ 指为得到给定 $\mathbf{x}_t$ 而注入的平均噪声.

2. **$\mathbf{x}$-预测（干净预测）**（Kingma 等, 2021; Karras 等, 2022; Song 等, 2023）:

$$\mathbf{x}_\phi(\mathbf{x}_t, t) \approx \mathbb{E}[\mathbf{x}_0 \mid \mathbf{x}_t] = \mathbf{x}^*(\mathbf{x}_t, t) \tag{6.6.2.270}$$

   训练目标

$$\mathcal{L}_{\text{clean}}(\phi) := \mathbb{E}_t \left[\omega(t) \mathbb{E}_{\mathbf{x}_0, \boldsymbol{\epsilon}} \left\| \mathbf{x}_\phi(\mathbf{x}_t, t) - \mathbf{x}_0 \right\|_2^2 \right].$$

   这里 $\mathbf{x}^*$ 指给定含噪观测 $\mathbf{x}_t$ 下所有合理干净猜测的平均.

基于分数视角. 预测噪声级 t 处的分数函数，它指向把 $\mathbf{x}_t$ 去噪回所有可能干净样本的平均方向:

3. **分数预测**（Song 与 Ermon, 2019; Song 等, 2020c）:

$$\mathbf{s}_\phi(\mathbf{x}_t, t) \approx \nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t) = \mathbb{E}\left[\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t \mid \mathbf{x}_0) \mid \mathbf{x}_t \right] = \mathbf{s}^*(\mathbf{x}_t, t) \tag{6.6.2.271}$$

   训练目标

$$\mathcal{L}_{\text{score}}(\phi) := \mathbb{E}_t \left[\omega(t) \mathbb{E}_{\mathbf{x}_0, \boldsymbol{\epsilon}} \left\| \mathbf{s}_\phi(\mathbf{x}_t, t) - \nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t \mid \mathbf{x}_0) \right\|_2^2 \right],$$

   其中条件分数满足 $\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t \mid \mathbf{x}_0) = -\frac{1}{\sigma_t} \boldsymbol{\epsilon}$.

基于流视角. 预测数据经过 $\mathbf{x}_t$ 时的瞬时平均速度：

4. **v-预测（速度预测）**（Lipman 等, 2022；Liu, 2022；Salimans 与 Ho, 2021；Albergo 等, 2023）：

$$\mathbf{v}_\phi(\mathbf{x}_t, t) \approx \mathbb{E}\left[\frac{\mathrm{d}\mathbf{x}_t}{\mathrm{d}t}\middle|\mathbf{x}_t\right] = \mathbf{v}^*(\mathbf{x}_t, t) \tag{6.6.2.272}$$

训练目标

$$\mathcal{L}_{\text{velocity}}(\phi) := \mathbb{E}_t\left[\omega(t)\mathbb{E}_{\mathbf{x}_0,\boldsymbol{\epsilon}}\left\|\mathbf{v}_\phi(\mathbf{x}_t, t) - \mathbf{v}_t(\mathbf{x}_t \mid \mathbf{x}_0, \boldsymbol{\epsilon})\right\|_2^2\right],$$

其中条件速度为 $\mathbf{v}_t(\mathbf{x}_t \mid \mathbf{x}_0, \boldsymbol{\epsilon}) = \alpha_t'\mathbf{x}_0 + \sigma_t'\boldsymbol{\epsilon}$.

这里 $\mathbf{v}^*$ 表示经过观测点 $\mathbf{x}_t$ 的平均速度向量.

基于 (6.6.1.267) 的洞见，四种预测类型最终都旨在逼近条件期望——即给定观测 $\mathbf{x}_t$ 下的平均噪声、干净数据、分数或速度.

6.2.2 解构扩散模型的训练目标

如 6.2.1 所示，四种预测类型的目标函数通常共享以下扩散训练模板：

$$\mathcal{L}(\phi) := \mathbb{E}_{\mathbf{x}_0,\boldsymbol{\epsilon}}\underbrace{\mathbb{E}_{p_{\text{time}}(t)}}_{\text{时间分布}}\left[\underbrace{\omega(t)}_{\text{时间加权}}\underbrace{\left\|\mathbf{NN}_\phi(\mathbf{x}_t, t) - (A_t\mathbf{x}_0 + B_t\boldsymbol{\epsilon})\right\|_2^2}_{\text{MSE 部分}}\right]. \tag{6.6.2.273}$$

为提升训练效率并优化扩散模型学习流水线，若干关键设计选择至关重要（Karras 等, 2022；Lu 与 Song, 2024）：

- (A) $\mathbf{x}_t$ 前向过程中的噪声调度，由 α_t 与 σ_t 决定；
- (B) $\mathbf{NN}_\phi$ 的预测类型及相应回归目标 $(A_t\mathbf{x}_0 + B_t\boldsymbol{\epsilon})$；
- (C) 时间加权函数 $\omega(\cdot) : [0, T] \to \mathbb{R}_{\geq 0}$；
- (D) 时间分布 p_{time}.

下面详述这四个组分，作为后续讨论的路线图.

(A) 噪声调度 α_t 与 σ_t. 用户可灵活选择贴合应用的调度，常见示例见表 7. 重要的是，我们将在 (6.6.3.276) 与 (6.6.3.278) 式中证明，所有形如 $\mathbf{x}_t = \alpha_t\mathbf{x}_0 + \sigma_t\boldsymbol{\epsilon}$ 的仿射流都数学等价. 具体地，任何此类插值都可通过适当的时间重参数化与空间缩放，转换为标准线性调度（$\alpha_t = 1 - t, \sigma_t = t$）或三角调度（$\alpha_t = \cos t, \sigma_t = \sin t$）.

表 7: 常见的仿射概率路径调度 (α_t, σ_t)，其中 $t \in [0,T]$，且归一化常数满足 $\alpha_t^2 + \sigma_t^2 = 1$（除线性调度外）.

调度名称	α_t	σ_t
线性（Rectified Flow / 标准 FM）	$1-t$	t
三角（sCM / Heun 整流）	$\cos\left(\frac{\pi}{2}t\right)$	$\sin\left(\frac{\pi}{2}t\right)$
VP SDE 前向核	$\exp\left(-\frac{1}{2}\int_0^t \beta(s)\,ds\right)$	$\sqrt{1-\alpha_t^2}$
VE SDE 前向核	1	$\sigma_{\min}\left(\sigma_{\max}/\sigma_{\min}\right)^t$
DDPM 离散加噪	$\prod_{i=1}^t \sqrt{1-\beta_i}$	$\sqrt{1-\alpha_t^2}$

(B) 参数化 NN_ϕ 与训练目标 $A_t\mathbf{x}_0 + B_t\boldsymbol{\epsilon}$. 用户可灵活选择模型的预测目标：干净信号、噪声、分数或速度预测. 如 6.2.1 所述，所有这些预测类型共享形如

$$\text{回归目标} = A_t\mathbf{x}_0 + B_t\boldsymbol{\epsilon}$$

的公共回归目标，其中系数 A_t、B_t 同时依赖所选预测类型与调度 (α_t, σ_t). 这些关系总结在表 8 中.

虽然四种参数化看似不同，但我们将在 (6.6.3.274) 式中证明，它们可通过简单代数变换相互转换. 此外，我们还将在 (6.6.3.279) 式中表明，(6.6.2.273) 中的平方-ℓ_2 损失项在所有预测类型下梯度等价，仅相差一个时间加权因子（$\omega(t)p_{\text{time}}(t)$ 之外），且该因子仅取决于噪声调度 (α_t, σ_t).

表 8: 不同参数化之间关系总结. 四种参数化数学等价，可通过直接代数变换相互转换.

$$\text{回归目标} = A_t\mathbf{x}_0 + B_t\boldsymbol{\epsilon}$$

	A_t	B_t
Clean	1	0
Noise	0	1
Conditional Score	0	$-\frac{1}{\sigma_t}$
Conditional Velocity	α_t'	σ_t'

(C) 时间分布 $p_{\text{time}}(t)$. 由于训练损失是对 t 的期望，从 $p_{\text{time}}(t)$ 采样时间在数学上等价于用 $p_{\text{time}}(t)$ 对每- t MSE 加权；该因子可吸收进已有时间加权 $\omega(t)$[29]. 但实证证据[30]表明不同 $p_{\text{time}}(t)$ 选择会影响性能. 因此我们分别讨论时间分布 $p_{\text{time}}(t)$ 与时间加权函数 $\omega(t)$.

[29]我们关于时间的目标总体损失为 $\mathcal{L} = \int_0^T \omega(t)\mathbf{mse}(t)\,\mathrm{d}t$，其中 $\mathbf{mse}(t)$ 表示每- t 的 MSE 项. 若训练时从 $t \sim p_{\text{time}}(t)$ 采样，则 $\widehat{\mathcal{L}} = \mathbb{E}_{t\sim p_{\text{time}}}\left[\frac{\omega(t)}{p_{\text{time}}(t)}\mathbf{mse}(t)\right]$ 给出 $\mathcal{L}$ 的无偏 Monte Carlo 估计，即采样与加权通过重要性加权可互换.

[30]实践中，我们在离散时间集上用 minibatch SGD 近似训练目标. 在此近似下，不同 $p_{\text{time}}(t)$ 的选择同时改变梯度方差与每步的有效权重. 因此我们分别讨论 $p_{\text{time}}(t)$（采样）与 $\omega(t)$（加权）.

时间分布的常见选择是 $[0,T]$ 上的均匀分布（Ho 等, 2020；Song 等, 2020c；Lipman 等, 2022；Liu, 2022）. 其他选项包括对数正态分布（Karras 等, 2022）与自适应重要性采样方法（Song 等, 2021；Kingma 等, 2021）.

(D) 时间加权函数 $\omega(t)$. 加权函数的常见选择是常数加权 $\omega \equiv 1$（Ho 等, 2020；Karras 等, 2022；Lipman 等, 2022；Liu, 2022），但也提出了自适应加权方案（Karras 等, 2023）. $\omega(t)$ 的某些选择把 (6.6.2.273) 变换为负对数似然的更紧上界，有效地把目标重述为极大似然训练. 值得注意的加权方案包括取 $\omega(t) = g^2(t)$（Song 等, 2021），其中 g 是 (4.4.3.184) 式前向 SDE 的扩散系数. 其他方法使用信噪比（SNR）加权（Kingma 等, 2021）或单调加权函数（Kingma 与 Gao, 2023），其中 $\omega(t)$ 是时间的单调函数.

总之，无论噪声调度器、预测类型或时间采样分布如何选择，这些因素理论上都收敛到影响目标函数中的时间加权. 该时间加权可影响实际训练地形，进而影响模型性能.

6.3 扩散模型中的等价性

6.2.1 介绍的四种预测类型将在 6.3.1 中被证明在梯度最小化下等价. 随后 6.3.3 把这一视角拓宽，表明不同前向噪声调度通过简单时间与空间缩放相互联系.

6.3.1 四种预测类型等价

我们先分析 (6.6.2.273) 中组件 (B) 的设计选择.

我们已看到四种预测类型并非独立选择，而是对同一底层量的不同视角. 例如噪声与干净预测直接相关（见 2.2 节），分数与噪声预测也相关（见 3.3.4 节）. 这一反复出现的模式指向更深的原理：四种参数化代数等价，可通过简单变换相互转换. 为使这一联系精确，我们陈述以下命题，图 6.31 给出示意，遵循（Kingma 等, 2021）.

命题 6.3.1 (参数化等价性)**：** *设最小化各自目标的最优预测为*

$$\boldsymbol{\epsilon}^*(\mathbf{x}_t,t), \quad \mathbf{x}^*(\mathbf{x}_t,t), \quad \mathbf{s}^*(\mathbf{x}_t,t), \quad \mathbf{v}^*(\mathbf{x}_t,t),$$

分别对应噪声、干净、分数与速度参数化. 它们满足以下等价关系：

$$\begin{aligned}
\boldsymbol{\epsilon}^*(\mathbf{x}_t,t) &= -\sigma_t \mathbf{s}^*(\mathbf{x}_t,t),\\
\mathbf{x}^*(\mathbf{x}_t,t) &= \frac{1}{\alpha_t}\mathbf{x}_t + \frac{\sigma_t^2}{\alpha_t}\mathbf{s}^*(\mathbf{x}_t,t),\\
\mathbf{v}^*(\mathbf{x}_t,t) &= \alpha_t'\mathbf{x}^* + \sigma_t'\boldsymbol{\epsilon}^* = f(t)\mathbf{x}_t - \tfrac{1}{2}g^2(t)\mathbf{s}^*(\mathbf{x}_t,t).
\end{aligned} \tag{6.6.3.274}$$

这里 $f(t)$ 与 $g(t)$ 通过 4.4.1 与 α_t、σ_t 相关. 此外，这些极小元满足 (6.6.2.269)–(6.6.2.272) 中的恒等式.

命题证明： 证明与 4.2.1 定理类似，后者分析了 DSM 目标下各种匹配损失的全局最优. 详见附录 D.4. □

(6.6.3.274) 式在每个 t（给定前向加噪系数）下诱导四种参数化

$$\boldsymbol{\epsilon}_\phi(\mathbf{x}_t,t), \quad \mathbf{x}_\phi(\mathbf{x}_t,t), \quad \mathbf{s}_\phi(\mathbf{x}_t,t), \quad \mathbf{v}_\phi(\mathbf{x}_t,t)$$

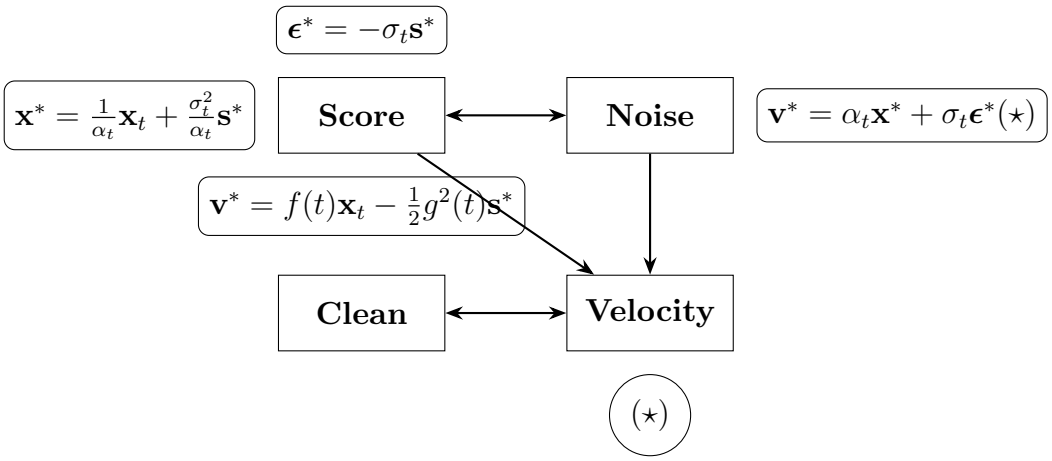


图 6.31: 四种参数化之间的等价关系. v-预测由 $\mathbf{v}^* = \alpha_t \mathbf{x}^* + \sigma_t \boldsymbol{\epsilon}^*$ 给出，而干净与 $\boldsymbol{\epsilon}$-预测通过 $\mathbf{x}_t = \alpha_t \mathbf{x}^* + \sigma_t \boldsymbol{\epsilon}^*$ 可互换.

之间的一一转换.

实践中，我们用一种参数化（例如 $\boldsymbol{\epsilon}_\phi$）训练单个网络. 其他量通过 (6.6.3.274) 的转换事后定义.

6.3.2 不同参数化下的 PF-ODE

PF-ODE 容许若干等价参数化（分数、噪声、去噪与速度）. 原理上虽可互换，选择却有实际后果：它改变向量场的刚性、离散化误差行为与优化难易. 对使用高级 ODE 求解器的快速采样（见第 9 章），从业者常用 $\boldsymbol{\epsilon}$ 或 $\mathbf{x}$ 预测，因为它们与求解器输入对齐、减少误差累积. 对只用少量函数评估训练生成器的情形（见第 11 章），$\mathbf{x}$ 或 $\mathbf{v}$ 预测常给出更平滑的目标与更好的步间一致性.

我们写出每种参数化下的 PF-ODE，并用 (6.6.3.274) 显式转换. 结果汇总为以下命题.

命题 6.3.2： 不同参数化下的 PF-ODE 设 α_t 与 σ_t 为前向扰动调度，记时间导数 $\alpha_t' := \frac{\mathrm{d}\alpha_t}{\mathrm{d}t}$、$\sigma_t' := \frac{\mathrm{d}\sigma_t}{\mathrm{d}t}$. 则经验 PF-ODE 有等价形式

$$\begin{aligned}
\frac{\mathrm{d}\mathbf{x}(t)}{\mathrm{d}t} &= \frac{\alpha_t'}{\alpha_t}\mathbf{x}(t) - \sigma_t\left(\frac{\alpha_t'}{\alpha_t} - \frac{\sigma_t'}{\sigma_t}\right)\boldsymbol{\epsilon}^*(\mathbf{x}(t), t) \\
&= \frac{\sigma_t'}{\sigma_t}\mathbf{x}(t) + \alpha_t\left(\frac{\alpha_t'}{\alpha_t} - \frac{\sigma_t'}{\sigma_t}\right)\mathbf{x}^*(\mathbf{x}(t), t) \\
&= \frac{\alpha_t'}{\alpha_t}\mathbf{x}(t) + \sigma_t^2\left(\frac{\alpha_t'}{\alpha_t} - \frac{\sigma_t'}{\sigma_t}\right)\mathbf{s}^*(\mathbf{x}(t), t) \\
&= \alpha_t'\mathbf{x}^*(\mathbf{x}(t), t) + \sigma_t'\boldsymbol{\epsilon}^*(\mathbf{x}(t), t) \\
&= \mathbf{v}^*(\mathbf{x}(t), t). \qquad (6.6.3.275)
\end{aligned}$$

为看到 Score SDE 记号，回顾 4.4.1 . 若设

$$f(t) = \frac{\alpha_t'}{\alpha_t}, \qquad g^2(t) = \frac{\mathrm{d}}{\mathrm{d}t}(\sigma_t^2) - 2\frac{\alpha_t'}{\alpha_t}\sigma_t^2 = 2\sigma_t\sigma_t' - 2\frac{\alpha_t'}{\alpha_t}\sigma_t^2,$$

则 PF-ODE 可写成熟悉的 Score SDE 形式：

$$\frac{\mathrm{d}\mathbf{x}(t)}{\mathrm{d}t} = f(t)\mathbf{x}(t) - \tfrac{1}{2}g^2(t)\mathbf{s}^*(\mathbf{x}(t), t).$$

为具体说明 PF-ODE 如何被离散化用于采样，我们将在 9.2 节给出广泛使用的 DDIM 方案这一基于扩散的 ODE 采样器的更新规则. 该例子将展示 Euler 离散化如何自然地与 PF-ODE 联系.

6.3.3 所有仿射流等价

我们接下来分析 (6.6.2.273) 中组件 (A) 的设计选择.

状态级等价. FM（Lipman 等, 2022）与 RF（Liu, 2022）中使用的一种方便标准插值是

$$\mathbf{x}_t^{\mathrm{FM}} = (1-t)\mathbf{x}_0 + t\boldsymbol{\epsilon} = \mathbf{x}_0 + t(\boldsymbol{\epsilon} - \mathbf{x}_0),$$

其速度为常向量 $\boldsymbol{\epsilon} - \mathbf{x}_0$. 本节的关键是：这种选择表面上的简单并非本质——任何仿射插值

$$\mathbf{x}_t = \alpha_t\mathbf{x}_0 + \sigma_t\boldsymbol{\epsilon}$$

都可写成标准路径的时间重参数化与空间缩放版本. 定义

$$c(t) := \alpha_t + \sigma_t, \qquad \tau(t) := \frac{\sigma_t}{\alpha_t + \sigma_t} \quad (c(t) \neq 0).$$

直接代数改写得

$$\begin{aligned}
\mathbf{x}_t &= \alpha_t\mathbf{x}_0 + \sigma_t\boldsymbol{\epsilon} \\
&= (\alpha_t + \sigma_t)\left(\frac{\alpha_t}{\alpha_t + \sigma_t}\mathbf{x}_0 + \frac{\sigma_t}{\alpha_t + \sigma_t}\boldsymbol{\epsilon}\right) \\
&= c(t)\left((1-\tau(t))\mathbf{x}_0 + \tau(t)\boldsymbol{\epsilon}\right) = c(t)\mathbf{x}_{\tau(t)}^{\mathrm{FM}}.
\end{aligned}$$

因此每条仿射路径都是标准 FM 路径在变量替换 $t \mapsto \tau(t)$ 与空间缩放 $\mathbf{x} \mapsto c(t)\mathbf{x}$ 下的像. 等式逐点成立，因而在分布意义下也成立.

对相应速度，对 $\mathbf{x}_t = c(t)\mathbf{x}_{\tau(t)}^{\mathrm{FM}}$ 应用链式法则：

$$\begin{aligned}
\mathbf{v}(\mathbf{x}_t, t) &:= \frac{\mathrm{d}}{\mathrm{d}t}(\alpha_t\mathbf{x}_0 + \sigma_t\boldsymbol{\epsilon}) \\
&= \frac{\mathrm{d}}{\mathrm{d}t}\left(c(t)\mathbf{x}_{\tau(t)}^{\mathrm{FM}}\right) \\
&= c'(t)\mathbf{x}_{\tau(t)}^{\mathrm{FM}} + c(t)\tau'(t)\left.\frac{\mathrm{d}}{\mathrm{d}s}\mathbf{x}_s^{\mathrm{FM}}\right|_{s=\tau(t)} \\
&= c'(t)\mathbf{x}_{\tau(t)}^{\mathrm{FM}} + c(t)\tau'(t)\mathbf{v}^{\mathrm{FM}}\left(\mathbf{x}_{\tau(t)}^{\mathrm{FM}}, \tau(t)\right),
\end{aligned}$$

因为沿标准路径 $\mathbf{v}^{\mathrm{FM}}(\mathbf{x}_\tau^{\mathrm{FM}}, \tau) = -\mathbf{x}_0 + \boldsymbol{\epsilon}$.

我们把上述推导总结为以下命题.

命题 6.3.3 (仿射流等价性)**：** 设 $\mathbf{x}_t^{\mathrm{FM}} = (1-t)\mathbf{x}_0 + t\boldsymbol{\epsilon}$，$\mathbf{x}_t = \alpha_t \mathbf{x}_0 + \sigma_t \boldsymbol{\epsilon}$，且 $c(t) := \alpha_t + \sigma_t \neq 0$、$\tau(t) := \sigma_t/(\alpha_t + \sigma_t)$. 则

$$\begin{aligned} \mathbf{x}_t &= c(t)\mathbf{x}_{\tau(t)}^{\mathrm{FM}}, \\ \mathbf{v}(\mathbf{x}_t, t) &= c'(t)\mathbf{x}_{\tau(t)}^{\mathrm{FM}} + c(t)\tau'(t)\mathbf{v}^{\mathrm{FM}}\left(\mathbf{x}_{\tau(t)}^{\mathrm{FM}}, \tau(t)\right). \end{aligned} \tag{6.6.3.276}$$

特别地，所有仿射插值在相差时间重参数化与空间缩放的意义下等价.

与三角流的等价性. 另一个广泛使用的仿射流是三角插值（Salimans 与 Ho, 2021；Albergo 等, 2023；Lu 与 Song, 2024）. 作为具体例子，我们还展示任何仿射流都可表为该形式. 三角路径定义为

$$\mathbf{x}_u^{\mathrm{Trig}} := \cos(u)\mathbf{x}_0 + \sin(u)\boldsymbol{\epsilon}. \tag{6.6.3.277}$$

设 $R_t := \sqrt{\alpha_t^2 + \sigma_t^2}$，并设 $R_t > 0$. 选角 τ_t 使

$$\cos\tau_t = \frac{\alpha_t}{R_t}, \qquad \sin\tau_t = \frac{\sigma_t}{R_t}.$$

则每条仿射插值 $\mathbf{x}_t = \alpha_t\mathbf{x}_0 + \sigma_t\boldsymbol{\epsilon}$ 都是缩放并重定时的三角路径：

$$\mathbf{x}_t = \alpha_t\mathbf{x}_0 + \sigma_t\boldsymbol{\epsilon} = R_t\left(\frac{\alpha_t}{R_t}\mathbf{x}_0 + \frac{\sigma_t}{R_t}\boldsymbol{\epsilon}\right) = R_t\mathbf{x}_{\tau_t}^{\mathrm{Trig}}. \tag{6.6.3.278}$$

对 (α_t, σ_t) 是平面上一点. 用 R_t 归一化将其放到单位圆上，固定角 τ_t，从而固定状态 $\mathbf{x}_{\tau_t}^{\mathrm{Trig}}$；半径 R_t 给出整体尺度.

对 $\mathbf{x}_u^{\mathrm{Trig}}$ 关于 u 求导得速度：

$$\mathbf{v}_u^{\mathrm{Trig}} = -\sin(u)\mathbf{x}_0 + \cos(u)\boldsymbol{\epsilon}.$$

通过 (6.6.3.278) 中相同的变量替换，这一关系给出速度的闭式转换（对其他参数化类似）.

总结上述讨论，得到以下结论：

注 6.3.1 (结论 6.3.1)**：** 无论调度 (α_t, σ_t) 如何（包括 VE、VP（如三角）、FM 或 RF），仿射插值都可通过适当的时间变量替换与标量缩放相互转换. ◇

四种参数化的训练目标. 设 $\mathbf{x}_t = \alpha_t\mathbf{x}_0 + \sigma_t\boldsymbol{\epsilon}$，$\sigma_t > 0$，$(\alpha_t, \sigma_t)$ 可微且 $\alpha_t'\sigma_t - \alpha_t\sigma_t' \neq 0$. 考虑 oracle 目标

$$\boldsymbol{\epsilon}^*(\mathbf{x}_t, t) = \mathbb{E}[\boldsymbol{\epsilon} \mid \mathbf{x}_t], \quad \mathbf{x}_0^*(\mathbf{x}_t, t) = \mathbb{E}[\mathbf{x}_0 \mid \mathbf{x}_t], \quad \mathbf{v}^*(\mathbf{x}_t, t) = \mathbb{E}[\alpha_t'\mathbf{x}_0 + \sigma_t'\boldsymbol{\epsilon} \mid \mathbf{x}_t].$$

由 6.3.1 ，它们满足

$$\nabla_{\mathbf{x}_t}\log p_t(\mathbf{x}_t) = -\frac{1}{\sigma_t}\boldsymbol{\epsilon}^*(\mathbf{x}_t, t) = \frac{\alpha_t}{\sigma_t^2}\left(\mathbf{x}_0^*(\mathbf{x}_t, t) - \frac{\mathbf{x}_t}{\alpha_t}\right), \qquad \mathbf{v}^* = \alpha_t'\mathbf{x}_0^* + \sigma_t'\boldsymbol{\epsilon}^*.$$

在头部转换

$$\mathbf{s}_\phi \equiv -\frac{1}{\sigma_t}\boldsymbol{\epsilon}_\phi \equiv \frac{\alpha_t}{\sigma_t^2}\left(\mathbf{x}_\phi - \frac{\mathbf{x}_t}{\alpha_t}\right),$$

以及速度到分数转换

$$\mathbf{s}_\phi = \frac{\alpha_t}{\sigma_t(\alpha_t'\sigma_t - \alpha_t\sigma_t')}\mathbf{v}_\phi - \frac{\alpha_t'}{\sigma_t(\alpha_t'\sigma_t - \alpha_t\sigma_t')}\mathbf{x}_t,$$

下，逐样本平方损失匹配时间依赖权重：

$$\begin{aligned}\|\mathbf{s}_\phi - \nabla_{\mathbf{x}_t}\log p_t(\mathbf{x}_t)\|_2^2 &= \frac{1}{\sigma_t^2}\|\boldsymbol{\epsilon}_\phi - \boldsymbol{\epsilon}^*\|_2^2 \\ &= \frac{\alpha_t^2}{\sigma_t^4}\|\mathbf{x}_\phi - \mathbf{x}_0^*\|_2^2 \\ &= \left(\frac{\alpha_t}{\sigma_t(\alpha_t'\sigma_t - \alpha_t\sigma_t')}\right)^2\|\mathbf{v}_\phi - \mathbf{v}^*\|_2^2. \end{aligned} \tag{6.6.3.279}$$

由 6.3.3 ，任意仿射流 $\mathbf{x}_t = \alpha_t\mathbf{x}_0 + \sigma_t\boldsymbol{\epsilon}$ 都可经 $\mathbf{x}_t = c(t)\mathbf{x}_{\tau(t)}^{\mathrm{FM}}$（$c(t) = \alpha_t + \sigma_t$、$\tau(t) = \sigma_t/(\alpha_t + \sigma_t)$）迁移到标准 FM 路径. 求导得

$$\mathbf{v}_\phi(\mathbf{x}_t, t) = c'(t)\mathbf{x}_{\tau(t)}^{\mathrm{FM}} + c(t)\tau'(t)\mathbf{v}_\phi^{\mathrm{FM}}\left(\mathbf{x}_{\tau(t)}^{\mathrm{FM}}, \tau(t)\right), \qquad \mathbf{x}_{\tau(t)}^{\mathrm{FM}} = \frac{\mathbf{x}_t}{c(t)},$$

对 $\mathbf{v}^*$ 同样成立. 因此速度损失变换为

$$\|\mathbf{v}_\phi(\mathbf{x}_t, t) - \mathbf{v}^*(\mathbf{x}_t, t)\|_2^2 = (c(t)\tau'(t))^2\left\|\mathbf{v}_\phi^{\mathrm{FM}}\left(\frac{\mathbf{x}_t}{c(t)}, \tau(t)\right) - (\mathbf{v}^{\mathrm{FM}})^*\left(\frac{\mathbf{x}_t}{c(t)}, \tau(t)\right)\right\|_2^2.$$

基于上述观察，得到以下结论：

注 6.3.2 (结论 6.3.2)**：** 分数、噪声、干净与速度训练目标在相差时间依赖权重（对速度而言还包含一个由 (α_t, σ_t) 决定、涉及 $\mathbf{x}_t$ 的仿射头部转换）的意义下，理论上等价.◇

6.3.4 （可选）参数化与标准流的概念分析

尽管前几节已表明四种参数化数学等价且可相互转换，前向仿射噪声注入流等价于标准形式

$$\mathbf{x}_t^{\mathrm{FM}} = (1-t)\mathbf{x}_0 + t\boldsymbol{\epsilon},$$

本节仍提供直觉，并分析把 v-预测参数化与该标准仿射流结合的潜在优势.

本节问一个简单问题：不同参数化与调度如何塑造模型所学以及我们如何采样？我们分三步推进：

- **回归目标与调度.** 我们聚焦为何把 v-预测与标准线性调度 $(\alpha_t, \sigma_t) = (1-t, t)$ 结合是自然的：它在时间上保持稳定的目标尺度，并消除动力学中的曲率效应.
- **对求解器的影响.** 我们考察该参数化如何与数值积分方案概念交互，具体例子（Euler 求解器与 Heun 方法）留待 9.2.2 与 9.4.5 节.

在继续之前，我们区分两类速度场以避免歧义. 条件速度用作易处理训练目标，定义为

$$\mathbf{v}_t(\mathbf{x}_t \mid \mathbf{z}) = \mathbf{x}_t' = \alpha_t' \mathbf{x}_0 + \sigma_t' \boldsymbol{\epsilon}, \qquad \text{其中} \mathbf{z} = (\mathbf{x}_0, \boldsymbol{\epsilon}),$$

而推断中用于移动样本的 *oracle*（边缘化）速度（用于 PF-ODE 求解）由

$$\mathbf{v}^*(\mathbf{x}, t) = \mathbb{E}\left[\mathbf{v}_t(\cdot \mid \mathbf{z}) \mid \mathbf{x}_t = \mathbf{x}\right]$$

给出.

视角 1：为何 $(\alpha_t, \sigma_t) = (1-t, t)$ 是自然调度. 记 $\sigma_t := \rho(t)$、$\alpha_t := 1 - \rho(t)$（$\rho(t)$ 随时间变化），条件速度变为

$$\mathbf{v}_t(\mathbf{x}_t \mid \mathbf{z}) = \rho'(t)(\boldsymbol{\epsilon} - \mathbf{x}_0), \qquad \text{其中} \mathbf{z} = (\mathbf{x}_0, \boldsymbol{\epsilon}).$$

单位尺度回归目标. 对标准调度 $\rho(t) = t$，条件速度 $\mathbf{v}_t(\cdot \mid \mathbf{z})$ 满足

$$\mathbb{E}\left[\|\mathbf{v}_t(\cdot \mid \mathbf{z})\|_2^2\right] = \mathbb{E}_{\boldsymbol{\epsilon}}\left[\|\boldsymbol{\epsilon}\|_2^2\right] + \mathbb{E}_{\mathbf{x}_0}\|\mathbf{x}_0\|_2^2 = D + \underbrace{\operatorname{Tr}\operatorname{Cov}[\mathbf{x}_0]}_{\text{总方差}} + \underbrace{\|\mathbb{E}\mathbf{x}_0\|_2^2}_{\text{均值}}. \tag{6.6.3.280}$$

因此期望目标幅值与 t 无关. 在数据标准化为零均值、单位协方差（即 $\operatorname{Cov}[\mathbf{x}_0] = \mathbf{I}$）后，两项 $\alpha_t'\mathbf{x}_0$ 与 $\sigma_t'\boldsymbol{\epsilon}$ 对所有 t 贡献相当，避免端点附近梯度爆炸/消失. 为此考察扩散训练目标：

$$\mathcal{L}_{\text{velocity}}(\phi) = \mathbb{E}_t \mathbb{E}_{\mathbf{x}_0, \boldsymbol{\epsilon}}\left[\|\mathbf{v}_\phi(\mathbf{x}_t, t) - \mathbf{v}_t(\mathbf{x}_t \mid \mathbf{z})\|_2^2\right].$$

对模型参数 ϕ 应用链式法则，该损失的梯度为

$$\nabla_\phi \mathcal{L}_{\text{velocity}}(\phi) = 2\mathbb{E}_t \mathbb{E}_{\mathbf{x}_0, \boldsymbol{\epsilon}}\left[\partial_\phi \mathbf{v}_\phi(\mathbf{x}_t, t)^\top (\mathbf{v}_\phi(\mathbf{x}_t, t) - \mathbf{v}_t(\mathbf{x}_t \mid \mathbf{z}))\right].$$

因此目标尺度 $\|\mathbf{v}_t(\mathbf{x}_t \mid \mathbf{z})\|_2$ 影响梯度稳定性：若它在某 t 处塌缩为 0（或爆炸），则梯度趋于消失（或爆炸）. 在标准选择 $\rho(t) = t$ 下，(6.6.3.280) 给出与 t 无关的目标幅值，因此端点处（$t = 0$ 或 $t = 1$）不会因回归信号出现塌缩或爆炸（假设 $\mathbb{E}\|\partial_\phi \mathbf{v}_\phi(\mathbf{x}_t, t)\|^2$ 与任何时间权重受控）.

标准调度与 v-预测的交互. 在仿射路径 $\mathbf{x}_t = \alpha_t \mathbf{x}_0 + \sigma_t \boldsymbol{\epsilon}$ 下，oracle 速度分解为

$$\mathbf{v}^*(\mathbf{x}, t) = \alpha_t' \mathbf{x}^*(\mathbf{x}, t) + \sigma_t' \boldsymbol{\epsilon}^*(\mathbf{x}, t),$$

其中 $\mathbf{x}^* = \mathbb{E}[\mathbf{x}_0 \mid \mathbf{x}_t = \mathbf{x}]$、$\boldsymbol{\epsilon}^* = \mathbb{E}[\boldsymbol{\epsilon} \mid \mathbf{x}_t = \mathbf{x}]$. 在固定 $\mathbf{x}$ 处求导：

$$\partial_t \mathbf{v}_t^* = \underbrace{\alpha_t'' \mathbf{x}^* + \sigma_t'' \boldsymbol{\epsilon}^*}_{\text{调度曲率}} + \alpha_t' \partial_t \mathbf{x}^* + \sigma_t' \partial_t \boldsymbol{\epsilon}^*.$$

对线性调度 $\alpha_t = 1 - t$、$\sigma_t = t$，曲率项消失（$\alpha_t'' = \sigma_t'' = 0$），因此 $\mathbf{v}_t^*$ 的时间变化主要反映后验演化（$\partial_t \mathbf{x}^*, \partial_t \boldsymbol{\epsilon}^*$）而非调度. 对 v-预测该效应尤其干净：$\alpha_t'$、$\sigma_t'$ 是常数（-1 与 $+1$），避免了漂移中额外的 t-依赖缩放. 与之相反，分数、$\mathbf{x}_0$ 或 $\boldsymbol{\epsilon}$ 参数化常引入诸如 σ_t'/σ_t 或 α_t'/α_t 的比值，即使在线性调度下也可能在端点附近剧烈变化. 因此，虽然原理

上并非独有，线性 $(1-t,t)$ 调度与 v-预测结合为 oracle 速度提供了特别稳定、透明的时间依赖.

最小化条件能量. 我们接下来采用更偏理论的最优传输视角（见第 7 章）. 这里条件动能量化沿前向路径条件速度的总期望运动，即从 $\mathbf{x}_0$ 到 $\boldsymbol{\epsilon}$ 遍历所需的瞬时运动（动能）:

$$\mathcal{K}[\rho] := \int_0^1 \mathbb{E}_{\mathbf{x}_0,\boldsymbol{\epsilon}}\left[\|\mathbf{v}_t(\cdot \mid \mathbf{z})\|_2^2\right] \mathrm{d}t = \left(D + \operatorname{Tr}\operatorname{Cov}[\mathbf{x}_0] + \|\mathbb{E}\mathbf{x}_0\|_2^2\right) \int_0^1 \left(\rho'(t)\right)^2 \mathrm{d}t.$$

最小化 $\mathcal{K}[\rho]$ 即在期望意义下寻找最平滑、能量最小的路径. 在边界条件 $\rho(0)=0$、$\rho(1)=1$ 下，Euler–Lagrange 方程 $\rho''(t)=0$ 给出极小元 $\rho(t)=t$，对应直线条件路径. 这意味着，在连接 $\mathbf{x}_0$ 与 $\boldsymbol{\epsilon}$ 的所有平滑插值中，标准流 $\rho(t)=t$ 是其间移动能量最有效的方式. 我们将在 7.5.1 中回到这一点.

关于 *oracle* 速度的注记. 若改而评估边缘化速度定义的能量

$$\int_0^1 \mathbb{E}_{\mathbf{x}_t}\left[\|\mathbf{v}^*(\mathbf{x}_t,t)\|_2^2\right] \mathrm{d}t,$$

则 $\mathbf{z}=(\mathbf{x}_0,\boldsymbol{\epsilon})$、$\mathbf{v}_t(\mathbf{x}_t \mid \mathbf{z}) = \rho'(t)(\boldsymbol{\epsilon}-\mathbf{x}_0)$，

$$\mathbf{v}^*(\mathbf{x},t) = \mathbb{E}\left[\mathbf{v}_t(\cdot \mid \mathbf{z}) \mid \mathbf{x}_t = \mathbf{x}\right] = \rho'(t)\mathbb{E}\left[\boldsymbol{\epsilon}-\mathbf{x}_0 \mid \mathbf{x}_t = \mathbf{x}\right];$$

因此边缘化速度的能量为

$$\int_0^1 \mathbb{E}_{\mathbf{x}_t\sim p_t}\left[\|\mathbf{v}^*(\mathbf{x}_t,t)\|_2^2\right] \mathrm{d}t = \int_0^1 \mathbb{E}_{\mathbf{x}_t}\left[\|\rho'(t)\mathbb{E}\left[\boldsymbol{\epsilon}-\mathbf{x}_0 \mid \mathbf{x}_t\right]\|_2^2\right] \mathrm{d}t = \int_0^1 \left(\rho'(t)\right)^2 \kappa(t)\,\mathrm{d}t,$$

其中 $\kappa(t) := \mathbb{E}_{\mathbf{x}_t\sim p_t}\left[\|\mathbb{E}\left[\boldsymbol{\epsilon}-\mathbf{x}_0 \mid \mathbf{x}_t\right]\|_2^2\right]$.

因此边缘化-最优调度 $\rho(t)$ 不必是线性的. 它线性当且仅当 $\kappa(t)$ 为常数；一般地，Euler–Lagrange 条件

$$(\kappa(t)\rho'(t))' = 0 \;\Rightarrow\; \rho'(t) \propto \frac{1}{\kappa(t)}$$

意味着 oracle 最优调度自适应地重参数化时间. 直观上，$\kappa(t)$ 度量标签 $(\boldsymbol{\epsilon}-\mathbf{x}_0)$ 从 $\mathbf{x}_t\sim p_t$ 中可预测的程度：oracle 流在 $\kappa(t)$ 大处减速（对应 oracle 速度期望幅值大的区域），在 $\kappa(t)$ 小处加速. 因此，尽管条件流使用线性调度 $(1-t,t)$，相应的边缘化（oracle）动力学一般是非线性的.

视角 2：为何速度预测对采样可视为自然. $\mathbf{x}$-、$\boldsymbol{\epsilon}$- 与 $\mathbf{s}$-预测下 *PF-ODE* 的半线性形式. 在干净、噪声与分数参数化下，漂移取半线性形式（见 (6.6.3.275) 前三个恒等式）:

$$\frac{\mathrm{d}\mathbf{x}(t)}{\mathrm{d}t} = \underbrace{L(t)\mathbf{x}(t)}_{\text{线性部分}} + \underbrace{\mathbf{N}_\phi(\mathbf{x}(t),t)}_{\text{非线性部分}}, \qquad \mathbf{N}_\phi \in \{\mathbf{x}_\phi, \boldsymbol{\epsilon}_\phi, \mathbf{s}_\phi\}.$$

当线性漂移 $L(t)\mathbf{x}(t)$ 在某些方向上驱动 $\mathbf{x}(t)$ 的速率与非线性部分非常不同时，系统是刚性的，即漂移关于 $\mathbf{x}$ 的 Jacobi 矩阵

$$\mathbf{J}(\mathbf{x},t) := L(t) + \nabla_{\mathbf{x}}\mathbf{N}_\phi(\mathbf{x},t)$$

的特征值实部相差数量级（幅值越大方向越快）[31]. 例如，动力学可能在 $\mathbf{x}(t)$ 中同时涉及 “快线性” 变化与 “慢非线性” 变化. 此类情形下，显式求解器必须取非常小的步长以保持数值稳定.

为应对这一不平衡，高阶稳定求解器常施加一个积分因子，解析处理线性项 $L(t)\mathbf{x}$，只离散化较慢的非线性余项，代价是额外的代数与实现复杂度. 第 9 章专门讨论该主题.

v-预测下的 *PF-ODE.* v-预测直接学习速度场并积分

$$\frac{\mathrm{d}\mathbf{x}(t)}{\mathrm{d}t} = \mathbf{v}_\phi(\mathbf{x}(t), t) \approx \mathbf{v}^*(\mathbf{x}(t), t).$$

在此表述下，显式线性项被吸收到单个学习场中，动力学不再分裂为独立部分. 步长由学习场 $\mathbf{v}_\phi(\mathbf{x}, t)$ 随 $\mathbf{x}$ 与 t 变化的平滑程度决定，而不依赖于预设标量系数 $L(t)$ 的幅值. 换言之，潜在快速线性漂移被折进一个连贯速度场，减小时间尺度差异并简化数值积分.

稍后在 9.2.2 节，我们用一个简单例子展示 v-预测在采样过程中的结构简洁性. 为获得与 DDIM（Song 等, 2020a）相同的 PF-ODE 离散化更新（扩散建模中最广泛使用的快速采样器之一），在 $\boldsymbol{\epsilon}$-、$\mathbf{x}$- 或 $\mathbf{s}$-参数化下的普通 Euler 步只近似线性项，而非精确计算（见 (9.9.2.465)）. 因此这些参数化需要更高级的方法，即指数积分器，来分离并精确计算线性项. 与之相反，v-预测在 PF-ODE 漂移中没有可分离的线性项，普通 Euler 更新自然与 DDIM 表述重合. 一个紧密类比出现在 9.4.5：二阶 DPM-Solver（Lu 等, 2022b）与经典 Heun 方法重合；对 v-预测这是普通 Heun，而对 $\boldsymbol{\epsilon}$-、$\mathbf{x}$- 或 $\mathbf{s}$-预测则是指数 Heun. 详细讨论留待各自章节.

我们注意，生成质量的任何改进（例如用更少模型评估获得更高样本质量，即 PF-ODE 求解）都同时取决于 $\mathbf{v}_\phi$ 对 oracle 速度逼近的精度，以及采样算法（含数值积分器、离散化调度、步长控制）与之交互的有效性. 因此，采用 v-参数化本身并不保证采样性能更好.

小结. 虽然 v-预测与标准线性调度结合具有某些理论优势（如恒定目标幅值、无调度曲率），但这些性质并不必然使其普适最优. 实践中，模型性能取决于一系列交互因素：网络架构、归一化方案、时间上的损失加权、采样器与离散化步的选择、引导强度、正则化策略、数据缩放以及整体训练预算. 不同数据集与目标可能偏好替代参数化或调度，最优配置最终是一个实证问题，应通过验证与消融研究来解决.

6.4 一切之下：Fokker–Planck 方程

本节表明，扩散模型的三大视角——变分、基于分数与基于流——并非孤立构造，而是源自同一统一原理：支配选定前向过程下密度演化的连续性（Fokker–Planck）方程.

首先回顾 4.5 节的分析把基于离散核与 Bayes 法则的变分视角，与连续动力学的基于分数 SDE 视角统一起来. 我们通过证明变分模型充当底层前向与反向 SDE 的一致离

[31] 设 PF-ODE 漂移 $\mathbf{F}(\mathbf{x}, t) = L(t)\mathbf{x} + \mathbf{N}_\phi(\mathbf{x}, t)$，并设 $\mathbf{N}_\phi$ 关于 $\mathbf{x}$ 局部 Lipschitz，常数 $\mathrm{Lip}_{\mathbf{N}_\phi}(t)$. 对邻近状态 $\mathbf{x}, \mathbf{y}$，$\|\tilde{\mathbf{F}}(\mathbf{x}, t) - \tilde{\mathbf{F}}(\mathbf{y}, t)\| \le \left(\|L(t)\| + \mathrm{Lip}_{\mathbf{N}_\phi}(t)\right) \|\mathbf{x} - \mathbf{y}\| =: C(t)\|\mathbf{x} - \mathbf{y}\|$. 等价地，Jacobi（关于 $\mathbf{x}$）$\mathbf{J}(\mathbf{x}, t) = L(t) + \nabla_{\mathbf{x}}\mathbf{N}_\phi(\mathbf{x}, t)$ 满足 $\|\mathbf{J}(\mathbf{x}, t)\|_{\mathrm{op}} \le C(t)$（即 $\mathbb{R}^D$ 上 Euclid 范数诱导的算子范数）. 因此 $\mathbf{J}$ 所有特征值实部的幅值以 $C(t)$ 为界. $C(t)$ 大意味着局部速率快，故显式求解器需小步长（$h \lesssim 1/C(t)$）.

散化来建立这一联系. 具体地，通过离散核逐步计算的边缘密度，其演化方式与支配连续时间动力学的 Fokker–Planck 方程一致. 这证实了两个视角在根本上等价.

随后我们把基于流与基于分数的视角联系起来. 在 6.4.1 中，我们证明 ODE 流确定一条密度路径，其边缘总可由一族随机过程实现. 这把确定性流与该族内的随机 SDE 置于同一框架.

综上，这些结果把三个视角统一在一个框架下（见图）. 最后我们在 6.5 结束本章.

6.4.1 基于流方法与 Score SDE 的联系

扩散模型的一个显著特点是：不同动力系统（确定性或随机）能描出相同的概率分布演化. 本节揭示 5.2 节基于 ODE 的流与 Score SDE 之间自然而优雅的联系. 具体地，我们证明定义生成 ODE 的速度场可变换为遵循同一 Fokker–Planck 动力学的随机对应物，从而在确定性插值与随机采样之间架起有原则的桥梁. 这给我们一族连续模型，从 ODE 到 SDE，都生成同一数据分布路径.

我们考虑连续时间设置，扰动核为

$$p_t(\mathbf{x}_t \mid \mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t; \alpha_t \mathbf{x}_0, \sigma_t^2 \mathbf{I}),$$

其中 $\mathbf{x}_0 \sim p_{\text{data}}$. 该条件分布诱导边缘密度路径 $p_t(\mathbf{x}_t) = \mathbb{E}_{\mathbf{x}_0 \sim p_{\text{data}}}[p(\mathbf{x}_t \mid \mathbf{x}_0)]$，与通常一致，$p_T \approx p_{\text{prior}}$.

为匹配该密度路径，考虑 ODE

$$\frac{\mathrm{d}\mathbf{x}(t)}{\mathrm{d}t} = \mathbf{v}_t(\mathbf{x}(t)), \qquad t \in [0, T], \tag{6.6.4.281}$$

其中 $\mathbf{v}_t(\mathbf{x}) = \mathbb{E}[\alpha_t' \mathbf{x}_0 + \sigma_t' \boldsymbol{\epsilon} \mid \mathbf{x}]$ 是 oracle 速度，如 (5.5.2.255) 所示（注意时间已翻转以遵循扩散模型约定）. 从 $\mathbf{x}(T) \sim p_{\text{prior}}$ 反向积分 (6.6.4.281) 即得 p_0 的样本.

虽然该 ODE 足以生成高质量样本，但加入随机性可能提升样本多样性. 这引出以下问题：

问题 6.4.1 (问题 6.4.1)**：** 是否存在一个 SDE，其动力学从 p_{prior} 出发，产生与 (6.6.4.281) 中 ODE 相同的边缘密度?

该命题断言存在一族反向时间 SDE，其诱导的边缘密度路径与相应 PF-ODE 相同. 这些 SDE 诱导的密度满足该路径同一 Fokker–Planck 方程，因此其一时间边缘与预定插值 $\{p_t\}_{t\in[0,T]}$ 重合[32].

命题 6.4.1 (反向时间 SDE 生成与插值相同的边缘)**：** *设 $\gamma(t) \geq 0$ 为任意时间依赖系数. 考虑反向时间 SDE*

$$\mathrm{d}\bar{\mathbf{x}}(t) = \left[\mathbf{v}^*(\bar{\mathbf{x}}(t), t) - \tfrac{1}{2}\gamma^2(t)\mathbf{s}^*(\bar{\mathbf{x}}(t), t)\right] \mathrm{d}\bar{t} + \gamma(t)\, \mathrm{d}\bar{\mathbf{w}}(t), \tag{6.6.4.282}$$

从 $\bar{\mathbf{x}}(T) \sim p_T$ 反向演化到 $t = 0$. 则该过程 $\{\bar{\mathbf{x}}(t)\}_{t\in[0,T]}$ 匹配 ODE 密度路径所诱导的预定边缘 $\{p_t\}_{t\in[0,T]}$. 这里 $\mathbf{s}(\mathbf{x}, t) := \nabla_{\mathbf{x}} \log p_t(\mathbf{x})$ 是分数函数，它与速度场 $\mathbf{v}(\mathbf{x}, t)$ 的关系

[32]完整起见，前向 SDE 表示（此处不需要）为 $\mathrm{d}\mathbf{x}(t) = f(t)\mathbf{x}(t)\,\mathrm{d}t + g(t)\,\mathrm{d}\mathbf{w}(t)$，其中 $f(t)$ 与 $g(t)$ 通过 (6.6.2.268) 式与 (α_t, σ_t) 相关.

为

$$\mathbf{v}^*(\mathbf{x},t) = f(t)\mathbf{x} - \tfrac{1}{2}g^2(t)\mathbf{s}^*(\mathbf{x},t), \qquad \mathbf{s}^*(\mathbf{x},t) = \frac{1}{\sigma_t}\frac{\alpha_t\mathbf{v}^*(\mathbf{x},t) - \alpha_t'\mathbf{x}}{\alpha_t'\sigma_t - \alpha_t\sigma_t'}. \tag{6.6.4.283}$$

命题证明： 与 (6.6.4.282) 对应的反向时间 Fokker–Planck 方程为

$$\partial_{\bar{t}}p = -\nabla\cdot\left([\mathbf{v}^* - \tfrac{1}{2}\gamma^2\mathbf{s}^*]p\right) + \tfrac{1}{2}\gamma^2\Delta p.$$

利用恒等式 $\nabla\cdot(\mathbf{s}^*p) = \Delta p$（因为 $\mathbf{s}^* = \nabla\log p$），二阶项相消，得

$$\partial_{\bar{t}}p = -\nabla\cdot(\mathbf{v}^*p),$$

即与 PF-ODE 关联的一阶（仅漂移）Fokker–Planck 方程. 因此反向时间 SDE 与 ODE 诱导相同的边缘密度路径 $\{p_t\}$. 见 Ma 等（2024）附录 A.2–A.3. □

超参数 $\gamma(t)$ 可任意选择，独立于 α_t 与 σ_t，甚至在训练之后，因为它不影响速度 $\mathbf{v}(\mathbf{x},t)$ 或分数 $\mathbf{s}(\mathbf{x},t)$. 下面给出一些例子：

- 取 $\gamma(t) = 0$ 恢复 (6.6.4.281) 的 ODE；
- 当 $\gamma(t) = g(t)$，(6.6.4.282) 变为 (4.4.1.119) 中的反向时间 SDE，因为 oracle 速度 $\mathbf{v}(\mathbf{x},t)$ 满足（见 6.3.2）：

$$\mathbf{v}^*(\mathbf{x},t) = f(t)\mathbf{x} - \tfrac{1}{2}g^2(t)\mathbf{s}^*(\mathbf{x},t);$$

- 其他 $\gamma(t)$ 选择也已被探索；例如 Ma 等（2024）选择 $\gamma(t)$ 以最小化 p_{data} 与从 $t = T$ 求解 (6.6.4.282) 得到的 $t = 0$ 处密度之间的 KL 差.

沿着 Score SDE 的思路，训练好的速度场 $\mathbf{v}_{\phi^\times}(\mathbf{x},t)$ 可通过 (6.6.4.283) 转换为参数化分数函数 $\mathbf{s}_{\phi^\times}(\mathbf{x},t)$. 将其代入 (6.6.4.282) 定义一个经验反向时间 *SDE*，可从 $t = T$ 起以 $\bar{\mathbf{x}}(T) \sim p_{\text{prior}}$ 数值积分进行采样.

该命题凸显了扩散模型惊人的灵活性：一旦边缘密度路径 $\{p_t\}_{t\in[0,T]}$ 固定，一整族动力学都可重现它，包括 PF-ODE 与反向时间 SDE

$$\mathrm{d}\bar{\mathbf{x}}(t) = \left[\mathbf{v}^*(\bar{\mathbf{x}},t) - \tfrac{1}{2}\gamma^2(t)\mathbf{s}^*(\bar{\mathbf{x}},t)\right]\mathrm{d}\bar{t} + \gamma(t)\,\mathrm{d}\bar{\mathbf{w}}(t), \qquad \gamma(t) \geq 0.$$

所有这些动力学都满足同一反向时间 Fokker–Planck 方程，因而产生相同的边缘演化. 函数 $\gamma(t)$ 连续调节随机性程度而不影响一时间分布，揭示了基于流的确定性 ODE 与其随机 SDE 对应物之间的深刻联系，如图所示.

6.5 本章小结

本章是我们理论探索的拱心石，把变分、基于分数与基于流视角综合进单一、连贯的框架. 我们已表明这三个看似不同的方法不仅平行，而且深刻地根本互联.

我们的统一建立在两个核心洞见之上. 首先，我们识别了所有框架共有的秘诀：条件技巧，它把不可处理的边缘训练目标转化为易处理的条件目标，实现稳定高效学习.

其次，我们确立 Fokker–Planck 方程是支配概率密度演化的普适定律. 三大视角各以自己的方式构造一个生成过程，都遵守这一基本动力学.

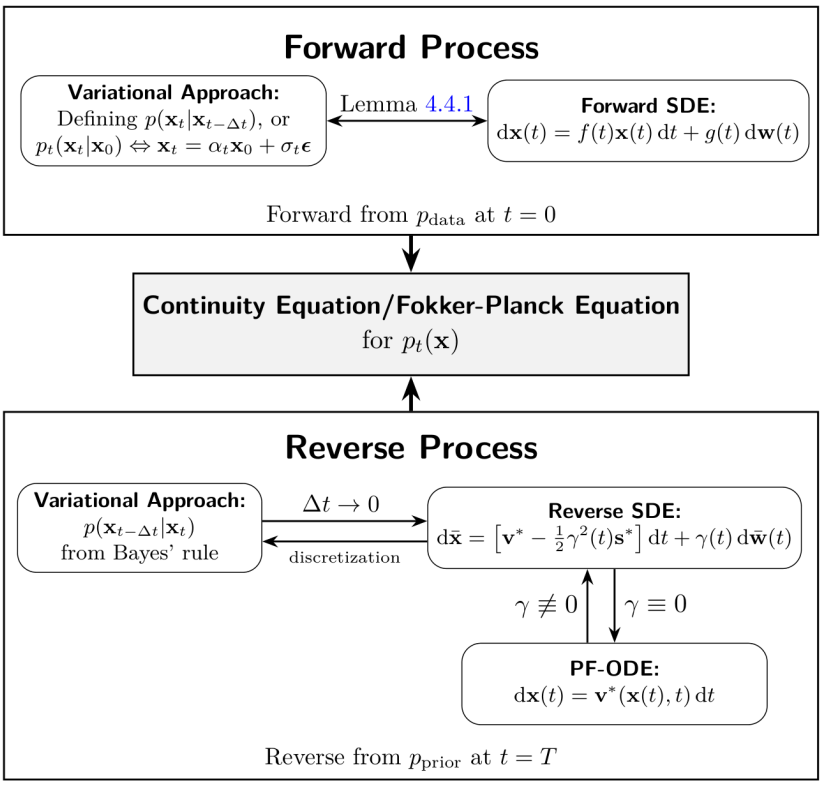
此外，我们证明了各种模型参数化——即噪声、干净数据、分数或速度预测——都可互换. 这表明预测目标的选择只是实现与稳定性问题，而非基本建模差异. 最终要点是：现代扩散方法尽管起源多样，都实例化同一核心原理——学习一个时间依赖向量场，把简单先验传输到数据分布.

这一统一而有原则的基础牢固建立后，我们即可从基础理论走向扩散模型的实际应用与加速. 生成等价于求解微分方程这一中心洞见，为控制与优化提供了强大平台. 本书后续部分将利用这一统一理解来应对关键实际挑战：

1. Part C 聚焦在推断时改进采样过程. 我们将探讨如何引导生成轨迹以实现可控生成（第 8 章），并研究高级数值求解器，以显著加速缓慢、迭代的采样过程（第 9 章）.

2. Part D 将超越迭代求解器，直接学习快速生成器. 我们将考察能在一步或少数步内产生高质量样本的方法，无论是通过教师模型蒸馏（第 10 章）还是从零训练（第 11 章）.

统一了扩散模型的 *what* 与 *why*，现在我们把目光转向激动人心而实际的 *how* 前沿.



In this section, we show that the three main perspectives of diffusion models—variational, score-based, and flow-based—are not separate constructions but arise from a single unifying principle: the continuity (Fokker–Planck) equation that governs density evolution under a chosen forward process.

First, we recall that the analysis in Section 4.5 unifies the variational perspective, based on discrete kernels and Bayes' rule, with the score-based SDE perspective of continuous dynamics. We establish this connection by showing that variational models act as consistent discretizations of the underlying forward and reverse SDEs. Specifically, the marginal densities calculated

图 6.32: 通过连续性方程连接变分、SDE 与 ODE 表述的统一视角，所有 $p_t(\mathbf{x})$ 在共享动力学下演化. 速度场 $\mathbf{v}^*(\mathbf{x}, t) = f(t)\mathbf{x} - \frac{1}{2}g^2(t)\mathbf{s}^*(\mathbf{x}, t)$ 由分数函数 $\mathbf{s}^*(\mathbf{x}, t) := \nabla_{\mathbf{x}} \log p_t(\mathbf{x})$ 控制. 系数 $f(t)$、$g(t)$、σ_t、α_t 是预定义时间依赖函数，$\gamma(t)$ 是可调时间变化超参数.

Chapter 7

（可选）扩散模型与最优传输

把一个分布映射到另一个分布（生成只是其特例）是一个核心挑战。流匹配通过学习一个随时间变化的速度场来解决这一问题，该速度场把质量从源分布搬运到目标分布。这自然地与传输理论相衔接：经典最优传输寻找分布之间代价最小的路径，而其熵正则化形式——Schrödinger 桥——则在相对于一个参考过程（如 Brown 运动）的意义下，选择最可能的受控扩散。

本章我们回顾最优传输、熵正则化最优传输以及 Schrödinger 桥的基础，将其作为“分布到分布” 问题的各种表述。这引出一个核心问题：扩散模型在多大程度上实现了这种最优传输？它们有两种视角：其一是随机过程视角，由前向与反向 SDE 定义；其二是确定性过程视角，由 PF-ODE 给出。随机视角与熵正则化最优传输直接对应，而 PF-ODE 一般不对应任何已知的传输目标。这一空缺留下一个开放问题：在何种条件下，可以把扩散模型视为在求解一个最优传输问题？

7.1 分布到分布迁移的序幕

扩散模型把终端分布固定为标准 Gaussian 分布 p_{prior}。然而，许多应用需要分布到分布的迁移：把一个源分布 p_{src} 变换为另一个不同的目标分布 p_{tgt}。例子包括把草图转换为照片级真实图像，或在艺术风格之间互译。

现代扩散方法为实现这一点提供了若干实用途径。单端点方法（如 SDEdit，Meng *et al.*, 2021b）从 $t = 0$ 处的一张源图像出发，把它扩散到某个中间步 t，然后用目标域上预训练好的扩散模型反向运行该过程。这样产生的输出在风格与内容上都匹配目标分布。

双端点方法（如 Dual Diffusion Bridge，Su *et al.*, 2022）则通过一个共享的隐分布连接两个域，该隐分布通常取 $t = 1$ 处的 Gaussian。一个前向概率流 ODE 把样本从 p_{src} 搬运到这一隐空间，而一个在目标域上训练的反向 ODE 再把它们映射回 p_{tgt}。除了这类采样时方法之外，流匹配框架（第 5.2 节）提供了一种基于训练的替代方案：它直接学习一条 ODE 流，把质量从 p_{src} 连续地搬运到 p_{tgt}。

关键在于，在分布之间做变换需要的不只是两个分别训练好的模型。它要求一个有原则的映射，能够在两个端点处对齐动力学，并以“最省钱”（代价最优）的方式做到这一点。

本节不再罗列众多基于扩散的迁移应用，而是把焦点放在这一经典分布到分布问题的数学基础上。特别地，我们强调最优传输（OT）及其熵正则化变体 Schrödinger 桥（SB），它们在理论界早已被研究为（在数学意义上）代价最优的分布变换的经典表述。

其核心的根本问题是：

问题 7.1.1： 给定两个概率分布，在把一个变换为另一个的同时最小化总代价，最高效

的方式是什么?

这里的代价 $c(\mathbf{x}, \mathbf{y})$ 是一个非负函数，它给把单位质量从点 $\mathbf{x}$ 搬到点 $\mathbf{y}$ 赋予一个惩罚。一个常见选择是平方距离 $c(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\|^2$。

本节给出一个简短综述，以厘清基于扩散的方法（包括流匹配）如何与经典及正则化最优传输相衔接。我们力图探索的中心问题是：

问题 7.1.2： 扩散模型是否是连接 p_{data} 与 p_{prior} 的某种最优传输？在何种意义上?

为回答这一问题，我们首先在第 7.2 节澄清 "最优" 意味着什么。我们回顾经典最优传输（OT）的静态 Monge–Kantorovich 形式（式 (7.7.2.286)）及其动态 Benamou–Brenier 表述（式 (7.7.2.291)）——即在连续性方程约束下最小化动能；以及熵正则化变体（熵最优传输，EOT），即式 (7.7.2.295)，它等价于 Schrödinger 桥问题（式 (7.7.2.303)）。在动态视角下，OT 诱导出一条满足连续性方程的确定性流，而 SB 诱导出一个受控扩散，其边缘由 Fokker–Planck 方程演化。我们在第 7.3 节给出这些表述之间的高层对应图。

随后我们把讨论分为两部分。首先，在第 7.4 节，我们说明标准扩散模型中所用的固定前向加噪 SDE 本身并不是任意 p_{src} 与 p_{tgt} 之间的 Schrödinger 桥：前向过程是一个选定的参考扩散，而无论是时间向前的还是反向时间的 SDE，一般都不强制匹配到一个预先指定的目标。因此，除非显式地以这些端点求解 SB 问题，它并不是熵 OT 最优的；而作为以一个起点锚定的半桥问题，它确实是该半桥问题的最优解。

其次，在第 7.5 节，我们回到生成设定，取 $p_{\text{src}} = p_{\text{prior}}$（Gaussian）而 $p_{\text{tgt}} = p_{\text{data}}$。PF-ODE 构造性地定义了一个把 p_{prior} 搬运到 p_{data} 的确定性映射。然而，对于给定的传输代价（例如二次型 W_2），这条流一般并不是 OT 映射：它只是众多可允许确定性耦合中的一个，并不最小化 Benamou–Brenier 作用量。接下来我们讨论 "rectify 流" 过程（第 5.4.1 节）能否给出 OT 映射；但一般而言不存在这样的理论保证。因此，扩散模型 PF-ODE 映射与 OT 之间的确切刻画仍然具有挑战性、尚未解决。

7.2 问题设定的分类

本节引入何谓把质量从 p_{src} 搬运到 p_{tgt} 的最 "高效" 或最 "最优" 方式。这些包括经典最优传输（OT）及其熵正则化变体，后者有一个等价表述，即 Schrödinger 桥。本分类提供背景，以便稍后厘清它们与扩散模型的联系。

7.2.1 最优传输（OT）

Monge–Kantorovich（静态）OT 问题表述。 我们固定一个代价函数 $c : \mathbb{R}^D \times \mathbb{R}^D \to \mathbb{R}$，它指定把概率质量从 $\mathbf{x}$ 送到 $\mathbf{y}$ 的花费。目标是以尽可能低的代价把源分布 p_{src} 变换为目标分布 p_{tgt}。

要定义代价，就必须知道哪些点对 $(\mathbf{x}, \mathbf{y})$ 被匹配。扮演这一角色的是耦合（coupling）：一个定义在 $\mathbb{R}^D \times \mathbb{R}^D$ 上、边缘分布为 p_{src} 与 p_{tgt} 的联合分布 γ。换言之，采样 $(\mathbf{x}, \mathbf{y}) \sim \gamma$ 意味着我们把源中的 $\mathbf{x}$ 与目标中的 $\mathbf{y}$ 相匹配。若 γ 关于 Lebesgue 测度有密度 $\gamma(\mathbf{x}, \mathbf{y})$，则边缘约束为

$$\int_{\mathbb{R}^D} \gamma(\mathbf{x}, \mathbf{y})\, d\mathbf{y} = p_{\text{src}}(\mathbf{x}), \qquad \int_{\mathbb{R}^D} \gamma(\mathbf{x}, \mathbf{y})\, d\mathbf{x} = p_{\text{tgt}}(\mathbf{y}). \tag{7.7.2.284}$$

也就是说，把 $\mathbf{y}$ 积分掉就恢复出 $\mathbf{x}$ 处的源密度，而把 $\mathbf{x}$ 积分掉就恢复出 $\mathbf{y}$ 处的目标密度。

我们给出两个标准示例以作说明：

1. **离散支撑**。若 p_{src} 与 p_{tgt} 支撑在有限多个点上，则一个耦合由一个非负矩阵 (γ_{ij}) 表示，其行和等于 $p_{\mathrm{src}}(i)$、列和等于 $p_{\mathrm{tgt}}(j)$。每个元素 γ_{ij} 是从 i 送到 j 的质量。

2. **确定性映射**。若存在一个可测映射 $\mathbf{T}$ 使得 $\mathbf{T}_{\#}p_{\mathrm{src}} = p_{\mathrm{tgt}}$，则 $\gamma = (\mathbf{I}, \mathbf{T})_{\#}p_{\mathrm{src}}$ 是一个确定性耦合，它把每个点 $\mathbf{x}$ 直接搬到 $\mathbf{T}(\mathbf{x})$。

一旦耦合 γ 固定，传输代价就是该方案下的平均单位代价：

$$\int c(\mathbf{x},\mathbf{y})\,\mathrm{d}\gamma(\mathbf{x},\mathbf{y}) = \mathbb{E}_{(\mathbf{x},\mathbf{y})\sim\gamma}\big[c(\mathbf{x},\mathbf{y})\big]. \tag{7.7.2.285}$$

在离散情形它退化为 $\sum_{i,j} c_{ij}\gamma_{ij}$，而在连续情形它成为一个二重积分。下文我们只关注连续情形。

于是最优传输问题就是在所有可允许耦合中，选择使这一期望代价最小的那个：

$$\mathrm{OT}(p_{\mathrm{src}}, p_{\mathrm{tgt}}) := \inf_{\gamma\in\Gamma(p_{\mathrm{src}},p_{\mathrm{tgt}})} \int c(\mathbf{x},\mathbf{y})\,\mathrm{d}\gamma(\mathbf{x},\mathbf{y}), \tag{7.7.2.286}$$

其中可行集只是强制边缘（即质量守恒）约束：

$$\Gamma(p_{\mathrm{src}}, p_{\mathrm{tgt}}) = \Big\{\gamma \in \mathcal{P}(\mathbb{R}^D\times\mathbb{R}^D) : \int \gamma(\mathbf{x},\mathbf{y})\,\mathrm{d}\mathbf{y} = p_{\mathrm{src}}(\mathbf{x}),\ \int \gamma(\mathbf{x},\mathbf{y})\,\mathrm{d}\mathbf{x} = p_{\mathrm{tgt}}(\mathbf{y})\Big\}, \tag{7.7.2.287}$$

其中 $\mathcal{P}(\mathbb{R}^D\times\mathbb{R}^D)$ 表示 $\mathbb{R}^D\times\mathbb{R}^D$ 上所有概率测度的集合。

特例：Wasserstein-2 距离。 Wasserstein-2 距离是 Monge–Kantorovich 问题在二次型代价 $c(\mathbf{x},\mathbf{y}) = \|\mathbf{x}-\mathbf{y}\|^2$ 下的特例。它把两个概率分布之间的距离度量为：

$$\mathcal{W}_2^2(p_{\mathrm{src}}, p_{\mathrm{tgt}}) := \inf_{\gamma\in\Gamma(p_{\mathrm{src}},p_{\mathrm{tgt}})} \mathbb{E}_{(\mathbf{x},\mathbf{y})\sim\gamma}\big[\|\mathbf{x}-\mathbf{y}\|^2\big]. \tag{7.7.2.288}$$

在对 p_{src} 与 p_{tgt} 适当的假设下，Brenier 定理（见定理 7.5.1）保证：对于二次型代价，最优耦合 γ 集中在一个确定性映射 $\mathbf{T}:\mathbb{R}^D\to\mathbb{R}^D$ 的图像上。因此，Wasserstein-2 距离可等价地写为：

$$\mathcal{W}_2^2(p_{\mathrm{src}}, p_{\mathrm{tgt}}) = \inf_{\substack{\mathbf{T}:\mathbb{R}^D\to\mathbb{R}^D,\\ \text{s.t. } \mathbf{T}_{\#}p_{\mathrm{src}}=p_{\mathrm{tgt}}}} \mathbb{E}_{\mathbf{x}\sim p_{\mathrm{src}}}\big[\|\mathbf{T}(\mathbf{x})-\mathbf{x}\|^2\big]. \tag{7.7.2.289}$$

这里 $\mathbf{T}_{\#}p_{\mathrm{src}} = p_{\mathrm{tgt}}$ 表示 $\mathbf{T}$ 把 p_{src} 推前为 p_{tgt}，即对 $\mathbf{x}\sim p_{\mathrm{src}}$ 有 $\mathbf{T}(\mathbf{x})\sim p_{\mathrm{tgt}}$。

于是，Wasserstein-2 距离表示在所有匹配给定边缘的耦合或传输映射中，最小的期望平方传输代价。由最优传输映射 $\mathbf{T}^*(\mathbf{x})$（称为 *Monge* 映射）给出把 p_{src} 变换为 p_{tgt} 的最高效方式。

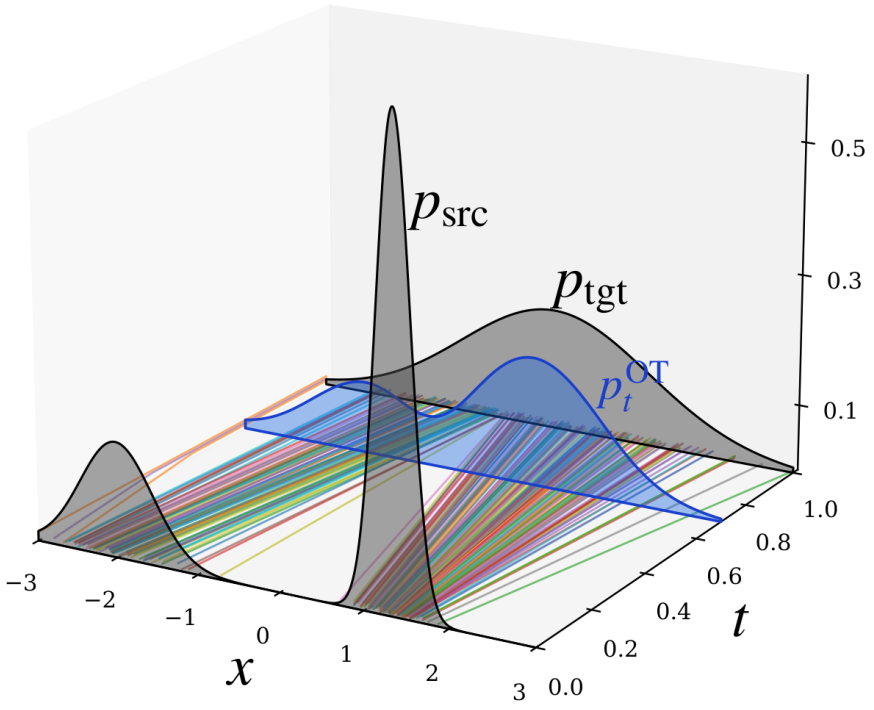


图 7.33: OT 动态视角示意。插值 p_t^{OT} 随时间连续演化，给出代价最低的传输方案，把 p_{src} 确定性地映射到 p_{tgt}（McCann 位移插值）。

Benamou–Brenier（动态）OT 表述。 传输不必像 Monge–Kantorovich 表述那样以静态方式直接映射分布，它也可以被建模为一条连续时间流：

$$p_0 := p_{\text{src}} \to p_t \to p_1 := p_{\text{tgt}}, \qquad t \in [0,1]. \tag{7.7.2.290}$$

这一最优传输的动态表述由 Benamou 与 Brenier（2000）引入，它寻找一个光滑速度场 $\mathbf{v}_t(\mathbf{x})$，用以描述 $p_t(\mathbf{x})$ 中的质量如何随时间演化。

Benamou–Brenier 表述表明，对于二次型代价 $c(\mathbf{x},\mathbf{y}) = \|\mathbf{x}-\mathbf{y}\|_2^2$（即 $\mathcal{W}_2$ 距离），式 (7.7.2.286) 中静态 OT 问题的最优值，等于下列动能最小化问题的最优值：

$$\mathcal{W}_2^2(p_{\text{src}}, p_{\text{tgt}}) = \min_{\substack{(p_t,\mathbf{v}_t)\ \text{s.t.}\ \partial_t p_t + \nabla\cdot(p_t\mathbf{v}_t)=0,\\ p_0=p_{\text{src}},\, p_1=p_{\text{tgt}}}} \int_0^1 \int_{\mathbb{R}^D} \|\mathbf{v}_t(\mathbf{x})\|^2 p_t(\mathbf{x})\,\mathrm{d}\mathbf{x}\,\mathrm{d}t, \tag{7.7.2.291}$$

其中对每个 $t \in [0,1]$，p_t 是 $\mathbb{R}^D$ 上的一个概率分布。特别地，最优传输流 $p_t(\mathbf{x})$ 遵循 *McCann* 位移插值：

$$\mathbf{T}_t^*(\mathbf{x}) = (1-t)\mathbf{x} + t\,\mathbf{T}^*(\mathbf{x}), \tag{7.7.2.292}$$

其中 $\mathbf{T}^*(\mathbf{x})$ 是把 p_{src} 搬运到 p_{tgt} 的 OT 映射。这条线性插值以恒定速度沿直线搬运质量：对每个 $t \in [0,1]$ 有 $p_t = \mathbf{T}_t^{\#} p_{\text{src}}$。

最优传输映射 $\mathbf{T}^*$ 满足 *Monge–Ampère* 方程：

$$p_{\text{tgt}}\big(\nabla\psi(\mathbf{x})\big)\det\big(\nabla^2\psi(\mathbf{x})\big) = p_{\text{src}}(\mathbf{x}), \tag{7.7.2.293}$$

其中由 Brenier 定理，对某个凸函数 ψ 有 $\mathbf{T}^*(\mathbf{x}) = \nabla\psi(\mathbf{x})$。然而这个非线性 PDE 一般难以求得显式解。注意这恰是归一化流所用的变量替换关系（参见第 5.0.1 节式）：流以一个可处理的 Jacobian 行列式参数化一个可逆传输映射，但一般并不强加 "势的梯度" 结构 $\mathbf{T}^* = \nabla\psi$；因此，训练好的流可能与 Brenier/OT 映射相差甚远。

7.2.2 熵正则化最优传输（EOT）

为具体地引出 EOT，考虑由样本构造的经验分布。设 p_{src} 支撑在点 $\{\mathbf{x}^{(i)}\}_{i=1}^n \subset \mathbb{R}^D$ 上、带权 a_i，p_{tgt} 支撑在 $\{\mathbf{y}^{(j)}\}_{j=1}^n \subset \mathbb{R}^D$ 上、带权 b_j。耦合于是成为一个 $n \times n$ 非负矩阵 $\gamma = (\gamma_{ij})$，其行和匹配 a、列和匹配 b。每个元素 γ_{ij} 表示从 $\mathbf{x}^{(i)}$ 搬到 $\mathbf{y}^{(j)}$ 的质量。

为什么要正则化 OT？ 在这一离散设定下，经典 OT（在连续表述式 (7.7.2.286) 中取计数测度得到）退化为在所有可行耦合 $\gamma = (\gamma_{ij})$ 上最小化

$$\min_{\gamma=(\gamma_{ij})} \sum_{i,j} C_{ij}\gamma_{ij}, \tag{7.7.2.294}$$

其中 $C_{ij} = c(\mathbf{x}^{(i)}, \mathbf{y}^{(j)})$ 是把单位质量从源点 $\mathbf{x}^{(i)}$ 搬到目标点 $\mathbf{y}^{(j)}$ 的代价，地面代价 $c : \mathbb{R}^D \times \mathbb{R}^D \to \mathbb{R}_{\geq 0}$ 给定（例如 $c(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\|_2^2$）。

由此产生两个主要问题：

1. **非唯一性与不稳定性**。极小元 γ^* 不必唯一。例如，若两个传输方案达到相同的最小代价，求解器可能任选其一。于是输入 (a, b, C) 的微小变化（如移动一个样本、调整权重或轻微扰动代价）就可能造成解的突兀跳变。

2. **高计算代价**。该问题是一个含 n^2 个变量、$2n$ 个约束的线性规划。实用求解器（如 Hungarian 算法、网络单纯形法，Peyré、Cuturi *et al.*, 2019）的规模通常为 $\mathcal{O}(n^3)$，对大 n 不可行。

为克服这些瓶颈，EOT 目标函数在经典 OT 问题上引入一个由参数 $\varepsilon > 0$ 控制的正则项：

$$\text{EOT}_\varepsilon(p_{\text{src}}, p_{\text{tgt}}) := \min_{\gamma \in \Gamma(p_{\text{src}}, p_{\text{tgt}})} \int c(\mathbf{x}, \mathbf{y})\, \mathrm{d}\gamma(\mathbf{x}, \mathbf{y}) + \varepsilon\, \mathcal{D}_{\text{KL}}\big(\gamma \,\|\, M\big). \tag{7.7.2.295}$$

参考测度 M 通常取边缘分布之积 $p_{\text{src}} \otimes p_{\text{tgt}}$。KL 散度项与传输方案 γ 的 Shannon 熵直接相关：

$$\mathcal{D}_{\text{KL}}\big(\gamma \,\|\, p_{\text{src}} \otimes p_{\text{tgt}}\big) = -\mathcal{H}(\gamma) + \text{Constant}, \tag{7.7.2.296}$$

其中 $\mathcal{H}(\gamma) := -\int \gamma(\mathbf{x}, \mathbf{y}) \log \gamma(\mathbf{x}, \mathbf{y})\, \mathrm{d}\mathbf{x}\, \mathrm{d}\mathbf{y}$。

加入这一正则项带来若干理论与实用上的优势，简述如下。

为什么熵正则项有用？

1. **质量扩散**。由于 $t \mapsto t \log t$ 是凸的且对大 t 快速增长，最小化 $\int \gamma \log \gamma$ 会惩罚尖峰耦合（某些 $\gamma(\mathbf{x}, \mathbf{y})$ 非常大、其余近于零）。在总质量 $\int \gamma = 1$ 固定时，它偏好 $\gamma(\mathbf{x}, \mathbf{y})$ 在 $\mathbb{R}^D \times \mathbb{R}^D$ 上更均匀分布的方案。等价地，最大化 Shannon 熵促进更高的 "不确定性"（扩散性）。

2. **严格凸性与唯一性**。由于 $\mathcal{H}$ 严格凹，式 (7.7.2.295) 的目标关于 γ 严格凸，从而给出唯一极小元 γ_ε^*，且它连续依赖于 $(p_{\mathrm{src}}, p_{\mathrm{tgt}}, c)$。

3. **Sinkhorn 形式与正性**。在温和条件下，最优解具有 Schrödinger/Sinkhorn 形式

$$\gamma_\varepsilon^*(\mathbf{x},\mathbf{y}) = u(\mathbf{x}) \exp\Big(-\frac{c(\mathbf{x},\mathbf{y})}{\varepsilon}\Big) v(\mathbf{y})\, p_{\mathrm{src}}(\mathbf{x}) p_{\mathrm{tgt}}(\mathbf{y}), \tag{7.7.2.297}$$

其中 u, v 为正的缩放函数（唯一差一个整体因子）。实践中连续表述用有限样本近似，把 EOT 化为有限（采样）Sinkhorn 迭代。熵目标严格凸，而缩放（Sinkhorn/IPFP）算法高效求解它（Sinkhorn, 1964；Cuturi, 2013）。对于每个边缘有 n 个支撑点的稠密问题（一个 $n \times n$ 核），每次 Sinkhorn 迭代耗时 $\mathcal{O}(n^2)$、内存 $\mathcal{O}(n^2)$，使该方法更可扩展、更实用（Altschuler *et al.*, 2017）。

4. **ε 的极限**。当 $\varepsilon \to 0$，最优方案 γ_ε^* 越来越集中，逼近一个（可能奇异的）经典 OT 耦合（这一联系我们将在第 7.3.1 节重访）。当 ε 增大，γ_ε^* 逐渐散开，逼近独立耦合 $p_{\mathrm{src}} \otimes p_{\mathrm{tgt}}$。

7.2.3 Schrödinger 桥（SB）

SB 的 KL 表述。 Schrödinger 桥（SB）问题由 Erwin Schrödinger 于 1930 年代提出，追问如下问题。设粒子按照某个简单参考动力学运动，例如 Brown 运动。现在设想我们在两个时刻观测这些粒子：$t = 0$ 时其分布为 p_{src}，$t = 1$ 时为 p_{tgt}。在所有连接这两个分布的随机过程中，哪一个偏离参考动力学最小？这里 “偏离” 由 KL 散度度量，因此 SB 问题的解就是把 Brown 运动变形为满足给定边界条件的过程的最可能方式。

为精确起见，令 $\mathbf{x}_{0:T} := \{\mathbf{x}_t\}_{t\in[0,T]}$ 表示该过程的一条完整轨迹。我们记 P 为轨迹的律（law of trajectories），即在整条采样路径上的概率分布。P 的时间-t 边缘记为 p_t（或 P_t），它描述在单一时刻状态 $\mathbf{x}_t$ 的分布。形式上，对可测集 $A \subseteq \mathbb{R}^D$，

$$p_t(A) = P(\mathbf{x}_t \in A). \tag{7.7.2.298}$$

换言之，p_t 可视为从 P 采样许多完整轨迹后、收集时刻 t 的状态所得到的经验分布——例如，若状态是一维的就画成直方图。

考虑一个由 SDE 支配的参考扩散 $\{\mathbf{x}_t\}_{t\in[0,T]}$：

$$\mathrm{d}\mathbf{x}_t = \mathbf{f}(\mathbf{x}_t, t)\,\mathrm{d}t + g(t)\,\mathrm{d}\mathbf{w}_t, \tag{7.7.2.299}$$

其中 $\mathbf{f} : \mathbb{R}^D \times [0,T] \to \mathbb{R}^D$，$g : [0,T] \to \mathbb{R}$，$\{\mathbf{w}_t\}_{t\in[0,T]}$ 是标准 Brown 运动。令 R 表示完整轨迹 $\mathbf{x}_{0:T} := \{\mathbf{x}_t\}_{t\in[0,T]}$ 的路径律（联合分布）；R 将作为参考轨迹分布。

用这一记法，Schrödinger 桥（SB）问题寻找一个轨迹律 P，使其在匹配给定端点边缘的同时，在 KL 散度意义下最接近 R：

$$\mathrm{SB}(p_{\mathrm{src}}, p_{\mathrm{tgt}}) := \min_P \mathcal{D}_{\mathrm{KL}}(P\|R) \qquad \text{s.t.} \quad P_0 = p_{\mathrm{src}},\ P_T = p_{\mathrm{tgt}}. \tag{7.7.2.300}$$

最优解 P^* 依赖于所选参考过程 R。

SB 的随机控制视角。 与其在式 (7.7.2.300) 中对任意路径分布 P 做优化，一个更易处理的做法是以参考动力学为锚、允许它漂移。做法是引入一个随时间变化的漂移 $\mathbf{v}_t(\mathbf{x}_t)$，它扰动参考过程并生成一族候选轨迹分布。所得动力学取受控扩散的形式：

$$\mathrm{d}\mathbf{x}_t = \big[\mathbf{f}(\mathbf{x}_t, t) + \mathbf{v}_t(\mathbf{x}_t)\big]\,\mathrm{d}t + g(t)\,\mathrm{d}\mathbf{w}_t, \tag{7.7.2.301}$$

其中 $\mathbf{v}_t : \mathbb{R}^D \to \mathbb{R}^D$ 是待优化的漂移（式 (7.7.2.303)）。在标准可积性条件下（如 Novikov 条件），由 Girsanov 定理（见第 C.2.1 节），受控律 P 与参考律 R 之间的 KL 散度具有动态（动能）形式

$$\mathcal{D}_{\mathrm{KL}}(P\|R) = \mathbb{E}_P\left[\frac{1}{2}\int_0^T \frac{\|\mathbf{v}_t(\mathbf{x}_t)\|^2}{g^2(t)}\,\mathrm{d}t\right] = \frac{1}{2}\int_0^T \int_{\mathbb{R}^D} \frac{\|\mathbf{v}_t(\mathbf{x})\|^2}{g^2(t)}\,p_t(\mathbf{x})\,\mathrm{d}\mathbf{x}\,\mathrm{d}t, \tag{7.7.2.302}$$

其中 p_t 是受控过程下 $\mathbf{x}_t$ 的时间-t 边缘。第二个等号来自全期望公式。

因此，SB 问题可重新表述为：在所有把过程从 $t = 0$ 处 p_{src} 导向 $t = T$ 处 p_{tgt} 的可允许漂移 $\mathbf{v}_t$ 上，最小化期望控制能量（Dai Pra, 1991；Pra 与 Pavon, 1990；Pavon 与 Wakolbinger, 1991；Chen *et al.*, 2016）。这给出随机控制表述：

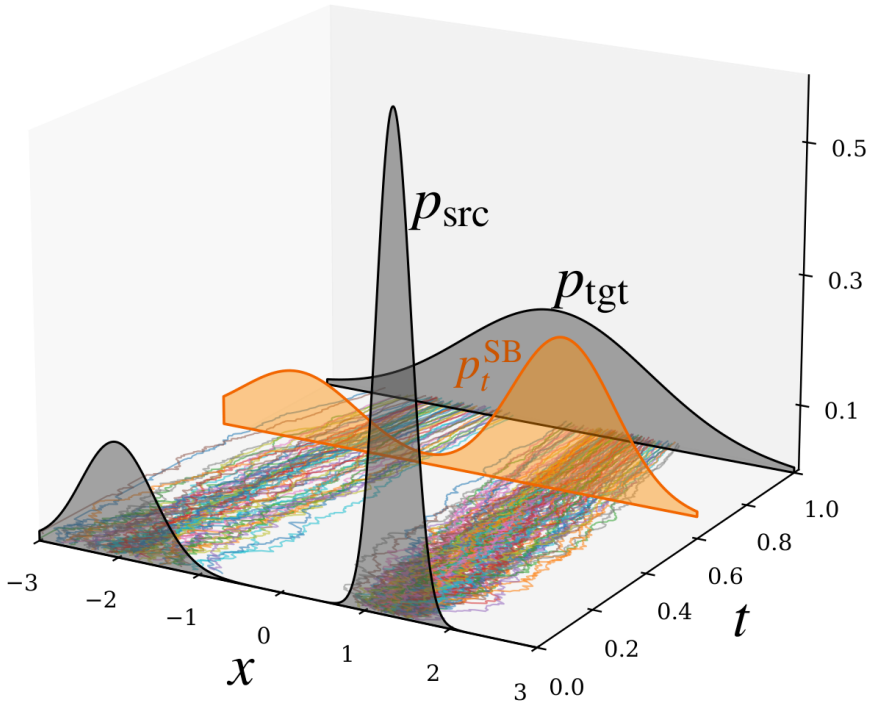


图 7.34: SB 随机控制视角示意。该桥寻找在连接 p_{src} 与 p_{tgt} 的同时偏离参考过程最小的随机路径。

$$\mathrm{SB}_\varepsilon(p_{\mathrm{src}}, p_{\mathrm{tgt}}) = \min_{\substack{\mathbf{v}_t \ \text{s.t.}\ \mathrm{d}\mathbf{x}_t = [\mathbf{f}(\mathbf{x}_t,t)+\mathbf{v}_t(\mathbf{x}_t)]\mathrm{d}t + g(t)\,\mathrm{d}\mathbf{w}_t,\\ \mathbf{x}_0\sim p_{\mathrm{src}},\ \mathbf{x}_T\sim p_{\mathrm{tgt}}}} \frac{1}{2}\int_0^T \int_{\mathbb{R}^D} \frac{\|\mathbf{v}_t(\mathbf{x})\|^2}{g^2(t)}\,p_t(\mathbf{x})\,\mathrm{d}\mathbf{x}\,\mathrm{d}t, \tag{7.7.2.303}$$

重要的是，端点分布 p_{src} 与 p_{tgt} 是任意的；控制 $\mathbf{v}_t$ 正是用来“桥接”参考动力学于这两个边缘之间，同时在 KL 散度下尽量贴近参考过程 R。

一个特例：Brown 参考。 式 (7.7.2.303) 与式 (7.7.2.291) 中的 OT 的 Benamou–Brenier 表述很相像，尤其是当参考过程 R^{ε}（$\varepsilon > 0$）取 Brown 运动时：

$$\mathrm{d}\mathbf{x}_t = \sqrt{\varepsilon}\,\mathrm{d}\mathbf{w}_t, \tag{7.7.2.304}$$

于是 $\mathbf{f} \equiv \mathbf{0}$ 且 $g(t) \equiv \sqrt{\varepsilon}$。

在这一设定下，SB 问题寻找一条在 KL 散度下最贴近 Brown 参考 R^{ε}、同时匹配端点边缘的路径分布 P：

$$\mathrm{SB}_{\varepsilon}(p_{\mathrm{src}}, p_{\mathrm{tgt}}) := \min_{P} \mathcal{D}_{\mathrm{KL}}(P \| R^{\varepsilon}) \qquad \text{s.t.} \quad P_0 = p_{\mathrm{src}},\ P_T = p_{\mathrm{tgt}}. \tag{7.7.2.305}$$

等价的随机控制表述于是成为

$$\mathrm{SB}_{\varepsilon}(p_{\mathrm{src}}, p_{\mathrm{tgt}}) = \min_{\substack{\mathbf{v}_t \text{ s.t. } \mathrm{d}\mathbf{x}_t = \sqrt{\varepsilon}\mathrm{d}\mathbf{w}_t, \\ \mathbf{x}_0 \sim p_{\mathrm{src}},\ \mathbf{x}_T \sim p_{\mathrm{tgt}}}} \frac{1}{2\varepsilon} \int_0^T \int_{\mathbb{R}^D} \|\mathbf{v}_t(\mathbf{x})\|^2 p_t(\mathbf{x})\,\mathrm{d}\mathbf{x}\,\mathrm{d}t. \tag{7.7.2.306}$$

为什么需要指定参考分布？ 与经典 OT 不同，SB 问题因其随机本性而需要一个参考分布。在 OT 中，代价函数（例如 $c(\mathbf{x}, \mathbf{y}) \propto \|\mathbf{x} - \mathbf{y}\|^2$）隐式定义了一条唯一的确定性测地线，因而无需参考。相比之下，SB 设定允许无穷多个连接边缘的随机过程，不存在“自然”路径的内蕴概念。参考测度 R 编码了系统 underlying 的物理或几何结构（如 Brown 运动），并定义基于 KL 的优化目标 $\mathcal{D}_{\mathrm{KL}}(P\|R)$；缺了它，“最优”这一概念就无从定义。

耦合 PDE 刻画。 描述 SB 解的一个方便方式是借助两个时空势 $\Psi(x,t)$ 与 $\widehat{\Psi}(x,t)$。令 p_t^{SB} 表示式 (7.7.2.300) 中最优轨迹律 P^* 在时刻 $t \in [0,T]$ 的边缘。则有对称分解（Dai Pra, 1991）：

$$p_t^{\mathrm{SB}}(x) = \Psi(x,t)\,\widehat{\Psi}(x,t), \tag{7.7.2.307}$$

其中 Ψ 与 $\widehat{\Psi}$ 求解（线性）Schrödinger 方程组（Caluya 与 Halder, 2021；Chen *et al.*, 2021；Chen *et al.*, 2022）：

$$\begin{aligned} \frac{\partial \Psi}{\partial t}(\mathbf{x},t) &= -\nabla_{\mathbf{x}}\Psi(\mathbf{x},t)\cdot\mathbf{f}(\mathbf{x},t) - \frac{g^2(t)}{2}\Delta_{\mathbf{x}}\Psi(\mathbf{x},t), \\ \frac{\partial \widehat{\Psi}}{\partial t}(\mathbf{x},t) &= -\nabla_{\mathbf{x}}\cdot\big(\widehat{\Psi}(\mathbf{x},t)\,\mathbf{f}(\mathbf{x},t)\big) + \frac{g^2(t)}{2}\Delta_{\mathbf{x}}\widehat{\Psi}(\mathbf{x},t), \end{aligned} \tag{7.7.2.308}$$

满足边界条件

$$\Psi(\mathbf{x},0)\widehat{\Psi}(\mathbf{x},0) = p_{\mathrm{src}}(\mathbf{x}), \qquad \Psi(\mathbf{x},T)\widehat{\Psi}(\mathbf{x},T) = p_{\mathrm{tgt}}(\mathbf{x}). \tag{7.7.2.309}$$

时间向前的 Schrödinger 桥 SDE。 一旦 Ψ 已知，最优动力学就是被时空因子 Ψ 倾斜的参考扩散：

$$\mathrm{d}\mathbf{x}_t = \big[\mathbf{f}(\mathbf{x}_t,t) + g^2(t)\nabla_{\mathbf{x}}\log\Psi(\mathbf{x}_t,t)\big]\mathrm{d}t + g(t)\,\mathrm{d}\mathbf{w}_t, \qquad \mathbf{x}_0 \sim p_{\mathrm{src}}. \tag{7.7.2.310}$$

令 Q 表示式 (7.7.2.310) 的轨迹律（由式 (7.7.2.307) 与 (7.7.2.308) 有 $Q_0 = p_{\mathrm{src}}$、$Q_T = p_{\mathrm{tgt}}$）。则 $Q = P^*$，而式 (7.7.2.303) 的极小元 $\mathbf{v}^*$ 为（见 Chen *et al.*, 2021 第 4.6 节）：

$$\mathbf{v}_t^*(\mathbf{x}) = g^2(t)\nabla_{\mathbf{x}}\log\Psi(\mathbf{x},t). \tag{7.7.2.311}$$

也就是说，漂移校正 $g^2\nabla_{\mathbf{x}}\log\Psi$ 恰是为匹配端点边缘所需的、对参考过程的最小 KL 扰动。

时间反向的 Schrödinger 桥 SDE。 同一条最优路径律也可时间反向地生成。查看反向时间漂移形式的一个便捷方式，是概念性地使用扩散的标准时间反演恒等式：

$$\mathbf{b}^-(\mathbf{x},t) = \mathbf{b}^+(\mathbf{x},t) - g^2(t)\nabla_{\mathbf{x}}\log p_t^{\mathrm{SB}}(\mathbf{x}), \tag{7.7.2.312}$$

其中 $\mathbf{b}^+ = \mathbf{f} + g^2\nabla\log\Psi$ 且 $p_t = \Psi\widehat{\Psi}$。由此给出

$$\mathbf{b}^-(\mathbf{x},t) = \mathbf{f}(\mathbf{x},t) - g^2(t)\nabla_{\mathbf{x}}\log\widehat{\Psi}(\mathbf{x},t). \tag{7.7.2.313}$$

于是反向时间 SDE 为

$$\mathrm{d}\mathbf{x}_t = \big[\mathbf{f}(\mathbf{x}_t,t) - g^2(t)\nabla_{\mathbf{x}}\log\widehat{\Psi}(\mathbf{x}_t,t)\big]\mathrm{d}t + g(t)\,\mathrm{d}\bar{\mathbf{w}}_t, \qquad \mathbf{x}_T \sim p_{\mathrm{tgt}}. \tag{7.7.2.314}$$

等价地，把时间重参数化为 $\mathbf{y}_\tau := \mathbf{x}_{T-\tau}$，使 τ 从 0 增到 T。则 $\mathbf{y}_\tau$ 在 τ 中向前演化，初值 $\mathbf{y}_0 \sim p_{\mathrm{tgt}}$：

$$\begin{aligned}\mathrm{d}\mathbf{y}_\tau = \big[-\mathbf{f}(\mathbf{y}_\tau, T-\tau) + g^2(T-\tau)\nabla_{\mathbf{y}}\log\widehat{\Psi}(\mathbf{y}_\tau, T-\tau)\big]\mathrm{d}\tau \\ + g(T-\tau)\,\mathrm{d}\mathbf{w}_\tau.\end{aligned} \tag{7.7.2.315}$$

在式 (7.7.2.303) 的反向时间随机控制表述中（反向时钟下二次型能量相同）：

$$\min_{\substack{\mathbf{u}_\tau \text{ s.t. } \mathrm{d}\mathbf{y}_\tau = [-\mathbf{f}(\mathbf{y}_\tau,T-\tau)+\mathbf{u}_\tau(\mathbf{y}_\tau)]\mathrm{d}\tau + g(T-\tau)\,\mathrm{d}\mathbf{w}_\tau,\\ \mathbf{y}_0\sim p_{\mathrm{tgt}},\ \mathbf{y}_T\sim p_{\mathrm{src}}}} \frac{1}{2}\int_0^T\int_{\mathbb{R}^D} \frac{\|\mathbf{u}_\tau(\mathbf{y})\|^2}{g^2(T-\tau)}\,p_{T-\tau}(\mathbf{y})\,\mathrm{d}\mathbf{y}\,\mathrm{d}\tau. \tag{7.7.2.316}$$

其最优控制为

$$\mathbf{u}_t^*(\mathbf{x}) = -g^2(t)\nabla_{\mathbf{x}}\log\widehat{\Psi}(\mathbf{x},t). \tag{7.7.2.317}$$

向前与反向两种描述都给出同一条最优路径律 P^*，它们由下式联系：

$$\nabla\log p_t^{\mathrm{SB}} = \nabla\log\Psi + \nabla\log\widehat{\Psi}, \qquad \mathbf{b}^- = \mathbf{b}^+ - g^2\nabla\log p_t^{\mathrm{SB}}, \tag{7.7.2.318}$$

故二者边缘在每一时刻都与 p_t^{SB} 重合。附加漂移项 $g^2\nabla\log\Psi$（向前）与 $-g^2\nabla\log\widehat{\Psi}$（反向时间）扮演控制力的角色，引导参考扩散匹配端点边缘，同时在相对熵下尽量贴近参考。

耦合 PDE 方法的实际障碍。 要基于式 (7.7.2.314) 构造生成过程，就必须求解式 (7.7.2.308) 中的耦合 PDE 以获得后向 Schrödinger 势 $\widehat{\Psi}$。然而这些 PDE 出了名地难求解，即便在低维情形也是如此，这使其在生成建模中难以直接应用。为绕开这一点，若干工作提出了替代策略：借助 Score SDE 技术迭代地求解每个半桥问题（$p_{\text{tgt}} \leftarrow p_{\text{src}}$ 与 $p_{\text{tgt}} \to p_{\text{src}}$，De Bortoli *et al.*, 2021）；优化代理似然界（Chen *et al.*, 2022；Liu *et al.*, 2023）；或基于后验 $\mathbf{x}_t|\mathbf{x}_0, \mathbf{x}_T$ 的解析解设计免模拟训练，样本对 $(\mathbf{x}_0, \mathbf{x}_T) \sim p_{\text{src}} \otimes p_{\text{tgt}}$（Liu *et al.*, 2023）。我们在此不深入技术细节，仅在第 7.4 节简要讨论扩散模型与 SB 的联系。

7.2.4 全局推前与局部动力学：DGM 的 OT 类比

从最优传输的视角（式 (7.7.2.286)）出发，可以借助深度生成模型学习一个从简单先验到数据的传输（推前）映射，即 $\mathbf{G}_{\#}p_{\text{prior}} \approx p_{\text{data}}$。虽然 $\mathbf{G}_\phi$ 一般并不与最优传输映射重合（除 Genevay *et al.*, 2018；Onken *et al.*, 2021 等在适当条件下强加 OT 目标的工作外），Benamou–Brenier 表述（式 (7.7.2.291)）提供了一个互补的动态视角。它不直接学习单个全局映射，而把传输描述为由一个随时间变化的局部向量场生成的连续流，刻画出 p_{prior} 与 p_{data} 之间的一条光滑路径。这一动态表述平行于静态 Schrödinger 桥问题（式 (7.7.2.300)）与其随机控制对应物（式 (7.7.2.303)）之间的关系——最优耦合在那里被实现为一个受控扩散过程。在生成建模中浮现出一个类似的类比：标准 DGM（如 GAN 或 VAE）学习一个全局推前映射，而扩散模型学习一个驱动生成动力学的、随时间变化的局部向量场。

7.3 各最优传输表述之间的关系

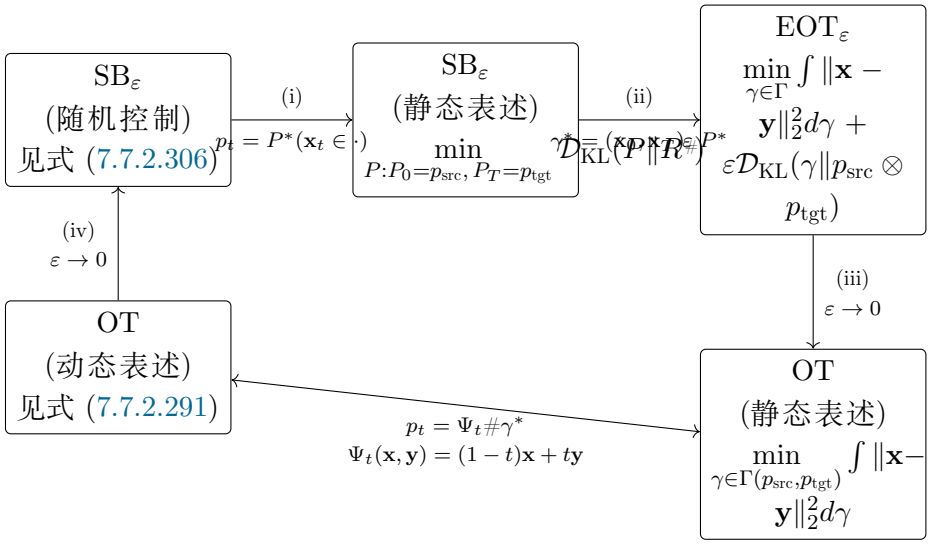


图 7.35: 取 $c(\mathbf{x},\mathbf{y}) = \|\mathbf{x}-\mathbf{y}\|_2^2$ 且 SB 中参考为 R^ε 时，各最优传输变体之间的关系。等价关系汇总：(i) SB$_\varepsilon$（随机控制）$\Leftrightarrow$ SB$_\varepsilon$（静态表述），其中 p_t 是路径测度 P 的时间-t 边缘；(ii) SB$_\varepsilon$（静态表述）$\Leftrightarrow$ EOT$_\varepsilon$（静态表述）（见第 7.3.1 节）；(iii) EOT$_\varepsilon$（静态）$\Leftrightarrow$ OT$_\varepsilon$（静态）（见第 7.3.2 节）；(iv) SB$_\varepsilon$（随机控制）$\Leftrightarrow$ OT（动态）（见第 7.3.3 节）。

在深入技术细节之前，先厘清各最优传输表述及其熵正则化版本如何相互衔接是有帮助的。在高层上，这些问题可视为相关（其衔接图见图 7.35）：

- (i) 取参考 R^ε 为 Brown 运动（$\mathrm{d}\mathbf{x}_t = \sqrt{\varepsilon}\,\mathrm{d}\mathbf{w}_t$）时，SB 问题 SB_ε 等价于其静态表述：演化中的边缘 p_t 恰是最优路径测度 P 的时间-t 切片（见第 7.7.2.300 节）；
- (ii) SB_ε 的静态表述直接连接到熵 OT 问题 EOT_ε（见第 7.3.1 节）；
- (iii) 而 EOT_ε 又可回溯连接到熵 OT 的静态表述 OT_ε（见第 7.3.2 节）；
- (iv) SB_ε 的随机控制视角也可连接到经典 OT 的动态表述（见第 7.3.3 节）。

这些非平凡关系合在一起，给出了一个横跨随机控制、熵正则化与经典 OT 框架的紧凑视图。

7.3.1 SB 与 EOT（对偶）等价

本节给出两个互补视角，说明 SB 本质上与 EOT 等价。与产生单个确定性映射的经典最优传输不同，SB 产生一条随机粒子流：质量以概率方式被传输，边缘在类似扩散的动力学下演化。

从静态视角看，SB 与 EOT 重合，其目标是在两个端点分布之间寻找一个耦合，使传输代价与熵取得平衡。从动态视角看，SB 描述一个受控扩散过程，使其在仍匹配所需端点的同时尽量贴近一个简单参考（如 Brown 运动）。两个视角各自独立地确立这一等价性，提供了两种一致的方式，把 SB/EOT 理解为分布到分布变换的经典表述。

静态 Schrödinger 桥。 令

$$\widetilde{R}^\varepsilon(\mathbf{x},\mathbf{y}) := \frac{1}{Z_\varepsilon} e^{-c(\mathbf{x},\mathbf{y})/\varepsilon}\, p_{\mathrm{src}}(\mathbf{x})\, p_{\mathrm{tgt}}(\mathbf{y}), \tag{7.7.3.319}$$

其中归一化常数为

$$Z_\varepsilon := \iint e^{-c(\mathbf{x},\mathbf{y})/\varepsilon} p_{\mathrm{src}}(\mathbf{x}) p_{\mathrm{tgt}}(\mathbf{y})\,\mathrm{d}\mathbf{x}\,\mathrm{d}\mathbf{y}. \tag{7.7.3.320}$$

于是熵 OT 目标

$$\min_{\gamma\in\Gamma(p_{\mathrm{src}},p_{\mathrm{tgt}})} \Big\{ \int c\,\mathrm{d}\gamma + \varepsilon \mathcal{D}_{\mathrm{KL}}\big(\gamma \| p_{\mathrm{src}} \otimes p_{\mathrm{tgt}}\big) \Big\} = \varepsilon \min_{\gamma\in\Gamma(p_{\mathrm{src}},p_{\mathrm{tgt}})} \mathcal{D}_{\mathrm{KL}}\big(\gamma \| \widetilde{R}^\varepsilon\big) - \varepsilon \log Z_\varepsilon, \tag{7.7.3.321}$$

因而（差一个相加常数后）等价于静态 Schrödinger 桥（式 (7.7.2.305)）：

$$\min_{\gamma\in\Gamma} \mathcal{D}_{\mathrm{KL}}\big(\gamma \| \widetilde{R}^\varepsilon\big). \tag{7.7.3.322}$$

动态等价 (Brown 参考)。 我们也可从动态等价来看这一问题。一个经典结果（Mikami 与 Thieullen, 2006）表明：取二次型代价

$$c(\mathbf{x},\mathbf{y}) = \frac{\|\mathbf{y}-\mathbf{x}\|^2}{2T} \tag{7.7.3.323}$$

的熵 OT，仿射等价于参考路径律 R^ε 为 $[0,T]$ 上 Brown 运动（$\mathrm{d}\mathbf{x}_t = \sqrt{\varepsilon}\,\mathrm{d}\mathbf{w}_t$）的 SB 问题。

这里“仿射等价”意味着最优值相差一个正的缩放因子与一个相加常数（与决策变量无关），故极小元重合。特别地，设 P^* 是 SB 的最优路径分布、γ^* 是 EOT 的最优传输方案。则若 $\mathbf{x}_{[0:T]} \sim P^*$，端点对 $(\mathbf{x}_0, \mathbf{x}_T)$ 服从分布 γ^*：

$$P^* \text{ 求解 SB} \quad \Longleftrightarrow \quad \gamma^* \text{ 求解 EOT，且} (\mathbf{x}_0, \mathbf{x}_T) \sim \gamma^*. \tag{7.7.3.324}$$

换言之：由动态（SB）问题得到的最优过程，诱导出静态（EOT）问题的最优耦合。反之（在关于热核的温和条件下），任何最优静态耦合都可被实现为某个最优 SB 过程的端点。

导出这一事实的关键想法是：路径上的 KL 散度可按端点分解，这意味着 Schrödinger 桥问题退化为仅仅关于 $(\mathbf{x}_0, \mathbf{x}_T)$ 联合分布的 KL 散度。对 Brown 运动，$\mathbf{x}$ 与 $\mathbf{y}$ 之间的转移密度具有 Gaussian 形式，故其负对数是二次型：

$$-\varepsilon \log p_T(\mathbf{y} \,|\, \mathbf{x}) = \frac{\|\mathbf{y} - \mathbf{x}\|^2}{2T} + \text{const.} \tag{7.7.3.325}$$

这表明端点 KL 恰与二次型代价下的熵 OT 目标相同（差一个无关常数）。

一般参考下的 SB 决定 EOT 代价。 如式 (7.7.2.300) 所讨论，SB 问题并不局限于 Brown 运动；它可对任意（适定的）参考过程定义。这一选择唯一地决定了相应 EOT 问题中的代价函数。关键联系在于：SB 的参考动力学诱导出 EOT 的代价函数。

设参考过程由 $[0,T]$ 上的一个 SDE 支配，产生转移密度 $p_T(\mathbf{y}|\mathbf{x})$，即从时刻 0 的 $\mathbf{x}$ 出发在时刻 T 到达 $\mathbf{y}$ 的似然。则 EOT 代价函数（差一个缩放常数）为

$$c(\mathbf{x}, \mathbf{y}) \propto -\log p_T(\mathbf{y} \,|\, \mathbf{x}). \tag{7.7.3.326}$$

用此代价，求解 SB 问题就等价于求解一个 EOT 问题。简言之，在 SB 中选择参考动力学，在数学上等价于在 EOT 中指定传输代价。由式 (7.7.3.321)，熵 OT 目标与静态 SB 目标相差一个相加项；故两问题等价、有相同极小元。

7.3.2 当 $\varepsilon \to 0$ 时 EOT_ε 退化为 OT

记 γ_ε^* 为 EOT_ε 的最优方案，γ^* 为式 (7.7.2.286) 中未正则化 OT 问题的一个最优方案。下列结果（Mikami 与 Thieullen, 2008；Peyré、Cuturi *et al.*, 2019）表明：当 $\varepsilon \to 0$，熵最优方案 γ_ε^*（在适当意义下）收敛到 OT 方案 γ^*，且 EOT 代价收敛到 OT 代价。

这一收敛结果既根本又实用。原因之一是熵正则化 OT 问题 EOT_ε 可通过 Sinkhorn 等算法高效数值求解。因此，该结果为“在代价函数 $c(\mathbf{x}, \mathbf{y})$ 比二次型更一般时，用小 ε 的 EOT_ε 作为式 (7.7.2.286) 经典 OT 问题的计算上易处理的代理”提供了理论依据。

定理 7.3.1 (EOT_ε 收敛到 OT（非正式））：　当 $\varepsilon \to 0$，最优值收敛：

$$\lim_{\varepsilon \to 0} \mathrm{EOT}_\varepsilon(p_{\mathrm{src}}, p_{\mathrm{tgt}}) = \mathrm{OT}(p_{\mathrm{src}}, p_{\mathrm{tgt}}). \tag{7.7.3.327}$$

此外，最优方案 γ_ε^* 弱收敛到 γ^*。即对所有有界连续（检验）函数 $g : \mathbb{R}^D \times \mathbb{R}^D \to \mathbb{R}$，

$$\mathbb{E}_{(\mathbf{x},\mathbf{y})\sim\gamma_\varepsilon^*}[g(\mathbf{x}, \mathbf{y})] \to \mathbb{E}_{(\mathbf{x},\mathbf{y})\sim\gamma^*}[g(\mathbf{x}, \mathbf{y})]. \tag{7.7.3.328}$$

定理的证明思路： 严格证明我们援引文献（Mikami 与 Thieullen, 2008；Peyré、Cuturi *et al.*, 2019）。下面给出关于值收敛的启发式推导。

记相应最优值为 $V_\varepsilon := \mathrm{EOT}_\varepsilon(p_{\mathrm{src}}, p_{\mathrm{tgt}})$、$V_0 := \mathrm{OT}(p_{\mathrm{src}}, p_{\mathrm{tgt}})$。

上界。 由 γ_ε^* 的最优性，其值 V_ε 不超过使用方案 γ^* 的代价：

$$V_\varepsilon \le \int c \,\mathrm{d}\gamma^* + \varepsilon\, \mathcal{D}_{\mathrm{KL}}\big(\gamma^* \| p_{\mathrm{src}} \otimes p_{\mathrm{tgt}}\big). \tag{7.7.3.329}$$

设 KL 项为有限常数 K，则 $V_\varepsilon \le V_0 + \varepsilon K$。取上极限得 $\limsup_{\varepsilon\to 0} V_\varepsilon \le V_0$。

下界。 由于 KL 散度非负，$V_\varepsilon \ge \int c \,\mathrm{d}\gamma_\varepsilon^*$。由 V_0 作为最小传输代价的定义，任一方案的代价至少为 V_0，故 $\int c \,\mathrm{d}\gamma_\varepsilon^* \ge V_0$。这给出对一切 $\varepsilon > 0$ 有 $V_\varepsilon \ge V_0$，从而 $\liminf_{\varepsilon\to 0} V_\varepsilon \ge V_0$。

结合上下界即得最优值收敛 $\lim_{\varepsilon\to 0} V_\varepsilon = V_0$。最优方案本身 $\gamma_\varepsilon^* \to \gamma^*$ 在弱意义下的收敛，是 Γ-收敛理论中一个更高级的结果，此处从略。 □

7.3.3 当 $\varepsilon \to 0$ 时 SB_ε 退化为 OT

对每个 $\varepsilon > 0$，令 $\mathbf{v}_t^\varepsilon$ 为式 (7.7.2.306) 中 SB 问题的一个极小元，p_t^ε 为由 $\mathbf{v}_t^\varepsilon$ 诱导的受控 SDE $\mathbf{x}_t$ 的边缘分布。则 p_t^ε 满足相应的 Fokker–Planck 方程。与之对比，记 $(p_t^0, \mathbf{v}_t^0)$ 为最优传输 Benamou–Brenier 表述（式 (7.7.2.291)）的一个极小元。

下列定理表明，当 $\varepsilon \to 0$，SB 问题收敛到 OT 问题。与定理 7.3.1 同理，这一结果在实践中很重要。目标 SB_ε 可用 Sinkhorn 型算法高效求解，给出一个数值上易处理、可微的最优传输代理。这在高维或大规模场景下尤为宝贵——那里直接求解器（如基于 Benamou–Brenier 表述者）在计算上变得昂贵。

定理 7.3.2 (SB_ε 收敛到 OT（非正式））**：** 当 $\varepsilon \to 0$，有

$$\lim_{\varepsilon\to 0} \mathrm{SB}_\varepsilon(p_{\mathrm{src}}, p_{\mathrm{tgt}}) = \mathrm{OT}(p_{\mathrm{src}}, p_{\mathrm{tgt}}), \tag{7.7.3.330}$$

其中 OT 为式 (7.7.2.291) 的 Benamou–Brenier 表述。此外，p_t^ε 弱收敛到 p_t^0，$\mathbf{v}_t^\varepsilon$ 在适当函数空间中弱收敛到 $\mathbf{v}_t^0$。

定理的证明思路： 该收敛结果的完整严格证明超出本书范围；详细推导见 Léonard（2012）与 Léonard（2014）。尽管如此，我们可启发式地理解这一收敛为何成立。

在 SB 问题式 (7.7.2.306) 的随机控制表述中，受控 SDE 为

$$\mathrm{d}\mathbf{x}_t = \mathbf{v}_t^\varepsilon(\mathbf{x}_t)\,\mathrm{d}t + \sqrt{2\varepsilon}\,\mathrm{d}\mathbf{w}_t. \tag{7.7.3.331}$$

当 $\varepsilon \to 0$，噪声项消失，SDE 形式上趋近于确定性 ODE：

$$\mathrm{d}\mathbf{x}_t = \mathbf{v}_t^0(\mathbf{x}_t)\,\mathrm{d}t. \tag{7.7.3.332}$$

这提示 SB 问题的最优值收敛到最优传输问题的最优值：

$$\lim_{\varepsilon\to 0} \mathrm{SB}_\varepsilon(p_{\mathrm{src}}, p_{\mathrm{tgt}}) = \mathrm{OT}(p_{\mathrm{src}}, p_{\mathrm{tgt}}). \tag{7.7.3.333}$$

并行地，边缘密度 p_t^ε 满足 Fokker–Planck 方程：

$$\partial_t p_t^\varepsilon + \nabla \cdot \big(p_t^\varepsilon \mathbf{v}_t^\varepsilon\big) = \varepsilon \Delta p_t^\varepsilon. \tag{7.7.3.334}$$

同样当 $\varepsilon \to 0$，扩散项消失，方程形式上退化为连续性方程：

$$\partial_t p_t^0 + \nabla \cdot \left(p_t^0 \mathbf{v}_t^0\right) = 0. \tag{7.7.3.335}$$

至此，我们给出了 EOT 与 SB 之间（在各自假设下）的基本等价性，以及它们通过一个极限过程与 OT 的重要联系，如图 7.35 所示。接下来我们将探索扩散模型如何与这些概念相衔接。 □

7.4 扩散模型的 SDE 是 SB 问题的最优解吗？

7.4.1 扩散模型作为 Schrödinger 桥的特例

SB 框架推广了（基于分数的）扩散模型，使之能在任意源分布与目标分布之间做非线性插值。它通过加入由标量势 $\Psi(\mathbf{x}, t)$ 与 $\widehat{\Psi}(\mathbf{x}, t)$ 导出的控制漂移项来实现这一点，这些势引导参考扩散过程匹配给定的端点边缘（见式 (7.7.2.308)），并遵循分解：

$$\nabla \log \Psi(x, t) + \nabla \log \widehat{\Psi}(x, t) = \nabla \log p_t^{\mathrm{SB}}(\mathbf{x}). \tag{7.7.4.336}$$

这一推广使模型能超越标准 Gaussian 先验、从更广的分布生成样本。

与扩散模型的联系。 扩散模型作为 SB 框架的一个特例出现。设势为常数 $\Psi(\mathbf{x}, t) \equiv 1$。在此假设下，式 (7.7.2.308) 中的第二个 PDE 退化为标准 Fokker–Planck 方程，其解即参考过程的边缘密度：

$$\widehat{\Psi}(\mathbf{x}, t) = p_t^{\mathrm{SB}}(\mathbf{x}). \tag{7.7.4.337}$$

相应的 SB 前向 SDE 于是成为无控制的参考过程：

$$\mathrm{d}\mathbf{x}_t = \mathbf{f}(\mathbf{x}_t, t)\,\mathrm{d}t + g(t)\,\mathrm{d}\mathbf{w}_t, \tag{7.7.4.338}$$

而 SB 反向 SDE 简化为：

$$\mathrm{d}\mathbf{x}_t = \left[\mathbf{f}(\mathbf{x}_t, t) - g^2(t)\nabla \log p_t^{\mathrm{SB}}(\mathbf{x}_t)\right]\mathrm{d}t + g(t)\,\mathrm{d}\bar{\mathbf{w}}_t, \tag{7.7.4.339}$$

这恰是扩散模型所用的 Anderson 反向时间 SDE。这一对应表明：扩散模型可解释为 SB 的零控制极限——势不引入任何附加漂移。

边界条件与一般性。 除非边界约束相容，上述归约纯粹是形式上的。对任意源/目标 $(p_{\mathrm{src}}, p_{\mathrm{tgt}})$，式 (7.7.2.308) 中的 PDE 边界条件一般不被 $\Psi \equiv 1$ 的选择满足。完整的 SB 通过学习非平凡势来解决这一点，这些势诱导出一个非线性控制漂移，弯曲参考动力学以匹配任意给定端点。相比之下，扩散模型把一个端点固定为简单先验（通常为 Gaussian），只学习反向时间分数以到达数据。从这一视角看，SB 是更灵活的框架：配上非平凡势时它桥接任意端点；取 $\Psi \equiv 1$ 时它坍缩为上述扩散模型情形。我们另外指出，在标准线性扩散模型中，$p_T \approx p_{\mathrm{prior}}$ 仅当 $T \to \infty$ 时成立，故与先验的匹配仅是近似的。

7.4.2 扩散模型作为 Schrödinger 半桥

本节说明扩散模型为何不是完整的 Schrödinger 桥，而可通过放松的 *Schrödinger* 半桥概念来理解。半桥只强制一个端点约束（p_{prior} 或 p_{data} 之一），而非同时强制两者，使之成为全桥的单边变体。在形式化这一联系之前，我们先在式 (7.7.2.300) 的一般表述（任意 p_{src}、p_{tgt}）上引入半桥定义。随后回到扩散模型，说明当端点为 p_{prior} 与 p_{data} 时，半桥视角如何自然适用。

Schrödinger 半桥。 SB 问题要求一个随机过程，使其律在 KL 散度下最贴近一个简单参考过程，同时匹配两个端点分布 p_{src} 与 p_{tgt}。求解全桥需要强制两个边界条件，这在计算上常常困难。一个有用的放松是半桥问题：我们只匹配其中一个端点，而非两个。

形式上，设 R 为参考路径分布。前向半桥寻找一个路径分布 P，最小化

$$\min_{P:\, P_0 = p_{\text{src}}} \mathcal{D}_{\text{KL}}(P \| R), \tag{7.7.4.340}$$

只受单一边界 $P_0 = p_{\text{src}}$ 约束。类似地，后向半桥只约束终端分布：

$$\min_{P:\, P_T = p_{\text{tgt}}} \mathcal{D}_{\text{KL}}(P \| R). \tag{7.7.4.341}$$

换言之，前向半桥追问：在所有从所需初始分布出发的过程中，哪一个最像参考？后向半桥对那些终止于所需终端分布的过程追问同一问题。通过迭代地组合这两个放松，可逼近完整的 SB。

扩散模型缺失精确的端点匹配。 扩散模型与 SB 框架的一个关键差异在于终端分布 p_T 的处理。在标准扩散模型中，前向 SDE 关于 $\mathbf{x}_t$ 通常是线性的（见第 4.3.2 节式），并被设计为使 p_T 仅当 $T \to \infty$ 时近似先验：

$$p_T \approx p_{\text{prior}}. \tag{7.7.4.342}$$

然而在有限时刻，p_T 是一个其参数依赖于 p_{data} 的 Gaussian（见第 C.1.5 节）。因此，它一般不能不经仔细调参就匹配所需先验。

相比之下，SB 框架通过引入形如 $g^2(t)\nabla_{\mathbf{x}} \log \Psi(\mathbf{x}, t)$ 的附加控制漂移，在有限时刻 T 强制精确的边缘匹配。这确保终端分布精确满足 $p_T = p_{\text{prior}}$，而不管初始数据分布 $p_0 = p_{\text{data}}$。总结：

- **扩散模型：** $p_T \approx p_{\text{prior}}$，仅当 $T \to \infty$ 时渐近成立；
- **Schrödinger 桥：** 在有限 T 处精确有 $p_T = p_{\text{prior}}$，这通过求解控制势 Ψ 与 $\widehat{\Psi}$ 实现。

扩散 Schrödinger 桥。 标准扩散模型并不强制 $P_T = p_{\text{prior}}$，因而只求解了从 p_{data} 到 p_{prior} 的一个 Schrödinger 半桥。为解决这一点，扩散 Schrödinger 桥（DSB，De Bortoli *et al.*, 2021）遵循迭代比例拟合（IPF）算法的思想、通过交替匹配两个端点边缘来工作，这是一种交替投影方法。它把扩散模型推广到求解完整 SB 问题，步骤如下：

- **步骤 0：参考过程**。以 $P^{(0)} := R_{\mathrm{fwd}}$（参考前向 SDE）初始化：

$$\mathrm{d}\mathbf{x}_t = \mathbf{f}(\mathbf{x}_t, t)\,\mathrm{d}t + g(t)\,\mathrm{d}\mathbf{w}_t, \qquad \mathbf{x}_0 \sim p_{\mathrm{data}}. \tag{7.7.4.343}$$

这保证 $P_0^{(0)} = p_{\mathrm{data}}$，但通常 $P_T^{(0)} \neq p_{\mathrm{prior}}$。

- **步骤 1：后向通过**。计算在时刻 T 匹配 p_{prior}、同时贴近 $P^{(0)}$ 的过程 $P^{(1)}$：

$$P^{(1)} = \arg\min_{P:\, P_T = p_{\mathrm{prior}}} \mathcal{D}_{\mathrm{KL}}(P \| P^{(0)}). \tag{7.7.4.344}$$

这通过用一个神经网络 $\mathbf{s}_{\phi^\times}$ 逼近 oracle 分数函数来实现，结果得到反向时间 SDE：

$$\mathrm{d}\mathbf{x}_t = \big[\mathbf{f}(\mathbf{x}_t, t) - g^2(t)\mathbf{s}_{\phi^\times}(\mathbf{x}_t, t)\big]\mathrm{d}t + g(t)\,\mathrm{d}\bar{\mathbf{w}}_t, \tag{7.7.4.345}$$

从 $\mathbf{x}_T \sim p_{\mathrm{prior}}$ 反向模拟。

- **迭代**。过程 $P^{(1)}$ 满足 $P_T^{(1)} = p_{\mathrm{prior}}$，但其初始边缘 $P_0^{(1)}$ 一般偏离 p_{data}。IPF 通过学习一个前向 SDE 把 $P_0^{(1)}$ 调回 p_{data} 来解决这一点，随后再来一次后向通过以强制 p_{prior}。如此交替往复，不断精化过程，直到收敛到最优桥 P^*，它同时满足 $P_0^* = p_{\mathrm{data}}$ 与 $P_T^* = p_{\mathrm{prior}}$。De Bortoli *et al.*（2021）在温和条件下证明了收敛性。

7.5 扩散模型的 ODE 是 OT 问题的最优映射吗？

本节我们聚焦于二次型代价的最优传输问题。

7.5.1 PF-ODE 流一般不是最优传输

本节给出 Lavenant 与 Santambrogio（2022）的结果，它表明 PF-ODE 的解映射一般并不在二次型代价下给出最优传输映射。

设定。我们考虑一个 VP SDE，具体取 Ornstein–Uhlenbeck 过程，它把一个光滑初始密度 p_0 演化到标准 Gaussian $\mathcal{N}(\mathbf{0}, \mathbf{I})$：

$$\mathrm{d}\mathbf{x}(t) = -\mathbf{x}(t)\,\mathrm{d}t + \sqrt{2}\,\mathrm{d}\mathbf{w}(t), \qquad \mathbf{x}(0) \sim p_0. \tag{7.7.5.346}$$

相应的 PF-ODE 为

$$\frac{\mathrm{d}\mathbf{S}_t(\mathbf{x})}{\mathrm{d}t} = -\mathbf{S}_t(\mathbf{x}) - \nabla \log p_t\big(\mathbf{S}_t(\mathbf{x})\big), \qquad \mathbf{S}_0(\mathbf{x}) = \mathbf{x}. \tag{7.7.5.347}$$

这里 $\mathbf{S}_t$ 表示把 p_0 推前为边缘 p_t 的流映射：

$$(\mathbf{S}_t)_{\#} p_0 = p_t, \qquad \text{即} \quad p_t(\mathbf{y}) = \int_{\mathbb{R}^D} \delta\big(\mathbf{y} - \mathbf{S}_t(\mathbf{x})\big) p_0(\mathbf{x})\,\mathrm{d}\mathbf{x}. \tag{7.7.5.348}$$

这些密度 p_t 经由 Fokker–Planck 方程演化：

$$\frac{\partial p_t}{\partial t} = \nabla \cdot (\mathbf{x} p_t) + \Delta p_t. \tag{7.7.5.349}$$

这等价于带速度场的连续性方程：

$$\mathbf{v}_t(\mathbf{x}) = -\mathbf{x} - \nabla \log p_t(\mathbf{x}), \tag{7.7.5.350}$$

其流由 $\mathbf{S}_t(\mathbf{x})$ 给出。换言之，PF-ODE 可写为：

$$\frac{\mathrm{d}\mathbf{S}_t(\mathbf{x})}{\mathrm{d}t} = \mathbf{v}_t\big(\mathbf{S}_t(\mathbf{x})\big). \tag{7.7.5.351}$$

当 $t \to \infty$，该映射把初始分布搬运到先验：

$$\mathbf{S}_\infty \# p_0 = \mathcal{N}(\mathbf{0}, \mathbf{I}) =: p_{\text{prior}}. \tag{7.7.5.352}$$

Lavenant 与 Santambrogio（2022）论证的目标。 他们并不直接评估从 p_0 到 Gaussian 的终端映射 $\mathbf{S}_\infty$ 是否最优。相反，他们构造一个特定的初始分布 p_0，并考察整条 PF-ODE 轨迹。其关键观察是：最优性可能沿流在某一点失效。

他们考虑中间边缘 $p_t = \mathbf{S}_t \# p_0$，并定义从 p_{t_0} 到 Gaussian 的残差传输映射为

$$\mathbf{T}_{t\to\infty} := \mathbf{S}_\infty \circ \mathbf{S}_t^{-1}, \qquad \text{对所有} t \geq 0. \tag{7.7.5.353}$$

其论证核心表明：对一个精心选择的 p_0，存在时刻 $t_0 \geq 0$ 使 $\mathbf{T}_{t_0\to\infty}$ 不是从新起始分布 p_{t_0} 到 $\mathcal{N}(\mathbf{0}, \mathbf{I})$ 的二次型代价最优传输映射。

这一结果表明：PF-ODE 流一般并不给出最优传输映射，且最优性这一性质对某些初始分布会失效。

若干工具。 Lavenant 与 Santambrogio（2022）的论证关键依赖下列结果，即 Brenier 定理：

定理 7.5.1 (Brenier 定理（非正式）)**：** *设 ν_1, ν_2 是 $\mathbb{R}^D$ 上两个带光滑密度的概率分布。一个光滑映射 $\mathbf{T} : \mathbb{R}^D \to \mathbb{R}^D$ 是从 ν_1 到 ν_2 的最优传输（在二次型代价下），当且仅当对某个凸函数 u 有 $\mathbf{T} = \nabla u$。此时 $\mathrm{D}\mathbf{T}$ 对称且半正定，且 u 满足 Monge–Ampère 方程：*

$$\det \mathrm{D}^2 u(\mathbf{x}) = \frac{\nu_1(\mathbf{x})}{\nu_2(\nabla u(\mathbf{x}))}. \tag{7.7.5.354}$$

该证明还隐含地使用下列事实（此后不再每次重复）：一个映射是两个分布之间的最优传输，当且仅当其逆是反方向的最优传输。

证明梗概：PF-ODE 一般不是 OT 映射。 Lavenant 与 Santambrogio（2022）采用反证法：他们假设对每个 $t \geq 0$，映射

$$\mathbf{T}_t = \mathbf{S}_t \circ \mathbf{S}_\infty^{-1} \tag{7.7.5.355}$$

都是从 $\mathcal{N}(\mathbf{0}, \mathbf{I})$ 到 p_t 的二次型代价最优传输映射。

步骤 1：Brenier 定理。由 Brenier 定理，任何从 Gaussian 出发的最优传输映射的 Jacobian 必须对称且半正定。于是

$$\mathrm{D}\mathbf{T}_t(\mathbf{x}) = \mathrm{D}\mathbf{S}_t\big(\mathbf{S}_\infty^{-1}(\mathbf{x})\big)\, \mathrm{D}\big(\mathbf{S}_\infty^{-1}\big)(\mathbf{x}) \tag{7.7.5.356}$$

必须对所有 t 与 $\mathbf{x}$ 对称。这里 $\mathrm{D}\mathbf{T}_t(\mathbf{x})$ 表示关于 $\mathbf{x}$ 的全微分。

步骤 2：对对称性条件关于时间求导。对时间求导：

$$\frac{\partial}{\partial t}\mathrm{D}\mathbf{T}_t(\mathbf{x}) = \Big(\frac{\partial}{\partial t}\mathrm{D}\mathbf{S}_t\Big)\big(\mathbf{S}_\infty^{-1}(\mathbf{x})\big)\mathrm{D}\big(\mathbf{S}_\infty^{-1}\big)(\mathbf{x}). \tag{7.7.5.357}$$

既然对称性对所有 t 成立，可知该导数保持对称。

利用流 ODE（关于 $\mathbf{x}$ 求导），我们得到：

$$\frac{\partial(\mathrm{D}\mathbf{S}_t)}{\partial t} = \mathrm{D}\mathbf{v}_t(\mathbf{S}_t)\cdot\mathrm{D}\mathbf{S}_t = \big(-\mathbf{I} - \mathrm{D}^2\log p_t(\mathbf{S}_t)\big)\cdot\mathrm{D}\mathbf{S}_t. \tag{7.7.5.358}$$

结合上式，可见

$$\big(-\mathbf{I} - \mathrm{D}^2\log p_t(\mathbf{S}_t)\big)\cdot\mathrm{D}\mathbf{S}_t\cdot\mathrm{D}\big(\mathbf{S}_\infty^{-1}\big) \tag{7.7.5.359}$$

对所有 $t \geq 0$ 对称。

在 $t = 0$，有 $\mathbf{S}_0 = \mathbf{I}$ 且 $\mathrm{D}\mathbf{S}_0 = \mathbf{I}$，从而：

$$\big(-\mathbf{I} - \mathrm{D}^2\log p_0\big(\mathbf{S}_\infty^{-1}(\mathbf{x})\big)\big)\cdot\mathrm{D}\big(\mathbf{S}_\infty^{-1}\big)(\mathbf{x}) \quad \text{对称}. \tag{7.7.5.360}$$

步骤 3：交换条件。既然 $\mathbf{T}_0 = \mathbf{S}_\infty^{-1}$ 被假设最优，其 Jacobian $D\mathbf{T}_0 = \mathrm{D}(\mathbf{S}_\infty^{-1})$ 对称。此外，Hessian $\mathrm{D}^2\log p_0$ 对称。回忆两个对称矩阵相乘为对称阵，当且仅当它们可交换。于是对所有 $\mathbf{x}\in\mathbb{R}^D$，

$$\mathrm{D}^2\log p_0\big(\mathbf{S}_\infty^{-1}(\mathbf{x})\big) \quad \text{必须与} \quad \mathrm{D}(\mathbf{S}_\infty^{-1})(\mathbf{x}) \text{ 可交换}. \tag{7.7.5.361}$$

令 $\mathbf{y} = \mathbf{S}_\infty^{-1}(\mathbf{x})$ 给出等价条件：对所有 $\mathbf{y}\in\mathbb{R}^D$，

$$\mathrm{D}^2\log p_0(\mathbf{y}) \quad \text{必须与} \quad \mathrm{D}\mathbf{S}_\infty(\mathbf{y}) \text{ 可交换}. \tag{7.7.5.362}$$

现在把这一条件化为更可计算的形式。既然 $\mathbf{S}_\infty$ 在 p_0 与 $\mathcal{N}(\mathbf{0},\mathbf{I})$ 之间最优，Brenier 定理保证对某个凸函数 u 有 $\mathbf{S}_\infty = \nabla u$。由 Monge–Ampère 方程，可得：

$$\log p_0(\mathbf{y}) = \log\det\big(\mathrm{D}^2u(\mathbf{y})\big) - \frac{1}{2}\|\nabla u(\mathbf{y})\|^2 + \text{Constant}. \tag{7.7.5.363}$$

该条件（代入 $\mathrm{D}\mathbf{S}_\infty = \mathrm{D}^2u$）成为：

$$\mathrm{D}^2\Big(\log\det\mathrm{D}^2u - \frac{1}{2}\|\nabla u\|^2\Big) \quad \text{必须与} \quad \mathrm{D}^2u \text{ 可交换}. \tag{7.7.5.364}$$

这给出了 $\mathbf{T}_t$ 最优的一个必要条件。

步骤 4：构造反例。我们展示如何利用这一必要条件导出矛盾。

假设我们能构造一个凸函数 u，使得对某个 $\mathbf{x}\in\mathbb{R}^D$，

$$\mathrm{D}^2\Big(\log\det\mathrm{D}^2u(\mathbf{x}) - \frac{1}{2}|\nabla u(\mathbf{x})|^2\Big) \tag{7.7.5.365}$$

不与 $\mathrm{D}^2u(\mathbf{x})$ 可交换。定义 $p_0 = (\nabla u)_\#^{-1}\mathcal{N}(\mathbf{0},\mathbf{I})$，Brenier 定理蕴含 ∇u 是从 p_0 到 $\mathcal{N}(\mathbf{0},\mathbf{I})$ 的最优传输。然而式 (7.7.5.364) 的条件失效，导致矛盾。因此我们的目标就是构造这样一个函数。考虑

$$u(\mathbf{x}) = \frac{1}{2}\|\mathbf{x}\|^2 + \varepsilon\phi(\mathbf{x}), \qquad \text{对小}\varepsilon. \tag{7.7.5.366}$$

则 $\mathrm{D}^2 u(\mathbf{0}) = \mathbf{I} + \varepsilon \mathrm{D}^2\phi(\mathbf{0})$，而 $\mathbf{x} = \mathbf{0}$ 处的交换条件要求 $\mathrm{D}^2\phi(\mathbf{0})$ 与 $\mathrm{D}^2(\Delta\phi)(\mathbf{0})$ 可交换。

例如，在 $\mathbb{R}^2$ 中取

$$\phi(x_1, x_2) = x_1 x_2 + x_1^4 \tag{7.7.5.367}$$

就给出一个反例，其中 Hessian $\mathrm{D}^2 \log p_0$ 与 Jacobian $\mathrm{D}^2 u$ 不可交换。

这一矛盾表明 $\mathbf{T}_t$ 不可能对所有 $t \geq 0$ 最优。因此，存在某个 $t_0 \geq 0$ 使映射 $\mathbf{T}_{t_0 \to \infty}$ 不是最优的。

7.5.2 典范线性流与 Reflow 能否给出 OT 映射？

我们已经看到 PF-ODE（尤其是 VP 型前向核）一般并不是 OT 映射。现在一个自然的问题是：

问题 7.5.1： 把线性插值流 $(1-t)\mathbf{x}_0 + t\mathbf{x}_1$（其中 $\mathbf{x}_0 \sim p_{\mathrm{src}}$、$\mathbf{x}_1 \sim p_{\mathrm{tgt}}$）作用于独立耦合 $\pi(\mathbf{x}_0, \mathbf{x}_1) = p_{\mathrm{src}}(\mathbf{x}_0) p_{\mathrm{tgt}}(\mathbf{x}_1)$ 时，能否恢复出 OT 映射?

答案是否定的。

尽管如此，把一条线性路径与一个给定耦合相结合，给出了真实 OT 代价的一个实用上界。在所有可能路径中，线性插值给出最紧的这种上界，如下述讨论所示。

典范线性流与最优传输。 聚焦于二次型代价的最优传输，我们考虑式 (7.7.2.286) 的等价形式，即式 (7.7.2.291) 的 Benamou–Brenier 表述：

$$\mathcal{K}(p_{\mathrm{src}}, p_{\mathrm{tgt}}) := \min_{\substack{(p_t, \mathbf{v}_t) \text{ s.t. } \partial_t p_t + \nabla\cdot(p_t \mathbf{v}_t) = 0, \\ p_0 = p_{\mathrm{src}},\, p_1 = p_{\mathrm{tgt}}}} \int_0^1 \int_{\mathbb{R}^D} \|\mathbf{v}_t(\mathbf{x})\|^2 p_t(\mathbf{x}) \,\mathrm{d}\mathbf{x}\,\mathrm{d}t. \tag{7.7.5.368}$$

然而直接求解这一最小化问题一般难以处理，因为它要求求解一个高度非线性的偏微分方程，即 Monge–Ampère 方程。

虽然求解 Benamou–Brenier 表述一般难以处理，Liu (2022) 与 Lipman *et al.* (2024) 揭示其动能容许一个实用上界。做法是把搜索限制在一族更简单的条件流上，其中每条路径由其固定端点 $(\mathbf{x}_0, \mathbf{x}_1)$（取自源分布与目标分布的某个耦合 $\pi_{0,1}$）定义。在这族条件流内，典范线性插值作为最优选择浮现，形式化如下。

命题 7.5.1 (通过条件流给出 OT 动能的上界)**：** 设 $\pi_{0,1}$ 是 p_{src} 与 p_{tgt} 之间的任一耦合。

1. 动能被任何连接端点的条件流 $\boxtimes_t(\mathbf{x}_0, \mathbf{x}_1)$ 的期望路径能量上界控制：

$$\mathcal{K}(p_{\mathrm{src}}, p_{\mathrm{tgt}}) \leq \mathbb{E}_{(\mathbf{x}_0, \mathbf{x}_1) \sim \pi_{0,1}} \left[\int_0^1 \|\boxtimes_t'(\mathbf{x}_0, \mathbf{x}_1)\|^2 \,\mathrm{d}t \right]. \tag{7.7.5.369}$$

2. 最小化右端上界的唯一条件流 $\boxtimes_t^*$ 是线性插值路径：

$$\boxtimes_t^*(\mathbf{x}_0, \mathbf{x}_1) = (1-t)\mathbf{x}_0 + t\mathbf{x}_1. \tag{7.7.5.370}$$

代入这条最优路径给出该界的最紧版本：

$$\mathcal{K}(p_{\mathrm{src}}, p_{\mathrm{tgt}}) \leq \mathbb{E}_{(\mathbf{x}_0, \mathbf{x}_1) \sim \pi_{0,1}} \|\mathbf{x}_1 - \mathbf{x}_0\|^2. \tag{7.7.5.371}$$

命题的证明思路： 该证明直接应用 Jensen 不等式与条件期望的塔式性质，随后在 Euler–Lagrange 方程下求解简化的变分问题；完整论证见 Lipman *et al.*（2024）第 4.7 节。

换言之，线性插值 $\boxtimes_t^*$（即流匹配与 Rectified Flow 所用的前向核）最小化了真实动能关于任一选定耦合 $\pi_{0,1}$ 的一个上界。

我们强调：在这族条件流内的最优性，并不保证在边缘分布上的全局最优性。 □

Reflow 与最优传输。 两个分布之间最朴素的传输方案，是用一个简单的独立耦合、以直线连接它们的样本。然而这一方案可证明不是最优的，因为其失败不在于直线路径本身，而在于低效的初始点配对。

Reflow 过程或许给出了一个建设性的回应。它是一个专门为校正这一配对而设计的迭代算法，关键在于每一步都保证代价不增（Liu、Gong *et al.*, 2022）。这一性质提示 Reflow 系统性地把传输方案推向更优的构型，这自然引出关于其收敛性的中心问题。

问题 7.5.2： 若我们迭代地施加 Rectify 算子会怎样？所得传输方案序列能否收敛到最优者，抑或 Reflow 过程的不动点会给出 OT 映射？

简短的答案一般是否定的。下面我们解释可能出什么问题。回忆 Reflow 过程通过下列更新迭代地精化 p_{src} 与 p_{tgt} 之间的耦合：

$$\pi^{(k+1)} = \mathrm{Rectify}\big(\pi^{(k)}\big), \tag{7.7.5.372}$$

以乘积耦合 $\pi^{(0)} := p_{\mathrm{src}}(\mathbf{x}_0)p_{\mathrm{tgt}}(\mathbf{x}_1)$ 初始化。更精确地，Rectify 输出更新后的耦合 $\pi^{(k+1)}$：在每次迭代 $k = 0, 1, 2, \ldots$，通过下式学习一个速度场 $\mathbf{v}_t^{(k)}$：

$$\mathbf{v}_t^{(k)} \in \arg\min_{\mathbf{u}_t} \mathcal{L}\big(\mathbf{u}_t \,\big|\, \pi^{(k)}\big), \tag{7.7.5.373}$$

其中 $\mathcal{L}(\mathbf{u}_t|\pi^{(k)})$ 是式 (5.5.4.263) 所定义的损失（例如 RF 或 FM 损失）。此处为记号简便，我们对速度场采用非参数化形式，而非其他语境中所用的参数化形式 ϕ。更新后的耦合于是为：

$$\pi^{(k+1)}(\mathbf{x}_0, \mathbf{x}_1) := p_{\mathrm{src}}(\mathbf{x}_0)\, \delta\big(\mathbf{x}_1 - \boxtimes_1^{(k)}(\mathbf{x}_0)\big), \tag{7.7.5.374}$$

其中 $\boxtimes_1^{(k)}$ 表示从初始条件 $\mathbf{x}_0$ 积分 $\mathbf{v}_t^{(k)}$ 得到的、时刻 $t = 1$ 的解映射。

Liu、Gong *et al.*（2022）观察到：对 p_{src} 与 p_{tgt} 之间的一个耦合 π，存在一个最小化 Reflow 损失（即满足 $\mathcal{L}(\mathbf{v}_t|\pi) = 0$）的速度场 $\mathbf{v}_t$，并不必然蕴含该传输是最优的。

受 Benamou–Brenier 框架启发（其中已知最优传输速度是某个势函数的梯度），Liu（2022）提出附加约束：速度场 $\mathbf{v}_t$ 应为一个势场。相应地，式 (5.5.4.263) 的目标被修改为把 $\mathbf{v}_t$ 限制在梯度向量场（亦称势流）空间内：

$$\mathbf{w}_t^{(k)} \in \arg \min_{\substack{\mathbf{u}_t:\ \mathbf{u}_t = \nabla\varphi, \\ \text{for some } \varphi:\mathbb{R}^D \to \mathbb{R}}} \mathcal{L}\big(\mathbf{u}_t \,\big|\, \pi^{(k)}\big), \tag{7.7.5.375}$$

过程其余部分与 Rectify 相同。我们把这一相应算子记为 $\mathrm{Rectify}_\perp$，强调它向无旋向量场做投影。

设 π 是 p_{src} 与 p_{tgt} 之间的一个耦合。Liu、Gong *et al.*（2022）猜测下列刻画最优性的等价关系：

1. π 是一个最优传输耦合；

2. π 是势校正算子的一个不动点：

$$\pi = \mathrm{Rectify}_{\perp}(\pi); \tag{7.7.5.376}$$

3. 存在一个梯度速度场 $\mathbf{v}_t = \nabla\varphi_t$ 使校正损失为零：

$$\mathcal{L}(\mathbf{v}_t|\pi) = 0. \tag{7.7.5.377}$$

然而，Hertrich *et al.*（2025）给出了两类反例：

1. 当中间分布 p_t 的支撑不连通时，可以找到 $\mathrm{Rectify}_{\perp}$ 的、Reflow 损失为零的不动点，以及梯度速度场，但它们仍不能产生最优耦合。

2. 即便两个端点分布都是 Gaussian，也存在这样的耦合：其损失任意小，但与最优耦合的偏差任意大。

因此，尽管校正流可能产生强生成模型，其作为最优传输求解器的可靠性仍然有限。这凸显了生成建模与有原则的最优传输理论之间的一个重要空缺，邀请人们在二者的交汇处做进一步研究。

最后我们指出，传输代价并不总与下游表现相关联；因此，计算精确的最优传输映射未必带来更好的实用结果。尽管如此，最优传输的各种变体仍是科学与工程中许多问题的基础。扩散模型为探索这些挑战提供了一个强有力的框架。

Part C　扩散模型的采样

Chapter 8

引导与可控生成

扩散模型是强大的生成框架。在无条件设定下，目标是学习 $p_{\text{data}}(\mathbf{x})$ 并在无外部输入的情况下生成样本。

然而，许多应用需要条件生成，即输出满足用户指定的判据。这可通过引导一个无条件模型，或直接学习条件分布 $p_0(\mathbf{x}|\mathbf{c})$ 来实现，其中条件 $\mathbf{c}$（如标签、文本描述或草图）引导整个过程。

本章建立在条件分数的有原则视角之上：它分解为一个无条件方向与一个引导方向，后者在保持真实感的同时把样本推向条件。我们解释为何引导不可或缺，展示条件分数如何作为控制的统一接口，并综述近似引导项的各种途径。随后我们区分控制（满足条件）与对齐（在条件下满足人类偏好），并描述偏好如何被纳入同一框架。最后，我们讨论在不附加奖励模型（即一个学习到的评分器，给与人类偏好更一致的输出赋更高分）的情况下，直接优化偏好。

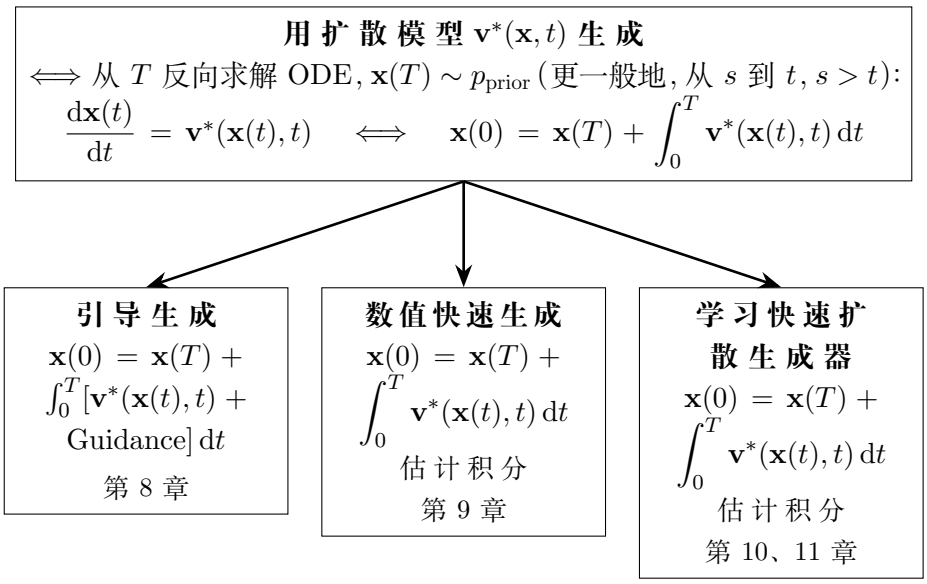


图 8.36: Part C 路线图。扩散生成等价于反向求解 PF-ODE；本章（第 8 章）研究在速度场上叠加引导项以引导生成，第 9 章研究用数值求解器加速积分，第 10、11 章研究学习一个快速生成器。

8.1 序幕

扩散模型的生成过程以由粗到细（coarse-to-fine）的方式进行，为可控生成提供了一个灵活框架。在每一步，少量噪声被去除、样本变得更清晰，逐渐显露更多结构与细

节。这一性质使对生成过程的控制成为可能：通过在学到的、随时间变化的速度场上加入一个引导项，我们可以引导生成轨迹以反映用户意图。

基于引导采样的一个有原则基础，是条件分数的 Bayesian 分解。对每个噪声级 t，

$$\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t|\mathbf{c}) = \underbrace{\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t)}_{\text{无条件方向}} + \underbrace{\nabla_{\mathbf{x}_t} \log p_t(\mathbf{c}|\mathbf{x}_t)}_{\text{引导方向}}. \tag{8.8.1.378}$$

该恒等式表明：条件采样可通过在无条件分数之上加入引导项 $\nabla_{\mathbf{x}_t} \log p_t(\mathbf{c}|\mathbf{x}_t)$ 来实现。范围广泛的可控生成方法（如分类器引导，Dhariwal 与 Nichol, 2021；通用免训练引导，Ye *et al.*, 2024）都可解释为这一引导项的不同近似；由于需要对 $\mathbf{x}_0$ 边缘化，$p_t(\mathbf{c}|\mathbf{x}_t)$ 一般难以处理。

一旦有了这样的近似，采样只需把无条件分数替换为其条件对应物。利用式 (8.8.1.378)，PF-ODE 成为

$$\begin{aligned} \frac{\mathrm{d}\mathbf{x}(t)}{\mathrm{d}t} &= f(t)\mathbf{x}(t) - \frac{1}{2}g^2(t)\underbrace{\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}(t)|\mathbf{c})}_{\text{条件分数}} \\ &= f(t)\mathbf{x}(t) - \frac{1}{2}g^2(t)\big[\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}(t)) + \nabla_{\mathbf{x}_t} \log p_t(\mathbf{c}|\mathbf{x}(t))\big]. \end{aligned} \tag{8.8.1.379}$$

我们强调：引导这些随时间变化的向量场，本质上依赖于它们的线性性；因此下面以分数预测（score prediction）形式表述的讨论，通过式 (6.6.3.274) 中的线性关系，自然地推广到 $\mathbf{x}$-、$\boldsymbol{\epsilon}$- 与 $\mathbf{v}$-预测。

引导方向的具体实现。

1. **分类器引导（CG）。**在第 8.2 节，分类器引导（CG）在加噪数据 $\mathbf{x}_t$（由在级别 t 处污染干净带标签样本得到）上训练一个时间条件分类器 $p_\psi(\mathbf{c}|\mathbf{x}_t, t)$。采样时，其输入梯度给出引导项：

   $$\nabla_{\mathbf{x}_t} \log p_\psi(\mathbf{c}|\mathbf{x}_t, t) \approx \nabla_{\mathbf{x}_t} \log p_t(\mathbf{c}|\mathbf{x}_t), \tag{8.8.1.380}$$

   随后加到无条件分数上（Dhariwal 与 Nichol, 2021）。

2. **无分类器引导（CFG）。**在第 8.3 节，CFG 直接训练单个条件模型

   $$\mathbf{s}_\phi(\mathbf{x}_t, t, \mathbf{c}) \approx \nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t|\mathbf{c}), \tag{8.8.1.381}$$

   其中无条件模型通过在一部分训练步中用一个特殊空 token 随机替换条件来联合学习。

3. **免训练（代理）引导。**条件 $p_t(\mathbf{c}|\mathbf{x}_t)$ 一般难以处理，因为它需要对干净隐变量 $\mathbf{x}_0$ 边缘化：

   $$p_t(\mathbf{c}|\mathbf{x}_t) = \int p(\mathbf{c}|\mathbf{x}_0)p(\mathbf{x}_0|\mathbf{x}_t)\,\mathrm{d}\mathbf{x}_0, \tag{8.8.1.382}$$

而在典型应用中这些因子至少有一个未知，使该积分不可解。在第 8.4 节（第 8.4.1 节），免训练（基于损失的）引导避免直接计算条件似然 $p_t(\mathbf{c}|\mathbf{x}_t)$。它引入一个现成的损失 $\ell(\mathbf{x}_t, \mathbf{c}; t)$，并定义代理条件分布 $\widetilde{p}_t(\mathbf{c}|\mathbf{x}_t)$ 为

$$\widetilde{p}_t(\mathbf{c}|\mathbf{x}_t) \propto \exp\big(-\tau\,\ell(\mathbf{x}_t, \mathbf{c}; t)\big), \qquad \tau > 0, \tag{8.8.1.383}$$

充当伪似然。这一表述绕开了计算真条件似然的不可解性，同时仍能通过所选损失的梯度实现引导。其条件分数仅由损失关于 τ 的梯度计算：

$$\nabla_{\mathbf{x}_t} \log \widetilde{p}_t(\mathbf{c}|\mathbf{x}_t) = -\tau \nabla_{\mathbf{x}_t} \ell(\mathbf{x}_t, \mathbf{c}; t). \tag{8.8.1.384}$$

该项以引导权重 w_t 加到无条件分数上：

$$\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t) + w_t\big[-\tau \nabla_{\mathbf{x}_t} \ell(\mathbf{x}_t, \mathbf{c}; t)\big], \tag{8.8.1.385}$$

这恰是下列倾斜密度 $\widetilde{p}_t^{\text{tilt}}(\mathbf{x}_t|\mathbf{c})$ 的分数：

$$\widetilde{p}_t^{\text{tilt}}(\mathbf{x}_t|\mathbf{c}) \propto p_t(\mathbf{x}_t)\widetilde{p}_t(\mathbf{c}|\mathbf{x}_t)^{w_t} \propto p_t(\mathbf{x}_t) \exp\big(-w_t \tau \ell(\mathbf{x}_t, \mathbf{c}; t)\big). \tag{8.8.1.386}$$

实践中，我们在式 (8.8.1.379) 的采样中用此倾斜分数替换条件分数，并求解所得 ODE 来采样。据此，分类器引导就是一种代理引导，其代理 $\widetilde{p}_t(\mathbf{c}|\mathbf{x}_t) := p_{\psi^\times}(\mathbf{c}|\mathbf{x}_t, t)$ 由下式学习：

$$\ell(\mathbf{x}_t, \mathbf{c}; t) = -\log p_{\psi^\times}(\mathbf{c}|\mathbf{x}_t, t), \qquad \tau = 1. \tag{8.8.1.387}$$

引导对采样轨迹的影响见图 8.37。所有这些技术同样可叠加在条件模型之上，从而在生成时注入额外控制信号。

注 8.1.1： 引导 PF-ODE 一般并不从倾斜族中采样。即便用精确分数与精确 ODE 积分，把分数替换为倾斜分数，也不会使时间-t 边缘等于 $\{\widetilde{p}_t^{\text{tilt}}(\cdot|\mathbf{c})\}_{t\in[0,1]}$，终端律也不等于 $\widetilde{p}_0^{\text{tilt}}(\cdot|\mathbf{c})$。

定义

$$\mathbf{v}_t^{\text{orig}} = \mathbf{f} - \frac{1}{2} g^2(t) \nabla \log p_t, \qquad \mathbf{h}_t(\mathbf{x}) = e^{-w_t \tau \ell(\mathbf{x}, \mathbf{c}; t)}, \qquad \widetilde{p}_t^{\text{tilt}} = \frac{p_t \mathbf{h}_t}{Z_t}. \tag{8.8.1.388}$$

引导 PF-ODE 使用

$$\mathbf{v}_t^{\text{tilt}} = \mathbf{f} - \frac{1}{2} g^2(t) \nabla \log \widetilde{p}_t^{\text{tilt}} = \mathbf{v}_t^{\text{orig}} - \frac{1}{2} g^2(t) \nabla \log \mathbf{h}_t. \tag{8.8.1.389}$$

若 $\widetilde{p}_t^{\text{tilt}}$ 是真边缘，它们应满足

$$\partial_t \widetilde{p}_t^{\text{tilt}} + \nabla \cdot \big(\widetilde{p}_t^{\text{tilt}} \mathbf{v}_t^{\text{tilt}}\big) = 0. \tag{8.8.1.390}$$

但直接计算给出残差

$$\begin{aligned} \partial_t \widetilde{p}_t^{\text{tilt}} + \nabla \cdot \big(\widetilde{p}_t^{\text{tilt}} \mathbf{v}_t^{\text{tilt}}\big) = \widetilde{p}_t^{\text{tilt}} \Big[& \partial_t \log \mathbf{h}_t + \mathbf{v}_t^{\text{orig}} \cdot \nabla \log \mathbf{h}_t \\ & - \frac{1}{2} g^2(t) \big(\Delta \log \mathbf{h}_t + \|\nabla \log \mathbf{h}_t\|^2\big) - \frac{Z_t'}{Z_t} \Big]. \end{aligned} \tag{8.8.1.391}$$

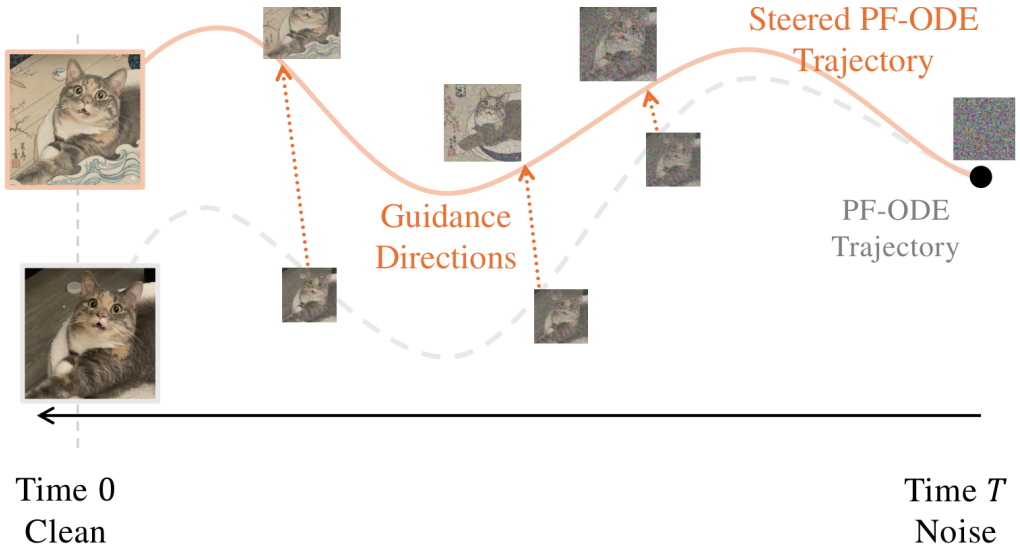


Figure 8.1: Illustration of steered diffusion sampling. Reverse-time PF-ODE sampling begins from pure noise at the right ($t = T$) and gradually evolves toward a clean sample at the left ($t = 0$). During this process, guidance directions $\nabla_{\mathbf{x}_t} \log \tilde{p}_t(\mathbf{c}|\mathbf{x}_t)$, weighted by w_t, modify the

图 8.37: 引导扩散采样示意。反向时间 PF-ODE 采样从右端纯噪声（$t = T$）出发，逐渐向左端干净样本（$t = 0$）演化。在此过程中，引导方向 $\nabla_{\mathbf{x}_t} \log \widetilde{p}_t(\mathbf{c}|\mathbf{x}_t)$（以 w_t 加权）按 $\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t) + w_t \nabla_{\mathbf{x}_t} \log \widetilde{p}_t(\mathbf{c}|\mathbf{x}_t)$ 修改速度场。这些附加方向把轨迹导向期望属性（日本画风格），同时样本由粗到细地逐步精化。

于是 $\widetilde{p}_t^{\text{tilt}}$ 与 PF-ODE 边缘重合，当且仅当该括号对所有 $\mathbf{x}$ 为零，即

$$\partial_t \log \mathbf{h}_t + \mathbf{v}_t^{\text{orig}} \cdot \nabla \log \mathbf{h}_t = \frac{1}{2} g^2(t) \big(\Delta \log \mathbf{h}_t + \|\nabla \log \mathbf{h}_t\|^2 \big) + \frac{Z_t'}{Z_t}. \tag{8.8.1.392}$$

当 $\omega_t \equiv 0$（无条件生成）时该条件平凡成立；但对 $\mathbf{h}_t(\mathbf{x}) = e^{-w_t \tau \ell(\mathbf{x}, \mathbf{c}; t)}$ 它几乎从不成立，除了 w_t 或 ℓ 的极特殊情形。因此一般而言，$\{\widetilde{p}_t^{\text{tilt}}\}$ 不是 PF-ODE 边缘，终端样本也不服从 $\widetilde{p}_0^{\text{tilt}}(\mathbf{x}_0|\mathbf{c})$。 ◇

从控制到借助直接偏好优化实现更好对齐。 强控制可能“符合条件但偏离偏好”：一个样本可能满足条件信号（如提示词），却偏离人类真正喜欢的样子。我们通过把条件目标按一个偏好评分倾斜来形式化这一点：

$$\widetilde{p}_0^{\text{tilt}}(\mathbf{x}_0|\mathbf{c}) \propto p_0(\mathbf{x}_0|\mathbf{c}) \exp\big(\beta r(\mathbf{x}_0, \mathbf{c})\big), \tag{8.8.1.393}$$

其中 $r(\mathbf{x}_0, \mathbf{c})$ 是干净样本 $\mathbf{x}_0$ 与条件 $\mathbf{c}$ 的标量对齐评分（奖励），r 越大对齐越好。实践中 r 可以是：(i) 外部奖励/分类器的 logit 或对数概率；(ii) 一个相似性度量（如 CLIP/感知相似性，Radford *et al.*, 2021）；(iii) 一个学习到的偏好模型。

实现这种可控性的现有方法通常收集人类对模型生成相对质量的标签，并微调条件扩散模型以对齐这些偏好，常借助基于人类反馈的强化学习（RLHF）。然而 RLHF 是一个复杂且常常不稳定的过程：它先拟合一个奖励模型来捕捉人类偏好，再用强化学习微调条件扩散模型以最大化该估计奖励，同时约束策略不偏离原始模型。

这自然引出问题：我们能否完全去掉奖励模型训练阶段？我们用 Diffusion-DPO（Wallace *et al.*, 2024）来回答，它是 Direct Preference Optimization（Rafailov *et al.*, 2023，原为大语言模型提出）的一个推广。如第 8.5 节所述，Diffusion-DPO 直接从成对选择中学习偏好倾斜，从而无需单独的奖励模型就能微调条件扩散模型以对齐偏好。

8.2 分类器引导

8.2.1 分类器引导的基础

设 $\mathbf{c}$ 为来自分布 $p(\mathbf{c})$ 的条件变量，例如类别标签、caption 或其他辅助信息。我们的目标是从 $p_0(\mathbf{x}|\mathbf{c})$ 采样。在基于扩散的条件生成中，我们通过运行其时间边缘为 $p_t(\cdot|\mathbf{c})$ 的反向时间动力学来实现。这些动力学的漂移依赖条件分数

$$\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t|\mathbf{c}), \qquad t \in [0, T]. \tag{8.8.2.394}$$

因此一个标准且有效的途径是估计这一量。

一个基于 Bayes 法则的基本洞察是：条件分数可分解为

$$\begin{aligned} \nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t|\mathbf{c}) &= \nabla_{\mathbf{x}_t} \log \Big(\frac{p_t(\mathbf{x}_t) p_t(\mathbf{c}|\mathbf{x}_t)}{p(\mathbf{c})} \Big) \\ &= \nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t) + \nabla_{\mathbf{x}_t} \log p_t(\mathbf{c}|\mathbf{x}_t) - \nabla_{\mathbf{x}_t} \log p(\mathbf{c}) \\ &= \underbrace{\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t)}_{\text{无条件分数}} + \underbrace{\nabla_{\mathbf{x}_t} \log p_t(\mathbf{c}|\mathbf{x}_t)}_{\text{分类器梯度}}, \end{aligned} \tag{8.8.2.395}$$

其中 $p_t(\mathbf{c}|\mathbf{x}_t)$ 表示在时刻 t 从含噪输入 $\mathbf{x}_t$ 预测条件 $\mathbf{c}$ 的概率。

这一分解启发了 Dhariwal 与 Nichol（2021）提出的分类器引导（CG）方法，它利用一个预训练的时间依赖分类器 $p_t(\mathbf{c}|\mathbf{x}_t)$ 来引导生成过程。具体地，我们定义一族带引导尺度 $\omega \geq 0$ 的引导密度（倾斜条件）：

$$p_t(\mathbf{x}_t|\mathbf{c}, \omega) \propto p_t(\mathbf{x}_t)\, p_t(\mathbf{c}|\mathbf{x}_t)^{\omega}, \tag{8.8.2.396}$$

给出分数函数

$$\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t|\mathbf{c}, \omega) = \nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t) + \omega \nabla_{\mathbf{x}_t} \log p_t(\mathbf{c}|\mathbf{x}_t). \tag{8.8.2.397}$$

几何上，这把无条件流朝增加类别似然的方向倾斜。当 $\omega = 1$，$p_t(\mathbf{x}_t|\mathbf{c}, \omega)$ 与真条件 $p_t(\mathbf{x}_t|\mathbf{c})$ 重合；当 $\omega \neq 1$，它是一个引导（tempered）重加权，而非字面条件。

标量 $\omega \geq 0$ 调节分类器的影响：

- $\omega = 1$：恢复真条件分数 $\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t|\mathbf{c})$；
- $\omega > 1$：放大分类器信号，通常提高条件保真度（常以多样性为代价）；
- $0 \leq \omega < 1$：降低分类器信号权重，通常提高样本多样性但弱化条件。

CG 中的实用近似。 实践中，CG 对扩散模型而言是一种免训练方法，用于引导一个预训练的无条件扩散模型 $\mathbf{s}_{\phi^\times}(\mathbf{x}_t, t) \approx \nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t)$。CG 只在采样时施加，不修改扩散模型本身。为使其可行，单独训练一个时间依赖分类器 $p_\psi(\mathbf{c}|\mathbf{x}_t, t)$，以从不同噪声级 t 的含噪输入 $\mathbf{x}_t$ 预测条件 $\mathbf{c}$。分类器以标准方式最小化交叉熵损失来训练：

$$\mathbb{E}_{t\sim\mathcal{U}[0,T],(\mathbf{x},\mathbf{c})\sim p_{\text{data}},\boldsymbol{\epsilon}\sim\mathcal{N}(\mathbf{0},\mathbf{I})}\big[-\log p_\psi(\mathbf{c}|\mathbf{x}_t, t)\big], \tag{8.8.2.398}$$

其中 $(\mathbf{x}, \mathbf{c}) \sim p_{\text{data}}$ 表示配对带标签数据，$\mathbf{x}_t = \alpha_t \mathbf{x} + \sigma_t \boldsymbol{\epsilon}$ 是时刻 t 的含噪输入。分类器必须显式以 t 为条件（如通过时间嵌入），因为它需要在所有噪声级上可靠工作。

训练后，分类器提供的分数充当真实似然梯度的代理：

$$\nabla_{\mathbf{x}_t} \log p_{\psi^\times}(\mathbf{c}|\mathbf{x}_t, t) \approx \nabla_{\mathbf{x}_t} \log p_t(\mathbf{c}|\mathbf{x}_t). \tag{8.8.2.399}$$

8.2.2 用 CG 推理

推理时，分类器梯度 $\nabla_{\mathbf{x}_t} \log p_{\psi^\times}(\mathbf{c}|\mathbf{x}_t, t)$ 被加到无条件分数上，并以引导权重 ω 缩放，得到式 (8.8.2.397) 中引导分数 $\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t|\mathbf{c}, \omega)$ 的近似：

$$\begin{aligned}\mathbf{s}^{\text{CG}}(\mathbf{x}_t, t, \mathbf{c}; \omega) &:= \underbrace{\mathbf{s}_{\phi^\times}(\mathbf{x}_t, t)}_{\text{无条件方向}} + \omega \underbrace{\nabla_{\mathbf{x}_t} \log p_{\psi^\times}(\mathbf{c}|\mathbf{x}_t, t)}_{\text{引导方向}} \\ &\approx \nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t|\mathbf{c}, \omega).\end{aligned} \tag{8.8.2.400}$$

于是，只需把反向时间 SDE 或 PF-ODE 中的无条件分数 $\mathbf{s}_{\phi^\times}(\mathbf{x}_t, t)$ 替换为指定 ω 下的引导分数 $\mathbf{s}^{\text{CG}}(\mathbf{x}_t, t, \mathbf{c}; \omega)$（如式 (8.8.1.379)），即可引导生成轨迹朝向与条件 $\mathbf{c}$ 对齐的样本。

8.2.3 优点与局限

CG 为条件生成提供了简单灵活的机制，允许通过 ω 显式控制条件强度。它可与任何预训练的无条件扩散模型配合，只需额外一个分类器。

然而该方法有显著局限：

- **训练代价：** 分类器必须在所有噪声级上工作，计算代价高。
- **鲁棒性：** 分类器必须对严重损坏的输入 $\mathbf{x}_t$（尤其大 t）良好泛化，这颇具挑战。
- **单独训练：** 由于分类器独立于扩散模型训练，它可能与学到的数据分布不完全对齐。

8.3 无分类器引导

8.3.1 无分类器引导的基础

无分类器引导（CFG，Ho 与 Salimans, 2021）是对基于分类器引导的简化，它消除了对单独分类器的需求。其关键想法是以一种无需显式分类器即可有效条件化的方式修改分数函数的梯度。具体地，条件分布的对数概率梯度调整为：

$$\nabla_{\mathbf{x}_t} \log p_t(\mathbf{c}|\mathbf{x}_t) = \nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t|\mathbf{c}) - \nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t). \tag{8.8.3.401}$$

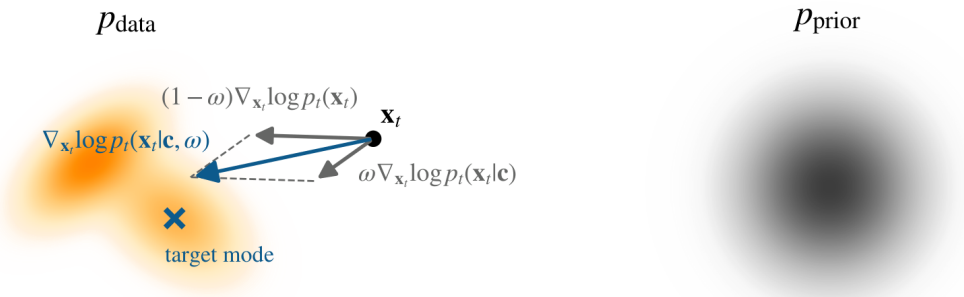


Figure 8.2: Illustration of CFG. The adjusted score $\nabla_{\mathbf{x}_t}\log p_t(\mathbf{x}_t|\mathbf{c},\omega)$ is obtained as a linear interpolation between the unconditional score $\nabla_{\mathbf{x}_t}\log p_t(\mathbf{x}_t)$ and the conditional score $\nabla_{\mathbf{x}_t}\log p_t(\mathbf{x}_t|\mathbf{c})$, weighted by ω. The resulting direction steers samples from the prior toward modes of the data distribution consistent with the target condition.

图 8.38: CFG 示意。调整后分数 $\nabla_{\mathbf{x}_t}\log p_t(\mathbf{x}_t|\mathbf{c},\omega)$ 由无条件分数 $\nabla_{\mathbf{x}_t}\log p_t(\mathbf{x}_t)$ 与条件分数 $\nabla_{\mathbf{x}_t}\log p_t(\mathbf{x}_t|\mathbf{c})$ 以 ω 加权做线性插值得到。所得方向把样本从先验朝向与目标条件一致的数据分布模态引导。

把此表达式代入式 (8.8.2.397)，得到条件分数的下列形式：

$$\begin{aligned}\nabla_{\mathbf{x}_t}\log p_t(\mathbf{x}_t|\mathbf{c},\omega) &= \nabla_{\mathbf{x}_t}\log p_t(\mathbf{x}_t) + \omega\big(\nabla_{\mathbf{x}_t}\log p_t(\mathbf{x}_t|\mathbf{c}) - \nabla_{\mathbf{x}_t}\log p_t(\mathbf{x}_t)\big)\\ &= \omega\underbrace{\nabla_{\mathbf{x}_t}\log p_t(\mathbf{x}_t|\mathbf{c})}_{\text{条件分数}} + (1-\omega)\underbrace{\nabla_{\mathbf{x}_t}\log p_t(\mathbf{x}_t)}_{\text{无条件分数}}.\end{aligned} \tag{8.8.3.402}$$

超参数 ω 同样在控制条件信息影响中起关键作用（取 $\omega \geq 0$）：

- $\omega = 0$：模型表现为无条件扩散模型，完全忽略条件；
- $\omega = 1$：模型使用条件分数，无附加引导；
- $\omega > 1$：模型更强调条件分数、更弱调整条件分数，加强与 $\mathbf{c}$ 的对齐，但通常降低多样性。

8.3.2 CFG 的训练与采样

经 CFG 联合训练无条件与条件扩散模型。 与 CG 不同，CFG 需要重新训练一个显式考虑条件变量 $\mathbf{c}$ 的扩散模型。然而分别训练条件与无条件两个分数模型在计算上常常不可行。为此，CFG 采用单个模型 $\mathbf{s}_\phi(\mathbf{x}_t, t, \mathbf{c})$，通过把 $\mathbf{c}$ 作为附加输入来在单个模型内同时学习两个分数函数。训练过程定义如下：

- 无条件训练：传入空 token $\emptyset$ 替代条件输入，得到 $\mathbf{s}_\phi(\mathbf{x}_t, t, \emptyset)$；
- 条件训练：传入真实条件变量 $\mathbf{c}$ 作为输入，得到 $\mathbf{s}_\phi(\mathbf{x}_t, t, \mathbf{c})$。

这两种训练机制通过以概率 p_{uncond}（用户自定义超参，通常取 0.1）用空输入 $\emptyset$ 随机替换 $\mathbf{c}$ 来统一。这一联合训练策略使模型能同时学习条件与无条件分数函数。完整训练算法见算法 4，并与标准无条件训练（算法 3）对比。我们指出，训练时并不使用 CFG 权重 ω。

Algorithm 3 无条件扩散模型训练（标准）

repeat
  采样 $\mathbf{x} \sim p_{\text{data}}(\mathbf{x})$
  采样 $t \sim \mathcal{U}[0, T]$
  采样 $\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$
  构造 $\mathbf{x}_t = \alpha_t \mathbf{x} + \sigma_t \boldsymbol{\epsilon}$
  在 $\nabla_\phi \|\mathbf{s}_\phi(\mathbf{x}_t, t) - \mathbf{s}\|^2$ 上做梯度步
until 收敛

Algorithm 4 CFG：条件扩散模型训练

Require: p_{uncond}：无条件 dropout 概率

repeat
  采样 $(\mathbf{x}, \mathbf{c}) \sim p_{\text{data}}(\mathbf{x}, \mathbf{c})$
  以概率 p_{uncond} 令 $\mathbf{c} \leftarrow \emptyset$
  采样 $t \sim \mathcal{U}[0, T]$
  采样 $\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$
  构造 $\mathbf{x}_t = \alpha_t \mathbf{x} + \sigma_t \boldsymbol{\epsilon}$
  在 $\nabla_\phi \|\mathbf{s}_\phi(\mathbf{x}_t, t, \mathbf{c}) - \mathbf{s}\|^2$ 上做梯度步
until 收敛

用 CFG 条件采样。 一旦用算法 4 训练好模型 $\mathbf{s}_{\phi^\times}(\mathbf{x}_t, t, \mathbf{c})$，即可在采样时施加 CFG。对数概率的梯度由下式给出：

$$\begin{aligned}\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t|\mathbf{c}, \omega) &= \omega \nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t|\mathbf{c}) + (1-\omega) \nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t) \\ &\approx \omega \underbrace{\mathbf{s}_{\phi^\times}(\mathbf{x}_t, t, \mathbf{c})}_{\text{条件分数}} + (1-\omega) \underbrace{\mathbf{s}_{\phi^\times}(\mathbf{x}_t, t, \emptyset)}_{\text{无条件分数}} \\ &=: \mathbf{s}^{\text{CFG}}_{\phi^\times}(\mathbf{x}_t, t, \mathbf{c}; \omega).\end{aligned} \tag{8.8.3.403}$$

采样时施加固定（或可选地随时间变化）的无分类器引导权重 ω。反向时间 SDE（第 4.1.6 节式）或 PF-ODE（第 4.1.8 节式）中的无条件分数 $\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t)$，随后被引导分数 $\mathbf{s}^{\text{CFG}}_{\phi^\times}(\mathbf{x}_t, t, \mathbf{c}; \omega)$ 替换（如式 (8.8.1.379)），它以加权方式组合条件与无条件分数。

这一表述通过调整 ω 实现可控生成，使样本被引导朝向条件信号 $\mathbf{c}$，同时保留多样性。因此 CFG 提供了一种有效且计算高效的精确条件生成途径，因为它只需训练单个扩散模型。

8.4 （可选）免训练引导

本节介绍一系列免训练引导方法背后的高层哲学（Chung *et al.*, 2023；Ye *et al.*, 2024；He *et al.*, 2024；Bansal *et al.*, 2023）。尽管实现与应用各异，这些方法都由式 (8.8.1.378) 表达的中心原理统一。我们先在第 8.4.1 节介绍免训练引导的高层方法，再把这一思想推广到免训练逆问题求解，第 8.4.2 节给出简要综述。

设定与记号。 设 $\mathbf{c}$ 为条件变量。假设我们能访问一个以分数预测形式表达的预训练扩散模型 $\mathbf{s}_{\phi^\times}(\mathbf{x}_t, t)$。此外，设给定一个非负函数

$$\ell(\cdot, \mathbf{c}) : \mathbb{R}^D \to \mathbb{R}_{\geq 0}, \tag{8.8.4.404}$$

它量化样本 $\mathbf{x} \in \mathbb{R}^D$ 与条件 $\mathbf{c}$ 的对齐程度，$\ell(\mathbf{x}, \mathbf{c})$ 越小表示对齐越强。此类函数的具体例子包括：(i) $\mathbf{c}$ 是参考图像，$\ell(\cdot, \mathbf{c})$ 是度量感知接近度的相似性分数；(ii) $\ell(\cdot, \mathbf{c})$ 是经预训练模型（如 CLIP，Radford *et al.*, 2021）计算的基于特征的相似性分数。

考虑标准线性–Gaussian 前向加噪核 $p_t(\cdot|\mathbf{x}_0) := \mathcal{N}(\cdot; \alpha_t \mathbf{x}_0, \sigma_t^2 \mathbf{I})$。回忆第 9.2.3 节的 DDIM 更新，取作示例：

$$\mathbf{x}_{t\to t-1} = \alpha_{t-1} \underbrace{\widehat{\mathbf{x}}_0(\mathbf{x}_t)}_{\text{数据空间}} - \sigma_{t-1}\sigma_t \underbrace{\widehat{\mathbf{s}}(\mathbf{x}_t)}_{\text{噪声空间}}, \tag{8.8.4.405}$$

其中 $\widehat{\mathbf{x}}_0(\mathbf{x}_t) := \mathbf{x}_{\phi^\times}(\mathbf{x}_t, t)$ 是（干净）$\mathbf{x}$-预测，$\widehat{\mathbf{s}}(\mathbf{x}_t) := \mathbf{s}_{\phi^\times}(\mathbf{x}_t, t)$ 是时刻 t 由 $\mathbf{x}_t$ 得到的分数预测。

8.4.1 免训练引导的概念框架

大多数免训练引导方法（Ye *et al.*, 2024）在数据空间或噪声空间引入校正，以把式 (8.8.4.405) 中的 DDIM 更新朝满足条件 $\mathbf{c}$ 的方向引导：

$$\mathbf{x}_{t\to t-1} = \alpha_{t-1}\Big(\underbrace{\widehat{\mathbf{x}}_0(\mathbf{x}_t) + \eta_t^{\text{data}}\mathcal{G}_0}_{\text{A. 数据空间}}\Big) - \sigma_{t-1}\sigma_t\Big(\underbrace{\widehat{\mathbf{s}}(\mathbf{x}_t) + \eta_t^{\text{latent}}\mathcal{G}_t}_{\text{B. 噪声空间}}\Big), \tag{8.8.4.406}$$

其中 $\eta_t^{\text{data}}, \eta_t^{\text{latent}} \geq 0$ 是随时间变化的引导强度，$\mathcal{G}_0, \mathcal{G}_t$ 是下文定义的校正项。

A. 数据空间中的引导。 沿负梯度方向下降

$$\mathcal{G}_0 := -\nabla_{\mathbf{x}_0}\ell(\mathbf{x}_0, \mathbf{c}), \tag{8.8.4.407}$$

则数据空间中修正后的干净估计

$$\widehat{\mathbf{x}}_0(\mathbf{x}_t) + \eta_t^{\text{data}}\mathcal{G}_0, \tag{8.8.4.408}$$

可被逐渐引导向更好满足条件 $\mathbf{c}$ 的样本。这一梯度下降格式可迭代施加以逐步改善对齐。代表性例子包括 MGPD（He *et al.*, 2023）与 UGD（Bansal *et al.*, 2023）。

B. 噪声空间中的引导。 如第 8.1 节所讨论，条件分数 $\nabla_{\mathbf{x}_t}\log p_t(\mathbf{c}|\mathbf{x}_t)$ 一般难以处理。一个实用近似是引入代理似然 $\widetilde{p}_t(\mathbf{c}|\mathbf{x}_t)$：

$$\widetilde{p}_t(\mathbf{c}|\mathbf{x}_t) \propto \exp\big(-\eta\,\ell(\widehat{\mathbf{x}}_0(\mathbf{x}_t),\mathbf{c})\big) \tag{8.8.4.409}$$

带重缩放常数 $\eta>0$，使

$$\nabla_{\mathbf{x}_t}\log\widetilde{p}_t(\mathbf{c}|\mathbf{x}_t) = -\eta\nabla_{\mathbf{x}_t}\ell(\widehat{\mathbf{x}}_0(\mathbf{x}_t),\mathbf{c}) =: \mathcal{G}_t, \tag{8.8.4.410}$$

其中 $\widehat{\mathbf{x}}_0(\mathbf{x}_t)$ 由扩散模型的预测得到。把它代入条件分数的 Bayes 法则，得到代理：

$$\nabla_{\mathbf{x}_t}\log p_t(\mathbf{x}_t|\mathbf{c}) \approx \underbrace{\nabla_{\mathbf{x}_t}\log p_t(\mathbf{x}_t)}_{\text{无条件}} + \underbrace{\nabla_{\mathbf{x}_t}\log\widetilde{p}_t(\mathbf{c}|\mathbf{x}_t)}_{\text{引导}} \approx \widehat{\mathbf{s}}(\mathbf{x}_t) + \eta_t^{\text{latent}}\mathcal{G}_t, \tag{8.8.4.411}$$

充当噪声空间中引导的校正项。

然而我们注意到，计算 $\mathcal{G}_t$ 需要穿过 $\mathbf{x}$-预测做反向传播，即

$$\nabla_{\mathbf{x}_t}\widehat{\mathbf{x}}_0(\mathbf{x}_t)^\top\cdot\nabla_{\mathbf{x}_0}\log\ell_{\mathbf{c}}(\mathbf{x}_0)\big|_{\mathbf{x}_0=\widehat{\mathbf{x}}_0(\mathbf{x}_t)}, \tag{8.8.4.412}$$

这在实践中可能带来可观的计算开销。代表性例子包括（Yu *et al.*, 2023；Chung *et al.*, 2022；Bansal *et al.*, 2023）。

8.4.2 免训练逆问题求解方法示例

第 8.4.1 节引入的原理在逆问题中有重要应用。我们先综述背景，再给出几个具体例子，说明如何利用预训练扩散模型做推理时逆问题求解。

逆问题背景。 设 $\mathcal{A}$ 为一个损坏算子（可线性或非线性、已知或未知），如模糊核或 inpainting 掩膜；$\mathbf{y}$ 为由下列损坏模型生成的观测：

$$\mathbf{y} = \mathcal{A}(\mathbf{x}_0) + \sigma_{\mathbf{y}}\mathbf{z}, \qquad \mathbf{z}\sim\mathcal{N}(\mathbf{0},\mathbf{I}). \tag{8.8.4.413}$$

逆问题的目标是从后验分布 $p_0(\mathbf{x}_0|\mathbf{y})$ 采样，其中对应给定观测 $\mathbf{y}$ 可能存在无穷多可能的重建 $\mathbf{x}_0$。目标是恢复一个去除 $\mathbf{y}$ 中损坏、同时保留其忠实与语义特征的 $\mathbf{x}_0$。

传统求解逆问题的方法通常遵循监督框架，需要收集损坏与修复样本的配对数据 $(\mathbf{y},\mathbf{x})$，并依赖优化方法或神经网络的监督训练。这类方法在数据准备上代价高昂，且可能缺乏对未见数据的泛化。

预训练扩散模型作为逆问题求解器。 如前所述，条件分数可经 Bayes 法则分解：

$$\nabla_{\mathbf{x}_t}\log p_t(\mathbf{x}_t|\mathbf{y}) = \underbrace{\nabla_{\mathbf{x}_t}\log p_t(\mathbf{x}_t)}_{\text{数据分数}} + \underbrace{\nabla_{\mathbf{x}_t}\log p_t(\mathbf{y}|\mathbf{x}_t)}_{\text{测量对齐}}. \tag{8.8.4.414}$$

这一分解把数据分数与一个特定于逆问题、带 $\mathbf{y}$ 的测量对齐项分开。它使我们能以无监督方式求解式 (8.8.4.413)：建模干净数据分布 p_{data}，并在反演时施加它。更具体地：

- **数据分数** $\nabla_{\mathbf{x}_t}\log p_t(\mathbf{x}_t)$：用在干净数据上训练的预训练扩散模型 $\mathbf{s}_{\phi^\times}(\mathbf{x}_t,t)$ 近似；
- **测量对齐** $\nabla_{\mathbf{x}_t}\log p_t(\mathbf{y}|\mathbf{x}_t)$：闭式不可解，因为它需要对隐变量边缘化。

因此，大多数使用预训练扩散模型的免训练方法聚焦于近似 $\nabla_{\mathbf{x}_t}\log p_t(\mathbf{y}|\mathbf{x}_t)$。我们采用一个常见的元形式（Daras *et al.*, 2024）：

$$\nabla_{\mathbf{x}_t}\log p_t(\mathbf{y}|\mathbf{x}_t)\approx -\frac{\mathcal{P}_t\,\mathcal{M}_t}{\gamma_t}. \tag{8.8.4.415}$$

其中：

- $\mathcal{M}_t$：误差向量，量化观测 $\mathbf{y}$ 与估计信号之间的失配；
- $\mathcal{P}_t$：把 $\mathcal{M}_t$ 投影回 $\mathbf{x}_t$ 所在 ambient 空间的映射；
- γ_t：控制引导强度的标量。

代表性方法以不同方式实例化 $\mathcal{M}_t,\mathcal{P}_t,\gamma_t$，如下以颜色编码组件所示。

基于扩散的逆问题求解器实例。 我们给出代表性方法，它们利用预训练扩散模型提供无监督途径（无需配对数据），可用同一学到的 p_{data} 代理灵活应用于各种逆问题。

Score SDE（Song *et al.*, 2020c）。最早基于扩散的逆问题求解器之一。它考虑已知线性损坏模型 $\mathbf{A}$，并聚焦无噪设定 $\sigma_{\mathbf{y}}=0$。由于 $\mathbf{A}$ 线性，可构造一个噪声级匹配的观测

$$\mathbf{y}_t := \alpha_t\mathbf{y}+\sigma_t\boldsymbol{\epsilon}, \tag{8.8.4.416}$$

并用残差 $\mathbf{y}_t-\mathbf{A}\mathbf{x}_t$（注意一般 $\mathbf{y}_t\neq\mathbf{A}\mathbf{x}_t$）驱动似然式校正。一个常见近似（略去乘性常数）为

$$\nabla_{\mathbf{x}_t}\log p_t(\mathbf{y}|\mathbf{x}_t)\approx -\mathbf{A}^\top(\mathbf{y}_t-\mathbf{A}\mathbf{x}_t). \tag{8.8.4.417}$$

迭代隐变量精化（ILVR，Choi *et al.*, 2021）。用与 ScoreSDE 相同的设定，ILVR 估计

$$\nabla_{\mathbf{x}_t}\log p_t(\mathbf{y}|\mathbf{x}_t)\approx -\mathbf{A}^\dagger(\mathbf{y}_t-\mathbf{A}\mathbf{x}_t)=-(\mathbf{A}^\top\mathbf{A})^{-1}\mathbf{A}^\top(\mathbf{y}_t-\mathbf{A}\mathbf{x}_t), \tag{8.8.4.418}$$

其中 $\mathbf{A}^\dagger$ 是 Moore–Penrose 伪逆，$\mathbf{y}_t=\alpha_t\mathbf{y}+\sigma_t\boldsymbol{\epsilon}_t$。

扩散后验采样（DPS，Chung *et al.*, 2022）。对已知非线性前向算子 $\mathcal{A}$ 与加性 Gaussian 噪声级 $\sigma_{\mathbf{y}}\geq 0$ 的逆问题，一种广泛使用的方法是去噪后验分数（DPS），它近似

$$\nabla_{\mathbf{x}_t}\log p_t(\mathbf{y}|\mathbf{x}_t)\approx\nabla_{\mathbf{x}_t}\log p_t(\mathbf{y}|X_0=\widehat{\mathbf{x}}_0(\mathbf{x}_t)), \tag{8.8.4.419}$$

其中 $\widehat{\mathbf{x}}_0(\mathbf{x}_t):=\mathbb{E}[\mathbf{x}_0|\mathbf{x}_t]$ 表示给定时刻 t 含噪观测 $\mathbf{x}_t$ 时干净样本的条件均值，通常用 Tweedie 公式（第 3.3.6 节式）从预训练扩散模型估计。

这一点近似假设条件分布 $p(\mathbf{x}_0|\mathbf{x}_t)$ 尖锐集中，并由下式得来：

$$\begin{aligned} p_t(\mathbf{y}|\mathbf{x}_t) &= \int p_t(\mathbf{y}|\mathbf{x}_0,\mathbf{x}_t)p(\mathbf{x}_0|\mathbf{x}_t)\,\mathrm{d}\mathbf{x}_0 \\ &= \int p_t(\mathbf{y}|\mathbf{x}_0)p(\mathbf{x}_0|\mathbf{x}_t)\,\mathrm{d}\mathbf{x}_0 \approx p_t(\mathbf{y}|X_0=\widehat{\mathbf{x}}_0(\mathbf{x}_t)), \end{aligned} \tag{8.8.4.420}$$

其中我们用到：给定 $\mathbf{x}_0$ 时 $\mathbf{y}$ 只依赖 $\mathbf{x}_0$（不依赖 $\mathbf{x}_t$），且该近似在 $p(\mathbf{x}_0|\mathbf{x}_t)$ 紧围绕其均值尖锐峰值的假设下成立。

由于

$$p_t(\mathbf{y}|X_0 = \widehat{\mathbf{x}}_0(\mathbf{x}_t)) = \mathcal{N}\big(\mathbf{y}; \mathcal{A}(\widehat{\mathbf{x}}_0(\mathbf{x}_t)), \sigma_{\mathbf{y}}^2\mathbf{I}\big), \tag{8.8.4.421}$$

我们计算

$$\begin{aligned}\nabla_{\mathbf{x}_t} \log p_t(\mathbf{y}|\mathbf{x}_t) &\approx \nabla_{\mathbf{x}_t} \log \mathcal{N}\big(\mathbf{y}; \mathcal{A}(\widehat{\mathbf{x}}_0), \sigma_{\mathbf{y}}^2\mathbf{I}\big) \\ &= -\frac{1}{2\sigma_{\mathbf{y}}^2}\nabla_{\mathbf{x}_t}\|\mathbf{y} - \mathcal{A}(\widehat{\mathbf{x}}_0)\|^2 \\ &= \frac{1}{\sigma_{\mathbf{y}}^2}\big[\mathcal{J}_{\mathcal{A}}(\widehat{\mathbf{x}}_0(\mathbf{x}_t)) \cdot \nabla_{\mathbf{x}_t}\widehat{\mathbf{x}}_0(\mathbf{x}_t)\big]^\top\big(\mathbf{y} - \mathcal{A}(\widehat{\mathbf{x}}_0(\mathbf{x}_t))\big),\end{aligned} \tag{8.8.4.422}$$

其中 $\mathcal{J}_{\mathcal{A}}(\widehat{\mathbf{x}}_0(\mathbf{x}_t)) := \nabla_{\mathbf{x}_0}\mathcal{A}(\mathbf{x})|_{\mathbf{x}=\widehat{\mathbf{x}}_0(\mathbf{x}_t)}$ 表示前向算子关于其输入的 Jacobian。该公式把梯度穿过分数近似流水线传播，反映测量似然如何随含噪样本 $\mathbf{x}_t$ 的扰动而变化。

对线性逆问题，这进一步简化为

$$\nabla_{\mathbf{x}_t} \log p_t(\mathbf{y}|\mathbf{x}_t) \approx \frac{1}{\sigma_{\mathbf{y}}^2}\big[\mathbf{A} \cdot \nabla_{\mathbf{x}_t}\widehat{\mathbf{x}}_0(\mathbf{x}_t)\big]^\top\big(\mathbf{y} - \mathbf{A}(\widehat{\mathbf{x}}_0(\mathbf{x}_t))\big). \tag{8.8.4.423}$$

大量工作通过为 $\nabla_{\mathbf{x}_t} \log p_t(\mathbf{y}|\mathbf{x}_t)$ 提出各种近似来探索基于扩散的逆问题求解器。全面综述见 Daras *et al.*（2024）。

8.5 从强化学习到面向模型对齐的直接偏好优化

在使生成模型与人类意图对齐的追求中，主流范式是基于人类反馈的强化学习（RLHF）。RLHF 虽有效，却是一个复杂的多阶段过程、可能不稳定。本节介绍 Direct Preference Optimization（DPO，Rafailov *et al.*, 2023），一个更精简、更稳定的方法，无需显式奖励建模或强化学习即达到同一目标。随后我们通过 Diffusion-DPO（Wallace *et al.*, 2024）勾勒其向扩散模型的推广。

8.5.1 动机：绕开 RLHF 的陷阱

对齐的目标是引导一个基础预训练模型（如 SFT 模型）朝向人类偏好的输出。RLHF 分三阶段进行。第一，监督微调（SFT）在 prompt–response 对上训练基础模型。第二，奖励建模（RM）在偏好数据上拟合一个模型，偏好数据由提示 $\mathbf{c}$ 与成对响应（一个偏好的“胜者”$\mathbf{x}_w$ 与一个不偏好的“输家”$\mathbf{x}_l$）构成，学习一个标量 $r(\mathbf{c}, \mathbf{x})$，使 $r(\mathbf{c}, \mathbf{x}_w) > r(\mathbf{c}, \mathbf{x}_l)$。第三，*RL* 微调用 PPO 等算法（Schulman *et al.*, 2017）优化 SFT 模型（策略 π^5），在以一个 KL 惩罚把 π 约束在参考/SFT 分布附近的同时，最大化来自 r 的期望奖励。

尽管影响巨大，该流水线有缺陷：RL 阶段不稳定且计算昂贵，因为它是 on-policy 的——每次更新都需要从当前模型新鲜采样；它还需要训练与托管多个大模型（SFT、奖励，有时还有价值模型）；它只优化人类偏好的一个代理，因此奖励模型中的缺陷可被利用。这引出一个中心问题：

问题 8.5.1： 我们能否消除显式奖励建模与不稳定的 RL 步骤，直接在偏好数据上优化模型？

Direct Preference Optimization（DPO）通过用单个监督风格步骤取代多阶段 RLHF 流水线来精简对齐。它不训练单独的奖励模型、不跑 PPO 等不稳定 RL 算法，而是用一个简单 logistic 损失直接把策略拟合到偏好对上，同时贴近一个固定参考模型。关键洞察是：KL 正则化的 RLHF 目标可被重写，使策略与参考之间的对数似然比充当隐式奖励。这保留了朝参考策略的正则化，但避免了昂贵的 rollout 与显式奖励建模。

在第 8.5.2 节我们简要回顾 RLHF 流水线及其对大型奖励模型与 RL 微调的依赖；第 8.5.3 节介绍 DPO（原为语言模型提出），它绕开奖励模型训练、简化对齐微调；最后在第 8.5.4 节把这一思想推广到扩散模型，引入 Diffusion-DPO 作为生成建模场景中实用稳定的对齐方法。

8.5.2 RLHF：Bradley–Terry 视角

RLHF 简介。 RLHF 始于一个学到的评判者：一个奖励模型 r_ψ，它为同一提示 $\mathbf{c}$ 下的候选响应赋一个标量偏好分数。数据集 $\mathcal{D}$ 由对 $(\widetilde{\mathbf{x}}, \mathbf{x})$ 构成，带标签 y 表示 $\widetilde{\mathbf{x}}$ 是否比 $\mathbf{x}$ 更受偏好。标签可以是二元 $y \in \{0, 1\}$，或由聚合多个评分者得到的软值 $y \in [0, 1]$。训练目标是一个简单 logistic 损失

$$\begin{aligned}\mathcal{L}_{\mathrm{RM}}(\psi) = -\mathbb{E}_{(\mathbf{c},\widetilde{\mathbf{x}},\mathbf{x},y)\sim\mathcal{D}}\Big[&y \log \sigma\big(r_\psi(\mathbf{c}, \widetilde{\mathbf{x}}) - r_\psi(\mathbf{c}, \mathbf{x})\big) \\ &+ (1-y) \log\big(1 - \sigma\big(r_\psi(\mathbf{c}, \widetilde{\mathbf{x}}) - r_\psi(\mathbf{c}, \mathbf{x})\big)\big)\Big],\end{aligned} \tag{8.8.5.424}$$

其中 $\sigma(u) = 1/(1 + e^{-u})$。实践中 $\mathcal{D}$ 中的偏好对可来自多种来源：精选响应、不同 checkpoint 的模型快照，或从预训练条件扩散模型生成。标准约定是以有序格式（胜者、输家）存储。在此约定下我们取 $y = 1$，式 (8.8.5.424) 退化为特例（取 $\widetilde{\mathbf{x}} = \mathbf{x}^w$、$\mathbf{x} = \mathbf{x}^l$）：

$$\mathcal{L}_{\mathrm{RM}}(\psi) = -\mathbb{E}_{(\mathbf{c},\mathbf{x}_w,\mathbf{x}_l)\sim\mathcal{D}}\Big[\log \sigma\big(r_\psi(\mathbf{c}, \mathbf{x}_w) - r_\psi(\mathbf{c}, \mathbf{x}_l)\big)\Big]. \tag{8.8.5.425}$$

Bradley–Terry 视角与 KL 联系。 标准做法是把

$$p_{r_\psi}(\widetilde{\mathbf{x}} \succ \mathbf{x} | \mathbf{c}) := \sigma\big(r_\psi(\mathbf{c}, \widetilde{\mathbf{x}}) - r_\psi(\mathbf{c}, \mathbf{x})\big) \tag{8.8.5.426}$$

通过 Bradley–Terry（BT）模型（Bradley 与 Terry, 1952）解释，它把两个标量分数转换为一个获胜概率。这一表述凸显两个关键性质：(i) 只有分数的差重要（故 $r_\psi(\mathbf{c}, \cdot$ 平移不变）；(ii) 损失把预测的胜者分数推到输家分数之上。

为直观看 (ii)，考虑一个带标签 $y \in \{0, 1\}$ 的对，定义

$$\Delta r := r_\psi(\mathbf{c}, \widetilde{\mathbf{x}}) - r_\psi(\mathbf{c}, \mathbf{x}), \qquad p := \sigma(\Delta r), \qquad \sigma(u) = \frac{1}{1 + e^{-u}}. \tag{8.8.5.427}$$

逐样本 logistic 损失为

$$\ell = -[y \log p + (1 - y) \log(1 - p)]. \tag{8.8.5.428}$$

则

$$\frac{\partial \ell}{\partial \Delta r} = \sigma(\Delta r) - y. \tag{8.8.5.429}$$

在步长 $\eta > 0$ 的梯度下降下，分数差更新为

$$\Delta r \leftarrow \Delta r - \eta\big(\sigma(\Delta r) - y\big). \tag{8.8.5.430}$$

因此，若 $y = 1$（“$\widetilde{\mathbf{x}}$ 胜”），则 $\sigma(\Delta r) - 1 \le 0$，故 Δr 增大（胜者上升、输家下降）；若 $y = 0$，Δr 减小。

式 (8.8.5.424) 中每个逐样本项可视为观测 Bernoulli 标签与模型预测获胜概率之间的交叉熵：

$$-[y \log p_{r_\psi} + (1-y)\log(1-p_{r_\psi})] = \mathcal{D}_{\mathrm{KL}}\big(\mathrm{Bern}(y)\|\mathrm{Bern}(p_{r_\psi})\big) + \mathcal{H}\big(\mathrm{Bern}(y)\big), \tag{8.8.5.431}$$

其中 $\mathcal{H}$ 是目标 Bernoulli 分布的熵。在数据集 $\mathcal{D}$ 上平均给出

$$\mathcal{L}_{\mathrm{RM}}(\psi) = \mathbb{E}_{\mathcal{D}}\Big[\mathcal{D}_{\mathrm{KL}}\big(\mathrm{Bern}(y)\|\mathrm{Bern}(p_{r_\psi})\big)\Big] + \underbrace{\mathbb{E}_{\mathcal{D}}\big[\mathcal{H}(\mathrm{Bern}(y))\big]}_{\text{与}\psi\text{ 无关}}. \tag{8.8.5.432}$$

因此，最小化 logistic 损失等价于最小化人类标签经验 Bernoulli 分布与模型预测 Bernoulli 分布之间的 KL 散度。二元情形（$y \in \{0,1\}$）下这一等价是精确的；软标签（$y \in [0,1]$）下它差一个熵常数偏移。直观上，奖励模型被训练去调整其获胜概率，直到它们与数据集里观测到的人类获胜率对齐。

此后我们采用最常见的约定：$\mathcal{D}$ 以有序格式存储对：$(\mathbf{x}^w, \mathbf{x}^l, \mathbf{c}) \sim \mathcal{D}$。此约定下标签恒为 $y = 1$，损失简化为式 (8.8.5.425) 的有序形式，下文即使用它。

KL 正则化的策略优化（固定奖励）。 用式 (8.8.5.425) 训练出拟合奖励 $r := r_{\phi^\times}$ 后，RLHF 接着调整一个可学习策略 $\pi_\theta(\mathbf{x}|\mathbf{c})$（通常在 $p_{\phi^\times}(\mathbf{x}|\mathbf{c})$ 之上微调），朝向更高奖励响应。同时，策略被正则化以贴近参考模型，参考模型取预训练扩散模型 $\pi_{\mathrm{ref}}(\mathbf{x}|\mathbf{c}) := p_{\phi^\times}(\mathbf{x}|\mathbf{c})$，用一个 $\mathcal{D}_{\mathrm{KL}}$ 惩罚：

$$\max_\theta \ \mathbb{E}_{\mathbf{c}\sim p(\mathbf{c})}\Big[\mathbb{E}_{\mathbf{x}\sim\pi_\theta(\cdot|\mathbf{c})}\big[r_\psi(\mathbf{c},\mathbf{x})\big] - \beta\mathcal{D}_{\mathrm{KL}}\big(\pi_\theta(\cdot|\mathbf{c})\|\pi_{\mathrm{ref}}(\cdot|\mathbf{c})\big)\Big], \tag{8.8.5.433}$$

它使两股力量显式化：寻找评判者偏好的样本，但贴近预训练参考。

我们指出，式 (8.8.5.425) 的奖励目标只使用带标签对，不要求 $\mathcal{D}$ 由参考模型（即预训练条件扩散模型）生成。虽非必需，从接近目标策略的模型收集对可减少分布漂移，并使学到的奖励在其将被使用的区域更可靠。

总之，RLHF 分两阶段进行：先最小化式 (8.8.5.425) 的损失（等价地，式 (8.8.5.432) 中的期望二元 $\mathcal{D}_{\mathrm{KL}}$）拟合奖励 r^*；再求解式 (8.8.5.433) 优化策略 π^*。

8.5.3 DPO 框架

从 RLHF 架起的桥。 对每个提示 $\mathbf{c}$，式 (8.8.5.433) 中 KL 正则化策略目标在给定拟合奖励 $r := r_{\phi^\times}$ 时有一个简单的闭式解，表示为下列基于能量的形式（Peters *et al.*, 2010）：

$$\pi^*(\mathbf{x}|\mathbf{c}) = \frac{1}{Z(\mathbf{c})}\pi_{\mathrm{ref}}(\mathbf{x}|\mathbf{c})\exp\big(r(\mathbf{c},\mathbf{x})/\beta\big), \tag{8.8.5.434}$$

其中 $\pi_{\text{ref}}(\mathbf{x}|\mathbf{c}) := p_{\phi^\times}(\mathbf{x}|\mathbf{c})$，$Z(\mathbf{c})$ 是配分函数，保证 $\int \pi^*(\mathbf{x}|\mathbf{c})\,\mathrm{d}\mathbf{x} = 1$。

β 越小，$\exp(r/\beta)$ 越尖锐，π^* 集中于高奖励区域：奖励主导、策略离 π_{ref} 越远、多样性下降，训练可能变得不稳定或易受奖励攻击。β 越大，$\exp(r/\beta)$ 越平，π^* 越贴近 π_{ref}：KL 项主导、更新保守、多样性跟随参考，但奖励增益有限。

既然我们的目标是直接微调策略（不训练单独奖励模型），式 (8.8.5.434) 让我们能从任意策略定义一个隐式奖励。下面引入：

由反转式 (8.8.5.434) 定义隐式奖励。 式 (8.8.5.434) 提示一个直接反转：对任意策略 π（其支撑含于 π_{ref}），定义

$$r_\pi(\mathbf{c}, \mathbf{x}) = \beta \log \frac{\pi(\mathbf{x}|\mathbf{c})}{\pi_{\text{ref}}(\mathbf{x}|\mathbf{c})} + \beta \log Z(\mathbf{c}). \tag{8.8.5.435}$$

则式 (8.8.5.434) 以 π 替换 π^* 成立，即 π 将是奖励函数 r_π 下式 (8.8.5.433) 的最优者。在这一意义下，r_π 是一个隐式（策略诱导）奖励：它被确定到只差一个依赖提示的常数 $\beta \log Z(\mathbf{c})$，而该常数在任何成对比较（如 BT 模型）中都消失：

$$r_\pi(\mathbf{c}, \mathbf{x}_w) - r_\pi(\mathbf{c}, \mathbf{x}_l) = \beta\Big(\log \frac{\pi(\mathbf{x}_w|\mathbf{c})}{\pi_{\text{ref}}(\mathbf{x}_w|\mathbf{c})} - \log \frac{\pi(\mathbf{x}_l|\mathbf{c})}{\pi_{\text{ref}}(\mathbf{x}_l|\mathbf{c})} \Big). \tag{8.8.5.436}$$

正是这一抵消使常数在偏好学习中无关，并直接导向基于对数概率差的 DPO 损失。

DPO 的训练损失。 把隐式奖励式 (8.8.5.435) 代入同一提示下带标签对 $(\mathbf{x}_w, \mathbf{x}_l)$ 的 BT 模型（式 (8.8.5.425)）。常数 $\log Z(\mathbf{c})$ 在胜者与输家之间抵消，给出关于对数概率差的单个 logistic 损失目标：

$$\mathcal{L}_{\text{DPO}}(\theta; \pi_{\text{ref}}) = -\mathbb{E}_{(\mathbf{c}, \mathbf{x}_w, \mathbf{x}_l) \sim \mathcal{D}} \Big[\log \sigma \Big(\beta \Big(\log \frac{\pi_\theta(\mathbf{x}_w|\mathbf{c})}{\pi_{\text{ref}}(\mathbf{x}_w|\mathbf{c})} - \log \frac{\pi_\theta(\mathbf{x}_l|\mathbf{c})}{\pi_{\text{ref}}(\mathbf{x}_l|\mathbf{c})} \Big) \Big) \Big]. \tag{8.8.5.437}$$

换言之，DPO 抬高胜者相对输家的（温度缩放后）优势，该优势以相对参考的对数似然改进之差衡量：

$$-\log \sigma \Big(\beta \big[\tfrac{\pi_\theta}{\pi_{\text{ref}}} \text{ 的对数比之差，在 } \mathbf{x}_w \text{ 处相对 } \mathbf{x}_l \text{ 处} \big] \Big). \tag{8.8.5.438}$$

这在单个、稳定的最大似然风格阶段达到 RLHF 的目标，而无需训练显式奖励模型。

8.5.4 Diffusion-DPO

为何朴素 DPO 对扩散模型失效？ 在扩散模型中评估样本似然 $\pi_\theta(\mathbf{x}|\mathbf{c})$ 需要 ODE 求解的瞬时变量替换公式（漂移的散度，见第 4.2.7 节式），计算代价高。此外，穿过整条采样轨迹求导可能遭遇梯度消失或爆炸。为避免这些问题，Diffusion-DPO 在路径层面工作。我们以离散时间扩散模型（如 DDPM）为示例；连续时间扩散模型类似。

定义路径级隐式奖励。 设轨迹为反向时间 Markov 链（条件为 $\pi(\mathbf{x}_{t-1}|\mathbf{x}_t,\mathbf{c})$）下的 $\mathbf{x}_{0:T} := (\mathbf{x}_T,\dots,\mathbf{x}_0)$。这里 $\mathbf{x}_T$ 表示从先验（最高噪声）采样，$\mathbf{x}_0$ 是数据空间中的干净输出。由于扩散模型的生成沿一条完整去噪路径进行，把偏好从最终输出推广到整条轨迹是自然的。因此我们为每条轨迹赋一个奖励 $R(\mathbf{c},\mathbf{x}_{0:T})$；若它只依赖 $\mathbf{x}_0$ 就退化为端点奖励，但也可捕捉沿路径的累积效应。

我们用路径级 KL 替换式 (8.8.5.433) 中的样本级 KL：

$$\max_{\theta}\ \mathbb{E}_{\mathbf{c}\sim p(\mathbf{c})}\Big[\underbrace{\mathbb{E}_{\mathbf{x}_{0:T}\sim\pi_\theta(\cdot|\mathbf{c})}\big[R(\mathbf{c},\mathbf{x}_{0:T})\big]}_{\text{对路径奖励}} -\beta\mathcal{D}_{\mathrm{KL}}\big(\pi_\theta(\cdot|\mathbf{c})\|\pi_{\mathrm{ref}}(\cdot|\mathbf{c})\big)\Big], \tag{8.8.5.439}$$

其中 $\pi_\theta(\cdot|\mathbf{c})$ 与 $\pi_{\mathrm{ref}}(\cdot|\mathbf{c})$ 是路径分布。它旨在最大化反向过程 $\pi_\theta(\cdot|\mathbf{c})$ 的奖励，同时匹配原参考反向过程 $\pi_{\mathrm{ref}}(\cdot|\mathbf{c})$ 的分布。

对每个提示 $\mathbf{c}$，最优者具有简单的基于能量的形式

$$\pi^*(\mathbf{x}_{0:T}|\mathbf{c}) = \frac{1}{Z(\mathbf{c})}\pi_{\mathrm{ref}}(\mathbf{x}_{0:T}|\mathbf{c})\exp\big(R(\mathbf{c},\mathbf{x}_{0:T})/\beta\big), \tag{8.8.5.440}$$

$Z(\mathbf{c})$ 为归一化常数。反转式 (8.8.5.440) 启发对任意策略 π 定义隐式路径奖励：

$$R_\pi(\mathbf{c},\mathbf{x}_{0:T}) := \beta\log\frac{\pi(\mathbf{x}_{0:T}|\mathbf{c})}{\pi_{\mathrm{ref}}(\mathbf{x}_{0:T}|\mathbf{c})} + \beta\log Z(\mathbf{c}), \tag{8.8.5.441}$$

其常数 $\beta\log Z(\mathbf{c})$ 在成对比较中无关。

从路径级隐式奖励到 DPO。 对同一提示 $\mathbf{c}$ 下带标签对 $(\mathbf{x}_0^w,\mathbf{x}_0^l)$ 的路径施加 Bradley–Terry 模型，用标准 logistic 损失：

$$\begin{aligned}
\mathcal{L}_{\text{Diff-DPO}}(\theta;\pi_{\mathrm{ref}}) &:= -\mathbb{E}_{(\mathbf{c},\mathbf{x}_0^w,\mathbf{x}_0^l)\sim\mathcal{D}}\big[\log\sigma\big(\Delta R(\mathbf{c};\theta)\big)\big],\\
\Delta R(\mathbf{c};\theta) &:= \underbrace{\mathbb{E}_{\mathbf{x}_{1:T}^w\sim\pi_\theta(\cdot|\mathbf{x}_0^w,\mathbf{c})}\big[R_{\pi_\theta}(\mathbf{c},(\mathbf{x}_0^w,\mathbf{x}_{1:T}))\big]}_{\text{胜者路径期望}}\\
&\quad - \underbrace{\mathbb{E}_{\mathbf{x}_{1:T}^l\sim\pi_\theta(\cdot|\mathbf{x}_0^l,\mathbf{c})}\big[R_{\pi_\theta}(\mathbf{c},(\mathbf{x}_0^l,\mathbf{x}_{1:T}))\big]}_{\text{输家路径期望}}.
\end{aligned} \tag{8.8.5.442}$$

这里期望 $\mathbb{E}_{\mathbf{x}_{1:T}\sim\pi_\theta(\cdot|\mathbf{x}_0,\mathbf{c})}[\cdot]$ 的含义是：给定一个固定端点 $\mathbf{x}_0$（如数据集中胜者 $\mathbf{x}_0^w$），我们对潜在去噪轨迹 $\mathbf{x}_{1:T}$ 在模型诱导的条件路径分布（反向时间轨迹的后验）上取期望——在核 $\pi_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t,\mathbf{c})$ 下，这些轨迹可能产生 $\mathbf{x}_0$。由于这些中间状态未观测，我们对所有此类轨迹平均路径奖励。

然而式 (8.8.5.442) 因三个实用原因而不切实际：

1. **端点条件化诱导不可解的路径后验。** 项 $\mathbb{E}_{\pi_\theta(\mathbf{x}_{1:T}|\mathbf{x}_0,\mathbf{c})}[\cdot]$ 在反向路径上平均、约束其击中 $\mathbf{x}_0$，而采样器无此约束地运行 $\mathbf{x}_T\to\cdots\to\mathbf{x}_0$。对端点条件化产生一个扩散桥后验，一般既无闭式形式、采样代价又高。

2. **嵌套的、θ 耦合的期望。** 损失 $-\log\sigma(\Delta R(\mathbf{c};\theta))$ 中

$$\Delta R = \mathbb{E}_{\mathrm{paths}|\mathbf{x}_0^w,\mathbf{c}}[R_{\pi_\theta}] - \mathbb{E}_{\mathrm{paths}|\mathbf{x}_0^l,\mathbf{c}}[R_{\pi_\theta}] \tag{8.8.5.443}$$

同时有路径联合分布与依赖 θ 的被积函数 R_{π_θ}。因此 ∇_θ 必须穿过采样分布求导，导致 REINFORCE/路径耦合与高方差梯度。

3. **长链、大求和与昂贵反向传播**。在 $R_{\pi_\theta}(\mathbf{c}, \mathbf{x}_{0:T})$ 中，计算

$$\beta\big[\log \pi_\theta(\mathbf{x}_{0:T}|\mathbf{c}) - \log \pi_{\text{ref}}(\mathbf{x}_{0:T}|\mathbf{c})\big] \tag{8.8.5.444}$$

需要 $\mathcal{O}(T)$ 个逐步对数密度，$T \sim 10^2$–10^3，且策略 π_θ 与参考 π_{ref}、胜者与输家路径都要。穿过这些随机链（或桥采样器）反向传播在内存与计算上沉重、且可能不稳定；在每对、所有三元组上重复采样，会使训练超出实际预算。

走向式 (8.8.5.442) 的易处理代理。 为使其可计算，我们应用一个关键数学洞察。借助扩散模型的性质并应用 Jensen 不等式，我们可对一个易处理的上界优化。这把问题从评估整条路径的似然，转化为对路径内单个逐步转移的期望：

由于 $-\log\sigma(\cdot)$ 是凸的，Jensen 不等式通过把内层期望移到 log 之外给出上界：

$$\mathcal{L}_{\text{Diff-DPO}}(\theta; \pi_{\text{ref}}) \le -\mathbb{E}_{(\mathbf{c},\mathbf{x}_0^w,\mathbf{x}_0^l)\sim\mathcal{D}} \mathbb{E}_{\substack{\mathbf{x}_{1:T}^w\sim\pi_\theta(\cdot|\mathbf{x}_0^w,\mathbf{c}) \\ \mathbf{x}_{1:T}^l\sim\pi_\theta(\cdot|\mathbf{x}_0^l,\mathbf{c})}} \Big[\log\sigma\Big(\beta\big(R(\mathbf{c},\mathbf{x}_{0:T}^w) - R(\mathbf{c},\mathbf{x}_{0:T}^l)\big)\Big)\Big]. \tag{8.8.5.445}$$

利用隐式奖励恒等式 $R_{\pi_\theta} = \beta\log\frac{\pi_\theta}{\pi_{\text{ref}}} + \beta\log Z(\mathbf{c})$ 以及胜者与输家间常数的抵消，该界成为

$$\mathcal{L}_{\text{Diff-DPO}}(\theta; \pi_{\text{ref}}) \le -\mathbb{E}\Big[\log\sigma\Big(\beta\Big(\log\frac{\pi_\theta(\mathbf{x}_{0:T}^w|\mathbf{c})}{\pi_{\text{ref}}(\mathbf{x}_{0:T}^w|\mathbf{c})} - \log\frac{\pi_\theta(\mathbf{x}_{0:T}^l|\mathbf{c})}{\pi_{\text{ref}}(\mathbf{x}_{0:T}^l|\mathbf{c})}\Big)\Big)\Big]. \tag{8.8.5.446}$$

易处理代理（逐步形式）。 现在我们利用反向过程的 Markov 性质来分解 $\mathcal{L}_{\text{Diff-DPO}}$ 的上界。这使我们能把路径级偏好表示为逐步贡献之和，把难处理的路径级损失转化为易处理的单步估计量。所得形式退化为一个 DSM 风格的 MSE 差。

具体地，对反向链，

$$\pi_\theta(\mathbf{x}_{0:T}|\mathbf{c}) = \pi_\theta(\mathbf{x}_T|\mathbf{c}) \prod_{t=1}^{T} \pi_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{c}), \tag{8.8.5.447}$$

$$\pi_{\text{ref}}(\mathbf{x}_{0:T}|\mathbf{c}) = \pi_{\text{ref}}(\mathbf{x}_T|\mathbf{c}) \prod_{t=1}^{T} \pi_{\text{ref}}(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{c}). \tag{8.8.5.448}$$

因此

$$\frac{\pi_\theta(\mathbf{x}_{0:T}|\mathbf{c})}{\pi_{\text{ref}}(\mathbf{x}_{0:T}|\mathbf{c})} = \frac{\pi_\theta(\mathbf{x}_T|\mathbf{c})}{\pi_{\text{ref}}(\mathbf{x}_T|\mathbf{c})} \prod_{t=1}^{T} \frac{\pi_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{c})}{\pi_{\text{ref}}(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{c})}. \tag{8.8.5.449}$$

若时刻 T 的先验对两模型相同，即 $\pi_\theta(\mathbf{x}_T|\mathbf{c}) = \pi_{\text{ref}}(\mathbf{x}_T|\mathbf{c})$，则第一因子等于 1，取对数得

$$\log\frac{\pi_\theta(\mathbf{x}_{0:T}|\mathbf{c})}{\pi_{\text{ref}}(\mathbf{x}_{0:T}|\mathbf{c})} = \sum_{t=1}^{T} \log\frac{\pi_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{c})}{\pi_{\text{ref}}(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{c})}. \tag{8.8.5.450}$$

于是式 (8.8.5.446) 的上界可写为

$$\mathcal{L}_{\text{Diff-DPO}}(\theta; \pi_{\text{ref}}) \le -\mathbb{E}\Big[\log\sigma\Big(\beta\sum_{t=1}^{T}\Delta_t\Big)\Big], \tag{8.8.5.451}$$

其中每个逐步贡献为

$$\Delta_t = \log \frac{\pi_\theta(\mathbf{x}_{t-1}^w|\mathbf{x}_t^w,\mathbf{c})}{\pi_{\text{ref}}(\mathbf{x}_{t-1}^w|\mathbf{x}_t^w,\mathbf{c})} - \log \frac{\pi_\theta(\mathbf{x}_{t-1}^l|\mathbf{x}_t^l,\mathbf{c})}{\pi_{\text{ref}}(\mathbf{x}_{t-1}^l|\mathbf{x}_t^l,\mathbf{c})}. \tag{8.8.5.452}$$

为得到易处理上界，我们施加单步 Jensen 估计量：采样 $t \sim \mathcal{U}\{1,\dots,T\}$（每训练对一个时间步）并按 T 重缩放。这给出

$$-\log\sigma\Big(\beta\sum_{t=1}^{T}\Delta_t\Big) \le \mathbb{E}_t\big[-\log\sigma(\beta T\Delta_t)\big]. \tag{8.8.5.453}$$

因此最终目标是一个期望的逐步代理，

$$\mathcal{L}_{\text{Diff-DPO}}(\theta;\pi_{\text{ref}}) \le -\mathbb{E}_{\substack{(\mathbf{c},\mathbf{x}_0^w,\mathbf{x}_0^l)\sim\mathcal{D}\\ t\sim\mathcal{U}\{1,\dots,T\}}}\big[\log\sigma(\beta T\Delta_t)\big], \tag{8.8.5.454}$$

它把原路径级损失退化为一个易处理的单步上界估计量。

对扩散模型所用的 Gaussian 反向条件（以 $\boldsymbol{\epsilon}$-预测为例），

$$\log\frac{\pi_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t,\mathbf{c})}{\pi_{\text{ref}}(\mathbf{x}_{t-1}|\mathbf{x}_t,\mathbf{c})} = \text{const} - \lambda_t\Big(\underbrace{\|\widehat{\boldsymbol{\epsilon}}_\theta(\mathbf{x}_t,t,\mathbf{c})-\boldsymbol{\epsilon}_t\|^2}_{\text{策略}} - \underbrace{\|\widehat{\boldsymbol{\epsilon}}_{\text{ref}}(\mathbf{x}_t,t,\mathbf{c})-\boldsymbol{\epsilon}_t\|^2}_{\text{参考}}\Big), \tag{8.8.5.455}$$

其中 $\lambda_t > 0$ 吸收噪声调度因子。于是每个时间贡献正比于切片 t 处（策略相对参考的）MSE 差。

为记号简便，对任意 $\mathbf{x}_t$ 定义

$$\Delta\text{MSE}(\mathbf{x}_t) := \|\widehat{\boldsymbol{\epsilon}}_\theta(\mathbf{x}_t,t,\mathbf{c})-\boldsymbol{\epsilon}\|^2 - \|\widehat{\boldsymbol{\epsilon}}_{\text{ref}}(\mathbf{x}_t,t,\mathbf{c})-\boldsymbol{\epsilon}\|^2. \tag{8.8.5.456}$$

这激下列关于 $\mathcal{L}_{\text{Diff-DPO}}(\theta;\pi_{\text{ref}})$ 的实用代理：

$$\widetilde{\mathcal{L}}_{\text{Diff-DPO}}(\theta;\pi_{\text{ref}}) := \mathbb{E}_{\substack{(\mathbf{c},\mathbf{x}_0^w,\mathbf{x}_0^l)\sim\mathcal{D}\\ t\sim\mathcal{U}\{1,\dots,T\},\boldsymbol{\epsilon}\sim\mathcal{N}(\mathbf{0},\mathbf{I})}}\Big[w(t)\big(\Delta\text{MSE}(\mathbf{x}_t^w)-\Delta\text{MSE}(\mathbf{x}_t^l)\big)\Big], \tag{8.8.5.457}$$

其中 $\mathbf{x}_t^w = \alpha_t\mathbf{x}_0^w + \sigma_t\boldsymbol{\epsilon}$、$\mathbf{x}_t^l = \alpha_t\mathbf{x}_0^l + \sigma_t\boldsymbol{\epsilon}$ 共享同一噪声 $\boldsymbol{\epsilon}$ 以做方差缩减，$w(t) > 0$ 收集时间权重（如 $w(t) \propto \lambda_t$）。

直观上，最小化 $\widetilde{\mathcal{L}}_{\text{Diff-DPO}}$ 提高模型在胜者上相对参考的预测精度，并降低其在输家上的。由于改进总是相对于同一时间步的 π_{ref} 测量，策略被推向胜者样的去噪轨迹、远离输家样的轨迹，同时仍锚定在参考上。

8.6 小结

本章把焦点从基础原理转向可控生成这一实际挑战。我们基于条件分数的 Bayesian 分解建立了引导的统一框架，它优雅地把生成过程分离为一个无条件方向与一个引导项。

我们看到这一原理在若干强大技术中体现。我们介绍了需要专门训练的方法，如使用外部分类器的分类器引导（CG），以及在单个模型内学习条件与无条件分数、更高效

的无分类器引导（CFG）。我们还探索了灵活的免训练引导方法：它们可在推理时通过从任意损失函数定义代理似然来引导预训练模型，从而无需任何重训练即可实现从艺术控制到求解逆问题的应用。

在简单条件之外，我们深入了把模型输出与人类偏好对齐这一更微妙的任务。回顾标准但复杂的 RLHF 流水线后，我们介绍了 Direct Preference Optimization（DPO）及其新推广 Diffusion-DPO，作为更直接、更稳定的替代。这一方法通过直接从偏好数据导出损失，优雅地绕开了显式奖励模型与强化学习的需要。

通过这些技术，我们装配了一套引导生成过程的强大工具包。然而一个主要实际障碍仍未触及：迭代采样过程本身高昂的计算代价与延迟。在解决了“生成什么”之后，我们转向同样重要的“能生成多快”的问题。下一章将直接应对这一挑战：

1. 我们将利用“采样等价于求解一个 ODE”这一洞见，探索专门设计的、大幅减少所需步数的数值求解器；

2. 我们将考察一系列有影响的方法，包括 DDIM、DEIS 与 DPM-Solver 族，它们把采样速度加速若干数量级，使扩散模型远更实用。

Chapter 9

快速采样的精巧求解器

大道至简。

— 译者拟

在前面的章节中，我们反复看到扩散模型的采样本质上是求解一个概率流 ODE（Probability Flow ODE, PF–ODE）（见第 4 章与第 6 章）. 给定一个预训练好的扩散模型 $\mathbf{s}_{\phi^\times}(\mathbf{x}, t) \approx \nabla_{\mathbf{x}} \log p_t(\mathbf{x})$，我们需要从初始噪声分布 p_T 出发，沿着 PF–ODE 的解一直演化到数据分布 p_0，从而得到生成样本. 然而，这条轨迹通常需要成百上千步离散化才能精确跟踪，使得采样成为扩散模型在实际部署中最主要的计算瓶颈.

本章介绍一类无需额外训练（training-free）的快速采样求解器. 它们不改动预训练模型，而是借助数值分析中处理常微分方程的成熟技巧，在每一步中更聪明地利用模型输出，从而把所需的模型前向次数（number of function evaluations, NFE）从数千压缩到个位数到几十，同时保持样本质量. 我们将按历史脉络介绍 DDIM、DEIS、DPM-Solver、DPM-Solver++、DPM-Solver-v3 以及时间并行的 ParaDiGMS，并把它们统一放进经典数值分析的坐标系中加以理解（PF–ODE 的推导见第 4 章与第 6 章）.

9.1 序幕

预训练扩散模型的采样慢，根源在于数值求解 PF–ODE 时采用了过于朴素的离散化策略. 本节先回顾问题的数学形式，再给出一个贯穿全章的统一框架，最后梳理文献中设计 PF–ODE 求解器的几条技术路线.

9.1.1 扩散模型的高阶求解器

回忆 Score SDE 框架（Song 等, 2021a）：反向时间的演化由一个 SDE

$$\mathrm{d}\mathbf{x} = \mathbf{f}(\mathbf{x}, t)\,\mathrm{d}t + g(t)\,\mathrm{d}\mathbf{w}, \tag{9.9.1.458}$$

描述，其中 $\mathbf{f}(\mathbf{x}, t)$ 为漂移系数，$g(t)$ 为扩散系数，$\mathbf{w}$ 为标准 Brown 运动. 与该 SDE 共享边缘分布 $p_t(\mathbf{x})$ 的确定性 PF–ODE 为

$$\mathrm{d}\mathbf{x} = \left[\mathbf{f}(\mathbf{x}, t) - \frac{1}{2} g^2(t) \nabla_{\mathbf{x}} \log p_t(\mathbf{x})\right] \mathrm{d}t. \tag{9.9.1.459}$$

一旦用预训练模型近似了分数 $\nabla_{\mathbf{x}} \log p_t(\mathbf{x}) \approx \mathbf{s}_{\phi^\times}(\mathbf{x}, t)$，采样就等价于从 $t = T$ 积分到 $t = 0$ 求解这个 ODE.

直接用显式 Euler 法以均匀时间步积分 (9.9.1.459) 会遇到两个困难. 其一，PF–ODE 的漂移在不同噪声尺度下变化剧烈，是典型的刚性（stiff）方程；其二，朴素 Euler

是一阶方法，要达到可接受的精度必须把步长取得很小. 高阶求解器的目标，就是在固定的模型预算下，通过更合理的时间重参数化、对半线性结构的精确处理、以及对历史模型输出的回收复用，来提高每一步的精度.

9.1.2 文献中设计求解器的统一框架

为了统一理解后续方法，我们先固定一套记号. 设前向过程的扰动核为

$$\mathbf{x}_t = \alpha_t \mathbf{x}_0 + \sigma_t \boldsymbol{\epsilon}, \qquad \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}), \tag{9.9.1.460}$$

其中 α_t 与 σ_t 分别是信号系数与噪声系数，由噪声调度决定. 在这一记法下，分数与预测噪声之间满足

$$\mathbf{s}_{\phi^\times}(\mathbf{x}, t) = -\frac{1}{\sigma_t}\, \boldsymbol{\epsilon}_{\phi^\times}(\mathbf{x}, t), \tag{9.9.1.461}$$

这里 $\boldsymbol{\epsilon}_{\phi^\times}(\mathbf{x}, t)$ 是模型对噪声的预测. 对应的 oracle 噪声为

$$\boldsymbol{\epsilon}^\star(\mathbf{x}, t) = -\sigma_t \nabla_{\mathbf{x}} \log p_t(\mathbf{x}). \tag{9.9.1.462}$$

记从时间 s 到 t 的 *oracle* 流图（flow map）为 $\Psi_{s\to t}(\mathbf{x})$，即 PF–ODE 从 s 到 t 的精确解算子；而用预训练模型代入后得到的经验流图记为 $\widetilde{\Psi}_{s\to t}(\mathbf{x}_s)$. 绝大多数快速采样方法，本质上都是在构造 $\widetilde{\Psi}_{s\to t}$ 的一个廉价而高精度的近似.

把 (9.9.1.461) 代入 (9.9.1.459)，并利用半线性结构，可以把经验 PF–ODE 写成

$$\widetilde{\Psi}_{s\to t}(\mathbf{x}_s) = \mathcal{E}(s \to t)\, \mathbf{x}_s + \frac{1}{2} \int_s^t \frac{g^2(\tau)}{\sigma_\tau}\, \mathcal{E}(\tau \to t)\, \boldsymbol{\epsilon}_{\phi^\times}(\mathbf{x}_\tau, \tau)\, \mathrm{d}\tau, \tag{9.9.1.463}$$

其中我们定义指数积分子（exponential integrator）

$$\mathcal{E}(s \to t) := \exp\left(\int_s^t \mathbf{f}(u)\, \mathrm{d}u \right). \tag{9.9.1.464}$$

式 (9.9.1.463) 中第一项是对线性漂移部分的精确积分，第二项是待近似的非线性残差. 这个 “线性部分精确处理、非线性部分多项式逼近” 的形式，是本章所有方法的共同骨架.

9.1.3 PF–ODE 数值求解器的几条路线

围绕如何近似 (9.9.1.463) 中的积分，文献中发展出几条互补的路线：

- **单步指数 Euler：** 把积分区间上的非线性项用其在左端点的值代替，得到 DDIM 一类的一阶格式；
- **多步（multistep）方法：** 回收过去若干步已经算出的模型输出，用 Lagrange 插值在历史节点上拟合非线性项，代表是 DEIS；

- **时间重参数化：**把自变量从物理时间 t 换成半对数信噪比 λ，使被积函数在新坐标系下足够光滑，从而局部 Taylor 展开就可给出高阶格式，代表是 DPM-Solver 与 DPM-Solver++；
- **自由参数优化：**在 ODE 中引入待定变量并离线最小化离散化误差，代表是 DPM-Solver-v3；
- **时间并行：**放弃严格串行，改用 Picard 不动点迭代在多个时间节点上并行推进，代表是 ParaDiGMS.

下面几节将依次展开这些方法，并在最后把它们放回经典数值分析（Euler、Heun、Runge–Kutta、Adams–Bashforth）的坐标系中对照.

9.2 DDIM

DDIM（Denoising Diffusion Implicit Models，Song 等, 2020c）是最早被广泛使用的快速采样方法之一. 它最初是作为 DDPM 的一个非随机推广提出的，后来才被揭示为 PF–ODE 的一阶指数 Euler 离散. 本节给出这一解释，并讨论不同参数化下的直觉.

9.2.1 把 DDIM 解释为 ODE 求解器

把 (9.9.1.463) 中的积分在左端点 s 处用矩形法近似，并利用 $t = s - \Delta$ 时 $\mathcal{E}(s \to t) = \alpha_t/\alpha_s$，可得一阶更新

$$\widetilde{\mathbf{x}}_t = \frac{\alpha_t}{\alpha_s}\widetilde{\mathbf{x}}_s - \alpha_t \left(\frac{\sigma_s}{\alpha_s} - \frac{\sigma_t}{\alpha_t}\right) \boldsymbol{\epsilon}_{\phi^\times}(\widetilde{\mathbf{x}}_s, s). \tag{9.9.2.465}$$

这正是 DDIM 在确定性情形（随机项 $\eta = 0$）下的更新公式. 我们把这一对应正式记录为下面的命题.

命题 9.2.1 (DDIM 即指数 Euler 更新)**：** *对固定调度 (α_t, σ_t)，PF–ODE (9.9.1.463) 在左端点矩形近似下的更新 (9.9.2.465) 与确定性 DDIM 更新完全一致.*

命题证明： 对 (9.9.1.463) 中的积分用左端点近似：

$$\frac{1}{2}\int_s^t \frac{g^2(\tau)}{\sigma_\tau}\mathcal{E}(\tau \to t)\, \boldsymbol{\epsilon}_{\phi^\times}(\mathbf{x}_\tau, \tau)\, \mathrm{d}\tau \approx \frac{1}{2}\frac{g^2(s)}{\sigma_s}\boldsymbol{\epsilon}_{\phi^\times}(\widetilde{\mathbf{x}}_s, s) \int_s^t \mathcal{E}(\tau \to t)\, \mathrm{d}\tau.$$

在 DDPM 调度下 $\frac{1}{2}g^2(s)/\sigma_s = -\alpha_s$，且 $\mathcal{E}(\tau \to t) = \alpha_t/\alpha_\tau$，积分结果为 $\alpha_t(\sigma_s/\alpha_s - \sigma_t/\alpha_t)$. 代入即得 (9.9.2.465). □

如图 9.2.1（即原书 Figure 9.1）所示，DDIM 的一步并不是沿切线方向的普通 Euler，而是先把线性漂移部分精确地沿指数演化推进一步，再加上非线性项的一阶贡献. 这正是“指数积分子”的含义.

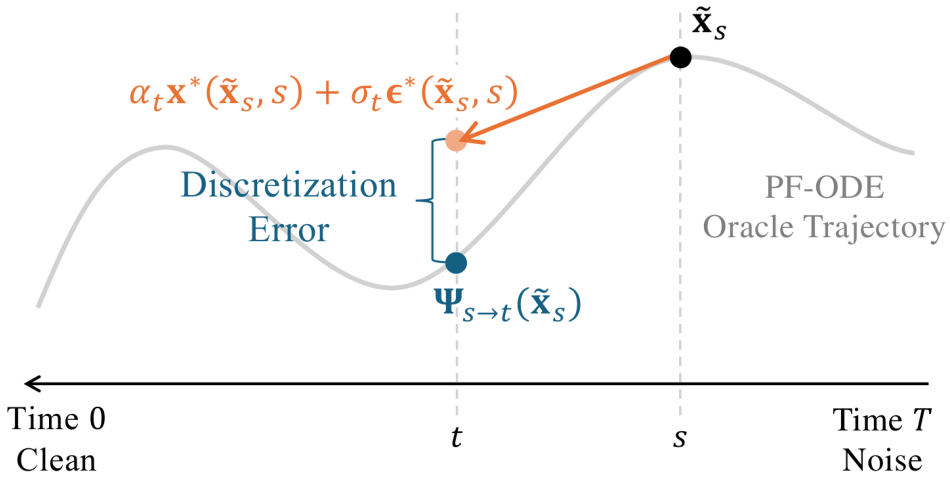


图 9.39: 把 DDIM 视作 PF–ODE 的 Euler 离散. 从状态 $\tilde{\mathbf{x}}_s$ 出发，oracle 流图 $\Psi_{s\to t}(\tilde{\mathbf{x}}_s)$（深蓝点）位于灰色 PF–ODE 轨迹上；指数 Euler 更新沿线性部分精确演化的方向（橙色箭头）给出 $\alpha_t \mathbf{x}^\star(\tilde{\mathbf{x}}_s, s) + \sigma_t \boldsymbol{\epsilon}^\star(\tilde{\mathbf{x}}_s, s)$（浅橙点）. 二者之差即离散化误差（蓝色括注）.

9.2.2 不同参数化下 DDIM 的直觉

扩散模型可以用噪声预测（$\boldsymbol{\epsilon}$-prediction）、数据预测（$\mathbf{x}$-prediction）或速度预测（$\mathbf{v}$-prediction）等不同参数化来训练. 由 (9.9.1.460)，它们彼此线性相关：

$$\boldsymbol{\epsilon}_{\phi^\times}(\mathbf{x}_t, t) = \frac{\mathbf{x}_t - \alpha_t \mathbf{x}_{\phi^\times}(\mathbf{x}_t, t)}{\sigma_t}. \tag{9.9.2.466}$$

在 $\mathbf{v}$-prediction 下，PF–ODE 中不再含有显式的线性项，普通 Euler 更新恰好等于 DDIM；而在 $\boldsymbol{\epsilon}$-、$\mathbf{x}$- 或 $\mathbf{s}$-prediction 下，普通 Euler 与 DDIM 相差一个指数积分因子. 这一区别在后面讨论 Heun 与 DPM-Solver-2 时还会再次出现.

9.2.3 （可选）DDIM 的变分视角

DDIM 也可以从变分（ELBO）角度理解：它对应于在 DDPM 的目标中引入一个额外的隐式边缘化步骤，从而在不改变训练目标的前提下，得到一条确定性的生成轨迹. 这一视角解释了为何 DDIM 可以复用 DDPM 训练好的权重，却能给出更少步数、更确定性的采样.

9.2.4 DDIM 即条件流匹配

从流匹配（Flow Matching）的视角看，DDIM 的前向加噪与反向去噪恰好构成一条直线型的概率路径：前向沿 $\mathbf{x}_t = \alpha_t \mathbf{x}_0 + \sigma_t \boldsymbol{\epsilon}$ 把数据逐步推向噪声，反向则沿同一族路径采样. 因此 DDIM 与直线型条件流匹配（Conditional Flow Matching, CFM）在数学上是同构的. 这一联系把 DDIM 纳入了更广泛的流模型谱系.

9.3 DEIS

DDIM 是一阶方法. DEIS (Diffusion Exponential Integrator Sampler, Liu 等, 2022) 指出：既然线性部分已被指数积分子精确处理，剩下的非线性残差可以用过去若干步的模型输出通过多项式外推来近似，从而在几乎不增加单步开销的前提下提高阶数.

9.3.1 多项式外推

回忆 (9.9.1.463)，待近似的核心积分形如

$$\int_s^t \mathcal{E}(\tau \to t)\, \boldsymbol{\epsilon}_{\phi^\times}(\mathbf{x}_\tau, \tau)\, \mathrm{d}\tau. \tag{9.9.3.467}$$

DEIS 的想法是：如果我们已经在过去的时间节点 $t_0 > t_1 > \cdots > t_r$ 上算出了模型输出 $\boldsymbol{\epsilon}_{\phi^\times}(\mathbf{x}_{t_i}, t_i)$，就可以用这 $r+1$ 个点作 Lagrange 插值，得到一个 r 次多项式 $P_r(\tau)$ 来近似被积函数，然后解析地积分该多项式. 由于 $\mathcal{E}(\tau \to t)$ 是已知的指数函数，多项式与之乘积的积分仍有闭式.

9.3.2 DEIS：PF–ODE 积分的 Lagrange 多项式逼近

设在当前步我们要从 $s = t_{r+1}$ 推进到 $t = t_{r+2}$，并已有 $t_0, \ldots, t_r$ 处的模型输出. 用通过 $(t_i, \boldsymbol{\epsilon}_{\phi^\times}(\mathbf{x}_{t_i}, t_i))_{i=0}^r$ 的 r 次 Lagrange 多项式代替被积函数，即得

$$\widetilde{\Psi}_{s\to t}(\mathbf{x}_s) = \mathcal{E}(s \to t)\mathbf{x}_s + \int_s^t \mathcal{E}(\tau \to t) P_r(\tau)\, \mathrm{d}\tau. \tag{9.9.3.468}$$

该积分完全由历史节点上的函数值与已知的指数权重闭式给出，不需要额外调用模型. 这就是 DEIS-r（r 步多步格式）.

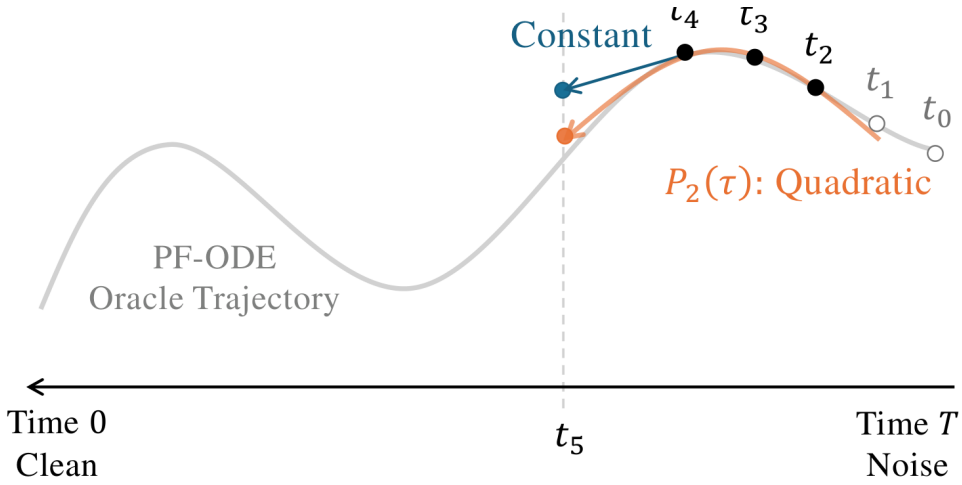


图 9.40: DEIS 作为多步方法的示意图. 以三个历史锚点 t_2, t_3, t_4 为例，DEIS 通过历史模型输出拟合一条二次曲线 $P_2(\tau)$（橙色），再把它解析地积分到当前步 t_5（蓝色“常数”点）. 灰色曲线为 PF–ODE oracle 轨迹.

如图 9.40（原书 Figure 9.2）所示，二次插值曲线（橙色）穿过三个历史锚点，再被解析积分到当前时刻. 因为每一步只需要一次新的模型调用，DEIS 能用少量步数达到高阶精度.

9.3.3 DDIM = AB-DEIS-0

当 $r = 0$ 时，Lagrange 多项式退化为常数，DEIS-0 就退化为左端点矩形近似，也就是 DDIM. 换言之，DDIM 是 Adams–Bashforth 意义下的零阶 DEIS（记作 AB-DEIS-0）. 这一对应把 DDIM 自然地嵌入多步方法谱系.

9.4 DPM-Solver

DEIS 用跨历史节点的 Lagrange 插值来近似被积函数. DPM-Solver (Lu 等, 2022b) 则走另一条路：它通过一次精巧的时间重参数化，使被积函数在新时间变量下变得光滑，于是只需局部 Taylor 展开就能得到闭式高阶格式.

9.4.1 DPM-Solver 的洞见：用对数 SNR 作时间重参数化

定义半对数信噪比（half-log SNR）

$$\lambda_t := \frac{1}{2}\log\frac{\alpha_t^2}{\sigma_t^2} = \log\frac{\alpha_t}{\sigma_t}. \tag{9.9.4.469}$$

换元到 λ 之后，经验 PF–ODE (9.9.1.463) 变为

$$\widetilde{\Psi}_{s\to t}(\mathbf{x}_s) = \frac{\alpha_t}{\alpha_s}\mathbf{x}_s - \alpha_t\int_{\lambda_s}^{\lambda_t} e^{-\lambda}\hat{\boldsymbol{\epsilon}}_{\phi^\times}(\hat{\mathbf{x}}_\lambda,\lambda)\,\mathrm{d}\lambda, \tag{9.9.4.470}$$

其中 $\hat{\mathbf{x}}_\lambda := \mathbf{x}_{t_\lambda}$，$\hat{\boldsymbol{\epsilon}}_{\phi^\times}$ 是在 λ 坐标下的噪声预测. 在新坐标 λ 下，被积函数 $e^{-\lambda}\hat{\boldsymbol{\epsilon}}_{\phi^\times}(\hat{\mathbf{x}}_\lambda,\lambda)$ 关于 λ 足够光滑，这使得局部 Taylor 展开非常高效.

常用调度下的 λ 网格. 例如在 EDM 调度（Karras 等, 2022）中取 $(\alpha_t,\sigma_t) = (1,t)$，则 $\lambda(t) = \log(1/t)$，$\lambda'(t) = -1/t$. 此时 λ 上的均匀网格对应物理时间 t 上的几何网格（高 SNR 段步长密、低 SNR 段步长疏），经验上非常有利于精度.

9.4.2 用 Taylor 展开估计积分

从 (9.9.4.470) 出发，把被积函数 $\hat{\boldsymbol{\epsilon}}_{\phi^\times}(\hat{\mathbf{x}}_\lambda,\lambda)$ 在区间 $\lambda\in[\lambda_s,\lambda_t]$ 上关于 λ 作 $(n-1)$ 阶 Taylor 展开：

$$\hat{\boldsymbol{\epsilon}}_{\phi^\times}(\hat{\mathbf{x}}_\lambda,\lambda) = \sum_{k=0}^{n-1}\frac{(\lambda-\lambda_s)^k}{k!}\hat{\boldsymbol{\epsilon}}^{(k)}_{\phi^\times}(\hat{\mathbf{x}}_{\lambda_s},\lambda_s) + \mathcal{O}\big((\lambda-\lambda_s)^n\big), \tag{9.9.4.471}$$

其中上标 (k) 表示关于 λ 的 k 阶全导数. 代入积分即得闭式近似，定义了 n 阶求解器 DPM-Solver-n. 记 $h := \lambda_t - \lambda_s$，其主公式为

$$\widetilde{\mathbf{x}}_t = \frac{\alpha_t}{\alpha_s}\widetilde{\mathbf{x}}_s - \alpha_t\sum_{k=0}^{n-1}\hat{\boldsymbol{\epsilon}}^{(k)}_{\phi^\times}(\hat{\mathbf{x}}_{\lambda_s},\lambda_s)\,C_k + \mathcal{O}(h^{n+1}), \tag{9.9.4.472}$$

其中系数

$$C_k := \int_{\lambda_s}^{\lambda_t} e^{-\lambda} \frac{(\lambda-\lambda_s)^k}{k!}\,\mathrm{d}\lambda \tag{9.9.4.473}$$

可通过分部积分 k 次解析地预计算.

例：DPM-Solver-1. 取 $n=1$，式 (9.9.4.472) 简化为

$$\widetilde{\mathbf{x}}_t = \frac{\alpha_t}{\alpha_s}\widetilde{\mathbf{x}}_s - \sigma_t(e^h-1)\boldsymbol{\epsilon}_{\phi^\times}(\widetilde{\mathbf{x}}_s, s) + \mathcal{O}(h^2). \tag{9.9.4.474}$$

这恰好就是 DDIM 更新；这一等价性由命题 9.4.1 正式给出.

9.4.3 DPM-Solver-n 的实现

对 $n \geq 2$, 需要估计 $k \leq n-1$ 阶导数 $\hat{\boldsymbol{\epsilon}}^{(k)}_{\phi^\times}$. 直接求高阶导数代价高昂, Lu 等 (2022b) 采用单步 ODE 求解器中常用的技巧：在 s 与 t 之间插入中间时间步 s^{mid}，用 s 与 s^{mid} 处的模型输出作有限差分来近似高阶导数. 记 $\varphi_{k+1}(\cdot)$ 为对应的闭式核函数，$k=0,1,2$ 时：

$$\varphi_1(h) = \frac{e^h-1}{h}, \qquad \varphi_2(h) = \frac{e^h-h-1}{h^2}, \qquad \varphi_3(h) = \frac{e^h-\frac{h^2}{2}-h-1}{h^3}. \tag{9.9.4.475}$$

例：用精确导数的 DPM-Solver-2/3. 对 $n=3$，离散步 $h := \lambda_t - \lambda_s$，展开为

$$\begin{aligned}\mathbf{x}_t = {}& \frac{\alpha_t}{\alpha_s}\mathbf{x}_s - \sigma_t(e^h-1)\hat{\boldsymbol{\epsilon}}_{\phi^\times}(\hat{\mathbf{x}}_{\lambda_s}, \lambda_s) \\ & - \sigma_t(e^h-h-1)\hat{\boldsymbol{\epsilon}}^{(1)}_{\phi^\times}(\hat{\mathbf{x}}_{\lambda_s}, \lambda_s) - \sigma_t\left(e^h - \frac{h^2}{2} - h - 1\right)\hat{\boldsymbol{\epsilon}}^{(2)}_{\phi^\times}(\hat{\mathbf{x}}_{\lambda_s}, \lambda_s) + \mathcal{O}(h^4).\end{aligned} \tag{9.9.4.476}$$

为近似 $k \leq n-1$ 阶导数，引入超参数 $\gamma \in (0,1]$ 指定插值点，并定义

$$s^{\mathrm{mid}} = t_\lambda(\lambda_s + \gamma h), \qquad h := \lambda_t - \lambda_s.$$

中间估计为

$$\mathbf{x}^{\mathrm{mid}} = \frac{\alpha_{s^{\mathrm{mid}}}}{\alpha_s}\widetilde{\mathbf{x}}_s - \sigma_{s^{\mathrm{mid}}}(e^{\gamma h}-1)\boldsymbol{\epsilon}_{\phi^\times}(\widetilde{\mathbf{x}}_s, s).$$

由此得到二阶近似

$$\begin{aligned}\widetilde{\mathbf{x}}_t = {}& \frac{\alpha_t}{\alpha_s}\widetilde{\mathbf{x}}_s - \sigma_t(e^h-1)\boldsymbol{\epsilon}_{\phi^\times}(\widetilde{\mathbf{x}}_s, s) \\ & - \frac{\sigma_t}{\gamma h}(e^h-h-1)\Big(\boldsymbol{\epsilon}_{\phi^\times}(\mathbf{x}^{\mathrm{mid}}, s^{\mathrm{mid}}) - \boldsymbol{\epsilon}_{\phi^\times}(\widetilde{\mathbf{x}}_s, s)\Big) + \mathcal{O}(h^3).\end{aligned} \tag{9.9.4.477}$$

当 $\gamma = \frac{1}{2}$ 时，算法 5 中的两阶段更新在 $\mathcal{O}(h^3)$ 意义下等价于式 (9.9.4.477).

注 9.4.1 (关于步长与有限差分)： 在式 (9.9.4.477) 中，差商 $\hat{\boldsymbol{\epsilon}}^{(1)}_{\phi^\times} \approx [\boldsymbol{\epsilon}_{\phi^\times}(\mathbf{x}^{\mathrm{mid}}, s^{\mathrm{mid}}) - \boldsymbol{\epsilon}_{\phi^\times}(\widetilde{\mathbf{x}}_s, s)]/(\gamma h)$ 近似了模型沿轨迹的全 λ 导数，精度为 $\mathcal{O}(h)$；再乘上精确系数 $e^h-h-1=\mathcal{O}(h^2)$，整体仍为二阶. 每步恰好两次模型调用，γ 不影响阶数、只影响误差常数；取 $\gamma=\frac{1}{2}$ 对称化模板，通常误差常数最小，故实践中常用中点版本. ◇

Algorithm 5 DPM-Solver-2（取 $\gamma = \frac{1}{2}$）

Input: initial value $\mathbf{x}_T$, time steps $\{t_i\}_{i=0}^M$, model $\boldsymbol{\epsilon}_{\phi\times}$

$\widetilde{\mathbf{x}}_{t_0} \leftarrow \mathbf{x}_T$

for $i \leftarrow 1$ to M **do**

  $h_i \leftarrow \lambda_{t_i} - \lambda_{t_{i-1}}$

  $s_i^{\text{mid}} \leftarrow t_\lambda\left(\frac{\lambda_{t_{i-1}}+\lambda_{t_i}}{2}\right)$

  $\mathbf{x}_i^{\text{mid}} \leftarrow \frac{\alpha_{s_i^{\text{mid}}}}{\alpha_{t_{i-1}}}\widetilde{\mathbf{x}}_{t_{i-1}} - \sigma_{s_i^{\text{mid}}}\left(e^{h_i/2}-1\right)\boldsymbol{\epsilon}_{\phi\times}(\widetilde{\mathbf{x}}_{t_{i-1}}, t_{i-1})$

  $\widetilde{\mathbf{x}}_{t_i} \leftarrow \frac{\alpha_{t_i}}{\alpha_{t_{i-1}}}\widetilde{\mathbf{x}}_{t_{i-1}} - \sigma_{t_i}(e^{h_i}-1)\boldsymbol{\epsilon}_{\phi\times}(\mathbf{x}_i^{\text{mid}}, s_i^{\text{mid}})$

end for

return $\widetilde{\mathbf{x}}_{t_M}$

采样时间步的选取. Lu 等（2022b）建议在 λ 上均匀取步：

$$\lambda_{t_i} = \lambda_T + \frac{i}{M}(\lambda_0 - \lambda_T), \qquad i = 0, \dots, M.$$

这与早期在物理时间 t 上均匀取步的做法（Ho 等, 2020；Song 等, 2020c）不同. 几何上，局部 Taylor 精度取决于动力学在 λ 上演化得有多光滑，λ 上均匀即局部误差大致均匀，因而在信号主导段步长更密、噪声主导段步长更疏.

9.4.4 DDIM = DPM-Solver-1

命题 9.4.1 (DDIM 即 DPM-Solver-1)：对固定调度 (α_t, σ_t)，DDIM 的更新规则（式 (9.9.2.465)）与 DPM-Solver-1 的更新规则（式 (9.9.4.474)）完全相同，且与时间参数化（物理时间 t 或对数 SNR 时间 λ）无关.

命题证明： 由 λ 的定义 (9.9.4.469)，有

$$\frac{\sigma_s}{\alpha_s} = e^{-\lambda_s}, \qquad \frac{\sigma_t}{\alpha_t} = e^{-\lambda_t}.$$

把这两式连同 $h = \lambda_t - \lambda_s$ 代入式 (9.9.2.465)，即恢复出式 (9.9.4.474) 的形式. □

这解释了为何 DDIM 优于朴素 Euler：它实际上在更合适的 λ 重参数化下利用了 PF–ODE 的半线性结构.

注 9.4.2 (与 Runge–Kutta 的对比)：Score SDE 出现时，人们常用 Runge–Kutta（RK45）直接求解式 (9.9.1.459) 的“原始”PF–ODE，却没有利用其漂移的半线性. DPM-Solver-k ($k \geq 2$) 虽与 Runge–Kutta 相关，但它通过时间重参数化显式利用了这种半线性，因而能用少得多的函数调用达到高阶精度，把通常数百步的 DDIM 调度压缩到约 10–15 步且保持高质量. ◇

9.4.5 DPM-Solver-2 与经典 Heun 更新的讨论

在 9.2.2 节我们看到：不同参数化下，经典 Euler 型更新对应不同. 具体地，

$$\mathbf{v}\text{-prediction}: \quad \text{Euler} = \text{DDIM},$$

$\boldsymbol{\epsilon}$-、$\mathbf{x}$- 或$\mathbf{s}$-prediction：　exp-Euler = DDIM $\neq$ plain Euler.

本段进一步考察经典 Heun 法与二阶 DPM-Solver 在四种参数化下的对应关系.

回忆 Heun 法是一种二阶预测–校正格式：先用 Euler 预测到步末，在该点求斜率，再用起点斜率与预测斜率的平均作更新. 在对数 SNR 时间 λ 下，PF–ODE 可写成“线性 + 非线性”形式

$$\frac{\mathrm{d}\hat{\mathbf{x}}(\lambda)}{\mathrm{d}\lambda} = \underbrace{L(\lambda)\hat{\mathbf{x}}(\lambda)}_{\text{线性部分}} + \underbrace{\mathbf{N}(\hat{\mathbf{x}}(\lambda),\lambda)}_{\text{非线性部分}},$$

其中标量 $L(\lambda)$ 由噪声调度决定. 在 $\boldsymbol{\epsilon}$-、$\mathbf{x}$-、$\mathbf{s}$-prediction 下 $L(\lambda) \neq 0$；而 $\mathbf{v}$-prediction 对应 $L(\lambda) \equiv 0$（即 $\mathbf{N} = \mathbf{v}$），没有显式线性项.

普通 Heun 更新. 记 $\lambda_i := \lambda_{t_i}$，$h := \lambda_i - \lambda_{i-1} > 0$. 直接作用于全漂移 $\mathbf{F}(\hat{\mathbf{x}},\lambda) = L(\lambda)\hat{\mathbf{x}} + \mathbf{N}(\hat{\mathbf{x}},\lambda)$ 的普通 Heun 更新为

$$\begin{aligned}
&\text{Predict:} \quad \hat{\mathbf{x}}_i^{\mathrm{mid}} = \hat{\mathbf{x}}_{i-1} + h\mathbf{F}(\hat{\mathbf{x}}_{i-1},\lambda_{i-1}),\\
&\text{Correct:} \quad \hat{\mathbf{x}}_i = \hat{\mathbf{x}}_{i-1} + \frac{h}{2}\Big(\mathbf{F}(\hat{\mathbf{x}}_{i-1},\lambda_{i-1}) + \mathbf{F}(\hat{\mathbf{x}}_i^{\mathrm{mid}},\lambda_i)\Big).
\end{aligned} \tag{9.9.4.478}$$

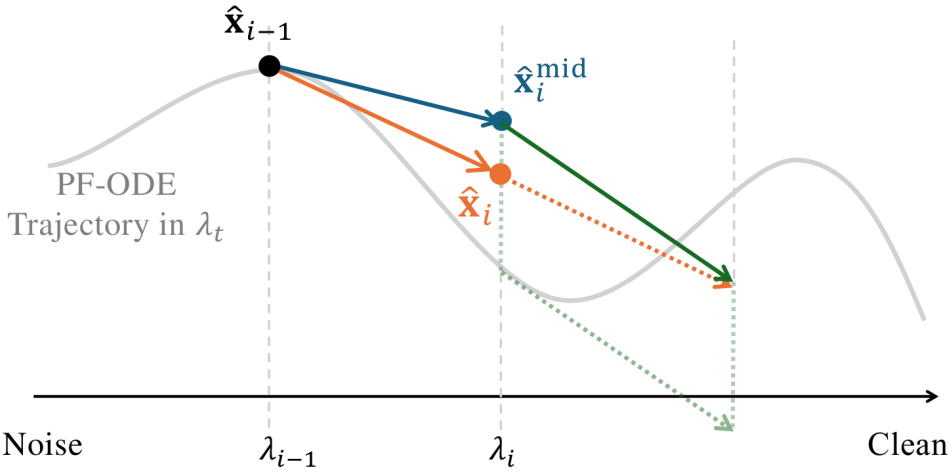


Figure 9.3: Plain Heun update in log-SNR time. Starting from the previous state $\hat{\mathbf{x}}_{i-1}$ at λ_{i-1}, the *predictor* step (blue arrow) performs an explicit Euler move $h\mathbf{F}(\hat{\mathbf{x}}_{i-1},\lambda_{i-1})$ to obtain the

图 9.41: 对数 SNR 时间下的普通 Heun 更新. 从 $\hat{\mathbf{x}}_{i-1}$（λ_{i-1}）出发，预测步（蓝色箭头）作显式 Euler 移动 $h\mathbf{F}(\hat{\mathbf{x}}_{i-1},\lambda_{i-1})$ 得到中间估计 $\hat{\mathbf{x}}_i^{\mathrm{mid}}$；校正步（绿色箭头）在该预测点求新斜率 $h\mathbf{F}(\hat{\mathbf{x}}_i^{\mathrm{mid}},\lambda_i)$，并通过平行四边形构造合并两个斜率（橙色虚线对角线）.

指数 Heun 更新（对半线性 PF–ODE）. 引入量

$$\mathcal{E} := \int_{\lambda_{i-1}}^{\lambda_i} L(\tau)\,\mathrm{d}\tau,$$

并定义两个系数

$$c_1(\mathcal{E}) = \begin{cases} \frac{e^{\mathcal{E}}-1}{\mathcal{E}}, & \mathcal{E} \neq 0, \\ 1, & \mathcal{E} = 0, \end{cases} \qquad c_2(\mathcal{E}) = \begin{cases} \frac{e^{\mathcal{E}}-1-\mathcal{E}}{\mathcal{E}^2}, & \mathcal{E} \neq 0, \\ \frac{1}{2}, & \mathcal{E} = 0. \end{cases}$$

指数 Heun 的一步为

$$\begin{aligned} \text{Predict:} \quad & \hat{\mathbf{x}}_i^{\text{mid}} = e^{\mathcal{E}}\hat{\mathbf{x}}_{i-1} + hc_1(\mathcal{E})\mathbf{N}(\hat{\mathbf{x}}_{i-1}, \lambda_{i-1}), \\ \text{Correct:} \quad & \hat{\mathbf{x}}_i = e^{\mathcal{E}}\hat{\mathbf{x}}_{i-1} + hc_1(\mathcal{E})\mathbf{N}(\hat{\mathbf{x}}_{i-1}, \lambda_{i-1}) + hc_2(\mathcal{E})\Big(\mathbf{N}(\hat{\mathbf{x}}_i^{\text{mid}}, \lambda_i) - \mathbf{N}(\hat{\mathbf{x}}_{i-1}, \lambda_{i-1})\Big). \end{aligned} \tag{9.9.4.479}$$

当 $L(\lambda) \equiv 0$ 时 $c_1 = 1, c_2 = \frac{1}{2}$，格式退化为式 (9.9.4.478) 的普通 Heun；当 $L(\lambda) \neq 0$ 时，线性部分被精确积分，而普通 Heun 只作近似. 二者之差只出现在 $\mathcal{O}(h^3)$ 的高阶项中.

四种参数化下 Heun 与 DPM-Solver-2 的对应. 在 $\boldsymbol{\epsilon}$-prediction 的 PF–ODE 中，对数 SNR 时间 λ 下的动力学自然取半线性形式，故式 (9.9.4.479) 的指数 Heun 更新与 DPM-Solver-2（$\gamma = \frac{1}{2}$，算法 5）完全等价. $\mathbf{x}$-、$\mathbf{s}$-prediction 同理. 而 $\mathbf{v}$-prediction 消去了线性项，其 PF–ODE 不需要指数积分子，普通 Heun 即给出正确的二阶更新. 我们总结为下面的观察.

注 9.4.3 (Heun 与 DPM-Solver-2 更新)**：** 在对数 SNR 时间 λ 下：

$$\mathbf{v}\text{-prediction:} \quad \text{Heun} = \text{DPM-Solver-2},$$

$$\boldsymbol{\epsilon}\text{-、}\mathbf{x}\text{- 或}\mathbf{s}\text{-prediction:} \quad \text{exp-Heun} = \text{DPM-Solver-2} \neq \text{plain Heun}.$$

在后三者中，普通 Heun 步之所以不等价，是因为它只近似而非精确积分了线性项. ◇

9.5 DPM-Solver++

高阶求解器在无引导时能加速采样，但扩散模型的价值在于可控生成，而这通常依赖引导（guidance，见第 8 章）. DPM-Solver++（Lu 等, 2022c）针对大引导强度下的稳定性问题作了改进.

9.5.1 从 DPM-Solver 到面向引导的 DPM-Solver++

DPM-Solver 及先前的高阶求解器在大引导尺度（更强条件）下会失稳，甚至可能比 DDIM 更慢. 作者把这种失稳归因于：引导会同时放大输出及其导数，而高阶求解器依赖高阶导数，因而对该放大尤其敏感. 为缓解这一点，DPM-Solver++ 提出两点：(1) 改用 $\mathbf{x}$-prediction 参数化而非 $\boldsymbol{\epsilon}$-prediction；(2) 使用阈值方法（如 dynamic thresholding，Saharia 等, 2022）把预测数据约束在训练数据范围内，缓解大引导下的训练–测试失配.

9.5.2 DPM-Solver++ 的方法

利用 $\mathbf{x}$-与 $\boldsymbol{\epsilon}$-预测的线性关系

$$\boldsymbol{\epsilon}_{\phi^\times}(\mathbf{x}_t, t) = \frac{\mathbf{x}_t - \alpha_t \mathbf{x}_{\phi^\times}(\mathbf{x}_t, t)}{\sigma_t},$$

DPM-Solver++ 把经验 PF–ODE 的精确解 (9.9.4.470) 改写成数据参数化形式：

$$\widetilde{\Psi}_{s\to t}(\mathbf{x}_s) = \frac{\sigma_t}{\sigma_s}\mathbf{x}_s + \sigma_t \int_{\lambda_s}^{\lambda_t} e^{\lambda}\, \hat{\mathbf{x}}_{\phi^\times}(\hat{\mathbf{x}}_\lambda, \lambda)\, \mathrm{d}\lambda, \tag{9.9.5.480}$$

其中 $\hat{\mathbf{x}}_\lambda := \mathbf{x}_{t_\lambda(\lambda)}$. 据此 DPM-Solver++ 提供两种变体：高阶单步求解器（9.5.3 节）与多步（两步）求解器（9.5.4 节）；后者类似 DEIS 但固定复用两个历史锚点，且每步只需一次新的模型调用.

9.5.3 DPM-Solver++：Taylor 展开的单步格式

记 $\hat{\mathbf{x}}^{(n)}_{\phi^\times}(\hat{\mathbf{x}}_{\lambda_{i-1}}, \lambda_{i-1})$ 为 $\hat{\mathbf{x}}_{\phi^\times}$ 在 λ_{i-1} 处关于 λ 的 n 阶全导数. 以 $(n-1)$ 阶 Taylor 展开近似被积函数，得

$$\widetilde{\mathbf{x}}_{t_i} = \frac{\sigma_{t_i}}{\sigma_{t_{i-1}}}\widetilde{\mathbf{x}}_{t_{i-1}} + \sigma_{t_i} \sum_{k=0}^{n-1} \hat{\mathbf{x}}^{(k)}_{\phi^\times}(\hat{\mathbf{x}}_{\lambda_{i-1}}, \lambda_{i-1}) \underbrace{\int_{\lambda_{t_{i-1}}}^{\lambda_{t_i}} e^{\lambda} \frac{(\lambda - \lambda_{t_{i-1}})^k}{k!}\, \mathrm{d}\lambda}_{\text{解析可算}} + \mathcal{O}(h_i^{n+1}). \tag{9.9.5.481}$$

其中积分有闭式，与式 (9.9.4.472) 同型. $n = 1$ 时退化为 DDIM；$n = 2$ 并用有限差分近似一阶导数时，给出 DPM-Solver++(2S)，它类比算法 5 但使用 $\mathbf{x}$-prediction，见算法 6.

Algorithm 6 DPM-Solver++(2S)：中点特例

Input: initial value $\mathbf{x}_T$, time steps $\{t_i\}_{i=0}^{M}$, data-prediction model $\hat{\mathbf{x}}_{\phi^\times}$

$\widetilde{\mathbf{x}}_{t_0} \leftarrow \mathbf{x}_T$; $\lambda_{t_i} \leftarrow \log(\alpha_{t_i}/\sigma_{t_i})$ ▷ 网格处的半对数 SNR

$\hat{\mathbf{x}}_0 \leftarrow \hat{\mathbf{x}}_{\phi^\times}(\widetilde{\mathbf{x}}_{t_0}, t_0)$ ▷ 起点缓存

for $i \leftarrow 1$ to M **do**

  $h_i \leftarrow \lambda_{t_i} - \lambda_{t_{i-1}}$; $s_i^{\mathrm{mid}} \leftarrow t_\lambda\left(\frac{\lambda_{t_{i-1}} + \lambda_{t_i}}{2}\right)$

  $\mathbf{u}_i \leftarrow \frac{\sigma_{s_i^{\mathrm{mid}}}}{\sigma_{t_{i-1}}}\widetilde{\mathbf{x}}_{t_{i-1}} + \alpha_{s_i^{\mathrm{mid}}}(1 - e^{-h_i/2})\hat{\mathbf{x}}_{i-1}$ ▷ 预报到中点

  $\mathbf{D}_i^{\mathrm{mid}} \leftarrow \hat{\mathbf{x}}_{\phi^\times}(\mathbf{u}_i, s_i^{\mathrm{mid}})$ ▷ 中点处一次新模型调用

  $\widetilde{\mathbf{x}}_{t_i} \leftarrow \frac{\sigma_{t_i}}{\sigma_{t_{i-1}}}\widetilde{\mathbf{x}}_{t_{i-1}} - \alpha_{t_i}(e^{-h_i} - 1)\mathbf{D}_i^{\mathrm{mid}}$

  $\hat{\mathbf{x}}_i \leftarrow \hat{\mathbf{x}}_{\phi^\times}(\widetilde{\mathbf{x}}_{t_i}, t_i)$ ▷ 缓存供下一步

end for

return $\widetilde{\mathbf{x}}_{t_M}$

9.5.4 DPM-Solver++：回收历史的多步格式

高阶单步格式依赖模型输出的高阶导数，在强 CFG 下这些导数会被强烈放大而失稳. DPM-Solver++ 改用对数 SNR 时间 λ 中的多步（Adams 型）策略：复用轨迹上一小段历史的 $\mathbf{x}$-预测值，通过有限差分近似所需导数，每步仍只需一次新的模型调用.

情形 I：单历史锚点（$i=1$）. 第一步无历史，用一阶 DPM 式更新（即数据预测下的确定性 DDIM 步）. 记 $h_1=\lambda_1-\lambda_0$，

$$\widetilde{\mathbf{x}}_{t_1}=\frac{\sigma_{t_1}}{\sigma_{t_0}}\widetilde{\mathbf{x}}_{t_0}+\sigma_{t_1}e^{\lambda_0}(e^{h_1}-1)\hat{\mathbf{x}}_{\phi^\times}(\widetilde{\mathbf{x}}_{t_0},t_0).$$

情形 II：双历史锚点（$i\geq 2$）. 之后的两步多步更新复用 t_{i-2} 与 t_{i-1} 两个最近锚点 $(\lambda_{i-1},\hat{\mathbf{x}}_{\phi^\times}(\widetilde{\mathbf{x}}_{t_{i-1}},t_{i-1}))$ 与 $(\lambda_{i-2},\hat{\mathbf{x}}_{\phi^\times}(\widetilde{\mathbf{x}}_{t_{i-2}},t_{i-2}))$. 在区间 $[\lambda_{i-1},\lambda_i]$ 上把被积函数近似为 λ 的线性函数

$$\hat{\mathbf{x}}_{\phi^\times}(\hat{\mathbf{x}}_\lambda,\lambda)\approx\mathbf{L}(\lambda):=\mathbf{a}_0+\mathbf{a}_1(\lambda-\lambda_{i-1}),$$

其中 $\mathbf{a}_0,\mathbf{a}_1$ 由过两锚点的直线唯一确定. 代入积分并整理，得简洁形式

$$\widetilde{\mathbf{x}}_{t_i}=\frac{\sigma_{t_i}}{\sigma_{t_{i-1}}}\widetilde{\mathbf{x}}_{t_{i-1}}+\alpha_{t_i}(1-e^{-h_i})\mathbf{D}_i,\qquad \mathbf{D}_i=\mathbf{a}_0+\beta(h_i)\mathbf{a}_1,\quad \beta(h)=\frac{h-1+e^{-h}}{1-e^{-h}}.$$

在步长比有界的标准光滑假设下，可以进一步用具有相同局部截断误差的简化更新

$$\widetilde{\mathbf{x}}_{t_i}=\frac{\sigma_{t_i}}{\sigma_{t_{i-1}}}\widetilde{\mathbf{x}}_{t_{i-1}}+\alpha_{t_i}(1-e^{-h_i})\mathbf{D}_i^{\mathrm{sim}}(\widetilde{\mathbf{x}}_{t_{i-1}},\widetilde{\mathbf{x}}_{t_{i-2}}),\tag{9.9.5.482}$$

其中

$$\mathbf{D}_i^{\mathrm{sim}}(\widetilde{\mathbf{x}}_{t_{i-1}},\widetilde{\mathbf{x}}_{t_{i-2}}):=\left(1+\frac{1}{2}r_i\right)\hat{\mathbf{x}}_{\phi^\times}(\widetilde{\mathbf{x}}_{t_{i-1}},t_{i-1})-\frac{1}{2}r_i\hat{\mathbf{x}}_{\phi^\times}(\widetilde{\mathbf{x}}_{t_{i-2}},t_{i-2}),$$

步长比 $r_i=h_i/h_{i-1}$，局部误差 $\mathcal{O}(h_i^3)$.

注 9.5.1 (均匀步长下即经典 AB-2)**：** 若对数 SNR 步均匀（$h_i\equiv h$，$r_i=1$），则双锚点混合退化为

$$\mathbf{D}_i^{\mathrm{sim}}=\left(1+\frac{1}{2}\right)\hat{\mathbf{x}}_{i-1}-\frac{1}{2}\hat{\mathbf{x}}_{i-2}=\frac{3}{2}\hat{\mathbf{x}}_{i-1}-\frac{1}{2}\hat{\mathbf{x}}_{i-2}.$$

权重 $(\frac{3}{2},-\frac{1}{2})$ 正是均匀步下 Adams–Bashforth 二阶的系数，即标准两步线性多步系数.◇

9.6 PF–ODE 求解器族及其数值对应

本节把前面介绍的 PF–ODE 采样器放回经典数值分析的坐标系，并比较两个代表性高阶求解器 DEIS 与 DPM-Solver++.

Algorithm 7 DPM-Solver++(2M)

Input: initial value $\mathbf{x}_T$, time steps $\{t_i\}_{i=0}^{M}$, model $\hat{\mathbf{x}}_{\phi\times}$

$\widetilde{\mathbf{x}}_{t_0} \leftarrow \mathbf{x}_T$; $\lambda_{t_i} \leftarrow \log(\alpha_{t_i}/\sigma_{t_i})$; $h_i \leftarrow \lambda_{t_i} - \lambda_{t_{i-1}}$

$\hat{\mathbf{x}}_0 \leftarrow \hat{\mathbf{x}}_{\phi\times}(\widetilde{\mathbf{x}}_{t_0}, t_0)$ ▷ 起点缓存

情形 I： 单锚点预热（$i=1$，即 $\mathbf{x}$-预测下的 DDIM）

$\widetilde{\mathbf{x}}_{t_1} \leftarrow \frac{\sigma_{t_1}}{\sigma_{t_0}}\widetilde{\mathbf{x}}_{t_0} - \alpha_{t_1}(e^{-h_1}-1)\hat{\mathbf{x}}_0$

$\hat{\mathbf{x}}_1 \leftarrow \hat{\mathbf{x}}_{\phi\times}(\widetilde{\mathbf{x}}_{t_1}, t_1)$ ▷ 一次模型调用并缓存

情形 II： 复用两个历史锚点（多步）

for $i \leftarrow 2$ to M **do**

  $r_i \leftarrow h_i/h_{i-1}$ ▷ 步长比

  $\mathbf{D}_i^{\mathrm{sim}} \leftarrow \left(1+\frac{1}{2}r_i\right)\hat{\mathbf{x}}_{i-1} - \frac{1}{2}r_i\hat{\mathbf{x}}_{i-2}$

  $\widetilde{\mathbf{x}}_{t_i} \leftarrow \frac{\sigma_{t_i}}{\sigma_{t_{i-1}}}\widetilde{\mathbf{x}}_{t_{i-1}} + \alpha_{t_i}(1-e^{-h_i})\mathbf{D}_i^{\mathrm{sim}}$

  $\hat{\mathbf{x}}_i \leftarrow \hat{\mathbf{x}}_{\phi\times}(\widetilde{\mathbf{x}}_{t_i}, t_i)$ ▷ 一次模型调用并缓存

end for

return $\widetilde{\mathbf{x}}_{t_M}$

9.6.1 PF–ODE 求解器族与经典对应

一旦线性漂移由积分因子精确处理，每个采样器都自然对应一种经典步进格式：Euler 型、Adams–Bashforth（AB）多步、或 Runge–Kutta（RK）单步. 表 9 汇总了这些对应.

特别地，对固定调度 (α_t, σ_t)，无论用对数 SNR 时间还是原物理时间，都有

$$\mathbf{v}\text{-prediction：}\quad \text{DDIM} = \text{DPM-Solver-1} = \text{DEIS-1} = \text{Euler},$$

$$\boldsymbol{\epsilon}\text{-、}\mathbf{x}\text{- 或}\mathbf{s}\text{-prediction：}\quad \text{DDIM} = \text{DPM-Solver-1} = \text{DEIS-1} = \text{exp Euler}.$$

推广到二阶，即 9.4.5 节的结论：

$$\mathbf{v}\text{-prediction：}\quad \text{DPM-Solver-2} = \text{Heun},$$

$$\boldsymbol{\epsilon}\text{-、}\mathbf{x}\text{- 或}\mathbf{s}\text{-prediction：}\quad \text{DPM-Solver-2} = \text{exp-Heun} \neq \text{plain Heun}.$$

9.6.2 关于 DEIS 与 DPM-Solver++ 的讨论

表 10 从几个维度比较二者.

DEIS 与 DPM-Solver++. 二者都是把线性部分精确积分、残差积分用低次多项式近似的指数积分子采样器. 无约束生成时，二者都能用 10–20 步达到高保真；但带 CFG 的条件生成中，DPM++ 因大引导下更稳定而常被优先选用.

DEIS. 它是一种多步方法，在 Lagrange 基下用跨历史节点的多项式拟合非线性项（穿过锚点插值）.

表 9: PF–ODE 采样器及其数值分析对应.“exp.” 表示对线性项采用积分因子（半线性）处理（见式 (9.9.1.463)）. AB = Adams–Bashforth, RK = Runge–Kutta. DPM-Solver-2 见算法 5.

PF–ODE 求解器	**类型**	**经典数值对应**
DDIM	单步	$\mathbf{v}$-prediction：普通 Euler；$\boldsymbol{\epsilon}/\mathbf{x}/\mathbf{s}$-prediction：指数 Euler
DEIS	多步	exp. AB（n 阶）
DPM-Solver-n	单步	对数 SNR 下 exp. RK（n 阶）
DPM-Solver-2	单步	$\mathbf{v}$-prediction：对数 SNR 下普通 Heun（二阶）； $\boldsymbol{\epsilon}/\mathbf{x}/\mathbf{s}$-prediction：对数 SNR 下 exp. Heun（二阶）
DPM-Solver++ 2S	单步	exp. RK（二阶）
DPM-Solver++ 2M	多步	exp. AB（二阶）

DPM-Solver++. 它在对数 SNR 时间中处理数据预测：单步（2S）变体用一个中间估值作 Taylor/指数积分步；多步 (2M) 变体通过向后差商回收历史，产生同一插值多项式但写在 Newton（有限差）基下. 换言之，对相同锚点与函数值，Lagrange 与 Newton 只是同一插值多项式的两套坐标：Lagrange 写成函数值乘基函数之和，Newton 写成带差商系数的乘积展开（差商比易于在多步格式中递推更新）. DPM++ 论文强调二阶 (2S/2M)；更高阶多步原则上可用高阶 Newton 基构造.

9.7 （可选）DPM-Solver-v3

DPM-Solver 与 DPM-Solver++ 都基于特定的模型参数化（$\boldsymbol{\epsilon}$- 或 $\mathbf{x}$-prediction）来设计求解器，缺乏选择参数化的有原则方法. DPM-Solver-v3（Zheng 等, 2023）针对这一问题，通过引入自由变量并离线最小化离散化误差，进一步提升少步、大引导下的样本质量，可视为整个 DPM-Solver 家族（Lu 等, 2022b；Lu 等, 2022c）思想的集大成.

其核心是：在式 (9.9.4.470)

$$\frac{\mathrm{d}\mathbf{x}_\lambda}{\mathrm{d}\lambda} = \frac{\alpha'_\lambda}{\alpha_\lambda}\mathbf{x}_\lambda - \sigma_\lambda \hat{\boldsymbol{\epsilon}}_{\phi^\times}(\mathbf{x}_\lambda, \lambda)$$

中引入三个欠定/自由变量，使原 ODE 解能等价地改写为新的模型参数化；再在预训练模型上高效搜索这些变量的最优取值，目标是最小化离散化误差.

9.7.1 洞见一：调整式 (9.9.4.470) 中的线性项

PF–ODE 是刚性 ODE，各方向时间尺度差异显著. 借鉴经典刚性 ODE 理论 (Hochbruck 与 Ostermann, 2010)，Zheng 等（2023）提议修改 ODE 的线性部分以更好处理刚性. 从抽象形式

$$\frac{\mathrm{d}\mathbf{x}_\lambda}{\mathrm{d}\lambda} = \mathbf{v}(\mathbf{x}_\lambda, \lambda)$$

方面	DEIS	DPM++
核心观点	指数积分子：精确积分线性项；用历史节点上的多项式近似非线性残差	同一积分子思想；在对数 SNR 时间 λ 中以数据预测形式表述
步型	仅多步	单步（2S）与多步（2M）
多项式基	跨历史锚点的 Lagrange 插值（高阶多步）	向后差商（Newton/Adams 型）；在 λ 时间中与 2M 张成同一多项式空间，但不作为 Lagrange 拟合
阶数	高阶多步（一般 r）	存在高阶单步方法（以 2S 为主），并给出二阶多步（2M）；更高阶多步变体未涵盖
历史使用	用 $r+1$ 次历史估值构造高阶更新	2S：一次中间估值（单步）；2M：复用两个锚点，预热后每步一次模型调用

表 10: DEIS 与 DPM-Solver++（DPM++）的对比.

出发，“Rosenbrock 型指数积分子” 把向量场分解为 $\mathbf{v}(\mathbf{x},\lambda)=\mathbf{L}\mathbf{x}+\mathbf{N}(\mathbf{x},\lambda)$，其中 $\mathbf{L}$ 是可灵活选取的线性算子. 对应更新为

$$\widetilde{\Psi}_{\lambda_s\to\lambda_t}(\mathbf{x}_{\lambda_s})=e^{h\mathbf{L}}\mathbf{x}_{\lambda_s}+\int_{\lambda_s}^{\lambda_t}e^{(\lambda_t-\tau)\mathbf{L}}\mathbf{N}(\mathbf{x}_\tau,\tau)\,\mathrm{d}\tau,\qquad \Delta h:=\lambda_t-\lambda_s.$$

把这一想法用于式 (9.9.4.470)，把它重写为

$$\frac{\mathrm{d}\mathbf{x}_\lambda}{\mathrm{d}\lambda}=\underbrace{\left(\frac{\alpha_\lambda'}{\alpha_\lambda}-\ell_\lambda\right)}_{\text{线性部分}}\mathbf{x}_\lambda-\underbrace{\left(\sigma_\lambda\hat{\boldsymbol{\epsilon}}_{\phi^\times}(\mathbf{x}_\lambda,\lambda)-\ell_\lambda\mathbf{x}_\lambda\right)}_{\text{非线性部分}}. \tag{9.9.7.483}$$

这里 ℓ_λ 是一个只依赖 λ 的 D 维自由/欠定变量. 记

$$\mathbf{L}(\lambda):=\frac{\alpha_\lambda'}{\alpha_\lambda}-\ell_\lambda,\qquad \mathbf{N}_{\phi^\times}(\mathbf{x}_\lambda,\lambda):=\sigma_\lambda\hat{\boldsymbol{\epsilon}}_{\phi^\times}(\mathbf{x}_\lambda,\lambda)-\ell_\lambda\mathbf{x}_\lambda. \tag{9.9.7.484}$$

Zheng 等（2023）提议通过求解下面的最小二乘问题来选 ℓ_λ：

$$\ell_\lambda^\star=\arg\min_{\ell_\lambda}\mathbb{E}_{\mathbf{x}_\lambda\sim p_\lambda^{\phi^\times}(\mathbf{x}_\lambda)}\left\|\nabla_{\mathbf{x}}\mathbf{N}_{\phi^\times}(\mathbf{x}_\lambda,\lambda)\right\|_F^2, \tag{9.9.7.485}$$

其中 $\|\cdot\|_F$ 为 Frobenius 范数，$p_\lambda^{\phi^\times}$ 为轨迹在 λ 处的样本边缘分布. 该问题有解析解. 直观上，这利用预训练模型的预处理信息，使 $\mathbf{N}_{\phi^\times}$ 对 $\mathbf{x}$ 误差更不敏感（其 Lipschitz 常数近似为 $\mathbf{x}$ 梯度），并抵消 $\mathbf{N}_{\phi^\times}$ 的 “线性”.

9.7.2 洞见二：在模型参数化中引入自由变量以进一步减小离散化误差

考虑经验 PF–ODE 的抽象半线性形式

$$\frac{\mathrm{d}\mathbf{x}_\lambda}{\mathrm{d}\lambda} = \mathbf{L}(\lambda)\mathbf{x}_\lambda + \mathbf{N}_{\phi^\times}(\mathbf{x}_\lambda, \lambda). \tag{9.9.7.486}$$

区间 $[\lambda_s, \lambda_t]$ 上的精确解由常数变易公式给出：

$$\widetilde{\Psi}_{\lambda_s\to\lambda_t}(\mathbf{x}_{\lambda_s}) = \mathcal{E}(\lambda_s \to \lambda_t)\mathbf{x}_{\lambda_s} + \int_{\lambda_s}^{\lambda_t} \mathcal{E}(\lambda \to \lambda_s)\mathbf{N}_{\phi^\times}(\mathbf{x}_\lambda, \lambda)\,\mathrm{d}\lambda, \tag{9.9.7.487}$$

其中 $\mathcal{E}(s \to t) := e^{-\int_s^t \mathbf{L}(u)\,\mathrm{d}u}$. 用 $\mathbf{N}_{\phi^\times}(\mathbf{x}_{\lambda_s}, \lambda_s) \approx \mathbf{N}_{\phi^\times}(\mathbf{x}_\lambda, \lambda)$ 近似可得近似解；二者相减并对 $\mathbf{N}_{\phi^\times}(\mathbf{x}_{\lambda_s}, \lambda_s)$ 作 Taylor 展开，可量化一阶离散化误差正比于 $\int_{\lambda_s}^{\lambda_t} \mathcal{E}(\lambda \to \lambda_s)(\lambda_s - \lambda)\mathbf{N}^{(1)}_{\phi^\times}(\mathbf{x}_\lambda, \lambda)\,\mathrm{d}\lambda + \mathcal{O}(h^3)$.

为减小该误差，Zheng 等（2023）用新参数化 $\mathbf{N}^{\mathrm{new}}_{\phi^\times}(\mathbf{x}_\lambda, \lambda)$ 改写式 (9.9.7.487)，使误差项保持相似结构，并要求新非线性项的 λ 导数满足

$$\mathbf{N}^{\mathrm{new},(1)}_{\phi^\times}(\mathbf{x}_\lambda, \lambda) \propto \mathbf{N}^{(1)}_{\phi^\times}(\mathbf{x}_\lambda, \lambda) - \big(\mathbf{a}_\lambda \mathbf{N}_{\phi^\times}(\mathbf{x}_\lambda, \lambda) + \mathbf{b}_\lambda\big), \tag{9.9.7.488}$$

其中 $\mathbf{a}_\lambda, \mathbf{b}_\lambda$ 为自由变量. 目标是通过求解

$$(\mathbf{a}^\star_\lambda, \mathbf{b}^\star_\lambda) = \arg\min_{\mathbf{a}_\lambda, \mathbf{b}_\lambda} \mathbb{E}_{\mathbf{x}_\lambda \sim p^{\phi^\times}_\lambda}\left[\left\|\mathbf{N}^{(1)}_{\phi^\times}(\mathbf{x}_\lambda, \lambda) - (\mathbf{a}_\lambda \mathbf{N}_{\phi^\times}(\mathbf{x}_\lambda, \lambda) + \mathbf{b}_\lambda)\right\|_2^2\right] \tag{9.9.7.489}$$

来最小化离散化误差. 该最小二乘问题有解析解，可离线预计算.

具体地，引入线性变换

$$\mathbf{N}^{\mathrm{new}}_{\phi^\times}(\mathbf{x}_\lambda, \lambda) := e^{-\int_{\lambda_s}^{\lambda} \mathbf{a}_u\,\mathrm{d}u}\mathbf{N}_{\phi^\times}(\mathbf{x}_\lambda, \lambda) - \int_{\lambda_s}^{\lambda} e^{-\int_{\lambda_s}^{r} \mathbf{a}_u\,\mathrm{d}u}\mathbf{b}_r\,\mathrm{d}r, \tag{9.9.7.490}$$

其 λ 导数恰取式 (9.9.7.488) 的形式. 代入后，式 (9.9.7.487) 与近似解相减，可将离散化误差化简为只含 $\mathbf{N}^{\mathrm{new},(1)}_{\phi^\times}$ 的项；于是解式 (9.9.7.489) 即有效最小化误差.

9.7.3 综合两个洞见

理论上的流程. 对任意 λ，先解析求解式 (9.9.7.485) 得 $\ell^\star_\lambda$；再在 $\ell_\lambda = \ell^\star_\lambda$ 固定下解析求解式 (9.9.7.489) 得 $(\mathbf{a}^\star_\lambda, \mathbf{b}^\star_\lambda)$. 由此得到的 $\widetilde{\mathbf{x}}_{\lambda_t}$ 即 $\widetilde{\Psi}_{\lambda_s\to\lambda_t}(\mathbf{x}_{\lambda_s})$ 的所需估计.

实现考量. 尽管 $\ell^\star_\lambda, \mathbf{a}^\star_\lambda, \mathbf{b}^\star_\lambda$ 的解析解涉及预训练扩散模型 $\boldsymbol{\epsilon}_{\phi^\times}$ 的 Jacobian–向量积（见 Zheng 等, 2023 附录 C.1.1），其期望需在 $p^{\phi^\times}_\lambda$ 上估计. 实践中用 Monte Carlo：抽取约 1K–4K 个数据点 $\mathbf{x}_\lambda \sim p^{\phi^\times}_\lambda$（例如用 200 步 DPM-Solver++（Lu 等, 2022c）跑式 (9.9.4.470)），相关项解析计算. 这些统计量均可预计算，从而在实际应用 DPM-Solver-v3 时避免额外开销.

9.7.4 高阶 DPM-Solver-v3

预计算的 $\ell_\lambda^\star, \mathbf{a}_\lambda^\star, \mathbf{b}_\lambda^\star$ 虽由一阶离散化误差导出，也可用于构造高阶求解器. 对式 (9.9.7.487) 的 $(n+1)$ 阶近似，对 $\mathbf{N}_{\phi^\times}^{\text{new}}(\mathbf{x}_\lambda, \lambda)$ 在 λ_s 处作 n 阶 Taylor 展开，忽略 $\mathcal{O}((\lambda_s-\lambda)^{n+1})$ 项，得

$$\widetilde{\mathbf{x}}_{\lambda_t} = \mathcal{E}(\lambda_s \to \lambda_t)\mathbf{x}_{\lambda_s} + \int_{\lambda_s}^{\lambda_t} \mathbf{E}(\lambda_s \to \lambda)\mathbf{B}(\lambda_s \to \lambda)\,\mathrm{d}\lambda + \sum_{k=0}^{n} \mathbf{N}_{\phi^\times}^{\text{new},(k)}(\mathbf{x}_{\lambda_s}, \lambda_s) \int_{\lambda_s}^{\lambda_t} \mathbf{E}(\lambda_s \to \lambda)\frac{(\lambda-\lambda_s)^k}{k!}\,\mathrm{d}\lambda \tag{9.9.7.491}$$

其中 $\mathbf{E}(\lambda_s \to \lambda) := \mathcal{E}(\lambda_s \to \lambda)e^{\int_{\lambda_s}^{\lambda} \mathbf{a}_u^\star\,\mathrm{d}u}$，$\mathbf{B}$ 含 $\mathbf{b}_r^\star$. 仿照 9.4.3 节，用前 $n+1$ 步 $\lambda_{i_n}, \ldots, \lambda_{i_1}, \lambda_{i_0} := \lambda_s$ 上的有限差分估计各阶导数.

例：估计高阶导数（$n=2$）. 用 3 个时刻 $\lambda_{i_2}, \lambda_{i_1}, \lambda_s$ 估计 $k=1,2$ 阶导数. 令 $\delta_k = \lambda_{i_k} - \lambda_s$，在 $\lambda = \lambda_{i_1}, \lambda_{i_2}$ 处展开并整理，得线性系统

$$\begin{bmatrix} \delta_1 & \delta_1^2 \\ \delta_2 & \delta_2^2 \end{bmatrix} \begin{bmatrix} \widetilde{\mathbf{N}}_{\phi^\times}^{\text{new},(1)}(\mathbf{x}_{\lambda_s}, \lambda_s)/1! \\ \widetilde{\mathbf{N}}_{\phi^\times}^{\text{new},(2)}(\mathbf{x}_{\lambda_s}, \lambda_s)/2! \end{bmatrix} = \begin{bmatrix} \mathbf{N}_{\phi^\times}^{\text{new}}(\mathbf{x}_{\lambda_{i_1}}, \lambda_{i_1}) - \mathbf{N}_{\phi^\times}^{\text{new}}(\mathbf{x}_{\lambda_s}, \lambda_s) \\ \mathbf{N}_{\phi^\times}^{\text{new}}(\mathbf{x}_{\lambda_{i_2}}, \lambda_{i_2}) - \mathbf{N}_{\phi^\times}^{\text{new}}(\mathbf{x}_{\lambda_s}, \lambda_s) \end{bmatrix}. \tag{9.9.7.492}$$

记 $\mathbf{R}_2 = \begin{bmatrix} \delta_1 & \delta_1^2 \\ \delta_2 & \delta_2^2 \end{bmatrix}$，右端为 $\mathbf{b}$，则近似导数 $= \mathbf{R}_2^{-1}\mathbf{b}$. 一般 n 阶对应反转 Vandermonde 矩阵 $\mathbf{R}_n$ 解析求解. 最终近似解仍记作 $\widetilde{\mathbf{x}}_{\lambda_t}$：

$$\widetilde{\mathbf{x}}_{\lambda_t} = \mathcal{E}(\lambda_s \to \lambda_t)\mathbf{x}_{\lambda_s} + \int_{\lambda_s}^{\lambda_t} \mathbf{E}(\lambda_s \to \lambda)\mathbf{B}(\lambda_s \to \lambda)\,\mathrm{d}\lambda + \sum_{k=0}^{n} \widetilde{\mathbf{N}}_{\phi^\times}^{\text{new},(k)}(\mathbf{x}_{\lambda_s}, \lambda_s) \int_{\lambda_s}^{\lambda_t} \mathbf{E}(\lambda_s \to \lambda)\frac{(\lambda-\lambda_s)^k}{k!}\,\mathrm{d}\lambda \tag{9.9.7.493}$$

9.7.5 DPM-Solver-v3 的更多解读

最小化一阶误差有助于高阶求解器. $\mathbf{a}_\lambda^\star, \mathbf{b}_\lambda^\star$ 虽由减小一阶离散化误差导出，理论上也有助于控制高阶误差.

命题 9.7.1 (减小一阶离散化误差有助于高阶求解器)**：** 从同一初值 $\mathbf{x}_{\lambda_s}$ 出发，近似解 $\widetilde{\mathbf{x}}_{\lambda_t}$（按上式定义）与精确解 $\widetilde{\Psi}_{\lambda_s \to \lambda_t}(\mathbf{x}_{\lambda_s})$（按式 (9.9.7.487)）之差为

$$\begin{aligned} \widetilde{\mathbf{x}}_{\lambda_t} - \widetilde{\Psi}_{\lambda_s \to \lambda_t}(\mathbf{x}_{\lambda_s}) = &\int_{\lambda_s}^{\lambda_t} \left(\int_{\lambda_s}^{\lambda} \mathbf{N}_{\phi^\times}^{\text{new},(1)}(\mathbf{x}_u, u)\,\mathrm{d}u \right) \mathbf{E}(\lambda_s \to \lambda)\,\mathrm{d}\lambda \\ &+ \sum_{k=1}^{n} \left(\sum_{j=1}^{n} (\mathbf{R}_n^{-1})_{kj} \int_{\lambda_s}^{\lambda_{i_j}} \mathbf{N}_{\phi^\times}^{\text{new},(1)}(\mathbf{x}_\lambda, \lambda)\,\mathrm{d}\lambda \right) \int_{\lambda_s}^{\lambda_t} \mathbf{E}(\lambda_s \to \lambda)\frac{(\lambda-\lambda_s)^k}{k!}\,\mathrm{d}\lambda. \end{aligned}$$

命题证明： 把精确解写成

$$\widetilde{\Psi}_{\lambda_s \to \lambda_t}(\mathbf{x}_{\lambda_s}) = \mathcal{E}(\lambda_s \to \lambda_t)\mathbf{x}_{\lambda_s} + \int_{\lambda_s}^{\lambda_t} \mathbf{E}(\lambda_s \to \lambda)\mathbf{B}(\lambda_s \to \lambda)\,\mathrm{d}\lambda + \int_{\lambda_s}^{\lambda_t} \mathbf{N}_{\phi^\times}^{\text{new}}(\mathbf{x}_\lambda, \lambda)\mathbf{E}(\lambda_s \to \lambda)\,\mathrm{d}\lambda.$$

与近似解相减，并利用微积分基本定理把 $\mathbf{N}_{\phi^\times}^{\text{new}}(\mathbf{x}_\lambda, \lambda) - \mathbf{N}_{\phi^\times}^{\text{new}}(\mathbf{x}_{\lambda_s}, \lambda_s)$ 写成导数的积分，再代入 $\widetilde{\mathbf{N}}^{\text{new},(k)} = \sum_j (\mathbf{R}_n^{-1})_{kj}(\mathbf{N}^{\text{new}}(\mathbf{x}_{\lambda_{i_j}}, \lambda_{i_j}) - \mathbf{N}^{\text{new}}(\mathbf{x}_{\lambda_s}, \lambda_s))$，即得所证. □

由此及式 (9.9.7.490)，在充分光滑假设下控制 $\|\mathbf{N}_{\phi^\times}^{\mathrm{new},(1)}\|_2$ 即可减小整体离散化误差.

广义参数化 $\mathbf{N}_{\phi^\times}^{\mathrm{new}}$ 的表达力. 综合式 (9.9.7.484) 与 (9.9.7.490)，可把 $\mathbf{N}_{\phi^\times}^{\mathrm{new}}$ 写成

$$\begin{aligned}\mathbf{N}_{\phi^\times}^{\mathrm{new}}(\mathbf{x}_\lambda,\lambda) = \sigma_\lambda e^{-\int_{\lambda_s}^{\lambda}\mathbf{a}_u\,\mathrm{d}u}\hat{\boldsymbol{\epsilon}}_{\phi^\times}(\mathbf{x}_\lambda,\lambda) - \ell_\lambda e^{-\int_{\lambda_s}^{\lambda}\mathbf{a}_u\,\mathrm{d}u}\mathbf{x}_\lambda \\ - \int_{\lambda_s}^{\lambda} e^{-\int_{\lambda_s}^{r}\mathbf{a}_u\,\mathrm{d}u}\mathbf{b}_r\,\mathrm{d}r,\end{aligned} \tag{9.9.7.494}$$

概念上形如

$$\mathbf{T}_{\phi^\times}(\mathbf{x}_\lambda,\lambda) := \alpha(\lambda)\hat{\boldsymbol{\epsilon}}_{\phi^\times}(\mathbf{x}_\lambda,\lambda) + \beta(\lambda)\mathbf{x}_\lambda + \gamma(\lambda). \tag{9.9.7.495}$$

即对固定 λ，$\mathbf{N}_{\phi^\times}^{\mathrm{new}}$ 是原模型经一个依赖 λ_s 的线性变换得到的.

9.7.6 DPM-Solver-v3 与其他方法的联系

$\mathbf{N}_{\phi^\times}^{\mathrm{new}}$ 是一般参数化. 把 DPM-Solver-v3 与先前 ODE 形式比较可知，$\boldsymbol{\epsilon}$- 与 $\mathbf{x}$-prediction 都是其特例：

- $\boldsymbol{\epsilon}$-prediction：$(\ell_\lambda,\mathbf{a}_\lambda,\mathbf{b}_\lambda) = (\mathbf{0}_D,-\mathbf{1}_D,\mathbf{0}_D)$；
- $\mathbf{x}$-prediction：$(\ell_\lambda,\mathbf{a}_\lambda,\mathbf{b}_\lambda) = (\mathbf{1}_D,\mathbf{0}_D,\mathbf{0}_D)$.

一阶离散化即改进的 DDIM. 由于 $\mathbf{N}_{\phi^\times}^{\mathrm{new}}$ 既非纯噪声也非纯数据参数化，而是以最小化一阶离散误差为目标的改进参数化，其一阶 DPM-Solver-v3 更新

$$\mathbf{x}_{t_{i-1}\to t_i} = \frac{\alpha_{t_i}}{\alpha_{t_{i-1}}}\widetilde{\mathbf{x}}_{t_{i-1}} - \alpha_{t_i}\left(\frac{\sigma_{t_{i-1}}}{\alpha_{t_{i-1}}} - \frac{\sigma_{t_i}}{\alpha_{t_i}}\right)\boldsymbol{\epsilon}_{\phi^\times}(\widetilde{\mathbf{x}}_{t_{i-1}},t_{i-1})$$

正是一个改进版的 DDIM.

9.8 （可选）ParaDiGMS

前面的方法都是时间步进（time-stepping）求解器：从 T 到 0 严格串行地一步步演化. ParaDiGMS（Parallel Diffusion Models，Wang 等, 2023）则借助经典 Picard 迭代实现时间并行积分，以计算资源换取更快的模拟.

9.8.1 从时间步进走向时间并行求解器

记经验 PF–ODE 漂移为

$$\mathbf{v}_{\phi^\times}(\mathbf{x},t) := \mathbf{f}(\mathbf{x},t) - \frac{1}{2}g^2(t)\mathbf{s}_{\phi^\times}(\mathbf{x},t).$$

从 T 到任意中间时刻 t 的精确演化是

$$\widetilde{\Psi}_{T\to t}(\mathbf{x}(T)) = \mathbf{x}(T) + \int_T^t \mathbf{v}_{\phi^\times}(\mathbf{x}(\tau),\tau)\,\mathrm{d}\tau, \qquad \mathbf{x}(T)\sim p_{\mathrm{prior}}. \tag{9.9.8.496}$$

时间步进格式用基于过去时刻的离散更新来近似该积分. ParaDiGMS 的核心思想则是: 用计算资源换取更快模拟，把整个轨迹作为待求对象，通过不动点迭代并行推进所有时间节点.

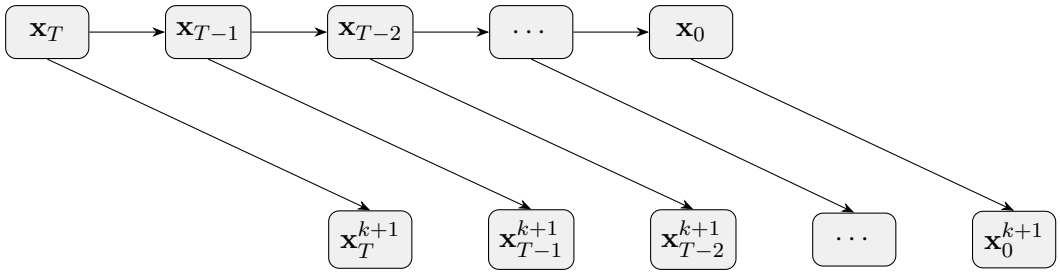


图 9.42: 两种计算图的比较（原书 Figure 9.4）. 左: 传统时间步进 ODE 求解，解沿时间顺序传播; 右: Picard 迭代，用上一轮迭代的结果同时更新所有时间节点，从而避免时间步进的严格串行性，实现并行计算.

如图 9.42（原书 Figure 9.4）所示，左图是严格串行的链状依赖，右图则是上下两层节点间的 “跳跃” 依赖——所有下层节点可并行更新.

9.8.2 ParaDiGMS 的方法

从轨迹到作为不动点更新的 Picard 迭代. 式 (9.9.8.496) 可看作一个把整条轨迹映到新轨迹的算子. 形式上，对候选轨迹 $\{\mathbf{y}(\tau)\}_{\tau\in[0,T]}$，定义算子

$$(\mathcal{L}[\mathbf{y}(\cdot)])(t) = \mathbf{y}(T) + \int_T^t \mathbf{v}_{\phi^\times}(\mathbf{y}(\tau),\tau)\,\mathrm{d}\tau, \qquad t\in[0,T].$$

PF–ODE 的真解轨迹 $\mathbf{x}^\star(\cdot)$ 恰是 $\mathcal{L}$ 的不动点:

$$\mathbf{x}^\star(t) = \mathcal{L}[\mathbf{x}^\star(\cdot)](t) \iff \mathbf{x}^\star(t) = \mathbf{x}^\star(T) + \int_T^t \mathbf{v}_{\phi^\times}(\mathbf{x}^\star(\tau),\tau)\,\mathrm{d}\tau.$$

基于算子 $\mathcal{L}$，用逐次代入（Picard 迭代）求不动点: 从初值 $\mathbf{x}^{(0)}(\cdot)$（实践中取常数路径 $\mathbf{x}^{(0)}(t)\equiv\mathbf{x}^{(0)}(T)\sim p_{\text{prior}}$）出发，

$$\mathbf{x}^{(k+1)}(t) = \mathcal{L}[\mathbf{x}^{(k)}(\cdot)](t) = \mathbf{x}^{(k)}(T) + \int_T^t \mathbf{v}_{\phi^\times}(\mathbf{x}^{(k)}(\tau),\tau)\,\mathrm{d}\tau, \qquad k=0,1,2,\ldots \tag{9.9.8.497}$$

该式始终以先验状态 $\mathbf{x}^{(k)}(T)$ 为锚，再从 T 向 t 反向累积漂移.

T 到 0 网格上的离散 Picard. 取均匀递减网格，步长 $\Delta t := T/M$，定义

$$t_j := T - j\Delta t, \qquad j=0,1,\ldots,M,$$

于是 $t_0 = T$、$t_M = 0$. 记采样迭代值 $\mathbf{x}_j^{(k)} := \mathbf{x}^{(k)}(t_j)$. 因网格时间反向，积分 $\int_T^{t_j}$ 取向为负; 在分划 $\{[t_{i+1},t_i]\}_{i=0}^{j-1}$ 上用左端点近似，得

$$\int_T^{t_j} \mathbf{v}_{\phi^\times}(\mathbf{x}^{(k)}(\tau),\tau)\,\mathrm{d}\tau \approx -\Delta t\sum_{i=0}^{j-1} \mathbf{v}_{\phi^\times}(\mathbf{x}_{t_i}^{(k)},t_i).$$

代入式 (9.9.8.497)，得离散 Picard 更新

$$\mathbf{x}_j^{(k+1)} = \mathbf{x}_0^{(k)} - \Delta t \underbrace{\sum_{i=0}^{j-1} \mathbf{v}_{\phi\times}(\mathbf{x}_i^{(k)}, t_i)}_{\text{漂移累积和}}, \qquad j = 1, \dots, M. \tag{9.9.8.498}$$

该格式简单且并行友好：每个漂移估值 $\mathbf{v}_{\phi\times}(\mathbf{x}_i^{(k)}, t_i)$ 只依赖同一时间节点上一轮的迭代值，因而所有 $i = 0, \dots, j-1$ 可跨网格独立计算；积分再由累积和（串行或并行前缀和/滑动窗口）恢复.

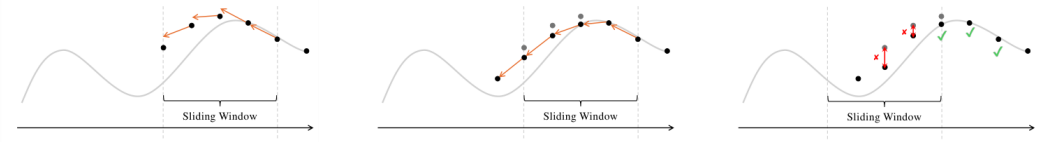


图 9.43: 滑动窗口示意（原书 Figure 9.5–9.7）. 左：在大小 $p = 4$ 的批量窗口上并行计算 $\mathbf{x}_{\ell:\ell+p}^{(k)}$ 的漂移；中：用窗口内各点漂移的累积值更新 $\mathbf{x}_{\ell:\ell+p}^{(k+1)}$；右：按误差 $\|\mathbf{x}_i^{(k+1)} - \mathbf{x}_i^{(k)}\|^2$ 决定窗口向前滑动多远.

滑动窗口与并行估值. 式 (9.9.8.498) 把每个 $\mathbf{x}_j^{(k+1)}$ 表为左锚值减漂移累积和. 为限制内存并利用并行硬件，在短的滑动指标块上局部施加同一思想. 固定窗口长 p 与左端点 ℓ，窗口覆盖 $j = \ell, \dots, \ell + p$，$t_\ell > t_{\ell+1} > \cdots > t_{\ell+p}$. 迭代 k 时：

步 1：窗口上的并行漂移估值. 只用上一轮迭代值，并行计算

$$\mathbf{v}_{\phi\times}(\mathbf{x}_{\ell+i}^{(k)}, t_{\ell+i}), \qquad i = 0, 1, \dots, p-1.$$

步 2：左锚累积更新. 以 $j = \ell$ 为锚、跨子区间累积漂移：

$$\mathbf{x}_{\ell+j+1}^{(k+1)} = \mathbf{x}_\ell^{(k)} - \Delta t \sum_{i=0}^{j} \mathbf{v}_{\phi\times}(\mathbf{x}_{\ell+i}^{(k)}, t_{\ell+i}), \qquad j = 0, 1, \dots, p-1. \tag{9.9.8.499}$$

内层求和即窗口漂移上的前缀和（scan），所有部分和可在并行硬件上高效产出.

步 3：进度控制与窗口推进. 用逐点 Picard 变化度量局部收敛：

$$\text{error}_j := \left\|\mathbf{x}_{\ell+j}^{(k+1)} - \mathbf{x}_{\ell+j}^{(k)}\right\|^2, \qquad j = 1, \dots, p-1,$$

与预设容差 $\text{tol}_{\ell+j}$ 比较. error_j 小表示两次相邻逼近一致、该节点局部收敛；大则表示尚未稳定、需更多 Picard 平滑. 步幅取窗口内首个未通过检验的指标（若全部通过则取整窗长 p）：

$$\text{stride} := \min\left(\{j \geq 1 : \text{error}_j > \text{tol}_{\ell+j}\} \cup \{p\}\right).$$

随后令 $\ell \leftarrow \ell + \text{stride}$ 滑动窗口：接受从左端点到（不含）首个未收敛节点为止的所有节点；若全部收敛则接受整窗. 若滑动将越过网格末端 M，则把窗口截断为 $p \leftarrow \min\{p, M - \ell\}$ 后继续. 窗口前移后会暴露尚无值的新时间节点；以窗口左边界的值作 “常数外推” 作为初值，留待后续更新校正（也可换成线性或多项式外推）.

完整流程见算法 8.

Algorithm 8 滑动窗口版 ParaDiGMS

Input: 漂移 $\mathbf{v}_{\phi^\times}(\mathbf{x}, t)$；网格 $\{t_j\}_{j=0}^{M}$；窗口长 p；容差 $\{\mathrm{tol}_j\}_{j=1}^{M}$

Output: 近似轨迹 $\{\mathbf{x}_j^{(k)}\}_{j=0}^{M}$（$\mathbf{x}_M^{(k)}$ 在 $t=0$ 处）

$k \leftarrow 0,\ \ell \leftarrow 0$

采样 $\mathbf{x}_0^{(0)} \sim p_{\text{prior}}$；置 $\mathbf{x}_j^{(0)} \leftarrow \mathbf{x}_0^{(0)},\ j = 1, \dots, \min(p, M)$ ▷ 常数外推

while $\ell < M$ **do**

  $J \leftarrow \min(p, M - \ell)$ ▷ 当前窗口长

  步 1： 并行

  For $i = 0, \dots, J-1$：$g_i \leftarrow \mathbf{v}_{\phi^\times}(\mathbf{x}_{\ell+i}^{(k)}, t_{\ell+i})$ ▷ 上一轮迭代值的漂移（Picard 冻结）

  计算前缀和 $S_j \leftarrow \sum_{i=0}^{j} g_i,\ j = 0, \dots, J-1$ ▷ 窗口漂移的 scan

  步 2： 累积更新

  For $j = 0, \dots, J-1$：$\mathbf{x}_{\ell+j+1}^{(k+1)} \leftarrow \mathbf{x}_\ell^{(k)} - \Delta t S_j$ ▷ 左锚更新，见式 (9.9.8.499)

  步 3： 进度控制与窗口推进

  For $j = 1, \dots, J-1$：$\mathrm{error}_j \leftarrow \|\mathbf{x}_{\ell+j}^{(k+1)} - \mathbf{x}_{\ell+j}^{(k)}\|^2$ ▷ 逐点 Picard 变化

  $\mathrm{stride} \leftarrow \min\big(\{j \in \{1, \dots, J-1\} : \mathrm{error}_j > \mathrm{tol}_{\ell+j}\} \cup \{J\}\big)$

  初始化新节点：For $r = 1, \dots, \mathrm{stride}$：$\mathbf{x}_{\ell+J+r}^{(k+1)} \leftarrow \mathbf{x}_{\ell+J}^{(k+1)}$ ▷ 对新暴露指标作常数外推

  $\ell \leftarrow \ell + \mathrm{stride};\ k \leftarrow k+1$

end while

return $\{\mathbf{x}_j^{(k)}\}_{j=0}^{M}$

9.8.3 与时间步进求解器的关系

滑动窗口大小的选取. 先看最小窗口：当 $p = 1$ 时窗口只含单步，式 (9.9.8.499) 退化为 PF–ODE 的一阶时间步进更新；若采用与 DDIM 相同的 ODE 写法（数据 vs. 噪声预测）与相同离散调度，方法即退化为 DDIM.

增大 p 则在不改变总步数 N 的前提下扩大并行度（每窗推进更多节点）. 因而样本质量仍由底层离散化（网格/参数化与逐步公式）及每窗 Picard 收敛共同决定，后者由局部容差监控.

与高阶求解器的兼容性（如 DPM）. 滑动窗口–Picard 结构控制的是如何并行地计算与累积增量，而非哪条局部公式定义这些增量. 因此可以用任意相容的高阶求积替换左端点规则而不改变并行布局. 例如式 (9.9.8.499) 的梯形变体为

$$\mathbf{x}_{\ell+j+1}^{(k+1)} = \mathbf{x}_\ell^{(k)} - \Delta t \Big[\tfrac{1}{2} \mathbf{v}_{\phi^\times}(\mathbf{x}_\ell^{(k)}, t_\ell) + \sum_{i=1}^{j-1} \mathbf{v}_{\phi^\times}(\mathbf{x}_{\ell+i}^{(k)}, t_{\ell+i}) + \tfrac{1}{2} \mathbf{v}_{\phi^\times}(\mathbf{x}_{\ell+j}^{(k)}, t_{\ell+j}) \Big],$$

其中各漂移仍取自上一轮 Picard 迭代值，逐节点估值仍相互独立、内层和仍为前缀和.

类似地，DPM 求解器家族所用的多步或指数积分更新（如对数 SNR 时间中的 DPM-Solver++ 2M）可通过把每个窗口增量替换为对应高阶线性组合（由历史模型输出的 $\mathbf{x}$- 或 $\boldsymbol{\epsilon}$-预测与预计算系数组成）而插入；scan 照旧按权重累积这些增量. 简言之：

并行格式与近似积分的求解器（离散化）选择相互独立——精度来自底层求解器，窗口前缀和只是让它变快.

9.9 本章结语

本章直面扩散模型最突出的实用局限之一：缓慢、迭代式的采样. 我们探索了一类无需训练的强大方法，借助微分方程数值分析的丰富成果来加速生成. 核心策略是更高效地求解 PF–ODE——它定义了从噪声到数据的确定性生成轨迹：

1. 从基础的 DDIM 出发，它可理解为一阶指数 Euler 方法；
2. 进而引入 DEIS 这类高阶多步方法，通过回收历史估值提升精度；
3. 最后考察高效的 DPM-Solver 家族，它通过引入关键的对数 SNR 时间重参数化取得卓越表现.

借助这些精巧求解器，高质量生成所需的函数调用次数（NFE）从成百上千锐减到 10–20，使扩散模型显著更实用.

然而，这些无需训练的方法本质上仍是迭代式的：它们一步步逼近连续路径. 这自然引出一个雄心勃勃的问题：能否仅用一步或极少几步离散化就达到高质量生成?

本书最后一部分（Part D）将通过基于训练的加速来回答这一问题，主要考察两条路线：

1. 第 10 章的蒸馏类方法：训练一个快速学生生成器去复现缓慢、预训练的教师扩散模型在少步下的输出；
2. 第 11 章进一步探索从 scratch 学习快速少步生成器的方法，如一致性训练（Consistency Training），它定义了不依赖任何预训练模型的独立训练原理.

这种从 “改进求解器” 到 “直接学习解映射本身” 的转变，代表了高效生成建模的前沿：把扩散模型的质量与单步生成器的速度结合起来.

Part D　走向快速扩散生成器的学习

Chapter 10

面向快速采样的蒸馏方法

本章介绍一类基于训练的方法，它们通过教授新的生成器仅用一步或少数几步即可产出样本，从而加速扩散模型的采样。这一核心思想被称为蒸馏（distillation）：让一个快速的学生（student）模型从一个慢速的、预训练好的扩散模型（教师，teacher）采样器中学习。教师可能需要数百步，而学生只需少数几步即可达到相当的质量[33]。与改进数值积分格式的求解器式加速不同，蒸馏直接训练一个生成器去走高效的捷径。我们强调两大范式：分布级蒸馏（distribution level distillation），它跳过整条轨迹的模拟，转而让学生输出分布与教师对齐；以及流映射级蒸馏（flow map level distillation），它训练学生以更快、更紧凑的方式复现教师的采样路径。

10.1 序幕

扩散模型的核心瓶颈之一是其缓慢的采样速度。

如 Tweedie 公式（第 §6.3.1 节）所示，一个扩散模型可以被解释为一个“$\mathbf{x}$-prediction”模型 $\mathbf{x}_{\phi^\times}(\mathbf{x}_t, t)$，其训练目标是在噪声输入 $\mathbf{x}_t$ 处、在噪声级 t 下恢复期望的干净数据：

$$\mathbf{x}_{\phi^\times}(\mathbf{x}_t, t) \approx \mathbb{E}[\mathbf{x}_0 \mid \mathbf{x}_t], \tag{10.10.1.500}$$

其中期望是关于 $p(\mathbf{x}_0 \mid \mathbf{x}_t)$ 取的，它表示与 $\mathbf{x}_t$ 对应的所有可能的干净数据。一个自然的想法是直接用 $\mathbf{x}_{\phi^\times}(\mathbf{x}_t, t)$ 做一步生成。然而，由于这个去噪器对许多可能的结果取平均，预测变得过度平滑，只用少数几步去噪得到的样本便模糊、质量低下。

另一方面，如第 §4.2.2 节所论，扩散采样遵循一条 ODE 或 SDE 轨迹，需要一长串迭代步。这能产出高保真样本，但所需步数众多使过程本质上缓慢。减少 NFE（即采样步数乘以模型调用次数）会加速生成，但不可避免地损失保真度。每个求解器步引入一个阶为 $\mathcal{O}(h^n)$ 的积分误差，其中 n 是求解器阶数，$h = \max_i |t_i - t_{i-1}|$ 是步长。步数越少意味着时间增量 h 越大，进而累积采样误差增大，轨迹精度下降。这就在扩散采样中造成了质量与效率的根本权衡。

为克服这一瓶颈，一条主要研究路线是蒸馏：它假设有一个训练良好的扩散模型（教师）可用，然后训练一个生成器（学生）通过单步前向或少数几步计算来复现其行为。这把教师的众多采样步压缩为一个快速过程，在保持高样本保真度的同时有效绕开缓慢的迭代求解器。

下文我们介绍两种蒸馏视角：分布级蒸馏与流映射级蒸馏[34]。

[33]此处的蒸馏指减少采样步数，而非缩小模型规模。

[34]按时间顺序，流映射级蒸馏以 Knowledge Distillation（KD，Luhman 与 Luhman, 2021）和 Progressive Distillation（PD，Ho 等, 2020）为代表，早在 2021 年即被提出，早于 2023 年前后涌现的分布级蒸馏方法族。但为行文顺畅并与下一章衔接，我们先介绍分布级蒸馏。

10.1.1 分布级蒸馏

基于分布的蒸馏的目标是训练一个单步生成器 $\mathbf{G}_\theta(\mathbf{z})$，它把噪声 $\mathbf{z} \sim p_{\text{prior}}$ 映射为样本 $\hat{\mathbf{x}} = \mathbf{G}_\theta(\mathbf{z})$，诱导出一个分布 $p_\theta(\hat{\mathbf{x}})$，逼近目标数据分布 $p_{\text{data}}(\mathbf{x})$。这通常通过最小化一个统计散度实现：

$$\min_\theta \mathcal{D}\big(p_\theta(\hat{\mathbf{x}}), p_{\text{data}}(\hat{\mathbf{x}})\big), \tag{10.10.1.501}$$

其中 $\mathcal{D}$ 表示一个合适的散度度量，例如 KL。

实践中，基于分布的方法把生成器的分布与一个预训练扩散模型产出的经验分布 $p_{\phi^\times}(\mathbf{x})$ 对齐：

$$\min_\theta \mathcal{D}\big(p_\theta(\hat{\mathbf{x}}), p_{\phi^\times}(\hat{\mathbf{x}})\big), \tag{10.10.1.502}$$

其中 $p_{\phi^\times}$ 充当 p_{data} 的替身。这些方法不显式计算该散度，而是逼近其梯度，该梯度可直接从预训练教师模型算出。这使学生无需完整评估散度即可让自身分布与教师对齐。

这一表述通过分布对齐把扩散模型的多步生成过程蒸馏为单步模型。我们在第 10.2 节展开这一方法。

10.1.2 流映射级蒸馏

我们考察 PF-ODE，对任意预测模型它可写为（式 (6.3.1)）：

$$\frac{\mathrm{d}\mathbf{x}(\tau)}{\mathrm{d}\tau} = f(\tau)\mathbf{x}(\tau) - \tfrac{1}{2}g^2(\tau)\nabla_{\mathbf{x}} \log p_\tau(\mathbf{x}(\tau)) =: \mathbf{v}^*(\mathbf{x}(\tau), \tau). \tag{10.10.1.503}$$

其解映射从时刻 s 的 $\mathbf{x}_s$ 出发、反向演化到时刻 $t \le s$，记为 $\Psi_{s\to t}(\mathbf{x}_s)$；即

$$\Psi_{s\to t}(\mathbf{x}_s) := \mathbf{x}_s + \int_s^t \mathbf{v}^*(\mathbf{x}(\tau), \tau)\,\mathrm{d}\tau, \tag{10.10.1.504}$$

该积分求解 PF-ODE。直观地，$\Psi_{s\to t}$ 把时刻 s 的噪声 $\mathbf{x}_s$ 搬运到噪声更小的状态 t（最终在 $t = 0$ 处得到数据）。

从扩散模型采样对应于对 $\mathbf{x}_T \sim p_{\text{prior}}$ 计算 $\Psi_{T\to 0}(\mathbf{x}_T)$。通常该积分借助速度场 $\mathbf{v}$ 由迭代数值求解器近似（第 9 章），但需要很多步（即便 DPM-Solver 也至少 10 步），使采样慢于 GAN 这类经典单步生成模型。这自然引出一个问题：

问题 10.1.1： 我们能否直接学习解映射 $\Psi_{s\to t}(\mathbf{x}_s)$?

特别地，对 $\mathbf{x}_T \sim p_{\text{prior}}$ 学习一个映射 $\Psi_{T\to 0}(\mathbf{x}_T)$ 即可实现单步生成。

轨迹蒸馏。 轨迹蒸馏（Trajectory Distillation）试图训练一个神经生成器，在实例层面逼近解映射。由于 PF-ODE 积分鲜有闭式，训练中必须数值近似它。为形式化，引入通用求解器记号

$$\texttt{Solver}_{s\to t}(\mathbf{x}_s; \phi^\times) \quad \text{或简记} \quad \texttt{Solver}_{s\to t}(\mathbf{x}_s), \tag{10.10.1.505}$$

表示从 $\mathbf{x}_s$ 出发、由经验 PF-ODE 从 s 数值积分到 t 的结果，教师参数为 $\phi^\times$（在语境清晰时省略）。

一种早期途径：直接知识蒸馏。 为实现少数步乃至单步生成，一个直接途径是训练一个生成器 $\mathbf{G}_\theta(\mathbf{x}_T, T, 0)$，使其模仿沿整条轨迹评估的数值求解器输出：

$$\mathbf{G}_\theta(\mathbf{x}_T, T, 0) \approx \texttt{Solver}_{T\to 0}(\mathbf{x}_T), \qquad \mathbf{x}_T \sim p_{\text{prior}}. \tag{10.10.1.506}$$

这一思想支撑了最早的一批轨迹蒸馏方法之一，*Knowledge Distillation*（KD，Luhman 与 Luhman, 2021），它使用回归损失

$$\mathcal{L}_{\text{KD}}(\theta) := \mathbb{E}_{\mathbf{x}_T\sim p_{\text{prior}}} \big\|\mathbf{G}_\theta(\mathbf{x}_T, T, 0) - \texttt{Solver}_{T\to 0}(\mathbf{x}_T)\big\|_2^2. \tag{10.10.1.507}$$

该方法虽从预训练教师获得直接监督，但无法利用原始训练数据中可用的强监督。此外，若在训练循环内调用 ODE 积分，计算代价很高：每次参数更新都需要求解 ODE 以构造目标。最后，由于生成器只学习从 T 到 0 的全局映射，它可能失去从中间状态引导生成过程的可控性。因此第 8 章介绍的多数可控生成技术无法直接套用。

Progressive Distillation 前奏。 *Progressive Distillation*（PD，Salimans 与 Ho, 2021）使用来自教师片段的局部监督训练一个时间条件的学生。令 $t_0 = T > t_1 > \cdots > t_N = 0$ 为一个固定时间网格。教师给出逐步映射 $\texttt{Teacher}_{t_k\to t_{k+1}}$，$k = 0, \ldots, N-1$。

PD 不只监督单跳 $T \to 0$，而是训练学生的两步跳映射，使其匹配连续两个教师步：

$$\texttt{Student}_{t_k\to t_{k+2}} \approx \texttt{Teacher}_{t_{k+1}\to t_{k+2}} \circ \texttt{Teacher}_{t_k\to t_{k+1}}, \tag{10.10.1.508}$$

$k = 0, 2, 4, \ldots$。匹配用简单的回归损失（如均方误差）完成。

在局部配对片段上训练后，学生不再跟随原网格的每个时间区间，而是每隔一个时间点前进：

$$t_0 \to t_2 \to t_4 \to \cdots \to t_N, \tag{10.10.1.509}$$

即每个学生步有效覆盖两个连续教师步。于是学生只用 $N/2$ 次转移就完成同样的整体时间跨度 $[0, T]$。

此阶段后，训练好的学生取代教师成为新的参考模型。整个过程在更粗的网格上重复，时间步加倍（$N \to N/2 \to N/4 \to \cdots$），逐步把轨迹蒸馏为越来越少的步数，直至达到所需推理步数。这种迭代减半在保持全局时间跨度的同时持续压缩生成过程的时间分辨率。

流映射学习的统一视角。 包括 KD 与 PD 在内的多种方法可在统一损失框架下表达：

$$\mathcal{L}_{\text{oracle}}(\theta) := \mathbb{E}_{s,t}\mathbb{E}_{\mathbf{x}_s\sim p_s}\big[w(s,t)\, d\big(\mathbf{G}_\theta(\mathbf{x}_s, s, t), \Psi_{s\to t}(\mathbf{x}_s)\big)\big], \tag{10.10.1.510}$$

其中 $\Psi_{s\to t}$ 是 oracle 流映射，$w(s,t) \geq 0$ 指定不同时间对 (s,t) 的加权方式，$d(\cdot,\cdot)$ 是一个差异度量，如 $d(\mathbf{x},\mathbf{y}) = \|\mathbf{x}-\mathbf{y}\|_2^2$ 或 $d(\mathbf{x},\mathbf{y}) = \|\mathbf{x}-\mathbf{y}\|_1$，$p_s$ 表示时刻 s 的前向加噪边缘。由于 $\Psi_{s\to t}$ 没有闭式，必须依赖逼近，通常是预训练扩散模型（教师）或另一个易处理的替身。

KD 是式 (10.10.1.510) 的一个简单实例。取退化权重 $w(s,t) = \delta(s-T)\delta(t-0)$ 并使用先验分布 $p_T = p_{\text{prior}}$[35]，oracle 损失 $\mathcal{L}_{\text{oracle}}(\theta)$ 退化为：

$$\mathbb{E}_{\mathbf{x}_T\sim p_T}\big\|\mathbf{G}_\theta(\mathbf{x}_T, T, 0) - \Psi_{T\to 0}(\mathbf{x}_T)\big\|_2^2 \approx \mathcal{L}_{\text{KD}}(\theta), \tag{10.10.1.511}$$

[35]在 T 足够大或噪声调度 (α_t, σ_t) 足够合适时，该假设成立。

其中 $\texttt{Solver}_{T\to 0} \approx \Psi_{T\to 0}$。关于这一表述的另一种视角见附录 D.5 节。

PD 也符合此模板，但它不只使用单个极端对 $(T, 0)$ 做监督，而是使用许多邻近时间对，并施加一个简单的局部一致性规则：一个短步再接一个短步应当等价于直接的两步移动。我们将在式 (10.10.3.518) 回到这一点。

实践中，主要困难在于 oracle 流映射 $\Psi_{s\to t}$ 一般没有闭式，直接监督不可行。人们发展了一系列方法高效地逼近这一目标，但其成功往往依赖教师模型的质量。我们将在第 11 章回到式 (10.10.1.510)，给出一个有原则的框架，用于把教师从学习循环中移除的 “从零训练” 方法。

10.2 基于分布的蒸馏

若干工作在不同名号下并行研究了这种基于分布的蒸馏，包括 Distributional Matching Distillation（DMD，Yin 等, 2024b；Yin 等, 2024a）、Variational Score Distillation（VSD，Poole 等, 2023；Wang 等, 2023；Luo 等, 2023；Lu 与 Song, 2024）以及 Score Identity Distillation（SiD，Zhou 等, 2024）。尽管技术细节各异，它们共享同一原理：训练一个生成器，使其前向加噪边缘与教师的边缘匹配。我们以 VSD 作为代表表述，因为其他方法遵循相似原理。

10.2.1 以 VSD 为代表的表述

前向过程。 令 $\{p_t\}_{t\in[0,T]}$ 表示由

$$\mathbf{x}_t = \alpha_t \mathbf{x}_0 + \sigma_t \boldsymbol{\epsilon}, \qquad \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}), \tag{10.10.2.512}$$

诱导的前向扩散过程的边缘密度，初始分布 $p_0 = p_{\text{data}}$。相应地，令 p_t^θ 表示由确定性单步生成器 $\mathbf{G}_\theta(\mathbf{z})$ 从隐变量 $\mathbf{z} \sim p_{\text{prior}}(\mathbf{z})$ 生成的合成样本的分布。把同一个前向扩散过程作用于 p_0^θ，得到边缘密度族 $\{p_t^\theta\}_{t\in[0,T]}$，即

$$\mathbf{x}_t^\theta := \alpha_t \mathbf{G}_\theta(\mathbf{z}) + \sigma_t \boldsymbol{\epsilon}, \tag{10.10.2.513}$$

其中 $\mathbf{z} \sim p_{\text{prior}}$，$\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$。于是 p_t 与 p_t^θ 共享同一个 Gaussian 扩散核 $p_t(\mathbf{x}_t \mid \mathbf{x}_0)$，但起点分布不同（$p_{\text{data}}$ 对比单步合成样本的 p_0^θ）。

训练目标与梯度。 文献通常采用 KL 散度来匹配分布 p_t 与 p_t^θ，一般通过最小化

$$\begin{aligned}\mathcal{L}_{\text{VSD}}(\theta) &:= \mathbb{E}_t\big[\omega(t) \mathcal{D}_{\text{KL}}(p_t^\theta \,\|\, p_t)\big] \\ &= \mathbb{E}_{t,\mathbf{z},\boldsymbol{\epsilon}}\Big[\omega(t)\big(\log p_t^\theta(\mathbf{x}_t^\theta) - \log p_t(\mathbf{x}_t^\theta)\big)\Big],\end{aligned} \tag{10.10.2.514}$$

其中 $\omega(t)$ 是一个时间相关的权重函数。我们将在第 §10.2.3 节讨论为何 KL 散度在分布级蒸馏中扮演特殊角色。

如 Wang 等（2023）所示，当 $p_0^{\theta^*} = p_{\text{data}}$ 时达到最优，这表明生成器分布与数据分布匹配，该训练目标可作为学习数据分布的有效损失。

然而，基于密度的目标表述缺乏高效训练机制。幸运地，对 θ 求梯度后我们得到式 (10.10.2.515) 的表达式，其要点总结于下命题。为记号简洁，记 $\hat{\mathbf{x}}_t := \mathbf{x}_t^\theta$（如式 (10.10.2.513) 所定义）。

命题 10.2.1 (VSD 的 θ-梯度)**：** 我们有

$$\nabla_\theta \mathcal{L}_{\mathrm{VSD}}(\theta) = \mathbb{E}_{t,\mathbf{z},\boldsymbol{\epsilon}}\Big[\omega(t)\alpha_t\big(\nabla_{\mathbf{x}}\log p_t^\theta(\hat{\mathbf{x}}_t) - \nabla_{\mathbf{x}}\log p_t(\hat{\mathbf{x}}_t)\big)\cdot \partial_\theta \mathbf{G}_\theta(\mathbf{z})\Big]. \tag{10.10.2.515}$$

证明： 对命题 10.2.1。推导使用链式法则：

$$\begin{aligned}
&\nabla_\theta \mathbb{E}_t\big[\mathcal{D}_{\mathrm{KL}}(p_t^\theta \,\|\, p_t)\big] \\
&\quad= \mathbb{E}_{t,\mathbf{z},\boldsymbol{\epsilon}}\Big[\partial_\theta\big(\log p_t^\theta(\hat{\mathbf{x}}_t) - \log p_t(\hat{\mathbf{x}}_t)\big)\Big] \\
&\quad= \mathbb{E}_{t,\mathbf{z},\boldsymbol{\epsilon}}\Big[\underbrace{\partial_\theta \log p_t^\theta(\hat{\mathbf{x}}_t)}_{\text{first}} + (\nabla_{\mathbf{x}}\log p_t^\theta(\hat{\mathbf{x}}_t))^\top \partial_\theta \hat{\mathbf{x}}_t - (\nabla_{\mathbf{x}}\log p_t(\hat{\mathbf{x}}_t))^\top \partial_\theta \hat{\mathbf{x}}_t\Big].
\end{aligned}$$

第一项由 score-function 恒等式消去：

$$\mathbb{E}_{\hat{\mathbf{x}}_t\sim p_t^\theta}\big[\partial_\theta \log p_t^\theta(\hat{\mathbf{x}}_t)\big] = \int \partial_\theta p_t^\theta(\mathbf{x})\,\mathrm{d}\mathbf{x} = \partial_\theta \int p_t^\theta(\mathbf{x})\,\mathrm{d}\mathbf{x} = \partial_\theta(1) = 0.$$

使用重参数化 $\hat{\mathbf{x}}_t = \alpha_t \mathbf{G}_\theta(\mathbf{z}) + \sigma_t \boldsymbol{\epsilon}$，得 $\partial_\theta \hat{\mathbf{x}}_t = \alpha_t \partial_\theta \mathbf{G}_\theta(\mathbf{z})$，于是

$$\nabla_\theta \mathcal{L}_{\mathrm{VSD}}(\theta) = \mathbb{E}_{t,\mathbf{z},\boldsymbol{\epsilon}}\Big[\omega(t)\alpha_t\big(\nabla_{\mathbf{x}}\log p_t^\theta(\hat{\mathbf{x}}_t) - \nabla_{\mathbf{x}}\log p_t(\hat{\mathbf{x}}_t)\big)^\top \partial_\theta \mathbf{G}_\theta(\mathbf{z})\Big].$$

这就证明了式 (10.10.2.515)。细节见附录 D.5 节。 □

我们看到，对 θ 求梯度时 score 函数自然涌现。因此我们需要分别逼近单步生成器的 score $\nabla_{\mathbf{x}}\log p_t^\theta(\hat{\mathbf{x}}_t)$ 与数据分布的 score $\nabla_{\mathbf{x}}\log p_t(\hat{\mathbf{x}}_t)$，如下一小节所述。

10.2.2 VSD 的训练流程

已有工作（Yin 等, 2024b；Yin 等, 2024a；Poole 等, 2023；Wang 等, 2023；Luo 等, 2023；Lu 与 Song, 2024）通常通过一种双层优化途径解决这一问题：在来自 $\mathbf{G}_\theta(\mathbf{z})$ 的样本上训练一个新的扩散模型，以逼近 $\nabla_{\mathbf{x}}\log p_t^\theta(\hat{\mathbf{x}}_t)$；并使用一个预训练扩散模型作为合成样本 $\hat{\mathbf{x}}_t$ 上难处理 oracle score $\nabla_{\mathbf{x}}\log p_t(\hat{\mathbf{x}}_t)$ 的代理（即教师的 *score*）。更精确地，训练在两个阶段之间交替进行：

- **Score 估计阶段**。固定 θ。令 $\hat{\mathbf{x}}_0 = \mathbf{G}_\theta(\mathbf{z})$，$\hat{\mathbf{x}}_t = \alpha_t \hat{\mathbf{x}}_0 + \sigma_t \boldsymbol{\epsilon}$，其中 $\mathbf{z}\sim p_{\mathrm{prior}}$，$\boldsymbol{\epsilon}\sim\mathcal{N}(\mathbf{0},\mathbf{I})$。使用已知的 Gaussian 扩散核 $p_t(\mathbf{x}_t \mid \mathbf{x}_0)$，以 DSM 训练 s_ζ：

  $$\mathcal{L}_{\mathrm{DSM}}(\zeta;\theta) = \mathbb{E}_{t,\mathbf{z},\boldsymbol{\epsilon}}\Big\| s_\zeta(\hat{\mathbf{x}}_t, t) - \nabla_{\mathbf{x}_t}\log p_t(\hat{\mathbf{x}}_t \mid \hat{\mathbf{x}}_0)\Big\|^2,$$

  在最优处给出 $s_\zeta(\cdot,t) \approx \nabla_{\mathbf{x}}\log p_t^\theta(\cdot)$（对固定的 θ）。

- **生成器更新阶段**。冻结 s_ζ（stop-grad），用式 (10.10.2.515) 中的梯度更新 θ，把各自 score 项替换为对应代理：

  $$s_\zeta(\hat{\mathbf{x}}_t, t) \approx \nabla_{\mathbf{x}}\log p_t^\theta(\hat{\mathbf{x}}_t), \qquad s_{\phi^\times}(\hat{\mathbf{x}}_t, t) \approx \nabla_{\mathbf{x}}\log p_t(\hat{\mathbf{x}}_t)\ (\text{教师})\ .$$

  式 (10.10.2.515) 于是近似为：

  $$\nabla_\theta \mathcal{L}_{\mathrm{VSD}}(\theta) \approx \mathbb{E}_{t,\mathbf{z},\boldsymbol{\epsilon}}\Big[\omega(t)\alpha_t\big(s_\zeta(\hat{\mathbf{x}}_t,t) - s_{\phi^\times}(\hat{\mathbf{x}}_t,t)\big)^\top \partial_\theta \mathbf{G}_\theta(\mathbf{z})\Big].$$

这两个阶段反复交替，直到对所有 t，在 p_t^θ 的支撑上都有 $s_\zeta(\cdot,t)\approx s_{\phi^\times}(\cdot,t)$，此时式 (10.10.2.515) 中的 plug-in 梯度消失。在该收敛状态下，对所有 $t>0$ 有 $p_t^\theta\approx p_t^{\phi^\times}$（教师的边缘）。由于对任意固定的 $t>0$，前向加噪算子（Gaussian 卷积）是单射的，于是 $p_0^\theta\approx p_0^{\phi^\times}$（教师的 $t=0$ 分布）。因此学到的单步生成器 $\mathbf{G}_\theta$ 在 $t=0$ 处与教师分布匹配；当教师本身很好地逼近 p_{data} 时，这进一步意味着 $p_0^\theta\approx p_{\text{data}}$。

10.2.3 补充讨论：散度选择与 VSD 的应用

超越 KL：能否使用一般散度？ 原则上，可以用更一般的散度族替换 VSD 中的前向 KL 项 $\mathcal{D}_{\mathrm{KL}}(p_t^\theta\,\|\,p_t)$，例如 f-散度（式 (1.1.4)）：

$$\mathcal{D}_f(p_t^\theta\,\|\,p_t)=\int p_t(\mathbf{x})\,f\!\left(\frac{p_t^\theta(\mathbf{x})}{p_t(\mathbf{x})}\right)\mathrm{d}\mathbf{x}. \tag{10.10.2.516}$$

然而，梯度 $\nabla_\theta\mathcal{D}_f(p_t^\theta\,\|\,p_t)$ 通过 $f'(r_t)$ 依赖于密度比

$$r_t(\mathbf{x})=\frac{p_t^\theta(\mathbf{x})}{p_t(\mathbf{x})},$$

这对一个隐式学生生成器而言是难处理的。这里称学生为隐式的，是因为它虽能通过随机映射 $\hat{\mathbf{x}}_t=\alpha_t\mathbf{G}_\theta(\mathbf{z})+\sigma_t\boldsymbol{\epsilon}$ 产出样本 $\hat{\mathbf{x}}_t$，却不为诱导密度 $p_t^\theta(\mathbf{x})$ 提供闭式表达式或似然。于是，计算 $\mathcal{D}_f$ 的泛函导数需要逐点访问 $r_t(\mathbf{x})$ 或其对数梯度，二者在此设定下都无法评估。常见的绕行是引入一个辅助 critic 或判别器，通过 f-散度的变分形式（如 f-GAN，Nowozin 等, 2016）来逼近密度比，但这会引入额外网络与嵌套 minimax 优化。

相比之下，对前向 KL，pathwise 梯度可干净地化简为 score-差异形式（式 (10.10.2.515)）：

$$\nabla_\theta\mathcal{D}_{\mathrm{KL}}(p_t^\theta\,\|\,p_t)=\mathbb{E}\Big[\big(\nabla_{\mathbf{x}}\log p_t^\theta(\hat{\mathbf{x}}_t)-\nabla_{\mathbf{x}}\log p_t(\hat{\mathbf{x}}_t)\big)^\top\partial_\theta\hat{\mathbf{x}}_t\Big].$$

这一结构使得只需 score 的更新即可处理。教师的预训练扩散模型已经提供 $\nabla_{\mathbf{x}}\log p_t(\cdot)$，我们可直接复用，无需再学一个辅助密度比估计器。这一表述给出一个非对抗训练目标，全程可微且计算高效。

仅用 2D 预训练扩散模型做 3D 生成的 VSD。 VSD（Wang 等, 2023）与其更早的特例 SDS（Poole 等, 2023，其中生成器是由 θ 参数化的 Dirac）最初为无 3D–2D 配对监督的 3D 场景（即没有 ground-truth 3D 标签）而提出。令 $\theta\in\mathbb{R}^d$ 表示一个 3D 场景的参数，$\mathbf{R}(\theta)$ 是一个可微渲染器，产出图像 $\hat{\mathbf{x}}:=\mathbf{R}(\theta)$。前向加噪过程定义为

$$\hat{\mathbf{x}}_t=\alpha_t\mathbf{R}(\theta)+\sigma_t\boldsymbol{\epsilon},\qquad\boldsymbol{\epsilon}\sim\mathcal{N}(\mathbf{0},\mathbf{I}).$$

一个预训练的 2D（图像）扩散教师提供 score

$$s_{\phi^\times}(\hat{\mathbf{x}}_t,t\mid\mathbf{c})\approx\nabla_{\hat{\mathbf{x}}_t}\log p_t(\hat{\mathbf{x}}_t\mid\mathbf{c}),$$

可选地以文本 $\mathbf{c}$ 为条件。目标是在每个 t 上把噪声渲染的分布与教师的边缘对齐。一个最小表述是渲染分布下的 score-alignment（VSD）目标：

$$\mathcal{L}_{\mathrm{VSD}}^{\mathrm{3D}}(\theta):=\mathbb{E}_{t,\boldsymbol{\epsilon}}\Big[\omega(t)\,\|s_\zeta(\hat{\mathbf{x}}_t,t)-s_{\phi^\times}(\hat{\mathbf{x}}_t,t\mid\mathbf{c})\|_2^2\Big],\qquad\hat{\mathbf{x}}_t=\alpha_t\mathbf{R}(\theta)+\sigma_t\boldsymbol{\epsilon},$$

它把图像空间的 score 引导经渲染器传递到 3D 参数。在更新 θ 时把两个 score 都视为对 $\hat{\mathbf{x}}_t$ 的 stop-grad，得到

$$\nabla_\theta \mathcal{L}_{\text{VSD}}^{\text{3D}}(\theta) = \mathbb{E}_{t,\boldsymbol{\epsilon}}\Big[\omega(t)\alpha_t \left(s_\zeta - s_{\phi\times}\right)^\top \frac{\partial \mathbf{R}}{\partial \theta}(\theta)\Big].$$

当学生 score s_ζ 被抑制（Dirac 生成器）时，该表述退化为 SDS（Poole 等, 2023）。实践中，优化完全按第 10.2.2 节所述交替：先在噪声渲染上更新学生 score，再通过两个 score 以 stop-grad 更新 θ。进一步的数学细节在此略去。

10.3 Progressive Distillation

Progressive Distillation（PD，Salimans 与 Ho, 2021）由两个过程组成，它们合起来使扩散模型能更高效地学习 PF-ODE 轨迹。其关键思想是：在保持对教师轨迹保真的同时，逐步减少高质量采样所需的积分步数。

- **蒸馏操作**：把一个确定性采样器（如 DDIM）基于预训练教师模型（最初是扩散模型）蒸馏为一个学生模型，后者只用一半的采样步复现同一条轨迹。
- **渐进操作**：迭代地重复该蒸馏过程，每次步数减半，直到学生能在一个小而固定的预算（通常 1–4 步）内生成高质量样本。

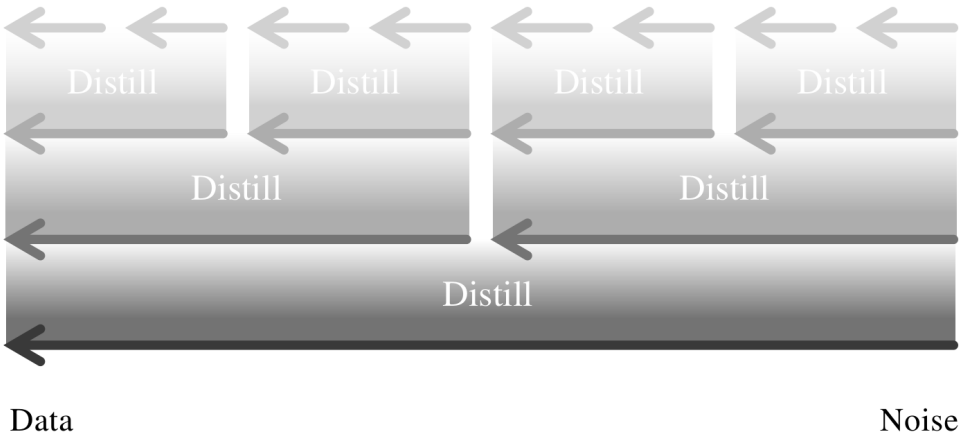


图 10.44: Progressive Distillation（PD）示意。每一轮中，学生模型被训练为用单步复现两个相邻教师步的效果；该过程把 N 个教师步蒸馏为 $N/2$ 个学生步，并反复进行，逐步把轨迹长度减半，直到达到所需步数。箭头表示多步教师转移如何被压缩为更少的学生步，方向从数据指向噪声。

我们先在第 §10.3.1 节介绍 PD 的蒸馏操作，再在第 §10.3.2 节总结整个训练流程。第 §10.3.4 节给出面向 CFG 引导的扩展。

10.3.1 PD 中的蒸馏操作

本节我们固定以 $\mathbf{x}$-prediction 参数化的 DDIM 作为时间步进规则，并仍把 $\texttt{Solver}_{s\to t}$ 写作把当前教师的 $\mathbf{x}$-denoiser 代入 DDIM 所得的确定性映射。

在第一轮 PD（教师 = 预训练扩散模型）中，这等价于用 DDIM 积分扩散 PF-ODE；在后续轮次（教师 = 上一轮学生）中，$\texttt{Solver}_{s\to t}$ 只是当前教师诱导的 DDIM 转移，而非原始扩散 PF-ODE。

蒸馏步如下：从一个噪声输入 $\mathbf{x}_s$（干净数据的扰动版本，$\mathbf{x}_s = \alpha_s \mathbf{x}_0 + \sigma_s \boldsymbol{\epsilon}$）出发，训练学生预测一个目标 $\tilde{\mathbf{x}}$，使单个学生步 $s \to t$ 复现教师连续两步 $s \to u \to t$。令 $\mathbf{x}_{\phi^\times}(\mathbf{x}, \tau)$ 为本轮教师的 $\mathbf{x}$-prediction 去噪器。把教师诱导的 DDIM 转移应用两次，给出

$$\tilde{\mathbf{x}}_u := \texttt{Solver}_{s\to u}(\mathbf{x}_s; \mathbf{x}_{\phi^\times}), \qquad \tilde{\mathbf{x}}_t := \texttt{Solver}_{u\to t}(\tilde{\mathbf{x}}_u; \mathbf{x}_{\phi^\times}).$$

此处我们使用式 (10.10.1.505) 的记号，表示把 $\mathbf{x}_{\phi^\times}$ 代入 DDIM 后、从 $\mathbf{x}_s$ 出发由 s 到 t 的确定性转移映射。

问题 10.3.1： 在时刻 s 处的伪干净（pseudo-clean）$\tilde{\mathbf{x}}$ 应取何值，使得求解器直接走 $s \to t$ 时产出的 $\tilde{\mathbf{x}}_t$，与经由 $s \to u \to t$ 得到的输出相同？具体地，求满足下式的 $\tilde{\mathbf{x}}$：

$$\tilde{\mathbf{x}}_t = \texttt{Solver}_{s\to t}(\mathbf{x}_s; \tilde{\mathbf{x}}).$$

一旦得到 $\tilde{\mathbf{x}}$ 的闭式表达式，我们就训练一个学生模型 $f_\theta(\mathbf{x}_s, s)$（此处也是一个 $\mathbf{x}$-prediction 模型），通过最小化下式来逼近这个“两步合一”的目标 $\tilde{\mathbf{x}}$：

$$\min_\theta \mathbb{E}_s \mathbb{E}_{\mathbf{x}_s \sim p_s} \Big[w(\lambda_s) \, \| f_\theta(\mathbf{x}_s, s) - \tilde{\mathbf{x}} \|_2^2 \Big]. \tag{10.10.3.517}$$

下文我们通过初等代数证明 DDIM 规则给出闭式 $\tilde{\mathbf{x}}$（注意结果在离散与连续时间下都成立）：

引理 10.3.1 (DDIM 的“两步合一”目标 $\tilde{\mathbf{x}}$)**：** *从初始条件 $\mathbf{x}_s$ 出发，若求解器取为 DDIM，则“两步合一”目标 $\tilde{\mathbf{x}}$ 可计算为*

$$\tilde{\mathbf{x}} = \frac{\sigma_s}{\alpha_t \sigma_s - \alpha_s \sigma_t} \tilde{\mathbf{x}}_t - \frac{\sigma_t}{\alpha_t \sigma_s - \alpha_s \sigma_t} \mathbf{x}_s.$$

这里 $\tilde{\mathbf{x}}_t$ 是把 DDIM（式 (9.2.3)）连续应用两次、从 $s \to u \to t$ 得到：

$$\begin{aligned} s \to u: \quad \tilde{\mathbf{x}}_u &= \frac{\sigma_u}{\sigma_s} \mathbf{x}_s + \alpha_s \left(\frac{\alpha_u}{\alpha_s} - \frac{\sigma_u}{\sigma_s} \right) \mathbf{x}_{\phi^\times}(\mathbf{x}_s, s) \\ u \to t: \quad \tilde{\mathbf{x}}_t &= \frac{\sigma_t}{\sigma_u} \tilde{\mathbf{x}}_u + \alpha_u \left(\frac{\alpha_t}{\alpha_u} - \frac{\sigma_t}{\sigma_u} \right) \mathbf{x}_{\phi^\times}(\tilde{\mathbf{x}}_u, u). \end{aligned}$$

证明： 对引理 10.3.1。$\tilde{\mathbf{x}}_t$ 必须与从 s 到 t 的单步 DDIM 输出 $\tilde{\mathbf{x}}'_t$ 匹配，后者可写为：

$$s \to t: \quad \tilde{\mathbf{x}}'_t = \frac{\sigma_t}{\sigma_s} \mathbf{x}_s + \alpha_s \left(\frac{\alpha_t}{\alpha_s} - \frac{\sigma_t}{\sigma_s} \right) \tilde{\mathbf{x}}.$$

令 $\tilde{\mathbf{x}}_t = \tilde{\mathbf{x}}'_t$，可把 $\tilde{\mathbf{x}}$ 用 $\tilde{\mathbf{x}}_t, s, t$ 解出：

$$\begin{aligned}
& \tilde{\mathbf{x}}_t = \tilde{\mathbf{x}}'_t \\
\iff \quad & \tilde{\mathbf{x}}_t = \frac{\sigma_t}{\sigma_s}\mathbf{x}_s + \alpha_s\left(\frac{\alpha_t}{\alpha_s} - \frac{\sigma_t}{\sigma_s}\right)\tilde{\mathbf{x}} \\
\iff \quad & \tilde{\mathbf{x}} = \frac{\tilde{\mathbf{x}}_t - \frac{\sigma_t}{\sigma_s}\mathbf{x}_s}{\alpha_s\left(\frac{\alpha_t}{\alpha_s} - \frac{\sigma_t}{\sigma_s}\right)} \\
\iff \quad & \tilde{\mathbf{x}} = \frac{\sigma_s}{\alpha_t\sigma_s - \alpha_s\sigma_t}\tilde{\mathbf{x}}_t - \frac{\sigma_t}{\alpha_t\sigma_s - \alpha_s\sigma_t}\mathbf{x}_s.
\end{aligned}$$

□

有了这一公式，PD 即可计算时刻 s 的伪干净目标，使单步 DDIM $s \to t$ 恰好落在两步输出 $\tilde{\mathbf{x}}_t$ 上。

实用离散时间网格与损失。 实践中，我们固定一个递减网格 $t_0 = T > t_1 > \cdots > t_N = 0$，并简记 $s := t_k$，$u := t_{k+1}$，$t := t_{k+2}$。教师给出单步映射 $\texttt{Teacher}_{t_k \to t_{k+1}}$，学生学习一个两步跳映射以匹配教师的复合：

$$\texttt{Student}_{t_k \to t_{k+2}} \approx \texttt{Teacher}_{t_{k+1} \to t_{k+2}} \circ \texttt{Teacher}_{t_k \to t_{k+1}}.$$

我们采样三元组 $(s, u, t) = (t_k, t_{k+1}, t_{k+2})$，$k \in \{0, \ldots, N-2\}$。目标式 (10.10.3.517) 变为

$$\min_\theta \mathbb{E}_{k \sim \mathcal{U}[\![0, N-2]\!]} \mathbb{E}_{\mathbf{x}_{t_k} \sim p_{t_k}} \left[w(\lambda_{t_k}) \, \| f_\theta(\mathbf{x}_{t_k}, t_k) - \tilde{\mathbf{x}}^{(k)} \|_2^2 \right],$$

其中教师两步目标 $\tilde{\mathbf{x}}^{(k)}$ 由引理 10.3.1 计算。若网格均匀，可写 $t_k = T(1 - k/N)$，于是

$$s = T\left(1 - \frac{k}{N}\right), \quad u = T\left(1 - \frac{k+1}{N}\right), \quad t = T\left(1 - \frac{k+2}{N}\right),$$

对应于步长 $\Delta s = T/N$ 的等距时间步。

10.3.2 PD 的完整训练流程与采样

通过式 (10.10.3.517) 在局部配对片段上训练后，学生不再跟随原网格的每个区间。相反，每个学到的步覆盖两个连续教师步，于是学生在每隔一个时间点上前进：

$$t_0 \to t_2 \to t_4 \to \cdots \to t_N,$$

只用 $N/2$ 次转移走完同一跨度 $[0, T]$。此阶段后，训练好的学生取代教师成为新的去噪模型。该过程在更粗的网格上重复（时间步加倍），即

$$N \to N/2 \to N/4 \to \cdots,$$

直到达到所需推理步数。每次迭代中，新学生从更新后的教师初始化。这种迭代减半在保持全局时间跨度的同时逐步压缩生成过程的时间分辨率。

采样。 推理时，使用（DDIM）求解器并以当前学生为去噪器，采样器在训练诱导的更粗网格上前进。第一轮后它做 “skip-2” 跳（$t_0 \to t_2 \to \cdots \to t_N$），下一轮后做 “skip-4”（$t_0 \to t_4 \to \cdots \to t_N$），如此往复，每次迭代采样步数减半，但保持相同的起止时间。

10.3.3 补充讨论：局部半群匹配与推广求解器的可能性

PD 作为局部半群匹配。 在统一目标式 (10.10.1.510) 中，难处理的 oracle 目标 $\Psi_{s\to 0}$ 被一个教师诱导的替身取代，该替身利用 ODE 流的半群性质（更详细见后文式 (11.2.1)）：从 s 演化到 t 应等价于先从 s 到某个中间 u、再从 u 到 t，

$$\Psi_{s\to t} = \Psi_{u\to t} \circ \Psi_{s\to u}.$$

PD 通过训练学生的单步映射去匹配两个相邻单步片段的教师复合，在局部施加这一性质：

$$\mathbb{E}_s \mathbb{E}_{\mathbf{x}_s\sim p_s} \Big\| \underbrace{\mathbf{G}_\theta(\mathbf{x}_s, s, s-2\Delta s)}_{\text{student one-step}} - \underbrace{\texttt{Solver}_{s-\Delta s\to s-2\Delta s}\big(\texttt{Solver}_{s\to s-\Delta s}(\mathbf{x}_s)\big)}_{\text{teacher two-step composition}} \Big\|_2^2. \quad (10.10.3.518)$$

最小化式 (10.10.3.518) 即在一个短递减网格上实例化半群恒等式（取 $s > u > t$，其中 $u = s - \Delta s$，$t = s - 2\Delta s$）：

$$\begin{aligned} \Psi_{s\to s-2\Delta s} &= \Psi_{s-\Delta s\to s-2\Delta s} \circ \Psi_{s\to s-\Delta s} \\ &\approx \texttt{Solver}_{s-\Delta s\to s-2\Delta s} \circ \texttt{Solver}_{s\to s-\Delta s}, \end{aligned}$$

于是训练只需短教师片段，无需从时刻 s 一直 rollout 到 0。

为与式 (10.10.1.510) 的少步去噪器视角相衔接，把学生的少步映射定义为若干学到跳的复合：

$$\underbrace{\mathbf{G}_\theta(\mathbf{x}_s, s, 0)}_{\text{few-step denoiser}} = \big(\mathbf{G}_\theta(\cdot, 2\Delta s, 0) \circ \cdots \circ \mathbf{G}_\theta(\cdot, s, s-2\Delta s)\big)(\mathbf{x}_s).$$

概念上，式 (10.10.3.518) 为全局回归提供了一个高效的局部替身：

$$\mathbb{E}_{s,\mathbf{x}_s} \Big\| \mathbf{G}_\theta(\mathbf{x}_s, s, 0) - (\texttt{Solver})^{\circ}_{s\to 0}(\mathbf{x}_s) \Big\|_2^2,$$

其中 $(\texttt{Solver})^{\circ}_{s\to 0}$ 表示教师在步长 Δs 的网格上从 s 到 0 的完整复合，充当 $\Psi_{s\to 0}$ 的代理。

能否使用其他求解器？ 在上面的 PD 介绍中，我们以 $\mathbf{x}$-prediction 参数化下的 DDIM 作为具体的 PF-ODE 采样器。带网格减半的局部半群匹配在确定性状态到状态映射层面是求解器无关的，在参数化（$\mathbf{x}, \boldsymbol{\epsilon}, \mathbf{v}$、score）之间做标准转换后，可推广到第 9 章的时间步进方法。然而，此处闭式伪目标依赖于一个单步、显式更新，其单步映射关于回归目标是仿射的（如 DDIM 以及作用于 PF-ODE 的 exponential-Euler 或显式 RK 等单步格式）。对于多步或隐式求解器，需要步历史或内部求解，应改为直接匹配对应的

转移映射（参见式 (10.10.3.518)），并提供必要的历史或热启动；一般不存在类似的闭式反解。

若采样器是随机的，则把每个样本的噪声序列冻结，得到一个确定性转移 $\texttt{Teacher}_{s\to t}^{(\omega)}$（$\omega$ 为固定噪声种子）。此时 PD 退化为对固定转移映射的回归；闭式伪目标一般只对单步显式仿射更新成立；否则按式 (10.10.3.518) 做直接匹配。

10.3.4 带引导的 PD

Meng 等 (2023) 提出了一个两阶段流程来蒸馏无分类器引导 (CFG) 扩散模型：(1) 把引导本身蒸馏进一个以引导权重为输入的单网络；(2) 应用 *Progressive Distillation* (*PD*) 来减少采样步数。他们在像素空间与隐空间（如 Stable Diffusion）上都验证了这一做法。

第一阶段蒸馏：蒸馏引导。 令 $\mathbf{x}_{\phi^\times}(\mathbf{x}_s, s, \mathbf{c})$ 表示预训练条件扩散模型在 "$\mathbf{x}$-prediction" 参数化下（即一个干净估计）、在时刻 s、条件 $\mathbf{c}$ 下的输出；条件也可为空，即 $\mathbf{c} = \emptyset$（无条件分支）。式 (8.3.3) 中 ω-加权 CFG 复合可写为

$$\mathbf{x}^{\omega}_{\phi^\times}(\mathbf{x}_s, s, \mathbf{c}) := (1+\omega)\,\mathbf{x}_{\phi^\times}(\mathbf{x}_s, s, \mathbf{c}) - \omega\,\mathbf{x}_{\phi^\times}(\mathbf{x}_s, s, \emptyset), \tag{10.10.3.519}$$

其中 $\omega \sim p_\omega(\omega)$ 是某个 CFG 加权分布，通常取 $p_\omega(\omega) = \mathcal{U}[\omega_{\min}, \omega_{\max}]$。

第一阶段引入一个新模型 $\mathbf{x}_{\theta_1}(\mathbf{x}_s, s, \mathbf{c}, \omega)$，直接以 ω 为输入，并通过有监督回归学习复现 CFG 输出 $\mathbf{x}^{\omega}_{\phi^\times}(\mathbf{x}_s, s, \mathbf{c})$：

$$\min_{\theta_1} \mathbb{E}_{\omega\sim p_\omega, s, \mathbf{x}\sim p_{\text{data}}, \mathbf{x}_s\sim p(\mathbf{x}_s|\mathbf{x})} \lambda(s)\, \|\mathbf{x}_{\theta_1}(\mathbf{x}_s, s, \mathbf{c}, \omega) - \mathbf{x}^{\omega}_{\phi^\times}(\mathbf{x}_s, s, \mathbf{c})\|_2^2.$$

这里 $\lambda(s)$ 是标准的、与调度相关的权重；每次迭代采样 ω 教会单个网络在任意引导强度下模拟 CFG。

第二阶段蒸馏：PD。 第一阶段模型 $\mathbf{x}_{\theta_1}(\mathbf{x}_s, s, \mathbf{c}, \omega)$ 作为 PD 中的教师，并按第 10.3.2 节逐步蒸馏为一个步数更少的学生 $\mathbf{x}_{\theta_2}(\mathbf{x}_s, s, \mathbf{c}, \omega)$。每次迭代采样步数减半（如 $N \to N/2 \to N/4 \to \cdots$）。

10.4 本章小结

本章介绍了我们第一个基于训练的加速范式。在穷举了无训练的数值求解器改进后，我们把焦点转向新策略：训练一个快速的学生生成器，让它学会复现一个慢速、预训练教师扩散模型的行为。

我们探索了两种主要蒸馏哲学。第一种是基于分布的蒸馏，以 Variational Score Distillation（VSD）为代表，学生的输出分布被训练为与教师匹配；这通过在不同噪声级上对齐二者各自的 score 函数实现，给出一个稳定、非对抗的目标。第二种是流映射级蒸馏，我们看到 Progressive Distillation（PD）这类方法训练学生直接逼近教师的解轨迹。PD 的迭代做法——每轮把采样步数减半——已被证明是把长迭代过程压缩为少数几步的有力、实用方法。

这些蒸馏技术成功地在迭代扩散模型的高样本质量与单步生成器的推理速度之间架起桥梁，为高效、高保真合成提供了一条有说服力的路径。

然而，依赖预训练教师模型带来了一个两阶段流程：先训练一个慢而强的教师，再把它蒸馏为快学生。这在生成建模研究的前沿提出了一个根本问题：我们能否完全绕开教师？

能否设计一种独立的训练原理，直接从数据中学到这些快速、少步的生成器？本专著的最后一章将回答这一问题。

1. 我们将介绍 Consistency Model 等开创性方法，它们学习从 ODE 轨迹上任意一点到其终点的映射。

2. 我们将深入 Consistency Model 的广义概念，它们学习在单步内把 ODE 轨迹上任意一点映射到另一点。

这种从 “改进求解器” 或 “蒸馏一个解” 转向 “学习解映射本身” 的转变，标志着朝着一类新的生成模型迈出重要一步：它们在设计上既有原则性、又高度高效。

Chapter 11

从零学习快速生成器

真理永远在简洁中被发现，而非在事物的繁杂与混乱之中。— *Isaac Newton*

在第 10 章中，我们看到扩散模型中缓慢的迭代采样器如何通过蒸馏被压缩为少数步生成器。从工程视角看，两阶段流程之所以实用，是因为它把一个复杂的生成训练任务拆分为清晰、独立的目标：第一阶段学习数据分布，第二阶段加速采样或提升质量。这种分离使每个阶段可独立优化，让整体系统更易管理、更稳定、更可靠。

然而本章的焦点转向一个驱动深度生成建模进展的中心问题：

问题 11.0.1： 我们能否设计一种独立的生成原理，使其训练稳定而高效、采样快速、并允许用户轻松引导或控制所生成的内容？

本章我们沿这一方向探讨一种替代途径：在不依赖预训练模型的情况下训练少数步的、基于扩散的生成器。我们的焦点是流映射模型（flow map model），它学习一个直接变换，通过逼近 PF-ODE 的 oracle 流映射来在时间上搬运样本。这一表述给出一条有原则的路径，把概率质量从先验分布 p_{prior} 搬运到数据分布 p_{data}，同时保持前向扩散过程在每个中间时刻指定的边缘分布 p_t。

11.1 序幕

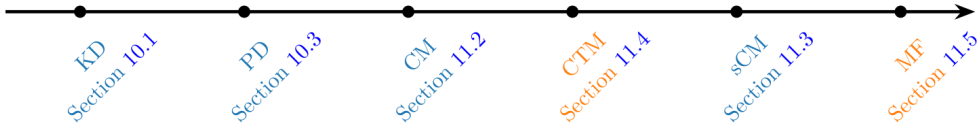


Figure 11.1: Timeline of Flow Map Modeling. We use blue for the special case $\Psi_{s\to 0}$ and orange for the general map $\Psi_{s\to t}$.

图 11.45: 流映射建模的时间线。蓝色表示特例 $\Psi_{s\to 0}$，橙色表示一般映射 $\Psi_{s\to t}$。

流映射模型的动机。 在第 10 章中，我们看到 oracle 流映射损失 $\mathcal{L}_{\text{oracle}}(\theta)$（式 (10.1.4)）中那个不可访问的回归目标，如何通过从预训练扩散模型中蒸馏知识来获得少步生成器。这条路有效而实用：两阶段流程可被工程化得很鲁棒，在数据与计算效率上往往仍具竞争力。

本章我们把焦点转向深度生成建模核心的更宽挑战：我们能否建立一种独立的生成原理，使其在不依赖预训练模型的情况下，实现稳定、可扩展、高效的训练、快速采样、以及可由用户意图轻松引导的生成？设计这样的独立原理正是生成建模的中心议题。

扩散模型提供了一个有用的设计原理：以一个连续时间前向过程为参考，该过程逐步把数据变换为简单先验（噪声）；并把建模任务框定为学习一个反向时间传输，把该

过程恢复为与期望的边缘分布匹配。这种时间相关的表述也使得在中间步上引导生成过程比一步到位的生成映射更容易。聚焦于受扩散启发的方法，这就引出一个问题：

问题 11.1.1： 我们能否在不访问预训练模型的情况下，用一个网络 $\mathbf{G}_\theta(\cdot, s, t)$（流映射模型）学习流映射 $\Psi_{s\to t}(\cdot)$，同时保持高保真生成?

本章朝这一目标发展方法，围绕一个既支撑蒸馏、又为流映射表述提供统一视角的单一目标组织（Boffi 等, 2024；Hu 等, 2025）：

$$\mathcal{L}_{\text{oracle}}(\theta) := \mathbb{E}_{s,t}\mathbb{E}_{\mathbf{x}_s\sim p_s}\big[w(s,t)\, d\big(\mathbf{G}_\theta(\mathbf{x}_s, s, t), \Psi_{s\to t}(\mathbf{x}_s)\big)\big]. \tag{11.11.1.520}$$

这里 s, t 从某个时间分布（如均匀分布）采样，$w(s,t) \geq 0$ 给时间对 (s,t) 加权，$d(\cdot,\cdot)$ 是一个差异度量，如平方 ℓ_2 范数。oracle 流映射 $\Psi_{s\to t}$ 表示那个把时刻 s 的状态 $\mathbf{x}_s$ 直接搬运到时刻 t 的理想变换：

$$\Psi_{s\to t}(\mathbf{x}_s) = \mathbf{x}_s + \int_s^t \mathbf{v}^*(\mathbf{x}_u, u)\,\mathrm{d}u,$$

其中 oracle 漂移给定为

$$\mathbf{v}^*(\mathbf{x}_u, u) = \mathbb{E}\big[\alpha'_u\mathbf{x}_0 + \sigma'_u\boldsymbol{\epsilon} \mid \mathbf{x}_u\big],$$

等价参数化也存在（见第 6 章），常见选择包括 $\mathbf{x}$-prediction 与 $\mathbf{v}$-prediction 形式。

在 oracle 损失的最优处，学到的模型精确恢复真实流映射：

$$\mathbf{G}^*(\mathbf{x}_s, s, t) = \Psi_{s\to t}(\mathbf{x}_s), \quad \text{对所有} s, t \text{ 与} \mathbf{x}_s \sim p_s.$$

由于流映射 $\Psi_{s\to t}$ 没有闭式，必须对其逼近。一种选择在第 10 章讨论，即依赖预训练扩散模型。另一种选择如本章所示，引入新的、更易处理的替身。为清晰起见，现有方法可按训练过程是否在循环中查询教师大致分为两类：蒸馏（distillation）显式调用教师模型；从零训练（training from scratch）通过构造自包含的替身来避免教师调用。

基于这一有原则的目标，我们现在转向学习流映射模型的系统方法，目标是发展既实用、又能更准确反映真实数据分布、且计算高效的生成方法。我们先对这一范式做高层介绍。

特殊流映射：一致性函数。 *Consistency Model*（CM，Song 等, 2023）是流映射学习最早的开创性方法之一。它们学习一个少步去噪器 $f_\theta(\cdot, s)$，逼近流映射到原点这一特例：

$$\Psi_{s\to 0}(\cdot), \qquad s \in (0, T].$$

其核心思想是：每个噪声样本 $\mathbf{x}_s$ 都应被映射回其轨迹终点的干净数据点 $\mathbf{x}_0$。形式上，CM 族的 oracle 训练目标（Song 等, 2023；Song 与 Dhariwal, 2024；Geng 等, 2024；Lu 与 Song, 2024）为

$$\mathcal{L}_{\text{oracle-CM}}(\theta) := \mathbb{E}_s\mathbb{E}_{\mathbf{x}_s\sim p_s}\big[w(s)\, d\big(f_\theta(\mathbf{x}_s, s), \Psi_{s\to 0}(\mathbf{x}_s)\big)\big]. \tag{11.11.1.521}$$

然而实践中 oracle $\Psi_{s\to 0}(\mathbf{x}_s)$ 不可得。它被一个 stop-gradient 目标替代，记为 f_{θ^-}，取自同一轨迹上稍早一步 $\Psi_{s\to s-\Delta s}(\mathbf{x}_s)$：

$$\Psi_{s\to 0}(\mathbf{x}_s) \approx f_{\theta^-}\big(\Psi_{s\to s-\Delta s}(\mathbf{x}_s), s-\Delta s\big), \quad \Delta s > 0,$$

其中 $\Psi_{s\to s-\Delta s}(\mathbf{x}_s)$ 本身也必须逼近。两条实用路线：(i) 蒸馏，依赖预训练扩散模型；(ii) 从零训练，在无教师引导下使用单点估计。

一般流映射。 两个代表方法是 *Consistency Trajectory Model*（CTM）与 *Mean Flow*（MF）。

Consistency Trajectory Models. *Consistency Trajectory Model*（CTM，Kim 等, 2024a）是首个学习任意起止时刻的一般流映射 $\Psi_{s\to t}$ 的工作，可视为式 (11.11.1.520) 统一目标下的一个具体实例。CTM 采用 Euler 启发的参数化，把 oracle 流映射表达为

$$\Psi_{s\to t}(\mathbf{x}_s) := \mathbf{x}_s + \int_s^t \mathbf{v}^*(\mathbf{x}_u, u)\,\mathrm{d}u = \frac{t}{s}\mathbf{x}_s + \frac{s-t}{s}\underbrace{\left[\mathbf{x}_s + \frac{s}{s-t}\int_s^t \mathbf{v}^*(\mathbf{x}_u, u)\,\mathrm{d}u\right]}_{\approx \mathbf{g}_\theta},$$

这启发了神经参数化

$$\mathbf{G}_\theta(\mathbf{x}_s, s, t) := \frac{t}{s}\mathbf{x}_s + \frac{s-t}{s}\mathbf{g}_\theta(\mathbf{x}_s, s, t),$$

其中 $\mathbf{g}_\theta$ 是一个神经网络，训练使 $\Psi_{s\to t}(\mathbf{x}_s) \approx \mathbf{G}_\theta(\mathbf{x}_s, s, t)$。

由于 oracle $\Psi_{s\to t}(\mathbf{x}_s)$ 不可访问，CTM 针对一个在中间时刻 u 处评估的 stop-gradient 目标进行训练：

$$\Psi_{s\to t}(\mathbf{x}_s) \approx \mathbf{G}_{\theta^-}\big(\Psi_{s\to u}(\mathbf{x}_s), u, t\big), \qquad u \in [t, s],$$

其中中间状态 $\Psi_{s\to u}(\mathbf{x}_s)$ 用两种方式之一逼近：(i) 蒸馏，对预训练扩散教师使用少步求解器；(ii) 从零训练，直接通过 $\mathbf{G}_\theta$ 参数化构造一个自诱导教师。

Mean Flow. *Mean Flow*（MF，Geng 等, 2025a）在流匹配基础上建模区间 $[t, s]$（$t \le s$）上的平均漂移：

$$\mathbf{h}_\theta(\mathbf{x}_s, s, t) \approx \mathbf{h}^*(\mathbf{x}_s, s, t) := \frac{1}{t-s}\int_s^t \mathbf{v}^*(\mathbf{x}_u, u)\,\mathrm{d}u,$$

这与式 (11.11.1.520) 一致。对恒等式

$$(t-s)\mathbf{h}^*(\mathbf{x}_s, s, t) = \int_s^t \mathbf{v}^*(\mathbf{x}_u, u)\,\mathrm{d}u$$

关于 s 求导，得到一个自 referential 关系，启发了 MF 目标

$$\mathcal{L}_{\mathrm{MF}}(\theta) := \mathbb{E}_s\mathbb{E}_{\mathbf{x}_s\sim p_s}\big[w(s)\,\|\mathbf{h}_\theta(\mathbf{x}_s, s, t) - \mathbf{h}^{\mathrm{tgt}}_{\theta^-}(\mathbf{x}_s, s, t)\|_2^2\big],$$

其中 stop-gradient 目标为

$$\mathbf{h}^{\mathrm{tgt}}_{\theta^-}(\mathbf{x}_s, s, t) := \mathbf{v}^*(\mathbf{x}_s, s) - (s-t)\big(\mathbf{v}^*(\mathbf{x}_s, s)\,\partial_{\mathbf{x}}\mathbf{h}_{\theta^-} + \partial_s \mathbf{h}_{\theta^-}\big).$$

实践中 oracle 速度 $\mathbf{v}^*(\mathbf{x}_s, s)$ 也必须逼近。两种常见策略：(i) 蒸馏，利用一个用流匹配训练的预训练扩散模型；(ii) 从零训练，使用从前向加噪过程 $\mathbf{x}_s = \alpha_s \mathbf{x}_0 + \sigma_s \boldsymbol{\epsilon}$ 导出的单点条件速度 $\alpha'_s \mathbf{x}_0 + \sigma'_s \boldsymbol{\epsilon}$。

CTM 与 MF 的关系。 CTM 与 MF 逼近同一条路径积分，但对其做不同的参数化替身：

$$\begin{aligned}
\Psi_{s\to t}(\mathbf{x}_s) &:= \mathbf{x}_s + \int_s^t \mathbf{v}^*(\mathbf{x}_u, u)\,\mathrm{d}u \\
&= \frac{t}{s}\mathbf{x}_s + \frac{s-t}{s}\underbrace{\left[\mathbf{x}_s + \frac{s}{s-t}\int_s^t \mathbf{v}^*(\mathbf{x}_u, u)\,\mathrm{d}u\right]}_{\approx \mathbf{g}_\theta} \\
&= \mathbf{x}_s + (t-s)\underbrace{\left[\frac{1}{t-s}\int_s^t \mathbf{v}^*(\mathbf{x}_u, u)\,\mathrm{d}u\right]}_{\approx \mathbf{h}_\theta}.
\end{aligned}$$

换言之，CTM 通过 $\mathbf{g}_\theta$ 学习一个斜率位移，而 MF 学习平均漂移 $\mathbf{h}_\theta$；二者都是逼近定义 $\Psi_{s\to t}$ 的同一积分的一致方式。

接下来？ 我们从 CM 族开始，它聚焦于特殊流映射 $\Psi_{s\to 0}$。这一部分覆盖其离散时间起源（第 §11.2 节）与连续时间扩展（第 §11.3 节）。随后转向一般流映射，详细讨论两个关键代表 CTM 与 MF，其参数化、训练策略与实用逼近分别在第 §11.4 节与第 §11.5 节给出。

我们指出，附录 D.6 节介绍的 *Elucidating Diffusion Model*（EDM）为设计 $\mathbf{x}$-prediction 模型的网络参数化提供了系统指南，并展示了强实证性能。虽然本节可视为可选，EDM 表述为 CM 风格模型提供了有价值的基础。

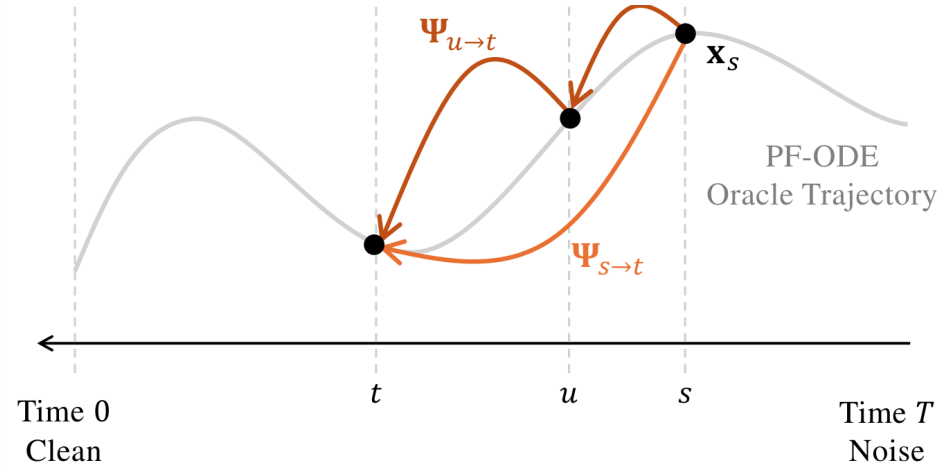
为后文行文清晰，我们不严格按这些方法出现的时间顺序组织，而是按概念关系组织。尽管如此，为尊重原创与年代，我们在图 11.45 中给出历史时间线。

11.2 特殊流映射：离散时间 Consistency Model

流映射的一条重要原理：半群性质。 Consistency Model（在第 §11.2、§11.3 节介绍）及其推广 Consistency Trajectory Model（第 §11.4 节）通过利用流映射的一条关键数学结构来定义回归目标，这一结构就是基本的半群性质：

$$\Psi_{u\to t} \circ \Psi_{s\to u} = \Psi_{s\to t}, \qquad \Psi_{s\to s} = \mathbf{I}, \quad \text{对所有} s, u, t \in [0, T]. \tag{11.11.2.522}$$

直观地，这意味着若我们先把状态从 s 演化到 u（经由 $\Psi_{s\to u}$）、再从 u 演化到 t（经由 $\Psi_{u\to t}$），最终到达的点与直接从 s 演化到 t 完全相同。这不过是 ODE 求解的基



igure 11.2: Illustration of the flow map semigroup property. This property states tha ransitioning from s to u and then from u to t is equivalent to transitioning directly from o t.

An Important Principle of Flow Maps: The Semigroup Property. Consis ency Models (introduced in Sections 11.2 and 11.3) and their generalizatior he Consistency Trajectory Model (Section 11.4), define their regression tar

图 11.46: 流映射半群性质示意。该性质表明：从 s 到 u 再从 u 到 t 的转移，等价于从 s 直接到 t 的转移。

本原理[36]：一旦指定流的起点，其未来演化即完全确定，并沿一条唯一定义的路径进行。无论我们把这条路径走成长长一步、还是切成更小区间，都仍沿同一轨迹移动，并到达同一最终状态。

为进一步建立对半群性质的直觉，考虑 PF-ODE 的解轨迹 $\{\mathbf{x}(s)\}_{s\in[0,T]}$：

$$\frac{\mathrm{d}\mathbf{x}(\tau)}{\mathrm{d}\tau} = \mathbf{v}^*(\mathbf{x}(\tau),\tau),$$

在时刻 T 给定固定初值 $\mathbf{x}(T)$、反向时间求解。若把终端时刻固定在 $t=0$，对应流映射可简写为

$$\mathbf{f}^*(\cdot,s) := \Psi_{s\to 0}(\cdot),$$

称为一致性函数（consistency function）。由构造，该函数直接继承自式 (11.11.2.522) 在 $t=0$ 时的半群恒等式的若干基本性质：

1. **全局一致性**：轨迹上每个点都映射到同一个干净终点，

$$\mathbf{f}^*(\mathbf{x}(s),s) = \mathbf{x}(0), \quad \text{对所有} s\in[0,T].$$

这是因为

$$\mathbf{f}^*(\mathbf{x}(s),s) = \Psi_{s\to 0}\big(\Psi_{0\to s}(\mathbf{x}(0))\big) = (\Psi_{s\to 0}\circ\Psi_{0\to s})(\mathbf{x}(0)) = \Psi_{0\to 0}(\mathbf{x}(0)) = \mathbf{x}(0).$$

[36]半群性质来自 ODE 初值问题的唯一性定理（见附录 A）。

2. **自一致性**：同一轨迹上任意两点必须给出相同输出，

$$\mathbf{f}^*(\mathbf{x}(s), s) = \mathbf{f}^*(\mathbf{x}(u), u), \quad \text{对所有} s, u \in [0, T]. \tag{11.11.2.523}$$

这是对半群恒等式的直接再解释：$\Psi_{s\to 0} \circ \Psi_{0\to s} = \Psi_{u\to 0} \circ \Psi_{0\to u}$。

3. **局部一致性**：沿轨迹评估时一致性函数关于 s 不变，

$$\frac{\mathrm{d}}{\mathrm{d}s}\mathbf{f}^*(\mathbf{x}(s), s) = 0, \qquad \mathbf{f}^*(\mathbf{x}(0), 0) = \mathbf{x}(0). \tag{11.11.2.524}$$

这由全局一致性推出：沿轨迹 $\mathbf{f}^*(\mathbf{x}(s), s)$ 不随 s 变化。

这三条性质等价。每条都陈述：沿任意解轨迹 $s \mapsto \mathbf{x}(s)$，流到原点/一致性映射 $\mathbf{f}^*(\mathbf{x}(s), s) = \Psi_{s\to 0}(\mathbf{x}(s))$ 都给出同一终端点 $\mathbf{x}(0)$，与起始时刻无关。

Consistency Model 的目标。 一个 CM 旨在训练一个神经网络 $\mathbf{f}_\theta : \mathbb{R}^D \times [0, T] \to \mathbb{R}^D$ 来逼近特殊流映射 $\Psi_{s\to 0}$，即一致性函数[37]。关键思想是在 PF-ODE 的多条轨迹上强制执行半群性质，使同一数据点的不同噪声版本一致地映射回同一干净原点（更精确地，这对应式 (11.11.2.522) 中 $t = 0$、$u = s - \Delta s$ 的特例）。

然而，实现这一目标有多种方式，取决于是否有预训练扩散模型可用、以及训练在离散还是连续时间下进行。我们先在表 11 中总结这些变体，并在图 11.47 中图示其目标。后续章节（第 §11.2、§11.3 节）逐步展开各方法细节。

表 11: Consistency Model 的训练目标

	蒸馏	**从零训练**
离散时间	式 (11.2.4)	式 (11.2.6)
连续时间	式 (11.3.5)	式 (11.3.6)

11.2.1 学习一致性函数的离散时间逼近

原则上，一致性函数可通过最小化 oracle 损失式 (11.11.1.521) 来学习：

$$\mathcal{L}_{\text{oracle-CM}}(\theta) := \mathbb{E}_s \mathbb{E}_{\mathbf{x}_s \sim p_s}\big[w(s)\, d\big(\mathbf{f}_\theta(\mathbf{x}_s, s), \Psi_{s\to 0}(\mathbf{x}_s)\big)\big].$$

该目标强制每个噪声样本 $\mathbf{x}_s$ 被映射回其干净终点 $\Psi_{s\to 0}(\mathbf{x}_s)$。

困难在于 oracle 映射 $\Psi_{s\to 0}(\mathbf{x}_s)$ 实践中不可得。为克服这一点，Song 等（2023）利用半群性质：任意噪声状态与其在同一 PF-ODE 轨迹上相邻一步必须映射到同一干净终点。具体地，oracle 目标被一个取自轨迹上稍早一点的 stop-gradient 目标替代：

$$\begin{aligned}\Psi_{s\to 0}(\mathbf{x}_s) &= \Psi_{s-\Delta s\to 0}\big(\Psi_{s\to s-\Delta s}(\mathbf{x}_s)\big) \\ &\approx \mathbf{f}_{\theta^-}\big(\Psi_{s\to s-\Delta s}(\mathbf{x}_s), s - \Delta s\big), \quad \Delta s > 0,\end{aligned}$$

[37] ODE 一致性函数的概念可推广到 SDE 上的函数 $\mathbf{f}(\mathbf{x}, t)$，使得 $\mathbf{f}(\mathbf{x}_t, t)$ 关于 SDE 自然 filtration 是一个（局部）鞅，即 $\mathbb{E}[\mathbf{f}(\mathbf{x}_t, t) \mid \mathbf{x}_s] = \mathbf{f}(\mathbf{x}_s, s)$，对所有 $t \geq s$。这一推广由 Daras 等（2023）与 Lai 等（2023a）提出/观察到，其理论联系总结于 Lai 等（2023b）。

其中 θ^- 是 stop-gradient 算子下的参数。进一步困难是中间状态 $\Psi_{s\to s-\Delta s}(\mathbf{x}_s)$ 也没有闭式，必须自行逼近。人们提出了两种实用范式：

使用预训练扩散模型（Consistency Distillation）。 假设我们有一个预训练扩散模型。Consistency Distillation（CD）利用教师模型，通过只模拟一个反向 ODE 步来逼近中间状态 $\Psi_{s\to s-\Delta s}(\mathbf{x}_s)$：

$$\Psi_{s\to s-\Delta s}(\mathbf{x}_s) \approx \texttt{Solver}_{s\to s-\Delta s}(\mathbf{x}_s).$$

更具体地，预训练扩散模型提供 score 函数估计 $s_{\phi^\times}(\mathbf{x}_s, s) \approx \nabla_{\mathbf{x}_s} \log p_s(\mathbf{x}_s)$。利用这一点，可从 $\mathbf{x}_s$ 做一步 DDIM 更新得到 $s' = s - \Delta s$ 处状态的近似：

$$\begin{aligned}
\Psi_{s\to s-\Delta s}(\mathbf{x}_s) &\approx \frac{\alpha_{s'}}{\alpha_s}\mathbf{x}_s + \sigma_s^2\left(\frac{\alpha_{s'}}{\alpha_s} - \frac{\sigma_{s'}}{\sigma_s}\right)\nabla_{\mathbf{x}_s}\log p_s(\mathbf{x}_s) \\
&\approx \frac{\alpha_{s'}}{\alpha_s}\mathbf{x}_s + \sigma_s^2\left(\frac{\alpha_{s'}}{\alpha_s} - \frac{\sigma_{s'}}{\sigma_s}\right)s_{\phi^\times}(\mathbf{x}_s, s) \\
&:= \tilde{\mathbf{x}}_{s'}^{\phi^\times}.
\end{aligned}$$

把这一构造与 stop-gradient 目标结合，得到 oracle 损失 $\mathcal{L}_{\text{oracle-CM}}(\theta)$ 的一个实用离散时间替身。形式上，在分割 $0 = s_1 < s_2 < \cdots < s_N = T$ 上，CD 训练目标为

$$\mathcal{L}_{\text{CD}}^N(\theta, \theta^-; \phi^\times) := \mathbb{E}_{\mathbf{x}_0,\boldsymbol{\epsilon},i}\Big[\omega(s_i)\, d\big(\mathbf{f}_\theta(\mathbf{x}_{s_{i+1}}, s_{i+1}), \mathbf{f}_{\theta^-}(\tilde{\mathbf{x}}_{s_i}^{\phi^\times}, s_i)\big)\Big]. \tag{11.11.2.525}$$

这里 $\omega(\cdot)$ 是时间相关权重，$d(\cdot,\cdot)$ 是距离度量，θ^- 表示 stop-gradient 参数，防止坍缩到平凡解（如常数预测）。

不使用预训练扩散模型（Consistency Training）。 当没有预训练扩散模型可用时，oracle score $\nabla_{\mathbf{x}} \log p_s(\mathbf{x}_s)$ 仍可直接用一个简单单点估计（尽管方差高）来估计。回忆它允许条件期望形式：

$$\begin{aligned}
\nabla_{\mathbf{x}_s}\log p_s(\mathbf{x}_s) &= \mathbb{E}_{\mathbf{x}_0\sim p(\mathbf{x}_0|\mathbf{x}_s)}\big[\nabla_{\mathbf{x}_s}\log p(\mathbf{x}_s \mid \mathbf{x}_0)\big] \\
&= \mathbb{E}_{\mathbf{x}_0\sim p(\mathbf{x}_0|\mathbf{x}_s)}\left[-\frac{\mathbf{x}_s - \alpha_s\mathbf{x}_0}{\sigma_s^2}\right].
\end{aligned}$$

上式提示一个简单单样本估计量。若 $\mathbf{x}_s$ 由配对样本 $(\mathbf{x}_0, \boldsymbol{\epsilon})$ 经 $\mathbf{x}_s = \alpha_s\mathbf{x}_0 + \sigma_s\boldsymbol{\epsilon}$ 得到，则

$$\widehat{\nabla_{\mathbf{x}}\log p_s}(\mathbf{x}_s) := -\frac{\boldsymbol{\epsilon}}{\sigma_s} = -\frac{\mathbf{x}_s - \alpha_s\mathbf{x}_0}{\sigma_s^2}$$

充当 $\mathbf{x}_s$ 处 score 的一个无偏估计量（关于 $p(\mathbf{x}_0 \mid \mathbf{x}_s)$ 条件无偏）。它恰好对应去噪分数匹配中作为回归目标使用的条件 score。

把该估计代入从 s 到 $s' = s - \Delta s$ 的 DDIM 单步更新（式 (9.2.3)），得到

$$\begin{aligned}
\Psi_{s\to s'}(\mathbf{x}_s) &\approx \frac{\alpha_{s'}}{\alpha_s}\mathbf{x}_s + \sigma_s^2\left(\frac{\alpha_{s'}}{\alpha_s} - \frac{\sigma_{s'}}{\sigma_s}\right)\nabla_{\mathbf{x}_s}\log p_s(\mathbf{x}_s) \quad \text{(DDIM)}\\
&\approx \frac{\alpha_{s'}}{\alpha_s}\mathbf{x}_s + \sigma_s^2\left(\frac{\alpha_{s'}}{\alpha_s} - \frac{\sigma_{s'}}{\sigma_s}\right)\widehat{\nabla_{\mathbf{x}_s}\log p_s}(\mathbf{x}_s) \quad \text{(1-pt score)}\\
&= \frac{\alpha_{s'}}{\alpha_s}\mathbf{x}_s - \left(\frac{\alpha_{s'}}{\alpha_s} - \frac{\sigma_{s'}}{\sigma_s}\right)(\mathbf{x}_s - \alpha_s\mathbf{x}_0)\\
&= \alpha_{s'}\mathbf{x}_0 + \sigma_{s'}\boldsymbol{\epsilon},
\end{aligned}$$

其中[38] $\mathbf{x}_0$ 是同一数据样本，$\boldsymbol{\epsilon}$ 是构造 $\mathbf{x}_s$ 时用的同一 Gaussian 噪声。

这给出 oracle 目标 $\mathcal{L}_{\text{oracle-CM}}$ 的一个无教师离散时间替身：

$$\mathcal{L}_{\text{CT}}^N(\theta,\theta^-) := \mathbb{E}_{\mathbf{x}_0,\boldsymbol{\epsilon},i}\Big[\omega(s_i)\,d\big(\mathbf{f}_\theta(\mathbf{x}_{s_{i+1}}, s_{i+1}), \mathbf{f}_{\theta^-}(\mathbf{x}_{s_i}, s_i)\big)\Big], \tag{11.11.2.526}$$

其中 $\mathbf{x}_{s_i} = \alpha_{s_i}\mathbf{x}_0 + \sigma_{s_i}\boldsymbol{\epsilon}$，$\mathbf{x}_{s_{i+1}} = \alpha_{s_{i+1}}\mathbf{x}_0 + \sigma_{s_{i+1}}\boldsymbol{\epsilon}$。

直接用 $\alpha_{s'}\mathbf{x}_0 + \sigma_{s'}\boldsymbol{\epsilon}$ 作为 $\Psi_{s\to s'}(\mathbf{x}_s)$ 的近似而不取期望，会引入高方差[39]。但回忆去噪分数匹配中的类似情形（第 §6.1 节）：单个条件 score 样本作为训练目标，但在损失中对 $\mathbf{x}_0, \boldsymbol{\epsilon}$ 平均后即变为无偏。按同样推理，$\mathcal{L}_{\text{CT}}^N$ 中对 $\mathbf{x}_0$ 与 $\boldsymbol{\epsilon}$ 的期望平均掉这一采样噪声，给出无偏的损失层面近似。下条定理形式化这种期望层面的单点估计正当性。

定理 11.2.1 (误差 $\mathcal{O}(\Delta s^2)$ 内的 CM–CT 等价)**：** 令 $s' := s - \Delta s$，定义

$$\begin{aligned}
\mathcal{L}_{\text{CM}}(\theta,\theta^-) &:= \mathbb{E}_{s,\mathbf{x}_0,\boldsymbol{\epsilon}}\big[w(s)\,d\big(\mathbf{f}_\theta(\mathbf{x}_s, s), \mathbf{f}_{\theta^-}(\mathbf{x}_{s'}^{\text{DDIM}}, s')\big)\big],\\
\mathcal{L}_{\text{CT}}(\theta,\theta^-) &:= \mathbb{E}_{s,\mathbf{x}_0,\boldsymbol{\epsilon}}\big[w(s)\,d\big(\mathbf{f}_\theta(\mathbf{x}_s, s), \mathbf{f}_{\theta^-}(\mathbf{x}_{s'}, s')\big)\big],
\end{aligned}$$

其中

$$\mathbf{x}_{s'}^{\text{DDIM}} := \frac{\alpha_{s'}}{\alpha_s}\mathbf{x}_s + \sigma_s^2\left(\frac{\alpha_{s'}}{\alpha_s} - \frac{\sigma_{s'}}{\sigma_s}\right)\nabla_{\mathbf{x}_s}\log p_s(\mathbf{x}_s)$$

是 oracle DDIM 更新。$\mathbf{x}_s = \alpha_s\mathbf{x}_0 + \sigma_s\boldsymbol{\epsilon}$ 与 $\mathbf{x}_{s'} = \alpha_{s'}\mathbf{x}_0 + \sigma_{s'}\boldsymbol{\epsilon}$ 共享同一配对 $(\mathbf{x}_0, \boldsymbol{\epsilon})$，其中 $\mathbf{x}_0 \sim p_{\text{data}}$，$\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$。则

$$\mathcal{L}_{\text{CM}}(\theta,\theta^-) = \mathcal{L}_{\text{CT}}(\theta,\theta^-) + \mathcal{O}(\Delta s^2).$$

证明： 对定理 11.2.1。首先注意，带 oracle score 的 DDIM 更新等于条件均值

$$\mathbf{x}_{s'}^{\text{DDIM}} = \mathbb{E}[\mathbf{x}_{s'} \mid \mathbf{x}_s],$$

这也可通过对式 (11.2.5) 关于 $p(\cdot \mid \mathbf{x}_s)$ 取期望验证。接着把

$$d\big(\mathbf{f}_\theta(\mathbf{x}_s, s), \mathbf{f}_{\theta^-}(\cdot, s')\big)$$

[38]最后一个恒等式由前向加噪过程 $\mathbf{x}_s = \alpha_s\mathbf{x}_0 + \sigma_s\boldsymbol{\epsilon}$ 经初等代数直接得到。

[39]单点（条件）score 估计 $\widehat{\nabla_{\mathbf{x}}\log p_s}(\mathbf{x}_s)$ 可视为一个单样本 Monte Carlo 估计量，它在给定 $\mathbf{x}_s$ 下是条件无偏的：对一般（通常难处理的）干净后验 $p(\cdot \mid \mathbf{x}_s)$ 平均该估计量即恢复真实 score：$\nabla_{\mathbf{x}_s}\log p_s(\mathbf{x}_s) = \mathbb{E}_{\mathbf{x}_0\sim p(\cdot\mid\mathbf{x}_s)}\big[\widehat{\nabla_{\mathbf{x}}\log p_s}(\mathbf{x}_s)\big]$。

在 $\mathbf{x}_{s'}^{\mathrm{DDIM}} = \mathbb{E}[\mathbf{x}_{s'} \mid \mathbf{x}_s]$ 处做 Taylor 展开。Taylor 展开的线性项消失，因为内层期望正是对 $\mathbf{x}_{s'} \mid \mathbf{x}_s$ 取的，满足 $\mathbb{E}[\mathbf{x}_{s'} - \mathbf{x}_{s'}^{\mathrm{DDIM}} \mid \mathbf{x}_s] = 0$。这表明：通过把条件重参数化为 $\mathbb{E}_{\mathbf{x}_0,\boldsymbol{\epsilon}|\mathbf{x}_s}[\cdot]$、并取 $\mathbf{x}_{s'} = \alpha_{s'}\mathbf{x}_0 + \sigma_{s'}\boldsymbol{\epsilon}$，用 1-pt score 的 DDIM 更新恰好对同一 $(\mathbf{x}_0, \boldsymbol{\epsilon})$ 逐路径恢复 $\mathbf{x}_{s'}$，因此内层期望不变。剩余项是二次的 $\mathcal{O}(\Delta s^2)$，故 $\mathcal{L}_{\mathrm{CT}} = \mathcal{L}_{\mathrm{CM}} + \mathcal{O}(\Delta s^2)$。详细推导见附录 D.5 节。 □

总之，CD 借助教师模型做初始化与引导，往往稳定优化、降低方差。相比之下，Consistency Training（CT）不需要预训练模型，因此可完全从零训练。尽管存在这一差别，CT 仍充当一个完全独立的生成模型。

实用考量。 实践中，Song 等（2023）采用 Karras 等（2022）的 EDM 表述（附录 D.6 节），其前向加噪核为

$$\mathbf{x}_s = \mathbf{x}_0 + s\boldsymbol{\epsilon},$$

并使用其中提出的神经网络参数化（参见式 (D.6.1)）：

$$\mathbf{f}_\theta(\mathbf{x}, s) = c_{\mathrm{skip}}(s)\mathbf{x} + c_{\mathrm{out}}(s)\mathbf{F}_\theta\big(c_{\mathrm{in}}(s)\mathbf{x}, c_{\mathrm{noise}}(s)\big),$$

其中 $\mathbf{F}_\theta$ 是神经网络，系数遵循式 (D.6.5)。该参数化具有重要的边界性质

$$\mathbf{f}_\theta(\mathbf{x}, 0) = \mathbf{x},$$

它在零时刻强制一致性，并确保无噪声时网络输出等于输入。

11.2.2 Consistency Model 的采样

一旦训练好一个一致性模型 $\mathbf{f}_{\theta^\times}$（无论连续还是离散时间），即可用于单步或少数几步生成样本。算法见算法 9。

单步生成。 给定从先验分布采样的初始隐变量 $\hat{\mathbf{x}}_T$（实践中为 $\mathcal{N}(\mathbf{0}, T^2\mathbf{I})$），一次函数评估即可生成干净样本：

$$\mathbf{f}_{\theta^\times}(\hat{\mathbf{x}}_T, T).$$

多步生成。 给定预选时间步

$$T > \tau_1 > \tau_2 > \cdots > \tau_{M-1} = 0,$$

从初始噪声 $\hat{\mathbf{x}}_T$ 出发，在更早时间点上交替进行噪声注入与经由一致性模型的大步干净跳变，逐步精化样本：

$$\hat{\mathbf{x}}_T \xrightarrow[\text{get a clean}]{\text{long jump}} \mathbf{f}_{\theta^\times}(\hat{\mathbf{x}}_T, T) \xrightarrow[\text{to level } \tau_1]{\text{add noise}} \hat{\mathbf{x}}_{\tau_1} \xrightarrow[\text{get a clean}]{\text{long jump}} \mathbf{f}_{\theta^\times}(\hat{\mathbf{x}}_{\tau_1}, \tau_1) \xrightarrow[\text{to level } \tau_2]{\text{add noise}} \cdots .$$

Algorithm 9 CM 的单步或多步生成采样

Require: 一致性模型 $\mathbf{f}_{\theta^\times}(\cdot,\cdot)$；时间点序列 $T>\tau_1>\tau_2>\cdots>\tau_{M-1}=0$；初始噪声 $\hat{\mathbf{x}}_T$

if 单步 **then**
  $\mathbf{x}\leftarrow\mathbf{f}_\theta^\times(\hat{\mathbf{x}}_T,T)$
else
  $\mathbf{x}\leftarrow\mathbf{f}_\theta^\times(\hat{\mathbf{x}}_T,T)$
  for $m=1$ to $M-1$ **do**
    采样 $\boldsymbol{\epsilon}\sim\mathcal{N}(\mathbf{0},\mathbf{I})$
    $\hat{\mathbf{x}}_{\tau_m}\leftarrow\alpha_{\tau_m}\mathbf{x}+\sigma_{\tau_m}\boldsymbol{\epsilon}$
    $\mathbf{x}\leftarrow\mathbf{f}_{\theta^\times}(\hat{\mathbf{x}}_{\tau_m},\tau_m)$
  end for
end if
return x

11.3 特殊流映射：连续时间 Consistency Model

我们现在超越离散时间设定，考虑连续时间视角。与固定时间网格、只在采样点上训练的离散方法不同，连续表述把流映射视为对所有时间都有定义。这一转变消除了对任意离散化的依赖，并与底层动力学做更有原则的对齐。它也有助于减少离散化积分自然引入的近似误差，并确保一致性是全局、而非仅在选定步上被强制。

11.3.1 连续时间 Consistency Model

为动机化连续时间表述，我们先重访式 (11.11.2.524)，它描述了可以对时间求导的条件。用链式法则，得到

$$\frac{\mathrm{d}}{\mathrm{d}s}\mathbf{f}^*(\mathbf{x}(s),s)=0\quad\Longleftrightarrow\quad(\nabla_{\mathbf{x}}\mathbf{f}^*)(\mathbf{x}(s),s)\cdot\underbrace{\frac{\mathrm{d}}{\mathrm{d}s}\mathbf{x}(s)}_{\text{ODE velocity}}+\left(\frac{\partial}{\partial s}\mathbf{f}^*\right)(\mathbf{x}(s),s)=0,\tag{11.11.3.527}$$

其中轨迹 $\mathbf{x}(s)$ 遵循 PF-ODE

$$\frac{\mathrm{d}}{\mathrm{d}s}\mathbf{x}(s)=\mathbf{v}^*(\mathbf{x}(s),s).$$

这一关系表明一致性函数沿 ODE 的任意解轨迹保持常数。速度场 $\mathbf{v}^*$ 实践中可从预训练扩散模型（若可用）估计，或直接用一个单点近似，如 $\alpha_s'\mathbf{x}_0+\sigma_s'\boldsymbol{\epsilon}$，如第 §11.2 节所释。

式 (11.11.3.527) 提示了一种在连续时间下设计训练目标的自然方式。一种途径是以类似物理 informed 神经网络（PINN，Raissi, 2018；Boffi 等, 2024）的方式最小化残差：

$$\min_\theta\mathbb{E}_{s,\mathbf{x}_0,\boldsymbol{\epsilon}}\left[\left\|\frac{\mathrm{d}}{\mathrm{d}s}\mathbf{f}_\theta(\mathbf{x}_s,s)\right\|_2^2\right].$$

然而实践中，Song 等（2023）与 Lu 和 Song（2024）观察到另一种表述在训练中效果更好。他们不直接强制微分条件，而是考虑离散近似在 $\Delta s \to 0$ 时的连续时间极限：

$$\mathcal{L}_{\mathrm{CM}}^{\Delta s}(\theta, \theta^-) := \mathbb{E}\Big[\omega(s)\big\|\mathbf{f}_\theta(\mathbf{x}_s, s) - \mathbf{f}_{\theta^-}\big(\Psi_{s\to s-\Delta s}(\mathbf{x}_s), s-\Delta s\big)\big\|_2^2\Big]. \tag{11.11.3.528}$$

在式 (11.11.3.528) 中取 $\Delta s \to 0$，等价于在式 (11.11.2.525) 与式 (11.11.2.526) 中令时间步数 $N \to \infty$。

我们将这一关键思想总结为下命题。

命题 11.3.1 (连续时间 Consistency Training)**：** 下述收敛结果成立：

$$\lim_{\Delta s\to 0} \frac{1}{\Delta s}\nabla_\theta \mathcal{L}_{\mathrm{CM}}^{\Delta s}(\theta, \theta^-) = \nabla_\theta \mathcal{L}_{\mathrm{CM}}^{\infty}(\theta, \theta^-).$$

这里

$$\mathcal{L}_{\mathrm{CM}}^{\infty}(\theta, \theta^-) := \mathbb{E}_{s,\mathbf{x}_0,\boldsymbol{\epsilon}}\left[2\omega(t)\mathbf{f}_\theta^\top(\mathbf{x}_s, s)\cdot \frac{\mathrm{d}}{\mathrm{d}s}\mathbf{f}_{\theta^-}(\mathbf{x}_s, s)\right],$$

以及全微分恒等式

$$\frac{\mathrm{d}}{\mathrm{d}s}\mathbf{f}_{\theta^-}(\mathbf{x}_s, s) = \partial_s \mathbf{f}_{\theta^-}(\mathbf{x}_s, s) + \left(\partial_{\mathbf{x}}\mathbf{f}_{\theta^-}(\mathbf{x}_s, s)\right)\mathbf{v}^*(\mathbf{x}_s, s). \tag{11.11.3.529}$$

证明： 对命题 11.3.1。把 stop-gradient 目标在 $(\mathbf{x}_s, s)$ 周围做一阶 Taylor 展开，可见损失 $\mathcal{L}_{\mathrm{CM}}^{\Delta s}$ 在 $\mathcal{O}(\Delta s^2)$ 内等价于学生更新 $\nabla_\theta \mathbf{f}_\theta(\mathbf{x}_s, s)$ 与切向变化 $\frac{\mathrm{d}}{\mathrm{d}s}\mathbf{f}_{\theta^-}(\mathbf{x}_s, s)$ 的内积。于是 scaled 梯度满足

$$\lim_{\Delta s\to 0}\frac{1}{\Delta s}\nabla_\theta \mathcal{L}_{\mathrm{CM}}^{\Delta s} = \nabla_\theta \mathbb{E}\Big[\tilde{\omega}(s)\mathbf{f}_\theta^\top(\mathbf{x}_s, s)\cdot\frac{\mathrm{d}}{\mathrm{d}s}\mathbf{f}_{\theta^-}(\mathbf{x}_s, s)\Big],$$

即所声称的恒等式。证明细节见附录 D.5 节。 □

上述结果写在梯度算子 ∇_θ 下，使涉及 θ^- 的项消失，因为 θ^- 在 stop-gradient 下视为常数。注意 $\frac{\mathrm{d}}{\mathrm{d}s}\mathbf{f}_{\theta^-}(\mathbf{x}_s, s)$ 表示沿 oracle 轨迹的全导数，而非简单偏导数。

总之，连续时间一致性模型可通过最小化下述目标来训练（忽略因子 2）：

$$\mathcal{L}_{\mathrm{CM}}^{\infty}(\theta, \theta^-) := \mathbb{E}_{s,\mathbf{x}_0,\boldsymbol{\epsilon}}\left[\omega(s)\mathbf{f}_\theta^\top(\mathbf{x}_s, s)\cdot \frac{\mathrm{d}}{\mathrm{d}s}\mathbf{f}_{\theta^-}(\mathbf{x}_s, s)\right]. \tag{11.11.3.530}$$

11.3.2 训练连续时间 Consistency Model

与第 §11.2.1 节讨论的离散时间情形类似，我们现在澄清式 (11.11.3.530) 中切向项的实用逼近，它涉及不可访问的 oracle 速度 $\mathbf{v}^*$：

$$\frac{\mathrm{d}}{\mathrm{d}s}\mathbf{f}_{\theta^-}(\mathbf{x}_s, s) = \partial_s \mathbf{f}_{\theta^-}(\mathbf{x}_s, s) + \left(\partial_{\mathbf{x}}\mathbf{f}_{\theta^-}(\mathbf{x}_s, s)\right)\mathbf{v}^*(\mathbf{x}_s, s).$$

训练好连续时间 CM 后，采样流程与离散时间情形相同（第 §11.2.2 节）。

连续时间 Consistency Distillation。 若有一个预训练扩散模型使 $\mathbf{v}_{\phi^\times} \approx \mathbf{v}^*$，则式 (11.11.3.529) 中的切向量 $\frac{\mathrm{d}}{\mathrm{d}s}\mathbf{f}_{\theta^-}(\mathbf{x}_s, s)$ 可用替身

$$\frac{\mathrm{d}}{\mathrm{d}s}\mathbf{f}_{\theta^-}(\mathbf{x}_s, s) \approx \partial_s \mathbf{f}_{\theta^-}(\mathbf{x}_s, s) + (\partial_{\mathbf{x}} \mathbf{f}_{\theta^-}(\mathbf{x}_s, s))\, \mathbf{v}_{\phi^\times}(\mathbf{x}_s, s). \tag{11.11.3.531}$$

得到的目标记为 $\mathcal{L}^{\infty}_{\mathrm{CD}}(\theta, \theta^-; \phi^\times)$。相应地，命题 11.3.1 可重述为

$$\lim_{N\to\infty} N\nabla_\theta \mathcal{L}^N_{\mathrm{CD}}(\theta, \theta^-; \phi^\times) = \nabla_\theta \mathcal{L}^{\infty}_{\mathrm{CD}}(\theta, \theta^-; \phi^\times).$$

连续时间 Consistency Training（从零开始）。 另一方面，若无预训练扩散模型，oracle 速度 $\mathbf{v}^*$ 可用单点条件估计 $\alpha'_s\mathbf{x}_0 + \sigma'_s\boldsymbol{\epsilon}$ 逼近。此时式 (11.11.3.529) 中的切向量 $\frac{\mathrm{d}}{\mathrm{d}s}\mathbf{f}_{\theta^-}(\mathbf{x}_s, s)$ 被替身

$$\frac{\mathrm{d}}{\mathrm{d}s}\mathbf{f}_{\theta^-}(\mathbf{x}_s, s) \approx \partial_s \mathbf{f}_{\theta^-}(\mathbf{x}_s, s) + (\partial_{\mathbf{x}} \mathbf{f}_{\theta^-}(\mathbf{x}_s, s))\, (\alpha'_s\mathbf{x}_0 + \sigma'_s\boldsymbol{\epsilon}). \tag{11.11.3.532}$$

得到的目标记为 $\mathcal{L}^{\infty}_{\mathrm{CT}}(\theta, \theta^-)$，对应从零训练设定。相应地，命题 11.3.1 可重述为

$$\lim_{N\to\infty} N\nabla_\theta \mathcal{L}^N_{\mathrm{CT}}(\theta, \theta^-) = \nabla_\theta \mathcal{L}^{\infty}_{\mathrm{CT}}(\theta, \theta^-).$$

至此，我们已介绍表 11 中所有实现学习一致性函数 $\Psi_{s\to 0}$ 的基础方法。为给出更清晰的总览，图 11.47 总结了各训练一致性函数的损失之间的关系，并指出各方法是否依赖预训练扩散模型、以及连续时间与离散时间目标之间的区别。

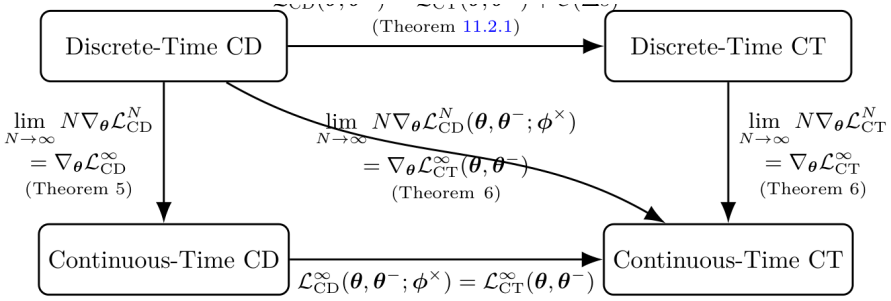


Figure 11.3: Diagram showing relationships between discrete/continuous time CD and

图 11.47: 离散/连续时间 CD 与 CT 在 ℓ_2 距离度量 $d(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\|_2^2$ 下的关系图。所标定理沿用 Song 等（2023）中的编号。凡涉及 CT 的定理，均假设完美 score：$s_{\phi^\times}(\mathbf{x}, t) \equiv \nabla_{\mathbf{x}} \log p_t(\mathbf{x})$。$\mathcal{L}^{\infty}_{\mathrm{CT}}$ 定义于式 (11.11.3.530)，$\mathcal{L}^{\infty}_{\mathrm{CD}}$ 定义于式 (11.11.3.531)。

然而切向量 $\frac{\mathrm{d}}{\mathrm{d}s}\mathbf{f}_{\theta^-}$ 常在训练中引起不稳定。在接下来的可选小节中，我们介绍 Simplifying, Stabilizing and Scaling Continuous Time Consistency Models（sCM，Lu 与 Song, 2024）中缓解这些问题的技术。

11.3.3 （可选）连续时间一致性训练的实用考量

我们的兴趣在从零训练场景，因为它给出一个不依赖外部预训练扩散模型的独立生成模型。因此我们聚焦连续时间情形。

然而实践中，直接按式 (11.11.3.530) 训练常不稳定，因为 $\frac{\mathrm{d}}{\mathrm{d}s}\mathbf{f}_{\theta^-}$ 项可能出现大或无界的时间导数，导致优化时梯度爆炸。为克服这一点，通常需要合适的参数化与稳定化策略（Geng 等, 2025b; Lu 与 Song, 2024）。如第 §6.2.2 节所总结，影响稳定训练的主要因素包括扩散过程、参数化选择、时间权重函数与时间采样分布，它们在连续时间 CM 中也都应被仔细设计并解耦。

扩散过程。 Lu 与 Song（2024）不使用标准扩散参数化 $\mathbf{x}_s = \alpha_s \mathbf{x}_0 + \sigma_s \boldsymbol{\epsilon}$（$\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$），而采用一个三角调度。该调度虽在数学上等价于原形式（式 (6.3.4)），但在训练目标中给出更干净的结构与更好的分离，有助于提升训练稳定性[40]。此外，他们引入数据分布 p_{data} 的标准差 σ_{d}，与附录 D.6 节 EDM 的设计一致：

$$\mathbf{x}_s := \cos(s)\mathbf{x}_0 + \sin(s)\mathbf{z}, \qquad \mathbf{z} \sim \mathcal{N}(\mathbf{0}, \sigma_{\mathrm{d}}^2 \mathbf{I}). \tag{11.11.3.533}$$

该表述是完全一般的。对任意形如 $\mathbf{x}_s = \alpha_s \mathbf{x}_0 + \sigma_s \boldsymbol{\epsilon}$（$\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$）的扩散过程，我们可等价写为

$$\mathbf{x}_s = \alpha_s \mathbf{x}_0 + \frac{\sigma_s}{\sigma_{\mathrm{d}}} \cdot (\sigma_{\mathrm{d}} \boldsymbol{\epsilon}),$$

通过定义 $\mathbf{z} := \sigma_{\mathrm{d}} \boldsymbol{\epsilon}$，$\alpha'_s := \alpha_s$，$\sigma'_s := \frac{\sigma_s}{\sigma_{\mathrm{d}}}$。变换后的对 (α'_s, σ'_s) 可再按式 (6.3.5) 所述归一化映射到三角形式 $(\cos(s), \sin(s))$。

参数化。 通过借鉴附录 D.6.1 节 EDM 的类似原理，Lu 与 Song（2024）提出如下神经网络参数化，与式 (D.6.1) 类似：

$$\mathbf{f}_\theta(\mathbf{x}, s) := c_{\text{skip}}(s)\mathbf{x} + c_{\text{out}}(s)\mathbf{F}_\theta\big(c_{\text{in}}(s)\mathbf{x}, c_{\text{noise}}(s)\big).$$

这里 $c_{\text{skip}}(s)$、$c_{\text{out}}(s)$ 与 $c_{\text{in}}(s)$ 可用第附录 D.6.1 节中的相同准则导出（详细推导见 Lu 与 Song, 2024 附录 B），给定为

$$c_{\text{skip}}(s) = \cos(s), \quad c_{\text{out}}(s) = -\sigma_{\mathrm{d}} \sin(s), \quad c_{\text{in}}(s) \equiv \frac{1}{\sigma_{\mathrm{d}}}.$$

这与默认选择 $c_{\text{noise}}(s) = s$ 一起考虑，其中 $\partial_s c_{\text{noise}}(s)$ 有界以保证训练稳定，将在式 (11.11.3.536) 附近讨论。这在三角调度下给出如下参数化：

$$\mathbf{f}_\theta(\mathbf{x}, s) = \cos(s)\mathbf{x} - \sin(s)\sigma_{\mathrm{d}}\mathbf{F}_\theta\left(\frac{\mathbf{x}}{\sigma_{\mathrm{d}}}, c_{\text{noise}}(s)\right). \tag{11.11.3.534}$$

我们注意到该参数化还确保神经网络对所有 $\mathbf{x}$ 都满足边界条件 $\mathbf{f}_\theta(\mathbf{x}, 0) \equiv \mathbf{x}$，这是一致性函数的一条本质性质。

稳定切向训练的技术。 在三角调度与式 (11.11.3.534) 的网络参数化下，式 (11.11.3.530) 中损失的梯度变为

$$\nabla_\theta \mathcal{L}_{\text{CT}}^{\infty}(\theta, \theta^-) = \nabla_\theta \mathbb{E}_{s, \mathbf{x}_0, \boldsymbol{\epsilon}}\left[-\omega(s)\sigma_{\mathrm{d}} \sin(s) \mathbf{F}_\theta^\top\left(\frac{\mathbf{x}_s}{\sigma_{\mathrm{d}}}, s\right) \cdot \frac{\mathrm{d}}{\mathrm{d}s}\mathbf{f}_{\theta^-}(\mathbf{x}_s, s)\right]. \tag{11.11.3.535}$$

[40] 直觉上，三角函数及其导数都有界，这有助于防止 $\frac{\mathrm{d}}{\mathrm{d}s}\mathbf{f}_{\theta^-}$ 这类项中的尺度爆炸。详细讨论见后文。

理论上，用式 (11.11.3.535) 的梯度更新训练即足以学习一致性函数。然而 Lu 与 Song（2024）实证观察到，由于切向函数的行为，训练过程在实践中可能变得不稳定：

$$\underbrace{\frac{\mathrm{d}}{\mathrm{d}s}\mathbf{f}_{\theta^-}(\mathbf{x}_s, s)}_{\text{A.}} = -\cos(s)\left(\sigma_{\mathrm{d}}\nabla_{\mathbf{x}_s}\mathbf{F}_{\theta^-}\left(\frac{\mathbf{x}_s}{\sigma_{\mathrm{d}}}, s\right) - \frac{\mathrm{d}\mathbf{x}_s}{\mathrm{d}s}\right) - \sin(s)\left(\mathbf{x}_s + \sigma_{\mathrm{d}}\frac{\mathrm{d}\mathbf{F}_{\theta^-}}{\mathrm{d}s}\left(\frac{\mathbf{x}_s}{\sigma_{\mathrm{d}}}, c_{\text{noise}}(s)\right)\right).$$

特别地，在项

$$\underbrace{\sin(s)\frac{\mathrm{d}\mathbf{F}_{\theta^-}}{\mathrm{d}s}\left(\frac{\mathbf{x}_s}{\sigma_{\mathrm{d}}}, c_{\text{noise}}(s)\right)}_{\text{B.}} = \sin(s)\nabla_{\mathbf{x}_s}\mathbf{F}_{\theta^-}\frac{\mathrm{d}\mathbf{x}_s}{\mathrm{d}s} + \sin(s)\partial_s\mathbf{F}_{\theta^-}$$

中观察到不稳定。更具体地，不稳定性来自分量

$$\sin(s)\partial_s\mathbf{F}_{\theta^-} = \sin(s)\underbrace{\frac{\partial c_{\text{noise}}(s)}{\partial s}\cdot\frac{\partial \mathrm{emb}(c_{\text{noise}})}{\partial c_{\text{noise}}}\cdot\frac{\partial\mathbf{F}_{\theta^-}}{\partial \mathrm{emb}(c_{\text{noise}})}}_{\text{C.}}. \tag{11.11.3.536}$$

这里我们遵循 DM 与 CM 文献中的常见做法，对时间变量 $c_{\text{noise}}(s)$ 施加 positional 或 Fourier 嵌入，记为 $\mathrm{emb}(\cdot)$：

$$s \mapsto c_{\text{noise}}(s) \mapsto \mathrm{emb}(c_{\text{noise}}(s)) \mapsto \mathbf{F}_{\theta^-}\left(\frac{\mathbf{x}_s}{\sigma_{\mathrm{d}}}, \mathrm{emb}(c_{\text{noise}}(s))\right).$$

因此引入若干额外实证技术以缓解不稳定：

- **A. 切向归一化**。显式归一化切向函数，把 $\frac{\mathrm{d}}{\mathrm{d}s}\mathbf{f}_{\theta^-}$ 替换为 $\frac{\frac{\mathrm{d}}{\mathrm{d}s}\mathbf{f}_{\theta^-}}{\|\frac{\mathrm{d}}{\mathrm{d}s}\mathbf{f}_{\theta^-}\|_2+c}$，其中 $c>0$ 是经验设定的常数。或者，把切向裁剪在 $[-1,1]$ 内也可有效限制其方差。
- **B. 切向 warm-up**。由于项 $\sin(s)(\mathbf{x}_s+\sigma_{\mathrm{d}}\frac{\mathrm{d}}{\mathrm{d}s}\mathbf{F}_{\theta^-})$ 可能引入不稳定，一个可选技术是把系数 $\sin(s)$ 替换为 $r\cdot\sin(s)$，其中 r 在最初少数训练迭代中从 0 线性增加到 1。
- **C. 时间嵌入**。鉴于式 (11.11.3.536) 中的求导链，Lu 与 Song（2024）选择更小量级的参数来控制导数 $\frac{\partial \mathrm{emb}(c_{\text{noise}})}{\partial c_{\text{noise}}}$。类似地，选择 $c_{\text{noise}}(s)=s$，其中 $\partial_s c_{\text{noise}}(s)=1$ 为有界常数。

在这些之上，为改进归一化（稳定性）与高效的 JVP 计算 $\frac{\mathrm{d}}{\mathrm{d}s}\mathbf{f}_{\theta^-}$，往往还需要架构改动，但已超出本章范围。

时间权重函数。手工设计时间权重函数 $\omega(s)$ 可能导致次优性能。为此，Lu 与 Song（2024）仿照 EDM-2（Karras 等, 2024）的类似做法，学习一个自适应权重函数 $\omega_\varphi(s)$ 来平衡不同时刻 s 处的训练损失方差（期望结果见式 (11.11.3.537)）。

为进一步说明，我们注意到式 (11.11.3.535) 中目标函数的形式为

$$\mathbb{E}_{s,\mathbf{x}_0,\boldsymbol{\epsilon}}\left[\mathbf{F}_\theta^\top\mathbf{y}\right], \quad \text{其中}\mathbf{y} = -\omega(s)\sigma_{\mathrm{d}}\sin(s)\frac{\mathrm{d}}{\mathrm{d}s}\mathbf{f}_{\theta^-}.$$

由于 $\mathbf{y}$ 是一个与 θ 无关的向量，式 (11.11.3.535) 等价于

$$\nabla_\theta \mathbb{E}_{s,\mathbf{x}_0,\boldsymbol{\epsilon}}\left[\mathbf{F}_\theta^\top \mathbf{y}\right] = \frac{1}{2}\nabla_\theta \mathbb{E}_{s,\mathbf{x}_0,\boldsymbol{\epsilon}}\|\mathbf{F}_\theta - \mathbf{F}_{\theta^-} + \mathbf{y}\|_2^2.$$

基于这一观察，Lu 与 Song（2024）额外提出训练一个自适应权重网络 $\omega_\varphi(s)$ 来估计损失范数，表述为如下最小化问题：

$$\min_\varphi \mathbb{E}_{s,\mathbf{x}_0,\boldsymbol{\epsilon}}\left[\frac{e^{\omega_\varphi(s)}}{D}\|\mathbf{F}_\theta - \mathbf{F}_{\theta^-} + \mathbf{y}\|_2^2 - \omega_\varphi(s)\right].$$

为理解自适应加权的效果，注意上述目标关于 ω_φ 取偏导得到的最优解 $\omega^*(s)$ 满足

$$\mathbb{E}_{s,\mathbf{x}_0,\boldsymbol{\epsilon}}\left[\frac{e^{\omega^*(s)}}{D}\|\mathbf{F}_\theta - \mathbf{F}_{\theta^-} + \mathbf{y}\|_2^2\right] = 1. \tag{11.11.3.537}$$

即在重标定后，不同 s 处的期望（加权）损失保持均匀。于是自适应加权有效减少了不同时间步间训练损失的方差，带来更平衡、稳定的训练。

时间采样分布。 Lu 与 Song (2024) 选择从一个 log-normal 提议分布采样 $\tan(s)$ (Karras 等, 2022)，即

$$e^{\sigma_\mathrm{d}\tan(s)} \sim \mathcal{N}(\cdot; P_\mathrm{mean}, P_\mathrm{std}^2). \tag{11.11.3.538}$$

这里 P_mean 与 P_std 是两个超参数。

训练目标总结。 综上，最终训练损失写为

$$\mathcal{L}_\mathrm{sCM}(\theta,\varphi) := \mathbb{E}_{s,\mathbf{x}_0,\boldsymbol{\epsilon}}\left[\frac{e^{\omega_\varphi(s)}}{D}\left\|\mathbf{F}_\theta\left(\frac{\mathbf{x}_s}{\sigma_\mathrm{d}}, s\right) - \mathbf{F}_{\theta^-}\left(\frac{\mathbf{x}_s}{\sigma_\mathrm{d}}, s\right) - \cos(s)\frac{\mathrm{d}}{\mathrm{d}s}\mathbf{f}_{\theta^-}(\mathbf{x}_s, s)\right\|_2^2 - \omega_\varphi(s)\right].$$

这里 s 按式 (11.11.3.538) 采样，$\mathbf{x}_s$ 由式 (11.11.3.533) 计算。用该损失训练的模型称为 sCM，其训练流程总结于算法 10。

11.4 一般流映射：Consistency Trajectory Model

Consistency Trajectory Model (CTM, Kim 等, 2024a) 是首批学习一般流映射 $\Psi_{s\to t}$ 的方法之一。

实践中 CTM 的设定。 与 CM 族类似，CTM 最初遵循 EDM（Karras 等, 2022）的表述（附录 D.6 节），使用 $\mathbf{x}$-prediction 形式的 PF-ODE，噪声调度 $\alpha_t = 1$、$\sigma_t = t$。在该设定下，PF-ODE 变为

$$\frac{\mathrm{d}\mathbf{x}(\tau)}{\mathrm{d}\tau} = \frac{\mathbf{x}(\tau) - \mathbb{E}[\mathbf{x} \mid \mathbf{x}(\tau)]}{\tau}.$$

从时刻 s 的 $\mathbf{x}_s$ 出发、演化到更晚时刻 $t \le s$，对应流映射（解）可等价写为

$$\mathbf{x}_s + \int_s^t \frac{\mathbf{x}_\tau - \mathbb{E}[\mathbf{x} \mid \mathbf{x}_\tau]}{\tau}\,\mathrm{d}\tau.$$

Algorithm 10 连续时间 Consistency Model（sCM）的训练

Require: 数据集 $\mathcal{D}$（标准差 σ_{d}）；带参数 $\theta_{\mathrm{pretrain}}$ 的预训练 DM $\mathbf{F}_{\mathrm{pretrain}}$；模型 $\mathbf{F}_\theta$；权重 ω_φ；学习率 η；提议分布 $(P_{\mathrm{mean}}, P_{\mathrm{std}}^2)$；常数 c；warm-up 迭代数 H

$\theta \leftarrow \theta_{\mathrm{pretrain}}$；Iters $\leftarrow 0$

repeat

  $\mathbf{x}_0 \sim \mathcal{D}$，$\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \sigma_{\mathrm{d}}^2 \mathbf{I})$，$\tau \sim \mathcal{N}(P_{\mathrm{mean}}, P_{\mathrm{std}}^2)$，$s \leftarrow \arctan\left(\frac{e^\tau}{\sigma_{\mathrm{d}}}\right)$

  $\mathbf{x}_s \leftarrow \cos(s)\mathbf{x}_0 + \sin(s)\mathbf{z}$

  if 一致性训练 **then**

    $\frac{\mathrm{d}\mathbf{x}_s}{\mathrm{d}s} \leftarrow \cos(s)\mathbf{z} - \sin(s)\mathbf{x}_0$

  else

    $\frac{\mathrm{d}\mathbf{x}_s}{\mathrm{d}s} \leftarrow \sigma_{\mathrm{d}} \mathbf{F}_{\mathrm{pretrain}}\left(\frac{\mathbf{x}_s}{\sigma_{\mathrm{d}}}, s\right)$

  end if

  $r \leftarrow \min\left(1, \frac{\mathrm{Iters}}{H}\right)$ ▷ 切向 warm-up

  $\mathbf{w} \leftarrow -\cos^2(s)\left(\sigma_{\mathrm{d}} \mathbf{F}_\theta^- - \frac{\mathrm{d}\mathbf{x}_s}{\mathrm{d}s}\right) - r\cos(s)\sin(s)\left(\mathbf{x}_s + \sigma_{\mathrm{d}} \frac{\mathrm{d}\mathbf{f}_{\theta^-}}{\mathrm{d}s}\right)$

  $\mathbf{w} \leftarrow \frac{\mathbf{w}}{\|\mathbf{w}\| + c}$ ▷ 切向归一化

  $\mathcal{L}_{\mathrm{sCM}}(\theta, \varphi) \leftarrow \frac{e^{\omega_\varphi(s)}}{D}\left\|\mathbf{F}_\theta\left(\frac{\mathbf{x}_s}{\sigma_{\mathrm{d}}}, s\right) - \mathbf{F}_{\theta^-}\left(\frac{\mathbf{x}_s}{\sigma_{\mathrm{d}}}, s\right) - \mathbf{w}\right\|_2^2 - \omega_\varphi(s)$ ▷ 自适应加权

  $(\theta, \varphi) \leftarrow (\theta, \varphi) - \eta \nabla_{\theta,\varphi} \mathcal{L}_{\mathrm{sCM}}(\theta, \varphi)$

  Iters $\leftarrow$ Iters $+ 1$

until 收敛

CTM 采用 Euler 启发的参数化：对 PF-ODE 应用单步 Euler 求解器（等价地 DDIM；式 (9.2.4)），给出

$$\mathbf{x}_{s\to t}^{\mathrm{Euler}} = \mathbf{x}_s - (s-t)\frac{\mathbf{x}_s - \mathbb{E}[\mathbf{x} \mid \mathbf{x}_s]}{s} = \frac{t}{s}\mathbf{x}_s + \left(1 - \frac{t}{s}\right)\mathbb{E}[\mathbf{x} \mid \mathbf{x}_s],$$

其中 $\mathbf{x}_{s\to t}^{\mathrm{Euler}}$ 给定时刻 s 的状态 $\mathbf{x}_s$、逼近时刻 t 的解。

虽然 EDM 设定提供了简单的示意情形，CTM 允许由任意线性 Gaussian 前向核 (α_t, σ_t) 定义的更宽噪声调度，并以 $\mathbf{v}$-prediction 形式表达 PF-ODE：

$$\Psi_{s\to t}(\mathbf{x}_s) = \mathbf{x}_s + \int_s^t \mathbf{v}^*(\mathbf{x}_u, u)\,\mathrm{d}u.$$

下文我们聚焦这一一般表述。

11.4.1 用于灵活转移学习的 CTM 参数化

沿上述 PF-ODE 的单步 Euler 求解器，CTM 把 oracle 流映射 $\Psi_{s\to t}$ 重写为输入 $\mathbf{x}_s$ 与一个残差函数 $\mathbf{g}^*$ 的凸组合：

$$\Psi_{s\to t}(\mathbf{x}_s) := \mathbf{x}_s + \int_s^t \mathbf{v}^*(\mathbf{x}_u, u)\,\mathrm{d}u = \frac{t}{s}\mathbf{x}_s + \frac{s-t}{s}\underbrace{\left[\mathbf{x}_s + \frac{s}{s-t}\int_s^t \mathbf{v}^*(\mathbf{x}_u, u)\,\mathrm{d}u\right]}_{=:\mathbf{g}^*}.$$

其中残差项 $\mathbf{g}^*$ 定义为

$$\mathbf{g}^*(\mathbf{x}_s, s, t) := \mathbf{x}_s + \frac{s}{s-t}\int_s^t \mathbf{v}^*(\mathbf{x}_u, u)\,\mathrm{d}u. \tag{11.11.4.539}$$

这启发了神经参数化

$$\mathbf{G}_\theta(\mathbf{x}_s, s, t) := \frac{t}{s}\mathbf{x}_s + \frac{s-t}{s}\mathbf{g}_\theta(\mathbf{x}_s, s, t), \tag{11.11.4.540}$$

其中 $\mathbf{g}_\theta$ 是一个神经网络，目标是 $\mathbf{g}_\theta \approx \mathbf{g}^*$，因此 $\mathbf{G}_\theta(\mathbf{x}_s, s, t)$ 被训练为逼近 oracle 流映射

$$\mathbf{G}_\theta(\mathbf{x}_s, s, t) \approx \Psi_{s\to t}(\mathbf{x}_s).$$

因此 CTM 自然落入式 (11.11.1.520) 的一般一致性映射框架，使学到的映射与 oracle 流映射对齐。

此外，该表述内在满足初始条件

$$\mathbf{G}_\theta(\mathbf{x}_s, s, s) = \mathbf{x}_s,$$

无需在训练中显式施加。

CTM 参数化的优势。 当 t 趋近 s（即结束时刻等于起始时刻）时，$\mathbf{g}^*$ 的一条关键性质变得明显：

命题 11.4.1 ($\mathbf{g}^*$ 的性质)**：** 1. **恢复扩散模型**：

$$\mathbf{g}^*(\mathbf{x}_s, s, s) = \lim_{t\to s}\mathbf{g}^*(\mathbf{x}_s, s, t) = \mathbf{x}_s - s\mathbf{v}^*(\mathbf{x}_s, s).$$

2. **积分表示**：

$$\mathbf{g}^*(\mathbf{x}_s, s, t) = \mathbf{x}_s - s\mathbf{v}^*(\mathbf{x}_s, s) + \mathcal{O}(|t-s|).$$

证明： 对命题 11.4.1。由 $\mathbf{g}^*$ 的定义，得到

$$\lim_{s\to t}\mathbf{g}^*(\mathbf{x}_s, s, t) = \mathbf{x}_t - s\lim_{s\to t}\frac{1}{t-s}\int_s^t \mathbf{v}^*(\mathbf{x}_\tau, \tau)\,\mathrm{d}\tau = \mathbf{x}_s - s\mathbf{v}^*(\mathbf{x}_s, s).$$

这就证明了第一个恒等式。对第二个断言，由 Taylor 展开，有

$$\begin{aligned}\mathbf{g}^*(\mathbf{x}_s, s, t) &= \mathbf{x}_s - \frac{s}{s-t}\int_t^s \mathbf{v}^*(\mathbf{x}_\tau, \tau)\,\mathrm{d}\tau \\ &= \mathbf{x}_s - \frac{s}{s-t}\left[(s-t)\mathbf{v}^*(\mathbf{x}_s, s) + \mathcal{O}((t-s)^2)\right] \\ &= \mathbf{x}_s - s\mathbf{v}^*(\mathbf{x}_s, s) + \mathcal{O}(|t-s|).\end{aligned}$$

□

由该命题可得：

1. 估计 $\mathbf{g}^*$ 不仅能逼近有限的 $s \to t$ 转移（当 $s \le t$），还能逼近由瞬时速度 $\mathbf{v}^*$ 刻画的无穷小 $s \to s$ 转移。

2. $\mathbf{g}^*(\mathbf{x}_s, s, t)$ 可解释为 oracle 速度 $\mathbf{v}^*$ 加上一个 Taylor 展开残差项。

因此，通过利用式 (11.11.4.540) 中 CTM 的参数化，学习 $\mathbf{G}_\theta \approx \Psi_{s\to t}$（等价地 $\mathbf{g}_\theta \approx \mathbf{g}^*$）既带来经由 $\mathbf{G}_\theta$ 的长跳能力，又通过 $\mathbf{g}_\theta$ 恢复扩散模型的速度（等价地 score 函数/去噪器）。因此该参数化是关键：通过学习 $\mathbf{g}^*$，CTM 在单一框架下统一了扩散模型与一致性模型（特殊流映射）的优势。

接下来两节中，我们先介绍 CTM 的一致性损失（第 §11.4.2 节），它同时支持蒸馏与从零训练，并强制半群性质以达到 $\mathbf{G}_\theta(\cdot, s, t) \approx \Psi_{s\to t}(\cdot, s, t)$。随后描述由式 (11.11.4.540) 参数化自然产生的辅助损失（第 §11.4.3 节），包括扩散模型损失与 GAN 损失，它们显著提升 CTM 的性能。

11.4.2 CTM 中的一致性损失

CTM 旨在逼近 oracle 解映射

$$\mathbf{G}_\theta(\cdot, s, t) \approx \Psi_{s\to t}(\cdot, s, t),$$

对任意 $s \ge t$。由于 oracle $\Psi_{s\to t}$ 通常没有闭式，CTM 通过强制半群性质（式 (11.11.2.522)）构造一个可行的回归目标：对任意 $s \ge u \ge t$，

$$\Psi_{u\to t} \circ \Psi_{s\to u} = \Psi_{s\to t}.$$

根据是否有预训练扩散模型可用，流映射 $\Psi_{s\to t}$ 可用不同方式逼近。下文我们假设 $s \ge u \ge t \in [0, T]$。

经由蒸馏训练。 假设可访问一个预训练扩散模型，其给出 $\mathbf{v}_{\phi^\times}(\mathbf{x}_s, s) \approx \mathbf{v}^*(\mathbf{x}_s, s)$。于是 PF-ODE 由经验动力学逼近

$$\frac{\mathrm{d}\mathbf{x}(\tau)}{\mathrm{d}\tau} = \mathbf{v}_{\phi^\times}(\mathbf{x}_\tau, \tau). \tag{11.11.4.541}$$

CTM 训练 $\mathbf{G}_\theta$ 以匹配应用于该经验 ODE 的数值求解器 $\texttt{Solver}_{s\to t}(\mathbf{x}_s; \phi^\times)$，后者充当 oracle 的可计算替身：

$$\mathbf{G}_\theta(\mathbf{x}_s, s, t) \approx \texttt{Solver}_{s\to t}(\mathbf{x}_s; \phi^\times) \approx \Psi_{s\to t}(\mathbf{x}_s, s, t).$$

有强教师时，求解器可恢复 $\Psi_{s\to t}$ 至多离散步误差，因此最优学生紧密匹配 ground truth（见 Kim 等, 2024a，命题 3 与 4）。

然而，当 s 与 t 相距较远时，训练循环中对整个区间 $[t, s]$ 求解代价高昂。为提升效率并提供更平滑的信号，CTM 引入软一致性匹配（soft consistency matching），把半群性质操作化。如图 11.48 所示，CTM 在时刻 t 比较两个预测：直接学生输出 $\mathbf{G}_\theta(\mathbf{x}_s, s, t)$，以及一个混合的教师–学生路径——先把教师从 s 推进到随机 $u \sim \mathcal{U}[t, s]$，再让学生从 u 跳到 t：

$$\mathbf{G}_{\theta^-}\big(\texttt{Solver}_{s\to u}(\mathbf{x}_s; \phi^\times), u, t\big).$$

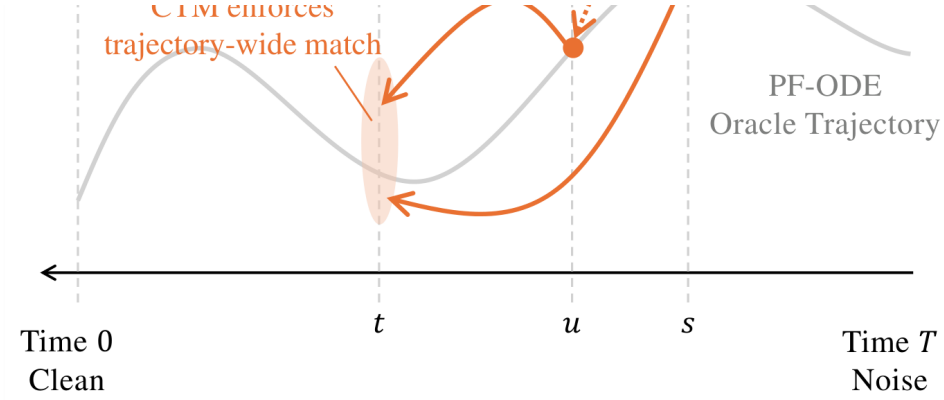
学生被训练为匹配该复合预测：

$$\underbrace{\mathbf{G}_\theta(\mathbf{x}_s, s, t)}_{\approx \Psi_{s\to t}(\mathbf{x}_s)} \approx \underbrace{\mathbf{G}_{\theta^-}\big(\texttt{Solver}_{s\to u}(\mathbf{x}_s;\phi^\times), u, t\big)}_{\approx \Psi_{u\to t}(\Psi_{s\to u}(\mathbf{x}_s))}, \tag{11.11.4.542}$$

其中 θ^- 是 $\mathbf{G}_\theta$ 的 stop-gradient 副本。

通过改变 u，CTM 在全局与局部监督之间插值：

- **全局一致性**（$u = s$）：学生在整个区间 (t, s) 上模仿教师，接收信息最丰富的教师信号。
- **局部一致性**（$u = s - \Delta s$）：学生在 s 附近的短教师步上学习；当 $s = 0$ 时退化为一致性蒸馏。



igure 11.4: Illustration of CTM's semigroup property. For any $s \geq u \geq t$, CTM enforce $\mathbf{G}_\theta(\mathbf{x}_s, s, t) \approx \mathbf{G}_{\theta^-}\big(\texttt{Solver}_{s\to u}(\mathbf{x}_s), u, t\big)$, i.e., a short solver segment $s \to u$ followed by CTM "jump" to t matches the direct CTM map $s \to t$. The solver may be a pre-traine iffusion or a CTM's self-induced teacher.

To couple trajectory matching with sample quality, both predictions ar napped to time 0 using the stop gradient student and compared in featur

图 11.48: CTM 半群性质示意。对任意 $s \geq u \geq t$，CTM 强制 $\mathbf{G}_\theta(\mathbf{x}_s, s, t) \approx \mathbf{G}_{\theta^-}(\texttt{Solver}_{s\to u}(\mathbf{x}_s), u, t)$，即一段短求解器段 $s \to u$ 后接一个 CTM "跳" 到 t，匹配直接 CTM 映射 $s \to t$。求解器可为预训练扩散模型，也可为 CTM 的自诱导教师。

为在对齐轨迹的同时增强样本质量，两个预测都通过 stop-gradient 学生映射到时刻 0，并在特征空间度量 d 中比较：

$$\begin{aligned}
\mathbf{x}_{\text{est}}(\mathbf{x}_s, s, t) &:= \mathbf{G}_{\theta^-}\big(\mathbf{G}_\theta(\mathbf{x}_s, s, t), t, 0\big), \\
\mathbf{x}_{\text{target}}(\mathbf{x}_s, s, u, t) &:= \mathbf{G}_{\theta^-}\big(\mathbf{G}_{\theta^-}(\texttt{Solver}_{s\to u}(\mathbf{x}_s;\phi^\times), u, t), t, 0\big).
\end{aligned}$$

CTM 一致性损失为

$$\mathcal{L}_{\text{consist}}(\theta;\phi^\times) := \mathbb{E}_{s\in[0,T]}\mathbb{E}_{t\in[0,s]}\mathbb{E}_{u\in[t,s]}\mathbb{E}_{\mathbf{x}_0}\mathbb{E}_{\mathbf{x}_s|\mathbf{x}_0}\big[d(\mathbf{x}_{\text{est}}, \mathbf{x}_{\text{target}})\big], \tag{11.11.4.543}$$

它鼓励学生匹配经验 PF-ODE 解，同时保持生成质量。

从零训练。 利用 CTM 的特殊参数化（命题 11.4.1(i)），

$$\mathbf{g}^*(\mathbf{x}_\tau,\tau,\tau)=\mathbf{x}_\tau-\tau\mathbf{v}^*(\mathbf{x}_\tau,\tau)\quad\Longrightarrow\quad\mathbf{v}^*(\mathbf{x}_\tau,\tau)=\frac{\mathbf{x}_\tau-\mathbf{g}^*(\mathbf{x}_\tau,\tau,\tau)}{\tau}.$$

于是我们可用 CTM 自身的估计 $\mathbf{g}_{\theta^-}(\cdot,\tau,\tau)$ 替换 oracle 残差函数 $\mathbf{g}^*(\cdot,\tau,\tau)$（$\tau\in[0,T]$），得到一个自诱导的经验 PF-ODE：

$$\frac{\mathrm{d}\mathbf{x}(\tau)}{\mathrm{d}\tau}=\frac{\mathbf{x}(\tau)-\mathbf{g}_{\theta^-}(\mathbf{x}(\tau),\tau,\tau)}{\tau}.\tag{11.11.4.544}$$

我们随后通过求解该 ODE 并训练学生匹配求解器输出，来逼近 oracle 解映射：

$$\mathbf{G}_\theta(\mathbf{x}_s,s,t)\approx\texttt{Solver}_{s\to t}(\mathbf{x}_s;\theta^-)\approx\Psi_{s\to t}(\mathbf{x}_s,s,t).$$

与蒸馏情形式 (11.11.4.542) 一样，当 s 与 t 相距较远时对 $[t,s]$ 完整积分代价高昂。CTM 因此强制半群性质以获得更短的监督路径：

$$\underbrace{\mathbf{G}_\theta(\mathbf{x}_s,s,t)}_{\approx\Psi_{s\to t}(\mathbf{x}_s)}\approx\underbrace{\mathbf{G}_{\theta^-}\big(\texttt{Solver}_{s\to u}(\mathbf{x}_s;\theta^-),u,t\big)}_{\approx\Psi_{u\to t}(\Psi_{s\to u}(\mathbf{x}_s))},$$

其中 $u\sim\mathcal{U}[t,s]$，θ^- 是学生的 stop-gradient 副本。与蒸馏的唯一区别是：外部教师 $\mathbf{v}_{\phi^\times}$ 被自诱导教师 $\mathbf{g}_{\theta^-}$ 替代。

为在轨迹匹配的同时耦合样本质量，两个预测都用 stop-gradient 学生映射到时刻 0 并在特征空间比较。无预训练模型时的目标为

$$\hat{\mathbf{x}}_{\text{target}}:=\mathbf{G}_{\theta^-}\big(\mathbf{G}_{\theta^-}(\texttt{Solver}_{s\to u}(\mathbf{x}_s;\theta^-),u,t),t,0\big),$$

它替换式 (11.11.4.543) 中的 $\mathbf{x}_{\text{target}}$，得到：

$$\mathcal{L}_{\text{consist}}(\theta;\theta^-):=\mathbb{E}_{s\in[0,T]}\mathbb{E}_{t\in[0,s]}\mathbb{E}_{u\in[t,s]}\mathbb{E}_{\mathbf{x}_0}\mathbb{E}_{\mathbf{x}_s|\mathbf{x}_0}\big[d(\mathbf{x}_{\text{est}},\hat{\mathbf{x}}_{\text{target}})\big].\tag{11.11.4.545}$$

概念上，这是 CTM 内部的自蒸馏：模型自身提供短视距教师信号，学生则学习完整转移。

11.4.3 CTM 中的辅助损失

（自）蒸馏可能逊于教师，因为它只优化教师生成的目标，缺乏来自真实数据的直接监督。相比之下，CTM 自然可纳入数据驱动的正则项，例如用去噪分数匹配与对抗（GAN，Goodfellow 等, 2014）项增广目标，以更好地学习流映射。

扩散损失的自然融入。 扩散模型损失（更精确地，条件流匹配损失；式 (5.2.9)）自然融入 CTM，并提供一个固定回归目标，便利流映射模型的学习。为看到这一点，注意有

$$\mathbf{v}^*(\mathbf{x}_s,s)=\frac{\mathbf{x}_s-\mathbf{g}^*(\mathbf{x}_s,s,s)}{s},\qquad\mathbf{g}^*(\mathbf{x}_s,s,s)\approx\mathbf{g}_\theta(\mathbf{x}_s,s,s).$$

这通过 $\mathbf{g}_\theta$ 自然诱导一个速度参数化

$$\mathbf{v}_\theta(\mathbf{x}_s,s):=\frac{1}{s}\big(\mathbf{x}_s-\mathbf{g}_\theta(\mathbf{x}_s,s,s)\big).$$

使用线性 Gaussian 路径

$$\mathbf{x}_s = \alpha_s \mathbf{x}_0 + \sigma_s \boldsymbol{\epsilon}, \qquad \mathbf{x}_0 \sim p_{\text{data}},\ \boldsymbol{\epsilon} \sim \mathcal{N}(0, \mathbf{I}),$$

扩散模型损失可写为

$$\mathcal{L}_{\text{DM}}(\theta) := \mathbb{E}_{\mathbf{x}_0, \boldsymbol{\epsilon}, s}\left[w(s) \left\| \mathbf{v}_\theta(\mathbf{x}_s, s) - (\alpha'_s \mathbf{x}_0 + \sigma'_s \boldsymbol{\epsilon}) \right\|_2^2 \right]. \tag{11.11.4.546}$$

当 t 接近 s 时，$\mathcal{L}_{\text{DM}}$ 通过显式监督沿轨迹的小跳来提升精度。在这一情形下，式 (11.11.4.540) 中的因子 $1 - \frac{t}{s}$ 趋近零，可能减弱梯度、拖慢学习；$\mathcal{L}_{\text{DM}}$ 提供更强的局部信号并稳定训练。

概念上，式 (11.11.4.543) 与式 (11.11.4.545) 强制轨迹匹配（零阶），而式 (11.11.4.546) 强制斜率匹配（一阶）。

（可选）GAN 损失。 虽然一致性与扩散模型损失提供强回归信号，但它们可能产出过度平滑的输出。CTM 因此可选加入一个对抗项，通过对齐生成器分布与数据分布来鼓励更锐利、更真实的样本。设判别器 D_ζ 区分真实 $\mathbf{x}_0 \sim p_{\text{data}}$ 与生成的 $\mathbf{x}_{\text{est}}(\mathbf{x}_s, s, t)$，目标为

$$\mathcal{L}_{\text{GAN}}(\theta, \zeta) := \mathbb{E}_{\mathbf{x}_0}\left[\log D_\zeta(\mathbf{x}_0) \right] + \mathbb{E}_{s \in [0,T]} \mathbb{E}_{t \in [0,s]} \mathbb{E}_{\mathbf{x}_0} \mathbb{E}_{\mathbf{x}_s | \mathbf{x}_0}\left[\log(1 - D_\zeta(\mathbf{x}_{\text{est}}(\mathbf{x}_s, s, t))) \right],$$

其中 D_ζ 被最大化、$\mathbf{G}_\theta$ 被最小化。直觉上，判别器充当一个自适应感知距离，鼓励真实细节。理论上，GAN 项驱动 p_{data} 与 $\mathbf{G}_\theta$ 诱导的模型分布之间的分布匹配（Jensen–Shannon 散度，Goodfellow 等, 2014），可把保真度提升到教师之上。

CTM 总体目标。 总之，CTM 把（自）蒸馏、扩散与 GAN 损失统一进一个训练框架：

$$\mathcal{L}_{\text{CTM}}(\theta, \zeta) := \mathcal{L}_{\text{consist}}(\theta; \phi^\times / \theta^-) + \lambda_{\text{DM}} \mathcal{L}_{\text{DM}}(\theta) + \lambda_{\text{GAN}} \mathcal{L}_{\text{GAN}}(\theta, \zeta), \tag{11.11.4.547}$$

其中教师可为外部预训练模型 $\phi^\times$，也可为自诱导教师 θ^-。回归式分量 $\mathcal{L}_{\text{consist}}$ 与 $\mathcal{L}_{\text{DM}}$ 充当强正则项，而可选 GAN 项在不牺牲稳定性的情况下改进细粒度细节（Kim 等, 2024b）。

11.4.4 CTM 的灵活采样

CTM 学习任意 $s > t$ 的一般流映射 $\Psi_{s \to t}$，这意味着它支持任意时刻到任意时刻的转移。该性质使灵活采样策略成为可能。例如，CTM 提出 γ 采样，其中超参数 γ 控制生成时的随机性。此外，CTM 可复用为扩散模型发展的标准推理技术，如基于 ODE 的求解器与精确似然计算。

下文我们固定一个离散时间网格用于采样 $T = \tau_0 > \tau_1 > \tau_2 > \cdots > \tau_M = 0$。

γ 采样的方法论。 CTM 的 γ 采样引入了一族统一的采样器，它们自然来自学习一般流映射模型。它涵盖了先前方法，如 CM 的多步采样（算法 9）与时间步进式采样（在概念上类似 ODE 求解器）。参数 γ 直接控制生成过程中的语义变化程度，使 γ 采样成为一种灵活、任务感知的策略，适用于多样的下游应用。

Algorithm 11 CTM 的 γ 采样

Require: 训练好的 CTM $\mathbf{G}_{\theta^\times}$；$\gamma \in [0,1]$；$T = \tau_0 > \tau_1 > \tau_2 > \cdots > \tau_M = 0$

从 $\mathbf{x}_{\tau_0} \sim p_{\text{prior}} = \mathcal{N}(\mathbf{0}, T^2\mathbf{I})$ 出发
for $n = 0$ to $M-1$ **do**
  $\tilde{\tau}_{n+1} \leftarrow \sqrt{1-\gamma^2}\,\tau_{n+1}$
  去噪 $\mathbf{x}_{\tilde{\tau}_{n+1}} \leftarrow \mathbf{G}_{\theta^\times}(\mathbf{x}_{\tau_n}, \tau_n, \tilde{\tau}_{n+1})$
  加噪 $\mathbf{x}_{\tau_{n+1}} \leftarrow \mathbf{x}_{\tilde{\tau}_{n+1}} + \gamma\tau_{n+1}\boldsymbol{\epsilon}$，其中 $\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$
end for
return $\mathbf{x}_{\tau_M}$

- **图 11.49（左）**：当 $\gamma = 1$ 时，它与 CM 中介绍的多步采样（即特殊流映射 $\Psi_{s\to 0}$）重合，是完全随机的，并在步数变化时带来语义变化。
- **图 11.49（右）**：当 $\gamma = 0$ 时，它退化为完全确定性的时间步进，估计 PF-ODE 的解轨迹。$\gamma = 0$ 采样与传统基于 ODE 的时间步进采样之间的关键区别在于：CTM 避免了数值求解器的离散化误差。
- **图 11.49（中）**：当 $0 < \gamma < 1$ 时，γ 采样通过在采样期间注入受控量的随机性，在两个极端之间插值。

我们强调，仅当模型学到一般流映射 $\Psi_{s\to t}$ 时，才能实现 $\gamma \in (0,1]$ 的采样器。

γ 采样分析。 CTM 实证观察到：一旦步数 $M \geq 4$，CM 多步采样的质量会下降。为解释这一现象，CTM 分析了其底层原因：当 $\gamma \neq 0$ 时，每个神经“跳”都引入小失配，这些失配在模型迭代地把状态映射到时刻 0 时累积。这种误差累积解释了长多步运行为何表现不佳。我们把这一思想形式化为下命题。

命题 11.4.2（（非正式）两步 γ 采样）：令 $\tau \in (0,T)$，$\gamma \in [0,1]$。记 $p_{\theta^*,2}$ 为从最优 CTM 出发、按转移序列 $T \to \sqrt{1-\gamma^2}\tau \to \tau \to 0$、从 p_{prior} 出发的 γ 采样器得到的密度。则

$$\mathcal{D}_{\text{TV}}(p_{\text{data}}, p_{\theta^*,2}) = \mathcal{O}\left(\sqrt{T - \sqrt{1-\gamma^2}\tau + \tau}\right).$$

这里 $\mathcal{D}_{\text{TV}}$ 表示分布间的总变差（见式 (1.1.4)）。

证明： 对命题 11.4.2。一般情形（采样步数为 M）见 Kim 等（2024a）定理 8。 □

上述定理的洞察可总结如下：

- **当 $\gamma = 1$**（对应 CM 的多步采样）：该方法在每步 n 从 τ_n 到 0 做迭代长程转移，导致误差按
$$\mathcal{O}\left(\sqrt{T + \tau_1 + \cdots + \tau_M}\right)$$
的阶累积。

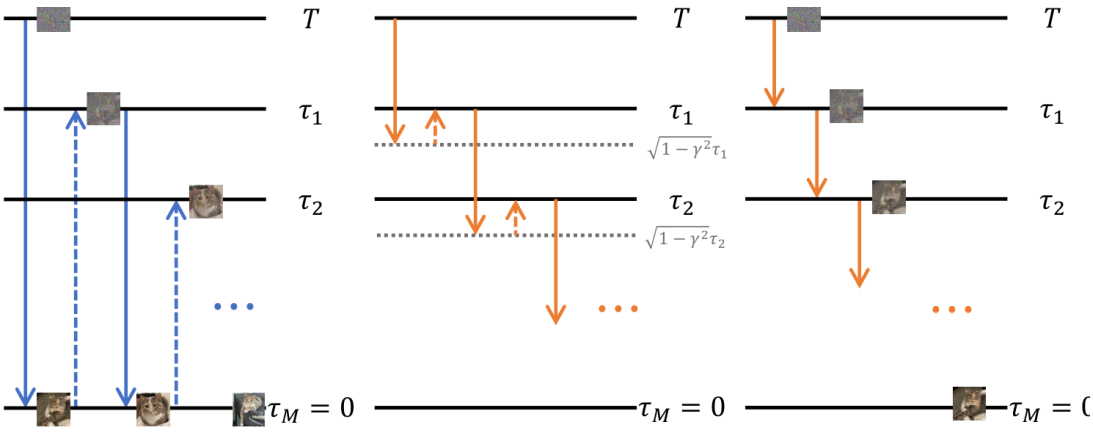


Figure 11.5: Illustration of γ-sampling with varying γ value. The procedure alternates between denoising with a network evaluation and adding noise in reverse, $(\tau_n \xrightarrow{\text{Denoise}} \sqrt{1-\gamma^2}\tau_{n+1} \xrightarrow{\text{Noisify}} \tau_{n+1})_{n=0}^{M-1}$. The leftmost panel illustrates $\gamma = 1$, corresponding to the fully stochastic case. The rightmost panel shows $\gamma = 0$, corresponding to the fully deterministic case. The middle panel depicts intermediate values $\gamma \in (0, 1)$, which interpolate between these two extremes.

图 11.49：不同 γ 值下的 γ 采样示意。该过程在网络评估去噪与反向加噪之间交替，$(\tau_n \xrightarrow{\text{Denoise}} \sqrt{1-\gamma^2}\tau_{n+1} \xrightarrow{\text{Noisify}} \tau_{n+1})_{n=0}^{M-1}$。最左面板示出 $\gamma = 1$，对应完全随机情形；最右面板示出 $\gamma = 0$，对应完全确定性情形；中间面板示出中间值 $\gamma \in (0, 1)$，在两个极端之间插值。

- **当** $\gamma = 0$（对应 CTM 的确定性多步采样）：转移之间的时间重叠被消除，避免了误差累积，并给出更紧的界 $\mathcal{O}(\sqrt{T})$。实证上，$\gamma = 0$ 的 CTM 在采样速度与样本质量之间给出有利的权衡：增加采样步数可提升生成质量而不引入不稳定。

CTM 支持扩散推理。 由于 CTM 通过 $\mathbf{g}_\theta$ 的参数化（式 (11.11.4.540)）直接学习 score 函数（或去噪器），它与最初为扩散模型发展的推理技术兼容。例如可用 $\mathbf{g}_\theta(\cdot, s, s)$ 计算精确似然（第 §4.2.2 节）或应用高级采样器（如 DDIM 或 DPM，第 9 章）进行生成。

11.5 一般流映射：Mean Flow

正如扩散模型承认多种等价参数化与训练目标，一般流映射 $\Psi_{s\to t}$ 也可用多种合理方式学习。本节介绍 *Mean Flow*（MF，Geng 等, 2025a），它是一般流映射族 $\Psi_{s\to t}$ 的一位较晚代表，展示了关于如何有效学习此类映射的另一种有原则视角。

11.5.1 Mean Flow 的建模与训练

与基于 EDM 框架的 CM、CTM 不同，MF 基于流匹配表述（$t \in [0, 1]$ 时 $\alpha_t = 1-t$、$\sigma_t = t$）。MF 不直接参数化流映射，而是学习区间 $[t, s]$（$t < s$）上的平均漂移：

$$\mathbf{h}_\theta(\mathbf{x}_s, s, t) \approx \mathbf{h}^*(\mathbf{x}_s, s, t) := \frac{1}{t-s}\int_s^t \mathbf{v}^*(\mathbf{x}_u, u)\,\mathrm{d}u.$$

对应 oracle 损失为

$$\mathbb{E}_{t<s}\mathbb{E}_{\mathbf{x}_s\sim p_s}\left[w(s)\,\|\mathbf{h}_\theta(\mathbf{x}_s,s,t)-\mathbf{h}^*(\mathbf{x}_s,s,t)\|_2^2\right]. \tag{11.11.5.548}$$

特别地，当 $s\to t$ 时损失退化为流匹配损失：

$$\mathbb{E}_{t}\mathbb{E}_{\mathbf{x}_t\sim p_t}\left[w(t)\,\|\mathbf{h}_\theta(\mathbf{x}_t,t,t)-\mathbf{v}^*(\mathbf{x}_t,t)\|_2^2\right], \tag{11.11.5.549}$$

即学习瞬时速度。后文第 §11.5.3 节将看到，MF 与式 (11.11.1.520) 中的一般目标保持一致，但从一个不同（而等价）的视角处理它。由于 oracle 回归目标 $\mathbf{h}^*(\mathbf{x}_s,s,t)$ 一般没有闭式，MF 通过对恒等式

$$(t-s)\mathbf{h}^*(\mathbf{x}_s,s,t)=\int_s^t \mathbf{v}^*(\mathbf{x}_u,u)\,\mathrm{d}u$$

关于 s 求导来构造替身。这给出

$$\begin{aligned}\mathbf{h}^*(\mathbf{x}_s,s,t)&=\mathbf{v}^*(\mathbf{x}_s,s)-(s-t)\frac{\mathrm{d}}{\mathrm{d}s}\mathbf{h}^*(\mathbf{x}_s,s,t)\\&=\mathbf{v}^*(\mathbf{x}_s,s)-(s-t)\left[(\partial_{\mathbf{x}}\mathbf{h}^*)(\mathbf{x}_s,s,t)\mathbf{v}^*(\mathbf{x}_s,s)+\partial_s\mathbf{h}^*(\mathbf{x}_s,s,t)\right],\end{aligned}$$

其中第二行连同

$$\frac{\mathrm{d}}{\mathrm{d}s}\mathbf{x}_s=\mathbf{v}^*(\mathbf{x}_s,s)$$

应用了链式法则。

受此恒等式启发，MF 用一个 stop-gradient 替身替换难处理的 oracle，得到实用训练目标

$$\mathcal{L}_{\mathrm{MF}}(\theta):=\mathbb{E}_{t<s}\mathbb{E}_{\mathbf{x}_s\sim p_s}\left[w(s)\,\|\mathbf{h}_\theta(\mathbf{x}_s,s,t)-\mathbf{h}^{\mathrm{tgt}}_{\theta^-}(\mathbf{x}_s,s,t)\|_2^2\right], \tag{11.11.5.550}$$

其中回归目标定义为

$$\mathbf{h}^{\mathrm{tgt}}_{\theta^-}(\mathbf{x}_s,s,t):=\mathbf{v}^*(\mathbf{x}_s,s)-(s-t)\underbrace{\left[(\partial_{\mathbf{x}}\mathbf{h}_{\theta^-})(\mathbf{x}_s,s,t)\mathbf{v}^*(\mathbf{x}_s,s)+\partial_s\mathbf{h}_{\theta^-}(\mathbf{x}_s,s,t)\right]}_{\mathrm{JVP}}.$$

实践中 oracle 速度 $\mathbf{v}^*$ 无法闭式计算，必须逼近。两种常见策略：依赖预训练扩散模型（蒸馏），或从数据构造直接估计（从零训练）。无论选择哪种，最终都需要计算目标网络 $\mathbf{h}_{\theta^-}$ 的 Jacobian–向量积（JVP）：

$$[\partial_{\mathbf{x}}\mathbf{h}_{\theta^-},\partial_s\mathbf{h}_{\theta^-},\partial_t\mathbf{h}_{\theta^-}]^\top\cdot[\mathbf{v}^*,1,0].$$

蒸馏。 使用一个带流匹配骨干的预训练扩散模型 $\mathbf{v}_{\phi^\times}\approx\mathbf{v}^*$。

从零训练。 使用从前向加噪 $\mathbf{x}_s=\alpha_s\mathbf{x}_0+\sigma_s\boldsymbol{\epsilon}$（$\boldsymbol{\epsilon}\sim\mathcal{N}(\mathbf{0},\mathbf{I})$）得到的单点条件速度 $\alpha_s'\mathbf{x}_0+\sigma_s'\boldsymbol{\epsilon}$。这给出在配对 $(\mathbf{x}_0,\boldsymbol{\epsilon})$ 上评估时、水平 s 处瞬时漂移的无单单样本估计。

11.5.2 Mean Flow 的采样

一旦训练好 MF $\mathbf{h}_{\theta^\times}$，它自然恢复流映射的一个替身。对任意起点 $\mathbf{x}_s$，从 s 到 t 的映射（近似）为

$$\Psi_{s\to t}(\mathbf{x}_s) = \mathbf{x}_s + (t-s)\mathbf{h}^*(\mathbf{x}_s, s, t) \approx \mathbf{x}_s + (t-s)\mathbf{h}_{\theta^\times}(\mathbf{x}_s, s, t).$$

这同时支持单步与多步采样。例如，取 $\mathbf{x}_T \sim p_{\text{prior}}$，干净样本的单步生成即

$$\mathbf{x}_0 \leftarrow \mathbf{x}_T + T\mathbf{h}_{\theta^\times}(\mathbf{x}_T, T, 0).$$

或者，多步生成可通过准备一个时间网格并按顺序应用映射来进行，与 CTM 中所用的时间步进方式相同。由于 MF 学习一般流映射，它也支持 CTM 中的 γ 采样，其中可控超参数 γ 把随机性注入采样过程。

11.5.3 CTM 与 MF 的等价性

初看 CTM 与 MF 似乎无关。事实上，二者只是同一 oracle 流映射 $\Psi_{s\to t}$ 的不同参数化，其训练损失（CTM 的一致性损失对比式 (11.11.5.548)）只在时间加权上有所不同（Hu 等, 2025）。

参数化之间的关系。 两个方法在同一一般框架下操作，但以不同方式表示学到的函数。流映射可等价写为

$$\begin{aligned}
\Psi_{s\to t}(\mathbf{x}_s) &= \mathbf{x}_s + \int_s^t \mathbf{v}^*(\mathbf{x}_u, u)\,\mathrm{d}u \\
&= \frac{t}{s}\mathbf{x}_s + \frac{s-t}{s}\underbrace{\left[\mathbf{x}_s + \frac{s}{s-t}\int_s^t \mathbf{v}^*(\mathbf{x}_u, u)\,\mathrm{d}u\right]}_{\approx \mathbf{g}_\theta} \\
&= \mathbf{x}_s + (t-s)\underbrace{\left[\frac{1}{t-s}\int_s^t \mathbf{v}^*(\mathbf{x}_u, u)\,\mathrm{d}u\right]}_{\approx \mathbf{h}_\theta}.
\end{aligned}$$

其中第一个是流映射的定义，第二种形式突出通过 $\mathbf{g}_\theta$ 的 CTM 参数化（见式 (11.11.4.539) 与式 (11.11.4.540)），最后一种突出通过 $\mathbf{h}_\theta$ 的 MF 参数化。

训练损失之间的关系。 给定上述对 oracle 流映射 $\Psi_{s\to t}$ 在 CTM 参数化下的再解释

$$\mathbf{g}_\theta(\mathbf{x}_s, s, t) \approx \mathbf{g}^*(\mathbf{x}_s, s, t) := \mathbf{x}_s + \frac{s}{s-t}\int_s^t \mathbf{v}^*(\mathbf{x}_u, u)\,\mathrm{d}u$$

与 MF 参数化

$$\mathbf{h}_\theta(\mathbf{x}_s, s, t) \approx \mathbf{h}^*(\mathbf{x}_s, s, t) := \frac{1}{t-s}\int_s^t \mathbf{v}^*(\mathbf{x}_u, u)\,\mathrm{d}u,$$

我们现在证明 CTM 与 MF 的训练损失实际上等价。

考虑关系

$$\mathbf{g}_\theta(\mathbf{x}_s, s, t) := \mathbf{x}_s - s\mathbf{h}_\theta(\mathbf{x}_s, s, t),$$

并取 $d(\mathbf{x}, \mathbf{y}) := \|\mathbf{x} - \mathbf{y}\|^2$ 为例。代入式 (11.11.1.520)，并把 $\mathbf{G}_\theta$ 视为 CTM 的流映射参数化（式 (11.11.4.540)），给出

$$\begin{aligned}
d\big(\mathbf{G}_\theta(\mathbf{x}_s, s, t), \Psi_{s\to t}(\mathbf{x}_s)\big) &= \|\mathbf{G}_\theta(\mathbf{x}_s, s, t) - \Psi_{s\to t}(\mathbf{x}_s)\|^2 \\
&= \left\| \left(\frac{t}{s}\mathbf{x}_s + \frac{s-t}{s}\mathbf{g}_\theta(\mathbf{x}_s, s, t)\right) - \left(\frac{t}{s}\mathbf{x}_s + \frac{s-t}{s}\left[\mathbf{x}_s + \frac{s}{s-t}\int_s^t \mathbf{v}^*(\mathbf{x}_u, u)\,\mathrm{d}u\right]\right)\right\|^2 \\
&= \left(\frac{s-t}{s}\right)^2 \left\|\mathbf{g}_\theta(\mathbf{x}_s, s, t) - \left(\mathbf{x}_s + \frac{s}{s-t}\int_s^t \mathbf{v}^*(\mathbf{x}_u, u)\,\mathrm{d}u\right)\right\|^2 \\
&= \left(\frac{s-t}{s}\right)^2 \left\|\big(\mathbf{x}_s - s\mathbf{h}_\theta(\mathbf{x}_s, s, t)\big) - \left(\mathbf{x}_s + \frac{s}{s-t}\int_s^t \mathbf{v}^*(\mathbf{x}_u, u)\,\mathrm{d}u\right)\right\|^2 \\
&= \left(\frac{s-t}{s}\right)^2 \left\|(\mathbf{x}_s - s\mathbf{h}_\theta(\mathbf{x}_s, s, t)) - \left(\mathbf{x}_s + \frac{s}{s-t}\int_s^t \mathbf{v}^*(\mathbf{x}_u, u)\,\mathrm{d}u\right)\right\|^2 \\
&= (s-t)^2 \left\|\mathbf{h}_\theta(\mathbf{x}_s, s, t) - \left(\frac{1}{t-s}\int_s^t \mathbf{v}^*(\mathbf{x}_u, u)\,\mathrm{d}u\right)\right\|^2.
\end{aligned}$$

因此

$$\frac{1}{s^2}\|\mathbf{g}_\theta(\mathbf{x}_s, s, t) - \mathbf{g}^*(\mathbf{x}_s, s, t)\|^2 = \|\mathbf{h}_\theta(\mathbf{x}_s, s, t) - \mathbf{h}^*(\mathbf{x}_s, s, t)\|^2.$$

于是 CTM 与 MF 的损失在一个权重函数的意义下根本等价。此外，在任一情形中取 $t = 0$ 即恢复 CM 设定（$\Psi_{s\to 0}$），其中每个状态直接映射到干净数据。

实践中的辅助损失。 在 CTM 中，训练联合使用式 (11.11.4.545) 的一致性损失与其自定义的式 (11.11.4.546) 扩散模型损失。MF 中也采用类似策略。如式 (11.11.5.549) 所示，当 $s \to t$ 时 MF 损失退化为标准流匹配目标。实践中，MF 控制 $s \neq t$ 配对与 $s = t$ 配对之间的比例；因此整体优化成为式 (11.11.5.550) 的 MF 目标与式 (11.11.5.549) 流匹配目标的混合。

两种参数化都能提供一个平滑过渡：从带固定回归目标、学习瞬时速度的扩散模型训练，过渡到使用 stop-gradient 伪回归目标的流映射学习。

CTM 与 MF 参数化都支持灵活推理。 CTM（$\mathbf{G}_\theta(\mathbf{x}_s, s, t)$）与 MF（$\mathbf{h}_\theta(\mathbf{x}_s, s, t)$）都旨在逼近底层流映射 $\Psi_{s\to t}$：

$$\mathbf{G}_\theta(\mathbf{x}_s, s, t) \approx \Psi_{s\to t}, \quad \text{且} \quad \mathbf{x}_s + (t-s)\mathbf{h}_\theta(\mathbf{x}_s, s, t) \approx \Psi_{s\to t}.$$

由于两个模型都学习任意两个时间步之间的显式映射，它们自然支持 CTM 的 γ 采样，并与最初为扩散模型发展的推理技术兼容，如引导（第 8 章）、精确似然计算（式 (4.2.7)）以及用高阶求解器加速采样（第 9 章）。这种兼容性来自其参数化在无穷小极限 $t \to s$ 中恢复瞬时扩散漂移：

$$\mathbf{g}^*(\mathbf{x}_s, s, s) = \mathbf{x}_s - \mathbf{v}^*(\mathbf{x}_s, s), \quad \text{且} \quad \mathbf{h}^*(\mathbf{x}_s, s, s) = \mathbf{v}^*(\mathbf{x}_s, s).$$

特殊流映射表述 $\Psi_{s\to 0}$（如 CM 族中的）不具备这一性质。因此 CTM 与 MF 都可视为灵活而一般的流映射表述，把基于扩散的推理推广为直接的时间到时间映射。

结论。 CTM 与 MF 之间的这种等价性类似于扩散模型中的情形（第 §6.3 节）：不同参数化最终描述同一底层 oracle 目标。原则上，这些表述在数学上恒等。但实践中，由于损失加权、网络设计或优化动力学等因素，其行为可能不同，使某一方法在特定条件下表现更好。

这一视角表明 CTM 与 MF 并非唯一可能：流映射的其他参数化也可能实现高效、稳定的训练，为新的独立生成模型打开大门。探索这些替代方案可进一步丰富扩散模型及其流映射扩展的版图，最终推动少步生成所能达到的边界。

11.6 本章小结

这最后一章让我们的探索完整闭环，最终汇聚为生成建模的新范式：从零学习快速、少步生成器。我们超越了改进数值求解器或蒸馏预训练模型的途径，聚焦于设计既原则性强、又在设计上高效的独立训练原理。

这里提出的核心创新是直接学习底层概率流 ODE 的流映射（$\Psi_{s\to t}$）。使这一过程可行的关键，是利用 ODE 流的基本半群性质。该性质规定一条长轨迹可分解为更短片段，为训练提供了强大的自监督信号。

我们从 Consistency Model（CM）开始，它率先学习把任意噪声状态搬运回其干净原点（$\Psi_{s\to 0}$）的特殊流映射。随后看到这一思想被 Consistency Trajectory Model（CTM）与 Mean Flow（MF）推广，它们学习满足 $s \geq t$ 的任意 s, t 的完整、任意时刻到任意时刻流映射 $\Psi_{s\to t}$。虽然在参数化上看似不同，我们展示了这些方法在逼近定义流映射的同一路径积分方面根本等价。

这些流映射模型代表本专著通篇发展的原理的一次有力综合。它们继承了 Score SDE 框架的连续时间基础与 Flow Matching 的确定性传输视角，但把训练目标重构为自包含而高效。

通过直接学习解映射，这些独立模型成功地把迭代扩散过程的高样本质量与单步生成器的推理速度统一起来。它们解决了保真度与速度之间的根本权衡，标志着生成建模的重要里程碑。这一成就不是终点，而是强大、高效、可控生成 AI 设计中新篇章的开始。

> 重要的不是停止提问。好奇心自有其存在的理由。 — *Albert Einstein*

Appendix A

微分方程速成

微分方程（differential equation, DE）是建模动力系统的基本工具，可大致分为常微分方程（ordinary differential equation, ODE）、随机微分方程（stochastic differential equation, SDE）与 偏微分方程（partial differential equation, PDE）。

ODE 描述系统状态如何依照一条精确规则随时间变化，因此一旦给定初值，未来轨迹便被唯一确定。SDE 在这一演化之上加入随机性，刻画噪声或不确定性如何影响系统行为，使结果变成概率性的而非固定的。PDE 则描述依赖多个变量（如时间与空间）的函数如何协同演化，用以刻画热扩散、波传播，或随机系统中概率密度随时间的演化（剧透：Fokker–Planck 方程）。这几类微分方程构成了一套基本语言，用于理解系统在确定性与随机性共同作用下如何随时间与空间演化。

本章给出微分方程方面的必备预备知识。

A.1 常微分方程基础

本节介绍 ODE 的基本理论，强调在给定初值下解的唯一性，并介绍使用数值求解器求解 ODE 的实用方法。

A.1.1 常微分方程的直观

确定性过程称为常微分方程（ODE）。在多元情形下，我们考虑如下形式的方程组：

$$\frac{d\mathbf{x}(t)}{dt} = \mathbf{v}\big(\mathbf{x}(t), t\big), \tag{A.A.1.551}$$

其中 $\mathbf{x}(t) \in \mathbb{R}^D$ 是取值为向量的函数，表示系统在时刻 t 的状态，而 $\mathbf{v} : \mathbb{R}^D \times \mathbb{R} \to \mathbb{R}^D$ 是一个向量场，指定了在空间与时间中每一点处变化的方向与大小。

求解 ODE 的高层直观。为建立直观，可把向量场 $\mathbf{v}(\mathbf{x}, t)$ 想象成一片动态的箭头景观，它告诉你在任一给定时刻 t，点 $\mathbf{x}$ 应如何移动。求解微分方程，就是在这片场中描出一条曲线 $\mathbf{x}(t)$，使曲线在任一点处的切方向（即瞬时速度）与 $\mathbf{v}(\mathbf{x}(t), t)$ 给出的向量对齐。

- **向量场视角：** 函数 $\mathbf{v}(\mathbf{x}, t)$ 规定了事物应当如何运动，它给出运动或变化的局部“指令”。
- **轨迹视角：** 解 $\mathbf{x}(t)$ 就是粒子若在每一瞬时都服从向量场 $\mathbf{v}$ 所设定的规则时所走过的路径。

因此，求解 ODE 就像把一粒粒子放入流场，观察它随时间流向何处。

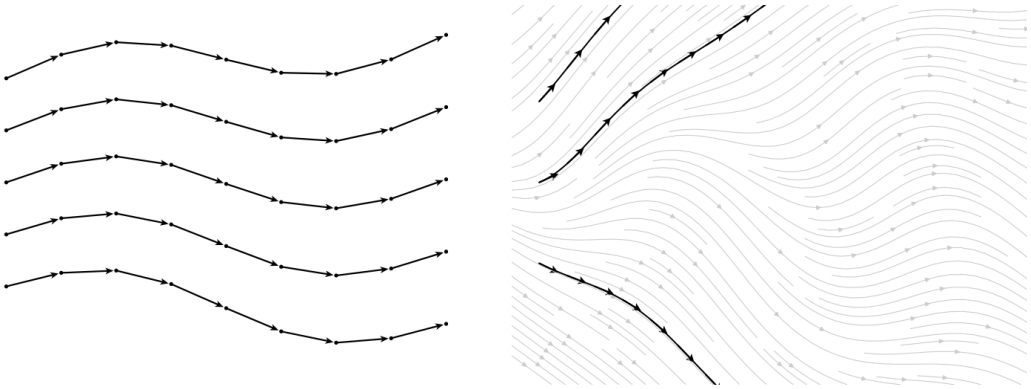


图 A.50: ODE 示意。速度场 $\mathbf{v}(\mathbf{x},t)$ 在每一点给出一个漂移向量。解轨迹 $\mathbf{x}(t)$ 是一条切方向始终与局部漂移一致的路径。左图展示逐步求解器更新（点与箭头）对路径的逼近，右图展示与速度场一致流动的精确轨迹（黑色）。若不指定初态 $\mathbf{x}(0)$，瞬时变化与同一速度场相符的轨迹有无穷多条；一旦固定 $\mathbf{x}(0)$，ODE 便确定出一条依照漂移流动的唯一路径。

A.1.2 常微分方程解的存在性与唯一性

至此我们看到，求解 ODE 就是找到一条在每一点都遵循向量场所给方向的路径。直观上，这类似于追踪粒子沿着速度所定义的流动运动时的轨迹。

但这一图景引出一个重要问题。

问题 A.1.1 (存在唯一性之问)**：** 若我们选定一个起点，能否确信真的存在一条遵循这些方向的路径？即便存在，这条路径是否唯一？粒子会不会突然跳到另一条轨迹上？

回答这些问题至关重要，因为它告诉我们系统行为能否由其初始位置可靠地预测。存在唯一性定理对向量场施加条件，保证从任一给定初值点出发恰有一条路径。这确保解的行为一致，是 ODE 理论的基石。

（时间上的）局部存在唯一性定理。下面陈述定理的局部版本：它断言在给定初值下，解在初始时刻的某个邻域内存在且唯一。

定理 A.1.1 (局部存在唯一性)**：** 设 $\mathbf{v}(\mathbf{x},t)$ 在区域 $\mathcal{D}\subseteq\mathbb{R}^D\times\mathbb{R}$ 上关于 $\mathbf{x}$ 与 t 连续。若 $\mathbf{v}$ 关于 $\mathbf{x}$ 满足 Lipschitz 条件：

$$\big\|\mathbf{v}(\mathbf{x}_1,t)-\mathbf{v}(\mathbf{x}_2,t)\big\|\le L\,\|\mathbf{x}_1-\mathbf{x}_2\| \qquad \forall\,(\mathbf{x}_1,t),(\mathbf{x}_2,t)\in\mathcal{D},$$

其中 $L>0$ 为常数，则对每个初值 $\mathbf{x}(t_0)=\mathbf{x}_0$，方程 (A.A.1.551) 在某个区间 $[t_0-\delta,\,t_0+\delta]$ 上存在唯一解 $\mathbf{x}(t)$。

证明（定理）：（证明梗概）存在唯一性定理可用 Picard–Lindelöf 迭代法构造性地证明。该方法生成一列函数 $\{\mathbf{x}_n(t)\}$，使其收敛到解 $\mathbf{x}(t)$。迭代定义为：

$$\mathbf{x}_{n+1}(t)=\mathbf{x}_0+\int_{t_0}^{t}\mathbf{v}\big(\mathbf{x}_n(s),s\big)\,ds.$$

- 从初始猜测 $\mathbf{x}_0(t)=\mathbf{x}_0$ 出发；

- 利用积分形式逐次 refine $\mathbf{x}_n(t)$；
- 在 Lipschitz 条件下，借助压缩映射定理保证收敛。

证明的精髓根植于 Picard–Lindelöf 迭代法，其核心思想也在第 9.8 节中被用于加速扩散模型的采样过程。 □

（时间上的）全局存在唯一性定理。局部存在唯一性定理只保证在一小段时间区间上解的存在性，而“全局（时间上的）存在唯一性定理”在附加正则性条件下把这一结果推广到整个区间 $[t_0, T]$。这一类中一个著名结果是 Carathéodory 定理，它在两条关键假设下保证 ODE 解的全局存在唯一性：状态变量上的局部 Lipschitz 连续与线性增长界：

1. 关于 $\mathbf{x}$ 的局部 Lipschitz 条件：存在在 $[0, T]$ 上可积的函数 $\mathrm{Lip}(t)$，使得对所有 $\mathbf{x}_1, \mathbf{x}_2 \in \mathbb{R}^D$，
$$\big\|\mathbf{v}(\mathbf{x}_1, t) - \mathbf{v}(\mathbf{x}_2, t)\big\| \le \mathrm{Lip}(t)\, \|\mathbf{x}_1 - \mathbf{x}_2\|.$$
2. 线性增长条件：存在在 $[0, T]$ 上可积的函数 $M(t)$，使得对所有 $\mathbf{x} \in \mathbb{R}^D$，
$$\|\mathbf{v}(\mathbf{x}, t)\| \le M(t)\big(1 + \|\mathbf{x}\|\big).$$

关于这些假设、定理的正式陈述与详细证明，我们参阅（Reid, 1971）。

注 A.1.1： 要把这些定理应用于扩散模型中的概率流 ODE（见方程 (4.1.7)），可能需要对分数函数 $\nabla_{\mathbf{x}} \log p_t(\mathbf{x})$ 附加额外假设，如上述条件 (i) 与 (ii)。对于不关注技术细节的读者，这些假设可以不加进一步论证而合理接受。 ◇

综上，当一个由含时速度场所定义的 ODE 被赋予初值时，粒子流的轨迹便被唯一确定。

唯一性蕴含解互不相交。局部存在唯一性定理所保证的 ODE 解的唯一性，蕴含一条基本性质：从不同初值出发的两条不同解轨迹不会相交。这反映了 ODE 的确定性本质，确保每个状态沿唯一路径演化。下面的推论将这一结果形式化。

推论 A.1.1 (解的互不相交)**：** 考虑 ODE $\dfrac{d\mathbf{x}(t)}{dt} = \mathbf{v}(\mathbf{x}(t), t)$，$t \in [0, T]$ 的两个解 $\mathbf{x}_1(t)$ 与 $\mathbf{x}_2(t)$。设它们有不同的初值 $\mathbf{x}_1(0) \neq \mathbf{x}_2(0)$。则这两个解在 $[0, T]$ 上不相交，即对所有 $t \in [0, T]$ 都有 $\mathbf{x}_1(t) \neq \mathbf{x}_2(t)$。

证明（推论）： 反设存在某 $t^* \in (0, T]$ 使得 $\mathbf{x}_1(t^*) = \mathbf{x}_2(t^*)$。定义两解首次相遇的时刻为
$$t_0 := \inf\{t \in [0, T] \mid \mathbf{x}_1(t) = \mathbf{x}_2(t)\}.$$
由于 $\mathbf{x}_1(0) \neq \mathbf{x}_2(0)$ 且 t^* 属于该集合，故 $t_0 > 0$。由 $\mathbf{x}_1, \mathbf{x}_2$ 的连续性，有 $\mathbf{x}_1(t_0) = \mathbf{x}_2(t_0)$。考虑初值问题 $\dfrac{d\mathbf{x}(t)}{dt} = \mathbf{v}(\mathbf{x}(t), t)$，$\mathbf{x}(t_0) = \mathbf{x}_1(t_0)$。由 ODE 的唯一性定理，$\mathbf{x}_1$ 与 $\mathbf{x}_2$ 在区间 $[t_0, T]$ 上必重合；向后时间方向应用唯一性同样可知两解在 $[0, t_0]$ 上重合。因此两解对所有 $t \in [0, T]$ 都满足 $\mathbf{x}_1(t) = \mathbf{x}_2(t)$，这与 $\mathbf{x}_1(0) \neq \mathbf{x}_2(0)$ 的假设矛盾。故得证 $\mathbf{x}_1(t) \neq \mathbf{x}_2(t)$ 对所有 $t \in [0, T]$ 成立。 □

这一定理通过保证解路径互不相交，为流映射模型（见第 10、11 章）提供了隐藏却关键的支撑。

A.1.3 指数积分因子

即便由一般含时速度 $\mathbf{v}$ 决定的 ODE 没有闭式解，在某些特殊情形下我们仍可解析求解，或将其化归为结构更良好的形式。

一个说明性例子。考虑如下线性标量 ODE：

$$\frac{dx(t)}{dt} = L(t)\, x(t),$$

其中 $L(t) \in \mathbb{R}$ 为连续函数。该方程有闭式解，其解众所周知（对任意 s 与 t）：

$$x(t) = x(s) \cdot \exp\left(\int_s^t L(\tau)\, d\tau \right).$$

这一公式展示了解如何依照一个累积含时系数 $L(t)$ 效应的指数因子演化。这启发我们使用指数积分因子：

$$E(s \triangleleft t) := \exp\left(\int_s^t L(\tau)\, d\tau \right), \tag{A.A.1.552}$$

尤其适用于动力学同时含有线性与非线性分量的更一般情形。

半线性 ODE 与指数积分因子。现在考虑一类更广泛的 ODE，称为半线性 ODE。这类方程把动力学拆成线性部分（关于状态变量）与非线性余项：

$$\frac{dx(t)}{dt} = L(t)\, x(t) + N\big(x(t), t\big), \tag{A.A.1.553}$$

其中 $x(t) \in \mathbb{R}^D$ 为状态向量，$L(t)$ 为标量值连续函数，$N : \mathbb{R}^D \times [0, T] \to \mathbb{R}^D$ 为非线性向量场。这种半线性结构在许多物理与工程系统中自然出现；特别地，它也出现在扩散模型的概率流 ODE 表述中（见方程 (4.1.7)）。识别出这一结构后便可使用指数积分因子，它不仅简化分析，还提升数值稳定性。具体而言，该技术在快速扩散 ODE 求解器的设计中扮演核心角色（见第 9 章）。

第 1 步：用积分因子隔离非线性项。观察到可从半线性 ODE (A.A.1.553) 中减去线性漂移，从而隔离非线性部分：

$$\frac{dx(t)}{dt} - L(t)\, x(t) = N\big(x(t), t\big).$$

为吸收线性项，两边同乘逆积分因子：

$$E^{-1}(s \triangleleft t) = \exp\left(-\int_s^t L(\tau)\, d\tau \right).$$

对左边应用乘积法则：

$$E^{-1}(s \triangleleft t) \left(\frac{dx(t)}{dt} - L(t) x(t) \right) = \frac{d}{dt} \Big[E^{-1}(s \triangleleft t)\, x(t) \Big].$$

于是方程变为：

$$\frac{d}{dt}\Big[E^{-1}(s \triangleleft t)\, x(t)\Big] = E^{-1}(s \triangleleft t)\, N\big(x(t), t\big).$$

这一变换通过隔离非线性分量简化了原方程，使我们能在变换后的坐标系中完全聚焦于非线性动力学。

第 2 步：对时间积分。将两边从 s 到 t 积分：

$$\int_s^t \frac{d}{d\tau}\Big[E^{-1}(s \triangleleft \tau)\, x(\tau)\Big] d\tau = \int_s^t E^{-1}(s \triangleleft \tau)\, N\big(x(\tau), \tau\big)\, d\tau.$$

左边恰是变换变量在 t 与 s 处取值之差：$E^{-1}(s \triangleleft t)\, x(t) - x(s)$。于是得到：

$$E^{-1}(s \triangleleft t)\, x(t) = x(s) + \int_s^t E^{-1}(s \triangleleft \tau)\, N\big(x(\tau), \tau\big)\, d\tau.$$

第 3 步：解出 $x(t)$。两边同乘指数流 $E(s \triangleleft t)$，即得解：

$$x(t) = \underbrace{E(s \triangleleft t)\, x(s)}_{\text{线性部分}} + \underbrace{\int_s^t E(\tau \triangleleft t)\, N\big(x(\tau), \tau\big)\, d\tau}_{\text{非线性部分}}. \tag{A.A.1.554}$$

解自然地分离为线性与非线性两个分量。指数积分器利用这一结构，以闭式精确求解线性部分，仅对非线性残差做离散化。这使得步长由非线性动力学而非可能很大的线性系数决定，从而即使步数更少也能得到既稳定又精确的更新（比较指数 Euler 更新方程 (9.1.7) 与普通 Euler 更新方程 (9.1.8)）。

A.1.4 常微分方程的数值求解器

我们考虑方程 (A.A.1.551) 在初值 $\mathbf{x}(0)$ 下的 ODE。求解该 ODE 就是找到一条对所有 $t \in [0, T]$ 都满足方程的连续轨迹 $\mathbf{x}(t)$。理想情形下希望得到闭式解，但实际中几乎难以实现。

一个有用的视角是把 ODE 改写为积分形式：

$$\mathbf{x}(t) = \mathbf{x}(0) + \int_0^t \mathbf{v}\big(\mathbf{x}(\tau), \tau\big)\, d\tau, \tag{A.A.1.555}$$

它把解表示为初态加上速度随时间累积的效应。然而，由于 $\mathbf{v}$ 的非线性与含时本性，该积分通常难以处理，闭式解无法获得。

此时我们转向数值方法，即将时间离散并迭代逼近 $\mathbf{x}(t)$。常见方法包括 Euler 法、Runge–Kutta 法，以及面向刚性系统的专门积分器。这些方法逐步模拟系统，给出真实轨迹的实用逼近。

注 A.1.2： 当 $\mathbf{v}$ 取方程 (A.A.1.553) 的半线性形式时，解容许一个含指数积分因子的积分表示（方程 (A.A.1.554)），它分离了线性与非线性分量。这一结构使高效数值求解器得以只聚焦于逼近非线性项，降低计算复杂度，并催生量身定制的算法（见第 9 章）。◇

关键概念。数值求解器通过离散时间、利用 ODE 的斜率 $\mathbf{v}$ 估计状态，来逼近 ODE 的连续动力学。这包括：

- **离散化：**把时间域划分为离散步 $t_0, t_1, \ldots, t_n$。
- **步长：**区间 $\Delta t_i = t_{i+1} - t_i$ 称为步长。
- **逼近：**每一步的解用数值方法估计；精度取决于步长与所用方法。
- **误差控制：**离散化与逼近带来的误差被监测与控制。

数值求解器的高层分类。 ODE 求解器大致可分为：

- **时间步进法：**这类方法逐步推进解，如显式/隐式 Euler、Runge–Kutta。
- **时间并行法：**这类方法利用并行性同时计算不同时间区间上的解，适用于大规模问题。

常见数值求解器。其中，Euler、Heun 与 Runge–Kutta 都是单步法，因为每次更新只用到当前状态 $(t_n, \mathbf{x}_n)$。与之相对，多步法（如 Adams–Bashforth 或 Adams–Moulton）计算 $\mathbf{x}_{n+1}$ 时不仅用当前状态 $\mathbf{x}_n$，还用此前若干个值 $\mathbf{x}_{n-1}, \mathbf{x}_{n-2}, \ldots$。它们通过复用过去信息（历史锚点）而非在当前步内重算一切来节省工作量。此处不展开这类方法，不过相关格式（如第 9.3、9.5 节讨论的 Adams–Bashforth）也利用多个过去状态。

另一方面，Picard 迭代则是另一类性质：它是一种理论上的不动点构造，其思想将在第 9.8 节再次出现。

Euler 法。 Euler 法是最简单的时间步进格式：

$$\mathbf{x}_{n+1} = \mathbf{x}_n + h\,\mathbf{v}(\mathbf{x}_n, t_n),$$

其中 h 为步长。它具有一阶精度：局部误差 $O(h^2)$，全局误差 $O(h)$。虽易实现，但为保证稳定与精确需取较小的 h。

Heun 法（改进 Euler）。 Heun 法是二阶预测–校正格式：

$$\begin{aligned} &\text{预测：} \quad \mathbf{x}_{\text{pred}} = \mathbf{x}_n + h\,\mathbf{v}(\mathbf{x}_n, t_n), \\ &\text{校正：} \quad \mathbf{x}_{n+1} = \mathbf{x}_n + \frac{h}{2}\Big[\mathbf{v}(\mathbf{x}_n, t_n) + \mathbf{v}(\mathbf{x}_{\text{pred}}, t_n + h)\Big]. \end{aligned}$$

它达到局部误差 $O(h^3)$、全局误差 $O(h^2)$。Karras 等（2022）提倡在扩散模型中用 Heun 法求解 ODE，不过更高阶方法如 DPM-Solver（见第 9.4、9.5 节）通常给出更好的性能。

Runge–Kutta 法。 Runge–Kutta（RK）法通过对中间斜率取加权平均来推广

Euler。四阶方法（RK4）是标准选择：

$$\begin{aligned}
\mathbf{k}_1 &= \mathbf{v}(\mathbf{x}_n, t_n),\\
\mathbf{k}_2 &= \mathbf{v}\left(\mathbf{x}_n + \frac{h}{2}\mathbf{k}_1,\ t_n + \frac{h}{2}\right),\\
\mathbf{k}_3 &= \mathbf{v}\left(\mathbf{x}_n + \frac{h}{2}\mathbf{k}_2,\ t_n + \frac{h}{2}\right),\\
\mathbf{k}_4 &= \mathbf{v}(\mathbf{x}_n + h\mathbf{k}_3,\ t_n + h),\\
\mathbf{x}_{n+1} &= \mathbf{x}_n + \frac{h}{6}\big(\mathbf{k}_1 + 2\mathbf{k}_2 + 2\mathbf{k}_3 + \mathbf{k}_4\big).
\end{aligned}$$

RK4 在精度与代价间取得平衡，应用广泛。DPM-Solver 基于类似思想，利用扩散模型的半线性结构实现为其定制的高阶精确积分（比较见（Lu 等, 2022b）附录 B.6）。

Picard 迭代。 Picard 迭代通过下式逐次精化解的逼近：

$$\mathbf{x}^{(k+1)}(t) = \mathbf{x}^{(0)} + \int_0^t \mathbf{v}\big(\mathbf{x}^{(k)}(s), s\big)\, ds,$$

从满足 $\mathbf{x}^{(0)}(0) = \mathbf{x}^{(0)}$ 的初始猜测函数 $\mathbf{x}^{(0)}(t)$ 出发。虽然理论上很基础，但 Picard 迭代常因强烈依赖初始猜测而收敛缓慢；此外每次迭代都涉及对时间的积分，计算代价可能较高。

正时间与反时间求解 ODE。至此我们考虑的都是正时间方向求解方程 (A.A.1.551)，即从初值 $\mathbf{x}(0)$ 演化到更晚的时刻 $t > 0$。

与之相对，反时间积分从终端条件 $\mathbf{x}(T)$ 出发，向更早的时刻 $t < T$ 逐步倒退地计算解。把时间重参数化为 $T - t$，该 ODE 变为：

$$\frac{d\mathbf{x}(t)}{dt} = -\mathbf{v}\big(\mathbf{x}(t), T - t\big), \qquad \mathbf{x}(0) = \mathbf{x}(T).$$

反时间积分使用与正时间积分相同的方法，只不过在递减的时间网格上进行。取 Euler 法、步长 $h > 0$，从 $t_0 = T$、$\mathbf{x}_0 = \mathbf{x}(T)$ 出发，更新为：

$$t_{n+1} = t_n - h, \qquad \mathbf{x}_{n+1} = \mathbf{x}_n - h\,\mathbf{v}(\mathbf{x}_n, t_n).$$

必须注意保证数值稳定性，尤其是对刚性问题（即状态向量某些分量演化远快于其他分量，需很小时间步才能稳定积分），这在扩散模型的 PF-ODE 采样中很常见。

虽然 ODE 的时间反转在理论上直接——由于 $\mathbf{x}(0)$ 与 $\mathbf{x}(T)$ 之间是双射映射，它只需要对时间做重参数化——但这对 SDE 并不成立。其内在随机性排除了直接的时间反转，下一节将详述这一点。

A.2 随机微分方程基础

随机微分方程 (stochastic differential equation, SDE) (SDE) 是常微分方程 (ODE) 的推广，它纳入随机性，为建模受不确定性影响的系统提供数学框架。本节介绍 SDE：先从 ODE 的离散化出发，推广到 SDE 的离散化，最后讨论一般 SDE，包括 Itô 演算与 Itô 公式。

A.2.1 从 ODE 到 SDE：直观引入

从一个描述状态变量 $\mathbf{x}(t) \in \mathbb{R}^D$ 确定性演化的 ODE 开始：

$$\frac{d\mathbf{x}(t)}{dt} = \mathbf{f}\big(\mathbf{x}(t), t\big), \qquad \mathbf{x}(0) = \mathbf{x}_0. \tag{A.A.2.556}$$

这里 $\mathbf{f} : \mathbb{R}^D \times [0, T] \to \mathbb{R}^D$ 是含时速度场，支配 $\mathbf{x}(t)$ 的动力学。该 ODE 的解是一条光滑轨迹 $t \mapsto \mathbf{x}(t)$，完全由初值 $\mathbf{x}_0$ 决定。

离散化视角。为建立直观，考虑方程 (A.A.2.556) 在小时间步 Δt 上的 Euler 离散：

$$\mathbf{x}_{t+\Delta t} = \mathbf{x}_t + \mathbf{f}(\mathbf{x}_t, t)\, \Delta t.$$

当 $\Delta t \to 0$ 时（在 $\mathbf{f}$ 的标准正则性条件下），这一逼近更精确，并收敛到 ODE 的精确解。

引入随机性：从 ODE 到 SDE。在许多真实系统中，对动力学的完美认知并不现实。噪声、不确定性或未建模的相互作用都可能影响演化。为纳入这种随机性，我们给 ODE 附加一个随机项：

$$\mathbf{x}_{t+\Delta t} = \mathbf{x}_t + \mathbf{f}(\mathbf{x}_t, t)\, \Delta t + g(t)\sqrt{\Delta t}\, \boldsymbol{\epsilon}_t, \tag{A.A.2.557}$$

其中

- $g : [0, T] \to \mathbb{R}$ 是扩散系数（可同时依赖状态与时间，此处仅假设含时）；
- $\boldsymbol{\epsilon}_t \sim \mathcal{N}(\mathbf{0}, \mathbf{I}_D)$ 为独立同分布的标准 Gauss 向量。

这一修改后的更新规则不仅反映确定性漂移，还反映按 $\sqrt{\Delta t}$ 缩放的随机扰动。该缩放保证在 $\Delta t \to 0$ 极限下随机扰动保持有限。重要的是，当 $\Delta t \to 0$ 时这一表述产生一个连续时间随机过程，将我们引向 SDE 框架。

随机微分方程。形式上，离散更新 (A.A.2.557) 在 $\Delta t \to 0$ 时的极限定义了 SDE：

$$d\mathbf{x}(t) = \mathbf{f}\big(\mathbf{x}(t), t\big)\, dt + g(t)\, d\mathbf{w}(t). \tag{A.A.2.558}$$

这里 $\mathbf{w}(t) \in \mathbb{R}^D$ 是一个 Wiener 过程（标准 Brown 运动），一个连续时间随机过程，其特征为：

- **初始状态：** $\mathbf{w}(0) = \mathbf{0}$ 几乎必然成立；
- **独立增量：** 对 $0 \le s < t$，增量 $\mathbf{w}(t) - \mathbf{w}(s)$ 与过去独立；
- **Gauss 增量：**

$$\mathbf{w}(t) - \mathbf{w}(s) \sim \mathcal{N}\big(\mathbf{0},\, (t-s)\mathbf{I}_D\big); \tag{A.A.2.559}$$

- **连续性：** 样本路径 $t \mapsto \mathbf{w}(t)$ 几乎必然连续，但处处不可微。

此外，记号 $d\mathbf{w}(t) := \mathbf{w}(t + dt) - \mathbf{w}(t)$ 常被用来表示 Wiener 过程的无穷小增量。虽然富有启发性，但这一记法是启发式的，不应解释为经典意义下的微分（如 Riemann 或 Lebesgue 意义下），因为 Brown 路径几乎必然处处不可微。相反，它是表达 Gauss 增量性质的形式化缩写：$d\mathbf{w}(t) \sim \mathcal{N}(\mathbf{0}, dt\, \mathbf{I}_D)$，即在长度为 dt 的无穷小时间区间上，Wiener 过程的增量表现为零均值、协方差 $dt\, \mathbf{I}_D$ 的 Gauss 随机变量。

A.2.2 对方程 (A.2.3) 的进一步说明

方程 (A.A.2.558) 中的 SDE 应按其积分形式理解：

$$\mathbf{x}(t) = \mathbf{x}(0) + \int_0^t \mathbf{f}\big(\mathbf{x}(s), s\big)\, ds + \int_0^t g(s)\, d\mathbf{w}(s), \tag{A.A.2.560}$$

并按 Itô 意义解释。这里第一项是经典（Riemann 或 Lebesgue）积分，表示累积的确定性漂移；第二项是 Itô 随机积分，关于 Wiener 过程 $\mathbf{w}(t)$ 积分。我们不完整给出 Itô 积分的严格构造，只提供如下直观。

Itô 积分的直观。 Itô 积分可视为离散和的（依概率）极限：

$$\sum_i g(t_i)\big[\mathbf{w}(t_{i+1}) - \mathbf{w}(t_i)\big],$$

其中被积函数 $g(t)$ 在每个子区间的左端点 t_i 处取值。这一左端点取值至关重要，把 Itô 积分与常使用中点或其他取值规则的经典积分区别开来。

由于 Brown 路径连续却几乎必然处处不可微，经典积分不再适用。Itô 积分处理了这种不规则性，捕捉随机涨落随时间的累积效应。

微分记号的使用。 $d\mathbf{x}(t)$、dt、$d\mathbf{w}(t)$ 等表达式并非经典微分。它们是表示相应过程无穷小增量的形式化记号。虽为启发式，却因其方便地以类似 ODE 的方式表达 SDE、并便于在 Itô 演算内做形式推导而被广泛使用。

Itô 演算如何应用于扩散模型，将在附录 C 中说明。

与 ODE 的比较。 在 ODE 中，例如 $\dfrac{d\mathbf{x}(t)}{dt} = \mathbf{f}(\mathbf{x}(t), t)$，其积分形式 $\mathbf{x}(t) = \mathbf{x}(0) + \int_0^t \mathbf{f}(\mathbf{x}(\tau), \tau) d\tau$ 由微积分基本定理保证成立，该定理确保可微函数可由其导数复原。

与之相对，在方程 (A.A.2.558) 这类 SDE 中，不存在该定理的直接类比，因为 Brown 运动缺乏可微性，随机积分不遵循经典链式法则。取而代之，Itô 演算引入替代工具（如 Itô 引理）来分析与处理随机动力学。

因此，尽管 SDE 的微分记号紧凑而直观，但其严格理解依赖于用 Itô 积分把它解释为积分形式。

A.2.3 SDE 的数值求解器

与 ODE 一样，方程 (A.A.2.558) 中的 SDE 在 $\mathbf{f}(\cdot, t)$ 与 $g(\cdot)$ 满足某些光滑性条件时存在唯一解[41]：$\mathbf{f}(\cdot, t)$ 关于 $\mathbf{x}$ Lipschitz 且线性增长，$g(\cdot)$ 平方可积。

对于方程 (A.A.2.558) 这类一般 SDE，闭式解通常不存在，故需数值方法。一个常用方法是 Euler–Maruyama 法，它把 ODE 的 Euler 法推广，事实上我们在方程 (A.A.2.557) 中已经见过。它在时间步 Δt 上逼近漂移项 $\mathbf{f}(\mathbf{x}(t), t)$，并用 Gauss 增量 $\sqrt{\Delta t}\,\boldsymbol{\epsilon}_t$ （$\boldsymbol{\epsilon}_t \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$）模拟随机噪声 $g(t)d\mathbf{w}(t)$。

稍后在第 C.1.5 节中我们将看到，线性 SDE 容许闭式解。

[41] 该解是强意义下的，即 $\mathbf{x}(t)$ 关于固定概率空间上给定的 Brown 运动 $\mathbf{w}(t)$ 满足积分形式的 SDE（见方程 (A.A.2.560)）。此处省略详细技术定义。

Appendix B

密度演化：从换元公式到 Fokker–Planck 方程

理解概率密度如何在变换下演化，在概率论与生成建模中都是基础性问题。特别地，扩散模型旨在构造生成过程，使其诱导的密度路径逆转一个预先定义好的前向过程。这一演化由连续性方程支配；在随机情形下则由 Fokker–Planck 方程支配。

尽管这些名字听起来陌生或令人生畏，它们实际上只是基础微积分中换元公式的连续时间类比。在第 B.1 节中，我们通过给出一系列换元公式来引出它们：从确定性双射出发，最终到达随机微分方程。这一递进自然地把离散映射与连续时间流动力学衔接起来。关于这一统一框架的概览见图 B.51。

在第 B.2 节中，我们对连续性方程给出物理与直观的解释，强调它与动力系统中密度守恒的联系。

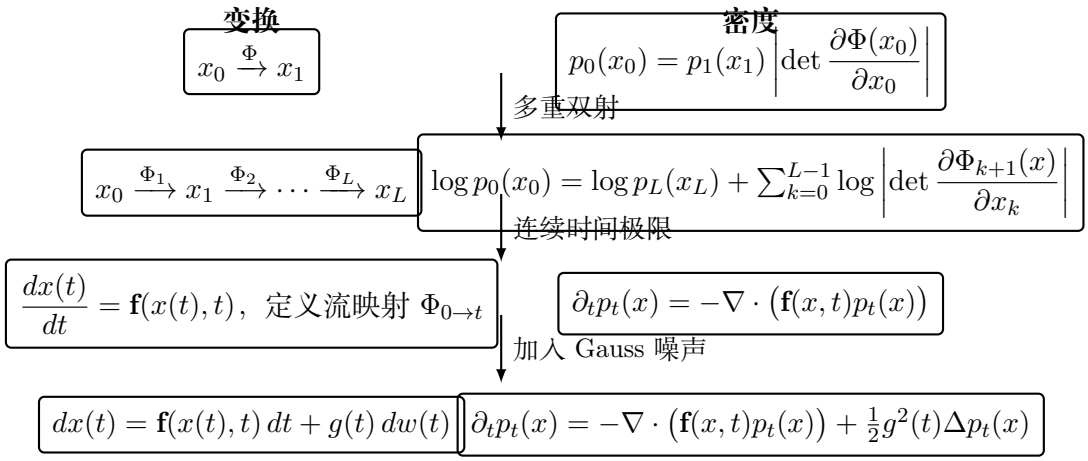


图 B.51: 统一的换元公式。自上而下：(1) 单个双射及其换元公式；(2) 多个双射的复合；(3) 由 ODE 支配的连续时间确定性流及相应的连续性方程；(4) 由 SDE 建模的随机流及相应的 Fokker–Planck 方程。

B.1 换元公式：从确定性映射到随机流

本节旨在通过与微积分中经典换元公式的类比，来揭开连续性方程与 Fokker–Planck 方程的神秘面纱。我们从熟悉的单变量情形开始，推广到多元情形与概率密度（第 B.1.1 节），再推广到双射映射的复合（其连续时间极限导出连续性方程，第 B.1.2 节）。最后，通过引入随机噪声纳入随机性，自然地把连续性方程推广到 Fokker–Planck 方程（第 B.1.3 节）。

B.1.1 确定性映射的换元公式

我们依照一个确定性映射移动粒子，并研究它们的律（密度）如何演化。关键原理是概率质量守恒，它根植于微积分与概率论中的一个基本结果：换元公式。该公式描述积分——因而概率密度——如何在光滑双射映射下变换。为建立直观，我们先考虑单个更新步，再把讨论推广到顺序变换。

单次更新。设想由施加一个向量场（类似力）$\Psi : \mathbb{R}^D \to \mathbb{R}^D$ 一个单位时间所诱导的单步更新规则。从初始粒子状态 $\mathbf{x}_0$ 出发，其下一状态为

$$\mathbf{x}_1 = \Psi(\mathbf{x}_0).$$

底层模式（密度）及其移动方式。若初始状态服从由密度 p_0 描述的底层 “律/模式”（即 $\mathbf{x}_0 \sim p_0$），则施加 Ψ 为 $\mathbf{x}_1$ 产生一个新密度 p_1（即 $\mathbf{x}_1 \sim p_1$）。假设 Ψ 是光滑双射，则 p_1 由 p_0 经标准换元公式得到：

$$p_1(\mathbf{x}_1) = p_0\big(\Psi^{-1}(\mathbf{x}_1)\big) \cdot \left|\det\left(\frac{\partial \Psi^{-1}}{\partial \mathbf{x}_1}\right)\right|. \tag{B.B.1.561}$$

这里 $\frac{\partial \Psi}{\partial \mathbf{x}}$ 是 Ψ 的 Jacobian 矩阵，记作 $\partial_{\mathbf{x}}\Psi$。等价地，在原坐标系中：

$$p_0(\mathbf{x}_0) = p_1\big(\Psi(\mathbf{x}_0)\big)\,\big|\det \partial_{\mathbf{x}}\Psi(\mathbf{x}_0)\big|.$$

换言之，Ψ 把密度 p_0 重塑为 p_1。因子 $|\det \partial_{\mathbf{x}}\Psi|$ 表示体积的局部变化；由于概率质量守恒，密度以其倒数补偿。

作为一个简单情形，若 Ψ 是带可逆矩阵 $\mathbf{A}$ 的线性映射（即 $\mathbf{x}_1 = \mathbf{A}\mathbf{x}_0$），则

$$p_1(\mathbf{x}_1) = p_0(\mathbf{A}^{-1}\mathbf{x}_1)\,|\det \mathbf{A}^{-1}|.$$

示意地，可读作：

$$\text{采样：}\quad \mathbf{x}_0 \xrightarrow{\Psi} \mathbf{x}_1, \qquad \text{密度：}\quad p_{\mathbf{x}_0}(\mathbf{x}_0) \xrightarrow{\Psi} p_{\mathbf{x}_1}(\mathbf{x}_1).$$

方程 (B.B.1.561) **为何是换元公式？**这直接来自微积分中熟悉的规则。

单变量情形。设 $y = \Psi(x)$ 光滑且可逆。把关于 y 的积分按 x 改写，得到 $\displaystyle\int g(y)\,dy = \int g(\Psi(x))\,|\Psi'(x)|\,dx$，其中 $|\Psi'(x)|$ 补偿区间的拉伸或压缩，确保面积保持。

多元情形。对 $\Psi : \mathbb{R}^D \to \mathbb{R}^D$、$y = \Psi(x)$，$\displaystyle\int g(y)\,dy = \int g(\Psi(x))\,|\det(\partial_x \Psi)|\,dx$，于是无穷小体积按 $dy = |\det(\partial_x \Psi)|\,dx$ 变换。由此得到方程 (B.B.1.561) 中的密度公式。

复合多个双射。现在顺序施加若干次更新。设 $\mathbf{x}_k = \Psi_k(\mathbf{x}_{k-1})$，$k = 1, \ldots, L$，即

$$\mathbf{x}_0 \xrightarrow{\Psi_1} \mathbf{x}_1 \xrightarrow{\Psi_2} \cdots \xrightarrow{\Psi_L} \mathbf{x}_L,$$

其中每个 $\Psi_k : \mathbb{R}^D \to \mathbb{R}^D$ 是光滑双射。若初始状态服从密度 p_0（即 $\mathbf{x}_0 \sim p_0$），则更新序列为 $\mathbf{x}_1, \ldots, \mathbf{x}_L$ 诱导出密度 $p_1, \ldots, p_L$。

由于每一步概率质量守恒，密度按

$$p_k(\mathbf{x}_k) = p_{k-1}(\mathbf{x}_{k-1}) \left| \det \frac{\partial}{\partial \mathbf{x}_{k-1}} \Psi_k(\mathbf{x}_{k-1}) \right|^{-1}, \quad k = 1, \ldots, L$$

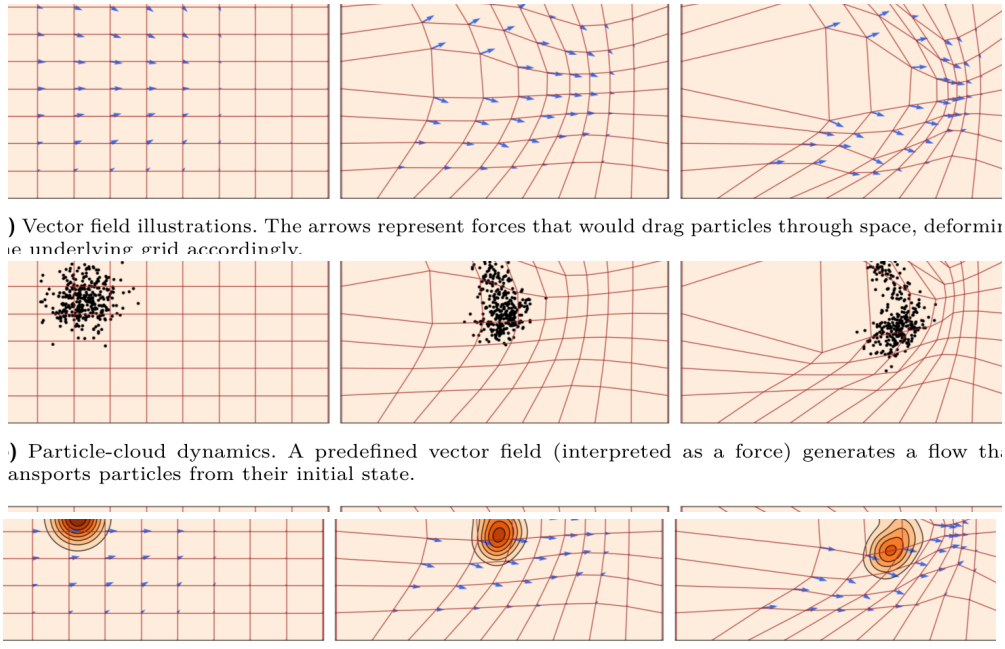
演化。由递归，$\mathbf{x}_L$ 处的最终密度为

$$p_{\mathbf{x}_L}(\mathbf{x}_L) = p_{\mathbf{x}_0}(\mathbf{x}_0) \cdot \prod_{k=1}^{L} \left| \det \left(\frac{\partial \Psi_k}{\partial \mathbf{x}_{k-1}} \right) \right|^{-1}. \tag{B.B.1.562}$$

等价地，在对数密度形式下：

$$\log p_{\mathbf{x}_L}(\mathbf{x}_L) = \log p_{\mathbf{x}_0}(\mathbf{x}_0) - \sum_{k=1}^{L} \log \left| \det \left(\frac{\partial \Psi_k}{\partial \mathbf{x}_{k-1}} \right) \right|.$$

这一表达式反映每次变换 Ψ_k 如何拉伸或收缩体积，由 Jacobian 行列式捕捉。这些局部体积变化沿变换路径的累积，决定了复合映射下的最终概率密度。方程 (B.B.1.562) 是归一化流背后的核心原理（见第 5.1.2 节）。



) Vector field illustrations. The arrows represent forces that would drag particles through space, deformi
e underlying grid accordingly.

) Particle-cloud dynamics. A predefined vector field (interpreted as a force) generates a flow th
ansports particles from their initial state.

) Density evolution. As particles are advected by the vector field, the density contours deform according
flecting how the flow reshapes the underlying distribution.

igure B.2: Illustrations of particle and density dynamics under a vector field. Each colum

图 B.52: 向量场下粒子与密度动力学示意。每列展示相继的时间快照（自左向右）。(a) 向量场示意：箭头表示会拖拽粒子在空间中运动的力，并相应地扭曲底层网格；(b) 粒子云动力学：一个预先定义的向量场（解释为力）生成流，把粒子从其初始状态输运；(c) 密度演化：当粒子被向量场平流输运时，密度等值线相应变形，反映流如何重塑底层分布。本图改编自 Lipman 等（2024），已经作者许可。

B.1.2 连续时间极限：连续性方程

现在从离散更新过渡到连续描述。假设粒子运动由一个含时速度场 $\mathbf{f}:\mathbb{R}^D\times[0,T]\to\mathbb{R}^D$ 驱动。设想把粒子 $\mathbf{x}_0\sim p_0$ 经过无穷多个小的双射更新来演化。在每个长度为 $\Delta t>0$ 的步长 t，更新为

$$\mathbf{x}_{t+\Delta t}=\Psi(\mathbf{x}_t):=\mathbf{x}_t+\Delta t\,\mathbf{f}(\mathbf{x}_t,t).$$

当 $\Delta t\to 0$ 时，这些更新的复合收敛为由速度场 $\mathbf{f}:\mathbb{R}^D\times[0,T]\to\mathbb{R}^D$ 支配的连续流：

$$\frac{d\mathbf{x}(t)}{dt}=\mathbf{f}\big(\mathbf{x}(t),t\big),\qquad \mathbf{x}(0)=\mathbf{x}_0\sim p_0. \tag{B.B.1.563}$$

在适当的光滑性假设下（见附录 A），该 ODE 对每个初值都有唯一解，它定义了一个确定性流映射 $\Psi_{0\to t}:\mathbb{R}^D\to\mathbb{R}^D$。换言之，$\Psi_{0\to t}$ 把初始状态 $\mathbf{x}_0$ 带到方程 (B.B.1.563) 在时刻 t 的解。

结果是整个分布也随之移动：初始密度 p_0 被输运为新密度 p_t，即 $\mathbf{x}(t)$ 的律。形式上，这写成一个推前：$p_t=(\Psi_{0\to t})_{\#}\,p_0$。

当 $\Psi_{0\to t}$ 光滑且可逆时，这化为熟悉的换元规则：

$$p_t(\mathbf{x})=p_0\big(\Psi_{t\to 0}(\mathbf{x})\big)\,\left|\det\partial_{\mathbf{x}}\Psi_{t\to 0}(\mathbf{x})\right|=\int\delta\big(\mathbf{x}-\Psi_{t\to 0}(\mathbf{x}_0)\big)\,p_0(\mathbf{x}_0)\,d\mathbf{x}_0.$$

连续性方程：密度如何随时间移动。我们不必为每个时刻分别写一个密度公式，而可以用空间 $\mathbf{x}$ 与时间 t 上的微分方程来描述它如何连续移动。想法很简单：概率质量守恒，速度场 $\mathbf{f}$ 只在空间中重新分配它。这给出连续性方程：

$$\frac{\partial}{\partial t}p_t(\mathbf{x})+\nabla\cdot\big(p_t(\mathbf{x})\mathbf{f}(\mathbf{x},t)\big)=0. \tag{B.B.1.564}$$

这里散度项 $\nabla\cdot(p_t\mathbf{f})$ 度量流如何局部膨胀或压缩密度，确保总概率保持为 1。该 PDE 确保流移动粒子时概率质量守恒。事实上，它可视为换元公式的连续时间类比。

由换元公式推导连续性方程。概念上，连续性方程也可通过取方程 (B.B.1.562) 的连续时间极限得到。不过这里我们采用基于方程 (B.B.1.561) 的更直接推导。

离散化与换元公式。考虑 $\mathbf{x}_{t+\Delta t}:=\Psi(\mathbf{x}_t)=\mathbf{x}_t+\Delta t\,\mathbf{f}(\mathbf{x}_t,t)$，这实际上是方程 (B.B.1.563) 在小时间区间 $\Delta t>0$ 上的前向 Euler 离散。映射 Ψ 关于 $\mathbf{x}_t$ 的 Jacobian 展开为 $\frac{\partial\Psi}{\partial\mathbf{x}_t}=\mathbf{I}+\Delta t\,\nabla_{\mathbf{x}}\mathbf{f}(\mathbf{x}_t,t)+O(\Delta t^2)$，故其行列式满足

$$\det\left(\frac{\partial\Psi}{\partial\mathbf{x}_t}\right)=1+\Delta t\,\nabla\cdot\mathbf{f}(\mathbf{x}_t,t)+O(\Delta t^2).$$

这里用到标准展开 $\det(\mathbf{I}+\Delta t\,\mathbf{A})=1+\Delta t\,\mathrm{Tr}(\mathbf{A})+O(\Delta t^2)$（当 $\Delta t\to 0$），以及 $\nabla\cdot\mathbf{f}=\mathrm{Tr}(\nabla_{\mathbf{x}}\mathbf{f})$。

应用换元公式，对数密度演化为

$$\log p_{t+\Delta t}(\mathbf{x}_{t+\Delta t})-\log p_t(\mathbf{x}_t)=-\Delta t\,\nabla\cdot\mathbf{f}(\mathbf{x}_t,t)+O(\Delta t^2). \tag{B.B.1.565}$$

使用 *Taylor* 展开。现在通过多元 Taylor 展开展开左边：

$$\log p_{t+\Delta t}(\mathbf{x}_{t+\Delta t}) - \log p_t(\mathbf{x}_t) = \Delta t\, \partial_t \log p_t(\mathbf{x}_t) + (\mathbf{x}_{t+\Delta t} - \mathbf{x}_t)^\top \nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t) + O(\Delta t^2).$$

代入 $\mathbf{x}_{t+\Delta t} - \mathbf{x}_t = \mathbf{f}(\mathbf{x}_t, t)\Delta t$，得

$$\log p_{t+\Delta t}(\mathbf{x}_{t+\Delta t}) - \log p_t(\mathbf{x}_t) = \Delta t\, \partial_t \log p_t(\mathbf{x}_t) + \Delta t\, \mathbf{f}(\mathbf{x}_t, t)^\top \nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t) + O(\Delta t^2).$$

与方程 (B.B.1.565) 匹配各项并令 $\Delta t \to 0$，得 $\partial_t \log p_t(\mathbf{x}_t) = -\nabla_{\mathbf{x}_t} \cdot \mathbf{f}(\mathbf{x}_t, t) - \mathbf{f}(\mathbf{x}_t, t)^\top \nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t)$。取指数并使用乘积法则，即得连续性方程。

速度优先（Lagrangian）与密度优先（Eulerian）。需要注意粒子动力学与密度动力学之间一个关键的不对称性。从速度场出发给出唯一的粒子流，因而唯一的密度演化；与之相对，仅规定密度路径并不能锁定单一速度场：许多不同的流可导致相同的密度序列。

速度优先（*Eulerian*：流 $\Rightarrow$ 密度）。至此我们假设速度场 $\mathbf{f}$ 已知。粒子 ODE $\frac{d\mathbf{x}(t)}{dt} = \mathbf{f}(\mathbf{x}(t), t)$ 描述每个粒子如何移动，而密度 PDE $\partial_t p_t + \nabla \cdot (p_t \mathbf{f}_t) = 0$ 描述粒子整个分布如何演化。这两种视角相连：按 ODE 移动粒子会自动产生一个满足 PDE 的密度。此时粒子流 $\Psi_{0\to t}$ 唯一确定：从 $\mathbf{x}(0) \sim p_0$ 出发，每条轨迹 $\mathbf{x}(t)$ 固定，所得密度 p_t 遵循连续性方程。此处粒子动力学与密度动力学完全一致。

密度优先（*Eulerian*：密度 $\not\Rightarrow$ 唯一流）。若我们只从密度路径 $t \mapsto p_t$ 出发（如流匹配第 5.3.2 节），则速度场不再唯一确定。例如，若向量场 $\mathbf{w}_t$ 满足 $\nabla_{\mathbf{x}} \cdot (p_t(\mathbf{x})\mathbf{w}_t(\mathbf{x})) = 0$（关于 p_t 无净通量），则 $\mathbf{f}_t$ 与 $\mathbf{f}_t + \mathbf{w}_t$ 都产生相同的密度演化。因此单个密度路径可能对应许多不同的流，选择某个特定粒子流 $\Psi_{0\to t}$ 就等于在这些可能中挑选一个特定速度场。

并非任意给定的路径 p_t 都能由粒子在某个速度场下移动而产生。连续性方程（方程 (B.B.1.564)）提供了“密度路径能否由流生成”的一致性检验。我们称 p_t 是可实现的（或由 $\mathbf{f}$ 生成的），若存在速度场 $\mathbf{f}$，使得遵循 $\frac{d\mathbf{x}(t)}{dt} = \mathbf{f}(\mathbf{x}(t), t)$ 的粒子经流映射 $\Psi_{0\to t}$ 恰好产生密度 p_t。即当 p_t 与 $\mathbf{f}$ 共同满足方程 (B.B.1.564) 时，可实现性成立。直观上，可实现性意味着 p_t 随时间的快照可由粒子在某个速度场下移动来解释，而非任意分布序列。

当该条件成立时，密度 p_t 无非是初始密度 p_0 沿流映射 $\Psi_{0\to t}$ 的推前。此时熟悉的换元公式适用。

（可选）条件化。若引入附加条件变量 $z \sim \pi(z)$，则同一推理对每个固定的 z 成立：$\frac{d\mathbf{x}(t)}{dt} = v_t(\mathbf{x}(t) \mid z)$，推前为 $p_t(\cdot \mid z) = (\Psi_{0\to t}(\cdot; z))_{\#} p_0$，连续性方程为 $\partial_t p_t(\mathbf{x} \mid z) + \nabla \cdot (p_t(\mathbf{x} \mid z) v_t(\mathbf{x} \mid z)) = 0$。边缘密度为 $p_t(\mathbf{x}) = \int p_t(\mathbf{x} \mid z)\pi(z)\, dz$。

B.1.3 随机过程：Fokker–Planck 方程

当加入噪声时，动力学遵循方程 (A.A.2.558) 中的 SDE：$d\mathbf{x}(t) = \mathbf{f}(\mathbf{x}(t), t)\, dt + g(t)\, d\mathbf{w}(t)$。此时密度 $p_t(\mathbf{x})$ 满足 Fokker–Planck 方程：

$$\begin{aligned}\frac{\partial p_t(\mathbf{x})}{\partial t} &= -\nabla \cdot \big(\mathbf{f}(\mathbf{x}, t)\, p_t(\mathbf{x})\big) + \frac{1}{2} g^2(t)\, \Delta p_t(\mathbf{x}) \\ &= -\nabla \cdot \left(\Big[\mathbf{f}(\mathbf{x}, t) - \frac{1}{2} g^2(t) \nabla_{\mathbf{x}} \log p_t(\mathbf{x}) \Big] p_t(\mathbf{x}) \right).\end{aligned}$$

这里 $\Delta p_t = \nabla \cdot \nabla_{\mathbf{x}} p_t$ 是 Laplace 算子。第一项描述确定性漂移 $\mathbf{f}$ 对概率质量的输运，第二项刻画方差正比于 $\frac{1}{2}g^2(t)$ 的随机噪声所导致的密度扩散（散布）。

Fokker–Planck 方程的推导较为复杂，我们在第 C.1.4 节给出。

B.2 连续性方程的直观

本节给出连续性方程的物理解释，强调它在动力系统中作为概率密度守恒定律的角色。

B.2.1 连续性方程的物理解释

考虑三维空间中一个小的固定控制体（一个矩形盒子），中心位于 $\mathbf{x} = (x, y, z)$，边长为 $\Delta x, \Delta y, \Delta z$。设 $p(\mathbf{x}, t)$ 表示位置 $\mathbf{x}$、时刻 t 处一个守恒量（如质量或概率）的密度。盒子内该量的总量为：

$$\text{盒内总量} = p(\mathbf{x}, t)\, \Delta x\, \Delta y\, \Delta z.$$

总量如何变化？总量的变化只能来自穿过盒子边界的通量。设 $\mathbf{j}(\mathbf{x}, t)$ 表示通量向量，即单位面积单位时间流过的量。

x 方向的通量。穿过左面（x 处）的流入约为 $j_x(x, y, z, t)\, \Delta y\, \Delta z$，穿过右面（$x + \Delta x$ 处）的流出约为 $j_x(x + \Delta x, y, z, t)\, \Delta y\, \Delta z$。因此 x 方向的净通量为 $[j_x(x, y, z, t) - j_x(x + \Delta x, y, z, t)]\, \Delta y\, \Delta z$。

所有方向的净通量。y、z 方向有类似项。汇总所有贡献，盒子的总净流出为 $-\nabla \cdot \mathbf{j}(\mathbf{x}, t)\, \Delta x\, \Delta y\, \Delta z$。

盒内的变化率。盒内总量的变化率为 $\frac{\partial p}{\partial t}(\mathbf{x}, t)\, \Delta x\, \Delta y\, \Delta z$。

守恒原理。假设该量守恒（如总质量或概率不随时间变化），则变化率等于净流出的负值：

$$\frac{\partial p}{\partial t}(\mathbf{x}, t)\, \Delta x\, \Delta y\, \Delta z = -\nabla \cdot \mathbf{j}(\mathbf{x}, t)\, \Delta x\, \Delta y\, \Delta z.$$

局部形式。约去公共体积因子（对任意小盒子成立），得到连续性方程的局部形式：

$$\frac{\partial p}{\partial t} + \nabla \cdot \mathbf{j} = 0.$$

B.2.2 由守恒定律推导连续性方程

连续性方程把一个物理量（如质量或电荷）在动力系统中的守恒形式化。设 $p(\mathbf{x}, t)$ 表示位置 $\mathbf{x} \in \mathbb{R}^D$、时刻 $t \in [0, T]$ 处守恒量的密度，$\mathbf{v}(\mathbf{x}, t)$ 表示速度场。

第 1 步：控制体内的变化率。考虑任意控制体 $V \subset \mathbb{R}^D$，边界为 ∂V。V 内守恒量总量为 $\int_V p(\mathbf{x}, t)\, dV$，其时间导数给出累积率：$\frac{\partial}{\partial t} \int_V p(\mathbf{x}, t)\, dV$。

第 2 步：穿过边界的净通量。该量经 ∂V 流出 V，外法向量为 $\mathbf{n}$。净外通量为 $\int_{\partial V} p(\mathbf{x}, t)\mathbf{v}(\mathbf{x}, t) \cdot \mathbf{n}\, dS$。

第 3 步：守恒原理。守恒意味着 V 内累积率等于净外通量的负值：

$$\frac{\partial}{\partial t}\int_V p\,dV + \int_{\partial V} p\mathbf{v}\cdot\mathbf{n}\,dS = 0.$$

第 4 步：散度定理。应用散度定理把面积分转为体积分：$\int_{\partial V} p\mathbf{v}\cdot\mathbf{n}\,dS = \int_V \nabla\cdot(p\mathbf{v})\,dV$。故

$$\frac{\partial}{\partial t}\int_V p\,dV + \int_V \nabla\cdot(p\mathbf{v})\,dV = 0.$$

第 5 步：局部形式。由于控制体 V 任意，被积函数必须逐点为零。这便得到连续性方程。

Appendix C

扩散模型幕后：Itô 演算与 Girsanov 定理

（基于分数的）扩散模型建立在 SDE 之上：一个推动状态的漂移项，与一个扰动状态的 Brown 项。与 ODE 路径不同，Brown 路径处处不可微，故普通链式法则失效。本节引入两个使数学严格化的基本工具：

- **Itô 公式**是随机轨迹的正确链式法则。它告诉我们当 $\mathbf{x}_t$ 遵循 SDE 时，函数 $h(\mathbf{x}_t, t)$ 如何演化。它使 Fokker–Planck 方程、矩动力学、Itô 乘积法则，以及分数训练中所用恒等式的推导成为可能。
- **Girsanov 定理**是路径概率上的一个换测度结果。它量化当噪声固定、仅改变漂移时似然如何变化。这把分数匹配与路径空间 KL 散度联系起来，并解释为何在反向 SDE 中学习分数对应于最大化数据似然。

有了这些工具，标准扩散模型推导（Fokker–Planck、反向时间 SDE、训练目标、似然关系）便可干净利落、无需含糊地完成。

C.1 Itô 公式：随机过程的链式法则

标准微积分不能直接应用于随机过程，因为 Wiener 过程在经典意义下不可微。取而代之，我们使用 Itô 演算，它提供处理随机积分的规则。

C.1.1 动机：为何需要特殊的链式法则？

考虑一个确定性含时函数 y_t，它随时间 t 光滑演化（如 ODE）。若有函数 $h(y_t, t)$，通常链式法则告诉我们：

$$\frac{dh}{dt} = \frac{\partial h}{\partial t} + \nabla_y h \, \frac{dy_t}{dt}.$$

这里 $\nabla_y h$ 是 h 的 Jacobian。这对确定性路径 y_t 完全适用。

问题 C.1.1 (Itô 公式之问)**：** 但若 $\mathbf{x}_t$ 是随机过程，比如由 SDE $d\mathbf{x}_t = \mathbf{f}(\mathbf{x}_t, t)\, dt + g(t)\, d\mathbf{w}_t$（如方程 (A.A.2.558)）驱动，会发生什么？过程 $h(\mathbf{x}_t, t)$ 满足什么 SDE?

普通链式法则为何失效？朴素地套用经典链式法则会得到 $dh = \frac{\partial h}{\partial t} dt + \nabla_y h \cdot d\mathbf{x}_t$。然而这忽略了 Brown 增量满足 $d\mathbf{w}_t = O(\sqrt{dt})$ 且 $(d\mathbf{w}_t)^2 = dt$。因此，在随机演算中 $d\mathbf{w}_t$ 的二阶项不会消失——这与经典演算中 $(dt)^2$ 项可忽略不同。

例 C.1.1 (简单例子 $h(x_t) = x_t^2$)**：** 为看直观，考虑简单实值函数 $h(x_t) = x_t^2 \in \mathbb{R}$，其中随机变量 $x_t \in \mathbb{R}$ 满足 $dx_t = \sigma\, dw_t$，$\sigma > 0$ 为常数。若尝试经典链式法则，$dh = 2x_t\, dx_t = 2x_t\sigma\, dw_t$。若此为真，$h(x_t)$ 的期望将不随时间变化，因为 $E[dh] = 2\sigma E[x_t\, dw_t] = 2\sigma E[x_t]E[dw_t] \underset{=0}{\mid} = 0$。但由经典 Brown 运动性质（见方程 (A.A.2.559)）我们知道 $E[x_t^2] = \sigma^2 t$，它随时间线性增长。故普通链式法则漏掉了一个重要项。 ◇

C.1.2 由 Taylor 展开推导一维 Itô 公式

经 Taylor 展开的确定性链式法则。为理解经典链式法则为何对 SDE 定义的随机过程失效，我们先在确定性设定下用 Taylor 展开回顾它。考虑标量情形：$y_t \in \mathbb{R}$，$h(\cdot,\cdot) \in \mathbb{R}$。形式上取 $dy_t = y_{t+dt} - y_t$，$dt \approx 0$，展开：

$$h(y_{t+dt}, t+dt) - h(y_t, t) = \frac{\partial h}{\partial t}dt + \frac{\partial h}{\partial y}dy_t + \frac{1}{2}\left(\frac{\partial^2 h}{\partial y^2}(dy_t)^2 + 2\frac{\partial^2 h}{\partial t \partial y}\, dt\, dy_t + \frac{\partial^2 h}{\partial t^2}(dt)^2\right) + O(dt^3).$$

这里 $dt\, dy_t = \frac{dy_t}{dt}(dt)^2 = O(dt^2)$，类似地 $(dt)^2 = O(dt^2)$，故灰色部分可忽略，全微分为 $dh = \frac{\partial h}{\partial t}dt + \frac{\partial h}{\partial y}dy_t + O(dt^2)$。

经随机 Taylor 展开的 Itô 公式。现在考虑由 SDE $dx_t = f(x_t, t)\, dt + g(t)\, dw_t$ 支配的随机过程 $x_t \in \mathbb{R}$，其中 w_t 为标准 Brown 运动。我们要计算标量函数 $h(x_t, t)$ 的微分。使用保留 dx_t 二阶项的随机 Taylor 展开（Kloeden 等, 1992），有：

$$h(x_{t+dt}, t+dt) - h(x_t, t) = \frac{\partial h}{\partial t}dt + \frac{\partial h}{\partial x}dx_t + \frac{1}{2}\left(\frac{\partial^2 h}{\partial x^2}(dx_t)^2 + 2\frac{\partial^2 h}{\partial t \partial x}\, dt\, dx_t + \frac{\partial^2 h}{\partial t^2}(dt)^2\right) + \cdots$$

可忽略的交叉项。由 Brown 运动的缩放性质（方程 (A.A.2.559)），$dw_t = O(\sqrt{dt}) \Rightarrow dt \cdot dw_t = O((dt)^{3/2})$。故 $dt \cdot dx_t = dt(f\, dt + g\, dw_t) = f(dt)^2 + g\, dt\, dw_t = O((dt)^{3/2})$，灰色项可忽略：$O((dt)^{3/2})$ 或更小。

二阶项 $(dx_t)^2$。用 SDE 展开：

$$(dx_t)^2 = (f\, dt + g\, dw_t)^2 = f^2(dt)^2 + 2fg\, dt\, dw_t + g^2(dw_t)^2 = O((dt)^2) + O((dt)^{3/2}) + g^2 O(dt) = g^2(t)\, dt$$

合并各项，得微分：

$$dh(x_t, t) = \frac{\partial h}{\partial t}dt + \frac{\partial h}{\partial x}dx_t + \frac{1}{2}\frac{\partial^2 h}{\partial x^2}g^2(t)\, dt.$$

代入 $dx_t = f(x_t, t)\, dt + g(t)\, dw_t$，得

$$dh(x_t, t) = \left(\frac{\partial h}{\partial t} + f\frac{\partial h}{\partial x} + \frac{1}{2}g^2\frac{\partial^2 h}{\partial x^2}\right)dt + g\frac{\partial h}{\partial x}dw_t.$$

这就是一维版本的 Itô 公式。

例 C.1.2 (简单例子 $h(x_t) = x_t^2$（续）)**：** 回到简单例子 $h(x_t) = x_t^2$，其中 $dx_t = \sigma\, dw_t$，$\sigma > 0$ 为常数。把 Itô 公式正确应用于 $h(x_t) = x_t^2$，得 $dh(x_t) = d(x_t^2) = 2x_t\, dx_t + \sigma^2\, dt$。代入 $dx_t = \sigma\, dw_t$，成为 $d(x_t^2) = 2x_t\sigma\, dw_t + \sigma^2\, dt$。 ◇

C.1.3 Itô 公式：SDE 的链式法则

我们总结上面推导的一维 Itô 公式。用类似论证，结果自然推广到多维情形。虽省略详细推导，我们仍陈述一般公式以供完整。最后，我们通过推导 Itô 乘积法则来说明 Itô 公式的一个应用，它使随机过程 $\mathbf{x}_t$ 与 $\mathbf{y}_t$ 的 $d(\mathbf{x}_t^\top \mathbf{y}_t)$ 可计算。

一维 Itô 公式。设 $x_t \in \mathbb{R}$ 满足 SDE $dx_t = f(x_t,t)\,dt + g(t)\,dw_t$。对标量函数 $h:\mathbb{R}\times[0,T]\to\mathbb{R}$，过程 $h(x_t,t)$ 满足

$$dh(x_t,t) = \left(\frac{\partial h}{\partial t} + f\frac{\partial h}{\partial x} + \frac{1}{2}g^2\frac{\partial^2 h}{\partial x^2}\right)dt + g\frac{\partial h}{\partial x}dw_t.$$

标量输出的多维 Itô 公式。设 $\mathbf{x}_t \in \mathbb{R}^D$ 满足 SDE $d\mathbf{x}_t = \mathbf{f}(\mathbf{x}_t,t)\,dt + g(t)\,d\mathbf{w}_t$，其中 $\mathbf{f}:\mathbb{R}^D\times[0,T]\to\mathbb{R}^D$，$g:[0,T]\to\mathbb{R}$，$\mathbf{w}_t\in\mathbb{R}^D$ 为 D 维 Brown 运动。设 $h:\mathbb{R}^D\times[0,T]\to\mathbb{R}$ 为标量值函数。则 $h(\mathbf{x}_t,t)$ 满足：

$$dh(\mathbf{x}_t,t) = \left(\frac{\partial h}{\partial t} + \nabla_{\mathbf{x}}h^\top\mathbf{f} + \frac{1}{2}g^2(t)\,\mathrm{Tr}\big(\nabla_{\mathbf{x}}^2 h\big)\right)dt + g(t)\,\nabla_{\mathbf{x}}h^\top d\mathbf{w}_t, \tag{C.C.1.566}$$

其中 $\nabla_{\mathbf{x}}h\in\mathbb{R}^D$ 是梯度，$\nabla_{\mathbf{x}}^2 h\in\mathbb{R}^{D\times D}$ 是 h 关于 $\mathbf{x}$ 的 Hessian 矩阵。

例 C.1.3 (Itô 乘积法则)**：** 设 $\mathbf{x}_t,\mathbf{y}_t\in\mathbb{R}^D$ 为向量值随机过程，由 SDE $d\mathbf{x}_t = \mathbf{a}(\mathbf{x}_t,t)\,dt + b(t)\,d\mathbf{w}_t$、$d\mathbf{y}_t = \mathbf{c}(\mathbf{y}_t,t)\,dt + d(t)\,d\mathbf{w}_t$ 支配，其中 $\mathbf{a},\mathbf{c}:\mathbb{R}^D\times[0,T]\to\mathbb{R}^D$ 为向量场，$b(t),d(t)\in\mathbb{R}$ 为标量值函数，$\mathbf{w}_t\in\mathbb{R}^D$ 为标准 D 维 Brown 运动。我们要推导标量过程 $z(t) := \mathbf{x}_t^\top\mathbf{y}_t$ 的 SDE。

对双线性函数 $h(\mathbf{x},\mathbf{y}) := \mathbf{x}^\top\mathbf{y}$ 应用多维 Itô 公式，得 $d(\mathbf{x}^\top\mathbf{y}) = (d\mathbf{x})^\top\mathbf{y} + \mathbf{x}^\top d\mathbf{y} + \mathrm{Tr}\big[d\mathbf{x}\cdot(d\mathbf{y})^\top\big]$。Itô 修正项计算为：

$$d\mathbf{x}\cdot(d\mathbf{y})^\top = b(t)\,d\mathbf{w}_t\cdot[d(t)\,d\mathbf{w}_t]^\top = b(t)d(t)\,d\mathbf{w}_t\cdot d\mathbf{w}_t^\top = b(t)d(t)\,dt\cdot\mathbf{I}_D.$$

故 $\mathrm{Tr}\big[d\mathbf{x}\cdot(d\mathbf{y})^\top\big] = b(t)d(t)\,\mathrm{Tr}(\mathbf{I}_D)\,dt = D\,b(t)d(t)\,dt$。合并一切，所得 SDE 为

$$d(\mathbf{x}^\top\mathbf{y}) = (d\mathbf{x})^\top\mathbf{y} + \mathbf{x}^\top d\mathbf{y} + D\,b(t)d(t)\,dt. \tag{C.C.1.567}$$

◇

C.1.4 Itô 公式的应用：Fokker–Planck 方程推导

本节应用方程 (C.C.1.566) 的 Itô 公式推导 Fokker–Planck 方程——一个刻画与方程 (A.A.2.558) 中 SDE 定义的 D 维扩散过程相联的概率密度 $p_t(\mathbf{x})$ 随时间演化的 PDE。

第 1 步：应用 Itô 公式。设 $\phi(\mathbf{x},t)$ 为光滑检验函数 $\phi:\mathbb{R}^D\times[0,T]\to\mathbb{R}$。由 Itô 公式：

$$d\phi(\mathbf{x}_t,t) = \left(\frac{\partial\phi}{\partial t} + \nabla_{\mathbf{x}}\phi^\top\mathbf{f}(\mathbf{x}_t,t) + \frac{1}{2}g^2(t)\,\mathrm{Tr}[\nabla_{\mathbf{x}}^2\phi]\right)dt + g(t)\,\nabla_{\mathbf{x}}\phi^\top d\mathbf{w}_t.$$

第 2 步：取期望。对 $p_t(\mathbf{x})$ 取期望，并注意 $E[d\mathbf{w}_t] = 0$：

$$E[d\phi(\mathbf{x}_t,t)] = E\left[\frac{\partial\phi}{\partial t} + \nabla_{\mathbf{x}}\phi^\top\mathbf{f}(\mathbf{x}_t,t) + \frac{1}{2}g^2(t)\,\mathrm{Tr}[\nabla_{\mathbf{x}}^2\phi]\right]dt.$$

第 3 步：用密度表示期望。该期望可写为：

$$E[d\phi(\mathbf{x}_t,t)] = \int \left(\frac{\partial \phi}{\partial t} + \nabla_{\mathbf{x}}\phi^\top \mathbf{f}(\mathbf{x},t) + \frac{1}{2} g^2(t)\,\mathrm{Tr}[\nabla^2_{\mathbf{x}}\phi] \right) p_t(\mathbf{x})\, d\mathbf{x}\, dt.$$

第 4 步：分部积分。在 $\mathbb{R}^D$ 中使用分部积分（散度定理）：

$$\int \nabla_{\mathbf{x}}\phi^\top \mathbf{f}\, p_t\, d\mathbf{x} = -\int \phi\, \nabla_{\mathbf{x}} \cdot (\mathbf{f} p_t)\, d\mathbf{x}, \qquad \int \mathrm{Tr}[\nabla^2_{\mathbf{x}}\phi]\, p_t\, d\mathbf{x} = -\int \phi\, \Delta p_t\, d\mathbf{x}.$$

第 5 步：代回并整理。代回：

$$E[d\phi(\mathbf{x}_t,t)] = \int \phi(\mathbf{x},t) \left(\frac{\partial p_t}{\partial t} + \nabla_{\mathbf{x}} \cdot (\mathbf{f} p_t) - \frac{1}{2} g^2(t) \Delta p_t \right) d\mathbf{x}\, dt.$$

第 6 步：得出 Fokker–Planck 方程。由于 ϕ 任意，被积函数必为零：

$$\frac{\partial p_t}{\partial t} = -\nabla_{\mathbf{x}} \cdot \big(\mathbf{f}(\mathbf{x},t) p_t(\mathbf{x}) \big) + \frac{1}{2} g^2(t) \Delta p_t(\mathbf{x}),$$

至此完成 Fokker–Planck 方程的推导。

C.1.5 Itô 公式的应用：线性 SDE 的闭式解

本小节演示如何用积分因子（类似 ODE 情形）与 Itô 公式获得线性 SDE 的闭式解。该方法模仿求解线性 ODE 的经典技巧，但适配随机设定。

我们考虑形如如下的线性 SDE：

$$dx_t = f(t)\, x_t\, dt + g(t)\, d\mathbf{w}_t, \tag{C.C.1.568}$$

其中 $f(t)$ 与 $g(t)$ 为确定性函数，$\mathbf{w}_t$ 为标准 Wiener 过程。这类前向 SDE 在扩散模型中常见（见第 4.1 节）。

线性 SDE 的闭式解。我们用积分因子法推导方程 (C.C.1.568) 的显式解。

第 *1* 步：定义积分因子。令 $\Psi(t) := \exp\Big(-\int_0^t f(s)\, ds \Big)$，并定义 $y_t := \Psi(t) x_t$。

第 *2* 步：应用 *Itô* 公式。对函数 $h(x,t) := \Psi(t)x$ 应用 Itô 公式。这实际上是方程 (C.C.1.567) 中 Itô 乘积法则的特例。由于 $\Psi(t)$ 确定性，无交叉变差项，公式简化为：

$$\begin{aligned} dy_t = d[\Psi(t)x_t] &= \Psi'(t) x_t\, dt + \Psi(t)\, dx_t \\ &= -f(t)\Psi(t) x_t\, dt + \Psi(t) \big[f(t) x_t\, dt + g(t)\, d\mathbf{w}_t \big] = \Psi(t) g(t)\, d\mathbf{w}_t. \end{aligned}$$

故（因 $\Psi(0) = 1$）$y_t = y_0 + \int_0^t \Psi(s) g(s)\, dw(s) = x_0 + \int_0^t \Psi(s) g(s)\, dw(s)$。

第 *3* 步：解出 x_t。用 $x_t = \Psi(t)^{-1} y_t$，得

$$x_t = e^{\int_0^t f(s)\, ds} x_0 + \int_0^t e^{-\int_0^s f(r)\, dr} g(s)\, dw(s). \tag{C.C.1.569}$$

这给出了向量值 SDE 的显式解。

闭式解的分析。方程 (C.C.1.569) 再次确认 $p_t(x_t \mid x_0)$ 是 Gauss 的。为此定义 $\phi(s) := e^{-\int_0^s f(u)\, du} g(s)$，它是时间的确定性矩阵值函数（假设 $f(u)$ 与 $g(s)$ 确定性）。于

是 Itô 积分 $\int_0^t \phi(s)\,dw_s$ 是零均值 Gauss 随机变量，因为它是确定性函数关于 Brown 运动的随机积分。故 $x_t \mid x_0$ 是 Gauss 随机变量的仿射变换，本身也是 Gauss 的。其分布完全由条件均值与协方差刻画。

定义条件均值与协方差（给定初值 x_0）为 $m(t) := E[x_t \mid x_0]$，$P(t) := E[(x_t - m(t))(x_t - m(t))^\top \mid x_0]$。

均值。利用期望线性性及确定性函数的 Itô 积分零均值：

$$m(t) = E\left[e^{\int_0^t f(s)\,ds}x_0 + \int_0^t \phi(s)\,dw_s \mid x_0\right] = e^{\int_0^t f(s)\,ds}x_0.$$

协方差。令 $z_t := \int_0^t \phi(s)\,dw_s$。则 $x_t - m(t) = A(t)z_t$，故 $P(t) = e^{2\int_0^t f(s)\,ds}E[z_t z_t^\top]$。由 Itô 等距[42]，$E[z_t z_t^\top] = \left(\int_0^t \phi^2(s)\,ds\right)\mathbf{I}_D$，故

$$P(t) = e^{2\int_0^t f(s)\,ds}\left(\int_0^t \left[e^{-\int_0^s f(u)\,du}g(s)\right]^2 ds\right)\mathbf{I}_D.$$

这表明条件协方差是各向同性的。

方程 *(4.3.3)* 中均值与方差 *ODE* 的推导。或者，我们可直接从线性 SDE (C.C.1.568) 推导矩演化方程。

均值演化：对 SDE 两边取条件期望并利用线性性，$\frac{dm(t)}{dt} = E[f(t)x_t \mid x_0] = f(t)E[x_t \mid x_0] = f(t)m(t)$。

协方差演化：定义中心化过程 $\tilde{x}_t := x_t - m(t)$。应用 Itô 乘积法则（见方程 (C.C.1.567)）：$d(\tilde{x}_t\tilde{x}_t^\top) = d\tilde{x}_t\cdot\tilde{x}_t^\top + \tilde{x}_t\cdot d\tilde{x}_t^\top + d\tilde{x}_t\cdot d\tilde{x}_t^\top$。由 SDE，$d\tilde{x}_t = dx_t - dm(t) = f(t)\tilde{x}_t\,dt + g(t)\,dw_t$。代入乘积法则并取期望：

$$\frac{dP(t)}{dt} = E[f(t)\tilde{x}_t\tilde{x}_t^\top + \tilde{x}_t\tilde{x}_t^\top f(t) + g^2(t)\mathbf{I}_D] = 2f(t)P(t) + g^2(t)\mathbf{I}_D.$$

于是我们恢复了方程 (4.3.3) 中的矩演化方程。

C.2 测度的换元：扩散模型中的 Girsanov 定理

扩散模型利用 SDE 把简单噪声转化为丰富的数据分布。这一变换的核心在于一个深刻思想：我们可以通过只修改 SDE 的确定性部分（漂移）而保留其底层随机性，来重新解释随机性。这正是 Girsanov 定理登场之处。

核心思想。考虑一条观测到的连续轨迹，描述数据从时刻 $t = 0$ 到 $t = T$ 的演化，记作 $\mathbf{x}_{0:T} := \{\mathbf{x}_t \mid t \in [0, T]\}$。Girsanov 定理处理一个基本问题。

问题 C.2.1 (Girsanov 之问)**：** 给定这一条观测路径，若假设它由某个 SDE 生成，其似然是多少？若假设它由另一个不同的 SDE 生成，似然又是多少？

[42]Itô 等距在期望意义下把随机积分联系到标准积分；其证明需 Itô 演算的完整工具，此处从略。对过程 $\psi : [0, T] \to \mathbb{R}^{D\times D}$，Itô 等距陈述为 $E\left[\left|\int_0^T \psi(t)\,dw_t\right|^2\right] = E\int_0^T \|\psi(t)\|_F^2\,dt$，其中 $\|\psi(t)\|_F^2 = \sum_{i,j=1}^D |\psi_{ij}(t)|^2$ 为 Frobenius 范数。对 $\psi(t) \in \mathbb{R}^D$（向量），积分是标量，等距简化为 $E\left[\left|\int_0^T \psi(t)\,dw_t\right|^2\right] = E\int_0^T \|\psi(t)\|^2\,dt$。

我们比较生成同一条轨迹的两个假设模型。这两个假设的 SDE 共享相同的底层纯随机性，由标准 Wiener 过程（Brown 运动）$\mathbf{w}_t$ 表示，仅在确定性 “推动” 或漂移函数上不同。我们假设 $\mathbf{x}_0$ 对两个假设生成过程有相同的初始分布。

为建立直观，把 $\mathbf{x}_{0:T}$ 想成纸上一条弯曲的线。一个假设是它由 “机器人画师” 按漂移 $\mathbf{f}$ 绘制、再由按 $g(t)$ 缩放的随机噪声扰动产生，似然为 $p_{\mathbf{f}}(\mathbf{x}_{0:T})$。或者想象第二个机器人，用不同漂移 $\tilde{\mathbf{f}}$ 但使用同一噪声过程，生成同一条线，似然为 $p_{\tilde{\mathbf{f}}}(\mathbf{x}_{0:T})$。

Girsanov 定理给出精确方法来比较同一条观测路径的这两个似然。它量化在固定随机性的同时，漂移变化如何影响生成特定轨迹的概率。

设定。设 $\mathbf{x}_t \in \mathbb{R}^D$ 是我们单条固定的连续路径。我们考虑它在两个 SDE 模型下的似然，这两个模型仅在漂移函数 $\mathbf{f}$ 与 $\tilde{\mathbf{f}}$ 上不同。它们共享相同的扩散系数 $g(t) \in \mathbb{R}$ 与相同的底层 Wiener 过程 $\mathbf{w}_t$：

$$d\mathbf{x}_t = \mathbf{f}(\mathbf{x}_t, t)\,dt + g(t)\,d\mathbf{w}_t \quad (\text{漂移为}\mathbf{f}\text{ 的模型}), \qquad d\mathbf{x}_t = \tilde{\mathbf{f}}(\mathbf{x}_t, t)\,dt + g(t)\,d\mathbf{w}_t \quad (\text{漂移为}\tilde{\mathbf{f}}\text{ 的模型}).$$

令 $\boldsymbol{\delta}_t := \mathbf{f}(\mathbf{x}_t, t) - \tilde{\mathbf{f}}(\mathbf{x}_t, t)$ 表示给定路径 $\mathbf{x}_t$ 上漂移之差。

Girsanov 似然比。Girsanov 定理给出这两种解释同一观测路径方式之间的基本似然比。它陈述：

$$\frac{p_{\mathbf{f}}(\mathbf{x}_{0:T})}{p_{\tilde{\mathbf{f}}}(\mathbf{x}_{0:T})} = \exp\left(\int_0^T \boldsymbol{\delta}_t^\top g(t)^{-1}\, d\mathbf{w}_t - \frac{1}{2}\int_0^T \left\| g(t)^{-1}\boldsymbol{\delta}_t \right\|^2 dt \right).$$

这个紧凑公式是两个积分的指数。第一个是 Itô 积分，第二个是标准 Riemann 积分。该比值在扩散模型中至关重要，使我们能在不同数据生成过程之间架桥，并评估模型似然。

Girsanov 定理最好理解为测度的换元公式。正如微积分中的换元通过 Jacobian 行列式在坐标系间变换积分，Girsanov 定理提供相应因子（Radon–Nikodym 导数），在漂移改变而扩散不变时，在两个随机过程之间变换概率或期望。

C.2.1 Girsanov 定理作为似然训练与分数匹配之间的桥梁

在理解 Girsanov 定理如何把单条路径在不同漂移假设下的似然联系起来之后，我们深入其对扩散模型的含义。

回忆扩散模型中的前向 SDE：$d\mathbf{x}_t = \mathbf{f}(\mathbf{x}_t, t)\,dt + g(t)\,d\mathbf{w}_t$，它在完整轨迹 $\mathbf{x}_{0:T} := \{\mathbf{x}_t\}_{t=0}^T$ 上诱导路径分布 P（即过程在整个时间区间上的联合律）。由可学习分数函数 $s_\phi(\mathbf{x}_t, t)$ 参数化的反向时间 SDE 为 $d\mathbf{x}_t = \big[\mathbf{f}(\mathbf{x}_t, t) - g^2(t) s_\phi(\mathbf{x}_t, t)\big]dt + g(t)\,d\bar{\mathbf{w}}_t$，它又定义了轨迹上另一个路径分布 P_ϕ。

扩散模型中的两个概念。在扩散模型中，我们在描述随机过程 $\mathbf{x}_{0:T}$ 的两个核心视角间穿行：前向过程及其反向时间对应物。这些视角产生两个不同但相关的目标：

- **概念 1. 边缘分布匹配：**该目标构造一个反向时间过程，使其边缘 $p_t(\mathbf{x}_t)$ 与前向 SDE 的边缘匹配，从时刻 T 的噪声出发，在 $t = 0$ 处恢复数据分布。如前所述，Fokker–Planck 方程保证反向时间 SDE 的这种边缘一致性。

- **概念 2. 联合路径分布匹配：**这个更强的目标寻求匹配整个轨迹上的完整联合分布 $P = p(\mathbf{x}_{0:T})$。它不仅匹配各单个时间步的快照，还确保整个状态序列及其时间依赖被忠实复现。

匹配完整路径分布 P 保证所有边缘匹配。形式上，设 $\mathbf{x}_{0:T} := \{\mathbf{x}_t \mid t \in [0,T]\}$ 为联合分布 $p(\mathbf{x}_{0:T})$ 的随机过程。设另一联合分布为 $q(\mathbf{x}_{0:T})$ 的过程满足 $p(\mathbf{x}_{0:T}) = q(\mathbf{x}_{0:T})$。则对任意 $t \in [0,T]$，边缘分布 $p_t(\mathbf{x}_t) = \int p(\mathbf{x}_{0:T})\, d\mathbf{x}_{[0,T]\setminus\{t\}}$、$q_t(\mathbf{x}_t) = \int q(\mathbf{x}_{0:T})\, d\mathbf{x}_{[0,T]\setminus\{t\}}$，这蕴含 $p_t(\mathbf{x}_t) = q_t(\mathbf{x}_t)$，$\forall t \in [0,T]$。故联合路径匹配蕴含边缘匹配。

但反之不成立：两个过程可在每个时间步都有相同边缘，却在时间相关性上显著不同。边缘匹配缺乏捕捉这些时间间依赖的能力，而这些依赖仅编码在联合分布中。

Girsanov 架起两个目标的桥梁。虽然反向时间 SDE 主要为边缘匹配（概念 1）而设计，Girsanov 定理揭示更深的联系：跨时间的分数匹配也鼓励联合路径匹配（概念 2）。

更精确地，Girsanov 定理联系前向路径分布 P 与学习到的反向路径分布 P_ϕ。基于分数的扩散模型中的目标函数是这些路径测度之间的 KL 散度：

$$D_{\mathrm{KL}}(P\|P_\phi) = \frac{1}{2}E_P\left[\int_0^T g^2(t)\left\|s_\phi(\mathbf{x}_t,t) - \nabla_{\mathbf{x}}\log p_t(\mathbf{x}_t)\right\|^2 dt\right] + \text{Const.}, \tag{C.C.2.570}$$

这里常数不依赖 ϕ，且我们用到 Itô 积分在 P 下零期望这一事实。该式表明，最小化联合路径间的 KL 散度，等价于学习一个逼近真实分数 $\nabla_{\mathbf{x}_t}\log p_t(\mathbf{x}_t)$ 的分数函数 s_ϕ。因此，分数匹配虽被框定为边缘目标，实际上却促进整个联合路径分布的对齐。

隐式似然训练。除匹配路径分布外，分数匹配还隐式地使扩散模型达成生成建模的一个基本目标：逼近数据似然（Song 等, 2021）。这一联系通过一个强大概念——换测度公式——变得清晰。该公式由 Girsanov 定理照亮，使我们能表达 $t = 0$ 处数据在学习模型下边缘似然 $p_\phi(\mathbf{x}_0)$ 的对数：

$$\log p_\phi(\mathbf{x}_0) = \log \int p_T(\mathbf{x}_T)\cdot \frac{p_\phi(\mathbf{x}_{0:T})}{p(\mathbf{x}_{0:T})}\, p(\mathbf{x}_{0:T})\, d\mathbf{x}_{0:T}. \tag{C.C.2.571}$$

这里 $p_T(\mathbf{x}_T)$ 是前向 SDE 给出的时刻 T 已知的噪声分布。项 $\frac{p_\phi(\mathbf{x}_{0:T})}{p(\mathbf{x}_{0:T})}$ 是对给定路径 $\mathbf{x}_{0:T}$ 学习到的反向过程与前向过程之间的密度比——一个恰由 Girsanov 定理量化的对象。本质上，该公式通过依据学习到的反向动力学解释观测路径轨迹的程度，对已知噪声似然重新加权，从而计算生成数据的似然。

我们进一步把它联系回方程 (C.C.2.570) 中的 KL 最小化，后者关注完整前向路径分布与学习到的反向路径分布之间的差异。二者（方程 (C.C.2.570) 与方程 (C.C.2.571)）深层交织：优化这一分数匹配目标（训练损失）直接转化为学习 Girsanov 密度比，从而隐式地最大化数据似然 $p_\phi(\mathbf{x}_0)$。这一优雅联系把 Girsanov 定理、基于分数的学习，以及生成建模给真实数据赋高概率的最终目标，漂亮地编织在一起。

Appendix D

补充材料与证明

D.1 变分视角

D.1.1 定理 2.2.1：边缘 KL 最小化与条件 KL 最小化的等价性

证明： 方程 *(2.2.3)* 的推导。我们先展开右端期望：

$$E_{p(\mathbf{x}_0,\mathbf{x}_i)}\Big[D_{\mathrm{KL}}\big(p(\mathbf{x}_{i-1}\mid\mathbf{x}_i,\mathbf{x}_0)\,\|\,p_\phi(\mathbf{x}_{i-1}\mid\mathbf{x}_i)\big)\Big]=\iint p(\mathbf{x}_0,\mathbf{x}_i)\,D_{\mathrm{KL}}\big(p(\mathbf{x}_{i-1}\mid\mathbf{x}_i,\mathbf{x}_0)\,\|\,p_\phi(\mathbf{x}_{i-1}\mid\mathbf{x}_i)\big)\,d\mathbf{x}_0\,d\mathbf{x}$$

由 KL 散度定义，$D_{\mathrm{KL}}\big(p(\mathbf{x}_{i-1}\mid\mathbf{x}_i,\mathbf{x}_0)\,\|\,p_\phi(\mathbf{x}_{i-1}\mid\mathbf{x}_i)\big)=\int p(\mathbf{x}_{i-1}\mid\mathbf{x}_i,\mathbf{x}_0)\log\frac{p(\mathbf{x}_{i-1}|\mathbf{x}_i,\mathbf{x}_0)}{p_\phi(\mathbf{x}_{i-1}|\mathbf{x}_i)}\,d\mathbf{x}_{i-1}$。代入期望，得 $\iiint p(\mathbf{x}_0,\mathbf{x}_i)p(\mathbf{x}_{i-1}\mid\mathbf{x}_i,\mathbf{x}_0)\log\frac{p(\mathbf{x}_{i-1}|\mathbf{x}_i,\mathbf{x}_0)}{p_\phi(\mathbf{x}_{i-1}|\mathbf{x}_i)}\,d\mathbf{x}_{i-1}\,d\mathbf{x}_0\,d\mathbf{x}_i$。用概率链式法则 $p(\mathbf{x}_0,\mathbf{x}_i)=p(\mathbf{x}_i)p(\mathbf{x}_0\mid\mathbf{x}_i)$，改写为 $\int p(\mathbf{x}_i)\int p(\mathbf{x}_0\mid\mathbf{x}_i)\int p(\mathbf{x}_{i-1}\mid\mathbf{x}_i,\mathbf{x}_0)\log\frac{p(\mathbf{x}_{i-1}|\mathbf{x}_i,\mathbf{x}_0)}{p_\phi(\mathbf{x}_{i-1}|\mathbf{x}_i)}\,d\mathbf{x}_{i-1}\,d\mathbf{x}_0\,d\mathbf{x}_i$。

这使我们能把期望表为嵌套形式。接下来应用对数分解：$\log\frac{p(\mathbf{x}_{i-1}|\mathbf{x}_i,\mathbf{x}_0)}{p_\phi(\mathbf{x}_{i-1}|\mathbf{x}_i)}=\log\frac{p(\mathbf{x}_{i-1}|\mathbf{x}_i,\mathbf{x}_0)}{p(\mathbf{x}_{i-1}|\mathbf{x}_i)}+\log\frac{p(\mathbf{x}_{i-1}|\mathbf{x}_i)}{p_\phi(\mathbf{x}_{i-1}|\mathbf{x}_i)}$。代回期望得到两项。由于第二个对数项不依赖 $\mathbf{x}_0$，由全概率律，它对 $\mathbf{x}_0$ 的期望退化为 $E_{p(\mathbf{x}_{i-1}|\mathbf{x}_i)}\big[\log\frac{p(\mathbf{x}_{i-1}|\mathbf{x}_i)}{p_\phi(\mathbf{x}_{i-1}|\mathbf{x}_i)}\big]$。类似地，第一项是 KL 散度 $E_{p(\mathbf{x}_0|\mathbf{x}_i)}\big[D_{\mathrm{KL}}\big(p(\mathbf{x}_{i-1}\mid\mathbf{x}_i,\mathbf{x}_0)\,\|\,p(\mathbf{x}_{i-1}\mid\mathbf{x}_i)\big)\big]$。

合并一切，得分解：

$$E_{p(\mathbf{x}_0,\mathbf{x}_i)}\big[D_{\mathrm{KL}}(p(\mathbf{x}_{i-1}\mid\mathbf{x}_i,\mathbf{x}_0)\|p_\phi(\mathbf{x}_{i-1}\mid\mathbf{x}_i))\big]=E_{p(\mathbf{x}_i)}\Big[E_{p(\mathbf{x}_0|\mathbf{x}_i)}\big[D_{\mathrm{KL}}(p(\mathbf{x}_{i-1}\mid\mathbf{x}_i,\mathbf{x}_0)\|p(\mathbf{x}_{i-1}\mid\mathbf{x}_i))\big]\Big]+E_{p(\mathbf{x}$$

最优性的证明。要证：$p^*(\mathbf{x}_{i-1}\mid\mathbf{x}_i)=p(\mathbf{x}_{i-1}\mid\mathbf{x}_i)=E_{p(\mathbf{x}|\mathbf{x}_i)}[p(\mathbf{x}_{i-1}\mid\mathbf{x}_i,\mathbf{x})]$，$\mathbf{x}_i\sim p_i$。第一个恒等式来自：在参数化足够表达力的假设下，KL 散度 $D_{\mathrm{KL}}(p\|p_\phi)$ 在 $p^*=p$ 时最小。第二个恒等式直接由全概率律得到。 □

D.1.2 定理 2.2.3：扩散模型的 ELBO

证明： 为记号简洁，记 $\mathbf{x}_{0:L}:=(\mathbf{x}_0,\mathbf{x}_1,\dots,\mathbf{x}_L)$。

第 *1* 步：应用 *Jensen* 不等式。边缘对数似然为：$\log p_\phi(\mathbf{x})=\log\int p_\phi(\mathbf{x},\mathbf{x}_{0:L})\,d\mathbf{x}_0\cdots d\mathbf{x}_L$，其联合分布为 $p_\phi(\mathbf{x},\mathbf{x}_{0:L})=p_{\text{prior}}(\mathbf{x}_L)\prod_{i=1}^{L}p_\phi(\mathbf{x}_{i-1}\mid\mathbf{x}_i)\cdot p_\phi(\mathbf{x}\mid\mathbf{x}_0)$。引入变分分布 $p(\mathbf{x}_{0:L}\mid\mathbf{x})$，改写：$\log p_\phi(\mathbf{x})=\log\int\frac{p(\mathbf{x}_{0:L}|\mathbf{x})\,p_\phi(\mathbf{x},\mathbf{x}_{0:L})}{p(\mathbf{x}_{0:L}|\mathbf{x})}\,d\mathbf{x}_0\cdots d\mathbf{x}_L$。应用 Jensen 不等式 $(\log E[Z]\ge E[\log Z])$，得 ELBO：$\log p_\phi(\mathbf{x})\ge E_{p(\mathbf{x}_{0:L}|\mathbf{x})}\big[\log\frac{p_\phi(\mathbf{x},\mathbf{x}_{0:L})}{p(\mathbf{x}_{0:L}|\mathbf{x})}\big]=:\mathcal{L}_{\mathrm{ELBO}}$，因而 $-\log p_\phi(\mathbf{x})\le-\mathcal{L}_{\mathrm{ELBO}}$。

第 *2* 步：展开 *ELBO*。假设变分分布分解为：$p(\mathbf{x}_{0:L}\mid\mathbf{x})=p(\mathbf{x}_L\mid\mathbf{x})\prod_{i=1}^{L}p(\mathbf{x}_{i-1}\mid$

$\mathbf{x}_i, \mathbf{x})$。把联合与变分分布代入 ELBO：

$$\mathcal{L}_{\text{ELBO}} = E_{p(\mathbf{x}_{0:L}|\mathbf{x})}\Big[\log p_{\text{prior}}(\mathbf{x}_L) + \sum_{i=1}^{L} \log p_\phi(\mathbf{x}_{i-1} \mid \mathbf{x}_i) + \log p_\phi(\mathbf{x} \mid \mathbf{x}_0) - \log p(\mathbf{x}_L \mid \mathbf{x}) - \sum_{i=1}^{L} \log p(\mathbf{x}_{i-1} \mid \mathbf{x}_i, \mathbf{x})\Big].$$

按各项依赖关系分组并边缘化，计算负 ELBO：

$$-\mathcal{L}_{\text{ELBO}} = E_{p(\mathbf{x}_0|\mathbf{x})}[-\log p_\phi(\mathbf{x} \mid \mathbf{x}_0)] + E_{p(\mathbf{x}_L|\mathbf{x})}\left[\log \frac{p(\mathbf{x}_L \mid \mathbf{x})}{p_{\text{prior}}(\mathbf{x}_L)}\right] + \sum_{i=1}^{L} E_{p(\mathbf{x}_i|\mathbf{x})}\left(E_{p(\mathbf{x}_{i-1}|\mathbf{x}_i,\mathbf{x})}\left[\log \frac{p(\mathbf{x}_{i-1} \mid \mathbf{x}_i, \mathbf{x})}{p_\phi(\mathbf{x}_{i-1} \mid \mathbf{x}_i)}\right]\right).$$

为证明最后一项，使用分解 $p(\mathbf{x}_i, \mathbf{x}_{i-1} \mid \mathbf{x}) = p(\mathbf{x}_i \mid \mathbf{x}) \cdot p(\mathbf{x}_{i-1} \mid \mathbf{x}_i, \mathbf{x})$。

可把 $-\mathcal{L}_{\text{ELBO}}$ 中三项记作 $\mathcal{L}_{\text{recon.}}$、$\mathcal{L}_{\text{prior}}$、$\mathcal{L}_{\text{diffusion}}$，分别对应重建损失、先验 KL 与逐步扩散 KL。推导至此完成。 □

D.2 分数视角

D.2.1 命题 3.2.1：经分部积分的可处理分数匹配

证明： 展开 $\mathcal{L}_{\text{SM}}(\phi)$。展开期望内的平方差：

$$\begin{aligned}\mathcal{L}_{\text{SM}}(\phi) &= \frac{1}{2} E_{\mathbf{x}\sim p_{\text{data}}(\mathbf{x})}\left[\|s_\phi(\mathbf{x})\|_2^2 - 2\langle s_\phi(\mathbf{x}), s(\mathbf{x})\rangle + \|s(\mathbf{x})\|_2^2\right] \\ &= \frac{1}{2} E_{\mathbf{x}\sim p_{\text{data}}}\|s_\phi(\mathbf{x})\|_2^2 - E_{\mathbf{x}\sim p_{\text{data}}}\langle s_\phi(\mathbf{x}), s(\mathbf{x})\rangle + \frac{1}{2} E_{\mathbf{x}\sim p_{\text{data}}}\|s(\mathbf{x})\|_2^2.\end{aligned}$$

聚焦交叉项 $E_{\mathbf{x}\sim p_{\text{data}}}\langle s_\phi(\mathbf{x}), s(\mathbf{x})\rangle$。利用 $\nabla_{\mathbf{x}} \log p_{\text{data}}(\mathbf{x}) = \frac{\nabla_{\mathbf{x}} p_{\text{data}}(\mathbf{x})}{p_{\text{data}}(\mathbf{x})}$，并假设 $p_{\text{data}}(\mathbf{x})$ 非零（如在其支撑上），交叉项变为：

$$\begin{aligned}E_{\mathbf{x}\sim p_{\text{data}}}\langle s_\phi(\mathbf{x}), s(\mathbf{x})\rangle &= \int s_\phi(\mathbf{x})^\top \nabla_{\mathbf{x}} \log p_{\text{data}}(\mathbf{x})\, p_{\text{data}}(\mathbf{x})\, d\mathbf{x} \\ &= \int s_\phi(\mathbf{x})^\top \nabla_{\mathbf{x}} p_{\text{data}}(\mathbf{x})\, d\mathbf{x} = \sum_{i=1}^{D} \int s_\phi^{(i)}(\mathbf{x})\, \partial_{x_i} p_{\text{data}}(\mathbf{x})\, d\mathbf{x},\end{aligned}$$

其中 $s_\phi^{(i)}(\mathbf{x})$ 是分数函数 $s_\phi = (s_\phi^{(1)}, \ldots, s_\phi^{(D)})$ 的第 i 个分量。

分部积分。使用如下分部积分公式（Evans, 2010），它由标准微积分导出：

引理 D.2.1： 设 u, v 为半径 $R > 0$ 的球 $B(\mathbf{0}, R) \subset \mathbb{R}^D$ 上可微的实值函数。则对 $i = 1, \ldots, D$，成立

$$\int_{B(\mathbf{0},R)} u\, \partial_{x_i} v\, dx = -\int_{B(\mathbf{0},R)} v\, \partial_{x_i} u\, dx + \int_{\partial B(\mathbf{0},R)} uv\, \nu_i\, dS,$$

其中 $\boldsymbol{\nu} = (\nu_1, \ldots, \nu_D)$ 是边界 $\partial B(\mathbf{0}, R)$（半径 R 的球面）的外单位法向，dS 为 $\partial B(\mathbf{0}, R)$ 上的曲面测度。

对所有 $i=1,\dots,D$，取 $u(\mathbf{x}):=s_\phi^{(i)}(\mathbf{x})$、$v(\mathbf{x})=p_{\text{data}}(\mathbf{x})$，假设 $|u(\mathbf{x})v(\mathbf{x})|\to 0$（当 $R\to\infty$）。对所有 i 求和，得：$E_{\mathbf{x}\sim p_{\text{data}}}\langle s_\phi(\mathbf{x}),s(\mathbf{x})\rangle=-\sum_{i=1}^{D}\int \partial_{x_i}s_\phi^{(i)}(\mathbf{x})\,p_{\text{data}}(\mathbf{x})\,d\mathbf{x}=-E_{\mathbf{x}\sim p_{\text{data}}}[\mathrm{Tr}(\nabla_{\mathbf{x}}s_\phi(\mathbf{x}))]$。

合并所有结果：

$$\mathcal{L}_{\text{SM}}(\phi)=\underbrace{E_{\mathbf{x}\sim p_{\text{data}}}\Big[\mathrm{Tr}(\nabla_{\mathbf{x}}s_\phi(\mathbf{x}))+\frac{1}{2}\|s_\phi(\mathbf{x})\|_2^2\Big]}_{\tilde{\mathcal{L}}_{\text{SM}}(\phi)}+\underbrace{\frac{1}{2}E_{\mathbf{x}\sim p_{\text{data}}}\|s(\mathbf{x})\|_2^2}_{=:C},$$

其中 C 只依赖分布 p_{data}。证明完毕。 □

D.2.2 定理 3.3.1：SM 与 DSM 最小化的等价性

证明： 展开 $\mathcal{L}_{\text{SM}}(\phi;\sigma)$ 与 $\mathcal{L}_{\text{DSM}}(\phi;\sigma)$：

$$\mathcal{L}_{\text{SM}}(\phi;\sigma)=\frac{1}{2}E_{\tilde{\mathbf{x}}\sim p_\sigma(\tilde{\mathbf{x}})}\big[\|s_\phi(\tilde{\mathbf{x}};\sigma)\|_2^2-2s_\phi(\tilde{\mathbf{x}};\sigma)^\top\nabla_{\tilde{\mathbf{x}}}\log p_\sigma(\tilde{\mathbf{x}})+\|\nabla_{\tilde{\mathbf{x}}}\log p_\sigma(\tilde{\mathbf{x}})\|_2^2\big],$$
$$\mathcal{L}_{\text{DSM}}(\phi;\sigma)=\frac{1}{2}E_{p_{\text{data}}(\mathbf{x})p_\sigma(\tilde{\mathbf{x}}|\mathbf{x})}\big[\|s_\phi(\tilde{\mathbf{x}};\sigma)\|_2^2-2s_\phi(\tilde{\mathbf{x}};\sigma)^\top\nabla_{\tilde{\mathbf{x}}}\log p_\sigma(\tilde{\mathbf{x}}\mid\mathbf{x})+\|\nabla_{\tilde{\mathbf{x}}}\log p_\sigma(\tilde{\mathbf{x}}\mid\mathbf{x})\|_2^2\big].$$

两式相减得 $\mathcal{L}_{\text{SM}}(\phi;\sigma)-\mathcal{L}_{\text{DSM}}(\phi;\sigma)$ 由三项组成，逐项处理。对第一项，因 $p_\sigma(\tilde{\mathbf{x}})=\int p_\sigma(\tilde{\mathbf{x}}\mid\mathbf{x})p_{\text{data}}(\mathbf{x})\,d\mathbf{x}$，可改写为 $E_{\tilde{\mathbf{x}}\sim p_\sigma}\|s_\phi(\tilde{\mathbf{x}};\sigma)\|_2^2=\iint p_\sigma(\tilde{\mathbf{x}}\mid\mathbf{x})p_{\text{data}}(\mathbf{x})\,dx\,\|s_\phi(\tilde{\mathbf{x}};\sigma)\|_2^2\,d\tilde{\mathbf{x}}=E_{p_{\text{data}}(\mathbf{x})p_\sigma(\tilde{\mathbf{x}}|\mathbf{x})}\|s_\phi(\tilde{\mathbf{x}};\sigma)\|_2^2$。故第一项为零。

对第二项：

$$\begin{aligned}
E_{\tilde{\mathbf{x}}\sim p_\sigma}\big[s_\phi(\tilde{\mathbf{x}};\sigma)^\top\nabla_{\tilde{\mathbf{x}}}\log p_\sigma(\tilde{\mathbf{x}})\big]&=\int p_\sigma(\tilde{\mathbf{x}})\,s_\phi(\tilde{\mathbf{x}};\sigma)^\top\frac{\nabla_{\tilde{\mathbf{x}}}p_\sigma(\tilde{\mathbf{x}})}{p_\sigma(\tilde{\mathbf{x}})}\,d\tilde{\mathbf{x}}\\
&=\int s_\phi(\tilde{\mathbf{x}};\sigma)^\top\nabla_{\tilde{\mathbf{x}}}\Big(\int p_\sigma(\tilde{\mathbf{x}}\mid\mathbf{x})p_{\text{data}}(\mathbf{x})\,dx\Big)d\tilde{\mathbf{x}}\\
&=\iint s_\phi(\tilde{\mathbf{x}};\sigma)^\top\nabla_{\tilde{\mathbf{x}}}p_\sigma(\tilde{\mathbf{x}}\mid\mathbf{x})p_{\text{data}}(\mathbf{x})\,d\tilde{\mathbf{x}}\,dx\\
&=E_{p_{\text{data}}(\mathbf{x})p_\sigma(\tilde{\mathbf{x}}|\mathbf{x})}\big[s_\phi(\tilde{\mathbf{x}};\sigma)^\top\nabla_{\tilde{\mathbf{x}}}\log p_\sigma(\tilde{\mathbf{x}}\mid\mathbf{x})\big].
\end{aligned}$$

故它也为零。对第三项，注意 $C:=\frac{1}{2}\big(E_{\tilde{\mathbf{x}}\sim p_\sigma}\|\nabla_{\tilde{\mathbf{x}}}\log p_\sigma(\tilde{\mathbf{x}})\|_2^2-E_{p_{\text{data}}p_\sigma(\cdot|\cdot)}\|\nabla_{\tilde{\mathbf{x}}}\log p_\sigma(\tilde{\mathbf{x}}\mid\mathbf{x})\|_2^2\big)$ 只依赖 $p_{\text{data}}(\mathbf{x})$ 与 $p_\sigma(\tilde{\mathbf{x}}\mid\mathbf{x})$，故关于 ϕ 为常数。 □

D.2.3 引理 3.3.2：Tweedie 公式

我们先陈述 Tweedie 公式的更一般形式，它考虑含时 Gauss 扰动，并在下面给出证明。

含时参数的 Tweedie 恒等式。设 $\mathbf{x}_t\sim\mathcal{N}(\cdot;\alpha_t\mathbf{x}_0,\sigma_t^2\mathbf{I})$ 为 Gauss 随机向量。则 Tweedie 公式断言 $\alpha_tE_{\mathbf{x}_0\sim p(\mathbf{x}_0|\mathbf{t})}[\mathbf{x}_0\mid\mathbf{x}_t]=\mathbf{x}_t+\sigma_t^2\nabla_{\mathbf{x}_t}\log p_t(\mathbf{x}_t)$，其中期望取自给定观测 $\mathbf{x}_t$ 时 $\mathbf{x}_0$ 的后验分布 $p(\mathbf{x}_0\mid\mathbf{x}_t)$，$p_t(\mathbf{x}_t)$ 是 $\mathbf{x}_t$ 的边缘密度。

证明： 边缘密度及其分数。回忆 $\mathbf{x}_t$ 的边缘密度为 $p_t(\mathbf{x}_t)=\int p_t(\mathbf{x}_t\mid\mathbf{x}_0)p_0(\mathbf{x}_0)\,d\mathbf{x}_0$。计算分数函数：$\nabla_{\mathbf{x}_t}\log p_t(\mathbf{x}_t)=\frac{\nabla_{\mathbf{x}_t}p_t(\mathbf{x}_t)}{p_t(\mathbf{x}_t)}=\frac{1}{p_t(\mathbf{x}_t)}\int\nabla_{\mathbf{x}_t}p_t(\mathbf{x}_t\mid\mathbf{x}_0)p_0(\mathbf{x}_0)\,d\mathbf{x}_0$。故需计算条件密度的梯度。

条件密度的梯度与重排。条件 Gauss 密度的梯度为 $\nabla_{\mathbf{x}_t} p_t(\mathbf{x}_t \mid \mathbf{x}_0) = -p_t(\mathbf{x}_t \mid \mathbf{x}_0) \cdot \sigma_t^{-2}(\mathbf{x}_t - \alpha_t \mathbf{x}_0)$。代入前式：

$$\begin{aligned}\nabla_{\mathbf{x}_t} p_t(\mathbf{x}_t) &= \int \nabla_{\mathbf{x}_t} p_t(\mathbf{x}_t \mid \mathbf{x}_0) p_0(\mathbf{x}_0)\, d\mathbf{x}_0 = -\sigma_t^{-2} \int (\mathbf{x}_t - \alpha_t \mathbf{x}_0) p_t(\mathbf{x}_t \mid \mathbf{x}_0) p_0(\mathbf{x}_0)\, d\mathbf{x}_0 \\ &= -\sigma_t^{-2} \int (\mathbf{x}_t - \alpha_t \mathbf{x}_0) p(\mathbf{x}_0 \mid \mathbf{x}_t) p_t(\mathbf{x}_t)\, d\mathbf{x}_0 = -p_t(\mathbf{x}_t)\sigma_t^{-2}\big(\mathbf{x}_t - \alpha_t E_{p(\mathbf{x}_0|\mathbf{x}_t)}[\mathbf{x}_0 \mid \mathbf{x}_t]\big).\end{aligned}$$

两边除以 $p_t(\mathbf{x}_t)$，得 $\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t) = -\sigma_t^{-2}\big(\mathbf{x}_t - \alpha_t E_{p(\mathbf{x}_0|\mathbf{x}_t)}[\mathbf{x}_0 \mid \mathbf{x}_t]\big)$。重排得 $\mathbf{x}_t + \sigma_t^2 \nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t) = \alpha_t E_{p(\mathbf{x}_0|\mathbf{x}_t)}[\mathbf{x}_0 \mid \mathbf{x}_t]$。推导完毕。 □

D.2.4 Stein 恒等式与代理 SURE 目标

Stein 恒等式。Stein 恒等式是一种分部积分技巧，它把未知密度下的期望转化为可观函数及其导数的期望，从而约配分函数，使我们无需评估未知密度或配分函数即可获得无偏、可处理的目标与检验。我们从最简单的一维情形开始，再推广到证明 SURE 代理损失所需的形式。

一维标准正态情形。若 $z \sim \mathcal{N}(0,1)$ 且 f 有适当衰减，则 Stein 恒等式陈述：$E[f'(z)] = E[z\, f(z)]$。记 $\phi(z) := \frac{1}{\sqrt{2\pi}} e^{-z^2/2}$ 为一维标准正态密度。证明由分部积分给出，使用 $\phi'(z) = -z\phi(z)$ 连同消失的边界项。精确地，$E[f'(Z)] = \int_{-\infty}^{\infty} f'(z)\phi(z)\, dz$。分部积分（$u = f(z)$，$dv = \phi'(z)dz$）得 $\int f'(z)\phi(z)\, dz = [f(z)\phi(z)]_{-\infty}^{\infty} - \int f(z)\phi'(z)\, dz$。由于 $\phi'(z) = -z\phi(z)$ 且 $f(z)\phi(z) \to 0$（当 $|z| \to \infty$，衰减条件），边界项消失，故 $E[f'(z)] = \int f(z) z \phi(z)\, dz = E[z\, f(z)]$。推导完毕，证明了 Stein 恒等式的一维情形。

多维标准正态情形。若 $\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}_D)$ 且 $g : \mathbb{R}^D \to \mathbb{R}$，则 Stein 恒等式为 $E[\nabla g(\mathbf{z})] = E[\mathbf{z}\, g(\mathbf{z})]$。等价地，对 $\mathbf{u} : \mathbb{R}^D \to \mathbb{R}^D$，

$$E[\nabla_{\tilde{\mathbf{x}}} \cdot \mathbf{u}(\mathbf{z})] = E[\mathbf{z}^\top \mathbf{u}(\mathbf{z})]. \tag{D.D.2.572}$$

SURE 所需恒等式。取 $\tilde{\mathbf{x}} = \mathbf{x} + \sigma \mathbf{z}$，$\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}_D)$，对任一适当正则的向量函数 $\mathbf{a}$，

$$E\big[(\tilde{\mathbf{x}} - \mathbf{x})^\top \mathbf{a}(\tilde{\mathbf{x}}) \mid \mathbf{x}\big] = \sigma^2 E[\nabla_{\tilde{\mathbf{x}}} \cdot \mathbf{a}(\tilde{\mathbf{x}}) \mid \mathbf{x}]. \tag{D.D.2.573}$$

这由应用方程 (D.D.2.572) 并使用链式法则得到。

由条件 *MSE* 推导 *SURE*。设 $D : \mathbb{R}^D \to \mathbb{R}^D$ 为去噪器，定义 $R(D;\mathbf{x}) := E[\|D(\tilde{\mathbf{x}}) - \mathbf{x}\|_2^2 \mid \mathbf{x}]$。在 $\tilde{\mathbf{x}}$ 附近展开：

$$\begin{aligned}R(D;\mathbf{x}) &= E[\|D(\tilde{\mathbf{x}}) - \tilde{\mathbf{x}}\|_2^2 \mid \mathbf{x}] + 2E[(D(\tilde{\mathbf{x}}) - \tilde{\mathbf{x}})^\top (\tilde{\mathbf{x}} - \mathbf{x}) \mid \mathbf{x}] + E[\|\tilde{\mathbf{x}} - \mathbf{x}\|_2^2 \mid \mathbf{x}] \\ &= E[\|D(\tilde{\mathbf{x}}) - \tilde{\mathbf{x}}\|_2^2 \mid \mathbf{x}] + 2 \underbrace{E[(\tilde{\mathbf{x}} - \mathbf{x})^\top D(\tilde{\mathbf{x}}) \mid \mathbf{x}]}_{\sigma^2 E[\nabla_{\tilde{\mathbf{x}}} \cdot D(\tilde{\mathbf{x}}) \mid \mathbf{x}],\ \text{由方程 (D.D.2.573)}} - \underbrace{E[(\tilde{\mathbf{x}} - \mathbf{x})^\top \tilde{\mathbf{x}} \mid \mathbf{x}]}_{\sigma^2 D} + \underbrace{E[\|\tilde{\mathbf{x}} - \mathbf{x}\|_2^2 \mid \mathbf{x}]}_{\sigma^2 D} \\ &= E\big[\|D(\tilde{\mathbf{x}}) - \tilde{\mathbf{x}}\|_2^2 + 2\sigma^2 \nabla_{\tilde{\mathbf{x}}} \cdot D(\tilde{\mathbf{x}}) - D\sigma^2 \mid \mathbf{x}\big].\end{aligned}$$

因此可观测量 $\mathrm{SURE}(D;\tilde{\mathbf{x}}) := \|D(\tilde{\mathbf{x}}) - \tilde{\mathbf{x}}\|_2^2 + 2\sigma^2 \nabla_{\tilde{\mathbf{x}}} \cdot D(\tilde{\mathbf{x}}) - D\sigma^2$ 满足 $E[\mathrm{SURE}(D;\tilde{\mathbf{x}}) \mid \mathbf{x}] = R(D;\mathbf{x})$。故（在期望意义或经验地）最小化 SURE，等价于仅用含噪观测时最小化真实条件 MSE。

D.2.5 定理 4.1.1：经 Fokker–Planck 的边缘对齐

证明： 第 *1* 部分：前向 *SDE* 的 *Fokker–Planck* 方程。考虑前向 SDE $d\mathbf{x}(t) = \mathbf{f}(\mathbf{x}(t), t)\, dt + g(t)\, d\mathbf{w}(t)$。扩散矩阵为 $\sigma(t) = g(t)\mathbf{I}_D$，故 $\sigma(t)\sigma(t)^\top = g^2(t)\mathbf{I}_D$。$\mathbf{x}(t)$ 边缘密度 $p_t(\mathbf{x})$ 的 Fokker–Planck 方程为：

$$\partial_t p_t(\mathbf{x}) = -\nabla_{\mathbf{x}} \cdot \big(\mathbf{f}(\mathbf{x}, t) p_t(\mathbf{x})\big) + \frac{1}{2} \sum_{i,j=1}^{D} \frac{\partial^2}{\partial x_i \partial x_j} \big(g^2(t)\delta_{ij}\big) p_t(\mathbf{x}).$$

计算扩散项：$\sum_{i,j=1}^{D} \frac{\partial^2}{\partial x_i \partial x_j}\big(g^2(t)\delta_{ij} p_t(\mathbf{x})\big) = \sum_{i=1}^{D} \frac{\partial^2}{\partial x_i^2}\big(g^2(t) p_t(\mathbf{x})\big) = g^2(t)\Delta_{\mathbf{x}} p_t(\mathbf{x})$。故 $\partial_t p_t(\mathbf{x}) = -\nabla_{\mathbf{x}} \cdot (\mathbf{f}(\mathbf{x}, t) p_t(\mathbf{x})) + \frac{1}{2} g^2(t) \Delta_{\mathbf{x}} p_t(\mathbf{x})$。

现用 $\tilde{\mathbf{f}}(\mathbf{x}, t) = \mathbf{f}(\mathbf{x}, t) - \frac{1}{2} g^2(t) \nabla_{\mathbf{x}} \log p_t(\mathbf{x})$ 改写。由于 $\nabla_{\mathbf{x}} \log p_t(\mathbf{x}) = \frac{\nabla_{\mathbf{x}} p_t(\mathbf{x})}{p_t(\mathbf{x})}$，计算 $\nabla_{\mathbf{x}} \cdot (\tilde{\mathbf{f}}(\mathbf{x}, t) p_t(\mathbf{x})) = \nabla_{\mathbf{x}} \cdot \Big(\mathbf{f}(\mathbf{x}, t) p_t(\mathbf{x}) - \frac{1}{2} g^2(t) \frac{\nabla_{\mathbf{x}} p_t(\mathbf{x})}{p_t(\mathbf{x})} p_t(\mathbf{x})\Big)$。第二项为 $\nabla_{\mathbf{x}} \cdot (-\frac{1}{2} g^2(t) \nabla_{\mathbf{x}} p_t(\mathbf{x})) = -\frac{1}{2} g^2(t) \Delta_{\mathbf{x}} p_t(\mathbf{x})$。故 $\nabla_{\mathbf{x}} \cdot (\tilde{\mathbf{f}} p_t) = \nabla_{\mathbf{x}} \cdot (\mathbf{f} p_t) - \frac{1}{2} g^2(t) \Delta_{\mathbf{x}} p_t$，从而 $\partial_t p_t(\mathbf{x}) = -\nabla_{\mathbf{x}} \cdot (\tilde{\mathbf{f}}(\mathbf{x}, t) p_t(\mathbf{x}))$，验证了两种形式的 Fokker–Planck 方程。

第 *2* 部分：*PF-ODE* 的边缘密度。考虑 PF-ODE：$\frac{d\tilde{\mathbf{x}}(t)}{dt} = \tilde{\mathbf{f}}(\tilde{\mathbf{x}}(t), t)$，$\tilde{\mathbf{f}}(\mathbf{x}, t) = \mathbf{f}(\mathbf{x}, t) - \frac{1}{2} g^2(t) \nabla_{\mathbf{x}} \log p_t(\mathbf{x})$。

正向：$\tilde{\mathbf{x}}(0) \sim p_0$。设 $\tilde{\mathbf{x}}(t)$ 遵循 PF-ODE、$\tilde{\mathbf{x}}(0) \sim p_0$。流映射 $\Psi_t : \mathbb{R}^D \to \mathbb{R}^D$ 定义为 $\frac{d}{dt}\Psi_t(\mathbf{x}_0) = \tilde{\mathbf{f}}(\Psi_t(\mathbf{x}_0), t)$，$\Psi_0(\mathbf{x}_0) = \mathbf{x}_0$。由于 $\tilde{\mathbf{x}}(t) = \Psi_t(\tilde{\mathbf{x}}(0))$，$\tilde{\mathbf{x}}(t)$ 的密度 $\tilde{p}_t(\mathbf{x})$ 满足连续性方程 $\partial_t \tilde{p}_t(\mathbf{x}) = -\nabla_{\mathbf{x}} \cdot (\tilde{\mathbf{f}}(\mathbf{x}, t) \tilde{p}_t(\mathbf{x}))$。因 $\tilde{\mathbf{x}}(0) \sim p_0$，有 $\tilde{p}_0(\mathbf{x}) = p_0(\mathbf{x})$。由第 1 部分，$p_t(\mathbf{x})$ 满足 $\partial_t p_t(\mathbf{x}) = -\nabla_{\mathbf{x}} \cdot (\tilde{\mathbf{f}}(\mathbf{x}, t) p_t(\mathbf{x}))$。$\tilde{p}_t$ 与 p_t 都满足同一连续性方程与同一初值 p_0。假设充分光滑（如 $\tilde{\mathbf{f}} \in C^1$），解在某适当函数空间中唯一，故 $\tilde{p}_t = p_t$。因而 $\tilde{\mathbf{x}}(t) \sim p_t$ 对所有 $t \in [0, T]$ 成立。

反向：$\tilde{\mathbf{x}}(T) \sim p_T$。现设 $\tilde{\mathbf{x}}(t)$ 从 $t = T$ 到 $t = 0$ 反向遵循 PF-ODE，$\tilde{\mathbf{x}}(T) \sim p_T$。令 $s = T - t$，反向 ODE 成为 $\frac{d}{ds}\tilde{\mathbf{x}}(T - s) = -\tilde{\mathbf{f}}(\tilde{\mathbf{x}}(T - s), T - s)$。$\tilde{\mathbf{x}}(T - s)$ 的密度 $\tilde{p}_{T-s}(\mathbf{x})$ 满足 $\partial_s \tilde{p}_{T-s}(\mathbf{x}) = \nabla_{\mathbf{x}} \cdot (\tilde{\mathbf{f}}(\mathbf{x}, T - s) \tilde{p}_{T-s}(\mathbf{x}))$。因 $\tilde{\mathbf{x}}(T) \sim p_T$，$\tilde{p}_T = p_T$。$p_t$ 在 $t = T - s$ 处的 Fokker–Planck 方程为 $\partial_t p_{T-s}(\mathbf{x}) = -\nabla_{\mathbf{x}} \cdot (\tilde{\mathbf{f}}(\mathbf{x}, T - s) p_{T-s}(\mathbf{x}))$。由于 $\partial_t = -\partial_s$，得 $\partial_s p_{T-s}(\mathbf{x}) = \nabla_{\mathbf{x}} \cdot (\tilde{\mathbf{f}}(\mathbf{x}, T - s) p_{T-s}(\mathbf{x}))$。$\tilde{p}_{T-s}$ 与 p_{T-s} 在 $s = 0$ 处满足同一 PDE 与同一初值（$\tilde{p}_T = p_T$）。唯一性蕴含 $\tilde{p}_{T-s} = p_{T-s}$，故 $\tilde{\mathbf{x}}(t) = \tilde{\mathbf{x}}(T - s) \sim p_{T-s} = p_t$，对所有 $t \in [0, T]$ 成立。

第 *3* 部分：反向时间 *SDE* 的边缘密度。考虑反向时间 SDE：$d\bar{\mathbf{x}}(t) = \big[\mathbf{f}(\bar{\mathbf{x}}(t), t) - g^2(t) \nabla_{\mathbf{x}} \log p_t(\bar{\mathbf{x}}(t))\big] dt + g(t)\, d\bar{\mathbf{w}}(t)$，$\bar{\mathbf{x}}(0) \sim p_T$，其中 $\bar{\mathbf{w}}(t)$ 是反向时间的标准 Wiener 过程，定义为 $\bar{\mathbf{w}}(t) = \mathbf{w}(T - t) - \mathbf{w}(T)$。需证 $\bar{\mathbf{x}}(t) \sim p_{T-t}$。

改写漂移：$\mathbf{f}(\mathbf{x}, t) = \tilde{\mathbf{f}}(\mathbf{x}, t) + \frac{1}{2} g^2(t) \nabla_{\mathbf{x}} \log p_t(\mathbf{x})$，故 $\mathbf{f}(\mathbf{x}, t) - g^2(t) \nabla_{\mathbf{x}} \log p_t(\mathbf{x}) = \tilde{\mathbf{f}}(\mathbf{x}, t) - \frac{1}{2} g^2(t) \nabla_{\mathbf{x}} \log p_t(\mathbf{x})$。反向时间 SDE 为 $d\bar{\mathbf{x}}(t) = \big[\tilde{\mathbf{f}}(\bar{\mathbf{x}}(t), t) - \frac{1}{2} g^2(t) \nabla_{\mathbf{x}} \log p_t(\bar{\mathbf{x}}(t))\big] dt + g(t)\, d\bar{\mathbf{w}}(t)$。

令 $s = T - t$，则 $\bar{\mathbf{x}}(t) = \bar{\mathbf{x}}(T - s)$，$dt = -ds$。SDE 成为 $d\bar{\mathbf{x}}(T - s) = \big[-\tilde{\mathbf{f}}(\bar{\mathbf{x}}(T - s), T - s) + \frac{1}{2} g^2(T - s) \nabla_{\mathbf{x}} \log p_{T-s}(\bar{\mathbf{x}}(T - s))\big] ds + g(T - s)\, d\bar{\mathbf{w}}(T - s)$。因 $\bar{\mathbf{w}}(t) = \mathbf{w}(T - t) - \mathbf{w}(T)$，有 $d\bar{\mathbf{w}}(T - s) = -dw(s)$，$\mathbf{w}(s)$ 为标准 Wiener 过程。令 $\bar{\mathbf{w}}'(s) = -\mathbf{w}(s)$（标准 Wiener 过程），则 $d\bar{\mathbf{x}}(s) = \big[\tilde{\mathbf{f}}(\bar{\mathbf{x}}(s), T - s) - \frac{1}{2} g^2(T - s) \nabla_{\mathbf{x}} \log p_{T-s}(\bar{\mathbf{x}}(s))\big] ds + g(T - s)\, d\bar{\mathbf{w}}'(s)$。

$\bar{\mathbf{x}}(s)$ 密度 $\bar{p}_s(\mathbf{x})$ 的 Fokker–Planck 方程为：

$$\partial_s \bar{p}_s(\mathbf{x}) = -\nabla_{\mathbf{x}} \cdot \Big(\big[\tilde{\mathbf{f}}(\mathbf{x}, T-s) - \frac{1}{2} g^2(T-s) \nabla_{\mathbf{x}} \log p_{T-s}(\mathbf{x})\big] \bar{p}_s(\mathbf{x}) \Big) + \frac{1}{2} g^2(T-s) \Delta_{\mathbf{x}} \bar{p}_s(\mathbf{x}).$$

设 $\bar{p}_s = p_{T-s}$。p_{T-s} 的 Fokker–Planck 方程为 $\partial_t p_{T-s}(\mathbf{x}) = -\nabla_{\mathbf{x}} \cdot (\tilde{\mathbf{f}}(\mathbf{x}, T-s) p_{T-s}(\mathbf{x}))$。由于 $\partial_t = -\partial_s$，$\partial_s p_{T-s}(\mathbf{x}) = \nabla_{\mathbf{x}} \cdot (\tilde{\mathbf{f}}(\mathbf{x}, T-s) p_{T-s}(\mathbf{x}))$。代入 $\bar{p}_s = p_{T-s}$：

$$\partial_s p_{T-s} = -\nabla_{\mathbf{x}} \cdot \Big(\tilde{\mathbf{f}}(\mathbf{x}, T-s) p_{T-s}(\mathbf{x}) - \frac{1}{2} g^2(T-s) \frac{\nabla_{\mathbf{x}} p_{T-s}(\mathbf{x})}{p_{T-s}(\mathbf{x})} p_{T-s}(\mathbf{x}) \Big) + \frac{1}{2} g^2(T-s) \Delta_{\mathbf{x}} p_{T-s}(\mathbf{x}).$$

额外项为 $-\nabla_{\mathbf{x}} \cdot (-\frac{1}{2} g^2(T-s) \nabla_{\mathbf{x}} p_{T-s}(\mathbf{x})) + \frac{1}{2} g^2(T-s) \Delta_{\mathbf{x}} p_{T-s}(\mathbf{x}) = \frac{1}{2} g^2(T-s) \Delta_{\mathbf{x}} p_{T-s}(\mathbf{x}) - \frac{1}{2} g^2(T-s) \Delta_{\mathbf{x}} p_{T-s}(\mathbf{x}) = 0$。故 $\bar{p}_s = p_{T-s}$ 满足 Fokker–Planck 方程。因 $\bar{\mathbf{x}}(0) \sim p_T$，$\bar{p}_0 = p_T$，匹配初值。唯一性（充分光滑下）保证 $\bar{p}_s = p_{T-s}$，故 $\bar{\mathbf{x}}(t) = \bar{\mathbf{x}}(T-s) \sim p_{T-t}$。 □

D.2.6 命题 4.2.1：SM 与 DSM 的最小化解

证明： 为找最小化解 s^*，先固定时间 t，分析目标函数中的内层期望：$\mathcal{J}(t, \phi) := E_{\mathbf{x}_0 \sim p_{\text{data}}} E_{\mathbf{x}_t \sim p_t(\cdot|\mathbf{x}_0)} \big[\| s_\phi(\mathbf{x}_t, t) - \nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t \mid \mathbf{x}_0) \|_2^2 \big]$。要使该期望最小，需对每个 $\mathbf{x}_t$ 找到最小化期望平方误差的 $s_\phi(\mathbf{x}_t, t)$。用 $\mathbf{X}_0$ 与 $\mathbf{X}_t$ 的联合分布改写：$\mathcal{J}(t, \phi) = \iint p_{\text{data}}(\mathbf{x}_0) p_t(\mathbf{x}_t \mid \mathbf{x}_0) \| s_\phi(\mathbf{x}_t, t) - \nabla_{\mathbf{x}_t} \log p(\mathbf{x}_t \mid \mathbf{x}_0) \|_2^2 \, d\mathbf{x}_0 \, d\mathbf{x}_t$。对每个固定 $\mathbf{x}_t$，需最小化 $\int p(\mathbf{x}_0 \mid \mathbf{X}_t = \mathbf{x}_t) p_t(\mathbf{x}_t) \| s_\phi(\mathbf{x}_t, t) - \nabla_{\mathbf{x}_t} \log p(\mathbf{x}_t \mid \mathbf{x}_0) \|_2^2 \, d\mathbf{x}_0$。由于 $p_t(\mathbf{x}_t)$ 关于 $s_\phi(\mathbf{x}_t, t)$ 为常数，这等价于最小化 $\int p(\mathbf{x}_0 \mid \mathbf{X}_t = \mathbf{x}_t) \| s_\phi(\mathbf{x}_t, t) - \nabla_{\mathbf{x}_t} \log p(\mathbf{x}_t \mid \mathbf{x}_0) \|_2^2 \, d\mathbf{x}_0$。当 $s_\phi(\mathbf{x}_t, t)$ 等于条件期望时取最小：$s^*(\mathbf{x}_t, t) = E_{\mathbf{x}_0 \sim p(\mathbf{x}_0 | \mathbf{X}_t = \mathbf{x}_t)} [\nabla_{\mathbf{x}_t} \log p(\mathbf{x}_t \mid \mathbf{X}_0)]$。

现需证它等于 $\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t)$。由 Bayes 规则与边缘概率定义：$p_t(\mathbf{x}_t) = \int p_t(\mathbf{x}_t \mid \mathbf{x}_0) p_{\text{data}}(\mathbf{x}_0) \, d\mathbf{x}_0$。取对数再对 $\mathbf{x}_t$ 求梯度：$\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t) = \frac{\nabla_{\mathbf{x}_t} p_t(\mathbf{x}_t)}{p_t(\mathbf{x}_t)} = \frac{\nabla_{\mathbf{x}_t} \int p_t(\mathbf{x}_t|\mathbf{x}_0) p_{\text{data}}(\mathbf{x}_0) \, d\mathbf{x}_0}{\int p_t(\mathbf{x}_t|\mathbf{x}_0) p_{\text{data}}(\mathbf{x}_0) \, d\mathbf{x}_0}$。在适当正则性条件下可交换梯度与积分：$\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t) = \frac{\int \nabla_{\mathbf{x}_t} p_t(\mathbf{x}_t|\mathbf{x}_0) p_{\text{data}}(\mathbf{x}_0) \, d\mathbf{x}_0}{\int p_t(\mathbf{x}_t|\mathbf{x}_0) p_{\text{data}}(\mathbf{x}_0) \, d\mathbf{x}_0}$。 □

D.2.7 Gauss 的闭式分数函数

供后续参考，我们把一般多元正态分布的分数公式总结为如下引理。

引理 D.2.2 (Gauss 的分数)**：** *设 $\mathbf{x} \in \mathbb{R}^D$，考虑多元正态分布 $p(\tilde{\mathbf{x}} \mid \mathbf{x}) := \mathcal{N}(\tilde{\mathbf{x}}; \boldsymbol{\mu}, \Sigma)$，其中 $\boldsymbol{\mu} \in \mathbb{R}^D$ 为均值，$\Sigma \in \mathbb{R}^{D \times D}$ 为可逆协方差矩阵。其分数函数为*

$$\nabla_{\tilde{\mathbf{x}}} \log p(\tilde{\mathbf{x}} \mid \mathbf{x}) = -\Sigma^{-1}(\tilde{\mathbf{x}} - \boldsymbol{\mu}). \tag{D.D.2.574}$$

证明（引理）： $p(\tilde{\mathbf{x}} \mid \mathbf{x})$ 的密度为 $p(\tilde{\mathbf{x}} \mid \mathbf{x}) = \frac{1}{(2\pi)^{D/2} |\Sigma|^{1/2}} \exp\big(-\frac{1}{2}(\tilde{\mathbf{x}} - \boldsymbol{\mu})^\top \Sigma^{-1} (\tilde{\mathbf{x}} - \boldsymbol{\mu})\big)$。为计算分数，先取对数：$\log p(\tilde{\mathbf{x}} \mid \mathbf{x}) = -\frac{D}{2} \log(2\pi) - \frac{1}{2} \log |\Sigma| - \frac{1}{2}(\tilde{\mathbf{x}} - \boldsymbol{\mu})^\top \Sigma^{-1} (\tilde{\mathbf{x}} - \boldsymbol{\mu})$。再对 $\tilde{\mathbf{x}}$ 求梯度：$\nabla_{\tilde{\mathbf{x}}} \log p(\tilde{\mathbf{x}} \mid \mathbf{x}) = -\frac{1}{2} \nabla_{\tilde{\mathbf{x}}} \big((\tilde{\mathbf{x}} - \boldsymbol{\mu})^\top \Sigma^{-1} (\tilde{\mathbf{x}} - \boldsymbol{\mu}) \big)$。由链式法则，$\nabla_{\tilde{\mathbf{x}}} \big((\tilde{\mathbf{x}} - \boldsymbol{\mu})^\top \Sigma^{-1} (\tilde{\mathbf{x}} - \boldsymbol{\mu}) \big) = 2\Sigma^{-1}(\tilde{\mathbf{x}} - \boldsymbol{\mu})$。故分数函数为

$$\nabla_{\tilde{\mathbf{x}}} \log p(\tilde{\mathbf{x}} \mid \mathbf{x}) = -\Sigma^{-1}(\tilde{\mathbf{x}} - \boldsymbol{\mu}). \tag{D.D.2.575}$$

□

D.3 流视角

D.3.1 引理 5.1.1：瞬时换元

证明： 方法 *1*: 换元公式。记 $p(\mathbf{x}(t),t)$ 为 $p_t(\mathbf{x}_t)$。从 ODE 离散化 $\mathbf{z}_{t+\Delta t}=\mathbf{z}_t+\Delta t\,\mathbf{F}(\mathbf{z}_t,t)$ 出发，归一化流的换元公式（方程 (5.1.1)）给出

$$\begin{aligned}\log p_{t+\Delta t}(\mathbf{z}_{t+\Delta t}) &= \log p_t(\mathbf{z}_t) - \log\det\big(\mathbf{I}+\Delta t\,\nabla_{\mathbf{z}}\mathbf{F}(\mathbf{z}_t,t)\big)\\ &= \log p_t(\mathbf{z}_t) - \operatorname{Tr}\log\big(\mathbf{I}+\Delta t\,\nabla_{\mathbf{z}}\mathbf{F}(\mathbf{z}_t,t)\big)\\ &= \log p_t(\mathbf{z}_t) - \Delta t\operatorname{Tr}\big(\nabla_{\mathbf{z}}\mathbf{F}(\mathbf{z}_t,t)\big)+O(\Delta t^2),\end{aligned}$$

其中用到 $\log\det=\operatorname{Tr}\log$ 及小 Δt 的展开。取 $\Delta t\to 0$ 极限，即得对数密度的连续时间微分方程。事实上，方程 (5.1.6) 也用了同一技巧。

方法 *2*: 连续性方程。我们也可利用连续性方程，它本质上充当换元公式：$\partial_t p(\mathbf{z},t)=-\nabla_{\mathbf{z}}\cdot(\mathbf{F}(\mathbf{z},t)p(\mathbf{z},t))$。展开散度：$\partial_t p=-(\nabla_{\mathbf{z}}\cdot\mathbf{F})p+\mathbf{F}\cdot\nabla_{\mathbf{z}}p$。沿满足 $\frac{d\mathbf{z}}{dt}=\mathbf{F}(\mathbf{z}(t),t)$ 的轨迹 $\mathbf{z}(t)$，全时间导数为

$$\frac{d}{dt}p(\mathbf{z}(t),t)=\nabla_{\mathbf{z}}p\cdot\frac{d\mathbf{z}}{dt}+\partial_t p=\nabla_{\mathbf{z}}p\cdot\mathbf{F}-\big((\nabla_{\mathbf{z}}\cdot\mathbf{F})p+\mathbf{F}\cdot\nabla_{\mathbf{z}}p\big)=-(\nabla_{\mathbf{z}}\cdot\mathbf{F})p.$$

除以 $p(\mathbf{z}(t),t)$，得 $\frac{d}{dt}\log p(\mathbf{z}(t),t)=-\nabla_{\mathbf{z}}\cdot\mathbf{F}(\mathbf{z}(t),t)$。 □

D.3.2 定理 5.2.2：质量守恒准则

若干预备知识：流映射与流诱导密度。对任一初始位置 $\mathbf{x}_0\in\mathbb{R}^D$，流映射 $\Psi_t:\mathbb{R}^D\to\mathbb{R}^D$ 是 ODE $\frac{d}{dt}\Psi_t(\mathbf{x}_0)=v_t(\Psi_t(\mathbf{x}_0))$、$\Psi_0(\mathbf{x}_0)=\mathbf{x}_0$ 的唯一解。在我们的正则性假设下，Ψ_t 关于 t 与 $\mathbf{x}_0$ 都连续可微。流诱导密度 p_t^{fwd} 是初始密度 p_0 经 Ψ_t 的推前：$p_t^{\mathrm{fwd}}(\mathbf{x})=p_0(\Psi_t^{-1}(\mathbf{x}))\,\det(\nabla\Psi_t^{-1}(\mathbf{x}))$。这给出从 $p_0=p_{\mathrm{data}}$ 出发、在速度场 v_t 下演化的粒子在时刻 t 位于 $\mathbf{x}$ 处的密度。

证明（非正式）： 充分条件：$p_t^{\mathrm{fwd}}=p_t\Rightarrow$ 连续性方程。在第 B.1.2 节中，我们通过取离散换元公式的连续时间极限得到连续性方程的强解。在那一方法中，假设密度 p_t 足够光滑、所有导数经典存在、PDE 逐点成立。这里我们在弱意义下给出补充推导：连续性方程仅在对任意光滑检验函数积分后施加，这放宽了对 p_t 与速度场 v_t 的正则性要求。这一弱形式不仅更严格（因容纳较少正则的解），也是 PDE 理论与数值分析中的标准框架。

对任一具有紧支撑的光滑检验函数 $\phi(\mathbf{x})$，推前性质给出：

$$\begin{aligned}\int p_t^{\mathrm{fwd}}(\mathbf{x})\phi(\mathbf{x})\,d\mathbf{x} &= \int p_0(\Psi_t^{-1}(\mathbf{x}))\,\det(\nabla\Psi_t^{-1}(\mathbf{x}))\,\phi(\mathbf{x})\,d\mathbf{x}\\ &= \int p_0(\mathbf{y})\phi(\Psi_t(\mathbf{y}))\,d\mathbf{y},\end{aligned}$$

其中第二个等号由换元 $\mathbf{x}=\Psi_t(\mathbf{y})$、$dy=\det(\nabla\Psi_t^{-1}(\mathbf{x}))dx$ 得到。

两边对 t 求导：$\frac{d}{dt}\int p_t^{\mathrm{fwd}}(\mathbf{x})\phi(\mathbf{x})\,dx=\frac{d}{dt}\int p_0(\mathbf{y})\phi(\Psi_t(\mathbf{y}))\,dy$。左边为 $\int\frac{\partial p_t^{\mathrm{fwd}}}{\partial t}(\mathbf{x})\phi(\mathbf{x})\,dx$。右边为 $\int p_0(\mathbf{y})\nabla\phi(\Psi_t(\mathbf{y}))\cdot v_t(\Psi_t(\mathbf{y}))\,dy$，因 $\frac{\partial\Psi_t}{\partial t}(\mathbf{y})=v_t(\Psi_t(\mathbf{y}))$。换元为 $\mathbf{x}=\Psi_t(\mathbf{y})$，

$dy = \det(\nabla\Psi_t^{-1}(\mathbf{x}))dx$，$p_0(\mathbf{y}) = \frac{p_t^{\text{fwd}}(\mathbf{x})}{\det(\nabla\Psi_t^{-1}(\mathbf{x}))}$。故右边成为 $\int p_t^{\text{fwd}}(\mathbf{x})\nabla\phi(\mathbf{x})\cdot v_t(\mathbf{x})\,dx$。利用 ϕ 的紧支撑分部积分：$\int p_t^{\text{fwd}}(\mathbf{x})\nabla\phi(\mathbf{x})\cdot v_t(\mathbf{x})\,dx = -\int \phi(\mathbf{x})\nabla\cdot(p_t^{\text{fwd}}(\mathbf{x})v_t(\mathbf{x}))\,dx$。两边相等：$\int\big[\frac{\partial p_t^{\text{fwd}}}{\partial t}(\mathbf{x}) + \nabla\cdot(p_t^{\text{fwd}}(\mathbf{x})v_t(\mathbf{x}))\big]\phi(\mathbf{x})\,dx = 0$。由于 ϕ 任意，得 $\frac{\partial p_t^{\text{fwd}}}{\partial t} + \nabla\cdot(p_t^{\text{fwd}}v_t) = 0$。给定 $p_t^{\text{fwd}} = p_t$，蕴含 $\frac{\partial p_t}{\partial t} + \nabla\cdot(p_t v_t) = 0$。

必要条件：连续性方程 $\Rightarrow p_t^{\text{fwd}} = p_t$。设 p_t 满足连续性方程 $\frac{\partial p_t}{\partial t} + \nabla\cdot(p_t v_t) = 0$，初值 $p_0(\mathbf{x}) = p_{\text{data}}(\mathbf{x})$。如前所述，$p_t^{\text{fwd}}$ 满足同一连续性方程，且 $p_0^{\text{fwd}}(\mathbf{x}) = p_0(\Psi_0^{-1}(\mathbf{x}))\det(\nabla\Psi_0^{-1}(\mathbf{x})) = p_0(\mathbf{x})$，因 $\Psi_0(\mathbf{x}) = \mathbf{x}$。故两密度共享同一初值 $p_0 = p_{\text{data}}$。

连续性方程可改写为 $\frac{\partial p}{\partial t} + v_t\cdot\nabla p + p\nabla\cdot v_t = 0$。这是一阶线性 PDE。假设 v_t 连续可微且全局 Lipschitz，p_t 充分光滑，特征线法保证光滑函数空间中解唯一。由于 p_t 与 p_t^{fwd} 满足同一 PDE 与同一初值，得 $p_t(\mathbf{x}) = p_t^{\text{fwd}}(\mathbf{x})$ 对所有 $t\in[0,1]$、$\mathbf{x}\in\mathbb{R}^D$ 成立。等价性证明完毕。 □

D.4 理论补充：扩散模型的统一系统视角

D.4.1 命题 6.3.1：参数化的等价性

证明： 与 DSM 损失上的定理 4.2.1 一样，匹配损失 $E_t\big[\omega(t)\,E_{\mathbf{x}_0,\boldsymbol{\epsilon}}[\|\cdot\|_2^2]\big]$ 的全局最优，在每个固定 t 的内层期望 $E_{\mathbf{x}_0,\boldsymbol{\epsilon}}[\|\cdot\|_2^2]$ 被最小化时达到。由于这是标准均方误差问题，最小化解唯一。由去噪分数匹配（Vincent, 2011），定理 4.2.1 表明最优分数函数满足 $s^*(\mathbf{x}_t,t) = E_{p(\mathbf{x}_0|\mathbf{x}_t)}[\nabla_{\mathbf{x}}\log p_t(\mathbf{x}_t\mid\mathbf{x}_0)] = \nabla_{\mathbf{x}_t}\log p_t(\mathbf{x}_t)$。利用恒等式 $\nabla_{\mathbf{x}}\log p_t(\mathbf{x}_t\mid\mathbf{x}_0) = -\frac{1}{\sigma_t}\boldsymbol{\epsilon}$ $(\boldsymbol{\epsilon}\sim\mathcal{N}(\mathbf{0},\mathbf{I}))$，得 $s^*(\mathbf{x}_t,t) = -\frac{1}{\sigma_t}\boldsymbol{\epsilon}^*(\mathbf{x}_t,t)$，其中 $\boldsymbol{\epsilon}^*(\mathbf{x}_t,t) = E_{p(\mathbf{x}_0|\mathbf{x}_t)}[\boldsymbol{\epsilon}\mid\mathbf{x}_t]$ 是 $\mathcal{L}_{\text{noise}}(\phi)$ 的最优 $\boldsymbol{\epsilon}$-预测。

对 x-预测损失 $\mathcal{L}_{\text{clean}}$，最优估计子为 $x^*(\mathbf{x}_t,t) = E_{p(\mathbf{x}_0|\mathbf{x}_t)}[\mathbf{x}_0\mid\mathbf{x}_t]$，由 Tweedie 公式，它与分数通过 $\alpha_t x^*(\mathbf{x}_t,t) = \mathbf{x}_t + \sigma_t^2 s^*(\mathbf{x}_t,t)$ 相联。对 v-预测损失 $\mathcal{L}_{\text{velocity}}$，最优估计子为 $v^*(\mathbf{x}_t,t) = E_{p(\mathbf{x}_0|\mathbf{x}_t)}[\alpha_t'\mathbf{x}_0 + \sigma_t'\boldsymbol{\epsilon}\mid\mathbf{x}_t] = \alpha_t' x^* + \sigma_t'\boldsymbol{\epsilon}^*$。把 x^* 与 $\boldsymbol{\epsilon}^*$ 用 s^* 代入，得

$$\begin{aligned} v^*(\mathbf{x}_t,t) &= \frac{\alpha_t'}{\alpha_t}\mathbf{x}_t + \left(\frac{\alpha_t'}{\alpha_t}\sigma_t^2 - \sigma_t\sigma_t'\right)s^*(\mathbf{x}_t,t) \\ &= f(t)\mathbf{x}_t - \frac{1}{2}g^2(t)s^*(\mathbf{x}_t,t). \end{aligned}$$

推导完毕。 □

D.5 理论补充：学习快速扩散生成器

D.5.1 知识蒸馏损失作为一般框架方程 (10.1.4) 的一个实例

我们从 oracle KD 损失出发：$\mathcal{L}_{\text{KD}}^{\text{oracle}}(\theta) = E_{\mathbf{x}_T\sim p_T}\big[\|G_\theta(\mathbf{x}_T,T,0) - \Psi_{T\to 0}(\mathbf{x}_T)\|_2^2\big]$，其中 $p_T = p_{\text{prior}}$。对确定性 ODE 流映射 Ψ（沿轨迹为半群、双射），边缘满足推前恒等式 $p_t = \Psi_{0\to t}\sharp p_{\text{data}} = \Psi_{T\to t}\sharp p_{\text{prior}}$；故 $\Psi_{s\to T}\sharp p_s = p_T$，且 $\Psi_{T\to 0}\circ\Psi_{s\to T} = \Psi_{s\to 0}$。换元 $\mathbf{x}_T = \Psi_{s\to T}(\mathbf{x}_s)$、$\mathbf{x}_s\sim p_s$，得 $\mathcal{L}_{\text{KD}}^{\text{oracle}}(\theta) = E_{\mathbf{x}_s\sim p_s}\big[\|G_\theta(\Psi_{s\to T}(\mathbf{x}_s),T,0) - \Psi_{s\to 0}(\mathbf{x}_s)\|_2^2\big]$。定义拉回学生 $\tilde{G}_\theta(\mathbf{x}_s,s,0) := G_\theta(\Psi_{s\to T}(\mathbf{x}_s),T,0)$，把同一损失表为统一流映射形式（在 $t=0$）：$\mathcal{L}_{\text{KD}}^{\text{oracle}}(\theta) = E_{\mathbf{x}_s\sim p_s}\big[\|\tilde{G}_\theta(\mathbf{x}_s,s,0) - \Psi_{s\to 0}(\mathbf{x}_s)\|_2^2\big]$。这一推导依赖经 oracle 流的换元与半群性质。

D.5.2 命题 10.2.1 的参数–流解释

由命题 10.2.1 的推导，我们可把 VSD 的梯度解释为参数诱导的输运流：调整模型参数，在数据空间中移动粒子，使其运动与学生–教师分布间的分数失配对齐。

令 $t\sim p(t)$，$z\sim p(z)$，$\boldsymbol{\epsilon}\sim\mathcal{N}(\mathbf{0},\mathbf{I})$，$\hat{\mathbf{x}}_t=\alpha_t G_\theta(z)+\sigma_t\boldsymbol{\epsilon}$。定义样本（粒子）速度 $\hat{v}_\theta(\hat{\mathbf{x}}_t):=\partial_\theta\hat{\mathbf{x}}_t=\alpha_t\partial_\theta G_\theta(z)$，$\mathbf{x}$ 空间中的速度场为条件平均 $v_\theta(\mathbf{x}):=E[\hat{v}_\theta(\hat{\mathbf{x}}_t)\mid\hat{\mathbf{x}}_t=\mathbf{x}]$。

有了此定义,在每个固定 t,密度遵循参数–流连续性方程 $\partial_\theta p_t^\theta(\mathbf{x})+\nabla_{\mathbf{x}}\cdot(p_t^\theta(\mathbf{x})v_\theta(\mathbf{x}))=0$。这里 $v_\theta(\hat{\mathbf{x}}_t)=\partial_\theta\hat{\mathbf{x}}_t$ 是数据空间中（t 固定时）参数诱导的粒子速度。等价地，在每个固定 t，密度满足 θ 中的连续性方程。

于是 $\mathcal{L}_{\text{VSD}}$ 的梯度取输运形式：

$$\nabla_\theta\mathcal{L}_{\text{VSD}}=E\left[\omega(t)\left\langle\underbrace{\nabla_{\mathbf{x}}\log p_t^\theta-\nabla_{\mathbf{x}}\log p_t}_{\text{固定}t\text{ 的分数失配}},\ \underbrace{v_\theta}_{\text{参数–流速度}}\right\rangle\right],$$

它说明：调整参数–流，使粒子运动与局部分数失配对齐，从而沿轨迹降低散度。

D.5.3 定理 11.2.1：CM 在 $O(\Delta s)$ 精度上等于 CT

证明： 第 *1* 步：*DDIM* 更新（带 *oracle* 分数）即条件均值。

$$\begin{aligned}\hat{\mathbf{x}}_{s'}&=\frac{\alpha_{s'}}{\alpha_s}\mathbf{x}_s+\frac{\sigma_s^2}{\alpha_s}\Big(\frac{\alpha_{s'}}{\alpha_s}-\frac{\sigma_{s'}}{\sigma_s}\Big)\nabla_{\mathbf{x}_s}\log p_s(\mathbf{x}_s)\\&=\frac{\alpha_{s'}}{\alpha_s}\mathbf{x}_s+\frac{\sigma_s^2}{\alpha_s}\nabla_{\mathbf{x}_s}\log p_s(\mathbf{x}_s)-\frac{\sigma_{s'}\sigma_s}{\alpha_s}\nabla_{\mathbf{x}_s}\log p_s(\mathbf{x}_s)\\&=\alpha_{s'}E[\mathbf{x}_0\mid\mathbf{x}_s]+\sigma_{s'}\frac{\mathbf{x}_s-\alpha_s E[\mathbf{x}_0\mid\mathbf{x}_s]}{\sigma_s}\\&=\alpha_{s'}E[\mathbf{x}_0\mid\mathbf{x}_s]+\sigma_{s'}E[\boldsymbol{\epsilon}\mid\mathbf{x}_s]=E[\alpha_{s'}\mathbf{x}_0+\sigma_{s'}\boldsymbol{\epsilon}\mid\mathbf{x}_s]=E[\mathbf{x}_{s'}\mid\mathbf{x}_s].\end{aligned}$$

这里在第三、第四个等式中使用 Tweedie 公式 $E[\mathbf{x}_0\mid\mathbf{x}_s]=\frac{\mathbf{x}_s+\sigma_s^2\nabla_{\mathbf{x}_s}\log p_s(\mathbf{x}_s)}{\alpha_s}$ 以及 $\mathbf{x}_s=\alpha_s\mathbf{x}_0+\sigma_s\boldsymbol{\epsilon}$。

第 *2* 步：在条件均值 $\hat{\mathbf{x}}_{s'}$ 附近展开 *CT*。

$$\begin{aligned}\mathcal{L}_{\text{CT}}&=E_{s,\mathbf{x}_s}E_{\mathbf{x}_{s'}|\mathbf{x}_s}\big[w(s)\,d\big(f_\theta(\mathbf{x}_s,s),f_{\theta^-}(\mathbf{x}_{s'},s')\big)\big]\\&\overset{(1)}{=}E_{s,\mathbf{x}_s}E_{\mathbf{x}_{s'}|\mathbf{x}_s}\big[w(s)\,d\big(f_\theta(\mathbf{x}_s,s),f_{\theta^-}(\hat{\mathbf{x}}_{s'},s')\big)+w(s)\,\partial_2 d\big(f_\theta(\mathbf{x}_s,s),f_{\theta^-}(\hat{\mathbf{x}}_{s'},s')\big)\partial_1 f_{\theta^-}(\hat{\mathbf{x}}_{s'},s')(\mathbf{x}_{s'}-\hat{\mathbf{x}}_{s'})\\&\qquad+w(s)\,O(\|\mathbf{x}_{s'}-\hat{\mathbf{x}}_{s'}\|^2)\big]\\&\overset{(2)}{=}E_{s,\mathbf{x}_s}\big[w(s)\,d(f_\theta(\mathbf{x}_s,s),f_{\theta^-}(\hat{\mathbf{x}}_{s'},s'))\big]+E_{s,\mathbf{x}_s}\big[w(s)\,\partial_2 d\cdots\partial_1 f_{\theta^-}(\hat{\mathbf{x}}_{s'},s')E_{\mathbf{x}_{s'}|\mathbf{x}_s}(\mathbf{x}_{s'}-\hat{\mathbf{x}}_{s'})\big]\\&\quad+E_{s,\mathbf{x}_s}E_{\mathbf{x}_{s'}|\mathbf{x}_s}\big[w(s)\,O(\|\mathbf{x}_{s'}-\hat{\mathbf{x}}_{s'}\|^2)\big]\\&\overset{(3)}{=}E_{s,\mathbf{x}_s}\big[w(s)\,d(f_\theta(\mathbf{x}_s,s),f_{\theta^-}(\hat{\mathbf{x}}_{s'},s'))\big]+E_{s,\mathbf{x}_s}E_{\mathbf{x}_{s'}|\mathbf{x}_s}\big[w(s)\,O(\|\mathbf{x}_{s'}-\hat{\mathbf{x}}_{s'}\|^2)\big]\\&=E_{s,\mathbf{x}_s}\big[w(s)\,d(f_\theta(\mathbf{x}_s,s),f_{\theta^-}(\hat{\mathbf{x}}_{s'},s'))\big]+O\big(E_{s,\mathbf{x}_s}E_{\mathbf{x}_{s'}|\mathbf{x}_s}\|\mathbf{x}_{s'}-\hat{\mathbf{x}}_{s'}\|^2\big)\\&=\mathcal{L}_{\text{CM}}+O\big(E_{s,\mathbf{x}_s}E_{\mathbf{x}_{s'}|\mathbf{x}_s}\|\mathbf{x}_{s'}-\hat{\mathbf{x}}_{s'}\|^2\big)\overset{(4)}{=}\mathcal{L}_{\text{CM}}+O(\Delta s).\end{aligned}$$

这里 (1) 在第二自变量处对 $\hat{\mathbf{x}}_{s'}$ 应用 $h(x'):=d(f_\theta(\mathbf{x}_s,s),f_{\theta^-}(x',s'))$ 的二阶 Taylor 展开；(2) 应用塔性质 $E_{s,\mathbf{x}_s}E_{\mathbf{x}_{s'}|\mathbf{x}_s}[\cdot]=E_{s,\mathbf{x}_s}[\cdot]$，并注意在 $E_{\mathbf{x}_{s'}|\mathbf{x}_s}$ 内唯一的 $\mathbf{x}_{s'}$ 依赖通过

$(\mathbf{x}_{s'}-\hat{\mathbf{x}}_{s'})$，故其余因子视为常数，内层期望退化为 $E_{\mathbf{x}_{s'}|\mathbf{x}_s}(\mathbf{x}_{s'}-\hat{\mathbf{x}}_{s'})$ 与 $E_{\mathbf{x}_{s'}|\mathbf{x}_s}\|\mathbf{x}_{s'}-\hat{\mathbf{x}}_{s'}\|^2$；(3) 使用 $E[\mathbf{x}_{s'}-\hat{\mathbf{x}}_{s'}\mid\mathbf{x}_s]=0$，因 $\hat{\mathbf{x}}_{s'}=E[\mathbf{x}_{s'}\mid\mathbf{x}_s]$；(4) 使用线性–Gauss 调度，它给出 $E[\|\mathbf{x}_{s'}-\hat{\mathbf{x}}_{s'}\|^2\mid\mathbf{x}_s]=O(\Delta s^2)$，故总余项为 $O(\Delta s)$。 □

D.5.4 命题 11.3.1：CT 梯度的连续时间极限

证明： 我们简化记号，对方程 (11.3.2) 证明：$\mathcal{L}_{\mathrm{CM}}^{\Delta s}(\theta,\theta^-):=E\big[\omega(s)\,\|f_\theta(\mathbf{x}_s,s)-f_{\theta^-}(\Psi_{s\to s-\Delta s}(\mathbf{x}_s),s-\Delta s)\|_2^2\big]$。为记号简洁，记 $\tilde{\mathbf{x}}_{s-\Delta s}:=\Psi_{s\to s-\Delta s}(\mathbf{x}_s)$。展开 MSE 损失：

$$\begin{aligned}&\|f_\theta(\mathbf{x}_s,s)-f_{\theta^-}(\tilde{\mathbf{x}}_{s-\Delta s},s-\Delta s)\|_2^2\\&=\|\underbrace{(f_\theta(\mathbf{x}_s,s)-f_{\theta^-}(\mathbf{x}_s,s))}_{=:\delta f}+(f_{\theta^-}(\mathbf{x}_s,s)-f_{\theta^-}(\tilde{\mathbf{x}}_{s-\Delta s},s-\Delta s))\|_2^2\\&=\|\delta f\|_2^2+2\delta f^\top\cdot\frac{d}{ds}f_{\theta^-}(\mathbf{x}_s,s)\Delta s+\Big\|\frac{d}{ds}f_{\theta^-}(\mathbf{x}_s,s)\Big\|_2^2|\Delta s|^2+O(|\Delta s|^3).\end{aligned}$$

这里我们在 $(\mathbf{x}_s,s)$ 处应用 Taylor 展开 $f_{\theta^-}(\mathbf{x}_s,s)-f_{\theta^-}(\tilde{\mathbf{x}}_{s-\Delta s},s-\Delta s)=\frac{d}{ds}f_{\theta^-}(\mathbf{x}_s,s)\Delta s+O(|\Delta s|^2)$，连同 oracle 流映射的一阶展开 $\mathbf{x}_s-\Psi_{s\to s-\Delta s}(\mathbf{x}_s)=v^*(\mathbf{x}_s,s)\Delta s+O(|\Delta s|^2)$，以及全微分恒等式 $\frac{d}{ds}f_{\theta^-}(\mathbf{x}_s,s)=\partial_s f_{\theta^-}(\mathbf{x}_s,s)+\partial_{\mathbf{x}}f_{\theta^-}(\mathbf{x}_s,s)\,v^*(\mathbf{x}_s,s)$。

由于 θ^- 视为常数、仅为 θ 的同一副本（无梯度穿过它），$\mathcal{L}_{\mathrm{CM}}^{\Delta s}(\theta,\theta^-)$ 关于 θ 的梯度为 $\nabla_\theta\mathcal{L}_{\mathrm{CM}}^{\Delta s}(\theta,\theta^-)=2E\big[\omega(s)\,\nabla_\theta f_\theta(\mathbf{x}_s,s)^\top\cdot\frac{d}{ds}f_{\theta^-}(\mathbf{x}_s,s)\big]\Delta s+O(|\Delta s|^2)$。除以 Δs 并取极限，得 $\lim_{\Delta s\to0}\frac{1}{\Delta s}\nabla_\theta\mathcal{L}_{\mathrm{CM}}^{\Delta s}(\theta,\theta^-)=\nabla_\theta E\big[2\omega(t)f_\theta^\top(\mathbf{x}_s,s)\cdot\frac{d}{ds}f_{\theta^-}(\mathbf{x}_s,s)\big]$。恒等式得证。 □

D.6 （可选）Elucidating Diffusion Model（EDM）

我们介绍 x-预测模型中神经网络参数化设计的具体准则，如 Elucidating Diffusion Models（EDM）（Karras 等, 2022）所提出。EDM 提供一个简单配方，使训练过程更易优化、更可靠。x-预测模型表达为含时跳跃连接与缩放残差的组合（方程 (D.D.6.576)）。核心思想是：在所有时刻把输入与回归目标都归一化到单位方差，并调整跳跃路径，使残差误差不随时间演化被放大。该配方已成为扩散模型实现中广泛采用的默认，并自然推广到流映射学习，尤其是一致性模型家族。

D.6.1 神经网络 x_ϕ 设计的准则

EDM 考虑 x-预测模型的一种参数化，略借记号记作 $x_\phi(\mathbf{x},t)$：

$$x_\phi(\mathbf{x},t):=c_{\mathrm{skip}}(t)\,\mathbf{x}+c_{\mathrm{out}}(t)\,F_\phi\big(c_{\mathrm{in}}(t)\mathbf{x},\,c_{\mathrm{noise}}(t)\big).\tag{D.D.6.576}$$

这里 $c_{\mathrm{skip}}(t)$、$c_{\mathrm{out}}(t)$、$c_{\mathrm{in}}(t)$、$c_{\mathrm{noise}}(t)$ 是含时函数。它们基于即将介绍的实践考虑选取，以增强训练时的稳定性与性能。

把它代入方程 (6.2.5)，经直接代数整理，目标函数变为

$$E_{\mathbf{x}_0,\boldsymbol{\epsilon},t}\Big[\omega(t)\,c_{\mathrm{out}}^2(t)\,\big\|F_\phi(c_{\mathrm{in}}(t)\mathbf{x}_t,c_{\mathrm{noise}}(t))-\mathbf{x}_{\mathrm{tgt}}(t)\big\|_2^2\Big].\tag{D.D.6.577}$$

这里回归目标 $\mathbf{x}_{\mathrm{tgt}}(t)$ 为 $\mathbf{x}_{\mathrm{tgt}}(t)=\frac{(1-c_{\mathrm{skip}}(t)\alpha_t)\mathbf{x}_0-c_{\mathrm{skip}}(t)\sigma_t\boldsymbol{\epsilon}}{c_{\mathrm{out}}(t)}$。

结合 p_{data} 的标准差（记作 σ_d），EDM 提出如下网络参数化设计准则，可称为单位方差准则。

输入的单位方差。$\mathrm{Var}_{\mathbf{x}_0,\boldsymbol{\epsilon}}[c_{\text{in}}(t)\mathbf{x}_t]=1 \iff c_{\text{in}}^2(t)\,\mathrm{Var}_{\mathbf{x}_0,\boldsymbol{\epsilon}}[\alpha_t\mathbf{x}_0+\sigma_t\boldsymbol{\epsilon}]=1 \iff c_{\text{in}}(t)=\frac{1}{\sqrt{\sigma_d^2\alpha_t^2+\sigma_t^2}}$，取正根。

训练目标的单位方差。 $\mathrm{Var}_{\mathbf{x}_0,\boldsymbol{\epsilon}}[\mathbf{x}_{\text{tgt}}(t)]=1 \iff$

$$c_{\text{out}}^2(t)=(1-c_{\text{skip}}(t)\alpha_t)^2\sigma_d^2+c_{\text{skip}}^2(t)\sigma_t^2, \tag{D.D.6.578}$$

（中心化数据 $E[\mathbf{x}_0]=0$ 时）。

最小化从 F_ϕ 到 x_ϕ 的误差放大。EDM 旨在缓解网络学习误差从 F_ϕ 到 x_ϕ 的放大。这通过选取 c_{skip} 使 c_{out} 最小来实现：$c_{\text{skip}}^*\in\arg\min_{c_{\text{skip}}} c_{\text{out}}^2$。用标准方法解 $\frac{\partial c_{\text{out}}}{\partial c_{\text{skip}}}=0$ 得临界点 $c_{\text{skip}}^*(t)=\frac{\alpha_t\sigma_d^2}{\alpha_t^2\sigma_d^2+\sigma_t^2}$。代入方程 (D.D.6.578)，最优值为 $c_{\text{out}}^*(t)=\pm\frac{\sigma_t\sigma_d}{\sqrt{\alpha_t^2\sigma_d^2+\sigma_t^2}}$。

按约定，输出缩放取非负分支：$c_{\text{out}}^*(t)=\frac{\sigma_t\sigma_d}{\sqrt{\alpha_t^2\sigma_d^2+\sigma_t^2}}$ (≥ 0)，这保证 $c_{\text{out}}(0)=0$ 且当 σ_t 足够大时 $c_{\text{out}}(t)\to\sigma_d$，给出直观极限 $x_\phi(\mathbf{x}_t,0)\approx\mathbf{x}_t$ 与 $x_\phi(\mathbf{x}_t,t)\approx\sigma_d F_\phi(\cdot)$。

记 $R_t:=\alpha_t^2\sigma_d^2+\sigma_t^2$，我们有如下选取：

$$c_{\text{in}}(t)=\frac{1}{\sqrt{R_t}},\qquad c_{\text{skip}}(t)=\frac{\alpha_t\sigma_d^2}{R_t},\qquad c_{\text{out}}(t)=\frac{\sigma_t\sigma_d}{\sqrt{R_t}}. \tag{D.D.6.579}$$

由方程 (D.D.6.579)，回归目标 $\mathbf{x}_{\text{tgt}}(t)$ 简化为 $\mathbf{x}_{\text{tgt}}(t)=\frac{1}{\sigma_d}\frac{\sigma_t\mathbf{x}_0-\alpha_t\sigma_d^2\boldsymbol{\epsilon}}{\sqrt{R_t}}$。此外，把这些表达式代入方程 (D.D.6.576) 与 (D.D.6.577)，可同时简化参数化与损失：$x_\phi(\mathbf{x},t)=\frac{\alpha_t\sigma_d^2}{R_t}\mathbf{x}+\frac{\sigma_t\sigma_d}{\sqrt{R_t}}F_\phi\Big(\frac{1}{\sqrt{R_t}}\mathbf{x},c_{\text{noise}}(t)\Big)$，以及 $E_{\mathbf{x}_0,\boldsymbol{\epsilon},t}\Big[\omega(t)\frac{\sigma_t^2}{R_t}\Big\|\sigma_d F_\phi\Big(\frac{1}{\sqrt{R_t}}\mathbf{x}_t,c_{\text{noise}}(t)\Big)-\frac{\sigma_t\mathbf{x}_0-\alpha_t\sigma_d^2\boldsymbol{\epsilon}}{\sqrt{R_t}}\Big\|_2^2\Big]$。

在该参数化及 $\alpha_0\approx 1$、$\sigma_0\approx 0$ 条件下，我们观察到 $c_{\text{skip}}(0)\approx 1$、$c_{\text{out}}(0)\approx 0$。

$c_{\text{noise}}(t)$ 的选取。它为 F_ϕ 提供噪声级嵌入；噪声级 σ_t 的任一一对一映射（如 $c_{\text{noise}}(t)=\log\sigma_t$）都合适。

D.6.2 一个常见 EDM 特例：$\alpha_t=1$、$\sigma_t=t$

我们考虑 EDM 中使用的简化噪声调度 $\alpha_t=1$、$\sigma_t=t$，它也出现在第 11.4 节对 CTM 的讨论中。该设定下前向过程成为 $\mathbf{x}_t=\mathbf{x}_0+t\boldsymbol{\epsilon}$，$\mathbf{x}_0\sim p_{\text{data}}$，$\boldsymbol{\epsilon}\sim\mathcal{N}(\mathbf{0},\mathbf{I})$，对应扰动核 $p_t(\mathbf{x}_t\mid\mathbf{x}_0)=\mathcal{N}(\mathbf{x}_t;\mathbf{x}_0,t^2\mathbf{I})$。相应地，终端时刻的先验分布设为 $p_{\text{prior}}(\mathbf{x}_T):=\mathcal{N}(\mathbf{x}_T;\mathbf{0},T^2\mathbf{I})$。扰动核诱导的边缘密度由卷积给出：$p_t(\mathbf{x})=\int\mathcal{N}(\cdot;\mathbf{0},t^2\mathbf{I})\,p_{\text{data}}(\mathbf{x}_0)\,d\mathbf{x}_0$。

该设定下，基于 x-预测 $x_\phi^\times$（见方程 (6.3.2)）的 PF-ODE 简化为 $\frac{d\mathbf{x}(t)}{dt}=\frac{\mathbf{x}(t)-x_\phi^\times(\mathbf{x}(t),t)}{t}$。把该表述代入方程 (D.D.6.579)，网络参数化系数变为

$$c_{\text{in}}(t)=\frac{1}{\sqrt{\sigma_d^2+t^2}},\qquad c_{\text{skip}}(t)=\frac{\sigma_d^2}{\sigma_d^2+t^2},\qquad c_{\text{out}}(t)=\pm\frac{t\sigma_d}{\sqrt{\sigma_d^2+t^2}}. \tag{D.D.6.580}$$

由这些表达式观察到：

- 当 $t\approx 0$，噪声级可忽略，故 $c_{\text{skip}}\approx 1$、$c_{\text{out}}\approx 0$。此极限下跳跃路径主导，网络本质上直通输入：$x_\phi(\mathbf{x},t)\approx\mathbf{x}$。

- 当 $t \gg 0$，输入被噪声严重污染，故 $c_{\text{skip}} \approx 0$、$c_{\text{out}} \approx \sigma_d$。此区域跳跃路径消失，模型输出完全由学习到的残差决定：$x_\phi(\mathbf{x}, t) \approx \sigma_d F_\phi(c_{\text{in}}(t)\mathbf{x}, c_{\text{noise}}(t))$，即网络 F_ϕ 从归一化含噪输入预测干净信号的缩放代理；在高噪声级下模型输出因而完全由学习到的去噪函数决定。

简言之，该参数化从小 t 处的恒等映射，平滑插值到大 t 处标准化输入上的缩放残差预测子。

参考文献

[1] Ackley, D. H., G. E. Hinton, and T. J. Sejnowski. (1985). "A learning algorithm for Boltzmann machines". *Cognitive science*. 9(1): 147–169.

[2] Albergo, M. S., N. M. Boffi, and E. Vanden-Eijnden. (2023). "Stochastic interpolants: A unifying framework for flows and diffusions". arXiv preprint arXiv:2303.08797.

[3] Albergo, M. S. and E. Vanden-Eijnden. (2023). "Building Normalizing Flows with Stochastic Interpolants". In: *The Eleventh International Conference on Learning Representations*.

[4] Altschuler, J., J. Niles-Weed, and P. Rigollet. (2017). "Near-linear time approximation algorithms for optimal transport via Sinkhorn iteration". *Advances in neural information processing systems*. 30.

[5] Anderson, B. D. (1982). "Reverse-time diffusion equation models". *Stochastic Processes and their Applications*. 12(3): 313–326.

[6] Atkinson, K., W. Han, and D. E. Stewart. (2009). *Numerical solution of ordinary differential equations*. Vol. 81. John Wiley & Sons.

[7] Bansal, A., H.-M. Chu, A. Schwarzschild, S. Sengupta, M. Goldblum, J. Geiping, and T. Goldstein. (2023). "Universal guidance for diffusion models". In: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 843–852.

[8] Behrmann, J., W. Grathwohl, R. T. Chen, D. Duvenaud, and J.-H. Jacobsen. (2019). "Invertible residual networks". In: *International conference on machine learning*. PMLR. 573–582.

[9] Benamou, J.-D. and Y. Brenier. (2000). "A computational fluid mechanics solution to the Monge-Kantorovich mass transfer problem". *Numerische Mathematik*. 84(3): 375–393.

[10] Boffi, N. M., M. S. Albergo, and E. Vanden-Eijnden. (2024). "Flow Map Matching". arXiv preprint arXiv:2406.07507.

[11] Bradley, R. A. and M. E. Terry. (1952). "Rank analysis of incomplete block designs: I. the method of paired comparisons". *Biometrika*. 39(3/4): 324–345.

[12] Caluya, K. F. and A. Halder. (2021). "Wasserstein proximal algorithms for the Schrödinger bridge problem: Density control with nonlinear drift". *IEEE Transactions on Automatic Control*. 67(3): 1163–1178.

[13] Chen, R. T., J. Behrmann, D. K. Duvenaud, and J.-H. Jacobsen. (2019). "Residual flows for invertible generative modeling". *Advances in Neural Information Processing Systems*. 32.

[14] Chen, R. T., Y. Rubanova, J. Bettencourt, and D. K. Duvenaud. (2018). "Neural ordinary differential equations". *Advances in neural information processing systems*. 31.

[15] Chen, T., G.-H. Liu, and E. Theodorou. (2022). "Likelihood Training of Schrödinger Bridge using Forward-Backward SDEs Theory". In: *International Conference on Learning Representations*.

[16] Chen, Y., T. T. Georgiou, and M. Pavon. (2016). "On the relation between optimal transport and Schrödinger bridges: A stochastic control viewpoint". *Journal of Optimization Theory and Applications*. 169: 671–691.

[17] Chen, Y., T. T. Georgiou, and M. Pavon. (2021). "Stochastic control liaisons: Richard Sinkhorn meets Gaspard Monge on a Schrödinger bridge". *SIAM Review*. 63(2): 249–313.

[18] Choi, J., S. Kim, Y. Jeong, Y. Gwon, and S. Yoon. (2021). "ILVR: Conditioning Method for Denoising Diffusion Probabilistic Models". In: *2021 IEEE/CVF International Conference on Computer Vision (ICCV)*. IEEE. 14347–14356.

[19] Chung, H., J. Kim, M. T. McCann, M. L. Klasky, and J. C. Ye. (2022). "Diffusion posterior sampling for general noisy inverse problems". arXiv preprint arXiv:2209.14687.

[20] Chung, H., J. Kim, M. T. McCann, M. L. Klasky, and J. C. Ye. (2023). "Diffusion Posterior Sampling for General Noisy Inverse Problems". In: *The Eleventh International Conference on Learning Representations*.

[21] Csiszár, I. (1963). "Eine informationstheoretische Ungleichung und ihre Anwendung auf den Beweis der Ergodizität von Markoffschen Ketten". *A Magyar Tudományos Akadémia Matematikai Kutató Intézetének Közleményei*. 8(1-2): 85–108.

[22] Cuturi, M. (2013). "Sinkhorn distances: Lightspeed computation of optimal transport". *Advances in neural information processing systems*. 26.

[23] Dai Pra, P. (1991). "A stochastic control approach to reciprocal diffusion processes". *Applied Mathematics and Optimization*. 23(1): 313–329.

[24] Daras, G., H. Chung, C.-H. Lai, Y. Mitsufuji, J. C. Ye, P. Milanfar, A. G. Dimakis, and M. Delbracio. (2024). "A survey on diffusion models for inverse problems". arXiv preprint arXiv:2410.00083.

[25] Daras, G., Y. Dagan, A. Dimakis, and C. Daskalakis. (2023). "Consistent diffusion models: Mitigating sampling drift by learning to be consistent". *Advances in Neural Information Processing Systems*. 36: 42038–42063.

[26] De Bortoli, V. (2022). "Convergence of denoising diffusion models under the manifold hypothesis". arXiv preprint arXiv:2208.05314.

[27] De Bortoli, V., J. Thornton, J. Heng, and A. Doucet. (2021). "Diffusion Schrödinger bridge with applications to score-based generative modeling". *Advances in Neural Information Processing Systems*. 34: 17695–17709.

[28] Dhariwal, P. and A. Nichol. (2021). "Diffusion models beat GANs on image synthesis". *Advances in Neural Information Processing Systems*. 34: 8780–8794.

[29] Efron, B. (2011). "Tweedie's formula and selection bias". *Journal of the American Statistical Association*. 106(496): 1602–1614.

[30] Esser, P., S. Kulal, A. Blattmann, R. Entezari, J. Müller, H. Saini, Y. Levi, D. Lorenz, A. Sauer, F. Boesel, et al. (2024). "Scaling rectified flow transformers for high-resolution image synthesis". In: *Forty-first International Conference on Machine Learning*.

[31] Evans, L. C. (2010). *Partial differential equations*. Providence, R.I.: American Mathematical Society.

[32] Fournier, N. and A. Guillin. (2015). "On the rate of convergence in Wasserstein distance of the empirical measure". *Probability theory and related fields*. 162(3): 707–738.

[33] Frey, B. J., G. E. Hinton, and P. Dayan. (1995). "Does the wake-sleep algorithm produce good density estimators?" *Advances in neural information processing systems*. 8.

[34] Genevay, A., G. Peyré, and M. Cuturi. (2018). "Learning generative models with Sinkhorn divergences". In: *International Conference on Artificial Intelligence and Statistics*. PMLR. 1608–1617.

[35] Geng, Z., M. Deng, X. Bai, J. Z. Kolter, and K. He. (2025a). "Mean flows for one-step generative modeling". arXiv preprint arXiv:2505.13447.

[36] Geng, Z., A. Pokle, W. Luo, J. Lin, and J. Z. Kolter. (2025b). "Consistency Models Made Easy". In: *The Thirteenth International Conference on Learning Representations*.

[37] Geng, Z., A. Pokle, W. Luo, J. Lin, and J. Z. Kolter. (2024). "Consistency models made easy". arXiv preprint arXiv:2406.14548.

[38] Goodfellow, I., J. Pouget-Abadie, M. Mirza, B. Xu, D. Warde-Farley, S. Ozair, A. Courville, and Y. Bengio. (2014). "Generative adversarial nets". *Advances in neural information processing systems*. 27.

[39] He, Y., N. Murata, C.-H. Lai, Y. Takida, T. Uesaka, D. Kim, W.-H. Liao, Y. Mitsufuji, J. Z. Kolter, R. Salakhutdinov, et al. (2023). "Manifold preserving guided diffusion". In: *International Conference on Learning Representations*.

[40] He, Y., N. Murata, C.-H. Lai, Y. Takida, T. Uesaka, D. Kim, W.-H. Liao, Y. Mitsufuji, J. Z. Kolter, R. Salakhutdinov, and S. Ermon. (2024). "Manifold Preserving Guided Diffusion". In: *The Twelfth International Conference on Learning Representations*.

[41] Heitz, E., L. Belcour, and T. Chambon. (2023). "Iterative α-(de)blending: A minimalist deterministic diffusion model". In: *ACM SIGGRAPH 2023 Conference Proceedings*. 1–8.

[42] Hertrich, J., A. Chambolle, and J. Delon. (2025). "On the Relation between Rectified Flows and Optimal Transport". arXiv preprint arXiv:2505.19712.

[43] Hinton, G. E. (2002). "Training products of experts by minimizing contrastive divergence". *Neural computation*. 14(8): 1771–1800.

[44] Ho, J., A. Jain, and P. Abbeel. (2020). "Denoising diffusion probabilistic models". *Advances in Neural Information Processing Systems*. 33: 6840–6851.

[45] Ho, J. and T. Salimans. (2021). "Classifier-Free Diffusion Guidance". In: *NeurIPS 2021 Workshop on Deep Generative Models and Downstream Applications*.

[46] Hochbruck, M. and A. Ostermann. (2005). "Explicit exponential Runge–Kutta methods for semilinear parabolic problems". *SIAM Journal on Numerical Analysis*. 43(3): 1069–1090.

[47] Hochbruck, M. and A. Ostermann. (2010). "Exponential integrators". *Acta Numerica*. 19: 209–286.

[48] Hu, Z., C.-H. Lai, Y. Mitsufuji, and S. Ermon. (2025). "CMT: Mid-Training for Efficient Learning of Consistency, Mean Flow, and Flow Map Models". arXiv preprint arXiv:2509.24526.

[49] Huang, C.-W., R. T. Chen, C. Tsirigotis, and A. Courville. (2021). "Convex Potential Flows: Universal Probability Distributions with Optimal Transport and Convex Optimization". In: *International Conference on Learning Representations*.

[50] Hutchinson, M. F. (1989). "A stochastic estimator of the trace of the influence matrix for Laplacian smoothing splines". *Communications in Statistics-Simulation and Computation*. 18(3): 1059–1076.

[51] Hyvärinen, A. and P. Dayan. (2005). "Estimation of non-normalized statistical models by score matching". *Journal of Machine Learning Research*. 6(4).

[52] Iserles, A. (2009). *A first course in the numerical analysis of differential equations*. No. 44. Cambridge University Press.

[53] Karras, T., M. Aittala, T. Aila, and S. Laine. (2022). "Elucidating the design space of diffusion-based generative models". *Advances in Neural Information Processing Systems*. 35: 26565–26577.

[54] Karras, T., M. Aittala, J. Lehtinen, J. Hellsten, T. Aila, and S. Laine. (2023). "Analyzing and improving the training dynamics of diffusion models". arXiv preprint arXiv:2312.02696.

[55] Karras, T., M. Aittala, J. Lehtinen, J. Hellsten, T. Aila, and S. Laine. (2024). "Analyzing and Improving the Training Dynamics of Diffusion Models". In: *IEEE Conference on Computer Vision and Pattern Recognition*. IEEE. 24174–24184.

[56] Kim, D., C.-H. Lai, W.-H. Liao, N. Murata, Y. Takida, T. Uesaka, Y. He, Y. Mitsufuji, and S. Ermon. (2024a). "Consistency trajectory models: Learning probability flow ODE trajectory of diffusion". In: *International Conference on Learning Representations*.

[57] Kim, D., C.-H. Lai, W.-H. Liao, Y. Takida, N. Murata, T. Uesaka, Y. Mitsufuji, and S. Ermon. (2024b). "PaGoDA: Progressive Growing of a One-Step Generator from a Low-Resolution Diffusion Teacher". arXiv preprint arXiv:2405.14822.

[58] Kim, D., S. Shin, K. Song, W. Kang, and I.-C. Moon. (2022). "Soft truncation: A universal training technique of score-based diffusion model for high precision score estimation". In: *International Conference on Machine Learning*. PMLR. 11201–11228.

[59] Kingma, D., T. Salimans, B. Poole, and J. Ho. (2021). "Variational diffusion models". *Advances in neural information processing systems*. 34: 21696–21707.

[60] Kingma, D. P. and R. Gao. (2023). "Understanding Diffusion Objectives as the ELBO with Simple Data Augmentation". In: *Thirty-seventh Conference on Neural Information Processing Systems*.

[61] Kingma, D. P. and M. Welling. (2013). "Auto-encoding variational Bayes". arXiv preprint arXiv:1312.6114.

[62] Kloeden, P. E., E. Platen, P. E. Kloeden, and E. Platen. (1992). *Stochastic differential equations*. Springer.

[63] Lai, C.-H., Y. Takida, N. Murata, T. Uesaka, Y. Mitsufuji, and S. Ermon. (2023a). "FP-Diffusion: Improving score-based diffusion models by enforcing the underlying score Fokker–Planck equation". In: *International Conference on Machine Learning*. PMLR. 18365–18398.

[64] Lai, C.-H., Y. Takida, T. Uesaka, N. Murata, Y. Mitsufuji, and S. Ermon. (2023b). "On the Equivalence of Consistency-Type Models: Consistency Models, Consistent Diffusion Models, and Fokker-Planck Regularization". arXiv preprint arXiv:2306.00367.

[65] Larochelle, H. and I. Murray. (2011). "The neural autoregressive distribution estimator". In: *Proceedings of the fourteenth international conference on artificial intelligence and statistics*. JMLR Workshop and Conference Proceedings. 29–37.

[66] Lavenant, H. and F. Santambrogio. (2022). "The flow map of the Fokker–Planck equation does not provide optimal transport". *Applied Mathematics Letters*. 133: 108225.

[67] LeCun, Y., S. Chopra, R. Hadsell, M. Ranzato, F. Huang, et al. (2006). "A tutorial on energy-based learning". *Predicting structured data*. 1(0).

[68] Léonard, C. (2012). "From the Schrödinger problem to the Monge–Kantorovich problem". *Journal of Functional Analysis*. 262(4): 1879–1920.

[69] Léonard, C. (2014). "A survey of the Schrödinger problem and some of its connections with optimal transport". *Discrete and Continuous Dynamical Systems-Series A*. 34(4): 1533–1574.

[70] Lipman, Y., R. T. Chen, H. Ben-Hamu, M. Nickel, and M. Le. (2022). "Flow Matching for Generative Modeling". In: *The Eleventh International Conference on Learning Representations*.

[71] Lipman, Y., M. Havasi, P. Holderrieth, N. Shaul, M. Le, B. Karrer, R. T. Chen, D. Lopez-Paz, H. Ben-Hamu, and I. Gat. (2024). "Flow matching guide and code". arXiv preprint arXiv:2412.06264.

[72] Liu, G.-H., A. Vahdat, D.-A. Huang, E. Theodorou, W. Nie, and A. Anandkumar. (2023). "I^2SB: Image-to-Image Schrödinger Bridge". In: *International Conference on Machine Learning*. PMLR. 22042–22062.

[73] Liu, Q. (2022). "Rectified flow: A marginal preserving approach to optimal transport". arXiv preprint arXiv:2209.14577.

[74] Liu, X., C. Gong, et al. (2022). "Flow Straight and Fast: Learning to Generate and Transfer Data with Rectified Flow". In: *The Eleventh International Conference on Learning Representations*.

[75] Lou, A., C. Meng, and S. Ermon. (2024). "Discrete Diffusion Modeling by Estimating the Ratios of the Data Distribution". In: *International Conference on Machine Learning*. PMLR. 32819–32848.

[76] Lu, C. and Y. Song. (2024). "Simplifying, stabilizing and scaling continuous-time consistency models". arXiv preprint arXiv:2410.11081.

[77] Lu, C., K. Zheng, F. Bao, J. Chen, C. Li, and J. Zhu. (2022a). "Maximum Likelihood Training for Score-based Diffusion ODEs by High Order Denoising Score Matching". In: *International Conference on Machine Learning*. PMLR. 14429–14460.

[78] Lu, C., Y. Zhou, F. Bao, J. Chen, C. Li, and J. Zhu. (2022b). "DPM-Solver: A fast ODE solver for diffusion probabilistic model sampling in around 10 steps". *Advances in Neural Information Processing Systems*. 35: 5775–5787.

[79] Lu, C., Y. Zhou, F. Bao, J. Chen, C. Li, and J. Zhu. (2022c). "DPM-Solver++: Fast solver for guided sampling of diffusion probabilistic models". arXiv preprint arXiv:2211.01095.

[80] Luan, V. T. (2021). "Efficient exponential Runge–Kutta methods of high order: construction and implementation". *BIT Numerical Mathematics*. 61(2): 535–560.

[81] Luhman, E. and T. Luhman. (2021). "Knowledge distillation in iterative generative models for improved sampling speed". arXiv preprint arXiv:2101.02388.

[82] Luo, W., T. Hu, S. Zhang, J. Sun, Z. Li, and Z. Zhang. (2023). "Diff-Instruct: A universal approach for transferring knowledge from pre-trained diffusion models". *Advances in Neural Information Processing Systems*. 36: 76525–76546.

[83] Ma, N., M. Goldstein, M. S. Albergo, N. M. Boffi, E. Vanden-Eijnden, and S. Xie. (2024). "SIT: Exploring flow and diffusion-based generative models with scalable interpolant transformers". In: *European Conference on Computer Vision*. Springer. 23–40.

[84] Maoutsa, D., S. Reich, and M. Opper. (2020). "Interacting particle solutions of Fokker–Planck equations through gradient–log–density estimation". *Entropy*. 22(8): 802.

[85] Meng, C., K. Choi, J. Song, and S. Ermon. (2022). "Concrete score matching: Generalized score matching for discrete data". *Advances in Neural Information Processing Systems*. 35: 34532–34545.

[86] Meng, C., R. Rombach, R. Gao, D. Kingma, S. Ermon, J. Ho, and T. Salimans. (2023). "On distillation of guided diffusion models". In: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 14297–14306.

[87] Meng, C., Y. Song, W. Li, and S. Ermon. (2021a). "Estimating high order gradients of the data distribution by denoising". *Advances in Neural Information Processing Systems*. 34: 25359–25369.

[88] Meng, C., Y. Song, J. Song, J. Wu, J.-Y. Zhu, and S. Ermon. (2021b). "SDEdit: Image synthesis and editing with stochastic differential equations". arXiv preprint arXiv:2108.01073.

[89] Mikami, T. and M. Thieullen. (2006). "Duality theorem for the stochastic optimal control problem". *Stochastic processes and their applications*. 116(12): 1815–1835.

[90] Mikami, T. and M. Thieullen. (2008). "Optimal transportation problem by stochastic optimal control". *SIAM Journal on Control and Optimization*. 47(3): 1127–1139.

[91] Mokady, R., A. Hertz, K. Aberman, Y. Pritch, and D. Cohen-Or. (2023). "Null-text inversion for editing real images using guided diffusion models". In: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 6038–6047.

[92] Neklyudov, K., R. Brekelmans, D. Severo, and A. Makhzani. (2023). "Action matching: Learning stochastic dynamics from samples". In: *International Conference on Machine Learning*. PMLR. 25858–25889.

[93] Nowozin, S., B. Cseke, and R. Tomioka. (2016). "f-GAN: Training generative neural samplers using variational divergence minimization". *Advances in neural information processing systems*. 29.

[94] Øksendal, B. (2003). "Stochastic differential equations". In: *Stochastic differential equations*. Springer. 65–84.

[95] Onken, D., S. W. Fung, X. Li, and L. Ruthotto. (2021). "OT-Flow: Fast and accurate continuous normalizing flows via optimal transport". In: *Proceedings of the AAAI Conference on Artificial Intelligence*. Vol. 35, No. 10. 9223–9232.

[96] Pavon, M. and A. Wakolbinger. (1991). "On free energy, stochastic control, and Schrödinger processes". In: *Modeling, Estimation and Control of Systems with Uncertainty*. Springer. 334–348.

[97] Peters, J., K. Mulling, and Y. Altun. (2010). "Relative entropy policy search". In: *Proceedings of the AAAI Conference on Artificial Intelligence*. Vol. 24, No. 1. 1607–1612.

[98] Peyré, G., M. Cuturi, et al. (2019). "Computational optimal transport: With applications to data science". *Foundations and Trends® in Machine Learning*. 11(5-6): 355–607.

[99] Pontryagin, L. S. (2018). *Mathematical theory of optimal processes*. Routledge.

[100] Poole, B., A. Jain, J. T. Barron, and B. Mildenhall. (2023). "DreamFusion: Text-to-3D using 2D Diffusion". In: *The Eleventh International Conference on Learning Representations*.

[101] Pra, P. D. and M. Pavon. (1990). "On the Markov processes of Schrödinger, the Feynman-Kac formula and stochastic control". In: *Realization and Modelling in System Theory: Proceedings of the International Symposium MTNS-89, Volume I*. Springer. 497–504.

[102] Radford, A., J. W. Kim, C. Hallacy, A. Ramesh, G. Goh, S. Agarwal, G. Sastry, A. Askell, P. Mishkin, J. Clark, et al. (2021). "Learning transferable visual models from natural language supervision". In: *International conference on machine learning*. PMLR. 8748–8763.

[103] Rafailov, R., A. Sharma, E. Mitchell, C. D. Manning, S. Ermon, and C. Finn. (2023). "Direct preference optimization: Your language model is secretly a reward model". *Advances in neural information processing systems*. 36: 53728–53741.

[104] Raissi, M. (2018). "Deep hidden physics models: Deep learning of nonlinear partial differential equations". *Journal of Machine Learning Research*. 19(25): 1–24.

[105] Reid, W. (1971). *Ordinary Differential Equations*. Applied mathematics series. Wiley.

[106] Rezende, D. and S. Mohamed. (2015). "Variational inference with normalizing flows". In: *International conference on machine learning*. PMLR. 1530–1538.

[107] Saharia, C., W. Chan, S. Saxena, L. Li, J. Whang, E. L. Denton, K. Ghasemipour, R. Gontijo Lopes, B. Karagol Ayan, T. Salimans, et al. (2022). "Photorealistic text-to-image diffusion models with deep language understanding". *Advances in Neural Information Processing Systems*. 35: 36479–36494.

[108] Salimans, T. and J. Ho. (2021). "Progressive Distillation for Fast Sampling of Diffusion Models". In: *International Conference on Learning Representations*.

[109] Särkkä, S. and A. Solin. (2019). *Applied stochastic differential equations*. Vol. 10. Cambridge University Press.

[110] Schulman, J., F. Wolski, P. Dhariwal, A. Radford, and O. Klimov. (2017). "Proximal policy optimization algorithms". arXiv preprint arXiv:1707.06347.

[111] Shih, A., S. Belkhale, S. Ermon, D. Sadigh, and N. Anari. (2023). "Parallel Sampling of Diffusion Models". arXiv preprint arXiv:2305.16317.

[112] Sinkhorn, R. (1964). "A relationship between arbitrary positive matrices and doubly stochastic matrices". *The Annals of Mathematical Statistics*. 35(2): 876–879.

[113] Sohl-Dickstein, J., E. Weiss, N. Maheswaranathan, and S. Ganguli. (2015). "Deep unsupervised learning using nonequilibrium thermodynamics". In: *International Conference on Machine Learning*. PMLR. 2256–2265.

[114] Song, J., C. Meng, and S. Ermon. (2020a). "Denoising Diffusion Implicit Models". In: *International Conference on Learning Representations*.

[115] Song, Y. and P. Dhariwal. (2024). "Improved Techniques for Training Consistency Models". In: *The Twelfth International Conference on Learning Representations*.

[116] Song, Y., P. Dhariwal, M. Chen, and I. Sutskever. (2023). "Consistency models". arXiv preprint arXiv:2303.01469.

[117] Song, Y., C. Durkan, I. Murray, and S. Ermon. (2021). "Maximum likelihood training of score-based diffusion models". *Advances in Neural Information Processing Systems*. 34: 1415–1428.

[118] Song, Y. and S. Ermon. (2019). "Generative modeling by estimating gradients of the data distribution". *Advances in Neural Information Processing Systems*. 32.

[119] Song, Y., S. Garg, J. Shi, and S. Ermon. (2020b). "Sliced score matching: A scalable approach to density and score estimation". In: *Uncertainty in Artificial Intelligence*. PMLR. 574–584.

[120] Song, Y., J. Sohl-Dickstein, D. P. Kingma, A. Kumar, S. Ermon, and B. Poole. (2020c). "Score-Based Generative Modeling through Stochastic Differential Equations". In: *International Conference on Learning Representations*.

[121] Su, X., J. Song, C. Meng, and S. Ermon. (2022). "Dual diffusion implicit bridges for image-to-image translation". arXiv preprint arXiv:2203.08382.

[122] Tabak, E. G. and E. Vanden-Eijnden. (2010). "Density estimation by dual ascent of the log-likelihood". *Communications in Mathematical Sciences*. 8(1): 217–233.

[123] Tong, A., K. Fatras, N. Malkin, G. Huguet, Y. Zhang, J. Rector-Brooks, G. Wolf, and Y. Bengio. (2024). "Improving and generalizing flow-based generative models with minibatch optimal transport". *Transactions on Machine Learning Research*.

[124] Turner, C. V. (2013). "A family of nonparametric density estimation algorithms". *Communications on Pure and Applied Mathematics*. 66(2): 145–164.

[125] Uria, B., M.-A. Côté, K. Gregor, I. Murray, and H. Larochelle. (2016). "Neural autoregressive distribution estimation". *Journal of Machine Learning Research*. 17(205): 1–37.

[126] Vahdat, A. and J. Kautz. (2020). "NVAE: A deep hierarchical variational autoencoder". *Advances in neural information processing systems*. 33: 19667–19679.

[127] Villani, C. et al. (2008). *Optimal transport: old and new*. Vol. 338. Springer.

[128] Vincent, P. (2011). "A connection between score matching and denoising autoencoders". *Neural computation*. 23(7): 1661–1674.

[129] Wallace, B., M. Dang, R. Rafailov, L. Zhou, A. Lou, S. Purushwalkam, S. Ermon, C. Xiong, S. Joty, and N. Naik. (2024). "Diffusion model alignment using direct preference optimization". In: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 8228–8238.

[130] Wang, Z., C. Lu, Y. Wang, F. Bao, C. Li, H. Su, and J. Zhu. (2023). "ProlificDreamer: High-fidelity and diverse text-to-3D generation with variational score distillation". *Advances in Neural Information Processing Systems*. 36: 8406–8441.

[131] Xu, Y., M. Deng, X. Cheng, Y. Tian, Z. Liu, and T. S. Jaakkola. (2023). "Restart Sampling for Improving Generative Processes". In: *Thirty-seventh Conference on Neural Information Processing Systems*.

[132] Ye, H., H. Lin, J. Han, M. Xu, S. Liu, Y. Liang, J. Ma, J. Y. Zou, and S. Ermon. (2024). "TFG: Unified training-free guidance for diffusion models". *Advances in Neural Information Processing Systems*. 37: 22370–22417.

[133] Yin, T., M. Gharbi, T. Park, R. Zhang, E. Shechtman, F. Durand, and B. Freeman. (2024a). "Improved distribution matching distillation for fast image synthesis". *Advances in neural information processing systems*. 37: 47455–47487.

[134] Yin, T., M. Gharbi, R. Zhang, E. Shechtman, F. Durand, W. T. Freeman, and T. Park. (2024b). "One-Step Diffusion with Distribution Matching Distillation". In: *2024 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. IEEE. 6613–6623.

[135] Yu, J., Y. Wang, C. Zhao, B. Ghanem, and J. Zhang. (2023). "FreeDoM: Training-free energy-guided conditional diffusion model". In: *Proceedings of the IEEE/CVF International Conference on Computer Vision*. 23174–23184.

[136] Zhang, Q. and Y. Chen. (2022). "Fast Sampling of Diffusion Models with Exponential Integrator". In: *The Eleventh International Conference on Learning Representations*.

[137] Zheng, K., C. Lu, J. Chen, and J. Zhu. (2023). "DPM-Solver-v3: Improved diffusion ODE solver with empirical model statistics". *Advances in Neural Information Processing Systems*. 36: 55502–55542.

[138] Zhou, M., H. Zheng, Z. Wang, M. Yin, and H. Huang. (2024). "Score identity distillation: Exponentially fast distillation of pretrained diffusion models for one-step generation". In: *Forty-first International Conference on Machine Learning*.

术语索引

中文术语	英文术语	页码
变分自编码器	Variational Autoencoder, VAE	2
深度生成模型	Deep Generative Model, DGM	10
基于能量的模型	Energy-Based Model, EBM	14
隐变量	latent variable	15
编码器	encoder	15
解码器	decoder	15
证据下界	Evidence Lower Bound, ELBO	15
归一化流	Normalizing Flow, NF	15
Langevin 动力学	Langevin dynamics	36
分数	score	36
基于分数的扩散模型	score-based diffusion model	36
配分函数	partition function	36
对比散度	contrastive divergence	37
分数匹配	score matching	37
分数函数	score function	37
分数匹配 (Hyvärinen–Dayan)	score matching	38
Langevin 随机微分方程	Langevin SDE	40
基于分数的扩散模型	score-based diffusion model	43
切片分数匹配	sliced score matching	43
去噪分数匹配	Denoising Score Matching, DSM	44
DSM 损失	DSM loss	44
Tweedie 公式	Tweedie's formula	47
噪声条件分数网络	Noise-Conditional Score Network, NCSN	52
退火 Langevin 动力学	annealed Langevin dynamics	54
连续时间框架	continuous-time framework	57
Score SDE	Score SDE	57
分数函数	score function	59

中文术语	英文术语	页码
前向 SDE	forward SDE	59
免模拟	simulation-free	60
退火	annealing	63
概率流 ODE	Probability Flow ODE, PF-ODE	63
流映射	flow map	65
方差爆炸 SDE	Variance Explosion SDE, VE SDE	73
方差保持 SDE	Variance Preserving SDE, VP SDE	73
随机微分方程	stochastic differential equation, SDE	237