
扩散模型原理

从起源到进展

The Principles of Diffusion Models

From Origins to Advances

Chieh-Hsin Lai Yang Song Dongjun Kim

Yuki Mitsufuji Stefano Ermon

摘要

本专著聚焦于塑造扩散模型发展的基本原理，追溯其起源，并展示不同表述如何源于共同的数学思想。

扩散建模首先指定一个前向加噪过程，逐渐将数据转化为噪声。该前向过程通过定义一族连续的中间分布，将数据分布与简单的噪声分布连接起来。扩散模型的核心目标是构造另一个沿相反方向运行的过程，将噪声转化为数据，同时恢复前向加噪过程所定义的同族中间分布。

我们介绍形式化这一思想的三种互补方式。受变分自编码器启发的变分视角将扩散理解为学习逐步去除噪声：各个较小的去噪目标共同教会模型如何将噪声还原为数据。植根于能量建模的基于得分的视角学习不断演化的数据分布的梯度，该梯度指示如何使样本向更可能的区域移动。与归一化流有关的基于流的视角则将生成理解为在学得的速度场作用下，沿着一条平滑路径将样本从噪声移动到数据。

这些视角具有共同的骨架：一个学得的、随时间变化的速度场，其流将简单的先验输运到数据。有了这一速度场，采样就相当于求解一个微分方程，沿连续的生成轨迹使噪声演化为数据。在此基础上，本专著讨论用于可控生成的引导、用于高效采样的先进数值求解器，以及受扩散启发、学习轨迹上任意时刻之间直接映射的流映射模型。

本专著面向具有基本深度学习背景、希望从概念与数学基础两方面清晰理解扩散模型的读者。它阐明理论基础，解释不同表述背后的推理，并为进一步学习和研究这一快速发展的领域提供坚实基础。它既是供研究者使用的原理性参考资料，也是学习者易于入门的起点。

作者与单位

Chieh-Hsin Lai: Sony AI; chieh-hsin.lai@sony.com / chiehhsinlai@gmail.com.

Yang Song: OpenAI¹; thusongyang@gmail.com.

Dongjun Kim: 斯坦福大学; dongjun@stanford.edu.

Yuki Mitsufuji: Sony Corporation, Sony AI; yuhki.mitsufuji@sony.com.

Stefano Ermon: 斯坦福大学; ermon@cs.stanford.edu.

¹作者单位反映开展本工作时所在的机构。

致谢

作者衷心感谢首尔市立大学及韩国高等科学院 (KIAS) 的 **Dohyun Kwon 教授**, 感谢他慷慨投入时间和精力参与本工作. 他仔细审阅了章 7 的部分内容, 帮助确保命题与证明的正确性, 并参与了多次有价值的讨论, 使表述更加清晰. 除了技术建议, 他深思熟虑的反馈和乐于分享观点的态度, 也在本专著的整个写作过程中给予我们鼓励. 我们由衷感谢他的支持与同仁精神, 它们丰富了本书的最终版本.

目录

摘要	i
致谢	ii
前言与阅读路线	xi
符号说明	xvi
第一部分 深度生成建模导论	1
第 1 章 深度生成建模	2
1.1 什么是深度生成建模?	3
1.1.1 数学设定	3
1.1.2 分布建模的挑战	6
1.2 主要的深度生成模型	8
1.3 建模方法的分类	10
1.4 结束语	11
第二部分 扩散模型的起源与基础	12
第 2 章 变分视角: 从 VAE 到 DDPM	14
2.1 变分自编码器	15
2.1.1 概率编码器和解码器	15
2.1.2 通过证据下界 (ELBO) 训练	16
2.1.3 高斯 VAE	17
2.1.4 标准 VAE 的缺点	18
2.1.5 (选读) 从标准 VAE 到层级 VAE	19
2.2 变分视角: DDPM	22
2.2.1 前向过程 (固定编码器)	22
2.2.2 反向去噪过程 (可学习解码器)	24
2.2.3 反向转移核 $p_\phi(\mathbf{x}_{i-1} \mathbf{x}_i)$ 的建模	25
2.2.4 预测与损失的实际选择	26

2.2.5	DDPM 的 ELBO	27
2.2.6	采样	29
2.3	结束语	31
第 3 章	基于得分的视角：从 EBM 到 NCSN	32
3.1	能量模型	33
3.1.1	用能量函数建模概率分布	33
3.1.2	动机：什么是得分？	35
3.1.3	通过得分匹配训练 EBM	36
3.1.4	使用得分函数的朗之万采样	36
3.2	从能量模型到基于得分的生成模型	39
3.2.1	用得分匹配训练	39
3.2.2	用朗之万动力学采样	41
3.2.3	序言：基于得分的生成模型	41
3.3	去噪得分匹配	42
3.3.1	动机	42
3.3.2	训练	42
3.3.3	采样	45
3.3.4	为何 DSM 是去噪：Tweedie 公式	45
3.3.5	(选读) 为何 DSM 是去噪：SURE	47
3.3.6	(选读) 广义得分匹配	49
3.4	多噪声水平的去噪得分匹配 (NCSN)	51
3.4.1	动机	51
3.4.2	训练	51
3.4.3	采样	53
3.5	总结：NCSN 与 DDPM 的比较视角	55
3.6	结束语	56
第 4 章	当今的扩散模型：得分 SDE 框架	57
4.1	得分 SDE：原理	58
4.1.1	动机：从离散到连续时间过程	58
4.1.2	前向 SDE：从数据到噪声	60
4.1.3	用于生成的反向随机过程	62
4.1.4	用于生成的确定性过程 (概率流 ODE)	63
4.1.5	前向 / 反向 SDE 与 PF-ODE 的边缘分布匹配	65
4.1.6	可计算的例子：高斯动力学的演化	67
4.2	得分 SDE：训练与采样	71
4.2.1	训练	71
4.2.2	采样与推断	71
4.3	SDE 的具体实例	75
4.3.1	VE SDE	75

4.3.2	VP SDE	76
4.3.3	(选读) 如何推导扰动核?	76
4.4	(选读) 重新思考基于得分与变分扩散模型的前向核	79
4.4.1	一般仿射前向过程 $p_t(\mathbf{x}_t \mathbf{x}_0)$	79
4.4.2	与得分 SDE 的联系	80
4.4.3	与基于变分的扩散模型的联系	81
4.5	(选读) 通过边缘化与 Bayes 法则理解 Fokker-Planck 方程及反向 SDE	84
4.5.1	由转移核边缘化得到 Fokker-Planck 方程	84
4.5.2	反向 SDE 为何具有此形式?	85
4.6	结束语	88
第 5 章	基于流的视角：从归一化流到流匹配	89
5.1	基于流的模型：归一化流与神经常微分方程	90
5.1.1	归一化流	90
5.1.2	神经常微分方程	92
5.2	流匹配框架	96
5.2.1	从基于得分的方法得到的启示	96
5.2.2	流匹配框架	99
5.2.3	扩散模型、一般流匹配与 NODE 的比较	102
5.2.4	(选读) 基本规则	103
5.3	构造分布之间的概率路径与速度	106
5.3.1	一个关键特例：高斯到高斯的桥中的边缘密度 $p_t(\mathbf{x}_t)$ 与速度 $\mathbf{v}_t(\mathbf{x}_t)$	106
5.3.2	先构造条件概率路径的 $\mathbf{v}_t(\cdot \mathbf{z})$ 与 $p_t(\cdot \mathbf{z})$ 构造	108
5.3.3	先构造条件流的 $\mathbf{v}_t(\cdot \mathbf{z})$ 与 $p_t(\cdot \mathbf{z})$ 构造	111
5.3.4	先构造概率路径与先构造流的比较	113
5.4	(选读) 典范仿射流的性质	115
5.4.1	整流：从噪声猜测到结构化配对	115
5.4.2	Reflow：迭代拉直流	116
5.4.3	Reflow 的性质	117
5.5	结束语	120
第 6 章	扩散模型的统一系统视角	121
6.1	条件化技巧：扩散模型的秘诀	122
6.2	阐明扩散模型训练损失的路线图	124
6.2.1	扩散模型中四种常见参数化	124
6.2.2	解析扩散模型的训练目标	125
6.3	扩散模型中的等价性	128
6.3.1	四种预测类型等价	128
6.3.2	不同参数化下的 PF-ODE	129
6.3.3	所有仿射流等价	130
6.3.4	(选读) 参数化与典范流的概念分析	132

6.4	共同基础: Fokker-Planck 方程	137
6.4.1	基于流的方法与得分 SDE 的联系	138
6.5	结束语	140
第 7 章	(选读) 扩散模型与最优输运	141
7.1	分布到分布转换的序言	142
7.2	问题设置的分类	144
7.2.1	最优输运 (OT)	144
7.2.2	熵正则化最优输运 (EOT)	146
7.2.3	薛定谔桥 (SB)	148
7.2.4	全局推前与局部动力学: 深度生成模型的 OT 类比	152
7.3	最优输运各变体表述之间的关系	153
7.3.1	SB 与 EOT (对偶) 等价	153
7.3.2	当 $\varepsilon \rightarrow 0$ 时 EOT_ε 化为 OT	155
7.3.3	当 $\varepsilon \rightarrow 0$ 时 SB_ε 化为 OT	156
7.4	扩散模型的 SDE 是 SB 问题的最优解吗?	158
7.4.1	扩散模型作为薛定谔桥的特例	158
7.4.2	扩散模型作为薛定谔半桥	158
7.5	扩散模型的 ODE 是 OT 问题的最优映射吗?	161
7.5.1	PF-ODE 流通常不是最优输运	161
7.5.2	典范线性流与 Reflow 能产生 OT 映射吗?	164
第三部分	扩散模型的采样	167
第 8 章	引导与可控生成	169
8.1	序言	170
8.2	分类器引导	174
8.2.1	分类器引导的基础	174
8.2.2	使用 CG 推断	175
8.2.3	优势与局限	175
8.3	无分类器引导	176
8.3.1	无分类器引导的基础	176
8.3.2	CFG 的训练与采样	176
8.4	(选读) 无需训练的引导	178
8.4.1	无需训练的引导的概念框架	178
8.4.2	无需训练的逆问题求解方法举例	179
8.5	从强化学习到用于模型对齐的直接偏好优化	182
8.5.1	动机: 避开 RLHF 的困难	182
8.5.2	RLHF: Bradley-Terry 视角	182
8.5.3	DPO 框架	185
8.5.4	Diffusion-DPO	186

8.6	结语	190
第 9 章	用于快速采样的高效求解器	191
9.1	序言	192
9.1.1	扩散模型的先进求解器	192
9.1.2	文献中设计求解器的共同框架	193
9.1.3	PF-ODE 数值求解器的方法	195
9.2	DDIM	198
9.2.1	将 DDIM 解释为 ODE 求解器	198
9.2.2	不同参数化下 DDIM 的直观解释	199
9.2.3	(选读) DDIM 的变分视角	202
9.2.4	作为条件流匹配的 DDIM	206
9.3	DEIS	208
9.3.1	多项式外推	208
9.3.2	DEIS: 用 Lagrange 多项式近似 PF-ODE 积分	209
9.3.3	DDIM = AB-DEIS-0	212
9.4	DPM-Solver	214
9.4.1	DPM-Solver 的洞见: 通过对数 SNR 进行时间重参数化	214
9.4.2	通过 Taylor 展开估计积分	216
9.4.3	DPM-Solver- n 的实现	217
9.4.4	DDIM = DPM-Solver-1	220
9.4.5	DPM-Solver-2 与经典 Heun 更新的讨论	220
9.5	DPM-Solver++	224
9.5.1	从 DPM-Solver 到用于引导的 DPM-Solver++	224
9.5.2	DPM-Solver++ 的方法	224
9.5.3	通过 Taylor 展开实现 DPM-Solver++ 单步方法	225
9.5.4	通过复用历史实现 DPM-Solver++ 多步方法	225
9.6	PF-ODE 求解器家族及其数值对应	230
9.6.1	PF-ODE 求解器家族与经典对应方法	230
9.6.2	DEIS 与 DPM-Solver++ 的讨论	231
9.7	(选读) DPM-Solver-v3	232
9.7.1	洞见 1: 调整式 (9.4.5) 中的线性项	232
9.7.2	洞见 2: 在模型参数化中引入自由变量以进一步最小化离散化误差	233
9.7.3	结合两项洞见	235
9.7.4	高阶 DPM-Solver-v3	236
9.7.5	DPM-Solver-v3 的进一步解释	238
9.7.6	DPM-Solver-v3 与其他方法的联系	239
9.8	(选读) ParaDiGMS	240
9.8.1	从时间步进到时间并行求解器	240
9.8.2	ParaDiGMS 的方法	240
9.8.3	与时间步进求解器的关系	243

9.9 结束语	245
第四部分 迈向快速扩散生成器的学习	246
第 10 章 基于蒸馏的快速采样方法	247
10.1 引言	248
10.1.1 分布层面的蒸馏	248
10.1.2 流映射层面的蒸馏	249
10.2 基于分布的蒸馏	251
10.2.1 以 VSD 为代表的方法表述	251
10.2.2 VSD 的训练流程	252
10.2.3 补充讨论：散度选择与 VSD 的应用	253
10.3 渐进蒸馏	255
10.3.1 PD 中的蒸馏操作	256
10.3.2 PD 的完整训练流程及其采样	257
10.3.3 补充讨论：局部半群匹配与推广求解器的可能性	258
10.3.4 带引导的 PD	259
10.4 结束语	260
第 11 章 从头学习快速生成器	261
11.1 引言	262
11.2 特殊流映射：离散时间一致性模型	266
11.2.1 学习一致性函数的离散时间近似	267
11.2.2 使用一致性模型采样	271
11.3 特殊流映射：连续时间一致性模型	272
11.3.1 连续时间一致性模型	272
11.3.2 连续时间一致性模型的训练	273
11.3.3 （选读）连续时间一致性训练的实践考虑	275
11.4 一般流映射：一致性轨迹模型	279
11.4.1 用于灵活转移学习的 CTM 参数化	279
11.4.2 CTM 的一致性损失	281
11.4.3 CTM 的辅助损失	283
11.4.4 使用 CTM 灵活采样	285
11.5 一般流映射：平均流	288
11.5.1 平均流的建模与训练	288
11.5.2 平均流的采样	289
11.5.3 CTM 与 MF 的等价性	289
11.6 结束语	292
附录 A 微分方程速成	293
A.1 常微分方程基础	294

A.1.1	常微分方程的直观理解	294
A.1.2	常微分方程的存在性与唯一性	295
A.1.3	指数积分因子	297
A.1.4	常微分方程的数值求解器	299
A.2	随机微分方程基础	302
A.2.1	从常微分方程到随机微分方程：直观介绍	302
A.2.2	式 (A.2.3) 的进一步说明	303
A.2.3	随机微分方程的数值求解器	304
附录 B	密度演化：从变量替换到 Fokker–Planck 方程	305
B.1	变量替换公式： 从确定性映射到随机流	306
B.1.1	确定性映射的变量替换公式	307
B.1.2	连续时间极限：连续性方程	309
B.1.3	随机过程：Fokker–Planck 方程	312
B.2	连续性方程的直观理解	314
B.2.1	连续性方程的物理解释	314
B.2.2	从守恒定律推导连续性方程	315
附录 C	扩散模型的幕后原理： 伊藤微积分与 Girsanov 定理	316
C.1	伊藤公式：随机过程的链式法则	317
C.1.1	动机：为什么需要特殊的链式法则？	317
C.1.2	由 Taylor 展开推导一维伊藤公式	318
C.1.3	伊藤公式：SDE 的链式法则	319
C.1.4	伊藤公式的应用：推导 Fokker–Planck 方程	321
C.1.5	伊藤公式的应用：线性 SDE 的闭式解	321
C.2	测度的变量替换：扩散模型中的 Girsanov 定理	324
C.2.1	Girsanov 定理：连接似然训练与得分匹配	325
附录 D	补充材料与证明	327
D.1	变分视角	327
D.1.1	定理 2.2.1：边缘与条件 KL 最小化的等价性	327
D.1.2	定理 2.2.3：扩散模型的 ELBO	328
D.2	基于得分的视角	330
D.2.1	命题 3.2.1：通过分部积分实现可处理的得分匹配	330
D.2.2	定理 3.3.1：SM 与 DSM 最小化的等价性	331
D.2.3	引理 3.3.2：Tweedie 公式	332
D.2.4	Stein 恒等式与 SURE 替代目标	333
D.2.5	定理 4.1.1：通过 Fokker–Planck 方程实现边缘对齐	334
D.2.6	命题 4.2.1：SM 与 DSM 的极小化子	338

D.2.7 高斯分布得分函数的闭式表达	338
D.3 基于流的视角	340
D.3.1 引理 5.1.1: 瞬时变量替换	340
D.3.2 定理 5.2.2: 质量守恒判据	340
D.4 理论补充: 扩散模型的统一系统视角	343
D.4.1 命题 6.3.1: 参数化的等价性	343
D.5 理论补充: 学习基于扩散的快速生成器	344
D.5.1 知识蒸馏损失作为一般框架式 (10.1.4) 的特例	344
D.5.2 命题 10.2.1 的参数流解释	344
D.5.3 定理 11.2.1: CM 与 CT 相等至 $\mathcal{O}(\Delta s)$	345
D.5.4 命题 11.3.1: CT 梯度的连续时间极限	346
D.6 (选读) 阐明扩散模型 (EDM)	348
D.6.1 神经网络 $\mathbf{x}_\phi$ 的设计准则	348
D.6.2 常见的 EDM 特例: $\alpha_t = 1, \sigma_t = t$	350
参考文献	352
术语索引	364

前言与阅读路线

扩散模型迅速成为生成建模的核心范式，相关工作数量庞大，遍布机器学习、计算机视觉、自然语言处理等领域。这些文献分散在不同研究群体中，强调进展的不同方面：理论基础涉及建模原理、训练目标、采样器设计及其背后的数学思想；实现进展涵盖工程实践与架构选择；实际应用将模型适配于特定领域或任务；系统层面的优化则提高计算、存储与部署效率。

本专著旨在为扩散模型提供以原理为基础的理论根基，重点围绕以下核心主题展开：

- 我们介绍支撑扩散模型研究的基本概念与表述，为读者提供阅读更广泛文献所需的核心理解。我们并不综述所有变体或特定领域的应用，而是建立一个稳定的概念基础，使读者能够由此理解这些发展。
- 经典生成模型学习从噪声到数据的直接映射，而扩散模型将生成视为随时间逐渐变化的过程，从粗略结构逐步细化出精细细节。这一核心思想主要沿着变分、基于得分与基于流三种视角发展，它们为理解和实现扩散建模提供了互补方式。我们聚焦这些表述的核心原理与基础，旨在追溯关键思想的起源，厘清不同表述之间的关系，并形成连接直觉洞见与严格数学表述的连贯理解。
- 在这些基础上，我们考察如何进一步发展扩散模型，以更高效地生成样本、更充分地控制生成过程，并启发基于扩散原理的独立生成建模形式。

本专著面向对深度学习具有基本理解（例如了解神经网络是什么，以及训练如何进行），或者更具体地说，对深度生成建模具有基本理解，并希望超越表面认识、加深对扩散模型理解的研究者、研究生与实践者。阅读完毕后，读者将从原理层面掌握扩散建模的基础，能够在连贯框架中解释不同表述，并具备自信地应用现有模型、探索新研究方向所需的背景知识。

本专著的阅读路线

本专著系统地介绍扩散模型的基础，并追溯其背后的核心原理。

建议的阅读顺序。 我们建议按照本书的编排顺序阅读，以建立全面的理解。已经熟悉基础知识的读者可以跳过标记为可选的各节。例如，熟悉深度生成模型（DGM）的读者可以略过章 1 中的概述。同样，预先了解变分自编码器（节 2.1）、能量模型（节 3.1）或归

一化流（节 5.1）的读者，可以跳过相应的入门章节。其他可选部分更深入地讨论高级或专门主题，可按需要查阅。

本专著分为四个主要部分。

A 与 B 部分：扩散模型的基础。 这部分通过回顾塑造本领域的三个基础视角，追溯扩散模型的起源。图 2 给出了这一部分的概览。

A 部分：深度生成建模 (DGM) 导论。 我们首先在章 1 回顾深度生成建模的基本目标。从一组数据样本出发，目标是构建能够生成新样本的模型，使这些新样本看起来来自同一个通常未知的底层数据分布。许多方法通过学习数据的分布来实现这一目标：或者利用概率模型显式地表示分布，或者利用学得变换隐式地表示分布。随后，我们解释这些模型如何用神经网络表示数据分布，如何从样本中学习，以及如何生成新样本。本章最后对主要生成框架进行分类，突出它们的核心思想和关键区别。




图 1: 扩散模型各视角的时间线。同一组使用相同的颜色。

- 在章 2 中，变分自编码器 (VAE) (Kingma and Welling, 2013) → 扩散概率模型 (DPM) (Sohl-Dickstein et al., 2015) → DDPM (Ho, Jain, and Abbeel, 2020).
- 在章 3 和 4 中，能量模型 (EBM) (Ackley, Hinton, and Sejnowski, 1985) → 噪声条件得分网络 (NCSN) (Song and Ermon, 2019) → 得分 SDE (Song et al., 2020b).
- 在章 5 中，归一化流 (NF) (Rezende and Mohamed, 2015) → 神经 ODE (NODE) (Chen et al., 2018) → 流匹配 (FM) (Lipman et al., 2022).

B 部分：扩散模型的核心视角。 概述深度生成建模的一般目标和机制之后，我们转向扩散模型——通过从噪声到数据的渐进变换实现生成的一类方法。我们考察三个相互联系的框架；它们都具有逐渐添加噪声的前向过程，以及由一系列逐步去噪模型近似的时间反向过程：

- **变分视角** (章 2)：源于变分自编码器 (VAE) (Kingma and Welling, 2013)，它通过变分目标将扩散表述为学习去噪过程，由此产生去噪扩散概率模型 (DDPM) (Sohl-Dickstein et al., 2015; Ho, Jain, and Abbeel, 2020).
- **基于得分的视角** (章 3)：植根于能量模型 (EBM) (Ackley, Hinton, and Sejnowski, 1985)，并发展为噪声条件得分网络 (NCSN) (Song and Ermon, 2019)。它学习

得分函数，即数据对数密度的梯度，以指引如何逐渐去除样本中的噪声。在连续时间下，章 4 介绍得分 *SDE* 框架，用随机微分方程 (SDE) 描述去噪过程，并用常微分方程 (ODE) 描述其确定性对应过程。这一视角将扩散建模与经典微分方程理论联系起来，为分析和算法设计提供清晰的数学基础。

- **基于流的视角** (章 5)：以归一化流 (Rezende and Mohamed, 2015) 为基础，并由流匹配 (Lipman et al., 2022) 加以推广。这一视角将生成建模为连续变换，把来自简单先验的样本输运到数据分布。演化由速度场通过 ODE 控制，它显式地定义了概率质量如何随时间移动。基于流的表述自然地将先验到数据的生成推广到更一般的分布到分布的转换问题，即学习连接任意一对源分布与目标分布的流。

虽然这些视角初看起来有所不同，章 6 表明它们具有深刻联系。每一种视角都使用条件化策略，将学习目标转化为易于处理的回归问题。在更深层次上，它们都描述从先验到数据的相同概率分布时间演化。这一演化由 *Fokker-Planck* 方程支配，该方程可以视为密度在连续时间下的变量替换，从而保证随机表述与确定性表述的一致性。

由于扩散模型可以视为将一个分布输运到另一个分布的方法，章 7 进一步讨论它们与经典最优输运和薛定谔桥的联系；后者可以解释为带熵正则化的最优输运。我们回顾静态与动态表述，并解释它们与连续性方程及 *Fokker-Planck* 视角的关系。关注实践的读者可选读本章；希望深入研究这些联系的读者，则可从中获得严格的数学背景及经典文献线索。


C 与 D 部分：控制扩散采样并使其加速。 统一了基础原理之后，我们转向利用扩散模型高效生成的实际问题。从扩散模型中采样对应于求解微分方程，但这一过程通常计算成本高昂。C 与 D 部分通过改进采样方法和学习加速技术，着重提高生成质量、可控性与效率。

C 部分：从扩散模型中采样。 扩散模型的生成过程呈现出独特的由粗到细的细化特征：噪声被逐步去除，产生结构与细节越来越连贯的样本。这一性质也带来权衡。积极的一面是它提供精细控制：在学得的随时间变化的速度场中加入引导项，就可以使 ODE 流体现用户意图，从而让采样可控。消极的一面是，相比一次完成的生成器，迭代积分使采样较慢。本部分着重在推理时改进生成过程，无需重新训练。

- **引导生成** (章 8)：分类器引导和无分类器引导等技术，使生成过程能够以用户定义的目标或属性为条件。在此基础上，我们进一步讨论如何利用偏好数据集，使扩散模型更好地与这些偏好对齐。
- **利用数值求解器快速生成** (章 9)：先进的数值求解器能够用更少的步骤近似反向过程，在保持质量的同时降低成本，从而显著加速采样。

D 部分：学习快速生成模型。 除了改进现有采样算法，我们还研究如何直接学习近似扩散过程的快速生成器。

图 2: **B 部分：扩散模型的统一原理视角**. 此图直观地将经典生成建模方法——变分自编码器、能量模型和归一化流——与各自对应的扩散模型表述联系起来. 每一条竖直路径展示一个概念谱系，最终汇入连续时间框架. 三种视角（变分、基于得分、基于流）提供了不同但在数学上等价的解释.



- **基于蒸馏的方法** (章 10): 训练学生模型模仿预训练的慢速扩散模型 (教师) 的行为. 目标并不是缩小教师模型, 而是以远少于教师的积分步骤复现其采样轨迹或输出分布, 通常只需几步, 甚至一步.
- **从头学习** (章 11): 由于扩散模型采样可以视为求解 ODE, 这类方法不依赖教师模型, 而是从头直接学习解映射 (即流映射). 学得的映射能够直接将噪声转换为数据, 或更一般地, 在解轨迹上的任意时刻之间跳转.

附录. 为使所有读者都能跟随本书的讨论, 附录提供基础概念的背景知识. 章 A 对已成为扩散模型语言的微分方程进行速成介绍.

尽管扩散模型具有不同的视角与起源, 其背后的核心洞见在于变量替换公式. 这一基础自然地延伸到 *Fokker-Planck* 方程和连续性方程等更深刻的概念; 它们描述概率密度在函数 (离散时间) 或微分方程 (连续时间) 所定义的映射下如何变换和演化. 章 B 提供平易的介绍, 将这些基础思想与更高级的概念连接起来. 在章 C 中, 我们介绍扩散模型背后两个强大却常被忽视的工具: 伊藤公式和 *Girsanov* 定理; 它们为 *Fokker-Planck* 方程和时间反向采样过程提供严格依据. 最后, 章 D 汇集正文中选定命题与定理的证明.

本专著涵盖与不涵盖的内容. 我们的目标是使内容经得起时间考验. 从自上而下的视角看, 本专著从一条原理出发: 构造连续时间动力学, 将简单先验输运到数据分布, 并确保每个时刻的边缘分布都与预先指定的从数据到噪声的前向过程所诱导的边缘分布一致. 从这一原理出发, 我们发展用于采样的随机流与确定性流, 展示如何引导轨迹 (引导), 并解释如何加速轨迹 (数值求解器). 随后, 我们研究受扩散启发的快速生成器, 包括蒸馏方法与流映射模型. 有了这些工具, 读者就能够把新论文放入共同框架中, 理解方法为何有效, 并设计改进的模型.

我们不试图对扩散模型文献进行穷尽式综述, 也不罗列架构、训练实践和超参数, 不比较不同方法的实验结果, 不介绍数据集与排行榜, 不描述特定领域或模态的应用, 不涉及系统层面的部署, 不提供大规模训练的操作方案, 也不讨论硬件工程. 这些主题发展迅速, 专门综述、开放代码仓库和实现指南能够更好地覆盖它们.

符号说明

数与数组

a	标量.
$\mathbf{a}$	列向量 (例如 $\mathbf{a} \in \mathbb{R}^D$) .
$\mathbf{A}$	矩阵 (例如 $\mathbf{A} \in \mathbb{R}^{m \times n}$) .
$\mathbf{A}^\top$	$\mathbf{A}$ 的转置.
$\text{Tr}(\mathbf{A})$	$\mathbf{A}$ 的迹.
$\mathbf{I}_D$	$D \times D$ 单位矩阵.
$\mathbf{I}$	单位矩阵; 维度由上下文确定.
$\text{diag}(\mathbf{a})$	以 $\mathbf{a}$ 的分量为对角元素的对角矩阵.
ϕ, θ	可学习的神经网络参数.
$\phi^\times, \theta^\times$	训练后的参数 (推理时固定) .
ϕ^*, θ^*	优化问题的最优参数.

微积分

$\frac{\partial \mathbf{y}}{\partial \mathbf{x}}$	$\mathbf{y}$ 关于 $\mathbf{x}$ 的偏导数 (逐分量) .
$\frac{d\mathbf{y}}{d\mathbf{x}}$ 或 $D\mathbf{y}(\mathbf{x})$	$\mathbf{y}$ 关于 $\mathbf{x}$ 的全导数 (Fréchet 导数) .
$\nabla_{\mathbf{x}} y$	标量函数 $y: \mathbb{R}^D \rightarrow \mathbb{R}$ 的梯度; $\mathbb{R}^D$ 中的列向量.
$\frac{\partial \mathbf{F}}{\partial \mathbf{x}}$ 或 $\nabla_{\mathbf{x}} \mathbf{F}$	$\mathbf{F}: \mathbb{R}^n \rightarrow \mathbb{R}^m$ 的雅可比矩阵; 形状为 $m \times n$.
$\nabla \cdot \mathbf{y}$	向量场 $\mathbf{y}: \mathbb{R}^D \rightarrow \mathbb{R}^D$ 的散度; 一个标量.
$\nabla_{\mathbf{x}}^2 f(\mathbf{x})$ 或 $\mathbf{H}(f)(\mathbf{x})$	$f: \mathbb{R}^D \rightarrow \mathbb{R}$ 的 Hessian 矩阵; 形状为 $D \times D$.
$\int f(\mathbf{x}) d\mathbf{x}$	f 在 $\mathbf{x}$ 的定义域上的积分.

概率与信息论

$p(\mathbf{a})$	连续向量 $\mathbf{a}$ 上的密度 / 分布.
p_{data}	数据分布.
p_{prior}	先验分布 (例如标准正态分布) .
p_{src}	源分布.
p_{tgt}	目标分布.
$\mathbf{a} \sim p$	随机向量 $\mathbf{a}$ 服从分布 p .
$\mathbb{E}_{\mathbf{x} \sim p}[\mathbf{f}(\mathbf{x})]$	$p(\mathbf{x})$ 下 $\mathbf{f}(\mathbf{x})$ 的期望.
$\mathbb{E}[\mathbf{f}(\mathbf{x}) \mathbf{z}]$, 或 $\mathbb{E}_{\mathbf{x} \sim p(\cdot \mathbf{z})}[\mathbf{f}(\mathbf{x})]$	给定 $\mathbf{z}$ 时 $\mathbf{f}(\mathbf{x})$ 的条件期望, 其中 $\mathbf{x}$ 服从 $p(\cdot \mathbf{z})$.
$\text{Var}(\mathbf{f}(\mathbf{x}))$	$p(\mathbf{x})$ 下的方差.
$\text{Cov}(\mathbf{f}(\mathbf{x}), \mathbf{g}(\mathbf{x}))$	$p(\mathbf{x})$ 下的协方差.
$\mathcal{D}_{\text{KL}}(p\ q)$	从 q 到 p 的 Kullback–Leibler 散度.
$\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$	标准正态样本.
$\mathcal{N}(\mathbf{x}; \boldsymbol{\mu}, \boldsymbol{\Sigma})$	以 $\boldsymbol{\mu}$ 为均值、 $\boldsymbol{\Sigma}$ 为协方差的 $\mathbf{x}$ 上的高斯分布.

说明. 我们用同一个符号表示随机向量及其实现值. 这一约定在深度学习与生成建模中很常见, 使符号简洁而不繁杂. 具体含义由上下文决定.

例如, 在 $p(\mathbf{x})$ 等表达式中, 符号 $\mathbf{x}$ 充当哑变量, 表达式将分布或密度表示为输入的函数. 因此, $p(\mathbf{x})$ 指的是函数形式, 而不是在某个特定样本处求值. 当需要在给定点处求值时, 我们会明确说明 (例如, “在给定点 $\mathbf{x}$ 处计算 p 的值”).

条件表达式按照上下文理解. 对于 $p(\mathbf{x}|\mathbf{y})$, 固定 $\mathbf{y}$ 时, 它是关于 $\mathbf{x}$ 的密度; 固定 $\mathbf{x}$ 时, 它是关于 $\mathbf{y}$ 的函数.

对于条件期望, $\mathbb{E}[\mathbf{f}(\mathbf{x})|\mathbf{z}]$ 表示 $\mathbf{z}$ 的函数, 给出以 $\mathbf{z}$ 为条件时 $\mathbf{f}(\mathbf{x})$ 的期望. 当条件是某个具体的实现值时, 我们写作 $\mathbb{E}[\mathbf{f}(\mathbf{x})|\mathbf{Z} = \mathbf{z}]$. 等价地, 它可以写成关于条件分布的积分:

$$\mathbb{E}_{\mathbf{x} \sim p(\cdot|\mathbf{z})}[\mathbf{f}(\mathbf{x})] = \int \mathbf{f}(\mathbf{x}) p(\mathbf{x}|\mathbf{z}) d\mathbf{x}.$$

这一区分说明, $\mathbf{z}$ 究竟是定义函数 $\mathbf{z} \mapsto \mathbb{E}[\mathbf{f}(\mathbf{x})|\mathbf{z}]$ 的变量, 还是该函数求值时所使用的固定值.

第一部分

深度生成建模导论

第 1 章 深度生成建模

凡是我不能创造的，我就不理解。

Richard P. Feynman

深度生成模型（deep generative model）（DGM）是学习高维数据（例如图像、文本、音频）概率分布的神经网络，借此生成与数据集相似的新样本。用 p_ϕ 表示模型分布， p_{data} 表示数据分布。给定有限数据集，我们通过最小化衡量 p_ϕ 与 p_{data} 差距的损失来拟合 ϕ 。训练后，生成就是运行模型的采样过程，抽取 $\mathbf{x} \sim p_\phi$ （能否直接计算密度 $p_\phi(\mathbf{x})$ 取决于模型类别）。模型质量通过生成样本及其汇总统计量与 p_{data} 的吻合程度，并结合任务特定指标或感知指标来评价。

本章建立这些思想的数学和概念基础。我们在节 1.1 将问题形式化，在节 1.2 介绍代表性模型类别，在节 1.3 总结实用分类体系。

1.1 什么是深度生成建模？

DGM 输入从未知而复杂的分布 p_{data} 抽取的大量现实世界样本（例如图像、文本），输出参数化近似分布 p_{ϕ} 的已训练神经网络。目标有两个：

1. **逼真生成**：生成新颖、逼真且无法与真实数据区分的样本。
2. **可控生成**：实现对生成过程细致且可解释的控制。

本节介绍 DGM 的基本概念和动机，为详细探索其数学框架和实际应用作准备。

1.1.1 数学设定

我们假设可以获得从潜在的复杂数据分布 $p_{\text{data}}(\mathbf{x})$ 独立同分布 (i.i.d.) 抽取的有限个样本¹。

DGM 的目标。 DGM 的主要目标是从有限数据集学习一个易于处理的概率分布。这些数据点是观测，假设采样自未知而复杂的真实分布 $p_{\text{data}}(\mathbf{x})$ 。由于 $p_{\text{data}}(\mathbf{x})$ 的形式未知，无法直接从中抽取新样本。因此，核心挑战是建立足够准确地逼近这一分布的模型，以生成新的逼真样本。

为此，DGM 用深度神经网络参数化模型分布 $p_{\phi}(\mathbf{x})$ ，其中 ϕ 是网络的可训练参数。训练目标是寻找最优参数 ϕ^* ，最小化模型分布 $p_{\phi}(\mathbf{x})$ 与真实数据分布 $p_{\text{data}}(\mathbf{x})$ 之间的散度。从概念上说，

$$p_{\phi^*}(\mathbf{x}) \approx p_{\text{data}}(\mathbf{x}).$$

当统计模型 $p_{\phi^*}(\mathbf{x})$ 很好地逼近数据分布 $p_{\text{data}}(\mathbf{x})$ 时，它可以作为生成新样本和计算概率值的替代模型。这种模型 $p_{\phi}(\mathbf{x})$ 通常称为生成模型。

DGM 的能力。 一旦得到数据分布的替代模型 $p_{\phi}(\mathbf{x})$ ，就可以用从 $p_{\phi}(\mathbf{x})$ 进行蒙特卡罗采样等方法生成任意数量的新数据点。此外，还可通过计算 $p_{\phi}(\mathbf{x}')$ ，获得任意给定数据样本 $\mathbf{x}'$ 的概率（或似然）。

DGM 的训练。 通过最小化差异 $\mathcal{D}(p_{\text{data}}, p_{\phi})$ ，学习模型族 $\{p_{\phi}\}$ 的参数 ϕ ：

$$\phi^* \in \arg \min_{\phi} \mathcal{D}(p_{\text{data}}, p_{\phi}). \quad (1.1.1)$$

由于 p_{data} 未知，实用的 $\mathcal{D}$ 必须能够用来自 p_{data} 的独立同分布样本高效估计。模型容量足够大时， p_{ϕ^*} 可很好地逼近 p_{data} 。

¹这是机器学习中的常见假设。为简洁起见，根据上下文用符号 p 表示概率分布或其概率密度 / 质量函数。




图 1.1: **DGM 目标示意图**. 训练 DGM 本质上是 minimize 模型分布 p_ϕ 与未知数据分布 p_{data} 之间的差异. 由于不能直接访问 p_{data} , 必须利用从中抽取的有限个独立同分布 (i.i.d.) 样本 $\mathbf{x}_i$ 高效估计这一差异.

前向 KL 与最大似然估计 (MLE). 标准选择是 (前向) Kullback–Leibler 散度 (Kullback–Leibler divergence)²:

$$\begin{aligned}\mathcal{D}_{\text{KL}}(p_{\text{data}} \| p_\phi) &:= \int p_{\text{data}}(\mathbf{x}) \log \frac{p_{\text{data}}(\mathbf{x})}{p_\phi(\mathbf{x})} d\mathbf{x} \\ &= \mathbb{E}_{\mathbf{x} \sim p_{\text{data}}} [\log p_{\text{data}}(\mathbf{x}) - \log p_\phi(\mathbf{x})].\end{aligned}$$

它是不对称的, 即

$$\mathcal{D}_{\text{KL}}(p_{\text{data}} \| p_\phi) \neq \mathcal{D}_{\text{KL}}(p_\phi \| p_{\text{data}}).$$

尤其是, 最小化 $\mathcal{D}_{\text{KL}}(p_{\text{data}} \| p_\phi)$ 鼓励覆盖模态: 若存在正测度集合 A , 满足 $p_{\text{data}}(A) > 0$, 但对 $\mathbf{x} \in A$ 有 $p_\phi(\mathbf{x}) = 0$, 则被积函数在 A 上包含 $\log(p_{\text{data}}(\mathbf{x})/0) = +\infty$, 所以 $\mathcal{D}_{\text{KL}} = +\infty$. 因此最小化前向 KL 迫使模型在数据具有支撑之处赋予概率. 虽然无法显式计算数据密度 $p_{\text{data}}(\mathbf{x})$, 前向 KL 散度仍可分解为

$$\begin{aligned}\mathcal{D}_{\text{KL}}(p_{\text{data}} \| p_\phi) &= \mathbb{E}_{\mathbf{x} \sim p_{\text{data}}} \left[\log \frac{p_{\text{data}}(\mathbf{x})}{p_\phi(\mathbf{x})} \right] \\ &= -\mathbb{E}_{\mathbf{x} \sim p_{\text{data}}} [\log p_\phi(\mathbf{x})] + \mathcal{H}(p_{\text{data}}),\end{aligned}$$

其中 $\mathcal{H}(p_{\text{data}}) := -\mathbb{E}_{\mathbf{x} \sim p_{\text{data}}} [\log p_{\text{data}}(\mathbf{x})]$ 是数据分布的熵, 相对于 ϕ 为常数. 这给出以下等价关系:

引理 1.1.1: 最小化 KL $\Leftrightarrow$ MLE

$$\min_{\phi} \mathcal{D}_{\text{KL}}(p_{\text{data}} \| p_\phi) \iff \max_{\phi} \mathbb{E}_{\mathbf{x} \sim p_{\text{data}}} [\log p_\phi(\mathbf{x})]. \quad (1.1.2)$$

²所有积分均按 Lebesgue 意义理解; 在计数测度下退化为求和.

换言之，最小化前向 KL 散度等价于进行 MLE. 实践中用独立同分布样本 $\{\mathbf{x}^{(i)}\}_{i=1}^N \sim p_{\text{data}}$ 的蒙特卡洛估计替代总体期望，得到经验 MLE 目标

$$\hat{\mathcal{L}}_{\text{MLE}}(\phi) := -\frac{1}{N} \sum_{i=1}^N \log p_{\phi}(\mathbf{x}^{(i)}),$$

并用小批量随机梯度优化；不需要计算 $p_{\text{data}}(\mathbf{x})$.

Fisher 散度. Fisher 散度是（基于得分的）扩散建模的另一重要概念（见章 3）. 对分布 p 和 q ，其定义为

$$\mathcal{D}_{\text{F}}(p\|q) := \mathbb{E}_{\mathbf{x} \sim p} [\|\nabla_{\mathbf{x}} \log p(\mathbf{x}) - \nabla_{\mathbf{x}} \log q(\mathbf{x})\|_2^2]. \quad (1.1.3)$$

它衡量得分函数（*score function*） $\nabla_{\mathbf{x}} \log p(\mathbf{x})$ 和 $\nabla_{\mathbf{x}} \log q(\mathbf{x})$ 的差异，这些函数是指向较高概率区域的向量场. 简言之， $\mathcal{D}_{\text{F}}(p\|q) \geq 0$ ，等号成立当且仅当 $p = q$ 几乎处处成立. 它不受归一化常数影响，因为得分仅依赖对数密度的梯度；它是得分匹配（*score matching*）（式 (3.1.3) 和 (3.2.1)）的基础，这是一种学习对数密度梯度用于生成的方法（基于得分的模型）. 在此设定中，数据分布 $p = p_{\text{data}}$ 是目标，模型 $q = p_{\phi}$ 通过训练使其得分场与数据的得分场对齐.

KL 以外的度量. 虽然 KL 散度是衡量概率分布差异最常用的度量，却非唯一选择. 不同散度刻画不同的几何或统计差异概念，进而影响学习算法的优化动力学. 一个广泛的族是 f 散度 (Csiszár, 1963):

$$\mathcal{D}_f(p\|q) = \int q(\mathbf{x}) f\left(\frac{p(\mathbf{x})}{q(\mathbf{x})}\right) d\mathbf{x}, \quad f(1) = 0, \quad (1.1.4)$$

其中 $f: \mathbb{R}_+ \rightarrow \mathbb{R}$ 是凸函数. 改变 f 得到许多熟知散度:

$$\begin{aligned} f(u) &= u \log u & \Rightarrow & \mathcal{D}_f = \mathcal{D}_{\text{KL}}(p\|q) \quad (\text{前向 KL}), \\ f(u) &= \frac{1}{2} [u \log u - (u+1) \log \frac{1+u}{2}] & \Rightarrow & \mathcal{D}_f = \mathcal{D}_{\text{JS}}(p\|q) \quad (\text{Jensen-Shannon}), \\ f(u) &= \frac{1}{2} |u - 1| & \Rightarrow & \mathcal{D}_f = \mathcal{D}_{\text{TV}}(p, q) \quad (\text{全变差}). \end{aligned}$$

为清晰起见，显式形式为

$$\mathcal{D}_{\text{JS}}(p\|q) = \frac{1}{2} \mathcal{D}_{\text{KL}}(p\|\frac{1}{2}(p+q)) + \frac{1}{2} \mathcal{D}_{\text{KL}}(q\|\frac{1}{2}(p+q)),$$

以及

$$\mathcal{D}_{\text{TV}}(p, q) = \frac{1}{2} \int_{\mathbb{R}^D} |p - q| d\mathbf{x} = \sup_{A \subseteq \mathbb{R}^D} |p(A) - q(A)|.$$

直观上，JS 散度提供平滑而对称的度量，兼顾两个分布，避免 KL 的无界惩罚（后文将看到它有助于解释生成对抗网络（GAN）框架）；全变差距离则刻画两者可能出现的最大概率差. 另一观点来自最优输运（见章 7），其代表是 Wasserstein 距离（见. 它衡量将概率质量从一个分布移到另一个分布的最小代价. 与比较密度比的 f 散度不同，Wasserstein 距离依赖样本空间的几何，即使 p 和 q 的支撑不相交仍有意义. 每种散度体现了分布接近程度的不同概念，因而带来不同学习行为. 本书中，当这些散度自然出现在生成建模的语境下时，我们将再讨论它们.

1.1.2 分布建模的挑战

为建模复杂数据分布，可用参数为 ϕ 的神经网络参数化概率密度函数 p_{data} ，得到记为 p_ϕ 的模型。为使 p_ϕ 为有效概率密度，必须满足两个基本性质：

(i) **非负性**：对定义域中所有 $\mathbf{x}$ ， $p_\phi(\mathbf{x}) \geq 0$ 。

(ii) **归一化**：在整个定义域的积分等于一，即 $\int p_\phi(\mathbf{x}) d\mathbf{x} = 1$ 。

网络可自然地为输入 $\mathbf{x}$ 产生实标量 $E_\phi(\mathbf{x}) \in \mathbb{R}$ 。要将输出解释为有效密度，必须变换它以满足 (i) 和 (ii)。实用的另一思路是将 $E_\phi: \mathbb{R}^D \rightarrow \mathbb{R}$ 视为定义未归一化密度，再显式强制这些性质。

步骤 1：确保非负性。 对神经网络的原始输出 $E_\phi(\mathbf{x})$ 施加正函数，例如 $|E_\phi(\mathbf{x})|$ 或 $E_\phi^2(\mathbf{x})$ ，可保证模型输出总为非负。标准且方便的选择是指数函数。这给出保证为正的未归一化密度 $\tilde{p}_\phi(\mathbf{x})$ ：

$$\tilde{p}_\phi(\mathbf{x}) = \exp(E_\phi(\mathbf{x})).$$

步骤 2：强制归一化。 函数 $\tilde{p}_\phi(\mathbf{x})$ 为正，但积分不等于一。要构造有效概率密度，必须除以它在整个空间的积分。由此得到模型最终形式：

$$p_\phi(\mathbf{x}) = \frac{\tilde{p}_\phi(\mathbf{x})}{\int \tilde{p}_\phi(\mathbf{x}') d\mathbf{x}'} = \frac{\exp(E_\phi(\mathbf{x}))}{\int \exp(E_\phi(\mathbf{x}')) d\mathbf{x}'}.$$

分母称为归一化常数或配分函数，记作 $Z(\phi)$ ：

$$Z(\phi) := \int \exp(E_\phi(\mathbf{x}')) d\mathbf{x}'.$$

虽然这一过程有效构造了 $p_\phi(\mathbf{x})$ ，却引入重大计算挑战。对大多数高维问题，计算归一化常数 $Z(\phi)$ 所需积分难以处理。这正是推动发展多种深度生成模型家族的核心问题。下文介绍 DGM 的若干主要方法。每种方法都旨在绕开归一化常数的计算，或降低其计算成本。




图 1.2: 主要深度生成模型的计算图. 从上到下: **EBM** 将输入 $\mathbf{x}$ 映射为标量能量; **AR** 按因果依赖从左到右生成序列 $\{\mathbf{x}_\ell\}$; **VAE** 将 $\mathbf{x}$ 编码为潜变量 $\mathbf{z}$, 再解码为重构 $\mathbf{x}'$; **NF** 在 $\mathbf{x}$ 和 $\mathbf{z}$ 间施加可逆映射 $\mathbf{f}_\phi$, 并用 $\mathbf{f}_\phi^{-1}$ 产生 $\mathbf{x}'$; **GAN** 将噪声 $\mathbf{z}$ 变换为样本 $\mathbf{x}'$, 由判别器 D_ζ 将它与真实 $\mathbf{x}$ 比较; **DM** 通过多步去噪链 $\{\mathbf{x}_\ell\}$ 迭代细化含噪样本. 方框表示变量, 梯形表示可学习网络, 椭圆表示标量; 箭头表示计算流向.

1.2 主要的深度生成模型

生成建模的核心挑战是学习富有表达能力的概率模型，以刻画高维数据丰富而复杂的结构。多年来出现了各种建模策略，在可处理性、表达能力和训练效率之间作出不同权衡。本节探索塑造这一领域的一些最有影响力的策略，并在图 1.2 比较其计算图。

能量模型 (EBM)。EBM (Ackley, Hinton, and Sejnowski, 1985; LeCun et al., 2006) 通过能量函数 $E_\phi(\mathbf{x})$ 定义概率分布，为概率较高的数据点赋予较低能量。数据点的概率定义为

$$p_\phi(\mathbf{x}) := \frac{1}{Z(\phi)} \exp(-E_\phi(\mathbf{x})),$$

其中

$$Z(\phi) = \int \exp(-E_\phi(\mathbf{x})) d\mathbf{x}$$

是配分函数。训练 EBM 通常最大化数据对数似然。然而，这需要技术来解决配分函数难以处理所导致的计算挑战。后续章节将探索扩散模型提供的另一途径：利用对数密度的梯度生成数据。梯度不依赖归一化常数，因而绕开配分函数计算。

自回归模型。深度自回归 (AR) 模型 (Frey, Hinton, and Dayan, 1995; Larochelle and Murray, 2011; Uria et al., 2016) 用概率的链式法则将联合数据分布 p_{data} 分解为条件概率乘积：

$$p_{\text{data}}(\mathbf{x}) = \prod_{i=1}^D p_\phi(x_i | \mathbf{x}_{<i}),$$

其中 $\mathbf{x} = (x_1, \dots, x_D)$, $\mathbf{x}_{<i} = (x_1, \dots, x_{i-1})$ 。每个条件分布 $p_\phi(x_i | \mathbf{x}_{<i})$ 由 Transformer 等神经网络参数化，可灵活建模复杂依赖。每一项在设计上已归一化（如离散变量使用 softmax，连续变量使用参数化高斯分布），所以整体归一化很简单。训练通过最大化精确似然，或等价地最小化负对数似然进行，虽然 AR 模型具有很强的密度估计能力并提供精确似然，其顺序性质限制采样速度，固定顺序也可能限制灵活性。尽管如此，它们仍是基于似然的生成模型的基础类别和现代研究的关键方法。

变分自编码器 (VAE)。VAE (Kingma and Welling, 2013) 引入潜变量 $\mathbf{z}$ 以刻画数据 $\mathbf{x}$ 的隐藏结构，扩展经典自编码器。它不直接学习 $\mathbf{x}$ 与 $\mathbf{z}$ 间的映射，而采用概率观点：同时学习编码器 $q_\theta(\mathbf{z} | \mathbf{x})$ ，逼近给定数据时未知的潜变量分布，以及解码器 $p_\phi(\mathbf{x} | \mathbf{z})$ ，从潜变量重构数据。为使训练可行，VAE 最大化真实对数似然的易于处理的替代目标，即证据下界 (ELBO)：

$$\mathcal{L}_{\text{ELBO}}(\theta, \phi; \mathbf{x}) = \mathbb{E}_{q_\theta(\mathbf{z} | \mathbf{x})} [\log p_\phi(\mathbf{x} | \mathbf{z})] - \mathcal{D}_{\text{KL}}(q_\theta(\mathbf{z} | \mathbf{x}) \parallel p_{\text{prior}}(\mathbf{z})).$$

第一项鼓励准确重构数据；第二项使潜变量接近简单先验分布 $p_{\text{prior}}(\mathbf{z})$ （通常为高斯分布），从而起正则化作用。VAE 为结合神经网络与潜变量模型提供有原则的方法，仍是应用最广泛的基于似然的方法之一。但它也有实际挑战，如样本清晰度有限和训练病态现象（例如编码器倾向于忽略潜变量）。尽管有这些局限，VAE 为包括扩散模型的后续进展奠定重要基础。

归一化流。 经典基于流的模型，如归一化流（NF）（Rezende and Mohamed, 2015）和神经常微分方程（NODE）（Chen et al., 2018），旨在用可逆算子学习简单潜在分布 $\mathbf{z}$ 与复杂数据分布 $\mathbf{x}$ 间的双射映射 $\mathbf{f}_\phi$ 。NF 用一系列双射变换实现它，NODE 则将变换建模为常微分方程。这些模型利用“密度的变量替换公式”进行 MLE 训练：

$$\log p_\phi(\mathbf{x}) = \log p(\mathbf{z}) + \log \left| \det \frac{\partial \mathbf{f}_\phi^{-1}(\mathbf{x})}{\partial \mathbf{z}} \right|,$$

其中 $\mathbf{f}_\phi$ 是将 $\mathbf{z}$ 映射至 $\mathbf{x}$ 的可逆变换。NF 用雅可比行列式易于计算的可逆变换显式建模归一化密度。归一化常数经变量替换公式在解析上被吸收，使似然计算精确且易于处理。尽管概念优雅，经典基于流的模型往往有实际限制。例如 NF 为确保双射性通常施加严格架构约束，NODE 可能因求解 ODE 的开销而训练低效。两者扩展到高维数据均面临挑战。后续章节将探索扩散模型与这些经典方法的联系及如何在基础上发展。

生成对抗网络（GAN）。 GAN (Goodfellow et al., 2014) 由相互竞争的两个神经网络——生成器 $\mathbf{G}_\phi$ 和判别器 D_ζ ——组成。生成器旨在从随机噪声 $\mathbf{z} \sim p_{\text{prior}}$ 产生逼真样本 $\mathbf{G}_\phi(\mathbf{z})$ ；判别器试图区分真实样本 $\mathbf{x}$ 与生成样本 $\mathbf{G}_\phi(\mathbf{z})$ 。目标函数可写为

$$\min_{\mathbf{G}_\phi} \max_{D_\zeta} \underbrace{\mathbb{E}_{\mathbf{x} \sim p_{\text{data}}(\mathbf{x})} [\log D_\zeta(\mathbf{x})]}_{\text{真实}} + \underbrace{\mathbb{E}_{\mathbf{z} \sim p_{\text{prior}}(\mathbf{z})} [\log(1 - D_\zeta(\mathbf{G}_\phi(\mathbf{z})))]}_{\text{生成}}.$$

GAN 不定义显式密度，完全绕开似然估计。它们不计算归一化常数，而专注生成紧密模仿数据分布的样本。从散度角度，判别器隐式衡量真实数据分布 p_{data} 与生成器分布 $p_{\mathbf{G}_\phi}$ 的差异； $p_{\mathbf{G}_\phi}$ 是噪声 $\mathbf{z} \sim p_{\text{prior}}$ 所得到生成样本 $\mathbf{G}_\phi(\mathbf{z})$ 的分布。对固定生成器 $\mathbf{G}_\phi$ ，最优判别器为

$$\frac{p_{\text{data}}(\mathbf{x})}{p_{\text{data}}(\mathbf{x}) + p_{\mathbf{G}_\phi}(\mathbf{x})},$$

生成器的最小化问题化为

$$\min_{\mathbf{G}_\phi} 2 \mathcal{D}_{\text{JS}}(p_{\text{data}} \parallel p_{\mathbf{G}_\phi}) - \log 4.$$

这里 $\mathcal{D}_{\text{JS}}$ 表示 Jensen–Shannon 散度，定义为

$$\mathcal{D}_{\text{JS}}(p \parallel q) := \frac{1}{2} \mathcal{D}_{\text{KL}}(p \parallel \frac{p+q}{2}) + \frac{1}{2} \mathcal{D}_{\text{KL}}(q \parallel \frac{p+q}{2}).$$

这表明 GAN 隐式最小化 $\mathcal{D}_{\text{JS}}(p_{\text{data}} \parallel p_{\mathbf{G}_\phi})$ 。更一般地， f -GAN (Nowozin, Cseke, and Tomioka, 2016) 等扩展说明对抗训练能最小化一族 f 散度，推广这一观点，将 GAN 纳入与其他生成模型相同的散度最小化框架。虽然 GAN 可生成高质量数据，其极小极大训练过程却以不稳定著称，往往需要精心设计的架构和工程技术才能达到满意表现。但此后 GAN 作为辅助组件重新受到重视，用以增强其他生成模型，尤其是扩散模型。

1.3 建模方法的分类

如上所见，DGM 覆盖广泛的建模策略。基本区别在于它们如何参数化潜在数据分布，即显式指定 $p_\phi(\mathbf{x})$ ，还是仅隐式指定它，与训练目标无关。

- **显式模型**：通过易于处理或近似易于处理的密度 / 质量函数，直接参数化概率分布 $p_\phi(\mathbf{x})$ 。如 AR、NF、VAE、DM，均精确定义 $p_\phi(\mathbf{x})$ ，或通过易于处理的界定义它。
- **隐式模型**：仅通过采样过程指定分布，通常形如 $\mathbf{x} = \mathbf{G}_\phi(\mathbf{z})$ ，其中噪声变量 $\mathbf{z} \sim p_{\text{prior}}$ 。此时 $p_\phi(\mathbf{x})$ 无闭式表达，甚至可能根本未定义。

表 1.1 简要总结了这些不同方法。

表 1.1: 显式与隐式生成模型的比较

	显式		隐式
	精确似然	近似似然	
似然	易于处理	界 / 近似	不直接建模 / 难以处理
目标	MLE	ELBO	对抗训练
例子	NF、AR	VAE、DM	GAN

与扩散模型的联系。 综合来看，这些经典 DGM 家族展示了建模复杂分布的互补策略。它们自身重要，也为理解扩散模型提供指导原则。扩散方法继承多种观点：通过变分训练目标联系 VAE，通过学习对数密度梯度（与能量函数紧密相关）的得分匹配方法联系 EBM，通过连续时间变换联系 NF。为后文的扩散方法奠定基础，我们将重点关注三个核心范式：VAE（节 2.1）、EBM（节 3.1）和 NF（节 5.1）。这一探索为现代基于扩散的生成建模的核心原理奠定基础，后续章节将进一步发展它们。

1.4 结束语

本章建立深度生成建模的基本概念。首先定义主要目标：学习易于处理的模型分布 p_{model} （由 ϕ 参数化），以逼近未知、复杂的数据分布 p_{data} 。核心挑战是归一化常数，即定义有效概率密度所需的配分函数 $Z(\phi)$ 难以计算。为绕开此问题，人们发展了多种深度生成模型家族，各有策略。我们概述能量模型（EBM）、自回归模型（AR）、变分自编码器（VAE）、归一化流（NF）和生成对抗网络（GAN）等主要方法。大体可分为定义易于处理密度的显式模型，以及仅通过采样过程定义分布的隐式模型。这些经典框架都很重要，其中三个尤其是本书重点讨论的扩散模型的概念起源：VAE、EBM 和 NF。后文将从三个基础范式追溯扩散模型的发展：


1. B 部分先探索变分视角（章 2），说明 VAE（的层级潜变量结构）如何自然导向去噪扩散概率模型（DDPM）。
2. 接着考察基于得分的视角（章 3），它源于 EBM 和得分匹配，发展为噪声条件得分网络（NCSN）和更一般的得分 SDE 框架（章 4）。
3. 最后研究基于流的视角（章 5），它建立在归一化流原理上，将生成表述为连续变换，再由流匹配概念推广。

理解这些起源，我们将建立连贯框架解释扩散模型的不同表述，揭示统一它们的深层原理。

第二部分

扩散模型的起源与基础

深度生成建模概览：第 1 章



第 2 章 变分视角：从 VAE 到 DDPM

本章从变分视角考察扩散模型。我们从变分自编码器 (variational autoencoder) (VAE) 开始，它用潜变量表示数据，通过最大化对数似然的一个易于处理的下界进行训练。在这一设定中，学得的编码器将观测映射到潜变量，学得的解码器将潜变量映射回观测，从而闭合建模循环。

在此模式上，层级变体 (层级 VAE) 堆叠多个潜变量层，以刻画多个尺度的结构。去噪扩散概率模型 (denoising diffusion probabilistic model) (DDPM) 遵循同一模板：编码器与解码器不再联合训练，而是将编码器固定为逐渐把数据映射为噪声的前向加噪过程，并通过训练学习解码器，以连续的去噪步骤反转这一路径。从这一视角看，VAE、层级 VAE 和扩散模型都优化由变分界定义的似然替代目标，为本章方法提供共同基础。

2.1 变分自编码器

神经网络如何学习生成逼真数据？自然的起点是自编码器，它由两个网络组成：确定性编码器将输入压缩为低维潜在编码，确定性解码器从编码重构输入。训练最小化原始输入与重构之间的误差。虽然能够准确重构，潜在空间却缺乏结构：随机采样潜在编码通常得到无意义的输出，限制了模型的生成用途。

变分自编码器（VAE）(Kingma and Welling, 2013) 通过为潜在空间施加概率结构解决这一问题，将模型从简单重构工具变为真正的生成模型，能够产生新颖、逼真的数据。

2.1.1 概率编码器和解码器




图 2.1: **VAE 示意图**. 它由随机编码器 $q_{\theta}(\mathbf{z}|\mathbf{x})$ 和解码器 $p_{\phi}(\mathbf{x}|\mathbf{z})$ 组成，前者将数据 $\mathbf{x}$ 映射为潜变量 $\mathbf{z}$ ，后者从潜变量重构数据。

解码器（生成器）的构造. VAE 区分两类变量：观测变量 $\mathbf{x}$ 对应所见数据（例如图像），潜变量 $\mathbf{z}$ 则刻画隐藏的变化因素（如物体形状、颜色、风格）。模型假设每个观测 $\mathbf{x}$ 都由从简单先验分布采样的潜变量生成，通常为标准高斯分布， $\mathbf{z} \sim p_{\text{prior}} := \mathcal{N}(\mathbf{0}, \mathbf{I})$ 。

为将 $\mathbf{z}$ 映射回数据空间，定义解码器（生成器）分布 $p_{\phi}(\mathbf{x}|\mathbf{z})$ 。实践中保持解码器简单，常用因子化高斯分布（见节 2.1.3）或类似分布，使学习聚焦提取有用的潜在特征而非记忆数据。直观上，直接逐个生成像素极其困难；潜变量提供紧凑表示，使解码精确像素排列容易得多。生成新样本时先采样 $\mathbf{z} \sim p_{\text{prior}}$ ，再解码 $\mathbf{x} \sim p_{\phi}(\mathbf{x}|\mathbf{z})$ 。

因此，VAE 通过边缘似然定义潜变量生成模型：

$$p_{\phi}(\mathbf{x}) = \int p_{\phi}(\mathbf{x}|\mathbf{z})p(\mathbf{z}) d\mathbf{z}.$$

理想情况下，解码器参数 ϕ 应像最大似然估计（见式 (1.1.2)）那样通过最大化边缘似然学习。但对富有表达能力的非线性解码器，关于 $\mathbf{z}$ 的积分难以处理，直接 MLE 在计算上不可行，这促使 VAE 采用变分方法。

编码器（推断网络）的构造. 为将难以处理的生成器与真实数据连接，考虑反向问题：给定观测 $\mathbf{x}$ ，哪些潜在编码 $\mathbf{z}$ 可能生成它？由 Bayes 法则，后验分布为

$$p_{\phi}(\mathbf{z}|\mathbf{x}) = \frac{p_{\phi}(\mathbf{x}|\mathbf{z})p(\mathbf{z})}{p_{\phi}(\mathbf{x})}.$$

困难在于分母包含边缘似然 $p_\phi(\mathbf{x})$ ，它需要对所有潜变量积分，对非线性解码器难以处理。因此从 $\mathbf{x}$ 精确推断 $\mathbf{z}$ 的计算代价高得不可接受。

VAE 的“变分”步骤通过易于处理的近似替代难以处理的后验。引入神经网络参数化的编码器（或推断网络） $q_\theta(\mathbf{z}|\mathbf{x})$ ，作为可学习的替代：

$$q_\theta(\mathbf{z}|\mathbf{x}) \approx p_\phi(\mathbf{z}|\mathbf{x}).$$

实践中，编码器将每个观测数据点 $\mathbf{x}$ 映射为潜在编码上的分布，提供从 $\mathbf{x}$ 回到 $\mathbf{z}$ 的可行、可训练路径，使学习成为可能。

2.1.2 通过证据下界 (ELBO) 训练

现在定义可计算的训练目标。虽然无法直接优化 $\log p_\phi(\mathbf{x})$ ，却能最大化其下界，即证据下界 (*evidence lower bound*) (ELBO)：

定理 2.1.1: 证据下界 (ELBO)

对任意数据点 $\mathbf{x}$ ，对数似然满足：

$$\log p_\phi(\mathbf{x}) \geq \mathcal{L}_{\text{ELBO}}(\boldsymbol{\theta}, \boldsymbol{\phi}; \mathbf{x}),$$

其中 ELBO 为

$$\mathcal{L}_{\text{ELBO}} = \underbrace{\mathbb{E}_{\mathbf{z} \sim q_\theta(\mathbf{z}|\mathbf{x})} [\log p_\phi(\mathbf{x}|\mathbf{z})]}_{\text{重构项}} - \underbrace{\mathcal{D}_{\text{KL}}(q_\theta(\mathbf{z}|\mathbf{x}) \| p(\mathbf{z}))}_{\text{潜变量正则化}}. \quad (2.1.1)$$

定理的证明。

ELBO 来自 Jensen 不等式：

$$\begin{aligned} \log p_\phi(\mathbf{x}) &= \log \int p_\phi(\mathbf{x}, \mathbf{z}) d\mathbf{z} = \log \int q_\theta(\mathbf{z}|\mathbf{x}) \frac{p_\phi(\mathbf{x}, \mathbf{z})}{q_\theta(\mathbf{z}|\mathbf{x})} d\mathbf{z} \\ &= \log \mathbb{E}_{\mathbf{z} \sim q_\theta(\mathbf{z}|\mathbf{x})} \left[\frac{p_\phi(\mathbf{x}, \mathbf{z})}{q_\theta(\mathbf{z}|\mathbf{x})} \right] \geq \mathbb{E}_{\mathbf{z} \sim q_\theta(\mathbf{z}|\mathbf{x})} \left[\log \frac{p_\phi(\mathbf{x}, \mathbf{z})}{q_\theta(\mathbf{z}|\mathbf{x})} \right]. \end{aligned}$$

ELBO 目标自然分解为两部分：

- **重构**：鼓励从潜在编码 $\mathbf{z}$ 准确恢复 $\mathbf{x}$ 。在高斯编码器和解码器假设下，这一项恰好退化为熟悉的自编码器重构损失（参见节 2.1.3）。然而，与自编码器一样，仅优化此项存在记忆训练数据的风险，因此需要额外正则化。
- **潜变量 KL**：鼓励编码器分布 $q_\theta(\mathbf{z}|\mathbf{x})$ 接近简单高斯先验 $p_{\text{prior}}(\mathbf{z})$ 。此正则化将潜在空间塑造成平滑、连续的结构，确保从先验采样能够可靠解码，实现有意义的生成。

此权衡同时保证忠实重构与连贯采样。

信息论视角：ELBO 作为散度界。 ELBO 目标具有自然的信息论解释。回顾最大似然训练等价于最小化 KL 散度

$$\mathcal{D}_{\text{KL}}(p_{\text{data}}(\mathbf{x}) \| p_{\phi}(\mathbf{x})),$$

它衡量模型分布对数据分布的逼近程度。由于此项通常难以处理，变分框架引入联合分布的比较。

具体考虑两个联合分布：

- **生成联合分布** $p_{\phi}(\mathbf{x}, \mathbf{z}) = p(\mathbf{z})p_{\phi}(\mathbf{x}|\mathbf{z})$ ，描述模型如何生成数据；
- **推断联合分布** $q_{\theta}(\mathbf{x}, \mathbf{z}) = p_{\text{data}}(\mathbf{x})q_{\theta}(\mathbf{z}|\mathbf{x})$ ，将真实数据与推断出的潜变量耦合。

比较这些分布得到不等式

$$\mathcal{D}_{\text{KL}}(p_{\text{data}}(\mathbf{x}) \| p_{\phi}(\mathbf{x})) \leq \mathcal{D}_{\text{KL}}(q_{\theta}(\mathbf{x}, \mathbf{z}) \| p_{\phi}(\mathbf{x}, \mathbf{z})), \quad (2.1.2)$$

有时称为 KL 散度的链式法则。直观上，只比较边缘分布 $(\mathbf{x})$ 可能掩盖某些不匹配，而考虑完整潜变量—数据联合分布时它们便会显现。

形式上，联合 KL 可展开为

$$\begin{aligned} & \underbrace{\mathcal{D}_{\text{KL}}(q_{\theta}(\mathbf{x}, \mathbf{z}) \| p_{\phi}(\mathbf{x}, \mathbf{z}))}_{\text{总误差界}} \\ &= \mathbb{E}_{q_{\theta}(\mathbf{x}, \mathbf{z})} \left[\log \frac{p_{\text{data}}(\mathbf{x})q_{\theta}(\mathbf{z}|\mathbf{x})}{p_{\phi}(\mathbf{x})p_{\phi}(\mathbf{z}|\mathbf{x})} \right] \\ &= \mathbb{E}_{p_{\text{data}}(\mathbf{x})} \left[\log \frac{p_{\text{data}}(\mathbf{x})}{p_{\phi}(\mathbf{x})} + \mathcal{D}_{\text{KL}}(q_{\theta}(\mathbf{z}|\mathbf{x}) \| p_{\phi}(\mathbf{z}|\mathbf{x})) \right] \\ &= \underbrace{\mathcal{D}_{\text{KL}}(p_{\text{data}} \| p_{\phi})}_{\text{真实建模误差}} + \underbrace{\mathbb{E}_{p_{\text{data}}(\mathbf{x})} [\mathcal{D}_{\text{KL}}(q_{\theta}(\mathbf{z}|\mathbf{x}) \| p_{\phi}(\mathbf{z}|\mathbf{x}))]}_{\text{推断误差}}, \end{aligned}$$

第一项是真实建模误差，第二项是推断误差，即近似后验与真实后验的差距。后者总为非负，解释了式 (2.1.2)。

最后注意

$$\log p_{\phi}(\mathbf{x}) - \mathcal{L}_{\text{ELBO}}(\boldsymbol{\theta}, \boldsymbol{\phi}; \mathbf{x}) = \mathcal{D}_{\text{KL}}(q_{\theta}(\mathbf{z}|\mathbf{x}) \| p_{\phi}(\mathbf{z}|\mathbf{x})).$$

推断误差恰好等于对数似然与 ELBO 的差距。因而最大化 ELBO 对应直接减少推断误差，确保训练最小化整体界中有意义的一部分。

2.1.3 高斯 VAE

VAE 的标准表述对编码器和解码器都采用高斯分布。

编码器部分. 编码器 $q_{\theta}(\mathbf{z}|\mathbf{x})$ 通常建模为高斯分布:

$$q_{\theta}(\mathbf{z}|\mathbf{x}) := \mathcal{N}(\mathbf{z}; \boldsymbol{\mu}_{\theta}(\mathbf{x}), \text{diag}(\boldsymbol{\sigma}_{\theta}^2(\mathbf{x}))),$$

其中 $\boldsymbol{\mu}_{\theta} : \mathbb{R}^D \rightarrow \mathbb{R}^d$ 和 $\boldsymbol{\sigma}_{\theta} : \mathbb{R}^D \rightarrow \mathbb{R}_+^d$ 是编码器网络的确定性输出.

解码器部分. 解码器通常建模为方差固定的高斯分布:

$$p_{\phi}(\mathbf{x}|\mathbf{z}) := \mathcal{N}(\mathbf{x}; \boldsymbol{\mu}_{\phi}(\mathbf{z}), \sigma^2 \mathbf{I}),$$

其中 $\boldsymbol{\mu}_{\phi} : \mathbb{R}^d \rightarrow \mathbb{R}^D$ 为神经网络, $\sigma > 0$ 是控制方差的小常数.

在此假设下, ELBO 的重构项简化为

$$\mathbb{E}_{q_{\theta}(\mathbf{z}|\mathbf{x})} [\log p_{\phi}(\mathbf{x}|\mathbf{z})] = -\frac{1}{2\sigma^2} \mathbb{E}_{q_{\theta}(\mathbf{z}|\mathbf{x})} [\|\mathbf{x} - \boldsymbol{\mu}_{\phi}(\mathbf{z})\|^2] + C,$$

其中 C 与 θ 、 ϕ 无关. ELBO 目标于是化为

$$\min_{\theta, \phi} \mathbb{E}_{q_{\theta}(\mathbf{z}|\mathbf{x})} \left[\frac{1}{2\sigma^2} \|\mathbf{x} - \boldsymbol{\mu}_{\phi}(\mathbf{z})\|^2 \right] + \mathcal{D}_{\text{KL}}(q_{\theta}(\mathbf{z}|\mathbf{x}) \| p_{\text{prior}}(\mathbf{z})),$$

由于高斯假设, KL 项具有闭式解. 因而 VAE 训练归结为最小化带正则化的重构损失.

2.1.4 标准 VAE 的缺点

尽管 VAE 框架在理论上很有吸引力, 它有一个关键缺点: 经常产生模糊输出.

VAE 中的模糊生成. 为理解这一现象, 考虑固定高斯编码器 $q_{\text{enc}}(\mathbf{z}|\mathbf{x})$ 和如下解码器:

$$p_{\text{dec}}(\mathbf{x}|\mathbf{z}) = \mathcal{N}(\mathbf{x}; \boldsymbol{\mu}(\mathbf{z}), \sigma^2 \mathbf{I}),$$

其中 $\boldsymbol{\mu}(\mathbf{z})$ 表示解码器网络. 对任意编码器, 优化 ELBO 等价于最小化期望重构误差 (相差加法常数):

$$\arg \min_{\boldsymbol{\mu}} \mathbb{E}_{p_{\text{data}}(\mathbf{x}) q_{\text{enc}}(\mathbf{z}|\mathbf{x})} [\|\mathbf{x} - \boldsymbol{\mu}(\mathbf{z})\|^2].$$

这是关于 $\boldsymbol{\mu}(\mathbf{z})$ 的标准最小二乘问题, 其闭式解由条件均值给出:

$$\boldsymbol{\mu}^*(\mathbf{z}) = \mathbb{E}_{q_{\text{enc}}(\mathbf{x}|\mathbf{z})} [\mathbf{x}],$$

其中 $q_{\text{enc}}(\mathbf{x}|\mathbf{z})$ 为编码器诱导的给定潜变量时输入的后验, 由 Bayes 法则定义:

$$q_{\text{enc}}(\mathbf{x}|\mathbf{z}) = \frac{q_{\text{enc}}(\mathbf{z}|\mathbf{x}) p_{\text{data}}(\mathbf{x})}{p_{\text{prior}}(\mathbf{z})}.$$

通过 Bayes 法则, 最优生成器还有等价形式:

$$\boldsymbol{\mu}^*(\mathbf{z}) = \frac{\mathbb{E}_{p_{\text{data}}(\mathbf{x})} [q_{\text{enc}}(\mathbf{z}|\mathbf{x}) \cdot \mathbf{x}]}{\mathbb{E}_{p_{\text{data}}(\mathbf{x})} [q_{\text{enc}}(\mathbf{z}|\mathbf{x})]}.$$

现假设两个不同输入 $\mathbf{x} \neq \mathbf{x}'$ 被映射到潜在空间中重叠的区域, 即 $q_{\text{enc}}(\cdot|\mathbf{x})$ 与 $q_{\text{enc}}(\cdot|\mathbf{x}')$ 的支撑相交. 于是 $\boldsymbol{\mu}^*(\mathbf{z})$ 对多个可能不相关的输入取平均, 导致模糊、缺少辨识度的输出. 对冲突模态取平均, 是 VAE 样本特有模糊性的根本原因.

2.1.5 (选读) 从标准 VAE 到层级 VAE

为建模复杂数据，层级变分自编码器 (HVAE) (Vahdat and Kautz, 2020) 引入潜变量层级以增强 VAE. 这种深层结构使模型能够在多个抽象层次刻画数据特征，大幅提高表达能力，并体现现实数据的组合性质。

$$\mathbf{x} \xrightleftharpoons[p_{\phi}(\mathbf{x}|\mathbf{z}_1)]{q_{\theta}(\mathbf{z}_1|\mathbf{x})} \mathbf{z}_1 \xrightleftharpoons[p_{\phi}(\mathbf{z}_1|\mathbf{z}_2)]{q_{\theta}(\mathbf{z}_2|\mathbf{z}_1)} \mathbf{z}_2 \xrightleftharpoons{\dots} \dots \xrightleftharpoons[p_{\phi}(\mathbf{z}_{L-1}|\mathbf{z}_L)]{q_{\theta}(\mathbf{z}_L|\mathbf{z}_{L-1})} \mathbf{z}_L$$

图 2.2: **HVAE 的计算图**. 它具有层级结构，在多个潜变量层之间堆叠可训练的编码器和解码器。

HVAE 的建模. 与仅使用单个潜在编码 $\mathbf{z}$ 的标准 VAE 不同，层级 VAE (HVAE) 引入多个潜变量层，按自顶向下层级排列. 每一层潜变量为下一层提供条件，形成条件先验链，在逐渐细化的抽象层次刻画结构. 联合分布因而具有如下自顶向下分解：

$$p_{\phi}(\mathbf{x}, \mathbf{z}_{1:L}) = p_{\phi}(\mathbf{x}|\mathbf{z}_1) \prod_{i=2}^L p_{\phi}(\mathbf{z}_{i-1}|\mathbf{z}_i) p(\mathbf{z}_L).$$

此结构定义边缘数据分布

$$p_{\text{HVAE}}(\mathbf{x}) := \int p_{\phi}(\mathbf{x}, \mathbf{z}_{1:L}) d\mathbf{z}_{1:L}.$$

生成逐步进行：从顶层潜变量 $\mathbf{z}_L$ 开始，依次向下解码各潜变量直到 $\mathbf{z}_1$ ，最后生成观测 $\mathbf{x}$.

编码部分使用反映生成层级的结构化可学习变分编码器 $q_{\theta}(\mathbf{z}_{1:L}|\mathbf{x})$. 常见选择是自底向上的 Markov 分解：

$$q_{\theta}(\mathbf{z}_{1:L}|\mathbf{x}) = q_{\theta}(\mathbf{z}_1|\mathbf{x}) \prod_{i=2}^L q_{\theta}(\mathbf{z}_i|\mathbf{z}_{i-1}).$$

HVAE 的 ELBO. 与式 (2.1.1) 类似，通过 Jensen 不等式推导 ELBO：

$$\begin{aligned} \log p_{\text{HVAE}}(\mathbf{x}) &= \log \int p_{\phi}(\mathbf{x}, \mathbf{z}_{1:L}) d\mathbf{z}_{1:L} \\ &= \log \int \frac{p_{\phi}(\mathbf{x}, \mathbf{z}_{1:L})}{q_{\theta}(\mathbf{z}_{1:L}|\mathbf{x})} q_{\theta}(\mathbf{z}_{1:L}|\mathbf{x}) d\mathbf{z}_{1:L} \\ &= \log \mathbb{E}_{q_{\theta}(\mathbf{z}_{1:L}|\mathbf{x})} \left[\frac{p_{\phi}(\mathbf{x}, \mathbf{z}_{1:L})}{q_{\theta}(\mathbf{z}_{1:L}|\mathbf{x})} \right] \\ &\geq \mathbb{E}_{q_{\theta}(\mathbf{z}_{1:L}|\mathbf{x})} \left[\log \frac{p_{\phi}(\mathbf{x}, \mathbf{z}_{1:L})}{q_{\theta}(\mathbf{z}_{1:L}|\mathbf{x})} \right] \\ &=: \mathcal{L}_{\text{ELBO}}(\phi). \end{aligned} \tag{2.1.3}$$

代入因子化形式得到：

$$\mathcal{L}_{\text{ELBO}} = \mathbb{E}_{q_{\theta}(\mathbf{z}_{1:L}|\mathbf{x})} \left[\log \frac{p(\mathbf{z}_L) \prod_{i=2}^L p_{\phi}(\mathbf{z}_{i-1}|\mathbf{z}_i) p_{\phi}(\mathbf{x}|\mathbf{z}_1)}{q_{\theta}(\mathbf{z}_1|\mathbf{x}) \prod_{i=2}^L q_{\theta}(\mathbf{z}_i|\mathbf{z}_{i-1})} \right].$$

这一层级 ELBO 分解为可解释的项，包括重构项，以及各生成条件分布与对应变分近似之间的 KL 散度。

从浅层到深层网络的跨越革新了机器学习，类似思想也改变了生成模型。HVAE 展示了用深层堆叠构建数据的力量。层级结构概念是现代生成建模的基石，也再次出现在基于得分的方法（节 3.4）和归一化流（节 5.1）中。核心洞见简单而有力：

观察 2.1.1:

堆叠层使模型逐步生成数据，从粗略细节开始，每一步增加精细细节。此过程使刻画高维数据的复杂结构容易得多。

为什么平坦 VAE 中更深的网络仍不够。 标准平坦 VAE 有两个基本限制，仅加深编码器和解码器无法解决。

第一个限制是变分族。在标准 VAE 中，

$$q_{\theta}(\mathbf{z}|\mathbf{x}) = \mathcal{N}(\mathbf{z}; \boldsymbol{\mu}_{\theta}(\mathbf{x}), \text{diag}(\sigma_{\theta}^2(\mathbf{x}))),$$

对每个固定 $\mathbf{x}$ ，编码器后验均为单个对角协方差高斯分布。更大的网络深度提高 $\boldsymbol{\mu}_{\theta}$ 和 σ_{θ} 的精度，却不扩大分布族；即使采用完整协方差，仍只是一个单峰椭圆。当 $p_{\phi}(\mathbf{z}|\mathbf{x})$ 有多个峰时，此族无法匹配，导致 ELBO 变松、推断变弱。解决它需要更丰富的后验类别，而非仅加深网络。

其次，解码器表达能力过强可能引起后验坍塌。为理解原因，回顾 VAE 目标：

$$\begin{aligned} \mathbb{E}_{p_{\text{data}}(\mathbf{x})}[\mathcal{L}_{\text{ELBO}}(\mathbf{x})] &= \mathbb{E}_{p_{\text{data}}(\mathbf{x})q_{\theta}(\mathbf{z}|\mathbf{x})}[\log p_{\phi}(\mathbf{x}|\mathbf{z})] - \mathbb{E}_{p_{\text{data}}(\mathbf{x})}[\mathcal{D}_{\text{KL}}(q_{\theta}(\mathbf{z}|\mathbf{x})\|p(\mathbf{z}))] \\ &= \mathbb{E}_{p_{\text{data}}(\mathbf{x})q_{\theta}(\mathbf{z}|\mathbf{x})}[\log p_{\phi}(\mathbf{x}|\mathbf{z})] - \mathcal{I}_q(\mathbf{x}; \mathbf{z}) - \mathcal{D}_{\text{KL}}(q_{\theta}(\mathbf{z})\|p(\mathbf{z})), \end{aligned}$$

其中 $\mathcal{I}_q(\mathbf{x}; \mathbf{z})$ 是互信息，定义为

$$\mathcal{I}_q(\mathbf{x}; \mathbf{z}) = \mathbb{E}_{q(\mathbf{x}, \mathbf{z})} \left[\log \frac{q_{\theta}(\mathbf{z}|\mathbf{x})}{q(\mathbf{z})} \right] = \mathbb{E}_{p_{\text{data}}(\mathbf{x})} [\mathcal{D}_{\text{KL}}(q_{\theta}(\mathbf{z}|\mathbf{x})\|q(\mathbf{z}))],$$

聚合后验为 $q_{\theta}(\mathbf{z}) = \int p_{\text{data}}(\mathbf{x})q_{\theta}(\mathbf{z}|\mathbf{x}) d\mathbf{x}$ 。

若解码器类不使用 $\mathbf{z}$ 也能很好地建模数据（即包含某个接近 p_{data} 的 $p_{\phi}(\mathbf{x}|\mathbf{z}) = r(\mathbf{x})$ ），则 ELBO 的一个最大化解令 $q_{\theta}(\mathbf{z}|\mathbf{x}) = p(\mathbf{z})$ ，因而 $\mathcal{I}_q(\mathbf{x}; \mathbf{z}) = 0$ 且 $q_{\theta}(\mathbf{z}) = p(\mathbf{z})$ 。加深网络不会消除这种“忽略 $\mathbf{z}$ ”的解：

1. 学得编码与 $\mathbf{x}$ 独立，不携带对下游任务有用的数据相关结构；
2. 在 $\mathbf{z}$ 中施加条件或移动不会影响生成样本，因而可控生成失效。

层级改变了什么？ HVAE 引入多个潜变量层，

$$p_\phi(\mathbf{x}, \mathbf{z}_{1:L}) = p_\phi(\mathbf{x}|\mathbf{z}_1) \prod_{i=2}^L p_\phi(\mathbf{z}_{i-1}|\mathbf{z}_i) p(\mathbf{z}_L),$$

其 ELBO 为

$$\begin{aligned} \mathcal{L}_{\text{ELBO}}(\mathbf{x}) = & \mathbb{E}_q[\log p_\phi(\mathbf{x}|\mathbf{z}_1)] - \mathbb{E}_q\left[\mathcal{D}_{\text{KL}}(q_\theta(\mathbf{z}_1|\mathbf{x})\|p_\phi(\mathbf{z}_1|\mathbf{z}_2))\right] \\ & - \sum_{i=2}^{L-1} \mathbb{E}_q\left[\mathcal{D}_{\text{KL}}(q_\theta(\mathbf{z}_i|\mathbf{z}_{i-1})\|p_\phi(\mathbf{z}_i|\mathbf{z}_{i+1}))\right] \\ & - \mathbb{E}_q\left[\mathcal{D}_{\text{KL}}(q_\theta(\mathbf{z}_L|\mathbf{z}_{L-1})\|p(\mathbf{z}_L))\right]. \end{aligned}$$

这里记 $\mathbb{E}_q := \mathbb{E}_{p_{\text{data}}(\mathbf{x})q_\theta(\mathbf{z}_{1:L}|\mathbf{x})}$. 各推断条件分布与其自顶向下的生成对应项对齐: $q_\theta(\mathbf{z}_1|\mathbf{x})$ 对齐 $p_\phi(\mathbf{z}_1|\mathbf{z}_2)$, 中间层对齐 $p_\phi(\mathbf{z}_i|\mathbf{z}_{i+1})$, 顶层对齐先验 $p(\mathbf{z}_L)$. 这将信息惩罚分散到各层, 通过相邻 KL 项使学习信号局部化. 这些性质源于层级潜变量图, 而非仅加深平坦 VAE 的网络.

后面将讨论什么？ HVAE 以多个潜变量层提高 VAE 的表达能, 但训练有独特挑战. 编码器与解码器必须联合优化, 使学习不稳定: 低层和解码器已能重构 $\mathbf{x}$, 高层潜变量获得的有效信号很少. 此外, 传到较深变量的梯度信息通常间接而微弱, 难以使其发挥实质作用. 平衡模型容量也困难, 因为表达能力过强的条件分布可能主导重构任务, 抑制较高层潜变量的用途.

有趣的是, 深层层级思想在变分扩散模型中得到更强的实现, 节 2.2 将讨论它. 扩散模型继承 HVAE 的渐进结构, 又巧妙避开其核心弱点. 通过固定编码过程、仅学习生成反转, 模型获得新的稳定性和建模灵活性, 大幅提高生成输出质量.

为简化记号, 我们不再遵循 VAE 常用的编码器记作 q 、生成器记作 p 的约定. 为避免歧义, 统一用 p 表示分布, 始终用适当上下标指定其角色, 并在上下文中澄清.

2.2 变分视角：DDPM

去噪扩散概率模型 (DDPM) (Sohl-Dickstein et al., 2015; Ho, Jain, and Abbeel, 2020) 是扩散建模的基石. 概念上它与 VAE、HVAE 一样在变分框架中工作, 但引入巧妙变化, 解决前者的部分挑战.

DDPM 的核心包含两个不同随机过程:

- **前向过程 (固定编码器)**: 通过转移核 $p(\mathbf{x}_i|\mathbf{x}_{i-1})$ 在逐步中注入高斯噪声, 逐步破坏数据. 数据演化成各向同性高斯分布, 实际上变为纯噪声. 这意味着编码器固定而不学习.
- **反向去噪过程 (可学习解码器)**: 神经网络通过参数化分布 $p_\phi(\mathbf{x}_{i-1}|\mathbf{x}_i)$ 学习反转加噪. 从纯噪声开始, 迭代去噪生成逼真样本. 每个去噪步骤比 VAE 常尝试的从头生成完整样本更易处理.

固定编码器、集中学习渐进的生成轨迹, 使 DDPM 获得显著稳定性和表达能力.

$$\mathbf{x}_0 \xrightleftharpoons[p_\phi(\mathbf{x}_0|\mathbf{x}_1)]{p(\mathbf{x}_1|\mathbf{x}_0)} \mathbf{x}_1 \xrightleftharpoons[p_\phi(\mathbf{x}_1|\mathbf{x}_2)]{p(\mathbf{x}_2|\mathbf{x}_1)} \mathbf{x}_2 \xrightleftharpoons[p_\phi(\mathbf{x}_{L-1}|\mathbf{x}_L)]{p(\mathbf{x}_L|\mathbf{x}_{L-1})} \dots \mathbf{x}_L$$

图 2.3: DDPM 示意图. 由逐步为数据添加高斯噪声的固定前向过程 (灰色), 以及逐步去噪生成新样本的学得反向过程组成.

本节聚焦 DDPM, 更广泛的讨论留至节 4.4, 届时介绍更一般、灵活的框架.

2.2.1 前向过程 (固定编码器)

DDPM 的前向过程是固定、不可训练的编码操作. 它在逐步中添加噪声, 逐渐破坏原数据, 最终变换为简单先验分布 $p_{\text{prior}} := \mathcal{N}(\mathbf{0}, \mathbf{I})$. 图 2.3 的前向链及图 2.4 展示此变换.




图 2.4: DDPM 前向过程示意图: 逐步添加高斯噪声, 将数据样本破坏成纯噪声.

将这种逐步退化形式化:

固定高斯转移. 前向过程的每一步由固定高斯转移核控制¹:

$$p(\mathbf{x}_i|\mathbf{x}_{i-1}) := \mathcal{N}(\mathbf{x}_i; \sqrt{1 - \beta_i^2} \mathbf{x}_{i-1}, \beta_i^2 \mathbf{I}).$$

¹这一表述看似不同, 但在数学上等价于原始 DDPM 转移核.

过程从真实数据分布 p_{data} 的样本 $\mathbf{x}_0$ 开始. 序列 $\{\beta_i\}_{i=1}^L$ 表示预定、单调递增的噪声调度, 每个 $\beta_i \in (0, 1)$ 控制第 i 步注入的高斯噪声方差. 为方便起见定义 $\alpha_i := \sqrt{1 - \beta_i^2}$. 此数学定义恰好等价于以下直观迭代更新:

$$\mathbf{x}_i = \alpha_i \mathbf{x}_{i-1} + \beta_i \boldsymbol{\epsilon}_i,$$

其中 $\boldsymbol{\epsilon}_i \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 独立同分布. 即每步 i 将前一状态 $\mathbf{x}_{i-1}$ 按 α_i 缩小, 再添加由 β_i 缩放的受控高斯噪声.

扰动核与先验分布. 递归应用转移核, 得到给定原数据 $\mathbf{x}_0$ 时第 i 步含噪样本分布的闭式表达:

$$p_i(\mathbf{x}_i | \mathbf{x}_0) = \mathcal{N}(\mathbf{x}_i; \bar{\alpha}_i \mathbf{x}_0, (1 - \bar{\alpha}_i^2) \mathbf{I}),$$

其中

$$\bar{\alpha}_i := \prod_{k=1}^i \sqrt{1 - \beta_k^2} = \prod_{k=1}^i \alpha_k.$$

这意味着可直接从 $\mathbf{x}$ 采样 $\mathbf{x}_i$ ²

$$\mathbf{x}_i = \bar{\alpha}_i \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_i^2} \boldsymbol{\epsilon}, \quad \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}). \quad (2.2.1)$$

令噪声调度 $\{\beta_i\}_{i=1}^L$ 为递增序列, 前向过程的边缘分布按如下方式收敛:

$$p_L(\mathbf{x}_L | \mathbf{x}_0) \longrightarrow \mathcal{N}(\mathbf{0}, \mathbf{I}) \quad \text{当 } L \rightarrow \infty,$$

由此选择先验分布为

$$p_{\text{prior}} := \mathcal{N}(\mathbf{0}, \mathbf{I})$$

它不依赖数据 $\mathbf{x}_0$.

²对固定指标 t , 本节及后文常使用高斯扰动形式

$$p_t(\mathbf{x}_t | \mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t; \alpha_t \mathbf{x}_0, \sigma_t^2 \mathbf{I}),$$

等价地写成分布意义下的恒等式

$$\mathbf{x}_t \stackrel{d}{=} \alpha_t \mathbf{x}_0 + \sigma_t \boldsymbol{\epsilon}, \quad \text{即} \quad \text{Law}(\mathbf{x}_t) = \text{Law}(\alpha_t \mathbf{x}_0 + \sigma_t \boldsymbol{\epsilon}),$$

其中 $\mathbf{x}_0 \sim p_{\text{data}}$, $\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 与 $\mathbf{x}_0$ 独立, α_t, σ_t 为确定标量. 等号 “ $\stackrel{d}{=}$ ” 表示两个随机变量有相同概率密度 (即分布律), 因而对任意测试函数 ϕ 有相同期望:

$$\mathbb{E}[\phi(\mathbf{x}_t)] = \mathbb{E}[\phi(\alpha_t \mathbf{x}_0 + \sigma_t \boldsymbol{\epsilon})].$$

为简洁起见写成 $\mathbf{x}_t = \alpha_t \mathbf{x}_0 + \sigma_t \boldsymbol{\epsilon}$, 理解为分布意义的相等, 或根据上下文理解为样本实现; 全文采用此简写.

2.2.2 反向去噪过程（可学习解码器）

DDPM 的本质在于能够反转前向扩散施加的受控退化. 从无结构的纯噪声 $\mathbf{x}_L \sim p_{\text{prior}}$ 开始, 目标是逐步去噪, 直到出现连贯、有意义的数据样本. 反向生成通过 Markov 链进行, 如图 2.5 所示.




图 2.5: DDPM 反向（去噪）过程示意图. 从噪声 $\mathbf{x}_L \sim p_{\text{prior}}$ 开始, 依次在 $i = L, \dots, 1$ 时采样 $\mathbf{x}_{i-1} \sim p(\mathbf{x}_{i-1}|\mathbf{x}_i)$, 获得新生成的数据 $\mathbf{x}$. 理想转移 $p(\mathbf{x}_{i-1}|\mathbf{x}_i)$ 未知, 因此需要逼近它.

根本挑战, 也是指导 DDPM 发展的核心问题, 变为:

问题 2.2.1. 能否精确计算, 或至少有效逼近反向转移核 $p(\mathbf{x}_{i-1}|\mathbf{x}_i)$, 特别是在 $\mathbf{x}_i \sim p_i(\mathbf{x}_i)$ 的分布复杂时?

原始 DDPM 论文直接深入证据下界 (ELBO) 的复杂数学推导 (节 2.2.5 将详细讨论); 这里先从更直观的角度构造训练目标: 利用条件概率得到易于处理的表述.

概述: 建模与训练目标. 为实现生成, 目标是逼近未知的真实反向转移核 $p(\mathbf{x}_{i-1}|\mathbf{x}_i)$. 引入可学习参数模型 $p_\phi(\mathbf{x}_{i-1}|\mathbf{x}_i)$, 训练时最小化期望 KL 散度:

$$\mathbb{E}_{p_i(\mathbf{x}_i)} [\mathcal{D}_{\text{KL}}(p(\mathbf{x}_{i-1}|\mathbf{x}_i) \| p_\phi(\mathbf{x}_{i-1}|\mathbf{x}_i))]. \quad (2.2.2)$$

但直接计算目标分布 $p(\mathbf{x}_{i-1}|\mathbf{x}_i)$ 很困难. 由 Bayes 定理, 需要计算:

$$p(\mathbf{x}_{i-1}|\mathbf{x}_i) = p(\mathbf{x}_i|\mathbf{x}_{i-1}) \underbrace{\frac{p_{i-1}(\mathbf{x}_{i-1})}{p_i(\mathbf{x}_i)}}_{\text{intractable}}.$$

边缘分布 $p_i(\mathbf{x}_i)$ 与 $p_{i-1}(\mathbf{x}_{i-1})$ 是关于未知数据分布 p_{data} 的期望:

$$p_i(\mathbf{x}_i) = \int p_i(\mathbf{x}_i|\mathbf{x}_0) p_{\text{data}}(\mathbf{x}_0) d\mathbf{x}_0,$$

$p_{i-1}(\mathbf{x}_{i-1})$ 类似. 由于 p_{data} 未知, 积分无闭式计算方法, 至多可从样本近似, 因此实践中无法获得精确密度.

用条件化克服难以处理性. DDPM 的核心洞见解决了这一困难: 将反向转移条件化于干净数据样本 $\mathbf{x}$. 这一微妙而有力的步骤把难以处理的核变为数学上易于处理的核:

$$p(\mathbf{x}_{i-1}|\mathbf{x}_i, \mathbf{x}) = p(\mathbf{x}_i|\mathbf{x}_{i-1}) \frac{p(\mathbf{x}_{i-1}|\mathbf{x})}{p(\mathbf{x}_i|\mathbf{x})}.$$

可处理性源于前向过程的两个关键性质：Markov 性，即 $p(\mathbf{x}_i|\mathbf{x}_{i-1}, \mathbf{x}) = p(\mathbf{x}_i|\mathbf{x}_{i-1})$ ，以及相关分布均为高斯分布。因而 $p(\mathbf{x}_{i-1}|\mathbf{x}_i, \mathbf{x})$ 本身也是高斯分布，且具有闭式表达（见式 (2.2.4)）。关键在于，这一巧妙条件化策略可推导出易于处理的目标，与式 (2.2.2) 中看似难以处理的边缘 KL 散度在功能上等价。

定理 2.2.1: 边缘与条件 KL 最小化的等价性

下面的等式成立：

$$\begin{aligned} & \mathbb{E}_{p_i(\mathbf{x}_i)} [\mathcal{D}_{\text{KL}}(p(\mathbf{x}_{i-1}|\mathbf{x}_i) \| p_\phi(\mathbf{x}_{i-1}|\mathbf{x}_i))] \\ &= \mathbb{E}_{p_{\text{data}}(\mathbf{x})} \mathbb{E}_{p(\mathbf{x}_i|\mathbf{x})} [\mathcal{D}_{\text{KL}}(p(\mathbf{x}_{i-1}|\mathbf{x}_i, \mathbf{x}) \| p_\phi(\mathbf{x}_{i-1}|\mathbf{x}_i))] + C, \end{aligned} \quad (2.2.3)$$

其中 C 与 ϕ 无关。此外，式 (2.2.3) 的最小化解满足

$$p^*(\mathbf{x}_{i-1}|\mathbf{x}_i) = \mathbb{E}_{p(\mathbf{x}|\mathbf{x}_i)} [p(\mathbf{x}_{i-1}|\mathbf{x}_i, \mathbf{x})] = p(\mathbf{x}_{i-1}|\mathbf{x}_i), \quad \mathbf{x}_i \sim p_i.$$

定理的证明。

证明展开 KL 散度期望的定义，应用概率链式法则，再用对数恒等式将其分解为期望条件 KL 散度与边缘 KL 散度之和。完整推导见节 D.1.1。

通过条件化获得易于处理目标的另一视角，构成 DDPM 的基础，并揭示与其他重要扩散模型的深刻共性，章 3 和章 5 将继续探索。

它揭示强大的等价性：最小化边缘分布之间的 KL 散度，在数学上等同于最小化特定条件分布之间的 KL 散度。后者尤其有用，因为关键条件分布 $p(\mathbf{x}_{i-1}|\mathbf{x}_i, \mathbf{x})$ 具有方便的闭式表达：

引理 2.2.2: 反向条件转移核

$p(\mathbf{x}_{i-1}|\mathbf{x}_i, \mathbf{x})$ 为高斯分布，其闭式表达为：

$$p(\mathbf{x}_{i-1}|\mathbf{x}_i, \mathbf{x}) = \mathcal{N}(\mathbf{x}_{i-1}; \boldsymbol{\mu}(\mathbf{x}_i, \mathbf{x}, i), \sigma^2(i)\mathbf{I}),$$

其中

$$\boldsymbol{\mu}(\mathbf{x}_i, \mathbf{x}, i) := \frac{\bar{\alpha}_{i-1}\beta_i^2}{1 - \bar{\alpha}_i^2}\mathbf{x} + \frac{(1 - \bar{\alpha}_{i-1}^2)\alpha_i}{1 - \bar{\alpha}_i^2}\mathbf{x}_i, \quad \sigma^2(i) := \frac{1 - \bar{\alpha}_{i-1}^2}{1 - \bar{\alpha}_i^2}\beta_i^2. \quad (2.2.4)$$

后文引理 4.4.2 给出更一般公式，超出式 (2.2.1) 描述的 DDPM 加噪过程。

2.2.3 反向转移核 $p_\phi(\mathbf{x}_{i-1}|\mathbf{x}_i)$ 的建模

利用定理 2.2.1 的梯度层面等价性，以及引理 2.2.2 的反向条件分布 $p(\mathbf{x}_{i-1}|\mathbf{x}_i, \mathbf{x})$ 的高斯形式，DDPM 假设每个反向转移 $p_\phi(\mathbf{x}_{i-1}|\mathbf{x}_i)$ 为高斯分布，参数化为

$$p_\phi(\mathbf{x}_{i-1}|\mathbf{x}_i) := \mathcal{N}(\mathbf{x}_{i-1}; \boldsymbol{\mu}_\phi(\mathbf{x}_i, i), \sigma^2(i)\mathbf{I}), \quad (2.2.5)$$

其中 $\mu_\phi(\cdot, i): \mathbb{R}^D \rightarrow \mathbb{R}^D$ 为可学习均值函数, $\sigma^2(i) > 0$ 按式 (2.2.4) 固定.

记在时间步 i 上平均、条件于数据 $\mathbf{x}_0 \sim p_{\text{data}}$ 的 KL 散度, 以匹配所有层的分布:

$$\mathcal{L}_{\text{diffusion}}(\mathbf{x}_0; \phi) := \sum_{i=1}^L \mathbb{E}_{p(\mathbf{x}_i|\mathbf{x}_0)} [\mathcal{D}_{\text{KL}}(p(\mathbf{x}_{i-1}|\mathbf{x}_i, \mathbf{x}_0) \| p_\phi(\mathbf{x}_{i-1}|\mathbf{x}_i))]. \quad (2.2.6)$$

由于两个分布的高斯形式和式 (2.2.5) 的参数化, 目标具有闭式表达, 可简化为

$$\mathcal{L}_{\text{diffusion}}(\mathbf{x}_0; \phi) = \sum_{i=1}^L \frac{1}{2\sigma^2(i)} \|\mu_\phi(\mathbf{x}_i, i) - \mu(\mathbf{x}_i, \mathbf{x}_0, i)\|_2^2 + C, \quad (2.2.7)$$

其中 C 与 ϕ 无关. 对数据分布平均, 略去不影响优化的常数 C , 得到最终 DDPM 训练目标

$$\mathcal{L}_{\text{DDPM}}(\phi) := \sum_{i=1}^L \frac{1}{2\sigma^2(i)} \mathbb{E}_{\mathbf{x}_0} \mathbb{E}_{p(\mathbf{x}_i|\mathbf{x}_0)} [\|\mu_\phi(\mathbf{x}_i, i) - \mu(\mathbf{x}_i, \mathbf{x}_0, i)\|_2^2], \quad (2.2.8)$$

其中 $\mathbf{x}_0 \sim p_{\text{data}}$.

2.2.4 预测与损失的实际选择

ϵ 预测. 典型 DDPM 实现不直接采用式 (2.2.8) 中基于均值预测参数化的原始损失训练, 而通常采用称为 ϵ 预测 (噪声预测) 的等价重参数化 (reparameterization).

回顾 DDPM 前向过程中噪声水平 i 的含噪样本 $\mathbf{x}_i \sim p(\mathbf{x}_i|\mathbf{x})$ 由下式生成:

$$\mathbf{x}_i = \bar{\alpha}_i \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_i^2} \epsilon, \quad \mathbf{x}_0 \sim p_{\text{data}}, \quad \epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I}). \quad (2.2.9)$$

由此, 式 (2.2.4) 的反向均值 $\mu(\mathbf{x}_i, \mathbf{x}_0, i)$ 可改写为

$$\mu(\mathbf{x}_i, \mathbf{x}_0, i) = \frac{1}{\alpha_i} \left(\mathbf{x}_i - \frac{1 - \alpha_i^2}{\sqrt{1 - \bar{\alpha}_i^2}} \epsilon \right).$$

这启发了使用直接预测噪声的神经网络 $\epsilon_\phi(\mathbf{x}_i, i)$ 参数化模型均值 μ_ϕ :

$$\mu_\phi(\mathbf{x}_i, i) = \frac{1}{\alpha_i} \left(\mathbf{x}_i - \frac{1 - \alpha_i^2}{\sqrt{1 - \bar{\alpha}_i^2}} \underbrace{\epsilon_\phi(\mathbf{x}_i, i)}_{\epsilon\text{-prediction}} \right).$$

代入原损失, 得到预测噪声与真实噪声之间的平方 ℓ_2 误差:

$$\|\mu_\phi(\mathbf{x}_i, i) - \mu(\mathbf{x}_i, \mathbf{x}_0, i)\|_2^2 \propto \|\epsilon_\phi(\mathbf{x}_i, i) - \epsilon\|_2^2,$$

相差依赖 i 的权重因子. 直观上, 模型像“噪声侦探”, 估计前向过程每步添加的随机噪声. 从受损样本减去估计, 使之接近干净原样本; 逐步重复便从纯噪声重构数据.

€ 预测的简化损失. 实践中进一步略去权重项, 得到广泛使用的 DDPM 训练损失:

$$\mathcal{L}_{\text{simple}}(\phi) := \mathbb{E}_i \mathbb{E}_{\mathbf{x} \sim p_{\text{data}}(\mathbf{x})} \mathbb{E}_{\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})} [\|\epsilon_{\phi}(\mathbf{x}_i, i) - \epsilon\|_2^2], \quad (2.2.10)$$

其中 $\mathbf{x}_i = \bar{\alpha}_i \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_i^2} \epsilon$, $\mathbf{x}_0 \sim p_{\text{data}}$. 目标噪声在每个时间步 t 均有单位方差, 故式 (2.2.10) 的 ℓ_2 损失在所有 t 上保持一致尺度, 避免目标消失或爆炸, 不再需要显式损失加权.

$\mathcal{L}_{\text{DDPM}}$ 和 $\mathcal{L}_{\text{simple}}$ 有相同最优解 ϵ^* , 因为式 (2.2.10) 本质上是最小二乘问题 (类似推导见命题 4.2.1 或命题 6.3.1):

$$\epsilon^*(\mathbf{x}_i, i) = \mathbb{E}[\epsilon | \mathbf{x}_i], \quad \mathbf{x}_i \sim p_i.$$

直观上, € 预测网络 $\epsilon_{\phi}(\mathbf{x}_i, i)$ 估计前向过程为产生 $\mathbf{x}_i$ 添加的噪声. 在最优处, 估计等于真实噪声的条件期望, 即使 $\mathbf{x}_i$ 并不唯一确定原始干净样本.

另一种等价参数化: x 预测. 式 (2.2.4) 启发另一种等价参数化, 即 $\mathbf{x}$ 预测 (干净预测): 训练网络 $\mathbf{x}_{\phi}(\mathbf{x}_i, i)$, 从噪声水平 i 的给定含噪输入 $\mathbf{x}_i \sim p_i(\mathbf{x}_i)$ 预测干净 (去噪) 样本. 用 $\mathbf{x}_{\phi}(\mathbf{x}_i, i)$ 替代反向均值中的真实干净样本 $\mathbf{x}$, 得到模型:

$$\mu_{\phi}(\mathbf{x}_i, i) = \frac{\bar{\alpha}_{i-1} \beta_i^2}{1 - \bar{\alpha}_i^2} \mathbf{x}_{\phi}(\mathbf{x}_i, i) + \frac{(1 - \bar{\alpha}_{i-1}^2) \alpha_i}{1 - \bar{\alpha}_i^2} \mathbf{x}_i.$$

类似 € 预测, 训练目标可写为

$$\|\mu_{\phi}(\mathbf{x}_i, i) - \mu(\mathbf{x}_i, \mathbf{x}_0, i)\|_2^2 \propto \|\mathbf{x}_{\phi}(\mathbf{x}_i, i) - \mathbf{x}_0\|_2^2, \quad \mathbf{x}_0 \sim p_{\text{data}},$$

训练模型从含噪版本 $\mathbf{x}_i$ 预测原数据 $\mathbf{x}$. 此等价性将式 (2.2.8) 的均值匹配损失化为

$$\mathbb{E}_i \mathbb{E}_{\mathbf{x}_0 \sim p_{\text{data}}} \mathbb{E}_{\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})} [\omega_i \|\mathbf{x}_{\phi}(\mathbf{x}_i, i) - \mathbf{x}_0\|_2^2],$$

其中 ω_i 为某个权重函数. 由于这是最小二乘问题, 最优解为 (见命题 4.2.1 或命题 6.3.1)

$$\mathbf{x}^*(\mathbf{x}_i, i) = \mathbb{E}[\mathbf{x}_0 | \mathbf{x}_i], \quad \mathbf{x}_i \sim p_i, \quad (2.2.11)$$

即模型应预测给定时间步 i 的含噪观测 $\mathbf{x}_i$ 时干净数据的期望.

$\mathbf{x}$ 预测与 € 预测在数学上等价, 由前向过程联系:

$$\mathbf{x}_i = \bar{\alpha}_i \mathbf{x}_{\phi}(\mathbf{x}_i, i) + \sqrt{1 - \bar{\alpha}_i^2} \epsilon_{\phi}(\mathbf{x}_i, i). \quad (2.2.12)$$

即可以预测干净样本 $\mathbf{x}_{\phi}(\mathbf{x}_i, i)$, 或噪声 $\epsilon_{\phi}(\mathbf{x}_i, i)$, 二者的组合应在前向加噪过程下复现 $\mathbf{x}_i$.

2.2.5 DDPM 的 ELBO

按式 (2.2.5) 定义反向转移后, DDPM 联合生成分布定义为

$$p_{\phi}(\mathbf{x}_0, \mathbf{x}_{1:L}) := p_{\phi}(\mathbf{x}_0 | \mathbf{x}_1) p_{\phi}(\mathbf{x}_1 | \mathbf{x}_2) \cdots p_{\phi}(\mathbf{x}_{L-1} | \mathbf{x}_L) p_{\text{prior}}(\mathbf{x}_L),$$

数据的边缘生成模型为

$$p_\phi(\mathbf{x}_0) := \int p_\phi(\mathbf{x}_0, \mathbf{x}_{1:L}) d\mathbf{x}_{1:L}.$$

事实上，式 (2.2.6) 的 DDPM 训练可以严格奠基于最大似然估计 (式 (1.1.2))。其目标构成 ELBO，类似节 2.1 的 VAE、HVAE，作为对数密度下界：

定理 2.2.3: DDPM 的 ELBO

$$\begin{aligned} -\log p_\phi(\mathbf{x}_0) &\leq -\mathcal{L}_{\text{ELBO}}(\mathbf{x}_0; \phi) \\ &:= \mathcal{L}_{\text{prior}}(\mathbf{x}_0) + \mathcal{L}_{\text{recon.}}(\mathbf{x}_0; \phi) + \mathcal{L}_{\text{diffusion}}(\mathbf{x}_0; \phi) \end{aligned} \quad (2.2.13)$$

各损失分量定义为

$$\begin{aligned} \mathcal{L}_{\text{prior}}(\mathbf{x}_0) &:= \mathcal{D}_{\text{KL}}\left(p(\mathbf{x}_L|\mathbf{x}_0) \| p_{\text{prior}}(\mathbf{x}_L)\right) \\ \mathcal{L}_{\text{recon.}}(\mathbf{x}_0; \phi) &:= \mathbb{E}_{p(\mathbf{x}_1|\mathbf{x}_0)} [-\log p_\phi(\mathbf{x}_0|\mathbf{x}_1)] \\ \mathcal{L}_{\text{diffusion}}(\mathbf{x}_0; \phi) &= \sum_{i=1}^L \mathbb{E}_{p(\mathbf{x}_i|\mathbf{x}_0)} \left[\mathcal{D}_{\text{KL}}\left(p(\mathbf{x}_{i-1}|\mathbf{x}_i, \mathbf{x}_0) \| p_\phi(\mathbf{x}_{i-1}|\mathbf{x}_i)\right) \right]. \end{aligned}$$

定理的证明。

推导与 HVAE / VAE 的 ELBO (式 (2.1.3)) 一样使用 Jensen 不等式，并进一步简化。详细证明见节 D.1.2.

ELBO $\mathcal{L}_{\text{ELBO}}$ 包含三项：

- 选择噪声调度 $\{\beta_i\}$ 使 $p(\cdot|\mathbf{x}_0) \approx p_{\text{prior}}(\cdot)$ ，可使 $\mathcal{L}_{\text{prior}}$ 忽略不计。
- $\mathcal{L}_{\text{recon.}}$ 可用蒙特卡洛估计近似并优化；实际实现见 (Ho, Jain, and Abbeel, 2020; Kingma et al., 2021)。
- $\mathcal{L}_{\text{diffusion}}$ (参见式 (2.2.6)) 在所有步骤 i 将反向条件分布 $p_\phi(\mathbf{x}_{i-1}|\mathbf{x}_i)$ 与 $p(\mathbf{x}_{i-1}|\mathbf{x}_i)$ 匹配。

ELBO 目标 $\mathcal{L}_{\text{ELBO}}$ 也可由潜变量 $\mathbf{z} = \mathbf{x}_{1:L}$ 的数据处理不等式解释，如式 (2.1.2) 所示：

$$\mathcal{D}_{\text{KL}}(p_{\text{data}}(\mathbf{x}_0) \| p_\phi(\mathbf{x}_0)) \leq \mathcal{D}_{\text{KL}}(p(\mathbf{x}_0, \mathbf{x}_{1:L}) \| p_\phi(\mathbf{x}_0, \mathbf{x}_{1:L})),$$

其中 $p(\mathbf{x}_0, \mathbf{x}_{1:L}) := p_{\text{data}}(\mathbf{x}_0)p(\mathbf{x}_1|\mathbf{x}_0)p(\mathbf{x}_2|\mathbf{x}_1) \cdots p(\mathbf{x}_L|\mathbf{x}_{L-1})$ 表示前向过程上的联合分布。

注.

扩散的变分视角符合 HVAE 模板：“编码器”是固定前向加噪链，潜变量 $\mathbf{x}_{1:T}$ 与数据维数相同。训练最大化同一 ELBO。无需学习编码器，也无逐层 KL 项；目标分解为从大噪声到小噪声（从粗到细）的条件良好去噪子问题，在保留时间 / 噪声上的由粗

到细层级的同时，获得稳定优化和高质量样本。

2.2.6 采样

训练 ϵ 预测模型 $\epsilon_{\phi \times}(\mathbf{x}_i, i)$ 后³，按图 2.5 依次采样，使用参数化转移 $p_{\phi \times}(\mathbf{x}_{i-1}|\mathbf{x}_i)$ 。

具体从随机种子 $\mathbf{x}_L \sim p_{\text{prior}} = \mathcal{N}(\mathbf{0}, \mathbf{I})$ 开始，在 $i = L, L-1, \dots, 1$ 时按以下更新规则递归从 $p_{\phi \times}(\mathbf{x}_{i-1}|\mathbf{x}_i)$ 采样：

$$\mathbf{x}_{i-1} \leftarrow \underbrace{\frac{1}{\alpha_i} \left(\mathbf{x}_i - \frac{1 - \alpha_i^2}{\sqrt{1 - \bar{\alpha}_i^2}} \epsilon_{\phi \times}(\mathbf{x}_i, i) \right)}_{\mu_{\phi \times}(\mathbf{x}_i, i)} + \sigma(i) \epsilon_i, \quad \epsilon_i \sim \mathcal{N}(\mathbf{0}, \mathbf{I}). \quad (2.2.14)$$

这一“去噪”过程持续至获得最终干净生成样本 $\mathbf{x}_0$ 。

DDPM 采样的另一解释。 由式 (2.2.12)，噪声估计 $\epsilon_{\phi \times}(\mathbf{x}_i, i)$ 对应的干净样本预测为

$$\mathbf{x}_{\phi \times}(\mathbf{x}_i, i) = \frac{\mathbf{x}_i - \sqrt{1 - \bar{\alpha}_i^2} \epsilon_{\phi \times}(\mathbf{x}_i, i)}{\bar{\alpha}_i}.$$

将其代入式 (2.2.14) 的 DDPM 采样规则，得到等价更新：

$$\mathbf{x}_{i-1} \leftarrow (\mathbf{x}_i \text{ 与干净预测 } \mathbf{x}_{\phi \times} \text{ 之间的插值}) + \sigma(i) \epsilon_i$$

表明每一步以预测干净样本为中心，再加入由 $\sigma(i)$ 缩放的高斯噪声。

这揭示 DDPM 采样可看作迭代去噪，交替执行：

1. 从当前含噪输入 $\mathbf{x}_i$ 估计干净数据 $\mathbf{x}_{\phi \times}(\mathbf{x}_i, i)$ ，
2. 用此干净估计，按更新规则采样噪声较小的潜变量 $\mathbf{x}_{i-1}$ 。

然而，即使 $\mathbf{x}_{\phi \times}$ 训练为最优去噪器（即条件期望最小化解，见式 (2.2.11)），也只能预测给定 $\mathbf{x}_i$ 时的平均干净样本。此限制使预测模糊，尤其在高噪声水平下，从严重受损输入恢复精细结构很困难。

从此视角，扩散采样通常从高噪声走向低噪声，逐渐细化干净信号估计。早期步骤确定整体结构，后期添加精细细节，噪声移除时样本越来越逼真。

DDPM 采样速度缓慢。 DDPM（也称扩散模型）的反向过程是顺序的，因此采样本质上缓慢⁴，受到以下因素限制。

定理 2.2.1 表明，表达力充分的 $p_{\phi}(\mathbf{x}_{i-1}|\mathbf{x}_i)$ 理论上可匹配真实反向分布 $p(\mathbf{x}_{i-1}|\mathbf{x}_i)$ 。但实践中通常用高斯分布建模前者以近似后者，限制了表达力。

前向噪声尺度 β_i 较小时，真实反向分布近似高斯，可准确逼近；反之，大 β_i 引起多模态或强非高斯性，单一高斯分布无法刻画。为保持准确，DDPM 使用许多小 β_i 步

³用符号“ $\times$ ”表示模型已训练并冻结。

⁴DDPM 通常需要 1,000 个去噪步骤。




图 2.6: 采用干净预测的 DDPM 采样示意图: 从 $\mathbf{x}_i$ 估计 $\mathbf{x}_{\phi^\times}(\mathbf{x}_i, i)$, 再更新至 $\mathbf{x}_{i-1}$.

骤, 形成每步依赖前一步并需要网络计算 $\epsilon_{\phi^\times}(\mathbf{x}_i, i)$ 的顺序链. 因此需要 $\mathcal{O}(L)$ 次顺序传播, 无法并行, 生成缓慢.

章 4 将此固有采样瓶颈更有原则地解释为微分方程问题, 从而启发加速生成的连续时间数值策略.

2.3 结束语

本章从变分视角追溯扩散模型的起源. 从基础生成模型变分自编码器 (VAE) 开始, 它通过证据下界 (ELBO) 学习数据与结构化潜在空间间的概率映射. 层级 VAE (HVAE) 堆叠潜变量层, 扩展此思想, 引入逐步、由粗到细生成的强大概念. 但这些模型在训练稳定性和样本质量上有挑战.

然后将去噪扩散概率模型 (DDPM) 表述为变分框架中的关键演进. 固定编码器为逐步加噪过程、仅学习反向去噪, 巧妙避开 HVAE 的训练不稳定. 关键是, 我们说明 DDPM 也通过最大化对数似然的变分界训练, 目标分解为一系列简单去噪任务. 可处理性来自强大的条件化策略, 将难以处理的边缘目标化为易于处理的条件目标, 这是扩散模型中反复出现的主题.

此变分框架为 DDPM 提供完整、有力的基础, 却非唯一理解方式. 能量建模原理给出另一同样基本的视角. 下一章探索基于得分的视角:

1. 焦点从学习去噪转移概率 $p_\phi(\mathbf{x}_{i-1}|\mathbf{x}_i)$ 转为直接学习数据对数密度的梯度, 即得分函数.
2. 我们将看到源于 EBM 的方法如何导出噪声条件得分网络 (NCSN), 并揭示 DDPM 学得的噪声预测 (ϵ 预测) 与得分函数本身的深刻数学等价性.

这一视角带来新的洞见, 也为后文将建立的统一连续时间扩散框架提供另一基石.

第 3 章 基于得分的视角：从 EBM 到 NCSN

前几章从变分根源追溯扩散模型，说明它们如何出现于 VAE 框架。现在转向另一同样基本的观点：能量模型 (*energy-based model*) (EBM) (Ackley, Hinton, and Sejnowski, 1985; LeCun et al., 2006)。EBM 用在数据处低、别处高的能量景观表示分布。采样通常依靠朗之万动力学 (Langevin dynamics)，沿景观梯度使样本走向高密度区域。此梯度场称为得分，指向概率较高的方向。

核心观察是，知道得分就足以生成：无需计算难以处理的归一化常数，它就能将样本移向高概率区域。基于得分的扩散模型直接建立于此思想。它们不仅关注干净数据分布，而是考虑一系列得分更易逼近的高斯噪声扰动分布。学习这些得分得到一族向量场，引导含噪样本逐步回到数据，将生成化为渐进去噪。

3.1 能量模型

对已熟悉 EBM 的读者，本节是简明回顾，也是通向扩散的得分视角的桥梁。

3.1.1 用能量函数建模概率分布

令 $\mathbf{x} \in \mathbb{R}^D$ 表示数据点. EBM 通过参数为 ϕ 的能量函数 $E_\phi(\mathbf{x})$ 定义概率密度，为较可能的构型赋予较低能量. 分布为

$$p_\phi(\mathbf{x}) := \frac{\exp(-E_\phi(\mathbf{x}))}{Z_\phi}, \quad Z_\phi := \int_{\mathbb{R}^D} \exp(-E_\phi(\mathbf{x})) d\mathbf{x},$$

其中 Z_ϕ 称为配分函数，保证归一化：

$$\int_{\mathbb{R}^D} p_\phi(\mathbf{x}) d\mathbf{x} = 1.$$




图 3.1: **EBM 训练示意图**. 模型在“坏”数据点降低密度（提高能量，红色箭头），在“好”数据点提高密度（降低能量，绿色箭头）。

从此视角，低能量点对应高概率，像球滚入谷地. 配分函数 Z_ϕ 保证所有概率之和为一，因此只有能量的相对值重要. 例如，给全部能量加常数，使分子分母同乘一个因子，分布不变.

配分函数 Z_ϕ 强制概率之和为一，因此数学上降低某区域的能量会提高其概率，同时其补集概率相应降低. EBM 遵循严格的全局权衡：加深一处谷地必然使其他谷地变浅，概率质量在整个空间重分配，而非对各区域独立赋值.

EBM 最大似然训练的挑战. 原则上 EBM 可通过最大似然训练, 天然平衡数据拟合与全局正则化 (见式 (1.1.2)):

$$\begin{aligned}\mathcal{L}_{\text{MLE}}(\phi) &= \mathbb{E}_{p_{\text{data}}(\mathbf{x})} \left[\log \frac{\exp(-E_{\phi}(\mathbf{x}))}{Z_{\phi}} \right] \\ &= - \underbrace{\mathbb{E}_{p_{\text{data}}}[E_{\phi}(\mathbf{x})]}_{\text{降低数据能量}} - \underbrace{\log \int \exp(-E_{\phi}(\mathbf{x})) \, d\mathbf{x}}_{\text{全局正则化}},\end{aligned}\tag{3.1.1}$$

其中 $Z_{\phi} = \int \exp(-E_{\phi}(\mathbf{x})) \, d\mathbf{x}$. 第一项降低真实数据的能量, 第二项通过配分函数强制归一化.

但高维中计算 $\log Z_{\phi}$ 及梯度难以处理, 需要模型分布下的期望. 这促使使用替代目标, 近似此项, 例如对比散度 (Hinton, 2002), 或通过得分匹配完全绕开它.

下文先在节 3.1.2 介绍得分函数, 在节 3.1.3 给出绕开配分函数的易于处理训练目标——得分匹配, 再在节 3.1.4 讨论利用得分函数的实用采样方法——朗之万动力学.

3.1.2 动机：什么是得分？

对 $\mathbb{R}^D$ 上密度 $p(\mathbf{x})$ ，得分函数是对数密度梯度：

$$\mathbf{s}(\mathbf{x}) := \nabla_{\mathbf{x}} \log p(\mathbf{x}), \quad \mathbf{s}: \mathbb{R}^D \rightarrow \mathbb{R}^D.$$

直观上，得分形成指向较高概率区域的向量场，提供数据最可能出现位置的局部指引（见图 3.2）。




图 3.2: 得分向量场示意图. 得分向量场 $\nabla_{\mathbf{x}} \log p(\mathbf{x})$ 指示密度增大的方向.

为什么建模得分而非密度？ 建模得分在理论与实践上都有益处：

摆脱归一化常数. 许多分布仅由未归一化密度 $\tilde{p}(\mathbf{x})$ 定义，例如 EBM 的 $\exp(-E_{\phi}(\mathbf{x}))$ ：

$$p(\mathbf{x}) = \frac{\tilde{p}(\mathbf{x})}{Z}, \quad Z = \int \tilde{p}(\mathbf{x}) \, d\mathbf{x}.$$

虽然计算 Z 难以处理，得分只依赖 $\tilde{p}$ ：

$$\nabla_{\mathbf{x}} \log p(\mathbf{x}) = \nabla_{\mathbf{x}} \log \tilde{p}(\mathbf{x}) - \underbrace{\nabla_{\mathbf{x}} \log Z}_{=0} = \nabla_{\mathbf{x}} \log \tilde{p}(\mathbf{x}), \quad (3.1.2)$$

因为 Z 相对于 $\mathbf{x}$ 是常数. 因而完全绕开配分函数.

完整表示. 得分函数完整刻画潜在分布. 由于它是对数密度梯度, 可通过下式恢复密度 (相差常数):

$$\log p(\mathbf{x}) = \log p(\mathbf{x}_0) + \int_0^1 \mathbf{s}(\mathbf{x}_0 + t(\mathbf{x} - \mathbf{x}_0))^\top (\mathbf{x} - \mathbf{x}_0) dt,$$

其中 $\mathbf{x}_0$ 是参考点, $\log p(\mathbf{x}_0)$ 由归一化确定. 因此建模得分与建模 $p(\mathbf{x})$ 本身具有同等表达力, 但生成建模中通常更易处理.

3.1.3 通过得分匹配训练 EBM

EBM 的密度定义为 $p_\phi(\mathbf{x}) = \frac{\exp(-E_\phi(\mathbf{x}))}{Z_\phi}$. 最大似然训练需要计算通常难以处理的 Z_ϕ . 关键观察是模型 p_ϕ 的得分简化为 $-\nabla_{\mathbf{x}} E_\phi(\mathbf{x})$, 不依赖 Z_ϕ (见式 (3.1.2)).

得分匹配 (Hyvärinen and Dayan, 2005) 利用得分仅依赖能量函数这一事实, 不拟合归一化概率, 而是将模型得分与 (未知) 数据得分对齐来训练 EBM:

$$\mathcal{L}_{\text{SM}}(\phi) = \frac{1}{2} \mathbb{E}_{p_{\text{data}}(\mathbf{x})} \left\| \nabla_{\mathbf{x}} \log p_\phi(\mathbf{x}) - \nabla_{\mathbf{x}} \log p_{\text{data}}(\mathbf{x}) \right\|_2^2. \quad (3.1.3)$$

虽然数据得分不可访问, 分部积分给出仅含能量及其导数的等价表达 (更多细节见命题 3.2.1):

$$\mathcal{L}_{\text{SM}}(\phi) = \mathbb{E}_{p_{\text{data}}(\mathbf{x})} \left[\text{Tr}(\nabla_{\mathbf{x}}^2 E_\phi(\mathbf{x})) + \frac{1}{2} \|\nabla_{\mathbf{x}} E_\phi(\mathbf{x})\|_2^2 \right] + C,$$

其中 $\nabla_{\mathbf{x}}^2 E_\phi(\mathbf{x})$ 是 E_ϕ 的 Hessian 矩阵, C 与 ϕ 无关.

此表述消除配分函数, 训练时不必从模型采样, 十分有吸引力. 主要缺点是需要二阶导数, 在高维中计算成本可能难以承受. 后文将再讨论解决方法.

3.1.4 使用得分函数的朗之万采样

可用朗之万动力学从由能量函数 $E_\phi(\mathbf{x})$ 定义的 EBM 采样. 先介绍离散时间更新, 再给出随机微分方程 (SDE) 形式的连续时间极限, 最后讨论它为何能有效探索复杂能量景观的物理直觉.

离散时间朗之万动力学. 离散时间更新为

$$\mathbf{x}_{n+1} = \mathbf{x}_n - \eta \nabla_{\mathbf{x}} E_\phi(\mathbf{x}_n) + \sqrt{2\eta} \boldsymbol{\epsilon}_n, \quad n = 0, 1, 2, \dots, \quad (3.1.4)$$

其中 $\mathbf{x}_0$ 从某分布 (常为高斯) 初始化, $\eta > 0$ 为步长, $\boldsymbol{\epsilon}_n \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 为高斯噪声. 添加随机性使噪声能够探索局部极小值之外的区域.

由于得分函数可计算为

$$\nabla_{\mathbf{x}} \log p_\phi(\mathbf{x}) = -\nabla_{\mathbf{x}} E_\phi(\mathbf{x}).$$

更新等价地写为

$$\mathbf{x}_{n+1} = \mathbf{x}_n + \eta \nabla_{\mathbf{x}} \log p_\phi(\mathbf{x}_n) + \sqrt{2\eta} \boldsymbol{\epsilon}_n, \quad (3.1.5)$$

得分函数引导样本走向高密度区域. 这一表述是扩散模型的核心, 后文将详细说明.




图 3.3: **朗之万采样示意图**. 利用得分函数 $\nabla_{\mathbf{x}} \log p_{\phi}(\mathbf{x})$, 通过式 (3.1.5) 的更新引导轨迹走向高密度区域 (由箭头指示) .

连续时间朗之万动力学. 步长 η 趋于零时, 离散更新自然收敛到由朗之万随机微分方程 (SDE) 描述的时间连续过程¹:

$$d\mathbf{x}(t) = \nabla_{\mathbf{x}} \log p_{\phi}(\mathbf{x}(t)) dt + \sqrt{2} d\mathbf{w}(t), \quad (3.1.6)$$

其中 $\mathbf{w}(t)$ 表示标准布朗运动 (也称 Wiener 过程²) . 应理解, 式 (3.1.4) 是该连续 SDE 的 Euler-Maruyama 离散化.

在标准正则假设下 (例如 $p_{\phi} \propto e^{-E_{\phi}}$ 且 E_{ϕ} 具有约束性、足够光滑), $\mathbf{x}(t)$ 的分布在 $t \rightarrow \infty$ 时 (指数快速地) 收敛到 p_{ϕ} ; 所以可以模拟 (求解) SDE 式 (3.1.6) 来采样.

为什么用朗之万采样? 通过物理视角可自然理解: 能量函数 $E_{\phi}(\mathbf{x})$ 定义影响粒子行为的势能景观. 按 Newton 动力学, 粒子在由能量导出的力场中的运动由 ODE 描述:

$$d\mathbf{x}(t) = -\nabla_{\mathbf{x}} E_{\phi}(\mathbf{x}(t)) dt,$$

它确定性地驱动粒子下滑至能量局部极小值. 但此动力学可能陷入局部极小, 无法探索完整数据分布.

¹因子 $\sqrt{2}$ 使动力学随时间保持 p_{ϕ} 不变. 即 p_{ϕ} 为平稳分布: 若 $\mathbf{x}(0) \sim p_{\phi}$, 则所有 $t \geq 0$ 有 $\mathbf{x}(t) \sim p_{\phi}$. 等价地, p_{ϕ} 为 Fokker-Planck 方程的平稳解 (见章 B):

$$\partial_t \rho = -\nabla \cdot (\rho \nabla \log p_{\phi}) + \frac{\sigma^2}{2} \Delta \rho.$$

令 $\rho = p_{\phi}$ 得 $(\frac{\sigma^2}{2} - 1) \Delta p_{\phi} = 0$, 仅在 $\sigma = \sqrt{2}$ 时成立.

²布朗增量满足 $\mathbf{w}(t+\eta) - \mathbf{w}(t) \sim \mathcal{N}(\mathbf{0}, \eta \mathbf{I})$. 因此 Euler-Maruyama 使用步噪声 $\sqrt{2}[\mathbf{w}(t+\eta) - \mathbf{w}(t)] = \sqrt{2\eta} \epsilon_n$, 其中 $\epsilon_n \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$, 解释了 $\sqrt{\eta}$ 因子, 这是平方根缩放的来源. 布朗运动和 SDE 的详细介绍见章 A.

为克服此限制，朗之万动力学引入随机扰动，得到 SDE

$$d\mathbf{x}(t) = -\nabla_{\mathbf{x}} E_{\phi}(\mathbf{x}(t)) dt + \underbrace{\sqrt{2} d\mathbf{w}(t)}_{\text{注入噪声}},$$

其中 $\mathbf{w}(t)$ 是标准布朗运动。噪声项使粒子跨越能垒、逃出局部极小，使轨迹成为随机过程，其平稳分布收敛到 Boltzmann 分布

$$p_{\phi}(\mathbf{x}) \propto e^{-E_{\phi}(\mathbf{x})}.$$

从此视角，EBM 学习推动样本走向高概率区域的力场。朗之万采样对 EBM 尤为有用，因为它无需显式计算配分函数，就提供从模型分布 $p_{\phi}(\mathbf{x})$ 生成样本的实用方法。迭代更新得到近似目标分布的样本。

朗之万采样的固有挑战。 朗之万动力学是广泛使用的基于 MCMC 的采样器，在高维空间有严重局限。效率对步长 η 、噪声尺度及准确逼近目标所需迭代次数高度敏感。

低效的核心是“混合时间”不佳：复杂数据分布有许多孤立模态，朗之万采样通常需要极长时间才能在高概率区域之间转移。维数增大时显著恶化，收敛缓慢到难以承受。

可将采样看作探索广阔、崎岖且有许多遥远谷地的景观，每个谷地对应数据模态。依赖局部随机更新的朗之万动力学难以高效跨越谷地，因此往往不能捕捉分布的完整多样性。

这说明需要更结构化、更有引导的采样方法，比纯随机探索更有效地导航复杂数据流形。

3.2 从能量模型到基于得分的生成模型

EBM 表明，生成只依赖指向较高概率区域的得分，无需完整归一化密度。虽然得分匹配避免配分函数，通过能量训练仍需要昂贵二阶导数。关键思想是：朗之万采样仅需得分，因此可用神经网络直接学习它。从建模能量转向建模得分，构成基于得分的生成模型的基础。




图 3.4: **得分匹配示意图**. 神经网络得分 $\mathbf{s}_\phi(\mathbf{x})$ 通过 MSE 损失训练以匹配真实得分 $\mathbf{s}(\mathbf{x})$ ，两者都表示为向量场。

3.2.1 用得分匹配训练

得分匹配. 为从 p_{data} 的样本逼近得分函数 $\mathbf{s}(\mathbf{x}) = \nabla_{\mathbf{x}} \log p_{\text{data}}(\mathbf{x})$ ，直接用网络参数化向量场 $\mathbf{s}_\phi(\mathbf{x})$ 近似它（见图 3.4）：

$$\mathbf{s}_\phi(\mathbf{x}) \approx \mathbf{s}(\mathbf{x}).$$

得分匹配通过最小化真实与估计得分的均方误差（MSE）拟合向量场：

$$\mathcal{L}_{\text{SM}}(\phi) := \frac{1}{2} \mathbb{E}_{\mathbf{x} \sim p_{\text{data}}} \left[\|\mathbf{s}_\phi(\mathbf{x}) - \mathbf{s}(\mathbf{x})\|_2^2 \right]. \quad (3.2.1)$$

易于处理的得分匹配. 乍看此目标不可行，因为回归目标——真实得分 $\mathbf{s}(\mathbf{x})$ ——未知。幸运的是，Hyvärinen and Dayan (2005) 证明分部积分给出仅依赖模型 $\mathbf{s}_\phi$ 和数据样本的等价目标，无需真实得分。关键结果如下：

命题 3.2.1: Hyvärinen 的易于处理 SM 形式

以下等式可写为：

$$\mathcal{L}_{\text{SM}}(\phi) = \tilde{\mathcal{L}}_{\text{SM}}(\phi) + C.$$

其中

$$\tilde{\mathcal{L}}_{\text{SM}}(\phi) := \mathbb{E}_{\mathbf{x} \sim p_{\text{data}}(\mathbf{x})} \left[\text{Tr}(\nabla_{\mathbf{x}} \mathbf{s}_{\phi}(\mathbf{x})) + \frac{1}{2} \|\mathbf{s}_{\phi}(\mathbf{x})\|_2^2 \right], \quad (3.2.2)$$

C 为与 ϕ 无关的常数. 最小化解为 $\mathbf{s}^*(\cdot) = \nabla_{\mathbf{x}} \log p(\cdot)$.

命题的证明.

展开 $\mathcal{L}_{\text{SM}}$ 的 MSE 并用分部积分即可得到结果. 证明见节 D.2.1. ■

利用式 (3.2.2) 的等价目标, 仅用 p_{data} 的观测样本训练得分模型 $\mathbf{s}_{\phi}(\mathbf{x})$, 不再需要真实得分函数.

式 (3.2.2) 的直觉. 替代得分匹配目标 $\tilde{\mathcal{L}}_{\text{SM}}(\phi)$ 可从两项直接理解. 范数项 $\frac{1}{2} \|\mathbf{s}_{\phi}(\mathbf{x})\|^2$ 在 p_{data} 较大处压低得分, 使其平稳. 散度项 $\text{Tr}(\nabla_{\mathbf{x}} \mathbf{s}_{\phi}(\mathbf{x}))$ 偏好负值, 使平稳点成为吸引的汇点. 共同作用将高密度区域塑造成得分场稳定、收缩的点. 下面详细解释.

幅值项带来的平稳性. 期望 $\tilde{\mathcal{L}}_{\text{SM}}(\phi)$ 在 p_{data} 下取, 故 $p_{\text{data}}(\mathbf{x})$ 大的区域 (数据高密度处) 对损失贡献最多. 因而幅值项 $\frac{1}{2} \|\mathbf{s}_{\phi}(\mathbf{x})\|^2$ 恰在高概率处驱动 $\mathbf{s}_{\phi}(\mathbf{x}) \rightarrow 0$, 使这些位置平稳.

场 (近似) 为梯度时的凹性. 散度项 $\text{Tr}(\nabla_{\mathbf{x}} \mathbf{s}_{\phi}(\mathbf{x}))$ 鼓励高密度区域中的向量场具有负散度. 负散度表示邻近向量汇聚而非散开, 故该区域的平稳点成为汇点, 吸引邻近轨迹向内. 精确而言, 假设 $\mathbf{s}_{\phi} = \nabla_{\mathbf{x}} u$, 其中 $u : \mathbb{R}^D \rightarrow \mathbb{R}$ 为标量函数; 匹配对数密度时这是自然的. 则 $\nabla_{\mathbf{x}} \mathbf{s}_{\phi} = \nabla_{\mathbf{x}}^2 u$ (Hessian), $\nabla \cdot \mathbf{s}_{\phi}(\mathbf{x}) = \text{Tr}(\nabla_{\mathbf{x}}^2 u(\mathbf{x}))$ (散度).

在平稳点 $\mathbf{x}_{\star}$ 有 $\mathbf{s}_{\phi}(\mathbf{x}_{\star}) = \nabla_{\mathbf{x}} u(\mathbf{x}_{\star}) = \mathbf{0}$, 二阶 Taylor 展开给出

$$u(\mathbf{x}) = u(\mathbf{x}_{\star}) + \frac{1}{2} (\mathbf{x} - \mathbf{x}_{\star})^{\top} \nabla_{\mathbf{x}}^2 u(\mathbf{x}_{\star}) (\mathbf{x} - \mathbf{x}_{\star}) + o(\|\mathbf{x} - \mathbf{x}_{\star}\|^2).$$

若 Hessian $\nabla_{\mathbf{x}}^2 u(\mathbf{x}_{\star})$ 负定, 则 u 在 $\mathbf{x}_{\star}$ 附近局部凹, 对数密度达到严格局部极大³. Hessian 的全部特征值为负, 故迹也为负: $\text{Tr}(\nabla_{\mathbf{x}}^2 u(\mathbf{x}_{\star})) < 0$. 所以学得向量场具有负散度, 平稳点是汇点: 小扰动收缩回 $\mathbf{x}_{\star}$.

³严格凹性 (因而严格局部对数密度极大) 要求整个 Hessian $\nabla_{\mathbf{x}}^2 u$ 负定, 而不只具有负迹. 负迹仅保证特征值之和为负, 某些特征值仍可为正, 导致鞍点而非极大点.

3.2.2 用朗之万动力学采样

最小化式 (3.2.2) 训练后, 得分模型 $\mathbf{s}_{\phi^\times}(\mathbf{x})$ 可替代朗之万动力学中的理想得分:

$$\mathbf{x}_{n+1} = \mathbf{x}_n + \eta \mathbf{s}_{\phi^\times}(\mathbf{x}_n) + \sqrt{2\eta} \boldsymbol{\epsilon}_n, \quad \boldsymbol{\epsilon}_n \sim \mathcal{N}(\mathbf{0}, \mathbf{I}), \quad (3.2.3)$$

$n = 0, 1, 2, \dots$, 从 $\mathbf{x}_0$ 初始化. 如 EBM 的式 (3.1.6), 此递归恰为连续时间朗之万 SDE 的 Euler-Maruyama 离散化:

$$d\mathbf{x}(t) = \mathbf{s}_{\phi^\times}(\mathbf{x}(t)) dt + \sqrt{2} d\mathbf{w}(t),$$

初值为 $\mathbf{x}(0)$. 因而小步长极限中离散与连续表述一致. 实践中可运行离散采样器, 也可直接模拟 SDE.

3.2.3 序言: 基于得分的生成模型

本章余下部分研究得分函数在现代扩散模型中的基础作用. 最初为高效训练 EBM 引入的得分函数, 已成为新一代生成模型的核心组件. 在此基础上, 探索它如何影响基于得分的扩散模型的理论表述与实际实现, 为通过随机过程生成数据提供有原则的框架.

3.3 去噪得分匹配

3.3.1 动机

虽然式 (3.2.2) 的替代目标

$$\tilde{\mathcal{L}}_{\text{SM}}(\phi) = \mathbb{E}_{\mathbf{x} \sim p_{\text{data}}} \left[\text{Tr}(\nabla_{\mathbf{x}} \mathbf{s}_{\phi}(\mathbf{x})) + \frac{1}{2} \|\mathbf{s}_{\phi}(\mathbf{x})\|_2^2 \right]$$

更易处理，仍需计算雅可比矩阵的迹 $\text{Tr}(\nabla_{\mathbf{x}} \mathbf{s}_{\phi}(\mathbf{x}))$ ，最坏复杂度 $\mathcal{O}(D^2)$ ，限制扩展到高维数据。

为此，切片得分匹配 (Song et al., 2020a) 用基于随机投影的随机估计替代迹项。简要介绍如下。

切片得分匹配与 Hutchinson 估计量。 沿随机“切片”平均方向导数，替代得分匹配的迹。令 $\mathbf{u} \in \mathbb{R}^D$ 为各向同性随机向量（如 Rademacher 或标准高斯），满足 $\mathbb{E}[\mathbf{u}] = 0$ 且 $\mathbb{E}[\mathbf{u}\mathbf{u}^\top] = \mathbf{I}$ 。由 Hutchinson 恒等式

$$\text{Tr}(\mathbf{A}) = \mathbb{E}_{\mathbf{u}}[\mathbf{u}^\top \mathbf{A} \mathbf{u}], \quad \text{且} \quad \mathbb{E}_{\mathbf{u}}[(\mathbf{u}^\top \mathbf{s}_{\phi}(\mathbf{x}))^2] = \|\mathbf{s}_{\phi}(\mathbf{x})\|_2^2,$$

得到精确形式

$$\tilde{\mathcal{L}}_{\text{SM}}(\phi) = \mathbb{E}_{\mathbf{x}, \mathbf{u}} \left[\mathbf{u}^\top (\nabla_{\mathbf{x}} \mathbf{s}_{\phi}(\mathbf{x})) \mathbf{u} + \frac{1}{2} (\mathbf{u}^\top \mathbf{s}_{\phi}(\mathbf{x}))^2 \right].$$

可利用自动微分，通过雅可比—向量和向量—雅可比乘积 (JVP / VJP) 高效计算，避免显式计算大雅可比或 Hessian 矩阵。对 K 个随机探测向量平均，得到方差为 $\mathcal{O}(1/K)$ 的无偏估计；方向项 $\mathbf{u}^\top (\nabla_{\mathbf{x}} \mathbf{s}_{\phi}) \mathbf{u}$ 也可用 JVP / VJP 高效计算而无需显式雅可比。直观上只检查随机方向的模型行为，将投影得分推向数据密度较高的区域，使数据点在期望意义下平稳。

从切片到去噪得分匹配。 切片得分匹配绕开雅可比，但仍依赖原始数据分布，因而脆弱：对位于低维流形的图像数据，得分 $\nabla_{\mathbf{x}} \log p_{\text{data}}(\mathbf{x})$ 可能未定义或不稳定；方法仅约束观测点处的向量场，对其邻域控制很弱。还存在探测向量引入的方差及重复 JVP / VJP 成本。

更稳健的选择，也是本节重点，是去噪得分匹配 (*denoising score matching*) (DSM) (Vincent, 2011)，提供有原则、可扩展的解决方法。

3.3.2 训练

回顾式 (3.2.1) 的 SM 损失：

$$\mathcal{L}_{\text{SM}}(\phi) = \frac{1}{2} \mathbb{E}_{\mathbf{x} \sim p_{\text{data}}(\mathbf{x})} [\|\mathbf{s}_{\phi}(\mathbf{x}) - \nabla_{\mathbf{x}} \log p_{\text{data}}(\mathbf{x})\|_2^2],$$

困难来自难以处理项 $\nabla_{\mathbf{x}} \log p_{\text{data}}(\mathbf{x})$ 。

Vincent (2011) 的条件化方法. 为克服 $\nabla_{\mathbf{x}} \log p_{\text{data}}(\mathbf{x})$ 的难以处理性, Vincent (2011) 提议通过已知、尺度为 σ 的条件分布 $p_{\sigma}(\tilde{\mathbf{x}}|\mathbf{x})$ 向数据 $\mathbf{x} \sim p_{\text{data}}$ 注入噪声. 训练网络 $\mathbf{s}_{\phi}(\tilde{\mathbf{x}}; \sigma)$ 逼近边缘扰动分布的得分:

$$p_{\sigma}(\tilde{\mathbf{x}}) = \int p_{\sigma}(\tilde{\mathbf{x}}|\mathbf{x}) p_{\text{data}}(\mathbf{x}) d\mathbf{x}$$

通过最小化损失

$$\mathcal{L}_{\text{SM}}(\phi; \sigma) := \frac{1}{2} \mathbb{E}_{\tilde{\mathbf{x}} \sim p_{\sigma}} [\|\mathbf{s}_{\phi}(\tilde{\mathbf{x}}; \sigma) - \nabla_{\tilde{\mathbf{x}}} \log p_{\sigma}(\tilde{\mathbf{x}})\|_2^2]. \quad (3.3.1)$$

虽然 $\nabla_{\tilde{\mathbf{x}}} \log p_{\sigma}(\tilde{\mathbf{x}})$ 通常难以处理, Vincent (2011) 表明条件化于 $\mathbf{x} \sim p_{\text{data}}$ 给出等价、易于处理的去噪得分匹配 (DSM) 损失:

$$\mathcal{L}_{\text{DSM}}(\phi; \sigma) := \frac{1}{2} \mathbb{E}_{\mathbf{x} \sim p_{\text{data}}, \tilde{\mathbf{x}} \sim p_{\sigma}(\cdot|\mathbf{x})} [\|\mathbf{s}_{\phi}(\tilde{\mathbf{x}}; \sigma) - \nabla_{\tilde{\mathbf{x}}} \log p_{\sigma}(\tilde{\mathbf{x}}|\mathbf{x})\|_2^2]. \quad (3.3.2)$$

式 (3.3.2) 的最优解 $\mathbf{s}^*$ 满足

$$\mathbf{s}^*(\tilde{\mathbf{x}}; \sigma) = \nabla_{\tilde{\mathbf{x}}} \log p_{\sigma}(\tilde{\mathbf{x}}),$$

它对式 (3.3.1) 也最优.

例如 $p_{\sigma}(\tilde{\mathbf{x}}|\mathbf{x})$ 为方差 σ^2 的高斯噪声时,

$$p_{\sigma}(\tilde{\mathbf{x}}|\mathbf{x}) = \mathcal{N}(\tilde{\mathbf{x}}; \mathbf{x}, \sigma^2 \mathbf{I}),$$

梯度 $\nabla_{\tilde{\mathbf{x}}} \log p_{\sigma}(\tilde{\mathbf{x}}|\mathbf{x})$ 有闭式表达 (见式 (3.3.4)), 回归目标因而显式且计算易于处理.

此外, 当 $\sigma \approx 0$, $p_{\sigma}(\tilde{\mathbf{x}}) \approx p_{\text{data}}(\mathbf{x})$, 且

$$\mathbf{s}^*(\tilde{\mathbf{x}}; \sigma) = \nabla_{\tilde{\mathbf{x}}} \log p_{\sigma}(\tilde{\mathbf{x}}) \approx \nabla_{\mathbf{x}} \log p_{\text{data}}(\mathbf{x}),$$

说明学得得分近似原始数据得分, 可用于生成.

将 $\mathcal{L}_{\text{SM}}$ 与 $\mathcal{L}_{\text{DSM}}$ 的梯度等价性形式化如下:

定理 3.3.1: $\mathcal{L}_{\text{SM}}$ 与 $\mathcal{L}_{\text{DSM}}$ 的等价性

对任意固定噪声尺度 $\sigma > 0$, 有

$$\mathcal{L}_{\text{SM}}(\phi; \sigma) = \mathcal{L}_{\text{DSM}}(\phi; \sigma) + C, \quad (3.3.3)$$

其中 C 与参数 ϕ 无关. 两种损失的最小化解 $\mathbf{s}^*(\cdot; \sigma)$ 满足

$$\mathbf{s}^*(\tilde{\mathbf{x}}; \sigma) = \nabla_{\tilde{\mathbf{x}}} \log p_{\sigma}(\tilde{\mathbf{x}}), \quad \text{对几乎所有 } \tilde{\mathbf{x}}.$$




图 3.5: **通过条件化实现 DSM 的示意图**. 用小的加性高斯噪声 $\mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I})$ 扰动数据分布 p_{data} , 得到的条件分布 $p_{\sigma}(\tilde{\mathbf{x}}|\mathbf{x}) = \mathcal{N}(\tilde{\mathbf{x}}; \mathbf{x}, \sigma^2 \mathbf{I})$ 具有闭式得分函数.

定理的证明.

等价性来自直接计算: 展开 $\mathcal{L}_{\text{SM}}$ 与 $\mathcal{L}_{\text{DSM}}$ 中的 MSE, 所有依赖 ϕ 的项抵消, 仅留下与 ϕ 无关的常数差.

最小化解的推导与命题 4.2.1 相同.

此定理与 DDPM 的定理 2.2.1 一样, 体现关键共同原则:

洞见 3.3.1: 条件化技术

DDPM 的变分视角也使用条件化 (见定理 2.2.1): 条件化于数据点 $\mathbf{x}$, 将难以处理的损失变成可用蒙特卡洛估计的易于处理损失. 基于流的视角中也有类似思想 (如流匹配 (Lipman et al., 2022)), 见节 5.2.

特例: 加性高斯噪声. 考虑常见情形: 对各数据点 $\mathbf{x} \sim p_{\text{data}}$ 添加方差 σ^2 的高斯噪声 $\mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I})$:

$$\tilde{\mathbf{x}} = \mathbf{x} + \sigma \boldsymbol{\epsilon}, \quad \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}),$$

受损数据 $\tilde{\mathbf{x}}$ 服从

$$p_{\sigma}(\tilde{\mathbf{x}}|\mathbf{x}) = \mathcal{N}(\tilde{\mathbf{x}}; \mathbf{x}, \sigma^2 \mathbf{I}).$$

此时条件得分的解析形式为

$$\nabla_{\tilde{\mathbf{x}}} \log p_{\sigma}(\tilde{\mathbf{x}}|\mathbf{x}) = \frac{\mathbf{x} - \tilde{\mathbf{x}}}{\sigma^2}.$$

因此 DSM 损失简化为

$$\begin{aligned}\mathcal{L}_{\text{DSM}}(\phi; \sigma) &= \frac{1}{2} \mathbb{E}_{\mathbf{x}, \tilde{\mathbf{x}} | \mathbf{x}} \left[\left\| \mathbf{s}_{\phi}(\tilde{\mathbf{x}}; \sigma) - \frac{\mathbf{x} - \tilde{\mathbf{x}}}{\sigma^2} \right\|_2^2 \right] \\ &= \frac{1}{2} \mathbb{E}_{\mathbf{x}, \epsilon} \left[\left\| \mathbf{s}_{\phi}(\mathbf{x} + \sigma \epsilon; \sigma) + \frac{\epsilon}{\sigma} \right\|_2^2 \right],\end{aligned}\tag{3.3.4}$$

其中 $\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$. 此目标是（基于得分的）扩散模型的核心.

噪声水平 σ 小时, 高斯平滑的边缘分布 $p_{\sigma} = p_{\text{data}} * \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I})$, 故其高密度区域与得分几乎一致: $\nabla_{\tilde{\mathbf{x}}} \log p_{\sigma}(\tilde{\mathbf{x}}) \approx \nabla_{\mathbf{x}} \log p_{\text{data}}(\mathbf{x})$. 因此沿含噪得分方向 $\nabla_{\tilde{\mathbf{x}}} \log p_{\sigma}$ 走一小步, 会把含噪样本移向基本相同的干净分布高似然区域, 与节 3.2.1 总结的得分匹配直觉类似. 相反, σ 大时, 平滑“过度简化”景观: p_{σ} 冲淡局部模态, 得分主要拉向全局质量 (可想作向均值收缩), 产生可能过度平滑的粗略去噪. 但实践中 DSM 通常假设注入噪声很小、温和.

为更清楚地说明目标为何自然对应“去噪”过程, 将在节 3.3.4 和 3.3.5 展开讨论.

3.3.3 采样

得到噪声水平 σ 下已训练得分模型 $\mathbf{s}_{\phi \times}(\tilde{\mathbf{x}}; \sigma)$ 后, 用学得模型替代真实得分, 通过朗之万动力学生成样本. 更新为

$$\tilde{\mathbf{x}}_{n+1} = \tilde{\mathbf{x}}_n + \eta \underbrace{\mathbf{s}_{\phi \times}(\tilde{\mathbf{x}}_n; \sigma)}_{\approx \nabla_{\tilde{\mathbf{x}}} \log p_{\sigma}(\tilde{\mathbf{x}}_n)} + \sqrt{2\eta} \epsilon_n, \quad \epsilon_n \sim \mathcal{N}(\mathbf{0}, \mathbf{I}), \tag{3.3.5}$$

$n = 0, 1, 2, \dots$, 从初值 $\tilde{\mathbf{x}}_0$ 开始. 若 σ 足够小, 足够多次迭代后 $\tilde{\mathbf{x}}_n$ 近似 p_{data} 的样本.

注入噪声的优势. 与式 (3.2.1) 的原始得分匹配相比, 注入高斯噪声形成 p_{σ} (如式 (3.3.4)) 有两个关键优势 (Song and Ermon, 2019):

- **良定义的梯度.** 噪声使数据偏离低维流形, 产生在 $\mathbb{R}^D$ 中具有全支撑的 p_{σ} , 故得分函数 $\nabla_{\tilde{\mathbf{x}}} \log p_{\sigma}(\tilde{\mathbf{x}})$ 处处良定义.
- **更好的覆盖.** 噪声平滑模态间稀疏区域, 提高训练信号质量, 帮助朗之万动力学更有效跨越低密度区域.

3.3.4 为何 DSM 是去噪: Tweedie 公式

从 Tweedie 公式 (Efron, 2011) 开始, 它为仅从含噪观测去噪提供有原则的依据. 具体而言: 对来自未知 $\mathbf{x} \sim p_{\text{data}}$ 的单个高斯受损观测 $\tilde{\mathbf{x}} \sim \mathcal{N}(\cdot; \alpha \mathbf{x}, \sigma^2 \mathbf{I})$, 沿含噪边缘分布得分 $\nabla_{\tilde{\mathbf{x}}} \log p_{\sigma}(\tilde{\mathbf{x}})$ 的方向将 $\tilde{\mathbf{x}}$ 移动步长 σ^2 , 即可获得去噪估计 (给定 $\tilde{\mathbf{x}}$ 时对所有可能干净信号的平均). 边缘分布定义为

$$p_{\sigma}(\tilde{\mathbf{x}}) := \int \mathcal{N}(\tilde{\mathbf{x}}; \alpha \mathbf{x}_0, \sigma^2 \mathbf{I}) p_{\text{data}}(\mathbf{x}) d\mathbf{x}.$$

正式表述如下.

引理 3.3.2: Tweedie 公式

假设 $\mathbf{x} \sim p_{\text{data}}$, 给定 $\mathbf{x}$ 时 $\tilde{\mathbf{x}} \sim \mathcal{N}(\cdot; \alpha \mathbf{x}, \sigma^2 \mathbf{I})$, 其中 $\alpha \neq 0$. 则 Tweedie 公式为

$$\alpha \mathbb{E}_{\mathbf{x} \sim p(\mathbf{x}|\tilde{\mathbf{x}})} [\mathbf{x}|\tilde{\mathbf{x}}] = \tilde{\mathbf{x}} + \sigma^2 \nabla_{\tilde{\mathbf{x}}} \log p_{\sigma}(\tilde{\mathbf{x}}), \quad (3.3.6)$$

其中期望在给定 $\tilde{\mathbf{x}}$ 时 $\mathbf{x}$ 的后验分布 $p(\mathbf{x}|\tilde{\mathbf{x}})$ 下取.

引理的证明.

证明计算边缘分布的得分 $p(\tilde{\mathbf{x}}) = \int p(\tilde{\mathbf{x}}|\mathbf{x})p_{\text{data}}(\mathbf{x}) d\mathbf{x}$. 在积分号下求导、利用条件密度的高斯形式, 直接得到可整理为所需恒等式的表达, 将得分与后验均值联系起来. 细节见节 D.2.3.

Tweedie 公式在如 DDPM 引入多层噪声的扩散模型中有核心作用. 它使得可用得分函数从含噪观测估计干净样本, 建立得分预测与去噪器的基本联系:

$$\underbrace{\mathbb{E}[\mathbf{x}|\tilde{\mathbf{x}}]}_{\substack{\text{去噪器} \\ \text{估计自}\tilde{\mathbf{x}}}} = \frac{1}{\alpha} (\tilde{\mathbf{x}} + \sigma^2 \nabla_{\tilde{\mathbf{x}}} \log p_{\sigma}(\tilde{\mathbf{x}})).$$

特别地, 以特定步长 σ^2 对含噪对数似然进行单步梯度上升, 得到去噪估计(干净信号的条件平均). DSM 训练与去噪因此紧密相关: 若 DSM 训练得到 $\mathbf{s}_{\phi}(\tilde{\mathbf{x}}) \approx \nabla_{\tilde{\mathbf{x}}} \log p_{\sigma}(\tilde{\mathbf{x}})$, 则

$$\frac{1}{\alpha} (\tilde{\mathbf{x}} + \sigma^2 \mathbf{s}_{\phi}(\tilde{\mathbf{x}}))$$

就是去噪器.

(选读) 高阶 Tweedie 公式. 经典 Tweedie 公式通过梯度 $\nabla_{\tilde{\mathbf{x}}} \log p(\tilde{\mathbf{x}})$ 表达后验均值 $\mathbb{E}[\mathbf{x}_0|\tilde{\mathbf{x}}]$. 高阶扩展 (Meng et al., 2021a) 用 $\log p(\tilde{\mathbf{x}})$ 的高阶导数表达后验协方差与更高阶累积量.

具有对数归一化因子 $\lambda(\tilde{\mathbf{x}})$ 的指数族设定. 假设给定潜在自然参数 $\boldsymbol{\eta} \in \mathbb{R}^D$ 时 $\tilde{\mathbf{x}}$ 的条件分布属于自然指数族:

$$q_{\sigma}(\tilde{\mathbf{x}}|\boldsymbol{\eta}) = \exp(\boldsymbol{\eta}^{\top} \tilde{\mathbf{x}} - \psi(\boldsymbol{\eta})) q_0(\tilde{\mathbf{x}}).$$

$q_0(\tilde{\mathbf{x}})$ 为基准测度, 即不依赖 $\boldsymbol{\eta}$ 的部分; 方差 $\sigma^2 \mathbf{I}$ 的加性高斯噪声中, 它等于 $(2\pi\sigma^2)^{-D/2} \exp(-\|\tilde{\mathbf{x}}\|^2/2\sigma^2)$. 令 $p(\boldsymbol{\eta})$ 为潜在自然参数的预定义分布, 可视为重参数化

的干净数据分布（高斯位置模型中 $\boldsymbol{\eta} = \mathbf{x}/\sigma^2$ ）。观测的含噪边缘分布为

$$p_\sigma(\tilde{\mathbf{x}}) = \int q_\sigma(\tilde{\mathbf{x}}|\boldsymbol{\eta}) p(\boldsymbol{\eta}) d\boldsymbol{\eta}.$$

定义关于 $\tilde{\mathbf{x}}$ 的对数配分函数（对数归一化因子）为

$$\lambda(\tilde{\mathbf{x}}) := \log p_\sigma(\tilde{\mathbf{x}}) - \log q_0(\tilde{\mathbf{x}}).$$

则给定 $\tilde{\mathbf{x}}$ 时 $\boldsymbol{\eta}$ 的后验为

$$p(\boldsymbol{\eta}|\tilde{\mathbf{x}}) \propto \exp(\boldsymbol{\eta}^\top \tilde{\mathbf{x}} - \psi(\boldsymbol{\eta}) - \lambda(\tilde{\mathbf{x}})) p(\boldsymbol{\eta}),$$

这表明，作为 $\tilde{\mathbf{x}}$ 的函数，后验具有指数族形式，自然参数 $\tilde{\mathbf{x}}$ ，充分统计量 $\boldsymbol{\eta}$ ，对数配分函数 $\lambda(\tilde{\mathbf{x}})$ 。

λ 的导数产生后验累积量。 涉及两个简单规则。首先，归一化：对每个 $\tilde{\mathbf{x}}$ ，

$$\int \exp(\boldsymbol{\eta}^\top \tilde{\mathbf{x}} - \psi(\boldsymbol{\eta}) - \lambda(\tilde{\mathbf{x}})) p(\boldsymbol{\eta}) d\boldsymbol{\eta} = 1.$$

对 $\tilde{\mathbf{x}}$ 求导，会从指数项引出 $\boldsymbol{\eta}$ 的幂及 $\lambda(\tilde{\mathbf{x}})$ 的导数；令结果为零，得到 λ 导数与 $\boldsymbol{\eta}$ 后验矩之间的等式。其次，指数族的标准性质：对数配分函数是充分统计量的累积量生成函数。因此

$$\nabla_{\tilde{\mathbf{x}}} \lambda(\tilde{\mathbf{x}}) = \mathbb{E}[\boldsymbol{\eta}|\tilde{\mathbf{x}}], \quad \nabla_{\tilde{\mathbf{x}}}^2 \lambda(\tilde{\mathbf{x}}) = \text{Cov}[\boldsymbol{\eta}|\tilde{\mathbf{x}}], \quad \nabla_{\tilde{\mathbf{x}}}^{(k)} \lambda(\tilde{\mathbf{x}}) = \kappa_k(\boldsymbol{\eta}|\tilde{\mathbf{x}}) \quad (k \geq 3),$$

其中 κ_k 为给定 $\tilde{\mathbf{x}}$ 时随机向量 $\boldsymbol{\eta}$ 的 k 阶条件累积量，由标准矩—累积量关系获得。

这些就是高阶 Tweedie 公式。特化到 $\boldsymbol{\eta} = \mathbf{x}/\sigma^2$ 的高斯位置模型，得到关于 $\log p_\sigma(\tilde{\mathbf{x}})$ 导数的熟悉形式：

$$\mathbb{E}[\mathbf{x}|\tilde{\mathbf{x}}] = \tilde{\mathbf{x}} + \sigma^2 \nabla_{\tilde{\mathbf{x}}} \log p_\sigma(\tilde{\mathbf{x}}), \quad \text{Cov}[\mathbf{x}|\tilde{\mathbf{x}}] = \sigma^2 \mathbf{I} + \sigma^4 \nabla_{\tilde{\mathbf{x}}}^2 \log p_\sigma(\tilde{\mathbf{x}}),$$

更高阶累积量按 $\log p_\sigma(\tilde{\mathbf{x}})$ 的更高阶导数缩放。

若干研究探索训练网络估计高阶得分 (Meng et al., 2021a; Lu et al., 2022a; Lai et al., 2023a)。此处旨在澄清与统计量的关系，方法细节请参阅这些研究。

3.3.5 （选读）为何 DSM 是去噪：SURE

SURE (Stein 无偏风险估计量)。概括而言，Stein 无偏风险估计量 (SURE) 可在不知道干净信号时估计去噪器 $\mathbf{D}$ 的均方误差 (MSE)。即仅有含噪数据时，SURE 提供选择或训练去噪器的方法。

为清晰起见，考虑加性高斯噪声设定：

$$\tilde{\mathbf{x}} = \mathbf{x} + \sigma \boldsymbol{\epsilon}, \quad \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}),$$

其中 $\mathbf{x} \in \mathbb{R}^D$ 为未知干净信号, $\tilde{\mathbf{x}}$ 为观测含噪版本. 去噪器是任意 (弱可微) 映射 $\mathbf{D}: \mathbb{R}^D \rightarrow \mathbb{R}^D$, 产生 $\mathbf{x}$ 的估计 $\mathbf{D}(\tilde{\mathbf{x}})$.

自然的质量度量为条件 MSE

$$R(\mathbf{D}; \mathbf{x}) := \mathbb{E}_{\tilde{\mathbf{x}}|\mathbf{x}} [\|\mathbf{D}(\tilde{\mathbf{x}}) - \mathbf{x}\|_2^2 | \mathbf{x}].$$

此量依赖未知真值 $\mathbf{x}$, 不能直接计算. 但 Stein 恒等式 (见节 D.2.4) 给出可观测替代量:

$$\text{SURE}(\mathbf{D}; \tilde{\mathbf{x}}) = \|\mathbf{D}(\tilde{\mathbf{x}}) - \tilde{\mathbf{x}}\|_2^2 + 2\sigma^2 \nabla_{\tilde{\mathbf{x}}} \cdot \mathbf{D}(\tilde{\mathbf{x}}) - D\sigma^2, \quad (3.3.7)$$

其中 $\nabla_{\tilde{\mathbf{x}}} \cdot \mathbf{D}(\tilde{\mathbf{x}})$ 表示 $\mathbf{D}$ 的散度. 强调 $\text{SURE}(\mathbf{D}; \tilde{\mathbf{x}})$ 仅需含噪观测 $\tilde{\mathbf{x}}$, 无需干净 $\mathbf{x}$.

直观上, SURE 包含互补的两部分. $\|\mathbf{D}(\tilde{\mathbf{x}}) - \tilde{\mathbf{x}}\|^2$ 衡量输出与含噪输入的距离; 单独使用会低估真实误差, 因为 $\tilde{\mathbf{x}}$ 已受损. 散度项作修正, 刻画去噪器对输入微小扰动的敏感度, 有效计入噪声方差.

对任意固定、未知的 $\mathbf{x}$,

$$\mathbb{E}_{\tilde{\mathbf{x}}|\mathbf{x}} [\text{SURE}(\mathbf{D}; \mathbf{x} + \sigma\epsilon) | \mathbf{x}] = R(\mathbf{D}; \mathbf{x}),$$

期望在高斯噪声 $\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 下取. 因此最小化 SURE (期望或经验意义) 等价于最小化真实 MSE, 却只依赖含噪数据. 实践中对 $\mathbf{x} \sim p_{\text{data}}$ 与加噪噪声 ϵ 一同平均 SURE, 得到全局 MSE 风险的无偏估计.

与 Tweedie 公式及 Bayes 最优性的联系. 令 $p_\sigma(\tilde{\mathbf{x}}) = (p_{\text{data}} * \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I}))(\tilde{\mathbf{x}})$ 表示本节的含噪边缘分布.

SURE 是给定 $\mathbf{x}$ 时关于噪声的均方误差无偏估计:

$$\mathbb{E}_{\tilde{\mathbf{x}}|\mathbf{x}} [\text{SURE}(\mathbf{D}; \tilde{\mathbf{x}})] = \mathbb{E}_{\tilde{\mathbf{x}}|\mathbf{x}} [\|\mathbf{D}(\tilde{\mathbf{x}}) - \mathbf{x}\|^2].$$

故最小化期望 SURE 等价于最小化 Bayes 风险 $\mathbb{E}_{(\mathbf{x}, \tilde{\mathbf{x}})} [\|\mathbf{D}(\tilde{\mathbf{x}}) - \mathbf{x}\|^2] = \mathbb{E}_{\tilde{\mathbf{x}}} [\mathbb{E}_{\mathbf{x}|\tilde{\mathbf{x}}} [\|\mathbf{D}(\tilde{\mathbf{x}}) - \mathbf{x}\|^2]]$, 由全期望公式 (塔性质) 得到. 此分解给出逐点优化: 对几乎所有 $\tilde{\mathbf{x}}$,

$$\mathbf{D}^*(\tilde{\mathbf{x}}) = \arg \min_{\mathbf{z}} \mathbb{E}_{\mathbf{x}|\tilde{\mathbf{x}}} [\|\mathbf{z} - \mathbf{x}\|^2] = \mathbb{E}[\mathbf{x}|\tilde{\mathbf{x}}].$$

所以 SURE 最优去噪器等于节 3.3.4 的 Bayes 估计量, 由 Tweedie 恒等式:

$$\mathbf{D}^*(\tilde{\mathbf{x}}) = \mathbb{E}[\mathbf{x}|\tilde{\mathbf{x}}] = \tilde{\mathbf{x}} + \sigma^2 \nabla_{\tilde{\mathbf{x}}} \log p_\sigma(\tilde{\mathbf{x}}). \quad (3.3.8)$$

SURE 与得分匹配的关系. 式 (3.3.8) 启发通过得分场参数化去噪器 $\mathbf{D}$:

$$\mathbf{D}(\tilde{\mathbf{x}}) = \tilde{\mathbf{x}} + \sigma^2 \mathbf{s}_\phi(\tilde{\mathbf{x}}; \sigma),$$

其中 $\mathbf{s}_\phi(\cdot; \sigma)$ 旨在逼近含噪得分 $\nabla_{\tilde{\mathbf{x}}} \log p_\sigma(\cdot)$. 将 $\mathbf{D}(\tilde{\mathbf{x}}) = \tilde{\mathbf{x}} + \sigma^2 \mathbf{s}_\phi(\tilde{\mathbf{x}}; \sigma)$ 代入式 (3.3.7) 得到

$$\frac{1}{2\sigma^4} \text{SURE}(\mathbf{D}; \tilde{\mathbf{x}}) = \text{Tr}(\nabla_{\tilde{\mathbf{x}}} \mathbf{s}_\phi(\tilde{\mathbf{x}}; \sigma)) + \frac{1}{2} \|\mathbf{s}_\phi(\tilde{\mathbf{x}}; \sigma)\|_2^2 + \text{常数}(\sigma).$$

因此对 $\tilde{\mathbf{x}} \sim p_\sigma$ 取期望, 最小化 SURE 等价于最小化噪声水平 σ 下 Hyvärinen 的替代得分匹配目标 (相差加法常数), 期望在 p_σ 下取 (见式 (3.2.2)). 两者具有相同最小化解, 即式 (3.3.8) 的去噪器.

3.3.6 (选读) 广义得分匹配

动机. 经典得分匹配、去噪得分匹配及高阶变体都以如下量为目标:

$$\frac{\mathcal{L}p(\mathbf{x})}{p(\mathbf{x})}, \quad \text{对某个密度 } p$$

其中线性算子 $\mathcal{L}$ 作用于密度. 经典情形 $\mathcal{L} = \nabla_{\mathbf{x}}$ 给出

$$\nabla_{\mathbf{x}} \log p(\mathbf{x}) = \frac{\nabla_{\mathbf{x}} p(\mathbf{x})}{p(\mathbf{x})}$$

$\frac{\mathcal{L}p}{p}$ 结构可通过分部积分消除归一化常数, 得到仅依赖 p 的样本与学得场 $\mathbf{s}_\phi$ 的易于处理目标. 此视角启发广义得分匹配框架.

广义 Fisher 散度. 令 p 为数据分布, q 为任意模型分布. 对作用于 $\mathbf{x}$ 的标量函数的线性算子 $\mathcal{L}$, 定义广义 Fisher 散度

$$\mathcal{D}_{\mathcal{L}}(p \parallel q) := \int p(\mathbf{x}) \left\| \frac{\mathcal{L}p(\mathbf{x})}{p(\mathbf{x})} - \frac{\mathcal{L}q(\mathbf{x})}{q(\mathbf{x})} \right\|_2^2 d\tilde{\mathbf{x}}.$$

若 $\mathcal{L}$ 是完备的, 即

$$\frac{\mathcal{L}p_1}{p_1} = \frac{\mathcal{L}p_2}{p_2} \text{ 几乎处处} \quad \text{推出} \quad p_1 = p_2 \text{ 几乎处处},$$

则 $\mathcal{D}_{\mathcal{L}}(p \parallel q) = 0$ 可识别 $q = p$. $\mathcal{L} = \nabla_{\tilde{\mathbf{x}}}$ 时恢复经典 Fisher 散度 (见式 (1.1.3)).

得分参数化. 实践中不建模归一化密度 q , 而直接参数化向量场 $\mathbf{s}_\phi(\mathbf{x})$, 逼近广义得分 $\frac{\mathcal{L}p(\mathbf{x})}{p(\mathbf{x})}$.

考虑

$$\mathcal{D}_{\mathcal{L}}(p \parallel \mathbf{s}_\phi) := \mathbb{E}_{\mathbf{x} \sim p} \left[\left\| \mathbf{s}_\phi(\mathbf{x}) - \frac{\mathcal{L}p(\mathbf{x})}{p(\mathbf{x})} \right\|_2^2 \right].$$

虽然 $\frac{\mathcal{L}p(\mathbf{x})}{p(\mathbf{x})}$ 未知, “分部积分”使损失仅依赖 $\mathbf{s}_\phi$. 令 $\mathcal{L}^\dagger$ 为 $\mathcal{L}$ 的伴随, 定义为

$$\int (\mathcal{L}f)^\top g = \int f (\mathcal{L}^\dagger g) \quad \text{对所有测试函数 } f, g,$$

边界项消失时, 形式上将 $\mathcal{L}$ “移动”至积分另一侧. 展开平方并应用此恒等式, 得到易于处理目标

$$\mathcal{L}_{\text{GSM}}(\phi) = \mathbb{E}_{\mathbf{x} \sim p} \left[\frac{1}{2} \|\mathbf{s}_\phi(\mathbf{x})\|_2^2 - (\mathcal{L}^\dagger \mathbf{s}_\phi)(\mathbf{x}) \right] + \text{常数},$$

常数不依赖 ϕ . 仅通过期望使用 p , 故广义得分匹配损失与经典情形一样, 可用训练数据进行经验估计.

$\mathcal{L} = \nabla$ 时有 $\mathcal{L}^\dagger = -\nabla \cdot$, 恢复式 (3.2.2) 的 Hyvärinen 得分匹配目标 $\mathbb{E}_p \left[\frac{1}{2} \|\mathbf{s}_\phi\|_2^2 + \nabla \cdot \mathbf{s}_\phi \right]$.

算子的例子.

- **经典得分匹配.** 考虑 $\mathcal{L} = \nabla_{\mathbf{x}}$, 广义得分退化为经典得分函数

$$\frac{\mathcal{L}p(\mathbf{x})}{p(\mathbf{x})} = \nabla_{\mathbf{x}} \log p(\mathbf{x}).$$

- **去噪得分匹配.** 对加性高斯噪声, 定义算子

$$(\mathcal{L}f)(\tilde{\mathbf{x}}) = \tilde{\mathbf{x}} f(\tilde{\mathbf{x}}) + \sigma^2 \nabla_{\tilde{\mathbf{x}}} f(\tilde{\mathbf{x}}).$$

则

$$\frac{\mathcal{L}p_{\sigma}(\tilde{\mathbf{x}})}{p_{\sigma}(\tilde{\mathbf{x}})} = \tilde{\mathbf{x}} + \sigma^2 \nabla_{\tilde{\mathbf{x}}} \log p_{\sigma}(\tilde{\mathbf{x}}) = \mathbb{E}[\mathbf{x}_0 | \tilde{\mathbf{x}}],$$

其中 $p_{\sigma}(\tilde{\mathbf{x}}) := \int \mathcal{N}(\tilde{\mathbf{x}}; \alpha \mathbf{x}_0, \sigma^2 \mathbf{I}) p_{\text{data}}(\mathbf{x}) d\mathbf{x}$, $\tilde{\mathbf{x}} = \mathbf{x} + \sigma \epsilon$. 这恰是 Tweedie 恒等式. 使用此算子最小化 $\mathcal{L}_{\text{GSM}}$, 训练 $\mathbf{s}_{\phi}$ 逼近去噪器, 恢复去噪得分匹配目标.

- **高阶目标.** 在 $\mathcal{L}$ 中堆叠导数, 显出 $\nabla^2 \log p$ 及高阶导数, 与后验协方差和高阶累积量对应.

扩展与用途. 广义得分匹配从连续变量扩展到离散设定, 包括语言建模 (Meng et al., 2022; Lou, Meng, and Ermon, 2024). 它也启发具有去噪形式目标的得分式训练. 算子视角统一多种目标, 可从数据经验估计, 并通过适当选择 $\mathcal{L}$ 提供设计损失的通用原则.

3.4 多噪声水平的去噪得分匹配 (NCSN)

3.4.1 动机

给数据添加单个固定方差的高斯噪声，可一定程度平滑分布，但仅一个噪声水平的得分模型有重要限制. 小噪声下，低密度区域梯度消失，朗之万动力学难以跨越多模态分布的模式. 大噪声下采样容易，却仅刻画粗略结构，样本模糊、缺少精细细节. 高维空间中朗之万动力学还可能收敛慢乃至失败. 它依赖对数密度梯度引导，不佳初始化，尤其在平台区或鞍点附近，可能阻碍探索，使采样器困于单一模态.




图 3.6: **SM 不准确性示意图 (再看图 3.4)**. 红色区域为低密度区域，样本覆盖有限，得分估计可能不准确；高密度区域通常有较准确估计.

Song and Ermon (2019) 为此提出在数据分布注入多个水平的高斯噪声，联合训练噪声条件得分网络 (NCSN)，估计不同噪声尺度的得分. 生成中按噪声退火方式应用朗之万动力学：从高噪声水平开始以粗略探索，再逐渐细化至低噪声恢复精细细节.

3.4.2 训练

为克服单噪声水平得分模型的限制，Song and Ermon (2019) 提出在数据分布添加多水平高斯噪声. 具体选择 L 个噪声水平 $\{\sigma_i\}_{i=1}^L$ ，使

$$0 < \sigma_1 < \sigma_2 < \cdots < \sigma_L,$$

σ_1 足够小，保留数据多数精细细节； σ_L 足够大，充分平滑分布使训练更容易.

含噪样本由扰动干净数据 $\mathbf{x} \sim p_{\text{data}}$ 构造， $\mathbf{x}_\sigma = \mathbf{x} + \sigma \boldsymbol{\epsilon}$ ， $\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$. 定义




图 3.7: **NCSN 示意图**. 前向过程用多水平加性高斯噪声 $p_\sigma(\mathbf{x}_\sigma|\mathbf{x})$ 扰动数据. 每个噪声水平用朗之万采样生成, 用当前结果初始化下一较低方差水平的采样.

扰动核:

$$p_\sigma(\mathbf{x}_\sigma|\mathbf{x}) := \mathcal{N}(\mathbf{x}_\sigma; \mathbf{x}, \sigma^2 \mathbf{I}),$$

它诱导

边缘分布:

$$p_\sigma(\mathbf{x}_\sigma) = \int p_\sigma(\mathbf{x}_\sigma|\mathbf{x}) p_{\text{data}}(\mathbf{x}) d\mathbf{x},$$

对应各噪声水平 σ , 表示高斯平滑的数据分布.

NCSN 的训练目标. 训练噪声条件得分网络 (noise-conditioned score network) $\mathbf{s}_\phi(\mathbf{x}, \sigma)$, 对所有 $\sigma \in \{\sigma_i\}_{i=1}^L$ 估计 $\nabla_{\mathbf{x}} \log p_\sigma(\mathbf{x})$. 通过在全部噪声水平最小化 DSM 目标实现:

$$\mathcal{L}_{\text{NCSN}}(\phi) := \sum_{i=1}^L \lambda(\sigma_i) \mathcal{L}_{\text{DSM}}(\phi; \sigma_i), \quad (3.4.1)$$

其中

$$\mathcal{L}_{\text{DSM}}(\phi; \sigma) = \frac{1}{2} \mathbb{E}_{\mathbf{x} \sim p_{\text{data}}(\mathbf{x}), \tilde{\mathbf{x}} \sim p_\sigma(\tilde{\mathbf{x}}|\mathbf{x})} \left[\left\| \mathbf{s}_\phi(\tilde{\mathbf{x}}, \sigma) - \left(\frac{\mathbf{x} - \tilde{\mathbf{x}}}{\sigma^2} \right) \right\|_2^2 \right],$$

$\lambda(\sigma_i) > 0$ 为各尺度权重函数.

最小化得到在各噪声水平恢复真实得分的模型 $\mathbf{s}^*(\mathbf{x}, \sigma)$:

$$\mathbf{s}^*(\cdot, \sigma) = \nabla_{\mathbf{x}} \log p_\sigma(\cdot), \quad \text{对所有 } \sigma \in \{\sigma_i\}_{i=1}^L,$$

本质上是 DSM 最小化 (见定理 3.3.1) .

与 DDPM 损失的关系. 令 $\mathbf{x}_\sigma = \mathbf{x} + \sigma\epsilon$, $\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$, p_σ 表示边缘分布. 由 Tweedie 公式,

$$\nabla_{\mathbf{x}_\sigma} \log p_\sigma(\mathbf{x}_\sigma) = -\frac{1}{\sigma} \mathbb{E}[\epsilon | \mathbf{x}_\sigma].$$

NCSN 最优解为真实得分 $\mathbf{s}^*(\mathbf{x}_\sigma, \sigma) = \nabla_{\mathbf{x}_\sigma} \log p_\sigma(\mathbf{x}_\sigma)$, DDPM 损失式 (2.2.10) 的 Bayes 最优噪声预测为 $\epsilon^*(\mathbf{x}_\sigma, \sigma) = \mathbb{E}[\epsilon | \mathbf{x}_\sigma]$. 它们通过下式精确等价:

$$\mathbf{s}^*(\mathbf{x}_\sigma, \sigma) = -\frac{1}{\sigma} \epsilon^*(\mathbf{x}_\sigma, \sigma), \quad \epsilon^*(\mathbf{x}_\sigma, \sigma) = -\sigma \mathbf{s}^*(\mathbf{x}_\sigma, \sigma).$$

离散指标 i 下 DDPM 扰动式 (2.2.9) 中,

$$\mathbf{x}_i = \bar{\alpha}_i \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_i^2}$$

同一关系给出

$$\mathbf{s}^*(\mathbf{x}_i, i) = -\frac{1}{\sigma_i} \mathbb{E}[\epsilon | \mathbf{x}_i],$$

所以最小化式 (2.2.10) 学习 ϵ 的条件去噪器, 即噪声水平 i 真实得分的缩放重参数化. 章 6 将系统比较并总结参数化等价性.

3.4.3 采样

算法 1 退火朗之万动力学

输入: 各噪声水平 $\ell = L, \dots, 2$ 的已训练得分 $\mathbf{s}_{\phi^\times}(\cdot, \sigma_\ell)$ 、步长 η_ℓ 、朗之万迭代预算 N_ℓ

1: $\mathbf{x}^{\sigma_L} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$

2: **对于** $\ell = L, \dots, 2$ **执行**

3: $\tilde{\mathbf{x}}_0 \leftarrow \mathbf{x}^{\sigma_\ell}$

▷ 由前一噪声水平的输出初始化朗之万采样

4: **对于** $n = 0$ **至** $N_\ell - 1$ **执行**

5: $\epsilon_n \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$

6: $\tilde{\mathbf{x}}_{n+1} \leftarrow \tilde{\mathbf{x}}_n + \eta_\ell \mathbf{s}_{\phi^\times}(\tilde{\mathbf{x}}_n, \sigma_\ell) + \sqrt{2\eta_\ell} \epsilon_n$

7: **结束 对于**

8: $\mathbf{x}^{\sigma_{\ell-1}} \leftarrow \tilde{\mathbf{x}}_{N_\ell}$

▷ 输出用于初始化下一噪声水平

9: **结束 对于**

输出: $\mathbf{x}^{\sigma_1}$

在多个噪声水平已有训练得分网络

$$\mathbf{s}_{\phi^\times}(\cdot, \sigma_1), \quad \mathbf{s}_{\phi^\times}(\cdot, \sigma_2), \quad \dots, \quad \mathbf{s}_{\phi^\times}(\cdot, \sigma_{L-1}), \quad \mathbf{s}_{\phi^\times}(\cdot, \sigma_L),$$

退火朗之万动力学 (Song and Ermon, 2019) 通过从高噪声 σ_L 逐步去噪至低噪声 $\sigma_1 \approx 0$ 生成数据.

从高斯噪声 $\mathbf{x}^{\sigma_L} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 开始, 各噪声水平 σ_ℓ 运行朗之万动力学, 近似从扰动分布 $p_{\sigma_\ell}(\mathbf{x})$ 采样. 其输出为下一较低噪声水平 $\sigma_{\ell-1}$ 提供更好初始化.

每个水平迭代更新为

$$\tilde{\mathbf{x}}_{n+1} = \tilde{\mathbf{x}}_n + \eta_\ell \mathbf{s}_{\phi \times}(\tilde{\mathbf{x}}_n, \sigma_\ell) + \sqrt{2\eta_\ell} \boldsymbol{\epsilon}_n, \quad \boldsymbol{\epsilon}_n \sim \mathcal{N}(\mathbf{0}, \mathbf{I}),$$

从 $\tilde{\mathbf{x}}_0 := \mathbf{x}^{\sigma_\ell}$ 开始. 步长通常按噪声水平缩放:

$$\eta_\ell = \delta \cdot \frac{\sigma_\ell^2}{\sigma_1^2}, \quad \text{对某个固定 } \delta > 0.$$

噪声退火细化持续至最低水平 σ_1 , 得到最终样本 $\mathbf{x}^{\sigma_1}$. 逐步使用前一水平输出作为下一水平更好初值, 使探索更有效, 改善复杂分布的覆盖. 算法 1 总结此过程.

NCSN 采样速度缓慢. NCSN 在噪声尺度 $\{\sigma_i\}_{i=1}^L$ 上使用退火 MCMC (通常朗之万动力学) 生成样本. 每个尺度 σ_i 执行 K 次迭代: “用得分 $\mathbf{s}_{\phi \times}(\tilde{\mathbf{x}}_n, \sigma_i)$ 加小随机扰动更新 $\tilde{\mathbf{x}}_n$ ”, 每次需要得分网络前向传播. 两个因素要求大的 $L \times K$:

- (i) **局部准确性与稳定性:** 学得得分仅对小扰动可靠, 需要小步长和每噪声水平许多迭代, 避免偏差、不稳定;
- (ii) **高维混合缓慢:** 局部 MCMC 移动对高维多模态目标探索低效, 需要许多迭代才能到达典型数据区域.

更新严格顺序进行, 每次依赖前一次且需要昂贵网络计算, 总成本 $\mathcal{O}(LK)$ 次顺序网络传播, 采样计算缓慢.

3.5 总结：NCSN 与 DDPM 的比较视角

比较. 先比较图 3.7 的 NCSN、DDPM 图模型，关键异同总结于表 3.1.

表 3.1: NCSN 与 DDPM 的比较

	NCSN	DDPM
$\mathbf{x}_{i+1} \mathbf{x}_i$	推导为 $\mathbf{x}_{i+1} = \mathbf{x}_i + \sqrt{\sigma_{i+1}^2 - \sigma_i^2} \epsilon$	定义为 $\mathbf{x}_{i+1} = \sqrt{1 - \beta_i} \mathbf{x}_i + \sqrt{\beta_i} \epsilon$
$\mathbf{x}_i \mathbf{x}$	定义为 $\mathbf{x}_i = \mathbf{x} + \sigma_i^2 \epsilon$	推导为 $\mathbf{x}_i = \bar{\alpha}_i \mathbf{x} + \sqrt{1 - \bar{\alpha}_i^2} \epsilon$
p_{prior}	$\mathcal{N}(\mathbf{0}, \sigma_L^2 \mathbf{I})$	$\mathcal{N}(\mathbf{0}, \mathbf{I})$
损失	$\mathbb{E}_i \mathbb{E}_{p_{\text{data}}(\mathbf{x})} \mathbb{E}_{\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})} \left[\left\ \mathbf{s}_\phi(\mathbf{x}_i, \sigma_i) + \frac{\epsilon}{\sigma_i} \right\ _2^2 \right]$	$\mathbb{E}_i \mathbb{E}_{p_{\text{data}}(\mathbf{x})} \mathbb{E}_{\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})} \left[\left\ \epsilon_\phi(\mathbf{x}_i, i) - \epsilon \right\ _2^2 \right]$
采样	每层应用朗之万动力学; 用输出初始化下一层	使用 $p_{\phi^\times}(\mathbf{x}_{i-1} \mathbf{x}_i)$ 遍历 Markov 链

共同瓶颈. 尽管表述不同，NCSN、DDPM 都依赖稠密时间离散化。关键限制是采样常需数百乃至数千次迭代，使生成缓慢且计算密集。

问题 3.5.1. 如何加速扩散模型的采样？

章 9 和章 10 将再讨论此挑战。

3.6 结束语

本章描绘通向扩散模型的第二条主要道路，从源于能量模型（EBM）的得分视角出发。首先识别 EBM 的核心挑战——难以处理的配分函数——并引入得分函数 $\nabla_{\mathbf{x}} \log p(\mathbf{x})$ ，完全绕开此问题的强大工具。

从经典得分匹配走向更可扩展、稳健的变体——去噪得分匹配（DSM）。DSM 显示用噪声扰动数据可获得易于处理的训练目标，再次利用条件化策略形成简单回归目标。还通过 Tweedie 公式建立得分估计与去噪的深刻联系：得分提供从含噪观测估计干净信号所需的精确方向。

随后通过噪声条件得分网络（NCSN）将原则从单一噪声水平扩展至连续范围，学习条件于多个噪声尺度的单个得分模型，并经退火朗之万动力学生成样本。最后发现 NCSN 与变分视角 DDPM 起源虽不同，却有惊人相似的结构和共同瓶颈：缓慢、顺序的采样。

这种汇合并非巧合，暗示更深的统一数学结构。离散时间模型的局限促使需要更一般框架。下一章将迈出关键一步：

1. 转向连续时间，说明 DDPM 与 NCSN 可统一为由随机微分方程（SDE）描述的单个强大过程的不同离散化。
2. 得分 SDE 框架正式联系变分与得分视角，将生成重新表述为求解微分方程的问题。

统一视角不仅在理论上澄清问题，也带来一类先进数值方法，应对采样缓慢的根本挑战。

第 4 章 当今的扩散模型：得分 SDE 框架

陈述定律只有一种精确的方式，那就是借助微分方程。它们的优点在于基本，而且据我们所知，是精确的。

Richard P. Feynman

此前从变分视角与基于得分的视角研究扩散模型，后者自然源于 EBM 表述。现在进一步转向连续时间框架。核心是得分 SDE ，将 DDPM、NCSN 统一为单一表述的连续极限。此视角以微分方程 (DE) 为基础，用清晰、有原则的描述扩展离散更新。生成归结为随时间求解 DE，可直接应用数值分析工具：例如基础 Euler 方法模拟动力学，更先进求解器改善稳定性与效率。连续时间还提供更丰富的数学结构，为理解、分析、改进扩散模型提供统一基础。本书将进一步发展此视角。




图 4.1: **离散时间加噪步骤示意图**. 从 t 到 $t + \Delta t$ 添加噪声, 均值漂移为 $\mathbf{f}(\mathbf{x}_t, t)$, 扩散系数为 $g(t)$.

4.1 得分 SDE: 原理

多个噪声尺度是 NCSN、DDPM 成功的关键. 本节介绍得分 *SDE* (Song et al., 2020b) 的基础, 考虑连续范围的噪声水平以提升此思想. Sohl-Dickstein et al. (2015) 已指出前向、反向扩散的连续时间极限, Song et al. (2020b) 则将其置于核心, 把数据演化表述为噪声水平随时间平滑增大的随机微分方程 (stochastic differential equation) / 常微分方程. 此表述不仅统一先前离散模型, 还通过将生成建模转化为求解微分方程, 提供有原则、灵活的基础.

4.1.1 动机: 从离散到连续时间过程

回顾 NCSN、DDPM 的前向噪声注入方案. NCSN 使用递增噪声水平 $\{\sigma_i\}_{i=1}^L$, 将每个干净样本 $\mathbf{x} \sim p_{\text{data}}$ 扰动为

$$\mathbf{x}_{\sigma_i} = \mathbf{x} + \sigma_i \boldsymbol{\epsilon}_i, \quad \boldsymbol{\epsilon}_i \sim \mathcal{N}(\mathbf{0}, \mathbf{I}).$$

DDPM 则按方差调度 $\{\beta_i\}_{i=1}^L$ 逐步注入噪声:

$$\mathbf{x}_i = \sqrt{1 - \beta_i^2} \mathbf{x}_{i-1} + \beta_i \boldsymbol{\epsilon}_i, \quad \boldsymbol{\epsilon}_i \sim \mathcal{N}(\mathbf{0}, \mathbf{I}).$$

在离散时间网格上统一看待它们, 从 $\mathbf{x}_t$ 到 $\mathbf{x}_{t+\Delta t}$ 的顺序更新为¹:

$$\text{NCSN: } \mathbf{x}_{t+\Delta t} = \mathbf{x}_t + \sqrt{\sigma_{t+\Delta t}^2 - \sigma_t^2} \boldsymbol{\epsilon}_t \quad \approx \mathbf{x}_t + \sqrt{\frac{d\sigma_t^2}{dt} \Delta t} \boldsymbol{\epsilon}_t$$

$$\text{DDPM: } \mathbf{x}_{t+\Delta t} = \sqrt{1 - \beta_t} \mathbf{x}_t + \sqrt{\beta_t} \boldsymbol{\epsilon}_t \quad \approx \mathbf{x}_t - \frac{1}{2} \beta_t \mathbf{x}_t \Delta t + \sqrt{\beta_t \Delta t} \boldsymbol{\epsilon}_t,$$

¹为方便, 交替使用 $\mathbf{x}(t)$ 、 $\mathbf{x}_t$ (其他时变变量同理) 表示时间 t 的样本.

其中 $\epsilon_t \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$. 两种加噪过程遵循共同结构:

$$\mathbf{x}_{t+\Delta t} \approx \mathbf{x}_t + \mathbf{f}(\mathbf{x}_t, t)\Delta t + g(t)\sqrt{\Delta t}\epsilon_t, \quad (4.1.1)$$

其中 $\mathbf{f}: \mathbb{R}^D \times \mathbb{R} \rightarrow \mathbb{R}^D$ 和 $g: \mathbb{R} \rightarrow \mathbb{R}$ 定义为:

$$\text{NCSN: } \mathbf{f}(\mathbf{x}, t) = 0, \quad g(t) = \sqrt{\frac{d\sigma^2(t)}{dt}}$$

$$\text{DDPM: } \mathbf{f}(\mathbf{x}, t) = -\frac{1}{2}\beta(t)\mathbf{x}, \quad g(t) = \sqrt{\beta(t)}.$$

此表述对应如下高斯转移:

$$p(\mathbf{x}_{t+\Delta t}|\mathbf{x}_t) := \mathcal{N}(\mathbf{x}_{t+\Delta t}; \mathbf{x}_t + \mathbf{f}(\mathbf{x}_t, t)\Delta t, g^2(t)\Delta t\mathbf{I}), \quad (4.1.2)$$

这里稍微滥用记号, 将 $\mathbf{x}_t$ 视作固定样本, $\mathbf{x}_{t+\Delta t}$ 视作随机变量.

当 $\Delta t \rightarrow 0$ (可理解为准备无穷多层噪声), 离散过程收敛为时间前向演化的连续 SDE²:

$$d\mathbf{x}(t) = \mathbf{f}(\mathbf{x}(t), t) dt + g(t) d\mathbf{w}(t),$$

其中 $\mathbf{w}(t)$ 是标准 Wiener 过程 (或布朗运动 (Brownian motion)).

注.

此处不需要完整形式定义, *Wiener* 过程是从零开始、有独立增量的连续时间随机过程 $\mathbf{w}(t)$, 对任意 $s < t$, 增量 $\mathbf{w}(t) - \mathbf{w}(s)$ 服从均值零、方差 $t - s$ 的正态分布. 它表示独立高斯波动随时间积累, 虽然几乎必然连续, 却处处不可微.

在无穷小时间区间 $[t, t + dt]$ 上, Wiener 过程的增量定义为

$$d\mathbf{w}(t) := \mathbf{w}(t + dt) - \mathbf{w}(t),$$

建模为均值零、方差 dt 的高斯随机变量:

$$d\mathbf{w}(t) \sim \mathcal{N}(\mathbf{0}, dt\mathbf{I}).$$

节 A.2 简要介绍 SDE 基础, 章 C 作更高级讨论. 概念上, 离散与连续表述的联系可理解为:

- $\mathbf{x}(t + \Delta t) - \mathbf{x}(t) \approx d\mathbf{x}(t),$
- $\Delta t \approx dt,$
- $\sqrt{\Delta t}\epsilon_t \sim \mathcal{N}(\mathbf{0}, \Delta t\mathbf{I}) \approx d\mathbf{w}(t).$

²式 (4.1.2) 的前向核在 $\Delta t \rightarrow 0$ 时收敛到对应伊藤 SDE 的解. 完全严格的证明依赖高级结果, 此处请参阅文献.

一旦指定漂移 $\mathbf{f}(\mathbf{x}, t)$ 与扩散 $g(t)$ ，前向 SDE 自动诱导反向 SDE，将终端噪声分布输运回数据分布。反向动力学仅有一个未知项，恰是各连续时间水平的得分函数。因此得分匹配成为训练目标；学得得分后，采样就是用学得得分数值积分反向 SDE。

节 4.2 给出实际实现；先在节 4.1.2、节 4.1.3 考察前向、反向过程的理论基础。

4.1.2 前向 SDE：从数据到噪声




图 4.2: **扩散模型前向过程的一维可视化**. 过程从复杂双模态数据分布 ($p_0 = p_{\text{data}}$) 采样的初始点 (“x”) 出发，走向简单单峰高斯先验 ($p_T \approx p_{\text{prior}}$)。背景热图展示随时间平滑的边缘概率密度 p_t 。样本轨迹从 $t=0$ 演化至 $t=T$ ，比较随机前向 SDE (蓝色路径) 与确定性对应过程 PF-ODE (白色路径)。注意，PF-ODE 是密度的确定性输运映射，一般并非从单点出发的样本路径均值。

据此，NCSN (Song and Ermon, 2019)、DDPM (Sohl-Dickstein et al., 2015; Ho, Jain, and Abbeel, 2020) 等离散时间方法可通过随机过程 $\mathbf{x}(t)$ 统一到连续时间框架，该过程由 $[0, T]$ 上的前向 SDE 控制：

$$d\mathbf{x}(t) = \mathbf{f}(\mathbf{x}(t), t) dt + g(t) d\mathbf{w}(t), \quad \mathbf{x}(0) \sim p_{\text{data}}. \quad (4.1.3)$$

$\mathbf{f}(\cdot, t): \mathbb{R}^D \rightarrow \mathbb{R}^D$ 为漂移 (drift)， $g(t) \in \mathbb{R}$ 为标量扩散系数， $\mathbf{w}(t)$ 为标准 Wiener 过程。称为前向 SDE，描述干净数据随时间逐渐扰动为噪声。

指定漂移 $\mathbf{f}$ 、扩散系数 g 后，前向过程完全确定，描述通过注入高斯噪声逐步破坏数据变量。特别诱导两族时变密度：

扰动核. 条件分布

$$p_t(\mathbf{x}_t|\mathbf{x}_0)$$

描述干净样本 $\mathbf{x}_0 \sim p_{\text{data}}$ 如何演化为时间 t 的含噪版本 $\mathbf{x}_t$. 一般地, 式 (4.1.3) 的漂移 $\mathbf{f}(\mathbf{x}, t)$ 可为 $\mathbf{x}$ 的任意函数; 常用且解析方便的选择是假定仿射形式:

$$\mathbf{f}(\mathbf{x}, t) = f(t)\mathbf{x}, \quad (4.1.4)$$

其中 $f(t)$ 为 t 的标量函数, 通常非正. 此结构使过程在每个时间保持高斯性, 求解均值—方差 ODE 可得条件分布闭式解 (Särkkä and Solin, 2019) (亦见节 4.3.3). 具体为

$$p_t(\mathbf{x}_t|\mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t; \mathbf{m}(t), P(t)\mathbf{I}_D),$$

其中

$$\mathbf{m}(t) = \exp\left(\int_0^t f(u) du\right)\mathbf{x}_0, \quad P(t) = \int_0^t \exp\left(2\int_s^t f(u) du\right)g^2(s) ds,$$

初始条件 $\mathbf{m}(0) = \mathbf{x}_0$ 、 $P(0) = 0$.

显式形式使得给定 $\mathbf{x}_0$ 时无需数值积分 SDE 就可直接采样 $\mathbf{x}_t$, 因而称为无需模拟. NCSN、DDPM 均属于仿射漂移设定.

下文对任意漂移 $\mathbf{f}(\mathbf{x}, t)$ 发展一般理论, 闭式分析有用时再回到仿射漂移.

边缘密度. 对扰动核积分得到时间边缘密度 $p_t(\mathbf{x}_t)$:

$$p_t(\mathbf{x}_t) := \int p_t(\mathbf{x}_t|\mathbf{x}_0)p_{\text{data}}(\mathbf{x}_0) d\mathbf{x}_0, \quad \text{其中 } p_0 = p_{\text{data}}. \quad (4.1.5)$$

适当选择 $f(t)$ 、 $g(t)$, 前向过程逐渐加噪, 直到有效遗忘初始状态影响. T 足够大时, 条件分布 $p_T(\mathbf{x}_T|\mathbf{x}_0)$ 不再依赖 $\mathbf{x}_0$, 因为均值按下式演化:

$$\mathbf{m}(T) = \exp\left(\int_0^T f(u) du\right)\mathbf{x}_0 \longrightarrow \mathbf{0}, \quad \text{当 } T \rightarrow \infty,$$

只要 $f(u)$ 非正, 使指数因子衰减. 同时方差增长并稳定到所选先验分布的方差. 因此边缘分布

$$p_T(\mathbf{x}_T) = \int p_T(\mathbf{x}_T|\mathbf{x}_0)p_{\text{data}}(\mathbf{x}_0) d\mathbf{x}_0,$$

初始为数据样本上的复杂混合, 最终收敛到简单先验 p_{prior} , 通常为高斯. 在此极限,

$$p_T(\mathbf{x}_T) \approx p_{\text{prior}}(\mathbf{x}_T) \quad \text{且} \quad p_T(\mathbf{x}_T|\mathbf{x}_0) \approx p_{\text{prior}}(\mathbf{x}_T),$$

所以前向过程将任意数据分布映射为易于处理先验, 为反转、生成提供方便起点.




图 4.3: **用于数据生成的时间反向随机过程可视化**. 从 $t = T$ 时简单先验 p_{prior} 的样本 (“x”) 开始, 用反向 SDE 使其沿时间向后演化. 轨迹在 $t = 0$ 结束, 共同形成目标双模态分布 ($p_0 = p_{\text{data}}$). 背景热图展示密度从简单高斯逐渐变换为复杂目标分布.

4.1.3 用于生成的反向随机过程

直观上, 从噪声生成数据可“反转”前向过程: 从先验采样随机点, 沿时间向后演化得到样本. 对确定性系统 (ODE), 这一思想自然成立: 无随机性, 反向时间仅指沿与前向相同路径逆向追踪点的轨迹³. SDE 则每步均含随机性, 同一点可沿多条合理随机轨迹演化, 因此反转更微妙⁴.

虽然单条随机轨迹不可逆, 轨迹上的分布却可以反转. Anderson (1982) 的基本结果使其形式化: 式 (4.1.3) 前向过程的时间反转过程 $\{\bar{\mathbf{x}}(t)\}_{t \in [0, T]}$ ⁵ 本身由良定义的 SDE 控制. 它从 T 演化至 0, 动力学为

$$\begin{aligned} d\bar{\mathbf{x}}(t) &= [\mathbf{f}(\bar{\mathbf{x}}(t), t) - g^2(t) \nabla_{\mathbf{x}} \log p_t(\bar{\mathbf{x}}(t))] dt + g(t) d\bar{\mathbf{w}}(t), \\ \bar{\mathbf{x}}(T) &\sim p_{\text{prior}} \approx p_T. \end{aligned} \quad (4.1.6)$$

$\bar{\mathbf{w}}(t)$ 是反向时间中的标准 Wiener 过程, 定义为 $\bar{\mathbf{w}}(t) := \mathbf{w}(T - t) - \mathbf{w}(T)$.

为建立式 (4.1.6) 的直觉, 节 4.1.6 给出高斯数据分布与线性高斯动力学的具体例子. 该设定易于解析: 仅需基本微积分、线性代数即可直接推导反向公式, 无需完整的 Anderson (1982) 一般理论.

随机性 ($g \neq 0$) 引入额外修正 $-g^2(t) \nabla_{\mathbf{x}} \log p_t(\bar{\mathbf{x}}(t))$, 计入扩散影响, 保证反向动力学正确复现前向 SDE 诱导的边缘演化 (见节 4.1.5).

³技术上对应通过时间翻转替换 $t \leftrightarrow T - t$ 求解 ODE.

⁴简单翻转时间不能得到正确反向过程.

⁵用横线记号区分反向过程 $\{\bar{\mathbf{x}}(t)\}_{t \in [0, T]}$ 与前向 SDE 定义的 $\{\mathbf{x}(t)\}_{t \in [0, T]}$.

概念上，反向过程为何有效？ 节 4.5.2 通过联系 DDPM 变分框架直观推导反向 SDE (选读但很有启发)。此处补充直觉，解释反向动力学如何从噪声恢复结构化数据。

反向过程中存在布朗噪声，乍看似悖论。前向扩散将数据散开为更含噪的构型，反转时又通过 $\bar{\mathbf{w}}(t)$ 引入额外随机性，如何产生集中于数据流形附近的干净、结构化样本？关键是反向 SDE 不注入任意随机性：扩散项 $g(t) d\bar{\mathbf{w}}(t)$ 始终与得分驱动漂移 $-g^2(t)\nabla_{\mathbf{x}} \log p_t(\bar{\mathbf{x}}(t))$ 耦合。两者平衡：得分引导轨迹走向高密度区，噪声引入受控随机性以探索而不压倒动力学。

回到式 (3.1.6) 的朗之万直觉。当 $f(t) \equiv 0$ ，式 (4.1.6) 为

$$d\bar{\mathbf{x}}(t) = -g^2(t)\nabla_{\mathbf{x}} \log p_t(\bar{\mathbf{x}}(t)) dt + g(t) d\bar{\mathbf{w}}(t).$$

用 $s := T - t$ 重新参数化时间为前向 ($dt = -ds$)，按分布律重命名布朗运动，使 $d\bar{\mathbf{w}}(t) = -d\mathbf{w}_s$ 。记 $\bar{\mathbf{x}}_s := \bar{\mathbf{x}}(T - s)$ 、 $\pi_s := p_{T-s}$ ，得到

$$\begin{aligned} d\bar{\mathbf{x}}_s &= g^2(T - s)\nabla \log \pi_s(\bar{\mathbf{x}}_s) ds + g(T - s) d\mathbf{w}_s \\ &= 2\tau(s)\nabla \log \pi_s(\bar{\mathbf{x}}_s) ds + \sqrt{2\tau(s)} d\mathbf{w}_s, \quad \tau(s) := \frac{1}{2}g^2(T - s). \end{aligned}$$

这具有时变温度 $\tau(s)$ 的朗之万形式，以演化密度 π_s 为目标。由 Tweedie 公式(式 (3.3.6))，各时间切片上得分 $\nabla \log \pi_s$ 指向条件干净信号，漂移不断“拉回”去噪结构。

关键在于 $g(t)$ 沿反向轨迹退火。早期 ($s \approx 0$ ，即 $t \approx T$)， $g(T - s)$ 通常较大，噪声较强，过程广泛探索。随 s 增大， $g(T - s)$ 减小，随机项减弱，得分项主导，将样本拉向 π_s 高密度区；至 $s = T$ ($t = 0$)，轨迹集中于数据流形附近。

反向 SDE 能力概述。 时变得分函数

$$\mathbf{s}(\mathbf{x}, t) := \nabla_{\mathbf{x}} \log p_t(\mathbf{x})$$

自然出现于式 (4.1.6)。指定前向系数 $f(t)$ 、 $g(t)$ 后，得分是反向动力学仅存未知量。这凸显其核心作用：得分已知，反向过程便确定；采样就是用学得得分数值积分式 (4.1.6)。

理想得分通常无闭式表达，因此采用章 3 方法，经得分匹配训练网络 $\mathbf{s}_\phi(\mathbf{x}, t)$ 逼近它；细节见节 4.2.1。将式 (4.1.6) 的 $\mathbf{s}(\mathbf{x}, t)$ 换为 $\mathbf{s}_\phi(\mathbf{x}, t)$ ，完全指定反向动力学。

生成对应从 $t = T$ 、 $\mathbf{x}_T \sim p_{\text{prior}}$ 起，反向求解 SDE 至 $t = 0$ 。Anderson (1982) 证明前向、反向过程的边缘密度相同，保证 $p_{\text{prior}} \approx p_T$ 时 $t = 0$ 的样本近似服从 p_{data} 。节 4.2.2 将继续探索。

4.1.4 用于生成的确定性过程（概率流 ODE）

虽然式 (4.1.6) 的 SDE 引入随机性，可能提高样本多样性，一个问题随之出现：

问题 4.1.1. 有必要用式 (4.1.6) 的 SDE 采样吗？

受 Maoutsa, Reich, and Opper (2020) 启发，Song et al. (2020b) 还引入确定性 ODE，使样本按与前向 SDE 相同的边缘分布演化。过程 $\{\tilde{\mathbf{x}}(t)\}_{t \in [0, T]}$ ⁶ 称为概率流 ODE (probability flow ODE) (PF-ODE)，定义为

⁶用波浪线区分与前向、反向 SDE 关联的过程。后文为简洁略去此区别。

$$\frac{d}{dt}\tilde{\mathbf{x}}(t) = \mathbf{f}(\tilde{\mathbf{x}}(t), t) - \frac{1}{2}g^2(t)\nabla_{\mathbf{x}}\log p_t(\tilde{\mathbf{x}}(t)). \quad (4.1.7)$$

与 SDE 类似，用学得近似替代真实得分，从 $t = T$ 反向积分至 $t = 0$ 可生成样本。具体而言，生成样本（PF-ODE 在 $t = 0$ 的解）为

$$\tilde{\mathbf{x}}(T) + \int_T^0 \left[\mathbf{f}(\tilde{\mathbf{x}}(\tau), \tau) - \frac{1}{2}g^2(\tau)\nabla_{\mathbf{x}}\log p_\tau(\tilde{\mathbf{x}}(\tau)) \right] d\tau,$$

初值 $\tilde{\mathbf{x}}(T) \sim p_{\text{prior}}$ 。此积分无易处理闭式表达，实际生成依靠数值求解器（例如 Euler 方法，见式 (4.2.4)）。

与反向 SDE 相比，PF-ODE 有两个关键优势：

- 给定所选端点的相应初值，ODE 可使用同一方程沿任一方向积分，从 $t = 0$ 到 $t = T$ 或反过来。此双向性区别于一般仅可沿前向时间积分的 SDE。
- 可使用大量成熟、现成的 ODE 数值求解器。

强调 PF-ODE 不是简单删除式 (4.1.6) 的扩散项；漂移中的 $\frac{1}{2}$ 有原则性来源。概括而言，式 (4.1.7) 选择 ODE 漂移，使其演化保留与前向 SDE 式 (4.1.3) 相同的边缘密度。下一节详述保证边缘对齐的原理，即 Fokker–Planck 方程 (Fokker–Planck equation) (Øksendal, 2003)。

4.1.5 前向 / 反向 SDE 与 PF-ODE 的边缘分布匹配




图 4.4: **边缘密度 p_t 的二维时间演化**. 前向 SDE 在 $[0, T]$ 上满足 $\mathbf{f} \equiv \mathbf{0}$, $g(t) = \sqrt{2t}$. 从双模态高斯混合 $p_0 = p_{\text{data}}$ 开始, 结束于 $p_T \approx p_{\text{prior}} := \mathcal{N}(\mathbf{0}, T^2 \mathbf{I})$. p_t 的时空演化遵循 Fokker-Planck 方程.

用 Fokker-Planck 方程保证边缘密度对齐. 扩散模型的核心概念是不同过程可产生同一边缘分布序列 (本小节后面将演示). 目标是构造把 p_{prior} 变为 p_{data} 的过程, 按时间对齐边缘, 尤其在 $t = 0$. 只要易于处理、可高效采样, 过程具体形式是次要的. 自然引出基本问题:

问题 4.1.2. 如何保证不同过程产生相同的边缘分布?

回到设定, 前向 SDE 指定从 p_{data} 到 p_{prior} 的边缘演化. 再构造反向 SDE、PF-

ODE, 使其轨迹给出与前向完全匹配的边缘. 关键是控制扩散过程边缘密度演化的 Fokker–Planck 方程. 下述定理 (Anderson, 1982; Song et al., 2020b) 奠定联系:

定理 4.1.1: Fokker–Planck 方程保证边缘对齐

令 $\{\mathbf{x}(t)\}_{t \in [0, T]}$ 按前向 SDE 演化

$$d\mathbf{x}(t) = \mathbf{f}(\mathbf{x}(t), t) dt + g(t) d\mathbf{w}(t),$$

初值 $\mathbf{x}(0) \sim p_0 = p_{\text{data}}$. 则边缘密度 p_t 满足 Fokker–Planck 方程

$$\begin{aligned} \partial_t p_t(\mathbf{x}) &= -\nabla_{\mathbf{x}} \cdot [\mathbf{f}(\mathbf{x}, t) p_t(\mathbf{x})] + \frac{1}{2} g^2(t) \Delta_{\mathbf{x}} p_t(\mathbf{x}) \\ &= -\nabla_{\mathbf{x}} \cdot [\tilde{\mathbf{f}}(\mathbf{x}, t) p_t(\mathbf{x})], \end{aligned} \quad (4.1.8)$$

其中 $\Delta_{\mathbf{x}}$ 是 Laplace 算子, 且

$$\mathbf{v}(\mathbf{x}, t) = \mathbf{f}(\mathbf{x}, t) - \frac{1}{2} g^2(t) \nabla_{\mathbf{x}} \log p_t(\mathbf{x}).$$

则 PF-ODE 与反向 SDE 均产生同一族 $\{p_t\}_{t \in [0, T]}$, 后者沿反向时间演化:

(i) PF-ODE $\{\tilde{\mathbf{x}}(t)\}_{t \in [0, T]}$

$$\frac{d\tilde{\mathbf{x}}(t)}{dt} = \mathbf{v}(\tilde{\mathbf{x}}(t), t),$$

若从 $\tilde{\mathbf{x}}(0) \sim p_0$ 开始沿 t 前向运行, 或等价从 $\tilde{\mathbf{x}}(T) \sim p_T$ 开始沿 t 反向运行, 所有 $t \in [0, T]$ 的边缘均为 $\tilde{\mathbf{x}}(t) \sim p_t$.

(ii) 反向 SDE $\{\bar{\mathbf{x}}(t)\}_{t \in [0, T]}$

$$d\bar{\mathbf{x}}(t) = [\mathbf{f}(\bar{\mathbf{x}}(t), t) - g^2(t) \nabla_{\mathbf{x}} \log p_t(\bar{\mathbf{x}}(t))] dt + g(t) d\bar{\mathbf{w}}(t),$$

初值 $\bar{\mathbf{x}}(0) \sim p_T$, $\bar{\mathbf{w}}(t)$ 为反向时间的标准 Wiener 过程, 其边缘为 $\bar{\mathbf{x}}(t) \sim p_{T-t}$.

定理的证明.

证明见节 D.2.5; 节 4.5.1 通过概率边缘化技术进一步提供 Fokker–Planck 方程的直觉.

固定边缘的多个条件分布. 为理解 PF-ODE 如何沿前向输运 p_{data} (或等价反向输运 p_{prior}), 考虑流映射 $\Psi_{s \rightarrow t} : \mathbb{R}^D \rightarrow \mathbb{R}^D$; $\Psi_{s \rightarrow t}(\mathbf{x}_s)$ 表示任意 $s, t \in [0, T]$ 下, 从时间 s 的 $\mathbf{x}_s$ 初始化的 PF-ODE 在 t 的解. 映射从初态 $\mathbf{x}_s$ 直接跳到时间 t 的状态:

$$\Psi_{s \rightarrow t}(\mathbf{x}_s) := \mathbf{x}_s + \int_s^t \mathbf{v}(\mathbf{x}_\tau, \tau) d\tau, \quad (4.1.9)$$

其速度场为

$$\mathbf{v}(\mathbf{x}, \tau) := \mathbf{f}(\mathbf{x}, \tau) - \frac{1}{2} g^2(\tau) \nabla_{\mathbf{x}} \log p_\tau(\mathbf{x}).$$

积分刻画沿 PF-ODE 轨迹 $\mathbf{x}_\tau$ 累积的净位移. 在 $\mathbf{v}$ 的温和光滑性假设下, 流映射 $\Psi_{s \rightarrow t} : \mathbb{R}^D \rightarrow \mathbb{R}^D$ 是光滑双射⁷.

对任意 $t \in [0, T]$, 推前 (*pushforward*) 密度定义为

$$p_t^{\text{fwd}}(\mathbf{x}_t) := \int \delta(\mathbf{x}_t - \Psi_{t \rightarrow 0}(\mathbf{x}_0)) p_{\text{data}}(\mathbf{x}_0) d\mathbf{x}_0,$$

记为 $\Psi_{t \rightarrow 0} \# p_{\text{data}}$, 表示在 $\Psi_{t \rightarrow 0}$ 下时间 t 的分布. 定理 4.1.1 保证 $p_t^{\text{fwd}} = p_t$, p_t 是前向 SDE 边缘密度, 将确定性 PF-ODE 与随机核相等同:

$$p_t(\mathbf{x}_t) = \int p_t(\mathbf{x}_t | \mathbf{x}_0) p_{\text{data}}(\mathbf{x}_0) d\mathbf{x}_0 = \int \delta(\mathbf{x}_t - \Psi_{t \rightarrow 0}(\mathbf{x}_0)) p_{\text{data}}(\mathbf{x}_0) d\mathbf{x}_0.$$

这意味着无穷多个条件分布 $Q_t(\mathbf{x}_t | \mathbf{x}_0)$ 产生同一 $p_t(\mathbf{x}_t)$, 例如:

- **随机 (无需模拟):** $Q_t(\mathbf{x}_t | \mathbf{x}_0) = p_t(\mathbf{x}_t | \mathbf{x}_0)$,
- **确定性 (需要求解 ODE):** $Q_t(\mathbf{x}_t | \mathbf{x}_0) = \delta(\mathbf{x}_t - \Psi_{t \rightarrow 0}(\mathbf{x}_0))$,
- **混合:** $Q_t(\mathbf{x}_t | \mathbf{x}_0) = \lambda p_t(\mathbf{x}_t | \mathbf{x}_0) + (1 - \lambda) \delta(\mathbf{x}_t - \Psi_{t \rightarrow 0}(\mathbf{x}_0))$, $\lambda \in [0, 1]$.

$Q_t(\mathbf{x}_t | \mathbf{x}_0)$ 的非唯一性源于边缘约束不能唯一确定条件分布. 此概念再次出现于节 5.2.2、节 9.2.3. 特别地, 存在整个反向 SDE 族与同一边缘 p_t 一致.

观察 4.1.1: 匹配给定边缘密度

多个过程可产生同一边缘密度序列; 关键是满足 Fokker–Planck 方程. 此基本洞见为设计从 p_{prior} 到 p_{data} 或反过来的生成过程提供显著灵活性.

Fokker–Planck 方程是扩散模型的核心, 源于概率密度的基本变量替换公式 (系统处理见章 B). 它并非次要技术细节, 而贯穿后文, 尤其是节 5.2.

4.1.6 可计算的例子: 高斯动力学的演化

p_{data} 为正态分布 (或高斯混合) 时, 得分有闭式表达, 是建立扩散过程直觉的理想设定: 仅用基本微积分即可显式推导反向 SDE、PF-ODE, 无需高级数学工具. 本小节展示这些方程在此易于处理情形中的行为.

高斯情形反向 SDE 的精确计算. p_{data} 为高斯时, 可直接推导式 (4.1.6), 无需 Anderson (1982) 的一般理论、证明. 为说明核心思想, 考虑一维情况; 高维扩展同理.

从前向 SDE 开始

$$dx(t) = f(t)x(t) dt + g(t) dw_t,$$

⁷提前说明: PF-ODE 流映射 $\Psi_{s \rightarrow t}$ 恰是将 p_s 输运至 p_t 的归一化流 (NF) 双射 (节 5.1 详述). 区别在于 PF-ODE 固定由 SDE 的 Fokker–Planck 动力学决定的唯一向量场, 而 NF (或连续时间 NF) 参数化场, 但都依赖同一变量替换原则.

取步长 $\Delta t > 0$ 的小 Euler 步骤:

$$x_{t+\Delta t} = ax_t + r\epsilon,$$

其中 $a := 1 + f(t)\Delta t$, $r := g(t)\sqrt{\Delta t}$, $\epsilon \sim \mathcal{N}(0, 1)$. 等价地, 前向单步转移核为高斯:

$$x_{t+\Delta t}|x_t \sim \mathcal{N}(ax_t, r^2).$$

假设 p_{data} 为高斯, 故时间 t 的当前边缘也是高斯:

$$x_t \sim \mathcal{N}(m_t, s_t^2),$$

其中 m_t, s_t 为标量. 条件化因而只是乘两个高斯分布再归一化, 代数保持初等.

由 Bayes 法则, 条件密度相差常数地等于先验与转移核之积:

$$\begin{aligned} p(x_t|x_{t+\Delta t}) &\propto p(x_{t+\Delta t}|x_t)p_t(\mathbf{x}_t) \\ &\propto \exp\left(-\frac{(x_t - m_t)^2}{2s_t^2}\right) \exp\left(-\frac{(x_{t+\Delta t} - ax_t)^2}{2r^2}\right). \end{aligned}$$

指数是 x_t 的二次式. 展开平方、合并项, 清楚显示重要系数:

$$-2\log p(x_t|x_{t+\Delta t}) = Ax_t^2 - 2Bx_t + \text{常数},$$

其中

$$A := \frac{1}{s_t^2} + \frac{a^2}{r^2}, \quad B := \frac{m_t}{s_t^2} + \frac{ax_{t+\Delta t}}{r^2}.$$

A 为精度之和 (先验精度加经 a 输运的转移核精度), B 为相应精度加权的标度之和. 配方一行即得后验:

$$Ax_t^2 - 2Bx_t = A\left(x_t - \frac{B}{A}\right)^2 - \frac{B^2}{A},$$

所以条件分布为高斯, 方差 $1/A$, 均值 B/A :

$$\text{Var}(x_t|x_{t+\Delta t}) = \frac{1}{\frac{1}{s_t^2} + \frac{a^2}{r^2}}, \quad \mathbb{E}[x_t|x_{t+\Delta t}] = \frac{\frac{m_t}{s_t^2} + \frac{ax_{t+\Delta t}}{r^2}}{\frac{1}{s_t^2} + \frac{a^2}{r^2}}.$$

闭式已描述任意小 Δt 的反向转移. 为读出反向 SDE, 将其在小 Δt 下展开.

使用 $a = 1 + f(t)\Delta t$, $r^2 = g^2(t)\Delta t$. $\Delta t \rightarrow 0$ 时, $\frac{a^2}{r^2} \sim \frac{1}{g^2(t)\Delta t}$ 主导精度, 故方差为

$$\text{Var}(x_t|x_{t+\Delta t}) = \left(\frac{1}{s_t^2} + \frac{a^2}{r^2}\right)^{-1} = g^2(t)\Delta t + \mathcal{O}(\Delta t^2),$$

说明反向步与前向具有相同扩散尺度 $g(t)$. 均值则对 B/A 展开至一阶:

$$\mathbb{E}[x_t|x_{t+\Delta t}] = x_{t+\Delta t} + \Delta t \left[-\left(f(t) + \frac{g^2(t)}{s_t^2}\right)x_{t+\Delta t} + \frac{g^2(t)}{s_t^2}m_t \right] + \mathcal{O}(\Delta t^2).$$

结合均值与方差，得到单步反向转移核

$$x_t | x_{t+\Delta t} \sim \mathcal{N}\left(x_{t+\Delta t} + \Delta t \left[-\left(f + \frac{g^2}{s_t^2}\right) x_{t+\Delta t} + \frac{g^2}{s_t^2} m_t \right], g^2 \Delta t\right) + \mathcal{O}(\Delta t^2).$$

这是从 $t + \Delta t$ 反向运行至 t 的 Euler-Maruyama 更新：

$$x_t - x_{t+\Delta t} = \Delta t \left[-\left(f + \frac{g^2}{s_t^2}\right) x_{t+\Delta t} + \frac{g^2}{s_t^2} m_t \right] + g\sqrt{\Delta t}\epsilon + \mathcal{O}(\Delta t^2).$$

$\Delta t \rightarrow 0$ 给出原时钟下的 SDE（时间沿路径递减）

$$dx(t) = \left[-\left(f(t) + \frac{g^2(t)}{s_t^2}\right)x(t) + \frac{g^2(t)}{s_t^2}m_t \right] dt + g(t) d\bar{w}_t.$$

高斯边缘 $p_t = \mathcal{N}(m_t, s_t^2)$ 的得分满足

$$\partial_x \log p_t(x) = -\frac{x - m_t}{s_t^2} \implies -\left(f + \frac{g^2}{s_t^2}\right)x + \frac{g^2}{s_t^2}m_t = -fx + g^2 \partial_x \log p_t(x).$$

为表述通常沿 t 前向的反向时间参数化，定义 $\bar{x}(t) := x(T - t)$ ，现在沿 t 前向演化。时间翻转将漂移变为

$$d\bar{x}(t) = \left[f(t)\bar{x}(t) - g^2(t)\partial_x \log p_t(\bar{x}(t)) \right] dt + g(t) d\bar{w}_t,$$

其中 $\bar{x}(T) \sim p_{\text{prior}} \approx p_T$ 。这恰是通常的反向 SDE。向量形式对应一般式 (4.1.6)，以 $\nabla_x \log p_t$ 替代一维导数。

高斯情形 PF-ODE 的精确计算。 假设数据为高斯，还可直接推导 PF-ODE，避开 Fokker-Planck 方程等复杂工具。最后将看到其边缘与前向、反向 SDE 都相同，建设性验证节 4.1.5 讨论的理论。

假设 $x_t \sim \mathcal{N}(m_t, s_t^2)$ 。小确定步 Δt 可写为光滑映射

$$x_{t+\Delta t} = \Phi_{t,\Delta t}(x_t) = x_t + \Delta t v_t(x_t) + \mathcal{O}(\Delta t^2),$$

这是关于 Δt 的一阶 Taylor 展开。目标是确定 v_t 的形式，使输入为高斯时，输出仍为高斯。

为此，在当前均值 m_t 附近展开 v_t ：

$$v_t(x) = v_t(m_t) + v_t'(m_t)(x - m_t) + \frac{1}{2}v_t''(m_t)(x - m_t)^2 + \dots$$

令 $y := x_t - m_t$ ，则 $y \sim \mathcal{N}(0, s_t^2)$ 。再减去输出均值，使之中心化（至 Δt 一阶）：

$$z := x_{t+\Delta t} - \mathbb{E}[x_{t+\Delta t}] = y + \Delta t(v_t'(m_t)y + \frac{1}{2}v_t''(m_t)(y^2 - s_t^2)) + \mathcal{O}(\Delta t^2).$$

回顾高斯的偏度为零，即三阶中心矩零。因此计算 $\mathbb{E}[z^3]$ 至一阶，并使用 $\mathbb{E}[y] = 0$ ， $\mathbb{E}[y^2] = s_t^2$ ， $\mathbb{E}[y^3] = 0$ ， $\mathbb{E}[y^4] = 3s_t^4$ ，得到

$$\mathbb{E}[z^3] = 3\Delta t \cdot \frac{1}{2}v_t''(m_t)(\mathbb{E}[y^4] - s_t^2\mathbb{E}[y^2]) + \mathcal{O}(\Delta t^2) = 3\Delta t v_t''(m_t)s_t^4 + \mathcal{O}(\Delta t^2).$$

为使所有小 Δt 的输出保持高斯, 此量的 Δt 阶必须消失, 迫使 $v_t''(m_t) = 0$. 对高阶导数重复同一论证, 也排除高次幂. 因而 v_t 必须是线性加平移:

$$v_t(x) = a_t x + b_t.$$

代回步骤得

$$x_{t+\Delta t} = (1 + \alpha_t \Delta t) x_t + \beta_t \Delta t + \mathcal{O}(\Delta t^2), \quad \alpha_t := a_t, \quad \beta_t := b_t.$$

现在通过此映射推前 $x_t \sim \mathcal{N}(m_t, s_t^2)$, 跟踪均值和方差至一阶:

$$\begin{aligned} \mathbb{E}[x_{t+\Delta t}] &= m_t + \Delta t(\alpha_t m_t + \beta_t) + \mathcal{O}(\Delta t^2), \\ \text{Var}(x_{t+\Delta t}) &= s_t^2 + \Delta t(2\alpha_t s_t^2) + \mathcal{O}(\Delta t^2). \end{aligned}$$

另一方面, 前向 SDE $dx = f(t)x dt + g(t)dw_t$ 有初等矩公式 (见式 (4.3.3)):

$$m_t' = f(t)m_t, \quad (s_t^2)' = 2f(t)s_t^2 + g^2(t).$$

匹配 Δt 系数得到

$$\alpha_t = f(t) + \frac{g^2(t)}{2s_t^2}, \quad \beta_t = -\frac{g^2(t)}{2s_t^2}m_t.$$

此时步骤为

$$x_{t+\Delta t} = x_t + \Delta t \left[\left(f(t) + \frac{g^2(t)}{2s_t^2} \right) x_t - \frac{g^2(t)}{2s_t^2} m_t \right] + \mathcal{O}(\Delta t^2).$$

高斯 $p_t = \mathcal{N}(m_t, s_t^2)$ 满足 $\partial_x \log p_t(x) = -(x - m_t)/s_t^2$, 故方括号可改写为 $f(t)x_t - \frac{1}{2}g^2(t)\partial_x \log p_t(x_t)$. 因此,

$$x_{t+\Delta t} = x_t + \Delta t \left[f(t)x_t - \frac{1}{2}g^2(t)\partial_x \log p_t(x_t) \right] + \mathcal{O}(\Delta t^2).$$

最后除以 Δt , 令 $\Delta t \rightarrow 0$, 得到 PF-ODE

$$x'(t) = f(t)x(t) - \frac{1}{2}g^2(t)\partial_x \log p_t(x(t)).$$

为何边缘与前向、反向 SDE 相同? 上述漂移为线性加平移, 故 $x(t)$ 仿射依赖 $x(0)$, 仿射映射保持高斯性. 此外, 沿 ODE 的均值 m_t 、方差 s_t^2 按匹配恰好满足与前向 SDE 相同的两个标量 ODE, 初值也相同. 因而每个 t 下两种演化的 $p_t = \mathcal{N}(m_t, s_t^2)$ 都一致.

4.2 得分 SDE：训练与采样

4.2.1 训练

按章 3 的思想，用以时间为条件的神经网络逼近理想得分 $\nabla_{\mathbf{x}} \log p_t(\mathbf{x})$ ：

$$\mathbf{s}_\phi = \mathbf{s}_\phi(\mathbf{x}, t)$$

在所有 $t \in [0, T]$ 上最小化类似式 (3.2.1) 的得分匹配目标：

$$\mathcal{L}_{\text{SM}}(\phi; \omega(\cdot)) := \frac{1}{2} \mathbb{E}_{t \sim p_{\text{time}}} \mathbb{E}_{\mathbf{x}_t \sim p_t} [\omega(t) \|\mathbf{s}_\phi(\mathbf{x}_t, t) - \nabla_{\mathbf{x}} \log p_t(\mathbf{x}_t)\|_2^2],$$

其中 p_{time} 为某个时间分布（如 $[0, T]$ 上均匀分布）， $\omega(\cdot)$ 是时间权重函数。

为避免依赖难以处理的理想得分 $\nabla_{\mathbf{x}} \log p_t(\mathbf{x})$ ，使用式 (3.3.2) 的 DSM 损失。条件化于数据点 $\mathbf{x}_0$ 后，可通过式 (D.2.4) 使用解析上易于处理的 $\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t | \mathbf{x}_0)$ ；具体例子见节 4.3。损失为

$$\begin{aligned} \mathcal{L}_{\text{DSM}}(\phi; \omega(\cdot)) := \\ \frac{1}{2} \mathbb{E}_t \mathbb{E}_{\mathbf{x}_0} \mathbb{E}_{p_t(\mathbf{x}_t | \mathbf{x}_0)} \left[\omega(t) \|\mathbf{s}_\phi(\mathbf{x}_t, t) - \nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t | \mathbf{x}_0)\|_2^2 \right], \end{aligned} \quad (4.2.1)$$

其中 $\mathbf{x}_0 \sim p_{\text{data}}$ 。式 (4.2.1) 可看作式 (3.4.1) 的连续时间版本，用积分替代离散求和。

类似定理 3.3.1，式 (4.2.1) 的最小化解唯一确定如下：

命题 4.2.1: DSM 的最小化解

最小化解 $\mathbf{s}^*$ 满足

$$\mathbf{s}^*(\mathbf{x}_t, t) = \mathbb{E}_{\mathbf{x}_0 \sim p(\mathbf{x}_0 | \mathbf{x}_t)} [\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t | \mathbf{x}_0)] = \nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t), \quad (4.2.2)$$

对几乎所有 $\mathbf{x}_t \sim p_t$ 、 $t \in [0, T]$ 成立。

命题的证明。

DSM 目标可看作最小二乘误差问题。各时间 t 的最优得分为条件对数密度梯度的条件期望，按 Bayes 法则等于边缘对数密度梯度。详细证明见附录 D.2.6。 ■

4.2.2 采样与推断

学习得到

$$\mathbf{s}_{\phi^\times} := \mathbf{s}_{\phi^\times}(\mathbf{x}, t) \approx \nabla_{\mathbf{x}} \log p_t(\mathbf{x}),$$

用学得替代 $\mathbf{s}_{\phi^\times}(\mathbf{x}, t)$ 替换反向 SDE（式 (4.1.6)）与 PF-ODE（式 (4.1.7)）中的难以处理理想得分 $\nabla_{\mathbf{x}} \log p_t(\mathbf{x})$ 。于是经 SDE 或 ODE 均可进行易于处理的推断。为清楚起见，所得过程分别记为 $\mathbf{x}_{\phi^\times}^{\text{SDE}}(t)$ 、 $\mathbf{x}_{\phi^\times}^{\text{ODE}}(t)$ ，后文略去此区别⁸。

⁸为简化本小节之后的记号。




图 4.5: **得分 SDE 采样的二维示意图**. 对与图 4.4 相同的前向 SDE 设定, 求解反向 SDE (蓝色, 通过式 (4.2.4)) 和 PF-ODE (红色, 通过式 (4.2.6)) 采样. 从随机点 $\mathbf{x}_T \sim p_{\text{prior}}$ (深色 “x”) 出发, 两类轨迹在 $t = 0$ 都结束于 p_{data} 支撑附近.

经验反向 SDE. 用已训练模型 $\mathbf{s}_{\phi^\times}$ 替换式 (4.1.6) 真实得分, 得到生成用参数化反向 SDE:

$$d\mathbf{x}_{\phi^\times}^{\text{SDE}}(t) = [\mathbf{f}(\mathbf{x}_{\phi^\times}^{\text{SDE}}(t), t) - g^2(t)\mathbf{s}_{\phi^\times}(\mathbf{x}_{\phi^\times}^{\text{SDE}}(t), t)] dt + g(t) d\bar{\mathbf{w}}(t). \quad (4.2.3)$$

生成时先从 p_{prior} 抽取初值 $\mathbf{x}_T$, 再从 $t = T$ 到 $t = 0$ 反向数值求解式 (4.2.3). 标准方法是 Euler-Maruyama, 给出离散更新:

$$\mathbf{x}_{t-\Delta t} \leftarrow \mathbf{x}_t - [\mathbf{f}(\mathbf{x}_t, t) - g^2(t)\mathbf{s}_{\phi^\times}(\mathbf{x}_t, t)] \Delta t + g(t)\sqrt{\Delta t} \cdot \boldsymbol{\epsilon}, \quad (4.2.4)$$

$\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$, $\Delta t > 0$ 为步长.

迭代得到最终样本 $\mathbf{x}_{\phi^\times}^{\text{SDE}}(0)$. 得分模型准确时, 生成分布 $p_{\phi^\times}^{\text{SDE}}(\cdot; 0)$ 很好地逼近真实数据⁹:

$$p_{\phi^\times}^{\text{SDE}}(\cdot; 0) \approx p_{\text{data}}(\cdot).$$

式 (2.2.14) 的 DDPM 采样正是对特定 $\mathbf{f}$ 、 g 的 Euler-Maruyama 离散化的特例 (见节 4.3).

经验 PF-ODE. PF-ODE 定义连接 p_{prior} 与 p_{data} 的连续流, 支持采样、编码及精确似然计算. 下文详细介绍各操作.

⁹理论上精度依赖 p_T 与 p_{prior} 的差异 (通常可忽略)、模型训练误差、数值离散误差 (De Bortoli, 2022). 此处不讨论形式误差界.

I. 使用 PF-ODE 采样. 用 $\mathbf{s}_{\phi^\times}$ 替换式 (4.1.7) 的理想得分, 得到经验 PF-ODE:

$$\frac{d}{dt}\mathbf{x}_{\phi^\times}^{\text{ODE}}(t) = \mathbf{f}(\mathbf{x}_{\phi^\times}^{\text{ODE}}(t), t) - \frac{1}{2}g^2(t)\mathbf{s}_{\phi^\times}(\mathbf{x}_{\phi^\times}^{\text{ODE}}(t), t). \quad (4.2.5)$$

先从先验 p_{prior} 抽取初始样本 $\mathbf{x}_T$, 再从 $t = T$ 到 $t = 0$ 反向数值求解式 (4.2.5). 等价于近似积分:

$$\mathbf{x}_{\phi^\times}^{\text{ODE}}(0) = \mathbf{x}_T + \int_T^0 \left[\mathbf{f}(\mathbf{x}_{\phi^\times}^{\text{ODE}}(\tau), \tau) - \frac{1}{2}g^2(\tau)\mathbf{s}_{\phi^\times}(\mathbf{x}_{\phi^\times}^{\text{ODE}}(\tau), \tau) \right] d\tau.$$

求解得到最终样本 $\mathbf{x}_{\phi^\times}^{\text{ODE}}(0)$. 确定性过程的生成分布 $p_{\phi^\times}^{\text{ODE}}(\cdot; 0)$ 近似数据分布, 即 $p_{\phi^\times}^{\text{ODE}}(\cdot; 0) \approx p_{\text{data}}$.

令 $\Delta t > 0$ 为离散步长. 标准数值积分方法是 Euler 法, 估计

$$\mathbf{f}(\mathbf{x}_\tau, \tau) - \frac{1}{2}g^2(\tau)\mathbf{s}_{\phi^\times}(\mathbf{x}_\tau, \tau) \approx \mathbf{f}(\mathbf{x}_t, t) - \frac{1}{2}g^2(t)\mathbf{s}_{\phi^\times}(\mathbf{x}_t, t), \quad \tau \in [t - \Delta t, t],$$

得到更新规则:

$$\mathbf{x}_{t-\Delta t} \leftarrow \mathbf{x}_t - \left[\mathbf{f}(\mathbf{x}_t, t) - \frac{1}{2}g^2(t)\mathbf{s}_{\phi^\times}(\mathbf{x}_t, t) \right] \Delta t. \quad (4.2.6)$$

此联系给出生成的核心洞见:

洞见 4.2.1: 生成 $\Leftrightarrow$ 求解 ODE / SDE

从扩散模型采样, 本质上等价于求解相应概率流 ODE 或反向 SDE.

这清晰解释问题 3.5.1 的采样缓慢: 微分方程数值求解器本质上迭代, 通常需许多步才能准确近似解轨迹¹⁰, 故生成计算密集. 但 PF-ODE 也有优势, 可使用加速数值求解器的丰富文献. 章 9 重点探索这些加速采样技术.

II. 使用 PF-ODE 反演. 不同于 SDE, 可沿前向 (0 到 T) 或反向 (T 到 0) 求解同一式 (4.2.5). 前向求解时, ODE 流将数据映射为所有 $t \in [0, T]$ 的 (含噪) 潜在表示, 充当编码器. 此概念支持图像翻译、编辑等强大可控生成应用 (Mokady et al., 2023; Su et al., 2022).

III. 通过 PF-ODE 精确计算对数似然. 将式 (4.2.5) 解释为神经 ODE (Chen et al., 2018) (节 5.1.2 介绍) 的变体, 仅参数化得分而非完整速度场. 由变量替换公式可精确计算对数似然.

将式 (5.1.9) 的恒等式应用于式 (4.2.5), 定义速度场

$$\mathbf{v}_{\phi^\times}(\mathbf{x}, t) := \mathbf{f}(\mathbf{x}, t) - \frac{1}{2}g^2(t)\mathbf{s}_{\phi^\times}(\mathbf{x}, t),$$

¹⁰例如 DDPM、得分 SDE 通常生成时使用 1,000 次函数计算.

使用学得得分 $\mathbf{s}_{\phi^\times}$. 沿 PF-ODE 轨迹 $\{\mathbf{x}_{\phi^\times}^{\text{ODE}}(t)\}_{t \in [0, T]}$, 对数密度 $p_{\phi^\times}^{\text{ODE}}(\cdot; t)$ 的演化满足

$$\frac{d}{dt} \log p_{\phi^\times}^{\text{ODE}}(\mathbf{x}_{\phi^\times}^{\text{ODE}}(t), t) = -\nabla \cdot \mathbf{v}_{\phi^\times}(\mathbf{x}_{\phi^\times}^{\text{ODE}}(t), t),$$

其中 $\nabla \cdot \mathbf{v}$ 为对 $\mathbf{x}$ 的散度.

为计算数据点 $\mathbf{x}_0 \sim p_{\text{data}}$ 的似然, 从 $t = 0$ 至 $t = T$ 积分增广 ODE 系统:

$$\frac{d}{dt} \begin{bmatrix} \mathbf{x}(t) \\ \delta(t) \end{bmatrix} = \begin{bmatrix} \mathbf{v}_{\phi^\times}(\mathbf{x}(t), t) \\ \nabla \cdot \mathbf{v}_{\phi^\times}(\mathbf{x}(t), t) \end{bmatrix}, \quad \begin{bmatrix} \mathbf{x}(0) \\ \delta(0) \end{bmatrix} = \begin{bmatrix} \mathbf{x}_0 \\ 0 \end{bmatrix}, \quad (4.2.7)$$

$\delta(t)$ 累积对数密度变化. 求解至 $t = T$, 得到终态:

$$\begin{bmatrix} \mathbf{x}(T) \\ \delta(T) \end{bmatrix}.$$

原样本 $\mathbf{x}_0$ 的模型对数似然可计算为

$$\log p_{\phi^\times}^{\text{ODE}}(\mathbf{x}_0; 0) = \log p_{\text{prior}}(\mathbf{x}(T)) + \delta(T),$$

其中 $p_{\text{prior}}(\mathbf{x}(T))$ 是在 $\mathbf{x}(T)$ 处计算的闭式先验密度.

4.3 SDE 的具体实例

Song et al. (2020b) 根据演化中的方差行为, 将前向 SDE 的漂移 $\mathbf{f}(\mathbf{x}, t)$ 与扩散 $g(t)$ 分为三类. 重点讨论两种常用类型: 方差爆炸 (VE) SDE 与方差保持 (VP) SDE. 虽可自定义噪声调度器, 其设计会显著影响实际表现. 表 4.1 总结这两个实例.

表 4.1: 前向 SDE 总结

	VE SDE	VP SDE
$\mathbf{f}(\mathbf{x}, t)$	$\mathbf{0}$	$-\frac{1}{2}\beta(t)\mathbf{x}$
$g(t)$	$\sqrt{\frac{d\sigma^2(t)}{dt}}$	$\sqrt{\beta(t)}$
SDE	$d\mathbf{x}(t) = g(t) d\mathbf{w}(t)$	$d\mathbf{x}(t) = -\frac{1}{2}\beta(t)\mathbf{x}(t) dt + \sqrt{\beta(t)} d\mathbf{w}(t)$
$p_t(\mathbf{x}_t \mathbf{x}_0)$	$\mathcal{N}(\mathbf{x}_t; \mathbf{x}_0, (\sigma^2(t) - \sigma^2(0)) \mathbf{I})$	$\mathcal{N}(\mathbf{x}_t; \mathbf{x}_0 e^{-\frac{1}{2} \int_0^t \beta(\tau) d\tau}, \mathbf{I} - \mathbf{I} e^{-\int_0^t \beta(\tau) d\tau})$
p_{prior}	$\mathcal{N}(\mathbf{0}, \sigma^2(T)\mathbf{I})$	$\mathcal{N}(\mathbf{0}, \mathbf{I})$

4.3.1 VE SDE

VE SDE 包含:

- **漂移项:** 零漂移 $\mathbf{f} = \mathbf{0}$.
- **扩散项:** 对某个 $\sigma(t)$, $g(t) = \sqrt{\frac{d\sigma^2(t)}{dt}}$.

前向 SDE 为

$$d\mathbf{x}(t) = \sqrt{\frac{d\sigma^2(t)}{dt}} d\mathbf{w}(t). \quad (4.3.1)$$

同样, 节 4.3.3 给出 VE SDE 的扰动核, 并指导选择适当先验:

- **扰动核:**

$$p_t(\mathbf{x}_t|\mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t; \mathbf{x}_0, (\sigma^2(t) - \sigma^2(0)) \mathbf{I})$$

- **先验分布:** 假设 $\sigma(t)$ 在 $t \in [0, T]$ 上递增, 且 $\sigma^2(T) \gg \sigma^2(0)$. 先验为

$$p_{\text{prior}} := \mathcal{N}(\mathbf{0}, \sigma^2(T)\mathbf{I}).$$

VE SDE 的典型实例是按如下设计的 NCSN:

$$\sigma(t) := \sigma_{\min} \left(\frac{\sigma_{\max}}{\sigma_{\min}} \right)^t, \quad \text{对 } t \in (0, 1],$$

$\sigma_{\min}$ 、 $\sigma_{\max}$ 为预定常数, 即方差序列设计为等比数列. 因而 NCSN 可视作 VE SDE 的离散版, 如节 4.1.1 讨论.

4.3.2 VP SDE

令 $\beta: [0, T] \rightarrow \mathbb{R}_{\geq 0}$ 为非负函数. VP SDE 由以下分量定义:

- **漂移项:** 线性漂移 $\mathbf{f}(\mathbf{x}, t) = -\frac{1}{2}\beta(t)\mathbf{x}$.
- **扩散项:** $g(t) = \sqrt{\beta(t)}$.

故前向 SDE 为

$$d\mathbf{x}(t) = -\frac{1}{2}\beta(t)\mathbf{x}(t) dt + \sqrt{\beta(t)} d\mathbf{w}(t). \quad (4.3.2)$$

利用节 4.3.3, 可导出 VP SDE 扰动核并选择适当先验:

- **扰动核:**

$$p_t(\mathbf{x}_t|\mathbf{x}_0) = \mathcal{N}\left(\mathbf{x}_t; \mathbf{x}_0 e^{-\frac{1}{2} \int_0^t \beta(\tau) d\tau}, \mathbf{I} - \mathbf{I} e^{-\int_0^t \beta(\tau) d\tau}\right).$$

- **先验分布:** $p_{\text{prior}} := \mathcal{N}(\mathbf{0}, \mathbf{I})$.

扰动核为均值、协方差已知的高斯分布, 可用式 (D.2.5) 计算得分.

VP SDE 的经典例子是 DDPM, 其噪声调度 $\beta(t)$ 为

$$\beta(t) := \beta_{\min} + t(\beta_{\max} - \beta_{\min}), \quad \text{对所有 } t \in [0, 1].$$

$\beta_{\min}$ 、 $\beta_{\max}$ 为预定常数. 因而 DDPM 可解释为 VP SDE 的离散化, 如节 4.1.1 讨论.

4.3.3 (选读) 如何推导扰动核?

若前向 SDE 式 (4.1.3) 漂移关于 $\mathbf{x}$ 线性, 形式为

$$\mathbf{f}(\mathbf{x}, t) = f(t)\mathbf{x},$$

其中 $f(t) \in \mathbb{R}$ 为随时间变化的标量函数, 则式 (4.1.3) 成为线性 SDE:

$$d\mathbf{x}(t) = f(t)\mathbf{x}(t) dt + g(t) d\mathbf{w}(t).$$

即使初始分布 p_{data} 非高斯, 漂移线性也保证条件过程保持高斯. 对 $t > 0$, 转移核形式为

$$p_t(\mathbf{x}_t|\mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t; \mathbf{m}(t), P(t)\mathbf{I}_D),$$

$\mathbf{x}_0 \sim p_{\text{data}}$, $\mathbf{m}(t) \in \mathbb{R}^D$ 、 $P(t) \in \mathbb{R}_{\geq 0}$ 表示给定 $\mathbf{x}_0$ 的条件均值、(标量) 方差, 定义为

$$\mathbf{m}(t) = \mathbb{E}[\mathbf{x}_t|\mathbf{x}(0) = \mathbf{x}_0], \quad P(t)\mathbf{I}_D = \text{Cov}[\mathbf{x}_t|\mathbf{x}(0) = \mathbf{x}_0].$$

一、二阶矩按如下 ODE 演化 (Särkkä and Solin, 2019):

$$\begin{aligned}\frac{d\mathbf{m}(t)}{dt} &= f(t)\mathbf{m}(t), \\ \frac{dP(t)}{dt} &= 2f(t)P(t) + g^2(t),\end{aligned}\tag{4.3.3}$$

只要初始均值 $\mathbf{m}(0)$ 、方差 $P(0)$ 有限.

两个 ODE 都线性, 可通过积分因子法获得闭式解. 给定初值 $\mathbf{x}_0$, 均值、方差演化为

$$\mathbf{m}(t) = \mathcal{E}(0 \rightarrow t)\mathbf{x}_0, \quad P(t) = \int_0^t \mathcal{E}^2(s \rightarrow t)g(s)^2 ds,\tag{4.3.4}$$

初值为 $\mathbf{m}(0) = \mathbf{x}_0$ 、 $P(0) = 0$. $\mathcal{E}(s \rightarrow t)$ 表示指数积分因子

$$\mathcal{E}(s \rightarrow t) := \exp\left(\int_s^t f(u) du\right),$$

刻画时间 s 到 t 漂移的累积作用. 因而转移核 $p_t(\mathbf{x}_t|\mathbf{x}_0)$ 也有闭式表达.

在坐标独立的 D 维 Wiener 过程与扩散 $g(t)\mathbf{I}_D$ 下, $p_t(\mathbf{x}_t|\mathbf{x}_0)$ 的条件协方差为各向同性, 即 $\text{Cov}[\mathbf{x}_t|\mathbf{x}_0] = P(t)\mathbf{I}_D$; 此说明及式 (4.3.3) 的推导留至节 C.1.5, 依赖伊藤微积分.

例: VE SDE 的转移核

特例 VE SDE 中, $\mathbf{f} \equiv 0$, $g(t) = \sqrt{\frac{d\sigma^2(t)}{dt}}$, 解的均值、协方差按如下演化.

均值.

$$\frac{d\mathbf{m}(t)}{dt} = 0, \quad \text{其中} \quad \mathbf{m}(0) = \mathbf{x}_0 \implies \mathbf{m}(t) = \mathbf{x}_0.$$

方差.

$$\frac{dP(t)}{dt} = \frac{d\sigma^2(t)}{dt}, \quad \text{其中} \quad P(0) = 0 \implies P(t) = \sigma^2(t) - \sigma^2(0).$$

因此

$$p_t(\mathbf{x}_t|\mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t; \mathbf{x}_0, (\sigma^2(t) - \sigma^2(0))\mathbf{I}_D).$$

例: VP SDE 的转移核

VP SDE 漂移 $\mathbf{f}(\mathbf{x}, t) = -\frac{1}{2}\beta(t)\mathbf{x}$ 、扩散 $g(t) = \sqrt{\beta(t)}$ 时:

均值 $\mathbf{m}(t)$.

$$\frac{d\mathbf{m}}{dt} = -\frac{1}{2}\beta(t)\mathbf{m}(t), \quad B(t) := \int_0^t \beta(s) ds, \quad \mathbf{m}(t) = e^{-\frac{1}{2}B(t)}\mathbf{x}_0.$$

方差 $P(t)$. 方差满足

$$\frac{dP}{dt} = -\beta(t)P(t) + \beta(t).$$

应用积分因子 $e^{B(t)}$, 其中 $B(t) = \int_0^t \beta(s) ds$, 得

$$\frac{d}{dt} [P(t)e^{B(t)}] = \beta(t)e^{B(t)}.$$

两边积分得到

$$P(t) = 1 - e^{-B(t)}.$$

故协方差各向同性, 且

$$\mathbf{P}(t) = P(t)\mathbf{I}_D = (1 - e^{-B(t)})\mathbf{I}_D.$$

最终闭式转移核.

$$p_t(\mathbf{x}_t | \mathbf{x}_0) = \mathcal{N} \left(\mathbf{x}_t; \underbrace{e^{-\frac{1}{2}B(t)}\mathbf{x}_0}_{\mathbf{m}(t)}, \underbrace{(1 - e^{-B(t)})\mathbf{I}_D}_{P(t)\mathbf{I}_D} \right), \quad B(t) = \int_0^t \beta(s) ds.$$

4.4 (选读) 重新思考基于得分与变分扩散模型的前向核

DDPM、得分 SDE 通常从前向转移核 $p(\mathbf{x}_t|\mathbf{x}_{t-\Delta t})$ 介绍，前者离散定义，后者定义为连续 SDE. 但实践中尤其损失 (式 (2.2.8) 和 (4.2.1)) 最相关的是从数据累积的转移核 $p_t(\mathbf{x}_t|\mathbf{x}_0)$. 两框架最终均依赖它，通过递归计算 (DDPM)，或求解 ODE (得分 SDE)，如节 4.3.3 详述。

本节先定义连续时间 $p_t(\mathbf{x}_t|\mathbf{x}_0)$ ，得到更简洁、直接的视角。两种核理论上等价，但定义后者通常更清楚、可解释；特别是它直接揭示 $t \rightarrow T$ 的先验，自然符合实际损失设计。




图 4.6: 引理 4.4.1 示意图. 经连续 SDE 逐步加噪 ($\Delta t \rightarrow 0$) 与式 (4.4.1) 的直接扰动在数学上等价。

4.4.1 一般仿射前向过程 $p_t(\mathbf{x}_t|\mathbf{x}_0)$

先定义一般前向扰动核：

$$p_t(\mathbf{x}_t|\mathbf{x}_0) := \mathcal{N}(\mathbf{x}_t; \alpha_t \mathbf{x}_0, \sigma_t^2 \mathbf{I}), \quad (4.4.1)$$

$\mathbf{x}_0 \sim p_{\text{data}}$, α_t, σ_t 是 $t \in [0, T]$ 的非负标量函数，满足

- (i) 对所有 $t \in (0, 1]$, $\alpha_t > 0$ 、 $\sigma_t > 0$ (允许 $\sigma_0 = 0$)，且
- (ii) 通常 $\alpha_0 = 1$ 且 $\sigma_0 = 0$.

即 $\mathbf{x}_t \sim p_t(\mathbf{x}_t|\mathbf{x}_0)$ 可通过下式采样：

$$\mathbf{x}_t = \alpha_t \mathbf{x}_0 + \sigma_t \boldsymbol{\epsilon}, \quad \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}).$$

框架涵盖 VE (如 NCSN)、VP (如 DDPM)，以及流匹配 (FM) 前向核 (Lipman et al., 2022; Liu, 2022)，后者在 $\mathbf{x}_0$ 和 $\boldsymbol{\epsilon}$ 间线性插值 (后文见节 5.2)。

- **VE (NCSN) 核：** $\alpha_t \equiv 1, \sigma_T \gg 1$;
- **VP (DDPM) 核：** $\alpha_t := \sqrt{1 - \sigma_t^2}$ ，因此 $\alpha_t^2 + \sigma_t^2 = 1$;
- **FM 核：** $\alpha_t = 1 - t, \sigma_t = t$.

4.4.2 与得分 SDE 的联系

对得分 SDE，指定线性形式的 $p_t(\mathbf{x}_t|\mathbf{x}_0)$ 自然诱导仿射系数 SDE，比从漂移、扩散开始求解矩 ODE 更直观（见节 4.3.3）。

给定式 (4.4.1) 的扰动核，对应前向 SDE 如式 (4.3.2) 关于 $\mathbf{x}$ 线性：

$$d\mathbf{x}(t) = \underbrace{f(t)\mathbf{x}(t)}_{\mathbf{f}(\mathbf{x}(t),t)} dt + g(t) d\mathbf{w}(t),$$

$f, g: [0, T] \rightarrow \mathbb{R}$ 为时间实函数。系数 $f(t)$ 、 $g(t)$ 可由 α_t, σ_t 解析表达，如下引理总结。

引理 4.4.1: 前向扰动核 $\Leftrightarrow$ 线性 SDE

对 $t \in (0, T]$ ，定义 $\lambda_t := \log \frac{\alpha_t}{\sigma_t}$ 。给定前向扰动核

$$\mathbf{x}_t = \alpha_t \mathbf{x}_0 + \sigma_t \boldsymbol{\epsilon}, \quad \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}),$$

线性 SDE

$$d\mathbf{x}(t) = f(t)\mathbf{x}(t) dt + g(t) d\mathbf{w}(t),$$

其系数为

$$\begin{aligned} f(t) &= \frac{d}{dt} \log \alpha_t, \\ g^2(t) &= \frac{d\sigma_t^2}{dt} - 2 \frac{d}{dt} \log \alpha_t \sigma_t^2 = -2\sigma_t^2 \frac{d}{dt} \lambda_t, \end{aligned} \tag{4.4.2}$$

对所有 $t \in (0, T]$ ，条件转移为 $p_t(\mathbf{x}_t|\mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t; \alpha_t \mathbf{x}_0, \sigma_t^2 \mathbf{I})$ 。反之，若线性 SDE 的条件转移为 $\mathcal{N}(\mathbf{x}_t; \alpha_t \mathbf{x}_0, \sigma_t^2 \mathbf{I})$ ，所有 $t \in (0, T]$ 的 $\alpha_t, \sigma_t > 0$ ，则系数在 $t \in (0, T]$ 满足式 (4.4.2)。

引理的证明。

由节 4.3.3，证明将均值、协方差 ODE $\mathbf{m}'(t) = f(t)\mathbf{m}(t)$ 、 $\mathbf{P}'(t) = 2f(t)\mathbf{P}(t) + g^2(t)\mathbf{I}$ 与以下量匹配：在 $(0, T]$ 上， $\mathbf{m}(t) = \alpha_t \mathbf{x}_0$ 且 $\mathbf{P}(t) = \sigma_t^2 \mathbf{I}$ 。■

注.

若要终端精确匹配高斯先验，过程须完全遗忘 $\mathbf{x}_0$ 并达到目标方差；要求 $\alpha_T = 0$ ， σ_T^2 等于先验方差。

SDE 表述中有

$$\alpha_t = \exp \left(\int_0^t f(u) du \right).$$

因此，在有限 T 强制 $\alpha_T = 0$ ，必然有

$$\int_0^T f(u) du = -\infty,$$

意味着 $t \rightarrow T$ 时漂移须以无穷快速度收缩. 同时扩散须发散以保持规定方差，体现为

$$g^2(t) = \sigma_t^{2'} - 2 \frac{\alpha_t'}{\alpha_t} \sigma_t^2 \rightarrow \infty \quad \text{当 } t \rightarrow T.$$

若 f, g 在 $[0, T]$ 有界，则必有 $\alpha_T > 0$ ，保留对 $\mathbf{x}_0$ 的残余依赖. 此时只能渐近达到高斯先验：或在 $t \rightarrow T$ 极限（不精确达到），或经适当时间重参数化，在 $T \rightarrow \infty$ 的无限时域上精确达到.

由引理，经系数 $f(t), g(t)$ 的线性 SDE 指定逐步加噪，与用 α_t, σ_t 定义扰动核在数学上等价. 扩散文献交替使用两视角. 因此：

观察 4.4.1:

定义 $p_t(\mathbf{x}_t|\mathbf{x}_0)$ 等价于指定线性 SDE 系数 $f(t), g(t)$.

4.4.3 与基于变分的扩散模型的联系

回顾 DDPM 通过 Bayes 法则得到的核心恒等式：

$$p(\mathbf{x}_{t-\Delta t}|\mathbf{x}_t, \mathbf{x}) = p(\mathbf{x}_t|\mathbf{x}_{t-\Delta t}) \cdot \frac{p_{t-\Delta t}(\mathbf{x}_{t-\Delta t}|\mathbf{x})}{p_t(\mathbf{x}_t|\mathbf{x})}, \quad (4.4.3)$$

对任意 $\mathbf{x}$ （通常 $\mathbf{x} \sim p_{\text{data}}$ ）成立. 反向条件分布 $p(\mathbf{x}_{t-\Delta t}|\mathbf{x}_t, \mathbf{x})$ 是建模核心，支持易于处理的训练目标和高效采样.

DDPM 通常先定义逐步核 $p(\mathbf{x}_t|\mathbf{x}_{t-\Delta t})$ ，但累积转移 $p_t(\mathbf{x}_t|\mathbf{x}_0)$ 通常更可解释、实用，尤其对先验和损失设计.

推导转移核. 扩展到连续时间. 令 $0 \leq t < s \leq T$ 为两个时间点. 给定扰动核 $p_t(\mathbf{x}_t|\mathbf{x}_0)$ ，以 $p(\mathbf{x}_s|\mathbf{x}_t)$ 为中间量，应用式 (4.4.3)¹¹，可对任意 $\mathbf{x}$ 计算 $p(\mathbf{x}_t|\mathbf{x}_s, \mathbf{x})$. 下述引理总结推导，将引理 2.2.2 扩展到无需假设 $\alpha_t^2 + \sigma_t^2 = 1$ 的情况.

引理 4.4.2: 反向条件转移核

令 $0 \leq t < s \leq T$. 反向条件转移核为

$$p(\mathbf{x}_t|\mathbf{x}_s, \mathbf{x}) = \mathcal{N}(\mathbf{x}_t; \boldsymbol{\mu}(\mathbf{x}_s, \mathbf{x}; s, t), \sigma^2(s, t)\mathbf{I}),$$

¹¹将 s 视作一般较早时间，此恒等式自然扩展到连续时间.

其中

$$\boldsymbol{\mu}(\mathbf{x}_s, \mathbf{x}; s, t) := \frac{\alpha_{s|t}\sigma_t^2}{\sigma_s^2}\mathbf{x}_s + \frac{\alpha_t\sigma_{s|t}^2}{\sigma_s^2}\mathbf{x}, \quad \sigma^2(s, t) := \sigma_{s|t}^2 \frac{\sigma_t^2}{\sigma_s^2}. \quad (4.4.4)$$

$\alpha_{s|t}$ 、 $\sigma_{s|t}$ 定义为

$$\alpha_{s|t} := \frac{\alpha_s}{\alpha_t}, \quad \sigma_{s|t}^2 := \sigma_s^2 - \alpha_{s|t}^2 \sigma_t^2.$$

引理的证明.

先计算前向转移核:

$$p(\mathbf{x}_s|\mathbf{x}_t) = \mathcal{N}(\mathbf{x}_s; \alpha_{s|t}\mathbf{x}_t, \sigma_{s|t}^2\mathbf{I}). \quad (4.4.5)$$

反向核来自 Bayes 法则, 所有相关分布均高斯, 可直接计算得到结果. 更多细节见 (Kingma et al., 2021) 附录 A.

虽然 $p(\mathbf{x}_{t+\Delta t}|\mathbf{x}_t)$ 、 $p_t(\mathbf{x}_t|\mathbf{x}_0)$ 理论等价, 后者通常更核心. 式 (4.4.5) 的逐步转移主要用于获得闭式反向核. 近期工作 (Kingma et al., 2021) 因而偏好直接指定 $p_t(\mathbf{x}_t|\mathbf{x}_0)$, 更清晰、可解释.

反向过程建模、训练与采样. 式 (2.2.13) 的训练目标 (ELBO) 与节 2.2 框架在一般设定下仍适用. 为清楚起见, 按 Kingma et al. (2021) 采用 $\mathbf{x}$ 预测 $\mathbf{x}_\phi(\mathbf{x}_s, s)$. 由如下关系 (同式 (2.2.12)), 等价 $\boldsymbol{\epsilon}$ 预测 $\boldsymbol{\epsilon}_\phi(\mathbf{x}_s, s)$ 也有效:

$$\mathbf{x}_s = \alpha_s \mathbf{x}_\phi(\mathbf{x}_s, s) + \sigma_s \boldsymbol{\epsilon}_\phi(\mathbf{x}_s, s), \quad \text{对任意给定 } \mathbf{x}_s \sim q_s.$$

建模与扩散损失 $\mathcal{L}_{\text{diffusion}}$. 类似 DDPM, 式 (4.4.4) 的条件分布 $p(\mathbf{x}_t|\mathbf{x}_s, \mathbf{x})$ 启发用可学习预测 $\mathbf{x}_\phi(\mathbf{x}_s, s)$ 替代干净信号 $\mathbf{x}$, 得到参数化反向模型:

$$p_\phi(\mathbf{x}_t|\mathbf{x}_s) := \mathcal{N}(\mathbf{x}_t; \boldsymbol{\mu}_\phi(\mathbf{x}_s, s, t), \sigma^2(s, t)\mathbf{I}), \quad (4.4.6)$$

均值参数化为

$$\boldsymbol{\mu}_\phi(\mathbf{x}_s, s, t) = \frac{\alpha_{s|t}\sigma_t^2}{\sigma_s^2}\mathbf{x}_s + \frac{\alpha_t\sigma_{s|t}^2}{\sigma_s^2}\mathbf{x}_\phi(\mathbf{x}_s, s).$$

给定式 (4.4.1), $\mathcal{L}_{\text{diffusion}}(\mathbf{x}; \phi)$ 的 KL 散度化为加权回归损失:

$$\begin{aligned} \mathcal{D}_{\text{KL}}(p(\mathbf{x}_t|\mathbf{x}_s, \mathbf{x}_0) \| p_\phi(\mathbf{x}_t|\mathbf{x}_s)) &= \frac{1}{2\sigma^2(s, t)} \|\boldsymbol{\mu}(\mathbf{x}_s, \mathbf{x}_0; s, t) - \boldsymbol{\mu}_\phi(\mathbf{x}_s, s, t)\|_2^2 \\ &= \frac{1}{2}(\text{SNR}(t) - \text{SNR}(s)) \|\mathbf{x}_0 - \mathbf{x}_\phi(\mathbf{x}_s, s)\|_2^2, \end{aligned} \quad (4.4.7)$$

$\mathbf{x}_s = \alpha_s \mathbf{x}_0 + \sigma_s \boldsymbol{\epsilon}$, $\mathbf{x}_0 \sim p_{\text{data}}$, $\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$, $\text{SNR}(s) := \alpha_s^2/\sigma_s^2$ 表示时间 s 的信噪比.

注.

(Kingma et al., 2021) 研究式 (4.4.7) 在 $t \rightarrow s$ 的连续时间极限, 得到

$$\mathcal{L}_{\text{VDM}}^{\infty}(\mathbf{x}_0) = -\frac{1}{2} \mathbb{E}_{s, \epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})} \text{SNR}'(s) \|\mathbf{x}_0 - \mathbf{x}_{\phi}(\mathbf{x}_s, s)\|_2^2.$$

此设定还引入可学习噪声调度, 且可推广到连续数据之外, 但此类扩展超出当前讨论范围.

采样. 类似 DDPM, 用式 (4.4.6) 的参数化核采样:

$$\mathbf{x}_t = \underbrace{\frac{\alpha_{s|t}\sigma_t^2}{\sigma_s^2}\mathbf{x}_s + \frac{\alpha_t\sigma_{s|t}^2}{\sigma_s^2}\mathbf{x}_{\phi^{\times}}(\mathbf{x}_s, s)}_{\mu_{\phi^{\times}}(\mathbf{x}_s, t, s)} + \sigma_{s|t}\frac{\sigma_t}{\sigma_s}\boldsymbol{\epsilon}_s, \quad \boldsymbol{\epsilon}_s \sim \mathcal{N}(\mathbf{0}, \mathbf{I}). \quad (4.4.8)$$

4.5 (选读) 通过边缘化与 Bayes 法则理解 Fokker–Planck 方程及反向 SDE

本节从概率角度看 Fokker–Planck 方程与反向 SDE 的结构. 用边缘化技巧、Bayes 法则等基本工具, 阐明随机过程统计表述与相应微分方程的联系.

强调此处“推导”不是严格数学证明, 而是旨在传达内在联系的启发式论证.

4.5.1 由转移核边缘化得到 Fokker–Planck 方程

给定式 (4.1.2) 的前向转移概率

$$p(\mathbf{x}_{t+\Delta t}|\mathbf{x}_t) = \mathcal{N}(\mathbf{x}_{t+\Delta t}; \mathbf{x}_t + \mathbf{f}(\mathbf{x}_t, t)\Delta t, g^2(t)\Delta t\mathbf{I}),$$

以及边缘分布

$$p_t(\mathbf{x}_t), \quad p_{t+\Delta t}(\mathbf{x}_{t+\Delta t}),$$

目标是推导控制 p_t 时间演化的 Fokker–Planck 方程.

变量替换. 由 Markov 性, 时间 $t+\Delta t$ 的边缘可写为对前状态 $\mathbf{x}_t$ 的积分 (即 Chapman–Kolmogorov 方程):

$$p_{t+\Delta t}(\mathbf{x}) = \int \mathcal{N}(\mathbf{x}; \mathbf{y} + \mathbf{f}(\mathbf{y}, t)\Delta t, g^2(t)\Delta t\mathbf{I})p_t(\mathbf{y}) d\mathbf{y}.$$

引入新变量

$$\mathbf{u} := \mathbf{y} + \mathbf{f}(\mathbf{y}, t)\Delta t,$$

使高斯以 $\mathbf{u}$ 为中心. 小 Δt 时, 映射可逆, 且

$$\mathbf{y} = \mathbf{u} - \mathbf{f}(\mathbf{u}, t)\Delta t + \mathcal{O}(\Delta t^2), \quad \left| \det \frac{\partial \mathbf{y}}{\partial \mathbf{u}} \right| = 1 - (\nabla_{\mathbf{u}} \cdot \mathbf{f})(\mathbf{u}, t)\Delta t + \mathcal{O}(\Delta t^2).$$

变量替换公式因而给出

$$p_{t+\Delta t}(\mathbf{x}) = \int \mathcal{N}(\mathbf{x}; \mathbf{u}, g^2(t)\Delta t\mathbf{I}) \cdot \left[p_t(\mathbf{u}) - \Delta t \mathbf{f}(\mathbf{u}, t) \cdot \nabla_{\mathbf{u}} p_t(\mathbf{u}) - \Delta t (\nabla_{\mathbf{u}} \cdot \mathbf{f})(\mathbf{u}, t) p_t(\mathbf{u}) \right] d\mathbf{u} + \mathcal{O}(\Delta t^2),$$

Taylor 展开. 对任意光滑函数 $\phi: \mathbb{R}^D \rightarrow \mathbb{R}$ 、尺度 $\sigma > 0$, 若 $\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$, 如下近似成立 (称为 Taylor–高斯平滑公式):

$$\int \mathcal{N}(\mathbf{x}; \mathbf{u}, \sigma^2\mathbf{I})\phi(\mathbf{u}) d\mathbf{u} = \mathbb{E}[\phi(\mathbf{x} + \sigma\mathbf{z})] = \phi(\mathbf{x}) + \frac{\sigma^2}{2} \Delta_{\mathbf{x}}\phi(\mathbf{x}) + \mathcal{O}(\sigma^4).$$

原因是 Taylor 展开为

$$\phi(\mathbf{x} + \sigma \mathbf{z}) = \phi(\mathbf{x}) + \sigma \nabla_{\mathbf{x}} \phi(\mathbf{x}) \cdot \mathbf{z} + \frac{\sigma^2}{2} \mathbf{z}^\top \nabla_{\mathbf{x}}^2 \phi(\mathbf{x}) \mathbf{z} + \mathcal{O}(\sigma^3)$$

且 $\mathbb{E}[\mathbf{z}] = \mathbf{0}$, $\mathbb{E}[\mathbf{z}\mathbf{z}^\top] = \mathbf{I}$.

对 $\phi = p_t$ 、 $\phi = \mathbf{f} \cdot \nabla_{\mathbf{u}} p_t$ 、 $\phi = (\nabla_{\mathbf{u}} \cdot \mathbf{f}) p_t$ 应用, 使用 $\sigma^2 = g^2(t) \Delta t$, 得到

$$\begin{aligned} & p_{t+\Delta t}(\mathbf{x}) - p_t(\mathbf{x}) \\ &= -\Delta t \mathbf{f}(\mathbf{x}, t) \cdot \nabla_{\mathbf{x}} p_t(\mathbf{x}) - \Delta t (\nabla_{\mathbf{x}} \cdot \mathbf{f})(\mathbf{x}, t) p_t(\mathbf{x}) + \frac{g^2(t)}{2} \Delta t \Delta_{\mathbf{x}} p_t(\mathbf{x}) + \mathcal{O}(\Delta t^2) \\ &= -\Delta t \nabla_{\mathbf{x}} \cdot (\mathbf{f}(\mathbf{x}, t) p_t(\mathbf{x})) + \frac{g^2(t)}{2} \Delta t \Delta_{\mathbf{x}} p_t(\mathbf{x}) + \mathcal{O}(\Delta t^2). \end{aligned}$$

除以 Δt 、令 $\Delta t \rightarrow 0$, 得到 Fokker–Planck 方程.

节 C.1.4 给出基于伊藤微积分的推导, 补充上述离散时间视角.

4.5.2 反向 SDE 为何具有此形式?

严格推导技术复杂, 需要深入 Fokker–Planck 方程的性质. 但可通过 Bayes 定理直观理解形式. 这里作启发式推导, 解释式 (4.1.6) 的形式及得分函数为何出现¹².

用 Bayes 法则反转. 目标是确定反向转移核, 先考虑离散情况:

$$p(\mathbf{x}_t | \mathbf{x}_{t+\Delta t}),$$

再取 $\Delta t \rightarrow 0$, 获得连续时间表述. 由 Bayes 定理:

$$\begin{aligned} p(\mathbf{x}_t | \mathbf{x}_{t+\Delta t}) &= p(\mathbf{x}_{t+\Delta t} | \mathbf{x}_t) \frac{p_t(\mathbf{x}_t)}{p_{t+\Delta t}(\mathbf{x}_{t+\Delta t})} \\ &= p(\mathbf{x}_{t+\Delta t} | \mathbf{x}_t) \exp(\log p_t(\mathbf{x}_t) - \log p_{t+\Delta t}(\mathbf{x}_{t+\Delta t})). \end{aligned} \quad (4.5.1)$$

假设前向转移核如式 (4.1.2):

$$p(\mathbf{x}_{t+\Delta t} | \mathbf{x}_t) = \mathcal{N}(\mathbf{x}_{t+\Delta t}; \mathbf{x}_t + \mathbf{f}(\mathbf{x}_t, t) \Delta t, g^2(t) \Delta t \mathbf{I})$$

Taylor 展开. 为处理指数项, 使用一阶 Taylor 展开. 关键是同时在空间、时间上围绕 $(\mathbf{x}_t, t)$ 展开:

$$\begin{aligned} \log p_{t+\Delta t}(\mathbf{x}_{t+\Delta t}) &= \log p_t(\mathbf{x}_t) + \nabla_{\mathbf{x}} \log p_t(\mathbf{x}_t) \cdot (\mathbf{x}_{t+\Delta t} - \mathbf{x}_t) \\ &\quad + \frac{\partial \log p_t(\mathbf{x}_t)}{\partial t} \Delta t + \mathcal{O}(\|\mathbf{h}\|_2^2) \end{aligned}$$

其中 $\mathbf{h} := (\mathbf{x}_{t+\Delta t} - \mathbf{x}_t, \Delta t)$. 因此:

$$\begin{aligned} \log p_t(\mathbf{x}_t) - \log p_{t+\Delta t}(\mathbf{x}_{t+\Delta t}) &= -\nabla_{\mathbf{x}} \log p_t(\mathbf{x}_t) \cdot (\mathbf{x}_{t+\Delta t} - \mathbf{x}_t) \\ &\quad - \frac{\partial \log p_t(\mathbf{x}_t)}{\partial t} \Delta t + \mathcal{O}(\|\mathbf{h}\|_2^2) \end{aligned} \quad (4.5.2)$$

前向过程漂移、扩散有限时, $\mathbb{E}[\|\mathbf{x}_{t+\Delta t} - \mathbf{x}_t\|_2^2] = \mathcal{O}(\Delta t)$, 保证余项期望为 $\mathcal{O}((\Delta t)^2)$.

¹²推导受到这篇文章方法的启发.

代入反向转移. 将式 (4.1.2)、式 (4.5.2) 代入式 (4.5.1):

$$\begin{aligned} & p(\mathbf{x}_t | \mathbf{x}_{t+\Delta t}) \\ &= \frac{1}{(2\pi g^2(t)\Delta t)^{D/2}} \exp\left(-\frac{\|\mathbf{x}_{t+\Delta t} - \mathbf{x}_t - \mathbf{f}(\mathbf{x}_t, t)\Delta t\|_2^2}{2g^2(t)\Delta t}\right) \\ & \quad \cdot \exp\left(-\nabla_{\mathbf{x}} \log p_t(\mathbf{x}_t) \cdot (\mathbf{x}_{t+\Delta t} - \mathbf{x}_t) - \frac{\partial \log p_t(\mathbf{x}_t)}{\partial t} \Delta t + \mathcal{O}((\Delta t)^2)\right). \end{aligned}$$

代数整理. 关键是对指数配方. 有

$$\begin{aligned} & -\frac{\|\mathbf{x}_{t+\Delta t} - \mathbf{x}_t - \mathbf{f}(\mathbf{x}_t, t)\Delta t\|_2^2}{2g^2(t)\Delta t} - \nabla_{\mathbf{x}} \log p_t(\mathbf{x}_t) \cdot (\mathbf{x}_{t+\Delta t} - \mathbf{x}_t) \\ &= -\frac{[\|\mathbf{x}_{t+\Delta t} - \mathbf{x}_t - \mathbf{f}(\mathbf{x}_t, t)\Delta t\|_2^2 + 2g^2(t)\Delta t \nabla_{\mathbf{x}} \log p_t(\mathbf{x}_t) \cdot (\mathbf{x}_{t+\Delta t} - \mathbf{x}_t)]}{2g^2(t)\Delta t} \end{aligned}$$

令 $\boldsymbol{\delta} := \mathbf{x}_{t+\Delta t} - \mathbf{x}_t$ 、 $\boldsymbol{\mu} := \mathbf{f}(\mathbf{x}_t, t)\Delta t$. 则:

$$\begin{aligned} & \|\boldsymbol{\delta} - \boldsymbol{\mu}\|_2^2 + 2g^2(t)\Delta t \nabla_{\mathbf{x}} \log p_t(\mathbf{x}_t) \cdot \boldsymbol{\delta} \\ &= \|\boldsymbol{\delta}\|_2^2 - 2\boldsymbol{\delta} \cdot \boldsymbol{\mu} + \|\boldsymbol{\mu}\|_2^2 + 2g^2(t)\Delta t \nabla_{\mathbf{x}} \log p_t(\mathbf{x}_t) \cdot \boldsymbol{\delta} \\ &= \|\boldsymbol{\delta}\|_2^2 - 2\boldsymbol{\delta} \cdot [\boldsymbol{\mu} - g^2(t)\Delta t \nabla_{\mathbf{x}} \log p_t(\mathbf{x}_t)] + \|\boldsymbol{\mu}\|_2^2 \\ &= \|\boldsymbol{\delta} - [\boldsymbol{\mu} - g^2(t)\Delta t \nabla_{\mathbf{x}} \log p_t(\mathbf{x}_t)]\|_2^2 - \|g^2(t)\Delta t \nabla_{\mathbf{x}} \log p_t(\mathbf{x}_t)\|_2^2 \end{aligned}$$

代回得

$$\begin{aligned} & \|\boldsymbol{\delta} - [\mathbf{f}(\mathbf{x}_t, t)\Delta t - g^2(t)\Delta t \nabla_{\mathbf{x}} \log p_t(\mathbf{x}_t)]\|_2^2 \\ &= \|\mathbf{x}_{t+\Delta t} - \mathbf{x}_t - [\mathbf{f}(\mathbf{x}_t, t) - g^2(t)\nabla_{\mathbf{x}} \log p_t(\mathbf{x}_t)]\Delta t\|_2^2. \end{aligned}$$

因此,

$$\begin{aligned} & p(\mathbf{x}_t | \mathbf{x}_{t+\Delta t}) \\ &= \frac{1}{(2\pi g^2(t)\Delta t)^{D/2}} \\ & \quad \cdot \exp\left(-\frac{\|\mathbf{x}_{t+\Delta t} - \mathbf{x}_t - [\mathbf{f}(\mathbf{x}_t, t) - g^2(t)\nabla_{\mathbf{x}} \log p_t(\mathbf{x}_t)]\Delta t\|_2^2}{2g^2(t)\Delta t}\right) \\ & \quad \cdot \exp(\mathcal{O}(\Delta t)) \\ &= \mathcal{N}(\mathbf{x}_t; \mathbf{x}_{t+\Delta t} - [\mathbf{f}(\mathbf{x}_t, t) - g^2(t)\nabla_{\mathbf{x}} \log p_t(\mathbf{x}_t)]\Delta t, g^2(t)\Delta t \mathbf{I}) \\ & \quad \cdot (1 + \mathcal{O}(\Delta t)). \end{aligned}$$

配方产生的额外项 $\|g^2(t)\Delta t \nabla_{\mathbf{x}} \log p_t(\mathbf{x}_t)\|_2^2$ 为 $\mathcal{O}((\Delta t)^2)$, 可吸收进误差项. 类似地, 时间导数项 $\frac{\partial \log p_t(\mathbf{x}_t)}{\partial t} \Delta t$ 为 $\mathcal{O}(\Delta t)$, 在连续极限消失.

取 $\Delta t \rightarrow 0$ 极限。 $\Delta t \approx 0$ 时，在光滑性假设下，如下近似成立：

$$\begin{aligned} \mathbf{f}(\mathbf{x}_t, t) &\approx \mathbf{f}(\mathbf{x}_{t+\Delta t}, t + \Delta t), \\ g(t) &\approx g(t + \Delta t), \\ \nabla_{\mathbf{x}} \log p_t(\mathbf{x}_t) &\approx \nabla_{\mathbf{x}} \log p_{t+\Delta t}(\mathbf{x}_{t+\Delta t}) \\ &= \mathbf{s}(\mathbf{x}_{t+\Delta t}, t + \Delta t). \end{aligned}$$

使用近似并整理得到

$$\begin{aligned} p(\mathbf{x}_t | \mathbf{x}_{t+\Delta t}) &\approx \frac{1}{(2\pi g^2(t) \Delta t)^{D/2}} \exp \left(- \frac{\left\| \mathbf{x}_t - \left(\mathbf{x}_{t+\Delta t} - [\mathbf{f}(\mathbf{x}_{t+\Delta t}, t + \Delta t) - g^2(t + \Delta t) \mathbf{s}(\mathbf{x}_{t+\Delta t}, t + \Delta t)] \Delta t \right) \right\|_2^2}{2g^2(t + \Delta t) \Delta t} \right). \end{aligned}$$

因此 $p(\mathbf{x}_t | \mathbf{x}_{t+\Delta t})$ 近似为正态分布，其参数为

$$\begin{aligned} \text{均值: } &\mathbf{x}_{t+\Delta t} - [\mathbf{f}(\mathbf{x}_{t+\Delta t}, t + \Delta t) - g^2(t + \Delta t) \mathbf{s}(\mathbf{x}_{t+\Delta t}, t + \Delta t)] \Delta t, \\ \text{协方差: } &g^2(t + \Delta t) \Delta t \mathbf{I}. \end{aligned}$$

取 $\Delta t \rightarrow 0$ ，“推导”出式 (4.1.6) 的反向连续 SDE.

4.6 结束语

本章将变分、得分视角的离散扩散统一为优雅的时间框架，标志关键进展。DDPM、NCSN 都可理解为具有不同漂移 / 波动系数的 SDE 的离散化。

框架基石是存在相应反向 SDE，正式定义反转加噪的生成过程。关键是反向漂移仅依赖一个未知量：每个时间边缘数据分布的得分 $\nabla_{\mathbf{x}} \log p_t(\mathbf{x})$ 。此洞见确立得分在生成建模的核心地位。

还引入纯确定性对应过程——概率流常微分方程（PF-ODE），其解轨迹沿与 SDE 相同的边缘密度 $\{p_t\}$ 演化，由 Fokker-Planck 方程保证。深刻意义是复杂生成任务本质上等于求解微分方程。训练化为学习定义向量场的得分函数，采样化为数值积分问题。

纯确定性 PF-ODE 提供通向扩散模型第三个、最后视角的强大桥梁。学习速度场控制的确定性变换，是近期重要生成模型家族的核心原理。下一章将：

1. 探索基于流的视角，从归一化流、神经 ODE 的起源开始。
2. 说明它如何导向现代流匹配框架，直接学习速度场以在分布间输运样本。

最终将看到，随机原理导出的确定性 PF-ODE 可从完全不同的流起源构造、推广，从而完成扩散建模的统一图景。

第 5 章 基于流的视角：从归一化流到流匹配

万物流转.

赫拉克利特

概率论的基石之一——变量替换公式 (Tabak and Vanden-Eijnden, 2010; Turner, 2013)——在现代生成建模中焕发了新的生命. 得分 SDE 借助 Fokker-Planck 方程 (节 4.1.5) 提供了连接数据分布与先验分布的微分方程框架, 而这种连续演化本质上就是同一基本原理的动态形式.

密度的变量替换公式. 给定可逆变换 $\mathbf{f}$, 若 $\mathbf{z} \sim p_{\text{prior}}$, 则 $\mathbf{x} = \mathbf{f}(\mathbf{z})$ 的密度为:

$$p(\mathbf{x}) = p_{\text{prior}}(\mathbf{z}) \left| \det \frac{\partial \mathbf{f}^{-1}(\mathbf{x})}{\partial \mathbf{x}} \right|, \quad \text{其中 } \mathbf{z} = \mathbf{f}^{-1}(\mathbf{x}). \quad (5.0.1)$$

当 $\mathbf{f}$ 可处理时, 这个看似简单的公式使密度和样本的精确双向输运成为可能, 构成了我们将在节 5.1 中介绍的归一化流 (normalizing flow) 的基础. 但如果从连续时间变换的角度重新思考这一思想, 会得到什么?

本章以这一核心原理为基础, 探索扩散模型的一种新视角: 流匹配 (flow matching) (见节 5.2). 流匹配自然地 (连续) 归一化流发展而来, 深化了我们对扩散作为一种强大密度输运过程的理解.

为帮助读者扎实地理解本章, 我们在章 B 中对变量替换公式的不同变体作了直观且自足的概述, 从基本情形逐步推进至连续性方程, 最终到达 Fokker-Planck 方程.

5.1 基于流的模型：归一化流与神经常微分方程

本节介绍基于流的模型，包括归一化流 (NF) (Rezende and Mohamed, 2015) 与神经常微分方程 (neural ODE) (NODE) (Chen et al., 2018)。

归一化流对简单的基础分布施加一系列可逆变换，从而实现灵活且可处理的概率密度估计。神经常微分方程将这一框架扩展到连续时间，变换由常微分方程支配。通过将变换视为连续时间动力学，NODE 为 NF 范式提供了平滑且可扩展的推广。




图 5.1: 可逆映射下归一化流中样本运动的示意图。它由一系列可逆函数 $\mathbf{f}: \mathbf{z} \mapsto \mathbf{x}$ 组成，将潜变量 $\mathbf{z}$ 变换为数据 $\mathbf{x}$ ，并配有重构数据的逆映射 $\mathbf{f}^{-1}: \mathbf{x} \mapsto \mathbf{z}$ 。NF 类似于编码器-解码器结构，其中编码器由光滑可逆映射实现，解码器恰好是它的逆映射。相应的密度变化可通过式 (5.0.1) 给出的变量替换公式计算。

5.1.1 归一化流

归一化流 (Rezende and Mohamed, 2015) 通过可逆映射，将简单先验 $p_{\text{prior}}(\mathbf{z})$ (例如标准高斯分布 $\mathcal{N}(\mathbf{0}, \mathbf{I})$) 变换为复杂的数据分布 $p_{\text{data}}(\mathbf{x})$ ：

$$\mathbf{f}_{\phi}: \mathbb{R}^D \rightarrow \mathbb{R}^D,$$

其中 $\mathbf{x} = \mathbf{f}_{\phi}(\mathbf{z})$ ，且 $\mathbf{z} \sim p_{\text{prior}}$ 。这里， $\mathbf{x}$ 和 $\mathbf{z}$ 的维数相同。利用式 (5.0.1) 中的变量替换公式，模型似然为¹

$$\log p_{\phi}(\mathbf{x}) = \log p_{\text{prior}}(\mathbf{z}) + \log \left| \det \frac{\partial \mathbf{f}_{\phi}^{-1}(\mathbf{x})}{\partial \mathbf{x}} \right|. \quad (5.1.1)$$

¹如果进一步将映射限制为凸势函数的梯度，即 $\mathbf{f}_{\phi} = \nabla \psi_{\phi}$ ，其中 ψ_{ϕ} 为凸函数，则式 (5.1.1) 化为式 (7.2.4) 中的 Monge-Ampère 关系。这个偏微分方程刻画了二次代价下将一个分布变换为另一个分布的最优变换。更多细节见章 7 和 (Huang et al., 2021)。

训练目标. 通过最大化数据上的似然来学习参数 ϕ :

$$\mathcal{L}_{\text{NF}}(\phi) = \mathbb{E}_{\mathbf{x} \sim p_{\text{data}}} [\log p_{\phi}(\mathbf{x})]. \quad (5.1.2)$$

计算式 (5.1.1) 中的雅可比行列式可能代价高昂, 通常具有 $\mathcal{O}(D^3)$ 的复杂度.

构造可逆变换. 单个复杂的可逆网络可能因雅可比行列式的计算而代价高昂. 反之, 简单变换 (例如线性变换) 虽高效, 却缺乏表达能力.

为平衡这两点, NF 使用由 K 个可训练的可逆映射 $\{\mathbf{f}_k\}_{k=0}^{L-1}$ 组成的序列, 每个映射的雅可比矩阵均可高效计算:

$$\mathbf{f}_{\phi} = \mathbf{f}_{L-1} \circ \mathbf{f}_{L-2} \circ \cdots \circ \mathbf{f}_0.$$

每个 $\mathbf{f}_k$ 都由神经网络参数化, 但为简化记号, 我们省略对 ϕ 的显式依赖.

样本通过以下方式变换:

$$\mathbf{x}_{k+1} = \mathbf{f}_k(\mathbf{x}_k), \quad k = 0, \dots, L-1, \quad (5.1.3)$$

其中 $\mathbf{z} = \mathbf{x}_0 \sim p_{\text{prior}}$, 而 $\mathbf{x} = \mathbf{x}_L$ 对应于数据. 所得 (对数) 密度可推导为

$$\begin{aligned} p_{\phi}(\mathbf{x}) &= p_{\text{prior}}(\mathbf{x}_0) \prod_{k=0}^{L-1} \left| \det \frac{\partial \mathbf{f}_k}{\partial \mathbf{x}_k} \right|^{-1}, \text{ 或等价地,} \\ \log p_{\phi}(\mathbf{x}) &= \log p_{\text{prior}}(\mathbf{x}_0) + \sum_{k=0}^{L-1} \log \left| \det \frac{\partial \mathbf{f}_k}{\partial \mathbf{x}_k} \right|^{-1}. \end{aligned} \quad (5.1.4)$$




图 5.2: **归一化流的示意图.** NF 由一组层叠的可逆映射组成, $\mathbf{f}_{\phi} = \mathbf{f}_{L-1} \circ \mathbf{f}_{L-2} \circ \cdots \circ \mathbf{f}_0$. 这一变换将潜在样本 $\mathbf{x}_0 \sim p_{\text{prior}}$ 映射为数据样本 $\mathbf{x}_L \sim p_{\text{data}}$.

可逆流的例子. 大量文献致力于设计能够高效计算雅可比矩阵的单层流结构. 下面介绍两类代表性结构: 平面流 (Rezende and Mohamed, 2015) 与残差流 (Chen et al., 2019; Behrmann et al., 2019), 后者推动了节 5.1.2 中的发展.

平面流: 它采用如下简单变换

$$\mathbf{f}(\mathbf{z}) = \mathbf{z} + \mathbf{u}h(\mathbf{w}^{\top} \mathbf{z} + b),$$

其中 $\mathbf{u}, \mathbf{w} \in \mathbb{R}^D$, $b \in \mathbb{R}$, 而 $h(\cdot)$ 是激活函数. 雅可比行列式为

$$|1 + \mathbf{u}^{\top} h'(\mathbf{w}^{\top} \mathbf{z} + b) \mathbf{w}|.$$

残差流： 将变换 $\mathbf{f}$ 定义为

$$\mathbf{f}(\mathbf{z}) = \mathbf{z} + \mathbf{v}(\mathbf{z}), \quad (5.1.5)$$

其中 $\mathbf{v}$ 是压缩映射 (Lipschitz 常数 < 1) . 根据 Banach 不动点定理, 这保证了可逆性. 雅可比矩阵的对数行列式可化为迹展开:

$$\begin{aligned} \log \left| \det \frac{\partial \mathbf{f}(\mathbf{z})}{\partial \mathbf{z}} \right| &= \log \left(\det \frac{\partial \mathbf{f}(\mathbf{z})}{\partial \mathbf{z}} \right) \\ &= \text{Tr} \left(\log \left(\frac{\partial \mathbf{f}(\mathbf{z})}{\partial \mathbf{z}} \right) \right) \\ &= \text{Tr} \left(\log \left(\mathbf{I} + \frac{\partial \mathbf{v}(\mathbf{z})}{\partial \mathbf{z}} \right) \right) \\ &= \sum_{k=1}^{\infty} \frac{(-1)^{k+1}}{k} \text{Tr} \left(\left(\frac{\partial \mathbf{v}(\mathbf{z})}{\partial \mathbf{z}} \right)^k \right), \end{aligned} \quad (5.1.6)$$

因此可利用迹估计器 (Hutchinson, 1989) 进行高效求值.

采样与推断. 从 NF 采样十分直接: 抽取 $\mathbf{x}_0 \sim p_{\text{prior}}$, 并计算 $\mathbf{x} = \mathbf{f}_{\phi}(\mathbf{x}_0)$. 精确似然可由式 (5.1.4) 得到.

5.1.2 神经常微分方程




图 5.3: **离散时间与连续时间归一化流.** (左) 离散 NF 通过有限个可逆映射 $\mathbf{x}_{k+1} = \mathbf{f}_k(\mathbf{x}_k)$ 输运样本, 产生逐步变化且互不交叉的轨迹 (带箭头的点). (右) 连续 NF (神经常微分方程) 使状态沿 $\frac{d\mathbf{x}(t)}{dt} = \mathbf{v}_{\phi}(\mathbf{x}(t), t)$ 的积分曲线演化, 图中灰色向量场上叠加了带切向箭头的黑色路径.

从离散时间 NF 到连续时间 NF (神经常微分方程). NF 通常表述为由 L 个离散可逆变换组成的序列. 结合式 (5.1.3) 和式 (5.1.5) 中的“残差流”表述, 每一层可写成如下形式:

$$\mathbf{x}_{k+1} = \mathbf{f}_k(\mathbf{x}_k) := \mathbf{x}_k + \mathbf{v}_{\phi_k}(\mathbf{x}_k, k),$$

其中 $\mathbf{v}_{\phi_k}(\cdot, k)$ 是由神经网络参数化、依赖于层的速度场. 直观地说, 这个速度场是一个学得的向量值函数, 以平滑的小步在输入空间中“推动”数据点. 每个变换都沿这一速度给出的方向移动各点, 逐渐将简单先验分布变形为复杂的目标分布.

事实上, 这一表述对应于具有可学习参数 ϕ 的连续时间常微分方程的 Euler 离散化:

$$\frac{d\mathbf{x}(t)}{dt} = \mathbf{v}_{\phi}(\mathbf{x}(t), t).$$

在层数趋于无穷、步长趋于零 ($\Delta t \rightarrow 0$) 的极限下, 离散 NF 收敛为连续模型, 从而得到神经常微分方程 (NODE) (Chen et al., 2018) 框架, 也称为连续归一化流 (CNF).

神经常微分方程的形式化设置. 神经常微分方程通过下式定义连续变换:

$$\frac{d\mathbf{x}(t)}{dt} = \mathbf{v}_{\phi}(\mathbf{x}(t), t), \quad t \in [0, T] \quad (5.1.7)$$

其中:

- $\mathbf{x}(t) \in \mathbb{R}^D$ 是时刻 t 的状态; 为简洁起见, 我们有时写作 $\mathbf{x}_t$;
- $\mathbf{v}_{\phi}(\mathbf{x}(t), t)$ 是由 ϕ 参数化的神经网络.

NODE 的目标. 从初始条件 $\mathbf{x}(0) \sim p_{\text{prior}}$ 出发, ODE 使状态随时间连续演化, 诱导出一族边缘分布 $p_{\phi}(\mathbf{x}_t, t)$ (与 PF-ODE 类似!) ².

目标是学习神经向量场 $\mathbf{v}_{\phi}$; 直观上, 它表示沿数据空间中的连续轨迹输运各点的速度. 学习这一速度后, $t = 0$ 时的终端分布与目标分布 $p_{\text{data}}(\cdot)$ 匹配. 这一连续变换将离散归一化流与神经常微分方程统一到同一框架中.

连续时间变量替换公式. 与式 (5.0.1) 或式 (5.1.4) 类似, Chen et al. (2018) 推导了变量替换公式的连续时间版本. 对于按式 (5.1.7) 演化的过程 $\mathbf{x}(t)$ 的时变密度 $p_{\phi}(\mathbf{x}(t), t)$, 所谓瞬时变量替换公式为:

$$\frac{d}{dt} \log p_{\phi}(\mathbf{x}(t), t) = -\nabla_{\mathbf{x}} \cdot \mathbf{v}_{\phi}(\mathbf{x}(t), t).$$

因此, 给定先验 $p_{\text{prior}}(\mathbf{x}(T), T)$, 神经常微分方程诱导出的终端状态 $\mathbf{x}(T)$ 的对数密度为

$$\log p_{\phi}(\mathbf{x}(T), T) = \log p_{\text{prior}}(\mathbf{x}(0), 0) - \int_0^T \nabla_{\mathbf{x}} \cdot \mathbf{v}_{\phi}(\mathbf{x}(t), t) dt. \quad (5.1.8)$$

²我们采用翻转的时间约定, 以 $t = 0$ 表示先验 (源) 分布, 以 $t = 1$ 表示数据 (目标) 分布. 先验可交替写成 $p_{\phi}(\mathbf{x}(0), 0)$ 、 $p_{\text{prior}}(\mathbf{x}(0), 0)$, 或简写为 $p_{\text{prior}}(\mathbf{z})$.

这一表达式使我们能够通过数值求解 ODE 来计算精确似然，进而对模型进行最大似然训练。后文将详细讨论这一点。

虽然这个瞬时变量替换公式乍看起来可能并不熟悉，但它是 Fokker-Planck 方程的特殊情形，具体而言，是其被称为连续性方程的确定性形式（见章 B）。它也可解释为式 (5.1.4) 的连续时间极限。以下引理总结了这一结果及其推导：

引理 5.1.1: 瞬时变量替换

设 $\mathbf{z}(t)$ 是具有时变密度 $p(\mathbf{z}(t), t)$ 的连续随机过程，并假定它按以下 ODE 演化

$$\frac{d\mathbf{z}(t)}{dt} = \mathbf{F}(\mathbf{z}(t), t).$$

假定 $\mathbf{F}$ 关于 $\mathbf{z}$ 一致 Lipschitz，且关于 t 连续，则对数密度的时间导数满足：

$$\frac{\partial \log p(\mathbf{z}(t), t)}{\partial t} = -\nabla_{\mathbf{z}} \cdot \mathbf{F}(\mathbf{z}(t), t). \quad (5.1.9)$$

引理的证明。

我们在节 D.3 中给出两种不同的推导。

与离散时间公式的联系。 式 (5.1.8) 中的 NODE 似然，

$$\log p_{\phi}(\mathbf{x}(T), T) = \log p_{\text{prior}}(\mathbf{x}(0), 0) - \int_0^T \nabla_{\mathbf{x}} \cdot \mathbf{v}_{\phi}(\mathbf{x}(t), t) dt,$$

可视为式 (5.1.4) 中离散归一化流表述的连续时间对应物：

$$\log p_{\phi}(\mathbf{x}_L) = \log p_{\text{prior}}(\mathbf{x}_0) - \sum_{k=0}^{L-1} \log \left| \det \frac{\partial \mathbf{f}_k}{\partial \mathbf{x}_k} \right|.$$

积分对应于求和，而迹算子取代了对数行列式，正如式 (5.1.6) 所讨论的那样。引理的证明进一步探讨了这些对应关系。

训练 NODE。 根据式 (5.1.8)，NODE 学习参数化速度场 $\mathbf{v}_{\phi}$ ，使终端分布满足

$$p_{\phi}(\cdot, T) \approx p_{\text{data}},$$

其中轨迹从潜变量 $\mathbf{x}(0) \sim p_{\text{prior}}$ 出发，通过 ODE 流演化。训练遵循式 (1.1.2) 中的最大似然估计框架：

$$\mathcal{L}_{\text{NODE}}(\phi) := \mathbb{E}_{\mathbf{x} \sim p_{\text{data}}} [\log p_{\phi}(\mathbf{x}, T)].$$

精确对数似然的计算。 要计算数据点 $\mathbf{x}$ 的 $\log p_{\phi}(\mathbf{x}, T)$ ，我们对变量替换公式 5.1.8 进行积分：

$$\log p_{\phi}(\mathbf{x}, T) = \log p_{\text{prior}}(\mathbf{z}(0)) - \int_0^T \nabla_{\mathbf{z}} \cdot \mathbf{v}_{\phi}(\mathbf{z}(t), t) dt. \quad (5.1.10)$$

这里， $\mathbf{z}(t)$ 通过从 $t = T$ 到 $t = 0$ 反向求解 ODE 得到：

$$\frac{d\mathbf{z}}{dt} = \mathbf{v}_\phi(\mathbf{z}(t), t)$$

终端条件为 $\mathbf{z}(T) = \mathbf{x}$. 对标准分布而言，先验项 $\log p_{\text{prior}}(\mathbf{z}(0))$ 可直接计算. 这使神经常微分方程中基于精确似然的训练和评估成为可能.

基于梯度的优化. 最大化 $\mathcal{L}_{\text{NODE}}$ 需要通过 ODE 求解器进行反向传播. 伴随灵敏度方法 (Pontryagin, 2018; Chen et al., 2018) 通过辅助 ODE 计算梯度，内存复杂度为 $\mathcal{O}(1)$ ；但由于每一步都需进行数值积分，NODE 的训练仍然代价高昂.

利用 NODE 进行推断. 利用训练好的模型 $\mathbf{v}_{\phi^\times}$ 采样时，先抽取 $\mathbf{x}(0) \sim p_{\text{prior}}$ ，再向前积分（借助数值求解器）：

$$\mathbf{x}(T) = \mathbf{x}(0) + \int_0^T \mathbf{v}_{\phi^\times}(\mathbf{x}(t), t) dt.$$

终端状态 $\mathbf{x}(T)$ 近似为来自 p_{data} 的样本.

此外，对于任意向量场 $\mathbf{F}$ ，以下恒等式成立：

$$\text{Tr} \left(\frac{\partial \mathbf{F}}{\partial \mathbf{z}(t)} \right) = \nabla_{\mathbf{z}} \cdot \mathbf{F}.$$

因此，可使用 Hutchinson 估计器 (Hutchinson, 1989) 等随机迹估计器高效估计散度，使高维情形下的精确似然计算更易处理.

5.2 流匹配框架

得分 SDE (章 4) 和 NODE (节 5.1) 提供了生成建模的另一种视角: 学习随机或确定性的连续时间流, 将来自简单高斯先验的样本 $\epsilon \sim p_{\text{prior}}$ 输运为来自 p_{data} 、类似数据的样本.

流匹配 (FM) 框架 (Lipman et al., 2022; Lipman et al., 2024; Tong et al., 2024) 建立在这一思想之上, 并将其推广为学习两个任意固定端点分布之间的流: 源分布 p_{src} 与目标分布 p_{tgt} , 假定二者都易于采样. 在这一更一般的设置下, 生成任务成为一个特例, 其中 p_{src} 为高斯先验, p_{tgt} 为数据分布.

本节采用 FM 的视角³, 强调其核心原理: 学习时变向量场 $\mathbf{v}_t(\mathbf{x}_t)$, 使其对应的 ODE 流与预先定义的概率路径 (probability path) $\{p_t\}_{t \in [0,1]}$ 匹配, 并满足边界条件

$$p_0 = p_{\text{src}}, \quad p_1 = p_{\text{tgt}}.$$

当 p_{src} 为高斯分布时, 我们将这一设置称为高斯流匹配. 与经典扩散模型相比, FM 仅使用端点样本, 便可对广泛的输运问题进行高效、无需模拟的训练.

5.2.1 从基于得分的方法得到的启示

我们用一种略有不同但等价的表述重新考察得分 SDE 框架 (章 4), 以提取推动 FM 方法的关键见解. 这一分析揭示了扩散模型如何隐式学习概率流, 并引出了更直接的表述.

步骤 1: 定义条件路径及其边缘密度. 扩散模型指定一个连续时间密度族 $\{p_t\}_{t \in [0,1]}$, 将作为源分布的 $t = 1$ 时的简单先验 p_{prior} (例如高斯分布) 输运到 $t = 0$ 时的目标数据分布 p_{data} :

$$p_1(\mathbf{x}_1) = p_{\text{prior}}(\mathbf{x}_1), \quad p_0(\mathbf{x}_0) = p_{\text{data}}(\mathbf{x}_0).$$

这条路径通过前向条件分布隐式定义:

$$p_t(\mathbf{x}_t | \mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t; \alpha_t \mathbf{x}_0, \sigma_t^2 \mathbf{I}), \quad \mathbf{x}_0 \sim p_{\text{data}} \quad (5.2.1)$$

它诱导出边缘密度

$$p_t(\mathbf{x}_t) := \int p_t(\mathbf{x}_t | \mathbf{x}_0) p_{\text{data}}(\mathbf{x}_0) d\mathbf{x}_0.$$

条件高斯分布不断增大的方差 σ_t^2 驱动 p_t 向高斯先验演化.

³若干相关方法共有利用连续时间流在端点分布之间输运的核心思想, 只是在表述上略有不同. 这些方法包括流匹配 (FM) (Lipman et al., 2022; Neklyudov et al., 2023)、整流 (RF) (Liu, 2022; Heitz, Belcour, and Chambon, 2023) 以及随机插值 (Albergo, Boffi, and Vanden-Eijnden, 2023; Albergo and Vanden-Eijnden, 2023; Ma et al., 2024). 这里, 我们用 FM 术语作统一表述.




图 5.4: **条件转移分布的示意图**. $p_t(\mathbf{x}_t|\mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t; \alpha_t \mathbf{x}_0, \sigma_t^2 \mathbf{I})$, 定义了一条 (高斯) 条件概率路径, 从数据样本 $\mathbf{x}_0 \sim p_{\text{data}}$ (左) 通向高斯先验 p_{prior} (右) .

步骤 2: 速度场. 边缘密度 p_t 的时间演化由从 Fokker–Planck 方程推导出的速度场 $\mathbf{v}_t: \mathbb{R}^D \rightarrow \mathbb{R}^D$ 支配:

$$\mathbf{v}_t(\mathbf{x}) := f(t)\mathbf{x} - \frac{1}{2}g^2(t)\nabla_{\mathbf{x}} \log p_t(\mathbf{x}), \quad (5.2.2)$$

这一速度场通过 PF-ODE 定义确定性的粒子流:

$$\frac{d\mathbf{x}(t)}{dt} = \underbrace{f(t)\mathbf{x}(t) - \frac{1}{2}g^2(t)\nabla_{\mathbf{x}} \log p_t(\mathbf{x}(t))}_{\mathbf{v}_t(\mathbf{x}(t))}.$$

此 ODE 将初始随机变量 $\mathbf{x}(0) \sim p_{\text{data}}$ 沿时间向前输运, 或将 $\mathbf{x}(1) \sim p_{\text{prior}}$ 沿时间向后输运, 使 $\mathbf{x}(t)$ 随时间演化的边缘密度在每个 $t \in [0, 1]$ 都与 p_t 匹配 (见下文的“基本规则”).

标量函数 $f(t)$ 与 $g(t)$ 由相应前向 SDE 的系数确定, 等价地, 也由条件路径中定义的高斯核参数 α_t 与 σ_t 确定 (见引理 4.4.1) .

步骤 3: 通过条件化策略学习. 目标是使用神经网络 $\mathbf{s}_\phi(\mathbf{x}_t, t)$ 近似理想速度场 $\mathbf{v}_t(\mathbf{x}_t)$, 通过以下期望平方误差进行训练:

$$\mathcal{L}_{\text{SM}}(\phi) = \mathbb{E}_{t \sim \mathcal{U}[0,1], \mathbf{x}_t \sim p_t} [\|\mathbf{s}_\phi(\mathbf{x}_t, t) - \nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t)\|^2].$$

由于边缘得分 $\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t)$ 不可直接获得, 我们利用可处理的条件分布来定义条件速度:

$$\mathbf{v}_t(\mathbf{x}_t|\mathbf{x}_0) := f(t)\mathbf{x}_t - \frac{1}{2}g^2(t)\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t|\mathbf{x}_0).$$

根据全期望公式, 边缘得分可恢复为

$$\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t) = \mathbb{E}_{\mathbf{x}_0 \sim p(\cdot|\mathbf{x}_t)} [\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t|\mathbf{x}_0)]. \quad (5.2.3)$$




图 5.5: **扩散中的条件视角与边缘视角的示意图**. (本图受 Lipman et al. (2024) 启发.) (1) 条件高斯路径 $p_t(\cdot|\mathbf{x}_0)$, 展示了从固定的 $\mathbf{x}_0$ 向先验扩展的密度. (2) 条件速度 $\mathbf{v}_t(\mathbf{x}_t|\mathbf{x}_0) = f(t)\mathbf{x}_t - \frac{1}{2}g^2(t)\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t|\mathbf{x}_0)$. (3) 边缘密度 p_t , 将数据分布 p_{data} (橙色) 输运至先验 p_{prior} (灰色). (4) 边缘速度 $\mathbf{v}_t(\mathbf{x}_t) = f(t)\mathbf{x}_t - \frac{1}{2}g^2(t)\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t)$, 通过平均从 $\mathbf{x}_t$ 指向多个可能起点的条件方向 (虚线) 得到, 产生红色箭头. 在采用单侧条件化 $\mathbf{z} = \mathbf{x}_0$ 的 FM 框架中, 相同示意图也适用于 $\mathbf{v}_t(\mathbf{x}_t|\mathbf{x}_0)$ 和 $\mathbf{v}_t(\mathbf{x}_t)$, 无需将它们显式写成得分 $\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t|\mathbf{x}_0)$ 或 $\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t)$ 的形式.

这为如下替代训练目标提供了依据:

$$\mathcal{L}_{\text{SM}}(\phi) = \underbrace{\mathbb{E}_{t, \mathbf{x}_0 \sim p_{\text{data}}, \mathbf{x}_t \sim p_t(\cdot|\mathbf{x}_0)} [\|\mathbf{s}_\phi(\mathbf{x}_t, t) - \nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t|\mathbf{x}_0)\|^2]}_{\mathcal{L}_{\text{DSM}}(\phi)} + C,$$

其中 C 是与 ϕ 无关的常数. 最小化解 $\mathbf{s}^*(\mathbf{x}_t, t)$ 满足

$$\mathbf{s}^*(\mathbf{x}_t, t) = \mathbb{E}_{\mathbf{x}_0 \sim p(\cdot|\mathbf{x}_t)} [\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t|\mathbf{x}_0)] = \nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t),$$

其中第二个等号由式 (5.2.3) 得到, 从而验证了条件训练目标的有效性.

基本规则: Fokker-Planck 方程. 边缘密度 p_t 根据 Fokker-Planck 方程演化:

$$\frac{\partial p_t(\mathbf{x})}{\partial t} + \nabla \cdot \left(\underbrace{\left(f(t)\mathbf{x} - \frac{1}{2}g^2(t)\nabla_{\mathbf{x}} \log p_t(\mathbf{x}) \right)}_{\mathbf{v}_t(\mathbf{x})} p_t(\mathbf{x}) \right) = 0.$$

这个偏微分方程保证 PF-ODE 给出的密度与前向 SDE 的边缘分布匹配. 为理解这一点, 回顾式 (4.1.9) 中定义的 PF-ODE 的流映射 $\Psi_{s \rightarrow t}(\mathbf{x}_s)$, 它将时刻 s 的初始状态 $\mathbf{x}_s$ 直接输运到时刻 t 的状态. 从 $\mathbf{x}_1 \sim p_{\text{prior}}$ 出发, 将 PF-ODE 从 $t = 1$ 反向运行到 $t = 0$, 通过推前公式得到时变密度:

$$p_t^{\text{rev}}(\mathbf{x}) = \int \delta(\mathbf{x} - \Psi_{1 \rightarrow t}(\mathbf{x}_1)) p_{\text{prior}}(\mathbf{x}_1) d\mathbf{x}_1. \quad (5.2.4)$$

Fokker-Planck 方程保证所诱导的密度路径与同一个演化密度重合:

$$p_t^{\text{rev}} = p_t. \quad (5.2.5)$$

特别地, 这意味着 $p_0^{\text{rev}} = p_0 = p_{\text{data}}$, 从而在时刻 $t = 0$ 恢复数据分布. 由于 ODE 的解映射是双向的, 我们也可类似地考虑从 $\mathbf{x}_0 \sim p_{\text{data}}$ 初始化并沿时间向前求解 ODE, 以进行平行的分析.

5.2.2 流匹配框架

节 5.2.1 中的分析揭示，扩散模型通过学习在分布之间输运并满足边界条件的速度场——具体而言，是得分——取得成功。式 (5.2.1) 中方差 σ_t^2 递增的高斯条件路径设计，隐式地将一个端点固定为高斯先验，同时使条件密度可在整个空间中定义，从而能够计算基于得分的梯度。

本小节基于这一见解介绍 FM 框架（图 5.5 中的示意图同样适用于 FM 框架），并将其扩展为学习在两个任意分布之间输运样本的连续流，这两个分布为 p_{src} 与 p_{tgt} 。

步骤 1：定义条件路径及其边缘密度。 考虑 $\mathbb{R}^D$ 上任意的源概率分布与目标概率分布 p_{src} 和 p_{tgt} 。我们令⁴

$$p_0(\mathbf{x}) = p_{\text{src}}(\mathbf{x}), \quad p_1(\mathbf{x}) = p_{\text{tgt}}(\mathbf{x}). \quad (5.2.6)$$

FM 隐式地定义在这些端点之间插值的连续中间密度族 $\{p_t\}_{t \in [0,1]}$ 。每个边缘密度 p_t 都通过从已知分布 $\pi(\mathbf{z})$ 抽取的潜变量 $\mathbf{z}$ 和条件分布 $p_t(\mathbf{x}_t|\mathbf{z})$ 表示：

$$p_t(\mathbf{x}_t) = \int p_t(\mathbf{x}_t|\mathbf{z})\pi(\mathbf{z}) \, d\mathbf{z}, \quad (5.2.7)$$

其中选择 $(\pi(\mathbf{z}), \{p_t(\cdot|\mathbf{z})\})$ ，使其满足式 (5.2.6) 中的边界条件。

需要指出的是，通常边缘密度 p_t 不可处理，因为它们需要对 $\pi(\mathbf{z})$ 积分，而 $\pi(\mathbf{z})$ 和条件分布 $p_t(\mathbf{x}_t|\mathbf{z})$ 都可能很复杂。尽管如此，以潜变量 $\mathbf{z}$ 为条件，使 FM 能够灵活地建模比节 5.2.1 所讨论的路径更广泛的一类插值路径。 $\mathbf{z}$ 的常见选择包括：

- **双侧条件化：** $\mathbf{z} = (\mathbf{x}_0, \mathbf{x}_1) \sim p_{\text{src}}(\mathbf{x}_0)p_{\text{tgt}}(\mathbf{x}_1)$ ，其中 π 耦合源分布与目标分布。这使 FM 能够定义任意分布之间的输运。
- **单侧条件化：** $\mathbf{z} = \mathbf{x}_0$ 或 $\mathbf{z} = \mathbf{x}_1$ 。尤其当源分布选为高斯分布时，它恢复了类似扩散的设置。

在所有情形中，条件分布 $p_t(\mathbf{x}_t|\mathbf{z})$ 都应具有可处理的闭式表达式。我们始终采用这一假定，并在节 5.3.2 中给出具体构造，示意图见 5.6。

步骤 2：速度场。 在标准扩散模型或高斯 FM 中，中间密度 $\{p_t\}_{t \in [0,1]}$ 的构造将一个端点设为标准高斯分布。在此设置下，速度场 $\mathbf{v}_t$ 被唯一确定，并具有与得分有关的闭式表达式（见式 (5.2.2)）。

相比之下，一般 FM 在一般的源分布和目标分布 p_{src} 与 p_{tgt} 之间插值，此时速度场不再唯一确定（下文将作解释）。

目标是找到速度场 $\mathbf{v}_t(\mathbf{x})$ ，使其诱导的、能够逐样本变换的 ODE，

$$\frac{d\mathbf{x}(t)}{dt} = \mathbf{v}_t(\mathbf{x}(t)), \quad t \in [0, 1],$$

⁴为与 FM 文献中的标准记号一致，相对于前面的各节，我们反转时间轴： $t = 0$ 对应于源分布， $t = 1$ 对应于目标分布。

产生的 $\mathbf{x}(t)$ 的边缘分布在每个时刻 t 都与 p_t 匹配，无论是从 $\mathbf{x}(0) \sim p_{\text{src}}$ 向前积分，还是从 $\mathbf{x}(1) \sim p_{\text{tgt}}$ 向后积分（更形式化的讨论见节 5.2.4）。

这一要求由连续性方程⁵刻画：

$$\frac{\partial p_t(\mathbf{x})}{\partial t} + \nabla \cdot (\mathbf{v}_t(\mathbf{x})p_t(\mathbf{x})) = 0. \quad (5.2.8)$$

任意满足式 (5.2.8) 的速度场 $\mathbf{v}_t$ 都保证 ODE 流以精确遵循预先指定的 p_t 的方式输运样本（详细讨论见节 5.2.4）。因此，求解 ODE 可实现从 p_{src} 到 p_{tgt} 的输运，同时匹配所有中间分布。

直观地说，许多不同的流可诱导相同的边缘分布演化。这是因为式 (5.2.8) 是标量方程，而 $\mathbf{v}_t$ 是 $\mathbb{R}^D$ 中的向量场，因此该方程具有无穷多个解。例如，若 $\mathbf{v}_t$ 是该方程的解，则对于任意无散度向量场，以下向量场也是解：

$$\mathbf{v}_t + \frac{1}{p_t} \tilde{\mathbf{v}}_t,$$

其中 $\tilde{\mathbf{v}}_t$ 无散度，即 $\nabla \cdot \tilde{\mathbf{v}}_t = 0$ 。因此，FM 寻找满足式 (5.2.8) 的某个速度场 $\mathbf{v}_t$ ，使样本能够沿路径 $\{p_t\}$ 连续输运。然而，对于任意分布， p_t 和 $\mathbf{v}_t$ 通常没有闭式表达式。作为具体例子，在节 5.3.1 中，我们考虑高斯到高斯的桥，此时这两个量都可以显式计算。

步骤 3：通过条件化策略学习。 FM 训练的目标是使用神经网络 $\mathbf{v}_\phi$ 近似理想速度场 $\mathbf{v}_t$ ，即最小化期望平方误差：

$$\mathcal{L}_{\text{FM}}(\phi) = \mathbb{E}_{t, \mathbf{x}_t \sim p_t} [\|\mathbf{v}_\phi(\mathbf{x}_t, t) - \mathbf{v}_t(\mathbf{x}_t)\|^2].$$

我们将这种神经网络参数化称为 $\mathbf{v}$ 预测（速度预测），其目的是直接学习 ODE 的漂移项。

与节 5.2.1 一样，理想速度 $\mathbf{v}_t(\mathbf{x})$ 通常不可处理。为此，我们引入潜变量 $\mathbf{z} \sim \pi(\mathbf{z})$ ，并通过构造定义条件速度场 $\mathbf{v}_t(\mathbf{x}|\mathbf{z})$ 。这使我们能够借助全期望公式改写损失⁶：

$$\mathcal{L}_{\text{FM}}(\phi) = \underbrace{\mathbb{E}_{t, \mathbf{z} \sim \pi(\mathbf{z}), \mathbf{x}_t \sim p_t(\cdot|\mathbf{z})} [\|\mathbf{v}_\phi(\mathbf{x}_t, t) - \mathbf{v}_t(\mathbf{x}_t|\mathbf{z})\|^2]}_{\mathcal{L}_{\text{CFM}}(\phi)} + C, \quad (5.2.9)$$

其中 C 是与 ϕ 无关的常数。主项 $\mathcal{L}_{\text{CFM}}$ 称为条件流匹配（conditional flow matching）。

也就是说，最小化 $\mathcal{L}_{\text{FM}}(\phi)$ 等价于最小化 $\mathcal{L}_{\text{CFM}}(\phi)$ ，后者的表述更易处理。要使 $\mathcal{L}_{\text{CFM}}(\phi)$ 能够用于可处理、无需模拟的训练，必须满足两个要求：

⁵即 Fokker-Planck 方程去掉扩散项后的确定性对应物。

⁶这遵循标准的分部积分论证，与式 (3.3.3) 的推导相同。同样，式 (5.2.11) 也是在得分匹配框架中使用类似方法推导的。

1. 从条件概率路径 $p_t(\mathbf{x}_t|\mathbf{z})$ 采样应当简单直接（无需模拟）。
2. 作为回归目标的条件速度 $\mathbf{v}_t(\mathbf{x}_t|\mathbf{z})$ 必须具有简单的闭式表达式。

我们将在节 5.3.2 中给出满足这些条件的显式构造。这一条件视角使训练成为可能：模型学习可处理的条件场 $\mathbf{v}_t(\cdot|\mathbf{z})$ ，而非不可处理的无条件速度场 $\mathbf{v}_t(\cdot)$ ，这与去噪得分匹配直接对应。

尽管与给定 p_t 一致的无条件速度场可能有无穷多个，其中一个仍可通过将条件速度场边缘化来恢复：

$$\mathbf{v}_t(\mathbf{x}_t) := \mathbb{E}_{\mathbf{z} \sim p(\cdot|\mathbf{x}_t)} [\mathbf{v}_t(\mathbf{x}_t|\mathbf{z})], \quad (5.2.10)$$

其中期望关于 $p(\mathbf{z}|\mathbf{x}_t)$ 计算。可以证明，式 (5.2.9) 中的条件流匹配目标的最小化解 $\mathbf{v}^*$ 恢复了这一边缘速度：

$$\mathbf{v}^*(\mathbf{x}_t, t) = \mathbf{v}_t(\mathbf{x}_t). \quad (5.2.11)$$

因此，学习匹配条件速度场 $\mathbf{v}_t(\cdot|\mathbf{z})$ ，就足以恢复一个有效的无条件速度场。

我们将以上讨论总结如下：

定理 5.2.1: $\mathcal{L}_{\text{FM}}$ 与 $\mathcal{L}_{\text{CFM}}$ 的等价性

以下等式成立：

$$\mathcal{L}_{\text{FM}}(\phi) = \mathcal{L}_{\text{CFM}}(\phi) + C,$$

其中 C 是与参数 ϕ 无关的常数。此外，这两个损失的最小化解 $\mathbf{v}^*$ 满足

$$\mathbf{v}^*(\mathbf{x}_t, t) = \mathbf{v}_t(\mathbf{x}_t), \quad \text{对几乎处处的 } \mathbf{x}_t \sim p_t,$$

其中 $\mathbf{v}_t(\mathbf{x}_t)$ 在式 (5.2.10) 中定义。

定理的证明。

最小化解的论证和推导与命题 4.2.1 中得分匹配情形的推理完全相同。

这是条件化技巧第三次产生可处理的训练目标。值得注意的是，变分方法、基于得分的方法和基于流的方法都体现了同一个基本原理。

注.

取 $\pi = p_{\text{data}}$ ，可应用 Bayes 公式：

$$p(\mathbf{x}_0|\mathbf{x}_t) = \frac{p_t(\mathbf{x}_t|\mathbf{x}_0)p_{\text{data}}(\mathbf{x}_0)}{p_t(\mathbf{x}_t)},$$

在基于得分的模型中，也出现了与式 (5.2.10) 类似的分解：

$$\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t) = \mathbb{E}_{\mathbf{x}_0 \sim p(\cdot|\mathbf{x}_t)} [\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t|\mathbf{x}_0)]$$

$$= \mathbb{E}_{\mathbf{x}_0 \sim p_{\text{data}}} \left[\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t | \mathbf{x}_0) \cdot \frac{p_t(\mathbf{x}_t | \mathbf{x}_0)}{p_t(\mathbf{x}_t)} \right],$$

这与式 (5.2.10) 中的边缘化策略相对应.

在节 5.2.1 中, 必须显式指定条件密度 $p_t(\mathbf{x}_t | \mathbf{z})$ 和条件速度场 $\mathbf{v}_t(\mathbf{x}_t | \mathbf{z})$, 其中 $p_t(\mathbf{x}_t | \mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t; \alpha_t \mathbf{x}_0, \sigma_t^2 \mathbf{I})$, $\mathbf{v}_t(\mathbf{x}_t | \mathbf{x}_0) = f(t)\mathbf{x}_t - \frac{1}{2}g^2(t)\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t | \mathbf{x}_0)$; 一般的条件流匹配框架也需要这两个组成部分. 然而, 在这一一般情形中, 我们还没有构造条件密度 $p_t(\mathbf{x}_t | \mathbf{z})$ 或条件速度场 $\mathbf{v}_t(\mathbf{x}_t | \mathbf{z})$. 下一节将介绍这些组成部分的若干常见实例.

5.2.3 扩散模型、一般流匹配与 NODE 的比较

扩散模型与一般流匹配的比较. 节 5.2.1 中的见解引出了保留相同基本原理的扩展 FM 框架. 为突出它们的相似性, 我们在表 5.1 中作了总结.

表 5.1: 扩散模型 (或高斯 FM) 与一般 FM 框架的比较. 这里, 一般 FM 框架指双侧条件化的设置, 其中 $\mathbf{x}_0 \sim p_{\text{src}}$ 和 $\mathbf{x}_1 \sim p_{\text{tgt}}$ 相互独立地采样.

方面	扩散模型	一般 FM
源分布 p_{src}	高斯先验	任意
目标分布 p_{tgt}	数据分布	任意
潜变量分布 $\pi(\mathbf{z})$	p_{data}	见节 5.3.2
条件分布 $p_t(\mathbf{x}_t \mathbf{z})$	$\mathcal{N}(\mathbf{x}_t; \alpha_t \mathbf{x}_0, \sigma_t^2 \mathbf{I})$	见节 5.3.2
边缘分布 $p_t(\mathbf{x}_t)$	$\int p_t(\mathbf{x}_t \mathbf{x}_0) p_{\text{data}}(\mathbf{x}_0) d\mathbf{x}_0$	$\int p_t(\mathbf{x}_t \mathbf{z}) \pi(\mathbf{z}) d\mathbf{z}$
条件速度 $\mathbf{v}_t(\mathbf{x} \mathbf{z})$	$f(t)\mathbf{x} - \frac{1}{2}g^2(t)\nabla \log p_t(\mathbf{x} \mathbf{x}_0)$	见节 5.3.2
边缘速度 $\mathbf{v}_t(\mathbf{x})$	$f(t)\mathbf{x} - \frac{1}{2}g^2(t)\nabla \log p_t(\mathbf{x})$	见式 (5.2.10)
学习目标	$\mathcal{L}_{\text{SM}} = \mathcal{L}_{\text{DSM}} + C$	$\mathcal{L}_{\text{FM}} = \mathcal{L}_{\text{CFM}} + C$
基本规则	Fokker–Planck 方程 / 连续性方程	

需要指出的是, 高斯 FM 本质上等价于标准扩散模型 (更多讨论见章 6), 因此除非特别说明, 我们不区分二者.

与 NODE 的联系. FM 可视为节 5.1.2 中介绍的 NODE 的无需模拟的替代方案. CNF 在最大似然训练中需要求解 ODE, 计算量很大; FM 则通过简单的回归损失直接回归预先指定的速度场, 从而绕过这一计算. 关键见解是, 当连接源分布与目标分布的边缘密度路径固定时, 训练过程中就不再需要精确模拟.

5.2.4 (选读) 基本规则

连续性方程：质量守恒准则. 与节 5.2.1 中的 PF-ODE 和 Fokker–Planck 分析类似，我们现在给出一个准则，用来检验 ODE 流所诱导的密度路径是否与预先指定的路径 $\{p_t\}_{t \in [0,1]}$ 一致.

考虑描述粒子在时变速度场 $\mathbf{v}_t$ 下流动的 ODE：

$$\frac{d\mathbf{x}(t)}{dt} = \mathbf{v}_t(\mathbf{x}(t)).$$

与式 (5.2.4) 一样，这个 ODE 对任意 $s, t \in [0, 1]$ 定义流映射 $\Psi_{s \rightarrow t}(\mathbf{x}_0)$ ，特别地，它将时刻 0 的初始点 $\mathbf{x}_0 \sim p_{\text{src}}$ 输运到时刻 t 的状态. 时刻 t 诱导出的分布由推前给出：

$$p_t^{\text{fwd}}(\mathbf{x}) = \int \delta(\mathbf{x} - \Psi_{0 \rightarrow t}(\mathbf{x}_0)) p_{\text{src}}(\mathbf{x}_0) d\mathbf{x}_0 =: \Psi_{0 \rightarrow t} \# p_{\text{src}}, \quad (5.2.12)$$

因此，只要 $\mathbf{x}_0 \sim p_{\text{src}}$ ，就有 $\Psi_{0 \rightarrow t}(\mathbf{x}_0) \sim p_t^{\text{fwd}}$. 类似地，可从 $\mathbf{x}_1 \sim p_{\text{tgt}}$ 出发，通过 $\Psi_{1 \rightarrow 0}(\mathbf{x}_1)$ 反向输运至 p_{src} .

假设给定预先指定的密度路径 $\{p_t\}_{t \in [0,1]}$ ，并构造速度场 $\{\mathbf{v}_t\}_{t \in [0,1]}$ 来定义粒子流. 这自然引出如下问题：

问题 5.2.1. 在什么条件下，流诱导的密度 p_t^{fwd} 对所有 $t \in [0, 1]$ 都与目标密度 p_t 精确匹配？

一旦这两种密度演化一致，我们就可以求解 ODE，利用 ODE 流在 p_{src} 与 p_{tgt} 之间灵活输运样本.

与式 (5.2.5) 一样，验证这种一致性的一个有理论依据的方法，是使用刻画随时间演化的密度中质量守恒的连续性方程：

定理 5.2.2: 质量守恒准则

流诱导的密度 p_t^{fwd} 对所有 $t \in [0, 1]$ 都等于预先指定的路径 p_t ，即

$$p_t^{\text{fwd}} = p_t, \quad \text{对所有 } t \in [0, 1],$$

当且仅当二元组 $(p_t, \mathbf{v}_t)$ 满足连续性方程：

$$\partial_t p_t(\mathbf{x}) + \nabla_{\mathbf{x}} \cdot (p_t(\mathbf{x}) \mathbf{v}_t(\mathbf{x})) = 0,$$

对所有 $t \in [0, 1]$ 和 $\mathbf{x}$ 均成立.

定理的证明.

节 D.3.2 提供了一种概念性的推导，而更严格的论述见 (Villani et al., 2008) (参见“质量守恒公式”).

从条件路径到边缘路径. 如节 5.2.2 所示, 我们首先定义条件概率路径 $p_t(\cdot|\mathbf{z})$ 和相应的条件速度场 $\mathbf{v}_t(\cdot|\mathbf{z})$. 然后, 通过下式构造边缘速度场:

$$\mathbf{v}_t(\mathbf{x}) = \int \mathbf{v}_t(\mathbf{x}|\mathbf{z}) \frac{p_t(\mathbf{x}|\mathbf{z})\pi(\mathbf{z})}{p_t(\mathbf{x})} d\mathbf{z},$$

这与式 (5.2.10) 一致. 然而, 仍需保证所得边缘速度 $\mathbf{v}_t$ 诱导的 ODE 流具有与预先指定的 p_t 一致的密度路径. 幸运的是, 这一检验可完全在条件层面进行: 若每个条件速度场 $\mathbf{v}_t(\cdot|\mathbf{z})$ 都诱导条件密度路径 $p_t(\cdot|\mathbf{z})$, 则所得边缘速度 $\mathbf{v}_t$ 也诱导正确的边缘路径. 形式化表述如下:

命题 5.2.3: 边缘向量场生成给定的边缘密度

若条件速度场 $\mathbf{v}_t(\cdot|\mathbf{z})$ 诱导出与 $p_t(\cdot|\mathbf{z})$ 匹配的条件密度路径 (从 $p_0(\cdot|\mathbf{z})$ 出发), 则式 (5.2.10) 中定义的边缘速度场 $\mathbf{v}_t(\cdot)$ 从 $p_0(\cdot)$ 出发, 诱导出与 $p_t(\cdot)$ 一致的边缘密度路径.

命题的证明.

验证二元组 $(p_t, \mathbf{v}_t)$ 满足连续性方程即可得到这一结果. 为直观解释为什么边缘化速度场具有式 (5.2.10) 中的形式, 我们以反向方式展开论证. 由于条件速度场 $\mathbf{v}_t(\cdot|\mathbf{z})$ 对 $\mathbf{z} \sim \pi$ 诱导出与条件密度 $p_t(\cdot|\mathbf{z})$ 匹配的密度路径, 每个条件二元组都满足连续性方程:

$$\frac{d}{dt}p_t(\mathbf{x}|\mathbf{z}) = -\nabla_{\mathbf{x}} \cdot (\mathbf{v}_t(\mathbf{x}|\mathbf{z})p_t(\mathbf{x}|\mathbf{z})). \quad (5.2.13)$$

我们希望找到速度场 $\mathbf{v}_t(\cdot)$, 使其诱导的密度与边缘密度 p_t 一致, 即满足

$$\frac{d}{dt}p_t(\mathbf{x}) = -\nabla_{\mathbf{x}} \cdot (\mathbf{v}_t(\mathbf{x})p_t(\mathbf{x})). \quad (5.2.14)$$

从式 (5.2.7) 中 p_t 的定义出发,

$$\begin{aligned} \frac{d}{dt}p_t(\mathbf{x}) &= \int \frac{d}{dt}p_t(\mathbf{x}|\mathbf{z})\pi(\mathbf{z}) d\mathbf{z} \\ &= -\int \nabla_{\mathbf{x}} \cdot (\mathbf{v}_t(\mathbf{x}|\mathbf{z})p_t(\mathbf{x}|\mathbf{z}))\pi(\mathbf{z}) d\mathbf{z} \\ &= -\nabla_{\mathbf{x}} \cdot \left(\int \mathbf{v}_t(\mathbf{x}|\mathbf{z})p_t(\mathbf{x}|\mathbf{z})\pi(\mathbf{z}) d\mathbf{z} \right), \end{aligned}$$

其中第二个等号来自应用式 (5.2.13). 将其与式 (5.2.14) 的右端比较可知, 在相差一个无散度项的意义下,

$$\mathbf{v}_t(\mathbf{x})p_t(\mathbf{x}) = \int \mathbf{v}_t(\mathbf{x}|\mathbf{z})p_t(\mathbf{x}|\mathbf{z})\pi(\mathbf{z}) d\mathbf{z}.$$

因此, 可以定义

$$\mathbf{v}_t(\mathbf{x}) := \int \mathbf{v}_t(\mathbf{x}|\mathbf{z}) \frac{p_t(\mathbf{x}|\mathbf{z})}{p_t(\mathbf{x})} \pi(\mathbf{z}) d\mathbf{z},$$

这恰好是式 (5.2.10) 中的形式. 这一定理的证明本质上沿相反方向运用上述论证. ■

这一联系使我们能够将可能不可处理的边缘速度场构造，化为定义更简单的条件场 $\mathbf{v}_t(\cdot|\mathbf{z})$ ；后者通过构造而更易处理.

5.3 构造分布之间的概率路径与速度

流匹配的本质在于将源分布逐渐变换为目标分布. 为引导这一变换, 需要两个关键要素: 概率路径 p_t 给出每个时刻 t 正在演化的分布的快照, 而速度场 $\mathbf{v}_t$ 描述各个粒子如何沿路径移动. 这两个对象并不独立; 它们通过连续性方程联系起来, 该方程保证粒子动力学与分布的演化一致. 因此, 学习任务归结为寻找如实驱动这一过程的速度场 $\mathbf{v}_t$. 但困难在于, 对于一般且复杂的分布, 真实边缘速度 $\mathbf{v}_t$ 是未知的, 因而我们面对的是一个不可处理、无法直接获得的目标.

条件流匹配的核心思想, 是构造一个人工设计但可处理的过程, 以应对真实边缘速度的不可处理性. 为此, 我们引入条件变量 $\mathbf{z}$, 并设计条件速度 $\mathbf{v}_t(\mathbf{x}_t|\mathbf{z})$ 和 / 或条件路径 $p_t(\mathbf{x}_t|\mathbf{z})$, 有意使其保持简单.

由于这些条件对象具有已知闭式形式, 它们可以作为模型回归的替代目标. 只要满足两个实际要求, 就得到有效的训练损失 $\mathcal{L}_{\text{CFM}}$: 一是能够从 $p_t(\cdot|\mathbf{z})$ 高效采样, 二是相应速度 $\mathbf{v}_t(\cdot|\mathbf{z})$ 具有闭式表达式.

我们应当如何设计性质良好的条件过程? 为寻找启发, 我们转向一个已经充分理解的情形: 高斯到高斯的桥 (节 5.3.1). 这个例子突出了两种自然的设计策略: 在每个时刻 t 采用高斯概率路径, 或指定仿射速度场; 二者在解析上都可处理.

在这一见解的指引下, 我们推广到一般端点分布, 采用两种互补视角 (另见节 B.1.2) 来构造条件路径与速度:

- **先构造条件概率路径 (Euler 视角)**. 从条件概率路径 $p_t(\cdot|\mathbf{z})$ 出发, 推导相应的条件速度场.
- **先构造条件流 (Lagrange 视角)**. 从通常为仿射形式的条件流 $\Psi_{0 \rightarrow t}(\cdot|\mathbf{z})$ 出发, 沿轨迹对时间求导, 推导条件速度场.

在节 5.3.2 中, 我们详细介绍第一种方法, 展示它与节 5.2.1 所讨论的扩散模型构造之间的紧密类比; 第二种方法则在节 5.3.3 中给出. 这两种视角共同提供了定义 $p_t(\mathbf{x}_t|\mathbf{z})$ 与 $\mathbf{v}_t(\mathbf{x}_t|\mathbf{z})$ 的实用框架, 使无需模拟的训练以及任意源分布与目标分布之间的流构造成为可能.

5.3.1 一个关键特例: 高斯到高斯的桥中的边缘密度 $p_t(\mathbf{x}_t)$ 与速度 $\mathbf{v}_t(\mathbf{x}_t)$

我们从高斯端点的情形出发, 此时可解析地计算边缘密度 $p_t(\mathbf{x}_t)$ 与速度场 $\mathbf{v}_t(\mathbf{x}_t)$. 这将作为构造一般条件密度 $p_t(\mathbf{x}_t|\mathbf{z}_t)$ 和速度场 $\mathbf{v}_t(\mathbf{x}_t|\mathbf{z}_t)$ 的模板.

当源分布与目标分布 p_{src} 和 p_{tgt} 都为高斯分布时, 速度场 $\mathbf{v}_t(\cdot)$ 具有闭式表达式. 考虑如下插值边缘密度路径:

$$p_t(\mathbf{x}_t) = \mathcal{N}(\mathbf{x}_t; \boldsymbol{\mu}(t), \sigma^2(t)\mathbf{I}), \quad (5.3.1)$$

其中均值 $\boldsymbol{\mu}(t)$ 与方差 $\sigma^2(t) > 0$ 随时间变化. 两个端点为

$$p_{\text{src}} = p_0 = \mathcal{N}(\mathbf{x}; \boldsymbol{\mu}(0), \sigma^2(0)\mathbf{I}), \quad p_{\text{tgt}} = p_1 = \mathcal{N}(\mathbf{x}; \boldsymbol{\mu}(1), \sigma^2(1)\mathbf{I}),$$

因此，路径 $\{p_t\}_{t \in [0,1]}$ 连接了这两个分布。

给定路径 $\{p_t\}_{t \in [0,1]}$ ，确实存在许多速度场，能够诱导 ODE 流 $\Psi_{0 \rightarrow t}(\mathbf{x})$ ，使 $\mathbf{x} \sim p_0$ 蕴含 $\Psi_{0 \rightarrow t}(\mathbf{x}) \sim p_t$ 。对这条高斯路径，一个特别简单的实现为⁷：

$$\Psi_{0 \rightarrow t}(\mathbf{x}) := \boldsymbol{\mu}(t) + \sigma(t) \left(\frac{\mathbf{x} - \boldsymbol{\mu}(0)}{\sigma(0)} \right). \quad (5.3.2)$$

对于定义的高斯路径 p_t （对所有 t 均为高斯分布），诱导式 (5.3.2) 中 ODE 流的速度场 $\mathbf{v}_t(\cdot)$ 可唯一地解析刻画如下 (Lipman et al., 2022)：

命题 5.3.1: 高斯密度路径的闭式速度场

设 p_t 为式 (5.3.1) 中的高斯路径。则对于已定义的 $\Psi_{0 \rightarrow t}$ ，生成式 (5.3.2) 中 ODE 流的速度场 $\mathbf{v}_t(\cdot)$ 是唯一的，且具有如下闭式表达式：

$$\mathbf{v}_t(\mathbf{x}) = \frac{\sigma'(t)}{\sigma(t)} (\mathbf{x} - \boldsymbol{\mu}(t)) + \boldsymbol{\mu}'(t).$$

命题的证明。

考虑初始条件为 $\mathbf{y}$ 的 ODE：

$$\frac{d}{dt} \Psi_{0 \rightarrow t}(\mathbf{y}) = \mathbf{v}_t(\Psi_{0 \rightarrow t}(\mathbf{y})).$$

由于 $\Psi_{0 \rightarrow t}$ 可逆（因为 $\sigma(t) > 0$ ），可令 $\mathbf{x} = \Psi_{0 \rightarrow t}(\mathbf{y})$ ，且 $\mathbf{y} = \Psi_{0 \rightarrow t}^{-1}(\mathbf{x}) = \Psi_{t \rightarrow 0}(\mathbf{x})$ ，从而得到

$$\Psi'_{0 \rightarrow t}(\Psi_{0 \rightarrow t}^{-1}(\mathbf{x})) = \mathbf{v}_t(\mathbf{x}).$$

对式 (5.3.2) 关于 t 求导，得到

$$\Psi'_{0 \rightarrow t}(\mathbf{x}) = \boldsymbol{\mu}'(t) + \sigma'(t) \left(\frac{\mathbf{x} - \boldsymbol{\mu}(0)}{\sigma(0)} \right).$$

求解 $\mathbf{y} = \Psi_{0 \rightarrow t}^{-1}(\mathbf{x})$ ，得到

$$\mathbf{y} = \boldsymbol{\mu}(0) + \sigma(0) \left(\frac{\mathbf{x} - \boldsymbol{\mu}(t)}{\sigma(t)} \right).$$

将其代入 $\Psi'_{0 \rightarrow t}(\mathbf{x})$ ，得到

$$\mathbf{v}_t(\mathbf{x}) = \frac{\sigma'(t)}{\sigma(t)} (\mathbf{x} - \boldsymbol{\mu}(t)) + \boldsymbol{\mu}'(t),$$

即所要证明的结果。

⁷在 (Lipman et al., 2022) 中，作者考虑 $\Psi_{0 \rightarrow t}(\mathbf{x}) = \boldsymbol{\mu}(t) + \sigma(t)\mathbf{x}$ ，这需要对 $\boldsymbol{\mu}(t)$ 和 $\sigma(t)$ 施加约束以保证边界条件。我们采用等价的归一化表述，从而避免这些约束。

需要指出的是，对于固定流映射 $\Psi_{0 \rightarrow t}$ （先构造流的视角），速度由下式唯一确定：

$$\mathbf{v}_t = \partial_t \Psi_{0 \rightarrow t} \circ \Psi_{0 \rightarrow t}^{-1}.$$

在这一构造下，二元组 $(p_t, \mathbf{v}_t)$ 自动满足连续性方程. 相反，对于给定密度路径 $t \mapsto p_t$ ，如果不固定 $\Psi_{0 \rightarrow t}$ （先构造概率路径的视角），速度场则不唯一.

这一区别精确地刻画了先构造流与先构造概率路径这两种视角之间的差异.

在以潜变量 $\mathbf{z}$ 为条件时，这一闭式刻画仍然成立. 下文将推广这一见解，构造条件高斯路径 $p_t(\cdot|\mathbf{z})$ ，并在一般边缘设置下推导相应的条件速度场 $\mathbf{v}_t(\cdot|\mathbf{z})$.

5.3.2 先构造条件概率路径的 $\mathbf{v}_t(\cdot|\mathbf{z})$ 与 $p_t(\cdot|\mathbf{z})$ 构造




图 5.6: 两类常见条件概率路径的示意图. 包括：(1) 双侧条件化，以具有一般端点分布的 $\mathbf{x}_0 \sim p_{\text{tgt}}$ 和 $\mathbf{x}_1 \sim p_{\text{src}}$ 为条件；(2) 单侧条件化，以 $\mathbf{x}_0 \sim p_{\text{tgt}}$ 或 $\mathbf{x}_1 \sim p_{\text{src}}$ 中的一端为条件.

我们旨在首先构造条件密度路径 $p_t(\cdot|\mathbf{z})$ ，再在关于 $\pi(\mathbf{z})$ 的条件化下推导相应的条件速度场 $\mathbf{v}_t(\cdot|\mathbf{z})$ （利用命题 5.3.1）. 根据 $\mathbf{z}$ 的选择，有两种自然情形：一是 $\mathbf{z} = (\mathbf{x}_0, \mathbf{x}_1)$ 的双侧条件化，二是 $\mathbf{z} = \mathbf{x}_0$ 或 $\mathbf{x}_1$ 的单侧条件化. 在任一种情形中，构造都必须匹配边界分布：

$$p_{\text{src}}(\mathbf{x}_0) = \int p_0(\mathbf{x}_0|\mathbf{z})\pi(\mathbf{z}) d\mathbf{z}, \quad p_{\text{tgt}}(\mathbf{x}_1) = \int p_1(\mathbf{x}_1|\mathbf{z})\pi(\mathbf{z}) d\mathbf{z}.$$

由于一旦指定具体构造，检验这些约束便很直接，我们在此不着重讨论检验步骤.

I. 双侧条件化 $\mathbf{z} = (\mathbf{x}_0, \mathbf{x}_1)$ ——“光束型”路径.

$\pi(\mathbf{z})$ 的选择. 考虑 $\mathbb{R}^D$ 上的一般分布 p_{src} 与 p_{tgt} . 令 $\mathbf{z} = (\mathbf{x}_0, \mathbf{x}_1)$ ，其中 $\mathbf{x}_0 \sim p_{\text{src}}$ 和 $\mathbf{x}_1 \sim p_{\text{tgt}}$ 相互独立，即

$$\pi(\mathbf{z}) = p_{\text{src}}(\mathbf{x}_0)p_{\text{tgt}}(\mathbf{x}_1).$$

条件路径 $p_t(\cdot|\mathbf{z})$ 的选择. 用具有固定方差 $\sigma > 0$ 的线性插值定义条件路径：

$$p_t(\mathbf{x}_t|\mathbf{z} = (\mathbf{x}_0, \mathbf{x}_1)) = \mathcal{N}(\mathbf{x}_t; a_t\mathbf{x}_0 + b_t\mathbf{x}_1, \sigma^2\mathbf{I}),$$

其中 a_t 和 b_t 是满足 $a_0 = 1, b_0 = 0$ 以及 $a_1 = 0, b_1 = 1$ 的时变函数. (Lipman et al., 2022; Liu, 2022) 建议的一种选择是 $a_t = 1 - t, b_t = t$. 在确定性情形 $\sigma = 0$ 下, 得到

$$p_t(\mathbf{x}_t|\mathbf{z}) = \delta(\mathbf{x}_t - [a_t\mathbf{x}_0 + b_t\mathbf{x}_1]),$$

它描述了从 $\mathbf{x}_0$ 到 $\mathbf{x}_1$ 的确定性插值路径.

推导出的条件速度 $\mathbf{v}_t(\cdot|\mathbf{z})$. 根据命题 5.3.1, 条件速度为

$$\mathbf{v}_t(\mathbf{x}|\mathbf{z}) = a'_t\mathbf{x}_0 + b'_t\mathbf{x}_1.$$

CFM 损失. 当 $\sigma = 0$, 即 $\mathbf{x}_t = a_t\mathbf{x}_0 + b_t\mathbf{x}_1$ 时, CFM 损失化为

$$\mathcal{L}_{\text{CFM}} = \mathbb{E}_{t, \mathbf{x}_0 \sim p_{\text{src}}, \mathbf{x}_1 \sim p_{\text{tgt}}} \|\mathbf{v}_\phi(\mathbf{x}_t, t) - (a'_t\mathbf{x}_0 + b'_t\mathbf{x}_1)\|^2.$$

由式 (5.2.10) 和 (5.2.11), 最优速度场为

$$\mathbf{v}^*(\mathbf{x}_t, t) = \mathbb{E}[\mathbf{x}'_t|\mathbf{x}_t] = \mathbb{E}[a'_t\mathbf{x}_0 + b'_t\mathbf{x}_1|\mathbf{x}_t].$$

这里, 期望关于 $p(\mathbf{x}_0, \mathbf{x}_1|\mathbf{x}_t)$ 计算, 它是源-目标对 $(\mathbf{x}_0, \mathbf{x}_1)$ 的条件分布, 这些点对可能在时刻 t 产生观测到的插值 $\mathbf{x}_t = a_t\mathbf{x}_0 + b_t\mathbf{x}_1$.

II. 单侧条件化 $\mathbf{z} = \mathbf{x}_0$ 或 $\mathbf{x}_1$ ——“聚光灯型”路径. 我们在单侧设置下说明先构造条件概率路径的方法, 考虑标准生成设置 $p_{\text{src}} = \mathcal{N}(\mathbf{0}, \mathbf{I})$ 与 $p_{\text{tgt}} = p_{\text{data}}$. 关键在于, 高斯源分布不是额外假设, 而是下文定义的条件路径的直接结果. 节 5.3.3 将对任意端点作更一般的处理.

$\pi(\mathbf{z})$ 的选择. 取 $\mathbf{z} = \mathbf{x}_1$, 且 $\pi(\mathbf{z}) = p_{\text{data}}(\mathbf{x}_1)$ ($\mathbf{z} = \mathbf{x}_0 \sim p_{\text{prior}}$ 的情形可类似处理).

条件路径 $p_t(\cdot|\mathbf{z})$ 的选择. 对于固定的 $\mathbf{x}_1 \sim p_{\text{data}}$, 定义

$$p_t(\mathbf{x}_t|\mathbf{z} = \mathbf{x}_1) = \mathcal{N}(\mathbf{x}_t; b_t\mathbf{x}_1, a_t^2\mathbf{I}),$$

其中 $a_0 = 1, b_0 = 0, a_1 = 0, b_1 = 1$ (通常按极限解释). 在边界处,

$$p_0(\cdot|\mathbf{z} = \mathbf{x}_1) = \mathcal{N}(\cdot; \mathbf{0}, \mathbf{I}), \quad p_1(\cdot|\mathbf{z} = \mathbf{x}_1) = \delta(\cdot - \mathbf{x}_1).$$

对 $\mathbf{x}_1$ 边缘化, 得到 $\{p_t\}_{t \in [0,1]}$, 其中 $p_0 = \mathcal{N}(\mathbf{0}, \mathbf{I})$ (与 p_{data} 无关), 且 $p_1 = p_{\text{data}}$.

推导出的条件速度 $\mathbf{v}_t(\cdot|\mathbf{z})$. 当 $t \in (0, 1)$ 且 $b_t > 0$ 时, 将命题 5.3.1 应用于条件高斯路径, 得到

$$\mathbf{v}_t(\mathbf{x}|\mathbf{x}_1) = b'_t\mathbf{x}_1 + \frac{a'_t}{a_t}(\mathbf{x} - b_t\mathbf{x}_1).$$

单侧 CFM 目标. 对于 $t \sim \mathcal{U}(0, 1)$ (或任意固定采样分布) 和 $\mathbf{x}_1 \sim p_{\text{data}}$, CFM 损失变为

$$\mathcal{L}_{\text{CFM}} = \mathbb{E}_{t, \mathbf{x}_1} \mathbb{E}_{\mathbf{x}_t \sim p_t(\cdot | \mathbf{x}_1)} \left\| \mathbf{v}_\phi(\mathbf{x}_t, t) - \left[b'_t \mathbf{x}_1 + \frac{a'_t}{a_t} (\mathbf{x}_t - b_t \mathbf{x}_1) \right] \right\|_2^2. \quad (5.3.3)$$

由均方误差的最优性, 唯一最小化解为边缘速度场

$$\mathbf{v}^*(\mathbf{x}, t) = \mathbb{E}[\mathbf{v}_t(\mathbf{x} | \mathbf{x}_1) | \mathbf{x}_t = \mathbf{x}] = \mathbb{E}[a'_t \mathbf{x}_0 + b'_t \mathbf{x}_1 | \mathbf{x}_t = \mathbf{x}].$$

与双侧目标的等价性. 对于满足 $\mathbf{x}_t = a_t \mathbf{x}_0 + b_t \mathbf{x}_1$ 的配对样本 $(\mathbf{x}_0, \mathbf{x}_1)$,

$$\mathbf{v}_t(\mathbf{x}_t | \mathbf{x}_1) = b'_t \mathbf{x}_1 + \frac{a'_t}{a_t} (\mathbf{x}_t - b_t \mathbf{x}_1) = a'_t \mathbf{x}_0 + b'_t \mathbf{x}_1.$$

因此, 单侧损失回归到给定 $\mathbf{x}_t$ 时双侧目标的条件期望:

$$\mathbf{v}^*(\mathbf{x}, t) = \mathbb{E}[a'_t \mathbf{x}_0 + b'_t \mathbf{x}_1 | \mathbf{x}_t = \mathbf{x}],$$

从而单侧与双侧 CFM 目标具有相同的最小化解.

高斯 FM = 扩散模型. 我们采用 FM 的时间约定, 以 $t = 0$ 表示源 / 先验, 以 $t = 1$ 表示目标 / 数据:

$$p_{\text{src}} = p_{\text{prior}}, \quad p_{\text{tgt}} = p_{\text{data}}.$$

相比之下, 扩散模型通常按从数据到噪声的方向标记时间 (即 $t = 0$ 为数据, $t = 1$ 为先验). 这里, 我们始终采用 FM 的时间标记约定, 以避免混淆. 如果进一步有 $p_{\text{src}} = \mathcal{N}(\mathbf{0}, \mathbf{I})$, 则对于固定条件 $\mathbf{x}_1 \sim p_{\text{data}}$, 条件路径 $p_t(\cdot | \mathbf{x}_1)$ 自然选为高斯分布, 而目标分布 p_{tgt} 本身无需为高斯分布. 一些文献通常将此设置称为高斯 FM.

选择 $a_t = 1 - t$ 与 $b_t = t$ (等价地, 在扩散模型中重新标记为 $a_t := \sigma_t$ 、 $b_t := \alpha_t$ 后, $\alpha_t = t$ 、 $\sigma_t = 1 - t$), 便恢复了熟悉的 FM/RF 调度 (Lipman et al., 2022; Liu, 2022).

表 5.2: 按 FM 约定书写的不同插值方式汇总, $\mathbf{x}_t = a_t \mathbf{x}_0 + b_t \mathbf{x}_1$, 其中 $\mathbf{x}_0 \sim p_{\text{src}} = p_{\text{prior}}$, $\mathbf{x}_1 \sim p_{\text{tgt}} = p_{\text{data}}$. VE/VP 通过 $a_t := \sigma_t$, $b_t := \alpha_t$ 从其扩散约定 (数据 $\rightarrow$ 噪声) 转换而来.

	VE	VP	FM/RF	三角函数 (Albergo, Boffi, and Vanden-Eijnden, 2023)
a_t (先验系数)	a_t	$\sqrt{1 - b_t^2}$	$1 - t$	$\cos(\frac{\pi}{2}t)$
b_t (数据系数)	1	b_t	t	$\sin(\frac{\pi}{2}t)$
a_0	0	0	1	1
b_0	1	1	0	0
a_1	a_1	1	0	0
b_1	1	0	1	1
p_{prior}	$\mathcal{N}(\mathbf{0}, a_1^2 \mathbf{I})$	$\mathcal{N}(\mathbf{0}, \mathbf{I})$	$\mathcal{N}(\mathbf{0}, \mathbf{I})$	$\mathcal{N}(\mathbf{0}, \mathbf{I})$

在高斯 FM 设置下，光束型与聚光灯型条件路径都导出与标准扩散损失类似的训练目标. 正如章 6 将详细阐述的那样，高斯 FM 实际上可等价解释为在线性调度 $a_t = 1 - t$ 和 $b_t = t$ 下，训练来预测速度的扩散模型. 这一视角表明，流匹配与扩散并无本质区别，而是可以相互转换的两种等价表述. 高斯 FM 目标在实践中特别有吸引力：其损失函数 $(\mathbb{E}_{t, \mathbf{x}_t} [\|\mathbf{v}_\phi(\mathbf{x}_t, t) - (\mathbf{x}_1 - \mathbf{x}_0)\|_2^2])$ 简单，并已被证明可在大规模应用中取得有竞争力的表现 (Esser et al., 2024).

注.

需要强调的是，一些先前工作 (Liu, 2022; Lipman et al., 2022) 认为，采用典范仿射流 $a_t = 1 - t$ 和 $b_t = t$ 会产生“直线”ODE 轨迹，从而实现更快采样. 然而，这一说法通常并不成立. 这一表述中的速度场由如下条件期望给出

$$\mathbf{v}(\mathbf{x}, t) = \mathbb{E}[\mathbf{x}_1 - \mathbf{x}_0 | \mathbf{X}_t = \mathbf{x}],$$

它依赖于 t ，因而并不总与朴素方向 $\mathbf{x}_1 - \mathbf{x}_0$ 一致. 实践中，时间加权函数与参数化的选择会显著影响训练动态，并可改善经验表现，但这些改进不能归因于调度器 $(a_t = 1 - t, b_t = t)$ 所声称的“直线性”.

5.3.3 先构造条件流的 $\mathbf{v}_t(\cdot | \mathbf{z})$ 与 $p_t(\cdot | \mathbf{z})$ 构造

我们处理端点 p_{src} (在 $t = 0$) 与 p_{tgt} (在 $t = 1$) 均任意的一般情形. 目标是直接在轨迹空间中设计条件流，将样本从 p_{src} 输运到 p_{tgt} ，并给出可用作回归目标的闭式 $\mathbf{v}_t(\mathbf{x}_t | \mathbf{z})$.

动机. 除了先设计条件密度路径之外，也可直接指定条件流映射 $\Psi_{0 \rightarrow t}(\cdot; \mathbf{z})$ ，使样本沿轨迹移动. 这有两项实际优势：一是通过沿轨迹的时间导数，立即得到训练所用的回归目标；二是在具有几何结构的空间 (Riemann 流形、Lie 群或受约束的子流形) 上，直接从几何结构 (例如测地线、指数映射或预度量) 构造条件流映射 $\Psi_{0 \rightarrow t}$ 往往很自然 (Lipman et al., 2024)，从而为训练提供解析、无需模拟的目标速度.

条件仿射流 (与命题 5.3.1 的联系). 固定条件变量 $\mathbf{z} \sim \pi$ (例如，单侧“聚光灯”训练中的 $\mathbf{z} = \mathbf{x}_1 \sim p_{\text{tgt}}$)，并通过时变的条件仿射流推前 $\mathbf{x}_0 \sim p_{\text{src}}$:

$$\Psi_{0 \rightarrow t}(\mathbf{x}_0; \mathbf{z}) := \boldsymbol{\mu}_t(\mathbf{z}) + \mathbf{A}_t(\mathbf{z})\mathbf{x}_0, \quad t \in [0, 1],$$

其中 $\boldsymbol{\mu}_t(\mathbf{z}) \in \mathbb{R}^D$ ，且 $\mathbf{A}_t(\mathbf{z}) \in \mathbb{R}^{D \times D}$ 对 $t \in (0, 1)$ 可逆. 边界条件 $\mathbf{A}_0(\mathbf{z}) = \mathbf{I}$ ， $\boldsymbol{\mu}_0(\mathbf{z}) = \mathbf{0}$ 在 $t = 0$ 恢复 p_{src} . 通常将 $t \rightarrow 1$ 时的边界解释为极限 (终端映射可将质量集中到低维集合或一个点)⁸.

⁸ 允许 $\mathbf{A}_1(\mathbf{z})$ 为奇异矩阵 (例如 $\mathbf{0}$) 与 $(0, 1)$ 上的可逆性相容，并使路径在 $t = 1$ 收缩到预先指定的端点.

诱导出的条件路径 $p_t(\cdot|\mathbf{z})$. 这一构造定义了

$$p_t(\cdot|\mathbf{z}) = (\Psi_{0 \rightarrow t}(\cdot; \mathbf{z}))_{\#} p_{\text{src}}, \quad p_t(\cdot) = \int p_t(\cdot|\mathbf{z}) \pi(\mathbf{z}) d\mathbf{z}.$$

在 $\mathcal{L}_{\text{CFM}}$ 中最终重要的是如何从中采样: 先抽取 $\mathbf{z} \sim \pi$, 再抽取 $\mathbf{x}_0 \sim p_{\text{src}}$, 最后令

$$\mathbf{x}_t = \boldsymbol{\mu}_t(\mathbf{z}) + \mathbf{A}_t(\mathbf{z})\mathbf{x}_0.$$

需要指出的是, 当 $\Psi_{0 \rightarrow t}$ 关于 $\mathbf{x}_0$ 为仿射映射时, $p_t(\cdot|\mathbf{z})$ 为高斯分布, 当且仅当 p_{src} 为高斯分布. 特别地, 对于任意 (非高斯) p_{src} , 仿射流产生的 $p_t(\cdot|\mathbf{z})$ 通常为非高斯分布.

推导出的条件速度 $\mathbf{v}_t(\cdot|\mathbf{z})$. 对条件流映射 $\Psi_{0 \rightarrow t}$ 关于 t 求导, 便得到条件速度 $\mathbf{v}_t(\cdot|\mathbf{z})$. 沿用命题 5.3.1 的推导, 考虑由流映射 $\Psi_{0 \rightarrow t}(\mathbf{y}; \mathbf{z})$ 定义、初始条件为 $\mathbf{y}$ 的条件 ODE, 目标是确定相应的条件速度场 $\mathbf{v}_t(\cdot|\mathbf{z})$:

$$\frac{d}{dt} \Psi_{0 \rightarrow t}(\mathbf{y}; \mathbf{z}) = \mathbf{v}_t \left(\underbrace{\Psi_{0 \rightarrow t}(\mathbf{y}; \mathbf{z})}_{\mathbf{x}} \middle| \mathbf{z} \right).$$

由于 $\Psi_{0 \rightarrow t}(\cdot; \mathbf{z})$ 对 $t \in (0, 1)$ 可逆, 可用当前状态 $\mathbf{x} := \Psi_{0 \rightarrow t}(\mathbf{y}; \mathbf{z})$ 表示 $\mathbf{y}$, 即 $\mathbf{y} = \Psi_{0 \rightarrow t}^{-1}(\mathbf{x}; \mathbf{z}) = \Psi_{t \rightarrow 0}(\mathbf{x}; \mathbf{z})$. 将其代入 ODE, 得到如下条件速度场构造:

$$\mathbf{v}_t(\mathbf{x}|\mathbf{z}) := \frac{d}{dt} \Psi_{0 \rightarrow t}(\Psi_{t \rightarrow 0}(\mathbf{x}; \mathbf{z}); \mathbf{z}),$$

这显式表明, 导数必须沿着在时刻 t 到达空间点 $\mathbf{x}$ 的轨迹计算.

由于 $\mathbf{x}_t = \boldsymbol{\mu}_t(\mathbf{z}) + \mathbf{A}_t(\mathbf{z})\mathbf{x}_0$, 且 $\mathbf{A}_t(\mathbf{z})$ 在 $(0, 1)$ 上可逆, 有 $\mathbf{x}_0 = \mathbf{A}_t(\mathbf{z})^{-1}(\mathbf{x} - \boldsymbol{\mu}_t(\mathbf{z}))$, 从而得到

$$\mathbf{v}_t(\mathbf{x}|\mathbf{z}) = \boldsymbol{\mu}'_t(\mathbf{z}) + \mathbf{A}'_t(\mathbf{z})\mathbf{A}_t(\mathbf{z})^{-1}(\mathbf{x} - \boldsymbol{\mu}_t(\mathbf{z})).$$

单侧条件化 ($\mathbf{z} = \mathbf{x}_1$). 选择 $\boldsymbol{\mu}_t(\mathbf{z}) = b_t \mathbf{z}$ 、 $\mathbf{A}_t(\mathbf{z}) = a_t \mathbf{I}$, 其中 $a_0 = 1, a_1 = 0, b_0 = 0, b_1 = 1$ (且对 $t \in (0, 1)$ 有 $a_t > 0$), 得到

$$\mathbf{x}_t = a_t \mathbf{x}_0 + b_t \mathbf{x}_1, \quad \mathbf{v}_t(\mathbf{x}|\mathbf{x}_1) = b'_t \mathbf{x}_1 + \frac{a'_t}{a_t}(\mathbf{x} - b_t \mathbf{x}_1).$$

对于配对样本 $(\mathbf{x}_0, \mathbf{x}_1)$ (其中 $\mathbf{x}_t = a_t \mathbf{x}_0 + b_t \mathbf{x}_1$), 它化为通常的 CFM 目标:

$$\mathbf{v}_t(\mathbf{x}_t|\mathbf{x}_1) = a'_t \mathbf{x}_0 + b'_t \mathbf{x}_1.$$

双侧条件化 ($\mathbf{z} = (\mathbf{x}_0, \mathbf{x}_1)$). 在同一模板中令 $\boldsymbol{\mu}_t(\mathbf{x}_0, \mathbf{x}_1) = b_t \mathbf{x}_1$ 、 $\mathbf{A}_t(\mathbf{x}_0, \mathbf{x}_1) = a_t \mathbf{I}$, 则条件路径为确定性的:

$$\mathbf{x}_t = a_t \mathbf{x}_0 + b_t \mathbf{x}_1, \quad p_t(\cdot|\mathbf{x}_0, \mathbf{x}_1) = \delta(\cdot - (a_t \mathbf{x}_0 + b_t \mathbf{x}_1)),$$

而条件速度为

$$\mathbf{v}_t(\mathbf{x}_t|\mathbf{x}_0, \mathbf{x}_1) = a'_t \mathbf{x}_0 + b'_t \mathbf{x}_1,$$

即标准的双侧 CFM 目标.

作为特例的无条件高斯路径. 若 μ_t 与 $\mathbf{z}$ 无关 (记为 $\mu(t)$), 且 $\mathbf{A}_t = \frac{\sigma(t)}{\sigma(0)}\mathbf{I}$, 则

$$\Psi_{0 \rightarrow t}(\mathbf{x}_0) = \mu(t) + \sigma(t) \frac{\mathbf{x}_0 - \mu(0)}{\sigma(0)}, \quad \mathbf{v}_t(\mathbf{x}) = \mu'(t) + \frac{\sigma'(t)}{\sigma(t)}(\mathbf{x} - \mu(t)),$$

这恢复了命题 5.3.1 中的高斯密度路径与闭式速度.

5.3.4 先构造概率路径与先构造流的比较

两种构造都旨在通过条件动力学连接源分布 p_{src} 与目标分布 p_{tgt} . 先构造概率路径 (Euler) 视角从假设条件密度路径 $p_t(\cdot|\mathbf{z})$ 出发, 通常从高斯族或仿射族中选择, 以便解析求解相应的速度 $\mathbf{v}_t(\cdot|\mathbf{z})$. 先构造流 (Lagrange) 视角则指定条件流映射 $\Psi_{0 \rightarrow t}(\cdot|\mathbf{z})$, 并沿粒子轨迹直接求导得到速度. 在满足正则性时, 两者给出等价的输运, 但在可辨识性、计算便利性和端点约束的实施方式上存在差异. 下表总结这些差异. 要点是: 当条件路径具有闭式速度时, 先构造路径很自然; 当对轨迹具有强结构先验时, 先构造流很自然.

维度	先构造条件概率路径	先构造条件流
给定对象	条件密度路径 $p_t(\cdot \mathbf{z})$.	条件流映射 $\Psi_{0 \rightarrow t}(\cdot \mathbf{z})$ (每个固定 $\mathbf{z}$ 对应的轨迹) .
获得速度	对每个 $\mathbf{z}$, 寻找满足下式的 $\mathbf{v}_t(\cdot \mathbf{z})$: $\partial_t p_t(\cdot \mathbf{z}) + \nabla \cdot (p_t(\cdot \mathbf{z}) \mathbf{v}_t(\cdot \mathbf{z})) = 0$; 不唯一: 若 $\nabla \cdot (p_t \mathbf{w}_t) = 0$, 则 $\mathbf{v}_t + \mathbf{w}_t$ 产生相同的 p_t .	沿路径 (对每个 $\mathbf{z}$): $\mathbf{v}_t(\Psi_{0 \rightarrow t}(\cdot \mathbf{z}) \mathbf{z}) = \frac{d}{dt} \Psi_{0 \rightarrow t}(\cdot \mathbf{z})$. 当 $\Psi_{0 \rightarrow t}$ 可逆时, 可解得 $\mathbf{v}_t(\mathbf{x} \mathbf{z}) = \frac{d}{dt} \Psi_{0 \rightarrow t}(\Psi_{0 \rightarrow t}^{-1}(\mathbf{x}) \mathbf{z})$.
$\mathbf{v}_t(\cdot \mathbf{z})$ 的闭式形式	当 $p_t(\cdot \mathbf{z})$ 为高斯分布 / 指数族时很便利; 否则, 获得 $\mathbf{v}_t(\cdot \mathbf{z})$ 并不简单.	当 $\Psi_{0 \rightarrow t}(\cdot \mathbf{z})$ 具有结构 (仿射 / 低秩) 时很便利; 避免密度求值.
$\mathbf{v}_t(\cdot \mathbf{z})$ 的唯一性	对每个 $\mathbf{z}$, 除非施加选择规则 (例如势流 / 最小动能), 否则 $\mathbf{v}_t(\cdot \mathbf{z})$ 并未完全确定.	给定 $\Psi_{0 \rightarrow t}(\cdot \mathbf{z})$ 后, $p_t(\cdot \mathbf{z}) = (\Psi_{0 \rightarrow t}(\cdot \mathbf{z}))_{\#} p_0$ 与 $\mathbf{v}_t(\cdot \mathbf{z})$ 均被确定; 不可逆映射仍可沿轨迹定义 $\mathbf{v}_t(\cdot \mathbf{z})$, 而可逆映射使其唯一.
可实现性	必须检验构造的 $\mathbf{v}_t(\cdot \mathbf{z})$ 在预期支撑上满足连续性方程.	由构造保证: $p_t(\cdot \mathbf{z}) = (\Psi_{0 \rightarrow t}(\cdot \mathbf{z}))_{\#} p_0(\cdot \mathbf{z})$.
匹配 ($p_{\text{src}}, p_{\text{tgt}}$)	混合条件分布: $p_{\text{src}} = \int p_0(\cdot \mathbf{z}) \pi(\mathbf{z}) d\mathbf{z}$, $p_{\text{tgt}} = \int p_1(\cdot \mathbf{z}) \pi(\mathbf{z}) d\mathbf{z}$. 对具有与 $\mathbf{z}$ 无关的系数的高斯-仿射条件路径, 可强制 p_{src} 为高斯分布. 对于一般固定端点 p_{src} (可能为非高斯分布), $p_t(\cdot \mathbf{z})$ 的选择通常并不能确定 p_{src} .	令 $\Psi_{0 \rightarrow 0} = \text{Id}$, 并选择边界条件以到达任意 p_{tgt} .
适用 场景	扩散式构造; 通过条件高斯分布 $p_t(\cdot \mathbf{z})$ 得到解析目标.	通过映射 $\Psi_{0 \rightarrow t}(\cdot \mathbf{z})$ 表达强结构先验; 便于控制边界; 容纳奇异 / 低维端点; 自然适用于基于映射的正则化 / 运输代价.

5.4 (选读) 典范仿射流的性质

给定两个端点分布 $p_0 = p_{\text{src}}$ 与 $p_1 = p_{\text{tgt}}$, 在流匹配 (FM) (Lipman et al., 2022) 和整流 (RF) (Liu, Gong, et al., 2022) 中定义条件路径时, 一种自然且广泛使用的选择是线性插值

$$a_t = 1 - t, \quad b_t = t,$$

它产生插值

$$\mathbf{x}_t = (1 - t)\mathbf{x}_0 + t\mathbf{x}_1, \quad \mathbf{x}_0 \sim p_{\text{src}}, \mathbf{x}_1 \sim p_{\text{tgt}}.$$

在这一选择下, 训练目标简化为

$$\mathbb{E}_{t \sim \mathcal{U}[0,1]} \mathbb{E}_{\mathbf{x}_0, \mathbf{x}_1} \left[\left\| \mathbf{v}_\phi(\mathbf{x}_t, t) - (\mathbf{x}_1 - \mathbf{x}_0) \right\|_2^2 \right].$$

这种线性流具有若干吸引人的性质. 特别地, 它允许一种称为 *Reflow* 的迭代细化方案, 在保持边缘分布的同时, 逐渐拉直分布之间的路径.

5.4.1 整流: 从噪声猜测到结构化配对

通过协调路径从噪声到数据. 考虑生成任务, 其中 p_{src} 为先验, p_{tgt} 为真实数据. 我们希望得到将噪声输运到数据的连续路径. 一种朴素策略是独立抽取 $\mathbf{z}_0 \sim p_{\text{src}}$ 与 $\mathbf{x}_1 \sim p_{\text{tgt}}$, 进行插值 (例如 $\mathbf{x}_t = (1 - t)\mathbf{x}_0 + t\mathbf{x}_1$), 并针对这条直线拟合速度场. 这会产生不协调的配对: 不同迭代之间的端点没有关联, 因此轨迹波动、方差爆炸、收敛变慢, 样本质量也受到影响.

独立耦合为何不足. 使用独立抽样的条件流匹配采用

$$\pi(\mathbf{z}) = p_{\text{src}}(\mathbf{x}_0)p_{\text{tgt}}(\mathbf{x}_1),$$

或其单侧变体. 这种耦合便于采样, 却会诱导曲折、高方差的路径, 使速度场难以建模.

通过相依耦合整流. 我们不再依赖任意配对, 而是将预训练扩散模型 $\mathbf{v}_{\phi^\times}(\cdot, t)$ 用作 PF-ODE 的漂移, 以确定性地输运每个源点. 从 $\mathbf{z}(0) = \mathbf{z}_0 \sim p_{\text{src}}$ 出发, 积分

$$\frac{d\mathbf{z}(t)}{dt} = \mathbf{v}_{\phi^\times}(\mathbf{z}(t), t), \quad t \in [0, 1],$$

得到 $\hat{\mathbf{z}}_1 := \mathbf{z}(1)$, 它位于预训练模型学得的数据空间附近. 所得点对 $(\mathbf{z}_0, \hat{\mathbf{z}}_1)$ 构成相依耦合: 它遵循结构化的、由模型引导的路径, 而非任意插值. 这一思想自然推广到形如 $\mathbf{x}_t = a_t\mathbf{x}_0 + b_t\mathbf{x}_1$ 的仿射参考路径, 其中 $\mathbf{x}_0 \sim p_{\text{src}}$ 、 $\mathbf{x}_1 \sim p_{\text{tgt}}$.

算法 2 Rectify 操作

输入： 参考路径 $\{\mathbf{x}_t\}_{t \in [0,1]}$ (例如 $\mathbf{x}_t = a_t \mathbf{x}_0 + b_t \mathbf{x}_1$)

1: **预训练扩散模型.** 在选定路径上, 通过最小化下式拟合 $\mathbf{v}_{\phi^\times}$:

$$\phi^\times \in \arg \min_{\phi} \mathbb{E}_{t, \mathbf{x}_0, \mathbf{x}_1} \left[\left\| \mathbf{v}_{\phi}(\mathbf{x}_t, t) - \frac{d\mathbf{x}_t}{dt} \right\|_2^2 \right].$$

2: **整流.** 抽取 $\mathbf{z}_0 \sim p_{\text{src}}$ 并积分

$$\frac{d\mathbf{z}(t)}{dt} = \mathbf{v}_{\phi^\times}(\mathbf{z}(t), t), \quad \mathbf{z}(0) = \mathbf{z}_0, \quad t \in [0, 1],$$

得到 $\hat{\mathbf{z}}_1 = \mathbf{z}(1)$ 及轨迹 $\{\mathbf{z}(t)\}_{t \in [0,1]}$.

输出： 相依 (协调) 点对 $(\mathbf{z}_0, \hat{\mathbf{z}}_1)$ 或完整轨迹.

为何有效：保持边缘分布的结构. 令 $\Phi_{0 \rightarrow t}$ 表示由上述预训练扩散 $\mathbf{v}_{\phi^\times}$ 定义的 ODE 生成的流映射, 则 $\mathbf{z}(t) = \Phi_{0 \rightarrow t}(\mathbf{z}_0)$ 、 $\hat{\mathbf{z}}_1 = \Phi_{0 \rightarrow 1}(\mathbf{z}_0)$. Rectify 过程将每个源点与其流的终点配对, 得到确定性的联合分布

$$\pi_{\text{Rectify}}(\mathbf{z}_0, \mathbf{z}_1) = p_{\text{src}}(\mathbf{z}_0) \delta(\mathbf{z}_1 - \Phi_{0 \rightarrow 1}(\mathbf{z}_0)).$$

立即得到两个推论:

- **源边缘分布保持不变:** $\int \pi_{\text{Rectify}}(\mathbf{z}_0, \mathbf{z}_1) d\mathbf{z}_1 = p_{\text{src}}(\mathbf{z}_0)$.
- **沿流推前:** $(\Phi_{0 \rightarrow t})_{\#} p_{\text{src}} = \text{Law}(\mathbf{z}(t))$, 即时刻 t 的分布是 p_{src} 经 $\Phi_{0 \rightarrow t}$ 的推前.

若 $\mathbf{v}_{\phi^\times}$ 匹配给定参考路径 $\mathbf{x}_t$ 的理想漂移, 则所有中间边缘分布都重合:

$$\text{Law}(\mathbf{z}(t)) = \text{Law}(\mathbf{x}_t), \quad \text{对所有 } t \in [0, 1], \quad \text{且} \quad (\Phi_{0 \rightarrow 1})_{\#} p_{\text{src}} = p_{\text{tgt}}.$$

总结. 整流用平滑、由教师引导的轨迹替换带噪声的独立配对, 从而降低方差、简化优化并改善样本. 这一思想涵盖典范线性路径 $\mathbf{x}_t = (1-t)\mathbf{x}_0 + t\mathbf{x}_1$ 和一般仿射形式 $\mathbf{x}_t = a_t \mathbf{x}_0 + b_t \mathbf{x}_1$.

对于典范路径, 反复应用 Rectify (“Reflow”) 能够在不增加输运代价的情况下进一步拉直轨迹, 使训练更为容易.

5.4.2 Reflow: 迭代拉直流

为何需要 Reflow? 独立配对往往在 p_{src} 与 p_{tgt} 之间诱导不规则、蜿蜒的 ODE 轨迹, 从而增加模拟时的离散化误差和方差. 这自然引出一个问题:

问题 5.4.1. 能否学习一种耦合, 使其诱导的输运路径在两个分布之间更接近直线, 同时仍保持正确的边缘分布?

这推动了 Reflow 的提出: 反复应用 Rectify 更新耦合, 使后续的流更易积分.

核心思想：通过 Rectify 递归拉直。 从乘积耦合 $\pi^{(0)} := p_{\text{src}}(\mathbf{x}_0)p_{\text{tgt}}(\mathbf{x}_1)$ 上的典范插值出发，

$$\mathbf{x}_t = t\mathbf{x}_0 + (1-t)\mathbf{x}_1.$$

应用 Rectify 将独立配对替换为相依配对 $(\mathbf{z}_0, \hat{\mathbf{z}}_1)$ ，经验上它在学得的场下诱导曲率更低的轨迹。迭代这一更新会逐渐减小路径曲率（并不强制成为严格的直线），改善数值稳定性与对齐。

Reflow 过程。 每次迭代执行两个步骤：

1. **重新拟合流：** 使用当前耦合的样本训练新的速度场：

$$\begin{aligned} \phi_{k+1} &= \arg \min_{\phi} \mathcal{L}(\phi | \pi^{(k)}), \quad \text{其中} \\ \mathcal{L}(\phi | \pi^{(k)}) &:= \mathbb{E}_{t, (\mathbf{z}_0^{(k)}, \hat{\mathbf{z}}_1^{(k)}) \sim \pi^{(k)}} \left[\left\| \mathbf{v}_{\phi}(\mathbf{z}_t, t) - (\hat{\mathbf{z}}_1^{(k)} - \mathbf{z}_0^{(k)}) \right\|^2 \right] \end{aligned} \quad (5.4.1)$$

其中 $\mathbf{z}_t = t\mathbf{z}_0^{(k)} + (1-t)\hat{\mathbf{z}}_1^{(k)}$ 。

2. **生成新耦合：** 从新的源样本 $\mathbf{z}_0^{(k+1)} \sim p_{\text{src}}$ 出发求解学得的 ODE：

$$\hat{\mathbf{z}}_1^{(k+1)} \leftarrow \mathbf{z}_0^{(k+1)} + \int_0^1 \mathbf{v}_{\phi_{k+1}}(\mathbf{z}(t), t) dt,$$

并定义更新后的耦合：

$$\pi^{(k+1)}(\mathbf{z}_0, \mathbf{z}_1) := p_{\text{src}}(\mathbf{z}_0) \delta(\mathbf{z}_1 - \hat{\mathbf{z}}_1^{(k+1)}).$$

换言之，Reflow 可视为反复应用 Rectify 算子，产生逐渐细化的耦合序列：

$$\pi^{(k+1)} = \text{Rectify}(\pi^{(k)}) \quad (5.4.2)$$

从而使流与耦合共同演化，得到越来越稳定的输运路径。

5.4.3 Reflow 的性质

Reflow 的实用性来自两个关键理论性质：降低输运代价和拉直轨迹。

I. Reflow 从不增加输运代价。 设 $c(\mathbf{y})$ 是凸代价函数（例如 $\|\mathbf{y}\|_2^p$ ，其中 $p \geq 1$ ）。每一步 Rectify 都形成新的耦合 $(\mathbf{z}_0, \hat{\mathbf{z}}_1)$ ，其代价不会高于原耦合：

命题 5.4.1: Rectify 可能降低输运代价

假定理想速度场 $\mathbf{v}^* = \mathbf{v}_{\phi^*}$ ，则有：

$$\mathbb{E}[c(\hat{\mathbf{z}}_1 - \mathbf{z}_0)] \leq \mathbb{E}[c(\mathbf{x}_1 - \mathbf{x}_0)].$$




图 5.7: 来自 Liu, Gong, et al. (2022) 的 Reflow 示意图. 随着 Rectify 过程进行, 路径逐渐变得更直.

命题的证明.

由 Jensen 不等式得到. 完整推导见 Liu, Gong, et al. (2022).

递归应用这一结果可知, Reflow 过程不增加输运代价.

II. Reflow 拉直路径. Reflow 的迭代次数越多, 学得的轨迹可能越直. 为衡量这一点, 将路径 $\mathbf{Y} = \{\mathbf{y}_t\}_{t \in [0,1]}$ 的直线性泛函定义为

$$\mathcal{S}(\mathbf{Y}) := \int_0^1 \mathbb{E} \left[\left\| \mathbf{y}_1 - \mathbf{y}_0 - \frac{d\mathbf{y}_t}{dt} \right\|_2^2 \right] dt.$$

若 $\mathcal{S}(\mathbf{Y}) = 0$, 则 $\mathbf{Y}$ 恰好是一条直线.

命题 5.4.2: Reflow 拉直随机路径

对于整流后的路径 $\mathbf{Z}^{(k)}$, 有:

$$\min_{k \in \{0, \dots, K\}} \mathcal{S}(\mathbf{Z}^{(k)}) \leq \frac{\mathbb{E} [\|\mathbf{x}_1 - \mathbf{x}_0\|^2]}{K}.$$

命题的证明.

见 Liu (2022) 的定理 3.7.

采用线性插值核的 FM 或 RF 表述, 结合 Reflow 过程, 提供了更简单的训练目标, 以及细化随机耦合的实用方法. 理论细节见 (Liu, Gong, et al., 2022; Liu, 2022).

III. 与最优输运的联系. 最后需要指出, 直线耦合未必在最优输运 (OT) 意义下最优. 这涉及将在节 7.2 中介绍的一些术语, 因此不熟悉 OT 的读者可参阅该节.

二次代价最优输运的一个特征是粒子沿直线运动: 位于 $\mathbf{x}_0$ 的粒子通过 $\mathbf{x}_t = (1-t)\mathbf{x}_0 + t\mathbf{T}(\mathbf{x}_0)$ 移动到 $\mathbf{T}(\mathbf{x}_0)$, 其中 $\mathbf{T}$ 为最优输运映射. 然而, 并非每个生成这种直线路径 (即 $\mathbf{x}_t = (1-t)\mathbf{x}_0 + t\mathbf{S}(\mathbf{x}_0)$) 的映射 $\mathbf{S}$ 都是最优的. 只有当映射 $\mathbf{S}$ 最小化 Monge 代价 $\mathbb{E}[\|\mathbf{x}_0 - \mathbf{S}(\mathbf{x}_0)\|^2]$ 时, 它才产生最优流. 因此, 直线路径虽是必要条件, 却不是充分条件; 最优性还取决于正确的端点映射 $\mathbf{T}$.

例：直线耦合未必最优

设 $p_{\text{src}} = p_{\text{tgt}} = \mathcal{N}(\mathbf{0}, \mathbf{I})$. 对代价 $c(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\|^p$, 其中 $p > 0$, c 最优耦合是恒等耦合 π^* ; π^* 是 $(\mathbf{x}, \mathbf{x})$ 的分布, 且 $\mathbf{x} \sim p_{\text{src}}$.

现在考虑定义为 $(\mathbf{x}, \mathbf{Ax})$ 的分布的耦合 $\pi_{\mathbf{A}}$, 其中 $\mathbf{x} \sim p_{\text{src}}$, $\mathbf{A}$ 为满足 $\mathbf{A}^\top \mathbf{A} = \mathbf{I}$ 、 $\det(\mathbf{A}) = 1$ 、 $\mathbf{A} \neq \mathbf{I}$ 且 -1 不是其特征值的旋转矩阵. 则 $\pi_{\mathbf{A}}$ 是 p_{src} 与 p_{tgt} 的有效耦合, 对应于 $\mathbf{x}$ 与 $\mathbf{Ax}$ 之间的直线路径, 但对于任何二次可微、严格凸且 Hessian 可逆的代价 c , 它都不是 c 最优的. 次优性源于旋转变换. 如式 (7.5.2) 所讨论的那样, 即使消除旋转, 也未必得到最优耦合. ■

我们将在节 7.5.2 中继续探讨与 OT 的联系.

5.5 结束语

本章阐明了扩散模型的第三种也是最后一种基础视角，它根植于确定性流的原理。探索始于归一化流（NF），它利用变量替换公式学习简单先验与数据分布之间精确、可逆的映射。随后，这一概念通过神经常微分方程发展为连续时间过程，由学得的速度场支配变换。然而，这一方法有一个重大缺点：需要在训练循环内进行代价高昂的 ODE 模拟。

现代流匹配（FM）框架为这一挑战提供了简洁、高效的解决方案。通过预先定义概率路径 $\{p_t\}_t$ 及满足连续性方程的相应速度场，FM 为 ODE 流确立了清晰的目标。关键在于，与变分视角和基于得分的视角一样，FM 采用了强大的条件化技巧。它将不可处理的边缘速度场匹配问题，变为对已知条件速度进行简单且可处理的回归，使训练完全无需模拟。这一视角将扩散模型本身重新解释为学习确定性流的一个特例，该流将高斯先验输运到数据分布。

随着基于流的视角的引入，我们对扩散建模三大概念支柱的考察已告完成。在这一过程中出现了一个显著模式：尽管各个框架分别起源于 VAE、EBM 或 NF，它们都汇聚到连续时间生成过程，并依靠条件化策略实现可处理的学习。

下一章将最终把这些平行的思路综合成单一的统一框架。我们将：

1. 形式化地证明，变分视角、基于得分的视角和基于流的视角不仅相互类似，而且在基本层面上数学等价。
2. 展示 Fokker-Planck 方程如何作为支配全部三种视角下密度演化的普遍规律，揭示它们只是描述同一核心生成原理的不同视角。

这一统一视角将提供对现代扩散范式完整而系统的理解。

第 6 章 扩散模型的统一系统视角

数学是一门赋予不同事物相同名称的艺术.

Henri Poincaré

本章提出一种系统视角，将变分视角、基于得分的视角和基于流的视角联系成一幅连贯的图景. 虽然这些方法由不同的直觉推动，但它们都汇聚到现代扩散方法背后的同一核心机制. 基于章 2至5，我们观察到一种共同做法：定义沿边缘分布路径演化的前向加噪过程，然后学习时变向量场，沿这条路径将简单先验输运到数据分布.

各种视角共有的一个关键要素，是节 6.1中介绍的条件化技巧：它将不可处理的边缘目标转化为可处理的条件目标，从而实现稳定、高效的训练.

在节 6.2中，我们系统分析训练目标，识别其基本组成部分，并阐明变分视角、基于得分的视角和基于流的视角如何构造损失函数.

节 6.3表明，任意形如 $\mathbf{x}_t = \alpha_t \mathbf{x}_0 + \sigma_t \epsilon$ 的仿射前向噪声注入，都可等价变换为标准线性调度 $\mathbf{x}_t = (1 - t)\mathbf{x}_0 + t\epsilon$. 此外，噪声预测、干净数据预测、得分预测和速度预测等常见参数化在梯度层面上可以相互转换. 因此，噪声调度器与参数化的选择都遵循同一个建模原理.

最后，节 6.4汇总讨论并识别支配规律：Fokker–Planck 方程. 无论将其视为变分方案（离散时间去噪）、基于得分的方法（SDE 表述），还是基于流的方法（ODE 表述），每种方法都构造边缘分布遵循同一密度演化的生成器. 因此，Fokker–Planck 方程是三种视角共同遵守的普遍约束，差异仅来自参数化和训练目标.

6.1 条件化技巧：扩散模型的秘诀

迄今为止，我们已经从三个看似不同的起源探索扩散模型：变分视角、基于得分的视角和基于流的视角。每种视角最初都由不同目标推动，并导出各自的训练目标（固定 t ）：

- **变分视角**：学习参数化密度 $p_\phi(\mathbf{x}_{t-\Delta t}|\mathbf{x}_t)$ ，通过最小化下式近似理想反向转移 $p(\mathbf{x}_{t-\Delta t}|\mathbf{x}_t)$ ：

$$\mathcal{J}_{\text{KL}}(\phi) := \mathbb{E}_{p_t(\mathbf{x}_t)} [\mathcal{D}_{\text{KL}}(p(\mathbf{x}_{t-\Delta t}|\mathbf{x}_t) \| p_\phi(\mathbf{x}_{t-\Delta t}|\mathbf{x}_t))];$$

- **基于得分的视角**：学习得分模型 $\mathbf{s}_\phi(\mathbf{x}_t, t)$ ，通过下式近似边缘得分 $\nabla_{\mathbf{x}} \log p_t(\mathbf{x}_t)$ ：

$$\mathcal{J}_{\text{SM}}(\phi) := \mathbb{E}_{p_t(\mathbf{x}_t)} [\|\mathbf{s}_\phi(\mathbf{x}_t, t) - \nabla_{\mathbf{x}} \log p_t(\mathbf{x}_t)\|_2^2];$$

- **基于流的视角**：学习速度模型 $\mathbf{v}_\phi(\mathbf{x}_t, t)$ ，通过最小化下式匹配理想速度 $\mathbf{v}_t(\mathbf{x}_t)$ （例如，由式 (5.2.10) 定义）：

$$\mathcal{J}_{\text{FM}}(\phi) := \mathbb{E}_{p_t(\mathbf{x}_t)} [\|\mathbf{v}_\phi(\mathbf{x}_t, t) - \mathbf{v}_t(\mathbf{x}_t)\|_2^2].$$

乍看之下，这些目标似乎都完全无法处理，因为它们都要求获得通常根本无法知道的目标量。但转折在于，每种方法都独立地得到了这一问题的同一个简洁解法：以数据 $\mathbf{x}_0$ 为条件。这一技术将每个不可处理的训练目标转化为可处理的目标。

这一简洁的“条件化技术”将目标改写为关于已知高斯条件分布 $p_t(\mathbf{x}_t|\mathbf{x}_0)$ 的期望，产生梯度等价的闭式回归目标和可处理的训练目标：

- **变分视角**（式 (2.2.3)）：

$$\mathcal{J}_{\text{KL}}(\phi) = \underbrace{\mathbb{E}_{\mathbf{x}_0} \mathbb{E}_{p_t(\mathbf{x}_t|\mathbf{x}_0)} [\mathcal{D}_{\text{KL}}(p(\mathbf{x}_{t-\Delta t}|\mathbf{x}_t, \mathbf{x}_0) \| p_\phi(\mathbf{x}_{t-\Delta t}|\mathbf{x}_t))]}_{\mathcal{J}_{\text{CKL}}(\phi)} + C;$$

- **基于得分的视角**（式 (3.3.3)）：

$$\mathcal{J}_{\text{SM}}(\phi) = \underbrace{\mathbb{E}_{\mathbf{x}_0} \mathbb{E}_{p_t(\mathbf{x}_t|\mathbf{x}_0)} [\|\mathbf{s}_\phi(\mathbf{x}_t, t) - \nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t|\mathbf{x}_0)\|_2^2]}_{\mathcal{J}_{\text{DSM}}(\phi)} + C;$$

- **基于流的视角**（式 (5.2.9)）：

$$\mathcal{J}_{\text{FM}}(\phi) = \underbrace{\mathbb{E}_{\mathbf{x}_0} \mathbb{E}_{p_t(\mathbf{x}_t|\mathbf{x}_0)} [\|\mathbf{v}_\phi(\mathbf{x}_t, t) - \mathbf{v}_t(\mathbf{x}_t|\mathbf{x}_0)\|_2^2]}_{\mathcal{J}_{\text{CFM}}(\phi)} + C.$$

为建立统一视角，接下来系统地重新考察条件 KL、得分和速度目标。关键在于，这些目标不仅可处理，而且除了常数的竖直平移之外，还与其原始形式等价。条件版本 ($\mathcal{J}_{\text{CKL}}$ 、 $\mathcal{J}_{\text{DSM}}$ 、 $\mathcal{J}_{\text{CFM}}$) 与原始版本 ($\mathcal{J}_{\text{KL}}$ 、 $\mathcal{J}_{\text{SM}}$ 、 $\mathcal{J}_{\text{FM}}$) 仅相差这一平移，梯度不变，因而保留了优化景观。因此，最小化解仍被唯一确定为真实的理想目标，因为每个问题都化为最小二乘回归问题，其解恢复相应的条件期望：

$$\begin{aligned}
p^*(\mathbf{x}_{t-\Delta t}|\mathbf{x}_t) &= \mathbb{E}_{\mathbf{x}_0 \sim p(\cdot|\mathbf{x}_t)} [p(\mathbf{x}_{t-\Delta t}|\mathbf{x}_t, \mathbf{x}_0)] &= p(\mathbf{x}_{t-\Delta t}|\mathbf{x}_t), \\
\mathbf{s}^*(\mathbf{x}_t, t) &= \mathbb{E}_{\mathbf{x}_0 \sim p(\cdot|\mathbf{x}_t)} [\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t|\mathbf{x}_0)] &= \nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t), \\
\mathbf{v}^*(\mathbf{x}_t, t) &= \mathbb{E}_{\mathbf{x}_0 \sim p(\cdot|\mathbf{x}_t)} [\mathbf{v}_t(\mathbf{x}_t|\mathbf{x}_0)] &= \mathbf{v}_t(\mathbf{x}_t).
\end{aligned} \tag{6.1.1}$$

这并非巧合：这些条件形式通过使训练可处理，揭示了一种深刻的统一性。变分扩散、基于得分的 SDE 和流匹配，只是同一原理的不同侧面。三种视角通过同一个见解巧妙相连。

本章余下部分将继续探索它们的等价性。

6.2 阐明扩散模型训练损失的路线图

本节建立扩散模型训练损失的系统视角. 在节 6.2.1 中, 我们将标准的三种目标扩展到更广泛的四种参数化, 展示它们如何从不同建模视角产生. 随后, 在节 6.2.2 中, 我们将这些结果提炼为解析扩散目标结构的一般框架, 为节 6.3 中的等价性结果奠定基础.

6.2.1 扩散模型中四种常见参数化

本节始终考虑前向扰动核

$$p_t(\mathbf{x}_t|\mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t; \alpha_t \mathbf{x}_0, \sigma_t^2 \mathbf{I}),$$

其中 $\mathbf{x}_0 \sim p_{\text{data}}$, 如式 (4.4.1) 所定义, 除非另作说明.

令 $\omega: [0, T] \rightarrow \mathbb{R}_{>0}$ 表示正的时间加权函数. 为清晰起见并便于后续讨论, 下面总结四种标准参数化 (噪声 ϵ_ϕ 、干净数据 $\mathbf{x}_\phi$ 、得分 $\mathbf{s}_\phi$ 和速度 $\mathbf{v}_\phi$), 以及各自的最小化解 ϵ^* 、 $\mathbf{x}^*$ 、 $\mathbf{s}^*$ 和 $\mathbf{v}^*$.

变分视角. 基于 DDPM 中的 KL 散度 (见节 2.2.4 和 4.4.3), 这一方法归结为预测产生 $\mathbf{x}_t$ 的噪声的期望, 或被扰动为 $\mathbf{x}_t$ 的干净信号的期望.

1. **ϵ 预测 (噪声预测)** (Ho, Jain, and Abbeel, 2020):

$$\epsilon_\phi(\mathbf{x}_t, t) \approx \mathbb{E}[\epsilon|\mathbf{x}_t] = \epsilon^*(\mathbf{x}_t, t) \quad (6.2.1)$$

训练目标为

$$\mathcal{L}_{\text{noise}}(\phi) := \mathbb{E}_t [\omega(t) \mathbb{E}_{\mathbf{x}_0, \epsilon} \|\epsilon_\phi(\mathbf{x}_t, t) - \epsilon\|_2^2].$$

这里, ϵ^* 表示为得到给定 $\mathbf{x}_t$ 而注入的噪声的平均值.

2. **$\mathbf{x}$ 预测 (干净数据预测)** (Kingma et al., 2021; Karras et al., 2022; Song et al., 2023):

$$\mathbf{x}_\phi(\mathbf{x}_t, t) \approx \mathbb{E}[\mathbf{x}_0|\mathbf{x}_t] = \mathbf{x}^*(\mathbf{x}_t, t) \quad (6.2.2)$$

训练目标为

$$\mathcal{L}_{\text{clean}}(\phi) := \mathbb{E}_t [\omega(t) \mathbb{E}_{\mathbf{x}_0, \epsilon} \|\mathbf{x}_\phi(\mathbf{x}_t, t) - \mathbf{x}_0\|_2^2].$$

这里, $\mathbf{x}^*$ 表示给定带噪观测 $\mathbf{x}_t$ 时, 所有可能的干净数据猜测的平均值.

基于得分的视角. 预测噪声水平 t 下的得分函数, 它指向将 $\mathbf{x}_t$ 去噪回所有可能生成它的干净样本的平均方向:

3. **得分预测** (Song and Ermon, 2019; Song et al., 2020b):

$$\mathbf{s}_\phi(\mathbf{x}_t, t) \approx \nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t) = \mathbb{E}[\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t|\mathbf{x}_0)|\mathbf{x}_t] = \mathbf{s}^*(\mathbf{x}_t, t) \quad (6.2.3)$$

训练目标为

$$\mathcal{L}_{\text{score}}(\phi) := \mathbb{E}_t [\omega(t) \mathbb{E}_{\mathbf{x}_0, \epsilon} \|\mathbf{s}_\phi(\mathbf{x}_t, t) - \nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t|\mathbf{x}_0)\|_2^2],$$

其中条件得分满足 $\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t|\mathbf{x}_0) = -\frac{1}{\sigma_t} \epsilon$.

基于流的视角. 预测数据演化经过 $\mathbf{x}_t$ 时的瞬时平均速度:

4. **v 预测 (速度预测)** (Lipman et al., 2022; Liu, 2022; Salimans and Ho, 2021; Albergo, Boffi, and Vanden-Eijnden, 2023):

$$\mathbf{v}_\phi(\mathbf{x}_t, t) \approx \mathbb{E} \left[\frac{d\mathbf{x}_t}{dt} \middle| \mathbf{x}_t \right] = \mathbf{v}^*(\mathbf{x}_t, t) \quad (6.2.4)$$

训练目标为

$$\mathcal{L}_{\text{velocity}}(\phi) := \mathbb{E}_t \left[\omega(t) \mathbb{E}_{\mathbf{x}_0, \epsilon} \left\| \mathbf{v}_\phi(\mathbf{x}_t, t) - \mathbf{v}_t(\mathbf{x}_t | \mathbf{x}_0, \epsilon) \right\|_2^2 \right],$$

其中条件速度为 $\mathbf{v}_t(\mathbf{x}_t | \mathbf{x}_0, \epsilon) = \alpha'_t \mathbf{x}_0 + \sigma'_t \epsilon$.

这里, $\mathbf{v}^*$ 表示经过观测点 $\mathbf{x}_t$ 的平均速度向量.

基于式 (6.1.1) 的见解, 四种预测最终都旨在近似条件期望, 即给定观测到的 $\mathbf{x}_t$ 时, 噪声、干净数据、得分或速度的平均值.

6.2.2 解析扩散模型的训练目标

如节 6.2.1 所示, 四种预测类型的目标函数通常共有如下扩散模型训练模板:

$$\mathcal{L}(\phi) := \mathbb{E}_{\mathbf{x}_0, \epsilon} \underbrace{\mathbb{E}_{p_{\text{time}}(t)}}_{\text{时间分布}} \left[\underbrace{\omega(t)}_{\text{时间加权}} \underbrace{\left\| \text{NN}_\phi(\mathbf{x}_t, t) - (A_t \mathbf{x}_0 + B_t \epsilon) \right\|_2^2}_{\text{均方误差部分}} \right]. \quad (6.2.5)$$

这里, 为提高训练效率并优化扩散模型学习流程, 若干关键设计选择至关重要 (Karras et al., 2022; Lu and Song, 2024):

- (A) 通过 α_t 与 σ_t 确定 $\mathbf{x}_t$ 的前向过程噪声调度;
- (B) NN_ϕ 的预测类型及其相应回归目标 $(A_t \mathbf{x}_0 + B_t \epsilon)$;
- (C) 时间加权函数 $\omega(\cdot) : [0, T] \rightarrow \mathbb{R}_{\geq 0}$;
- (D) 时间分布 p_{time} .

这里详细阐述这四个组成部分, 为随后各节的讨论提供路线图.

(A) 噪声调度 α_t 与 σ_t . 使用者可灵活选择适合其应用的调度, 常见例子总结于表 5.2. 关键在于, 正如式 (6.3.3) 和 (6.3.5) 将证明的那样, 所有形如 $\mathbf{x}_t = \alpha_t \mathbf{x}_0 + \sigma_t \epsilon$ 的仿射流在数学上等价. 具体来说, 借助适当的时间重参数化与空间缩放, 任意此类插值都可变换为典范线性调度 ($\alpha_t = 1 - t$, $\sigma_t = t$) 或三角函数调度 ($\alpha_t = \cos t$, $\sigma_t = \sin t$).

(B) 参数化 NN_ϕ 与训练目标 $A_t \mathbf{x}_0 + B_t \epsilon$. 使用者可灵活选择模型的预测目标：干净信号、噪声、得分或速度预测。如节 6.2.1 所述，所有这些预测类型都有形如下式的共同回归目标

$$\text{回归目标} = A_t \mathbf{x}_0 + B_t \epsilon,$$

其中系数 A_t 和 B_t 依赖于所选预测类型及调度 (α_t, σ_t) 。表 6.1 总结了这些关系。

虽然这四种参数化看起来不同，但式 (6.3.1) 将证明它们可以通过简单代数运算相互转换。此外，式 (6.3.6) 也将表明，式 (6.2.5) 中的平方 ℓ_2 损失项在各种预测类型之间保持梯度等价，仅相差一个只依赖噪声调度 (α_t, σ_t) 的时间加权因子（除 $\omega(t)p_{\text{time}}(t)$ 之外）。

表 6.1: 不同参数化之间的关系汇总。四种参数化在数学上等价，可通过直接的代数变换相互转换。

回归目标 =	A_t	B_t
干净数据	1	0
噪声	0	1
条件得分	0	$-\frac{1}{\sigma_t}$
条件速度	α'_t	σ'_t

(C) 时间分布 $p_{\text{time}}(t)$. 由于训练损失是关于 t 的期望，从 $p_{\text{time}}(t)$ 采样时间，在数学上等价于以 $p_{\text{time}}(t)$ 加权每个 t 的均方误差；这一因子可吸收到已有的时间权重 $\omega(t)$ 中¹。然而，经验证据²表明， $p_{\text{time}}(t)$ 的不同选择会影响表现。因此，我们分别讨论时间分布 $p_{\text{time}}(t)$ 和时间加权函数 $\omega(t)$ 。

¹我们关于时间的总体目标具有如下积分形式

$$\mathcal{L} = \int_0^T \omega(t) \text{mse}(t) dt,$$

其中 $\text{mse}(t)$ 表示每个 t 的类似均方误差的项。若训练时抽取 $t \sim p_{\text{time}}(t)$ ，则通过下式获得 $\mathcal{L}$ 的无偏 Monte Carlo 估计：

$$\hat{\mathcal{L}} = \mathbb{E}_{t \sim p_{\text{time}}} \left[\frac{\omega(t)}{p_{\text{time}}(t)} \text{mse}(t) \right],$$

即采样与加权可通过重要性加权相互转换。

²不过，在实践中，我们使用小批量随机梯度下降，在离散时间集合上近似训练目标。在这种近似下， $p_{\text{time}}(t)$ 的不同选择既改变梯度方差，也改变赋予每个时间步的有效权重。因此，我们分别讨论 $p_{\text{time}}(t)$ （采样）与 $\omega(t)$ （加权）。

时间分布的一个常见选择是 $[0, T]$ 上的均匀分布 (Ho, Jain, and Abbeel, 2020; Song et al., 2020b; Lipman et al., 2022; Liu, 2022). 其他选择包括对数正态分布 (Karras et al., 2022) 以及自适应重要性采样方法 (Song et al., 2021; Kingma et al., 2021).

(D) 时间加权函数 $\omega(t)$. 加权函数的一个常见选择是常数加权 $\omega \equiv 1$ (Ho, Jain, and Abbeel, 2020; Karras et al., 2022; Lipman et al., 2022; Liu, 2022), 也已有自适应加权方案被提出 (Karras et al., 2023). $\omega(t)$ 的某些选择将式 (6.2.5) 变为负对数似然的更紧上界, 有效地将目标改写为最大似然训练. $\omega(t)$ 的重要加权方案包括令 $\omega(t) = g^2(t)$ (Song et al., 2021), 其中 g 是式 (4.1.3) 中的前向 SDE 的扩散系数. 其他方法使用信噪比 (SNR) 加权 (Kingma et al., 2021) 或单调加权函数 (Kingma and Gao, 2023), 其中 $\omega(t)$ 是时间的单调函数.

总体而言, 无论选择何种噪声调度器、预测类型或时间采样分布, 这些因素在理论上最终都影响目标函数中的时间加权. 这种时间加权会影响实际训练景观, 进而影响模型表现.

6.3 扩散模型中的等价性

节 6.2.1 介绍的四种预测类型，将在后文（节 6.3.1）证明在梯度最小化下等价。随后，在节 6.3.3 中拓展这一视角，展示不同前向噪声调度如何通过简单的时间与空间缩放相联系。

6.3.1 四种预测类型等价

首先分析式 (6.2.5) 中组成部分 (B) 的设计选择。

我们已经看到，四种预测类型并非独立选择，而是同一基本量的不同视角。例如，噪声预测与干净数据预测直接相关（节 2.2.4），得分预测与噪声预测也如此（节 3.4）。这一反复出现的模式揭示了更深层的原理：四种参数化都在代数上等价，可通过简单变换相互转换。为精确表述这一联系，我们依据 (Kingma et al., 2021) 给出如下命题，其示意图 6.1。

命题 6.3.1: 参数化的等价性

设分别最小化各自目标的最优预测为

$$\epsilon^*(\mathbf{x}_t, t), \quad \mathbf{x}^*(\mathbf{x}_t, t), \quad \mathbf{s}^*(\mathbf{x}_t, t), \quad \mathbf{v}^*(\mathbf{x}_t, t),$$

它们分别对应于噪声、干净数据、得分和速度参数化，满足以下等价关系：

$$\begin{aligned} \epsilon^*(\mathbf{x}_t, t) &= -\sigma_t \mathbf{s}^*(\mathbf{x}_t, t), \\ \mathbf{x}^*(\mathbf{x}_t, t) &= \frac{1}{\alpha_t} \mathbf{x}_t + \frac{\sigma_t^2}{\alpha_t} \mathbf{s}^*(\mathbf{x}_t, t), \\ \mathbf{v}^*(\mathbf{x}_t, t) &= \alpha'_t \mathbf{x}^* + \sigma'_t \epsilon^* = f(t) \mathbf{x}_t - \frac{1}{2} g^2(t) \mathbf{s}^*(\mathbf{x}_t, t). \end{aligned} \tag{6.3.1}$$

这里， $f(t)$ 与 $g(t)$ 通过引理 4.4.1 与 α_t 和 σ_t 联系起来。此外，这些最小化解满足式 (6.2.1) 至 (6.2.4) 中的恒等式。

命题的证明。

证明与定理 4.2.1 相似，后者分析 DSM 目标下各种匹配损失的全局最优解。详细讨论见节 D.4。

式 (6.3.1) 在四种参数化之间诱导一一转换（在每个 t ，给定前向加噪系数）：

$$\epsilon_\phi(\mathbf{x}_t, t), \quad \mathbf{x}_\phi(\mathbf{x}_t, t), \quad \mathbf{s}_\phi(\mathbf{x}_t, t), \quad \mathbf{v}_\phi(\mathbf{x}_t, t).$$

实践中，我们用一种参数化训练单个网络（例如， ϵ_ϕ ）。然后，通过式 (6.3.1) 中的转换事后定义其他量。




图 6.1: 四种参数化之间的等价关系. $\mathbf{v}$ 预测由 $\mathbf{v}^* = \alpha_t \mathbf{x}^* + \sigma_t \epsilon^*$ 给出, 其中干净数据预测与 ϵ 预测通过 $\mathbf{x}_t = \alpha_t \mathbf{x}^* + \sigma_t \epsilon^*$ 相互转换.

6.3.2 不同参数化下的 PF-ODE

PF-ODE 具有若干等价参数化 (得分、噪声、去噪数据和速度). 虽然原则上可以相互转换, 选择仍会带来实际影响: 它改变向量场的刚性、离散化误差的行为以及优化的难易程度. 对于采用高级 ODE 求解器的快速采样 (见章 9), 实践者通常采用 ϵ 或 $\mathbf{x}$ 预测, 因为它们与求解器输入配合良好, 并减少误差累积. 对于只使用少量函数求值的生成器训练 (见章 11), $\mathbf{x}$ 或 $\mathbf{v}$ 预测通常产生更平滑的目标, 以及更好的步间一致性.

我们写出每种参数化下的 PF-ODE, 并利用 式 (6.3.1) 显式给出转换. 结果汇总于以下命题.

命题 6.3.2: 不同参数化下的 PF-ODE

设 α_t 和 σ_t 为前向扰动调度, 时间导数记作 $\alpha'_t := \frac{d\alpha_t}{dt}$ 与 $\sigma'_t := \frac{d\sigma_t}{dt}$. 则经验 PF-ODE 具有以下等价形式

$$\begin{aligned}
 \frac{d\mathbf{x}(t)}{dt} &= \frac{\alpha'_t}{\alpha_t} \mathbf{x}(t) - \sigma_t \left(\frac{\alpha'_t}{\alpha_t} - \frac{\sigma'_t}{\sigma_t} \right) \epsilon^*(\mathbf{x}(t), t) \\
 &= \frac{\sigma'_t}{\sigma_t} \mathbf{x}(t) + \alpha_t \left(\frac{\alpha'_t}{\alpha_t} - \frac{\sigma'_t}{\sigma_t} \right) \mathbf{x}^*(\mathbf{x}(t), t) \\
 &= \frac{\alpha'_t}{\alpha_t} \mathbf{x}(t) + \sigma_t^2 \left(\frac{\alpha'_t}{\alpha_t} - \frac{\sigma'_t}{\sigma_t} \right) \mathbf{s}^*(\mathbf{x}(t), t) \\
 &= \alpha'_t \mathbf{x}^*(\mathbf{x}(t), t) + \sigma'_t \epsilon^*(\mathbf{x}(t), t) \\
 &= \mathbf{v}^*(\mathbf{x}(t), t).
 \end{aligned} \tag{6.3.2}$$

为看出得分 SDE 的记号, 回顾引理 4.4.1. 若令

$$f(t) = \frac{\alpha'_t}{\alpha_t}, \quad g^2(t) = \frac{d}{dt}(\sigma_t^2) - 2\frac{\alpha'_t}{\alpha_t}\sigma_t^2 = 2\sigma_t\sigma'_t - 2\frac{\alpha'_t}{\alpha_t}\sigma_t^2,$$

则 PF-ODE 可写成熟悉的得分 SDE 形式：

$$\frac{d\mathbf{x}(t)}{dt} = f(t)\mathbf{x}(t) - \frac{1}{2}g^2(t)\mathbf{s}^*(\mathbf{x}(t), t).$$

为具体说明 PF-ODE 如何离散化用于采样，我们将在节 9.2 中给出一种广泛使用的基于扩散的 ODE 采样器——DDIM 方案——的更新规则。这个例子将展示 Euler 离散化如何自然地与 PF-ODE 联系起来。

6.3.3 所有仿射流等价

接下来分析式 (6.2.5) 中组成部分 (A) 的设计选择。

状态层面的等价性。 FM (Lipman et al., 2022) 与 RF (Liu, 2022) 中采用的一种便利的典范插值为

$$\mathbf{x}_t^{\text{FM}} = (1-t)\mathbf{x}_0 + t\boldsymbol{\epsilon} = \mathbf{x}_0 + t(\boldsymbol{\epsilon} - \mathbf{x}_0),$$

其速度为常向量 $\boldsymbol{\epsilon} - \mathbf{x}_0$ 。本小节的关键在于，这种选择表面上的简单性并非本质：任意仿射插值

$$\mathbf{x}_t = \alpha_t \mathbf{x}_0 + \sigma_t \boldsymbol{\epsilon}$$

都可写成典范路径经时间重参数化与缩放后的版本。定义

$$c(t) := \alpha_t + \sigma_t, \quad \tau(t) := \frac{\sigma_t}{\alpha_t + \sigma_t} \quad (c(t) \neq 0).$$

直接进行代数改写，得到

$$\begin{aligned} \mathbf{x}_t &= \alpha_t \mathbf{x}_0 + \sigma_t \boldsymbol{\epsilon} \\ &= (\alpha_t + \sigma_t) \left(\frac{\alpha_t}{\alpha_t + \sigma_t} \mathbf{x}_0 + \frac{\sigma_t}{\alpha_t + \sigma_t} \boldsymbol{\epsilon} \right) \\ &= c(t) \left((1 - \tau(t)) \mathbf{x}_0 + \tau(t) \boldsymbol{\epsilon} \right) = c(t) \mathbf{x}_{\tau(t)}^{\text{FM}}. \end{aligned}$$

因此，每条仿射路径都是典范 FM 路径在变量替换 $t \mapsto \tau(t)$ 与空间缩放 $\mathbf{x} \mapsto c(t)\mathbf{x}$ 下的像。这一等式逐点成立，因而在分布意义下也成立。

对于相应速度，对 $\mathbf{x}_t = c(t)\mathbf{x}_{\tau(t)}^{\text{FM}}$ 应用链式法则：

$$\begin{aligned} \mathbf{v}(\mathbf{x}_t, t) &:= \frac{d}{dt} (\alpha_t \mathbf{x}_0 + \sigma_t \boldsymbol{\epsilon}) \\ &= \frac{d}{dt} (c(t) \mathbf{x}_{\tau(t)}^{\text{FM}}) \\ &= c'(t) \mathbf{x}_{\tau(t)}^{\text{FM}} + c(t) \tau'(t) \frac{d}{ds} \mathbf{x}_s^{\text{FM}} \Big|_{s=\tau(t)} \\ &= c'(t) \mathbf{x}_{\tau(t)}^{\text{FM}} + c(t) \tau'(t) \mathbf{v}^{\text{FM}}(\mathbf{x}_{\tau(t)}^{\text{FM}}, \tau(t)), \end{aligned}$$

因为沿典范路径有 $\mathbf{v}^{\text{FM}}(\mathbf{x}_{\tau}^{\text{FM}}, \tau) = -\mathbf{x}_0 + \boldsymbol{\epsilon}$ 。

我们在以下命题中将上述推导总结为形式化陈述。

命题 6.3.3: 仿射流的等价性

设 $\mathbf{x}_t^{\text{FM}} = (1-t)\mathbf{x}_0 + t\epsilon$, 且 $\mathbf{x}_t = \alpha_t\mathbf{x}_0 + \sigma_t\epsilon$, 其中 $c(t) := \alpha_t + \sigma_t \neq 0$, $\tau(t) := \sigma_t/(\alpha_t + \sigma_t)$. 则

$$\begin{aligned}\mathbf{x}_t &= c(t)\mathbf{x}_{\tau(t)}^{\text{FM}}, \\ \mathbf{v}(\mathbf{x}_t, t) &= c'(t)\mathbf{x}_{\tau(t)}^{\text{FM}} + c(t)\tau'(t)\mathbf{v}^{\text{FM}}(\mathbf{x}_{\tau(t)}^{\text{FM}}, \tau(t)).\end{aligned}\tag{6.3.3}$$

特别地, 所有仿射插值在相差时间重参数化与空间缩放的意义下等价.

与三角函数流的等价性. 另一种广泛使用的仿射流是三角函数插值 (Salimans and Ho, 2021; Albergo, Boffi, and Vanden-Eijnden, 2023; Lu and Song, 2024). 作为具体例子, 我们也说明任意仿射流都可表示为这一形式. 三角函数路径定义为

$$\mathbf{x}_u^{\text{Trig}} := \cos(u)\mathbf{x}_0 + \sin(u)\epsilon.\tag{6.3.4}$$

令 $R_t := \sqrt{\alpha_t^2 + \sigma_t^2}$, 并假定 $R_t > 0$. 选择角度 τ_t 使得

$$\cos \tau_t = \frac{\alpha_t}{R_t}, \quad \sin \tau_t = \frac{\sigma_t}{R_t}.$$

则每个仿射插值 $\mathbf{x}_t = \alpha_t\mathbf{x}_0 + \sigma_t\epsilon$ 都是经缩放和时间重参数化后的三角函数路径:

$$\mathbf{x}_t = \alpha_t\mathbf{x}_0 + \sigma_t\epsilon = R_t \left(\frac{\alpha_t}{R_t}\mathbf{x}_0 + \frac{\sigma_t}{R_t}\epsilon \right) = R_t\mathbf{x}_{\tau_t}^{\text{Trig}}.\tag{6.3.5}$$

二元组 (α_t, σ_t) 是平面上的点. 用 R_t 归一化后, 它落在单位圆上, 确定了角度 τ_t , 进而确定状态 $\mathbf{x}_{\tau_t}^{\text{Trig}}$; 半径 R_t 给出整体尺度.

对 $\mathbf{x}_u^{\text{Trig}}$ 关于 u 求导, 得到其速度,

$$\mathbf{v}_u^{\text{Trig}} = -\sin(u)\mathbf{x}_0 + \cos(u)\epsilon.$$

通过与式 6.3.5 相同的变量替换, 这一关系给出了速度的闭式转换 (其他参数化也可类似处理).

总结以上讨论, 得到如下结论:

结论 6.3.1:

无论调度 (α_t, σ_t) 如何选择, 包括 VE、VP (例如三角函数调度)、FM 或 RF, 仿射插值都可通过适当的时间变量替换与标量缩放相互转换.

四种参数化的训练目标. 设 $\mathbf{x}_t = \alpha_t\mathbf{x}_0 + \sigma_t\epsilon$, 其中 $\sigma_t > 0$, 且 (α_t, σ_t) 可微并满足 $\alpha'_t\sigma_t - \alpha_t\sigma'_t \neq 0$. 考虑理想目标

$$\epsilon^*(\mathbf{x}_t, t) = \mathbb{E}[\epsilon|\mathbf{x}_t], \quad \mathbf{x}_0^*(\mathbf{x}_t, t) = \mathbb{E}[\mathbf{x}_0|\mathbf{x}_t], \quad \mathbf{v}^*(\mathbf{x}_t, t) = \mathbb{E}[\alpha'_t\mathbf{x}_0 + \sigma'_t\epsilon|\mathbf{x}_t].$$

根据命题 6.3.1，它们满足

$$\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t) = -\frac{1}{\sigma_t} \boldsymbol{\epsilon}^*(\mathbf{x}_t, t) = \frac{\alpha_t}{\sigma_t^2} \left(\mathbf{x}_0^*(\mathbf{x}_t, t) - \frac{\mathbf{x}_t}{\alpha_t} \right), \quad \mathbf{v}^* = \alpha_t' \mathbf{x}_0^* + \sigma_t' \boldsymbol{\epsilon}^*.$$

在如下输出头转换下，

$$\mathbf{s}_\phi \equiv -\frac{1}{\sigma_t} \boldsymbol{\epsilon}_\phi \equiv \frac{\alpha_t}{\sigma_t^2} \left(\mathbf{x}_\phi - \frac{\mathbf{x}_t}{\alpha_t} \right),$$

且从速度到得分的转换为

$$\mathbf{s}_\phi = \frac{\alpha_t}{\sigma_t(\alpha_t' \sigma_t - \alpha_t \sigma_t')} \mathbf{v}_\phi - \frac{\alpha_t'}{\sigma_t(\alpha_t' \sigma_t - \alpha_t \sigma_t')} \mathbf{x}_t,$$

逐样本平方损失在相差时变权重的意义下匹配：

$$\begin{aligned} \|\mathbf{s}_\phi - \nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t)\|_2^2 &= \frac{1}{\sigma_t^2} \|\boldsymbol{\epsilon}_\phi - \boldsymbol{\epsilon}^*\|_2^2 \\ &= \frac{\alpha_t^2}{\sigma_t^4} \|\mathbf{x}_\phi - \mathbf{x}_0^*\|_2^2 \\ &= \left(\frac{\alpha_t}{\sigma_t(\alpha_t' \sigma_t - \alpha_t \sigma_t')} \right)^2 \|\mathbf{v}_\phi - \mathbf{v}^*\|_2^2. \end{aligned} \quad (6.3.6)$$

根据命题 6.3.3，任意仿射流 $\mathbf{x}_t = \alpha_t \mathbf{x}_0 + \sigma_t \boldsymbol{\epsilon}$ 都可通过 $\mathbf{x}_t = c(t) \mathbf{x}_{\tau(t)}^{\text{FM}}$ 转换为典范 FM 路径，其中 $c(t) = \alpha_t + \sigma_t$ ， $\tau(t) = \sigma_t / (\alpha_t + \sigma_t)$ 。求导得到

$$\mathbf{v}_\phi(\mathbf{x}_t, t) = c'(t) \mathbf{x}_{\tau(t)}^{\text{FM}} + c(t) \tau'(t) \mathbf{v}_\phi^{\text{FM}}(\mathbf{x}_{\tau(t)}^{\text{FM}}, \tau(t)), \quad \mathbf{x}_{\tau(t)}^{\text{FM}} = \frac{\mathbf{x}_t}{c(t)},$$

$\mathbf{v}^*$ 也满足相同关系。因此，速度损失按下式变换：

$$\begin{aligned} &\|\mathbf{v}_\phi(\mathbf{x}_t, t) - \mathbf{v}^*(\mathbf{x}_t, t)\|_2^2 \\ &= (c(t) \tau'(t))^2 \left\| \mathbf{v}_\phi^{\text{FM}} \left(\frac{\mathbf{x}_t}{c(t)}, \tau(t) \right) - (\mathbf{v}^{\text{FM}})^* \left(\frac{\mathbf{x}_t}{c(t)}, \tau(t) \right) \right\|_2^2. \end{aligned}$$

由以上观察，得到如下结论：

结论 6.3.2:

得分、噪声、干净数据和速度训练目标在理论上等价，仅相差由 (α_t, σ_t) 确定的时变权重（对于速度，还包括涉及 $\mathbf{x}_t$ 的仿射输出头转换）。

6.3.4 （选读）参数化与典范流的概念分析

虽然前面各节已经证明四种参数化在数学上等价且可相互转换，前向仿射噪声注入流也等价于典范形式

$$\mathbf{x}_t^{\text{FM}} = (1 - t) \mathbf{x}_0 + t \boldsymbol{\epsilon},$$

本小节仍将提供进一步的直觉，并分析同时使用 $\mathbf{v}$ 预测参数化与这一典范仿射流的潜在优势。

本小节提出一个简单问题：不同参数化与调度如何塑造模型学习的内容，以及我们采样的方式？我们按三个步骤展开：

1. **回归目标与调度.** 重点解释为什么将 $\mathbf{v}$ 预测与典范线性调度 $(\alpha_t, \sigma_t) = (1-t, t)$ 相结合很自然：它使目标尺度随时间保持稳定，并消除动力学中的曲率效应。
2. **对求解器的影响.** 从概念上考察这一参数化如何与数值积分方案相互作用，Euler 求解器和 Heun 方法等具体例子则留到节 9.2.2 和 9.4.5。

继续之前，先区分两类速度场，以避免歧义。用作可处理训练目标的条件速度定义为

$$\mathbf{v}_t(\mathbf{x}_t|\mathbf{z}) = \mathbf{x}'_t = \alpha'_t \mathbf{x}_0 + \sigma'_t \boldsymbol{\epsilon}, \quad \text{其中 } \mathbf{z} = (\mathbf{x}_0, \boldsymbol{\epsilon}),$$

而在推断时求解 PF-ODE、用于移动样本的理想（边缘化）速度为

$$\mathbf{v}^*(\mathbf{x}, t) = \mathbb{E}[\mathbf{v}_t(\cdot|\mathbf{z})|\mathbf{x}_t = \mathbf{x}].$$

视角 1：为何 $(\alpha_t, \sigma_t) = (1-t, t)$ 是自然的调度. 对时变的 $\rho(t)$ ，记 $\sigma_t := \rho(t)$ 、 $\alpha_t := 1 - \rho(t)$ ，则条件速度变为

$$\mathbf{v}_t(\mathbf{x}_t|\mathbf{z}) = \rho'(t)(\boldsymbol{\epsilon} - \mathbf{x}_0), \quad \text{其中 } \mathbf{z} = (\mathbf{x}_0, \boldsymbol{\epsilon}).$$

单位尺度的回归目标. 对于典范调度 $\rho(t) = t$ ，条件速度 $\mathbf{v}_t(\cdot|\mathbf{z})$ 满足

$$\mathbb{E}[\|\mathbf{v}_t(\cdot|\mathbf{z})\|_2^2] = \mathbb{E}_{\boldsymbol{\epsilon}} \|\boldsymbol{\epsilon}\|_2^2 + \mathbb{E}_{\mathbf{x}_0} \|\mathbf{x}_0\|_2^2 = D + \underbrace{\text{Tr Cov}[\mathbf{x}_0]}_{\text{总方差}} + \underbrace{\|\mathbb{E}\mathbf{x}_0\|_2^2}_{\text{均值}}. \quad (6.3.7)$$

因此，目标幅值的期望不随 t 变化。将数据标准化为零均值和单位协方差（即 $\text{Cov}[\mathbf{x}_0] = \mathbf{I}$ ）后，两个组成部分 $\alpha'_t \mathbf{x}_0$ 与 $\sigma'_t \boldsymbol{\epsilon}$ 对所有 t 的贡献相近，从而避免端点附近的梯度爆炸 / 消失。为理解这一点，考虑扩散的训练目标：

$$\mathcal{L}_{\text{velocity}}(\phi) = \mathbb{E}_t \mathbb{E}_{\mathbf{x}_0, \boldsymbol{\epsilon}} \left[\|\mathbf{v}_\phi(\mathbf{x}_t, t) - \mathbf{v}_t(\mathbf{x}_t|\mathbf{z})\|_2^2 \right].$$

应用链式法则，得到该损失关于模型参数 ϕ 的梯度：

$$\nabla_\phi \mathcal{L}_{\text{velocity}}(\phi) = 2 \mathbb{E}_t \mathbb{E}_{\mathbf{x}_0, \boldsymbol{\epsilon}} \left[\partial_\phi \mathbf{v}_\phi(\mathbf{x}_t, t)^\top (\mathbf{v}_\phi(\mathbf{x}_t, t) - \mathbf{v}_t(\mathbf{x}_t|\mathbf{z})) \right].$$

因此，目标尺度 $\|\mathbf{v}_t(\mathbf{x}_t|\mathbf{z})\|_2$ 影响梯度稳定性：若它在某个 t 塌缩到 0（或发散），则在其他条件相同的情况下，梯度趋于消失（或爆炸）。对于典范选择 $\rho(t) = t$ ，式 (6.3.7) 给出了与 t 无关的目标幅值，因此不会因回归信号而在端点（ $t = 0$ 或 $t = 1$ ）出现塌缩或发散（假定 $\mathbb{E}\|\partial_\phi \mathbf{v}_\phi(\mathbf{x}_t, t)\|^2$ 及任何时间权重均受到控制）。

典范调度与 $\mathbf{v}$ 预测的相互作用. 在仿射路径 $\mathbf{x}_t = \alpha_t \mathbf{x}_0 + \sigma_t \epsilon$ 下, 理想速度分解为

$$\mathbf{v}^*(\mathbf{x}, t) = \alpha'_t \mathbf{x}^*(\mathbf{x}, t) + \sigma'_t \epsilon^*(\mathbf{x}, t),$$

其中 $\mathbf{x}^* = \mathbb{E}[\mathbf{x}_0 | \mathbf{x}_t = \mathbf{x}]$, $\epsilon^* = \mathbb{E}[\epsilon | \mathbf{x}_t = \mathbf{x}]$. 固定 $\mathbf{x}$ 求导, 得到

$$\partial_t \mathbf{v}_t^* = \underbrace{\alpha''_t \mathbf{x}^* + \sigma''_t \epsilon^*}_{\text{调度曲率}} + \alpha'_t \partial_t \mathbf{x}^* + \sigma'_t \partial_t \epsilon^*.$$

采用线性调度 $\alpha_t = 1 - t$, $\sigma_t = t$ 时, 曲率项消失 ($\alpha''_t = \sigma''_t = 0$), 因此 $\mathbf{v}_t^*$ 的时间变化主要反映后验演化 ($\partial_t \mathbf{x}^*, \partial_t \epsilon^*$), 而非调度本身. 这一效果对于 $\mathbf{v}$ 预测尤其清晰: 系数 α'_t, σ'_t 为常数 (-1 与 $+1$), 从而避免在漂移中引入额外的依赖于 t 的缩放. 相比之下, 得分、 $\mathbf{x}_0$ 或 ϵ 参数化往往引入诸如 σ'_t/σ_t 或 α'_t/α_t 的比值, 即使采用线性调度, 这些比值在端点附近也可能剧烈变化. 因此, 虽然原则上并非独有, 线性 $(1-t, t)$ 调度结合 v 预测, 为理想速度提供了特别稳定且清晰的时间依赖关系.

最小化条件能量. 接下来采用更理论化的最优输运视角 (见章 7). 这里, 条件能量化了沿前向路径的条件速度的总期望运动, 即从 $\mathbf{x}_0$ 运动到 ϵ 所需的瞬时移动量 (或动力投入):

$$\mathcal{K}[\rho] := \int_0^1 \mathbb{E}_{\mathbf{x}_0, \epsilon} [\|\mathbf{v}_t(\cdot | \mathbf{z})\|_2^2] dt = \left(D + \text{Tr Cov}[\mathbf{x}_0] + \|\mathbb{E} \mathbf{x}_0\|_2^2 \right) \int_0^1 (\rho'(t))^2 dt.$$

因此, 最小化 $\mathcal{K}[\rho]$ 对应于寻找期望意义下最平滑、能量最低的路径. 对边界条件 $\rho(0) = 0$ 和 $\rho(1) = 1$, Euler-Lagrange 方程 $\rho''(t) = 0$ 给出最小化解 $\rho(t) = t$, 对应于直线条件路径. 这意味着, 在连接 $\mathbf{x}_0$ 和 ϵ 的所有光滑插值中, 典范流 $\rho(t) = t$ 是二者之间最节省能量的运动方式. 命题 7.5.1 将重新讨论这一点, 并作更详细的处理.

关于理想速度的注记. 如果改为计算由边缘速度定义的能量

$$\int_0^1 \mathbb{E}_{\mathbf{x}_t} [\|\mathbf{v}^*(\mathbf{x}_t, t)\|^2] dt,$$

则令 $\mathbf{z} = (\mathbf{x}_0, \epsilon)$, 且 $\mathbf{v}_t(\mathbf{x}_t | \mathbf{z}) = \rho'(t)(\epsilon - \mathbf{x}_0)$, 有

$$\mathbf{v}^*(\mathbf{x}, t) = \mathbb{E}[\mathbf{v}_t(\cdot | \mathbf{z}) | \mathbf{x}_t = \mathbf{x}] = \rho'(t) \mathbb{E}[\epsilon - \mathbf{x}_0 | \mathbf{x}_t = \mathbf{x}];$$

因此, 边缘速度的能量变为

$$\int_0^1 \mathbb{E}_{\mathbf{x}_t \sim p_t} [\|\mathbf{v}^*(\mathbf{x}_t, t)\|_2^2] dt = \int_0^1 \mathbb{E}_{\mathbf{x}_t} [\|\rho'(t) \mathbb{E}[\epsilon - \mathbf{x}_0 | \mathbf{x}_t]\|_2^2] dt = \int_0^1 (\rho'(t))^2 \kappa(t) dt,$$

其中 $\kappa(t) := \mathbb{E}_{\mathbf{x}_t \sim p_t} [\|\mathbb{E}[\epsilon - \mathbf{x}_0 | \mathbf{x}_t]\|_2^2]$.

因此, 边缘最优的调度 $\rho(t)$ 未必是线性的. 当且仅当 $\kappa(t)$ 为常数时, 它才是线性的; 一般情况下, Euler-Lagrange 条件

$$(\kappa(t) \rho'(t))' = 0 \Rightarrow \rho'(t) \propto \frac{1}{\kappa(t)}$$

意味着理想最优调度自适应地重参数化时间. 直观地说, $\kappa(t)$ 量化了由 $\mathbf{x}_t \sim p_t$ 可预测多少标签 ($\epsilon - \mathbf{x}_0$): 当 $\kappa(t)$ 较大时, 理想流减速, 对应于理想速度期望幅值较高的区域; 当 $\kappa(t)$ 较小时, 理想流加速. 因此, 即使条件流采用线性调度 $(1-t, t)$, 相应的边缘化(理想)动力学通常仍是非线性的.

视角 2: 为何速度预测可被认为是采样的自然选择.

$\mathbf{x}$ 、 ϵ 和 $\mathbf{s}$ 预测下 PF-ODE 的半线性形式. 在干净数据、噪声和得分参数化下, 漂移具有半线性形式 (见式 (6.3.2) 中的前三个恒等式):

$$\frac{d\mathbf{x}(t)}{dt} = \underbrace{L(t)\mathbf{x}(t)}_{\text{线性部分}} + \underbrace{\mathbf{N}_\phi(\mathbf{x}(t), t)}_{\text{非线性部分}}, \quad \mathbf{N}_\phi \in \{\mathbf{x}_\phi, \epsilon_\phi, \mathbf{s}_\phi\}.$$

当线性漂移 $L(t)\mathbf{x}(t)$ 在某些方向驱动 $\mathbf{x}(t)$ 变化的速率与非线性部分相差很大时, 系统具有刚性, 即漂移 (关于 $\mathbf{x}$) 的雅可比矩阵

$$\mathbf{J}(\mathbf{x}, t) := L(t) + \nabla_{\mathbf{x}} \mathbf{N}_\phi(\mathbf{x}, t)$$

的特征值实部相差若干数量级 (绝对值越大, 对应的方向越快)³. 例如, $\mathbf{x}(t)$ 的动力学可能同时涉及 “快速线性” 变化和 “慢速非线性” 变化. 在此情形中, 显式求解器必须采用很小的时间步以保持数值稳定.

为处理这种不平衡, 稳定的高阶求解器通常使用积分因子, 解析处理线性项 $L(t)\mathbf{x}$, 仅离散化较慢的非线性余项, 但代价是额外的代数和实现复杂度. 章 9 将专门详细讨论这一主题.

$\mathbf{v}$ 预测下的 PF-ODE. 采用 $\mathbf{v}$ 预测时, 模型直接学习速度场并积分

$$\frac{d\mathbf{x}(t)}{dt} = \mathbf{v}_\phi(\mathbf{x}(t), t) \approx \mathbf{v}^*(\mathbf{x}(t), t).$$

在这一表述中, 显式线性项吸收到单一的学得场内, 因此动力学不再分成独立部分. 步长由学得场 $\mathbf{v}_\phi(\mathbf{x}, t)$ 关于 $\mathbf{x}$ 与 t 的变化平滑性支配, 而非预先指定的标量系数 $L(t)$ 的幅值. 换言之, 可能很快的线性漂移并入一个协调的速度场, 减少时间尺度差异并简化数值积分.

³ 设 PF-ODE 的漂移为 $\mathbf{F}(\mathbf{x}, t) = L(t)\mathbf{x} + \mathbf{N}_\phi(\mathbf{x}, t)$, 并假定 $\mathbf{N}_\phi$ 关于 $\mathbf{x}$ (局部) Lipschitz, 常数为 $\text{Lip}_{\mathbf{N}_\phi}(t)$. 对于邻近状态 $\mathbf{x}, \mathbf{y}$,

$$\|\tilde{\mathbf{f}}(\mathbf{x}, t) - \tilde{\mathbf{f}}(\mathbf{y}, t)\| \leq \underbrace{(\|L(t)\| + \text{Lip}_{\mathbf{N}_\phi}(t))}_{=: C(t)} \|\mathbf{x} - \mathbf{y}\|.$$

等价地, 雅可比矩阵 (关于 $\mathbf{x}$)

$$\mathbf{J}(\mathbf{x}, t) = L(t) + \nabla_{\mathbf{x}} \mathbf{N}_\phi(\mathbf{x}, t)$$

满足 $\|\mathbf{J}(\mathbf{x}, t)\|_{\text{op}} \leq C(t)$ (这里是 $\mathbb{R}^D$ 上欧氏范数诱导的算子范数). 因此, $\mathbf{J}$ 的所有特征值的实部, 其绝对值都由 $C(t)$ 控制. 所以, 较大的 $C(t)$ 意味着较快的局部速率, 显式求解器需要小步长 ($h \lesssim 1/C(t)$).


后文节 9.2.2 将通过一个简单例子，说明 $\mathbf{v}$ 预测在采样过程中的结构简洁性。要得到与 DDIM (Song, Meng, and Ermon, 2020) 相同的 PF-ODE 离散化更新 (DDIM 是扩散建模中最广泛使用的快速采样器之一)，在 ϵ 、 $\mathbf{x}$ 或 $\mathbf{s}$ 参数化下，普通 Euler 步仅近似线性项，而不精确计算它 (见式 (9.1.8))。因此，这些参数化需要更高级的方法，即指数积分器，来分离并精确计算线性项。相比之下， $\mathbf{v}$ 预测的 PF-ODE 漂移中没有独立线性项需要分离，因此普通 Euler 更新自然与 DDIM 表述一致。节 9.4.5 中出现了紧密相关的类比：二阶 DPM-Solver (Lu et al., 2022b) 与经典 Heun 方法一致；对于 $\mathbf{v}$ 预测，这是普通 Heun，而对于 ϵ 、 $\mathbf{x}$ 或 $\mathbf{s}$ 预测，这是指数 Heun。详细讨论留到相应各节。

需要指出的是，生成效果的任何改善 (例如在求解 PF-ODE 时，以更少的模型求值获得更高样本质量)，既取决于 $\mathbf{v}_\phi$ 近似理想速度的准确程度，也取决于采样算法 (包括数值积分器、离散化调度和步长控制) 与它相互作用的有效程度。因此，采用 $\mathbf{v}$ 参数化本身并不保证更好的采样表现。

结论. 虽然 $\mathbf{v}$ 预测与典范线性调度相结合具有某些理论优势，例如恒定的目标幅值和没有调度曲率，但这些性质并不必然使其普遍更优。实践中，模型表现取决于一系列相互作用的因素，包括网络结构、归一化方案、随时间的损失加权、采样器与离散化步数的选择、引导强度、正则化策略、数据缩放和总训练预算。不同数据集与目标可能更适合其他参数化或调度，最佳配置最终是一个应通过验证和消融研究解决的经验问题。

6.4 共同基础：Fokker–Planck 方程

图 6.2: 通过连续性方程连接变分、SDE 与 ODE 表述的统一视角，其中所有 $p_t(\mathbf{x})$ 在共同动力学下演化. 速度场 $\mathbf{v}^*(\mathbf{x}, t) = f(t)\mathbf{x} - \frac{1}{2}g^2(t)\mathbf{s}^*(\mathbf{x}, t)$ 由得分函数 $\mathbf{s}^*(\mathbf{x}, t) := \nabla_{\mathbf{x}} \log p_t(\mathbf{x})$ 支配. 系数 $f(t)$ 、 $g(t)$ 、 σ_t 和 α_t 是预先定义的时变函数， $\gamma(t)$ 则是可调的时变超参数.



本节说明，扩散模型的三种主要视角——变分视角、基于得分的视角和基于流的视角——并非独立构造，而是来自单一的统一原理：支配所选前向过程下密度演化的连续性（Fokker–Planck）方程。

首先，回顾节 4.5 中的分析，它将基于离散核和 Bayes 公式的变分视角，与描述连续动力学的基于得分的 SDE 视角统一起来。我们通过说明变分模型是底层前向与反向 SDE 的一致离散化，建立这一联系。具体而言，通过离散核逐步计算的边缘密度，其演化方式与支配连续时间动力学的 Fokker–Planck 方程一致。这确认了两种视角在本质上等价。

随后将基于流的视角与基于得分的视角联系起来。在节 6.4.1 中，我们说明 ODE 流确定的密度路径，其边缘分布总可由一族随机过程实现。这将确定性流与随机 SDE 纳入同一个族。

这些结果共同将三种视角统一在一个框架下（见图 6.2）。最后，在节 6.5 中总结本章。

6.4.1 基于流的方法与得分 SDE 的联系

扩散模型的一个显著特点在于，不同的动力系统，无论确定性还是随机性，都能描绘相同的概率分布演化。本节揭示节 5.2 中基于 ODE 的流与得分 SDE 之间自然且简洁的联系。具体而言，定义生成 ODE 的速度场可变换为遵循同一 Fokker-Planck 动力学的随机对应物，为确定性插值与随机采样提供有理论依据的桥梁。这给出从 ODE 到 SDE 的连续模型族，它们生成相同的数据分布路径。

考虑连续时间设置，扰动核为

$$p_t(\mathbf{x}_t | \mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t; \alpha_t \mathbf{x}_0, \sigma_t^2 \mathbf{I}),$$

其中 $\mathbf{x}_0 \sim p_{\text{data}}$ 。如常，这一条件分布诱导边缘密度路径 $p_t(\mathbf{x}_t) = \mathbb{E}_{\mathbf{x}_0 \sim p_{\text{data}}} [p(\mathbf{x}_t | \mathbf{x}_0)]$ ，并有 $p_T \approx p_{\text{prior}}$ 。

为匹配这一密度路径，考虑 ODE

$$\frac{d\mathbf{x}(t)}{dt} = \mathbf{v}_t(\mathbf{x}(t)), \quad t \in [0, T], \quad (6.4.1)$$

其中 $\mathbf{v}_t(\mathbf{x}) = \mathbb{E}[\alpha'_t \mathbf{x}_0 + \sigma'_t \epsilon | \mathbf{x}]$ 是式 (5.2.10) 中的理想速度（注意，时间已翻转以遵循扩散模型的约定）。从 $\mathbf{x}(T) \sim p_{\text{prior}}$ 出发，反向积分式 6.4.1，便产生来自 p_0 的样本。

虽然这个 ODE 已足以生成高质量样本，加入随机性可能改善样本多样性。这引出如下问题：

问题 6.4.1. 是否存在一个 SDE，使其动力学从 p_{prior} 出发，产生与式 (6.4.1) 中的 ODE 相同的边缘密度？

以下陈述确认，存在一族时间反向 SDE，诱导与相应 PF-ODE 相同的边缘密度路径。这些 SDE 诱导的密度对于这条路径满足相同的 Fokker-Planck 方程，因此其单时刻边缘分布与预先指定的插值 $\{p_t\}_{t \in [0, T]}$ 重合⁴。

命题 6.4.1: 时间反向 SDE 生成与插值相同的边缘分布

设 $\gamma(t) \geq 0$ 为任意时变系数。考虑时间反向 SDE

$$d\bar{\mathbf{x}}(t) = \left[\mathbf{v}^*(\bar{\mathbf{x}}(t), t) - \frac{1}{2} \gamma^2(t) \mathbf{s}^*(\bar{\mathbf{x}}(t), t) \right] d\bar{t} + \gamma(t) d\bar{\mathbf{w}}(t), \quad (6.4.2)$$

从 $\bar{\mathbf{x}}(T) \sim p_T$ 出发反向演化到 $t = 0$ 。则该过程 $\{\bar{\mathbf{x}}(t)\}_{t \in [0, T]}$ 匹配由 ODE 的密度路径诱导的预先指定的边缘分布 $\{p_t\}_{t \in [0, T]}$ 。这里， $\mathbf{s}(\mathbf{x}, t) := \nabla_{\mathbf{x}} \log p_t(\mathbf{x})$ 是得分函数，它与速度场 $\mathbf{v}(\mathbf{x}, t)$ 通过下式联系：

$$\mathbf{v}^*(\mathbf{x}, t) = f(t)\mathbf{x} - \frac{1}{2} g^2(t) \mathbf{s}^*(\mathbf{x}, t), \quad \mathbf{s}^*(\mathbf{x}, t) = \frac{1}{\sigma_t} \frac{\alpha_t \mathbf{v}^*(\mathbf{x}, t) - \alpha'_t \mathbf{x}}{\alpha'_t \sigma_t - \alpha_t \sigma'_t}. \quad (6.4.3)$$

⁴为完整起见，前向 SDE 表示（此处不需要）为

$$d\mathbf{x}(t) = f(t)\mathbf{x}(t) dt + g(t) d\mathbf{w}(t),$$

其中 $f(t)$ 和 $g(t)$ 通过式 (4.4.2) 与 (α_t, σ_t) 联系起来。

命题的证明.

与式 (6.4.2) 对应的时间反向 Fokker–Planck 方程为

$$\partial_t p = -\nabla \cdot \left([\mathbf{v}^* - \frac{1}{2}\gamma^2 \mathbf{s}^*] p \right) + \frac{1}{2}\gamma^2 \Delta p.$$

利用恒等式 $\nabla \cdot (\mathbf{s}^* p) = \Delta p$ (因为 $\mathbf{s}^* = \nabla \log p$), 二阶项抵消, 得到

$$\partial_t p = -\nabla \cdot (\mathbf{v}^* p),$$

即与 PF-ODE 对应的一阶 (仅有漂移) Fokker–Planck 方程. 因此, 时间反向 SDE 与 ODE 诱导相同的边缘密度路径 $\{p_t\}$. 见 Ma et al. (2024) 的附录 A.2–A.3. ■

即使训练结束后, 也可独立于 α_t 和 σ_t 任意选择超参数 $\gamma(t)$, 因为它不影响速度 $\mathbf{v}(\mathbf{x}, t)$ 或得分 $\mathbf{s}(\mathbf{x}, t)$. 以下给出一些例子:

- 令 $\gamma(t) = 0$, 恢复式 (6.4.1) 中的 ODE.
- 当 $\gamma(t) = g(t)$ 时, 式 (6.4.2) 成为式 (4.1.6) 中的时间反向 SDE, 因为理想速度 $\mathbf{v}(\mathbf{x}, t)$ 满足 (见命题 6.3.1):

$$\mathbf{v}^*(\mathbf{x}, t) = f(t)\mathbf{x} - \frac{1}{2}g^2(t)\mathbf{s}^*(\mathbf{x}, t).$$

- 其他 $\gamma(t)$ 选择也已有研究; 例如, Ma et al. (2024) 选择 $\gamma(t)$, 以最小化 p_{data} 与从 $t = T$ 求解式 (6.4.2) 得到的 $t = 0$ 密度之间的 KL 差距.

沿用得分 SDE 的做法, 训练好的速度场 $\mathbf{v}_{\phi \times}(\mathbf{x}, t)$ 可通过式 (6.4.3) 转换为参数化得分函数 $\mathbf{s}_{\phi \times}(\mathbf{x}, t)$. 将其代入式 (6.4.2), 定义经验时间反向 SDE, 可从 $t = T$ 、 $\bar{\mathbf{x}}(T) \sim p_{\text{prior}}$ 出发进行数值积分来采样.

这一命题突出了扩散模型的显著灵活性: 一旦固定边缘密度路径 $\{p_t\}_{t \in [0, T]}$, 整个动力学族都能重现它, 包括 PF-ODE 与时间反向 SDE:

$$d\bar{\mathbf{x}}(t) = [\mathbf{v}^*(\bar{\mathbf{x}}, t) - \frac{1}{2}\gamma^2(t)\mathbf{s}^*(\bar{\mathbf{x}}, t)] d\bar{t} + \gamma(t) d\bar{\mathbf{w}}(t), \quad \gamma(t) \geq 0.$$

所有这些动力学都满足同一个时间反向 Fokker–Planck 方程, 因此产生相同的边缘演化. 函数 $\gamma(t)$ 连续调节随机性水平, 同时不影响单时刻分布, 揭示了基于确定性流的 ODE 与其随机 SDE 对应物之间的深刻联系, 如图 6.2 所示.

6.5 结束语

本章是我们理论探索的关键，将变分视角、基于得分的视角和基于流的视角综合为单一、连贯的框架。我们说明，这三种看似不同的方法不只是平行发展，而是在深层次和根本上相互联系。

统一建立在两个核心见解之上。第一，识别了所有框架共有的秘诀：将不可处理的边缘训练目标转化为可处理的条件目标的条件化技巧，从而实现稳定、高效的学习。第二，确立了 Fokker-Planck 方程作为支配概率密度演化的普遍规律。三种视角各以自己的方式构造遵循这一基本动力学的生成过程。

此外，我们证明各种模型参数化，即噪声、干净数据、得分或速度预测，都可相互转换。这揭示，预测目标的选择关乎实现与稳定性，而非基本建模差异。最终要点是，现代扩散方法虽然起源多样，却都实现同一个核心原理：学习时变向量场，将简单先验输运到数据分布。

在牢固建立这一统一且有理论依据的基础后，我们可以从基础理论转向扩散模型的实际应用与加速。生成等价于求解微分方程这一核心见解，为控制和优化提供了强大平台。本专著后续各部分将利用这一统一认识，处理关键实际挑战：

1. 第 C 部分着重改进推断时的采样过程。我们将探索如何引导生成轨迹以实现可控生成（章 8），并研究高级数值求解器，以显著加速缓慢的迭代采样过程（章 9）。
2. 第 D 部分将进一步超越迭代求解器，直接学习快速生成器。我们将考察仅需一步或几步就能产生高质量样本的方法，既包括从教师模型蒸馏（章 10），也包括从头训练（章 11）。

在统一了扩散模型是什么和为什么之后，我们现在转向令人振奋且实用的如何做这一前沿。

第 7 章 （选读）扩散模型与最优输运

将一个分布映射为另一个分布（生成为其特例）是一个核心挑战。流匹配通过学习将质量从源分布输运到目标分布的时变速度场来处理它。这自然与输运理论相联系：经典最优输运 (optimal transport) 寻找分布之间代价最小的路径，而其熵正则化形式——薛定谔桥 (Schrödinger bridge) ——则选出相对于布朗运动等参考过程最可能的受控扩散。

本章回顾最优输运、熵正则化最优输运及薛定谔桥的基础，将其作为分布到分布问题的表述。这引出一个核心问题：扩散模型在多大程度上实现了这样的最优输运？它们有两种视角：作为由前向和反向 SDE 定义的随机过程，以及作为由 PF-ODE 给出的确定性过程。随机视角直接对应于熵正则化最优输运，而 PF-ODE 通常不对应任何已知输运目标。这一差距留下一个开放问题：在什么条件下，扩散模型可被视为求解最优输运问题？

7.1 分布到分布转换的序言

扩散模型将终端分布固定为标准高斯分布 p_{prior} 。然而，许多应用需要分布到分布的转换：将源分布 p_{src} 变换为不同的目标分布 p_{tgt} 。例子包括将素描转换为逼真图像，或在艺术风格之间转换。

现代扩散方法提供了实现这一目标的实用途径。SDEdit (Meng et al., 2021b) 等单端点方法从 $t = 0$ 的源图像出发，将其扩散到中间步骤 t ，然后使用目标域的预训练扩散模型反转这一过程。这产生了在风格和内容上匹配目标分布的输出。

Dual Diffusion Bridge (Su et al., 2022) 等双端点方法则通过共享潜在分布连接两个域，该分布通常是 $t = 1$ 的高斯分布。前向概率流 ODE 将样本从 p_{src} 输运到这一潜在空间，而在目标域训练的反向 ODE 将其映射回 p_{tgt} 。除了这些采样时的方法之外，节 5.2 中的流匹配框架提供了基于训练的替代方案：它直接学习 ODE 流，将质量从 p_{src} 连续移动到 p_{tgt} 。

关键在于，分布之间的变换需要的不只是两个分别训练的模型。它需要有理论依据的映射，在两个端点对齐动力学，并以“最便宜”（代价高效）的方式完成。

本节将重点转向这个经典分布到分布问题的数学基础，而不逐一考察众多基于扩散的转换应用。特别地，我们强调最优输运 (OT) 及其熵正则化变体——薛定谔桥 (SB)；理论界长期将它们研究为（数学意义上）代价高效的分布变换的典范表述。

其核心的基本问题是：

问题 7.1.1. 给定两个概率分布，如何以最有效的方式将一个变换为另一个，同时最小化总代价？

这里，代价 $c(\mathbf{x}, \mathbf{y})$ 是非负函数，为从点 $\mathbf{x}$ 移动单位质量到点 $\mathbf{y}$ 赋予惩罚。常见选择是距离平方 $c(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\|^2$ 。

本节作简要概述，阐明包括流匹配在内的基于扩散的方法，如何与经典及正则化最优输运相联系。我们旨在探索的核心问题是：

问题 7.1.2. 扩散模型是否是一种连接 p_{data} 与 p_{prior} 的最优输运；若是，又是在什么意义下？

为回答这一问题，首先在节 7.2 中阐明“最优性”的含义。我们回顾经典最优输运 (OT) 的静态 Monge–Kantorovich 形式 (式 (7.2.1)) 及其动态 Benamou–Brenier 表述 (式 (7.2.3))；在连续性方程约束下最小化动能)，并回顾式 (7.2.5) 中的熵正则化变体（熵正则化 OT），它等价于薛定谔桥问题 (式 (7.2.8))。在动态视角下，OT 诱导满足连续性方程的确定性流，而 SB 诱导受控扩散，其边缘分布按 Fokker–Planck 方程演化。节 7.3 给出这些表述之间的概览。

随后，将讨论分为两部分。首先，在节 7.4 中，解释标准扩散模型采用的固定前向加噪 SDE，本身并不是任意 p_{src} 与 p_{tgt} 之间的薛定谔桥：前向过程是选定的参考扩散，沿时间向前或时间反向的 SDE 通常都不强制与预先指定的目标精确匹配端点。因此，除非显式求解这些端点下的 SB 问题，否则它并非熵正则化 OT 的最优解；但由于固定了一个起点，它是半桥问题的最优解。

第二，在节 7.5 中，回到生成设置，其中 $p_{\text{src}} = p_{\text{prior}}$ （高斯分布）， $p_{\text{tgt}} = p_{\text{data}}$ 。

PF-ODE 通过构造定义了将 p_{prior} 输运到 p_{data} 的确定性映射. 然而, 对于预先指定的输运代价 (例如二次代价 W_2), 这一流通常不是 OT 映射: 它只是许多可行确定性耦合 (coupling) 中的一个, 并不最小化 Benamou–Brenier 作用量. 随后将讨论“整流”过程 (节 5.4.1) 能否得到 OT 映射; 但通常并无这样的理论保证. 因此, 精确刻画扩散模型的 PF-ODE 映射与 OT 的关系, 仍是一个具有挑战性的未解决问题.

7.2 问题设置的分类

本节介绍如何判定从 p_{src} 到 p_{tgt} 输运质量的最“高效”或“最优”方式. 这包括经典最优输运 (OT) 及其熵正则化变体, 后者具有称为薛定谔桥的等价表述. 这一分类提供背景, 有助于后文阐明它们与扩散模型的联系.

7.2.1 最优输运 (OT)

OT 问题的 Monge–Kantorovich (静态) 表述. 固定代价函数 $c: \mathbb{R}^D \times \mathbb{R}^D \rightarrow \mathbb{R}$, 指定将概率质量从 $\mathbf{x}$ 发送到 $\mathbf{y}$ 的费用. 目标是尽可能便宜地将源分布 p_{src} 变换为目标分布 p_{tgt} .

要定义代价, 首先必须知道哪些点对 $(\mathbf{x}, \mathbf{y})$ 被匹配. 这一角色由耦合承担: $\mathbb{R}^D \times \mathbb{R}^D$ 上的联合分布 γ , 其边缘分布为 p_{src} 与 p_{tgt} . 换言之, 抽取 $(\mathbf{x}, \mathbf{y}) \sim \gamma$ 意味着将来自源分布的 $\mathbf{x}$ 与来自目标分布的 $\mathbf{y}$ 匹配. 若 γ 关于 Lebesgue 测度具有密度 $\gamma(\mathbf{x}, \mathbf{y})$, 则边缘约束写作

$$\int_{\mathbb{R}^D} \gamma(\mathbf{x}, \mathbf{y}) \, d\mathbf{y} = p_{\text{src}}(\mathbf{x}), \quad \int_{\mathbb{R}^D} \gamma(\mathbf{x}, \mathbf{y}) \, d\mathbf{x} = p_{\text{tgt}}(\mathbf{y}).$$

即对 $\mathbf{y}$ 积分恢复 $\mathbf{x}$ 的源密度, 而对 $\mathbf{x}$ 积分恢复 $\mathbf{y}$ 的目标密度.

给出两个标准例子来说明:

1. **离散支撑.** 若 p_{src} 与 p_{tgt} 支撑在有限多个点上, 耦合由非负矩阵 (γ_{ij}) 表示, 其行和等于 $p_{\text{src}}(i)$, 列和等于 $p_{\text{tgt}}(j)$. 每个元素 γ_{ij} 是从 i 发送到 j 的质量.
2. **确定性映射.** 若存在可测映射 $\mathbf{T}$ 满足 $\mathbf{T}_\# p_{\text{src}} = p_{\text{tgt}}$, 则 $\gamma = (\mathbf{I}, \mathbf{T})_\# p_{\text{src}}$ 是确定性耦合, 将每个点 $\mathbf{x}$ 直接移动到 $\mathbf{T}(\mathbf{x})$.

耦合 γ 固定后, 输运代价就是这一方案下单位代价的平均值:

$$\int c(\mathbf{x}, \mathbf{y}) \, d\gamma(\mathbf{x}, \mathbf{y}) = \mathbb{E}_{(\mathbf{x}, \mathbf{y}) \sim \gamma} [c(\mathbf{x}, \mathbf{y})].$$

在离散情形中, 它化为 $\sum_{i,j} c_{ij} \gamma_{ij}$, 而在连续设置中, 它成为双重积分. 下文仅关注连续情形.

最优输运问题就是在所有可行耦合中选择使这一期望代价最小的耦合.

$$\text{OT}(p_{\text{src}}, p_{\text{tgt}}) := \inf_{\gamma \in \Gamma(p_{\text{src}}, p_{\text{tgt}})} \int c(\mathbf{x}, \mathbf{y}) \, d\gamma(\mathbf{x}, \mathbf{y}), \quad (7.2.1)$$

其中可行集仅施加边缘约束, 即质量守恒约束:

$$\Gamma(p_{\text{src}}, p_{\text{tgt}}) = \left\{ \gamma \in \mathcal{P}(\mathbb{R}^D \times \mathbb{R}^D) : \int \gamma(\mathbf{x}, \mathbf{y}) \, d\mathbf{y} = p_{\text{src}}(\mathbf{x}), \int \gamma(\mathbf{x}, \mathbf{y}) \, d\mathbf{x} = p_{\text{tgt}}(\mathbf{y}) \right\},$$

其中 $\mathcal{P}(\mathbb{R}^D \times \mathbb{R}^D)$ 表示 $\mathbb{R}^D \times \mathbb{R}^D$ 上所有概率测度的集合.

一个特例：Wasserstein-2 距离. Wasserstein-2 距离是采用二次代价 $c(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\|^2$ 的 Monge–Kantorovich 问题的特殊情形. 它通过下式衡量两个概率分布之间的距离：

$$\mathcal{W}_2^2(p_{\text{src}}, p_{\text{tgt}}) := \inf_{\gamma \in \Gamma(p_{\text{src}}, p_{\text{tgt}})} \mathbb{E}_{(\mathbf{x}, \mathbf{y}) \sim \gamma} [\|\mathbf{x} - \mathbf{y}\|^2].$$

在 p_{src} 与 p_{tgt} 满足适当假设时，Brenier 定理（见定理 7.5.1.1）¹ 保证，二次代价的最优耦合 γ 集中在确定性映射 $\mathbf{T} : \mathbb{R}^D \rightarrow \mathbb{R}^D$ 的图像上. 因此，Wasserstein-2 距离可等价表示为²：

$$\mathcal{W}_2^2(p_{\text{src}}, p_{\text{tgt}}) = \inf_{\substack{\mathbf{T} : \mathbb{R}^D \rightarrow \mathbb{R}^D, \\ \text{满足 } \mathbf{T} \# p_{\text{src}} = p_{\text{tgt}}}} \mathbb{E}_{\mathbf{x} \sim p_{\text{src}}} [\|\mathbf{T}(\mathbf{x}) - \mathbf{x}\|^2]. \quad (7.2.2)$$

这里， $\mathbf{T} \# p_{\text{src}} = p_{\text{tgt}}$ 表示 $\mathbf{T}$ 将 p_{src} 推前为 p_{tgt} ，即对于 $\mathbf{x} \sim p_{\text{src}}$ ，有 $\mathbf{T}(\mathbf{x}) \sim p_{\text{tgt}}$.

因此，Wasserstein-2 距离表示在所有匹配给定边缘分布的耦合或输运映射中，最小的期望平方输运代价. 最优输运映射记为 $\mathbf{T}^*(\mathbf{x})$ ，称为 *Monge* 映射，给出了将 p_{src} 变换为 p_{tgt} 的最有效方式.

OT 的 Benamou–Brenier (动态) 表述. 除了像 Monge–Kantorovich 表述那样静态地直接映射分布，输运还可建模为连续时间流：

$$p_0 := p_{\text{src}} \rightarrow p_t \rightarrow p_1 := p_{\text{tgt}}, \quad t \in [0, 1].$$

这一由 Benamou and Brenier (2000) 提出的最优输运动态表述，寻找光滑速度场 $\mathbf{v}_t(\mathbf{x})$ ，描述 $p_t(\mathbf{x})$ 中的质量如何随时间演化.

Benamou–Brenier 表述³表明，对于二次代价 $c(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\|_2^2$ （即 $\mathcal{W}_2$ 距离），式 (7.2.1) 中静态 OT 问题的最优值等于动能最小化问题的最优值：

$$\mathcal{W}_2^2(p_{\text{src}}, p_{\text{tgt}}) = \min_{\substack{(p_t, \mathbf{v}_t) \text{ 满足 } \partial_t p_t + \nabla \cdot (p_t \mathbf{v}_t) = 0, \\ p_0 = p_{\text{src}}, p_1 = p_{\text{tgt}}}} \int_0^1 \int_{\mathbb{R}^D} \|\mathbf{v}_t(\mathbf{x})\|^2 p_t(\mathbf{x}) \, d\mathbf{x} \, dt \quad (7.2.3)$$

其中，对于每个 $t \in [0, 1]$ ， p_t 都是 $\mathbb{R}^D$ 上的概率分布. 特别地，最优输运流 $p_t(\mathbf{x})$ 遵循 *McCann* 位移插值：

$$\mathbf{T}_t^*(\mathbf{x}) = (1 - t)\mathbf{x} + t\mathbf{T}^*(\mathbf{x}),$$

其中 $\mathbf{T}^*(\mathbf{x})$ 是将 p_{src} 输运为 p_{tgt} 的 OT 映射. 这一线性插值沿直线、以恒定速度移动质量：对于每个 $t \in [0, 1]$ ，有 $p_t = \mathbf{T}_t^* \# p_{\text{src}}$.

¹Brenier 定理讨论二次代价下最优输运映射的存在性及结构. 特别地，若 p_{src} 不向维数至多为 $D - 1$ 的集合赋予质量，则最优输运映射 $\mathbf{T}^*$ 唯一存在.

² $\mathcal{W}_2$ 距离有三种常用表述：Monge 表述（基于最优输运映射）、Kantorovich 表述（基于耦合）以及 Benamou–Brenier 动态表述（见式 (7.2.3)）. 它们在适当正则性条件下等价.

³Benamou–Brenier 表述说明如何通过连续测度路径和速度上最小化动能来计算 $\mathcal{W}_2$ 距离.




图 7.1: **OT 动态视角的示意图**. 插值 p_t^{OT} 随时间连续演化, 提供了将 p_{src} 确定性映射为 p_{tgt} 的最低代价运输方案 (McCann 位移插值) .

最优运输映射 $\mathbf{T}^*$ 满足 *Monge–Ampère* 方程:

$$p_{\text{tgt}}(\nabla\psi(\mathbf{x})) \det(\nabla^2\psi(\mathbf{x})) = p_{\text{src}}(\mathbf{x}), \quad (7.2.4)$$

其中, 根据 Brenier 定理, 对某个凸函数 ψ 有 $\mathbf{T}^*(\mathbf{x}) = \nabla\psi(\mathbf{x})$. 然而, 这个非线性偏微分方程通常难以显式求解. 注意, 这恰好是归一化流所用的变量替换关系 (参见式 (5.0.1)): 流参数化具有可处理雅可比行列式的可逆运输映射, 但通常不施加势函数梯度结构 $\mathbf{T}^* = \nabla\psi$; 因此, 训练好的流可能与 Brenier / OT 映射存在很大差异.

7.2.2 熵正则化最优运输 (EOT)

为具体说明 EOT 的动机, 考虑由样本构建的经验分布. 假设 p_{src} 支撑在点 $\{\mathbf{x}^{(i)}\}_{i=1}^n \subset \mathbb{R}^D$ 上, 权重为 a_i , 而 p_{tgt} 支撑在点 $\{\mathbf{y}^{(j)}\}_{j=1}^n \subset \mathbb{R}^D$ 上, 权重为 b_j . 耦合是 $n \times n$ 非负矩阵 $\gamma = (\gamma_{ij})$, 其行和匹配 a , 列和匹配 b . 每个元素 γ_{ij} 表示从 $\mathbf{x}^{(i)}$ 输运到 $\mathbf{y}^{(j)}$ 的质量⁴.

⁴经验 (离散) 测度提供了连续分布的有理论依据的代理. 当基础代价为 $c(x, y) = d(x, y)^p$ (因而 OT 值等于 W_p^p) 且测度具有有限 p 阶矩时, 经验测度以定量速率在 W_p 中收敛到总体; 见 Fournier and Guillin

为何正则化 OT？ 这一离散设置下的经典 OT（在连续表述式 (7.2.1) 中取计数测度得到）归结为在所有可行耦合上最小化

$$\min_{\gamma=(\gamma_{ij})} \sum_{i,j} C_{ij} \gamma_{ij},$$

其中 $\gamma = (\gamma_{ij})$ 遍历所有可行耦合， $C_{ij} = c(\mathbf{x}^{(i)}, \mathbf{y}^{(j)})$ 是将单位质量从源点 $\mathbf{x}^{(i)}$ 移动到目标点 $\mathbf{y}^{(j)}$ 的代价，基础代价预先给定为 $c: \mathbb{R}^D \times \mathbb{R}^D \rightarrow \mathbb{R}_{\geq 0}$ （例如 $c(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\|_2^2$ ）。有两个主要问题：

1. **非唯一性与不稳定性：** 最小化解 γ^* 未必唯一。例如，若两个输运方案达到相同最小代价，求解器可能选取任一个。因此，输入 (a, b, C) 的小变化（例如移动一个样本、调整权重或轻微扰动代价）可能造成解的突然跳变。
2. **计算代价高：** 这是具有 n^2 个变量和 $2n$ 个约束的线性规划问题。实用求解器（例如匈牙利算法、网络单纯形法 (Peyré, Cuturi, et al., 2019)）的复杂度通常为 $\mathcal{O}(n^3)$ ，对于较大的 n 不可行。

为克服这些瓶颈，EOT 目标在经典 OT 问题中引入由参数 $\varepsilon > 0$ 控制的正则项：

$$\text{EOT}_{\varepsilon}(p_{\text{src}}, p_{\text{tgt}}) := \min_{\gamma \in \Gamma(p_{\text{src}}, p_{\text{tgt}})} \int c(\mathbf{x}, \mathbf{y}) d\gamma(\mathbf{x}, \mathbf{y}) + \varepsilon \mathcal{D}_{\text{KL}}(\gamma \| M). \quad (7.2.5)$$

参考测度 M 通常选为边缘分布的乘积 $p_{\text{src}} \otimes p_{\text{tgt}}$ 。KL 散度项与输运方案 γ 的 Shannon 熵直接相关：

$$\mathcal{D}_{\text{KL}}(\gamma \| p_{\text{src}} \otimes p_{\text{tgt}}) = -\mathcal{H}(\gamma) + \text{常数},$$

其中 $\mathcal{H}(\gamma) := -\int \gamma(\mathbf{x}, \mathbf{y}) \log \gamma(\mathbf{x}, \mathbf{y}) d\mathbf{x} d\mathbf{y}$ 。

加入这一正则项带来若干理论及实践优势，下面简述这些优势：

熵正则项为何有效？

1. **质量扩散。** 由于 $t \mapsto t \log t$ 是凸函数，且在较大的 t 处快速增长，最小化 $\int \gamma \log \gamma$ 会惩罚尖峰型耦合（某些 $\gamma(\mathbf{x}, \mathbf{y})$ 很大，而大部分接近零）。在总质量固定为 $\int \gamma = 1$ 时，它偏好 $\gamma(\mathbf{x}, \mathbf{y})$ 在 $(\mathbf{x}, \mathbf{y}) \in \mathbb{R}^D \times \mathbb{R}^D$ 上分布更均匀的方案。等价地，最大化 Shannon 熵鼓励更高的“不确定性”（弥散性）。
2. **严格凸性与唯一性。** 由于 $\mathcal{H}$ 严格凹，式 (7.2.5) 中的目标关于 γ 严格凸，从而产生唯一的最小化解 γ_{ε}^* ，并连续依赖于 $(p_{\text{src}}, p_{\text{tgt}}, c)$ 。

(2015) 及 Peyré, Cuturi, et al. (2019) 中的概述。

3. **Sinkhorn 形式与正性.** 在温和条件下⁵, 最优解具有薛定谔 / Sinkhorn 形式

$$\gamma_\varepsilon^*(\mathbf{x}, \mathbf{y}) = u(\mathbf{x}) \exp\left(-\frac{c(\mathbf{x}, \mathbf{y})}{\varepsilon}\right) v(\mathbf{y}) p_{\text{src}}(\mathbf{x}) p_{\text{tgt}}(\mathbf{y}),$$

其中缩放函数 u, v 为正 (在相差一个全局因子的意义下唯一). 实践中, 连续表述用有限样本近似, 将 EOT 化为有限 (采样的) Sinkhorn 迭代. 熵正则化目标严格凸, 缩放算法 (Sinkhorn/IPFP) 能够高效求解它 (Sinkhorn, 1964; Cuturi, 2013). 对于每个边缘分布具有 n 个支撑点的稠密问题 ($n \times n$ 核), 每次 Sinkhorn 迭代花费 $\mathcal{O}(n^2)$ 时间和 $\mathcal{O}(n^2)$ 内存, 使方法更可扩展且实用 (Altschuler, Niles-Weed, and Rigollet, 2017).

4. **ε 的极限.** 当 $\varepsilon \rightarrow 0$ 时, 最优方案 γ_ε^* 越来越集中, 趋于 (可能奇异的) 经典 OT 耦合 (节 7.3.2 将重新讨论这一联系). 当 ε 增大时, γ_ε^* 逐渐弥散, 趋于独立耦合 $p_{\text{src}} \otimes p_{\text{tgt}}$.

7.2.3 薛定谔桥 (SB)

SB 的 KL 表述. 由 Erwin Schrödinger 在 20 世纪 30 年代提出的薛定谔桥 (SB) 问题, 提出如下问题. 假设粒子按布朗运动等简单参考动力学运动. 现在设想, 我们在两个时刻观测粒子: 在 $t = 0$ 时, 其分布为 p_{src} , 而在 $t = 1$ 时为 p_{tgt} . 在连接这两个分布的所有可能随机过程中, 哪一个偏离参考动力学最少? 这里, “偏离” 用 KL 散度衡量, 因此 SB 问题的解, 就是将布朗运动变形为满足预先指定的边界条件的过程的最可能方式.

为精确表述, 令 $\mathbf{x}_{0:T} := \{\mathbf{x}_t\}_{t \in [0, T]}$ 表示过程的完整轨迹. 用 P 表示轨迹的分布, 即整个样本路径上的概率分布. P 的时刻 t 边缘分布记为 p_t (或 P_t), 它描述单个时刻的状态 $\mathbf{x}_t$ 的分布. 形式化地, 对于可测集合 $A \subseteq \mathbb{R}^D$,

$$p_t(A) = P(\mathbf{x}_t \in A).$$

换言之, 可将 p_t 视为从 P 采样许多完整轨迹, 再收集时刻 t 的状态得到的经验分布——例如, 若状态为一维, 可用直方图表示.

考虑由 SDE 支配的参考扩散 $\{\mathbf{x}_t\}_{t \in [0, T]}$:

$$d\mathbf{x}_t = \mathbf{f}(\mathbf{x}_t, t) dt + g(t) d\mathbf{w}_t, \quad (7.2.6)$$

其中 $\mathbf{f}: \mathbb{R}^D \times [0, T] \rightarrow \mathbb{R}^D$, $g: [0, T] \rightarrow \mathbb{R}$, 且 $\{\mathbf{w}_t\}_{t \in [0, T]}$ 为标准布朗运动. 令 R 表示完整轨迹 $\mathbf{x}_{0:T} := \{\mathbf{x}_t\}_{t \in [0, T]}$ 的路径分布 (联合分布); 这个 R 将用作参考轨迹分布.

在这一记号下, 薛定谔桥 (SB) 问题寻找轨迹分布 P , 使其在匹配预先指定端点边缘分布的同时, 在 KL 散度意义下最接近 R :

$$\text{SB}(p_{\text{src}}, p_{\text{tgt}}) := \min_P \mathcal{D}_{\text{KL}}(P \| R) \quad \text{满足} \quad P_0 = p_{\text{src}}, \quad P_T = p_{\text{tgt}}. \quad (7.2.7)$$

最优解 P^* 依赖于选定的参考过程 R .




图 7.2: **SB 随机控制视角的示意图**. 桥寻找连接 p_{src} 与 p_{tgt} 、同时偏离参考过程最少的随机路径.

SB 的随机控制视角. 除了在式 (7.2.7) 中对任意路径分布 P 进行优化之外, 更易处理的方法是以参考动力学为基准, 允许其发生漂移. 为此, 引入时变漂移 $\mathbf{v}_t(\mathbf{x}_t)$, 扰动参考过程并生成一族候选轨迹分布. 所得动力学具有受控扩散的形式:

$$d\mathbf{x}_t = [\mathbf{f}(\mathbf{x}_t, t) + \mathbf{v}_t(\mathbf{x}_t)] dt + g(t) d\mathbf{w}_t,$$

其中 $\mathbf{v}_t: \mathbb{R}^D \rightarrow \mathbb{R}^D$ 是随后要优化的漂移 (式 (7.2.8)). 在标准可积性条件 (例如 Novikov 条件) 下, 根据 Girsanov 定理 (见节 C.2.1), 受控分布 P 与参考 R 之间的 KL 散度具有动态 (动能) 形式

$$\mathcal{D}_{\text{KL}}(P \| R) = \mathbb{E}_P \left[\frac{1}{2} \int_0^T \frac{\|\mathbf{v}_t(\mathbf{x}_t)\|^2}{g^2(t)} dt \right] = \frac{1}{2} \int_0^T \int_{\mathbb{R}^D} \frac{\|\mathbf{v}_t(\mathbf{x})\|^2}{g^2(t)} p_t(\mathbf{x}) d\mathbf{x} dt,$$

其中 p_t 是受控过程下 $\mathbf{x}_t$ 的时刻 t 边缘分布. 第二个等号由全期望公式得到.

因此, SB 问题可改写为: 在将过程从 $t = 0$ 时的 p_{src} 引导到 $t = T$ 时的 p_{tgt} 的所

⁵假设 $c < \infty$ 对 $p_{\text{src}} \otimes p_{\text{tgt}}$ 几乎处处成立, 且边缘核积分有限且为正. 为简洁起见, 重点考虑 γ_ε^* 、 p_{src} 和 p_{tgt} 关于 Lebesgue 测度具有密度的情形.

有可行漂移 $\mathbf{v}_t$ 上, 最小化期望控制能量 (Dai Pra, 1991; Pra and Pavon, 1990; Pavon and Wakolbinger, 1991; Chen, Georgiou, and Pavon, 2016). 这导出随机控制表述:

$$\begin{aligned} & \text{SB}_\varepsilon(p_{\text{src}}, p_{\text{tgt}}) \\ &= \min_{\substack{\mathbf{v}_t \text{ 满足 } d\mathbf{x}_t = [\mathbf{f}(\mathbf{x}_t, t) + \mathbf{v}_t(\mathbf{x}_t)] dt + g(t) d\mathbf{w}_t, \\ \mathbf{x}_0 \sim p_{\text{src}}, \mathbf{x}_T \sim p_{\text{tgt}}}} \frac{1}{2} \int_0^T \int_{\mathbb{R}^D} \frac{\|\mathbf{v}_t(\mathbf{x})\|^2}{g^2(t)} p_t(\mathbf{x}) d\mathbf{x} dt, \end{aligned} \quad (7.2.8)$$

关键在于, 端点分布 p_{src} 与 p_{tgt} 任意; 控制 $\mathbf{v}_t$ 的选择正是在尽可能接近 (KL 散度意义下) 参考过程 R 的同时, 在这些边缘分布之间“搭桥”, 连接参考动力学.

一种特殊的布朗参考过程. 式 (7.2.8) 类似于式 (7.2.3) 中 OT 的 Benamou–Brenier 表述, 尤其当参考过程 R^ε ($\varepsilon > 0$) 选为布朗运动时:

$$d\mathbf{x}_t = \sqrt{\varepsilon} d\mathbf{w}_t,$$

此时 $\mathbf{f} \equiv \mathbf{0}$ 、 $g(t) \equiv \sqrt{\varepsilon}$.

在此设置中, SB 问题寻找路径分布 P , 使其在匹配端点边缘分布的同时, 在 KL 散度意义下最接近布朗参考 R^ε :

$$\text{SB}_\varepsilon(p_{\text{src}}, p_{\text{tgt}}) := \min_P \mathcal{D}_{\text{KL}}(P \| R^\varepsilon) \quad \text{满足} \quad P_0 = p_{\text{src}}, P_T = p_{\text{tgt}}. \quad (7.2.9)$$

等价的随机控制表述变为

$$\text{SB}_\varepsilon(p_{\text{src}}, p_{\text{tgt}}) = \min_{\substack{\mathbf{v}_t \text{ 满足 } d\mathbf{x}_t = \sqrt{\varepsilon} d\mathbf{w}_t, \\ \mathbf{x}_0 \sim p_{\text{src}}, \mathbf{x}_T \sim p_{\text{tgt}}}} \frac{1}{2\varepsilon} \int_0^T \int_{\mathbb{R}^D} \|\mathbf{v}_t(\mathbf{x})\|^2 p_t(\mathbf{x}) d\mathbf{x} dt. \quad (7.2.10)$$

为何需要指定参考分布? 与经典 OT 不同, SB 问题由于其随机性而需要参考分布. 在 OT 中, 代价函数 (例如 $c(\mathbf{x}, \mathbf{y}) \propto \|\mathbf{x} - \mathbf{y}\|^2$) 隐式定义了唯一、确定性的测地路径, 因此无需参考过程. 相比之下, SB 设置允许无穷多个连接边缘分布的随机过程, 并不存在内在的“自然”路径概念. 参考测度 R 编码系统底层的物理或几何结构 (例如布朗运动), 并定义基于 KL 的优化目标 $\mathcal{D}_{\text{KL}}(P \| R)$; 缺少它, 就无法定义最优性.

耦合偏微分方程刻画. 描述 SB 解的一种便利方式, 是使用两个时空势函数 $\Psi(x, t)$ 与 $\hat{\Psi}(x, t)$. 令 p_t^{SB} 表示式 (7.2.7) 中的最优轨迹分布 P^* 在时刻 $t \in [0, T]$ 的边缘分布. 则有对称分解 (Dai Pra, 1991)

$$p_t^{\text{SB}}(x) = \Psi(x, t) \hat{\Psi}(x, t), \quad (7.2.11)$$

其中 Ψ 与 $\hat{\Psi}$ 求解 (线性) 薛定谔系统 (Caluya and Halder, 2021; Chen, Georgiou, and Pavon, 2021; Chen, Liu, and Theodorou, 2022):

$$\begin{aligned}\frac{\partial \Psi}{\partial t}(\mathbf{x}, t) &= -\nabla_{\mathbf{x}} \Psi(\mathbf{x}, t) \cdot \mathbf{f}(\mathbf{x}, t) - \frac{g^2(t)}{2} \Delta_{\mathbf{x}} \Psi(\mathbf{x}, t), \\ \frac{\partial \hat{\Psi}}{\partial t}(\mathbf{x}, t) &= -\nabla_{\mathbf{x}} \cdot (\hat{\Psi}(\mathbf{x}, t) \mathbf{f}(\mathbf{x}, t)) + \frac{g^2(t)}{2} \Delta_{\mathbf{x}} \hat{\Psi}(\mathbf{x}, t)\end{aligned}\quad (7.2.12)$$

满足约束

$$\Psi(\mathbf{x}, 0) \hat{\Psi}(\mathbf{x}, 0) = p_{\text{src}}(\mathbf{x}), \quad \Psi(\mathbf{x}, T) \hat{\Psi}(\mathbf{x}, T) = p_{\text{tgt}}(\mathbf{x}).$$

沿时间向前的薛定谔桥 SDE. 一旦知道 Ψ , 最优动力学就是由时空因子 Ψ 倾斜后的参考扩散:

$$d\mathbf{x}_t = [\mathbf{f}(\mathbf{x}_t, t) + g^2(t) \nabla_{\mathbf{x}} \log \Psi(\mathbf{x}_t, t)] dt + g(t) d\mathbf{w}_t, \quad \mathbf{x}_0 \sim p_{\text{src}}. \quad (7.2.13)$$

令 Q 表示式 (7.2.13) 的轨迹分布 (因此, 根据式 (7.2.11) 和 (7.2.12), $Q_0 = p_{\text{src}}, Q_T = p_{\text{tgt}}$) . 则 $Q = P^*$, 而式 (7.2.8) 的最小化解 $\mathbf{v}^*$ 为 (见 (Chen, Georgiou, and Pavon, 2021) 的第 4.6 节):

$$\mathbf{v}_t^*(\mathbf{x}) = g^2(t) \nabla_{\mathbf{x}} \log \Psi(\mathbf{x}, t).$$

也就是说, 漂移修正 $g^2 \nabla_{\mathbf{x}} \log \Psi$ 恰好是匹配端点边缘分布所需的、对参考过程的最小 KL 扰动.

时间反向薛定谔桥 SDE. 同一个最优路径分布也可沿时间反向生成. 为看出时间反向漂移的形式, 可在概念上使用扩散的标准时间反演恒等式:

$$\mathbf{b}^-(\mathbf{x}, t) = \mathbf{b}^+(\mathbf{x}, t) - g^2(t) \nabla_{\mathbf{x}} \log p_t^{\text{SB}}(\mathbf{x}),$$

其中 $\mathbf{b}^+ = \mathbf{f} + g^2 \nabla \log \Psi$, $p_t = \Psi \hat{\Psi}$. 这给出

$$\mathbf{b}^-(\mathbf{x}, t) = \mathbf{f}(\mathbf{x}, t) - g^2(t) \nabla_{\mathbf{x}} \log \hat{\Psi}(\mathbf{x}, t).$$

因此, 时间反向 SDE 为

$$d\mathbf{x}_t = [\mathbf{f}(\mathbf{x}_t, t) - g^2(t) \nabla_{\mathbf{x}} \log \hat{\Psi}(\mathbf{x}_t, t)] dt + g(t) d\bar{\mathbf{w}}_t, \quad \mathbf{x}_T \sim p_{\text{tgt}}. \quad (7.2.14)$$

等价地, 用 $\mathbf{y}_\tau := \mathbf{x}_{T-\tau}$ 重参数化时间, 使 τ 从 0 增加到 T . 则 $\mathbf{y}_\tau$ 从 $\mathbf{y}_0 \sim p_{\text{tgt}}$ 出发, 沿 τ 向前演化为

$$\begin{aligned}d\mathbf{y}_\tau &= [-\mathbf{f}(\mathbf{y}_\tau, T-\tau) + g^2(T-\tau) \nabla_{\mathbf{y}} \log \hat{\Psi}(\mathbf{y}_\tau, T-\tau)] d\tau \\ &\quad + g(T-\tau) d\mathbf{w}_\tau.\end{aligned}\quad (7.2.15)$$

在式 (7.2.8) 的时间反向随机控制表述中 (反转时钟后采用相同二次能量):

$$\min_{\substack{\mathbf{u}_\tau \text{ 满足 } d\mathbf{y}_\tau = [-\mathbf{f}(\mathbf{y}_\tau, T-\tau) + \mathbf{u}_\tau(\mathbf{y}_\tau)] d\tau + g(T-\tau) d\mathbf{w}_\tau, \\ \mathbf{y}_0 \sim p_{\text{tgt}}, \mathbf{y}_T \sim p_{\text{src}}}} \frac{1}{2} \int_0^T \int_{\mathbb{R}^D} \frac{\|\mathbf{u}_\tau(\mathbf{y})\|^2}{g^2(T-\tau)} p_{T-\tau}(\mathbf{y}) d\mathbf{y} d\tau. \quad (7.2.16)$$

最优控制为

$$\mathbf{u}_t^*(\mathbf{x}) = -g^2(t) \nabla_{\mathbf{x}} \log \hat{\Psi}(\mathbf{x}, t).$$

前向与反向描述都产生同一个最优路径分布 P^* ，通过下式联系

$$\nabla \log p_t^{\text{SB}} = \nabla \log \Psi + \nabla \log \hat{\Psi}, \quad \mathbf{b}^- = \mathbf{b}^+ - g^2 \nabla \log p_t^{\text{SB}},$$

因此，它们的边缘分布在每个时刻都与 p_t^{SB} 重合。额外漂移项 $g^2 \nabla \log \Psi$ （前向）与 $-g^2 \nabla \log \hat{\Psi}$ （时间反向）充当控制力，引导参考扩散匹配端点边缘分布，同时在相对熵意义下保持最接近参考过程。


耦合偏微分方程方法的实际障碍。 要基于式 (7.2.14) 构造生成过程，必须求解式 (7.2.12) 中的耦合偏微分方程，以获得后向薛定谔势 $\hat{\Psi}$ 。然而，即使在低维设置中，这些方程也极难求解，使其在生成建模中的直接应用面临挑战。为绕过这一困难，若干工作提出了其他策略：利用得分 SDE 技术，迭代求解每个半桥问题 ($p_{\text{tgt}} \leftarrow p_{\text{src}}$ 与 $p_{\text{tgt}} \rightarrow p_{\text{src}}$) (De Bortoli et al., 2021)；优化替代似然界 (Chen, Liu, and Theodorou, 2022; Liu et al., 2023)；或基于样本对 $(\mathbf{x}_0, \mathbf{x}_T) \sim p_{\text{src}} \otimes p_{\text{tgt}}$ 下后验 $\mathbf{x}_t | \mathbf{x}_0, \mathbf{x}_T$ 的解析解，设计无需模拟的训练 (Liu et al., 2023)。这里不深入技术细节，而在节 7.4 中简要讨论扩散模型与 SB 的联系。

7.2.4 全局推前与局部动力学：深度生成模型的 OT 类比

从最优输运视角（式 (7.2.1)），可以利用深度生成模型学习从简单先验到数据的输运（推前）映射，即 $\mathbf{G}_{\phi \# p_{\text{prior}}} \approx p_{\text{data}}$ 。虽然 $\mathbf{G}_{\phi}$ 通常不与最优输运映射重合（在适当条件下施加 OT 目标的工作 (Genevay, Peyré, and Cuturi, 2018; Onken et al., 2021) 除外），Benamou–Brenier 表述（式 (7.2.3)）仍提供了互补的动态视角。它并不直接学习单个全局映射，而是将输运描述为由时变局部向量场生成的连续流，描绘 p_{prior} 与 p_{data} 之间的光滑路径。这一动态表述对应于静态薛定谔桥问题（式 (7.2.7)）及其随机控制对应物（式 (7.2.8)）之间的关系，其中最优耦合实现为受控扩散过程。生成建模中也出现了类似类比：GAN 或 VAE 等标准深度生成模型学习全局推前映射，而扩散模型学习驱动生成动力学的时变局部向量场。

7.3 最优输运各变体表述之间的关系

图 7.3: 代价 $c(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\|_2^2$ 下最优输运各变体及 SB 中参考 R^ε 之间的关系. 总结如下等价关系: (i) SB_ε (随机控制) $\Leftrightarrow \text{SB}_\varepsilon$ (静态表述), 其中 p_t 为路径测度 P 的时刻 t 边缘分布; (ii) SB_ε (静态表述) $\Leftrightarrow \text{EOT}_\varepsilon$ (见节 7.3.1); (iii) EOT_ε (静态表述) $\Leftrightarrow \text{OT}_\varepsilon$ (静态) (见节 7.3.2); (iv) SB_ε (随机控制) $\Leftrightarrow \text{OT}$ (动态) (见节 7.3.3) .



深入技术细节之前, 先阐明最优输运的不同表述及其熵正则化如何相联系, 这会很有帮助. 概括而言, 可将这些问题视为相关的 (关系图见图 7.3):

(i) 采用由布朗运动给出的特定参考 R^ε 的 SB 问题 SB_ε

$$d\mathbf{x}_t = \sqrt{\varepsilon} d\mathbf{w}_t$$

等价于其静态表述: 演化的边缘分布 p_t 恰好是最优路径测度 P 的时刻 t 截面 (见节 7.2.3);

(ii) SB_ε 的静态表述直接联系熵正则化 OT 问题 EOT_ε (见节 7.3.1);

(iii) EOT_ε 又可联系回熵正则化 OT 的静态表述 OT_ε (见节 7.3.2);

(iv) SB_ε 的随机控制视角也可联系经典 OT 的动态表述 (见节 7.3.3) .

这些非平凡关系共同提供了随机控制、熵正则化及经典 OT 框架的简明概览.

7.3.1 SB 与 EOT (对偶) 等价

本节提出两种互补视角, 说明 SB 本质上等价于 EOT. 经典最优输运产生单个确定性映射, 而 SB 产生粒子的随机流: 质量以概率方式输运, 边缘分布按类似扩散的动力学演化.

从静态视角, SB 与 EOT 一致, 目标是寻找平衡输运代价与熵的两个端点分布之间的耦合. 从动态视角, SB 描述在匹配所需端点的同时, 尽可能接近简单参考过程 (例如布朗运动) 的受控扩散过程. 每种视角都独立确立了等价性, 为将 SB/EOT 理解为分布到分布变换的典范表述, 提供了两种一致方式.

静态薛定谔桥. 令

$$\tilde{R}^\varepsilon(\mathbf{x}, \mathbf{y}) := \frac{1}{Z_\varepsilon} e^{-c(\mathbf{x}, \mathbf{y})/\varepsilon} p_{\text{src}}(\mathbf{x}) p_{\text{tgt}}(\mathbf{y}),$$

归一化常数为:

$$Z_\varepsilon := \iint e^{-c(\mathbf{x}, \mathbf{y})/\varepsilon} p_{\text{src}}(\mathbf{x}) p_{\text{tgt}}(\mathbf{y}) d\mathbf{x} d\mathbf{y}.$$

则熵正则化 OT 目标

$$\min_{\gamma \in \Gamma(p_{\text{src}}, p_{\text{tgt}})} \left\{ \int c d\gamma + \varepsilon \mathcal{D}_{\text{KL}}(\gamma \| p_{\text{src}} \otimes p_{\text{tgt}}) \right\} = \varepsilon \min_{\gamma \in \Gamma(p_{\text{src}}, p_{\text{tgt}})} \mathcal{D}_{\text{KL}}(\gamma \| \tilde{R}^\varepsilon) - \varepsilon \log Z_\varepsilon, \quad (7.3.1)$$

因此它 (在相差加法常数的意义下) 等价于静态薛定谔桥 (式 (7.2.9)):

$$\min_{\gamma \in \Gamma} \mathcal{D}_{\text{KL}}(\gamma \| \tilde{R}^\varepsilon).$$

动态等价性 (布朗参考). 我们也可从动态等价性来理解这一关系. 经典结果 (Mikami and Thieullen, 2006) 指出, 具有二次代价的熵正则化 OT

$$c(\mathbf{x}, \mathbf{y}) = \frac{\|\mathbf{y} - \mathbf{x}\|^2}{2T}$$

仿射等价于 SB 问题, 其中参考路径分布 R^ε 为 $[0, T]$ 上的布朗运动,

$$d\mathbf{x}_t = \sqrt{\varepsilon} d\mathbf{w}_t.$$

这里, “仿射等价” 表示最优值相差正的缩放与加法常数 (与决策变量无关), 因此最小化解重合. 特别地, 令 P^* 为 SB 的最优路径分布, γ^* 为 EOT 的最优输运方案. 若 $\mathbf{x}_{[0:T]} \sim P^*$, 则端点对 $(\mathbf{x}_0, \mathbf{x}_T)$ 具有分布 γ^* :

$$P^* \text{ 求解 SB } \iff \gamma^* \text{ 求解 EOT, 且 } (\mathbf{x}_0, \mathbf{x}_T) \sim \gamma^*.$$

换言之, 动态 (SB) 问题的最优过程诱导静态 (EOT) 问题的最优耦合. 反过来, (在热核满足温和条件时,) 任意最优静态耦合都可实现为某个最优 SB 过程的端点.

推导这一事实的关键思想, 是路径上的 KL 散度可根据端点分解, 这意味着薛定谔桥问题化为仅关于 $(\mathbf{x}_0, \mathbf{x}_T)$ 联合分布的 KL 散度. 对布朗运动, 从 $\mathbf{x}$ 到 $\mathbf{y}$ 的转移密度具有高斯形式, 因此其负对数为二次形式:

$$-\varepsilon \log p_T(\mathbf{y} | \mathbf{x}) = \frac{\|\mathbf{y} - \mathbf{x}\|^2}{2T} + \text{常数}.$$

这说明, 除了一个无关紧要的常数之外, 端点 KL 恰好与二次代价的熵正则化 OT 目标相同.

一般参考下的 SB 确定 EOT 代价. 如式 (7.2.7) 所讨论, SB 问题不限于布朗运动; 它可针对任意 (适定的) 参考过程定义. 这一选择唯一确定相应 EOT 问题中的代价函数. 关键联系是, SB 的参考动力学诱导 EOT 的代价函数.

设参考过程由 $[0, T]$ 上的 SDE 支配, 产生转移密度 $p_T(\mathbf{y}|\mathbf{x})$, 即从时刻 0 的 $\mathbf{x}$ 到达时刻 T 的 $\mathbf{y}$ 的似然. 则 EOT 代价函数 (在相差缩放常数的意义下) 由下式给出

$$c(\mathbf{x}, \mathbf{y}) \propto -\log p_T(\mathbf{y}|\mathbf{x}).$$

采用这一代价, 求解 SB 问题变为等价地求解 EOT 问题. 简言之, 在 SB 中选择参考动力学, 在数学上等价于指定 EOT 中的输运代价. 根据式 (7.3.1), 熵正则化 OT 目标与静态 SB 目标有所差异; 因而两个问题等价, 并具有相同最小化解.

7.3.2 当 $\varepsilon \rightarrow 0$ 时 EOT_ε 化为 OT

令 γ_ε^* 表示 EOT_ε 的最优方案, γ^* 表示式 (7.2.1) 中无正则化 OT 问题的一个最优方案. 以下结果 (Mikami and Thieullen, 2008; Peyré, Cuturi, et al., 2019) 表明, 当 $\varepsilon \rightarrow 0$ 时, 熵正则化最优方案 γ_ε^* (在适当意义下) 收敛到 OT 方案 γ^* , 且 EOT 代价收敛到 OT 代价.

这一收敛结果既基础又有重要的实践意义. 一个原因是, 熵正则化 OT 问题 EOT_ε 可通过 Sinkhorn 等算法高效数值求解. 因此, 即使代价函数 $c(\mathbf{x}, \mathbf{y})$ 比二次情形更一般, 这一结果仍为使用小 ε 下的 EOT_ε , 作为式 (7.2.1) 中经典 OT 问题的可计算代理提供理论依据.

定理 7.3.1: (非正式) EOT_ε 收敛到 OT.

当 $\varepsilon \rightarrow 0$ 时, 最优值收敛:

$$\lim_{\varepsilon \rightarrow 0} \text{EOT}_\varepsilon(p_{\text{src}}, p_{\text{tgt}}) = \text{OT}(p_{\text{src}}, p_{\text{tgt}}).$$

此外, 最优方案 γ_ε^* 弱收敛于 γ^* . 即

$$\mathbb{E}_{(\mathbf{x}, \mathbf{y}) \sim \gamma_\varepsilon^*} [g(\mathbf{x}, \mathbf{y})] \rightarrow \mathbb{E}_{(\mathbf{x}, \mathbf{y}) \sim \gamma^*} [g(\mathbf{x}, \mathbf{y})],$$

对所有有界连续 (检验) 函数 $g: \mathbb{R}^D \times \mathbb{R}^D \rightarrow \mathbb{R}$ 成立.

定理的证明.

严格证明参见文献 (Mikami and Thieullen, 2008; Peyré, Cuturi, et al., 2019). 下面给出最优值收敛的启发式推导.

为简化记号, 将相应最优值记为

$$V_\varepsilon := \text{EOT}_\varepsilon(p_{\text{src}}, p_{\text{tgt}}), \quad V_0 := \text{OT}(p_{\text{src}}, p_{\text{tgt}})$$

如下.

上界. 根据 γ_ε^* 的最优性, 其值 V_ε 不超过使用方案 γ^* 的代价:

$$V_\varepsilon \leq \int c d\gamma^* + \varepsilon \mathcal{D}_{\text{KL}}(\gamma^* \| p_{\text{src}} \otimes p_{\text{tgt}}).$$

假定 KL 项是有限常数 K , 得到 $V_\varepsilon \leq V_0 + \varepsilon K$. 取上极限, 得到 $\limsup_{\varepsilon \rightarrow 0} V_\varepsilon \leq V_0$.

下界. 由于 KL 散度非负, $V_\varepsilon \geq \int c d\gamma_\varepsilon^*$. 根据 V_0 是最小输运代价的定义, 任意方案的代价都至少为 V_0 , 因此 $\int c d\gamma_\varepsilon^* \geq V_0$. 这意味着, 对所有 $\varepsilon > 0$ 有 $V_\varepsilon \geq V_0$, 从而 $\liminf_{\varepsilon \rightarrow 0} V_\varepsilon \geq V_0$.

结合上下界, 得到最优值收敛 $\lim_{\varepsilon \rightarrow 0} V_\varepsilon = V_0$. 最优方案本身的弱收敛 $\gamma_\varepsilon^* \rightarrow \gamma^*$, 是来自 Γ 收敛理论的更高级结果, 此处省略.

7.3.3 当 $\varepsilon \rightarrow 0$ 时 SB_ε 化为 OT

对每个 $\varepsilon > 0$, 令 $\mathbf{v}_t^\varepsilon$ 为式 (7.2.10) 中的 SB 问题的最小化解, p_t^ε 为由 $\mathbf{v}_t^\varepsilon$ 诱导的受控 SDE $\mathbf{x}_t$ 的边缘分布. 则 p_t^ε 满足相应 Fokker–Planck 方程. 相应地, 用 $(p_t^0, \mathbf{v}_t^0)$ 表示最优输运 Benamou–Brenier 表述的一个最小化解 (见式 (7.2.3)).

以下定理⁶说明, 当 $\varepsilon \rightarrow 0$ 时, SB 问题收敛到 OT 问题. 其实际意义与定理 7.3.1 中的理由相似. 目标 SB_ε 可借助 Sinkhorn 型算法高效求解, 得到最优输运的数值可处理且可微的代理. 在高维或大规模设置中, 这尤其有价值, 因为直接求解器 (例如基于 Benamou–Brenier 表述的求解器) 计算代价很高.

定理 7.3.2: (非正式) SB_ε 收敛到 OT.

当 $\varepsilon \rightarrow 0$ 时, 有:

$$\lim_{\varepsilon \rightarrow 0} \text{SB}_\varepsilon(p_{\text{src}}, p_{\text{tgt}}) = \text{OT}(p_{\text{src}}, p_{\text{tgt}}),$$

其中 OT 为式 (7.2.3) 中的 Benamou–Brenier 表述. 此外, p_t^ε 弱收敛到 p_t^0 , $\mathbf{v}_t^\varepsilon$ 在适当函数空间中弱收敛到 $\mathbf{v}_t^0$.

定理的证明.

收敛结果的完整严格证明超出本书范围; 详细推导参见 Léonard (2012) and Léonard (2014). 尽管如此, 仍可启发式地理解为何可能有这一收敛.

在 SB 问题式 (7.2.10) 的随机控制表述中, 受控 SDE 为:

$$d\mathbf{x}_t = \mathbf{v}_t^\varepsilon(\mathbf{x}_t)dt + \sqrt{2\varepsilon}d\mathbf{w}_t.$$

当 $\varepsilon \rightarrow 0$ 时, 噪声项消失, SDE 形式上趋于确定性 ODE:

$$d\mathbf{x}_t = \mathbf{v}_t^0(\mathbf{x}_t)dt.$$

⁶需要指出, 定理中的最优值收敛是在 Γ 收敛意义下, 而非经典逐点极限意义下. 虽然这需要更多技术背景, 我们此处省略细节, 仅陈述概念性结果.

这表明，SB 问题的最优值收敛到最优输运问题的最优值：

$$\lim_{\varepsilon \rightarrow 0} \text{SB}_\varepsilon(p_{\text{src}}, p_{\text{tgt}}) = \text{OT}(p_{\text{src}}, p_{\text{tgt}}).$$

同时，边缘密度 p_t^ε 满足 Fokker-Planck 方程：

$$\partial_t p_t^\varepsilon + \nabla \cdot (p_t^\varepsilon \mathbf{v}_t^\varepsilon) = \varepsilon \Delta p_t^\varepsilon.$$

同样，当 $\varepsilon \rightarrow 0$ 时，扩散项消失，方程形式上化为连续性方程：

$$\partial_t p_t^0 + \nabla \cdot (p_t^0 \mathbf{v}_t^0) = 0.$$

迄今为止，我们已经给出了 EOT 与 SB 之间的基本等价性（在各自假设下），以及它们通过极限过程与 OT 的重要联系，如图 7.3 所示。接下来将探索扩散模型如何与这些概念相联系。

7.4 扩散模型的 SDE 是 SB 问题的最优解吗？

7.4.1 扩散模型作为薛定谔桥的特例

SB 框架通过实现任意源分布与目标分布之间的非线性插值，扩展了（基于得分的）扩散模型。它加入由标量势 $\Psi(\mathbf{x}, t)$ 与 $\hat{\Psi}(\mathbf{x}, t)$ 导出的控制漂移项，引导参考扩散过程匹配预先指定的端点边缘分布（见式 (7.2.12)），并遵循如下分解：

$$\nabla \log \Psi(x, t) + \nabla \log \hat{\Psi}(x, t) = \nabla \log p_t^{\text{SB}}(\mathbf{x}).$$

这一推广使模型超越标准高斯先验，能够从更广泛的分布生成样本。

与扩散模型的联系。 扩散模型是 SB 框架的特殊情形。假设势为常数 $\Psi(\mathbf{x}, t) \equiv 1$ 。在这一假设下，式 (7.2.12) 中的第二个偏微分方程化为标准 Fokker-Planck 方程，其解为参考过程的边缘密度：

$$\hat{\Psi}(\mathbf{x}, t) = p_t^{\text{SB}}(\mathbf{x}). \quad (7.4.1)$$

因此，相应 SB 前向 SDE 成为无控制的参考过程：

$$d\mathbf{x}_t = \mathbf{f}(\mathbf{x}_t, t) dt + g(t) d\mathbf{w}_t,$$

而 SB 后向 SDE 简化为：

$$d\mathbf{x}_t = [\mathbf{f}(\mathbf{x}_t, t) - g^2(t) \nabla \log p_t^{\text{SB}}(\mathbf{x}_t)] dt + g(t) d\bar{\mathbf{w}}_t,$$

这与扩散模型采用的 Anderson 时间反向 SDE 一致。这一对应表明，扩散模型可解释为 SB 的零控制极限，其中势函数不引入额外漂移。

边界条件与一般性。 除非边界约束相容，否则上述化简仅是形式上的。对于任意源 / 目标 $(p_{\text{src}}, p_{\text{tgt}})$ ，式 (7.2.12) 中的偏微分方程边界条件通常并不被 $\Psi \equiv 1$ 这一选择满足。完整 SB 通过学习非平凡势来解决这一问题，这些势诱导非线性控制漂移，使参考动力学弯曲以匹配任意预先指定的端点。相比之下，扩散模型将一个端点固定为简单先验（通常为高斯分布），仅学习时间反向得分以到达数据。从这一视角，SB 是更灵活的总框架：采用非平凡势时，它连接任意端点；采用 $\Psi \equiv 1$ 时，它化为上述扩散模型情形。还需指出，在标准线性扩散模型中，仅当 $T \rightarrow \infty$ 时才有 $p_T \approx p_{\text{prior}}$ ，因此与先验的匹配只是近似的。

7.4.2 扩散模型作为薛定谔半桥

本节解释，为什么扩散模型并非完整薛定谔桥，而是可通过放宽的薛定谔半桥概念理解。半桥仅施加一个端点约束（ p_{prior} 或 p_{data} ），而非两个，因此是完整桥的单侧变体。在形式化这一联系之前，先基于式 (7.2.7) 中任意 p_{src} 与 p_{tgt} 的一般表述，介绍薛定谔半桥的定义。随后回到扩散模型，说明当端点为 p_{prior} 和 p_{data} 时，半桥视角如何自然适用。

薛定谔半桥. SB 问题寻找随机过程，其分布在匹配两个端点分布 p_{src} 和 p_{tgt} 的同时，(KL 散度意义下) 最接近简单参考过程. 求解完整桥需要施加两个边界条件，这在计算上往往很困难. 一个有用的放宽是 半桥问题: 不匹配两个端点，而仅匹配其中一个.

形式化地，令 R 为参考路径分布. 前向半桥寻找最小化下式的路径分布 P

$$\min_{P: P_0 = p_{\text{src}}} \mathcal{D}_{\text{KL}}(P \parallel R),$$

只受单个约束 $P_0 = p_{\text{src}}$ 限制. 类似地，后向半桥仅约束终端分布，

$$\min_{P: P_T = p_{\text{tgt}}} \mathcal{D}_{\text{KL}}(P \parallel R).$$

换言之，前向半桥问：在所有从所需初始分布出发的过程中，哪一个最像参考过程？后向半桥对于终止于所需终端分布的过程提出同样问题. 通过迭代结合这两种放宽，可近似完整 SB.

扩散模型缺少精确端点匹配. 扩散模型与 SB 框架的一个关键差异，在于对终端分布 p_T 的处理. 在标准扩散模型中，前向 SDE 通常关于 $\mathbf{x}_t$ 线性（见式 (4.3.2)），并设计为仅当 $T \rightarrow \infty$ 时， p_T 才近似先验：

$$p_T \approx p_{\text{prior}}.$$

然而，在有限时间下， p_T 是参数依赖于 p_{data} 的高斯分布（见节 C.1.5）. 因此，若无细致调节，它通常不匹配所需先验.

相比之下，SB 框架通过引入形如 $g^2(t)\nabla_{\mathbf{x}} \log \Psi(\mathbf{x}, t)$ 的额外控制漂移，在有限时间 T 施加精确的边缘匹配. 这保证无论初始数据分布 $p_0 = p_{\text{data}}$ 如何，终端分布都精确满足 $p_T = p_{\text{prior}}$. 总结如下：

- **扩散模型：** 当 $T \rightarrow \infty$ 时，渐近地有 $p_T \approx p_{\text{prior}}$ ；
- **薛定谔桥：** 通过求解控制势 Ψ 和 $\hat{\Psi}$ ，在有限 T 处精确有 $p_T = p_{\text{prior}}$.

扩散薛定谔桥. 标准扩散模型不施加 $P_T = p_{\text{prior}}$ ，因此仅求解从 p_{data} 到 p_{prior} 的薛定谔半桥.

为解决这一点，扩散薛定谔桥 (DSB) (De Bortoli et al., 2021) 遵循迭代比例拟合 (IPF) 算法——一种交替投影方法——的思想，交替匹配两个端点边缘分布. 这将扩散模型扩展为如下求解完整 SB 问题⁷：

1. **步骤 0：参考过程.** 用参考前向 SDE $P^{(0)} := R_{\text{fwd}}$ 初始化：

$$d\mathbf{x}_t = \mathbf{f}(\mathbf{x}_t, t)dt + g(t)d\mathbf{w}_t, \quad \mathbf{x}_0 \sim p_{\text{data}}.$$

这保证 $P_0^{(0)} = p_{\text{data}}$ ，但通常 $P_T^{(0)} \neq p_{\text{prior}}$.

⁷虽然这里用 p_{data} 和 p_{prior} 描述，DSB 框架适用于任意一对端点分布.

2. **步骤 1：后向遍历.** 计算在时刻 T 匹配 p_{prior} 、同时保持接近 $P^{(0)}$ 的过程 $P^{(1)}$:

$$P^{(1)} = \arg \min_{P: P_T = p_{\text{prior}}} \mathcal{D}_{\text{KL}}(P \| P^{(0)}).$$

通过神经网络 $\mathbf{s}_{\phi^\times}$ 近似理想得分函数实现这一点，得到时间反向 SDE:

$$d\mathbf{x}_t = [\mathbf{f}(\mathbf{x}_t, t) - g^2(t)\mathbf{s}_{\phi^\times}(\mathbf{x}_t, t)] dt + g(t)d\bar{\mathbf{w}}_t,$$

从 $\mathbf{x}_T \sim p_{\text{prior}}$ 出发反向模拟.

3. **迭代.** 过程 $P^{(1)}$ 满足 $P_T^{(1)} = p_{\text{prior}}$ ，但其初始边缘分布 $P_0^{(1)}$ 通常偏离 p_{data} . IPF 通过学习前向 SDE，将 $P_0^{(1)}$ 调整回 p_{data} ，再进行后向遍历以施加 p_{prior} ，从而解决这一问题. 持续交替会细化过程，直到收敛到同时满足 $P_0^* = p_{\text{data}}$ 与 $P_T^* = p_{\text{prior}}$ 的最优桥 P^* . De Bortoli et al. (2021) 在温和条件下证明了收敛性.

7.5 扩散模型的 ODE 是 OT 问题的最优映射吗？

本节关注二次代价最优输运问题.

7.5.1 PF-ODE 流通常不是最优输运

本节介绍Lavenant and Santambrogio (2022) 的结果, 它证明 PF-ODE 的解映射通常不产生二次代价下的最优输运映射.

设置. 考虑 VP SDE, 具体为 Ornstein-Uhlenbeck 过程, 它将光滑初始密度 p_0 演化至标准高斯分布 $\mathcal{N}(\mathbf{0}, \mathbf{I})$:

$$d\mathbf{x}(t) = -\mathbf{x}(t) dt + \sqrt{2} d\mathbf{w}(t), \quad \mathbf{x}(0) \sim p_0.$$

相应 PF-ODE 为

$$\frac{d\mathbf{S}_t(\mathbf{x})}{dt} = -\mathbf{S}_t(\mathbf{x}) - \nabla \log p_t(\mathbf{S}_t(\mathbf{x})), \quad \mathbf{S}_0(\mathbf{x}) = \mathbf{x}.$$

这里, $\mathbf{S}_t$ 表示将 p_0 推前为边缘分布 p_t 的流映射:

$$(\mathbf{S}_t) \# p_0 = p_t, \quad \text{即,} \quad p_t(\mathbf{y}) = \int_{\mathbb{R}^D} \delta(\mathbf{y} - \mathbf{S}_t(\mathbf{x})) p_0(\mathbf{x}) d\mathbf{x}.$$

这些密度 p_t 通过 Fokker-Planck 方程演化:

$$\frac{\partial p_t}{\partial t} = \nabla \cdot (\mathbf{x} p_t) + \Delta p_t.$$

这等价于具有以下速度场的连续性方程:

$$\mathbf{v}_t(\mathbf{x}) = -\mathbf{x} - \nabla \log p_t(\mathbf{x}),$$

其流由 $\mathbf{S}_t(\mathbf{x})$ 给出. 换言之, PF-ODE 可写成:

$$\frac{d\mathbf{S}_t(\mathbf{x})}{dt} = \mathbf{v}_t(\mathbf{S}_t(\mathbf{x})).$$

当 $t \rightarrow \infty$ 时, 映射将初始分布输运到先验:

$$\mathbf{S}_\infty \# p_0 = \mathcal{N}(\mathbf{0}, \mathbf{I}) =: p_{\text{prior}}.$$

Lavenant and Santambrogio (2022) 论证的目标. Lavenant and Santambrogio (2022) 并不直接评估从 p_0 到高斯分布的终端映射 $\mathbf{S}_\infty$ 是否最优. 相反, 他们构造特定初始分布 p_0 , 考察整个 PF-ODE 轨迹. 其关键观察是, 流在某个时刻可能不满足最优性.

他们考虑中间边缘分布 $p_t = \mathbf{S}_t \# p_0$, 并定义从 p_{t_0} 到高斯分布的剩余输运映射为

$$\mathbf{T}_{t \rightarrow \infty} := \mathbf{S}_\infty \circ \mathbf{S}_t^{-1}, \quad \text{对所有 } t \geq 0.$$

论证核心说明, 对于精心选择的 p_0 , 存在时刻 $t_0 \geq 0$, 使 $\mathbf{T}_{t_0 \rightarrow \infty}$ 不是从新的起始分布 p_{t_0} 到 $\mathcal{N}(\mathbf{0}, \mathbf{I})$ 的二次代价最优输运映射.

这一结果说明, PF-ODE 流通常不产生最优输运映射, 且对于某些初始分布, 最优性可能失效.

一些工具. Lavenant and Santambrogio (2022) 的论证关键地依赖于以下结果, 称为 *Brenier 定理*:

定理 7.5.1.1 (非正式的 Brenier 定理). 设 ν_1, ν_2 为 $\mathbb{R}^D$ 上具有光滑密度的两个概率分布. 光滑映射 $\mathbf{T} : \mathbb{R}^D \rightarrow \mathbb{R}^D$ 是从 ν_1 到 ν_2 的最优输运 (二次代价下), 当且仅当对于某个凸函数 u 有 $\mathbf{T} = \nabla u$. 此时, $D\mathbf{T}$ 对称且半正定, 而 u 满足 Monge–Ampère 方程:

$$\det D^2 u(\mathbf{x}) = \frac{\nu_1(\mathbf{x})}{\nu_2(\nabla u(\mathbf{x}))}.$$

证明还隐式使用以下事实, 后文不再每次重复: 映射是两个分布之间的最优输运, 当且仅当其逆映射是反方向的最优输运.

证明概要: PF-ODE 通常不是 OT 映射. Lavenant and Santambrogio (2022) 采用反证法: 假设对于每个 $t \geq 0$, 映射

$$\mathbf{T}_t = \mathbf{S}_t \circ \mathbf{S}_\infty^{-1}$$

都是从 $\mathcal{N}(\mathbf{0}, \mathbf{I})$ 到 p_t 的二次代价最优输运映射.

步骤 1: Brenier 定理. 根据 Brenier 定理, 任意从高斯分布出发的最优输运映射, 其雅可比矩阵必须对称且半正定. 因此,

$$D\mathbf{T}_t(\mathbf{x}) = D\mathbf{S}_t(\mathbf{S}_\infty^{-1}(\mathbf{x}))D(\mathbf{S}_\infty^{-1})(\mathbf{x})$$

必须对所有 t 和 $\mathbf{x}$ 对称. 这里, $D\mathbf{T}_t(\mathbf{x})$ 表示关于 $\mathbf{x}$ 的全微分.

步骤 2: 对对称性条件关于时间求导. 关于时间求导:

$$\frac{\partial}{\partial t} D\mathbf{T}_t(\mathbf{x}) = \left(\frac{\partial}{\partial t} D\mathbf{S}_t \right) (\mathbf{S}_\infty^{-1}(\mathbf{x})) D(\mathbf{S}_\infty^{-1})(\mathbf{x}).$$

由于对称性对所有 t 都成立, 这个导数仍然对称.

利用流的 ODE (关于 $\mathbf{x}$ 求导), 得到:

$$\frac{\partial(D\mathbf{S}_t)}{\partial t} = D\mathbf{v}_t(\mathbf{S}_t) \cdot D\mathbf{S}_t = (-\mathbf{I} - D^2 \log p_t(\mathbf{S}_t)) \cdot D\mathbf{S}_t.$$

结合以上结果可知,

$$(-\mathbf{I} - D^2 \log p_t(\mathbf{S}_t)) \cdot D\mathbf{S}_t \cdot D(\mathbf{S}_\infty^{-1})$$

对所有 $t \geq 0$ 对称.

在 $t = 0$ 处, 有 $\mathbf{S}_0 = \mathbf{I}$ 、 $D\mathbf{S}_0 = \mathbf{I}$, 得到:

$$(-\mathbf{I} - D^2 \log p_0(\mathbf{S}_\infty^{-1}(\mathbf{x}))) \cdot D(\mathbf{S}_\infty^{-1})(\mathbf{x}) \quad \text{为对称矩阵.}$$

步骤 3: 交换性条件. 由于假定 $\mathbf{T}_0 = \mathbf{S}_\infty^{-1}$ 最优, 其雅可比矩阵 $D\mathbf{T}_0 = D(\mathbf{S}_\infty^{-1})$ 对称. 此外, Hessian 矩阵 $D^2 \log p_0$ 对称. 回顾, 两个对称矩阵的乘积对称, 当且仅当它们可交换. 因此, 对所有 $\mathbf{x} \in \mathbb{R}^D$,

$$D^2 \log p_0(\mathbf{S}_\infty^{-1}(\mathbf{x})) \quad \text{必须与之交换} \quad D(\mathbf{S}_\infty^{-1})(\mathbf{x}).$$

令 $\mathbf{y} = \mathbf{S}_\infty^{-1}(\mathbf{x})$, 得到等价条件: 对所有 $\mathbf{y} \in \mathbb{R}^D$,

$$D^2 \log p_0(\mathbf{y}) \quad \text{必须与之交换} \quad D\mathbf{S}_\infty(\mathbf{y}).$$

现在, 将这一条件变为更易计算的形式. 由于 $\mathbf{S}_\infty$ 是 p_0 与 $\mathcal{N}(\mathbf{0}, \mathbf{I})$ 之间的最优映射, Brenier 定理保证对某个凸函数 u 有 $\mathbf{S}_\infty = \nabla u$. 根据 Monge–Ampère 方程, 得到:

$$\log p_0(\mathbf{y}) = \log \det(D^2 u(\mathbf{y})) - \frac{1}{2} \|\nabla u(\mathbf{y})\|^2 + \text{常数}.$$

条件变为 (其中 $D\mathbf{S}_\infty = D^2 u$):

$$D^2 \left(\log \det D^2 u - \frac{1}{2} \|\nabla u\|^2 \right) \quad \text{必须与之交换} \quad D^2 u. \quad (7.5.1)$$

这给出 $\mathbf{T}_t$ 最优的一个必要条件.

步骤 4: 构造反例. 说明如何利用这一必要条件导出矛盾.

假定能够构造凸函数 u , 使

$$D^2 \left(\log \det D^2 u(\mathbf{x}) - \frac{1}{2} \|\nabla u(\mathbf{x})\|^2 \right)$$

对于某个 $\mathbf{x} \in \mathbb{R}^D$, 它不与 $D^2 u(\mathbf{x})$ 交换. 定义 $p_0 = (\nabla u)^{-1} \# \mathcal{N}(\mathbf{0}, \mathbf{I})$, Brenier 定理意味着 ∇u 是从 p_0 到 $\mathcal{N}(\mathbf{0}, \mathbf{I})$ 的最优输运. 然而, 式 (7.5.1) 中的条件不成立, 产生矛盾. 因此, 目标是构造这样的函数. 考虑

$$u(\mathbf{x}) = \frac{1}{2} \|\mathbf{x}\|^2 + \varepsilon \phi(\mathbf{x}), \quad \text{其中充分小的 } \varepsilon.$$

则 $D^2 u(\mathbf{0}) = \mathbf{I} + \varepsilon D^2 \phi(\mathbf{0})$, 而 $\mathbf{x} = \mathbf{0}$ 处的交换性条件要求 $D^2 \phi(\mathbf{0})$ 与 $D^2(\Delta \phi)(\mathbf{0})$ 交换.

例如, 在 $\mathbb{R}^2$ 中, 选择

$$\phi(x_1, x_2) = x_1 x_2 + x_1^4$$

给出 Hessian 矩阵 $D^2 \log p_0$ 与雅可比矩阵 $D^2 u$ 不交换的反例.

这一矛盾表明, $\mathbf{T}_t$ 不可能对所有 $t \geq 0$ 都最优. 因此, 存在某个 $t_0 \geq 0$, 使映射 $\mathbf{T}_{t_0 \rightarrow \infty}$ 非最优.

7.5.2 典范线性流与 Reflow 能产生 OT 映射吗？

我们已经看到，PF-ODE（尤其采用 VP 型前向核时）通常不是 OT 映射。自然产生一个问题：

问题 7.5.1. 将线性插值流 $(1-t)\mathbf{x}_0 + t\mathbf{x}_1$ ，其中 $\mathbf{x}_0 \sim p_{\text{src}}$ 、 $\mathbf{x}_1 \sim p_{\text{tgt}}$ ，应用于独立耦合 $\pi(\mathbf{x}_0, \mathbf{x}_1) = p_{\text{src}}(\mathbf{x}_0)p_{\text{tgt}}(\mathbf{x}_1)$ 时，是否恢复 OT 映射？

答案是否定的。

尽管如此，将线性路径与给定耦合结合，仍为真实 OT 代价提供实用上界。在所有可能路径中，线性插值给出这一上界的最紧形式，下面的讨论将说明这一点。

典范线性流与最优输运。 关注二次代价最优输运，考虑式 (7.2.1) 的等价形式，即式 (7.2.3) 中的 Benamou–Brenier 表述：

$$\mathcal{K}(p_{\text{src}}, p_{\text{tgt}}) := \min_{\substack{(p_t, \mathbf{v}_t) \text{ 满足 } \partial_t p_t + \nabla \cdot (p_t \mathbf{v}_t) = 0, \\ p_0 = p_{\text{src}}, p_1 = p_{\text{tgt}}}} \int_0^1 \int_{\mathbb{R}^D} \|\mathbf{v}_t(\mathbf{x})\|^2 p_t(\mathbf{x}) \, d\mathbf{x} \, dt.$$

然而，直接求解这一最小化问题通常不可处理，因为需要求解高度非线性的偏微分方程，即 Monge–Ampère 方程。

虽然求解 Benamou–Brenier 表述通常不可处理，Liu (2022) and Lipman et al. (2024) 仍揭示其动能具有实用上界。方法是将搜索限制在更简单的条件流族内，每条路径由其固定端点 $(\mathbf{x}_0, \mathbf{x}_1)$ 定义，而端点从源分布与目标分布的耦合 $\pi_{0,1}$ 抽取。在这一条件流族内，典范线性插值成为最优选择，形式化如下。

命题 7.5.1: 通过条件流得到 OT 动能的上界

设 $\pi_{0,1}$ 为 p_{src} 与 p_{tgt} 之间的任意耦合。

(1) 任意连接端点的条件流 $\Psi_t(\mathbf{x}_0, \mathbf{x}_1)$ 的期望路径能量，都是动能的上界：

$$\mathcal{K}(p_{\text{src}}, p_{\text{tgt}}) \leq \mathbb{E}_{(\mathbf{x}_0, \mathbf{x}_1) \sim \pi_{0,1}} \left[\int_0^1 \|\Psi'_t(\mathbf{x}_0, \mathbf{x}_1)\|^2 \, dt \right].$$

(2) 使右端上界最小的唯一条件流 Ψ_t^* ，是线性插值路径：

$$\Psi_t^*(\mathbf{x}_0, \mathbf{x}_1) = (1-t)\mathbf{x}_0 + t\mathbf{x}_1.$$

代入这一最优路径，得到上界的最紧版本：

$$\mathcal{K}(p_{\text{src}}, p_{\text{tgt}}) \leq \mathbb{E}_{(\mathbf{x}_0, \mathbf{x}_1) \sim \pi_{0,1}} \|\mathbf{x}_1 - \mathbf{x}_0\|^2.$$

命题的证明。

证明先直接应用 Jensen 不等式和条件期望的塔式性质，再用 Euler–Lagrange 方程求解简化的变分问题；完整论证见 (Lipman et al., 2024) 的第 4.7 节。

换言之，对任意所选耦合 $\pi_{0,1}$ ，线性插值 Ψ_t^* （即流匹配与整流所用的前向核）最小化了真实动能的一个上界。

强调的是，在这一条件流类中的最优性，并不保证边缘分布上的全局最优性。

Reflow 与最优输运。 两个分布之间最朴素的输运方案，是采用简单独立耦合，将样本用直线相连。然而，这种方式显然并非最优，问题不在直线路径本身，而在点的初始配对低效。

Reflow 过程可能提供一种建设性方案。它是专门设计来纠正这种配对的迭代算法，关键在于，每一步都保证代价不增加 (Liu, Gong, et al., 2022)。这一性质表明，Reflow 系统地将输运方案推向更优的配置，自然引出其收敛性的核心问题。

问题 7.5.2. 如果迭代应用 Rectify 算子，会发生什么？所得输运方案序列能否收敛到最优方案，或者 Reflow 过程的不动点是否给出 OT 映射？

简短的答案是，一般情况下不能。下面解释可能出现的问题。回顾，Reflow 通过以下更新，迭代细化 p_{src} 与 p_{tgt} 之间的耦合：

$$\pi^{(k+1)} = \text{Rectify}(\pi^{(k)}),$$

以乘积耦合 $\pi^{(0)} := p_{\text{src}}(\mathbf{x}_0)p_{\text{tgt}}(\mathbf{x}_1)$ 初始化。更精确地，Rectify 通过以下方式输出更新的耦合 $\pi^{(k+1)}$ ：在每次迭代 $k = 0, 1, 2, \dots$ ，通过下式学习速度场 $\mathbf{v}_t^{(k)}$ ：

$$\mathbf{v}_t^{(k)} \in \arg \min_{\mathbf{u}_t} \mathcal{L}(\mathbf{u}_t | \pi^{(k)}),$$

其中 $\mathcal{L}(\mathbf{u}_t | \pi^{(k)})$ 是式 (5.4.1) 中定义的损失（例如 RF 或 FM 损失）。为简化记号，这里采用速度场的非参数化表述，而非其他情形中使用的参数化形式 ϕ 。随后，更新的耦合为：

$$\pi^{(k+1)}(\mathbf{x}_0, \mathbf{x}_1) := p_{\text{src}}(\mathbf{x}_0) \delta(\mathbf{x}_1 - \Psi_1^{(k)}(\mathbf{x}_0)),$$

其中 $\Psi_1^{(k)}$ 表示从初始条件 $\mathbf{x}_0$ 出发积分 $\mathbf{v}_t^{(k)}$ ，在时刻 $t = 1$ 得到的解映射。

(Liu, Gong, et al., 2022) 观察到，对于 p_{src} 与 p_{tgt} 之间的耦合 π ，存在最小化 Reflow 损失的速度场 $\mathbf{v}_t$ ，即满足 $\mathcal{L}(\mathbf{v}_t | \pi) = 0$ ，并不必然意味着输运最优。

受 Benamou–Brenier 框架启发——其中最优输运速度已知为势函数的梯度——Liu (2022) 提出额外约束：速度场 $\mathbf{v}_t$ 应为势场。相应地，式 (5.4.1) 中的目标被修改，将 $\mathbf{v}_t$ 限制在梯度向量场空间中，也称为势流：

$$\mathbf{w}_t^{(k)} \in \arg \min_{\substack{\mathbf{u}_t: \mathbf{u}_t = \nabla \varphi \\ \text{对某个 } \varphi: \mathbb{R}^D \rightarrow \mathbb{R}}} \mathcal{L}(\mathbf{u}_t | \pi^{(k)}), \quad (7.5.2)$$

过程其余部分与 Rectify 相同。将相应算子记为 $\text{Rectify}_\perp$ ，强调向无旋向量场的投影。

设 π 为 p_{src} 与 p_{tgt} 之间的耦合。Liu, Gong, et al. (2022) 猜想，以下等价关系刻画最优性：

(i) π 是最优输运耦合.

(ii) π 是势整流算子的不动点:

$$\pi = \text{Rectify}_\perp(\pi).$$

(iii) 存在梯度速度场 $\mathbf{v}_t = \nabla \varphi_t$, 使整流损失为零:

$$\mathcal{L}(\mathbf{v}_t|\pi) = 0.$$

然而, Hertrich, Chambolle, and Delon (2025) 给出了两类反例:

1. 当中间分布 p_t 的支撑不连通时, 可找到 $\text{Rectify}_\perp$ 的不动点, 具有零 Reflow 损失及梯度速度场, 却仍不能产生最优耦合.
2. 即使两个端点分布都为高斯分布, 也存在损失任意小、但偏离最优耦合任意大的耦合.

因此, 虽然整流可能产生强大的生成模型, 但作为最优输运求解器的可靠性仍然有限. 这突出了生成建模与有理论依据的最优输运理论之间的重要差距, 促使人们进一步研究其交汇处.

最后需要指出, 输运代价并不总与下游表现相关; 因此, 计算精确最优输运映射未必带来更好的实际结果. 尽管如此, 最优输运的变体仍是许多科学和工程问题的基础. 扩散模型提供了探索这些挑战的强大框架.

第三部分


扩散模型的采样

用扩散模型 $\mathbf{v}^*(\mathbf{x}, t)$ 生成：第 4 章

以 $\mathbf{x}(T) \sim p_{\text{prior}}$ 从 T 到 0 反向求解 ODE
(更一般地，以 $s > t$ 从 s 到 t 求解)：

$$\frac{d\mathbf{x}(t)}{dt} = \mathbf{v}^*(\mathbf{x}(t), t),$$

$$\iff \mathbf{x}(0) = \mathbf{x}(T) + \int_0^T \mathbf{v}^*(\mathbf{x}(t), t) dt.$$



第 8 章 引导与可控生成

扩散模型是强大的生成框架. 在无条件设置中, 目标是学习 $p_{\text{data}}(\mathbf{x})$ 并在没有外部输入的情况下生成样本.

然而, 许多应用需要条件生成, 要求输出满足使用者指定的准则. 可以通过引导无条件模型, 或直接学习条件分布 $p_0(\mathbf{x}|\mathbf{c})$ 实现这一点, 由条件 $\mathbf{c}$ (例如标签、文字描述或素描) 引导过程.

本章基于条件得分的理论视角: 它分解为无条件方向和引导方向, 后者在保持真实性的同时将样本推向条件. 我们解释为什么引导不可或缺, 说明条件得分如何作为控制的统一接口, 并考察近似引导项的方法. 随后区分控制 (满足条件) 与对齐 (在条件下满足人类偏好), 并描述如何将偏好纳入同一框架. 最后, 讨论无需额外奖励模型 (即给更符合人类偏好的输出赋予更高值的学得评分器) 的直接偏好优化 (direct preference optimization) .

8.1 序言




图 8.1: **受引导的扩散采样示意图**. 时间反向 PF-ODE 采样从右侧纯噪声 ($t = T$) 出发, 逐渐向左侧干净样本 ($t = 0$) 演化. 在这一过程中, 按 w_t 加权的引导方向 $\nabla_{\mathbf{x}_t} \log \tilde{p}_t(\mathbf{c}|\mathbf{x}_t)$, 依照下式修改速度场 $\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t) + w_t \nabla_{\mathbf{x}_t} \log \tilde{p}_t(\mathbf{c}|\mathbf{x}_t)$. 这些额外方向将轨迹引向所需属性 (日本绘画风格), 同时逐渐从粗到细地细化样本.

扩散模型的生成过程以从粗到细的方式进行, 为可控生成提供了灵活框架. 每一步都去除少量噪声, 样本变得更清晰, 逐渐显露更多结构与细节. 这一性质使控制生成过程成为可能: 向学得的时变速度场加入引导项, 即可引导生成轨迹体现使用者意图.

扩散模型中基于引导的采样, 其理论基础是条件得分的 Bayes 分解. 对每个噪声水平 t ,

$$\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t|\mathbf{c}) = \underbrace{\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t)}_{\text{无条件方向}} + \underbrace{\nabla_{\mathbf{x}_t} \log p_t(\mathbf{c}|\mathbf{x}_t)}_{\text{引导方向}}. \quad (8.1.1)$$

这一恒等式说明, 可在无条件得分上加入引导项 $\nabla_{\mathbf{x}_t} \log p_t(\mathbf{c}|\mathbf{x}_t)$ 来实现条件采样. 广泛的可控生成方法 (例如分类器引导 (classifier guidance) (Dhariwal and Nichol, 2021)、一般的无需训练的引导 (Ye et al., 2024)) 都可解释为这一引导项的不同近似, 因为 $p_t(\mathbf{c}|\mathbf{x}_t)$ 由于需要对 $\mathbf{x}_0$ 边缘化, 通常不可处理.

一旦有了这种近似, 采样只需将无条件得分替换为其条件对应物. 利用式 (8.1.1),

PF-ODE 变为

$$\begin{aligned}\frac{d\mathbf{x}(t)}{dt} &= f(t)\mathbf{x}(t) - \frac{1}{2}g^2(t) \underbrace{\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}(t)|\mathbf{c})}_{\text{条件得分}} \\ &= f(t)\mathbf{x}(t) - \frac{1}{2}g^2(t) \left[\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}(t)) + \nabla_{\mathbf{x}_t} \log p_t(\mathbf{c}|\mathbf{x}(t)) \right].\end{aligned}\quad (8.1.2)$$

强调的是，引导这些时变向量场根本上依赖于其线性关系，因此下文采用得分预测表述的讨论，自然可通过式 (6.3.1) 中的线性关系扩展到 $\mathbf{x}$ 、 ϵ 和 $\mathbf{v}$ 预测。

引导方向的具体实现.

1. **分类器引导 (CG)**. 在节 8.2 中，分类器引导 (CG) 在带噪数据 $\mathbf{x}_t$ 上训练时间条件分类器 $p_\psi(\mathbf{c}|\mathbf{x}_t, t)$ (带噪数据由在噪声水平 t 扰动干净的带标签样本得到). 采样时，其输入梯度提供引导项：

$$\nabla_{\mathbf{x}_t} \log p_\psi(\mathbf{c}|\mathbf{x}_t, t) \approx \nabla_{\mathbf{x}_t} \log p_t(\mathbf{c}|\mathbf{x}_t),$$

再将其加入无条件得分 (Dhariwal and Nichol, 2021).

2. **无分类器引导 (CFG)**. 在节 8.3 中，CFG 直接训练单个条件模型

$$\mathbf{s}_\phi(\mathbf{x}_t, t, \mathbf{c}) \approx \nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t|\mathbf{c}),$$

通过在部分训练步骤中随机将条件替换为特殊空标记，联合学习无条件模型。

3. **无需训练的 (替代引导)**. 条件分布 $p_t(\mathbf{c}|\mathbf{x}_t)$ 通常不可处理，因为它需要对干净潜变量 $\mathbf{x}_0$ 边缘化：

$$p_t(\mathbf{c}|\mathbf{x}_t) = \int p(\mathbf{c}|\mathbf{x}_0)p(\mathbf{x}_0|\mathbf{x}_t)d\mathbf{x}_0,$$

而在典型应用中，至少一个因子未知，使积分不可处理。

在节 8.4.1 中，无需训练的 (基于损失的) 引导避免直接计算条件似然 $p_t(\mathbf{c}|\mathbf{x}_t)$. 它引入现成的损失 $\ell(\mathbf{x}_t, \mathbf{c}; t)$ ，并如下定义替代条件分布 $\tilde{p}_t(\mathbf{c}|\mathbf{x}_t)$ ：

$$\tilde{p}_t(\mathbf{c}|\mathbf{x}_t) \propto \exp(-\tau \ell(\mathbf{x}_t, \mathbf{c}; t)), \quad \tau > 0,$$

它充当伪似然. 这一表述绕过计算真实条件似然的不可处理性，同时仍能通过所选损失的梯度实现引导. 其条件得分仅由损失梯度和 τ 计算：

$$\nabla_{\mathbf{x}_t} \log \tilde{p}_t(\mathbf{c}|\mathbf{x}_t) = -\tau \nabla_{\mathbf{x}_t} \ell(\mathbf{x}_t, \mathbf{c}; t).$$

将此项以引导权重 w_t 加入无条件得分：

$$\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t) + w_t [-\tau \nabla_{\mathbf{x}_t} \ell(\mathbf{x}_t, \mathbf{c}; t)].$$

这恰好是如下定义的倾斜密度 $\tilde{p}_t^{\text{tilt}}(\mathbf{x}_t|\mathbf{c})$ 的得分：

$$\tilde{p}_t^{\text{tilt}}(\mathbf{x}_t|\mathbf{c}) \propto p_t(\mathbf{x}_t)\tilde{p}_t(\mathbf{c}|\mathbf{x}_t)^{w_t} \propto p_t(\mathbf{x}_t) \exp(-w_t\tau\ell(\mathbf{x}_t, \mathbf{c}; t)).$$

实践中，将式 (8.1.2) 中采样所用的条件得分替换为这一倾斜得分，并求解所得 ODE 来抽取样本。

由此看来，分类器引导就是采用学得分类器 $\tilde{p}_t(\mathbf{c}|\mathbf{x}_t) := p_{\psi^*}(\mathbf{c}|\mathbf{x}_t, t)$ 的替代引导，其中：

$$\ell(\mathbf{x}_t, \mathbf{c}; t) = -\log p_{\psi^*}(\mathbf{c}|\mathbf{x}_t, t), \quad \tau = 1.$$

引导对采样轨迹的作用示意图 8.1.

所有这些技术同样可以应用于条件模型之上，允许在生成过程中注入额外控制信号。

注.

受引导的 PF-ODE（一般情况下）不从倾斜族采样. 即使得分精确、ODE 积分精确，将得分替换为 倾斜得分，也不会使时刻 t 的边缘分布等于 $\{\tilde{p}_t^{\text{tilt}}(\cdot|\mathbf{c})\}_{t \in [0,1]}$ ，也不会使终端分布等于 $\tilde{p}_0^{\text{tilt}}(\cdot|\mathbf{c})$.

定义

$$\mathbf{v}_t^{\text{orig}} = \mathbf{f} - \frac{1}{2}g^2(t)\nabla \log p_t, \quad \mathbf{h}_t(\mathbf{x}) = e^{-w_t\tau\ell(\mathbf{x}, \mathbf{c}; t)}, \quad \tilde{p}_t^{\text{tilt}} = \frac{p_t \mathbf{h}_t}{Z_t}.$$

受引导的 PF-ODE 使用

$$\mathbf{v}_t^{\text{tilt}} = \mathbf{f} - \frac{1}{2}g^2(t)\nabla \log \tilde{p}_t^{\text{tilt}} = \mathbf{v}_t^{\text{orig}} - \frac{1}{2}g^2(t)\nabla \log \mathbf{h}_t.$$

若 $\tilde{p}_t^{\text{tilt}}$ 是真实边缘分布，则它们满足

$$\partial_t \tilde{p}_t^{\text{tilt}} + \nabla \cdot (\tilde{p}_t^{\text{tilt}} \mathbf{v}_t^{\text{tilt}}) = 0.$$

但直接计算给出残差

$$\begin{aligned} & \partial_t \tilde{p}_t^{\text{tilt}} + \nabla \cdot (\tilde{p}_t^{\text{tilt}} \mathbf{v}_t^{\text{tilt}}) \\ &= \tilde{p}_t^{\text{tilt}} \left[\partial_t \log \mathbf{h}_t + \mathbf{v}_t^{\text{orig}} \cdot \nabla \log \mathbf{h}_t - \frac{1}{2}g^2(t)(\Delta \log \mathbf{h}_t + \|\nabla \log \mathbf{h}_t\|^2) - \frac{Z'_t}{Z_t} \right]. \end{aligned}$$

因此， $\tilde{p}_t^{\text{tilt}}$ 与 PF-ODE 边缘分布重合，当且仅当此方括号对所有 $\mathbf{x}$ 都为零，即

$$\partial_t \log \mathbf{h}_t + \mathbf{v}_t^{\text{orig}} \cdot \nabla \log \mathbf{h}_t = \frac{1}{2}g^2(t)(\Delta \log \mathbf{h}_t + \|\nabla \log \mathbf{h}_t\|^2) + \frac{Z'_t}{Z_t}.$$

当 $\omega_t \equiv 0$ (无条件生成) 时，此条件显然成立，但对于 $\mathbf{h}_t(\mathbf{x}) = e^{-w_t\tau\ell(\mathbf{x}, \mathbf{c}; t)}$ ，除非 w_t 或 ℓ 有非常特殊的形式，否则几乎从不成立. 因此，一般情况下， $\{\tilde{p}_t^{\text{tilt}}\}$ 不是 PF-ODE 的边缘分布，终端样本也不服从 $\tilde{p}_0^{\text{tilt}}(\mathbf{x}_0|\mathbf{c})$.

从控制到更好对齐：直接偏好优化。 强控制可以满足条件却偏离偏好：样本可能满足条件信号（例如提示词），但偏离人类实际偏好。我们通过用偏好评分倾斜条件目标来形式化这一点¹：

$$\hat{p}_0^{\text{tilt}}(\mathbf{x}_0|\mathbf{c}) \propto p_0(\mathbf{x}_0|\mathbf{c}) \exp(\beta r(\mathbf{x}_0, \mathbf{c})),$$

其中 $r(\mathbf{x}_0, \mathbf{c})$ 是干净样本 $\mathbf{x}_0$ 与条件 $\mathbf{c}$ 的标量对齐评分（奖励）（ r 越大，表示对齐越好）。实践中， r 可以是外部奖励模型 / 分类器的 logit 或对数概率，也可以是相似度度量（例如 CLIP / 感知度量 (Radford et al., 2021)），或学得的偏好模型。

实现这种可引导性的现有方法，通常收集模型生成结果相对质量的人类标签，并微调条件扩散模型以对齐这些偏好，往往采用基于人类反馈的强化学习（reinforcement learning from human feedback）（RLHF）。然而，RLHF 是复杂且往往不稳定的过程：先拟合奖励模型以捕捉人类偏好，再通过强化学习微调条件扩散模型，以最大化这一估计奖励，同时限制策略偏离原始模型。

这自然引出问题：能否完全去掉奖励模型训练阶段？我们用 Diffusion-DPO (Wallace et al., 2024) 回答，它改编自最初为大语言模型开发的直接偏好优化 (Rafailov et al., 2023)。如节 8.5 所述，Diffusion-DPO 直接从成对选择学习偏好倾斜，从而在没有独立奖励模型的情况下，微调条件扩散模型使其对齐偏好。

¹需要指出，无需训练的引导也可视为同一框架中的问题，即在损失 $\ell(\mathbf{x}_t, \mathbf{c}, t)$ 的引导下寻找倾斜分布。

8.2 分类器引导

8.2.1 分类器引导的基础

设 $\mathbf{c}$ 为从分布 $p(\mathbf{c})$ 抽取的条件变量，例如类别标签、图像描述或其他辅助信息。目标是从 $p_0(\mathbf{x}|\mathbf{c})$ 抽取样本。在基于扩散的条件生成中，我们运行时间边缘分布为 $p_t(\cdot|\mathbf{c})$ 的时间反向动力学来实现这一目标。这些动力学的漂移依赖于条件得分

$$\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t|\mathbf{c}), \quad t \in [0, T].$$

因此，一条标准且有效的途径²是估计这一量。

基于 Bayes 公式的一个基本见解，是条件得分可分解为：

$$\begin{aligned} \nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t|\mathbf{c}) &= \nabla_{\mathbf{x}_t} \log \left(\frac{p_t(\mathbf{x}_t)p_t(\mathbf{c}|\mathbf{x}_t)}{p(\mathbf{c})} \right) \\ &= \nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t) + \nabla_{\mathbf{x}_t} \log p_t(\mathbf{c}|\mathbf{x}_t) - \nabla_{\mathbf{x}_t} \log p(\mathbf{c}) \\ &= \underbrace{\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t)}_{\text{无条件得分}} + \underbrace{\nabla_{\mathbf{x}_t} \log p_t(\mathbf{c}|\mathbf{x}_t)}_{\text{分类器梯度}}, \end{aligned} \quad (8.2.1)$$

其中 $p_t(\mathbf{c}|\mathbf{x}_t)$ 表示给定 $\mathbf{x}_t$ 时 $\mathbf{c}$ 的概率，它在时刻 t 从带噪输入 $\mathbf{x}_t$ 预测条件 $\mathbf{c}$ 。

这一分解³推动了 Dhariwal and Nichol (2021) 提出的分类器引导 (CG) 方法，它利用预训练的时变分类器 $p_t(\mathbf{c}|\mathbf{x}_t)$ 引导生成过程。具体地，以引导尺度 $\omega \geq 0$ 定义单参数的引导密度族（倾斜条件分布）：

$$p_t(\mathbf{x}_t|\mathbf{c}, \omega) \propto p_t(\mathbf{x}_t)p_t(\mathbf{c}|\mathbf{x}_t)^\omega, \quad (8.2.2)$$

这给出得分函数：

$$\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t|\mathbf{c}, \omega) = \nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t) + \omega \nabla_{\mathbf{x}_t} \log p_t(\mathbf{c}|\mathbf{x}_t). \quad (8.2.3)$$

几何上，它将无条件流倾斜到提高类别似然的方向。当 $\omega = 1$ 时， $p_t(\mathbf{x}_t|\mathbf{c}, \omega)$ 与真实条件分布 $p_t(\mathbf{x}_t|\mathbf{c})$ 重合；当 $\omega \neq 1$ 时，它是受引导（调温）的重加权，而非严格的条件分布。

标量 $\omega \geq 0$ 调节分类器的影响：

- $\omega = 1$ ：恢复真实条件得分 $\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t|\mathbf{c})$ 。
- $\omega > 1$ ：增强分类器信号，通常提高条件保真度（往往以多样性为代价）。
- $0 \leq \omega < 1$ ：降低分类器信号权重，通常增加样本多样性，同时减弱条件作用。

²原则上，若 $p(\mathbf{c}|\mathbf{x})$ 可用且校准良好，可以通过拒绝采样或重要性采样，从无条件生成器获得 $p_0(\mathbf{x}|\mathbf{c})$ 。对于高维或稀有条件，这通常不实用。

³在最后的恒等式中，由于 $\nabla_{\mathbf{x}_t} \log p(\mathbf{c})$ 不依赖于 $\mathbf{x}_t$ ，求导后消失。

CG 的实际近似. 实践中, CG 是引导预训练无条件扩散模型的无需训练的方法 (就扩散模型而言),

$$\mathbf{s}_{\phi^\times}(\mathbf{x}_t, t) \approx \nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t).$$

CG 仅在采样时应用, 不修改扩散模型本身. 为此, 分别训练时间相关分类器 $p_\psi(\mathbf{c}|\mathbf{x}_t, t)$, 从不同噪声水平 t 的带噪输入 $\mathbf{x}_t$ 预测条件 $\mathbf{c}$. 分类器按标准方式, 通过最小化交叉熵损失训练:

$$\mathbb{E}_{t \sim \mathcal{U}[0, T], (\mathbf{x}, \mathbf{c}) \sim p_{\text{data}}, \epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})} \left[-\log p_\psi(\mathbf{c}|\mathbf{x}_t, t) \right], \quad (8.2.4)$$

其中 $(\mathbf{x}, \mathbf{c}) \sim p_{\text{data}}$ 表示配对的带标签数据, $\mathbf{x}_t = \alpha_t \mathbf{x} + \sigma_t \epsilon$ 是时刻 t 的带噪输入. 分类器必须显式以 t 为条件 (例如通过时间嵌入), 因为它应在所有噪声水平下可靠运行.

训练后, 分类器提供作为真实似然梯度替代的得分:

$$\nabla_{\mathbf{x}_t} \log p_{\psi^\times}(\mathbf{c}|\mathbf{x}_t, t) \approx \nabla_{\mathbf{x}_t} \log p_t(\mathbf{c}|\mathbf{x}_t).$$

8.2.2 使用 CG 推断

推断时, 将分类器梯度 $\nabla_{\mathbf{x}_t} \log p_{\psi^\times}(\mathbf{c}|\mathbf{x}_t, t)$ 加入无条件得分函数, 并按引导权重 ω 缩放, 得到对式 (8.2.3) 中引导得分 $\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t|\mathbf{c}, \omega)$ 的近似:

$$\begin{aligned} \mathbf{s}^{\text{CG}}(\mathbf{x}_t, t, \mathbf{c}; \omega) &:= \underbrace{\mathbf{s}_{\phi^\times}(\mathbf{x}_t, t)}_{\text{无条件方向}} + \omega \underbrace{\nabla_{\mathbf{x}_t} \log p_{\psi^\times}(\mathbf{c}|\mathbf{x}_t, t)}_{\text{引导方向}} \\ &\approx \nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t|\mathbf{c}, \omega). \end{aligned}$$

相应地, 只需按式 (8.1.2), 针对指定 ω 将时间反向 SDE 或 PF-ODE 中的无条件得分函数 $\mathbf{s}_{\phi^\times}(\mathbf{x}_t, t)$ 替换为引导得分 $\mathbf{s}^{\text{CG}}(\mathbf{x}_t, t, \mathbf{c}; \omega)$, 即可将生成轨迹引向与条件 $\mathbf{c}$ 一致的样本.

8.2.3 优势与局限

CG 为条件生成提供了简单灵活的机制, 允许通过 ω 显式控制条件作用强度. 它可用于任意预训练无条件扩散模型, 仅需额外分类器来实现条件化.

然而, 这一方法有显著局限:

- **训练代价:** 必须训练分类器使其在所有噪声水平运行, 计算代价高.
- **鲁棒性:** 分类器必须很好地泛化到严重加噪的输入 $\mathbf{x}_t$, 尤其在较大的 t 处, 这可能很有挑战.
- **独立训练:** 由于分类器独立于扩散模型训练, 它可能不能与学得的数据分布完全一致.

8.3 无分类器引导

8.3.1 无分类器引导的基础




图 8.2: **CFG 示意图**. 调整后的得分 $\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t|\mathbf{c}, \omega)$ 是无条件得分 $\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t)$ 与条件得分 $\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t|\mathbf{c})$ 之间按 ω 加权的线性插值. 所得方向将来自先验的样本引向数据分布中与目标条件一致的众数.

无分类器引导 (*classifier-free guidance*) (CFG) (Ho and Salimans, 2021) 是对基于分类器的引导的简化, 无需独立分类器. 核心思想是修改得分函数的梯度, 使其在没有显式分类器的情况下实现有效条件化. 具体地, 条件分布对数概率的梯度调整如下:

$$\nabla_{\mathbf{x}_t} \log p_t(\mathbf{c}|\mathbf{x}_t) = \nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t|\mathbf{c}) - \nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t). \quad (8.3.1)$$

将这一表达式代入式 (8.2.3), 得到条件化得分的如下表述:

$$\begin{aligned} \nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t|\mathbf{c}, \omega) &= \nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t) + \omega (\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t|\mathbf{c}) - \nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t)) \\ &= \underbrace{\omega \nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t|\mathbf{c})}_{\text{条件得分}} + (1 - \omega) \underbrace{\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t)}_{\text{无条件得分}}. \end{aligned} \quad (8.3.2)$$

超参数 ω 再次在控制条件信息影响上起关键作用 (取 $\omega \geq 0$):

- 在 $\omega = 0$ 时, 模型表现为无条件扩散模型, 完全忽略条件.
- 在 $\omega = 1$ 时, 模型使用条件得分, 无额外引导.
- 当 $\omega > 1$ 时, 模型更强调条件得分、减弱无条件得分, 增强与 $\mathbf{c}$ 的一致性, 但通常降低多样性.

8.3.2 CFG 的训练与采样

通过 CFG 联合训练无条件与条件扩散模型. 与 CG 不同, CFG 需要重新训练显式考虑条件变量 $\mathbf{c}$ 的扩散模型. 然而, 为条件与无条件得分函数分别训练两个模型, 计算代

价往往过高. 为此, CFG 使用单个模型 $\mathbf{s}_\phi(\mathbf{x}_t, t; \mathbf{c})$, 将 $\mathbf{c}$ 作为额外输入, 在一个模型内学习两个得分函数. 训练过程定义如下:

- 无条件训练时, 以空标记 $\emptyset$ 代替条件输入, 得到 $\mathbf{s}_\phi(\mathbf{x}_t, t, \emptyset)$.
- 条件训练时, 提供真实条件变量 $\mathbf{c}$ 作为输入, 得到 $\mathbf{s}_\phi(\mathbf{x}_t, t, \mathbf{c})$.

通过以概率 p_{uncond} (使用者定义的超参数, 通常设为 0.1) 随机将 $\mathbf{c}$ 替换为空输入 $\emptyset$, 统一这两种训练方式. 联合训练策略使模型能同时学习条件与无条件得分函数. 完整训练算法见算法 4, 并与算法 3 中的标准无条件训练作比较. 注意, 训练时不使用 CFG 权重 ω .

算法 3 无条件扩散模型

- 1: **重复**
 - 2: $\mathbf{x} \sim p_{\text{data}}(\mathbf{x})$
 - 3: $t \sim \mathcal{U}[0, T]$
 - 4: $\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$
 - 5: $\mathbf{x}_t = \alpha_t \mathbf{x} + \sigma_t \epsilon$
 - 6: 对下式进行梯度更新:
 $\nabla_\phi \|\mathbf{s}_\phi(\mathbf{x}_t, t) - \mathbf{s}\|^2$
 - 7: **直到** 收敛
-

算法 4 条件扩散模型的 CFG

输入: p_{uncond} : 无条件丢弃的概率

- 1: **重复**
 - 2: $(\mathbf{x}, \mathbf{c}) \sim p_{\text{data}}(\mathbf{x}, \mathbf{c})$
 - 3: 以概率 p_{uncond} 令 $\mathbf{c} \leftarrow \emptyset$
 - 4: $t \sim \mathcal{U}[0, T]$
 - 5: $\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$
 - 6: $\mathbf{x}_t = \alpha_t \mathbf{x} + \sigma_t \epsilon$
 - 7: 对下式进行梯度更新:
 $\nabla_\phi \|\mathbf{s}_\phi(\mathbf{x}_t, t, \mathbf{c}) - \mathbf{s}\|^2$
 - 8: **直到** 收敛
-

使用 CFG 的条件采样. 按照算法 4 训练模型 $\mathbf{s}_{\phi^\times}(\mathbf{x}_t, t, \mathbf{c})$ 后, 可在采样时应用 CFG. 对数概率梯度为:

$$\begin{aligned}
 \nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t | \mathbf{c}, \omega) &= \omega \nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t | \mathbf{c}) + (1 - \omega) \nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t) \\
 &\approx \omega \underbrace{\mathbf{s}_{\phi^\times}(\mathbf{x}_t, t, \mathbf{c})}_{\text{条件得分}} + (1 - \omega) \underbrace{\mathbf{s}_{\phi^\times}(\mathbf{x}_t, t, \emptyset)}_{\text{无条件得分}} \\
 &=: \mathbf{s}_{\phi^\times}^{\text{CFG}}(\mathbf{x}_t, t, \mathbf{c}; \omega).
 \end{aligned} \tag{8.3.3}$$

采样时, 应用固定 (也可选择随时间变化) 的无分类器引导权重 ω . 然后, 按式 (8.1.2), 将时间反向 SDE (式 (4.1.6)) 或 PF-ODE (式 (4.1.8)) 中的无条件得分 $\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t)$, 替换为以加权方式结合条件和无条件得分的引导得分 $\mathbf{s}_{\phi^\times}^{\text{CFG}}(\mathbf{x}_t, t, \mathbf{c}; \omega)$.

这一表述通过调整 ω 实现可控生成, 使样本在保持多样性的同时被引向条件信号 $\mathbf{c}$. 因此, CFG 提供了有效且计算高效的精确条件生成方式, 因为只需训练单个扩散模型.

8.4 (选读) 无需训练的引导

本节介绍一系列无需训练的引导方法背后的总体思想 (Chung et al., 2023; Ye et al., 2024; He et al., 2024; Bansal et al., 2023). 尽管实现方式和应用场景有所不同, 这些方法都遵循式 (8.1.1) 所表达的核心原则. 我们首先在节 8.4.1 中介绍无需训练的引导的总体方法, 再将这一思想推广到无需训练的逆问题求解, 并在节 8.4.2 中作简要概述.

设定与记号. 令 $\mathbf{c}$ 表示条件变量. 假设我们可以使用一个以得分预测形式表示的预训练扩散模型 $\mathbf{s}_{\phi \times}(\mathbf{x}_t, t)$ ⁴. 此外, 假设给定一个非负函数

$$\ell(\cdot, \mathbf{c}): \mathbb{R}^D \rightarrow \mathbb{R}_{\geq 0}$$

来量化样本 $\mathbf{x} \in \mathbb{R}^D$ 与条件 $\mathbf{c}$ 的吻合程度, 其中 $\ell(\mathbf{x}, \mathbf{c})$ 越小, 表示吻合程度越高. 这样的函数的具体例子包括:

- (i) $\mathbf{c}$ 是一幅参考图像, $\ell(\cdot, \mathbf{c})$ 是衡量感知接近程度的相似性得分;
- (ii) $\ell(\cdot, \mathbf{c})$ 是通过 CLIP (Radford et al., 2021) 等预训练模型计算的基于特征的相似性得分.

考虑标准的线性高斯前向加噪核 $p_t(\cdot | \mathbf{x}_0) := \mathcal{N}(\cdot; \alpha_t \mathbf{x}_0, \sigma_t^2 \mathbf{I})$. 回顾式 (9.2.3) 中的 DDIM 更新, 并以其为例:

$$\mathbf{x}_{t \rightarrow t-1} = \alpha_{t-1} \underbrace{\hat{\mathbf{x}}_0(\mathbf{x}_t)}_{\text{在数据空间中}} - \sigma_{t-1} \sigma_t \underbrace{\hat{\mathbf{s}}(\mathbf{x}_t)}_{\text{在噪声空间中}}, \quad (8.4.1)$$

其中 $\hat{\mathbf{x}}_0(\mathbf{x}_t) := \mathbf{x}_{\phi \times}(\mathbf{x}_t, t)$ 是 (干净样本的) $\mathbf{x}$ 预测, 而 $\hat{\mathbf{s}}(\mathbf{x}_t) := \mathbf{s}_{\phi \times}(\mathbf{x}_t, t)$ 是根据时间层级 t 处的 $\mathbf{x}_t$ 得到的得分预测.

8.4.1 无需训练的引导的概念框架

大多数无需训练的引导方法 (Ye et al., 2024) 在数据空间或噪声空间中引入修正, 使式 (8.4.2) 中的 DDIM 更新朝着满足条件 $\mathbf{c}$ 的方向推进:

$$\mathbf{x}_{t \rightarrow t-1} = \alpha_{t-1} \underbrace{(\hat{\mathbf{x}}_0(\mathbf{x}_t) + \eta_t^{\text{data}} \mathcal{G}_0)}_{\text{A. 数据空间}} - \sigma_{t-1} \sigma_t \underbrace{(\hat{\mathbf{s}}(\mathbf{x}_t) + \eta_t^{\text{latent}} \mathcal{G}_t)}_{\text{B. 噪声空间}}, \quad (8.4.2)$$

其中 $\eta_t^{\text{data}}, \eta_t^{\text{latent}} \geq 0$ 是随时间变化的引导强度, 而 $\mathcal{G}_0, \mathcal{G}_t$ 是下文定义的修正项.

⁴为简化数学表达, 我们在这里采用得分预测和 $\mathbf{x}$ 预测参数化; 其他参数化 (例如 ϵ 预测) 也可以类似处理.

A. 数据空间中的引导. 沿负梯度方向下降, 即

$$\mathcal{G}_0 := -\nabla_{\mathbf{x}_0} \ell(\mathbf{x}_0, \mathbf{c}),$$

便可以使数据空间中修正后的干净样本估计

$$\hat{\mathbf{x}}_0(\mathbf{x}_t) + \eta_t^{\text{data}} \mathcal{G}_0,$$

逐渐朝着更好地满足条件 $\mathbf{c}$ 的样本移动. 这种梯度下降方案可以迭代应用, 从而逐步改善吻合程度.

代表性方法包括 MGPD (He et al., 2023) 和 UGD (Bansal et al., 2023).

B. 噪声空间中的引导. 如节 8.1 所述, 条件得分 $\nabla_{\mathbf{x}_t} \log p_t(\mathbf{c}|\mathbf{x}_t)$ 通常难以求解. 一个实用的近似方法是引入替代似然 $\tilde{p}_t(\mathbf{c}|\mathbf{x}_t)$:

$$\tilde{p}_t(\mathbf{c}|\mathbf{x}_t) \propto \exp(-\eta \ell(\hat{\mathbf{x}}_0(\mathbf{x}_t), \mathbf{c}))$$

其中重标度常数 $\eta > 0$ 使得

$$\nabla_{\mathbf{x}_t} \log \tilde{p}_t(\mathbf{c}|\mathbf{x}_t) = -\eta \nabla_{\mathbf{x}_t} \ell(\hat{\mathbf{x}}_0(\mathbf{x}_t), \mathbf{c}) =: \mathcal{G}_t,$$

这里 $\hat{\mathbf{x}}_0(\mathbf{x}_t)$ 通过扩散模型的预测获得. 将其代入条件得分的贝叶斯法则, 得到如下替代近似:

$$\begin{aligned} \nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t|\mathbf{c}) &\approx \underbrace{\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t)}_{\text{无条件项}} + \underbrace{\nabla_{\mathbf{x}_t} \log \tilde{p}_t(\mathbf{c}|\mathbf{x}_t)}_{\text{引导项}} \\ &\approx \hat{\mathbf{s}}(\mathbf{x}_t) + \eta_t^{\text{latent}} \mathcal{G}_t, \end{aligned}$$

它作为噪声空间中的引导修正.

不过, 我们注意到, 计算 $\mathcal{G}_t$ 需要通过 $\mathbf{x}$ 预测进行反向传播, 即

$$\nabla_{\mathbf{x}_t} \hat{\mathbf{x}}_0(\mathbf{x}_t)^\top \cdot \nabla_{\mathbf{x}_0} \log \ell_{\mathbf{c}}(\mathbf{x}_0)|_{\mathbf{x}_0=\hat{\mathbf{x}}_0(\mathbf{x}_t)},$$

这在实践中可能带来相当大的计算开销.

代表性方法包括 (Yu et al., 2023; Chung et al., 2022; Bansal et al., 2023).

8.4.2 无需训练的逆问题求解方法举例

节 8.4.1 中介绍的原则在逆问题中有重要应用. 我们先概述背景, 再给出若干具体例子, 说明如何利用预训练扩散模型在推断时求解逆问题.

逆问题背景. 令 $\mathcal{A}$ 为退化算子 (可以是线性或非线性、已知或未知的), 例如模糊核或图像修补中的遮挡算子, 并令 $\mathbf{y}$ 为以下退化模型生成的观测:

$$\mathbf{y} = \mathcal{A}(\mathbf{x}_0) + \sigma_{\mathbf{y}} \mathbf{z}, \quad \mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}). \quad (8.4.3)$$

逆问题的目标是从后验分布 $p_0(\mathbf{x}_0|\mathbf{y})$ 中采样; 对于给定观测 $\mathbf{y}$, 可能存在无穷多个可行的重建 $\mathbf{x}_0$. 我们希望恢复一个 $\mathbf{x}_0$, 既消除 $\mathbf{y}$ 中的退化, 又忠实保留其内容与语义特征.

传统逆问题求解方法通常采用监督框架, 需要收集退化样本与恢复样本的配对数据 $(\mathbf{y}, \mathbf{x})$, 并依赖优化方法或神经网络的监督训练. 这些方法的数据准备成本可能很高, 对未见数据的泛化能力也可能不足.

作为逆问题求解器的预训练扩散模型。如前所示，条件得分可以通过贝叶斯法则分解：

$$\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t|\mathbf{y}) = \underbrace{\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t)}_{\text{数据得分}} + \underbrace{\nabla_{\mathbf{x}_t} \log p_t(\mathbf{y}|\mathbf{x}_t)}_{\text{测量吻合项}}. \quad (8.4.4)$$

这一分解将数据得分与逆问题特有的、关于 $\mathbf{y}$ 的测量吻合项分开。通过建模干净数据分布 p_{data} 并在求逆时应用该分布，它使我们能够以无监督方式求解式 (8.4.3)。具体而言：

- **数据得分** $\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t)$ ：使用在干净数据上训练的预训练扩散模型 $\mathbf{s}_{\phi^\times}(\mathbf{x}_t, t)$ 来近似。
- **测量吻合项** $\nabla_{\mathbf{x}_t} \log p_t(\mathbf{y}|\mathbf{x}_t)$ ：由于涉及对潜变量的边缘化，难以求得闭式表达。

因此，大多数利用预训练扩散模型的无需训练方法都侧重于近似 $\nabla_{\mathbf{x}_t} \log p_t(\mathbf{y}|\mathbf{x}_t)$ 。我们采用 (Daras et al., 2024) 概括的一种常见通用形式：

$$\nabla_{\mathbf{x}_t} \log p_t(\mathbf{y}|\mathbf{x}_t) \approx -\frac{\mathcal{P}_t \mathcal{M}_t}{\gamma_t}.$$

这里：

- $\mathcal{M}_t$ ：量化观测 $\mathbf{y}$ 与估计信号之间不匹配程度的误差向量；
- $\mathcal{P}_t$ ：将 $\mathcal{M}_t$ 映射回 $\mathbf{x}_t$ 所在环境空间的映射；
- γ_t ：控制引导强度的标量。

不同代表性方法对 $\mathcal{M}_t$ 、 $\mathcal{P}_t$ 和 γ_t 采用不同的具体形式，下文用不同颜色突出相应分量。

基于扩散模型的逆问题求解器的具体形式。 我们介绍一些代表性方法，它们利用预训练扩散模型提供无监督方法（无需配对数据），并使用同一个学习得到的 p_{data} 替代模型，灵活地求解各种逆问题。

得分 SDE (Song et al., 2020b). 这是最早基于扩散模型求解逆问题的工作之一。它考虑已知的线性退化模型 $\mathbf{A}$ ，并侧重于 $\sigma_{\mathbf{y}} = 0$ 的无噪声设定。由于 $\mathbf{A}$ 是线性的，可以构造与噪声层级相匹配的观测

$$\mathbf{y}_t := \alpha_t \mathbf{y} + \sigma_t \boldsymbol{\epsilon},$$

并使用残差 $\mathbf{y}_t - \mathbf{A}\mathbf{x}_t$ （注意：一般而言 $\mathbf{y}_t \neq \mathbf{A}\mathbf{x}_t$ ）来驱动类似似然的修正。一种常见近似（略去乘法常数）为

$$\nabla_{\mathbf{x}_t} \log p_t(\mathbf{y}|\mathbf{x}_t) \approx -\mathbf{A}^\top (\mathbf{y}_t - \mathbf{A}\mathbf{x}_t).$$

迭代潜变量细化 (ILVR) (Choi et al., 2021). 在与得分 SDE 相同的设定下, ILVR 作如下估计:

$$\nabla_{\mathbf{x}_t} \log p_t(\mathbf{y}|\mathbf{x}_t) \approx -\mathbf{A}^\dagger(\mathbf{y}_t - \mathbf{A}\mathbf{x}_t) = -(\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top (\mathbf{y}_t - \mathbf{A}\mathbf{x}_t),$$

其中 $\mathbf{A}^\dagger$ 是 Moore–Penrose 伪逆, 且 $\mathbf{y}_t = \alpha_t \mathbf{y} + \sigma_t \boldsymbol{\epsilon}_t$.

扩散后验采样 (DPS) (Chung et al., 2022). 对于具有已知非线性前向算子 $\mathcal{A}$ 且加性高斯噪声水平为 $\sigma_y \geq 0$ 的逆问题, 一种广泛使用的方法是去噪后验得分 (DPS), 它作如下近似:

$$\nabla_{\mathbf{x}_t} \log p_t(\mathbf{y}|\mathbf{x}_t) \approx \nabla_{\mathbf{x}_t} \log p_t(\mathbf{y}|X_0 = \hat{\mathbf{x}}_0(\mathbf{x}_t)), \quad (8.4.5)$$

其中 $\hat{\mathbf{x}}_0(\mathbf{x}_t) := \mathbb{E}[\mathbf{x}_0|\mathbf{x}_t]$ 表示给定时间 t 处含噪观测 $\mathbf{x}_t$ 时干净样本的条件均值, 通常利用预训练扩散模型通过 Tweedie 公式 (式 (3.3.6)) 来估计.

这种单点近似假设条件分布 $p(\mathbf{x}_0|\mathbf{x}_t)$ 高度集中, 可由下式得到:

$$\begin{aligned} p_t(\mathbf{y}|\mathbf{x}_t) &= \int p_t(\mathbf{y}|\mathbf{x}_t, \mathbf{x}_0) p(\mathbf{x}_0|\mathbf{x}_t) d\mathbf{x}_0 \\ &= \int p_t(\mathbf{y}|\mathbf{x}_0) p(\mathbf{x}_0|\mathbf{x}_t) d\mathbf{x}_0 \approx p_t(\mathbf{y}|X_0 = \hat{\mathbf{x}}_0(\mathbf{x}_t)), \end{aligned}$$

这里利用了以下事实: 给定 $\mathbf{x}_0$ 后, $\mathbf{y}$ 只依赖于 $\mathbf{x}_0$ (而不依赖于 $\mathbf{x}_t$); 该近似在后验 $p(\mathbf{x}_0|\mathbf{x}_t)$ 紧密集中于其均值附近的假设下成立.

由于

$$p_t(\mathbf{y}|X_0 = \hat{\mathbf{x}}_0(\mathbf{x}_t)) = \mathcal{N}(\mathbf{y}; \mathcal{A}(\hat{\mathbf{x}}_0(\mathbf{x}_t)), \sigma_y^2 \mathbf{I}),$$

可计算得到

$$\begin{aligned} \nabla_{\mathbf{x}_t} \log p_t(\mathbf{y}|\mathbf{x}_t) &\approx \nabla_{\mathbf{x}_t} \log \mathcal{N}(\mathbf{y}; \mathcal{A}(\hat{\mathbf{x}}_0), \sigma_y^2 \mathbf{I}) \\ &= -\frac{1}{2\sigma_y^2} \nabla_{\mathbf{x}_t} \|\mathbf{y} - \mathcal{A}(\hat{\mathbf{x}}_0)\|^2 \\ &= \frac{1}{\sigma_y^2} [\mathcal{J}_{\mathcal{A}}(\hat{\mathbf{x}}_0(\mathbf{x}_t)) \cdot \nabla_{\mathbf{x}_t} \hat{\mathbf{x}}_0(\mathbf{x}_t)]^\top (\mathbf{y} - \mathcal{A}(\hat{\mathbf{x}}_0(\mathbf{x}_t))), \end{aligned}$$

其中 $\mathcal{J}_{\mathcal{A}}(\hat{\mathbf{x}}_0(\mathbf{x}_t)) := \nabla_{\mathbf{x}_0} \mathcal{A}(\mathbf{x})|_{\mathbf{x}=\hat{\mathbf{x}}_0(\mathbf{x}_t)}$ 表示前向算子对其输入的雅可比矩阵. 该公式将梯度通过得分近似的整个计算流程传播, 反映了测量似然如何随含噪样本 $\mathbf{x}_t$ 的扰动而变化.

对于线性逆问题, 上式进一步简化为:

$$\nabla_{\mathbf{x}_t} \log p_t(\mathbf{y}|\mathbf{x}_t) \approx \frac{1}{\sigma_y^2} [\mathbf{A} \cdot \nabla_{\mathbf{x}_t} \hat{\mathbf{x}}_0(\mathbf{x}_t)]^\top (\mathbf{y} - \mathbf{A}(\hat{\mathbf{x}}_0(\mathbf{x}_t))).$$

大量工作通过提出 $\nabla_{\mathbf{x}_t} \log p_t(\mathbf{y}|\mathbf{x}_t)$ 的不同近似来研究基于扩散模型的逆问题求解器. 关于全面的概述, 读者可参见 Daras et al. (2024) 的综述.

8.5 从强化学习到用于模型对齐的直接偏好优化

在使生成模型与人类意图对齐的研究中，基于人类反馈的强化学习（RLHF）一直是主流范式。RLHF 虽然有效，但其流程复杂、包含多个阶段，并可能不稳定。本节介绍直接偏好优化（DPO）（Rafailov et al., 2023）：这一方法更简洁、更稳定，无需显式奖励建模或强化学习就能达到同样的目标。随后，我们概述它通过 *Diffusion-DPO*（Wallace et al., 2024）向扩散模型的推广。

8.5.1 动机：避开 RLHF 的困难

对齐的目标是引导一个预训练基础模型（例如 SFT 模型）生成更符合人类偏好的输出。RLHF 分三个阶段进行。首先，监督微调（SFT）在提示与响应的配对数据上训练基础模型。其次，奖励建模（RM）在偏好数据上拟合模型；这些数据包含提示 $\mathbf{c}$ 及成对响应（更受偏好的“胜者” $\mathbf{x}_w$ 与不受偏好的“败者” $\mathbf{x}_l$ ），学习一个满足 $r(\mathbf{c}, \mathbf{x}_w) > r(\mathbf{c}, \mathbf{x}_l)$ 的标量 $r(\mathbf{c}, \mathbf{x})$ 。第三，强化学习微调利用 PPO（Schulman et al., 2017）等算法优化 SFT 模型（策略 π^5 ），最大化来自 r 的期望奖励，同时通过 KL 惩罚进行正则化，使 π 保持接近参考分布或 SFT 分布。

尽管产生了重要影响，这一流程仍有一些缺点：强化学习阶段不稳定且计算成本高，因为它采用同策略学习，每次更新都需要当前模型新生成的样本；它还需要训练和部署多个大型模型（SFT 模型、奖励模型，有时还有价值模型）；它优化的只是人类偏好的替代指标，因此奖励模型的缺陷可能被利用。这引出了一个核心问题：

问题 8.5.1. 能否消除显式奖励建模和不稳定的强化学习步骤，直接在偏好数据上优化模型？

直接偏好优化（DPO）以单个类似监督学习的步骤替代多阶段 RLHF 流程，从而简化对齐。DPO 无需训练独立的奖励模型和运行 PPO 等不稳定的强化学习算法，而是利用简单的逻辑损失直接在偏好对上拟合策略，同时保持接近一个固定的参考模型。关键洞见是，带 KL 正则化的 RLHF 目标可以重写，使策略与参考模型之间的对数似然比充当隐式奖励。这保留了朝参考策略的相同正则化，同时避免了高成本的轨迹展开和显式奖励建模。

在节 8.5.2 中，我们简要回顾 RLHF 流程及其对大型奖励模型和强化学习微调的依赖。在节 8.5.3 中，我们介绍最初为语言模型提出的 DPO，它绕过奖励模型训练并简化对齐微调。最后，在节 8.5.4 中，我们将这一思想推广到扩散模型，介绍 Diffusion-DPO 这一在生成建模中实用且稳定的对齐方法。

8.5.2 RLHF: Bradley–Terry 视角

RLHF 简介。 RLHF 从一个学习得到的评判者开始：奖励模型 r_ψ 为同一提示 $\mathbf{c}$ 下的候选响应赋予标量偏好得分。数据集 $\mathcal{D}$ 由样本对 $(\tilde{\mathbf{x}}, \mathbf{x})$ 组成，并标注一个标签 y ，表示 $\tilde{\mathbf{x}}$ 是否比 $\mathbf{x}$ 更受偏好。标签可以是二元值 $y \in \{0, 1\}$ ，也可以是汇总多个评判者所得的

⁵策略将提示或历史（状态）映射为响应或动作的分布。

软标签 $y \in [0, 1]$. 训练目标是简单的逻辑损失

$$\mathcal{L}_{\text{RM}}(\psi) = -\mathbb{E}_{(\mathbf{c}, \tilde{\mathbf{x}}, \mathbf{x}, y) \sim \mathcal{D}} \left[y \log \sigma(r_\psi(\mathbf{c}, \tilde{\mathbf{x}}) - r_\psi(\mathbf{c}, \mathbf{x})) + (1 - y) \log (1 - \sigma(r_\psi(\mathbf{c}, \tilde{\mathbf{x}}) - r_\psi(\mathbf{c}, \mathbf{x}))) \right], \quad (8.5.1)$$

其中 $\sigma(u) = 1/(1 + e^{-u})$. 实践中, $\mathcal{D}$ 中的偏好对可以来自多种来源: 人工筛选的响应、不同检查点的模型快照, 或预训练条件扩散模型的生成结果. 一种标准约定是以有序格式 (胜者, 败者) 存储它们. 在这一约定下, 我们直接令 $y = 1$, 于是式 (8.5.1) 化为如下特殊情形 (其中 $\tilde{\mathbf{x}} = \mathbf{x}^w$ 且 $\mathbf{x} = \mathbf{x}^l$):

$$\mathcal{L}_{\text{RM}}(\psi) = -\mathbb{E}_{(\mathbf{c}, \mathbf{x}_w, \mathbf{x}_l) \sim \mathcal{D}} \left[\log \sigma(r_\psi(\mathbf{c}, \mathbf{x}_w) - r_\psi(\mathbf{c}, \mathbf{x}_l)) \right]. \quad (8.5.2)$$

Bradley–Terry 视角及与 KL 的联系. 通常将

$$p_{r_\psi}(\tilde{\mathbf{x}} \succ \mathbf{x} | \mathbf{c}) := \sigma(r_\psi(\mathbf{c}, \tilde{\mathbf{x}}) - r_\psi(\mathbf{c}, \mathbf{x}))$$

解释为 Bradley–Terry (BT) 模型 (Bradley and Terry, 1952), 它将两个标量得分转化为获胜概率. 这一形式突出两个关键性质:

- (i) 只有得分的差起作用 (因此 $r_\psi(\mathbf{c}, \cdot)$ 具有平移不变性);
- (ii) 损失推动预测胜者的得分超过败者的得分.

为直观理解第二点, 考虑一个标签为 $y \in \{0, 1\}$ 的样本对, 并定义

$$\Delta r := r_\psi(\mathbf{c}, \tilde{\mathbf{x}}) - r_\psi(\mathbf{c}, \mathbf{x}), \quad p := \sigma(\Delta r), \quad \sigma(u) = \frac{1}{1 + e^{-u}}.$$

单个样本的逻辑损失为

$$\ell = -[y \log p + (1 - y) \log(1 - p)].$$

于是

$$\frac{\partial \ell}{\partial \Delta r} = \sigma(\Delta r) - y.$$

在步长为 $\eta > 0$ 的梯度下降下, 得分差更新为

$$\Delta r \leftarrow \Delta r - \eta(\sigma(\Delta r) - y).$$

因此, 如果 $y = 1$ (“ $\tilde{\mathbf{x}}$ 获胜”), 则 $\sigma(\Delta r) - 1 \leq 0$, 所以 Δr 增大 (胜者得分上升, 败者得分下降); 如果 $y = 0$, 则 Δr 减小.

式 (8.5.1) 中的每个单样本项都可视为观测到的 Bernoulli 标签与模型预测获胜概率之间的交叉熵:

$$-[y \log p_{r_\psi} + (1 - y) \log(1 - p_{r_\psi})] = \mathcal{D}_{\text{KL}}(\text{Bern}(y) \parallel \text{Bern}(p_{r_\psi})) + \mathcal{H}(\text{Bern}(y)),$$

其中 $\mathcal{H}$ 是目标 Bernoulli 分布的熵. 在数据集 $\mathcal{D}$ 上取平均, 得到

$$\mathcal{L}_{\text{RM}}(\psi) = \mathbb{E}_{\mathcal{D}} \left[\mathcal{D}_{\text{KL}}(\text{Bern}(y) \parallel \text{Bern}(p_{r_\psi})) \right] + \underbrace{\mathbb{E}_{\mathcal{D}} [\mathcal{H}(\text{Bern}(y))]}_{\text{不依赖于 } \psi}. \quad (8.5.3)$$

因此, 最小化逻辑损失等价于最小化人类标签的经验 Bernoulli 分布与模型预测的 Bernoulli 分布之间的 KL 散度. 在二元情形 ($y \in \{0, 1\}$) 下, 这一等价关系是精确的; 对于软标签 ($y \in [0, 1]$), 两者相差一个熵常数. 直观地说, 奖励模型通过训练调整其获胜概率, 直到与数据集中观测到的人类经验获胜率一致.

从这里开始, 我们采用最常见的约定, 即 $\mathcal{D}$ 以有序格式存储样本对: $(\mathbf{x}^w, \mathbf{x}^l, \mathbf{c}) \sim \mathcal{D}$. 在这一约定下, 标签总为 $y = 1$, 损失简化为式 (8.5.2) 给出的有序形式, 下文均使用这一形式.

带 KL 正则化的策略优化 (固定奖励). 给定通过式 (8.5.2) 训练得到的奖励 $r := r_{\psi^\times}$ 以及条件预训练扩散模型 $p_{\phi^\times}(\mathbf{x}|\mathbf{c})$ 后, RLHF 调整可学习策略 $\pi_\theta(\mathbf{x}|\mathbf{c})$, 使其趋向奖励更高的响应; 该策略通常在 $p_{\phi^\times}(\mathbf{x}|\mathbf{c})$ 的基础上微调. 同时, 使用 $\mathcal{D}_{\text{KL}}$ 惩罚对策略进行正则化, 使其保持接近参考模型; 这里取预训练扩散模型 $\pi_{\text{ref}}(\mathbf{x}|\mathbf{c}) := p_{\phi^\times}(\mathbf{x}|\mathbf{c})$ 为参考模型:

$$\max_{\theta} \mathbb{E}_{\mathbf{c} \sim p(\mathbf{c})} \left[\mathbb{E}_{\mathbf{x} \sim \pi_\theta(\cdot|\mathbf{c})} [r_\psi(\mathbf{c}, \mathbf{x})] - \beta \mathcal{D}_{\text{KL}}(\pi_\theta(\cdot|\mathbf{c}) \parallel \pi_{\text{ref}}(\cdot|\mathbf{c})) \right], \quad (8.5.4)$$

这明确表达了两种作用: 寻找评判者更偏好的样本, 同时保持接近预训练参考模型.

我们指出, 式 (8.5.2) 中的奖励目标只使用已标注的样本对, 并不要求 $\mathcal{D}$ 由参考模型 (即预训练条件扩散模型) 生成. 尽管没有这一要求, 从接近目标策略的模型收集样本对, 可以减少分布偏移, 使学习得到的奖励在其实际使用的区域内更加可靠.

概括而言, RLHF 分两个阶段进行: 首先通过最小化式 (8.5.2) 中的损失 (等价地, 最小化式 (8.5.3) 中二元 $\mathcal{D}_{\text{KL}}$ 的期望) 来拟合奖励 r^* ; 然后通过求解式 (8.5.4) 来优化策略 π^* .

8.5.3 DPO 框架

从 RLHF 搭起的桥梁. 给定拟合得到的奖励 $r := r_{\psi^\times}$, 式 (8.5.4) 中带 KL 正则化的策略目标对每个提示 $\mathbf{c}$ 都有一个简单的闭式解, 可表达为以下基于能量的形式 (Peters, Mulling, and Altun, 2010):

$$\pi^*(\mathbf{x}|\mathbf{c}) = \frac{1}{Z(\mathbf{c})} \pi_{\text{ref}}(\mathbf{x}|\mathbf{c}) \exp(r(\mathbf{c}, \mathbf{x})/\beta), \quad (8.5.5)$$

其中 $\pi_{\text{ref}}(\mathbf{x}|\mathbf{c}) := p_{\phi^\times}(\mathbf{x}|\mathbf{c})$, 而 $Z(\mathbf{c})$ 是确保 $\int \pi^*(\mathbf{x}|\mathbf{c}) d\mathbf{x} = 1$ 的配分函数.

当 β 较小时, $\exp(r/\beta)$ 变得更尖锐, 因此 π^* 集中于高奖励区域: 奖励占主导, 策略远离 π_{ref} , 多样性下降, 训练可能变得不稳定或容易出现奖励投机. 当 β 较大时, $\exp(r/\beta)$ 变得平坦, 使 π^* 更接近 π_{ref} : KL 项占主导, 更新较为保守, 多样性遵循参考模型, 但奖励提升有限.

由于我们的目标是直接微调策略 (无需训练独立的奖励模型), 式 (8.5.5) 使我们可以从任意策略定义一个隐式奖励. 下文给出这一构造:

通过反解式 (8.5.5) 来定义隐式奖励. 式 (8.5.5) 提示了一个直接的反解: 对于任意策略 π (其支撑集包含于 π_{ref} 的支撑集), 定义

$$r_\pi(\mathbf{c}, \mathbf{x}) = \beta \log \frac{\pi(\mathbf{x}|\mathbf{c})}{\pi_{\text{ref}}(\mathbf{x}|\mathbf{c})} + \beta \log Z(\mathbf{c}). \quad (8.5.6)$$

于是, 将 π^* 替换为 π 后, 式 (8.5.5) 成立; 即对于奖励函数 r_π , π 将成为式 (8.5.4) 的最优解. 在此意义下, r_π 是一个隐式 (由策略诱导的) 奖励: 它只确定到一个依赖于提示的常数 $\beta \log Z(\mathbf{c})$, 而这个常数会在 BT 模型等任何成对比较中消去:

$$r_\pi(\mathbf{c}, \mathbf{x}_w) - r_\pi(\mathbf{c}, \mathbf{x}_l) = \beta \left(\log \frac{\pi(\mathbf{x}_w|\mathbf{c})}{\pi_{\text{ref}}(\mathbf{x}_w|\mathbf{c})} - \log \frac{\pi(\mathbf{x}_l|\mathbf{c})}{\pi_{\text{ref}}(\mathbf{x}_l|\mathbf{c})} \right).$$

正是这一消去使该常数与偏好学习无关, 并直接导出基于对数概率差的 DPO 损失.

DPO 的训练损失. 对于同一提示 $\mathbf{c}$ 下的已标注样本对 $(\mathbf{x}_w, \mathbf{x}_l)$, 将隐式奖励式 (8.5.6) 代入式 (8.5.2) 中的 BT 模型. 胜者与败者之间的常数 $\log Z(\mathbf{c})$ 相互抵消, 得到一个关于对数概率差的单一逻辑损失目标:

$$\mathcal{L}_{\text{DPO}}(\theta; \pi_{\text{ref}}) = -\mathbb{E}_{(\mathbf{c}, \mathbf{x}_w, \mathbf{x}_l) \sim \mathcal{D}} \left[\log \sigma \left(\beta \left(\log \frac{\pi_\theta(\mathbf{x}_w|\mathbf{c})}{\pi_{\text{ref}}(\mathbf{x}_w|\mathbf{c})} - \log \frac{\pi_\theta(\mathbf{x}_l|\mathbf{c})}{\pi_{\text{ref}}(\mathbf{x}_l|\mathbf{c})} \right) \right) \right].$$

用文字表达, DPO 提高胜者相对于败者的 (经温度缩放的) 优势; 这一优势用相对于参考模型的对数似然改进之差来衡量:

$$-\log \sigma \left(\beta \left[\text{下列比值的对数之差: } \frac{\pi_\theta}{\pi_{\text{ref}}} \text{ 在 } \mathbf{x}_w \text{ 与 } \mathbf{x}_l \right] \right).$$

这通过单个稳定的、类似最大似然的阶段实现了 RLHF 的目标, 无需训练显式奖励模型.

8.5.4 Diffusion-DPO

为何朴素 DPO 不适用于扩散模型？ 在扩散模型中计算样本似然 $\pi_\theta(\mathbf{x}|\mathbf{c})$ ，需要在求解 ODE 时使用瞬时变量替换公式（漂移的散度，见式 (4.2.7)）⁶，计算成本很高。此外，通过整个采样轨迹求导可能遭遇梯度消失或爆炸。为避免这些问题，Diffusion-DPO 在路径层面工作。我们以离散时间扩散模型（例如 DDPM）为例说明；连续时间扩散模型的情况类似。

定义路径层面的隐式奖励。 令 $\mathbf{x}_{0:T} := (\mathbf{x}_T, \dots, \mathbf{x}_0)$ 表示具有条件核 $\pi(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{c})$ 的逆时间 Markov 链的一条轨迹。这里， $\mathbf{x}_T$ 表示从先验中取得的样本（最高噪声）， $\mathbf{x}_0$ 是数据空间中的干净输出。由于扩散模型的生成沿完整的去噪路径进行，将偏好从最终输出推广到整个轨迹是自然的。因此，我们为每条轨迹赋予奖励 $R(\mathbf{c}, \mathbf{x}_{0:T})$ ；如果该奖励只依赖于 $\mathbf{x}_0$ ，便退化为端点奖励，但它也可以刻画沿路径累积的影响。

我们将式 (8.5.4) 中样本层面的 KL 替换为路径层面的 KL：

$$\max_{\theta} \mathbb{E}_{\mathbf{c} \sim p(\mathbf{c})} \left[\underbrace{\mathbb{E}_{\mathbf{x}_{0:T} \sim \pi_\theta(\cdot|\mathbf{c})} [R(\mathbf{c}, \mathbf{x}_{0:T})]}_{\text{路径奖励}} - \beta \mathcal{D}_{\text{KL}}(\pi_\theta(\cdot|\mathbf{c}) \parallel \pi_{\text{ref}}(\cdot|\mathbf{c})) \right],$$

其中 $\pi_\theta(\cdot|\mathbf{c})$ 和 $\pi_{\text{ref}}(\cdot|\mathbf{c})$ 是路径分布。该目标旨在最大化反向过程 $\pi_\theta(\cdot|\mathbf{c})$ 的奖励，同时匹配原始参考反向过程 $\pi_{\text{ref}}(\cdot|\mathbf{c})$ 的分布。

对于每个提示 $\mathbf{c}$ ，最优解具有简单的基于能量的形式

$$\pi^*(\mathbf{x}_{0:T}|\mathbf{c}) = \frac{1}{Z(\mathbf{c})} \pi_{\text{ref}}(\mathbf{x}_{0:T}|\mathbf{c}) \exp(R(\mathbf{c}, \mathbf{x}_{0:T})/\beta), \quad (8.5.7)$$

其中 $Z(\mathbf{c})$ 是归一化因子。反解式 (8.5.7)，便可为任意策略 π 定义一个隐式路径奖励：

$$R_\pi(\mathbf{c}, \mathbf{x}_{0:T}) := \beta \log \frac{\pi(\mathbf{x}_{0:T}|\mathbf{c})}{\pi_{\text{ref}}(\mathbf{x}_{0:T}|\mathbf{c})} + \beta \log Z(\mathbf{c}),$$

其中常数 $\beta \log Z(\mathbf{c})$ 与成对比较无关。

从路径隐式奖励到 DPO。 对于同一提示 $\mathbf{c}$ 下的已标注样本对 $(\mathbf{x}_0^w, \mathbf{x}_0^l)$ ，将 Bradley-Terry 模型应用于路径，并使用标准的逻辑对数损失：

$$\begin{aligned} \mathcal{L}_{\text{Diff-DPO}}(\theta; \pi_{\text{ref}}) &:= -\mathbb{E}_{(\mathbf{c}, \mathbf{x}_0^w, \mathbf{x}_0^l) \sim \mathcal{D}} [\log \sigma(\Delta R(\mathbf{c}; \theta))], \quad \text{其中} \\ \Delta R(\mathbf{c}; \theta) &:= \underbrace{\mathbb{E}_{\mathbf{x}_{1:T}^w \sim \pi_\theta(\cdot|\mathbf{x}_0^w, \mathbf{c})} [R_{\pi_\theta}(\mathbf{c}, (\mathbf{x}_0^w, \mathbf{x}_{1:T}^w))]}_{\text{胜者路径期望}} \\ &\quad - \underbrace{\mathbb{E}_{\mathbf{x}_{1:T}^l \sim \pi_\theta(\cdot|\mathbf{x}_0^l, \mathbf{c})} [R_{\pi_\theta}(\mathbf{c}, (\mathbf{x}_0^l, \mathbf{x}_{1:T}^l))]}_{\text{败者路径期望}}. \end{aligned} \quad (8.5.8)$$

这里，期望 $\mathbb{E}_{\mathbf{x}_{1:T} \sim \pi_\theta(\cdot|\mathbf{x}_0, \mathbf{c})}[\cdot]$ 的含义是：给定数据集中的固定端点 $\mathbf{x}_0$ （例如胜者 $\mathbf{x}_0^w$ ），我们在模型诱导的条件路径分布（逆时间轨迹的后验）下，对潜在去噪轨迹 $\mathbf{x}_{1:T}$ 取期望；

⁶在离散时间扩散模型（例如 DDPM）中，计算 $\pi_\theta(\mathbf{x}_0|\mathbf{c})$ 需要对潜在反向轨迹 $\mathbf{x}_{1:T}$ 进行边缘化。

这些轨迹可以通过条件核 $\pi_{\theta}(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{c})$ 产生 $\mathbf{x}_0$. 由于这些中间状态未被观测, 我们对所有这样的轨迹上的路径奖励取平均.

然而, 式 (8.5.8) 由于以下三个实际原因而难以应用:

1. **端点条件诱导难以求解的路径后验.** 项 $\mathbb{E}_{\pi_{\theta}(\mathbf{x}_{1:T}|\mathbf{x}_0, \mathbf{c})}[\cdot]$ 对被约束为到达 $\mathbf{x}_0$ 的反向路径取平均, 而采样器在不施加这一约束的情况下运行 $\mathbf{x}_T \rightarrow \cdots \rightarrow \mathbf{x}_0$. 以端点为条件会产生一个扩散桥后验, 通常没有闭式表达且采样成本高.
2. **嵌套且与 θ 耦合的期望.** 在损失 $-\log \sigma(\Delta R(\mathbf{c}; \theta))$ 中,

$$\Delta R = \mathbb{E}_{\text{路径}|\mathbf{x}_0^w, \mathbf{c}}[R_{\pi_{\theta}}] - \mathbb{E}_{\text{路径}|\mathbf{x}_0^l, \mathbf{c}}[R_{\pi_{\theta}}]$$

路径的联合分布和被积函数 $R_{\pi_{\theta}}$ 都依赖于 θ . 因此, ∇_{θ} 必须通过采样分布求导, 产生 REINFORCE 或路径求导的耦合, 以及高方差梯度.

3. **长链、大量求和与高成本反向传播.** 在 $R_{\pi_{\theta}}(\mathbf{c}, \mathbf{x}_{0:T})$ 中, 计算

$$\beta [\log \pi_{\theta}(\mathbf{x}_{0:T}|\mathbf{c}) - \log \pi_{\text{ref}}(\mathbf{x}_{0:T}|\mathbf{c})]$$

需要对策略 π_{θ} 和参考模型 π_{ref} , 以及胜者和败者两条路径, 分别计算 $\mathcal{O}(T)$ 个逐步对数密度, 其中 $T \sim 10^2$ 至 10^3 . 通过这些随机链 (或桥采样器) 反向传播需要大量内存和计算, 并可能不稳定; 若对每个样本对的多个样本以及所有三元组重复此过程, 训练成本将超出实际预算.

构造式 (8.5.8) 的可计算替代目标. 为使这一目标可以计算, 我们运用一个关键的数学洞见. 利用扩散模型的性质并应用 Jensen 不等式, 可以优化该损失的一个可计算上界. 这将问题从计算整条路径的似然转化为计算路径中各个单步转移上的期望:

由于 $-\log \sigma(\cdot)$ 是凸函数, Jensen 不等式允许将内层期望移到对数之外, 从而得到上界:

$$\begin{aligned} & \mathcal{L}_{\text{Diff-DPO}}(\theta; \pi_{\text{ref}}) \\ & \leq -\mathbb{E}_{(\mathbf{c}, \mathbf{x}_0^w, \mathbf{x}_0^l) \sim \mathcal{D}} \mathbb{E}_{\substack{\mathbf{x}_{1:T}^w \sim \pi_{\theta}(\cdot|\mathbf{x}_0^w, \mathbf{c}) \\ \mathbf{x}_{1:T}^l \sim \pi_{\theta}(\cdot|\mathbf{x}_0^l, \mathbf{c})}} \left[\log \sigma \left(\beta (R(\mathbf{c}, \mathbf{x}_{0:T}^w) - R(\mathbf{c}, \mathbf{x}_{0:T}^l)) \right) \right]. \end{aligned}$$

使用隐式奖励恒等式 $R_{\pi_{\theta}} = \beta \log \frac{\pi_{\theta}}{\pi_{\text{ref}}} + \beta \log Z(\mathbf{c})$, 并消去胜者与败者之间的常数, 该上界变为

$$\mathcal{L}_{\text{Diff-DPO}}(\theta; \pi_{\text{ref}}) \leq -\mathbb{E} \left[\log \sigma \left(\beta \left(\log \frac{\pi_{\theta}(\mathbf{x}_{0:T}^w|\mathbf{c})}{\pi_{\text{ref}}(\mathbf{x}_{0:T}^w|\mathbf{c})} - \log \frac{\pi_{\theta}(\mathbf{x}_{0:T}^l|\mathbf{c})}{\pi_{\text{ref}}(\mathbf{x}_{0:T}^l|\mathbf{c})} \right) \right) \right]. \quad (8.5.9)$$

可计算的替代目标 (逐步形式). 我们现在利用反向过程的 Markov 性质来分解 $\mathcal{L}_{\text{Diff-DPO}}$ 的上界. 这使我们能够将路径层面的偏好表示为逐步贡献之和, 把难以求解的路径损失转化为可计算的单步估计量. 所得形式归结为类似 DSM 的 MSE 之差. 具体

而言，对于反向链，

$$\begin{aligned}\pi_{\theta}(\mathbf{x}_{0:T}|\mathbf{c}) &= \pi_{\theta}(\mathbf{x}_T|\mathbf{c}) \prod_{t=1}^T \pi_{\theta}(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{c}), \\ \pi_{\text{ref}}(\mathbf{x}_{0:T}|\mathbf{c}) &= \pi_{\text{ref}}(\mathbf{x}_T|\mathbf{c}) \prod_{t=1}^T \pi_{\text{ref}}(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{c}).\end{aligned}$$

因此

$$\frac{\pi_{\theta}(\mathbf{x}_{0:T}|\mathbf{c})}{\pi_{\text{ref}}(\mathbf{x}_{0:T}|\mathbf{c})} = \frac{\pi_{\theta}(\mathbf{x}_T|\mathbf{c})}{\pi_{\text{ref}}(\mathbf{x}_T|\mathbf{c})} \prod_{t=1}^T \frac{\pi_{\theta}(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{c})}{\pi_{\text{ref}}(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{c})}.$$

如果两个模型在时间 T 处的先验相同，即 $\pi_{\theta}(\mathbf{x}_T|\mathbf{c}) = \pi_{\text{ref}}(\mathbf{x}_T|\mathbf{c})$ ，则第一个因子等于 1，取对数得到

$$\log \frac{\pi_{\theta}(\mathbf{x}_{0:T}|\mathbf{c})}{\pi_{\text{ref}}(\mathbf{x}_{0:T}|\mathbf{c})} = \sum_{t=1}^T \log \frac{\pi_{\theta}(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{c})}{\pi_{\text{ref}}(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{c})}.$$

于是，式 (8.5.9) 中的上界可以写成

$$\mathcal{L}_{\text{Diff-DPO}}(\boldsymbol{\theta}; \pi_{\text{ref}}) \leq -\mathbb{E} \left[\log \sigma \left(\beta \sum_{t=1}^T \Delta_t \right) \right],$$

其中每步的贡献为

$$\Delta_t = \log \frac{\pi_{\theta}(\mathbf{x}_{t-1}^w|\mathbf{x}_t^w, \mathbf{c})}{\pi_{\text{ref}}(\mathbf{x}_{t-1}^w|\mathbf{x}_t^w, \mathbf{c})} - \log \frac{\pi_{\theta}(\mathbf{x}_{t-1}^l|\mathbf{x}_t^l, \mathbf{c})}{\pi_{\text{ref}}(\mathbf{x}_{t-1}^l|\mathbf{x}_t^l, \mathbf{c})}.$$

为得到可计算的估计量，我们应用单步 Jensen 上界：采样 $t \sim \mathcal{U}\{1, \dots, T\}$ （每个训练样本对选取一个时间步），并用 T 重标度。这给出

$$-\log \sigma \left(\beta \sum_{t=1}^T \Delta_t \right) \leq \mathbb{E}_t \left[-\log \sigma(\beta T \Delta_t) \right].$$

因此，最终目标是逐步替代量的期望，

$$\mathcal{L}_{\text{Diff-DPO}}(\boldsymbol{\theta}; \pi_{\text{ref}}) \leq -\mathbb{E}_{\substack{(\mathbf{c}, \mathbf{x}_0^w, \mathbf{x}_0^l) \sim \mathcal{D} \\ t \sim \mathcal{U}\{1, \dots, T\}}} \left[\log \sigma(\beta T \Delta_t) \right],$$

它将原始的路径损失简化为可计算的单步上界估计量。

对于扩散模型中使用的高斯反向条件分布（以 ϵ 预测为例），

$$\log \frac{\pi_{\theta}(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{c})}{\pi_{\text{ref}}(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{c})} = \text{常数} - \lambda_t \left(\underbrace{\|\hat{\epsilon}_{\theta}(\mathbf{x}_t, t, \mathbf{c}) - \epsilon_t\|^2}_{\text{策略}} - \underbrace{\|\hat{\epsilon}_{\text{ref}}(\mathbf{x}_t, t, \mathbf{c}) - \epsilon_t\|^2}_{\text{参考模型}} \right),$$

其中 $\lambda_t > 0$ 吸收了噪声调度中的因子。因此，每个时间的贡献正比于时间切片 t 处的 MSE 之差（策略与参考模型之差）。

为简化记号，对任意 $\mathbf{x}_t$ 定义：

$$\Delta \text{MSE}(\mathbf{x}_t) := \|\hat{\epsilon}_{\theta}(\mathbf{x}_t, t, \mathbf{c}) - \epsilon\|^2 - \|\hat{\epsilon}_{\text{ref}}(\mathbf{x}_t, t, \mathbf{c}) - \epsilon\|^2.$$

由此得到 $\mathcal{L}_{\text{Diff-DPO}}(\boldsymbol{\theta}; \pi_{\text{ref}})$ 的如下实用替代目标：

$$\tilde{\mathcal{L}}_{\text{Diff-DPO}}(\boldsymbol{\theta}; \pi_{\text{ref}}) := \mathbb{E}_{\substack{(\mathbf{c}, \mathbf{x}_0^w, \mathbf{x}_0^l) \sim \mathcal{D} \\ t \sim \mathcal{U}\{1, \dots, T\}, \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})}} \left[w(t) (\Delta \text{MSE}(\mathbf{x}_t^w) - \Delta \text{MSE}(\mathbf{x}_t^l)) \right],$$

其中 $\mathbf{x}_t^w = \alpha_t \mathbf{x}_0^w + \sigma_t \boldsymbol{\epsilon}$ 与 $\mathbf{x}_t^l = \alpha_t \mathbf{x}_0^l + \sigma_t \boldsymbol{\epsilon}$ 共享相同噪声 $\boldsymbol{\epsilon}$ 以降低方差，而 $w(t) > 0$ 汇集了时间权重（例如 $w(t) \propto \lambda_t$ ）。

直观地说，最小化 $\tilde{\mathcal{L}}_{\text{Diff-DPO}}$ 提高了模型在胜者上的预测精度（相对于参考模型），并降低其在败者上的预测精度。由于改进始终相对于同一时间步的 π_{ref} 来衡量，策略被推动着趋向类似胜者的去噪轨迹，远离类似败者的轨迹，同时仍以参考模型为锚点。

8.6 结语

本章将关注点从基础原理转向可控生成这一实际挑战。我们基于条件得分的贝叶斯分解建立了统一的引导框架，将生成过程清晰地分成无条件方向与引导项。

我们看到，这一原则体现在若干强大的技术之中。我们介绍了需要专门训练的方法，例如使用外部分类器的分类器引导（CG），以及在单个模型中学习条件得分和无条件得分、效率更高的无分类器引导（CFG）。我们还探索了灵活的无需训练的引导方法：在推断时，从任意损失函数定义替代似然，就可以引导预训练模型；无需任何重新训练，便可实现从艺术创作控制到逆问题求解的应用。

除了简单的条件控制，我们还深入探讨了使模型输出与人类偏好对齐这一更细致的任务。在回顾标准但复杂的 RLHF 流程后，我们介绍了直接偏好优化（DPO）及其新推广 Diffusion-DPO，作为更直接、更稳定的方法。这一方法直接从偏好数据推导损失，从而绕过了显式奖励模型和强化学习的需要。

通过这些技术，我们构建了一套强大的生成过程引导工具。然而，一个主要的实际障碍仍未处理：迭代采样过程本身的显著计算成本与延迟。在解决了生成什么的问题之后，我们现在转向同样重要的问题：能以多快的速度生成。下一章将直接处理这一挑战：

1. 利用采样等价于求解 ODE 这一洞见，我们将探索旨在大幅减少所需步数的高效数值求解器。
2. 我们将研究一系列有影响力的方法，包括 DDIM、DEIS 和 DPM-Solver 家族；它们将采样速度提升数个数量级，使扩散模型更具实用性。

第 9 章 用于快速采样的高效求解器

扩散模型将噪声映射为数据样本的生成过程，在数学上等价于求解 SDE 或与之关联的 ODE. 这一过程本身较慢，因为它依赖数值求解器，通过许多小积分步来近似解轨迹（简要介绍见章 A）. 因此，加速推断成为核心研究目标. 总体而言，现有方法分为两类：

- **无需训练的方法**：本章的重点. 这些方法开发先进数值求解器，无需额外训练即可提高扩散采样效率.
- **需要训练的方法**：在章 10 和 11 中介绍. 这些技术将预训练扩散模型蒸馏为快速生成器，或直接学习 ODE 流映射（解），使采样只需少量步骤.

基于 SDE 的采样器（例如 Euler-Maruyama 方法）由于具有随机性，可能产生更多样的样本，但通常需要更多步骤 (Xu et al., 2023). 这里我们关注基于 ODE 的生成，其原理可以自然推广到 SDE 设定.

9.1 序言

9.1.1 扩散模型的先进求解器

得分 SDE 框架 (Song et al., 2020b) 通过严格联系离散时间扩散与 ELBO 表述 (Sohl-Dickstein et al., 2015; Ho, Jain, and Abbeel, 2020) 和生成建模的连续时间 SDE / ODE 视角, 奠定了关键基础. 这一统一不仅使理论更清晰, 也使基于数值积分、有原则地开发高效采样算法成为可能.

具体而言, 假设有一个预训练扩散模型 $\mathbf{s}_{\phi \times}(\mathbf{x}, t) \approx \nabla_{\mathbf{x}} \log p_t(\mathbf{x})$ (它还可以写成分节 6.3 中的另外三种等价形式). 此时, 采样过程可以视为求解初始条件为 $\mathbf{x}(T) \sim p_{\text{prior}}$ 的 PF-ODE, 从 $t = T$ 沿时间反向积分到 $t = 0$:

$$\frac{d\mathbf{x}(t)}{dt} = \mathbf{f}(\mathbf{x}(t), t) - \frac{1}{2}g^2(t) \underbrace{\nabla_{\mathbf{x}} \log p_t(\mathbf{x}(t))}_{\approx \mathbf{s}_{\phi \times}(\mathbf{x}(t), t)}.$$

这一 ODE 与前向随机过程直接关联:

$$d\mathbf{x}(t) = \mathbf{f}(\mathbf{x}(t), t) dt + g(t) d\mathbf{w}(t),$$

这显示了生成 (逆时间) 动力学与加噪 (正时间) 动力学之间的连续时间联系.

PF-ODE 的精确解可以等价地写成积分形式:

$$\begin{aligned} \Psi_{T \rightarrow 0}(\mathbf{x}(T)) &= \mathbf{x}(T) + \int_T^0 \left[f(\tau)\mathbf{x}(\tau) - \frac{1}{2}g^2(\tau)\nabla_{\mathbf{x}} \log p_{\tau}(\mathbf{x}(\tau)) \right] d\tau \\ &\approx \mathbf{x}(T) + \int_T^0 \left[f(\tau)\mathbf{x}(\tau) - \frac{1}{2}g^2(\tau)\mathbf{s}_{\phi \times}(\mathbf{x}(\tau), \tau) \right] d\tau \\ &=: \tilde{\Psi}_{T \rightarrow 0}(\mathbf{x}(T)). \end{aligned} \tag{9.1.1}$$

这里, $\Psi_{s \rightarrow t}(\mathbf{x})$ 表示理想 PF-ODE 的流映射, 将时间 s 处的状态 $\mathbf{x}$ 映射为时间 t 处演化后的状态 (见式 (4.1.9)). 而 $\tilde{\Psi}_{s \rightarrow t}(\mathbf{x})$ 表示经验 PF-ODE 的流映射, 即将真实扩散模型 $\nabla_{\mathbf{x}} \log p_t(\mathbf{x})$ 替换为学习得到的近似 $\mathbf{s}_{\phi \times}(\mathbf{x}, t)$. 因此, $\tilde{\Psi}_{s \rightarrow t} \approx \Psi_{s \rightarrow t}$.

由于 $\tilde{\Psi}_{s \rightarrow t}$ 的积分形式无法以闭式计算, 采样必须依赖数值求解器. 这些方法将时间离散化, 以局部漂移求值的有限和代替连续积分, 从而追踪近似轨迹并近似解. 这种基于求解器的积分类近似称为快速扩散采样的无需训练算法, 因为它们直接利用冻结的预训练得分模型 $\mathbf{s}_{\phi \times}$ 近似 PF-ODE 的解, 无需任何额外学习.

下面首先详细介绍数值求解器的共同概念, 并引入后文使用的记号.

连续轨迹的离散近似. 令 $\mathbf{x}_T$ 表示时间 T 处的初始状态, 并考虑递减分割

$$T = t_0 > t_1 > \dots > t_M = 0. \tag{9.1.2}$$

从 $\tilde{\mathbf{x}}_{t_0} = \mathbf{x}_T \sim p_{\text{prior}}$ 出发, 求解器产生序列 $\{\tilde{\mathbf{x}}_{t_i}\}_{i=0}^M$, 理想情况下它近似经验 PF-ODE 流 $\tilde{\Psi}_{T \rightarrow t_i}(\mathbf{x}_T)$, 后者本身是理想映射 $\Psi_{T \rightarrow t_i}(\mathbf{x}_T)$ 的替代近似. 每个数值步骤通过这一经验速度场推进状态, 最终迭代值 $\tilde{\mathbf{x}}_{t_M}$ 作为 $t = 0$ 处干净样本 $\mathbf{x}_0$ 的估计.

9.1.2 文献中设计求解器的共同框架

Zhang and Chen (2022) 强调了为扩散模型关联的 PF-ODE 设计数值求解器的三个实用原则.

I. 半线性结构. 尽管 Song et al. (2020b) 为一般漂移 $\mathbf{f}(\mathbf{x}(t), t)$ 奠定了基础, 在大多数调度表述中, 漂移被具体设为线性形式

$$\mathbf{f}(\mathbf{x}, t) := f(t) \mathbf{x}, \quad f: \mathbb{R} \rightarrow \mathbb{R},$$

从而使 PF-ODE 具有半线性结构:

$$\frac{d\mathbf{x}(t)}{dt} = \underbrace{f(t)\mathbf{x}(t)}_{\text{线性部分}} - \underbrace{\frac{1}{2}g^2(t)\mathbf{s}_{\phi^\times}(\mathbf{x}(t), t)}_{\text{非线性部分}}. \quad (9.1.3)$$

这种关于 $\mathbf{x}$ 的线性与非线性分拆有利于精度和稳定性, 并推动了专门积分器的设计 (见下文式 (9.1.6) 附近的讨论) (Hochbruck and Ostermann, 2005; Hochbruck and Ostermann, 2010).

II. 得分之外的参数化. 当 $t \rightarrow 0$ 时, 真实得分 $\nabla_{\mathbf{x}} \log p_t(\cdot)$ 可能变化得非常快 (例如, 当 p_{data} 集中于低维流形附近时) (Kim et al., 2022). 这使得直接训练以近似得分的神经网络 $\mathbf{s}_{\phi^\times}$ 难以保持精确.

为理解其原因, 回顾理想关系 (见式 (6.3.1))

$$\boldsymbol{\epsilon}^*(\mathbf{x}_t, t) = -\sigma_t \nabla_{\mathbf{x}} \log p_t(\mathbf{x}_t),$$

其中 $\boldsymbol{\epsilon}^*(\mathbf{x}_t, t) = \mathbb{E}[\boldsymbol{\epsilon}|\mathbf{x}_t]$ 是理想噪声, (α_t, σ_t) 是扰动核的均值和标准差:

$\mathbf{x}_t | \mathbf{x}_0 \sim \mathcal{N}(\alpha_t \mathbf{x}_0, \sigma_t^2 I)$, 它们通过式 (4.4.2) 与 $f(t), g(t)$ 相联系. 根据 L^2 中的正交性质,

$$\mathbb{E} \|\boldsymbol{\epsilon}\|_2^2 = \mathbb{E} \|\boldsymbol{\epsilon}^*\|_2^2 + \mathbb{E} \|\boldsymbol{\epsilon} - \boldsymbol{\epsilon}^*\|_2^2 \Rightarrow \mathbb{E} \|\boldsymbol{\epsilon}^*\|_2^2 \leq \mathbb{E} \|\boldsymbol{\epsilon}\|_2^2 = D.$$

因此, 理想噪声预测器始终有界, 但得分按下式增长:

$$\mathbb{E} \|\mathbf{s}^*(\mathbf{x}_t, t)\|_2^2 = \sigma_t^{-2} \mathbb{E} \|\boldsymbol{\epsilon}^*(\mathbf{x}_t, t)\|_2^2 \leq \frac{D}{\sigma_t^2}.$$

所以, 当 $t \rightarrow 0$ 时, 得分可能以 $1/\sigma_t^2$ 的速率发散, 而噪声预测器保持有界. 由于神经网络只能近似平滑增长的函数, 得分预测往往数值不稳定且精度较低; 当数值 PF-ODE 求解器依赖预训练模型作为漂移时, 这又可能影响其表现.

因此, 一种广泛使用的替代方案是预测噪声 $\boldsymbol{\epsilon}_{\phi^\times}$ (或其变体, 例如 $\mathbf{x}$ 预测或 $\mathbf{v}$ 预测),

它稳定有界, 并与得分具有简单的闭式关系:

$$\mathbf{s}_{\phi^\times}(\mathbf{x}, t) = -\frac{1}{\sigma_t} \boldsymbol{\epsilon}_{\phi^\times}(\mathbf{x}, t).$$

将这一关系代入 PF-ODE (参见式 (6.3.2)) 得到

$$\frac{d\mathbf{x}(t)}{dt} = \underbrace{f(t)\mathbf{x}(t)}_{\text{线性部分}} + \underbrace{\frac{1}{2} \frac{g^2(t)}{\sigma_t} \boldsymbol{\epsilon}_{\phi \times}(\mathbf{x}(t), t)}_{\text{非线性部分}}. \quad (9.1.4)$$

现代 PF-ODE 求解器普遍采用这一参数化.

III. 半线性 PF-ODE 的指数积分器. 对于式 (9.1.4) 中的半线性结构, 式 (9.1.6) 中的指数积分器公式提供了解的另一种精确表示. 为说明这一点, 令 $\mathbf{x}_s$ 表示起始时间 s 处的状态, 令 $t \in [0, s]$ 为终止时间¹.

为清晰起见, 将式 (9.1.4) 的非线性部分写作

$$\mathbf{N}(\mathbf{x}(t), t) := \frac{1}{2} \frac{g^2(t)}{\sigma_t} \boldsymbol{\epsilon}_{\phi \times}(\mathbf{x}(t), t).$$

于是 ODE 可写为

$$\frac{d\mathbf{x}(t)}{dt} - \underbrace{f(t)\mathbf{x}(t)}_{\text{线性部分}} = \underbrace{\mathbf{N}(\mathbf{x}(t), t)}_{\text{非线性部分}}. \quad (9.1.5)$$

为分离线性项, 我们引入指数积分因子

$$\mathcal{E}(s \rightarrow t) := \exp\left(\int_s^t f(u) du\right),$$

并将 ODE 两侧乘以其逆 $\mathcal{E}(t \rightarrow s)$. 由乘积法则,

$$\mathcal{E}^{-1}(s \rightarrow t) \left(\frac{d\mathbf{x}(t)}{dt} - f(t)\mathbf{x}(t) \right) = \frac{d}{dt} \left[\mathcal{E}^{-1}(s \rightarrow t) \mathbf{x}(t) \right].$$

于是方程变为

$$\frac{d}{dt} \left[\mathcal{E}^{-1}(s \rightarrow t) \mathbf{x}(t) \right] = \mathcal{E}^{-1}(s \rightarrow t) \mathbf{N}(\mathbf{x}(t), t).$$

从 s 积分到 t , 再乘回 $\mathcal{E}(s \rightarrow t)$, 得到解:

$$\tilde{\Psi}_{s \rightarrow t}(\mathbf{x}_s) = \underbrace{\mathcal{E}(s \rightarrow t) \mathbf{x}_s}_{\text{线性部分}} + \frac{1}{2} \int_s^t \frac{g^2(\tau)}{\sigma_\tau} \mathcal{E}(\tau \rightarrow t) \boldsymbol{\epsilon}_{\phi \times}(\mathbf{x}_\tau, \tau) d\tau. \quad (9.1.6)$$

完整推导细节请参见节 A.1.3.

¹这里 s 是起始时间, t 是终止时间, 因此采样在 $s > t$ 时沿时间反向积分.

为解释为何在少步采样 (较大的 Δs) 中, 式 (9.1.6) 的指数积分形式优于式 (9.1.4), 我们比较两者的单步更新. 使用常数变易法, 令 $\mathcal{E}(s \rightarrow s - \Delta s) = e^{-f(s)\Delta s}$, 并在 $\tau \in [s - \Delta s, s]$ 上冻结 $\mathbf{N}(\mathbf{x}(\tau), \tau) \approx \mathbf{N}(\mathbf{x}_s, s)$, 则式 (9.1.6) 的指数 Euler 更新为

$$\mathbf{x}_{s-\Delta s}^{\text{Exp-Euler}} = \underbrace{e^{-f(s)\Delta s} \mathbf{x}_s}_{\text{线性部分}} + \underbrace{\frac{e^{-f(s)\Delta s} - 1}{f(s)} \mathbf{N}(\mathbf{x}_s, s)}_{\text{非线性部分}}, \quad (9.1.7)$$

当 $f \rightarrow 0$ 时, 有自然极限 $(e^{-f\Delta s} - 1)/f \rightarrow -\Delta s$. 这里线性因子 $e^{-f(s)\Delta s}$ 被精确计算 (没有近似).

相比之下, 在 $\tau \in [s - \Delta s, s]$ 上近似 $f(\tau)\mathbf{x}_\tau - \mathbf{N}(\mathbf{x}_\tau, \tau) \approx f(s)\mathbf{x}_s - \mathbf{N}(\mathbf{x}_s, s)$, 得到式 (9.1.4) 的普通 Euler 步骤:

$$\mathbf{x}_{s-\Delta s}^{\text{Euler}} = \mathbf{x}_s - \Delta s [f(s)\mathbf{x}_s + \mathbf{N}(\mathbf{x}_s, s)] = \underbrace{(1 - f(s)\Delta s) \mathbf{x}_s}_{\text{线性部分}} - \underbrace{\Delta s \mathbf{N}(\mathbf{x}_s, s)}_{\text{非线性部分}}. \quad (9.1.8)$$

式 (9.1.8) 中的线性因子是式 (9.1.7) 中指数的一阶 Taylor 近似:

$$e^a = 1 + a + \frac{a^2}{2} + \frac{a^3}{6} + \cdots, \quad a := -f(s)\Delta s,$$

因此, 差值为 $e^a - (1 + a) = \frac{a^2}{2} + \mathcal{O}(a^3)$. 一旦 $|f(s)|\Delta s$ 并非极小 (即步长 Δs 不够小), Euler 的线性更新 $(1 + a)\mathbf{x}_s$ 就会错误缩放真实因子 $e^a\mathbf{x}_s$, 相对误差为 $a/2$ 量级. 这纯粹是离散化产生的线性失真. 指数 Euler 步骤通过使用精确线性乘子来避免它, 这在采用大步长时尤为重要.

9.1.3 PF-ODE 数值求解器的方法

扩散模型的数值求解器总体上可分为两类.

时间步进方法. 这类方法将时间区间 $[0, T]$ 离散化, 并使用各种旨在提高效率的数值积分方案近似 PF-ODE. 我们选取最基础、最有原则且最广泛采用的方法作为代表性例子:

去噪扩散隐式模型 (DDIM). DDIM 在节 9.2 中介绍 (其更新形式已出现于节 4.1.4), 是扩散模型最早的快速采样器之一. 它最初从变分视角提出, 通过引入边缘分布与原扩散过程相同的非 Markov 前向族, 实现确定性反向过程和灵活跳步. 不过, 从 ODE 视角可更直接地理解 DDIM: 它对应于对指数积分公式式 (9.1.6) 应用单个指数 Euler 步骤, 即将积分内部的扩散模型项近似为常数, 从而得到式 (9.1.7) 中的更新.

扩散指数积分采样器 (DEIS). 在节 9.3 中介绍的 DEIS (Zhang and Chen, 2022) 率先通过应用指数积分器利用 PF-ODE 的半线性结构. 关键思想是利用积分因子精确处理线性部分, 只近似非线性积分项. 与在指数积分器公式中假设被积函数恒定的 Euler 方法不同, DEIS 复用沿轨迹先前估计点的历史. 具体而言, 它对过去的求值拟合高阶

插值 (*Lagrange* 多项式), 并用它近似下一步的积分. 从几何上看, 这种多项式插值比常数近似更准确地刻画轨迹曲率, 从而在大步长下实现更高阶精度和更好的稳定性.

通过复用过去的求值来确定下一次更新 (使每步只需一次新的模型调用), 称为多步方法. 相比之下, 单步方法 (例如 DDIM) 仅依赖最近的状态进行下一次更新. 这类方法更简单, 但为了达到高精度通常成本更高, 因为总体上需要更多函数求值 (或更多步骤).

扩散概率模型 (DPM) 求解器家族. DPM-Solver 家族包括 DPM-Solver (Lu et al., 2022b) (节 9.4)、DPM-Solver++ (Lu et al., 2022c) (节 9.5) 及 DPM-Solver-v3 (Zheng et al., 2023) (节 9.7); 它们基于 PF-ODE 的半线性结构, 并采用关键的时间重参数化, 即半对数信噪比 (*SNR*):

$$\lambda_t := \frac{1}{2} \log \frac{\alpha_t^2}{\sigma_t^2} = \log \frac{\alpha_t}{\sigma_t}.$$

这一变量替换将非线性项转化为指数加权积分

$$\int_{\lambda_s}^{\lambda_t} e^{-\lambda} \hat{\epsilon}_{\phi^\times}(\hat{\mathbf{x}}_\lambda, \lambda) d\lambda,$$

其中 $\hat{\epsilon}_{\phi^\times}$ 表示用重参数化时间 λ 表达的模型 (细节见式 (9.4.4)). 这种表示使积分的高阶近似更精确.

DPM-Solver 通过针对半对数 SNR 重参数化、在 λ 上使用 Taylor 展开, 引入高阶求解器, 表明少量 NFE 便足以生成高质量样本. DPM-Solver++ 采用 $\mathbf{x}$ 预测, 使该方法适用于无分类器引导并提高稳定性. DPM-Solver-v3 进一步将参数化选择表达为有原则地最小化局部误差的优化问题, 从而自动完成参数化选择.

(选读) 时间并行方法. 一种互补策略通过在不同时间区间之间并行计算来加速采样, 而不是严格按顺序处理.

ParaDiGMs. 节 9.8 介绍的这一方法 (Shih et al., 2023) 将 ODE 求解重写为不动点问题. 这一视角允许并行计算积分项, 缓解标准时间步进求解器的顺序瓶颈. 该方法并不限于指数积分器形式, 同样适用于具有非线性漂移 $\mathbf{f}(\mathbf{x}, t)$ 的一般 PF-ODE. 此外, 它与求解器的具体选择无关: 不动点表述通过选定时间处以模型求值的加权和代替积分, 包裹任意时间步进规则; 因此, 可以使用 Euler、DEIS 或 DPM-Solver 风格的更新, 同时并行进行其求值.

真实计算成本 (NFE). 实践中, 实际运行时间主要取决于模型网络被调用的次数, 而不是离散化的步数. 我们将这一次数称为函数求值次数 (*NFE*). 如果采样器在 N 步中每步求值 m 次, 则成本随下式增长:

$$\text{NFE} = m N.$$

例如，一阶 Euler 或指数 Euler 方案具有 $m = 1$ ，而单步 k 阶方法通常需要 $m \geq k$ （例如 k 阶 DPM-Solver）。多步方法（例如 DEIS、DPM-Solver++ 的多步版本）复用过去的求值，因此在短暂预热阶段之后，平均 m 接近 1。无分类器引导实际上使每步调用次数翻倍。因此，实践中“更快”的采样意味着更低的 NFE，而不仅仅是更少的步骤。

使用 PF-ODE 等价形式的说明. 在下文讨论中，我们将使用节 6.3 的结果，它支持交替使用扰动核的等价参数化 $(f(t), g(t))$ 和 (α_t, σ_t) ，其中 $\mathbf{x}_t | \mathbf{x}_0 \sim \mathcal{N}(\cdot; \alpha_t \mathbf{x}_0, \sigma_t^2 \mathbf{I})$ ，它们通过下式联系：

$$f(t) = \frac{\alpha'_t}{\alpha_t}, \quad g^2(t) = \frac{d}{dt}(\sigma_t^2) - 2\frac{\alpha'_t}{\alpha_t}\sigma_t^2 = 2\sigma_t\sigma'_t - 2\frac{\alpha'_t}{\alpha_t}\sigma_t^2.$$

在这些关系下，PF-ODE 可写成若干等价形式（参见式 (6.3.2)）。

9.2 DDIM

本节介绍扩散模型采样加速的先驱方法之一：去噪扩散隐式模型（DDIM），它也是最广泛使用的基于 ODE 的求解器之一。尽管名称暗示其变分起源，如节 6.3.2 对 $(\mathbf{x}, \epsilon)$ 预测所展示，我们将说明，其实际更新规则也可解释为直接应用 Euler 方法来近似式 (9.1.6) 中的积分。这一 ODE 视角不仅提供了对 DDIM 有原则的重新解释，也为设计更灵活、更高效的快速采样器奠定基础。

DDIM 最初的变分推导将在节 9.2.3 中重访。在节 9.2.4 中，我们建立 DDIM 更新规则与条件流匹配之间的明确对应，表明 DDIM 动力学可解释为 CFM 学习到的流。

9.2.1 将 DDIM 解释为 ODE 求解器

令 $s > t$ 表示两个离散时间步，其中 s 是起始时间， t 是更新的目标时间。为近似式 (9.1.6) 中的积分，一个自然选择是在 s （步骤的起点）固定被积函数，假设

$$\epsilon_{\phi^\times}(\mathbf{x}_\tau, \tau) \approx \epsilon_{\phi^\times}(\mathbf{x}_s, s), \quad \text{对所有 } \tau \in [t, s].$$

这一假设导出 Euler 更新近似（亦见式 (9.1.7)），从而产生如下更新规则：

$$\tilde{\mathbf{x}}_t = \mathcal{E}(s \rightarrow t) \tilde{\mathbf{x}}_s + \left(\frac{1}{2} \int_s^t \frac{g^2(\tau)}{\sigma_\tau} \mathcal{E}(\tau \rightarrow t) d\tau \right) \epsilon_{\phi^\times}(\tilde{\mathbf{x}}_s, s), \quad (9.2.1)$$

这里初始点为 $\tilde{\mathbf{x}}_s$ ，此时积分可解析计算，得到以下实用且高效的 DDIM 更新公式：

命题 9.2.1: DDIM = Euler 方法（指数 Euler）

对式 (9.1.6) 中的指数积分器形式应用 Euler 方法，所得式 (9.2.1) 更新规则给出如下 DDIM 更新：

$$\tilde{\mathbf{x}}_t = \frac{\alpha_t}{\alpha_s} \tilde{\mathbf{x}}_s - \alpha_t \left(\frac{\sigma_s}{\alpha_s} - \frac{\sigma_t}{\alpha_t} \right) \epsilon_{\phi^\times}(\tilde{\mathbf{x}}_s, s). \quad (9.2.2)$$

命题的证明。

我们使用式 (4.4.2) 中的关系

$$f(t) = \frac{\alpha'_t}{\alpha_t}, \quad g^2(t) = \frac{d}{dt}(\sigma_t^2) - 2\frac{\alpha'_t}{\alpha_t}\sigma_t^2 = 2\sigma_t\sigma'_t - 2\frac{\alpha'_t}{\alpha_t}\sigma_t^2.$$

由此得到

$$\mathcal{E}(s \rightarrow t) = e^{\int_s^t f(u) du} = e^{\log \alpha_u|_{u=s}^{u=t}} = \frac{\alpha_t}{\alpha_s}.$$

因此

$$\int_s^t \frac{g^2(\tau)}{2\sigma_\tau} e^{\int_\tau^t f(u) du} d\tau = \int_s^t \frac{g^2(\tau)}{2\sigma_\tau} \frac{\alpha_t}{\alpha_\tau} d\tau$$

$$\begin{aligned}
&= \alpha_t \int_s^t \frac{1}{2\sigma_\tau \alpha_\tau} \left(\frac{d\sigma_\tau^2}{d\tau} - 2 \frac{d \log \alpha_\tau}{d\tau} \sigma_\tau^2 \right) d\tau \\
&= \alpha_t \int_s^t \frac{d}{d\tau} \left(\frac{\sigma_\tau}{\alpha_\tau} \right) d\tau \\
&= -\alpha_t \left(\frac{\sigma_s}{\alpha_s} - \frac{\sigma_t}{\alpha_t} \right).
\end{aligned}$$

这一对应表明，DDIM 可解释为对经过指数积分器变换的半线性 PF-ODE 应用的一阶 Euler 方法。

9.2.2 不同参数化下 DDIM 的直观解释

DDIM 是最广泛使用的扩散采样加速方法之一，通常可以采用 ϵ 预测以外的不同参数化（见式 (6.3.1)）。本小节给出不同参数化下的重新表述，随后提供 DDIM 的更直观解释。

不同参数化下的 DDIM. 实践中，我们使用以某种标准参数化表达的预训练扩散模型，并在 PF-ODE 的 DDIM 离散化中，以相应预测器替代理想目标。为清晰起见，下文给出理想版本；通过以下替换即可得到可实现的版本：

$$\epsilon_{\phi^\times} \approx \epsilon^*, \quad \mathbf{x}_{\phi^\times} \approx \mathbf{x}^*, \quad \mathbf{s}_{\phi^\times} \approx \mathbf{s}^*, \quad \mathbf{v}_{\phi^\times} \approx \mathbf{v}^*.$$

推论 9.2.1: 不同参数化下的 DDIM

令 $s > t$. 从 $\tilde{\mathbf{x}}_s \sim p_s$ 出发并在时间 t 终止，不同参数化下的 DDIM 更新为：

$$\begin{aligned}
\tilde{\mathbf{x}}_t &= \frac{\alpha_t}{\alpha_s} \tilde{\mathbf{x}}_s + \alpha_t \left(\frac{\sigma_t}{\alpha_t} - \frac{\sigma_s}{\alpha_s} \right) \epsilon^*(\tilde{\mathbf{x}}_s, s) \\
&= \frac{\sigma_t}{\sigma_s} \tilde{\mathbf{x}}_s + \alpha_s \left(\frac{\alpha_t}{\alpha_s} - \frac{\sigma_t}{\sigma_s} \right) \mathbf{x}^*(\tilde{\mathbf{x}}_s, s) \\
&= \frac{\alpha_t}{\alpha_s} \tilde{\mathbf{x}}_s + \sigma_s^2 \left(\frac{\alpha_t}{\alpha_s} - \frac{\sigma_t}{\sigma_s} \right) \mathbf{s}^*(\tilde{\mathbf{x}}_s, s) \\
&= \alpha_t \underbrace{\mathbf{x}^*(\tilde{\mathbf{x}}_s, s)}_{\approx \mathbf{x}_{\phi^\times} \text{ 估计的干净样本}} + \sigma_t \underbrace{\epsilon^*(\tilde{\mathbf{x}}_s, s)}_{\approx \epsilon_{\phi^\times} \text{ 估计的噪声}}.
\end{aligned} \tag{9.2.3}$$

式 (9.2.3) 中的最后一个恒等式清楚地揭示了 DDIM：从 $\tilde{\mathbf{x}}_s \sim p_s$ 出发，（估计的）干净部分 $\mathbf{x}^*(\tilde{\mathbf{x}}_s, s)$ 和（估计的）噪声部分 $\epsilon^*(\tilde{\mathbf{x}}_s, s)$ 作为插值端点，以系数 (α_t, σ_t) 重构 $\tilde{\mathbf{x}}_t \sim p_t$ 。

事实上，DDIM 可视为对 $\mathbf{v}$ 参数化的 PF-ODE 进行直接 Euler 离散化，无需应用指数积分器。由命题 6.3.2，PF-ODE 还具有如下 $\mathbf{v}$ 预测形式：

$$\frac{d\mathbf{x}(\tau)}{d\tau} = \alpha'_\tau \mathbf{x}^*(\mathbf{x}(\tau), \tau) + \sigma'_\tau \epsilon^*(\mathbf{x}(\tau), \tau), \quad \tau \in [t, s].$$

从 $\tilde{\mathbf{x}}_s$ 开始，在 $[t, s]$ 上积分，Euler 方法将预测器冻结于右端点：

$$\mathbf{x}^*(\mathbf{x}(\tau), \tau) \approx \mathbf{x}^*(\tilde{\mathbf{x}}_s, s), \quad \epsilon^*(\mathbf{x}(\tau), \tau) \approx \epsilon^*(\tilde{\mathbf{x}}_s, s),$$

对所有 $\tau \in [t, s]$ 均如此. 这给出

$$\begin{aligned} \tilde{\mathbf{x}}_t &= \tilde{\mathbf{x}}_s + \int_s^t (\alpha'_\tau \mathbf{x}^* + \sigma'_\tau \epsilon^*) d\tau \\ &\approx \tilde{\mathbf{x}}_s + (\alpha_t - \alpha_s) \mathbf{x}^*(\tilde{\mathbf{x}}_s, s) + (\sigma_t - \sigma_s) \epsilon^*(\tilde{\mathbf{x}}_s, s) \\ &= \alpha_t \mathbf{x}^*(\tilde{\mathbf{x}}_s, s) + \sigma_t \epsilon^*(\tilde{\mathbf{x}}_s, s), \end{aligned}$$

最后一个恒等式直接由式 (6.3.1) 得到. 上述推导公式与 DDIM 更新 (式 (9.2.3)) 中的最后一个恒等式完全相符. 示意图式 (9.2.3).




图 9.1: 将 DDIM 视为 PF-ODE 的 Euler 离散化的示意图. 从时间 s 处的状态 $\tilde{\mathbf{x}}_s$ 出发, 理想 PF-ODE 轨迹 (灰色曲线) 确定性地演化至时间 t 处的 $\Psi_{s \rightarrow t}(\tilde{\mathbf{x}}_s)$. 相比之下, DDIM 更新 (橙色) 直接将 $\tilde{\mathbf{x}}_s$ 映射至 $\alpha_t \mathbf{x}^*(\tilde{\mathbf{x}}_s, s) + \sigma_t \epsilon^*(\tilde{\mathbf{x}}_s, s)$. 这一 Euler 步骤与真实 PF-ODE 轨迹之间的偏差引入离散化误差, 以蓝色显示. 如果 t 远离 s , 偏差可能很大, 导致生成质量下降.

在速度预测中, PF-ODE 的线性项 $f(t)\mathbf{x}$ 被吸收到目标 $\mathbf{v}^*(\mathbf{x}(t), t) = \alpha'_t \mathbf{x}_0 + \sigma'_t \epsilon$ 中. 根据微积分基本定理, 积分 $\int_s^t \alpha'_\tau d\tau$ 和 $\int_s^t \sigma'_\tau d\tau$ 简化为 $(\alpha_t - \alpha_s)$ 和 $(\sigma_t - \sigma_s)$, 因此单个 Euler 步骤就能得到闭式 DDIM 更新:

$$\tilde{\mathbf{x}}_t = \alpha_t \tilde{\mathbf{x}}^*(\tilde{\mathbf{x}}_s, s) + \sigma_t \tilde{\epsilon}^*(\tilde{\mathbf{x}}_s, s).$$

即在 $\mathbf{v}$ 预测下, PF-ODE 漂移没有需要单独分离的线性项, 因此普通 Euler 更新自然与 DDIM 表述一致. 相比之下, 在 ϵ 、 $\mathbf{x}$ 或 $\mathbf{s}$ 预测参数化下, PF-ODE 漂移可分解为由线性项与非线性修正组成的半线性形式, 符合式 (9.1.5) 给出的通用模板. 朴素 Euler 步骤只近似线性项, 而不精确计算它 (见式 (9.1.8) 中的论证). DDIM 则对应于解析处理这一线性分量的指数 Euler (积分因子) 步骤. 因此, $\mathbf{v}$ 预测产生最简单、最直接的 Euler 积分, 而其他参数化需要指数 Euler 形式才能实现相同的 DDIM 行为.

上述讨论也呼应了节 6.3.4 中的论证, 并导出以下结论:

观察 9.2.1: (指数) Euler 与 DDIM 更新

给定相同的调度 (α_t, σ_t) ,

$\mathbf{v}$ 预测: Euler = DDIM,

ϵ 、 $\mathbf{x}$ 、或 $\mathbf{s}$ 预测: 指数 Euler = DDIM $\neq$ 普通 Euler,

其中, 在 ϵ 、 $\mathbf{x}$ 或 $\mathbf{s}$ 预测情形下, 普通 Euler 步骤不等价于 DDIM, 因为线性项仅被近似, 可能降低稳定性.

不同参数化下 DDIM 的说明性例子. 我们根据式 (9.2.3), 用一个简单例子说明理想量替换 (ϵ^* 、 $\mathbf{x}^*$ 、 $\nabla_{\mathbf{x}} \log p_t$ 和 $\mathbf{v}^*$). 假设前向核满足 $\alpha_t = 1$ 且 $\sigma_t = t$ (Karras et al., 2022). DDIM (指数 Euler) 更新

$$\tilde{\mathbf{x}}_t = \frac{\alpha_t}{\alpha_s} \tilde{\mathbf{x}}_s - \alpha_t \left(\frac{\sigma_s}{\alpha_s} - \frac{\sigma_t}{\alpha_t} \right) \epsilon^*(\tilde{\mathbf{x}}_s, s)$$

简化为

$$\tilde{\mathbf{x}}_t = \tilde{\mathbf{x}}_s - (s - t) \epsilon^*(\tilde{\mathbf{x}}_s, s).$$

从概念上看, 减去时间差 $(s - t)$ 与理想噪声估计 $\epsilon^*(\tilde{\mathbf{x}}_s, s)$ 的乘积, 将当前样本 $\tilde{\mathbf{x}}_s$ 推向更干净的估计.

使用 $\mathbf{x}$ 预测的理想量 $\mathbf{x}^*$, 它与理想噪声通过下式联系:

$$\epsilon^*(\tilde{\mathbf{x}}_s, s) = \frac{\tilde{\mathbf{x}}_s - \mathbf{x}^*(\tilde{\mathbf{x}}_s, s)}{s},$$

得到

$$\tilde{\mathbf{x}}_t = \tilde{\mathbf{x}}_s - \frac{s - t}{s} (\tilde{\mathbf{x}}_s - \mathbf{x}^*(\tilde{\mathbf{x}}_s, s)) = \frac{t}{s} \tilde{\mathbf{x}}_s + \left(1 - \frac{t}{s}\right) \mathbf{x}^*(\tilde{\mathbf{x}}_s, s). \quad (9.2.4)$$

因此, $\tilde{\mathbf{x}}_t$ 是当前样本 $\tilde{\mathbf{x}}_s$ 与 $\mathbf{x}$ 预测 $\mathbf{x}^*(\tilde{\mathbf{x}}_s, s)$ 的凸组合, 后者作为干净数据的理想估计. 此外, 可将其重写为

$$\tilde{\mathbf{x}}_t - \mathbf{x}^* = \frac{t}{s} (\tilde{\mathbf{x}}_s - \mathbf{x}^*), \quad t < s,$$

这表明每步的去噪残差都按因子 $t/s \in (0, 1)$ 收缩（所以在 $t < s$ 时不会发生越过目标的情况）。

使用与理想噪声通过下式联系的理想得分，

$$\epsilon^*(\tilde{\mathbf{x}}_s, s) = -\sigma_s \nabla_{\mathbf{x}} \log p_s(\tilde{\mathbf{x}}_s),$$

DDIM（指数 Euler）更新变为

$$\tilde{\mathbf{x}}_t = \tilde{\mathbf{x}}_s + (s - t) s \nabla_{\mathbf{x}} \log p_s(\tilde{\mathbf{x}}_s).$$

这使 $\tilde{\mathbf{x}}_s$ 沿得分场上升（朝向似然更高的区域），步长正比于时间差 $(s - t)$ 和噪声尺度 s 。

最后，使用理想速度 $\mathbf{v}^*(\tilde{\mathbf{x}}_s, s) = -\epsilon^*(\tilde{\mathbf{x}}_s, s)$ ，DDIM 更新可写为

$$\tilde{\mathbf{x}}_t = \tilde{\mathbf{x}}_s + (t - s) \mathbf{v}^*(\tilde{\mathbf{x}}_s, s),$$

因此，割线斜率满足有限差分恒等式

$$\frac{\tilde{\mathbf{x}}_t - \tilde{\mathbf{x}}_s}{t - s} = \mathbf{v}^*(\tilde{\mathbf{x}}_s, s).$$

直观地说，这意味着更新是沿局部 ODE 漂移前进的直线步骤。

DDIM 的挑战。 然而，一阶 Euler 离散化具有全局误差 $\mathcal{O}(h)$ ，所以随着最大步长 $h := \max_i |t_i - t_{i-1}|$ 增大，精度会下降。为提高精度，文献开发了高阶方案，通过更丰富的局部近似将全局阶提升至 $\mathcal{O}(h^k)$ ($k \geq 2$)。配合适当的时间步分配，这些方法可能用更少步骤达到目标质量。但需要注意，单凭高阶并不能保证更少步骤或更低实际运行成本，因为每步可能需要多次模型求值。实践中，真正衡量效率的是函数求值次数 $\text{NFE} = mN$ ；“更快”意味着用更小 NFE 达到所需质量，而不仅是更少步骤。

9.2.3 （选读）DDIM 的变分视角

DDIM 的动机实际上源于从变分视角重访 DDPM。在 DDPM 中，反向过程与特定的 Markov 前向转移核 $p(\mathbf{x}_t|\mathbf{x}_{t-\Delta t})$ 绑定；为了正确近似多步后验，必须采用小步长。DDIM 摆脱了这一限制，因为它注意到训练目标只依赖边缘扰动 $p_t(\mathbf{x}_t|\mathbf{x}_0)$ ，而不依赖具体的前向转移。

这一洞见使我们可以直接从边缘分布构造反向动力学，从而在保持边缘一致性的同时跳过中间步骤。由于转移被定义为对任意 $t < s$ 都将 $p_s(\mathbf{x}_s|\mathbf{x}_0)$ 映射为 $p_t(\mathbf{x}_t|\mathbf{x}_0)$ ，我们可以使用更新次数少得多的粗时间网格，减少模型求值次数，实现快速少步采样。

重访 DDPM 的变分视角。 在 DDPM 中，训练固定一族边缘扰动核 $p_t(\mathbf{x}_t|\mathbf{x}_0)$ ，并优化只依赖这些边缘分布的替代目标。然而，在采样时，反向条件分布是一阶前向核下的贝叶斯后验：

$$p(\mathbf{x}_{t-\Delta t}|\mathbf{x}_t, \mathbf{x}_0) = \frac{p(\mathbf{x}_t|\mathbf{x}_{t-\Delta t}) p_{t-\Delta t}(\mathbf{x}_{t-\Delta t}|\mathbf{x}_0)}{p_t(\mathbf{x}_t|\mathbf{x}_0)}.$$

这使反向更新与特定前向转移 $p(\mathbf{x}_t|\mathbf{x}_{t-\Delta t})$ 绑定。如果通过增大 Δt 来尝试跳步，同时复用相同的一步核，就不再匹配真实的多步后验，通常会使边缘分布失真。

DDIM 最初的动机. DDIM 注意到, 训练目标只约束边缘分布 $p_t(\mathbf{x}_t|\mathbf{x}_0)$, 而不约束中间反向转移. 因此, 对于任意 $t < s$, 可以指定一族反向条件分布

$\pi(\mathbf{x}_t|\mathbf{x}_s, \mathbf{x}_0)$, 使其具有一步边缘一致性²:

$$\int \pi(\mathbf{x}_t|\mathbf{x}_s, \mathbf{x}_0) p_s(\mathbf{x}_s|\mathbf{x}_0) d\mathbf{x}_s = p_t(\mathbf{x}_t|\mathbf{x}_0). \quad (9.2.5)$$

这一构造消除了对前向一步核 $p(\mathbf{x}_t|\mathbf{x}_{t-\Delta t})$ 的任何依赖, 并使粗 (跳步) 时间步具有合理依据.

离散时间 DDIM 的推导. 考虑一般前向扰动:

$$p_t(\mathbf{x}_t|\mathbf{x}_0) := \mathcal{N}(\mathbf{x}_t; \alpha_t \mathbf{x}_0, \sigma_t^2 \mathbf{I}),$$

其中 $\mathbf{x}_0 \sim p_{\text{data}}$.

DDIM 不要求反向更新与绑定于一步前向核的贝叶斯后验一致. 只需选择一个保持边缘分布的反向条件分布即可. 具体而言, 对于任意 $t < s$, 我们设定如下高斯族:

$$\pi(\mathbf{x}_t|\mathbf{x}_s, \mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t; a_{t,s} \mathbf{x}_0 + b_{t,s} \mathbf{x}_s, c_{t,s}^2 \mathbf{I}), \quad (9.2.6)$$

其中系数 $(a_{t,s}, b_{t,s}, c_{t,s})$ 由边缘一致性约束式 (9.2.5) 确定. 由于所有涉及的核均为高斯, 先采样 $\mathbf{x}_s|\mathbf{x}_0 = \alpha_s \mathbf{x}_0 + \sigma_s \epsilon'$, 再从式 (9.2.6) 采样 $\mathbf{x}_t|\mathbf{x}_s, \mathbf{x}_0$, 得到

²如果将式 (9.2.5) 中的“用户定义”反向转移核 π 选为与“真实”条件分布完全相同: $\pi(\mathbf{x}_t|\mathbf{x}_s, \mathbf{x}_0) = p(\mathbf{x}_t|\mathbf{x}_s, \mathbf{x}_0)$, 则边缘一致性条件

$$\int \pi(\mathbf{x}_t|\mathbf{x}_s, \mathbf{x}_0) p_s(\mathbf{x}_s|\mathbf{x}_0) d\mathbf{x}_s = p_t(\mathbf{x}_t|\mathbf{x}_0)$$

只是条件联合分布的全概率公式 (亦称塔性质) 的结果:

$$p_t(\mathbf{x}_t|\mathbf{x}_0) = \int p(\mathbf{x}_t, \mathbf{x}_s|\mathbf{x}_0) d\mathbf{x}_s = \int p(\mathbf{x}_t|\mathbf{x}_s, \mathbf{x}_0) p_s(\mathbf{x}_s|\mathbf{x}_0) d\mathbf{x}_s.$$

等价地, 显式地将贝叶斯后验表达为

$$p(\mathbf{x}_t|\mathbf{x}_s, \mathbf{x}_0) = \frac{p(\mathbf{x}_s|\mathbf{x}_t, \mathbf{x}_0) p_t(\mathbf{x}_t|\mathbf{x}_0)}{p_s(\mathbf{x}_s|\mathbf{x}_0)},$$

再乘以 $p_s(\mathbf{x}_s|\mathbf{x}_0)$, 并对 $\mathbf{x}_s$ 边缘化, 就恢复

$$\int p(\mathbf{x}_t|\mathbf{x}_s, \mathbf{x}_0) p_s(\mathbf{x}_s|\mathbf{x}_0) d\mathbf{x}_s = p_t(\mathbf{x}_t|\mathbf{x}_0),$$

这正是同一边缘一致性条件.

在 Markov 前向情形下, 还具有 $p(\mathbf{x}_t|\mathbf{x}_s, \mathbf{x}_0) = p(\mathbf{x}_t|\mathbf{x}_s)$, 从而化为以下表达:

$$p_t(\mathbf{x}_t|\mathbf{x}_0) = \int p(\mathbf{x}_t|\mathbf{x}_s) p_s(\mathbf{x}_s|\mathbf{x}_0) d\mathbf{x}_s.$$

$$\begin{aligned}
\mathbf{x}_t &= a_{t,s} \mathbf{x}_0 + b_{t,s} \mathbf{x}_s + c_{t,s} \boldsymbol{\epsilon} \\
&= a_{t,s} \mathbf{x}_0 + b_{t,s} (\alpha_s \mathbf{x}_0 + \sigma_s \boldsymbol{\epsilon}') + c_{t,s} \boldsymbol{\epsilon} \\
&= (a_{t,s} + b_{t,s} \alpha_s) \mathbf{x}_0 + \sqrt{b_{t,s}^2 \sigma_s^2 + c_{t,s}^2} \boldsymbol{\epsilon}'',
\end{aligned} \tag{9.2.7}$$

其中 $\boldsymbol{\epsilon}, \boldsymbol{\epsilon}', \boldsymbol{\epsilon}'' \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 相互独立（高斯和性质）。另一方面，

$$\mathbf{x}_t \sim p_t(\mathbf{x}_t | \mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t; \alpha_t \mathbf{x}_0, \sigma_t^2 \mathbf{I}).$$

将这一目标与式 (9.2.7) 的均值和方差相等，得到

$$\alpha_t = a_{t,s} + b_{t,s} \alpha_s, \quad \sigma_t^2 = b_{t,s}^2 \sigma_s^2 + c_{t,s}^2.$$

这一方程组欠定，因此将 $c_{t,s}$ 视为自由参数，并施加自然约束 $0 \leq c_{t,s} \leq \sigma_t$ ，解出 $a_{t,s}, b_{t,s}$ ：

$$b_{t,s} = \frac{\sqrt{\sigma_t^2 - c_{t,s}^2}}{\sigma_s}, \quad a_{t,s} = \alpha_t - \alpha_s b_{t,s}. \tag{9.2.8}$$

这里，不失一般性地取 $b_{t,s}$ 的非负根。

将式 (9.2.8) 代入式 (9.2.6)，得到

$$\pi(\mathbf{x}_t | \mathbf{x}_s, \mathbf{x}_0) = \mathcal{N}\left(\mathbf{x}_t; \underbrace{\alpha_t \mathbf{x}_0 + \frac{\sqrt{\sigma_t^2 - c_{t,s}^2}}{\sigma_s} (\mathbf{x}_s - \alpha_s \mathbf{x}_0)}_{\text{均值}}, c_{t,s}^2 \mathbf{I}\right). \tag{9.2.9}$$

等价地，式 (9.2.9) 中的均值展开为

$$\left(\alpha_t - \alpha_s \frac{\sqrt{\sigma_t^2 - c_{t,s}^2}}{\sigma_s}\right) \mathbf{x}_0 + \left(\frac{\sqrt{\sigma_t^2 - c_{t,s}^2}}{\sigma_s}\right) \mathbf{x}_s.$$

引理 9.2.2: DDIM 系数

令 $\pi(\mathbf{x}_t | \mathbf{x}_s, \mathbf{x}_0)$ 由式 (9.2.6) 给定。如果边缘一致性条件式 (9.2.5) 成立，则系数恰为式 (9.2.8) 所给，其中 $0 \leq c_{t,s} \leq \sigma_t$ 。

注.

1. 在 DDIM 中，我们选择反向核 $\pi(\mathbf{x}_t | \mathbf{x}_s, \mathbf{x}_0)$ 来满足边缘一致性约束，一般而言

$$\pi(\mathbf{x}_t | \mathbf{x}_s, \mathbf{x}_0) \neq p(\mathbf{x}_t | \mathbf{x}_s, \mathbf{x}_0),$$

其中 $p(\mathbf{x}_t | \mathbf{x}_s, \mathbf{x}_0)$ 是与特定的一步前向核关联的贝叶斯后验。由贝叶斯法则，

$$p(\mathbf{x}_t|\mathbf{x}_s, \mathbf{x}_0) \propto p(\mathbf{x}_s|\mathbf{x}_t) p_t(\mathbf{x}_t|\mathbf{x}_0),$$

而指定 π 或进行训练均不需要这一后验.

2. 仅当方差参数被选为与 DDPM 后验方差相匹配 (式 (9.2.10) 中的 $\eta = 1$ 设定) 时, 才有 $\pi(\mathbf{x}_t|\mathbf{x}_s, \mathbf{x}_0) = p(\mathbf{x}_t|\mathbf{x}_s, \mathbf{x}_0)$; 否则 $\pi(\mathbf{x}_t|\mathbf{x}_s, \mathbf{x}_0) \neq p(\mathbf{x}_t|\mathbf{x}_s, \mathbf{x}_0)$.
3. 不施加 Markov 约束时, 一般有 $p(\mathbf{x}_s|\mathbf{x}_t, \mathbf{x}_0) \neq p(\mathbf{x}_s|\mathbf{x}_t)$. 等式 $p(\mathbf{x}_s|\mathbf{x}_t, \mathbf{x}_0) = p(\mathbf{x}_s|\mathbf{x}_t)$ 绑定于特定的 Markov 前向模型, 而 DDIM 的反向构造并不假设这一模型.

前向边缘分布 $\{p_t(\mathbf{x}_t|\mathbf{x}_0)\}_t$ 不能唯一确定反向条件转移. 存在无穷多个满足式 (9.2.5) 的核 $\pi(\mathbf{x}_t|\mathbf{x}_s, \mathbf{x}_0)$, 任何一个都可以自由指定. 参数 $c_{t,s}$ 标记这一族, 并控制每次反向步骤 $s \rightarrow t$ 注入的噪声量. 下文介绍这一族 DDIM 求解器.

DDIM 采样器 (步骤 $s \rightarrow t$). DDIM 采样器由式 (9.2.9) 中选择的反向核 $\pi(\mathbf{x}_t|\mathbf{x}_s, \mathbf{x}_0)$ 得到, 只需将 $\mathbf{x}_0$ 替换为预训练模型的预测器.

使用 ϵ 预测网络 $\epsilon_{\phi^\times}$ (即插即用, 无需重新训练), 令

$$\mathbf{x}_{\phi^\times}(\mathbf{x}_s, s) := \frac{\mathbf{x}_s - \sigma_s \epsilon_{\phi^\times}(\mathbf{x}_s, s)}{\alpha_s}, \quad p_{\phi^\times}(\mathbf{x}_t|\mathbf{x}_s) := \pi(\mathbf{x}_t | \mathbf{x}_s, \mathbf{x}_{\phi^\times}(\mathbf{x}_s, s)).$$

将 $\mathbf{x}_{\phi^\times}$ 代入式 (9.2.9), 得到更新

$$\mathbf{x}_t = \frac{\alpha_t}{\alpha_s} \mathbf{x}_s + \left(\sqrt{\sigma_t^2 - c_{t,s}^2} - \frac{\alpha_t}{\alpha_s} \sigma_s \right) \epsilon_{\phi^\times}(\mathbf{x}_s, s) + c_{t,s} \epsilon_t, \quad \epsilon_t \sim \mathcal{N}(\mathbf{0}, \mathbf{I}),$$

其中 $c_{t,s} \in [0, \sigma_t]$ 控制随机性.

为记号方便, 定义前向因子

$$\alpha_{t|s} := \frac{\alpha_t}{\alpha_s}, \quad \sigma_{t|s}^2 := \sigma_t^2 - \alpha_{t|s}^2 \sigma_s^2,$$

使得 $p(\mathbf{x}_t|\mathbf{x}_s) = \mathcal{N}(\alpha_{t|s}\mathbf{x}_s, \sigma_{t|s}^2 \mathbf{I})$. 于是采样器可写成

$$\mathbf{x}_t = \alpha_{t|s} \mathbf{x}_s + \left(\sqrt{\sigma_{t|s}^2} - \alpha_{t|s} \sigma_s \right) \epsilon_{\phi^\times}(\mathbf{x}_s, s) + c_{t,s} \epsilon_t.$$

改变 $c_{t,s}$ 便得到一族共享同一预训练扩散模型且无需重新训练的采样器:

- **DDPM 步骤 (后验方差):** $c_{t,s} = \frac{\sigma_s}{\sigma_t} \sigma_{t|s}$ 使 $\pi(\mathbf{x}_t|\mathbf{x}_s, \mathbf{x}_0)$ 等于一步前向核诱导的贝叶斯后验 $p(\mathbf{x}_t|\mathbf{x}_s, \mathbf{x}_0)$. 以其预测器替换 $\mathbf{x}_0$, 便得到标准 DDPM 反向更新 $p_{\phi^\times}(\mathbf{x}_t|\mathbf{x}_s)$, 即满足 $\alpha_t^2 + \sigma_t^2 = 1$ 的 Markov DDPM 步骤 (式 (2.2.14)).

- **确定性 DDIM** ($\eta = 0$): $c_{t,s} = 0$ 给出

$$\mathbf{x}_t = \alpha_{t|s} \mathbf{x}_s + (\sigma_t - \alpha_{t|s} \sigma_s) \epsilon_{\phi \times}(\mathbf{x}_s, s),$$

这与 ODE 视角的 DDIM 跳步一致.

- **插值**: 定义

$$c_{t,s} = \eta \frac{\sigma_s}{\sigma_t} \sigma_{t|s}, \quad \eta \in [0, 1], \quad (9.2.10)$$

于是 η 在随机 DDPM 更新 ($\eta = 1$) 与确定性 DDIM 更新 ($\eta = 0$) 之间平滑插值.

9.2.4 作为条件流匹配的 DDIM

本小节将说明, 确定性 DDIM 可理解为寻找一个将 $p_s(\cdot|\mathbf{x}_0)$ 推前到 $p_t(\cdot|\mathbf{x}_0)$ 的条件流映射. 这一条件流的切向量与条件流匹配 (CFM) 使用的条件速度一致. 对这一条件速度边缘化, 便得到 PF-ODE 漂移, 其普通 Euler 离散化在 $\mathbf{v}$ 预测下恢复边缘 DDIM 更新.

我们重访 DDIM 的一步条件边缘一致性恒等式 (式 (9.2.5)):

$$\int \pi(\mathbf{x}_t|\mathbf{x}_s, \mathbf{x}_0) p_s(\mathbf{x}_s|\mathbf{x}_0) d\mathbf{x}_s = p_t(\mathbf{x}_t|\mathbf{x}_0), \quad t < s,$$

即如果 $\mathbf{x}_s \sim p_s(\cdot|\mathbf{x}_0)$, 则通过选择的反向核推前 $\mathbf{x}_s$ 会再现 $p_t(\cdot|\mathbf{x}_0)$. 当反向核为确定性时, 这等价于寻找条件映射 $\Psi_{s \rightarrow t}(\cdot|\mathbf{x}_0)$, 使其将 $p_s(\cdot|\mathbf{x}_0)$ 推前到 $p_t(\cdot|\mathbf{x}_0)$:

$$\pi(\mathbf{x}_t|\mathbf{x}_s, \mathbf{x}_0) = \delta(\mathbf{x}_t - \Psi_{s \rightarrow t}(\mathbf{x}_s|\mathbf{x}_0)), \quad (\Psi_{s \rightarrow t}(\cdot|\mathbf{x}_0))_{\#} p_s(\cdot|\mathbf{x}_0) = p_t(\cdot|\mathbf{x}_0).$$

在线性高斯路径 $\mathbf{x}_\tau = \alpha_\tau \mathbf{x}_0 + \sigma_\tau \epsilon$ 下, 通过类似于式 (9.2.6) 和 (9.2.7) 的论证, 得到条件映射

$$\Psi_{s \rightarrow t}(\mathbf{x}_s|\mathbf{x}_0) = \frac{\sigma_t}{\sigma_s} \mathbf{x}_s + \left(\alpha_t - \alpha_s \frac{\sigma_t}{\sigma_s} \right) \mathbf{x}_0,$$

其瞬时条件速度为

$$\mathbf{v}_t^*(\mathbf{x}|\mathbf{x}_0) = \partial_h \Big|_{h=0} \Psi_{t \rightarrow t+h}(\mathbf{x}|\mathbf{x}_0) = \frac{\sigma'_t}{\sigma_t} \mathbf{x} + \left(\alpha'_t - \alpha_t \frac{\sigma'_t}{\sigma_t} \right) \mathbf{x}_0.$$

我们将 $\Psi_{s \rightarrow t}(\cdot|\mathbf{x}_0)$ 称为 DDIM 条件映射.

给定 $p_t(\mathbf{x}|\mathbf{x}_0)$, 条件流匹配将随时间变化的场拟合到这一目标速度:

$$\mathcal{L}_{\text{CFM}}(\phi) = \mathbb{E}_{t, \mathbf{x}_0, \mathbf{x}_t \sim p_t(\cdot|\mathbf{x}_0)} \left\| \mathbf{v}_\phi(\mathbf{x}_t, t) - \mathbf{v}_t^*(\mathbf{x}_t|\mathbf{x}_0) \right\|^2,$$

因此, CFM 回归目标等于 DDIM 条件映射的条件速度.

观察 9.2.2: 条件层面

沿条件高斯路径，DDIM 条件映射与 CFM 目标生成相同的条件流 $\Psi_{s \rightarrow t}(\cdot | \mathbf{x}_0)$.

对给定 $\mathbf{x}_t = \mathbf{x}$ 时 $\mathbf{x}_0$ 的后验分布取条件速度的平均，得到边缘 PF-ODE 漂移：

$$\mathbf{v}^*(\mathbf{x}, t) = \mathbb{E} [\mathbf{v}_t^*(\mathbf{x} | \mathbf{x}_0) | \mathbf{x}_t = \mathbf{x}],$$

在线性高斯调度下，它具有可分离的预测器形式

$$\mathbf{v}^*(\mathbf{x}, t) = \alpha'_t \mathbf{x}^*(\mathbf{x}, t) + \sigma'_t \boldsymbol{\epsilon}^*(\mathbf{x}, t), \quad \mathbf{x} = \alpha_t \mathbf{x}^*(\mathbf{x}, t) + \sigma_t \boldsymbol{\epsilon}^*(\mathbf{x}, t).$$

我们已经看到，采用这一边缘化 $\mathbf{v}$ 预测的 PF-ODE 的普通 Euler 步骤，恰为 DDIM 更新（式 (9.2.3) 中的最后一个恒等式）。

概括而言，DDIM (i) 是一个确定性条件输运，其切向量等于 CFM 目标；(ii) 对该切向量边缘化后，成为 PF-ODE 的 Euler 步骤，该步骤与 DDIM 更新一致。

9.3 DEIS

在指数积分器公式 (式 (9.1.6)) 中,

$$\int_s^t \frac{g^2(\tau)}{2\sigma_\tau} \mathcal{E}(\tau \rightarrow t) \epsilon_{\phi \times}(\mathbf{x}_\tau, \tau) d\tau,$$

唯一未知的量是模型输出 $\epsilon_{\phi \times}(\mathbf{x}_\tau, \tau)$; 一旦固定 (α, σ, g) , 调度项及权重 $\mathcal{E}(\tau \rightarrow t)$ 便已知. DDIM (Euler 方法) 通过保持模型输出恒定来近似这一积分:

$$\epsilon_{\phi \times}(\mathbf{x}_\tau, \tau) \approx \epsilon_{\phi \times}(\mathbf{x}_s, s), \quad \tau \in [t, s].$$

然而, 这只是一阶精度, 当模型输出随时间快速变化时可能失效.

于是自然产生一个问题: 能否更好地利用已经计算的模型求值? 如同经典多步求解器, 我们无需将 $\epsilon_{\phi \times}(\mathbf{x}_\tau, \tau)$ 视为常数 (Euler), 而可复用先前输出 (锚点) 来拟合一条简单的时间曲线. 由于权重 $\frac{g^2(\tau)}{2\sigma_\tau} \mathcal{E}(\tau \rightarrow t)$ 已知, 可以对拟合曲线精确计算积分. 实质上, 未知函数的困难积分被替换为由过去模型调用定义的近似曲线的精确积分. 这正是扩散指数积分采样器 (DEIS) (Zhang and Chen, 2022) 背后的原则.

对于熟悉经典 ODE 求解器的读者, DEIS 可视为在半线性 PF-ODE (式 (9.1.6)) 的指数积分器框架中应用 Adams–Bashforth 方案 (Iserles, 2009): 通过积分因子精确处理线性漂移, 而剩余非线性项使用多步多项式外推来推进.

我们首先在节 9.3.1 中介绍如何构造经过一组锚点的光滑曲线. 然后在节 9.3.2 中应用这一插值技术来近似 PF-ODE 积分, 从而导出 DEIS 算法. 最后在节 9.3.3 中说明, DDIM 是 DEIS 采用常数多项式时的特殊情形.

9.3.1 多项式外推

简单曲线的锚点插值. 假设我们已知某个时变量在最近若干时间的值

$$(\tau_0, \mathbf{Y}_0), (\tau_1, \mathbf{Y}_1), \dots, (\tau_n, \mathbf{Y}_n), \quad \tau_0 < \tau_1 < \dots < \tau_n,$$

其中每个 $\mathbf{Y}_j$ 可以是向量值. 要获得精确匹配这些锚点的简单曲线, 最自然的方式是使用经过它们的最低次数多项式. 最简单的构造是将所有在其他节点处消失的因子相乘, 然后归一化, 使 τ_j 处的值变为 1. 低次情形很直观:

例:

$n = 0$ (**常数**): 使用最后一个值,

$$\mathbf{Y}(\tau) \equiv \mathbf{Y}_n.$$

$n = 1$ (**直线**): 画出经过最后两个锚点的直线,

$$\mathbf{Y}(\tau) = \frac{\tau - \tau_n}{\tau_{n-1} - \tau_n} \mathbf{Y}_{n-1} + \frac{\tau - \tau_{n-1}}{\tau_n - \tau_{n-1}} \mathbf{Y}_n.$$

$n = 2$ (**二次; 抛物线**): 画出经过最后三个锚点的二次曲线. 例如, 若锚点为

$$(\tau_{n-2}, \mathbf{Y}_{n-2}), \quad (\tau_{n-1}, \mathbf{Y}_{n-1}), \quad (\tau_n, \mathbf{Y}_n),$$

则二次插值多项式为

$$\mathbf{Y}(\tau) = \mathbf{Y}_{n-2} \ell_{n-2}(\tau) + \mathbf{Y}_{n-1} \ell_{n-1}(\tau) + \mathbf{Y}_n \ell_n(\tau),$$

其中 Lagrange 基函数为

$$\begin{aligned}\ell_{n-2}(\tau) &= \frac{(\tau - \tau_{n-1})(\tau - \tau_n)}{(\tau_{n-2} - \tau_{n-1})(\tau_{n-2} - \tau_n)}, \\ \ell_{n-1}(\tau) &= \frac{(\tau - \tau_{n-2})(\tau - \tau_n)}{(\tau_{n-1} - \tau_{n-2})(\tau_{n-1} - \tau_n)}, \\ \ell_n(\tau) &= \frac{(\tau - \tau_{n-2})(\tau - \tau_{n-1})}{(\tau_n - \tau_{n-2})(\tau_n - \tau_{n-1})}.\end{aligned}$$

这些函数满足插值条件

$$\ell_j(\tau_k) = \delta_{jk}, \quad \text{对于 } j, k \in \{n-2, n-1, n\}$$

且对于所有 τ , 有 $\ell_{n-2}(\tau) + \ell_{n-1}(\tau) + \ell_n(\tau) = 1$. 这条曲线不仅匹配全部三个锚点, 还通过弯曲反映局部曲率. ■

这些情形都属于同一构造, 称为 *Lagrange* 多项式. 思想很简单: 将曲线构造为锚点的线性混合, 其权重随时间变化,

$$\mathbf{Y}(\tau) = \sum_{j=0}^n \ell_j(\tau) \mathbf{Y}_j, \quad \ell_j(\tau_k) = \delta_{jk}, \quad \sum_{j=0}^n \ell_j(\tau) = 1.$$

每个 $\ell_j(\tau)$ 都像一个“聚光灯”, 在自己的锚点取值 1 ($\ell_j(\tau_j) = 1$), 在其他锚点取值 0 ($\ell_j(\tau_k) = 0, k \neq j$).

在此意义下, Lagrange 插值多项式就是以基函数 $\ell_j(\tau)$ 为权重的锚点线性组合.

9.3.2 DEIS: 用 Lagrange 多项式近似 PF-ODE 积分

令 $n \geq 0$ 为选定的多项式次数. 在第 i 步, 我们用基于过去模型输出构造的 n 次插值多项式, 在 $[t_{i-1}, t_i]$ 上近似未知映射 $\tau \mapsto \epsilon_{\phi \times}(\mathbf{x}_\tau, \tau)$, 并将这一近似代入指数积分器更新 (式 (9.1.6)) 以得到 $\tilde{\mathbf{x}}_{t_i}$. 拟合的多项式通过弯曲来捕捉轨迹的短期趋势, 因此直观上该更新更紧密地遵循真实 ODE 解的曲线行为, 尤其是在较大步长下.

n 次更新需要 $n+1$ 个锚点. 当这些锚点可用时 (历史充分, $i \geq n+1$), 使用完整的 n 次方案. 在早期步骤中 (历史不足, $i \leq n$), 以可行的最高次数 $i-1$ 应用相同构造, 并随锚点累积而提高次数. 下文依次处理这两种情形.

情形 I: $i = n+1, \dots, M$ (历史充分). DEIS 不只依赖最近的估计 $\epsilon_{\phi \times}(\tilde{\mathbf{x}}_{t_{i-1}}, t_{i-1})$, 而是复用最后 $n+1$ 次模型求值作为锚点,

$$(\tau_j, \mathbf{Y}_j) := (t_{i-1-j}, \epsilon_{\phi \times}(\tilde{\mathbf{x}}_{t_{i-1-j}}, t_{i-1-j})), \quad j = 0, \dots, n.$$




图 9.2: 将 DEIS 视为多步方法的示意图. 给定 t_2, t_3, t_4 处的三个过去锚点, DEIS 构造经过模型输出的二次曲线, 并对其解析积分, 从 t_4 步进至 t_5 (外推). 与 DDIM 等只使用 t_4 处值 (对积分作常数近似) 的一阶方法相比, 这一高阶更新减少离散化误差.

将 $\tau \mapsto \epsilon_{\phi^\times}(\mathbf{x}_\tau, \tau)$ 视为沿轨迹的光滑时间函数, 构造 n 次多项式 (Lagrange 插值多项式):

$$P_n(\tau) = \sum_{j=0}^n \underbrace{\left[\prod_{\substack{k=0 \\ k \neq j}}^n \frac{\tau - t_{i-1-k}}{t_{i-1-j} - t_{i-1-k}} \right]}_{=: \ell_j^{(i)}(\tau)} \epsilon_{\phi^\times}(\tilde{\mathbf{x}}_{t_{i-1-j}}, t_{i-1-j})$$

根据构造, 对于每个锚点都有 $P_n(\tau_j) = \mathbf{Y}_j$:

$$P_n(\tau_j) = \mathbf{Y}_j = \epsilon_{\phi^\times}(\tilde{\mathbf{x}}_{t_{i-1-j}}, t_{i-1-j}), \quad j = 0, \dots, n.$$

每个 $\ell_j^{(i)}$ 满足

$$\ell_j^{(i)}(t_{i-1-m}) = \begin{cases} 1, & m = j, \\ 0, & m \neq j. \end{cases}$$

Lagrange 多项式在新的步进区间上给出光滑外推:

$$\epsilon_{\phi^\times}(\mathbf{x}_\tau, \tau) \approx P_n(\tau) = \sum_{j=0}^n \ell_j^{(i)}(\tau) \epsilon_{\phi^\times}(\tilde{\mathbf{x}}_{t_{i-1-j}}, t_{i-1-j}), \quad \tau \in [t_{i-1}, t_i].$$

随后, 在指数积分器公式 (式 (9.1.6)) 中, 以 $P_r(\tau)$ 代替 $\epsilon_{\phi^\times}(\mathbf{x}_\tau, \tau)$:

$$\begin{aligned} & \int_{t_{i-1}}^{t_i} \frac{g^2(\tau)}{2\sigma_\tau} \mathcal{E}(\tau \rightarrow t_i) \epsilon_{\phi^\times}(\mathbf{x}_\tau, \tau) d\tau \\ & \approx \sum_{j=0}^r \underbrace{\int_{t_{i-1}}^{t_i} \frac{g^2(\tau)}{2\sigma_\tau} \mathcal{E}(\tau \rightarrow t_i) \ell_j^{(i)}(\tau) d\tau}_{=: C_{i,j}} \epsilon_{\phi^\times}(\tilde{\mathbf{x}}_{t_{i-1-j}}, t_{i-1-j}). \end{aligned}$$

权重 $C_{i,j}$ 由下式给定:

$$C_{i,j} := \frac{1}{2} \int_{t_{i-1}}^{t_i} \frac{g^2(\tau)}{\sigma_\tau} \mathcal{E}(\tau \rightarrow t_i) \ell_j^{(i)}(\tau) d\tau,$$

它只依赖于调度 $(\alpha_\tau, \sigma_\tau)$ 和网格 $\{t_i\}$. 因此, 一旦固定步骤, 就能预先以闭式精确计算它们.

用 $\mathcal{E}(t_{i-1} \rightarrow t_i)$ 精确积分线性部分, 便得到 *AB-DEIS- r* 更新规则³,

$$\tilde{\mathbf{x}}_{t_i} = \mathcal{E}(t_{i-1} \rightarrow t_i) \tilde{\mathbf{x}}_{t_{i-1}} + \sum_{j=0}^r C_{i,j} \epsilon_{\phi^\times}(\tilde{\mathbf{x}}_{t_{i-1-j}}, t_{i-1-j}).$$

在标准光滑性假设下, 它产生 $r+1$ 阶局部截断误差.

情形 II: $i = 1, \dots, n$ (**历史不足**). 对于初始步骤, 只有 i 个过去点可用. 因此, 将次数设为 $i-1$, 并定义

$$P_{i-1}(\tau) = \sum_{j=0}^{i-1} \ell_j^{(i)}(\tau) \epsilon_{\phi^\times}(\tilde{\mathbf{x}}_{t_{i-1-j}}, t_{i-1-j}),$$

其中 $\ell_j^{(i)}$ 是基于时间节点 $\{t_{i-1}, t_{i-2}, \dots, t_0\}$ 构造的 $i-1$ 次 Lagrange 基. 这匹配全部可用锚点, 并在 $i \geq n+1$ 时无缝过渡到完整历史公式.

这是多步求解器中标准的“热启动”. 当历史较短时, 拟合数据所允许的最高次多项式: 一个锚点 ($i=1$) 使用 0 次 (常数); 两个锚点 ($i=2$) 使用 1 次 (线性); 三个锚点 ($i=3$) 使用 2 次 (二次); 依此类推, 直到目标次数 n . 实质上, 随着更多历史可用, 我们逐渐从一步预测提升到真正的 $(n+1)$ 步预测.

例: Lagrange 多项式的特殊情形

当 $r = 0$ (一个锚点) 时:

$$P_0(\tau) = \epsilon_{\phi^\times}(\tilde{\mathbf{x}}_{t_{i-1}}, t_{i-1}).$$

这里只使用最近的值, 因此近似在 τ 上是平坦的. 它对应于被积函数的左端点取值.

³“AB” 指经典 Adams–Bashforth 家族及指数时间差分多步方法 (Hochbruck and Ostermann, 2010).

当 $r = 1$ (两个锚点) 时: Lagrange 多项式是经过两个预先指定锚点的线性映射.

$$P_1(\tau) = \underbrace{\frac{\tau - t_{i-2}}{t_{i-1} - t_{i-2}}}_{\ell_{i-1}(\tau)} \epsilon_{\phi^\times}(\tilde{\mathbf{x}}_{t_{i-1}}, t_{i-1}) + \underbrace{\frac{\tau - t_{i-1}}{t_{i-2} - t_{i-1}}}_{\ell_{i-2}(\tau)} \epsilon_{\phi^\times}(\tilde{\mathbf{x}}_{t_{i-2}}, t_{i-2}).$$

这里 $\ell_{i-1}(\tau)$ 和 $\ell_{i-2}(\tau)$ 为 Lagrange 基权重. 它们满足插值 (节点) 条件 $P_1(t_{i-1}) = \epsilon_{\phi^\times}(\tilde{\mathbf{x}}_{t_{i-1}}, t_{i-1})$ 及 $P_1(t_{i-2}) = \epsilon_{\phi^\times}(\tilde{\mathbf{x}}_{t_{i-2}}, t_{i-2})$, 且有 $\ell_{i-1}(\tau) + \ell_{i-2}(\tau) = 1$. ■

AB-DEIS- n 更新概述. 综合历史充分与热启动 (历史不足) 两种情形, 得到如下 AB-DEIS- n 更新⁴, 其中 n 为多项式次数 (最多使用 $n+1$ 次过去的求值):

$$\tilde{\mathbf{x}}_{t_i} = \mathcal{E}(t_{i-1} \rightarrow t_i) \tilde{\mathbf{x}}_{t_{i-1}} + \sum_{j=0}^{\min\{n, i-1\}} C_{i,j} \epsilon_{\phi^\times}(\tilde{\mathbf{x}}_{t_{i-1-j}}, t_{i-1-j}),$$

其中系数为

$$C_{i,j} := \frac{1}{2} \int_{t_{i-1}}^{t_i} \frac{g^2(\tau)}{\sigma_\tau} \mathcal{E}(\tau \rightarrow t_i) \left[\prod_{\substack{k=0 \\ k \neq j}}^{\min\{n, i-1\}} \frac{\tau - t_{i-1-k}}{t_{i-1-j} - t_{i-1-k}} \right] d\tau.$$

当 $i \geq n+1$ (历史充分) 时, $\min\{n, i-1\} = n$, 在标准光滑性假设下, 该步骤达到局部截断误差 $\mathcal{O}(h^{n+1})$. 在热启动期间 ($i \leq n$), $\min\{n, i-1\} = i-1$, 每步的阶为 $\mathcal{O}(h^{\min\{n, i-1\}+1})$, 逐渐提高直到达到完整阶.

然而, 过大的 n 常因插值的病态性、噪声放大及更严格的稳定性约束而降低性能; 较低次数 (例如 $n \in \{1, 2, 3\}$) 通常提供最佳精度与稳定性权衡.

如下一小节将说明, 特殊情形 $n=0$ 退化为指数 Euler / DDIM.

9.3.3 DDIM = AB-DEIS-0

我们注意到, 当 $n = 0$ (即常数多项式) 时, 系数简化为:

$$C_{i0} = \frac{1}{2} \int_{t_{i-1}}^{t_i} \frac{g^2(\tau)}{\sigma_\tau} \mathcal{E}(\tau \rightarrow t_i) d\tau.$$

代入更新公式, 得到零次 AB-DEIS 方案:

$$\begin{aligned} \tilde{\mathbf{x}}_{t_i} &= \mathcal{E}(t_{i-1} \rightarrow t_i) \tilde{\mathbf{x}}_{t_{i-1}} + C_{i0} \epsilon_{\phi^\times}(\tilde{\mathbf{x}}_{t_{i-1}}, t_{i-1}) \\ &= e^{\int_{t_{i-1}}^{t_i} f(u) du} \tilde{\mathbf{x}}_{t_{i-1}} + \left(\int_{t_{i-1}}^{t_i} \frac{g^2(\tau)}{2\sigma_\tau} e^{\int_\tau^{t_i} f(u) du} d\tau \right) \epsilon_{\phi^\times}(\tilde{\mathbf{x}}_{t_{i-1}}, t_{i-1}). \end{aligned} \quad (9.3.1)$$

这恰是指数 Euler 步骤 (在 $[t_{i-1}, t_i]$ 上 $\epsilon_{\phi^\times}$ 随时间恒定), 与确定性 DDIM 更新一致. 下文正式陈述这一对应.

⁴“AB” 指指数时间差分多步方法的 Adams–Bashforth 家族 (Hochbruck and Ostermann, 2010).

命题 9.3.1: $\text{DDIM} = \text{AB-DEIS-0}$

式 (9.3.1) 与式 (9.2.2) 中的 DDIM 更新相同.

9.4 DPM-Solver

DPM-Solver 家族包括 DPM-Solver (Lu et al., 2022b)、DPM-Solver++ (Lu et al., 2022c) 和 DPM-Solver-v3 (Zheng et al., 2023), 是 PF-ODE 求解器的重要进展. 目标很简单: 以少得多的步骤达到相似样本质量. 实践中, 这些方法将 DDIM 所需步骤从超过 50 步降至约 10 至 15 步, 显著提高生成效率. 此外, DPM-Solver++ 和 DPM-Solver-v3 被设计为处理条件生成中的无分类器引导 (CFG, 见节 8.3). 本节首先解释核心 DPM-Solver (Lu et al., 2022b); 其扩展见节 9.5 和节 9.7.

DPM-Solver 的总体思想. 与 DEIS 类似, DPM-Solver 从 PF-ODE 的半线性形式出发, 在 ϵ 预测参数化下工作, 使用式 (A.1.2) 中的指数积分器 (常数变易法) 表示:

$$\frac{d\mathbf{x}_t}{dt} = \frac{\alpha'_t}{\alpha_t} \mathbf{x}_t - \sigma_t \left(\frac{\alpha'_t}{\alpha_t} - \frac{\sigma'_t}{\sigma_t} \right) \epsilon_{\phi^\times}(\mathbf{x}_t, t). \quad (9.4.1)$$

关键思想是以半对数信噪比重参数化时间, 使指数积分器公式中的非线性项变为指数加权积分. 这一表示允许低成本的 λ 变量 Taylor 展开, 从而自然产生高阶更新规则. 我们即将直观解释这一重参数化为何有效.

9.4.1 DPM-Solver 的洞见: 通过对数 SNR 进行时间重参数化

除了半线性结构, DPM-Solver 的关键洞见是, 标准时间参数化 t 对扩散模型数值积分并非最优. 它提出改用半对数信噪比 (半对数 SNR) 重参数化时间:

$$\lambda_t := \frac{1}{2} \log \frac{\alpha_t^2}{\sigma_t^2} = \log \frac{\alpha_t}{\sigma_t}, \quad (9.4.2)$$

这沿用了 VDM (Kingma et al., 2021) 的对数 SNR 参数化. 这一变量替换简化了非线性被积函数, 使高阶模型估计更易计算且更准确.

在 PF-ODE 中替换变量为对数 SNR. 现在使用半对数 SNR $\lambda_t := \log(\alpha_t/\sigma_t)$ 重参数化时间. 对于常见噪声调度, λ_t 关于 t 严格递减. 在这一假设下, 它具有将 λ 映射至 t 的逆函数 $t_\lambda(\cdot)$, 满足

$$t = t_\lambda(\lambda(t)).$$

随后将 $\mathbf{x}$ 和 $\epsilon_{\phi^\times}$ 的下标从 t 改为 λ . 帽号 ($\hat{\cdot}$) 表示量以 λ 表达. 更确切地, 定义:

$$\begin{aligned} \hat{\mathbf{x}}_\lambda &:= \mathbf{x}_{t_\lambda(\lambda)}, \\ \hat{\epsilon}_{\phi^\times}(\hat{\mathbf{x}}_\lambda, \lambda) &:= \epsilon_{\phi^\times}(\mathbf{x}_{t_\lambda(\lambda)}, t_\lambda(\lambda)). \end{aligned} \quad (9.4.3)$$

通过这一从 t 到 λ_t 的变量替换, 式 (9.4.1) 中 PF-ODE 的精确解 $\tilde{\Psi}_{s \rightarrow t}$ 变为:

命题 9.4.1: 指数加权的精确解

给定时间 $s > 0$ 处的初值 $\mathbf{x}_s$, 时间 $t \in [0, s]$ 处 PF-ODE 的精确解 $\tilde{\Psi}_{s \rightarrow t}(\mathbf{x}_s)$ 可以重新表达为:

$$\tilde{\Psi}_{s \rightarrow t}(\mathbf{x}_s) = \frac{\alpha_t}{\alpha_s} \mathbf{x}_s - \alpha_t \int_{\lambda_s}^{\lambda_t} e^{-\lambda} \hat{\epsilon}_{\phi \times}(\hat{\mathbf{x}}_{\lambda}, \lambda) d\lambda. \quad (9.4.4)$$

命题的证明.

虽然可以直接对式 (9.4.1) 应用变量替换得到结果, 为清晰完整起见, 我们在下文给出另一种推导. 利用关系 $g^2(t) = -2\sigma_t^2 \frac{d\lambda_t}{dt}$, 式 (9.4.1) 可重写为:

$$\frac{d\mathbf{x}_t}{dt} = \frac{d \log \alpha_t}{dt} \mathbf{x}_t - \sigma_t \frac{d\lambda_t}{dt} \epsilon_{\phi \times}(\mathbf{x}_t, t).$$

应用链式法则:

$$\frac{d\mathbf{x}_t}{dt} = \frac{d\hat{\mathbf{x}}_{\lambda}}{d\lambda} \frac{d\lambda_t}{dt} \quad \text{且} \quad \frac{d \log \alpha_t}{dt} = \frac{d \log \alpha_{\lambda}}{d\lambda} \frac{d\lambda_t}{dt},$$

关于 t 的 ODE 转化为如下关于 λ 的 ODE:

$$\begin{aligned} \frac{d\hat{\mathbf{x}}_{\lambda}}{d\lambda} &= \left(\frac{d\lambda_t}{dt} \right)^{-1} \frac{d\mathbf{x}_t}{dt} \\ &= \left(\frac{d\lambda_t}{dt} \right)^{-1} \left[\frac{d \log \alpha_t}{dt} \mathbf{x}_t - \sigma_t \frac{d\lambda_t}{dt} \epsilon_{\phi \times}(\mathbf{x}_t, t) \right] \\ &= \left(\frac{d\lambda_t}{dt} \right)^{-1} \left[\frac{d \log \alpha_{\lambda}}{d\lambda} \frac{d\lambda_t}{dt} \hat{\mathbf{x}}_{\lambda} - \sigma_{\lambda} \frac{d\lambda_t}{dt} \hat{\epsilon}_{\phi \times}(\hat{\mathbf{x}}_{\lambda}, \lambda) \right] \\ &= \frac{d \log \alpha_{\lambda}}{d\lambda} \hat{\mathbf{x}}_{\lambda} - \sigma_{\lambda} \hat{\epsilon}_{\phi \times}(\hat{\mathbf{x}}_{\lambda}, \lambda). \end{aligned}$$

因此, 变换后的 ODE 成为式 (9.4.5). 然后, 可以对式 (9.4.5) 应用相同的“指数积分器 (EI)”技术, 推导式 (9.4.4).

在 λ 时间中, 模型出现在指数加权积分内:

$$\int_{\lambda_s}^{\lambda_t} e^{-\lambda} \hat{\epsilon}_{\phi \times}(\hat{\mathbf{x}}_{\lambda}, \lambda) d\lambda,$$

其中 $e^{-\lambda}$ 因子产生闭式系数, 并使被积函数更光滑, 这正是高阶局部近似所需要的.

等价地, 将变量从 t 替换为 λ , 会将 PF-ODE 转化为下列微分形式 (推导见前一命题):

$$\frac{d\hat{\mathbf{x}}_{\lambda}}{d\lambda} = \frac{\alpha'_{\lambda}}{\alpha_{\lambda}} \hat{\mathbf{x}}_{\lambda} - \sigma_{\lambda} \hat{\epsilon}_{\phi \times}(\hat{\mathbf{x}}_{\lambda}, \lambda). \quad (9.4.5)$$

为何重参数化时间的直观解释. 对于严格单调的 $\lambda(t)$, 一阶变量替换给出

$$\Delta t \approx \frac{\Delta \lambda}{|\lambda'(t)|}.$$

因此, 对固定的 $\Delta \lambda$, 在 $|\lambda'(t)|$ 较大处 (即 λ 随 t 快速变化处), 诱导的 Δt 较小; 在 $|\lambda'(t)|$ 较小处, Δt 较大. 这一重参数化不改变 PF-ODE 的解路径, 只改变速度:

$$\frac{d\hat{\mathbf{x}}_\lambda}{d\lambda} = \frac{1}{\lambda'(t)} \frac{d\mathbf{x}_t}{dt}.$$

因此, 在 $|\lambda'(t)|$ 较大的区域, λ 域中的导数按 $1/|\lambda'(t)|$ 缩放, 这常使被积函数在均匀 λ 网格上更易光滑近似. ($|\lambda'(t)|$ 较大处的具体位置取决于所选调度.)

从概念上看, 当过程接近复杂的 (数据) 分布时, 我们可能希望分配更多时间步. 以下两个简单调度说明这一效果:

- $(\alpha_t, \sigma_t) = (1-t, t)$: 这对应 FM 调度. 此时

$$\lambda(t) = \log \frac{1-t}{t}, \quad \lambda'(t) = -\frac{1}{t(1-t)}, \quad \Delta t \approx \Delta \lambda t(1-t).$$

因此, 两端附近 ($t \rightarrow 0, 1$) 步长极小, 中间时间附近最大.

- $(\alpha_t, \sigma_t) = (1, t)$: 这是节 D.6 介绍的 EDM 调度 (Karras et al., 2022). 如果直接将自变量取为噪声水平 $t = \sigma_t$, 则

$$\lambda(t) = \log \frac{1}{t}, \quad \lambda'(t) = -\frac{1}{t}, \quad \Delta t \approx \Delta \lambda t.$$

在 λ 上均匀间隔, 相当于 t 上 (或等价地, 方差上) 的几何间隔 (在小 t / 高 SNR 处有许多小步, 在大 t 处较粗).

9.4.2 通过 Taylor 展开估计积分

DEIS 通过对过去的求值进行 Lagrange 插值来拟合被积函数. DPM-Solver 则在 λ 上使用局部 Taylor 展开: 其求值更便宜, 与 λ 参数化诱导的光滑性相适应, 并产生闭式步进系数. 下文给出详细说明.

由式 (9.4.4), 从时间 s 处的前一点 $\tilde{\mathbf{x}}_s$ 出发, 时间 t 处的解 $\tilde{\mathbf{x}}_t$ 由下式给定:

$$\tilde{\mathbf{x}}_t = \frac{\alpha_t}{\alpha_s} \tilde{\mathbf{x}}_s - \alpha_t \int_{\lambda_s}^{\lambda_t} e^{-\lambda} \hat{\epsilon}_{\phi \times}(\hat{\mathbf{x}}_\lambda, \lambda) d\lambda. \quad (9.4.6)$$

因此, 我们需要近似如下形式的积分:

$$\int_{\lambda_s}^{\lambda_t} e^{-\lambda} \hat{\epsilon}_{\phi \times}(\hat{\mathbf{x}}_\lambda, \lambda) d\lambda.$$

在区间 $\lambda \in [\lambda_s, \lambda_{t_i}]$ 上, 我们用关于 λ 的 Taylor 展开近似式 (9.4.6) 中的被积函数 $\hat{\epsilon}_{\phi \times}(\hat{\mathbf{x}}_\lambda, \lambda)$. 对于 $n \geq 1$, 在 λ_s 处的 $(n-1)$ 阶 Taylor 展开为

$$\hat{\epsilon}_{\phi \times}(\hat{\mathbf{x}}_\lambda, \lambda) = \sum_{k=0}^{n-1} \frac{(\lambda - \lambda_s)^k}{k!} \hat{\epsilon}_{\phi \times}^{(k)}(\hat{\mathbf{x}}_{\lambda_s}, \lambda_s) + \mathcal{O}((\lambda - \lambda_s)^n),$$

其中关于 λ 的 k 阶全导数记作

$$\hat{\epsilon}_{\phi^\times}^{(k)}(\hat{\mathbf{x}}_\lambda, \lambda) := \frac{d^k}{d\lambda^k} \hat{\epsilon}_{\phi^\times}(\hat{\mathbf{x}}_\lambda, \lambda).$$

将这一展开代入式 (9.4.6) 中的积分, 得到闭式近似, 它定义了称为 *DPM-Solver- n* 的 n 阶求解器.

从前一步的估计 $\tilde{\mathbf{x}}_s$ 出发,

$$\tilde{\mathbf{x}}_t = \frac{\alpha_t}{\alpha_s} \tilde{\mathbf{x}}_s - \alpha_t \sum_{k=0}^{n-1} \hat{\epsilon}_{\phi^\times}^{(k)}(\tilde{\mathbf{x}}_{\lambda_s}, \lambda_s) C_k + \mathcal{O}(h^{n+1}), \quad (9.4.7)$$

这里记 $h := \lambda_t - \lambda_s$, 并定义:

$$C_k := \int_{\lambda_s}^{\lambda_t} e^{-\lambda} \frac{(\lambda - \lambda_s)^k}{k!} d\lambda.$$

通过应用 k 次分部积分, 可以预先解析计算 C_k .

我们注意到, 变量替换 $t \mapsto \lambda$ 用于使被积函数更光滑并推导系数, 而求解器返回 t 网格上的估计 $\tilde{\mathbf{x}}_t$.

下面以 DPM-Solver-1 为例说明.

例: DPM-Solver-1

考虑 $n = 1$ (一阶) 作为演示. 从先前估计点 $\tilde{\mathbf{x}}_s$ 出发, 式 (9.4.7) 简化为:

$$\begin{aligned} \tilde{\mathbf{x}}_t &= \frac{\alpha_t}{\alpha_s} \tilde{\mathbf{x}}_s - \alpha_t \epsilon_{\phi^\times}(\tilde{\mathbf{x}}_s, s) \int_{\lambda_s}^{\lambda_t} e^{-\lambda} d\lambda + \mathcal{O}(h^2) \\ &= \frac{\alpha_t}{\alpha_s} \tilde{\mathbf{x}}_s - \sigma_t(e^h - 1) \epsilon_{\phi^\times}(\tilde{\mathbf{x}}_s, s) + \mathcal{O}(h^2). \end{aligned} \quad (9.4.8)$$

上述公式恰为 DDIM 更新; 我们在命题 9.4.2 中证明其等价性. ■

当 $n \geq 2$ 时, DPM-Solver- n 需要对 $k \leq n-1$ 计算 k 阶导数 $\hat{\epsilon}_{\phi^\times}^{(k)}(\hat{\mathbf{x}}_\lambda, \lambda)$. 但实践中直接计算高阶导数的成本很高. Lu et al. (2022b) 还提出了这些导数的高效近似方法, 下一小节将详细介绍.

9.4.3 DPM-Solver- n 的实现

$n \geq 2$ 时的 DPM-Solver- n . 实践中, 实现高阶 DPM-Solver- n 需要以下工作:

- 预先计算系数 C_k ;
- 对 $k \leq n-1$, 近似 k 阶导数 $\hat{\epsilon}_{\phi^\times}^{(k)}(\hat{\mathbf{x}}_\lambda, \lambda)$, 以绕过精确高阶导数的高成本计算; 这一挑战在 ODE 文献中已有充分研究 (Hochbruck and Ostermann, 2005; Luan, 2021). 一种常见策略是有限差分近似.

下面详细解释前两点.

预先计算 C_k . 令 s 和 t 分别表示起始与终止时间, 定义 $h := \lambda_t - \lambda_s$. 从 $\mathbf{x}_s$ 出发, 式 (9.1.6) 精确解的解析展开为:

$$\mathbf{x}_t = \frac{\alpha_t}{\alpha_s} \mathbf{x}_s - \sigma_t \sum_{k=0}^{n-1} h^{k+1} \varphi_{k+1}(h) \hat{\epsilon}_{\phi^\times}^{(k)}(\hat{\mathbf{x}}_{\lambda_s}, \lambda_s) + \mathcal{O}(h^{n+1}), \quad (9.4.9)$$

其中每个 $\varphi_{k+1}(\cdot)$ 都具有闭式表达. 对 $k = 0, 1, 2$, 分别为:

$$\varphi_1(h) = \frac{e^h - 1}{h}, \quad \varphi_2(h) = \frac{e^h - h - 1}{h^2}, \quad \varphi_3(h) = \frac{e^h - \frac{h^2}{2} - h - 1}{h^3}.$$

例: 使用精确导数的 DPM-Solver-2 / 3

对于 $n = 3$ 以及满足 $h := \lambda_t - \lambda_s$ 的离散时间步, 展开成为:

$$\begin{aligned} \mathbf{x}_t &= \frac{\alpha_t}{\alpha_s} \mathbf{x}_s - \sigma_t (e^h - 1) \hat{\epsilon}_{\phi^\times}(\hat{\mathbf{x}}_{\lambda_s}, \lambda_s) \\ &\quad - \sigma_t (e^h - h - 1) \hat{\epsilon}_{\phi^\times}^{(1)}(\hat{\mathbf{x}}_{\lambda_s}, \lambda_s) \\ &\quad - \sigma_t \left(e^h - \frac{h^2}{2} - h - 1 \right) \hat{\epsilon}_{\phi^\times}^{(2)}(\hat{\mathbf{x}}_{\lambda_s}, \lambda_s) \\ &\quad + \mathcal{O}(h^4). \end{aligned} \quad (9.4.10)$$

对 $k \leq n - 1$ 近似 $\hat{\epsilon}_{\phi^\times}^{(k)}(\hat{\mathbf{x}}_\lambda, \lambda)$. 对于 $n \geq 2$, 遵循单步 ODE 求解器的标准方法 (Atkinson, Han, and Stewart, 2009), Lu et al. (2022b) 在 s 和 t 之间引入中间时间步 s^{mid} , 使用 s 和 s^{mid} 处的函数求值近似高阶导数. 我们用 $n = 2$ 的情形说明.

令 $\gamma \in (0, 1]$ 为指定对数 SNR 区间 $[\lambda_s, \lambda_t]$ 内插值点的超参数. 给定 s 处的估计 $\tilde{\mathbf{x}}_s$, 定义

$$s^{\text{mid}} = t_\lambda(\lambda_s + \gamma h), \quad \text{其中 } h := \lambda_t - \lambda_s,$$

中间估计由下式给出:

$$\mathbf{x}^{\text{mid}} = \frac{\alpha_{s^{\text{mid}}}}{\alpha_s} \tilde{\mathbf{x}}_s - \sigma_{s^{\text{mid}}} (e^{\gamma h} - 1) \epsilon_{\phi^\times}(\tilde{\mathbf{x}}_s, s).$$

这产生如下二阶近似:

$$\begin{aligned} \tilde{\mathbf{x}}_t &= \frac{\alpha_t}{\alpha_s} \tilde{\mathbf{x}}_s - \sigma_t (e^h - 1) \epsilon_{\phi^\times}(\tilde{\mathbf{x}}_s, s) \\ &\quad - \frac{\sigma_t}{\gamma h} (e^h - h - 1) (\epsilon_{\phi^\times}(\mathbf{x}^{\text{mid}}, s^{\text{mid}}) - \epsilon_{\phi^\times}(\tilde{\mathbf{x}}_s, s)) + \mathcal{O}(h^3). \end{aligned} \quad (9.4.11)$$

当 $\gamma = \frac{1}{2}$ 时, 算法 5 中的两阶段更新与 式 (9.4.11) 相差 $\mathcal{O}(h^3)$ (局部截断误差).

算法 5 DPM-Solver-2 (取 $\gamma = \frac{1}{2}$) .

输入： 初值 $\mathbf{x}_T$, 时间步 $\{t_i\}_{i=0}^M$, 模型 $\epsilon_{\phi^\times}$

- 1: $\tilde{\mathbf{x}}_{t_0} \leftarrow \mathbf{x}_T$
 - 2: **对于** $i \leftarrow 1$ 至 M **执行**
 - 3: $h_i \leftarrow \lambda_{t_i} - \lambda_{t_{i-1}}$
 - 4: $s_i^{\text{mid}} \leftarrow t_\lambda \left(\frac{\lambda_{t_{i-1}} + \lambda_{t_i}}{2} \right)$
 - 5: $\mathbf{x}_i^{\text{mid}} \leftarrow \frac{\alpha_{s_i^{\text{mid}}}}{\alpha_{t_{i-1}}} \tilde{\mathbf{x}}_{t_{i-1}} - \sigma_{s_i^{\text{mid}}} \left(e^{\frac{h_i}{2}} - 1 \right) \epsilon_{\phi^\times}(\tilde{\mathbf{x}}_{t_{i-1}}, t_{i-1})$
 - 6: $\tilde{\mathbf{x}}_{t_i} \leftarrow \frac{\alpha_{t_i}}{\alpha_{t_{i-1}}} \tilde{\mathbf{x}}_{t_{i-1}} - \sigma_{t_i} (e^{h_i} - 1) \epsilon_{\phi^\times}(\mathbf{x}_i^{\text{mid}}, s_i^{\text{mid}})$
 - 7: **结束 对于**
 - 8: **返回** $\tilde{\mathbf{x}}_{t_M}$
-

注.

在式 (9.4.11) 中, 差商

$$\hat{\epsilon}_{\phi^\times}^{(1)}(\hat{\mathbf{x}}_{\lambda_s}, \lambda_s) \approx \frac{\epsilon_{\phi^\times}(\mathbf{x}^{\text{mid}}, s^{\text{mid}}) - \epsilon_{\phi^\times}(\tilde{\mathbf{x}}_s, s)}{\gamma h}$$

近似模型沿轨迹的 λ 全导数. 这一近似的误差为 $\mathcal{O}(h)$, 而在式 (9.4.11) 中, 它乘以精确的 φ_2 系数 $e^h - h - 1 = \mathcal{O}(h^2)$. 因此, 所得贡献只有 $\mathcal{O}(h^3)$, 所以对于任意 $\gamma \in (0, 1]$, 整体方案都达到二阶精度.

每步恰需两次模型求值: 一次在 $(\tilde{\mathbf{x}}_s, s)$, 一次在预测的中点 $(\mathbf{x}^{\text{mid}}, s^{\text{mid}})$. 插值参数 γ 不影响精度阶, 但会改变误差常数: 取 $\gamma = \frac{1}{2}$ 使差分模板对称, 通常最小化该常数, 因此实践中偏好中点版本.

对于 $n \geq 3$ 的更高阶 DPM-Solver- n , 采用类似方法, 利用中间时间步以有限差分方式近似高阶导数. 详细方法请参见 DPM 原论文.

对于熟悉数值 ODE 求解器的读者, DPM-SOLVER 可视为半线性 PF-ODE 的单步指数积分器, 结合向 (半) 对数 SNR 的时间变量替换. 其二阶与三阶变体是指数 Runge-Kutta 型方案, 在每步内使用少量分阶段模型求值.

实现细节: 采样时间步的选择. 为进行采样, 求解器必须先预定义时间步序列 $\{t_i\}_{i=0}^M$. Lu et al. (2022b) 提出根据对数 SNR 时间 λ_t 上的均匀间隔选择步骤, 其中

$$\lambda_{t_i} = \lambda_T + \frac{i}{M}(\lambda_0 - \lambda_T), \quad i = 0, \dots, M.$$

这不同于较早直接在物理时间变量 t 上使用均匀间隔的方法 (Ho, Jain, and Abbeel, 2020; Song et al., 2020b). 经验上, 使用均匀 λ 间隔时, DPM-Solver 即使仅用很少步骤也能得到高质量样本⁵.

⁵另一种选择是自适应步长策略, 结合不同阶求解器来动态调整时间步; 见 Lu et al. (2022b) 的附录 C.

从概念上可作几何理解：局部 Taylor 近似的精度取决于动力学在 λ 上演化的光滑程度。因此，在 λ 上均匀间隔，会沿轨迹产生近似均匀的局部误差；在信号主导（高 SNR）处，对应 t 上的更细（更密）步骤，在噪声主导处对应更粗（更疏）步骤。

尽管推导在 λ 空间进行，PF-ODE 也在这一域中采用方便的半线性形式，预训练模型及噪声调度 (α_t, σ_t) 通常仍关于原时间变量 t 定义。采样时，求解器为了数值稳定性选择在 λ 上均匀间隔的节点，但所有更新方程都用 t 表达。每当需要计算模型或取得调度值时，所选 λ 节点会映射回相应的时间变量，例如物理时间 $t = t_\lambda(\lambda)$ 或方差参数 σ_t ，具体取决于模型的参数化（例如见算法 5）。

9.4.4 DDIM = DPM-Solver-1

对于固定调度 (α_t, σ_t) ，DPM-Solver-1 步骤与确定性 DDIM ($\eta = 0$) 更新一致，与时间参数化（物理时间 t 或对数 SNR 时间 λ ）无关；正式陈述如下。

命题 9.4.2: DDIM 就是 DPM-Solver-1

式 (9.2.2) 给出的 DDIM 更新规则与式 (9.4.8) 给出的 DPM-Solver-1 相同。

命题的证明。

由 λ 的定义，有

$$\frac{\sigma_s}{\alpha_s} = e^{-\lambda_s} \quad \text{且} \quad \frac{\sigma_t}{\alpha_t} = e^{-\lambda_t}. \quad (9.4.12)$$

将这些表达以及 $h = \lambda_t - \lambda_s$ 代入式 (9.2.2)，即可恢复式 (9.4.8) 中的更新规则，完成等价性证明。 ■

上述命题或许解释了为何 DDIM 优于 t 参数化下的传统 Euler 方法：它实际上在更合适的 λ 重参数化下利用了扩散 ODE 的半线性性质。

注.

得分 SDE 论文发表时，常使用 Runge–Kutta (RK45) 求解式 (4.2.5) 中基本形式的 PF-ODE，但其漂移的半线性性质仍未被利用。尽管 DPM-Solver- k ($k \geq 2$) 与 Runge–Kutta 方法有关，它通过时间重参数化显式利用这一半线性性质。这解释了为何 DPM-Solver 用少得多的函数求值就达到高阶精度，将典型 DDIM 调度的数百步减少至约 10 至 15 步，同时保持高样本质量。

9.4.5 DPM-Solver-2 与经典 Heun 更新的讨论

在节 9.2.2 中，我们看到 PF-ODE 的不同参数化产生经典 Euler 型更新的不同解释：

$$\begin{aligned} \mathbf{v} \text{ 预测: } & \text{Euler} = \text{DDIM}, \\ \boldsymbol{\epsilon}, \mathbf{x}, \text{ 或 } \mathbf{s} \text{ 预测: } & \text{指数 Euler} = \text{DDIM} \neq \text{普通 Euler}. \end{aligned}$$

本小节进一步通过考察四种参数化下经典 *Heun* 方法与二阶 DPM-Solver 之间的类似关系, 说明这一联系.

首先, 简要回顾 *Heun* 方法 (亦见节 A.1.4). *Heun* 方法是一个二阶求解器, 通过预测与校正方案改进 Euler 方法: 先作到步骤终点的 Euler 预测, 在该处计算斜率, 再使用起始斜率和预测斜率的平均值更新. 直观地说, 它沿曲线跟随区间上的平均斜率 (梯形面积) 推进, 精度远高于普通 Euler 方法.

我们在对数 SNR 时间 λ 中工作, 此时 PF-ODE 可表达为简单的 “线性加非线性” 形式:

$$\frac{d\hat{\mathbf{x}}(\lambda)}{d\lambda} = \underbrace{L(\lambda)\hat{\mathbf{x}}(\lambda)}_{\text{线性部分}} + \underbrace{\mathbf{N}(\hat{\mathbf{x}}(\lambda), \lambda)}_{\text{非线性部分}},$$

其中标量 $L(\lambda)$ 由噪声调度确定, $\mathbf{N}(\cdot, \lambda)$ 汇集非线性部分. 这一结构自然源于式 (6.3.2): ϵ 、 $\mathbf{x}$ 和 $\mathbf{s}$ 预测参数化产生非零的 $L(\lambda)$, 形成半线性形式. 相比之下, $\mathbf{v}$ 预测对应 $L(\lambda) \equiv 0$ (所以 $\mathbf{N} = \mathbf{v}$), 不留下显式线性项.

在余下讨论中, 我们首先回顾不考虑半线性结构的普通 *Heun* 更新, 然后引入为半线性 ODE 设计的指数 *Heun* 更新; 后者精确处理线性部分, 与式 (9.1.7) 和 (9.1.8) 中的指数 Euler 步骤类似.

最后, 我们联系四种参数化下的两种 *Heun* 更新与 DPM-Solver-2, 并得到结论:

$\mathbf{v}$ 预测: $\text{Heun} = \text{DPM-Solver-2}$,

ϵ 、 $\mathbf{x}$ 、或 $\mathbf{s}$ 预测: 指数 *Heun* = DPM-Solver-2 $\neq$ 普通 *Heun*.

普通 *Heun* 更新. 记 $\lambda_i := \lambda_{t_i}$, 则 $\{\lambda_i\}_{i=0}^M$ 为对数 SNR 域中的递增网格, 并令 $h := \lambda_i - \lambda_{i-1} > 0$. 令 $\hat{\mathbf{x}}_{i-1}$ 表示对数 SNR 时间中的前一迭代点. 直接应用于完整漂移

$$\mathbf{F}(\hat{\mathbf{x}}, \lambda) := L(\lambda)\hat{\mathbf{x}} + \mathbf{N}(\hat{\mathbf{x}}, \lambda),$$

对数 SNR 时间中的普通 *Heun* 更新为

$$\begin{aligned} \text{预测: } \quad \hat{\mathbf{x}}_i^{\text{mid}} &= \hat{\mathbf{x}}_{i-1} + h\mathbf{F}(\hat{\mathbf{x}}_{i-1}, \lambda_{i-1}), \\ \text{校正: } \quad \hat{\mathbf{x}}_i &= \hat{\mathbf{x}}_{i-1} + \frac{h}{2} \left(\mathbf{F}(\hat{\mathbf{x}}_{i-1}, \lambda_{i-1}) + \mathbf{F}(\hat{\mathbf{x}}_i^{\text{mid}}, \lambda_i) \right). \end{aligned} \tag{9.4.13}$$

指数 *Heun* 更新 (用于半线性 PF-ODE). 指数积分器技术的思想是对 ODE 的线性和非线性部分作不同处理. 线性项 $L(\lambda)\hat{\mathbf{x}}$ 在步骤区间上被精确积分, 而非线性项 $\mathbf{N}(\hat{\mathbf{x}}, \lambda)$ 只通过平均其跨步骤影响来近似.

为整洁地表达这一点, 引入量

$$\mathcal{E} := \int_{\lambda_{i-1}}^{\lambda_i} L(\tau) d\tau,$$

它表示线性系数 $L(\lambda)$ 在区间 $[\lambda_{i-1}, \lambda_i]$ 上的总贡献. 使用 $\mathcal{E}$, 定义两个辅助系数 $c_1(\mathcal{E})$ 和 $c_2(\mathcal{E})$, 同时处理 $\mathcal{E}$ 非零和为零的两种情形:




图 9.3: **对数 SNR 时间中的普通 Heun 更新**. 从 λ_{i-1} 处的前一状态 $\hat{\mathbf{x}}_{i-1}$ 出发, 预测步骤 (蓝色箭头) 进行显式 Euler 移动 $h\mathbf{F}(\hat{\mathbf{x}}_{i-1}, \lambda_{i-1})$, 得到中间估计 $\hat{\mathbf{x}}_i^{\text{mid}}$. 在这一预测点, 校正步骤计算新斜率 $h\mathbf{F}(\hat{\mathbf{x}}_i^{\text{mid}}, \lambda_i)$ (绿色箭头), 并通过平行四边形构造组合两者: 橙色虚线对角线表示从 $\hat{\mathbf{x}}_{i-1}$ 出发的向量和 $h(\mathbf{F}(\hat{\mathbf{x}}_{i-1}, \lambda_{i-1}) + \mathbf{F}(\hat{\mathbf{x}}_i^{\text{mid}}, \lambda_i))$, 而橙色实线箭头是其半条对角线, 方向相同但长度减半. 这一过程实现了对数 SNR 时间中 PF-ODE 轨迹的普通 Heun 积分.

$$c_1(\mathcal{E}) = \begin{cases} \frac{e^{\mathcal{E}} - 1}{\mathcal{E}}, & \text{若 } \mathcal{E} \neq 0, \\ 1, & \text{若 } \mathcal{E} = 0, \end{cases} \quad c_2(\mathcal{E}) = \begin{cases} \frac{e^{\mathcal{E}} - 1 - \mathcal{E}}{\mathcal{E}^2}, & \text{若 } \mathcal{E} \neq 0, \\ \frac{1}{2}, & \text{若 } \mathcal{E} = 0. \end{cases}$$

第二种情形只是在消除线性项 ($L(\lambda) = 0$) 时确保连续性, 使公式仍有效, 并光滑地退化为式 (9.4.13) 中的标准 Heun 更新.

使用这些系数, 指数 Heun 方案的一步更新可写为:

$$\begin{aligned} \text{预测: } \quad \hat{\mathbf{x}}_i^{\text{mid}} &= e^{\mathcal{E}} \hat{\mathbf{x}}_{i-1} + hc_1(\mathcal{E}) \mathbf{N}(\hat{\mathbf{x}}_{i-1}, \lambda_{i-1}), \\ \text{校正: } \quad \hat{\mathbf{x}}_i &= e^{\mathcal{E}} \hat{\mathbf{x}}_{i-1} + hc_1(\mathcal{E}) \mathbf{N}(\hat{\mathbf{x}}_{i-1}, \lambda_{i-1}) \\ &\quad + hc_2(\mathcal{E}) \left(\mathbf{N}(\hat{\mathbf{x}}_i^{\text{mid}}, \lambda_i) - \mathbf{N}(\hat{\mathbf{x}}_{i-1}, \lambda_{i-1}) \right). \end{aligned} \quad (9.4.14)$$

当 $L(\lambda) \equiv 0$ 时, 系数简化为 $c_1 = 1$ 及 $c_2 = \frac{1}{2}$, 方法退化为式 (9.4.13) 中的普通 Heun 求解器.

当 $L(\lambda) \neq 0$ 时, 更新的指数积分器形式精确积分线性项, 而普通 Heun 方法只给出近似. 为说明这一点, 对小步长

$h = \lambda_i - \lambda_{i-1} > 0$ 展开指数项. 由于

$$\mathcal{E} = \int_{\lambda_{i-1}}^{\lambda_i} L(\tau) d\tau = hL(\lambda_{i-1}) + \mathcal{O}(h^2),$$

可以将 $\mathcal{E}$ 视为 $\mathcal{O}(h)$ 阶的小量. Taylor 展开给出:

$$e^{\mathcal{E}} = 1 + \mathcal{E} + \frac{\mathcal{E}^2}{2} + \mathcal{O}(\mathcal{E}^3), \quad c_1(\mathcal{E}) = 1 + \frac{\mathcal{E}}{2} + \frac{\mathcal{E}^2}{6} + \mathcal{O}(\mathcal{E}^3), \quad c_2(\mathcal{E}) = \frac{1}{2} + \frac{\mathcal{E}}{6} + \frac{\mathcal{E}^2}{24} + \mathcal{O}(\mathcal{E}^3).$$

将这些近似代入式 (9.4.14), 并保留至 $\mathcal{E}^2$ 的项 (即由于 $\mathcal{E} = \mathcal{O}(h)$, 保留至 h^2 阶), 更新恰简化为普通 Heun 形式 (式 (9.4.13)). 两方案的剩余差异只出现在 $\mathcal{O}(\mathcal{E}^3) = \mathcal{O}(h^3)$ 大小的更高阶项中. 直观地说, 当步长 h 较小时, $\mathcal{E}$ 也较小, 因此指数因子退化为

$$e^{\mathcal{E}} \approx 1 + \mathcal{E}, \quad c_1(\mathcal{E}) \approx 1, \quad c_2(\mathcal{E}) \approx \frac{1}{2}.$$

因此, 这一“处理了线性项”的指数 Heun 更新退化为普通 Heun 步骤.

四种预测下 Heun 更新与 DPM-Solver-2 的联系. 我们强调, 在 PF-ODE 的 ϵ 预测形式 (见式 (9.4.5)) 下, 对数 SNR 时间 λ 中的动力学自然具有所需的半线性形式:

$$\frac{d\hat{\mathbf{x}}_\lambda}{d\lambda} = \underbrace{\frac{\alpha'_\lambda}{\alpha_\lambda}}_{=:L(\lambda)} \hat{\mathbf{x}}_\lambda + \underbrace{\left(-\sigma_\lambda \hat{\epsilon}_{\phi^\times}(\hat{\mathbf{x}}_\lambda, \lambda) \right)}_{=:N(\hat{\mathbf{x}}_\lambda, \lambda)}.$$

因此, 对于对数 SNR 时间 λ 中的 ϵ 预测, 式 (9.4.14) 中的指数 Heun 更新与 DPM-Solver-2 完全等价 (取中点参数 $\gamma = \frac{1}{2}$; 见算法 5) .

类似地, 在对数 SNR 时间中的 $\mathbf{x}$ 和 $\mathbf{s}$ 预测参数化下, 其 PF-ODE 也具有相同半线性结构. 因此, ϵ 、 $\mathbf{x}$ 或 $\mathbf{s}$ 预测下的 DPM-Solver-2 与式 (9.4.14) 中的指数 Heun 更新相同. 而 $\mathbf{v}$ 预测形式自然消除了线性项, 所以其 PF-ODE 不需要指数积分器; 对数 SNR 时间中的普通 Heun 方法已给出正确的二阶更新.

与 DDIM 中 Euler 与指数 Euler 的情形类似, 我们因此得出以下结论:

观察 9.4.1: Heun 与 DPM-Solver-2 更新

给定对数 SNR 时间 λ 中的 PF-ODE,

$\mathbf{v}$ 预测: Heun = DPM-Solver-2,

ϵ 、 $\mathbf{x}$ 、或 $\mathbf{s}$ 预测: 指数 Heun = DPM-Solver-2 $\neq$ 普通 Heun,

其中, 在 ϵ 、 $\mathbf{x}$ 或 $\mathbf{s}$ 预测情形下, 普通 Heun 步骤不等价于 DPM-Solver-2, 因为线性项只是被近似, 而未被精确积分.

9.5 DPM-Solver++

9.5.1 从 DPM-Solver 到用于引导的 DPM-Solver++

高阶求解器在没有引导时实现更快采样. 然而, 扩散模型以其可控、灵活的生成能力受到重视, 通常通过引导实现 (详见章 8).

DPM-Solver++ (Lu et al., 2022c) 发现先前高阶求解器的关键局限: 在大引导尺度 (更强条件) 下, 它们存在稳定性问题, 甚至可能比 DDIM 更慢. 作者将这一不稳定性归因于大引导尺度同时放大输出及其导数. 由于高阶求解器依赖高阶导数, 它们对这一影响尤其敏感, 导致效率和稳定性下降.

9.5.2 DPM-Solver++ 的方法

为处理上述问题, DPM-Solver++ 提出:

1. 采用 $\mathbf{x}$ 预测参数化来代替 ϵ 预测;
2. 应用阈值处理方法 (例如动态阈值 (Saharia et al., 2022)), 将预测数据保持在训练数据范围内 (缓解大引导尺度下训练与测试之间的不匹配).

我们详细解释第一点. 回顾式 (6.3.1), 数据与噪声参数化存在线性关系:

$$\epsilon_{\phi^\times}(\mathbf{x}_t, t) = \frac{\mathbf{x}_t - \alpha_t \mathbf{x}_{\phi^\times}(\mathbf{x}_t, t)}{\sigma_t}.$$

利用这一关系, DPM-Solver++ 从任意 $\mathbf{x}_s$ 出发, 将经验 PF-ODE 的精确解 $\tilde{\Psi}_{s \rightarrow t}(\mathbf{x}_s)$ (原本在式 (9.4.4) 中用噪声参数化表达)

$$\tilde{\Psi}_{s \rightarrow t}(\mathbf{x}_s) = \frac{\alpha_t}{\alpha_s} \mathbf{x}_s - \alpha_t \int_{\lambda_s}^{\lambda_t} e^{-\lambda} \hat{\epsilon}_{\phi^\times}(\hat{\mathbf{x}}_\lambda, \lambda) d\lambda,$$

重写为数据参数化:

$$\tilde{\Psi}_{s \rightarrow t}(\mathbf{x}_s) = \frac{\sigma_t}{\sigma_s} \mathbf{x}_s + \sigma_t \int_{\lambda_s}^{\lambda_t} e^{\lambda} \hat{\mathbf{x}}_{\phi^\times}(\hat{\mathbf{x}}_\lambda, \lambda) d\lambda,$$

其中沿用式 (9.4.3) 中的记号, 并进一步记为:

$$\begin{aligned} \hat{\mathbf{x}}_\lambda &:= \mathbf{x}_{t_\lambda(\lambda)}, \\ \hat{\mathbf{x}}_{\phi^\times}(\hat{\mathbf{x}}_\lambda, \lambda) &:= \mathbf{x}_{\phi^\times}(\mathbf{x}_{t_\lambda(\lambda)}, t_\lambda(\lambda)). \end{aligned}$$

基于 $\mathbf{x}$ 预测, DPM-Solver++ 提供两种求解器变体:

- **高阶单步求解器:** 在节 9.5.3 中介绍. 这一方法类似 DPM-Solver, 利用高阶 Taylor 展开来近似积分, 但这里以 $\mathbf{x}$ 预测表述. 更新只使用一个过去点来估计下一步.
- **多步 (两步) 求解器:** 在节 9.5.4 中介绍. 设计思想类似 DEIS (同样是多步方法); 不过, DPM-Solver++ 专门复用两个过去点 (DEIS 则允许一般阶) 来估计下一步. 每次更新只需一次新的扩散模型求值.

9.5.3 通过 Taylor 展开实现 DPM-Solver++ 单步方法

遵循与节 9.4.3 类似的方法，DPM-Solver++ 在 $\mathbf{x}$ 参数化下推导高阶求解器。对于 $n \geq 0$ ，用下式表示 $\hat{\mathbf{x}}_{\phi^\times}$ 关于 λ 、在 λ_{i-1} 处取值的 n 阶全导数：

$$\hat{\mathbf{x}}_{\phi^\times}^{(n)}(\hat{\mathbf{x}}_{\lambda_{i-1}}, \lambda_{i-1}) := \left. \frac{d^n}{d\lambda^n} \hat{\mathbf{x}}_{\phi^\times}(\hat{\mathbf{x}}_\lambda, \lambda) \right|_{\lambda=\lambda_{i-1}}.$$

给定时间 t_{i-1} 处的前一估计 $\tilde{\mathbf{x}}_{t_{i-1}}$ ，在 λ_{i-1} 处使用 $(n-1)$ 阶 Taylor 展开，近似 $\lambda \in [\lambda_{t_{i-1}}, \lambda_{t_i}]$ 上的 $\hat{\mathbf{x}}_{\phi^\times}(\hat{\mathbf{x}}_\lambda, \lambda)$ （其中 $s = t_{i-1}$ 且 $t = t_i$ ），得到 $\tilde{\Psi}_{s \rightarrow t}(\mathbf{x}_s)$ 的如下近似：

$$\tilde{\mathbf{x}}_{t_i} = \frac{\sigma_{t_i}}{\sigma_{t_{i-1}}} \tilde{\mathbf{x}}_{t_{i-1}} + \sigma_{t_i} \underbrace{\sum_{k=0}^{n-1} \hat{\mathbf{x}}_{\phi^\times}^{(k)}(\hat{\mathbf{x}}_{\lambda_{i-1}}, \lambda_{i-1})}_{\text{通过以下方式估计有限差分}} \underbrace{\int_{\lambda_{t_{i-1}}}^{\lambda_{t_i}} e^{\lambda} \frac{(\lambda - \lambda_{t_{i-1}})^k}{k!} d\lambda}_{\text{可解析计算}} + \mathcal{O}(h_i^{n+1}).$$

其中 $h_i := \lambda_{t_i} - \lambda_{t_{i-1}} > 0$ 。与式 (9.4.9) 类似，积分具有闭式形式

$$\int_{\lambda_{t_{i-1}}}^{\lambda_{t_i}} e^{\lambda} \frac{(\lambda - \lambda_{t_{i-1}})^k}{k!} d\lambda = e^{\lambda_{t_{i-1}}} h_i^{k+1} \varphi_{k+1}(h_i), \quad \varphi_m(h) := \frac{e^h - \sum_{j=0}^{m-1} \frac{h^j}{j!}}{h^m}.$$

这给出 DPM-Solver++ 的单步更新（用一个过去点估计下一步）。当 $n = 1$ 时，它退化为 DDIM 更新。当 $n = 2$ ，并通过有限差分近似 $\hat{\mathbf{x}}_{\phi^\times}^{(1)}(\hat{\mathbf{x}}_{\lambda_{i-1}}, \lambda_{i-1})$ 时，得到 DPM-Solver++(2S)，这一更新类似算法 5 中的 DPM-Solver-2，但采用 $\mathbf{x}$ 预测。DPM-Solver++(2S) 的算法见算法 6。

算法 6 DPM-Solver++(2S)：中点特殊情形。

输入： 初值 $\mathbf{x}_T$ ，时间步 $\{t_i\}_{i=0}^M$ ，数据预测模型 $\hat{\mathbf{x}}_{\phi^\times}$

- 1: $\tilde{\mathbf{x}}_{t_0} \leftarrow \mathbf{x}_T$; $\lambda_{t_i} \leftarrow \log(\alpha_{t_i}/\sigma_{t_i})$ ▷ 网格处的对数 SNR
 - 2: $\hat{\mathbf{x}}_0 \leftarrow \hat{\mathbf{x}}_{\phi^\times}(\tilde{\mathbf{x}}_{t_0}, t_0)$ ▷ 缓存起点的预测
 - 3: **对于** $i \leftarrow 1$ **至** M **执行**
 - 4: $h_i \leftarrow \lambda_{t_i} - \lambda_{t_{i-1}}$; $s_i^{\text{mid}} \leftarrow t_\lambda\left(\frac{\lambda_{t_{i-1}} + \lambda_{t_i}}{2}\right)$
 - 5: $\mathbf{u}_i \leftarrow \frac{\sigma_{s_i^{\text{mid}}}}{\sigma_{t_{i-1}}} \tilde{\mathbf{x}}_{t_{i-1}} + \alpha_{s_i^{\text{mid}}} (1 - e^{-h_i/2}) \hat{\mathbf{x}}_{i-1}$ ▷ 预测至中点
 - 6: $\mathbf{D}_i^{\text{mid}} \leftarrow \hat{\mathbf{x}}_{\phi^\times}(\mathbf{u}_i, s_i^{\text{mid}})$ ▷ 在中点进行一次新模型调用
 - 7: $\tilde{\mathbf{x}}_{t_i} \leftarrow \frac{\sigma_{t_i}}{\sigma_{t_{i-1}}} \tilde{\mathbf{x}}_{t_{i-1}} - \alpha_{t_i} (e^{-h_i} - 1) \mathbf{D}_i^{\text{mid}}$
 - 8: $\hat{\mathbf{x}}_i \leftarrow \hat{\mathbf{x}}_{\phi^\times}(\tilde{\mathbf{x}}_{t_i}, t_i)$ ▷ 为下一步缓存
 - 9: **结束 对于**
 - 10: **返回** $\tilde{\mathbf{x}}_{t_M}$
-

9.5.4 通过复用历史实现 DPM-Solver++ 多步方法

高阶单步求解器（显式或隐式地）依赖模型输出的高阶导数；在强 CFG 下，这些导数可能被大幅放大，使更新不稳定。DPM-Solver++ 用对数 SNR 时间 λ 中的多步

(Adams 型) 策略缓解这一问题: 沿轨迹复用少量过去的数据预测求值, 通过有限差分近似所需导数. 这一复用使每步只需一次新模型调用. 与 DEIS 类似, 分两种情形介绍: 情形 1, 无历史的热启动 (第一步); 情形 2, 具有两个历史锚点的后续步骤.

情形 I. 具有一个历史锚点的 DPM-Solver++ ($i = 1$). 对于第一步 ($i = 1$; 没有历史), 使用一阶 DPM 风格更新 (与数据预测下的确定性 DDIM 步骤相同). 令 $h_1 = \lambda_1 - \lambda_0$.

$$\tilde{\mathbf{x}}_{t_1} = \frac{\sigma_{t_1}}{\sigma_{t_0}} \tilde{\mathbf{x}}_{t_0} + \sigma_{t_1} e^{\lambda_0} (e^{h_1} - 1) \hat{\mathbf{x}}_{\phi \times}(\tilde{\mathbf{x}}_{t_0}, t_0)$$

情形 II. 具有两个历史锚点的 DPM-Solver++ ($i \geq 2$). 热启动后, 两步多步更新复用时间 t_{i-2} 处的 $\tilde{\mathbf{x}}_{t_{i-2}}$ 估计及时间 t_{i-1} 处的 $\tilde{\mathbf{x}}_{t_{i-1}}$ 估计. 在每步 $i \geq 2$ 中, 这些提供最近的两个锚点, 等价地在 λ 时间中为:

$$(\lambda_{i-1}, \hat{\mathbf{x}}_{\phi \times}(\tilde{\mathbf{x}}_{t_{i-1}}, t_{i-1})) \quad \text{且} \quad (\lambda_{i-2}, \hat{\mathbf{x}}_{\phi \times}(\tilde{\mathbf{x}}_{t_{i-2}}, t_{i-2})),$$

只使用这些缓存锚点计算更新 $\tilde{\mathbf{x}}_{t_i}$ (形成更新无需新模型调用). 得到 $\tilde{\mathbf{x}}_{t_i}$ 后, 在 $(\tilde{\mathbf{x}}_{t_i}, t_i)$ 处计算一次模型, 并缓存 $\hat{\mathbf{x}}_{\phi \times}(\tilde{\mathbf{x}}_{t_i}, t_i)$. 这一求值在第 i 步中执行, 用作后续第 $i+1$ 步的锚点. 即我们通过离散化精确的 $\mathbf{x}$ 预测形式, 寻求每步一次调用、在大引导尺度下保持稳定的更新:

$$\tilde{\Psi}_{s \rightarrow t}(\mathbf{x}_s) = \frac{\sigma_t}{\sigma_s} \mathbf{x}_s + \sigma_t \int_{\lambda_s}^{\lambda_t} e^{\lambda} \hat{\mathbf{x}}_{\phi \times}(\hat{\mathbf{x}}_{\lambda}, \lambda) d\lambda.$$

在单个步骤 $[\lambda_{i-1}, \lambda_i]$ 上, 精确处理线性 ODE 部分, 并将被积函数近似为 λ 的线性函数 (由于有两个锚点), 以近似残余积分. 具体而言, 在 $[\lambda_{i-1}, \lambda_i]$ 上, 以仿射模型近似

$$\lambda \mapsto \hat{\mathbf{x}}_{\phi \times}(\hat{\mathbf{x}}_{\lambda}, \lambda)$$

$$\hat{\mathbf{x}}_{\phi \times}(\hat{\mathbf{x}}_{\lambda}, \lambda) \approx \mathbf{L}(\lambda) := \mathbf{a}_0 + \mathbf{a}_1(\lambda - \lambda_{i-1}), \quad \lambda \in [\lambda_{i-1}, \lambda_i],$$

其中 $\lambda_i = \lambda_{t_i}$ 、 $h_i = \lambda_i - \lambda_{i-1} > 0$, 系数 $\mathbf{a}_0$ 和 $\mathbf{a}_1$ 由经过最近两个锚点的直线唯一确定:

$$\mathbf{a}_0 = \hat{\mathbf{x}}_{\phi \times}(\tilde{\mathbf{x}}_{t_{i-1}}, t_{i-1}), \quad \mathbf{a}_1 = \frac{\hat{\mathbf{x}}_{\phi \times}(\tilde{\mathbf{x}}_{t_{i-1}}, t_{i-1}) - \hat{\mathbf{x}}_{\phi \times}(\tilde{\mathbf{x}}_{t_{i-2}}, t_{i-2})}{h_{i-1}}.$$

将 $\mathbf{L}(\lambda)$ 代入积分, 得到⁶

$$\begin{aligned}
\sigma_{t_i} \int_{\lambda_{i-1}}^{\lambda_i} e^\lambda \hat{\mathbf{x}}_{\phi^\times}(\tilde{\mathbf{x}}_\lambda, \lambda) d\lambda &\approx \sigma_{t_i} \int_{\lambda_{i-1}}^{\lambda_i} e^\lambda \mathbf{L}(\lambda) d\lambda \\
&= \left(\sigma_{t_i} \int_{\lambda_{i-1}}^{\lambda_i} e^\lambda d\lambda \right) \mathbf{a}_0 + \left(\sigma_{t_i} \int_{\lambda_{i-1}}^{\lambda_i} e^\lambda (\lambda - \lambda_{i-1}) d\lambda \right) \mathbf{a}_1 \\
&= (\alpha_{t_i} (1 - e^{-h_i})) \mathbf{a}_0 + (\alpha_{t_i} (h_i - 1 + e^{-h_i})) \mathbf{a}_1 \\
&= \alpha_{t_i} (1 - e^{-h_i}) (\mathbf{a}_0 + \beta(h_i) \mathbf{a}_1),
\end{aligned}$$

其中 $\beta(h) := \frac{h-1+e^{-h}}{1-e^{-h}}$. 至此, 我们已经得到 $\tilde{\mathbf{x}}_{t_i}$ 的有效估计:

$$\tilde{\mathbf{x}}_{t_i} = \frac{\sigma_{t_i}}{\sigma_{t_{i-1}}} \tilde{\mathbf{x}}_{t_{i-1}} + \alpha_{t_i} (1 - e^{-h_i}) \mathbf{D}_i, \quad \text{其中 } \mathbf{D}_i = \mathbf{a}_0 + \beta(h_i) \mathbf{a}_1.$$

实践中, 可以得到与上述规则具有相同局部截断误差的简化更新规则 (假设步长比有界):

$$\tilde{\mathbf{x}}_{t_i} = \frac{\sigma_{t_i}}{\sigma_{t_{i-1}}} \tilde{\mathbf{x}}_{t_{i-1}} + \alpha_{t_i} (1 - e^{-h_i}) \mathbf{D}_i^{\text{sim}}(\tilde{\mathbf{x}}_{t_{i-1}}, \tilde{\mathbf{x}}_{t_{i-2}}).$$

这里定义步长比 $r_i = h_i/h_{i-1}$, 并令

$$\mathbf{D}_i^{\text{sim}}(\tilde{\mathbf{x}}_{t_{i-1}}, \tilde{\mathbf{x}}_{t_{i-2}}) := \left(1 + \frac{1}{2}r_i\right) \hat{\mathbf{x}}_{\phi^\times}(\tilde{\mathbf{x}}_{t_{i-1}}, t_{i-1}) - \frac{1}{2}r_i \hat{\mathbf{x}}_{\phi^\times}(\tilde{\mathbf{x}}_{t_{i-2}}, t_{i-2}).$$

在标准光滑性假设下, 局部误差为 $\mathcal{O}(h_i^3)$.

为说明原因, 简化记号如下:

$$\mathbf{a}_0 = \hat{\mathbf{x}}_{\phi^\times}(\tilde{\mathbf{x}}_{t_{i-1}}, t_{i-1}) =: \hat{\mathbf{x}}_{i-1}, \quad \mathbf{a}_1 = \frac{\hat{\mathbf{x}}_{i-1} - \hat{\mathbf{x}}_{i-2}}{h_{i-1}}.$$

⁶第二个恒等式由直接代数运算得到. 所需两个指数矩为

$$\int_{\lambda_{i-1}}^{\lambda_i} e^\lambda d\lambda = e^{\lambda_{i-1}} (e^{h_i} - 1), \quad \int_{\lambda_{i-1}}^{\lambda_i} e^\lambda (\lambda - \lambda_{i-1}) d\lambda = e^{\lambda_{i-1}} (h_i e^{h_i} - e^{h_i} + 1).$$

乘以精确形式的前因子 σ_{t_i} , 并使用 $\alpha_t = \sigma_t e^{\lambda_t}$ (因此 $\sigma_{t_i} e^{\lambda_{i-1}} = \alpha_{t_i} e^{-h_i}$), 得到方便的系数

$$\sigma_{t_i} \int_{\lambda_{i-1}}^{\lambda_i} e^\lambda d\lambda = \alpha_{t_i} (1 - e^{-h_i}), \quad \sigma_{t_i} \int_{\lambda_{i-1}}^{\lambda_i} e^\lambda (\lambda - \lambda_{i-1}) d\lambda = \alpha_{t_i} (h_i - 1 + e^{-h_i}).$$

于是

$$\begin{aligned}
\mathbf{D}_i &:= \mathbf{a}_0 + \beta(h_i) \mathbf{a}_1 \\
&= \hat{\mathbf{x}}_{i-1} + \frac{\beta(h_i)}{h_{i-1}} (\hat{\mathbf{x}}_{i-1} - \hat{\mathbf{x}}_{i-2}) \\
&= \left(1 + \frac{r_i}{2}\right) \hat{\mathbf{x}}_{i-1} - \frac{r_i}{2} \hat{\mathbf{x}}_{i-2} + \left(\frac{\beta(h_i)}{h_{i-1}} - \frac{r_i}{2}\right) (\hat{\mathbf{x}}_{i-1} - \hat{\mathbf{x}}_{i-2}) \\
&= \left[\left(1 + \frac{1}{2}r_i\right) \hat{\mathbf{x}}_{i-1} - \frac{1}{2}r_i \hat{\mathbf{x}}_{i-2}\right] + \mathcal{O}(h_i^2) \\
&= \mathbf{D}_i^{\text{sim}} + \mathcal{O}(h_i^2)
\end{aligned}$$

这里使用了以下事实：对于小步长， $\beta(h)$ 在 $h = 0$ 处的 Taylor 展开给出

$$\beta(h) = \frac{h}{2} + \mathcal{O}(h^2) \implies \frac{\beta(h_i)}{h_{i-1}} = \frac{h_i}{2h_{i-1}} + \mathcal{O}(h_i^2/h_{i-1}) = \frac{r_i}{2} + \mathcal{O}(h_i^2/h_{i-1}),$$

且在某个光滑性假设下，有 $\hat{\mathbf{x}}_{i-1} - \hat{\mathbf{x}}_{i-2} = \mathcal{O}(h_{i-1})$.

注.

如果对数 SNR 步骤均匀（每步大小均为 h ，因此 $h_i \equiv h$ 且 $r_i = h_i/h_{i-1} = 1$ ），则双锚点混合

$$\mathbf{D}_i^{\text{sim}} = \left(1 + \frac{1}{2}r_i\right) \hat{\mathbf{x}}_{i-1} - \frac{1}{2}r_i \hat{\mathbf{x}}_{i-2}$$

退化为经典常数

$$\mathbf{D}_i^{\text{sim}} = \left(1 + \frac{1}{2} \cdot 1\right) \hat{\mathbf{x}}_{i-1} - \frac{1}{2} \cdot 1 \hat{\mathbf{x}}_{i-2} = \frac{3}{2} \hat{\mathbf{x}}_{i-1} - \frac{1}{2} \hat{\mathbf{x}}_{i-2}.$$

这些 $(\frac{3}{2}, -\frac{1}{2})$ 恰是均匀步长下 Adams–Bashforth 2 方法的权重，即标准两步线性多步系数.

算法 7 DPM-Solver++(2M).

输入： 初值 $\mathbf{x}_T$, 时间步 $\{t_i\}_{i=0}^M$, 模型 $\hat{\mathbf{x}}_{\phi^\times}$

1: $\tilde{\mathbf{x}}_{t_0} \leftarrow \mathbf{x}_T$; $\lambda_{t_i} \leftarrow \log(\alpha_{t_i}/\sigma_{t_i})$; $h_i \leftarrow \lambda_{t_i} - \lambda_{t_{i-1}}$

2: $\hat{\mathbf{x}}_0 \leftarrow \hat{\mathbf{x}}_{\phi^\times}(\tilde{\mathbf{x}}_{t_0}, t_0)$

▷ 缓存起点预测

情形 I. 一个锚点的热启动 ($i = 1$, $\mathbf{x}$ 预测下的 DDIM)

3: $\tilde{\mathbf{x}}_{t_1} \leftarrow \frac{\sigma_{t_1}}{\sigma_{t_0}} \tilde{\mathbf{x}}_{t_0} - \alpha_{t_1}(e^{-h_1} - 1) \hat{\mathbf{x}}_0$

4: $\hat{\mathbf{x}}_1 \leftarrow \hat{\mathbf{x}}_{\phi^\times}(\tilde{\mathbf{x}}_{t_1}, t_1)$

▷ 一次模型调用并缓存

情形 II. 使用两个已缓存的历史锚点 (多步)

5: **对于** $i \leftarrow 2$ **至** M **执行**

6: $r_i \leftarrow h_i/h_{i-1}$

▷ 步长比

7: $\mathbf{D}_i^{\text{sim}} \leftarrow \left(1 + \frac{1}{2}r_i\right)\hat{\mathbf{x}}_{i-1} - \frac{1}{2}r_i\hat{\mathbf{x}}_{i-2}$

8: $\tilde{\mathbf{x}}_{t_i} \leftarrow \frac{\sigma_{t_i}}{\sigma_{t_{i-1}}} \tilde{\mathbf{x}}_{t_{i-1}} + \alpha_{t_i}(1 - e^{-h_i}) \mathbf{D}_i^{\text{sim}}$

9: $\hat{\mathbf{x}}_i \leftarrow \hat{\mathbf{x}}_{\phi^\times}(\tilde{\mathbf{x}}_{t_i}, t_i)$

▷ 一次模型调用并缓存

10: **结束 对于**

11: **返回** $\tilde{\mathbf{x}}_{t_M}$

9.6 PF-ODE 求解器家族及其数值对应

本节首先将目前介绍的 PF-ODE 求解器 (DDIM、DEIS、DPM-Solver、DPM-Solver++) 置于经典数值积分方法的背景中. 随后进一步考察两个代表性高阶求解器 DEIS 与 DPM-Solver++, 比较各自的设计.

9.6.1 PF-ODE 求解器家族与经典对应方法

可以从经典数值分析的视角理解各种 PF-ODE 采样器家族. 一旦通过积分因子处理线性漂移, 每个采样器便自然对应一个已建立的时间步进方案: Euler 型方法、Adams–Bashforth (AB) 多步方案或 Runge–Kutta (RK) 单步积分器. 表 9.1 概括这些对应.

表 9.1: PF-ODE 采样器及其数值分析对应方法. “exp.” 表示对线性项的积分因子 (半线性) 处理 (见式 (9.1.6)). AB = Adams–Bashforth, RK = Runge–Kutta. *DPM-Solver-2* 见算法 5.

PF-ODE 求解器	类型	经典数值对应方法
DDIM	单步	$\mathbf{v}$ 预测: 普通 Euler; ϵ / $\mathbf{x}$ / $\mathbf{s}$ 预测: 指数 Euler
DEIS	多步	指数 AB (n^{th} 阶)
DPM-Solver- n	单步	对数 SNR 中的指数 RK (n^{th} 阶)
DPM-Solver-2	单步	$\mathbf{v}$ 预测: 对数 SNR 中的普通 Heun (2^{nd} 阶); ϵ / $\mathbf{x}$ / $\mathbf{s}$ 预测: 对数 SNR 中的指数 Heun (2^{nd} 阶)
DPM-Solver++ 2S	单步	指数 RK (2^{nd} 阶)
DPM-Solver++ 2M	多步	指数 AB (2^{nd} 阶)

我们突出表 9.1 中的两个代表性例子: DDIM 与 DPM-Solver-2. 对于固定调度 (α_t, σ_t) , 强调节 9.2.2、9.3.3 和 9.4.4 中的说明性结果: 无论使用对数 SNR 时间还是原物理时间,

$\mathbf{v}$ 预测: DDIM = DPM-Solver-1 = DEIS-1 = Euler,

ϵ 、 $\mathbf{x}$ 、或 $\mathbf{s}$ 预测: DDIM = DPM-Solver-1 = DEIS-1 = 指数 Euler.

在节 9.4.5 中, 我们通过考察四种参数化下 DPM-Solver-2 与经典 Heun 求解器的联系, 扩展了这一类比:

$\mathbf{v}$ 预测: DPM-Solver-2 = Heun,

ϵ 、 $\mathbf{x}$ 、或 $\mathbf{s}$ 预测: DPM-Solver-2 = 指数 Heun $\neq$ 普通 Heun.

DPM-Solver- n 与经典 RK 方法之间更一般的对应关系, 可以用同样方式理解.

9.6.2 DEIS 与 DPM-Solver++ 的讨论

方面	DEIS	DPM++
核心视角	指数积分器：精确积分线性项；通过过去节点上的多项式近似非线性残余。	相同的积分器思想；在对数 SNR 时间 λ 中以数据预测表述。
步骤类型	仅多步	单步 (2S) 与多步 (2M)
多项式基	跨过去锚点的 Lagrange 插值 (高阶多步)。	2M 在 λ 时间中使用后向差商 (Newton / Adams 型)；代数上张成与 Lagrange 相同的多项式空间，但并不表述为 Lagrange 拟合。
求解器阶	高阶多步 (一般 r)。	存在高阶单步方法 (主要关注 2S)，并提供二阶多步 (2M) 方案；未讨论更高阶多步变体。
历史使用	使用 $r+1$ 次过去求值来构造高阶更新。	2S：一次中间求值 (单步)。 2M：复用两个锚点；热启动后，每步一次模型调用。

DEIS 与 DPM-Solver++ 的比较。 DEIS 与 DPM++ 都是指数积分采样器，精确积分线性部分，并用低次多项式近似残余积分。在无条件生成中，两者都可以仅用 10 至 20 个 ODE 步骤达到高保真度。然而，对于 CFG 条件生成，DPM++ 通常更合适，因为它在大引导尺度下更稳定。我们概括 DEIS 与 DPM++ 的比较，并在下文进一步讨论。

DEIS. 它是在 Lagrange 基中跨过去节点对非线性项拟合多项式 (通过锚点插值) 所得的多步方法。

DPM-Solver++. 它在对数 SNR 时间中使用数据预测：其单步 (2S) 变体采用一次中间求值的 Taylor / 指数积分器步骤，多步 (2M) 变体则通过后向差商复用历史；这些差商产生同一插值多项式，但以 Newton (有限差分) 基表达。

换言之，对于相同锚点和函数值，Lagrange 形式与 Newton 形式是同一插值多项式的两套不同坐标：Lagrange 将其表达为函数值乘基数多项式之和，Newton 则表达为乘积展开，其系数由差商给出 (即在多步方案中易于更新的有限差分比)。DPM++ 论文重点讨论二阶 (2S / 2M)；原则上，可以使用更高阶 Newton 基构造高阶多步扩展。

9.7 (选读) DPM-Solver-v3

DPM-Solver 与 DPM-Solver++ 都基于扩散模型的特定参数化 (ϵ / $\mathbf{x}$ 预测) 设计求解器, 缺少有原则的参数化选择方法, 也未必代表最优选择.

本节介绍 DPM-Solver-v3 (Zheng et al., 2023), 它处理这一问题, 并在更少时间步或大引导尺度下改善样本质量. DPM-Solver-v3 可视为整个 DPM-Solver 家族 (Lu et al., 2022b; Lu et al., 2022c) 洞见的集成.

DPM-Solver-v3 的总体概述. 我们继续关注 DPM-Solver (Lu et al., 2022b) 的关键原则, 即式 (9.4.5) 表达的 SNR 时间重参数化:

$$\frac{d\mathbf{x}_\lambda}{d\lambda} = \frac{\alpha'_\lambda}{\alpha_\lambda} \mathbf{x}_\lambda - \sigma_\lambda \hat{\epsilon}_{\phi^\times}(\mathbf{x}_\lambda, \lambda).$$

DPM-Solver-v3 (Zheng et al., 2023) 的核心思想是在式 (9.4.5) 中引入三个额外的欠定 / 自由变量, 使原 ODE 解能够通过新模型参数化作等价重写. 随后提出高效搜索方法, 在预训练模型上计算, 以最小化离散化误差为目标, 确定这些变量的最优组合.

9.7.1 洞见 1: 调整式 (9.4.5) 中的线性项

PF-ODE 是一个刚性 ODE, 在时间演化的各个方向上有不同的时间尺度, 使少时间步求解变得复杂. 借鉴经典刚性 ODE 理论 (Hochbruck and Ostermann, 2010), Zheng et al. (2023) 提出修改 ODE 的线性部分, 以更好地处理这些刚性动力学. 我们首先从经典数值 ODE 理论解释这一方法的动机.

动机: 从经典刚性 ODE 求解器出发. 首先考虑式 (9.4.5) 的抽象形式:

$$\frac{d\mathbf{x}_\lambda}{d\lambda} = \mathbf{v}(\mathbf{x}_\lambda, \lambda),$$

其中 $\mathbf{v}(\mathbf{x}, \lambda)$ 表示向量场.

“Rosenbrock 型指数积分器”是一类为高效求解刚性 ODE 而开发的方法. 关键特点是可以灵活选择线性算子 $\mathbf{L}$, 将向量场分解为:

$$\mathbf{v}(\mathbf{x}, \lambda) = \mathbf{L}\mathbf{x} + \mathbf{N}(\mathbf{x}, \lambda),$$

其中 $\mathbf{N}(\mathbf{x}, \lambda)$ 表示非线性余项. 如常应用指数积分器技术, 从 $\mathbf{x}_{\lambda_s}$ 出发, 得到以下更新:

$$\tilde{\Psi}_{\lambda_s \rightarrow \lambda_t}(\mathbf{x}_{\lambda_s}) = e^{h\mathbf{L}}\mathbf{x}_{\lambda_s} + \int_{\lambda_s}^{\lambda_t} e^{(\lambda_t - \tau)\mathbf{L}}\mathbf{N}(\mathbf{x}_\tau, \tau) d\tau, \quad \text{其中 } \Delta h := \lambda_t - \lambda_s.$$

我们注意到, 线性部分具有指数形式. 通常通过利用预条件信息来选择 $\mathbf{L}$, 以更高效地处理刚性, 目标是 (1) 确保方法稳定; (2) 改善数值解收敛速度; (3) 保证 $e^{\Delta\lambda\mathbf{L}}$ 保持较高计算效率.

将上述思想应用于式 (9.4.5) 中的 PF-ODE. 将介绍的概念应用于式 (9.4.5):

$$\frac{d\mathbf{x}_\lambda}{d\lambda} = \underbrace{\frac{\alpha'_\lambda}{\alpha_\lambda} \mathbf{x}_\lambda - \sigma_\lambda \hat{\epsilon}_{\phi^\times}(\mathbf{x}_\lambda, \lambda)}_{\mathbf{v}(\mathbf{x}_\lambda, \lambda)},$$

将其重写为:

$$\frac{d\mathbf{x}_\lambda}{d\lambda} = \underbrace{\left(\frac{\alpha'_\lambda}{\alpha_\lambda} - \ell_\lambda\right) \mathbf{x}_\lambda}_{\text{线性部分}} - \underbrace{(\sigma_\lambda \hat{\epsilon}_{\phi^\times}(\mathbf{x}_\lambda, \lambda) - \ell_\lambda \mathbf{x}_\lambda)}_{\text{非线性部分}}. \quad (9.7.1)$$

这里, ℓ_λ 是只依赖于 λ 的 D 维自由 / 欠定变量. 为方便记号, 将线性和非线性部分记为

$$\begin{aligned} \mathbf{L}(\lambda) &:= \frac{\alpha'_\lambda}{\alpha_\lambda} - \ell_\lambda, \\ \mathbf{N}_{\phi^\times}(\mathbf{x}_\lambda, \lambda) &:= \sigma_\lambda \hat{\epsilon}_{\phi^\times}(\mathbf{x}_\lambda, \lambda) - \ell_\lambda \mathbf{x}_\lambda. \end{aligned} \quad (9.7.2)$$

Zheng et al. (2023) 提出通过求解以下简单最小二乘问题来选择 ℓ_λ :

$$\ell_\lambda^* = \arg \min_{\ell_\lambda} \mathbb{E}_{\mathbf{x}_\lambda \sim p_{\lambda}^{\phi^\times}(\mathbf{x}_\lambda)} \|\nabla_{\mathbf{x}} \mathbf{N}_{\phi^\times}(\mathbf{x}_\lambda, \lambda)\|_F^2, \quad (9.7.3)$$

其中 $\|\cdot\|_F$ 表示 Frobenius 范数, $p_{\lambda}^{\phi^\times}$ 表示式 (9.7.4) 中 ODE 轨迹上样本在 λ 处的边缘分布.

注意, $\ell_\lambda = \ell_\lambda^*$ 可以解析求解. 这一选择利用预训练模型的预条件信息, 从概念上降低 $\mathbf{N}_{\phi^\times}$ 对 $\mathbf{x}$ 误差的敏感度 (因为 $\mathbf{N}_{\phi^\times}$ 的 Lipschitz 程度近似由 $\mathbf{x}$ 梯度刻画, 得到降低), 并消去 $\mathbf{N}_{\phi^\times}$ 的“线性部分”.

9.7.2 洞见 2: 在模型参数化中引入自由变量以进一步最小化离散化误差

PF-ODE 具有半线性结构 (见式 (9.7.1) 和式 (9.7.2)). 为使记号清晰, 考虑经验 PF-ODE 的如下 (抽象) 表述:

$$\frac{d\mathbf{x}_\lambda}{d\lambda} = \mathbf{L}(\lambda) \mathbf{x}_\lambda + \mathbf{N}_{\phi^\times}(\mathbf{x}_\lambda, \lambda). \quad (9.7.4)$$

动机: 理解离散化误差及其最小化策略. 如常, 这一经验 ODE 在区间 $[\lambda_s, \lambda_t]$ 上的精确解可以通过常数变易公式表达:

$$\tilde{\Psi}_{\lambda_s \rightarrow \lambda_t}(\mathbf{x}_{\lambda_s}) = \mathcal{E}(\lambda_s \rightarrow \lambda_t) \mathbf{x}_{\lambda_s} + \int_{\lambda_s}^{\lambda_t} \mathcal{E}(\lambda \rightarrow \lambda_s) \mathbf{N}_{\phi^\times}(\mathbf{x}_\lambda, \lambda) d\lambda, \quad (9.7.5)$$

其中 $\mathcal{E}(s \rightarrow t) := e^{-\int_s^t \mathbf{L}(u) du}$. 使用估计

$$\mathbf{N}_{\phi^\times}(\mathbf{x}_{\lambda_s}, \lambda_s) \approx \mathbf{N}_{\phi^\times}(\mathbf{x}_\lambda, \lambda) \quad \text{对于 } \lambda \in [\lambda_s, \lambda_t],$$

便可得到如下近似解：

$$\tilde{\mathbf{x}}_{\lambda_t} = \mathcal{E}(\lambda_s \rightarrow \lambda_t) \mathbf{x}_{\lambda_s} + \int_{\lambda_s}^{\lambda_t} \mathcal{E}(\lambda \rightarrow \lambda_s) \mathbf{N}_{\phi^\times}(\mathbf{x}_{\lambda_s}, \lambda_s) d\lambda. \quad (9.7.6)$$

将式 (9.7.5) 与式 (9.7.6) 相减，并将 $\mathbf{N}_{\phi^\times}(\mathbf{x}_{\lambda_s}, \lambda_s)$ 作 Taylor 展开：

$$\mathbf{N}_{\phi^\times}(\mathbf{x}_{\lambda_s}, \lambda_s) = \mathbf{N}_{\phi^\times}(\mathbf{x}_\lambda, \lambda) + (\lambda_s - \lambda) \mathbf{N}_{\phi^\times}^{(1)}(\mathbf{x}_\lambda, \lambda) + \mathcal{O}((\lambda_s - \lambda)^2),$$

便可量化一阶离散化误差：

$$\tilde{\mathbf{x}}_{\lambda_t} - \tilde{\Psi}_{\lambda_s \rightarrow \lambda_t}(\mathbf{x}_{\lambda_s}) = \int_{\lambda_s}^{\lambda_t} \mathcal{E}(\lambda \rightarrow \lambda_s) (\lambda_s - \lambda) \mathbf{N}_{\phi^\times}^{(1)}(\mathbf{x}_\lambda, \lambda) d\lambda + \mathcal{O}(h^3),$$

其中 $h := \lambda_t - \lambda_s$. 这一观察表明，离散化误差依赖于 $\mathbf{N}_{\phi^\times}^{(1)}(\mathbf{x}_\lambda, \lambda)$.

为减少这一误差，Zheng et al. (2023) 提出使用新参数化 $\mathbf{N}_{\phi^\times}^{\text{new}}(\mathbf{x}_\lambda, \lambda)$ ，将式 (9.7.5) 重写为等价形式，使误差项保持类似结构：

$$\tilde{\mathbf{x}}_{\lambda_t} - \tilde{\Psi}_{\lambda_s \rightarrow \lambda_t}(\mathbf{x}_{\lambda_s}) = \int_{\lambda_s}^{\lambda_t} \mathcal{E}(\lambda \rightarrow \lambda_s) (\lambda_s - \lambda) \mathbf{N}_{\phi^\times}^{\text{new},(1)}(\mathbf{x}_\lambda, \lambda) d\lambda + \mathcal{O}(h^3).$$

此外， $\mathbf{N}_{\phi^\times}^{\text{new}}(\mathbf{x}_\lambda, \lambda)$ 的 λ 导数满足：

$$\mathbf{N}_{\phi^\times}^{\text{new},(1)}(\mathbf{x}_\lambda, \lambda) \propto \mathbf{N}_{\phi^\times}^{(1)}(\mathbf{x}_\lambda, \lambda) - (\mathbf{a}_\lambda \mathbf{N}_{\phi^\times}(\mathbf{x}_\lambda, \lambda) + \mathbf{b}_\lambda). \quad (9.7.7)$$

这里 $\mathbf{a}_\lambda$ 和 $\mathbf{b}_\lambda$ 是自由 / 欠定变量。

于是目标是确定 $\mathbf{a}_\lambda$ 和 $\mathbf{b}_\lambda$ 的最优值，通过减小 $\mathbf{N}_{\phi^\times}^{\text{new},(1)}(\mathbf{x}_\lambda, \lambda)$ 最小化离散化误差。可通过求解以下最小二乘优化问题实现：

$$(\mathbf{a}_\lambda^*, \mathbf{b}_\lambda^*) = \arg \min_{\mathbf{a}_\lambda, \mathbf{b}_\lambda} \mathbb{E}_{\mathbf{x}_\lambda \sim p_{\lambda_s}^{\phi^\times}(\mathbf{x}_\lambda)} \left[\|\mathbf{N}_{\phi^\times}^{(1)}(\mathbf{x}_\lambda, \lambda) - (\mathbf{a}_\lambda \mathbf{N}_{\phi^\times}(\mathbf{x}_\lambda, \lambda) + \mathbf{b}_\lambda)\|_2^2 \right]. \quad (9.7.8)$$

值得注意的是，式 (9.7.8) 具有依赖预训练扩散模型、可预先计算的解析解。

实现最小化离散化误差的策略。 首先考虑 $\mathbf{N}_{\phi^\times}(\mathbf{x}_\lambda, \lambda)$ 的线性变换版本，定义为：

$$\mathbf{N}_{\phi^\times}^{\text{new}}(\mathbf{x}_\lambda, \lambda) := e^{-\int_{\lambda_s}^{\lambda} \mathbf{a}_u du} \mathbf{N}_{\phi^\times}(\mathbf{x}_\lambda, \lambda) - \int_{\lambda_s}^{\lambda} e^{-\int_{\lambda_s}^r \mathbf{a}_u du} \mathbf{b}_r dr. \quad (9.7.9)$$

随后可以容易地计算其 λ 导数：

$$\mathbf{N}_{\phi^\times}^{\text{new},(1)}(\mathbf{x}_\lambda, \lambda) = e^{-\int_{\lambda_s}^{\lambda} \mathbf{a}_u du} \left[\mathbf{N}_{\phi^\times}^{(1)}(\mathbf{x}_\lambda, \lambda) - (\mathbf{a}_\lambda \mathbf{N}_{\phi^\times}(\mathbf{x}_\lambda, \lambda) + \mathbf{b}_\lambda) \right], \quad (9.7.10)$$

它具有式 (9.7.7) 所期望的形式。

利用这一关系， $\mathbf{N}_{\phi^\times}(\mathbf{x}_\lambda, \lambda)$ 可重写为：

$$\begin{aligned} \mathbf{N}_{\phi^\times}(\mathbf{x}_\lambda, \lambda) &= e^{\int_{\lambda_s}^{\lambda} \mathbf{a}_u du} \left[\underbrace{e^{-\int_{\lambda_s}^{\lambda} \mathbf{a}_u du} \mathbf{N}_{\phi^\times}(\mathbf{x}_\lambda, \lambda) - \int_{\lambda_s}^{\lambda} e^{-\int_{\lambda_s}^r \mathbf{a}_u du} \mathbf{b}_r dr}_{\mathbf{N}_{\phi^\times}^{\text{new}}(\mathbf{x}_\lambda, \lambda)} \right. \\ &\quad \left. + \int_{\lambda_s}^{\lambda} e^{-\int_{\lambda_s}^r \mathbf{a}_u du} \mathbf{b}_r dr \right] \\ &= e^{\int_{\lambda_s}^{\lambda} \mathbf{a}_u du} \left[\mathbf{N}_{\phi^\times}^{\text{new}}(\mathbf{x}_\lambda, \lambda) + \int_{\lambda_s}^{\lambda} e^{-\int_{\lambda_s}^r \mathbf{a}_u du} \mathbf{b}_r dr \right] \end{aligned}$$

通过这一重写，可以将式 (9.7.5) 和式 (9.7.6) 写为：

$$\tilde{\Psi}_{\lambda_s \rightarrow \lambda_t}(\mathbf{x}_{\lambda_s}) = \mathcal{E}(\lambda_s \rightarrow \lambda_t) \mathbf{x}_{\lambda_s} + \int_{\lambda_s}^{\lambda_t} \mathcal{E}(\lambda \rightarrow \lambda_s) e^{\int_{\lambda_s}^{\lambda} \mathbf{a}_u du} \quad (9.7.11)$$

$$\begin{aligned} & \left[\mathbf{N}_{\phi^\times}^{\text{new}}(\mathbf{x}_\lambda, \lambda) + \int_{\lambda_s}^{\lambda} e^{-\int_{\lambda_s}^r \mathbf{a}_u du} \mathbf{b}_r dr \right] d\lambda \\ \tilde{\mathbf{x}}_{\lambda_t} &= \mathcal{E}(\lambda_s \rightarrow \lambda_t) \mathbf{x}_{\lambda_s} + \int_{\lambda_s}^{\lambda_t} \mathcal{E}(\lambda \rightarrow \lambda_s) e^{\int_{\lambda_s}^{\lambda} \mathbf{a}_u du} \quad (9.7.12) \\ & \left[\mathbf{N}_{\phi^\times}^{\text{new}}(\mathbf{x}_{\lambda_s}, \lambda_s) + \int_{\lambda_s}^{\lambda} e^{-\int_{\lambda_s}^r \mathbf{a}_u du} \mathbf{b}_r dr \right] d\lambda \end{aligned}$$

将两式相减，并使用 Taylor 展开：

$$\mathbf{N}_{\phi^\times}^{\text{new}}(\mathbf{x}_{\lambda_s}, \lambda_s) = \mathbf{N}_{\phi^\times}^{\text{new}}(\mathbf{x}_\lambda, \lambda) + (\lambda_s - \lambda) \mathbf{N}_{\phi^\times}^{\text{new},(1)}(\mathbf{x}_\lambda, \lambda) + \mathcal{O}((\lambda_s - \lambda)^2),$$

得到：

$$\begin{aligned} & \tilde{\mathbf{x}}_{\lambda_t} - \tilde{\Psi}_{\lambda_s \rightarrow \lambda_t}(\mathbf{x}_{\lambda_s}) \\ &= \int_{\lambda_s}^{\lambda_t} \mathcal{E}(\lambda \rightarrow \lambda_s) (\lambda_s - \lambda) e^{\int_{\lambda_s}^{\lambda} \mathbf{a}_u du} \mathbf{N}_{\phi^\times}^{\text{new},(1)}(\mathbf{x}_\lambda, \lambda) d\lambda + \mathcal{O}(h^3) \\ &= \int_{\lambda_s}^{\lambda_t} \mathcal{E}(\lambda \rightarrow \lambda_s) (\lambda_s - \lambda) \left[\mathbf{N}_{\phi^\times}^{(1)}(\mathbf{x}_\lambda, \lambda) - (\mathbf{a}_\lambda \mathbf{N}_{\phi^\times}(\mathbf{x}_\lambda, \lambda) + \mathbf{b}_\lambda) \right] d\lambda + \mathcal{O}(h^3) \end{aligned}$$

这里，最后一个等式由式 (9.7.10) 得到，这是设计的核心，它消去了因子 $e^{\int_{\lambda_s}^{\lambda} \mathbf{a}_u du}$ 。

因此，通过求解式 (9.7.8)，可以确定最优系数 $(\mathbf{a}_\lambda^*, \mathbf{b}_\lambda^*)$ ，从而有效地最小化离散化误差。

9.7.3 结合两项洞见.

现在概括目前的讨论。

理论流程. 对于任意 λ ，首先通过求解式 (9.7.3) 中的最小二乘问题，解析计算 ℓ_λ^* ：

$$\ell_\lambda^* = \arg \min_{\ell_\lambda} \mathbb{E}_{\mathbf{x}_\lambda \sim p_{\ell_\lambda}^{\phi^\times}(\mathbf{x}_\lambda)} \|\nabla_{\mathbf{x}} \mathbf{N}_{\phi^\times}(\mathbf{x}_\lambda, \lambda)\|_F^2,$$

其中 $\mathbf{N}_{\phi^\times}(\mathbf{x}_\lambda, \lambda)$ 由式 (9.7.2) 定义。然后，固定 $\ell_\lambda = \ell_\lambda^*$ ，通过求解式 (9.7.8) 中的最小二乘问题，解析计算 $(\mathbf{a}_\lambda^*, \mathbf{b}_\lambda^*)$ ：

$$(\mathbf{a}_\lambda^*, \mathbf{b}_\lambda^*) = \arg \min_{\mathbf{a}_\lambda, \mathbf{b}_\lambda} \mathbb{E}_{\mathbf{x}_\lambda \sim p_{\ell_\lambda}^{\phi^\times}(\mathbf{x}_\lambda)} \left[\|\mathbf{N}_{\phi^\times}^{(1)}(\mathbf{x}_\lambda, \lambda) - (\mathbf{a}_\lambda \mathbf{N}_{\phi^\times}(\mathbf{x}_\lambda, \lambda) + \mathbf{b}_\lambda)\|_2^2 \right].$$

因此，式 (9.7.12) 定义的所得 $\tilde{\mathbf{x}}_{\lambda_t}$ （在式 (9.7.9) 中将 ℓ_λ 、 $\mathbf{a}_\lambda$ 和 $\mathbf{b}_\lambda$ 替换为 ℓ_λ^* 、 $\mathbf{a}_\lambda^*$ 和 $\mathbf{b}_\lambda^*$ ），作为所需的 $\tilde{\Psi}_{\lambda_s \rightarrow \lambda_t}(\mathbf{x}_{\lambda_s})$ 估计。

实现考虑. 尽管 ℓ_λ^* 、 $\mathbf{a}_\lambda^*$ 和 $\mathbf{b}_\lambda^*$ 具有涉及预训练扩散模型 $\epsilon_{\phi^\times}$ 的雅可比矩阵向量积的解析解（详见 Zheng et al. (2023) 的附录 C.1.1），计算它们需要对 $p_\lambda^{\phi^\times}$ 求期望。

实践中，通过 Monte Carlo (MCMC) 方法估计这些量。具体而言，对式 (9.4.5) 使用其他求解器（例如 200 步 DPM-Solver++ (Lu et al., 2022c)），抽取一批数据点 $\mathbf{x}_\lambda \sim p_\lambda^{\phi^\times}$ （约 1K 至 4K 个样本），随后解析计算与 $\epsilon_{\phi^\times}$ 有关的项。这些统计量均可预先计算，确保应用 DPM-Solver-v3 时避免相关计算开销。

9.7.4 高阶 DPM-Solver-v3

通过分析一阶离散化误差导出的预计算统计量 ℓ_λ^* 、 $\mathbf{a}_\lambda^*$ 和 $\mathbf{b}_\lambda^*$ ，也可用来构造高阶求解器（进一步解释亦见节 9.7.5）。

为得到式 (9.7.11) 的 $(n+1)$ 阶近似，我们使用 $\mathbf{N}_{\phi^\times}^{\text{new}}(\mathbf{x}_\lambda, \lambda)$ 关于 λ 在 λ_s 处的 n 阶 Taylor 展开，略去 $\mathcal{O}((\lambda_s - \lambda)^{(n+1)})$ 阶项。由此近似 $\lambda \in [\lambda_s, \lambda_t]$ 上的 $\mathbf{N}_{\phi^\times}^{\text{new}}(\mathbf{x}_\lambda, \lambda)$ ：

$$\mathbf{N}_{\phi^\times}^{\text{new}}(\mathbf{x}_\lambda, \lambda) \approx \mathbf{N}_{\phi^\times}^{\text{new}}(\mathbf{x}_{\lambda_s}, \lambda_s) + \sum_{k=1}^n \frac{(\lambda - \lambda_s)^k}{k!} \mathbf{N}_{\phi^\times}^{\text{new},(k)}(\mathbf{x}_{\lambda_s}, \lambda_s),$$

这一近似产生式 (9.7.11) 的估计解：

$$\begin{aligned} \tilde{\mathbf{x}}_{\lambda_t} &= \mathcal{E}(\lambda_s \rightarrow \lambda_t) \mathbf{x}_{\lambda_s} + \underbrace{\int_{\lambda_s}^{\lambda_t} \mathcal{E}(\lambda \rightarrow \lambda_s) e^{\int_{\lambda_s}^{\lambda} \mathbf{a}_u^* du}}_{=: \mathbf{E}(\lambda_s \rightarrow \lambda)} \\ &\quad \cdot \left[\sum_{k=0}^n \frac{(\lambda - \lambda_s)^k}{k!} \mathbf{N}_{\phi^\times}^{\text{new},(k)}(\mathbf{x}_{\lambda_s}, \lambda_s) + \underbrace{\int_{\lambda_s}^{\lambda} e^{-\int_{\lambda_s}^r \mathbf{a}_u^* du} \mathbf{b}_r^* dr}_{=: \mathbf{B}(\lambda_s \rightarrow \lambda)} \right] d\lambda. \\ &= \mathcal{E}(\lambda_s \rightarrow \lambda_t) \mathbf{x}_{\lambda_s} + \int_{\lambda_s}^{\lambda_t} \mathbf{E}(\lambda_s \rightarrow \lambda) \mathbf{B}(\lambda_s \rightarrow \lambda) d\lambda \\ &\quad + \sum_{k=0}^n \mathbf{N}_{\phi^\times}^{\text{new},(k)}(\mathbf{x}_{\lambda_s}, \lambda_s) \int_{\lambda_s}^{\lambda_t} \mathbf{E}(\lambda_s \rightarrow \lambda) \frac{(\lambda - \lambda_s)^k}{k!} d\lambda. \end{aligned} \tag{9.7.13}$$

与节 9.4.3 中高阶 DPM 的推导类似，对于 $(n+1)$ 阶近似，我们利用前 $n+1$ 步 $\lambda_{i_n}, \dots, \lambda_{i_1}, \lambda_{i_0} := \lambda_s$ 处 $\mathbf{N}_{\phi^\times}^{\text{new},(k)}(\mathbf{x}_\lambda, \lambda)$ 的有限差分，估计每个 $\mathbf{N}_{\phi^\times}^{\text{new},(k)}(\mathbf{x}_{\lambda_s}, \lambda_s)$ 。这一方法旨在匹配 Taylor 展开的系数。

下文用 $n=2$ 的例子演示：

例：估计高阶导数 ($n=2$ 情形)。

当 $n=2$ 时，我们希望用先前 3 个时间步 $\lambda_{i_2}, \lambda_{i_1}, \lambda_s$ 来估计 $k=1, 2$ 的导数 $\mathbf{N}_{\phi^\times}^{\text{new},(k)}(\mathbf{x}_\lambda, \lambda)$ 。

近似导数的线性方程组. 令 $\delta_k = \lambda_{i_k} - \lambda_s$ ($k=1, 2$)。在 λ_s 附近对 $\mathbf{N}_{\phi^\times}^{\text{new}}(\mathbf{x}_\lambda, \lambda)$ 作

Taylor 展开. 在 $\lambda = \lambda_{i_1}$ 和 $\lambda = \lambda_{i_2}$ 处求值, 并重排以分离导数项, 得到:

$$\begin{aligned} \mathbf{N}_{\phi^\times}^{\text{new}}(\mathbf{x}_{\lambda_{i_1}}, \lambda_{i_1}) - \mathbf{N}_{\phi^\times}^{\text{new}}(\mathbf{x}_{\lambda_s}, \lambda_s) \\ \approx \delta_1 \mathbf{N}_{\phi^\times}^{\text{new},(1)}(\mathbf{x}_{\lambda_s}, \lambda_s) + \frac{\delta_1^2}{2!} \mathbf{N}_{\phi^\times}^{\text{new},(2)}(\mathbf{x}_{\lambda_s}, \lambda_s), \\ \mathbf{N}_{\phi^\times}^{\text{new}}(\mathbf{x}_{\lambda_{i_2}}, \lambda_{i_2}) - \mathbf{N}_{\phi^\times}^{\text{new}}(\mathbf{x}_{\lambda_s}, \lambda_s) \\ \approx \delta_2 \mathbf{N}_{\phi^\times}^{\text{new},(1)}(\mathbf{x}_{\lambda_s}, \lambda_s) + \frac{\delta_2^2}{2!} \mathbf{N}_{\phi^\times}^{\text{new},(2)}(\mathbf{x}_{\lambda_s}, \lambda_s). \end{aligned}$$

这里分别略去高阶项 $\mathcal{O}(\delta_1^3)$ 和 $\mathcal{O}(\delta_2^3)$. 这形成线性方程组:

$$\begin{bmatrix} \delta_1 & \delta_1^2 \\ \delta_2 & \delta_2^2 \end{bmatrix} \begin{bmatrix} \frac{\tilde{\mathbf{N}}_{\phi^\times}^{\text{new},(1)}(\mathbf{x}_{\lambda_s}, \lambda_s)}{1!} \\ \frac{\tilde{\mathbf{N}}_{\phi^\times}^{\text{new},(2)}(\mathbf{x}_{\lambda_s}, \lambda_s)}{2!} \end{bmatrix} = \begin{bmatrix} \mathbf{N}_{\phi^\times}^{\text{new}}(\mathbf{x}_{\lambda_{i_1}}, \lambda_{i_1}) - \mathbf{N}_{\phi^\times}^{\text{new}}(\mathbf{x}_{\lambda_s}, \lambda_s) \\ \mathbf{N}_{\phi^\times}^{\text{new}}(\mathbf{x}_{\lambda_{i_2}}, \lambda_{i_2}) - \mathbf{N}_{\phi^\times}^{\text{new}}(\mathbf{x}_{\lambda_s}, \lambda_s) \end{bmatrix}$$

其中待求量为近似导数 $\tilde{\mathbf{N}}_{\phi^\times}^{\text{new},(k)}(\mathbf{x}_{\lambda_s}, \lambda_s)$; 因此,

$$\tilde{\mathbf{N}}_{\phi^\times}^{\text{new},(k)}(\mathbf{x}_{\lambda_s}, \lambda_s) \approx \mathbf{N}_{\phi^\times}^{\text{new},(k)}(\mathbf{x}_{\lambda_s}, \lambda_s).$$

求解近似导数 $\tilde{\mathbf{N}}_{\phi^\times}^{\text{new},(k)}$. 令:

$$\mathbf{R}_2 = \begin{bmatrix} \delta_1 & \delta_1^2 \\ \delta_2 & \delta_2^2 \end{bmatrix}, \quad \mathbf{b} = \begin{bmatrix} \mathbf{N}_{\phi^\times}^{\text{new}}(\mathbf{x}_{\lambda_{i_1}}, \lambda_{i_1}) - \mathbf{N}_{\phi^\times}^{\text{new}}(\mathbf{x}_{\lambda_s}, \lambda_s) \\ \mathbf{N}_{\phi^\times}^{\text{new}}(\mathbf{x}_{\lambda_{i_2}}, \lambda_{i_2}) - \mathbf{N}_{\phi^\times}^{\text{new}}(\mathbf{x}_{\lambda_s}, \lambda_s) \end{bmatrix}.$$

近似导数为:

$$\begin{bmatrix} \frac{\tilde{\mathbf{N}}_{\phi^\times}^{\text{new},(1)}(\mathbf{x}_{\lambda_s}, \lambda_s)}{1!} \\ \frac{\tilde{\mathbf{N}}_{\phi^\times}^{\text{new},(2)}(\mathbf{x}_{\lambda_s}, \lambda_s)}{2!} \end{bmatrix} = \mathbf{R}_2^{-1} \mathbf{b},$$

它可以显式计算.

沿用这一说明性例子的思想, 可容易地推广至一般 n 下 $k \leq n$ 的 k 阶导数情形:

$$\underbrace{\begin{bmatrix} \delta_1 & \delta_1^2 & \cdots & \delta_1^n \\ \delta_2 & \delta_2^2 & \cdots & \delta_2^n \\ \vdots & \vdots & \ddots & \vdots \\ \delta_n & \delta_n^2 & \cdots & \delta_n^n \end{bmatrix}}_{\mathbf{R}_n} \begin{bmatrix} \frac{\tilde{\mathbf{N}}_{\phi^\times}^{\text{new},(1)}(\mathbf{x}_{\lambda_s}, \lambda_s)}{1!} \\ \frac{\tilde{\mathbf{N}}_{\phi^\times}^{\text{new},(2)}(\mathbf{x}_{\lambda_s}, \lambda_s)}{2!} \\ \vdots \\ \frac{\tilde{\mathbf{N}}_{\phi^\times}^{\text{new},(n)}(\mathbf{x}_{\lambda_s}, \lambda_s)}{n!} \end{bmatrix} = \begin{bmatrix} \mathbf{N}_{\phi^\times}^{\text{new}}(\mathbf{x}_{\lambda_{i_1}}, \lambda_{i_1}) - \mathbf{N}_{\phi^\times}^{\text{new}}(\mathbf{x}_{\lambda_s}, \lambda_s) \\ \mathbf{N}_{\phi^\times}^{\text{new}}(\mathbf{x}_{\lambda_{i_2}}, \lambda_{i_2}) - \mathbf{N}_{\phi^\times}^{\text{new}}(\mathbf{x}_{\lambda_s}, \lambda_s) \\ \vdots \\ \mathbf{N}_{\phi^\times}^{\text{new}}(\mathbf{x}_{\lambda_{i_n}}, \lambda_{i_n}) - \mathbf{N}_{\phi^\times}^{\text{new}}(\mathbf{x}_{\lambda_s}, \lambda_s) \end{bmatrix}. \quad (9.7.14)$$

通过求逆 Vandermonde 矩阵 $\mathbf{R}_n$, 可解析求解 $k \leq n$ 的近似导数 $\tilde{\mathbf{N}}_{\phi^\times}^{\text{new},(k)}(\mathbf{x}_{\lambda_s}, \lambda_s)$. 因此, 在式 (9.7.13) 中, 以 $\tilde{\mathbf{N}}_{\phi^\times}^{\text{new},(k)}(\mathbf{x}_{\lambda_s}, \lambda_s)$ 替换 $\mathbf{N}_{\phi^\times}^{\text{new},(k)}(\mathbf{x}_{\lambda_s}, \lambda_s)$, 就得到一个近似解, 仍记作 $\tilde{\mathbf{x}}_{\lambda_t}$:

$$\begin{aligned}\tilde{\mathbf{x}}_{\lambda_t} &= \mathcal{E}(\lambda_s \rightarrow \lambda_t) \mathbf{x}_{\lambda_s} + \int_{\lambda_s}^{\lambda_t} \mathbf{E}(\lambda_s \rightarrow \lambda) \mathbf{B}(\lambda_s \rightarrow \lambda) d\lambda \\ &\quad + \sum_{k=0}^n \tilde{\mathbf{N}}_{\phi^\times}^{\text{new},(k)}(\mathbf{x}_{\lambda_s}, \lambda_s) \int_{\lambda_s}^{\lambda_t} \mathbf{E}(\lambda_s \rightarrow \lambda) \frac{(\lambda - \lambda_s)^k}{k!} d\lambda.\end{aligned}\quad (9.7.15)$$

9.7.5 DPM-Solver-v3 的进一步解释

最小化一阶离散化误差可以帮助高阶求解器. $\mathbf{a}_\lambda^*$ 和 $\mathbf{b}_\lambda^*$ 是通过减少一阶离散化误差推导的; 然而, 理论上它们也能帮助控制高阶求解器的误差. 以下命题概括这一结果.

命题 9.7.1: 减少一阶离散化误差有助于高阶求解器

从同一初始条件 $\mathbf{x}_{\lambda_s}$ 出发, 令近似解 $\tilde{\mathbf{x}}_{\lambda_t}$ 按式 (9.7.15) 定义, 精确解 $\tilde{\Psi}_{\lambda_s \rightarrow \lambda_t}(\mathbf{x}_{\lambda_s})$ 按式 (9.7.11) 定义. 则离散化误差为:

$$\begin{aligned}\tilde{\mathbf{x}}_{\lambda_t} - \tilde{\Psi}_{\lambda_s \rightarrow \lambda_t}(\mathbf{x}_{\lambda_s}) &= \int_{\lambda_s}^{\lambda_t} \left(\int_{\lambda_s}^{\lambda} \mathbf{N}_{\phi^\times}^{\text{new},(1)}(\mathbf{x}_u, u) du \right) \mathbf{E}(\lambda_s \rightarrow \lambda) d\lambda \\ &\quad + \sum_{k=1}^n \left(\sum_{j=1}^n (\mathbf{R}_n^{-1})_{kj} \int_{\lambda_s}^{\lambda_{i_j}} \mathbf{N}_{\phi^\times}^{\text{new},(1)}(\mathbf{x}_\lambda, \lambda) d\lambda \right) \\ &\quad \cdot \int_{\lambda_s}^{\lambda_t} \mathbf{E}(\lambda_s \rightarrow \lambda) \frac{(\lambda - \lambda_s)^k}{k!} d\lambda.\end{aligned}$$

命题的证明.

$\tilde{\Psi}_{\lambda_s \rightarrow \lambda_t}(\mathbf{x}_{\lambda_s})$ 可重写为如下表达:

$$\begin{aligned}\tilde{\Psi}_{\lambda_s \rightarrow \lambda_t}(\mathbf{x}_{\lambda_s}) &= \mathcal{E}(\lambda_s \rightarrow \lambda_t) \mathbf{x}_{\lambda_s} + \int_{\lambda_s}^{\lambda_t} \mathbf{E}(\lambda_s \rightarrow \lambda) \mathbf{B}(\lambda_s \rightarrow \lambda) d\lambda \\ &\quad + \int_{\lambda_s}^{\lambda_t} \mathbf{N}_{\phi^\times}^{\text{new}}(\mathbf{x}_\lambda, \lambda) \mathbf{E}(\lambda_s \rightarrow \lambda) d\lambda.\end{aligned}$$

从式 (9.7.15) 中减去 $\tilde{\Psi}_{\lambda_s \rightarrow \lambda_t}(\mathbf{x}_{\lambda_s})$:

$$\begin{aligned}\tilde{\mathbf{x}}_{\lambda_t} - \tilde{\Psi}_{\lambda_s \rightarrow \lambda_t}(\mathbf{x}_{\lambda_s}) &= \int_{\lambda_s}^{\lambda_t} \left(\mathbf{N}_{\phi^\times}^{\text{new}}(\mathbf{x}_\lambda, \lambda) - \mathbf{N}_{\phi^\times}^{\text{new}}(\mathbf{x}_{\lambda_s}, \lambda_s) \right) \mathbf{E}(\lambda_s \rightarrow \lambda) d\lambda \\ &\quad + \sum_{k=1}^n \tilde{\mathbf{N}}_{\phi^\times}^{\text{new},(k)}(\mathbf{x}_{\lambda_s}, \lambda_s) \int_{\lambda_s}^{\lambda_t} \mathbf{E}(\lambda_s \rightarrow \lambda) \frac{(\lambda - \lambda_s)^k}{k!} d\lambda.\end{aligned}$$

对式 (9.7.14) 中的矩阵 $\mathbf{R}_n$ 求逆, 对任意 $k = 1, \dots, n$, 解为:

$$\tilde{\mathbf{N}}_{\phi^\times}^{\text{new},(k)}(\mathbf{x}_{\lambda_s}, \lambda_s) = \sum_{j=1}^n (\mathbf{R}_n^{-1})_{kj} \left(\mathbf{N}_{\phi^\times}^{\text{new}}(\mathbf{x}_{\lambda_{i_j}}, \lambda_{i_j}) - \mathbf{N}_{\phi^\times}^{\text{new}}(\mathbf{x}_{\lambda_s}, \lambda_s) \right).$$

应用微积分基本定理得到结果，即

$$\begin{aligned}\mathbf{N}_{\phi^\times}^{\text{new}}(\mathbf{x}_\lambda, \lambda) - \mathbf{N}_{\phi^\times}^{\text{new}}(\mathbf{x}_{\lambda_s}, \lambda_s) &= \int_{\lambda_s}^{\lambda} \mathbf{N}_{\phi^\times}^{\text{new},(1)}(\mathbf{x}_u, u) \, du \\ \mathbf{N}_{\phi^\times}^{\text{new}}(\mathbf{x}_{\lambda_{i_j}}, \lambda_{i_j}) - \mathbf{N}_{\phi^\times}^{\text{new}}(\mathbf{x}_{\lambda_s}, \lambda_s) &= \int_{\lambda_s}^{\lambda_{i_j}} \mathbf{N}_{\phi^\times}^{\text{new},(1)}(\mathbf{x}_\lambda, \lambda) \, d\lambda.\end{aligned}$$

根据上述命题和式 (9.7.10)，在充分光滑的假设下，控制 $\|\mathbf{N}_{\phi^\times}^{\text{new},(1)}\|_2$ 会减少 $\|\tilde{\mathbf{x}}_{\lambda_t} - \tilde{\Psi}_{\lambda_s \rightarrow \lambda_t}(\mathbf{x}_{\lambda_s})\|_2$ 。

推广参数化 $\mathbf{N}_{\phi^\times}^{\text{new}}$ 的表达能力。 利用式 (9.7.2) 和式 (9.7.9)，可以将 $\mathbf{N}_{\phi^\times}^{\text{new}}$ 重写为如下形式：

$$\begin{aligned}\mathbf{N}_{\phi^\times}^{\text{new}}(\mathbf{x}_\lambda, \lambda) &= \sigma_\lambda e^{-\int_{\lambda_s}^{\lambda} \mathbf{a}_u \, du} \hat{\epsilon}_{\phi^\times}(\mathbf{x}_\lambda, \lambda) - \ell_\lambda e^{-\int_{\lambda_s}^{\lambda} \mathbf{a}_u \, du} \mathbf{x}_\lambda \\ &\quad - \int_{\lambda_s}^{\lambda} e^{-\int_{\lambda_s}^r \mathbf{a}_u \, du} \mathbf{b}_r \, dr,\end{aligned}\tag{9.7.16}$$

从概念上具有如下形式：

$$\mathbf{T}_{\phi^\times}(\mathbf{x}_\lambda, \lambda) := \alpha(\lambda) \hat{\epsilon}_{\phi^\times}(\mathbf{x}_\lambda, \lambda) + \beta(\lambda) \mathbf{x}_\lambda + \gamma(\lambda).\tag{9.7.17}$$

事实上，对于固定 λ ， $\Psi_{\phi^\times}(\mathbf{x}_\lambda, \lambda)$ 可通过依赖于 λ_s 的线性变换，用 $\mathbf{N}_{\phi^\times}^{\text{new}}(\mathbf{x}_\lambda, \lambda)$ 表达（详见 (Zheng et al., 2023) 的附录 I.1）。

9.7.6 DPM-Solver-v3 与其他方法的联系


DPM-Solver-v3 的 $\mathbf{N}_{\phi^\times}^{\text{new}}$ 是一般参数化。 比较 DPM-Solver-v3 与先前 ODE 表述及其相应 ϵ / $\mathbf{x}$ 预测，可以容易地发现：将 ℓ_λ 、 $\mathbf{a}_\lambda$ 和 $\mathbf{b}_\lambda$ 设为特定值，它们就是本方法的特殊情形：

- ϵ 预测： $(\ell_\lambda, \mathbf{a}_\lambda, \mathbf{b}_\lambda) = (\mathbf{0}_D, -\mathbf{1}_D, \mathbf{0}_D)$
- $\mathbf{x}$ 预测： $(\ell_\lambda, \mathbf{a}_\lambda, \mathbf{b}_\lambda) = (\mathbf{1}_D, \mathbf{0}_D, \mathbf{0}_D)$

作为改进 DDIM 的一阶离散化。 由于 $\mathbf{N}_{\phi^\times}^{\text{new}}$ 表示旨在最小化一阶离散化误差的改进参数化，而非噪声或数据参数化，式 (9.7.12) 中的一阶 DPM-Solver-v3 更新不同于式 (9.2.2) 中的 DDIM 更新：

$$\mathbf{x}_{t_{i-1} \rightarrow t_i} = \frac{\alpha_{t_i}}{\alpha_{t_{i-1}}} \tilde{\mathbf{x}}_{t_{i-1}} - \alpha_{t_i} \left(\frac{\sigma_{t_{i-1}}}{\alpha_{t_{i-1}}} - \frac{\sigma_{t_i}}{\alpha_{t_i}} \right) \epsilon_{\phi^\times}(\tilde{\mathbf{x}}_{t_{i-1}}, t_{i-1}).$$

9.8 (选读) ParaDiGMs



(a) 生成过程中通过时间步进估计进行顺序采样.

(b) 具有跳跃依赖的 Picard 迭代.

图 9.4: **两种计算图的比较**. 左: 常规的时间步进 ODE 求解, 解按时间顺序传播. 右: Picard 迭代利用上一次迭代的结果同时更新所有时间节点, 实现并行计算, 从而避免时间步进的严格顺序性.

9.8.1 从时间步进到时间并行求解器

前面各节着重讨论时间步进方法: 从先验时间 T 向任意 $t \in [0, T]$ 演化以估计轨迹. 令

$$\mathbf{v}_{\phi^\times}(\mathbf{x}, t) := \mathbf{f}(\mathbf{x}, t) - \frac{1}{2}g^2(t)\mathbf{s}_{\phi^\times}(\mathbf{x}, t)$$

表示预训练扩散模型的经验 PF-ODE 漂移. 从 T 到任意中间时间 t 的精确演化为

$$\tilde{\Psi}_{T \rightarrow t}(\mathbf{x}(T)) = \mathbf{x}(T) + \int_T^t \mathbf{v}_{\phi^\times}(\mathbf{x}(\tau), \tau) d\tau, \quad \mathbf{x}(T) \sim p_{\text{prior}}. \quad (9.8.1)$$

时间步进方案利用基于此前时间步的离散更新近似此积分.

本节转向以 *ParaDiGMS* 为代表的时间并行方法, 它基于经典 Picard 迭代实现跨时间的并行积分. *ParaDiGMS* 的核心思想是用计算资源换取更快的模拟.

9.8.2 ParaDiGMS 的方法

从轨迹到作为不动点更新的 Picard 迭代. 式 (9.8.1) 的积分表达式可理解为输入一条完整轨迹、输出另一条轨迹的映射. 形式上, 给定任意候选轨迹 $\{\mathbf{y}(\tau)\}_{\tau \in [0, T]}$, 定义算子 $\mathcal{L}$ 为

$$(\mathcal{L}[\mathbf{y}(\cdot)])(t) = \mathbf{y}(T) + \int_T^t \mathbf{v}_{\phi^\times}(\mathbf{y}(\tau), \tau) d\tau, \quad t \in [0, T].$$

即 $\mathcal{L}$ 取终点 $\mathbf{y}(T)$, 沿路径对指定速度场 $\mathbf{v}_{\phi^\times}$ 积分, 将该终点沿时间反向延伸.

PF-ODE 的真实解轨迹 $\mathbf{x}^*(\cdot)$ 恰是在此映射下保持不变的轨迹. 换言之, $\mathbf{x}^*(\cdot)$ 是 $\mathcal{L}$ 的不动点:

$$\mathbf{x}^*(t) = \mathcal{L}[\mathbf{x}^*(\cdot)](t) \iff \mathbf{x}^*(t) = \mathbf{x}^*(T) + \int_T^t \mathbf{v}_{\phi^\times}(\mathbf{x}^*(\tau), \tau) d\tau.$$

这一改写把问题从逐步求解 ODE 转化为寻找与算子 $\mathcal{L}$ 一致的轨迹.

基于上述算子视角,一旦有了轨迹到轨迹的映射 $\mathcal{L}$, 寻找其不动点的一种自然方法便是逐次代入 (Picard 迭代): 反复应用 $\mathcal{L}$, 每次都用上一次迭代的轨迹计算积分. 更精确地, 从任意初始路径 $\mathbf{x}^{(0)}(\cdot)$ 出发 (实践中为常值路径 $\mathbf{x}^{(0)}(t) \equiv \mathbf{x}^{(0)}(T)$, 其中固定的 $\mathbf{x}^{(0)}(T) \sim p_{\text{prior}}$), 更新为

$$\begin{aligned}\mathbf{x}^{(k+1)}(t) &:= \mathcal{L}^{(k)}[\mathbf{x}^{(0)}(\cdot)](t) \\ &= \mathbf{x}^{(k)}(T) + \int_T^t \mathbf{v}_{\phi \times}(\mathbf{x}^{(k)}(\tau), \tau) d\tau, \quad k = 0, 1, 2, \dots\end{aligned}\tag{9.8.2}$$

此式保持正确的时间 T 锚定: 迭代始终从先验采样状态 $\mathbf{x}^{(k)}(T)$ 出发, 随时间从 T 减小至 t 累积漂移.

从 T 到 0 网格上的离散 Picard 迭代. 为将式 (9.8.2) 转化为实际算法, 在 $[0, T]$ 上设置均匀递减网格: 选择步数 N , 设 $\Delta t := T/M$, 定义

$$t_j := T - j\Delta t, \quad j = 0, 1, \dots, M,$$

于是 $t_0 = T$ 、 $t_M = 0$. 将采样的迭代值记为

$$\mathbf{x}_j^{(k)} := \mathbf{x}^{(k)}(t_j).$$

由于网格按时间反向排列, 从 T 到 t_j 的积分取负方向. 在分割 $\{[t_{i+1}, t_i]\}_{i=0}^{j-1}$ 上用左端点近似, 得到

$$\int_T^{t_j} \mathbf{v}_{\phi \times}(\mathbf{x}^{(k)}(\tau), \tau) d\tau \approx -\Delta t \sum_{i=0}^{j-1} \mathbf{v}_{\phi \times}(\mathbf{x}_{t_i}^{(k)}, t_i),$$

因为 $[t_{i+1}, t_i]$ 上的每个小积分等于 $-\int_{t_i}^{t_{i+1}} \cdot d\tau$. 将此近似代入式 (9.8.2), 得到离散 Picard 更新

$$\mathbf{x}_j^{(k+1)} = \mathbf{x}_0^{(k)} - \underbrace{\Delta t \sum_{i=0}^{j-1} \mathbf{v}_{\phi \times}(\mathbf{x}_i^{(k)}, t_i)}_{\text{漂移的累积和}}, \quad j = 1, \dots, M.\tag{9.8.3}$$

此方案简单且适于并行: 每次漂移计算 $\mathbf{v}_{\phi \times}(\mathbf{x}_i^{(k)}, t_i)$ 只依赖同一时间节点 t_i 上的前一次迭代, 因此所有 $i = 0, \dots, j-1$ 的计算都可在网格上独立进行. 随后通过累积和恢复积分, 可以顺序计算, 也可用并行前缀和 (扫描 / 滑动窗口) 计算.

滑动窗口与并行计算. 离散 Picard 更新式 (9.8.3) 把每个 $\mathbf{x}_j^{(k+1)}$ 表示为左端锚定值 $\mathbf{x}_0^{(k)}$ 减去漂移的累积和. 为限制内存并利用并行硬件, 在较短的滑动索引块上局部应用同一思想很方便.

固定窗口长度 p 与左索引 ℓ ; 窗口覆盖 $j = \ell, \dots, \ell + p$, 且 $t_\ell > t_{\ell+1} > \dots > t_{\ell+p}$. 在第 k 次迭代中:




图 9.5: 在大小 $p = 4$ 的批处理窗口中, 并行计算 $\mathbf{x}_{\ell:\ell+p}^{(k)}$ 的漂移.




图 9.6: 利用窗口内各点的累积漂移, 将值更新为 $\mathbf{x}_{\ell:\ell+p}^{(k+1)}$.




图 9.7: 根据误差 $\|\mathbf{x}_i^{(k+1)} - \mathbf{x}_i^{(k)}\|^2$, 确定窗口向前滑动的距离.

步骤 1: 在窗口上并行计算漂移. 仅利用前一次迭代并行计算

$$\mathbf{v}_{\phi \times}(\mathbf{x}_{\ell+i}^{(k)}, t_{\ell+i}), \quad i = 0, 1, \dots, p-1.$$

这些是从左边缘 t_ℓ 推进至整个窗口所需的 p 个局部增量.

步骤 2: 左端锚定的累积更新. 在 $j = \ell$ 处锚定, 并跨子区间累积漂移, 形成窗口更新:

$$\mathbf{x}_{\ell+j+1}^{(k+1)} = \mathbf{x}_\ell^{(k)} - \Delta t \sum_{i=0}^j \mathbf{v}_{\phi \times}(\mathbf{x}_{\ell+i}^{(k)}, t_{\ell+i}), \quad j = 0, 1, \dots, p-1. \quad (9.8.4)$$

这恰是式 (9.8.3) 在窗口上的限制, 其中负号反映时间递减方向. 内部求和是窗口内漂移的前缀和 (扫描), 因此所有部分和都可在并行硬件上高效生成.

步骤 3: 进度控制与窗口推进. 在当前窗口上形成左端锚定的累积更新 (步骤 2) 后, 决定窗口应滑动多远. 用逐点 Picard 变化衡量局部收敛:

$$\text{error}_j := \|\mathbf{x}_{\ell+j}^{(k+1)} - \mathbf{x}_{\ell+j}^{(k)}\|^2, \quad j = 1, \dots, p-1,$$

并与预设容差 $\text{tol}_{\ell+j}$ 比较. 即 error_j 衡量最近一次 Picard 更新中节点 $\ell+j$ 的迭代值改变了多少. 数值较小表明相邻两次近似在局部一致, 从而表示该节点的不动点迭代局部收敛. 数值较大则表示该节点尚未稳定, 需要更多 Picard 平滑.

将步幅选为窗口内第一个未通过检验的索引 (若全部通过, 则为完整窗口长度 p):

$$\text{stride} := \min \left(\{j \geq 1 : \text{error}_j > \text{tol}_{\ell+j}\} \cup \{p\} \right).$$

随后设置 $\ell \leftarrow \ell + \text{stride}$, 使窗口滑动. 换言之, 接受从左边缘到第一个尚未收敛的节点之前的所有节点; 若所有节点均收敛, 则接受整个窗口. 再按接受的节点数滑动窗口, 即 $\ell \leftarrow \ell + \text{stride}$, 继续迭代. 每次最多推进窗口长度 p , 绝不跳过任何尚未满足容差的节点. 若滑动会超出网格终点 M , 则将窗口截断为 $p \leftarrow \min\{p, M - \ell\}$, 然后继续.

窗口向前移动时, 会暴露尚无取值的新时间节点. 为在这些节点开始 Picard 迭代, 只需复制窗口左边界值作为初始猜测. 这种“常值外推”成本低且稳定, 后续更新会修正它. 如有需要, 也可用更准确的猜测替代, 例如根据此前各点作线性或多项式外推.

至此完成 ParaDiGMS 的流程. 算法 8 总结此算法.

算法 8 采用滑动窗口的 ParaDiGMS

输入： 漂移 $\mathbf{v}_{\phi^\times}(\mathbf{x}, t)$; $\{t_j\}_{j=0}^M$; 窗口长度 p ; $\{\text{tol}_j\}_{j=1}^M$

输出： 近似轨迹 $\{\mathbf{x}_j^{(k)}\}_{j=0}^M$, 其中 $\mathbf{x}_M^{(k)}$ 位于 $t = 0$

1: $k \leftarrow 0, \ell \leftarrow 0$

2: 采样 $\mathbf{x}_0^{(0)} \sim p_{\text{prior}}$; 对 $j = 1, \dots, \min(p, M)$, 设 $\mathbf{x}_j^{(0)} \leftarrow \mathbf{x}_0^{(0)}$

▷ 常值外推

3: **当** $\ell < M$ **执行**

4: $J \leftarrow \min(p, M - \ell)$

▷ 当前窗口长度

5: **步骤 1：并行**

6: 对 $i = 0, \dots, J - 1$: $g_i \leftarrow \mathbf{v}_{\phi^\times}(\mathbf{x}_{\ell+i}^{(k)}, t_{\ell+i})$

▷ 前一次迭代的漂移 (Picard 冻结)

7: 对 $j = 0, \dots, J - 1$, 计算前缀和 $S_j \leftarrow \sum_{i=0}^j g_i$

▷ 对窗口内漂移作扫描

8: **步骤 2：累积更新**

9: 对 $j = 0, \dots, J - 1$: $\mathbf{x}_{\ell+j+1}^{(k+1)} \leftarrow \mathbf{x}_\ell^{(k)} - \Delta t S_j$

▷ 左端锚定更新; 参见式 (9.8.4)

10: **步骤 3：进度控制与窗口推进**

11: 对 $j = 1, \dots, J - 1$: $\text{error}_j \leftarrow \|\mathbf{x}_{\ell+j}^{(k+1)} - \mathbf{x}_{\ell+j}^{(k)}\|^2$

▷ 逐点 Picard 变化

12: $\text{stride} \leftarrow \min \left(\{j \in \{1, \dots, J - 1\} : \text{error}_j > \text{tol}_{\ell+j}\} \cup \{J\} \right)$

13: **初始化新节点**

14: 对 $r = 1, \dots, \text{stride}$: $\mathbf{x}_{\ell+J+r}^{(k+1)} \leftarrow \mathbf{x}_{\ell+J}^{(k+1)}$

▷ 向新暴露的索引作常值外推

15: $\ell \leftarrow \ell + \text{stride}; k \leftarrow k + 1$

16: **结束 当**

17: **返回** $\{\mathbf{x}_j^{(k)}\}_{j=0}^M$

9.8.3 与时间步进求解器的关系

滑动窗口大小的选择. 为理解滑动窗口方案, 先考察最小窗口大小的情形. 当 $p = 1$ 时, 窗口只含一个步骤, 因此式 (9.8.4) 退化为 PF-ODE 的一阶时间步进更新. 例如, 若采用与 DDIM 相同的 ODE 表述 (如数据预测或噪声预测), 并选择与 DDIM 相同的离散时间步调度, 此方法便退化为 DDIM.

增大 p 可扩展并行性 (每个窗口推进更多节点), 而不改变总步数 N . 因此, 样本质量仍取决于基础离散化 (网格 / 参数化选择与逐步公式), 以及每个窗口上的 Picard 收敛; 后者通过局部容差监控.

与高阶求解器 (如 DPM) 的兼容性. 滑动窗口 Picard 结构控制增量如何计算 (并行计算并通过扫描累积), 而非由哪种局部公式定义这些增量. 因此, 可用任意一致的高阶

求积替代左端点规则，而无需改变并行布局. 例如，式 (9.8.4) 的梯形变体为

$$\mathbf{x}_{\ell+j+1}^{(k+1)} = \mathbf{x}_{\ell}^{(k)} - \Delta t \left[\frac{1}{2} \mathbf{v}_{\phi \times}(\mathbf{x}_{\ell}^{(k)}, t_{\ell}) + \sum_{i=1}^{j-1} \mathbf{v}_{\phi \times}(\mathbf{x}_{\ell+i}^{(k)}, t_{\ell+i}) + \frac{1}{2} \mathbf{v}_{\phi \times}(\mathbf{x}_{\ell+j}^{(k)}, t_{\ell+j}) \right],$$

其中所有漂移仍取自前一次 Picard 迭代，因此各节点计算仍相互独立，内部求和仍为前缀和.

同样，可引入 DPM 求解器家族中的多步或指数积分器更新（例如对数 SNR 时间中的 DPM-Solver++ 2M）：将窗口内每个增量替换为此前模型计算的相应高阶线性组合（采用预先计算的系数，对 $\mathbf{x}$ 或 ϵ 预测进行组合）. 随后扫描与此前完全一样，在整个窗口中累积这些加权增量. 因而，并行方案独立于近似积分所选择的求解器（离散化）. 精度来自基础求解器，窗口化前缀和则使计算更快.

9.9 结束语

本章直面扩散模型最重要的实际局限之一：缓慢的迭代采样过程。我们研究了一类强大的无需训练的解决方法，利用丰富的微分方程数值方法加速生成。核心策略是更高效地求解 PF-ODE，它定义从噪声到数据的确定性生成轨迹：

1. 从基础 DDIM 开始，它可理解为一阶指数 Euler 方法。
2. 随后转向 DEIS 等高阶多步方法，通过利用此前计算的历史改善精度。
3. 最后考察高效的 DPM-Solver 家族，通过关键的对数 SNR 时间重参数化获得出色表现。

通过这些先进求解器，高质量生成所需的函数计算次数 (NFE) 从数百乃至数千次大幅减少到仅 10–20 次，使扩散模型显著更为实用。

然而，这些无需训练的方法本质上仍是迭代的，逐步近似连续路径。这引出一个自然且雄心勃勃的问题：能否仅用一步或极少几个离散步骤实现高质量生成？

本书最后的 D 部分将通过基于训练的加速探索这一问题。我们将研究两种主要策略：

1. 首先在章 10 研究基于蒸馏的方法，训练快速的学生生成器，用远少于预训练慢速教师扩散模型的步骤复现其输出。
2. 然后在章 11 进一步探索从头学习快速少步生成器的方法，例如一致性训练；它们给出独立的训练原则，不依赖任何预训练模型。

从改进求解器转向学习解映射本身，代表高效生成建模的前沿，旨在把扩散模型的质量与单步生成器的速度相结合。

第四部分

迈向快速扩散生成器的学习

第 10 章 基于蒸馏的快速采样方法

本章介绍基于训练的扩散模型采样加速方法：训练新的生成器，使其仅用一步或少数几步就能生成样本。其核心思想称为蒸馏（*distillation*），即让快速的学生模型向速度较慢的预训练扩散模型（教师）采样器学习。教师可能需要数百步，而学生只需少数几步就能达到相近的质量¹。基于求解器的加速通过改进数值积分方案实现，而蒸馏直接训练生成器，使其沿高效的捷径生成样本。我们着重介绍两种主要范式：分布层面的蒸馏不再模拟完整轨迹，而是将学生的输出分布与教师的输出分布对齐；流映射层面的蒸馏则训练学生，以更快、更紧凑的方式复现教师的采样路径。

¹这里的蒸馏指减少采样步数，而非缩小模型规模。

10.1 引言

扩散模型的一个主要瓶颈是采样速度慢.

由 Tweedie 公式 (节 6.3.1) 可知, 扩散模型可以解释为一个 “ $\mathbf{x}$ 预测” 模型 $\mathbf{x}_{\phi^\times}(\mathbf{x}_t, t)$, 训练目标是从噪声水平 t 下的含噪输入 $\mathbf{x}_t$ 中恢复干净数据的条件期望:

$$\mathbf{x}_{\phi^\times}(\mathbf{x}_t, t) \approx \mathbb{E}[\mathbf{x}_0 | \mathbf{x}_t],$$

其中, 期望关于 $p(\mathbf{x}_0 | \mathbf{x}_t)$ 计算, 该分布描述与 $\mathbf{x}_t$ 对应的所有可能的干净数据. 一个自然的想法是使用 $\mathbf{x}_{\phi^\times}(\mathbf{x}_t, t)$ 进行一步生成. 然而, 这个去噪器对许多可能的结果取平均, 因而预测会过度平滑, 只用少数几步去噪生成的样本往往模糊且质量较低.

另一方面, 如节 4.2.2 所述, 扩散采样通过一长串迭代步骤沿常微分方程或随机微分方程的轨迹演化. 这样可以生成高保真样本, 但所需步数众多, 使这一过程本身较慢. 减少 NFE (即采样步数乘以模型调用次数) 可以加快生成, 却不可避免地降低保真度. 求解器的每一步都会引入 $\mathcal{O}(h^n)$ 阶的积分误差, 其中 n 是求解器阶数, $h = \max_i |t_i - t_{i-1}|$ 是步长. 步数越少, 时间增量 h 越大, 进而使累积采样误差增大, 得到的轨迹也越不准确. 这使扩散采样的质量与效率之间存在根本性的权衡.

为克服这一瓶颈, 一条主要研究路线是蒸馏: 假设已有训练充分的扩散模型 (教师), 再训练一个生成器 (学生), 使其通过一次前馈计算或少数几步计算复现教师的行为. 这将教师的众多采样步骤压缩成一个快速过程, 在保持较高样本保真度的同时, 有效绕过缓慢的迭代求解器.

下面从两个角度介绍蒸馏: 分布层面的蒸馏与流映射层面的蒸馏².

10.1.1 分布层面的蒸馏

基于分布的蒸馏旨在训练一步生成器 $\mathbf{G}_\theta(\mathbf{z})$, 将噪声 $\mathbf{z} \sim p_{\text{prior}}$ 映射为样本 $\hat{\mathbf{x}} = \mathbf{G}_\theta(\mathbf{z})$, 使其诱导的分布 $p_\theta(\hat{\mathbf{x}})$ 逼近目标数据分布 $p_{\text{data}}(\mathbf{x})$. 通常通过最小化某个统计散度来实现这一目标:

$$\min_{\theta} \mathcal{D}(p_\theta(\hat{\mathbf{x}}), p_{\text{data}}(\mathbf{x})),$$

其中, $\mathcal{D}$ 表示适当的散度度量, 例如 KL 散度.

实践中, 基于分布的方法将生成器分布与预训练扩散模型产生的经验分布 $p_{\phi^\times}(\mathbf{x})$ 对齐:

$$\min_{\theta} \mathcal{D}(p_\theta(\hat{\mathbf{x}}), p_{\phi^\times}(\mathbf{x})),$$

其中, $p_{\phi^\times}$ 作为 p_{data} 的替代. 这些方法并不显式计算该散度, 而是近似计算其梯度; 梯度可直接由预训练教师模型得到. 因此, 学生无需完整计算散度, 就能将自身分布与教师分布对齐.

²从时间顺序看, 以知识蒸馏 (KD) (Luhman and Luhman, 2021) 和渐进蒸馏 (progressive distillation) (PD) (Ho, Jain, and Abbeel, 2020) 为代表的流映射层面蒸馏早在 2021 年便已提出, 早于 2023 年前后出现的一系列分布层面蒸馏方法. 不过, 为使叙述更加顺畅, 并与下一章衔接, 我们先介绍分布层面的蒸馏.

这一表述通过分布对齐，将扩散模型的多步生成过程蒸馏为一步模型。我们在节 10.2 中详细介绍这种方法。

10.1.2 流映射层面的蒸馏

考虑概率流常微分方程 (PF-ODE)，它可用任意预测模型表示 (见式 (6.3.1))：

$$\frac{d\mathbf{x}(\tau)}{d\tau} = f(\tau)\mathbf{x}(\tau) - \frac{1}{2}g^2(\tau)\nabla_{\mathbf{x}}\log p_{\tau}(\mathbf{x}(\tau)) =: \mathbf{v}^*(\mathbf{x}(\tau), \tau). \quad (10.1.1)$$

其解映射从时刻 s 的 $\mathbf{x}_s$ 出发，反向演化至时刻 $t \leq s$ ，记为 $\Psi_{s \rightarrow t}(\mathbf{x}_s)$ ；即

$$\Psi_{s \rightarrow t}(\mathbf{x}_s) := \mathbf{x}_s + \int_s^t \mathbf{v}^*(\mathbf{x}(\tau), \tau) d\tau, \quad (10.1.2)$$

其中，积分用于求解 PF-ODE。直观地说， $\Psi_{s \rightarrow t}$ 将时刻 s 的噪声 $\mathbf{x}_s$ 输运到时刻 t 噪声更少的状态（最终成为 $t = 0$ 时的数据）。

从扩散模型采样，等价于对 $\mathbf{x}_T \sim p_{\text{prior}}$ 计算 $\Psi_{T \rightarrow 0}(\mathbf{x}_T)$ 。通常借助速度场 $\mathbf{v}$ ，使用迭代数值求解器近似该积分（见章 9），但这需要很多步（例如，即便 DPM-Solver 也至少需要 10 步），使采样速度慢于 GAN 等经典的一步生成模型。由此产生了一个自然的问题：

问题 10.1.1. 能否直接学习解映射 $\Psi_{s \rightarrow t}(\mathbf{x}_s)$ ？

特别地，学习以 $\mathbf{x}_T \sim p_{\text{prior}}$ 为输入的映射 $\Psi_{T \rightarrow 0}(\mathbf{x}_T)$ ，就能实现一步生成。

轨迹蒸馏。 轨迹蒸馏旨在训练神经网络生成器，在实例层面逼近解映射。由于 PF-ODE 的积分很少具有闭式表达式，训练时必须进行数值近似。为形式化这一过程，我们引入通用的求解器记号：

$$\text{Solver}_{s \rightarrow t}(\mathbf{x}_s; \phi^\times) \text{ 或简记为 } \text{Solver}_{s \rightarrow t}(\mathbf{x}_s), \quad (10.1.3)$$

它表示从 $\mathbf{x}_s$ 出发，使用教师参数 $\phi^\times$ （上下文明确时省略），对经验 PF-ODE 从 s 到 t 作数值积分。

早期方法：直接知识蒸馏。 为实现少步乃至一步生成，一种直接方法是训练生成器 $\mathbf{G}_\theta(\mathbf{x}_T, T, 0)$ ，模仿数值求解器沿完整轨迹计算得到的输出：

$$\mathbf{G}_\theta(\mathbf{x}_T, T, 0) \approx \text{Solver}_{T \rightarrow 0}(\mathbf{x}_T), \quad \mathbf{x}_T \sim p_{\text{prior}}.$$

这一思想是最早的轨迹蒸馏方法之一——知识蒸馏 (Luhman and Luhman, 2021)——的基础，该方法采用如下回归损失：

$$\mathcal{L}_{\text{KD}}(\theta) := \mathbb{E}_{\mathbf{x}_T \sim p_{\text{prior}}} \|\mathbf{G}_\theta(\mathbf{x}_T, T, 0) - \text{Solver}_{T \rightarrow 0}(\mathbf{x}_T)\|_2^2.$$

这种方法虽然能获得预训练教师的直接监督，却无法利用原始训练数据中提供的强监督。此外，如果在训练循环内进行常微分方程积分，计算成本会很高，因为每次参数更新都需要求解常微分方程以构造目标。最后，由于生成器只学习从 T 到 0 的全局映射，它可能失去从中间状态引导生成过程的可控性。因此，章 8 中介绍的大多数可控生成技术无法直接应用。

渐进蒸馏概述. 渐进蒸馏 (PD) (Salimans and Ho, 2021) 使用 Teacher 轨迹片段提供的局部监督, 训练一个以时间为条件的 Student. 设 $t_0 = T > t_1 > \dots > t_N = 0$ 是固定的时间网格. Teacher 提供时间步进映射 $\text{Teacher}_{t_k \rightarrow t_{k+1}}$, 其中 $k = 0, \dots, N-1$.

PD 并非仅监督从 $T \rightarrow 0$ 的一次跳跃, 而是训练 Student 的两步跨越映射, 使其匹配 Teacher 连续两步的结果:

$$\text{Student}_{t_k \rightarrow t_{k+2}} \approx \text{Teacher}_{t_{k+1} \rightarrow t_{k+2}} \circ \text{Teacher}_{t_k \rightarrow t_{k+1}},$$

其中 $k = 0, 2, 4, \dots$. 匹配采用简单的回归损失 (例如均方误差).

在局部配对的片段上训练后, Student 不再沿原始网格的每个时间区间推进, 而是每隔一个时间点推进一次:

$$t_0 \rightarrow t_2 \rightarrow t_4 \rightarrow \dots \rightarrow t_N,$$

这意味着 Student 的每一步实际上覆盖 Teacher 连续的两步. 因此, Student 仅用 $N/2$ 次转移便能完成同一整体时间跨度 $[0, T]$.

这一阶段结束后, 训练好的 Student 替代 Teacher, 成为新的参考模型. 随后在更粗的网格上重复整个过程, 时间步长加倍, 步数依次变为 $(N \rightarrow N/2 \rightarrow N/4 \rightarrow \dots)$, 逐渐将轨迹蒸馏为越来越少的步骤, 直至达到所需的推断步数. 这种迭代减半的过程保持整体时间范围不变, 同时不断压缩生成过程的时间分辨率.

流映射学习的统一视角. 包括 KD 和 PD 在内的多种方法, 都可以表示在统一的损失框架中:

$$\mathcal{L}_{\text{oracle}}(\theta) := \mathbb{E}_{s,t} \mathbb{E}_{\mathbf{x}_s \sim p_s} [w(s,t) d(\mathbf{G}_\theta(\mathbf{x}_s, s, t), \Psi_{s \rightarrow t}(\mathbf{x}_s))], \quad (10.1.4)$$

其中, $\Psi_{s \rightarrow t}$ 是理想流映射, $w(s,t) \geq 0$ 指定不同时间对 (s,t) 的权重, $d(\cdot, \cdot)$ 是差异度量, 例如 $d(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\|_2^2$ 或 $d(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\|_1$, p_s 表示时刻 s 的前向加噪边缘分布. 由于无法获得 $\Psi_{s \rightarrow t}$ 的闭式表达式, 必须依赖近似, 通常使用预训练扩散模型 (教师) 或其他可处理的替代模型.

KD 是式 (10.1.4) 的一个简单特例. 取退化权重 $w(s,t) = \delta(s-T) \delta(t-0)$, 并使用先验分布 $p_T = p_{\text{prior}}$ ³, 理想损失 $\mathcal{L}_{\text{oracle}}(\theta)$ 简化为:

$$\mathbb{E}_{\mathbf{x}_T \sim p_T} \|\mathbf{G}_\theta(\mathbf{x}_T, T, 0) - \Psi_{T \rightarrow 0}(\mathbf{x}_T)\|_2^2 \approx \mathcal{L}_{\text{KD}}(\theta),$$

其中 $\text{Solver}_{T \rightarrow 0} \approx \Psi_{T \rightarrow 0}$. 节 D.5 给出了这一表述的另一种视角.

PD 也符合这一模板, 不过它不只用唯一的极端时间对 $(T, 0)$ 进行监督, 而是使用许多相邻时间对, 并施加一条简单的局部一致性规则: 一个短步之后再走一个短步, 应与直接跨越两步的移动一致. 我们将在式 (10.3.3) 中再次讨论这一点.

实践中的主要挑战是, 理想流映射 $\Psi_{s \rightarrow t}$ 通常没有闭式表达式, 因而无法直接提供监督. 已有多种方法用于高效近似这一目标, 但其效果往往取决于教师模型的质量. 在章 11 中, 我们将再次讨论式 (10.1.4), 给出从头训练方法的一个原则性框架, 使教师模型不再参与学习循环.

³当 T 足够大, 或采用适当的噪声调度 (α_t, σ_t) 时, 这一假设成立.

10.2 基于分布的蒸馏

多项工作以不同名称同时探索了这种基于分布的蒸馏，包括分布匹配蒸馏 (DMD) (Yin et al., 2024b; Yin et al., 2024a)、变分得分蒸馏 (variational score distillation) (VSD) (Poole et al., 2023; Wang et al., 2023; Luo et al., 2023; Lu and Song, 2024) 以及得分恒等式蒸馏 (SiD) (Zhou et al., 2024). 尽管技术细节有所不同，它们遵循同一原则：训练生成器，使其前向加噪边缘分布与教师的边缘分布匹配。由于其他方法遵循类似原则，我们以 VSD 为代表介绍这一表述。

10.2.1 以 VSD 为代表的方法表述

前向过程. 设 $\{p_t\}_{t \in [0, T]}$ 表示下列前向扩散过程诱导的边缘密度：

$$\mathbf{x}_t = \alpha_t \mathbf{x}_0 + \sigma_t \boldsymbol{\epsilon}, \quad \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}),$$

初始分布为 $p_0 = p_{\text{data}}$. 相应地，设 p_0^θ 表示确定性一步生成器 $\mathbf{G}_\theta(\mathbf{z})$ 从潜变量 $\mathbf{z} \sim p_{\text{prior}}(\mathbf{z})$ 生成的合成样本分布。定义 $\{p_t^\theta\}_{t \in [0, T]}$ 为将同一前向扩散过程作用于 p_0^θ 所得到的边缘密度，即

$$\mathbf{x}_t^\theta := \alpha_t \mathbf{G}_\theta(\mathbf{z}) + \sigma_t \boldsymbol{\epsilon}, \quad (10.2.1)$$

其中 $\mathbf{z} \sim p_{\text{prior}}$, $\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$. 因此， p_t 与 p_t^θ 具有相同的高斯扩散核 $p_t(\mathbf{x}_t | \mathbf{x}_0)$ ，但初始分布不同（分别为 p_{data} 和一步合成样本的分布 p_0^θ ）。

训练目标及其梯度. 文献通常采用 KL 散度匹配分布 p_t 与 p_t^θ ，常见做法是最小化

$$\begin{aligned} \mathcal{L}_{\text{VSD}}(\boldsymbol{\theta}) &:= \mathbb{E}_t [\omega(t) \mathcal{D}_{\text{KL}}(p_t^\theta \| p_t)] \\ &= \mathbb{E}_{t, \mathbf{z}, \boldsymbol{\epsilon}} [\omega(t) (\log p_t^\theta(\mathbf{x}_t^\theta) - \log p_t(\mathbf{x}_t^\theta))], \end{aligned}$$

其中 $\omega(t)$ 是依赖时间的权重函数。我们将在节 10.2.3 中讨论 KL 散度为何在分布层面的蒸馏中发挥特殊作用。

如 (Wang et al., 2023) 所示，当 $p_0^{\theta^*} = p_{\text{data}}$ 时达到最优值，这意味着生成器分布与数据分布匹配，因此该训练目标是学习数据分布的有效损失。

然而，基于密度的目标表述缺乏高效的训练机制。幸运的是，对 $\boldsymbol{\theta}$ 求梯度，可以得到式 (10.2.2) 中的表达式，概括为下面的命题。为简化记号，将式 (10.2.1) 中定义的变量记为 $\hat{\mathbf{x}}_t := \mathbf{x}_t^\theta$ 。

命题 10.2.1: $\mathcal{L}_{\text{VSD}}$ 关于 $\boldsymbol{\theta}$ 的梯度

有

$$\begin{aligned} &\nabla_{\boldsymbol{\theta}} \mathcal{L}_{\text{VSD}}(\boldsymbol{\theta}) \\ &= \mathbb{E}_{t, \mathbf{z}, \boldsymbol{\epsilon}} [\omega(t) \alpha_t (\nabla_{\mathbf{x}} \log p_t^\theta(\hat{\mathbf{x}}_t) - \nabla_{\mathbf{x}} \log p_t(\hat{\mathbf{x}}_t)) \cdot \partial_{\boldsymbol{\theta}} \mathbf{G}_\theta(\mathbf{z})]. \end{aligned} \quad (10.2.2)$$

命题的证明.

推导应用链式法则:

$$\begin{aligned}
& \nabla_{\theta} \mathbb{E}_t [\mathcal{D}_{\text{KL}}(p_t^{\theta} \| p_t)] \\
&= \mathbb{E}_{t, \mathbf{z}, \epsilon} [\partial_{\theta} (\log p_t^{\theta}(\hat{\mathbf{x}}_t) - \log p_t(\hat{\mathbf{x}}_t))] \\
&= \mathbb{E}_{t, \mathbf{z}, \epsilon} \left[\underbrace{\partial_{\theta} \log p_t^{\theta}(\hat{\mathbf{x}}_t)}_{\text{第一项}} + (\nabla_{\mathbf{x}} \log p_t^{\theta}(\hat{\mathbf{x}}_t))^{\top} \partial_{\theta} \hat{\mathbf{x}}_t - (\nabla_{\mathbf{x}} \log p_t(\hat{\mathbf{x}}_t))^{\top} \partial_{\theta} \hat{\mathbf{x}}_t \right].
\end{aligned}$$

由得分函数恒等式, 第一项为零:

$$\mathbb{E}_{\hat{\mathbf{x}}_t \sim p_t^{\theta}} [\partial_{\theta} \log p_t^{\theta}(\hat{\mathbf{x}}_t)] = \int \partial_{\theta} p_t^{\theta}(\mathbf{x}) d\mathbf{x} = \partial_{\theta} \int p_t^{\theta}(\mathbf{x}) d\mathbf{x} = \partial_{\theta}(1) = 0.$$

使用重参数化 $\hat{\mathbf{x}}_t = \alpha_t \mathbf{G}_{\theta}(\mathbf{z}) + \sigma_t \epsilon$, 得到 $\partial_{\theta} \hat{\mathbf{x}}_t = \alpha_t \partial_{\theta} \mathbf{G}_{\theta}(\mathbf{z})$, 因此

$$\nabla_{\theta} \mathcal{L}_{\text{VSD}}(\theta) = \mathbb{E}_{t, \mathbf{z}, \epsilon} \left[\omega(t) \alpha_t (\nabla_{\mathbf{x}} \log p_t^{\theta}(\hat{\mathbf{x}}_t) - \nabla_{\mathbf{x}} \log p_t(\hat{\mathbf{x}}_t))^{\top} \partial_{\theta} \mathbf{G}_{\theta}(\mathbf{z}) \right].$$

这就证明了式 (10.2.2). 详细内容见节 D.5. ■

可以看到, 在对 θ 求梯度时, 得分函数自然地出现. 因此, 我们需要近似一步生成器的得分 $\nabla_{\mathbf{x}} \log p_t^{\theta}(\hat{\mathbf{x}}_t)$, 以及数据分布的得分 $\nabla_{\mathbf{x}} \log p_t(\hat{\mathbf{x}}_t)$; 下一小节将详细说明.

10.2.2 VSD 的训练流程

现有工作 (Yin et al., 2024b; Yin et al., 2024a; Poole et al., 2023; Wang et al., 2023; Luo et al., 2023; Lu and Song, 2024) 通常通过双层优化处理这一问题: 在 $\mathbf{G}_{\theta}(\mathbf{z})$ 的样本上训练新的扩散模型, 近似 $\nabla_{\mathbf{x}} \log p_t^{\theta}(\hat{\mathbf{x}}_t)$; 同时使用预训练扩散模型, 替代合成样本 $\hat{\mathbf{x}}_t$ 上不可直接计算的理想得分函数 $\nabla_{\mathbf{x}} \log p_t(\hat{\mathbf{x}}_t)$ (即教师得分). 更准确地说, 训练交替进行以下两个阶段:

- **得分估计阶段.** 固定 θ . 令 $\hat{\mathbf{x}}_0 = \mathbf{G}_{\theta}(\mathbf{z})$, $\hat{\mathbf{x}}_t = \alpha_t \hat{\mathbf{x}}_0 + \sigma_t \epsilon$, 其中 $\mathbf{z} \sim p_{\text{prior}}$, $\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$. 利用已知的高斯扩散核 $p_t(\mathbf{x}_t | \mathbf{x}_0)$, 通过去噪得分匹配 (DSM) 训练 s_{ζ} :

$$\mathcal{L}_{\text{DSM}}(\zeta; \theta) = \mathbb{E}_{t, \mathbf{z}, \epsilon} \left\| s_{\zeta}(\hat{\mathbf{x}}_t, t) - \nabla_{\mathbf{x}_t} \log p_t(\hat{\mathbf{x}}_t | \hat{\mathbf{x}}_0) \right\|^2,$$

在最优点 (固定 θ 时), 得到 $s_{\zeta}(\cdot, t) \approx \nabla_{\mathbf{x}} \log p_t^{\theta}(\cdot)$.

- **生成器更新阶段.** 冻结 s_{ζ} (停止梯度), 利用式 (10.2.2) 中的梯度更新 θ , 并将各得分项替换为相应的近似:

$$s_{\zeta}(\hat{\mathbf{x}}_t, t) \approx \nabla_{\mathbf{x}} \log p_t^{\theta}(\hat{\mathbf{x}}_t), \text{ 以及 } s_{\phi \times}(\hat{\mathbf{x}}_t, t) \approx \nabla_{\mathbf{x}} \log p_t(\hat{\mathbf{x}}_t) \text{ (教师)}.$$

此时, 式 (10.2.2) 近似变为:

$$\nabla_{\theta} \mathcal{L}_{\text{VSD}}(\theta) \approx \mathbb{E}_{t, \mathbf{z}, \epsilon} \left[\omega(t) \alpha_t (s_{\zeta}(\hat{\mathbf{x}}_t, t) - s_{\phi \times}(\hat{\mathbf{x}}_t, t))^{\top} \partial_{\theta} \mathbf{G}_{\theta}(\mathbf{z}) \right].$$

重复这两个阶段,直到对所有 t , 在 p_t^θ 的支撑集上都有 $\mathbf{s}_\zeta(\cdot, t) \approx \mathbf{s}_{\phi^\times}(\cdot, t)$, 从而式 (10.2.2) 中代入近似得分所得的梯度为零. 在这一收敛状态下, 对所有 $t > 0$, 都有 $p_t^\theta \approx p_t^{\phi^\times}$ (教师的边缘分布). 由于对任意固定的 $t > 0$, 前向加噪算子 (高斯卷积) 都是单射, 故有 $p_0^\theta \approx p_0^{\phi^\times}$ (教师在 $t = 0$ 时的分布). 因此, 学得的一步生成器 $\mathbf{G}_\theta$ 在 $t = 0$ 时匹配教师分布; 当教师充分逼近 p_{data} 时, 进一步有 $p_0^\theta \approx p_{\text{data}}$.

10.2.3 补充讨论: 散度选择与 VSD 的应用

超越 KL: 能否使用一般散度? 原则上, 可以将 VSD 中的前向 KL 项 $\mathcal{D}_{\text{KL}}(p_t^\theta \| p_t)$ 替换为更一般的散度族, 例如 f 散度 (见式 (1.1.4)):

$$\mathcal{D}_f(p_t^\theta \| p_t) = \int p_t(\mathbf{x}) f\left(\frac{p_t^\theta(\mathbf{x})}{p_t(\mathbf{x})}\right) d\mathbf{x}.$$

然而, 梯度 $\nabla_\theta \mathcal{D}_f(p_t^\theta \| p_t)$ 依赖于密度比

$$r_t(\mathbf{x}) = \frac{p_t^\theta(\mathbf{x})}{p_t(\mathbf{x})},$$

具体通过 $f'(r_t)$ 依赖于它; 对隐式学生生成器而言, 该量不可直接计算. 这里将学生称为隐式, 是因为它能够通过随机映射 $\hat{\mathbf{x}}_t = \alpha_t \mathbf{G}_\theta(\mathbf{z}) + \sigma_t \epsilon$ 产生样本 $\hat{\mathbf{x}}_t$, 却无法给出其诱导密度 $p_t^\theta(\mathbf{x})$ 的闭式表达式或似然. 因此, 计算 $\mathcal{D}_f$ 的泛函导数, 需要逐点获得 $r_t(\mathbf{x})$ 或其对数梯度, 而在此设置下两者都无法计算. 常见的变通办法是引入辅助评价器或判别器, 通过 f 散度的变分表述来近似密度比, 例如 f -GAN (Nowozin, Cseke, and Tomioka, 2016); 不过这会引入额外的网络和嵌套的极小极大优化.

相比之下, 对于前向 KL, 路径梯度恰好简化为得分差的形式 (式 (10.2.2)):

$$\nabla_\theta \mathcal{D}_{\text{KL}}(p_t^\theta \| p_t) = \mathbb{E} \left[\left(\nabla_{\mathbf{x}} \log p_t^\theta(\hat{\mathbf{x}}_t) - \nabla_{\mathbf{x}} \log p_t(\hat{\mathbf{x}}_t) \right)^\top \partial_\theta \hat{\mathbf{x}}_t \right].$$

这一结构使仅依赖得分的更新能够计算. 教师的预训练扩散模型已经提供 $\nabla_{\mathbf{x}} \log p_t(\cdot)$, 因此可以直接复用, 无需学习辅助密度比估计器. 这一表述给出了一个非对抗的训练目标, 同时保持完全可微且计算高效.

仅使用二维预训练扩散模型进行三维生成的 VSD. VSD (Wang et al., 2023) 及其较早的特例 SDS (Poole et al., 2023) (生成器为由 θ 参数化的 Dirac 分布), 最初用于三维数据与二维数据之间没有配对监督的三维场景 (即没有真实三维标签). 设 $\theta \in \mathbb{R}^d$ 表示三维场景参数, $\mathbf{R}(\theta)$ 是可微渲染器, 生成图像 $\hat{\mathbf{x}}_0 := \mathbf{R}(\theta)$. 前向加噪过程定义为

$$\hat{\mathbf{x}}_t = \alpha_t \mathbf{R}(\theta) + \sigma_t \epsilon, \quad \epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I}).$$

预训练的二维 (图像) 扩散教师提供得分:

$$\mathbf{s}_{\phi^\times}(\hat{\mathbf{x}}_t, t | \mathbf{c}) \approx \nabla_{\hat{\mathbf{x}}_t} \log p_t(\hat{\mathbf{x}}_t | \mathbf{c}),$$

可以选择以文本 $\mathbf{c}$ 为条件. 目标是在每个 t 将含噪渲染结果的分布与教师边缘分布对齐. 一个最简表述是渲染分布下的得分对齐 (VSD) 目标:

$$\mathcal{L}_{\text{VSD}}^{3\text{D}}(\boldsymbol{\theta}) := \mathbb{E}_{t,\epsilon} \left[\omega(t) \left\| \mathbf{s}_{\zeta}(\hat{\mathbf{x}}_t, t) - \mathbf{s}_{\phi^{\times}}(\hat{\mathbf{x}}_t, t | \mathbf{c}) \right\|_2^2 \right], \quad \hat{\mathbf{x}}_t = \alpha_t \mathbf{R}(\boldsymbol{\theta}) + \sigma_t \epsilon,$$

它通过渲染器将图像空间中的得分引导传递至三维参数. 更新 $\boldsymbol{\theta}$ 时, 对两个得分关于 $\hat{\mathbf{x}}_t$ 的梯度都停止传播, 得到


$$\nabla_{\boldsymbol{\theta}} \mathcal{L}_{\text{VSD}}^{3\text{D}}(\boldsymbol{\theta}) = \mathbb{E}_{t,\epsilon} \left[\omega(t) \alpha_t (\mathbf{s}_{\zeta} - \mathbf{s}_{\phi^{\times}})^{\top} \frac{\partial \mathbf{R}}{\partial \boldsymbol{\theta}}(\boldsymbol{\theta}) \right].$$

当去掉学生得分 $\mathbf{s}_{\zeta}$ 时 (Dirac 生成器), 这一表述退化为 SDS (Poole et al., 2023). 实践中, 优化严格按照节 10.2.2 的描述交替进行: 先在含噪渲染结果上更新学生得分, 再停止通过两个得分的梯度传播, 更新 $\boldsymbol{\theta}$. 为简洁起见, 此处省略进一步的数学细节.

10.3 渐进蒸馏

渐进蒸馏 (PD) (Salimans and Ho, 2021) 由两个过程组成, 共同使扩散模型更高效地学习 PF-ODE 轨迹. 核心思想是在保持对教师轨迹的忠实性的同时, 逐渐减少高质量采样所需的积分步数.

- **蒸馏操作:** 将基于预训练教师模型 (最初为扩散模型) 的确定性采样器 (例如 DDIM) 蒸馏为学生模型, 学生仅用一半的采样步数即可复现同一轨迹.
- **渐进操作:** 迭代重复上述蒸馏过程, 每次将步数减半, 直到学生能在较小的固定预算内 (通常为 1-4 步) 生成高质量样本.



数据

噪声

图 10.1: **渐进蒸馏 (PD) 示意图**. 每轮训练学生模型, 使其一步复现教师相邻两步的效果. 这一过程将教师的 N 步蒸馏为学生的 $N/2$ 步, 反复进行便能逐渐将轨迹长度减半, 直到达到所需步数. 箭头表示从数据到噪声的方向上, 教师的多步转移如何压缩成更少的学生步骤.

我们先在节 10.3.1 中介绍 PD 的蒸馏操作, 再在节 10.3.2 中概括完整训练流程. 节 10.3.4 给出适用于无分类器引导 (CFG) 的扩展.

10.3.1 PD 中的蒸馏操作

本节固定采用 $\mathbf{x}$ 预测参数化下的 DDIM 作为时间步进规则，并仍用 $\text{Solver}_{s \rightarrow t}$ 表示将当前教师的 $\mathbf{x}$ 去噪器代入 DDIM 得到的确定性映射。

在第一轮 PD 中（教师 = 预训练扩散模型），这等同于通过 DDIM 对扩散 PF-ODE 积分；在后续各轮中（教师 = 上一轮学生）， $\text{Solver}_{s \rightarrow t}$ 只是由当前教师诱导的 DDIM 转移，而非原始扩散 PF-ODE。

蒸馏步骤如下：从含噪输入 $\mathbf{x}_s$ （干净数据的扰动版本， $\mathbf{x}_s = \alpha_s \mathbf{x}_0 + \sigma_s \epsilon$ ）出发，训练学生预测目标 $\tilde{\mathbf{x}}$ ，使学生的一步 $s \rightarrow t$ 复现教师连续两步 $s \rightarrow u \rightarrow t$ 的结果。设 $\mathbf{x}_{\phi^\times}(\mathbf{x}, \tau)$ 表示本轮教师的 $\mathbf{x}$ 预测去噪器。将教师诱导的 DDIM 转移应用两次，得到

$$\tilde{\mathbf{x}}_u := \text{Solver}_{s \rightarrow u}(\mathbf{x}_s; \mathbf{x}_{\phi^\times}), \quad \tilde{\mathbf{x}}_t := \text{Solver}_{u \rightarrow t}(\tilde{\mathbf{x}}_u; \mathbf{x}_{\phi^\times}).$$

这里使用式 (10.1.3) 中的记号，表示将 $\mathbf{x}_{\phi^\times}$ 代入 DDIM 所诱导的、从 s 到 t （以 $\mathbf{x}_s$ 为起点）的确定性转移映射。

问题 10.3.1. 时刻 s 的伪干净目标 $\tilde{\mathbf{x}}$ 应取何值，才能使求解器直接从 $s \rightarrow t$ 步进时，得到与经过 $s \rightarrow u \rightarrow t$ 相同的输出 $\tilde{\mathbf{x}}_t$ ？具体而言，确定满足下式的 $\tilde{\mathbf{x}}$ ：

$$\tilde{\mathbf{x}}_t = \text{Solver}_{s \rightarrow t}(\mathbf{x}_s; \tilde{\mathbf{x}}).$$

获得 $\tilde{\mathbf{x}}$ 的闭式表达式后，我们通过最小化下式，训练学生模型 $\mathbf{f}_\theta(\mathbf{x}_s, s)$ （这里同样是 $\mathbf{x}$ 预测模型），使其逼近“两步合一”目标 $\tilde{\mathbf{x}}$ ：

$$\min_{\theta} \mathbb{E}_s \mathbb{E}_{\mathbf{x}_s \sim p_s} \left[w(\lambda_s) \left\| \mathbf{f}_\theta(\mathbf{x}_s, s) - \tilde{\mathbf{x}} \right\|_2^2 \right]. \quad (10.3.1)$$

下面说明，通过初等代数运算，DDIM 规则可以给出 $\tilde{\mathbf{x}}$ 的闭式表达式（注意，该结果对离散时间和连续时间均成立）：

引理 10.3.1: DDIM 的两步合一目标 $\tilde{\mathbf{x}}$

从初始条件 $\mathbf{x}_s$ 出发，如果求解器取为 DDIM，则“两步合一”目标 $\tilde{\mathbf{x}}$ 可计算为

$$\tilde{\mathbf{x}} = \frac{\sigma_s}{\alpha_t \sigma_s - \alpha_s \sigma_t} \tilde{\mathbf{x}}_t - \frac{\sigma_t}{\alpha_t \sigma_s - \alpha_s \sigma_t} \mathbf{x}_s.$$

这里， $\tilde{\mathbf{x}}_t$ 由沿 $s \rightarrow u \rightarrow t$ 两次应用 DDIM（式 (9.2.3)）得到：

$$\begin{aligned} s \rightarrow u : \quad & \tilde{\mathbf{x}}_u = \frac{\sigma_u}{\sigma_s} \mathbf{x}_s + \alpha_s \left(\frac{\alpha_u}{\alpha_s} - \frac{\sigma_u}{\sigma_s} \right) \mathbf{x}_{\phi^\times}(\mathbf{x}_s, s) \\ u \rightarrow t : \quad & \tilde{\mathbf{x}}_t = \frac{\sigma_t}{\sigma_u} \tilde{\mathbf{x}}_u + \alpha_u \left(\frac{\alpha_t}{\alpha_u} - \frac{\sigma_t}{\sigma_u} \right) \mathbf{x}_{\phi^\times}(\tilde{\mathbf{x}}_u, u). \end{aligned}$$

引理的证明.

$\tilde{\mathbf{x}}_t$ 必须与从 s 到 t 的一步 DDIM 结果 $\tilde{\mathbf{x}}'_t$ 匹配, 后者表示为:

$$s \rightarrow t: \quad \tilde{\mathbf{x}}'_t = \frac{\sigma_t}{\sigma_s} \mathbf{x}_s + \alpha_s \left(\frac{\alpha_t}{\alpha_s} - \frac{\sigma_t}{\sigma_s} \right) \tilde{\mathbf{x}}.$$

令 $\tilde{\mathbf{x}}'_t$ 与 $\tilde{\mathbf{x}}_t$ 相等, 即可用 $\tilde{\mathbf{x}}_t$ 、 s 和 t 解出 $\tilde{\mathbf{x}}$:

$$\begin{aligned} \tilde{\mathbf{x}}_t &= \tilde{\mathbf{x}}'_t \\ \iff \tilde{\mathbf{x}}_t &= \frac{\sigma_t}{\sigma_s} \mathbf{x}_s + \alpha_s \left(\frac{\alpha_t}{\alpha_s} - \frac{\sigma_t}{\sigma_s} \right) \tilde{\mathbf{x}} \\ \iff \tilde{\mathbf{x}} &= \frac{\tilde{\mathbf{x}}_t - \frac{\sigma_t}{\sigma_s} \mathbf{x}_s}{\alpha_s \left(\frac{\alpha_t}{\alpha_s} - \frac{\sigma_t}{\sigma_s} \right)} \\ \iff \tilde{\mathbf{x}} &= \frac{\sigma_s}{\alpha_t \sigma_s - \alpha_s \sigma_t} \tilde{\mathbf{x}}_t - \frac{\sigma_t}{\alpha_t \sigma_s - \alpha_s \sigma_t} \mathbf{x}_s. \end{aligned} \tag{10.3.2}$$

利用这一公式, PD 计算时刻 s 的伪干净目标, 使其单次 DDIM 步进 $s \rightarrow t$ 恰好到达两步输出 $\tilde{\mathbf{x}}_t$.

实际使用的离散时间网格与损失. 实践中, 固定递减网格 $t_0 = T > t_1 > \dots > t_N = 0$, 并简记 $s := t_k$ 、 $u := t_{k+1}$ 、 $t := t_{k+2}$. 教师提供一步映射 $\text{Teacher}_{t_k \rightarrow t_{k+1}}$, 学生则学习两步跨越映射, 以匹配教师映射的复合:

$$\text{Student}_{t_k \rightarrow t_{k+2}} \approx \text{Teacher}_{t_{k+1} \rightarrow t_{k+2}} \circ \text{Teacher}_{t_k \rightarrow t_{k+1}}.$$

采样三元组 $(s, u, t) = (t_k, t_{k+1}, t_{k+2})$, 其中 $k \in \{0, \dots, N-2\}$. 目标式 (10.3.1) 变为

$$\min_{\theta} \mathbb{E}_{k \sim \mathcal{U}[0, N-2]} \mathbb{E}_{\mathbf{x}_{t_k} \sim p_{t_k}} \left[w(\lambda_{t_k}) \left\| \mathbf{f}_{\theta}(\mathbf{x}_{t_k}, t_k) - \tilde{\mathbf{x}}^{(k)} \right\|_2^2 \right],$$

其中, 教师的两步目标 $\tilde{\mathbf{x}}^{(k)}$ 通过引理 10.3.1 计算. 若网格均匀, 可写为 $t_k = T(1 - k/N)$, 从而

$$s = T \left(1 - \frac{k}{N} \right), \quad u = T \left(1 - \frac{k+1}{N} \right), \quad t = T \left(1 - \frac{k+2}{N} \right),$$

对应于步长为 $\Delta s = T/N$ 的等间隔时间步.

10.3.2 PD 的完整训练流程及其采样

通过式 (10.3.1) 在局部配对片段上训练后, Student 不再沿原始网格的每个区间推进. 每个学得步骤覆盖 Teacher 连续两步, 因此 Student 每隔一个时间点推进一次:

$$t_0 \rightarrow t_2 \rightarrow t_4 \rightarrow \dots \rightarrow t_N,$$

因此，仅用 $N/2$ 次转移就能遍历同一时间范围 $[0, T]$ 。这一阶段结束后，训练好的 **Student** 替代 **Teacher**，成为新的去噪器模型。随后在更粗的网格上重复此过程（时间步长加倍），步数依次变为

$$N \rightarrow N/2 \rightarrow N/4 \rightarrow \dots,$$

直至达到所需的推断步数。每次迭代时，新的 **Student** 都由更新后的 **Teacher** 初始化。这种迭代减半保持整体时间范围不变，同时逐渐压缩生成过程的时间分辨率。

采样。 推断时，以当前 **Student** 为去噪器，使用 (DDIM) 求解器，采样器沿训练诱导的更粗网格推进。第一轮之后进行“跨越 2 步”的跳跃 ($t_0 \rightarrow t_2 \rightarrow \dots \rightarrow t_N$)，下一轮之后进行“跨越 4 步”的跳跃 ($t_0 \rightarrow t_4 \rightarrow \dots \rightarrow t_N$)，依此类推；每次迭代都将采样步数减半，同时保持起止时刻不变。

10.3.3 补充讨论：局部半群匹配与推广求解器的可能性

作为局部半群匹配的渐进蒸馏。 在统一目标式 (10.1.4) 中，不可直接计算的理想目标 $\Psi_{s \rightarrow 0}$ 被教师诱导的替代目标取代，这一目标利用常微分方程流的半群性质（详细内容见后文式 (11.2.1)）：从 s 演化到 t 应等价于先从 s 到任意中间时刻 u ，再从 u 到 t ，即

$$\Psi_{s \rightarrow t} = \Psi_{u \rightarrow t} \circ \Psi_{s \rightarrow u}.$$

PD 在局部施加这一性质：训练学生的一步映射，使其匹配教师相邻两个一步片段的复合：

$$\mathbb{E}_s \mathbb{E}_{\mathbf{x}_s \sim p_s} \left\| \underbrace{\mathbf{G}_\theta(\mathbf{x}_s, s, s - 2\Delta s)}_{\text{学生的一步}} - \underbrace{\text{Solver}_{s-\Delta s \rightarrow s-2\Delta s}(\text{Solver}_{s \rightarrow s-\Delta s}(\mathbf{x}_s))}_{\text{教师两步的复合}} \right\|_2^2. \quad (10.3.3)$$

最小化式 (10.3.3)，就在一段短的递减网格上实现了半群恒等式（取 $s > u > t$ ，其中 $u = s - \Delta s$ 、 $t = s - 2\Delta s$ ）：

$$\begin{aligned} \Psi_{s \rightarrow s-2\Delta s} &= \Psi_{s-\Delta s \rightarrow s-2\Delta s} \circ \Psi_{s \rightarrow s-\Delta s} \\ &\approx \text{Solver}_{s-\Delta s \rightarrow s-2\Delta s} \circ \text{Solver}_{s \rightarrow s-\Delta s}, \end{aligned}$$

因此，训练只需较短的教师轨迹片段，而无需从时刻 s 一直完整演化到 0。

为衔接式 (10.1.4) 中的少步去噪器视角，将学生的少步映射定义为学得跳跃的复合：

$$\underbrace{\mathbf{G}_\theta(\mathbf{x}_s, s, 0)}_{\text{少步去噪器}} = (\mathbf{G}_\theta(\cdot, 2\Delta s, 0) \circ \dots \circ \mathbf{G}_\theta(\cdot, s, s - 2\Delta s))(\mathbf{x}_s).$$

从概念上看，式 (10.3.3) 为如下全局回归提供了高效的局部替代：

$$\mathbb{E}_{s, \mathbf{x}_s} \left\| \mathbf{G}_\theta(\mathbf{x}_s, s, 0) - (\text{Solver})_{s \rightarrow 0}^\circ(\mathbf{x}_s) \right\|_2^2,$$

其中， $(\text{Solver})_{s \rightarrow 0}^\circ$ 表示教师在步长为 Δs 的网格上从 s 到 0 的完整复合，作为 $\Psi_{s \rightarrow 0}$ 的近似。

能否使用其他求解器？ 上述 PD 介绍以 $\mathbf{x}$ 预测参数化下的 DDIM 为具体的 PF-ODE 采样器. 在确定性状态到状态映射层面, 结合网格减半的局部半群匹配不依赖具体求解器; 在参数化 ($\mathbf{x}$ 、 ϵ 、 $\mathbf{v}$ 、得分) 之间进行标准转换后, 它可推广至章 9 中的时间步进方法. 然而, 此处的闭式伪目标依赖单步显式更新, 其一步映射关于回归目标是仿射的 (例如 DDIM, 以及应用于 PF-ODE 的指数 Euler 或显式 RK 等显式单步格式). 对于需要历史步骤或内部求解的多步或隐式求解器, 应直接匹配对应的转移映射 (参见式 (10.3.3)), 并提供所需的历史信息或热启动; 通常不存在类似的闭式逆解.

如果采样器是随机的, 对每个样本固定噪声序列, 得到确定性转移 $\text{Teacher}_{s \rightarrow t}^{(\omega)}$ (其中 ω 为固定的噪声种子). 此时, PD 回归到一个固定的转移映射; 闭式伪目标一般要求单步显式仿射更新, 否则应采用式 (10.3.3) 中的直接匹配.

10.3.4 带引导的 PD

Meng et al. (2023) 提出了蒸馏无分类器引导 (CFG) 扩散模型的两阶段流程:

1. 将引导蒸馏到一个以引导权重为输入的网络中.
2. 应用渐进蒸馏 (PD) 减少采样步数.

他们在像素空间和潜空间 (例如 Stable Diffusion) 中均验证了这一方法.

第一阶段蒸馏: 蒸馏引导. 设 $\mathbf{x}_{\phi \times}(\mathbf{x}_s, s, \mathbf{c})$ 表示 (预训练) 条件扩散模型在时刻 s 、条件 $\mathbf{c}$ 下, 采用 “ $\mathbf{x}$ 预测” 参数化的输出 (即干净估计); 条件也可以为空, 即 $\mathbf{c} = \emptyset$ (无条件分支). 式 (8.3.3) 中以 ω 加权的 CFG 组合可写为

$$\mathbf{x}_{\phi \times}^{\omega}(\mathbf{x}_s, s, \mathbf{c}) := (1 + \omega) \mathbf{x}_{\phi \times}(\mathbf{x}_s, s, \mathbf{c}) - \omega \mathbf{x}_{\phi \times}(\mathbf{x}_s, s, \emptyset), \quad (10.3.4)$$

其中 $\omega \sim p_{\omega}(\omega)$, p_{ω} 是某个 CFG 权重分布, 通常取 $p_{\omega}(\omega) = \mathcal{U}[\omega_{\min}, \omega_{\max}]$.

第一阶段引入新模型 $\mathbf{x}_{\theta_1}(\mathbf{x}_s, s, \mathbf{c}, \omega)$, 直接以 ω 为输入, 通过监督回归学习复现 CFG 输出 $\mathbf{x}_{\phi \times}^{\omega}(\mathbf{x}_s, s, \mathbf{c})$:

$$\min_{\theta_1} \mathbb{E}_{\omega \sim p_{\omega}, s, \mathbf{x} \sim p_{\text{data}}, \mathbf{x}_s \sim p(\mathbf{x}_s | \mathbf{x})} \lambda(s) \left\| \mathbf{x}_{\theta_1}(\mathbf{x}_s, s, \mathbf{c}, \omega) - \mathbf{x}_{\phi \times}^{\omega}(\mathbf{x}_s, s, \mathbf{c}) \right\|_2^2.$$

这里, $\lambda(s)$ 是标准的依赖调度的权重; 每次迭代都采样 ω , 使单个网络学会模拟任意引导强度下的 CFG.

第二阶段蒸馏: PD. 第一阶段模型 $\mathbf{x}_{\theta_1}(\mathbf{x}_s, s, \mathbf{c}, \omega)$ 作为 PD 中的教师, 按照节 10.3.2, 渐进蒸馏成采样步数更少的学生 $\mathbf{x}_{\theta_2}(\mathbf{x}_s, s, \mathbf{c}, \omega)$. 每次迭代将步数减半 (例如 $N \rightarrow N/2 \rightarrow N/4 \rightarrow \dots$).

10.4 结束语

本章介绍了基于训练的加速的第一种主要范式. 在充分讨论通过数值求解器实现的无需训练的改进后, 我们将注意力转向新的策略: 训练一个快速的学生生成器, 学习复现速度较慢的预训练教师扩散模型的行为.

我们探讨了两种主要的蒸馏思想. 首先, 在以变分得分蒸馏 (VSD) 等方法为代表的基于分布的蒸馏中, 训练学生, 使其输出分布与教师分布匹配. 这一目标通过在不同噪声水平下对齐二者的得分函数来实现, 得到稳定的非对抗目标. 其次, 在流映射蒸馏中, 我们看到渐进蒸馏 (PD) 等方法如何训练学生, 直接逼近教师的解轨迹. PD 每轮将采样步数减半的迭代方法, 已被证明是将漫长迭代过程压缩为少数几步的有力且实用的方法.

这些蒸馏技术成功地将迭代扩散模型的高样本质量与一步生成器的推断速度结合起来, 为高效、高保真的合成提供了有吸引力的路径.

然而, 对预训练教师模型的依赖带来了两阶段流程: 先训练一个速度慢但能力强的教师, 再将其蒸馏为快速学生. 这引出了生成建模前沿研究中的一个根本问题: 能否完全绕过教师?

能否设计独立的训练原则, 直接从数据学习这些快速的少步生成器? 本专著的最后一章将讨论这一问题.

1. 我们将探讨一致性模型等开创性方法, 它们学习从常微分方程轨迹上任意点到其终点的映射.
2. 我们将深入讨论一致性模型的推广概念, 它们学习用一步将常微分方程轨迹上的任意点映射到另一个点.

从改进求解器或蒸馏解, 转向学习解映射本身, 是迈向新一类生成模型的重要一步; 这类模型在设计上既有理论依据, 又具有很高效率.

第 11 章 从头学习快速生成器

真理总能在简单之中找到，而非在事物的繁多与混乱之中。

Isaac Newton

在章 10 中，我们看到扩散模型中缓慢的迭代采样器可以通过蒸馏压缩为少步生成器。从工程角度看，两阶段流程具有实用性，因为它将复杂的生成训练任务划分为明确、独立的目标。第一阶段学习数据分布，第二阶段加速采样或提高质量。这种划分使每个阶段都能独立优化，令整体系统更易管理、更稳定且更可靠。

不过，本章将注意力转向一个推动深度生成建模进展的核心问题：

问题 11.0.1. 能否设计独立的生成原则，使训练稳定高效、采样快速，并让用户能够方便地引导或控制生成结果？

本章沿这一方向讨论另一种方法：不依赖预训练模型，训练基于扩散的少步生成器。我们关注流映射 (*flow map*) 模型，它通过逼近 PF-ODE 的理想流映射，学习直接跨时间移动样本的变换。这一表述给出了一种有理论依据的方式，将概率质量从先验分布 p_{prior} 输运至数据分布 p_{data} ，同时保持每个中间时刻由前向扩散过程指定的边缘分布 p_t 。

11.1 引言




图 11.1: 流映射建模的时间线. 用蓝色表示特例 $\Psi_{s \rightarrow 0}$, 用橙色表示一般映射 $\Psi_{s \rightarrow t}$.

流映射模型的动机. 在章 10 中, 我们说明了如何从预训练扩散模型蒸馏知识, 以估计理想流映射损失 $\mathcal{L}_{\text{oracle}}(\theta)$ (见式 (10.1.4)) 中无法直接获得的回归目标, 从而得到少步生成器. 这条路线有效且实用: 通过工程设计, 两阶段流程可以具有稳健性, 并且往往在数据效率和计算效率上仍具有竞争力.

本章将注意力转向深度生成建模核心的一项更广泛挑战: 能否建立独立的生成原则, 在不依赖预训练模型的情况下, 实现稳定、可扩展且高效的训练、快速采样, 以及易于按用户意图引导的生成? 设计这样的独立原则是生成建模的核心任务.

扩散模型提供了一条有用的设计原则: 以逐渐将数据变换为简单先验 (噪声) 的连续时间前向过程作为参考, 并将建模任务表述为学习时间反向输运, 逆转该过程, 以匹配所需的边缘分布. 与一次性生成映射相比, 这种依赖时间的表述也使得在中间步骤引导生成过程更加容易. 对受扩散启发的方法而言, 这引出了如下问题:

问题 11.1.1. 能否在没有预训练模型的情况下, 用网络 $\mathbf{G}_{\theta}(\cdot, s, t)$ (即流映射模型) 学习流映射 $\Psi_{s \rightarrow t}(\cdot)$, 同时保持高保真的生成?

本章围绕一个统一目标, 发展实现上述目的的方法; 该目标也是蒸馏的基础, 并提供了流映射表述的统一视角 (Boffi, Albergo, and Vanden-Eijnden, 2024; Hu et al., 2025):

$$\mathcal{L}_{\text{oracle}}(\theta) := \mathbb{E}_{s,t} \mathbb{E}_{\mathbf{x}_s \sim p_s} \left[w(s, t) d(\mathbf{G}_{\theta}(\mathbf{x}_s, s, t), \Psi_{s \rightarrow t}(\mathbf{x}_s)) \right]. \quad (10.1.4)$$

这里, s, t 从某个时间分布 (例如均匀分布) 采样, $w(s, t) \geq 0$ 为时间对 (s, t) 赋予权重, $d(\cdot, \cdot)$ 是差异度量, 例如 ℓ_2 范数的平方. 理想流映射 $\Psi_{s \rightarrow t}$ 表示将时刻 s 的状态 $\mathbf{x}_s$ 直接输运到时刻 t 的理想变换:

$$\Psi_{s \rightarrow t}(\mathbf{x}_s) = \mathbf{x}_s + \int_s^t \mathbf{v}^*(\mathbf{x}_u, u) \, du,$$

其中, 理想漂移为

$$\mathbf{v}^*(\mathbf{x}_u, u) = \mathbb{E} [\alpha'_u \mathbf{x}_0 + \sigma'_u \epsilon | \mathbf{x}_u],$$

也可以使用等价的参数化（见章 6），常见选择包括 $\mathbf{x}$ 预测和 $\mathbf{v}$ 预测形式。

在理想损失的最优点，学得模型精确恢复真实流映射：

$$\mathbf{G}^*(\mathbf{x}_s, s, t) = \Psi_{s \rightarrow t}(\mathbf{x}_s), \quad \text{对所有 } s, t, \text{ 及 } \mathbf{x}_s \sim p_s.$$

由于流映射 $\Psi_{s \rightarrow t}$ 无法用闭式表达，必须进行近似。一种选择是依赖预训练扩散模型，如章 10 所述。另一种选择则是引入新的、更加容易处理的替代目标，本章将介绍这一做法。为明确区分，可根据训练循环内是否调用教师，将现有方法大体分为两类：蒸馏显式调用教师模型；从头训练则通过构造自包含的替代目标，避免调用教师。

基于这一有理论依据的目标，我们现在转向学习流映射模型的系统性方法，旨在发展兼具实用性与计算效率的方法，使生成结果更准确地反映真实数据分布。首先概述这一范式。

特殊流映射：一致性函数。 一致性模型 (Song et al., 2023) 是流映射学习最早的开创性方法之一。它们学习少步去噪器 $\mathbf{f}_\theta(\cdot, s)$ ，逼近流映射至原点的这一特例：

$$\Psi_{s \rightarrow 0}(\cdot), \quad s \in (0, T].$$

核心思想是将每个含噪样本 $\mathbf{x}_s$ 映射回其轨迹终点处的干净数据点 $\mathbf{x}_0$ 。形式化地，CM 方法族 (Song et al., 2023; Song and Dhariwal, 2024; Geng et al., 2024; Lu and Song, 2024) 的理想训练目标为

$$\mathcal{L}_{\text{oracle-CM}}(\theta) := \mathbb{E}_s \mathbb{E}_{\mathbf{x}_s \sim p_s} [w(s) d(\mathbf{f}_\theta(\mathbf{x}_s, s), \Psi_{s \rightarrow 0}(\mathbf{x}_s))]. \quad (11.1.0)$$

然而，实践中无法获得理想值 $\Psi_{s \rightarrow 0}(\mathbf{x}_s)$ 。因此，使用一个停止梯度的目标替代它，记为 $\mathbf{f}_{\theta-}$ ，该目标取自同一轨迹上略早一步的状态 $\Psi_{s \rightarrow s-\Delta s}(\mathbf{x}_s)$ ：

$$\Psi_{s \rightarrow 0}(\mathbf{x}_s) \approx \mathbf{f}_{\theta-}(\Psi_{s \rightarrow s-\Delta s}(\mathbf{x}_s), s - \Delta s), \quad \Delta s > 0,$$

其中， $\Psi_{s \rightarrow s-\Delta s}(\mathbf{x}_s)$ 本身也必须近似。有两种实用策略：

1. 蒸馏：依赖预训练扩散模型。
2. 从头训练：使用不依赖教师引导的单点估计。

一般流映射。 两种代表性方法是一致性轨迹模型 (CTM) 和平均流 (MF)。

一致性轨迹模型。 一致性轨迹模型 (CTM)

(Kim et al., 2024a) 是首个学习任意起止时刻间一般流映射 $\Psi_{s \rightarrow t}$ 的工作，可以视为式 (10.1.4) 统一目标下的一个具体实例。CTM 采用受 Euler 方法启发的参数化，将理想流映射表示为

$$\Psi_{s \rightarrow t}(\mathbf{x}_s) := \mathbf{x}_s + \int_s^t \mathbf{v}^*(\mathbf{x}_u, u) du = \frac{t}{s} \mathbf{x}_s + \frac{s-t}{s} \underbrace{\left[\mathbf{x}_s + \frac{s}{s-t} \int_s^t \mathbf{v}^*(\mathbf{x}_u, u) du \right]}_{\approx \mathbf{g}_\theta},$$

由此得到神经网络参数化：

$$\mathbf{G}_\theta(\mathbf{x}_s, s, t) := \frac{t}{s} \mathbf{x}_s + \frac{s-t}{s} \mathbf{g}_\theta(\mathbf{x}_s, s, t),$$

其中， $\mathbf{g}_\theta$ 是神经网络，训练使其满足 $\Psi_{s \rightarrow t}(\mathbf{x}_s) \approx \mathbf{G}_\theta(\mathbf{x}_s, s, t)$.

由于无法直接获得理想值 $\Psi_{s \rightarrow t}(\mathbf{x}_s)$ ，CTM 使用在中间时刻 u 计算的停止梯度目标进行训练：

$$\Psi_{s \rightarrow t}(\mathbf{x}_s) \approx \mathbf{G}_{\theta^-}(\Psi_{s \rightarrow u}(\mathbf{x}_s), u, t), \quad u \in [t, s],$$

其中，中间状态 $\Psi_{s \rightarrow u}(\mathbf{x}_s)$ 可用两种方式之一近似：

1. 蒸馏：对预训练扩散教师应用少步求解器。
2. 从头训练：直接通过 $\mathbf{G}_\theta$ 参数化构造自身诱导的教师。

平均流. 平均流 (mean flow) (MF) (Geng et al., 2025a) 在流匹配基础上，对区间 $[t, s]$ (其中 $t \leq s$) 上的平均漂移建模：

$$\mathbf{h}_\theta(\mathbf{x}_s, s, t) \approx \mathbf{h}^*(\mathbf{x}_s, s, t) := \frac{1}{t-s} \int_s^t \mathbf{v}^*(\mathbf{x}_u, u) \, du,$$

这也符合式 (10.1.4). 将恒等式

$$(t-s) \mathbf{h}^*(\mathbf{x}_s, s, t) = \int_s^t \mathbf{v}^*(\mathbf{x}_u, u) \, du$$

对 s 求导，得到一个自指关系，由此构造 MF 目标：

$$\mathcal{L}_{\text{MF}}(\theta) := \mathbb{E}_s \mathbb{E}_{\mathbf{x}_s \sim p_s} \left[w(s) \left\| \mathbf{h}_\theta(\mathbf{x}_s, s, t) - \mathbf{h}_{\theta^-}^{\text{tgt}}(\mathbf{x}_s, s, t) \right\|_2^2 \right],$$

其中，停止梯度目标为

$$\mathbf{h}_{\theta^-}^{\text{tgt}}(\mathbf{x}_s, s, t) := \mathbf{v}^*(\mathbf{x}_s, s) - (s-t) (\mathbf{v}^*(\mathbf{x}_s, s) \partial_{\mathbf{x}} \mathbf{h}_{\theta^-} + \partial_s \mathbf{h}_{\theta^-}).$$

实践中，也必须近似理想速度 $\mathbf{v}^*(\mathbf{x}_s, s)$. 两种常见策略是：

1. 蒸馏：利用通过流匹配训练的预训练扩散模型。
2. 从头训练：使用由前向加噪过程 $\mathbf{x}_s = \alpha_s \mathbf{x}_0 + \sigma_s \epsilon$ 导出的单点条件速度 $\alpha'_s \mathbf{x}_0 + \sigma'_s \epsilon$.

CTM 与 MF 的关系. CTM 与 MF 近似同一条路径积分，但对其不同替代量进行参数化：

$$\begin{aligned} \Psi_{s \rightarrow t}(\mathbf{x}_s) &:= \mathbf{x}_s + \int_s^t \mathbf{v}^*(\mathbf{x}_u, u) \, du \\ &= \frac{t}{s} \mathbf{x}_s + \frac{s-t}{s} \underbrace{\left[\mathbf{x}_s + \frac{s}{s-t} \int_s^t \mathbf{v}^*(\mathbf{x}_u, u) \, du \right]}_{\approx \mathbf{g}_\theta} \\ &= \mathbf{x}_s + (t-s) \underbrace{\left[\frac{1}{t-s} \int_s^t \mathbf{v}^*(\mathbf{x}_u, u) \, du \right]}_{\approx \mathbf{h}_\theta}. \end{aligned}$$

换言之，CTM 通过 $\mathbf{g}_\theta$ 学习斜率位移，而 MF 学习平均漂移 $\mathbf{h}_\theta$ ；两者都是近似定义 $\Psi_{s \rightarrow t}$ 的同一积分的一致方法。

后续内容. 首先介绍关注特定流映射 $\Psi_{s \rightarrow 0}$ 的 CM 方法族。这一部分涵盖节 11.2 中的离散时间起源与节 11.3 中的连续时间扩展。随后转向一般流映射，详细讨论两种主要代表 CTM 与 MF。它们的参数化、训练策略及实际近似分别见节 11.4 与节 11.5。

需要说明，节 D.6 介绍的阐明扩散模型（EDM）为 $\mathbf{x}$ 预测模型的网络参数化设计提供了系统性指导，且已展现出很强的实验性能。尽管该节可以视为选读内容，EDM 表述仍是 CM 类模型的重要基础。

为使后续叙述清晰，我们不严格遵循这些方法出现的时间顺序，而是按概念关系组织讨论。不过，为承认原创贡献并尊重时间顺序，图 11.1 给出了历史时间线。

11.2 特殊流映射：离散时间一致性模型




图 11.2: **流映射半群性质示意图**. 这一性质说明, 先从 s 转移至 u , 再从 u 转移至 t , 等价于直接从 s 转移至 t .

流映射的重要原则：半群性质. 一致性模型 (consistency model) (见节 11.2和11.3) 及其推广——一致性轨迹模型 (节 11.4) ——利用流映射的一种关键数学结构来定义回归目标. 这一结构就是基本的半群性质：

$$\Psi_{u \rightarrow t} \circ \Psi_{s \rightarrow u} = \Psi_{s \rightarrow t}, \quad \Psi_{s \rightarrow s} = \mathbf{I}, \quad \text{对所有 } s, u, t \in [0, T]. \quad (11.2.1)$$

直观地说, 如果先将状态从 s 演化到 u (通过 $\Psi_{s \rightarrow u}$), 再从 u 演化到 t (通过 $\Psi_{u \rightarrow t}$), 所得终点与直接从 s 演化到 t 完全相同. 这正是求解常微分方程的基本原则¹: 一旦指定流的起点, 其后续演化就完全确定, 并沿一条明确的路径进行. 无论沿这一路径走一个长步, 还是将它划分成较小区间, 我们都沿同一轨迹移动, 到达相同的最终状态.

为进一步直观理解半群性质, 考虑 PF-ODE 的解轨迹 $\{\mathbf{x}(s)\}_{s \in [0, T]}$:

$$\frac{d\mathbf{x}(\tau)}{d\tau} = \mathbf{v}^*(\mathbf{x}(\tau), \tau),$$

固定时刻 T 的初始条件 $\mathbf{x}(T)$, 沿时间反向求解. 若将终止时刻固定为 $t = 0$, 对应的流映射可简记为

$$\mathbf{f}^*(\cdot, s) := \Psi_{s \rightarrow 0}(\cdot),$$

它称为一致性函数. 按照其构造, 该函数从式 (11.2.1) 在 $t = 0$ 时的半群恒等式直接继承了以下基本性质:

¹半群 (semigroup) 性质由常微分方程初值问题的唯一性定理得出 (见章 A) .

(i) **全局一致性**: 轨迹上的每个点都映射至同一干净终点:

$$\mathbf{f}^*(\mathbf{x}(s), s) = \mathbf{x}(0), \quad \text{对所有 } s \in [0, T].$$

这是因为

$$\begin{aligned} \mathbf{f}^*(\mathbf{x}(s), s) &= \Psi_{s \rightarrow 0}(\Psi_{0 \rightarrow s}(\mathbf{x}(0))) = (\Psi_{s \rightarrow 0} \circ \Psi_{0 \rightarrow s})(\mathbf{x}(0)) \\ &= \Psi_{0 \rightarrow 0}(\mathbf{x}(0)) = \mathbf{x}(0). \end{aligned}$$

(ii) **自一致性**: 同一轨迹上的任意两点必须给出相同输出:

$$\mathbf{f}^*(\mathbf{x}(s), s) = \mathbf{f}^*(\mathbf{x}(u), u), \quad \text{对所有 } s, u \in [0, T]. \quad (11.2.2)$$

这正是对半群恒等式的直接重新解释: $\Psi_{s \rightarrow 0} \circ \Psi_{0 \rightarrow s} = \Psi_{u \rightarrow 0} \circ \Psi_{0 \rightarrow u}$.

(iii) **局部一致性**: 沿轨迹计算一致性函数时, 其值不随 s 改变:

$$\frac{d}{ds} \mathbf{f}^*(\mathbf{x}(s), s) = 0, \quad \mathbf{f}^*(\mathbf{x}(0), 0) = \mathbf{x}(0). \quad (11.2.3)$$

这由全局一致性得出, 因为全局一致性说明沿轨迹的 $\mathbf{f}^*(\mathbf{x}(s), s)$ 不随 s 改变.

这三种性质彼此等价. 它们都说明, 沿任意解轨迹 $s \mapsto \mathbf{x}(s)$, 流向原点的映射, 即一致性映射 $\mathbf{f}^*(\mathbf{x}(s), s) = \Psi_{s \rightarrow 0}(\mathbf{x}(s))$, 均给出同一终点 $\mathbf{x}(0)$, 与起始时刻无关.

一致性模型的目标. CM 旨在训练神经网络 $\mathbf{f}_\theta: \mathbb{R}^D \times [0, T] \rightarrow \mathbb{R}^D$, 以逼近特殊流映射 $\Psi_{s \rightarrow 0}$, 即一致性函数². 核心思想是在 PF-ODE 的多条轨迹上施加半群性质, 确保同一数据点的不同含噪版本一致地映射回同一干净起点 (更准确地说, 这对应于式 (11.2.1) 中 $t = 0$ 、 $u = s - \Delta s$ 的特例).

不过, 实现这一目标有多种方式, 选择取决于是否有预训练扩散模型, 以及训练是在离散时间还是连续时间下进行. 我们先在表 11.1 中概括这些变体, 并在图 11.3 中示意其目标. 后续各节 (节 11.2 和 11.3) 将逐步展开每种方法的细节.

11.2.1 学习一致性函数的离散时间近似

原则上, 可通过最小化理想损失式 (11.1.0) 学习一致性函数:

$$\mathcal{L}_{\text{oracle-CM}}(\theta) := \mathbb{E}_s \mathbb{E}_{\mathbf{x}_s \sim p_s} [w(s) d(\mathbf{f}_\theta(\mathbf{x}_s, s), \Psi_{s \rightarrow 0}(\mathbf{x}_s))].$$

这一目标要求每个含噪样本 $\mathbf{x}_s$ 都映射回其干净终点 $\Psi_{s \rightarrow 0}(\mathbf{x}_s)$.

²常微分方程的一致性函数概念可以推广至随机微分方程的函数 $\mathbf{f}(\mathbf{x}, t)$, 使 $\mathbf{f}(\mathbf{x}_t, t)$ 关于该随机微分方程的自然滤过为 (局部) 鞅, 即

$$\mathbb{E}[\mathbf{f}(\mathbf{x}_t, t) | \mathbf{x}_s] = \mathbf{f}(\mathbf{x}_s, s), \quad \text{对所有 } t \geq s.$$

这一推广由 (Daras et al., 2023; Lai et al., 2023a) 提出或观察到, 理论联系总结于 (Lai et al., 2023b).

表 11.1: 一致性模型的训练目标

	蒸馏	从头训练
离散时间	式 (11.2.4)	式 (11.2.6)
连续时间	式 (11.3.5)	式 (11.3.6)

挑战在于, 实践中无法获得理想映射 $\Psi_{s \rightarrow 0}(\mathbf{x}_s)$. 为解决这一问题, Song et al. (2023) 利用半群性质: 任意含噪状态及其沿同一 PF-ODE 轨迹相邻一步的状态, 都必须映射至同一干净终点. 具体而言, 将理想目标替换为取自轨迹上略早一点的停止梯度目标:

$$\begin{aligned}\Psi_{s \rightarrow 0}(\mathbf{x}_s) &= \Psi_{s-\Delta s \rightarrow 0}(\Psi_{s \rightarrow s-\Delta s}(\mathbf{x}_s)) \\ &\approx \mathbf{f}_{\theta^-}(\Psi_{s \rightarrow s-\Delta s}(\mathbf{x}_s), s-\Delta s), \quad \Delta s > 0,\end{aligned}$$

其中, θ^- 表示停止梯度算子下的参数. 另一个困难是, 中间状态 $\Psi_{s \rightarrow s-\Delta s}(\mathbf{x}_s)$ 同样没有闭式表达式, 因而也需要近似. 已提出以下两种实用方案:

有预训练扩散模型: 一致性蒸馏. 假设已有预训练扩散模型. 一致性蒸馏 (CD) 利用教师模型, 只模拟一次反向常微分方程步进, 即可近似中间状态 $\Psi_{s \rightarrow s-\Delta s}(\mathbf{x}_s)$:

$$\Psi_{s \rightarrow s-\Delta s}(\mathbf{x}_s) \approx \text{Solver}_{s \rightarrow s-\Delta s}(\mathbf{x}_s).$$

更具体地说, 预训练扩散模型提供得分函数估计 $\mathbf{s}_{\phi^\times}(\mathbf{x}_s, s) \approx \nabla_{\mathbf{x}_s} \log p_s(\mathbf{x}_s)$. 利用它, 可从 $\mathbf{x}_s$ 进行一次 DDIM 更新, 近似得到 $s' = s - \Delta s$ 时的状态:

$$\begin{aligned}\Psi_{s \rightarrow s-\Delta s}(\mathbf{x}_s) &\approx \frac{\alpha_{s'}}{\alpha_s} \mathbf{x}_s + \sigma_s^2 \left(\frac{\alpha_{s'}}{\alpha_s} - \frac{\sigma_{s'}}{\sigma_s} \right) \nabla_{\mathbf{x}_s} \log p_s(\mathbf{x}_s) \\ &\approx \frac{\alpha_{s'}}{\alpha_s} \mathbf{x}_s + \sigma_s^2 \left(\frac{\alpha_{s'}}{\alpha_s} - \frac{\sigma_{s'}}{\sigma_s} \right) \mathbf{s}_{\phi^\times}(\mathbf{x}_s, s) \\ &:= \tilde{\mathbf{x}}_{s'}^{\phi^\times}.\end{aligned}$$

将这一构造与停止梯度目标结合, 得到理想损失 $\mathcal{L}_{\text{oracle-CM}}(\theta)$ 的实用离散时间替代. 形式化地, 在划分 $0 = s_1 < s_2 < \dots < s_N = T$ 上, CD 的训练目标为

$$\mathcal{L}_{\text{CD}}^N(\theta, \theta^-; \phi^\times) := \mathbb{E}_{\mathbf{x}_0, \epsilon, i} \left[\omega(s_i) d(\mathbf{f}_\theta(\mathbf{x}_{s_{i+1}}, s_{i+1}), \mathbf{f}_{\theta^-}(\tilde{\mathbf{x}}_{s_i}^{\phi^\times}, s_i)) \right]. \quad (11.2.4)$$

这里, $\omega(\cdot)$ 是依赖时间的权重, $d(\cdot, \cdot)$ 是距离度量, θ^- 表示停止梯度的参数, 以防坍缩至平凡解 (例如常数预测).

无预训练扩散模型：一致性训练. 即使没有预训练扩散模型，仍可使用简单的单点近似直接估计理想得分 $\nabla_{\mathbf{x}} \log p_s(\mathbf{x}_s)$ （尽管方差较大）。回顾它的条件期望形式：

$$\begin{aligned}\nabla_{\mathbf{x}_s} \log p_s(\mathbf{x}_s) &= \mathbb{E}_{\mathbf{x}_0 \sim p(\mathbf{x}_0|\mathbf{x}_s)} [\nabla_{\mathbf{x}_s} \log p(\mathbf{x}_s|\mathbf{x}_0)] \\ &= \mathbb{E}_{\mathbf{x}_0 \sim p(\mathbf{x}_0|\mathbf{x}_s)} \left[-\frac{\mathbf{x}_s - \alpha_s \mathbf{x}_0}{\sigma_s^2} \right].\end{aligned}$$

上述恒等式给出了一个简单的单样本估计器。若 $\mathbf{x}_s$ 由配对样本 $(\mathbf{x}_0, \epsilon)$ 通过 $\mathbf{x}_s = \alpha_s \mathbf{x}_0 + \sigma_s \epsilon$ 构造，则

$$\widehat{\nabla_{\mathbf{x}} \log p_s(\mathbf{x}_s)} := -\frac{\epsilon}{\sigma_s} = -\frac{\mathbf{x}_s - \alpha_s \mathbf{x}_0}{\sigma_s^2}$$

是 $\mathbf{x}_s$ 处得分的无偏估计（关于 $p(\mathbf{x}_0|\mathbf{x}_s)$ 条件无偏）。它恰好对应于去噪得分匹配中作为回归目标的条件得分。

将这一估计代入从 s 到 $s' = s - \Delta s$ 的 DDIM 单步更新（见式 (9.2.3)），得到

$$\begin{aligned}\Psi_{s \rightarrow s'}(\mathbf{x}_s) &\approx \frac{\alpha_{s'}}{\alpha_s} \mathbf{x}_s + \sigma_s^2 \left(\frac{\alpha_{s'}}{\alpha_s} - \frac{\sigma_{s'}}{\sigma_s} \right) \nabla_{\mathbf{x}_s} \log p_s(\mathbf{x}_s) \quad (\text{DDIM}) \\ &\approx \frac{\alpha_{s'}}{\alpha_s} \mathbf{x}_s + \sigma_s^2 \left(\frac{\alpha_{s'}}{\alpha_s} - \frac{\sigma_{s'}}{\sigma_s} \right) \widehat{\nabla_{\mathbf{x}_s} \log p_s(\mathbf{x}_s)} \quad (\text{单点得分}) \\ &= \frac{\alpha_{s'}}{\alpha_s} \mathbf{x}_s - \left(\frac{\alpha_{s'}}{\alpha_s} - \frac{\sigma_{s'}}{\sigma_s} \right) (\mathbf{x}_s - \alpha_s \mathbf{x}_0) \\ &= \alpha_{s'} \mathbf{x}_0 + \sigma_{s'} \epsilon,\end{aligned} \tag{11.2.5}$$

其中³， $\mathbf{x}_0$ 与 ϵ 分别是构造 $\mathbf{x}_s$ 时使用的同一数据样本与同一高斯噪声。

由此得到不依赖教师的、理想目标 $\mathcal{L}_{\text{oracle-CM}}$ 的离散时间替代，写为

$$\mathcal{L}_{\text{CT}}^N(\theta, \theta^-) := \mathbb{E}_{\mathbf{x}_0, \epsilon, i} [\omega(s_i) d(\mathbf{f}_\theta(\mathbf{x}_{s_{i+1}}, s_{i+1}), \mathbf{f}_{\theta^-}(\mathbf{x}_{s_i}, s_i))], \tag{11.2.6}$$

其中 $\mathbf{x}_{s_i} = \alpha_{s_i} \mathbf{x}_0 + \sigma_{s_i} \epsilon$ ， $\mathbf{x}_{s_{i+1}} = \alpha_{s_{i+1}} \mathbf{x}_0 + \sigma_{s_{i+1}} \epsilon$ 。

直接用 $\alpha_{s'} \mathbf{x}_0 + \sigma_{s'} \epsilon$ 近似 $\Psi_{s \rightarrow s'}(\mathbf{x}_s)$ 而不取期望，会引入很大的方差⁴。不过，回顾去噪得分匹配中的类似情形（见节 6.1）：单个条件得分样本作为训练目标，而在损失中对 $\mathbf{x}_0, \epsilon$ 取平均后就成为无偏的。同理， $\mathcal{L}_{\text{CT}}^N$ 中对 $\mathbf{x}_0$ 和 ϵ 的期望会平均掉这一采样噪声，在损失层面得到无偏近似。以下定理形式化地说明单点估计器在期望层面的合理性。

³最后一个恒等式由前向加噪过程 $\mathbf{x}_s = \alpha_s \mathbf{x}_0 + \sigma_s \epsilon$ 经初等代数运算直接得出。

⁴单点（条件）得分估计 $\widehat{\nabla_{\mathbf{x}} \log p_s(\mathbf{x}_s)}$ 可视为单样本 Monte Carlo 估计器，在给定 $\mathbf{x}_s$ 时条件无偏：关于（通常不可直接计算的）干净后验 $p(\cdot|\mathbf{x}_s)$ 对该估计器取平均，即恢复真实得分：

$$\nabla_{\mathbf{x}_s} \log p_s(\mathbf{x}_s) = \mathbb{E}_{\mathbf{x}_0 \sim p(\cdot|\mathbf{x}_s)} [\widehat{\nabla_{\mathbf{x}} \log p_s(\mathbf{x}_s)}].$$

定理 11.2.1: 误差为 $\mathcal{O}(\Delta s^2)$ 的 CM-CT 等价性

令 $s' := s - \Delta s$, 并定义

$$\begin{aligned}\mathcal{L}_{\text{CM}}(\boldsymbol{\theta}, \boldsymbol{\theta}^-) &:= \mathbb{E}_{s, \mathbf{x}_0, \epsilon} \left[w(s) d(\mathbf{f}_{\boldsymbol{\theta}}(\mathbf{x}_s, s), \mathbf{f}_{\boldsymbol{\theta}^-}(\mathbf{x}_{s'}^{\text{DDIM}}, s')) \right], \\ \mathcal{L}_{\text{CT}}(\boldsymbol{\theta}, \boldsymbol{\theta}^-) &:= \mathbb{E}_{s, \mathbf{x}_0, \epsilon} \left[w(s) d(\mathbf{f}_{\boldsymbol{\theta}}(\mathbf{x}_s, s), \mathbf{f}_{\boldsymbol{\theta}^-}(\mathbf{x}_{s'}, s')) \right],\end{aligned}$$

其中

$$\mathbf{x}_{s'}^{\text{DDIM}} := \frac{\alpha_{s'}}{\alpha_s} \mathbf{x}_s + \sigma_s^2 \left(\frac{\alpha_{s'}}{\alpha_s} - \frac{\sigma_{s'}}{\sigma_s} \right) \nabla_{\mathbf{x}_s} \log p_s(\mathbf{x}_s)$$

是理想 DDIM 更新. $\mathbf{x}_s = \alpha_s \mathbf{x}_0 + \sigma_s \epsilon$ 与 $\mathbf{x}_{s'} = \alpha_{s'} \mathbf{x}_0 + \sigma_{s'} \epsilon$ 使用同一对 $(\mathbf{x}_0, \epsilon)$, 其中 $\mathbf{x}_0 \sim p_{\text{data}}$, $\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$. 那么,

$$\mathcal{L}_{\text{CM}}(\boldsymbol{\theta}, \boldsymbol{\theta}^-) = \mathcal{L}_{\text{CT}}(\boldsymbol{\theta}, \boldsymbol{\theta}^-) + \mathcal{O}(\Delta s^2).$$

定理的证明.

首先, 注意使用理想得分的 DDIM 更新等于条件均值:

$$\mathbf{x}_{s'}^{\text{DDIM}} = \mathbb{E}[\mathbf{x}_{s'} | \mathbf{x}_s],$$

这也可以通过在式 (11.2.5) 中关于 $p(\cdot | \mathbf{x}_s)$ 取期望来验证. 接下来, 将

$$d(\mathbf{f}_{\boldsymbol{\theta}}(\mathbf{x}_s, s), \mathbf{f}_{\boldsymbol{\theta}^-}(\cdot, s'))$$

在 $\mathbf{x}_{s'}^{\text{DDIM}} = \mathbb{E}[\mathbf{x}_{s'} | \mathbf{x}_s]$ 附近作 Taylor 展开. 由于内部期望关于 $\mathbf{x}_{s'} | \mathbf{x}_s$ 计算, 满足 $\mathbb{E}[\mathbf{x}_{s'} - \mathbf{x}_{s'}^{\text{DDIM}} | \mathbf{x}_s] = 0$, Taylor 展开的线性项为零. 这表明, 将条件期望重参数化为 $\mathbb{E}_{\mathbf{x}_0, \epsilon | \mathbf{x}_s}[\cdot]$, 其中 $\mathbf{x}_{s'} = \alpha_{s'} \mathbf{x}_0 + \sigma_{s'} \epsilon$ 后, 使用单点得分的 DDIM 更新对同一对 $(\mathbf{x}_0, \epsilon)$ 逐路径精确恢复 $\mathbf{x}_{s'}$, 因而保持内部期望不变. 剩余项为二次项 $\mathcal{O}(\Delta s^2)$, 故 $\mathcal{L}_{\text{CT}} = \mathcal{L}_{\text{CM}} + \mathcal{O}(\Delta s^2)$. 详细推导见节 D.5. ■

总之, CD 利用教师模型进行初始化和引导, 通常能够稳定优化并降低方差. 一致性训练 (CT) 则不需要预训练模型, 因此可以完全从头训练. 尽管存在这一差别, CT 仍构成一个完全独立的生成模型.

实践中的考虑. 实践中, Song et al. (2023) 采用 Karras et al. (2022) 的 EDM 表述 (见节 D.6), 使用前向加噪核

$$\mathbf{x}_s = \mathbf{x}_0 + s\epsilon,$$

以及其中提出的神经网络参数化 (参见式 (D.6.1)):

$$\mathbf{f}_{\boldsymbol{\theta}}(\mathbf{x}, s) = c_{\text{skip}}(s)\mathbf{x} + c_{\text{out}}(s) \mathbf{F}_{\boldsymbol{\theta}}(c_{\text{in}}(s)\mathbf{x}, c_{\text{noise}}(s)),$$

其中, $\mathbf{F}_\theta$ 是神经网络, 系数遵循式 (D.6.5). 这一参数化具有重要的边界性质:

$$\mathbf{f}_\theta(\mathbf{x}, 0) = \mathbf{x},$$

它施加了零时刻的一致性, 保证没有噪声时网络输出与输入相同.

11.2.2 使用一致性模型采样

一致性模型 $\mathbf{f}_{\theta^\times}$ 在连续时间或离散时间下训练完成后, 都可以用一步或少数几步生成样本. 算法概括于算法 9.

一步生成. 给定从先验分布 (实践中为 $\mathcal{N}(\mathbf{0}, T^2\mathbf{I})$) 采样的初始潜变量 $\hat{\mathbf{x}}_T$, 只需一次函数求值即可生成干净样本:

$$\mathbf{f}_{\theta^\times}(\hat{\mathbf{x}}_T, T).$$

多步生成. 预先选择时间步

$$T > \tau_1 > \tau_2 > \cdots > \tau_{M-1} = 0,$$

从初始噪声 $\hat{\mathbf{x}}_T$ 出发, 在注入噪声与通过较早时间点的一致性模型大幅跳跃到干净状态之间交替进行, 逐渐改善样本:

$$\hat{\mathbf{x}}_T \xrightarrow[\text{得到干净样本}]{\text{长跳跃}} \mathbf{f}_{\theta^\times}(\hat{\mathbf{x}}_T, T) \xrightarrow[\text{至水平 } \tau_1]{\text{加噪}} \hat{\mathbf{x}}_{\tau_1} \xrightarrow[\text{得到干净样本}]{\text{长跳跃}} \mathbf{f}_{\theta^\times}(\hat{\mathbf{x}}_{\tau_1}, \tau_1) \xrightarrow[\text{至水平 } \tau_2]{\text{加噪}} \cdots$$

算法 9 CM 的一步或多步生成采样

输入: 一致性模型 $\mathbf{f}_{\theta^\times}(\cdot, \cdot)$ 、时间点序列 $T > \tau_1 > \tau_2 > \cdots > \tau_{M-1} = 0$ 、初始噪声 $\hat{\mathbf{x}}_T$

1: **如果** 一步生成 **则**

2: $\mathbf{x} \leftarrow \mathbf{f}_{\theta^\times}(\hat{\mathbf{x}}_T, T)$

3: **否则**

4: $\mathbf{x} \leftarrow \mathbf{f}_{\theta^\times}(\hat{\mathbf{x}}_T, T)$

5: **对于** $m = 1$ **至** $M - 1$ **执行**

6: 采样 $\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$

7: $\hat{\mathbf{x}}_{\tau_m} \leftarrow \alpha_{\tau_m} \mathbf{x} + \sigma_{\tau_m} \epsilon$

8: $\mathbf{x} \leftarrow \mathbf{f}_{\theta^\times}(\hat{\mathbf{x}}_{\tau_m}, \tau_m)$

9: **结束 对于**

10: **结束 如果**

输出: $\mathbf{x}$

11.3 特殊流映射：连续时间一致性模型

现在超越一致性模型的离散时间设置，考虑连续时间视角。离散方法固定时间网格，仅在这些采样点上训练；连续表述则将流映射视为在所有时刻上定义。这一转变消除了对任意离散化的依赖，使模型与底层动力学之间的对应更有理论依据。它还有助于减少离散积分自然产生的近似误差，并确保全局施加一致性，而非只在选定步骤上施加。

11.3.1 连续时间一致性模型

为引出连续时间表述，首先回顾式 (11.2.3)，它描述了对时间求导时的条件。利用链式法则，得到

$$\begin{aligned} \frac{d}{ds} \mathbf{f}^*(\mathbf{x}(s), s) &= 0 \\ \iff (\nabla_{\mathbf{x}} \mathbf{f}^*)(\mathbf{x}(s), s) \cdot \underbrace{\frac{d}{ds} \mathbf{x}(s)}_{\text{常微分方程速度}} + \left(\frac{\partial}{\partial s} \mathbf{f}^* \right)(\mathbf{x}(s), s) &= 0, \end{aligned} \quad (11.3.1)$$

其中，轨迹 $\mathbf{x}(s)$ 遵循 PF-ODE：

$$\frac{d}{ds} \mathbf{x}(s) = \mathbf{v}^*(\mathbf{x}(s), s).$$

这一关系说明，一致性函数 $\mathbf{f}^*$ 沿常微分方程的任意解轨迹保持常数。实践中，速度场 $\mathbf{v}^*$ 可由预训练扩散模型估计（若有这样的模型），也可通过直接的单点近似估计，例如 $\alpha'_s \mathbf{x}_0 + \sigma'_s \boldsymbol{\epsilon}$ ，如节 11.2 所述。

式 (11.3.1) 给出了设计连续时间训练目标的一种自然方式。一种做法是通过最小化残差施加该条件，类似于物理信息神经网络 (PINN) (Raissi, 2018; Boffi, Albergo, and Vanden-Eijnden, 2024)：

$$\min_{\boldsymbol{\theta}} \mathbb{E}_{s, \mathbf{x}_0, \boldsymbol{\epsilon}} \left[\left\| \frac{d}{ds} \mathbf{f}_{\boldsymbol{\theta}}(\mathbf{x}_s, s) \right\|_2^2 \right].$$

不过，Song et al. (2023) and Lu and Song (2024) 在实践中观察到，另一种表述的训练效果更好。他们不直接施加微分条件，而是考虑离散近似在 $\Delta s \rightarrow 0$ 时的连续时间极限：

$$\mathcal{L}_{\text{CM}}^{\Delta s}(\boldsymbol{\theta}, \boldsymbol{\theta}^-) := \mathbb{E} \left[\omega(s) \left\| \mathbf{f}_{\boldsymbol{\theta}}(\mathbf{x}_s, s) - \mathbf{f}_{\boldsymbol{\theta}^-}(\boldsymbol{\Psi}_{s \rightarrow s - \Delta s}(\mathbf{x}_s), s - \Delta s) \right\|_2^2 \right]. \quad (11.3.2)$$

在式 (11.3.2) 中取极限 $\Delta s \rightarrow 0$ ，等价于在式 (11.2.4) 和 (11.2.6) 中令时间步数 $N \rightarrow \infty$ 。

以下命题概括了这一关键思想。

命题 11.3.1: 连续时间一致性训练

以下收敛结果成立：

$$\lim_{\Delta s \rightarrow 0} \frac{1}{\Delta s} \nabla_{\theta} \mathcal{L}_{\text{CM}}^{\Delta s}(\theta, \theta^-) = \nabla_{\theta} \mathcal{L}_{\text{CM}}^{\infty}(\theta, \theta^-).$$

这里，

$$\mathcal{L}_{\text{CM}}^{\infty}(\theta, \theta^-) := \mathbb{E}_{s, \mathbf{x}_0, \epsilon} \left[2\omega(t) \mathbf{f}_{\theta}^{\top}(\mathbf{x}_s, s) \cdot \frac{d}{ds} \mathbf{f}_{\theta^-}(\mathbf{x}_s, s) \right],$$

且有全微分恒等式：

$$\frac{d}{ds} \mathbf{f}_{\theta^-}(\mathbf{x}_s, s) = \partial_s \mathbf{f}_{\theta^-}(\mathbf{x}_s, s) + (\partial_{\mathbf{x}} \mathbf{f}_{\theta^-}(\mathbf{x}_s, s)) \mathbf{v}^*(\mathbf{x}_s, s). \quad (11.3.3)$$

命题的证明。

将停止梯度目标在 $(\mathbf{x}_s, s)$ 附近作一阶 Taylor 展开可知，在 $\mathcal{O}(\Delta s^2)$ 误差内，损失 $\mathcal{L}_{\text{CM}}^{\Delta s}$ 的行为类似于学生更新 $\nabla_{\theta} \mathbf{f}_{\theta}(\mathbf{x}_s, s)$ 与切向变化 $\frac{d}{ds} \mathbf{f}_{\theta^-}(\mathbf{x}_s, s)$ 的内积。因而，缩放后的梯度满足

$$\lim_{\Delta s \rightarrow 0} \frac{1}{\Delta s} \nabla_{\theta} \mathcal{L}_{\text{CM}}^{\Delta s} = \nabla_{\theta} \mathbb{E} \left[\tilde{\omega}(s) \mathbf{f}_{\theta}^{\top}(\mathbf{x}_s, s) \cdot \frac{d}{ds} \mathbf{f}_{\theta^-}(\mathbf{x}_s, s) \right],$$

这就是所述恒等式。证明留待节 D.5 给出。 ■

上述结果写在梯度算子 ∇_{θ} 下，使涉及 θ^- 的项消失，因为停止梯度时 θ^- 被视为常数。注意， $\frac{d}{ds} \mathbf{f}_{\theta^-}(\mathbf{x}_s, s)$ 表示沿理想轨迹的全导数，而非简单的时间偏导数。

总之，可通过最小化以下目标训练连续时间一致性模型（忽略因子 2）：

$$\mathcal{L}_{\text{CM}}^{\infty}(\theta, \theta^-) := \mathbb{E}_{s, \mathbf{x}_0, \epsilon} \left[\omega(s) \mathbf{f}_{\theta}^{\top}(\mathbf{x}_s, s) \cdot \frac{d}{ds} \mathbf{f}_{\theta^-}(\mathbf{x}_s, s) \right]. \quad (11.3.4)$$

11.3.2 连续时间一致性模型的训练

类似于节 11.2.1 讨论的离散时间情形，现在说明如何在实践中近似式 (11.3.4) 中的切向项，该项涉及无法直接获得的理想速度 $\mathbf{v}^*$ ：

$$\frac{d}{ds} \mathbf{f}_{\theta^-}(\mathbf{x}_s, s) = \partial_s \mathbf{f}_{\theta^-}(\mathbf{x}_s, s) + (\partial_{\mathbf{x}} \mathbf{f}_{\theta^-}(\mathbf{x}_s, s)) \mathbf{v}^*(\mathbf{x}_s, s).$$

连续时间 CM 训练完成后，采用与离散时间情形相同的采样流程（节 11.2.2）。

连续时间一致性蒸馏. 若已有预训练扩散模型, 使 $\mathbf{v}_{\phi^\times} \approx \mathbf{v}^*$, 则式 (11.3.3) 中的切向量 $\frac{d}{ds}\mathbf{f}_{\theta^-}(\mathbf{x}_s, s)$ 可用下式近似:

$$\frac{d}{ds}\mathbf{f}_{\theta^-}(\mathbf{x}_s, s) \approx \partial_s \mathbf{f}_{\theta^-}(\mathbf{x}_s, s) + (\partial_{\mathbf{x}} \mathbf{f}_{\theta^-}(\mathbf{x}_s, s)) \mathbf{v}_{\phi^\times}(\mathbf{x}_s, s). \quad (11.3.5)$$

将所得目标记为 $\mathcal{L}_{\text{CD}}^\infty(\boldsymbol{\theta}, \boldsymbol{\theta}^-; \phi^\times)$. 相应地, 命题 11.3.1 可重述为

$$\lim_{N \rightarrow \infty} N \nabla_{\boldsymbol{\theta}} \mathcal{L}_{\text{CD}}^N(\boldsymbol{\theta}, \boldsymbol{\theta}^-; \phi^\times) = \nabla_{\boldsymbol{\theta}} \mathcal{L}_{\text{CD}}^\infty(\boldsymbol{\theta}, \boldsymbol{\theta}^-; \phi^\times).$$

连续时间一致性训练: 从头训练. 另一方面, 若没有预训练扩散模型, 则可使用单点条件估计 $\alpha'_s \mathbf{x}_0 + \sigma'_s \epsilon$ 近似理想速度 $\mathbf{v}^*$. 此时, 式 (11.3.3) 中的切向量 $\frac{d}{ds}\mathbf{f}_{\theta^-}(\mathbf{x}_s, s)$ 由下式替代:

$$\frac{d}{ds}\mathbf{f}_{\theta^-}(\mathbf{x}_s, s) \approx \partial_s \mathbf{f}_{\theta^-}(\mathbf{x}_s, s) + (\partial_{\mathbf{x}} \mathbf{f}_{\theta^-}(\mathbf{x}_s, s)) (\alpha'_s \mathbf{x}_0 + \sigma'_s \epsilon). \quad (11.3.6)$$

将所得目标记为 $\mathcal{L}_{\text{CT}}^\infty(\boldsymbol{\theta}, \boldsymbol{\theta}^-)$, 它对应从头训练的设置. 相应地, 命题 11.3.1 可重述为

$$\lim_{N \rightarrow \infty} N \nabla_{\boldsymbol{\theta}} \mathcal{L}_{\text{CT}}^N(\boldsymbol{\theta}, \boldsymbol{\theta}^-) = \nabla_{\boldsymbol{\theta}} \mathcal{L}_{\text{CT}}^\infty(\boldsymbol{\theta}, \boldsymbol{\theta}^-).$$

至此, 已介绍表 11.1 列出的全部基本方法, 以实现一致性函数 $\Psi_{s \rightarrow 0}$ 的学习. 为提供更清晰的概览, 图 11.3 总结了用于训练一致性函数的不同损失函数之间的关系. 该图也表明各方法是否依赖预训练扩散模型, 并区分连续时间与离散时间目标.




图 11.3: 在 ℓ_2 距离度量 $d(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\|_2^2$ 下, 离散 / 连续时间 CD 与 CT 之间的关系图. 标注的定理沿用 (Song et al., 2023) 中的编号. 只要定理涉及 CT, 就假设得分完全准确: $\mathbf{s}_{\phi^\times}(\mathbf{x}, t) \equiv \nabla_{\mathbf{x}} \log p_t(\mathbf{x})$. $\mathcal{L}_{\text{CT}}^\infty$ 定义于式 (11.3.4), 而 $\mathcal{L}_{\text{CD}}^\infty$ 定义于式 (11.3.5).

然而, 切向量 $\frac{d}{ds}\mathbf{f}_{\theta^-}$ 往往导致训练不稳定. 在以下选读小节中, 我们介绍连续时间一致性模型的简化、稳定化与规模扩展 (sCM) (Lu and Song, 2024) 中缓解这些问题的技术.

11.3.3 (选读) 连续时间一致性训练的实践考虑

我们关注从头训练的情形，因为它产生了不依赖外部预训练扩散模型的独立生成模型。因此，讨论着重于连续时间情形。

不过，实践中直接使用式 (11.3.4) 训练往往不稳定，因为 $\frac{d}{ds}\mathbf{f}_\theta$ 项的时间导数可能很大或无界，导致优化时梯度爆炸。为解决这一问题，通常需要适当的参数化和稳定化策略 (Geng et al., 2025b; Lu and Song, 2024)。如节 6.2.2 所总结，影响稳定训练的主要因素包括扩散过程、参数化选择、时间权重函数和时间采样分布；在连续时间 CM 中，同样应对这些因素仔细设计并进行解耦。

扩散过程。 Lu and Song (2024) 采用三角函数调度，替代标准扩散参数化 $\mathbf{x}_s = \alpha_s \mathbf{x}_0 + \sigma_s \epsilon$ ，其中 $\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 。尽管这一调度在数学上与原形式等价（如式 (6.3.4) 所示），它为训练目标提供了更清晰的结构和更好的分离，从而有助于改善训练稳定性⁵。此外，他们引入数据分布 p_{data} 的标准差 σ_d ，与节 D.6.1 中 EDM 的设计一致：

$$\mathbf{x}_s := \cos(s)\mathbf{x}_0 + \sin(s)\mathbf{z}, \quad \text{其中 } \mathbf{z} \sim \mathcal{N}(\mathbf{0}, \sigma_d^2 \mathbf{I}). \quad (11.3.7)$$

这一表述完全一般。对任意形式为 $\mathbf{x}_s = \alpha_s \mathbf{x}_0 + \sigma_s \epsilon$ 的扩散过程，其中 $\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ ，都可以等价地写为：

$$\mathbf{x}_s = \alpha_s \mathbf{x}_0 + \frac{\sigma_s}{\sigma_d} \cdot (\sigma_d \epsilon),$$

这里定义 $\mathbf{z} := \sigma_d \epsilon$ 、 $\alpha'_s := \alpha_s$ 和 $\sigma'_s := \frac{\sigma_s}{\sigma_d}$ 。随后，利用式 (6.3.5) 描述的归一化，可将变换后的 (α'_s, σ'_s) 映射至三角函数形式 $(\cos(s), \sin(s))$ 。

参数化。 参考节 D.6.1 中 EDM 的类似原则，Lu and Song (2024) 提出如下神经网络参数化，与式 (D.6.1) 类似：

$$\mathbf{f}_\theta(\mathbf{x}, s) := c_{\text{skip}}(s)\mathbf{x} + c_{\text{out}}(s)\mathbf{F}_\theta(c_{\text{in}}(s)\mathbf{x}, c_{\text{noise}}(s)).$$

这里， $c_{\text{skip}}(s)$ 、 $c_{\text{out}}(s)$ 与 $c_{\text{in}}(s)$ 可按节 D.6.1 中的相同准则推导（详细推导见 Lu and Song (2024) 的附录 B），结果为

$$c_{\text{skip}}(s) = \cos(s), \quad c_{\text{out}}(s) = -\sigma_d \sin(s), \quad c_{\text{in}}(s) \equiv \frac{1}{\sigma_d}.$$

同时采用默认选择 $c_{\text{noise}}(s) = s$ ，其中 $\partial_s c_{\text{noise}}(s)$ 有界，以保证训练稳定性，相关讨论见式 (11.3.10) 附近。由此得到三角函数调度下的参数化：

$$\mathbf{f}_\theta(\mathbf{x}, s) = \cos(s)\mathbf{x} - \sin(s)\sigma_d \mathbf{F}_\theta\left(\frac{\mathbf{x}}{\sigma_d}, c_{\text{noise}}(s)\right). \quad (11.3.8)$$

注意，这一参数化还保证神经网络对所有 $\mathbf{x}$ 始终满足边界条件 $\mathbf{f}_\theta(\mathbf{x}, 0) \equiv \mathbf{x}$ ，这是一致性函数的必要性质。

⁵直观地说，三角函数及其导数都有界，这有助于防止 $\frac{d}{ds}\mathbf{f}_\theta$ 等项的尺度爆炸。后文将详细讨论。

稳定切向训练的技术. 采用三角函数调度及式 (11.3.8) 描述的网络参数化后, 式 (11.3.4) 中损失的梯度变为

$$\nabla_{\theta} \mathcal{L}_{\text{CT}}^{\infty}(\theta, \theta^{-}) = \nabla_{\theta} \mathbb{E}_{s, \mathbf{x}_0, \epsilon} \left[-\omega(s) \sigma_d \sin(s) \mathbf{F}_{\theta}^{\top} \left(\frac{\mathbf{x}_s}{\sigma_d}, s \right) \cdot \frac{d\mathbf{f}_{\theta^{-}}}{ds}(\mathbf{x}_s, s) \right]. \quad (11.3.9)$$

理论上, 使用式 (11.3.9) 中的梯度更新训练, 可能已足以学习一致性函数. 然而, Lu and Song (2024) 在实验中观察到, 实践中切向函数的行为可能使训练过程不稳定, 该函数为

$$\underbrace{\frac{d\mathbf{f}_{\theta^{-}}(\mathbf{x}_s, s)}{ds}}_{\text{A.}} = -\cos(s) \left(\sigma_d \nabla_{\mathbf{x}_s} \mathbf{F}_{\theta^{-}} \left(\frac{\mathbf{x}_s}{\sigma_d}, s \right) - \frac{d\mathbf{x}_s}{ds} \right) - \sin(s) \left(\mathbf{x}_s + \sigma_d \frac{d\mathbf{F}_{\theta^{-}}}{ds} \left(\frac{\mathbf{x}_s}{\sigma_d}, c_{\text{noise}}(s) \right) \right).$$

特别地, 以下项中观察到了不稳定性:

$$\underbrace{\sin(s) \frac{d\mathbf{F}_{\theta^{-}}}{ds} \left(\frac{\mathbf{x}_s}{\sigma_d}, c_{\text{noise}}(s) \right)}_{\text{B.}} = \sin(s) \nabla_{\mathbf{x}_s} \mathbf{F}_{\theta^{-}} \frac{d\mathbf{x}_s}{ds} + \sin(s) \partial_s \mathbf{F}_{\theta^{-}}.$$

更具体地说, 不稳定性来自如下分量:

$$\sin(s) \partial_s \mathbf{F}_{\theta^{-}} = \sin(s) \underbrace{\frac{\partial c_{\text{noise}}(s)}{\partial s} \cdot \frac{\partial \text{emb}(c_{\text{noise}})}{\partial c_{\text{noise}}}}_{\text{C.}} \cdot \frac{\partial \mathbf{F}_{\theta^{-}}}{\partial \text{emb}(c_{\text{noise}})}. \quad (11.3.10)$$

这里遵循扩散模型和一致性模型文献中的常见做法, 对时间变量 $c_{\text{noise}}(s)$ 应用位置嵌入或 Fourier 嵌入, 记为 $\text{emb}(\cdot)$:

$$s \mapsto c_{\text{noise}}(s) \mapsto \text{emb}(c_{\text{noise}}(s)) \mapsto \mathbf{F}_{\theta^{-}} \left(\frac{\mathbf{x}_s}{\sigma_d}, \text{emb}(c_{\text{noise}}(s)) \right).$$

因此, 引入一些额外的经验技术来缓解不稳定性:

- **A. 切向归一化.** 显式归一化切向函数, 将 $\frac{d}{ds} \mathbf{f}_{\theta^{-}}$ 替换为 $\frac{\frac{d}{ds} \mathbf{f}_{\theta^{-}}}{\left\| \frac{d}{ds} \mathbf{f}_{\theta^{-}} \right\|_2 + c}$, 其中 $c > 0$ 是按经验设定的常数. 另一种方法是将切向量截断在 $[-1, 1]$ 内, 这也能有效限制其方差.
- **B. 切向预热.** 由于 $\sin(s)(\mathbf{x}_s + \sigma_d \frac{d}{ds} \mathbf{F}_{\theta^{-}})$ 项可能导致不稳定, 可选择将系数 $\sin(s)$ 替换为 $r \cdot \sin(s)$, 其中 r 在最初若干次训练迭代中从 0 线性增加到 1.
- **C. 时间嵌入.** 考虑式 (11.3.10) 中的导数链, Lu and Song (2024) 选择了幅度较小的参数, 以控制导数 $\frac{\partial \text{emb}(c_{\text{noise}})}{\partial c_{\text{noise}}}$. 出于类似原因, 取 $c_{\text{noise}}(s) = s$, 此时 $\partial_s c_{\text{noise}}(s) = 1$ 是有界常数.

此外, 通常还需改变网络架构, 以改进归一化 (提高稳定性), 并利用雅可比矩阵与向量乘积 (JVP) 高效计算 $\frac{d}{ds} \mathbf{f}_{\theta^{-}}$, 但这些内容超出本书范围.

时间权重函数. 手工设计时间权重函数 $\omega(s)$ 可能无法达到最优性能. 为解决这一问题, Lu and Song (2024) 采用类似 EDM-2 (Karras et al., 2024) 的方法, 学习自适应权重函数 $\omega_\varphi(s)$, 平衡不同时间 s 下训练损失的方差 (所需结果见式 (11.3.11)).

进一步说明, 式 (11.3.9) 中的目标函数具有如下形式:

$$\mathbb{E}_{s, \mathbf{x}_0, \epsilon} [\mathbf{F}_\theta^\top \mathbf{y}], \quad \text{其中} \quad \mathbf{y} = -\omega(s) \sigma_d \sin(s) \frac{d\mathbf{f}_{\theta^-}}{ds}.$$

由于 $\mathbf{y}$ 是与 θ 无关的向量, 式 (11.3.9) 等价于

$$\nabla_\theta \mathbb{E}_{s, \mathbf{x}_0, \epsilon} [\mathbf{F}_\theta^\top \mathbf{y}] = \frac{1}{2} \nabla_\theta \mathbb{E}_{s, \mathbf{x}_0, \epsilon} \|\mathbf{F}_\theta - \mathbf{F}_{\theta^-} + \mathbf{y}\|_2^2.$$

基于这一观察, Lu and Song (2024) 提出额外训练自适应权重网络 $\omega_\varphi(s)$, 以估计损失范数, 表述为如下最小化问题:

$$\min_{\varphi} \mathbb{E}_{s, \mathbf{x}_0, \epsilon} \left[\frac{e^{\omega_\varphi(s)}}{D} \|\mathbf{F}_\theta - \mathbf{F}_{\theta^-} + \mathbf{y}\|_2^2 - \omega_\varphi(s) \right].$$

为理解自适应权重的作用, 注意最优解 $\omega^*(s)$ (通过对上述目标关于 ω_φ 求偏导得到) 满足

$$\mathbb{E}_{s, \mathbf{x}_0, \epsilon} \left[\frac{e^{\omega^*(s)}}{D} \|\mathbf{F}_\theta - \mathbf{F}_{\theta^-} + \mathbf{y}\|_2^2 \right] = 1. \quad (11.3.11)$$

也就是说, 重新缩放后, 不同 s 下的期望 (加权) 损失保持一致. 因此, 自适应权重有效减少了不同时间步之间训练损失的方差, 使训练更加平衡、稳定.

时间采样分布. Lu and Song (2024) 选择从对数正态提议分布 (Karras et al., 2022) 采样 $\tan(s)$, 即

$$e^{\sigma_d \tan(s)} \sim \mathcal{N}(\cdot; P_{\text{mean}}, P_{\text{std}}^2). \quad (11.3.12)$$

这里, P_{mean} 与 P_{std} 是两个超参数.

训练目标总结. 综合上述讨论, 最终训练损失表示为:

$$\mathcal{L}_{\text{sCM}}(\theta, \varphi) := \mathbb{E}_{s, \mathbf{x}_0, \epsilon} \left[\frac{e^{\omega_\varphi(s)}}{D} \left\| \mathbf{F}_\theta \left(\frac{\mathbf{x}_s}{\sigma_d}, s \right) - \mathbf{F}_{\theta^-} \left(\frac{\mathbf{x}_s}{\sigma_d}, s \right) - \cos(s) \frac{d\mathbf{f}_{\theta^-}}{ds}(\mathbf{x}_s, s) \right\|_2^2 - \omega_\varphi(s) \right].$$

这里, 按式 (11.3.12) 采样 s , 通过式 (11.3.7) 计算 $\mathbf{x}_s$. 用这一损失训练的模型称为 $s\text{CM}$, 其训练过程概括于算法 10.

算法 10 连续时间一致性模型 (sCM) 的训练

输入： 标准差为 σ_d 的数据集 $\mathcal{D}$ 、参数为 θ_{pretrain} 的预训练扩散模型 $\mathbf{F}_{\text{pretrain}}$ 、模型 $\mathbf{F}_\theta$ 、权重 ω_φ 、学习率 η 、提议分布参数 $(P_{\text{mean}}, P_{\text{std}})$ 、常数 c 、预热迭代数 H

- 1: **初始化：** $\theta \leftarrow \theta_{\text{pretrain}}, \text{Iters} \leftarrow 0$
 - 2: **重复**
 - 3: $\mathbf{x}_0 \sim \mathcal{D}, \mathbf{z} \sim \mathcal{N}(\mathbf{0}, \sigma_d^2 \mathbf{I}), \tau \sim \mathcal{N}(P_{\text{mean}}, P_{\text{std}}^2), s \leftarrow \arctan\left(\frac{e^\tau}{\sigma_d}\right)$
 - 4: $\mathbf{x}_s \leftarrow \cos(s)\mathbf{x}_0 + \sin(s)\mathbf{z}$
 - 5: **如果** 一致性训练 **则**
 - 6: $\frac{d\mathbf{x}_s}{ds} \leftarrow \cos(s)\mathbf{z} - \sin(s)\mathbf{x}_0$
 - 7: **否则**
 - 8: $\frac{d\mathbf{x}_s}{ds} \leftarrow \sigma_d \mathbf{F}_{\text{pretrain}}\left(\frac{\mathbf{x}_s}{\sigma_d}, s\right)$
 - 9: **结束 如果**
 - 10: $r \leftarrow \min\left(1, \frac{\text{Iters}}{H}\right)$ ▷ 切向预热
 - 11: $\mathbf{w} \leftarrow -\cos^2(s)(\sigma_d \mathbf{F}_\theta^- - \frac{d\mathbf{x}_s}{ds}) - r \cos(s) \sin(s) \left(\mathbf{x}_s + \sigma_d \frac{d\mathbf{F}_{\theta^-}}{ds}\right)$
 - 12: $\mathbf{w} \leftarrow \frac{\mathbf{w}}{\|\mathbf{w}\| + c}$ ▷ 切向归一化
 - 13: $\mathcal{L}_{\text{sCM}}(\theta, \varphi) \leftarrow \frac{e^{\omega_\varphi(s)}}{D} \left\| \mathbf{F}_\theta\left(\frac{\mathbf{x}_s}{\sigma_d}, s\right) - \mathbf{F}_{\theta^-}\left(\frac{\mathbf{x}_s}{\sigma_d}, s\right) - \mathbf{w} \right\|_2^2 - \omega_\varphi(s)$ ▷ 自适应权重
 - 14: $(\theta, \varphi) \leftarrow (\theta, \varphi) - \eta \nabla_{\theta, \varphi} \mathcal{L}_{\text{sCM}}(\theta, \varphi)$
 - 15: $\text{Iters} \leftarrow \text{Iters} + 1$
 - 16: **直到** 收敛
-

11.4 一般流映射：一致性轨迹模型

一致性轨迹模型 (CTM) (Kim et al., 2024a) 是最早学习一般流映射 $\Psi_{s \rightarrow t}$ 的方法之一。

CTM 的实际设置. 与 CM 方法族类似, CTM 最初遵循 EDM (Karras et al., 2022) (节 D.6) 的表述, 采用 $\mathbf{x}$ 预测形式的 PF-ODE, 噪声调度为 $\alpha_t = 1$ 和 $\sigma_t = t$. 在这一设置下, PF-ODE 变为

$$\frac{d\mathbf{x}(\tau)}{d\tau} = \frac{\mathbf{x}(\tau) - \mathbb{E}[\mathbf{x}|\mathbf{x}(\tau)]}{\tau}.$$

从时刻 s 的 $\mathbf{x}_s$ 出发, 演化到后续时刻 $t \leq s$, 对应流映射 (解) 可等价地写为

$$\mathbf{x}_s + \int_s^t \frac{\mathbf{x}_\tau - \mathbb{E}[\mathbf{x}|\mathbf{x}_\tau]}{\tau} d\tau.$$

CTM 采用受 Euler 方法启发的参数化: 对 PF-ODE 应用单步 Euler 求解器 (等价于 DDIM; 见式 (9.2.4)), 得到

$$\mathbf{x}_{s \rightarrow t}^{\text{Euler}} = \mathbf{x}_s - (s - t) \frac{\mathbf{x}_s - \mathbb{E}[\mathbf{x}|\mathbf{x}_s]}{s} = \frac{t}{s} \mathbf{x}_s + \left(1 - \frac{t}{s}\right) \mathbb{E}[\mathbf{x}|\mathbf{x}_s],$$

其中, $\mathbf{x}_{s \rightarrow t}^{\text{Euler}}$ 近似给定时刻 s 的状态 $\mathbf{x}_s$ 时, 在时刻 t 的解。

EDM 设置提供了简单的说明性例子, 而 CTM 允许由任意线性高斯前向核 (α_t, σ_t) 定义的更广泛噪声调度, 并将 PF-ODE 表示为 $\mathbf{v}$ 预测形式:

$$\Psi_{s \rightarrow t}(\mathbf{x}_s) = \mathbf{x}_s + \int_s^t \mathbf{v}^*(\mathbf{x}_u, u) du.$$

后续讨论着重于这一一般表述。

11.4.1 用于灵活转移学习的 CTM 参数化

根据上述 PF-ODE 的单步 Euler 求解器, CTM 将理想流映射 $\Psi_{s \rightarrow t}$ 改写为输入 $\mathbf{x}_s$ 与残差函数 $\mathbf{g}^*$ 的凸组合:

$$\Psi_{s \rightarrow t}(\mathbf{x}_s) := \mathbf{x}_s + \int_s^t \mathbf{v}^*(\mathbf{x}_u, u) du = \frac{t}{s} \mathbf{x}_s + \frac{s-t}{s} \underbrace{\left[\mathbf{x}_s + \frac{s}{s-t} \int_s^t \mathbf{v}^*(\mathbf{x}_u, u) du \right]}_{=: \mathbf{g}^*}.$$

其中, 残差项 $\mathbf{g}^*$ 定义为

$$\mathbf{g}^*(\mathbf{x}_s, s, t) := \mathbf{x}_s + \frac{s}{s-t} \int_s^t \mathbf{v}^*(\mathbf{x}_u, u) du. \quad (11.4.1)$$

由此得到神经网络参数化:

$$\mathbf{G}_\theta(\mathbf{x}_s, s, t) := \frac{t}{s} \mathbf{x}_s + \frac{s-t}{s} \mathbf{g}_\theta(\mathbf{x}_s, s, t), \quad (11.4.2)$$

其中, $\mathbf{g}_\theta$ 是以 $\mathbf{g}_\theta \approx \mathbf{g}^*$ 为目标的神经网络, 因此训练 $\mathbf{G}_\theta(\mathbf{x}_s, s, t)$ 以逼近理想流映射:

$$\mathbf{G}_\theta(\mathbf{x}_s, s, t) \approx \Psi_{s \rightarrow t}(\mathbf{x}_s).$$

因此, CTM 自然地符合式 (10.1.4) 的一般一致性映射框架, 该框架将学得映射与理想流映射对齐.

此外, 这一表述本身满足初始条件:

$$\mathbf{G}_\theta(\mathbf{x}_s, s, s) = \mathbf{x}_s,$$

无需在训练时显式施加.

CTM 参数化的优点. 令 t 趋于 s (即终止时刻等于起始时刻) 取极限, 便可看出 $\mathbf{g}^*$ 的一个关键特征:

命题 11.4.1: $\mathbf{g}^*$ 的性质

(i) 恢复扩散模型:

$$\mathbf{g}^*(\mathbf{x}_s, s, s) = \lim_{t \rightarrow s} \mathbf{g}^*(\mathbf{x}_s, s, t) = \mathbf{x}_s - s\mathbf{v}^*(\mathbf{x}_s, s).$$

(ii) 积分表示:

$$\mathbf{g}^*(\mathbf{x}_s, s, t) = \mathbf{x}_s - s\mathbf{v}^*(\mathbf{x}_s, s) + \mathcal{O}(|t - s|).$$

命题的证明.

由 $\mathbf{g}^*$ 的定义, 得到

$$\lim_{s \rightarrow t} \mathbf{g}^*(\mathbf{x}_s, s, t) = \mathbf{x}_t - s \lim_{s \rightarrow t} \frac{1}{t - s} \int_s^t \mathbf{v}^*(\mathbf{x}_\tau, \tau) d\tau = \mathbf{x}_s - s\mathbf{v}^*(\mathbf{x}_s, s).$$

这就证明了第一个恒等式. 对于第二个结论, 由 Taylor 展开可得

$$\begin{aligned} \mathbf{g}^*(\mathbf{x}_s, s, t) &= \mathbf{x}_s - \frac{s}{s - t} \int_t^s \mathbf{v}^*(\mathbf{x}_\tau, \tau) d\tau \\ &= \mathbf{x}_s - \frac{s}{s - t} \left[(s - t)\mathbf{v}^*(\mathbf{x}_s, s) + \mathcal{O}((t - s)^2) \right] \\ &= \mathbf{x}_s - s\mathbf{v}^*(\mathbf{x}_s, s) + \mathcal{O}(|t - s|). \end{aligned}$$

由此命题可以得出:

1. 估计 $\mathbf{g}^*$, 不仅可以近似有限的 s 到 t 转移 ($s \leq t$), 还可以近似由瞬时速度 $\mathbf{v}^*$ 刻画的无穷小 s 到 s 转移.
2. $\mathbf{g}^*(\mathbf{x}_s, s, t)$ 可解释为理想速度 $\mathbf{v}^*$ 加上 Taylor 展开的残差项.

因此，利用式 (11.4.2) 中的 CTM 参数化，学习 $\mathbf{G}_\theta \approx \Psi_{s \rightarrow t}$ （或等价地， $\mathbf{g}_\theta \approx \mathbf{g}^*$ ），既能通过 $\mathbf{G}_\theta$ 获得长跳跃能力，又能通过 $\mathbf{g}_\theta$ 恢复扩散模型的速度（或等价的得分函数 / 去噪器）。因而这一参数化至关重要：通过学习 $\mathbf{g}^*$ ，CTM 将扩散模型与一致性模型（特殊流映射）的优势统一到一个框架中。

接下来两个小节先介绍 CTM 的一致性损失（节 11.4.2），它既支持蒸馏，也支持从头训练，并通过施加半群性质实现 $\mathbf{G}_\theta(\cdot, s, t) \approx \Psi_{s \rightarrow t}(\cdot, s, t)$ 。随后介绍从式 (11.4.2) 的参数化自然产生的辅助损失（节 11.4.3），包括扩散模型损失和 GAN 损失，它们可以进一步显著改善 CTM 的性能。

11.4.2 CTM 的一致性损失

CTM 旨在逼近理想解映射：

$$\mathbf{G}_\theta(\cdot, s, t) \approx \Psi_{s \rightarrow t}(\cdot, s, t),$$

对任意 $s \geq t$ 成立。由于理想映射 $\Psi_{s \rightarrow t}$ 通常没有可用的闭式表达式，CTM 通过施加半群性质（式 (11.2.1)）构造可行的回归目标：对任意 $s \geq u \geq t$ ，有

$$\Psi_{u \rightarrow t} \circ \Psi_{s \rightarrow u} = \Psi_{s \rightarrow t}.$$

根据是否有预训练扩散模型，可以用不同方式近似流映射 $\Psi_{s \rightarrow t}$ 。以下始终假设 $s \geq u \geq t \in [0, T]$ 。

通过蒸馏训练。 假设已有预训练扩散模型，输出 $\mathbf{v}_{\phi^\times}(\mathbf{x}_s, s) \approx \mathbf{v}^*(\mathbf{x}_s, s)$ 。则 PF-ODE 由如下经验动力学近似：

$$\frac{d\mathbf{x}(\tau)}{d\tau} = \mathbf{v}_{\phi^\times}(\mathbf{x}_\tau, \tau). \quad (11.4.3)$$

CTM 训练 $\mathbf{G}_\theta$ ，使其匹配应用于这一经验常微分方程的数值求解器 $\text{Solver}_{s \rightarrow t}(\mathbf{x}_s; \phi^\times)$ ，后者作为理想映射的可计算近似：

$$\mathbf{G}_\theta(\mathbf{x}_s, s, t) \approx \text{Solver}_{s \rightarrow t}(\mathbf{x}_s; \phi^\times) \approx \Psi_{s \rightarrow t}(\mathbf{x}_s, s, t).$$

当教师足够强时，求解器可在离散化误差范围内恢复 $\Psi_{s \rightarrow t}$ ，因此最优学生与真实值非常接近（见 (Kim et al., 2024a) 的命题 3 和 4）。

然而，当 s 和 t 相距较远时，在训练循环内求解整个区间 $[t, s]$ 的成本可能很高。为提高效率并提供更平滑的信号，CTM 引入软一致性匹配，将半群性质转化为具体操作。如图 11.4 所示，CTM 比较时刻 t 的两个预测：学生的直接输出 $\mathbf{G}_\theta(\mathbf{x}_s, s, t)$ ，以及教师与学生混合的路径，即先用教师从 s 推进到随机时刻 $u \sim \mathcal{U}[t, s]$ ，再让学生从 u 跳跃至 t ：

$$\mathbf{G}_\theta(\text{Solver}_{s \rightarrow u}(\mathbf{x}_s; \phi^\times), u, t).$$

训练学生匹配这一复合预测：

$$\underbrace{\mathbf{G}_\theta(\mathbf{x}_s, s, t)}_{\approx \Psi_{s \rightarrow t}(\mathbf{x}_s)} \approx \underbrace{\mathbf{G}_{\theta^-}(\text{Solver}_{s \rightarrow u}(\mathbf{x}_s; \phi^\times), u, t)}_{\approx \Psi_{u \rightarrow t}(\Psi_{s \rightarrow u}(\mathbf{x}_s))}, \quad (11.4.4)$$

其中， θ^- 是 $\mathbf{G}_\theta$ 的停止梯度副本。

通过改变 u ，CTM 在全局与局部监督之间插值：

- **全局一致性** ($u = s$)：学生在整个区间 (t, s) 上模仿教师，接收信息最丰富的教师信号。
- **局部一致性** ($u = s - \Delta s$)：学生从 s 附近的一个短教师步进中学习；当 $s = 0$ 时，它退化为一致性蒸馏。

为在对齐轨迹的同时提高样本质量，用停止梯度的学生将两个预测映射至时刻 0，并用特征空间度量 d 比较：

$$\begin{aligned} \mathbf{x}_{\text{est}}(\mathbf{x}_s, s, t) &:= \mathbf{G}_{\theta^-}(\mathbf{G}_\theta(\mathbf{x}_s, s, t), t, 0), \\ \mathbf{x}_{\text{target}}(\mathbf{x}_s, s, u, t) &:= \mathbf{G}_{\theta^-}(\mathbf{G}_{\theta^-}(\text{Solver}_{s \rightarrow u}(\mathbf{x}_s; \phi^\times), u, t), t, 0). \end{aligned}$$

CTM 的一致性损失为

$$\mathcal{L}_{\text{consist}}(\theta; \phi^\times) := \mathbb{E}_{s \in [0, T]} \mathbb{E}_{t \in [0, s]} \mathbb{E}_{u \in [t, s]} \mathbb{E}_{\mathbf{x}_0} \mathbb{E}_{\mathbf{x}_s | \mathbf{x}_0} \left[d(\mathbf{x}_{\text{est}}, \mathbf{x}_{\text{target}}) \right], \quad (11.4.5)$$

它鼓励学生匹配经验 PF-ODE 的解，同时保持生成质量。

从头训练. 利用 CTM 的特殊参数化 (命题 11.4.1(i))，有

$$\mathbf{g}^*(\mathbf{x}_\tau, \tau, \tau) = \mathbf{x}_\tau - \tau \mathbf{v}^*(\mathbf{x}_\tau, \tau) \implies \mathbf{v}^*(\mathbf{x}_\tau, \tau) = \frac{\mathbf{x}_\tau - \mathbf{g}^*(\mathbf{x}_\tau, \tau, \tau)}{\tau}.$$

因此，对 $\tau \in [0, T]$ ，可将理想残差函数 $\mathbf{g}^*(\cdot, \tau, \tau)$ 替换为 CTM 自身的估计 $\mathbf{g}_{\theta^-}(\cdot, \tau, \tau)$ ，得到自身诱导的经验 PF-ODE：

$$\frac{d\mathbf{x}(\tau)}{d\tau} = \frac{\mathbf{x}(\tau) - \mathbf{g}_{\theta^-}(\mathbf{x}(\tau), \tau, \tau)}{\tau}. \quad (11.4.6)$$

随后，通过求解这一常微分方程近似理想解映射，并训练学生匹配求解器输出：

$$\mathbf{G}_\theta(\mathbf{x}_s, s, t) \approx \text{Solver}_{s \rightarrow t}(\mathbf{x}_s; \theta^-) \approx \Psi_{s \rightarrow t}(\mathbf{x}_s, s, t).$$

与蒸馏情形 (11.4.4) 一样，当 s 和 t 相距较远时，在 $[t, s]$ 上完整积分的成本可能很高。因此，CTM 施加半群性质，得到更短的监督路径：

$$\underbrace{\mathbf{G}_\theta(\mathbf{x}_s, s, t)}_{\approx \Psi_{s \rightarrow t}(\mathbf{x}_s)} \approx \underbrace{\mathbf{G}_{\theta^-}(\text{Solver}_{s \rightarrow u}(\mathbf{x}_s; \theta^-), u, t)}_{\approx \Psi_{u \rightarrow t}(\Psi_{s \rightarrow u}(\mathbf{x}_s))},$$




图 11.4: **CTM 的半群性质示意图**. 对任意 $s \geq u \geq t$, CTM 施加 $\mathbf{G}_\theta(\mathbf{x}_s, s, t) \approx \mathbf{G}_{\theta^-}(\text{Solver}_{s \rightarrow u}(\mathbf{x}_s), u, t)$, 即较短的求解器片段 $s \rightarrow u$ 后接 CTM 至 t 的“跳跃”, 与直接的 CTM 映射 $s \rightarrow t$ 匹配. 求解器可以使用预训练扩散模型, 也可以使用 CTM 自身诱导的教师.

其中 $u \sim \mathcal{U}[t, s]$, θ^- 是学生的停止梯度副本. 与蒸馏相比, 唯一变化是将外部教师 $\mathbf{v}_{\phi^\times}$ 替换为自身诱导的教师 $\mathbf{g}_{\theta^-}$.

为结合轨迹匹配与样本质量, 用停止梯度的学生将两个预测映射至时刻 0, 再在特征空间比较. 不使用任何预训练模型时的目标为

$$\hat{\mathbf{x}}_{\text{target}} := \mathbf{G}_{\theta^-}(\mathbf{G}_{\theta^-}(\text{Solver}_{s \rightarrow u}(\mathbf{x}_s; \theta^-), u, t), t, 0),$$

它替代式 (11.4.5) 中的 $\mathbf{x}_{\text{target}}$, 得到:

$$\mathcal{L}_{\text{consist}}(\theta; \theta^-) := \mathbb{E}_{s \in [0, T]} \mathbb{E}_{t \in [0, s]} \mathbb{E}_{u \in [t, s]} \mathbb{E}_{\mathbf{x}_0} \mathbb{E}_{\mathbf{x}_s | \mathbf{x}_0} \left[d(\mathbf{x}_{\text{est}}, \hat{\mathbf{x}}_{\text{target}}) \right], \quad (11.4.7)$$

从概念上看, 这是 CTM 内部的自蒸馏: 模型自身提供短时间范围内的教师信号, 而学生学习完整转移.

11.4.3 CTM 的辅助损失

(自) 蒸馏的表现可能不如教师, 因为它只针对教师生成的目标优化, 缺乏真实数据的直接监督. CTM 则能自然地纳入数据驱动的正则项, 例如在目标中加入去噪得分匹配与对抗 (GAN) 项 (Goodfellow et al., 2014), 以更好地学习流映射.

自然整合扩散损失. 扩散模型损失 (更准确地说, 是条件流匹配损失; 见式 (5.2.9)) 自然地融入 CTM, 并提供固定回归目标, 以促进流映射模型的学习. 为说明这一点, 注

意有

$$\mathbf{v}^*(\mathbf{x}_s, s) = \frac{\mathbf{x}_s - \mathbf{g}^*(\mathbf{x}_s, s, s)}{s}, \quad \mathbf{g}^*(\mathbf{x}_s, s, s) \approx \mathbf{g}_\theta(\mathbf{x}_s, s, s).$$

这自然地通过 $\mathbf{g}_\theta$ 诱导出速度参数化：

$$\mathbf{v}_\theta(\mathbf{x}_s, s) := \frac{1}{s}(\mathbf{x}_s - \mathbf{g}_\theta(\mathbf{x}_s, s, s)).$$

使用线性高斯路径

$$\mathbf{x}_s = \alpha_s \mathbf{x}_0 + \sigma_s \boldsymbol{\epsilon}, \quad \mathbf{x}_0 \sim p_{\text{data}}, \boldsymbol{\epsilon} \sim \mathcal{N}(0, \mathbf{I}),$$

扩散模型损失可写为

$$\mathcal{L}_{\text{DM}}(\boldsymbol{\theta}) := \mathbb{E}_{\mathbf{x}_0, \boldsymbol{\epsilon}, s} \left[w(s) \left\| \mathbf{v}_\theta(\mathbf{x}_s, s) - (\alpha'_s \mathbf{x}_0 + \sigma'_s \boldsymbol{\epsilon}) \right\|_2^2 \right]. \quad (11.4.8)$$

$\mathcal{L}_{\text{DM}}$ 通过显式监督沿轨迹的小跳跃，提高 t 接近 s 时的精度。在这一情形下，式 (11.4.2) 中的因子 $1 - \frac{t}{s}$ 趋于零，可能削弱梯度并减慢学习； $\mathcal{L}_{\text{DM}}$ 提供更强的局部信号，并稳定训练。

从概念上看，式 (11.4.5) 和 (11.4.7) 施加轨迹匹配（零阶），而式 (11.4.8) 施加斜率匹配（一阶）。

(选读) GAN 损失. 一致性损失和扩散模型损失虽提供较强的回归信号，却可能产生过度平滑的输出。因此，CTM 可选择加入对抗项，通过将生成器分布与数据分布对齐，促进更清晰、更真实的样本。使用判别器 D_ζ 区分真实样本 $\mathbf{x}_0 \sim p_{\text{data}}$ 与生成样本 $\mathbf{x}_{\text{est}}(\mathbf{x}_s, s, t)$ ，目标为

$$\mathcal{L}_{\text{GAN}}(\boldsymbol{\theta}, \boldsymbol{\zeta}) := \mathbb{E}_{\mathbf{x}_0} [\log D_\zeta(\mathbf{x}_0)] + \mathbb{E}_{s \in [0, T]} \mathbb{E}_{t \in [0, s]} \mathbb{E}_{\mathbf{x}_0} \mathbb{E}_{\mathbf{x}_s | \mathbf{x}_0} [\log(1 - D_\zeta(\mathbf{x}_{\text{est}}(\mathbf{x}_s, s, t)))] ,$$

其中，对 D_ζ 最大化，对 $\mathbf{G}_\theta$ 最小化。直观地说，判别器起到自适应感知距离的作用，促进真实的细节。理论上，GAN 项推动 p_{data} 与 $\mathbf{G}_\theta$ 诱导的模型分布之间的分布匹配 (Jensen–Shannon 散度) (Goodfellow et al., 2014)，从而可能获得超越教师的保真度。

完整 CTM 目标. 总之，CTM 将（自）蒸馏、扩散及 GAN 损失统一在一个训练框架中：

$$\mathcal{L}_{\text{CTM}}(\boldsymbol{\theta}, \boldsymbol{\zeta}) := \mathcal{L}_{\text{consist}}(\boldsymbol{\theta}; \boldsymbol{\phi}^\times / \boldsymbol{\theta}^-) + \lambda_{\text{DM}} \mathcal{L}_{\text{DM}}(\boldsymbol{\theta}) + \lambda_{\text{GAN}} \mathcal{L}_{\text{GAN}}(\boldsymbol{\theta}, \boldsymbol{\zeta}),$$

其中，教师可以是外部预训练模型 $\boldsymbol{\phi}^\times$ ，也可以是自身诱导的教师 $\boldsymbol{\theta}^-$ 。回归形式的分量 $\mathcal{L}_{\text{consist}}$ 和 $\mathcal{L}_{\text{DM}}$ 起到较强正则化作用，可选的 GAN 项则在保持稳定性的同时改善精细细节 (Kim et al., 2024b)。

11.4.4 使用 CTM 灵活采样

CTM 学习任意 $s > t$ 的一般流映射 $\Psi_{s \rightarrow t}$ ，即支持任意时刻到任意时刻的转移. 这一性质使灵活采样策略成为可能. 例如，CTM 提出 γ 采样，通过超参数 γ 控制生成时的随机性. 此外，CTM 可以复用为扩散模型开发的标准推断技术，例如基于常微分方程的求解器和精确似然计算.

以下固定采用离散时间网格 $T = \tau_0 > \tau_1 > \tau_2 > \dots > \tau_M = 0$ 进行采样.

算法 11 CTM 的 γ 采样

输入： 训练好的 CTM $\mathbf{G}_{\theta^\times}$ 、 $\gamma \in [0, 1]$ 、 $T = \tau_0 > \tau_1 > \tau_2 > \dots > \tau_M = 0$.

- 1: 从 $\mathbf{x}_{\tau_0} \sim p_{\text{prior}} = \mathcal{N}(\mathbf{0}, T^2 \mathbf{I})$ 出发
- 2: **对于** $n = 0$ **至** $M - 1$ **执行**
- 3: $\tilde{\tau}_{n+1} \leftarrow \sqrt{1 - \gamma^2} \tau_{n+1}$
- 4: 去噪 $\mathbf{x}_{\tilde{\tau}_{n+1}} \leftarrow \mathbf{G}_{\theta^\times}(\mathbf{x}_{\tau_n}, \tau_n, \tilde{\tau}_{n+1})$
- 5: 扩散 $\mathbf{x}_{\tau_{n+1}} \leftarrow \mathbf{x}_{\tilde{\tau}_{n+1}} + \gamma \tau_{n+1} \boldsymbol{\epsilon}$ ，其中 $\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$
- 6: **结束 对于**

输出： $\mathbf{x}_{\tau_M}$

γ 采样的方法. CTM 的 γ 采样引入了一个统一的采样器族，自然地源于一般流映射模型的学习. 它涵盖已有方法，例如 CM 的多步采样（见算法 9）与时间步进式采样，后者在概念上类似常微分方程求解器. 参数 γ 直接控制生成过程中语义变化的程度，使 γ 采样成为灵活且能适应任务的策略，可用于多种下游应用.

- 图 11.5 (左)：当 $\gamma = 1$ 时，它与 CM 中的多步采样一致（即特殊流映射 $\Psi_{s \rightarrow 0}$ ），完全随机，步数改变时会产生语义变化.
- 图 11.5 (右)：当 $\gamma = 0$ 时，它退化为完全确定性的时间步进，估计 PF-ODE 的解轨迹. $\gamma = 0$ 的 γ 采样与传统的基于常微分方程的时间步进采样之间，一个关键区别是 CTM 避免了数值求解器的离散化误差.
- 图 11.5 (中)：当 $0 < \gamma < 1$ 时， γ 采样允许在采样中注入受控的随机性，从而在两个极端之间插值.

需要强调，只有模型学习了一般流映射 $\Psi_{s \rightarrow t}$ ，才有可能实现 $\gamma \in (0, 1]$ 的采样器.

γ 采样的分析. CTM 在实验中观察到，一旦步数 $M \geq 4$ ，CM 多步采样的质量便会下降. 为解释这一现象，CTM 分析了底层原因：当 $\gamma \neq 0$ 时，神经网络的每次“跳跃”都引入微小的不匹配，而在模型迭代地将状态映射向零时刻时，这些不匹配会累积. 这种误差累积解释了为何较长的多步运行可能表现不佳. 下面的命题形式化了这一思想.




图 11.5: 不同 γ 值下的 γ 采样示意图. 该过程交替执行通过网络求值去噪与反向加噪, $(\tau_n \xrightarrow{\text{去噪}} \sqrt{1 - \gamma^2}\tau_{n+1} \xrightarrow{\text{加噪}} \tau_{n+1})_{n=0}^{M-1}$. 最左图为 $\gamma = 1$, 对应完全随机的情形. 最右图为 $\gamma = 0$, 对应完全确定性的情形. 中图为中间值 $\gamma \in (0, 1)$, 在两个极端之间插值.

命题 11.4.2: (非正式) 两步 γ 采样

设 $\tau \in (0, T)$, $\gamma \in [0, 1]$. 设 $p_{\theta^*, 2}$ 表示以最优 CTM 进行 γ 采样、从 p_{prior} 出发, 沿转移序列 $T \rightarrow \sqrt{1 - \gamma^2}\tau \rightarrow \tau \rightarrow 0$ 所得到的密度. 那么

$$\mathcal{D}_{\text{TV}}(p_{\text{data}}, p_{\theta^*, 2}) = \mathcal{O}\left(\sqrt{T - \sqrt{1 - \gamma^2}\tau + \tau}\right).$$

这里, $\mathcal{D}_{\text{TV}}$ 表示分布之间的全变差 (见式 (1.1.4)).

命题的证明.

采样步数为 M 的一般情形, 请参阅 Kim et al. (2024a) 的定理 8.

上述定理的启示可概括如下:

- 当 $\gamma = 1$ (对应 CM 的多步采样) 时: 该方法在每一步 n 都执行从 τ_n 到 0 的迭代长距离转移. 这导致如下阶数的误差累积:

$$\mathcal{O}\left(\sqrt{T + \tau_1 + \cdots + \tau_M}\right).$$

- 当 $\gamma = 0$ (对应 CTM 的确定性多步采样) 时: 转移之间的这种时间重叠被消除. 这避免了误差累积, 并给出更紧的界 $\mathcal{O}(\sqrt{T})$. 实验上, $\gamma = 0$ 的 CTM 在采样速度与样本质量之间提供了良好的权衡: 增加采样步数可以提高生成质量, 而不会引入不稳定性.

CTM 支持扩散推断. 借助式 (11.4.2) 的参数化, CTM 通过 $\mathbf{g}_\theta$ 直接学习得分函数 (或去噪器), 因此兼容最初为扩散模型开发的推断技术. 例如, 使用 $\mathbf{g}_\theta(\cdot, s, s)$ 可以计算精确似然 (节 4.2.2), 或应用 DDIM、DPM 等高级采样器 (章 9) 进行生成.

11.5 一般流映射：平均流

正如扩散模型具有许多等价参数化和训练目标，一般流映射 $\Psi_{s \rightarrow t}$ 也可以通过多种合理方式学习。本节介绍平均流（MF）（Geng et al., 2025a），它是一般流映射族 $\Psi_{s \rightarrow t}$ 中较晚出现的一种代表，从另一种有理论依据的视角说明如何有效学习此类映射。

11.5.1 平均流的建模与训练

CM 和 CTM 建立在 EDM 框架之上，MF 则基于流匹配表述（ $t \in [0, 1]$ 时， $\alpha_t = 1-t$ 、 $\sigma_t = t$ ）。MF 不直接参数化流映射，而是学习区间 $[t, s]$ （其中 $t < s$ ）上的平均漂移：

$$\mathbf{h}_\theta(\mathbf{x}_s, s, t) \approx \mathbf{h}^*(\mathbf{x}_s, s, t) := \frac{1}{t-s} \int_s^t \mathbf{v}^*(\mathbf{x}_u, u) \, du.$$

对应的理想损失为

$$\mathbb{E}_{t < s} \mathbb{E}_{\mathbf{x}_s \sim p_s} \left[w(s) \|\mathbf{h}_\theta(\mathbf{x}_s, s, t) - \mathbf{h}^*(\mathbf{x}_s, s, t)\|_2^2 \right]. \quad (11.5.1)$$

特别地，当 $s \rightarrow t$ 时，损失函数退化为流匹配损失：

$$\mathbb{E}_t \mathbb{E}_{\mathbf{x}_t \sim p_t} \left[w(t) \|\mathbf{h}_\theta(\mathbf{x}_t, t, t) - \mathbf{v}^*(\mathbf{x}_t, t)\|_2^2 \right], \quad (11.5.2)$$

用于学习瞬时速度。后文节 11.5.3 将说明，MF 仍与式 (10.1.4) 中的一般目标一致，只是从不同（但等价）的视角处理该目标。由于理想回归目标 $\mathbf{h}^*(\mathbf{x}_s, s, t)$ 通常没有闭式表达式，MF 利用将下式求导所得的恒等式构造替代目标：

$$(t-s) \mathbf{h}^*(\mathbf{x}_s, s, t) = \int_s^t \mathbf{v}^*(\mathbf{x}_u, u) \, du$$

对 s 求导，得到

$$\begin{aligned} \mathbf{h}^*(\mathbf{x}_s, s, t) &= \mathbf{v}^*(\mathbf{x}_s, s) - (s-t) \frac{d}{ds} \mathbf{h}^*(\mathbf{x}_s, s, t) \\ &= \mathbf{v}^*(\mathbf{x}_s, s) - (s-t) \left[(\partial_{\mathbf{x}} \mathbf{h}^*)(\mathbf{x}_s, s, t) \mathbf{v}^*(\mathbf{x}_s, s) + \partial_s \mathbf{h}^*(\mathbf{x}_s, s, t) \right], \end{aligned}$$

其中，第二行应用链式法则，并使用

$$\frac{d}{ds} \mathbf{x}_s = \mathbf{v}^*(\mathbf{x}_s, s).$$

受这一恒等式启发，MF 将不可直接计算的理想目标替换为停止梯度的替代目标，得到实用的训练目标：

$$\mathcal{L}_{\text{MF}}(\theta) := \mathbb{E}_{t < s} \mathbb{E}_{\mathbf{x}_s \sim p_s} \left[w(s) \|\mathbf{h}_\theta(\mathbf{x}_s, s, t) - \mathbf{h}_{\theta^-}^{\text{tgt}}(\mathbf{x}_s, s, t)\|_2^2 \right], \quad (11.5.3)$$

其中，回归目标定义为

$$\mathbf{h}_{\theta^-}^{\text{tgt}}(\mathbf{x}_s, s, t) := \mathbf{v}^*(\mathbf{x}_s, s) - (s - t) \underbrace{\left[(\partial_{\mathbf{x}} \mathbf{h}_{\theta^-})(\mathbf{x}_s, s, t) \mathbf{v}^*(\mathbf{x}_s, s) + \partial_s \mathbf{h}_{\theta^-}(\mathbf{x}_s, s, t) \right]}_{\text{JVP}}.$$

实践中，理想速度 $\mathbf{v}^*$ 无法以闭式计算，必须近似。两种常见策略是：依赖预训练扩散模型（蒸馏），或从数据构造直接估计器（从头训练）。无论选择哪种方式，最终都需要计算目标网络 $\mathbf{h}_{\theta^-}$ 的雅可比矩阵与向量乘积（JVP）：

$$[\partial_{\mathbf{x}} \mathbf{h}_{\theta^-}, \partial_s \mathbf{h}_{\theta^-}, \partial_t \mathbf{h}_{\theta^-}]^\top \cdot [\mathbf{v}^*, 1, 0]$$

蒸馏。 使用基于流匹配的预训练扩散模型， $\mathbf{v}_{\phi^\times} \approx \mathbf{v}^*$ 。

从头训练。 使用单点条件速度 $\alpha'_s \mathbf{x}_0 + \sigma'_s \epsilon$ ，它来自前向噪声注入 $\mathbf{x}_s = \alpha_s \mathbf{x}_0 + \sigma_s \epsilon$ ，其中 $\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 。在配对的 $(\mathbf{x}_0, \epsilon)$ 上计算时，它给出水平 s 下瞬时漂移的无偏单样本估计。

11.5.2 平均流的采样

MF $\mathbf{h}_{\theta^\times}$ 训练完成后，自然地恢复了流映射的近似。对任意起点 $\mathbf{x}_s$ ，从 s 到 t 的映射（近似）为

$$\Psi_{s \rightarrow t}(\mathbf{x}_s) = \mathbf{x}_s + (t - s) \mathbf{h}^*(\mathbf{x}_s, s, t) \approx \mathbf{x}_s + (t - s) \mathbf{h}_{\theta^\times}(\mathbf{x}_s, s, t).$$

这既支持一步采样，也支持多步采样。例如，采样 $\mathbf{x}_T \sim p_{\text{prior}}$ 后，一步生成干净样本为

$$\mathbf{x}_0 \leftarrow \mathbf{x}_T + T \mathbf{h}_{\theta^\times}(\mathbf{x}_T, T, 0).$$

也可以预先准备时间网格，采用与 CTM 相同的时间步进方式，依次应用映射进行多步生成。由于 MF 学习一般流映射，它也支持 CTM 中的 γ 采样，通过可控的超参数 γ 向采样过程注入随机性。

11.5.3 CTM 与 MF 的等价性

初看之下，CTM 与 MF 似乎互不相关。实际上，两者只是同一理想流映射 $\Psi_{s \rightarrow t}$ 的不同参数化，其训练损失（CTM 的一致性损失与式 (11.5.1)）仅在时间权重上不同 (Hu et al., 2025)。

参数化之间的关系. 两种方法采用同一一般框架, 但以不同方式表示学得函数. 流映射可等价地写为

$$\begin{aligned}
 \Psi_{s \rightarrow t}(\mathbf{x}_s) &= \mathbf{x}_s + \int_s^t \mathbf{v}^*(\mathbf{x}_u, u) \, du \\
 &= \frac{t}{s} \mathbf{x}_s + \frac{s-t}{s} \underbrace{\left[\mathbf{x}_s + \frac{s}{s-t} \int_s^t \mathbf{v}^*(\mathbf{x}_u, u) \, du \right]}_{\approx \mathbf{g}_\theta} \\
 &= \mathbf{x}_s + (t-s) \underbrace{\left[\frac{1}{t-s} \int_s^t \mathbf{v}^*(\mathbf{x}_u, u) \, du \right]}_{\approx \mathbf{h}_\theta}.
 \end{aligned}$$

这里, 第一种形式是流映射的定义, 第二种形式突出通过 $\mathbf{g}_\theta$ 实现的 CTM 参数化 (见式 (11.4.1) 和 (11.4.2)), 最后一种形式突出通过 $\mathbf{h}_\theta$ 实现的 MF 参数化.

训练损失之间的关系. 根据上面对理想流映射 $\Psi_{s \rightarrow t}$ 的重新解释, 采用 CTM 参数化

$$\mathbf{g}_\theta(\mathbf{x}_s, s, t) \approx \mathbf{g}^*(\mathbf{x}_s, s, t) := \mathbf{x}_s + \frac{s}{s-t} \int_s^t \mathbf{v}^*(\mathbf{x}_u, u) \, du$$

以及 MF 参数化

$$\mathbf{h}_\theta(\mathbf{x}_s, s, t) \approx \mathbf{h}^*(\mathbf{x}_s, s, t) := \frac{1}{t-s} \int_s^t \mathbf{v}^*(\mathbf{x}_u, u) \, du,$$

现在说明 CTM 与 MF 的训练损失实际上等价.

考虑关系

$$\mathbf{g}_\theta(\mathbf{x}_s, s, t) := \mathbf{x}_s - s\mathbf{h}_\theta(\mathbf{x}_s, s, t),$$

以 $d(\mathbf{x}, \mathbf{y}) := \|\mathbf{x} - \mathbf{y}\|^2$ 为例. 将其代入式 (10.1.4), 并将 $\mathbf{G}_\theta$ 视为 CTM 的流映射参数化 (式 (11.4.2)), 得到

$$\begin{aligned}
 &d(\mathbf{G}_\theta(\mathbf{x}_s, s, t), \Psi_{s \rightarrow t}(\mathbf{x}_s)) \\
 &= \|\mathbf{G}_\theta(\mathbf{x}_s, s, t) - \Psi_{s \rightarrow t}(\mathbf{x}_s)\|^2 \\
 &= \left\| \left(\frac{t}{s} \mathbf{x}_s + \frac{s-t}{s} \mathbf{g}_\theta(\mathbf{x}_s, s, t) \right) - \left(\frac{t}{s} \mathbf{x}_s + \frac{s-t}{s} \left[\mathbf{x}_s + \frac{s}{s-t} \int_s^t \mathbf{v}^*(\mathbf{x}_u, u) \, du \right] \right) \right\|^2 \\
 &= \left(\frac{s-t}{s} \right)^2 \left\| \mathbf{g}_\theta(\mathbf{x}_s, s, t) - \left(\mathbf{x}_s + \frac{s}{s-t} \int_s^t \mathbf{v}^*(\mathbf{x}_u, u) \, du \right) \right\|^2 \tag{11.5.4}
 \end{aligned}$$

$$\begin{aligned}
 &= \left(\frac{s-t}{s} \right)^2 \left\| (\mathbf{x}_s - s\mathbf{h}_\theta(\mathbf{x}_s, s, t)) - \left(\mathbf{x}_s + \frac{s}{s-t} \int_s^t \mathbf{v}^*(\mathbf{x}_u, u) \, du \right) \right\|^2 \\
 &= \left(\frac{s-t}{s} \right)^2 \left\| (\mathbf{x}_s - s\mathbf{h}_\theta(\mathbf{x}_s, s, t)) - \left(\mathbf{x}_s + \frac{s}{s-t} \int_s^t \mathbf{v}^*(\mathbf{x}_u, u) \, du \right) \right\|^2 \\
 &= (s-t)^2 \left\| \mathbf{h}_\theta(\mathbf{x}_s, s, t) - \left(\frac{1}{t-s} \int_s^t \mathbf{v}^*(\mathbf{x}_u, u) \, du \right) \right\|^2 \tag{11.5.5}
 \end{aligned}$$

因此,

$$\frac{1}{s^2} \left\| \mathbf{g}_\theta(\mathbf{x}_s, s, t) - \mathbf{g}^*(\mathbf{x}_s, s, t) \right\|^2 = \left\| \mathbf{h}_\theta(\mathbf{x}_s, s, t) - \mathbf{h}^*(\mathbf{x}_s, s, t) \right\|^2.$$

所以, 除权重函数外, CTM 与 MF 的损失本质上等价. 此外, 在任一情形下令 $t = 0$, 都恢复 CM 设置 ($\Psi_{s \rightarrow 0}$), 此时每个状态都直接映射至干净数据.

实践中的辅助损失. CTM 联合使用式 (11.4.7) 的一致性损失与式 (11.4.8) 中自身定义的扩散模型损失进行训练. MF 采用类似策略. 如式 (11.5.2) 所示, 当 $s \rightarrow t$ 时, MF 损失退化为标准流匹配目标. 实践中, MF 控制 $s \neq t$ 的时间对与 $s = t$ 的时间对之间的比例; 因此, 整体优化成为式 (11.5.3) 的 MF 目标与式 (11.5.2) 的流匹配目标的混合.

两种参数化都能够实现从扩散模型训练到流映射学习的平滑过渡: 前者通过固定回归目标学习瞬时速度, 后者使用停止梯度的伪回归目标.

CTM 与 MF 的参数化均支持灵活推断. CTM ($\mathbf{G}_\theta(\mathbf{x}_s, s, t)$) 与 MF ($\mathbf{h}_\theta(\mathbf{x}_s, s, t)$) 均旨在逼近底层流映射 $\Psi_{s \rightarrow t}$:

$$\mathbf{G}_\theta(\mathbf{x}_s, s, t) \approx \Psi_{s \rightarrow t}, \quad \text{且} \quad \mathbf{x}_s + (t - s)\mathbf{h}_\theta(\mathbf{x}_s, s, t) \approx \Psi_{s \rightarrow t}.$$

由于两个模型都学习任意两个时间步之间的显式映射, 它们自然支持 CTM 的 γ 采样, 并兼容最初为扩散模型开发的推断技术, 例如引导 (章 8)、精确似然计算 (式 (4.2.7)), 以及使用高阶求解器加速采样 (章 9). 这种兼容性源于它们的参数化在无穷小极限 $t \rightarrow s$ 时恢复瞬时扩散漂移:

$$\mathbf{g}^*(\mathbf{x}_s, s, s) = \mathbf{x}_s - \mathbf{v}^*(\mathbf{x}_s, s), \quad \text{且} \quad \mathbf{h}^*(\mathbf{x}_s, s, s) = \mathbf{v}^*(\mathbf{x}_s, s).$$

专门针对 $\Psi_{s \rightarrow 0}$ 的流映射表述 (如 CM 方法族) 不具有这一性质. 因此, CTM 与 MF 都可以视为灵活的一般流映射表述, 将基于扩散的推断推广为直接的时间到时间映射.

结论. CTM 与 MF 的这一等价性类似于扩散模型中的情形 (节 6.3): 不同参数化最终描述同一底层理想目标. 原则上, 这些表述在数学上相同. 不过, 实践中损失权重、网络设计或优化动力学等因素可能使它们表现不同, 从而使某种方法在特定条件下优于另一种方法.

这一视角说明, CTM 与 MF 并非仅有的可能性: 流映射的其他参数化也可能实现高效、稳定的训练, 为新的独立生成模型打开大门. 探索这些替代方案, 可进一步丰富扩散模型及其流映射扩展, 最终拓展少步生成的能力边界.

11.6 结束语

最后一章使我们的探索回到出发点，并最终形成一种新的生成建模范式：从头学习快速的少步生成器。超越改进数值求解器或蒸馏预训练模型的方法，我们着重于设计独立训练原则，使其在设计上既有理论依据，又具有很高效率。

这里的核心创新是直接学习底层概率流常微分方程的流映射 ($\Psi_{s \rightarrow t}$)。无需教师仍可实现可行学习，关键在于利用常微分方程流的基本半群性质。这一性质规定，长轨迹可以分解为较短片段，从而为训练提供强大的自监督信号。

我们从一致性模型 (CM) 开始，它通过学习将任意含噪状态输运回干净起点的特殊流映射 ($\Psi_{s \rightarrow 0}$)，开创了这一方法。随后看到，一致性轨迹模型 (CTM) 和平均流 (MF) 推广了这一思想，对所有满足 $s \geq t$ 的 s, t ，学习完整的任意时刻到任意时刻的流映射 $\Psi_{s \rightarrow t}$ 。尽管这些方法的参数化看似不同，我们证明它们本质上是近似定义流映射的同一路径积分的等价方式。

这些流映射模型有力地综合了本专著发展出的各项原则。它们继承得分 SDE 框架的连续时间基础，以及流匹配的确定性输运视角，同时将训练目标重新表述为自包含且高效的形式。

通过直接学习解映射，这些独立模型成功结合了迭代扩散过程的高样本质量与一步生成器的推断速度。它们解决了保真度与速度之间的根本权衡，标志着生成建模的重要里程碑。这一成就并非终点，而是设计强大、高效且可控的生成式人工智能的新篇章的开端。

重要的是不要停止提问。好奇心自有其存在的理由。

Albert Einstein

附录 A 微分方程速成

微分方程 (DE) 是动态系统建模的基本工具，大体可分为常微分方程 (ODE)、随机微分方程 (SDE) 与偏微分方程 (PDE)。

常微分方程描述系统状态如何按照精确规则随时间变化，因而知道起点就能精确确定后续路径。随机微分方程在这一演化中加入随机性，对噪声或不确定性如何影响系统行为建模，使结果具有概率性而非固定不变。偏微分方程描述依赖时间、空间等多个变量的函数如何共同演化，刻画热扩散、波传播，以及随机系统中概率密度随时间演化等现象（提前透露：Fokker–Planck 方程）。这些微分方程构成了理解系统在确定性和随机影响下如何随时间、空间演化的基本语言。

本章介绍微分方程的必要预备知识。

A.1 常微分方程基础

本节介绍常微分方程的基本理论，重点是给定初始条件时解的唯一性，也介绍使用数值求解器求解常微分方程的实用方法。

A.1.1 常微分方程的直观理解

这种确定性过程称为常微分方程 (ODE)。在多变量情形下，考虑如下形式的系统：

$$\frac{d\mathbf{x}(t)}{dt} = \mathbf{v}(\mathbf{x}(t), t), \quad (\text{A.1.1})$$

其中， $\mathbf{x}(t) \in \mathbb{R}^D$ 是向量值函数，表示系统在时刻 t 的状态； $\mathbf{v} : \mathbb{R}^D \times \mathbb{R} \rightarrow \mathbb{R}^D$ 是向量场，指定每个时空点处变化的方向与大小。




图 A.1: 常微分方程示意图. 速度场 $\mathbf{v}(\mathbf{x}, t)$ 在每个点赋予一个漂移向量. 解轨迹 $\mathbf{x}(t)$ 是其切向量始终与局部漂移一致的路径. 左图显示逐步求解器更新 (点与箭头) 如何近似路径, 右图显示与速度场一致流动的精确轨迹 (黑色). 未指定初始状态 $\mathbf{x}(0)$ 时, 有无穷多条轨迹的瞬时变化与同一速度场匹配. 然而, 一旦固定 $\mathbf{x}(0)$, 常微分方程就确定了按照漂移流动的唯一路径 $\mathbf{x}(t)$.

求解常微分方程的整体直觉. 为建立直觉, 可将向量场 $\mathbf{v}(\mathbf{x}, t)$ 想象成由箭头组成的动态景观, 告诉我们点 $\mathbf{x}$ 在任意给定时刻 t 应如何移动. 求解微分方程, 就是在这一场中追踪曲线 $\mathbf{x}(t)$, 使曲线每一点的切向量 (即瞬时速度) 与 $\mathbf{v}(\mathbf{x}(t), t)$ 给出的向量一致.

- **向量场视角:** 函数 $\mathbf{v}(\mathbf{x}, t)$ 定义了事物应如何移动, 给出运动或变化的局部“指令”.
- **轨迹视角:** 解 $\mathbf{x}(t)$ 是粒子在每一时刻都遵循向量场 $\mathbf{v}$ 规定的规则时所走的路径.

因此, 求解常微分方程就像将粒子放入流场, 观察它随时间移动到哪里.

A.1.2 常微分方程的存在性与唯一性

到目前为止，我们看到求解常微分方程，就是寻找在每一点都遵循向量场所给方向的路径。直观地说，这就像追踪粒子沿速度定义的流移动时的轨迹。

但这一图景引出了一个重要问题：

问题 A.1.1. 选择一个起点后，能否保证确实存在遵循这些方向的路径？如果存在，这一路径是否唯一，还是粒子可能突然跳到另一条轨迹上？

回答这些问题至关重要，因为它决定了能否从起始位置可靠地预测系统行为。存在唯一性定理对向量场给出条件，保证从任意给定初始点出发恰有一条路径。这保证了解的行为一致，并构成常微分方程理论的基石。

局部（时间上）存在唯一性定理。 下面陈述该定理的局部版本，它断言：给定初始条件，在初始时刻的某个邻域内，解存在且唯一。

定理 A.1.1: 局部存在性与唯一性

设 $\mathbf{v}(\mathbf{x}, t)$ 在区域 $D \subseteq \mathbb{R}^D \times \mathbb{R}$ 内关于 $\mathbf{x}$ 和 t 连续。若 $\mathbf{v}$ 关于 $\mathbf{x}$ 满足 Lipschitz 条件：

$$\|\mathbf{v}(\mathbf{x}_1, t) - \mathbf{v}(\mathbf{x}_2, t)\| \leq L \|\mathbf{x}_1 - \mathbf{x}_2\| \quad \forall (\mathbf{x}_1, t), (\mathbf{x}_2, t) \in D,$$

其中 $L > 0$ 是常数，则对每个初始条件 $\mathbf{x}(t_0) = \mathbf{x}_0$ ，式 (A.1.1) 在某个区间 $[t_0 - \delta, t_0 + \delta]$ 上存在唯一解 $\mathbf{x}(t)$ 。

定理的证明。

(证明概要) 存在唯一性定理可使用 Picard–Lindelöf 迭代法构造性地证明。该方法产生函数序列 $\{\mathbf{x}_n(t)\}$ ，收敛至解 $\mathbf{x}(t)$ 。迭代定义为：

$$\mathbf{x}_{n+1}(t) = \mathbf{x}_0 + \int_{t_0}^t \mathbf{v}(\mathbf{x}_n(s), s) \, ds.$$

- 从初始猜测 $\mathbf{x}_0(t) = \mathbf{x}_0$ 出发。
- 利用积分形式，迭代改善 $\mathbf{x}_n(t)$ 。
- 在 Lipschitz 条件下，应用压缩映射定理可保证收敛。

证明的本质在于 Picard–Lindelöf 迭代法，其核心思想也在节 9.8 中用于加速扩散模型的采样过程。

全局（时间上）存在唯一性定理。 局部存在唯一性定理保证解在较小时间区间上的存在性，而“全局（时间上）存在唯一性定理”在额外正则性条件下，将这一结果推广至整个区间 $[t_0, T]$ 。此类结果中的一个著名定理是 *Carathéodory* 定理：在两个关键假设下，

它保证常微分方程解的全局存在性与唯一性，即状态变量上的局部 Lipschitz 连续性与线性增长界。

- (i) **关于 $\mathbf{x}$ 的局部 Lipschitz 条件**：存在在 $[0, T]$ 上可积的函数 $\text{Lip}(t)$ ，使对所有 $\mathbf{x}_1, \mathbf{x}_2 \in \mathbb{R}^D$ ，有

$$\|\mathbf{v}(\mathbf{x}_1, t) - \mathbf{v}(\mathbf{x}_2, t)\| \leq \text{Lip}(t) \|\mathbf{x}_1 - \mathbf{x}_2\|.$$

- (ii) **线性增长条件**：存在在 $[0, T]$ 上可积的函数 $M(t)$ ，使对所有 $\mathbf{x} \in \mathbb{R}^D$ ，有

$$\|\mathbf{v}(\mathbf{x}, t)\| \leq M(t)(1 + \|\mathbf{x}\|).$$

关于该定理假设、正式表述和详细证明的全面讨论，请参阅 (Reid, 1971).

注.

将这些定理应用于扩散模型的概率流常微分方程（见式 (4.1.7)）时，可能需要对得分函数 $\nabla_{\mathbf{x}} \log p_t(\mathbf{x})$ 施加额外假设，例如条件 (i) 和 (ii). 不关注技术细节的读者可以合理地接受这些假设，无需进一步论证。

总之，对于由依赖时间的速度场定义的常微分方程，一旦给定初始条件，粒子流的轨迹就唯一确定。

唯一性蕴含解不相交 局部存在唯一性定理保证的常微分方程解的唯一性，蕴含一项基本性质：从不同初始条件出发的两条不同解轨迹不能相交。这反映了常微分方程的确定性，保证每个状态都沿唯一路径演化。以下推论形式化了这一结果。

推论 A.1.1: 解不相交

考虑下列常微分方程的两个解 $\mathbf{x}_1(t)$ 和 $\mathbf{x}_2(t)$ ：

$$\frac{d\mathbf{x}(t)}{dt} = \mathbf{v}(\mathbf{x}(t), t), \quad t \in [0, T].$$

假设它们的初值不同， $\mathbf{x}_1(0) \neq \mathbf{x}_2(0)$. 则这两个解在 $[0, T]$ 上不相交，即

$$\mathbf{x}_1(t) \neq \mathbf{x}_2(t) \quad \text{对所有 } t \in [0, T].$$

推论的证明。

用反证法，假设存在某个 $t^* \in (0, T]$ ，使

$$\mathbf{x}_1(t^*) = \mathbf{x}_2(t^*).$$

将两个解首次相遇的时刻定义为

$$t_0 := \inf\{t \in [0, T] | \mathbf{x}_1(t) = \mathbf{x}_2(t)\}.$$

由于 $\mathbf{x}_1(0) \neq \mathbf{x}_2(0)$, 且 t^* 属于此集合, 故 $t_0 > 0$. 由 $\mathbf{x}_1$ 和 $\mathbf{x}_2$ 的连续性, 有

$$\mathbf{x}_1(t_0) = \mathbf{x}_2(t_0).$$

考虑初值问题

$$\frac{d\mathbf{x}(t)}{dt} = \mathbf{v}(\mathbf{x}(t), t), \quad \mathbf{x}(t_0) = \mathbf{x}_1(t_0).$$

由常微分方程的唯一性定理, $\mathbf{x}_1$ 与 $\mathbf{x}_2$ 必须在区间 $[t_0, T]$ 上重合. 沿时间反向应用唯一性, 同样可知两个解在 $[0, t_0]$ 上重合. 因此, 解满足

$$\mathbf{x}_1(t) = \mathbf{x}_2(t) \quad \text{对所有 } t \in [0, T],$$

这与假设 $\mathbf{x}_1(0) \neq \mathbf{x}_2(0)$ 矛盾. 故得到

$$\mathbf{x}_1(t) \neq \mathbf{x}_2(t) \quad \text{对所有 } t \in [0, T].$$

该定理保证解路径不相交, 为流映射模型提供了隐含而关键的支持(见章 10和11).

A.1.3 指数积分因子

由一般时变速度 $\mathbf{v}$ 确定的常微分方程虽然没有闭式解, 但在某些特殊情形下, 可以解析求解, 或将其化为结构更好的形式.

说明性例子. 考虑下列线性标量常微分方程:

$$\frac{d\mathbf{x}(t)}{dt} = L(t)\mathbf{x}(t),$$

其中, $L(t) \in \mathbb{R}$ 是连续函数. 这一方程可闭式求解, 其解是熟知的 (对任意 s 和 t):

$$\mathbf{x}(t) = \mathbf{x}(s) \cdot \exp\left(\int_s^t L(\tau) d\tau\right).$$

该公式表明, 解按照某个指数因子演化, 该因子累积依赖时间的系数 $L(t)$ 的影响. 由此引入指数积分因子:

$$\mathcal{E}(s \rightarrow t) := \exp\left(\int_s^t L(\tau) d\tau\right), \quad (\text{A.1.2})$$

尤其适用于动力学同时包含线性与非线性分量的更一般设置.

半线性常微分方程与指数积分因子. 现在考虑一类更广泛的常微分方程, 称为半线性常微分方程. 它们将动力学分为 (关于状态变量的) 线性部分与非线性余项:

$$\frac{d\mathbf{x}(t)}{dt} = L(t)\mathbf{x}(t) + \mathbf{N}(\mathbf{x}(t), t), \quad (\text{A.1.3})$$

其中, $\mathbf{x}(t) \in \mathbb{R}^D$ 是状态向量, $L(t)$ 是标量值连续函数, $\mathbf{N}: \mathbb{R}^D \times [0, T] \rightarrow \mathbb{R}^D$ 是非线性向量场. 许多物理和工程系统中自然出现这种半线性结构. 特别地, 扩散模型的概率流常微分方程表述也具有这种结构 (见式 (4.1.7)). 识别这一结构后, 就能使用指数积分因子, 不仅简化分析, 也改善数值稳定性. 具体而言, 这一技术在快速扩散常微分方程求解器的设计中起核心作用 (见章 9).

步骤 1: 通过积分因子分离非线性项. 注意, 从式 (A.1.3) 的半线性常微分方程中减去线性漂移, 即可分离非线性部分:

$$\frac{d\mathbf{x}(t)}{dt} - L(t)\mathbf{x}(t) = \mathbf{N}(\mathbf{x}(t), t).$$

为吸收线性项, 将两边乘以积分因子的逆:

$$\mathcal{E}^{-1}(s \rightarrow t) = \exp\left(-\int_s^t L(\tau) d\tau\right).$$

现在对左边应用乘积法则:

$$\mathcal{E}^{-1}(s \rightarrow t) \left(\frac{d\mathbf{x}(t)}{dt} - L(t)\mathbf{x}(t) \right) = \frac{d}{dt} [\mathcal{E}^{-1}(s \rightarrow t)\mathbf{x}(t)].$$

因此, 方程变为:

$$\frac{d}{dt} [\mathcal{E}^{-1}(s \rightarrow t)\mathbf{x}(t)] = \mathcal{E}^{-1}(s \rightarrow t)\mathbf{N}(\mathbf{x}(t), t).$$

这一变换分离出非线性分量, 简化了原方程, 使我们能在变换后的坐标系中完全聚焦于非线性动力学.

步骤 2: 对时间积分. 现在将两边从 s 到 t 积分:

$$\int_s^t \frac{d}{d\tau} [\mathcal{E}^{-1}(s \rightarrow \tau)\mathbf{x}(\tau)] d\tau = \int_s^t \mathcal{E}^{-1}(s \rightarrow \tau)\mathbf{N}(\mathbf{x}(\tau), \tau) d\tau.$$

左边就是变换后的变量在 t 与 s 两时刻的值之差:

$$\mathcal{E}^{-1}(s \rightarrow t)\mathbf{x}(t) - \mathbf{x}(s).$$

因此, 得到:

$$\mathcal{E}^{-1}(s \rightarrow t)\mathbf{x}(t) = \mathbf{x}(s) + \int_s^t \mathcal{E}^{-1}(s \rightarrow \tau)\mathbf{N}(\mathbf{x}(\tau), \tau) d\tau.$$

步骤 3: 解出 $\mathbf{x}(t)$. 将两边乘以指数流 $\mathcal{E}(s \rightarrow t)$, 得到解:

$$\mathbf{x}(t) = \underbrace{\mathcal{E}(s \rightarrow t)\mathbf{x}(s)}_{\text{线性部分}} + \underbrace{\int_s^t \mathcal{E}(\tau \rightarrow t)\mathbf{N}(\mathbf{x}(\tau), \tau) d\tau}_{\text{非线性部分}}. \quad (\text{A.1.4})$$

解自然地分为线性与非线性分量. 指数积分器利用这一结构, 精确地闭式求解线性部分, 仅离散化非线性余项. 这样, 步长由非线性动力学决定, 而非由可能很大的线性系数决定, 即使步数较少, 也能得到稳定且准确的更新 (见指数 Euler 更新式 (9.1.7) 与普通 Euler 更新式 (9.1.8) 的比较).

A.1.4 常微分方程的数值求解器

考虑带初始条件 $\mathbf{x}(0)$ 的常微分方程式 (A.1.1). 求解此方程, 就是寻找连续轨迹 $\mathbf{x}(t)$, 使其对所有 $t \in [0, T]$ 满足该方程. 理想情况下, 希望得到闭式解, 但实践中很少能够做到.

一个有用的视角是将常微分方程改写为积分形式:

$$\mathbf{x}(t) = \mathbf{x}(0) + \int_0^t \mathbf{v}(\mathbf{x}(\tau), \tau) d\tau, \quad (\text{A.1.5})$$

它将解表示为初始状态加上速度随时间累积的影响. 不过, 由于 $\mathbf{v}$ 的非线性和时间依赖性, 该积分通常不可直接计算, 因而无法获得闭式解.

此时, 转而使用数值方法: 离散化时间, 并迭代近似 $\mathbf{x}(t)$. 常见方法包括 Euler 法、Runge-Kutta 方法, 以及针对刚性系统的专用积分器. 这些方法逐步模拟系统, 提供真实轨迹的实用近似.

注.

当 $\mathbf{v}$ 具有式 (A.1.3) 的半线性形式时, 解具有包含指数积分因子的积分表示 (式 (A.1.4)), 将线性与非线性分量分离. 这一结构使高效数值求解器可以只近似非线性项, 从而降低计算复杂度, 并促进专用算法的设计 (见章 9).

关键概念. 数值求解器通过离散化时间, 并利用常微分方程的斜率 $\mathbf{v}$ 估计状态, 近似常微分方程的连续动力学. 这涉及:

- **离散化:** 将时间域划分为离散时间点 $t_0, t_1, \dots, t_n$.
- **步长:** 区间长度 $\Delta t_i = t_{i+1} - t_i$ 称为步长.
- **近似:** 每一步的解通过数值估计获得; 精度取决于步长与所用方法.
- **误差控制:** 监测并控制离散化与近似产生的误差.

数值求解器的总体分类. 常微分方程求解器大体可分为:

- **时间步进方法:** 逐步推进解, 例如显式 / 隐式 Euler 法和 Runge-Kutta 方法.
- **时间并行方法:** 利用并行计算, 同时求解不同时间区间上的解, 适用于大规模问题.

常见数值求解器. Euler、Heun 和 Runge-Kutta 都是单步方法, 因为每次更新仅使用当前状态 $(t_n, \mathbf{x}_n)$. 多步方法 (例如 Adams-Bashforth 或 Adams-Moulton) 在计算 $\mathbf{x}_{n+1}$ 时, 不仅使用当前状态 $\mathbf{x}_n$, 还使用若干历史值 $\mathbf{x}_{n-1}, \mathbf{x}_{n-2}, \dots$. 它们通过复用过去的信息 (历史锚点) 节省计算, 而不在当前步骤重新计算全部信息. 此处不介绍这些方法, 不过相关格式 (例如节 9.3 和 9.5 讨论的 Adams-Bashforth) 也利用多个过去状态.

Picard 迭代的性质则不同: 它是一种理论上的不动点构造, 节 9.8 将再次讨论这一思想.

Euler 法. Euler 法是最简单的时间步进格式：

$$\mathbf{x}_{n+1} = \mathbf{x}_n + h\mathbf{v}(\mathbf{x}_n, t_n),$$

其中， h 是步长. 它具有一阶精度：局部误差为 $\mathcal{O}(h^2)$ ，全局误差为 $\mathcal{O}(h)$. 虽然易于实现，但为了稳定性与精度，需要较小的 h .

Heun 法：改进 Euler 法. Heun 法是一种二阶预测—校正格式：

$$\text{预测： } \mathbf{x}_{\text{pred}} = \mathbf{x}_n + h\mathbf{v}(\mathbf{x}_n, t_n),$$

$$\text{校正： } \mathbf{x}_{n+1} = \mathbf{x}_n + \frac{h}{2}(\mathbf{v}(\mathbf{x}_n, t_n) + \mathbf{v}(\mathbf{x}_{\text{pred}}, t_n + h)).$$

它的局部误差为 $\mathcal{O}(h^3)$ ，全局误差为 $\mathcal{O}(h^2)$. Karras et al. (2022) 倡导使用 Heun 法求解扩散模型中的常微分方程，不过 DPM-Solver 等高阶方法（见节 9.4 和 9.5）通常表现更好.

Runge–Kutta 方法. Runge–Kutta (RK) 方法使用中间斜率的加权平均，推广了 Euler 法. 四阶方法 (RK4) 是一种标准选择：

$$\mathbf{k}_1 = \mathbf{v}(\mathbf{x}_n, t_n),$$

$$\mathbf{k}_2 = \mathbf{v}(\mathbf{x}_n + \frac{h}{2}\mathbf{k}_1, t_n + \frac{h}{2}),$$

$$\mathbf{k}_3 = \mathbf{v}(\mathbf{x}_n + \frac{h}{2}\mathbf{k}_2, t_n + \frac{h}{2}),$$

$$\mathbf{k}_4 = \mathbf{v}(\mathbf{x}_n + h\mathbf{k}_3, t_n + h),$$

$$\mathbf{x}_{n+1} = \mathbf{x}_n + \frac{h}{6}(\mathbf{k}_1 + 2\mathbf{k}_2 + 2\mathbf{k}_3 + \mathbf{k}_4).$$

RK4 在精度与成本之间取得平衡，因而被广泛使用. DPM-Solver 基于类似思想，利用扩散模型的半线性结构，实现专为扩散模型设计的高阶精确积分（比较见 (Lu et al., 2022b) 的附录 B.6）.

Picard 迭代. Picard 迭代通过下式逐次改善解的近似：

$$\mathbf{x}^{(k+1)}(t) = \mathbf{x}(0) + \int_0^t \mathbf{v}(\mathbf{x}^{(k)}(s), s) \, ds,$$

从满足 $\mathbf{x}^{(0)}(0) = \mathbf{x}(0)$ 的初始猜测函数 $\mathbf{x}^{(0)}(t)$ 出发. Picard 迭代虽在理论上具有基础地位，但由于强烈依赖初始猜测，往往收敛较慢. 此外，每次迭代都涉及时间积分，计算成本可能很高.

沿时间正向与反向求解常微分方程. 到目前为止，我们考虑沿时间正向求解式 (A.1.1)，使解从初始条件 $\mathbf{x}(0)$ 演化至后续时刻 $t > 0$.

时间反向积分则从终端条件 $\mathbf{x}(T)$ 向较早时刻 $t < T$ 反向步进，计算解. 将时间重参数化为 $T - t$ ，常微分方程变为：

$$\frac{d\mathbf{x}(t)}{dt} = -\mathbf{v}(\mathbf{x}(t), T - t), \quad \mathbf{x}(0) = \mathbf{x}(T).$$

时间反向积分采用与正向积分相同的方法，但沿递减时间网格进行. 使用 Euler 法、步长 $h > 0$ ，从 $t_0 = T$ 、 $\mathbf{x}_0 = \mathbf{x}(T)$ 出发，更新为

$$t_{n+1} = t_n - h, \quad \mathbf{x}_{n+1} = \mathbf{x}_n - h \mathbf{v}(\mathbf{x}_n, t_n).$$

必须注意保证数值稳定性，尤其对于刚性问题（即状态向量的某些分量比其他分量演化快得多，需要极小时间步才能稳定积分），扩散模型的 PF-ODE 采样中经常遇到这类问题.

常微分方程的时间反转在理论上很直接：由于 $\mathbf{x}(0)$ 与 $\mathbf{x}(T)$ 之间是双射，只需对时间重参数化. 但随机微分方程并非如此，其内在随机性使直接时间反转不可行，下一节将详细说明.

A.2 随机微分方程基础

随机微分方程 (SDE) 是加入随机性的常微分方程 (ODE) 的扩展, 为受不确定性影响的系统建模提供数学框架. 本章介绍随机微分方程: 从常微分方程的离散化出发, 扩展至随机微分方程的离散化, 最后讨论一般随机微分方程, 包括伊藤微积分与伊藤公式.

A.2.1 从常微分方程到随机微分方程: 直观介绍

从描述状态变量 $\mathbf{x}(t) \in \mathbb{R}^D$ 确定性演化的常微分方程开始:

$$\frac{d\mathbf{x}(t)}{dt} = \mathbf{f}(\mathbf{x}(t), t), \quad \mathbf{x}(0) = \mathbf{x}_0. \quad (\text{A.2.1})$$

这里, $\mathbf{f}: \mathbb{R}^D \times [0, T] \rightarrow \mathbb{R}^D$ 是依赖时间的速度场, 决定 $\mathbf{x}(t)$ 的动力学. 该常微分方程的解为光滑轨迹 $t \mapsto \mathbf{x}(t)$, 完全由初始条件 $\mathbf{x}_0$ 确定.

离散化视角. 为建立直觉, 考虑以小时间步 Δt 对式 (A.2.1) 进行 Euler 离散化:

$$\mathbf{x}_{t+\Delta t} = \mathbf{x}_t + \mathbf{f}(\mathbf{x}_t, t)\Delta t.$$

当 $\Delta t \rightarrow 0$ 时, 这一近似越来越准确, 并在 $\mathbf{f}$ 满足标准正则性条件时, 收敛至常微分方程的精确解.

引入随机性: 从常微分方程到随机微分方程. 对许多实际系统而言, 完全掌握动力学并不现实. 噪声、不确定性或未建模的相互作用都可能影响演化. 为纳入这类随机性, 我们在常微分方程中加入随机项:

$$\mathbf{x}_{t+\Delta t} = \mathbf{x}_t + \mathbf{f}(\mathbf{x}_t, t)\Delta t + g(t)\sqrt{\Delta t} \cdot \boldsymbol{\epsilon}_t, \quad (\text{A.2.2})$$

其中

- $g: [0, T] \rightarrow \mathbb{R}$ 是扩散系数 (可能同时依赖状态与时间, 但此处假设只依赖时间);
- $\boldsymbol{\epsilon}_t \sim \mathcal{N}(\mathbf{0}, \mathbf{I}_D)$ 是独立同分布的标准高斯向量.

修改后的更新规则不仅反映确定性漂移, 也反映按 $\sqrt{\Delta t}$ 缩放的随机扰动. 这一缩放保证在极限 $\Delta t \rightarrow 0$ 下, 随机扰动仍保持有限. 关键在于, 当 $\Delta t \rightarrow 0$ 时, 这一表述产生了连续时间随机过程, 从而引出随机微分方程框架.

随机微分方程. 形式上, 离散更新式 (A.2.2) 在 $\Delta t \rightarrow 0$ 时的极限定义了随机微分方程:

$$d\mathbf{x}(t) = \mathbf{f}(\mathbf{x}(t), t) dt + g(t) d\mathbf{w}(t). \quad (\text{A.2.3})$$

这里, $\mathbf{w}(t) \in \mathbb{R}^D$ 是 *Wiener* 过程 (标准布朗运动), 即具有下列特征的连续时间随机过程:

- **初始状态**: $\mathbf{w}(0) = 0$ 几乎必然成立;
- **独立增量**: 对 $0 \leq s < t$, 增量 $\mathbf{w}(t) - \mathbf{w}(s)$ 与过去独立;
- **高斯增量**:

$$\mathbf{w}(t) - \mathbf{w}(s) \sim \mathcal{N}(\mathbf{0}, (t-s)\mathbf{I}_D) \quad (\text{A.2.4})$$

- **连续性**: 样本路径 $t \mapsto \mathbf{w}(t)$ 几乎必然连续, 但处处不可微.

此外, 常用记号

$$d\mathbf{w}(t) := \mathbf{w}(t+dt) - \mathbf{w}(t)$$

表示 Wiener 过程的无穷小增量.

这一记号虽富于启发性, 却是直觉性的, 不应解释为经典微分 (例如 Riemann 或 Lebesgue 意义下的微分), 因为布朗路径几乎必然处处不可微. 它只是表达高斯增量性质的形式简记:

$$d\mathbf{w}(t) \sim \mathcal{N}(\mathbf{0}, dt \mathbf{I}_D),$$

意即在长度为 dt 的无穷小时间区间上, Wiener 过程的增量表现为均值为零、协方差为 $dt \mathbf{I}_D$ 的高斯随机变量.

A.2.2 式 (A.2.3) 的进一步说明

式 (A.2.3) 中的随机微分方程应理解为其积分形式:

$$\mathbf{x}(t) = \mathbf{x}(0) + \int_0^t \mathbf{f}(\mathbf{x}(s), s) ds + \int_0^t g(s) d\mathbf{w}(s), \quad (\text{A.2.5})$$

在伊藤意义下解释. 这里, 第一个积分是经典 (Riemann 或 Lebesgue) 积分, 表示确定性漂移的累积; 第二个积分是伊藤随机积分, 关于 Wiener 过程 $\mathbf{w}(t)$ 积分. 我们不完整给出伊藤积分的严格构造, 而提供以下直观理解.

伊藤积分的直观理解. 伊藤积分可视为离散和的 (依概率) 极限:

$$\sum_i g(t_i) (\mathbf{w}(t_{i+1}) - \mathbf{w}(t_i)),$$

其中, 被积函数 $g(t)$ 在每个子区间的左端点 t_i 求值. 这种左端点求值至关重要, 使伊藤积分区别于常使用中点或其他求值规则的经典积分.

由于布朗路径连续却几乎必然处处不可微, 经典积分无法适用. 伊藤积分处理这种不规则性, 刻画随机波动随时间的累积影响.

微分记号的使用. $dx(t)$ 、 dt 与 $d\mathbf{w}(t)$ 等表达式并非经典微分，而是表示相应过程无穷小增量的形式记号。尽管是直觉性的，它们便于以类似常微分方程的方式表达随机微分方程，因此被广泛使用，也便于在伊藤微积分中进行形式运算。

伊藤微积分如何应用于扩散模型，将在章 C 中说明。

与常微分方程的比较. 对于常微分方程，例如

$$\frac{dx(t)}{dt} = \mathbf{f}(\mathbf{x}(t), t),$$

其积分形式

$$\mathbf{x}(t) = \mathbf{x}(0) + \int_0^t \mathbf{f}(\mathbf{x}(\tau), \tau) d\tau$$

由微积分基本定理保证，该定理保证可从导数恢复可微函数。

对于式 (A.2.3) 等随机微分方程，这一定理没有直接对应的形式，因为布朗运动不可微，且随机积分不遵循经典链式法则。伊藤微积分引入了其他工具（例如伊藤引理）来分析和处理随机动力学。

因此，随机微分方程的微分记号虽紧凑、直观，但严格理解依赖于通过伊藤积分给出的积分表述来解释它们。

A.2.3 随机微分方程的数值求解器.

与常微分方程类似，若 $\mathbf{f}(\cdot, t)$ 和 $g(\cdot)$ 满足某些光滑性条件，即 $\mathbf{f}(\cdot, t)$ 关于 $\mathbf{x}$ 满足 Lipschitz 条件与线性增长条件，且 $g(\cdot)$ 平方可积，则式 (A.2.3) 有唯一解¹。

对于式 (A.2.3) 形式的一般随机微分方程，通常无法获得闭式解，因而需要数值方法。一种常见方法是 *Euler-Maruyama* 法，它推广了常微分方程的 Euler 法；事实上，我们已在式 (A.2.2) 中见过它。它在时间步 Δt 上近似漂移项 $\mathbf{f}(\mathbf{x}(t), t)$ ，并使用高斯增量 $\sqrt{\Delta t} \epsilon_t$ 模拟随机噪声 $g(t) d\mathbf{w}(t)$ ，其中 $\epsilon_t \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 。

后文节 C.1.5 将说明，线性随机微分方程具有闭式解。

¹这里的解是在强意义下的，即在固定概率空间上，相对于给定布朗运动 $\mathbf{w}(t)$ ， $\mathbf{x}(t)$ 满足随机微分方程的积分形式（见式 (A.2.5)）。此处省略详细技术定义。

附录 B 密度演化：从变量替换到 Fokker–Planck 方程

理解概率密度如何在变换下演化，是概率论与生成建模的基础。特别地，扩散模型旨在构造生成过程，使其诱导的密度路径逆转预先定义的前向过程。这一演化由连续性方程控制；在随机情形下，则由 Fokker–Planck 方程控制。

这些名称虽然可能陌生或令人望而生畏，但实际上都是基础微积分中变量替换公式的连续时间对应形式。节 B.1 通过一系列逐步推广的变量替换公式来引出它们，从确定性双射开始，最终到达随机微分方程。这一过程自然地衔接离散映射与连续时间流动力学。这一统一框架的概览见图 B.1。

节 B.2 给出连续性方程的物理与直观解释，强调它与动力系统中密度守恒的联系。




图 B.1: 统一的变量替换公式. 从上至下: 单个双射及其 (原文此处未完); 多个双射的复合; 由常微分方程控制的连续时间确定性流及相关连续性方程; 由随机微分方程建模的随机流及对应的 Fokker–Planck 方程.

B.1 变量替换公式: 从确定性映射到随机流

本节通过类比微积分中的经典变量替换公式, 揭开连续性方程与 Fokker–Planck 方程的神秘面纱. 从熟悉的单变量情形出发, 推广至多变量情形与概率密度 (节 B.1.1), 再推广至双射映射的复合, 其连续时间极限引出连续性方程 (节 B.1.2). 最后, 通过引入随机噪声纳入随机性, 自然地将连续性方程扩展为 Fokker–Planck 方程 (节 B.1.3).

B.1.1 确定性映射的变量替换公式

按照确定性映射移动粒子，研究其分布规律（密度）如何演化。关键原则是概率质量守恒，其基础是微积分与概率论中的基本结果：变量替换公式。该公式描述积分，进而描述概率密度，如何在光滑双射映射下变换。为建立直觉，先考虑一次更新，再扩展至连续多次变换。

单次更新. 考虑将向量场（类似于力） $\Psi: \mathbb{R}^D \rightarrow \mathbb{R}^D$ 作用一个单位时间所诱导的单次更新规则。从粒子初始状态 $\mathbf{x}_0$ 出发，其下一状态为

$$\mathbf{x}_1 = \Psi(\mathbf{x}_0).$$

底层模式（密度）及其移动方式. 若初始状态遵循密度 p_0 描述的底层“规律 / 模式”（即 $\mathbf{x}_0 \sim p_0$ ），则应用 Ψ 会产生 $\mathbf{x}_1$ 的新密度 p_1 （即 $\mathbf{x}_1 \sim p_1$ ）。假设 Ψ 是光滑双射，可通过标准变量替换公式从 p_0 得到 p_1 ：

$$p_1(\mathbf{x}_1) = p_0(\Psi^{-1}(\mathbf{x}_1)) \cdot \left| \det \left(\frac{\partial \Psi^{-1}}{\partial \mathbf{x}_1} \right) \right|. \quad (\text{B.1.1})$$

这里， $\frac{\partial \Psi}{\partial \mathbf{x}}$ 是 Ψ 的雅可比矩阵，记为 $\partial_{\mathbf{x}} \Psi$ 。等价地，在原坐标中，

$$p_0(\mathbf{x}_0) = p_1(\Psi(\mathbf{x}_0)) \left| \det \partial_{\mathbf{x}} \Psi(\mathbf{x}_0) \right|.$$

换言之， Ψ 将密度 p_0 重塑为 p_1 。因子 $|\det \partial_{\mathbf{x}} \Psi|$ 表示局部体积变化；由于概率质量守恒，密度通过该因子的逆来补偿。

作为简单情形，若 Ψ 是由可逆矩阵 $\mathbf{A}$ 给出的线性映射（即 $\mathbf{x}_1 = \mathbf{A}\mathbf{x}_0$ ），则

$$p_1(\mathbf{x}_1) = p_0(\mathbf{A}^{-1}\mathbf{x}_1) \left| \det \mathbf{A}^{-1} \right|.$$

示意地，可以理解为：

$$\begin{array}{ll} \text{样本:} & \mathbf{x}_0 \xrightarrow{\Psi} \mathbf{x}_1 \\ \text{密度:} & p_{\mathbf{x}_0}(\mathbf{x}_0) \xrightarrow{\Psi} p_{\mathbf{x}_1}(\mathbf{x}_1) \end{array}$$

为何式 (B.1.1) 是变量替换公式？ 它直接来自微积分中熟悉的规则。

单变量情形. 设 $y = \Psi(x)$ 光滑且可逆。将关于 y 的积分改写为关于 x 的积分，得到

$$\int g(y) \, dy = \int g(\Psi(x)) \cdot |\Psi'(x)| \, dx,$$

其中， $|\Psi'(x)|$ 补偿区间的拉伸或压缩，保证面积保持不变。

多变量情形. 对 $\Psi: \mathbb{R}^D \rightarrow \mathbb{R}^D$, 令 $\mathbf{y} = \Psi(\mathbf{x})$, 有

$$\int g(\mathbf{y}) \, d\mathbf{y} = \int g(\Psi(\mathbf{x})) |\det(\partial_{\mathbf{x}} \Psi)| \, d\mathbf{x},$$

因此, 无穷小体积按如下方式变换:

$$d\mathbf{y} = |\det(\partial_{\mathbf{x}} \Psi)| \, d\mathbf{x}.$$

由此得到式 (B.1.1) 中的密度公式:

$$\begin{aligned} p_{\mathbf{y}}(\mathbf{y}) &= \int_{\mathbb{R}^D} \delta(\mathbf{y} - \Psi(\mathbf{x})) p_{\mathbf{x}}(\mathbf{x}) \, d\mathbf{x} \\ &= p_{\mathbf{x}}(\Psi^{-1}(\mathbf{y})) \left| \det \left(\frac{\partial \Psi^{-1}}{\partial \mathbf{y}} \right) \right|. \end{aligned}$$

多个双射的复合. 现在依次应用若干次更新. 令 $\mathbf{x}_k = \Psi_k(\mathbf{x}_{k-1})$, $k = 1, \dots, L$; 即

$$\mathbf{x}_0 \xrightarrow{\Psi_1} \mathbf{x}_1 \xrightarrow{\Psi_2} \dots \xrightarrow{\Psi_L} \mathbf{x}_L,$$

其中, 每个 $\Psi_k: \mathbb{R}^D \rightarrow \mathbb{R}^D$ 都是光滑双射. 若初始状态遵循密度 p_0 (即 $\mathbf{x}_0 \sim p_0$), 则这串更新为 $\mathbf{x}_1, \dots, \mathbf{x}_L$ 诱导密度 $p_1, \dots, p_L$.

由于每一步都保持概率质量守恒, 密度按下式演化:

$$p_k(\mathbf{x}_k) = p_{k-1}(\mathbf{x}_{k-1}) \left| \det \partial_{\mathbf{x}_{k-1}} \Psi_k(\mathbf{x}_{k-1}) \right|^{-1}, \quad k = 1, \dots, L.$$

递推可得, $\mathbf{x}_L$ 处的最终密度为

$$p_{\mathbf{x}_L}(\mathbf{x}_L) = p_{\mathbf{x}_0}(\mathbf{x}_0) \cdot \prod_{k=1}^L \left| \det \left(\frac{\partial \Psi_k}{\partial \mathbf{x}_{k-1}} \right) \right|^{-1}. \quad (\text{B.1.2})$$


等价地, 以对数密度形式表示为:

$$\log p_{\mathbf{x}_L}(\mathbf{x}_L) = \log p_{\mathbf{x}_0}(\mathbf{x}_0) - \sum_{k=1}^L \log \left| \det \left(\frac{\partial \Psi_k}{\partial \mathbf{x}_{k-1}} \right) \right|.$$


这一表达式反映了每个变换 Ψ_k 如何拉伸或收缩体积, 由雅可比行列式刻画. 这些局部体积变化沿变换路径累积, 决定复合映射下的最终概率密度.

式 (B.1.2) 是归一化流的核心原理 (见节 5.1.2) .


B.1.2 连续时间极限：连续性方程



(a) 向量场示意图. 箭头表示拖动粒子穿过空间的力, 使底层网格相应变形.



(b) 粒子云动力学. 预先定义的向量场 (解释为力) 产生流, 将粒子从初始状态输运出去.



(c) 密度演化. 粒子被向量场平流输运时, 密度等高线相应变形, 反映流如何重塑底层分布.

图 B.2: 向量场下粒子与密度动力学的示意图. 各列从左至右显示连续时刻的快照. 这些图经作者许可, 改编自 Lipman et al. (2024).

现在从离散更新转向连续描述. 假设粒子运动由时变速度场 $\mathbf{f}: \mathbb{R}^D \times [0, T] \rightarrow \mathbb{R}^D$ 驱动. 想象通过无穷多次微小双射更新, 使粒子 $\mathbf{x}_0 \sim p_0$ 演化. 在时刻 t 、长度为 $\Delta t > 0$ 的每一步中, 更新为

$$\mathbf{x}_{t+\Delta t} = \Psi(\mathbf{x}_t) := \mathbf{x}_t + \Delta t \mathbf{f}(\mathbf{x}_t, t).$$

当 $\Delta t \rightarrow 0$ 时, 这些更新的复合收敛至由速度场 $\mathbf{f}: \mathbb{R}^D \times [0, T] \rightarrow \mathbb{R}^D$ 控制的连续流:

$$\frac{d\mathbf{x}(t)}{dt} = \mathbf{f}(\mathbf{x}(t), t), \quad \mathbf{x}(0) = \mathbf{x}_0 \sim p_0. \quad (\text{B.1.3})$$

在适当的光滑性假设下 (见章 A), 该常微分方程对每个初始条件都有唯一解, 定义确定性流映射 $\Psi_{0 \rightarrow t}: \mathbb{R}^D \rightarrow \mathbb{R}^D$. 换言之, $\Psi_{0 \rightarrow t}$ 将初始状态 $\mathbf{x}_0$ 送至式 (B.1.3) 在时刻 t

的解：

$$\Psi_{0 \rightarrow t}(\mathbf{x}_0) = \mathbf{x}_0 + \int_0^t \mathbf{f}(\mathbf{x}(\tau), \tau) d\tau.$$

因此，整个分布也随之移动：初始密度 p_0 被输运为新密度 p_t ，即 $\mathbf{x}(t)$ 的分布。形式化地，将其写成推前：

$$p_t = (\Psi_{0 \rightarrow t})_{\#} p_0.$$

当 $\Psi_{0 \rightarrow t}$ 光滑且可逆时，它简化为熟悉的变量替换规则：

$$p_t(\mathbf{x}) = p_0(\Psi_{t \rightarrow 0}(\mathbf{x})) \left| \det \partial_{\mathbf{x}} \Psi_{t \rightarrow 0}(\mathbf{x}) \right| = \int \delta(\mathbf{x} - \Psi_{t \rightarrow 0}(\mathbf{x}_0)) p_0(\mathbf{x}_0) d\mathbf{x}_0.$$

连续性方程：密度如何随时间移动。 无需为每个时刻的密度分别写公式，而可用关于空间 $\mathbf{x}$ 和时间 t 的微分方程描述它如何连续移动。思想很简单：概率质量守恒，速度场 $\mathbf{f}$ 只在空间中重新分配概率质量。由此得到连续性方程：

$$\frac{\partial}{\partial t} p_t(\mathbf{x}) + \nabla \cdot (p_t(\mathbf{x}) \mathbf{f}(\mathbf{x}, t)) = 0. \quad (\text{B.1.4})$$

这里，散度项 $\nabla \cdot (p_t \mathbf{f})$ 衡量流如何在局部扩张或压缩密度，保证总概率保持为 1。

这一偏微分方程（PDE）保证流移动粒子时概率质量守恒。事实上，它可视为变量替换公式的连续时间对应形式。

通过变量替换公式推导连续性方程。 从概念上说，也可对式 (B.1.2) 取连续时间极限，得到连续性方程。不过，此处采用基于式 (B.1.1) 的更直接推导。

离散化与变量替换公式。 考虑

$$\mathbf{x}_{t+\Delta t} := \Psi(\mathbf{x}_t) = \mathbf{x}_t + \Delta t \mathbf{f}(\mathbf{x}_t, t),$$

这实际上是在小时间区间 $\Delta t > 0$ 上，对式 (B.1.3) 作前向 Euler 离散化。映射 Ψ 关于 $\mathbf{x}_t$ 的雅可比矩阵展开为

$$\frac{\partial \Psi}{\partial \mathbf{x}_t} = \mathbf{I} + \Delta t \nabla_{\mathbf{x}} \mathbf{f}(\mathbf{x}_t, t) + \mathcal{O}(\Delta t^2),$$

因此，其行列式满足

$$\det \left(\frac{\partial \Psi}{\partial \mathbf{x}_t} \right) = 1 + \Delta t \nabla \cdot \mathbf{f}(\mathbf{x}_t, t) + \mathcal{O}(\Delta t^2).$$

这里使用了 $\Delta t \rightarrow 0$ 时的标准展开 $\det(\mathbf{I} + \Delta t \mathbf{A}) = 1 + \Delta t \text{Tr}(\mathbf{A}) + \mathcal{O}(\Delta t^2)$ ，以及 $\nabla \cdot \mathbf{f} = \text{Tr}(\nabla_{\mathbf{x}} \mathbf{f})$ 。

应用变量替换公式，对数密度按如下方式演化：

$$\log p_{t+\Delta t}(\mathbf{x}_{t+\Delta t}) = \log p_t(\mathbf{x}_t) - \Delta t \nabla \cdot \mathbf{f}(\mathbf{x}_t, t) + \mathcal{O}(\Delta t^2).$$

应用变量替换公式，对数密度按如下方式演化：

$$\log p_{t+\Delta t}(\mathbf{x}_{t+\Delta t}) = \log p_t(\mathbf{x}_t) - \Delta t \nabla \cdot \mathbf{f}(\mathbf{x}_t, t) + \mathcal{O}(\Delta t^2).$$

即

$$\log p_{t+\Delta t}(\mathbf{x}_{t+\Delta t}) - \log p_t(\mathbf{x}_t) = -\Delta t \nabla \cdot \mathbf{f}(\mathbf{x}_t, t) + \mathcal{O}(\Delta t^2). \quad (\text{B.1.5})$$

使用 Taylor 展开。 现在对左边作多变量 Taylor 展开：

$$\begin{aligned} & \log p_{t+\Delta t}(\mathbf{x}_{t+\Delta t}) - \log p_t(\mathbf{x}_t) \\ &= \Delta t \partial_t \log p_t(\mathbf{x}_t) + (\mathbf{x}_{t+\Delta t} - \mathbf{x}_t)^\top \nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t) + \mathcal{O}(\Delta t^2). \end{aligned}$$

代入 $\mathbf{x}_{t+\Delta t} - \mathbf{x}_t = \mathbf{f}(\mathbf{x}_t, t)\Delta t$ ，得到：

$$\begin{aligned} & \log p_{t+\Delta t}(\mathbf{x}_{t+\Delta t}) - \log p_t(\mathbf{x}_t) \\ &= \Delta t \partial_t \log p_t(\mathbf{x}_t) + \Delta t \mathbf{f}(\mathbf{x}_t, t)^\top \nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t) + \mathcal{O}(\Delta t^2). \end{aligned}$$

与式 (B.1.5) 中的各项匹配，并令 $\Delta t \rightarrow 0$ ，得到

$$\partial_t \log p_t(\mathbf{x}_t) = -\nabla_{\mathbf{x}_t} \cdot \mathbf{f}(\mathbf{x}_t, t) - \mathbf{f}(\mathbf{x}_t, t)^\top \nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t).$$

取指数并应用乘积法则，即得连续性方程。

速度优先 (Lagrange 视角) 与密度优先 (Euler 视角)。 应注意粒子动力学与密度动力学之间的关键不对称性。从速度场出发，可得到唯一的粒子流，进而得到唯一的密度演化。但仅指定密度路径，并不能确定唯一速度场：许多不同的流都可能产生同一串密度。

速度优先 (Euler 视角：流 $\Rightarrow$ 密度)。 到目前为止，我们假设速度场 $\mathbf{f}$ 已给定。粒子的常微分方程

$$\frac{d\mathbf{x}(t)}{dt} = \mathbf{f}(\mathbf{x}(t), t)$$

描述每个粒子如何移动，而密度的偏微分方程

$$\partial_t p_t + \nabla \cdot (p_t \mathbf{f}_t) = 0$$

描述整个粒子分布如何演化。这两个视角相互联系：按常微分方程移动粒子，自然产生满足偏微分方程的密度。此时，粒子流 $\Psi_{0 \rightarrow t}$ 唯一确定：从 $\mathbf{x}(0) \sim p_0$ 出发，每条轨迹 $\mathbf{x}(t)$ 都被确定，所得密度 p_t 遵循连续性方程。这里，粒子动力学与密度动力学完全一致。

密度优先 (Euler 视角: 密度 $\nRightarrow$ 唯一的流). 若只从密度路径 $t \mapsto p_t$ 出发 (例如流匹配中的节 5.3.2), 速度场便不再唯一确定. 例如, 若向量场 $\mathbf{w}_t$ 满足

$$\nabla_{\mathbf{x}} \cdot (p_t(\mathbf{x}) \mathbf{w}_t(\mathbf{x})) = 0 \quad (\text{相对于 } p_t \text{ 无净通量}),$$

则 $\mathbf{f}_t$ 与 $\mathbf{f}_t + \mathbf{w}_t$ 都产生同一密度演化. 因此, 同一密度路径可能对应许多不同的流, 选择某个特定粒子流 $\Psi_{0 \rightarrow t}$, 就相当于从这些可能性中选择某个特定速度场.

并非每条给定路径 p_t 都能实际由粒子在某个速度场下移动产生. 连续性方程 (式 (B.1.4)) 提供一致性检验, 判断密度路径能否 “由流生成”. 若存在速度场 $\mathbf{f}$, 使遵循下式的粒子

$$\frac{d\mathbf{x}(t)}{dt} = \mathbf{f}(\mathbf{x}(t), t)$$

通过流映射 $\Psi_{0 \rightarrow t}$ 恰好产生密度 p_t , 则称 p_t 可实现 (或由 $\mathbf{f}$ 生成). 即当 p_t 与 $\mathbf{f}$ 共同满足式 (B.1.4) 时, 可实现性成立.

直观地说, 可实现性意味着 p_t 随时间的快照可由粒子在某个速度场下移动来解释, 而非任意一串分布.

这一条件成立时, 密度 p_t 就是初始密度 p_0 沿流映射 $\Psi_{0 \rightarrow t}$ 的推前. 此时, 熟悉的变量替换公式适用:

$$\begin{aligned} p_t &= (\Psi_{0 \rightarrow t})_{\#} p_0 \\ &= p_0(\Psi_{t \rightarrow 0}(\mathbf{x})) \left| \det \partial_{\mathbf{x}} \Psi_{t \rightarrow 0}(\mathbf{x}) \right| \\ &= \int \delta(\mathbf{x} - \Psi_{t \rightarrow 0}(\mathbf{x}_0)) p_0(\mathbf{x}_0) d\mathbf{x}_0. \end{aligned}$$

(选读) 条件化. 若引入额外条件变量 $\mathbf{z} \sim \pi(\mathbf{z})$, 则相同推理对每个固定 $\mathbf{z}$ 适用:

$$\frac{d\mathbf{x}(t)}{dt} = \mathbf{v}_t(\mathbf{x}(t)|\mathbf{z})$$

其推前为 $p_t(\cdot|\mathbf{z}) = (\Psi_{0 \rightarrow t}(\cdot; \mathbf{z}))_{\#} p_0$, 连续性方程为

$$\partial_t p_t(\mathbf{x}|\mathbf{z}) + \nabla \cdot (p_t(\mathbf{x}|\mathbf{z}) \mathbf{v}_t(\mathbf{x}|\mathbf{z})) = 0$$

边缘密度则为

$$p_t(\mathbf{x}) = \int p_t(\mathbf{x}|\mathbf{z}) \pi(\mathbf{z}) d\mathbf{z}.$$

B.1.3 随机过程: Fokker–Planck 方程

加入噪声后, 动力学遵循式 (A.2.3) 中的随机微分方程:

$$d\mathbf{x}(t) = \mathbf{f}(\mathbf{x}(t), t) dt + g(t) d\mathbf{w}(t).$$

此时, 密度 $p_t(\mathbf{x})$ 满足 Fokker–Planck 方程:

$$\begin{aligned}\frac{\partial p_t(\mathbf{x})}{\partial t} &= -\nabla \cdot (\mathbf{f}(\mathbf{x}, t) p_t(\mathbf{x})) + \frac{1}{2} g^2(t) \Delta p_t(\mathbf{x}) \\ &= -\nabla \cdot \left(\left(\mathbf{f}(\mathbf{x}, t) - \frac{1}{2} g^2(t) \nabla_{\mathbf{x}} \log p_t(\mathbf{x}) \right) p_t(\mathbf{x}) \right).\end{aligned}$$

这里, $\Delta p_t = \nabla \cdot \nabla_{\mathbf{x}} p_t$ 是 Laplace 算子. 第一项描述确定性漂移 $\mathbf{f}$ 对概率质量的输运; 第二项对随机噪声导致的密度扩散建模, 其方差与 $\frac{1}{2} g^2(t)$ 成正比.

Fokker-Planck 方程的推导更为复杂, 留待节 C.1.4 给出.

B.2 连续性方程的直观理解

本节给出连续性方程的物理解释，强调它作为动力系统中概率密度守恒定律的作用。

B.2.1 连续性方程的物理解释

考虑三维空间中一个固定的小控制体积（长方体），其中心为 $\mathbf{x} = (x, y, z)$ ，边长为 Δx 、 Δy 与 Δz 。设 $p(\mathbf{x}, t)$ 表示某个守恒量（例如质量或概率）在位置 $\mathbf{x}$ 、时刻 t 的密度。盒内该量的总量为：

$$\text{盒内总量} = p(\mathbf{x}, t) \Delta x \Delta y \Delta z.$$

总量如何变化？ 总量的变化只能来自穿过盒子边界的通量。设 $\mathbf{j}(\mathbf{x}, t)$ 表示通量向量，即单位时间、单位面积流过的量。

x 方向的通量。 通过左侧面（位于 x ）的流入量近似为：

$$j_x(x, y, z, t) \Delta y \Delta z,$$

通过右侧面（位于 $x + \Delta x$ ）的流出量为：

$$j_x(x + \Delta x, y, z, t) \Delta y \Delta z.$$

因此， x 方向的净通量为：

$$[j_x(x, y, z, t) - j_x(x + \Delta x, y, z, t)] \Delta y \Delta z.$$

所有方向的净通量。 y 和 z 方向具有类似的项：

$$\begin{aligned} & [j_y(x, y, z, t) - j_y(x, y + \Delta y, z, t)] \Delta x \Delta z, \\ & [j_z(x, y, z, t) - j_z(x, y, z + \Delta z, t)] \Delta x \Delta y. \end{aligned}$$

将所有贡献相加，从盒子向外的总净通量为：

$$-\nabla \cdot \mathbf{j}(\mathbf{x}, t) \Delta x \Delta y \Delta z.$$

盒内变化率。 盒内总量的变化率为：

$$\frac{\partial p}{\partial t}(\mathbf{x}, t) \Delta x \Delta y \Delta z.$$

守恒原则。 假设该量守恒（例如总质量或总概率不随时间改变），则变化率等于净流出通量的负值：

$$\frac{\partial p}{\partial t}(\mathbf{x}, t) \Delta x \Delta y \Delta z = -\nabla \cdot \mathbf{j}(\mathbf{x}, t) \Delta x \Delta y \Delta z.$$

局部形式. 约去共同的体积因子 (对任意小盒子都成立), 得到连续性方程的局部形式:

$$\frac{\partial p}{\partial t} + \nabla \cdot \mathbf{j} = 0.$$

B.2.2 从守恒定律推导连续性方程

连续性方程形式化了动力系统中质量或电荷等物理量的守恒. 设 $p(\mathbf{x}, t)$ 表示守恒量在位置 $\mathbf{x} \in \mathbb{R}^D$ 、时刻 $t \in [0, T]$ 的密度, $\mathbf{v}(\mathbf{x}, t)$ 表示速度场.

步骤 1: 控制体积内的变化率. 考虑边界为 ∂V 的任意控制体积 $V \subset \mathbb{R}^D$. V 内守恒量的总量为

$$\int_V p(\mathbf{x}, t) dV,$$

其时间导数给出累积速率:

$$\frac{\partial}{\partial t} \int_V p(\mathbf{x}, t) dV.$$

步骤 2: 穿过边界的净通量. 该量通过外法向量为 $\mathbf{n}$ 的边界 ∂V 离开 V . 净流出通量为

$$\int_{\partial V} p(\mathbf{x}, t) \mathbf{v}(\mathbf{x}, t) \cdot \mathbf{n} dS.$$

步骤 3: 守恒原则. 守恒意味着 V 内的累积速率等于净流出通量的负值:

$$\frac{\partial}{\partial t} \int_V p dV + \int_{\partial V} p \mathbf{v} \cdot \mathbf{n} dS = 0.$$

步骤 4: 散度定理. 应用散度定理, 将曲面积分变为体积分:

$$\int_{\partial V} p \mathbf{v} \cdot \mathbf{n} dS = \int_V \nabla \cdot (p \mathbf{v}) dV.$$

因此,

$$\frac{\partial}{\partial t} \int_V p dV + \int_V \nabla \cdot (p \mathbf{v}) dV = 0.$$

步骤 5: 局部形式. 由于控制体积 V 任意, 被积函数必须逐点为零. 由此得到连续性方程.

附录 C 扩散模型的幕后原理： 伊藤微积分与 Girsanov 定理

（基于得分的）扩散模型建立在 SDE 之上：漂移推动状态，而布朗项使状态随机扰动。与 ODE 轨迹不同，布朗轨迹处处不可微，因此普通链式法则失效。本节介绍两个使数学论述严谨的基本工具：

- **伊藤公式**是随机轨迹的正确链式法则。它说明当 $\mathbf{x}_t$ 遵循 SDE 时，函数 $\mathbf{h}(\mathbf{x}_t, t)$ 如何演化。它可用于推导 Fokker–Planck 方程、矩的动力学、伊藤乘积法则，以及基于得分的训练中使用的恒等式。
- **Girsanov 定理**是关于路径概率的测度变换结果。它量化了固定噪声而改变漂移时，似然如何变化。这将得分匹配与路径空间的 KL 散度联系起来，并解释了为什么学习反向 SDE 中的得分对应于最大化数据似然。

借助这些工具，扩散模型的标准推导（Fokker–Planck 方程、时间反向 SDE、训练目标和似然关系）便能清晰严谨地展开，无须诉诸含糊的直觉。

C.1 伊藤公式：随机过程的链式法则

标准微积分不能直接应用于随机过程，因为 Wiener 过程在经典意义下不可微。我们转而使用伊藤微积分，它提供了处理随机积分的运算法则。

C.1.1 动机：为什么需要特殊的链式法则？

考虑一个随时间 t 光滑演化的确定性时变函数 $\mathbf{y}_t$ （例如 ODE 的解）。对于函数 $\mathbf{h}(\mathbf{y}_t, t)$ ，通常的链式法则给出：

$$\frac{d\mathbf{h}}{dt} = \frac{\partial \mathbf{h}}{\partial t} + \nabla_{\mathbf{y}} \mathbf{h} \frac{d\mathbf{y}_t}{dt}.$$

这里， $\nabla_{\mathbf{y}} \mathbf{h}$ 是 $\mathbf{h}$ 的雅可比矩阵。对确定性轨迹 $\mathbf{y}_t$ ，这一法则完全适用。

问题 C.1.1. 但若 $\mathbf{x}_t$ 是一个随机过程，例如由如下 SDE 驱动，情况会如何？

$$d\mathbf{x}_t = \mathbf{f}(\mathbf{x}_t, t) dt + g(t) d\mathbf{w}_t$$

这正如式 (A.2.3) 所示。过程 $\mathbf{h}(\mathbf{x}_t, t)$ 满足什么 SDE？

普通链式法则为何失效？ 直接套用经典链式法则得到

$$d\mathbf{h} = \frac{\partial \mathbf{h}}{\partial t} dt + \nabla_{\mathbf{y}} \mathbf{h} \cdot d\mathbf{x}_t.$$

然而，这忽略了布朗增量满足 $d\mathbf{w}_t = \mathcal{O}(\sqrt{dt})$ ，并且

$$(d\mathbf{w}_t)^2 = dt.$$

因此，在随机微积分中， $d\mathbf{w}_t$ 的二阶项不会消失；这与经典微积分中 $(dt)^2$ 项可以忽略的情况不同。

例：简单例子—— $h(x_t) = x_t^2$

为获得直观认识，考虑简单的实值函数 $h(x_t) = x_t^2 \in \mathbb{R}$ ，其中随机变量 $x_t \in \mathbb{R}$ 满足

$$dx_t = \sigma dw_t,$$

其中 $\sigma > 0$ 为常数。若尝试使用经典链式法则，

$$dh = 2x_t dx_t = 2x_t \sigma dw_t.$$

若这一式子成立， $h(x_t)$ 的期望将不随时间变化，因为

$$\mathbb{E}[dh] = 2\sigma \mathbb{E}[x_t dw_t] = 2\sigma \mathbb{E}[x_t] \underbrace{\mathbb{E}[dw_t]}_{=0} = 0.$$

但根据布朗运动的经典性质（见式 (A.2.4)），我们知道

$$\mathbb{E}[x_t^2] = \sigma^2 t,$$

它随时间线性增长. 因而普通链式法则遗漏了一个重要的项. ■

C.1.2 由 Taylor 展开推导一维伊藤公式

由 Taylor 展开得到确定性链式法则. 为理解经典链式法则为何对 SDE 定义的随机过程失效, 我们先用 Taylor 展开回顾确定性情形. 考虑标量情况: $y_t \in \mathbb{R}$ 且 $h(\cdot, \cdot) \in \mathbb{R}$. 形式地令 $dy_t = y_{t+dt} - y_t$, 其中 $dt \approx 0$, 展开得:

$$\begin{aligned} & h(y_{t+dt}, t+dt) - h(y_t, t) \\ &= \frac{\partial h}{\partial t} dt + \frac{\partial h}{\partial y} dy_t + \frac{1}{2} \left(\frac{\partial^2 h}{\partial y^2} (dy_t)^2 + 2 \frac{\partial^2 h}{\partial t \partial y} dt dy_t + \frac{\partial^2 h}{\partial t^2} (dt)^2 \right) + \mathcal{O}(dt^3), \end{aligned}$$

这里, $dt dy_t = \left(\frac{dy_t}{dt}\right) (dt)^2 = \mathcal{O}(dt^2)$, 同样有 $(dt)^2 = \mathcal{O}(dt^2)$. 因此, 所有灰色部分均可忽略, 全微分为:

$$dh = \frac{\partial h}{\partial t} dt + \frac{\partial h}{\partial y} dy_t + \mathcal{O}(dt^2).$$

由随机 Taylor 展开得到伊藤公式. 现在考虑由如下 SDE 支配的随机过程 $x_t \in \mathbb{R}$:

$$dx_t = f(x_t, t) dt + g(t) dw_t,$$

其中 w_t 是标准布朗运动. 我们希望计算标量值函数 $h(x_t, t)$ 的微分.

使用保留 dx_t 二阶项的随机 Taylor 展开 (Kloeden et al., 1992), 得到:

$$\begin{aligned} & h(x_{t+dt}, t+dt) - h(x_t, t) \\ &= \frac{\partial h}{\partial t} dt + \frac{\partial h}{\partial x} dx_t + \frac{1}{2} \left(\frac{\partial^2 h}{\partial x^2} (dx_t)^2 + 2 \frac{\partial^2 h}{\partial t \partial x} dt dx_t + \frac{\partial^2 h}{\partial t^2} (dt)^2 \right) + \dots \end{aligned}$$

可忽略的交叉项. 由布朗运动的尺度性质 (式 (A.2.4)),

$$dw_t = \mathcal{O}(\sqrt{dt}) \quad \Rightarrow \quad dt \cdot dw_t = \mathcal{O}((dt)^{3/2}).$$

因此,

$$dt \cdot dx_t = dt (f dt + g dw_t) = f(dt)^2 + g \cdot dt \cdot dw_t = \mathcal{O}((dt)^{3/2}).$$

所以, 灰色项可以忽略: 它们为 $\mathcal{O}((dt)^{3/2})$ 或更小的量.

二阶项 $(dx_t)^2$. 利用 SDE 展开得:

$$\begin{aligned} (dx_t)^2 &= (f dt + g dw_t)^2 \\ &= f^2(dt)^2 + 2fg dt dw_t + g^2(dw_t)^2 \\ &= \mathcal{O}((dt)^2) + \mathcal{O}((dt)^{3/2}) + g^2 \mathcal{O}(dt) \\ &= g^2(t) dt + \mathcal{O}((dt)^{3/2}). \end{aligned}$$

合并各项，得到微分：

$$dh(x_t, t) = \frac{\partial h}{\partial t} dt + \frac{\partial h}{\partial x} dx_t + \frac{1}{2} \frac{\partial^2 h}{\partial x^2} g^2(t) dt.$$

代入 $dx_t = f(x_t, t) dt + g(t) dw_t$ ，得到：

$$dh(x_t, t) = \left(\frac{\partial h}{\partial t} + f \frac{\partial h}{\partial x} + \frac{1}{2} g^2 \frac{\partial^2 h}{\partial x^2} \right) dt + g \frac{\partial h}{\partial x} dw_t.$$

这就是一维伊藤公式。

例：简单例子—— $h(x_t) = x_t^2$

重新考察简单例子 $h(x_t) = x_t^2$ ，其中随机过程 $x_t \in \mathbb{R}$ 满足

$$dx_t = \sigma dw_t,$$

其中 $\sigma > 0$ 为常数. 对 $h(x_t) = x_t^2$ 正确应用伊藤公式，得到：

$$dh(x_t) = d(x_t^2) = 2x_t dx_t + \sigma^2 dt.$$

代入 $dx_t = \sigma dw_t$ ，上式变为：

$$d(x_t^2) = 2x_t \sigma dw_t + \sigma^2 dt.$$

C.1.3 伊藤公式：SDE 的链式法则

下面总结刚才推导的一维伊藤公式. 采用类似论证，这一结果可自然推广到多维情形. 虽然我们省略详细推导，但为完整起见仍给出一般公式.

最后，通过推导伊藤乘积法则展示伊藤公式的一个应用；该法则可用于计算随机过程 $\mathbf{x}_t$ 和 $\mathbf{y}_t$ 的 $d(\mathbf{x}_t^\top \mathbf{y}_t)$.

一维伊藤公式. 设 $x_t \in \mathbb{R}$ 是满足如下 SDE 的随机过程：

$$dx_t = f(x_t, t) dt + g(t) dw_t.$$

对于标量函数 $h: \mathbb{R} \times [0, T] \rightarrow \mathbb{R}$ ，过程 $h(x_t, t)$ 满足：

$$dh(x_t, t) = \left(\frac{\partial h}{\partial t} + f \frac{\partial h}{\partial x} + \frac{1}{2} g^2 \frac{\partial^2 h}{\partial x^2} \right) dt + g \frac{\partial h}{\partial x} dw_t.$$

标量输出的多维伊藤公式. 设 $\mathbf{x}_t \in \mathbb{R}^D$ 满足 SDE:

$$d\mathbf{x}_t = \mathbf{f}(\mathbf{x}_t, t) dt + g(t) d\mathbf{w}_t,$$

其中 $\mathbf{f}: \mathbb{R}^D \times [0, T] \rightarrow \mathbb{R}^D$, $g: [0, T] \rightarrow \mathbb{R}$, 而 $\mathbf{w}_t \in \mathbb{R}^D$ 是 D 维布朗运动. 设 $h: \mathbb{R}^D \times [0, T] \rightarrow \mathbb{R}$ 为标量值函数. 则 $h(\mathbf{x}_t, t)$ 满足:

$$dh(\mathbf{x}_t, t) = \left(\frac{\partial h}{\partial t} + \nabla_{\mathbf{x}} h^\top \mathbf{f} + \frac{1}{2} g^2(t) \text{Tr}(\nabla_{\mathbf{x}}^2 h) \right) dt + g(t) \nabla_{\mathbf{x}} h^\top d\mathbf{w}_t, \quad (\text{C.1.1})$$

其中 $\nabla_{\mathbf{x}} h \in \mathbb{R}^D$ 是梯度, $\nabla_{\mathbf{x}}^2 h \in \mathbb{R}^{D \times D}$ 是 h 关于 $\mathbf{x}$ 的 Hessian 矩阵.

例: 伊藤乘积法则

设 $\mathbf{x}_t, \mathbf{y}_t \in \mathbb{R}^D$ 为由如下 SDE 支配的向量值随机过程:

$$d\mathbf{x}_t = \mathbf{a}(\mathbf{x}_t, t) dt + b(t) d\mathbf{w}_t,$$

$$d\mathbf{y}_t = \mathbf{c}(\mathbf{y}_t, t) dt + d(t) d\mathbf{w}_t,$$

其中 $\mathbf{a}, \mathbf{c}: \mathbb{R}^D \times [0, T] \rightarrow \mathbb{R}^D$ 是向量场, $b(t), d(t) \in \mathbb{R}$ 是标量值函数. 这里, $\mathbf{w}_t \in \mathbb{R}^D$ 表示标准 D 维布朗运动.

我们希望推导如下标量值过程的 SDE:

$$z(t) := \mathbf{x}_t^\top \mathbf{y}_t.$$

对双线性函数 $h(\mathbf{x}, \mathbf{y}) := \mathbf{x}^\top \mathbf{y}$ 应用多元伊藤公式, 得到:

$$d(\mathbf{x}^\top \mathbf{y}) = (d\mathbf{x})^\top \mathbf{y} + \mathbf{x}^\top d\mathbf{y} + \text{Tr} [d\mathbf{x} \cdot (d\mathbf{y})^\top].$$

伊藤修正项计算如下:

$$\begin{aligned} d\mathbf{x} \cdot (d\mathbf{y})^\top &= b(t) d\mathbf{w}_t \cdot [d(t) d\mathbf{w}_t]^\top \\ &= b(t) d(t) d\mathbf{w}_t \cdot d\mathbf{w}_t^\top \\ &= b(t) d(t) dt \cdot \mathbf{I}_D. \end{aligned}$$

于是,

$$\text{Tr} [d\mathbf{x} \cdot (d\mathbf{y})^\top] = b(t) d(t) \text{Tr}(\mathbf{I}_D) dt = D b(t) d(t) dt.$$

汇总以上结果, 得到的 SDE 为:

$$d(\mathbf{x}^\top \mathbf{y}) = (d\mathbf{x})^\top \mathbf{y} + \mathbf{x}^\top d\mathbf{y} + D b(t) d(t) dt \quad (\text{C.1.2})$$

C.1.4 伊藤公式的应用：推导 Fokker–Planck 方程

本节应用式 (C.1.1) 中的伊藤公式推导 Fokker–Planck 方程。这一 PDE 描述了式 (A.2.3) 中 SDE 定义的 D 维扩散过程所对应的概率密度 $p_t(\mathbf{x})$ 随时间的演化。

步骤一：应用伊藤公式。 设 $\phi(\mathbf{x}, t)$ 为光滑检验函数 $\phi: \mathbb{R}^D \times [0, T] \rightarrow \mathbb{R}$ 。由伊藤公式：

$$d\phi(\mathbf{x}_t, t) = \left(\frac{\partial \phi}{\partial t} + \nabla_{\mathbf{x}} \phi^\top \mathbf{f}(\mathbf{x}_t, t) + \frac{1}{2} g^2(t) \text{Tr}[\nabla_{\mathbf{x}}^2 \phi] \right) dt + g(t) \nabla_{\mathbf{x}} \phi^\top d\mathbf{w}_t.$$

步骤二：取期望。 对 $p_t(\mathbf{x})$ 取期望，并注意到 $\mathbb{E}[d\mathbf{w}_t] = 0$ ：

$$\mathbb{E}[d\phi(\mathbf{x}_t, t)] = \mathbb{E} \left[\left(\frac{\partial \phi}{\partial t} + \nabla_{\mathbf{x}} \phi^\top \mathbf{f}(\mathbf{x}_t, t) + \frac{1}{2} g^2(t) \text{Tr}[\nabla_{\mathbf{x}}^2 \phi] \right) dt \right].$$

步骤三：用密度表示期望。 这一期望可以写为：

$$\mathbb{E}[d\phi(\mathbf{x}_t, t)] = \int \left(\frac{\partial \phi}{\partial t} + \nabla_{\mathbf{x}} \phi^\top \mathbf{f}(\mathbf{x}, t) + \frac{1}{2} g^2(t) \text{Tr}[\nabla_{\mathbf{x}}^2 \phi] \right) p_t(\mathbf{x}) d\mathbf{x} dt.$$

步骤四：分部积分。 在 $\mathbb{R}^D$ 中使用分部积分（散度定理）：

$$\begin{aligned} \int \nabla_{\mathbf{x}} \phi^\top \mathbf{f} p_t d\mathbf{x} &= - \int \phi \nabla_{\mathbf{x}} \cdot (\mathbf{f} p_t) d\mathbf{x}, \\ \int \text{Tr}[\nabla_{\mathbf{x}}^2 \phi] p_t d\mathbf{x} &= - \int \phi \Delta p_t d\mathbf{x}. \end{aligned}$$

步骤五：代入并整理。 代回得：

$$\mathbb{E}[d\phi(\mathbf{x}_t, t)] = \int \phi(\mathbf{x}, t) \left[\frac{\partial p_t}{\partial t} + \nabla_{\mathbf{x}} \cdot (\mathbf{f} p_t) - \frac{1}{2} g^2(t) \Delta p_t \right] d\mathbf{x} dt.$$

步骤六：得到 Fokker–Planck 方程。 由于 ϕ 任意，被积函数必须为零：

$$\frac{\partial p_t}{\partial t} = -\nabla_{\mathbf{x}} \cdot (\mathbf{f}(\mathbf{x}, t) p_t(\mathbf{x})) + \frac{1}{2} g^2(t) \Delta p_t(\mathbf{x}),$$

这就完成了 Fokker–Planck 方程的推导。

C.1.5 伊藤公式的应用：线性 SDE 的闭式解

本小节说明如何使用积分因子（类似 ODE 情形）与伊藤公式，得到线性 SDE 的闭式解。这一方法沿用了求解线性 ODE 的经典技巧，并将其适配于随机情形。

考虑如下形式的线性 SDE：

$$d\mathbf{x}_t = f(t)\mathbf{x}_t dt + g(t)d\mathbf{w}_t, \tag{C.1.3}$$

其中 $f(t)$ 和 $g(t)$ 是确定性函数， $\mathbf{w}_t$ 是标准 Wiener 过程。

线性 SDE 的闭式解. 使用积分因子法推导式 (C.1.3) 中线性 SDE 的显式解. 这类前向 SDE 经常出现在扩散模型中 (见节 4.1) .

步骤一: 定义积分因子. 令

$$\Psi(t) := \exp\left(-\int_0^t f(s)ds\right), \quad \text{并定义 } \mathbf{y}_t := \Psi(t)\mathbf{x}_t.$$

步骤二: 应用伊藤公式. 对函数 $\mathbf{h}(\mathbf{x}, t) := \Psi(t)\mathbf{x}$ 应用伊藤公式. 这实际上是式 (C.1.2) 中伊藤乘积法则的特殊情形. 由于 $\Psi(t)$ 是确定性的, 不存在交叉变差项, 公式简化为:

$$\begin{aligned} d\mathbf{y}_t &= d[\Psi(t)\mathbf{x}_t] \\ &= \Psi'(t)\mathbf{x}_t dt + \Psi(t)d\mathbf{x}_t \\ &= -f(t)\Psi(t)\mathbf{x}_t dt + \Psi(t)[f(t)\mathbf{x}_t dt + g(t)d\mathbf{w}_t] \\ &= \Psi(t)g(t)d\mathbf{w}_t. \end{aligned}$$

因此,

$$\mathbf{y}_t = \mathbf{y}_0 + \int_0^t \Psi(s)g(s)d\mathbf{w}(s) = \mathbf{x}_0 + \int_0^t \Psi(s)g(s)d\mathbf{w}(s),$$

因为 $\Psi(0) = 1$.

步骤三: 解出 $\mathbf{x}_t$. 利用 $\mathbf{x}_t = \Psi(t)^{-1}\mathbf{y}_t$, 得到

$$\mathbf{x}_t = e^{\int_0^t f(s)ds} \left[\mathbf{x}_0 + \int_0^t e^{-\int_0^s f(r)dr} g(s)d\mathbf{w}(s) \right]. \quad (\text{C.1.4})$$

这给出了向量值 SDE 的显式解.

下面展示两种计算 $p_t(\mathbf{x}_t|\mathbf{x}_0)$ 解析形式的方法.

闭式解的分析. 式 (C.1.4) 再次确认 $p_t(\mathbf{x}_t|\mathbf{x}_0)$ 为高斯分布. 为看清这一点, 定义

$$\phi(s) := e^{-\int_0^s f(u)du} g(s),$$

这是时间的确定性矩阵值函数 (假定 $f(u)$ 和 $g(s)$ 为确定性的). 伊藤积分 $\int_0^t \phi(s) d\mathbf{w}_s$ 因而是零均值高斯随机变量, 因为它是确定性函数关于布朗运动的随机积分. 所以, $\mathbf{x}_t|\mathbf{x}_0$ 是高斯随机变量的仿射变换, 因而自身也为高斯分布. 其分布完全由条件均值和协方差确定.

定义条件均值和协方差 (给定初始条件 $\mathbf{x}_0$) 为

$$\mathbf{m}(t) := \mathbb{E}[\mathbf{x}_t|\mathbf{x}_0], \quad \mathbf{P}(t) := \mathbb{E}[(\mathbf{x}_t - \mathbf{m}(t))(\mathbf{x}_t - \mathbf{m}(t))^\top | \mathbf{x}_0].$$

均值. 利用期望的线性性, 以及确定性函数的伊藤积分具有零均值这一事实:

$$\mathbf{m}(t) = \mathbb{E} \left[e^{\int_0^t f(s)ds} \left(\mathbf{x}_0 + \int_0^t \phi(s) d\mathbf{w}_s \right) \middle| \mathbf{x}_0 \right] = e^{\int_0^t f(s)ds} \mathbf{x}_0.$$

协方差. 令 $\mathbf{z}_t := \int_0^t \phi(s) d\mathbf{w}_s$. 则 $\mathbf{x}_t - \mathbf{m}(t) = A(t)\mathbf{z}_t$, 所以

$$\mathbf{P}(t) = e^{2 \int_0^t f(s) ds} \mathbb{E}[\mathbf{z}_t \mathbf{z}_t^\top].$$

由伊藤等距公式¹,

$$\mathbb{E}[\mathbf{z}_t \mathbf{z}_t^\top] = \left(\int_0^t \phi^2(s) ds \right) \mathbf{I}_D,$$

于是,

$$\mathbf{P}(t) = e^{2 \int_0^t f(s) ds} \left(\int_0^t \left(e^{-\int_0^s f(u) du} g(s) \right)^2 ds \right) \mathbf{I}_D.$$

这说明条件协方差是各向同性的.

推导式 (4.3.3) 中均值与方差的 ODE. 也可以直接由线性 SDE 式 (C.1.3) 推导矩的演化方程.

均值演化. 对 SDE 两边取条件期望, 并利用线性性:

$$\frac{d\mathbf{m}(t)}{dt} = \mathbb{E}[f(t)\mathbf{x}_t | \mathbf{x}_0] = f(t)\mathbb{E}[\mathbf{x}_t | \mathbf{x}_0] = f(t)\mathbf{m}(t).$$

协方差演化. 定义中心化过程 $\tilde{\mathbf{x}}_t := \mathbf{x}_t - \mathbf{m}(t)$. 应用伊藤乘积法则 (见式 (C.1.2)):

$$d(\tilde{\mathbf{x}}_t \tilde{\mathbf{x}}_t^\top) = d\tilde{\mathbf{x}}_t \cdot \tilde{\mathbf{x}}_t^\top + \tilde{\mathbf{x}}_t \cdot d\tilde{\mathbf{x}}_t^\top + d\tilde{\mathbf{x}}_t \cdot d\tilde{\mathbf{x}}_t^\top.$$

由 SDE 计算得:

$$d\tilde{\mathbf{x}}_t = d\mathbf{x}_t - d\mathbf{m}(t) = f(t)\tilde{\mathbf{x}}_t dt + g(t) d\mathbf{w}_t.$$

代入乘积法则并取期望:

$$\begin{aligned} \frac{d\mathbf{P}(t)}{dt} &= \mathbb{E}[f(t)\tilde{\mathbf{x}}_t \tilde{\mathbf{x}}_t^\top + \tilde{\mathbf{x}}_t \tilde{\mathbf{x}}_t^\top f(t) + g^2(t)\mathbf{I}_D] \\ &= 2f(t)\mathbf{P}(t) + g^2(t)\mathbf{I}_D. \end{aligned}$$

于是得到式 (4.3.3) 中矩的演化方程.

¹伊藤等距公式在期望意义下将随机积分与普通积分联系起来; 其证明需要完整的伊藤微积分理论, 故此处省略. 对过程 $\psi: [0, T] \rightarrow \mathbb{R}^{D \times D}$, 伊藤等距公式为

$$\mathbb{E} \left[\left\| \int_0^T \psi(t) d\mathbf{w}_t \right\|^2 \right] = \mathbb{E} \left[\int_0^T \|\psi(t)\|_F^2 dt \right],$$

其中 $\|\psi(t)\|_F^2 = \sum_{i,j=1}^D |\psi_{ij}(t)|^2$ 是 Frobenius 范数. 当 $\psi(t) \in \mathbb{R}^D$ (即为向量) 时, 积分为标量, 等距公式简化为

$$\mathbb{E} \left[\left(\int_0^T \psi(t) d\mathbf{w}_t \right)^2 \right] = \mathbb{E} \left[\int_0^T \|\psi(t)\|^2 dt \right].$$

C.2 测度的变量替换：扩散模型中的 Girsanov 定理

扩散模型利用 SDE 将简单噪声变换为丰富的数据分布. 这一变换的核心是一个深刻的思想：仅修改 SDE 的确定性部分（漂移），同时保留其底层随机性，就能重新解释随机性. Girsanov 定理恰在此处发挥作用.

核心思想. 考虑一条观测到的连续轨迹，它描述数据从 $t = 0$ 到 $t = T$ 的演化，记为 $\mathbf{x}_{0:T} := \{\mathbf{x}_t | t \in [0, T]\}$. Girsanov 定理回答了一个基本问题：

问题 C.2.1. 给定这一条观测路径，假定它由一个 SDE 生成时，其似然是多少？若假定它由另一个 SDE 生成，似然又是多少？

我们比较生成同一轨迹的两个假设模型. 这两个假设的 SDE 共享相同的底层纯随机性，由标准 Wiener 过程（布朗运动） $\mathbf{w}_t$ 表示，仅在确定性的“推动”或“漂移”函数上不同. 假定两个生成过程的 $\mathbf{x}_0$ 具有相同的初始分布.

为建立直观认识，将 $\mathbf{x}_{0:T}$ 想象成画在纸上的一条蜿蜒曲线. 一个假设是：它由“机器人画家”在漂移 $\mathbf{f}$ 引导下绘出，并受到由 $g(t)$ 缩放的随机噪声扰动，其似然为 $p_{\mathbf{f}}(\mathbf{x}_{0:T})$. 另一种假设是：第二个机器人采用不同的漂移 $\tilde{\mathbf{f}}$ ，但使用相同的噪声过程，以似然 $p_{\tilde{\mathbf{f}}}(\mathbf{x}_{0:T})$ 生成同一条曲线. Girsanov 定理给出了精确比较同一条观测路径这两种似然的方法. 它量化了在保持随机性固定的情况下，改变漂移如何影响生成某条特定轨迹的概率.

设定. 设 $\mathbf{x}_t \in \mathbb{R}^D$ 是这一条固定的连续路径. 考虑它在两个 SDE 模型下的似然；两个模型仅在漂移函数 $\mathbf{f}$ 与 $\tilde{\mathbf{f}}$ 上不同，共享相同的扩散系数 $g(t) \in \mathbb{R}$ 和底层 Wiener 过程 $\mathbf{w}_t$ ：

$$d\mathbf{x}_t = \mathbf{f}(\mathbf{x}_t, t) dt + g(t) d\mathbf{w}_t \quad (\text{漂移为 } \mathbf{f} \text{ 的模型})$$

$$d\mathbf{x}_t = \tilde{\mathbf{f}}(\mathbf{x}_t, t) dt + g(t) d\mathbf{w}_t \quad (\text{漂移为 } \tilde{\mathbf{f}} \text{ 的模型})$$

令 $\delta_t := \mathbf{f}(\mathbf{x}_t, t) - \tilde{\mathbf{f}}(\mathbf{x}_t, t)$ 表示给定路径 $\mathbf{x}_t$ 上的漂移之差.

Girsanov 似然比. Girsanov 定理给出了这两种解释同一条观测路径的方式之间的基本似然比：

$$\frac{p_{\mathbf{f}}(\mathbf{x}_{0:T})}{p_{\tilde{\mathbf{f}}}(\mathbf{x}_{0:T})} = \exp \left(\int_0^T \delta_t^\top g(t)^{-1} d\mathbf{w}_t - \frac{1}{2} \int_0^T \|g(t)^{-1} \delta_t\|^2 dt \right).$$

这一简洁公式是两个积分之和的指数. 第一个是伊藤积分，第二个是普通 Riemann 积分. 这一比值在扩散模型中至关重要，它使我们能够联系不同的数据生成过程，并计算模型似然.

将 Girsanov 定理理解为测度的变量替换公式最为合适. 正如微积分中的变量替换通过雅可比行列式将积分从一个坐标系变换到另一个坐标系，Girsanov 定理提供了相应的因子（Radon–Nikodym 导数），使我们在漂移改变而扩散保持不变时，能够在两个随机过程之间变换概率或期望.

C.2.1 Girsanov 定理：连接似然训练与得分匹配

了解 Girsanov 定理如何联系同一路径在不同漂移假设下的似然后，我们进一步探讨它对扩散模型的意义。

回顾扩散模型中的前向 SDE：

$$d\mathbf{x}_t = \mathbf{f}(\mathbf{x}_t, t) dt + g(t) d\mathbf{w}_t,$$

它在完整轨迹 $\mathbf{x}_{0:T} := \{\mathbf{x}_t\}_{t=0}^T$ 上诱导一个路径分布 P （即过程在整个时间区间上的联合分布）。由可学习的得分函数 $\mathbf{s}_\phi(\mathbf{x}_t, t)$ 参数化的时间反向 SDE 为

$$d\mathbf{x}_t = [\mathbf{f}(\mathbf{x}_t, t) - g^2(t) \mathbf{s}_\phi(\mathbf{x}_t, t)] dt + g(t) d\bar{\mathbf{w}}_t,$$

它又在轨迹上定义了另一个路径分布 P_ϕ 。

扩散模型中的两个概念。 在扩散模型中，我们从两个核心视角描述随机过程 $\mathbf{x}_{0:T}$ ：前向过程与对应的时间反向过程。这两个视角产生了两个不同但相关的目标：

- **概念一：边缘分布匹配：**构造一个时间反向过程，使其边缘分布 $p_t(\mathbf{x}_t)$ 与前向 SDE 的边缘分布匹配，从时刻 T 的噪声出发，在 $t = 0$ 恢复数据分布。如前所强调，Fokker-Planck 方程保证时间反向 SDE 的这一边缘一致性。
- **概念二：联合路径分布匹配：**这一更强的目标要求匹配整条轨迹上的完整联合分布 $P = p(\mathbf{x}_{0:T})$ 。它不仅匹配各个时间步的快照，还确保整个状态序列及其时间依赖关系都被忠实再现。

匹配完整路径分布 P 可保证所有边缘分布匹配。形式地，设 $\mathbf{x}_{0:T} := \{\mathbf{x}_t | t \in [0, T]\}$ 为具有联合分布 $p(\mathbf{x}_{0:T})$ 的随机过程。假定另一过程的联合分布 $q(\mathbf{x}_{0:T})$ 满足

$$p(\mathbf{x}_{0:T}) = q(\mathbf{x}_{0:T}).$$

则对任意 $t \in [0, T]$ ，边缘分布为

$$p_t(\mathbf{x}_t) = \int p(\mathbf{x}_{0:T}) d\mathbf{x}_{[0,T] \setminus \{t\}}, \quad q_t(\mathbf{x}_t) = \int q(\mathbf{x}_{0:T}) d\mathbf{x}_{[0,T] \setminus \{t\}},$$

从而

$$p_t(\mathbf{x}_t) = q_t(\mathbf{x}_t), \quad \forall t \in [0, T].$$

因此，联合路径匹配蕴含边缘匹配。

然而，反之并不成立：两个过程可以在每个时间步拥有相同的边缘分布，但其时间相关性却有显著差异。边缘匹配无法捕捉这些跨时间依赖关系，只有联合分布才编码了这些关系。

Girsanov 定理连接两个目标. 虽然时间反向 SDE 主要用于边缘匹配 (概念一), Girsanov 定理揭示了更深层的联系: 跨时间的得分匹配也促进联合路径匹配 (概念二).

更准确地说, Girsanov 定理联系了前向路径分布 P 与学得的反向路径分布 P_ϕ . 基于得分的扩散模型的目标函数就是这些路径测度之间的 KL 散度:

$$\mathcal{D}_{\text{KL}}(P \| P_\phi) = \frac{1}{2} \mathbb{E}_P \left[\int_0^T g^2(t) \|\mathbf{s}_\phi(\mathbf{x}_t, t) - \nabla_{\mathbf{x}} \log p_t(\mathbf{x}_t)\|^2 dt \right] + \text{Const.}, \quad (\text{C.2.1})$$

这里的常数不依赖于 ϕ , 并使用了伊藤积分在 P 下期望为零这一事实. 该表达式说明, 最小化联合路径之间的 KL 散度, 等价于学习一个逼近真实得分 $\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t)$ 的得分函数 $\mathbf{s}_\phi$. 因此, 尽管得分匹配以边缘目标的形式表述, 它实际上也促进整个联合路径分布的对齐.

隐式似然训练. 得分匹配不仅匹配路径分布, 还隐式地使扩散模型能够实现生成建模的基本目标: 逼近数据似然 (Song et al., 2021).

通过测度变换公式这一有力概念, 这种联系便清晰起来. Girsanov 定理揭示的这一公式, 使我们能够表示学得模型下 $t = 0$ 时数据边缘似然 ($p_\phi(\mathbf{x}_0)$) 的对数.

$$\log p_\phi(\mathbf{x}_0) = \log \int p_T(\mathbf{x}_T) \cdot \frac{p_\phi(\mathbf{x}_{0:T})}{p(\mathbf{x}_{0:T})} p(\mathbf{x}_{0:T}) d\mathbf{x}_{0:T}. \quad (\text{C.2.2})$$

这里, $p_T(\mathbf{x}_T)$ 是前向 SDE 给出的时刻 T 的已知噪声分布. 项 $\frac{p_\phi(\mathbf{x}_{0:T})}{p(\mathbf{x}_{0:T})}$ 是给定路径 $\mathbf{x}_{0:T}$ 上, 学得的反向过程与前向过程之间的密度比, Girsanov 定理恰好精确量化了它. 本质上, 这一公式根据学得的反向动力学对观测路径轨迹的解释程度, 对已知的噪声似然重新加权, 从而计算生成数据的似然.

进一步联系式 (C.2.1) 中的 KL 最小化, 它涉及完整前向路径分布与学得的反向路径分布之间的差异. 式 (C.2.1) 和 式 (C.2.2) 紧密相连: 优化这一得分匹配目标 (训练损失), 直接对应于学习 Girsanov 密度比, 因而隐式地最大化数据似然 ($p_\phi(\mathbf{x}_0)$). 这一优美的联系将 Girsanov 定理、基于得分的学习, 以及为真实数据赋予高概率这一生成建模的最终目标联系在一起.

附录 D 补充材料与证明

D.1 变分视角

D.1.1 定理 2.2.1: 边缘与条件 KL 最小化的等价性

证明. 式 (2.2.3) 的推导.

首先展开右侧的期望:

$$\begin{aligned} & \mathbb{E}_{p(\mathbf{x}_0, \mathbf{x}_i)} [\mathcal{D}_{\text{KL}}(p(\mathbf{x}_{i-1}|\mathbf{x}_i, \mathbf{x}_0) \| p_\phi(\mathbf{x}_{i-1}|\mathbf{x}_i))] \\ &= \int \int p(\mathbf{x}_0, \mathbf{x}_i) \mathcal{D}_{\text{KL}}(p(\mathbf{x}_{i-1}|\mathbf{x}_i, \mathbf{x}_0) \| p_\phi(\mathbf{x}_{i-1}|\mathbf{x}_i)) d\mathbf{x}_0 d\mathbf{x}_i. \end{aligned}$$

根据 KL 散度的定义,

$$\mathcal{D}_{\text{KL}}(p(\mathbf{x}_{i-1}|\mathbf{x}_i, \mathbf{x}_0) \| p_\phi(\mathbf{x}_{i-1}|\mathbf{x}_i)) = \int p(\mathbf{x}_{i-1}|\mathbf{x}_i, \mathbf{x}_0) \log \frac{p(\mathbf{x}_{i-1}|\mathbf{x}_i, \mathbf{x}_0)}{p_\phi(\mathbf{x}_{i-1}|\mathbf{x}_i)} d\mathbf{x}_{i-1}.$$

将其代入期望, 得到

$$\int \int \int p(\mathbf{x}_0, \mathbf{x}_i) p(\mathbf{x}_{i-1}|\mathbf{x}_i, \mathbf{x}_0) \log \frac{p(\mathbf{x}_{i-1}|\mathbf{x}_i, \mathbf{x}_0)}{p_\phi(\mathbf{x}_{i-1}|\mathbf{x}_i)} d\mathbf{x}_{i-1} d\mathbf{x}_0 d\mathbf{x}_i.$$

利用概率的链式法则,

$$p(\mathbf{x}_0, \mathbf{x}_i) = p(\mathbf{x}_i) p(\mathbf{x}_0|\mathbf{x}_i),$$

将积分改写为

$$\int p(\mathbf{x}_i) \int p(\mathbf{x}_0|\mathbf{x}_i) \int p(\mathbf{x}_{i-1}|\mathbf{x}_i, \mathbf{x}_0) \log \frac{p(\mathbf{x}_{i-1}|\mathbf{x}_i, \mathbf{x}_0)}{p_\phi(\mathbf{x}_{i-1}|\mathbf{x}_i)} d\mathbf{x}_{i-1} d\mathbf{x}_0 d\mathbf{x}_i.$$

由此可将期望写成嵌套形式:

$$\mathbb{E}_{p(\mathbf{x}_i)} \left[\mathbb{E}_{p(\mathbf{x}_0|\mathbf{x}_i)} \left[\mathbb{E}_{p(\mathbf{x}_{i-1}|\mathbf{x}_i, \mathbf{x}_0)} \left[\log \frac{p(\mathbf{x}_{i-1}|\mathbf{x}_i, \mathbf{x}_0)}{p_\phi(\mathbf{x}_{i-1}|\mathbf{x}_i)} \right] \right] \right].$$

接下来, 应用对数的分解:

$$\log \frac{p(\mathbf{x}_{i-1}|\mathbf{x}_i, \mathbf{x}_0)}{p_\phi(\mathbf{x}_{i-1}|\mathbf{x}_i)} = \log \frac{p(\mathbf{x}_{i-1}|\mathbf{x}_i, \mathbf{x}_0)}{p(\mathbf{x}_{i-1}|\mathbf{x}_i)} + \log \frac{p(\mathbf{x}_{i-1}|\mathbf{x}_i)}{p_\phi(\mathbf{x}_{i-1}|\mathbf{x}_i)}.$$

代回期望得到两项：

$$\begin{aligned} & \mathbb{E}_{p(\mathbf{x}_i)} \left[\mathbb{E}_{p(\mathbf{x}_0|\mathbf{x}_i)} \left[\mathbb{E}_{p(\mathbf{x}_{i-1}|\mathbf{x}_i, \mathbf{x}_0)} \left[\log \frac{p(\mathbf{x}_{i-1}|\mathbf{x}_i, \mathbf{x}_0)}{p(\mathbf{x}_{i-1}|\mathbf{x}_i)} \right] \right] \right] \\ & + \mathbb{E}_{p(\mathbf{x}_i)} \left[\mathbb{E}_{p(\mathbf{x}_0|\mathbf{x}_i)} \left[\mathbb{E}_{p(\mathbf{x}_{i-1}|\mathbf{x}_i, \mathbf{x}_0)} \left[\log \frac{p(\mathbf{x}_{i-1}|\mathbf{x}_i)}{p_\phi(\mathbf{x}_{i-1}|\mathbf{x}_i)} \right] \right] \right]. \end{aligned}$$

由于第二个对数项不依赖于 $\mathbf{x}_0$ ，由全概率公式，

$$\mathbb{E}_{p(\mathbf{x}_0|\mathbf{x}_i)} \left[\mathbb{E}_{p(\mathbf{x}_{i-1}|\mathbf{x}_i, \mathbf{x}_0)} \left[\log \frac{p(\mathbf{x}_{i-1}|\mathbf{x}_i)}{p_\phi(\mathbf{x}_{i-1}|\mathbf{x}_i)} \right] \right] = \mathbb{E}_{p(\mathbf{x}_{i-1}|\mathbf{x}_i)} \left[\log \frac{p(\mathbf{x}_{i-1}|\mathbf{x}_i)}{p_\phi(\mathbf{x}_{i-1}|\mathbf{x}_i)} \right].$$

同样，第一项为 KL 散度

$$\mathbb{E}_{p(\mathbf{x}_0|\mathbf{x}_i)} \left[\mathcal{D}_{\text{KL}}(p(\mathbf{x}_{i-1}|\mathbf{x}_i, \mathbf{x}_0) \| p(\mathbf{x}_{i-1}|\mathbf{x}_i)) \right].$$

合并以上结果，得到分解：

$$\begin{aligned} & \mathbb{E}_{p(\mathbf{x}_0, \mathbf{x}_i)} \left[\mathcal{D}_{\text{KL}}(p(\mathbf{x}_{i-1}|\mathbf{x}_i, \mathbf{x}_0) \| p_\phi(\mathbf{x}_{i-1}|\mathbf{x}_i)) \right] \\ & = \mathbb{E}_{p(\mathbf{x}_i)} \left[\mathbb{E}_{p(\mathbf{x}_0|\mathbf{x}_i)} \left[\mathcal{D}_{\text{KL}}(p(\mathbf{x}_{i-1}|\mathbf{x}_i, \mathbf{x}_0) \| p(\mathbf{x}_{i-1}|\mathbf{x}_i)) \right] \right] \\ & + \mathbb{E}_{p(\mathbf{x}_i)} \left[\mathcal{D}_{\text{KL}}(p(\mathbf{x}_{i-1}|\mathbf{x}_i) \| p_\phi(\mathbf{x}_{i-1}|\mathbf{x}_i)) \right]. \end{aligned}$$

最优性的证明. 要证明：

$$p^*(\mathbf{x}_{i-1}|\mathbf{x}_i) = p(\mathbf{x}_{i-1}|\mathbf{x}_i) = \mathbb{E}_{p(\mathbf{x}|\mathbf{x}_i)} [p(\mathbf{x}_{i-1}|\mathbf{x}_i, \mathbf{x})], \quad \mathbf{x}_i \sim p_i.$$

第一个恒等式源于如下事实：假定参数化的表达能力足够强，KL 散度 $\mathcal{D}_{\text{KL}}(p \| p_\phi)$ 在 $p^* = p$ 时达到最小值。第二个恒等式直接由全概率公式得到。 ■

D.1.2 定理 2.2.3：扩散模型的 ELBO

证明. 为简化记号，令 $\mathbf{x}_{0:L} := (\mathbf{x}_0, \mathbf{x}_1, \dots, \mathbf{x}_L)$.

步骤一：应用 Jensen 不等式. 边缘对数似然为：

$$\log p_\phi(\mathbf{x}) = \log \int p_\phi(\mathbf{x}, \mathbf{x}_{0:L}) d\mathbf{x}_0 \cdots d\mathbf{x}_L,$$

其中联合分布为：

$$p_\phi(\mathbf{x}, \mathbf{x}_{0:L}) = p_{\text{prior}}(\mathbf{x}_L) \prod_{i=1}^L p_\phi(\mathbf{x}_{i-1}|\mathbf{x}_i) \cdot p_\phi(\mathbf{x}|\mathbf{x}_0).$$

引入变分分布 $p(\mathbf{x}_{0:L}|\mathbf{x})$ ，改写为：

$$\log p_\phi(\mathbf{x}) = \log \int p(\mathbf{x}_{0:L}|\mathbf{x}) \frac{p_\phi(\mathbf{x}, \mathbf{x}_{0:L})}{p(\mathbf{x}_{0:L}|\mathbf{x})} d\mathbf{x}_0 \cdots d\mathbf{x}_L.$$

应用 Jensen 不等式 ($\log \mathbb{E}[Z] \geq \mathbb{E}[\log Z]$), 得到 ELBO:

$$\log p_\phi(\mathbf{x}) \geq \mathbb{E}_{p(\mathbf{x}_{0:L}|\mathbf{x})} \left[\log \frac{p_\phi(\mathbf{x}, \mathbf{x}_{0:L})}{p(\mathbf{x}_{0:L}|\mathbf{x})} \right] =: \mathcal{L}_{\text{ELBO}},$$

因此,

$$-\log p_\phi(\mathbf{x}) \leq -\mathcal{L}_{\text{ELBO}}.$$

步骤二：展开 ELBO. 假定变分分布分解为:

$$p(\mathbf{x}_{0:L}|\mathbf{x}) = p(\mathbf{x}_L|\mathbf{x}) \prod_{i=1}^L p(\mathbf{x}_{i-1}|\mathbf{x}_i, \mathbf{x}).$$

将联合分布与变分分布代入 ELBO:

$$\begin{aligned} \mathcal{L}_{\text{ELBO}} = \mathbb{E}_{p(\mathbf{x}_{0:L}|\mathbf{x})} & \left[\log p_{\text{prior}}(\mathbf{x}_L) + \sum_{i=1}^L \log p_\phi(\mathbf{x}_{i-1}|\mathbf{x}_i) + \log p_\phi(\mathbf{x}|\mathbf{x}_0) \right. \\ & \left. - \log p(\mathbf{x}_L|\mathbf{x}) - \sum_{i=1}^L \log p(\mathbf{x}_{i-1}|\mathbf{x}_i, \mathbf{x}) \right]. \end{aligned}$$

根据各项的依赖关系分组, 并进行边缘化, 计算负 ELBO:

$$\begin{aligned} -\mathcal{L}_{\text{ELBO}} = & \mathbb{E}_{p(\mathbf{x}_0|\mathbf{x})} [-\log p_\phi(\mathbf{x}|\mathbf{x}_0)] + \mathbb{E}_{p(\mathbf{x}_L|\mathbf{x})} \left[\log \frac{p(\mathbf{x}_L|\mathbf{x})}{p_{\text{prior}}(\mathbf{x}_L)} \right] \\ & + \sum_{i=1}^L \mathbb{E}_{p(\mathbf{x}_i|\mathbf{x})} \left[\mathbb{E}_{p(\mathbf{x}_{i-1}|\mathbf{x}_i, \mathbf{x})} \left[\log \frac{p(\mathbf{x}_{i-1}|\mathbf{x}_i, \mathbf{x})}{p_\phi(\mathbf{x}_{i-1}|\mathbf{x}_i)} \right] \right]. \end{aligned}$$

为说明最后一项, 使用如下分解:

$$p(\mathbf{x}_i, \mathbf{x}_{i-1}|\mathbf{x}) = p(\mathbf{x}_i|\mathbf{x}) \cdot p(\mathbf{x}_{i-1}|\mathbf{x}_i, \mathbf{x}),$$

从而得到:

$$\begin{aligned} & \mathbb{E}_{p(\mathbf{x}_{0:L}|\mathbf{x})} \left[\log \frac{p(\mathbf{x}_{i-1}|\mathbf{x}_i, \mathbf{x})}{p_\phi(\mathbf{x}_{i-1}|\mathbf{x}_i)} \right] \\ = & \int p(\mathbf{x}_i|\mathbf{x}) \left[\int p(\mathbf{x}_{i-1}|\mathbf{x}_i, \mathbf{x}) \log \frac{p(\mathbf{x}_{i-1}|\mathbf{x}_i, \mathbf{x})}{p_\phi(\mathbf{x}_{i-1}|\mathbf{x}_i)} d\mathbf{x}_{i-1} \right] d\mathbf{x}_i \\ = & \mathbb{E}_{p(\mathbf{x}_i|\mathbf{x})} \left[\mathbb{E}_{p(\mathbf{x}_{i-1}|\mathbf{x}_i, \mathbf{x})} \left[\log \frac{p(\mathbf{x}_{i-1}|\mathbf{x}_i, \mathbf{x})}{p_\phi(\mathbf{x}_{i-1}|\mathbf{x}_i)} \right] \right]. \end{aligned}$$

将 $-\mathcal{L}_{\text{ELBO}}$ 中的三项分别记为:

$$\mathcal{L}_{\text{recon.}}, \quad \mathcal{L}_{\text{prior}}, \quad \mathcal{L}_{\text{diffusion}},$$

它们依次对应重构损失、先验 KL, 以及逐步扩散 KL. 推导完毕. ■

D.2 基于得分的视角

D.2.1 命题 3.2.1: 通过分部积分实现可处理的得分匹配

证明. 展开 $\mathcal{L}_{\text{SM}}(\phi)$. 展开期望中的平方差:

$$\begin{aligned}\mathcal{L}_{\text{SM}}(\phi) &= \frac{1}{2} \mathbb{E}_{\mathbf{x} \sim p_{\text{data}}(\mathbf{x})} [\|\mathbf{s}_{\phi}(\mathbf{x})\|_2^2 - 2\langle \mathbf{s}_{\phi}(\mathbf{x}), \mathbf{s}(\mathbf{x}) \rangle + \|\mathbf{s}(\mathbf{x})\|_2^2] \\ &= \frac{1}{2} \mathbb{E}_{\mathbf{x} \sim p_{\text{data}}(\mathbf{x})} [\|\mathbf{s}_{\phi}(\mathbf{x})\|_2^2] - \mathbb{E}_{\mathbf{x} \sim p_{\text{data}}(\mathbf{x})} [\langle \mathbf{s}_{\phi}(\mathbf{x}), \mathbf{s}(\mathbf{x}) \rangle] \\ &\quad + \frac{1}{2} \mathbb{E}_{\mathbf{x} \sim p_{\text{data}}(\mathbf{x})} [\|\mathbf{s}(\mathbf{x})\|_2^2].\end{aligned}$$

现在关注交叉乘积项:

$$\mathbb{E}_{\mathbf{x} \sim p_{\text{data}}(\mathbf{x})} [\langle \mathbf{s}_{\phi}(\mathbf{x}), \mathbf{s}(\mathbf{x}) \rangle].$$

利用如下事实:

$$\nabla_{\mathbf{x}} \log p_{\text{data}}(\mathbf{x}) = \frac{\nabla_{\mathbf{x}} p_{\text{data}}(\mathbf{x})}{p_{\text{data}}(\mathbf{x})},$$

并假定 $p_{\text{data}}(\mathbf{x})$ 非零 (例如在其支集上), 交叉乘积项变为:

$$\begin{aligned}\mathbb{E}_{\mathbf{x} \sim p_{\text{data}}(\mathbf{x})} [\langle \mathbf{s}_{\phi}(\mathbf{x}), \mathbf{s}(\mathbf{x}) \rangle] &= \int \mathbf{s}_{\phi}(\mathbf{x})^{\top} \nabla_{\mathbf{x}} \log p_{\text{data}}(\mathbf{x}) p_{\text{data}}(\mathbf{x}) \, \mathrm{d}\mathbf{x} \\ &= \int \mathbf{s}_{\phi}(\mathbf{x})^{\top} \nabla_{\mathbf{x}} p_{\text{data}}(\mathbf{x}) \, \mathrm{d}\mathbf{x} \\ &= \sum_{i=1}^D \int s_{\phi}^{(i)}(\mathbf{x}) \partial_{x_i} p_{\text{data}}(\mathbf{x}) \, \mathrm{d}\mathbf{x},\end{aligned}$$

其中 $s_{\phi}^{(i)}(\mathbf{x})$ 是如下得分函数的第 i 个分量:

$$\mathbf{s}_{\phi} = (s_{\phi}^{(1)}, s_{\phi}^{(2)}, \dots, s_{\phi}^{(D)}).$$

分部积分. 使用以下由标准微积分得到的分部积分公式 (Evans, 2010):

引理. 设 u, v 是半径为 $R > 0$ 的球 $\mathbb{B}(\mathbf{0}, R) \subset \mathbb{R}^D$ 上的可微实值函数. 则对于 $i = 1, \dots, D$, 有:

$$\int_{\mathbb{B}(\mathbf{0}, R)} u \partial_{x_i} v \, \mathrm{d}\mathbf{x} = - \int_{\mathbb{B}(\mathbf{0}, R)} v \partial_{x_i} u \, \mathrm{d}\mathbf{x} + \int_{\partial \mathbb{B}(\mathbf{0}, R)} u v \nu_i \, \mathrm{d}S,$$

其中 $\nu = (\nu_1, \dots, \nu_D)$ 为边界 $\partial \mathbb{B}(\mathbf{0}, R)$ (半径为 $R > 0$ 的球面) 的外向单位法向量, 而 $\mathrm{d}S$ 为 $\partial \mathbb{B}(\mathbf{0}, R)$ 上的曲面测度.

对所有 $i = 1, \dots, D$, 将此公式应用于 $u(\mathbf{x}) := s_{\phi}^{(i)}(\mathbf{x})$ 和 $v(\mathbf{x}) = p_{\text{data}}(\mathbf{x})$, 并假定

$$|u(\mathbf{x})v(\mathbf{x})| \rightarrow 0 \quad \text{当 } R \rightarrow \infty.$$

对所有 $i = 1, \dots, D$ 的结果求和，得到：

$$\begin{aligned}\mathbb{E}_{\mathbf{x} \sim p_{\text{data}}(\mathbf{x})} [\langle \mathbf{s}_\phi(\mathbf{x}), \mathbf{s}(\mathbf{x}) \rangle] &= - \sum_{i=1}^D \int \partial_{x_i} s_\phi^{(i)}(\mathbf{x}) p_{\text{data}}(\mathbf{x}) d\mathbf{x} \\ &= - \mathbb{E}_{\mathbf{x} \sim p_{\text{data}}(\mathbf{x})} [\text{Tr}(\nabla_{\mathbf{x}} \mathbf{s}_\phi(\mathbf{x}))].\end{aligned}$$

合并所有结果，得到：

$$\begin{aligned}\mathcal{L}_{\text{SM}}(\phi) &= \underbrace{\mathbb{E}_{\mathbf{x} \sim p_{\text{data}}(\mathbf{x})} \left[\text{Tr}(\nabla_{\mathbf{x}} \mathbf{s}_\phi(\mathbf{x})) + \frac{1}{2} \|\mathbf{s}_\phi(\mathbf{x})\|_2^2 \right]}_{\tilde{\mathcal{L}}_{\text{SM}}(\phi)} \\ &\quad + \underbrace{\frac{1}{2} \mathbb{E}_{\mathbf{x} \sim p_{\text{data}}(\mathbf{x})} [\|\mathbf{s}(\mathbf{x})\|_2^2]}_{=:C},\end{aligned}$$

其中 C 仅依赖于分布 p_{data} ，证明完毕. ■

D.2.2 定理 3.3.1: SM 与 DSM 最小化的等价性

证明. 展开 $\mathcal{L}_{\text{SM}}(\phi; \sigma)$ 和 $\mathcal{L}_{\text{DSM}}(\phi; \sigma)$ ，得到：

$$\begin{aligned}\mathcal{L}_{\text{SM}}(\phi; \sigma) &= \frac{1}{2} \mathbb{E}_{\tilde{\mathbf{x}} \sim p_\sigma(\tilde{\mathbf{x}})} \left[\|\mathbf{s}_\phi(\tilde{\mathbf{x}}; \sigma)\|_2^2 - 2 \mathbf{s}_\phi(\tilde{\mathbf{x}}; \sigma)^\top \nabla_{\tilde{\mathbf{x}}} \log p_\sigma(\tilde{\mathbf{x}}) \right. \\ &\quad \left. + \|\nabla_{\tilde{\mathbf{x}}} \log p_\sigma(\tilde{\mathbf{x}})\|_2^2 \right], \\ \mathcal{L}_{\text{DSM}}(\phi; \sigma) &= \frac{1}{2} \mathbb{E}_{p_{\text{data}}(\mathbf{x}) p_\sigma(\tilde{\mathbf{x}}|\mathbf{x})} \left[\|\mathbf{s}_\phi(\tilde{\mathbf{x}}; \sigma)\|_2^2 - 2 \mathbf{s}_\phi(\tilde{\mathbf{x}}; \sigma)^\top \nabla_{\tilde{\mathbf{x}}} \log p_\sigma(\tilde{\mathbf{x}}|\mathbf{x}) \right. \\ &\quad \left. + \|\nabla_{\tilde{\mathbf{x}}} \log p_\sigma(\tilde{\mathbf{x}}|\mathbf{x})\|_2^2 \right].\end{aligned}$$

两式相减，得到：

$$\begin{aligned}&\mathcal{L}_{\text{SM}}(\phi; \sigma) - \mathcal{L}_{\text{DSM}}(\phi; \sigma) \\ &= \frac{1}{2} \left(\mathbb{E}_{\tilde{\mathbf{x}} \sim p_\sigma(\tilde{\mathbf{x}})} \|\mathbf{s}_\phi(\tilde{\mathbf{x}}; \sigma)\|_2^2 - \mathbb{E}_{p_{\text{data}}(\mathbf{x}) p_\sigma(\tilde{\mathbf{x}}|\mathbf{x})} \|\mathbf{s}_\phi(\tilde{\mathbf{x}}; \sigma)\|_2^2 \right) \\ &\quad - \left(\mathbb{E}_{\tilde{\mathbf{x}} \sim p_\sigma(\tilde{\mathbf{x}})} [\mathbf{s}_\phi(\tilde{\mathbf{x}}; \sigma)^\top \nabla_{\tilde{\mathbf{x}}} \log p_\sigma(\tilde{\mathbf{x}})] \right. \\ &\quad \left. - \mathbb{E}_{p_{\text{data}}(\mathbf{x}) p_\sigma(\tilde{\mathbf{x}}|\mathbf{x})} [\mathbf{s}_\phi(\tilde{\mathbf{x}}; \sigma)^\top \nabla_{\tilde{\mathbf{x}}} \log p_\sigma(\tilde{\mathbf{x}}|\mathbf{x})] \right) \\ &\quad + \frac{1}{2} \left(\mathbb{E}_{\tilde{\mathbf{x}} \sim p_\sigma(\tilde{\mathbf{x}})} \|\nabla_{\tilde{\mathbf{x}}} \log p_\sigma(\tilde{\mathbf{x}})\|_2^2 - \mathbb{E}_{p_{\text{data}}(\mathbf{x}) p_\sigma(\tilde{\mathbf{x}}|\mathbf{x})} \|\nabla_{\tilde{\mathbf{x}}} \log p_\sigma(\tilde{\mathbf{x}}|\mathbf{x})\|_2^2 \right).\end{aligned}$$

接下来逐项处理这三项. 对第一项, 由于 $p_\sigma(\tilde{\mathbf{x}}) = \int p_\sigma(\tilde{\mathbf{x}}|\mathbf{x})p_{\text{data}}(\mathbf{x}) d\mathbf{x}$, 可将它改写为:

$$\begin{aligned}\mathbb{E}_{\tilde{\mathbf{x}} \sim p_\sigma(\tilde{\mathbf{x}})} \|\mathbf{s}_\phi(\tilde{\mathbf{x}}; \sigma)\|_2^2 &= \int \left(\int p_\sigma(\tilde{\mathbf{x}}|\mathbf{x})p_{\text{data}}(\mathbf{x}) d\mathbf{x} \right) \|\mathbf{s}_\phi(\tilde{\mathbf{x}}; \sigma)\|_2^2 d\tilde{\mathbf{x}} \\ &= \int p_{\text{data}}(\mathbf{x}) \int p_\sigma(\tilde{\mathbf{x}}|\mathbf{x}) \|\mathbf{s}_\phi(\tilde{\mathbf{x}}; \sigma)\|_2^2 d\tilde{\mathbf{x}} d\mathbf{x} \\ &= \mathbb{E}_{p_{\text{data}}(\mathbf{x})p_\sigma(\tilde{\mathbf{x}}|\mathbf{x})} \|\mathbf{s}_\phi(\tilde{\mathbf{x}}; \sigma)\|_2^2.\end{aligned}$$

因此第一项为零. 对第二项:

$$\begin{aligned}&\mathbb{E}_{\tilde{\mathbf{x}} \sim p_\sigma(\tilde{\mathbf{x}})} [\mathbf{s}_\phi(\tilde{\mathbf{x}}; \sigma)^\top \nabla_{\tilde{\mathbf{x}}} \log p_\sigma(\tilde{\mathbf{x}})] \\ &= \int p_\sigma(\tilde{\mathbf{x}}) \mathbf{s}_\phi(\tilde{\mathbf{x}}; \sigma)^\top \frac{\nabla_{\tilde{\mathbf{x}}} p_\sigma(\tilde{\mathbf{x}})}{p_\sigma(\tilde{\mathbf{x}})} d\tilde{\mathbf{x}} \\ &= \int \mathbf{s}_\phi(\tilde{\mathbf{x}}; \sigma)^\top \nabla_{\tilde{\mathbf{x}}} \int p_\sigma(\tilde{\mathbf{x}}|\mathbf{x})p_{\text{data}}(\mathbf{x}) d\mathbf{x} d\tilde{\mathbf{x}} \\ &= \int \int \mathbf{s}_\phi(\tilde{\mathbf{x}}; \sigma)^\top \nabla_{\tilde{\mathbf{x}}} p_\sigma(\tilde{\mathbf{x}}|\mathbf{x})p_{\text{data}}(\mathbf{x}) d\tilde{\mathbf{x}} d\mathbf{x} \\ &= \mathbb{E}_{p_{\text{data}}(\mathbf{x})p_\sigma(\tilde{\mathbf{x}}|\mathbf{x})} [\mathbf{s}_\phi(\tilde{\mathbf{x}}; \sigma)^\top \nabla_{\tilde{\mathbf{x}}} \log p_\sigma(\tilde{\mathbf{x}}|\mathbf{x})].\end{aligned}\tag{D.2.1}$$

因此第二项也为零. 对第三项, 注意到:

$$C := \frac{1}{2} \left(\mathbb{E}_{\tilde{\mathbf{x}} \sim p_\sigma(\tilde{\mathbf{x}})} \|\nabla_{\tilde{\mathbf{x}}} \log p_\sigma(\tilde{\mathbf{x}})\|_2^2 - \mathbb{E}_{p_{\text{data}}(\mathbf{x})p_\sigma(\tilde{\mathbf{x}}|\mathbf{x})} \|\nabla_{\tilde{\mathbf{x}}} \log p_\sigma(\tilde{\mathbf{x}}|\mathbf{x})\|_2^2 \right)$$

它仅依赖于 $p_{\text{data}}(\mathbf{x})$ 和 $p_\sigma(\tilde{\mathbf{x}}|\mathbf{x})$, 因而相对于 ϕ 为常数. ■

D.2.3 引理 3.3.2: Tweedie 公式

首先陈述考虑时变高斯扰动的更一般形式的 Tweedie 公式, 并在下面给出证明.

带时变参数的 Tweedie 恒等式. 设 $\mathbf{x}_t \sim \mathcal{N}(\cdot; \alpha_t \mathbf{x}_0, \sigma_t^2 \mathbf{I})$ 为高斯随机向量. 则 Tweedie 公式给出

$$\alpha_t \mathbb{E}_{\mathbf{x}_0 \sim p(\mathbf{x}_0|\mathbf{x}_t)} [\mathbf{x}_0|\mathbf{x}_t] = \mathbf{x}_t + \sigma_t^2 \nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t),$$

其中期望是关于给定观测 $\mathbf{x}_t$ 时 $\mathbf{x}_0$ 的后验分布 $p(\mathbf{x}_0|\mathbf{x}_t)$ 取的, 而 $p_t(\mathbf{x}_t)$ 是 $\mathbf{x}_t$ 的边缘密度.

证明.

边缘密度及其得分. 回顾 $\mathbf{x}_t$ 的边缘密度为

$$p_t(\mathbf{x}_t) = \int p_t(\mathbf{x}_t|\mathbf{x}_0)p_0(\mathbf{x}_0) d\mathbf{x}_0.$$

现在计算得分函数:

$$\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t) = \frac{\nabla_{\mathbf{x}_t} p_t(\mathbf{x}_t)}{p_t(\mathbf{x}_t)} = \frac{1}{p_t(\mathbf{x}_t)} \int \nabla_{\mathbf{x}_t} p_t(\mathbf{x}_t|\mathbf{x}_0)p_0(\mathbf{x}_0) d\mathbf{x}_0.$$

因此需要计算条件密度的梯度.

条件密度的梯度与整理. 条件高斯密度的梯度为:

$$\nabla_{\mathbf{x}_t} p_t(\mathbf{x}_t | \mathbf{x}_0) = -p_t(\mathbf{x}_t | \mathbf{x}_0) \cdot \sigma_t^{-2} (\mathbf{x}_t - \alpha_t \mathbf{x}_0).$$

将其代入前面的表达式, 得到:

$$\begin{aligned} \nabla_{\mathbf{x}_t} p_t(\mathbf{x}_t) &= \int \nabla_{\mathbf{x}_t} p_t(\mathbf{x}_t | \mathbf{x}_0) p_0(\mathbf{x}_0) d\mathbf{x}_0 \\ &= -\sigma_t^{-2} \int (\mathbf{x}_t - \alpha_t \mathbf{x}_0) p_t(\mathbf{x}_t | \mathbf{x}_0) p_0(\mathbf{x}_0) d\mathbf{x}_0 \\ &= -\sigma_t^{-2} \int (\mathbf{x}_t - \alpha_t \mathbf{x}_0) p(\mathbf{x}_0 | \mathbf{x}_t) p_t(\mathbf{x}_t) d\mathbf{x}_0 \\ &= -p_t(\mathbf{x}_t) \sigma_t^{-2} (\mathbf{x}_t - \alpha_t \mathbb{E}_{p(\mathbf{x}_0 | \mathbf{x}_t)}[\mathbf{x}_0 | \mathbf{x}_t]). \end{aligned}$$

两边除以 $p_t(\mathbf{x}_t)$, 得到:

$$\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t) = -\sigma_t^{-2} (\mathbf{x}_t - \alpha_t \mathbb{E}_{p(\mathbf{x}_0 | \mathbf{x}_t)}[\mathbf{x}_0 | \mathbf{x}_t]).$$

整理得到:

$$\mathbf{x}_t + \sigma_t^2 \nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t) = \alpha_t \mathbb{E}_{p(\mathbf{x}_0 | \mathbf{x}_t)}[\mathbf{x}_0 | \mathbf{x}_t].$$

推导完毕.

D.2.4 Stein 恒等式与 SURE 替代目标

Stein 恒等式. Stein 恒等式是一种分部积分技巧, 它将未知密度下的期望变换为可观测函数及其导数的期望, 从而消去配分函数, 使我们无需计算未知密度或配分函数, 就能得到无偏且可处理的目标与检验. 从最简单的一维情形开始, 再将其推广到证明 SURE 替代损失所需的形式.

一维标准正态情形. 若 $z \sim \mathcal{N}(0, 1)$ 且 f 具有适当的衰减性质, Stein 恒等式为:

$$\mathbb{E}[f'(z)] = \mathbb{E}[Zf(z)].$$

用 $\phi(z) := \frac{1}{\sqrt{2\pi}} e^{-z^2/2}$ 表示一维标准正态密度. 利用 $\phi'(z) = -z\phi(z)$ 和边界项为零, 通过分部积分即可证明. 具体而言, 计算

$$\mathbb{E}[f'(Z)] = \int_{-\infty}^{\infty} f'(z) \phi(z) dz.$$

令 $u = f(z)$, $dv = \phi'(z) dz$, 通过分部积分得到

$$\int f'(z) \phi(z) dz = \left[f(z) \phi(z) \right]_{-\infty}^{\infty} - \int f(z) \phi'(z) dz.$$

由于 $\phi'(z) = -z\phi(z)$, 且当 $|z| \rightarrow \infty$ 时 $f(z)\phi(z) \rightarrow 0$ (衰减条件), 边界项为零, 因此

$$\mathbb{E}[f'(z)] = \int f(z) z \phi(z) dz = \mathbb{E}[zf(z)].$$

推导完毕, 并证明了 Stein 恒等式的一维情形.

多元标准正态情形. 若 $\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}_D)$ 且 $g: \mathbb{R}^D \rightarrow \mathbb{R}$, 则 Stein 恒等式为

$$\mathbb{E}[\nabla g(\mathbf{z})] = \mathbb{E}[\mathbf{z}g(\mathbf{z})].$$

等价地, 对于 $\mathbf{u}: \mathbb{R}^D \rightarrow \mathbb{R}^D$,

$$\mathbb{E}[\nabla_{\tilde{\mathbf{x}}} \cdot \mathbf{u}(\mathbf{z})] = \mathbb{E}[\mathbf{z}^\top \mathbf{u}(\mathbf{z})]. \quad (\text{D.2.2})$$

SURE 所需的恒等式. 令 $\tilde{\mathbf{x}} = \mathbf{x} + \sigma\mathbf{z}$, 其中 $\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}_D)$, 则对任何具有适当正则性的向量函数 $\mathbf{a}$,

$$\mathbb{E}[(\tilde{\mathbf{x}} - \mathbf{x})^\top \mathbf{a}(\tilde{\mathbf{x}}) | \mathbf{x}] = \sigma^2 \mathbb{E}[\nabla_{\tilde{\mathbf{x}}} \cdot \mathbf{a}(\tilde{\mathbf{x}}) | \mathbf{x}]. \quad (\text{D.2.3})$$

应用式 (D.2.2) 并使用链式法则即可得到此式.

由条件 MSE 推导 SURE. 设 $\mathbf{D}: \mathbb{R}^D \rightarrow \mathbb{R}^D$ 为去噪器, 定义

$$R(\mathbf{D}; \mathbf{x}) := \mathbb{E}[\|\mathbf{D}(\tilde{\mathbf{x}}) - \mathbf{x}\|_2^2 | \mathbf{x}].$$

围绕 $\tilde{\mathbf{x}}$ 展开:

$$\begin{aligned} R(\mathbf{D}; \mathbf{x}) &= \mathbb{E}[\|\mathbf{D}(\tilde{\mathbf{x}}) - \tilde{\mathbf{x}}\|^2 | \mathbf{x}] + 2\mathbb{E}[(\mathbf{D}(\tilde{\mathbf{x}}) - \tilde{\mathbf{x}})^\top (\tilde{\mathbf{x}} - \mathbf{x}) | \mathbf{x}] + \mathbb{E}[\|\tilde{\mathbf{x}} - \mathbf{x}\|^2 | \mathbf{x}] \\ &= \mathbb{E}[\|\mathbf{D}(\tilde{\mathbf{x}}) - \tilde{\mathbf{x}}\|^2 | \mathbf{x}] + 2\left(\underbrace{\mathbb{E}[(\tilde{\mathbf{x}} - \mathbf{x})^\top \mathbf{D}(\tilde{\mathbf{x}}) | \mathbf{x}]}_{\substack{\sigma^2 \mathbb{E}[\nabla_{\tilde{\mathbf{x}}} \cdot \mathbf{D}(\tilde{\mathbf{x}}) | \mathbf{x}] \\ \text{由式 (D.2.3)}}} - \underbrace{\mathbb{E}[(\tilde{\mathbf{x}} - \mathbf{x})^\top \tilde{\mathbf{x}} | \mathbf{x}]}_{\sigma^2 D}\right) \\ &\quad + \underbrace{\mathbb{E}[\|\tilde{\mathbf{x}} - \mathbf{x}\|^2 | \mathbf{x}]}_{\sigma^2 D} \\ &= \mathbb{E}[\|\mathbf{D}(\tilde{\mathbf{x}}) - \tilde{\mathbf{x}}\|^2 + 2\sigma^2 \nabla_{\tilde{\mathbf{x}}} \cdot \mathbf{D}(\tilde{\mathbf{x}}) - D\sigma^2 | \mathbf{x}]. \end{aligned}$$

因此, 可观测的替代量

$$\text{SURE}(\mathbf{D}; \tilde{\mathbf{x}}) := \|\mathbf{D}(\tilde{\mathbf{x}}) - \tilde{\mathbf{x}}\|_2^2 + 2\sigma^2 \nabla_{\tilde{\mathbf{x}}} \cdot \mathbf{D}(\tilde{\mathbf{x}}) - D\sigma^2$$

满足 $\mathbb{E}[\text{SURE}(\mathbf{D}; \tilde{\mathbf{x}}) | \mathbf{x}] = R(\mathbf{D}; \mathbf{x})$. 因此, 仅使用带噪观测, 最小化 SURE (在期望意义下或经验意义下) 就等价于最小化真实的条件 MSE.

D.2.5 定理 4.1.1: 通过 Fokker–Planck 方程实现边缘对齐

证明.

第一部分：前向 SDE 的 Fokker–Planck 方程. 考虑前向 SDE:

$$d\mathbf{x}(t) = \mathbf{f}(\mathbf{x}(t), t) dt + g(t) d\mathbf{w}(t).$$

扩散矩阵为 $\sigma(t) = g(t)I_D$, 所以 $\sigma(t)\sigma(t)^T = g^2(t)I_D$. $\mathbf{x}(t)$ 的边缘密度 $p_t(\mathbf{x})$ 所满足的 Fokker–Planck 方程为:

$$\partial_t p_t(\mathbf{x}) = -\nabla_{\mathbf{x}} \cdot [\mathbf{f}(\mathbf{x}, t)p_t(\mathbf{x})] + \frac{1}{2} \sum_{i,j=1}^D \frac{\partial^2}{\partial x_i \partial x_j} [(g^2(t)\delta_{ij})p_t(\mathbf{x})].$$

计算扩散项:

$$\sum_{i,j=1}^D \frac{\partial^2}{\partial x_i \partial x_j} [g^2(t)\delta_{ij}p_t(\mathbf{x})] = \sum_{i=1}^D \frac{\partial^2}{\partial x_i^2} [g^2(t)p_t(\mathbf{x})] = g^2(t)\Delta_{\mathbf{x}}p_t(\mathbf{x}).$$

于是:

$$\partial_t p_t(\mathbf{x}) = -\nabla_{\mathbf{x}} \cdot [\mathbf{f}(\mathbf{x}, t)p_t(\mathbf{x})] + \frac{1}{2}g^2(t)\Delta_{\mathbf{x}}p_t(\mathbf{x}).$$

现在利用下式改写:

$$\tilde{\mathbf{f}}(\mathbf{x}, t) = \mathbf{f}(\mathbf{x}, t) - \frac{1}{2}g^2(t)\nabla_{\mathbf{x}} \log p_t(\mathbf{x}).$$

由于 $\nabla_{\mathbf{x}} \log p_t(\mathbf{x}) = \frac{\nabla_{\mathbf{x}} p_t(\mathbf{x})}{p_t(\mathbf{x})}$, 计算得:

$$\nabla_{\mathbf{x}} \cdot [\tilde{\mathbf{f}}(\mathbf{x}, t)p_t(\mathbf{x})] = \nabla_{\mathbf{x}} \cdot \left[\mathbf{f}(\mathbf{x}, t)p_t(\mathbf{x}) - \frac{1}{2}g^2(t)\frac{\nabla_{\mathbf{x}} p_t(\mathbf{x})}{p_t(\mathbf{x})}p_t(\mathbf{x}) \right].$$

第二项为:

$$\nabla_{\mathbf{x}} \cdot \left[-\frac{1}{2}g^2(t)\nabla_{\mathbf{x}} p_t(\mathbf{x}) \right] = -\frac{1}{2}g^2(t)\Delta_{\mathbf{x}}p_t(\mathbf{x}).$$

于是:

$$\nabla_{\mathbf{x}} \cdot [\tilde{\mathbf{f}}(\mathbf{x}, t)p_t(\mathbf{x})] = \nabla_{\mathbf{x}} \cdot [\mathbf{f}(\mathbf{x}, t)p_t(\mathbf{x})] - \frac{1}{2}g^2(t)\Delta_{\mathbf{x}}p_t(\mathbf{x}).$$

因此:

$$\partial_t p_t(\mathbf{x}) = -\nabla_{\mathbf{x}} \cdot [\tilde{\mathbf{f}}(\mathbf{x}, t)p_t(\mathbf{x})],$$

这就验证了两种形式的 Fokker–Planck 方程.

第二部分：PF-ODE 的边缘密度. 考虑 PF-ODE:

$$\frac{d\tilde{\mathbf{x}}(t)}{dt} = \tilde{\mathbf{f}}(\tilde{\mathbf{x}}(t), t), \quad \tilde{\mathbf{f}}(\mathbf{x}, t) = \mathbf{f}(\mathbf{x}, t) - \frac{1}{2}g^2(t)\nabla_{\mathbf{x}} \log p_t(\mathbf{x}).$$

前向: $\tilde{\mathbf{x}}(0) \sim p_0$. 设 $\tilde{\mathbf{x}}(t)$ 遵循 PF-ODE, 且 $\tilde{\mathbf{x}}(0) \sim p_0$. 流映射 $\Psi_t: \mathbb{R}^D \rightarrow \mathbb{R}^D$ 定义为:

$$\frac{d}{dt}\Psi_t(\mathbf{x}_0) = \tilde{\mathbf{f}}(\Psi_t(\mathbf{x}_0), t), \quad \Psi_0(\mathbf{x}_0) = \mathbf{x}_0.$$

由于 $\tilde{\mathbf{x}}(t) = \Psi_t(\tilde{\mathbf{x}}(0))$, $\tilde{\mathbf{x}}(t)$ 的密度 $\tilde{p}_t(\mathbf{x})$ 满足连续性方程:

$$\partial_t \tilde{p}_t(\mathbf{x}) = -\nabla_{\mathbf{x}} \cdot [\tilde{\mathbf{f}}(\mathbf{x}, t) \tilde{p}_t(\mathbf{x})].$$

由于 $\tilde{\mathbf{x}}(0) \sim p_0$, 有 $\tilde{p}_0(\mathbf{x}) = p_0(\mathbf{x})$. 根据第一部分, $p_t(\mathbf{x})$ 满足:

$$\partial_t p_t(\mathbf{x}) = -\nabla_{\mathbf{x}} \cdot [\tilde{\mathbf{f}}(\mathbf{x}, t) p_t(\mathbf{x})].$$

$\tilde{p}_t$ 和 p_t 满足相同的连续性方程, 具有相同的初始条件 p_0 . 假定足够光滑 (例如 $\tilde{\mathbf{f}} \in C^1$), 解在某个适当的函数空间中唯一, 所以 $\tilde{p}_t = p_t$. 因此, 对所有 $t \in [0, T]$, $\tilde{\mathbf{x}}(t) \sim p_t$.

反向: $\tilde{\mathbf{x}}(T) \sim p_T$. 现在令 $\tilde{\mathbf{x}}(t)$ 从 $t = T$ 到 $t = 0$ 反向遵循 PF-ODE, 且 $\tilde{\mathbf{x}}(T) \sim p_T$. ODE 为:

$$\frac{d}{dt}\tilde{\mathbf{x}}(t) = \tilde{\mathbf{f}}(\tilde{\mathbf{x}}(t), t).$$

令 $s = T - t$, 则反向 ODE 变为:

$$\frac{d}{ds}\tilde{\mathbf{x}}(T - s) = -\tilde{\mathbf{f}}(\tilde{\mathbf{x}}(T - s), T - s).$$

$\tilde{\mathbf{x}}(T - s)$ 的密度 $\tilde{p}_{T-s}(\mathbf{x})$ 满足:

$$\partial_s \tilde{p}_{T-s}(\mathbf{x}) = \nabla_{\mathbf{x}} \cdot [\tilde{\mathbf{f}}(\mathbf{x}, T - s) \tilde{p}_{T-s}(\mathbf{x})].$$

由于 $\tilde{\mathbf{x}}(T) \sim p_T$, 有 $\tilde{p}_T = p_T$. p_t 在 $t = T - s$ 处的 Fokker-Planck 方程为:

$$\partial_t p_{T-s}(\mathbf{x}) = -\nabla_{\mathbf{x}} \cdot [\tilde{\mathbf{f}}(\mathbf{x}, T - s) p_{T-s}(\mathbf{x})].$$

由于 $\partial_t = -\partial_s$, 得到:

$$\partial_s p_{T-s}(\mathbf{x}) = \nabla_{\mathbf{x}} \cdot [\tilde{\mathbf{f}}(\mathbf{x}, T - s) p_{T-s}(\mathbf{x})].$$

$\tilde{p}_{T-s}$ 和 p_{T-s} 满足相同的 PDE, 在 $s = 0$ 具有相同的初始条件 ($\tilde{p}_T = p_T$). 由唯一性, $\tilde{p}_{T-s} = p_{T-s}$, 所以对所有 $t \in [0, T]$, $\tilde{\mathbf{x}}(t) = \tilde{\mathbf{x}}(T - s) \sim p_{T-s} = p_t$.

第三部分：时间反向 SDE 的边缘密度。 考虑时间反向 SDE：

$$d\bar{\mathbf{x}}(t) = [\mathbf{f}(\bar{\mathbf{x}}(t), t) - g^2(t)\nabla_{\mathbf{x}} \log p_t(\bar{\mathbf{x}}(t))] dt + g(t) d\bar{\mathbf{w}}(t),$$

其中 $\bar{\mathbf{x}}(0) \sim p_T$, $\bar{\mathbf{w}}(t)$ 为反向时间中的标准 Wiener 过程, 定义为 $\bar{\mathbf{w}}(t) = \mathbf{w}(T-t) - \mathbf{w}(T)$. 需要证明 $\bar{\mathbf{x}}(t) \sim p_{T-t}$.

改写漂移：

$$\mathbf{f}(\mathbf{x}, t) = \tilde{\mathbf{f}}(\mathbf{x}, t) + \frac{1}{2}g^2(t)\nabla_{\mathbf{x}} \log p_t(\mathbf{x}),$$

于是：

$$\mathbf{f}(\mathbf{x}, t) - g^2(t)\nabla_{\mathbf{x}} \log p_t(\mathbf{x}) = \tilde{\mathbf{f}}(\mathbf{x}, t) - \frac{1}{2}g^2(t)\nabla_{\mathbf{x}} \log p_t(\mathbf{x}).$$

时间反向 SDE 为：

$$d\bar{\mathbf{x}}(t) = \left[\tilde{\mathbf{f}}(\bar{\mathbf{x}}(t), t) - \frac{1}{2}g^2(t)\nabla_{\mathbf{x}} \log p_t(\bar{\mathbf{x}}(t)) \right] dt + g(t) d\bar{\mathbf{w}}(t).$$

令 $s = T - t$, 则 $\bar{\mathbf{x}}(t) = \bar{\mathbf{x}}(T - s)$, 且 $dt = -ds$. SDE 变为：

$$\begin{aligned} d\bar{\mathbf{x}}(T - s) &= \left[-\tilde{\mathbf{f}}(\bar{\mathbf{x}}(T - s), T - s) + \frac{1}{2}g^2(T - s)\nabla_{\mathbf{x}} \log p_{T-s}(\bar{\mathbf{x}}(T - s)) \right] ds \\ &\quad + g(T - s) d\bar{\mathbf{w}}(T - s). \end{aligned}$$

由于 $\bar{\mathbf{w}}(t) = \mathbf{w}(T - t) - \mathbf{w}(T)$, 有 $d\bar{\mathbf{w}}(T - s) = -d\mathbf{w}(s)$, 其中 $\mathbf{w}(s)$ 是标准 Wiener 过程. 因此, 令 $\bar{\mathbf{w}}'(s) = -\mathbf{w}(s)$, 它也是标准 Wiener 过程, 从而：

$$d\bar{\mathbf{x}}(s) = \left[\tilde{\mathbf{f}}(\bar{\mathbf{x}}(s), T - s) - \frac{1}{2}g^2(T - s)\nabla_{\mathbf{x}} \log p_{T-s}(\bar{\mathbf{x}}(s)) \right] ds + g(T - s) d\bar{\mathbf{w}}'(s).$$

$\bar{\mathbf{x}}(s)$ 的密度 $\bar{p}_s(\mathbf{x})$ 所满足的 Fokker-Planck 方程为：

$$\begin{aligned} \partial_s \bar{p}_s(\mathbf{x}) &= -\nabla_{\mathbf{x}} \cdot \left[\left(\tilde{\mathbf{f}}(\mathbf{x}, T - s) - \frac{1}{2}g^2(T - s)\nabla_{\mathbf{x}} \log p_{T-s}(\mathbf{x}) \right) \bar{p}_s(\mathbf{x}) \right] \\ &\quad + \frac{1}{2}g^2(T - s)\Delta_{\mathbf{x}} \bar{p}_s(\mathbf{x}). \end{aligned}$$

假定 $\bar{p}_s = p_{T-s}$. p_{T-s} 的 Fokker-Planck 方程为：

$$\partial_t p_{T-s}(\mathbf{x}) = -\nabla_{\mathbf{x}} \cdot [\tilde{\mathbf{f}}(\mathbf{x}, T - s)p_{T-s}(\mathbf{x})].$$

由于 $\partial_t = -\partial_s$ ：

$$\partial_s p_{T-s}(\mathbf{x}) = \nabla_{\mathbf{x}} \cdot [\tilde{\mathbf{f}}(\mathbf{x}, T - s)p_{T-s}(\mathbf{x})].$$

代入 $\bar{p}_s = p_{T-s}$ ：

$$\begin{aligned} \partial_s p_{T-s} &= -\nabla_{\mathbf{x}} \cdot \left[\tilde{\mathbf{f}}(\mathbf{x}, T - s)p_{T-s}(\mathbf{x}) - \frac{1}{2}g^2(T - s)\frac{\nabla_{\mathbf{x}} p_{T-s}(\mathbf{x})}{p_{T-s}(\mathbf{x})}p_{T-s}(\mathbf{x}) \right] \\ &\quad + \frac{1}{2}g^2(T - s)\Delta_{\mathbf{x}} p_{T-s}(\mathbf{x}). \end{aligned}$$

额外的一项为：

$$\begin{aligned} & -\nabla_{\mathbf{x}} \cdot \left[-\frac{1}{2}g^2(T-s)\nabla_{\mathbf{x}}p_{T-s}(\mathbf{x}) \right] + \frac{1}{2}g^2(T-s)\Delta_{\mathbf{x}}p_{T-s}(\mathbf{x}) \\ & = \frac{1}{2}g^2(T-s)\Delta_{\mathbf{x}}p_{T-s}(\mathbf{x}) - \frac{1}{2}g^2(T-s)\Delta_{\mathbf{x}}p_{T-s}(\mathbf{x}) = 0. \end{aligned}$$

因此， $\bar{p}_s = p_{T-s}$ 满足 Fokker-Planck 方程. 由于 $\bar{\mathbf{x}}(0) \sim p_T$ ，有 $\bar{p}_0 = p_T$ ，初始条件也匹配. 唯一性（在足够光滑的条件下）保证 $\bar{p}_s = p_{T-s}$ ，所以 $\bar{\mathbf{x}}(t) = \bar{\mathbf{x}}(T-s) \sim p_{T-t}$. ■

D.2.6 命题 4.2.1: SM 与 DSM 的极小化子

证明. 为求极小化子 $\mathbf{s}^*$ ，先考虑固定时刻 t ，分析目标函数中的内层期望：

$$\mathcal{J}(t, \phi) := \mathbb{E}_{\mathbf{x}_0 \sim p_{\text{data}}} \mathbb{E}_{\mathbf{x}_t \sim p_t(\cdot|\mathbf{x}_0)} [\|\mathbf{s}_\phi(\mathbf{x}_t, t) - \nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t|\mathbf{x}_0)\|_2^2].$$

为最小化这一期望，需要找到使每个 $\mathbf{x}_t$ 处的期望平方误差最小的 $\mathbf{s}_\phi(\mathbf{x}_t, t)$. 利用 X_0 和 X_t 的联合分布，可以改写这一期望：

$$\mathcal{J}(t, \phi) = \iint p_{\text{data}}(\mathbf{x}_0)p_t(\mathbf{x}_t|\mathbf{x}_0) \|\mathbf{s}_\phi(\mathbf{x}_t, t) - \nabla_{\mathbf{x}_t} \log p(\mathbf{x}_t|\mathbf{x}_0)\|_2^2 d\mathbf{x}_0 d\mathbf{x}_t.$$

对于每个固定的 $\mathbf{x}_t$ ，需要最小化：

$$\int p(\mathbf{x}_0|X_t = \mathbf{x}_t)p_t(\mathbf{x}_t) \|\mathbf{s}_\phi(\mathbf{x}_t, t) - \nabla_{\mathbf{x}_t} \log p(\mathbf{x}_t|\mathbf{x}_0)\|_2^2 d\mathbf{x}_0.$$

由于 $p_t(\mathbf{x}_t)$ 相对于 $\mathbf{s}_\phi(\mathbf{x}_t, t)$ 是常数，这等价于最小化：

$$\int p(\mathbf{x}_0|X_t = \mathbf{x}_t) \|\mathbf{s}_\phi(\mathbf{x}_t, t) - \nabla_{\mathbf{x}_t} \log p(\mathbf{x}_t|\mathbf{x}_0)\|_2^2 d\mathbf{x}_0$$

当 $\mathbf{s}_\phi(\mathbf{x}_t, t)$ 等于如下条件期望时，达到最小值：

$$\mathbf{s}^*(\mathbf{x}_t, t) = \mathbb{E}_{X_0 \sim p(X_0|X_t=\mathbf{x}_t)} [\nabla_{\mathbf{x}_t} \log p(\mathbf{x}_t|X_0)].$$

现在需要证明它等于 $\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t)$. 由 Bayes 公式与边缘概率的定义：

$$p_t(\mathbf{x}_t) = \int p_t(\mathbf{x}_t|\mathbf{x}_0)p_{\text{data}}(\mathbf{x}_0) d\mathbf{x}_0.$$

取对数，再对 $\mathbf{x}_t$ 求梯度：

$$\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t) = \frac{\nabla_{\mathbf{x}_t} p_t(\mathbf{x}_t)}{p_t(\mathbf{x}_t)} = \frac{\nabla_{\mathbf{x}_t} \int p_t(\mathbf{x}_t|\mathbf{x}_0)p_{\text{data}}(\mathbf{x}_0) d\mathbf{x}_0}{\int p_t(\mathbf{x}_t|\mathbf{x}_0)p_{\text{data}}(\mathbf{x}_0) d\mathbf{x}_0}.$$

在适当的正则性条件下，可以交换梯度与积分：

$$\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t) = \frac{\int \nabla_{\mathbf{x}_t} p_t(\mathbf{x}_t|\mathbf{x}_0)p_{\text{data}}(\mathbf{x}_0) d\mathbf{x}_0}{\int p_t(\mathbf{x}_t|\mathbf{x}_0)p_{\text{data}}(\mathbf{x}_0) d\mathbf{x}_0}.$$

■

D.2.7 高斯分布得分函数的闭式表达

为便于后文引用，将一般多元正态分布的得分公式总结为如下引理：

引理 D.2.1: 高斯分布的得分

设 $\mathbf{x} \in \mathbb{R}^D$, 考虑多元正态分布

$$p(\tilde{\mathbf{x}}|\mathbf{x}) := \mathcal{N}(\tilde{\mathbf{x}}; \boldsymbol{\mu}, \boldsymbol{\Sigma}),$$

其中 $\boldsymbol{\mu} \in \mathbb{R}^D$ 是均值, $\boldsymbol{\Sigma} \in \mathbb{R}^{D \times D}$ 是可逆协方差矩阵. 其得分函数为

$$\nabla_{\tilde{\mathbf{x}}} \log p(\tilde{\mathbf{x}}|\mathbf{x}) = -\boldsymbol{\Sigma}^{-1}(\tilde{\mathbf{x}} - \boldsymbol{\mu}). \quad (\text{D.2.4})$$

引理的证明.

$p(\tilde{\mathbf{x}}|\mathbf{x})$ 的密度函数为:

$$p(\tilde{\mathbf{x}}|\mathbf{x}) = \frac{1}{(2\pi)^{D/2} |\boldsymbol{\Sigma}|^{1/2}} \exp \left(-\frac{1}{2} (\tilde{\mathbf{x}} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1} (\tilde{\mathbf{x}} - \boldsymbol{\mu}) \right).$$

为计算得分函数, 先取 $p(\tilde{\mathbf{x}}|\mathbf{x})$ 的对数:

$$\log p(\tilde{\mathbf{x}}|\mathbf{x}) = -\frac{D}{2} \log(2\pi) - \frac{1}{2} \log |\boldsymbol{\Sigma}| - \frac{1}{2} (\tilde{\mathbf{x}} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1} (\tilde{\mathbf{x}} - \boldsymbol{\mu}).$$

现在计算 $\log p(\tilde{\mathbf{x}}|\mathbf{x})$ 关于 $\tilde{\mathbf{x}}$ 的梯度:

$$\nabla_{\tilde{\mathbf{x}}} \log p(\tilde{\mathbf{x}}|\mathbf{x}) = -\frac{1}{2} \nabla_{\tilde{\mathbf{x}}} \left((\tilde{\mathbf{x}} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1} (\tilde{\mathbf{x}} - \boldsymbol{\mu}) \right).$$

利用链式法则, 得到:

$$\nabla_{\tilde{\mathbf{x}}} \left((\tilde{\mathbf{x}} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1} (\tilde{\mathbf{x}} - \boldsymbol{\mu}) \right) = 2\boldsymbol{\Sigma}^{-1}(\tilde{\mathbf{x}} - \boldsymbol{\mu}).$$

因此, 得分函数为:

$$\nabla_{\tilde{\mathbf{x}}} \log p(\tilde{\mathbf{x}}|\mathbf{x}) = -\boldsymbol{\Sigma}^{-1}(\tilde{\mathbf{x}} - \boldsymbol{\mu}). \quad (\text{D.2.5})$$

D.3 基于流的视角

D.3.1 引理 5.1.1: 瞬时变量替换

证明. 方法一: 变量替换公式. 将 $p(\mathbf{x}(t), t)$ 记为 $p_t(\mathbf{x}_t)$. 从 ODE 的离散化出发:

$$\mathbf{z}_{t+\Delta t} = \mathbf{z}_t + \Delta t \mathbf{F}(\mathbf{z}_t, t),$$

归一化流的变量替换公式 (式 (5.1.1)) 给出

$$\begin{aligned} \log p_{t+\Delta t}(\mathbf{z}_{t+\Delta t}) &= \log p_t(\mathbf{z}_t) - \log \left| \det (\mathbf{I} + \Delta t \nabla_{\mathbf{z}} \mathbf{F}(\mathbf{z}_t, t)) \right| \\ &= \log p_t(\mathbf{z}_t) - \text{Tr} \left(\log(\mathbf{I} + \Delta t \nabla_{\mathbf{z}} \mathbf{F}(\mathbf{z}_t, t)) \right) \\ &= \log p_t(\mathbf{z}_t) - \Delta t \text{Tr} (\nabla_{\mathbf{z}} \mathbf{F}(\mathbf{z}_t, t)) + \mathcal{O}(\Delta t^2), \end{aligned}$$

其中使用了 $\log \det = \text{Tr} \log$, 以及 Δt 较小时的展开. 取极限 $\Delta t \rightarrow 0$, 得到对数密度的连续时间微分方程. 实际上, 式 (5.1.6) 也使用了相同技巧.

方法二: 连续性方程. 也可以使用本质上起变量替换公式作用的连续性方程:

$$\partial_t p(\mathbf{z}, t) = -\nabla_{\mathbf{z}} \cdot (\mathbf{F}(\mathbf{z}, t) p(\mathbf{z}, t)).$$

展开散度,

$$\partial_t p = -((\nabla_{\mathbf{z}} \cdot \mathbf{F})p + \mathbf{F} \cdot \nabla_{\mathbf{z}} p).$$

沿满足 $\frac{d\mathbf{z}}{dt} = \mathbf{F}(\mathbf{z}(t), t)$ 的轨迹 $\mathbf{z}(t)$, 关于时间的全导数为

$$\begin{aligned} \frac{d}{dt} p(\mathbf{z}(t), t) &= \nabla_{\mathbf{z}} p \cdot \frac{d\mathbf{z}}{dt} + \partial_t p \\ &= \nabla_{\mathbf{z}} p \cdot \mathbf{F} - ((\nabla_{\mathbf{z}} \cdot \mathbf{F})p + \mathbf{F} \cdot \nabla_{\mathbf{z}} p) \\ &= -(\nabla_{\mathbf{z}} \cdot \mathbf{F})p. \end{aligned}$$

除以 $p(\mathbf{z}(t), t)$, 得到

$$\frac{d}{dt} \log p(\mathbf{z}(t), t) = -\nabla_{\mathbf{z}} \cdot \mathbf{F}(\mathbf{z}(t), t).$$

■

D.3.2 定理 5.2.2: 质量守恒判据

预备知识: 流映射与流诱导的密度. 对于任意初始位置 $\mathbf{x}_0 \in \mathbb{R}^D$, 流映射 $\Psi_t: \mathbb{R}^D \rightarrow \mathbb{R}^D$ 是如下 ODE 的唯一解:

$$\frac{d}{dt} \Psi_t(\mathbf{x}_0) = \mathbf{v}_t(\Psi_t(\mathbf{x}_0)), \quad \Psi_0(\mathbf{x}_0) = \mathbf{x}_0.$$

在所假定的正则性条件下, Ψ_t 关于 t 与 $\mathbf{x}_0$ 均连续可微.

流诱导的密度 p_t^{fwd} 是初始密度 p_0 在 Ψ_t 下的推前:

$$p_t^{\text{fwd}}(\mathbf{x}) = p_0(\Psi_t^{-1}(\mathbf{x})) \left| \det(\nabla \Psi_t^{-1}(\mathbf{x})) \right|.$$

这给出了从 $p_0 = p_{\text{data}}$ 出发、在速度场 $\mathbf{v}_t$ 下演化的粒子, 在时刻 t 、位置 $\mathbf{x}$ 处的密度.

非形式化证明：充分条件： $p_t^{\text{fwd}} = p_t \Rightarrow$ **连续性方程**. 在节 B.1.2 中，通过取离散变量替换公式的连续时间极限，得到了连续性方程的强解. 那种方法假定密度 p_t 足够光滑，使所有导数都在经典意义下存在，并且 PDE 逐点成立. 这里给出弱意义下的补充推导：仅在与任意光滑检验函数积分后施加连续性方程，从而放宽对 p_t 和速度场 $\mathbf{v}_t$ 的正则性要求. 这种弱表述可以容纳正则性较低的解，因而更为严谨，同时也是 PDE 理论与数值分析中的标准框架.

对于任意具有紧支集的光滑检验函数 $\varphi(\mathbf{x})$ ，推前性质给出：

$$\begin{aligned} \int p_t^{\text{fwd}}(\mathbf{x}) \varphi(\mathbf{x}) d\mathbf{x} &= \int p_0(\Psi_t^{-1}(\mathbf{x})) |\det(\nabla \Psi_t^{-1}(\mathbf{x}))| \varphi(\mathbf{x}) d\mathbf{x} \\ &= \int p_0(\mathbf{y}) \varphi(\Psi_t(\mathbf{y})) d\mathbf{y}, \end{aligned}$$

其中第二个等式来自变量替换 $\mathbf{x} = \Psi_t(\mathbf{y})$ ，此时 $d\mathbf{y} = |\det(\nabla \Psi_t^{-1}(\mathbf{x}))| d\mathbf{x}$.

两边关于 t 求导：

$$\frac{d}{dt} \int p_t^{\text{fwd}}(\mathbf{x}) \varphi(\mathbf{x}) d\mathbf{x} = \frac{d}{dt} \int p_0(\mathbf{y}) \varphi(\Psi_t(\mathbf{y})) d\mathbf{y}.$$

左侧为：

$$\int \frac{\partial p_t^{\text{fwd}}}{\partial t}(\mathbf{x}) \varphi(\mathbf{x}) d\mathbf{x}.$$

右侧为：

$$\int p_0(\mathbf{y}) \nabla \varphi(\Psi_t(\mathbf{y})) \cdot \mathbf{v}_t(\Psi_t(\mathbf{y})) d\mathbf{y},$$

因为 $\frac{\partial \Psi_t}{\partial t}(\mathbf{y}) = \mathbf{v}_t(\Psi_t(\mathbf{y}))$. 作变量替换 $\mathbf{x} = \Psi_t(\mathbf{y})$ ，则

$$d\mathbf{y} = |\det(\nabla \Psi_t^{-1}(\mathbf{x}))| d\mathbf{x},$$

并且

$$p_0(\mathbf{y}) = p_t^{\text{fwd}}(\mathbf{x}) |\det(\nabla \Psi_t^{-1}(\mathbf{x}))| = \frac{p_t^{\text{fwd}}(\mathbf{x})}{|\det(\nabla \Psi_t^{-1}(\mathbf{x}))|}.$$

因此，右侧变为：

$$\int p_t^{\text{fwd}}(\mathbf{x}) \nabla \varphi(\mathbf{x}) \cdot \mathbf{v}_t(\mathbf{x}) d\mathbf{x}.$$

利用 φ 的紧支集性质，应用分部积分：

$$\int p_t^{\text{fwd}}(\mathbf{x}) \nabla \varphi(\mathbf{x}) \cdot \mathbf{v}_t(\mathbf{x}) d\mathbf{x} = - \int \varphi(\mathbf{x}) \nabla \cdot (p_t^{\text{fwd}}(\mathbf{x}) \mathbf{v}_t(\mathbf{x})) d\mathbf{x}.$$

令两边相等：

$$\int \left[\frac{\partial p_t^{\text{fwd}}}{\partial t}(\mathbf{x}) + \nabla \cdot (p_t^{\text{fwd}}(\mathbf{x}) \mathbf{v}_t(\mathbf{x})) \right] \varphi(\mathbf{x}) d\mathbf{x} = 0.$$

由于 φ 任意, 得到:

$$\frac{\partial p_t^{\text{fwd}}}{\partial t} + \nabla \cdot (p_t^{\text{fwd}} \mathbf{v}_t) = 0.$$

给定 $p_t^{\text{fwd}} = p_t$, 这蕴含:

$$\frac{\partial p_t}{\partial t} + \nabla \cdot (p_t \mathbf{v}_t) = 0.$$

必要条件: 连续性方程 $\Rightarrow p_t^{\text{fwd}} = p_t$. 假设 p_t 满足连续性方程:

$$\frac{\partial p_t}{\partial t} + \nabla \cdot (p_t \mathbf{v}_t) = 0,$$

初始条件为 $p_0(\mathbf{x}) = p_{\text{data}}(\mathbf{x})$. 由前面的推导, p_t^{fwd} 满足相同的连续性方程, 并且:

$$p_0^{\text{fwd}}(\mathbf{x}) = p_0(\Psi_0^{-1}(\mathbf{x})) |\det(\nabla \Psi_0^{-1}(\mathbf{x}))| = p_0(\mathbf{x}),$$

因为 $\Psi_0(\mathbf{x}) = \mathbf{x}$. 因而两个密度具有相同的初始条件 $p_0 = p_{\text{data}}$.

连续性方程可以改写为:

$$\frac{\partial p}{\partial t} + \mathbf{v}_t \cdot \nabla p + p \nabla \cdot \mathbf{v}_t = 0.$$

这是一阶线性 PDE. 假定 $\mathbf{v}_t$ 连续可微且全局 Lipschitz, p_t 足够光滑, 特征线法保证光滑函数空间中存在唯一解. 由于 p_t 和 p_t^{fwd} 满足相同的 PDE 与初始条件, 得到:

$$p_t(\mathbf{x}) = p_t^{\text{fwd}}(\mathbf{x})$$

对所有 $t \in [0, 1]$ 和 $\mathbf{x} \in \mathbb{R}^D$ 成立.

这就完成了等价性的证明. ■

D.4 理论补充：扩散模型的统一系统视角

D.4.1 命题 6.3.1：参数化的等价性

证明： 正如关于 DSM 损失的定理 4.2.1，匹配损失

$$\mathbb{E}_t [\omega(t) \mathbb{E}_{\mathbf{x}_0, \epsilon} [\|\cdot\|_2^2]]$$

在对每个固定的 t 最小化内层期望

$$\mathbb{E}_{\mathbf{x}_0, \epsilon} [\|\cdot\|_2^2]$$

时取得全局最优值。由于这是标准的均方误差问题，极小化子唯一。根据去噪得分匹配 (Vincent, 2011)，定理 4.2.1 表明最优得分函数满足

$$\mathbf{s}^*(\mathbf{x}_t, t) = \mathbb{E}_{p(\mathbf{x}_0|\mathbf{x}_t)} [\nabla_{\mathbf{x}} \log p_t(\mathbf{x}_t|\mathbf{x}_0)] = \nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t).$$

对于 $\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ ，利用恒等式 $\nabla_{\mathbf{x}} \log p_t(\mathbf{x}_t|\mathbf{x}_0) = -\frac{1}{\sigma_t} \epsilon$ ，得到

$$\mathbf{s}^*(\mathbf{x}_t, t) = -\frac{1}{\sigma_t} \epsilon^*(\mathbf{x}_t, t),$$

其中 $\epsilon^*(\mathbf{x}_t, t) = \mathbb{E}_{p(\mathbf{x}_0|\mathbf{x}_t)} [\epsilon|\mathbf{x}_t]$ 是 $\mathcal{L}_{\text{noise}}(\phi)$ 的最优 ϵ 预测。对于 $\mathbf{x}$ 预测损失 $\mathcal{L}_{\text{clean}}$ ，最优估计器为

$$\mathbf{x}^*(\mathbf{x}_t, t) = \mathbb{E}_{p(\mathbf{x}_0|\mathbf{x}_t)} [\mathbf{x}_0|\mathbf{x}_t],$$

根据 Tweedie 公式，它与得分具有如下关系：

$$\alpha_t \mathbf{x}^*(\mathbf{x}_t, t) = \mathbf{x}_t + \sigma_t^2 \mathbf{s}^*(\mathbf{x}_t, t).$$

对于 $\mathbf{v}$ 预测损失 $\mathcal{L}_{\text{velocity}}$ ，最优估计器为

$$\begin{aligned} \mathbf{v}^*(\mathbf{x}_t, t) &= \mathbb{E}_{p(\mathbf{x}_0|\mathbf{x}_t)} [\alpha'_t \mathbf{x}_0 + \sigma'_t \epsilon|\mathbf{x}_t] \\ &= \alpha'_t \mathbf{x}^* + \sigma'_t \epsilon^*. \end{aligned}$$

代入由 $\mathbf{s}^*$ 表示的 $\mathbf{x}^*$ 和 ϵ^* ，得到

$$\begin{aligned} \mathbf{v}^*(\mathbf{x}_t, t) &= \frac{\alpha'_t}{\alpha_t} \mathbf{x}_t + \left(\frac{\alpha'_t}{\alpha_t} \sigma_t^2 - \sigma_t \sigma'_t \right) \mathbf{s}^*(\mathbf{x}_t, t) \\ &= f(t) \mathbf{x}_t - \frac{1}{2} g^2(t) \mathbf{s}^*(\mathbf{x}_t, t), \end{aligned}$$

推导完毕. ■

D.5 理论补充：学习基于扩散的快速生成器

D.5.1 知识蒸馏损失作为一般框架式 (10.1.4) 的特例

从理想 KD 损失出发：

$$\mathcal{L}_{\text{KD}}^{\text{oracle}}(\theta) = \mathbb{E}_{\mathbf{x}_T \sim p_T} \left\| \mathbf{G}_\theta(\mathbf{x}_T, T, 0) - \Psi_{T \rightarrow 0}(\mathbf{x}_T) \right\|_2^2,$$

其中 $p_T = p_{\text{prior}}$. 对于确定性 ODE 流映射 Ψ (具有半群性质, 且沿轨迹为双射), 边缘分布满足推前恒等式

$$p_t = \Psi_{0 \rightarrow t} \# p_{\text{data}} = \Psi_{T \rightarrow t} \# p_{\text{prior}};$$

因此,

$$\Psi_{s \rightarrow T} \# p_s = p_T \quad \text{且} \quad \Psi_{T \rightarrow 0} \circ \Psi_{s \rightarrow T} = \Psi_{s \rightarrow 0}.$$

令 $\mathbf{x}_s \sim p_s$, 作变量替换 $\mathbf{x}_T = \Psi_{s \rightarrow T}(\mathbf{x}_s)$, 得到

$$\mathcal{L}_{\text{KD}}^{\text{oracle}}(\theta) = \mathbb{E}_{\mathbf{x}_s \sim p_s} \left\| \mathbf{G}_\theta(\Psi_{s \rightarrow T}(\mathbf{x}_s), T, 0) - \Psi_{s \rightarrow 0}(\mathbf{x}_s) \right\|_2^2.$$

定义拉回后的学生 $\tilde{\mathbf{G}}_\theta(\mathbf{x}_s, s, 0) := \mathbf{G}_\theta(\Psi_{s \rightarrow T}(\mathbf{x}_s), T, 0)$, 将同一损失表示为统一的流映射形式 (在 $t = 0$ 处):

$$\mathcal{L}_{\text{KD}}^{\text{oracle}}(\theta) = \mathbb{E}_{\mathbf{x}_s \sim p_s} \left\| \tilde{\mathbf{G}}_\theta(\mathbf{x}_s, s, 0) - \Psi_{s \rightarrow 0}(\mathbf{x}_s) \right\|_2^2.$$

这一推导依赖于通过理想流进行变量替换, 以及半群性质. ■

D.5.2 命题 10.2.1 的参数流解释

根据命题 10.2.1 的推导, 可将 VSD 的梯度解释为参数诱导的输运流: 调整模型参数会移动数据空间中的粒子, 使其运动与学生分布和教师分布之间的得分差异对齐.

令 $t \sim p(t)$, $\mathbf{z} \sim p(\mathbf{z})$, $\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$, 并且

$$\hat{\mathbf{x}}_t = \alpha_t \mathbf{G}_\theta(\mathbf{z}) + \sigma_t \epsilon.$$

定义样本 (粒子) 速度

$$\hat{\mathbf{v}}_\theta(\hat{\mathbf{x}}_t) := \partial_\theta \hat{\mathbf{x}}_t = \alpha_t \partial_\theta \mathbf{G}_\theta(\mathbf{z}),$$

并将 $\mathbf{x}$ 空间中的速度场定义为条件平均

$$\mathbf{v}_\theta(\mathbf{x}) := \mathbb{E}[\hat{\mathbf{v}}_\theta(\hat{\mathbf{x}}_t) | \hat{\mathbf{x}}_t = \mathbf{x}].$$

在这一定义下，每个固定 t 处的密度遵循参数流连续性方程

$$\partial_{\theta} p_t^{\theta}(\mathbf{x}) + \nabla_{\mathbf{x}} \cdot (p_t^{\theta}(\mathbf{x}) \mathbf{v}_{\theta}(\mathbf{x})) = 0.$$

这里， $\mathbf{v}_{\theta}(\hat{\mathbf{x}}_t) = \partial_{\theta} \hat{\mathbf{x}}_t$ 是数据空间中参数诱导的粒子速度（固定 t ）。等价地，在每个固定的 t 处，密度满足关于 θ 的连续性方程：

$$\partial_{\theta} p_t^{\theta}(\mathbf{x}) + \nabla_{\mathbf{x}} \cdot (p_t^{\theta}(\mathbf{x}) \mathbf{v}_{\theta}(\mathbf{x})) = 0.$$

因此， $\mathcal{L}_{\text{VSD}}$ 的梯度具有输运形式：

$$\nabla_{\theta} \mathcal{L}_{\text{VSD}} = \mathbb{E} \left[\omega(t) \underbrace{(\nabla_{\mathbf{x}} \log p_t^{\theta} - \nabla_{\mathbf{x}} \log p_t)}_{\text{固定 } t \text{ 处的得分差异}}, \underbrace{\mathbf{v}_{\theta}}_{\text{参数流速度}} \right],$$

这表明：调整参数流，使粒子运动与局部得分差异对齐，从而沿轨迹减小散度。

D.5.3 定理 11.2.1: CM 与 CT 相等至 $\mathcal{O}(\Delta s)$

证明：步骤一：DDIM 更新（采用理想得分）是条件均值。

$$\begin{aligned} \hat{\mathbf{x}}_{s'} &:= \frac{\alpha_{s'}}{\alpha_s} \mathbf{x}_s + \sigma_s^2 \left(\frac{\alpha_{s'}}{\alpha_s} - \frac{\sigma_{s'}}{\sigma_s} \right) \nabla_{\mathbf{x}_s} \log p_s(\mathbf{x}_s) \\ &= \frac{\alpha_{s'}}{\alpha_s} (\mathbf{x}_s + \sigma_s^2 \nabla_{\mathbf{x}_s} \log p_s(\mathbf{x}_s)) - \sigma_{s'} \sigma_s \nabla_{\mathbf{x}_s} \log p_s(\mathbf{x}_s) \\ &= \alpha_{s'} \mathbb{E}[\mathbf{x}_0 | \mathbf{x}_s] + \sigma_{s'} \left(\frac{\mathbf{x}_s - \alpha_s \mathbb{E}[\mathbf{x}_0 | \mathbf{x}_s]}{\sigma_s} \right) \\ &= \alpha_{s'} \mathbb{E}[\mathbf{x}_0 | \mathbf{x}_s] + \sigma_{s'} \mathbb{E}[\epsilon | \mathbf{x}_s] \\ &= \mathbb{E}[\alpha_{s'} \mathbf{x}_0 + \sigma_{s'} \epsilon | \mathbf{x}_s] \\ &= \mathbb{E}[\mathbf{x}_{s'} | \mathbf{x}_s]. \end{aligned}$$

这里，在第三和第四个等式中使用了 Tweedie 公式 $\mathbb{E}[\mathbf{x}_0 | \mathbf{x}_s] = \frac{\mathbf{x}_s + \sigma_s^2 \nabla_{\mathbf{x}_s} \log p_s(\mathbf{x}_s)}{\alpha_s}$ ，以及 $\mathbf{x}_s = \alpha_s \mathbf{x}_0 + \sigma_s \epsilon$ 。

步骤二：在条件均值 $\hat{\mathbf{x}}_{s'}$ 附近展开 CT。

$$\begin{aligned} \mathcal{L}_{\text{CT}} &= \mathbb{E}_{s, \mathbf{x}_s} \mathbb{E}_{\mathbf{x}_{s'} | \mathbf{x}_s} \left[w(s) d(\mathbf{f}_{\theta}(\mathbf{x}_s, s), \mathbf{f}_{\theta-}(\mathbf{x}_{s'}, s')) \right] \\ &\stackrel{(1)}{=} \mathbb{E}_{s, \mathbf{x}_s} \mathbb{E}_{\mathbf{x}_{s'} | \mathbf{x}_s} \left[w(s) d(\mathbf{f}_{\theta}(\mathbf{x}_s, s), \mathbf{f}_{\theta-}(\hat{\mathbf{x}}_{s'}, s')) \right. \\ &\quad \left. + w(s) \partial_2 d(\mathbf{f}_{\theta}(\mathbf{x}_s, s), \mathbf{f}_{\theta-}(\hat{\mathbf{x}}_{s'}, s')) [\partial_1 \mathbf{f}_{\theta-}(\hat{\mathbf{x}}_{s'}, s') (\mathbf{x}_{s'} - \hat{\mathbf{x}}_{s'})] \right. \\ &\quad \left. + w(s) \mathcal{O}(\|\mathbf{x}_{s'} - \hat{\mathbf{x}}_{s'}\|^2) \right] \\ &\stackrel{(2)}{=} \mathbb{E}_{s, \mathbf{x}_s} \left[w(s) d(\mathbf{f}_{\theta}(\mathbf{x}_s, s), \mathbf{f}_{\theta-}(\hat{\mathbf{x}}_{s'}, s')) \right] \\ &\quad + \mathbb{E}_{s, \mathbf{x}_s} \left[w(s) \partial_2 d(\mathbf{f}_{\theta}(\mathbf{x}_s, s), \mathbf{f}_{\theta-}(\hat{\mathbf{x}}_{s'}, s')) [\partial_1 \mathbf{f}_{\theta-}(\hat{\mathbf{x}}_{s'}, s') \mathbb{E}_{\mathbf{x}_{s'} | \mathbf{x}_s} (\mathbf{x}_{s'} - \hat{\mathbf{x}}_{s'})] \right] \\ &\quad + \mathbb{E}_{s, \mathbf{x}_s} \mathbb{E}_{\mathbf{x}_{s'} | \mathbf{x}_s} \left[w(s) \mathcal{O}(\|\mathbf{x}_{s'} - \hat{\mathbf{x}}_{s'}\|^2) \right] \end{aligned}$$

$$\begin{aligned}
&\stackrel{(3)}{=} \mathbb{E}_{s, \mathbf{x}_s} \left[w(s) d(\mathbf{f}_\theta(\mathbf{x}_s, s), \mathbf{f}_{\theta^-}(\hat{\mathbf{x}}_{s'}, s')) \right] + \mathbb{E}_{s, \mathbf{x}_s} \mathbb{E}_{\mathbf{x}_{s'} | \mathbf{x}_s} \left[w(s) \mathcal{O}(\|\mathbf{x}_{s'} - \hat{\mathbf{x}}_{s'}\|^2) \right] \\
&= \mathbb{E}_{s, \mathbf{x}_s} \left[w(s) d(\mathbf{f}_\theta(\mathbf{x}_s, s), \mathbf{f}_{\theta^-}(\hat{\mathbf{x}}_{s'}, s')) \right] + \mathcal{O} \left(\mathbb{E}_{s, \mathbf{x}_s} \mathbb{E}_{\mathbf{x}_{s'} | \mathbf{x}_s} \|\mathbf{x}_{s'} - \hat{\mathbf{x}}_{s'}\|^2 \right) \\
&= \mathcal{L}_{\text{CM}} + \mathcal{O} \left(\mathbb{E}_{s, \mathbf{x}_s} \mathbb{E}_{\mathbf{x}_{s'} | \mathbf{x}_s} \|\mathbf{x}_{s'} - \hat{\mathbf{x}}_{s'}\|^2 \right) \\
&\stackrel{(4)}{=} \mathcal{L}_{\text{CM}} + o(\Delta s)
\end{aligned}$$

这里，各步说明如下：

1. 对

$$h(\mathbf{x}') := d(\mathbf{f}_\theta(\mathbf{x}_s, s), \mathbf{f}_{\theta^-}(\mathbf{x}', s'))$$

的第二个自变量，在 $\hat{\mathbf{x}}_{s'}$ 附近进行二阶 Taylor 展开。

2. 应用塔式性质

$$\mathbb{E}_{s, \mathbf{x}_s} \mathbb{E}_{\mathbf{x}_{s'} | \mathbf{x}_s} [\cdot] = \mathbb{E}_{s, \mathbf{x}_s} [\cdot]$$

并注意到，在 $\mathbb{E}_{\mathbf{x}_{s'} | \mathbf{x}_s}$ 内，只有 $(\mathbf{x}_{s'} - \hat{\mathbf{x}}_{s'})$ 依赖于 $\mathbf{x}_{s'}$ ；所以其他因子均作为常数，内层期望简化为 $\mathbb{E}_{\mathbf{x}_{s'} | \mathbf{x}_s} (\mathbf{x}_{s'} - \hat{\mathbf{x}}_{s'})$ 和 $\mathbb{E}_{\mathbf{x}_{s'} | \mathbf{x}_s} \|\mathbf{x}_{s'} - \hat{\mathbf{x}}_{s'}\|^2$ 。

3. 使用 $\mathbb{E}[\mathbf{x}_{s'} - \hat{\mathbf{x}}_{s'} | \mathbf{x}_s] = \mathbf{0}$ ，因为 $\hat{\mathbf{x}}_{s'} = \mathbb{E}[\mathbf{x}_{s'} | \mathbf{x}_s]$ 。

4. 使用线性高斯调度，它给出

$$\mathbb{E}[\|\mathbf{x}_{s'} - \hat{\mathbf{x}}_{s'}\|^2 | \mathbf{x}_s] = \mathcal{O}(\Delta s^2),$$

因此总余项为 $o(\Delta s)$ 。

■

D.5.4 命题 11.3.1: CT 梯度的连续时间极限

证明： 为简化记号，对式 (11.3.2) 进行证明：

$$\mathcal{L}_{\text{CM}}^{\Delta s}(\boldsymbol{\theta}, \boldsymbol{\theta}^-) := \mathbb{E} \left[\omega(s) \left\| \mathbf{f}_\theta(\mathbf{x}_s, s) - \mathbf{f}_{\theta^-}(\Psi_{s \rightarrow s - \Delta s}(\mathbf{x}_s), s - \Delta s) \right\|_2^2 \right].$$

为简化记号，写为 $\tilde{\mathbf{x}}_{s - \Delta s} := \Psi_{s \rightarrow s - \Delta s}(\mathbf{x}_s)$ 。

展开 MSE 损失，得到

$$\begin{aligned}
&\left\| \mathbf{f}_\theta(\mathbf{x}_s, s) - \mathbf{f}_{\theta^-}(\tilde{\mathbf{x}}_{s - \Delta s}, s - \Delta s) \right\|_2^2 \\
&= \left\| \underbrace{(\mathbf{f}_\theta(\mathbf{x}_s, s) - \mathbf{f}_{\theta^-}(\mathbf{x}_s, s))}_{=: \delta \mathbf{f}} + (\mathbf{f}_{\theta^-}(\mathbf{x}_s, s) - \mathbf{f}_{\theta^-}(\tilde{\mathbf{x}}_{s - \Delta s}, s - \Delta s)) \right\|_2^2 \\
&= \|\delta \mathbf{f}\|_2^2 + 2\delta \mathbf{f}^\top \cdot \frac{d}{ds} \mathbf{f}_{\theta^-}(\mathbf{x}_s, s) \Delta s + \left\| \frac{d}{ds} \mathbf{f}_{\theta^-}(\mathbf{x}_s, s) \right\|_2^2 |\Delta s|^2 + \mathcal{O}(|\Delta s|^3).
\end{aligned}$$

这里，在 $(\mathbf{x}_s, s)$ 处进行 Taylor 展开：

$$\mathbf{f}_{\theta^-}(\mathbf{x}_s, s) - \mathbf{f}_{\theta^-}(\tilde{\mathbf{x}}_{s-\Delta s}, s - \Delta s) = \frac{d}{ds} \mathbf{f}_{\theta^-}(\mathbf{x}_s, s) \Delta s + \mathcal{O}(|\Delta s|^2),$$

结合理想流映射的一阶展开，

$$\mathbf{x}_s - \Psi_{s \rightarrow s-\Delta s}(\mathbf{x}_s) = \mathbf{v}^*(\mathbf{x}_s, s) \Delta s + \mathcal{O}(|\Delta s|^2),$$

以及全微分恒等式，

$$\frac{d}{ds} \mathbf{f}_{\theta^-}(\mathbf{x}_s, s) = \partial_s \mathbf{f}_{\theta^-}(\mathbf{x}_s, s) + (\partial_{\mathbf{x}} \mathbf{f}_{\theta^-}(\mathbf{x}_s, s)) \mathbf{v}^*(\mathbf{x}_s, s),$$

来简化这一表达式。

由于 θ^- 被视为常数，且是 θ 的相同副本（即梯度不通过它传播）， $\mathcal{L}_{\text{CM}}^{\Delta s}(\theta, \theta^-)$ 关于 θ 的梯度为：

$$\nabla_{\theta} \mathcal{L}_{\text{CM}}^{\Delta s}(\theta, \theta^-) = 2\mathbb{E} \left[\omega(s) \nabla_{\theta} \mathbf{f}_{\theta}(\mathbf{x}_s, s)^{\top} \cdot \frac{d}{ds} \mathbf{f}_{\theta^-}(\mathbf{x}_s, s) \right] \Delta s + \mathcal{O}(|\Delta s|^2).$$

除以 Δs 并取极限，得到：

$$\lim_{\Delta s \rightarrow 0} \frac{1}{\Delta s} \nabla_{\theta} \mathcal{L}_{\text{CM}}^{\Delta s}(\theta, \theta^-) = \nabla_{\theta} \mathbb{E} \left[2\omega(t) \mathbf{f}_{\theta}^{\top}(\mathbf{x}_s, s) \cdot \frac{d}{ds} \mathbf{f}_{\theta^-}(\mathbf{x}_s, s) \right].$$

这就证明了该恒等式。 ■

D.6 (选读) 阐明扩散模型 (EDM)

介绍阐明扩散模型 (EDM) (Karras et al., 2022) 为 $\mathbf{x}$ 预测模型提出的神经网络参数化设计的具体准则. EDM 提供了一个简单方案, 使训练过程更容易优化, 也更加可靠. $\mathbf{x}$ 预测模型表示为随时间变化的跳跃连接与缩放残差的组合 (式 (D.6.1)). 核心思想是在所有时刻将输入与回归目标都归一化为单位方差, 并调整跳跃路径, 使残差误差 not 随时间演化而放大. 这一方案已成为扩散模型实现中广泛采用的默认方案, 也可自然推广至流映射学习, 尤其是一致性模型系列.

D.6.1 神经网络 $\mathbf{x}_\phi$ 的设计准则

EDM 考虑如下形式的 $\mathbf{x}$ 预测模型参数化, 稍微滥用记号, 将其记为 $\mathbf{x}_\phi(\mathbf{x}, t)$ ¹:

$$\mathbf{x}_\phi(\mathbf{x}, t) := c_{\text{skip}}(t)\mathbf{x} + c_{\text{out}}(t)\mathbf{F}_\phi(c_{\text{in}}(t)\mathbf{x}, c_{\text{noise}}(t)). \quad (\text{D.6.1})$$

这里, $c_{\text{skip}}(t)$ 、 $c_{\text{out}}(t)$ 、 $c_{\text{in}}(t)$ 和 $c_{\text{noise}}(t)$ 是时变函数. 根据稍后介绍的实际考虑选择这些函数, 以增强训练过程的稳定性和性能.

将其代入 式 (6.2.5), 经过直接的代数运算, 目标函数变为²:

$$\mathbb{E}_{\mathbf{x}_0, \epsilon, t} [\omega(t) c_{\text{out}}^2(t) \|\mathbf{F}_\phi(c_{\text{in}}(t)\mathbf{x}_t, c_{\text{noise}}(t)) - \mathbf{x}_{\text{tgt}}(t)\|_2^2]. \quad (\text{D.6.2})$$

这里, 回归目标 $\mathbf{x}_{\text{tgt}}(t)$ 为:

$$\mathbf{x}_{\text{tgt}}(t) = \frac{(1 - c_{\text{skip}}(t)\alpha_t)\mathbf{x}_0 - c_{\text{skip}}(t)\sigma_t\epsilon}{c_{\text{out}}(t)}.$$

引入 p_{data} 的标准差 σ_d , EDM 为网络参数化提出如下设计准则, 可称为单位方差准则.

¹如前所述, 四种预测类型均等价, 都可化归为 $\mathbf{x}$ 预测情形. EDM 采用这一形式, 它既经过充分研究, 也与流映射模型生成干净样本的目标自然一致.

²从 $\mathbf{x}$ 预测扩散损失出发, 代入 式 (D.6.1) 给出的参数化:

$$\begin{aligned} & \mathbb{E}_{\mathbf{x}_0, \epsilon, t} [\omega(t) \|\mathbf{x}_\phi(\mathbf{x}_t, t) - \mathbf{x}_0\|_2^2] \\ &= \mathbb{E}_{\mathbf{x}_0, \epsilon, t} \left[\omega(t) \left\| c_{\text{skip}}(t) \underbrace{(\alpha_t \mathbf{x}_0 + \sigma_t \epsilon)}_{\mathbf{x}_t} + c_{\text{out}}(t) \mathbf{F}_\phi(c_{\text{in}}(t)\mathbf{x}_t, c_{\text{noise}}(t)) - \mathbf{x}_0 \right\|_2^2 \right] \\ &= \mathbb{E}_{\mathbf{x}_0, \epsilon, t} \left[\omega(t) c_{\text{out}}^2(t) \left\| \mathbf{F}_\phi(c_{\text{in}}(t)\mathbf{x}, c_{\text{noise}}(t)) - \underbrace{\left(\frac{(1 - c_{\text{skip}}(t)\alpha_t)\mathbf{x}_0 - c_{\text{skip}}(t)\sigma_t\epsilon}{c_{\text{out}}(t)} \right)}_{\mathbf{x}_{\text{tgt}}(t)} \right\|_2^2 \right] \\ &= \text{式 (D.6.1)}. \end{aligned}$$

输入的单位方差.

$$\begin{aligned} \text{Var}_{\mathbf{x}_0, \epsilon} [c_{\text{in}}(t) \mathbf{x}_t] &= 1 \\ \iff c_{\text{in}}^2(t) \text{Var}_{\mathbf{x}_0, \epsilon} [\alpha_t \mathbf{x}_0 + \sigma_t \epsilon] &= 1 \\ \iff c_{\text{in}}(t) &= \frac{1}{\sqrt{\sigma_d^2 \alpha_t^2 + \sigma_t^2}}, \end{aligned}$$

其中取正根.

训练目标的单位方差.

$$\begin{aligned} \text{Var}_{\mathbf{x}_0, \epsilon} [\mathbf{x}_{\text{tgt}}(t)] &= 1 \\ \iff c_{\text{out}}^2(t) &= (1 - c_{\text{skip}}(t) \alpha_t)^2 \sigma_d^2 + c_{\text{skip}}^2(t) \sigma_t^2, \end{aligned} \quad (\text{D.6.3})$$

其中数据已中心化 ($\mathbb{E}[\mathbf{x}_0] = \mathbf{0}$).

最小化从 $\mathbf{F}_\phi$ 到 $\mathbf{x}_\phi$ 的误差放大. EDM 旨在减轻网络学习误差从 $\mathbf{F}_\phi$ 到 $\mathbf{x}_\phi$ 的放大. 通过选择使 c_{out} 最小的 c_{skip} 来实现:

$$c_{\text{skip}}^* \in \arg \min_{c_{\text{skip}}} c_{\text{out}}^2.$$

采用标准方法, 求解 $\frac{\partial c_{\text{out}}}{\partial c_{\text{skip}}} = 0$ 得到驻点 c_{skip}^* , 有

$$c_{\text{skip}}^*(t) = \frac{\alpha_t \sigma_d^2}{\alpha_t^2 \sigma_d^2 + \sigma_t^2}.$$

将其代入 式 (D.6.3), 最优值为

$$c_{\text{out}}^*(t) = \pm \frac{\sigma_t \sigma_d}{\sqrt{\alpha_t^2 \sigma_d^2 + \sigma_t^2}}.$$

按照惯例, 输出尺度取非负分支:

$$c_{\text{out}}^*(t) = \frac{\sigma_t \sigma_d}{\sqrt{\alpha_t^2 \sigma_d^2 + \sigma_t^2}} \quad (\geq 0),$$

这保证了 $c_{\text{out}}(0) = 0$, 且当 σ_t 足够大时 $c_{\text{out}}(t) \rightarrow \sigma_d$, 得到直观的极限 $\mathbf{x}_\phi(\mathbf{x}_t, 0) \approx \mathbf{x}_t$ 与 $\mathbf{x}_\phi(\mathbf{x}_t, t) \approx \sigma_d \mathbf{F}_\phi(\cdot)$.

将这些系数总结如下:

记 $R_t := \alpha_t^2 \sigma_d^2 + \sigma_t^2$, 有如下选择:

$$c_{\text{in}}(t) = \frac{1}{\sqrt{R_t}}, \quad c_{\text{skip}}(t) = \frac{\alpha_t \sigma_d^2}{R_t}, \quad c_{\text{out}}(t) = \frac{\sigma_t \sigma_d}{\sqrt{R_t}}. \quad (\text{D.6.4})$$

利用式 (D.6.4), 回归目标 $\mathbf{x}_{\text{tgt}}(t)$ 简化为

$$\mathbf{x}_{\text{tgt}}(t) = \frac{1}{\sigma_d} \frac{\sigma_t \mathbf{x}_0 - \alpha_t \sigma_d^2 \boldsymbol{\epsilon}}{\sqrt{R_t}}.$$

此外, 将这些表达式代入式 (D.6.1) 和式 (D.6.2), 可同时简化参数化与损失函数, 得到:

$$\mathbf{x}_\phi(\mathbf{x}, t) = \frac{\alpha_t \sigma_d^2}{R_t} \mathbf{x} + \frac{\sigma_t \sigma_d}{\sqrt{R_t}} \mathbf{F}_\phi \left(\frac{1}{\sqrt{R_t}} \mathbf{x}, c_{\text{noise}}(t) \right),$$

以及

$$\mathbb{E}_{\mathbf{x}_0, \boldsymbol{\epsilon}, t} \left[\omega(t) \frac{\sigma_t^2}{R_t} \left\| \sigma_d \mathbf{F}_\phi \left(\frac{1}{\sqrt{R_t}} \mathbf{x}_t, c_{\text{noise}}(t) \right) - \left(\frac{\sigma_t \mathbf{x}_0 - \alpha_t \sigma_d^2 \boldsymbol{\epsilon}}{\sqrt{R_t}} \right) \right\|_2^2 \right].$$

采用这一参数化, 并在条件 $\alpha_0 \approx 1$ 和 $\sigma_0 \approx 0$ 下, 有

$$c_{\text{skip}}(0) \approx 1 \quad \text{且} \quad c_{\text{out}}(0) \approx 0.$$

$c_{\text{noise}}(t)$ 的选择. 它为 $\mathbf{F}_\phi$ 提供噪声水平嵌入; 噪声水平 σ_t 的任何一一映射 (例如 $c_{\text{noise}}(t) = \log \sigma_t$) 均适用.

D.6.2 常见的 EDM 特例: $\alpha_t = 1, \sigma_t = t$

考虑 EDM 使用的简化噪声调度, 其中 $\alpha_t = 1, \sigma_t = t$; 节 11.4 关于 CTM 的讨论也采用了此调度. 在这一设定下, 前向过程变为

$$\mathbf{x}_t = \mathbf{x}_0 + t\boldsymbol{\epsilon}, \quad \text{其中 } \mathbf{x}_0 \sim p_{\text{data}}, \quad \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}),$$

对应于扰动核

$$p_t(\mathbf{x}_t | \mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t; \mathbf{x}_0, t^2 \mathbf{I}).$$

相应地, 终止时刻的先验分布设为

$$p_{\text{prior}}(\mathbf{x}_T) := \mathcal{N}(\mathbf{x}_T; \mathbf{0}, T^2 \mathbf{I}).$$

扰动核诱导的边缘密度由如下卷积给出:

$$p_t(\mathbf{x}) = \int \mathcal{N}(\cdot; \mathbf{0}, t^2 \mathbf{I}) p_{\text{data}}(\mathbf{x}_0) d\mathbf{x}_0.$$

在这一设定下, 基于 $\mathbf{x}$ 预测 $\mathbf{x}_{\phi^\times}$ 的 PF-ODE (见式 (6.3.2)) 简化为

$$\frac{d\mathbf{x}(t)}{dt} = \frac{\mathbf{x}(t) - \mathbf{x}_{\phi^\times}(\mathbf{x}(t), t)}{t}.$$

将这一形式代入式 (D.6.4), 神经网络参数化系数变为

$$c_{\text{in}}(t) = \frac{1}{\sqrt{\sigma_d^2 + t^2}}, \quad c_{\text{skip}}(t) = \frac{\sigma_d^2}{\sigma_d^2 + t^2}, \quad c_{\text{out}}(t) = \pm \frac{t\sigma_d}{\sqrt{\sigma_d^2 + t^2}}. \quad (\text{D.6.5})$$

由这些表达式可见:

- 当 $t \approx 0$ 时，噪声水平可忽略，因此 $c_{\text{skip}} \approx 1$, $c_{\text{out}} \approx 0$. 在这一极限下，跳跃路径占主导，网络基本上直接传递其输入：

$$\mathbf{x}_\phi(\mathbf{x}, t) \approx \mathbf{x}.$$

- 当 $t \gg 0$ 时，输入受到严重的噪声扰动，因此 $c_{\text{skip}} \approx 0$, $c_{\text{out}} \approx \sigma_d$. 此时跳跃路径消失，模型输出完全由学得残差决定：

$$\mathbf{x}_\phi(\mathbf{x}, t) \approx \sigma_d \mathbf{F}_\phi(c_{\text{in}}(t)\mathbf{x}, c_{\text{noise}}(t)),$$

这意味着网络 $\mathbf{F}_\phi$ 从归一化的带噪输入中预测干净信号的缩放替代量；因此，在高噪声水平下，模型输出完全由学得的去噪函数决定。

总之，这一参数化在 t 较小时的恒等映射与 t 较大时作用于标准化输入的缩放残差预测器之间平滑插值。

参考文献

- Ackley, D. H., G. E. Hinton, and T. J. Sejnowski (1985). “A learning algorithm for Boltzmann machines”. In: *Cognitive science* 9.1, pp. 147–169.
- Albergo, M. S., N. M. Boffi, and E. Vanden-Eijnden (2023). “Stochastic interpolants: A unifying framework for flows and diffusions”. In: *arXiv preprint arXiv:2303.08797*.
- Albergo, M. S. and E. Vanden-Eijnden (2023). “Building Normalizing Flows with Stochastic Interpolants”. In: *The Eleventh International Conference on Learning Representations*.
- Altschuler, J., J. Niles-Weed, and P. Rigollet (2017). “Near-linear time approximation algorithms for optimal transport via Sinkhorn iteration”. In: *Advances in neural information processing systems* 30.
- Anderson, B. D. (1982). “Reverse-time diffusion equation models”. In: *Stochastic Processes and their Applications* 12.3, pp. 313–326.
- Atkinson, K., W. Han, and D. E. Stewart (2009). *Numerical solution of ordinary differential equations*. Vol. 81. John Wiley & Sons.
- Bansal, A., H.-M. Chu, A. Schwarzschild, S. Sengupta, M. Goldblum, J. Geiping, and T. Goldstein (2023). “Universal guidance for diffusion models”. In: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 843–852.
- Behrmann, J., W. Grathwohl, R. T. Chen, D. Duvenaud, and J.-H. Jacobsen (2019). “Invertible residual networks”. In: *International conference on machine learning*. PMLR, pp. 573–582.
- Benamou, J.-D. and Y. Brenier (2000). “A computational fluid mechanics solution to the Monge-Kantorovich mass transfer problem”. In: *Numerische Mathematik* 84.3, pp. 375–393.
- Boffi, N. M., M. S. Albergo, and E. Vanden-Eijnden (2024). “Flow Map Matching”. In: *arXiv preprint arXiv:2406.07507*.
- Bradley, R. A. and M. E. Terry (1952). “Rank analysis of incomplete block designs: I. the method of paired comparisons”. In: *Biometrika* 39.3/4, pp. 324–345.

- Caluya, K. F. and A. Halder (2021). “Wasserstein proximal algorithms for the Schrödinger bridge problem: Density control with nonlinear drift”. In: *IEEE Transactions on Automatic Control* 67.3, pp. 1163–1178.
- Chen, R. T., J. Behrmann, D. K. Duvenaud, and J.-H. Jacobsen (2019). “Residual flows for invertible generative modeling”. In: *Advances in Neural Information Processing Systems* 32.
- Chen, R. T., Y. Rubanova, J. Bettencourt, and D. K. Duvenaud (2018). “Neural ordinary differential equations”. In: *Advances in neural information processing systems* 31.
- Chen, T., G.-H. Liu, and E. Theodorou (2022). “Likelihood Training of Schrödinger Bridge using Forward-Backward SDEs Theory”. In: *International Conference on Learning Representations*.
- Chen, Y., T. T. Georgiou, and M. Pavon (2016). “On the relation between optimal transport and Schrödinger bridges: A stochastic control viewpoint”. In: *Journal of Optimization Theory and Applications* 169, pp. 671–691.
- (2021). “Stochastic control liaisons: Richard sinkhorn meets gaspard monge on a schrodinger bridge”. In: *Siam Review* 63.2, pp. 249–313.
- Choi, J., S. Kim, Y. Jeong, Y. Gwon, and S. Yoon (2021). “ILVR: Conditioning Method for Denoising Diffusion Probabilistic Models”. In: *2021 IEEE/CVF International Conference on Computer Vision (ICCV)*. IEEE, pp. 14347–14356.
- Chung, H., J. Kim, M. T. Mccann, M. L. Klasky, and J. C. Ye (2022). “Diffusion posterior sampling for general noisy inverse problems”. In: *arXiv preprint arXiv:2209.14687*.
- Chung, H., J. Kim, M. T. Mccann, M. L. Klasky, and J. C. Ye (2023). “Diffusion Posterior Sampling for General Noisy Inverse Problems”. In: *The Eleventh International Conference on Learning Representations*. URL: <https://openreview.net/forum?id=0nD9zGAGT0k>.
- Csiszár, I. (1963). “Eine informationstheoretische Ungleichung und ihre Anwendung auf den Beweis der Ergodizität von Markoffschen Ketten”. In: *A Magyar Tudományos Akadémia Matematikai Kutató Intézetének Közleményei* 8.1-2, pp. 85–108.
- Cuturi, M. (2013). “Sinkhorn distances: Lightspeed computation of optimal transport”. In: *Advances in neural information processing systems* 26.
- Dai Pra, P. (1991). “A stochastic control approach to reciprocal diffusion processes”. In: *Applied mathematics and Optimization* 23.1, pp. 313–329.

- Daras, G., H. Chung, C.-H. Lai, Y. Mitsufuji, J. C. Ye, P. Milanfar, A. G. Dimakis, and M. Delbracio (2024). “A survey on diffusion models for inverse problems”. In: *arXiv preprint arXiv:2410.00083*.
- Daras, G., Y. Dagan, A. Dimakis, and C. Daskalakis (2023). “Consistent diffusion models: Mitigating sampling drift by learning to be consistent”. In: *Advances in Neural Information Processing Systems* 36, pp. 42038–42063.
- De Bortoli, V. (2022). “Convergence of denoising diffusion models under the manifold hypothesis”. In: *arXiv preprint arXiv:2208.05314*.
- De Bortoli, V., J. Thornton, J. Heng, and A. Doucet (2021). “Diffusion schrödinger bridge with applications to score-based generative modeling”. In: *Advances in Neural Information Processing Systems* 34, pp. 17695–17709.
- Dhariwal, P. and A. Nichol (2021). “Diffusion models beat gans on image synthesis”. In: *Advances in Neural Information Processing Systems* 34, pp. 8780–8794.
- Efron, B. (2011). “Tweedie’ s formula and selection bias”. In: *Journal of the American Statistical Association* 106.496, pp. 1602–1614.
- Esser, P., S. Kulal, A. Blattmann, R. Entezari, J. Müller, H. Saini, Y. Levi, D. Lorenz, A. Sauer, F. Boesel, et al. (2024). “Scaling rectified flow transformers for high-resolution image synthesis”. In: *Forty-first International Conference on Machine Learning*.
- Evans, L. C. (2010). *Partial differential equations*. Providence, R.I.: American Mathematical Society.
- Fournier, N. and A. Guillin (2015). “On the rate of convergence in Wasserstein distance of the empirical measure”. In: *Probability theory and related fields* 162.3, pp. 707–738.
- Frey, B. J., G. E. Hinton, and P. Dayan (1995). “Does the wake-sleep algorithm produce good density estimators?” In: *Advances in neural information processing systems* 8.
- Genevay, A., G. Peyré, and M. Cuturi (2018). “Learning generative models with sinkhorn divergences”. In: *International Conference on Artificial Intelligence and Statistics*. PMLR, pp. 1608–1617.
- Geng, Z., M. Deng, X. Bai, J. Z. Kolter, and K. He (2025a). “Mean flows for one-step generative modeling”. In: *arXiv preprint arXiv:2505.13447*.
- Geng, Z., A. Pokle, W. Luo, J. Lin, and J. Z. Kolter (2025b). “Consistency Models Made Easy”. In: *The Thirteenth International Conference on Learning Representations*. URL: <https://openreview.net/forum?id=xQVxo9dSID>.

- Geng, Z., A. Pokle, W. Luo, J. Lin, and J. Z. Kolter (2024). “Consistency models made easy”. In: *arXiv preprint arXiv:2406.14548*.
- Goodfellow, I., J. Pouget-Abadie, M. Mirza, B. Xu, D. Warde-Farley, S. Ozair, A. Courville, and Y. Bengio (2014). “Generative adversarial nets”. In: *Advances in neural information processing systems* 27.
- He, Y., N. Murata, C.-H. Lai, Y. Takida, T. Uesaka, D. Kim, W.-H. Liao, Y. Mitsufuji, J. Z. Kolter, R. Salakhutdinov, and S. Ermon (2024). “Manifold Preserving Guided Diffusion”. In: *The Twelfth International Conference on Learning Representations*. URL: <https://openreview.net/forum?id=o3Bx0Loxm1>.
- He, Y., N. Murata, C.-H. Lai, Y. Takida, T. Uesaka, D. Kim, W.-H. Liao, Y. Mitsufuji, J. Z. Kolter, R. Salakhutdinov, et al. (2023). “Manifold preserving guided diffusion”. In: *International Conference on Learning Representations*.
- Heitz, E., L. Belcour, and T. Chambon (2023). “Iterative α -(de) blending: A minimalist deterministic diffusion model”. In: *ACM SIGGRAPH 2023 Conference Proceedings*, pp. 1–8.
- Hertrich, J., A. Chambolle, and J. Delon (2025). “On the Relation between Rectified Flows and Optimal Transport”. In: *arXiv preprint arXiv:2505.19712*.
- Hinton, G. E. (2002). “Training products of experts by minimizing contrastive divergence”. In: *Neural computation* 14.8, pp. 1771–1800.
- Ho, J., A. Jain, and P. Abbeel (2020). “Denoising diffusion probabilistic models”. In: *Advances in Neural Information Processing Systems* 33, pp. 6840–6851.
- Ho, J. and T. Salimans (2021). “Classifier-Free Diffusion Guidance”. In: *NeurIPS 2021 Workshop on Deep Generative Models and Downstream Applications*.
- Hochbruck, M. and A. Ostermann (2005). “Explicit exponential Runge–Kutta methods for semilinear parabolic problems”. In: *SIAM Journal on Numerical Analysis* 43.3, pp. 1069–1090.
- (2010). “Exponential integrators”. In: *Acta Numerica* 19, pp. 209–286.
- Hu, Z., C.-H. Lai, Y. Mitsufuji, and S. Ermon (2025). “CMT: Mid-Training for Efficient Learning of Consistency, Mean Flow, and Flow Map Models”. In: *arXiv preprint arXiv:2509.24526*.
- Huang, C.-W., R. T. Chen, C. Tsirigotis, and A. Courville (2021). “Convex Potential Flows: Universal Probability Distributions with Optimal Transport and Convex Optimization”. In: *International Conference on Learning Representations*.

- Hutchinson, M. F. (1989). “A stochastic estimator of the trace of the influence matrix for Laplacian smoothing splines”. In: *Communications in Statistics-Simulation and Computation* 18.3, pp. 1059–1076.
- Hyvärinen, A. and P. Dayan (2005). “Estimation of non-normalized statistical models by score matching.” In: *Journal of Machine Learning Research* 6.4.
- Iserles, A. (2009). *A first course in the numerical analysis of differential equations*. 44. Cambridge university press.
- Karras, T., M. Aittala, T. Aila, and S. Laine (2022). “Elucidating the design space of diffusion-based generative models”. In: *Advances in Neural Information Processing Systems* 35, pp. 26565–26577.
- Karras, T., M. Aittala, J. Lehtinen, J. Hellsten, T. Aila, and S. Laine (2023). “Analyzing and improving the training dynamics of diffusion models”. In: *arXiv preprint arXiv:2312.02696*.
- (2024). “Analyzing and Improving the Training Dynamics of Diffusion Models”. In: *IEEE Conference on Computer Vision and Pattern Recognition*. IEEE, pp. 24174–24184.
- Kim, D., C.-H. Lai, W.-H. Liao, N. Murata, Y. Takida, T. Uesaka, Y. He, Y. Mitsufuji, and S. Ermon (2024a). “Consistency trajectory models: Learning probability flow ode trajectory of diffusion”. In: *International Conference on Learning Representations*.
- Kim, D., C.-H. Lai, W.-H. Liao, Y. Takida, N. Murata, T. Uesaka, Y. Mitsufuji, and S. Ermon (2024b). “PaGoDA: Progressive Growing of a One-Step Generator from a Low-Resolution Diffusion Teacher”. In: *arXiv preprint arXiv:2405.14822*.
- Kim, D., S. Shin, K. Song, W. Kang, and I.-C. Moon (2022). “Soft truncation: A universal training technique of score-based diffusion model for high precision score estimation”. In: *International Conference on Machine Learning*. PMLR, pp. 11201–11228.
- Kingma, D., T. Salimans, B. Poole, and J. Ho (2021). “Variational diffusion models”. In: *Advances in neural information processing systems* 34, pp. 21696–21707.
- Kingma, D. P. and R. Gao (2023). “Understanding Diffusion Objectives as the ELBO with Simple Data Augmentation”. In: *Thirty-seventh Conference on Neural Information Processing Systems*.
- Kingma, D. P. and M. Welling (2013). “Auto-encoding variational bayes”. In: *arXiv preprint arXiv:1312.6114*.

- Kloeden, P. E., E. Platen, P. E. Kloeden, and E. Platen (1992). *Stochastic differential equations*. Springer.
- Lai, C.-H., Y. Takida, N. Murata, T. Uesaka, Y. Mitsufuji, and S. Ermon (2023a). “FP-Diffusion: Improving score-based diffusion models by enforcing the underlying score fokker-planck equation”. In: *International Conference on Machine Learning*. PMLR, pp. 18365–18398.
- Lai, C.-H., Y. Takida, T. Uesaka, N. Murata, Y. Mitsufuji, and S. Ermon (2023b). “On the Equivalence of Consistency-Type Models: Consistency Models, Consistent Diffusion Models, and Fokker-Planck Regularization”. In: *arXiv preprint arXiv:2306.00367*.
- Larochelle, H. and I. Murray (2011). “The neural autoregressive distribution estimator”. In: *Proceedings of the fourteenth international conference on artificial intelligence and statistics*. JMLR Workshop and Conference Proceedings, pp. 29–37.
- Lavenant, H. and F. Santambrogio (2022). “The flow map of the fokker-planck equation does not provide optimal transport”. In: *Applied Mathematics Letters* 133, p. 108225.
- LeCun, Y., S. Chopra, R. Hadsell, M. Ranzato, F. Huang, et al. (2006). “A tutorial on energy-based learning”. In: *Predicting structured data 1.0*.
- Léonard, C. (2012). “From the Schrödinger problem to the Monge–Kantorovich problem”. In: *Journal of Functional Analysis* 262.4, pp. 1879–1920.
- (2014). “A survey of the Schrödinger problem and some of its connections with optimal transport”. In: *Discrete and Continuous Dynamical Systems-Series A* 34.4, pp. 1533–1574.
- Lipman, Y., R. T. Chen, H. Ben-Hamu, M. Nickel, and M. Le (2022). “Flow Matching for Generative Modeling”. In: *The Eleventh International Conference on Learning Representations*.
- Lipman, Y., M. Havasi, P. Holderrieth, N. Shaul, M. Le, B. Karrer, R. T. Chen, D. Lopez-Paz, H. Ben-Hamu, and I. Gat (2024). “Flow matching guide and code”. In: *arXiv preprint arXiv:2412.06264*.
- Liu, G.-H., A. Vahdat, D.-A. Huang, E. Theodorou, W. Nie, and A. Anandkumar (2023). “I2SB: Image-to-Image Schrödinger Bridge”. In: *International Conference on Machine Learning*. PMLR, pp. 22042–22062.
- Liu, Q. (2022). “Rectified flow: A marginal preserving approach to optimal transport”. In: *arXiv preprint arXiv:2209.14577*.

- Liu, X., C. Gong, et al. (2022). “Flow Straight and Fast: Learning to Generate and Transfer Data with Rectified Flow”. In: *The Eleventh International Conference on Learning Representations*.
- Lou, A., C. Meng, and S. Ermon (2024). “Discrete Diffusion Modeling by Estimating the Ratios of the Data Distribution”. In: *International Conference on Machine Learning*. PMLR, pp. 32819–32848.
- Lu, C. and Y. Song (2024). “Simplifying, stabilizing and scaling continuous-time consistency models”. In: *arXiv preprint arXiv:2410.11081*.
- Lu, C., K. Zheng, F. Bao, J. Chen, C. Li, and J. Zhu (2022a). “Maximum Likelihood Training for Score-based Diffusion ODEs by High Order Denoising Score Matching”. In: *International Conference on Machine Learning*. PMLR, pp. 14429–14460.
- Lu, C., Y. Zhou, F. Bao, J. Chen, C. Li, and J. Zhu (2022b). “Dpm-solver: A fast ode solver for diffusion probabilistic model sampling in around 10 steps”. In: *Advances in Neural Information Processing Systems* 35, pp. 5775–5787.
- (2022c). “Dpm-solver++: Fast solver for guided sampling of diffusion probabilistic models”. In: *arXiv preprint arXiv:2211.01095*.
- Luan, V. T. (2021). “Efficient exponential Runge–Kutta methods of high order: construction and implementation”. In: *BIT Numerical Mathematics* 61.2, pp. 535–560.
- Luhman, E. and T. Luhman (2021). “Knowledge distillation in iterative generative models for improved sampling speed”. In: *arXiv preprint arXiv:2101.02388*.
- Luo, W., T. Hu, S. Zhang, J. Sun, Z. Li, and Z. Zhang (2023). “Diff-instruct: A universal approach for transferring knowledge from pre-trained diffusion models”. In: *Advances in Neural Information Processing Systems* 36, pp. 76525–76546.
- Ma, N., M. Goldstein, M. S. Albergo, N. M. Boffi, E. Vanden-Eijnden, and S. Xie (2024). “Sit: Exploring flow and diffusion-based generative models with scalable interpolant transformers”. In: *European Conference on Computer Vision*. Springer, pp. 23–40.
- Maoutsa, D., S. Reich, and M. Opper (2020). “Interacting particle solutions of fokker–planck equations through gradient–log–density estimation”. In: *Entropy* 22.8, p. 802.
- Meng, C., K. Choi, J. Song, and S. Ermon (2022). “Concrete score matching: Generalized score matching for discrete data”. In: *Advances in Neural Information Processing Systems* 35, pp. 34532–34545.
- Meng, C., R. Rombach, R. Gao, D. Kingma, S. Ermon, J. Ho, and T. Salimans (2023). “On distillation of guided diffusion models”. In: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 14297–14306.

- Meng, C., Y. Song, W. Li, and S. Ermon (2021a). “Estimating high order gradients of the data distribution by denoising”. In: *Advances in Neural Information Processing Systems* 34, pp. 25359–25369.
- Meng, C., Y. Song, J. Song, J. Wu, J.-Y. Zhu, and S. Ermon (2021b). “Sdedit: Image synthesis and editing with stochastic differential equations”. In: *arXiv preprint arXiv:2108.01073*.
- Mikami, T. and M. Thieullen (2006). “Duality theorem for the stochastic optimal control problem”. In: *Stochastic processes and their applications* 116.12, pp. 1815–1835.
- Mikami, T. and M. Thieullen (2008). “Optimal transportation problem by stochastic optimal control”. In: *SIAM Journal on Control and Optimization* 47.3, pp. 1127–1139.
- Mokady, R., A. Hertz, K. Aberman, Y. Pritch, and D. Cohen-Or (2023). “Null-text inversion for editing real images using guided diffusion models”. In: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 6038–6047.
- Neklyudov, K., R. Brekelmans, D. Severo, and A. Makhzani (2023). “Action matching: Learning stochastic dynamics from samples”. In: *International Conference on Machine Learning*. PMLR, pp. 25858–25889.
- Nowozin, S., B. Cseke, and R. Tomioka (2016). “f-gan: Training generative neural samplers using variational divergence minimization”. In: *Advances in neural information processing systems* 29.
- Øksendal, B. (2003). “Stochastic differential equations”. In: *Stochastic differential equations*. Springer, pp. 65–84.
- Onken, D., S. W. Fung, X. Li, and L. Ruthotto (2021). “Ot-flow: Fast and accurate continuous normalizing flows via optimal transport”. In: *Proceedings of the AAAI Conference on Artificial Intelligence*. Vol. 35. 10, pp. 9223–9232.
- Pavon, M. and A. Wakolbinger (1991). “On free energy, stochastic control, and Schrödinger processes”. In: *Modeling, Estimation and Control of Systems with Uncertainty: Proceedings of a Conference held in Sopron, Hungary, September 1990*. Springer, pp. 334–348.
- Peters, J., K. Mulling, and Y. Altun (2010). “Relative entropy policy search”. In: *Proceedings of the AAAI Conference on Artificial Intelligence*. Vol. 24. 1, pp. 1607–1612.

- Peyré, G., M. Cuturi, et al. (2019). “Computational optimal transport: With applications to data science”. In: *Foundations and Trends® in Machine Learning* 11.5-6, pp. 355–607.
- Pontryagin, L. S. (2018). *Mathematical theory of optimal processes*. Routledge.
- Poole, B., A. Jain, J. T. Barron, and B. Mildenhall (2023). “DreamFusion: Text-to-3D using 2D Diffusion”. In: *The Eleventh International Conference on Learning Representations*.
- Pra, P. D. and M. Pavon (1990). “On the Markov processes of Schrödinger, the Feynman-Kac formula and stochastic control”. In: *Realization and Modelling in System Theory: Proceedings of the International Symposium MTNS-89, Volume I*. Springer, pp. 497–504.
- Radford, A., J. W. Kim, C. Hallacy, A. Ramesh, G. Goh, S. Agarwal, G. Sastry, A. Askell, P. Mishkin, J. Clark, et al. (2021). “Learning transferable visual models from natural language supervision”. In: *International conference on machine learning*. PMLR, pp. 8748–8763.
- Rafailov, R., A. Sharma, E. Mitchell, C. D. Manning, S. Ermon, and C. Finn (2023). “Direct preference optimization: Your language model is secretly a reward model”. In: *Advances in neural information processing systems* 36, pp. 53728–53741.
- Raissi, M. (2018). “Deep hidden physics models: Deep learning of nonlinear partial differential equations”. In: *Journal of Machine Learning Research* 19.25, pp. 1–24.
- Reid, W. (1971). *Ordinary Differential Equations*. Applied mathematics series. Wiley.
- Rezende, D. and S. Mohamed (2015). “Variational inference with normalizing flows”. In: *International conference on machine learning*. PMLR, pp. 1530–1538.
- Saharia, C., W. Chan, S. Saxena, L. Li, J. Whang, E. L. Denton, K. Ghasemipour, R. Gontijo Lopes, B. Karagol Ayan, T. Salimans, et al. (2022). “Photorealistic text-to-image diffusion models with deep language understanding”. In: *Advances in Neural Information Processing Systems* 35, pp. 36479–36494.
- Salimans, T. and J. Ho (2021). “Progressive Distillation for Fast Sampling of Diffusion Models”. In: *International Conference on Learning Representations*.
- Särkkä, S. and A. Solin (2019). *Applied stochastic differential equations*. Vol. 10. Cambridge University Press.
- Schulman, J., F. Wolski, P. Dhariwal, A. Radford, and O. Klimov (2017). “Proximal policy optimization algorithms”. In: *arXiv preprint arXiv:1707.06347*.

- Shih, A., S. Belkhale, S. Ermon, D. Sadigh, and N. Anari (2023). “Parallel Sampling of Diffusion Models”. In: *arXiv preprint arXiv:2305.16317*.
- Sinkhorn, R. (1964). “A relationship between arbitrary positive matrices and doubly stochastic matrices”. In: *The annals of mathematical statistics* 35.2, pp. 876–879.
- Sohl-Dickstein, J., E. Weiss, N. Maheswaranathan, and S. Ganguli (2015). “Deep unsupervised learning using nonequilibrium thermodynamics”. In: *International Conference on Machine Learning*. PMLR, pp. 2256–2265.
- Song, J., C. Meng, and S. Ermon (2020). “Denoising Diffusion Implicit Models”. In: *International Conference on Learning Representations*.
- Song, Y. and P. Dhariwal (2024). “Improved Techniques for Training Consistency Models”. In: *The Twelfth International Conference on Learning Representations*.
- Song, Y., P. Dhariwal, M. Chen, and I. Sutskever (2023). “Consistency models”. In: *arXiv preprint arXiv:2303.01469*.
- Song, Y., C. Durkan, I. Murray, and S. Ermon (2021). “Maximum likelihood training of score-based diffusion models”. In: *Advances in Neural Information Processing Systems* 34, pp. 1415–1428.
- Song, Y. and S. Ermon (2019). “Generative modeling by estimating gradients of the data distribution”. In: *Advances in Neural Information Processing Systems* 32.
- Song, Y., S. Garg, J. Shi, and S. Ermon (2020a). “Sliced score matching: A scalable approach to density and score estimation”. In: *Uncertainty in Artificial Intelligence*. PMLR, pp. 574–584.
- Song, Y., J. Sohl-Dickstein, D. P. Kingma, A. Kumar, S. Ermon, and B. Poole (2020b). “Score-Based Generative Modeling through Stochastic Differential Equations”. In: *International Conference on Learning Representations*.
- Su, X., J. Song, C. Meng, and S. Ermon (2022). “Dual diffusion implicit bridges for image-to-image translation”. In: *arXiv preprint arXiv:2203.08382*.
- Tabak, E. G. and E. Vanden-Eijnden (2010). “Density estimation by dual ascent of the log-likelihood”. In: *Commun. Math. Sci.* 8.1, pp. 217–233.
- Tong, A., K. FATRAS, N. Malkin, G. Huguet, Y. Zhang, J. Rector-Brooks, G. Wolf, and Y. Bengio (2024). “Improving and generalizing flow-based generative models with minibatch optimal transport”. In: *Transactions on Machine Learning Research*.
- Turner, C. V. (2013). “A family of nonparametric density estimation algorithms”. In: *Communications on Pure and Applied Mathematics* 66.2, pp. 145–164.

- Uria, B., M.-A. Côté, K. Gregor, I. Murray, and H. Larochelle (2016). “Neural autoregressive distribution estimation”. In: *Journal of Machine Learning Research* 17.205, pp. 1–37.
- Vahdat, A. and J. Kautz (2020). “NVAE: A deep hierarchical variational autoencoder”. In: *Advances in neural information processing systems* 33, pp. 19667–19679.
- Villani, C. et al. (2008). *Optimal transport: old and new*. Vol. 338. Springer.
- Vincent, P. (2011). “A connection between score matching and denoising autoencoders”. In: *Neural computation* 23.7, pp. 1661–1674.
- Wallace, B., M. Dang, R. Rafailov, L. Zhou, A. Lou, S. Purushwalkam, S. Ermon, C. Xiong, S. Joty, and N. Naik (2024). “Diffusion model alignment using direct preference optimization”. In: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 8228–8238.
- Wang, Z., C. Lu, Y. Wang, F. Bao, C. Li, H. Su, and J. Zhu (2023). “Prolificdreamer: High-fidelity and diverse text-to-3d generation with variational score distillation”. In: *Advances in Neural Information Processing Systems* 36, pp. 8406–8441.
- Xu, Y., M. Deng, X. Cheng, Y. Tian, Z. Liu, and T. S. Jaakkola (2023). “Restart Sampling for Improving Generative Processes”. In: *Thirty-seventh Conference on Neural Information Processing Systems*. URL: <https://openreview.net/forum?id=wFuemocyHZ>.
- Ye, H., H. Lin, J. Han, M. Xu, S. Liu, Y. Liang, J. Ma, J. Y. Zou, and S. Ermon (2024). “Tfg: Unified training-free guidance for diffusion models”. In: *Advances in Neural Information Processing Systems* 37, pp. 22370–22417.
- Yin, T., M. Gharbi, T. Park, R. Zhang, E. Shechtman, F. Durand, and B. Freeman (2024a). “Improved distribution matching distillation for fast image synthesis”. In: *Advances in neural information processing systems* 37, pp. 47455–47487.
- Yin, T., M. Gharbi, R. Zhang, E. Shechtman, F. Durand, W. T. Freeman, and T. Park (2024b). “One-Step Diffusion with Distribution Matching Distillation”. In: *2024 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. IEEE, pp. 6613–6623.
- Yu, J., Y. Wang, C. Zhao, B. Ghanem, and J. Zhang (2023). “Freedom: Training-free energy-guided conditional diffusion model”. In: *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pp. 23174–23184.

- Zhang, Q. and Y. Chen (2022). “Fast Sampling of Diffusion Models with Exponential Integrator”. In: *The Eleventh International Conference on Learning Representations*.
- Zheng, K., C. Lu, J. Chen, and J. Zhu (2023). “Dpm-solver-v3: Improved diffusion ode solver with empirical model statistics”. In: *Advances in Neural Information Processing Systems* 36, pp. 55502–55542.
- Zhou, M., H. Zheng, Z. Wang, M. Yin, and H. Huang (2024). “Score identity distillation: Exponentially fast distillation of pretrained diffusion models for one-step generation”. In: *Forty-first International Conference on Machine Learning*.

术语索引

中文术语	英文术语	页码
深度生成模型	deep generative model	2
Kullback–Leibler 散度	Kullback–Leibler divergence	4
得分函数	score function	5
得分匹配	score matching	5
变分自编码器	variational autoencoder	14
去噪扩散概率模型	denoising diffusion probabilistic model	14
证据下界	evidence lower bound	16
重参数化	reparameterization	26
能量模型	energy-based model	32
朗之万动力学	Langevin dynamics	32
去噪得分匹配	denoising score matching	42
噪声条件得分网络	noise-conditioned score network	52
随机微分方程	stochastic differential equation	58
布朗运动	Brownian motion	59
漂移	drift	60
概率流 ODE	probability flow ODE	63
Fokker–Planck 方程	Fokker–Planck equation	64
推前	pushforward	67
归一化流	normalizing flow	89
流匹配	flow matching	89
神经常微分方程	neural ODE	90
概率路径	probability path	96

中文术语	英文术语	页码
条件流匹配	conditional flow matching	100
最优输运	optimal transport	141
薛定谔桥	Schrödinger bridge	141
耦合	coupling	143
直接偏好优化	direct preference optimization	169
分类器引导	classifier guidance	170
基于人类反馈的强化学习	reinforcement learning from human feedback	173
无分类器引导	classifier-free guidance	176
蒸馏	distillation	247
渐进蒸馏	progressive distillation	248
变分得分蒸馏	variational score distillation	251
流映射	flow map	261
平均流	mean flow	264
一致性模型	consistency model	266
半群	semigroup	266