计算最优传输

Computational Optimal Transport

Gabriel Peyré　Marco Cuturi

CNRS and DMA, ENS　Google and CREST, ENSAE

arXiv v4 · now Publishers · 2019 / 2020

Codex 翻译及重排

Model: GPT-6 / GPT-6.1 sol

Updated: 2026-10-01

数译

mathtranslations.org

译者说明

本译稿以用户提供的 209 页 PDF（arXiv:1803.00567v4，2020 年 3 月 18 日）为内容依据，以对应版本的作者 TeX 文件恢复数学标记、编号与参考文献. 本译本包括摘要、全部十章、致谢、参考文献及术语索引. 原书中发现的数学和记号疑点按原文保留，校对记录随工程提供，未擅自订正. 彩色配图直接使用英文原书的原生图像，保留其颜色、图内标记及几何细节，图注译为中文. 纯数学网络与关系示意图用 `tikzcd` 排版. 原书刊载信息为 *Foundations and Trends in Machine Learning*，第 11 卷，第 5–6 期，355–607 页，2019 年. 所供 PDF 的摘要页仍含出版社的卷期和 DOI 占位符；本译稿不将其猜测补全.

目录

摘要 1

第 1 章 引言 2

第 2 章 理论基础 5

2.1 直方图与测度 . . . 5
2.2 指派与 Monge 问题 . . . 6
2.3 Kantorovich 松弛 . . . 10
2.4 最优传输的度量性质 . . . 13
2.5 对偶问题 . . . 18
2.6 特殊情形 . . . 23

第 3 章 算法基础 30

3.1 Kantorovich 线性规划 . . . 30
3.2 **C**-变换 . . . 32
3.3 互补松弛 . . . 33
3.4 运输多胞形的顶点 . . . 34
3.4.1 $\mathbf{U}(\mathbf{a},\mathbf{b})$ 所有顶点支撑的树结构 . . . 34
3.4.2 西北角法则 . . . 35
3.5 网络单纯形法的启发式描述 . . . 36
3.5.1 求取与 **P** 互补的对偶对 . . . 37
3.5.2 网络单纯形更新 . . . 38
3.5.3 原始解的改进 . . . 39
3.6 对偶上升方法 . . . 40
3.7 拍卖算法 . . . 43

第 4 章 最优传输的熵正则化 46

4.1 熵正则化 . . . 46
4.2 Sinkhorn 算法及其收敛性 . . . 51
4.3 加速 Sinkhorn 迭代 . . . 59
4.4 稳定性与对数域计算 . . . 61
4.5 最优传输代价的正则化近似 . . . 64
4.6 广义 Sinkhorn . . . 65

第 5 章 半离散最优传输 67

5.1 c-变换与 $\bar{c}$-变换 . . . 67
5.2 半离散表述 . . . 68
5.3 熵半离散表述 . . . 70
5.4 随机优化方法 . . . 72

第 6 章 $\mathcal{W}_1$ 最优传输 75

6.1 度量空间上的 $\mathcal{W}_1$ . . . 75

6.2 欧氏空间上的 $\mathcal{W}_1$ . . . 77
6.3 图上的 $\mathcal{W}_1$ . . . 77

第 7 章 动态表述 79
7.1 连续表述 . . . 79
7.2 均匀交错网格上的离散化 . . . 81
7.3 近端求解器 . . . 82
7.4 动态非平衡最优传输 . . . 84
7.5 更一般的迁移率泛函 . . . 85
7.6 路径空间上的动态表述 . . . 86

第 8 章 统计散度 88
8.1 φ-散度 . . . 88
8.2 积分概率度量 . . . 93
8.2.1 $\mathcal{W}_1$ 与平坦范数 . . . 93
8.2.2 对偶 RKHS 范数与最大均值差异 . . . 94
8.3 Wasserstein 空间并非 Hilbert 型 . . . 97
8.3.1 嵌入与失真 . . . 98
8.3.2 最优传输的负定与正定变体 . . . 99
8.4 最优传输、MMD 与 φ-散度的经验估计量 . . . 100
8.4.1 最优传输与 MMD 的经验估计量 . . . 100
8.4.2 φ-散度的经验估计量 . . . 101
8.5 熵正则化：最优传输与 MMD 之间 . . . 102

第 9 章 Wasserstein 变分问题 104
9.1 Wasserstein 损失的求导 . . . 104
9.1.1 Euler 型离散化 . . . 105
9.1.2 Lagrange 型离散化 . . . 106
9.1.3 自动微分 . . . 107
9.2 Wasserstein 重心、聚类与字典学习 . . . 108
9.3 梯度流 . . . 116
9.4 最小 Kantorovich 估计器 . . . 121

第 10 章 最优传输的扩展 124
10.1 多边缘问题 . . . 124
10.2 非平衡最优传输 . . . 126
10.3 对耦合施加额外约束的问题 . . . 129
10.4 切片 Wasserstein 距离与重心 . . . 129
10.5 向量与矩阵的传输 . . . 132
10.6 Gromov–Wasserstein 距离 . . . 133
10.6.1 Hausdorff 距离 . . . 134
10.6.2 Gromov–Hausdorff 距离 . . . 135
10.6.3 Gromov–Wasserstein 距离 . . . 136

10.6.4 熵正则化 137
参考文献 **140**
附录 A 术语索引 **174**

摘要

最优传输（optimal transport，OT）理论，可以借法国数学家 Gaspard Monge（1746–1818）的描述作非正式说明：一位手持铁锹的工人需要搬运建筑工地上的一大堆沙子. 她的目标是用全部沙子堆成具有指定形状的目标沙堆，例如一座巨大的沙堡. 自然地，她希望使总付出最小；例如，可以用搬运一铲铲沙子所经过的总距离或耗费的总时间来量化这种付出.

研究 OT 的数学家将这个问题表述为比较两个概率分布，也就是体积相同、形状不同的两个沙堆. 他们考虑把第一个沙堆变形、传输或重塑为第二个沙堆的所有可能方式，并依据把一粒沙子从一处移到另一处所需费用这一 “局部” 考虑，为每种传输方式赋予 “整体” 代价. 数学家关心代价最小的传输的性质，以及如何高效地计算它. 这一最小代价不仅定义了分布之间的距离，还使概率分布空间具有丰富的几何结构. 这种结构在如下意义上是典范的：它继承了这些分布所在的底层 “基础” 空间的重要几何性质. 例如，当底层空间是欧氏空间时，插值、重心、凸性和函数梯度等重要概念，自然地延伸到带有 OT 几何的分布空间.

OT 曾在许多背景下、以不同形式被发现或重新发现，因此拥有丰富的历史. Monge 的奠基工作源于一个工程问题；20 世纪 20 年代的 Tolstoi，以及 40 年代的 Hitchcock、Kantorovich 和 Koopmans，则确立了它对物流和经济学的重要性. Dantzig 于 1949 年在线性规划框架内数值求解了这一问题，使 OT 在优化领域获得了坚实基础. 到了 90 年代，分析学家，尤其是 Brenier，重新研究了 OT；同时，它也以推土机距离之名在计算机视觉领域受到广泛关注. 近年来，能够处理大规模问题的近似求解器不断涌现，OT 的传播又经历了一次变革. 因此，OT 越来越多地用于解决成像科学中的颜色或纹理处理、图形学中的形状操纵，以及机器学习中的回归、分类和生成建模等问题.

本文从数值方法的角度综述 OT，并介绍可用于指导新算法设计的 OT 理论性质. 我们特别关注近期涌现的一系列高效算法，它们推动了 OT 在数据科学中的应用. 对于短短几年内提出的众多 OT 推广，我们给予较大篇幅，并将其与源于统计推断、核方法和信息论的相关方法联系起来. 所有插图都可用配套网站[1]提供的代码复现. 该网站托管《计算最优传输》图书项目，还提供幻灯片和计算资源.

[1] https://optimaltransport.github.io/

Chapter 1

引言

最短路径原理指导着生活和科学中的大多数决策：当一件商品、一个人或一个信息比特位于某个给定位置，而需要被送至目标位置时，应当尽可能减少付出．在平面上，这通常通过沿直线移动来实现；在更复杂的度量空间中，则沿测地线移动．最优传输理论将这一直觉推广到如下情形：我们关注的不再是一次移动一个对象，而是把多个对象，或它们的连续分布，同时从一种配置移到另一种配置．正如学校教师能够体会的那样，在要求一群人抵达后形成给定目标配置的约束下，规划他们的运输，比安排单个人的运输复杂得多．的确，以群体或分布来思考，需要更深入的数学形式体系；Monge (1781) 的奠基工作首次触及了这一体系．然而，无论这一形式体系乍看起来多么复杂，这个问题都与我们的日常生活有深刻而具体的联系．无论运输的是人、商品还是信息，都很少只涉及一个对象．物流、生产计划和网络路由中的主要经济问题都涉及分布的移动，而这条线索贯穿了最优传输的所有奠基文献．事实上，Tolstoı (1930)、Hitchcock (1941) 和 Kantorovich (1942) 都受到实际问题的引导．直到后来，主要是在 20 世纪 80 年代以后，借助 Brenier (1991) 等人的工作，数学家才发现这一理论提供了丰饶的研究土壤，并与凸性、偏微分方程和统计学有深刻联系．千年之交，计算机科学、成像科学及更广泛的数据科学领域的研究者认识到，最优传输理论也为在另一种、更抽象的背景下研究分布提供了强有力的工具：比较他们手中以特征袋或描述子的形式提供的分布．

关于最优传输，已有多部参考著作，包括 Villani 的两部较近的专著（2003; 2009），Rachev and Rüschendorf 的著作（1998a; 1998b），以及更近的 Santambrogio (2015) 的著作．正如这些书所展示的，这一理论中更形式化、更抽象的概念，本身就值得用数百页篇幅讨论．如今，最优传输已逐步成为应用工具，例如 Galichon (2016) 最近所强调的经济学应用；我们因此尝试从计算的角度补充这一丰富文献，重点关注数据科学应用，尤其是成像科学和机器学习．从这个意义上说，我们与 Kolouri et al. (2017) 最近的综述具有相近的出发点，但希望覆盖更多内容．最终，我们的目标是概述支撑 OT 实际有效性的主要理论认识，并用更多篇幅解释如何将这些认识转化为快速计算方案．

第 2、3、4、9 和 10 章的主体，专门研究最优传输在概率向量或离散直方图空间上诱导的几何．面向基础较好的读者，我们在这些章节的浅灰色框中，也针对离散测度给出更一般的数学阐述．离散测度不仅由概率权重定义，还由这些权重所在的位置定义．这些位置通常取自连续度量空间，因此为随机现象的建模提供了第二个重要自由度．最后，第三层阐述也是技术性最强的一层，用深灰色框标出，讨论不必离散的任意测度；特别地，这些测度可以具有相对于某个基准测度的密度．这通常是大多数经典 OT 理论教材的默认背景，但对实际应用而言，它一般没有那么重要．第 5 至第 8 章讨论连续测度与离散测度之间的相互作用，因此面向数学兴趣更浓厚的读者．

在撰写本书时，计算最优传输仍是极为活跃的领域．因此，本综述还有许多主题没有涉及．以下不按特定顺序列举一些：分布鲁棒优化 (Shafieezadeh Abadeh et al.,

2015; Esfahani and Kuhn, 2018; Lee and Raginsky, 2018; GAO et al., 2018)，其中通过最小化与输入数据的 Wasserstein 距离不超过某个界的任意数据测度所能产生的最坏经验风险来估计参数；Langevin 蒙特卡洛采样算法在 Wasserstein 几何下的收敛性 (Dalalyan and Karagulyan, 2017; Dalalyan, 2017; Bernton, 2018)；以及在低维情形下，通过 Monge–Ampère 方程求解具有平方欧氏代价的 OT 的其他数值方法 (Froese and Oberman, 2011; Benamou et al., 2014; Sulman et al., 2011)，我们只在注 2.25 中简要提及这些方法.

记号

- $[\![n]\!]$：整数集合 $\{1,\dots,n\}$.
- $\mathbb{1}_{n,m}$：$\mathbb{R}^{n\times m}$ 中所有元素均为 1 的矩阵；$\mathbb{1}_n$：全一向量.
- $\mathbb{I}_n$：大小为 $n\times n$ 的单位矩阵.
- 对 $u\in\mathbb{R}^n$，$\mathrm{diag}(u)$ 是以 u 为对角线、其余元素为零的 $n\times n$ 矩阵.
- Σ_n：具有 n 个分箱的概率单纯形，即 $\mathbb{R}^n_+$ 中概率向量的集合.
- $(\mathbf{a},\mathbf{b})$：单纯形 $\Sigma_n\times\Sigma_m$ 中的直方图.
- (α,β)：分别定义在空间 $(\mathcal{X},\mathcal{Y})$ 上的测度.
- $\frac{\mathrm{d}\alpha}{\mathrm{d}\beta}$：测度 α 相对于 β 的相对密度.
- $\rho_\alpha=\frac{\mathrm{d}\alpha}{\mathrm{d}x}$：测度 α 相对于 Lebesgue 测度的密度.
- $(\alpha=\sum_i \mathbf{a}_i\delta_{x_i},\beta=\sum_j \mathbf{b}_j\delta_{y_j})$：支撑分别位于 $x_1,\dots,x_n\in\mathcal{X}$ 和 $y_1,\dots,y_m\in\mathcal{Y}$ 的离散测度.
- $c(x,y)$：基础代价；在 α,β 的支撑上计算，得到相应的两两代价矩阵 $\mathbf{C}_{i,j}=(c(x_i,y_j))_{i,j}$.
- π：α 与 β 之间的耦合测度，即对任意 $A\subset\mathcal{X}$，有 $\pi(A\times\mathcal{Y})=\alpha(A)$；对任意 $B\subset\mathcal{Y}$，有 $\pi(\mathcal{X}\times B)=\beta(B)$. 对离散测度，$\pi=\sum_{i,j}\mathbf{P}_{i,j}\delta_{(x_i,y_j)}$.
- $\mathcal{U}(\alpha,\beta)$：耦合测度的集合；对离散测度，记为 $\mathbf{U}(\mathbf{a},\mathbf{b})$.
- $\mathcal{R}(c)$：可容许的对偶势的集合；对离散测度，记为 $\mathbf{R}(\mathbf{C})$.
- $T:\mathcal{X}\to\mathcal{Y}$：Monge 映射，通常满足 $T_\sharp\alpha=\beta$.
- $(\alpha_t)_{t=0}^1$：动态测度，满足 $\alpha_{t=0}=\alpha_0$ 和 $\alpha_{t=1}=\alpha_1$.
- v：Benamou–Brenier 表述中的速度；$J=\alpha v$：动量.
- (f,g)：对偶势；对离散测度，$(\mathbf{f},\mathbf{g})$ 是对偶变量.

- $(\mathbf{u}, \mathbf{v}) \overset{\text{def.}}{=} (e^{\mathbf{f}/\varepsilon}, e^{\mathbf{g}/\varepsilon})$：Sinkhorn 缩放因子.
- $\mathbf{K} \overset{\text{def.}}{=} e^{-\mathbf{C}/\varepsilon}$：Sinkhorn 算法中的 Gibbs 核.
- s：$\mathcal{W}_1$ 型问题的流，即散度约束下优化问题中的流.
- $\mathrm{L}_{\mathbf{C}}(\mathbf{a}, \mathbf{b})$ 和 $\mathcal{L}_c(\alpha, \beta)$：代价分别为 $\mathbf{C}$（直方图）和 c（任意测度）的 OT 优化问题的最优值.
- $\mathrm{W}_p(\mathbf{a}, \mathbf{b})$ 和 $\mathcal{W}_p(\alpha, \beta)$：与基础距离矩阵 $\mathbf{D}$（直方图）和距离 d（任意测度）相应的 p-Wasserstein 距离.
- $\lambda \in \Sigma_S$：用于计算 S 个测度的重心的权重向量.
- $\langle \cdot, \cdot \rangle$：向量的通常欧氏内积；对大小相同的矩阵 A, B，$\langle A, B \rangle \overset{\text{def.}}{=} \mathrm{tr}(A^\top B)$ 是 Frobenius 内积.
- 对两个函数 $f : \mathcal{X} \to \mathbb{R}$、$g : \mathcal{Y} \to \mathbb{R}$，$f \oplus g(x, y) \overset{\text{def.}}{=} f(x) + g(y)$ 定义了函数 $f \oplus g : \mathcal{X} \times \mathcal{Y} \to \mathbb{R}$.
- 对两个向量 $\mathbf{f} \in \mathbb{R}^n$、$\mathbf{g} \in \mathbb{R}^m$，$\mathbf{f} \oplus \mathbf{g} \overset{\text{def.}}{=} \mathbf{f}\mathbb{1}_m^\top + \mathbb{1}_n \mathbf{g}^\top \in \mathbb{R}^{n \times m}$.
- $\alpha \otimes \beta$ 是 $\mathcal{X} \times \mathcal{Y}$ 上的乘积测度，即

$$\int_{\mathcal{X} \times \mathcal{Y}} g(x, y) \mathrm{d}(\alpha \otimes \beta)(x, y) \overset{\text{def.}}{=} \int_{\mathcal{X} \times \mathcal{Y}} g(x, y) \mathrm{d}\alpha(x) \mathrm{d}\beta(y).$$

- $\mathbf{a} \otimes \mathbf{b} \overset{\text{def.}}{=} \mathbf{a}\mathbf{b}^\top \in \mathbb{R}^{n \times m}$.
- 对 $(\mathbf{u}, \mathbf{v}) \in (\mathbb{R}^n)^2$，$\mathbf{u} \odot \mathbf{v} = (\mathbf{u}_i \mathbf{v}_i) \in \mathbb{R}^n$.

Chapter 2

理论基础

本章介绍最优传输的基础知识，首先引入概率向量 $(\mathbf{a}, \mathbf{b})$ 之间的最优匹配和耦合等相关概念，再逐步将这些计算推广到离散测度 (α, β) 之间的传输，最后讨论任意测度的一般情形. 初读时可以略过后面这些细微差别，只关注概率向量，即直方图之间的计算；这是实现第 3 和第 4 章所详述算法的唯一必要基础. 更有经验的读者则可以通过任意测度的表述，更深入地理解这一问题，并将其用于更复杂的问题，例如移动点云的位置，或处理从连续密度中采样点的统计问题.

2.1 直方图与测度

对概率单纯形中的任意元素 $\mathbf{a} \in \Sigma_n$，我们交替使用直方图（histogram）和概率向量（probability vector）这两个名称；概率单纯形（probability simplex）定义为

$$\Sigma_n \overset{\text{def.}}{=} \left\{ \mathbf{a} \in \mathbb{R}_+^n \ : \ \sum_{i=1}^n \mathbf{a}_i = 1 \right\}.$$

本综述的大部分内容，专门研究最优传输在这一单纯形上诱导的几何.

注 2.1 (离散测度)**.** 权重为 $\mathbf{a}$、位置为 $x_1, \ldots, x_n \in \mathcal{X}$ 的离散测度 (discrete measure) 写成

$$\alpha = \sum_{i=1}^n \mathbf{a}_i \delta_{x_i}, \tag{2.1}$$

其中 δ_x 是位置 x 处的 Dirac 测度；直观地说，它是无限集中于位置 x 的单位质量. 如果还满足 $\mathbf{a} \in \Sigma_n$，这一测度就是概率测度；更一般地，如果向量 $\mathbf{a}$ 的所有元素非负，它就是正测度. 为避免把不含质量的位置计入支撑而造成退化，在讨论离散测度时，我们假定 $\mathbf{a}$ 的所有元素均为正.

注 2.2 (一般测度)**.** OT 的一个便利之处是，它能在同一框架内处理离散测度、连续测度以及同时包含这两类成分的测度. 为此，我们使用空间 $\mathcal{X}$ 上的Radon 测度 (Radon measure) 集合 $\mathcal{M}(\mathcal{X})$. 这一集合的正式定义要求 $\mathcal{X}$ 配备一个距离，通常记为 d，因为我们只能通过对连续函数 $f \in \mathcal{C}(\mathcal{X})$ 作“测试”，即积分，来研究测度.

将 $f \in \mathcal{C}(\mathcal{X})$ 对离散测度 α 积分，就是计算如下和式：

$$\int_{\mathcal{X}} f(x) \mathrm{d}\alpha(x) = \sum_{i=1}^n \mathbf{a}_i f(x_i).$$

更一般的测度，例如 $\mathcal{X} = \mathbb{R}^d$（其中 $d \in \mathbb{N}^*$ 是维数）上的测度，可以具有相对于 Lebesgue 测度的密度 $\mathrm{d}\alpha(x) = \rho_\alpha(x)\mathrm{d}x$，通常记为 $\rho_\alpha = \frac{\mathrm{d}\alpha}{\mathrm{d}x}$；其含义是

$$\forall\, h \in \mathcal{C}(\mathbb{R}^d), \quad \int_{\mathbb{R}^d} h(x)\mathrm{d}\alpha(x) = \int_{\mathbb{R}^d} h(x)\rho_\alpha(x)\mathrm{d}x.$$

任意测度 $\alpha \in \mathcal{M}(\mathcal{X})$ 不必具有密度，也不必是 Dirac 测度之和；它的定义在于，可以将任意连续函数 $f \in \mathcal{C}(\mathcal{X})$ 对它积分，得到 $\int_{\mathcal{X}} f(x)\mathrm{d}\alpha(x) \in \mathbb{R}$. 如果 $\mathcal{X}$ 不紧，还应要求 f 具有紧支撑，或至少在无穷远处趋于 0. 因而，在某种意义上，测度比函数“不那么正则”，但比广义函数更正则；广义函数与光滑函数对偶. 例如，Dirac 测度的导数不是测度. 我们用 $\mathcal{M}_+(\mathcal{X})$ 表示 $\mathcal{X}$ 上所有正测度的集合，用 $\mathcal{M}_+^1(\mathcal{X})$ 表示概率测度的集合；这意味着任意 $\alpha \in \mathcal{M}_+^1(\mathcal{X})$ 为正，且 $\alpha(\mathcal{X}) = \int_{\mathcal{X}} \mathrm{d}\alpha = 1$. 图 2.1 展示了本文除直方图以外所考虑的各类测度.

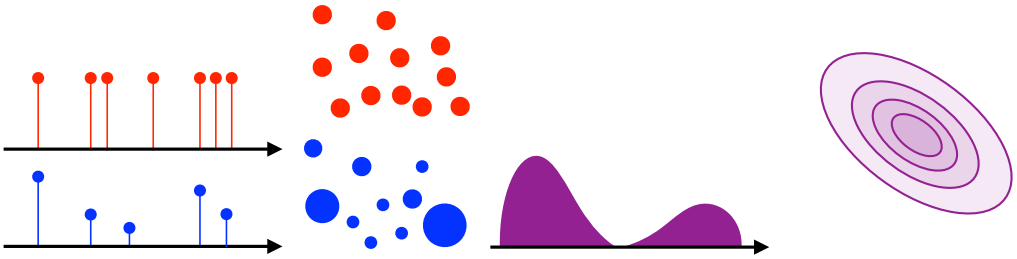

图 2.1: 一维和二维情形下，离散分布 $\alpha = \sum_{i=1}^n \mathbf{a}_i \delta_{x_i}$ 与密度 $\mathrm{d}\alpha(x) = \rho_\alpha(x)\mathrm{d}x$ 的示意图. 红色对应经验均匀分布 $\mathbf{a}_i = 1/n$，蓝色对应任意分布，紫色表示密度. 一维离散分布用针状图表示，针的长度等于 $\mathbf{a}_i$；二维离散分布用点云表示，此时圆点的半径可以等于 $\mathbf{a}_i$，也可以为获得更准确的视觉表达而令其面积等于 $\mathbf{a}_i$.

2.2 指派与 Monge 问题

给定代价矩阵 $(\mathbf{C}_{i,j})_{i\in[\![n]\!],j\in[\![m]\!]}$，假设 $n = m$，最优指派问题（optimal assignment problem）是在 n 个元素的排列集合 $\mathrm{Perm}(n)$ 中，寻找求解下式的双射 σ：

$$\min_{\sigma\in\mathrm{Perm}(n)} \frac{1}{n}\sum_{i=1}^n \mathbf{C}_{i,\sigma(i)}. \tag{2.2}$$

一种朴素办法是对 $\mathrm{Perm}(n)$ 中的所有排列计算上述代价. 然而，这一集合的大小为 $n!$；即使 n 很小，它也极其庞大. 例如，当 n 仅为 70 时，该集合就已包含超过 10^{100} 个元素 (Dantzig, 1983). 因此，只有存在能在排列集合上高效优化这一代价函数的算法，才能求解这个问题；第 3.7 节将讨论这一主题.

注 2.3 (唯一性). 最优指派问题可能具有多个最优解. 例如，设 $n = m = 2$，且矩阵 $\mathbf{C}$ 是边长为 1 的二维正方形四个顶点之间的两两距离矩阵，如图 2.2 左图所示. 此时只有两种指派，而它们都是最优的.

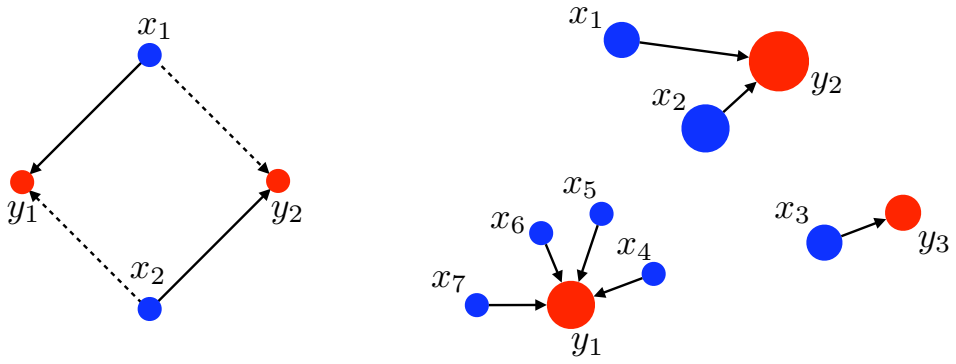

图 2.2: 左：来自测度 α 的蓝点与来自测度 β 的红点两两等距. 因而匹配 $\sigma = (1, 2)$（实线）和 $\sigma = (2, 1)$（虚线）都是最优的. 右：Monge 映射可以把蓝色测度 α 关联到红色测度 β. 各位置圆盘的面积与权重 α_i 成比例. 此处映射满足 $T(x_1) = T(x_2) = y_2$、$T(x_3) = y_3$，而对 $4 \leq i \leq 7$，有 $T(x_i) = y_1$.

注 2.4 (离散测度之间的 Monge 问题). 对离散测度

$$\alpha = \sum_{i=1}^{n} \mathbf{a}_i \delta_{x_i} \quad \text{且} \quad \beta = \sum_{j=1}^{m} \mathbf{b}_j \delta_{y_j}, \tag{2.3}$$

Monge 问题 (1781) 寻找一个映射，使每个点 x_i 只对应一个点 y_j，并将 α 的质量推送为 β 的质量. 即映射 $T : \{x_1, \ldots, x_n\} \to \{y_1, \ldots, y_m\}$ 必须满足

$$\forall\, j \in [\![m]\!], \quad \mathbf{b}_j = \sum_{i : T(x_i) = y_j} \mathbf{a}_i, \tag{2.4}$$

我们将其简记为 $T_\sharp \alpha = \beta$. 由于 $\mathbf{b}$ 的所有元素均为正，该映射必为满射. 这一映射应使某个传输代价最小；代价由定义在 $(x, y) \in \mathcal{X} \times \mathcal{Y}$ 上的函数 $c(x, y)$ 参数化：

$$\min_{T} \left\{ \sum_i c(x_i, T(x_i)) \;:\; T_\sharp \alpha = \beta \right\}. \tag{2.5}$$

当然，假设所有 x 互异、所有 y 也互异，这种离散点之间的映射可以用指标映射 $\sigma : [\![n]\!] \to [\![m]\!]$ 编码，使 $j = \sigma(i)$；质量守恒写成

$$\sum_{i \in \sigma^{-1}(j)} \mathbf{a}_i = \mathbf{b}_j,$$

其中 $\sigma^{-1}(j)$ 应理解为 j 的原像集合. 在 $n = m$ 且所有权重均匀，即 $\mathbf{a}_i = \mathbf{b}_j = 1/n$ 的特殊情形下，质量守恒约束意味着 T 为双射，满足 $T(x_i) = y_{\sigma(i)}$，而 Monge 问题等价于最优匹配问题 (2.2)，其代价矩阵为

$$\mathbf{C}_{i,j} \overset{\text{def.}}{=} c(x_i, y_j).$$

当 $n \neq m$ 时，即使暂且不考虑最优性，两个离散测度之间也可能根本不存在 Monge 映射. 当它们的权重向量不相容时，就会出现这种情况；特别地，当目标测度的点比源测度更多，即 $n < m$ 时，总是如此. 例如，图 2.2 右图给出了 α 到 β 的一个最优 Monge 映射，但 β 到 α 不存在 Monge 映射.

注 2.5 (推前算子)**.** 对连续映射 $T : \mathcal{X} \to \mathcal{Y}$，我们定义相应的推前算子 (push-forward operator) $T_\sharp : \mathcal{M}(\mathcal{X}) \to \mathcal{M}(\mathcal{Y})$. 对离散测度 (2.1)，推前运算仅仅是移动测度支撑中所有点的位置：

$$T_\sharp \alpha \overset{\text{def.}}{=} \sum_i \mathbf{a}_i \delta_{T(x_i)}.$$

对于更一般的测度，例如具有密度的测度，推前概念在描述概率测度的空间变化或传输时起着根本作用. 正式定义如下.

定义 2.1 (推前)**.** 对 $T : \mathcal{X} \to \mathcal{Y}$，测度 $\alpha \in \mathcal{M}(\mathcal{X})$ 的推前测度 $\beta = T_\sharp \alpha \in \mathcal{M}(\mathcal{Y})$ 满足

$$\forall\, h \in \mathcal{C}(\mathcal{Y}), \quad \int_{\mathcal{Y}} h(y) \mathrm{d}\beta(y) = \int_{\mathcal{X}} h(T(x)) \mathrm{d}\alpha(x). \tag{2.6}$$

等价地，对任意可测集 $B \subset \mathcal{Y}$，有

$$\beta(B) = \alpha\big(\{x \in \mathcal{X} \,:\, T(x) \in B\}\big) = \alpha\big(T^{-1}(B)\big). \tag{2.7}$$

注意，$T_\sharp$ 保持正性与总质量，因此若 $\alpha \in \mathcal{M}_+^1(\mathcal{X})$，则 $T_\sharp \alpha \in \mathcal{M}_+^1(\mathcal{Y})$.

直观地说，可测映射 $T : \mathcal{X} \to \mathcal{Y}$ 可以理解为把一个点从某个可测空间移到另一个可测空间的函数. $T_\sharp$ 是 T 的延伸，它能够将 $\mathcal{X}$ 上的整个概率测度移动为 $\mathcal{Y}$ 上的一个新概率测度. 算子 $T_\sharp$ 对 $\mathcal{X}$ 上测度 α 的每份基本质量应用映射 T，从而将其推前为 $\mathcal{Y}$ 中的一份基本质量. 注意，推前算子 $T_\sharp : \mathcal{M}_+^1(\mathcal{X}) \to \mathcal{M}_+^1(\mathcal{Y})$ 是线性的，其含义是：对 $\mathcal{X}$ 上两个测度 α_1, α_2，有 $T_\sharp(\alpha_1 + \alpha_2) = T_\sharp \alpha_1 + T_\sharp \alpha_2$.

注 2.6 (多元密度的推前)**.** 对 $\mathbb{R}^d$ 上具有密度 $(\rho_\alpha, \rho_\beta)$ 的测度，在公式 (2.6) 中显式作变量替换，假设 T 光滑且为双射，就会看出：推前在密度上的作用是线性的，表现为积分公式中的变量替换. 事实上，有

$$\rho_\alpha(x) = |\det(T'(x))| \rho_\beta(T(x)), \tag{2.8}$$

其中 $T'(x) \in \mathbb{R}^{d \times d}$ 是 T 的 Jacobian 矩阵，即由 T 的每个坐标的梯度组成的矩阵. 这意味着

$$|\det(T'(x))| = \frac{\rho_\alpha(x)}{\rho_\beta(T(x))}.$$

注 2.7 (任意测度之间的 Monge 问题). Monge 问题 (2.5) 可以推广到任意概率测度的情形：分别支撑在空间 $(\mathcal{X},\mathcal{Y})$ 上的两个任意概率测度 (α,β)，可以通过一个使下式最小的映射 $T:\mathcal{X}\to\mathcal{Y}$ 联系起来：

$$\min_{T}\left\{\int_{\mathcal{X}} c(x,T(x))\mathrm{d}\alpha(x)\ :\ T_\sharp\alpha=\beta\right\}. \tag{2.9}$$

约束 $T_\sharp\alpha=\beta$ 表示，T 利用注 2.5 中定义的推前算子，将 α 的质量推前为 β 的质量.

注 2.8 (推前与拉回). 测度的推前 $T_\sharp$ 不应与函数的拉回 (pull-back) $T^\sharp:\mathcal{C}(\mathcal{Y})\to\mathcal{C}(\mathcal{X})$ 混淆. 后者对应函数间的“变形”，定义为把 $g\in\mathcal{C}(\mathcal{Y})$ 变为 $T^\sharp g=g\circ T$ 的线性映射. 实际上，推前与拉回互为伴随，其含义是

$$\forall(\alpha,g)\in\mathcal{M}(\mathcal{X})\times\mathcal{C}(\mathcal{Y}),\quad \int_{\mathcal{Y}} g\mathrm{d}(T_\sharp\alpha)=\int_{\mathcal{X}}(T^\sharp g)\mathrm{d}\alpha.$$

注意，即使 (α,β) 相对于某个固定测度，例如 $\mathbb{R}^d$ 上的 Lebesgue 测度，具有密度 (ρ_α,ρ_β)，$T_\sharp\alpha$ 的密度也不是 $T^\sharp\rho_\beta$，因为式 (2.8) 中存在 Jacobian 因子. 这解释了为何使用 OT 进行图像配准时应当谨慎：它并不以图像变形方法的方式起作用. 图 2.3 说明了推前算子与拉回算子的差别.

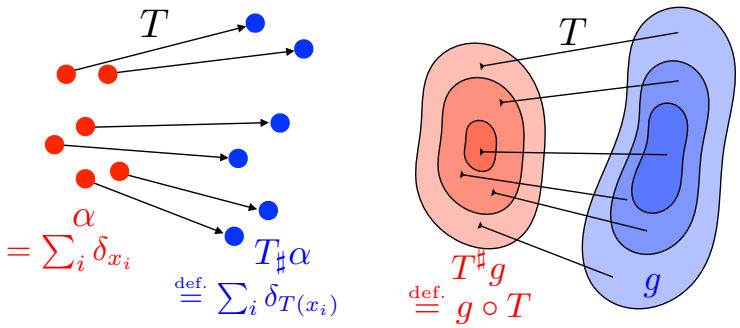

测度的推前　　函数的拉回

图 2.3: 推前算子 $T_\sharp$ 与拉回算子 $T^\sharp$ 的比较. 前者可以接受任意测度作为输入；后者作用于函数，特别是密度函数.

注 2.9 (测度与随机变量). Radon 测度也可以看作随机变量的分布. $\mathcal{X}$ 上的随机变量 X 实际上是从某个抽象的、往往不具体说明的概率空间 $(\Omega,\mathbb{P})$ 到 $\mathcal{X}$ 的映射 $X:\Omega\to\mathcal{X}$；其分布 α 是满足 $\mathbb{P}(X\in A)=\alpha(A)=\int_A\mathrm{d}\alpha(x)$ 的 Radon 测度 $\alpha\in\mathcal{M}_+^1(\mathcal{X})$. 等价地，它是 $\mathbb{P}$ 经 X 的推前，即 $\alpha=X_\sharp\mathbb{P}$. 依照式 (2.6)，对 $T:\mathcal{X}\to\mathcal{Y}$ 再作一次推前 $\beta=T_\sharp\alpha$，等价于定义另一个随机变量 $Y=T(X):\omega\in\Omega\to T(X(\omega))\in Y$，于是 β 是 Y 的分布. 因此，从 Y 抽取随机样本 y，只需先从 X 抽取 x，再计算

$y = T(x)$.

2.3 Kantorovich 松弛

指派问题及其在注 2.4 所述 Monge 问题中的推广，并不总适合研究实际问题中的离散测度. 事实上，指派问题被表述为排列问题，因此只能比较大小相同的均匀直方图. 利用 Monge 的推前映射形式体系，可以直接推广到具有非均匀权重的离散测度；但如果不存在满足质量守恒约束 (2.4) 的可行解，这种表述也可能退化，见注 2.4 末尾. 此外，指派问题 (2.5) 是组合问题；Monge 问题 (2.9) 的可行集，虽然作为满足质量守恒约束的全部推前测度的集合而被连续参数化，却是非凸的. 因此，直接从原始表述入手，两者都难以求解.

Kantorovich (1942) 的关键思想，是放松传输的确定性，也就是源点 x_i 只能被指派给另一个点或位置 y_{σ_i} 或 $T(x_i)$ 的要求. Kantorovich 提出，任意点 x_i 处的质量都可以分送到多个位置. 他不再要求质量传输是确定性的，而是考虑概率性传输；这种传输允许源点的质量分送给多个目标，即现在通常所说的质量分裂（mass splitting）. 这种灵活性用耦合矩阵（coupling matrix）$\mathbf{P} \in \mathbb{R}_+^{n\times m}$ 编码，以取代排列 σ 或映射 T. 其中 $\mathbf{P}_{i,j}$ 表示从分箱 i 流向分箱 j 的质量；在离散测度 (2.3) 的形式体系中，它表示从 x_i 流向 y_j 的质量. 可容许耦合的刻画比 Monge 映射简单得多：

$$\mathbf{U}(\mathbf{a},\mathbf{b}) \overset{\text{def.}}{=} \left\{\mathbf{P} \in \mathbb{R}_+^{n\times m} \;:\; \mathbf{P}\mathbb{1}_m = \mathbf{a} \quad \text{且} \quad \mathbf{P}^{\mathrm{T}}\mathbb{1}_n = \mathbf{b}\right\}, \tag{2.10}$$

这里采用如下矩阵与向量记号：

$$\mathbf{P}\mathbb{1}_m = \left(\sum_j \mathbf{P}_{i,j}\right)_i \in \mathbb{R}^n \quad \text{且} \quad \mathbf{P}^{\mathrm{T}}\mathbb{1}_n = \left(\sum_i \mathbf{P}_{i,j}\right)_j \in \mathbb{R}^m.$$

矩阵集合 $\mathbf{U}(\mathbf{a},\mathbf{b})$ 有界，且由 $n+m$ 个等式约束定义，因此是凸多胞体，即有限个矩阵的凸包 (Brualdi, 2006, 第 8.1 节).

此外，Monge 表述在本质上是不对称的，如图 2.2 右图所示；而 Kantorovich 的松弛表述始终对称，其含义是：耦合 $\mathbf{P}$ 属于 $\mathbf{U}(\mathbf{a},\mathbf{b})$，当且仅当 $\mathbf{P}^{\mathrm{T}}$ 属于 $\mathbf{U}(\mathbf{b},\mathbf{a})$. Kantorovich 的最优传输问题写成

$$\mathrm{L}_{\mathbf{C}}(\mathbf{a},\mathbf{b}) \overset{\text{def.}}{=} \min_{\mathbf{P}\in\mathbf{U}(\mathbf{a},\mathbf{b})} \langle \mathbf{C}, \mathbf{P}\rangle \overset{\text{def.}}{=} \sum_{i,j} \mathbf{C}_{i,j}\mathbf{P}_{i,j}. \tag{2.11}$$

这是一个线性规划，见第 3 章；与这类规划通常的情形相同，最优解不一定唯一.

注 2.10 (矿山与工厂)**.** 下面的资源分配问题为 Kantorovich 问题提供了很自然的解释，亦见 Hitchcock (1941). 假设某经营者管理 n 座仓库和 m 家工厂. 每座仓库储存一种工厂正常运转所需的贵重原材料. 更具体地说，每座仓库用整数 i 编号，储存 $\mathbf{a}_i$ 单位原材料. 这些原材料必须全部运往工厂，而工厂 j 需要指定数量 $\mathbf{b}_j$ 才能正常运转. 要把资源从仓库 i 运到工厂 j，经营者可以使用一家运输公司；该公司从位置 i 向位置 j 运送一单位资源，收取 $\mathbf{C}_{i,j}$ 的费用. 假设这家公司垄断货物运输，并对所有经济参与者采用相同的线性定价：从 i 向 j 运送 a 单位资源的费用为 $a \times \mathbf{C}_{i,j}$.

面对这一问题，经营者选择求解式 (2.11) 所述线性规划，得到传输方案 $\mathbf{P}^\star$，为每一对 i,j 确定从仓库 i 运往工厂 j 的货物数量 $\mathbf{P}_{i,j}$. 为执行该方案，经营者向运输公司支付总计 $\langle \mathbf{P}^\star, \mathbf{C}\rangle$ 的费用.

作为耦合的排列矩阵. 对排列 $\sigma \in \mathrm{Perm}(n)$，用 $\mathbf{P}_\sigma$ 表示相应的排列矩阵：

$$\forall (i,j) \in [\![n]\!]^2, \quad (\mathbf{P}_\sigma)_{i,j} = \begin{cases} 1/n & \text{若} j = \sigma_i, \\ 0 & \text{否则.} \end{cases} \tag{2.12}$$

可以验证，此时

$$\langle \mathbf{C}, \mathbf{P}_\sigma \rangle = \frac{1}{n} \sum_{i=1}^{n} \mathbf{C}_{i,\sigma_i},$$

这说明，指派问题 (2.2) 可以改写为 Kantorovich 问题 (2.11)，但将耦合 $\mathbf{P}$ 限制为恰好是排列矩阵：

$$\min_{\sigma \in \mathrm{Perm}(n)} \frac{1}{n} \sum_{i=1}^{n} \mathbf{C}_{i,\sigma(i)} = \min_{\sigma \in \mathrm{Perm}(n)} \langle \mathbf{C}, \mathbf{P}_\sigma \rangle.$$

其次，容易验证，排列矩阵的集合严格包含于 Birkhoff 多胞体 $\mathbf{U}(\mathbb{1}_n/n, \mathbb{1}_n/n)$. 事实上，对任意排列 σ，有 $\mathbf{P}_\sigma \mathbb{1} = \mathbb{1}_n$ 和 $\mathbf{P}_\sigma{}^{\mathrm{T}} \mathbb{1} = \mathbb{1}_n$，而 $\mathbb{1}_n \mathbb{1}_n{}^{\mathrm{T}}/n^2$ 是有效耦合，却不是排列矩阵. 因此，考虑全部传输时，$\langle \mathbf{C}, \mathbf{P} \rangle$ 的最小值必不大于只考虑排列矩阵时的最小值：

$$\mathrm{L}_{\mathbf{C}}(\mathbb{1}_n/n, \mathbb{1}_n/n) \leq \min_{\sigma \in \mathrm{Perm}(n)} \langle \mathbf{C}, \mathbf{P}_\sigma \rangle.$$

以下命题说明，两种问题实际上具有相同的最优值：在两个均匀测度 $\mathbf{a} = \mathbf{b} = \mathbb{1}_n/n$ 之间，总可以找到一个使 Kantorovich 问题 (2.11) 最小的排列矩阵. 因而，对指派问题而言，Kantorovich 松弛是紧的. 图 2.4 左图给出了这一特殊情形下的二维最优匹配示例.

命题 2.1 (用于匹配的 Kantorovich 问题)**.** *若 $m = n$ 且 $\mathbf{a} = \mathbf{b} = \mathbb{1}_n/n$，则问题 (2.11) 存在一个最优解 $\mathbf{P}_{\sigma^\star}$，它是与问题 (2.2) 的某个最优排列 $\sigma^\star \in \mathrm{Perm}(n)$ 相应的排列矩阵.*

证明： Birkhoff 定理 (1946) 说明，$\mathbf{U}(\mathbb{1}_n/n, \mathbb{1}_n/n)$ 的极点集合，恰好等于排列矩阵的集合. 线性规划的一个基本定理 (Bertsimas and Tsitsiklis, 1997, 定理 2.7) 说明，线性目标函数在非空多面体上的最小值，如果有限，就在该多面体的某个极点达到. □

注 2.11 (离散测度之间的 Kantorovich 问题)**.** 对式 (2.3) 所示的离散测度 α, β，将二者支撑上的点之间所有两两代价存入矩阵 $\mathbf{C}$，即 $\mathbf{C}_{i,j} \overset{\text{def.}}{=} c(x_i, y_j)$，定义

$$\mathcal{L}_c(\alpha, \beta) \overset{\text{def.}}{=} \mathrm{L}_{\mathbf{C}}(\mathbf{a}, \mathbf{b}). \tag{2.13}$$

因此，离散测度之间最优传输的 Kantorovich 表述，与其相应概率权重向量 $\mathbf{a}, \mathbf{b}$ 之间的问题相同，区别只在于代价矩阵 $\mathbf{C}$ 依赖于 α, β 的支撑. 不过，在某些情形下，

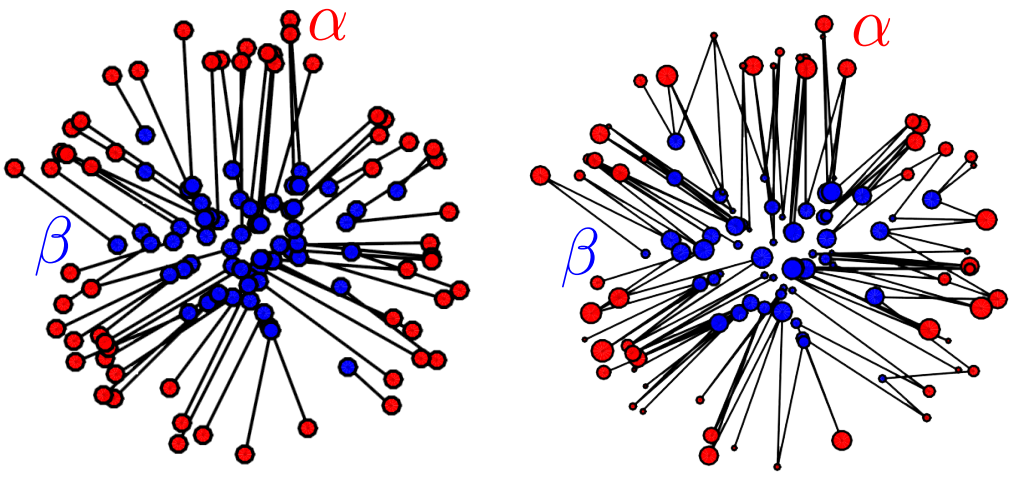

图 2.4: 最优匹配与一般耦合的比较. x_i 与 y_j 之间的黑色线段，表示图示最优耦合 $\mathbf{P}_{i,j}$ 中的非零元素，该耦合求解式 (2.11). 左：最优匹配，对应命题 2.1 的情形，即点数相同 $n = m$ 的经验测度. 右：这两个带权点云无法进行匹配；但可以使用 Kantorovich 耦合，将两个任意离散测度关联起来.

记号 $\mathcal{L}_c(\alpha, \beta)$ 很有用，因为它明确表达了对概率权重和支撑点二者的依赖；对后者的考虑完全通过代价函数 c 体现.

注 2.12 (最优指派与耦合的应用). 最优传输方案本身，无论表示为耦合 $\mathbf{P}$，还是在存在时表示为 Monge 映射 T，都已在数据科学，特别是图像处理中得到许多应用. 例如，它用于对比度均衡 (Delon, 2004) 和纹理合成 Gutierrez et al. (2017). OT 在成像科学中的大量应用涉及图像匹配 (Zhu et al., 2007; Wang et al., 2013; Museyko et al., 2009; Li et al., 2013)、图像融合 (Courty et al., 2016)、医学成像 (Wang et al., 2011)、形状配准 (Makihara and Yagi, 2010; Lai and Zhao, 2017; Su et al., 2015)，以及图像水印 (Mathon et al., 2014). 在天体物理学中，OT 用于重建早期宇宙 (Frisch et al., 2002). OT 还用于音乐转录 (Flamary et al., 2016)，并在经济学中通过解释匹配数据而获得众多应用 (Galichon, 2016). 最后，利用 OT 技术或由其启发的方法计算传输映射，也有助于进行采样 (Reich, 2013; Oliver, 2014) 和 Bayesian 推断 (Kim et al., 2013; El Moselhy and Marzouk, 2012).

注 2.13 (任意测度之间的 Kantorovich 问题). 通过考虑乘积空间上的联合分布，即耦合 $\pi \in \mathcal{M}_+^1(\mathcal{X} \times \mathcal{Y})$，可以将 $\mathcal{L}_c$ 的定义 (2.13) 推广到任意测度. 离散情形是一种特殊情况，其中要求这一乘积空间上的测度具有形式 $\pi = \sum_{i,j} \mathbf{P}_{i,j} \delta_{(x_i, y_j)}$. 在一般情形下，质量守恒约束 (2.10) 应改写为联合概率分布的边缘约束：

$$\mathcal{U}(\alpha, \beta) \overset{\text{def.}}{=} \left\{ \pi \in \mathcal{M}_+^1(\mathcal{X} \times \mathcal{Y}) \;:\; P_{\mathcal{X}\sharp}\pi = \alpha \quad \text{且} \quad P_{\mathcal{Y}\sharp}\pi = \beta \right\}. \tag{2.14}$$

这里 $P_{\mathcal{X}\sharp}$ 和 $P_{\mathcal{Y}\sharp}$ 是投影 $P_{\mathcal{X}}(x, y) = x$、$P_{\mathcal{Y}}(x, y) = y$ 的推前，见定义 2.1. 图 2.5 展示了这些耦合约束在不同问题类别，即离散测度与密度中的形式. 利用式 (2.7)，这些边

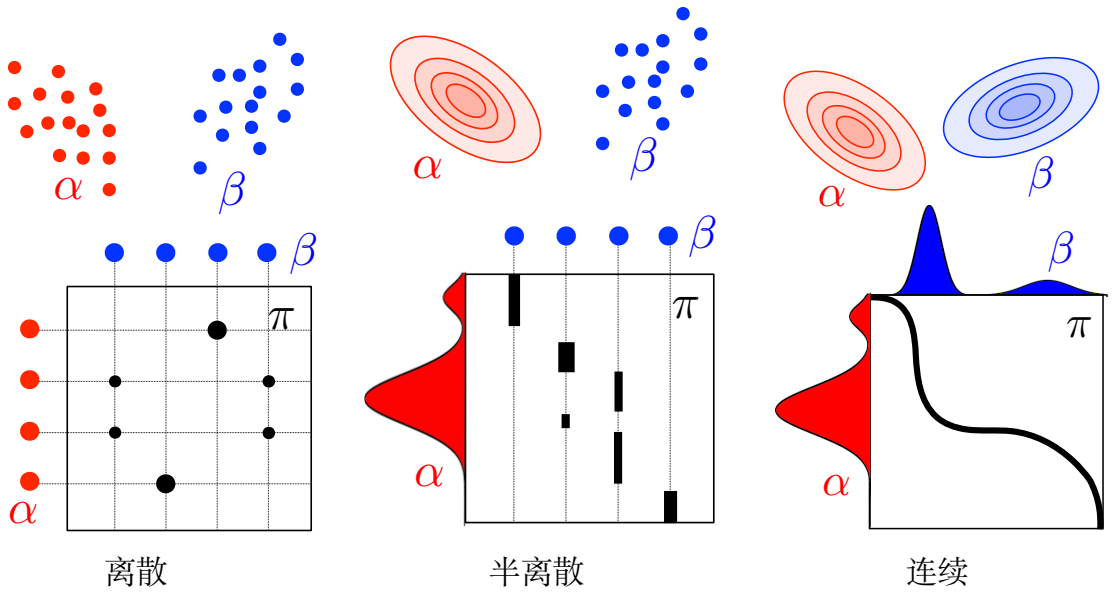

图 2.5: Kantorovich OT 三种主要情形中，输入测度 (α, β) 和耦合 $\mathcal{U}(\alpha, \beta)$ 的示意图. 第 5 章专门讨论半离散情形.

缘约束等价于对集合 $A \subset \mathcal{X}$ 和 $B \subset \mathcal{Y}$ 要求 $\pi(A \times \mathcal{Y}) = \alpha(A)$ 和 $\pi(\mathcal{X} \times B) = \beta(B)$. Kantorovich 问题 (2.11) 于是推广为

$$\mathcal{L}_c(\alpha, \beta) \stackrel{\text{def.}}{=} \min_{\pi \in \mathcal{U}(\alpha,\beta)} \int_{\mathcal{X}\times\mathcal{Y}} c(x, y) \mathrm{d}\pi(x, y). \tag{2.15}$$

这是测度空间上的无限维线性规划. 若 $(\mathcal{X}, \mathcal{Y})$ 是紧空间，且 c 连续，则容易证明它总有解. 事实上，$\mathcal{U}(\alpha, \beta)$ 在测度的弱拓扑下是紧的，见定义 2.2；$\pi \mapsto \int c \mathrm{d}\pi$ 对这一拓扑连续，而且约束集非空，例如 $\alpha \otimes \beta \in \mathcal{U}(\alpha, \beta)$. 图 2.6 给出了求解式 (2.15) 的离散与连续最优耦合示例. 图 2.7 给出了其他一维最优耦合示例，涉及离散与连续边缘分布.

注 2.14 (概率解释). 依照注 2.9，可以从随机变量的角度重新解释 Kantorovich 问题. 事实上，问题 (2.15) 等价于

$$\mathcal{L}_c(\alpha, \beta) = \min_{(X,Y)} \left\{ \mathbb{E}_{(X,Y)}(c(X, Y)) \ : \ X \sim \alpha, \ Y \sim \beta \right\}, \tag{2.16}$$

其中 (X, Y) 是取值于 $\mathcal{X} \times \mathcal{Y}$ 的一对随机变量，$X \sim \alpha$ (分别地，$Y \sim \beta$) 表示，X (分别地，Y) 的分布作为测度必须为 α (分别地，β) . 随机变量对 (X, Y) 的分布，就是乘积空间 $\mathcal{X} \times \mathcal{Y}$ 上的 $\pi \in \mathcal{U}(\alpha, \beta)$.

2.4 最优传输的度量性质

OT 的一个重要特点是，只要代价矩阵满足某些适当性质，它就定义了直方图及概率测度之间的距离. 事实上，可以将 OT 理解为一种典范方式，将点之间的基础距离提

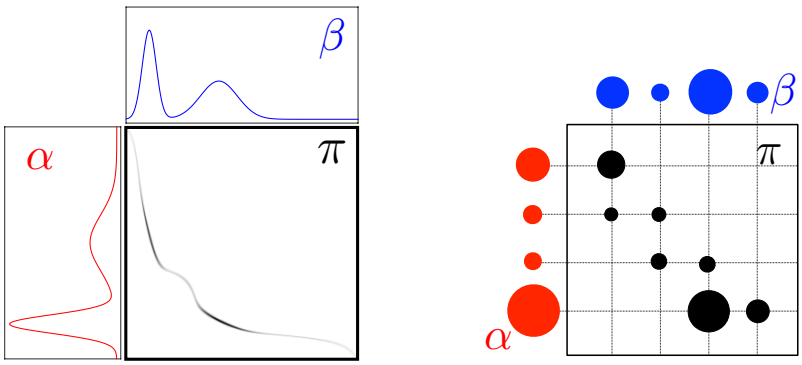

图 2.6: 左：两个具有密度的一维测度之间，求解式 (2.14) 的 “连续” 耦合 π. 耦合集中在 Monge 映射的图像 $(x, T(x))$ 上，以黑色表示. 右：两个形如式 (2.3) 的离散测度之间，求解式 (2.11) 的 “离散” 耦合 T. 正元素 $T_{i,j}$ 用位于 (i, j) 的黑色圆盘表示，其半径与 $T_{i,j}$ 成比例.

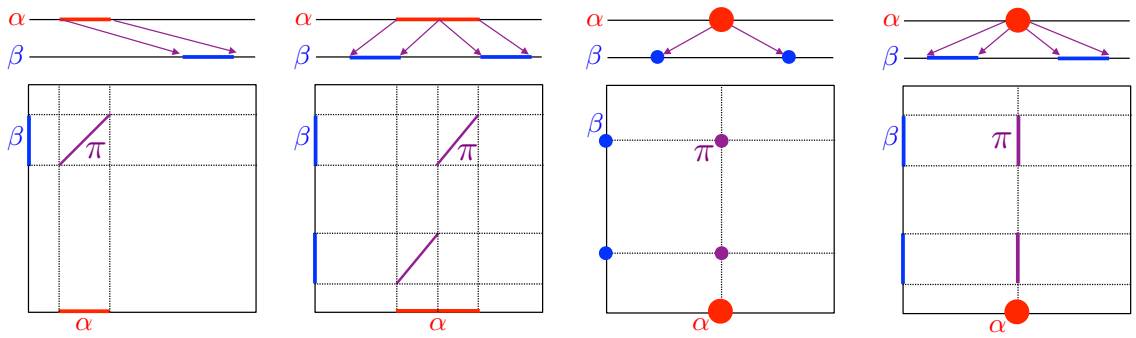

图 2.7: 一维分布之间最优耦合的四个简单示例，上方表示为映射（箭头），下方表示为耦合. 受 Lévy and Schwindt (2018) 启发.

升为直方图或测度之间的距离.

我们首先考虑如下情形：采用 Rubner et al. (2000) 首次引入的术语，“基础度量” 矩阵 $\mathbf{C}$ 是固定的，表示分箱之间的替换代价；我们想要比较的多个直方图共用这一矩阵. 以下命题说明，OT 为支撑在这些分箱上的直方图提供了一个有效的距离.

命题 2.2. 假设 $n = m$，且对某个 $p \geq 1$，$\mathbf{C} = \mathbf{D}^p = (\mathbf{D}_{i,j}^p)_{i,j} \in \mathbb{R}^{n \times n}$，其中 $\mathbf{D} \in \mathbb{R}_+^{n \times n}$ 是 $[\![n]\!]$ 上的距离，即

(i) $\mathbf{D} \in \mathbb{R}_+^{n \times n}$ 对称；

(ii) $\mathbf{D}_{i,j} = 0$ 当且仅当 $i = j$；

(iii) $\forall (i,j,k) \in [\![n]\!]^3$，$\mathbf{D}_{i,k} \leq \mathbf{D}_{i,j} + \mathbf{D}_{j,k}$.

则

$$\mathrm{W}_p(\mathbf{a}, \mathbf{b}) \overset{\text{def.}}{=} \mathrm{L}_{\mathbf{D}^p}(\mathbf{a}, \mathbf{b})^{1/p} \tag{2.17}$$

定义了 Σ_n 上的p-Wasserstein 距离 (p-Wasserstein distance)；注意，W_p 依赖于 $\mathbf{D}$. 即 W_p 对称、非负，$\mathrm{W}_p(\mathbf{a}, \mathbf{b}) = 0$ 当且仅当 $\mathbf{a} = \mathbf{b}$，且满足三角不等式

$$\forall \mathbf{a}, \mathbf{b}, \mathbf{c} \in \Sigma_n, \quad \mathrm{W}_p(\mathbf{a}, \mathbf{c}) \leq \mathrm{W}_p(\mathbf{a}, \mathbf{b}) + \mathrm{W}_p(\mathbf{b}, \mathbf{c}).$$

证明： 距离的对称性与正定性容易证明：由于 $\mathbf{C} = \mathbf{D}^p$ 的对角线为零，$\mathrm{W}_p(\mathbf{a}, \mathbf{a}) = 0$，相应的最优传输矩阵为 $\mathbf{P}^\star = \mathrm{diag}(\mathbf{a})$；由于 $\mathbf{D}^p$ 的所有非对角元素均为正，只要 $\mathbf{a} \neq \mathbf{b}$，就有 $\mathrm{W}_p(\mathbf{a}, \mathbf{b}) > 0$，因为此时可容许耦合必在对角线以外有非零元素；由于 $\mathbf{D}^p$ 对称，$\mathrm{W}_p(\mathbf{a}, \mathbf{b})$ 本身也是对称函数.

为证明任意测度的 Wasserstein 距离满足三角不等式，Villani (2003, 定理 7.3) 使用了粘合引理，它强调具有指定结构的耦合的存在性. 在离散情形下，显式构造这样的粘合耦合很简单. 设 $\mathbf{a}, \mathbf{b}, \mathbf{c} \in \Sigma_n$，并设 $\mathbf{P}$ 和 $\mathbf{Q}$ 分别是 $\mathbf{a}$ 与 $\mathbf{b}$、$\mathbf{b}$ 与 $\mathbf{c}$ 之间传输问题的两个最优解. 为避免 $\mathbf{b}$ 的零坐标可能引起的问题，定义向量 $\tilde{\mathbf{b}}$：若 $\mathbf{b}_j > 0$，则 $\tilde{\mathbf{b}}_j \overset{\text{def.}}{=} \mathbf{b}_j$，否则 $\tilde{\mathbf{b}}_j \overset{\text{def.}}{=} 1$. 写成

$$\mathbf{S} \overset{\text{def.}}{=} \mathbf{P}\,\mathrm{diag}(1/\tilde{\mathbf{b}})\mathbf{Q} \in \mathbb{R}_+^{n \times n},$$

并注意 $\mathbf{S} \in \mathbf{U}(\mathbf{a}, \mathbf{c})$，因为

$$\begin{aligned} \mathbf{S}\mathbb{1}_n &= \mathbf{P}\,\mathrm{diag}(1/\tilde{\mathbf{b}})\mathbf{Q}\mathbb{1}_n = \mathbf{P}(\mathbf{b}/\tilde{\mathbf{b}}) \\ &= \mathbf{P}\mathbb{1}_{\mathrm{Supp}(\mathbf{b})} = \mathbf{a}, \end{aligned}$$

其中 $\mathbb{1}_{\mathrm{Supp}(\mathbf{b})}$ 表示长度为 n 的向量，在 $\mathbf{b}_j > 0$ 的指标 j 处取 1，其余位置取 0. 这里使用了 $\mathbf{P}\mathbb{1}_{\mathrm{Supp}(\mathbf{b})} = \mathbf{P}\mathbb{1} = \mathbf{a}$，因为只要 $\mathbf{b}_j = 0$，必有 $\mathbf{P}_{i,j} = 0$. 类似地可验证 $\mathbf{S}^{\mathrm{T}}\mathbb{1}_n = \mathbf{c}$.

三角不等式于是由下式得到：

$$\begin{aligned}
\mathrm{W}_p(\mathbf{a},\mathbf{c}) &= \left(\min_{\mathbf{P}\in U(\mathbf{a},\mathbf{c})} \langle \mathbf{P}, \mathbf{D}^p\rangle\right)^{1/p} \leq \langle \mathbf{S}, \mathbf{D}^p\rangle^{1/p} \\
&= \left(\sum_{ik} \mathbf{D}_{ik}^p \sum_j \frac{\mathbf{P}_{ij}\mathbf{Q}_{jk}}{\tilde{\mathbf{b}}_j}\right)^{1/p} \\
&\leq \left(\sum_{ijk} (\mathbf{D}_{ij}+\mathbf{D}_{jk})^p \frac{\mathbf{P}_{ij}\mathbf{Q}_{jk}}{\tilde{\mathbf{b}}_j}\right)^{1/p} \\
&\leq \left(\sum_{ijk} \mathbf{D}_{ij}^p \frac{\mathbf{P}_{ij}\mathbf{Q}_{jk}}{\tilde{\mathbf{b}}_j}\right)^{1/p} + \left(\sum_{ijk} \mathbf{D}_{jk}^p \frac{\mathbf{P}_{ij}\mathbf{Q}_{jk}}{\tilde{\mathbf{b}}_j}\right)^{1/p}.
\end{aligned}$$

第一个不等式源于 $\mathbf{S}$ 不一定最优；第二个是 $\mathbf{D}$ 的元素满足的三角不等式；第三个来自 Minkowski 不等式. 因而有

$$\begin{aligned}
\mathrm{W}_p(\mathbf{a},\mathbf{c}) &\leq \left(\sum_{ij} \mathbf{D}_{ij}^p \mathbf{P}_{ij} \sum_k \frac{\mathbf{Q}_{jk}}{\tilde{\mathbf{b}}_j}\right)^{1/p} \\
&\quad + \left(\sum_{jk} \mathbf{D}_{jk}^p \mathbf{Q}_{jk} \sum_i \frac{\mathbf{P}_{ij}}{\tilde{\mathbf{b}}_j}\right)^{1/p} \\
&= \left(\sum_{ij} \mathbf{D}_{ij}^p \mathbf{P}_{ij}\right)^{1/p} + \left(\sum_{jk} \mathbf{D}_{jk}^p \mathbf{Q}_{jk}\right)^{1/p} \\
&= \mathrm{W}_p(\mathbf{a},\mathbf{b}) + \mathrm{W}_p(\mathbf{b},c),
\end{aligned}$$

证明完毕. □

注 2.15 ($0 < p \leq 1$ 的情形)**.** 注意，当 $0 < p \leq 1$ 时，$\mathbf{D}^p$ 本身也是距离. 这意味着，虽然在 $p \geq 1$ 时 $\mathrm{W}_p(\mathbf{a},\mathbf{b})$ 是距离，但在 $p \leq 1$ 时，真正定义单纯形上距离的是 $\mathrm{W}_p(\mathbf{a},\mathbf{b})^p$.

注 2.16 (Wasserstein 距离的应用)**.** OT 距离能够自动将分箱之间的基础度量“提升”为这些分箱上的直方图之间的度量，因此是计算机视觉和机器学习应用中比较直方图的一种理想方法. 在这些领域，一种经典方法是“汇集”局部特征，例如图像描述子，并计算特征经验分布的直方图，即所谓的特征袋，以进行检索、聚类或分类；例如见 (Oliva and Torralba, 2001). 按照相近思路，OT 距离可用于某些提升后的特征空间，进行信号和图像分析 (Thorpe et al., 2017). 里程碑式的论文 (Rubner et al., 2000) 开创了检索和聚类应用；后来，针对适合某些应用的截断矩阵 $\mathbf{C}$ 的更快算法，又带来了新应用，例如计算机视觉中的应用 (Pele and Werman, 2008, 2009). 较近的应用强调将推土机距离用于词袋：既可进行降维 (Rolet et al., 2016) 和文本分类 (Kusner et al., 2015; Huang et al., 2016)，也可定义另一种损失，用来训练输出词袋的多类分类器 (Frogner et al., 2015). Kolouri et al. (2017) 对这类信号处理

和机器学习应用给出了较近的概述.

注 2.17 (测度之间的 Wasserstein 距离)**.** 命题 2.2 可以推广到不必离散的任意测度.

命题 2.3. 假设 $\mathcal{X}=\mathcal{Y}$，且对某个 $p\geq 1$，有 $c(x,y)=d(x,y)^p$，其中 d 是 $\mathcal{X}$ 上的距离，即

(i) $d(x,y)=d(y,x)\geq 0$;

(ii) $d(x,y)=0$ 当且仅当 $x=y$;

(iii) $\forall (x,y,z)\in\mathcal{X}^3$，$d(x,z)\leq d(x,y)+d(y,z)$.

则 $\mathcal{X}$ 上的 p-Wasserstein 距离

$$\mathcal{W}_p(\alpha,\beta)\overset{\text{def.}}{=}\mathcal{L}_{d^p}(\alpha,\beta)^{1/p} \tag{2.18}$$

确实是距离；注意，$\mathcal{W}_p$ 依赖于 d. 也就是说，$\mathcal{W}_p$ 对称、非负，$\mathcal{W}_p(\alpha,\beta)=0$ 当且仅当 $\alpha=\beta$，并满足三角不等式

$$\forall(\alpha,\beta,\gamma)\in\mathcal{M}_+^1(\mathcal{X})^3,\quad \mathcal{W}_p(\alpha,\gamma)\leq\mathcal{W}_p(\alpha,\beta)+\mathcal{W}_p(\beta,\gamma).$$

证明： 证明与命题 2.2 采用相同思路，依赖于如下耦合的存在性：通过“粘合” (α,β) 与 (β,γ) 之间的最优耦合，得到 (α,γ) 之间的耦合. □

注 2.18 (几何直觉与弱收敛)**.** Wasserstein 距离 $\mathcal{W}_p$ 有许多重要性质，其中最重要的是它是一种弱距离，即它允许比较支撑互不重叠的奇异分布，例如离散分布，并量化两个分布支撑之间的空间位移. 特别地，“经典” 距离或散度甚至无法在离散分布之间定义：L^2 范数只能用于相对于某个基准测度具有密度的连续测度；离散 ℓ^2 范数则要求位置 (x_i,y_j) 取自预先指定的离散集合，才能正常使用. 与此形成鲜明对照，对任意 $p>0$，有 $\mathcal{W}_p^p(\delta_x,\delta_y)=d(x,y)$. 事实上，只需注意 $\mathcal{U}(\delta_x,\delta_y)=\{\delta_{x,y}\}$；因此 Kantorovich 问题只有一个可行解，$\mathcal{W}_p^p(\delta_x,\delta_y)$ 必为 $(d(x,y)^p)^{1/p}=d(x,y)$. 这说明，若 $x\to y$，则 $\mathcal{W}_p(\delta_x,\delta_y)\to 0$. 这一性质对应于如下事实：$\mathcal{W}_p$ 能够量化弱收敛. 现在定义弱收敛.

定义 2.2 (弱收敛)**.** 在紧区域 $\mathcal{X}$ 上，$(\alpha_k)_k$ 在 $\mathcal{M}_+^1(\mathcal{X})$ 中弱收敛 (weak convergence) 于 α，记为 $\alpha_k\rightharpoonup\alpha$，当且仅当对任意连续函数 $g\in\mathcal{C}(\mathcal{X})$，都有 $\int_{\mathcal{X}}g\mathrm{d}\alpha_k\to\int_{\mathcal{X}}g\mathrm{d}\alpha$. 在非紧区域上，还需对 g 加入额外的衰减条件. 这种弱收敛概念对应于随机向量的依分布收敛.

可以证明，这种收敛等价于 $\mathcal{W}_p(\alpha_k,\alpha)\to 0$ (Villani, 2009, 定理 6.8)；对无界度量空间，还需同时有直到 p 阶的矩的收敛.

注 2.19 (平移). 欧氏空间 $\mathcal{X} = \mathbb{R}^d$ 上，基础代价 $c(x,y) = \|x-y\|^2$ 所对应的 Wasserstein 距离具有一个良好性质：可以将平移的影响分离出来. 事实上，将平移算子记为 $T_\tau : x \mapsto x - \tau$，则有

$$\mathcal{W}_2(T_{\tau\sharp}\alpha, T_{\tau'\sharp}\beta)^2 = \mathcal{W}_2(\alpha,\beta)^2 - 2\langle \tau-\tau', \mathbf{m}_\alpha - \mathbf{m}_\beta\rangle + \|\tau-\tau'\|^2,$$

其中 $\mathbf{m}_\alpha \overset{\text{def.}}{=} \int_{\mathcal{X}} x \mathrm{d}\alpha(x) \in \mathbb{R}^d$ 是 α 的均值. 特别地，这给出了距离的如下分解：

$$\mathcal{W}_2(\alpha,\beta)^2 = \mathcal{W}_2(\tilde\alpha,\tilde\beta)^2 + \|\mathbf{m}_\alpha - \mathbf{m}_\beta\|^2,$$

其中 $(\tilde\alpha,\tilde\beta)$ 是经过“中心化”的零均值测度，$\tilde\alpha = T_{\mathbf{m}_\alpha\sharp}\alpha$.

注 2.20 ($p=+\infty$ 的情形). 非正式地，$\mathcal{W}_p^p$ 在 $p\to+\infty$ 时的极限为

$$\mathcal{W}_\infty(\alpha,\beta) \overset{\text{def.}}{=} \min_{\pi\in\mathcal{U}(\alpha,\beta)} \sup_{(x,y)\in\mathrm{Supp}(\pi)} d(x,y), \tag{2.19}$$

其中上确界应理解为相对于 $\mathcal{X}^2$ 上测度 π 的本质上确界. 与 $p<+\infty$ 的情形不同，这是一个非凸优化问题，数值求解和理论研究都很困难. $\mathcal{W}_\infty$ 距离与 (α,β) 的支撑之间的 Hausdorff 距离有关，见第 10.6.1 节. 详情参见 (Champion et al., 2008).

2.5 对偶问题

Kantorovich 问题 (2.11) 是一个带约束的凸最小化问题，因此可以自然地与一个所谓的对偶问题配对，后者是带约束的凹最大化问题. 以下基本命题说明原问题与对偶问题的关系.

命题 2.4. Kantorovich 问题 (2.11) 具有如下对偶：

$$\mathrm{L}_{\mathbf{C}}(\mathbf{a},\mathbf{b}) = \max_{(\mathbf{f},\mathbf{g})\in\mathbf{R}(\mathbf{C})} \langle \mathbf{f},\mathbf{a}\rangle + \langle \mathbf{g},\mathbf{b}\rangle, \tag{2.20}$$

其中可容许对偶变量的集合为

$$\mathbf{R}(\mathbf{C}) \overset{\text{def.}}{=} \Big\{ (\mathbf{f},\mathbf{g}) \in \mathbb{R}^n\times\mathbb{R}^m : \ \forall (i,j)\in[\![n]\!]\times[\![m]\!], \ \mathbf{f}\oplus\mathbf{g} \le \mathbf{C} \Big\}. \tag{2.21}$$

这类对偶变量常被称为“Kantorovich 势（Kantorovich potential）”.

证明： 这一结果是线性规划强对偶性这一更一般结论的直接推论 (Bertsimas and Tsitsiklis, 1997, 第 148 页，定理 4.4). 证明中较容易的部分，即证明式 (2.20) 的右端是 $\mathrm{L}_{\mathbf{C}}(\mathbf{a},\mathbf{b})$ 的下界，将在下一节的注 3.2 中讨论. 为完整起见，我们利用 Lagrange 对偶推导这一结论. 与式 (2.11) 相应的 Lagrange 表述为

$$\min_{\mathbf{P}\ge 0} \max_{(\mathbf{f},\mathbf{g})\in\mathbb{R}^n\times\mathbb{R}^m} \langle \mathbf{C},\mathbf{P}\rangle + \langle \mathbf{a}-\mathbf{P}\mathbb{1}_m, \mathbf{f}\rangle + \langle \mathbf{b}-\mathbf{P}^{\mathrm{T}}\mathbb{1}_n, \mathbf{g}\rangle. \tag{2.22}$$

交换其中的最小化与最大化；对于有限维线性规划，这总是可以的. 得到

$$\max_{(\mathbf{f},\mathbf{g})\in\mathbb{R}^n\times\mathbb{R}^m} \langle \mathbf{a}, \mathbf{f}\rangle + \langle \mathbf{b}, \mathbf{g}\rangle + \min_{\mathbf{P}\geq 0} \langle \mathbf{C} - \mathbf{f}\mathbb{1}_m{}^{\mathrm{T}} - \mathbb{1}_n\mathbf{g}^{\mathrm{T}}, \mathbf{P}\rangle.$$

最后，注意

$$\min_{\mathbf{P}\geq 0} \langle \mathbf{Q}, \mathbf{P}\rangle = \begin{cases} 0 & \text{若}\mathbf{Q}\geq 0, \\ -\infty & \text{否则}, \end{cases}$$

因而约束写成 $\mathbf{C} - \mathbf{f}\mathbb{1}_m{}^{\mathrm{T}} - \mathbb{1}_n\mathbf{g}^{\mathrm{T}} = \mathbf{C} - \mathbf{f}\oplus\mathbf{g} \geq 0$，结论即得. □

Lagrange 表述 (2.22) 的原始—对偶最优性关系，允许我们确定最优传输方案的支撑，亦见第 3.3 节：

$$\{(i,j)\in[\![n]\!]\times[\![m]\!] : \mathbf{P}_{i,j} > 0\} \subset \{(i,j)\in[\![n]\!]\times[\![m]\!] : \mathbf{f}_i + \mathbf{g}_j = \mathbf{C}_{i,j}\}. \tag{2.23}$$

注 2.21. 沿用注 2.10 对 Kantorovich 问题的解释，我们给出对偶的直观说明. 回忆那里，经营者希望以最小代价把一定总量的资源从仓库运到工厂. 他可以通过求解式 (2.11)，按照 $\mathbf{P}^\star$ 指定的方案运输，并向运输公司支付 $\langle \mathbf{P}^\star, \mathbf{C}\rangle$ 来完成这一任务.

外包物流. 假设经营者没有求解线性规划 (2.11) 所需的计算能力，于是决定把任务外包给一家服务商. 服务商采用如下定价结构：将物流任务分为收货和送货，在每座仓库 i 收取一单位资源，按 $\mathbf{f}_i$ 收费，不论该单位送往何处；向工厂 j 送达一单位资源，按 $\mathbf{g}_j$ 收费，不论该单位来自哪座仓库. 由于仓库 i 恰有 $\mathbf{a}_i$ 单位资源，而工厂 j 需要 $\mathbf{b}_j$ 单位，按这种定价方案，服务商解决经营者物流问题的总报价为 $\langle \mathbf{f}, \mathbf{a}\rangle + \langle \mathbf{g}, \mathbf{b}\rangle$.

设定价格. 服务商的定价体系很自然地允许任意负价格. 事实上，如果她为仓库采用价格向量 $\mathbf{f}$，为工厂采用价格向量 $\mathbf{g}$，则把 $\mathbf{f}$ 的所有元素同时减去任意一个数，并把 $\mathbf{g}$ 的所有元素同时增加这个数，总账单不会改变；因为所有仓库中的资源总量，恰好等于必须运往工厂的资源总量. 换言之，服务商可以通过付款给经营者以收取部分货物，制造极其优惠的表象，再通过提高送货收费来补偿损失. 明白这一点后，希望对服务收取尽可能高费用的服务商，会将向量 $\mathbf{f},\mathbf{g}$ 设得尽可能高.

核查价格. 在没有另一家服务商竞争的情况下，经营者必须想出一种快速方法，判断报价是否合理. 一种可能的办法是求解问题 (2.11)，计算最高效方案的费用 $\mathrm{L}_{\mathbf{C}}(\mathbf{a},\mathbf{b})$，并核查服务商的报价至少不超过该金额. 然而，经营者原本就无法承担这样漫长的计算. 幸运的是，有一种高效得多的办法核查服务商是否有竞争力. 回忆 $\mathbf{f}_i$ 是在 i 收取一单位资源的价格，$\mathbf{g}_j$ 是向 j 送达一单位资源的价格，因此按服务商的方案，从 i 向 j 转运一单位资源，费用恰为 $\mathbf{f}_i + \mathbf{g}_j$. 经营者又知道，运输公司对此收取的费用是 $\mathbf{C}_{i,j}$. 因而，只要某对 i,j 的合计价格 $\mathbf{f}_i + \mathbf{g}_j$ 严格大于 $\mathbf{C}_{i,j}$，服务商就比运输公司对此任务收取的公平价格要价更高，经营者应拒绝报价.

作为对偶问题的最优价格. 因而，核查服务商的报价对所有 i,j 都满足 $\mathbf{f}_i+\mathbf{g}_j \leq \mathbf{C}_{i,j}$，符合经营者的利益. 假设他确实核查了价格向量满足这 $n\times m$ 个不等式，能否断定报价有吸引力？作一个简短的粗略计算，他便会确认接受报价符合自己的利益. 事实上，他的任意传输方案 $\mathbf{P}$ 的代价为 $\langle \mathbf{P}, \mathbf{C}\rangle = \sum_{i,j} \mathbf{P}_{i,j}\mathbf{C}_{i,j}$；应用这 $n\times m$ 个不等式，经营者

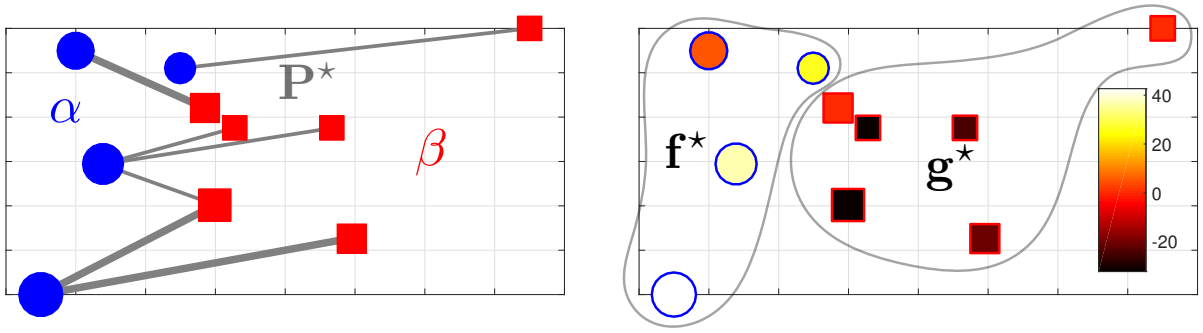

图 2.8: 左图考虑两个离散测度 α, β 之间的最优传输问题，分别用蓝色圆点和红色方块表示；标记面积与各位置的权重成比例. 图中还展示了平方欧氏代价下的最优传输 $\mathbf{P}^\star$. 右图给出对应的对偶 Kantorovich 势 $\mathbf{f}^\star, \mathbf{g}^\star$. 由于 α 的每个点都对应一个 "价格" $\mathbf{f}_i^\star$，对 $\mathbf{g}, \beta$ 也类似，各点颜色按右侧色标表示所得数值. 这些势可以理解为相对价格：在最佳传输方案下，它们表示从 α 的每个位置移走质量，或向 β 的每个点送入质量的个别代价. 因此，最优传输代价等于左图所有连线长度的平方按粗细加权后求和；或者根据对偶表述，等于右图各标记的数值（用颜色编码）乘以面积后求和.

可以断定，对于任意传输方案 $\mathbf{P}$，包括最优方案 $\mathbf{P}^\star$，边缘约束给出

$$\begin{aligned}\sum_{i,j} \mathbf{P}_{i,j}\mathbf{C}_{i,j} &\geq \sum_{i,j} \mathbf{P}_{i,j}(\mathbf{f}_i + \mathbf{g}_j) \\ &= \left(\sum_i \mathbf{f}_i \sum_j \mathbf{P}_{i,j}\right) + \left(\sum_j \mathbf{g}_j \sum_i \mathbf{P}_{i,j}\right) \\ &= \langle \mathbf{f}, \mathbf{a}\rangle + \langle \mathbf{g}, \mathbf{b}\rangle.\end{aligned}$$

于是他发现，任何自行完成任务的尝试，都必比服务商报价更贵.

因此，服务商必须寻找一组使 $\langle \mathbf{f}, \mathbf{a}\rangle + \langle \mathbf{g}, \mathbf{b}\rangle$ 最大的价格 $\mathbf{f}, \mathbf{g}$，但为了让报价被接受，至少必须对所有 i, j 满足基本不等式 $\mathbf{f}_i + \mathbf{g}_j \leq \mathbf{C}_{i,j}$，这就得到问题 (2.20). 可以证明，正如我们随后在第 3.1 节所做的，服务商获得的最佳价格，实际上恰等于经营者通过计算 $\mathrm{L}_\mathbf{C}(\mathbf{a}, \mathbf{b})$ 所能获得的最佳代价.

图 2.8 展示同一传输问题的原始解和对偶解. 左侧蓝点表示仓库，红点表示工厂；面积表示概率权重 $\mathbf{a}, \mathbf{b}$，连接表示最优传输，粗细与转运量成比例. 右侧显示服务商优化问题 (2.20) 后得到的最优价格，价格经过选取，使其均值等于 0. 最高的相对价格来自在图左下方孤立仓库收货，以及向右上方工厂送货.

注 2.22 (任意测度之间的对偶问题). 要将这一原始—对偶构造推广到任意测度，需要认识到，测度自然地与连续函数对偶配对；只能通过对连续函数积分来研究测度. 以下命题形式化这种对偶性，在离散测度的情形下，它归结为命题 2.4.

命题 2.5. 有

$$\mathcal{L}_c(\alpha,\beta) = \sup_{(f,g)\in\mathcal{R}(c)} \int_{\mathcal{X}} f(x)\mathrm{d}\alpha(x) + \int_{\mathcal{Y}} g(y)\mathrm{d}\beta(y), \tag{2.24}$$

其中可容许对偶势的集合为

$$\mathcal{R}(c) \overset{\text{def.}}{=} \{(f,g)\in\mathcal{C}(\mathcal{X})\times\mathcal{C}(\mathcal{Y}) \;:\; \forall (x,y),\; f(x)+g(y)\leq c(x,y)\}. \tag{2.25}$$

这里 (f,g) 是一对连续函数，与离散情形相同，也称为 “Kantorovich 势”.

离散情形 (2.20) 对应于对偶向量是连续势的采样，即 $(\mathbf{f}_i,\mathbf{g}_j) = (f(x_i),g(y_j))$. 原始—对偶最优性条件使我们能够确定最优方案的支撑；式 (2.23) 推广为

$$\mathrm{Supp}(\pi) \subset \{(x,y)\in\mathcal{X}\times\mathcal{Y} \;:\; f(x)+g(y)=c(x,y)\}. \tag{2.26}$$

与原问题 (2.15) 不同，证明式 (2.24) 存在解并不平凡，因为约束集 $\mathcal{R}(c)$ 不紧，而待最小化的函数不具强制性. 不过，在 $c(x,y)=d(x,y)^p$、$p\geq 1$ 的情形下，利用第 5.1 节详述的 c-变换工具，可以证明最优 (f,g) 必具有 Lipschitz 正则性，从而可以将约束替换为一个紧约束.

注 2.23 (无约束对偶). 当 $\int_{\mathcal{X}}\mathrm{d}\alpha = \int_{\mathcal{Y}}\mathrm{d}\beta = 1$ 时，可以将带约束的对偶问题 (2.24) 替换为无约束问题：

$$\mathcal{L}_c(\alpha,\beta) = \sup_{(f,g)\in\mathcal{C}(\mathcal{X})\times\mathcal{C}(\mathcal{Y})} \int_{\mathcal{X}} f\mathrm{d}\alpha + \int_{\mathcal{Y}} g\mathrm{d}\beta + \min_{\mathcal{X}\otimes\mathcal{Y}} (c - f\oplus g), \tag{2.27}$$

其中记 $(f\oplus g)(x,y) = f(x)+g(y)$. 这里的最小值应理解为与测度 $\alpha\otimes\beta$ 相应的本质上确界；即在 α,β 的零测集上修改 f 或 g，不会改变它. Francis Bach 向我们指出了这一替代的对偶表述. 它通过在原问题 (2.15) 中加入冗余约束 $\int\mathrm{d}\pi = 1$ 得到.

注 2.24 (Monge–Kantorovich 等价性——Brenier 定理). 以下定理常归于 Brenier (1991)；它保证，在 $\mathbb{R}^d$ 中，当 $p=2$、至少一个输入测度具有密度，且测度具有二阶矩时，Kantorovich 问题与 Monge 问题等价. 有兴趣的读者也应查阅几乎同时发表的变体 Cuesta and Matran (1989); Rüschendorf and Rachev (1990)，特别包括 (Brenier, 1987) 中的原始结果，以及 Knott and Smith (1984) 的先驱工作.

定理 2.1 (Brenier). 当 $\mathcal{X}=\mathcal{Y}=\mathbb{R}^d$ 且 $c(x,y)=\|x-y\|^2$ 时，若至少一个输入测度，记为 α，具有相对于 Lebesgue 测度的密度 ρ_α，则 Kantorovich 表述 (2.15) 中的最优 π 唯一，且支撑在某个 “Monge 映射” $T:\mathbb{R}^d\to\mathbb{R}^d$ 的图像 $(x,T(x))$ 上. 这表示 $\pi = (\mathrm{Id},T)_\sharp\alpha$，即

$$\forall h\in\mathcal{C}(\mathcal{X}\times\mathcal{Y}),\quad \int_{\mathcal{X}\times\mathcal{Y}} h(x,y)\mathrm{d}\pi(x,y) = \int_{\mathcal{X}} h(x,T(x))\mathrm{d}\alpha(x). \tag{2.28}$$

此外，该映射 T 唯一地定义为某个凸函数 φ 的梯度，即 $T(x) = \nabla\varphi(x)$；φ 是满足 $(\nabla\varphi)_\sharp\alpha = \beta$ 的唯一凸函数，唯一性相差一个加法常数. 这一凸函数与求解式 (2.24) 的对偶势 f 的关系为 $\varphi(x) = \frac{\|x\|^2}{2} - f(x)$.

证明： 我们概述证明的主要要素；更多细节可见例如 (Santambrogio, 2015). 注意，$\int c\mathrm{d}\pi = C_{\alpha,\beta} - 2\int\langle x, y\rangle\mathrm{d}\pi(x,y)$，其中常数为 $C_{\alpha,\beta} = \int\|x\|^2\mathrm{d}\alpha(x) + \int\|y\|^2\mathrm{d}\beta(y)$. 因而，可以不求解式 (2.15)，而考虑问题

$$\max_{\pi\in\mathcal{U}(\alpha,\beta)}\int_{\mathcal{X}\times\mathcal{Y}}\langle x, y\rangle\mathrm{d}\pi(x,y),$$

其对偶为

$$\min_{(\varphi,\psi)}\left\{\int_{\mathcal{X}}\varphi\mathrm{d}\alpha + \int_{\mathcal{Y}}\psi\mathrm{d}\beta \;:\; \forall(x,y),\quad \varphi(x)+\psi(y)\geq\langle x, y\rangle\right\}. \tag{2.29}$$

这些变量与式 (2.25) 中变量的关系是 $(\varphi,\psi) = (\frac{\|\cdot\|^2}{2} - f, \frac{\|\cdot\|^2}{2} - g)$. 可以将约束替换为

$$\forall y,\quad \psi(y)\geq\varphi^*(y)\overset{\text{def.}}{=}\sup_x\langle x, y\rangle - \varphi(x). \tag{2.30}$$

这里 φ^* 是 φ 的 Legendre 变换；它作为线性形式的上确界，是凸函数，亦见式 (4.54). 由于式 (2.31) 中的目标为线性，且积分所用测度为正，可以显式地对 ψ 最小化，令 $\psi = \varphi^*$，转而考虑无约束问题

$$\min_{\varphi}\int_{\mathcal{X}}\varphi\mathrm{d}\alpha + \int_{\mathcal{Y}}\varphi^*\mathrm{d}\beta; \tag{2.31}$$

亦见第 3.2 节和第 5.1 节，那里分别在离散情形以及一般代价 $c(x,y)$ 下应用这一思想. 将此论证重复两次，可以用凸函数 φ^{**} 替换 φ，从而在式 (2.31) 中要求 φ 为凸函数. 条件 (2.26) 表明，最优 π 支撑在 $\{(x,y)\;:\;\varphi(x)+\varphi^*(y) = \langle x, y\rangle\}$ 上. 因而这样的 y 对 Legendre 变换的最小化 (2.30) 是最优的，其最优性条件为 $y\in\partial\varphi(x)$. 由于 φ 为凸函数，它几乎处处可微；又因为 α 具有密度，它也 α-几乎处处可微. 这说明，对每个 x，相应的 y 在 α-几乎处处意义下唯一地定义为 $y = \nabla\varphi(x)$，从而必有 $\pi = (\mathrm{Id}, \nabla\varphi)_\sharp\alpha$. □

这一结果表明，在具有非奇异密度的 $\mathcal{W}_2$ 情形下，Monge 问题 (2.9) 与其 Kantorovich 松弛 (2.15) 相等，即松弛是紧的. 这是指派情形的命题 2.1 在连续背景下的对应结果：当边缘分布相同且均匀时，最优传输问题的最小值在某个排列矩阵，即离散映射处达到. Brenier 定理说明，最优传输映射必须是凸函数的梯度，从而为一维以上的递增函数概念提供了有用推广. 这是最优传输可以用于在任意维数定义分位数函数的主要原因，进而有助于分位数回归问题的应用 (Carlier et al., 2016).

此外，这一定理可以沿许多方向推广. α 具有密度的条件，可以弱化为：它不给 Hausdorff 维数小于 $d-1$ 的“小集合”赋予质量，例如超曲面. 还可以考虑 $c(x,y)=h(x-y)$ 型代价，其中 h 严格凸.

注 2.25 (Monge–Ampère 方程). 对具有密度的测度，利用式 (2.8)，得到 φ 是求解以下 Monge–Ampère 型方程的唯一凸函数，唯一性相差一个加法常数：

$$\det(\partial^2\varphi(x))\rho_\beta(\nabla\varphi(x))=\rho_\alpha(x), \tag{2.32}$$

其中 $\partial^2\varphi(x)\in\mathbb{R}^{d\times d}$ 是 φ 的 Hessian 矩阵. Monge–Ampère 算子 $\det(\partial^2\varphi(x))$ 可以理解为一个非线性的退化 Laplace 算子. 在小位移极限下，$\varphi=\mathrm{Id}+\varepsilon\psi$，确实可以通过线性化恢复 Laplace 算子 Δ，因为对光滑映射有

$$\det(\partial^2\varphi(x))=1+\varepsilon\Delta\psi(x)+o(\varepsilon).$$

凸性约束迫使 $\det(\partial^2\varphi(x))\geq 0$，并且是这一方程有解的必要条件. 关于 Monge–Ampère 方程的理论分析，特别是解的正则性，已有大量文献；例如见 (Gutiérrez, 2016)，有兴趣的读者可参阅 Caffarelli (2003) 的综述. 主要困难在于，一般情形下解不必光滑；当输入测度任意，例如 Dirac 质量时，需要借助 Alexandrov 解的工具. 在右端 f 固定的较简单情形 $\det(\partial^2\varphi(x))=f(x)$ 下，已有许多求解器，例如见 (Benamou et al., 2016b) 及其中引用的文献. 特别地，捕捉各向异性凸函数需要格外谨慎，通常的有限差分可能不准确. 对最优传输而言，f 实际依赖于 $\nabla\varphi$；式 (2.32) 的离散化及边界条件，带来了 (Benamou et al., 2014) 及其中引用文献所述的技术挑战. 还应注意，基于不动点迭代的相关求解器已用于图像配准 (Haker et al., 2004).

2.6 特殊情形

一般而言，计算最优传输距离需要复杂的数值运算. 在第 3、4、7 章介绍各种数值求解器之前，我们先回顾一些便于求解最优传输问题的特殊情形.

注 2.26 (二元代价矩阵与 1-范数). 容易验证，当代价矩阵 $\mathbf{C}$ 的对角元为 0，其余元素为 1，即 $\mathbf{C}=\mathbb{1}_{n\times n}-\mathbb{I}_n$ 时，$\mathbf{a}$ 与 $\mathbf{b}$ 之间的 1-Wasserstein 距离等于其差的 1-范数：$\mathrm{L}_{\mathbf{C}}(\mathbf{a},\mathbf{b})=\|\mathbf{a}-\mathbf{b}\|_1$.

注 2.27 (Kronecker 代价函数与全变差). 除了上面的注 2.26，还容易验证：若 $c(x,y)$ 在 $x=y$ 时为 0，在 $x\neq y$ 时为 1，则该结果可推广到任意测度. 两个离散测度 α 与 β 之间的最优传输距离等于其全变差距离（另见例 8.1.2）.

注 2.28 (一维情形——经验测度). 此处 $\mathcal{X}=\mathbb{R}$. 设 $\alpha=\frac{1}{n}\sum_{i=1}^n\delta_{x_i}$，$\beta=\frac{1}{n}\sum_{j=1}^n\delta_{y_j}$，并不失一般性地假设点已排序，即 $x_1\leq x_2\leq\cdots\leq x_n$，$y_1\leq y_2\leq\cdots\leq y_n$，则有简

单公式

$$\mathcal{W}_p(\alpha,\beta)^p = \frac{1}{n}\sum_{i=1}^{n} |x_i - y_i|^p. \tag{2.33}$$

也就是说，局部地（假设各点互异），$\mathcal{W}_p(\alpha,\beta)$ 是表示 α 与 β 的两个有序数值向量之间的 ℓ^p 范数. 该结论仅局部成立，因为当某些数值变化时，排序以及相应的向量表示也可能改变. 此公式是注 2.30 中更一般情形的直接推论. 图 2.9 上行展示了点数相同的经验测度之间的一维传输映射，下行展示了此单调映射如何推广到任意离散测度. 还可以利用这一维计算，高效计算圆周上的最优传输，见 Delon et al. (2010). 注意，若代价是距离的凹函数，特别是 $p < 1$ 时，最优传输方案的行为会很不相同，但仍存在高效求解器 (Delon et al., 2012).

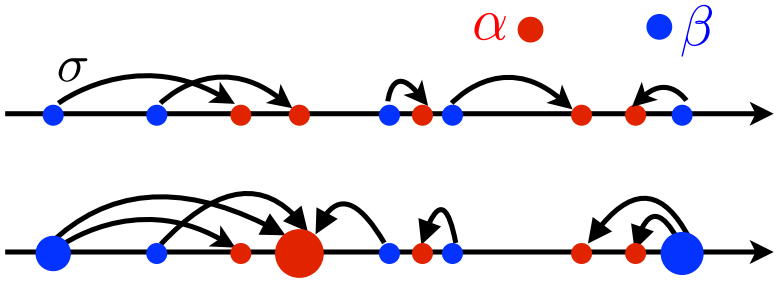

图 2.9: 一维最优耦合：每条箭头 $x_i \to y_j$ 表示最优耦合中非零的 $\mathbf{P}_{i,j}$. 上：点数相同的经验测度（最优匹配）. 下：一般情形. 这对应于单调重排：若 $x_i \le x_{i'}$ 且 $\mathbf{P}_{i,j} \neq 0$、$\mathbf{P}_{i',j'} \neq 0$，则必有 $y_j \le y_{j'}$.

注 2.29 (直方图均衡化). 一维最优传输可以用于直方图均衡化，应用之一是灰度图像调色板的归一化，见图 2.10. 在此，将两幅输入图像的全部像素按预定顺序（例如逐列）编号，以 $(\bar{x}_i)_i$、$(\bar{y}_j)_j$ 表示其灰度值，其中 0 为黑色，1 为白色，其余值表示中间灰度. 假设每幅图像都有 $n \times m$ 个像素. 将灰度值排序，定义注 2.28 中的 $x_i = \bar{x}_{\sigma_1(i)}$ 与 $y_j = \bar{y}_{\sigma_2(j)}$，其中 $\sigma_1, \sigma_2 : \{1,\dots,nm\} \to \{1,\dots,nm\}$ 是置换. 因而 $\sigma \overset{\text{def.}}{=} \sigma_2 \circ \sigma_1^{-1}$ 是两个离散分布之间的最优指派. 在图像处理应用中，$(\bar{y}_{\sigma(i)})_i$ 给出 $\bar{x}$ 的均衡化版本的颜色值，其经验分布与 $\bar{y}$ 的经验分布完全一致. 将这个 nm 维向量重新折叠成 $n \times m$ 的图像，即可恢复均衡化图像. 此外，$t \in [0,1] \mapsto (1-t)\bar{x}_i + t\bar{y}_{\sigma(i)}$ 定义了原图与均衡化图像之间的插值；其像素经验分布是输入分布之间的位移插值，定义见式 (7.7).

注 2.30 (一维情形——一般情形). 对 $\mathbb{R}$ 上的测度 α，引入从 $\mathbb{R}$ 到 $[0,1]$ 的累积分布函数

$$\forall\, x \in \mathbb{R}, \quad \mathcal{C}_\alpha(x) \overset{\text{def.}}{=} \int_{-\infty}^{x} \mathrm{d}\alpha, \tag{2.34}$$

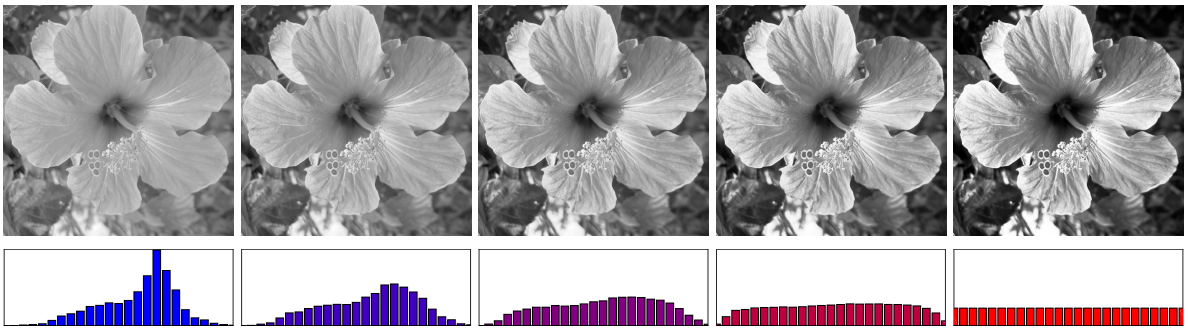

图 2.10: 图像处理中的直方图均衡化，其中 t 参数化直方图之间的位移插值.

及其伪逆 $\mathcal{C}_\alpha^{-1} : [0,1] \to \mathbb{R} \cup \{-\infty\}$:

$$\forall r \in [0,1], \quad \mathcal{C}_\alpha^{-1}(r) = \min_x \{x \in \mathbb{R} \cup \{-\infty\} \ : \ \mathcal{C}_\alpha(x) \geq r\}. \tag{2.35}$$

这一函数也称为 α 的广义分位数函数. 对任何 $p \geq 1$，有

$$\begin{aligned} \mathcal{W}_p(\alpha,\beta)^p &= \left\|\mathcal{C}_\alpha^{-1} - \mathcal{C}_\beta^{-1}\right\|_{L^p([0,1])}^p \\ &= \int_0^1 |\mathcal{C}_\alpha^{-1}(r) - \mathcal{C}_\beta^{-1}(r)|^p \mathrm{d}r. \end{aligned} \tag{2.36}$$

这意味着，通过映射 $\alpha \mapsto \mathcal{C}_\alpha^{-1}$，Wasserstein 距离等距于一个配备 L^p 范数的线性空间；等价地，实线上测度的 Wasserstein 距离是一个 Hilbert 型度量. 因而一维最优传输的几何十分简单，却也与高维情形的几何有很大差异：后者并非 Hilbert 型，见命题 8.1 以及更一般的第 8.3 节. 当 $p = 1$ 时，还有更简单的公式

$$\mathcal{W}_1(\alpha,\beta) = \|\mathcal{C}_\alpha - \mathcal{C}_\beta\|_{L^1(\mathbb{R})} = \int_{\mathbb{R}} |\mathcal{C}_\alpha(x) - \mathcal{C}_\beta(x)| \mathrm{d}x \tag{2.37}$$

$$= \int_{\mathbb{R}} \left| \int_{-\infty}^x \mathrm{d}(\alpha - \beta) \right| \mathrm{d}x, \tag{2.38}$$

由此可知 $\mathcal{W}_1$ 是范数（推广到任意维数的情形见第 6.2 节）. 于是，一个满足 $T_\sharp \alpha = \beta$ 的最优 Monge 映射 T 定义为

$$T = \mathcal{C}_\beta^{-1} \circ \mathcal{C}_\alpha. \tag{2.39}$$

图 2.11 展示了通过累积分布函数计算一维最优传输的过程，同时展示了按式 (7.7) 计算的位移插值；另见注 9.6. 关于一维最优传输性质的详细综述，参见 (Santambrogio, 2015, 第 2 章).

注 2.31 (高斯分布之间的距离). 若 $\alpha = \mathcal{N}(\mathbf{m}_\alpha, \mathbf{\Sigma}_\alpha)$ 与 $\beta = \mathcal{N}(\mathbf{m}_\beta, \mathbf{\Sigma}_\beta)$ 是 $\mathbb{R}^d$ 中的

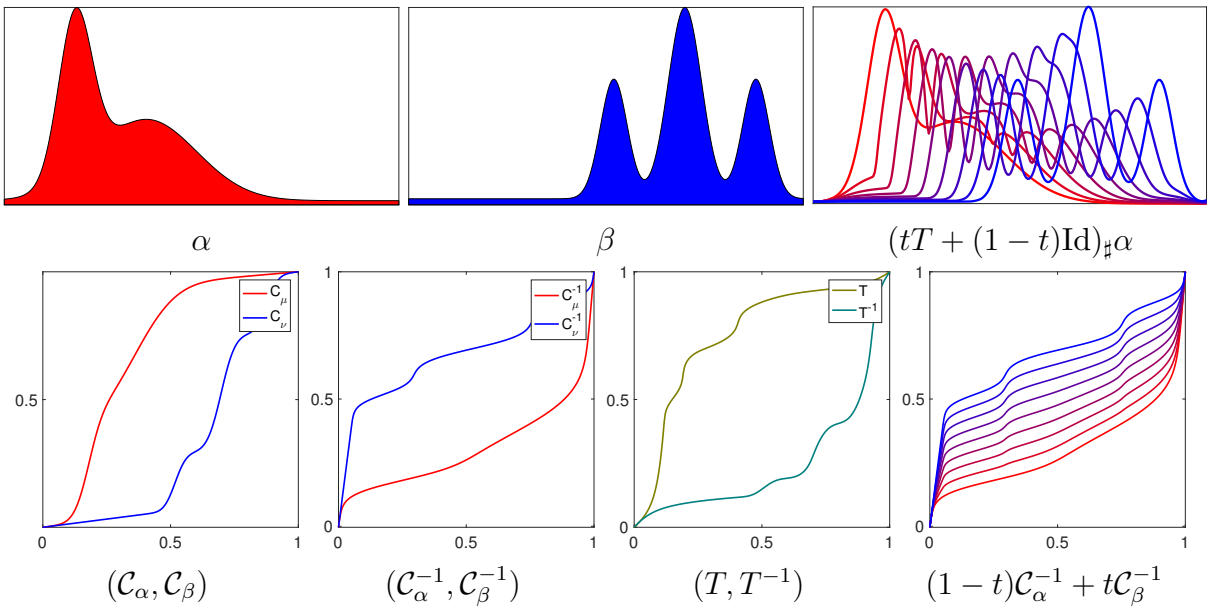

图 2.11: 利用累积分布函数计算两个一维测度之间的最优传输与位移插值，见式 (2.39).

两个高斯分布，则可以证明以下映射

$$T : x \mapsto \mathbf{m}_\beta + A(x - \mathbf{m}_\alpha), \tag{2.40}$$

其中

$$A = \boldsymbol{\Sigma}_\alpha^{-\frac{1}{2}} \left(\boldsymbol{\Sigma}_\alpha^{\frac{1}{2}} \boldsymbol{\Sigma}_\beta \boldsymbol{\Sigma}_\alpha^{\frac{1}{2}} \right)^{\frac{1}{2}} \boldsymbol{\Sigma}_\alpha^{-\frac{1}{2}} = A^{\mathrm{T}},$$

满足 $T_\sharp \rho_\alpha = \rho_\beta$. 事实上，只需注意变量替换公式 (2.8) 成立，因为

$$\begin{aligned}
\rho_\beta(T(x)) &= \det(2\pi\boldsymbol{\Sigma}_\beta)^{-\frac{1}{2}} \exp(-\langle T(x) - \mathbf{m}_\beta,\, \boldsymbol{\Sigma}_\beta^{-1}(T(x) - \mathbf{m}_\beta)\rangle) \\
&= \det(2\pi\boldsymbol{\Sigma}_\beta)^{-\frac{1}{2}} \exp(-\langle x - \mathbf{m}_\alpha,\, A^{\mathrm{T}}\boldsymbol{\Sigma}_\beta^{-1} A(x - \mathbf{m}_\alpha)\rangle) \\
&= \det(2\pi\boldsymbol{\Sigma}_\beta)^{-\frac{1}{2}} \exp(-\langle x - \mathbf{m}_\alpha,\, \boldsymbol{\Sigma}_\alpha^{-1}(x - \mathbf{m}_\alpha)\rangle),
\end{aligned}$$

且 T 是线性映射，故有

$$|\det T'(x)| = \det A = \left(\frac{\det \boldsymbol{\Sigma}_\beta}{\det \boldsymbol{\Sigma}_\alpha} \right)^{\frac{1}{2}}.$$

于是恢复 $\rho_\alpha = |\det T'| \rho_\beta$，即 $T_\sharp \alpha = \beta$. 再注意，T 是凸函数 $\psi : x \mapsto \frac{1}{2}\langle x - \mathbf{m}_\alpha,\, A(x - \mathbf{m}_\alpha)\rangle + \langle \mathbf{m}_\beta,\, x\rangle$ 的梯度，利用 Brenier 定理 (1991) (见注 2.24)，可知 T 是最优的. 此映射 T 及相应的势 ψ 分别如图 2.12、2.13 所示. 进一步计算 ρ_α 的一阶与二阶矩，得到此映射的传输代价

$$\mathcal{W}_2^2(\alpha, \beta) = \|\mathbf{m}_\alpha - \mathbf{m}_\beta\|^2 + \mathcal{B}(\boldsymbol{\Sigma}_\alpha, \boldsymbol{\Sigma}_\beta)^2, \tag{2.41}$$

其中 $\mathcal{B}$ 是正定矩阵之间的 Bures 度量 (1969) (另见 Forrester and Kieburg (2016))，

$$\mathcal{B}(\mathbf{\Sigma}_\alpha, \mathbf{\Sigma}_\beta)^2 \stackrel{\text{def.}}{=} \operatorname{tr}\left(\mathbf{\Sigma}_\alpha + \mathbf{\Sigma}_\beta - 2(\mathbf{\Sigma}_\alpha^{1/2}\mathbf{\Sigma}_\beta\mathbf{\Sigma}_\alpha^{1/2})^{1/2}\right), \tag{2.42}$$

其中 $\mathbf{\Sigma}^{1/2}$ 是矩阵平方根. 可以证明 $\mathcal{B}$ 是协方差矩阵上的距离，且 $\mathcal{B}^2$ 对其两个自变量是凸的. 当 $\mathbf{\Sigma}_\alpha = \operatorname{diag}(r_i)_i$ 与 $\mathbf{\Sigma}_\beta = \operatorname{diag}(s_i)_i$ 为对角矩阵时，Bures 度量就是 Hellinger 距离

$$\mathcal{B}(\mathbf{\Sigma}_\alpha, \mathbf{\Sigma}_\beta) = \left\|\sqrt{r} - \sqrt{s}\right\|_2.$$

因此，对一维高斯分布，$\mathcal{W}_2$ 是由高斯分布均值与标准差 $(\mathbf{m}, \sqrt{\mathbf{\Sigma}})$ 所表示的二维平面上的欧氏距离，如图 2.14 所示. 关于高斯分布 Wasserstein 几何的详细论述，参见 Takatsu (2011)；关于 Bures 度量的其他讨论，可查阅较新的文献 (Malagò et al., 2018; Bhatia et al., 2018). 此外，(Muzellec and Cuturi, 2018) 将该度量用于计算词的概率嵌入，(Shafieezadeh Abadeh et al., 2018) 利用它计算 Kalman 滤波的稳健推广，(Mallasto and Feragen, 2017) 则将它应用于再生核 Hilbert 空间中的协方差函数.

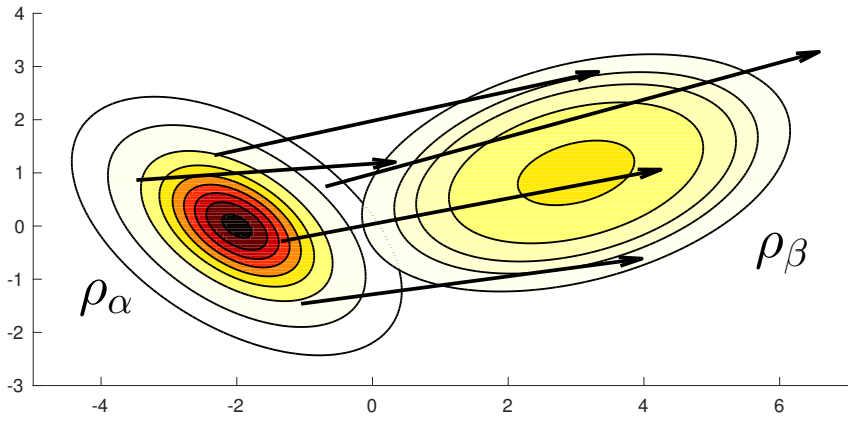

图 2.12: 两个高斯分布 ρ_α 与 ρ_β，以密度等高线表示，均值与协方差矩阵分别为 $\mathbf{m}_\alpha = (-2, 0)$、$\mathbf{\Sigma}_\alpha = \frac{1}{2}\left(1, -\frac{1}{2}; -\frac{1}{2}, 1\right)$ 及 $\mathbf{m}_\beta = (3, 1)$、$\mathbf{\Sigma}_\beta = \left(2, \frac{1}{2}; \frac{1}{2}, 1\right)$. 箭头起于平面上随机选取的点 x，终于其相应像 $T(x) = \mathbf{m}_\beta + A(x - \mathbf{m}_\alpha)$.

注 2.32 (椭圆等高线分布之间的距离). Gelbrich 给出了比注 2.31 更一般的结果：高斯分布之间的 Bures 度量可以推广到椭圆等高线分布 (1990). 简言之，首先可证明，对具有给定均值与协方差矩阵的两个测度，具有相应参数的两个高斯分布之间的距离，是这两个测度的 Wasserstein 距离的下界 (Gelbrich, 1990, 定理 2.1). 此外，闭式表达式 (2.41) 可推广到椭圆等高线密度族. 若两个密度 ρ_α 与 ρ_β 属于这样的密度

族，即对任意点 x，可用均值与正定参数写成

$$\rho_\alpha(x) = \frac{1}{\sqrt{\det(\mathbf{A})}} h(\langle x - \mathbf{m}_\alpha,\, \mathbf{A}^{-1}(x - \mathbf{m}_\alpha)\rangle),$$
$$\rho_\beta(x) = \frac{1}{\sqrt{\det(\mathbf{B})}} h(\langle x - \mathbf{m}_\beta,\, \mathbf{B}^{-1}(x - \mathbf{m}_\beta)\rangle),$$

其中两式使用相同的非负函数 h，且

$$\int_{\mathbb{R}^d} h(\langle x,\, x\rangle)\mathrm{d}x = 1,$$

则其最优传输映射仍是式 (2.40) 中的线性映射，Wasserstein 距离也仍由式 (2.41) 给出，只是 Bures 度量的缩放因子略有不同，且仅依赖于生成函数 h. 例如，高斯分布 $(h(t) = e^{-t/2})$ 的缩放因子为 1，椭球上的均匀分布 (h 是 $[0,1]$ 的示性函数) 的缩放因子为 $1/(d+2)$. 这一结果源于以下事实：椭圆分布的协方差矩阵是其正定参数的常数倍 (Gómez et al., 2003, 定理 4(ii))，而椭圆分布之间的 Wasserstein 距离是其协方差矩阵之间 Bures 距离的函数 (Gelbrich, 1990, 推论 2.5).

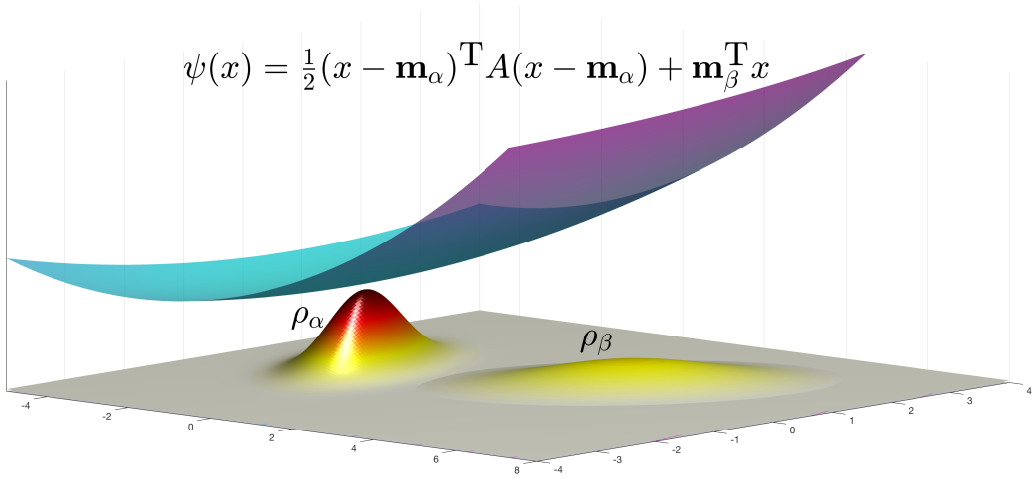

图 2.13: 图 2.12 中的相同高斯分布 ρ_α 与 ρ_β，此次以曲面表示. 上方曲面是 Brenier 势 ψ，它在相差一个加性常数的意义下确定（此处加 50），并满足 $T = \nabla\psi$. 为便于观察，两个高斯密度均放大了 100 倍.

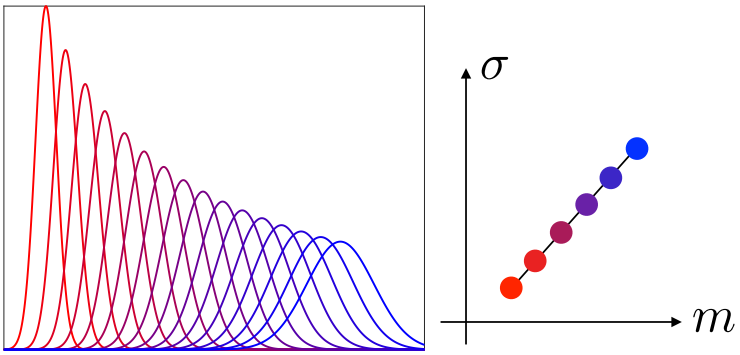

图 2.14: 两个一维高斯分布之间的位移插值计算. 以 $\mathcal{G}_{m,\sigma}(x) \overset{\text{def.}}{=} \frac{1}{\sqrt{2\pi}s} e^{-\frac{(x-m)^2}{2s^2}}$ 表示高斯密度，图中展示的插值为 $\mathcal{G}_{(1-t)m_0+tm_1,(1-t)\sigma_0+t\sigma_1}$.

Chapter 3

算法基础

本章介绍组合优化与线性规划中最常用的算法工具，它们可用于求解最优传输的离散形式，即原始问题 (2.11)，或者其对偶问题 (2.20).

这些算法的起源可以追溯到第二次世界大战：战前有 Tolstoı 的开创性工作 (1930)，战争期间则有 Hitchcock (1941) 和 Kantorovich (1942) 对一般资源最优调配问题的形式化，即以最优方式将现有资源送往各个消费地点. 这两种表述以及后来 Koopmans (1949) 的贡献，都没有给出一个可证明正确的求解算法（Tolstoı (1939) 已将循环违反方法作为启发式方法提出）. 直到线性规划领域充分发展、单纯形法问世，这些问题才终于有了严格的求解方法.

线性规划旨在求解目标函数为线性、约束为相关变量的线性等式或不等式的优化问题. 最优传输问题符合这一描述，因而是这类更广泛问题的特例. 不过，可以说最优传输在线性规划中确实十分特殊. 首先，Dantzig 早期求解线性规划的动机与求解运输问题密切相关 (Dantzig, 1949, p. 210). 其次，尽管只是一个特例，最优传输问题一直受到优化领域的关注：人们很快借助 Ford and Fulkerson (1962) 的结果认识到，最优传输问题与一类重要的线性规划——最小费用网络流——相关，实际上二者等价 (Korte and Vygen, 2012, p. 213, Lem. 9.3). 因此，从数学规划诞生之初起，OT 问题就受到特别关注 (Dantzig, 1951)，至今仍广泛用于向初学者介绍优化 (Nocedal and Wright, 1999, §1, p. 4).

3.1 Kantorovich 线性规划

我们已经在式 (2.11) 中介绍了原始 OT 问题：

$$\mathrm{L}_{\mathbf{C}}(\mathbf{a},\mathbf{b}) = \min_{\mathbf{P}\in\mathbf{U}(\mathbf{a},\mathbf{b})} \sum_{i\in[\![n]\!],j\in[\![m]\!]} \mathbf{C}_{i,j}\mathbf{P}_{i,j}. \tag{3.1}$$

为与线性规划文献建立联系，可以将上式写为标准形式的线性规划，即具有线性目标、由矩阵和常向量给出的等式约束以及变量非负约束的线性规划. 令 $\mathbb{I}_n$ 表示 n 阶单位矩阵，$\otimes$ 表示 Kronecker 积. 矩阵

$$\mathbf{A} = \begin{bmatrix} \mathbb{1}_n{}^{\mathrm{T}} \otimes \mathbb{I}_m \\ \mathbb{I}_n \otimes \mathbb{1}_m{}^{\mathrm{T}} \end{bmatrix} \in \mathbb{R}^{(n+m)\times nm}$$

可用于编码 $\mathbf{P}\in\mathbf{U}(\mathbf{a},\mathbf{b})$ 所须满足的行和与列和约束. 为此，只需将矩阵 $\mathbf{P}\in\mathbb{R}^{n\times m}$ 写成向量 $\mathbf{p}\in\mathbb{R}^{nm}$，使 $\mathbf{p}$ 的第 $i+n(j-1)$ 个元素等于 $\mathbf{P}_{ij}$（即按列枚举 $\mathbf{P}$），便有下述等价关系：

$$\mathbf{P}\in\mathbb{R}^{n\times m}\in\mathbf{U}(\mathbf{a},\mathbf{b}) \Leftrightarrow \mathbf{p}\in\mathbb{R}^{nm}_{+}, \quad \mathbf{A}\mathbf{p} = \begin{bmatrix}\mathbf{a}\\ \mathbf{b}\end{bmatrix}.$$

于是，原始最优传输问题可写为

$$\mathrm{L}_{\mathbf{C}}(\mathbf{a},\mathbf{b}) = \min_{\substack{\mathbf{p}\in\mathbb{R}_+^{nm} \\ \mathbf{A}\mathbf{p}=\left[\begin{smallmatrix}\mathbf{a}\\ \mathbf{b}\end{smallmatrix}\right]}} \mathbf{c}^{\mathrm{T}}\mathbf{p}, \tag{3.2}$$

其中 nm 维向量 $\mathbf{c}$ 由费用矩阵 $\mathbf{C}$ 的各列依次堆叠而成.

注 3.1. 上述 $n+m$ 个约束中有一个是冗余的；换言之，矩阵 A 的行向量并不线性无关. 事实上，前 n 行之和与后 m 行之和给出同一向量，即

$$A\left[\begin{smallmatrix}\mathbb{1}_n\\ \mathbb{0}_m\end{smallmatrix}\right] = A\left[\begin{smallmatrix}\mathbb{0}_n\\ \mathbb{1}_m\end{smallmatrix}\right] = \mathbb{1}_{nm}{}^{\mathrm{T}}.$$

可以证明，删去 A 的一行以及 $\left[\begin{smallmatrix}\mathbf{a}\\ \mathbf{b}\end{smallmatrix}\right]$ 的对应分量，会得到一个适当定义的线性系统. 为简单起见，并避免对 $\mathbf{a}$ 与 $\mathbf{b}$ 作不对称处理，下文仍保留冗余表述，同时牢记某些计算中会出现退化现象.

根据线性规划对偶性 (Bertsimas and Tsitsiklis, 1997, p. 143)，式 (3.2) 对应的对偶问题定义为

$$\mathrm{L}_{\mathbf{C}}(\mathbf{a},\mathbf{b}) = \max_{\substack{\mathbf{h}\in\mathbb{R}^{n+m} \\ A^{\mathrm{T}}\mathbf{h}\le\mathbf{c}}} \left[\begin{smallmatrix}\mathbf{a}\\ \mathbf{b}\end{smallmatrix}\right]^{\mathrm{T}}\mathbf{h}. \tag{3.3}$$

这一规划与式 (2.4) 给出的规划完全等价.

注 3.2. 下面给出上述对偶性结果的一个简单推导，它可视为注 2.21 中论证的直接表述. 强对偶性，即原始问题 (3.2) 与对偶问题 (3.3) 的最优值确实相等，需要较长的证明 (Bertsimas and Tsitsiklis, 1997, §4.10). 为简化记号，记 $\mathbf{q} = \left[\begin{smallmatrix}\mathbf{a}\\ \mathbf{b}\end{smallmatrix}\right]$. 考虑最优传输原始问题的一个松弛：不再强制约束 $\mathbf{A}\mathbf{p} = \mathbf{q}$，而是赋予它由任意费用向量 $\mathbf{h}\in\mathbb{R}^{n+m}$ 参数化的费用 $\mathbf{h}^{\mathrm{T}}(\mathbf{A}\mathbf{p}-\mathbf{q})$. 这一松弛的最优值直接依赖于费用向量 $\mathbf{h}$，可写为

$$\mathrm{H}(\mathbf{h}) \overset{\text{def.}}{=} \min_{\mathbf{p}\in\mathbb{R}_+^{nm}} \mathbf{c}^{\mathrm{T}}\mathbf{p} - \mathbf{h}^{\mathrm{T}}(\mathbf{A}\mathbf{p}-\mathbf{q}).$$

首先，这个松弛问题没有关于 $\mathbf{p}$ 的边缘约束. 由于最小化允许更多 $\mathbf{p}$ 作为候选解，我们预期 $\mathrm{H}(\mathbf{h})$ 小于 $\bar{z} = \mathrm{L}_{\mathbf{C}}(\mathbf{a},\mathbf{b})$. 事实上，令 $\mathbf{p}^\star$ 为原始问题 (3.1) 的任一最优解，则

$$\min_{\mathbf{p}\in\mathbb{R}_+^{nm}} \mathbf{c}^{\mathrm{T}}\mathbf{p} - \mathbf{h}^{\mathrm{T}}(\mathbf{A}\mathbf{p}-\mathbf{q}) \le \mathbf{c}^{\mathrm{T}}\mathbf{p}^\star - \mathbf{h}^{\mathrm{T}}(\mathbf{A}\mathbf{p}^\star-\mathbf{q}) = \mathbf{c}^{\mathrm{T}}\mathbf{p}^\star = \bar{z}.$$

因此，上述方法定义了一个问题，对任意费用向量 $\mathbf{h}$，它均可用于计算原始问题 (3.1) 的一个最优上界；这一函数称为 L 的 Lagrange 对偶函数 (Lagrange dual function). 对偶理论的目标是在任意费用向量 $\mathbf{h}$ 上最大化 H，从而计算最佳下界 $\underline{z}$，即

$$\underline{z} = \max_{\mathbf{h}} \left(\mathrm{H}(\mathbf{h}) = \max_{\mathbf{h}} \mathbf{h}^{\mathrm{T}}\mathbf{q} + \min_{\mathbf{p}\in\mathbb{R}_+^{nm}} (\mathbf{c} - A^{\mathrm{T}}\mathbf{h})^{\mathrm{T}}\mathbf{p} \right).$$

容易证明，只要 $\mathbf{c}^{\mathrm{T}} - A^{\mathrm{T}}\mathbf{h}$ 的任一分量为负，第二个涉及 $\mathbf{p}$ 的最小化项便为 $-\infty$. 例如，若某个指标 $i \le n+m$ 满足 $\mathbf{c}_i - (A^{\mathrm{T}}\mathbf{h})_i < 0$，只需取 $\mathbf{p}$ 为标准基向量 $\mathbf{e}_i$ 乘以任意

大的正数，即可得到无界的值. 因此，在最大化下界 $\mathrm{H}(\mathbf{h})$ 时，应将向量 $\mathbf{h}$ 限制为满足 $A^{\mathrm{T}}\mathbf{h} \leq \mathbf{c}$ 的向量，此时最佳下界成为

$$\underline{z} = \max_{\substack{\mathbf{h}\in\mathbb{R}^{n+m} \\ A^{\mathrm{T}}\mathbf{h}\leq\mathbf{c}}} \mathbf{h}^{\mathrm{T}}\mathbf{q}.$$

由此证明了弱对偶性，即 $\underline{z} \leq \bar{z}$.

3.2 C-变换

本节介绍最优传输对偶问题 (3.3) 的一个重要性质，在第 5.1 节的半离散最优传输问题中，它有更重要的意义. 本节以原始表述 (2.20) 为基础，按照行和与列和约束拆分对偶变量：

$$\mathrm{L}_{\mathbf{C}}(\mathbf{a}, \mathbf{b}) = \max_{(\mathbf{f},\mathbf{g})\in\mathbf{R}(\mathbf{C})} \langle \mathbf{f}, \mathbf{a}\rangle + \langle \mathbf{g}, \mathbf{b}\rangle. \tag{3.4}$$

考虑任意对偶可行对 $(\mathbf{f}, \mathbf{g})$. 若 “固定” $\mathbf{f}$ 的值，则 $\mathbf{g}$ 的最佳向量解就是 $\mathbf{f}$ 的 $\mathbf{C}$-变换（$\mathbf{C}$-transform）向量，记为 $\mathbf{f}^{\mathbf{C}} \in \mathbb{R}^m$，定义为

$$(\mathbf{f}^{\mathbf{C}})_j = \min_{i\in[\![n]\!]} \mathbf{C}_{ij} - \mathbf{f}_i,$$

因为容易证明 $(\mathbf{f}, \mathbf{f}^{\mathbf{C}}) \in \mathbf{R}(\mathbf{C})$，且 $\mathbf{f}^{\mathbf{C}}$ 是满足这一约束的最大向量. 因此

$$\langle \mathbf{f}, \mathbf{a}\rangle + \langle \mathbf{g}, \mathbf{b}\rangle \leq \langle \mathbf{f}, \mathbf{a}\rangle + \langle \mathbf{f}^{\mathbf{C}}, \mathbf{b}\rangle.$$

这一结果首先允许我们将对偶问题改写为仅用一个变量 $\mathbf{f}$ 表示的分段仿射凹最大化问题：

$$\mathrm{L}_{\mathbf{C}}(\mathbf{a}, \mathbf{b}) = \max_{\mathbf{f}\in\mathbb{R}^n} \langle \mathbf{f}, \mathbf{a}\rangle + \langle \mathbf{f}^{\mathbf{C}}, \mathbf{b}\rangle. \tag{3.5}$$

同理，若固定 $\mathbf{g}$ 的值，考虑 $\mathbf{g}$ 的 $\bar{\mathbf{C}}$-变换，即定义向量 $\mathbf{g}^{\bar{\mathbf{C}}} \in \mathbb{R}^n$ 为

$$(\mathbf{g}^{\bar{\mathbf{C}}})_i = \min_{j\in[\![m]\!]} \mathbf{C}_{ij} - \mathbf{g}_j,$$

便有另一种目标增大方式：

$$\langle \mathbf{f}, \mathbf{a}\rangle + \langle \mathbf{g}, \mathbf{b}\rangle \leq \langle \mathbf{g}^{\bar{\mathbf{C}}}, \mathbf{a}\rangle + \langle \mathbf{g}, \mathbf{b}\rangle.$$

因此，从给定 $\mathbf{f}$ 出发，很自然会尝试多次交替施行 $\mathbf{C}$ 与 $\bar{\mathbf{C}}$ 变换以改进 $\mathbf{f}$. 事实上，存在如下不等式链：

$$\langle \mathbf{f}, \mathbf{a}\rangle + \langle \mathbf{f}^{\mathbf{C}}, \mathbf{b}\rangle \leq \langle \mathbf{f}^{\mathbf{C}\bar{\mathbf{C}}}, \mathbf{a}\rangle + \langle \mathbf{f}^{\mathbf{C}}, \mathbf{b}\rangle \leq \langle \mathbf{f}^{\mathbf{C}\bar{\mathbf{C}}}, \mathbf{a}\rangle + \langle \mathbf{f}^{\mathbf{C}\bar{\mathbf{C}}\mathbf{C}}, \mathbf{b}\rangle \leq \dots$$

我们可能希望每次迭代都严格增大目标值. 然而，这并不可行，因为交替施行 $\mathbf{C}$ 与 $\bar{\mathbf{C}}$ 变换很快就会进入平台期.

命题 3.1. 下列关系成立，其中向量间的不等号按分量理解：

(i) $\mathbf{f} \le \mathbf{f}' \Rightarrow \mathbf{f}^{\mathbf{C}} \ge \mathbf{f}'^{\mathbf{C}}$.

(ii) $\mathbf{f}^{\mathbf{C}\bar{\mathbf{C}}} \ge \mathbf{f}$, $\mathbf{g}^{\bar{\mathbf{C}}\mathbf{C}} \ge \mathbf{g}$.

(iii) $\mathbf{f}^{\mathbf{C}\bar{\mathbf{C}}\mathbf{C}} = \mathbf{f}^{\mathbf{C}}$.

证明： 第一个不等式由 $\mathbf{C}$-变换的定义得到. 展开 $\mathbf{f}^{\mathbf{C}\bar{\mathbf{C}}}$ 的定义，有

$$(\mathbf{f}^{\mathbf{C}\bar{\mathbf{C}}})_i = \min_{j\in[\![m]\!]} \mathbf{C}_{ij} - \mathbf{f}^{\mathbf{C}}_j = \min_{j\in[\![m]\!]} \mathbf{C}_{ij} - \min_{i'\in[\![n]\!]} \mathbf{C}_{i'j} - \mathbf{f}_{i'}.$$

由于 $-\min_{i'\in[\![n]\!]} \mathbf{C}_{i'j} - \mathbf{f}_{i'} \ge -(\mathbf{C}_{ij} - \mathbf{f}_i)$，故

$$(\mathbf{f}^{\mathbf{C}\bar{\mathbf{C}}})_i \ge \min_{j\in[\![m]\!]} \mathbf{C}_{ij} - \mathbf{C}_{ij} + \mathbf{f}_i = \mathbf{f}_i.$$

同理得到 $\mathbf{g}^{\bar{\mathbf{C}}\mathbf{C}} \ge \mathbf{g}$. 现令 $\mathbf{g} = \mathbf{f}^{\mathbf{C}}$，则 $\mathbf{g}^{\bar{\mathbf{C}}} = \mathbf{f}^{\mathbf{C}\bar{\mathbf{C}}} \ge \mathbf{f}$. 由 (i) 得 $\mathbf{f}^{\mathbf{C}\bar{\mathbf{C}}\mathbf{C}} \le \mathbf{f}^{\mathbf{C}}$，而 (ii) 给出反向不等式 $\mathbf{f}^{\mathbf{C}\bar{\mathbf{C}}\mathbf{C}} \ge \mathbf{f}^{\mathbf{C}}$，故等式成立. □

3.3 互补松弛

原始问题 (3.2) 与对偶问题 (3.3)、(2.20) 可独立求解，得到原始最优解 $\mathbf{P}^\star$ 与对偶最优解 $(\mathbf{f}^\star, \mathbf{g}^\star)$. 下述命题刻画它们的关系.

命题 3.2. 令 $\mathbf{P}^\star$ 与 $\mathbf{f}^\star, \mathbf{g}^\star$ 分别为原始问题 (2.24) 与对偶问题 (2.11) 的最优解. 则对任意 $(i,j) \in [\![n]\!] \times [\![m]\!]$，有 $\mathbf{P}^\star_{i,j}(\mathbf{C}_{i,j} - \mathbf{f}^\star_i + \mathbf{g}^\star_j) = 0$. 换言之，若 $\mathbf{P}^\star_{i,j} > 0$，则必有 $\mathbf{f}^\star_i + \mathbf{g}^\star_j = \mathbf{C}_{i,j}$；若 $\mathbf{f}^\star_i + \mathbf{g}^\star_j < \mathbf{C}_{i,j}$，则必有 $\mathbf{P}^\star_{i,j} = 0$.

证明： 由强对偶性有 $\langle \mathbf{P}^\star, \mathbf{C}\rangle = \langle \mathbf{f}^\star, \mathbf{a}\rangle + \langle \mathbf{g}^\star, \mathbf{b}\rangle$. 注意 $\mathbf{P}^\star \mathbb{1}_m = \mathbf{a}$、$\mathbf{P}^{\star\mathrm{T}} \mathbb{1}_n = \mathbf{b}$，所以

$$\begin{aligned}\langle \mathbf{f}^\star, \mathbf{a}\rangle + \langle \mathbf{g}^\star, \mathbf{b}\rangle &= \langle \mathbf{f}^\star, \mathbf{P}^\star \mathbb{1}_m\rangle + \langle \mathbf{g}^\star, \mathbf{P}^{\star\mathrm{T}} \mathbb{1}_n\rangle \\ &= \langle \mathbf{f}^\star {\mathbb{1}_m}^{\mathrm{T}}, \mathbf{P}^\star\rangle + \langle \mathbb{1}_n \mathbf{g}^{\star\mathrm{T}}, \mathbf{P}^\star\rangle,\end{aligned}$$

从而 $\langle \mathbf{P}^\star, \mathbf{C} - \mathbf{f}^\star \oplus \mathbf{g}^\star\rangle = 0$. 由于 $(\mathbf{f}^\star, \mathbf{g}^\star)$ 属于对偶约束多面体 (2.21)，矩阵 $\mathbf{C} - \mathbf{f}^\star \oplus \mathbf{g}^\star$ 的各元素必非负. 又因 $\mathbf{P}$ 的所有元素非负，上述内积等于 0 就迫使：凡 $\mathbf{P}_{i,j} > 0$ 的指标对 (i,j) 均满足 $\mathbf{C}_{i,j} - (\mathbf{f}_i + \mathbf{g}_j) = 0$；凡 $\mathbf{C}_{i,j} > \mathbf{f}_i + \mathbf{g}_j$ 的指标对均满足 $\mathbf{P}_{i,j} = 0$. □

逆命题也成立. 先定义原始与对偶变量互补的概念.

定义 3.1. 若对所有满足 $\mathbf{P}_{i,j} > 0$ 的指标对 (i,j)，均有 $\mathbf{C}_{i,j} = \mathbf{f}_i + \mathbf{g}_j$，则称矩阵 $\mathbf{P} \in \mathbb{R}^{n\times m}$ 与向量对 $(\mathbf{f}, \mathbf{g})$ 关于 $\mathbf{C}$ *互补* (complementary).

若原始与对偶可行变量互补，则可断定它们最优.

命题 3.3. 若 $\mathbf{P}$ 与 $(\mathbf{f}, \mathbf{g})$ 互补，且分别为原始问题 (2.24) 与对偶问题 (2.11) 的可行解，则它们分别为原始与对偶最优解.

证明： 由弱对偶性，

$$\mathrm{L}_{\mathbf{C}}(\mathbf{a}, \mathbf{b}) \le \langle \mathbf{P}, \mathbf{C}\rangle = \langle \mathbf{P}, \mathbf{f} \oplus \mathbf{g}\rangle = \langle \mathbf{a}, \mathbf{f}\rangle + \langle \mathbf{b}, \mathbf{g}\rangle \le \mathrm{L}_{\mathbf{C}}(\mathbf{a}, \mathbf{b}).$$

故 $\mathbf{P}$ 与 $(\mathbf{f}, \mathbf{g})$ 分别为原始与对偶最优解. □

3.4 运输多胞形的顶点

回顾凸集的极点（extreme point）（或顶点）的正式定义：它是集合中的一点 $\mathbf{x}$，使得若集合中存在 $\mathbf{y}, \mathbf{z}$ 满足 $\mathbf{x} = (\mathbf{y} + \mathbf{z})/2$，则必有 $\mathbf{x} = \mathbf{y} = \mathbf{z}$. 具有非空有界可行集的线性规划在可行集的一个顶点（或极点）处达到最小值 (Bertsimas and Tsitsiklis, 1997, p. 65, Theo. 2.7). 原始最优传输问题 (3.2) 的可行集 $\mathbf{U}(\mathbf{a}, \mathbf{b})$ 有界，因此可将最优 $\mathbf{P}$ 的搜索限制在多胞形 $\mathbf{U}(\mathbf{a}, \mathbf{b})$ 的极点集合中. 这些极点矩阵 $\mathbf{P}$ 具有有趣的结构，已有大量研究 (Brualdi, 2006, §8). 描述这一结构需要借助二分图形式化运输问题.

3.4.1 $\mathbf{U}(\mathbf{a}, \mathbf{b})$ 所有顶点支撑的树结构

令 $V = (1, 2, \dots, n)$、$V' = (1', 2', \dots, m')$ 为两组节点. 给 V' 的标号添加撇号，是为了与 V 区分. 考虑有 $n + m$ 个节点的并集 $V \cup V'$，以及二者之间全部 nm 条有向边组成的集合 $\mathcal{E} = \{(i, j'), i \in [\![n]\!], j \in [\![m]\!]\}$. 这里给整数 $j \leq m$ 添加撇号，得到 V' 中的 j'. 为边 (i, j') 赋予费用 $\mathbf{C}_{ij}$. V 与 V' 之间的完全二分图 $\mathcal{G}$ 为 $(V \cup V', E)$. 传输方案是该图上满足源约束（节点 i 流出 $\mathbf{a}_i$）和汇约束（节点 j' 流入 $\mathbf{b}_j$）的流，如图 3.1 所示. $\mathbf{U}(\mathbf{a}, \mathbf{b})$ 的极点具有下述性质 (Brualdi, 2006, p. 338, Theo. 8.1.2).

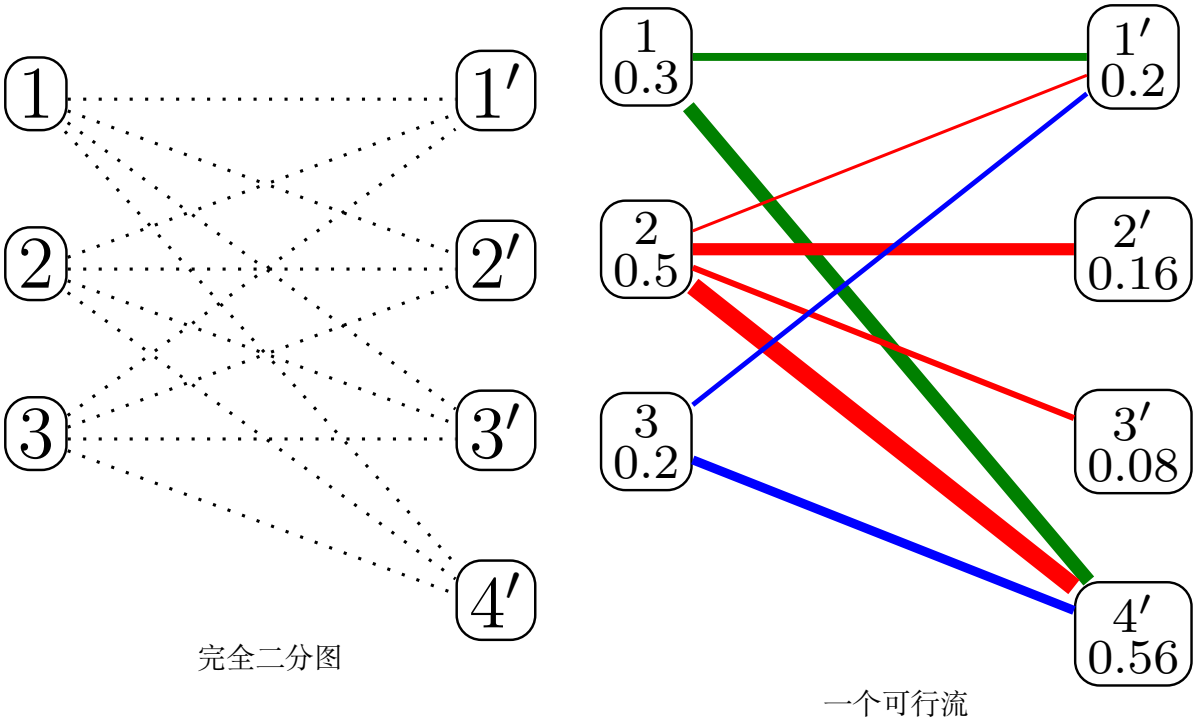

图 3.1: 作为二分网络流问题的最优传输. 这里 $n = 3, m = 4$. 源直方图 $\mathbf{a}$ 的各分量表示为左侧标号 $1, 2, 3$ 的源节点，目标直方图 $\mathbf{b}$ 的各分量表示为标号 $1', 2', 3', 4'$ 的节点. 图是二分的：每个源节点与每个目标节点相连，除此之外没有其他边. 每条边 (i, j') 对应费用 $\mathbf{C}_{ij}$. 右侧给出一个可行流. 命题 3.4 表明该流不是极点，因为它至少具有循环 $((1, 1'), (2, 1'), (2, 4'), (1, 4'))$.

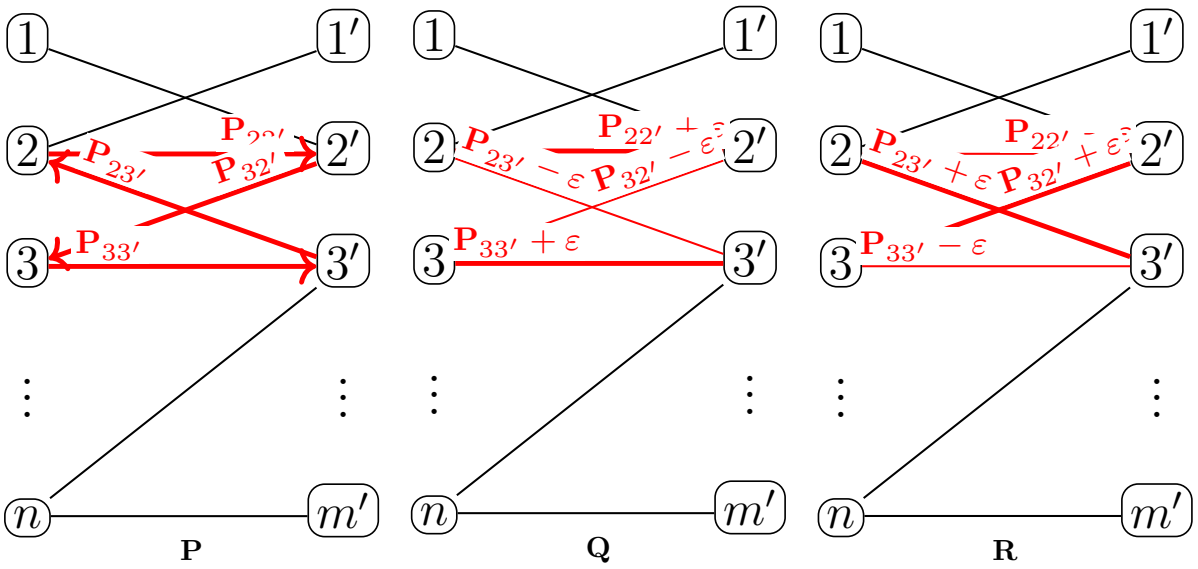

图 3.2: 若解 $\mathbf{P}$ 的支撑图含有循环，便可扰动它得到两个可行解 $\mathbf{Q}$ 与 $\mathbf{R}$，使 $\mathbf{P}$ 为二者的平均，从而证明 $\mathbf{P}$ 不是极点.

命题 3.4 (极点解)**.** 令 $\mathbf{P}$ 为多胞形 $\mathbf{U}(\mathbf{a},\mathbf{b})$ 的极点，$S(\mathbf{P}) \subset \mathcal{E}$ 为边子集 $\{(i,j'), i \in [\![n]\!], j \in [\![m]\!]$ 且$\mathbf{P}_{ij} > 0\}$. 则图 $G(\mathbf{P}) \overset{\text{def.}}{=} (V \cup V', S(\mathbf{P}))$ 不含循环. 特别地，$\mathbf{P}$ 的非零元素不超过 $n+m-1$ 个.

证明： 用反证法. 假设 $\mathbf{P}$ 是 $\mathbf{U}(\mathbf{a},\mathbf{b})$ 的极点，而相应边集 $S(\mathbf{P})$（简记为 F）使图 $G = (V \cup V', F)$ 含有循环. 即存在 $k > 1$ 及互异指标序列 $i_1, \ldots, i_{k-1} \in [\![n]\!]$、$j_1, \ldots, j_{k-1} \in [\![m]\!]$，使下列边集 H 为 F 的子集：

$$H = \{(i_1, j_1'), (i_2, j_1'), (i_2, j_2'), \ldots, (i_k, j_k'), (i_1, j_k')\}.$$

现构造两个可行矩阵 $\mathbf{Q}, \mathbf{R}$，使 $\mathbf{P} = (\mathbf{Q}+\mathbf{R})/2$. 考虑对应于 H 的有向循环 $\bar{H}$，即 $i_1 \to j_1', j_1' \to i_2, i_2 \to j_2', \ldots, i_k \to j_k', j_k' \to i_1$，以及基本流量 $\varepsilon < \min_{(i,j')\in F} \mathbf{P}_{ij}$. 构造扰动矩阵 $\mathbf{E}$：若 $i \to j' \in \bar{H}$，则其 (i,j) 元素为 ε；若 $j \to i' \in \bar{H}$，则为 $-\varepsilon$；否则为零. 令 $\mathbf{Q} = \mathbf{P} + \mathbf{E}$、$\mathbf{R} = \mathbf{P} - \mathbf{E}$，如图 3.2. 因 ε 足够小，$\mathbf{Q}, \mathbf{R}$ 的所有元素均非负. 按构造，$\mathbf{E}$ 的每行（相应地，每列）或者全为零，或者在标号 $i_1, \ldots, i_k$（相应地 $j_1, \ldots, j_k$）的行（列）上恰有一个 ε 和一个 $-\varepsilon$. 因此 $\mathbf{E}\mathbb{1}_m = \mathbb{0}_n$、$\mathbf{E}^{\mathrm{T}}\mathbb{1}_n = \mathbb{0}_m$，故 $\mathbf{Q}, \mathbf{R}$ 与 $\mathbf{P}$ 有相同边缘，都是可行的. 最后，$\mathbf{P} = (\mathbf{Q}+\mathbf{R})/2$ 且 $\mathbf{Q}, \mathbf{R} \neq \mathbf{P}$，与 $\mathbf{P}$ 为极点矛盾. 有 k 个节点的无循环图不超过 $k-1$ 条边，故 $S(\mathbf{P})$ 不超过 $n+m-1$ 条边，$\mathbf{P}$ 的非零元素也不超过 $n+m-1$ 个. □

3.4.2 西北角法则

西北角法则（north-west corner rule）（NW）是一种启发式方法，它在至多 $n+m$ 次操作内产生多胞形 $\mathbf{U}(\mathbf{a},\mathbf{b})$ 的一个顶点. 它可用于初始化任何在原始问题上工作的算法，例如下一节介绍的网络单纯形法. 法则首先令 $\mathbf{P}_{1,1} = \min(\mathbf{a}_1, \mathbf{b}_1)$，赋予它尽可能大的值. 每步选取 $\mathbf{P}_{i,j}$，使第 i 行约束、第 j 列约束，或可能时二者同时饱和. 随后更新

指标：第一种情形增加 i，第二种情形增加 j，第三种情形同时增加二者. 如此继续，直到 $\mathbf{P}_{n,m}$ 获得一个值. 形式上，算法如下：初始化 $i=j=1$，$r\leftarrow \mathbf{a}_1, c\leftarrow \mathbf{b}_1$. 当 $i\le n$ 且 $j\le m$ 时，令 $t\leftarrow \min(r,c)$、$\mathbf{P}_{i,j}\leftarrow t$、$r\leftarrow r-t$、$c\leftarrow s-t$；若 $r=0$，则增加 i，并在 $i\le n$ 时更新 $r\leftarrow \mathbf{a}_i$；若 $c=0$，则增加 j，并在 $j\le n$ 时更新 $c\leftarrow \mathbf{b}_j$；重复. 以下为 $\mathbf{a}=[0.2,0.5,0.3]$、$\mathbf{b}=[0.5,0.1,0.4]$ 的示例：

$$\begin{bmatrix}\bullet & 0 & 0\\ 0 & 0 & 0\\ 0 & 0 & 0\end{bmatrix}\to\begin{bmatrix}0.2 & 0 & 0\\ \bullet & 0 & 0\\ 0 & 0 & 0\end{bmatrix}\to\begin{bmatrix}0.2 & 0 & 0\\ 0.3 & \bullet & 0\\ 0 & 0 & 0\end{bmatrix}$$
$$\to\begin{bmatrix}0.2 & 0 & 0\\ 0.3 & 0.1 & \bullet\\ 0 & 0 & 0\end{bmatrix}\to\begin{bmatrix}0.2 & 0 & 0\\ 0.3 & 0.1 & 0.1\\ 0 & 0 & \bullet\end{bmatrix}\to\begin{bmatrix}0.2 & 0 & 0\\ 0.3 & 0.1 & 0.1\\ 0 & 0 & 0.3\end{bmatrix}.$$

记这一启发式方法所得唯一方案为 $\mathbf{NW}(\mathbf{a},\mathbf{b})$. 不过，若先任意置换 $\mathbf{a},\mathbf{b}$ 的顺序，计算对应西北角表，再逆置换行列恢复 $\mathbf{U}(\mathbf{a},\mathbf{b})$ 中的表，便可得到更多西北角解. 取 $\sigma=(3,1,2),\sigma'=(3,2,1)$，得 $\mathbf{a}_\sigma=[0.3,0.2,0.5],\mathbf{b}_{\sigma'}=[0.4,0.1,0.5]$，以及 $\sigma^{-1}=(2,3,1),\sigma'=(3,2,1)$. 注意

$$\mathbf{NW}(\mathbf{a}_\sigma,\mathbf{b}_{\sigma'})=\begin{bmatrix}0.3 & 0 & 0\\ 0.1 & 0.1 & 0\\ 0 & 0 & 0.5\end{bmatrix}\in\mathbf{U}(\mathbf{a}_\sigma,\mathbf{b}_{\sigma'}),$$
$$\mathbf{NW}_{\sigma^{-1}\sigma'^{-1}}(\mathbf{a}_\sigma,\mathbf{b}_{\sigma'})=\begin{bmatrix}0 & 0.1 & 0.1\\ 0.5 & 0 & 0\\ 0 & 0 & 0.3\end{bmatrix}\in\mathbf{U}(\mathbf{a},\mathbf{b}).$$

令 $\mathcal{N}(\mathbf{a},\mathbf{b})$ 为这样产生的所有西北角解的集合：

$$\mathcal{N}(\mathbf{a},\mathbf{b})\overset{\text{def.}}{=}\{\mathbf{NW}_{\sigma^{-1}\sigma'^{-1}}(r_\sigma,c_{\sigma'}),\sigma,\sigma'\in S_d\}.$$

按构造，每个西北角解最多有 $n+m-1$ 个非零元素. 对给定 $\mathbf{a}_\sigma,\mathbf{b}'_\sigma$，西北角法则产生唯一的表，但可能有指数多个行列置换对 (σ,σ') 产生同一个表 (Stougie, 2002, p. 2). $\mathcal{N}(\mathbf{a},\mathbf{b})$ 是 $\mathbf{U}(\mathbf{a},\mathbf{b})$ 极点集的子集，通常是真子集 (Brualdi, 2006, Cor. 8.1.4).

3.5 网络单纯形法的启发式描述

考虑可行矩阵 $\mathbf{P}$，其图 $G(\mathbf{P})=(V\cup V',S(\mathbf{P}))$ 不含循环. 因此 $\mathbf{P}$ 至多有 $n+m-1$ 个非零元素，并由命题 3.4 为 $\mathbf{U}(\mathbf{a},\mathbf{b})$ 的顶点. 根据命题 3.3，只需得到一个可行（即 $\mathbf{C}-\mathbf{f}\oplus\mathbf{g}$ 的元素非负）且与 $\mathbf{P}$ 互补（即 $S(\mathbf{P})$ 中的 (i,j') 满足 $\mathbf{C}_{i,j}=\mathbf{f}_i+\mathbf{g}_j$）的对偶解 $(\mathbf{f},\mathbf{g})$，即可证明 $\mathbf{P}$ 最优. 网络单纯形法（network simplex）依赖两个简单原则：每个可行原始解 $\mathbf{P}$ 都可关联一个互补对 $(\mathbf{f},\mathbf{g})$. 若该对可行，则达到最优；否则，可修改 $\mathbf{P}$，使其仍然可行，并相应改变互补对 $(\mathbf{f},\mathbf{g})$，使之更接近可行性.

3.5.1 求取与 P 互补的对偶对

单纯形法首先将任一极点解 $\mathbf{P}$ 与一对互补对偶变量 $(\mathbf{f},\mathbf{g})$ 关联. 只需找出两个向量 $\mathbf{f},\mathbf{g}$，使每个 $(i,j')\in S(\mathbf{P})$ 均满足 $\mathbf{f}_i+\mathbf{g}_j=\mathbf{C}_{i,j}$. 这本身并不保证 $(\mathbf{f},\mathbf{g})$ 可行. 令 s 为

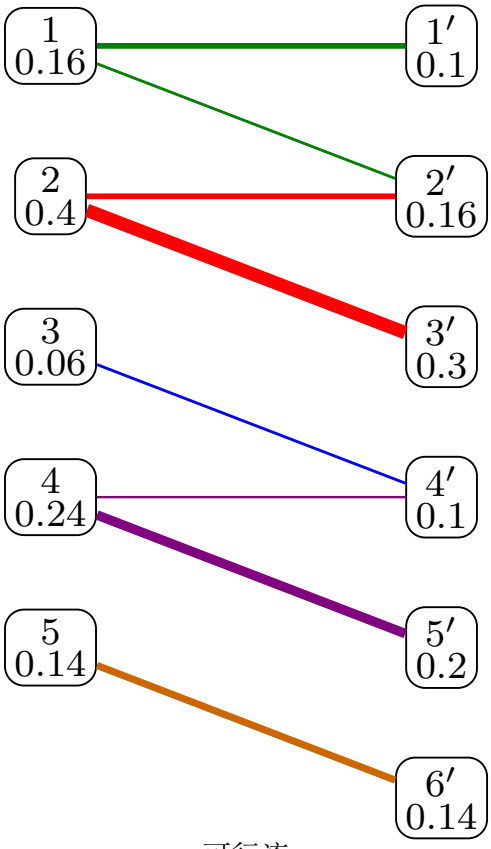

可行流

$$F(\mathbf{P})=\{\{1,1'\},\{1,2'\},\{2,2'\},\{2,3'\},\{3,4'\},\{4,4'\},\{4,5'\},\{5,6'\}\}.$$

$$G(\mathbf{P})=\{(\{1,2,1',2',3'\},\{\{1,1'\},\{1,2'\},\{2,2'\},\{2,3'\}\}),(\{3,4,4',5'\},\{\{3,4'\},\{4,4'\},\{4,5'\}\}),(\{5,6'\},\{\{5,6'\}\})\}.$$

图 3.3: 一个可行传输 $\mathbf{P}$ 及其相应边集 $S(\mathbf{P})$ 与图 $G(\mathbf{P})$. 图 $G(\mathbf{P})=(\{1,\dots,5,1',\dots,6'\},S(\mathbf{P}))$ 是森林，即若干树图的并；本例中有三棵树.

$S(\mathbf{P})$ 的基数. 因 $\mathbf{P}$ 为极点，$s\le n+m-1$. 由于 $G(\mathbf{P})$ 无循环，它是一棵树或一片森林（若干树的并），如图 3.3. 为求与 $\mathbf{P}$ 互补的 $(\mathbf{f},\mathbf{g})$，考虑关于 $n+m$ 个变量的以下 s 个线性等式约束：

$$\begin{aligned}\mathbf{f}_{i_1}+\mathbf{g}_{j_1}&=\mathbf{C}_{i_1,j_1}\\ \mathbf{f}_{i_2}+\mathbf{g}_{j_1}&=\mathbf{C}_{i_2,j_1}\\ \vdots\quad&=\quad\vdots\\ \mathbf{f}_{i_s}+\mathbf{g}_{j_s}&=\mathbf{C}_{i_s,j_s},\end{aligned}\tag{3.6}$$

其中将 $S(\mathbf{P})$ 的元素枚举为 $(i_1,j_1'),\dots,(i_s,j_s')$. 由于 $s\le n+m-1<n+m$，线性系统 (3.6) 总是欠定的. 这种退化的一部分来自：以 $n+m$ 个约束参数化 $\mathbf{U}(\mathbf{a},\mathbf{b})$，产生了 $n+m$ 个对偶变量. 注 3.1 所述更细致的表述只含 $n+m-1$ 个约束，因而只有 $n+m-1$ 个对偶变量. 然而，s 也可能严格小于 $n+m-1$：当 $G(\mathbf{P})$ 是两棵或更多树的不交并时即如此. 例如图 3.3 有 $5+6=11$ 个对偶变量（每节点一个），但 11 个节点之间只有 8 条边，即用来定义 $(\mathbf{f},\mathbf{g})$ 的 8 个线性方程. 因此，此时未确定对偶变量的数目等于 $G(\mathbf{P})$

的连通分支数. 考虑 $G(\mathbf{P})$ 中的一棵树. 假设它有 k 个源节点 $i_1,\dots,i_k$ 和 l 个目标节点 $j'_1,\dots,j'_l$，共 $r \overset{\text{def.}}{=} k+l$ 个节点、$r-1$ 条边. 对应 $\mathbf{f}$ 中 k 个变量、$\mathbf{g}$ 中 l 个变量，它们由 $r-1$ 个线性方程联系. 为消除不确定性，可任意选一个根节点，将其对应对偶变量设为 0. 随后用广度优先或深度优先搜索遍历树，通过一连串简单变量赋值确定其余所有对偶变量，如图 3.4. 对 $\mathbf{P}$ 的图中所有树重复这一过程，即得与 $\mathbf{P}$ 互补的 $(\mathbf{f},\mathbf{g})$.

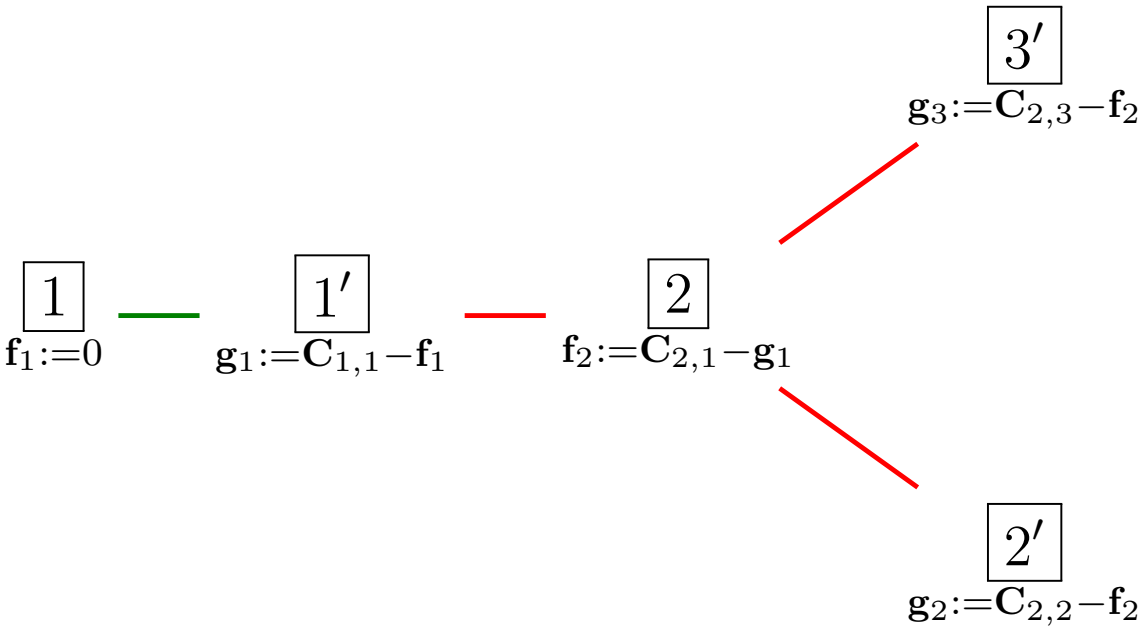

图 3.4: 图 3.3 的 $G(\mathbf{P})$ 第一棵树中，五个节点对应五个对偶变量 $\mathbf{f}_1,\mathbf{f}_2,\mathbf{g}_1,\mathbf{g}_2,\mathbf{g}_3$，它们由涉及费用矩阵 $\mathbf{C}$ 对应元素的四个线性方程联系. 因系统退化，选一个根（本例为节点 1），将对应变量设为 0，再由根出发广度优先或深度优先遍历，逐次得到其余四个对偶变量.

3.5.2 网络单纯形更新

此前所得 $(\mathbf{f},\mathbf{g})$ 可能可行，即所有 i,j 均满足 $\mathbf{f}_i+\mathbf{g}_j \le \mathbf{C}_{i,j}$；此时由命题 3.3 已达到最优. 若非如此，即存在 i,j 满足 $\mathbf{f}_i+\mathbf{g}_j > \mathbf{C}_{i,j}$，则启动网络单纯形算法. 先令图 G 等于可行解 $\mathbf{P}$ 的图 $G(\mathbf{P})$，再向 G 加入违反约束的边 (i,j'). 有两种情形：

(a) G 仍是森林. 当 (i,j') 连接两棵原有子树时可能如此. 用第 3.5.1 节方法从图 G 恢复新的互补对偶向量 $(\mathbf{f},\mathbf{g})$. 这一加边仅消除 $n+m$ 个对偶变量中的一个不确定性，并不改变原始变量 $\mathbf{P}$. 这种更新通常称为退化更新，因为 (i,j') 进入了图 G，但 $\mathbf{P}_{i,j}$ 仍为 0. 不过 $G(\mathbf{P})$ 包含于 G.

(b) G 出现循环. 此时须移去 G 中一条边，使它仍为森林，同时修改 $\mathbf{P}$，保持 $\mathbf{P}$ 可行且 $G(\mathbf{P})$ 仍包含于 G. 可通过增大 $\mathbf{P}_{i,j}$ 并修改所检测循环中的其他元素完成这些操作，其方式与命题 3.4 的证明十分相似. 具体地，将循环写作 $(i_1,j'_1),(j'_1,i_2),(i_2,j'_2),\dots,(i_l,j'_l),(j'_l,i_{l+1})$，约定 $i_1=i_{l+1}=i$，使循环从 i 出发并返回 i；另令 $j_1=j$，强调循环首先沿正方向通过新边 $\{i,j\}$. 增大所有“正”边 (i_k,j'_k) $(k\le l)$

的流，减小所有“负”边 (j'_k, i_{k+1})（$k \le l$）的流，得到原始更新解 $\tilde{\mathbf{P}}$，它除下列元素外均与 $\mathbf{P}$ 相同：

$$\forall k \le l, \quad \tilde{\mathbf{P}}_{i_k,j_k} := \mathbf{P}_{i_k,j_k} + \theta; \quad \tilde{\mathbf{P}}_{i_{k+1},j_k} := \mathbf{P}_{i_{k+1},j_k} - \theta.$$

这里 θ 是沿该循环在 (i,j) 处允许的最大增量，其值由循环中受到负向影响的最小流 $\min_k \mathbf{P}_{i_{k+1},j_k}$ 控制. 图 3.5 展示了这一更新. 令 $k^\star$ 为达到该最小值的指标. 最后从 G 移除 $(i_{k^\star+1}, j_{k^\star})$，再用第 3.5.1 节方法计算新的 $(\mathbf{f}, \mathbf{g})$.

3.5.3 原始解的改进

虽然未必是最初动机，但可以证明上述操作只能改进 $\mathbf{P}$ 的费用. 若加入的边不产生循环，即情形 (a)，原始解不变. 若产生循环，即情形 (b)，将 $\mathbf{P}$ 更新为 $\tilde{\mathbf{P}}$，有

$$\langle \tilde{\mathbf{P}}, \mathbf{C} \rangle - \langle \mathbf{P}, \mathbf{C} \rangle = \theta \left(\sum_{k=1}^{l} \mathbf{C}_{i_k,j_k} - \sum_{k=1}^{l} \mathbf{C}_{i_{k+1},j_k} \right).$$

现使用前次迭代末计算出的对偶向量 $(\mathbf{f}, \mathbf{g})$. 对最初在 G 中的所有边，它们满足 $f_{i_k} + g_{i_k} = \mathbf{C}_{i_k,j_k}$、$f_{i_{k+1}} + g_{i_k} = \mathbf{C}_{i_{k+1},j_k}$，从而

$$\begin{aligned} \sum_{k=1}^{l} \mathbf{C}_{i_k,j_k} - \sum_{k=1}^{l} \mathbf{C}_{i_{k+1},j_k} &= \mathbf{C}_{i,j} + \sum_{k=2}^{l} \mathbf{f}_{i_k} + \mathbf{g}_{j_k} - \sum_{k=1}^{l} \mathbf{f}_{i_{k+1}} + \mathbf{g}_{j_k} \\ &= \mathbf{C}_{i,j} - (\mathbf{f}_i + \mathbf{g}_j). \end{aligned}$$

按定义这一项为负，因为选取 i, j 的原因是 $C_{i,j} < \mathbf{f}_i - \mathbf{g}_j$. 因此，若 $\theta > 0$，则

$$\langle \tilde{\mathbf{P}}, \mathbf{C} \rangle = \langle \mathbf{P}, \mathbf{C} \rangle + \theta \, (\mathbf{C}_{i,j} - (\mathbf{f}_i - \mathbf{f}_g)) < \langle \mathbf{P}, \mathbf{C} \rangle.$$

若 $\theta = 0$（当 G 与 $G(\mathbf{P})$ 不同时可能如此），则仅改变图 G，而不改变 $\mathbf{P}$. 因此，网络单纯形算法可概括如下. 用第 3.4.2 节的西北角法则所得极点解 $\mathbf{P}$ 初始化算法，令 $G = G(\mathbf{P})$，并按第 3.5.1 节利用 G 的树结构求解线性系统，得到与 $\mathbf{P}$ 互补的 $(\mathbf{f}, \mathbf{g})$.

(i) 寻找违反 $\mathbf{C} - \mathbf{f} \oplus \mathbf{g} \ge 0$ 的指标对；若不存在，则 $\mathbf{P}$ 最优，停止.

(ii) 若存在违反约束的 (i, j')，将该边加入 G. 若 G 仍无循环，则相应更新 $(\mathbf{f}, \mathbf{g})$；若出现循环，则为它定向，使 (i, j') 为正边，移去循环中流最小的负边，按图 3.5 更新 $\mathbf{P}, G$，并相应构造互补对 $\mathbf{f}, \mathbf{g}$；返回第一步.

上述操作涉及循环检测、树遍历等图操作，可在此背景下高效实现 (Bertsekas, 1998, §5). Orlin (1997) 首次证明网络单纯形法的多项式时间复杂度. 随后 Tarjan (1997) 借助更高效的数据结构选择枢轴边，给出改进上界 $O\big((n+m)nm \log(n+m) \log((n+m)\|\mathbf{C}\|_\infty)\big)$.

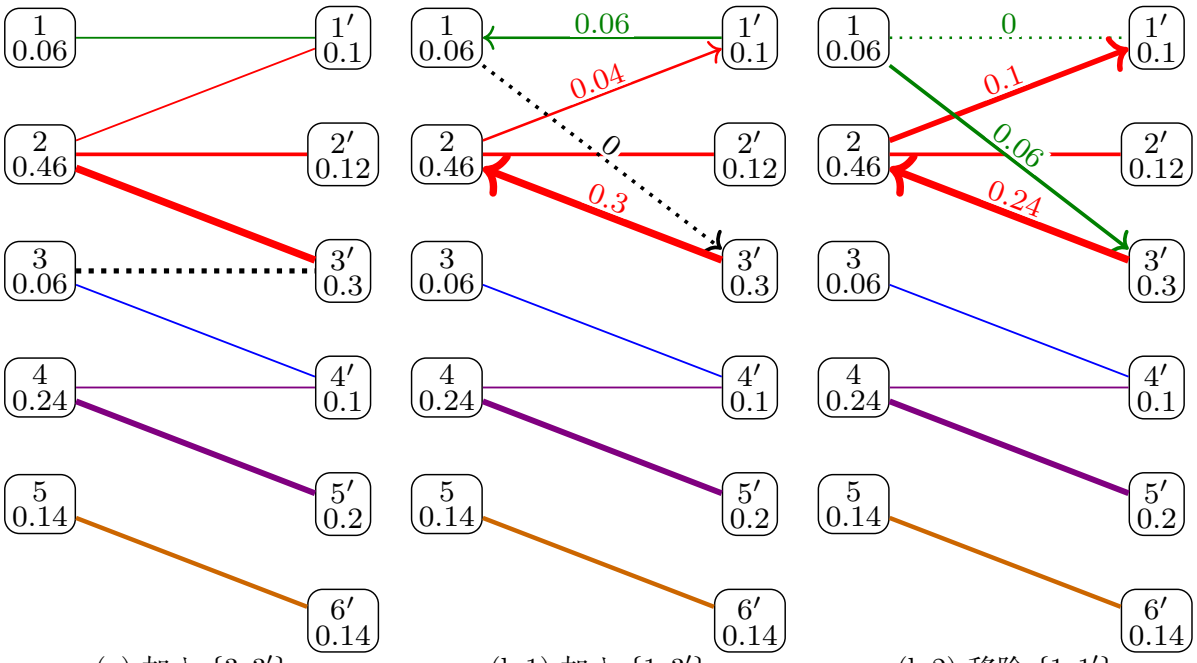

(a) 加入 $\{3, 3'\}$　(b.1) 加入 $\{1, 3'\}$　(b.2) 移除 $\{1, 1'\}$

图 3.5: 向 $G(\mathbf{P})$ 加入边 $\{i, j\}$ 可能产生两种结果：(a) 加边后仍为森林，可按第 3.5.1 节方法重新计算 $\mathbf{f}, \mathbf{g}$；(b.1) 加边产生循环，由此定义有向路径；(b.2) 利用该路径增大 $\mathbf{P}_{i,j}$，并沿循环传播改变量以保持流的可行性，直到某条边的流降至 0，此时可将该边移去，使图再次成为森林.

3.6 对偶上升方法

对偶上升方法比网络单纯形法早数十年，可追溯到 Borchardt and Jocobi (1865) 以及后来 König 和 Egerváry 的工作，其历史见 Kuhn (1955). 这一类中最著名的是匈牙利算法，它只能用于 $\mathbf{a}, \mathbf{b}$ 相等且均匀的特殊情形，即 $\mathbf{a} = \mathbf{b} = \mathbb{1}_n/n$. 下文简要描述更一般的对偶上升（dual ascent）方法，需用到最大流问题的知识 (Bertsimas and Tsitsiklis, 1997, §7.5). 与上述作用于原始问题的网络单纯形法不同，对偶上升方法每次迭代都保持对偶解可行，通过向 $\mathbf{f}, \mathbf{g}$ 添加稀疏向量逐步改善目标值. 本节主要依据 (Bertsimas and Tsitsiklis, 1997, §7.7)，从以下定义开始.

定义 3.2. 对 $S \subset [\![n]\!], S' \subset [\![m]\!]' \overset{\text{def.}}{=} \{1', \ldots, m'\}$，记 $\mathbb{1}_S \in \mathbb{R}^n$ 为除 S 中指标分量为 1 外均为 0 的向量；同样定义 $\mathbb{1}_{S'} \in \mathbb{R}^m$，其非零指标位于 S'.

下文 $(\mathbf{f}, \mathbf{g})$ 是 $\mathbf{R}(\mathbf{C})$ 中的可行对偶对，即对所有 $(i, j') \in [\![n]\!] \times [\![m]\!]'$，$\mathbf{f}_i + \mathbf{g}_j \leq \mathbf{C}_{ij}$. 若等号成立，称 (i, j') 为平衡边（balanced edge）（或平衡对）；否则即严格小于，称其为非活跃边. 采用这一约定，先给出一个简单结果，说明如何用由 S, S' 索引的稀疏向量扰动可行 $(\mathbf{f}, \mathbf{g})$，同时保持可行性.

命题 3.5. 若对所有 $i \in S$，(i, j') 平衡都蕴含 $j' \in S'$，则对充分小的 $\varepsilon > 0$，$(\tilde{\mathbf{f}}, \tilde{\mathbf{g}}) \overset{\text{def.}}{=} (\mathbf{f}, \mathbf{g}) + \varepsilon(\mathbb{1}_S, -\mathbb{1}_{S'})$ 对偶可行.

证明： 对任意 $i \in S$，令 $\mathcal{I}_i$ 为使 (i, j') 非活跃的所有 $j' \in [\![m]\!]'$ 的集合，即 $\mathbf{f}_i + \mathbf{g}_j < \mathbf{C}_{ij}$.

定义 $\varepsilon_i \overset{\text{def.}}{=} \min_{j\in I_i} \mathbf{C}_{i,j} - \mathbf{f}_i - \mathbf{g}_j$，这是增大 $\mathbf{f}_i$ 而不违反 $j' \in \mathcal{I}_i$ 对应约束所允许的最小余量. 确实，若 $\varepsilon \le \varepsilon_i$，则任意 $j' \in \mathcal{I}_i$ 均满足 $\tilde{\mathbf{f}}_i + \tilde{\mathbf{g}}_j < \mathbf{C}_{i,j}$. 再考虑与 i 关联的平衡边集 $\mathcal{B}_i = [\![m]\!]' \setminus \mathcal{I}_i$. 假设给出 $j' \in \mathcal{B}_i \Rightarrow j' \in S'$，故这些边满足 $\tilde{\mathbf{f}}_i + \tilde{\mathbf{g}}_j = \mathbf{f}_i + \mathbf{g}_j = \mathbf{C}_{i,j}$. 因此所有 $j \in [\![m]\!]'$ 均满足 $\tilde{\mathbf{f}}_i + \tilde{\mathbf{g}}_j \le \mathbf{C}_{i,j}$. 选增量 ε 小于所有允许增量的最小值 $\min_{i\in S} \varepsilon_i$，即得 $(\tilde{\mathbf{f}}, \tilde{\mathbf{g}})$ 对偶可行. □

第 3.5.1 节网络单纯形迭代的主要动机，是从可行原始解 $\mathbf{P}$ 得到互补且可行的对偶对 $(\mathbf{f}, \mathbf{g})$. 为此，逐步修改 $\mathbf{P}$，直到其互补对偶对达到对偶可行性. 对偶上升方法则由对称思路驱动：从可行对偶变量出发，获得可行原始解 $\mathbf{P}$. 下述命题是这一方法的主要推动力，因为它构造性地保证存在保持可行性的 $(\mathbf{f}, \mathbf{g})$ 上升方向. 类似网络单纯形法，通过设计候选原始解 $\mathbf{P}$，用其不可行性指导 $(\mathbf{f}, \mathbf{g})$ 的更新来构造方向.

命题 3.6. *要么 $(\mathbf{f}, \mathbf{g})$ 是问题 (3.4) 的最优解，要么存在 $S \subset [\![n]\!], S' \subset [\![m]\!]'$，使充分小的 $\varepsilon > 0$ 下，$(\tilde{\mathbf{f}}, \tilde{\mathbf{g}}) \overset{\text{def.}}{=} (\mathbf{f}, \mathbf{g}) + \varepsilon(\mathbb{1}_S, -\mathbb{1}_{S'})$ 可行且目标值严格改善.*

证明： 首先考虑与 $(\mathbf{f}, \mathbf{g})$ 互补的原始变量 $\mathbf{P}$. 令 $\mathcal{B}$ 为平衡边集，即满足 $\mathbf{f}_i + \mathbf{g}_j = \mathbf{C}_{i,j}$ 的所有 $(i, j') \in [\![n]\!] \times [\![m]\!]'$. 构造仅用 $\mathcal{B}$ 中的边连接节点 $\{1, \dots, n, 1', \dots, m'\}$ 的二分图，再添加源节点 s，用容量分别为 $\mathbf{a}_i$ 的有容量限制的边连接所有 $i \in [\![n]\!]$；添加终节点 t，用容量分别为 $\mathbf{b}_j$ 的边连接所有 $j' \in [\![m]\!]'$，如图 3.6. Ford–Fulkerson 算法 (Bertsimas and Tsitsiklis, 1997, p. 305) 可计算该网络的最大流 $\mathbf{F}$：一族 $n + m + |\mathcal{B}|$ 个非负值 $f_{si} \le \mathbf{a}_i, f_{ij'}, f_{j't} \le \mathbf{b}_j$（其中 $(i, j') \in \mathcal{B}$），满足流约束并使 $\sum_i f_{si}$ 最大. 若总流量等于 1，令 $(i, j') \in \mathcal{B}$ 时 $\mathbf{P}_{i,j} = f_{ij'}$，其他位置为零，即可从 $\mathbf{F}$ 提取一个按构造与 $\mathbf{f}, \mathbf{g}$ 互补的可行原始解 $\mathbf{P}$；命题 3.3 保证二者均最优. 若 $\mathbf{F}$ 的总流量严格小于 1，标号算法从 s 开始，迭代标记（识别）$\mathbf{F}$ 未使容量饱和的可达节点，以及向已标号节点输送流的节点. 将标号节点存入非空集合 Q；由 $\mathbf{F}$ 的最优性，终节点 t 不属于 Q（严格算法说明见 Bertsimas and Tsitsiklis 1997, p. 308）. 将 Q 拆为 $S = Q \cap [\![n]\!]$、$S' = Q \cap [\![m]\!]'$. 因总流量严格小于 1，$S \ne \emptyset$. 若 $i \in S$ 且 (i, j) 平衡，则必有 $j' \in S'$：按构造所有 (i, j') 的容量无限，故标号算法若将 i 加入 S，必然也到达 j'. 由命题 3.5，存在足够小的 ε 使 $\tilde{\mathbf{f}}, \tilde{\mathbf{g}}$ 可行. 还须证明 $\mathbb{1}_S{}^{\mathrm{T}}\mathbf{a} - \mathbb{1}_{S'}{}^{\mathrm{T}}\mathbf{b} > 0$，以确保新对目标值更好. 令 $\bar{S} = [\![n]\!] \setminus S$、$\bar{S}' = [\![m]\!]' \setminus S'$，定义

$$A = \sum_{i\in S} f_{si}, \quad B = \sum_{i\in \bar{S}} f_{si}, \quad C = \sum_{j'\in S'} f_{j't}, \quad D = \sum_{j'\in \bar{S}'} f_{j't}.$$

最大流从 s 出发，故为 $A + B$；到达 t，故也为 $C + D$. 流守恒约束还要求同一个流等于 $B + C$，所以 $A = C$. 另一方面，按标号算法定义，对所有 $i \in S$ 有 $f_{si} < \mathbf{a}_i$，而对 $j' \in \bar{S}'$ 有 $f_{j't} = \mathbf{b}_j$，因为所考虑流最优，t 不能在 S' 中. 因此 $A < \mathbb{1}_S{}^{\mathrm{T}}\mathbf{a}$，$C = \mathbb{1}'_S{}^{\mathrm{T}}\mathbf{b}$. 所以 $\mathbb{1}_S{}^{\mathrm{T}}\mathbf{a} - \mathbb{1}'_S{}^{\mathrm{T}}\mathbf{b} > A - C = 0$. □

对偶上升方法用由 S, S' 生成、保持可行性且改善目标值的向量修改任意可行解 $(\mathbf{f}, \mathbf{g})$. 当 S, S' 由命题 3.6 的证明构造，而步长 ε 按命题 3.5 的证明定义时，就得到所谓*原始–对偶方法*（primal-dual method）. 对匹配问题，该方法化为匈牙利算法. 对偶上升方法与网络单纯形的对偶变体相似，但至少有两点重要差异. 单纯形类方法始终保证当前解是可行集的*极点*（对偶可行集为 $\mathbf{R}(\mathbf{C})$）；这里的对偶上升没有这一假设，可以自由产生位于可行集内部的迭代点. 此外，对偶网络单纯形修改 $(\mathbf{f}, \mathbf{g})$，产生满足线性边

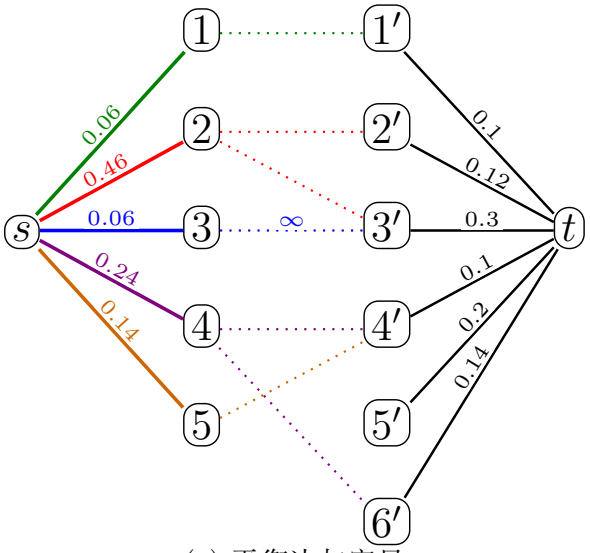

(a) 平衡边与容量

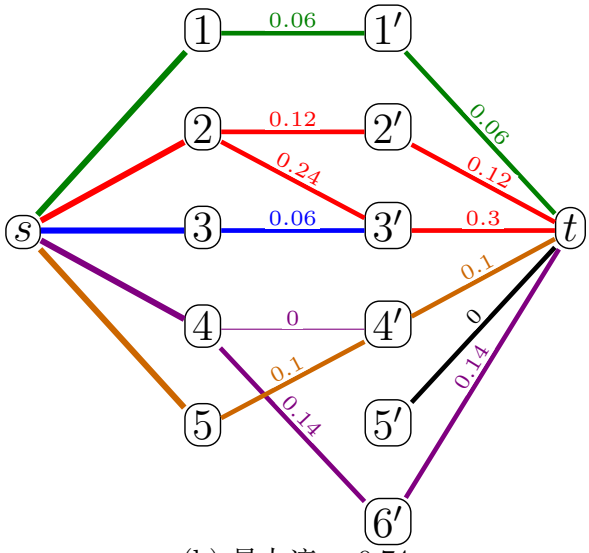

(b) 最大流 $= 0.74$

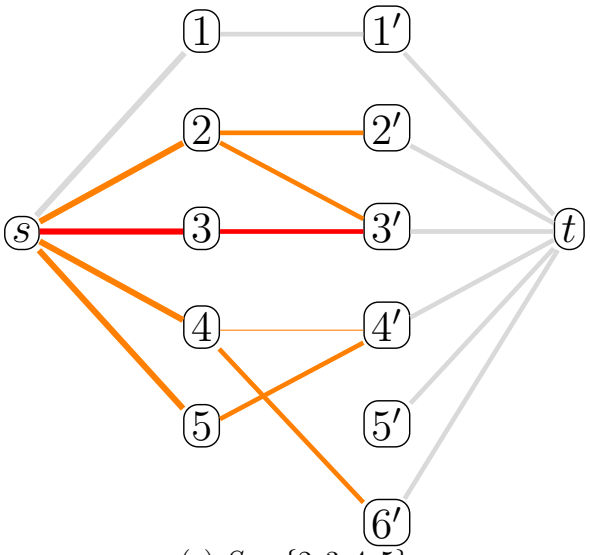

(c) $S = \{2, 3, 4, 5\}$
$S' = \{2', 3', 4', 6'\}$

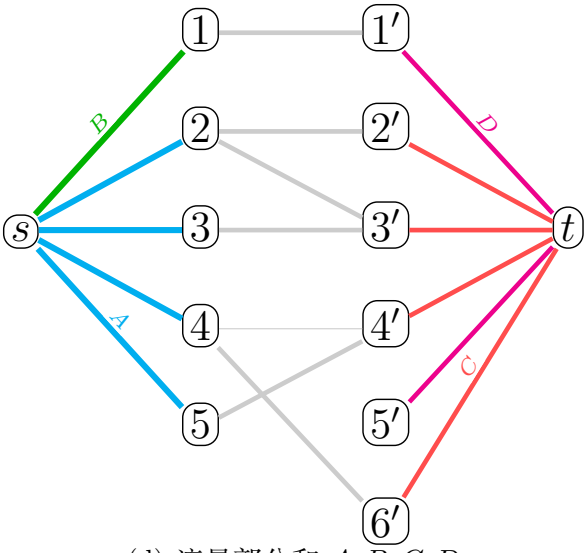

(d) 流量部分和 A, B, C, D

图 3.6: 考虑边缘为图 3.3 首次引入的边缘、$n = 5, m = 6$ 的运输问题. 给定可行对偶向量 $\mathbf{f}, \mathbf{g}$，尝试求与它们互补的 "最佳" 流矩阵 P，即 $\mathbf{P}$ 只能在 $\mathbf{f}_i + \mathbf{g}_j = \mathbf{C}_{i,j}$ 的边 (i, j') 上取正值，(a) 中用虚线表示. 在这一图结构下，最佳流可写为有容量网络中的最大流问题: 抽象源 s 连接所有 $i \in [\![n]\!]$，抽象终节点 t 连接所有 j'，其中 $j \in [\![m']\!]$; 边 $(s, i), (j', t)$ 的容量分别为 $\mathbf{a}_i, \mathbf{b}_j$，其他边容量无限. Ford–Fulkerson 算法 (Bertsimas and Tsitsiklis, 1997, p. 305) 算得的最大流，如 (b)，仅为所需单位质量中的 0.74. 最大流算法的子程序标号算法 (Bertsimas and Tsitsiklis, 1997, p. 308) 可识别从 s 接收未饱和流的节点以及递归得到的所有后继，(c) 中以橙色表示. 算法还默认添加向已标号节点发送正流的节点; 节点 3 正是因向 $3'$ 贡献红色流而被选中. 将标号节点分组为 S, S'，便可识别可进一步利用的节点，通过修改 $\mathbf{f}, \mathbf{g}$ 得到不同的图并提高流量. 证明涉及 (d) 中的流量部分和.

缘约束、仅在收敛时满足非负性的原始解 $\mathbf{P}$；对偶上升构造的 $\mathbf{P}$ 始终非负，却未必满足边缘约束.

3.7 拍卖算法

拍卖算法（auction algorithm）最初由 Bertsekas (1981) 提出，后在 (Bertsekas and Eckstein, 1988) 中改进. 已有人提出多种经济学解释，例如 Bertsekas (1992). 算法可推广至任意边缘，这里介绍其求解最优指派问题的形式.

互补松弛. 在最优指派问题中，最优传输的原始–对偶条件更易表述，因为任意极点解 $\mathbf{P}$ 必为某个 σ 的置换矩阵 $\mathbf{P}_\sigma$（见式 (3.3)）. 给定原始最优解 $\mathbf{P}_{\sigma^\star}$ 与对偶最优解 $\mathbf{f}^\star, \mathbf{g}^\star$，必有

$$\mathbf{f}^\star_i + \mathbf{g}^\star_{\sigma^\star_i} = \mathbf{C}_{i,\sigma^\star_i}.$$

由第 3.2 节的 $\mathbf{C}$-变换原理，可取 $\mathbf{f}^\star = \mathbf{g}^{\bar{\mathbf{C}}}$，因此

$$\mathbf{C}_{i,\sigma^\star_i} - \mathbf{g}^\star_{\sigma_i} = \min_j \mathbf{C}_{i,j} - \mathbf{g}^\star_j. \tag{3.7}$$

反之，容易证明，若存在向量 $\mathbf{g}$ 与置换 σ 满足

$$\mathbf{C}_{i,\sigma_i} - \mathbf{g}_{\sigma_i} = \min_j \mathbf{C}_{i,j} - \mathbf{g}_j, \tag{3.8}$$

则它们均最优：σ 为最优指派，$\mathbf{g}^{\bar{\mathbf{C}}}, \mathbf{g}$ 为最优对偶对.

部分指派与 ε-互补松弛. 拍卖算法旨在迭代修改三元组 $S, \xi, \mathbf{g}$，其中 $S \subset [\![n]\!]$，ξ 为部分指派向量，即从 S 到 $[\![n]\!]$ 的单射，$\mathbf{g}$ 为对偶向量. 对偶向量旨在收敛至满足近似互补松弛性质 (3.8) 的解，S 则扩张至覆盖 $[\![n]\!]$，而 ξ 描述一个置换. 算法每次迭代后保持以下三个性质：

(a) $\forall i \in S,\quad \mathbf{C}_{i,\xi_i} - \mathbf{g}_{\xi_i} \le \varepsilon + \min_j \mathbf{C}_{i,j} - \mathbf{g}_j$（$\varepsilon$-CS）.

(b) 每次迭代中 S 的大小只能增加.

(c) 存在指标 i 使 $\mathbf{g}_i$ 至少减小 ε.

拍卖算法更新. 给定一点 j，拍卖算法不仅使用通常 $\mathbf{C}$-变换中的最优值，还使用次优值：

$$j_i^1 \in \operatorname{argmin}_j \mathbf{C}_{i,j} - \mathbf{g}_j, \quad j_i^2 \in \operatorname{argmin}_{j \neq j_i^1} \mathbf{C}_{i,j} - \mathbf{g}_j.$$

对 $i \notin S$，由此定义 $\mathbf{g}$ 以及 S, ξ 的以下更新：

1. **更新 $\mathbf{g}$：** 从 $\mathbf{g}$ 的第 j_i^1 个分量减去 ε 与调整费用 $\{\mathbf{C}_{i,j}-\mathbf{g}_j\}_j$ 的次小值和最小值之差的和，

$$\begin{aligned}\mathbf{g}_{j_i^1} &\leftarrow \mathbf{g}_{j_i^1} - \underbrace{\big((\mathbf{C}_{i,j_i^2}-\mathbf{g}_{j_i^2})-(\mathbf{C}_{i,j_i^1}-\mathbf{g}_{j_i^1})+\varepsilon\big)}_{\geq\varepsilon>0} \\ &= \mathbf{C}_{i,j_i^1}-(\mathbf{C}_{i,j_i^2}-\mathbf{g}_{j_i^2})-\varepsilon.\end{aligned} \tag{3.9}$$

2. **更新 S,ξ：** 若存在 $i'\in S$ 满足 $\xi_{i'}=j_i^1$，则令 $S\leftarrow S\setminus\{i'\}$ 将其移除. 令 $\xi_i=j_i^1$，并将 i 加入 S，即 $S\leftarrow S\cup\{i\}$.

算法性质. 算法从空指派点集 $S=\emptyset$、无指派的空部分指派向量 ξ 与 $\mathbf{g}=\mathbb{0}_n$ 开始，循环执行以上两步，直到 $S=[\![n]\!]$ 时终止. 每次迭代后性质 (b)、(c) 成立，由更新形式直接可见（只需看式 (3.9)）. 首次迭代易于满足 ε-互补松弛，因为此时 $S=\emptyset$. 下述命题说明迭代保持这一性质.

命题 3.7. *拍卖算法在每次迭代中保持 ε-互补松弛.*

证明： 令 $\mathbf{g},\xi,S$ 为某次迭代开始时的三个变量，假设任意 $i'\in S$ 满足

$$\mathbf{C}_{i,\xi_{i'}}-\mathbf{g}_{\xi_{i'}}\leq\varepsilon+\min_j\mathbf{C}_{i',j}-\mathbf{g}_j.$$

考虑这次迭代选定的 $i\notin S$. 使用 j_i^1,j_i^2 将 $\mathbf{g},\xi,S$ 分别更新为 $\mathbf{g}^{\mathrm{n}},\xi^{\mathrm{n}},S^{\mathrm{n}}$. 更具体地，$\mathbf{g}^{\mathrm{n}}$ 除分量 j_i^1 外均等于 $\mathbf{g}$，该分量为

$$\mathbf{g}^{\mathrm{n}}_{j_i^1}=\mathbf{g}_{j_i^1}-\big((\mathbf{C}_{i,j_i^2}-\mathbf{g}_{j_i^2})-(\mathbf{C}_{i,j_i^1}-\mathbf{g}_{j_i^1})\big)-\varepsilon\leq\mathbf{g}_{j_i^1}-\varepsilon.$$

ξ^{n} 除第 i 个元素等于 j_i^1 外均等于 ξ；S^{n} 为 S 与 $\{i\}$ 的并，可能先移除一个元素. $\mathbf{g}^{\mathrm{n}}$ 的更新可写为

$$\mathbf{g}^{\mathrm{n}}_{j_i^1}=\mathbf{C}_{i,j_i^1}-(\mathbf{C}_{i,j_i^2}-\mathbf{g}_{j_i^2})-\varepsilon,$$

所以

$$\mathbf{C}_{i,j_i^1}-\mathbf{g}^{\mathrm{n}}_{j_i^1}=\varepsilon+(\mathbf{C}_{i,j_i^2}-\mathbf{g}_{j_i^2})=\varepsilon+\min_{j\neq j_i^1}(\mathbf{C}_{i,j}-\mathbf{g}_j).$$

因 $-\mathbf{g}\leq-\mathbf{g}^{\mathrm{n}}$，故

$$\mathbf{C}_{i,j_i^1}-\mathbf{g}^{\mathrm{n}}_{j_i^1}=\varepsilon+\min_{j\neq j_i^1}(\mathbf{C}_{i,j}-\mathbf{g}_j)\leq\varepsilon+\min_{j\neq j_i^1}(\mathbf{C}_{i,j}-\mathbf{g}^{\mathrm{n}}_j).$$

而 $j=j_i^1$ 时不等式显然成立，故指标 i 满足 ε-互补松弛. 对其余 $i'\neq i$，由 $\mathbf{g}^{\mathrm{n}}\leq\mathbf{g}$ 再得

$$\begin{aligned}\mathbf{C}_{i,\xi^{\mathrm{n}}_{i'}}-\mathbf{g}^{\mathrm{n}}_{\xi^{\mathrm{n}}_{i'}} &= \mathbf{C}_{i,\xi_{i'}}-\mathbf{g}_{\xi_{i'}} \\ &\leq\varepsilon+\min_j\mathbf{C}_{i',j}-\mathbf{g}_j\leq\varepsilon+\min_j\mathbf{C}_{i',j}-\mathbf{g}^{\mathrm{n}}_j.\end{aligned}$$

□

命题 3.8. 拍卖算法步数至多为 $N = n\|\mathbf{C}\|_\infty/\varepsilon$.

证明： 假设算法在 $T > N$ 步后仍未停止，则存在不在 ξ 的像中的指标 j，其价格分量 $\mathbf{g}_j$ 从未更新，仍为 0. 此时不可能有某个 j' 的 $\mathbf{g}_{j'}$ 已被更新 n 次且 $n > \|\mathbf{C}\|_\infty/\varepsilon$. 否则，对任意 i，

$$\mathbf{g}_{j'} \le -n\varepsilon < -\|\mathbf{C}\|_\infty \le -\mathbf{C}_{i,j} = \mathbf{g}_j - \mathbf{C}_{i,j},$$

从而对所有 i，

$$\mathbf{C}_{i,j'} - \mathbf{g}_{j'} > \mathbf{C}_{i,j} + (\mathbf{C}_{i,j} - \mathbf{g}_j),$$

与 ε-CS 矛盾. 因每个变量更新不超过 $\|C\|_\infty/\varepsilon$ 次，总迭代数 T 不超过 $n\|\mathbf{C}\|_\infty/\varepsilon = N$. □

注 3.3. 这一结果给出算法终止所需操作数的朴素上界 $N^3\|\mathbf{C}\|_\infty/\varepsilon$. 使用称为 ε-缩放（ε-scaling）的巧妙方法，逐次迭代降低 ε，可将复杂度降为 $N^3 \log \|\mathbf{C}\|_\infty$ (Bertsekas, 1998, p. 264).

命题 3.9. 拍卖算法找到的指派费用与最优值的差至多为 $n\varepsilon$.

证明： 令 $\sigma, \mathbf{g}^\star$ 为矩阵 $\mathbf{C}$ 指派问题的原始和对偶最优解，最优值为

$$t^\star = \sum \mathbf{C}_{i,\sigma_i} = \sum_i \min_j \mathbf{C}_{i,j} - \mathbf{g}_j^\star + \sum_j \mathbf{g}_j^\star.$$

令 $\xi, \mathbf{g}$ 为拍卖算法终止时的输出解. ε-CS 给出对任意 $i \in S$，

$$\min_j \mathbf{C}_{i,j} - \mathbf{g}_j \ge \mathbf{C}_{i,\xi_i} - \mathbf{g}_{\xi_i} - \varepsilon.$$

于是首先由 $\mathbf{g}$ 的次优性，有

$$\begin{aligned} t^\star &\ge \sum_i \left(\min_j \mathbf{C}_{i,j} - \mathbf{g}_j \right) + \sum_j \mathbf{g}_j \\ &\ge \sum_i -\varepsilon + (\mathbf{C}_{i,\xi_i} - \mathbf{g}_{\xi_i}) + \sum_j \mathbf{g}_j = -n\varepsilon + \sum_i \mathbf{C}_{i,\xi_j} \ge -n\varepsilon + t^\star. \end{aligned}$$

第二个不等式来自 ε-CS，随后等式来自 $\mathbf{g}_{\xi_i}$ 与 $\mathbf{g}_j$ 各项之和的抵消，最后不等式来自置换 ξ 的次优性. □

因此，拍卖算法可看作使用 $\mathbf{C}$-变换机制的另一种方式. 接下来探讨以正则化为基础的另一种方法，即 Sinkhorn 算法；它也与拍卖算法相似，讨论见 (Schmitzer, 2016b). 最后，在欧氏空间的低维规则网格上，可以将这些经典线性求解器与多尺度策略结合，以显著加速 (Schmitzer, 2016a; Oberman and Ruan, 2015).

Chapter 4

最优传输的熵正则化

本章介绍一类数值方法，用于近似求解最优传输的 Kantorovich 形式及其众多推广. 其做法是在原问题中加入熵正则化（entropic regularization）惩罚项. 这种正则化具有若干重要优势，综合起来使它成为十分有用的工具：正则化问题可以通过简单的交替最小化方法求解；相应迭代只是矩阵与向量的乘积，因此特别适合在 GPU 上执行；在某些应用中，无须存储 $n \times m$ 代价矩阵，只需能够计算核函数；当大量测度具有相同支撑时，所有矩阵与向量的乘积都可以组织为矩阵乘积，从而显著加速；所得近似距离关于输入直方图的权重和 Dirac 质量的位置是光滑的，并可用自动微分求导.

4.1 熵正则化

耦合矩阵的离散熵（discrete entropy）定义为

$$\mathbf{H}(\mathbf{P}) \stackrel{\text{def.}}{=} -\sum_{i,j} \mathbf{P}_{i,j}(\log(\mathbf{P}_{i,j}) - 1), \tag{4.1}$$

向量的定义与此类似，并约定：如果 $\mathbf{a}$ 的某个分量 $\mathbf{a}_j$ 为零或负数，则 $\mathbf{H}(\mathbf{a}) = -\infty$. 函数 $\mathbf{H}$ 是 1-强凹的，因为其 Hessian 为 $\partial^2\mathbf{H}(P) = -\operatorname{diag}(1/\mathbf{P}_{i,j})$，且 $\mathbf{P}_{i,j} \leq 1$. 最优传输熵正则化的思想是以 $-\mathbf{H}$ 为正则化函数，得到原传输问题 (2.11)的近似解：

$$\mathrm{L}_{\mathbf{C}}^{\varepsilon}(\mathbf{a}, \mathbf{b}) \stackrel{\text{def.}}{=} \min_{\mathbf{P} \in \mathbf{U}(\mathbf{a},\mathbf{b})} \langle \mathbf{P}, \mathbf{C} \rangle - \varepsilon \mathbf{H}(\mathbf{P}). \tag{4.2}$$

由于目标函数是 ε-强凸的，问题 (4.2)具有唯一最优解. 用熵项正则化最优传输的思想可以追溯到传输理论中的建模工作 (Wilson, 1969)：网络中的实际交通模式与最优传输解预测的模式并不一致. 实际交通更为分散，而由于 (2.11)的最优耦合具有稀疏性，预测结果往往只采用少数路径. 为缓解这种稀疏性，交通研究者提出了称为“引力”模型的模型 (Erlander, 1980)，使给定边缘分布和传输代价下的交通预测更为“模糊”.

图 4.1展示熵对单纯形 Σ_3 上线性规划的正则化作用（该单纯形可以在二维空间中画成三角形）. 注意，熵使原线性规划的解离开三角形边界. 最优解 $\mathbf{P}_\varepsilon$ 逐渐向三角形的“熵中心”移动. 下面的命题将进一步阐明这一点. Cominetti and San Martín (1994) 研究了正则化问题的解向原线性规划最优解的收敛，并给出精确渐近分析.

命题 4.1 (关于 ε 的收敛性)**.** 问题 (4.2)的唯一解 $\mathbf{P}_\varepsilon$ 收敛到 Kantorovich 问题所有最优解中熵最大的最优解，即

$$\mathbf{P}_\varepsilon \xrightarrow{\varepsilon \to 0} \operatorname*{argmin}_{\mathbf{P}} \{-\mathbf{H}(\mathbf{P}) \ : \ \mathbf{P} \in \mathbf{U}(\mathbf{a}, \mathbf{b}), \langle \mathbf{P}, \mathbf{C} \rangle = \mathrm{L}_{\mathbf{C}}(\mathbf{a}, \mathbf{b}), \} \tag{4.3}$$

因而特别有

$$\mathrm{L}_{\mathbf{C}}^{\varepsilon}(\mathbf{a}, \mathbf{b}) \xrightarrow{\varepsilon \to 0} \mathrm{L}_{\mathbf{C}}(\mathbf{a}, \mathbf{b}).$$

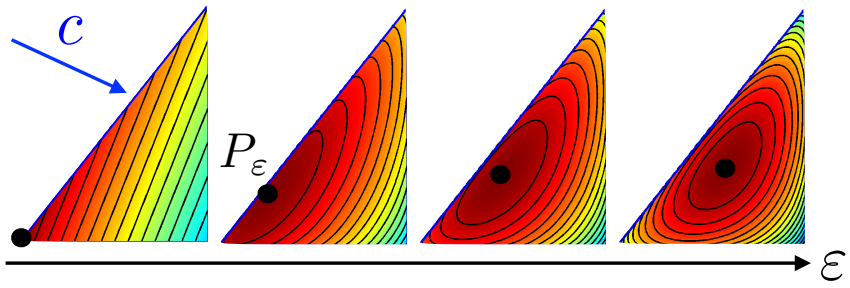

图 4.1: ε 对单纯形上线性函数优化的影响：改变 ε，求解 $\mathbf{P}_\varepsilon = \mathrm{argmin}_{\mathbf{P}\in\Sigma_3}\langle \mathbf{C}, \mathbf{P}\rangle - \varepsilon\mathbf{H}(\mathbf{P})$.

此外还有

$$\mathbf{P}_\varepsilon \overset{\varepsilon\to\infty}{\longrightarrow} \mathbf{a}\otimes\mathbf{b} = \mathbf{a}\mathbf{b}^{\mathrm{T}} = (\mathbf{a}_i\mathbf{b}_j)_{i,j}. \tag{4.4}$$

证明： 考虑满足 $\varepsilon_\ell \to 0$ 且 $\varepsilon_\ell > 0$ 的序列 $(\varepsilon_\ell)_\ell$. 用 $\mathbf{P}_\ell$ 表示 (4.2)在 $\varepsilon = \varepsilon_\ell$ 时的解. 由于 $\mathbf{U}(\mathbf{a},\mathbf{b})$ 有界，可抽取一个子序列（为简便起见不另行编号），使 $\mathbf{P}_\ell \to \mathbf{P}^\star$. 由于 $\mathbf{U}(\mathbf{a},\mathbf{b})$ 是闭集，$\mathbf{P}^\star \in \mathbf{U}(\mathbf{a},\mathbf{b})$. 任取满足 $\langle \mathbf{C}, \mathbf{P}\rangle = \mathrm{L}_{\mathbf{C}}(\mathbf{a},\mathbf{b})$ 的 $\mathbf{P}$. 由 $\mathbf{P}$ 与 $\mathbf{P}_\ell$ 分别在各自优化问题（$\varepsilon = 0$ 和 $\varepsilon = \varepsilon_\ell$）中的最优性，有

$$0 \le \langle \mathbf{C}, \mathbf{P}_\ell\rangle - \langle \mathbf{C}, \mathbf{P}\rangle \le \varepsilon_\ell(\mathbf{H}(\mathbf{P}_\ell) - \mathbf{H}(\mathbf{P})). \tag{4.5}$$

由于 $\mathbf{H}$ 连续，在此式中令 $\ell \to +\infty$，得到 $\langle \mathbf{C}, \mathbf{P}^\star\rangle = \langle \mathbf{C}, \mathbf{P}\rangle$，故 $\mathbf{P}^\star$ 是 (4.3)的可行点. 此外，将 (4.5)除以 ε_ℓ 再取极限，得到 $\mathbf{H}(\mathbf{P}) \le \mathbf{H}(\mathbf{P}^\star)$，说明 $\mathbf{P}^\star$ 是 (4.3)的解. 由 $-\mathbf{H}$ 的严格凸性，此问题的解 $\mathbf{P}_0^\star$ 唯一，故 $\mathbf{P}^\star = \mathbf{P}_0^\star$，整个序列也收敛. 在 $\varepsilon \to +\infty$ 的极限下，类似的证明表明，此时应考虑问题

$$\min_{\mathbf{P}\in\mathbf{U}(\mathbf{a},\mathbf{b})} -\mathbf{H}(\mathbf{P}),$$

其解为 $\mathbf{a}\otimes\mathbf{b}$. □

式 (4.3)表明，当正则化参数 ε 很小时，解收敛到最大熵的最优传输耦合. 与此形成鲜明对比，式 (4.4)表明，当正则化参数很大时，解收敛到给定边缘分布 $\mathbf{a},\mathbf{b}$ 下熵最大的耦合，即两个分别服从 $\mathbf{a},\mathbf{b}$ 的独立随机变量的联合概率分布. Cominetti and San Martín (1994) 对这种收敛作了更精细的分析，包括在 $\varepsilon = 0$（相应地 $\varepsilon = +\infty$）附近关于 ε（相应地 $1/\varepsilon$）的一阶展开. 图 4.2和图 4.3直观展示这两种收敛的作用. 一个关键认识是，随着 ε 增大，最优耦合越来越不稀疏（这里以超过给定阈值的分量数来衡量），从而既加快计算算法（见第 4.2节），又加快统计收敛（见第 8.5节）.

将耦合之间的Kullback–Leibler 散度（Kullback–Leibler divergence）定义为

$$\mathbf{KL}(\mathbf{P}|\mathbf{K}) \overset{\text{def.}}{=} \sum_{i,j} \mathbf{P}_{i,j}\log\left(\frac{\mathbf{P}_{i,j}}{\mathbf{K}_{i,j}}\right) - \mathbf{P}_{i,j} + \mathbf{K}_{i,j}, \tag{4.6}$$

问题 (4.2)的唯一解 $\mathbf{P}_\varepsilon$ 是与代价矩阵 $\mathbf{C}$ 对应的 Gibbs 核在 $\mathbf{U}(\mathbf{a},\mathbf{b})$ 上的投影，其中

$$\mathbf{K}_{i,j} \overset{\text{def.}}{=} e^{-\frac{\mathbf{C}_{i,j}}{\varepsilon}}.$$

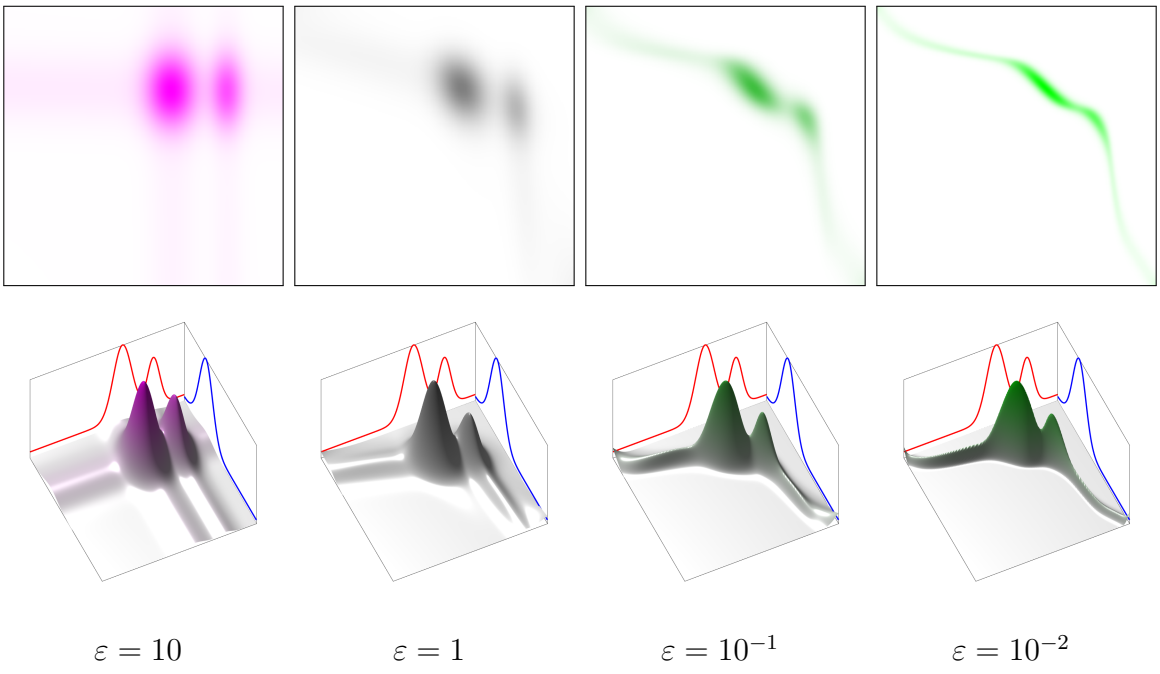

$\varepsilon = 10$ $\varepsilon = 1$ $\varepsilon = 10^{-1}$ $\varepsilon = 10^{-2}$

图 4.2: ε 对两个一维密度之间耦合的影响，说明命题 4.1. 上排：两个一维密度之间的耦合. 下排：点数相同 $n = m$ 的两个二维离散经验密度之间的耦合（只将最优耦合 $(\mathbf{P}_{i,j})_{i,j}$ 中超过某个小阈值的分量画成连接 x_i 与 y_j 的线段）.

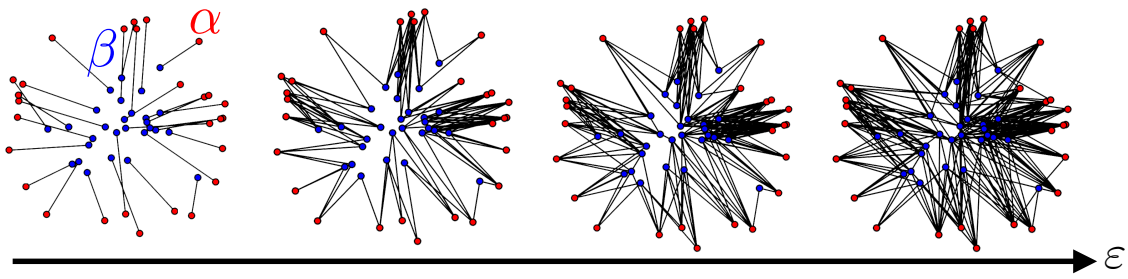

图 4.3: ε 对点数相同 $n = m$ 的两个二维离散经验密度之间耦合的影响（只将最优 $(\mathbf{P}_{i,j})_{i,j}$ 中超过某个小阈值的分量画成连接 x_i 与 y_j 的线段）.

事实上，由上述定义可得

$$\mathbf{P}_\varepsilon = \mathrm{Proj}^{\mathbf{KL}}_{\mathbf{U(a,b)}}(\mathbf{K}) \overset{\text{def.}}{=} \operatorname*{argmin}_{\mathbf{P}\in\mathbf{U(a,b)}} \mathbf{KL}(\mathbf{P}|\mathbf{K}). \tag{4.7}$$

注 4.1 (离散测度之间的熵正则化)**.** 对于形如 (2.1)的离散测度，正则化传输的定义自然扩展为

$$\mathcal{L}^\varepsilon_c(\alpha,\beta) \overset{\text{def.}}{=} \mathrm{L}^\varepsilon_{\mathbf{C}}(\mathbf{a},\mathbf{b}), \tag{4.8}$$

其中代价为 $\mathbf{C}_{i,j} = c(x_i, y_j)$，以强调它对输入测度支撑位置 (x_i, y_j) 的依赖.

注 4.2 (一般形式). 对于任意测度，可将离散熵替换为相对于乘积测度 $\mathrm{d}\alpha \otimes \mathrm{d}\beta(x,y) \overset{\text{def.}}{=} \mathrm{d}\alpha(x)\mathrm{d}\beta(y)$ 的相对熵 (relative entropy)，从而提出 (2.15)的正则化形式：

$$\mathcal{L}_c^{\varepsilon}(\alpha,\beta) \overset{\text{def.}}{=} \min_{\pi\in\mathcal{U}(\alpha,\beta)} \int_{\mathcal{X}\times\mathcal{Y}} c(x,y)\mathrm{d}\pi(x,y) + \varepsilon\,\mathrm{KL}(\pi|\alpha\otimes\beta), \tag{4.9}$$

其中相对熵推广了离散 Kullback–Leibler 散度 (4.6)：

$$\begin{aligned}\mathrm{KL}(\pi|\xi) \overset{\text{def.}}{=} &\int_{\mathcal{X}\times\mathcal{Y}} \log\Big(\frac{\mathrm{d}\pi}{\mathrm{d}\xi}(x,y)\Big)\mathrm{d}\pi(x,y)\\ &+\int_{\mathcal{X}\times\mathcal{Y}} (\mathrm{d}\xi(x,y)-\mathrm{d}\pi(x,y)),\end{aligned} \tag{4.10}$$

按约定，当 π 关于 ξ 不存在密度 $\frac{\mathrm{d}\pi}{\mathrm{d}\xi}$ 时，$\mathrm{KL}(\pi|\xi)=+\infty$. 必须认识到，在 (4.9)中用于定义熵正则项 $\mathrm{KL}(\cdot|\alpha\otimes\beta)$ 的参考测度 $\alpha\otimes\beta$ 并无特殊作用；只有它的支撑重要，正如以下命题所说明的.

命题 4.2. 对于任意 $\pi\in\mathcal{U}(\alpha,\beta)$，以及与 (α,β) 分别具有相同零测集的任意 (α',β') (因而双方相互存在密度)，有

$$\mathrm{KL}(\pi|\alpha\otimes\beta) = \mathrm{KL}(\pi|\alpha'\otimes\beta') - \mathrm{KL}(\alpha\otimes\beta|\alpha'\otimes\beta').$$

此命题说明，在 (4.9)中用 $\mathrm{KL}(\cdot|\alpha'\otimes\beta')$ 替换 $\mathrm{KL}(\cdot|\alpha\otimes\beta)$，会得到相同的解. 式 (4.9)可以改写成投影问题

$$\min_{\pi\in\mathcal{U}(\alpha,\beta)} \mathrm{KL}(\pi|\mathcal{K}), \tag{4.11}$$

其中 $\mathcal{K}$ 为 Gibbs 分布，$\mathrm{d}\mathcal{K}(x,y) \overset{\text{def.}}{=} e^{-\frac{c(x,y)}{\varepsilon}}\mathrm{d}\alpha(x)\mathrm{d}\beta(y)$. 此问题常被称为“静态 Schrödinger 问题 (static Schrödinger problem)” (Léonard, 2014; Rüschendorf and Thomsen, 1998)，因为 Schrödinger 最初在统计物理中考察了它 (Schrödinger, 1931). 当 $\varepsilon\to 0$ 时，问题 (4.11)的唯一解收敛到 (2.15)的最大熵解；见 (Léonard, 2012; Carlier et al., 2017). 第 7.6节将详述另一种“动态” Schrödinger 形式，它定义在连接两个测度中点的路径空间上.

注 4.3 (互熵). 与 (2.16)类似，可用随机变量将 (4.9)改写为

$$\mathcal{L}_c^{\varepsilon}(\alpha,\beta) = \min_{(X,Y)} \left\{\mathbb{E}_{(X,Y)}(c(X,Y)) + \varepsilon \mathrm{I}(X,Y) \;:\; X\sim\alpha, Y\sim\beta\right\},$$

记 π 为 (X,Y) 的分布，则 $\mathrm{I}(X,Y) \overset{\text{def.}}{=} \mathrm{KL}(\pi|\alpha\otimes\beta)$ 称为两个随机变量之间的*互信息* (mutual information). 有 $\mathrm{I}(X,Y)\geq 0$，并且 $\mathrm{I}(X,Y)=0$ 当且仅当两个随机变量独立.

注 4.4 (独立性与耦合). 耦合 $\pi \in \mathcal{U}(\alpha,\beta)$ 描述定义在 $(\mathcal{X},\mathcal{Y})$ 上的一对随机变量 (X,Y) 的分布，其中 X（相应地 Y）的分布为 α（相应地 β）. 命题 4.1也适用于一般的（不必离散的）测度，因此当 $\varepsilon \to +\infty$ 时，(4.9)的解 π_ε 收敛到张量积耦合 $\alpha \otimes \beta$. 此耦合对应于随机变量 (X,Y) 相互独立. 相反，当 $\varepsilon \to 0$ 时，π_ε 收敛到最优传输问题 (2.15)的一个解 π_0. 在 $\mathcal{X} = \mathcal{Y} = \mathbb{R}^d$ 上，如果 α 和 β 关于 Lebesgue 测度存在密度，如注 2.24所述，则 π_0 唯一，并支撑在双射 Monge 映射 $T : \mathbb{R}^d \to \mathbb{R}^d$ 的图像上. 此时 (X,Y) 在某种意义上完全依赖，因为 $Y = T(X)$ 且 $X = T^{-1}(Y)$. 在简单的一维情形 $d = 1$ 下，可用联合分布 π 对应的联结函数（copula）ξ_π 直观展示 X 与 Y 的依赖结构. 将 (2.34)中定义的累积分布函数扩展到耦合：

$$\forall (x,y) \in \mathbb{R}^2, \quad \mathcal{C}_\pi(x,y) \overset{\text{def.}}{=} \int_{-\infty}^{x}\int_{-\infty}^{y} \mathrm{d}\pi.$$

联结函数随后定义为

$$\forall (s,t) \in [0,1]^2, \quad \xi_\pi(s,t) \overset{\text{def.}}{=} \mathcal{C}_\pi(\mathcal{C}_\alpha^{-1}(s), \mathcal{C}_\beta^{-1}(t)),$$

其中累积分布函数的伪逆定义见 (2.35). 对于独立变量，$\varepsilon = +\infty$，即 $\pi = \alpha \otimes \beta$，有 $\xi_{\pi_{+\infty}}(s,t) = st$. 相反，对于完全依赖的变量，$\varepsilon = +\infty$，有 $\xi_{\pi_0}(s,t) = \min(s,t)$. 图 4.4展示熵正则化如何生成在这两个极端情形之间插值的联结函数 ξ_{π_ε}.

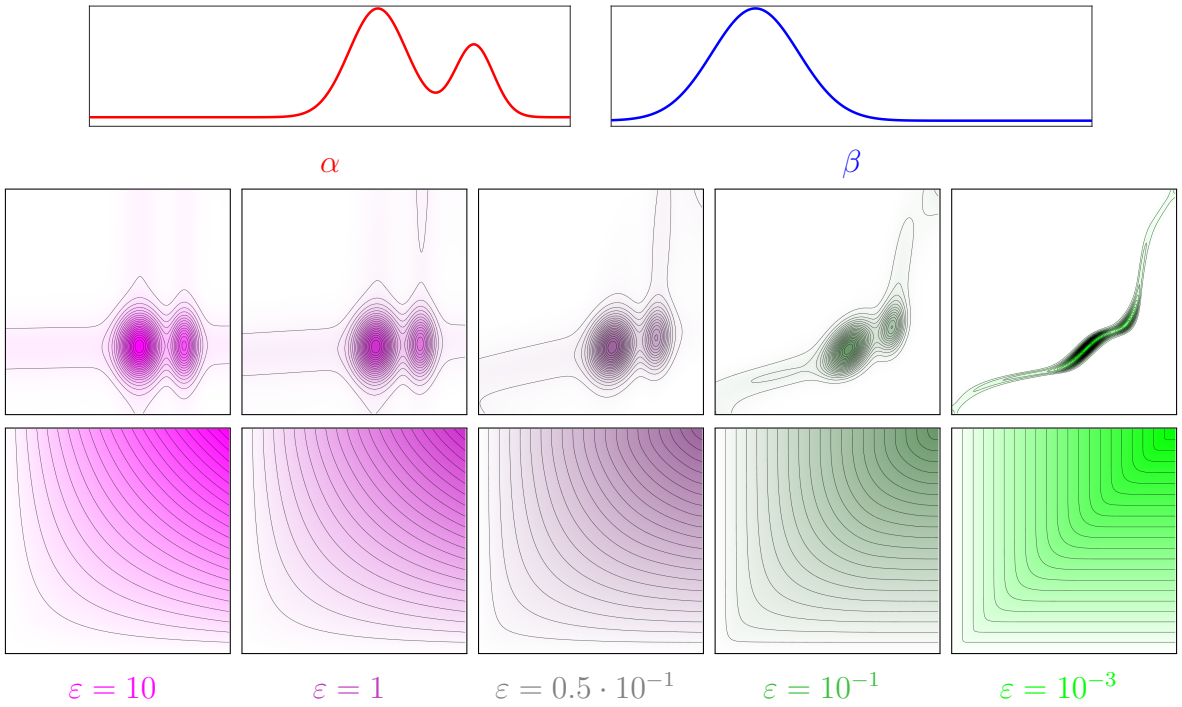

图 4.4: 上：(4.9)的解 π_ε 随 ε 的变化. 下：联结函数 ξ_{π_ε} 的变化.

4.2 Sinkhorn 算法及其收敛性

以下命题表明，(4.2)的解具有特定形式，可用 $n+m$ 个变量参数化. 这种参数化本质上是对偶的，因为 $\mathbf{U}(\mathbf{a},\mathbf{b})$ 中的耦合 $\mathbf{P}$ 有 nm 个变量，但只有 $n+m$ 个约束.

命题 4.3. 问题 (4.2)的解唯一，且具有形式

$$\forall (i,j) \in [\![n]\!] \times [\![m]\!], \quad \mathbf{P}_{i,j} = \mathbf{u}_i \mathbf{K}_{i,j} \mathbf{v}_j \tag{4.12}$$

其中 $(\mathbf{u},\mathbf{v}) \in \mathbb{R}_+^n \times \mathbb{R}_+^m$ 为两个（未知的）缩放变量.

证明： 为两个边缘约束引入对偶变量 $\mathbf{f} \in \mathbb{R}^n, \mathbf{g} \in \mathbb{R}^m$， (4.2)的 Lagrange 函数为

$$\mathcal{E}(\mathbf{P},\mathbf{f},\mathbf{g}) = \langle \mathbf{P}, \mathbf{C} \rangle - \varepsilon \mathbf{H}(\mathbf{P}) - \langle \mathbf{f}, \mathbf{P}\mathbb{1}_m - \mathbf{a} \rangle - \langle \mathbf{g}, \mathbf{P}^{\mathrm{T}}\mathbb{1}_n - \mathbf{b} \rangle.$$

一阶条件给出

$$\frac{\partial \mathcal{E}(\mathbf{P},\mathbf{f},\mathbf{g})}{\partial \mathbf{P}_{i,j}} = \mathbf{C}_{i,j} + \varepsilon \log(\mathbf{P}_{i,j}) - \mathbf{f}_i - \mathbf{g}_j = 0,$$

于是，正则化问题的最优耦合 $\mathbf{P}$ 满足 $\mathbf{P}_{i,j} = e^{\mathbf{f}_i/\varepsilon} e^{-\mathbf{C}_{i,j}/\varepsilon} e^{\mathbf{g}_j/\varepsilon}$，用非负向量 $\mathbf{u},\mathbf{v}$ 即可将其改写为上述形式. □

正则化最优传输与矩阵缩放. 式 (4.12)给出的最优解分解可方便地写成矩阵形式 $\mathbf{P} = \mathrm{diag}(\mathbf{u})\mathbf{K}\,\mathrm{diag}(\mathbf{v})$. 因此，变量 $(\mathbf{u},\mathbf{v})$ 必须满足以下非线性方程，它们对应于 $\mathbf{U}(\mathbf{a},\mathbf{b})$ 中固有的质量守恒约束：

$$\mathrm{diag}(\mathbf{u})\mathbf{K}\,\mathrm{diag}(\mathbf{v})\mathbb{1}_m = \mathbf{a}, \quad \text{且} \quad \mathrm{diag}(\mathbf{v})\mathbf{K}^{\top}\,\mathrm{diag}(\mathbf{u})\mathbb{1}_n = \mathbf{b}. \tag{4.13}$$

由于 $\mathrm{diag}(\mathbf{v})\mathbb{1}_m = \mathbf{v}$，而 $\mathrm{diag}(\mathbf{u})$ 与 $\mathbf{K}\mathbf{v}$ 相乘可写成逐分量乘积，这两个方程进一步简化为

$$\mathbf{u} \odot (\mathbf{K}\mathbf{v}) = \mathbf{a} \quad \text{且} \quad \mathbf{v} \odot (\mathbf{K}^{\mathrm{T}}\mathbf{u}) = \mathbf{b}, \tag{4.14}$$

其中 $\odot$ 表示向量的逐分量乘法. 在数值分析领域，此问题称为*矩阵缩放* (matrix scaling)问题（见 (Nemirovski and Rothblum, 1999) 及其中的参考文献）. 直观的求解办法是迭代处理：先修改 $\mathbf{u}$，使其满足 (4.14)左边的方程，再修改 $\mathbf{v}$，使其满足右边的方程. 这两步更新定义了Sinkhorn 算法（Sinkhorn's algorithm）：

$$\mathbf{u}^{(\ell+1)} \overset{\text{def.}}{=} \frac{\mathbf{a}}{\mathbf{K}\mathbf{v}^{(\ell)}} \quad \text{且} \quad \mathbf{v}^{(\ell+1)} \overset{\text{def.}}{=} \frac{\mathbf{b}}{\mathbf{K}^{\mathrm{T}}\mathbf{u}^{(\ell+1)}}, \tag{4.15}$$

用任意正向量初始化，例如 $\mathbf{v}^{(0)} = \mathbb{1}_m$. 上述向量除法均按分量进行. 不同初始化可能得到不同的 $\mathbf{u},\mathbf{v}$，因为它们只在相差一个乘法常数的意义下确定（若 $\mathbf{u},\mathbf{v}$ 满足 (4.13)，则任意 $\lambda > 0$ 下的 $\lambda\mathbf{u}, \mathbf{v}/\lambda$ 也满足）. 不过，这些迭代确实收敛（注 4.8用迭代投影解释这一点，注 4.14给出严格收缩结果），并且都得到相同的最优耦合 $\mathrm{diag}(\mathbf{u})\mathbf{K}\,\mathrm{diag}(\mathbf{v})$. 图 4.5上排展示 Sinkhorn 迭代计算的耦合 $\mathrm{diag}(\mathbf{u}^{(\ell)})\mathbf{K}\,\mathrm{diag}(\mathbf{v}^{(\ell)})$ 的变化. 它逐渐将质量移离对角线，从 Gibbs 核 $\mathbf{K}$ 演变为求解 (4.2)的最优耦合.

注 4.5 (历史背景). 迭代 (4.15)最早出现于 (Yule, 1912; Kruithof, 1937)，后来被称为迭代比例拟合过程 (IPFP) Deming and Stephan (1940) 和 RAS (Bacharach, 1965) 方法 (Idel, 2016). 其收敛证明归功于 Sinkhorn (1964)，算法因而得名. Ruschendorf (1995) 后来将其扩展到无限维. 在经济学中，这种正则化以引力模型的名称用于近似求解最优传输 (Wilson, 1969; Erlander, 1980; Erlander and Stewart, 1990). 在指派情形，即 $\mathbf{a} = \mathbf{b} = \mathbb{1}_n/n$ 时，Kosowsky and Yuille (1994) 将其重新称为 "softassign"；较近的工作中，Galichon and Salanié (2009) 用它求解经济学中的匹配问题. (Cuturi, 2013) 之后，这种正则化在数据科学 (包括机器学习、视觉、图形学和成像) 中重新受到关注. 该工作表明，得益于同时求解多个最优传输问题时便于并行化 (尤其是在 GPU 上；见注 4.16)，Sinkhorn 算法可高效且可扩展地近似最优传输；与线性规划形式不同，正则化后的量还定义了可微的损失函数 (见第 4.5节) . Sinkhorn 算法有众多扩展和推广 (例如第 4.6节) . 例如，当 $\mathbf{a} = \mathbf{b}$ 时，可以使用平均投影迭代来保持对称性 (Knight et al., 2014).

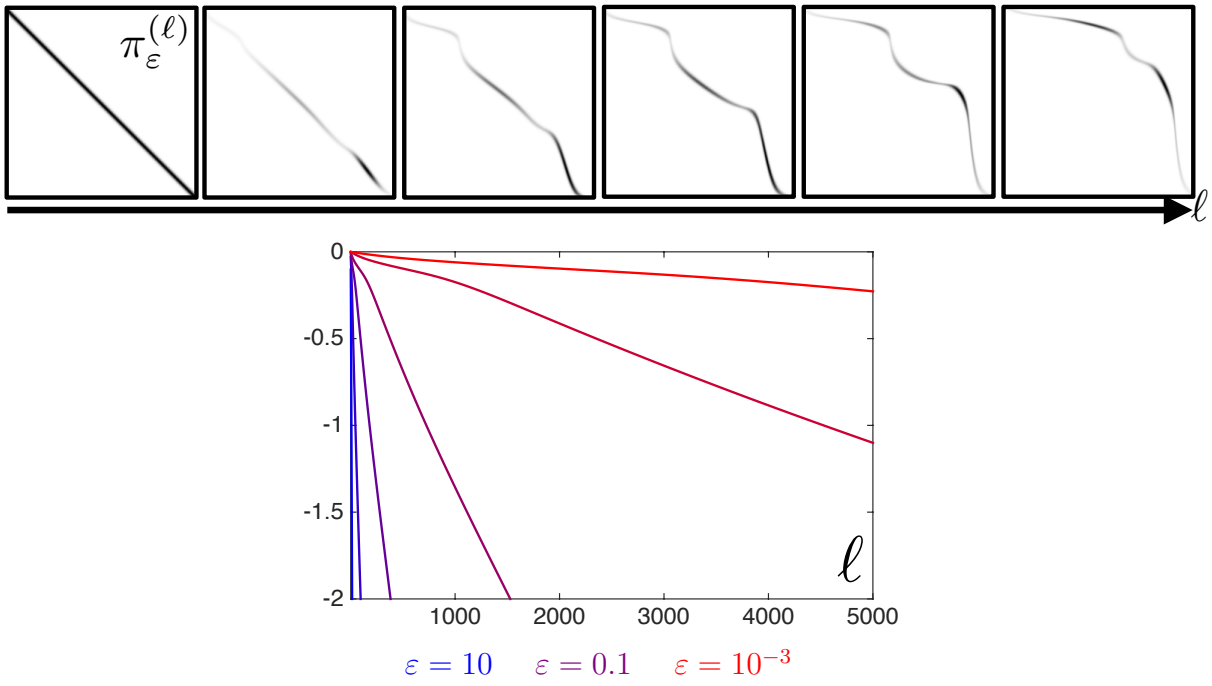

图 4.5: 上：在 $\mathcal{X} = [0,1]$ 上的一维密度、$c(x,y) = |x-y|^2$ 和 $\varepsilon = 0.1$ 下，Sinkhorn 第 ℓ 次迭代计算的耦合 $\pi_\varepsilon^{(\ell)} = \mathrm{diag}(\mathbf{u}^{(\ell)})\mathbf{K}\,\mathrm{diag}(\mathbf{v}^{(\ell)})$ 的变化. 下：ε 对 Sinkhorn 收敛速度的影响，以边缘约束违反量 $\log(\|\pi_\varepsilon^{(\ell)}\mathbb{1}_m - \mathbf{b}\|_1)$ 衡量.

注 4.6 (总体复杂度). 通过细致的收敛分析 (为简便起见假设 $n = m$)，Altschuler et al. (2017) 表明：取 $\varepsilon = \frac{4\log(n)}{\tau}$，经过 $O(\|\mathbf{C}\|_\infty^3 \log(n)\tau^{-3})$ 次 Sinkhorn 迭代，再加一步舍入以得到有效耦合 $\hat{\mathbf{P}} \in \mathbf{U}(\mathbf{a},\mathbf{b})$，足以保证 $\langle \hat{\mathbf{P}}, \mathbf{C}\rangle \leq \mathrm{L}_\mathbf{C}(\mathbf{a},\mathbf{b}) + \tau$. 因此，Sinkhorn 可在 $O(n^2\log(n)\tau^{-3})$ 次运算内计算未正则化最优传输问题的 τ-近似解.

给定 $\mathbf{u} \in \mathbb{R}^n, \mathbf{v} \in \mathbb{R}^m$，舍入方法执行如下更新 ((Altschuler et al., 2017, 算法 2))：

$$\begin{aligned}
\mathbf{u}' &\overset{\text{def.}}{=} \mathbf{u} \odot \min\left(\frac{\mathbf{a}}{\mathbf{u} \odot (\mathbf{K}\mathbf{v})}, \mathbb{1}_n\right), \mathbf{v}' \overset{\text{def.}}{=} \mathbf{v} \odot \min\left(\frac{\mathbf{b}}{\mathbf{v} \odot (\mathbf{K}^{\mathrm{T}}\mathbf{u}')}, \mathbb{1}_n\right), \\
\Delta_{\mathbf{a}} &\overset{\text{def.}}{=} \mathbf{a} - \mathbf{u}' \odot (\mathbf{K}\mathbf{v}'), \Delta_{\mathbf{b}} \overset{\text{def.}}{=} \mathbf{b} - \mathbf{v}' \odot (\mathbf{K}^{\mathrm{T}}\mathbf{u}), \\
\hat{\mathbf{P}} &\overset{\text{def.}}{=} \operatorname{diag}(\mathbf{u}')\mathbf{K}\operatorname{diag}(\mathbf{v}') + \Delta_{\mathbf{a}}(\Delta_{\mathbf{b}})^{\mathrm{T}} / \|\Delta_{\mathbf{a}}\|_1 .
\end{aligned}$$

所得矩阵 $\hat{\mathbf{P}} \in \mathbf{U}(\mathbf{a}, \mathbf{b})$ 与 $\operatorname{diag}(\mathbf{u})\mathbf{K}\operatorname{diag}(\mathbf{v})$ 的 1-范数差受后者的边缘违反量控制，即

$$\left\|\hat{\mathbf{P}} - \operatorname{diag}(\mathbf{u})\mathbf{K}\operatorname{diag}(\mathbf{v})\right\|_1 \leq \|\mathbf{a} - \mathbf{u} \odot (\mathbf{K}\mathbf{v})\|_1 + \left\|\mathbf{b} - \mathbf{v} \odot (\mathbf{K}^{\mathrm{T}}\mathbf{u})\right\|_1 .$$

这一领域仍在持续发展，例如 Dvurechensky et al. (2018) 近期改进了上述结果.

注 4.7 (Sinkhorn 迭代的数值稳定性)**.** 如注 4.14和注 4.15所述，Sinkhorn 算法的收敛在 $\varepsilon \to 0$ 时变慢. 然而，数值计算中很少实际观察到这种减速，原因更直接：一旦核 $\mathbf{K}$ 的一些元素过小，以致无法在内存中存为正数而被记为零，Sinkhorn 算法往往无法正常终止. 随后，矩阵乘积 $\mathbf{K}\mathbf{v}$ 或 $\mathbf{K}^{\mathrm{T}}\mathbf{u}$ 的分量可能不断变小直至归零，使 (4.15)中的更新出现除以零. 在对数域中计算乘子 $\mathbf{u}, \mathbf{v}$ 可以部分解决这些问题. 注 4.23将详细介绍此方法，它与直接求解 (4.2)的对偶问题有关.

注 4.8 (与迭代投影的关系)**.** 将行、列约束分别记为

$$\mathcal{C}_{\mathbf{a}}^1 \overset{\text{def.}}{=} \{\mathbf{P} : \mathbf{P}\mathbb{1}_m = \mathbf{a}\} \quad \text{且} \quad \mathcal{C}_{\mathbf{b}}^2 \overset{\text{def.}}{=} \{\mathbf{P} : \mathbf{P}^{\mathrm{T}}\mathbb{1}_m = \mathbf{b}\}$$

则 $\mathbf{U}(\mathbf{a}, \mathbf{b}) = \mathcal{C}_{\mathbf{a}}^1 \cap \mathcal{C}_{\mathbf{b}}^2$. 可使用 Bregman 迭代投影 (Bregman, 1967)：

$$\mathbf{P}^{(\ell+1)} \overset{\text{def.}}{=} \operatorname{Proj}_{\mathcal{C}_{\mathbf{a}}^1}^{\mathbf{KL}}(\mathbf{P}^{(\ell)}) \quad \text{且} \quad \mathbf{P}^{(\ell+2)} \overset{\text{def.}}{=} \operatorname{Proj}_{\mathcal{C}_{\mathbf{b}}^2}^{\mathbf{KL}}(\mathbf{P}^{(\ell+1)}). \tag{4.16}$$

由于 $\mathcal{C}_{\mathbf{a}}^1, \mathcal{C}_{\mathbf{b}}^2$ 是仿射集，已知这些迭代收敛到 (4.7)的解；见 (Bregman, 1967). 它们与 Sinkhorn 迭代 (4.15)等价，因为若定义

$$\mathbf{P}^{(2\ell)} \overset{\text{def.}}{=} \operatorname{diag}(\mathbf{u}^{(\ell)})\mathbf{K}\operatorname{diag}(\mathbf{v}^{(\ell)}),$$

便有

$$\begin{aligned}
&\mathbf{P}^{(2\ell+1)} \overset{\text{def.}}{=} \operatorname{diag}(\mathbf{u}^{(\ell+1)})\mathbf{K}\operatorname{diag}(\mathbf{v}^{(\ell)}) \\
\text{且} \quad &\mathbf{P}^{(2\ell+2)} \overset{\text{def.}}{=} \operatorname{diag}(\mathbf{u}^{(\ell+1)})\mathbf{K}\operatorname{diag}(\mathbf{v}^{(\ell+1)}).
\end{aligned}$$

实际计算中应优先采用 (4.15)，它只需操作缩放向量及与 Gibbs 核相乘，而后者通常可加速（见下文注 4.17和注 4.19）.

注 4.9 (近端点算法)**.** 为了近似求解未正则化（$\varepsilon = 0$）问题 (2.11)，可通过 KL 度量下的所谓近端点算法 (proximal point algorithm) 反复使用 Sinkhorn 算法. 将未正则化目标函数记为 $F(\mathbf{P}) \overset{\text{def.}}{=} \langle \mathbf{P}, \pi \rangle + \iota_{\mathbf{U}(\mathbf{a},\mathbf{b})}(\mathbf{P})$. **KL** 散度下的近端点迭代通过反复计算以下步

骤求得 F 的极小点，从而得到未正则化最优传输问题 (2.11)的解：

$$\mathbf{P}^{(\ell+1)} \overset{\text{def.}}{=} \mathrm{Prox}^{\mathbf{KL}}_{\frac{1}{\varepsilon}F}(\mathbf{P}^{(\ell)}) \overset{\text{def.}}{=} \operatorname*{argmin}_{\mathbf{P}\in\mathbb{R}_+^{n\times m}} \mathbf{KL}(\mathbf{P}|\mathbf{P}^{(\ell)}) + \frac{1}{\varepsilon}F(\mathbf{P}) \tag{4.17}$$

从任意 $\mathbf{P}^{(0)}$ 出发（另见 (4.52)）. 近端点算法是最基本的近端分裂方法. 它最初在 Euclidean 度量下提出（例如 Rockafellar 1976），可以扩展到任意 Bregman 散度 (Censor and Zenios, 1992)，因而也适用于这里的 $\mathbf{KL}$ 散度（见注 8.1.1）. 近端算子通常没有闭式表达，因此需要某种内部迭代. 式 (4.17)中的优化与熵正则化问题 (4.2)非常相似，只是以相对熵 $\mathbf{KL}(\cdot|\mathbf{P}^{(\ell)})$ 替换负熵 $-\mathbf{H}$. 当将 Gibbs 核定义为 $\mathbf{K} = e^{-\frac{\mathbf{C}}{\varepsilon}} \odot \mathbf{P}^{(\ell)} = (e^{-\frac{\mathbf{C}_{i,j}}{\varepsilon}}\mathbf{P}^{(\ell)}_{i,j})_{i,j}$ 时，命题 4.3与 Sinkhorn 迭代 (4.15)仍适用于这一更一般的情形. 因此，迭代 (4.17)可在每一步运行 Sinkhorn 算法来实现. 为简便起见设 $\mathbf{P}^{(0)} = \mathbb{1}_n\mathbb{1}_m^\top$，则这些迭代具有形式

$$\begin{aligned} P^{(\ell+1)} &= \mathrm{diag}(\mathbf{u}^{(\ell)})(e^{-\frac{\mathbf{C}}{\varepsilon}} \odot \mathbf{P}^{(\ell)})\,\mathrm{diag}(\mathbf{v}^{(\ell)}) \\ &= \mathrm{diag}(\mathbf{u}^{(\ell)} \odot \cdots \odot \mathbf{u}^{(0)})e^{-\frac{(\ell+1)\mathbf{C}}{\varepsilon}} \odot \mathbf{P}^{(\ell)})\,\mathrm{diag}(\mathbf{v}^{(\ell)} \odot \cdots \odot \mathbf{v}^{(0)}). \end{aligned}$$

因此，近端点迭代反复对核 $e^{-\frac{\mathbf{C}}{\varepsilon/\ell}}$ 应用 Sinkhorn 算法，即使用递减的正则化参数 ε/ℓ. 此方法与将 Sinkhorn 和正则化参数递减策略相结合的一系列工作密切相关，例如 (Kosowsky and Yuille, 1994). 在较低空间维数下，将它们与多重网格策略结合，在自适应稀疏网格上近似耦合，可取得较高效率 (Schmitzer, 2016b).

注 4.10 (其他正则化)**.** 可将 (4.2)中的熵项 $-\mathbf{H}(\mathbf{P})$ 替换为任意严格凸惩罚 $R(\mathbf{P})$，例如 (Dessein et al., 2018) 中的讨论. 典型例子是平方 ℓ^2 范数：

$$R(\mathbf{P}) = \sum_{i,j} \mathbf{P}_{i,j}^2 + \iota_{\mathbb{R}_+}(\mathbf{P}_{i,j}); \tag{4.18}$$

见 (Essid and Solomon, 2017). 另一个例子是 Tsallis 熵族 (Muzellec et al., 2017). 然而，如果惩罚函数在 $\mathbf{P}$ 的分量非正时也有定义，例如二次正则化 (4.18)，那么除了边缘约束 $\mathbf{P}\mathbb{1}_m = \mathbf{a}$ 和 $\mathbf{P}^\top\mathbb{1}_n = \mathbf{b}$，还必须加回非负约束 $\mathbf{P} \geq 0$. 使用熵时可以忽略此约束，因为其中的对数项迫使 $\mathbf{P}$ 的分量留在正象限. 这意味着约束集不再仿射，Bregman 迭代投影也不再收敛到解. 一种解决办法是改用 Dykstra的算法 (1983; 1985)（另见 Bauschke and Lewis 2000），详见 (Benamou et al., 2015). 此算法使用与 R 对应的 Bregman 散度投影. 关于 Bregman 散度的细节见注 8.1.1. 一个困难是这些投影一般不能显式计算. 对于平方范数 (4.18)，这相当于在 $(\mathcal{C}^1_{\mathbf{a}}, \mathcal{C}^2_{\mathbf{b}})$ 上计算 Euclidean 投影（另加正性约束），可通过单纯形上的投影算法高效求解 (Condat, 2015). 与熵相比，二次正则化的主要优势是产生最优耦合的稀疏近似；代价则是算法较慢，而且同时计算多个最优传输时无法像 Sinkhorn 那样高效并行化（见第 4.16节）. 图 4.6比较这两种正则化得到的近似.

注 4.11 (重心投影)**.** 再次考虑注 4.1中的情形，用熵正则化近似离散测度之间的最优传输. Kantorovich 形式 (2.11)及其熵正则化 (4.2)都给出耦合 $\mathbf{P} \in \mathbf{U}(\mathbf{a}, \mathbf{b})$. 当 $\mathcal{Y} = \mathbb{R}^d$ 时，为定义传输映射 $T : \mathcal{X} \to \mathcal{Y}$，可定义所谓重心投影（barycentric

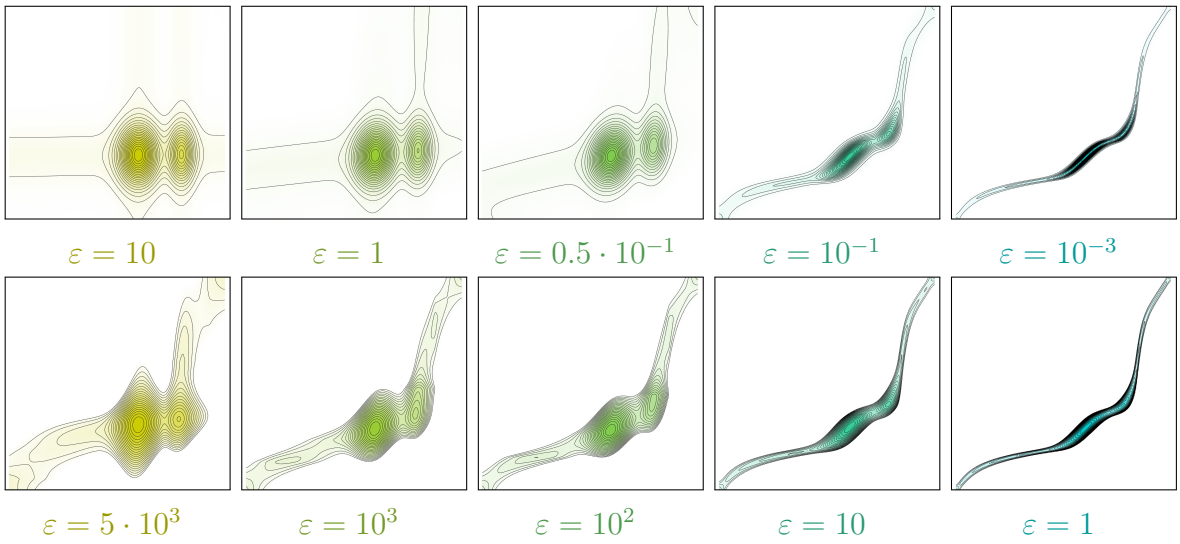

图 4.6: 熵正则化 $R = -\mathbf{H}$（上排）与二次正则化 $R = \|\cdot\|^2 + \iota_{\mathbb{R}_+}$（下排）的比较. 边缘分布 (α, β) 与图 4.4相同.

projection）映射

$$T : x_i \in \mathcal{X} \longmapsto \frac{1}{\mathbf{a}_i} \sum_j \mathbf{P}_{i,j} y_j \in \mathcal{Y}, \tag{4.19}$$

其中输入测度为 (2.3)形式的离散测度. 注意，此映射只在 α 支撑中的点 $(x_i)_i$ 上有定义. 当 T 为置换矩阵时（详见命题 2.1），T 等于一个 Monge 映射；如果此映射唯一，则在 $\varepsilon \to 0$ 时，重心投影逐渐收敛到它. 对于任意（不必离散的）测度，求解 (2.15)或其正则化形式 (4.9)得到耦合 $\pi \in \mathcal{U}(\alpha, \beta)$. 注意，此耦合 π 关于 $\alpha \otimes \beta$ 总有密度 $\frac{\mathrm{d}\pi(x,y)}{\mathrm{d}\alpha(x)\mathrm{d}\beta(y)}$. 因而可由下式恢复映射：

$$T : x \in \mathcal{X} \longmapsto \int_{\mathcal{Y}} y \frac{\mathrm{d}\pi(x, y)}{\mathrm{d}\alpha(x)\mathrm{d}\beta(y)} \mathrm{d}\beta(y). \tag{4.20}$$

若在 $\varepsilon = 0$ 时，π 支撑在 Monge 映射的图像上（见注 2.24），则取 $\varepsilon > 0$ 会产生此映射的光滑近似. 这种重心投影有助于应用最优传输 Monge 映射来求解成像问题；颜色修改的应用见图 9.6. 它也曾用于近似计算赋予 Wasserstein 度量的概率测度空间中的主测地线；见 (Seguy and Cuturi, 2015).

注 4.12 (Hilbert 度量). 正如 (Franklin and Lorenz, 1989) 最初指出的，使用正向量空间 $\mathbb{R}^n_{+,*}$ 上的Hilbert 射影度量 (Hilbert projective metric) 可大幅简化 Sinkhorn 的全局收敛分析，其定义为

$$\forall (\mathbf{u}, \mathbf{u}') \in (\mathbb{R}^n_{+,*})^2, \quad d_{\mathcal{H}}(\mathbf{u}, \mathbf{u}') \overset{\text{def.}}{=} \log \max_{i,j} \frac{\mathbf{u}_i \mathbf{u}'_j}{\mathbf{u}_j \mathbf{u}'_i}.$$

可以证明，它是射影锥 $\mathbb{R}^n_{+,*}/\sim$ 上的距离，其中 $\mathbf{u} \sim \mathbf{u}'$ 表示存在 $r > 0$ 使 $\mathbf{u} =$

$r\mathbf{u}'$（向量相差一个缩放，因此称为“射影”）. 这意味着 $d_{\mathcal{H}}$ 满足三角不等式，且 $d_{\mathcal{H}}(\mathbf{u},\mathbf{u}')=0$ 当且仅当 $\mathbf{u}\sim\mathbf{u}'$. 这是 Hilbert 最初在有界开凸集上定义的距离的射影版本 (Hilbert, 1895). 对于此距离，射影锥 $\mathbb{R}^n_{+,*}/\sim$ 是完备度量空间. 通过对数变量变换，正锥射线上的 Hilbert 度量等距于变差半范数（对于只确定到一个加法常数的向量，它是范数）:

$$d_{\mathcal{H}}(\mathbf{u},\mathbf{u}')=\|\log(\mathbf{u})-\log(\mathbf{u}')\|_{\mathrm{var}} \tag{4.21}$$

$$\text{其中}\quad \|\mathbf{f}\|_{\mathrm{var}}\overset{\text{def.}}{=}(\max_i \mathbf{f}_i)-(\min_i \mathbf{f}_i).$$

此变差半范数与 ℓ^∞ 范数密切相关，因为总有 $\|\mathbf{f}\|_{\mathrm{var}}\leq 2\|\mathbf{f}\|_\infty$. 若令某个固定 i 的 $\mathbf{f}_i=0$，则反向不等式也成立，即 $\|\mathbf{f}\|_\infty\leq\|\mathbf{f}\|_{\mathrm{var}}$. 这些界对于分析 Sinkhorn 收敛特别有用（见下文注 4.14），因为求解 (4.14)的对偶变量 $\mathbf{f}=\log(\mathbf{u})$ 只确定到一个加法常数，因而可令某个 $\mathbf{f}_i=0$. Hilbert 度量由 (Birkhoff, 1957) 和 (Samelson et al., 1957) 独立引入. 他们证明了下面的基本定理，表明正矩阵在正向量锥上是严格收缩的.

定理 4.1. 设 $\mathbf{K}\in\mathbb{R}^{n\times m}_{+,*}$，则对于 $(\mathbf{v},\mathbf{v}')\in(\mathbb{R}^m_{+,*})^2$，有

$$d_{\mathcal{H}}(\mathbf{K}\mathbf{v},\mathbf{K}\mathbf{v}')\leq\lambda(\mathbf{K})d_{\mathcal{H}}(\mathbf{v},\mathbf{v}'),\text{其中}\begin{cases}\lambda(\mathbf{K})\overset{\text{def.}}{=}\frac{\sqrt{\eta(\mathbf{K})}-1}{\sqrt{\eta(\mathbf{K})}+1}<1,\\ \eta(\mathbf{K})\overset{\text{def.}}{=}\max\limits_{i,j,k,\ell}\frac{\mathbf{K}_{i,k}\mathbf{K}_{j,\ell}}{\mathbf{K}_{j,k}\mathbf{K}_{i,\ell}}.\end{cases}$$

图 4.7说明此定理.

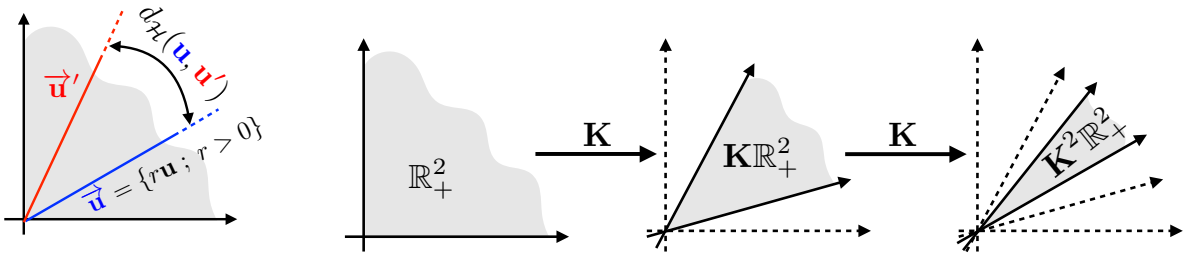

图 4.7: 左：Hilbert 度量 $d_{\mathcal{H}}$ 是锥中射线之间的距离（此处为正向量）. 右：正矩阵 $\mathbf{K}$ 的迭代所产生收缩的示意图.

注 4.13 (Perron–Frobenius)**.** 定理 4.1的典型应用是给出 Perron–Frobenius 定理的定量证明；如注 4.15所述，它与 Sinkhorn 迭代的局部线性化有关. 满足 $\mathbf{K}^\top\mathbb{1}_n=\mathbb{1}_n$ 的矩阵 $\mathbf{K}\in\mathbb{R}^{n\times n}_+$ 将 Σ_n 映入自身. 若进一步 $\mathbf{K}>0$，则由定理 4.1，它关于度量 $d_{\mathcal{H}}$ 严格收缩，因而存在唯一不变概率分布 $p^\star\in\Sigma_n$，满足 $\mathbf{K}p^\star=p^\star$. 此外，对任意

$p_0 \in \Sigma_n$，有 $d_{\mathcal{H}}(\mathbf{K}^\ell p_0, p^\star) \leq \lambda(\mathbf{K})^\ell d_{\mathcal{H}}(p_0, p^\star)$，即矩阵迭代线性收敛到 $p^\star$. 图 4.8展示这一现象.

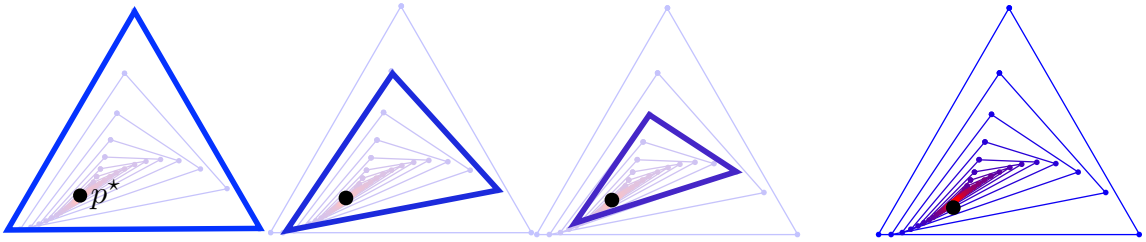

图 4.8: $\mathbf{K}^\ell\Sigma_3 \to \{p^\star\}$ 的演变，其中 $p^\star$ 是满足 $\mathbf{K}^\top \mathbb{1}_3 = \mathbb{1}_3$ 的 $\mathbf{K} \in \mathbb{R}^{3\times 3}_{+,*}$ 的不变概率分布.

注 4.14 (全局收敛). 以下定理由 (Franklin and Lorenz, 1989) 证明，它利用定理 4.1说明 Sinkhorn 迭代的线性收敛.

定理 4.2. 有 $(\mathbf{u}^{(\ell)}, \mathbf{v}^{(\ell)}) \to (\mathbf{u}^\star, \mathbf{v}^\star)$，且

$$d_{\mathcal{H}}(\mathbf{u}^{(\ell)}, \mathbf{u}^\star) = O(\lambda(\mathbf{K})^{2\ell}), \quad d_{\mathcal{H}}(\mathbf{v}^{(\ell)}, \mathbf{v}^\star) = O(\lambda(\mathbf{K})^{2\ell}). \tag{4.22}$$

此外还有

$$\begin{aligned} d_{\mathcal{H}}(\mathbf{u}^{(\ell)}, \mathbf{u}^\star) &\leq \frac{d_{\mathcal{H}}(\mathbf{P}^{(\ell)}\mathbb{1}_m, \mathbf{a})}{1-\lambda(\mathbf{K})^2}, \\ d_{\mathcal{H}}(\mathbf{v}^{(\ell)}, \mathbf{v}^\star) &\leq \frac{d_{\mathcal{H}}(\mathbf{P}^{(\ell),\top}\mathbb{1}_n, \mathbf{b})}{1-\lambda(\mathbf{K})^2}, \end{aligned} \tag{4.23}$$

这里记 $\mathbf{P}^{(\ell)} \overset{\text{def.}}{=} \operatorname{diag}(\mathbf{u}^{(\ell)})\mathbf{K}\operatorname{diag}(\mathbf{v}^{(\ell)})$. 最后还有

$$\|\log(\mathbf{P}^{(\ell)}) - \log(\mathbf{P}^\star)\|_\infty \leq d_{\mathcal{H}}(\mathbf{u}^{(\ell)}, \mathbf{u}^\star) + d_{\mathcal{H}}(\mathbf{v}^{(\ell)}, \mathbf{v}^\star), \tag{4.24}$$

其中 $\mathbf{P}^\star$ 是 (4.2)的唯一解.

证明： 注意，对任意 $(\mathbf{v}, \mathbf{v}') \in (\mathbb{R}^m_{+,*})^2$，有

$$d_{\mathcal{H}}(\mathbf{v}, \mathbf{v}') = d_{\mathcal{H}}(\mathbf{v}/\mathbf{v}', \mathbb{1}_m) = d_{\mathcal{H}}(\mathbb{1}_m/\mathbf{v}, \mathbb{1}_m/\mathbf{v}').$$

由此可得

$$\begin{aligned} d_{\mathcal{H}}(\mathbf{u}^{(\ell+1)}, \mathbf{u}^\star) &= d_{\mathcal{H}}\left(\frac{\mathbf{a}}{\mathbf{K}\mathbf{v}^{(\ell)}}, \frac{\mathbf{a}}{\mathbf{K}\mathbf{v}^\star}\right) \\ &= d_{\mathcal{H}}(\mathbf{K}\mathbf{v}^{(\ell)}, \mathbf{K}\mathbf{v}^\star) \leq \lambda(\mathbf{K}) d_{\mathcal{H}}(\mathbf{v}^{(\ell)}, \mathbf{v}^\star), \end{aligned}$$

这里使用了定理 4.1. 这证明 (4.22). 利用三角不等式，还有

$$\begin{aligned} d_{\mathcal{H}}(\mathbf{u}^{(\ell)}, \mathbf{u}^{\star}) &\leq d_{\mathcal{H}}(\mathbf{u}^{(\ell+1)}, \mathbf{u}^{(\ell)}) + d_{\mathcal{H}}(\mathbf{u}^{(\ell+1)}, \mathbf{u}^{\star}) \\ &\leq d_{\mathcal{H}}\left(\frac{\mathbf{a}}{\mathbf{K}\mathbf{v}^{(\ell)}}, \mathbf{u}^{(\ell)}\right) + \lambda(\mathbf{K})^2 d_{\mathcal{H}}(\mathbf{u}^{(\ell)}, \mathbf{u}^{\star}) \\ &= d_{\mathcal{H}}\left(\mathbf{a}, \mathbf{u}^{(\ell)} \odot (\mathbf{K}\mathbf{v}^{(\ell)})\right) + \lambda(\mathbf{K})^2 d_{\mathcal{H}}(\mathbf{u}^{(\ell)}, \mathbf{u}^{\star}), \end{aligned}$$

由此得到 (4.23)的第一部分，因为 $\mathbf{u}^{(\ell)} \odot (\mathbf{K}\mathbf{v}^{(\ell)}) = \mathbf{P}^{(\ell)}\mathbb{1}_m$（第二部分类似）. 式 (4.24)的证明来自 (Franklin and Lorenz, 1989, 引理 3). □

界 (4.23)表明，某些边缘约束违反量的误差度量，例如 $\|\mathbf{P}^{(\ell)}\mathbb{1}_m - \mathbf{a}\|_1$ 和 $\|\mathbf{P}^{(\ell)^{\mathrm{T}}}\mathbb{1}_n - \mathbf{b}\|_1$，是监测收敛的有效停止准则. 由 (4.21)，缩放变量 $(\mathbf{u}^{(\ell)}, \mathbf{v}^{(\ell)})$ 的 Hilbert 度量收敛速度还给出对偶变量 $(\mathbf{f}^{(\ell)}, \mathbf{g}^{(\ell)}) \stackrel{\text{def.}}{=} (\varepsilon \log(\mathbf{u}^{(\ell)}), \varepsilon \log(\mathbf{v}^{(\ell)}))$ 在变差范数 $\|\cdot\|_{\mathrm{var}}$ 下的线性收敛速度.

图 4.5下排突出展示约束违反量的线性收敛，并说明此速度如何在 $\varepsilon \to 0$ 时恶化. 这些结果证明于 (Franklin and Lorenz, 1989)，并与非线性 Perron–Frobenius 理论密切相关 (Lemmens and Nussbaum, 2012). Perron–Frobenius 理论对应于迭代的线性化；见 (4.25). (Linial et al., 1998) 扩展了此收敛分析，表明每次 Sinkhorn 迭代都增加缩放后耦合矩阵的积和式.

注 4.15 (局部收敛)**.** 全局线性速度 (4.24)通常相当保守，典型情形是在 $\mathcal{X} = \mathcal{Y} = \mathbb{R}^d$ 中，$\varepsilon = 0$ 时存在 Monge 映射（见注 2.7）. 相反，在代价矩阵 $\mathbf{C}$ 接近随机的较困难情形中，全局速度相当精确，此时速度随 ε 按指数恶化：$1 - \lambda(\mathbf{K}) \sim e^{-1/\varepsilon}$. 为了更精细地分析收敛的渐近行为（例如需要高精度解并执行大量迭代时），通常转而研究局部收敛速度. 一次 Sinkhorn 更新可写成不动点映射的迭代 $\mathbf{f}^{(\ell+1)} = \Phi(\mathbf{f}^{(\ell)})$，其中

$$\Phi \stackrel{\text{def.}}{=} \Phi_2 \odot \Phi_1 \quad \text{其中} \quad \begin{cases} \Phi_1(\mathbf{f}) = \varepsilon \log \mathbf{K}^{\mathrm{T}}(e^{\mathbf{f}/\varepsilon}) - \log(\mathbf{b}), \\ \Phi_2(\mathbf{g}) = \varepsilon \log \mathbf{K}(e^{\mathbf{g}/\varepsilon}) - \log(\mathbf{a}). \end{cases}$$

对于求解 (4.30)的最优 $(\mathbf{f}, \mathbf{g})$，记 $\mathbf{P} = \mathrm{diag}(e^{\mathbf{f}/\varepsilon})\mathbf{K}\,\mathrm{diag}(e^{\mathbf{g}/\varepsilon})$ 为求解 (4.2)的最优耦合，则 Jacobian 为

$$\partial\Phi(\mathbf{f}) = \mathrm{diag}(\mathbf{a})^{-1} \odot \mathbf{P} \odot \mathrm{diag}(\mathbf{b})^{-1} \odot \mathbf{P}^{\mathrm{T}}. \tag{4.25}$$

此 Jacobian 是正矩阵，且 $\partial\Phi(\mathbf{f})\mathbb{1}_n = \mathbb{1}_n$，故由 Perron–Frobenius 定理，它有唯一主特征向量 $\mathbb{1}_m$，对应特征值 1. 由于 $\mathbf{f}$ 只确定到一个常数，真正控制局部线性速度的是第二特征值 $1 - \kappa < 1$，因此当 ℓ 足够大时，

$$\|\mathbf{f}^{(\ell)} - \mathbf{f}\| = O((1-\kappa)^{\ell}).$$

数值上，在“简单情形”（例如 $\varepsilon = 0$ 时存在光滑 Monge 映射）中，这一速度满足 $\kappa \sim \varepsilon$. 双随机（指派）情形的更多细节见 (Knight, 2008).

4.3 加速 Sinkhorn 迭代

Sinkhorn 迭代的主要计算瓶颈是与核 $\mathbf{K}, \mathbf{K}^\top$ 的矩阵与向量乘法，朴素实现的复杂度为 $O(nm)$. 下面详述可显著改进复杂度的几种重要情形.

注 4.16 (适合并行与 GPU 的计算)**.** Sinkhorn 算法形式简单，因而能极高效地同时计算多对直方图之间的正则化 Wasserstein 距离. 设 N 为整数，$\mathbf{a}_1, \dots, \mathbf{a}_N$ 为 Σ_n 中的直方图，$\mathbf{b}_1, \dots, \mathbf{b}_N$ 为 Σ_m 中的直方图. 目标是计算全部 N 个近似距离 $\mathrm{L}^\varepsilon_{\mathbf{C}}(\mathbf{a}_1, \mathbf{b}_1), \dots, \mathrm{L}^\varepsilon_{\mathbf{C}}(\mathbf{a}_N, \mathbf{b}_N)$. 此时，用 $n \times N$ 矩阵 $\mathbf{A} = [\mathbf{a}_1, \dots, \mathbf{a}_N]$ 和 $m \times N$ 矩阵 $\mathbf{B} = [\mathbf{b}_1, \dots, \mathbf{b}_N]$ 存储所有直方图，即可并行执行这 N 对输入的全部 Sinkhorn 迭代，例如设置

$$\mathbf{U}^{(\ell+1)} \overset{\text{def.}}{=} \frac{\mathbf{A}}{\mathbf{K}\mathbf{V}^{(\ell)}} \quad \text{且} \quad \mathbf{V}^{(\ell+1)} \overset{\text{def.}}{=} \frac{\mathbf{B}}{\mathbf{K}^{\mathrm{T}}\mathbf{U}^{(\ell+1)}}, \tag{4.26}$$

初值为 $\mathbf{V}^{(0)} = \mathbb{1}_{m \times N}$. 这里 $\frac{\cdot}{\cdot}$ 表示矩阵的逐分量除法. 还可验证，当 $\mathbf{V}, \mathbf{U}$ 收敛时，正则化距离组成的行向量简化为

$$\mathbb{1}_n{}^{\mathrm{T}}(\mathbf{U} \odot \log \mathbf{U} \odot ((\mathbf{K} \odot \mathbf{C})\mathbf{V}) + \mathbf{U} \odot ((\mathbf{K} \odot \mathbf{C})(\mathbf{V} \odot \log \mathbf{V}))) \in \mathbb{R}^N.$$

式 (4.15)中的基本 Sinkhorn 迭代本身适合 GPU，因为只包含矩阵与向量的乘积；例如 Slomp et al. (2011) 利用这一点求解匹配问题. 而 (4.26)中的矩阵乘法提供更多并行机会，这解释了 Sinkhorn 算法在大规模计算直方图间最优传输距离时的成功.

注 4.17 (可分离核的加速)**.** 本注考虑一种重要特殊情形，其中每次 Sinkhorn 迭代的复杂度可显著降低. 代价矩阵中的每个指标 i, j 都可写成 d 个有限集 $[\![n_1]\!], \dots, [\![n_d]\!]$ 的笛卡儿积中的 d 元组：

$$i = (i_k)_{k=1}^d, j = (j_k)_{k=1}^d \in [\![n_1]\!] \times \cdots \times [\![n_d]\!].$$

在此情形下，若指标 i, j 之间的代价 $\mathbf{C}_{ij}$ 关于这些子指标可加，即存在 d 个矩阵 $\mathbf{C}^1, \dots, \mathbf{C}^d$，大小分别为 $n_1 \times n, \dots, n_d \times n_d$，使得

$$\mathbf{C}_{ij} = \sum_{k=1}^d \mathbf{C}^k_{i_k, j_k},$$

则直接得到 Sinkhorn 迭代中的核具有可分离的乘法结构：

$$\mathbf{K}_{i,j} = \prod_{k=1}^d \mathbf{K}^k_{i_k, j_k}. \tag{4.27}$$

这种可分离结构允许极快地精确计算 $\mathbf{K}\mathbf{u}$. 事实上，无须构造 $n \times n$ 矩阵 $\mathbf{K}$（由于 $n = \prod_k n_k$ 通常随维数 d 指数增长，其规模难以承受），只需沿 $\mathbf{u}$ 的每个“切片”分别作用 $\mathbf{K}^k$，便可恢复 $\mathbf{K}\mathbf{u}$. 当 $n = m$ 时，复杂度从 $O(n^2)$ 降为 $O(n^{1+1/d})$.

一个重要例子是 $\mathcal{X} = \mathcal{Y} = [0,1]^d$，基础代价为 q-范数的 q 次幂，

$$c(x, y) = \|x - y\|_q^q = \sum_{i=1}^d |x_i - y_i|^q, \qquad q > 0,$$

并在规则网格上离散，只考虑 $x_i = (i_1/n_1, \ldots, i_d/n_d)$，其中 $i = (i_1, \ldots, i_d) \in [\![n_1]\!] \times \cdots \times [\![n_d]\!]$. 此时，与 $\mathbf{K}$ 的乘法可以更高效地进行：将 $\mathbf{u}$ 重排为张量，并置换其首维，使之对应第 k 组指标，再作用各个一维 $n_k \times n_k$ 卷积矩阵

$$\mathbf{K}^k = \left[\exp(-|\tfrac{r-s}{n_k}|^q/\varepsilon)\right]_{1\leq r,s\leq n_k}.$$

例如，当 $d = 2$（平面情形）、$q = 2$（2-Wasserstein，对应 Gaussian 卷积）时，直方图 $\mathbf{a}$ 以及 Sinkhorn 乘子 $\mathbf{u}$ 可以存为 $n_1 \times n_2$ 矩阵. 用 $\mathbf{U}$ 强调 $\mathbf{u}$ 已重排为 $n_1 \times n_2$ 矩阵，而非长度为 $n_1 n_2$ 的向量. 朴素计算 $\mathbf{Ku}$ 需要 $(n_1 n_2)^2$ 次运算，但分别应用两个一维卷积，

$$(\mathbf{K}^2(\mathbf{K}^1\mathbf{U})^T)^T = \mathbf{K}^1\mathbf{U}\mathbf{K}^2,$$

便可用 $(n_1^2)n_2 + n_1(n_2^2)$ 次运算恢复 $n_1 \times n_2$ 矩阵，代替 $n_1^2 n_2^2$ 次运算. 此例与上述指数 $(1 + 1/d)$ 一致. 在更高维度，只需对 $\mathbf{u}$（重排为适当大小的张量）的各切片应用同样的一维卷积，这在 GPU 上非常高效.

这一重要观察支撑了最优传输处理二维、三维形状数据的许多实际成功，例如 (Solomon et al., 2015; Bonneel et al., 2016) 可处理支撑在规模达 $200^3 = 8 \times 10^6$ 网格上的分布.

注 4.18 (近似卷积). Sinkhorn 迭代 (4.15)的主要计算瓶颈是向量与 $\mathbf{K}$ 或其伴随相乘. 除了利用可分离性 (4.27)，还可利用核的其他特殊结构. 最简单的是平移不变核 $\mathbf{K}_{i,j} = k_{i-j}$，这通常出现在 Euclidean 空间 $\mathcal{X} = \mathbb{R}^d$ 的固定均匀网格上离散测度时. 此时 $\mathbf{Kv} = k \star \mathbf{v}$ 是卷积，有多种算法可在近线性时间内近似它. 最常用的方法是 Fourier 变换 $\mathcal{F}$；为简便起见假设周期边界条件，则 $\mathcal{F}(k \star \mathbf{v}) = \mathcal{F}(k) \odot \mathcal{F}(\mathbf{v})$. 然而这会造成数值不稳定，在 ε 较小时通常不可接受. 另一种常用加速方法是通过连续的自回归滤波器近似卷积，例如 Deriche 滤波方法 Deriche (1993). 各种快速滤波方法的比较见 (Getreuer, 2013).

注 4.19 (热核测地距离近似). 在非平面区域上，核 $\mathbf{K}$ 不再是卷积；但当代价为 $\mathbf{C}_{i,j} = d_{\mathcal{M}}(x_i, y_j)^p$，其中 $d_{\mathcal{M}}$ 是曲面 $\mathcal{M}$（或更一般流形）上的测地距离时，仍可快速近似 $\mathbf{K} = e^{-\frac{d_{\mathcal{M}}}{\varepsilon}}$ 对向量的作用. Varadhan的公式 (1967) 表明，此核接近 Laplace 核（$p = 1$）或热核（$p = 2$）. Varadhan 的第一个公式为

$$-\frac{\sqrt{t}}{2}\log(\mathcal{P}_t(x,y)) = d_{\mathcal{M}}(x,y) + o(t) \quad \text{其中} \quad \mathcal{P}_t \overset{\text{def.}}{=} (\mathrm{Id} - t\Delta_{\mathcal{M}})^{-1}, \tag{4.28}$$

其中 $\Delta_{\mathcal{M}}$ 是流形 $\mathcal{M}$ 对应的 Laplace–Beltrami 算子（它是负半定的），因而 $\mathcal{P}_t$ 是积分核，$g = \int_{\mathcal{M}} \mathcal{P}_t(x,y) f(y)\mathrm{d}y$ 是 $g - t\Delta_{\mathcal{M}} g = f$ 的解. Varadhan 的第二个公式为

$$\sqrt{-4t\log(\mathcal{H}_t(x,y))} = d_{\mathcal{M}}(x,y) + o(t), \tag{4.29}$$

其中积分核 $\mathcal{H}_t$ 的定义使得 $g_t = \int_{\mathcal{M}} \mathcal{H}_t(x,y) f(y)\mathrm{d}y$ 是热方程在时刻 t 的解：

$$\frac{\partial g_t(x)}{\partial t} = (\Delta_{\mathcal{M}} g_t)(x).$$

公式 (4.28)和 (4.29)中的收敛在紧流形上一致成立. 数值上，将区域 $\mathcal{M}$ 离散（例如用有限元），以离散 Laplace 矩阵 L 近似 $\Delta_{\mathcal{M}}$. 典型例子是分片线性有限元，此时 L 为著名的余切 Laplace 算子（此构造详见 (Botsch et al., 2010)）. 这些公式可以高效近似与 Gibbs 核 $\mathbf{K}_{i,j} = e^{-\frac{d(x_i,y_j)^p}{\varepsilon}}$ 的乘法. 对于 $p=1$，式 (4.28)提示取 $\varepsilon = \frac{\sqrt{t}}{2}$，将与 $\mathbf{K}$ 相乘替换为与 $(\mathrm{Id} - tL)^{-1}$ 相乘，这需要求解对称正定线性系统. 对于 $p=2$，式 (4.29)结合用于稳定求解热流的 R 步隐式 Euler 方法，提示在 $4t = \varepsilon$ 时将与 $\mathbf{K}$ 相乘替换为与 $(\mathrm{Id} - \frac{t}{R}L)^{-R}$ 相乘，从而需要求解 R 个线性系统. 幸运的是，每次 Sinkhorn 迭代都要求解这些系统，因此可预先计算稀疏 Cholesky 分解来高效求解. 通过重排行、列 (George and Liu, 1989)，可在二维流形上得到近线性的稀疏度，因而每次 Sinkhorn 迭代具有线性复杂度（性能随流形维数增加而下降）. (Crane et al., 2013) 最初提出用 Varadhan 公式近似测地距离，(Solomon et al., 2015) 则将其与 Sinkhorn 迭代结合.

注 4.20 (外推加速)**.** 由于 Sinkhorn 是不动点算法（见注 4.15），可使用标准线性乃至非线性外推方法，改善解附近不动点映射的条件性，提升线性收敛速度. 这类似于逐次超松弛方法（例如 (Hadjidimos, 2000)），对于某个 $\kappa > 0$，局部线性收敛速度从 $O((1-\kappa)^\ell)$ 改善为 $O((1-\sqrt{\kappa})^\ell)$（见注 4.15）. 更多细节见 (Peyré et al., 2017).

4.4 稳定性与对数域计算

如注 4.7简述，当正则化参数 ε 相比代价矩阵 $\mathbf{C}$ 的元素较小时，Sinkhorn 算法会发生数值溢出. 在对数域中计算可在一定程度上缓解此问题. 考察 (4.2)的对偶问题能够更清楚地说明这一方法，因为对数域计算在其中自然出现.

命题 4.4. 有

$$\mathrm{L}_{\mathbf{C}}^{\varepsilon}(\mathbf{a},\mathbf{b}) = \max_{\mathbf{f}\in\mathbb{R}^n,\mathbf{g}\in\mathbb{R}^m} \langle \mathbf{f},\mathbf{a}\rangle + \langle \mathbf{g},\mathbf{b}\rangle - \varepsilon\langle e^{\mathbf{f}/\varepsilon}, \mathbf{K}e^{\mathbf{g}/\varepsilon}\rangle. \tag{4.30}$$

最优 $(\mathbf{f},\mathbf{g})$ 与 (4.12)中的缩放 $(\mathbf{u},\mathbf{v})$ 通过下式联系：

$$(\mathbf{u},\mathbf{v}) = (e^{\mathbf{f}/\varepsilon}, e^{\mathbf{g}/\varepsilon}). \tag{4.31}$$

证明： 从命题 4.3证明的末尾出发，最优原始解 $\mathbf{P}$ 与边缘约束的对偶乘子 $\mathbf{f},\mathbf{g}$ 满足

$$\mathbf{P}_{i,j} = e^{\mathbf{f}_i/\varepsilon} e^{-\mathbf{C}_{i,j}/\varepsilon} e^{\mathbf{g}_j/\varepsilon}.$$

在 (4.2)的 Lagrange 函数 $\mathcal{E}(\mathbf{P},\mathbf{f},\mathbf{g})$ 中代入作为 $\mathbf{f},\mathbf{g}$ 函数的最优 $\mathbf{P}$，得到 Lagrange 对偶函数

$$\mathbf{f},\mathbf{g} \mapsto \langle e^{\mathbf{f}/\varepsilon}, (\mathbf{K}\odot\mathbf{C})\, e^{\mathbf{g}/\varepsilon}\rangle - \varepsilon\mathbf{H}(\mathrm{diag}(e^{\mathbf{f}/\varepsilon})\mathbf{K}\,\mathrm{diag}(e^{\mathbf{g}/\varepsilon})). \tag{4.32}$$

$\mathbf{P}$ 的负熵乘以 ε，即 $\varepsilon\langle \mathbf{P}, \log\mathbf{P} - \mathbb{1}_{n\times m}\rangle$，可显式写成 $\mathbf{f},\mathbf{g},\mathbf{C}$ 的函数：

$$\begin{aligned}&\langle \mathrm{diag}(e^{\mathbf{f}/\varepsilon})\mathbf{K}\,\mathrm{diag}(e^{\mathbf{g}/\varepsilon}),\ \mathbf{f}\mathbb{1}_m{}^{\mathrm{T}} + \mathbb{1}_n\mathbf{g}^{\mathrm{T}} - \mathbf{C} - \varepsilon\mathbb{1}_{n\times m}\rangle\\ &= -\langle e^{\mathbf{f}/\varepsilon}, (\mathbf{K}\odot\mathbf{C})\, e^{\mathbf{g}/\varepsilon}\rangle + \langle \mathbf{f},\mathbf{a}\rangle + \langle \mathbf{g},\mathbf{b}\rangle - \varepsilon\langle e^{\mathbf{f}/\varepsilon}, \mathbf{K}e^{\mathbf{g}/\varepsilon}\rangle;\end{aligned}$$

因此，(4.32)中的首项与上述熵的首项抵消，剩下的项正是 (4.30)中的各项. □

注 4.21 (Sinkhorn 是对偶问题的块坐标上升)**.** 求解无约束最大化问题 (4.30)的简单办法是采用精确的块坐标上升(block coordinate ascent)策略，即交替更新 $\mathbf{f},\mathbf{g}$，使 (4.30)目标关于相应变量的梯度为零. 事实上，用 $Q(\mathbf{f},\mathbf{g})$ 表示目标函数，经过简单计算得到

$$\nabla|_{\mathbf{f}}\, Q(\mathbf{f},\mathbf{g}) = \mathbf{a} - e^{\mathbf{f}/\varepsilon} \odot \left(\mathbf{K} e^{\mathbf{g}/\varepsilon}\right), \tag{4.33}$$

$$\nabla|_{\mathbf{g}}\, Q(\mathbf{f},\mathbf{g}) = \mathbf{b} - e^{\mathbf{g}/\varepsilon} \odot \left(\mathbf{K}^{\mathrm{T}} e^{\mathbf{f}/\varepsilon}\right). \tag{4.34}$$

因此，块坐标上升可用闭式更新实现：从任意 $\mathbf{g}^{(0)}$ 出发，对 $l \geq 0$，依次执行

$$\mathbf{f}^{(\ell+1)} = \varepsilon \log \mathbf{a} - \varepsilon \log \left(\mathbf{K} e^{\mathbf{g}^{(\ell)}/\varepsilon}\right), \tag{4.35}$$

$$\mathbf{g}^{(\ell+1)} = \varepsilon \log \mathbf{b} - \varepsilon \log \left(\mathbf{K}^{\mathrm{T}} e^{\mathbf{f}^{(\ell+1)}/\varepsilon}\right). \tag{4.36}$$

根据 (4.31)中的原始与对偶关系，这些迭代在数学上等价于 Sinkhorn 迭代 (4.15). 事实上，在任意迭代步都有

$$(\mathbf{f}^{(\ell)}, \mathbf{g}^{(\ell)}) = \varepsilon(\log(\mathbf{u}^{(\ell)}), \log(\mathbf{v}^{(\ell)})).$$

注 4.22 (用软最小值改写)**.** 利用以下记号可为迭代 (4.35)和 (4.36)赋予另一种解释. 对实向量 $\mathbf{z}$，用 $\min_\varepsilon \mathbf{z}$ 表示其分量的软最小值 (soft-minimum)，即

$$\min_\varepsilon \mathbf{z} = -\varepsilon \log \sum_i e^{-\mathbf{z}_i/\varepsilon}. \tag{4.37}$$

对任意向量 $\mathbf{z}$，当 $\varepsilon \to 0$ 时，$\min_\varepsilon(\mathbf{z})$ 收敛到 $\min \mathbf{z}$. 事实上，$\min_\varepsilon$ 可以解释为 min 函数的可微近似，如图 4.9所示.

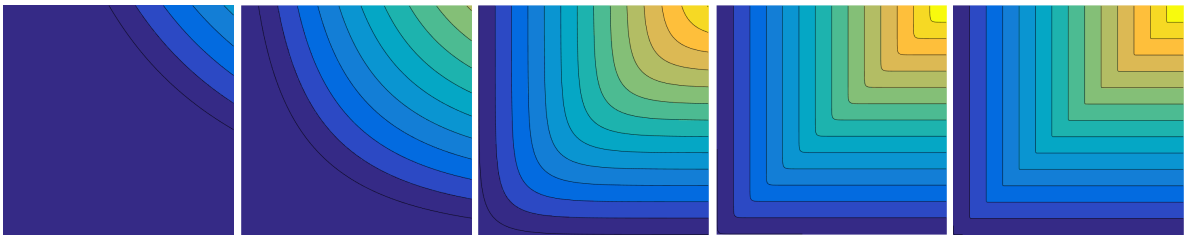

$\varepsilon = 1$　　$\varepsilon = 0.5$　　$\varepsilon = 10^{-1}$　　$\varepsilon = 10^{-2}$　　$\varepsilon = 10^{-3}$

图 4.9: 二维向量 $\mathbf{z} \in \mathbb{R}^2$ 下，函数 $\min_\varepsilon(\mathbf{z})$ 随 ε 的变化.

利用此记号，式 (4.35)和 (4.36)可改写为

$$(\mathbf{f}^{(\ell+1)})_i = \min_\varepsilon{}_j\, (\mathbf{C}_{ij} - \mathbf{g}_j^{(\ell)}) + \varepsilon \log \mathbf{a}_i, \tag{4.38}$$

$$(\mathbf{g}^{(\ell+1)})_j = \min_\varepsilon{}_i\, (\mathbf{C}_{ij} - \mathbf{f}_i^{(\ell)}) + \varepsilon \log \mathbf{b}_j. \tag{4.39}$$

此处 $\min_\varepsilon{}_j\,(\mathbf{C}_{ij} - \mathbf{g}_j^{(\ell)})$ 表示矩阵 $(\mathbf{C} - \mathbb{1}_n(\mathbf{g}^{(\ell)})^\top)$ 第 j 列所有数值的软最小值. 为简化记号，引入以矩阵为输入、以各列或各行软最小值组成的列向量为输出的算子. 具体而言，对任意矩阵 $A \in \mathbb{R}^{n\times m}$，定义

$$\mathrm{Min}_\varepsilon^{\mathrm{row}}(\mathbf{A}) \overset{\text{def.}}{=} \left(\min_\varepsilon{}_j\, (\mathbf{A}_{i,j})_j\right)_i \in \mathbb{R}^n,$$

$$\mathrm{Min}_\varepsilon^{\mathrm{col}}(\mathbf{A}) \overset{\text{def.}}{=} \left(\min_\varepsilon{}_i\, (\mathbf{A}_{i,j})_i\right)_j \in \mathbb{R}^m.$$

注意，这些操作等价于第 5.3节引入的熵 c-变换（特别参见 (5.11)）. 用此记号，Sinkhorn 迭代写为

$$\mathbf{f}^{(\ell+1)} = \mathrm{Min}_\varepsilon^{\mathrm{row}}\,(\mathbf{C} - \mathbb{1}_n \mathbf{g}^{(\ell)\mathrm{T}}) + \varepsilon \log \mathbf{a}, \tag{4.40}$$

$$\mathbf{g}^{(\ell+1)} = \mathrm{Min}_\varepsilon^{\mathrm{col}}\,(\mathbf{C} - \mathbf{f}^{(\ell)} \mathbb{1}_m{}^{\mathrm{T}}) + \varepsilon \log \mathbf{b}. \tag{4.41}$$

当 $\varepsilon \to 0$ 时，$\min_\varepsilon$ 收敛到 min，但在极限 $\varepsilon = 0$ 下迭代不再收敛，因为交替最小化对约束问题不保证收敛，而未正则化对偶 (2.20)正是约束问题.

注 4.23 (对数域 Sinkhorn)**.** 虽然迭代 (4.38)和 (4.39)在数学上与 Sinkhorn 更新 (4.15)等价，但它们提示使用指数和的对数（log-sum-exp）稳定化技巧，以避免较小 ε 下的下溢. 记 $\underline{z} = \min \mathbf{z}$，此技巧将 $\min_\varepsilon \mathbf{z}$ 计算为

$$\min_\varepsilon \mathbf{z} = \underline{z} - \varepsilon \log \sum_i e^{-(\mathbf{z}_i - \underline{z})/\varepsilon}. \tag{4.42}$$

除了像 (4.42)那样减去 $\underline{z}$ 来稳定对数域迭代，也可减去此前计算的缩放量. 这给出稳定化迭代

$$\mathbf{f}^{(\ell+1)} = \mathrm{Min}_\varepsilon^{\mathrm{row}}\,(\mathbf{S}(\mathbf{f}^{(\ell)}, \mathbf{g}^{(\ell)})) + \mathbf{f}^{(\ell)} + \varepsilon \log(\mathbf{a}), \tag{4.43}$$

$$\mathbf{g}^{(\ell+1)} = \mathrm{Min}_\varepsilon^{\mathrm{col}}\,(\mathbf{S}(\mathbf{f}^{(\ell+1)}, \mathbf{g}^{(\ell)})) + \mathbf{g}^{(\ell)} + \varepsilon \log(\mathbf{b}), \tag{4.44}$$

其中定义

$$\mathbf{S}(\mathbf{f}, \mathbf{g}) = (\mathbf{C}_{i,j} - \mathbf{f}_i - \mathbf{g}_j)_{i,j}.$$

与原迭代 (4.15)不同，对数域迭代 (4.43)和 (4.44)对任意 $\varepsilon > 0$ 都稳定，因为 $\mathbf{S}(\mathbf{f}, \mathbf{g})$ 在迭代过程中保持有界. 缺点是每一步需要计算 nm 次 exp. 计算 $\mathrm{Min}_\varepsilon^{\mathrm{row}}$ 或 $\mathrm{Min}_\varepsilon^{\mathrm{col}}$ 通常明显慢于矩阵乘法，而且需要逐行计算矩阵 $\mathbf{S}$ 的软最小值. 因而无法高效并行地对多个边缘分布同时应用 Sinkhorn 映射. 在低维 Euclidean 区域中，可采用递减 ε 策略发展高效的多尺度求解器，利用稀疏网格显著加速计算 (Schmitzer, 2016b).

注 4.24 (一般测度的对偶)**.** 对于一般的、未必离散的输入测度 (α, β)，对偶问题 (4.30)写为

$$\sup_{(f,g)\in\mathcal{C}(\mathcal{X})\times\mathcal{C}(\mathcal{Y})} \int_{\mathcal{X}} f \mathrm{d}\alpha + \int_{\mathcal{Y}} g \mathrm{d}\beta - \varepsilon \int_{\mathcal{X}\times\mathcal{Y}} e^{\frac{-c(x,y)+f(x)+g(y)}{\varepsilon}} \mathrm{d}\alpha(x)\mathrm{d}\beta(y). \tag{4.45}$$

这相当于平滑原问题 (2.24)中的约束 $\mathcal{R}(c)$，在 $\varepsilon \to 0$ 的极限下恢复原问题. 在熵传输情形下，证明这些 Kantorovich 势 (f, g) 的存在性（即上确界实际为最大值）比经典最优传输更困难，因为不能使用 c-变换，且势不自动具有 Lipschitz 性. 可利用 Sinkhorn 迭代的收敛证明存在性；详见 (Chizat et al., 2018b).

注 4.25 (无约束熵对偶). 与注 2.23类似，当 $\int_{\mathcal{X}} \mathrm{d}\alpha = \int_{\mathcal{Y}} \mathrm{d}\beta = 1$ 时，可考虑另一种对偶形式

$$\sup_{(f,g)\in\mathcal{C}(\mathcal{X})\times\mathcal{C}(\mathcal{Y})} \int_{\mathcal{X}} f\mathrm{d}\alpha + \int_{\mathcal{Y}} g\mathrm{d}\beta + \min_\varepsilon (c - f \oplus g), \tag{4.46}$$

其最优值与 (4.45)相同. 与 (4.37)类似，此处 $\mathcal{X}\times\mathcal{Y}$ 上的软最小值定义为

$$\forall\, S \in \mathcal{C}(\mathcal{X}\times\mathcal{Y}), \quad \min_\varepsilon S \stackrel{\text{def.}}{=} -\varepsilon \int_{\mathcal{X}\times\mathcal{Y}} e^{\frac{-S(x,y)}{\varepsilon}} \mathrm{d}\alpha(x)\mathrm{d}\beta(y)$$

(注意，它依赖于 (α,β)) . 当 $\varepsilon \to 0$ 时，$\min_\varepsilon \to \min$，如未正则化的无约束形式 (2.27)中所用的那样. 虽然 (4.45)和 (4.46)都是无约束问题，但 (4.46)的主要优点是条件性更好，即该泛函的 Hessian 一致地被 ε 控制. 另一种改善条件性的办法是考虑半对偶问题；见第 5.3节，特别是注 5.1. 这一替代对偶形式的缺点是其中的对数阻碍使用第 5.4节详述的随机优化方法；特别参见注 5.3.

4.5 最优传输代价的正则化近似

熵对偶 (4.30)是光滑无约束凹最大化问题，它近似原始 Kantorovich 对偶 (2.20)，如以下命题所述.

命题 4.5. 问题 (4.30)的任意一对最优解 $(\mathbf{f}^\star, \mathbf{g}^\star)$ 都属于 $\mathbf{R}(\mathbf{C})$，即 (2.21)定义的可行 Kantorovich 势集合. 因而，对任意 ε，有

$$\langle \mathbf{f}^\star, \mathbf{a}\rangle + \langle \mathbf{g}^\star, \mathbf{b}\rangle \leq \mathrm{L}_{\mathbf{C}}(\mathbf{a},\mathbf{b}).$$

证明： 由 (4.4)中的原始与对偶最优性条件，以及 $\mathbf{P}$ 是概率、因而对所有 i,j 有 $\mathbf{P}_{i,j} \leq 1$，得到 $\exp(-(\mathbf{f}^\star_i + \mathbf{g}^\star_j - \mathbf{C}_{i,j})/\varepsilon) \leq 1$，进而 $\mathbf{f}^\star_i + \mathbf{g}^\star_j \leq \mathbf{C}_{i,j}$. □

式 (4.2)定义的正则化传输代价 $\mathrm{L}^\varepsilon_{\mathbf{C}}$ 的主要优势是光滑且凸，因此很适合作为损失函数纳入变分问题（见第 9章）.

命题 4.6. 当 $\varepsilon \geq 0$ 时，$\mathrm{L}^\varepsilon_{\mathbf{C}}(\mathbf{a},\mathbf{b})$ 关于 $\mathbf{a},\mathbf{b}$ 联合凸. 当 $\varepsilon > 0$ 时，其梯度为

$$\nabla \mathrm{L}^\varepsilon_{\mathbf{C}}(\mathbf{a},\mathbf{b}) = \begin{bmatrix} \mathbf{f}^\star \\ \mathbf{g}^\star \end{bmatrix},$$

其中 $\mathbf{f}^\star, \mathbf{g}^\star$ 是 (4.30)的最优解，选取它们使各自分量之和为零.

(Cuturi, 2013) 提出用于近似两个直方图之间 Wasserstein 距离的下界和上界. 这些界通过在 Sinkhorn 算法所得解处计算原始、对偶目标而得到.

定义 4.1 (Sinkhorn 散度). 设 $\mathbf{f}^\star, \mathbf{g}^\star$ 是 (4.30)的最优解，$\mathbf{P}^\star$ 是 (4.2)的解. 可用以下原始、对偶Sinkhorn 散度 (Sinkhorn divergence) 近似 Wasserstein 距离：

$$\mathfrak{P}^\varepsilon_{\mathbf{C}}(\mathbf{a},\mathbf{b}) \stackrel{\text{def.}}{=} \langle \mathbf{C}, \mathbf{P}^\star\rangle = \langle e^{\frac{\mathbf{f}^\star}{\varepsilon}}, (\mathbf{K}\odot\mathbf{C}) e^{\frac{\mathbf{g}^\star}{\varepsilon}}\rangle,$$
$$\mathfrak{D}^\varepsilon_{\mathbf{C}}(\mathbf{a},\mathbf{b}) \stackrel{\text{def.}}{=} \langle \mathbf{f}^\star, \mathbf{a}\rangle + \langle \mathbf{g}^\star, \mathbf{b}\rangle,$$

其中 $\odot$ 表示矩阵的逐分量乘积.

命题 4.7. 有如下关系：

$$\mathfrak{D}_{\mathbf{C}}^{\varepsilon}(\mathbf{a},\mathbf{b}) \leq \mathrm{L}_{\mathbf{C}}^{\varepsilon}(\mathbf{a},\mathbf{b}) \leq \mathfrak{P}_{\mathbf{C}}^{\varepsilon}(\mathbf{a},\mathbf{b}).$$

此外，

$$\mathfrak{P}_{\mathbf{C}}^{\varepsilon}(\mathbf{a},\mathbf{b}) - \mathfrak{D}_{\mathbf{C}}^{\varepsilon}(\mathbf{a},\mathbf{b}) = \varepsilon(\mathbf{H}(\mathbf{P}^{\star}) + 1). \tag{4.47}$$

证明： 在最优点处原始、对偶问题的值相同（见 (4.30)），由此得到 (4.47)，因为

$$\mathrm{L}_{\mathbf{C}}^{\varepsilon}(\mathbf{a},\mathbf{b}) = \mathfrak{P}_{\mathbf{C}}^{\varepsilon}(\mathbf{a},\mathbf{b}) - \varepsilon\mathbf{H}(\mathbf{P}^{\star}) = \mathfrak{D}_{\mathbf{C}}^{\varepsilon}(\mathbf{a},\mathbf{b}) - \varepsilon\langle e^{\mathbf{f}^{\star}/\varepsilon}, \mathbf{K}e^{\mathbf{g}^{\star}/\varepsilon}\rangle$$

注意 $\langle e^{\mathbf{f}^{\star}/\varepsilon}, \mathbf{K}e^{\mathbf{g}^{\star}/\varepsilon}\rangle = 1$，因为它等于 $\mathbf{P}^{\star}$ 所有分量之和，即得最终结果. □

上述关系提示了给真实最优传输距离提供界的实际方法，但它们仅在 Sinkhorn 算法收敛后成立，因此实际中无法真正直接使用. 实际计算总是在达到某个精度阈值后终止迭代. 不过，若预先固定迭代次数 L，以迭代值 $\mathbf{f}^{(L)}, \mathbf{g}^{(L)}$ 代替最优解 $\mathbf{f}^{\star}, \mathbf{g}^{\star}$ 来计算 $\mathfrak{D}_{\mathbf{C}}^{\varepsilon}$，仍能得到下界. 采用 (4.43)和 (4.44)中的记号，引入 $\mathrm{L}_{\mathbf{C}}^{\varepsilon}$ 的有限步近似：

$$\mathfrak{D}_{\mathbf{C}}^{(L)}(\mathbf{a},\mathbf{b}) \stackrel{\text{def.}}{=} \langle \mathbf{f}^{(L)}, \mathbf{a}\rangle + \langle \mathbf{g}^{(L)}, \mathbf{b}\rangle. \tag{4.48}$$

只要 $L \geq 1$，这一 “算法” Sinkhorn 泛函便是正则化代价函数的下界.

命题 4.8 (有限步 Sinkhorn 散度)**.** 有如下关系：

$$\mathfrak{D}_{\mathbf{C}}^{(L)}(\mathbf{a},\mathbf{b}) \leq \mathrm{L}_{\mathbf{C}}^{\varepsilon}(\mathbf{a},\mathbf{b}).$$

证明： 与命题 4.5的证明类似，即使只执行一次 Sinkhorn 迭代，由 (4.35)和 (4.36)，$\mathbf{f}^{(L)}, \mathbf{g}^{(L)}$ 也使元素为 $\exp(-(\mathbf{f}_i^{(L)} + \mathbf{g}_j^{(L)} - \mathbf{C}_{i,j})/\varepsilon)$ 的矩阵列和为 $\mathbf{b}$，故每个元素都不超过 1，从而 $(\mathbf{f}_i^{(L)}, \mathbf{g}^{(L)})$ 对偶可行. □

注 4.26 (Sinkhorn 迭代的原始不可行性)**.** 式 (4.8)给出的原始迭代值并不原始可行，因为这些迭代只保证收敛时满足边缘约束. 因此，不能将 $\langle \mathbf{C}, \mathbf{P}^{(2L+1)}\rangle$ 作为 $\mathrm{L}_{\mathbf{C}}(\mathbf{a},\mathbf{b})$ 的近似，因为 $\mathbf{P}^{(2L+1)}$ 不可行. 然而，使用注 4.6中的 Altschuler et al. (2017) 舍入方法可以给出 $\mathrm{L}_{\mathbf{C}}^{\varepsilon}(\mathbf{a},\mathbf{b})$ 的上界；而且与 Sinkhorn 算法类似，可用矩阵运算方便地并行计算多对直方图 (Lacombe et al., 2018).

注 4.27 (有限步对偶 Sinkhorn 散度的非凸性)**.** 与 (4.30)中的正则化表达式 $\mathrm{L}_{\mathbf{C}}^{\varepsilon}$ 不同，有限步 Sinkhorn 散度 $\mathfrak{D}_{\mathbf{C}}^{(L)}(\mathbf{a},\mathbf{b})$ 一般不是关于自变量的凸函数（数值上容易验证）. 不过，它是可微函数，可用自动微分技术（见注 9.1.3）对任意自变量求导，尤其是 $\mathbf{C}, \mathbf{a}, \mathbf{b}$.

4.6 广义 Sinkhorn

正则化最优传输问题 (4.2)是以下结构化凸优化问题的特例：

$$\min_{\mathbf{P}} \sum_{i,j} \mathbf{C}_{i,j}\mathbf{P}_{i,j} - \varepsilon\mathbf{H}(\mathbf{P}) + F(\mathbf{P}\mathbb{1}_m) + G(\mathbf{P}^{\mathrm{T}}\mathbb{1}_n). \tag{4.49}$$

事实上，令 $F = \iota_{\{\mathbf{a}\}}$、$G = \iota_{\{\mathbf{b}\}}$，其中闭凸集 $\mathcal{C}$ 的指示函数（indicator function）为

$$\iota_{\mathcal{C}}(x) = \begin{cases} 0 & \text{若} \quad x \in \mathcal{C}, \\ +\infty & \text{否则}, \end{cases} \tag{4.50}$$

就恢复了定义 $\mathcal{U}(\mathbf{a}, \mathbf{b})$ 的硬边缘约束. 命题 4.3的证明适用于更一般的问题 (4.49)，因此它的唯一解也具有 (4.12)的形式.

如 (Peyré, 2015; Frogner et al., 2015; Chizat et al., 2018b; Karlsson and Ringh, 2016) 所示，Sinkhorn 迭代 (4.15)可扩展到此问题，写为

$$\mathbf{u} \leftarrow \frac{\mathrm{Prox}_F^{\mathbf{KL}}(\mathbf{Kv})}{\mathbf{Kv}} \quad \text{且} \quad \mathbf{v} \leftarrow \frac{\mathrm{Prox}_G^{\mathbf{KL}}(\mathbf{K}^{\mathrm{T}}\mathbf{u})}{\mathbf{K}^{\mathrm{T}}\mathbf{u}}, \tag{4.51}$$

其中 $\mathbf{KL}$ 散度下的近端算子（proximal operator）为

$$\forall\, \mathbf{u} \in \mathbb{R}_+^N, \quad \mathrm{Prox}_F^{\mathbf{KL}}(\mathbf{u}) = \operatorname*{argmin}_{\mathbf{u}' \in \mathbb{R}_+^N} \mathbf{KL}(\mathbf{u}'|\mathbf{u}) + F(\mathbf{u}'). \tag{4.52}$$

对某些函数 F, G，可证明迭代 (4.51)的线性收敛速度，而且这些方法可推广到任意测度；详见 (Chizat et al., 2018b).

因此，当 $\mathrm{Prox}_F^{\mathbf{KL}}, \mathrm{Prox}_G^{\mathbf{KL}}$ 具有闭式表达或可高效计算时，迭代 (4.51)很有用. 特别地，对于形如 $F(\mathbf{u}) = \sum_i F_i(\mathbf{u}_i)$ 的可分离函数，因为

$$\mathrm{Prox}_F^{\mathbf{KL}}(\mathbf{u}) = \left(\mathrm{Prox}_{F_i}^{\mathbf{KL}}(\mathbf{u}_i)\right)_i.$$

每个 $\mathrm{Prox}_{F_i}^{\mathbf{KL}}$ 都是标量优化问题，通常容易计算. 与原始 Sinkhorn 算法类似，也可在对数域中计算以提高稳定性 (Chizat et al., 2018b).

此算法可近似求解最优传输的各种推广，特别是形如 (10.7)的非平衡最优传输问题（见第 10.2节，尤其是迭代 (10.9)），以及形如 (9.26)的梯度流问题（见第 9.3节）.

注 4.28 (对偶性与 Legendre 变换)**.** 问题 (4.49)的对偶为

$$\max_{\mathbf{f},\mathbf{g}} \; -F^*(\mathbf{f}) - G^*(\mathbf{g}) - \varepsilon \sum_{i,j} e^{\frac{\mathbf{f}_i + \mathbf{g}_j - \mathbf{C}_{i,j}}{\varepsilon}} \tag{4.53}$$

因而 $(\mathbf{u}, \mathbf{v}) = (e^{\mathbf{f}/\varepsilon}, e^{\mathbf{g}/\varepsilon})$ 是 (4.12)中的对应缩放变量. 这里 F^*, G^* 是 Fenchel–Legendre 共轭，它们是凸函数，定义为

$$\forall\, \mathbf{f} \in \mathbb{R}^n, \quad F^*(\mathbf{f}) \overset{\text{def.}}{=} \max_{\mathbf{a} \in \mathbb{R}^n} \langle \mathbf{f}, \mathbf{a} \rangle - F(\mathbf{a}). \tag{4.54}$$

广义 Sinkhorn 迭代 (4.51)是 Dykstra 算法 (Dykstra, 1983, 1985) 的特例（推广到 Bregman 散度见 (Bauschke and Lewis, 2000; Censor and Reich, 1998)；另见注 8.1.1)，也是对偶问题 (4.53)上的交替最大化方法.

形式 (4.49)还可扩展到两个以上函数和多个耦合；详见 (Chizat et al., 2018b). 特别地，它包括多边缘问题的 Sinkhorn 算法 (10.2)，见第 10.1节. 正则化重心问题 (9.15)也可按此方式改写，迭代 (9.18)实际上是广义 Sinkhorn 的特例.

Chapter 5

半离散最优传输

本章研究两个输入测度中一个为离散测度（Dirac 质量之和）、另一个为任意测度时求解最优传输问题的方法，特别包括后者相对于 Lebesgue 测度具有密度的情形. 当环境空间维数较低时，这个问题具有鲜明的几何特点，因为可以证明，从连续密度到离散测度的最优传输是分片常值映射，离散测度支撑中每一点的原像都是若干互不相交单元的并. 当代价为欧氏距离的平方时，这些单元对应于计算几何中的重要概念，即 Laguerre 单元（Laguerre cell）：它们是经常数偏移得到的 Voronoi 单元. 这一联系使我们能够借用计算几何工具，得到快速计算方法. 在高维情形中，半离散最优传输（semidiscrete optimal transport）也可以解释为随机规划问题，并且同样可以从少量正则化中获益，从而扩展第 4 章所介绍的熵正则化方法的应用范围. 所有这些构造都高度依赖 c-变换的概念；这里处理的是一般代价函数，而不再仅限于第 3.2 节中的矩阵. c-变换推广了凸分析中的 Legendre 变换，在最优传输理论与算法中起着核心作用.

5.1 c-变换与 $\bar{c}$-变换

回顾对偶最优传输问题 (2.24)：

$$\sup_{(f,g)} \mathcal{E}(f,g) \overset{\text{def.}}{=} \int_{\mathcal{X}} f(x)\mathrm{d}\alpha(x) + \int_{\mathcal{Y}} g(y)\mathrm{d}\beta(y) + \iota_{\mathcal{R}(c)}(f,g),$$

这里使用了方便的示性函数记号 (4.50). 固定对偶势 f 或 g，分别对 g 或 f 优化，可得到闭式解，由此定义 c-变换：

$$\forall\, y \in \mathcal{Y}, \quad f^c(y) \overset{\text{def.}}{=} \inf_{x\in\mathcal{X}} c(x,y) - f(x), \tag{5.1}$$

$$\forall\, x \in \mathcal{X}, \quad g^{\bar{c}}(x) \overset{\text{def.}}{=} \inf_{y\in\mathcal{Y}} c(x,y) - g(y), \tag{5.2}$$

其中记 $\bar{c}(y,x) \overset{\text{def.}}{=} c(x,y)$. 事实上，可以验证

$$f^c \in \operatorname*{argmax}_g \mathcal{E}(f,g) \quad \text{且} \quad g^{\bar{c}} \in \operatorname*{argmax}_f \mathcal{E}(f,g). \tag{5.3}$$

注意，这些部分极小化分别在 α 和 β 的支撑上确定极大化解，而定义 (5.1) 实际上在整个空间 $\mathcal{X}$ 和 $\mathcal{Y}$ 上定义了函数. 因此，这给出了将 (2.24) 的解典范地延拓到整个空间的方法. 当 $\mathcal{X} = \mathbb{R}^d$ 且 $c(x,y) = \|x-y\|_2^p = (\sum_{i=1}^d |x_i - y_i|)^{p/2}$ 时，c-变换 (5.1) f^c 就是 $-f$ 与 $\|\cdot\|^p$ 的下确界卷积（inf-convolution）. f^c 的定义也常称为 “Hopf–Lax 公式”.

映射 $(f,g) \in \mathcal{C}(\mathcal{X}) \times \mathcal{C}(\mathcal{Y}) \mapsto (g^{\bar{c}}, f^c) \in \mathcal{C}(\mathcal{X}) \times \mathcal{C}(\mathcal{Y})$ 将对偶势替换为 “更好” 的势（提高对偶目标 $\mathcal{E}$）. 能够写成 f^c 和 $g^{\bar{c}}$ 的函数分别称为 c-凹函数和 $\bar{c}$-凹函数. 在

$\mathcal{X}=\mathcal{Y}=\mathbb{R}^d$、$c(x,y)=\langle x,\,y\rangle$ 的特殊情形中，这一定义与通常的凹函数概念一致. 将命题 3.1 自然推广到连续情形，得到性质

$$f^{c\bar{c}c}=f^c \quad \text{且} \quad g^{\bar{c}c\bar{c}}=g^{\bar{c}},$$

其中记 $f^{c\bar{c}}=(f^c)^{\bar{c}}$. 这个不变性说明，以这种方式只能 “改进” 对偶势一次. 换言之，交替极大化不会收敛，而会立即进入循环；对于优化变量之间存在非光滑耦合（约束）的泛函，这是典型现象. 这与第 4 章的熵正则化最优传输形成鲜明对比. 在后者中，正则化使对偶目标 (4.30) 光滑，交替极大化对应于 Sinkhorn 迭代 (4.43) 和 (4.44). 在对偶变量上写出的这些迭代定义了 c-变换的熵平滑版本，其中 min 运算被 “软极小值” 替代.

利用 (5.3)，可以将 (2.24) 改写成只含一个势的无约束凸规划：

$$\mathcal{L}_c(\alpha,\beta)=\sup_{f\in\mathcal{C}(\mathcal{X})}\int_{\mathcal{X}}f(x)\mathrm{d}\alpha(x)+\int_{\mathcal{Y}}f^c(y)\mathrm{d}\beta(y) \tag{5.4}$$

$$=\sup_{g\in\mathcal{C}(\mathcal{Y})}\int_{\mathcal{X}}g^{\bar{c}}(x)\mathrm{d}\alpha(x)+\int_{\mathcal{Y}}g(y)\mathrm{d}\beta(y). \tag{5.5}$$

由于可以迭代映射 $(f,g)\mapsto(g^{\bar{c}},f^c)$，可以加入 f 为 $\bar{c}$-凹函数、g 为 c-凹函数的约束. 这对于保证势具有足够的正则性很重要，例如可用于证明 (2.24) 的解存在.

5.2 半离散表述

特别值得关注的是 $\beta=\sum_j \mathbf{b}_j\delta_{y_j}$ 为离散测度的情形（当然，如果 α 离散，只需交换 α,β 的角色，同样的构造仍然适用）. 将极小化限制在 β 的支撑 $(y_j)_j$ 上，就能把 $\bar{c}$-变换的定义 (5.1) 调整到这个情形：

$$\forall\,\mathbf{g}\in\mathbb{R}^m,\ \forall\,x\in\mathcal{X},\quad \mathbf{g}^{\bar{c}}(x)\overset{\text{def.}}{=}\min_{j\in[\![m]\!]}c(x,y_j)-\mathbf{g}_j. \tag{5.6}$$

这个变换将向量 $\mathbf{g}$ 映为连续函数 $\mathbf{g}^{\bar{c}}\in\mathcal{C}(\mathcal{X})$. 注意，若要求空间 $\mathcal{X}$ 等于 β 的支撑，这一定义就与 (5.1) 一致. 图 5.1 给出了一维和二维离散 $\bar{c}$-变换的例子.

关键在于，在半离散问题 (5.4) 中采用离散 $\bar{c}$-变换，会得到有限维优化问题：

$$\mathcal{L}_c(\alpha,\beta)=\max_{\mathbf{g}\in\mathbb{R}^m}\mathcal{E}(\mathbf{g})\overset{\text{def.}}{=}\int_{\mathcal{X}}\mathbf{g}^{\bar{c}}(x)\mathrm{d}\alpha(x)+\sum\mathbf{g}_y\mathbf{b}_j. \tag{5.7}$$

与对偶权重 $\mathbf{g}$ 对应的 Laguerre 单元

$$\mathbb{L}_j(\mathbf{g})\overset{\text{def.}}{=}\{x\in\mathcal{X}\ :\ \forall\,j'\neq j, c(x,y_j)-\mathbf{g}_j\leq c(x,y_{j'})-\mathbf{g}_{j'}\}$$

给出互不相交的分解 $\mathcal{X}=\bigcup_j\mathbb{L}_j(\mathbf{g})$. 当 $\mathbf{g}$ 为常数时，Laguerre 单元分解就是空间的 Voronoi 图划分. 图 5.1 下排给出了二维 Laguerre 单元划分的例子.

由此可方便地将待极小化的能量改写为

$$\mathcal{E}(\mathbf{g})=\sum_{j=1}^m\int_{\mathbb{L}_j(\mathbf{g})}(c(x,y_j)-\mathbf{g}_j)\,\mathrm{d}\alpha(x)+\langle\mathbf{g},\,\mathbf{b}\rangle. \tag{5.8}$$

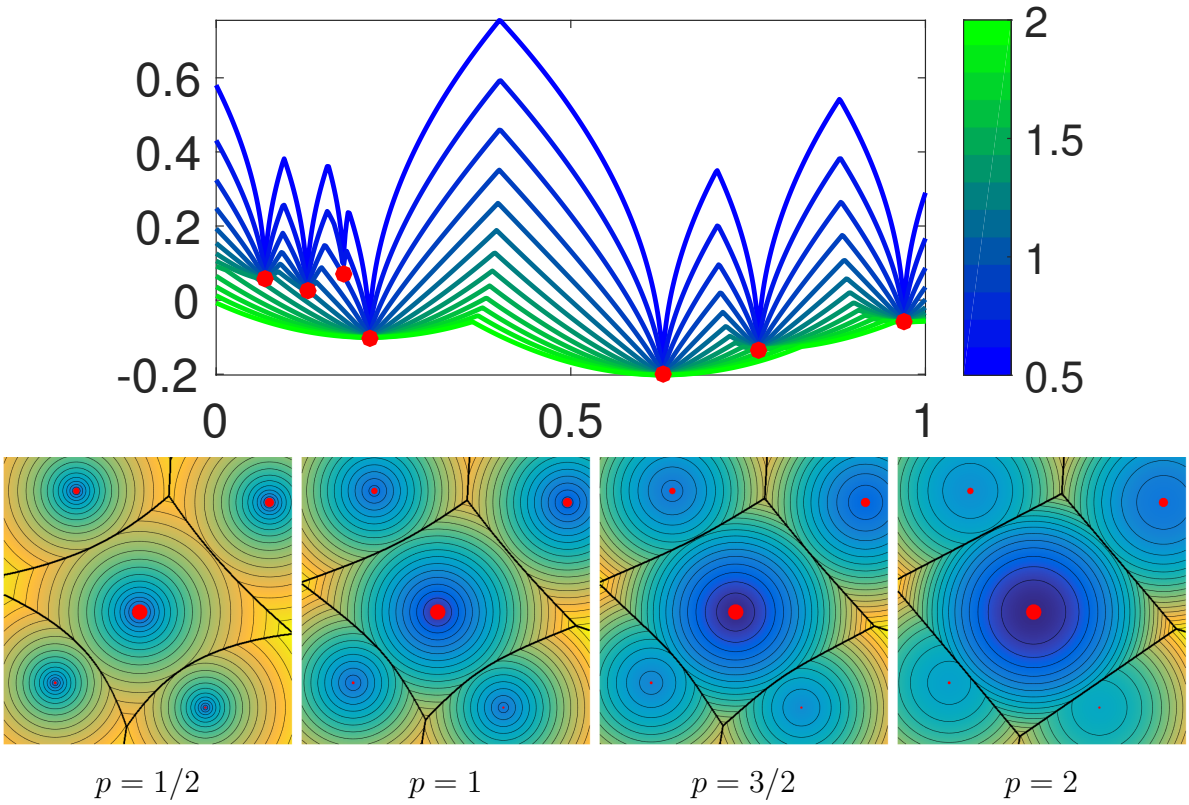

图 5.1: 上：基础代价为 $c(x,y) = |x-y|^p$、p 取不同值（见色条）时，一维半离散 $\bar{c}$-变换 $\mathbf{g}^{\bar{c}}$ 的例子. 红点位于 $(y_j, -\mathbf{g}_j)_j$. 下：基础代价为 $c(x,y) = \|x-y\|_2^p = (\sum_{i=1}^d |x_i - y_i|)^{p/2}$、$p$ 取不同值时，二维半离散 $\bar{c}$-变换 $\mathbf{g}^{\bar{c}}$ 的例子. 红点位于 $y_j \in \mathbb{R}^2$，其大小正比于 $\mathbf{g}_j$. 粗黑曲线围出的区域就是与点 $(y_j)_j$ 对应的 Laguerre 单元 $(\mathbb{L}_j(\mathbf{g}))_j$.

这个函数的梯度可以按下式计算：

$$\forall\, j \in [\![m]\!], \quad \nabla\mathcal{E}(\mathbf{g})_j = -\int_{\mathbb{L}_j(\mathbf{g})} \mathrm{d}\alpha(x) + \mathbf{b}_j.$$

图 5.2 展示了极小化 $\mathcal{E}$ 的梯度下降迭代. 一旦算出最优 $\mathbf{g}$，从 α 到 β 的最优传输映射 T 就将每个 $x \in \mathbb{L}_j(\mathbf{g})$ 映到 y_j，因而是分片常值的.

在 $c(x,y) = \|x-y\|^2$ 的特殊情形中，Laguerre 单元分解也称为幂图（power diagram）. 这些单元是多面体，可以用计算几何算法高效计算；见 (Aurenhammer, 1987). 最常用的算法基于如下事实：$\mathbb{R}^d$ 中点的幂图，等于点集 $((y_j, \|y_j\|^2 - \mathbf{g}_j))_{j=1}^m \subset \mathbb{R}^{d+1}$ 的凸包在 $\mathbb{R}^d$ 上的投影. 计算凸包的算法很多，例如 Chan (1996) 的二维和三维算法具有复杂度 $O(m\log(Q))$，其中 Q 为凸包顶点数.

Oliker and Prussner (1989) 最早提出了 Monge–Ampère 方程的半离散求解器思想，Aurenhammer et al. (1998) 则揭示了它与对偶变分问题的联系. 理论分析及其在光学反射器问题中的应用详见 (Caffarelli et al., 1999). (Carlier et al., 2010) 将半离散表述与基于 Knothe 传输的延拓方法结合使用. 这一方法近年在各个领域的复兴归功于 Mérigot (2011)：他提出了拟 Newton 求解器，并阐明了其与计算几何概念的联系. 较新的综述见 (Lévy and Schwindt, 2018). (De Goes et al., 2012) 提出了用于计算机图形学采样的 Newton 求解器；三维体积和曲面处理的应用另见 (Lévy, 2015). 半离散方法的一个

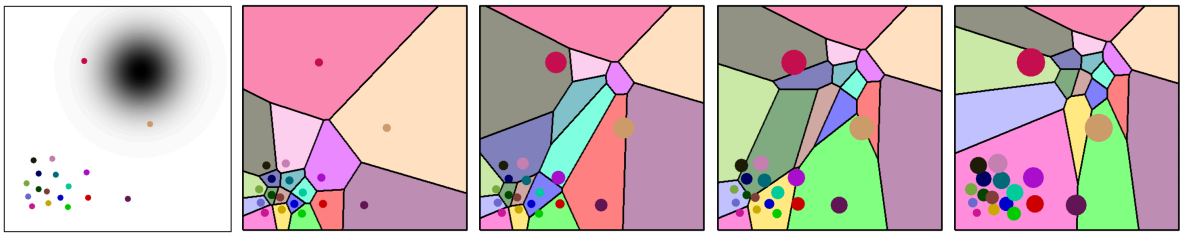

α 与 β　　$\ell = 1$　　$\ell = 20$　　$\ell = 40$　　$\ell = 100$

图 5.2: 极小化 (5.8) 的半离散最优传输算法迭代（此处采用简单梯度下降）. 彩色点表示离散测度 β 的支撑 $(y_j)_j$，连续测度 α 则为正方形上的均匀测度. 彩色单元表示 Laguerre 划分 $(\mathbb{L}_j(\mathbf{g}^{(\ell)}))_j$，其中 $\mathbf{g}^{(\ell)}$ 为第 ℓ 次迭代计算的离散对偶势.

重要应用是用 Lagrange 方法求解不可压缩流体动力学（Euler 方程）(de Goes et al., 2015; Gallouët and Mérigot, 2017). 半离散最优传输求解器在每次迭代中要求点云（可能带权）近似区域内的均匀分布，从而强制满足不可压缩性. (Mirebeau, 2015) 针对 Monge–Ampère 方程证明了阻尼 Newton 迭代的线性收敛，(Kitagawa et al., 2016) 将其细化到最优传输问题. 半离散最优传输在照明设计，特别是反射器设计中有重要应用；见 (Meyron et al., 2018).

5.3 熵半离散表述

任意测度之间的熵正则化问题 (4.9) 的对偶是光滑无约束优化问题：

$$\mathcal{L}_c^\varepsilon(\alpha,\beta) = \sup_{(f,g)\in\mathcal{C}(\mathcal{X})\times\mathcal{C}(\mathcal{Y})} \int_{\mathcal{X}} f\mathrm{d}\alpha + \int_{\mathcal{Y}} g\mathrm{d}\beta - \varepsilon\int_{\mathcal{X}\times\mathcal{Y}} e^{\frac{-c+f\oplus g}{\varepsilon}}\mathrm{d}\alpha\mathrm{d}\beta, \tag{5.9}$$

其中记 $(f\oplus g)(x,y) \overset{\text{def.}}{=} f(x)+g(y)$.

与未正则化问题 (5.1) 类似，可以在 (5.9) 中对 f 或 g 显式极小化，得到平滑的 c-变换

$$\forall\, y\in\mathcal{Y},\quad f^{c,\varepsilon}(y) \overset{\text{def.}}{=} -\varepsilon\log\left(\int_{\mathcal{X}} e^{\frac{-c(x,y)+f(x)}{\varepsilon}}\mathrm{d}\alpha(x)\right),$$
$$\forall\, x\in\mathcal{X},\quad g^{\bar{c},\varepsilon}(x) \overset{\text{def.}}{=} -\varepsilon\log\left(\int_{\mathcal{Y}} e^{\frac{-c(x,y)+g(y)}{\varepsilon}}\mathrm{d}\beta(y)\right).$$

若 $\beta = \sum_{j=1}^m \mathbf{b}_j\delta_{y_j}$ 为离散测度，则与 (5.7) 一样，问题简化为离散对偶势 $\mathbf{g}\in\mathbb{R}^m$ 的有限维问题：

$$\forall\, x\in\mathcal{X},\quad \mathbf{g}^{\bar{c},\varepsilon}(x) \overset{\text{def.}}{=} -\varepsilon\log\left(\sum_{j=1}^m e^{\frac{-c(x,y_j)+\mathbf{g}_j}{\varepsilon}}\mathbf{b}_j\right). \tag{5.10}$$

当 α 为离散测度时，同样定义 $\mathbf{f}^{\bar{c},\varepsilon}$. 注意，以软极小值算子 $\min_\varepsilon$ 改写 Sinkhorn 方法的 (4.40) 和 (4.41)，对应于交替计算熵平滑的 c-变换：

$$\mathbf{f}_i^{(\ell+1)} = \mathbf{g}^{\bar{c},\varepsilon}(x_i)\quad\text{且}\quad \mathbf{g}_j^{(\ell+1)} = \mathbf{f}^{c,\varepsilon}(y_j). \tag{5.11}$$

因此，可以求解下面的有限维优化问题来代替极大化 (5.9)：

$$\max_{\mathbf{g}\in\mathbb{R}^n} \mathcal{E}^\varepsilon(\mathbf{g}) \overset{\text{def.}}{=} \int_{\mathcal{X}} \mathbf{g}^{\bar{c},\varepsilon}(x)\mathrm{d}\alpha(x) + \langle \mathbf{g}, \mathbf{b}\rangle. \tag{5.12}$$

注意，即使在未正则化的情形 $\varepsilon = 0$，这个优化问题仍然成立. 此时 $\mathbf{g}^{\bar{c},\varepsilon=0} = \mathbf{g}^{\bar{c}}$ 就是 (5.6) 定义的 $\bar{c}$-变换，因此 (5.12) 实际上就是 (5.8). 这个泛函的梯度为

$$\forall\, j \in [\![m]\!], \quad \nabla\mathcal{E}^\varepsilon(\mathbf{g})_j = -\int_{\mathcal{X}} \chi_j^\varepsilon(x)\mathrm{d}\alpha(x) + \mathbf{b}_j, \tag{5.13}$$

其中 χ_j^ε 是 Laguerre 单元 $\mathbb{L}_j(\mathbf{g})$ 的示性函数 χ_j^0 的平滑版本：

$$\chi_j^\varepsilon(x) = \frac{e^{\frac{-c(x,y_j)+\mathbf{g}_j}{\varepsilon}}}{\sum_\ell e^{\frac{-c(x,y_\ell)+\mathbf{g}_\ell}{\varepsilon}}}.$$

再次注意，公式 (5.13) 对 $\varepsilon = 0$ 仍成立. 还要注意，函数族 $(\chi_j^\varepsilon)_j$ 是单位分解 (partition of unity)，即 $\sum_j \chi_j^\varepsilon = 1$ 且 $\chi_j^\varepsilon \geq 0$. 图 5.3 下排展示了这一点.

注 5.1 (二阶方法及其与逻辑回归的联系)**.** 平滑半离散表述 (5.12) 的一个关键特点是它对应于光滑函数的极小化. 事实上，(Genevay et al., 2016) 证明 $\mathcal{E}^\varepsilon$ 的 Hessian 有上界 $1/\varepsilon$，因此 $\nabla\mathcal{E}^\varepsilon$ 是 $\frac{1}{\varepsilon}$-Lipschitz 连续的. 这个问题实际上与多分类逻辑回归问题紧密相关 (图 5.3 展示了相应的模糊分类边界)，并具有同样的良好性质 (见 (Hosmer Jr et al., 2013))；这些性质是自协调性的推广，见 (Bach, 2010). 特别地，Newton 方法具有二次收敛性，实际计算也可以采用拟 Newton 技术，例如 (Cuturi and Peyré, 2016) 提倡的 L-BFGS. 注意，(Cuturi and Peyré, 2016) 研究的是第 9.2 节详述的更一般的重心问题，但只有一对输入测度时，它与这里的半离散情形等价. (Mérigot, 2011; De Goes et al., 2012; Lévy, 2015) 也主张在未正则化情形 $\varepsilon = 0$ 中采用二阶方法 (Newton 或 L-BFGS). (Kitagawa et al., 2016, 定理 5.1) 证明，只要 Laguerre 单元的体积有正的下界且 α 具有连续密度，$\mathcal{E}^0(\mathbf{g})$ 的 Hessian 就一致有界. Kitagawa et al. 随后证明了阻尼 Newton 算法的线性收敛，其中利用回溯保证 Laguerre 单元在相邻两次迭代之间始终不消失. 这一结果说明，即使未正则化，也可以使用二阶方法. 直观上，熵正则化问题的条件数按 $1/\varepsilon$ 缩放，而 $\varepsilon = 0$ 时，条件数主要由离散分布的样本数 m 决定 (它控制 Laguerre 单元的大小). (Knight and Ruiz, 2013; Sugiyama et al., 2017; Cohen et al., 2017; Allen-Zhu et al., 2017) 近期也研究了其他利用二阶方法的算法.

注 5.2 (最优传输代价函数的 Legendre 变换)**.** 由命题 4.6，$\mathrm{L}_{\mathbf{C}}^\varepsilon(\mathbf{a},\mathbf{b})$ 是 $(\mathbf{a},\mathbf{b})$ 的凸函数 (未正则化情形 $\varepsilon = 0$ 也成立). 因此可以计算其 Legendre–Fenchel 变换，定义见 (4.54). 记 $F_{\mathbf{a}}(\mathbf{b}) = \mathrm{L}_{\mathbf{C}}^\varepsilon(\mathbf{a},\mathbf{b})$；按照 Cuturi and Peyré (2016)，固定 $\mathbf{a}$ 时有

$$F_{\mathbf{a}}^*(\mathbf{g}) = -\varepsilon H(\mathbf{a}) + \sum_i \mathbf{a}_i \mathbf{g}^{\bar{c},\varepsilon}(x_i).$$

这里 $\mathbf{g}^{\bar{c},\varepsilon}$ 是 (5.10) 引入的熵平滑 c-变换. 在未正则化情形 $\varepsilon = 0$ 中，对于一般测度，Carlier et al. (2015) 证明，记 $\mathcal{F}_\alpha(\beta) \overset{\text{def.}}{=} \mathcal{L}_c(\alpha,\beta)$，则

$$\forall\, g \in \mathcal{C}(\mathcal{Y}), \quad \mathcal{F}_\alpha^*(g) = \int_{\mathcal{X}} g^{\bar{c}}(x)\mathrm{d}\alpha(x),$$

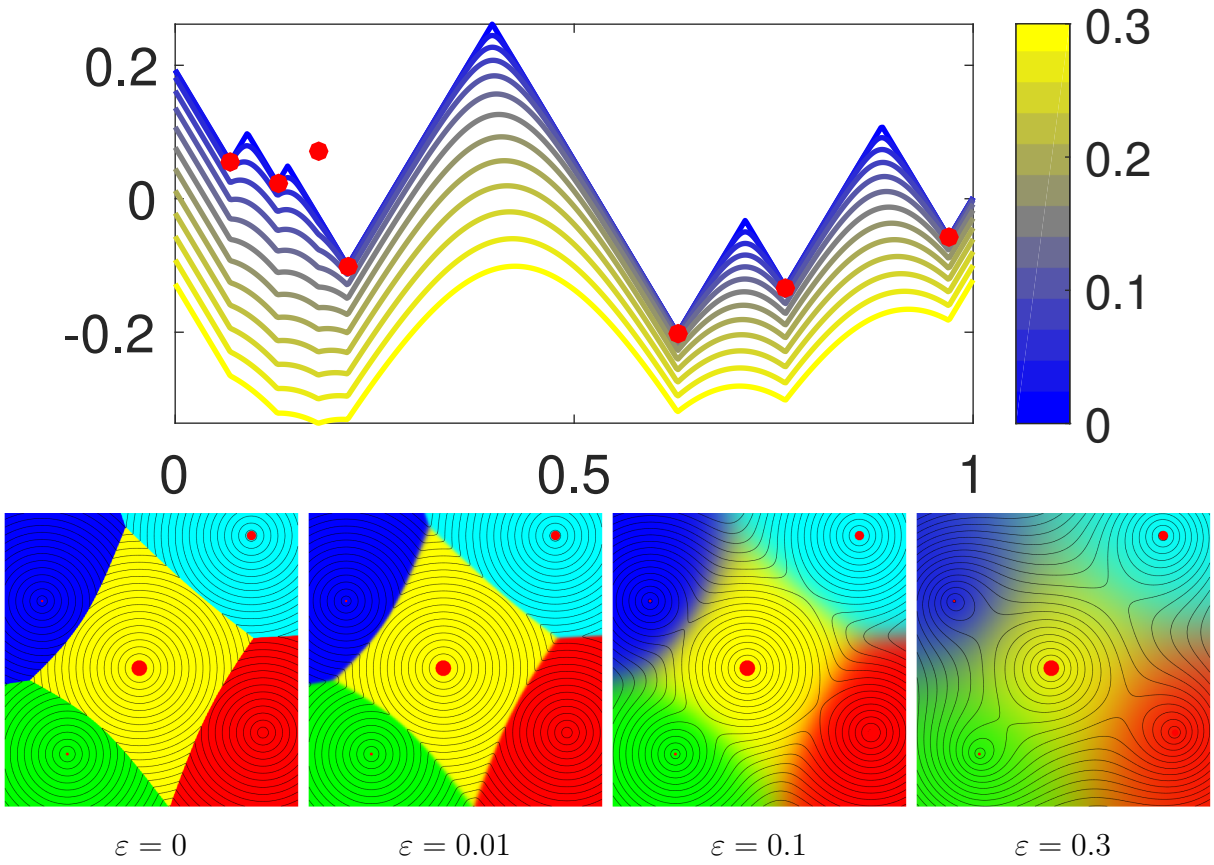

图 5.3: 上：基础代价为 $c(x,y) = |x-y|$、ε 取不同值（见色条）时，一维熵半离散 $\bar{c}$-变换 $\mathbf{g}^{\bar{c},\varepsilon}$ 的例子. 红点位于 $(y_j, -\mathbf{g}_j)_j$. 下：基础代价为 $c(x,y) = \|x-y\|_2$、ε 取不同值时，二维熵半离散 $\bar{c}$-变换 $\mathbf{g}^{\bar{c},\varepsilon}$ 的例子. 黑曲线是函数 $\mathbf{g}^{\bar{c},\varepsilon}$ 的等值线，颜色表示 Laguerre 单元的平滑示性函数 χ_j^ε. 红点位于 $y_j \in \mathbb{R}^2$，其大小正比于 $\mathbf{g}_j$.

其中 g 的 $\bar{c}$-变换 $g^{\bar{c}} \in \mathcal{C}(\mathcal{X})$ 定义于第 5.1 节. 注意，由于 $\mathcal{M}(\mathcal{X})$ 与 $\mathcal{C}(\mathcal{X})$ 对偶，此处的 Legendre 变换以连续函数为自变量. 现在记 $G(\mathbf{a},\mathbf{b}) \overset{\text{def.}}{=} \mathrm{L}_{\mathbf{C}}^{\varepsilon}(\mathbf{a},\mathbf{b})$，可按照 (Cuturi and Peyré, 2016, 2018) 推导关于两个自变量的 Legendre 变换：

$$\forall (\mathbf{f},\mathbf{g}) \in \mathbb{R}^n \times \mathbb{R}^m, \quad G^*(\mathbf{f},\mathbf{g}) = -\varepsilon \log \sum_{i,j} e^{\frac{-\mathbf{C}_{i,j}+\mathbf{f}_i+\mathbf{g}_j}{\varepsilon}},$$

它可看作 $\mathcal{G}(\alpha,\beta) \overset{\text{def.}}{=} \mathcal{L}_c(\alpha,\beta)$ 的 Legendre 变换的平滑版本：

$$\forall (f,g) \in \mathcal{C}(\mathcal{X}) \times \mathcal{C}(\mathcal{Y}), \quad \mathcal{G}^*(f,g) = \inf_{(x,y)\in\mathcal{X}\times\mathcal{Y}} c(x,y) - f(x) - g(y).$$

5.4 随机优化方法

半离散表述 (5.8) 及其平滑版本 (5.12) 的吸引力在于，待极小化的能量可以写成关于概率分布 α 的期望：

$$\mathcal{E}^\varepsilon(\mathbf{g}) = \int_{\mathcal{X}} E^\varepsilon(\mathbf{g},x)\mathrm{d}\alpha(x) = \mathbb{E}_X(E^\varepsilon(\mathbf{g},X))$$

$$\text{其中} \quad E^{\varepsilon}(\mathbf{g}, x) \overset{\text{def.}}{=} \mathbf{g}^{\bar{c},\varepsilon}(x) - \langle \mathbf{g}, \mathbf{b} \rangle,$$

其中 X 是在 $\mathcal{X}$ 上按 α 分布的随机向量. 注意，各个泛函的梯度为

$$\nabla_{\mathbf{g}} E^{\varepsilon}(x, \mathbf{g}) = (\chi_j^{\varepsilon}(x) - \mathbf{b}_j)_{j=1}^m \in \mathbb{R}^m.$$

因此可以用随机优化方法进行极大化，如 Genevay et al. (2016) 所提出的那样. 由此得到可证明收敛的算法，无须对 α 作任意离散化（用 Dirac 质量之和近似 α，或用求积公式计算积分）. 测度 α 被视为可从中抽取独立样本的黑箱，这对于统计学与机器学习中的许多高维应用，是自然的计算设定. (Staib et al., 2017b) 将这类方法推广到 Wasserstein 重心的计算（见第 9.2 节）.

随机梯度下降. 初始化 $\mathbf{g}^{(0)} = \mathbb{0}_P$ 后，随机梯度下降 (stochastic gradient descent)(SGD; 此处用作极大化方法）在第 ℓ 步按分布 α 抽取点 $x_\ell \in \mathcal{X}$（与过去及将来的所有样本 $(x_\ell)_\ell$ 独立），并进行更新

$$\mathbf{g}^{(\ell+1)} \overset{\text{def.}}{=} \mathbf{g}^{(\ell)} + \tau_\ell \nabla_{\mathbf{g}} E^{\varepsilon}(\mathbf{g}^{(\ell)}, x_\ell). \tag{5.14}$$

步长 τ_ℓ 应足够快地衰减到零，使得以 $\nabla_{\mathbf{g}} E^{\varepsilon}(x_\ell, \mathbf{g})$ 代替真实梯度 $\nabla \mathcal{E}^{\varepsilon}(\mathbf{g})$ 所产生的 “噪声” 在极限中消失. 一种典型的步长安排为

$$\tau_\ell \overset{\text{def.}}{=} \frac{\tau_0}{1 + \ell/\ell_0}, \tag{5.15}$$

其中 ℓ_0 大致表示预热阶段的迭代次数. 可以证明收敛结果

$$\mathcal{E}^{\varepsilon}(\mathbf{g}^\star) - \mathbb{E}(\mathcal{E}^{\varepsilon}(\mathbf{g}^{(\ell)})) = O\left(\frac{1}{\sqrt{\ell}}\right),$$

其中 $\mathbf{g}^\star$ 是 (5.12) 的解，$\mathbb{E}$ 表示关于各次迭代独立同分布抽样 $(x_\ell)_\ell$ 的期望. 图 5.4 展示了算法在简单二维例子中的演化，α 为 $[0,1]^2$ 上的均匀分布.

带平均的随机梯度下降. SGD 较慢，因为步长 τ_ℓ 很快衰减到零.

为了提高收敛速度，可以对过去的迭代取平均；等价地，在辅助变量 $(\tilde{\mathbf{g}}^{(\ell)})_\ell$ 上运行 “经典” SGD

$$\tilde{\mathbf{g}}^{(\ell+1)} \overset{\text{def.}}{=} \tilde{\mathbf{g}}^{(\ell)} + \tau_\ell \nabla_{\mathbf{g}} E^{\varepsilon}(\tilde{\mathbf{g}}^{(\ell)}, x_\ell),$$

其中 x_ℓ 按 α 抽样（所有 $(x_\ell)_\ell$ 相互独立），并输出平均值作为估计的权重向量：

$$\mathbf{g}^{(\ell)} \overset{\text{def.}}{=} \frac{1}{\ell} \sum_{k=1}^{\ell} \tilde{\mathbf{g}}^{(k)}.$$

这定义了带平均的随机梯度下降 (stochastic gradient descent with averaging)（SGA）算法.

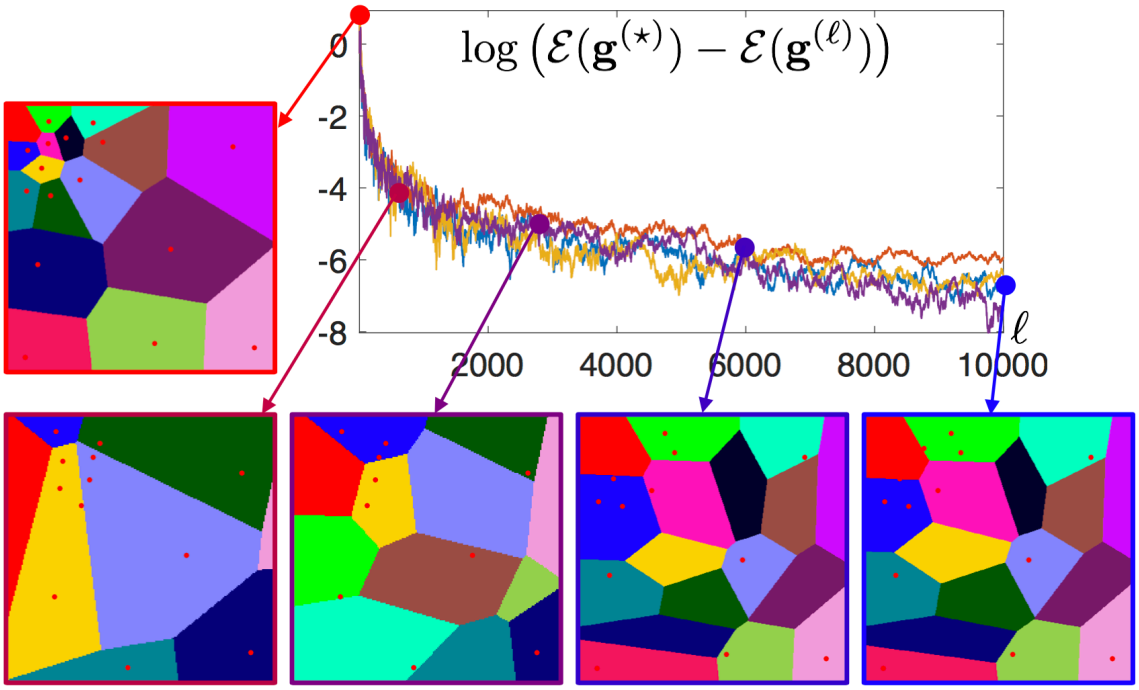

图 5.4: $\varepsilon = 0$（无正则化）时，SGD 迭代 (5.14) 中能量 $\mathcal{E}^{\varepsilon}(\mathbf{g}^{(\ell)})$ 的演化. 每条彩色曲线表示一次不同的随机运行. 各图显示迭代过程中 Laguerre 单元 $(\mathbb{L}_j(\mathbf{g}^{(\ell)}))_j$ 的演化.

注意，只需按如下方式更新运行平均值，就不必显式存储所有迭代：

$$\mathbf{g}^{(\ell+1)} = \frac{1}{\ell+1}\tilde{\mathbf{g}}^{(\ell+1)} + \frac{\ell}{\ell+1}\mathbf{g}^{(\ell)}.$$

此时，典型的衰减方式为

$$\tau_\ell \overset{\text{def.}}{=} \frac{\tau_0}{1+\sqrt{\ell/\ell_0}}.$$

注意，与 (5.15) 相比，步长现在以 $\ell^{-1/2}$ 的速率更缓慢地趋于零. Bach (2014) 证明，SGA 比 SGD 收敛更快（所涉及的常数更小），因为 SGA 能适应泛函的局部强凸性（极大化问题中为强凹性），而 SGD 不能.

注 5.3 (连续–连续问题). 若 α 和 β 都不是离散测度，就不能使用涉及有限维对偶变量的半离散策略，例如问题 (5.7). 唯一选择是在对偶问题 (4.45) 上使用随机优化方法，如 (Genevay et al., 2016) 所提出的那样. 对该问题施加适当正则化至关重要，例如令熵正则化强度 $\varepsilon > 0$，以得到可用随机下降方法求解的无约束问题. 重新处理问题 (4.45) 的一种方法，是将连续函数空间上的无限维优化限制到小得多的子集，例如多层神经网络张成的集合 (Seguy et al., 2018). 这会产生没有近似保证的非凸有限维优化问题，但在高维情形中仍可能有效地计算 Wasserstein 距离的替代量. 另一种办法是使用非参数函数族，相当于某种逐步细化；例如 Genevay et al. (2016) 采用再生核 Hilbert 空间，其维数与 SGD 算法的迭代次数成正比.

Chapter 6

$\mathcal{W}_1$ 最优传输

本章关注基础代价等于距离的最优传输问题. 从历史上看，这对应于 Monge 在 1781 年提出的原始问题；计算机视觉中最优传输的早期应用 (Rubner et al., 2000) 也选择了这一设定，并称之为 “推土机距离”.

与基础代价为 Hilbert 空间距离的平方的情形（特别见第 7 章）相比，代价为度量的传输问题在理论上更难分析. 注 2.24 指出，采用平方度量时，两个绝对连续测度之间的传输映射或耦合具有唯一性；但当代价为基础距离本身时，最优 Kantorovich 耦合一般不唯一. 因此，在这一情形中通常无法恢复唯一定义的 Monge 映射，使得这类问题不适合用于测度插值. 最优 $\mathcal{W}_1$ 传输方案存在性的证明及其几何结构的详细分析，见 Trudinger and Wang (2001); Caffarelli et al. (2002); Sudakov (1979); Evans and Gangbo (1999) 的工作.

虽然理论分析更困难，但采用线性基础距离的最优传输通常比二次代价对异常值和噪声更稳健. 此外，度量代价具有简洁的对偶改写，涉及局部流、散度约束或对偶势的 Lipschitz 性，从而启发计算成本更低的数值算法，与图论中的网络最小费用流 (minimum-cost flow) 方法相吻合. 这个设定也很受欢迎，因为相应的最优传输距离定义了一个范数，可以比较任意分布，即使它们不为正；更大一类称为对偶范数的对象也具有这一性质（详见第 8.2 节和注 10.6）.

6.1 度量空间上的 $\mathcal{W}_1$

这里假设 d 为 $\mathcal{X}=\mathcal{Y}$ 上的距离，并求解基础代价 $c(x,y)=d(x,y)$ 的最优传输问题. 以下命题说明这一设定中 c-变换 (5.1) 的关键性质. 下文将函数 $f\in\mathcal{C}(\mathcal{X})$ 的 Lipschitz 常数记为

$$\mathrm{Lip}(f)\overset{\text{def.}}{=}\sup\left\{\frac{|f(x)-f(y)|}{d(x,y)}\ :\ (x,y)\in\mathcal{X}^2, x\neq y\right\}.$$

我们把满足 $\mathrm{Lip}(f)<+\infty$ 的函数 f 称为 Lipschitz 函数；它们组成 $\mathcal{C}(\mathcal{X})$ 的凸子集.

命题 6.1. *假设 $\mathcal{X}=\mathcal{Y}$ 且 $c(x,y)=d(x,y)$. 存在 g 使得 $f=g^c$，当且仅当 $\mathrm{Lip}(f)\leq 1$. 此外，若 $\mathrm{Lip}(f)\leq 1$，则 $f^c=-f$.*

证明： 首先，假设 $f=g^c$. 对于 $x,y\in\mathcal{X}$，有

$$\begin{aligned}|f(x)-f(y)| &= \left|\inf_{z\in\mathcal{X}} d(x,z)-g(z) \quad - \quad \inf_{z\in\mathcal{X}} d(y,z)-g(z)\right| \\ &\leq \sup_{z\in\mathcal{X}} |d(x,z)-d(y,z)| \leq d(x,y).\end{aligned}$$

第一个等式来自 g^c 的定义，接下来的不等式来自恒等关系 $|\inf f - \inf g| \leq \sup |f-g|$，最后一个不等式来自三角不等式. 因此 $\mathrm{Lip}(f) \leq 1$.

现在假设 $\mathrm{Lip}(f) \leq 1$，并定义 $g \overset{\text{def.}}{=} -f$. 由 Lipschitz 性质，对所有 $x, y \in \mathcal{X}$ 有 $f(y) - d(x,y) \leq f(x) \leq f(y) + d(x,y)$. 利用这些不等式，

$$g^c(y) = \inf_{x \in \mathcal{X}} [d(x,y) + f(x)] \geq \inf_{x \in \mathcal{X}} [d(x,y) + f(y) - d(x,y)] = f(y),$$
$$g^c(y) = \inf_{x \in \mathcal{X}} [d(x,y) + f(x)] \leq \inf_{x \in \mathcal{X}} [d(x,y) + f(y) + d(x,y)] = f(y).$$

因此 $f = g^c$，其中 $g = -f$. 同样的不等式还给出

$$f^c(y) = \inf_{x \in \mathcal{X}} [d(x,y) - f(x)] \geq \inf_{x \in \mathcal{X}} [d(x,y) - f(y) - d(x,y)] = -f(y),$$
$$f^c(y) = \inf_{x \in \mathcal{X}} [d(x,y) - f(x)] \leq \inf_{x \in \mathcal{X}} [d(x,y) - f(y) + d(x,y)] = -f(y).$$

这就说明 $f^c = -f$. □

从单势表述 (5.4) 出发，可以迭代这一构造，将 (g, g^c) 替换为 $(g^c, (g^c)^c)$. 上述命题说明，可以使用 $(g^c, -g^c)$，这又等价于任意满足 $\mathrm{Lip}(f) \leq 1$ 的函数对 $(f, -f)$. 于是得到 $\mathcal{W}_1$ 距离的另一种表达式：

$$\mathcal{W}_1(\alpha, \beta) = \max_f \left\{ \int_{\mathcal{X}} f(x)(\mathrm{d}\alpha(x) - \mathrm{d}\beta(x)) \;:\; \mathrm{Lip}(f) \leq 1 \right\}. \tag{6.1}$$

这个表达式表明，$\mathcal{W}_1$ 实际上是一个范数，即 $\mathcal{W}_1(\alpha,\beta) = \|\alpha - \beta\|_{\mathcal{W}_1}$；而且只要 $\int_{\mathcal{X}} \alpha = \int_{\mathcal{X}} \beta$，它对任意测度（不必为正）仍然有效. 这个范数常称为 Kantorovich and Rubinstein 范数 (1958).

对于形如 (2.1) 的离散测度，写成 $\alpha - \beta = \sum_k \mathbf{m}_k \delta_{z_k}$，其中 $z_k \in \mathcal{X}$ 且 $\sum_k \mathbf{m}_k = 0$，则优化问题 (6.1) 可改写为

$$\mathcal{W}_1(\alpha, \beta) = \max_{(\mathbf{f}_k)_k} \left\{ \sum_k \mathbf{f}_k \mathbf{m}_k \;:\; \forall\, (k,\ell), |\mathbf{f}_k - \mathbf{f}_\ell| \leq d(z_k, z_\ell), \right\} \tag{6.2}$$

这是带二次锥约束的有限维凸规划. 可以用内点法求解，也可以用近端方法；下文将对一个类似问题详细说明.

当 $\mathcal{X} = \mathbb{R}$ 且 $d(x,y) = |x-y|$ 时，通过将 z_k 排序为 $z_1 \leq z_2 \leq \ldots$，可减少约束数目. 此时只需求解

$$\mathcal{W}_1(\alpha, \beta) = \max_{(\mathbf{f}_k)_k} \left\{ \sum_k \mathbf{f}_k \mathbf{m}_k \;:\; \forall\, k, |\mathbf{f}_{k+1} - \mathbf{f}_k| \leq z_{k+1} - z_k \right\},$$

这是一个线性规划. 此外，在这一维情形中，利用累积分布函数表示 $\mathcal{W}_1$ 的闭式表达式见 (2.37).

注 6.1 ($0 < p \leq 1$ 时的 $\mathcal{W}_p$)**.** 若 $0 < p \leq 1$，则 $\tilde{d}(x,y) \overset{\text{def.}}{=} d(x,y)^p$ 满足三角不等式，所以 $\tilde{d}$ 本身也是距离. 因此，只需将 d 换成 $\tilde{d}$，就可以用上述关于 $\mathcal{W}_1$ 的结果与算法计算 $\mathcal{W}_p$. 等价地，$\mathcal{W}_p$ 是 p-Hölder 函数 $\{f \;:\; \mathrm{Lip}_p(f) \leq 1\}$ 的对偶，其中

$$\mathrm{Lip}_p(f) \overset{\text{def.}}{=} \sup \left\{ \frac{|f(x) - f(y)|}{d(x,y)^p} \;:\; (x,y) \in \mathcal{X}^2, x \neq y \right\}.$$

6.2 欧氏空间上的 $\mathcal{W}_1$

在欧氏空间 $\mathcal{X}=\mathcal{Y}=\mathbb{R}^d$ 的特殊情形中，采用 $c(x,y)=\|x-y\|$，则 (6.1) 中的全局 Lipschitz 约束可以局部化为 f 的梯度的一致上界：

$$\mathcal{W}_1(\alpha,\beta)=\max_f\left\{\int_{\mathbb{R}^d} f(x)(\mathrm{d}\alpha(x)-\mathrm{d}\beta(x)) \;:\; \|\nabla f\|_\infty\leq 1\right\}. \tag{6.3}$$

这里约束 $\|\nabla f\|_\infty\leq 1$ 表示，f 在每一点 x 的梯度范数不超过 1，即对每个 x 都有 $\|\nabla f(x)\|_2\leq 1$.

考虑 (6.3) 的对偶问题，得到带固定散度约束的优化问题

$$\mathcal{W}_1(\alpha,\beta)=\min_s\left\{\int_{\mathbb{R}^d}\|s(x)\|_2\,\mathrm{d}x \;:\; \mathrm{div}(s)=\alpha-\beta\right\}, \tag{6.4}$$

它常称为Beckmann 表述（Beckmann formulation）(Beckmann, 1952). 这里向量值函数 $s(x)\in\mathbb{R}^2$ 可以解释为流场，局部描述质量的运动. 在两个输入测度的支撑之外，$\mathrm{div}(s)=0$，即质量守恒约束. 用有限元适当离散化之后，问题 (6.3) 和 (6.4) 成为非光滑凸优化问题. 可以使用现成的内点二次锥优化求解器，但如第 7.3 节所述，大规模问题需要更简单且更适合的一阶方法. 例如可以采用 Douglas–Rachford（DR）迭代 (7.14)，或与之相关的交替方向乘子法. 注意，在均匀网格上，利用快速 Fourier 变换可以方便地处理散度约束上的投影. 这些方法及其在三角网格上最优传输的应用，详见 Solomon et al. (2014a). 采用原始–对偶分裂方法的类似工作另见 Li et al. (2018a); Ryu et al. (2017b,a). 也有人提出放松对偶势 f 的 Lipschitz 约束的近似方法，例如约束小波系数，从而得到显式公式 (Shirdhonkar and Jacobs, 2008)；或者仅考虑由多层神经网络参数化的函数 f，使用 “整流线性” 激活函数 $\max(0,\cdot)$ 并截断权重 (Arjovsky et al., 2017).

6.3 图上的 $\mathcal{W}_1$

前面的 $\mathcal{W}_1$ 表述 (6.3) 和 (6.4) 可以推广到 $\mathcal{X}$ 为测地空间的情形，即 $c(x,y)=d(x,y)$，其中 d 为测地距离. $\mathcal{X}$ 为 Riemann 流形时的理论分析见 Feldman and McCann (2002). 当 $\mathcal{X}=[\![1,n]\!]$ 是离散集合，具有无向边 $(i,j)\in\mathcal{E}\subset\mathcal{X}^2$，且每条边带有权重（长度）$\mathbf{w}_{i,j}$ 时，就得到 $\mathcal{X}$ 为图并配备测地距离（最短路度量）的重要情形：

$$\mathbf{D}_{i,j}\overset{\text{def.}}{=}\min_{K\geq 0,(i_k)_k:i\to j}\left\{\sum_{k=1}^{K-1}\mathbf{w}_{i_k,i_{k+1}} \;:\; \forall\, k\in[\![1,K-1]\!],(i_k,i_{k+1})\in\mathcal{E}\right\},$$

其中 $i\to j$ 表示 $i_1=i$ 且 $i_K=j$，即路径从 i 出发并在 j 结束.

考虑两个向量 $(\mathbf{a},\mathbf{b})\in(\mathbb{R}^n)^2$，它们在图 $\mathcal{X}$ 上定义（有符号）离散测度，满足 $\sum_i\mathbf{a}_i=\sum_i\mathbf{b}_i$（这些权重不必为正）. 目标是在基础度量为图测地距离时，计算 (2.17) 中 $p=1$ 时引入的 $\mathrm{W}_1(\mathbf{a},\mathbf{b})$. 计算时应利用图的连通结构，依靠局部算子，避免计算大小为 $n\times n$ 的 “完整” 耦合 $\mathbf{P}$. 这些算子是梯度与散度微分算子的离散版本.

离散对偶 Kantorovich 势 $\mathbf{f}\in\mathbb{R}^n$ 是以图的全部顶点为指标的向量. 梯度算子 $\nabla:\mathbb{R}^n\to\mathbb{R}^{\mathcal{E}}$ 定义为

$$\forall\,(i,j)\in\mathcal{E},\quad(\nabla\mathbf{f})_{i,j}\overset{\text{def.}}{=}\mathbf{f}_i-\mathbf{f}_j.$$

流 $\mathbf{s}=(\mathbf{s}_{i,j})_{i,j}$ 定义在边上. 散度算子 $\mathrm{div}:\mathbb{R}^{\mathcal{E}}\to\mathbb{R}^n$ 是梯度 ∇ 的伴随，将流映为定义在顶点上的向量，定义为

$$\forall\, i\in[\![1,n]\!],\quad \mathrm{div}(\mathbf{s})_i \overset{\text{def.}}{=} \sum_{j:(i,j)\in\mathcal{E}} (\mathbf{s}_{i,j}-\mathbf{s}_{j,i})\in\mathbb{R}^n.$$

在图的设定中，问题 (6.3) 成为

$$\mathrm{W}_1(\mathbf{a},\mathbf{b}) = \max_{\mathbf{f}\in\mathbb{R}^n} \left\{ \sum_{i=1}^n \mathbf{f}_i(\mathbf{a}_i-\mathbf{b}_i) \;:\; \forall (i,j)\in\mathcal{E},\, |(\nabla\mathbf{f})_{i,j}|\leq \mathbf{w}_{i,j} \right\}. \tag{6.5}$$

相应的对偶问题与公式 (6.4) 类似，为

$$\mathrm{W}_1(\mathbf{a},\mathbf{b}) = \min_{\mathbf{s}\in\mathbb{R}^{\mathcal{E}}_+} \left\{ \sum_{(i,j)\in\mathcal{E}} \mathbf{w}_{i,j}\mathbf{s}_{i,j} \;:\; \mathrm{div}(\mathbf{s})=\mathbf{a}-\mathbf{b} \right\}. \tag{6.6}$$

这是一个线性规划，更准确地说，是最小费用流问题的一个实例. 已有专用且非常高效的单纯形求解器来求解它；例如见 (Ling and Okada, 2007). 图 6.1 给出了原始解与对偶解的例子. 表述 (6.6) 即 Beckmann 表述 (Beckmann, 1952)，曾被使用并推广以定义和研究交通拥堵模型；例如见 (Carlier et al., 2008).

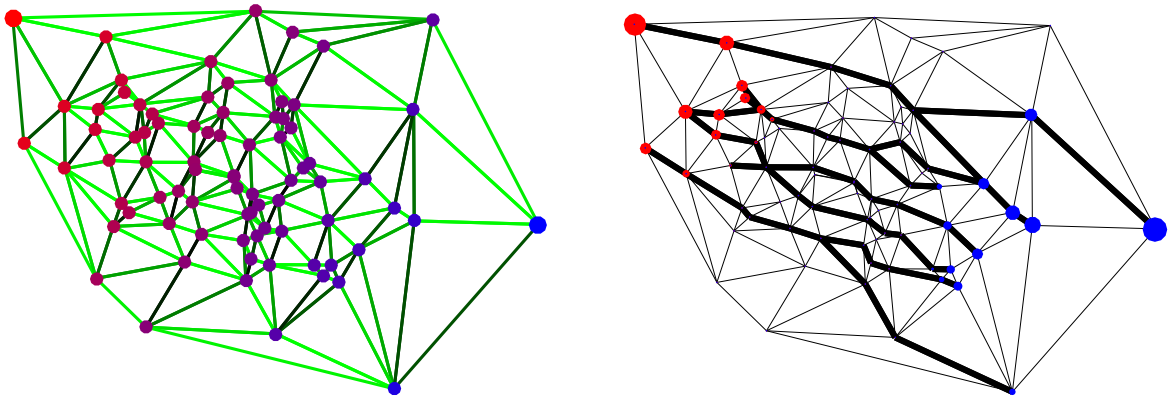

$\mathbf{f}$ $\qquad$ $(\mathbf{a},\mathbf{b})$ 与 $\mathbf{s}$

图 6.1: 在平面图上计算 $\mathrm{W}_1(\mathbf{a},\mathbf{b})$ 的例子，边权重统一为 $\mathbf{w}_{i,j}=1$. 左: (6.5) 的势解 $\mathbf{f}$（数值由红色到蓝色递增）. 边的绿色深浅正比于 $|(\nabla\mathbf{f})_{i,j}|$. 右: (6.6) 的流解 $\mathbf{s}$，粗黑边表示非零 $\mathbf{s}_{i,j}$，它们饱和至 $\mathbf{w}_{i,j}=1$. 右图中的这些饱和流边对应于左图中满足 $|(\nabla\mathbf{f})_{i,j}|=1$ 的浅绿色边.

Chapter 7

动态表述

本章介绍代价为测地距离平方时最优传输的测地观点（也称动态观点）. 它将两个测度之间的最优传输描述为测度空间中使总长度最小的曲线. 动态观点提供了另一种直观解释，不仅将最优传输与流体动力学联系起来，而且在低维空间中对两个密度作插值时，给出了高效的数值计算工具. 其不足是无法扩展到大规模稀疏测度，只适用于低维规则区域（因为需要对空间划分网格），并要求平方测地代价.

本章用 (α_0, α_1) 代替 (α, β)，对应于在 $t = 0$ 从一个测度出发、在 $t = 1$ 到达另一个测度的思想.

7.1 连续表述

当 $\mathcal{X} = \mathcal{Y} = \mathbb{R}^d$ 且 $c(x, y) = \|x - y\|^2$ 时，(2.15) 定义的最优传输距离 $\mathcal{W}_2^2(\alpha, \beta) = \mathcal{L}_c(\alpha, \beta)$ 可以通过寻找两个测度之间的最短路径 $(\alpha_t)_{t=0}^1$ 来计算. 这条路径通过每个时刻定义的向量场 v_t 对测度的平流来描述. 向量场 v_t 与路径 α_t 必须满足质量守恒公式，因此有

$$\frac{\partial \alpha_t}{\partial t} + \operatorname{div}(\alpha_t v_t) = 0 \quad \text{且} \quad \alpha_{t=0} = \alpha_0, \alpha_{t=1} = \alpha_1, \tag{7.1}$$

上式应理解为 $\mathbb{R}^d$ 上的分布意义等式. 向量场的无穷小长度由测度 α_t 对应的 L^2 范数衡量，其定义为

$$\|v_t\|_{L^2(\alpha_t)} = \left(\int_{\mathbb{R}^d} \|v_t(x)\|^2 \, \mathrm{d}\alpha_t(x) \right)^{1/2}.$$

这一定义给出了如下 $\mathcal{W}_2$ 的最短路径改写，最初由 Benamou and Brenier (2000) 提出：

$$\mathcal{W}_2^2(\alpha_0, \alpha_1) = \min_{(\alpha_t, v_t)_t \text{ 满足 } (7.1)} \int_0^1 \int_{\mathbb{R}^d} \|v_t(x)\|^2 \, \mathrm{d}\alpha_t(x) \mathrm{d}t, \tag{7.2}$$

其中 α_t 为标量值测度，v_t 为向量值测度. 图 7.1 给出了这类测度路径，即位移插值（displacement interpolation），的两个例子.

由于约束 (7.1) 含有乘积 $\alpha_t v_t$，表述 (7.2) 关于变量 $(\alpha_t, v_t)_t$ 是非凸的. 引入向量值测度（通常称为“动量”）

$$J_t \overset{\text{def.}}{=} \alpha_t v_t,$$

Benamou and Brenier 在其奠基性论文 (2000) 中证明，改写为下式后，它关于变量 $(\alpha_t, J_t)_t$ 是凸的：

$$\mathcal{W}_2^2(\alpha_0, \alpha_1) = \min_{(\alpha_t, J_t)_t \in \mathcal{C}(\alpha_0, \alpha_1)} \int_0^1 \int_{\mathbb{R}^d} \theta(\alpha_t(x), J_t(x)) \mathrm{d}x \mathrm{d}t, \tag{7.3}$$

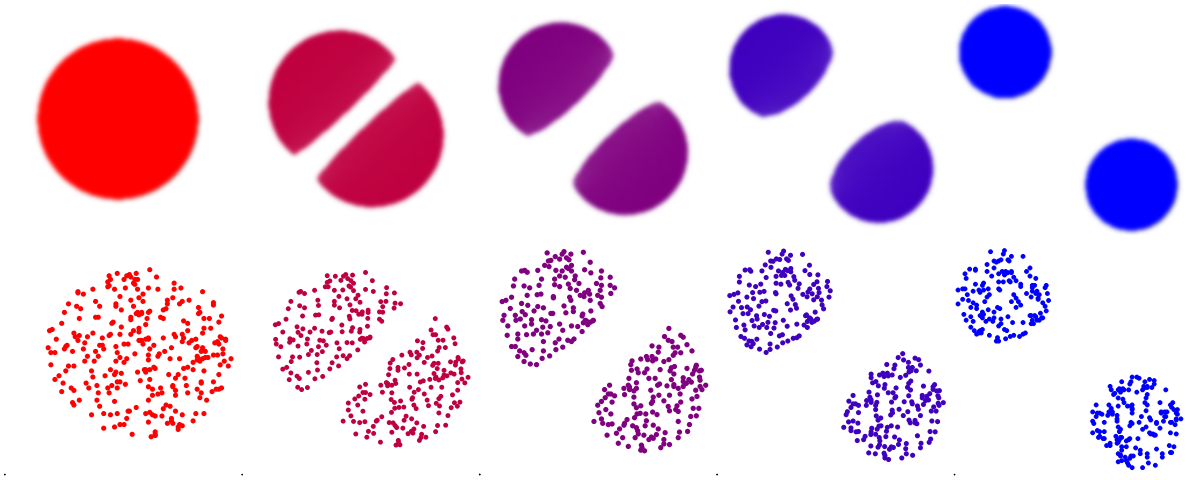

图 7.1: 满足 (7.2) 的位移插值 α_t. 上：两个相对于 Lebesgue 测度具有密度的测度 (α_0, α_1). 下：点数相同的两个离散经验测度（下排）.

其中约束集合定义为

$$\mathcal{C}(\alpha_0, \alpha_1) \overset{\text{def.}}{=} \left\{ (\alpha_t, J_t) \ : \ \frac{\partial \alpha_t}{\partial t} + \operatorname{div}(J_t) = 0, \alpha_{t=0} = \alpha_0, \alpha_{t=1} = \alpha_1 \right\}, \tag{7.4}$$

而 $\theta :\to \mathbb{R}^+ \cup \{+\infty\}$ 为下列下半连续凸函数：

$$\forall\, (a,b) \in \mathbb{R}_+ \times \mathbb{R}^d, \quad \theta(a,b) = \begin{cases} \frac{\|b\|^2}{a} & \text{若} \quad a > 0, \\ 0 & \text{若} \quad (a,b) = 0, \\ +\infty & \text{其他情形.} \end{cases} \tag{7.5}$$

这个定义可能显得复杂，但关键是要保证在 $\alpha_t(x) = 0$ 时，动量 $J_t(x)$ 必须消失. 还要注意，(7.3) 的写法并不严格，仿佛测度 (α_t, J_t) 是密度函数. 但这是可接受的，因为 θ 是一次齐次函数（因而即使测度没有相对于 Lebesgue 测度的密度，也有定义），所以能从密度无歧义地延拓到函数.

注 7.1 (与 McCann 插值的联系). 若存在满足 $T_\sharp \alpha_0 = \alpha_1$ 的最优 Monge 映射 $T : \mathbb{R}^d \to \mathbb{R}^d$ (见公式 (2.28))，则 α_t 就是 McCann 插值

$$\alpha_t = ((1-t)\mathrm{Id} + tT)_\sharp \alpha_0. \tag{7.6}$$

在一维情形中，利用注 2.30，可以由下列关系计算这一插值：

$$\mathcal{C}_{\alpha_t}^{-1} = (1-t)\mathcal{C}_{\alpha_0}^{-1} + t\mathcal{C}_{\alpha_1}^{-1}; \tag{7.7}$$

见图 2.11. Wasserstein 空间的 Riemann 几何的详细综述见 Gangbo and McCann (1996). 若“仅”有最优耦合 π，且其支撑未必位于 Monge 映射上，仍可如下计算插

值：

$$\alpha_t = P_{t\sharp}\pi \quad \text{其中} \quad P_t : (x,y) \in \mathbb{R}^d \times \mathbb{R}^d \mapsto (1-t)x + ty. \tag{7.8}$$

例如，在离散设定 (2.3) 中，令 $\mathbf{P}$ 为 (2.11) 的一个解，则插值定义为

$$\alpha_t = \sum_{i,j} \mathbf{P}_{i,j} \delta_{(1-t)x_i + ty_j}. \tag{7.9}$$

这样的插值通常支撑在 $n+m-1$ 个点上，这是 $\mathbf{P}$ 非零元素的最大数目. 图 7.2 给出了离散测度位移插值的两个例子. 将 P_t 替换为沿测地路径的插值，就能把这个构造推广到测地空间 $\mathcal{X}$. McCann 插值有许多应用，例如计算机图形学中的颜色、形状与照明插值 (Bonneel et al., 2011).

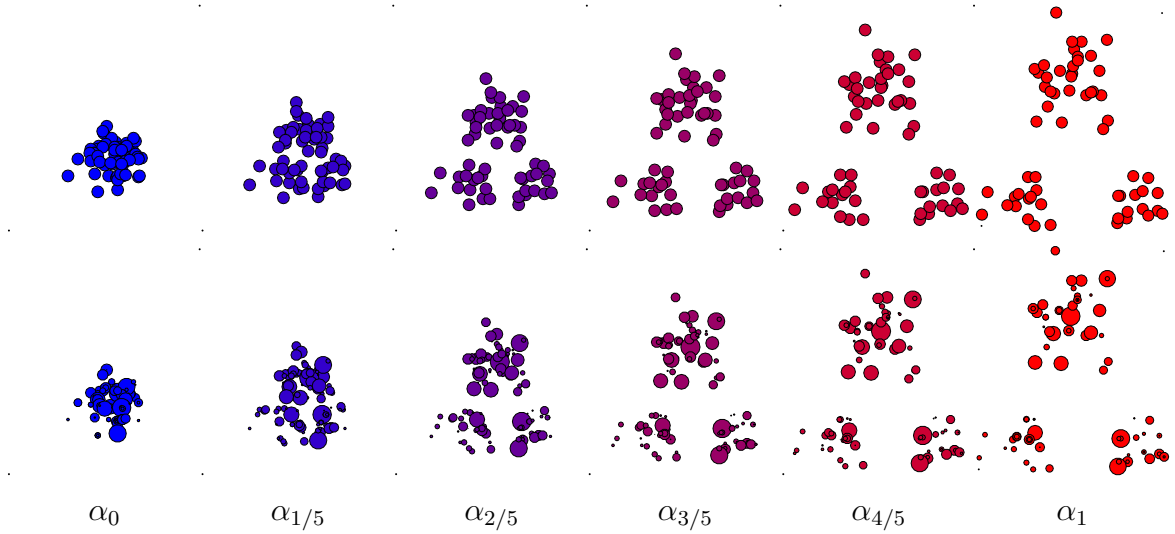

图 7.2: 离散测度的位移插值 (7.8) 比较. 上：点云（点数相同的经验测度 (α_0, α_1)）. 下：同样的点，但权重不同. 当 $0 < t < 1$ 时，上排对应于具有 N 个点的经验测度插值 α_t，下排则定义了支撑在 $2N-1$ 个点上的测度.

7.2 均匀交错网格上的离散化

为简单起见，我们在 $d = 2$ 时描述数值方法；推广到更高维是直接的. 我们采用 Papadakis et al. (2014) 提出的离散化方法，它受到流体动力学中常用的交错网格 (staggered grid) 技术的启发. 将时间离散为 $t_k = k/T \in [0,1]$，并假设空间在点 $x_i = (i_1/n_1, i_2/n_2) \in X = [0,1]^2$ 上均匀离散化. 采用交错网格表示，α_t 用对应于时间方向半网格点的 $\mathbf{a} \in \mathbb{R}^{(T+1)\times n_1 \times n_2}$ 表示，J 则用 $\mathbf{J} = (\mathbf{J}_1, \mathbf{J}_2)$ 表示，其中 $\mathbf{J}_1 \in \mathbb{R}^{T\times(n_1+1)\times n_2}$ 和 $\mathbf{J}_1 \in \mathbb{R}^{T\times n_1\times(n_2+1)}$ 存储在各空间方向的半网格点上. 在这一表示下，对于 $(k, i_1, i_2) \in [\![1,T]\!] \times [\![1,n_1]\!] \times [\![1,n_2]\!]$，时间导数计算为

$$(\partial_t \mathbf{a})_{k,i} \overset{\text{def.}}{=} \mathbf{a}_{k+1,i} - \mathbf{a}_{k,i}$$

空间散度计算为

$$\mathrm{div}(\mathbf{J})_{k,i} \overset{\text{def.}}{=} \mathbf{J}^1_{k,i_1+1,i_2} - \mathbf{J}^1_{k,i_1,i_2} + \mathbf{J}^2_{k,i_1,i_2+1} - \mathbf{J}^2_{k,i_1,i_2}, \tag{7.10}$$

它们都定义在网格点上，从而构成 $\mathbb{R}^{T\times n_1\times n_2}$ 中的数组.

为计算待优化泛函，需要从半网格点到网格点的插值算子. 对于所有 $(k,i_1,i_2)\in[\![1,T]\!]\times[\![1,n_1]\!]\times[\![1,n_2]\!]$，有

$$\mathcal{I}_a(\mathbf{a})_{k,i} \overset{\text{def.}}{=} \mathcal{I}(\mathbf{a}_{k+1,i},\mathbf{a}_{k,i}),$$

$$\mathcal{I}_J(\mathbf{J})_{k,i} \overset{\text{def.}}{=} (\mathcal{I}(\mathbf{J}^1_{k,i_1+1,i_2},\mathbf{J}^1_{k,i_1,i_2}),\mathcal{I}(\mathbf{J}^2_{k,i_1,i_2+1},\mathbf{J}^2_{k,i_1,i_2})).$$

最简单的选择是线性算子 $\mathcal{I}(r,s)=\frac{r+s}{2}$，下文就采用它. (7.3) 的离散对应式为

$$\min_{(\mathbf{a},\mathbf{J})\in\mathbf{C}(\mathbf{a}_0,\mathbf{a}_1)} \Theta(\mathcal{I}_a(\mathbf{a}),\mathcal{I}_J(\mathbf{J})), \tag{7.11}$$

$$\text{其中}\quad \Theta(\tilde{\mathbf{a}},\tilde{\mathbf{J}}) \overset{\text{def.}}{=} \sum_{k=1}^{T}\sum_{i_1=1}^{n_1}\sum_{i_2=1}^{n_2}\theta(\tilde{\mathbf{a}}_{k,i},\tilde{\mathbf{J}}_{k,i}),$$

其中约束变为

$$\mathbf{C}(\mathbf{a}_0,\mathbf{a}_1) \overset{\text{def.}}{=} \{(\mathbf{a},\mathbf{J}) \;:\; \partial_t\mathbf{a}+\mathrm{div}(\mathbf{J})=0, (\mathbf{a}_{0,\cdot},\mathbf{a}_{T,\cdot})=(\mathbf{a}_0,\mathbf{a}_1)\},$$

这里 $\mathbf{a}\in\mathbb{R}^{(T+1)\times n_1\times n_2}$，$\mathbf{J}=(\mathbf{J}_1,\mathbf{J}_2)$，且 $\mathbf{J}_1\in\mathbb{R}^{T\times(n_1+1)\times n_2}$，$\mathbf{J}_2\in\mathbb{R}^{T\times n_1\times(n_2+1)}$. 图 7.3 展示了用这种离散化方法近似演化 $(\alpha_t)_t$ 的例子.

注 7.2 (图上的动态表述). 当 $\mathcal{X}$ 为图且 $c(x,y)=d_{\mathcal{X}}(x,y)^2$ 为测地距离的平方时，可以推导忠实的离散化方法，用与图结构对应的离散散度代替均匀网格离散化 (7.10). 为使热方程对于相应的动态 Wasserstein 距离具有梯度流结构（梯度流详见第 9.3 节），Maas (2011) 以及后来的 Mielke (2013) 提议采用对数平均 $\mathcal{I}(r,s)$（另见 (Solomon et al., 2016b; Chow et al., 2012, 2017b,a)）.

7.3 近端求解器

离散动态最优传输问题 (7.11) 难以求解，因为需要在仿射约束下极小化非光滑目标. 事实上，函数 θ 虽然凸，但在质量 $\mathbf{a}_{k,i}$ 消失时不光滑. 对两个紧支撑输入测度 $(\mathbf{a}_0,\mathbf{a}_1)$ 插值时，插值测度 $(\mathbf{a}_k)_{k=1}^T$ 的质量通常也会在某些位置消失；优化过程的难点正是跟踪支撑的这种演化. 特别地，不能使用标准光滑优化技术.

可以用多种方式将 (7.11) 改写为二次锥规划，例如考虑对偶问题，或者直接在约束下用线性函数替换泛函 $\theta(\mathbf{a}_{k,i},\mathbf{J}_{k,i})$：

$$\Theta(\tilde{\mathbf{a}},\tilde{\mathbf{J}}) = \min_{\tilde{\mathbf{z}}}\left\{\sum_{k,i}\tilde{\mathbf{z}}_{k,i} \;:\; \forall\,(k,i),(\mathbf{z}_{k,i},\tilde{\mathbf{a}}_{k,i},\tilde{\mathbf{J}}_{i,j})\in\mathcal{L}\right\},$$

因此需要引入额外变量 $\tilde{\mathbf{z}}$. 这里 $\mathcal{L} \overset{\text{def.}}{=} \{(z,a,J) \in \mathbb{R} \times \mathbb{R}^+ \times \mathbb{R}^d \;:\; \|J\|^2 \leq za\}$ 为旋转 Lorentz 二次锥. 加入这个变量后，可以用标准二次锥规划内点求解器求解离散问题 (Nesterov and Nemirovskii, 1994). 这些求解器收敛快，能够高精度地计算解. 但每次迭代代价高昂，需要求解维数随离散点数增长的线性系统，因此不适用于成像应用中出现的大规模多维问题.

替代这些高精度求解器的是低精度一阶方法；它们适合 (7.11) 这样非光滑但结构丰富的问题. 这类求解器并不新颖，却在近年的成像与机器学习领域重新活跃起来，因为这些应用并不以数值精度为主要目标，恰好适合这类方法. 例如，关于这些求解器及其大规模应用的详细介绍，见专著 (Bauschke and Combettes, 2011). 这里集中介绍一种求解器，当然还可以使用许多其他方法；动态最优传输的多种相关方法见 (Papadakis et al., 2014). 注意，最早由 Benamou and Brenier (2000) 提出了在动态最优传输中使用一阶方法的思想.

DR 算法 (Lions and Mercier, 1979) 专门用于求解形如下式的非光滑结构化问题：

$$\min_{x \in \mathcal{H}} F(x) + G(x), \tag{7.12}$$

其中 $\mathcal{H}$ 为某个欧氏空间，$F, G : \mathcal{H} \to \mathbb{R} \cup \{+\infty\}$ 是两个闭凸函数，且可 “容易地” 计算其近端算子（例如通过闭式公式或快速收敛的方法）：

$$\forall\, x \in \mathcal{H}, \quad \mathrm{Prox}_{\tau F}(x) \overset{\text{def.}}{=} \operatorname*{argmin}_{x' \in \mathcal{H}} \frac{1}{2}\|x - x'\|^2 + \tau F(x) \tag{7.13}$$

其中参数 $\tau > 0$. 注意，这对应于欧氏度量下的近端映射；定义还可用更一般的 Bregman 散度代替 $\|x - x'\|^2$ 来推广. 使用 **KL** 散度的例子见 (4.52). DR 算法从初值 $(x^{(0)}, w^{(0)}) \in \mathcal{H}^2$ 出发，以下列迭代定义序列 $(x^{(\ell)}, w^{(\ell)}) \in \mathcal{H}^2$：

$$\begin{aligned} w^{(\ell+1)} &\overset{\text{def.}}{=} w^{(\ell)} + \alpha(\mathrm{Prox}_{\gamma F}(2x^{(\ell)} - w^{(\ell)}) - x^{(\ell)}), \\ x^{(\ell+1)} &\overset{\text{def.}}{=} \mathrm{Prox}_{\gamma G}(w^{(\ell+1)}). \end{aligned} \tag{7.14}$$

若 $0 < \alpha < 2$ 且 $\gamma > 0$，可证明 $x^{(\ell)} \to z^\star$，其中 $z^\star$ 为 (7.12) 的解；详见 (Combettes and Pesquet, 2007). 这一算法与另一种常用方法——交替方向乘子法 (Gabay and Mercier, 1976; Glowinski and Marroco, 1975)——紧密相关（综述另见 (Boyd et al., 2011)）；在对偶问题上应用 DR，就可得到该方法. 两者等价性的更多细节见 (Papadakis et al., 2014)，最初证明见 (Eckstein and Bertsekas, 1992).

将问题 (7.11) 改写为 (7.12) 有很多办法，详见 (Papadakis et al., 2014). 一种简单办法是令 $x = (\mathbf{a}, \mathbf{J}, \tilde{\mathbf{a}}, \tilde{\mathbf{J}})$ 并设

$$F(x) \overset{\text{def.}}{=} \Theta(\tilde{\mathbf{a}}, \tilde{\mathbf{J}}) + \iota_{\mathbf{C}(\mathbf{a}_0, \mathbf{a}_1)}(\mathbf{a}, \mathbf{J}) \quad \text{且} \quad G(x) = \iota_{\mathcal{D}}(\mathbf{a}, \mathbf{J}, \tilde{\mathbf{a}}, \tilde{\mathbf{J}}),$$

$$\text{其中} \quad \mathcal{D} \overset{\text{def.}}{=} \left\{ (\mathbf{a}, \mathbf{J}, \tilde{\mathbf{a}}, \tilde{\mathbf{J}}) \;:\; \tilde{\mathbf{a}} = \mathcal{I}_a(\mathbf{a}), \tilde{\mathbf{J}} = \mathcal{I}_J(\mathbf{J}) \right\}.$$

这两个函数的近端算子都可高效计算. 事实上，有

$$\mathrm{Prox}_{\tau F}(x) = (\mathrm{Prox}_{\tau\Theta}(\tilde{\mathbf{a}}, \tilde{\mathbf{J}}), \mathrm{Proj}_{\mathbf{C}(\mathbf{a}_0, \mathbf{a}_1)}(\mathbf{a}, \mathbf{J})).$$

近端算子 $\mathrm{Prox}_{\tau\Theta}$ 通过在每个网格位置求解三次多项式方程来计算. 仿射约束 $\mathbf{C}(\mathbf{a}_0, \mathbf{a}_1)$ 上的正交投影涉及求解 Poisson 方程，可用快速 Fourier 变换在 $O(N\log(N))$ 次运算内完成，其中 $N = Tn_1n_2$ 是网格点数. 最后，近端算子 $\mathrm{Prox}_{\tau G}$ 为线性投影，需要求解一个小型线性系统. 这些计算的更多细节见 Papadakis et al. (2014). 图 7.3 展示了用这种方法在复杂平面区域内计算动态插值的例子. 这类动态最优传输近端方法也曾用于求解平均场博弈等相关问题 (Benamou and Carlier, 2015).

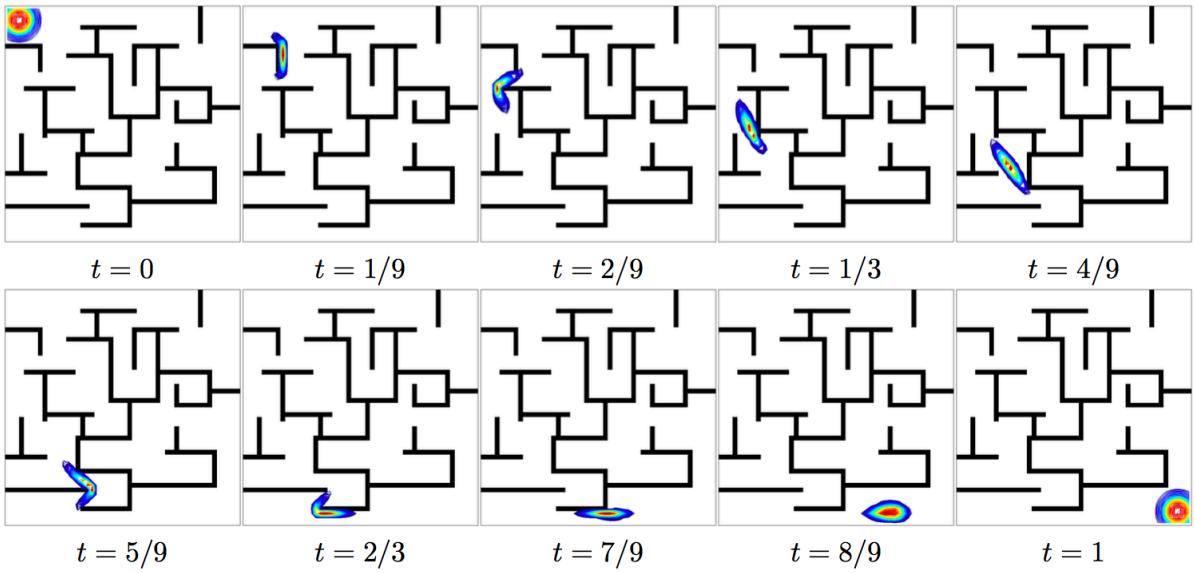

图 7.3: 利用近端分裂方法计算的动态最优传输解 α_t.

7.4 动态非平衡最优传输

为了匹配质量不同的输入测度 $\alpha_0(\mathcal{X}) \neq \alpha_1(\mathcal{X})$（即 “非平衡” 情形，这个术语由 Benamou (2003) 提出），并处理局部质量变化，人们提出了多种归一化或松弛方式，特别是放松固定边缘约束；见第 10.2 节. 一种通用办法是在连续性方程 (7.4) 中引入源项 $s_t(x)$. 因此考虑

$$\bar{\mathcal{C}}(\alpha_0, \alpha_1) \overset{\text{def.}}{=} \left\{ (\alpha_t, J_t, s_t) \;:\; \frac{\partial \alpha_t}{\partial t} + \mathrm{div}(J_t) = s_t, \alpha_{t=0} = \alpha_0, \alpha_{t=1} = \alpha_1 \right\}.$$

关键问题是如何衡量源项的代价，并将其加入原始动态表述 (7.3). 文献已有多种提议，例如 Piccoli and Rossi (2014) 使用 L^2 代价. 为避免质量 “瞬移”（以无限速度运动，突然在原来没有质量的区域增长），相应代价应为无穷大. 事实上，只需允许 s_t 也是任意测度（例如采用一次齐次代价），并以与动量 J_t 相同的方式惩罚 s_t，就可通过简单的凸方法做到这一点：

$$\mathrm{WFR}^2(\alpha_0, \alpha_1) = \min_{(\alpha_t, J_t, s_t)_t \in \bar{\mathcal{C}}(\alpha_0, \alpha_1)} \Theta(\alpha, J, s), \tag{7.15}$$

$$\text{其中}\quad \Theta(\alpha,J,s)\overset{\text{def.}}{=}\int_0^1\int_{\mathbb{R}^d}(\theta(\alpha_t(x),J_t(x))+\tau\theta(\alpha_t(x),s_t(x)))\,\mathrm{d}x\mathrm{d}t,$$

其中 θ 为 (7.5) 引入的一次齐次凸函数，τ 控制质量传输与质量生成/消灭之间的权衡. 多位作者独立提出了这个表述 (Liero et al., 2016; Chizat et al., 2018c; Kondratyev et al., 2016). 这一 "动态" 表述具有 "静态" 对应式；见注 10.5. 凸优化问题 (7.15) 可以用与第 7.3 节类似的方法求解. 图 7.4 比较了多种非平衡最优传输动态插值. 这一动态表述与形状配准中的 "蜕变" 模型 (Trouvé and Younes, 2005) 相似，更精确的联系见 (Maas et al., 2015, 2016).

当 $\tau\to 0$ 且 $\alpha_0(\mathcal{X})=\alpha_1(\mathcal{X})$ 时，恢复经典最优传输问题，即 $\mathrm{WFR}(\alpha_0,\alpha_1)\to\mathcal{W}(\alpha_0,\alpha_1)$. 相反，当 $\tau\to+\infty$ 时，这个距离趋近于密度上的 Hellinger 度量：

$$\begin{aligned}\frac{1}{\tau}\mathrm{WFR}(\alpha_0,\alpha_1)^2 &\overset{\tau\to+\infty}{\longrightarrow}\int_{\mathcal{X}}|\sqrt{\rho_{\alpha_0}(x)}-\sqrt{\rho_{\alpha_1}(x)}|^2\mathrm{d}x\\ &=\int_{\mathcal{X}}|1-\sqrt{\frac{\mathrm{d}\alpha_1}{\mathrm{d}\alpha_0}(x)}|^2\mathrm{d}\alpha_0(x).\end{aligned}$$

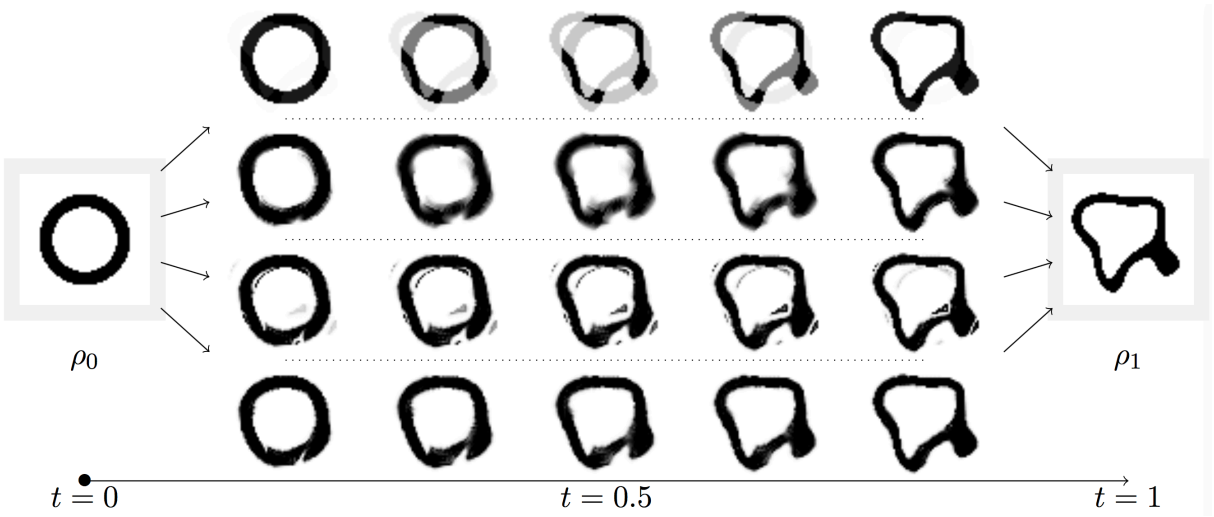

图 7.4: Hellinger（第 1 排）、Wasserstein（第 2 排）、部分最优传输（第 3 排）与 Wasserstein–Fisher–Rao（第 4 排）的动态插值比较.

7.5 更一般的迁移率泛函

用其他迁移率函数（mobility function）θ 代替 (7.5) 定义的函数，可以推广动态表述 (7.3). Dolbeault et al. (2009) 提出的一种选择为

$$\forall\,(a,b)\in\mathbb{R}_+\times\mathbb{R}^d,\quad \theta(a,b)=a^{s-p}\,\|b\|^p\,,\tag{7.16}$$

为了使 θ 为凸函数，参数应满足 $p\geq 1$ 且 $s\in[1,p]$. 注意，在 $1<s\leq p$ 时使用这个定义要谨慎，因为 θ 在无穷远处不具有线性增长，所以 (7.3) 的解必须被限制为具有相对于 Lebesgue 测度的密度.

$s=1$ 对应于经典最优传输问题，(7.3) 的最优值定义了 $\mathcal{W}_p(\alpha,\beta)$. 此时 θ 为一次齐次函数，因此 (7.3) 的解可以是任意测度. $(s=1,p=2)$ 就是在 (7.3) 中定义 $\mathcal{W}_2$ 的原始设定.

极限情形 $s=p$ 也很有意义，它对应于对偶 Sobolev 范数 $W^{-1,p}$，此时 (7.3) 的值为

$$\|\alpha-\beta\|^p_{W^{-1,p}(\mathbb{R}^d)}=\min_f\left\{\int_{\mathbb{R}^d} f\mathrm{d}(\alpha-\beta)\ :\ \int_{\mathbb{R}^d}\|\nabla f(x)\|^q\,\mathrm{d}x\leq 1\right\}$$

其中 $1/q+1/p=1$. 在极限 $(p=s,q)\to(1,\infty)$ 中，恢复 $\mathcal{W}_1$ 范数. $s=p=2$ 对应于 (8.15) 定义的 Sobolev $H^{-1}(\mathbb{R}^d)$ Hilbert 范数.

7.6 路径空间上的动态表述

经典最优传输与熵正则化最优传输（见第 4 章）都具有自然的动态表述：在空间 $\mathcal{X}$ 上所有可能路径 $\gamma:[0,1]\to\mathcal{X}$（即曲线）组成的空间 $\bar{\mathcal{X}}$ 上研究抽象优化问题. 为简单起见，假设 $\mathcal{X}=\mathbb{R}^d$；这也可推广到测地空间、图等更一般空间. 非严格地说，两个输入测度 α_0,α_1 之间在 $t=0,1$ 时的“粒子”动态由概率分布 $\bar\pi\in\mathcal{M}_+^1(\bar{\mathcal{X}})$ 描述. 起点与终点的分布应分别为 (α_0,α_1)，用推前严格写为

$$\bar{\mathcal{U}}(\alpha_0,\alpha_1)\overset{\text{def.}}{=}\left\{\bar\pi\in\mathcal{M}_+^1(\bar{\mathcal{X}})\ :\ \bar P_{0\sharp}\bar\pi=\alpha_0,\bar P_{1\sharp}\bar\pi=\alpha_1\right\},$$

其中，对于任意路径 $\gamma\in\bar{\mathcal{X}}$，$P_0(\gamma)=\gamma(0),P_1(\gamma)=\gamma(1)$.

路径空间上的最优传输. 经典最优传输 (2.15) 在路径空间上的动态版本为

$$\mathcal{W}_2(\alpha_0,\alpha_1)^2=\min_{\bar\pi\in\bar{\mathcal{U}}(\alpha_0,\alpha_1)}\int_{\bar{\mathcal{X}}}\mathcal{L}(\gamma)^2\mathrm{d}\bar\pi(\gamma),\tag{7.17}$$

其中 $\mathcal{L}(\gamma)=\int_0^1|\gamma'(s)|^2\mathrm{d}s$ 是路径 $s\in[0,1]\mapsto\gamma(s)\in\mathcal{X}$ 的动能. 分别求解 (7.17) 与 (2.15) 的最优耦合 $\pi^\star$ 和 $\bar\pi^\star$ 的联系是：$\bar\pi^\star$ 仅向连接点对的测地线赋予质量，比例由 $\pi^\star$ 决定. 特别地，对于离散测度，这意味着

$$\pi^\star=\sum_{i,j}\mathbf{P}_{i,j}\delta_{(x_i,y_j)}\quad\text{且}\quad\bar\pi^\star=\sum_{i,j}\mathbf{P}_{i,j}\delta_{\gamma_{x_i,y_j}},$$

其中 γ_{x_i,y_j} 是 x_i 与 y_j 之间的测地线. 此外，从 $\bar\pi^\star$ 抽取 γ，由时刻 t 的曲线点 $\gamma(t)$ 的分布定义的测度，即

$$t\in[0,1]\mapsto\alpha_t\overset{\text{def.}}{=}P_{t\sharp}\bar\pi^\star\quad\text{其中}\quad P_t(\gamma)=\gamma(t)\in\mathcal{X},\tag{7.18}$$

是动态表述 (7.3) 的解，也就是位移插值. 在离散情形中，就得到 (7.9).

路径空间上的熵最优传输. 现在利用路径空间重新解释第 4 章定义的熵最优传输. 与 (4.11) 类似，它由 Kullback–Leibler 投影定义，但此次投影的是路径空间上的参考测度 $\bar{\mathcal{K}}$：它是可逆 Brown 运动（Wiener 过程）的分布，初始与终止时刻都具有均匀分布：

$$\min_{\bar{\pi}\in\bar{\mathcal{U}}(\alpha_0,\alpha_1)} \mathrm{KL}(\bar{\pi}|\bar{\mathcal{K}}). \tag{7.19}$$

关于这一问题的概述以及 Schrödinger (1931) 工作的历史介绍，见 Léonard (2014) 的综述. 可以证明，(7.19) 的（唯一）解 $\bar{\pi}^\star_\varepsilon$ 在 $\varepsilon\to 0$ 时收敛于 (7.17) 的一个解. 此外，这个解通过 Brown 桥 $\bar{\gamma}^\varepsilon_{x,y}\in\bar{\mathcal{X}}$ 与静态熵最优传输问题 (4.9) 的解联系起来（Brown 桥类似模糊的测地线，且在 $\varepsilon\to 0$ 时收敛到 $\delta_{\gamma_{x,y}}$）. 在离散设定中，这意味着

$$\pi^\star_\varepsilon=\sum_{i,j}\mathbf{P}^\star_{\varepsilon,i,j}\delta_{(x_i,y_j)} \quad 且 \quad \bar{\pi}^\star_\varepsilon=\sum_{i,j}\mathbf{P}^\star_{\varepsilon,i,j}\bar{\gamma}^\varepsilon_{x_i,y_j}, \tag{7.20}$$

其中 $\mathbf{P}^\star_{\varepsilon,i,j}$ 可以用 Sinkhorn 算法计算. 与 (7.18) 类似，可以定义熵插值

$$\alpha_{\varepsilon,t}\overset{\text{def.}}{=}\mathbf{P}_{t\sharp}\bar{\pi}^\star_\varepsilon.$$

由于沿 Brown 桥在时刻 t 的位置分布 $\mathbf{P}_{t\sharp}\bar{\gamma}^\varepsilon_{x,y}$ 为以 $\gamma_{x,y}(t)$ 为中心、方差为 $t(1-t)\varepsilon^2$ 的 Gaussian 分布 $\mathcal{G}_{t(1-t)\varepsilon^2}(\cdot-\gamma_{x,y}(t))$，可推出 $\alpha_{\varepsilon,t}$ 是一组移动 Dirac 质量的 Gaussian 模糊：

$$\alpha_{\varepsilon,t}=\sum_{i,j}\mathbf{P}^\star_{\varepsilon,i,j}\mathcal{G}_{t(1-t)\varepsilon^2}(\cdot-\gamma_{x_i,y_j}(t)).$$

相应的 Brown 桥混合见图 7.5.

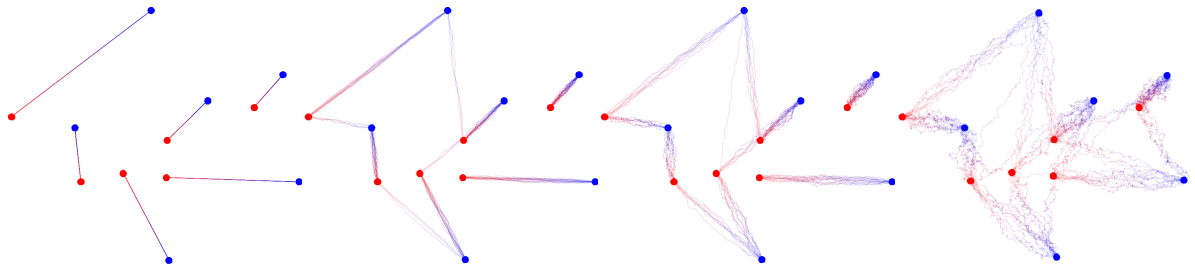

图 7.5: 路径空间中 Schrödinger 熵插值 (7.20) 对应的 Brown 桥路径样本. 蓝色对应 $t=0$，红色对应 $t=1$.

描述这一熵插值 $(\alpha_t)_t$ 的另一种方式，是正则化 Benamou–Brenier 动态表述 (7.2)，即

$$\min_{(\alpha_t,v_t)_t\ 满足\ (7.1)}\int_0^1\int_{\mathbb{R}^d}\left(\|v_t(x)\|^2+\frac{\varepsilon}{4}\|\nabla\log(\alpha_t)(x)\|^2\right)\mathrm{d}\alpha_t(x)\mathrm{d}t; \tag{7.21}$$

见 (Gentil et al., 2015; Chen et al., 2016a).

Chapter 8

统计散度

本章研究 Wasserstein 距离的统计性质. 具体而言，将它与数据科学中常用的其他主要距离和散度比较，并量化仅能获得两个概率分布的样本时，如何近似分布之间的距离. 为引入这些主题，第 8.1 节和第 8.2 节分别回顾概率分布之间的散度与积分概率度量. 散度 D 通常满足 $D(\alpha,\beta)\geq 0$，且 $D(\alpha,\beta)=0$ 当且仅当 $\alpha=\beta$，但不必对称，也不必满足三角不等式. 测度的积分概率度量是由指定检验函数族定义的对偶范数. 这些量可以合理替代 Wasserstein 距离，常用作损失函数来处理推断问题，第 9 章将介绍这类应用. 首先，第 8.3 节说明最优传输距离并非 Hilbert 型，即不能通过概率测度的适当特征表示上的 Hilbert 度量高效近似. 第 8.4 节介绍如何利用从 α 和 β 抽取的离散样本 $(x_i)_i$ 与 $(y_j)_j$ 近似 $D(\alpha,\beta)$. 在机器学习中使用 Wasserstein 距离时，充分理解这一问题的统计性质至关重要. 本节主要讨论支撑在连续集合上的分布之间最优传输的统计近似. 基础空间为有限集合时，同一问题在 Sommerfeld and Munk (2018) 的工作之后也受到关注， Bigot et al. (2017a) 将其推广到熵正则化的量.

8.1 φ-散度

下节将详述构造方式与 $\mathcal{W}_1$ 类似的 “弱” 范数；在此之前，先介绍测度之间所谓散度的一般构造，它们可用作估计概率分布时的损失函数. 这些散度通过逐点比较两个输入测度的质量来比较测度，不涉及质量传输概念. 散度是通过两个测度的逐点比值衡量其接近程度的泛函，具有良好的分析与计算性质，建立在熵函数之上.

定义 8.1 (熵函数). 函数 $\varphi:\mathbb{R}\to\mathbb{R}\cup\{\infty\}$ 称为熵函数 (entropy function)，如果它下半连续、凸，满足 $\operatorname{dom}\varphi\subset[0,\infty[$，并满足可行性条件 $\operatorname{dom}\varphi\cap]0,\infty[\neq\emptyset$. φ 在无穷远处的增长速度由下式描述：

$$\varphi'_\infty=\lim_{x\to+\infty}\varphi(x)/x\in\mathbb{R}\cup\{\infty\}.$$

若 $\varphi'_\infty=\infty$，则 φ 比任何线性函数增长都快，称为超线性函数. 任意熵函数 φ 按如下方式诱导一个 φ-散度 (也称 Ciszár 散度 (Ciszár, 1967; Ali and Silvey, 1966) 或 f-散度).

定义 8.2 (φ-散度). 设 φ 为熵函数. 对于 $\alpha,\beta\in\mathcal{M}(\mathcal{X})$，令 $\frac{\mathrm{d}\alpha}{\mathrm{d}\beta}\beta+\alpha^\perp$ 为 α 关于 β 的 Lebesgue 分解[2]. 若 α,β 非负，散度 $\mathcal{D}_\varphi$ 定义为

$$\mathcal{D}_\varphi(\alpha|\beta)\overset{\text{def.}}{=}\int_{\mathcal{X}}\varphi\left(\frac{\mathrm{d}\alpha}{\mathrm{d}\beta}\right)\mathrm{d}\beta+\varphi'_\infty\alpha^\perp(\mathcal{X}) \tag{8.1}$$

[2]Lebesgue 分解定理断言，给定 β 后，α 唯一地分解为两个测度之和 $\alpha^s+\alpha^\perp$，使得 α^s 相对于 β 绝对连续，而 $\alpha^\perp$ 与 β 相互奇异.

否则定义为 ∞.

(8.1) 中的附加项 $\varphi'_\infty \alpha^\perp(\mathcal{X})$ 很重要，它保证即使 φ 在无穷远处线性增长，$\mathcal{D}_\varphi$ 仍定义连续泛函（相对于测度的弱拓扑）. 定义 TV 范数的绝对值函数 (8.8) 就是这种情形. 若 φ 超线性增长，例如通常的熵 (8.4)，则 $\varphi'_\infty = +\infty$；因此，如果 α 没有关于 β 的密度，则 $\mathcal{D}_\varphi(\alpha|\beta) = +\infty$.

在离散设定中，假设

$$\alpha = \sum_i \mathbf{a}_i \delta_{x_i} \quad \text{且} \quad \beta = \sum_i \mathbf{b}_i \delta_{x_i} \tag{8.2}$$

支撑在同一组 n 个点 $(x_i)_{i=1}^n \subset \mathcal{X}$ 上，则 (8.1) 在 Σ_n 上定义散度

$$\mathbf{D}_\varphi(\mathbf{a}|\mathbf{b}) = \sum_{i \in \mathrm{Supp}(\mathbf{b})} \varphi\left(\frac{\mathbf{a}_i}{\mathbf{b}_i}\right) \mathbf{b}_i + \varphi'_\infty \sum_{i \notin \mathrm{Supp}(\mathbf{b})} \mathbf{a}_i, \tag{8.3}$$

其中 $\mathrm{Supp}(\mathbf{b}) \overset{\text{def.}}{=} \{i \in [\![n]\!] : b_i \neq 0\}$.

下面命题的证明见 (Liero et al., 2018, 定理 2.7).

命题 8.1.1. *若 φ 为熵函数，则 $\mathcal{D}_\varphi$ 关于 (α, β) 联合一次齐次、凸且弱 * 下半连续.*

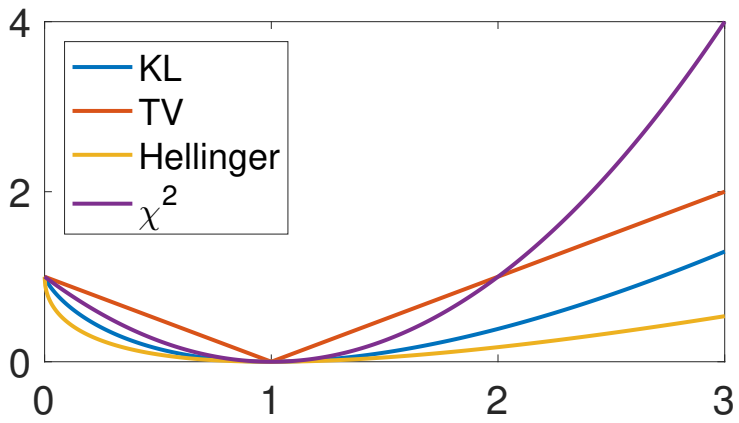

图 8.1: 熵泛函的例子.

注 8.1 (对偶表达式)**.** *φ-散度可以用 φ 的 Legendre 变换*

$$\varphi^*(s) \overset{\text{def.}}{=} \sup_{t \in \mathbb{R}} st - \varphi(t)$$

(另见 (4.54)) 表达为

$$\mathcal{D}_\varphi(\alpha|\beta) = \sup_{f:\mathcal{X}\to\mathbb{R}} \int_{\mathcal{X}} f(x)\mathrm{d}\alpha(x) - \int_{\mathcal{X}} \varphi^*(f(x))\mathrm{d}\beta(x);$$

更多细节见 Liero et al. (2018).

现在回顾这个框架的几个常见实例. 图 8.1 给出了相应的熵泛函，图 8.2 则总结了它们之间的关系.

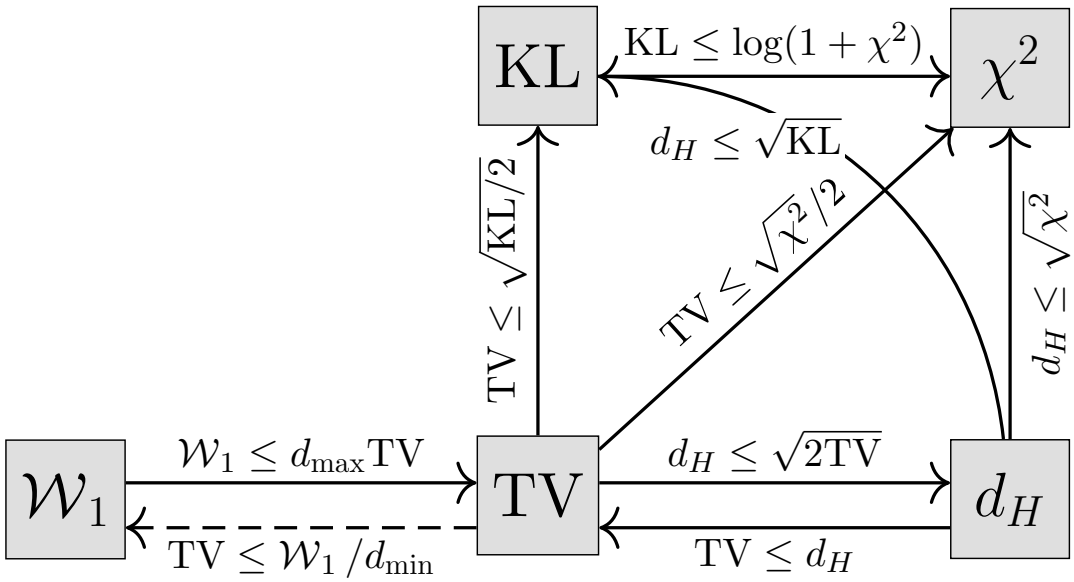

图 8.2: 散度之间的关系图（受 Gibbs and Su (2002) 启发）. 若 $\mathcal{X}$ 为基础距离为 d 的度量空间，则 $d_{\max} = \sup_{(x,x')} d(x,x')$ 是 $\mathcal{X}$ 的直径. 当 $\mathcal{X}$ 离散时，$d_{\min} \overset{\text{def.}}{=} \min_{x \neq x'} d(x,x')$.

例 8.1.1 (Kullback–Leibler 散度). Kullback–Leibler 散度 $\mathrm{KL} \overset{\text{def.}}{=} \mathcal{D}_{\varphi_{\mathrm{KL}}}$，也称相对熵，已在 (4.10) 和 (4.6) 中引入. 它对应于 Shannon–Boltzman 熵函数 φ_{KL}：

$$\varphi_{\mathrm{KL}}(s) = \begin{cases} s\log(s) - s + 1 & \text{当} s > 0, \\ 1 & \text{当} s = 0, \\ +\infty & \text{其他情形.} \end{cases} \tag{8.4}$$

◇

注 8.1.1 (Bregman 散度). 离散 KL 散度 $\mathbf{KL} \overset{\text{def.}}{=} \mathbf{D}_{\varphi_{\mathrm{KL}}}$ 具有既是 φ-散度又是 Bregman 散度这一独特性质. 对于 $\mathbb{R}^n$ 中的离散向量，与光滑严格凸函数 $\psi : \mathbb{R}^n \to \mathbb{R}$ 对应的 Bregman 散度 (Bregman, 1967) 定义为

$$\mathbf{B}_\psi(\mathbf{a}|\mathbf{b}) \overset{\text{def.}}{=} \psi(\mathbf{a}) - \psi(\mathbf{b}) - \langle \nabla\psi(\mathbf{b}), \mathbf{a} - \mathbf{b} \rangle, \tag{8.5}$$

其中 $\langle \cdot, \cdot \rangle$ 是 $\mathbb{R}^n$ 上的典范内积. 注意，$\mathbf{B}_\psi(\mathbf{a}|\mathbf{b})$ 关于 $\mathbf{a}$ 为凸函数，关于 ψ 为线性函数. 与 φ-散度类似，Bregman 散度满足 $\mathbf{B}_\psi(\mathbf{a}|\mathbf{b}) \ge 0$，且 $\mathbf{B}_\psi(\mathbf{a}|\mathbf{b}) = 0$ 当且仅当 $\mathbf{a} = \mathbf{b}$. KL 散度对应于负熵 $\psi = -\mathbf{H}$（定义见 (4.1)）的 Bregman 散度，即 $\mathbf{KL} = \mathbf{B}_{-\mathbf{H}}$. Bregman 散度局部为平方欧氏距离，因为

$$\mathbf{B}_\psi(\mathbf{a} + \varepsilon|\mathbf{a} + \eta) = \langle \partial^2\psi(\mathbf{a})(\varepsilon - \eta), \varepsilon - \eta \rangle + o(\|\varepsilon - \eta\|^2)$$

而分离点集合 $\{\mathbf{a} : \mathbf{B}_\psi(\mathbf{a}|\mathbf{b}) = \mathbf{B}_\psi(\mathbf{a}|\mathbf{b}')\}$ 是位于 $\mathbf{b}$ 与 $\mathbf{b}'$ 之间的超平面. 这些性质使 Bregman 散度适合在一阶优化方法中代替欧氏距离. 最著名的例子是镜像梯度下降 (Beck and Teboulle, 2003)，它是形如 (9.32) 的显式下降步骤. Bregman 散度在凸优化中也很重要，例如可用于推导 Sinkhorn 迭代并研究其在有限维中的收敛性；见注 4.8. ◇

注 8.1.2 (KL 的双曲几何). 比较 Gaussian 分布时，将 Kullback–Leibler 散度的几何与二次最优传输的几何对照很有意思. 例如 Costa et al. (2015) 详细说明，Kullback–Leibler 散度对 Gaussian 密度有闭式公式. 在单变量情形 $d=1$ 中，若 $\alpha=\mathcal{N}(m_\alpha,\sigma_\alpha^2)$ 且 $\beta=\mathcal{N}(m_\beta,\sigma_\beta^2)$，则

$$\mathrm{KL}(\alpha|\beta)=\frac{1}{2}\left(\frac{\sigma_\alpha^2}{\sigma_\beta^2}+\log\left(\frac{\sigma_\beta^2}{\sigma_\alpha^2}\right)+\frac{|m_\alpha-m_\beta|}{\sigma_\beta^2}-1\right). \tag{8.6}$$

这个表达式表明，当 σ_β 减小到 0、β 变为 Dirac 质量时，α 与 β 之间的散度趋于无穷大. 因此可以说，在 KL 几何中，奇异 Gaussian 分布与其他所有 Gaussian 分布相距无穷远. 所以，若希望避免奇异协方差，这种几何很有用. 为简化分析，可以研究 KL 的无穷小几何，它通过二阶 Taylor 展开得到：

$$\mathrm{KL}(\mathcal{N}(m+\delta_m,(\sigma+\delta_\sigma)^2)|\mathcal{N}(m,\sigma^2))=\frac{1}{\sigma^2}\left(\frac{1}{2}\delta_m^2+\delta_\sigma^2\right)+o(\delta_m^2,\delta_\sigma^2).$$

这个局部 Riemann 度量称为 Fisher 度量，在 $(m/\sqrt{2},\sigma)\in\mathbb{R}\times\mathbb{R}_{+,*}$ 上表达时，恰好与双曲 Poincaré 半平面的度量一致. 该空间中的测地线为圆心位于 $\sigma=0$ 直线上的半圆，速度呈指数变化，即只有在无穷时间后才到达极限 $\sigma=0$. 特别要注意，若 $\sigma_\alpha=\sigma_\beta$ 但 $m_\alpha\neq m_\alpha$，则 (α,β) 在这个双曲半平面中的测地线不具有常数标准差.

Gaussian 参数空间 (m,σ) 上的 KL 双曲几何，应与注 2.31 所述的最优传输欧氏几何比较，因为在单变量情形中

$$\mathcal{W}_2^2(\alpha,\beta)=|m_\alpha-m_\beta|^2+|\sigma_\alpha-\sigma_\beta|^2. \tag{8.7}$$

图 8.3 直观比较了这两种几何及其测地线. Jean Feydy 向我们提出了这一有趣的比较.◇

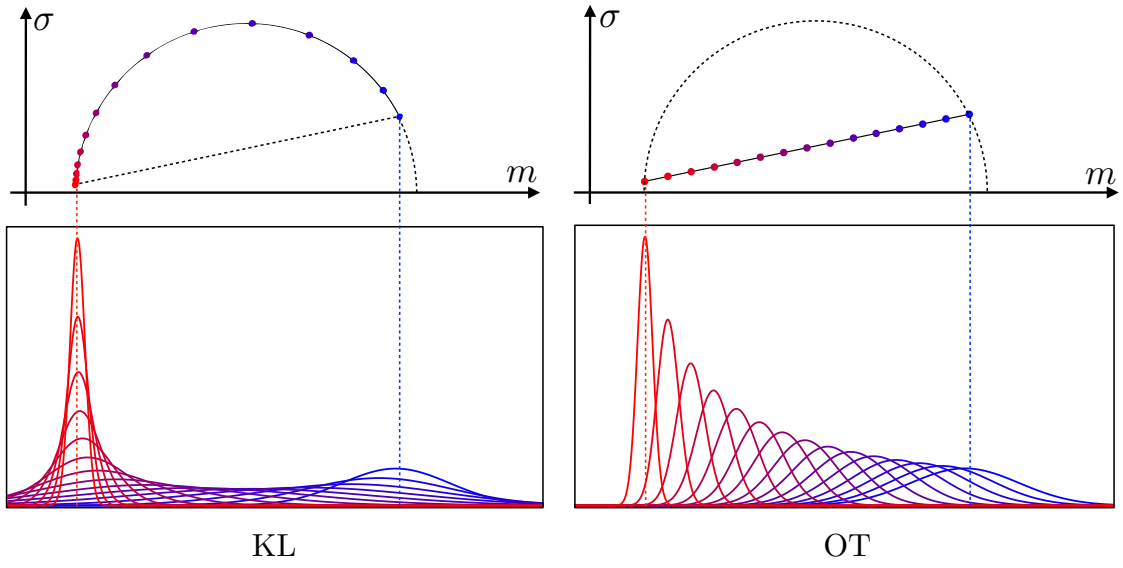

图 8.3: 利用 KL（双曲）与最优传输（欧氏）几何在 Gaussian 分布之间插值的比较.

例 8.1.2 (全变差). 全变差距离 $\mathrm{TV} \overset{\text{def.}}{=} \mathcal{D}_{\varphi_{\mathrm{TV}}}$ 是与下列函数对应的散度:

$$\varphi_{\mathrm{TV}}(s) = \begin{cases} |s-1| & \text{当} s \geq 0, \\ +\infty & \text{其他情形.} \end{cases} \tag{8.8}$$

它实际上在整个测度空间 $\mathcal{M}(\mathcal{X})$ 上定义范数，其中

$$\mathrm{TV}(\alpha|\beta) = \|\alpha-\beta\|_{\mathrm{TV}}, \quad \text{其中} \quad \|\alpha\|_{\mathrm{TV}} = |\alpha|(\mathcal{X}) = \int_{\mathcal{X}} \mathrm{d}|\alpha|(x). \tag{8.9}$$

若 α 在 $\mathcal{X} = \mathbb{R}^d$ 上具有密度 ρ_α，则 TV 范数就是函数的 L^1 范数，即 $\|\alpha\|_{\mathrm{TV}} = \int_{\mathcal{X}} |\rho_\alpha(x)| \mathrm{d}x = \|\rho_\alpha\|_{L^1}$. 若 α 如 (8.2) 那样离散，则 TV 范数是 $\mathbb{R}^n$ 中向量的 ℓ^1 范数，即 $\|\alpha\|_{\mathrm{TV}} = \sum_i |\mathbf{a}_i| = \|\mathbf{a}\|_{\ell^1}$. ◇

注 8.2 (强拓扑与弱拓扑). 全变差范数 (8.9) 定义了测度空间上所谓的“强”拓扑. 在半径为 R 的紧区域 $\mathcal{X}$ 上，有

$$\mathcal{W}_1(\alpha,\beta) \leq R\,\|\alpha-\beta\|_{\mathrm{TV}}$$

因此，这种强收敛蕴含由 Wasserstein 距离度量化的弱收敛. 反之则不成立，因为当 $x \to y$ 时，δ_x 并不强收敛到 δ_y (注意，若 $x \neq y$，则 $\|\delta_x - \delta_y\|_{\mathrm{TV}} = 2$). 一个主要优势是，$\mathcal{M}_+^1(\mathcal{X})$ (这里同样要求基础空间 $\mathcal{X}$ 紧) 在弱拓扑下为紧集，因此任意概率测度序列 $(\alpha_k)_k$ 都能抽取收敛子列，从而适合许多优化问题，例如第 9 章考虑的问题.

例 8.1.3 (Hellinger). Hellinger 距离 $\mathfrak{h} \overset{\text{def.}}{=} \mathcal{D}_{\varphi_H}^{1/2}$ 是与下列函数对应的散度的平方根:

$$\varphi_H(s) = \begin{cases} |\sqrt{s}-1|^2 & \text{当} s \geq 0, \\ +\infty & \text{其他情形.} \end{cases}$$

顾名思义，$\mathfrak{h}$ 是 $\mathcal{M}_+(\mathcal{X})$ 上的距离，与 $\|\cdot\|_{\mathrm{TV}}$ 一样度量化强拓扑. 若 (α,β) 在 $\mathcal{X} = \mathbb{R}^d$ 上具有密度 $(\rho_\alpha, \rho_\beta)$，则 $\mathfrak{h}(\alpha,\beta) = \|\sqrt{\rho_\alpha} - \sqrt{\rho_\beta}\|_{L^2}$. 若 (α,β) 如 (8.2) 那样离散，则 $\mathfrak{h}(\alpha,\beta) = \|\sqrt{\mathbf{a}} - \sqrt{\mathbf{b}}\|$. 考虑 $\varphi_{L^p}(s) = |s^{1/p}-1|^p$ 就推广了 Hellinger ($p=2$) 与全变差 ($p=1$) 距离，而 $\mathcal{D}_{\varphi_{L^p}}^{1/p}$ 是度量化强收敛的距离，其中 $0 < p < +\infty$. ◇

例 8.1.4 (Jensen–Shannon 距离). KL 散度不对称，虽然是 Bregman 散度 (局部为二次范数)，却不是距离的平方. 而 Jensen–Shannon 距离 $\mathrm{JS}(\alpha,\beta)$ 定义为

$$\mathrm{JS}(\alpha,\beta)^2 \overset{\text{def.}}{=} \frac{1}{2}\left(\mathrm{KL}(\alpha|\xi) + \mathrm{KL}(\beta|\xi)\right) \quad \text{其中} \quad \xi = \frac{\alpha+\beta}{2},$$

它是一个距离 (Endres and Schindelin, 2003; Österreicher and Vajda, 2003). 可以证明，JS^2 是与 $\varphi(s) = t\log(t) - (t+1)\log(t+1)$ 对应的 φ-散度. 与 KL 不同，$\mathrm{JS}(\alpha,\beta)$ 始终有界；更准确地说，$0 \leq \mathrm{JS}(\alpha,\beta)^2 \leq \ln(2)$. 与 TV 范数和 Hellinger 距离一样，它度量化强收敛. ◇

例 8.1.5 (χ^2). χ^2-散度 $\chi^2 \overset{\text{def.}}{=} \mathcal{D}_{\varphi_{\chi^2}}$ 是与下列函数对应的散度:

$$\varphi_{\chi^2}(s) = \begin{cases} |s-1|^2 & \text{当} s \geq 0, \\ +\infty & \text{其他情形.} \end{cases}$$

若 (α, β) 如 (8.2) 那样离散且具有相同支撑，则

$$\chi^2(\alpha|\beta) = \sum_i \frac{(\mathbf{a}_i - \mathbf{b}_i)^2}{\mathbf{b}_i}.$$

◇

8.2 积分概率度量

表述 (6.3) 是对偶范数的特殊情形. 对偶范数是构造可处理任意测度的 "弱" 范数的方便方式. 对于可测函数的对称凸集 B，定义

$$\|\alpha\|_B \overset{\text{def.}}{=} \max_f \left\{ \int_{\mathcal{X}} f(x) \mathrm{d}\alpha(x) \;:\; f \in B \right\}. \tag{8.10}$$

这些对偶范数常称为积分概率度量（integral probability metric）；见 (Sriperumbudur et al., 2012).

例 8.2.1 (全变差). 全变差范数（例 8.1.2）是与整个连续函数空间对应的对偶范数，其函数集合为

$$B = \{f \in \mathcal{C}(\mathcal{X}) \;:\; \|f\|_\infty \leq 1\}.$$

全变差距离是唯一同时为对偶范数的非平凡散度；见 (Sriperumbudur et al., 2009). ◇

注 8.3 (度量化弱收敛). 采用较小的 "球" B，通常仅含连续（有时还要求正则）的函数，就定义了更弱的对偶范数. 为了使 $\|\cdot\|_B$ 度量化弱收敛（见定义 2.2），一个充分条件是 B 张成的空间在连续函数集合中对于上确界范数 $\|\cdot\|_\infty$（即一致收敛拓扑）稠密；见 (Ambrosio et al., 2006, 第 5.1 段).

图 8.4 比较了多种对偶范数，下面逐一介绍.

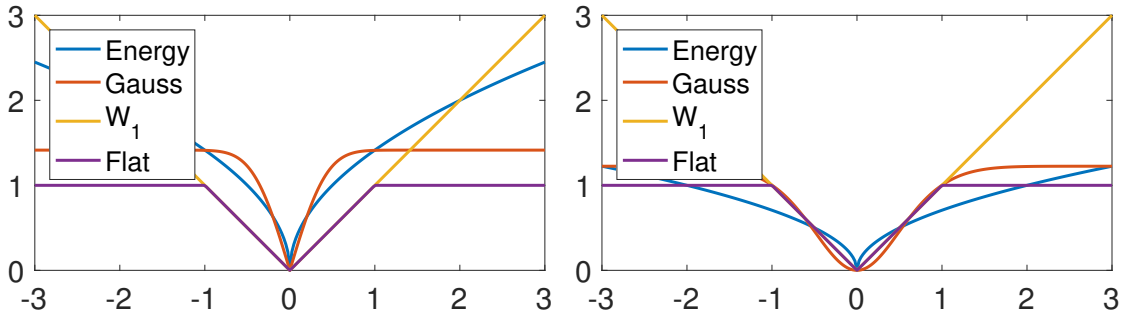

$(\alpha, \beta) = (\delta_0, \delta_t)$ $\qquad$ $(\alpha, \beta) = (\delta_0, \frac{1}{2}(\delta_{-t/2} + \delta_{t/2}))$

图 8.4: 对偶范数的比较.

8.2.1 $\mathcal{W}_1$ 与平坦范数

若集合 B 有界，则 $\|\cdot\|_B$ 是整个测度空间 $\mathcal{M}(\mathcal{X})$ 上的范数. $\mathcal{W}_1$ 并非如此，它只对满足 $\int_{\mathcal{X}} \mathrm{d}\alpha = 0$ 的 α 有定义（否则 $\|\alpha\|_B = +\infty$）. 给势 f 的值加上界可以缓解这一问题，例如据此定义平坦范数.

例 8.2.2 ($\mathcal{W}_1$ 范数). (6.3) 定义的 $\mathcal{W}_1$ 是对偶范数 (8.10) 的特殊情形，采用

$$B = \{f \ : \ \mathrm{Lip}(f) \leq 1\}$$

即 1-Lipschitz 函数集合. ◇

例 8.2.3 (平坦范数与 Dudley 度量). 平坦范数（flat norm）利用下列集合定义：

$$B = \{f \ : \ \|\nabla f\|_\infty \leq 1 \quad \text{且} \quad \|f\|_\infty \leq 1\}. \tag{8.11}$$

它在整个空间 $\mathcal{M}(\mathcal{X})$ 上度量化弱收敛. 只需加入约束 $|\mathbf{f}_k| \leq 1$，就可将公式 (6.2) 扩展到平坦范数的计算. 平坦范数有时称为 "Kantorovich–Rubinstein" 范数 (Hanin, 1992)，并曾用作成像逆问题的保真项 (Lellmann et al., 2014). 平坦范数类似于 Dudley 度量，后者采用

$$B = \{f \ : \ \|\nabla f\|_\infty + \|f\|_\infty \leq 1\}.$$

◇

8.2.2 对偶 RKHS 范数与最大均值差异

也可利用核方法在测度上定义 "欧氏" 范数（由二次泛函构造），特别是使用以下空间：

再生核 Hilbert 空间（reproducing kernel Hilbert space）(RKHS；数据科学应用的综述见 (Schölkopf and Smola, 2002)) . 首先回顾一些基本定义.

定义 8.3. 定义在集合 $\mathcal{X} \times \mathcal{X}$ 上的对称函数 k（分别为 φ）称为正定（分别为负定），如果对于任意 $n \geq 0$、点族 $x_1, \ldots, x_n \in \mathcal{Z}$ 和向量 $r \in \mathbb{R}^n$，下列不等式成立：

$$\sum_{i,j=1}^n r_i r_j k(x_i, x_j) \geq 0, \quad \left(\text{分别为} \quad \sum_{i,j=1}^n r_i r_j \varphi(x_i, x_j) \leq 0\right). \tag{8.12}$$

若 (8.12) 的正性仅对零均值向量 r（即 $\langle r, \mathbb{1}_n \rangle = 0$）成立，则称核为条件正定.

若 k 为条件正定，则定义范数

$$\|\alpha\|_k^2 \stackrel{\text{def.}}{=} \int_{\mathcal{X}\times\mathcal{X}} k(x,y) \mathrm{d}\alpha(x) \mathrm{d}\alpha(y). \tag{8.13}$$

这些范数常称为最大均值差异（maximum mean discrepancy）（MMD）（见 (Gretton et al., 2007)），在形状分析中也称为 "核范数" (Glaunes et al., 2004). 引入 $\mathcal{X}$ 上两个独立、分布为 α 的随机向量 (X, X')，就可以将 (8.13) 改写为

$$\|\alpha\|_k^2 = \mathbb{E}_{X,X'}(k(X, X')).$$

可以证明，$\|\cdot\|_k^2$ 是 (8.10) 意义下的对偶范数，对应于核 k 的 RKHS 单位球 B. RKHS 函数空间的更多细节见 (Berlinet and Thomas-Agnan, 2003; Hofmann et al., 2008; Schölkopf and Smola, 2002).

注 8.4 (万能核)**.** 根据注 8.3，若对偶球 B 的线性包在连续函数空间 $\mathcal{C}(\mathcal{X})$ 中稠密，则 MMD 范数 $\|\cdot\|_k$ 度量化弱收敛. 这意味着形如 $\sum_{i=1}^n a_i k(x_i,\cdot)$ 的有限和（任意 n 及点 $(x_i)_i$）对于一致范数 $\|\cdot\|_\infty$ 在 $\mathcal{C}(\mathcal{X})$ 中稠密. 对 $\mathcal{X}=\mathbb{R}^d$ 上的平移不变核 $k(x,y)=k_0(x-y)$，这等价于 Fourier 变换不消失，即 $\hat{k}_0(\omega)>0$.

特别地，若 α 为形如 (2.3) 的离散测度，则有简单表达式

$$\|\alpha\|_k^2=\sum_{i=1}^n\sum_{i'=1}^n \mathbf{a}_i\mathbf{a}_{i'}\mathbf{k}_{i,i'}=\langle \mathbf{k}\mathbf{a},\mathbf{a}\rangle \quad \text{其中} \quad \mathbf{k}_{i,i'}\overset{\text{def.}}{=}k(x_i,x_{i'}).$$

特别地，若 $\alpha=\sum_{i=1}^n \mathbf{a}_i\delta_{x_i}$ 与 $\beta=\sum_{i=1}^n \mathbf{b}_i\delta_{x_i}$ 支撑在同一组点上，则 $\|\alpha-\beta\|_k^2=\langle \mathbf{k}(\mathbf{a}-\mathbf{b}),\mathbf{a}-\mathbf{b}\rangle$，所以 $\|\cdot\|_k$ 是单纯形 Σ_n 上的欧氏范数（$\mathbf{k}$ 正定时为真正范数，半正定时退化）. 计算两个形如 (2.3) 的离散测度之间的差异，可以使用

$$\|\alpha-\beta\|_k^2=\sum_{i,i'}\mathbf{a}_i\mathbf{a}_{i'}k(x_i,x_{i'})+\sum_{j,j'}\mathbf{b}_j\mathbf{b}_{j'}k(y_j,y_{j'})-2\sum_{i,j}\mathbf{a}_i\mathbf{b}_j k(x_i,y_j). \tag{8.14}$$

例 8.2.4 (Gaussian RKHS)**.** 最常用的核之一是 Gaussian 核 $k(x,y)=e^{-\frac{\|x-y\|^2}{2\sigma^2}}$，它是 $\mathcal{X}=\mathbb{R}^d$ 上的正定万能核. Gaussian 核的一个优点是可分离为一维核的乘积，因此在规则网格上计算方便（另见注 4.17）. 然而，使用 Gaussian 核时必须选择带宽参数 σ，它应与待比较测度中观测之间的“典型尺度”吻合. 如果测度具有多尺度特征（有些区域非常密集，另一些区域非常稀疏），Gaussian 核就不太合适，应考虑下面介绍的“无尺度”核. 此类无尺度核的问题是具有全局性（以较慢的多项式速率衰减），通常计算成本更高，因为不能作紧支撑近似. 图 8.5 比较了多种核. ◇

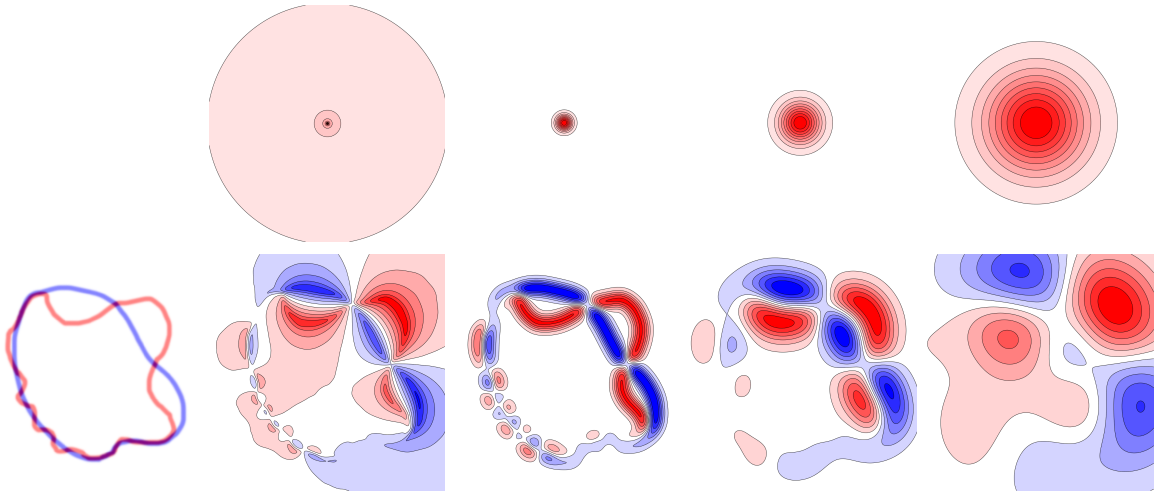

(α,β) $\quad$ $\mathrm{ED}(\mathbb{R}^2,\|\cdot\|)$ $\quad$ $(G,.005)$ $\quad$ $(G,.02)$ $\quad$ $(G,.05)$

图 8.5: 上排：展示满足 $\|\alpha-\beta\|_k=\|\psi\star(\alpha-\beta)\|_{L^2(\mathbb{R}^2)}$ 的 ψ，其形式 Fourier 定义为 $\hat{\psi}(\omega)=\sqrt{\hat{k}_0(\omega)}$，其中 $k(x,x')=k_0(x-x')$. 下排：展示 $\psi\star(\alpha-\beta)$. (G,σ) 表示方差为 σ^2 的 Gaussian 核. $\mathrm{ED}(\mathbb{R}^2,\|\cdot\|)$ 的核为 $\psi(x)=1/\sqrt{\|x\|}$.

例 8.2.5 ($H^{-1}(\mathbb{R}^d)$)**.** 另一个重要的对偶范数是 $H^{-1}(\mathbb{R}^d)$，它是导数属于 $L^2(\mathbb{R}^d)$ 的函数组成的 Sobolev 空间 $H^1(\mathbb{R}^d)$ 的对偶（在分布意义下）. 它由原始 RKHS 范数 $\|\nabla f\|^2_{L^2(\mathbb{R}^d)}$ 定义. 除非 $d=1$，否则它对奇异测度（例如 Dirac 质量）没有定义，因为 Sobolev 空间 $H^1(\mathbb{R}^d)$ 中的函数一般并不连续. 这个 H^{-1} 范数（定义在具有密度的零均值测度空间上）也可表达成散度形式：

$$\|\alpha-\beta\|^2_{H^{-1}(\mathbb{R}^d)} = \min_{s} \left\{ \int_{\mathbb{R}^d} \|s(x)\|_2^2 \,\mathrm{d}x \;:\; \operatorname{div}(s) = \alpha - \beta \right\}, \tag{8.15}$$

应将其与 (6.4) 对照：后者使用向量场 s 的 L^1 范数，而这里使用 L^2 范数. 这个 Sobolev 对偶范数的 “加权” 版本

$$\|\rho\|^2_{H^{-1}(\alpha)} = \min_{\operatorname{div}(s)=\rho} \int_{\mathbb{R}^d} \|s(x)\|_2^2 \,\mathrm{d}\alpha(x),$$

可以理解为 Wasserstein $\mathcal{W}_2$ 范数的自然 “线性化”，因为 Benamou–Brenier 动态表述的无穷小解释为

$$\mathcal{W}_2(\alpha, \alpha+\varepsilon\rho) = \varepsilon \|\rho\|_{H^{-1}(\alpha)} + o(\varepsilon). \tag{8.16}$$

可证明泛函 $\mathcal{W}_2(\alpha,\beta)$ 与 $\|\alpha-\beta\|_{H^{-1}(\alpha)}$ 等价 (Peyre, 2011). 问题在于 $\|\alpha-\beta\|_{H^{-1}(\alpha)}$ 不是范数（因为它以 α 加权），一般不能用 $\|\alpha-\beta\|_{H^{-1}(\mathbb{R}^d)}$ 替代，除非 (α,β) 具有密度. 在后一情形中，若 α 和 β 在相同支撑上具有密度，且密度下界为 $a>0$、上界为 $b<+\infty$，则

$$b^{-1/2}\|\alpha-\beta\|_{H^{-1}(\mathbb{R}^d)} \le W_2(\alpha,\beta) \le a^{-1/2}\|\alpha-\beta\|_{H^{-1}(\mathbb{R}^d)}; \tag{8.17}$$

见 (Santambrogio, 2015, 定理 5.34)；精确常数见 (Peyre, 2011). ◇

例 8.2.6 (负指标 Sobolev 空间)**.** 考虑任意负指标的 Sobolev 空间 $H^{-r}(\mathbb{R}^d)$，就可推广这一构造；它是具有 r 阶导数（分布意义下）且导数属于 $L^2(\mathbb{R}^d)$ 的函数组成的 Sobolev 空间 $H^r(\mathbb{R}^d)$ 的对偶. 为度量化弱收敛，需要 $H^r(\mathbb{R}^d)$ 中的函数连续；当 $r>d/2$ 时满足这一条件. 因此随着维数 d 增加，需要更高的正则性. 对于任意 α（不必为整数），这些空间通过 Fourier 变换定义. 若测度 α 的 Fourier 变换为 $\hat{\alpha}(\omega)$（这里将其写为相对于 Lebesgue 测度 $\mathrm{d}\omega$ 的密度），则

$$\|\alpha\|^2_{H^{-r}(\mathbb{R}^d)} \overset{\text{def.}}{=} \int_{\mathbb{R}^d} \|\omega\|^{-2r} |\hat{\alpha}(\omega)|^2 \mathrm{d}\omega.$$

这对应于卷积核 $k(x,y)=k_0(x-y)$、$\hat{k}_0(\omega) = \pm\|\omega\|^{-2r}$ 所定义的对偶 RKHS 范数. 取逆 Fourier 变换可知，忽略常数后有

$$\forall\, x\in\mathbb{R}^d, \quad k_0(x) = \begin{cases} \frac{1}{\|x\|^{d-2r}} & \text{若} \quad r<d/2, \\ -\|x\|^{2r-d} & \text{若} \quad r>d/2. \end{cases} \tag{8.18}$$

◇

例 8.2.7 (能量距离). 与距离 d 对应的能量距离 (energy distance) ($d=1$ 时也称 Cramer 距离) (Székely and Rizzo, 2004) 定义为

$$\|\alpha-\beta\|_{\mathrm{ED}(\mathcal{X},d^p)} \overset{\text{def.}}{=} \|\alpha-\beta\|_{k_{\mathrm{ED}}} \quad \text{其中} \quad k_{\mathrm{ED}}(x,y) = -d(x,y)^p \tag{8.19}$$

其中 $0<p<2$. 若 d 负定 (见定义 8.3), 它就是测度上的有效 MMD 范数; 一个典型例子是欧氏距离 $d(x,y)=\|x-y\|$. 当 $\mathcal{X}=\mathbb{R}^d$、$d(x,y)=\|\cdot\|$ 时, 利用 (8.18) 可知, 能量距离是 Sobolev 范数

$$\|\cdot\|_{\mathrm{ED}(\mathbb{R}^d,\|\cdot\|^p)} = \|\cdot\|_{H^{-\frac{d+p}{2}}(\mathbb{R}^d)}.$$

与 Gaussian 核 (例 8.2.4) 等常见核相比, 能量距离的主要优势是无尺度性, 不依赖带宽参数 σ. 更准确地说, 在 $\mathcal{X}=\mathbb{R}^d$ 上, 将比例为 $s>0$ 的伸缩记为 $f_s(x)=sx$, 则有下列缩放规律:

$$\|f_{s\sharp}(\alpha-\beta)\|_{\mathrm{ED}(\mathbb{R}^d,\|\cdot\|^p)} = s^{\frac{p}{2}}\|\alpha-\beta\|_{\mathrm{ED}(\mathbb{R}^d,\|\cdot\|^p)},$$

而 Wasserstein 距离具有完全线性的缩放规律:

$$\mathcal{W}_p(f_{s\sharp}\alpha, f_{s\sharp}\beta)) = s\,\mathcal{W}_p(\alpha,\beta)).$$

但要注意, 能量距离的参数 p 必须满足 $0<p<2$; 当 $p=2$ 时, 它退化为均值之间的距离

$$\|\alpha-\beta\|_{\mathrm{ED}(\mathbb{R}^d,\|\cdot\|^2)} = \left\|\int_{\mathbb{R}^d} x(\mathrm{d}\alpha(x)-\mathrm{d}\beta(x))\right\|,$$

因此不再是范数. 这说明, 能量距离不可能在 $f_{s\sharp}$ 下具有与 Wasserstein 距离相同的线性缩放规律. ◇

8.3 Wasserstein 空间并非 Hilbert 型

前面第 2.6 节列举的 Wasserstein 几何特殊情形表明, 最优传输距离有时可用闭式公式计算. 它们也说明, 在这些情形中, 最优传输距离是概率测度之间的 *Hilbert* 型度量, 即存在从输入测度空间到 Hilbert 空间的映射 ϕ, 具体定义如下.

定义 8.4. 定义在集合 $\mathcal{Z}\times\mathcal{Z}$ 上的距离 d 称为Hilbert 型距离 (Hilbertian distance), 如果存在 Hilbert 空间 $\mathcal{H}$ 与映射 $\phi:\mathcal{Z}\to\mathcal{H}$, 使得对于 $\mathcal{Z}$ 中任意 z,z' 都有 $d(z,z')=\|\phi(z)-\phi(z')\|_{\mathcal{H}}$.

例如, 注 2.30 表明, 只需将 ϕ 定义为把测度映到其广义分位数函数的映射, Wasserstein 度量就是单变量分布之间的 Hilbert 范数. 注 2.31 说明, 对于单变量 Gaussian 分布, 正如本章 (8.7) 所示, Wasserstein 距离就是均值与标准差之间的欧氏距离.

Hilbert 型距离用于数据分析时具有许多良好性质 (Dattorro, 2017). 首先, 它们很容易构造成径向基函数核: 对于任意 Hilbert 型距离 d, $e^{-d^p/t}$ 在任意 $0\le p\le 2$ 及正数 t 下都是正定核, 证明见 (Berg et al., 1984, 推论 3.3.3, 命题 3.2.7). Gaussian

($p=2$) 与 Laplace ($p=1$) 核就是将通常欧氏距离代入这一结果的简单应用. 核方法领域 (Hofmann et al., 2008) 以核函数的正定性为基础，定义作用于正定核矩阵的凸学习算法. 利用多维尺度分析 (Borg and Groenen, 2005) 等简单方法，Hilbert 空间中的点也可以高效地以较低失真嵌入低维空间 (Johnson and Lindenstrauss, 1984)， (Barvinok, 2002, 第 V.6.2 节).

因为 Hilbert 型距离具有这些性质，人们可能希望 Wasserstein 距离在比上述情形更一般的设定中仍然为 Hilbert 型，特别是在 $\mathcal{X}$ 的维数不小于 2 时. 以下等价关系可以否定这一猜想.

命题 8.1. *距离 d 为 Hilbert 型，当且仅当 d^2 负定.*

证明： 若距离为 Hilbert 型，则 d^2 显然负定. 事实上，给定 $\mathcal{Z}$ 中 n 个点，和式 $\sum r_i r_j d^2(z_i, z_j)$ 可改写成

$$\sum r_i r_j \|\phi(z_i) - \phi(z_j)\|_{\mathcal{H}}^2.$$

利用 $\sum r_i = 0$ 展开，得到

$$-2\sum r_i r_j \langle \phi(z_i), \phi(z_j)\rangle_{\mathcal{H}},$$

由 Hilbert 内积的定义它非正. 反之，若 d^2 负定，则由 Schoenberg (1938) 的关键结果可知 d 为 Hilbert 型，该结果概述于 (Berg et al., 1984, 第 82 页，命题 3.2). □

因此，为证明 Wasserstein 距离并非 Hilbert 型，只需说明其平方不负定，如下列命题所述.

命题 8.2. *若 $\mathcal{X} = \mathbb{R}^d$、$d \geq 2$，且基础代价为 $d(x,y) = \|x-y\|_2$，则 $p = 1, 2$ 时的 p-Wasserstein 距离不是 Hilbert 型.*

证明： 只需证明 $d = 2$ 时的结论，因为二维反例也是所有更高维中的反例. 给出一个非随机反例，使用支撑在四个向量 $x^1, x^2, x^3, x^4 \in \mathbb{R}^2$ 上的测度，其中 $x^1 = [0,0], x^2 = [1,0], x^3 = [0,1], x^4 = [1,1]$. 考虑四维概率单纯形上间隔为 $1/4$ 的规则网格中的全部点. 单纯形中有 $35 = \left(\!\binom{4}{4}\!\right) = \binom{4+4-1}{4}$ 个这样的点. 网格中的每个概率向量 $\mathbf{a}^i$ 都满足：对于 $j \leq 4$，$\mathbf{a}^i_j$ 属于 $\{0, \frac{1}{4}, \frac{1}{2}, \frac{3}{4}, 1\}$，且 $\sum_{j=1}^4 \mathbf{a}^i_j = 1$. 给定 p，可计算这些直方图之间的 35×35 两两 Wasserstein 距离矩阵 $\mathbf{D}_p$. $\mathbf{D}_p$ 不负定，当且仅当其逐元素平方 $\mathbf{D}_p^2$ 满足 $\mathbf{J}\mathbf{D}_p^2\mathbf{J}$ 具有正特征值，其中 $\mathbf{J}$ 为中心化矩阵 $\mathbf{J} = \mathbb{I}_n - \frac{1}{n}\mathbb{1}_{n,n}$；图 8.6 展示的正是这一情形. □

8.3.1 嵌入与失真

大量重要工作量化了利用 Hilbert 型嵌入近似 Wasserstein 距离的困难程度. 已有结果表明，当 $\mathcal{X} = \mathbb{R}^d$ 且 $d \geq 2$ 时，将测度嵌入 ℓ_2 空间必然引入显著失真 Naor and Schechtman (2007); Andoni et al. (2018).

可以将 $0 < p \leq 1$ 的 p-Wasserstein 空间拟等距嵌入 ℓ_1（见 (Indyk and Thaper, 2003; Andoni et al., 2008; Do Ba et al., 2011)），但距离之间的等价常数随维数 d 快速增长. 还要注意，$p = 1$ 时，这种嵌入仅对离散测度成立（即嵌入常数依赖于质量尖峰

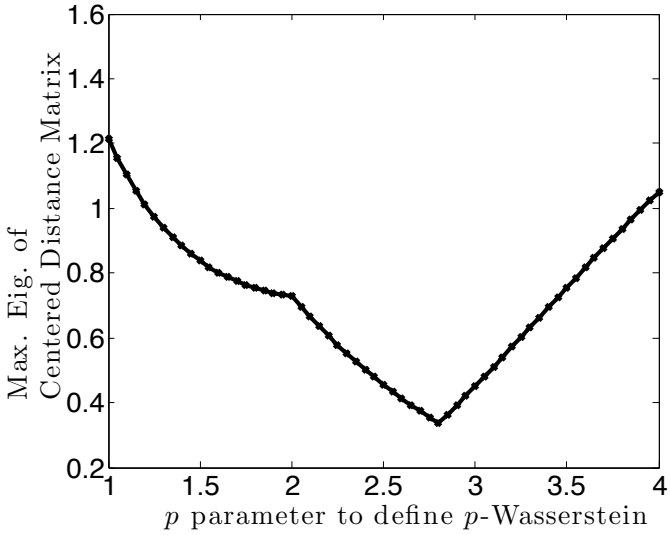

图 8.6: 可以通过一组点的两两平方距离矩阵 $\mathbf{D}_p^2$ 所对应的中心化矩阵 $\mathbf{J}\mathbf{D}_p^2\mathbf{J}$ 的谱，说明某距离不是 Hilbert 型. 若距离为 Hilbert 型，该矩阵的谱必定非正. 这里对命题 8.2 证明中选取的点，绘出该矩阵的最大特征值，考察不同的 p. 所得特征值全部为正，说明这些 p 值对应的 p-Wasserstein 距离均不是 Hilbert 型.

之间的最小距离）. 一种紧密相关的嵌入技术，是利用 $\mathcal{W}_1$ 为 Lipschitz 函数 f 的对偶这一刻画（见第 6.2 节），以小波系数上的加权 ℓ_1 球近似 Lipschitz 约束 $\|\nabla f\|_1 \leq 1$; 见 (Shirdhonkar and Jacobs, 2008). 这个小波系数的加权 ℓ_1 球定义了所谓的负指标 Besov 空间 (Leeb and Coifman, 2016). 这些嵌入结果也类似于利用二进划分得到的 Wasserstein 距离界；见 (Weed and Bach, 2017, 命题 1)，另见 (Fournier and Guillin, 2015). 这还给出了 ℓ_1 中的拟等距嵌入（由重新缩放的小波系数给出），其优势是，当输入测度在均匀网格上离散时，可以在线性时间内近似计算这个嵌入. 小波的更多细节见 (Mallat, 2008). 利用多尺度嵌入计算类似 Wasserstein 距离的思想，在计算机视觉中已有广泛应用；例如见 (Ling and Okada, 2006; Grauman and Darrell, 2005; Cuturi and Fukumizu, 2007; Lazebnik et al., 2006).

8.3.2 最优传输的负定与正定变体

后文第 10.4 节将说明，Wasserstein 距离的*切片*近似，本质上是在随机投影到直线的测度推前上计算的一维方向传输距离之和，作为负定函数之和是负定的 (Berg et al., 1984, 第 3.1.11 节). 这一结果可用来定义正定核 (Kolouri et al., 2016). 另一种恢复正定核的方法，是将最优传输写成对所有可能传输表的软极小值，而非极小值； Kosowsky and Yuille (1994) 提出这一方法以引入熵正则化. 这个软极小值所定义的量的负指数（也称生成函数）为正定核 (Cuturi, 2012).

8.4 最优传输、MMD 与 φ-散度的经验估计量

在应用中，给定两个输入测度 $(\alpha,\beta)\in\mathcal{M}_+^1(\mathcal{X})^2$，一个重要统计问题是，仅利用从 α 抽取的样本 $(x_i)_{i=1}^n$ 及从 β 抽取的样本 $(y_j)_{j=1}^m$，近似通常未知的散度 $D(\alpha,\beta)$. 假设样本来自各自分布，且独立同分布.

8.4.1 最优传输与 MMD 的经验估计量

对于 Wasserstein 距离 $\mathcal{W}_p$（见 2.18）与 MMD 范数（见第 8.2 节），估计未知分布距离的直接办法是在经验测度之间计算该距离，并希望能控制后者收敛到前者的速率：

$$D(\alpha,\beta)\approx D(\hat\alpha_n,\hat\beta_m)\quad\text{其中}\quad\begin{cases}\hat\alpha_n\overset{\text{def.}}{=}\frac{1}{n}\sum_i\delta_{x_i},\\ \hat\beta_m\overset{\text{def.}}{=}\frac{1}{m}\sum_j\delta_{y_j}.\end{cases}$$

注意，$\hat\alpha_n$ 和 $\hat\beta_m$ 都是随机测度，因此 $D(\hat\alpha_n,\hat\beta_m)$ 是随机数. 为简单起见，假设 $\mathcal{X}$ 紧（处理无界区域需要对输入测度的矩施加额外约束）.

对于度量化弱收敛(见定义 2.2)的这类对偶距离，由于 $\hat\alpha_n\to\alpha$ 弱收敛，当 $n\to+\infty$ 时，有 $D(\hat\alpha_n,\hat\beta_n)\to D(\alpha,\beta)$. 但重要的问题是 $D(\hat\alpha_n,\hat\beta_n)$ 收敛到 $D(\alpha,\beta)$ 的速度，这一速率常称为 D 的样本复杂度（sample complexity）.

注意，对于 $D(\alpha,\beta)=\|\cdot\|_{\mathrm{TV}}$，由于 TV 范数不度量化弱收敛，$\|\hat\alpha_n-\hat\beta_n\|_{\mathrm{TV}}$ 不是一致估计量，即不收敛到 $\|\alpha-\beta\|_{\mathrm{TV}}$. 事实上，因为两个离散测度的支撑不相交，以概率 1 有 $\|\hat\alpha_n-\hat\beta_n\|_{\mathrm{TV}}=2$. 其他 φ-散度也存在类似问题，不能通过经验分布之间的散度估计.

最优传输的速率. 对于 $\mathcal{X}=\mathbb{R}^d$ 以及支撑在有界区域上的测度，(Dudley, 1969) 证明，当 $d>2$ 且 $1\le p<+\infty$ 时，

$$\mathbb{E}(|\,\mathcal{W}_p(\hat\alpha_n,\hat\beta_n)-\mathcal{W}_p(\alpha,\beta)|)=O(n^{-\frac{1}{d}}),$$

其中期望 $\mathbb{E}$ 关于随机样本 $(x_i,y_i)_i$ 计算. 若两个测度之一具有关于 Lebesgue 测度的密度，则这个速率在 $\mathbb{R}^d$ 中是紧的. (Dudley, 1969) 利用覆盖数概念在一般度量空间中证明了这一结果，后来又得到细化，特别是 $\mathcal{X}=\mathbb{R}^d$ 的情形，见 (Dereich et al., 2013; Fournier and Guillin, 2015). 当测度支撑在低维子区域时，可以细化这一速率： Weed and Bach (2017) 证明，速率实际上依赖于支撑的内蕴维数. Weed and Bach 也研究了收敛的非渐近行为，例如可由离散测度近似的分布（如小方差 Gaussian 混合）. 还可以证明 $\mathcal{W}_p(\hat\alpha_n,\hat\beta_n)$ 在其均值 $\mathcal{W}_p(\alpha,\beta)$ 附近的集中性；见 (Bolley et al., 2007; Boissard, 2011; Weed and Bach, 2017).

MMD 的速率. 对于 (8.13) 定义的 RKHS 范数对偶弱范数 $\|\cdot\|_k^2$（也称 MMD），与 Wasserstein 距离不同，其样本复杂度不依赖于环境维数：

$$\mathbb{E}(|\|\hat\alpha_n-\hat\beta_n\|_k-\|\alpha-\beta\|_k|)=O(n^{-\frac{1}{2}});$$

见 (Sriperumbudur et al., 2012). 图 8.7 数值比较了 Wasserstein 与 MMD 距离的样本复杂度速率. 但要注意，$\|\hat{\alpha}_n - \hat{\beta}_n\|_k^2$ 是 $\|\alpha - \beta\|_k^2$ 的略有偏估计. 为得到无偏估计量，从而能够例如用 SGD 极小化这些损失，应改用无偏估计量

$$\mathrm{MMD}_k(\hat{\alpha}_n, \hat{\beta}_n)^2 \overset{\text{def.}}{=} \frac{1}{n(n-1)} \sum_{i,i'} k(x_i, x_{i'}) + \frac{1}{n(n-1)} \sum_{j,j'} k(y_j, y_{j'}) - 2\frac{1}{n^2} \sum_{i,j} k(x_i, y_j),$$

应将其与 (8.14) 比较. 它满足 $\mathbb{E}(\mathrm{MMD}_k(\hat{\alpha}_n, \hat{\beta}_n)^2) = \|\alpha - \beta\|_k^2$; 见 (Gretton et al., 2012).

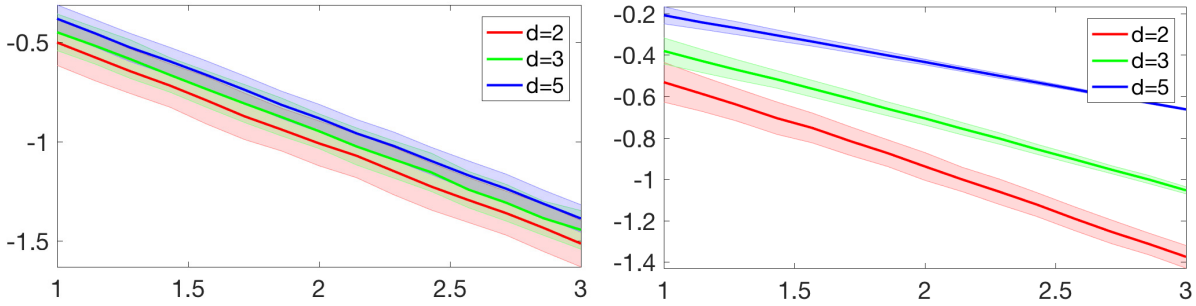

能量距离 $\|\cdot\|_{H^{-1}}$ $\mathcal{W}_2$

图 8.7: $\log_{10}(D(\hat{\alpha}_n, \hat{\alpha}'_n))$ 随 $\log_{10}(n)$ 的衰减，左图 D 为例 8.2.7 定义的能量距离 $D = \|\cdot\|_{H^{-1}}$ (即 H^{-1} 范数)，右图为 Wasserstein 距离 $D = \mathcal{W}_2$. 这里 $(\hat{\alpha}_n, \hat{\alpha}'_n)$ 是 α 的两个独立经验分布，α 为单位立方体 $[0,1]^d$ 上的均匀分布，考察了 $d \in \{2,3,5\}$ 的多个值. 阴影带给出 $\log(D(\hat{\alpha}_n, \alpha))$ 的正负一个标准差范围的置信区间.

8.4.2 φ-散度的经验估计量

不能用 $\mathcal{D}_\varphi(\hat{\alpha}_n|\hat{\beta}_n)$ 从离散样本近似 (8.2) 定义的 $\mathcal{D}_\varphi(\alpha|\beta)$. 事实上，这个量要么为 $+\infty$ (例如 KL 散度)，要么在 $n \to +\infty$ 时不收敛到 $\mathcal{D}_\varphi(\alpha|\beta)$ (例如 TV 范数). 因此需要密度估计量，以某种方式平滑离散经验测度，将其替换为密度；见 (Silverman, 1986). 在欧氏空间 $\mathcal{X} = \mathbb{R}^d$ 中，用光滑窗函数与带宽 $\sigma > 0$ 定义 $h_\sigma = h(\cdot/\sigma)$，则通过与该核卷积定义 α 的密度估计量:

$$\hat{\alpha}_n \star h_\sigma = \frac{1}{n} \sum_i h_\sigma(\cdot - x_i). \tag{8.20}$$

随后可以按下式近似 φ-散度:

$$\mathcal{D}_\varphi^\sigma(\hat{\alpha}_n|\hat{\beta}_n) \overset{\text{def.}}{=} \frac{1}{n} \sum_{j=1}^n \varphi\left(\frac{\sum_i h_\sigma(y_j - x_i)}{\sum_{j'} h_\sigma(y_j - y_{j'}),}\right)$$

其中 σ 应与样本数 n 和维数 d 相适应. 也可以设计非参数估计量，不选择固定带宽 σ，而选择近邻数 k. 这些方法通常利用近邻之间的距离 (Loftsgaarden and Quesenberry,

1965)，类似于根据局部采样密度局部调整带宽 σ. 记 $\Delta_k(x)$ 为 $x \in \mathbb{R}^d$ 与 $(x_i)_{i=1}^n$ 中第 k 个最近邻之间的距离，则密度估计量定义为

$$\rho^k_{\hat{\alpha}_n}(x) \stackrel{\text{def.}}{=} \frac{k/n}{|B_d|\Delta_k(x)^r}, \tag{8.21}$$

其中 $|B_d|$ 是 $\mathbb{R}^d$ 中单位球的体积. 与 (8.20) 中 "计数" 落入宽度为 σ 的区域的样本数不同，公式 (8.21) 估计包含 k 个样本所需的半径. 图 8.8 比较了估计量 (8.20) 和 (8.21). 典型应用是 (4.1) 中详述的熵泛函，它是关于 Lebesgue 测度的 KL 散度. 更多细节见 (Moon and Hero, 2014).

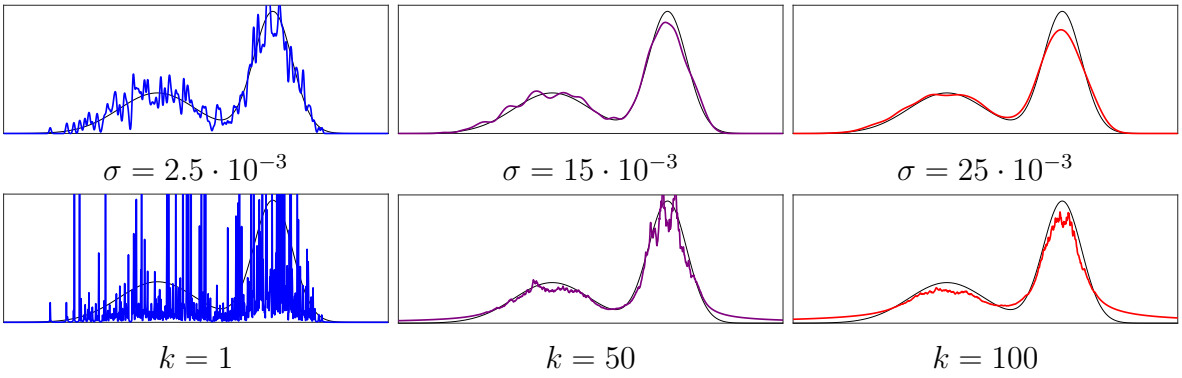

图 8.8: 从两个 Gaussian 分布的混合中抽取 $n = 200$ 个样本，比较核密度估计 $\hat{\alpha}_n \star h_\sigma$（上排，采用 Gaussian 核 h）与 k-近邻估计 $\rho^k_{\hat{\alpha}_n}$（下排）.

8.5 熵正则化：最优传输与 MMD 之间

按照命题 4.7，回顾 Sinkhorn 散度的定义

$$\mathfrak{P}^\varepsilon_{\mathbf{C}}(\mathbf{a}, \mathbf{b}) \stackrel{\text{def.}}{=} \langle \mathbf{P}^\star, \mathbf{C} \rangle = \langle e^{\frac{\mathbf{f}^\star}{\varepsilon}}, (\mathbf{K} \odot \mathbf{C}) e^{\frac{\mathbf{g}^\star}{\varepsilon}} \rangle,$$

其中 $\mathbf{P}^\star$ 是 (4.2) 的解，而 $(\mathbf{f}^\star, \mathbf{g}^\star)$ 是 (4.30) 的解. 假设 $\mathbf{C}_{i,j} = d(x_i, x_j)^p$，其中 d 是 $\mathcal{X}$ 上的某个距离，则对于两个形如 (2.3) 的离散概率分布，这定义了正则化 Wasserstein 代价

$$\mathcal{W}_{p,\varepsilon}(\alpha, \beta)^p \stackrel{\text{def.}}{=} \mathfrak{P}^\varepsilon_{\mathbf{C}}(\mathbf{a}, \mathbf{b}).$$

这一定义推广到任意输入分布（不必离散）为

$$\mathcal{W}_{p,\varepsilon}(\alpha, \beta)^p \stackrel{\text{def.}}{=} \int_{\mathcal{X}\times\mathcal{X}} d(x,y)^p \mathrm{d}\pi^\star(x,y),$$

其中 $\pi^\star$ 为 (4.9) 的解.

为了消除正则化引入的偏差（特别是 $\mathcal{W}_{p,\varepsilon}(\alpha, \alpha) \neq 0$），引入修正的正则化散度

$$\tilde{\mathcal{W}}_{p,\varepsilon}(\alpha, \beta)^p \stackrel{\text{def.}}{=} 2\,\mathcal{W}_{p,\varepsilon}(\alpha, \beta)^p - \mathcal{W}_{p,\varepsilon}(\alpha, \alpha)^p - \mathcal{W}_{p,\varepsilon}(\beta, \beta)^p.$$

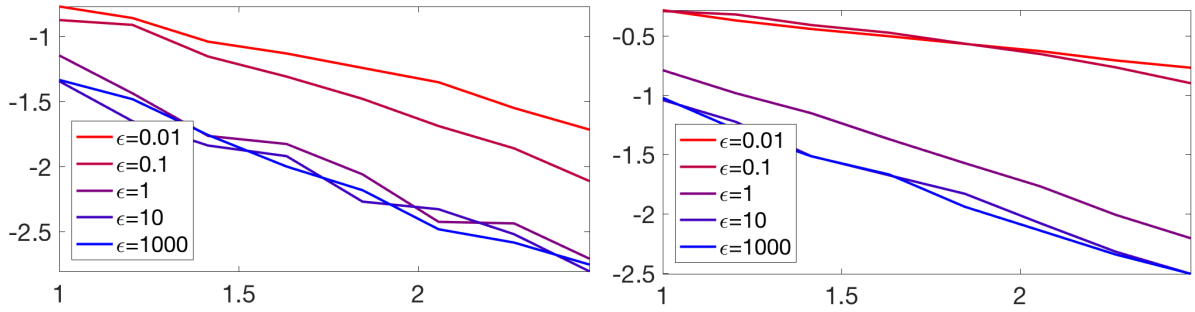

$d = 2$ $d = 5$

图 8.9: 在 $p = 3/2$、不同 ε 下，$\mathbb{E}(\log_{10}(\tilde{\mathcal{W}}_{p,\varepsilon}(\hat{\alpha}_n, \hat{\alpha}'_n)))$ 随 $\log_{10}(n)$ 的衰减，其中 α 与图 8.7 相同.

(Feydy et al., 2019) 证明，若 $e^{-c/\varepsilon}$ 为正定核，则一个相关的修正散度为正（将 $\mathfrak{P}_{\mathrm{C}}^{\varepsilon}$ 换成 $\mathrm{L}_{\mathrm{C}}^{\varepsilon}$ 后得到）. 也可定义其他基于正则化最优传输的重新归一化方法，例如 Amari et al. (2018) 提出的方案.

下列命题的证明见 (Ramdas et al., 2017)；它表明，这个正则化散度在 Wasserstein 距离与例 8.2.7 定义的能量距离之间插值.

命题 8.3. 有

$$\tilde{\mathcal{W}}_{p,\varepsilon}(\alpha,\beta) \xrightarrow{\varepsilon\to 0} 2\,\mathcal{W}_p(\alpha,\beta) \quad \text{且} \quad \tilde{\mathcal{W}}_{p,\varepsilon}(\alpha,\beta)^p \xrightarrow{\varepsilon\to+\infty} \|\alpha-\beta\|^2_{\mathrm{ED}(\mathcal{X},d)},$$

其中 $\|\cdot\|_{\mathrm{ED}(\mathcal{X},d)}$ 定义于 (8.19).

图 8.9 数值展示了 ε 对样本复杂度速率的影响. Genevay et al. (2019) 证明，在 $\mathcal{X} = \mathbb{R}^d$、$c(x,y) = \|x-y\|^2$ 时，这些速率在最优传输与 MMD 的速率之间插值.

Chapter 9

Wasserstein 变分问题

在数据分析中，概率测度之间的常见散度（如欧氏、全变差、Hellinger、Kullback–Leibler 散度）常用于度量参数估计问题中的拟合误差或损失. 在前面各章中，我们已经说明，最优传输几何具有其他信息散度所不具备的独特能力：借助物理思想（质量位移）和几何（观测值或区间之间的基础费用）比较测度. 结合这两点，很自然会想到以 Wasserstein 距离作为损失函数. 最近，这一思想已在多种应用问题中得到探索. 其主要技术挑战在于高效近似 Wasserstein 距离并求导. 本章先介绍若干动机性示例，再说明如何用本书前几章的不同数值格式求解 Wasserstein 变分问题.

在图像处理中，可以将 Wasserstein 距离用作纹理合成的损失 (Tartavel et al., 2016)，度量合成样例与输入样例统计量之间的差异. 它也用于图像分割，刻画图像区域的统计同质性 (Swoboda and Schnörr, 2013; Rabin and Papadakis, 2015; Peyré et al., 2012; Ni et al., 2009; Schmitzer and Schnörr, 2013b; Li et al., 2018b).

当观测量是概率测度时，Wasserstein 距离也是逆问题中十分自然的保真项，例如图像恢复 (Lellmann et al., 2014)、层析反演 (Abraham et al., 2017)、密度正则化 (Burger et al., 2012)、粒子图像测速 (Saumier et al., 2015)、稀疏恢复与压缩感知 (Indyk and Price, 2011) 以及地震反演 (Métivier et al., 2016).

在计算解剖学中，测度之间的距离（主要基于核，见第 8.2.2 节）经常用于形状匹配；形状表示为提升空间上的测度，通常称为流 (Vaillant and Glaunès, 2005). OT 距离提供了一种有趣的替代方案 (Feydy et al., 2017).

为降低直方图数据集的维数，Lee and Seung 说明，可用 Kullback–Leibler 散度量化重构损失，从而表述非负矩阵分解问题 (Lee and Seung, 1999). 若已知这些直方图区间的几何先验信息，则可改用 Wasserstein 距离，所得结果显著不同 (Sandler and Lindenbaum, 2011; Zen et al., 2014; Rolet et al., 2016).

所有这些问题的共同点是需要 Wasserstein 距离的梯度或其近似. 本节先介绍近似这些梯度的方法，随后给出三个可表述为 Wasserstein 变分问题的重要应用.

9.1 Wasserstein 损失的求导

在统计、文本处理或成像中，通常须将观测产生的概率分布 β 与模型比较，即与参数化分布族 $\{\alpha_\theta, \theta \in \Theta\}$ 比较，其中 Θ 是欧氏空间的一个子集. 这种比较通过 “损失” 或 “保真” 项进行，本节采用 Wasserstein 距离.

最简单的情形是直接最小化以下目标以求适当参数 θ：

$$\min_{\theta \in \Theta} \mathcal{E}(\theta) \stackrel{\text{def.}}{=} \mathcal{L}_c(\alpha_\theta, \beta). \tag{9.1}$$

当然，也可考虑更复杂的问题，例如第 9.2 节的重心问题由若干此类项之和组成. 不过，

通常可调整上述基本情形的工具来求解更复杂的问题：用链式法则显式计算导数，或采用第 9.1.3 节倡导的自动微分.

凸性. 由式 (2.20) 与 (2.24) 分别可见，两个直方图或两个密度之间的 Wasserstein 距离关于两个输入是凸的. 因此，若参数 θ 本身是直方图，即 $\Theta = \Sigma_n$、$\alpha_\theta = \theta$，或更一般地，θ 描述单纯形中的 K 个权重，$\Theta = \Sigma_K$，而 $\alpha_\theta = \sum_{i=1}^K \theta_i \alpha_i$ 是 Σ_N 中已知原子 $\alpha_1, \dots, \alpha_K$ 的凸组合，则问题 (9.1) 仍为凸问题. 第一种情形对应重心问题，第二种对应使用 Wasserstein 损失的字典学习问题的一次迭代 (Rolet et al., 2016). 但对更一般的参数化 $\theta \mapsto \alpha_\theta$，问题 (9.1) 一般不是凸的.

简单情形. 当 Wasserstein 距离有闭式表达时，例如单变量分布（见注 2.30）或椭圆轮廓分布（见注 2.31），可采用简单的变通方法：主要是将 Wasserstein 距离化为分布适当表示之间的较简单距离，再直接在这些表示上求解问题 (9.1). 对单变量测度，它是分位数函数之间的欧氏距离；对同族椭圆轮廓分布，它是协方差矩阵之间的 Bures 度量.

然而，多数情况下须仔细离散化 α_θ，以计算问题 (9.1) 的局部极小点. 可考虑 Euler 型和 Lagrange 型两种方法. 图 9.1 展示这两种基本离散格式的差别. 尽管这种说法可能过于简化，但可以说：当测度支撑在低维空间上（如形状或颜色空间），或问题本身离散（如字符串或文本分析）时，Euler 型离散最合适. 当拟合问题的观测可在高维空间中连续取值时，Lagrange 型观点通常是唯一适当的选择.

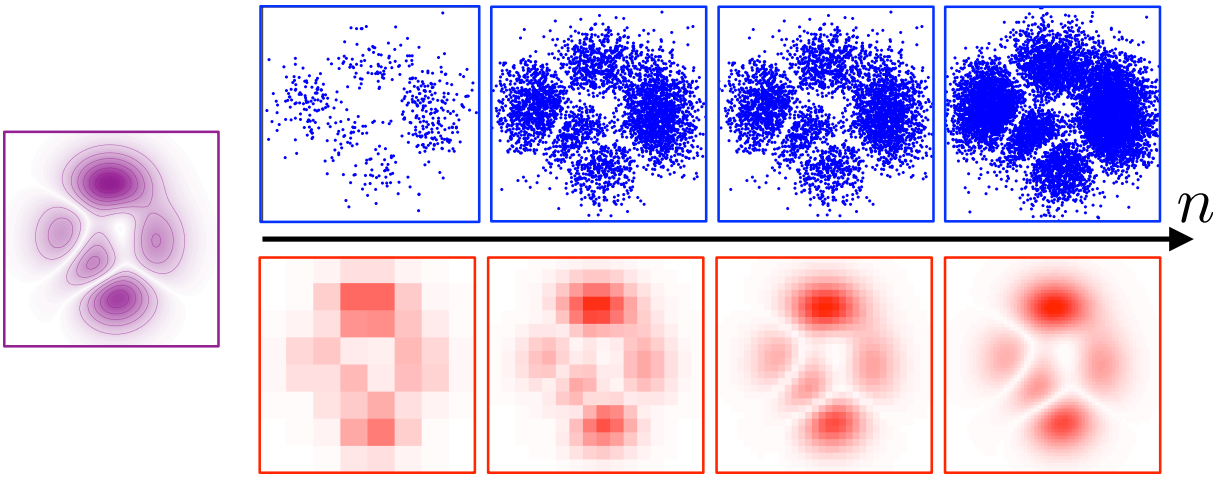

图 9.1: 用 Lagrange 型表示 $\frac{1}{n}\sum_i \delta_{x_i}$（蓝色，上排）和 Euler 型表示 $\sum_i \mathbf{a}_i \delta_{x_i}$（红色，下排）对具有密度的连续分布（紫色，左侧）作逐渐加细的离散化. 在后者中，x_i 表示不断加大的网格中的单元. Euler 型表示从像素化图像开始，逐渐提高分辨率，直到几乎与原密度一致. 权重 $\mathbf{a}_i$ 与各像素单元的强度成正比.

9.1.1 Euler 型离散化

第一种离散化方法是假设 $\beta = \sum_{j=1}^m \mathbf{b}_j \delta_{y_j}$ 与 $\alpha_\theta = \sum_{i=1}^n \mathbf{a}(\theta)_i \delta_{x_i}$ 均为定义在固定位置 $(x_i)_i, (y_j)_j$ 上的离散分布. 这些位置可代表把整个观测空间分成网格的单元，也可

代表连续空间中所关心的有限点集，例如给定字典中所有词的向量嵌入 (Kusner et al., 2015; Rolet et al., 2016). 此时，参数化测度 α_θ 完全由权重向量 $\mathbf{a} : \theta \mapsto \mathbf{a}(\theta) \in \Sigma_n$ 表示；在大网格上，它实际可能非常稀疏. 这对应所谓 Euler 型离散化 (Eulerian discretization) . 问题 (9.1) 的原始目标不可微. 为得到光滑的最小化问题，使用熵正则化 OT，以如下问题近似 (9.1)：

$$\min_{\theta\in\Theta} \mathcal{E}_E(\theta) \overset{\text{def.}}{=} \mathrm{L}^\varepsilon_{\mathbf{C}}(\mathbf{a}(\theta), \mathbf{b}) \quad \text{其中} \quad \mathbf{C}_{i,j} \overset{\text{def.}}{=} c(x_i, y_j).$$

回顾命题 4.6：熵损失关于输入直方图可微且凸，其梯度如下.

命题 9.1.1 (关于直方图的导数)**.** 当 $\varepsilon > 0$ 时，映射 $(\mathbf{a}, \mathbf{b}) \mapsto \mathrm{L}^\varepsilon_{\mathbf{C}}(\mathbf{a}, \mathbf{b})$ 是凸且可微的，梯度为

$$\nabla \mathrm{L}^\varepsilon_{\mathbf{C}}(\mathbf{a}, \mathbf{b}) = (\mathbf{f}, \mathbf{g}), \tag{9.2}$$

其中 $(\mathbf{f}, \mathbf{g})$ 是式 (4.30) 的唯一解，中心化使 $\sum_i \mathbf{f}_i = \sum_j \mathbf{g}_j = 0$. 当 $\varepsilon = 0$ 时，该式定义 $\mathrm{L}^\varepsilon_{\mathbf{C}}$ 的次微分元素；若这些元素唯一，则函数可微.

用梯度下降时，$(\mathbf{f}, \mathbf{g})$ 的零均值条件对保证质量守恒很重要.

由链式法则，$\mathcal{E}_E$ 光滑，且梯度为

$$\nabla \mathcal{E}_E(\theta) = [\partial \mathbf{a}(\theta)]^\top (\mathbf{f}), \tag{9.3}$$

其中 $\partial \mathbf{a}(\theta) \in \mathbb{R}^{n \times \dim(\Theta)}$ 是映射 $\mathbf{a}(\theta)$ 的 Jacobian 矩阵（微分），$\mathbf{f} \in \mathbb{R}^n$ 是代价矩阵 $\mathbf{C}$ 下 $\mathbf{a}(\theta)$ 与 $\mathbf{b}$ 之间熵 OT 对偶问题 (4.30) 对应的对偶势向量. 在 Euler 型框架中 $\mathbf{C}$ 固定，特别地不依赖 θ.

可以利用这一结果，通过梯度下降局部最小化 $\mathcal{E}_E$.

9.1.2 Lagrange 型离散化

另一种方法采用固定权重（通常均匀），以经验测度 $\alpha_\theta = \frac{1}{n}\sum_i \delta_{x(\theta)_i}$ 近似输入测度 α，其中点云参数化映射为 $x : \theta \mapsto x(\theta) = (x(\theta)_i)_{i=1}^n \in \mathcal{X}^n$，此处假设 $\mathcal{X}$ 为欧氏空间. 这称为 Lagrange 型离散化（Lagrangian discretization）. 于是问题 (9.1) 近似为

$$\min_\theta \mathcal{E}_L(\theta) \overset{\text{def.}}{=} \mathrm{L}^\varepsilon_{\mathbf{C}(x(\theta))}(\mathbb{1}_n/n, \mathbf{b}) \quad \text{其中} \quad \mathbf{C}(x)_{i,j} \overset{\text{def.}}{=} c(x(\theta)_i, y_j). \tag{9.4}$$

此时 α_θ 的支撑随 θ 改变，因而代价矩阵 $\mathbf{C}(x(\theta))$ 依赖于 θ.

下述命题表明熵 OT 损失是代价矩阵的光滑函数，并给出其梯度表达式.

命题 9.1.2 (关于费用的导数)**.** 固定输入直方图 $(\mathbf{a}, \mathbf{b})$，当 $\varepsilon > 0$ 时，映射 $\mathbf{C} \mapsto \mathcal{R}(\mathbf{C}) \overset{\text{def.}}{=} \mathrm{L}^\varepsilon_{\mathbf{C}}(\mathbf{a}, \mathbf{b})$ 凹且光滑，并且

$$\nabla \mathcal{R}(\mathbf{C}) = \mathbf{P}, \tag{9.5}$$

其中 $\mathbf{P}$ 是式 (4.2) 的唯一最优解.

当 $\varepsilon = 0$ 时，该公式定义上梯度的集合.

假设 $(\mathcal{X},\mathcal{Y})$ 是 $\mathbb{R}^d$ 的凸子集，对形如 (2.3) 的离散测度 (α,β)，由链式法则得到 $x=(x_i)_{i=1}^n\in\mathcal{X}^n\mapsto\mathcal{F}(x)\overset{\text{def.}}{=}\mathrm{L}_{\mathbf{C}(x)}(\mathbb{1}_n/n,\mathbf{b})$ 光滑，且

$$\nabla\mathcal{F}(x)=\left(\sum_{j=1}^m\mathbf{P}_{i,j}\nabla_1 c(x_i,y_j)\right)_{i=1}^n\in\mathcal{X}^n, \tag{9.6}$$

其中 $\nabla_1 c$ 是关于第一个变量的梯度.

例如，若 $\mathcal{X}=\mathcal{Y}=\mathbb{R}^d$，费用为 $c(s,t)=\|s-t\|^2$，则

$$\nabla\mathcal{F}(x)=2\left(\mathbf{a}_i x_i-\sum_{j=1}^m\mathbf{P}_{i,j}y_j\right)_{i=1}^n, \tag{9.7}$$

此处 $\mathbf{a}_i=1/n$.

忽略一个常数因子后，该梯度就是 $\mathrm{Id}-T$，其中 T 为式 (4.19) 定义的重心投影.

由链式法则，Lagrange 型离散问题 (9.4) 光滑，其梯度为

$$\nabla\mathcal{E}_L(\theta)=[\partial x(\theta)]^\top(\nabla\mathcal{F}(x(\theta))), \tag{9.8}$$

其中 $\partial x(\theta)\in\mathbb{R}^{\dim(\Theta)\times(nd)}$ 为映射 $x(\theta)$ 的 Jacobian 矩阵；$\nabla\mathcal{F}$ 按式 (9.6) 或 (9.7) 实现，$\mathbf{P}$ 取为 α_θ 与 β 之间的最优耦合矩阵.

于是可用梯度下降计算 $\mathcal{E}_L$ 的局部极小点，例如 (Cuturi and Doucet, 2014) 采用了这种方法.

9.1.3 自动微分

应用式 (9.3)、(9.8) 的困难在于：为使公式有效，需要计算精确最优解 $\mathbf{f}$ 或 $\mathbf{P}$，而这只有通过大量 Sinkhorn 迭代才能达到可接受精度.

当待比较直方图的规模和数量都很大时，计算单个 Wasserstein 距离的预算通常有限，只容许少量 Sinkhorn 迭代. 此时，通常更好的做法是用反向模式自动微分直接对 Sinkhorn 算法的输出求导，而非以某次迭代值近似式 (4.30) 的梯度. 这对应使用式 (4.48) 引入的“算法型” Sinkhorn 散度，直接将其视为输入所决定的简单映射的复合并求导，而非使用式 (4.2) 中含正则化最优传输熵的量 $\mathrm{L}_{\mathbf{C}}^{\varepsilon}$. 输入在 Euler 型情形为直方图，在 Lagrange 型情形为代价矩阵. 根据第 4.5 节的定义，当 L 足够大时，这分别等价于对

$$\mathfrak{D}_{\mathbf{C}}^{(L)}(\mathbf{a}(\theta),\mathbf{b})\quad\text{或}\quad\mathfrak{D}_{\mathbf{C}(x(\theta))}^{(L)}(\mathbf{a},\mathbf{b})$$

关于 θ 求导.

计算涉及 Sinkhorn 散度的泛函梯度，与计算泛函本身具有相同的费用；应用示例见 (Bonneel et al., 2016; Genevay et al., 2018). 早期关于 Sinkhorn 迭代对代价矩阵求导（如 Lagrange 型框架）及其学习排序应用的工作见 (Adams and Zemel, 2011).

自动微分的更多细节见 (Griewank and Walther, 2008; Rall, 1981; Neidinger, 2010)，尤其是计算梯度最快的“反向模式”.

实现方面，近年来的深度学习 Python 框架均提供先进的反向模式微分，支持 GPU/TPU 计算 (Al-Rfou et al., 2016; Abadi et al., 2016; Pytorch, 2017)，大规模 Sinkhorn 损失应用应采用这些框架.

我们强烈建议使用此类自动微分技术，因为其复杂度与计算式 (9.3)、(9.8) 相同；这些公式主要有助于从理论上理解自动微分计算的内容. 唯一缺点是反向模式自动微分需要大量内存，内存占用与迭代次数成正比. 不过，可用子采样策略缓解这一问题 (Griewank, 1992).

9.2 Wasserstein 重心、聚类与字典学习

无监督学习的一个基本问题是计算若干数据点的 “均值” 或 “重心”. 对度量空间 $(\mathcal{X}, d)$ 中的点 $(x_s)_{s=1}^S \in \mathcal{X}^S$ (d 为距离，或更一般为散度)，经典的加权均值定义是求解变分问题

$$\min_{x\in\mathcal{X}} \sum_{s=1}^{S} \lambda_s d(x, x_s)^p \tag{9.9}$$

其中给定权重族 $(\lambda_s)_s \in \Sigma_S$，$p$ 常取 2.

当 $\mathcal{X} = \mathbb{R}^d$、$d(x,y) = \|x-y\|_2$ 时，$p=2$ 得到通常的线性平均 $x = \sum_s \lambda_s x_s$，$p=1$ 则得到更复杂的中位点. 此形式可恢复多种均值概念，例如 $\mathcal{X} = \mathbb{R}_+$ 上的调和均值与几何均值.

这一过程常称为 Fréchet 均值 (Fréchet mean) 或 Karcher 均值，历史介绍见 Karcher (2014). 对一般距离 d，问题 (9.9) 通常是困难的非凸优化问题. 幸运的是，对最优传输距离，该问题可表述为凸规划，能证明解的存在性，并有高效数值格式.

Wasserstein 空间上的 Fréchet 均值. 给定输入直方图 $\{\mathbf{b}_s\}_{s=1}^S$，其中 $b_s \in \Sigma_{n_s}$，以及权重 $\lambda \in \Sigma_S$，可通过最小化

$$\min_{\mathbf{a}\in\Sigma_n} \sum_{s=1}^{S} \lambda_s \mathrm{L}_{\mathbf{C}_s}(\mathbf{a}, \mathbf{b}_s), \tag{9.10}$$

计算 Wasserstein 重心 (Wasserstein barycenter)，其中需指定代价矩阵 $\mathbf{C}_s \in \mathbb{R}^{n\times n_s}$.

典型设置是 “Euler 型”：所有重心定义在同一网格上，$n_s = n$，令 $\mathbf{C}_s = \mathbf{C} = \mathbf{D}^p$ 为距离矩阵，求解

$$\min_{\mathbf{a}\in\Sigma_n} \sum_{s=1}^{S} \lambda_s \, \mathrm{W}_p^p(\mathbf{a}, \mathbf{b}_s).$$

Agueh and Carlier (2011) 延续 Carlier and Ekeland (2010) 的早期思想，以任意测度的更一般形式引入重心问题 (9.10)，详见注 9.1. 直方图重心问题 (9.10) 实际上是线性规划，因为可以搜索各输入与重心之间的 S 个耦合 $(\mathbf{P}_s)_s$，并按构造约束它们共享相同行边缘：

$$\min_{\mathbf{a}\in\Sigma_n, (\mathbf{P}_s\in\mathbb{R}^{n\times n_s})_s} \left\{ \sum_{s=1}^{S} \lambda_s \langle \mathbf{P}_s, \mathbf{C}_s\rangle \;:\; \forall\, s, \mathbf{P}_s^\top \mathbb{1}_{n_s} = \mathbf{a}, \mathbf{P}_s^\top \mathbb{1}_n = \mathbf{b}_s \right\}.$$

虽然这是 LP，但其规模使得中等规模问题也无法使用通用求解器. 可采用对偶次梯度下降等一阶方法 (Carlier et al., 2015).

注 9.1 (任意测度的重心). 给定空间 $\mathcal{X}$ 上的一组输入测度 $(\beta_s)_s$，重心问题成为

$$\min_{\alpha\in\mathcal{M}_+^1(\mathcal{X})} \sum_{s=1}^{S} \lambda_s \mathcal{L}_c(\alpha,\beta_s). \tag{9.11}$$

当 $\mathcal{X}=\mathbb{R}^d$、$c(x,y)=\|x-y\|^2$ 时，Agueh and Carlier (2011) 证明，若有一个输入测度具有密度，则重心唯一.

问题 (9.11) 可视为从点 $(x_s)_{s=1}^S \in \mathcal{X}^S$ 的重心推广到任意测度. 事实上，若 $\beta_s=\delta_{x_s}$ 是单个 Dirac 质量，则问题 (9.11) 的一个解为 $\delta_{x^\star}$，其中 $x^\star$ 为求解 (9.9) 的 Fréchet 均值.

当 $c(x,y)=\|x-y\|^2$ 时，重心 $\alpha^\star$ 的均值必为各均值的重心，即

$$\int_{\mathcal{X}} x\mathrm{d}\alpha^\star(x) = \sum_s \lambda_s \int_{\mathcal{X}} x\mathrm{d}\alpha_s(x),$$

且 $\alpha^\star$ 的支撑位于 $(\alpha_s)_s$ 各支撑的凸包中.

用离散分布近似输入分布、从而改为求解 (9.10) 时，对无限维优化问题 (9.11) 的近似一致性见 Carlier et al. (2015).

还可将问题 (9.11) 重写为多边缘 OT 问题，见注 10.2.

注 9.2 (作为 Wasserstein 变分问题的 k-均值). 若输入测度族 $(\beta_s)_s$ 仅含一个测度 β，它支撑在 $\mathcal{X}=\mathbb{R}^d$ 的有限离散子集上，且费用为欧氏距离平方，则重心问题

$$\min_{\alpha\in\mathcal{M}_k^1(\mathcal{X})} \mathcal{L}_c(\alpha,\beta), \tag{9.12}$$

与以 β 为输入的通常 k-均值问题等价，其中约束 α 为支撑至多含 k 点的离散测度. 易证 k-均值输出的质心对应解 α 的支撑，而其权重对应 β 中分配到每个质心的点所占比例. 用熵正则化近似 $\mathcal{L}_c$ 会产生平滑指派，它们也出现在高斯混合等 k-均值软聚类变体中 (Dessein et al., 2017).

注 9.3 (分布的分布与一致性). 可将问题 (9.11) 推广到可能无限的测度族. 在概率分布空间 $\mathcal{M}_+^1(\mathcal{X})$ 上考虑概率分布 M，即 $M\in\mathcal{M}_+^1(\mathcal{M}_+^1(\mathcal{X}))$. 此时重心为如下问题的解：

$$\min_{\alpha\in\mathcal{M}_+^1(\mathcal{X})} \mathbb{E}_M(\mathcal{L}_c(\alpha,\beta)) = \int_{\mathcal{M}_+^1(\mathcal{X})} \mathcal{L}_c(\alpha,\beta)\mathrm{d}M(\beta), \tag{9.13}$$

其中 β 是按 M 分布的随机测度. 按 M 均匀随机抽取有限个输入测度 $(\beta_s)_{s=1}^S$，再取均匀权重 $\lambda_s=1/S$，定义 $\hat{\beta}_S$ 为问题 (9.11) 的一个解；此处 $\hat{\beta}_S$ 本身也是随机测度.

问题 (9.11) 对应“离散”测度 $M=\sum_s \lambda_s \delta_{\beta_s}$ 的特殊情形.

$\mathcal{L}_c(\hat{\beta}_S,\alpha)$ 在期望意义或以高概率趋于零（其中 α 为 (9.13) 的唯一解），对应重心的一致性，其证明见 (Bigot and Klein, 2012a; Le Gouic and Loubes, 2016; Bigot and Klein, 2012b).

这可解释为 Wasserstein 空间上的大数定律. 将其推广为中心极限定理是重要问题；近期的问题表述和一维分布、高斯测度等特殊情形的解见 (Panaretos and Zemel, 2016; Agueh and Carlier, 2017).

注 9.4 (不动点映射). 对欧氏空间 $\mathcal{X}=\mathbb{R}^d$、基础费用 $c(x,y)=\|x-y\|^2$，可用传输映射研究重心问题. 若 α 有密度，根据注 2.24，可定义 α 与 α_s 之间的最优传输映射 T_s，特别地 $T_{s,\sharp}\alpha=\alpha_s$. 平均映射

$$T^{(\alpha)} \overset{\text{def.}}{=} \sum_{s=1}^{S} \lambda_s T_s$$

本身是 α 与 $T^{(\alpha)}_\sharp\alpha$ 之间的最优映射，上述记号显式表示对 α 的依赖. 由 Brenier 定理（注 2.24），最优映射的正组合等于凸函数梯度之和，也即凸函数之和的梯度；再次由 Brenier 定理，它最优. 如 (Agueh and Carlier, 2011) 所示，在最优测度 $\alpha^\star$（重心）处，重心问题 (9.13) 的一阶最优性条件实际为 $T^{(\alpha^\star)}=\mathbb{I}_{\mathbb{R}^d}$（恒等映射）. 文献 (Álvarez-Esteban et al., 2016) 证明，在 (Zemel and Panaretos, 2018, Theo. 2) 阐明的正则性条件下，重心 $\alpha^\star$ 是以下不动点方程的唯一解：

$$G(\alpha)=\alpha \quad \text{其中} \quad G(\alpha)\overset{\text{def.}}{=}T^{(\alpha)}_\sharp\alpha, \tag{9.14}$$

在输入测度的温和条件下，Álvarez-Esteban et al. (2016) 与 Zemel and Panaretos (2018) 证明，若 α 不是重心，则 $\alpha\mapsto G(\alpha)$ 严格降低问题 (9.13) 的目标函数，且不动点迭代 $\alpha^{(\ell+1)}\overset{\text{def.}}{=}G(\alpha^{(\ell)})$ 收敛至重心 $\alpha^\star$.

当最优传输映射有闭式表达时（例如高斯情形），可使用该不动点算法. 对同样大小的经验测度，调整算法后以最优指派代替 Monge 映射. 对任意大小的更一般离散测度，也可利用重心投影 (4.19) 调整该格式 (Cuturi and Doucet, 2014).

特殊情形. 一般而言，求解 (9.10) 或 (9.11) 并不直接，但有些特殊情形的解显式或简单.

注 9.5 (高斯分布的重心). 文献 (Agueh and Carlier, 2011) 证明，对欧氏距离平方费用 $c(x,y)=\|x-y\|^2$，高斯分布 $\alpha_s=\mathcal{N}(\mathbf{m}_s,\mathbf{\Sigma}_s)$ 的重心仍为高斯分布 $\mathcal{N}(\mathbf{m}^\star,\mathbf{\Sigma}^\star)$.

由式 (2.41)，重心均值为输入均值的平均：

$$\mathbf{m}^\star=\sum_s \lambda_s \mathbf{m}_s$$

协方差则最小化

$$\min_{\boldsymbol{\Sigma}} \sum_s \lambda_s \mathcal{B}(\boldsymbol{\Sigma}, \boldsymbol{\Sigma}_s)^2,$$

其中 $\mathcal{B}$ 是 Bures 度量 (2.42). 如 (Agueh and Carlier, 2011) 所研究，该凸问题的一阶最优性条件表明，$\boldsymbol{\Sigma}^\star$ 为下述映射的唯一正定不动点：

$$\boldsymbol{\Sigma}^\star = \Psi(\boldsymbol{\Sigma}^\star) \quad \text{其中} \quad \Psi(\boldsymbol{\Sigma}) \overset{\text{def.}}{=} \sum_s \lambda_s (\boldsymbol{\Sigma}^{\frac{1}{2}} \boldsymbol{\Sigma}_s \boldsymbol{\Sigma}^{\frac{1}{2}})^{\frac{1}{2}},$$

其中 $\boldsymbol{\Sigma}^{1/2}$ 为半正定矩阵的平方根.

这一结果已见于 (Knott and Smith, 1994; Rüschendorf and Uckelmann, 2002)，证明见 (Agueh and Carlier, 2011).

虽然 Ψ 不严格压缩，但迭代此不动点映射，即令 $\boldsymbol{\Sigma}^{(\ell+1)} \overset{\text{def.}}{=} \Psi(\boldsymbol{\Sigma}^{(\ell)})$，实际会收敛到解 $\boldsymbol{\Sigma}^\star$.

该方法已用于纹理合成 (Xia et al., 2014). Álvarez-Esteban et al. (2016) 还提出替代映射

$$\bar{\Psi}(\boldsymbol{\Sigma}) \overset{\text{def.}}{=} \boldsymbol{\Sigma}^{-\frac{1}{2}} \Big(\sum_s \lambda_s (\boldsymbol{\Sigma}^{\frac{1}{2}} \boldsymbol{\Sigma}_s \boldsymbol{\Sigma}^{\frac{1}{2}})^{\frac{1}{2}} \Big)^2 \boldsymbol{\Sigma}^{-\frac{1}{2}}$$

其迭代 $\boldsymbol{\Sigma}^{(\ell+1)} \overset{\text{def.}}{=} \bar{\Psi}(\boldsymbol{\Sigma}^{(\ell)})$ 收敛.

原因是式 (9.14) 定义的不动点映射 G 保持高斯分布；事实上，

$$G(\mathcal{N}(\mathbf{m}, \boldsymbol{\Sigma})) = \mathcal{N}(\mathbf{m}^\star, \bar{\Psi}(\boldsymbol{\Sigma})).$$

图 9.2 给出四个二维高斯分布之间重心计算的两个示例.

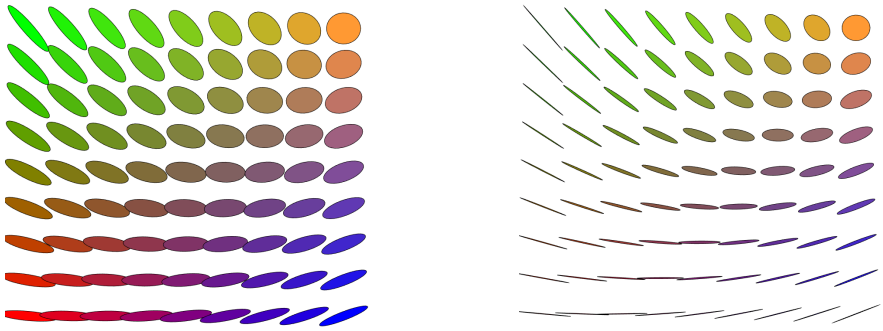

图 9.2: 四个二维高斯分布之间的重心. 每个高斯分布用一个椭圆表示，轴与协方差的主轴对齐，各轴伸长量与对应特征值成正比.

注 9.6 (一维情形). 对一维分布，利用传输为单调重排这一事实，几乎可以闭式计算 $\mathcal{W}_p$ 重心，详见注 2.30.

最简单的情形是 n 点经验测度 $\beta_s = \frac{1}{n}\sum_{i=1}^n \delta_{y_{s,i}}$，假设点已排序为 $y_{s,1} \leq y_{s,2} \leq$

…… 由式 (2.33)，重心 α_λ 也是 n 点经验测度：

$$\alpha_\lambda = \frac{1}{n}\sum_{i=1}^{n} \delta_{x_{\lambda,i}} \quad \text{其中} \quad x_{\lambda,i} = A_\lambda(x_{s,i})_s,$$

其中 A_λ 为重心映射

$$A_\lambda(x_s)_s \overset{\text{def.}}{=} \operatorname*{argmin}_{x\in\mathbb{R}} \sum_{s=1}^{S} \lambda_s |x - x_s|^p.$$

例如 $p=2$ 时，$x_{\lambda,i} = \sum_{s=1}^{S} \lambda_s x_{s,i}$.

一般情形须用式 (2.34) 定义的累积分布函数；由式 (2.36)，有

$$\forall r \in [0,1], \quad \mathcal{C}^{-1}_{\alpha_\lambda}(r) = A_\lambda(\mathcal{C}^{-1}_{\alpha_s}(r))_{s=1}^{S},$$

例如，对支撑少于 n 点的离散测度，这可通过简单排序在 $O(n\log(n))$ 次操作内计算重心.

注 9.7 (简单情形). 以 $T_{r,u} : x \mapsto rx + u$ 表示缩放和平移，假设 $\alpha_s = T_{r_s,u_s,\sharp}\alpha_0$ 由初始模板测度经缩放和平移得到，则重心 α_λ 也由缩放和平移得到：

$$\alpha_\lambda = T_{r^\star,u^\star,\sharp}\alpha_0 \quad \text{其中} \quad \begin{cases} r^\star = (\sum_s \lambda_s/r_s)^{-1}, \\ u^\star = \sum_s \lambda_s u_s. \end{cases}$$

注 9.8 ($S=2$ 的情形). 当 $\mathcal{X} = \mathbb{R}^d$、$c(x,y) = \|x-y\|^2$ 时（可更一般地推广至测地空间），$S=2$ 个测度 (α_0,α_1) 之间的重心就是式 (7.6) 引入的 McCann 插值. 记 Monge 映射为 $T_\sharp\alpha_0 = \alpha_1$，则重心为 $\alpha_\lambda = (\lambda_1\mathrm{Id} + \lambda_2 T)_\sharp\alpha_0$.

式 (7.9) 说明离散情形的计算方法.

重心的熵近似. 对某个 $\varepsilon > 0$，可用熵平滑，通过

$$\min_{\mathbf{a}\in\Sigma_n} \sum_{s=1}^{S} \lambda_s \mathrm{L}^{\varepsilon}_{\mathbf{C}_s}(\mathbf{a}, \mathbf{b}_s) \tag{9.15}$$

近似问题 (9.10) 的解.

这是光滑凸最小化问题，可用梯度下降求解 (Cuturi and Doucet, 2014; Gramfort et al., 2015). 也可在半对偶上使用下降法，通常为拟 Newton 法 (Cuturi and Peyré, 2016)，便于为重心添加其他正则化，例如施加关于给定范数的某种光滑性.

如 Benamou et al. (2015) 指出，更简单却十分有效的方法是将式 (9.15) 改写为加权 KL 投影问题：

$$\min_{(\mathbf{P}_s)_s} \left\{ \sum_s \lambda_s \varepsilon \mathbf{KL}(\mathbf{P}_s|\mathbf{K}_s) \;:\; \forall s, {\mathbf{P}_s}^{\mathrm{T}}\mathbb{1}_m = \mathbf{b}_s,\ \mathbf{P}_1\mathbb{1}_1 = \cdots = \mathbf{P}_S\mathbb{1}_S, \right\} \tag{9.16}$$

其中记 $\mathbf{K}_s \overset{\text{def.}}{=} e^{-\mathbf{C}_s/\varepsilon}$. 此处重心 $\mathbf{a}$ 隐式编码在所有耦合 $\mathbf{P}_s \in \mathbb{R}^{n\times n_s}$ 的行边缘中，即 $\mathbf{a} = \mathbf{P}_1\mathbb{1}_1 = \cdots = \mathbf{P}_S\mathbb{1}_S$.

如 Benamou et al. (2015) 详述，可将 Sinkhorn 推广到这个问题，它也对应迭代投影；亦可视为第 4.6 节广义 Sinkhorn 的一个特例.

求解 (9.16) 的最优耦合 $(\mathbf{P}_s)_s$ 以缩放形式计算：

$$\mathbf{P}_s = \operatorname{diag}(\mathbf{u}_s)\mathbf{K}\operatorname{diag}(\mathbf{v}_s), \tag{9.17}$$

缩放向量依次更新为

$$\forall\, s \in [\![1,S]\!], \quad \mathbf{v}_s^{(\ell+1)} \overset{\text{def.}}{=} \frac{\mathbf{b}_s}{\mathbf{K}_s^{\mathrm{T}}\mathbf{u}_s^{(\ell)}}, \tag{9.18}$$

$$\forall\, s \in [\![1,S]\!], \quad \mathbf{u}_s^{(\ell+1)} \overset{\text{def.}}{=} \frac{\mathbf{a}^{(\ell+1)}}{\mathbf{K}_s\mathbf{v}_s^{(\ell+1)}}, \tag{9.19}$$

$$\text{其中} \quad \mathbf{a}^{(\ell+1)} \overset{\text{def.}}{=} \prod_s (\mathbf{K}_s\mathbf{v}_s^{(\ell+1)})^{\lambda_s}. \tag{9.20}$$

另一种推导方式是在对偶问题的变量上交替最小化，见下述命题.

命题 9.1. 式 (9.17) 的最优 $(\mathbf{u}_s, \mathbf{v}_s)$ 可写为 $(\mathbf{u}_s, \mathbf{v}_s) = (e^{\mathbf{f}_s/\varepsilon}, e^{\mathbf{g}_s/\varepsilon})$，其中 $(\mathbf{f}_s, \mathbf{g}_s)_s$ 是下述规划的解，其值与式 (9.15) 的值相同：

$$\max_{(\mathbf{f}_s,\mathbf{g}_s)_s} \left\{ \sum_s \lambda_s \left(\langle \mathbf{g}_s, \mathbf{b}_s\rangle - \varepsilon \langle \mathbf{K}_s e^{\mathbf{g}_s/\varepsilon}, e^{\mathbf{f}_s/\varepsilon}\rangle \right) \;:\; \sum_s \lambda_s \mathbf{f}_s = 0 \right\}. \tag{9.21}$$

证明： 在式 (9.16) 中引入 Lagrange 乘子，得

$$\min_{(\mathbf{P}_s)_s, \mathbf{a}} \max_{(\mathbf{f}_s,\mathbf{g}_s)_s} \sum_s \lambda_s \Big(\varepsilon \mathbf{KL}(\mathbf{P}_s|\mathbf{K}_s) + \langle \mathbf{a} - \mathbf{P}_s\mathbb{1}_m, \mathbf{f}_s\rangle + \langle \mathbf{b}_s - {\mathbf{P}_s}^{\mathrm{T}}\mathbb{1}_m, \mathbf{g}_s\rangle \Big).$$

强对偶性成立，因此可交换最小化与最大化，得到

$$\max_{(\mathbf{f}_s,\mathbf{g}_s)_s} \sum_s \lambda_s \left(\langle \mathbf{g}_s, \mathbf{b}_s\rangle + \min_{\mathbf{P}_s} \varepsilon \mathbf{KL}(\mathbf{P}_s|\mathbf{K}_s) - \langle \mathbf{P}_s, \mathbf{f}_s \oplus \mathbf{g}_s\rangle \right) + \min_{\mathbf{a}} \langle \sum_s \lambda_s \mathbf{f}_s, \mathbf{a}\rangle.$$

显式最小化 $\mathbf{a}$ 给出约束 $\sum_s \lambda_s \mathbf{f}_s = 0$，以及

$$\max_{(\mathbf{f}_s,\mathbf{g}_s)_s} \sum_s \lambda_s \langle \mathbf{g}_s, \mathbf{b}_s\rangle - \varepsilon \mathbf{KL}^*\left(\frac{\mathbf{f}_s \oplus \mathbf{g}_s}{\varepsilon} | \mathbf{K}_s \right),$$

其中 $\mathbf{KL}^*(\cdot|\mathbf{K}_s)$ 是函数 $\mathbf{KL}^*(\cdot|\mathbf{K}_s)$ 的 Legendre 变换 (4.54).

这一 Legendre 变换为

$$\mathbf{KL}^*(\mathbf{U}|\mathbf{K}) = \sum_{i,j} \mathbf{K}_{i,j}(e^{\mathbf{U}_{i,j}} - 1), \tag{9.22}$$

从而得到所需公式.

为证明式 (9.22)，利用函数的可分离性，只需计算

$$\forall\,(u,k)\in\mathbb{R}_+^2,\quad \mathbf{KL}^*(u|k)\overset{\text{def.}}{=}\max_r\, ur-(r\log(r/k)-r+k)$$

其最优性条件为 $u=\log(r/k)$，即 $r=ke^u$，由此得到结果. □

保持其他变量固定，对各 $\mathbf{g}_s$ 最小化式 (9.21)，由式 (9.18) 得到闭式解.

对所有 $(\mathbf{f}_s)_s$ 最小化式 (9.21)，需要按式 (9.20) 求解 $\mathbf{a}$，从而得到式 (9.19).

图 9.3、9.4 给出二维和三维形状插值应用. 图 9.5 给出曲面上重心的计算，基础费用为测地距离平方；此图采用注 4.19 详述的热测地近似. 更多细节以及计算机图形学和成像科学的其他应用见 (Solomon et al., 2015).

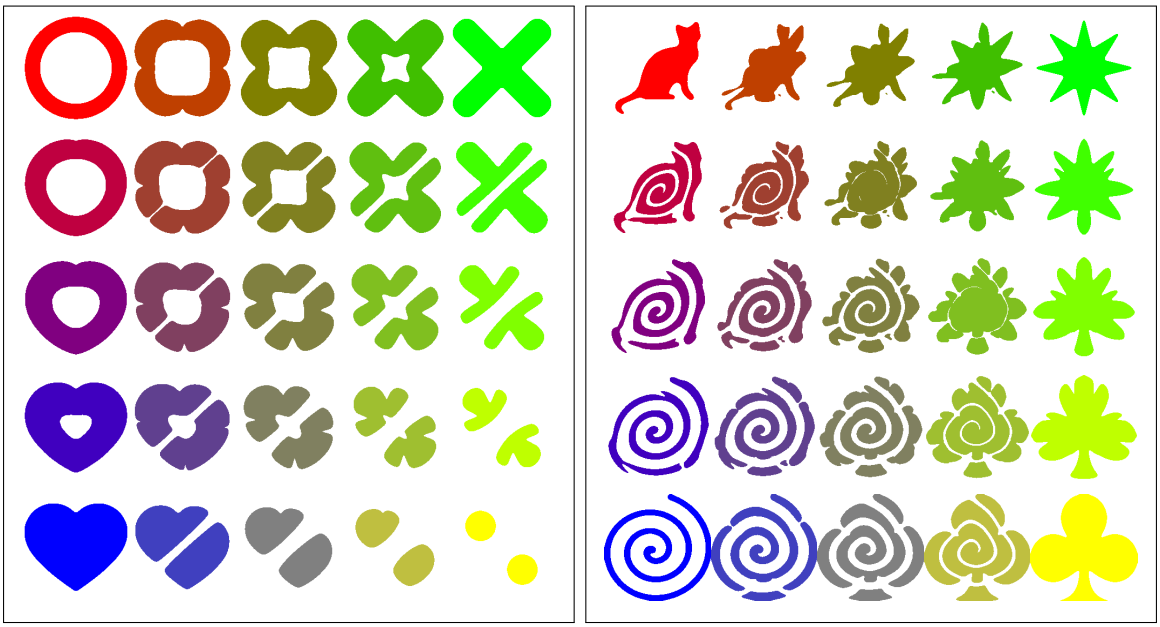

图 9.3: 利用熵正则化 (9.15) 计算四个输入二维形状的重心. 为显示二值形状，图像显示经过阈值处理的密度. 权重 $(\lambda_s)_s$ 是相对于正方形四角的双线性权重.

高效计算 Wasserstein 重心在当时仍是活跃的研究主题 (Staib et al., 2017a; Dvurechenskii et al., 2018). 除方法上的价值外，Wasserstein 重心还在形状分析以外得到广泛应用：图像处理 (Rabin et al., 2011)，尤其颜色修改 (Solomon et al., 2015)（见图 9.6）；用于概括测度的 Bayesian 计算 (Srivastava et al., 2015a,b)；以及将输入测度表示为其他已知测度的 Wasserstein 重心的非线性降维 (Bonneel et al., 2016). 这些问题均产生复杂的非凸目标函数，可用自动微分精确优化，见注 9.1.3.

与重心计算密切相关的问题包括 Wasserstein 空间上的主成分分析，例如 (Seguy and Cuturi, 2015; Bigot et al., 2017b)，以及模板模型的统计估计 (Boissard et al., 2015). 重心计算能力还使概率测度空间上的 k-均值等更复杂的聚类方法成为可能 (del Barrio et al., 2016; Ho et al., 2017).

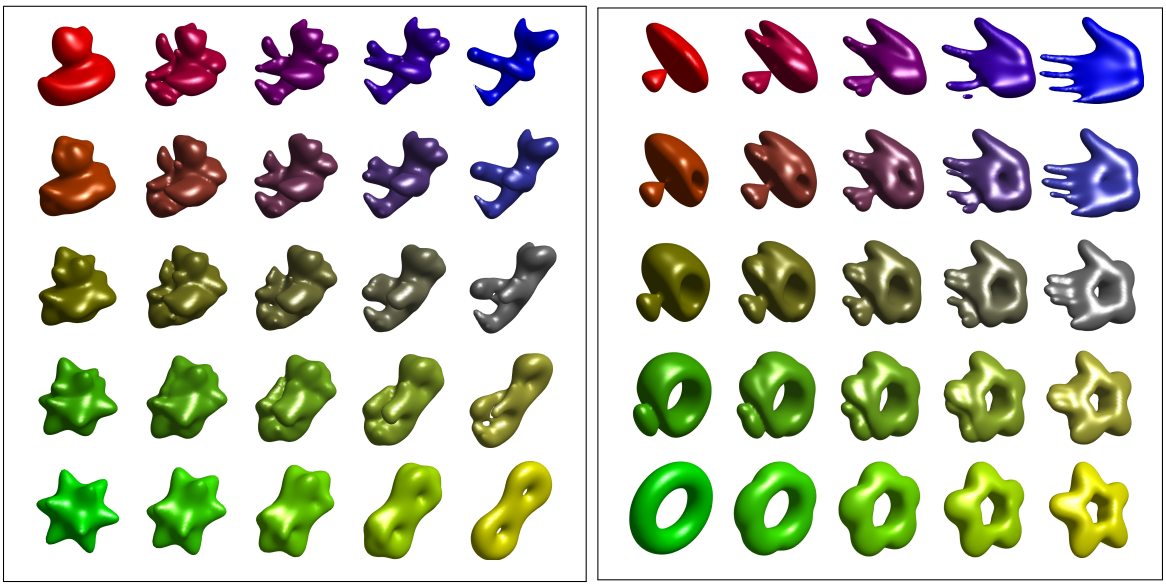

图 9.4: 利用熵正则化 (9.15) 计算四个输入三维形状的重心. 权重 $(\lambda_s)_s$ 是相对于正方形四角的双线性权重. 形状表示为测度，在形状边界内部均匀，外部为零.

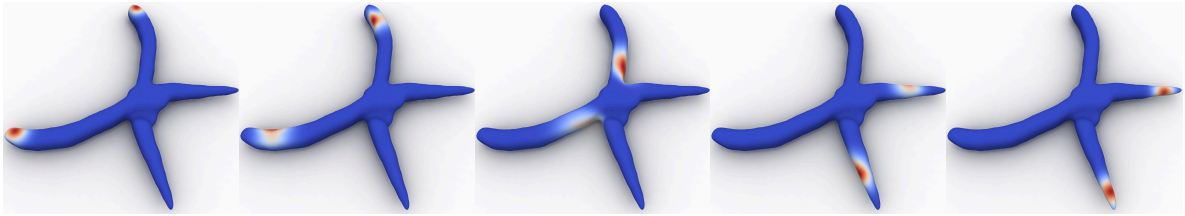

图 9.5: 曲面上两个输入测度之间的重心插值，采用热测地快速核近似计算，见注 4.19. 摘自 (Solomon et al., 2015).

注 9.9 (Wasserstein 传播)**.** 如 Solomon et al. (2014b) 所研究，可以推广重心问题 (9.10)：给定图 $\mathcal{G}$ 中一组节点 U，求这些节点上的分布 $(\mathbf{b}_u)_{u\in U}$，而补集节点 V 上的输入分布 $(\mathbf{b}_v)_{v\in V}$ 固定. 通过最小化图中所有构成边的节点对 $(r,s)\in\mathcal{G}$ 之间的总传输距离，确定未知量：

$$\min_{(\mathbf{b}_u\in\Sigma_{n_u})_{u\in U}} \sum_{(r,s)\in\mathcal{G}} \mathrm{L}_{\mathbf{C}_{r,s}}(\mathbf{b}_r,\mathbf{b}_s), \tag{9.23}$$

其中代价矩阵 $\mathbf{C}_{r,s}\in\mathbb{R}^{n_r\times n_s}$ 须由用户指定.

重心问题 (9.10) 是上述问题的特殊情形：图 $\mathcal{G}$ 呈“星形”，U 为一个顶点，与所有其他顶点 V 相连. 与 $\mathbf{b}_s$ 对应的权重 λ_s 可吸收到代价矩阵中.

为每条边 $(r,s)\in\mathcal{G}$ 显式引入耦合 $\mathbf{P}_{r,s}\in\mathbf{U}(\mathbf{b}_r,\mathbf{b}_s)$ 并使用熵正则化，便可类似式 (9.16) 重写该问题，并将 Sinkhorn 迭代 (9.18) 推广至此. 也可将问题化为第 4.6 节的广义 Sinkhorn 形式来推导.

将图替换为连续区域，可将图上的离散变分问题 (9.23) 推广为 Dirichlet 能

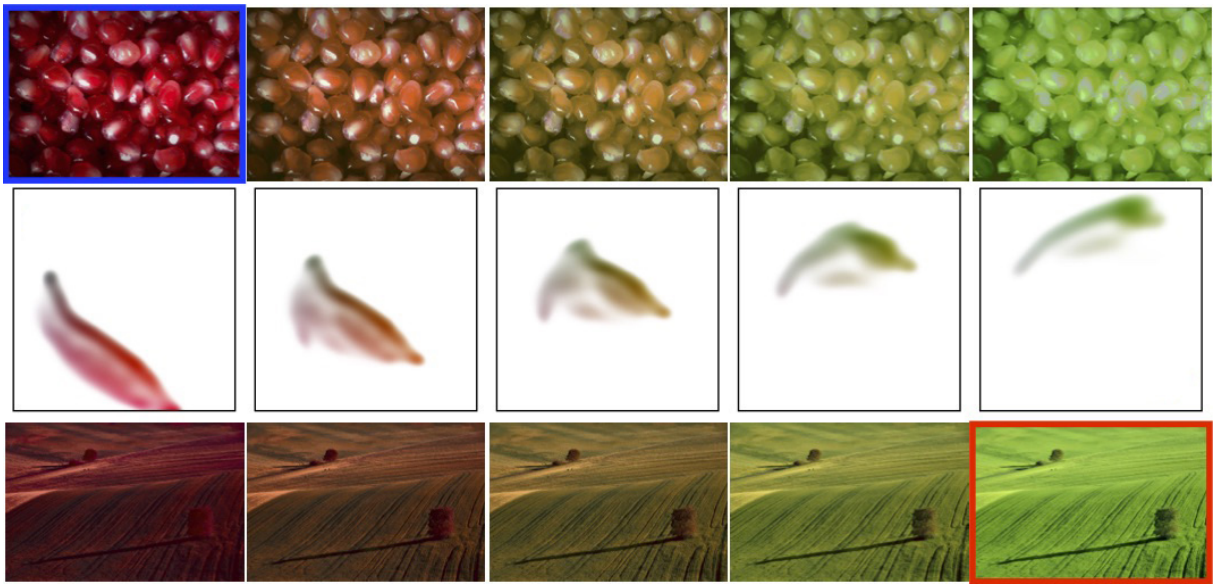

图 9.6: 两个输入图像的三维颜色经验直方图之间的插值，为简明起见仅显示二维色度投影. 再按注 4.11 详述的重心投影，将修改后的直方图应用于输入图像. 摘自 (Solomon et al., 2015).

量 (Solomon et al., 2013)，从而定义测度值调和函数，用于图像和曲面处理. 理论分析另见 Lavenant (2017)，对非二次 (全变差) 泛函的推广及成像应用见 Vogt and Lellmann (2018).

9.3 梯度流

给定光滑函数 $\mathbf{a} \mapsto F(\mathbf{a})$，可用标准梯度下降

$$\mathbf{a}^{(\ell+1)} \overset{\text{def.}}{=} \mathbf{a}^{(\ell)} - \tau \nabla F(\mathbf{a}^{(\ell)}), \tag{9.24}$$

其中 τ 为足够小的步长. 这对应所谓 "显式" 最小化格式，仅适用于光滑 F. 对非光滑函数，可改用 "隐式" 格式，也称近端点算法，例如 Bauschke and Combettes (2011)：

$$\mathbf{a}^{(\ell+1)} \overset{\text{def.}}{=} \mathrm{Prox}_{\tau F}^{\|\cdot\|}(\mathbf{a}^{(\ell)}) \overset{\text{def.}}{=} \operatorname*{argmin}_{\mathbf{a}} \frac{1}{2} \left\|\mathbf{a} - \mathbf{a}^{(\ell)}\right\|^2 + \tau F(\mathbf{a}). \tag{9.25}$$

这对应式 (7.13) 中已经遇到的欧氏近端算子.

更新 (9.24) 可理解为迭代显式算子 $\mathrm{Id} - \tau\nabla F$，而式 (9.25) 使用隐式算子 $(\mathrm{Id} + \tau\nabla F)^{-1}$. 对凸 F，任意 $\tau > 0$ 下迭代 (9.25) 均收敛.

若 F 定义在直方图单纯形 Σ_n 上，则自然可在式 (9.25) 中以最优传输度量代替 ℓ^2 范数 $\|\cdot\|$，求解

$$\mathbf{a}^{(\ell+1)} \overset{\text{def.}}{=} \operatorname*{argmin}_{\mathbf{a}} \mathrm{W}_p(\mathbf{a}, \mathbf{a}^{(\ell)})^p + \tau F(\mathbf{a}). \tag{9.26}$$

注 9.10 (Wasserstein 梯度流). 对 $\mathcal{M}_+^1(\mathcal{X})$ 上的函数 F，定义迭代

$$\alpha^{(\ell+1)} \overset{\text{def.}}{=} \operatorname*{argmin}_{\alpha} \mathcal{W}_p(\alpha, \alpha^{(\ell)})^p + \tau F(\alpha) \tag{9.27}$$

便可将式 (9.26) 推广至任意测度. 这种隐式时间步进是构造连续流的有用工具：形式地取 $\tau \to 0$，引入时间 $t = \tau\ell$，使 $\alpha^{(\ell)}$ 近似连续流 $t \in \mathbb{R}_+ \mapsto \alpha_t$. 在 $p = 2$、$\mathcal{X} = \mathbb{R}^d$ 的特殊情形，形式计算表明 α_t 应满足如下偏微分方程：

$$\frac{\partial \alpha_t}{\partial t} = \operatorname{div}(\alpha_t \nabla(F'(\alpha_t))), \tag{9.28}$$

其中 $F'(\alpha)$ 表示函数 F 的导数，即它是连续函数 $F'(\alpha) \in \mathcal{C}(\mathcal{X})$，满足

$$F(\alpha + \varepsilon\xi) = F(\alpha) + \varepsilon \int_{\mathcal{X}} F'(\alpha) \mathrm{d}\xi(x) + o(\varepsilon).$$

典型示例是 $F = -H$，其中 $H(\alpha) = \mathrm{KL}(\alpha|\mathcal{L}_{\mathbb{R}^d})$ 为关于 $\mathcal{X} = \mathbb{R}^d$ 上 Lebesgue 测度 $\mathcal{L}_{\mathbb{R}^d}$ 的相对熵：

$$H(\alpha) = -\int_{\mathbb{R}^d} \rho_\alpha(x)(\log(\rho_\alpha(x)) - 1)\mathrm{d}x \tag{9.29}$$

当 α 没有密度时，置 $H(\alpha) = -\infty$. 此时式 (9.28) 表明，这一负熵的梯度流是线性热扩散

$$\frac{\partial \alpha_t}{\partial t} = \Delta \alpha_t, \tag{9.30}$$

其中 Δ 为空间 Laplace 算子.

因此，热扩散既可解释为 Dirichlet 能量 $\int_{\mathbb{R}^d} \|\nabla \rho_\alpha(x)\|^2 \mathrm{d}x$ 的“经典”欧氏流（某种意义上沿质量幅值“竖直”移动），也可解释为熵的最优传输流（某种意义上沿质量位置“水平”移动）.

Jordan、Kinderlehrer 和 Otto 的开创性论文 (Jordan et al., 1998) 引发了人们对 Wasserstein 梯度流的兴趣；沿用他们的工作，这些演化常称为 JKO 流（JKO flow）. 如 Ambrosio et al. (2006) 的专著详述，JKO 流是度量空间梯度流的特例. 另见近期综述 (Santambrogio, 2017).

JKO 流尤其可用于研究多孔介质方程 (Otto, 2001)、全变差流 (Carlier and Poon, 2019)、量子漂移 (Gianazza et al., 2009) 或流形上的热演化 (Erbar, 2010) 等非线性演化方程. 其灵活形式允许对解施加约束，例如 Maury et al. 用来模拟人群运动的拥挤约束，即每一点密度的上界 (Maury et al., 2010)，另见综述 (Santambrogio, 2018).

注 9.11 (度量空间中的梯度流). 隐式步进 (9.27) 是在度量空间 $(\mathcal{X}, d)$ 上定义梯度流的一般形式的特例，其中 d 为距离，详见 (Ambrosio et al., 2006).

对 $x \in \mathcal{X}$ 上的函数 $F(x)$，定义隐式离散最小化步骤为

$$x^{(\ell+1)} \in \operatorname*{argmin}_{x\in\mathcal{X}} d(x^{(\ell)}, x)^2 + \tau F(x). \tag{9.31}$$

JKO 步骤 (9.27) 对应概率分布空间上 Wasserstein 距离的使用. 某些情形下可证明，当 $\tau \to 0$、$k\tau = t$ 时，式 (9.31) 存在连续流极限 x_t.

若 $\mathcal{X}$ 还具有欧氏结构，将 F 线性化可定义显式步进：

$$x^{(\ell+1)} = \operatorname*{argmin}_{x\in\mathcal{X}} d(x^{(\ell)}, x)^2 + \tau\langle \nabla F(x^{(\ell)}), x\rangle. \tag{9.32}$$

与隐式公式 (9.31) 相比，这通常容易计算，但可能不稳定. 隐式步骤始终稳定，也适用于非光滑 F，但通常没有闭式表达.

图 9.7 用 $\mathcal{X} = \mathbb{R}^2$ 上函数 $F(x) = \|x\|^2$，以及不同 p 值的距离 $d(x,y) = \|x-y\|_p = (|x_1-y_1|^p + |x_2-y_2|^p)^{1/p}$ 展示这一概念.

当 $p = 1$ 或 $p = +\infty$ 时，显式格式 (9.32) 不稳定；$p = 1$ 时产生与坐标轴平行的步骤，即逐坐标下降.

相反，隐式格式 (9.31) 稳定. 特别注意 $p = 1$ 时，两个坐标相等后，下一步沿对角方向进行.

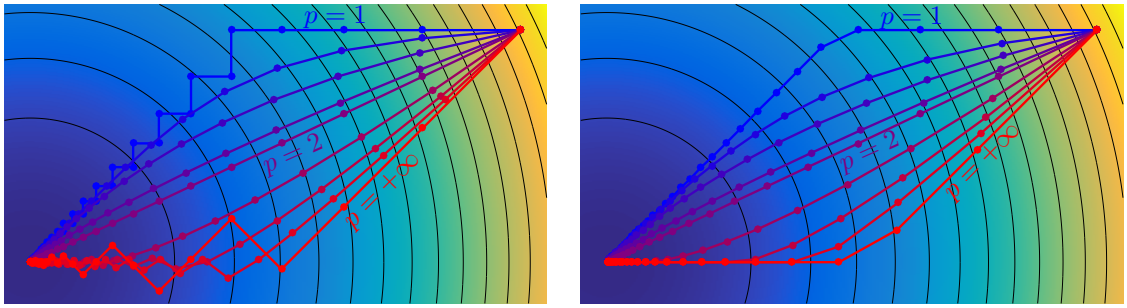

显式　　隐式

图 9.7: 对不同 p 值的距离 $d(x,y) = \|x-y\|_p$，比较在 $\mathcal{X} = \mathbb{R}^2$ 上最小化函数 $f(x) = \|x\|^2$ 的显式和隐式梯度流.

注 9.12 (用粒子系统作 Lagrange 型离散化)**.** 有限维问题 (9.26) 可解释为测度空间上的流 (9.27) 的 Euler 型离散化.

另一种离散化方式是使用粒子系统的 Lagrange 型方法：将解参数化为随时间移动的离散经验测度，以其位置而非权重作为变量. 实际上，可考虑随时间变化的动态粒子点云 $\alpha_t = \frac{1}{n}\sum_{i=1}^n \delta_{x_i(t)}$.

于是，初始问题 (9.26) 替换为 n 个耦合常微分方程，规定点 $X(t) = (x_i(t))_i \in \mathcal{X}^n$ 的动力学.

若能量 F 在离散测度上有限，可直接定义 $\mathcal{F}(X) = F(\frac{1}{n}\sum_{i=1}^n \delta_{x_i})$. 典型示例为线性函数 $F(\alpha) = \int_{\mathcal{X}} V(x)\mathrm{d}\alpha(x)$ 和二次相互作用 $F(\alpha) = \int_{\mathcal{X}^2} W(x,y)\mathrm{d}\alpha(x)\mathrm{d}\alpha(y)$，

分别可取

$$\mathcal{F}(X)=\frac{1}{n}\sum_i V(x_i)\quad\text{且}\quad \mathcal{F}(X)=\frac{1}{n^2}\sum_{i,j}W(x_i,x_j).$$

广义熵等函数仅在有密度的测度上有限，应使用密度估计器将点云转为密度，从而也可定义在 $n\to+\infty$ 时与 F 一致的函数 $\mathcal{F}(x)$. 典型示例是式 (9.29) 的熵 $F(\alpha)=H(\alpha)$；忽略常数项后，将到最近邻的距离取对数再求和可得到一致估计：

$$\mathcal{F}(X)=\frac{1}{n}\sum_i \log(d_X(x_i))\quad\text{其中}\quad d_X(x)=\min_{x'\in X,x'\neq x}\|x-x'\|;\tag{9.33}$$

非参数熵估计器综述见 Beirlant et al. (1997).

假设 $\mathcal{X}=\mathbb{R}^d$，步长 τ 充分小时，Wasserstein 距离 $\mathcal{W}_2$ 与点之间的欧氏距离一致，即若 $|t-t'|$ 足够小，则 $\mathcal{W}_2(\alpha_t,\alpha_{t'})=\|X(t)-X(t')\|$. 因此梯度流等价于位置上的欧氏流 $X'(t)=-\nabla\mathcal{F}(X(t))$，在时刻 $t_k=\tau k$ 以类似 (9.24) 的显式 Euler 步骤离散：

$$X^{(\ell+1)}\overset{\text{def.}}{=}X^{(\ell)}-\tau\nabla\mathcal{F}(X^{(\ell)}).$$

图 9.8 给出线性加熵泛函的此类离散显式演化示例，产生 Fokker–Planck 方程的离散版本.

对线性 Fokker–Planck 方程这一特殊情形，也可借助随机偏微分方程方法，通过演化带高斯漂移的单个随机粒子作数值近似. 这些所谓 Langevin Monte Carlo 格式趋向平稳分布的收敛性，还可用 Wasserstein 距离量化，例如 (Dalalyan and Karagulyan, 2017).

若 $\mathcal{F}$ 非光滑，应类似式 (9.25) 用隐式 Euler 步骤离散，即考虑

$$X^{(\ell+1)}\overset{\text{def.}}{=}\operatorname{Prox}_{\tau\mathcal{F}}^{\|\cdot\|}(X^{(\ell)})\overset{\text{def.}}{=}\operatorname*{argmin}_{Z\in\mathcal{X}^n}\frac{1}{2}\left\|Z-X^{(\ell)}\right\|^2+\tau\mathcal{F}(Z).$$

最简单的情形是线性函数 $F(\alpha)=\int_X V(x)\mathrm{d}\alpha(x)$：流独立作用于各粒子 $x_i(t)$，对应函数 V 的通常欧氏流 $x_i'(t)=-\nabla V(x_i(t))$，即密度沿流的积分曲线输运的偏微分方程.

注 9.13 (测地凸性)**.** 与梯度流相关的重要概念是泛函 F 关于 Wasserstein-2 几何的凸性，即沿 Wasserstein 测地线的凸性；测地线就是注 7.1 中的位移插值. 此类函数的连续时间 Wasserstein 梯度流存在且唯一，是 $\tau\to0$ 时离散步进 (9.27) 的极限，并在 $t\to+\infty$ 时收敛到固定的平稳分布.

熵是典型的测地凸函数. 若 $V:\mathcal{X}\to\mathbb{R}$、$W:\mathcal{X}\times\mathcal{X}\to\mathbb{R}$ 为凸函数，则线性函数 $F(\alpha)=\int_{\mathcal{X}}V(x)\mathrm{d}\alpha(x)$ 与二次相互作用函数 $F(\alpha)=\int_{\mathcal{X}\times\mathcal{X}}W(x,y)\mathrm{d}\alpha(x)\mathrm{d}\alpha(y)$ 也测地凸.

线性函数在经典意义下也是凸的，但二次相互作用函数未必如此.

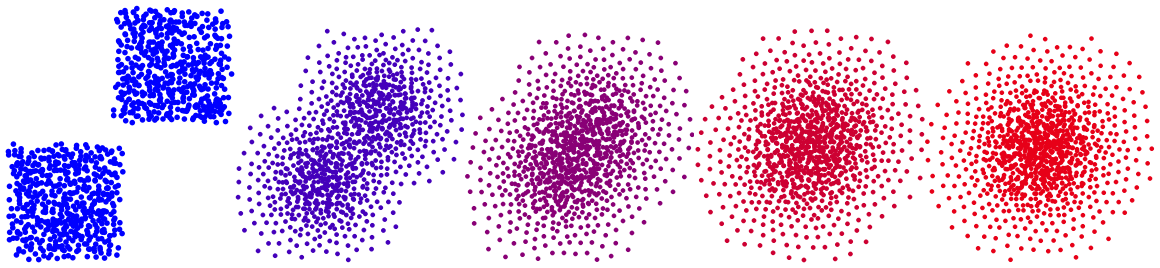

图 9.8: 用 Lagrange 型离散化计算函数 $F(\alpha)=\int V\mathrm{d}\alpha - H(\alpha)$ 的梯度流演化，其中 $V(x)=\|x\|^2$. 熵按式 (9.33) 离散化. 极限平稳分布为高斯分布.

典型示例为 $W(x,y)=\|x-y\|^2$，它是负半定核，见定义 8.3；因此 $F(\alpha)$ 在通常意义下为凹函数，同时却测地凸.

McCann (1997) 的重要结果是：在 $\mathcal{X}=\mathbb{R}^d$ 上，广义“熵”函数 $F(\alpha)=\int_{\mathbb{R}^d}\varphi(\rho_\alpha(x))\mathrm{d}x$ 测地凸，只要 φ 凸，$\varphi(0)=0$，$t\to+\infty$ 时 $\varphi(t)/t\to+\infty$，且 $s\mapsto s^d\varphi(s^{-d})$ 凸且递减.

关于所得离散流的数值求解，已有大量文献，这里仅列若干代表性工作. 一维问题中，OT 是逆累积分布函数的二次泛函，见注 2.30，因此已有很精确的求解器 Kinderlehrer and Walkington (1999); Blanchet et al. (2008); Agueh and Bowles (2013); Matthes and Osberger (2014); Blanchet and Carlier (2015). 更高维情形可用有限元、有限体积格式 Carrillo et al. (2015); Burger et al. (2010)，或用 Lagrange 型粒子系统格式构造其他求解器 Carrillo and Moll (2009); Benamou et al. (2016a); Westdickenberg and Wilkening (2010).

另一方向是寻找保留连续对应物某些性质的离散流，通常定义在离散网格或图上，见 Mielke (2013); Erbar and Maas (2014); Chow et al. (2012); Maas (2011).

基于熵正则化求解 Euler 型离散问题 (9.24) 的近似方法最初由 Peyré (2015) 提出，后由 Chizat et al. (2018b) 改进，并由 Carlier et al. (2017) 作理论分析.

加上熵正则化后，令 $G=\iota_{\mathbf{a}^{(\ell)}}$ 并以 τF 替代 F，问题 (9.26) 具有式 (4.49) 的形式. 因而可按 Peyré (2015) 的最初建议，用迭代 (4.51) 近似 $\mathbf{a}^{(\ell+1)}$. 当 $\varepsilon\to 0$ 时该格式收敛，证明见 Carlier et al. (2017).

图 9.9 给出用这一方法计算的演化示例.

梯度流在机器学习中的有趣应用是学习最能模拟某种密度动力学的底层函数 F. 通过熵正则化传输与自动微分，见注 9.1.3，求解光滑非凸优化即可完成这种学习，见 Hashimoto et al. (2016).

一般而言，同时在时间和空间上离散的梯度流，其收敛性分析很困难. 定义距离的线性规划具有多面体结构，步长过小会产生“锁定”现象：分布停滞，不再演化，因此步长不应过小，讨论见 (Maury and Preux, 2017). 一维梯度流离散化方法的收敛分析见 (Matthes and Osberger, 2014, 2017).

也可计算第 10.2 节详述的非平衡最优传输距离下的梯度流. 这类演化允许质量产生或消失，对模拟许多物理、生物和化学现象至关重要. 著名的细胞生长 Hele-Shaw 模型 (Perthame et al., 2014) 是非平衡梯度流的一个示例，理论研究见 (Gallouët and

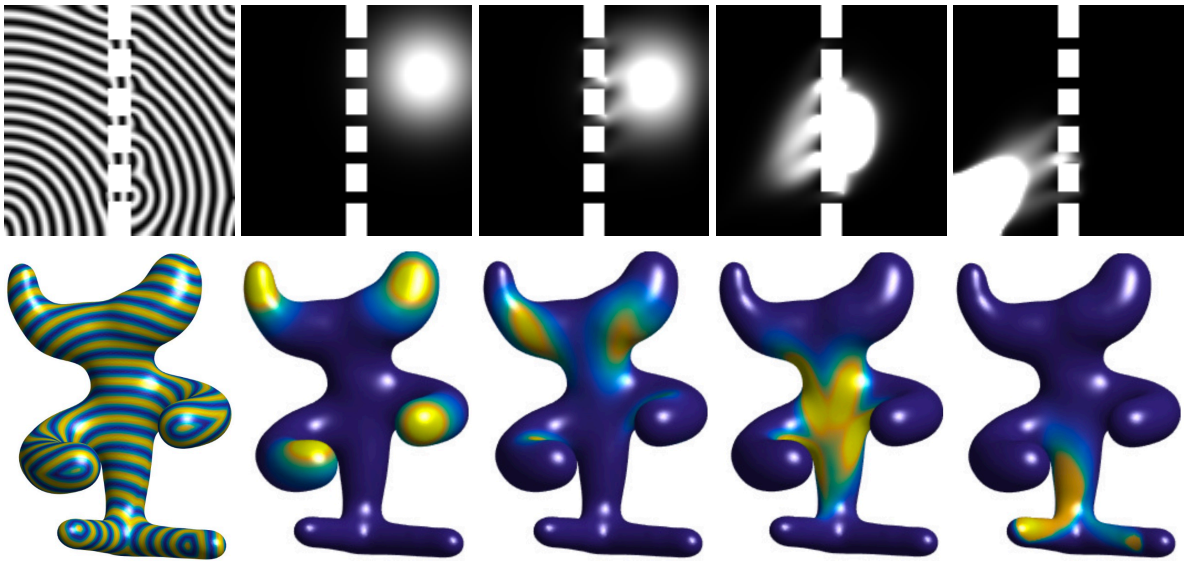

图 9.9: 含漂移 V 和拥挤项的梯度流演化示例，来自 Peyré (2015)，其中 $F(\alpha) = \int_{\mathcal{X}} V(x)\mathrm{d}\alpha(x) + \iota_{\leq\kappa}(\rho_\alpha)$.

Monsaingeon, 2017; Di Marino and Chizat, 2017). 也可用广义 Sinkhorn 算法近似此类非平衡梯度流 (Chizat et al., 2018b).

9.4 最小 Kantorovich 估计器

给定未知分布的离散样本 $(x_i)_{i=1}^n \subset \mathcal{X}$，目标是将参数模型 $\theta \mapsto \alpha_\theta \in \mathcal{M}(\mathcal{X})$ 拟合到观测经验输入测度 β:

$$\min_{\theta\in\Theta} \mathcal{L}(\alpha_\theta, \beta) \quad \text{其中} \quad \beta = \frac{1}{n}\sum_i \delta_{x_i}, \tag{9.34}$$

其中 $\mathcal{L}$ 为离散分布与 “连续”（任意）分布之间的某种 “损失” 函数，见图 9.10.

若 α_θ 关于 Lebesgue 测度或其他固定参考测度具有密度 $\rho_\theta \overset{\text{def.}}{=} \rho_{\alpha_\theta}$，则通过求解

$$\min_\theta \mathcal{L}_{\text{MLE}}(\alpha_\theta, \beta) \overset{\text{def.}}{=} -\sum_i \log(\rho_\theta(x_i)).$$

得到最大似然估计器（MLE）. 这对应使用 Kullback–Leibler 损失的经验版本：假设 x_i 为某个 $\bar\beta$ 的独立同分布样本，则

$$\mathcal{L}_{\text{MLE}}(\alpha, \beta) \overset{n\to+\infty}{\longrightarrow} \mathrm{KL}(\alpha|\bar\beta).$$

已知 MLE 方法在许多情形产生最优估计过程，例如 Owen (2001). 但估计奇异分布时它不可行：典型地，α_θ 无密度，从而 $\mathcal{L}_{\text{MLE}}(\alpha_\theta, \beta) = +\infty$；或 $(x_i)_i$ 来自某个奇异 $\bar\beta$，此时为使 $\mathrm{KL}(\alpha_\theta|\bar\beta)$ 有限，α_θ 应与 β 共享支撑，但该支撑通常未知. 另一个问题是，在若干实际情形中，密度 ρ_θ 无法获得或太难计算.

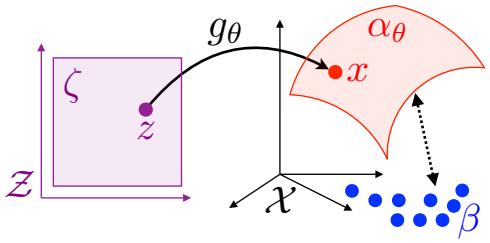

图 9.10: 密度拟合问题 9.34 的示意图.

奇异和未知密度这两个问题同时出现的典型情形是所谓生成模型，其参数测度写为固定参考测度 $\zeta \in \mathcal{M}(\mathcal{Z})$ 的推前：

$$\alpha_\theta = h_{\theta,\sharp}\zeta \quad \text{其中} \quad h_\theta : \mathcal{Z} \to \mathcal{X},$$

推前算子见定义 2.1. 空间 $\mathcal{Z}$ 通常为低维，因此 α_θ 的支撑位于低维 "流形" 上，所得密度高度奇异，即没有关于 Lebesgue 测度的密度.

此外，该密度通常难以计算，但只需计算 $x_i = h_\theta(z_i)$ 就能从 α_θ 生成独立同分布样本，其中 $(z_i)_i$ 为 ζ 的独立同分布样本.

为处理这种困难情形，须用弱度量代替 MLE 泛函 $\mathcal{L}_{\text{MLE}}$，将其写成对偶形式：

$$\mathcal{L}(\alpha,\beta) \overset{\text{def.}}{=} \max_{(f,g)\in\mathcal{C}(\mathcal{X})^2} \left\{ \int_{\mathcal{X}} f(x)\mathrm{d}\alpha(x) + \int_{\mathcal{X}} g(x)\mathrm{d}\beta(x) \;:\; (f,g)\in\mathcal{R} \right\}. \tag{9.35}$$

第 8.2 节的对偶范数对应约束

$$\mathcal{R} = \{(f,-f) \;:\; f \in B\},$$

而最优传输 (2.24) 按式 (2.25) 设置 $\mathcal{R} = \mathcal{R}(c)$.

固定 θ 时，使用这类损失函数计算式 (9.34) 中待最小化的能量，对应求解第 5 章所研究的半离散最优传输. 关于 θ 最小化能量则复杂得多，通常高度非凸.

计算 $\mathcal{E}(\theta) = \mathcal{L}(\alpha_\theta,\beta)$ 时，记 f_θ 为式 (9.35) 的一个解，可用下式得到次梯度：

$$\nabla\mathcal{E}(\theta) = \int_{\mathcal{X}} [\partial h_\theta(x)]^\top \nabla f_\theta(x)\mathrm{d}\alpha_\theta(x), \tag{9.36}$$

其中 $\partial h_\theta(x) \in \mathbb{R}^{\dim(\Theta)\times d}$ 为映射 $\theta \in \mathbb{R}^{\dim(\Theta)} \mapsto h_\theta(x)$ 关于 θ 的微分，$\nabla f_\theta(x)$ 为 f_θ 关于 x 的梯度.

这一公式难以数值使用，首先因为须计算半离散问题的解，即连续函数 f_θ. 如第 8.5 节所示，对 OT 损失可用随机优化实现，但难以适用于高维. 另一个选择是为势施加参数形式，例如 RKHS 展开 Genevay et al. (2016) 或深度网络近似 (Arjovsky et al., 2017)；不过，这会引入尚未得到理论分析的重要近似误差.

最后，公式需要计算对偶势 f_θ 的梯度 ∇f_θ，因此数值上不稳定.

对 OT 损失，若改为计算下述等价问题的原始最优耦合，便可得到另一种梯度公式：

$$\mathcal{L}_c(\alpha_\theta,\beta) = \min_{\gamma\in\mathcal{M}(\mathcal{Z}\times\mathcal{X})} \left\{ \int_{\mathcal{Z}\times\mathcal{X}} c(h_\theta(z),x)\mathrm{d}\gamma(z,x) \;:\; \gamma\in\mathcal{U}(\zeta,\beta) \right\}. \tag{9.37}$$

在此处的半离散情形，待最小化目标实际上可分解为

$$\min_{(\gamma_i)_{i=1}^n} \sum_{i=1}^n \int_{\mathcal{Z}} c(h_\theta(z), x_i) \mathrm{d}\gamma_i(z) \quad \text{其中} \quad \sum_{i=1}^n \gamma_i = \zeta, \quad \int_{\mathcal{Z}} \mathrm{d}\gamma_i(z) = \frac{1}{n}, \tag{9.38}$$

其中各 $\gamma_i \in \mathcal{M}_+^1(\mathcal{Z})$.

取得式 (9.38) 的最优解 $(\gamma_{\theta,i})_i$ 后，$\mathcal{E}(\theta)$ 的梯度计算为

$$\nabla \mathcal{E}(\theta) = \sum_{i=1}^n \int_{\mathcal{Z}} [\partial h_\theta(z)]^\top \nabla_1 c(h_\theta(z), x_i) \mathrm{d}\gamma_i(z),$$

其中 $\nabla_1 c(x, y) \in \mathbb{R}^d$ 为 $x \mapsto c(x, y)$ 的梯度. 与式 (9.36) 不同，该公式不涉及计算 OT 对偶问题最优势的梯度.

使用 $\mathcal{L} = \mathcal{L}_c$ 得到的估计器通常称为最小 Kantorovich 估计器 (minimum Kantorovich estimator)，最初由 (Bassetti et al., 2006) 引入，另见 (Canas and Rosasco, 2012). 在生成模型中，文献 (Montavon et al., 2016) 用它训练受限 Boltzmann 机，文献 (Bernton et al., 2017) 将它与近似 Bayesian 计算结合. 借助深度网络近似这些计算，可训练 GAN (Arjovsky et al., 2017) 和 VAE (Bousquet et al., 2017) 两类深度生成模型，另见 (Genevay et al., 2018, 2017; Salimans et al., 2018). 以 Sinkhorn 散度作参数模型拟合，已常用于形状匹配和配准，见 (Gold et al., 1998; Chui and Rangarajan, 2000; Myronenko and Song, 2010; Feydy et al., 2017).

注 9.14 (度量学习与迁移学习). 强调一点：在机器学习应用中，OT 相关方法是否成功，很大程度取决于能否选择适当费用 $c(x, y)$ 来捕捉数据几何.

虽然多种数据均可嵌入欧氏空间，例如词嵌入 (Mikolov et al., 2013)，但许多情形仍须对度量作某种适配或优化.

监督任务中的度量学习是经典问题，例如 (Kulis, 2012; Weinberger and Saul, 2009). 当学习流程使用某种 OT 距离时，已将其推广到基础度量 $c(x, y)$ 的学习 (Cuturi and Avis, 2014)，另见 Zen et al. 2014; Wang and Guibas 2012; Huang et al. 2016.

还有一个相关逆问题：从最优耦合 $\mathbf{P}$ 的观测学习代价矩阵，可用低秩先验正则化 (Dupuy et al., 2016).

相关问题包括迁移学习 (Pan and Yang, 2010) 和域适应 (Glorot et al., 2011)，即将已经训练的机器学习流程迁移，使其适配新数据集. 可用 OT 技术建模并求解这一问题，见 (Courty et al., 2017b,a).

Chapter 10

最优传输的扩展

本章详述与最优传输 Kantorovich 形式相关且具有相同结构的若干变分问题，旨在将最优传输扩展到更一般的情形：多个输入直方图和测度、未归一化的测度、更一般的测度类别，以及注重局部规律（源测度中邻近的点应映到目标测度中邻近的点）而非总传输代价的测度间最优传输，包括两个测度位于不同度量空间的情形.

10.1 多边缘问题

除了用 Kantorovich 形式 (2.11)耦合两个输入直方图，还可求解以下多边缘问题 (multimarginal problem)，耦合 S 个直方图 $(\mathbf{a}_s)_{s=1}^S$，其中 $\mathbf{a}_s \in \Sigma_{n_s}$：

$$\min_{\mathbf{P}\in\mathbf{U}(\mathbf{a}_s)_s} \langle \mathbf{C}, \mathbf{P}\rangle \overset{\text{def.}}{=} \sum_s \sum_{i_s=1}^{n_s} \mathbf{C}_{i_1,\ldots,i_S}\mathbf{P}_{i_1,\ldots,i_S}, \tag{10.1}$$

其中有效耦合的集合为

$$\mathbf{U}(\mathbf{a}_s)_s = \left\{ \mathbf{P}\in\mathbb{R}^{n_1\times\ldots\times n_S} \;:\; \forall\, s, \forall\, i_s, \sum_{\ell\neq s}\sum_{i_\ell=1}^{n_\ell} \mathbf{P}_{i_1,\ldots,i_S} = \mathbf{a}_{s,i_s} \right\}.$$

熵正则化方法 (4.2)自然扩展到此情形：

$$\min_{\mathbf{P}\in\mathbf{U}(\mathbf{a}_s)_s} \langle \mathbf{P}, \mathbf{C}\rangle - \varepsilon \mathbf{H}(\mathbf{P}),$$

随后可用 Sinkhorn 算法计算缩放形式的最优 $\mathbf{P}$，其分量以多重指标向量 $i=(i_1,\ldots,i_S)$ 索引，写为

$$\mathbf{P}_i = \mathbf{K}_i \prod_{s=1}^S \mathbf{u}_{s,i_s} \quad \text{其中} \quad \mathbf{K} \overset{\text{def.}}{=} e^{-\frac{\mathbf{C}}{\varepsilon}},$$

其中 $\mathbf{u}_s \in \mathbb{R}_+^{n_s}$ 为（未知的）缩放向量，反复循环 $s=1,\ldots,S$，通过以下迭代更新：

$$\mathbf{u}_{s,i_s} \leftarrow \frac{\mathbf{a}_{s,i_s}}{\sum_{\ell\neq s}\sum_{i_\ell=1}^{n_\ell} \mathbf{K}_i \prod_{r\neq s} \mathbf{u}_{\ell,i_r}} \tag{10.2}$$

.

注 10.1 (一般测度)**.** 离散多边缘问题 (10.1)可推广到空间 $(\mathcal{X}_1,\ldots,\mathcal{X}_S)$ 上的测度 $(\alpha_s)_s$，求解耦合测度

$$\min_{\pi\in\mathcal{U}(\alpha_s)_s} \int_{\mathcal{X}_1\times\ldots\times\mathcal{X}_S} c(x_1,\ldots,x_S)\mathrm{d}\pi(x_1,\ldots,x_S), \tag{10.3}$$

其中耦合集合为

$$\mathcal{U}(\alpha_s)_s \stackrel{\text{def.}}{=} \{\pi \in \mathcal{M}_+^1(\mathcal{X}_1 \times \ldots \times \mathcal{X}_S) \;:\; \forall s = 1, \ldots, S, P_{s,\sharp}\pi = \alpha_s, \}$$

$P_s : \mathcal{X}_1 \times \ldots \times \mathcal{X}_S \to \mathcal{X}_s$ 是到第 s 个分量的投影，$P_s(x_1, \ldots, x_S) = x_s$；例如见 (Gangbo and Swiech, 1998). 多边缘最优传输主要性质的综述见 (Pass, 2015, 2012). 多边缘最优传输的典型应用是近似求解量子化学问题，特别是密度泛函理论中的问题 (Cotar et al., 2013; Gori-Giorgi et al., 2009; Buttazzo et al., 2012). 考虑具有奇性的 Coulomb 相互作用代价便得到此问题：

$$c(x_1, \ldots, x_S) = \sum_{i \neq j} \frac{1}{\|x_i - x_j\|}.$$

注 10.2 (重心的多边缘形式). 线性规划优化 (9.11)可改写为对 $\mathcal{X}^{S+1}$ 上单个耦合的优化，其中最后一个边缘是重心，其余边缘是输入测度 $(\alpha_s)_{s=1}^S$：

$$\min_{\bar{\pi} \in \mathcal{M}_+^1(X^{S+1})} \int_{\mathcal{X}^{S+1}} \sum_{s=1}^{S} \lambda_s c(x, x_s) \mathrm{d}\bar{\pi}(x_1, \ldots, x_s, x) \tag{10.4}$$

$$\text{约束为} \quad \forall s = 1, \ldots, S, \quad P_{s,\sharp}\bar{\pi} = \alpha_s.$$

这来自“粘合引理”：给定耦合 $(\pi_s)_{s=1}^S$，其中 $\pi_s \in \mathcal{U}(\alpha_s, \alpha)$，可以构造高维耦合 $\bar{\pi} \in \mathcal{M}_+^1(X^{S+1})$，其相应边缘为 π_s，即 $Q_{s\sharp}\bar{\pi} = \pi_s$，其中 $Q_s(x_1, \ldots, x_S, x) \stackrel{\text{def.}}{=} (x_s, x) \in \mathcal{X}^2$. 在 (10.4)中对最后一个边缘（对应 $x \in \mathcal{X}$）显式最小化，得到重心问题 (9.11)的解 α 可计算为 $\alpha = A_{\lambda,\sharp}\pi$，其中“重心映射” A_λ 定义为

$$A_\lambda : (x_1, \ldots, x_S) \in \mathcal{X}^S \mapsto \operatorname*{argmin}_{x \in \mathcal{X}} \sum_s \lambda_s c(x, x_s)$$

（假设此映射单值），而 π 是多边缘问题 (10.3)在以下代价下的任意解：

$$c(x_1, \ldots, x_S) = \sum_\ell \lambda_\ell c(x_\ell, A_\lambda(x_1, \ldots, x_S)). \tag{10.5}$$

例如，对于 $c(x, y) = \|x - y\|^2$，去掉恒定的平方项后得到

$$c(x_1, \ldots, x_S) = -\sum_{r \leq s} \lambda_r \lambda_s \langle x_r, x_s \rangle,$$

这正是 Gangbo and Swiech (1998) 研究的问题. 更多细节见 Agueh and Carlier (2011). 此公式表明，若所有输入测度都离散，$\beta_s = \sum_{i_s=1}^{n_s} \mathbf{a}_{s,i_s} \delta_{x_{s,i_s}}$，则重心 α 也离

散，由下式给出：

$$\alpha = \sum_{(i_1,\dots,i_S)} \mathbf{P}_{(i_1,\dots,i_S)} \delta_{A_\lambda(x_{i_1},\dots,x_{i_S})},$$

其中 $\mathbf{P}$ 为 (10.1)的最优解，代价矩阵 $\mathbf{C}_{i_1,\dots,i_S} = c(x_{i_1},\dots,x_{i_S})$ 中的代价按 (10.5)定义. $\mathbf{P}$ 是维数为 $\prod_s n_s$ 的非负张量，由具有 $\sum_s n_s - S + 1$ 个等式约束的线性规划求得，故可选取至多有 $\sum_s n_s - S + 1$ 个非零分量的最优解 $\mathbf{P}$. 因而可得到支撑至多含 $\sum_s n_s - S + 1$ 个点的重心 α. 此结果及离散情形的其他讨论见 Anderes et al. (2016).

注 10.3 (Euler 方程的松弛). Brenier (1990、1993、1999、2008) 及 (Ambrosio and Figalli, 2009) 提出了不可压缩流体动力学 Euler 方程的凸松弛. 与第 7.6节的情形类似，此问题是在所有路径 $\gamma : [0,1] \to \mathcal{X}$ 组成的集合 $\bar{\mathcal{X}}$ 上寻找概率分布 $\bar{\pi} \in \mathcal{M}_+^1(\bar{\mathcal{X}})$，以描述流体中粒子的运动. 这是原始偏微分方程模型的松弛版本，因为如同最优传输的 Kantorovich 形式，质量可以分裂. 随时间的演化不必在基础空间 $\mathcal{X}$ 上定义微分同胚. 如 (7.17)，通过最小化每条路径的能量 $\int_0^1 \|\gamma'(t)\|^2 \,\mathrm{d}t$ 得到流体动力学. 与路径空间上的最优传输不同，此处还要求流体不可压缩. 为实现不可压缩性，要求粒子密度在任意时刻 $t \in [0,1]$ 都均匀（而不是像经典最优传输那样只在初始、最终时刻 $t \in \{0,1\}$ 施加此条件）. 假设 $\mathcal{X}$ 紧，记 $\rho_{\mathcal{X}}$ 为 $\mathcal{X}$ 上的均匀分布，则条件写为 $\bar{P}_{t,\sharp}\bar{\pi} = \rho_{\mathcal{X}}$，其中 $\bar{P}_t : \gamma \in \bar{\mathcal{X}} \to \gamma(t) \in \mathcal{X}$. 可将连续路径 $(\gamma(t))_{t\in[0,1]}$ 替换为网格 $(x_k)_{k=1}^n \subset \mathcal{X}$ 上的 S 点序列 $(x_{i_1}, x_{i_2}, \dots, x_{i_S})$，从而离散此问题. $\bar{\Pi}$ 用 S 阶耦合 $\mathbf{P} \in \mathbb{R}^{n^S} \in \mathcal{U}(\mathbf{a}_s)_s$ 表示，边缘均匀，$\mathbf{a}_s = n^{-1}\mathbb{1}_n$. 相应多边缘问题的代价为

$$\mathbf{C}_{i_1,\dots,i_S} = \sum_{s=1}^{S-1} \|x_{i_s} - x_{i_{s+1}}\|^2 + R\,\|x_{\sigma(i_1)} - x_{i_S}\|^2. \tag{10.6}$$

这里 R 是足够大的惩罚常数，用于强制初始、最终时刻之间的粒子运动满足给定置换 $\sigma : [\![n]\!] \to [\![n]\!]$. 利用代价的特殊结构，将所得多边缘问题与 Sinkhorn 迭代 (10.2)结合，可以高效实现；详见 (Benamou et al., 2015). 事实上，(10.2)分母的计算本来需要 $O(n^S)$ 次运算，但可分解为连续 S 次矩阵与向量相乘，将代价降为 Sn^2. 还存在其他求解器，例如使用第 5.2节中的半离散框架；见 (de Goes et al., 2015; Gallouët and Mérigot, 2017).

10.2 非平衡最优传输

通常形式的最优传输有一个主要障碍：要求两个输入测度 (α, β) 的总质量相同. 虽然已有许多变通方法（包括重新归一化输入测度，或使用第 8.2节详述的对偶范数），直到近期才发展出令人满意的统一理论. 这里仅概述一个简单但重要的特例.

沿用 Liero et al. (2018)，为了处理任意正直方图 $(\mathbf{a}, \mathbf{b}) \in \mathbb{R}_+^n \times \mathbb{R}_+^m$，用 (8.3)定义的散度 $\mathbf{D}_\varphi$ 仅惩罚边缘偏差，从而“松弛”原始 Kantorovich 形式 (2.11). 等价地，这是最

小化近似测度之间的最优传输距离：

$$\mathrm{L}_{\mathbf{C}}^{\tau}(\mathbf{a},\mathbf{b}) = \min_{\tilde{\mathbf{a}},\tilde{\mathbf{b}}} \mathrm{L}_{\mathbf{C}}(\mathbf{a},\mathbf{b}) + \tau_1 \mathbf{D}_{\varphi}(\mathbf{a},\tilde{\mathbf{a}}) + \tau_2 \mathbf{D}_{\varphi}(\mathbf{b},\tilde{\mathbf{b}}) \tag{10.7}$$

$$= \min_{\mathbf{P}\in\mathbb{R}_+^{n\times m}} \langle \mathbf{C}, \mathbf{P}\rangle + \tau_1 \mathbf{D}_{\varphi}(\mathbf{P}\mathbb{1}_m|\mathbf{a}) + \tau_2 \mathbf{D}_{\varphi}(\mathbf{P}^{\top}\mathbb{1}_m|\mathbf{b}), \tag{10.8}$$

其中 (τ_1,τ_2) 控制质量变化相对于质量传输的惩罚强度. 在 $\tau_1=\tau_2\to+\infty$ 的极限下，若 $\sum_i \mathbf{a}_i = \sum_j \mathbf{b}_j$ （“平衡”情形），便恢复具有硬边缘约束的原始最优传输形式 (2.11).

此框架涵盖许多此前的工作，例如取 $\mathbf{D}_{\varphi}$ 为 ℓ^2 范数 (Benamou, 2003)，或部分传输中使用的 ℓ^1 范数 (Figalli, 2010; Caffarelli and McCann, 2010). 特别重要的情形是取 $\mathbf{D}_{\varphi}=\mathbf{KL}$，即 Kullback–Leibler 散度，详见注 10.5. 对于此代价，在 $\tau=\tau_1=\tau_2\to 0$ 的极限下，得到所谓平方 Hellinger 距离（另见例 8.1.3）：

$$\mathrm{L}_{\mathbf{C}}^{\tau}(\mathbf{a},\mathbf{b}) \overset{\tau\to 0}{\longrightarrow} \mathfrak{h}^2(\mathbf{a},\mathbf{b}) = \sum_i (\sqrt{\mathbf{a}_i}-\sqrt{\mathbf{b}_i})^2.$$

利用第 4.6节详述的广义算法，可将 Sinkhorn 迭代 (4.15)改用于此问题. 解具有 (4.12)的形式，缩放变量更新为

$$\mathbf{u} \leftarrow \left(\frac{\mathbf{a}}{\mathbf{K}\mathbf{v}}\right)^{\frac{\tau_1}{\tau_1+\varepsilon}} \quad \text{且} \quad \mathbf{v} \leftarrow \left(\frac{\mathbf{b}}{\mathbf{K}^{\mathrm{T}}\mathbf{u}}\right)^{\frac{\tau_2}{\tau_2+\varepsilon}}. \tag{10.9}$$

注 10.4 (一般测度)**.** 对任意两个测度 (α,β)，(2.15)的非平衡形式（也称“对数熵”形式）为

$$\mathcal{L}_c^{\tau}(\alpha,\beta) \overset{\text{def.}}{=} \min_{\pi\in\mathcal{M}_+(\mathcal{X}\times\mathcal{Y})} \int_{\mathcal{X}\times\mathcal{Y}} c(x,y)\mathrm{d}\pi(x,y) + \tau\mathcal{D}_{\varphi}(P_{1,\sharp}\pi|\alpha) + \tau\mathcal{D}_{\varphi}(P_{2,\sharp}\pi|\beta),$$

其中测度之间的散度 $\mathcal{D}_{\varphi}$ 定义见 (8.1). 在特殊情形 $c(x,y)=\|x-y\|^2$、$\mathcal{D}_{\varphi}=\mathrm{KL}$ 下，$\mathcal{L}_c^{\tau}(\alpha,\beta)^{1/2}$ 是Gaussian–Hellinger 距离（Gaussian–Hellinger distance）(Liero et al., 2018)，且已证明它是 $\mathcal{M}_+^1(\mathbb{R}^d)$ 上的距离.

注 10.5 (Wasserstein–Fisher–Rao)**.** 特别地，选取代价

$$c(x,y) = -\log\cos(\min(d(x,y)/\kappa,\pi/2)),$$

其中 κ 为截断距离，并使用 $\mathcal{D}_{\varphi}=\mathrm{KL}$，则

$$\mathrm{WFR}(\alpha,\beta) \overset{\text{def.}}{=} \mathcal{L}_c^{\tau}(\alpha,\beta)^{\frac{1}{2}}$$

是所谓Wasserstein–Fisher–Rao 距离（Wasserstein–Fisher–Rao distance）或 Hellinger–Kantorovich 距离. 在特殊情形 $\mathcal{X}=\mathbb{R}^d$ 中，此静态（类似 Kantorovich

的）形式与动态形式 (7.15)一致，这由 Liero et al. (2018); Chizat et al. (2018a) 独立证明. 动态形式详见第 7.4节.

将 $\mathcal{L}_c$ 替换为 $\mathcal{L}_c^\tau$，便可把重心问题 (9.11)推广到非平衡情形. 图 10.1展示所得插值，清楚说明松弛参数 τ 的作用. 输入测度是质量不等的两个 Gaussian 混合. 经典最优传输迫使最左边的峰分裂为两个峰，造成不规则插值. 相比之下，非平衡最优传输允许插值过程中质量变化，因此峰不分裂，分布的局部模态得以光滑匹配. 因此，取有限 τ（回忆最优传输对应于 $\tau = \infty$）有助于避免质量分裂造成的不规则插值；质量分裂源自“硬”质量守恒约束. 所得优化问题可用熵正则化与第 4.6节详述的广义 Sinkhorn 算法数值求解.

实际中，若输入数据含噪或未完全已知，非平衡最优传输似乎比经典最优传输更适合成像、机器学习等应用. 当必须考虑以测度总质量衡量的信号强度，或者归一化没有意义时，它们也很关键. 这正是 Frogner et al. (2015) 的最初动机，其目标是比较描述图像的词标签集合. 非平衡最优传输及相应 Sinkhorn 迭代也已用于细胞动力学 (Schiebinger et al., 2017).

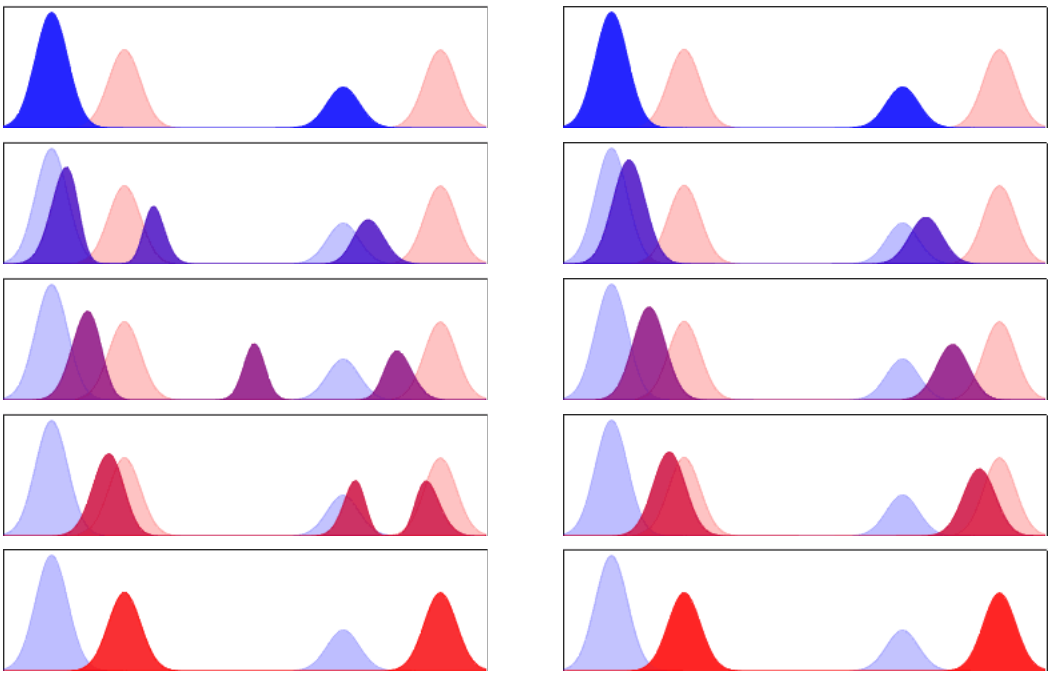

经典最优传输（$\tau = +\infty$）　　非平衡最优传输（$\tau = 1$）

图 10.1: 松弛参数 τ 对非平衡重心的影响. 从上到下：两个输入测度之间重心的演变.

注 10.6 (与对偶范数的关系). 处理质量变化的一种特别简单的办法是使用对偶范数，详见第 8.2节. 选取紧集 $B \subset \mathcal{C}(\mathcal{X})$，得到定义在整个空间 $\mathcal{M}(\mathcal{X})$ 上的范数（特别地，测度不必为正）. 具体例子是平坦范数 (8.11)：取 $\mathcal{D}_\varphi(\alpha|\alpha') = \|\alpha - \alpha'\|_{\mathrm{TV}}$ 为全变差范数 (8.9)，便得到非平衡传输的这一特例；例如见 (Hanin, 1992; Lellmann et al., 2014). 定义 Wasserstein-1 非平衡传输的一般框架另见 (Schmitzer and Wirth, 2017).

10.3 对耦合施加额外约束的问题

文献中还有许多类似最优传输的问题，通常是在原始最优传输问题 (2.15)的可行耦合集合上添加额外约束 $\mathcal{C}$：

$$\min_{\pi\in\mathcal{U}(\alpha,\beta)} \left\{ \int_{\mathcal{X}\times\mathcal{Y}} c(x,y)\mathrm{d}\pi(x,y) \;:\; \pi\in\mathcal{C} \right\}. \tag{10.10}$$

下面给出两个典型例子. 具有容量约束的最优传输 (Korman and McCann, 2015) 要求密度 ρ_π（例如关于 Lebesgue 测度）有上界：

$$\mathcal{C} = \{\pi \;:\; \rho_\pi \leq \kappa\} \tag{10.11}$$

其中 $\kappa > 0$. 此约束排除集中在 Monge 映射上的奇异耦合. 鞅传输（martingale transport）问题（例如 Galichon et al. (2014); Dolinsky and Soner (2014); Tan and Touzi (2013); Beiglböck et al. (2013)）在金融中有许多应用. 当 $\mathcal{X}=\mathcal{Y}=\mathbb{R}^d$ 时，它对耦合的条件均值施加所谓鞅约束：

$$\mathcal{C} = \left\{ \pi \;:\; \forall x\in\mathbb{R}^d, \int_{\mathbb{R}^d} y \frac{\mathrm{d}\pi(x,y)}{\mathrm{d}\alpha(x)\mathrm{d}\beta(y)}\mathrm{d}\beta(y) = x \right\}. \tag{10.12}$$

此约束要求任意容许耦合的重心投影映射 (4.20)等于恒等映射. 对于任意 (α,β)，此集合 $\mathcal{C}$ 通常为空；但存在必要充分条件（α,β 应满足“凸序”），保证 $\mathcal{C}\neq\emptyset$，从而 (α,β) 可满足鞅约束. 离散已有问题时，此约束可能难以数值实现. 它还禁止解集中在单个 Monge 映射上，并可能导致耦合集中在多个图像的并（“多值” Monge 映射）上，甚至更复杂的支撑集上. 如 (4.9)加入熵惩罚，可用 Benamou et al. (2015) 介绍的 Dykstra 算法近似求解 (10.10)，这是第 4.2节 Sinkhorn 算法的推广. 此时需要计算 KL 散度下到 $\mathcal{C}$ 的投影，对 (10.11)而言很直接，但对 (10.12)没有闭式解，因此需要内部迭代；详见 (Guo and Obloj, 2017).

10.4 切片 Wasserstein 距离与重心

对定义在 $\mathbb{R}^d$ 上的两个测度 (α,β)，可以汇总它们在球面各方向投影之间的一维 Wasserstein 距离来定义距离，得到*切片 Wasserstein 距离* (sliced Wasserstein distance)：

$$\mathrm{SW}(\alpha,\beta)^2 \overset{\text{def.}}{=} \int_{\mathbf{S}^d} \mathcal{W}_2(P_{\theta,\sharp}\alpha, P_{\theta,\sharp}\beta)^2\mathrm{d}\theta, \tag{10.13}$$

其中 $\mathbf{S}^d = \{\theta\in\mathbb{R}^d \;:\; \|\theta\|=1\}$ 是 d 维球面，$P_\theta : x\in\mathbb{R}^d \to \mathbb{R}$ 是投影. 此方法遵循 Marc Bernot 的思想，详见 (Bonneel et al., 2015). 它与测度空间上的 Radon 反演问题有关 (Abraham et al., 2017).

Lagrange 离散化与随机梯度下降. 这一泛函的优势是一维 Wasserstein 距离计算简单，见第 2.6节. 特别地，当 $m=n$ 且

$$\alpha = \frac{1}{n}\sum_{i=1}^n \delta_{x_i} \quad \text{且} \quad \beta = \frac{1}{n}\sum_{i=1}^m \delta_{y_i}, \tag{10.14}$$

只需对点排序即可计算：

$$\mathrm{SW}(\alpha,\beta)^2 = \int_{\mathbf{S}^d} \left(\sum_{i=1}^{n} |\langle x_{\sigma_\theta(i)} - y_{\kappa_\theta(i)},\, \theta\rangle|^2 \right) \mathrm{d}\theta,$$

其中 $\sigma_\theta, \kappa_\theta \in \mathrm{Perm}(n)$ 是分别将 $(\langle x_i,\, \theta\rangle)_i$ 和 $(\langle y_i,\, \theta\rangle)_i$ 按升序排列的置换.

固定向量 y，函数 $\mathcal{E}_\beta(x) \overset{\text{def.}}{=} \mathrm{SW}(\alpha,\beta)^2$ 光滑，可用它通过梯度下降定义映射：

$$x \leftarrow x - \tau \nabla \mathcal{E}_\beta(x) \quad \text{其中} \tag{10.15}$$

$$\nabla \mathcal{E}_\beta(x)_i = 2 \int_{\mathbf{S}^d} \Big(\langle x_i - y_{\kappa_\theta \circ \sigma_\theta^{-1}(i)},\, \theta\rangle \theta \Big)\, \mathrm{d}\theta$$

其中步长 $\tau > 0$ 足够小. 为使计算可行，可使用随机梯度下降（SGD），将积分替换为对随机抽取方向 $\theta \in \mathbf{S}^d$ 的离散求和（SGD 的更多细节见第 5.4节）. 流 (10.15)可理解为函数 $\alpha \mapsto \mathrm{SW}(\alpha,\beta)^2$ 的 Wasserstein 梯度流的 Lagrange 实现（梯度流的意义见第 9.3节）. 数值上发现，此流没有局部极小点，因此收敛到 $\alpha = \beta$. Lagrange 求解器的作用在于，它在收敛时定义两个分布之间的匹配（类似 Monge 映射）. 此方法已成功用于颜色迁移和纹理合成 (Rabin et al., 2011)，并与 (Pitié et al., 2007) 中的交替最小化方法有关.

模仿 Wasserstein 重心的 Fréchet 定义 (9.11)，此 Lagrange 方法容易扩展为计算测度的近似 “切片” 重心，只需最小化

$$\min_{\alpha \in \mathcal{M}_+^1(\mathcal{X})} \sum_{s=1}^{S} \lambda_s \,\mathrm{SW}(\alpha,\beta_s)^2, \tag{10.16}$$

其中 $(\beta_s)_{s=1}^S$ 为固定输入测度. 对 α 和 $(\beta_s)_s$ 都采用 (10.14)形式的 Lagrange 离散化，可对位置 $x = (x_i)_i$ 作非凸最小化：

$$\min_x \mathcal{E}(x) \overset{\text{def.}}{=} \sum_s \lambda_s \mathcal{E}_{\beta_s}(x), \quad \text{且} \quad \nabla \mathcal{E}(x) = \sum_s \lambda_s \nabla \mathcal{E}_{\beta_s}(x), \tag{10.17}$$

用梯度下降求解，并以 (10.15)计算 $\nabla \mathcal{E}_{\beta_s}(x)$（同时随机采样方向 θ）.

Euler 离散化与 Radon 变换. 另一种相关的近似切片重心计算方法无须迭代最小化. 它利用 (10.13)是在 Radon 变换 $\mathcal{R}(\alpha), \mathcal{R}(\beta)$ 之间计算距离这一事实，其中

$$\mathcal{R}(\alpha) \overset{\text{def.}}{=} (P_{\theta,\sharp}\alpha)_{\theta \in \mathbf{S}^d}.$$

关键在于 Radon 变换可逆，其逆可用滤波反投影公式计算. 给定测度族 $\rho = (\rho_\theta)_{\theta \in \mathbf{S}^d}$，定义滤波反投影（filtered backprojection）算子为

$$\mathcal{R}^+(\rho) = C_d \Delta^{\frac{d-1}{2}} \mathcal{B}(\rho), \tag{10.18}$$

其中测度 $\xi = \mathcal{B}(\rho) \in \mathcal{M}(\mathbb{R}^d)$ 由以下关系定义：

$$\forall\, g \in \mathcal{C}(\mathbb{R}^d), \quad \int_{\mathbb{R}^d} g(x)\mathrm{d}\xi(x) = \int_{\mathbf{S}^d} \int_{\mathbb{R}^{d-1}} \int_{\mathbb{R}} g(r\theta + U_\theta z)\mathrm{d}\rho_\theta(r)\mathrm{d}z\mathrm{d}\theta, \tag{10.19}$$

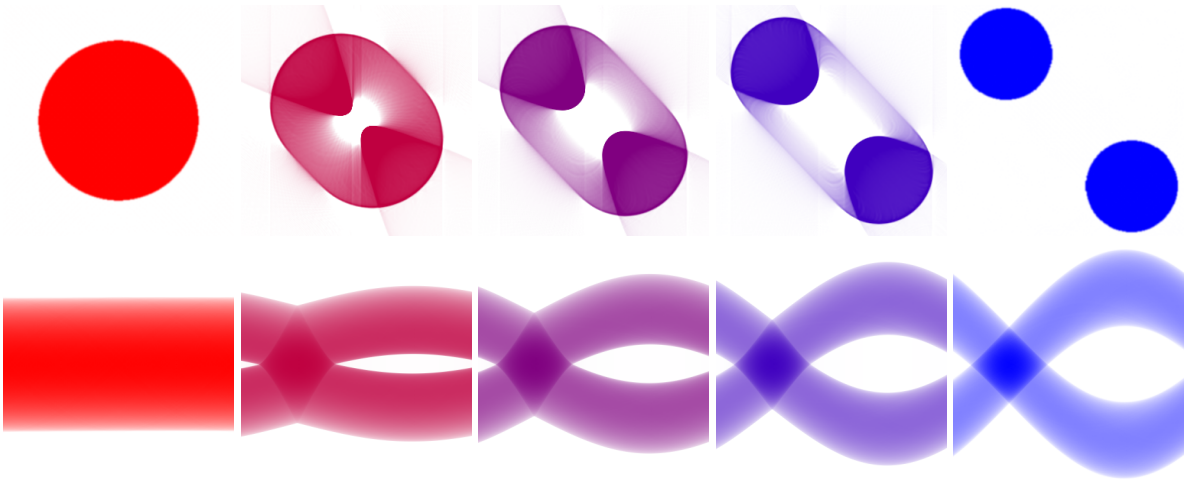

$t=0$ $t=1/4$ $t=1/2$ $t=3/4$ $t=1$

图 10.2: 使用 Radon 变换计算切片重心的例子（按 (10.20)定义）. 上: $S=2$ 个输入和权重 $(\lambda_1,\lambda_2)=(1-t,t)$ 对应的重心 α_t. 下: 它们的 Radon 变换 $\mathcal{R}(\alpha_t)$（横轴为方向角 θ）.

这里 U_θ 是 $\theta^\perp$ 的任意正交基, $C_d\in\mathbb{R}$ 是依赖维数的归一化常数. $\Delta^{\frac{d-1}{2}}$ 是分数阶 Laplace 算子, 即在 Fourier 域中按下式定义的高通滤波器: $\hat{\Delta}^{\frac{d-1}{2}}(\omega)=\|\omega\|^{d-1}$. 反投影 (10.19)将每个 ρ_θ 沿垂直于 θ 的方向常值延拓，再汇总所有测度 $(\rho_\theta)_\theta$ 的贡献. 由此有左逆关系 $\mathcal{R}^+\circ\mathcal{R}=\mathbb{I}_{\mathcal{M}(\mathbb{R}^d)}$，故 $\mathcal{R}^+$ 是有效的重构公式.

为计算输入密度的重心，可以用其 Radon 变换下的等价表达替换 (9.11)，从而对各 θ 分别考虑一维重心问题:

$$\rho_\theta^\star\in\operatorname*{argmin}_{(\rho_\theta\in\mathcal{M}_+^1(\mathbb{R}))}\sum_{s=1}^{S}\lambda_s\,\mathcal{W}_2(\rho_\theta,P_{\theta,\sharp}\beta_s)^2. \tag{10.20}$$

每个一维重心问题都可通过单调重排容易地计算，见注 9.6. 随后通过逆 Radon 变换 $\mathcal{R}^+$，得到求解 (9.11)的切片重心的 Radon 近似 $\alpha_R\overset{\text{def.}}{=}\mathcal{R}^+(\rho^\star)$. 一般而言，$\alpha_R$ 不是 (9.11)的解，因为 Radon 变换不满射；作为 Radon 变换 $\mathcal{R}(\beta_s)$ 的重心得到的 $\rho^\star$，不必属于 $\mathcal{R}$ 的像. 不过，实际数值上它似乎几乎属于该像 (Bonneel et al., 2015). 数值上，对于离散在固定网格上的输入测度和重心（例如图像的均匀网格），此 Radon 变换形式非常有效. $\mathcal{R}$ 和 $\mathcal{R}^+$ 可在该网格上用快速算法近似计算（例如 (Averbuch et al., 2001)）. 图 10.2展示这种重心计算（突出说明 Radon 变换的插值方式），图 10.3则比较 Radon 重心 (10.20)与 Lagrange 离散化 (10.17)所得的重心.

切片 Wasserstein 核. 除了计算简单，切片 Wasserstein 距离还与 Euclidean 距离等距（因而是 “Hilbert 型” 度量），如注 2.30，特别是 (2.36)所述. 如第 8.3节所强调，这与 $\mathbb{R}^d$ 上的 Wasserstein 距离 $\mathcal{W}_2$ 不同；后者在 $d\geq 2$ 时不是 Hilbert 型的. 因此可用切片距离赋予分布空间 $\mathcal{M}_1^+(\mathbb{R}^d)$ 一个再生核 Hilbert 空间结构（详见第 8.3节）. 例如，可使用指数核和能量距离核

$$k(\alpha,\beta)=e^{-\frac{\mathrm{SW}(\alpha,\beta)^p}{2\sigma^p}}\quad\text{且}\quad k(\alpha,\beta)=-\mathrm{SW}(\alpha,\beta)^p$$

图 10.3: 用 Radon 变换 (10.20)(Euler 离散化)、Lagrange 离散化 (10.17)及 Wasserstein 最优传输（用 Sinkhorn 迭代 (9.18)计算）得到的重心比较.

其中指数核取 $1 \leq p \leq 2$，能量距离核取 $0 < p < 2$. 这意味着，对于任意输入测度族 $(\alpha_i)_i$，矩阵 $(k(\alpha_i, \alpha_j))_{i,j}$ 都对称半正定. 通过“核技巧”，可用这些核完成各种机器学习任务，例如回归、分类（SVM 和逻辑回归）、聚类（K-means）及降维（PCA）(Hofmann et al., 2008). 细节和应用见 Kolouri et al. (2016).

10.5 向量与矩阵的传输

实值测度 $\alpha \in \mathcal{M}(\mathcal{X})$ 容易推广为向量值测度(vector-valued measure) $\alpha \in \mathcal{M}(\mathcal{X}; \mathbb{V})$，其中 $\mathbb{V}$ 是向量空间. 为简化记号，假设 $\mathbb{V}$ 是赋有内积 $\langle \cdot, \cdot \rangle$ 的 Euclidean 空间（典型地 $\mathbb{V} = \mathbb{R}^d$，内积为标准内积）. 借助该内积，可将向量值测度等同于连续函数 $g : \mathcal{X} \to \mathbb{V}$ 的对偶；即对任意这样的 g，定义它关于测度的积分为

$$\int_{\mathcal{X}} g(x) \mathrm{d}\alpha(x) \in \mathbb{R}, \tag{10.21}$$

这关于 g, α 都是线性操作. 离散测度形如 $\alpha = \sum_i \mathbf{a}_i \delta_{x_i}$，其中 $(x_i, a_i) \in \mathcal{X} \times \mathbb{V}$，积分公式 (10.21)简化为

$$\int_{\mathcal{X}} g(x) \mathrm{d}\alpha(x) = \sum_i \langle \mathbf{a}_i, g(x_i) \rangle \in \mathbb{R}.$$

等价地，若 $\mathbb{V} = \mathbb{R}^d$，则 α 可看成 d 个“经典”实值测度（其各坐标）组成的族 $(\alpha_s)_{s=1}^d$，写为

$$\int_{\mathcal{X}} g(x) \mathrm{d}\alpha(x) = \sum_{s=1}^{d} \int_{\mathcal{X}} g_s(x) \mathrm{d}\alpha_s(x),$$

其中 $g(x) = (g_s(x))_{s=1}^d$ 是 g 在标准基下的坐标.

对偶范数. 将最优传输距离扩展到如此一般的情形并不容易，事实上一般不可能. 即使处理可取正负值的实值测度也很困难. 唯一简单的选择是考虑第 8.2节定义的对偶范数. 取 B 为 $\mathcal{C}(\mathcal{X};\mathbb{V})$ 的子集， (6.3)便直接扩展到 $\mathcal{M}(\mathcal{X};\mathbb{V})$. 特别地，可以对向量值测度计算 $\mathcal{W}_1$、平坦范数和 MMD 范数.

锥值测度上的最优传输. 若将 α 限制在子集 $\mathcal{M}(\mathcal{X};\mathcal{V}) \subset \mathcal{M}(\mathcal{X};\mathbb{V})$ 中，可以定义更复杂的最优传输距离. 集合 $\mathcal{V}$ 应为 $\mathbb{V}$ 中正一齐次的凸锥：

$$\mathcal{V} \overset{\text{def.}}{=} \{\lambda u \;:\; \lambda \in \mathbb{R}^+, u \in \mathcal{V}_0,\}$$

其中 $\mathcal{V}_0$ 是紧凸集. 典型例子是正测度集合，此时 $\mathcal{V} = \mathbb{R}^d_+$. 已有人提出此锥上最优传输的动态凸形式；见 (Zinsl and Matthes, 2015). 它被用于化学组分分布的建模. 另一个重要例子是对称正矩阵集合 $\mathcal{V} = \mathcal{S}^d_+ \subset \mathbb{R}^{d\times d}$. 当然，可将矩阵视为向量，在此空间上使用对偶范数，例如 (Ning and Georgiou, 2014). 此锥上最优传输的动态凸形式见 (Chen et al., 2016b; Jiang et al., 2012). 也有静态（类似 Kantorovich 的）形式 (Ning et al., 2015; Peyré et al., 2017)，但仍缺乏数学上严谨的理论框架. 特别地，这些静态方法是否定义向量值测度上的距离，以及是否联系某种动态形式，尚不清楚. 图 10.4展示用 (Peyré et al., 2017) 的方法所得的张量插值；该方法利用量子相对熵 (10.22)推广 Sinkhorn 算法以处理张量场.

正矩阵上的最优传输. 另一个相关但很不同的情形，是用单位迹的正矩阵 $A \in \mathcal{S}^+_n$、$\operatorname{tr}(A) = 1$ 替换离散测度，即直方图 $\mathbf{a} \in \Sigma_n$. 其依据是 A 的特征值 $\lambda(A) \in \Sigma_n$ 扮演直方图的角色；但还必须处理特征向量的旋转，因此问题更复杂.

第 8.1节引入的若干散度可扩展到此情形. 例如 Bures 度量 (2.42)推广了 Hellinger 距离（见注 8.1.3的定义），因为二者在正对角矩阵上相等. Kullback–Leibler 散度 (4.6)（另见注 8.1.1）也可推广到正矩阵：

$$\mathbf{KL}(A|B) \overset{\text{def.}}{=} \operatorname{tr}\left(P\log(P) - P\log(Q) - P + Q,\right) \tag{10.22}$$

其中 $\log(\cdot)$ 是矩阵对数. 此矩阵 **KL** 关于两个自变量凸.

通过求解动态凸形式，可以定义此类矩阵之间的最优传输距离 (Carlen and Maas, 2014; Chen et al., 2016b, 2017). 还存在 Sinkhorn 算法的对应版本，由 Gurvits (2004) 提出，并在 (Georgiou and Pavon, 2015) 中得到深入研究；另见综述 (Idel, 2016). 目前仅在某些情形下知道它收敛，但经验上似乎总是有效.

10.6 Gromov–Wasserstein 距离

在形状匹配等应用中，最优传输距离的一个重要不足是，它对于缩放、平移、旋转等重要变换族不具有不变性. 虽然已有处理这类全局变换的最优传输非凸变体 (Cohen and Guibas, 1999; Pele and Taskar, 2013)，并在近期用于跨语言词嵌入对齐 (Grave et al., 2019; Alvarez-Melis et al., 2019; Grave et al., 2019)，但这些方法必须先指定有关的不变变换族，且可能涉及不同度量空间. 本节介绍一种更一般且十分自然的最优传输扩展，它可处理不同空间上的测度，无须定义不变变换族.

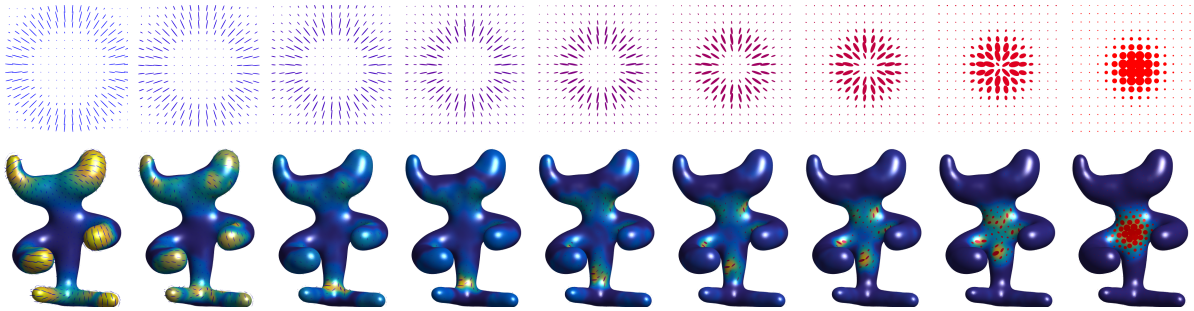

图 10.4: 用 Peyré et al. (2017) 的方法，在某区域（此处是二维平面正方形及曲面网格）上的两个半正定矩阵输入场之间插值（时刻 $t \in \{0,1\}$ 的输入以椭圆显示）. 与线性插值方法不同，这种类似最优传输的方法既传输张量的 “质量”（椭圆大小），也传输其各向异性与方向.

10.6.1 Hausdorff 距离

对于度量 $d_{\mathcal{Z}}$，两个集合 $A, B \subset \mathcal{Z}$ 之间的Hausdorff 距离（Hausdorff distance）为

$$\mathcal{H}_{\mathcal{Z}}(A,B) \overset{\text{def.}}{=} \max\Big(\sup_{a\in A}\inf_{b\in B} d_{\mathcal{Z}}(a,b), \sup_{b\in B}\inf_{a\in A} d_{\mathcal{Z}}(a,b)\Big),$$

见图 10.5. 这在 $\mathcal{Z}$ 的紧集空间 $\mathcal{K}(\mathcal{Z})$ 上定义距离；若 $\mathcal{Z}$ 紧，则 $(\mathcal{K}(\mathcal{Z}), \mathcal{H}_{\mathcal{Z}})$ 自身也紧；见 (Burago et al., 2001).

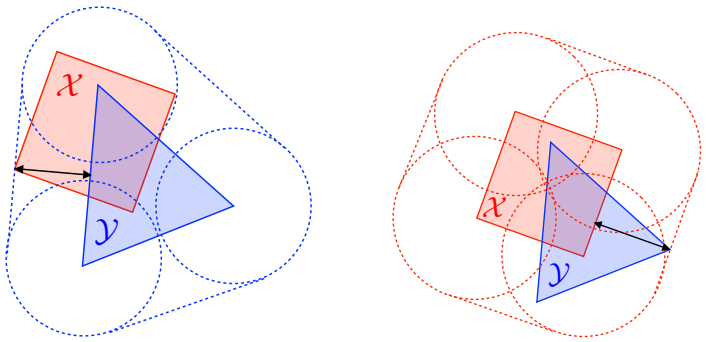

图 10.5: $\mathbb{R}^2$ 中 Hausdorff 距离的计算.

沿用 Mémoli (2011)，集合 (A,B) 之间的此距离可仿照测度之间的 Wasserstein 距离定义（测度可在某种意义上视为 “带权” 集合）. 将测度耦合 (2.14)替换为集合耦合

$$\mathcal{R}(A,B) \overset{\text{def.}}{=} \left\{ R \in \mathcal{X}\times\mathcal{Y} \;:\; \begin{array}{l} \forall\, a\in A, \exists b\in B, (a,b)\in R \\ \forall\, b\in B, \exists a\in A, (a,b)\in R \end{array} \right\}.$$

与 Kantorovich 问题 (2.15)相比，此处无测度，因而将积分替换为最大化，得到

$$\mathcal{H}_{\mathcal{Z}}(A,B) = \inf_{R\in\mathcal{R}(A,B)} \sup_{(a,b)\in R} d(a,b). \tag{10.23}$$

注意，测度耦合 $\pi \in \mathcal{U}(\alpha,\beta)$ 的支撑是两个支撑之间的集合耦合，即 $\mathrm{Supp}(\pi) \in \mathcal{R}(\mathrm{Supp}(\alpha),\mathrm{Supp}(\beta))$. 因此 Hausdorff 距离与 ∞-Wasserstein 距离有关（见注 2.20）；对支撑分别为 (A,B) 的任意测度 (α,β)，有 $\mathcal{H}(A,B) \leq \mathcal{W}_\infty(\alpha,\beta)$.

10.6.2 Gromov–Hausdorff 距离

Gromov–Hausdorff 距离（Gromov–Hausdorff distance）(GH)（Gromov, 2001）(另见 (Edwards, 1975)）通过量化两个度量空间 $(\mathcal{X},d_\mathcal{X}),(\mathcal{Y},d_\mathcal{Y})$ 距离相互等距有多远，来衡量它们之间的距离，见图 10.6. 它定义为将两个空间等距嵌入第三个空间的所有可能方式中，最小的 Hausdorff 距离：

$$\mathcal{GH}(d_\mathcal{X},d_\mathcal{Y}) \overset{\text{def.}}{=} \inf_{\mathcal{Z},f,g} \left\{ \mathcal{H}_\mathcal{Z}(f(\mathcal{X}),g(\mathcal{Y})) \ : \ \begin{array}{c} f:\mathcal{X} \overset{\text{isom}}{\longrightarrow} \mathcal{Z} \\ g:\mathcal{Y} \overset{\text{isom}}{\longrightarrow} \mathcal{Z} \end{array} \right\}.$$

这里要求 f 为等距嵌入，即任意 $(x,x') \in \mathcal{X}^2$ 满足 $d_\mathcal{Z}(f(x),f(x')) = d_\mathcal{X}(x,x')$（$g$ 类似）. 可证明，$\mathcal{GH}$ 在相差等距映射的紧度量空间等价类上定义距离. 特别地，$\mathcal{GH}(d_\mathcal{X},d_\mathcal{Y}) = 0$ 当且仅当存在等距映射 $h:\mathcal{X}\to\mathcal{Y}$，即 h 是双射，且对任意 $(x,x') \in \mathcal{X}^2, d_\mathcal{Y}(h(x),h(x')) = d_\mathcal{X}(x,x')$.

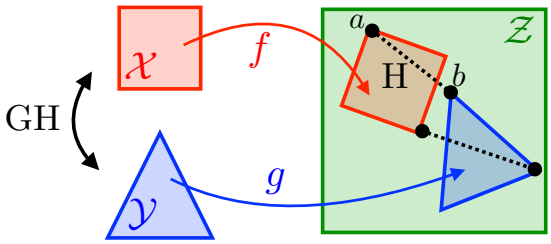

图 10.6: 用 GH 方法比较两个度量空间.

与 (10.23)类似，如 (Mémoli, 2011) 所述，可通过耦合等价地改写 GH 距离：

$$\mathcal{GH}(d_\mathcal{X},d_\mathcal{Y}) = \frac{1}{2} \inf_{R\in\mathcal{R}(\mathcal{X},\mathcal{Y})} \sup_{((x,y),(x',y'))\in R^2} |d_\mathcal{X}(x,x') - d_\mathcal{X}(y,y')|.$$

对于离散空间 $\mathcal{X} = (x_i)_{i=1}^n, \mathcal{Y} = (y_j)_{j=1}^m$，用距离矩阵 $\mathbf{D} = (d_\mathcal{X}(x_i,x_{i'}))_{i,i'} \in \mathbb{R}^{n\times n}$、$\mathbf{D}' = (d_\mathcal{Y}(y_j,y_{j'}))_{j,j'} \in \mathbb{R}^{m\times m}$ 表示. 利用二元矩阵 $\mathbf{R} \in \{0,1\}^{n\times m}$ 表示集合耦合 R 的支撑，此优化可改写为

$$\mathrm{GH}(\mathbf{D},\mathbf{D}') = \frac{1}{2} \inf_{\mathbf{R}\mathbb{1}>0,\mathbf{R}^\top\mathbb{1}>0} \max_{(i,i',j,j')} \mathbf{R}_{i,j}\mathbf{R}_{j,j'}|\mathbf{D}_{i,i'} - \mathbf{D}'_{j,j'}|. \tag{10.24}$$

GH 距离的最初动机是定义、研究度量空间的极限，如图 10.7所示，详见 (Burago et al., 2001). GH 距离的测地线有显式描述 (Chowdhury and Mémoli, 2016)，与注 10.8详述的 Gromov–Wasserstein 空间的测地线很相似.

基础优化问题 (10.24)高度非凸，全局极小值的计算难以处理. 已有人通过近似方法进行数值求解，并用于视觉和图形学中的形状匹配 (Mémoli and Sapiro, 2005; Bronstein et al., 2006).

通常希望将最大化替换为积分，以“平滑” Hausdorff 距离的定义. 这需要引入测度，也是下一小节定义 GW 距离的动机之一.

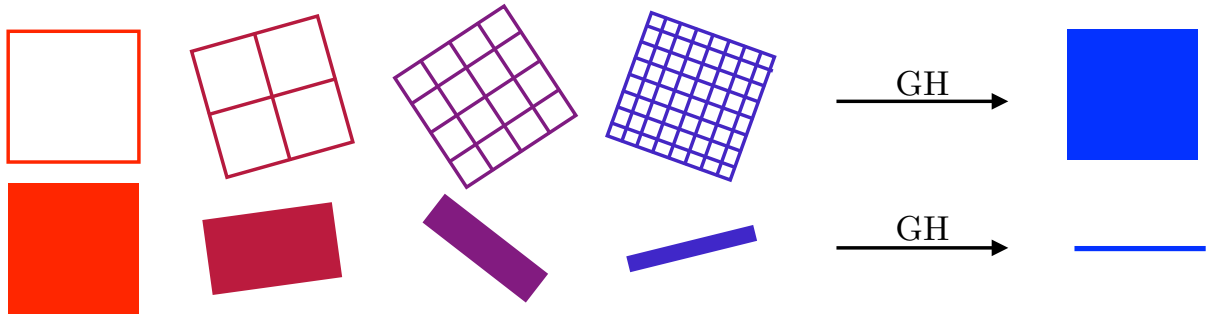

图 10.7: 度量空间序列的 GH 极限.

10.6.3 Gromov–Wasserstein 距离

最优传输需要基础代价 $\mathbf{C}$ 来比较直方图 $(\mathbf{a}, \mathbf{b})$；因此，若直方图区间并不定义在同一基础空间上，或者无法预先配准两个空间以定义分别属于第一、第二直方图的任意两个区间之间的基础代价，便无法使用它. 为克服这一限制，只需作更弱的假设：两个矩阵 $\mathbf{D} \in \mathbb{R}^{n\times n}$ 和 $\mathbf{D}' \in \mathbb{R}^{m\times m}$ 量化各直方图支撑点之间的相似关系. 典型情形是这些矩阵为距离矩阵或其幂. Gromov–Wasserstein 距离（Gromov–Wasserstein distance）（GW）问题为

$$\mathrm{GW}((\mathbf{a},\mathbf{D}),(\mathbf{b},\mathbf{D}'))^2 \overset{\text{def.}}{=} \min_{\mathbf{P}\in\mathbf{U}(\mathbf{a},\mathbf{b})} \mathcal{E}_{\mathbf{D},\mathbf{D}'}(\mathbf{P}) \tag{10.25}$$

$$\text{其中}\quad \mathcal{E}_{\mathbf{D},\mathbf{D}'}(\mathbf{P}) \overset{\text{def.}}{=} \sum_{i,j,i',j'} |\mathbf{D}_{i,i'} - \mathbf{D}'_{j,j'}|^2 \mathbf{P}_{i,j}\mathbf{P}_{i',j'},$$

见图 10.8. 此问题类似 GH 问题 (10.24)，只是将最大化替换为求和、集合耦合替换为测度耦合. 这是非凸问题，可改写为二次指派问题 (Loiola et al., 2007)；对任意输入，一般情况下求解是 NP-hard 的. 对于特定代价，它实际上等价于图匹配问题 (Lyzinski et al., 2016).

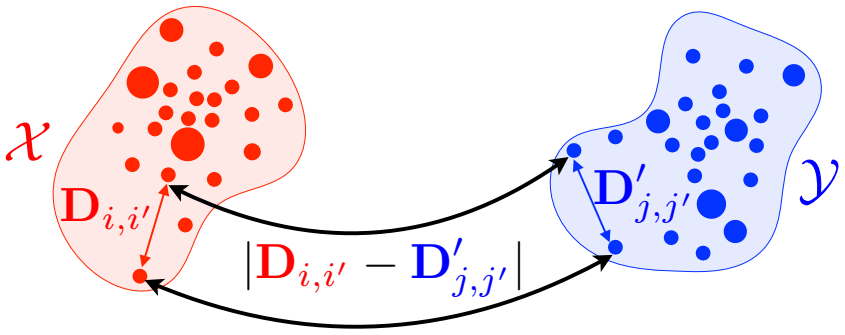

图 10.8: 用 GW 方法比较两个度量测度空间.

可证明 GW 满足三角不等式，且在赋有概率分布的度量空间上（定义 (10.25)中假设为离散情形），模掉保持测度的等距映射后，它确实定义距离. Mémoli (2011) 引入

并详细研究了此距离. 深入的数学论述（特别是测地结构与梯度流）见 (Sturm, 2012). 计算机视觉中的应用另见 (Schmitzer and Schnörr, 2013a). 此距离还与度量空间之间的 GH 距离 (Gromov, 2001) 密切相关，后者已用于形状匹配 (Mémoli, 2007; Bronstein et al., 2010).

注 10.7 (Gromov–Wasserstein 距离). 一般情形是在度量测度空间 $(\mathcal{X}, d_{\mathcal{X}}, \alpha_{\mathcal{X}})$ 与 $(\mathcal{Y}, d_{\mathcal{Y}}, \alpha_{\mathcal{Y}})$ 之间计算耦合，其中 $(d_{\mathcal{X}}, d_{\mathcal{Y}})$ 是距离，$\alpha_{\mathcal{X}}, \alpha_{\mathcal{Y}}$ 是相应空间上的测度. 定义

$$\begin{aligned}&\mathcal{GW}((\alpha_{\mathcal{X}}, d_{\mathcal{X}}), (\alpha_{\mathcal{Y}}, d_{\mathcal{Y}}))^2 \overset{\text{def.}}{=} \\ &\min_{\pi \in \mathcal{U}(\alpha_{\mathcal{X}}, \alpha_{\mathcal{Y}})} \int_{\mathcal{X}^2 \times \mathcal{Y}^2} |d_{\mathcal{X}}(x, x') - d_{\mathcal{Y}}(y, y')|^2 \mathrm{d}\pi(x, y) \mathrm{d}\pi(x', y').\end{aligned} \tag{10.26}$$

$\mathcal{GW}$ 在模掉等距映射的度量测度空间上定义距离. 若存在双射 $\varphi : \mathcal{X} \to \mathcal{Y}$，满足 $\varphi_\sharp \alpha_{\mathcal{X}} = \alpha_{\mathcal{Y}}$ 且 $d_{\mathcal{Y}}(\varphi(x), \varphi(x')) = d_{\mathcal{X}}(x, x')$，则称 $(\mathcal{X}, \alpha_{\mathcal{X}}, d_{\mathcal{X}})$ 与 $(\mathcal{Y}, \alpha_{\mathcal{Y}}, d_{\mathcal{Y}})$ 等距.

注 10.8 (Gromov–Wasserstein 测地线). 赋予 GW 距离 (10.26)的度量空间集合（模掉等距映射）具有测地结构. Sturm (2012) 表明，$(\mathcal{X}_0, d_{\mathcal{X}_0}, \alpha_0)$ 与 $(\mathcal{X}_1, d_{\mathcal{X}_1}, \alpha_1)$ 之间的测地线可选为 $t \in [0,1] \mapsto (\mathcal{X}_0 \times \mathcal{X}_1, d_t, \pi^\star)$，其中 $\pi^\star$ 是 (10.26)的解，对任意 $((x_0, x_1), (x_0', x_1')) \in (\mathcal{X}_0 \times \mathcal{X}_1)^2$，

$$d_t((x_0, x_1), (x_0', x_1')) \overset{\text{def.}}{=} (1-t) d_{\mathcal{X}_0}(x_0, x_0') + t d_{\mathcal{X}_1}(x_1, x_1').$$

此公式可定义、分析最小化涉及度量空间的泛函的梯度流；见 Sturm (2012). 不过，它涉及乘积空间 $\mathcal{X}_0 \times \mathcal{X}_1$ 上的计算，因而难以数值处理. (Peyré et al., 2016) 采用启发式方法定义度量测度空间的测地线和重心，同时固定涉及空间的基数，并使用下文详述的熵平滑 (10.27).

10.6.4 熵正则化

为了近似计算 GW，并帮助最小化方法收敛到更好的极小值，可以考虑熵正则化变体

$$\min_{\mathbf{P} \in \mathbf{U}(\mathbf{a}, \mathbf{b})} \mathcal{E}_{\mathbf{D}, \mathbf{D}'}(\mathbf{P}) - \varepsilon \mathbf{H}(\mathbf{P}). \tag{10.27}$$

如 (Gold and Rangarajan, 1996; Rangarajan et al., 1999) 最初提出，后来由 (Solomon et al., 2016a) 重新用于图形学应用，可反复使用 Sinkhorn 算法，逐步计算 (10.27)的驻点. 事实上，连续线性化目标函数得到以下更新序列：

$$\mathbf{P}^{(\ell+1)} \overset{\text{def.}}{=} \min_{\mathbf{P} \in \mathbf{U}(\mathbf{a}, \mathbf{b})} \langle \mathbf{P}, \mathbf{C}^{(\ell)} \rangle - \varepsilon H(\mathbf{P}) \quad \text{其中} \tag{10.28}$$

$$\mathbf{C}^{(\ell)} \overset{\text{def.}}{=} \nabla \mathcal{E}_{\mathbf{D}, \mathbf{D}'}(\mathbf{P}^{(\ell)}) = -\mathbf{D} \mathbf{P}^{(\ell)} \mathbf{D}',$$

它可解释为镜像下降方法 (Solomon et al., 2016a). 因而每步更新可用代价 $\mathbf{C}^{(\ell)}$ 下的 Sinkhorn 迭代 (4.15)求解. 图 10.9展示算法的演变. 图 10.10说明用此熵 GW 计算区域之间软映射的应用.

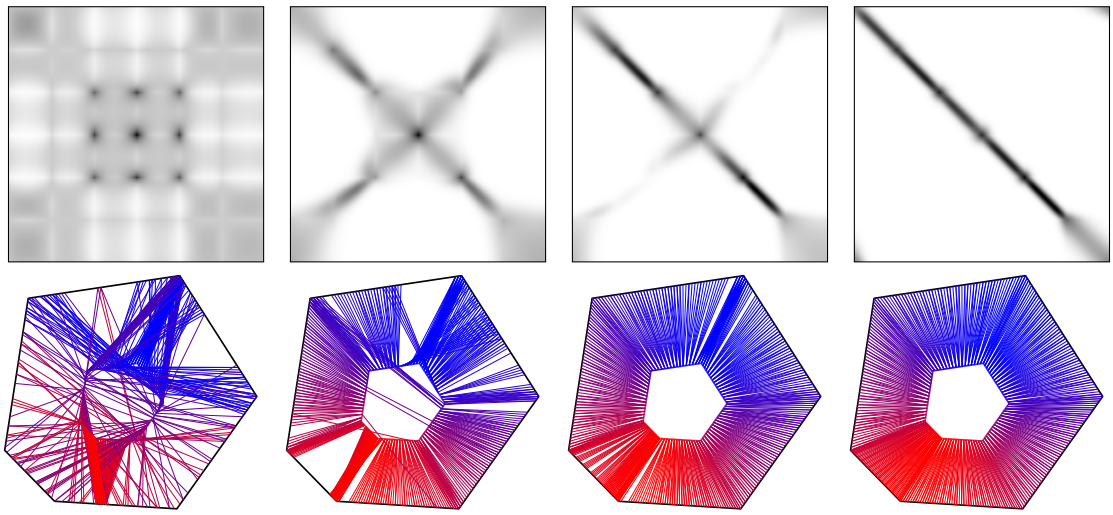

图 10.9: 在 $\mathbb{R}^2$ 中两个形状 $(x_i)_i, (y_j)_j$ 之间执行熵 GW 算法 (10.28)的迭代，初值 $\mathbf{P}^{(0)} = \mathbf{a} \otimes \mathbf{b}$. 距离矩阵为 $\mathbf{D}_{i,i'} = \|x_i - x_{i'}\|$ 和 $\mathbf{D}'_{j,j'} = \|y_j - y_{j'}\|$. 上排：以二维图像显示耦合 $\mathbf{P}^{(\ell)}$. 下排：$\mathbf{P}^{(\ell)}$ 诱导的匹配（每个 x_i 与 $\{\mathbf{P}^{(\ell)}_{i,j}\}_j$ 中取最大三个值的三个 y_j 连接）. 两个形状大小相同，但为了显示，将内侧形状 $(x_i)_i$ 缩小.

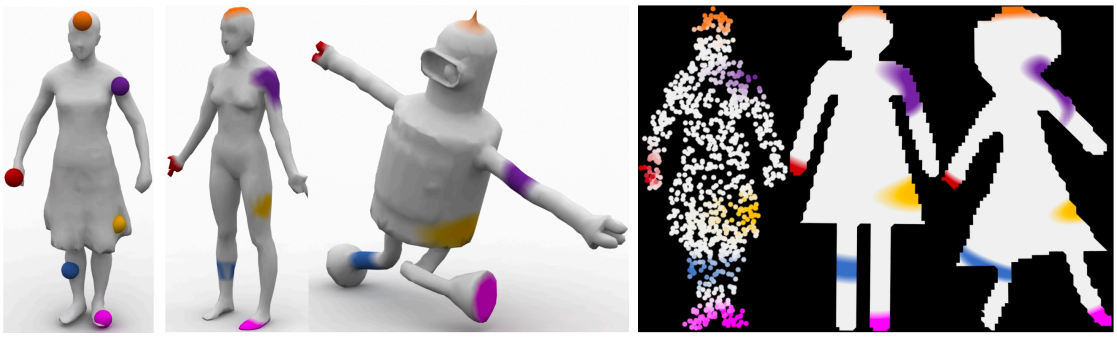

图 10.10: 用 Sinkhorn 迭代 (10.28)求解 GW 问题 (10.27)所得模糊对应关系的例子. 摘自 (Solomon et al., 2016a).

致谢

我们感谢在准备本综述的各个阶段给予帮助的众多同事、合作者和学生. 其中一些人的意见塑造了本书；我们尤其感谢 Inria 的 Jean-David Benamou、Yann Brenier、Guillaume Carlier、Vincent Duval 及整个 MOKAPLAN 团队；Francis Bach、Espen Bernton、Mathieu Blondel、Nicolas Courty、Rémi Flamary、Alexandre Gramfort、Young-Heon Kim、Daniel Matthes、Philippe Rigollet、Filippo Santambrogio、Justin Solomon、Jonathan Weed；以及我们现在和过去的学生对这些主题提出的反馈，特别是 Gwendoline de Bie、Lénaïc Chizat、Aude Genevay、Hicham Janati、Théo Lacombe、Boris Muzellec、Franccois-Pierre Paty、Vivien Seguy.

参考文献

Martín Abadi, Ashish Agarwal, Paul Barham, Eugene Brevdo, Zhifeng Chen, Craig Citro, Greg S Corrado, Andy Davis, Jeffrey Dean, Matthieu Devin, et al. Tensorflow: large-scale machine learning on heterogeneous distributed systems. *arXiv preprint arXiv:1603.04467*, 2016.

Isabelle Abraham, Romain Abraham, Maıtine Bergounioux, and Guillaume Carlier. Tomographic reconstruction from a few views: a multi-marginal optimal transport approach. *Applied Mathematics & Optimization*, 75(1):55–73, 2017.

Ryan Prescott Adams and Richard S Zemel. Ranking via sinkhorn propagation. *arXiv preprint arXiv:1106.1925*, 2011.

Martial Agueh and Malcolm Bowles. One-dimensional numerical algorithms for gradient flows in the p-Wasserstein spaces. *Acta Applicandae Mathematicae*, 125(1):121–134, 2013.

Martial Agueh and Guillaume Carlier. Barycenters in the Wasserstein space. *SIAM Journal on Mathematical Analysis*, 43(2):904–924, 2011.

Martial Agueh and Guillaume Carlier. Vers un théorème de la limite centrale dans l'espace de Wasserstein? *Comptes Rendus Mathematique*, 355(7):812–818, 2017.

Rami Al-Rfou, Guillaume Alain, Amjad Almahairi, Christof Angermüller, Dzmitry Bahdanau, and Nicolas Ballas et al. Theano: A python framework for fast computation of mathematical expressions. *CoRR*, abs/1605.02688, 2016.

Syed Mumtaz Ali and Samuel D Silvey. A general class of coefficients of divergence of one distribution from another. *Journal of the Royal Statistical Society. Series B (Methodological)*, 28(1):131–142, 1966.

Zeyuan Allen-Zhu, Yuanzhi Li, Rafael Oliveira, and Avi Wigderson. Much faster algorithms for matrix scaling. *arXiv preprint arXiv:1704.02315*, 2017.

Jason Altschuler, Jonathan Weed, and Philippe Rigollet. Near-linear time approximation algorithms for optimal transport via Sinkhorn iteration. *arXiv preprint arXiv:1705.09634*, 2017.

Pedro C Álvarez-Esteban, E del Barrio, JA Cuesta-Albertos, and C Matrán. A fixed-point approach to barycenters in Wasserstein space. *Journal of Mathematical Analysis and Applications*, 441(2):744–762, 2016.

David Alvarez-Melis, Stefanie Jegelka, and Tommi S Jaakkola. Towards optimal transport with global invariances. 2019.

Shun-ichi Amari, Ryo Karakida, and Masafumi Oizumi. Information geometry connecting Wasserstein distance and Kullback-Leibler divergence via the entropy-relaxed transportation problem. *Information Geometry*, (1):13–37, 2018.

L. Ambrosio, N. Gigli, and G. Savaré. *Gradient Flows in Metric Spaces and in the Space of Probability Measures*. Springer, 2006.

Luigi Ambrosio and Alessio Figalli. Geodesics in the space of measure-preserving maps and plans. *Archive for Rational Mechanics and Analysis*, 194(2):421–462, 2009.

Ethan Anderes, Steffen Borgwardt, and Jacob Miller. Discrete Wasserstein barycenters: optimal transport for discrete data. *Mathematical Methods of Operations Research*, 84(2):389–409, 2016.

Alexandr Andoni, Piotr Indyk, and Robert Krauthgamer. Earth mover distance over high-dimensional spaces. In *Proceedings of the nineteenth annual ACM-SIAM Symposium on Discrete Algorithms*, pages 343–352. Society for Industrial and Applied Mathematics, 2008.

Alexandr Andoni, Assaf Naor, and Ofer Neiman. Snowflake universality of Wasserstein spaces. *Annales scientifiques de l'École normale supérieure*, 51:657–700, 2018.

Martin Arjovsky, Soumith Chintala, and Léon Bottou. Wasserstein generative adversarial networks. *Proceedings of the 34th International Conference on Machine Learning*, 70:214–223, 2017.

Franz Aurenhammer. Power diagrams: properties, algorithms and applications. *SIAM Journal on Computing*, 16(1):78–96, 1987.

Franz Aurenhammer, Friedrich Hoffmann, and Boris Aronov. Minkowski-type theorems and least-squares clustering. *Algorithmica*, 20(1):61–76, 1998.

Amir Averbuch, Ronald Coifman, David Donoho, Moshe Israeli, and Johan Walden. Fast slant stack: a notion of radon transform for data in a cartesian grid which is rapidly computible, algebraically exact, geometrically faithful and invertible. *Tech. Rep., Stanford University*, 2001.

Francis Bach. Self-concordant analysis for logistic regression. *Electronic Journal of Statistics*, 4:384–414, 2010.

Francis R Bach. Adaptivity of averaged stochastic gradient descent to local strong convexity for logistic regression. *Journal of Machine Learning Research*, 15(1):595–627, 2014.

Michael Bacharach. Estimating nonnegative matrices from marginal data. *International Economic Review*, 6(3):294–310, 1965.

Alexander Barvinok. *A Course in Convexity*. Graduate Studies in Mathematics. American Mathematical Society, 2002. ISBN 9780821829684.

Federico Bassetti, Antonella Bodini, and Eugenio Regazzini. On minimum kantorovich distance estimators. *Statistics & Probability Letters*, 76(12):1298–1302, 2006.

Heinz H Bauschke and Patrick L Combettes. *Convex analysis and monotone operator theory in Hilbert spaces*. Springer-Verlag, New York, 2011.

Heinz H Bauschke and Adrian S Lewis. Dykstra's algorithm with Bregman projections: a convergence proof. *Optimization*, 48(4):409–427, 2000.

Amir Beck and Marc Teboulle. Mirror descent and nonlinear projected subgradient methods for convex optimization. *Operations Research Letters*, 31(3):167–175, 2003.

Martin Beckmann. A continuous model of transportation. *Econometrica*, 20:643–660, 1952.

Mathias Beiglböck, Pierre Henry-Labordère, and Friedrich Penkner. Model-independent bounds for option prices: a mass transport approach. *Finance and Stochastics*, 17(3): 477–501, 2013.

Jan Beirlant, Edward J Dudewicz, Laszlo Gyorfi, and Edward C Van der Meulen. Nonparametric entropy estimation: an overview. *International Journal of Mathematical and Statistical Sciences*, 6(1):17–39, 1997.

Jean-David Benamou. Numerical resolution of an "unbalanced" mass transport problem. *ESAIM: Mathematical Modelling and Numerical Analysis*, 37(05):851–868, 2003.

Jean-David Benamou and Yann Brenier. A computational fluid mechanics solution to the Monge-Kantorovich mass transfer problem. *Numerische Mathematik*, 84(3): 375–393, 2000.

Jean-David Benamou and Guillaume Carlier. Augmented lagrangian methods for transport optimization, mean field games and degenerate elliptic equations. *Journal of Optimization Theory and Applications*, 167(1):1–26, 2015.

Jean-David Benamou, Brittany D Froese, and Adam M Oberman. Numerical solution of the optimal transportation problem using the Monge–Ampere equation. *Journal of Computational Physics*, 260:107–126, 2014.

Jean-David Benamou, Guillaume Carlier, Marco Cuturi, Luca Nenna, and Gabriel Peyré. Iterative Bregman projections for regularized transportation problems. *SIAM Journal on Scientific Computing*, 37(2):A1111–A1138, 2015.

Jean-David Benamou, Guillaume Carlier, Quentin Mérigot, and Edouard Oudet. Dis-

cretization of functionals involving the Monge–Ampère operator. *Numerische Mathematik*, 134(3):611–636, 2016a.

Jean-David Benamou, Francis Collino, and Jean-Marie Mirebeau. Monotone and consistent discretization of the Monge-Ampere operator. *Mathematics of Computation*, 85(302):2743–2775, 2016b.

Christian Berg, Jens Peter Reus Christensen, and Paul Ressel. *Harmonic Analysis on Semigroups*. Number 100 in Graduate Texts in Mathematics. Springer Verlag, 1984.

Alain Berlinet and Christine Thomas-Agnan. *Reproducing Kernel Hilbert Spaces in Probability and Statistics*. Kluwer Academic Publishers, 2003.

Espen Bernton. Langevin Monte Carlo and JKO splitting. In Sébastien Bubeck, Vianney Perchet, and Philippe Rigollet, editors, *Proceedings of the 31st Conference On Learning Theory*, volume 75 of *Proceedings of Machine Learning Research*, pages 1777–1798. PMLR, 2018.

Espen Bernton, Pierre E Jacob, Mathieu Gerber, and Christian P Robert. Inference in generative models using the Wasserstein distance. *arXiv preprint arXiv:1701.05146*, 2017.

Dimitri P Bertsekas. A new algorithm for the assignment problem. *Mathematical Programming*, 21(1):152–171, 1981.

Dimitri P Bertsekas. Auction algorithms for network flow problems: a tutorial introduction. *Computational Optimization and Applications*, 1(1):7–66, 1992.

Dimitri P Bertsekas. *Network Optimization: Continuous and Discrete Models*. Athena Scientific, 1998.

Dimitri P Bertsekas and Jonathan Eckstein. Dual coordinate step methods for linear network flow problems. *Mathematical Programming*, 42(1):203–243, 1988.

Dimitris Bertsimas and John N Tsitsiklis. *Introduction to Linear Optimization*. Athena Scientific, 1997.

Rajendra Bhatia, Tanvi Jain, and Yongdo Lim. On the bures-wasserstein distance between positive definite matrices. *Expositiones Mathematicae, to appear*, 2018.

Jérémie Bigot and Thierry Klein. Consistent estimation of a population barycenter in the Wasserstein space. *arXiv Preprint arXiv:1212.2562*, 2012a.

Jérémie Bigot and Thierry Klein. Characterization of barycenters in the Wasserstein space by averaging optimal transport maps. *arXiv preprint arXiv:1212.2562*, 2012b.

Jérémie Bigot, Elsa Cazelles, and Nicolas Papadakis. Central limit theorems for sinkhorn

divergence between probability distributions on finite spaces and statistical applications. *arXiv preprint arXiv:1711.08947*, 2017a.

Jérémie Bigot, Raúl Gouet, Thierry Klein, and Alfredo López. Geodesic PCA in the Wasserstein space by convex pca. *Annales de l'Institut Henri Poincaré, Probabilités et Statistiques*, 53(1):1–26, 2017b.

Garrett Birkhoff. Tres observaciones sobre el algebra lineal. *Universidad Nacional de Tucumán Revista Series A*, 5:147–151, 1946.

Garrett Birkhoff. Extensions of jentzsch's theorem. *Transactions of the American Mathematical Society*, 85(1):219–227, 1957.

Adrien Blanchet and Guillaume Carlier. Optimal transport and Cournot-Nash equilibria. *Mathematics of Operations Research*, 41(1):125–145, 2015.

Adrien Blanchet, Vincent Calvez, and José A Carrillo. Convergence of the mass-transport steepest descent scheme for the subcritical Patlak-Keller-Segel model. *SIAM Journal on Numerical Analysis*, 46(2):691–721, 2008.

Emmanuel Boissard. Simple bounds for the convergence of empirical and occupation measures in 1-Wasserstein distance. *Electronic Journal of Probability*, 16:2296–2333, 2011.

Emmanuel Boissard, Thibaut Le Gouic, and Jean-Michel Loubes. Distribution's template estimate with Wasserstein metrics. *Bernoulli*, 21(2):740–759, 2015.

Franccois Bolley, Arnaud Guillin, and Cédric Villani. Quantitative concentration inequalities for empirical measures on non-compact spaces. *Probability Theory and Related Fields*, 137(3):541–593, 2007.

Nicolas Bonneel, Michiel Van De Panne, Sylvain Paris, and Wolfgang Heidrich. Displacement interpolation using lagrangian mass transport. *ACM Transactions on Graphics*, 30(6):158, 2011.

Nicolas Bonneel, Julien Rabin, Gabriel Peyré, and Hanspeter Pfister. Sliced and Radon Wasserstein barycenters of measures. *Journal of Mathematical Imaging and Vision*, 51(1):22–45, 2015.

Nicolas Bonneel, Gabriel Peyré, and Marco Cuturi. Wasserstein barycentric coordinates: histogram regression using optimal transport. *ACM Transactions on Graphics*, 35(4): 71:1–71:10, 2016.

CW Borchardt and CGJ Jocobi. De investigando ordine systematis aequationum differentialium vulgarium cujuscunque. *Journal für die reine und angewandte Mathematik*, 64:297–320, 1865.

Ingwer Borg and Patrick JF Groenen. *Modern Multidimensional Scaling: Theory and Applications*. Springer Science & Business Media, 2005.

Mario Botsch, Leif Kobbelt, Mark Pauly, Pierre Alliez, and Bruno Lévy. *Polygon mesh processing*. Taylor & Francis, 2010.

Olivier Bousquet, Sylvain Gelly, Ilya Tolstikhin, Carl-Johann Simon-Gabriel, and Bernhard Schoelkopf. From optimal transport to generative modeling: the VEGAN cookbook. *arXiv preprint arXiv:1705.07642*, 2017.

Stephen Boyd, Neal Parikh, Eric Chu, Borja Peleato, and Jonathan Eckstein. Distributed optimization and statistical learning via the alternating direction method of multipliers. *Foundations and Trends in Machine Learning*, 3(1):1–122, January 2011.

Lev M Bregman. The relaxation method of finding the common point of convex sets and its application to the solution of problems in convex programming. *USSR Computational Mathematics and Mathematical Physics*, 7(3):200–217, 1967.

Yann Brenier. Décomposition polaire et réarrangement monotone des champs de vecteurs. *C. R. Acad. Sci. Paris Sér. I Math.*, 305(19):805–808, 1987.

Yann Brenier. The least action principle and the related concept of generalized flows for incompressible perfect fluids. *Journal of the AMS*, 2:225–255, 1990.

Yann Brenier. Polar factorization and monotone rearrangement of vector-valued functions. *Communications on Pure and Applied Mathematics*, 44(4):375–417, 1991.

Yann Brenier. The dual least action problem for an ideal, incompressible fluid. *Archive for Rational Mechanics and Analysis*, 122(4):323–351, 1993.

Yann Brenier. Minimal geodesics on groups of volume-preserving maps and generalized solutions of the Euler equations. *Communications on Pure and Applied Mathematics*, 52(4):411–452, 1999.

Yann Brenier. Generalized solutions and hydrostatic approximation of the Euler equations. *Physica D. Nonlinear Phenomena*, 237(14-17):1982–1988, 2008.

Alexander M Bronstein, Michael M Bronstein, and Ron Kimmel. Generalized multidimensional scaling: a framework for isometry-invariant partial surface matching. *Proceedings of the National Academy of Sciences*, 103(5):1168–1172, 2006.

Alexander M Bronstein, Michael M Bronstein, Ron Kimmel, Mona Mahmoudi, and Guillermo Sapiro. A Gromov-Hausdorff framework with diffusion geometry for topologically-robust non-rigid shape matching. *International Journal on Computer Vision*, 89(2-3):266–286, 2010.

Richard A Brualdi. *Combinatorial Matrix Classes*, volume 108. Cambridge University Press, 2006.

Dmitri Burago, Yuri Burago, and Sergei Ivanov. *A Course in Metric Geometry*, volume 33. American Mathematical Society Providence, RI, 2001.

Donald Bures. An extension of Kakutani's theorem on infinite product measures to the tensor product of semifinite w^*-algebras. *Transactions of the American Mathematical Society*, 135:199–212, 1969.

Martin Burger, José Antonio Carrillo de la Plata, and Marie-Therese Wolfram. A mixed finite element method for nonlinear diffusion equations. *Kinetic and Related Models*, 3(1):59–83, 2010.

Martin Burger, Marzena Franek, and Carola-Bibiane Schönlieb. Regularised regression and density estimation based on optimal transport. *Applied Mathematics Research Express*, 2:209–253, 2012.

Giuseppe Buttazzo, Luigi De Pascale, and Paola Gori-Giorgi. Optimal-transport formulation of electronic density-functional theory. *Physical Review A*, 85(6):062502, 2012.

Luis Caffarelli. The Monge-Ampere equation and optimal transportation, an elementary review. *Lecture Notes in Mathematics, Springer-Verlag*, pages 1–10, 2003.

Luis Caffarelli, Mikhail Feldman, and Robert McCann. Constructing optimal maps for Monge's transport problem as a limit of strictly convex costs. *Journal of the American Mathematical Society*, 15(1):1–26, 2002.

Luis A Caffarelli and Robert J McCann. Free boundaries in optimal transport and Monge-Ampère obstacle problems. *Annals of Mathematics*, 171(2):673–730, 2010.

Luis A Caffarelli, Sergey A Kochengin, and Vladimir I Oliker. Problem of reflector design with given far-field scattering data. In *Monge Ampère equation: applications to geometry and optimization*, volume 226, page 13, 1999.

Guillermo Canas and Lorenzo Rosasco. Learning probability measures with respect to optimal transport metrics. In F. Pereira, C. J. C. Burges, L. Bottou, and K. Q. Weinberger, editors, *Advances in Neural Information Processing Systems 25*, pages 2492–2500. 2012.

Eric A Carlen and Jan Maas. An analog of the 2-Wasserstein metric in non-commutative probability under which the fermionic Fokker–Planck equation is gradient flow for the entropy. *Communications in Mathematical Physics*, 331(3):887–926, 2014.

Guillaume Carlier and Ivar Ekeland. Matching for teams. *Economic Theory*, 42(2):

397–418, 2010.

Guillaume Carlier and Clarice Poon. On the total variation Wasserstein gradient flow and the TV-JKO scheme. *to appear in ESAIM: COCV*, 2019.

Guillaume Carlier, Chloé Jimenez, and Filippo Santambrogio. Optimal transportation with traffic congestion and Wardrop equilibria. *SIAM Journal on Control and Optimization*, 47(3):1330–1350, 2008.

Guillaume Carlier, Alfred Galichon, and Filippo Santambrogio. From knothe's transport to Brenier's map and a continuation method for optimal transport. *SIAM Journal on Mathematical Analysis*, 41(6):2554–2576, 2010.

Guillaume Carlier, Adam Oberman, and Edouard Oudet. Numerical methods for matching for teams and Wasserstein barycenters. *ESAIM: Mathematical Modelling and Numerical Analysis*, 49(6):1621–1642, 2015.

Guillaume Carlier, Victor Chernozhukov, and Alfred Galichon. Vector quantile regression beyond correct specification. *arXiv preprint arXiv:1610.06833*, 2016.

Guillaume Carlier, Vincent Duval, Gabriel Peyré, and Bernhard Schmitzer. Convergence of entropic schemes for optimal transport and gradient flows. *SIAM Journal on Mathematical Analysis*, 49(2):1385–1418, 2017.

José A Carrillo and J Salvador Moll. Numerical simulation of diffusive and aggregation phenomena in nonlinear continuity equations by evolving diffeomorphisms. *SIAM Journal on Scientific Computing*, 31(6):4305–4329, 2009.

José A Carrillo, Alina Chertock, and Yanghong Huang. A finite-volume method for nonlinear nonlocal equations with a gradient flow structure. *Communications in Computational Physics*, 17:233–258, 1 2015.

Yair Censor and Simeon Reich. The Dykstra algorithm with Bregman projections. *Communications in Applied Analysis*, 2:407–419, 1998.

Yair Censor and Stavros Andrea Zenios. Proximal minimization algorithm with d-functions. *Journal of Optimization Theory and Applications*, 73(3):451–464, 1992.

Thierry Champion, Luigi De Pascale, and Petri Juutinen. The ∞-wasserstein distance: local solutions and existence of optimal transport maps. *SIAM Journal on Mathematical Analysis*, 40(1):1–20, 2008.

Timothy M Chan. Optimal output-sensitive convex hull algorithms in two and three dimensions. *Discrete & Computational Geometry*, 16(4):361–368, 1996.

Yongxin Chen, Tryphon T Georgiou, and Michele Pavon. On the relation between

optimal transport and Schrödinger bridges: A stochastic control viewpoint. *Journal of Optimization Theory and Applications*, 169(2):671–691, 2016a.

Yongxin Chen, Tryphon T Georgiou, and Allen Tannenbaum. Matrix optimal mass transport: a quantum mechanical approach. *arXiv preprint arXiv:1610.03041*, 2016b.

Yongxin Chen, Wilfrid Gangbo, Tryphon T Georgiou, and Allen Tannenbaum. On the matrix Monge-Kantorovich problem. *arXiv preprint arXiv:1701.02826*, 2017.

Lenaic Chizat, Gabriel Peyré, Bernhard Schmitzer, and Franccois-Xavier Vialard. Unbalanced optimal transport: geometry and Kantorovich formulation. *Journal of Functional Analysis*, 274(11):3090–3123, 2018a.

Lenaic Chizat, Gabriel Peyré, Bernhard Schmitzer, and Franccois-Xavier Vialard. Scaling algorithms for unbalanced transport problems. *Mathematics of Computation*, 87: 2563–2609, 2018b.

Lenaic Chizat, Gabriel Peyré, Bernhard Schmitzer, and Franccois-Xavier Vialard. An interpolating distance between optimal transport and Fisher–Rao metrics. *Foundations of Computational Mathematics*, 18(1):1–44, 2018c.

Shui-Nee Chow, Wen Huang, Yao Li, and Haomin Zhou. Fokker-Planck equations for a free energy functional or Markov process on a graph. *Archive for Rational Mechanics and Analysis*, 203(3):969–1008, 2012.

Shui-Nee Chow, Wuchen Li, and Haomin Zhou. A discrete Schrodinger equation via optimal transport on graphs. *arXiv preprint arXiv:1705.07583*, 2017a.

Shui-Nee Chow, Wuchen Li, and Haomin Zhou. Entropy dissipation of Fokker-Planck equations on graphs. *arXiv preprint arXiv:1701.04841*, 2017b.

Samir Chowdhury and Facundo Mémoli. Constructing geodesics on the space of compact metric spaces. *arXiv preprint arXiv:1603.02385*, 2016.

Haili Chui and Anand Rangarajan. A new algorithm for non-rigid point matching. In *Computer Vision and Pattern Recognition, 2000. Proceedings. IEEE Conference on*, volume 2, pages 44–51. IEEE, 2000.

Imre Ciszár. Information-type measures of difference of probability distributions and indirect observations. *Studia Scientiarum Mathematicarum Hungarica*, 2:299–318, 1967.

Michael B Cohen, Aleksander Madry, Dimitris Tsipras, and Adrian Vladu. Matrix scaling and balancing via box constrained Newton's method and interior point methods. *arXiv preprint arXiv:1704.02310*, 2017.

Scott Cohen and Leonidas Guibas. The earth mover's distance under transformation sets. In *Proceedings of the Seventh IEEE International Conference on Computer vision*, volume 2, pages 1076–1083. IEEE, 1999.

Patrick L Combettes and Jean-Christophe Pesquet. A Douglas-Rachford splitting approach to nonsmooth convex variational signal recovery. *IEEE Journal of Selected Topics in Signal Processing*, 1(4):564 –574, 2007.

Roberto Cominetti and Jaime San Martín. Asymptotic analysis of the exponential penalty trajectory in linear programming. *Mathematical Programming*, 67(1-3):169–187, 1994.

Laurent Condat. Fast projection onto the simplex and the ℓ_1 ball. *Math. Programming, Ser. A*, pages 1–11, 2015.

Sueli IR Costa, Sandra A Santos, and João E Strapasson. Fisher information distance: a geometrical reading. *Discrete Applied Mathematics*, 197:59–69, 2015.

Codina Cotar, Gero Friesecke, and Claudia Klüppelberg. Density functional theory and optimal transportation with Coulomb cost. *Communications on Pure and Applied Mathematics*, 66(4):548–599, 2013.

Nicolas Courty, Rémi Flamary, Devis Tuia, and Thomas Corpetti. Optimal transport for data fusion in remote sensing. In *2016 IEEE International Geoscience and Remote Sensing Symposium*, pages 3571–3574. IEEE, 2016.

Nicolas Courty, Rémi Flamary, Amaury Habrard, and Alain Rakotomamonjy. Joint distribution optimal transportation for domain adaptation. In I. Guyon, U. V. Luxburg, S. Bengio, H. Wallach, R. Fergus, S. Vishwanathan, and R. Garnett, editors, *Advances in Neural Information Processing Systems 30*, pages 3730–3739. 2017a.

Nicolas Courty, Rémi Flamary, Devis Tuia, and Alain Rakotomamonjy. Optimal transport for domain adaptation. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 39(9):1853–1865, 2017b.

Keenan Crane, Clarisse Weischedel, and Max Wardetzky. Geodesics in heat: a new approach to computing distance based on heat flow. *ACM Transaction on Graphics*, 32(5):152:1–152:11, October 2013.

Juan Antonio Cuesta and Carlos Matran. Notes on the wasserstein metric in hilbert spaces. *The Annals of Probability*, 17(3):1264–1276, 07 1989.

Marco Cuturi. Positivity and transportation. *arXiv preprint 1209.2655*, 2012.

Marco Cuturi. Sinkhorn distances: lightspeed computation of optimal transport. In *Advances in Neural Information Processing Systems 26*, pages 2292–2300, 2013.

Marco Cuturi and David Avis. Ground metric learning. *Journal of Machine Learning Research*, 15:533–564, 2014.

Marco Cuturi and Arnaud Doucet. Fast computation of Wasserstein barycenters. In *Proceedings of ICML*, volume 32, pages 685–693, 2014.

Marco Cuturi and Kenji Fukumizu. Kernels on structured objects through nested histograms. In P. B. Schölkopf, J. C. Platt, and T. Hoffman, editors, *Advances in Neural Information Processing Systems 19*, pages 329–336. MIT Press, 2007.

Marco Cuturi and Gabriel Peyré. A smoothed dual approach for variational Wasserstein problems. *SIAM Journal on Imaging Sciences*, 9(1):320–343, 2016.

Marco Cuturi and Gabriel Peyré. Semidual regularized optimal transport. *SIAM Review*, 60(4):941–965, 2018.

Arnak Dalalyan. Further and stronger analogy between sampling and optimization: Langevin monte carlo and gradient descent. In *Proceedings of the 2017 Conference on Learning Theory*, volume 65 of *Proceedings of Machine Learning Research*, pages 678–689. PMLR, 2017.

Arnak S Dalalyan and Avetik G Karagulyan. User-friendly guarantees for the Langevin Monte Carlo with inaccurate gradient. *arXiv preprint arXiv:1710.00095*, 2017.

George B. Dantzig. Programming of interdependent activities: II mathematical model. *Econometrica*, 17(3/4):200–211, 1949.

George B Dantzig. Application of the simplex method to a transportation problem. *Activity Analysis of Production and Allocation*, 13:359–373, 1951.

George B. Dantzig. *Reminiscences Aabout the origins of linear programming*, pages 78–86. Springer, 1983.

George B. Dantzig. Linear programming. In J. K. Lenstra, A. H. G. Rinnooy Kan, and A. Schrijver, editors, *History of mathematical programming: a collection of personal reminiscences*, pages 257–282. Elsevier Science Publishers, 1991.

Jon Dattorro. *Convex Optimization & Euclidean Distance Geometry*. Meboo Publishing, 2017.

Fernando De Goes, Katherine Breeden, Victor Ostromoukhov, and Mathieu Desbrun. Blue noise through optimal transport. *ACM Transactions on Graphics*, 31(6):171, 2012.

Fernando de Goes, Corentin Wallez, Jin Huang, Dmitry Pavlov, and Mathieu Desbrun. Power particles: an incompressible fluid solver based on power diagrams. *ACM*

Transaction Graphics, 34(4):50:1–50:11, July 2015.

Eustasio del Barrio, JA Cuesta-Albertos, C Matrán, and A Mayo-Íscar. Robust clustering tools based on optimal transportation. *arXiv preprint arXiv:1607.01179*, 2016.

Julie Delon. Midway image equalization. *Journal of Mathematical Imaging and Vision*, 21(2):119–134, 2004.

Julie Delon, Julien Salomon, and Andrei Sobolevski. Fast transport optimization for Monge costs on the circle. *SIAM Journal on Applied Mathematics*, 70(7):2239–2258, 2010.

Julie Delon, Julien Salomon, and Andrei Sobolevski. Local matching indicators for transport problems with concave costs. *SIAM Journal on Discrete Mathematics*, 26 (2):801–827, 2012.

Edwards Deming and Frederick F Stephan. On a least squares adjustment of a sampled frequency table when the expected marginal totals are known. *Annals of Mathematical Statistics*, 11(4):427–444, 1940.

Steffen Dereich, Michael Scheutzow, and Reik Schottstedt. Constructive quantization: Approximation by empirical measures. In *Annales de l'Institut Henri Poincaré, Probabilités et Statistiques*, volume 49, pages 1183–1203, 2013.

Rachid Deriche. *Recursively implementating the Gaussian and its derivatives.* PhD thesis, INRIA, 1993.

Arnaud Dessein, Nicolas Papadakis, and Charles-Alban Deledalle. Parameter estimation in finite mixture models by regularized optimal transport: a unified framework for hard and soft clustering. *arXiv preprint arXiv:1711.04366*, 2017.

Arnaud Dessein, Nicolas Papadakis, and Jean-Luc Rouas. Regularized optimal transport and the rot mover's distance. *Journal of Machine Learning Research*, 19(15):1–53, 2018.

Simone Di Marino and Lenaic Chizat. A tumor growth model of Hele-Shaw type as a gradient flow. *Arxiv*, 2017.

Khanh Do Ba, Huy L Nguyen, Huy N Nguyen, and Ronitt Rubinfeld. Sublinear time algorithms for earth mover's distance. *Theory of Computing Systems*, 48(2):428–442, 2011.

Jean Dolbeault, Bruno Nazaret, and Giuseppe Savaré. A new class of transport distances between measures. *Calculus of Variations and Partial Differential Equations*, 34(2): 193–231, 2009.

Yan Dolinsky and H Mete Soner. Martingale optimal transport and robust hedging in continuous time. *Probability Theory and Related Fields*, 160(1-2):391–427, 2014.

Richard M. Dudley. The speed of mean Glivenko-Cantelli convergence. *Annals of Mathematical Statistics*, 40(1):40–50, 1969.

Arnaud Dupuy, Alfred Galichon, and Yifei Sun. Estimating matching affinity matrix under low-rank constraints. *Arxiv:1612.09585*, 2016.

Pavel Dvurechenskii, Darina Dvinskikh, Alexander Gasnikov, Cesar Uribe, and Angelia Nedich. Decentralize and randomize: Faster algorithm for wasserstein barycenters. In S. Bengio, H. Wallach, H. Larochelle, K. Grauman, N. Cesa-Bianchi, and R. Garnett, editors, *Advances in Neural Information Processing Systems 31*, pages 10783–10793. 2018.

Pavel Dvurechensky, Alexander Gasnikov, and Alexey Kroshnin. Computational optimal transport: Complexity by accelerated gradient descent is better than by sinkhorn's algorithm. In Jennifer Dy and Andreas Krause, editors, *Proceedings of the 35th International Conference on Machine Learning*, volume 80 of *Proceedings of Machine Learning Research*, pages 1367–1376. PMLR, 2018.

Richard L Dykstra. An algorithm for restricted least squares regression. *Journal American Statistical Association*, 78(384):839–842, 1983.

Richard L Dykstra. An iterative procedure for obtaining I-projections onto the intersection of convex sets. *Annals of Probability*, 13(3):975–984, 1985.

Jonathan Eckstein and Dimitri P Bertsekas. On the Douglas-Rachford splitting method and the proximal point algorithm for maximal monotone operators. *Mathematical Programming*, 55:293–318, 1992.

David A Edwards. The structure of superspace. In *Studies in topology*, pages 121–133. Elsevier, 1975.

Tarek A El Moselhy and Youssef M Marzouk. Bayesian inference with optimal maps. *Journal of Computational Physics*, 231(23):7815–7850, 2012.

Dominik Maria Endres and Johannes E Schindelin. A new metric for probability distributions. *IEEE Transactions on Information theory*, 49(7):1858–1860, 2003.

Matthias Erbar. The heat equation on manifolds as a gradient flow in the Wasserstein space. *Annales de l'Institut Henri Poincaré, Probabilités et Statistiques*, 46(1):1–23, 2010.

Matthias Erbar and Jan Maas. Gradient flow structures for discrete porous medium equations. *Discrete and Continuous Dynamical Systems*, 34(4):1355–1374, 2014.

Sven Erlander. *Optimal Spatial Interaction and the Gravity Model*, volume 173. Springer-Verlag, 1980.

Sven Erlander and Neil F Stewart. *The Gravity Model in Transportation Analysis: Theory and Extensions*. 1990.

Peyman Mohajerin Esfahani and Daniel Kuhn. Data-driven distributionally robust optimization using the wasserstein metric: Performance guarantees and tractable reformulations. *Mathematical Programming*, 171(1-2):115–166, 2018.

Montacer Essid and Justin Solomon. Quadratically-regularized optimal transport on graphs. *arXiv preprint arXiv:1704.08200*, 2017.

Lawrence C. Evans and Wilfrid Gangbo. *Differential Equations Methods for the Monge-Kantorovich Mass Transfer Problem*, volume 653. American Mathematical Society, 1999.

Mikhail Feldman and Robert McCann. Monge's transport problem on a Riemannian manifold. *Transaction AMS*, 354(4):1667–1697, 2002.

Jean Feydy, Benjamin Charlier, Francois-Xavier Vialard, and Gabriel Peyré. Optimal transport for diffeomorphic registration. In *Proceedings of MICCAI'17*, pages 291–299. Springer, 2017.

Jean Feydy, Thibault Séjourné, Franccois-Xavier Vialard, Shun-Ichi Amari, Alain Trouvé, and Gabriel Peyré. Interpolating between optimal transport and mmd using sinkhorn divergences. In *Proceedings of the 22th International Conference on Artificial Intelligence and Statistics*, 2019.

Alessio Figalli. The optimal partial transport problem. *Archive for Rational Mechanics and Analysis*, 195(2):533–560, 2010.

Rémi Flamary, Cédric Févotte, Nicolas Courty, and Valentin Emiya. Optimal spectral transportation with application to music transcription. In *Advances in Neural Information Processing Systems*, pages 703–711, 2016.

Lester Randolph Ford and Delbert Ray Fulkerson. *Flows in Networks*. Princeton University Press, 1962.

Peter J Forrester and Mario Kieburg. Relating the Bures measure to the Cauchy two-matrix model. *Communications in Mathematical Physics*, 342(1):151–187, 2016.

Nicolas Fournier and Arnaud Guillin. On the rate of convergence in Wasserstein distance of the empirical measure. *Probability Theory and Related Fields*, 162(3-4):707–738, 2015.

Joel Franklin and Jens Lorenz. On the scaling of multidimensional matrices. *Linear Algebra and its Applications*, 114:717–735, 1989.

Uriel Frisch, Sabino Matarrese, Roya Mohayaee, and Andrei Sobolevski. A reconstruction of the initial conditions of the universe by optimal mass transportation. *Nature*, 417(6886):260–262, 2002.

Brittany D Froese and Adam M Oberman. Convergent finite difference solvers for viscosity solutions of the elliptic monge–ampère equation in dimensions two and higher. *SIAM Journal on Numerical Analysis*, 49(4):1692–1714, 2011.

Charlie Frogner, Chiyuan Zhang, Hossein Mobahi, Mauricio Araya, and Tomaso A Poggio. Learning with a Wasserstein loss. In *Advances in Neural Information Processing Systems*, pages 2053–2061, 2015.

Daniel Gabay and Bertrand Mercier. A dual algorithm for the solution of nonlinear variational problems via finite element approximation. *Computers & Mathematics with Applications*, 2(1):17–40, 1976.

Alfred Galichon. *Optimal Transport Methods in Economics*. Princeton University Press, 2016.

Alfred Galichon and Bernard Salanié. Matching with trade-offs: revealed preferences over competing characteristics. Technical report, Preprint SSRN-1487307, 2009.

Alfred Galichon, Pierre Henry-Labordère, and Nizar Touzi. A stochastic control approach to no-arbitrage bounds given marginals, with an application to lookback options. *Annals of Applied Probability*, 24(1):312–336, 2014.

Thomas O Gallouët and Quentin Mérigot. A lagrangian scheme à la brenier for the incompressible euler equations. *Foundations of Computational Mathematics*, 18:1–31, 2017.

Thomas O Gallouët and Leonard Monsaingeon. A JKO splitting scheme for Kantorovich–Fisher–Rao gradient flows. *SIAM Journal on Mathematical Analysis*, 49(2):1100–1130, 2017.

Wilfrid Gangbo and Robert J McCann. The geometry of optimal transportation. *Acta Mathematica*, 177(2):113–161, 1996.

Wilfrid Gangbo and Andrzej Swiech. Optimal maps for the multidimensional Monge-Kantorovich problem. *Communications on Pure and Applied Mathematics*, 51(1): 23–45, 1998.

RUI GAO, Liyan Xie, Yao Xie, and Huan Xu. Robust hypothesis testing using wasserstein uncertainty sets. In S. Bengio, H. Wallach, H. Larochelle, K. Grauman, N. Cesa-

Bianchi, and R. Garnett, editors, *Advances in Neural Information Processing Systems 31*, pages 7913–7923. 2018.

Matthias Gelbrich. On a formula for the l^2 wasserstein metric between measures on euclidean and hilbert spaces. *Mathematische Nachrichten*, 147(1):185–203, 1990.

Aude Genevay, Marco Cuturi, Gabriel Peyré, and Francis Bach. Stochastic optimization for large-scale optimal transport. In *Advances in Neural Information Processing Systems*, pages 3440–3448, 2016.

Aude Genevay, Gabriel Peyré, and Marco Cuturi. GAN and VAE from an optimal transport point of view. (arXiv preprint arXiv:1706.01807), 2017.

Aude Genevay, Gabriel Peyré, and Marco Cuturi. Learning generative models with Sinkhorn divergences. In *Proceedings of the 21st International Conference on Artificial Intelligence and Statistics*, pages 1608–1617, 2018.

Aude Genevay, Lénaic Chizat, Francis Bach, Marco Cuturi, and Gabriel Peyré. Sample complexity of sinkhorn divergences. In *Proceedings of the 22th International Conference on Artificial Intelligence and Statistics*, 2019.

Ivan Gentil, Christian Léonard, and Luigia Ripani. About the analogy between optimal transport and minimal entropy. *arXiv preprint arXiv:1510.08230*, 2015.

Alan George and Joseph WH Liu. The evolution of the minimum degree ordering algorithm. *SIAM Review*, 31(1):1–19, 1989.

Tryphon T Georgiou and Michele Pavon. Positive contraction mappings for classical and quantum Schrödinger systems. *Journal of Mathematical Physics*, 56(3):033301, 2015.

Pascal Getreuer. A survey of Gaussian convolution algorithms. *Image Processing On Line*, 2013:286–310, 2013.

Ugo Gianazza, Giuseppe Savaré, and Giuseppe Toscani. The Wasserstein gradient flow of the Fisher information and the quantum drift-diffusion equation. *Archive for Rational Mechanics and Analysis*, 194(1):133–220, 2009.

Alison L Gibbs and Francis Edward Su. On choosing and bounding probability metrics. *International Statistical Review*, 70(3):419–435, 2002.

Joan Glaunes, Alain Trouvé, and Laurent Younes. Diffeomorphic matching of distributions: a new approach for unlabelled point-sets and sub-manifolds matching. In *Proceedings of the 2004 IEEE Computer Society Conference on Computer Vision and Pattern Recognition*, volume 2, 2004.

Xavier Glorot, Antoine Bordes, and Yoshua Bengio. Domain adaptation for large-scale sentiment classification: A deep learning approach. In *Proceedings of the 28th International Conference on Machine Learning*, pages 513–520, 2011.

Roland Glowinski and A. Marroco. Sur l'approximation, par éléments finis d'ordre un, et la résolution, par pénalisation-dualité d'une classe de problèmes de Dirichlet non linéaires. *ESAIM: Mathematical Modelling and Numerical Analysis*, 9(R2):41–76, 1975.

Steven Gold and Anand Rangarajan. A graduated assignment algorithm for graph matching. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 18(4): 377–388, April 1996.

Steven Gold, Anand Rangarajan, Chien-Ping Lu, Suguna Pappu, and Eric Mjolsness. New algorithms for 2d and 3d point matching: pose estimation and correspondence. *Pattern Recognition*, 31(8):1019–1031, 1998.

Eusebio Gómez, Miguel A Gómez-Villegas, and J Miguel Marín. A survey on continuous elliptical vector distributions. *Rev. Mat. Complut*, 16:345–361, 2003.

Paola Gori-Giorgi, Michael Seidl, and Giovanni Vignale. Density-functional theory for strongly interacting electrons. *Physical Review Letters*, 103(16):166402, 2009.

Alexandre Gramfort, Gabriel Peyré, and Marco Cuturi. Fast optimal transport averaging of neuroimaging data. In *Information Processing in Medical Imaging - 24th International Conference, IPMI 2015*, pages 261–272, 2015.

Kristen Grauman and Trevor Darrell. The pyramid match kernel: discriminative classification with sets of image features. In *Tenth IEEE International Conference on Computer Vision*, volume 2, pages 1458–1465. IEEE, 2005.

Edouard Grave, Armand Joulin, and Quentin Berthet. Unsupervised alignment of embeddings with wasserstein procrustes. In *Proceedings of the 22th International Conference on Artificial Intelligence and Statistics*, 2019.

Arthur Gretton, Karsten M Borgwardt, Malte Rasch, Bernhard Schölkopf, and Alex J Smola. A kernel method for the two-sample-problem. In *Advances in Neural Information Processing Systems*, pages 513–520, 2007.

Arthur Gretton, Karsten M Borgwardt, Malte J Rasch, Bernhard Schölkopf, and Alexander Smola. A kernel two-sample test. *Journal of Machine Learning Research*, 13(Mar):723–773, 2012.

Andreas Griewank. Achieving logarithmic growth of temporal and spatial complexity in reverse automatic differentiation. *Optimization Methods and Software*, 1(1):35–54,

1992.

Andreas Griewank and Andrea Walther. *Evaluating Derivatives: Principles and Techniques of Algorithmic Differentiation*. SIAM, 2008.

Mikhail Gromov. *Metric Structures for Riemannian and Non-Riemannian Spaces*. Progress in Mathematics. Birkhäuser, 2001.

Gaoyue Guo and Jan Obloj. Computational methods for martingale optimal transport problems. *arXiv preprint arXiv:1710.07911*, 2017.

Leonid Gurvits. Classical complexity and quantum entanglement. *Journal of Computer and System Sciences*, 69(3):448–484, 2004.

Cristian E Gutiérrez. *The Monge-Ampere Equation*. Springer, 2016.

Jorge Gutierrez, Julien Rabin, Bruno Galerne, and Thomas Hurtut. Optimal patch assignment for statistically constrained texture synthesis. In *International Conference on Scale Space and Variational Methods in Computer Vision*, pages 172–183. Springer, 2017.

A Hadjidimos. Successive overrelaxation (SOR) and related methods. *Journal of Computational and Applied Mathematics*, 123(1):177–199, 2000.

Steven Haker, Lei Zhu, Allen Tannenbaum, and Sigurd Angenent. Optimal mass transport for registration and warping. *International Journal of Computer Vision*, 60(3): 225–240, 2004.

Leonid G Hanin. Kantorovich-Rubinstein norm and its application in the theory of Lipschitz spaces. *Proceedings of the American Mathematical Society*, 115(2):345–352, 1992.

Tatsunori Hashimoto, David Gifford, and Tommi Jaakkola. Learning population-level diffusions with generative RNNs. In *International Conference on Machine Learning*, pages 2417–2426, 2016.

David Hilbert. Über die gerade linie als kürzeste verbindung zweier punkte. *Mathematische Annalen*, 46(1):91–96, 1895.

Frank L Hitchcock. The distribution of a product from several sources to numerous localities. *Studies in Applied Mathematics*, 20(1-4):224–230, 1941.

Nhat Ho, XuanLong Nguyen, Mikhail Yurochkin, Hung Hai Bui, Viet Huynh, and Dinh Phung. Multilevel clustering via wasserstein means. In *International Conference on Machine Learning*, pages 1501–1509, 2017.

Thomas Hofmann, Bernhard Schölkopf, and Alexander J Smola. Kernel methods in

machine learning. *Annals of Statistics*, 36(3):1171–1220, 2008.

David W Hosmer Jr, Stanley Lemeshow, and Rodney X Sturdivant. *Applied Logistic Regression*, volume 398. John Wiley & Sons, 2013.

Gao Huang, Chuan Guo, Matt J Kusner, Yu Sun, Fei Sha, and Kilian Q Weinberger. Supervised word mover's distance. In *Advances in Neural Information Processing Systems*, pages 4862–4870, 2016.

Martin Idel. A review of matrix scaling and Sinkhorn's normal form for matrices and positive maps. *arXiv preprint arXiv:1609.06349*, 2016.

Piotr Indyk and Eric Price. K-median clustering, model-based compressive sensing, and sparse recovery for earth mover distance. In *Proceedings of the forty-third annual ACM Symposium on Theory of Computing*, pages 627–636. ACM, 2011.

Piotr Indyk and Nitin Thaper. Fast image retrieval via embeddings. In *3rd International Workshop on Statistical and Computational Theories of Vision*, 2003.

Xianhua Jiang, Lipeng Ning, and Tryphon T Georgiou. Distances and Riemannian metrics for multivariate spectral densities. *IEEE Transactions on Automatic Control*, 57(7):1723–1735, 2012.

William B Johnson and Joram Lindenstrauss. Extensions of Lipschitz mappings into a Hilbert space. In *Conference in Modern Analysis and Probability (New Haven, Conn., 1982)*, volume 26 of *Contemporary Mathematics*, pages 189–206. American Mathematical Society, 1984.

Richard Jordan, David Kinderlehrer, and Felix Otto. The variational formulation of the Fokker-Planck equation. *SIAM Journal on Mathematical Analysis*, 29(1):1–17, 1998.

Leonid Kantorovich. On the transfer of masses (in russian). *Doklady Akademii Nauk*, 37(2):227–229, 1942.

LV Kantorovich and G.S. Rubinstein. On a space of totally additive functions. *Vestn Leningrad Universitet*, 13:52–59, 1958.

Hermann Karcher. Riemannian center of mass and so called Karcher mean. *arXiv preprint arXiv:1407.2087*, 2014.

Johan Karlsson and Axel Ringh. Generalized Sinkhorn iterations for regularizing inverse problems using optimal mass transport. *arXiv preprint arXiv:1612.02273*, 2016.

Sanggyun Kim, Rui Ma, Diego Mesa, and Todd P Coleman. Efficient bayesian inference methods via convex optimization and optimal transport. In *IEEE International Symposium on Information Theory*, pages 2259–2263. IEEE, 2013.

David Kinderlehrer and Noel J Walkington. Approximation of parabolic equations using the Wasserstein metric. *ESAIM: Mathematical Modelling and Numerical Analysis*, 33 (04):837–852, 1999.

Jun Kitagawa, Quentin Mérigot, and Boris Thibert. A Newton algorithm for semi-discrete optimal transport. *arXiv preprint arXiv:1603.05579*, 2016.

Philip A Knight. The Sinkhorn–Knopp algorithm: convergence and applications. *SIAM Journal on Matrix Analysis and Applications*, 30(1):261–275, 2008.

Philip A Knight and Daniel Ruiz. A fast algorithm for matrix balancing. *IMA Journal of Numerical Analysis*, 33(3):1029–1047, 2013.

Philip A Knight, Daniel Ruiz, and Bora Uccar. A symmetry preserving algorithm for matrix scaling. *SIAM Journal on Matrix Analysis and Applications*, 35(3):931–955, 2014.

Martin Knott and Cyril S Smith. On the optimal mapping of distributions. *Journal of Optimization Theory and Applications*, 43(1):39–49, 1984.

Martin Knott and Cyril S Smith. On a generalization of cyclic monotonicity and distances among random vectors. *Linear Algebra and Its Applications*, 199:363–371, 1994.

Soheil Kolouri, Yang Zou, and Gustavo K Rohde. Sliced Wasserstein kernels for probability distributions. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 5258–5267, 2016.

Soheil Kolouri, Se Rim Park, Matthew Thorpe, Dejan Slepcev, and Gustavo K Rohde. Optimal mass transport: signal processing and machine-learning applications. *IEEE Signal Processing Magazine*, 34(4):43–59, 2017.

Stanislav Kondratyev, Léonard Monsaingeon, and Dmitry Vofnikov. A new optimal transport distance on the space of finite Radon measures. *Advances in Differential Equations*, 21(11/12):1117–1164, 2016.

Tjalling C Koopmans. Optimum utilization of the transportation system. *Econometrica: Journal of the Econometric Society*, pages 136–146, 1949.

Jonathan Korman and Robert McCann. Optimal transportation with capacity constraints. *Transactions of the American Mathematical Society*, 367(3):1501–1521, 2015.

Bernhard Korte and Jens Vygen. *Combinatorial Optimization*. Springer, 2012.

JJ Kosowsky and Alan L Yuille. The invisible hand algorithm: Solving the assignment problem with statistical physics. *Neural networks*, 7(3):477–490, 1994.

J. Kruithof. Telefoonverkeersrekening. *De Ingenieur*, 52:E15–E25, 1937.

Harold W. Kuhn. The hungarian method for the assignment problem. *Naval Research Logistics Quarterly*, 2:83–97, 1955.

Brian Kulis. Metric learning: a survey. *Foundations and Trends in Machine Learning*, 5(4):287–364, 2012.

Matt Kusner, Yu Sun, Nicholas Kolkin, and Kilian Weinberger. From word embeddings to document distances. In *International Conference on Machine Learning*, pages 957–966, 2015.

Theo Lacombe, Marco Cuturi, and Steve Oudot. Large scale computation of means and clusters for persistence diagrams using optimal transport. *Advances in Neural Information Processing Systems 31*, pages 9792–9802, 2018.

Rongjie Lai and Hongkai Zhao. Multiscale nonrigid point cloud registration using rotation-invariant sliced-wasserstein distance via laplace–beltrami eigenmap. *SIAM Journal on Imaging Sciences*, 10(2):449–483, 2017.

Hugo Lavenant. Harmonic mappings valued in the Wasserstein space. *Preprint cvgmt 3649*, 2017.

Svetlana Lazebnik, Cordelia Schmid, and Jean Ponce. Beyond bags of features: Spatial pyramid matching for recognizing natural scene categories. In *IEEE Computer Society Conference on Computer Vision and Pattern Recognition*, volume 2, pages 2169–2178. IEEE, 2006.

Thibaut Le Gouic and Jean-Michel Loubes. Existence and consistency of Wasserstein barycenters. *Probability Theory and Related Fields*, 168:901–917, 2016.

Daniel D Lee and H Sebastian Seung. Learning the parts of objects by non-negative matrix factorization. *Nature*, 401(6755):788–791, 1999.

Jaeho Lee and Maxim Raginsky. Minimax statistical learning with wasserstein distances. In S. Bengio, H. Wallach, H. Larochelle, K. Grauman, N. Cesa-Bianchi, and R. Garnett, editors, *Advances in Neural Information Processing Systems 31*, pages 2692–2701. 2018.

William Leeb and Ronald Coifman. Hölder–Lipschitz norms and their duals on spaces with semigroups, with applications to earth mover's distance. *Journal of Fourier Analysis and Applications*, 22(4):910–953, 2016.

Jan Lellmann, Dirk A Lorenz, Carola Schönlieb, and Tuomo Valkonen. Imaging with Kantorovich–Rubinstein discrepancy. *SIAM Journal on Imaging Sciences*, 7(4):2833–2859, 2014.

Bas Lemmens and Roger Nussbaum. *Nonlinear Perron-Frobenius Theory*, volume 189. Cambridge University Press, 2012.

Christian Léonard. From the Schrödinger problem to the Monge–Kantorovich problem. *Journal of Functional Analysis*, 262(4):1879–1920, 2012.

Christian Léonard. A survey of the Schrödinger problem and some of its connections with optimal transport. *Discrete Continuous Dynamical Systems Series A*, 34(4): 1533–1574, 2014.

Bruno Lévy. A numerical algorithm for l^2 semi-discrete optimal transport in 3d. *ESAIM: Mathematical Modelling and Numerical Analysis*, 49(6):1693–1715, 2015.

Bruno Lévy and Erica L Schwindt. Notions of optimal transport theory and how to implement them on a computer. *Computers & Graphics*, 72:135–148, 2018.

Peihua Li, Qilong Wang, and Lei Zhang. A novel earth mover's distance methodology for image matching with Gaussian mixture models. In *Proceedings of the IEEE International Conference on Computer Vision*, pages 1689–1696, 2013.

Wuchen Li, Ernest K. Ryu, Stanley Osher, Wotao Yin, and Wilfrid Gangbo. A parallel method for Earth Mover's distance. *Journal of Scientific Computing*, 75(1):182–197, 2018a.

Yupeng Li, Wuchen Li, and Guo Cao. Image segmentation via l^1 monge-kantorovich problem. *CAM report 17-73*, 2018b.

Matthias Liero, Alexander Mielke, and Giuseppe Savaré. Optimal transport in competition with reaction: the Hellinger–Kantorovich distance and geodesic curves. *SIAM Journal on Mathematical Analysis*, 48(4):2869–2911, 2016.

Matthias Liero, Alexander Mielke, and Giuseppe Savaré. Optimal entropy-transport problems and a new hellinger–kantorovich distance between positive measures. *Inventiones Mathematicae*, 211(3):969–1117, 2018.

Haibin Ling and Kazunori Okada. Diffusion distance for histogram comparison. In *IEEE Computer Society Conference on Computer Vision and Pattern Recognition*, volume 1, pages 246–253. IEEE, 2006.

Haibin Ling and Kazunori Okada. An efficient earth mover's distance algorithm for robust histogram comparison. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 29(5):840–853, 2007.

Nathan Linial, Alex Samorodnitsky, and Avi Wigderson. A deterministic strongly polynomial algorithm for matrix scaling and approximate permanents. In *Proceedings of the Thirtieth Annual ACM Symposium on Theory of Computing*, pages 644–652.

ACM, 1998.

Pierre-Louis Lions and Bertrand Mercier. Splitting algorithms for the sum of two nonlinear operators. *SIAM Journal on Numerical Analysis*, 16:964–979, 1979.

Don O Loftsgaarden and Charles P Quesenberry. A nonparametric estimate of a multivariate density function. *Annals of Mathematical Statistics*, 36(3):1049–1051, 1965.

Eliane Maria Loiola, Nair Maria Maia de Abreu, Paulo Oswaldo Boaventura-Netto, Peter Hahn, and Tania Querido. A survey for the quadratic assignment problem. *European Journal Operational Research*, 176(2):657–690, 2007.

Vince Lyzinski, Donniell E Fishkind, Marcelo Fiori, Joshua T Vogelstein, Carey E Priebe, and Guillermo Sapiro. Graph matching: relax at your own risk. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 38(1):60–73, 2016.

Jan Maas. Gradient flows of the entropy for finite Markov chains. *Journal of Functional Analysis*, 261(8):2250–2292, 2011.

Jan Maas, Martin Rumpf, Carola Schönlieb, and Stefan Simon. A generalized model for optimal transport of images including dissipation and density modulation. *ESAIM: Mathematical Modelling and Numerical Analysis*, 49(6):1745–1769, 2015.

Jan Maas, Martin Rumpf, and Stefan Simon. Generalized optimal transport with singular sources. *arXiv preprint arXiv:1607.01186*, 2016.

Yasushi Makihara and Yasushi Yagi. Earth mover's morphing: Topology-free shape morphing using cluster-based EMD flows. In *Asian Conference on Computer Vision*, pages 202–215. Springer, 2010.

Luigi Malagò, Luigi Montrucchio, and Giovanni Pistone. Wasserstein riemannian geometry of positive-definite matrices. *arXiv preprint arXiv:1801.09269*, 2018.

Anton Mallasto and Aasa Feragen. Learning from uncertain curves: The 2-wasserstein metric for gaussian processes. In I. Guyon, U. V. Luxburg, S. Bengio, H. Wallach, R. Fergus, S. Vishwanathan, and R. Garnett, editors, *Advances in Neural Information Processing Systems 30*, pages 5660–5670. 2017.

Stephane Mallat. *A Wavelet Tour of Signal Processing: the Sparse Way*. Academic press, 2008.

Benjamin Mathon, Francois Cayre, Patrick Bas, and Benoit Macq. Optimal transport for secure spread-spectrum watermarking of still images. *IEEE Transactions on Image Processing*, 23(4):1694–1705, 2014.

Daniel Matthes and Horst Osberger. Convergence of a variational Lagrangian scheme for

a nonlinear drift diffusion equation. *ESAIM: Mathematical Modelling and Numerical Analysis*, 48(3):697–726, 2014.

Daniel Matthes and Horst Osberger. A convergent lagrangian discretization for a nonlinear fourth-order equation. *Foundations of Computational Mathematics*, 17(1):73–126, 2017.

Bertrand Maury and Anthony Preux. Pressureless Euler equations with maximal density constraint: a time-splitting scheme. *Topological Optimization and Optimal Transport: In the Applied Sciences*, 17:333, 2017.

Bertrand Maury, Aude Roudneff-Chupin, and Filippo Santambrogio. A macroscopic crowd motion model of gradient flow type. *Mathematical Models and Methods in Applied Sciences*, 20(10):1787–1821, 2010.

Robert J McCann. A convexity principle for interacting gases. *Advances in Mathematics*, 128(1):153–179, 1997.

Facundo Mémoli. On the use of Gromov–Hausdorff distances for shape comparison. In *Symposium on Point Based Graphics*, pages 81–90. 2007.

Facundo Mémoli. Gromov–Wasserstein distances and the metric approach to object matching. *Foundations of Computational Mathematics*, 11(4):417–487, 2011.

Facundo Mémoli and Guillermo Sapiro. A theoretical and computational framework for isometry invariant recognition of point cloud data. *Foundations of Computational Mathematics*, 5(3):313–347, 2005.

Quentin Mérigot. A multiscale approach to optimal transport. *Computer Graphics Forum*, 30(5):1583–1592, 2011.

Ludovic Métivier, Romain Brossier, Quentin Merigot, Edouard Oudet, and Jean Virieux. An optimal transport approach for seismic tomography: Application to 3D full waveform inversion. *Inverse Problems*, 32(11):115008, 2016.

Jocelyn Meyron, Quentin Mérigot, and Boris Thibert. Light in power: a general and parameter-free algorithm for caustic design. In *SIGGRAPH Asia 2018 Technical Papers*, page 224. ACM, 2018.

Alexander Mielke. Geodesic convexity of the relative entropy in reversible Markov chains. *Calculus of Variations and Partial Differential Equations*, 48(1-2):1–31, 2013.

Tomas Mikolov, Kai Chen, Greg Corrado, and Jeffrey Dean. Efficient estimation of word representations in vector space. *arXiv preprint arXiv:1301.3781*, 2013.

Jean-Marie Mirebeau. Discretization of the 3D Monge-Ampere operator, between wide

stencils and power diagrams. *ESAIM: Mathematical Modelling and Numerical Analysis*, 49(5):1511–1523, 2015.

Gaspard Monge. Mémoire sur la théorie des déblais et des remblais. *Histoire de l'Académie Royale des Sciences*, pages 666–704, 1781.

Grégoire Montavon, Klaus-Robert Müller, and Marco Cuturi. Wasserstein training of restricted Boltzmann machines. In D. D. Lee, M. Sugiyama, U. V. Luxburg, I. Guyon, and R. Garnett, editors, *Advances in Neural Information Processing Systems 29*, pages 3718–3726. 2016.

Kevin Moon and Alfred Hero. Multivariate f-divergence estimation with confidence. In *Advances in Neural Information Processing Systems*, pages 2420–2428, 2014.

Oleg Museyko, Michael Stiglmayr, Kathrin Klamroth, and Günter Leugering. On the application of the Monge–Kantorovich problem to image registration. *SIAM Journal on Imaging Sciences*, 2(4):1068–1097, 2009.

Boris Muzellec and Marco Cuturi. Generalizing point embeddings using the wasserstein space of elliptical distributions. In S. Bengio, H. Wallach, H. Larochelle, K. Grauman, N. Cesa-Bianchi, and R. Garnett, editors, *Advances in Neural Information Processing Systems 31*, pages 10258–10269. 2018.

Boris Muzellec, Richard Nock, Giorgio Patrini, and Frank Nielsen. Tsallis regularized optimal transport and ecological inference. In *AAAI*, pages 2387–2393, 2017.

Andriy Myronenko and Xubo Song. Point set registration: coherent point drift. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 32(12):2262–2275, 2010.

Assaf Naor and Gideon Schechtman. Planar earthmover is not in l_1. *SIAM Journal on Computing*, 37(3):804–826, 2007.

Richard D Neidinger. Introduction to automatic differentiation and Matlab object-oriented programming. *SIAM Review*, 52(3):545–563, 2010.

Arkadi Nemirovski and Uriel Rothblum. On complexity of matrix scaling. *Linear Algebra and its Applications*, 302:435–460, 1999.

Yurii Nesterov and Arkadii Nemirovskii. *Interior-point polynomial algorithms in convex programming*, volume 13. SIAM, 1994.

Kangyu Ni, Xavier Bresson, Tony Chan, and Selim Esedoglu. Local histogram based segmentation using the Wasserstein distance. *International Journal of Computer Vision*, 84(1):97–111, 2009.

Lipeng Ning and Tryphon T Georgiou. Metrics for matrix-valued measures via test

functions. In *53rd IEEE Conference on Decision and Control*, pages 2642–2647. IEEE, 2014.

Lipeng Ning, Tryphon T Georgiou, and Allen Tannenbaum. On matrix-valued Monge–Kantorovich optimal mass transport. *IEEE Transactions on Automatic Control*, 60 (2):373–382, 2015.

Jorge Nocedal and Stephen J Wright. *Numerical Optimization*. Springer-Verlag, 1999.

Adam M Oberman and Yuanlong Ruan. An efficient linear programming method for optimal transportation. *arXiv preprint arXiv:1509.03668*, 2015.

Vladimir Oliker and Laird D Prussner. On the numerical solution of the equation $\frac{\partial^2 z}{\partial x^2}\frac{\partial^2 z}{\partial y^2} - \left(\frac{\partial^2 z}{\partial x \partial y}\right)^2 = f$ and its discretizations, I. *Numerische Mathematik*, 54(3):271–293, 1989.

Aude Oliva and Antonio Torralba. Modeling the shape of the scene: a holistic representation of the spatial envelope. *International Journal of Computer Vision*, 42(3): 145–175, 2001.

Dean S Oliver. Minimization for conditional simulation: Relationship to optimal transport. *Journal of Computational Physics*, 265:1–15, 2014.

James B. Orlin. A polynomial time primal network simplex algorithm for minimum cost flows. *Mathematical Programming*, 78(2):109–129, 1997.

Ferdinand Österreicher and Igor Vajda. A new class of metric divergences on probability spaces and its applicability in statistics. *Annals of the Institute of Statistical Mathematics*, 55(3):639–653, 2003.

Felix Otto. The geometry of dissipative evolution equations: the porous medium equation. *Communications in Partial Differential Equations*, 26(1-2):101–174, 2001.

Art B Owen. *Empirical Likelihood*. Wiley Online Library, 2001.

Sinno Jialin Pan and Qiang Yang. A survey on transfer learning. *IEEE Transactions on knowledge and data engineering*, 22(10):1345–1359, 2010.

Victor M Panaretos and Yoav Zemel. Amplitude and phase variation of point processes. *Annals of Statistics*, 44(2):771–812, 2016.

Nicolas Papadakis, Gabriel Peyré, and Edouard Oudet. Optimal transport with proximal splitting. *SIAM Journal on Imaging Sciences*, 7(1):212–238, 2014.

Brendan Pass. On the local structure of optimal measures in the multi-marginal optimal transportation problem. *Calculus of Variations and Partial Differential Equations*, 43(3-4):529–536, 2012.

Brendan Pass. Multi-marginal optimal transport: theory and applications. *ESAIM: Mathematical Modelling and Numerical Analysis*, 49(6):1771–1790, 2015.

Ofir Pele and Ben Taskar. The tangent earth mover's distance. In *Geometric Science of Information*, pages 397–404. Springer, 2013.

Ofir Pele and Michael Werman. A linear time histogram metric for improved sift matching. *Computer Vision–ECCV 2008*, pages 495–508, 2008.

Ofir Pele and Michael Werman. Fast and robust earth mover's distances. In *IEEE 12th International Conference on Computer Vision*, pages 460–467, 2009.

Benoît Perthame, Fernando Quirós, and Juan Luis Vázquez. The Hele-Shaw asymptotics for mechanical models of tumor growth. *Archive for Rational Mechanics and Analysis*, 212(1):93–127, 2014.

Gabriel Peyré. Entropic approximation of Wasserstein gradient flows. *SIAM Journal on Imaging Sciences*, 8(4):2323–2351, 2015.

Gabriel Peyré, Jalal Fadili, and Julien Rabin. Wasserstein active contours. In *19th IEEE International Conference on Image Processing*, pages 2541–2544. IEEE, 2012.

Gabriel Peyré, Marco Cuturi, and Justin Solomon. Gromov-Wasserstein averaging of kernel and distance matrices. In *International Conference on Machine Learning*, pages 2664–2672, 2016.

Gabriel Peyré, Lenaic Chizat, Francois-Xavier Vialard, and Justin Solomon. Quantum entropic regularization of matrix-valued optimal transport. *to appear in European Journal of Applied Mathematics*, 2017.

Rémi Peyre. Comparison between w_2 distance and h^{-1} norm, and localisation of Wasserstein distance. *arXiv preprint arXiv:1104.4631*, 2011.

Benedetto Piccoli and Francesco Rossi. Generalized Wasserstein distance and its application to transport equations with source. *Archive for Rational Mechanics and Analysis*, 211(1):335–358, 2014.

Franccois Pitié, Anil C Kokaram, and Rozenn Dahyot. Automated colour grading using colour distribution transfer. *Computer Vision and Image Understanding*, 107(1): 123–137, 2007.

Pytorch. Pytorch library. *http://pytorch.org/*, 2017.

Julien Rabin and Nicolas Papadakis. Convex color image segmentation with optimal transport distances. In *Proceedings of SSVM'15*, pages 256–269, 2015.

Julien Rabin, Gabriel Peyré, Julie Delon, and Marc Bernot. Wasserstein barycenter

and its application to texture mixing. In *International Conference on Scale Space and Variational Methods in Computer Vision*, pages 435–446. Springer, 2011.

Svetlozar T Rachev and Ludger Rüschendorf. *Mass Transportation Problems: Volume I: Theory*. Springer Science & Business Media, 1998a.

Svetlozar T Rachev and Ludger Rüschendorf. *Mass Transportation Problems: Volume II: Applications*. Springer Science & Business Media, 1998b.

Louis B Rall. *Automatic Differentiation: Techniques and Applications*. Springer, 1981.

Aaditya Ramdas, Nicolás García Trillos, and Marco Cuturi. On Wasserstein two-sample testing and related families of nonparametric tests. *Entropy*, 19(2):47, 2017.

Anand Rangarajan, Alan L Yuille, Steven Gold, and Eric Mjolsness. Convergence properties of the softassign quadratic assignment algorithm. *Neural Computation*, 11 (6):1455–1474, August 1999.

Sebastian Reich. A nonparametric ensemble transform method for bayesian inference. *SIAM Journal on Scientific Computing*, 35(4):A2013–A2024, 2013.

R Tyrrell Rockafellar. Monotone operators and the proximal point algorithm. *SIAM Journal on Control and Optimization*, 14(5):877–898, 1976.

Antoine Rolet, Marco Cuturi, and Gabriel Peyré. Fast dictionary learning with a smoothed Wasserstein loss. In *Proceedings of the 19th International Conference on Artificial Intelligence and Statistics*, volume 51 of *Proceedings of Machine Learning Research*, pages 630–638, 2016.

Yossi Rubner, Carlo Tomasi, and Leonidas J Guibas. The earth mover's distance as a metric for image retrieval. *International Journal of Computer Vision*, 40(2):99–121, 2000.

Ludger Ruschendorf. Convergence of the iterative proportional fitting procedure. *Annals of Statistics*, 23(4):1160–1174, 1995.

Lüdger Rüschendorf and Svetlozar T Rachev. A characterization of random variables with minimum l2-distance. *Journal of Multivariate Analysis*, 32(1):48–54, 1990.

Ludger Rüschendorf and Wolfgang Thomsen. Closedness of sum spaces and the generalized Schrodinger problem. *Theory of Probability and its Applications*, 42(3):483–494, 1998.

Ludger Rüschendorf and Ludger Uckelmann. On the n-coupling problem. *Journal of Multivariate Analysis*, 81(2):242–258, 2002.

Ernest K. Ryu, Yongxin Chen, Wuchen Li, and Stanley Osher. Vector and matrix opti-

mal mass transport: theory, algorithm, and applications. *SIAM Journal on Scientific Compututing*, 40(5):A3675–A3698, 2017a.

Ernest K. Ryu, Wuchen Li, Penghang Yin, and Stanley Osher. Unbalanced and partial l^1 Monge-Kantorovich problem: a scalable parallel first-order method. *Journal of Scientific Computing*, 75(3):1596–1613, 2017b.

Tim Salimans, Han Zhang, Alec Radford, and Dimitris Metaxas. Improving GANs using optimal transport. In *International Conference on Learning Representations*, 2018.

Hans Samelson et al. On the perron-frobenius theorem. *Michigan Mathematical Journal*, 4(1):57–59, 1957.

Roman Sandler and Michael Lindenbaum. Nonnegative matrix factorization with earth mover's distance metric for image analysis. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 33(8):1590–1602, 2011.

Filippo Santambrogio. *Optimal transport for applied mathematicians*. Birkhauser, 2015.

Filippo Santambrogio. {Euclidean, metric, and Wasserstein} gradient flows: an overview. *Bulletin of Mathematical Sciences*, 7(1):87–154, 2017.

Filippo Santambrogio. Crowd motion and population dynamics under density constraints. *GMT preprint 3728*, 2018.

Louis-Philippe Saumier, Boualem Khouider, and Martial Agueh. Optimal transport for particle image velocimetry. *Communications in Mathematical Sciences*, 13(1): 269–296, 2015.

Geoffrey Schiebinger, Jian Shu, Marcin Tabaka, Brian Cleary, Vidya Subramanian, Aryeh Solomon, Siyan Liu, Stacie Lin, Peter Berube, Lia Lee, et al. Reconstruction of developmental landscapes by optimal-transport analysis of single-cell gene expression sheds light on cellular reprogramming. *bioRxiv*, page 191056, 2017.

Bernhard Schmitzer. A sparse multiscale algorithm for dense optimal transport. *Journal of Mathematical Imaging and Vision*, 56(2):238–259, 2016a.

Bernhard Schmitzer. Stabilized sparse scaling algorithms for entropy regularized transport problems. *arXiv preprint arXiv:1610.06519*, 2016b.

Bernhard Schmitzer and Christoph Schnörr. Modelling convex shape priors and matching based on the Gromov-Wasserstein distance. *Journal of Mathematical Imaging and Vision*, 46(1):143–159, 2013a.

Bernhard Schmitzer and Christoph Schnörr. Object segmentation by shape matching with Wasserstein modes. In *International Workshop on Energy Minimization Methods*

in Computer Vision and Pattern Recognition, pages 123–136. Springer, 2013b.

Bernhard Schmitzer and Benedikt Wirth. A framework for Wasserstein-1-type metrics. *arXiv preprint arXiv:1701.01945*, 2017.

Isaac J Schoenberg. Metric spaces and positive definite functions. *Transactions of the American Mathematical Society*, 38:522–356, 1938.

Bernhard Schölkopf and Alexander J Smola. *Learning with Kernels: Support Vector Machines, Regularization, Optimization, and Beyond*. MIT Press, 2002.

Erwin Schrödinger. Über die Umkehrung der Naturgesetze. *Sitzungsberichte Preuss. Akad. Wiss. Berlin. Phys. Math.*, 144:144–153, 1931.

Vivien Seguy and Marco Cuturi. Principal geodesic analysis for probability measures under the optimal transport metric. In *Advances in Neural Information Processing Systems 28*, pages 3294–3302. 2015.

Vivien Seguy, Bharath Bhushan Damodaran, Rémi Flamary, Nicolas Courty, Antoine Rolet, and Mathieu Blondel. Large-scale optimal transport and mapping estimation. In *Proceedings of ICLR 2018*, 2018.

Soroosh Shafieezadeh Abadeh, Peyman Mohajerin Mohajerin Esfahani, and Daniel Kuhn. Distributionally robust logistic regression. In C. Cortes, N. D. Lawrence, D. D. Lee, M. Sugiyama, and R. Garnett, editors, *Advances in Neural Information Processing Systems 28*, pages 1576–1584. 2015.

Soroosh Shafieezadeh Abadeh, Viet Anh Nguyen, Daniel Kuhn, and Peyman Mohajerin Mohajerin Esfahani. Wasserstein distributionally robust kalman filtering. In S. Bengio, H. Wallach, H. Larochelle, K. Grauman, N. Cesa-Bianchi, and R. Garnett, editors, *Advances in Neural Information Processing Systems 31*, pages 8483–8492. 2018.

Sameer Shirdhonkar and David W Jacobs. Approximate earth mover's distance in linear time. In *IEEE Conference on Computer Vision and Pattern Recognition*, pages 1–8. IEEE, 2008.

Bernard W Silverman. *Density Estimation for Statistics and Data Analysis*, volume 26. CRC press, 1986.

Richard Sinkhorn. A relationship between arbitrary positive matrices and doubly stochastic matrices. *Annals of Mathematical Statististics*, 35:876–879, 1964.

Marcos Slomp, Michihiro Mikamo, Bisser Raytchev, Toru Tamaki, and Kazufumi Kaneda. Gpu-based softassign for maximizing image utilization in photomosaics. *International Journal of Networking and Computing*, 1(2):211–229, 2011.

Justin Solomon, Leonidas Guibas, and Adrian Butscher. Dirichlet energy for analysis and synthesis of soft maps. In *Computer Graphics Forum*, volume 32, pages 197–206. Wiley Online Library, 2013.

Justin Solomon, Raif Rustamov, Leonidas Guibas, and Adrian Butscher. Earth mover's distances on discrete surfaces. *Transaction on Graphics*, 33(4), 2014a.

Justin Solomon, Raif Rustamov, Guibas Leonidas, and Adrian Butscher. Wasserstein propagation for semi-supervised learning. In *Proceedings of the 31st International Conference on Machine Learning*, pages 306–314, 2014b.

Justin Solomon, Fernando De Goes, Gabriel Peyré, Marco Cuturi, Adrian Butscher, Andy Nguyen, Tao Du, and Leonidas Guibas. Convolutional Wasserstein distances: efficient optimal transportation on geometric domains. *ACM Transactions on Graphics*, 34(4):66:1–66:11, 2015.

Justin Solomon, Gabriel Peyré, Vladimir G Kim, and Suvrit Sra. Entropic metric alignment for correspondence problems. *ACM Transactions on Graphics*, 35(4):72:1–72:13, 2016a.

Justin Solomon, Raif Rustamov, Leonidas Guibas, and Adrian Butscher. Continuous-flow graph transportation distances. *arXiv preprint arXiv:1603.06927*, 2016b.

Max Sommerfeld and Axel Munk. Inference for empirical wasserstein distances on finite spaces. *Journal of the Royal Statistical Society: Series B (Statistical Methodology)*, 80(1):219–238, 2018.

Bharath K Sriperumbudur, Kenji Fukumizu, Arthur Gretton, Bernhard Schölkopf, and Gert RG Lanckriet. On integral probability metrics,φ-divergences and binary classification. *arXiv preprint arXiv:0901.2698*, 2009.

Bharath K Sriperumbudur, Kenji Fukumizu, Arthur Gretton, Bernhard Schölkopf, and Gert RG Lanckriet. On the empirical estimation of integral probability metrics. *Electronic Journal of Statistics*, 6:1550–1599, 2012.

Sanvesh Srivastava, Volkan Cevher, Quoc Dinh, and David Dunson. WASP: Scalable Bayes via barycenters of subset posteriors. In Guy Lebanon and S. V. N. Vishwanathan, editors, *Proceedings of the Eighteenth International Conference on Artificial Intelligence and Statistics*, volume 38 of *Proceedings of Machine Learning Research*, pages 912–920, San Diego, California, USA, 2015a. PMLR. URL http://proceedings.mlr.press/v38/srivastava15.html.

Sanvesh Srivastava, Volkan Cevher, Quoc Dinh, and David Dunson. WASP: scalable bayes via barycenters of subset posteriors. In *Artificial Intelligence and Statistics*, pages 912–920, 2015b.

Matthew Staib, Sebastian Claici, Justin M Solomon, and Stefanie Jegelka. Parallel streaming wasserstein barycenters. In I. Guyon, U. V. Luxburg, S. Bengio, H. Wallach, R. Fergus, S. Vishwanathan, and R. Garnett, editors, *Advances in Neural Information Processing Systems 30*, pages 2647–2658. 2017a.

Matthew Staib, Sebastian Claici, Justin M Solomon, and Stefanie Jegelka. Parallel streaming wasserstein barycenters. In I. Guyon, U. V. Luxburg, S. Bengio, H. Wallach, R. Fergus, S. Vishwanathan, and R. Garnett, editors, *Advances in Neural Information Processing Systems 30*, pages 2647–2658. 2017b.

Leen Stougie. A polynomial bound on the diameter of the transportation polytope. Technical report, TU/e, Technische Universiteit Eindhoven, Department of Mathematics and Computing Science, 2002.

Karl-Theodor Sturm. The space of spaces: curvature bounds and gradient flows on the space of metric measure spaces. Preprint 1208.0434, arXiv, 2012.

Zhengyu Su, Yalin Wang, Rui Shi, Wei Zeng, Jian Sun, Feng Luo, and Xianfeng Gu. Optimal mass transport for shape matching and comparison. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 37(11):2246–2259, 2015.

Vladimir N Sudakov. *Geometric Problems in the Theory of Infinite-dimensional Probability Distributions*. Number 141. American Mathematical Society, 1979.

Mahito Sugiyama, Hiroyuki Nakahara, and Koji Tsuda. Tensor balancing on statistical manifold. *arXiv preprint arXiv:1702.08142*, 2017.

Mohamed M Sulman, JF Williams, and Robert D Russell. An efficient approach for the numerical solution of the monge–ampère equation. *Applied Numerical Mathematics*, 61(3):298–307, 2011.

Paul Swoboda and Christoph Schnörr. Convex variational image restoration with histogram priors. *SIAM Journal on Imaging Sciences*, 6(3):1719–1735, 2013.

Gábor J Székely and Maria L Rizzo. Testing for equal distributions in high dimension. *InterStat*, 5(16.10), 2004.

Asuka Takatsu. Wasserstein geometry of Gaussian measures. *Osaka Journal of Mathematics*, 48(4):1005–1026, 2011.

Xiaolu Tan and Nizar Touzi. Optimal transportation under controlled stochastic dynamics. *Annals of Probability*, 41(5):3201–3240, 2013.

Robert E. Tarjan. Dynamic trees as search trees via euler tours, applied to the network simplex algorithm. *Mathematical Programming*, 78(2):169–177, 1997.

Guillaume Tartavel, Gabriel Peyré, and Yann Gousseau. Wasserstein loss for image synthesis and restoration. *SIAM Journal on Imaging Sciences*, 9(4):1726–1755, 2016.

Matthew Thorpe, Serim Park, Soheil Kolouri, Gustavo K Rohde, and Dejan Slepčev. A transportation l^p distance for signal analysis. *Journal of Mathematical Imaging and Vision*, 59(2):187–210, 2017.

AN Tolstoı. Metody nakhozhdeniya naimen'shego summovogo kilome-trazha pri planirovanii perevozok v prostranstve (russian; methods of finding the minimal total kilometrage in cargo transportation planning in space). *TransPress of the National Commissariat of Transportation*, pages 23–55, 1930.

AN Tolstoı. Metody ustraneniya neratsional'nykh perevozok priplanirovanii [russian; methods of removing irrational transportation in planning]. *Sotsialisticheskiı Transport*, 9:28–51, 1939.

Alain Trouvé and Laurent Younes. Metamorphoses through Lie group action. *Foundations of Computational Mathematics*, 5(2):173–198, 2005.

Neil S Trudinger and Xu-Jia Wang. On the monge mass transfer problem. *Calculus of Variations and Partial Differential Equations*, 13(1):19–31, 2001.

Marc Vaillant and Joan Glaunès. Surface matching via currents. In *Information Processing in Medical Imaging*, pages 1–5. Springer, 2005.

Sathamangalam R Srinivasa Varadhan. On the behavior of the fundamental solution of the heat equation with variable coefficients. *Communications on Pure and Applied Mathematics*, 20(2):431–455, 1967.

Cedric Villani. *Topics in Optimal Transportation*. Graduate Studies in Mathematics Series. American Mathematical Society, 2003. ISBN 9780821833124.

Cedric Villani. *Optimal Transport: Old and New*, volume 338. Springer Verlag, 2009.

Thomas Vogt and Jan Lellmann. Measure-valued variational models with applications to diffusion-weighted imaging. *Journal of Mathematical Imaging and Vision*, 60(9): 1482–1502, 2018.

Fan Wang and Leonidas J Guibas. Supervised earth mover's distance learning and its computer vision applications. *ECCV2012*, pages 442–455, 2012.

Wei Wang, John A. Ozolek, Dejan Slepcev, Ann B. Lee, Cheng Chen, and Gustavo K. Rohde. An optimal transportation approach for nuclear structure-based pathology. *IEEE Transactions on Medical Imaging*, 30(3):621–631, 2011.

Wei Wang, Dejan Slepčev, Saurav Basu, John A Ozolek, and Gustavo K Rohde. A

linear optimal transportation framework for quantifying and visualizing variations in sets of images. *International Journal of Computer Vision*, 101(2):254–269, 2013.

Jonathan Weed and Francis Bach. Sharp asymptotic and finite-sample rates of convergence of empirical measures in Wasserstein distance. *arXiv preprint arXiv:1707.00087*, 2017.

Kilian Q Weinberger and Lawrence K Saul. Distance metric learning for large margin nearest neighbor classification. *Journal of Machine Learning Research*, 10:207–244, 2009.

Michael Westdickenberg and Jon Wilkening. Variational particle schemes for the porous medium equation and for the system of isentropic Euler equations. *ESAIM: Mathematical Modelling and Numerical Analysis*, 44(1):133–166, 2010.

Alan Geoffrey Wilson. The use of entropy maximizing models, in the theory of trip distribution, mode split and route split. *Journal of Transport Economics and Policy*, pages 108–126, 1969.

Gui-Song Xia, Sira Ferradans, Gabriel Peyré, and Jean-Franccois Aujol. Synthesizing and mixing stationary Gaussian texture models. *SIAM Journal on Imaging Sciences*, 7(1):476–508, 2014.

G Udny Yule. On the methods of measuring association between two attributes. *Journal of the Royal Statistical Society*, 75(6):579–652, 1912.

Yoav Zemel and Victor M Panaretos. Fréchet means and procrustes analysis in wasserstein space. *to appear in Bernoulli*, 2018.

Gloria Zen, Elisa Ricci, and Nicu Sebe. Simultaneous ground metric learning and matrix factorization with earth mover's distance. *Proceedings of ICPR'14*, pages 3690–3695, 2014.

Lei Zhu, Yan Yang, Steven Haker, and Allen Tannenbaum. An image morphing technique based on optimal mass preserving mapping. *IEEE Transactions on Image Processing*, 16(6):1481–1495, 2007.

Jonathan Zinsl and Daniel Matthes. Transport distances and geodesic convexity for systems of degenerate diffusion equations. *Calculus of Variations and Partial Differential Equations*, 54(4):3397–3438, 2015.

Appendix A

术语索引

中文术语	英文术语	页码
最优传输	optimal transport，OT	1
直方图	histogram	5
概率向量	probability vector	5
概率单纯形	probability simplex	5
离散测度	discrete measure	5
Radon 测度	Radon measure	5
最优指派问题	optimal assignment problem	6
推前算子	push-forward operator	8
拉回	pull-back	9
质量分裂	mass splitting	10
耦合矩阵	coupling matrix	10
p-Wasserstein 距离	p-Wasserstein distance	15
弱收敛	weak convergence	17
Kantorovich 势	Kantorovich potential	18
Lagrange 对偶函数	Lagrange dual function	31
C-变换	**C**-transform	32
互补	complementary	33
极点	extreme point	34
西北角法则	north-west corner rule	35
网络单纯形法	network simplex	36
对偶上升	dual ascent	40
平衡边	balanced edge	40
原始–对偶方法	primal-dual method	41
拍卖算法	auction algorithm	43

中文术语	英文术语	页码
ε-缩放	ε-scaling	45
熵正则化	entropic regularization	46
离散熵	discrete entropy	46
Kullback–Leibler 散度	Kullback–Leibler divergence	47
相对熵	relative entropy	49
静态 Schrödinger 问题	static Schrödinger problem	49
互信息	mutual information	49
联结函数	copula	50
矩阵缩放	matrix scaling	51
Sinkhorn 算法	Sinkhorn's algorithm	51
近端点算法	proximal point algorithm	53
重心投影	barycentric projection	54
Hilbert 射影度量	Hilbert projective metric	55
块坐标上升	block coordinate ascent	62
软最小值	soft-minimum	62
指数和的对数	log-sum-exp	63
Sinkhorn 散度	Sinkhorn divergence	64
指示函数	indicator function	66
近端算子	proximal operator	66
Laguerre 单元	Laguerre cell	67
半离散最优传输	semidiscrete optimal transport	67
下确界卷积	inf-convolution	67
幂图	power diagram	69
单位分解	partition of unity	71
随机梯度下降	stochastic gradient descent	73
带平均的随机梯度下降	stochastic gradient descent with averaging	73
最小费用流	minimum-cost flow	75
Beckmann 表述	Beckmann formulation	77
位移插值	displacement interpolation	79
交错网格	staggered grid	81

中文术语	英文术语	页码
迁移率函数	mobility function	85
熵函数	entropy function	88
积分概率度量	integral probability metric	93
平坦范数	flat norm	94
再生核 Hilbert 空间	reproducing kernel Hilbert space	94
最大均值差异	maximum mean discrepancy	94
能量距离	energy distance	97
Hilbert 型距离	Hilbertian distance	97
样本复杂度	sample complexity	100
Euler 型离散化	Eulerian discretization	106
Lagrange 型离散化	Lagrangian discretization	106
Fréchet 均值	Fréchet mean	108
Wasserstein 重心	Wasserstein barycenter	108
JKO 流	JKO flow	117
最小 Kantorovich 估计器	minimum Kantorovich estimator	123
多边缘问题	multimarginal problem	124
Gaussian–Hellinger 距离	Gaussian–Hellinger distance	127
Wasserstein–Fisher–Rao 距离	Wasserstein–Fisher–Rao distance	127
鞅传输	martingale transport	129
切片 Wasserstein 距离	sliced Wasserstein distance	129
滤波反投影	filtered backprojection	130
向量值测度	vector-valued measure	132
Hausdorff 距离	Hausdorff distance	134
Gromov–Hausdorff 距离	Gromov–Hausdorff distance	135
Gromov–Wasserstein 距离	Gromov–Wasserstein distance	136